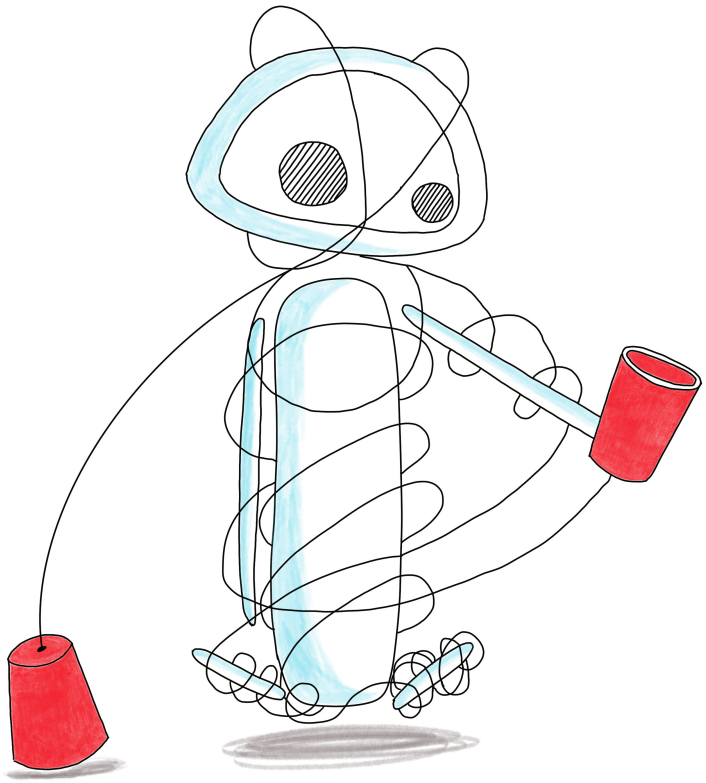


本材料将由剑桥大学出版社出版，书名为Yury Polyanskiy和Yihong Wu所著的《信息理论》。此预出版版本仅供个人查看和下载使用，不得再分发、转售或用于衍生作品中。

请注意，虽然此版本有匹配的公式编号、定理等，但印刷版将更正许多错别字。我们建议使用此版本进行深入阅读，而免费版本可用于快速参考查阅。

波利安斯基与吴 © 2023

书籍标题

本教材以适合高年级本科生和研究生的水平介绍信息论学科。它既发展了经典香农理论，也介绍了统计学习中的最新应用。全书分为六个部分，涵盖信息度量的基础；数据压缩；假设检验与大偏差理论；信道编码与信道容量；率失真与度量熵；最后是统计应用。书中包含超过210道习题，帮助读者深化知识并了解最新发现。

尤里·波利安斯基是麻省理工学院电气工程与计算机科学教授，也是信息与决策系统实验室（LIDS）和统计与数据科学中心（SDSC）的成员。他于2024年当选IEEE会士，获得了2020年IEEE信息论学会詹姆斯·马西奖，并合著了获得IEEE信息论学会（2011年）、IEEE国际信息论研讨会（2008年、2010年、2022年）和学习理论会议（2021年）最佳论文奖的论文。在麻省理工学院，他教授信息论、概率、统计和机器学习课程。

吴一宏是耶鲁大学统计与数据科学系的教授。他是2011年马可尼学会保罗·巴兰青年学者奖、2017年美国国家科学基金会职业奖、2018年斯隆数学研究奖学金以及2023年IMS会士的获得者。他曾在耶鲁大学和伊利诺伊大学厄巴纳-香槟分校教授概率论、统计学和信息论课程。

信息论

从编码到学习

FIRST EDITION

尤里·波利安斯基
麻省理工学院电气工程与计算机科学系

易鸿昊

Department of Statistics and Data Science
Yale University

CAMBRIDGE
UNIVERSITY PRESS

CAMBRIDGE
UNIVERSITY PRESS

剑桥大学出版社，剑桥 CB2 8BS，英国

美国纽约州纽约市自由广场一号20楼，邮编10006

477 Williamstown Road, Port Melbourne, VIC 3207, 澳大利亚

314–321，3楼，3号地块，Splendor Forum，Jasola区中心，新德里 – 110025，印度

79 安顺路， #06–04/06， 新加坡 079906

剑桥大学出版社是剑桥大学的一部分。

它通过在国际最高卓越水平上传播知识，追求教育、学习和研究，进一步推进了大学的使命。

www.cambridge.org 关于此标题的信息：www.cambridge.org/XXX-X
-XXX-XXXXX-X DOI：10.1017/XXX-X-XXX-XXXXX-X

© 作者姓名 XXXX

本出版物受版权保护。除法定例外情形及相关集体许可协议的条款规定外，未经剑桥大学出版社书面许可，不得以任何形式复制本出版物的任何部分。

首次发布 XXXX
由 <、> 在 <、> 印刷

A catalogue record for this publication is available from the British Library.

Library of Congress Cataloging-in-Publication Data

ISBN XXX-X-XXX-XXXXX-X 精装版

剑桥大学出版社对本出版物中提及的外部或第三方互联网网站的URL的持久性或准确性不承担责任，并且不保证这些网站上的任何内容现在或将来是准确或适当的。

献给

根纳季的记忆 **(Y.P.)**

我的家人 **(Y.W.)**

目录

Preface *page* xv
Introduction xvii

常用符号 1

第一部分 信息度量 5

1 熵 8

1.1 熵与条件熵 8 1.2 公理化特征 13 1.3 熵的历史 14 1.4* 子模性 16 1.5* 汉不等式与希勒引理 17

2 散度 20

2.1 散度与拉东-尼科迪姆导数 20 2.2 散度：主要不等式与等价表达式 24 2.3 微分熵 26 2.4 马尔可夫核 29 2.5 条件散度、链式法则、数据处理不等式 31 2.6* 散度与费舍尔信息的局部行为 36 2.6.1* 混合物的散度局部行为 36 2.6.2* 参数化族 38

3 互信息 41

3.1 互信息 41 3.2 互信息作为熵的差 44 3.3 计算互信息的示例 47 3.4 条件互信息与条件独立 50 3.5 充分统计量与数据处理 53 3.6 错误概率与Fano不等式 55 3.7* 高斯噪声中的估计误差（I-MMSE） 58 3.8* 熵-功率不等式 63

4 信息度量的变分表征与连续性 66

4.1 互信息的几何解释 67 4.2 散度的变分特性：Gelfand-Yaglom-Perez 70 4.3 散度的变分特性：Donsker-Varadhan 71 4.4 吉布斯变分原理 74 4.5 散度的连续性 78 4.6* σ-代数的单调极限下的连续性 79 4.7 互信息的变分特性与连续性 81 4.8* PAC-Bayes 83 4.8.1 一致收敛性 85 4.8.2 统计学习理论中的泛化界限 87

5 互信息的极值化：容量鞍点 91

5.1 信息度量的凸性 915.2 互信息的鞍点 945.3 作为信息半径的容量 965.4* 达到容量的输出分布的存在性（一般信道） 975.5 高斯鞍点 1005.6 迭代算法：Blahut-Arimoto、期望最大化、Sinkhorn 102

6 张量化和信息速率 106

6.1 互信息的张量化（单字母化） 106 6.2* 通过正交对称性的高斯容量 107 6.3 熵率 109 6.4 熵与符号（比特）错误率 112 6.5 互信息率 113

7 f-散度 115

7.1 f-散度的定义与基本性质 115 7.2 数据处理不等式；通过有限划分的近似 118 7.3 假设检验中的全变差与 Hellinger 距离 122 7.4 f-散度与联合范围之间的不等式 126 7.5 计算联合范围的例子 130 7.5.1 Hellinger 距离与全变差 131 7.5.2 KL 散度与全变差 131 7.5.3 χ^2-散度与全变差 132 7.6 各种散度之间的一组不等式 132 7.7 高斯分布之间的散度 133 7.8 基于 f-散度的互信息 134 7.9 经验分布与 χ^2-信息 136

7.10 大多数 f-散度局部类似 χ^2 138

7.11 参数族中的 f-散度：Fisher 信息 140 7.12 Rényi 散度与张量积化 144 7.13 f-散度的变分表示 147 7.14* 技术证明：凸性、局部展开与变分表示 152

8 组合数学与几何中的熵方法 158

8.1 平均权重的二进制向量 158 8.2 Shearer引理与子图计数 159 8.3 布雷格曼定理 161 8.4 欧几里得几何：Bollobás-Thomason与Loomis-Whitney 164

9 随机数生成器 166

9.1 设置 166 9.2 对话 167 9.3 Elias基于数据压缩的构造 167 9.4 Peres的迭代冯·诺依曼方案 169 9.5 伯努利工厂 172

第一部分练习 174

第二部分 无损数据压缩 193

10 变长压缩 197

10.1 可变长度无损压缩 197 10.2 曼德布罗特关于齐普夫（幂）律普遍性的论证 203 10.3 唯一可解码码、前缀码和霍夫曼码 206

11 定长压缩与Slepian-Wolf定理 212

11.1 信源编码定理 212 11.2 渐近均分性质（AEP）217 11.3 线性压缩（哈希）218 11.4 在压缩器和解压器两端均有边信息的压缩 221 11.5 Slepian-Wolf：仅在解压器处有边信息 222 11.6 Slepian-Wolf：压缩多个信源 224 11.7*带有辅助信息的信源编码（Ahlswede-Körner-Wyner）226

12 遍历过程的熵 230

12.1 遍历理论的点滴 230 12.2 香农-麦克米伦、熵率及渐近均分性 233 12.3 香农-麦克米伦-布莱曼定理的证明 234

12.4*遍历理论的伯克霍夫-辛钦定理的证明 237
12.5*西奈生成元定理 239

13 通用压缩 244

13.1 算术编码 245 13.2 Fitingof 的组合构造 246 13.3 一类信源的最优压缩器。冗余度。 247 13.4*渐近极大极小解：杰弗里斯先验 250 13.5 序贯概率分配：Krichevsky-Trofimov 253 13.6 在线预测与密度估计 255 13.7 个体序列与最坏情况遗憾 259 13.8 Lempel-Ziv 压缩器 261

第二部分练习 265

第三部分 假设检验与大偏差 273

14 内曼-皮尔逊引理 276

14.1 Neyman-Pearson 表述 276 14.2 似然比检验 280 14.3 $\mathcal{R}(P,Q)$ 的逆界 282 14.4 $\mathcal{R}(P,Q)$ 的可达界 283 14.5 渐近性：Stein 区域 286 14.6 Chernoff 区域：预览 289

15 信息投影与大偏差 291

15.1 大偏差理论的基础 291 15.1.1 对数矩生成函数与速率函数 293 15.1.2 倾斜分布 297 15.2 大偏差指数与KL散度 299 15.3 信息投影 302 15.4 I-投影与KL测地线 306 15.5 萨诺夫定理 307 15.6*多重约束下的信息投影 308

16 假设检验：误差指数 313

16.1 (E_0, E_1)-权衡 313 16.2 定理16.1的等价形式 317 16.3*序贯假设检验 319 16.4 复合、稳健和拟合优度假设检验 324

16.5*通信约束下的假设检验 325

第三部分练习 329

第四部分 信道编码 339 17 纠错码 342

17.1 码与错误概率 342 17.2 二进制对称信道的编码 344 17.3 最佳解码器 347 17.4 弱逆界 348

18 随机与最大编码 350

18.1 信息密度 351 18.2 香农随机编码界 353 18.3 依赖性检验(DT)界 356 18.4 费恩斯坦最大编码界 357 18.5 RCU与Gallager界 359 18.6 线性码 362 18.7 为何随机编码和最大编码工作良好？ 366

19 信道容量 370

19.1 信道与信道容量 370 19.2 香农有噪信道编码定理 375 19.3 容量计算示例 379 19.4* 对称信道 381 19.5*信息稳定性 386 19.6 误码率下的容量 389 19.7 联合信源信道编码 391

20个具有输入约束的信道。高斯信道。 394

20.1 输入约束下的信道编码 394 20.2 可分离代价约束下的信道容量 397 20.3 平稳AWGN信道 399 20.4 并行AWGN信道 402 20.5*非平稳AWGN 403 20.6*加性有色高斯噪声信道 405 20.7*带码间干扰的AWGN信道 406 20.8*带幅度约束的高斯信道 407 20.9*带衰落的高斯信道 408

21 单位成本容量 410

21.1 每比特能量 410 21.2 每单位成本容量 414 21.3 衰落信道的每比特能量 416 21.4 连续时间AWGN信道的容量 417 21.5*连续时间带限AWGN信道的容量 419

22 强逆定理。信道色散。误差指数。有限块长度。422

22.1 强逆定理 422 22.2 无强逆定理的平稳无记忆信道 427 22.3 元逆定理 428 22.4*误差指数 430 22.5 信道色散 434 22.6 有限块长度界与正态近似 439 22.7 归一化速率 439

23 带反馈的信道编码 442

23.1 反馈不增加无记忆平稳信道的容量 442 23.2*马西的有向信息 446 23.3 反馈何时真正有用？450 23.3.1 错误概率极小（如零）的编码 450 23.3.2 变长编码 455 23.3.3 可变功率编码 457

第四部分练习 460

第五部分 率失真理论与度量熵 473

24 率失真理论 477

24.1 标量与矢量量化 477 24.1.1 标量均匀量化 477 24.1.2 标量非均匀量化 479 24.1.3 最优量化器 480 24.1.4 精细量化 481 24.1.5 精细量化与可变速率 483 24.2 信息论表述 483 24.3 逆向界限 485 24.4*将超额失真转换为平均值 488

25 率失真：可达性界限 490

25.1 香农率失真定理 490 25.1.1 直观理解 492 25.1.2 定理25.1的证明 493 25.2*覆盖引理与联合典型性 497 25.3*Wyner的公共信息 502 25.4*输出统计的近似与软覆盖引理 504

26 评估率失真函数。有损信源-信道分离。 507

26.1 $R(D)$ 的评估 507 26.1.1 伯努利源 507 26.1.2 高斯源 509 26.2*率失真中鞍点性质的类比 512 26.3 有损联合信源信道编码 515 26.3.1 逆定理 515 26.3.2 通过分离的可达性 516 26.4 经典有损压缩中缺失了什么？ 519

27 度量熵 522

27.1 覆盖与填充 52227.2 有限维空间与体积界 52527.3 超越体积界 52827.3.1 Sudakov 的极小化 53027.3.2 Hilbert 球具有度量熵 $\frac{1}{\epsilon^2}$ 53227.3.3 Maurey 的经验方法 53427.3.4 度量熵的对偶性 53527.4 无穷维空间：光滑函数 53527.5 度量熵与小球概率 53927.6 度量熵与率失真理论 542

第五部分练习 545

第六部分 统计应用 555

28 统计决策论基础 558

28.1 基本设置 558 28.2 高斯位置模型（GLM）560 28.3 贝叶斯风险、极小极大风险和极小极大定理 561 28.3.1 贝叶斯风险 561 28.3.2 极小极大风险 563

itbook-export CUP/HE2-design 2024年8月16日 18:58 第xiii页

28.3.3 极小极大与贝叶斯风险：对偶视角 565 28.3.4 极小极大定理 566 28.4 多重观测与样本复杂度 567 28.5 实验的张量积 568 28.6 对数凹性、安德森引理与GLM中的精确极小极大风险 571

29 经典大样本渐近理论 575

29.1 数据处理下的统计下界 575 29.1.1 Hammersley-Chapman-Robbins (HCR) 下界 575 29.1.2 贝叶斯 CR 与 HCR 577 29.2 贝叶斯 CR 下界及其扩展 578 29.3 最大似然估计量与渐近效率 581 29.4 应用：估计离散分布与熵 583

30 互信息方法 585

30.1 重新审视GLM与香农下界 586 30.2 稀疏均值GLM 589 30.3 社区检测 591 30.4 超越随机估计 592

31 通过归约到假设检验的下界 594

31.1 Le Cam 两点法 594 31.2 Assouad 引理 597 31.3 从互信息方法推导 Assouad 引理 598 31.4 Fano 方法 599

32 统计估计的熵界 602

32.1 Yang-Barron的构造 603 32.1.1 贝叶斯风险作为条件互信息与容量界 605 32.1.2 通过KL覆盖数的容量上界 608 32.1.3 利用Hellinger熵界定容量与KL覆盖数 609 32.1.4 累积风险与个体（单步）风险之间的一般界 610

32.2 Le Cam-Birgé 成对比较 612 32.2.1 复合假设检验与 Hellinger 距离 612 32.2.2 Le Cam-Birgé 成对比较估计量的 Hellinger 保证 614 32.2.3 使用局部熵的精化 616

32.2.4 使用局部 Hellinger 装箱的下界 618 32.3 Yatracos 类与最小距离估计量 620 32.4 Hölder 类上的密度估计 622

33 强数据处理不等式 626

33.1 使用噪声门计算布尔函数 626 33.2 强数据处理不等式 629 33.3 有向信息渗透 633 33.4 输入依赖的SDPI。马尔可夫链的混合 637 33.5 应用：树上的广播与着色 641 33.6 应用：分布式相关性估计 644 33.7 信道比较：退化、较低噪声、更强能力 646 33.8 无向信息渗透 648 33.9 应用：尖峰维格纳模型 651 33.10强数据后处理不等式（post-SDPI） 653 33.11应用：分布式均值估计 657

第六部分练习 660

References 672

Index 695

Index 695

前言

这是一本关于信息论的现代导论。在过去二十年中，该学科已从主要处理信息存储与传输问题（“编码”）的领域，演变为日益关注信息提取与去噪（“学习”）的领域。这一转变体现在本书的标题和内容中。

我们花了十多年时间才完成这项工作。它最初是作者们在麻省理工学院、伊利诺伊大学和耶鲁大学讲授常规课程，以及在洛桑联邦理工学院（瑞士）和法国国家统计与经济管理学院讲授专题课程时积累的一套讲义。因此，本手稿的预期用途是作为研究生和高年级本科生信息论入门课程的教科书，或者作为深入探讨特定领域的第二门（专题）课程的教科书。

这本教科书有两个不同寻常之处。首先，尽管由信息论领域的“内部人士”撰写，但其内容极具外向性。我们不仅深入涵盖了信息论的基本成果（编码定理），还投入大量篇幅介绍那些在统计学习、统计物理、遍历理论、计算机科学、概率论等领域产生重要影响的思想和方法。第二个方面是，我们既涵盖了久经考验的经典内容（如与组合学、遍历性、泛函分析的联系），也包含了近年来的最新进展（大字母表分布估计、社区检测、马尔可夫链混合、图模型、PAC-Bayes、泛化界）。

很难提及所有帮助我们开始和完成这项工作的人，但有些人尤为突出。我们非常感谢Sergio Verdú，他在普林斯顿的课程让我们对此课题终身热爱。他的热情与教学法，即便不完美，也在本书中有所体现。如需了解未失真的观点，请参见他即将出版的综合性专著[436]。

接下来，我们很幸运有许多聪明学生为原始讲义（本书的前身）的打字工作做出了贡献，并且在更正和扩展内容方面也做出了贡献。其中，我们特别感谢 Ganesh Ajjanagadde、Austin Collins、Yuzhou Gu、Richard Guo、Qingqing Huang、Alexander Haberman、Matthew Ho、Yunus Inan、Reka Inovan、Jason Klusowski、Anuran Makur、Pierre Quinton、Aolin Xu、Sheng Xu、Pengkun Yang、Andrew Yao 和 Junhui Zhang。

我们感谢多年来在本书草稿各个阶段提供宝贵反馈的许多同事，特别是Lucien Birgé、Marco Dalai、Meir Feder、Bob Gallager、Bobak Nazer、Or Ordentlich、Henry Pfister、Maxim Raginsky、Sasha Rakhlin、Philippe Rigollet、Mark Sellke和Nikita Zhivotovskiy。Rachel Cohen（麻省理工学院）非常慷慨地付出了时间，并在无数方面提供了帮助。

我们感谢剑桥大学出版社（CUP）的编辑Chloe Mcloughlin、Elizabeth Horne、Sarah Strange、Julie Lancashire的支持，以及CUP允许我们保留在线免费版本。我们特别感谢Julie给予的最初推动，以及

2019年的动力，没有它我们甚至永远不会考虑超越最初那套混乱的在线讲义。（尽管，如果我们知道会花4年时间……）

封面艺术和插图由才华横溢的插画师Nastya Mukhanova贡献 [311]，我们对她的赞美之情难以言表。

Y. P. 想要感谢 Olga 始终不渝的耐心与鼓励。她无私的牺牲为 Y. P. 赢得了宝贵的时间，使他能够投入无数额外小时来撰写这本书。Y. P. 还想向 Yana、Alina 和 Evan 给予一个文学式的拥抱，并感谢他们为他的生活带来光明。

Y. W. 要感谢他的父母和他的妻子，Nanxi。

Y. Polyanskiy `<yp@mit.edu>` 麻省理工学院 Y. Wu `<yihong.wu@yale.edu>` 耶鲁大学

简介

什么是信息?

《牛津英语词典》列出了*information*一词的18种定义，而《韦氏词典》则列出了17种。这强调了“信息”一词可能出现的意义和上下文的多样性。然而，本书仅关注对信息的精确数学理解，与具体应用领域无关。

我们如何度量甚至无法很好定义的东西？在量化信息的最早尝试中，我们可以列出R.A.费舍尔关于统计估计不确定性（“置信区间”）的工作以及R.哈特利将信息定义为可能性数量的对数。大约在同一时期，费舍尔[169]和其他人识别出了信息与热力学*entropy*之间的联系。这一思路在克劳德·香农的巨著[378]中达到顶峰，他在其中形式化了（我们今天所称的）香农信息的概念，并通过接受约翰·图基的词语*bit*作为其度量单位，永远改变了人类语言。除了具有许多优雅的性质外，香农信息还被证明能够回答某些严格的数学问题（例如数据压缩和数据传输的最佳速率）。这使得香农的定义成为量化信息的正确方式。经典信息论，如[106, 111, 177]中所述，完全专注于这一观点。

然而，在本书中，我们采取了一个稍微更为广泛的观点。为了介绍这一观点，让我们引用著名物理学家L.布里渊[76]的话：

> 我们必须从“信息”一词的精确定义开始。我们考虑一个问题，涉及一定数量的可能答案，如果我们对实际情况没有特别的信息。当我们恰好掌握关于该问题的一些信息时，可能答案的数量会减少，而完整的信息甚至可能只留下一个可能的答案。信息是前后可能答案数量之比的函数，我们选择对数规律以确保独立情境中所含信息的可加性。

请注意，只有最后一句将更一般的术语“信息”特化为香农的特殊版本。在本书中，我们所思考的信息不包含最后一句。也就是说，对我们而言，信息是 *difference between two beliefs about the system state* 的一种度量。例如，它可以是我们在观察到某个事件或现象后，世界观中所包含的 *change* 的数量。具体而言，假设最初概率分布 P 描述了我们对世界的理解（例如，P 使我们能够回答诸如今天下雨的可能性有多大之类的问题）。在观察到某些现象后，我们的分布变为 Q（，例如，在观察到多云或晴空后)。该观察中的信息量是 P 与 Q 之间的 *dissimilarity*。如何量化不相似性取决于具体情境。正如香农所论证的，在许多情况下，正确的选择是 Kullback-Leibler

(KL) 散度 $D(Q\|P)$，见定义 2.1。事实上，如果先验信念由 k 个可能结果集合上的概率质量函数 $P = (p_1, \ldots, p_k)$ 描述，那么观察到第一个结果会导致新的（后验）信念向量 $Q = (1, 0, \ldots, 0)$ 给出 $D(Q\|P) = \log \frac{1}{p_1}$，其他结果同理。由于结果 i 发生的概率为 p_i，我们看到先验和后验信念之间的平均差异为

$$\sum_{i=1}^{k} p_i \log \frac{1}{p_i},$$

这恰好是香农熵，参见定义1.1。

然而，我们坚信，为了将信息论应用于经典领域之外，除了KL散度之外，还需要其他差异性度量（或“信息度量”）。例如，总变差、Hellinger距离和χ^2-散度（两者都是*f*-散度族的重要成员）的概念，在统计估计和概率论中，以及在通信复杂性、受通信约束的估计、属性测试等理论计算机科学的当代主题中（我们将在第六部分详细讨论这些），都找到了深刻而富有成果的应用。因此，当我们在本书第一部分谈论信息度量时，我们并不只关注香农类型的度量，尽管后者理应得到特别优待。

什么是信息理论?

与*information*类似，*information theory*的主题没有精确的定义。在最狭窄的意义上，它是一门关注数据传输和存储最优方法的科学学科。这一主题部分的重点在于所谓的“编码定理”，这些定理展示了在噪声信道中压缩和传递信息的算法的存在性。经典成果，如香农的噪声信道编码定理（定理19.9），不仅展示了算法的存在性，还量化了它们的性能，并表明这种性能是最佳的。因此，这部分关注的是识别实际相关（工程）问题的根本极限。 consequently，这一分支有时被称为“IEEE[1]风格的信息论”，它影响或彻底变革了我们今天所目睹的许多信息技术：数字通信、无线（蜂窝和WiFi）网络、密码学（Diffie-Hellman）、数据压缩（Lempel-Ziv系列算法），以及更多。

然而，本书并不局限于IEEE风格的信息论，因为该领域的真正范围要广泛得多。事实上，希尔伯特第13问题（针对光滑函数）正是通过Arnold和Kolmogorov借助Kolmogorov在Shannon率失真理论[440]之后引入的度量熵思想而得到阐明和解决的。遍历理论中伯努利移位的同构问题也已通过引入Kolmogorov-Sinai

[1] For Institute of Electrical and Electronics Engineers; pronounced “Eye-triple-E”.

熵 [387, 322]。在物理学中，兰道尔原理及其他关于麦克斯韦妖的研究深受信息论的影响 [267, 42]。自然语言处理（NLP）中，将文本建模为高阶马尔可夫模型的思想，近期以GPT [320]及相关模型的形式取得了显著成功。从生物学、神经科学和热力学到模式识别、人工智能和控制论等更多领域的话题，都经常出现在信息论相关的会议和期刊中。

似乎客观地界定信息理论所声称的领域是徒劳的。相反，我们更愿意强调我们认为近期的哪些发展令我们着迷，并促使我们撰写这本书。

首先，当今的信息处理系统与本世纪相比变化多端。现代控制器（机器人）不仅仅是对几维观测向量做出反应，这些向量通常被建模为线性时不变系统。相反，它拥有百万维的输入（例如，栅格化图像），这些输入既延迟又量化，还需要在噪声链接中传输。统计推断的目标不再是一个低维参数，而是一个具有结构的高维（可能是离散的）对象（例如，稀疏矩阵，或具有潜在社区结构的人际社交网络）。此外，观测数据从空间或时间上分离的来源到达统计学家，这些来源的传输需要考虑到速率限制。认识到这些新挑战后，多个领域同时开始重新审视关于最大似然最优性和由费舍尔信息给出的（最优）方差界的经典结果（第29章）。这些高维统计、计算机科学和统计学习的发展依赖于对f-散度（第7章）、互信息方法（第30章）以及数据处理不等式强版本（第33章）的掌握。

其次，自20世纪90年代以来，技术进步催生了一系列新的噪声信道模型。经典理论探讨的是所谓的无记忆信道，而现代信道，如闪存存储或城市无线（多径、多天线）通信，远非无记忆。为了分析这些，经典的“渐近独立同分布”理论是不够的。解决方案是信息论的所谓“一次性”方法，其中所有主要结果都是在将信道输入和输出视为抽象$\{v^*\}$的情况下发展起来的。只有在最后一步，这些输入才被赋予长序列的结构，并计算渐近值。这种新的“一次性”方法对量子信息论具有额外的相关性，在那里它实际上是必要的。

第三，在2010年代取得了令人瞩目的实证成就之后，人们对于理解从数据中进行机器学习的方法及其局限性的兴趣激增。信息论原理在该领域的若干发现中起到了关键作用。例如，我们回顾了度量熵的概念（第27章），它是Vapnik监督学习方法（称为经验风险最小化）、非线性回归和密度估计理论（第32章）的基石。在机器学习中，密度估计被称为概率生成建模，这是无监督学习中的一个典型问题。目前，最佳算法是通过应用信息论思想推导得出的：Kullback-Leibler散度的Gibbs变分原理（在变分自编码器（VAE）中，参见例4.2）以及Jensen-Shannon散度的变分表征（在生成对抗网络（GAN）中，参见例7.5）。

另一个引人入胜的联系是，在线学习算法的最佳预测性能由互信息的最大值给出。这通过预测与通用压缩（第13章）之间的深层联系得以展示，该联系导致了乘法权重更新算法的发现[445, 104]。

在理论方面，一种称为强数据处理不等式（第33章）的常见信息论方法，解决了分布式估计、社区检测（在图中的）和主成分分析（尖峰Wigner模型）中的一系列问题。根植于Donsker-Varadhan对Kullback-Leibler散度的刻画的PAC-Bayes方法，在学习算法泛化误差界理论以及对高维经验过程的集中性和一致收敛性质的理解方面，带来了众多突破（第4.8*节）。

第四，理论计算机科学也一直在与信息论交流思想。经典联系包括熵与组合数学（第8章）；熵与随机性提取（第9章）；冯·诺依曼的噪声门计算（第33.1节）；树和一般图上的Ising、Potts和着色模型（第33.5节）；通信复杂性与Hellinger距离（练习I.41）。最近，链式法则的巧妙应用使Tao在图论中对Szemerédi正则引理进行了优雅的强化（练习I.63），并使Gilmer在并封闭集猜想上取得了突破（练习I.61）。所谓的I-MMSE恒等式（第3.7*节）被应用于获得随机局部化的非常简短的证明（练习I.66）。在随机采样和计数领域，谱独立方法（练习VI.26）解决了多个长期存在的猜想。

为什么要再写一本关于信息论的书?

我们撰写本书的动机有两点。首先，根据我们的经验，需要一本研究生水平的信息论教材，它在可接受的通用性水平上展开（即不局限于离散或分类随机变量），同时不牺牲任何数学严谨性。其次，我们希望向读者介绍我们在前一节中概述的信息论与其他学科之间所有令人兴奋的（经典的和新的）联系。我们相信，像{v*}-散度、单次视角、与统计学习和概率的联系等主题，在现有教材中没有得到充分覆盖，并且具有未来适应性：它们的重要性只会随着时间增长。目前这些内容被降级到专门专著中，有志于此的学生获取这套工具包的进程被延迟了。

有两本经典的教科书在短时间内不太可能过时：[106]由Cover-Thomas编写，[111]由Csiszár-Körner编写（以及后者的修订版[115]）。前者已成为全球大多数本科信息论课程的主要教材。它严谨地介绍了熵、信息和散度的概念，并证明了该领域的所有主要成果，同时还涉及了一些较为非标准的主题，如通用压缩、赌博和投资组合理论。

教科书 [111] 开创了信息论的组合方法，即“类型法”。尽管与 [106] 相比对数学要求更高，[111] 却成功引入了更强的结果，如误差指数的精确估计，特别是在多终端通信系统中的速率区域。然而，这两本书几乎完全专注于渐近性、香农型信息度量以及离散（有限字母表）情形。

专注于专门主题，已有若干专著可供参考。对于面向通信领域的读者而言，经典著作[177]仍然不可或缺。一次性视角的观点在[211]中得以采纳。与统计学习理论及图学习（信念传播）的联系在[287]中得到了精彩阐述。遍历理论是[198]的核心主题。量子信息理论——一个新兴领域——在近期的[451]中有所论述。唯一一本专门探讨信息论与统计学之间联系的教科书出自Kullback[264]，尽管其内容局限于假设检验中的大样本渐近性。在非参数统计中，信息论方法的应用在[424]中被简要（但优雅地）涵盖。

然而，无法从这些优秀的前辈著作的章节中拼凑出这本教科书。许多重要主题仅在此处涉及，例如第7章（{v*}-散度）、第18章（单次编码定理）、第22章（有限块长度）、第27章（度量熵）、第30章（互信息方法）、第32章（估计的熵界）和第33章（强数据处理不等式）。此外，为了构建这些章节，需要在教科书其余部分进行大量小的创新，而这些创新在其他地方并不存在。另外，习题探索了最近几年的工作。

关于省略的部分，本书几乎完全跳过了多终端信息论的议题（例外的是第11.7*、16.5*和 25.3* 节）。这一艰深主题在香农之后的“IEEE风格”理论中吸引了大量研究努力。我们参考了经典著作[115]以及近期优秀的教科书[147]，后者对该领域提供了百科式的覆盖。

另一个不幸的遗漏是信息论与函数不等式之间的联系[106，第17章]。这一主题近来涌现出大量活动，尤其是在对数Sobolev不等式、等周不等式、测度集中、Brascamp-Lieb不等式、(Marton-Talagrand)信息-运输不等式等方面。我们仅在3.7*、3.8*节及相关练习(例如I.47和I.65)中简要提及这些主题。更全面的论述见专著[353]及其参考文献。

最后，本书不会教授如何构造实用的纠错码或设计现代无线通信系统。在涵盖基础知识的第四部分之后，建议有兴趣的读者通过[360]掌握编码理论的工具，并通过[423]了解多天线信道。

给统计学家的提示

信息论与统计学之间的相互作用是这两个领域发展中的一个永恒主题。自信息论诞生以来，它对于理解统计估计的基本极限一直是不可或缺的。信息论量，如互信息、f-散度、度量熵和容量，在建立

自Le Cam [272]、Ibragimov和Khas’minski [222]、Pinsker [328]、Birgé [53]、Haussler和Opper [216]、Yang和Barron [464]等人的开创性工作以来，估计的极小极大速率早已被认识到。在本书第六部分，我们阐述了若干最具影响力的信息论思想及其在统计学中的应用。本部分并非对决策论或数理统计的全面论述；为此，我们参考经典著作[222, 276, 68, 424]以及更近期的专注于高维问题的专著[78, 190, 446]。相反，我们将本书前五部分所发展的理论应用于若干具体且精心选择的例子，以确定经典（固定维、大样本渐近）和现代（高维、非渐近）设定下的极小极大风险。

在高层次上，信息论（特别是数据传输）与统计推断之间的联系在于，这两个问题都由一个条件分布 $P_{Y|X}$ 定义，前者称之为 *channel*，后者称之为 *statistical model* 或 *experiment*。在这两个学科中，最终目标都是利用计算高效的算法，基于带噪观测 Y 高保真地估计 X。然而，在数据传输中，X 的允许取值集合通常是离散的，并且限于一个精心选择的输入子集（称为码本），其设计被认为是主要难点。而在统计学中，允许取值 X (参数) 的空间或分布受到问题设定（例如，要求 X 具有稀疏性或低秩性）的约束，而非受统计学家约束。尽管存在这一关键差异，这两个学科最终都是关于基于 Y 估计 X，并且信息论思想在这两种情境中都适用。

具体而言，在第29章中，我们展示了如何利用数据处理不等式推导统计估计中的经典下界（Hammersley-Chapman-Robbins、Cramér-Rao、van Trees）。在第30章中，我们基于联合信源信道编码的推理引入了*the mutual information method*。即，通过比较数据中包含的信息量与达到给定估计精度所需的信息量（两者均以比特为单位），该方法使我们能够应用第四部分和第五部分中发展的容量和率失真函数理论来下界统计风险。除了具有原则性外，这种方法还统一了分别由Le Cam、Assouad和Fano提出的三种证明极小极大下界的流行方法（第31章）。

一个常见的误解是，信息论仅提供证明统计学中否定结果的技巧。在第32章中，我们介绍了基于*metric entropy*的三种*upper bounds*统计估计风险方法：受通用压缩启发的Yang-Barron构造、基于成对假设检验的Le Cam-Birgé锦标赛法，以及Yatracos的最小距离方法。这些强大的方法促成了一些统计学中最强且最通用的结果，并适用于高维和非参数问题。最后，在第33章中，我们引入了基于强数据处理不等式的方法，并将其应用于解决一系列当代问题，包括图上的社区检测、受通信约束的分布式估计以及生成随机树着色。这些问题也日益吸引着计算机科学家的关注。

如何使用这本教科书

面向高年级本科生或研究生的信息论入门课程可以按照以下顺序进行:

• 第一部分：第1–3章，第4.1节、5.1–5.3节、6.1节及3.6节，仅聚焦于离散概率空间，忽略Radon-Nikodym导数。建议提及组合数学与密码学中的应用（第8章、第9章及部分习题）。• 第二部分：第10章，第11.1–11.5节。• 第三部分：第14章，第15.1–15.3节及第16.1节。• 第四部分：第17–18章，第19.1–19.3节、19.7节、20.1–20.2节、23.1节。• 第五部分：第24.1–24.3节、25.1节、26.1节及26.3节。• 以信息论在经典领域之外的若干应用作为结束（第30章和第33章）。

一门以传统通信和压缩为重点的研究生信息论课程可以更快地讲完第一部分（略去f-散度和其他非必要章节），然后深入讲授第二至第五部分，包括强逆定理、有限块长度情形以及带反馈的通信，但略去第27章。对于这类课程，做完第四部分末尾的习题很重要。

对于一门侧重统计学习的信息论研究生课程，从第一部分（尤其是第7章）开始，接着是第二部分（尤其是第13章）和第三部分，第四部分限定覆盖第17-19章，第五部分覆盖第27章（尤其是第27.1–27.4节）。这样应该能留下超过半个学期的时间来仔细学习第六部分。例如，为了保持良好进度，我们建议至少留出5-6次讲座用于第32章和第33章。最后这几章包含一些前沿研究结果和开放问题，希望能吸引学生投身其中。为此，我们也建议复习第一部分和第六部分末尾的习题。

难度较大的章节用星号标记，初次阅读时可以跳过，因为它们可能依赖于后续章节或外部资料的内容。

一个详尽的索引应有助于将不同主题相互关联。例如，查找“社区检测”会显示这个有趣示例在各章节中的所有众多出现之处。

常用记号

通用约定

• 符号 $\triangleq$ 读作 *defined as* 和 $\equiv$ *abbreviated as*。• 实数集合和整数集合分别记作 $\mathbb{R}$ 和 $\mathbb{Z}$。令 $\mathbb{N} = \{1, 2, \ldots\}$，$\mathbb{Z}_+ = \{0, 1, \ldots\}$，$\mathbb{R}_+ = \{x : x \geq 0\}$。• 对于 $n \in \mathbb{N}$，令 $[n] = \{1, \ldots, n\}$。• 在整本书中，$x^n \triangleq (x_1, \ldots, x_n)$ 表示一个 n 维向量，$x_i^j \triangleq (x_i, \ldots, x_j)$ 对于 $1 \leq i < j \leq n$ 和 $x_S \triangleq \{x_i : i \in S\}$ 对于 $S \subset [n]$。• 除非明确说明，对数 log 和指数 exp 都相对于某个通用的公共底数。自然对数记作 $\ln = \log_e$ 和 $\exp_e\{\cdot\} = e^{(\cdot)}$。• 我们约定取 $\exp\{+\infty\} = +\infty, \exp\{-\infty\} = 0, \log(+\infty) = +\infty, \log(0) = -\infty$。函数 $x \mapsto x \log x$ 通过取 $0 \cdot \log 0 = 0$ 扩展到 $x = 0$。扩展到 $x = 0$ 和 $y = 0$ 的双变量函数 $(x, y) \mapsto \log \frac{x}{y}$ 记作 $\mathrm{Log}\, \frac{x}{y}$，并有一个特殊约定 (2.10)。• $a \wedge b = \min\{a, b\}$ 和 $a \vee b = \max\{a, b\}$。• 对于 $p \in [0, 1]$，$\bar{p} \triangleq 1 - p$。• $x^+ = \max\{x, 0\}$。• $f(x+) \triangleq \lim_{y \searrow x} f(y)$，$f(x-) \triangleq \lim_{y \nearrow x} f(y)$。• 下极限和上极限：$\liminf_{n\to\infty} g_n \triangleq \lim_{n\to\infty} \inf_{m \geq n} g_m$ 和 $\limsup_{n\to\infty} g_n \triangleq \lim_{n\to\infty} \sup_{m \geq n} g_m$。• $w_{\mathrm{H}}(x)$ 表示二进制向量 x 的汉明重量（1 的个数）。$d_{\mathrm{H}}(x, y) = \sum_{i=1}^n 1\{x_i \neq y_i\}$ 表示长度为 n 的向量 x 和 y 之间的汉明距离。• 整本书中使用标准的大 O 记号：例如，对于任意正序列 $\{a_n\}$ 和 $\{b_n\}$，如果存在绝对常数 $c > 0$ 使得 $a_n \leq c b_n$，则 $a_n = O(b_n)$；如果 $b_n = O(a_n)$，则 $a_n = \Omega(b_n)$；如果 $a_n = O(b_n)$ 和 $a_n = \Omega(b_n)$ 都成立，则 $a_n = \Theta(b_n)$，在这些情况下我们也写作 $a_n \asymp b_n$；如果对于某个 $\epsilon_n \to 0$ 有 $a_n \leq \epsilon_n b_n$，则 $a_n = o(b_n)$ 或 $b_n = \omega(a_n)$。此外，如果讨论中存在一个参数 p，并且 $a_n = O(b_n)$ 的定义中的常数 c 依赖于 p，那么我们通过写作 $a_n = O_p(b_n)$ 来强调这一事实。

信息论与统计学

• $h(\cdot)$ 是二元熵函数，$H(\cdot)$ 表示一般的香农熵。• $d(\cdot\|\cdot)$ 是二元散度函数，$D(\cdot\|\cdot)$ 表示一般的 Kullback-Leibler 散度 • 标准信道 BSC_δ, BEC_δ, $\mathsf{BIAWGN}_{\sigma^2}$ • 常见的散度有 $\chi^2(\cdot\|\cdot)$ (卡方), $D_\alpha(\cdot\|\cdot)$ (Rényi 散度), $D_f(\cdot\|\cdot)$ (一般 f-散度)。

• 常见的统计距离 TV$(\cdot,\cdot)$（总变差）、$H^2(\cdot,\cdot)$ (Hellinger平方)、$W_1(\cdot,\cdot)$ (Wasserstein距离)
根据上下文，P_θ 可以表示由参数 θ 索引的参数化分布类，也可以表示随机变量 θ 的分布律。

分析与代数

• 对于 $x \in \mathbb{R}^d$，我们用 $\|x\|_p = \left(\sum_{i=1}^p |x_i|^p\right)^{1/p}$ 和 $\|x\| = \|x\|_2$ 表示标准欧几里得范数。• 令 int(E) 和 cl(E) 分别表示集合 E 的内部和闭包，即分别包含于 E 的最大开集和包含 E 的最小闭集。• 令 co(E) 表示 E (在不含拓扑结构)下的凸包，即包含 E 的最小凸集，由 co(E) $= \{\sum_{i=1}^n \alpha_i x_i : \alpha_i \geq 0, \sum_{i=1}^n \alpha_i = 1, x_i \in E, n \in \mathbb{N}\}$ 给出。• 对于实向量空间的子集 A, B 和 $\lambda \in \mathbb{R}$，记膨胀 $\lambda A = \{\lambda a : a \in A\}$ 和 Minkowski 和 $A + B = \{a + b : a \in A, B \in B\}$。• 对于度量空间 $(\mathcal{X}, d)$，若函数 $f : \mathcal{X} \to \mathbb{R}$ 对所有 $x, y \in \mathcal{X}$ 满足 $|f(x) - f(y)| \leq Cd(x, y)$，则称其为 C-Lipschitz。我们记 $\|f\|_{\mathrm{Lip}(\mathcal{X})} = \inf\{C : f \text{ 是 } C\text{-Lipschitz}\}$。• 线性代数记号。对于实元素矩阵 A，我们定义 – 迹 $\operatorname{tr} A = \sum_i A_{i,i} - \sigma_1(A) \geq \sigma_2(A) \geq \cdots$ 其按降序排列的奇异值列表。回忆 $\sigma_j(A)$ 是 $A^\top A$ 的第 j 大特征值的平方根。– 算子范数 $\|A\|_{op} = \sup_{v \neq 0} \frac{\|Av\|}{\|v\|} = \sigma_1(A)$。– Frobenius 范数 $\|A\|_{\mathrm{F}}^2 = \sum_{i,j} |A_{i,j}|^2 = \operatorname{tr} A^\top A = \operatorname{tr} AA^\top = \sum_i \sigma_i^2(A)$。– 我们写 $A \succeq 0$ 表示 A 是半正定的，写 $A \succeq B$ 表示 $A - B \succeq 0$。• Hess $f(x)$ 表示 f 的 Hessian：$(\operatorname{Hess} f(x))_{i,j} = \frac{\partial^2 f}{\partial x_i \partial x_j}$。$\Delta f(x) = \operatorname{tr} \operatorname{Hess} f(x) = \sum_i \frac{\partial^2}{\partial x_i^2} f(x)$ 表示拉普拉斯算子。• 两个函数 f, g 在 $\mathbb{R}^d$ 上的卷积定义为 $(f * g)(x) = \int_{\mathbb{R}^d} f(y) g(x - y) dy$ 对所有 x 成立，其中（勒贝格）积分存在。对于 $\mathbb{R}^d$ 上的两个概率测度 p, q，我们还定义 $p * q$ 为 $A + B$ 的分布，其中 $A \perp\!\!\!\perp B$ 和 $A \sim p$，$B \sim q$。

测度论与概率

• 欧几里得空间上的勒贝格测度记为 Leb，也记为 vol（体积）。• 在整本书中，所有可测空间（$\mathcal{X}, \mathcal{E}$）都是标准博雷尔空间。除非明确需要，我们省略底层的 σ-代数 $\mathcal{E}$。• $\mathcal{X}$ 上所有概率测度的集合记为 $\mathcal{P}(\mathcal{X})$。对于有限空间，我们缩写 $\mathcal{P}_k \equiv \mathcal{P}([k])$，一个（$k-1$）维单纯形。• 对于测度 P 和 Q，它们的乘积测度记为 $P \times Q$ 或 $P \otimes Q$。P 的 n 重积记为 P^n 或 $P^{\otimes n}$。类似地，给定一个马尔可夫核 $P_{Y|X}$：$\mathcal{X} \to \mathcal{Y}$，独立作用于 n 个坐标中每一个的核记为 $P_{Y|X}^{\otimes n}$：$\mathcal{X}^n \to \mathcal{Y}^n$。• 设 P 关于 Q 绝对连续，记为 $P \ll Q$。P 关于 Q 的拉东-尼科迪姆导数记为 $\frac{dP}{dQ}$。对于概率测度 P，如果 $Q = \mathrm{Leb}$，$\frac{dP}{dQ}$

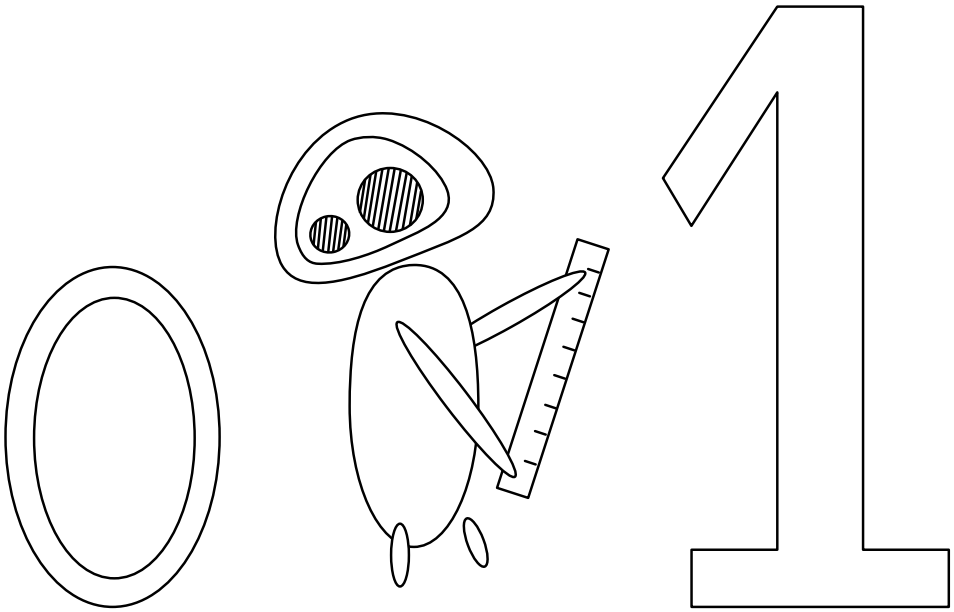
称为概率密度函数（pdf）；如果 Q 是可数 $\mathcal{X}$ 上的计数测度，则 $\frac{dP}{dQ}$ 是概率质量函数（pmf）。

• 令 $P \perp Q$ 表示它们的相互奇异性，即对于某个 A，有 $P(A) = 0$ 和 $Q(A) = 1$。• 概率测度 P 的 *support*，记作 $\mathrm{supp}(P)$，是使得 $P(C) = 1$ 成立的最小闭集 C。P 的 *atom* x 满足 $P(\{x\}) > 0$。若 $\mathrm{supp}(P)$ 是可数集（由其原子组成），则分布 P 是 *discrete*。• 令 X 为取值于 $\mathcal{X}$ 的随机变量，$\mathcal{X}$ 称为 X 的 *alphabet*。其实现用小写字母标记，例如 x。因此，大写、小写和花体字母分别对应于随机变量、实现和字母表（如 $X = x \in \mathcal{X}$ 中所示）。通常自动假定 $\mathcal{X}$ 和 $\mathcal{Y}$ 分别是 X 和 Y 的字母表，等等。我们也写作 $X \in \mathcal{X}$ 来表示随机变量 X 取值于 $\mathcal{X}$。• 令 P_X 表示随机变量 X 的分布（律），$P_{X,Y}$ 表示 X 和 Y 的联合分布，$P_{Y|X}$ 表示给定 X 时 Y 的条件分布。• 条件分布 $P_{Y|X}$ 也称为作用在空间 $\mathcal{X}$ 和 $\mathcal{Y}$ 之间的马尔可夫核，记作 $P_{Y|X} : \mathcal{X} \to \mathcal{Y}$。给定条件分布 $P_{Y|X}$ 和边缘分布，我们可以构造联合分布，记作 $P_X \times P_{Y|X}$，或简记为 $P_X P_{Y|X}$。其边缘分布 P_Y 通过复合运算 $P_Y \triangleq P_{Y|X} \circ P_X$ 表示。• 随机变量 X 和 Y 的独立性记作 $X \perp\!\!\!\perp Y$，此时 $P_{X,Y} = P_X \times P_Y$。类似地，$X \perp\!\!\!\perp Y|Z$ 表示给定 Z 时它们的条件独立性，此时 $P_{X,Y|Z} = P_{X|Z} \times P_{Y|Z}$。• 在本书中，$X^n \equiv X_1^n \triangleq (X_1, \ldots, X_n)$ 表示一个 n 维随机向量。若它们独立同分布（iid）为 P，我们写作 $X_1, \ldots, X_n \overset{\text{i.i.d.}}{\sim} P$，此时 $P_{X^n} = P^n$。• 序列 $x_1, \ldots, x_n$ 的经验分布记作 $\hat{P}_{x^n}$；随机样本 $X_1, \ldots, X_n$ 的经验分布记作 $\hat{P}_n \equiv \hat{P}_{X^n}$。• $\xrightarrow{\text{a.s.}}$、$\xrightarrow{\mathbb{P}}$、$\xrightarrow{\text{d}}$ 分别表示几乎必然收敛、依概率收敛和依分布（律）收敛。我们定义 $\overset{\text{d}}{=}$ 表示依分布相等。• 偶尔，为清楚起见，我们使用自解释的记号 $\mathbb{E}_{Y\sim Q}[\cdot]$ 来表示期望是在 Y 由分布 Q 生成的情况下取的。我们也使用如 $\mathbb{E}_C[\cdot]$ 这样的提示来表示期望是对 C 取的。• 一些常用的分布如下：– $\mathrm{Ber}(p)$：均值为 p 的伯努利分布。– $\mathrm{Bin}(n, p)$：具有 n 次试验和成功概率 p 的二项分布。– $\mathrm{Poisson}(\lambda)$：均值为 λ 的泊松分布。– $\mathcal{N}(\mu, \sigma^2)$ 是 $\mathbb{R}$ 上均值为 μ 和 σ^2 的高斯（正态）分布。$\mathcal{N}(\mu, \Sigma)$ 是 $\mathbb{R}^d$ 上均值为 μ 和协方差矩阵为 Σ 的高斯分布。将标准正态密度记作 $\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$，CDF 和互补 CDF 分别记作 $\Phi(t) = \int_{-\infty}^{t} \varphi(x)dx$ 和 $Q(t) = \Phi^c(t) = 1 - \Phi(t)$。$Q$ 的逆记作 Q^{-1}。– $Z \sim \mathcal{N}_c(\mu, \sigma^2)$ 表示复值圆对称正态分布，其期望为 $\mathbb{E}[Z] = \mu \in \mathbb{C}$ 和 $\mathbb{E}[|Z - \mu|^2] = \sigma^2$。

– 对于具有非空内部的 $\mathbb{R}^d$ 的紧子集 $\mathcal{X}$，$\mathrm{Unif}(\mathcal{X})$ 表示 $\mathcal{X}$ 上的均匀分布，其中对于区间 $[a,b]$，$\mathrm{Unif}(a,b) \equiv \mathrm{Unif}([a,b])$。我们也用 $\mathrm{Unif}(\mathcal{X})$ 表示有限集 $\mathcal{X}$ 上的均匀（等概率）分布。• 对于取值于 $\mathbb{R}^d$ 的随机变量 X，我们记 $\mathrm{Cov}(X) = \mathbb{E}[(X-\mathbb{E}[X])(X-\mathbb{E}[X])^\top]$ 为其协方差矩阵。条件版本记为 $\mathrm{Cov}(X|Y) = \mathbb{E}[(X-\mathbb{E}[X|Y])(X-\mathbb{E}[X|Y])^\top]$。• 对于集合 $E \subset \Omega$，我们用 $1_E(\omega)$ 表示当且仅当 $\omega \in E$ 时等于 1 的函数。类似地，$1\{$布尔条件$\}$ 表示一个随机变量，当且仅当“布尔条件”满足时等于 1，否则等于零。因此，例如，$\mathbb{P}[X > 1] = \mathbb{E}[1\{X > 1\}]$。

第一部分

信息量度



信息度量构成了信息论的基石。本书的第一部分致力于深入研究其中的一些度量，最显著的是熵、散度、互信息，以及它们的条件版本（第1-3章）。除了通过具体实例说明基本定义外，我们还将研究包括链式法则、正则性、张量化、变分表示、局部展开、凸性和优化性质，以及数据处理原理（第4-6章）在内的各个方面。当我们进入信息论的经典主题，如数据压缩和传输时，这些信息度量将在本书后续部分被赋予操作意义。本部分还包括将信息论与其他学科联系起来的主题，如I-MMSE关系（估计理论）、熵功率不等式（概率论）、PAC-Bayes界和吉布斯变分原理（机器学习）。

除了经典（香农）信息度量之外，第7章还系统论述了f-散度，这是由Csíszar引入的（香农）度量的一种推广，在许多统计问题中发挥着重要作用（见第三和第六部分）。最后，在本部分末尾，我们将讨论两个操作主题：第9章中的随机数生成器，以及第8章中熵方法在组合学和几何学中的应用。

若干当代主题在习题中展开，如随机块模型（习题I.49）、组合数学中的Gilmer方法（习题I.61）、Tao对Szemerédi正则性引理的证明（习题I.63）、Eldan的随机局部化（习题I.66）、Gross的对数Sobolev不等式（习题I.65）等。

1 Entropy

本章介绍第一个信息度量——香农熵。在研究了它的标准性质（链式法则、条件作用）之后，我们将简要描述如何得出其定义。我们讨论公理化刻画、统计力学中的历史发展，以及潜在的组合基础（“类型方法”）。我们以Han不等式和Shearer不等式结束本章，它们都利用了熵的次模性。在本章之后，读者可以参阅组合数学（第8章）和随机数生成（第9章）中的应用，这些内容与本部分其余部分无关。

1.1 熵与条件熵

定义1.1（熵）设X为一个离散随机变量，其概率质量函数为$P_X(x), x \in \mathcal{X}$。$X$的*entropy* (或*Shannon entropy*)是

$$\begin{aligned} H(X) &= \mathbb{E}\Big[\log \frac{1}{P_X(X)}\Big] \\ &= \sum_{x\in\mathcal{X}} P_X(x) \log \frac{1}{P_X(x)} \,. \end{aligned}$$

在计算总和时，我们同意（由于$x \mapsto x \log \frac{1}{x}$的连续性）

$$0 \log \frac{1}{0} = 0. \tag{1.1}$$

由于熵只依赖于随机变量的分布，因此在信息论中习惯上也会用$H(P_X)$来代替$H(X)$，本书中我们将随意这样做。定义1.1中对数的底决定了熵的单位：

$\log_2 \leftrightarrow$ 比特
$\log_e \leftrightarrow$ 纳特 l
$\mathrm{og}_{256} \leftrightarrow$ 字节
$\log \leftrightarrow$ 任意单位，底数始终与 exp 匹配

不同情况下会使用不同的单位，因此本书中的大多数一般性结果都是以“无基数”的对数/指数形式给出的。

定义1.2（联合熵）*joint entropy*个离散随机变量$X^n \triangleq (X_1, X_2, \ldots, X_n)$的$n$为

$$H(X^n) = H(X_1, \ldots, X_n) = \mathbb{E}\Big[\log \frac{1}{P_{X_1,\ldots,X_n}(X_1, \ldots, X_n)}\Big],$$

也可以明确地写为对联合概率质量函数（PMF）的求和：

$$H(X^n) = \sum_{x_1} \cdots \sum_{x_n} P_{X_1,\ldots,X_n}(x_1, \ldots, x_n) \log \frac{1}{P_{X_1,\ldots,X_n}(x_1, \ldots, x_n)}.$$

注意，联合熵是定义1.1应用于取值于乘积空间的随机向量$X^n = (X_1, X_2, \ldots, X_n)$的一个特例。

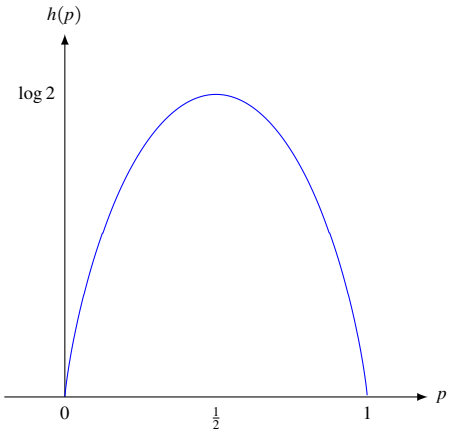
注 1.1 “熵”这个名称源自热力学——见第 1.3 节，该节也为这一定义提供了组合学上的依据。另一个常见的依据是从“信息量”的任何度量的自然公理推导出 $H(X)$——见第 1.2 节。还有自然实验表明，$H(X)$ 确实是 X 中的“信息量”。例如，可以测量蚂蚁侦察蚁向工蚁描述食物位置所需的时间。研究发现，当巢穴位于深度为 d 的满二叉树的根，而食物位于其中一片叶子时，时间与描述食物位置的随机变量的熵成正比 [358]。（还估计出蚂蚁的交流速率约为 0.7–1 比特/分钟，并且如果路径描述中存在某些规律，交流时间会减少：诸如“左、右、左、右、左、右”这样的路径会被侦察蚁更快地描述出来。）

熵衡量随机变量的内在随机性或不确定性。在 X 在有限集合 $\mathcal{X}$ 上均匀取值的简单情形中，熵由对数基数给出：$H(X) = \log |\mathcal{X}|$。一般来说，概率质量函数越分散（相应地，越集中），其熵越高（相应地，越低），如下例所示。

示例 1.1（伯努利分布）令 $X \sim$ 服从 Ber(p), 其中 $P_X(1) = p$ 且 $P_X(0) = \bar{p} \triangleq 1 - p$。则

$$H(X) = h(p) \triangleq p \log \frac{1}{p} + \bar{p} \log \frac{1}{\bar{p}}.$$

这里 $h(\cdot)$ 被称为 *binary entropy function*，它在 $[0, 1]$ 上连续、凹，关于 $\frac{1}{2}$ 对称，并满足 $h'(p) = \log \frac{p}{\bar{p}}$，在 0 和 1 处具有无穷斜率。最高熵在 $p = \frac{1}{2}$ (uniform) 处达到，而最低熵在 $p = 0$ 或 1（确定性）处达到。将二元熵函数的图与方差 $p(1-p)$ 进行比较是有启发性的。



例 1.2（几何分布）设 X 服从几何分布，其中 $P_X(i) = p\bar{p}^i, i = 0, 1, \ldots$。那么 $\mathbb{E}[X] = \frac{\bar{p}}{p}$ 且

$$H(X) = \mathbb{E}\Big[\log \frac{1}{p\bar{p}^X}\Big] = \log \frac{1}{p} + \mathbb{E}[X] \log \frac{1}{\bar{p}} = \frac{h(p)}{p}.$$

示例 1.3（无限熵）$H(X) = +\infty$ 可能吗？是的，例如，$\mathbb{P}[X = k] \propto \frac{1}{k \ln^2 k}, k = 2, 3, \ldots$。

许多常用的信息度量都有其对应的条件形式，通过将原始定义应用于条件概率测度并进一步求平均来定义。对于熵，其定义如下。

定义 1.3（条件熵） 设 X 为离散随机变量，Y 为任意变量。用 $P_{X|Y=y}(\cdot)$ 或 $P_{X|Y}(\cdot|y)$ 表示在给定 $Y = y$ 的条件下 X 的条件分布。在给定 Y 的条件下 X 的条件熵为

$$H(X|Y) = \mathbb{E}_{y\sim P_Y}[H(P_{X|Y=y})] = \mathbb{E}\Big[\log \frac{1}{P_{X|Y}(X|Y)}\Big].$$

注意，如果Y也是离散的，我们可以根据联合PMF $P_{X,Y}$ 和条件PMF $P_{X|Y}$ 来写出表达式，即

$$H(X|Y) = \sum_x \sum_y P_{X,Y}(x, y) \log \frac{1}{P_{X|Y}(x|y)}.$$

与熵类似，条件熵衡量的是当一个随机变量被揭示时，另一个随机变量剩余的随机性。因此，当Y独立于X时，$H(X|Y) = H(X)$。但当Y依赖于X时，观测Y确实会降低X的熵。在下一个定理中将其形式化之前，这里有一个具体的例子。

例1.4（条件熵与噪声信道）设Y为如下对$X \sim \text{Ber}(\frac{1}{2})$的噪声观测。

1 $Y = X \oplus Z$，其中 $\oplus$ 表示二进制加法（异或），且 $Z \sim \text{Ber}(\delta)$ 与 X 独立。换句话说，Y 以概率 δ 与 X 一致，并以概率 $\bar{\delta}$ 不一致。那么 $P_{X|Y=0} = \text{Ber}(\delta)$，且 $P_{X|Y=1} = \text{Ber}(\bar{\delta})$。由于 $h(\delta) = h(\bar{\delta})$，$H(X|Y) = h(\delta)$。注意当 $\delta = \frac{1}{2}$ 时，Y 与 X 独立，并且 $H(X|Y) = H(X) = 1$ `bits`；当 $\delta =$ 为 0 或 1 时，X 完全由 Y 决定，因此 $H(X|Y) = 0$。

2 $Y = X + Z$ 是实值的，其中 $Z \sim \mathcal{N}(0, \sigma^2)$。那么 $H(X|Y) = \mathbb{E}[h(\mathbb{P}[X = 1|Y])]$，其中 $\mathbb{P}[X = 1|Y = y] = \frac{\varphi(\frac{y-1}{\sigma})}{\varphi(\frac{y}{\sigma})+\varphi(\frac{y-1}{\sigma})}$ 且 $Y \sim \frac{1}{2}(\mathcal{N}(0, \sigma^2) + \mathcal{N}(1, \sigma^2))$。下面是 $H(X|Y)$ 作为 σ^2 的函数的数值图，可以证明其从 0 单调递增到 1`bit`。（提示：定理 1.4(d)。）

在讨论熵和条件熵的各种性质之前，让我们首先回顾一些凸分析中的相关事实，这些事实将在本书中广泛使用。

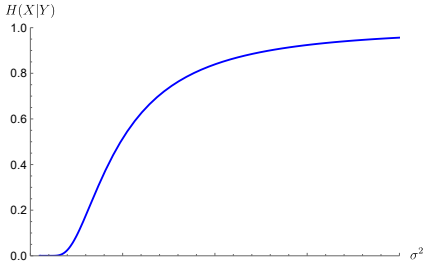


图1.1 给定高斯噪声观测的伯努利x的条件熵。

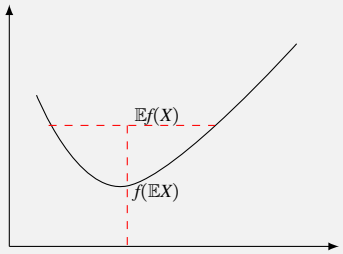
审查：凸性

- **Convex set**: A subset S of some vector space is *convex* if $x, y \in S \Rightarrow \alpha x + \bar{\alpha} y \in S$ for all $\alpha \in [0,1]$. (Recall: $\bar{\alpha} \triangleq 1 - \alpha$.)
  Examples: unit interval $[0,1]$; $S = \{\text{probability distributions on } \mathcal{X}\}$; $S = \{P_X : \mathbb{E}[X] = 0\}$.
- **Convex function**: $f : S \to \mathbb{R}$ is
  - *convex* if $f(\alpha x + \bar{\alpha} y) \le \alpha f(x) + \bar{\alpha} f(y)$ for all $x, y \in S, \alpha \in [0,1]$.
  - *strictly convex* if $f(\alpha x + \bar{\alpha} y) < \alpha f(x) + \bar{\alpha} f(y)$ for all $x \neq y \in S, \alpha \in (0,1)$.
  - *(strictly) concave* if $-f$ is (strictly) convex.

  Examples: $x \mapsto x \log x$ is strictly convex; the mean $P \mapsto \int x dP$ is convex but not strictly convex, variance is concave (Question: is it strictly concave? Think of zero-mean distributions.).
- **Jensen's inequality**:

  For any S-valued random variable X,

  - f is convex $\Rightarrow f(\mathbb{E}X) \le \mathbb{E}f(X)$
  - f is strictly convex $\Rightarrow f(\mathbb{E}X) < \mathbb{E}f(X)$, unless X is a constant ($X = \mathbb{E}X$ a.s.)



定理 1.4（熵的性质）

(a) (Positivity) $H(X) \ge 0$ with equality, iff X is a constant (no randomness).
(b) (Uniform distribution maximizes entropy) For finite $\mathcal{X}$, $H(X) \le$ 日志 $|\mathcal{X}|$, with equality iff X is uniform on $\mathcal{X}$.
(d) (Conditioning reduces entropy) $H(X|Y) \le H(X)$, with equality iff X and Y are independent.
(c) (Invariance) $H(X|Y) = H(X)$ if X and Y are independent.

(e) (Simple chain rule)

$$H(X,Y) = H(X) + H(Y|X) \le H(X) + H(Y). \tag{1.2}$$

(f) (Entropy under deterministic transformation) $H(X) = H(X,f(X)) \ge H(f(X))$ *with equality iff* f *is one-to-one on the support of* P_X.

(g) (Full chain rule)

$$H(X_1,\dots,X_n) = \sum_{i=1}^{n} H(X_i|X^{i-1}) \le \sum_{i=1}^{n} H(X_i), \tag{1.3}$$

with equality iff $X_1,\dots,X_n$ *are mutually independent.*

Proof. (a) 由于 $\log\frac{1}{P_X(X)}$ 是一个正随机变量，其期望 $H(X)$ 也是正的，且 $H(X)=0$ 当且仅当 $\log\frac{1}{P_X(X)} =$ 几乎必然为0，也就是说，P_X是一个点质量。

(b) 对严格凹函数 $x \mapsto \log x$ 应用詹森不等式：

$$H(X) = \mathbb{E}\left[\log\frac{1}{P_X(X)}\right] \le \log\mathbb{E}\left[\frac{1}{P_X(X)}\right] = \log|\mathcal{X}|.$$

(c) $H(X)$作为求和仅取决于P_X的值，而非位置。

(d) 简化 $P(x) \equiv P_X(x)$ 和 $P(x|y) \equiv P_{X|Y}(x|y)$。使用 $P(x) = \mathbb{E}_Y[P(x|Y)]$ 并将琴生不等式应用于严格凹函数 $x \mapsto x\log\frac{1}{x}$,

$$H(X|Y) = \sum_{x\in\mathcal{X}} \mathbb{E}_Y\left[P(x|Y)\log\frac{1}{P(x|Y)}\right] \le \sum_{x\in\mathcal{X}} P(x)\log\frac{1}{P(x)} = H(X).$$

此外，这也可由第3章推论3.5或第5章定理5.2得出（且与之等价）。

(e) 利用望远镜求和 $P_{X,Y}(X,Y) = P_{Y|X}(Y|X)P_X(X)$ 并注意到两边几乎必然为正 $P_{X,Y}$，我们有

$$\mathbb{E}\Big[\log\frac{1}{P_{X,Y}(X,Y)}\Big] = \mathbb{E}\Big[\log\frac{1}{P_X(X)\cdot P_{Y|X}(Y|X)}\Big] = \underbrace{\mathbb{E}\Big[\log\frac{1}{P_X(X)}\Big]}_{H(X)} + \underbrace{\mathbb{E}\Big[\log\frac{1}{P_{Y|X}(Y|X)}\Big]}_{H(Y|X)}$$

(f) 直觉是 $(X,f(X))$ 包含与 X 相同的信息量。实际上，$x \mapsto (x,f(x))$ 是一对一的。因此，根据 (c) 和 (e):

$$H(X) = H(X,f(X)) = H(f(X)) + H(X|f(X)) \ge H(f(X))$$

当且仅当 $H(X|f(X))=0$ 时达到该界，而这又当且仅当在给定 $f(X)$ 的情况下 X 是一个 *constant* 时发生。(g) 与 (e) 类似，通过 telescoping

$$P_{X_1X_2\cdots X_n} = P_{X_1}P_{X_2|X_1}\cdots P_{X_n|X^{n-1}}$$

然后取对数即可证明该等式。不等式由(d)得出，等号成立当且仅当对于$i=1,\dots,n$有 $P_{X_i|X^{i-1}} = P_{X_i}$，即$P_{X^n} = \prod_{i=1}^n P_{X_i}$。 □

为了预览熵的*operational meaning*，让我们玩*20 Questions*的游戏。我们可以通过提出*yes-no*个问题来查询某个未知的离散随机变量X。游戏的目标是猜测随机变量X的实现值。例如，$X \in \{a,b,c,d\}$具有$\mathbb{P}[X=a]=1/2$，$\mathbb{P}[X=b]=1/4$，以及$\mathbb{P}[X=c]=\mathbb{P}[X=d]=1/8$。在这种情况下，我们可以问“$X=a$? ”。如果不是，继续问“$X=b$? ”。如果不是，再问“$X=c$? ”，之后我们就能确定$X$的实现值。由此得到的平均问题数为$1/2+1/4\times 2+1/8\times 3+1/8\times 3=1.75$，这等于以比特为单位的$H(X)$。另一种策略是在第一轮问“$X=a,b$或$c,d$”，然后在第二轮确定值，这总是需要两个问题，平均表现更差。

事实证明（第10.3节），确定X值所需的最少是/否问题平均数总是介于$H(X)$ `bits`和$H(X)+1$ `bits`之间。在这个特殊情况下，上述方案是最优的，因为（直观上）它总是将概率一分为二。

1.2 公理化特征

人们可能会好奇为什么熵被定义为$H(P)=\sum p_i \log\frac{1}{p_i}$，以及是否还有其他定义。事实上，熵的信息论定义与统计物理学中的熵有关。此外，它也是作为特定操作问题的答案而出现的，例如上文讨论的描述一个随机变量所需的最小平均比特数。因此，可以说它并非凭空而来。

1948年，香农在其论文中也展示了熵可以被定义*axiomatically*，作为一个满足若干自然条件的函数。将以$P=(p_1,\dots,p_m)$表示在m个字母上的概率分布，并考虑一个泛函$H_m(p_1,\dots,p_m)$。如果H_m遵循以下公理：

(a) 排列不变性：对于$[m]$上的任意排列π，有$H_m(p_{\pi(1)},\dots,p_{\pi(m)})=H_m(p_1,\dots,p_m)$。(b) 可扩展性：$H_m(p_1,\dots,p_{m-1},0)=H_{m-1}(p_1,\dots,p_{m-1})$。(c) 归一化：$H_2(\frac{1}{2},\frac{1}{2})=\log 2$。(d) 次可加性：$H(X,Y)\le H(X)+H(Y)$。等价地，当$\sum_{j=1}^n r_{ij}=p_i$和$\sum_{i=1}^m r_{ij}=q_j$时，$H_{mn}(r_{11},\dots,r_{mn})\le H_m(p_1,\dots,p_m)+H_n(q_1,\dots,q_n)$。(e) 可加性：如果$X \perp\!\!\!\perp Y$，则$H(X,Y)=H(X)+H(Y)$。等价地，$H_{mn}(p_1q_1,\dots,p_mq_n)=H_m(p_1,\dots,p_m)+H_n(q_1,\dots,q_n)$。(f) 连续性：当$p\to 0$时，$H_2(p,1-p)\to 0$。

那么$H_m(p_1,\dots,p_m)=\sum_{i=1}^m p_i\log\frac{1}{p_i}$是唯一的可能。感兴趣的读者可参阅[115，练习1.13]及其中的参考文献。

我们注意到还有其他有意义的随机性度量，特别包括由 Alfréd Rényi [356] 引入的*Rényi entropy of order* α

$$H_\alpha(P)\triangleq\begin{cases}\frac{1}{1-\alpha}\log\sum_{i=1}^m p_i^\alpha & \alpha\in(0,1)\cup(1,\infty)\\ \min_i \log\frac{1}{p_i} & \alpha=\infty.\end{cases} \tag{1.4}$$

(量 H_∞ 在密码学文献中也称为 *min-entropy*，或 $H_{\min}$)。可以验证

1 0 $\leq H_\alpha(P) \leq \log m$，其中下界（相应地，上界）在 P 为点质量（相应地，均匀分布）时达到；2 $H_\alpha(P)$ 关于 α 非增，并当 $\alpha \to 1$ 时趋于香农熵 $H(P)$。3 Rényi熵满足上述六条公理，但不满足次可加性。

1.3 熵的历史

在工业时代的早期，工程师们思索着是否有可能建造一台永动机。历经多次失败尝试后，能量守恒定律被提出：机器无法产生比其从周围世界消耗的能量更多的工作量。（这也被称为热力学的*first law*。）接下来的尝试转向构建一种机器，它能从温暖物体中以热量的形式吸取能量，并将其转换成等量（或近似等量）的工作。蒸汽机便是一例。然而，人们再次发现所有这类机器的效率极低。即，通过吸收热量Q所产生的工作量远小于Q。剩余的能量以热量的形式散失到周围环境中。在多次尝试各种设计之后，克劳修斯和开尔文又提出了另一条定律：

Second law 热力学：不存在这样一种机器，它循环工作（即周期性回到初始状态），产生有用功，并且对外界唯一的影响是从热源吸热。（也就是说，任何这样的机器，也必须向冷源排放一定量的热！）[1]

等价表述如下：“不存在将热量从低温物体传递到高温物体的循环过程”。也就是说，每一个这样的过程都需要消耗一定量的外部功来帮助实现；例如，遗憾的是，空调总是需要使用一些电力。

注意，与第一定律相比，第二定律有些令人困扰。在第一定律中，存在一个守恒量，这在逻辑上容易接受。第二定律似乎较难令人信服（有些工程师并不相信，只有他们屡次尝试规避却最终失败，才使他们信服）。因此，克劳修斯在S.卡诺的巧妙工作基础上，发现了任何循环机器为何必须消耗热量的“解释”。他提出，必定存在某种与机器相关的隐藏量，即其熵（最初被描述为“转化内容”或德语中的*Verwandlungsinhalt*），其值必须恢复到原始状态。此外，在任何可逆（即准静态，或“非常缓慢”）的过程中，对该机器进行操作时，熵的变化与以下比率成正比：

[1] Note that the reverse effect (that is converting work into heat) is rather easy: friction is an example.

吸收的热量和机器的温度:

$$\Delta S = \frac{\Delta Q}{T}\,. \tag{1.5}$$

如果在温度 T_{hot} 下吸收热量 Q，那么为了回到初始状态，必须返还一定量的热量 Q'，其中 Q' 可以显著小于 Q，但如果 Q' 是在温度 $0 < T_{\text{cold}} < T_{\text{hot}}$ 下返还的，则永远不可能为零。进一步的逻辑论证可以使人相信，对于不可逆循环过程，循环结束时的熵变只能是正值，因此 *entropy cannot reduce*。

第二定律产生了大量经实验验证的推论。然而，令人惊讶的是，神秘的熵并没有任何计算公式（不像能量那样），因此只能基于关系式（1.5）间接计算。这一状况随着玻尔兹曼和吉布斯革命性的工作而改变，他们基于统计物理原理为第二定律提供了微观解释，并证明了例如对于一个由n个独立粒子组成的系统（如理想气体），给定宏观态的熵可以计算为

$$S = kn\sum_{j=1}^{\ell} p_j \log\frac{1}{p_j}\,, \tag{1.6}$$

其中k是玻尔兹曼常数，我们假设每个粒子只能处于ℓ个分子态之一（例如自旋向上/向下，或者我们将相空间体积量子化为ℓ个子立方体），而p_j是处于第j个分子态的粒子比例。

更明确地说，他们的创新有两点。首先，他们区分了微观状态的概念（在我们上面的例子中，这对应于一个 n 状态的元组，每个粒子一个）和宏观状态（一个列出每个状态中粒子比例的列表 $\{p_j\}$）。其次，他们假设只有宏观状态对实验观察重要，但宏观状态的多重性（对应于给定宏观状态的微观状态数量）正是熵的（指数）。公式 (1.6) 随后由以下连接组合学与熵的显式结果得出。

命题1.5（类型方法）*Let $n_1,\dots,n_k$ be non-negative integers with $\sum_{i=1}^k n_i = n$, and denote the distribution $P = (p_1,\dots,p_k)$, $p_i = \frac{n_i}{n}$. Then the multinomial coefficient $\binom{n}{n_1,\dots n_k} \triangleq \frac{n!}{n_1!\cdots n_k!}$ satisfies*

$$\frac{1}{(1+n)^{k-1}}\exp\{nH(P)\} \le \binom{n}{n_1,\dots n_k} \le \exp\{nH(P)\}\,.$$

Proof. 对于上界，令 $X_1,\dots,X_n \overset{\text{i.i.d.}}{\sim} P$ 并令 $N_i = \sum_{i=1}^n 1\{X_j = i\}$ 表示 i 的出现次数。那么 $(N_1,\dots,N_k)$ 服从多项分布:

$$\mathbb{P}[N_1 = n_1',\dots,N_k = n_k'] = \binom{n}{n_1',\dots,n_k'}\prod_{i=1}^k p_i^{n_i'},$$

对于任意非负整数 n_i'，满足 $n_1' + \cdots + n_k' = n$。回想 $p_i = n_i/n$，上界由 $\mathbb{P}[N_1 = n_1,\dots,N_k = n_k] \le 1$ 得出。此外，由于 $(N_1,\dots,N_k)$ 最多取

$(n+1)^k$–1 值，下界成立，前提是我们能证明 $(n_1,\dots,n_k)$ 是其众数。实际上，对于任意满足 $n_1'+\cdots+n_k'=n$ 的 n_i'，定义 $\Delta_i = n_i' - n_i$，我们有

$$\frac{\mathbb{P}[N_1=n_1',\dots,N_k=n_k']}{\mathbb{P}[N_1=n_1,\dots,N_k=n_k]} = \prod_{i=1}^k \frac{n_i!}{(n_i+\Delta_i)!} p_i^{\Delta_i} \le \prod_{i=1}^k n_i^{-\Delta_i} p_i^{\Delta_i} = 1,$$

其中不等式由 $\frac{m!}{(m+\Delta)!} \le m^{-\Delta}$ 推出，最后一个等式由 $\sum_{i=1}^n \Delta_i = 0$ 推出。

□

命题 1.5 表明，多项式项（在 n 中）可以通过 $\exp(nH(P))$ 来近似多项式系数。可以得到更精细的估计；参见练习 I.2。特别地，二项式系数可以使用二元熵函数近似如下：假设 $p=\frac{k}{n}\in(0,1)$，

$$e^{-1/6} \le \frac{\binom{n}{k}}{\frac{1}{\sqrt{2\pi np(1-p)}} e^{nh(p)}} \le 1. \tag{1.7}$$

关于组合数学和熵的更多信息，参见练习I.1、I.3和第8章。关于统计描述、机械描述和信息论描述之间复杂关系的更多内容，参见第12.5*节关于柯尔莫哥洛夫-西奈熵的讨论。

1.4* 子模性

回想一下，$[n]$ 表示集合 $\{1,\dots,n\}$，$\binom{S}{k}$ 表示 S 的大小为 k 的子集，而 2^S 表示 S 的所有子集。一个集合函数 $f\colon 2^S\to\mathbb{R}$ 被称为 *submodular*，如果对于任何 $T_1,T_2\subset S$

$$f(T_1\cup T_2)+f(T_1\cap T_2)\le f(T_1)+f(T_2) \tag{1.8}$$

子模性类似于凹性，即“添加元素会带来递减的回报”。确实，考虑 $T'\subset T$ 和 $b\notin T$。那么

$$f(T\cup b)-f(T)\le f(T'\cup b)-f(T')\,.$$

定理 1.6 *Let X^n be discrete RV. Then $T\mapsto H(X_T)$ is submodular.*

Proof. 设 {v*}。那么我们需要证明

$$H(A,B,C)+H(B)\le H(A,B)+H(B,C)\,.$$

这源于一条简单的链

$$\begin{aligned} H(A,B,C)+H(B) &= H(A,C|B)+2H(B) && (1.9)\\ &\le H(A|B)+H(C|B)+2H(B) && (1.10)\\ &= H(A,B)+H(B,C) && (1.11)\end{aligned}$$

□

注意，熵不仅是子模的，而且是单调的：

$$T_1 \subset T_2 \implies H(X_{T_1}) \le H(X_{T_2}) .$$

因此，固定 n，让我们用 Γ_n 表示 $[n]$ 上所有非负、单调、子模集函数的集合。注意，通过对 $[n]$ 的所有非空子集进行显然的枚举，Γ_n 是 $\mathbb{R}_+^{2^n-1}$ 中的一个闭凸锥。类似地，让我们用 Γ_n^* 表示对应于 X^n 上分布的所有集函数的集合。我们还需要用 $\bar{\Gamma}_n^*$ 表示 Γ_n^* 的闭包。不难证明，参见 [472]，$\bar{\Gamma}_n^*$ 也是一个闭凸锥，并且

$$\Gamma_n^* \subset \bar{\Gamma}_n^* \subset \Gamma_n .$$

[473]的惊人结果是

$$\Gamma_2^* = \bar{\Gamma}_2^* = \Gamma_2 \tag{1.12}$$

$$\Gamma_3^* \subsetneq \bar{\Gamma}_3^* = \Gamma_3 \tag{1.13}$$

$$\Gamma_n^* \subsetneq \bar{\Gamma}_n^* \subsetneq \Gamma_n \qquad n \ge 4 . \tag{1.14}$$

这源自一个基本的新信息不等式，它并非由熵的子模性所暗示（因此被称为 *non-Shannon inequality*）。即，[473]证明了对于任意四元离散随机变量：

$$I(X_3;X_4) - I(X_3;X_4|X_1) - I(X_3;X_4|X_2) \le \frac{1}{2}I(X_1;X_2) + \frac{1}{4}I(X_1;X_3,X_4) + \frac{1}{4}I(X_2;X_3,X_4) .$$

这里我们使用了互信息和条件互信息——这些概念我们将在后面介绍。然而，上述不等式（借助定理3.4）可以很容易地被改写为一个用变量集合的熵表示的相当繁琐的表达式 X_1, X_2, X_3, X_4。总之，文献[473]表明，即使只考虑线性约束，熵集函数也比一般的子模非负集函数受到更多约束。

1.5* 汉不等式与希勒引理

定理 1.7（Han 不等式）*Let X^n be discrete n-dimensional RV and denote $\bar{H}_k(X^n) = \frac{1}{\binom{n}{k}} \sum_{T \in \binom{[n]}{k}} H(X_T)$ the average entropy of a k-subset of coordinates. Then $\frac{\bar{H}_k}{k}$ is decreasing in k:*

$$\frac{1}{n}\bar{H}_n \le \cdots \le \frac{1}{k}\bar{H}_k \cdots \le \bar{H}_1 . \tag{1.15}$$

Furthermore, the sequence $\bar{H}_k$ is increasing and concave in the sense of decreasing slope:

$$\bar{H}_{k+1} - \bar{H}_k \le \bar{H}_k - \bar{H}_{k-1} . \tag{1.16}$$

Proof. 为方便起见，将 $\bar{H}_0 =$ 记为 0。注意，$\frac{\bar{H}_m}{m}$ 是差值的平均值：

$$\frac{1}{m}\bar{H}_m = \frac{1}{m}\sum_{k=1}^{m}(\bar{H}_k - \bar{H}_{k-1})$$

因此，显然（1.16）蕴含（1.15），因为将 m 增加一会在平均值中加入一个更小的元素。为了证明（1.16），观察到由子模性

$$H(X_1,\dots,X_{k+1})+H(X_1,\dots,X_{k-1})\le H(X_1,\dots,X_k)+H(X_1,\dots,X_{k-1},X_{k+1})\,.$$

现在平均 对所有 n 个索引排列 $\{1,\dots,n$ 求此不等式 $\}$ 以获得 {v*}

$$\bar H_{k+1}+\bar H_{k-1}\le 2\bar H_k$$

如(1.16)所声称的那样。

替代证明：注意，根据“条件作用减少熵”，我们有

$$H(X_{k+1}|X_1,\dots,X_k)\le H(X_{k+1}|X_2,\dots,X_k)\,.$$

平均对所有索引排列进行此不等式的年龄化处理得到 (1.16)。 □

定理 1.8（Shearer 引理）*Let X^n be discrete n-dimensional RV and let $S\subset[n]$ be a random variable independent of X^n and taking values in subsets of $[n]$. Then*

$$H(X_S|S)\ge H(X^n)\cdot\min_{i\in[n]}\mathbb{P}[i\in S]\,. \tag{1.17}$$

备注 1.2 在 S 在所有基数为 k 的子集上均匀分布的特殊情况下，(1.17) 简化为 Han 不等式 $\frac{1}{n}H(X^n)\le\frac{1}{k}\bar H_k$。$n=3$ 和 $k=2$ 的情况可用于给出以下著名几何结果的熵证明，该结果将三维对象的大小与其二维投影的大小联系起来：将 N 个点任意放置在 $\mathbb{R}^3$ 中。令 N_1,N_2,N_3 分别表示投影到 xy、xz 和 yz 平面上的不同点的数量。那么 $N_1N_2N_3\ge N^2$。关于另一个应用，见第 8.2 节。

Proof. 我们将证明一个等价的（通过取适当极限）版本：如果 $\mathcal{C}=(S_1,\dots,S_M)$ 是 $[n]$ 的子集的一个列表（可能包含重复项），那么

$$\sum_j H(X_{S_j})\ge H(X^n)\cdot\min_i\deg(i)\,, \tag{1.18}$$

其中 $\deg(i)\triangleq\#\{j:i\in S_j\}$。如果所有子集都能重新排列使得 $S_1\subseteq S_2\cdots\subseteq S_M$，我们就称 $\mathcal{C}$ 为一个 *chain*。对于链来说，(1.18) 是平凡的，因为右侧的最小值要么为零（如果 $S_M\ne[n]$），要么等于 S_M 在 $\mathcal{C}$、[2] 中的重数，在这种情况下我们有

$$\sum_j H(X_{S_j})\ge H(X_{S_M})\#\{j:S_j=S_M\}=H(X^n)\cdot\min_i\deg(i)\,.$$

对于 $\mathcal{C}$ 不是链的情况，考虑一对不被包含关系所关联的集合 S_1,S_2，并将它们替换为 $S_1\cap S_2,S_1\cup S_2$。子模性 (1.8) 意味着在替换下 (1.18) 左侧的和不增加，值 $\deg(i)$ 不变。

[2] Note that, consequently, for X^n without constant coordinates, and if $\mathcal{C}$ is a chain, (1.18) is only tight if $\mathcal{C}$ consists of only $\emptyset$ and $[n]$ (with multiplicities). Thus if degrees $\deg(i)$ are known and non-constant, then (1.18) can be improved, cf. [288].

注意，严格来说，通过这种替换，不因包含关系而相关的配对总数会减少：如果T与S_1通过包含关系相关，那么它也将至少与$S_1 \cup S_2$或$S_1 \cap S_2$之一相关；如果T与S_1, S_2两者都相关，那么它也将与新集合中的两者都相关。因此，通过应用这一操作，我们最终必然能得到一个链，对于该链，(1.18)已被证明。

□

注1.3 汉氏不等式（1.16）对任何子模集函数均成立。对于汉氏不等式（1.15），我们还需要$f(\emptyset) = 0$（这可以通过给f的所有值加上一个常数来实现）。Shearer引理适用于任何非负的子模集函数。

例1.5（非熵次模函数）另一个次模集合函数是

$$S \mapsto I(X_S; X_{S^c}) .$$

关于这个的Han不等式读作

$$0 = \frac{1}{n} I_n \leq \cdots \leq \frac{1}{k} I_k \cdots \leq I_1 ,$$

其中 $I_k = \frac{1}{\binom{n}{k}} \sum_{S:|S|=k} I(X_S;\ X_{S^c})$ 度量随机向量 X^n 中 k-子集耦合的程度。

2 Divergence

在本章中，我们研究散度$D(P\|Q)$ (，也称为信息散度、Kullback-Leibler（KL)散度、相对熵），这是一对分布P和Q之间相异性（信息）度量的第一个例子。正如我们将在第7章中看到的，KL散度是f-散度的一个特例。完全一般性地定义KL散度及其条件版本需要一些测度论的技巧（Radon-Nikodym导数和马尔可夫核），我们将花一些时间讨论这些内容。（我们再次强调，如果只愿意处理有限或可数无限字母表，所有这些抽象概念都可以忽略。）

除了定义之外，我们还证明了“主要不等式”，表明KL散度是非负的。结合散度的链式法则，这一不等式蕴含了数据处理不等式，后者可以说是信息论及本书的核心支柱。本章结尾，我们研究了当P与Q接近时散度的局部行为。在P和Q属于参数族的特殊情况下，我们将看到散度局部上是二次的，其Hessian矩阵为Fisher信息，从而解释了后者在经典统计学中的基础性作用。

2.1 散度与Radon-Nikodym导数

审查：可测性

关于测度论预备知识的阐述，参见[84，第一章和第四章]。我们强调两个方面。*First,*在本书中，我们将Lebesgue积分$\int_{\mathcal{X}} f d\mu$理解为针对可测函数定义的，这些函数是扩展实值的，即f: $\mathcal{X} \to \mathbb{R} \cup \{\pm\infty\}$。特别地，对于可忽略集$E$，即$\mu[E]=0$，我们有$\int_{\mathcal{X}} 1_E f d\mu = 0$，无论$f$在$E$上的值（可能为无穷大）如何，参见[84，第一章，命题4.13]。*Second,*我们几乎总是假设字母表是标准Borel空间。标准Borel空间的一些优良性质：

• 所有完备可分度量空间，若赋予博雷尔σ-代数，则都是标准博雷尔空间。特别地，可数字母表、$\mathbb{R}^n$以及$\mathbb{R}^\infty$ (序列空间)都是标准博雷尔空间。• 如果$\mathcal{X}_i, i = 1, \ldots$是标准博雷尔空间，那么$\prod_{i=1}^{\infty} \mathcal{X}_i$也是。• 单点集$\{x\}$是可测集。• 对角线$\{(x,x)$: $x \in \mathcal{X}\}$在$\mathcal{X} \times \mathcal{X}$中是可测的。

现在我们需要定义本书的第二个核心概念：*relative entropy*，或*Kullback-Leibler divergence*。在给出正式定义之前，我们先从特殊情况开始。为此，我们固定某个字母表$\mathcal{A}$。在$\mathcal{X}$上的分布P和Q之间的相对熵记为$D(P\|Q)$，定义如下。

- 假设 $\mathcal{A}$ 是一个离散（有限或可数无限）字母表。那么

$$D(P\|Q) \triangleq \begin{cases} \sum_{a\in\mathcal{A}:P(a),Q(a)>0} P(a)\log\frac{P(a)}{Q(a)}, & \text{supp}(P)\subset\text{supp}(Q) \\ +\infty, & \text{otherwise} \end{cases} \tag{2.1}$$

- 假设 $\mathcal{A}=\mathbb{R}^k$、P 和 Q 相对于勒贝格测度有密度（概率密度函数）p 和 q。那么

$$D(P\|Q) = \begin{cases} \int_{\{p>0,q>0\}} p(x)\log\frac{p(x)}{q(x)}dx & \text{Leb}\{p>0,q=0\}=0 \\ +\infty & \text{otherwise} \end{cases} \tag{2.2}$$

这两个特殊情况涵盖了本书中我们遇到的大多数情形。然而，从数学角度看，仅局限于这两种特殊情况并不十分令人满意。例如，当P和Q是嵌入在$\mathbb{R}^k$中的流形（如单位球面）上的两个测度时，如何计算$D(P\|Q)$尚不明确。另一个有问题的情形是计算序列空间（随机过程）上的测度之间的$D(P\|Q)$。为了处理这些情况，我们需要回顾*Radon-Nikodym derivative*和*absolute continuity*的概念。

回想一下，对于两个测度 P 和 Q，我们说 P 关于 Q (绝对连续，记作 $P\ll Q$)，如果对于所有可测集 E，当 $Q(E)=$ 为 0 时，必有 $P(E)=$ 为 0。若 $P\ll Q$ 成立，则 Radon-Nikodym 定理表明存在一个函数 $f\colon\mathcal{X}\to\mathbb{R}_+$，使得对于任何可测集 E,

$$P(E)=\int_E f dQ. \qquad \text{[change of measure]} \tag{2.3}$$

这样的 f 被称为 *relative density* 或 P 关于 Q 的 Radon-Nikodym 导数，记为 $\frac{dP}{dQ}$。注意 $\frac{dP}{dQ}$ 可能不唯一。在简单情况下，$\frac{dP}{dQ}$ 就是熟悉的 *likelihood ratio*:

- 对于离散分布，我们只需取 $\frac{dP}{dQ}(x)$ 为概率质量函数的比值。 - 对于连续分布，我们可以取 $\frac{dP}{dQ}(x)$ 为概率密度函数的比值。

我们可以看到，$D(P\|Q)$的两种特殊情况都在计算 $\mathbb{E}_P[\log\frac{dP}{dQ}]$。这恰好是我们正在寻找的最通用定义。然而，按照传统，我们将稍微不同地表述它。

定义2.1（Kullback-Leibler (KL) 散度）设 P,Q 为 $\mathcal{A}$ 上的分布，其中 Q 称为参考测度。P 与 Q 之间的散度（或相对熵）为

$$D(P\|Q)=\begin{cases} \mathbb{E}_Q[\frac{dP}{dQ}\log\frac{dP}{dQ}] & P\ll Q \\ +\infty & \text{otherwise} \end{cases} \tag{2.4}$$

再次采用（1.1）中的约定，即$0 \log 0 = 0$。

下面我们将展示（引理2.5），(2.4)中的期望是有良好定义的（但可能无限），并且只要$P \ll Q$，就与$\mathbb{E}_P[$日志$\frac{dP}{dQ}]$一致。

为了证明在离散/连续特化未涵盖的情况下的通用定义，考虑以下情形：P和Q均作为关于共同支配测度μ的密度给出，对于某个非负的f_P, f_Q，写为$dP = f_P d\mu$和$dQ = f_Q d\mu$。（换句话说，$P \ll \mu$和$f_P = \frac{dP}{d\mu}$。）例如，取$\mu = P + Q$总是允许以这种形式指定P和Q。在这种情况下，我们有以下散度表达式：

$$D(P\|Q) = \begin{cases} \int_{f_Q>0, f_P>0} d\mu\, f_P \log \frac{f_P}{f_Q} & \mu(\{f_Q = 0, f_P > 0\}) = 0, \\ +\infty & \text{otherwise} \end{cases} \tag{2.5}$$

事实上，首先注意到，在 $P \ll \mu$ 和 $Q \ll \mu$ 的假设下，我们有 $P \ll Q$ 当且仅当 $\mu(\{f_Q = 0, f_P > 0\}) = 0$。此外，如果 $P \ll Q$，则 $\frac{dP}{dQ} = \frac{f_P}{f_Q}$ Q-几乎处处成立，此时应用 (2.3) 和 (1.1) 将 (2.5) 简化为 (2.4)。即，$D(P\|Q) = \mathbb{E}_Q[\frac{dP}{dQ} \log \frac{dP}{dQ}] = \mathbb{E}_Q[\frac{f_P}{f_Q} \log \frac{f_P}{f_Q}] = \int d\mu f_P \log \frac{f_P}{f_Q} 1\{f_Q > 0\} = \int d\mu f_P \log \frac{f_P}{f_Q} 1\{f_Q > 0, f_P > 0\}$。

请注意，$D(P\|Q)$ 被定义为 $+\infty$ 如果 $P \not\ll Q$。然而，即使当 $P \ll Q$ 时，它也可以是 $+\infty$。例如，$D(\text{Cauchy}\|\text{Gaussian}) = \infty$。但这并不意味着 D 可以无限的方式存在两种不同的情况。事实上，可以表明的是，在两种情况下，都存在一系列（越来越细的）有限分割 Π 的空间 $\mathcal{A}$，使得评估诱导离散分布 $P_{|\Pi}$ 和 $Q_{|\Pi}$ 之间的KL散度无界增长。这将是下文定理4.5的主题。

我们的下一个观察是，通常情况下，$D(P\|Q) \neq D(Q\|P)$，因此，散度不是距离。我们稍后会看到，在许多情况下这是自然的；例如，它反映了假设检验固有的*asymmetry*（参见第三部分，特别是第14.5节）。考虑抛硬币的例子，在P下硬币是公平的，而在Q下硬币总是正面朝上。在观察到HHHHHHH后，人们倾向于相信它是Q，但永远无法绝对确定；在观察到HHT后，人们确切知道它是P。确实，$D(P\|Q) = \infty$，$D(Q\|P) = 1$ bit。

已经做出这些说明，我们继续看一些例子。首先，我们展示 D 毫不意外地是熵的一种推广。

定理 2.2（熵与散度）*If distribution P is supported on a finite set $\mathcal{A}$, then*

$$H(P) = \log |\mathcal{A}| - D(P\|U_{\mathcal{A}}),$$

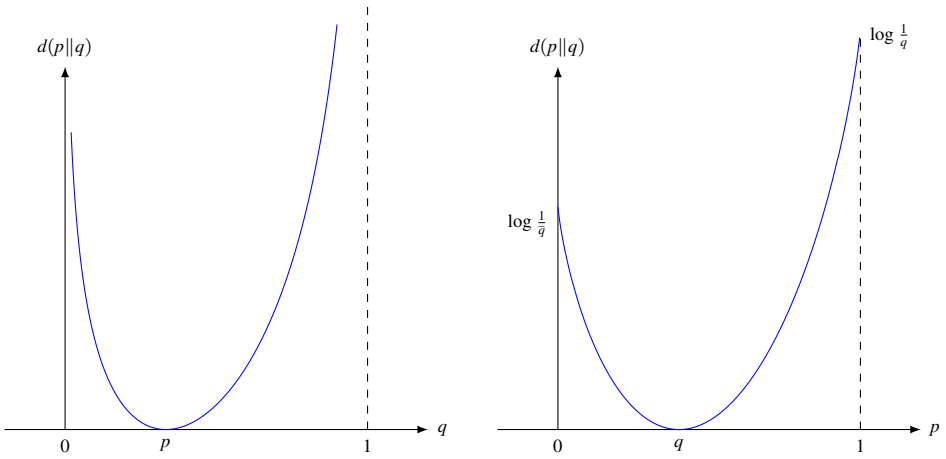
where $U_{\mathcal{A}}$ is the uniform distribution on $\mathcal{A}$.

Proof. $D(P\|U_{\mathcal{A}}) = \mathbb{E}_P[\log \frac{P(X)}{1/|\mathcal{A}|}] = \log |\mathcal{A}| - H(P)$。 □

示例 2.1（二元散度）考虑 $\mathcal{A} = \{0, 1\}$ 上的 $P = \text{Ber}(p)$ 和 $Q = \text{Ber}(q)$。那么

$$D(P\|Q) = d(p\|q) \triangleq p \log \frac{p}{q} + \bar{p} \log \frac{\bar{p}}{\bar{q}}. \tag{2.6}$$

以下是 $d(p\|q)$ 如何取决于 p 和 q:



以下二次下界易于验证:

$$d(p\|q) \geq 2(p-q)^2 \log e\,.$$

事实上，这是著名的平斯克不等式（定理7.10）的一个特例。

示例 2.2（实高斯）对于 $\mathcal{A} = \mathbb{R}$ 上的两个高斯分布，

$$D(\mathcal{N}(m_1,\sigma_1^2)\|\mathcal{N}(m_0,\sigma_0^2)) = \frac{\log e}{2}\frac{(m_1-m_0)^2}{\sigma_0^2} + \frac{1}{2}\Big[\log\frac{\sigma_0^2}{\sigma_1^2} + \Big(\frac{\sigma_1^2}{\sigma_0^2}-1\Big)\log e\Big]. \tag{2.7}$$

这里，第一项和第二项分别比较均值和方差。类似地，在 $\mathcal{A} = \mathbb{R}^k$ 的向量情况下，并假设 $\det\Sigma_0 \neq 0$，我们有

$$\begin{aligned} &D(\mathcal{N}(m_1,\Sigma_1)\|\mathcal{N}(m_0,\Sigma_0)) \\ &= \frac{\log e}{2}(m_1-m_0)^\top\Sigma_0^{-1}(m_1-m_0) + \frac{1}{2}\Big(\log\det\Sigma_0 - \log\det\Sigma_1 + \operatorname{tr}(\Sigma_0^{-1}\Sigma_1 - I)\log e\Big). \end{aligned} \tag{2.8}$$

关于推导过程，参见练习 I.8。

例2.3（复高斯分布）具有均值$m \in \mathbb{C}$和方差σ^2的复高斯分布$\mathcal{N}_c(m,\sigma^2)$，其密度函数为$\frac{1}{\pi\sigma^2}e^{-|z-m|^2/\sigma^2}$，对于$z \in \mathbb{C}$。换言之，实部和虚部是独立的实高斯分布：

$$\mathcal{N}_c(m,\sigma^2) = \mathcal{N}\left(\begin{bmatrix}\operatorname{Re}(m) & \operatorname{Im}(m)\end{bmatrix}, \begin{bmatrix}\sigma^2/2 & 0\\ 0 & \sigma^2/2\end{bmatrix}\right)$$

然后

$$D(\mathcal{N}_c(m_1,\sigma_1^2)\|\mathcal{N}_c(m_0,\sigma_0^2)) = \frac{\log e}{2}\frac{|m_1-m_0|^2}{\sigma_0^2} + \log\frac{\sigma_0^2}{\sigma_1^2} + \Big(\frac{\sigma_1^2}{\sigma_0^2}-1\Big)\log e. \tag{2.9}$$

这由(2.8)得出。更一般地，对于$\mathbb{C}^k$上的复高斯向量，假设$\det \Sigma_0 \neq \neq 0$,

$$\begin{aligned} D(\mathcal{N}_c(m_1,\Sigma_1)\|\mathcal{N}_c(m_0,\Sigma_0)) =& (m_1-m_0)^H\Sigma_0^{-1}(m_1-m_0)\log e \\ &+ \log\det\Sigma_0 - \log\det\Sigma_1 + \mathrm{tr}(\Sigma_0^{-1}\Sigma_1 - I)\log e \end{aligned}$$

2.2 散度：主要不等式与等价表达式

信息论中的许多不等式都可以归因于以下基本结果，即散度的非负性。

定理2.3（信息不等式）

$$D(P\|Q) \geq 0,$$

with equality iff $P = Q$.

Proof. 鉴于定义（2.4），只需考虑 $P \ll Q$。设 $\varphi(x) \triangleq x$ 为对数 x，其在 $\mathbb{R}_+$ 上严格凸。应用琴生不等式:

$$D(P\|Q) = \mathbb{E}_Q\left[\varphi\left(\frac{dP}{dQ}\right)\right] \geq \varphi\left(\mathbb{E}_Q\left[\frac{dP}{dQ}\right]\right) = \varphi(1) = 0,$$

等式成立的充要条件是 $\frac{dP}{dQ} = 1$ Q-几乎处处，即 $P = Q$。 □

这里是前一结果的典型应用（本书中将多次应用其变体）。这一结果在机器学习中被广泛使用，因为它表明最小化平均交叉熵损失$\ell(Q,x) \triangleq \log\frac{1}{Q(x)}$可以恢复真实分布（练习III.11）。

推论 2.4 *Let X be a discrete random variable with $H(X) < \infty$. Then*

$$\min_Q \mathbb{E}\left[\log\frac{1}{Q(X)}\right] = H(P)\,,$$

and unique minimizer is $Q = P_X$.

Proof. 足以证明对于任意 $Q \neq P_X$，我们有

$$\mathbb{E}\left[\log\frac{1}{Q(X)}\right] > H(X)\,.$$

如果左边是无穷大，这一点显然成立，因此我们假设其为有限，从而只要$P_X(x) >$为0，就有$Q(x) >$为0。接着，从两边减去$H(X)$，并利用期望的线性性质，我们得到

$$\mathbb{E}\left[\log\frac{1}{Q(X)}\right] - H(X) = \mathbb{E}\left[\log\frac{P_X(X)}{Q(X)}\right] = D(P_X\|Q) > 0$$

其中该不等式通过定理2.3得出。 □

定理2.3证明的另一个意义在于，它揭示了为何定义$D(P\|Q) = \mathbb{E}_Q[\frac{dP}{dQ}\log\frac{dP}{dQ}]$而非$D(P\|Q) = \mathbb{E}_P[\log\frac{dP}{dQ}]$的原因。然而，我们仍需证明这两个定义是等价的，这正是我们接下来要做的。此外，我们还将统一处理定义2.1中的两种情况（$P \ll Q$与$P \not\ll Q$）。

引理 2.5 *Let $P, Q, R \ll \mu$ and f_P, f_Q, f_R denote their densities relative to μ. Define a bivariate function* 对数$\frac{a}{b}$： $\mathbb{R}_+ \times \mathbb{R}_+ \to \mathbb{R} \cup \{\pm\infty\}$ *by*

$$\mathrm{Log}\frac{a}{b} = \begin{cases} -\infty & a = 0, b > 0 \\ +\infty & a > 0, b = 0 \\ 0 & a = 0, b = 0 \\ \log\frac{a}{b} & a > 0, b > 0. \end{cases} \tag{2.10}$$

Then the following results hold:

- *First, the following expectation exists and equals*

$$\mathbb{E}_P\left[\mathrm{Log}\frac{f_R}{f_Q}\right] = D(P\|Q) - D(P\|R)\,, \tag{2.11}$$

  provided at least one of the divergences is finite.
- *Second, the expectation $\mathbb{E}_P\left[$记录$\frac{f_R}{f_Q}\right]$ is well-defined (but possibly infinite) and, furthermore,*

$$D(P\|Q) = \mathbb{E}_P\left[\mathrm{Log}\frac{f_P}{f_Q}\right]\,. \tag{2.12}$$

  In particular, when $P \ll Q$ we have

$$D(P\|Q) = \mathbb{E}_P\left[\log\frac{dP}{dQ}\right]\,. \tag{2.13}$$

注2.1 注意，忽略除以0或对0取对数的问题，(2.12)的证明仅仅是简单的恒等式$\log\frac{dR}{dQ} = \log\frac{dRdP}{dQdP} = \log\frac{dP}{dQ} - \log\frac{dP}{dR}$。使我们能够处理零的是Log函数，它满足对数的一些自然性质：对于每个$a, b \in \mathbb{R}_+$

$$\mathrm{Log}\frac{a}{b} = -\mathrm{Log}\frac{b}{a}$$

并且对于每个$c > 0$，我们有

$$\mathrm{Log}\frac{a}{b} = \mathrm{Log}\frac{a}{c} + \mathrm{Log}\frac{c}{b} = \mathrm{Log}\frac{ac}{b} - \log(c)$$

except 对于情况$a = b = 0$。

Proof. 首先，假设$D(P\|Q) = \infty$和$D(P\|R) < \infty$。然后$P[f_R(Y) = 0] = 0$，因此在计算（2.11）中的期望时，只有约定（2.10）的第二部分可能适用。由于$f_P > 0$ P-几乎必然成立，我们有

$$\mathrm{Log}\frac{f_R}{f_Q} = \mathrm{Log}\frac{f_R}{f_P} + \mathrm{Log}\frac{f_P}{f_Q}\,, \tag{2.14}$$

其中两个对数均按(2.10)式进行评估。对P取期望后，我们看到第一项等于$-D(P\|R)$，是有限的，而第二项则是无限的。因此，(2.11)式中的期望是有明确定义的，并且等于$+\infty$，这与(2.11)式左侧相同。

现在考虑 $D(P\|Q) < \infty$。这意味着 $P[f_Q(Y) = 0] = 0$，并且此时在 (2.11) 中只有约定 (2.10) 的第一部分适用。因此，我们同样得到恒等式 (2.14)。由于第二项的 P-期望是有限的，而第一项的期望是非负的，我们再次得出结论：(2.11) 中的期望是良定义的，等于 (2.11) 的左边（并且两边可能都等于 $-\infty$）。

对于第二部分，我们首先展示

$$\mathbb{E}_P\left[\min(\mathrm{Log}\frac{f_P}{f_Q}, 0)\right] \geq -\frac{\log e}{e}\,. \tag{2.15}$$

令$g(x) = \min(x\log x, 0)$。显然对于所有x，$-\frac{\log e}{e} \leq g(x) \leq 0$。由于对于$P$-几乎所有$Y$，$f_P(Y) > 0$，在约定(2.10)中仅$\frac{1}{0}$情形可能，而该情形被(2.15)期望中的$\min(\cdot, 0)$排除。因此，(2.15)中的LHS等于

$$\begin{aligned}\int_{\{f_P>f_Q>0\}} f_P(y)\log\frac{f_P(y)}{f_Q(y)}d\mu &= \int_{\{f_P>f_Q>0\}} f_Q(y)\frac{f_P(y)}{f_Q(y)}\log\frac{f_P(y)}{f_Q(y)}d\mu\\ &= \int_{\{f_Q>0\}} f_Q(y)g\left(\frac{f_P(y)}{f_Q(y)}\right)d\mu\\ &\geq -\frac{\log e}{e}\,.\end{aligned}$$

由于 $\mathbb{E}_P\left[\mathrm{Log}\frac{f_P}{f_Q}\right]$ 的负部分有界，期望 $\mathbb{E}_P\left[\mathrm{Log}\frac{f_P}{f_Q}\right]$ 是良定义的。如果 $P[f_Q = 0] > 0$，那么它显然是 $+\infty$，如同 $D(P\|Q)$ (，因为 $P \not\ll Q$)。否则，令 $E = \{f_P > 0, f_Q > 0\}$。那么 $P[E] = 1$，并且在 E 上有 $f_P = f_Q \cdot \frac{f_P}{f_Q}$。因此，我们得到

$$\mathbb{E}_P\left[\mathrm{Log}\frac{f_P}{f_Q}\right] = \int_E d\mu f_P \log\frac{f_P}{f_Q} = \int_E d\mu f_Q \varphi(\frac{f_P}{f_Q}) = \mathbb{E}_Q\left[1_E\varphi(\frac{f_P}{f_Q})\right].$$

由此，我们注意到 $Q[f_Q > 0] = 1$，而在 $\{f_P = 0, f_Q > 0\}$ 上我们有 $\varphi(\frac{f_P}{f_Q}) = 0$。因此，可以舍弃项 1_E，从而得到所需的 (2.12)。

引理的最终陈述由取$\mu = Q$并注意到P-几乎必然我们有得出

$$\mathrm{Log}\frac{\frac{dP}{dQ}}{1} = \log\frac{dP}{dQ}\,. \qquad \square$$

2.3 微分熵

$D(P\|Q)$ 的定义逐字扩展到测度 P 和 Q (不一定是概率测度)，此时 $D(P\|Q)$ 可以为负。$D(P\|Q) \geq 0$ 的一个充分条件是 P 是概率测度且 Q 是次概率测度，即 $\int dQ \leq 1 = \int dP$。*differential entropy* 的概念就是关于勒贝格测度的散度。

定义2.6 随机向量x的微分熵为

$$h(X) = h(P_X) \triangleq -D(P_X \| \mathrm{Leb}). \tag{2.16}$$

特别地，如果 X 具有概率密度函数（pdf）p，则 $h(X) = \mathbb{E}\log\frac{1}{p(X)}$；否则 $h(X) = -\infty$。条件微分熵为 $h(X|Y) \triangleq \mathbb{E}\log\frac{1}{p_{X|Y}(X|Y)}$，其中 $p_{X|Y}$ 是条件 pdf。

示例 2.4（高斯）对于 $X \sim N(\mu, \sigma^2)$，

$$h(X) = \frac{1}{2}\log(2\pi e\sigma^2) \tag{2.17}$$

更一般地，对于$\mathbb{R}^d$中的$X \sim N(\mu, \Sigma)$，

$$h(X) = \frac{1}{2}\log((2\pi e)^d \det\Sigma) \tag{2.18}$$

警告：即使对于连续随机变量 X，$h(X)$ 也可能是正的、负的、取值为 $\pm\infty$，甚至未定义。[1] 香农熵与微分熵之间存在许多关键差异。例如，由定理1.4可知，确定性处理不能增加香农熵，即对于任何离散的 X，有 $H(f(X)) \le H(X)$，这在直观上是显然的。然而，对于微分熵，这一点完全失效（例如考虑缩放）。此外，对于独立随机变量之和，对于整数值的 X 和 Y，只要 $H(X)$ 和 $H(Y)$ 有限，$H(X+Y)$ 就有限，因为 $H(X+Y) \le H(X,Y) = H(X)+H(Y)$。这一点对微分熵同样失效。事实上，存在实值 X 具有有限的 $h(X)$，使得对于任何独立的 Y（满足 $h(Y) > -\infty$），有 $h(X+Y) = \infty$；同时也存在具有有限微分熵的 X 和 Y，使得 $h(X+Y)$ 不存在（参见[65，第V节]）。

然而，微分熵与通常的香农熵在功能性质上有很多相似之处。关于其在欧几里得几何中的简短应用，参见第8.4节。

定理2.7（微分熵的性质）*Assume that all differential entropies appearing below exist and are finite (in particular all RVs have pdfs and conditional pdfs).*

(a) (Uniform distribution maximizes differential entropy) If $\mathbb{P}[X^n \in S] = 1$ *then* $h(X^n) \le$ 对数 $\mathrm{Leb}(S)$,*with equality iff* X^n *is uniform on* S.
(b) (Scaling and shifting) $h(X^n + x) = h(X^n), h(\alpha X^n) = h(X^n) +$ 对数 $|\alpha|$ *and for an invertible matrix* A, $h(AX^n) = h(X^n) +$ 对数 $|$ 行列式 $A|$.
(c) (Conditioning reduces differential entropy) $h(X|Y) \le h(X)$. *(Here* Y *is arbitrary.)*
(d) (Chain rule) Let X^n *has a joint probability density function. Then*

$$h(X^n) = \sum_{k=1}^{n} h(X_k|X^{k-1})\,.$$

1 例如，考虑一个分段常数概率密度函数，在第n个宽度为$\Delta_n = \frac{c}{n^2}e^{-(-1)^n n}$的区间上取值为$e^{(-1)^n n}$。

(e) (Submodularity) The set-function $T \mapsto h(X_T)$ is submodular.
(f) (Han's inequality) The function $k \mapsto \frac{1}{\binom{n}{k}} \sum_{T \in \binom{[n]}{k}} h(X_T)$ is decreasing in k.

Proof. (a)、(c)和(d)部分遵循定理1.4证明中(b)、(d)和(g)的类似论证。对于(b)部分，它是通过密度函数中的变量替换得出的。最后，(e)和(f)与定理1.6和1.7相类似。

□

有趣的是，第一个性质对于小的加性扰动是稳健的，参见例I.6。关于在二次约束下最大化熵，我们有如下高斯分布的特征描述。

定理 2.8 *Let* $\mathrm{Cov}(X) = \mathbb{E}[XX^\top] - \mathbb{E}[X]\mathbb{E}[X]^\top$ *denote the covariance matrix of a random vector X. For any $d \times d$ positive definite matrix Σ,*

$$\max_{P_X : \mathrm{Cov}(X) \preceq \Sigma} h(X) = h(N(0,\Sigma)) = \frac{1}{2}\log((2\pi e)^d \det \Sigma) \tag{2.19}$$

Furthermore, for any $a > 0$,

$$\max_{P_X : \mathbb{E}[\|X\|^2] \le a} h(X) = h\left(N\left(0, \frac{a}{d} I_d\right)\right) = \frac{d}{2}\log\frac{2\pi e a}{d}. \tag{2.20}$$

Proof. 为了展示（2.19），不失一般性，假设$\mathbb{E}[X] = 0$。通过对比高斯分布，我们有

$$\begin{aligned} 0 &\le D(P_X \| N(0,\Sigma)) \\ &= -h(X) + \frac{1}{2}\log((2\pi)^d \det(\Sigma)) + \frac{\log e}{2}\mathbb{E}[X^\top \Sigma^{-1} X] \\ &\le -h(X) + h(N(0,\Sigma)), \end{aligned}$$

其中最后一步我们应用了$\mathbb{E}[X^\top \Sigma^{-1} X] = \mathrm{Tr}(\mathbb{E}[XX^\top]\Sigma^{-1}) \le \mathrm{Tr}(I)$，这是基于约束$\mathrm{Cov}(X) \preceq \Sigma$和公式(2.18)。不等式(2.20)通过类似地选择参考测度为$N(0, \frac{a}{d} I_d)$而得出。

□

推论 2.9 *The map* $\Sigma \mapsto$ 对数行列式
Σ *is concave on the space of real positive definite $n \times n$ matrices.*

Proof. 令 Σ_1, Σ_2 为正定 $n \times n$ 矩阵。令 $Y \sim$ 服从 Ber(1/2)，且给定 $Y = 0$ 时令 $X \sim \mathcal{N}(0, \Sigma_1)$，否则 $X \sim \mathcal{N}(0, \Sigma_2)$。令 $\mathrm{Cov}(X) = \Sigma = \frac{1}{2}\Sigma_1 + \frac{1}{2}\Sigma_2$。则有 $h(X|Y) \le h(X) \le \frac{1}{2}\log((2\pi e)^n \det \Sigma)$。对于 $h(X|Y)$，我们应用 (2.18) 并化简后得到

$$\frac{1}{2}\log\det\Sigma_1 + \frac{1}{2}\log\det\Sigma_2 \le \log\det\left(\frac{1}{2}\Sigma_1 + \frac{1}{2}\Sigma_2\right),$$

这正是所声称的凹性。 □

最后，让我们提及微分熵与香农熵之间的联系。设 X 为 $\mathbb{R}^d$ 中的连续随机向量。将其离散化版本记为 $X_m = \frac{1}{m}\lfloor mX \rfloor$

对于 $m \in \mathbb{N}$，其中 $\lfloor \cdot \rfloor$ 按分量取值。Rényi 证明了 [357，定理 1]，如果给定 $H(\lfloor X \rfloor) < \infty$ 且 $h(X)$ 有定义，则我们有

$$H(X_m) = d \log m + h(X) + o(1), \quad m \to \infty. \tag{2.21}$$

为解释此结果，可简化考虑，$d = 1, m = 2^k$ 并假设 X 取值于单位区间，此时 X_{2^k} 是 X 的 k 位均匀量化。于是（2.21）表明，对于较大的 k，量化比特的行为如同独立的公平硬币投掷。根本原因在于，对于“良好”的密度函数，限制在小间隔上近似均匀。关于量化的更多内容，参见第 24 章第 24.1 节（特别是第 24.1.5 节）。

2.4 马尔可夫核

本书的主要对象是随机变量和概率分布。生成新随机变量的主要操作以及定义随机变量之间关系的主要操作是*Markov kernel* (，也称为*transition probability kernel*)。

定义2.10 马尔可夫核 $K : \mathcal{X} \to \mathcal{Y}$ 是一个二元函数 $K(\cdot|\cdot)$，其第一个参数是 $\mathcal{Y}$ 的可测子集，第二个参数是 $\mathcal{X}$ 的一个元素，满足：

1 对于任意 $x \in \mathcal{X}$：$K(\cdot|x)$ 是 $\mathcal{Y}$ 上的概率测度。2 对于任意可测集 A：$x \mapsto K(A|x)$ 是 $\mathcal{X}$ 上的可测函数。

核 K 可以被视为一个从 $\mathcal{X}$ 到 $\mathcal{Y}$ 的随机变换，它根据 X 的实现从某个分布中抽取 Y，并将确定性变换作为特例包含在内。因此，我们写作 $P_{Y|X} : \mathcal{X} \to \mathcal{Y}$，也写作 $X \xrightarrow{P_{Y|X}} Y$。在信息论语境中，我们也将 $P_{Y|X}$ 称为 *channel*，其中 X 和 Y 分别是信道输入和输出。获得马尔可夫核有两种方式。第一种方式是显式地定义它们。以下是一些这样的例子：

1 确定性系统：$Y = f(X)$。这对应于设置$P_{Y|X=x} = \delta_{f(x)}$。 2 解耦系统：$Y \perp\!\!\!\perp X$。这里我们设定$P_{Y|X=x} = P_Y$。 3 加性噪声（卷积）：$Y = X + Z$与$Z \perp\!\!\!\perp X$。这次我们选择 $P_{Y|X=x}(\cdot) = P_Z(\cdot - x)$。术语“卷积”对应于这样一个事实，即得到的边际分布$P_Y = P_X * P_Z$是测度的卷积。 4 本书中将贯穿使用的一些最实用的信道将在例3.3、3.4、3.6中简短定义。

第二种方法是通过对 X 进行条件化，从而 *disintegrate* 一个联合分布 $P_{X,Y}$，简记为 $P_{Y|X}$。具体而言，我们有以下结果 [84, 第四章, 定理 2.18]：

定理 2.11（分解）*Suppose $P_{X,Y}$ is a distribution on $\mathcal{X} \times \mathcal{Y}$ with $\mathcal{Y}$ being standard Borel. Then there exists a Markov kernel K: $\mathcal{X} \to \mathcal{Y}$ so that for any measurable $E \subset \mathcal{X} \times \mathcal{Y}$ and any integrable f we have*

$$P_{X,Y}[E] = \int_{\mathcal{X}} P_X(dx)K(E^x|x)\,, \qquad E^x \triangleq \{y : (x,y) \in E\} \tag{2.22}$$

$$\int_{\mathcal{X}\times\mathcal{Y}} f(x,y)P_{X,Y}(dx\,dy) = \int_{\mathcal{X}} P_X(dx) \int_{\mathcal{Y}} f(x,y)K(dy|x)\,.$$

注意，上述内容中我们已隐含使用了以下事实：对于每个 x，E 的切片 E^x 是 $\mathcal{Y}$ 的可测子集，并且函数 $x \mapsto K(E^x|x)$ 是可测的（分别参见 [84，第一章，命题 6.8 和 6.9]）。我们还注意到，一个联合分布 $P_{X,Y}$ 可以有许多不同的 $P_{Y|X}$ 的 *versions*，它们在 x 的一个零测集上有所不同。

在$\mathcal{X}$上组合一个输入分布和一个核K：$\mathcal{X} \to \mathcal{Y}$的操作，正如我们在(2.22)中所做的那样，将在本书中大量出现。我们通常将其表示为*multiplication*：给定P_X和核$P_{Y|X}$，我们可以将它们相乘得到$P_{X,Y} \triangleq P_X P_{Y|X}$，在离散情况下，这仅意味着联合概率质量函数分解为边际概率质量函数和条件概率质量函数的乘积：

$$P_{X,Y}(x,y) = P_{Y|X}(y|x)P_X(x)\,,$$

并且更一般地由(2.22)与$K = P_{Y|X}$给出。

另一个有用的操作是 *composition* (边缘化)，我们将其表示为 $P_{Y|X} \circ P_X \triangleq P_Y$。换句话说，这意味着形成一个分布 $P_{X,Y} = P_X P_{Y|X}$，然后计算边缘 P_Y，或者明确地说，

$$P_Y[E] = \int_{\mathcal{X}} P_X(dx)P_{Y|X}(E|x)\,.$$

为了表示输入 P_X 和输出 P_Y 之间的这种（线性）关系，我们有时也写作 $P_X \xrightarrow{P_{Y|X}} P_Y$。

我们必须指出，诸如限定于标准Borel空间的技术性假设，对于构建任何合理的分解/条件化及乘法理论而言，确实是必要的。为了强调这一点，我们考虑一个涉及病态度量空间$\mathcal{Y}$的（警示性的！）例子。

例 2.5（$X \perp\!\!\!\perp Y$ 但 x 对所有 $P_{Y|X=x} \not\ll P_Y$）考虑 $\mathcal{X}$ 一个具有 Borel σ-代数 的单位区间，以及 $\mathcal{Y}$ 一个具有由所有可数或具有可数补集的集合组成的 σ-代数 $\sigma\mathcal{Y}$ 的单位区间。显然，$\sigma\mathcal{Y}$ 是 Borel 代数的一个子-σ-代数。我们定义如下核 K：$\mathcal{X} \to \mathcal{Y}$:

$$K(A|x) \triangleq 1\{x \in A\}\,.$$

这只是在说，Y是通过设置$Y = X$从X产生的。应当清楚的是，对于每个$A \in \sigma\mathcal{Y}$，映射 $x \mapsto K(A|x)$是可测的，因此K是一个有效的马尔可夫核。令$X \sim \sim \text{Unif}(0,1)$并使用公式(2.22)，我们可以定义一个联合分布$P_{X,Y}$。但条件分布$P_{Y|X}$是什么？一方面，显然我们可以设定$P_{Y|X}(A|x) = K(A|x)$，因为$P_{X,Y}$就是这样构造的。另一方面，我们将证明$P_{X,Y} = P_X P_Y$，即$X \perp\!\!\!\perp Y$

并且同时有 $X = Y$! 事实上，考虑任意集合 $E = B \times C \subset \mathcal{X} \times \mathcal{Y}$。我们总有 $P_{X,Y}[B \times C] = P_X[B \cap C]$。因此，如果 C 是可数的，那么 $P_{X,Y}[E] = 0$，$P_X P_Y[E] = 0$ 也是如此。另一方面，如果 C^c 是可数的，那么 $P_X[C] = P_Y[C] = 1$，而 $P_{X,Y}[E] = P_X P_Y[E]$ 再次成立。因此，$P_{Y|X} = K$ 和 $P_{Y|X} = P_Y$ 都是有效的条件分布。但请注意，由于 $P_Y[\{x\}] = 0$，对于每个 $x \in \mathcal{X}$，我们有 $K(\cdot|x) \not\ll P_Y$。特别地，对于每个 x，$D(P_{Y|X=x}\|P_Y)$ 的值可以是 0 或 $+\infty$，这取决于 $P_{Y|X}$ 的版本选择。因此，明智的做法是保持在标准博雷尔空间的范围内。

我们还将需要广泛使用以下结果。我们提醒，如果一个σ-代数是由可数集合族生成的，则称其为可分的。任何标准博雷尔空间的σ-代数都是可分的。以下关于马尔可夫核的另一个有用结果，参见[84，第5章，定理4.44]:

定理2.12（Radon-Nikodym定理的Doob版本）*Assume that $\mathcal{Y}$ is a measurable space with a separable σ-algebra. Let $P_{Y|X}\colon\ \mathcal{X} \to \mathcal{Y}$ and $R_{Y|X}\colon\ \mathcal{X} \to \mathcal{Y}$ be two Markov kernels. Suppose that for every x we have $P_{Y|X=x} \ll R_{Y|X=x}$. Then there exists a measurable function $(x, y) \mapsto f(y|x) \geq 0$ such that* 对于每个$x \in \mathcal{X}$及$\mathcal{Y}$的每个可测子集E,

$$P_{Y|X}(E|x) = \int_E f(y|x) R_{Y|X}(dy|x)\,.$$

该定理的意义在于，Radon-Nikodym 导数 $\frac{dP_{Y|X=x}}{dR_{Y|X=x}}$ 可以被使得关于 (x, y) 是 *jointly* 可测的。

2.5 条件散度、链式法则、数据处理不等式

我们旨在定义两个马尔可夫核之间的条件散度。在本章中，我们固定一对马尔可夫核 $P_{Y|X}\colon\ \mathcal{X} \to \mathcal{Y}$ 和 $Q_{Y|X}\colon\ \mathcal{X} \to \mathcal{Y}$，以及 $\mathcal{X}$ 上的一个概率测度 P_X。首先，让我们考虑离散 $\mathcal{X}$ 的情况。我们将条件散度定义为

$$D(P_{Y|X}\|Q_{Y|X}|P_X) \triangleq \sum_{x \in \mathcal{X}} P_X(x) D(P_{Y|X=x}\|Q_{Y|X=x})\,.$$

为了将上述定义推广到更一般的 $\mathcal{X}$，我们首先需要理解映射 $x \mapsto D(P_{Y|X=x}\|Q_{Y|X=x})$ 是否可测。

引理 2.13 *Suppose that $\mathcal{Y}$ is standard Borel. The set $A_0 \triangleq \{x\colon\ P_{Y|X=x} \ll Q_{Y|X=x}\}$ and the function*

$$x \mapsto D(P_{Y|X=x}\|Q_{Y|X=x})$$

are both measurable.

Proof. 取 $R_{Y|X} = \frac{1}{2}P_{Y|X} + \frac{1}{2}Q_{Y|X}$ 并定义 $f_P(y|x) \triangleq \frac{dP_{Y|X=x}}{dR_{Y|X=x}}(y)$ 和 $f_Q(y|x) \triangleq \frac{dQ_{Y|X=x}}{dR_{Y|X=x}}(y)$。由定理 2.12，可以选择它们在 $\mathcal{X} \times \mathcal{Y}$ 上是联合可测的。让我们定义 $B_0 \triangleq$

$\{(x,y): f_P(y|x)>0, f_Q(y|x)=0\}$ 及其切片 $B_0^x=\{y:(x,y)\in B_0\}$。然后注意 $P_{Y|X=x}\ll Q_{Y|X=x}$ 当且仅当 $R_{Y|X=x}[B_0^x]=0$。换句话说，$x\in A_0$ 当且仅当 $R_{Y|X=x}[B_0^x]=0$。B_0 的可测性蕴含 $x\mapsto R_{Y|X=x}[B_0^x]$ 的可测性，从而蕴含 A_0 的可测性。最后，由 (2.12) 我们得到

$$D(P_{Y|X=x}\|Q_{Y|X=x})=\mathbb{E}_{Y\sim P_{Y|X=x}}\left[\mathrm{Log}\frac{f_P(Y|x)}{f_Q(Y|x)}\right], \tag{2.23}$$

这是可测的，例如[84，第1章，命题6.9]。 □

有了这些准备，我们可以给出以下定义。

定义 2.14（条件散度）假设 $\mathcal{Y}$ 是标准博雷尔空间，定义

$$D(P_{Y|X}\|Q_{Y|X}|P_X)\triangleq\mathbb{E}_{x\sim P_X}[D(P_{Y|X=x}\|Q_{Y|X=x})]$$

我们注意到，正如勒贝格积分中通常的情况，条件散度可能是有限的，即使对于某个 (P_X-可忽略集) 的 x，$D(P_{Y|X=x}\|Q_{Y|X=x})=\infty$ 是成立的。

定理 2.15（链式法则）*For any pair of measures $P_{X,Y}$ and $Q_{X,Y}$ we have*

$$D(P_{X,Y}\|Q_{X,Y})=D(P_{Y|X}\|Q_{Y|X}|P_X)+D(P_X\|Q_X), \tag{2.24}$$

regardless of the versions of conditional distributions $P_{Y|X}$ and $Q_{Y|X}$ one chooses.

Proof. 首先，让我们考虑最简单的情况：$\mathcal{X},\mathcal{Y}$是离散的，且对于所有x,y，$Q_{X,Y}(x,y)>$均为0。令$(X,Y)\sim P_{X,Y}$，我们得到

$$\begin{aligned}D(P_{X,Y}\|Q_{X,Y})&=\mathbb{E}\left[\log\frac{P_{X,Y}(X,Y)}{Q_{X,Y}(X,Y)}\right]=\mathbb{E}\left[\log\frac{P_X(X)P_{Y|X}(Y|X)}{Q_X(X)Q_{Y|X}(Y|X)}\right]\\&=\mathbb{E}\left[\log\frac{P_{Y|X}(Y|X)}{Q_{Y|X}(Y|X)}\right]+\mathbb{E}\left[\log\frac{P_X(X)}{Q_X(X)}\right]\end{aligned}$$

完成证明。

接下来，我们讨论一般情况。若 $P_X\not\ll Q_X$，则 $P_{X,Y}\not\ll Q_{X,Y}$，且(2.24)式两边均为无穷大。因此，我们假设 $P_X\ll Q_X$ 并设定 $\lambda_P(x)\triangleq\frac{dP_X}{dQ_X}(x)$。按照引理2.13的证明中定义 $f_P(y|x)$、$f_Q(y|x)$ 和 $R_{Y|X}$。于是我们有 $P_{X,Y},Q_{X,Y}\ll R_{X,Y}\triangleq Q_XR_{Y|X}$，并且对于任意可测的 E

$$P_{X,Y}[E]=\int_E\lambda_P(x)f_P(y|x)R_{X,Y}(dx\,dy),\quad Q_{X,Y}[E]=\int_E f_Q(y|x)R_{X,Y}(dx\,dy).$$

然后从(2.12)我们得到

$$D(P_{X,Y}\|Q_{X,Y})=\mathbb{E}_{P_{X,Y}}\left[\mathrm{Log}\frac{f_P(Y|X)\lambda_P(X)}{f_Q(Y|X)}\right]. \tag{2.25}$$

注意 Log 的以下性质：对于任意 $c>0$

$$\mathrm{Log}\frac{ac}{b}=\log(c)+\mathrm{Log}\frac{a}{b}$$

除非 $a = b = 0$。现在，由于 $P_{X,Y}[f_P(Y|X) > 0, \lambda_P(X) > 0] = 1$，我们得出 $P_{X,Y}$-几乎必然

$$\mathrm{Log}\frac{f_P(Y|X)\lambda_P(X)}{f_Q(Y|X)} = \log \lambda_P(X) + \mathrm{Log}\frac{f_P(Y|X)}{f_Q(Y|X)}\,.$$

我们的目标是对两边关于 $P_{X,Y}$ 取期望，并利用期望的线性性质。为了确保不会出现 $\infty - \infty$ 的问题，我们注意到每一项的负部根据(2.15)具有有限的期望。总体而言，继续(2.25)并利用线性性质，我们得到

$$D(P_{X,Y}\|Q_{X,Y}) = \mathbb{E}_{P_{X,Y}}[\log \lambda_P(X)] + \mathbb{E}_{P_{X,Y}}\left[\mathrm{Log}\frac{f_P(Y|X)}{f_Q(Y|X)}\right],$$

其中第一项由(2.12)等于$D(P_X\|Q_X)$，第二项由(2.23)及条件散度的定义等于 $D(P_{Y|X}\|Q_{Y|X}|P_X)$。 □

链式法则有许多有用的推论，我们将在下面进行总结。

定理 2.16（散度的性质）*Assume that $\mathcal{X}$ and $\mathcal{Y}$ are standard Borel. Then*

(a) Conditional divergence can be expressed unconditionally:

$$D(P_{Y|X}\|Q_{Y|X}|P_X) = D(P_XP_{Y|X}\|P_XQ_{Y|X})\,.$$

(b) (Monotonicity) $D(P_{X,Y}\|Q_{X,Y}) \geq D(P_Y\|Q_Y)$.

(c) (Full chain rule)

$$D(P_{X_1\cdots X_n}\|Q_{X_1\cdots X_n}) = \sum_{i=1}^{n} D(P_{X_i|X^{i-1}}\|Q_{X_i|X^{i-1}}|P_{X^{i-1}}). \tag{2.26}$$

In the special case of $Q_{X^n} = \prod_{i=1}^n Q_{X_i}$,

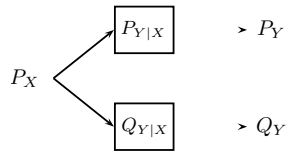
$$\begin{aligned} D(P_{X_1\cdots X_n}\|Q_{X_1}\cdots Q_{X_n}) &= D(P_{X_1\cdots X_n}\|P_{X_1}\cdots P_{X_n}) + \sum_{i=1}^{n} D(P_{X_i}\|Q_{X_i}) \\ &\geq \sum_{i=1}^{n} D(P_{X_i}\|Q_{X_i}), \end{aligned} \tag{2.27}$$

where the inequality holds with equality if and only if $P_{X^n} = \prod_{j=1}^n P_{X_j}$.

(d) (Tensorization)

$$D\left(\prod_{j=1}^{n} P_{X_j}\middle\|\prod_{j=1}^{n} Q_{X_j}\right) = \sum_{j=1}^{n} D(P_{X_j}\|Q_{X_j}).$$

(e) (Conditioning increases divergence) Given $P_{Y|X}$, $Q_{Y|X}$ and P_X, let $P_Y = P_{Y|X} \circ P_X$ and $Q_Y = Q_{Y|X} \circ P_X$, as represented by the diagram:



Then $D(P_Y\|Q_Y) \le D(P_{Y|X}\|Q_{Y|X}|P_X)$, with equality iff $D(P_{X|Y}\|Q_{X|Y}|P_Y) = 0$.

我们注意到，如同之前一样，如果没有标准的Borel假设，即使第一个性质也可能失效。例如，例2.5展示了一个情况，其中$P_X P_{Y|X} = P_X Q_{Y|X}$但$P_{Y|X} \neq Q_{Y|X}$和$D(P_{Y|X}\|Q_{Y|X}|P_X) = \infty$。

Proof. (a) 这由链式法则(2.24)得出，因为$P_X = Q_X$。
(b) 应用(2.24)，将X和Y互换，并利用条件散度非负的事实。(c) 通过望远镜求和的$P_{X^n} = \prod_{i=1}^n P_{X_i|X^{i-1}}$和$Q_{X^n} = \prod_{i=1}^n Q_{X_i|X^{i-1}}$。(d) 应用(c)。(e) 该不等式由(a)和(b)得出。要得到等号成立的条件，注意根据D的链式法则：

$$\begin{aligned} D(P_{X,Y}\|Q_{X,Y}) &= D(P_{Y|X}\|Q_{Y|X}|P_X) + \underbrace{D(P_X\|P_X)}_{=0} \\ &= D(P_{X|Y}\|Q_{X|Y}|P_Y) + D(P_Y\|Q_Y). \end{aligned}$$

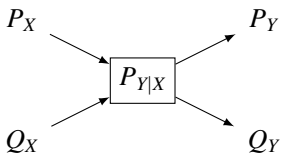
□

需要作出一些说明：

• 对完整链式法则有一个很好的解释，即把从 P_{X^n} 到 Q_{X^n} 的“距离”分解为中间分布之间的“距离”之和，参见练习 I.43。• 一般来说，$D(P_{X,Y}\|Q_{X,Y})$ 和 $D(P_X\|Q_X)+D(P_Y\|Q_Y)$ 是不可比较的。例如，如果 $X = Y$ 在 P 和 Q 下，那么 $D(P_{X,Y}\|Q_{X,Y}) = D(P_X\|Q_X) < 2$ $D(P_X\|Q_X)$。反过来，如果 $P_X = Q_X$ 和 $P_Y = Q_Y$ 但 $P_{X,Y} \neq Q_{X,Y}$ 我们有 $D(P_{X,Y}\|Q_{X,Y}) > 0$ $= D(P_X\|Q_X) + D(P_Y\|Q_Y)$。

以下结果被称为*Data-Processing Inequality (DPI)*，是所有信息论中的一个重要原理。在许多方面，它支撑了整个信息的概念。直观解释是，使用干净（相应地，完整）数据比使用嘈杂（相应地，部分）数据更容易区分两个分布。DPI是本书中反复出现的主题，稍后我们将研究其他信息度量的DPI，如互信息和f-散度。

定理 2.17 (KL 散度的 DPI) *Let $P_Y = P_{Y|X} \circ P_X$ and $Q_Y = P_{Y|X} \circ Q_X$, as represented by the diagram:*



Then

$$D(P_Y\|Q_Y) \le D(P_X\|Q_X), \tag{2.28}$$

with equality if and only if $D(P_{X|Y}\|Q_{X|Y}|P_Y) = 0$.

Proof. 这可以由链式法则或单调性推导得出:

$$\begin{aligned} D(P_{X,Y}\|Q_{X,Y}) &= \underbrace{D(P_{Y|X}\|Q_{Y|X}|P_X)}_{=0} + D(P_X\|Q_X) \\ &= D(P_{X|Y}\|Q_{X|Y}|P_Y) + D(P_Y\|Q_Y) \end{aligned}$$

□

推论 2.18（确定性变换下的散度）*Let* $Y = f(X)$.
Then $D(P_Y\|Q_Y) \le D(P_X\|Q_X)$*, with equality if* f *is one-to-one.*

注意，$D(P_{f(X)}\|Q_{f(X)}) = D(P_X\|Q_X)$并不意味$f$是一一对应的；例如，考虑$P_X$ =高斯, Q_X =拉普拉斯, $Y = |X|$。实际上，当$f(X)$是一个*sufficient statistic*用于检验P与Q时，等式恰好成立；换句话说，就检验这两个假设而言，将X概括为$f(X)$不会造成信息损失。详情见例3.9。

推论2.18的一个特别有用的应用是当我们取f为指示函数时:

推论 2.19（大偏差估计） *For any subset* $E \subset \mathcal{X}$ *we have*

$$d(P_X[E]\|Q_X[E]) \le D(P_X\|Q_X),$$

where $d(\cdot\|\cdot)$ *is the binary divergence function in (2.6).*

Proof. 考虑 $Y = 1\{X \in E\}$。 □

该方法在大偏差理论中非常有用，该理论研究稀有事件（第14.5节和第15.2节），其中我们将推论2.19应用于一个在 P 下极有可能但在 Q 下极不可能的事件 E。

2.6* 散度和Fisher信息的局部行为

正如我们将在第4.5节中看到的，KL散度通常不是连续的。然而，我们有理由预期，在非病态情况下，当P平滑地逼近Q时，泛函$D(P\|Q)$会消失。由于$x\log x$在$x=1$处的平滑性和严格凸性，因此也自然地期望该泛函呈“二次”衰减。在本节中，我们首先沿P与Q之间的线性插值来考察这一问题，然后更一般地在光滑参数化分布族中加以考察。这些性质将在后面的第7.10节和第7.11节中推广到更一般的散度。

2.6.1* 混合发散性的局部行为

设$0\le\lambda\le 1$，并考虑$D(\lambda P+\bar{\lambda}Q\|Q)$，当$\lambda\to 0$时趋于零。接下来，我们证明这种衰减总是次线性的。

命题 2.20 *When $D(P\|Q)<\infty$, the one-sided derivative at $\lambda=0$ vanishes:*

$$\frac{d}{d\lambda}\Big|_{\lambda=0} D(\lambda P+\bar{\lambda}Q\|Q)=0$$

If we exchange the arguments, the criterion is even simpler:

$$\frac{d}{d\lambda}\Big|_{\lambda=0} D(Q\|\lambda P+\bar{\lambda}Q)=0 \quad\iff\quad P\ll Q \tag{2.29}$$

Proof.

$$\frac{1}{\lambda}D(\lambda P+\bar{\lambda}Q\|Q)=\mathbb{E}_Q\left[\frac{1}{\lambda}(\lambda f+\bar{\lambda})\log(\lambda f+\bar{\lambda})\right]$$

其中$f=\dfrac{dP}{dQ}$。当$\lambda\to$趋近于0时，期望下的函数单调递减至$(f-1)\log e$。实际上，该函数

$$\lambda\mapsto g(\lambda)\triangleq(\lambda f+\bar{\lambda})\log(\lambda f+\bar{\lambda})$$

是凸的，并且在$\lambda=0$处等于零。因此，$\frac{g(\lambda)}{\lambda}$在$\lambda$中递增。此外，由$x\mapsto x\log x$的凸性：

$$\frac{1}{\lambda}(\lambda f+\bar{\lambda})(\log(\lambda f+\bar{\lambda}))\le\frac{1}{\lambda}(\lambda f\log f+\bar{\lambda}1\log 1)=f\log f$$

并且根据假设$f\log f$是Q-可积的。因此，单调收敛定理适用。

为了证明(2.29)，首先注意到如果$P\not\ll Q$，那么存在一个集合E，其中$p=P[E]>0=Q[E]$。将散度的数据处理应用于$X\mapsto 1_E(X)$，我们得到

$$D(Q\|\lambda P+\bar{\lambda}Q)\ge d(0\|\lambda p)=\log\frac{1}{1-\lambda p}$$

并且导数为非零。如果 $P \ll Q$，则令 $f = \frac{dP}{dQ}$ 并注意简单不等式

$$\log \bar{\lambda} \le \log(\bar{\lambda} + \lambda f) \le \lambda(f-1)\log e\,.$$

除以 λ 并假设 $\lambda < \frac{1}{2}$，我们得到一些绝对常数 c_1, c_2:

$$\left|\frac{1}{\lambda}\log(\bar{\lambda} + \lambda f)\right| \le c_1 f + c_2\,.$$

因此，根据控制收敛定理，我们得到

$$\frac{1}{\lambda}D(Q\|\lambda P + \bar{\lambda}Q) = -\int dQ\left(\frac{1}{\lambda}\log(\bar{\lambda}+\lambda f)\right) \xrightarrow{\lambda\to 0} \int dQ(1-f) = 0\,.$$

□

备注 2.2 更一般地，在适当的技术条件下，

$$\frac{d}{d\lambda}\Big|_{\lambda=0} D(\lambda P + \bar{\lambda}Q\|R) = \mathbb{E}_P\left[\log\frac{dQ}{dR}\right] - D(Q\|R)$$

和

$$\frac{d}{d\lambda}\Big|_{\lambda=0} D(\bar{\lambda}P_1 + \lambda Q_1\|\bar{\lambda}P_0 + \lambda Q_0) = \mathbb{E}_{Q_1}\left[\log\frac{dP_1}{dP_0}\right] - D(P_1\|P_0) + \mathbb{E}_{P_1}\left[1 - \frac{dQ_0}{dP_0}\right]\log e.$$

参见练习 I.22 的示例。

命题2.20的主要信息是，函数

$$\lambda \mapsto D(\lambda P + \bar{\lambda}Q\|Q)\,,$$

是 $o(\lambda)$ 作为 $\lambda \to 0$。实际上，在大多数情况下，它是关于 λ 的二次函数。为了精确表述，我们需要定义 χ^2-散度的概念——这是 f-散度的一个版本（见第7章）：

$$\chi^2(P\|Q) \triangleq \int dQ\left(\frac{dP}{dQ} - 1\right)^2\,.$$

这是一种在 P 和 Q 之间流行的不相似度度量，常用于统计学中。它具有许多重要性质，但我们仅提及 χ^2 优于KL散度（参见(7.34)）：

$$D(P\|Q) \le \log(1 + \chi^2(P\|Q))\,.$$

我们关于KL散度局部行为的第二个结果如下（推广见第7.10节）：

命题 2.21（KL 局部类似 χ^2）*We have*

$$\liminf_{\lambda\to 0}\frac{1}{\lambda^2}D(\lambda P + \bar{\lambda}Q\|Q) = \frac{\log e}{2}\chi^2(P\|Q)\,, \tag{2.30}$$

where both sides are finite or infinite simultaneously.

Proof. 首先，我们假设$\chi^2(P\|Q) < \infty$并证明

$$D(\lambda P + \bar{\lambda} Q\|Q) = \frac{\lambda^2 \log e}{2}\chi^2(P\|Q) + o(\lambda^2)\,, \qquad \lambda \to 0\,.$$

为此，请注意

$$D(P\|Q) = \mathbb{E}_Q\left[g\left(\frac{dP}{dQ}\right)\right],$$

其中

$$g(x) \triangleq x\log x - (x-1)\log e\,.$$

注意，$x \mapsto \frac{g(x)}{(x-1)^2\log e} = \int_0^1 \frac{sds}{x(1-s)+s}$ 在 $(0,\infty)$ 上关于 x 是递减的。因此

$$0 \le g(x) \le (x-1)^2 \log e\,,$$

因此

$$0 \le \frac{1}{\lambda^2} g\left(\bar{\lambda} + \lambda\frac{dP}{dQ}\right) \le \left(\frac{dP}{dQ} - 1\right)^2 \log e.$$

根据控制收敛定理（由于$\chi^2(P\|Q) < \infty$适用），我们有

$$\lim_{\lambda\to 0}\frac{1}{\lambda^2}\mathbb{E}_Q\left[g\left(\bar{\lambda} + \lambda\frac{dP}{dQ}\right)\right] = \frac{g''(1)}{2}\mathbb{E}_Q\left[\left(\frac{dP}{dQ} - 1\right)^2\right] = \frac{\log e}{2}\chi^2(P\|Q)\,.$$

其次，我们展示无条件地

$$\liminf_{\lambda\to 0}\frac{1}{\lambda^2}D(\lambda P + \bar{\lambda}Q\|Q) \ge \frac{\log e}{2}\chi^2(P\|Q)\,. \tag{2.31}$$

事实上，这可由法图引理得出：

$$\liminf_{\lambda\to 0}\mathbb{E}_Q\left[\frac{1}{\lambda^2}g\left(\bar{\lambda} + \lambda\frac{dP}{dQ}\right)\right] \ge \mathbb{E}_Q\left[\liminf_{\lambda\to 0} g\left(\bar{\lambda} + \lambda\frac{dP}{dQ}\right)\right] = \frac{\log e}{2}\chi^2(P\|Q)\,.$$

因此，从(2.31)我们得出结论，如果$\chi^2(P\|Q) = \infty$成立，那么(2.30)的左边也成立。 □

2.6.2* 参数化族

扩展第2.6.1*节的设置，考虑参数化分布集$\{P_\theta\colon\ \theta \in \Theta\}$，其中参数空间$\Theta$是$\mathbb{R}^d$的开子集。此外，假设分布$P_\theta$均以如下形式给出：

$$P_\theta(dx) = p_\theta(x)\mu(dx)\,,$$

其中 μ 是某种常见的主导测度（例如勒贝格测度或计数测度）。如果对于每个固定的 x，密度 $p_\theta(x)$ 都随 θ 平滑变化，那么可以定义参数 θ 的 *Fisher information matrix* 为

$$J_F(\theta) \triangleq \mathbb{E}_\theta\left[VV^\top\right], \quad V \triangleq \nabla_\theta \ln p_\theta(X)\,, \tag{2.32}$$

其中 $\mathbb{E}_\theta$ 是相对于 $X \sim P_\theta$ 而言的。特别地，V 被称为 *score*。

在适当的正则性条件下，我们有以下恒等式

$$\mathbb{E}_\theta[V] = 0 \tag{2.33}$$

以及Fisher信息矩阵的几个等价表达式：

$$\begin{aligned} J_F(\theta) &= \operatorname*{cov}_\theta(V) \\ &= 4\int \mu(dx)(\nabla_\theta \sqrt{p_\theta(x)})(\nabla_\theta \sqrt{p_\theta(x)})^\top \\ &= -\mathbb{E}_\theta[\mathrm{Hess}_\theta(\ln p_\theta(X))], \end{aligned}$$

其中最后一个恒等式是通过对(2.33)关于每个θ_j进行微分得到的。

Fisher信息矩阵的重要性源于这样一个事实：它衡量了光滑参数族中散度的局部行为。即，我们有（同样在适当的技术条件下）：[2]

$$D(P_{\theta_0}\|P_{\theta_0+\xi}) = \frac{\log e}{2}\xi^\top J_F(\theta_0)\xi + o(\|\xi\|^2), \tag{2.34}$$

这是通过对泰勒展开进行积分得到的：

$$\ln p_{\theta_0+\xi}(x) = \ln p_{\theta_0}(x) + \xi^\top \nabla_\theta \ln p_{\theta_0}(x) + \frac{1}{2}\xi^\top \mathrm{Hess}_\theta(\ln p_{\theta_0}(x))\xi + o(\|\xi\|^2).$$

我们将在第7.11节严格证明这一事实。性质(2.34)在统计学中至关重要。我们应记住它：*Divergence is locally quadratic on the parameter space, with Hessian given by the Fisher information matrix.* 注意，对于高斯位置模型 $P_\theta = \mathcal{N}(\theta, \Sigma)$，(2.34)实际上是精确的，其中$J_F(\theta) \equiv \Sigma^{-1}$——参见例2.2。

再举一个例子，注意到命题2.21是(2.34)的一个特例，通过考虑$P_\lambda = \bar{\lambda}Q + \lambda P$由$\lambda \in [0, 1]$参数化。在这种情况下，$\lambda = 0$处的Fisher信息简单地就是$\chi^2(P\|Q)$。尽管如此，命题2.21是完全通用的，而渐近展开(2.34)则不然，它需要正则条件（见第7.11节）。

备注 2.3 费舍尔信息的一些有用性质如下： 如下：

- 重参数化：可以看出，如果通过一个光滑可逆映射$\tilde{\Theta} \to \Theta$引入另一个参数化$\tilde{\theta} \in \tilde{\Theta}$，那么Fisher信息矩阵会变为

$$J_F(\tilde{\theta}) = A^\top J_F(\theta) A, \tag{2.35}$$

[2] 为了说明这里的微妙之处，考虑一个标量位置族，即对于某个密度 f_0，有 $p_\theta(x) = f_0(x-\theta)$。在这种情况下，Fisher 信息 $J_F(\theta_0) = \int \frac{(f_0')^2}{f_0}$ 不依赖于 θ_0，并且即使对于紧支撑的 f_0 也有良好定义，只要 f_0' 在端点处足够快地消失。但与此同时，对于任何 $\xi > 0$，(2.34) 的左侧是无穷大。因此，Fisher 信息的一个更一般的解释是作为展开式 $D(P_{\theta_0}\|\frac{1}{2}P_{\theta_0} + \frac{1}{2}P_{\theta_0+\xi}) = \frac{\xi^2}{8}J_F(\theta_0) + o(\xi^2)$ 中的系数。我们将在第 7.11 节中更详细地讨论这一点。

其中 $A = \frac{d\theta}{d\tilde{\theta}}$ 是映射的雅可比矩阵。因此我们可以看到，J_F 的变换方式与黎曼几何中的度量张量类似。这一思想可用于在参数空间 Θ 上定义黎曼度量，称为 *Fisher-Rao metric*。这在信息几何这一领域得到了探讨 [85, 17]。

- 可加性：假设我们有一个由 n 个独立同分布观测 $X^n \overset{\text{i.i.d.}}{\sim} P_\theta$ 组成的样本。因此，考虑乘积分布 $\{P_\theta^{\otimes n}$ 的参数化族：$\theta \in \Theta\}$，其 Fisher 信息矩阵记为 $J_F^{\otimes n}(\theta)$。在这种情况下，得分是独立同分布之和。应用 (2.32) 和 (2.33) 得到

$$J_F^{\otimes n}(\theta) = nJ_F(\theta). \tag{2.36}$$

例2.6 设 $P_\theta = (\theta_0, \ldots, \theta_d)$ 为有限字母表 $\{0, \ldots, d\}$ 上的概率分布。我们将 $\theta = (\theta_1, \ldots, \theta_d)$ 作为自由参数，并设定 $\theta_0 = 1 - \sum_{i=1}^d \theta_i$。因此，所有导数都仅关于 $\theta_1, \ldots, \theta_d$。于是我们得到

$$p_\theta(i) = \begin{cases} \theta_i, & i = 1, \ldots, d \\ 1 - \sum_{i=1}^d \theta_i, & i = 0 \end{cases}$$

而对于费舍尔信息矩阵，我们得到

$$J_F(\theta) = \operatorname{diag}\left(\frac{1}{\theta_1}, \ldots, \frac{1}{\theta_d}\right) + \frac{1}{1 - \sum_{i=1}^d \theta_i} 11^\top, \tag{2.37}$$

其中 1 是 $d \times 1$ 的全1向量。为了后续参考（见29.4节和13.4*节），我们还计算了 $J_F(\theta)$ 的逆和行列式。根据矩阵求逆引理（$A + UCV$）$^{-1} = A^{-1} - A^{-1}U(C^{-1} + VA^{-1}U)^{-1}VA^{-1}$，我们有

$$J_F^{-1}(\theta) = \operatorname{diag}(\theta) - \theta\theta^\top. \tag{2.38}$$

对于行列式，注意 $\det(A + xy^\top) = \det A \cdot \det(I + A^{-1}xy^\top) = \det A \cdot (1 + y^\top A^{-1}x)$，其中我们使用了恒等式 $\det(I + AB) = \det(I + BA)$。因此，我们有

$$\det J_F(\theta) = \prod_{i=0}^d \frac{1}{\theta_i}. \tag{2.39}$$

例 2.7（位置族）在统计学和信息论中，通常谈论一个（单个）随机变量或分布的 Fisher 信息，而不涉及参数族。在这种情况下，人们隐含地考虑一个位置参数。具体来说，对于 $\mathbb{R}^d$ 上的任意密度 p_0，我们通过设置 $P_\theta(dx) = p_0(x - \theta)dx$，$\theta \in \mathbb{R}^d$ 来定义 $\mathbb{R}^d$ 上的一个分布 *location family*。注意，这里的 $J_F(\theta)$ 不依赖于 θ。对于这个特殊情况，我们将采用标准记号：令 $X \sim p_0$，则

$$J(X) \equiv J(p_0) \triangleq \mathbb{E}_{X \sim p_0}[(\nabla \ln p_0(X))(\nabla \ln p_0(X))^\top] = -\mathbb{E}_{X \sim p_0}[\operatorname{Hess}(\ln p_0(X))], \tag{2.40}$$

其中第二个等式要求分部积分的适用性。（关于变分定义，另见(7.96)。）

3 Mutual information

在前几章的技术准备之后，我们定义信息论领域或许最为著名的概念，即*mutual information*。它最初由香农定义，尽管这个名称后来由罗伯特·法诺提出。[1] 它有两种等价的表达形式（作为KL散度和熵差），两者各有优点。在本章中，我们收集互信息的一些基本性质（非负性、链式法则和数据处理不等式）。在定义条件信息时，我们还引入*directed graphical models*的语言，并将数据处理不等式中的等号情形与费雪的充分统计量概念联系起来。

到目前为止，本书尚未尝试将信息量与任何操作概念联系起来。首次尝试将在第3.6节进行，我们将互信息与错误概率以*Fano's inequality*的形式关联起来，该形式表明，只要$I(X;Y)$很小，就不应能基于Y以较小的错误概率预测X。因此，这一不等式将在本书后续内容中被无数次应用，作为研究信息论和统计学中问题基本极限的主要工具。

信息与估计之间的联系在第3.7*节得到进一步探讨，该节中我们将互信息与高斯噪声中的最小均方误差（*I-MMSE*关系）相关联。从后者我们还能推导出熵功率不等式，它在高维概率与测度集中现象中扮演着核心角色。

3.1 互信息

互信息最初由香农定义，用于衡量在观测到另一个（相关的）随机量后，某个随机量熵的减少量。与当时在统计力学中已广为人知的熵概念本身不同，互信息是全新且具有革命性的，在科学中没有类似物。然而，如今人们更倾向于用一种不同的形式来定义互信息（在[378，附录7]中提出）。

[1] Professor of electrical engineering at MIT, who developed the first course on information theory and as part of it formalized and rigorized much of Shannon's ideas. Most famously, he showed the "converse part" of the noisy channel coding theorem, see Section 17.4.

定义 3.1（互信息）对于一对随机变量 X 和 Y，我们定义

$$I(X;Y) = D(P_{X,Y}\|P_XP_Y).$$

互信息的直观解释是 $I(X;Y)$ 通过比较 X 和 Y 的联合分布与边缘分布乘积的 KL 散度来衡量它们之间的依赖关系，正如我们接下来将展示的，这也等价于比较条件分布与无条件分布。

我们定义 $I(X;Y)$ 的方式是将其视为联合分布 $P_{X,Y}$ 的泛函。然而，将其视为对 $(P_X, P_{Y|X})$ 的泛函也颇具成效——更多内容见第5.1节。

一般来说，散度 $D(P_{X,Y}\|P_XP_Y)$ 应使用通用定义（2.4）来评估。请注意，$P_{X,Y} \ll P_XP_Y$ 并不总是成立。不过，让我们考虑以下例子。

例 3.1 若 $X = Y \sim N(0,1)$ 则 $P_{X,Y} \not\ll P_XP_Y$ 与 $I(X;Y) = \infty$。这反映了我们的直觉，即 X 包含“无限”量的信息，需要无限多位来描述。另一方面，若 X 或 Y 中至少有一个是离散的，则我们 *always* 有 $P_{X,Y} \ll P_XP_Y$。事实上，考虑乘积 sigma 代数中任何满足 $P_{X,Y}(E) > 0$ 的 $E \subset \mathcal{X} \times \mathcal{Y}$。由于 $P_{X,Y}(E) = \sum_{x\in S}\mathbb{P}[(X,Y) \in S, X = x]$，存在某个 $x_0 \in S$ 使得 $P_Y(E^{x_0}) \geq \mathbb{P}[X = x_0, Y \in E^{x_0}] > 0$，其中 $E^{x_0} \triangleq \{y : (x_0, y) \in E\}$ 是 E (的一个截面，且对每个 x_0) 可测。但这样 $P_XP_Y(E) \geq P_XP_Y(\{x_0\} \times E^{x_0}) = P_X(\{x_0\})P_Y(E^{x_0}) > 0$，意味着 $P_{X,Y} \ll P_XP_Y$。

定理 3.2（互信息的性质）

(a) (Mutual information as conditional divergence) Whenever $\mathcal{Y}$ is standard Borel,

$$I(X;Y) = D(P_{Y|X}\|P_Y|P_X)\,. \tag{3.1}$$

(b) (Symmetry) $I(X;\ Y) = I(Y;\ X)$;\ $Y) \geq 0$
, with equality $I(X;$ $Y) = 0$ iff $X \perp\!\!\!\perp Y$
(c) (Positivity)
(d) (Deterministic maps) For any function f we have

$$I(f(X);Y) \leq I(X;Y)\,.$$

If f is one-to-one (with a measurable inverse), then $I(f(X);\ Y) = I(X;\ .Y)$
(e) (More data $\Rightarrow$ more information) $I(X_1, X_2; Z) \geq I(X_1; Z)$

Proof. (根据定理2.16(a)及$Q_{Y|X} = P_Y$，可得a)。
(b) 考虑一个马尔可夫核 K 发送 $(x,y) \mapsto (y,x)$。此核发送测度 $P_{X,Y} \xrightarrow{K} P_{Y,X}$ 和 $P_XP_Y \xrightarrow{K} P_YP_X$。因此，根据应用于此核的DPI定理2.17，我们得到

$$D(P_{X,Y}\|P_XP_Y) \geq D(P_{Y,X}\|P_YP_X)\,.$$

Ap再次运用这个论证，表明该不等式实际上是　　平等。
(c) 这仅是从定理2.3得出的$D \geq 0$。

(考虑一个马尔可夫核 K 将 $(x,y)\mapsto(f(x),y)$ 发送。该核发送测度 $P_{X,Y}\xrightarrow{K}P_{f(X),Y}$ 和 $P_XP_Y\xrightarrow{K}P_{f(X)}P_Y$。因此，通过将此核应用于 DPI 定理2.17，我们得到

$$D(P_{X,Y}\|P_XP_Y)\geq D(P_{f(X),Y}\|P_{f(X)}P_Y)\,.$$

显然，两边对应于两个互信息。对于双射 f，只需对 f 和 f^{-1} 应用不等式。(e) 对 $f(X_1,X_2)=X_1$ 应用 (d)。

□

在上述结果中，我们将最常使用的是（3.1）。注意，它意味着{v*}当且仅当

$$x\mapsto D(P_{Y|X=x}\|P_Y)$$

是 P_X-可积的。该性质在绝对连续性方面有一个对应性质，如下所述。

引理 3.3 *Let $\mathcal{Y}$ be standard Borel. Then*

$$P_{X,Y}\ll P_XP_Y\quad\Longleftrightarrow\quad P_{Y|X=x}\ll P_Y\quad \textit{for } P_X\textit{-a.e. } x$$

Proof. 假设 $P_{X,Y}\ll P_XP_Y$。我们需要证明条件概率的 *any* 版本对几乎每个 x 满足 $P_{Y|X=x}\ll P_Y$。然而请注意，如果我们对 *some* 版本 $\tilde{P}_{Y|X}$ 证明这一点，那么任何版本的陈述都随之成立，因为对于 P_X-几乎处处 x，有 $P_{Y|X=x}=\tilde{P}_{Y|X=x}$。（这个测度论事实可以从链式法则 (2.24) 推导出来：由于 $P_X\tilde{P}_{Y|X}=P_{X,Y}=P_XP_{Y|X}$，我们必须有 $0=D(P_{X,Y}\|P_{X,Y})=D(\tilde{P}_{Y|X}\|P_{Y|X}|P_X)=\mathbb{E}_{x\sim P_X}[D(\tilde{P}_{Y|X=x}\|P_{Y|X=x})]$，从而推出所述事实。）因此设 $g(x,y)=\frac{dP_{X,Y}}{dP_XP_Y}(x,y)$ 和 $\rho(x)\triangleq\int_{\mathcal{Y}}g(x,y)P_Y(dy)$。固定任意集合 $E\subset\mathcal{X}$ 并注意到

$$P_X[E]=\int_{\mathcal{X}\times\mathcal{Y}}1_E(x)g(x,y)P_X(dx)\,P_Y(dy)=\int_{\mathcal{X}}1_E(x)\rho(x)P_X(dx)\,.$$

另一方面，我们还有 $P_X[E]=\int 1_E dP_X$，这意味着对于 P_X-几乎处处 x 有 $\rho(x)=1$。现在定义

$$\tilde{P}_{Y|X}(dy|x)=\begin{cases}g(x,y)P_Y(dy), & \rho(x)=1\\ P_Y(dy), & \rho(x)\neq 1\,.\end{cases}$$

直接将 $\tilde{P}_{Y|X}$ 代入 (2.22) 中表明，$\tilde{P}_{Y|X}$ 确实定义了在给定 X 条件下 Y 的条件概率的有效版本。由于按构造，对于每个 x，都有 $\tilde{P}_{Y|X=x}\ll P_Y$，因此结果得证。

相反，设 $P_{Y|X}$ 为一个核，使得 $P_X[E]=1$，其中 $E=\{x\colon P_{Y|X=x}\ll P_Y\}$ (回忆一下，根据引理2.13，E是可测的)。定义 $\tilde{P}_{Y|X=x}=P_{Y|X=x}$ 如果 $x\in E$ 和 $\tilde{P}_{Y|X=x}=P_Y$，否则。通过构造，对于每个 x，$P_X\tilde{P}_{Y|X}=P_XP_{Y|X}=P_{X,Y}$ 和 $\tilde{P}_{Y|X=x}\ll P_Y$。因此，根据定理2.12，存在一个联合可测的 $f(y|x)$，使得

$$\tilde{P}_{Y|X}(dy|x)=f(y|x)P_Y(dy)\,,$$

因此，由（2.22）

$$P_{X,Y}[E] = \int_E f(y|x)P_Y(dy)P_X(dx)\,,$$

意味着 $P_{X,Y} \ll P_X P_Y$。 □

3.2 互信息作为熵的差值

正如所承诺的，我们接下来介绍一个关于 $I(X;\ Y)$ 的不同视角，即作为熵的差异。这种（条件熵）香农的视角强调，$I(X;\ Y)$ 也是在衡量观察 Y 后 X 的分布扩散或不确定性的变化。

定理 3.4（互信息与熵）

(a) $I(X;X) = \begin{cases} H(X) & X \text{ discrete} \\ +\infty & \text{otherwise.} \end{cases}$

(b) If X is discrete, then

$$I(X;Y) + H(X|Y) = H(X)\,. \tag{3.2}$$

Consequently, either $H(X|Y) = H(X) = \infty$,[2] *or* $H(X|Y) < \infty$ *and*

$$I(X;Y) = H(X) - H(X|Y). \tag{3.3}$$

(c) If both X and Y are discrete, then

$$I(X;Y) + H(X,Y) = H(X) + H(Y),$$

so that whenever $H(X,Y) < \infty$ *we have*

$$I(X;Y) = H(X) + H(Y) - H(X,Y)\,.$$

(d) Similarly, if X, Y are real-valued random vectors with a joint PDF, then

$$I(X;Y) = h(X) + h(Y) - h(X,Y)$$

provided that $h(X,Y) < \infty$. *If X has a marginal PDF* p_X *and a conditional PDF* $p_{X|Y}(x|y)$, *then*

$$I(X;Y) = h(X) - h(X|Y)\,,$$

provided $h(X|Y) < \infty$.

[2] This is indeed possible if one takes $Y = 0$ (constant) and X from Example 1.3, demonstrating that (3.3) does not always hold.

(e) If X or Y are discrete then $I(X;Y) \le$ 最小值 $(H(X), H(Y))$, with equality iff $H(X|Y) = 0$ or $H(Y|X) = 0$, or, equivalently, iff one is a deterministic function of the other.

Proof. (a) 根据定理3.2.(a)，$I(X;X) = D(P_{X|X}\|P_X|P_X) = \mathbb{E}_{x\sim X} D(\delta_x\|P_X)$。如果$P_X$是离散的，那么$D(\delta_x\|P_X) = \log\frac{1}{P_X(x)}$ 和 $I(X;X) = H(X)$。如果P_X不是离散的，令$\mathcal{A} = \{x: P_X(x) > 0\}$ 表示P_X的原子集。令$\Delta = \{(x,x): x \notin \mathcal{A}\} \subset \mathcal{X}\times\mathcal{X}$。（$\Delta$是可测的，因为它是$\mathcal{A}^c \times \mathcal{A}^c$与对角线$\{(x,x): x \in \mathcal{X}\}$的交集。）那么$P_{X,X}(\Delta) = P_X(\mathcal{A}^c) > 0$，但由于

$$(P_X \times P_X)(E) \triangleq \int_{\mathcal{X}} P_X(dx_1) \int_{\mathcal{X}} P_X(dx_2) 1\{(x_1,x_2) \in E\}$$

根据取 $E = \Delta$，我们得到 $(P_X \times P_X)(\Delta) = 0$。因此 $P_{X,X} \not\ll P_X \times P_X$，从而根据定义

$$I(X;X) = D(P_{X,X}\|P_X P_X) = +\infty\,.$$

(由于 X 是离散的，存在一个可数集 S，使得 $\mathbb{P}[X \in S] = 1$，并且对于任意 $x_0 \in S$，我们有 $\mathbb{P}[X = x_0] > 0$。设 λ 为 S 上的计数测度，并设 $\mu = \lambda \times P_Y$，因此 $P_X P_Y \ll \mu$。如例3.1所示，我们也有 $P_{X,Y} \ll \mu$。此外，$f_P(x,y) \triangleq \frac{dP_{X,Y}}{d\mu}(x,y) = p_{X|Y}(x|y)$，其中后者表示在给定 Y (下 X 的条件概率质量函数，对于几乎所有的 y，它是一个正常概率质量函数，因为对于几乎所有的 y)，$\mathbb{P}[X \in S|Y = y] = 1$。我们还有 $f_Q(x,y) = \frac{dP_X P_Y}{d\mu}(x,y) = \frac{dP_X}{d\lambda}(x) = p_X(x)$，其中后者是 X 的无条件概率质量函数。注意，根据Radon-Nikodym导数的定义，我们有

$$\mathbb{E}[p_{X|Y}(x_0|Y)] = p_X(x_0)\,. \tag{3.4}$$

接下来，根据(2.12)，我们有

$$I(X;Y) = \mathbb{E}\left[\mathrm{Log}\frac{f_P(X,Y)}{f_Q(X,Y)}\right] = \mathbb{E}_{y\sim P_Y}\sum_{x\in S}\left[p_{X|Y}(x|y)\mathrm{Log}\frac{p_{X|Y}(x|y)}{p_X(x)}\right].$$

注意，$P_{X,Y}$-几乎必然地，$p_{X|Y}(X|Y) > 0$ 和 $P_X(x) > 0$，因此我们可以将上式中的 Log 替换为 log。另一方面，

$$H(X|Y) = \mathbb{E}_{y\sim P_Y}\sum_{x\in S}\left[p_{X|Y}(x|y)\log\frac{1}{p_{X|Y}(x|y)}\right].$$

将这两个表达式相加，我们得到

$$\begin{aligned} I(X;Y) + H(X|Y) &\overset{(a)}{=} \mathbb{E}_{y\sim P_Y}\sum_{x\in S}\left[p_{X|Y}(x|y)\log\frac{1}{p_X(x)}\right] \\ &\overset{(b)}{=} \sum_{x\in S}\mathbb{E}_{y\sim P_Y}\left[p_{X|Y}(x|y)\right]\log\frac{1}{p_X(x)} \overset{(c)}{=} \mathbb{E}\left[\log\frac{1}{P_X(X)}\right] \triangleq H(X)\,, \end{aligned}$$

其中在 (a) 中我们使用了 Lebesgue 积分的线性性 $\mathbb{E}_{P_Y}\sum_x$，在 (b) 中我们通过 Fubini 交换了 $\mathbb{E}$ 和 $\sum$；而 (c) 成立是由于 (3.4)。
(c) 只需将 $H(Y)$ 加到 (3.2) 的两边，并使用 (1.2) 中 H 的链式法则。

(d) 这些论证与离散情形相似，不同之处在于计数测度被勒贝格测度替代。细节留作练习。(e) 由(b)推出。

□

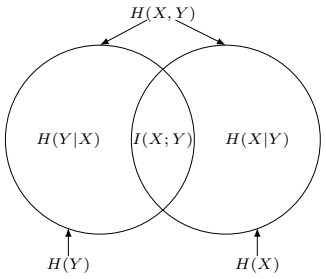
从（3.2）我们推导出以下结果，该结果先前已在定理1.4(d)中展示。

推论 3.5 (条件作用降低熵) *For discrete X, $H(X|Y) \leq H(X)$, with equality iff $X \perp\!\!\!\perp Y$.*

Proof. 如果 $H(X) = \infty$ 则无需证明。否则，应用（3.2）。 □

因此，最后一个推论的直观含义（也是香农的一项重要创新）在于赋予熵减量（互信息）以意义。需要注意的是，条件化降低的是熵 *on average*，而非针对每个实现。事实上，取 $X = U \,\mathtt{OR}\, Y$，其中 $U, Y \overset{\text{i.i.d.}}{\sim}$ 服从 Ber($\frac{1}{2}$)。那么 $X \sim$ 服从 Ber($\frac{3}{4}$)，且 $H(X) = h(\frac{1}{4}) < 1\,\mathtt{bit} = H(X|Y=0)$，即以 $Y=0$ 为条件会增加熵。但 *on average*，$H(X|Y) = \mathbb{P}[Y=0]\, H(X|Y=0) + \mathbb{P}[Y=1]\, H(X|Y=1) = \frac{1}{2}\,\mathtt{bits} < H(X)$，这由 $h(\cdot)$ 的强凹性可得。

注3.1（信息、熵与维恩图）对于离散随机变量，下面的维恩图展示了定理3.4(b)和(c)中熵、条件熵、联合熵以及互信息之间的关系。



类似地将容斥原理应用于三个变量X_1, X_2, X_3，我们看到三重交集对应于

$$H(X_1) + H(X_2) + H(X_3) - H(X_1, X_2) - H(X_2, X_3) - H(X_1, X_3) + H(X_1, X_2, X_3) \tag{3.5}$$

有时用$I(X_1$表示；X_2；$X_3)$。它可以是正数也可以是负数（为什么？）。

通常，可以将随机变量视为集合（这样，X_i对应于集合E_i，而配对（X_1, X_2）对应于$E_1 \cup E_2$）。随后，我们可以在这个由这些集合生成的有限代数上定义一个唯一的符号测度μ，使得每一个信息量都可以通过替换

$$I/H \to \mu \quad ; \to \cap \quad , \to \cup \quad | \to \setminus .$$

作为一个例子，我们有

$$H(X_1|X_2, X_3) = \mu(E_1 \setminus (E_2 \cup E_3)), \tag{3.6}$$

$$I(X_1, X_2; X_3|X_4) = \mu(((E_1 \cup E_2) \cap E_3) \setminus E_4)\,. \tag{3.7}$$

通过容斥原理，(3.5)中的量对应于$\mu(E_1 \cap E_2 \cap E_3)$，这解释了为什么$\mu$不一定是正测度。有关广泛讨论，参见[110，第1.3章]。

3.3 互信息计算示例

下面我们演示如何在连续和离散设置中计算 I。

示例 3.2（二元高斯分布）设 X, Y 为联合高斯分布。那么

$$I(X;Y) = \frac{1}{2}\log\frac{1}{1-\rho_{X,Y}^2} \tag{3.8}$$

其中 $\rho_{X,Y} \triangleq \frac{\mathbb{E}[(X-\mathbb{E}X)(Y-\mathbb{E}Y)]}{\sigma_X\sigma_Y} \in [-1,1]$ 是相关系数；其图示见图3.1。为证明(3.8)，通过必要的平移和缩放，我们可以不失一般性地假设

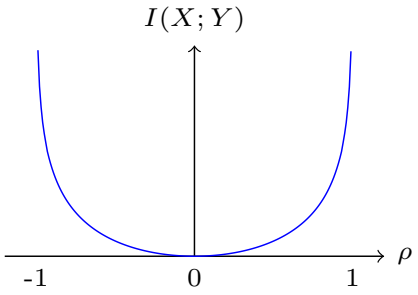


图3.1 相关高斯分布之间的互信息。

$\mathbb{E}X = \mathbb{E}Y = 0$ 和 $\mathbb{E}X^2 = \mathbb{E}Y^2 = 1$。然后 $\rho = \mathbb{E}XY$。根据联合高斯性，$Y = \rho X + Z$ 对于某个 $Z \sim \mathcal{N}(0, 1-\rho^2) \perp\!\!\!\perp X$。接着利用高斯分布的散度公式 (2.7)，我们得到

$$\begin{aligned} I(X;Y) &= D(P_{Y|X}\|P_Y|P_X) \\ &= \mathbb{E}D(\mathcal{N}(\rho X, 1-\rho^2)\|\mathcal{N}(0,1)) \\ &= \mathbb{E}\left[\frac{1}{2}\log\frac{1}{1-\rho^2} + \frac{\log e}{2}\left((\rho X)^2 + 1 - \rho^2 - 1\right)\right] \\ &= \frac{1}{2}\log\frac{1}{1-\rho^2}. \end{aligned}$$

或者，我们可以使用定理3.4(d)中的微分熵表示以及高斯分布的熵公式(2.17)：

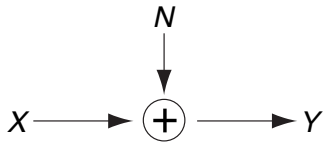
$$\begin{aligned} I(X;Y) &= h(Y) - h(Y|X) \\ &= h(Y) - h(Z) \end{aligned}$$

$$= \frac{1}{2}\log(2\pi e) - \frac{1}{2}\log(2\pi e(1-\rho^2)) = \frac{1}{2}\log\frac{1}{1-\rho^2}.$$

其中第二个等式是通过应用h的平移不变性以及X和Z之间的独立性来得到
$h(Y|X) = h(Y-X|X) = h(Z|X) = h(Z)$。

与互信息的作用类似，相关系数也在某种意义上衡量了实值（或更一般地，内积空间中的值）随机变量之间的依赖关系。相比之下，互信息对双射不变且更为通用，因为它不仅可以定义数值随机变量，还可以定义任意随机变量。

例 3.3（AWGN 信道）加性白高斯噪声（AWGN）信道是本书中将使用的马尔可夫核的主要例子之一。该核通过取输入 x 并设置 $K(\cdot|x) \sim \mathcal{N}(x, \sigma_N^2)$，从 $\mathbb{R}$ 作用到 $\mathbb{R}$，或者，在方程形式中我们写作 $Y = X + N$，其中 $X \perp\!\!\!\perp N \sim \mathcal{N}(0, \sigma_N^2)$。在图形上，我们可以将其视为



现在，假设 $X \sim \mathcal{N}(0, \sigma_X^2)$，此时 $Y \sim \mathcal{N}(0, \sigma_X^2 + \sigma_N^2)$。那么通过两次应用(2.17)，我们得到

$$I(X;Y) = h(Y) - h(Y|X) = h(X+N) - h(N) = \frac{1}{2}\log\left(1 + \frac{\sigma_X^2}{\sigma_N^2}\right),$$

其中 $\frac{\sigma_X^2}{\sigma_N^2}$ 常被称为 *signal-to-noise ratio (SNR)*。参见图3.2的说明。注意，在工程中通常以分贝（dB）表示SNR，因此SNR（以dB为单位）等于$10\log_{10}(SNR)$。稍后，我们将在定义20.10中更正式地定义AWGN信道。

示例 3.4（BI-AWGN 信道）在通信和统计应用中，人们也经常遇到一种情况，即 AWGN 信道的输入被限制为 $X \in \{\pm 1\}$。这个马尔可夫核记为 $\mathsf{BIAWGN}_{\sigma_N^2}\colon \{\pm 1\} \to \mathbb{R}$，并通过设定

$$Y = X + N, \qquad X \perp\!\!\!\perp N \sim \mathcal{N}(0, \sigma_N^2)\,.$$

如果我们将$X \sim$设为Ber(1/2)，那么在这种情况下，通过不同于AWGN情况的分解来计算互信息更为方便。实际上，我们有

$$I(X;Y) = H(X) - H(X|Y) = \log 2 - H(X|Y)\,.$$

为了计算 $H(X|Y=y)$，我们只需评估给定观测 $Y=y$ 的后验分布。在这种情况下，我们有 $\mathbb{P}[X=+1|Y=y] = \frac{e^{\frac{y}{\sigma_N^2}}}{e^{-\frac{y}{\sigma_N^2}} + e^{\frac{y}{\sigma_N^2}}}$。因此，经过一些代数运算，我们得到

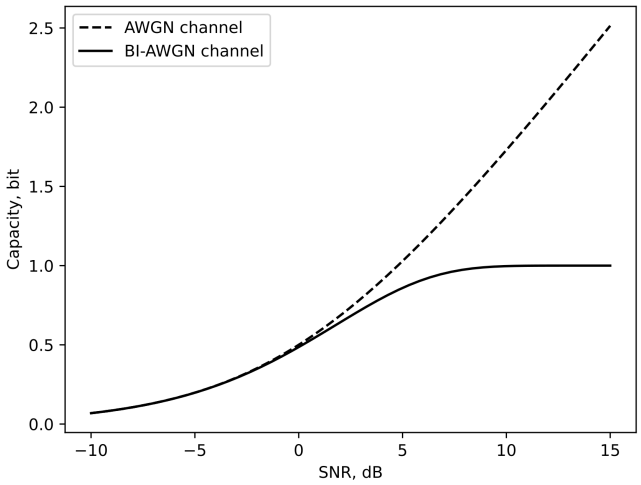


图3.2 比较AWGN信道和BI-AWGN信道的互信息（参见例3.3和3.4）。本书后续将展示，这些互信息与各自信道的容量相等。

以下表达式

$$I(X;Y) = \log 2 - \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}} \log(1 + e^{-\frac{2}{\sigma^2} + \frac{2}{\sigma} z})\, dz\,.$$

(可以验证，这里的 $H(X|Y)$ 与例1.4(2) 中的 σ 替换为2σ) 一致。对于此信道，SNR由 $\frac{\mathbb{E}[X^2]}{\mathbb{E}[N^2]} = \frac{1}{\sigma_N^2}$ 给出。我们在图3.2中比较了AWGN和BI-AWGN的互信息随SNR的变化。注意，在低SNR下，限制为二进制输入几乎不会导致信息损失——这一事实支撑了BI-AWGN信道在许多现实世界通信系统中所起的作用。

例 3.5（高斯向量）令 $\mathrm{X} \in \mathbb{R}^m$ 和 $\mathrm{Y} \in \mathbb{R}^n$ 为联合高斯分布。那么

$$I(\mathbf{X};\mathbf{Y}) = \frac{1}{2} \log \frac{\det \Sigma_{\mathbf{X}} \det \Sigma_{\mathbf{Y}}}{\det \Sigma_{[\mathbf{X},\mathbf{Y}]}}$$

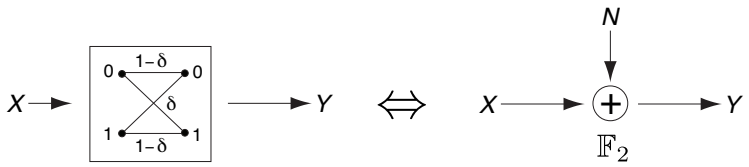
其中 $\Sigma_{\mathbf{X}} \triangleq \mathbb{E}\left[(\mathrm{X} - \mathbb{E}\mathrm{X})(\mathrm{X} - \mathbb{E}\mathrm{X})^{\top}\right]$ 表示 $\mathrm{X} \in \mathbb{R}^m$ 的协方差矩阵，而 $\Sigma_{[\mathbf{X},\mathbf{Y}]}$ 表示随机向量 $[\mathrm{X}, \mathrm{Y}] \in \mathbb{R}^{m+n}$ 的协方差矩阵。

在加性噪声的特殊情况下：$\mathrm{Y} = \mathrm{X} + \mathrm{N}$，其中 $\mathrm{N} \perp\!\!\!\perp \mathrm{X}$，我们有

$$I(\mathbf{X};\mathbf{X}+\mathbf{N}) = \frac{1}{2} \log \frac{\det(\Sigma_{\mathbf{X}} + \Sigma_{\mathbf{N}})}{\det \Sigma_{\mathbf{N}}}$$

由于 $\det \Sigma_{[\mathbf{X},\mathbf{X}+\mathbf{N}]} = \det \begin{pmatrix} \Sigma_{\mathbf{X}} & \Sigma_{\mathbf{X}} \\ \Sigma_{\mathbf{X}} & \Sigma_{\mathbf{X}}+\Sigma_{\mathbf{N}} \end{pmatrix} \overset{\text{why?}}{=} \det \Sigma_{\mathbf{X}} \det \Sigma_{\mathbf{N}}$。

例 3.6（二元对称信道）回顾例 1.4(1) 中的设定。设 $X \sim \mathrm{Ber}(\frac{1}{2})$ 与 $N \sim \mathrm{Ber}(\delta)$ 相互独立。令 $Y = X \oplus N$；等价地，Y 是通过以概率 δ 翻转 X 得到的。



如例1.4(1)所示，$H(X|Y) = H(N) = h(\delta)$，因此

$$I(X;Y) = \log 2 - h(\delta).$$

相应的条件分布$P_{Y|X}$ (马尔可夫核)被称为参数为δ的二进制对称信道（BSC），并用BSC_δ表示。

例3.7（有限群上的加法）将例3.6推广，令X和Z取值于有限阿贝尔群G。若X在G上均匀分布且与Z独立，则

$$I(X;X+Z) = \log|G| - H(Z),$$

这直接源于 $X+Z$ 在 G 上均匀分布，无论 Z 的分布如何。对于非阿贝尔群也是如此，但此时 $+$ 应替换为群运算 $\circ$，信道作用为 $x \mapsto x \circ Z$、$Z \sim P_Z$。

3.4 条件互信息与条件独立性

定义 3.6（条件互信息）如果 $\mathcal{X}$ 和 $\mathcal{Y}$ 是标准博雷尔空间，则我们定义

$$I(X;Y|Z) \triangleq D(P_{X,Y|Z}\|P_{X|Z}P_{Y|Z}|P_Z) \tag{3.9}$$

$$= \mathbb{E}_{z\sim P_Z}[I(X;Y|Z=z)]\,. \tag{3.10}$$

其中乘积 $P_{X|Z}P_{Y|Z}$ 是一个条件分布，使得 $(P_{X|Z}P_{Y|Z})(A\times B|z) = P_{X|Z}(A|z)P_{Y|Z}(B|z)$，在此条件下，$X$ 和 Y 在给定 Z 时相互独立。

将 $I(X;Y)$ 表示为联合分布 $P_{X,Y}$ 的函数 $I(P_{X,Y})$，我们有 $I(X;Y|Z) = \mathbb{E}_{z\sim P_Z}[I(P_{X,Y|Z=z})]$。因此，$I(X;Y|Z)$ 是 P_Z 中的线性泛函。映射 $z \mapsto I(P_{X,Y|Z=z})$ 的可测性并不显然，但可由引理2.13推出。

为了进一步讨论条件互信息的性质，让我们首先引入条件独立性的记号。一族联合分布可以用一个编码底层随机变量依赖结构的有向无环图（DAG）来表示。我们不打算在此引入正式定义，详细内容请参阅标准专著 [271]。但简而言之，每个由有限（或可数无限）

许多随机变量可以用DAG来表示。DAG的节点对应于随机变量，节点U的入边简单地描述了需要知道哪些变量才能生成U。一个简单的例子是马尔可夫链（路径图）$X \to Y \to Z$，它表示的分布分解为$\{P_{X,Y,Z}\colon\ P_{X,Y,Z} = P_X P_{Y|X} P_{Z|Y}\}$。我们有以下等价描述：

$$\begin{aligned} X \to Y \to Z \quad &\Leftrightarrow \quad P_{X,Z|Y} = P_{X|Y} \cdot P_{Z|Y} \\ &\Leftrightarrow \quad P_{Z|X,Y} = P_{Z|Y} \\ &\Leftrightarrow \quad P_{X,Y,Z} = P_X \cdot P_{Y|X} \cdot P_{Z|Y} \\ &\Leftrightarrow \quad X, Y, Z \text{ form a Markov chain} \\ &\Leftrightarrow \quad X \perp\!\!\!\perp Z|Y \\ &\Leftrightarrow \quad X \leftarrow Y \to Z, P_{X,Y,Z} = P_Y \cdot P_{X|Y} \cdot P_{Z|Y} \\ &\Leftrightarrow \quad Z \to Y \to X \end{aligned}$$

有一种通用方法可以获得一般图的这些等价关系，称为*d-separation*，参见[271]。我们说变量V在某条无向路径上是*collider*，如果它作为出现在该路径上：

$$\text{collider:} \qquad \cdots \to V \leftarrow \cdots . \tag{3.11}$$

否则，V 被称为非碰撞点（因此表现为 $\to V \to$、$\leftarrow V \leftarrow$ 或 $\leftarrow V \to$）。如果存在从 A 中某个变量到 B 中某个变量的无向路径，且满足 a) C 中没有非碰撞点，b) 每个碰撞点要么在 C 中，要么在 C 中有一个后代，则称变量集合对 A 和 B 被集合 C *d-connected*。*d*-连通性的概念很重要，因为它刻画了条件独立性。具体而言，$A \perp\!\!\!\perp B|C$ 在 *every distribution* 中满足给定的图模型，当且仅当 A 和 B 被 C *not d*-连通。掌握这一准则对于许多信息论方面的考虑相当有用。然而，在我们的书中，除了上面列出的线性马尔可夫链的基本等价性之外，我们不会正式要求这一工具。不过，我们确实建议进行练习，例如通过做练习 I.26–I.30。

定理3.7（互信息的进一步性质） *Suppose that all random variables are valued in standard Borel spaces. Then:*

(a) $I(X;\ Z|Y) \geq 0$
, with equality iff $X \to Y \to Z$.
(b) (Simple chain rule)[3]

$$\begin{aligned} I(X,Y;Z) &= I(X;Z) + I(Y;Z|X) \\ &= I(Y;Z) + I(X;Z|Y). \end{aligned}$$

3 也称为“Kolmogorov identities”。

(c) (DPI for mutual information) If $X \to Y \to Z$, then

$$I(X;Z) \le I(X;Y)\,, \tag{3.12}$$

with equality iff $X \to Z \to Y$.

(d) If $X \to Y \to Z \to W$, then $I(X;W) \le I(Y;Z)$.

(e) (Full chain rule)

$$I(X^n;Y) = \sum_{k=1}^{n} I(X_k;Y|X^{k-1}).$$

(f) (Permutation invariance) If f and g are one-to-one (with measurable inverses), then $I(f(X);g(Y)) = I(X;Y)$.

Proof. (a) 根据定义及定理3.2(c)。
(b) 首先，注意到由(3.1)我们得到（采用不言自明的记号）：

$$I(Y;Z|X=x) = D(P_{Y|Z,X=x}\|P_{Y|X=x}|P_{Z|X=x})\,.$$

在此处对X取期望，我们得到

$$I(Y;Z|X) \overset{\text{(a)}}{=} D(P_{Y|X,Z}\|P_{Y|X}|P_{X,Z})\,.$$

另一方面，根据链式法则对于D，（2.24），我们有

$$D(P_{X,Y,Z}\|P_{X,Y}P_Z) \overset{\text{(b)}}{=} D(P_{X,Z}\|P_XP_Z) + D(P_{Y|X,Z}\|P_{Y|X}|P_{X,Z})\,,$$

其中在第二项中，我们注意到在测度$P_{X,Y}P_Z$下对X,Z进行条件化会导致$P_{Y|X}$ (独立于Z)。结合(a)和(b)即完成了证明。
(c) 将柯尔莫哥洛夫恒等式应用于 $I(Y,Z;\ X)$:

$$\begin{aligned} I(Y,Z;X) &= I(X;Y) + \underbrace{I(X;Z|Y)}_{=0} \\ &= I(X;Z) + I(X;Y|Z) \end{aligned}$$

(d) DPI 的几个应用：$I(X;\ W) \le I(X;\ Z) \le I(Y\quad\quad;Z)$
(e) Kolmogorov 恒等式的递归应用。(f) 对 f 应用 DPI，然后对 f^{-1} 应用 DPI。

□

注3.2 通常情况下，$I(X;\ Y|Z)$与$I(X;\ Y)$是不可比较的。实际上，考虑以下例子：

- $I(X;Y|Z) > I(X;Y)$：我们需要找到一个 X,Y,Z 的例子，它不构成马尔可夫链。为此，请注意只有一个有向无环图不与 $X \to Y \to Z$ 同构，即 $X \to Y \leftarrow Z$。基于这一思路，我们构造 $X,Z \overset{\text{i.i.d.}}{\sim} \text{Ber}(\frac{1}{2})$ 和 $Y = X \oplus Z$。那么 $I(X;$ 由于 $X \perp\!\!\!\perp Y$，$Y) = 0$；然而，$I(X;\ Y|Z) = I(X;\ X \oplus Z|Z) = H(X) = 1\,\texttt{bit}$。

- $I(X;Y|Z) < I(X;Y)$: 只需令 X,Y,Z 为有限字母表上的任意随机变量，且 $Z=Y$。那么 $I(X;Y|Z)=I(X;Y|Y)=H(Y|Y)-H(Y|X,Y)=0$ 由 (3.3) 的条件版本。

备注 3.3（$I\Rightarrow$ 的链式法则 H 的链式法则）设 $Y=X^n$。则 $H(X^n)=I(X^n;X^n)=\sum_{k=1}^n I(X_k;X^n|X^{k-1})=\sum_{k=1}^n H(X_k|X^{k-1})$，因为 $H(X_k|X^n,X^{k-1})=0$。

备注3.4（散度的DPI $\Longrightarrow$ 互信息的DPI）我们在定理3.7中利用Kolmogorov恒等式证明了互信息的DPI。事实上，互信息的DPI是定理2.17中散度的 *implied by*：

$$I(X;Z)=D(P_{Z|X}\|P_Z|P_X)\le D(P_{Y|X}\|P_Y|P_X)=I(X;Y),$$

其中注意对于每个 x，我们有 $P_{Y|X=x}\xrightarrow{P_{Z|Y}}P_{Z|X=x}$ 和 $P_Y\xrightarrow{P_{Z|Y}}P_Z$。因此，如果我们有一个满足 DPI 的分布的双变量泛函 $\mathcal{D}(P\|Q)$，那么我们可以通过 $I_{\mathcal{D}}(X;Y)\triangleq\mathcal{D}(P_{Y|X}\|P_Y|P_X)\triangleq\mathbb{E}_{x\sim P_X}\mathcal{D}(P_{Y|X=x}\|P_Y)$ 定义一个“类互信息”量，它将在马尔可夫链上满足 DPI。通过取 $\mathcal{D}=D_f$ (一个 f-散度，可以产生丰富的一类例子——见第7章)。

注3.5（强数据处理不等式）对于许多信道$P_{Y|X}$，可以将数据处理不等式（2.28）加强如下：对于任意P_X,Q_X，我们有

$$D(P_Y\|Q_Y)\le\eta_{\mathrm{KL}}D(P_X\|Q_X)\,,$$

其中 $\eta_{\mathrm{KL}}<1$ 且仅依赖于信道 $P_{Y|X}$。类似地，这改进了定理3.7(c)中互信息的数据处理不等式：对于任意 $P_{U,X}$，我们有

$$U\to X\to Y\quad\Longrightarrow\quad I(U;Y)\le\eta_{\mathrm{KL}}I(U;X)\,.$$

例如，对于$P_{Y|X}=\mathsf{BSC}_\delta$我们有$\eta_{\mathrm{KL}}=(1-2\delta)^2$。强数据处理不等式（SDPIs）量化了一个直观观察：信道$P_{Y|X}$固有的噪声必定会减少Y携带的关于数据U的信息量，无论我们如何优化编码$U\mapsto X$。我们在第33章进一步探讨SDPI及其在统计学中的影响。

除 DPI 中的严格不等式情况外，等式成立的情形也值得进一步审视。如果 $U\to X\to Y$ 和 $I(U;X)=I(U;Y)$，直观上意味着，就 U 而言，将 X 概括为 Y 不会造成信息损失。用统计学的术语来说，Y 是 X 关于 U 的充分统计量。这是下一节的主题。

3.5 充分统计量与数据处理

在本书的后续部分，我们将对估计X的概率分布的参数θ产生兴趣。为此，人们通常首先尝试去除X中包含的不必要信息。让我们将这一设定正式化如下：

- 令 P_X^θ 为以 $\theta\in\Theta$ 为参数的 X 分布的集合；

- 令 $P_{T|X}$ 为某个马尔可夫核。对每个 θ，令 $P_T^\theta \triangleq P_{T|X} \circ P_X^\theta$ 为 T 上的诱导分布。

定义3.8（充分统计量）若存在转移概率核 $P_{X|T}$ 使得 $P_X^\theta P_{T|X} = P_T^\theta P_{X|T}$，即 $P_{X|T}$ 可以选择不依赖于 θ，则称 T 是 θ 的 X 的一个 *sufficient statistic*。

T 充分的直观解释是，有了 T，就可以忽略 X；换句话说，T 包含了推断 θ 所需的全部相关信息。这是因为 X 可以仅基于 T 模拟，而无需知道 θ。因此，X 不为识别 θ 提供额外信息。X 的任何一对一变换都是充分的，然而，这并不是有趣的情形。在有趣的情形中，T 的维数将远小于 X 的维数（通常等于 θ 的维数）。参见下面的例子。

还要注意，参数 θ 不必是随机变量，因为定义3.8不涉及 θ 上的任何分布（先验）。这是关于参数估计问题的一种所谓的 *frequentist* 观点。

定理 3.9 *Let θ, X, T be as in the setting above. Then the following are equivalent*

(a) T is a sufficient statistic of X for θ.
(b) $\forall P_\theta$, $\theta \to T \to X$.
(c) $\forall P_\theta$, $I(\theta; X|T) = 0$.; $X) = I(\theta;$
(d) $\forall P_\theta$, $I(\theta$ the data processing inequality for mutual information holds with equality.

Proof. 我们省略细节，这些细节相当于要么以条件独立性的形式重述条件，要么引用定理3.7中所述性质中的等号成立情况。 □

Fisher的以下结果提供了一个验证充分性的准则：

定理3.10（费舍尔因子分解定理）*For all $\theta \in \Theta$, let P_X^θ have a density p_θ with respect to a common dominating measure μ. Let $T = T(X)$ be a deterministic function of X. Then T is a sufficient statistic of X for θ iff*

$$p_\theta(x) = g_\theta(T(x))h(x)$$

for some measurable functions g_θ and h and all $\theta \in \Theta$.

Proof. 我们仅在离散情况下给出证明，其中 p_θ 表示概率质量函数。（一般情况的论证类似，只需将 $\sum$ 替换为 $\int d\mu$）。设 $t = T(x)$。

“$\Rightarrow$”：假设 T 是 X 关于 θ 的充分统计量。那么 $p_\theta(x) = P_\theta(X = x) = P_\theta(X = x, T = t) = P_\theta(X = x|T = t)P_\theta(T = t) = \underbrace{P(X = x|T = T(x))}_{h(x)} \underbrace{P_\theta(T = T(x))}_{g_\theta(T(x))}$

"⇐"：假设因式分解成立。那么

$$P_\theta(X=x|T=t)=\frac{p_\theta(x)}{\sum_x 1\{T(x)=t\}p_\theta(x)}=\frac{g_\theta(t)h(x)}{\sum_x 1\{T(x)=t\}g_\theta(t)h(x)}=\frac{h(x)}{\sum_x 1\{T(x)=t\}h(x)},$$

不含 θ。 □

例 3.8（独立观测）在以下示例中，一个参数化分布生成大小为 n 的独立样本，该样本可以概括为一个标量值充分统计量。这些可以通过检查 n 重乘积分布的因子分解并应用定理 3.10 来验证。

• *Normal mean model*。令 $\theta\in\mathbb{R}$ 和观测值 $X_1,\dots,X_n \overset{\text{i.i.d.}}{\sim} \mathcal{N}(\theta,1)$。则样本均值 $\bar{X}=\frac{1}{n}\sum_{j=1}^n X_j$ 是 X^n 对于 θ 的充分统计量。• *Coin flips*。令 $B_i \overset{\text{i.i.d.}}{\sim} \text{Ber}(\theta)$。则 $\sum_{i=1}^n B_i$ 是 B^n 对于 θ 的充分统计量。• *Uniform distribution*。令 $U_i \overset{\text{i.i.d.}}{\sim} \text{Unif}(0,\theta)$。则 $\max_{i\in[n]} U_i$ 是 U^n 对于 θ 的充分统计量。

例 3.9（假设检验的充分统计量）设 $\Theta=\{0,1\}$。给定 $\theta=0$ 或 1，分别为 $X\sim P_X$ 或 Q_X。那么，Y —— $P_{Y|X}$ 的输出 —— 是 X 关于 θ 的充分统计量，当且仅当 $D(P_{X|Y}\|Q_{X|Y}|P_Y)=0$，即 $P_{X|Y}=Q_{X|Y}$ 成立 P_Y-几乎必然。事实上，后者意味着对于核 $Q_{X|Y}$，我们有

$$P_XP_{Y|X}=P_YQ_{X|Y}\quad\text{and}\quad Q_XP_{Y|X}=Q_YQ_{X|Y},$$

这正是当$\theta\in\{0,1\}$时充分统计量的定义。此例解释了定理2.17中散度数据处理不等式取等号的条件。接着假设$D(P_Y\|Q_Y)<\infty$，我们得到：

$$D(P_X\|Q_X)=D(P_Y\|Q_Y)\quad\Longleftrightarrow\quad Y\text{是用于检验}P_X\text{与}Q_X\text{的充分统计量}$$

Proof. 让 $Q_{X,Y}=Q_XP_{Y|X}$、$P_{X,Y}=P_XP_{Y|X}$，然后

$$\begin{aligned}D(P_{X,Y}\|Q_{X,Y})&=\underbrace{D(P_{Y|X}\|Q_{Y|X}|P_X)}_{=0}+D(P_X\|Q_X)\\&=D(P_{X|Y}\|Q_{X|Y}|P_Y)+D(P_Y\|Q_Y)\\&\geq D(P_Y\|Q_Y)\end{aligned}$$

当且仅当$D(P_{X|Y}\|Q_{X|Y}|P_Y)=0$时取等号，这等价于$Y$是用于检验$P_X$与$Q_X$的充分统计量，正如所需。 □

3.6 错误概率与Fano不等式

设 W 为一个随机变量，$\hat{W}$ 为对其的预测。根据用于生成 $\hat{W}$ 的可用信息，我们可以考虑三类问题：

1 随机猜测：$W \perp\!\!\!\perp \hat{W}$。2 使用数据进行猜测：$W \to X \to \hat{W}$，其中 $X = f(W)$ 是 W 的确定性函数。3 使用含噪数据进行猜测：$W \to X \to Y \to \hat{W}$，其中 $X \to Y$ 由某个噪声信道给出。

我们的目标是得出如下类型的逆命题：如果W的不确定性过高，或者数据提供的信息过于稀少，那么就很难猜测W的值。在本节中，我们利用（条件）熵和互信息将这些直觉形式化。

定理 3.11 *Let* $|\mathcal{X}| = M < \infty$. *Then for any* $\hat{X} \perp\!\!\!\perp X$,

$$H(X) \le F_M(\mathbb{P}[X = \hat{X}]) \tag{3.13}$$

where

$$F_M(x) \triangleq (1-x)\log(M-1) + h(x), x \in [0,1] \tag{3.14}$$

and $h(x) = x\log\frac{1}{x} + (1-x)$ 日志$\frac{1}{1-x}$ *is the binary entropy function.*

If P最大 $\triangleq$ 最大 $_{x\in\mathcal{X}} P_X(x)$, *then*

$$H(X) \le F_M(P_{\max}) = (1-P_{\max})\log(M-1) + h(P_{\max}), \tag{3.15}$$

with equality iff $P_X = (P_{\max}, \frac{1-P_{\max}1}{M-}, \ldots, \frac{1-P_{\max}1}{M-})$.

函数 $F_M(\cdot)$ 如图 3.3 所示。注意，由于其非单调性，陈述（3.15）并不蕴含（3.13），即使 $\mathbb{P}[X = \hat{X}] \le P_{\max}$。

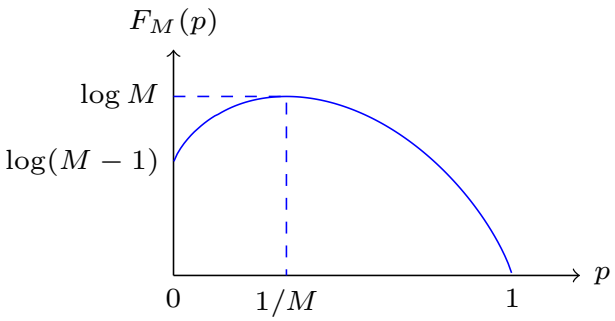


图3.3 (3.14)中的函数F_M是凹函数，在最大值点$1/M$处取得最大对数M，但不是单调的。

Proof. 为展示（3.13），考虑一个辅助（乘积）分布 $Q_{X,\hat{X}} = U_X P_{\hat{X}}$，其中 U_X 在 $\mathcal{X}$ 上均匀分布。于是 $Q[X = \hat{X}] = 1/M$。记 $P[X = \hat{X}] \triangleq P_S$，对数据处理器 $(X, \hat{X}) \mapsto 1\left\{X = \hat{X}\right\}$ 应用散度的 DPI 可得 $d(P_S\|1/M) \le D(P_{X\hat{X}}\|Q_{X\hat{X}}) = \log M - H(X)$。

为了说明第二部分，假设有人在没有任何附加信息的情况下试图猜测X的值。那么最佳猜测显然是最可能的结果（众数）以及最大概率

成功的{v*}

$$\max_{\hat{X}\perp X} \mathbb{P}[X=\hat{X}] = P_{\max}. \tag{3.16}$$

因此，应用(3.13)，其中$\hat{X}$为模式产量(3.15)。最后，假设$P = (P_{\max}, P_2, \ldots, P_M)$并引入$Q = (P_{\max}, \frac{1-P_{\max}}{M-1}, \ldots, \frac{1-P_{\max}}{M-1})$。那么(3.15)的右侧与左侧之差等于$D(P\|Q) \geq 0$，当且仅当$P = Q$时取等号。 □

注 3.6 我们来讨论一下这个不寻常的证明技巧。我们没有直接研究给定的概率空间 $P_{X,\hat{X}}$，而是引入了一个辅助概率空间：$Q_{X,\hat{X}}$。然后我们对辅助问题（错误概率 $= 1 - \frac{1}{M}$）的目标度量（错误概率）得出了结论。最后，我们使用 DPI 将关于 Q 的陈述转化为关于 P 的陈述：如果 $D(P\|Q)$ 很小，那么事件（例如 $\{X \neq \hat{X}\}$）的概率也应该很小。这是一个通用方法，被称为 *meta-converse*，我们将在本书后面针对信道编码（见第 22.3 节）更详细地展开。然而，对于具体结果 (3.15)，有更显式的方法来推导它——见练习 I.25。

与香农熵 H 类似，$P_{\max}$ 也是衡量 P 随机性的一个合理度量。事实上，回顾（1.4）可知

$$H_\infty(P) = \log \frac{1}{P_{\max}} \tag{3.17}$$

是∞阶的Rényi熵，参见(1.4)。在这方面，定理3.11可以被视为我们 *comparison of information measures*的第一个例子：它比较了H和H_∞。我们将在7.4节系统地研究此类比较。

接下来我们进入Fano不等式的设定，其中估计$\hat{X}$是基于与X相关的某个观测Y进行的。我们将看到，前一定理的证明可以平凡地推广到这种可能为随机估计量的新情况。尽管在证明中并不需要，但值得一提的是，最小化错误概率$\mathbb{P}[X \neq \hat{X}]$的最佳估计量是最大后验（MAP）规则，即后验众数：$\hat{X}(y) = \operatorname{argmax}_x P_{X|Y}(x|y)$。

定理3.12 (Fano不等式) *Let* $|\mathcal{X}| = M < \infty$ *and* $X \to Y \to \hat{X}$. *Let* $P_e = \mathbb{P}[X \neq \hat{X}]$, *then*

$$H(X|Y) \leq F_M(1-P_e) = P_e \log(M-1) + h(P_e)\,. \tag{3.18}$$

Furthermore, if $P_{\max} \triangleq \max_{x\in\mathcal{X}} P_X(x) > 0$, *then regardless of* $|\mathcal{X}|$,

$$I(X;Y) \geq (1-P_e)\log\frac{1}{P_{\max}} - h(P_e)\,. \tag{3.19}$$

Proof. 为了展示（3.18），我们对 $P_{X,Y,\hat{X}} = P_X P_{Y|X} P_{\hat{X}|Y}$ 与 $Q_{X,Y,\hat{X}} = U_X P_Y P_{\hat{X}|Y}$ 应用数据处理（针对散度）以及数据处理器（核）$(X,Y,\hat{X}) \mapsto 1\left\{X \neq \hat{X}\right\}$ (注意，$P_{\hat{X}|Y}$ 对两者是相同的)。

为了展示(3.19)，我们对$P_{X,Y,\hat{X}} = P_X P_{Y|X} P_{\hat{X}|Y}$与$Q_{X,Y,\hat{X}} = P_X P_Y P_{\hat{X}|Y}$应用数据处理（针对散度），并通过数据处理器（核）$(X,Y,\hat{X}) \mapsto 1\left\{X \neq \hat{X}\right\}$得到：

$$\begin{aligned} I(X;Y) = D(P_{X,Y,\hat{X}} \| Q_{X,Y,\hat{X}}) &\geq d(\mathbb{P}[X=\hat{X}] \| \mathbb{Q}[X=\hat{X}]) \\ &\geq -h(P_e) + (1-P_e)\log\frac{1}{\mathbb{Q}[X=\hat{X}]} \geq -h(P_e) - (1-P_e)\log P_{\max}\,, \end{aligned}$$

其中最后一步由 $\mathbb{Q}[X=\hat{X}] \leq P_{\max}$ 得出，因为 $X \perp\!\!\!\perp \hat{X}$ 在 $\mathbb{Q}$ 下成立。（同样，我们参考例I.25 以获得直接证明。）□

前一个结果的以下推论强调了其在为统计和数据传输提供逆命题（或不可能性结果）方面的作用。

推论 3.13（平均错误概率的下界）*Let $W \to X \to Y \to \hat{W}$, where W is uniform on $[M] \triangleq \{1,\dots,M\}$. Then*

$$P_e \triangleq \mathbb{P}[W \neq \hat{W}] \geq 1 - \frac{I(X;Y) + h(P_e)}{\log M} \tag{3.20}$$

$$\geq 1 - \frac{I(X;Y) + \log 2}{\log M}\,. \tag{3.21}$$

Proof. 应用定理3.12和互信息数据处理：{v*}；{v*}；{v*}。

□

3.7* 高斯噪声中的估计误差（I-MMSE）

在上一节中，我们考虑基于观测 Y 估计离散随机变量 X，并展示了重建误差概率的界。这里我们考虑 $X \in \mathbb{R}^d$ 和二次损失的更一般情况，这在信号处理中也称为均方误差（MSE）。具体来说，当 $\mathbb{E}[\|X\|^2] < \infty$ 时，我们定义

$$\mathsf{mmse}(X|Y) \triangleq \mathbb{E}[\|X - \mathbb{E}[X|Y]\|^2]\,,$$

其中MMSE表示最小MSE（这源于给定Y时，X的最佳估计器正是$\mathbb{E}[X|Y]$这一事实）。就像Fano不等式一样，可以推导出关联$I(X、Y)$和$\mathsf{mmse}(X|Y)$的*inequalities*。例如，根据Tao不等式（见推论7.11），对于$X \in [-1,1]$的情形，很容易得到

$$0 \leq \mathrm{Var}(X) - \mathsf{mmse}(X|Y) \leq \frac{2}{\log e} I(X;Y)\,,$$

这表明由 Y 导致的 X 方差减少至多与其互信息成正比。（只需注意 $\mathbb{E}[|\,\mathbb{E}[X|Y] - \mathbb{E}[X]|^2] = \mathrm{Var}(X) - \mathsf{mmse}(X|Y)$）。

然而，本节并非讨论这类不等式。在此，我们展示一个关于特殊情况下的显著*equality*，当Y是受高斯噪声影响的X的观测时。作为应用，

我们将在练习I.66中推导*stochastic localization*这一恒等式，并在定理3.16中推导熵功率不等式。

定理 3.14 (I-MMSE [205]) *Let $X \in \mathbb{R}^d$ be independent of $Z \sim \mathcal{N}(0, I_d)$. If $\mathbb{E}[\|X\|^2] < \infty$ then for all $\gamma > 0$ we have*

$$\frac{d}{d\gamma} I(X; \sqrt{\gamma}X + Z) = \frac{\log e}{2} \mathsf{mmse}(X|\sqrt{\gamma}X + Z) \tag{3.22}$$

$$\frac{d^2}{d\gamma^2} I(X; \sqrt{\gamma}X + Z) = -\frac{\log e}{2} \mathbb{E}[\|\Sigma_\gamma(\sqrt{\gamma}X + Z)\|_{\mathrm{F}}^2], \tag{3.23}$$

where $\Sigma_\gamma(y) =$ 协方差$(X|\sqrt{\gamma}X + Z = y)$ and $\|\cdot\|_{\mathrm{F}}$ is the Frobenius norm of the matrix.

作为一个简单的例子，对于高斯 X，可以通过结合例3.3中的互信息和例28.1中的MMSE来验证(3.22)。

在证明定理3.14之前，我们先引入一些记号与初步结果。设$I \subset \mathbb{R}$为一个开区间，μ为定义在$\mathbb{R}^d$上的一个（正）测度，且K, L：$\mathbb{R}^d \times I \to \mathbb{R}$，满足以下条件：a) 对于所有$\theta \in I$，$\int K(x,\theta)\mu(dx)$存在；b) $\int_{\mathbb{R}^d} \mu(dx) \int_I d\theta |L(x,\theta)| < \infty$；c) $t \mapsto \int_{\mathbb{R}^d} \mu(dx) L(x,t)$连续，且d) 我们有

$$\frac{\partial}{\partial\theta} K(x,\theta) = L(x,\theta)$$

对于所有 x, θ。然后

$$\frac{\partial}{\partial\theta} \int_{\mathbb{R}^d} K(x,\theta)\, dx = \int_{\mathbb{R}^d} L(x,\theta)\, dx\,. \tag{3.24}$$

(要看到这一点，取 $\theta > \theta_0 \in I$ 并写出 $K(x,\theta) = K(x,\theta_0) + \int_{\theta_0}^{\theta} dt L(x,t)$。现在我们可以对 x 积分并交换积分顺序得到 $\int dx K(x,\theta) =$ 常数 $+ \int_{\theta_0}^{\theta} g(t)dt$，其中 $g(t) = \int dx L(x,t)$ 是连续的)。注意在有限区间 I 的情况下，条件 b) 和 c) 都由条件 e) 蕴含：对所有 $t \in I$，我们有 $|L(x,t)| \le \ell(x)$，且 ℓ 是 μ-可积的。

设 $\phi_a(x) = \frac{1}{(2\pi a)^{d/2}} e^{-\|x\|^2/(2a)}$ 为 $\mathcal{N}(0, aI_d)$ 的密度。假设 p 是某个概率分布，f 是一个函数，则我们用 $p * f(x) = \mathbb{E}_{X' \sim p}[f(x - X')]$ 表示，若 p 是密度，则它与通常的卷积一致。特别地，高斯卷积 $p * \phi_a$ 被称为带有 *mixing distribution* p 的 *Gaussian mixture*。对于任何微分算子 $D = \frac{\partial^k}{\partial x_{i_1} \cdots \partial x_{i_k}}$，我们有

$$D(p * \phi_a) = p * (D\phi_a)\,. \tag{3.25}$$

对于 $D = \frac{\partial}{\partial x_1}$，这由 (3.24) 通过取 $\mu = p$、$K(x,\theta) = \phi_a(y - x)$ 可得，其中 $y = (\theta, y_2, \ldots, y_d)$。$L(x,\theta)$ 的条件由 $D\phi_a$ 一致有界这一事实得出。一般 D 的情形由归纳法可得。

作为下一个应用，我们将展示

$$\frac{\partial}{\partial a} p * \phi_a(y) = p * (\frac{\partial}{\partial a}\phi_a)(y) = \frac{1}{2}\Delta(p * \phi_a)(y)\,, \tag{3.26}$$

其中 $\Delta f = \mathrm{tr}(\mathrm{Hess}\, f)$ 是拉普拉斯算子。注意，第二个等式由 (3.25) 以及容易验证的恒等式得出

$$\frac{\partial}{\partial a}\phi_a(x) = \frac{1}{2a^2}(\|x\|^2 - ad)\phi_a(x) = \frac{1}{2}\Delta\phi_a(x)\,.$$

因此，我们只需证明(3.26)中的第一个等式。为此，我们使用(3.24)式，取$\mu = p$、$K(x,a) = \phi_a(y-x)$和$L(x,a) = \frac{\partial}{\partial a}K(x,a)$。注意，根据之前的计算，我们有$\sup_x |\frac{\partial}{\partial a}\phi_a(x)| < \infty$，因此(3.24)的条件e)适用，所以(3.24)蕴含(3.26)。

下一个引理展示了高斯卷积的一个特殊性质（对数卷积的导数对应于条件矩）。

引理 3.15 *Let $Y = X + \sqrt{a}Z$, where $X \perp\!\!\!\perp Z$ and $X \sim p$ and $Z \sim \mathcal{N}(0, I_d)$. Then*

1 If $\mathbb{E}[\|X\|] < \infty$ we have

$$\nabla \ln(p * \phi_a)(y) = \frac{1}{a}(\mathbb{E}[X|Y=y] - y)\,. \tag{3.27}$$

and also

$$\|\nabla \ln p * \phi_a(x)\| \le \frac{3}{a}\|x\| + \frac{4}{a}\,\mathbb{E}[\|X\|]\,. \tag{3.28}$$

2 If $\mathbb{E}[\|X\|^2] < \infty$ we have

$$\mathrm{Hess}\,\ln(p * \phi_a)(y) = \frac{1}{a^2}\,\mathrm{Cov}[X|Y=y] - \frac{1}{a}I_d\,. \tag{3.29}$$

Proof. 请注意，由于 $Y \sim p * \phi_a$ 我们有

$$\begin{aligned}\mathbb{E}[X|Y=y] &= \frac{1}{p*\phi_a(y)}\int_{\mathbb{R}^d} xp(x)\phi_a(y-x)dx = \frac{1}{p*\phi_a(y)}\int_{\mathbb{R}^d}(y-x)p(y-x)\phi_a(x)dx \\ &\overset{\text{(a)}}{=} y + \frac{a}{p*\phi_a(y)}\int p(y-x)(\nabla\phi_a(x)) \overset{\text{(b)}}{=} y + \frac{a}{p*\phi_a(y)}\nabla\left(p*\phi_a(x)\right)\,,\end{aligned}$$

其中 (a) 由 $\nabla\phi_a(x) = -\frac{x}{a}\phi_a(x)$ 这一事实得出，(b) 由 (3.25) 得出。在注意到 $\frac{1}{p*\phi_a(y)}\nabla\left(p*\phi_a(x)\right) = \nabla \ln(p*\phi_a)(y)$ 后，(3.27) 的证明完成。技术估计 (3.28) 在 [344，命题 2] 中给出。

恒等式（3.29）的证明完全类似。 □

有了这些准备，我们就可以证明该定理了 。

Proof of Theorem 3.14. 为简化起见，在本证明中，我们使用自然对数来计算所有信息和熵，因此 log = ln。有了这些准备，我们可以证明 (3.22)。首先，令 $a = 1/\gamma$，并注意

$$I(X; \sqrt{\gamma}X + Z) = I(X; X + \sqrt{a}Z) = h(X + \sqrt{a}Z) - \frac{d}{2}\ln(2\pi e a)\,,$$

其中我们通过定理2.8计算了高斯分布的微分熵。因此，如果我们能证明，则证明完成。

$$\frac{d}{da}h(X+\sqrt{a}Z)=\frac{d}{2a}-\frac{1}{2a^2}\mathsf{mmse}(X|Y_a)\,, \tag{3.30}$$

其中我们定义了$Y_a=X+\sqrt{a}Z$。令X的规律为p。从概念上讲，计算只需几行:

$$\begin{aligned}
-\frac{d}{da}h(X+\sqrt{a}Z) &= \frac{d}{da}\int (p*\phi_a)(x)\ln(p*\phi_a)(x)dx \\
&\overset{\text{(a)}}{=} \int \frac{\partial}{\partial a}[(p*\phi_a)(x)\ln(p*\phi_a)(x)]dx \\
&\overset{\text{(b)}}{=} \frac{1}{2}\int (1+\ln p*\phi_a)\Delta(p*\phi_a)dx \\
&\overset{\text{(c)}}{=} \frac{1}{2}\int (p*\phi_a)\Delta(\ln p*\phi_a)dx \\
&\overset{\text{(d)}}{=} \frac{1}{2}\int (p*\phi_a)(y)(\frac{1}{a^2}\mathsf{mmse}(X|Y_a=y)-\frac{d}{a})dy\,,
\end{aligned}$$

其中 (a) 和 (c) 将需要技术性论证，而 (b) 仅是 (3.26)、(d) 则通过取 (3.29) 的迹得到。注意 (a) 只是微分与积分的交换，而 (c) 仅仅是拉普拉斯算子的“自伴性”。

我们继续论证（a）。我们将应用（3.24），其中 $\mu=\text{Leb}$，$I=(a_1,a_2)$ 为某有限区间，$K(x,a)=(p*\phi_a)(x)\ln(p*\phi_a)(x)$ 且

$$L(x,a)=\frac{\partial}{\partial a}K(x,a)=\frac{1}{2}(1+\ln(p*\phi_a)(x))(p*\Delta\phi_a)(x)\,,$$

其中我们再次使用了(3.26)。

对 (3.28) 式进行积分，我们得到

$$|\ln p*\phi_a(x)-\ln p*\phi_a(0)|\le\frac{3}{2a}\|x\|^2+\frac{4}{a}\|x\|\,\mathbb{E}[\|X\|]\,.$$

由于 $p*\phi_a(0)\le\phi_a(0)$，我们得到对于所有 $a\in(a_1,a_2)$，存在某个 $c>0$:

$$|\ln p*\phi_a(x)|\le c(1+\|x\|+\|x\|^2)\,. \tag{3.31}$$

从这个估计中我们注意到

$$K(x,a)\le c(1+\|x\|+\|x\|^2)(p*\phi_a)(x)\,.$$

右手边对 x 的积分就是 $c(1+\mathbb{E}[\|Y_a\|+\|Y_a\|^2])<\infty$，这证实了(3.24)中的条件a)。

接下来，我们注意到对于任何微分算子 D，我们有 $D\phi_a(x)=f(x)\phi_a(x)$，其中 f 是 x 中的某个多项式。由于对于 $a<a_2$，我们有 $\sup_x\frac{f(x)\phi_a(x)}{\phi_{a_2}(x)}<\infty$，因此对于某个常数 c' 以及所有 $a<a_2$ 和所有 x，我们有

$$|D(p*\phi_a)(x)|\le c'p*\phi_{a_2}(x)\,, \tag{3.32}$$

这里我们也使用了(3.25)。因此，对于$L(x,a)$，我们可以看到第一项由(3.31)界定，第二项由前一个展示界定，因此总体上

$$L(x,a) \le \frac{cc'}{2}|2+\|x\|+\|x\|^2|(p*\phi_{a_2})(x)\,.$$

由于右侧再次可积，我们看到(3.24)的条件e)适用，因此在步骤(a)中微分和$\int$的交换是有效的。

最后，我们认为步骤(c)是适用的。为此，我们首先证明一个辅助结果：如果u,v是两个单变量二次可微函数，满足a) $\int_{\mathbb{R}}|u''v|$和$\int_{\mathbb{R}}|v''u|$均有限且b) $\int|u'v'|<\infty$，那么

$$\int_{\mathbb{R}} u''v = \int_{\mathbb{R}} v''u\,. \tag{3.33}$$

实际上，由条件b)可知，必然存在一个序列$c_n \to +\infty$、$b_n \to -\infty$，使得$|u'(c_n)v'(c_n)|+|u'(b_n)v'(b_n)|\to$为0。另一方面，根据条件a)，我们有

$$\lim_{n\to\infty}\int_{b_n}^{c_n} u''v = \int_{\mathbb{R}} u''v\,,$$

同样地，对于$\int v''u$。现在应用分部积分法，我们得到

$$\int_{b_n}^{c_n} u''v = u'(c_n)v'(c_n) - u'(b_n)v'(b_n) + \int_{b_n}^{c_n} v''u\,,$$

并且前两项随n消失。

接下来，考虑多元二次可微函数 U、V，其中 a) $\int_{\mathbb{R}^d}|V\frac{\partial^2}{\partial x_i^2}U|$ 和 $\int_{\mathbb{R}^d}|U\frac{\partial^2}{\partial x^2}$

$_i$ $V|$ 既是有限的，也是 b) $\int_{\mathbb{R}^d}\|\nabla U\|\,\|\nabla V\|<\infty$ 然后

$$\int_{\mathbb{R}^d} V\Delta U = \int_{\mathbb{R}^d} U\Delta V\,. \tag{3.34}$$

我们将最后 $(d-1)$ 个坐标分组，记作 $x=(x_1,x_2^d)$。固定 x_2^d，并定义 $u(x_1)=U(x_1,x_2,\cdots,x_d)$ 和 $v(x_1)=V(x_1,x_2,\cdots,x_d)$。对于勒贝格几乎处处 x_2^d，我们看到 u,v 满足 (3.33) 的条件。因此，对于这样的 x_2^d，我们得到

$$\int_{\mathbb{R}} V(x)\frac{\partial^2}{\partial x_1^2}U(x)\,dx_1 = \int_{\mathbb{R}} U(x)\frac{\partial^2}{\partial x_1^2}V(x)\,dx_1\,.$$

将其在x_2^d上积分，我们得到

$$\int_{\mathbb{R}^d} V(x)\frac{\partial^2}{\partial x_1^2}U(x)\,dx = \int_{\mathbb{R}^d} U(x)\frac{\partial^2}{\partial x_1^2}V(x)\,dx\,.$$

现在，为了证明步骤(c)，我们必须验证 $U(x)=1+\ln(p*\phi_a)(x)$ 和 $V(x)=p*\phi_a(x)$ 满足前一个结果的条件。为此，请注意从(3.29)我们有 $|\frac{\partial^2}{\partial y_i^2}U(y)|\le\frac{1}{a^2}\,\mathbb{E}[X_i^2|Y_a=y]+\frac{1}{a}$，因此

$$\int_{\mathbb{R}^d}|V\frac{\partial^2}{\partial x_i^2}U| = O_a(\mathbb{E}[X_i^2])<\infty\,.$$

另一方面，由(3.25)和(3.32)我们得到$|\frac{\partial^2}{\partial y_i^2}V(y)| \le c'p * \phi_{a_2}(y)$。再由(3.31)我们得到

$$\int_{\mathbb{R}^d} |U\frac{\partial^2}{\partial x_i^2}V| \le cc' \int (1+\|x\|+\|x\|^2)p * \phi_{a_2}(x) = cc'\,\mathbb{E}[1+\|Y_{a_2}\|+\|Y_{a_2}\|^2] < \infty\,.$$

最后，为了展示 $\int_{\mathbb{R}^d} \|\nabla U\|\|\nabla V\| < \infty$，我们应用 (3.28) 来估计 $\|\nabla U\| \lesssim_a 1+\|y\|$，并使用 (3.32) 来估计 $\|\nabla V\| \lesssim_a p * \phi_{a_2}(x)$。因此，我们有

$$\int_{\mathbb{R}^d} \|\nabla U\|\|\nabla V\| \lesssim_a \mathbb{E}[1+\|Y_{a_2}\|] < \infty\,.$$

这完成了条件的验证，我们得出结论 $\int U\Delta V = \int V\Delta U$ 符合步骤 (c) 的要求。

恒等式 (3.23) 是通过使用非常相似的方法对函数 $\gamma \mapsto \mathsf{mmse}(X|\sqrt{\gamma}+Z)$ 进行微分得到的。关于完整的证明，我们参考 [206]。 □

注 3.7（I-MMSE 的张量化）我们直接证明了 d 维向量的 I-MMSE 恒等式。然而，事实证明一维版本蕴含了 d 维版本。具体而言，假设 (3.22) 的 1D 版本已被证明。我们按 (3.22) 中那样记 $X = (X_1,\dots,X_d)$、$Y = (Y_1,\dots,Y_d)$、$Z = (Z_1,\dots,Z_d)$。但现在令 $\underline{\gamma} = (\gamma_1,\dots,\gamma_d)$ 为一个向量，并令 $Y_j = \sqrt{\gamma_j}X_j + Z_j$。我们感兴趣的是计算 $I(X;Y)$ 沿对角线 $\underline{\gamma} = (\gamma,\dots,\gamma)$ 的导数。为此，记 $Y_{\sim j} = \{Y_i\colon i \ne j\}$，并注意根据链式法则我们有

$$\frac{\partial}{\partial\gamma_j} I(X;Y) = \frac{\partial}{\partial\gamma_j} I(X_j;Y_j|Y_{\sim j})\,. \tag{3.35}$$

同样，注意 $\mathbb{E}_{y_{\sim j}\sim P_{Y_{\sim j}}}[\mathsf{mmse}(X_j|Y_j, Y_{\sim j}=y_{\sim j})] = \mathsf{mmse}(X_j|Y)$。因此，应用 (3.22) 的 1$D$-版本，我们得到

$$\frac{\partial}{\partial\gamma_j} I(X;Y) = \frac{\log e}{2}\mathsf{mmse}(X_j|Y)\,.$$

现在，通过对 j 求和 (3.35) 式，我们得到了 (3.22) 式的 d 维版本。注意，我们通过引入向量参数 $\underline{\gamma}$ 并利用链式法则简化偏导数，从而计算了标量参数 γ 的导数。这一思想是信息论中 *area theorem* 的基础 [360, Lemma 3] 以及统计物理中 *Guerra interpolation* 的基础 [410]。

3.8* 熵-功率不等式

作为上一节结果的应用，我们展示了 $\mathbb{R}^n$ 的加法结构与熵之间的一个重要关系。为了陈述这一结果，回顾由（2.18），一个具有功率 σ^2 的坐标的独立同分布高斯向量 Z^d 具有微分熵 $h(Z^d) = \frac{d}{2}\log(2\pi e\sigma^2)$。相应地，

对于任何取值于 $\mathbb{R}^d$ 的随机变量 X，我们定义其 *entropy power* 为

$$N(X) \triangleq \frac{1}{2\pi e}\exp\{\frac{2}{d}h(X)\}\,.$$

请注意，根据定理2.8，在二阶矩约束下，熵功率由独立同分布的高斯向量最大化。因此，我们接下来证明的结果可以解释为一个陈述，即*convolution increases Gaussianity*。[4]该结果由香农提出猜想，并由斯坦证明。

定理 3.16（熵功率不等式（EPI）[399]）*Suppose $A_1 \perp\!\!\!\perp A_2$ are independent $\mathbb{R}^d$-valued random variables with finite second moments $\mathbb{E}[\|A_i\|^2] < \infty$, $i \in \{1, 2\}$. Then*

$$N(A_1 + A_2) \geq N(A_1) + N(A_2)\,.$$

备注 3.8 (Costa 的 EPI) 考虑 $A_2 = \sqrt{a}Z, Z \sim \mathcal{N}(0, I_d)$ 的情形。此时 EPI 等价于 $\frac{d}{da}N(A_1+\sqrt{a}Z) \geq 1$ 这一陈述。对于这一特殊情形，Costa [100] 建立了一个更强的性质，即 $a \mapsto N(A_1 + \sqrt{a}Z)$ 是凹的。针对这一情形，[103] 中提出了以 F_I-曲线（参见定义 16.5）表述的进一步改进。

Proof. 我们给出[437]的一个优雅证明。首先，Lieb[280]的一个观察表明，EPI等价于证明：对于所有$U_1 \perp\!\!\!\perp U_2$和$\alpha \in\in [0, 2\pi)$，我们有

$$h(U_1\cos\alpha + U_2\sin\alpha) \geq h(U_1)\cos^2\alpha + h(U_2)\sin^2(\alpha)\,. \tag{3.36}$$

(要看出（3.36)蕴含EPI，只需取$\cos^2\alpha = \frac{N(A_1)}{N(A_1)+N(A_2)}$和$U_1 = A_1/\cos\alpha$，$U_2 = A_2/\sin\alpha$。)

接下来，我们断言，证明一般 U_i 的 (3.36) 等价于证明其“平滑”版本的 (3.36)，即 $\tilde{U}_i = U_i + \sqrt{\epsilon}Z_i$，其中 $Z_i \sim \mathcal{N}(0, I_d)$ 独立于 U_1, U_2。事实上，这一技术连续性结果可由例如 [344, 命题1] 得出，该命题表明，只要 $\mathbb{E}[\|U_i\|^2] < \infty$，则函数 $\epsilon \mapsto h(U_i + \sqrt{\epsilon}Z_i)$ 连续，并且实际上当 $\epsilon \to 0$ 时 $h(U_i + \sqrt{\epsilon}Z) = h(U_i) + O(\sqrt{\epsilon})$。

换句话说，为了证明Lieb的EPI，只需对所有$\epsilon > 0$进行证明即可。

$$h(X + \sqrt{\epsilon}Z) \geq h(U_1 + \sqrt{\epsilon}Z_1)\cos^2\alpha + h(U_2 + \sqrt{\epsilon}Z_2)\sin^2(\alpha)\,,$$

其中我们还定义了 $X \triangleq U_1\cos\alpha + U_2\sin\alpha, Z \triangleq Z_1\cos\alpha + Z_2\sin\alpha$。由于上述不等式具有尺度不变性，因此我们可以等价地对所有 $\gamma \geq 0$ 证明以下内容：

$$h(\sqrt{\gamma}X + Z) \geq h(\sqrt{\gamma}U_1 + Z_1)\cos^2\alpha + h(\sqrt{\gamma}U_2 + Z_2)\sin^2(\alpha)\,.$$

[4] Another deep manifestation of this phenomenon is in the context of CLT. Barron's *entropic CLT* states that for iid X_i's with zero mean and unit variance, the KL divergence $D(\frac{X_1+\ldots+X_n}{\sqrt{n}}\|\mathcal{N}(0,1))$, whenever finite, converges to zero. This convergence is in fact monotonic as shown in [27, 102].

作为最后的简化，我们用互信息替换微分熵。即，如果我们证明

$$I(X;\sqrt{\gamma}X+Z)\geq I(U_1;\sqrt{\gamma}U_1+Z_1)\cos^2\alpha+I(U_2;\sqrt{\gamma}U_2+Z_2)\sin^2(\alpha)\,.$$

最后这个不等式对于$\gamma=0$显然成立。因此，只需证明两边关于γ的导数满足相同的不等式，然后从0到γ积分即可。通过(3.22)计算导数，我们需要证明

$$\mathsf{mmse}(X|\sqrt{\gamma}X+Z)\geq\mathsf{mmse}(U_1|\sqrt{\gamma}U_1+Z_1)\cos^2\alpha+\mathsf{mmse}(U_2|\sqrt{\gamma}U_2+Z_2)\sin^2(\alpha)\,.$$

但后一个不等式非常容易论证，因为显然 ly

$$\mathsf{mmse}(X|\sqrt{\gamma}X+Z)\geq\mathsf{mmse}(X|\sqrt{\gamma}U_1+Z_1,\sqrt{\gamma}U_2+Z_2)\,.$$

另一方面，对于右侧，X 是两个条件独立项的和，因此

$$\mathsf{mmse}(X|\sqrt{\gamma}U_1+Z_1,\sqrt{\gamma}U_2+Z_2)=\mathsf{mmse}(U_1|\sqrt{\gamma}U_1+Z_1)\cos^2\alpha+\mathsf{mmse}(U_2|\sqrt{\gamma}U_2+Z_2)\sin^2(\alpha)\,.$$

□

在推论2.9中，我们已经看到了如何将微分熵的性质转换为正定矩阵的性质。这里是另一个应用：

推论 3.17（闵可夫斯基不等式）*Let Σ_1,Σ_2 be real positive definite $n\times n$ matrices. Then*

$$\det(\Sigma_1+\Sigma_2)^{\frac{1}{n}}\geq\det(\Sigma_1)^{\frac{1}{n}}+\det(\Sigma_2)^{\frac{1}{n}}\,.$$

Proof. 取 $A_i\sim\mathcal{N}(0,\Sigma_i)$，使用 (2.18) 和 EPI。 □

EPI是许多信息论论证的基石：例如，它被用来确立高斯广播信道的容量区域[45]。然而，其重要性遍及几何学和分析学，对高维概率、凸几何和测度集中有着深远的影响。作为一个例子，参见练习I.65，它推导了Gross的*log-Sobolev inequality*。进一步的讨论超出了本书的范围，但我们建议阅读[106，第16章]。

4 信息度量的变分特征与连续性

在本章中，我们汇集了一些关于信息测度的变分刻画的结果。在分析中，通过证明形如 $F(x) = \sup_{\lambda\in\Lambda} f_\lambda(x)$ 或 $F(x) = \inf_{\mu\in M} g_\mu(x)$ 的变分刻画来研究泛函是一种众所周知的方法。这样的表示对于多种目的都可能有用：

• 凸性：凸函数的逐点上确界是凸的。• 正则性：下半连续（lsc）函数的逐点上确界是下半连续的。• 边界：通过选择任意 λ (μ) 并计算 f_λ (g_μ)，可得到 F 的上界/下界。

我们将在本章中看到，散度有两种不同的上确界特征描述（针对划分和针对函数）。互信息更为特殊。除了继承自KL散度的特征外，它还具有两个额外的特性：一个是关于（质心）测度Q_Y的下确界表示，另一个是关于马尔可夫核的上确界表示。

作为这些变分刻画的应用，我们讨论*Gibbs variational prin- ciple*，它作为机器学习中许多现代算法的基础，包括*EM algorithm*和*variational autoencoders*；见第4.4节。机器学习中的一个重要理论构造是PAC-贝叶斯界（第4.8*节）的思想。

从信息论的角度来看，变分刻画之所以重要，是因为它们解决了连续性问题。在本章中，我们将讨论几种类型的连续性。首先是离散化中的连续性。这与*computation*问题相关。对于复杂的P和Q，直接计算$D(P\|Q)$可能很困难。相反，人们可能希望离散化无限字母表并以数值方式计算有限和。这种近似是否有效，即随着量化变得更精细，所得的有限和是否保证收敛到$D(P\|Q)$的真实值？答案是肯定的，这种关于离散化的连续性正是定理4.5的内容。

其次，是分布变化下的连续性。例如，这出现在*estimating information measures*的问题中。在许多统计设置中，我们往往不知道P或Q，并且我们通过$\hat{P}_n$使用从P (独立同分布采样得到的n个观测值来估计分布，在离散情况下，我们可以简单地将$\hat{P}_n$设为经验分布)。$D(\hat{P}_n\|Q)$是否为$D(P\|Q)$提供了一个好的估计量？如果$\hat{P}_n \to P$，$D(\hat{P}_n\|Q) \to D(P\|Q)$是否成立？答案很微妙——见第4.5节。

第三，还有另一种连续性：即“σ代数中的”连续性。尽管名字听起来吓人，但在最“离散”的情形下它也很有用。例如，假设$\theta \sim$

Unif(0, 1) 和 $X_i \overset{\text{i.i.d.}}{\sim} \text{Ber}(\theta)$。假设你观察一系列$X_i$，直到随机时刻$\tau$等于模式0101的首次出现。到时刻$\tau$为止，你获得了关于$\theta$的多少信息？我们可以将这些观察编码为

$$Z_j = \begin{cases} X_j, & j \le \tau \\ ?, & j > \tau \end{cases},$$

其中 ? 表示我们不知道那些时刻的 X_j 值。那么，我们上面提出的问题就是计算 $I(\theta;\ Z^\infty)$。我们将在本章中证明

$$I(\theta; Z^\infty) = \lim_{n\to\infty} I(\theta; Z^n) = \sum_{n=1}^{\infty} I(\theta; Z_n | Z^{n-1}) \tag{4.1}$$

因此，将计算简化为评估一个由更简单项（不涉及无限维向量）组成的无穷级数。这样一来，即便是在这个关于偏斜硬币投掷的简单问题中，我们也必须理解如何安全地处理无限维向量。

4.1 互信息的几何解释

互信息（MI）可以被理解为从条件分布到边缘分布的一种加权“距离”。实际上，对于离散的 X 我们可得

$$I(X;Y) = D(P_{Y|X}\|P_Y|P_X) = \sum_{x\in\mathcal{X}} D(P_{Y|X=x}\|P_Y)P_X(x).$$

此外，事实证明，P_Y与重心类似，能够最小化这种加权距离，因此可以被视为分布集合$\{P_{Y|X=x}\colon\ x \in \mathcal{X}\}$的“中心”的最佳近似，其中权重由$P_X$给出。我们在本节中形式化这些结果，并从“黄金公式”的证明开始。其重要性在于架起了互信息的两种视角之间的桥梁。回顾一下，一方面我们有Fano的定义3.1，另一方面对于离散情况，我们有Shannon的定义（3.3）作为熵的差。接下来的结果（4.3）以Shannon的风格将MI呈现为*relative*熵的差，同时保持以Fano的风格适用于连续空间。

定理4.1（黄金公式） *For any Q_Y we have*

$$D(P_{Y|X}\|Q_Y|P_X) = I(X;Y) + D(P_Y\|Q_Y). \tag{4.2}$$

Thus, if $D(P_Y\|Q_Y) < \infty$, then

$$I(X;Y) = D(P_{Y|X}\|Q_Y|P_X) - D(P_Y\|Q_Y). \tag{4.3}$$

Proof. 在离散情况下，且忽略除以零的可能性，论证其实非常简单。我们只需写出：

$$I(X;Y) \overset{(3.1)}{=} \mathbb{E}_{P_{X,Y}}\left[\log\frac{P_{Y|X}}{P_Y}\right] = \mathbb{E}_{P_{X,Y}}\left[\log\frac{P_{Y|X}Q_Y}{P_YQ_Y}\right]$$

然后展开 $\log \frac{P_{Y|X}Q_Y}{P_Y Q_Y} = \log \frac{P_{Y|X}}{Q_Y} - \log \frac{P_Y}{Q_Y}$。下面的论证是这一思想的严格实现。

首先，注意根据定理2.16(e)，我们有$D(P_{Y|X}\|Q_Y|P_X) \geq D(P_Y\|Q_Y)$，因此如果$D(P_Y\|Q_Y) = \infty$，那么(4.2)的两边都是无穷大。于是，我们假设$D(P_Y\|Q_Y) < \infty$，特别地$P_Y \ll Q_Y$。通过链式法则(2.24)重写(4.2)的左边，我们看到该定理等价于证明

$$D(P_{X,Y}\|P_X Q_Y) = D(P_{X,Y}\|P_X P_Y) + D(P_Y\|Q_Y)\,.$$

$D(P_{X,Y}\|P_X Q_Y) = D(P_{X,Y}\|P_X P_Y) = \infty$的情况是明确的。因此，我们可以假设这些发散中至少有一个是有限的，从而$P_{X,Y} \ll P_X Q_Y$也是有限的。

令 $\lambda(y) = \frac{dP_Y}{dQ_Y}(y)$。由于 $\lambda(Y) > 0$ P_Y-几乎必然，应用 (2.10) 中对数的定义，我们可以写出

$$\mathbb{E}_{P_Y}[\log \lambda(Y)] = \mathbb{E}_{P_{X,Y}}\left[\mathrm{Log}\frac{\lambda(Y)}{1}\right]\,. \tag{4.4}$$

注意，相同的 $\lambda(y)$ 也是乘积测度 $P_X P_Y$ 相对于 $P_X Q_Y$ 的密度 $\frac{dP_X P_Y}{dP_X Q_Y}(x,y)$。因此，根据 (2.11) 应用于 $\mu = P_X Q_Y$ 时，(4.4) 的右侧等于

$$D(P_{X,Y}\|P_X Q_Y) - D(P_{X,Y}\|P_X P_Y)\,,$$

而 {v*} 的左侧 (4.4) 由 (2.13) 等于 $D(P_Y\|Q_Y)$。因此，我们已经展示了 r所需

$$D(P_Y\|Q_Y) = D(P_{X,Y}\|P_X Q_Y) - D(P_{X,Y}\|P_X P_Y)\,.$$

□

通过舍弃(4.2)中的第二项，我们得到以下结果。

推论 4.2（互信息作为重心）*For any Q_Y we have*

$$I(X;Y) \leq D(P_{Y|X}\|Q_Y|P_X)$$

and, consequently,

$$I(X;Y) = \min_{Q_Y} D(P_{Y|X}\|Q_Y|P_X). \tag{4.5}$$

If $I(X;Y) < \infty$, the unique minimizer is $Q_Y = P_Y$.

备注 4.1 变分表示 (4.5) 对于通过选择合适的 Q_Y 来上界互信息是有用的。实际上，集合 $P_{Y|X=x}$ 中的每个分布通常都很简单，但它们的混合 P_Y 却很难处理。在这些情况下，在 (4.5) 中选择一个合适的 Q_Y 提供了一个方便的上界。作为例子，考虑例 3.3 中的 AWGN 信道 $Y = X+Z$，其中 $\mathrm{Var}(X) = \sigma^2$，$Z \sim \mathcal{N}(0,1)$。然后，选择最佳可能的高斯 Q 并应用上述界，我们有：

$$I(X;Y) \leq \inf_{\mu\in\mathbb{R},s\geq 0} \mathbb{E}[D(\mathcal{N}(X,1)\|\mathcal{N}(\mu,s))] = \frac{1}{2}\log(1+\sigma^2),$$

当X为高斯分布时，该不等式是紧致的。更多示例及统计应用，请参见第30章。

定理4.3（互信息作为与乘积分布的距离）

$$I(X;Y) = \min_{Q_X,Q_Y} D(P_{X,Y}\|Q_XQ_Y)$$

with the unique minimizer $(Q_X, Q_Y) = (P_X, P_Y)$.

Proof. 我们只需要使用前面的推论和链式法则 (2.24)：

$$D(P_{X,Y}\|Q_XQ_Y) \overset{(2.24)}{=} D(P_{Y|X}\|Q_Y|P_X) + D(P_X\|Q_X) \geq I(X;Y)\,.$$

□

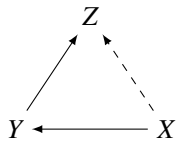
有趣的是，前一个结果中的观点可以按如下方式扩展到条件互信息：我们有

$$I(X;Z|Y) = \min_{Q_{X,Y,Z}:X\to Y\to Z} D(P_{X,Y,Z}\|Q_{X,Y,Z})\,, \tag{4.6}$$

其中最小化是在所有 $Q_{X,Y,Z} = Q_XQ_{Y|X}Q_{Z|Y}$ 上进行的，参见第3.4节。展示这一刻画与上一个定理非常相似。通过重复(4.2)中的相同论证，我们得到

$$\begin{aligned}
&D(P_{X,Y,Z}\|Q_XQ_{Y|X}Q_{Z|Y})\\
=&D(P_{X,Y,Z}\|P_XP_{Y|X}P_{Z|Y}) + D(P_X\|Q_X) + D(P_{Y|X}\|Q_{Y|X}|P_X) + D(P_{Z|Y}\|Q_{Z|Y}|P_Y)\\
=&D(P_{X,Y,Z}\|P_YP_{X|Y}P_{Z|Y}) + D(P_X\|Q_X) + D(P_{Y|X}\|Q_{Y|X}|P_X) + D(P_{Z|Y}\|Q_{Z|Y}|P_Y)\\
=&\underbrace{D(P_{XZ|Y}\|P_{X|Y}P_{Z|Y}|P_Y)}_{I(X;Z|Y)} + D(P_X\|Q_X) + D(P_{Y|X}\|Q_{Y|X}|P_X) + D(P_{Z|Y}\|Q_{Z|Y}|P_Y)\\
\geq&I(X;Z|Y)\,.
\end{aligned}$$

表征（4.6）可以如下理解。对于三元组（X, Y, Z）而言，最一般的定向图模型是一个3团（三角形）。



虚线边 $X \to Z$ 上的信息流是什么？要回答这个问题，注意移除这条边会将联合分布限制为马尔可夫链 $X \to Y \to Z$。因此，自然会问给定 $P_{X,Y,Z}$ 与满足马尔可夫链约束的所有分布 $Q_{X,Y,Z}$ 的集合之间的最小（KL散度）距离是多少。根据上述计算，最优 $Q_{X,Y,Z} = P_YP_{X|Y}P_{Z|Y}$ 以及因此的距离是 $I(X;\ Z|Y)$。因此，我们可以将 $I(X;\ Z|Y)$ 解释为通过 $X \to Z$ 边的信息量。

除了inf-特征化之外，互信息还具有sup-特征化。

定理 4.4 *For any Markov kernel $Q_{X|Y}$ such that $Q_{X|Y=y} \ll P_X$ for P_Y-a.e. y we have*

$$I(X;Y) \geq \mathbb{E}_{P_{X,Y}}\left[\log \frac{dQ_{X|Y}}{dP_X}\right].$$

If $I(X;Y) < \infty$ then

$$I(X;Y) = \sup_{Q_{X|Y}} \mathbb{E}_{P_{X,Y}}\left[\log \frac{dQ_{X|Y}}{dP_X}\right], \tag{4.7}$$

where the supremum is over Markov kernels $Q_{X|Y}$ as in the first sentence.

注4.2 类似于使用(4.5)来上界$I(X;Y)$这个结果被用来下界$I(X;Y)$：通过选择对P_Y的良好近似，通过选取一个通常对非常复杂的后验$P_{X|Y}$的良好（但可计算的）近似$Q_{X|Y}$。应用参见第5.6节。

Proof. 由于在可忽略的 y 集合上修改 $Q_{X|Y=y}$ 不会改变期望，我们将假设对于每个 y 有 $Q_{X|Y=y} \ll P_Y$。如果 $I(X;Y) = \infty$ 则无需证明。因此我们假设 $I(X;Y) < \infty$，这意味着 $P_{X,Y} \ll P_X P_Y$。然后根据引理3.3，对于几乎所有的 y，我们有 $P_{X|Y=y} \ll P_X$。选择任一这样的 y，并应用（2.11），其中 $\mu = P_X$，注意到 $\text{Log}\frac{dQ_{X|Y=y}/dP_X}{1} = \log\frac{dQ_{X|Y=y}}{dP_X}$，我们得到

$$\mathbb{E}_{P_{X|Y=y}}\left[\log \frac{dQ_{X|Y=y}}{dP_X}\right] = D(P_{X|Y=y}\|P_X) - D(P_{X|Y=y}\|Q_{X|Y=y}),$$

由于第一项对于几乎处处的 y 由 (3.1) 是有限的，因此适用。对前一恒等式关于 y 取期望，我们得到

$$\mathbb{E}_{P_{X,Y}}\left[\log \frac{dQ_{X|Y}}{dP_X}\right] = I(X;Y) - D(P_{X|Y}\|Q_{X|Y}|P_Y) \leq I(X;Y), \tag{4.8}$$

暗示第一部分。(4.7) 中的等号情况通过取 $Q_{X|Y} = P_{X|Y}$ 得到，当 $I(X;Y) < \infty$ 时，$Q_{X|Y} = P_{X|Y}$ 满足 Q 上的条件。 □

4.2 散度的变分特性：Gelfand-Yaglom-Perez

以下定理的要点在于，一般字母表上的散度可以通过有限字母表上的散度和离散化来定义。此外，随着量化变得更精细，我们逼近散度的值。

定理4.5（Gelfand-Yaglom-Perez [182]）*Let P, Q be two probability measures on $\mathcal{X}$ with σ-algebra $\mathcal{F}$. Then*

$$D(P\|Q) = \sup_{\{E_1,\ldots,E_n\}} \sum_{i=1}^{n} P[E_i] \log \frac{P[E_i]}{Q[E_i]}, \tag{4.9}$$

where the supremum is over all finite $\mathcal{F}$-measurable partitions: $\bigcup_{j=1}^{n} E_j = \mathcal{X}, E_j \cap E_i = \emptyset$, and 0 日志 $\frac{1}{0} = 0$ and 日志 $\frac{1}{0} = \infty$ per our usual convention.

注4.3 特别地，该定理允许我们先证明离散随机变量情形下的所有一般恒等式和不等式，然后取极限。在互信息 $I(X;\ Y) = D(P_{X,Y}\|P_XP_Y)$ 的情况下，$\mathcal{X}$ 和 $\mathcal{Y}$ 的分割可以分别选择，参见（4.29）。

Proof. “$\geq$”：固定一个有限划分 $E_1,\dots E_n$。定义一个函数（量化器）f: $\mathcal{X}\to\{1,\dots,n\}$ 如下：对于任意 x，令 $f(x)$ 表示 x 所属集合 E_j 的索引 j。令 X 根据 P 或 Q 分布，并设置 $Y=f(X)$。对散度应用数据处理不等式可得

$$\begin{aligned} D(P\|Q) &= D(P_X\|Q_X) \\ &\geq D(P_Y\|Q_Y) \\ &= \sum_i P(E_i)\log\frac{P(E_i)}{Q(E_i)}\,. \end{aligned} \tag{4.10}$$

“$\leq$”：为了表明 $D(P\|Q)$ 确实可达，首先注意到如果 $P\not\ll Q$，那么根据定义，存在 B 使得 $Q(B)=0<P(B)$。选择划分 $E_1=B$ 和 $E_2=B^{\rm c}$，我们有 $D(P\|Q)=\infty=\sum_{i=1}^2 P[E_i]\log\frac{P[E_i]}{Q[E_i]}$。在后续中，我们假设 $P\ll Q$ 并令 $X=\frac{dP}{dQ}$。那么由（2.4），$D(P\|Q)=\mathbb{E}_Q[X\log X]=\mathbb{E}_Q[\varphi(X)]$。注意 $\varphi(x)\geq 0$ 当且仅当 $x\geq 1$。根据单调收敛定理，我们有 $\mathbb{E}_Q[\varphi(X)1\{X<c\}]\to D(P\|Q)$ 当 $c\to\infty$，无论 $D(P\|Q)$ 的有限性如何。

接下来，我们构造一个有限划分。设$n=c/\epsilon$为整数，且对于 $j=0,\dots,n-1$，令 $E_j=\{j\epsilon\leq X\leq(j+1)\epsilon\}$ 和 $E_n=\{X\geq c\}$。定义 $Y=\epsilon\lfloor X/\epsilon\rfloor$ 为量化版本。由于 φ 在 $[0,c]$ 上一致连续，对于任意 $x,y\in[0,c]$ 使得 $|x-y|\leq\epsilon$，我们有 $|\varphi(x)-\varphi(y)|\leq\epsilon'$ 对于某个 $\epsilon'=\epsilon'(\epsilon,c)$ 如 $\epsilon'\to 0$ 当 $\epsilon\to 0$ 时。那么 $\mathbb{E}_Q[\varphi(Y)1\{X<c\}]\geq\mathbb{E}_Q[\varphi(X)1\{X<c\}]-\epsilon'$。此外，

$$\begin{aligned} \mathbb{E}_Q[\varphi(Y)1\{X<c\}] &= \sum_{j=0}^{n-1}\varphi(j\epsilon)Q(E_j)\leq\epsilon'+\sum_{j=0}^{n-1}\varphi\left(\frac{P(E_j)}{Q(E_j)}\right)Q(E_j) \\ &\leq \epsilon'+Q(X\geq c)\log e+\sum_{j=0}^{n}P(E_j)\log\frac{P(E_j)}{Q(E_j)}, \end{aligned}$$

其中第一个不等式应用了 φ 的一致连续性，因为 $j\epsilon\leq\frac{P(E_j)}{Q(E_j)}<(j+1)\epsilon$，第二个应用了 $\varphi\geq-\log e$。由于当 $c\to\infty$ 时 $Q(X\geq c)\to$ 趋于 0，证明通过先令 $\epsilon\to$ 趋于 0，然后 $c\to\infty$ 来完成。 □

4.3 散度的变分特征：Donsker-Varadhan

以下是散度最重要的变分刻画。我们提醒约定$\exp\{-\infty\}=0$，$\log 0=-\infty$。

定理 4.6（Donsker-Varadhan [134]）*Let P, Q be probability measures on $\mathcal{X}$ and denote a class of functions $\mathcal{C}_Q = \{f\colon\ \mathcal{X} \to \mathbb{R} \cup \{-\infty\}\colon\ 0 < \mathbb{E}_Q[\exp\{f(X)\}] < \infty\}$. Then*

$$D(P\|Q) = \sup_{f \in \mathcal{C}_Q} \mathbb{E}_P[f(X)] - \log \mathbb{E}_Q[\exp\{f(X)\}] \tag{4.11}$$

In particular, if $D(P\|Q) < \infty$ then $\mathbb{E}_P[f(X)]$ is well-defined and $< \infty$ for every $f \in \mathcal{C}_Q$. The identity (4.11) *holds with $\mathcal{C}_Q$ replaced by the class of all $\mathbb{R}$-valued simple functions. If $\mathcal{X}$ is a normal topological space (e.g., a metric space) with the Borel σ-algebra, then also*

$$D(P\|Q) = \sup_{f \in \mathcal{C}_b} \mathbb{E}_P[f(X)] - \log \mathbb{E}_Q[\exp\{f(X)\}]\,, \tag{4.12}$$

where $\mathcal{C}_b$ is the class of all bounded continuous functions.

Proof. “$D \geq \sup_{f \in \mathcal{C}_Q}$”：对于这部分，我们可以假设 $D(P\|Q) < \infty$，否则无需证明。然后固定 $f \in \mathcal{C}_Q$，并定义 Q) 上的一个概率测度 Q^f (*tilted version*，通过

$$Q^f(dx) = \exp\{f(x) - \psi_f\} Q(dx)\,, \qquad \psi_f \triangleq \log \mathbb{E}_Q[\exp\{f(X)\}]\,. \tag{4.13}$$

然后，$Q^f \ll Q$。接下来我们将以参考测度 $\mu = Q$ 应用 (2.11)。注意根据 (2.10)，即使当 $f(x) = -\infty$ 时，我们总有 $\mathrm{Log}\frac{\exp\{f(x)-\psi_f\}}{1} = f(x) - \psi_f$。因此，由 (2.11) 我们得到

$$\mathbb{E}_P[f(X)] - \psi_f = \mathbb{E}_P\left[\mathrm{Log}\frac{dQ^f/dQ}{1}\right] = D(P\|Q) - D(P\|Q^f) \leq D(P\|Q)\,.$$

请注意，(2.11) 也意味着如果 $D(P\|Q) < \infty$ 和 $f \in \mathcal{C}_Q$，期望 $\mathbb{E}_P[f]$ 是明确定义的。

“$D \leq \sup_f$” 对所有简单函数取上确界：思路是直接取 $f = \log \frac{dP}{dQ}$；然而为处理所有情况，我们更谨慎地进行。首先，注意到若 $P \not\ll Q$，则对某个 E 有 $Q[E] = 0 < P[E]$ 且 $c \to \infty$ 取 $f = c1_E$ 表明 (4.11) 两边均为无穷大。因此，我们假设 $P \ll Q$。对 $\mathcal{X} = \cup_{j=1}^n E_j$ 的任意分割，我们令 $f = \sum_{j=1}^n 1_{E_j} \log \frac{P[E_j]}{Q[E_j]}$。于是 (4.11) 与 (4.9) 的右边计算得到相同的值，从而由定理 4.5 可得，对简单函数（因而对 $\mathcal{C}_Q$）的上确界至少与 $D(P\|Q)$ 一样大。

最后，为了证明(4.12)，我们证明对于每一个简单函数 f，存在一个连续有界的 f'，使得 $\mathbb{E}_P[f'] - \log \mathbb{E}_Q[\exp\{f'\}]$ 任意接近在 f 处计算的同一泛函。为此，我们首先证明对于任意 $a \in \mathbb{R}$ 和可测的 $A \subset \mathcal{X}$，存在一个连续有界 f_n 的序列，使得

$$\mathbb{E}_P[f_n] \to aP[A], \quad \text{and} \quad \mathbb{E}_Q[\exp\{f_n\}] \to \exp\{a\}Q[A] \tag{4.14}$$

保持 *simultaneously*，即在近似两个期望的意义上满足 $f_n \to a1_A$。下面我们仅考虑 $a > 0$ 的情形。设紧集 F 与开集 U 满足 $F \subset A \subset U$ 且 $\max(P[U] - P[F], Q[U] - Q[F]) \leq \epsilon$。只要 P 和 Q 是所谓的正则测度，这样的 F 和 U 就存在。不深入细节，我们只需注意到 Polish 空间上的有限测度自动是正则的。然后由 Urysohn 引理，存在连续函数 $f_\epsilon : \mathcal{X} \to [0, a]$，在 F 上等于 a，在 U^c 上为 0。于是我们有

$$aP[F] \leq \mathbb{E}_P[f_\epsilon] \leq aP[U]$$

$$\exp\{a\}Q[F] \le \mathbb{E}_Q[\exp\{f_\epsilon\}] \le \exp\{a\}Q[U]\,.$$

对每个不等式分别减去 $aP[A]$ 和 $\exp\{a\}Q[A]$，我们看到取 $\epsilon \to 0$ 确实得到满足（4.14）的函数序列。

类似地，如果我们想近似一般简单函数 $g = \sum_{i=1}^n a_i 1_{A_i}$ (，其中 A_i 互不相交，且 $|a_i| \le a_{\max} < \infty$) 我们固定 $\epsilon > 0$ 并定义函数 $f_{i,\epsilon}$ 近似 $a_i 1_{A_i}$ 如上所述，集合为 $F_i \subset A_i \subset U_i$ ，因此 $S \triangleq \cup_i (U_i \setminus F_i)$ 满足 $\max(P[S], Q[S]) \le n\epsilon$。我们还有

$$|\sum_i f_{i,\epsilon} - g| \le a_{\max} \sum_i 1_{U_i \setminus F_i} \le n a_{\max} 1_S\,.$$

我们于是显然有 $|\mathbb{E}_P[\sum_i f_{i,\epsilon}] - \mathbb{E}_P[g]| \le a_{\max} n^2 \epsilon$。另一方面，我们也有

$$\begin{aligned}\sum_i \exp\{a_i\}Q[F_i] &\le \mathbb{E}_Q[\exp\{\sum_i f_{i,\epsilon}\}] \\ &\le \mathbb{E}_Q[\exp\{g\}1_{S^c}] + \exp\{n a_{\max}\}Q[S] \le \mathbb{E}_Q[\exp\{g\}] + \exp\{n a_{\max}\} n\epsilon\,.\end{aligned}$$

因此，取$\epsilon \to 0$，和$\sum_i f_{i,\epsilon} \to \sum_i a_i 1_{A_i}$，在$\mathbb{E}_P[\cdot]$和$\mathbb{E}_Q[\exp\{\cdot\}]$两种意义下。 □

备注 4.4 1 Donsker-Varadhan 表示有什么用处？通过设置 $f(x) = \epsilon \cdot g(x)$ 且 $\epsilon \ll$ 为 1，并对 exp 和 log 进行线性化，我们可以看到当 $D(P\|Q)$ 很小时，P 下的期望可以通过 Q (测度变换) 下的期望来近似：$\mathbb{E}_P[g(X)] \approx \mathbb{E}_Q[g(X)]$。这对所有在 Q 下具有有限指数矩的函数 g 都成立。全变差距离提供了类似的界，但适用于更窄的一类有界函数：

$$|\mathbb{E}_P[g(X)] - \mathbb{E}_Q[g(X)]| \le \|g\|_\infty \mathrm{TV}(P, Q)\,.$$

2 更正式地，不等式 $\mathbb{E}_P[f(X)] \le \log \mathbb{E}_Q[\exp f(X)] + D(P\|Q)$ 在估计 $\mathbb{E}_P[f(X)]$ 时非常有用，特别是对于复杂分布 P (，例如在高维 X 且坐标弱相关)的情况下，通过做出聪明的选择 Q (，例如具有独立同分布分量)。

3 在第5章中我们将证明$D(P\|Q)$在P (中是凸的，事实上，在)对中也是凸的。获得像(4.11)这样的变分公式的一般方法是通过Young-Fenchel对偶性，我们将在下面的(7.84)中回顾这一点。实际上，(4.11)正是那个不等式，因为$D(\cdot\|Q)$的Fenchel-Legendre共轭由一个凸映射 $f \mapsto \psi_f$给出。更多细节，见第7.13节。

4 Donsker-Varadhan 也应被视为 DPI 的“改进版”。例如，本书中 DPI 的主要应用之一就是获得如下估计：

$$P[A] \log \frac{1}{Q[A]} \le D(P\|Q) + \log 2\,, \tag{4.15}$$

这是大偏差理论（推论2.19和第15章）以及Fano不等式（定理3.12）的基础。通过应用(4.11)式并令$f(x) = 1\{x \in A\} \log \frac{1}{Q[A]}$，可以得到相同的估计。

4.4 吉布斯变分原理

正如我们之前所述，Donsker-Varadhan 表征可以视为将凸函数 $P \mapsto D(P\|Q)$ 表示为线性函数 $P \mapsto \mathbb{E}_P[f] - \psi_f$ 的上确界的一种方式，其中 $\psi_f = \log \mathbb{E}_Q[\exp\{f\}]$，此时 ψ_f 被称为凸共轭。现在，根据一般凸对偶理论，人们会预期函数 $f \mapsto \psi_f$ 是凸的，并且应该具有类似 f 的线性函数上确界的表征。在本节中，我们推导它，并展示其几个（相当有影响力的）经典和现代应用。

命题 4.7（吉布斯变分原理）*Let f: $\mathcal{X} \to \mathbb{R} \cup \{-\infty\}$ be any measurable function and Q a probability measure on $\mathcal{X}$. Then*

$$\log \mathbb{E}_Q[\exp\{f(X)\}] = \sup_P \mathbb{E}_P[f(X)] - D(P\|Q)\,,$$

where the supremum is taken over all P with $D(P\|Q) < \infty$. If the left-hand side is finite then the unique maximizer of the right-hand side is $P = Q^f$, a tilted version of Q defined in (4.13)*.*

Proof. 令 $\psi_f \triangleq$ 记录 $\mathbb{E}_Q[\exp\{f(X)\}]$。首先，若 $\psi_f = -\infty$，则 Q-几乎必然 $f = -\infty$，因此 P-几乎必然也有 $f = -\infty$，从而等式两边均为 $-\infty$。接下来，假设 $-\infty < \psi_f < \infty$。那么根据 Donsker-Varadhan (4.11)，我们得到

$$\psi_f \geq \mathbb{E}_P[f(X)] - D(P\|Q)\,.$$

另一方面，设置 $P = Q^f$ 我们得到等式。为了证明唯一性，请注意 $\operatorname{Log} \frac{dQ^f}{dQ}_1 = f - \psi_f$ 即使在 $f = -\infty$ 时也是如此。因此，从(2.11)我们得到当 $D(P\|Q) < \infty$ 时

$$\mathbb{E}_P[f(X) - \psi_f] = D(P\|Q) - D(P\|Q^f)\,.$$

由此我们得出$\mathbb{E}_P[f(X)] < \infty$，因此可以将上述内容重写为

$$\mathbb{E}_P[f(X)] - D(P\|Q) = \psi_f - D(P\|Q^f)\,,$$

这表明 $\mathbb{E}_P[f(X)] - D(P\|Q) = \psi_f$ 蕴含 $P = Q^f$。

接下来，假设 $\psi_f = \infty$。让我们定义 $f_n = f \wedge n$，$n \geq 1$。由于 $\psi_{f_n} < \infty$，根据之前的刻画，我们有一个序列 P_n 使得 $D(P_n\|Q) < \infty$，并且当 $n \to \infty$

$$\mathbb{E}_{P_n}[f(X) \wedge n] - D(P_n\|Q) = \psi_{f_n} \nearrow \psi_f = \infty\,.$$

由于 $\mathbb{E}_{P_n}[f(X) \wedge n] \leq \mathbb{E}_{P_n}[f(X)]$，我们有

$$\mathbb{E}_{P_n}[f(X)] - D(P_n\|Q) \geq \psi_{f_n} \to \infty\,,$$

证明结束。 □

我们现在简要探讨命题4.7在过去一个世纪中的应用。我们从统计物理和图模型的例子开始。这里的关键思想是将所有分布P上的sup替换为一个更易于处理的子集。这一思想是许多变分推断[447]的基础。

示例 4.1（Ising 模型的平均场近似）假设我们有一个关于向量 $\tilde{X} \in \{0,1\}^{n+m}$ 分布的复杂模型，由 *Ising model* 给出

$$P_{\tilde{X}}(\tilde{x}) = \frac{1}{\tilde{Z}} \exp\{\tilde{x}^\top \tilde{A} \tilde{x} + \tilde{b}^\top \tilde{x}\},$$

其中 $\tilde{A} \in \mathbb{R}^{(n+m)\times(n+m)}$ 是一个对角线为零的对称 *interaction matrix*，$\tilde{b}$ 是由 *external fields* 和 $\tilde{Z}$ 组成的向量，$\tilde{Z}$ 是归一化常数。我们注意到，$\tilde{A}$ 通常非常稀疏，非零项仅出现在那些被视为相互作用（或在某个图中相邻）的少数变量 x_i 和 x_j 中。我们将向量 $\tilde{X} = (X, Y)$ 分解为两个部分：最后 m 个坐标是可观测的，前 n 个坐标是隐藏的（潜在的），我们想要推断它们的值；换句话说，我们的目标是在观测到 y 的情况下评估 $P_{X|Y=y}$。显然，这个条件分布仍然是一个伊辛模型，因此

$$P_{X|Y}(x|y) = \frac{1}{Z} \exp\{x^\top A x + b^\top x\}, \qquad x \in \{0,1\}^n$$

其中 A 是 $\tilde{A}$ 的 $n \times n$ 阶主子式，而 b 和 Z 依赖于 y。不幸的是，即使计算单个值 $P[X_1 = 1]$ 通常也被认为是计算上不可行的 [394, 175]，因为计算 Z 需要对 2^n 个 x 值求和。

让我们用$f(x) = x^\top A x + b^\top x$表示，并用$Q$表示$\{0,1\}^n$上的均匀分布。应用命题4.7，我们得到

$$\log Z - n \log 2 = \log \mathbb{E}_Q[\exp\{f\}] = \sup_{P_{X^n}} \mathbb{E}_P[f(X^n)] - D(P\|Q).$$

然后根据定理2.2，我们得到

$$\log Z = \sup_{P_{X^n}} \mathbb{E}_P[f(X^n)] + H(P_{X^n}).$$

正如我们所说，精确计算 $\log Z$ 并不可行。一个颇具影响力的想法是在乘积分布 $P_{X^n} = \prod_{i=1}^n \mathrm{Ber}(p_i)$ 类中寻找最大化者。在这种情况下，这个最大化问题几乎可以以闭式形式求解：

$$\sup_p p^\top A p + b^\top p + \sum_i h(p_i),$$

其中 $p = (p_1, \ldots, p_n)$。由于目标函数是强凹的（练习 I.37），我们只需解一阶最优性条件（或 *mean-field equations*），这是一组 n 个关于 n 个变量的非线性方程：

$$p_i = \sigma\Big(b_i + 2\sum_{j=1}^n a_{i,j} p_j\Big), \qquad \sigma(x) \triangleq \frac{1}{1+\exp(-x)}.$$

这些通过迭代消息传递算法求解 [447]。一旦获得 p_i 的值，*mean-field approximation* 就取

$$P_{X|Y=y} \approx \prod_{i=1}^n \mathrm{Ber}(p_i).$$

需要强调的是，平均场思想不仅在于近似 Z 的值，还在于将相应的最大化器（在受限的乘积分布类上）视为近似后验分布。

为了获得另一种类型的示例，让我们考虑一个更一般的设定，其中我们有一个由 $\theta \in \mathbb{R}^d$ 索引的分布参数族 $P^{(\theta)}_{X,Y}$。通常情况下，联合分布使得 $P^{(\theta)}_X$ 和 $P^{(\theta)}_{Y|X}$ 都“简单”，但 $P^{(\theta)}_Y$ 和 $P^{(\theta)}_{X|Y}$ “复杂”甚至难以处理（例如，在稀疏线性回归和社区检测第30.3节中）。如前一示例，X 是潜在（未观测）变量，Y 是观测变量。

暂时我们将省略写作 θ，并考虑评估 $P_Y(y)$ 的问题——一个表明观察到的 y 有多极端的量（称为证据）。注意

$$P_Y(y) = \mathbb{E}_{x\sim P_X}[P_{Y|X}(y|x)]\,.$$

尽管根据假设P_X和$P_{Y|X}$都易于计算，但这种边缘化可能难以处理。作为变通方法，我们引用命题4.7，取$f(x) =$的对数$P_{Y|X}(y|x)$和$Q = P_X$，得到

$$\log P_Y(y) = \sup_R \mathbb{E}_R[f(X)] - D(R\|P_X) = \sup_R \mathbb{E}_{X\sim R}\left[\log \frac{P_{X,Y}(X,y)}{R(X)}\right]\,, \tag{4.16}$$

其中 R 是任意分布。注意，右侧仅涉及一个简单的量 $P_{X,Y}$，因此所有计算的复杂性都转移到了对 R 的优化上。表达式 (4.16) 被称为 *evidence lower bound (ELBO)*，因为对于 R 的任意固定值，我们都能得到 $\log P_Y(y)$ 的一个可证明下界。通常，人们会在某个方便的分布集合上优化 R 的选择，以获得该类中最佳（最紧）的下界。

其中一个应用导致了著名的迭代（EM）算法，见下文(5.33)。另一个应用是现代密度估计算法，我们接下来将进行描述。

例4.2（变分自编码器[245]）无监督学习中的一个经典问题是密度估计：给定一个样本 $y_1,\dots,y_n \overset{\text{i.i.d.}}{\sim} P_Y$，估计 $\mathbb{R}^d$ 上的真实 P_Y。我们描述[245]中的一种现代解决方案。首先，他们为 P_Y 提出了一个潜在参数模型（一个 *generative model*）。即，生成 Y 的过程是：首先采样一个潜在变量 $X \sim \mathcal{N}(0, I_{d'})$，然后将 Y 设为条件高斯分布：

$$Y = \mu(X;\theta) + D(X;\theta)Z, \qquad X \perp\!\!\!\perp Z \sim \mathcal{N}(0, I_d)\,,$$

其中向量 $\mu(\cdot;\ \theta)$ 和对角矩阵 $D(\cdot;\ \theta)$ 是输入为 $(\cdot)$、权重为 θ 的深度神经网络。（详细描述见 [245, App. C.2]。）由此得到的分布 $P^{(\theta)}_Y$ 是一个（复杂的）位置-尺度高斯混合。为了找到最佳密度，[245] 旨在通过求解以下问题来最大化似然

$$\max_\theta \sum_i \log P^{(\theta)}_Y(y_i)\,.$$

由于获得 P_Y 的边缘化是棘手的，我们（通过求助于ELBO（4.16））将目标替换为

$$\max_{\theta} \sup_{R_{X|Y}} \sum_i \mathbb{E}_{X\sim R_{X|Y=y_i}} \left[\log \frac{p^{(\theta)}_{X,Y}(X, y_i)}{r_{X|Y}(X|y_i)} \right] , \tag{4.17}$$

其中我们用小写字母表示 $P_{X,Y}$ 和 $R_{X|Y}$ 的 PDF。现在以这种形式，该算法就是 EM 算法（正如我们在第 5.6 节中讨论的那样）。将这个思想带入 21 世纪的是将优化限制在 $R_{X|Y}$ 的集合上，而这些集合同样通过以下方式定义：

$$X = \tilde{\mu}(Y;\phi) + \tilde{D}(Y;\phi)\tilde{Z}, \qquad Y \perp\!\!\!\perp \tilde{Z} \sim \mathcal{N}(0, I_{d'})$$

其中 $\tilde{\mu}(Y;\ \phi)$ 和对角协方差矩阵 $\tilde{D}(Y;\ \phi)$ 是由某个参数为 ϕ 的神经网络输出的。该辅助模型（*recognition model*）下的条件分布，记为 $R^{(\phi)}_{X|Y}$，是高斯分布。由于 ELBO（4.16）由后验 $P^{(\theta)}_{X|Y}$ 得到，这实质上是用高斯分布来近似生成模型下的真实后验。同样将关于 $R_{X|Y=y_i}$ 的期望替换为其经验版本（通过生成 $\tilde{Z}_{ij} \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0, I_{d'})$，我们得到以下

$$\max_{\theta} \max_{\phi} \sum_i \sum_j \left[\log \frac{p^{(\theta)}_{X,Y}(x_{i,j}, y_i)}{r^{(\phi)}_{X|Y}(x_{i,j}|y_i)} \right] , \qquad x_{i,j} = \tilde{\mu}(y_i;\phi) + \tilde{D}(y_i;\phi)\tilde{Z}_{ij} . \tag{4.18}$$

现在将密度的高斯形式 p_X、$p^{(\theta)}_{Y|X}$ 和 $r^{(\phi)}_{X|Y}$ 代入，可得到一个表达式，其梯度 ∇_θ 和 ∇_ϕ 可通过自动微分软件轻松计算。[1] 事实上，由于 $r^{(\phi)}_{X|Y}$ 和 $r^{(\theta)}_{Y|X}$ 均为高斯分布，我们可以比 (4.18) 使用更少的蒙特卡洛近似，因为 (4.17) 中的目标函数等于 $\mathbb{E}_{X\sim R_{X|Y=y_i}}\left[\log \frac{p^{(\theta)}_{X,Y}(X,y_i)}{r^{(\phi)}_{X|Y}(X|y_i)}\right] = -D(R_{X|Y=y_i}\|P_X) + \mathbb{E}_{X\sim R_{X|Y=y_i}}\left[\log p^{(\theta)}_{Y|X}(y_i|X)\right]$，其中 $P_X = N(0, I'_d)$，$R_{X|Y=y_i} = N(\tilde{\mu}(y_i;\ \phi);\ \tilde{D}^2(y_i;\ \phi))$，$P^{(\theta)}_{Y|X=x} = N(\mu(x;\ \theta);\ D^2(x;\ \theta))$，因此第一个高斯 KL 散度具有闭式解（例 2.2），我们只需对第二项应用蒙特卡洛近似。对于两个版本，优化都通过对 θ 和 ϕ 进行（随机）梯度上升，直至收敛到某个 (θ^*, ϕ^*)。然后，$P^{(\theta^*)}_Y$ 可用于从学习到的分布中生成新样本，$R^{(\phi^*)}_{X|Y}$ 用于将样本映射（“编码”）到潜在空间，$P^{(\theta^*)}_{Y|X}$ 用于将潜在表示“解码”为目标样本。关于其他编码器和解码器架构，我们请读者参阅综述 [246] 的第 3 章和第 4 章。

[1] An important part of the contribution of [245] is the “reparametrization trick”. Namely, since [452] a standard way to compute $\nabla_\phi \mathbb{E}_{Q^{(\phi)}}[f]$ in machine learning is to write $\nabla_\phi \mathbb{E}_{Q^{(\phi)}}[f] = \mathbb{E}_{Q^{(\phi)}}[f(X)\nabla_\phi \ln q^{(\phi)}(X)]$ and replace the latter expectation by its empirical approximation. However, in this case a much better idea is to write $\mathbb{E}_{Q^{(\phi)}}[f] = \mathbb{E}_{Z\sim\mathcal{N}}[f(g(Z;\phi))]$ for some explicit g and then move gradient inside the expectation before computing the empirical version.

4.5 散度的连续性

对于有限字母表$\mathcal{X}$，很容易建立熵和散度的连续性：

命题 4.8 *Let $\mathcal{X}$ be finite. Fix a distribution Q on $\mathcal{X}$ with $Q(x) > 0$ for all $x \in \mathcal{X}$. Then the map $P \mapsto D(P\|Q)$ is continuous. In particular, $P \mapsto H(P)$ is continuous.*

警告：散度在该对中从不连续，即使对于有限字母表也是如此。例如，当$n \to \infty$时，$d(\frac{1}{n}\|2^{-n}) \not\to 0$。

Proof. 注意

$$D(P\|Q) = \sum_x P(x) \log \frac{P(x)}{Q(x)}$$

并且每一项都是 $P(x)$ 的连续函数。 □

我们的下一个目标是研究一般字母表下发散性的连续性性质。我们从一个否定的观察开始。

备注 4.5 一般而言，$D(P\|Q)$ 在 P 或 Q 中均为 *not* 连续。例如，令 $X_1, \ldots, X_n$ 为独立同分布且等可能地取 $\{\pm 1\}$。则由中心极限定理，当 $n \to \infty$ 时，$S_n = \frac{1}{\sqrt{n}} \sum_{i=1}^n X_i \xrightarrow{\mathrm{d}} \mathcal{N}(0,1)$。但对于所有 n，由于 S_n 是离散的，$D(P_{S_n}\|\mathcal{N}(0,1)) = \infty$。注意，这也是 (4.19) 中严格不等式的一个例子。

然而，存在一个非常有用的半连续性性质。

定理 4.9（散度的下半连续性）*Let $\mathcal{X}$ be a metric space with Borel σ-algebra $\mathcal{H}$. If P_n and Q_n converge weakly to P and Q, respectively,*[2] *then*

$$D(P\|Q) \le \liminf_{n\to\infty} D(P_n\|Q_n)\,. \tag{4.19}$$

On a general space if $P_n \to P$ and $Q_n \to Q$ pointwise[3] *(i.e. $P_n[E] \to P[E]$ and $Q_n[E] \to Q[E]$ for every measurable E) then* (4.19) *also holds.*

Proof. 这直接由（4.12）得出，因为对于每个$f \in \mathcal{C}_b$，有$\mathbb{E}_{P_n}[f] \to \mathbb{E}_P[f]$和$\mathbb{E}_{Q_n}[\exp\{f\}] \to \mathbb{E}_Q[\exp\{f\}]$。 □

[2] Recall that sequence of random variables X_n converges in distribution to X if and only if their laws P_{X_n} converge weakly to P_X.

[3] Pointwise convergence is weaker than convergence in total variation and stronger than weak convergence.

4.6* 在σ-代数的单调极限下的连续性

我们最后且略显微妙的话题是理解 D 和 I 对空间隐含的 σ-代数（至今被忽视）的依赖性。实际上，散度 $D(P\|Q)$ 的定义隐含地（通过拉东-尼科迪姆导数）依赖于定义可测空间 $(\mathcal{X},\mathcal{F})$ 的 σ-代数 $\mathcal{F}$。为了强调对 $\mathcal{F}$ 的依赖性，在本节中我们将仅如下明确写出底层的 σ-代数:

$$D(P_{\mathcal{F}}\|Q_{\mathcal{F}})\,.$$

我们的主要结果是σ-代数在单调极限下的连续性。回顾一下，嵌套的σ-代数序列 $\mathcal{F}_1 \subset \mathcal{F}_2 \cdots$，当$\mathcal{F} \triangleq \sigma\left(\cup_n \mathcal{F}_n\right)$是包含$\cup_n \mathcal{F}_n$ (的最小σ-代数时，称其为$\mathcal{F}_n \nearrow \mathcal{F}$$\sigma$-代数的并可能不是$\sigma$-代数，因此需要完备化)。类似地，嵌套的$\sigma$-代数序列$\mathcal{F}_1 \supset \mathcal{F}_2 \cdots$，如果 $\mathcal{F}=\cap_n \mathcal{F}_n$ (σ-代数的交集始终是σ-代数)，则称其为$\mathcal{F}_n \searrow \mathcal{F}$。我们将在本节中证明，我们始终有:

$$\mathcal{F}_n \nearrow \mathcal{F} \quad \Longrightarrow \quad D(P_{\mathcal{F}_n}\|Q_{\mathcal{F}_n}) \nearrow D(P_{\mathcal{F}}\|Q_{\mathcal{F}}) \tag{4.20}$$

$$\mathcal{F}_n \searrow \mathcal{F} \quad \Longrightarrow \quad D(P_{\mathcal{F}_n}\|Q_{\mathcal{F}_n}) \searrow D(P_{\mathcal{F}}\|Q_{\mathcal{F}}) \tag{4.21}$$

为建立第一个结果，将散度 $D(P_{\mathcal{F}}\|Q_{\mathcal{F}})$ 的定义推广到（a）任意集合 $\mathcal{F}$ 的 *algebra* 以及（b）$\mathcal{F}$ 上的两个正加性（不必是 σ-加性）集函数 P,Q，将会很方便。我们按照散度的 Gelfand-Yaglom-Perez 变分表示（定理 4.5）来这样做。

定义4.10（代数上的KL散度）设P和Q是定义在$\mathcal{X}$ (的子集构成的代数$\mathcal{F}$（不一定是σ-代数)）上的两个正的可加（不一定σ-可加）集函数。我们定义

$$D(P_{\mathcal{F}}\|Q_{\mathcal{F}}) \triangleq \sup_{\{E_1,\ldots,E_n\}} \sum_{i=1}^{n} P[E_i]\log\frac{P[E_i]}{Q[E_i]}\,,$$

其中上确界取遍所有有限 $\mathcal{F}$-可测分拆：$\bigcup_{j=1}^{n} E_j = \mathcal{X}, E_j \cap E_i = \emptyset$，并且根据我们通常的约定，$0\log\frac{1}{0}=0$ 以及 $\log\frac{1}{0}=\infty$。

注意，当 $\mathcal{F}$ 不是 σ-代数或 P,Q 不是 σ-可加的时，我们没有 Radon-Nikodym 定理，因此我们原来对 KL 散度的定义不适用。

定理 4.11（散度的测度论性质）*Let P,Q be probability measures on the measurable space $(\mathcal{X},\mathcal{H})$. Assume all algebras below are sub-algebras of $\mathcal{H}$. Then:*

- *(Monotonicity) If $\mathcal{F}\subseteq\mathcal{G}$ are nested algebras then*

$$D(P_{\mathcal{F}}\|Q_{\mathcal{F}}) \le D(P_{\mathcal{G}}\|Q_{\mathcal{G}})\,. \tag{4.22}$$

- *Let $\mathcal{F}_1 \subseteq \mathcal{F}_2 \ldots$ be an increasing sequence of algebras and let $\mathcal{F} = \bigcup_n \mathcal{F}_n$ be their limit, then*

$$D(P_{\mathcal{F}_n} \| Q_{\mathcal{F}_n}) \nearrow D(P_{\mathcal{F}} \| Q_{\mathcal{F}}) .$$

- *If $\mathcal{F}$ is $(P+Q)$-dense in $\mathcal{G}$ then*[4]

$$D(P_{\mathcal{F}} \| Q_{\mathcal{F}}) = D(P_{\mathcal{G}} \| Q_{\mathcal{G}}) . \tag{4.23}$$

- *(Monotone convergence theorem) Let $\mathcal{F}_1 \subseteq \mathcal{F}_2 \ldots$ be an increasing sequence of algebras and let $\mathcal{F} = \bigvee_n \mathcal{F}_n$ be the smallest σ-algebra containing all of $\mathcal{F}_n$. Then we have*

$$D(P_{\mathcal{F}_n} \| Q_{\mathcal{F}_n}) \nearrow D(P_{\mathcal{F}} \| Q_{\mathcal{F}})$$

and, in particular,

$$D(P_{X^\infty} \| Q_{X^\infty}) = \lim_{n\to\infty} D(P_{X^n} \| Q_{X^n}) .$$

Proof. 前两项是定义的直接应用。第三项则源于以下事实：若 $\mathcal{F}$ 在 $\mathcal{G}$ 中稠密，则任意 $\mathcal{G}$ 可测划分 $\{E_1, \ldots, E_n\}$ 都可由一个 $\mathcal{F}$ 可测划分 $\{E_1', \ldots, E_n'\}$ 逼近，满足 $(P+Q)[E_i \triangle E_i'] \le \epsilon$。实际上，我们首先令 E_1' 为 $\mathcal{F}$ 中的一个元素，使得 $(P+Q)(E_1 \triangle E_1') \le \frac{\epsilon}{2n}$。然后，我们令 E_2' 为 $E_2 \setminus E_1'$ 的一个$\frac{\epsilon}{2n}$-近似，依此类推。最后，$E_n' = (\cup_{j\le 1} E_j')^c$。取 $\epsilon \to 0$，我们得到 $\sum_i P[E_i'] \log \frac{P[E_i']}{Q[E_i']} \to \sum_i P[E_i] \log \frac{P[E_i]}{Q[E_i]}$。

最后一个陈述由前一个陈述以及以下事实得出：对于 $(\mathcal{X}, \mathcal{H})$ 上的任意有界 μ，任何代数 $\mathcal{F}$ 在其生成的 σ-代数 $\sigma\{\mathcal{F}\}$ 中是 μ-稠密的（参见 [142，引理 III.7.1]。） □

最后，w 我们在递减的 σ-代数下处理连续性，即 (4.21)。

命题 4.12 *Let $\mathcal{F}_n \searrow \mathcal{F}$ be a sequence of decreasing σ-algebras with intersection $\mathcal{F} = \cap_n \mathcal{F}_n$; let P, Q be two probability measures on $\mathcal{F}_0$. If $D(P_{\mathcal{F}_0} \| Q_{\mathcal{F}_0}) < \infty$ then we have*

$$D(P_{\mathcal{F}_n} \| Q_{\mathcal{F}_n}) \searrow D(P_{\mathcal{F}} \| Q_{\mathcal{F}}) \tag{4.24}$$

The condition $D(P_{\mathcal{F}_0} \| Q_{\mathcal{F}0}) < \infty$ can not be dropped, cf. the example after (4.32).

Proof. 设 $X_{-n} = \left.\frac{dP}{dQ}\right|_{\mathcal{F}_n}$。由于 $X_{-n} = \mathbb{E}_Q\left[\left.\frac{dP}{dQ}\right| \mathcal{F}_n\right]$，我们有 $(\ldots, X_{-1}, X_0)$ 是一致可积鞅。根据反向时间的鞅收敛定理，参见 [84, Theorem 5.4.17]，我们几乎必然有

$$X_{-n} \to X_{-\infty} \triangleq \left.\frac{dP}{dQ}\right|_{\mathcal{F}} . \tag{4.25}$$

我们需要证明

$$\mathbb{E}_Q[X_{-n} \log X_{-n}] \to \mathbb{E}_Q[X_{-\infty} \log X_{-\infty}] .$$

4 回忆，如果 $\forall E \in \mathcal{G}, \epsilon > 0 \exists E' \in \mathcal{F}$ 使得 $\mu[E \Delta E'] \le \epsilon$，则 $\mathcal{F}$ 在 $\mathcal{G}$ 中是 μ-稠密的。

我们将通过将 $x \log x$ 分解如下

$$x \log x = x \log^+ x + x \log^- x,$$

其中 $\log^+ x = \max(\log x, 0)$ 且 $\log^- x = \min(\log x, 0)$。由于 $x \log^- x$ 有界，由有界收敛定理可得:

$$\mathbb{E}_Q[X_{-n} \log^- X_{-n}] \to \mathbb{E}_Q[X_{-\infty} \log^- X_{-\infty}].$$

为了证明$\log^+$的类似收敛性，我们需要注意到两点。首先，函数

$$x \mapsto x \log^+ x$$

是凸的。其次，对于任何非负凸函数 ϕ，满足 $\mathbb{E}[\phi(X_0)] < \infty$ 条件，集合 $\{Z_n = \phi(\mathbb{E}[X_0|\mathcal{F}_n]), n \geq 0\}$ 是一致可积的。实际上，根据詹森不等式，我们有

$$\mathbb{P}[Z_n > c] \leq \frac{1}{c} \mathbb{E}[\phi(\mathbb{E}[X_0|\mathcal{F}_n])] \leq \frac{\mathbb{E}[\phi(X_0)]}{c}$$

因此，$\mathbb{P}[Z_n > c] \to 0$ 作为 $c \to \infty$。因此，我们再次根据Jensen

$$\mathbb{E}[Z_n 1\{Z_n > c\}] \leq \mathbb{E}[\phi(X_0) 1\{Z_n > c\}] \to 0 \qquad c \to \infty.$$

最后，由于 $X_{-n} \log^+ X_{-n}$ 是一致可积的，我们从 (4.25) 得到

$$\mathbb{E}_Q[X_{-n} \log^- X_{-n}] \to \mathbb{E}_Q[X_{-\infty} \log^- X_{-\infty}]$$

至此证明完成。 □

4.7 交互信息的变分特征与连续性

同样地，与命题4.8类似，容易证明在有限字母表的情况下，互信息在分布的有限维单纯形上总是连续的。[5]

命题 4.13 *(a) If $\mathcal{X}$ and $\mathcal{Y}$ are both finite alphabets, then $P_{X,Y} \mapsto I(X; Y)$ is continuous.*
(b) If $\mathcal{X}$ is finite, then $P_X \mapsto I(X; Y)$ is continuous.
(c) Without any assumptions on $\mathcal{X}$ and $\mathcal{Y}$, let P_X range over the convex hull $\Pi = \mathrm{co}(P_1, \ldots, P_n) = \{\sum_{i=1}^n \alpha_i P_i : \sum_{i=1}^n \alpha_i = 1, \alpha_i \geq 0\}$. If $I(P_j, P_{Y|X}) < \infty$ (using the notation $I(P_X, P_{Y|X}) = I(X; Y)$) for all $j \in [n]$, then the map $P_X \mapsto I(X; Y)$ is continuous.

Proof. 对于第一个命题，应用表示

$$I(X;Y) = H(X) + H(Y) - H(X,Y)$$

以及命题4.8中熵的连续性。

[5] Here we only assume that topology on the space of measures is compatible with the linear structure, so that all linear operations on measures are continuous.

对于第二个陈述，取$Q_Y = \frac{1}{|\mathcal{X}|}\sum_{x\in\mathcal{X}} P_{Y|X=x}$。注意

$$D(P_Y\|Q_Y) = \mathbb{E}_{Q_Y}\left[f\left(\sum_x P_X(x)h_x(Y)\right)\right],$$

其中$f(t) = t\log t$和$h_x(y) = \frac{dP_{Y|X=x}}{dQ_Y}(y)$由$|\mathcal{X}|$界定且非负。因此，根据有界收敛定理，我们有$P_X \mapsto D(P_Y\|Q_Y)$是连续的。证明完毕，因为根据黄金公式

$$I(X;Y) = D(P_{Y|X}\|Q_Y|P_X) - D(P_Y\|Q_Y),$$

而第一项对于P_X是线性的。

对于第三个陈述，用$Z\in[n]$和$P_{X|Z=j} = P_j$构造一个链$Z\to X\to Y$。WLOG假设$P_1,\ldots,P_n$是co$(P_1,\ldots,P_n)$的不同极点。则P_Z与$P_X\in\Pi$之间存在一个线性双射。此外，$I(X;Y) = I(Z;Y) + I(X;Y|Z)$。根据前面的断言，第一项对$P_Z$是连续的，而第二项对$P_Z$仅是线性的。因此，映射$P_Z\mapsto I(X;Y)$是连续的，$P_X\mapsto I(X;Y)$也是如此。

□

互信息的更多性质来自$I(X;Y) = D(P_{X,Y}\|P_XP_Y)$以及散度的相应性质，例如

1 用于互信息的Donsker-Varadhan：按互信息的定义

$$I(X;Y) = \sup_f \mathbb{E}[f(X,Y)] - \log\mathbb{E}[\exp\{f(X,\bar{Y})\}], \tag{4.26}$$

其中$\bar{Y}$是Y的一个副本，独立于X，并且上确界可以在定理4.6中的任何一类（二元）函数上取得。但请注意，对于互信息，我们也可以得到一个更强的刻画：[6]

$$I(X;Y) \geq \mathbb{E}[f(X,Y)] - \mathbb{E}[\log\mathbb{E}[\exp\{f(X,\bar{Y})\}|X]], \tag{4.27}$$

由此，通过将外部期望移入对数内部即可得到（4.26）。只要X与Y(之间由$I(X$衡量的相关性较弱（参见习题I.55），这两者均可用于证明$\mathbb{E}[f(X,Y)]\approx\mathbb{E}[f(X,\bar{Y})]$。

如果$(X_n,Y_n)\xrightarrow{d}(X,Y)$依分布收敛，则

$$I(X;Y)\leq\liminf_{n\to\infty} I(X_n;Y_n). \tag{4.28}$$

• 严格不等式的例子：$X_n = Y_n = \frac{1}{n}Z$。在这种情况下$(X_n,Y_n)\xrightarrow{d}(0,0)$但$I(X_n;Y_n) = H(Z) > 0 = I(0;0)$。• 一个更令人印象深刻的例子：设$(X_p,Y_p)$在平面上的单位$\ell_p$-球上均匀分布：$\{(x,y)\in\mathbb{R}^2: |x|^p + |y|^p\leq 1\}$。那么当$p\to 0$，$(X_p,Y_p)\xrightarrow{d}(0,0)$，但$I(X_p;Y_p)\to\infty$。（见练习I.16）

[6] Just apply Donsker-Varadhan to $D(P_{Y|X=x_0}\|P_Y)$ and average over $x_0\sim P_X$.

3 互信息作为分割上的上确界：

$$I(X;Y) = \sup_{\{E_i\}\times\{F_j\}} \sum_{i,j} P_{X,Y}[E_i \times F_j] \log \frac{P_{X,Y}[E_i \times F_j]}{P_X[E_i]P_Y[F_j]}\,, \tag{4.29}$$

其中上确界取遍空间 $\mathcal{X}$ 和 $\mathcal{Y}$ 的所有有限划分 .[7]

4（单调收敛 I）：

$$I(X^\infty;Y) = \lim_{n\to\infty} I(X^n;Y) \tag{4.30}$$

$$I(X^\infty;Y^\infty) = \lim_{n\to\infty} I(X^n;Y^n) \tag{4.31}$$

这意味着两个过程 X^∞ 和 Y^∞ 之间的全部互信息都包含在它们的有限维投影中，尾 σ-代数中不留下任何信息。另请注意，对（4.30）应用（有限 n）链式法则可恢复（4.1）。

5 (单调收敛 II)：回想对于任意随机过程 $(X_1,\ldots)$，我们将其尾部 σ-代数定义为 $\mathcal{F}_{tail} = \cap_{n\geq 1}\sigma(X_n^\infty)$。令 X_{tail} 为一个随机变量，使得 $\sigma(X_{tail}) = \bigcap_{n\geq 1}\sigma(X_n^\infty)$。那么

$$I(X_{tail};Y) = \lim_{n\to\infty} I(X_n^\infty;Y)\,, \tag{4.32}$$

只要右侧有限。这是命题4.12的结果。如果没有有限性假设，该陈述是不正确的。事实上，考虑 $X_j \overset{\text{i.i.d.}}{\sim} \text{Ber}(1/2)$ 和 $Y = X_0^\infty$。那么每个 $I(X_n^\infty;\ Y) = \infty$，但由Kolmogorov的0-1律，$X_{tail}$ =几乎处处恒定，因此(4.32)的左侧为零。

4.8* PAC-贝叶斯

Donsker-Varadhan和Gibbs原理的一个深刻含义是一种历史上称为PAC-Bayes的方法，[8]用于界定经验过程的 supremum。这里我们介绍其核心思想及两个应用：一个在高维概率中，另一个在统计学习理论中。

但首先，让我们同意在本节中，ρ和π将表示Θ上的分布，我们将写为$\mathbb{E}_\rho[\cdot]$和$\mathbb{E}_\pi[\cdot]$，意思是在*only*上对θ变量关于相应先验进行积分，即

$$\mathbb{E}_\rho[f_\theta(x)] \triangleq \mathbb{E}_{\theta\sim\rho}[f_\theta(x)] = \int_\Theta f_\theta(x)\rho(d\theta)$$

表示 x 的函数。类似地，$\mathbb{E}_{P_X}[f_\theta(X)]$ 将表示在 $X \sim P_X$ 上的期望 *only*。以下估计是 PAC-Bayes 方法的核心。

[7] To prove this from (4.9) one needs to notice that algebra of measurable rectangles is dense in the product σ-algebra. See [129, Sec. 2.2].

[8] For probably approximately correct (PAC), as developed by Shawe-Taylor and Williamson [382], McAllester [298], Mauer [297], Catoni [83] and many others, see [16] for a survey.

命题 4.14 (PAC-贝叶斯不等式) *Consider a collection of functions* $\{f_\theta : \mathcal{X} \to \mathbb{R}, \theta \in \Theta\}$ *such that* $(\theta, x) \mapsto f_\theta(x)$ *is measurable. Fix a random variable* $X \in \mathcal{X}$ *and prior* $\pi \in \mathcal{P}(\Theta)$*. Then with probability at least* $1-\delta$ *we have for all* $\rho \in \mathcal{P}(\Theta)$*:*

$$\mathbb{E}_\rho[f_\theta(X) - \psi(\theta)] \le D(\rho\|\pi) + \log\frac{1}{\delta}\,, \qquad \psi(\theta) \triangleq \log \mathbb{E}_{P_X}[\exp\{f_\theta(X)\}]\,. \tag{4.33}$$

Furthermore, for any joint distribution $P_{\theta,X}$ *we have*

$$\mathbb{E}[f_\theta(X) - \psi(\theta)] \le I(\theta; X) \le D(P_{\theta|X}\|\pi|P_X)\,. \tag{4.34}$$

Proof. 我们将证明以下结果，该结果在此领域被称为*exponential inequality*：

$$\mathbb{E}_{P_X}\left[\sup_\rho \exp\{\mathbb{E}_\rho[f_\theta(X) - \psi(\theta)] - D(\rho\|\pi)\}\right] \le 1\,, \tag{4.35}$$

其中内部的 supremum 是在所有满足 $D(\rho\|\pi) < \infty$ 的 ρ 上取的。事实上，由它通过 Markov 不等式可推出（4.33）。注意这个 supremum 是在不可数个值上取的，因此先验地并不清楚外层期望下的 X 的函数是否甚至可测。我们将与指数不等式一起证明后者。

为此，我们将吉布斯原理（命题4.7）应用于函数$\theta \mapsto f_\theta(X) - \psi(\theta)$和基础测度$\pi$。需要注意的是，该函数可能取值为$-\infty$，但我们仍可得到

$$\sup_\rho \mathbb{E}_\rho[f_\theta(X) - \psi(\theta)] - D(\rho\|\pi) = \log \mathbb{E}_\pi[\exp\{f_\theta(X) - \psi(\theta)\}]\,,$$

其中右侧是 {v*} 的可测函数。取指数并对 {v*} 取期望，我们得到

$$\mathbb{E}_{P_X}\left[\sup_\rho \exp\{\mathbb{E}_\rho[f_\theta(X) - \psi(\theta)] - D(\rho\|\pi)\}\right] = \mathbb{E}_{P_X}\left[\mathbb{E}_\pi[\exp\{f_\theta(X) - \psi(\theta)\}]\right]\,.$$

我们断言右侧等于 $\pi[\psi(\theta) < \infty] \le 1$，这完成了(4.35)的证明。事实上，令 $E = \{\theta : \psi(\theta) < \infty\}$。那么对于任意 $\theta \in E$，我们有 $\mathbb{E}_{P_X}[\exp\{f_\theta(X) - \psi(\theta)\}] = 1$，或者换句话说，对于所有 θ:

$$\mathbb{E}_{P_X}[\exp\{f_\theta(X) - \psi(\theta)\}]1\{\theta \in E\} = 1\{\theta \in E\}\,.$$

现在在两边应用$\mathbb{E}_\pi$并调用富比尼定理，我们得到

$$\mathbb{E}_{P_X}[\mathbb{E}_\pi[\exp\{f_\theta(X) - \psi(\theta)\}]1\{\theta \in E\}] = \pi[E]\,.$$

最后，注意到 $1\{\theta \in E\}$ 可以省略，因为对于 $\theta \in E^c$，根据约定我们有 $\exp\{f_\theta(X) - \infty\} = 0$。

为了展示（4.34），对于每个 x，取（4.35）中的 $\rho = P_{\theta|X=x}$，得到

$$\mathbb{E}_{x\sim P_X}\left[\exp\{\mathbb{E}[f_\theta(X) - \psi(\theta)|X = x] - D(P_{\theta|X=x}\|\pi)\}\right] \le 1\,.$$

根据Jensen不等式，我们可以将外部期望移入指数内部，并得到(4.34)中最右边的的不等式。要以$I(\theta;\ X)$的形式得到界，取$\pi = P_\theta$并回顾(4.5)。 □

4.8.1 一致收敛

如前所述，PAC-Bayes不等式过于宽泛，以至于难以领会其重要性。唯有掌握了应用它的艺术，其意义与深度才会显现。我们首先在一致收敛性和高维概率的背景下给出这样的例子。

例 4.3（次高斯向量的范数 [475]）假设 $X \sim \mathcal{N}(0, \Sigma)$ 取值于 $\mathbb{R}^d$。$\|X\| \equiv \|X\|_2$ 的量级是多少？首先，根据 Jensen 不等式，我们得到

$$\mathbb{E}[\|X\|] \le \sqrt{\mathbb{E}[\|X\|^2]} = \sqrt{\operatorname{tr}\Sigma}\,.$$

但$\|X\|$的典型值呢，即我们能否展示一个以高概率成立的$\|X\|$上界？为了看看PAC-Bayes在这里如何有用，注意到$\|X\| = \sup_{\|v\|=1} v^\top X$。因此，我们旨在利用(4.33)来界定这个上确界。对于任意v，令$\rho_v = \mathcal{N}(v, \beta^2 I_d)$并注意$v^\top X = \mathbb{E}_{\rho_v}[\theta^\top X]$。我们还取$\pi = \mathcal{N}(0, \beta^2 I_d)$和$f_\theta(x) = \lambda\theta^\top x$，$\theta \in \mathbb{R}^d$，其中$\beta, \lambda > 0$是稍后优化的参数。取对数的底为$e$，我们显式计算$\psi(\theta) = \frac{1}{2}\lambda^2\theta^\top\Sigma\theta$，$\mathbb{E}_{\rho_v}[\psi(\theta)] = \frac{\lambda^2}{2}(v^\top\Sigma v + \beta^2 \operatorname{tr}\Sigma)$以及通过(2.8)得到的$D(\rho_v\|\pi) = \frac{\|v\|^2}{2\beta^2}$。因此，利用限制在$\rho_v$且$\|v\| = 1$的(4.33)，我们得到以概率$\ge 1-\delta$，对于所有满足$\|v\| = 1$的$v$

$$\lambda v^\top X \le \frac{\lambda^2}{2}(v^\top\Sigma v + \beta^2 \operatorname{tr}\Sigma) + \frac{1}{2\beta^2} + \ln\frac{1}{\delta}\,.$$

现在，我们可以通过选择$\beta^2 = 1/\sqrt{\lambda^2 \operatorname{tr}\Sigma}$ 来优化右侧关于 β 的表达式，从而得到

$$\lambda v^\top X \le \frac{\lambda^2}{2}(v^\top\Sigma v) + \lambda\sqrt{\operatorname{tr}\Sigma} + \ln\frac{1}{\delta}\,.$$

最后，估计 $v^\top\Sigma v \le \|\Sigma\|_{op}$ 并优化 λ，我们得到高概率界的结果：

$$\|X\| \le \sqrt{\operatorname{tr}\Sigma} + \sqrt{2\|\Sigma\|_{op}\ln\frac{1}{\delta}}\,.$$

虽然可以使用切尔诺夫界（第15.1节）的标准技术获得此结果——对于更强版本，参见[270，引理1]，或对于基于复杂高斯集中不等式的一般范数，参见[69，例5.7]——但PAC-Bayes证明的优势在于：(a) 它不特定于高斯分布，并且对于任何满足X且$\psi(\theta) \le \frac{\lambda^2}{2}\theta^\top\Sigma\theta$ (类似于下文介绍)的次高斯随机变量的X都成立；(b) 其扩展可用于分析样本协方差矩阵的集中性，参见[475]。

为了展示更多的应用，我们需要引入一个新的概念。

定义 4.15（次高斯随机变量）如果　　随机变量称为 σ^2-次高斯

$$\mathbb{E}[e^{\lambda(X-\mathbb{E}[X])}] \le e^{\frac{\sigma^2\lambda^2}{2}} \qquad \forall\lambda \in \mathbb{R}\,.$$

以下是一些有用的观察结果：

• $\mathcal{N}(0, \sigma 2)$ 是 σ^2-次高斯。事实上，它以等式满足该条件，并解释了此名称的由来。• 如果 $X \in [a, b]$，则 X 是 $\frac{(b-a)^2}{4}$-次高斯。这是著名的霍夫丁引理（证明见习题 III.22）。• 如果 X_i 是独立同分布且 σ^2-次高斯，那么经验平均 $S_n = \frac{1}{n}\sum_{i=1}^n X_i$ 是 (σ^2/n)-次高斯。

定义次高斯性有许多等价的方法[438, 命题 2.5.2]，包括要求 X 的尾部满足 $\mathbb{P}[|X - \mathbb{E}[X]| > t] \le 2e^{-\frac{t^2}{2\sigma^2}}$。然而，对我们来说最重要的性质是上述两个观察的结果：独立有界随机变量的经验平均是 $O(1/n)$-次高斯的。

次高斯性的概念在 PAC-Bayes 方法中如下使用。假设我们有一组从 $\mathcal{X}$ 到 $\mathbb{R}$ 的函数 $\mathcal{F}$，以及一个独立同分布样本 $X^n \overset{\text{i.i.d.}}{\sim} P_X$。*empirical process theory* 和一致收敛的主要问题之一是对 得到高概率界。

$$\sup_{f\in\mathcal{F}} \mathbb{E}[f(X)] - \hat{\mathbb{E}}_n[f(X)]\,, \qquad \hat{\mathbb{E}}_n[f(X)] \triangleq \frac{1}{n}\sum_{i=1}^n f(X_i)\,.$$

假设我们知道每个 f 取值在 $[0, 1]$ 中。那么 $(\mathbb{E} - \hat{\mathbb{E}}_n)f$ 是 $\frac{1}{4n}$-次高斯分布，并且将 PAC-Bayes 不等式应用于函数 $\lambda(\mathbb{E} - \hat{\mathbb{E}}_n)f(X)$，我们得到以概率 $\ge 1 - \delta$，对于 $\mathcal{F}$ 上的任意 ρ，我们有

$$\mathbb{E}_{f\sim\rho}[(\mathbb{E} - \hat{\mathbb{E}}_n)f(X)] \le \frac{\lambda}{8n} + \frac{1}{\lambda}D(\rho\|\pi) + \ln\frac{1}{\delta}\,,$$

其中 π 是一个固定的先验。此方法可用于获得可数无限集合 $\mathcal{F}$ (的有趣界限，参见练习 I.55 和 I.56)。然而，该方法的真正威力在于当 $\mathcal{F}$ 不可数时（如前面关于高斯范数的例子所示）。

我们注意到，对由连续参数索引的随机过程（例如经验过程或高斯过程）的上确界进行界定是一个广泛的主题[139, 429, 431]。通常的方法基于离散化和逼近（更高级的版本称为链式；参见(27.22)和练习V.28中关于高斯过程的对应内容）。PAC-Bayes不等式提供了一种替代方法，通常可以得到更尖锐的结果和更短的证明。它也有在高维概率（小球概率和随机矩阵理论）中的应用，参见[317, 309]。在这些工作中，PAC-Bayes被应用时，π是小球上的均匀分布。

备注 4.6（PAC-Bayes 与 Rademacher 复杂度）注意 PAC-Bayes 界定了一个经验过程的上确界。实际上，对于任何值 Y，我们可以将 $\theta \mapsto f_\theta(Y)$ 视为由 $\theta \in \Theta$ 索引的向量（随机过程）。每个 $\rho \in \mathcal{P}(\Theta)$ 定义了这个向量的一个线性函数 $F(\rho) \triangleq \mathbb{E}_{\theta\sim\rho}[f_\theta(Y)]$。一种现代的界定一组函数上确界的方法[38]是使用 *Rademacher complexity*。结果表明，PAC-Bayes 可以在该框架中相当自然地理解：如果 $|f_\theta(\cdot)| \le M$，那么集合 $\{F(\rho) : D(\rho\|\pi) \le C < \infty\}$ 具有 Rademacher 复杂度

$O(M\sqrt{\frac{c}{n}})$，见[239]。事实上，他们证明了只要G是强凸的，任何集合$\{F(\rho)\colon G(\rho)\le C\}$都满足这个界。回忆一下，根据练习I.37，$\rho\mapsto D(\rho\|\pi)$确实是强凸的。

4.8.2 统计学习理论中的泛化边界

引入PAC-Bayes的最初目的是为了分析学习算法。我们首先介绍学习理论的标准（PAC）设定。

假设可以访问一个训练样本$X^n=(X_1,\dots,X_n)\overset{\text{i.i.d.}}{\sim}P$，并且存在一个参数空间$\Theta$。目标是找到使估计误差（损失）最小化的$\theta\in\Theta$。具体而言，由某个参数$\theta\in\Theta$索引的估计器在数据点$X_i$上产生的损失由$\ell_\theta(X_i)$给出。学习算法旨在找到*test loss*（的最小化者，也称为测试误差或泛化风险），即

$$L(\theta)\triangleq\mathbb{E}[\ell_\theta(X_{new})]\,,\qquad X_{new}\sim P\,.$$

请注意，由于P未知，直接最小化$L(\theta)$是不可能的。这一设定涵盖了机器学习和统计学中的许多问题。例如，我们可能有$X_i=(Y_i,Z_i)$，其中Z_i是特征（协变量），Y_i是标签（响应），损失函数在分类中为$1\{Y_i=f_\theta(Z_i)\}$（，在回归中为$(Y_i-f_\theta(Z_i))^2$（，而f_θ例如是线性预测器$\theta^\top Z_i$或带有权重θ的深度神经网络。或者（如例4.2所示），我们可能试图通过在一类参数化密度上优化交叉熵损失$\log\frac{1}{p_\theta(X)}$来估计分布$P$本身。

正如我们提到的，$L(\theta)$的值对于学习器来说是不可计算的。可计算的是*training error*（或经验风险），即

$$\hat{L}_n(\theta)\triangleq\frac{1}{n}\sum_{i=1}^n\ell_\theta(X_i)\,.$$

那么一个人如何 在给定训练样本X^n的情况下，如何选择一个好的估计值$\hat{\theta}$？这里有两个

• 经验风险最小化（ERM）：$\hat{\theta}_{\text{ERM}}=\operatorname{argmin}_{\theta\in\Theta}\hat{L}_n(\theta)$ • Gibbs采样器：固定某个$\lambda>0$。给定Θ上的某个先验分布π，从“后验”中抽取$\hat{\theta}$

$$\rho(d\theta)\propto\pi(d\theta)e^{-\lambda\hat{L}_n(\theta)}\tag{4.36}$$

在$\lambda\to\infty$的极限下，这简化为经验风险最小化。注意，在这种情况下，$\hat{\theta}$是X^n的随机函数。

然而，针对特定问题，每天都在发明许多其他选择。

理论要解决的主要问题如下：选择$\hat{\theta}$是由样本X^n引导的，因此值$\hat{L}_n(\hat{\theta})$可能无法代表估计器在新样本X_{new}上达到的值$L(\hat{\theta})$，原因是对训练样本的过拟合。为了衡量过拟合的程度，人们试图证明如下形式的估计：

$$L(\hat{\theta})\le\hat{L}_n(\hat{\theta})+\text{small error terms}$$

在样本 X^n 上以高概率成立。注意，这里的 $\hat{\theta}$ 可以是训练样本的确定性函数（如 ERM 中）或随机化函数（如 Gibbs 中）。无论哪种情况，将估计量视为从依赖于数据的分布 ρ 中抽取的 θ 都是方便的，换句话说，即从 X^n 到 θ 的一个信道，因此我们始终将 $L(\hat{\theta})$ 理解为 $\mathbb{E}_\rho[L(\theta)]$，将 $\hat{L}_n(\hat{\theta})$ 理解为 $\mathbb{E}_\rho[\hat{L}_n(\theta)]$。注意，无论哪种情况，值 $L(\hat{\theta})$ 和 $\hat{L}_n(\hat{\theta})$ 都是依赖于样本 X^n 的随机量。

我们将展示的一种特定类型的界是一个高概率界，它保持 *uniformly over all data-dependent* ρ，具体来说

$$\mathbb{P}\left[\forall \rho : \mathbb{E}_{\theta\sim\rho}[L(\theta)] \le \mathbb{E}_{\theta\sim\rho}[\hat{L}_n(\theta)] + \text{excess risk}(\rho)\right] \ge 1-\delta,$$

对于取决于 (n,ρ,δ) 的某种超额风险。我们强调，这里的概率是关于 $X^n \overset{\text{i.i.d.}}{\sim} P$ 的，并且量词“$\forall\rho$”位于概率内部。拥有这样的统一界建议选择使不等式右侧最小化的 ρ，从而使第二项起到防止过拟合的 *regularization term* 的作用。

本节的主要定理是 McAllester [298] 中 *generalization error bound* 的以下版本。存在许多其他类似的界，例如见练习 I.54。

定理 4.16 *Fix a reference distribution* π *on* Θ *and suppose that for all* θ, x *the loss* $\ell_\theta(x) \in [0,1]$. *Then for any* $\delta \le e^{-1}$

$$\mathbb{P}\left[\forall \rho : \mathbb{E}_{\theta\sim\rho}[L(\theta)] \le \mathbb{E}_{\theta\sim\rho}[\hat{L}_n(\theta)] + \frac{5}{4}\sqrt{\frac{D(\rho\|\pi) + \ln\frac{1}{\delta}}{2n}} + \frac{1}{\sqrt{10n}}\right] \ge 1-\delta. \tag{4.37}$$

The same result holds if (instead of being bounded) $\ell_\theta(X)$ *is* $\frac{1}{4}$*-subgaussian for each* θ.

在证明该定理之前，让我们考虑一个有限类 Θ 并论证

$$\mathbb{P}\left[\forall \rho : \mathbb{E}_{\theta\sim\rho}[L(\theta)] \le \mathbb{E}_{\theta\sim\rho}[\hat{L}_n(\theta)] + \sqrt{\frac{1}{2n}\ln\frac{M}{\delta}}\right] \ge 1-\delta, \tag{4.38}$$

事实上，根据线性性质，只需考虑点质量分布 $\rho = \delta_\theta$。对于每个 θ，随机变量 $\hat{L}_n(\theta) - L(\theta)$ 是零均值且 $\frac{1}{4n}$-次高斯的（Hoeffding引理）。因此，对 $e^{\lambda(L(\theta)-\hat{L}_n(\theta))}$ 应用马尔可夫不等式，对于任意 $\lambda > 0$ 和 $t > 0$，我们有：

$$\mathbb{P}[L(\theta) - \hat{L}_n(\theta) \ge t] \le e^{\frac{\lambda^2}{8n} - \lambda t}.$$

因此，通过设定t使得右侧等于$\frac{\delta}{M}$，根据联合界，我们得到在概率为$\ge 1-\delta$的情况下，同时对于所有的θ，有

$$L(\theta) - \hat{L}_n(\theta) \le \frac{\lambda}{8n} + \frac{1}{\lambda}\ln\frac{M}{\delta}.$$

优化 $\lambda = \sqrt{8n\ln\frac{M}{\delta}}$ 得到 (4.38)。另一方面，如果我们应用 (4.37) 并设 $\pi = \text{Unif}(\Theta)$，且观察到 $D(\rho\|\pi) \le \log M$，我们就能恢复 (4.38)，只是超额风险的估计稍差一些。

我们可以看到，正如前一小节一样，展示定理4.16的核心问题在于联合界仅适用于有限的Θ，我们需要利用PAC-Bayes不等式来绕过这个问题。

Proof. 首先，我们固定 λ 并对函数 $f_\theta(X^n) = \lambda(L(\theta) - \hat{L}_n(\theta))$ 应用 PAC-Bayes 不等式。根据 Hoeffding 引理，我们知道 $\hat{L}_n(\theta)$ 是$\frac{1}{8n}$-次高斯分布，因此 $\psi(\theta) \le \frac{\lambda^2}{8n}$。于是，对于所有 ρ，我们以概率 $\ge 1-\delta$ 同时有：

$$\mathbb{E}_\rho[L(\theta) - \hat{L}_n(\theta)] \le \frac{\lambda}{8n} + \frac{D(\rho\|\pi) + \ln\frac{1}{\delta}}{\lambda} \tag{4.39}$$

为方便起见，我们记 $b(\rho) = D(\rho\|\pi) + \ln\frac{1}{\delta}$。由于 $\delta < e^{-1}$，我们看到 $b(\rho) \ge 1$。我们希望通过设置 $\lambda = \lambda^* \triangleq \sqrt{8nb(\rho)}$ 来优化 (4.39) 中的 λ。然而，当然，λ 不能依赖于 ρ。因此，我们改为选择一个可数网格 $\lambda_i = \sqrt{2n}2^i, i \ge 1$，并对每个 λ_i 分别应用 PAC-Bayes 不等式，概率选为 $\delta_i = \delta 2^{-i}$。然后由联合界，我们对所有 ρ 和所有 $i \ge 1$ 同时有：

$$\mathbb{E}_\rho[L(\theta) - \hat{L}_n(\theta)] \le \frac{\lambda_i}{8n} + \frac{b(\rho) + i\ln 2}{\lambda}\,.$$

令 $i^* = i^*(\rho)$ 选择为使 $\lambda^*(\rho) \le \lambda_{i^*} < 2\lambda^*(\rho)$。由后一不等式我们得到 $\sqrt{2n}2^{i^*} < 2\sqrt{8b(\rho)n}$，因此

$$i^*\ln 2 < \ln 4 + \frac{1}{2}\ln(b(\rho)) \le \ln 4 - 1/2 + \frac{1}{2}b(\rho)\,.$$

因此，在边界中选择 $i = i^*$，将 $\lambda_{i^*} \le 2\lambda^*$ 和$\frac{1}{\lambda_{i^*}} \le \frac{1}{\lambda^*}$上界，我们得到对于所有 ρ

$$\mathbb{E}_\rho[L(\theta) - \hat{L}_n(\theta)] \le \sqrt{\frac{b(\rho)}{8n}}(2 + \frac{3}{2}) + \frac{\ln 4 - 1/2}{\sqrt{8nb(\rho)}}\,.$$

最后，由于 $b \ge 1$)，用$\frac{1}{\sqrt{10n}}$ (对最后一项进行界定，我们得到该定理。 □

我们注意到，尽管我们证明了一个优化（关于 λ）的界，但中间结果（4.39）也相当重要。实际上，它建议选择 ρ (随机估计量)，基于最小化正则化经验风险 $\mathbb{E}_\rho \hat{L}_n(\theta) + \frac{1}{\lambda}D(\rho\|\pi)$。最小化 ρ 正是由命题4.7得出的吉布斯采样器（4.36），这证明了它的流行性。

PAC-Bayes 界常常因以下理由而受到批评。假设我们取一个神经网络并训练它（也许通过使用某种版本的梯度下降），直到它找到某个权重矩阵的选择 $\hat{\theta}$，使得 $\hat{L}_n(\hat{\theta})$ 的值低到可以接受。我们现在希望应用 PAC-Bayes 定理 4.16 来使我们确信测试损失 $L(\hat{\theta})$ 也会很小。但请注意，神经网络的权重是非随机的，即 $\rho = \delta_{\hat{\theta}}$，因此对于任何连续先验 π，我们都会有 $D(\rho\|\pi) = \infty$，从而导致一个空洞的界。有一段时间，这被认为是不可避免的局限，直到 [476] 的一项优雅工作。作者们认为，归根结底，神经网络的权重是以有限位近似（浮点数）存储的，我们可以使用 $\pi(\theta) = 2^{-\text{length}(\theta)}$ 作为先验。这里 length(θ) 表示 θ 的压缩表示中的总位数。正如我们将在第二部分中学到的，这确实定义了一个有效的概率

分布（对于任何无损压缩器的选择）。通过这种方式，[476]中的想法搭建了数据压缩与泛化边界之间的桥梁：如果训练后的神经网络高度可压缩θ (例如，有许多零权重)那么它的超额风险较小，因此更不容易过拟合。

在结束本节之前，我们还应应用PAC-贝叶斯(4.34)的“期望”版本。即，再次假设损失$\ell_\theta(x)$位于[0, 1]区间内，并假设学习算法（给定X^n）选择ρ，然后抽样得到$\hat{\theta} \sim \rho$。这形成了一个联合分布$P_{\hat{\theta},X^n}$。根据(4.34)，如前述证明，对于每个$\lambda >>0$，我们得到

$$\mathbb{E}[L(\hat{\theta}) - \hat{L}_n(\hat{\theta})] \leq \frac{\lambda}{8n} + \lambda I(\hat{\theta}; X^n)\,.$$

对 λ 进行优化，我们得到界限

$$\mathbb{E}[L(\hat{\theta}) - \hat{L}_n(\hat{\theta})] \leq \sqrt{\frac{1}{2n} I(\hat{\theta}; X^n)}\,.$$

这个版本的McAllester结果[369, 461]提供了一个有用的直观理解：算法过拟合的倾向可以通过从X^n泄露到$\hat{\theta}$的信息量来衡量。然而，在实际应用中，如定理4.16所示，采用灵活参考先验π的版本似乎更为便捷。

5 互信息的极值化：容量鞍点

信息论中出现了四个基本的优化问题：

• 信息投影（或 I 投影）：给定 Q，在 P 类的凸集上最小化 $D(P\|Q)$。（见第 15 章。）• 最大似然：给定 P，在 Q 的某个类上最小化 $D(P\|Q)$。（见第 29.3 节。）• 率失真：给定 P_X，在 $P_{Y|X}$ 的凸类上最小化 $I(X;Y)$。（见第 26 章。）• 容量：给定 $P_{Y|X}$，在 P_X 的凸类上最大化 $I(X;Y)$。（本章。）

在本章中，我们展示所有这些问题的目标函数均为凸/凹函数，讨论求解它们的迭代算法，并更详细地研究容量问题。具体而言，我们会发现，关于输入分布P_X的上确界也可以写成关于输出分布P_Y的下确界，由此产生的极小极大问题具有鞍点。这将引导我们将容量理解为以KL散度度量的一组条件分布$\{P_{Y|X=x}, x \in \mathcal{X}\}$的信息半径。

5.1 信息度量的凸性

定理5.1 *The map* $(P,Q) \mapsto D(P\|Q)$ *is convex.*

Proof. 设 $P_X = Q_X =$ 属于 Ber(λ)，并定义两个条件核：

$$P_{Y|X=0} = P_0, \quad P_{Y|X=1} = P_1$$
$$Q_{Y|X=0} = Q_0, \quad Q_{Y|X=1} = Q_1$$

一个显式计算表明，

$$D(P_{X,Y}\|Q_{X,Y}) = \bar{\lambda}D(P_0\|Q_0) + \lambda D(P_1\|Q_1)\,.$$

因此，从DPI（单调性）我们得到：

$$\bar{\lambda}D(P_0\|Q_0) + \lambda D(P_1\|Q_1) = D(P_{X,Y}\|Q_{X,Y}) \geq D(P_Y\|Q_Y) = D(\bar{\lambda}P_0 + \lambda P_1\|\bar{\lambda}Q_0 + \lambda Q_1).$$

□

注5.1 证明表明，对于任意相似度度量$\mathcal{D}(P\|Q)$，$(P,Q) \mapsto \mathcal{D}(P\|Q)$ 的凸性等价于$\mathcal{D}$的“条件增加散度”性质。凸性也可以理解为“混合减少散度”。

注5.2（严格凸性与强凸性）存在多种可能的替代论证。例如，$(p,q) \mapsto p \log \frac{p}{q}$ 在 $\mathbb{R}_+^2$ 上是凸的，这是一般现象的一种体现：对于凸的 $f(\cdot)$，*perspective* 函数 $(p,q) \mapsto qf\left(\frac{p}{q}\right)$ 也是凸的。另一种方式是引用Donsker-Varadhan变分表示定理4.6，并注意到凸函数的上确界是凸的。然而，我们的证明使我们能够立即注意到映射 $(P,Q) \mapsto D(P\|Q)$ 不是 *strictly convex*。实际上，我们在证明中使用的DPI中的间隙等于 $D(P_{X|Y}\|Q_{X|Y}|P_Y)$，它可以为零。例如，当 P_0, Q_0 具有共同支撑集，且该支撑集与 P_1, Q_1 的共同支撑集不相交时，就会发生这种情况。与此同时，映射 $P \mapsto D(P\|Q)$，其凸性在上一章中至关重要，结果不仅被证明是严格凸的，而且实际上关于全变差是 *strongly convex*，参见练习I.37。这种强凸性对于分析 *mirror descent* 算法至关重要，该算法是一种用于概率测度优化的一阶方法（见[40，示例9.10和5.27]）。

定理 5.2 *The map $P_X \mapsto H(X)$ is concave. Furthermore, if $P_{Y|X}$ is any channel, then $P_X \mapsto H(X|Y)$ is concave. If $\mathcal{X}$ is finite, then $P_X \mapsto H(X|Y)$ is continuous.*

Proof. 对于第一个命题的特殊情形，当 P_X 处于有限字母表上时，证明由 $H(X) = \log|\mathcal{X}| - D(P_X\|U_X)$ 完成。更一般地，我们按如下方式证明第二个命题。令 $f(P_X) = H(X|Y)$。引入随机变量 $U \sim \text{Ber}(\lambda)$ 并定义变换

$$P_{X|U} = \begin{cases} P_0 & U = 0 \\ P_1 & U = 1 \end{cases}$$

考虑概率空间 $U \to X \to Y$。那么我们有 $f(\lambda P_1 + (1-\lambda)P_0) = H(X|Y)$ 和 $\lambda f(P_1) + (1-\lambda)f(P_0) = H(X|Y,U)$。由于 $H(X|Y,U) \le H(X|Y)$，证明完成。连续性由命题4.13推出。 □

回想一下 $I(X;Y)$ 是 $P_{X,Y}$ 的函数，或者等价地，$(P_X, P_{Y|X})$。记作 $I(P_X, P_{Y|X}) = I(X;Y)$。

定理 5.3（互信息）

- *For fixed $P_{Y|X}$, $P_X \mapsto I(P_X, P_{Y|X})$ is concave.*
- *For fixed P_X, $P_{Y|X} \mapsto I(P_X, P_{Y|X})$ is convex.*

Proof. 有几种方法可以证明第一个陈述，每种方法都有其优点。

• *First proof*：引入 $\theta \in \text{Ber}(\lambda)$。定义 $P_{X|\theta=0} = P_X^0$ 和 $P_{X|\theta=1} = P_X^1$。然后 $\theta \to X \to Y$。然后 $P_X = \bar{\lambda}P_X^0 + \lambda P_X^1$。$I(X;Y) = I(X,\theta;Y) = I(\theta;Y) + I(X;Y|\theta) \ge I(X;Y|\theta)$，即我们所需的 $I(\bar{\lambda}P_X^0 + \lambda P_X^1, P_{Y|X}) \ge \bar{\lambda}I(P_X^0, P_{Y|X}) + \lambda I(P_X^0, P_{Y|X})$。• *Second proof*：$I(X;Y) = \min_Q D(P_{Y|X}\|Q|P_X)$，这是 P_X 中仿射函数的逐点最小值，因此是凹的。

- *Third proof*：选择Q并使用黄金公式：$I(X;\ Y) = D(P_{Y|X}\|Q|P_X) - D(P_Y\|Q)$，其中$P_X \mapsto D(P_Y\|Q)$是凸的，作为$P_X \mapsto P_Y$ (仿射)和$P_Y \mapsto D(P_Y\|Q)$(凸)的复合。

为了证明第二个（凸性）命题，只需注意到

$$I(X;Y) = D(P_{Y|X}\|P_Y|P_X)\,.$$

参数 P_Y 是 $P_{Y|X}$ 的线性函数，因此该结论由 D 在配对中的凸性得出。

□

回顾：极小极大值和鞍点

假设我们有一个二元函数 f。那么我们总是有 *minimax inequality*：

$$\inf_y \sup_x f(x,y) \geq \sup_x \inf_y f(x,y).$$

它在什么时候取等号?

1 事实证明，鞍点的存在（x^*, y^*）意味着极小极大等式成立，即，

$$f(x,y^*) \leq f(x^*,y^*) \leq f(x^*,y) \qquad \forall x,y$$

此外，若下确界和上确界均可达到，则极小极大等式也意味着鞍点的存在（参见[49, 第2.6节]）对所有x, y而言[直接验证即可。参见下文推论的证明]。

2 有若干已知的标准确立

$$\inf_y \sup_x f(x,y) = \sup_x \inf_y f(x,y)$$

它们通常要求f的某种连续性、域的紧致性以及在x中的凹性和在y中的凸性。其中最普遍的版本之一归功于M. Sion [389]。

3 所有这些极小极大理论的核心结果是冯·诺依曼关于双线性函数的定理：设A和B具有有限字母表，且$g(a,b)$为任意，则

$$\min_{P_A} \max_{P_B} \mathbb{E}[g(A,B)] = \max_{P_B} \min_{P_A} \mathbb{E}[g(A,B)]$$

这里（x, y）$\leftrightarrow (P_A, P_B)$和$f(x,y) \leftrightarrow \sum_{a,b} P_A(a)P_B(b)g(a,b)$。

一个更通用的版本是：如果$\mathcal{X}$和$\mathcal{Y}$是$\mathbb{R}^n$中的紧凸域，$f(x,y)$在(x,y)上连续，在x中凹，在y中凸，那么

$$\max_{x\in\mathcal{X}} \min_{y\in\mathcal{Y}} f(x,y) = \min_{y\in\mathcal{Y}} \max_{x\in\mathcal{X}} f(x,y)$$

5.2 互信息的鞍点

以下结果是分析互信息在输入分布的凸集上的最大值的基石。我们将在本节中立即看到其应用，以及本书后面章节（在信道编码、序列预测、通用数据压缩和密度估计中）中的更多应用。

定理5.4（鞍点）*Let $\mathcal{P}$ be a convex set of distributions on $\mathcal{X}$. Suppose there exists $P_X^* \in \mathcal{P}$, called a*达到容量的输入分布*, such that*

$$\sup_{P_X \in \mathcal{P}} I(P_X, P_{Y|X}) = I(P_X^*, P_{Y|X}) \triangleq C.$$

Let $P_Y^* = P_{Y|X} \circ P_X^*$, called a 达到容量的输出分布*. Then for all $P_X \in \mathcal{P}$ and for all Q_Y, we have*

$$D(P_{Y|X}\|P_Y^*|P_X) \le D(P_{Y|X}\|P_Y^*|P_X^*) \le D(P_{Y|X}\|Q_Y|P_X^*). \tag{5.1}$$

Proof. (5.1) 中的右侧不等式源自 $C = I(P_X^*, P_{Y|X}) = \min_{Q_Y} D(P_{Y|X}\|Q_Y|P_X^*)$，其中后者是 (4.5)。

(5.1)中的左侧不等式在$C = \infty$时是平凡的。因此假设$C < \infty$，从而对所有$P_X \in \mathcal{P}$有$I(P_X, P_{Y|X}) < \infty$。令$P_{X_\lambda} = \lambda P_X + \bar{\lambda} P_X^* \in \mathcal{P}$和$P_{Y_\lambda} = P_{Y|X} \circ P_{X_\lambda}$。显然，$P_{Y_\lambda} = \lambda P_Y + \bar{\lambda} P_Y^*$，其中$P_Y = P_{Y|X} \circ P_X$。

我们于是有如下链:

$$\begin{aligned} C \ge I(X_\lambda; Y_\lambda) &= D(P_{Y|X}\|P_{Y_\lambda}|P_{X_\lambda}) \\ &= \lambda D(P_{Y|X}\|P_{Y_\lambda}|P_X) + \bar{\lambda} D(P_{Y|X}\|P_{Y_\lambda}|P_X^*) \\ &\ge \lambda D(P_{Y|X}\|P_{Y_\lambda}|P_X) + \bar{\lambda} C \\ &= \lambda D(P_{X,Y}\|P_X P_{Y_\lambda}) + \bar{\lambda} C, \end{aligned}$$

其中不等式由（5.1）的右侧部分（已证明）得出。因此，减去$\bar{\lambda}C$并除以λ，我们得到

$$D(P_{X,Y}\|P_X P_{Y_\lambda}) \le C$$

并通过取 $\liminf_{\lambda \to 0}$ 并应用散度的下半连续性（定理4.9），证明得以完成。

□

推论 5.5 *In addition to the assumptions of Theorem 5.4, suppose $C < \infty$. Then the capacity-achieving output distribution P_Y^* is unique. It satisfies the property that for any P_Y induced by some $P_X \in \mathcal{P}$ (i.e. $P_Y = P_{Y|X} \circ P_X$) we have*

$$D(P_Y\|P_Y^*) \le C < \infty \tag{5.2}$$

and in particular $P_Y \ll P_Y^*$.

Proof. 该陈述是：$I(P_X, P_{Y|X}) = C \Rightarrow P_Y = P_Y^*$。确实：

$$\begin{aligned} C = D(P_{Y|X}\|P_Y|P_X) &= D(P_{Y|X}\|P_Y^*|P_X) - D(P_Y\|P_Y^*) \\ &\le D(P_{Y|X}\|P_Y^*|P_X^*) - D(P_Y\|P_Y^*) \\ &= C - D(P_Y\|P_Y^*) \Rightarrow P_Y = P_Y^* \end{aligned}$$

陈述（5.2）由（5.1）中的左侧不等式及定理2.16中的“条件作用增加散度”性质得出。 □

备注 5.3 • C 的有限性对于推论 5.5 成立是必要的。作为反例，考虑恒等信道 $Y = X$，其中 X 在整数上取值。那么任何具有无限熵的分布都是达到容量的输入（和输出）分布。• 与输出分布不同，达到容量的输入分布不必唯一。例如，考虑 $Y_1 = X_1 \oplus Z_1$ 和 $Y_2 = X_2$，其中 $Z_1 \sim \mathrm{Ber}(\frac{1}{2})$ 独立于 X_1。那么 $\max_{P_{X_1X_2}} I(X_1, X_2; Y_1, Y_2) = \log 2$，由 $P_{X_1X_2} = \mathrm{Ber}(p) \times \mathrm{Ber}(\frac{1}{2})$ 对任意 p 达到。注意达到容量的 *output* 分布是唯一的：$P^*_{Y_1Y_2} = \mathrm{Ber}(\frac{1}{2}) \times \mathrm{Ber}(\frac{1}{2})$。

将定理5.4应用于条件散度，得到以下结果。

推论 5.6 (极小极大) *Under the assumptions of Theorem 5.4, we have*

$$\begin{aligned} \max_{P_X \in \mathcal{P}} I(X;Y) &= \max_{P_X \in \mathcal{P}} \min_{Q_Y} D(P_{Y|X}\|Q_Y|P_X) \\ &= \min_{Q_Y} \sup_{P_X \in \mathcal{P}} D(P_{Y|X}\|Q_Y|P_X) \end{aligned}$$

Proof. 这源于鞍点的标准性质：最大化/最小化(5.1)最左/最右侧得到

$$\begin{aligned} \text{最小化}_{P_X \in \mathcal{P}} D(P_{Y|X}\|P_Y|P_X) &= \text{上确界}_{P_X \in \mathcal{P}} D(P_{Y|X}\|P_Y^*|P_X) \le \text{最大化} \\ &\le \text{最小}_{Q_Y} D(P_{Y|X}\|Q_Y|P_X^*) \le \text{最大}_{P_X \in \mathcal{P}} \text{最小} \end{aligned}$$

但根据定义，最小最大≥最大最小。请注意，我们仅在已知最优解可达的情况下谨慎使用最大和最小。 □

复习：半径和直径

令 (X, d) 为一个度量空间。令 A 为一个有界子集。

1 *Radius* (又称切比雪夫半径)，指的是覆盖A的最小球的半径，即，

$$\operatorname{rad}(A) = \inf_{y \in X} \sup_{x \in A} d(x, y). \tag{5.3}$$

2 第 *Diameter* 个，共 A 个：

$$\operatorname{diam}(A) = \sup_{x,y \in A} d(x, y). \tag{5.4}$$

注意，半径和直径都衡量集合的庞大性/丰富度。

3 根据定义和三角不等式，我们有

$$\frac{1}{2}\operatorname{diam}(A) \le \operatorname{rad}(A) \le \operatorname{diam}(A). \tag{5.5}$$

当 A 分别为欧几里得球和汉明空间时，分别达到下界和上界。

4 在许多特殊情况下，(5.5)中的上界可以改进为：

• Bohnenblust [67] 的一个结果表明，在配备任意范数的 $\mathbb{R}^n$ 中，我们总有 rad$(A) \le \frac{n}{n+1}\operatorname{diam}(A)$。• 对于具有欧几里得距离的 $\mathbb{R}^n$，Jung 证明了 rad$(A) \le \sqrt{\frac{n}{2(n+1)}}\operatorname{diam}(A)$，且可由单纯形达到。最佳常数有时称为该空间的 Jung 常数。• 对于具有 ℓ_∞-范数的 $\mathbb{R}^n$，情况甚至更简单：rad$(A) = \frac{1}{2}\operatorname{diam}(A)$；这样的空间称为可中心化的。

5.3 容量作为信息半径

下一个简单的推论表明，当距离以散度衡量（尽管我们提醒，散度并非度量），信道的容量（马尔可夫核）恰好是一组有限分布$\{P_{Y|X=x}\colon\ x \in \mathcal{X}\}$的半径。

推论 5.7 *For any finite $\mathcal{X}$ and any kernel $P_{Y|X}$, the maximal mutual information over all distributions P_X on $\mathcal{X}$ satisfies*

$$\begin{aligned}\max_{P_X} I(X;Y) &= \max_{x \in \mathcal{X}} D(P_{Y|X=x} \| P_Y^*) \\ &= D(P_{Y|X=x} \| P_Y^*) \qquad \forall x : P_X^*(x) > 0\,.\end{aligned}$$

最后一个推论给出了容量的几何解释：它等于包含所有分布 $\{P_{Y|X=x}:\ x\in\mathcal{X}\}$ 的最小散度“球”的半径。此外，最优中心 P_Y^* 是某些 $P_{Y|X=x}$ 的凸组合，并且与那些 *equidistant*
。

以下是任意输入空间的“半径 $\le$ 直径”（在KL散度下）的信息论版本（相关表示见定理32.4）：

推论 5.8 *Let $\{P_{Y|X=x}:\ x\in\mathcal{X}\}$ be a set of distributions. Then*

$$C=\sup_{P_X} I(X;Y)\le \underbrace{\inf_Q \sup_{x\in\mathcal{X}} D(P_{Y|X=x}\|Q)}_{\text{radius}}\le \underbrace{\sup_{x,x'\in\mathcal{X}} D(P_{Y|X=x}\|P_{Y|X=x'})}_{\text{diameter}}$$

Proof. 根据黄金公式推论4.2，我们有

$$I(X;Y)=\inf_Q D(P_{Y|X}\|Q|P_X)\le \inf_Q \sup_{x\in\mathcal{X}} D(P_{Y|X=x}\|Q)\le \inf_{x'\in\mathcal{X}} \sup_{x\in\mathcal{X}} D(P_{Y|X=x}\|P_{Y|X=x'}).$$

□

5.4* 达到容量输出分布的存在性（一般信道）

在上一节中，我们已经展示了该解决方案

$$C=\sup_{P_X\in\mathcal{P}} I(X;Y)$$

可以被 (a) 解释为一个鞍点；(b) 写成极小极大形式；(c) 容量达成的输出分布 P_Y^* 是唯一的。这一切都是在额外假设 P_X 上的上确界可达成的条件下完成的。事实证明，性质 b) 和 c) 可以在没有该额外假设的情况下被证明。

定理5.9（Kemperman [243]）*For any $P_{Y|X}$ and a convex set of distributions $\mathcal{P}$ such that*

$$C=\sup_{P_X\in\mathcal{P}} I(P_X,P_{Y|X})<\infty, \tag{5.6}$$

there exists a unique P_Y^* with the property that

$$C=\sup_{P_X\in\mathcal{P}} D(P_{Y|X}\|P_Y^*|P_X)\,. \tag{5.7}$$

Furthermore,

$$\begin{aligned} C&=\sup_{P_X\in\mathcal{P}}\min_{Q_Y} D(P_{Y|X}\|Q_Y|P_X) && (5.8)\\ &=\min_{Q_Y}\sup_{P_X\in\mathcal{P}} D(P_{Y|X}\|Q_Y|P_X) && (5.9)\\ &=\min_{Q_Y}\sup_{x\in\mathcal{X}} D(P_{Y|X=x}\|Q_Y)\,, \qquad (\textit{if } \mathcal{P}=\{\textit{all } P_X\}.) && (5.10)\end{aligned}$$

请注意，如果存在一个 Q_Y 使得，则条件 (5.6) 自动满足

$$\sup_{P_X\in\mathcal{P}} D(P_{Y|X}\|Q_Y|P_X) < \infty\,. \tag{5.11}$$

示例5.1（不存在容量达到输入分布）令$Z\sim\mathcal{N}(0,1)$并考虑该问题

$$C = \sup_{\substack{P_X:\mathbb{E}[X]=0,\mathbb{E}[X^2]=P\\ \mathbb{E}[X^4]=s}} I(X;X+Z)\,. \tag{5.12}$$

如果没有约束 $\mathbb{E}[X^4]=s$，则在输入分布 $P_X=\mathcal{N}(0,P)$ 下唯一达到容量；见定理 5.11。当 $s\neq 3P^2$ 时，这样的 P_X 不再可行。然而，对于 $s>3P^2$，最大值

$$C=\frac{1}{2}\log(1+P)$$

仍然是可以实现的。实际上，我们可以对高斯分布添加一个小的“凸起”，如下所示：

$$P_X=(1-p)\mathcal{N}(0,P)+p\delta_x\,,$$

其中 $p\to 0$ 且 $x\to\infty$ 使得 $px^2\to 0$ 但 $px^4\to s-3P^2>0$。这表明对于具有 $s>3P^2$ 的问题 (5.12)，不存在达到容量的输入分布，但达到容量的输出分布 $P_Y^*=\mathcal{N}(0,1+P)$ 存在且如定理 5.9 所示是唯一的。

Proof of Theorem 5.9. 令 P'_{X_n} 为一列达到 C 的输入分布，即 $I(P'_{X_n},P_{Y|X})\to C$。令 $\mathcal{P}_n$ 为 $\{P'_{X_1},\dots,P'_{X_n}\}$ 的凸包。由于 $\mathcal{P}_n$ 是有限维单纯形，该（凹）函数 $P_X\mapsto I(P_X,P_{Y|X})$ 连续（命题 4.13），并在某点 $P_{X_n}\in\mathcal{P}_n$ 处取得最大值，即

$$I_n\triangleq I(P_{X_n},P_{Y|X})=\max_{P_X\in\mathcal{P}_n} I(P_X,P_{Y|X})\,.$$

用P_{Y_n}表示由P_{X_n}诱导的输出分布。那么我们有：

$$\begin{aligned} D(P_{Y_n}\|P_{Y_{n+k}}) &= D(P_{Y|X}\|P_{Y_{n+k}}|P_{X_n}) - D(P_{Y|X}\|P_{Y_n}|P_{X_n}) && (5.13)\\ &\le I(P_{X_{n+k}},P_{Y|X}) - I(P_{X_n},P_{Y|X}) && (5.14)\\ &\le C - I_n\,, && (5.15)\end{aligned}$$

其中在（5.14）中，我们将定理5.4应用于（$\mathcal{P}_{n+k},P_{Y_{n+k}}$）。关键思想是将KL散度（并非距离）与在下面（7.3）中定义的、称为*total variation*的真实距离进行比较。此类比较将成为第7章的主题。此处我们假定Pinsker不等式（见定理7.10）的有效性成立。根据该不等式，并且由于$I_n\nearrow C$，我们得出序列P_{Y_n}在总变差中是柯西序列：

$$\sup_{k\ge 1}\mathrm{TV}(P_{Y_n},P_{Y_{n+k}})\to 0\,,\qquad n\to\infty\,.$$

由于固定字母表上所有概率分布的空间在全变差下是完备的，该序列必有一个极限点 $P_{Y_n} \to P_Y^*$。在全变差意义下的收敛蕴含弱收敛，因此对 (5.15) 取 $k \to \infty$ 的极限并应用散度的下半连续性（定理 4.9），我们得到

$$D(P_{Y_n}\|P_Y^*) \le \lim_{k\to\infty} D(P_{Y_n}\|P_{Y_{n+k}}) \le C - I_n\,,$$

因此，$P_{Y_n} \to P_Y^*$在$D(P_{Y_n}\|P_Y^*) \to 0$的（更强）意义下。根据定理4.1,

$$D(P_{Y|X}\|P_Y^*|P_{X_n}) = I_n + D(P_{Y_n}\|P_Y^*) \to C\,. \tag{5.16}$$

取任意 $P_X \in \bigcup_{k\ge 1}\mathcal{P}_k$。那么对于所有足够大的 n，有 $P_X \in \mathcal{P}_n$，因此根据定理5.4

$$D(P_{Y|X}\|P_{Y_n}|P_X) \le I_n \le C\,, \tag{5.17}$$

根据散度的下半连续性和法图引理，这意味着

$$D(P_{Y|X}\|P_Y^*|P_X) \le C\,. \tag{5.18}$$

为了证明(5.18)对任意$P_X \in \mathcal{P}$成立，我们可以重复上述论证，将$\mathcal{P}_n$替换为$\tilde{\mathcal{P}}_n$ =conv($\{P_X\} \cup \mathcal{P}_n$)，记所得序列为$\tilde{P}_{X_n}, \tilde{P}_{Y_n}$，极限点为$\tilde{P}_Y^*$，从而得到:

$$D(P_{Y_n}\|\tilde{P}_{Y_n}) = D(P_{Y|X}\|\tilde{P}_{Y_n}|P_{X_n}) - D(P_{Y|X}\|P_{Y_n}|P_{X_n}) \tag{5.19}$$

$$\le C - I_n\,, \tag{5.20}$$

其中(5.20)由(5.18)根据$P_{X_n} \in \tilde{\mathcal{P}}_n$得出。因此，当$n \to \infty$取极限时，我们得到$\tilde{P}_Y^* = P_Y^*$，从而(5.18)成立。

为了看出P_Y^*的唯一性，假设存在满足$C = \sup_{P_X\in\mathcal{P}} D(P_{Y|X}\|Q_Y^*|P_X)$的$Q_Y^*$，我们证明 $Q_Y^* = P_Y^*$。事实上，

$$C \ge D(P_{Y|X}\|Q_Y^*|P_{X_n}) = D(P_{Y|X}\|P_{Y_n}|P_{X_n}) + D(P_{Y_n}\|Q_Y^*) = I_n + D(P_{Y_n}\|Q_Y^*).$$

由于 $I_n \to C$，我们有 $D(P_{Y_n}\|Q_Y^*) \to 0$。由于我们已经证明 $D(P_{Y_n}\|P_Y^*) \to 0$，我们得出 $P_Y^* = Q_Y^*$ (，这可以从例如 Pinsker 不等式和三角不等式 $\mathrm{TV}(P_Y^*, Q_Y^*) \le \mathrm{TV}(P_{Y_n}, Q_Y^*) + \mathrm{TV}(P_{Y_n}, P_Y^*) \to 0$) 中看出。

最后，为了理解(5.9)，请注意根据定义，最大最小容量至多为最小最大容量，即:

$$C = \sup_{P_X\in\mathcal{P}} \min_{Q_Y} D(P_{Y|X}\|Q_Y|P_X) \le \min_{Q_Y} \sup_{P_X\in\mathcal{P}} D(P_{Y|X}\|Q_Y|P_X) \le \sup_{P_X\in\mathcal{P}} D(P_{Y|X}\|P_Y^*|P_X) = C$$

鉴于 (5.16) 和 (5.17)。 □

推论 5.10 *Let $\mathcal{X}$ be countable and $\mathcal{P}$ a convex set of distributions on $\mathcal{X}$. If* $\sup_{P_X\in\mathcal{P}} H(X) < \infty$ *then*

$$\sup_{P_X\in\mathcal{P}} H(X) = \min_{Q_X} \sup_{P_X\in\mathcal{P}} \sum_x P_X(x)\log\frac{1}{Q_X(x)} < \infty$$

and the optimizer Q_X^* exists and is unique. If $Q_X^* \in \mathcal{P}$, then it is also the unique maximizer of $H(X)$.

Proof. 只需将Kemperman定理5.9应用于恒等信道$Y = X$。 □

例5.2（最大熵）假设f: $\mathbb{Z} \to \mathbb{R}$满足$Z(\lambda) \triangleq \sum_{n\in\mathbb{Z}} \exp\{-\lambda f(n)\} < \infty$对所有$\lambda >= 0$成立。那么

$$\max_{X:\mathbb{E}[f(X)]\le a} H(X) \le \inf_{\lambda>0} \{\lambda a + \log Z(\lambda)\} .$$

这源于取

$$Q_X(n) = Z(\lambda)^{-1} \exp\{-\lambda f(n)\} \tag{5.21}$$

在推论5.10中。这种形式的分布被称为能量函数f的*Gibbs distributions*。这个界限通常是紧的，并由$P_X(n) = Z(\lambda^*)^{-1} \exp\{-\lambda^* f(n)\}$达到，其中$\lambda^*$是最小化者，见练习III.27。（注意命题4.7讨论了同一问题的拉格朗日版本。）

5.5 高斯鞍点

对于加性噪声信道，还存在另一个奇特的鞍点关系，我们将在下一个结果中严格给出。证明基于分别应用(4.5)和(4.7)中互信息的inf-和sup-刻画。注意我们已经看到，在协方差约束下高斯分布是极端的（定理2.8）。

定理 5.11 *Let* $X_g \sim \mathcal{N}(0, \sigma_X^2)$, $N_g \sim \mathcal{N}(0, \sigma_N^2)$, $X_g \perp\!\!\!\perp N_g$. *Then:*

1. *"Gaussian capacity":*

$$C = I(X_g; X_g + N_g) = \frac{1}{2} \log \left(1 + \frac{\sigma_X^2}{\sigma_N^2}\right)$$

2. *"Gaussian input is the best for Gaussian noise": For all* $X \perp\!\!\!\perp N_g$ *and* 变量 $X \le \sigma_X^2$,

$$I(X; X + N_g) \le I(X_g; X_g + N_g), \tag{5.22}$$

   with equality iff $X \overset{\mathrm{d}}{=} X_g$.

3. *"Gaussian noise is the worst for Gaussian input": For for all* N *s.t.* $\mathbb{E}[X_g N] = 0$ *and* $\mathbb{E}N^2 \le \sigma_N^2$,

$$I(X_g; X_g + N) \ge I(X_g; X_g + N_g),$$

   with equality iff $N \overset{\mathrm{d}}{=} N_g$ *and independent of* X_g.

该结果编码了正态分布的极值性质：对于AWGN信道，高斯输入是最有利的（达到最大互信息，即容量），而对于一般的加性噪声信道，最不利的噪声是高斯噪声。关于前者陈述的向量版本，请参见练习I.9。

Proof. 不失一般性，假设所有随机变量均值为零。令 $Y_g = X_g + N_g$。定义

$$f(x) \triangleq D(P_{Y_g|X_g=x}\|P_{Y_g}) = D(\mathcal{N}(x,\sigma_N^2)\|\mathcal{N}(0,\sigma_X^2+\sigma_N^2)) = \underbrace{\frac{1}{2}\log\left(1+\frac{\sigma_X^2}{\sigma_N^2}\right)}_{=C} + \frac{\log e}{2}\frac{x^2-\sigma_X^2}{\sigma_X^2+\sigma_N^2}$$

1. 计算 $I(X_g;\ X_g+N_g) = \mathbb{E}[f(X_g)] = C$
2. 回顾 inf-表示（推论4.2）：$I(X;\ Y) = \min_Q D(P_{Y|X}\|Q|P_X)$。那么

$$I(X;X+N_g) \le D(P_{Y_g|X_g}\|P_{Y_g}|P_X) = \mathbb{E}[f(X)] \le C < \infty\,.$$

此外，若 $I(X;\ X+N_g) = C$，则达到容量的输出分布的唯一性（参见推论5.5）意味着 $P_Y = P_{Y_g}$。但 $P_Y = P_X * \mathcal{N}(0,\sigma_N^2)$，其中 $*$ 表示卷积。那么，只需考虑特征函数，必有 $X \sim \mathcal{N}(0,\sigma_X^2)$:

$$\Psi_X(t)\cdot e^{-\frac{1}{2}\sigma_N^2 t^2} = e^{-\frac{1}{2}(\sigma_X^2+\sigma_N^2)t^2} \Rightarrow \Psi_X(t) = e^{-\frac{1}{2}\sigma_X^2 t^2} \Longrightarrow X \sim \mathcal{N}(0,\sigma_X^2)$$

3. 令 $Y = X_g + N$ 并令 $P_{Y|X_g}$ 为各自的核。注意这里我们只假设 N 是 *uncorrelated* 且 X_g，即 $\mathbb{E}[NX_g]=0$，而不一定是独立的。那么

$$\begin{aligned}
I(X_g;X_g+N) &\ge \mathbb{E}\log\frac{dP_{X_g|Y_g}(X_g|Y)}{dP_{X_g}(X_g)} && (5.23)\\
&= \mathbb{E}\log\frac{dP_{Y_g|X_g}(Y|X_g)}{dP_{Y_g}(Y)} && (5.24)\\
&= C + \frac{\log e}{2}\,\mathbb{E}\left[\frac{Y^2}{\sigma_X^2+\sigma_N^2} - \frac{N^2}{\sigma_N^2}\right] && (5.25)\\
&= C + \frac{\log e}{2}\frac{\sigma_X^2}{\sigma_X^2+\sigma_N^2}\left(1-\frac{\mathbb{E}N^2}{\sigma_N^2}\right) && (5.26)\\
&\ge C\,, && (5.27)
\end{aligned}$$

其中

• (5.23)：由(4.7)推出，• (5.24)：$\frac{dP_{X_g|Y_g}}{dP_{X_g}} = \frac{dP_{Y_g|X_g}}{dP_{Y_g}}$5.26)：$\mathbb{E}[X_gN]=0$ 且 $\mathbb{E}[Y^2] = \mathbb{E}[$
• ($N^2] + \mathbb{E}[X_g^2]$。• (5.27)：$\mathbb{E}N^2 \le \sigma_N^2$。

最后，(5.23)（见(4.8)）中等式成立的条件要求

$$D(P_{X_g|Y}\|P_{X_g|Y_g}|P_Y) = 0$$

因此，$P_{X_g|Y} = P_{X_g|Y_g}$，即X_g，是条件高斯的：$P_{X_g|Y=y} = \mathcal{N}(by,c^2)$对应某些常数$b$和$c$。换言之，在$P_{X_gY}$条件下，我们有

$$X_g = bY + cZ\ ,\ Z \sim \text{Gaussian}\ \perp\!\!\!\perp Y.$$

但随后Y本身必须是高斯的，根据Cramer定理[107]，或者简单通过考虑特征函数：

$$\Psi_Y(t)\cdot e^{ct^2} = e^{c't^2} \Rightarrow \Psi_Y(t) = e^{c''t^2} \Longrightarrow Y \text{ is Gaussian}$$

因此，(X_g, Y) 必须是联合高斯分布，从而 $N = Y - X_g$ 是高斯分布。由此我们得出结论，只有当 N 是方差为 σ_N^2 且独立于 X_g 的高斯分布时，才可能得到 $I(X_g; X_g + N) = C$ 。 □

5.6 迭代算法：Blahut-Arimoto、期望最大化、Sinkhorn

虽然我们上面讨论的优化问题是凸的（因此在有限维中会被认为是算法上“简单”的），但仍有一些巧妙的想法用于加速其数值解。主要的基本原理如下 *alternating minimization algorithm*：

• 优化问题：$\min_t f(t)$。• 假设I：$f(t) = \min_s F(t,s)$ (即f可以写成某个其他函数F)的最小值。• 假设II：存在两个求解器$t^*(s) = \operatorname{argmin}_t F(t,s)$和$s^*(t) = \operatorname{argmin}_s F(t,s)$。• 迭代算法：– 步骤0：固定某个$s_0, t_0$。– 步骤$2k-1$：$s_k = s^*(t_{k-1})$。– 步骤$2k$：$t_k = t^*(s_k)$。

请注意，每一步都有稳定的改进（$F(s_k, t_k)$的值在减小），因此通常可以证明算法收敛到一个局部最小值，甚至在适当条件下（例如f的凸性）收敛到全局最小值。下面我们将讨论这一思想的若干应用，并参考[113]以获取收敛性的证明。一般来说，这类用于最大化与最小化互信息的迭代方法，根据其最初发现者[24, 62]的名字，被称为 *Blahut-Arimoto algorithms*。与通过决策变量的微小（“局部”）变化进行的梯度上升/下降不同，本节中的算法通过大的（“全局”）跳跃进行移动，因此收敛速度快得多。

所有这些算法的基础是吉布斯变分原理（命题4.7）：对于任何函数 $c : \mathcal{Y} \to \mathbb{R}$ 和 $\mathcal{Y}$ 上的任何 Q_Y，在可积性条件 $Z = \int Q_Y(dy) \exp\{-c(y)\} < \infty$ 下，最小值

$$\min_{P_Y} D(P_Y \| Q_Y) + \mathbb{E}_{Y \sim P_Y}[c(Y)] \tag{5.28}$$

在$P_Y^*(dy) = \frac{1}{Z} Q_Y(dy) \exp\{-c(y)\}$处达到。为简单起见，下面我们主要考虑离散字母表$\mathcal{X}, \mathcal{Y}$的情况。

最大化互信息（容量）。我们有一个固定的 $P_{Y|X}$ 和优化问题

$$C = \max_{P_X} I(X;Y) = \max_{P_X} \max_{Q_{X|Y}} \mathbb{E}_{P_{X,Y}} \left[\log \frac{Q_{X|Y}}{P_X} \right] ,$$

其中在第二个等式中我们引用了(4.7)。这导致了以下迭代:

$$Q_{X|Y}(x|y) \leftarrow \frac{1}{Z(y)} P_X(x) P_{Y|X}(y|x)$$
$$P_X(x) \leftarrow Q'(x) \triangleq \frac{1}{Z} \exp\left\{ \sum_y P_{Y|X}(y|x) \log Q_{X|Y}(x|y) \right\},$$

其中 $Z(y)$ 和 Z 是归一化常数。为了推导这一点，注意到对于固定的 P_X，最优的 $Q_{X|Y} = P_{X|Y}$。对于固定的 $Q_{X|Y}$，我们可以看到

$$\mathbb{E}_{P_{X,Y}}\left[\log \frac{Q_{X|Y}}{P_X}\right] = \log Z - D(P_X \| Q'),$$

因此最优的$P_X = Q'$。

将P_n表示为第n次迭代时P_X的值，我们观察到

$$I(P_n, P_{Y|X}) \le C \le \sup_x D(P_{Y|X=x} \| P_{Y|X} \circ P_n). \tag{5.29}$$

这很有用，因为在每次迭代中，我们不仅得到优化器P_n的估计值，而且还得到与最优性 $C - I(P_n, P_{Y|X}) \le C$ −右侧的差距。此外，可以证明，(5.29)中的右侧和左侧都单调收敛到 C，随着$n \to \infty$，详见[113]。

最小化互信息（率失真）。我们有一个固定的 P_X、一个代价函数 $c(x,y)$ 和优化问题

$$R = \min_{P_{Y|X}} I(X;Y) + \mathbb{E}[d(X,Y)] = \min_{P_{Y|X}, Q_Y} D(P_{Y|X} \| Q_Y | P_X) + \mathbb{E}[d(X,Y)], \tag{5.30}$$

其中在第二个等式中我们引用了(4.5)。这个最小化问题是有损压缩的基础，并将在第五部分详细讨论。利用(5.28)，我们推导出迭代:

$$P_{Y|X}(y|x) \leftarrow \frac{1}{Z(x)} Q_Y(y) \exp\{-d(x,y)\}$$
$$Q_Y \leftarrow P_{Y|X} \circ P_X.$$

此处存在一个类似于（5.29）的三明治界，参见（5.32），因此可以得到两个可计算的序列，分别从上方和下方收敛至R，以及收敛至（5.30）中argmin的$P_{Y|X}$。

EM算法（凸情形）。在[121]中提出的期望最大化（EM）算法是求解最大似然问题的一种启发式方法。已知对于凸问题，它会收敛到全局最大值点。我们首先考虑这一特殊情形（随后将讨论一般情形）。给定一个分布P_X，我们的目标是最小化关于混合分布 $Q_X = Q_{X|Y} \circ Q_Y$的散度:

$$L = \min_{Q_Y} D(P_X \| Q_{X|Y} \circ Q_Y), \tag{5.31}$$

其中 $Q_{X|Y}$ 是一个给定的信道。这是混合模型的最大似然估计中出现的问题，其中 Q_Y 是未知的混合分布，而 $P_X = \frac{1}{n}\sum_{i=1}^n \delta_{x_i}$ 是样本的经验分布（$x_1, \ldots, x_n$）。为了推导出 (5.31) 的迭代算法，我们写出

$$\min_{Q_Y} D(P_X \| Q_X) = \min_{Q_Y} \min_{P_{Y|X}} D(P_{X,Y} \| Q_{X,Y}) .$$

(注意，取 $d(x,y) = -\log \frac{dQ_{X|Y}(x|y)}{dP_X(x)}$ 表明此问题等价于 (5.30).) 因此，根据链式法则，我们得到迭代

$$P_{Y|X} \leftarrow \frac{1}{Z(x)} Q_Y(y) Q_{X|Y}(x|y)$$
$$Q_Y \leftarrow P_{Y|X} \circ P_X .$$

记 $Q_Y^{(n)}$ 为 Q_Y 在第 n 次迭代的值，$Q_X^{(n)} = Q_{X|Y} \circ Q_Y^{(n)}$。注意，对于任意 n 及所有 Q_Y，由 Jensen 不等式可得，

$$D(P_X \| Q_X^{(n)}) - D(P_X \| Q_X) = \mathbb{E}_{X \sim P_X}\left[\log \mathbb{E}_{Y \sim Q_Y} \frac{dQ_{X|Y}}{dQ_X^{(n)}}\right] \le \mathrm{gap}(Q_X^{(n)}) ,$$

其中 $\mathrm{gap}(Q_X) \triangleq \log \operatorname{esssup}_y \mathbb{E}_{X \sim P_X}[\frac{dQ_{X|Y=y}}{dQ_X}]$。总之，我们得到以下夹逼界：

$$D(P_X \| Q_X^{(n)}) - \mathrm{gap}(Q_X^{(n)}) \le L \le D(P_X \| Q_X^{(n)}) , \tag{5.32}$$

可以证明，当$n \to \infty$时，两边都收敛于L，参见例如[112，定理5.3]。

EM算法（一般情况）。EM算法的应用范围也比(5.31)更广泛，在(5.31)中量$Q_{X|Y}$是固定的。通常，我们考虑的模型中$Q_Y^{(\theta)}$和$Q_{X|Y}^{(\theta)}$都依赖于未知参数θ，目标（见第29.3节）是在θ上最大化总对数似然$\sum_{i=1}^n \log Q_X^{(\theta)}(x_i)$。一个典型的例子（也是EM算法最初的动机之一）是$k$分量的高斯混合模型$Q_X^{(\theta)} = \sum_{j=1}^k w_j \mathcal{N}(\mu_j, 1)$；换句话说，$Q_Y = (w_1, \ldots, w_k)$，$Q_{X|Y=j} = \mathcal{N}(\mu_j, 1)$和$\theta = (w_1, \ldots, w_k, \mu_1, \ldots, \mu_k)$。如果中心$\mu_j$已知，仅需估计权重$w_j$，则得到(5.31)中的简单凸情形。否则，我们需要在中心和权重上联合优化对数似然，这是一个非凸问题。

这里，处理该问题的一种方法是应用ELBO（4.16）如下：

$$\log Q_X^{(\theta)}(x_i) = \sup_P \mathbb{E}_{Y \sim P}\left[\log \frac{Q_{X,Y}^{(\theta)}(x_i, Y)}{P(Y)}\right] .$$

因此，最大似然可以表示为双重最大化问题

$$\sup_\theta \sum_i \log Q_X^{(\theta)}(x_i) = \sup_\theta \sup_{P_{Y|X}} F(\theta, P_{Y|X}) ,$$

其中

$$F(\theta, P_{Y|X}) = \sum_i \mathbb{E}_{Y \sim P_{Y|X=x_i}}\left[\log \frac{Q_{X,Y}^{(\theta)}(x_i, Y)}{P_{Y|X}(Y|x_i)}\right] .$$

因此，迭代算法是从某个{v*}开始，并根据以下规则进行更新：

$$\begin{aligned} P_{Y|X} &\leftarrow Q_{Y|X}^{(\theta)} && \text{E-step} \\ \theta &\leftarrow \operatorname*{argmax}_{\theta} F(\theta, P_{Y|X}) && \text{M-step.} \end{aligned} \tag{5.33}$$

一般来说，如果对数似然函数在 θ 中是非凸的，那么即使样本量无限大，EM 迭代也可能不收敛到全局最优（关于三分量高斯混合的一个例子，见 [234]）。此外，对于某些问题，在 E 步中 $Q_{Y|X}^{(\theta)}$ 可能难以计算。在这些情况下，人们执行 EM 的近似版本，其中步骤 max$_{P_{Y|X}} F(\theta, P_{Y|X})$ 是在受限的分布类上求解的，参见例 4.1 和 4.2。

Sinkhorn算法。该算法[388]与上述算法非常相似，但不完全相同。我们固定$Q_{X,Y}$，两个边际分布V_X, V_Y并解决问题

$$S = \min\{D(P_{X,Y}\|Q_{X,Y}) : P_X = V_X, P_Y = V_Y)\}\,.$$

从第15章的结果（见定理15.16和例15.2）可以清楚地看出，最优分布 $P_{X,Y}$ 由下式给出

$$P^*_{X,Y} = A(x)Q_{X,Y}(x,y)B(y)\,,$$

对于某个 $A, B \geq 0$。为了找到函数 A, B，我们注意到在固定的 B 下，使得 $P_X = V_X$ 成立的 A 的值由下式给出：

$$A(x) \leftarrow \frac{V_X(x)Q_{X,Y}(x,y)B(y)}{\sum_y Q_{X,Y}(x,y)B(y)}\,.$$

类似地，为了固定Y-边际，我们设置

$$B(y) \leftarrow \frac{A(x)Q_{X,Y}(x,y)V_Y(y)}{\sum_x A(x)Q_{X,Y}(x,y)}\,.$$

Sinkhorn算法交替进行A和B更新，直至收敛。

[388] 中的原始版本对应于 $V_X = V_Y = \text{Unif}([n])$，那里的目标是证明任何具有非负元素的矩阵 $\{C_{x,y}\}$ 都可以仅通过重新缩放行和列变换为双随机矩阵 $\{A(x)C_{x,y}B(y)\}$。对这种经典算法的重新关注源于一个观察：取联合高斯 $Q_{X,Y}(x,y) = c\exp\{-\|x-y\|^2/\epsilon\}$ 会产生一个耦合 $P_{X,Y}$，它类似于并近似（当 $\epsilon \to 0$ 时）计算 Wasserstein 距离 $W_2(V_X, V_Y)$ 所需的最优传输耦合，更多内容见 [117]。

6 Tensorization and information rates

在本章中，我们首先解释互信息的重要性质，即张量化（或单字母化），它允许人们在两个高维向量之间最大化和最小化互信息。接下来，我们通过引入随机过程)的*entropy rate* (和一对随机过程)的*mutual information rate* (的概念，将前几章讨论的随机变量的信息度量扩展到随机过程。对于前者，展示了两个能够良好耦合（即具有小的*Ornstein's distance*）的随机过程具有接近的熵率——这一事实将在后续讨论遍历性时使用（见第12.5*节）。对于后者，我们给出了平稳高斯过程对之间信息率的一个简单表达式，以其联合谱密度表示。这个表达式将在很久以后，当我们研究带有有色噪声的高斯信道时至关重要（第20.6*节）。

6.1 互信息的张量化（单字母化）

对于许多应用，我们将处理*memoryless*信道或无记忆源。在那些情况下，以下结果对于极大化互信息至关重要。

定理 6.1（联合互信息与边缘互信息）

(a) If the channel is memoryless, i.e., $P_{Y^n|X^n} = \prod P_{Y_i|X_i}$,

$$I(X^n; Y^n) \le \sum_{i=1}^{n} I(X_i; Y_i) \tag{6.1}$$

with equality iff $P_{Y^n} = \prod P_{Y_i}$. *Consequently, the (unconstrained) capacity is additive for memoryless channels:*

$$\max_{P_{X^n}} I(X^n; Y^n) = \sum_{i=1}^{n} \max_{P_{X_i}} I(X_i; Y_i).$$

(b) If the source is memoryless, i.e., $X_1 \perp\!\!\!\perp \ldots \perp\!\!\!\perp X_n$, *then*

$$I(X^n; Y) \ge \sum_{i=1}^{n} I(X_i; Y) \tag{6.2}$$

with equality iff $P_{X^n|Y} = \prod P_{X_i|Y}$ P_Y*-almost surely.*[1] *Consequently,*

$$\min_{P_{Y^n|X^n}} I(X^n; Y^n) = \sum_{i=1}^{n} \min_{P_{Y_i|X_i}} I(X_i; Y_i).$$

Proof. (1) 使用 $I(X^n;\ Y^n) - \sum I(X_i;\ Y_i) = D(P_{Y^n|X^n} \| \prod P_{Y_i|X_i} | P_{X^n}) - D(P_{Y^n} \| \prod P_{Y_i})$
(2) 反转 X 和 Y 的角色：$I(X^n;\ Y) - \sum I(X_i;\ Y) = D(P_{X^n|Y} \| \prod P_{X_i|Y} | P_Y) - D(P_{X^n} \| \prod P_{X_i})$
□

简而言之，我们看到

1 对于乘积信道，使互信息最大化的输入是乘积分布。2 对于乘积源，使互信息最小化的信道是乘积信道。

这种类型的结果在信息论中通常被称为 *single-letterization*。它将高维（多字母）问题的优化问题极大地简化为标量（单字母）问题。例如，在最简单的情况下，X^n, Y^n 是二进制向量，优化 $I(X^n;\ Y^n)$ 关于 P_{X^n} 和 $P_{Y^n|X^n}$ 需要在 2^n 维向量和 $2^n \times 2^n$ 矩阵上进行优化，而单独优化每个 $I(X_i;\ Y_i)$ 则很容易。在分析中，当某些量可加地扩展到张量幂时，这种效应被称为 *tensorization*。最著名的此类例子之一是 log-Sobolev 不等式，见练习 I.65 或 [200]。由于形成信道或分布的乘积是张量幂的一种形式，定理的第一部分表明容量具有张量性。

例6.1 让我们用以下示例来补充定理6.1。

• *(6.1) fails for non-product channels.* 令 $X_1 \perp\!\!\!\perp X_2 \sim \text{Ber}(1/2)$。令 $Y_1 = X_1 + X_2$ (二进制加法) 和 $Y_2 = X_1$。则 $I(X_1;\ Y_1) = I(X_2;\ Y_2) = 0$ 但 $I(X^2;\ Y^2) = 2$ `bits`。
• *Strict inequality in (6.1)*。考虑对所有 k 的 $Y_k = X_k = U \sim \text{Ber}(1/2)$。则 $I(X_k;\ Y_k) = 1$ `bit` 和 $I(X^n;\ Y^n) = 1$ `bit` $< \sum I(X_k;\ Y_k) = n$ `bits`。 • *Strict inequality in (6.2)*。令 $X_1 \perp\!\!\!\perp \ldots \perp\!\!\!\perp X_n$。考虑 $Y_1 = X_2, Y_2 = X_3, \ldots, Y_n = X_1$。则对所有 k 有 $I(X_k;\ Y_k) = 0$，且 $I(X^n;\ Y^n) = \sum H(X_i) > 0 = \sum I(X_k;\ Y_k)$。

6.2* 通过正交对称性的高斯容量

在本节中，我们重新审视定理5.11中的“高斯鞍点”结果。在那里，它是通过显式论证得出的。此处，我们展示如何利用张量积性质来证明高斯输入/噪声的极值性，而无需任何显式计算。

1 也就是说，如果{v*}作为联合分布。

我们从互信息（容量）最大化问题开始。在定理5.11的记号中，我们知道（对于 $Z\sim\mathcal{N}(0,1)$）

$$\max_{P_X:\mathbb{E}[X^2]\le\sigma_X^2} I(X;X+Z)=\frac{1}{2}\log\left(1+\sigma_X^2\right)\,.$$

注意，从张量化我们也可以立即得到（对于 $Z^n\sim\mathcal{N}(0,I_n)$）

$$\max_{P_{X^n}:\mathbb{E}[\|X^n\|^2]\le n\sigma_X^2} I(X^n;X^n+Z^n)=\frac{n}{2}\log\left(1+\sigma_X^2\right)\,.$$

因此，解决n维问题的传统方法是先通过显式（通常为变分法）计算解出一维版本，然后应用张量积。然而，事实证明，有时直接求解n维问题会神奇地变得更容易，而这正是我们在本节中想要展示的。

因此，假设我们试图直接解决

$$\max_{\mathbb{E}[\sum X_k^2]\le n\sigma_X^2} I(X^n;X^n+Z^n)$$

在联合分布 P_{X^n} 上。根据定理6.1(a) 中的张量性质，我们得到

$$\max_{\mathbb{E}[\sum X_k^2]\le n\sigma_X^2} I(X^n;X^n+Z^n)=\max_{\mathbb{E}[\sum X_k^2]\le n\sigma_X^2}\sum_{k=1}^n I(X_k;X_k+Z_k)\,.$$

给定满足约束的分布 $P_{X_1}\cdots P_{X_n}$，形成“边缘分布的平均”分布 $\bar{P}_X=\frac{1}{n}\sum_{k=1}^n P_{X_k}$，该分布也满足单字母约束 $\mathbb{E}[X^2]=\frac{1}{n}\sum_{k=1}^n\mathbb{E}[X_k^2]\le\sigma_X^2$。然后由 $I(P_X,P_{Y|X})$ 在 P_X 中的凹性

$$I(\bar{P}_X;P_{Y|X})\ge\frac{1}{n}\sum_{k=1}^n I(P_{X_k},P_{Y|X})$$

因此，$\bar{P}_X$给出了相同或更好的互信息，这表明上述极值化应随n线性增长，即

$$\max_{\mathbb{E}[\sum X_k^2]\le n\sigma_X^2} I(X^n;X^n+Z^n)=n\max_{P_X:\mathbb{E}[X^2]\le\sigma_X^2} I(X;X+Z)\,.$$

接下来，让我们回到 $Y^n=X^n+Z^n$。由于各向同性高斯分布具有旋转对称性，对于任何正交变换 $U\in O(n)$，$U\cdot(Z^n)\sim\mathcal{N}(0,I_n)$，因此 $P_{UY^n|UX^n}=P_{Y^n|X^n}$，并且

$$I(P_{X^n},P_{Y^n|X^n})=I(P_{UX^n},P_{UY^n|UX^n})=I(P_{UX^n},P_{Y^n|X^n}).$$

与上述“边缘分布的平均”论证类似，对所有正交旋转 U 的 X^n 取平均只会使互信息增大。因此，最优输入分布 P_{X^n} 可以选择为正交变换下不变的分布。从而，根据定理5.9，（唯一的！）达到容量的输出分布 $P_{Y^n}^*$ 必须是旋转不变的。此外，由(6.1)中等式成立的条件，我们得出结论：$P_{Y^n}^*$ 必须具有独立分量。由于满足功率约束且具有旋转对称性的唯一乘积分布是各向同性高斯分布，我们得出结论：$P_{Y^n}=(P_Y^*)^{\otimes n}$ 和 $P_Y^*=\mathcal{N}(0,1+\sigma_X^2)$。

反过来，唯一使得$P_{X+Z} = P_Y^*$成立的分布P_X是$P_X = \mathcal{N}(0, \sigma_X^2)$ (，这一点可以通过考虑特征函数)来论证。

定理 5.11 的最后一部分也可以类似处理。也就是说，我们可以证明，在

$$\min_{P_N:\mathbb{E}[N^2]=1} I(X_G; X_G + N)$$

通过将问题扩展到多维并对所有正交旋转取平均，它必然为高斯分布。

“提升维度”的思想（即先通过解决一个 $n = 1$ 问题来间接解决一个 $n > 1$ 问题）如本文所述源自 [333]，并且仅仅重新推导了我们在定理 5.11 中已经直接证明过的内容。但该思想也可用于解决各种非凸微分熵最大化问题，参见 [184]。

6.3 熵率

定义6.2 随机过程$\mathbb{X} = (X_1, X_2, \ldots)$的熵率为

$$H(\mathbb{X}) \triangleq \lim_{n\to\infty} \frac{1}{n} H(X^n) \tag{6.3}$$

前提是该极限存在。

熵率存在的充分条件是 *stationarity*，这本质上意味着对时间平移的不变性。形式上，如果 $(X_{t_1}, \ldots, X_{t_n}) \overset{\mathrm{d}}{=} (X_{t_1+k}, \ldots, X_{t_n+k})$ 对于任意 $t_1, \ldots, t_n, k \in \mathbb{N}$ 都成立，则 $\mathbb{X}$ 是平稳的。这个定义自然可以推广到以 $\mathbb{Z}$ 为索引的双边过程。

定理 6.3 *For any stationary process* $\mathbb{X} = (X_1, X_2, \ldots)$

(a) $H(X_n|X^{n-1}) \le H(X_{n-1}|X^{n-2})$. $\frac{1}{n}H(X^n) \ge H(X_n|X^{n-1})$. *(b)* $\frac{1}{n}H(X^n)$ *exists and* $H(\mathbb{X}) = \lim_{n\to\infty} \frac{1}{n}H(X^n) = \lim_{n\to\infty} H(X_n|X^{n-1})$. *Both sequences converge to* $H(\mathbb{X})$ *from above.*

(c) $H(\mathbb{X}) = H(X_1|X_0^{-\infty})$ *provided* $H(X_1) < \infty$.

(d) $H(X^n) \le nH(X_1)$.

(e) If $\mathbb{X}$ *can be extended to a two-sided stationary process* $\mathbb{X} = (\ldots, X_{-1}, X_0, X_1, X_2, \ldots)$, *then*

Proof.

(a) 进一步条件化 + 平稳性： $H(X_n|X^{n-1}) \le H(X_n|X_2^{n-1}) = H(X_{n-1}|X^{n-2})$ (b) 使用链式法则： $\frac{1}{n}H(X^n) = \frac{1}{n}\sum H(X_i|X^{i-1}) \ge H(X_n|X^{n-1})$ (c) $H(X^n) = H(X^{n-1}) + H(X_n|X^{n-1}) \le H(X^{n-1}) + \frac{1}{n}H(X^n)$

(d) $n \mapsto \frac{1}{n}H(X^n)$ 是一个递减序列且下界为零，因此有极限 $H(\mathbb{X})$。此外，根据链式法则，$\frac{1}{n}H(X^n) = \frac{1}{n}\sum_{i=1}^n H(X_i|X^{i-1})$。由此我们断言 $H(X_n|X^{n-1})$ 收敛于相同的极限 $H(\mathbb{X})$。实际上，由 (a) 部分所示的单调性，$\lim_n H(X_n|X^{n-1}) = H'$ 存在。接下来，回忆微积分中的以下事实：如果 $a_n \to a$，那么切萨罗均值 $\frac{1}{n}\sum_{i=1}^n a_i \to a$ 亦然。因此，$H' = H(\mathbb{X})$。

(e) 假设 $H(X_1) < \infty$，我们从(4.30)得出：

$$\lim_{n\to\infty} H(X_1) - H(X_1|X_{-n}^0) = \lim_{n\to\infty} I(X_1; X_{-n}^0) = I(X_1; X_{-\infty}^0) = H(X_1) - H(X_1|X_{-\infty}^0).$$

□

例6.2（平稳过程）让我们讨论一些最标准的平稳过程示例。

(a) 无记忆源：如果 $\mathbb{X}$ 是独立同分布的，那么 $H(\mathbb{X}) = H(X_1)$。
(b) 独立同分布过程是平稳随机过程最简单的例子。复杂程度次之的是*mixed source*：给定两个平稳（例如独立同分布）过程$\mathbb{Y}$和$\mathbb{Z}$，如下定义另一个$\mathbb{X}$。抛掷一枚偏置为p的硬币。若正面朝上，设$\mathbb{X} = \mathbb{Y}$；若反面朝上，设$\mathbb{X} = \mathbb{Z}$。应用定理3.4(b)可得，对于所有n，有$0 \le H(X^n) - (pH(Y^n) + \bar{p}H(Y^n)) \le \log 2$。于是$H(\mathbb{X}) = pH(\mathbb{Y}) + \bar{p}H(\mathbb{Z})$。
(c) 平稳马尔可夫过程：设 $\mathbb{X}$ 是一个马尔可夫链 $X_1 \to X_2 \to X_3 \to \cdots$，其转移核为 $\mathbb{P}[X_2 = b|X_1 = a] = K(b|a)$，并以不变分布 $X_1 \sim \mu$ (初始化，即 $\mu(b) = \sum_a K(b|a)\mu(a)$)。则对所有 n，有 $H(X_n|X^{n-1}) = H(X_n|X_{n-1})$，因此

$$H(\mathbb{X}) = H(X_2|X_1) = \sum_{a,b} \mu(a)K(b|a)\log\frac{1}{K(b|a)}.$$

参见练习 I.31 中的示例。这种过程被称为 *first-order* 马尔可夫过程，因为 X_n 仅依赖于 X_{n-1}。这一思想有一个扩展，其中 k 阶马尔可夫过程由核 $P_{X_n|X_{n-k}^{n-1}}$ 定义。香农经典地提出，这种过程是自然语言的一个良好模型（具有足够大的 k），而最近在大型语言模型 [320] 中的突破在很大程度上验证了他的愿景。

注意，我们对熵率的两种刻画都从上方收敛到极限，因此对于任意大的n计算 $H(X_n|X^{n-1})$或$\frac{1}{n}H(X^n)$，除了给出一个上界之外，无法对$H(\mathbb{X})$的真实值提供任何保证（特别地，我们甚至不能排除$H(\mathbb{X}) = 0$）。然而，对于语音和语言建模中广泛使用的一类特定平稳过程，我们可以得到一个夹逼界。

定义 6.4（隐马尔可夫模型（HMM））给定状态空间 $\mathcal{S}$ 上的平稳马尔可夫链 $\ldots, S_{-1}, S_0, S_1, \ldots$ 和马尔可夫核 $P_{X|S}$：$\mathcal{S} \to \mathcal{X}$，我们将 HMM 定义为一个平稳过程 $\ldots, X_{-1}, X_0, X_1, \ldots$，如下所示。首先，生成一条轨迹 $S_{-\infty}^{\infty}$。然后，以该轨迹为条件，我们独立地生成每个 $X_i \sim P_{X|S=S_i}$。换言之，$\mathbb{X}$ 只是 $\mathbb{S}$，但是在一个称为 *emission channel*) 的平稳无记忆信道 $P_{X|S}$ (上观测得到的。

该领域的基本结果之一归功于Blackwell [60]，他证明了由$R_{s,n} \triangleq \mathbb{P}[S_n = s|X_{-\infty}^{n-1}]$给出的$\mathcal{P}(\mathcal{S})$值信念过程$\mathrm{R}_n = (R_{s,n}, s \in \mathcal{S})$实际上是一个平稳的一阶马尔可夫过程。$\mathrm{R}_n$ (独立于n)的共同律μ被称为*Blackwellmeasure*。尽管即使对最简单的过程而言，求解μ也非常困难（见下例），但我们确实有以下用μ表示的熵率表示：

$$H(\mathbb{X}) = \int_{\mathcal{P}(\mathcal{S})} \mu(d\mathbf{r})\, \mathbb{E}_{s\sim\mathbf{r}}[H(P_{X|S=s})]\,.$$

也就是说，熵率是简单函数$\mathrm{r} \mapsto \sum_s r_s H(P_{X|S=s})$在$\mu$上的积分。

例6.3（Gilbert-Elliott隐马尔可夫模型[187, 151]）这是一个具有二元状态和二元发射的隐马尔可夫模型。设$\mathcal{S} = \{0, 1\}$与$\mathbb{P}[S_1 \neq S_0|S_0] = \tau$，即$\mathbb{S}$过程的转移矩阵为$\begin{pmatrix} 1-\tau & \tau \\ \bar{\tau} & \bar{\tau} \end{pmatrix}$。设定$X_i = \mathsf{BSC}_\delta(S_i)$。在此情况下，Blackwell测度$\mu$支持在$[\tau, \bar{\tau}]$上，并且是随机变量$\mathbb{P}[S_1 = 1|X_{-\infty}^0]$的分布，熵率可以用二元熵函数$h$表示：

$$H(\mathbb{X}) = \int_0^1 \mu(dx) h(\delta\bar{x} + \bar{\delta}x)\,,$$

其中我们提醒$\bar{x} = 1 - x$等。实际上，我们可以用极限$\int f d\mu = \lim_{n\to\infty} K^n f(1/2)$来表示关于$\mu$的积分，其中$K$是信念过程的转移核，它作用于函数$g : [0, 1] \to \mathbb{R}$上，形式为

$$Kg(x) = p(x)g\left(\frac{x\bar{\tau}\bar{\delta} + \bar{x}\tau\delta}{p(x)}\right) + \bar{p}(x)g\left(\frac{x\bar{\tau}\delta + \bar{x}\tau\bar{\delta}}{\bar{p}(x)}\right)\,, \quad p(x) = 1 - \bar{p}(x) = \delta\bar{x} + \bar{\delta}x\,.$$

我们可以看到，信念过程遵循简单的分数线性更新，然而平稳测度μ极其复杂，它可以是绝对连续的或奇异的（类似分形）[33, 32]。因此，理解作为(τ, δ)函数的$H(\mathbb{X})$是该领域的一个主要开放问题。然而，我们注意到，如果我们不使用BSC而是使用$X = \mathsf{BEC}_\delta(S)$，那么得到的熵率要容易计算得多，参见练习I.32。

尽管存在这些复杂情况，HMM的熵率仍具有一个良好性质：它可以被夹在一个单调递增和一个单调递减的序列之间。正如我们上面提到的，对于一般的平稳过程，这样的夹逼界是不可能的。

命题 6.5 *Consider an HMM process $\mathbb{X}$ with state process $\mathbb{S}$. Then*

$$H(X_n|X_1^{n-1}, S_0) \le H(\mathbb{X}) \le H(X_n|X_1^{n-1})\,, \tag{6.4}$$

and both sides converge monotonically to $H(\mathbb{X})$ as $n \to \infty$.

Proof. 关于上界部分我们已经确立。为了展示下界，注意

$$H(\mathbb{X}) = H(X_n|X_{-\infty}^{n-1}) \ge H(X_n|X_{-\infty}^{n-1}, S_0) = H(X_n|X_1^{n-1}, S_0)\,,$$

其中最后一步我们使用了马尔可夫性质 $X^0_{-\infty} \to S_0 \to X_1^n$。接下来，我们证明 $H(X_n|X_1^{n-1}, S_0)$ 在 n 中是递增的。事实上

$$H(X_{n+1}|X_1^n, S_0) = H(X_n|X_0^{n-1}, S_{-1}) \geq H(X_n|X_0^{n-1}, S_{-1}, S_0) = H(X_n|X_1^{n-1}, S_0)\,,$$

其中第一个等式由平稳性得出，不等式由添加条件（定理1.4）得出，最后一个等式则由于马尔可夫性质（S_{-1}, X_0）$\to S_0 \to X_1^n$。

最后，我们展示了

$$H(\mathbb{X}) = \lim_{n\to\infty} H(X_n|X_1^{n-1}, S_0)\,.$$

事实上，注意由(4.30)我们有

$$I(S_0; X_1^\infty) = \lim_{n\to\infty} I(S_0; X_1^n) \leq H(S_0) < \infty\,,$$

因此 $I(S_0; X_1^n) - I(S_0; X_1^{n-1}) \to 0$。但根据链式法则，我们也有

$$I(S_0; X_1^n) - I(S_0; X_1^{n-1}) = I(S_0; X_n|X_1^{n-1}) = H(X_n|X_1^{n-1}) - H(X_n|X_1^{n-1}, S_0) \to 0\,.$$

因此，我们可以看到(6.4)两边的差随n消失。 □

6.4 熵与符号（比特）错误率

在本节中，我们展示当两个过程$\mathbb{X}$和$\mathbb{Y}$能够“耦合”时，它们的熵率是接近的。两个过程的耦合意味着在一个共同的概率空间上定义它们，使得它们实现之间的平均距离很小。在下文中，我们将要求所谓的*symbol error rate* (期望误差比例)很小，即

$$\frac{1}{n}\sum_{j=1}^{n} \mathbb{P}[X_j \neq Y_j] \leq \epsilon\,. \tag{6.5}$$

(在所有可能的耦合中，最小的这样的 ϵ 被称为随机过程之间的 *Ornstein's distance*。) 对于二元字母表，这个量被称为 *bit error rate*，这是我们在第四部分中考虑用于可靠数据传输的性能指标之一（见第17.1节和第19.6节）。注意，如果我们定义汉明距离为

$$d_{\mathrm{H}}(x^n, y^n) \triangleq \sum_{j=1}^{n} 1\{x_j \neq y_j\} \tag{6.6}$$

那么(6.5)对应于要求$\mathbb{E}[d_{\mathrm{H}}(X^n, Y^n)] \leq n\epsilon$。

在展示我们的主要结果之前，我们先展示Fano不等式定理3.12可以进行张量化处理：

命题 6.6 *Let $X_1, \ldots, X_n$ take values on a finite alphabet $\mathcal{X}$. Then*

$$H(X^n|Y^n) \leq nF_{|\mathcal{X}|}(1-\delta) = n(\delta \log(|\mathcal{X}|-1) + h(\delta))\,, \tag{6.7}$$

where the function F_M is defined in (3.14), and

$$\delta = \frac{1}{n}\,\mathbb{E}[d_{\mathrm{H}}(X^n, Y^n)] = \frac{1}{n}\sum_{j=1}^{n}\mathbb{P}[X_j \neq Y_j]\,.$$

Proof. 对于每个 $j \in [n]$，将 (3.18) 应用于马尔可夫链 $X_j \to Y^n \to Y_j$ 可得

$$H(X_j|Y^n) \leq F_M(\mathbb{P}\,[X_j = Y_j])\,, \tag{6.8}$$

其中我们记 $M = |\mathcal{X}|$。然后，用边缘熵之和来上界联合熵，参见(1.3)，并与(6.8)结合，我们得到

$$\begin{aligned} H(X^n|Y^n) &\leq \sum_{j=1}^{n} H(X_j|Y^n) && (6.9)\\ &\leq \sum_{j=1}^{n} F_M(\mathbb{P}[X_j = Y_j]) && (6.10)\\ &\leq nF_M\left(\frac{1}{n}\sum_{j=1}^{n}\mathbb{P}[X_j = Y_j]\right) && (6.11) \end{aligned}$$

其中最后一步我们使用了F_M的凹性和詹森不等式。 □

推论 6.7 *Consider two processes $\mathbb{X}$ and $\mathbb{Y}$ with entropy rates $H(\mathbb{X})$ and $H(\mathbb{Y})$. If*

$$\mathbb{P}[X_j \neq Y_j] \leq \epsilon$$

for every j and if $\mathbb{X}$ takes values on a finite alphabet of size M, then

$$H(\mathbb{X}) - H(\mathbb{Y}) \leq F_M(1-\epsilon)\,.$$

If both processes have alphabets of size M, then

$$|H(\mathbb{X}) - H(\mathbb{Y})| \leq \epsilon \log M + h(\epsilon) \to 0 \qquad \text{as } \epsilon \to 0.$$

Proof. 几乎没有什么需要证明的：

$$H(X^n) \leq H(X^n, Y^n) = H(Y^n) + H(X^n|Y^n)$$

并应用(6.7)。对于最后一条陈述，只需回忆F_M的表达式。 □

6.5 互信息率

扩展熵率的定义，两个随机过程$\mathbb{X} = (X_1, X_2, \ldots)$和$\mathbb{Y} = (Y_1, Y_2, \ldots)$的互信息率定义如下。

定义 6.8（互信息率）

$$I(\mathbb{X};\mathbb{Y}) = \lim_{n\to\infty} \frac{1}{n} I(X^n; Y^n)$$

前提是该极限存在。

我们提供了一个高斯过程的例子，这对于研究具有相关噪声的高斯信道（第20.6*节）将是有用的。

例 6.4（高斯过程）考虑 $\mathbb{X}, \mathbb{N}$ 两个彼此独立的平稳高斯过程。假设它们的自协方差函数绝对可和，因此存在连续的功率谱密度函数 f_X 和 f_N。不失一般性，假设所有均值均为零。令 $c_X(k) = \mathbb{E}[X_1 X_{k+1}]$。那么 f_X 是自协方差函数 c_X 的傅里叶变换，即 $f_X(\omega) = \sum_{k=-\infty}^{\infty} c_X(k) e^{i\omega k}$，$|\omega| \le \pi$。最后，假设 $f_N \ge \delta > 0$。那么回忆例 3.5:

$$\begin{aligned} I(X^n; X^n + N^n) &= \frac{1}{2} \log \frac{\det(\Sigma_{X^n} + \Sigma_{N^n})}{\det \Sigma_{N^n}} \\ &= \frac{1}{2} \sum_{i=1}^{n} \log \sigma_i - \frac{1}{2} \sum_{i=1}^{n} \log \lambda_i \,, \end{aligned}$$

其中 σ_j, λ_j 是协方差矩阵 $\Sigma_{Y^n} = \Sigma_{X^n} + \Sigma_{N^n}$ 和 Σ_{N^n} 的特征值，这些矩阵都是托普利茨矩阵，例如 $(\Sigma_{X^n})_{ij} = \mathbb{E}[X_i X_j] = c_X(i-j)$。根据 Szegö 定理 [199, 第 5.2 节]:

$$\frac{1}{n} \sum_{i=1}^{n} \log \sigma_i \to \frac{1}{2\pi} \int_{-\pi}^{\pi} \log f_Y(\omega) d\omega \tag{6.12}$$

注意 $c_Y(k) = \mathbb{E}[(X_1 + N_1)(X_{k+1} + N_{k+1})] = c_X(k) + c_N(k)$，因此 $f_Y = f_X + f_N$。于是，我们有

$$\frac{1}{n} I(X^n; X^n + N^n) \to I(\mathbb{X}; \mathbb{X} + \mathbb{N}) = \frac{1}{4\pi} \int_{-\pi}^{\pi} \log \frac{f_X(w) + f_N(\omega)}{f_N(\omega)} d\omega.$$

在矩约束条件下对 f_X 最大化此式，便得到了著名的 *water-filling solution* $f_X^*(\omega) = |T - f_N(\omega)|^+$——参见定理20.18。

7 f-divergences

在第2章中，我们介绍了衡量两个分布之间差异的KL散度。事实证明，这只是被称为f-散度的一系列此类度量中的一个特例，由Csiszár [109] 引入。与KL散度一样，f-散度满足许多有用的性质：

• 操作意义：KL散度通过为信道编码和数据压缩中的问题提供基本答案，构成了信息论的基础。类似地，诸如χ^2、H^2和TV等f-散度分别在参数估计、高维统计和假设检验中具有基础性作用。•对双射变换的不变性。•数据处理不等式 •变分表示（à la Donsker-Varadhan）•局部行为由χ^2 (在非参数情况下)或Fisher信息（在参数情况下）给出。

本章的目的是建立这些性质，并为后续章节的应用奠定基础。重点在于Harremoës和Vajda的*joint range*定理[214]，它给出了任意f-散度之间最精确的比较不等式，并为从Pinsker不等式——定理7.10开始的一系列长期成果画上了句号。这部分内容不仅对于那些对信息论“非经典”应用（如我们将在第六部分探讨的那些）感兴趣的人是必读的。其他人可以略读本章，并在需要时回头参考。

7.1 f - 散度的定义与基本性质

定义 7.1 (f-散度) 设$f:(0,\infty)\to\mathbb{R}$是一个凸函数，且$f(1)=0$。令$P$和$Q$为可测空间$(\mathcal{X},\mathcal{F})$上的两个概率分布。若$P\ll Q$则$f$-散度定义为

$$D_f(P\|Q)\triangleq\mathbb{E}_Q\left[f\left(\frac{dP}{dQ}\right)\right] \tag{7.1}$$

其中$\frac{dP}{dQ}$是拉东-尼科迪姆导数，且$f(0)\triangleq f(0+)$。更一般地，令$f'(\infty)\triangleq\lim_{x\downarrow 0}xf(1/x)$。假设对于某个共同的，$Q(dx)=q(x)\mu(dx)$和$P(dx)=p(x)\mu(dx)$

主导测度μ，则有

$$D_f(P\|Q) = \int_{q>0} q(x) f\left(\frac{p(x)}{q(x)}\right) d\mu + f'(\infty) P[q=0] \tag{7.2}$$

在$P[q=0]=0$的情况下，无论可能为无穷大的$f'(\infty)$ ()的值如何，最后一项均视为零。

注7.1 对于离散情形，若$Q(x)$和$P(x)$分别为各自的部分累积分布函数，我们也可以写作

$$D_f(P\|Q) = \sum_x Q(x) f\left(\frac{P(x)}{Q(x)}\right)$$

在理解这一点的基础上

• $f(0) = f(0+)$，• $0 f(\frac{0}{0}) = 0$，以及 • 0
$f(\frac{a}{0}) = \lim_{x\downarrow 0} x f(\frac{a}{x}) = a f'(\infty)$ 对于 $a > 0$。

注 7.2 $D_f(P\|Q)$ 的一个良好性质是其定义对于 (7.2) 中主导测度 μ 的选择具有不变性。对于其他不相似性度量则不然，例如密度 $\|p-q\|^2_{L^2(d\mu)}$ 之间的平方 L_2-距离，这是统计学文献中密度估计的一种流行损失函数（参见第 32.4 节）。

以下是常见的f-散度：

• Kullback-Leibler（KL）散度：在第2章中，通过取 $f(x) = x\log x$，我们恢复了通常的$D(P\|Q)$。• 全变差：$f(x) = \frac{1}{2}|x-1|$，

$$\mathrm{TV}(P,Q) \triangleq \frac{1}{2}\mathbb{E}_Q\left[\left|\frac{dP}{dQ} - 1\right|\right] = \frac{1}{2}\int |dP - dQ| = 1 - \int d(P\wedge Q). \tag{7.3}$$

此外，TV$(\cdot,\cdot)$ 是概率分布空间上的一个度量。[1]
• χ^2-散度：$f(x) = (x-1)^2$，

$$\chi^2(P\|Q) \triangleq \mathbb{E}_Q\left[\left(\frac{dP}{dQ} - 1\right)^2\right] = \int \frac{(dP - dQ)^2}{dQ} = \int \frac{dP^2}{dQ} - 1. \tag{7.4}$$

注意，我们也可以选择$f(x) = x^2 - 1$。事实上，f相差一个线性项会导致相同的f散度，参见命题7.2。

1 在(7.3)中，$\int d(P\wedge Q)$是$\int(\frac{dP}{d\mu}\wedge\frac{dQ}{d\mu})d\mu$的常用简写，其中$\mu$是任意主导测度。(7.4)和(7.5)中的表达式以类似方式理解。

- 平方 Hellinger 距离：$f(x) = \left(1-\sqrt{x}\right)^2$，

$$H^2(P,Q) \triangleq \mathbb{E}_Q\left[\left(1-\sqrt{\frac{dP}{dQ}}\right)^2\right] = \int\left(\sqrt{dP}-\sqrt{dQ}\right)^2 = 2-2\int\sqrt{dPdQ}. \tag{7.5}$$

这里，量$B(P,Q) \triangleq \int\sqrt{dPdQ}$被称为*Bhattacharyya coefficient* (或 Hellinger 亲和度) [52]。注意，$H(P,Q) = \sqrt{H^2(P,Q)}$在概率分布空间上定义了一个度量：事实上，三角不等式是由共同支配测度的$L_2(\mu)$的三角不等式得出的。然而，请注意，

$$P \mapsto H(P,Q) \text{ is not convex.} \tag{7.6}$$

(这是因为度量 H 不是由测度空间上的巴拿赫范数诱导的。) 具体例子，考虑 $p \mapsto H(\mathrm{Ber}(p), \mathrm{Ber}(0.1))$。

- Le Cam散度（距离）[273, p. 47]：$f(x) = \frac{1-x}{2x+2}$，

$$\mathrm{LC}(P,Q) = \frac{1}{2}\int\frac{(dP-dQ)^2}{dP+dQ}. \tag{7.7}$$

此外，$\sqrt{\mathrm{LC}(P\|Q)}$ 是概率分布空间上的一个度量[152]，被称为Le Cam距离。

- Jensen-Shannon散度：$f(x) = x\log\frac{2x}{x+1} + \log\frac{2}{x+1}$，

$$\mathrm{JS}(P,Q) = D\left(P\middle\|\frac{P+Q}{2}\right) + D\left(Q\middle\|\frac{P+Q}{2}\right). \tag{7.8}$$

此外，$\sqrt{\mathrm{JS}(P\|Q)}$ 是概率分布空间上的一个度量 [152]。

备注7.3 若$D_f(P\|Q)$为f-散度，则易证对于所有$\lambda \in [0,1]$，$D_f(\lambda P + \bar{\lambda}Q\|Q)$和$D_f(P\|\lambda P + \bar{\lambda}Q)$均为$f$-散度。特别地，$D_f(Q\|P) = D_{\tilde{f}}(P\|Q)$与$\tilde{f}(x) \triangleq xf(\frac{1}{x})$。

我们首先总结一些关于 f-散度的形式化观察

命题 7.2（基本性质）*The following hold:*

1 $D_{f_1+f_2}(P\|Q) = D_{f_1}(P\|Q) + D_{f_2}(P\|Q)$.*2* $D_f(P\|P) = 0$.0 *for all* $P \neq Q$ *iff* $f(x) = c(x-1)$ *for some c. For any other f we have* $D_f(P\|Q) = f(0)+f'(\infty) > 0$ *for* $P \perp Q$.

4 If $P_{X,Y} = P_X P_{Y|X}$ *and* $Q_{X,Y} = P_X Q_{Y|X}$ *then the function* $x \mapsto D_f(P_{Y|X=x}\|Q_{Y|X=x})$ *is measurable and*

$$D_f(P_{X,Y}\|Q_{X,Y}) = \int_{\mathcal{X}} dP_X(x) D_f(P_{Y|X=x}\|Q_{Y|X=x}) \triangleq D_f(P_{Y|X}\|Q_{Y|X}|P_X), \tag{7.9}$$

the latter referred to as the 条件 f-散度 *(similar to Definition 2.14 for conditional KL divergence).*

5 *If* $P_{X,Y} = P_X P_{Y|X}$ *and* $Q_{X,Y} = Q_X P_{Y|X}$ *then*

$$D_f(P_{X,Y}\|Q_{X,Y}) = D_f(P_X\|Q_X)\,. \tag{7.10}$$

In particular,

$$D_f(P_X P_Y\|Q_X P_Y) = D_f(P_X\|Q_X)\,. \tag{7.11}$$

6 *Let* $f_1(x) = f(x) + c(x-1)$, *then*

$$D_{f_1}(P\|Q) = D_f(P\|Q) \qquad \forall P, Q\,.$$

In particular, we can always assume that $f \geq 0$ *and (if* f *is differentiable at 1) that* $f'(1) = 0$.

Proof. 前两个性质是显然的。对于第三个性质，需明确验证 $D_f(P\|Q) = 0$ 对于 $f = c(x-1)$。接着考虑一般情况 f，并注意到对于 $P \perp Q$，根据定义我们有

$$D_f(P\|Q) = f(0) + f'(\infty), \tag{7.12}$$

这是良定义的（即 $\infty - \infty$ 不可能），因为由凸性可知 $f(0) > -\infty$ 且 $f'(\infty) > -\infty$。因此，我们只需验证 $f(0) + f'(\infty) = 0$ 当且仅当对于某个 $c \in \mathbb{R}$ 有 $f = c(x-1)$。事实上，由于 $f(1) = 0$，f 的凸性意味着 $x \mapsto g(x) \triangleq \frac{f(x)}{x-1}$ 非递减。根据假设，我们有 $g(0+) = g(\infty)$，因此 $g(x)$ 在 $x > 0$ 上为常数，正如所需。

对于性质4，令 $R_{Y|X} = \frac{1}{2}P_{Y|X} + \frac{1}{2}Q_{Y|X}$。根据定理2.12，存在联合可测的 $p(y|x)$ 和 $q(y|x)$，使得 $dP_{Y|X=x} = p(y|x)dR_{Y|X=x}$ 和 $Q_{Y|X} = q(y|x)dR_{Y|X=x}$。于是我们可以将（7.2）中的 μ 取为 $\mu = P_X R_{Y|X}$，这给出 $dP_{X,Y} = p(y|x)d\mu$ 和 $dQ_{X,Y} = q(y|x)d\mu$，因此

$$\begin{aligned}
&D_f(P_{X,Y}\|Q_{X,Y})\\
&= \int_{\mathcal{X}\times\mathcal{Y}} d\mu 1\{y : q(y|x) > 0\}\, q(y|x) f\left(\frac{p(y|x)}{q(y|x)}\right) + f'(\infty)\int_{\mathcal{X}\times\mathcal{Y}} d\mu 1\{y : q(y|x) = 0\}\, p(y|x)\\
&\overset{(7.2)}{=} \int_{\mathcal{X}} dP_X \underbrace{\left\{\int_{\{y:q(y|x)>0\}} dR_{Y|X=x}\, q(y|x) f\left(\frac{p(y|x)}{q(y|x)}\right) + f'(\infty)\int_{\{y:q(y|x)=0\}} dR_{Y|X=x}\, p(y|x)\right\}}_{D_f(P_{Y|X=x}\|Q_{Y|X=x})}
\end{aligned}$$

即所需的 (7.9)。

性质5源自以下观察：如果我们取 $\mu = P_{X,Y} + Q_{X,Y}$ 和 $\mu_1 = P_X + Q_X$，则得到 $\frac{dP_{X,Y}}{d\mu} = \frac{dP_X}{d\mu}$ 对于 Q 也类似。

性质6由第一条和第三条推出。还要注意，归约到 $f \geq 0$ 是通过取 $c = f'(1)$ (或 $x = 1$ 处的任意次微分（如果 f 不可微)）来实现的。 □

7.2 数据处理不等式；有限分区的近似

定理 7.3（单调性）

$$D_f(P_{X,Y}\|Q_{X,Y}) \geq D_f(P_X\|Q_X)\,. \tag{7.13}$$

Proof. 请注意，在 $P_{X,Y} \ll Q_{X,Y}$ (因而 $P_X \ll Q_X$) 的情况下，证明只需将詹森不等式简单应用于定义(7.1)：

$$\begin{aligned} D_f(P_{X,Y}\|Q_{X,Y}) &= \mathbb{E}_{X\sim Q_X}\,\mathbb{E}_{Y\sim Q_{Y|X}}\left[f\left(\frac{dP_{Y|X}P_X}{dQ_{Y|X}Q_X}\right)\right] \\ &\geq \mathbb{E}_{X\sim Q_X}\left[f\left(\mathbb{E}_{Y\sim Q_{Y|X}}\left[\frac{dP_{Y|X}P_X}{dQ_{Y|X}Q_X}\right]\right)\right] \\ &= \mathbb{E}_{X\sim Q_X}\left[f\left(\frac{dP_X}{dQ_X}\right)\right]. \end{aligned}$$

为了证明一般情况，我们需要更加谨慎。令 $R_X = \frac{1}{2}(P_X+Q_X)$ 和 $R_{Y|X} = \frac{1}{2}P_{Y|X}+\frac{1}{2}Q_{Y|X}$。显然，$P_{X,Y}, Q_{X,Y} \ll R_{X,Y} \triangleq R_X R_{Y|X}$ 且对于每个 x：$P_{Y|X=x}, Q_{Y|X=x} \ll R_{Y|X=x}$。根据定理2.12，存在可测函数 p_1, p_2, q_1, q_2，使得

$$dP_{X,Y} = p_1(x)p_2(y|x)dR_{X,Y}, \quad dQ_{X,Y} = q_1(x)q_2(y|x)dR_{X,Y}$$

以及 $dP_{Y|X=x} = p_2(y|x)dR_{Y|X=x}$、$dQ_{Y|X=x} = q_2(y|x)dR_{Y|X=x}$。我们还表示 $p(x,y) = p_1(x)p_2(y|x)$、$q(x,y) = q_1(x)q_2(y|x)$。

修复 > 0 并考虑在 t 处对 f 的一条支撑线，斜率为 μ, s o that

$$f(u) \geq f(t) + \mu(u-t), \qquad \forall u \geq 0.$$

因此，$f'(\infty) \geq \mu$ 并且对于任意 $\lambda \in [0,1]$ 取 $u = \lambda t$，我们已经证明：

$$f(\lambda t) + \bar{\lambda} t f'(\infty) \geq f(t), \qquad \forall t \geq 0, \lambda \in [0,1]. \tag{7.14}$$

请注意，我们也添加了 $t = 0$ 的情况，因为对于 $t = 0$，该陈述是显然的（但请回想，$f(0) \triangleq f(0+)$ 可能等于 $+\infty$）。

接下来，固定某个 x 与 $q_1(x) > 0$，并考虑链

$$\begin{aligned} &\int_{\{y:q_2(y|x)>0\}} dR_{Y|X=x}\, q_2(y|x) f\left(\frac{p_1(x)p_2(y|x)}{q_1(x)q_2(y|x)}\right) + \frac{p_1(x)}{q_1(x)} P_{Y|X=x}[q_2(Y|x)=0] f'(\infty) \\ &\overset{(a)}{\geq} f\left(\frac{p_1(x)}{q_1(x)} P_{Y|X=x}[q_2(Y|x)>0]\right) + \frac{p_1(x)}{q_1(x)} P_{Y|X=x}[q_2(Y|x)=0] f'(\infty) \\ &\overset{(b)}{\geq} f\left(\frac{p_1(x)}{q_1(x)}\right) \end{aligned}$$

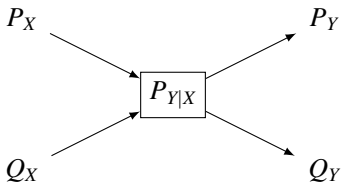
其中 (a) 由 Jensen 不等式和 f 的凸性得出，而 (b) 通过在 (7.14) 中取 $t = \frac{p_1(x)}{q_1(x)}$ 和 $\lambda = P_{Y|X=x}[q_2(Y|x) > 0]$ 得到。现在将所得不等式乘以 $q_1(x)$ 并在 $\{x : q_1(x) > 0\}$ 上积分，我们得到

$$\int_{\{q>0\}} dR_{X,Y}\, q(x,y) f\left(\frac{p(x,y)}{q(x,y)}\right) + f'(\infty) P_{X,Y}[q_1(X) > 0, q_2(Y|X) = 0] \geq \int_{\{q_1>0\}} dR_X\, q_1(x) f\left(\frac{p_1(x)}{q_1(x)}\right).$$

将 $f'(\infty)P_X[q_1(X) = 0]$ 加到两边，我们得到（7.13），因为两边都计算为定义（7.2）。 □

以下是本节的主要结果。

定理 7.4（数据处理）*Consider a channel that produces Y given X based on the conditional law $P_{Y|X}$ (shown below).*



Let P_Y (resp. Q_Y) denote the distribution of Y when X is distributed as P_X (resp. Q_X). For any f-divergence $D_f(\cdot\|\cdot)$,

$$D_f(P_Y\|Q_Y) \le D_f(P_X\|Q_X). \tag{7.15}$$

Proof. 这由单调性 (7.13) 和 (7.10) 推出。 □

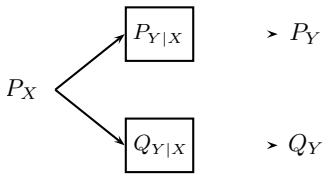
接下来我们讨论*f*-散度的一些更有用的性质，这些性质与定理2.16中KL散度的性质类似：

定理7.5 (*f*-散度的性质)

(a) Non-negativity: $D_f(P\|Q) \ge 0$. If f is strictly convex[2] *at 1, then $D_f(P\|Q) = 0$ if and only if $P = Q$.*

(b) Joint convexity: $(P, Q) \mapsto D_f(P\|Q)$ is a jointly convex function. Consequently, $P \mapsto D_f(P\|Q)$ and $Q \mapsto D_f(P\|Q)$ are also convex.

(c) Conditioning increases f-divergence. Let $P_Y = P_{Y|X} \circ P_X$ and $Q_Y = Q_{Y|X} \circ Q_Y$, or, pictorially,



Then

$$D_f(P_Y\|Q_Y) \le D_f\left(P_{Y|X}\|Q_{Y|X}|P_X\right).$$

Proof. (a) 非负性由单调性得出，取 X 为一元即可。为证明严格正性，假设反证存在某个 $P \ne Q$ 使得 $D_f(P\|Q) = 0$。则存在某个可测的 A 使得 $p = P(A) \ne q = Q(A) > 0$。应用该数据

[2] By strict convexity at 1, we mean for all $s, t \in [0, \infty)$ and $\alpha \in (0, 1)$ such that $\alpha s + \bar{\alpha} t = 1$, we have $\alpha f(s) + (1 - \alpha) f(t) > f(1)$.

处理不等式（其中 $Y = 1\{X \in A\}$），我们得到 $D_f(\text{Ber}(p)\|\text{Ber}(q)) = 0$。考虑两种情况

a $0 < q < 1$：那么 $D_f(\text{Ber}(p)\|\text{Ber}(q)) = qf(\frac{p}{q}) + \bar{q}f(\frac{\bar{p}}{\bar{q}}) = f(1)$；b $q = 1$：那么 $p < 1$ 且 $D_f(\text{Ber}(p)\|\text{Ber}(q)) = f(p) + \bar{p}f'(\infty) = 0$，即 $f'(\infty) = \frac{f(p)}{p-1}$。由于 $x \mapsto \frac{f(x)}{x-1}$ 非递减，我们得出 f 在 $[p, \infty)$ 上是仿射的。两种情况都与假设的 f 在 1 处的严格凸性矛盾。

(b) 凸性由定理5.1证明中的DPI得出。
(c) 回顾条件散度在(7.9)中定义，因此该不等式由单调性得出。另一种理解该不等式的方式是，将其视为对联合凸函数$D_f(P\|Q)$应用琴生不等式的结果。

□

备注 7.4（严格凸性） 正如 KL 散度一样，f-散度永远不是严格凸的，即 $(P, Q) \mapsto D_f(P\|Q)$ 在连接 (P_0, Q_0) 与 (P_1, Q_1) 的区间上可以是线性的。如备注 5.2 所述，当 (P_0, Q_0) 与 (P_1, Q_1) 的支撑集不相交时便是如此。然而，对于 f-散度，即使具有共同支撑集的对也可能出现这种情况。例如，$\text{TV}(\text{Ber}(p), \text{Ber}(q)) = |p - q|$ 是分段线性的。反过来，f 的严格凸性与 f-信息 $I_f(X; Y)$ 的某些理想性质相关，参见练习 I.40。

注记 7.5 (g-散度) 我们注意到，更一般地，我们可以将泛函 $\mathcal{D}(P\|Q)$ 称为“g-散度”，或广义相异性度量，如果它满足以下性质：正性、单调性（如 (7.13) 中所示）、数据处理不等式（DPI，参见 (7.15)）以及对任意 P 有 $\mathcal{D}(P\|P) = 0$。注意，后三个性质通过在 DPI 中取 X 为一元情形蕴含正性。在许多方面，g-散度的性质允许将其解释为本书所采用的一般意义上的信息度量。我们已经看到 f-散度满足两个额外性质：条件化增加散度（CID）以及关于该对的凸性，二者本质上是等价的（参见定理 5.1 的证明）。CID 和凸性并不一定对任意 f-散度成立。事实上，f-散度的任意单调函数都是 g-散度，当然这些不必是单调的（例子参见 (7.6)）。有趣的是，存在不是任何 f-散度的单调变换的 g-散度，参见 [338, 第 V 节]；那里的例子实际上是 $\mathcal{D}(P\|Q) = \alpha - \beta_\alpha(P, Q)$，其中 β 在本书后面的 (14.3) 中定义。另一方面，对于有限字母表，[325] 表明任意 $\mathcal{D}(P\|Q) = \sum_i \phi(P_i, Q_i)$ 是 g-散度当且仅当它是 f-散度。

以下便利性质，作为定理4.5的对应，允许我们将关于f-散度的一般问题简化为有限字母表上的问题。证明见第7.14*节。

定理 7.6 *Let P, Q be two probability measures on $\mathcal{X}$ with σ-algebra $\mathcal{F}$. Given a finite $\mathcal{F}$-measurable partitions $\mathcal{E} = \{E_1, \ldots, E_n\}$ define the distribution $P_\mathcal{E}$ on $[n]$ by $P_\mathcal{E}(i) = P[E_i]$ and $Q_\mathcal{E}(i) = Q[E_i]$. Then*

$$D_f(P\|Q) = \sup_{\mathcal{E}} D_f(P_\mathcal{E}\|Q_\mathcal{E}) \tag{7.16}$$

where the supremum is over all finite $\mathcal{F}$-measurable partitions $\mathcal{E}$.

7.3 假设检验中的总变差和海林格距离

正如我们在整本书中将会发现的，不同的f-散度具有不同的操作意义。例如，χ^2-散度在研究马尔可夫链时很有用（见例33.8和练习VI.19）；在估计中，二值先验的贝叶斯二次风险由Le Cam散度决定（7.7）。在这里，我们讨论TV和Hellinger H^2与二值假设检验问题的关系。我们将在第三部分深入探讨这个问题（并在第六部分回到其复合版本）。在本节中，我们仅为了说明的目的介绍一些基础知识。

binary hypothesis testing 问题如下所述：给定一个观测值（随机变量）X，并且已知要么 $X \sim P$ (一种称为零假设 H_0) 的情形，要么 $X \sim Q$ (备择假设 H_1)。目标是在仅依据 X 的基础上，判定这两个假设中哪一个成立。换句话说，我们希望找到一个（可能是随机的）决策函数 ϕ：$\mathcal{X} \to \{0,1\}$，使得两类错误概率之和

$$P[\phi(X)=1] + Q[\phi(X)=0] \tag{7.17}$$

最小化。

在本节中，我们首先展示对ϕ进行优化自然地引出了TV的概念。随后，我们将看到渐近考虑（当P和Q被替换为$P^{\otimes n}$和$Q^{\otimes n}$时）引出了H^2。我们从前者情况开始。

定理 7.7 *(a)* sup-*representation of* TV*:*

$$\mathrm{TV}(P,Q) = \sup_E P(E) - Q(E) = \frac{1}{2}\sup_{f\in\mathcal{F}} \mathbb{E}_P[f(X)] - \mathbb{E}_Q[f(X)] \tag{7.18}$$

where the first supremum is over all measurable sets E, and the second is over $\mathcal{F} = \{f : \mathcal{X} \to \mathbb{R}, \|f\|_\infty \le 1\}$. *In particular, the minimal total error probability in* (7.17) *is given by*

$$\min_\phi \{P[\phi(X)=1] + Q[\phi(X)=0]\} = 1 - \mathrm{TV}(P,Q), \tag{7.19}$$

where the minimum is over all decision rules $\phi : \mathcal{X} \to \{0,1\}$.[3]

(b) inf-*representation of* 电视 *[403]:*[4] *Provided that the diagonal* $\{(x,x)\colon x \in \mathcal{X}\}$ *is measurable,*

$$\mathrm{TV}(P,Q) = \min_{P_{X,Y}} \{P_{X,Y}[X \neq Y] \colon P_X = P, P_Y = Q\}, \tag{7.20}$$

where minimization is over joint distributions $P_{X,Y}$ *with the property* $P_X = P$ *and* $P_Y = Q$, *which are called* 联轴器 *of P and Q.*

Proof. 设 p, q, μ 如定义 7.1 所述。那么对于任意 $f \in \mathcal{F}$，我们有

$$\int f(x)(p(x)-q(x))d\mu \le \int |p(x)-q(x)|d\mu = 2\mathrm{TV}(P,Q)\,,$$

3 从简单假设检验到复合假设检验，(7.19) 的扩展见 (32.28)。[4] 另一种 inf-表示参见习题 I.36。

这确立了(7.18)中的第二个上确界是TV的下界，因此（通过取$f(x) = 2 \cdot 1_E(x) - 1$）第一个上确界也是如此。对于另一个方向，令$E = \{x : p(x) > q(x)\}$，并注意到

$$0 = \int (p(x) - q(x))d\mu = \int_E + \int_{E^c} (p(x) - q(x))d\mu\,,$$

这意味着$\int_{E^c}(q(x)-p(x))d\mu = \int_E (p(x)-q(x))d\mu$。但这两个积分之和恰好等于$2 \cdot \mathrm{TV}$，这意味着这种$E$的选择在(7.18)中达到等号。

对于 inf-表示　　在开启的情况下，我们注意到给定一个耦合 $P_{X,Y}$，对于我们有$\|f\|_\infty \le 1$，

$$\mathbb{E}_P[f(X)] - \mathbb{E}_Q[f(X)] = \mathbb{E}[f(X) - f(Y)] \le 2P_{X,Y}[X \neq Y]$$

鉴于 (7.18)，这表明 inf-表示总是一个上界。为了证明这个界是紧的，我们按如下方式构建 X, Y：以概率 $\pi \triangleq \int \min(p(x), q(x))d\mu$，我们取 $X = Y = c$，其 c 从密度为 $r(x) = \frac{1}{\pi}\min(p(x), q(x))$ 的分布中采样，而以概率 $1 - \pi$，我们取 X, Y 独立地从分别为 $p_1(x) = \frac{1}{1-\pi}(p(x) - \min(p(x), q(x)))$ 和 $q_1(x) = \frac{1}{1-\pi}(q(x) - \min(p(x), q(x)))$ 的分布中采样。验证该 $P_{X,Y}$ 确实定义了 P 和 Q 的一个耦合，并应用 (7.3) 的最后一个恒等式，即可得到结果。

□

备注 7.6（变分表示） 全变差的上确界表示 (7.18) 将在第 7.13 节中推广到一般的 f-散度。然而，只有 TV 具有在函数类上形如 $\sup_{f\in\mathcal{F}} |\mathbb{E}_P[f] - \mathbb{E}_Q[f]|$ 的表示。这种形式的距离（对于不同的 $\mathcal{F}$ 类）有时被称为积分概率度量（IPMs）。因此，TV 是所有有界函数类 $\mathcal{F}$ 的 IPM 的一个例子。

反过来，inf-表示（7.20）对于其他f-散度没有类似物，显著的例外是Marton的d_2，见注7.15。通过耦合上的inf-表示定义的距离通常被称为*Wasserstein distances*，因此我们可以将TV视为关于$\mathcal{X}$上汉明距离$d(x, x') = 1\{x \neq x'\}$的Wasserstein距离。变分表示的好处在于，在（7.20）中选择特定的耦合给出了$\mathrm{TV}(P, Q)$的上界，而在（7.18）中选择特定的f则给出了下界。

特别相关的是具有多个观测值的测试的特殊情况，其中数据 $X = (X_1, \ldots, X_n)$ 是从 P 或 Q 中独立同分布地抽取的。换句话说，目标是检验

$$H_0 : X \sim P^{\otimes n} \quad \text{vs} \quad H_1 : X \sim Q^{\otimes n}.$$

根据定理7.7，最优总错误概率由$1 - \mathrm{TV}(P^{\otimes n}, Q^{\otimes n})$给出。根据数据处理不等式，$\mathrm{TV}(P^{\otimes n}, Q^{\otimes n})$在$n$ (中是一个非减序列，并且根据定义)被1所界定，因此收敛。人们会预期，当$n \to \infty$时，$\mathrm{TV}(P^{\otimes n}, Q^{\otimes n})$收敛于1，从而假设检验中的错误概率消失。事实证明，对于固定分布$P \neq Q$，大偏差理论（见第16章）表明，$\mathrm{TV}(P^{\otimes n}, Q^{\otimes n})$确实随着$n \to \infty$收敛于一，并且实际上是指数级快速地：

$$\mathrm{TV}(P^{\otimes n}, Q^{\otimes n}) = 1 - \exp(-nC(P, Q) + o(n)), \tag{7.21}$$

其中指数 $C(P, Q) > 0$ 被称为 (16.2) 中给出的 P 和 Q 的 *Chernoff Information*。然而，正如在高维统计问题中经常遇到的那样，如果分布

$P = P_n$ 并且 $Q = Q_n$ 依赖于 n，那么 (7.21) 中的大偏差渐近展开式将不再能直接应用。由于计算两个 n-重乘积分布之间的全变差通常很困难，理解更易处理的 f-散度如何与全变差相关联，或许能为了解其行为提供线索。事实证明，Hellinger 距离恰好适合这一任务。

不久之后，我们将展示TV与Hellinger散度之间的以下关系：

$$\frac{1}{2}H^2(P,Q) \le \mathrm{TV}(P,Q) \le H(P,Q)\sqrt{1-\frac{H^2(P,Q)}{4}} \le 1. \tag{7.22}$$

界（7.22）的直接后果是：

• $H2(P,Q) = 2$，当且仅当 $\mathrm{TV}(P,Q) = 1$。在这种情况下，错误概率为零，因为本质上 P 和 Q 具有不相交的支集。• $H^2(P,Q) = 0$ 当且仅当 $\mathrm{TV}(P,Q) = 0$。在这种情况下，最小的总错误概率为一，意味着最佳检验是随机猜测。• Hellinger 一致性等价于 TV 一致性：我们有

$$H^2(P_n,Q_n) \to 0 \iff \mathrm{TV}(P_n,Q_n) \to 0 \tag{7.23}$$
$$H^2(P_n,Q_n) \to 2 \iff \mathrm{TV}(P_n,Q_n) \to 1; \tag{7.24}$$

然而，收敛速度不必相同。

定理 7.8 *For any sequence of distributions P_n and Q_n, as $n \to \infty$,*

$$\mathrm{TV}(P_n^{\otimes n}, Q_n^{\otimes n}) \to 0 \iff H^2(P_n,Q_n) = o\left(\frac{1}{n}\right)$$
$$\mathrm{TV}(P_n^{\otimes n}, Q_n^{\otimes n}) \to 1 \iff H^2(P_n,Q_n) = \omega\left(\frac{1}{n}\right)$$

Proof. 为方便起见，令$X_1, X_2, \ldots X_n \overset{\text{i.i.d.}}{\sim} Q_n$。那么

$$\begin{aligned} H^2(P_n^{\otimes n}, Q_n^{\otimes n}) &= 2 - 2\mathbb{E}\left[\sqrt{\prod_{i=1}^n \frac{P_n}{Q_n}(X_i)}\right] \\ &= 2 - 2\prod_{i=1}^n \mathbb{E}\left[\sqrt{\frac{P_n}{Q_n}(X_i)}\right] = 2 - 2\left(\mathbb{E}\left[\sqrt{\frac{P_n}{Q_n}}\right]\right)^n \\ &= 2 - 2\left(1 - \frac{1}{2}H^2(P_n,Q_n)\right)^n. \end{aligned} \tag{7.25}$$

我们现在使用 (7.25) 来结束证明。回顾 (7.23)，$\mathrm{TV}(P_n^{\otimes n}, Q_n^{\otimes n}) \to 0$ 当且仅当 $H^2(P_n^{\otimes n}, Q_n^{\otimes n}) \to 0$，这恰好发生在 $H^2(P_n,Q_n) = o(\frac{1}{n})$ 时。类似地，根据 (7.24)，$\mathrm{TV}(P_n^{\otimes n}, Q_n^{\otimes n}) \to 1$ 当且仅当 $H^2(P_n^{\otimes n}, Q_n^{\otimes n}) \to 2$，这进一步等价于 $H^2(P_n,Q_n) = \omega(\frac{1}{n})$。

□

注7.7 性质(7.25)被称为*tensorization*。更一般地，我们有

$$H^2\left(\prod_{i=1}^n P_i, \prod_{i=1}^n Q_i\right) = 2 - 2\prod_{i=1}^n \left(1 - \frac{1}{2}H^2(P_i, Q_i)\right). \tag{7.26}$$

虽然其他一些 f-散度也满足张量性，见第7.12节，但H^2具有夹逼界(7.22)的优势，使其成为检验假设渐近可测性的最便捷工具。

注7.8（角谷二分法）设$P = \prod_{i\geq 1} P_i$和$Q = \prod_{i\geq 1} Q_i$，其中$P_i \ll Q_i$。角谷定理揭示了无限序列空间上这两种分布之间的以下二分性：

• 如果 $\sum_{i\geq 1} H^2(P_i, Q_i) = \infty$，那么 P 和 Q 是相互奇异的（即 $P \perp Q$）。• 如果 $\sum_{i\geq 1} H^2(P_i, Q_i) < \infty$，那么 P 和 Q 是等价的（即 $P \ll Q$ 和 $Q \ll P$）。

在高斯情况下，比如，$P_i = N(\mu_i, 1)$和$Q_i = N(0, 1)$，等价条件简化为$\sum \mu_i^2 < \infty$。

要理解Kakutani准则，注意根据张量积性质(7.26)，我们有

$$H^2(P, Q) = 2 - 2\prod_{i\geq 1}\left(1 - \frac{H^2(P_i, Q_i)}{2}\right).$$

因此，如果 $\prod_{i\geq 1}(1 - \frac{H^2(P_i,Q_i)}{2}) = 0$，或者等价地，$\sum_{i\geq 1} H^2(P_i, Q_i) = \infty$，那么 $H^2(P, Q) = 2$，根据(7.22)，这等价于 $\mathrm{TV}(P, Q) = 0$，从而 $P \perp Q$。如果 $\sum_{i\geq 1} H^2(P_i, Q_i) < \infty$，那么 $H^2(P, Q) < 2$。为了得出 P 与 Q 之间的等价性，注意似然比 $\frac{dP}{dQ} = \prod_{i\geq 1} \frac{dP_i}{dQ_i}$ 满足 $Q(\frac{dP}{dQ} = 0) = 0$ 或 1，根据Kolmogorov的0-1律。详见[143, 定理5.3.5]。

我们以讨论 *contiguity* 的相关概念来结束本节。注意，如果两个分布 P_n 和 Q_n 的全变差为零，则对于所有事件 A，$P_n(A) = Q_n(A) + o(1)$ 一致成立。有时，特别是在统计应用中，我们只关心比较那些概率接近零或一的事件。这引出了以下定义。

定义 7.9（邻接性与渐近分离性）设 $\{P_n\}$ 和 $\{Q_n\}$ 是某个 Ω_n 上的概率测度序列。若对任意可测集序列 $\{A_n\}$，$Q_n(A_n) \to 0$ 蕴涵 $P_n(A_n) \to 0$，则称 P_n 关于 Q_n 是 *contiguous*，记作 $P_n \lhd Q_n$)。若 $P_n \lhd Q_n$ 且 $Q_n \lhd P_n$，则称 P_n 与 Q_n 是 *mutually contiguous* (，记作 $P_n \lhd\rhd Q_n$)。若 $\limsup_{n\to\infty} \mathrm{TV}(P_n, Q_n) = 1$，则称 P_n 与 Q_n (是 *asymptotically separated*，记作 $P_n \triangle Q_n$)。

注意，当 $P_n = P$ 和 $Q_n = Q$ 时，这些定义分别对应 $P \ll Q$ 和 $P \perp Q$，因此应视为它们的渐近版本。显然，$P_n \lhd\rhd Q_n$ 远弱于 $\mathrm{TV}(P_n, Q_n) \to 0$；例如，$P_n(A_n) = 1/2$ 仅保证 $Q_n(A_n)$ 不趋向于

0 或 1。此外，如果 $P_n \lhd Q_n$，那么任何以高 Q_n 概率成功的测试必须以高 P_n 概率失败；换言之，P_n 和 Q_n 无法被完美区分，因此 $\mathrm{TV}(P_n, Q_n) = 1 - \Omega(1)$，特别地，相邻性和分离性是互斥的。此外，许多有趣的测度序列通常满足类似于 Kakutani 的二分类：要么 $P_n \lhd\rhd Q_n$，要么 $P_n \triangle Q_n$，见 [282]。

我们对这些概念的兴趣源于这样一个事实：f-散度对于建立相邻性和分离性是至关重要的。例如，从(7.24)我们可以得出

$$P_n \triangle Q_n \iff \limsup_{n\to\infty} H^2(P_n, Q_n) = 2\,.$$

另一方面，[385，定理III.10.1]表明

$$P_n \lhd Q_n \iff \lim_{\alpha\to 0+} \limsup_{n\to\infty} D_\alpha(P_n\|Q_n) = 0\,,$$

其中 D_α 是 Rényi 散度（定义 7.24）。该准则可以弱化为以下（常用）形式：若 $\chi^2(P_n\|Q_n) = O(1)$，则 $P_n \lhd Q_n$。事实上，通过测度变换和 Cauchy-Schwarz 不等式，$P_n(A_n) = \mathbb{E}_{P_n}[1\{A_n\}] = \mathbb{E}_{Q_n}[\frac{dP_n}{dQ_n} 1\{A_n\}] \le \sqrt{1+\chi^2(P_n\|Q_n)}\sqrt{Q_n(A_n)}$，当 $Q_n(A_n)$ 消失时该式也消失。（关于社区检测和随机图背景下的具体示例，参见习题 I.49。）特别地，互连续的一个充分条件是似然比的有界性：对某些常数 c, C，有 $c \le \frac{P_n}{Q_n} \le C$。

7.4 f-散度与联合范围之间的不等式

在本节中，我们探讨f散度之间的关系，特别是不等式。为了获得一些直观理解，我们首先采用特定方法证明*Pinsker's inequality*，该不等式以KL散度为上界约束总变差。

定理 7.10（Pinsker 不等式）

$$D(P\|Q) \ge (2\log e)\mathrm{TV}^2(P, Q). \tag{7.27}$$

Proof. 只需考虑自然对数即可计算KL散度。首先我们展示，通过数据处理不等式，只需证明伯努利分布的结果即可。对于任何事件 E，令 $Y = 1\{X \in E\}$，这是参数为 $P(E)$ 或 $Q(E)$ 的伯努利分布。根据DPI，$D(P\|Q) \ge d(P(E)\|Q(E))$。如果Pinsker不等式对所有伯努利分布成立，我们有

$$\sqrt{\frac{1}{2}D(P\|Q)} \ge \mathrm{TV}(\mathrm{Ber}(P(E)), \mathrm{Ber}(Q(E)) = |P(E) - Q(E)|$$

对所有 E 取上确界，根据定理 7.7，得到 $\sqrt{\frac{1}{2}D(P\|Q)} \ge \sup_E |P(E) - Q(E)| = \mathrm{TV}(P, Q)$。

二元情形很容易由 $p \mapsto d(p\|q)$ 的二阶泰勒展开（带积分余项形式）推出：

$$d(p\|q) = \int_q^p \frac{p-t}{t(1-t)}dt \geq 4\int_q^p (p-t)dt = 2(p-q)^2$$

和 $\mathrm{TV}(\mathrm{Ber}(p), \mathrm{Ber}(q)) = |p-q|$。 □

Pinsker 不等式在本书中已被多次使用。这里还有另一个推论，将在练习 I.62 和 I.63（Szemerédi 正则性）中进一步探讨。

推论 7.11（Tao 不等式 [414]） *Let $Y \to X \to X'$ be a Markov chain with $Y \in [-1, 1]$. Then*

$$\mathbb{E}[|\,\mathbb{E}[Y|X] - \mathbb{E}[Y|X']|^2] \leq \frac{2}{\log e} I(Y; X|X')\,. \tag{7.28}$$

The same estimate holds for Y ranging over a unit ball in any normed vector space with $|\cdot|$ in the LHS being the norm.

Proof. 如果 Y_1 和 Y_2 是两个取值于 $[-1, 1]$ 的随机变量，那么由 (7.20)，存在一个耦合使得 $\mathbb{P}[Y_1 \neq Y_2] \leq \mathrm{TV}(P_{Y_1}, P_{Y_2})$。因此，$|\,\mathbb{E}[Y_1] - \mathbb{E}[Y_2]| \leq 2\mathrm{TV}(P_{Y_1}, P_{Y_2})$。现在，将此应用于 $P_{Y_1} = P_{Y|X=a}$ 和 $P_{Y_2} = P_{Y|X'=b}$，我们得到

$$|\,\mathbb{E}[Y|X=a] - \mathbb{E}[Y|X'=b]|^2 \leq 4\mathrm{TV}^2(P_{Y|X=a}, P_{Y|X'=b}) \leq \frac{2}{\log e} D(P_{Y|X=a}\|P_{Y|X'=b})\,,$$

其中，我们在最后一步应用了Pinsker不等式。通过对$(a, b) \sim P_{X,X'}$取平均并注意到 $D(P_{Y|X}\|P_{Y|X'}|P_{X,X'}) = I(Y$，证明得以完成；根据假设，$P_{Y|X,X'} = P_{Y|X}$导致了$X|X')$。 □

Pinsker不等式和Tao不等式在常数无法改进的意义上都是精确的。例如，对于(7.27)，我们可以取$P_n = \mathrm{Ber}(\frac{1}{2} + \frac{1}{n})$和$Q_n = \mathrm{Ber}(\frac{1}{2})$，并计算得出$\frac{D(P_n\|Q_n)}{\mathrm{TV}^2(P_n,Q_n)} \to 2\log e$ 当$n \to \infty$时。（这一点最好通过检查命题2.21中的局部二次行为来看出。）然而，这并不意味着不等式(7.27)不可改进，因为右侧可以用$\mathrm{TV}(P, Q)$的其他函数替换，并带有额外的高阶项。事实上，已知有若干这样的Pinsker不等式的改进。但什么是最佳不等式？此外，另一个自然的问题是反向不等式：我们能否用$\mathrm{TV}(P, Q)$来上界$D(P\|Q)$？

解决这些问题取决于对给定一对*f*-散度的*joint range* (可能值集合)的表征。这种比较*f*-散度的系统方法（与上面我们给出的定理7.10的特定证明相反）是本节剩余部分的主题。

定义 7.12（联合范围）考虑两个 *f*-散度 $D_f(P\|Q)$ 和 $D_g(P\|Q)$。它们的联合范围是由下式定义的 $[0, \infty]^2$ 的一个子集

$$\mathcal{R} \triangleq \{(D_f(P\|Q), D_g(P\|Q)) :\ P, Q \text{ 是某个可测空间 }\}\,.\ \text{上的概率测度}$$

此外，所有{v*}元分布上的联合范围定义为

$$\mathcal{R}_k \triangleq \{(D_f(P\|Q), D_g(P\|Q)) : P, Q \text{ are probability measures on } [k]\}.$$

例如，图7.1给出了KL散度与总变差之间的联合范围$\mathcal{R}$。根据定义，区域$\mathcal{R}$的下边界给出了Pinsker不等式的最优改进：

$$D(P\|Q) \geq F(\mathrm{TV}(P,Q)), \quad F(\epsilon) \triangleq \inf_{(P,Q):\mathrm{TV}(P,Q)=\epsilon} D(P\|Q) = \inf\{s : (\epsilon, s) \in \mathcal{R}\}.$$

同样从图7.1中我们可以看出，由于缺乏上界，无法用$\mathrm{TV}(P,Q)$来从上方界定$D(P\|Q)$。

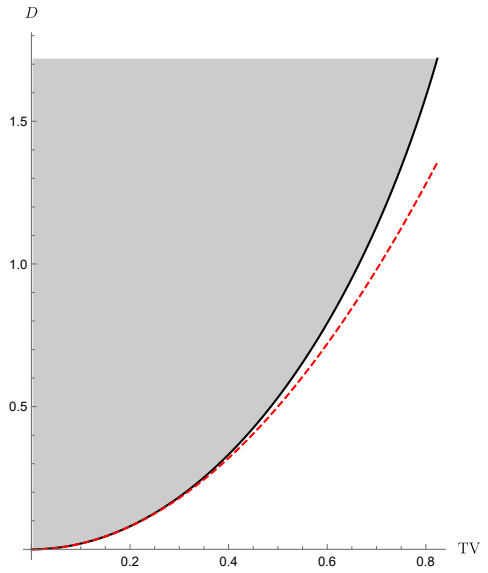


图7.1 总变差与KL散度的联合范围。虚线表示由Pinsker不等式（7.27）给出的二次下界。

联合范围 $\mathcal{R}$ 可能难以刻画，因为我们需要在所有可测空间上考虑 P, Q；另一方面，对于小 k 的区域 $\mathcal{R}_k$ 是容易获得的（至少在数值上）。回顾定理7.10中Pinsker不等式的证明，我们看到关键步骤是归约到伯努利分布。自然要问：为了得到完整的联合范围，是否可能归约到二元情形？事实证明，考虑四元分布，或者二元分布的凸包，总是足够的。

定理 7.13（哈勒莫斯-瓦伊达 [214]）

$$\mathcal{R} = \mathrm{co}(\mathcal{R}_2) = \mathcal{R}_4.$$

where 协作 *denotes the convex hull with a natural extension of convex operations to* $[0,\infty]^2$.

我们将依赖于凸分析中的以下著名结果（例如参见[145，第2章，定理18]）。

引理 7.14 (Fenchel-Eggleston-Carathéodory 定理) *Let $S \subseteq \mathbb{R}^d$ and $x \in \mathrm{co}(S)$. Then there exists a set of $d+1$ points $S' = \{x_1, x_2, \ldots, x_{d+1}\} \in S$ such that $x \in \mathrm{co}(S')$. If S has at most d connected components, then d points are enough.*

Proof. 我们的证明将由三个断言组成：

• *Claim 1:* $\mathrm{co}(\mathcal{R}_2) \subset \mathcal{R}_4$; • *Claim 2:* $\mathcal{R}_k \subset \mathrm{co}(\mathcal{R}_2)$; • *Claim 3:* $\mathcal{R} = \mathcal{R}_4$ 。

注意，命题1-2证明了最有趣的部分：$\bigcup_{k=1}^{\infty} \mathcal{R}_k = \mathrm{co}(\mathcal{R}_2)$。命题3更偏技术性，其证明可在[214]中找到。然而，定理7.6中的逼近结果表明，$\mathcal{R}$是$\bigcup_{k=1}^{\infty} \mathcal{R}_k$的闭包。因此，为了得到$D_f$与$D_g$之间的不等式，命题1-2就足够了。

我们从命题1开始。给定某个空间$\mathcal{X}$上的任意两对分布(P_0, Q_0)和(P_1, Q_1)，并给定任意$\alpha \in \in [0,1]$，定义随机变量(X, B)的两个联合分布，其中$P_B = Q_B = \sim \mathrm{Ber}(\alpha)$、$P_{X|B=i} = P_i$，且$Q_{X|B=i} = Q_i$对于$i = \in 0,1$。那么由(7.9)我们得到

$$D_f(P_{X,B} \| Q_{X,B}) = \bar{\alpha} D_f(P_0 \| Q_0) + \alpha D_f(P_1 \| Q_1)\,,$$

并且对于D_g也同样如此。因此，$\mathcal{R}$是凸的。接下来，注意

$$\mathcal{R}_2 = \tilde{\mathcal{R}}_2 \cup \{(pf'(\infty), pg'(\infty)) : p \in (0,1]\} \cup \{(qf(0), qg(0)) : q \in (0,1]\}\,,$$

其中$\tilde{\mathcal{R}}_2$ 是连续映射的 $(0,1)^2$ 的像

$$(p,q) \mapsto \left(D_f(\mathrm{Ber}(p) \| \mathrm{Ber}(q)), D_g(\mathrm{Ber}(p) \| \mathrm{Ber}(q)) \right).$$

由于 $(0,0) \in \tilde{\mathcal{R}}_2$，我们看到无论哪些 $f(0), f'(\infty), g(0), g'(\infty)$ 是无限的，集合 $\mathcal{R}_2 \cap \mathbb{R}^2$ 都是连通的。因此，根据引理 7.14，$\mathrm{co}(\mathcal{R}_2 \cap \mathbb{R}^2)$ 中的任何一点都是 $\mathcal{R}_2 \cap \mathbb{R}^2$ 中两点的组合，而根据上述论证，这是 $\mathcal{R}_4$ 的子集。最后，不难看出 $\mathrm{co}(\mathcal{R}_2) \backslash \mathbb{R}^2 \subset \mathcal{R}_4$，这完成了 $\mathrm{co}(\mathcal{R}_2) \subset \mathcal{R}_4$ 的证明。

接下来，我们证明断言2。在$[k]$上固定P, Q，并分别记其PMF为(p_j)和(q_j)。注意，在不改变$D_f(P\|Q)$或$D_g(P\|Q)$ (的情况下，或许可以通过将k增加1)，使得当$j > $为1且$q_1 = $为0时，$q_j > $为0，因此我们如此假设。对于$j > $为1，记$\phi_j = \frac{p_j}{q_j}$，并考虑集合

$$\mathcal{S} = \left\{ \tilde{Q} = (\tilde{q}_j)_{j \in [k]} : \tilde{q}_j \geq 0, \sum \tilde{q}_j = 1, \tilde{q}_1 = 0, \sum_{j=2}^{k} \tilde{q}_j \phi_j \leq 1 \right\}.$$

我们还定义了一个子集 $\mathcal{S}_e \subset \mathcal{S}$，由两种类型的点 $\tilde{Q}$ 组成：

1 $\tilde{q}_j = 1$ 对于某个 $j \geq 2$ 和 $\phi_j \leq 1$。 2 $\tilde{q}_{j_1} + \tilde{q}_{j_2} = 1$ 对于某个 $j_1, j_2 \geq 2$ 和 $\tilde{q}_{j_1}\phi_{j_1} + \tilde{q}_{j_2}\phi_{j_2} = 1$.

可以看出，$\mathcal{S}_e$ 恰好是 $\mathcal{S}$ 的所有极点。事实上，任何具有 $\sum_{j\geq 2} \tilde{q}_j\phi_j < 1$ 且含有多于一个非零原子的 $\tilde{Q} \in \mathcal{S}$ 都不可能是极值点（因为只有一个活跃的线性约束 $\sum_j \tilde{q}_j = 1$）。类似地，具有 $\sum_{j\geq 2} \tilde{q}_j\phi_j = 1$ 的 $\tilde{Q}$ 只有在包含一个或两个非零原子时才能是极值点。

我们接下来断言，$\mathcal{S}$中的任意一点都可以表示为$\mathcal{S}_e$中有限多个点的凸组合。这可以如下看出。首先，我们可以将$\mathcal{S}$和$\mathcal{S}_e$视为$\mathbb{R}^{k-1}$的子集。由于$\mathcal{S}$显然是闭且凸的，根据Krein-Milman定理（见[12，定理7.68]），$\mathcal{S}$与其极值点凸包的闭包重合。由于$\mathcal{S}_e$是紧的（因此是闭的），co($\mathcal{S}_e$)也是紧的[12，推论5.33]。因此，我们有$\mathcal{S} = \text{co}(\mathcal{S}_e)$，特别地，存在概率权重$\{\alpha_i\colon\ i \in [m]\}$和极值点$\tilde{Q}_i \in \mathcal{S}_e$，使得

$$Q = \sum_{i=1}^{m} \alpha_i \tilde{Q}_i \,. \tag{7.29}$$

接下来，对于每个 $\tilde{Q}$，我们按如下方式关联 $\tilde{P} = (\tilde{p}_j)_{j\in[k]}$:

$$\tilde{p}_j = \begin{cases} \phi_j \tilde{q}_j, & j \in \{2, \ldots, k\}\,, \\ 1 - \sum_{j=2}^{k} \phi_j \tilde{q}_j, & j = 1 \end{cases}$$

然后我们有

$$\tilde{Q} \mapsto D_f(\tilde{P}\|\tilde{Q}) = \sum_{j\geq 2} \tilde{q}_j f(\phi_j) + f'(\infty)\tilde{p}_1$$

仿射映射 $\mathcal{S}$ 到 $[0, \infty]$（注意 $f(0)$ 或 $f'(\infty)$ 可以等于 ∞）。特别地，如果我们用 $\tilde{P}_i = \tilde{P}(\tilde{Q}_i)$ 表示分解（7.29）中对应于 $\tilde{Q}_i$ 的项，我们得到

$$D_f(P\|Q) = \sum_{i=1}^{m} \alpha_i D_f(\tilde{P}_i\|\tilde{Q}_i)\,,$$

同样地，对于 $D_g(P\|Q)$。我们还需证明 $(\tilde{P}_i, \tilde{Q}_i)$ 至多支撑在两个点上，这验证了 $\mathcal{R}_k$ 中的任何元素都是 $\mathcal{R}_2$ 的 k 个元素的凸组合。实际上，对于 $\tilde{Q} \in \mathcal{S}_e$，集合 $\{j \in [k] : \tilde{q}_j > 0$ 或 $\tilde{p}_j > 0\}$ 的基数至多为二（对于第二类极值点，我们注意到 $\tilde{p}_{j_1} + \tilde{p}_{j_2} = 1$ 意味着 $\tilde{p}_1 = 0$）。至此，完成 Claim 2 的证明。

□

7.5 计算关节范围的示例

在本节中，我们展示如何应用Harremoës和Vajda的方法来证明各种{v*}散度之间最佳可能的比较不等式。

7.5.1 Hellinger距离与总变差

H^2 与 TV 在二值分布上的联合范围 $\mathcal{R}_2$ 简单地是:

$$\mathcal{R}_2 = \left\{(2(1-\sqrt{pq}-\sqrt{\bar{p}\bar{q}}), |p-q|) : 0 \le p \le 1, 0 \le q \le 1\right\}.$$

如图7.2所示的非凸灰色区域。根据定理7.13，它们的完整联合范围$\mathcal{R}$是$\mathcal{R}_2$的凸包，这恰好由先前在第7.3节展示的夹逼边界(7.22)精确描述。这意味着(7.22)是不可改进的。实际上，当t从0变化到1时，

• 上边界由 $P = \mathrm{Ber}(\frac{1+t}{2}), Q = \mathrm{Ber}(\frac{1-t}{2})$ 达到，• 下边界由 $P = (1-t, t, 0), Q = (1-t, 0, t)$ 达到。

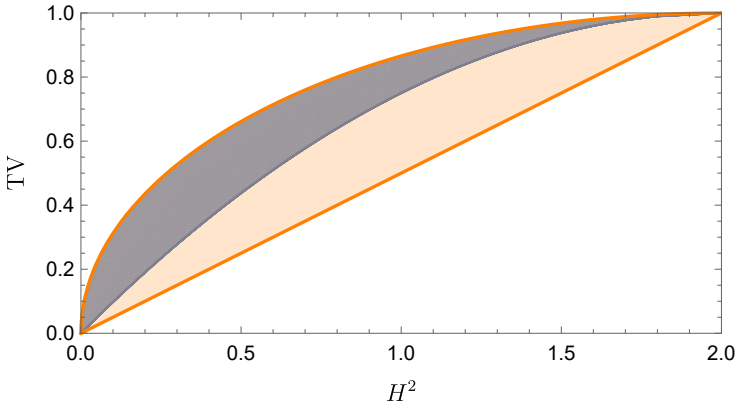


图7.2 TV的联合范围$\mathcal{R}$和H^2由(7.22)表征，即灰色区域$\mathcal{R}_2$的凸包。

7.5.2 KL散度与总变差

KL与TV之间的联合范围先前在图7.1中展示。尽管没有已知的闭式表达式，但下边界（见图7.1）的以下参数公式是已知的[163，定理1]:

$$\begin{cases} \mathrm{TV}_t = \frac{1}{2}t\left(1 - \left(\coth(t) - \frac{1}{t}\right)^2\right) \\ D_t = -t^2\mathrm{csch}^2(t) + t\coth(t) + \log(t\,\mathrm{csch}(t)) \end{cases}, \quad t \ge 0. \tag{7.30}$$

其中我们取自然对数。以下是[427]给出的一个推论（较弱的界）：

$$D(P\|Q) \ge \text{对数}\frac{1+\mathrm{TV}(P,Q)}{\mathrm{V}(P,Q)}\,1\frac{-\mathrm{TV}(P,Q)}{1+\mathrm{TV}(P,Q)}\,\text{对数}\,e.\,2\mathrm{T} \tag{7.31}$$

两个界都比Pinsker不等式(7.27)更强。注意以下推论:

• $D \to 0 \Rightarrow \mathrm{TV} \to 0$，这可以从 Pinsker 不等式推导出来；• $\mathrm{TV} \to 1 \Rightarrow D \to \infty$，因此 $D = O(1)$ 意味着 TV 被限制在远离 1 的范围内。这可以从 (7.30) 或 (7.31) 得到，但不能从 Pinsker 不等式得到。

7.5.3 χ^2-散度与总变差

命题 7.15 *We have the following bound*

$$\chi^2(P\|Q) \geq f(\mathrm{TV}(P,Q)) \geq 4\mathrm{TV}^2(P,Q), \qquad f(t) = \begin{cases} 4t^2. & t \leq \frac{1}{2} \\ \frac{t}{1-t} & t \geq \frac{1}{2}. \end{cases}, \tag{7.32}$$

where the function f is a convex increasing bijection of $[0,1)$ *onto* $[0,\infty)$ *. Furthermore, for every* $s \geq f(t)$ *there exists a pair of distributions such that* $\chi^2(P\|Q) = s$ *and* 电视$(P,Q) = t$.

Proof. 我们断言二元联合范围是凸的。事实上，

$$\mathrm{TV}(\mathrm{Ber}(p),\mathrm{Ber}(q)) = |p-q| \triangleq t, \quad \chi^2(\mathrm{Ber}(p)\|\mathrm{Ber}(q)) = \frac{(p-q)^2}{q(1-q)} = \frac{t^2}{q(1-q)}.$$

给定 $|p-q| = t$，让我们确定 $q(1-q)$ 的可能范围。通过选择 $p = t, q = 0$，$q(1-q)$ 的最小值总是 0。如果 $t \leq 1/2$，则最大值为 $1/4$（通过选择 $p = 1/2 - t$，$q = 1/2$）。如果 $t > 1/2$，那么我们最多可以通过设置 $p = 0$ 和 $q = t$) 得到 $t(1-t)$ (。因此如所声称的那样，我们得到 $\chi^2(\mathrm{Ber}(p)\|\mathrm{Ber}(q)) \geq f(|p-q|)$。$f$ 的凸性随之而来，因为其导数单调递增。显然，$f(t) \geq 4t^2$，因为 $t(1-t) \leq \frac{1}{4}$。 □

7.6 各种分歧之间的不等式选择

本节介绍了一系列有用的不等式。更完整的论述可参阅[373]和[424，第2.4节]。这些不等式大多为联合范围，这意味着它们是紧的。

- KL 与 TV：见 (7.30)。对于离散分布，在相反方向存在部分比较（“反向 Pinsker”，参见 [373, 第VI节]）：

$$D(P\|Q) \leq \log\left(1 + \frac{2}{Q_{min}}\mathrm{TV}(P,Q)^2\right) \leq \frac{2\log e}{Q_{min}}\mathrm{TV}(P,Q)^2, \qquad Q_{min} = \min_x Q(x)$$

- KL与Hellinger：

$$D(P||Q) \geq 2\log\frac{2}{2 - H^2(P,Q)} \geq \log e \cdot H^2(P,Q). \tag{7.33}$$

第一个不等式给出了联合范围，并在$P = \mathrm{Ber}(0)$、$Q = \mathrm{Ber}(q)$处达到。对于固定的H^2，一般来说$D(P||Q)$没有有限上界，这从$P = \mathrm{Ber}(p)$、$Q = \mathrm{Ber}(0)$可以看出。

在相反方向上有一个部分结果（Bonami-Beckner半群的对数Sobolev不等式，参见[122，定理A.1]和练习I.64）：

$$D(P\|Q) \le \frac{\log(\frac{1}{Q_{min}}-1)}{1-2Q_{min}}\left(1-(1-H^2(P,Q))^2\right), \qquad Q_{min}=\min_x Q(x)$$

另一个部分结果见练习 I.59。

- KL vs χ^2:

$$0 \le D(P||Q) \le \log(1+\chi^2(P||Q)) \le \log e \cdot \chi^2(P\|Q). \tag{7.34}$$

左侧不等式表明，不可能存在以 χ^2 表示的 KL 下界。

- TV与Hellinger：参见(7.22)。来自[186]的一个有用的简化界如下所示：

$$\mathrm{TV}(P,Q) \le \sqrt{-2\ln\left(1-\frac{H^2(P,Q)}{2}\right)}$$

- Le Cam 与 Hellinger [273, p. 48]:

$$\frac{1}{2}H^2(P,Q) \le \mathrm{LC}(P,Q) \le H^2(P,Q). \tag{7.35}$$

- Le Cam 与 Jensen-Shannon [422]：

$$\mathrm{LC}(P,Q)\log e \le \mathrm{JS}(P,Q) \le \mathrm{LC}(P,Q)\cdot 2\log 2 \tag{7.36}$$

- $\chi 2$ 与电视：全联合范围由(7.32)给出。两个简单的推论是：

$$\mathrm{TV}(P,Q) \le \frac{1}{2}\sqrt{\chi^2(P\|Q)} \tag{7.37}$$

$$\mathrm{TV}(P,Q) \le \max\left\{\frac{1}{2}, \frac{\chi^2(P\|Q)}{1+\chi^2(P\|Q)}\right\} \tag{7.38}$$

其中第二个对于将TV界定在远离1的范围内是有用的。

- JS 与 TV：完整联合区域由下式给出

$$2d\left(\frac{1-\mathrm{TV}(P,Q)}{2}\Big\|\frac{1}{2}\right) \le \mathrm{JS}(P,Q) \le \mathrm{TV}(P,Q)\cdot 2\log 2\,. \tag{7.39}$$

下界是Fano不等式的结果。对于上界，注意到对于$p,q\in[0,1]$和$|p-q|=\tau$，$d(p\|\frac{p+q}{2})$的最大值在$p=0,q=\tau$ (处取得，这源于$d(\cdot\|\cdot)$)的凸性，因此，二元联合范围由$\tau\mapsto d(\tau\|\tau/2)+d(1-\tau\|1-\tau/2)$给出。由于后者是凸的，其凹包络是一条连接端点$\tau=0$和$\tau=1$的直线。

7.7 高斯分布间的差异

为了更好地理解f-散度的行为，这里我们收集了高斯分布之间散度的表达式（以及渐近展开式）。

1 全变分：

$$\mathrm{TV}(\mathcal{N}(0,\sigma^2),\mathcal{N}(\mu,\sigma^2)) = 2\Phi\left(\frac{|\mu|}{2\sigma}\right) - 1 = \int_{-\frac{|\mu|}{2\sigma}}^{\frac{|\mu|}{2\sigma}} \varphi(x)\mathrm{d}x = \frac{|\mu|}{\sqrt{2\pi}\sigma} + O(\mu^2), \quad \mu \to 0. \tag{7.40}$$

2 Hellinger距离：

$$H^2(\mathcal{N}(0,\sigma^2)\|\mathcal{N}(\mu,\sigma^2)) = 2 - 2e^{-\frac{\mu^2}{8\sigma^2}} = \frac{\mu^2}{4\sigma^2} + O(\mu^3), \quad \mu \to 0. \tag{7.41}$$

更一般地，

$$H^2(\mathcal{N}(\mu_1,\Sigma_1)\|\mathcal{N}(\mu_2,\Sigma_2)) = 2 - 2\frac{|\Sigma_1|^{\frac{1}{4}}|\Sigma_2|^{\frac{1}{4}}}{|\bar{\Sigma}|^{\frac{1}{2}}} \exp\left\{-\frac{1}{8}(\mu_1-\mu_2)'\bar{\Sigma}^{-1}(\mu_1-\mu_2)\right\},$$

其中 $\bar{\Sigma} = \frac{\Sigma_1+\Sigma_2}{2}$。

3 KL 散度：

$$D(\mathcal{N}(\mu_1,\sigma_1^2)\|\mathcal{N}(\mu_2,\sigma_2^2)) = \frac{1}{2}\log\frac{\sigma_2^2}{\sigma_1^2} + \frac{1}{2}\left(\frac{(\mu_1-\mu_2)^2}{\sigma_2^2} + \frac{\sigma_1^2}{\sigma_2^2} - 1\right)\log e. \tag{7.42}$$

关于更一般的结果，请参见（2.8）。

4 χ^2-散度：

$$\chi^2(\mathcal{N}(\mu,\sigma^2)\|\mathcal{N}(0,\sigma^2)) = e^{\frac{\mu^2}{\sigma^2}} - 1 = \frac{\mu^2}{\sigma^2} + O(\mu^3), \quad \mu \to 0 \tag{7.43}$$

$$\chi^2(\mathcal{N}(\mu,\sigma^2)\|\mathcal{N}(0,1)) = \begin{cases} \frac{e^{\mu^2/(2-\sigma^2)}}{\sigma\sqrt{2-\sigma^2}} - 1 & \sigma^2 < 2 \\ \infty & \sigma^2 \geq 2 \end{cases} \tag{7.44}$$

5 高斯混合的 χ^2-散度 [225]（关于适用于一般混合分布的 Ingster-Suslina 方法，另见练习 I.48）：

$$\chi^2(P * \mathcal{N}(0,\Sigma)\|\mathcal{N}(0,\Sigma)) = \mathbb{E}[e^{\langle \Sigma^{-1}X, X'\rangle}] - 1\,, \qquad X \perp\!\!\!\perp X' \sim P\,. \tag{7.45}$$

7.8 基于 f-散度的互信息

给定一个 f-散度 D_f，我们可以定义 *f-information*，即互信息的一种扩展，如下所示：

$$I_f(X;Y) \triangleq D_f(P_{X,Y}\|P_X P_Y)\,. \tag{7.46}$$

定理 7.16（数据处理）*For $U \to X \to Y$, we have $I_f(U;\ Y) \leq I_f(U;\ X)$.*

Proof. 注意，$I_f(U;\ X) = D_f(P_{U,X}\|P_U P_X) \geq D_f(P_{U,Y}\|P_U P_Y) = I_f(U;\ Y)$，其中我们将数据处理定理7.4应用于（可能是随机的）映射 $(U,X) \mapsto (U,Y)$。另见备注3.4。

□

互信息的一个有用性质是$X \perp\!\!\!\perp Y$当且仅当$I(X;\ Y) = 0$。其推广是，对于$X \to Y \to Z$，我们有$I(X;\ Y) = I(X;\ Z)$当且仅当$X \to Z \to Y$。这两者是否对I_f成立，取决于f的严格凸性，参见练习I.40。

标准互信息的另一个常用性质是*subadditivity*：如果$P_{A,B|X} = P_{A|X}P_{B|X}$ (，即A和B在给定X)的条件下条件独立，那么

$$I(X;A,B) \le I(X;A) + I(X;B). \tag{7.47}$$

然而，其他f信息的概念与次可加性有着复杂的关系：

1 与χ^2-散度对应的f-信息，

$$I_{\chi^2}(X;Y) \triangleq \chi^2(P_{X,Y}\|P_XP_Y) \tag{7.48}$$

通常不是次可加的。当I_{χ^2}是次可加时，有两种特殊情况：如果$I_{\chi^2}(X、A)$或$I_{\chi^2}(X、B)$中的一个是小的[202, 引理26]，或者如果$X \sim \mathrm{Ber}(1/2)$信道$P_{A|X}$和$P_{B|X}$是BMS（第19.4*节），参见[1]。

2 与全变差 $I_{\mathrm{TV}}(X$ 相对应的 f-信息；$Y) \triangleq \mathrm{TV}(P_{X,Y}, P_XP_Y)$ 不是次可加的。此外，它还具有“卡住”这种反直觉的行为。例如，取 $X \sim \mathrm{Ber}(1/2)$ 和 $A = \mathsf{BSC}_\delta(X)$、$B = \mathsf{BSC}_\delta(X)$——$X$ 在 BSC 上的两个独立观测。一个简单的计算（习题 I.35）表明：

$$I_{\mathrm{TV}}(X;A,B) = I_{\mathrm{TV}}(X;A) = I_{\mathrm{TV}}(X;B)\,.$$

换句话说，额外的观察丝毫不会增加电视信息。这是经济学中著名的羊群效应的主要原因[30]。

3 *symmetric KL-information*

$$I_{\mathrm{SKL}}(X;Y) \triangleq D(P_{X,Y}\|P_XP_Y) + D(P_XP_Y\|P_{X,Y}), \tag{7.49}$$

对应于 *symmetric KL divergence* (的 f 信息也称为 *Jeffreys divergence*)

$$D_{\mathrm{SKL}}(P,Q) \triangleq D(P\|Q) + D(Q\|P), \tag{7.50}$$

非常令人惊讶地[265]满足 *additivity property*：

$$I_{\mathrm{SKL}}(X;A,B) = I_{\mathrm{SKL}}(X;A) + I_{\mathrm{SKL}}(X;B). \tag{7.51}$$

让我们在离散情况下证明这一点。首先注意以下与 I_{SKL} 等价的表达式：

$$I_{\mathrm{SKL}}(X;Y) = \sum_{x,x'} P_X(x)P_X(x')D(P_{Y|X=x}\|P_{Y|X=x'})\,. \tag{7.52}$$

从(7.52)我们通过可加性$D(P_{A,B|X=x}\|P_{A,B|X=x'}) = D(P_{A|X=x}\|P_{A|X=x'}) + D(P_{B|X=x}\|P_{B|X=x'})$得到(7.51)。为了证明(7.52)，首先考虑显而易见的恒等式：

$$\sum_{x,x'} P_X(x)P_X(x')[D(P_Y\|P_{Y|X=x'}) - D(P_Y\|P_{Y|X=x})] = 0$$

其重写为

$$\sum_{x,x'} P_X(x)P_X(x') \sum_y P_Y(y) \log \frac{P_{Y|X}(y|x)}{P_{Y|X}(y|x')} = 0 . \tag{7.53}$$

接下来，根据定义，

$$I_{\mathrm{SKL}}(X;Y) = \sum_{x,y} [P_{X,Y}(x,y) - P_X(x)P_Y(y)] \log \frac{P_{X,Y}(x,y)}{P_X(x)P_Y(y)} .$$

由于 $P_{X,Y}$ 和 $P_X P_Y$ 的边缘分布相同，我们可以将 $\log \frac{P_{X,Y}(x,y)}{P_X(x)P_Y(y)}$ 替换为任意 f 下的任意 $\log \frac{P_{Y|X}(y|x)}{f(y)}$。我们选择 $f(y) = P_{Y|X}(y|x')$ 来得到

$$I_{\mathrm{SKL}}(X;Y) = \sum_{x,y} [P_{X,Y}(x,y) - P_X(x)P_Y(y)] \log \frac{P_{Y|X}(y|x)}{P_{Y|X}(y|x')} .$$

现在对 $P_X(x')$ 进行平均，并应用（7.53）以消除 $[\cdots]$ 中的第二项，我们得到（7.52）。关于 I_{SKL} 的另一个有趣性质，请参见练习 I.54。

7.9 经验分布与 χ^2 信息

考虑一个任意信道 $P_{Y|X}$ 和某个输入分布 P_X。假设对于 $i = 1, \ldots, n$，我们有 $X_i \overset{\text{i.i.d.}}{\sim} P_X$。令

$$\hat{P}_n = \frac{1}{n} \sum_{i=1}^{n} \delta_{X_i}$$

表示对应于该样本的经验分布。令$P_Y = P_{Y|X} \circ P_X$为对应于P_X的输出分布，$P_{Y|X} \circ \hat{P}_n$为对应于$\hat{P}_n$ (一个随机分布)的输出分布。注意当$P_{Y|X=x}(\cdot) = \phi(\cdot - x)$时，其中$\phi$是固定密度，我们可以将$P_{Y|X} \circ \hat{P}_n$视为一个*kernel density estimator (KDE)*，其密度为 $\hat{p}_n(x) = (\phi * \hat{P}_n)(x) = \frac{1}{n} \sum_{i=1}^{n} \phi(X_i - x)$。此外，利用$\mathbb{E}[P_{Y|X} \circ \hat{P}_n] = P_Y$这一事实，我们有

$$\mathbb{E}[D(P_{Y|X} \circ \hat{P}_n \| P_X)] = D(P_Y \| P_X) + \mathbb{E}[D(P_{Y|X} \circ \hat{P}_n \| P_Y)] ,$$

其中第一项表示由于卷积导致的KDE偏差，并随着ϕ的带宽增加而增大，而第二项表示KDE的变异性，并随着ϕ的带宽减小而减小。令人惊讶的是，第二项由I_{χ^2}信息精确给出（在二倍因子范围内）。更准确地说，我们证明了以下结果。

命题 7.17

$$\mathbb{E}[D(P_{Y|X} \circ \hat{P}_n \| P_Y)] \le \log \left(1 + \frac{1}{n} I_{\chi^2}(X;Y) \right) , \tag{7.54}$$

where $I_{\chi}2(X;Y)$ is defined in (7.48). Furthermore,

$$\liminf_{n\to\infty} n\,\mathbb{E}[D(P_{Y|X}\circ\hat{P}_n\|P_Y)] \geq \frac{\log e}{2} I_{\chi^2}(X;Y)\,. \tag{7.55}$$

In particular, $\mathbb{E}[D(P_{Y|X}\circ\hat{P}_n\|P_Y)] = O(1/n)$ if $I_{\chi^2}(X;\ Y) < \infty$ and $\omega(1/n)$ otherwise.

在第25.4*节中，我们将讨论这一简单界限的扩展，特别是表明在许多情况下，大约$n = \exp\{I(X;\ Y)+K\}$个观测值足以确保$D(P_{Y|X}\circ\hat{P}_n\|P_Y) = e^{-O(K)}$。

Proof. 首先，一个简单的计算表明

$$\mathbb{E}[\chi^2(P_{Y|X}\circ\hat{P}_n\|P_Y)] = \frac{1}{n} I_{\chi^2}(X;Y)\,.$$

然后由 (7.34) 和 Jensen 不等式，我们得到 (7.54)。

为了得到(7.55)中的下界，令$\bar{X}$从样本$\{X_1,\ldots,X_n\}$中均匀随机抽取，并令$\bar{Y}$为输入$\bar{X}$时$P_{Y|X}$通道的输出。根据这个定义，我们有：

$$\mathbb{E}[D(P_{Y|X}\circ\hat{P}_n\|P_Y)] = I(X^n;\bar{Y})\,. \tag{7.56}$$

接下来，应用(6.2)得到

$$I(X^n;\bar{Y}) \geq \sum_{i=1}^{n} I(X_i;\bar{Y}) = nI(X_1;\bar{Y})\,.$$

最后，请注意

$$I(X_1;\bar{Y}) = D\left(\frac{n-1}{n}P_X P_Y + \frac{1}{n}P_{X,Y}\middle\|P_X P_Y\right)$$

并应用KL散度的局部展开（命题2.21）得到(7.55)。 □

在离散情况下，通过将 $P_{Y|X}$ 设为恒等通道（$Y = X$），我们得到经验分布与总体分布接近程度的以下保证。这一事实可用于检验样本是否确实由分布 P_X 生成。

推论 7.18 *Suppose P_X is discrete with support $\mathcal{X}$. If $\mathcal{X}$ is infinite, then*

$$\lim_{n\to\infty} n\,\mathbb{E}[D(\hat{P}_n\|P_X)] = \infty\,. \tag{7.57}$$

Otherwise, we have

$$\mathbb{E}[D(\hat{P}_n\|P_X)] \leq \log\left(1+\frac{|\mathcal{X}|-1}{n}\right) \leq \frac{\log e}{n}(|\mathcal{X}|-1)\,. \tag{7.58}$$

Proof. 只需注意 $I_{\chi^2}(X;\ X) = |\mathcal{X}|-1$。 □

注7.9 对于固定的P_X，紧渐近结果是

$$\lim_{n\to\infty} n\,\mathbb{E}[D(\hat{P}_n\|P_X)] = \frac{\log e}{2}(|\mathrm{supp}(P_X)|-1)\,. \tag{7.59}$$

参见下文引理13.2。关于通过非经验分布手段在不同损失函数下估计P_X的结果，另见练习VI.10。

推论 7.18 对于 *entropy estimation* 的统计应用也很有用。给定 n 个独立同分布观测值，P_X 的熵的一个自然估计量是经验熵 $\hat{H}_{\mathrm{emp}} = H(\hat{P}_n)$ (插入估计量)。显然，经验熵是一个 *underestimate*，从偏差的意义上讲

$$\mathbb{E}[\hat{H}_{\mathrm{emp}}] - H(P_X) = -\,\mathbb{E}[D(\hat{P}_n\|P_X)]$$

总是非负的。对于固定的P_X，已知$\hat{H}_{\mathrm{emp}}$即使在可数无限字母表上也是一致的[22]，尽管收敛速度可能任意慢，这与(7.57)的结论一致。然而，对于大小为$\Theta(n)$的大字母表，上界(7.58)不会消失（例如，对于均匀分布，这是紧的）。在这种情况下，需要去偏经验熵（例如基于(7.59)）或采用不同的技术以实现一致估计。详见第29.4节。

7.10 大多数 f-散度局部类似 χ^2

在本节中，我们为一般 f-散度证明命题2.20和命题2.21的类似命题。

定理 7.19 *Suppose that $D_f(P\|Q) < \infty$ and derivative of $f(x)$ at $x = 1$ exist. Then,*

$$\lim_{\lambda\to 0}\frac{1}{\lambda}D_f(\lambda P + \bar{\lambda}Q\|Q) = (1 - P[\mathrm{supp}(Q)])f'(\infty)\,,$$

where as usual we take $0\cdot\infty = 0$ in the left-hand side.

注7.10 注意，我们不需要为$D_f(Q\|\lambda P + \bar{\lambda}Q)$单独定理，因为交换论证会导致另一个$f$-散度，其中$f(x)$被$xf(1/x)$替换。

Proof. 不失一般性，我们可以假设$f(1) = f'(1) = 0$和$f \geq 0$。然后，将$P = \mu P_1 + \bar{\mu}P_0$与$P_0 \perp Q$及$P_1 \ll Q$分解，我们得到

$$\frac{1}{\lambda}D_f(\lambda P + \bar{\lambda}Q\|Q) = \bar{\mu}f'(\infty) + \int dQ\frac{1}{\lambda}f\left(1 + \lambda(\mu\frac{dP_1}{dQ} - 1)\right)\,.$$

请注意，$g(\lambda) = f(1+\lambda t)$ 对每个 $t \in \mathbb{R}$ 都是正且凸的，因此 $\frac{1}{\lambda}g(\lambda)$ 单调递减到 $g'(0) = 0$，当 $\lambda \searrow 0$ 时。由于对于 $\lambda = 1$，被积函数假定是 Q-可积的，控制收敛定理适用，我们得到结果。 □

定理 7.20 *Let f be twice continuously differentiable on $(0,\infty)$ with*

$$\limsup_{x\to+\infty} f''(x) < \infty\,.$$

If $\chi 2(P\|Q) < \infty$, then $D_f(\bar{\lambda}Q + \lambda P\|Q) < \infty$ for all $0 \le \lambda < 1$ and

$$\lim_{\lambda\to 0}\frac{1}{\lambda^2}D_f(\bar{\lambda}Q+\lambda P\|Q) = \frac{f''(1)}{2}\chi^2(P\|Q)\,. \tag{7.60}$$

If $\chi 2(P\|Q) = \infty$ and $f''(1) > 0$ then (7.60) also holds, i.e. $D_f(\bar{\lambda}Q + \lambda P\|Q) = \omega(\lambda^2)$.

备注 7.11 定理的条件包括 D、D_{SKL}、H^2、JS、LC 以及所有阶数为 $\lambda < 2$ 的 Rényi 散度（其中 $f(x) = \frac{1}{\lambda-1}(x^\lambda - 1)$；参见定义 7.24）。类似的结果也适用于 $f''(x) \to \infty$ 且 $x \to +\infty$ (例如阶数为 $\lambda > 2$) 的 Rényi 散度的情况，但此时我们需要做出额外的假设以确保控制收敛定理的适用性（通常仅需 $D_f(P\|Q)$ 的有限性即可）。

Proof. 假设 $\chi^2(P\|Q) < \infty$，我们必须有 $P \ll Q$，因此我们可以用 (7.1) 作为 D_f 的定义。注意在 (7.1) 下，不失一般性，我们可以假设 $f'(1) = f(1) = 0$（事实上，为此我们只需将 $(x-1)$ 的倍数加到 $f(x)$ 上，这不会改变 $D_f(P\|Q)$ 的值）。由泰勒展开，我们于是有

$$f(1+u) = u^2\int_0^1 (1-t)f''(1+tu)dt\,.$$

将其应用于 $u = \lambda\frac{P-Q}{Q}$，我们得到

$$D_f(\bar{\lambda}Q+\lambda P\|Q) = \int dQ\int_0^1 dt(1-t)\lambda^2\left(\frac{P-Q}{Q}\right)^2 f''\left(1+t\lambda\frac{P-Q}{Q}\right)\,. \tag{7.61}$$

注意，对于任意 $\epsilon > 0$，我们有 $\sup_{x>\epsilon}|f''(x)| \triangleq C_\epsilon < \infty$。注意 $\frac{P-Q}{Q} \ge -1$，因此，对于每个 λ，被积函数非负且有界，界限为

$$\left(\frac{P-Q}{Q}\right)^2 C_{1-\lambda} \tag{7.62}$$

它在 $dQ \times \mathrm{Leb}[0,1]$ 上可积（由于 $\chi^2(P\|Q)$ 的有限性和 Fubini 定理，后者因非负性而适用）。因此，$D_f(\bar{\lambda}Q+\lambda P\|Q) < \infty$。将 (7.61) 除以 λ^2，我们看到被积函数由 (7.62) 控制，因此我们可以应用控制收敛定理得出结论

$$\begin{aligned}\lim_{\lambda\to 0}\frac{1}{\lambda^2}D_f(\bar{\lambda}Q+\lambda P\|Q) &\overset{\text{(a)}}{=} \int_0^1 dt(1-t)\int dQ\left(\frac{P-Q}{Q}\right)^2\lim_{\lambda\to 0}f''\left(1+t\lambda\frac{P-Q}{Q}\right)\\ &= \int_0^1 dt(1-t)\int dQ\left(\frac{P-Q}{Q}\right)^2 f''(1) = \frac{f''(1)}{2}\chi^2(P\|Q)\,,\end{aligned}$$

这证明了 (7.60)。

我们继续证明当 $\chi^2(P\|Q) = \infty$ 时 $D_f(\lambda P + \bar{\lambda}Q\|Q) = \omega(\lambda^2)$ 成立。如果 $P \ll Q$，则由 Fatou 引理，将 (a) 中的等式替换为 $\ge$ 即可得出。如果 $P \not\ll Q$，我们考虑

使用 $P_1 \ll Q$ 和 $P_0 \perp Q$ 分解 $P = \mu P_1 + \bar{\mu} P_0$。根据定义 (7.2)，我们有（对于 $\lambda_1 = \frac{\lambda\mu}{1-\lambda\bar{\mu}}$ ）

$$D_f(\lambda P + \bar{\lambda} Q \| Q) = (1 - \lambda\bar{\mu}) D_f(\lambda_1 P_1 + \bar{\lambda}_1 Q \| Q) + \lambda\bar{\mu} D_f(P_0 \| Q) \geq \lambda\bar{\mu} D_f(P_0 \| Q) \,.$$

回忆命题7.2，除非对于某个常数c有$D_f(P_0\|Q)$ >=0，$f(x) = c(x-1)$，则证明完成。

□

7.11 参数族中的 f-散度：Fisher 信息

在第2.6.2*节中，我们已经预览了这一事实：在参数分布族中，KL散度的Hessian恰好与Fisher信息一致。此处，我们汇集此类事实及其证明。这些材料构成了我们将在第29章后续研究中探讨的参数估计精确边界的基础。

以一个例子开始，让我们回到高斯位置模型（GLM）$P_t \triangleq \mathcal{N}(t, 1), t \in \mathbb{R}$。根据第7.7节中给出的恒等式，我们得到以下渐近性质：

$$\begin{aligned}
&\mathrm{TV}(P_t, P_0) = \frac{|t|}{\sqrt{2\pi}} + o(|t|), && H^2(P_t, P_0) = \frac{t^2}{4} + o(t^2)\,, \\
&\chi^2(P_t \| P_0) = t^2 + o(t^2), && D(P_t \| P_0) = \frac{t^2}{2\log e} + o(t^2)\,, \\
&\mathrm{LC}(P_t, P_0) = \frac{1}{4} t^2 + o(t^2)\,.
\end{aligned}$$

我们可以看到，除了TV之外，其他f散度在小位移$t \to 0$下表现出二次行为。事实证明，这是一个普遍现象，而且t^2前的系数由（在$t = 0$处的）Fisher信息给出。为了谨慎进行，我们需要对族P_t作出一些技术性假设。

定义 7.21（正则单参数族）固定 $\tau > 0$，空间 $\mathcal{X}$ 以及一个分布在 $\mathcal{X}$、$t \in [0, \tau$ ）上的族 P_t。我们定义以下类型的条件，我们称之为在 $t = 0$ 处的正则性：

(a) $P_t(dx) = p_t(x)\mu(dx)$，对于某个可测的 $(t, x) \mapsto p_t(x) \in \mathbb{R}_+$ 以及 $\mathcal{X}$ 上的一个固定测度 μ；(b_0) 存在一个可测函数 $(s, x) \mapsto \dot{p}_s(x)$，$s \in [0, \tau), x \in \mathcal{X}$，使得对于 μ-几乎每一个 x_0，我们有 $\int_0^\tau |\dot{p}_s(x_0)| ds < \infty$ 并且

$$p_t(x_0) = p_0(x_0) + \int_0^t \dot{p}_s(x_0) ds \,. \tag{7.63}$$

此外，对于 μ-几乎每一个 x_0，我们有 $\lim_{t \searrow 0} \dot{p}_t(x_0) = \dot{p}_{0(x_0)}$。
($b1$) 当 $p_0(x) = 0$ 时，我们有 $\dot{p}_t(x) = 0$，此外，

$$\int_{\mathcal{X}} \mu(dx) \sup_{0 \leq t < \tau} \frac{(\dot{p}_t(x))^2}{p_0(x)} < \infty \,. \tag{7.64}$$

(c_0) 存在一个可测函数 $(s,x)\mapsto \dot{h}_s(x), s\in[0,\tau), x\in\mathcal{X}$，使得对于 μ-几乎每一个 x_0，我们有 $\int_0^\tau |\dot{h}_s(x_0)|ds<\infty$ 并且

$$h_t(x_0)\triangleq\sqrt{p_t(x_0)}=\sqrt{p_0(x_0)}+\int_0^t \dot{h}_s(x_0)ds\,. \tag{7.65}$$

此外，对于μ-几乎每一个x_0，我们有$\lim_{t\searrow 0}\dot{h}_t(x_0)=\dot{h}_0(x_0)$。

($c1$) 函数族 $\{(\dot{h}_t(x))^2: t\in[0,\tau)\}$ 是一致 μ-可积的。

注7.12 回顾一下，一致可积性条件（c_1）由以下更强（但更易于验证）的条件所蕴含：

$$\int_{\mathcal{X}}\mu(dx)\sup_{0\le t<\tau}(\dot{h}_t(x))^2<\infty\,. \tag{7.66}$$

令人印象深刻的是，如果还假设h_t是连续可微的，那么一致可积性条件就等价于Fisher信息的连续性

$$t\mapsto J_F(t)\triangleq 4\int\mu(dx)(\dot{h}_t(x))^2\,. \tag{7.67}$$

我们参考[68，附录V]以了解这一细节。

定理 7.22 *Let the family of distributions $\{P_t\colon\ t\in[0,\tau)\}$ satisfy the conditions (a), (b_0) and (b_1) in Definition 7.21. Then we have*

$$\chi^2(P_t\|P_0)=J_F(0)t^2+o(t^2)\,, \tag{7.68}$$

$$D(P_t\|P_0)=\frac{\log e}{2}J_F(0)t^2+o(t^2)\,, \tag{7.69}$$

where $J_F(0)\triangleq\int_{\mathcal{X}}\mu(dx)\frac{(\dot{p}_0(x))^2}{p_0(x)}<\infty$ is the Fisher information at $t=0$.

Proof. 从假设（b_1)）可知，对于任意满足$p_0(x_0)=0$的x_0，必须有$\dot{p}_t(x_0)=0$，因此对于所有$t\in[0,\tau)$都有$p_t(x_0)=0$。因此，我们可以将下面所有积分限制在子集$\{x\colon\ p_0(x)>0\}$上，在该子集上比值$\frac{(p_t(x_0)-p_0(x_0))^2}{p_0(x_0)}$是良定义的。从而，根据（7.63）我们有

$$\begin{aligned}\frac{1}{t^2}\chi^2(P_t\|P_0)&=\frac{1}{t^2}\int\mu(dx)\frac{(p_t(x)-p_0(x))^2}{p_0(x)}\\&=\frac{1}{t^2}\int\mu(dx)\frac{1}{p_0(x)}\left(t\int_0^1 du\dot{p}_{tu}(x)\right)^2\\&\overset{(a)}{=}\int\mu(dx)\int_0^1 du_1\int_0^1 du_2\frac{\dot{p}_{tu_1}(x)\dot{p}_{tu_2}(x)}{p_0(x)}\end{aligned}$$

注意，根据(b_1)中的连续性假设，对于每个(u_1,u_2,x)，当$t\ \to$趋于0时，我们有$\dot{p}_{tu_1}(x)\dot{p}_{tu_2}(x)\to\dot{p}_0^2(x)$。此外，我们还有$\left|\frac{\dot{p}_{tu_1}(x)\dot{p}_{tu_2}(x)}{p_0(x)}\right|\le\sup_{0\le t<\tau}\frac{(\dot{p}_t(x_0))^2}{p_0(x_0)}$，这由(7.64)可知是可积的。因此，对(a)中的积分应用控制收敛定理即可完成(7.68)的证明。

接下来我们证明，对于任何具有二阶连续可微 f (的 f-散度，事实上，无需假设 (7.64)) ，我们有：

$$\liminf_{t\to 0}\frac{1}{t^2}D_f(P_t\|P_0)\geq\frac{f''(1)}{2}J_F(0)\,. \tag{7.70}$$

实际上，类似于(7.61)，我们得到

$$D_f(P_t\|P_0)=\int_0^1 dz(1-z)\,\mathbb{E}_{X\sim P_0}\left[f''\left(1+z\frac{p_t(X)-p_0(X)}{p_0(X)}\right)\left(\frac{p_t(X)-p_0(X)}{p_0(X)}\right)^2\right]\,. \tag{7.71}$$

除以 t^2 注意从 (b_0) 我们得到 $\frac{p_t(X)-p_0(X)}{tp_0(X)}\xrightarrow{\text{a.s.}}\frac{\dot p_0(X)}{p_0(X)}$，因此

$$f''\left(1+z\frac{p_t(X)-p_0(X)}{p_0(X)}\right)\left(\frac{p_t(X)-p_0(X)}{tp_0(X)}\right)^2\to f''(1)\left(\frac{\dot p_0(X)}{p_0}\right)^2\,.$$

因此，应用法图引理，我们恢复了(7.70)。

接下来，将 $f(x)=x\log x$ 代入 (7.71) 中，我们得到 KL 散度

$$\frac{1}{t^2}D(P_t\|P_0)=(\log e)\int_0^1 dz\,\mathbb{E}_{X\sim P_0}\left[\frac{1-z}{1+z\frac{p_t(X)-p_0(X)}{p_0(X)}}\left(\frac{p_t(X)-p_0(X)}{tp_0(X)}\right)^2\right]\,. \tag{7.72}$$

括号内的第一个分数在 0 和 1 之间，第二个由 $\sup_{0<t<\tau}\left(\frac{\dot p_t(X)}{p_0(X)}\right)^2$ 决定，根据 (b_1) 是 P_0-可积的。因此，控制收敛定理适用于 (7.71) 中的二重积分，我们得到

$$\lim_{t\to 0}\frac{1}{t^2}D(P_t\|P_0)=(\log e)\int_0^1 dz\,\mathbb{E}_{X\sim P_0}\left[(1-z)\left(\frac{\dot p_0(X)}{p_0(X)}\right)^2\right]\,,$$

完成(7.69)的证明。 □

注 7.13 定理 7.22 可推广至多维参数情形如下。定义在 $\theta\in\mathbb{R}^d$ 处的 Fisher 信息矩阵：

$$J_F(\theta)\triangleq\int\mu(dx)\nabla_\theta\sqrt{p_\theta(x)}\nabla_\theta\sqrt{p_\theta(x)}^\top \tag{7.73}$$

然后 (7.68) 变为 $\chi^2(P_t\|P_0)=t^\top J_F(0)t+o(\|t\|^2)$ 当 $t\to 0$ 且对于 (7.69) 同样如此，此前已在 (2.34) 中出现过。

定理7.22适用于许多情况（例如，指数族的光滑子族，对于这些情况可以取$\mu=P_0$和 $p_0(x)\equiv$为1），但它并不足够普遍。为了说明这个问题，考虑以下示例。

例 7.1（具有紧支集的定位族）如果 $\mathcal{X}=\mathbb{R}$、$\mu=$Leb 且 $p_t(x)=p_0(x-t)$，则称族 P_t 是（标量）定位族。考虑以下

例如，对于 $\alpha > -1$:

$$p_0(x) = C_\alpha \times \begin{cases} x^\alpha, & x \in [0,1]\,, \\ (2-x)^\alpha, & x \in [1,2]\,, \\ 0, & \text{otherwise} \end{cases},$$

在C_α从归一化中选择的情况下。显然，这里条件(7.64)并不满足，且对于$t > 0$, $\chi^2(P_t\|P_0)$和$D(P_t\|P_0)$均为无限，因为$P_t \not\ll P_0$。但只要$\alpha > 1$，$J_F(0) < \infty$便成立，因此人们预期某种补救措施应当是可能的。实际上，可以计算那些在$P_t \not\ll P_0$下有限的f散度，并发现当$\alpha > 1$时，它们是t的二次型。作为例证，我们有

$$H^2(P_t, P_0) = \begin{cases} \Theta(t^{1+\alpha}), & 0 \le \alpha < 1 \\ \Theta(t^2 \log \frac{1}{t}), & \alpha = 1 \\ \Theta(t^2), & \alpha > 1 \end{cases} \tag{7.74}$$

作为 $t \to 0$。这可以直接计算，或者根据 [222, Theorem VI.1.1] 的更一般结果来计算。[5] 关于 Hellinger 和 Fisher 信息之间的关系，另见 (VI.5)。

前面的例子表明，即使当 $P_t \not\ll P_0$，二次行为 $t \to 0$ 也可能成立，这正是下一个（更技术性的）结果所处理的情况，其证明我们放在了第7.14节*）。可以验证，在例7.1中，对于所有的 $\alpha > 1$，条件(c_1)确实被满足，从而确立了二次行为。同时注意，更强的(7.66)仅适用于 $\alpha \ge 2$。

定理 7.23 *Given a family of distributions $\{P_t : t \in [0,\tau)\}$ satisfying the conditions (a), (c_0) and (c_1) of Definition 7.21, we have*

$$\chi^2(P_t\|\bar\epsilon P_0 + \epsilon P_t) = t^2\bar\epsilon^2\left(J_F(0) + \frac{1-4\epsilon}{\epsilon}J^{\#}(0)\right) + o(t^2)\,, \qquad \forall \epsilon \in (0,1) \tag{7.75}$$

$$H^2(P_t, P_0) = \frac{t^2}{4}J_F(0) + o(t^2)\,, \tag{7.76}$$

where $J_F(0) = 4\int \dot h_0^2 d\mu < \infty$ is the Fisher information and $J^{\#}(0) = \int \dot h_0^2 1\{h_0 = 0\}d\mu$ can be called the Fisher defect at $t = 0$.

例 7.2（关于 Fisher 缺陷）注意，在大多数我们感兴趣的情形中，会出现这样的情况：$t \mapsto h_t(x)$ 实际上对某个 *two-sided* 邻域 $(-\tau,\tau)$ 内的所有 t 都是可微的，该邻域是 0 的邻域。在这类情况下，$h_0(x) = 0$ 意味着 $t = 0$ 是一个局部极小值，因此 $\dot h_0(x) = 0$，这意味着

[5] Statistical significance of this calculation is that if we were to estimate the location parameter t from n iid observations, then precision δ_n^* of the optimal estimator up to constant factors is given by solving $H^2(P_{\delta_n^*}, P_0) \asymp \frac{1}{n}$, cf. [222, Chapter VI]. For $\alpha < 1$ we have $\delta_n^* \asymp n^{-\frac{1}{1+\alpha}}$ which is notably better than the empirical mean estimator (attaining precision of only $n^{-\frac{1}{2}}$). For $\alpha = 1/2$ this fact was noted by D. Bernoulli in 1777 as a consequence of his (newly proposed) maximum likelihood estimation.

缺陷 $J_F^{\#}=$ 为0。然而，对于其他族来说并非如此，有时甚至在 $p_t(x)$ 在 $t\in(-\tau,\tau)$ (上光滑但在 h_t) 上不光滑时也是如此。下面就是一个这样的例子。

考虑 $P_t=\mathrm{Ber}(t^2)$。一个直接的计算表明:

$$\chi^2(P_t\|\bar{\epsilon}P_0+\epsilon P_t)=t^2\frac{\bar{\epsilon}^2}{\epsilon}+O(t^4),\qquad H^2(P_t,P_0)=2(1-\sqrt{1-t^2})=t^2+O(t^4)\,.$$

将 $\mu(\{0\})=\mu(\{1\})=1$ 视为计数测度，我们得到以下结果

$$h_t(x)=\begin{cases}\sqrt{1-t^2}, & x=0\\ |t|, & x=1\end{cases},\qquad \dot{h}_t(x)=\begin{cases}\frac{-t}{\sqrt{1-t^2}}, & x=0\\ \mathrm{sign}(t), & x=1,t\neq 0\\ 1, & x=1,t=0\quad\text{(just as an agreement)}\end{cases}.$$

注意，如果我们将 P_t 视为 $t\in[0,\tau)$ 上的一个族，对于小的 τ，那么条件 (a)、(c_0) 和 (c_1) 显然都满足（$\dot{h}_t$ 在 $t\in(-\tau,\tau)$ 上有界）。我们有 $J_F(0)=4$ 和 $J^{\#}(0)=1$，因此 (7.75) 恢复了 χ^2 的正确展开，(7.76) 恢复了 H^2 的正确展开。

注意，h_t 的非光滑性只有在我们将定义域扩展到 $t\in(-\tau,\tau)$ 时才变得明显。实际上，这个问题在密度 p_t 方面是看不到的。确实，让我们也显式计算密度 p_t 及其导数 $\dot{p}_t$:

$$p_t(x)=\begin{cases}1-t^2, & x=0\\ t^2, & x=1\end{cases},\qquad \dot{p}_t(x)=\begin{cases}-2t, & x=0\\ 2t, & x=1\end{cases}.$$

显然，p_t 在 $t\in(-\tau,\tau)$ 上连续可微。此外，下述期望（通常等于 (7.67) 中的 $J_F(t)$）

$$\mathbb{E}_{X\sim P_t}\left[\left(\frac{\dot{p}_t(X)}{p_t(X)}\right)^2\right]=\begin{cases}0, & t=0\\ 4+\frac{4t^2}{1-t^2}, & t\neq 0\end{cases}$$

在 $t=0$ 处不连续。更糟糕的是，在 $t=0$ 处，该期望值与定理 7.23 中 Fisher 信息 $J_F(0)$ 的定义不符，因此无法为 χ^2 或 H^2 给出正确的小 t 行为。一般来说，为避免困难，应限制在那些 $t\mapsto h_t(x)$ 对 $t\in(-\tau,\tau)$ 连续可微的族上。

7.12 Rényi散度与张量化

Rényi 引入的以下散度度量族在涉及乘积测度的许多应用中至关重要。尽管这些度量不是 f-散度，但它们可作为适当 f-散度的单调变换得到，因此满足 DPI 以及 f-散度的其他性质。稍后，Rényi 散度将在刻画假设检验中的最优误差指数（见第 16.1 节，尤其是注 16.1）、信道输出统计量的近似（见第 25.4* 节）以及复合假设检验的非渐近界（见第 32.2.1 节）中占据重要地位。

定义7.24 对于任意 $\lambda \in \mathbb{R} \setminus \{0, 1\}$，概率分布 P 和 Q 之间阶为 λ 的 *Rényi divergence* 定义为

$$D_\lambda(P\|Q) \triangleq \frac{1}{\lambda - 1} \log \mathbb{E}_Q \left[\left(\frac{dP}{dQ} \right)^\lambda \right] ,$$

其中 $\mathbb{E}_Q[(\frac{dP}{dQ})^\lambda]$ 被形式化地理解为 $\text{sign}(\lambda-1)D_f(P\|Q)+1$ 与 $f(x) = \text{sign}(\lambda-1)(x^\lambda-1)$——参见定义 7.1。扩展条件 KL 散度的定义 2.14 并假设相同的设置，条件 Rényi 散度定义为

$$\begin{aligned} D_\lambda(P_{X|Y}||Q_{X|Y}|P_Y) &\triangleq D_\lambda(P_Y \times P_{X|Y}||P_Y \times Q_{X|Y}) \\ &= \frac{1}{\lambda - 1} \log \mathbb{E}_{Y\sim P_Y} \int_{\mathcal{X}} (dP_{X|Y}(x))^\lambda (dQ_{X|Y}(a))^{1-\lambda} . \end{aligned}$$

Rényi散度的众多性质已知，参见[432]。此处我们仅注意到几点：

- $\lambda = \frac{1}{2}, 1, 2$ 的特殊情况：在温和的正则条件下，$\lim_{\lambda\to 1} D_\lambda(P\|Q) = D(P\|Q)$。另一方面，$D_2 = \log(1 + \chi^2)$ 和 $D_{\frac{1}{2}} = -2\log(1 - \frac{H^2}{2})$ 分别是 χ^2-散度 (7.4) 和 Hellinger 距离 (7.5) 的单调变换。• 对于所有 $\lambda \in \mathbb{R}$，映射 $\lambda \mapsto D_\lambda(P\|Q)$ 是非减的，且映射 $\lambda \mapsto (1 - \lambda)D_\lambda(P\|Q)$ 是凹的。

- 对于 $\lambda \in [0, 1]$，映射 $(P, Q) \mapsto D_\lambda(P\|Q)$ 是凸的。
- 对于 $\lambda \geq 0$，映射 $Q \mapsto D_\lambda(P\|Q)$ 是凸的。• 对于在大小为 m 的有限字母表上均匀分布的 Q，$D_\lambda(P\|Q) = \log m - H_\lambda(P)$，其中 H_λ 是 (1.4) 中定义的 λ 阶 Rényi 熵。这将定理 2.2 作为 $\lambda = 1$ 的特例恢复出来。• 存在一个链式法则的版本：

$$D_\lambda(P_{A,B}||Q_{A,B}) = D_\lambda(P_B||Q_B) + D_\lambda(P_{A|B}||Q_{A|B}|P_B^{(\lambda)}) , \tag{7.77}$$

其中 $P_B^{(\lambda)}$ 是 P_B 向 Q_B 的 λ 倾斜，由下式给出

$$P_B^{(\lambda)}(b) \triangleq P_B^\lambda(b) Q_B^{1-\lambda}(b) \exp\{-(\lambda - 1)D_\lambda(P_B||Q_B)\} . \tag{7.78}$$

- 关键性质是乘积下的可加性，即 *tensorization*：

$$D_\lambda \left(\prod_i P_{X_i} \middle\| \prod_i Q_{X_i} \right) = \sum_i D_\lambda(P_{X_i}\|Q_{X_i}) , \tag{7.79}$$

这是（7.77）的一个简单结果。D_λ是唯一满足DPI和张量化的散度[310]。（7.79）最著名的特例是针对Hellinger距离（见（7.26））和χ^2：

$$1 + \chi^2 \left(\prod_{i=1}^n P_i \middle\| \prod_{i=1}^n Q_i \right) = \prod_{i=1}^n \left(1 + \chi^2(P_i\|Q_i)\right) .$$

我们也可以得到非乘积分布的加性界，见练习I.42和I.43。

链式法则的以下推论在后续的统计应用中至关重要（特别参见第32.2节，定理32.8）。

命题 7.25 *Consider product channels $P_{Y^n|X^n} = \prod P_{Y_i|X_i}$ and $Q_{Y^n|X^n} = \prod Q_{Y_i|X_i}$. We have (with all optimizations over all possible distributions)*

$$\inf_{P_{X^n},Q_{X^n}} D_\lambda(P_{Y^n}\|Q_{Y^n}) = \sum_{i=1}^n \inf_{P_{X_i},Q_{X_i}} D_\lambda(P_{Y_i}\|Q_{Y_i}), \tag{7.80}$$

$$\sup_{P_{X^n},Q_{X^n}} D_\lambda(P_{Y^n}\|Q_{Y^n}) = \sum_{i=1}^n \sup_{P_{X_i},Q_{X_i}} D_\lambda(P_{Y_i}\|Q_{Y_i}) = \sum_{i=1}^n \sup_{x,x'} D_\lambda(P_{Y_i|X_i=x}\|Q_{Y_i|X_i=x'}). \tag{7.81}$$

In particular, for any collections of distributions $\{P_\theta : \theta \in \Theta\}$ and $\{Q_\theta : \theta \in \Theta\}$:

$$\inf_{P\in\mathrm{co}\{P_\theta^{\otimes n}\},Q\in\mathrm{co}\{Q_\theta^{\otimes n}\}} D_\lambda(P\|Q) \geq n \inf_{P\in\mathrm{co}\{P_\theta\},Q\in\mathrm{co}\{Q_\theta\}} D_\lambda(P\|Q), \tag{7.82}$$

$$\sup_{P\in\mathrm{co}\{P_\theta^{\otimes n}\},Q\in\mathrm{co}\{Q_\theta^{\otimes n}\}} D_\lambda(P\|Q) \leq n \sup_{P\in\mathrm{co}\{P_\theta\},Q\in\mathrm{co}\{Q_\theta\}} D_\lambda(P\|Q). \tag{7.83}$$

注7.14 （7.82）-（7.83）的记忆方法是“混合的乘积比乘积的混合更难区分”。前者出现在统计环境中，其中独立同分布的观测值是从单一分布中抽取的，而该分布参数是从先验分布中抽取的。

Proof. (7.81) 中的第二个等式源于 D_λ 是 f 散度的增函数这一事实，因此最大化应在概率空间的极值点处达到，而这些极值点正是单点质量。主要等式 (7.80)-(7.81) 来源于 a) 将优化限制在乘积分布上并引用 (7.79)；以及 b) D_λ 的链式法则。例如对于 $n = 2$，我们固定 P_{X^2} 和 Q_{X^2}，它们 (通过通道) 诱导出联合分布 P_{X^2,Y^2} 和 Q_{X^2,Y^2}。于是我们有

$$D_\lambda(P_{Y_1|Y_2=y}\|Q_{Y_1|Y_2=y'}) \geq \inf_{\tilde{P}_{X_1},\tilde{Q}_{X_1}} D_\lambda(\tilde{P}_{Y_1}\|\tilde{Q}_{Y_1}),$$

由于 $P_{Y_1|Y_2=y}$ 是由取 $\tilde{P}_{X_1} = P_{X_1|Y_2=y}$ 所诱导的分布，类似地 $Q_{Y_1|Y_2=y'}$ 也是如此。总之，我们得到

$$D_\lambda(P_{Y^2}\|Q_{Y^2}) = D_\lambda(P_{Y_2}\|Q_{Y_2}) + D_\lambda(P_{Y_1|Y_2}\|Q_{Y_1|Y_2}|P_{Y_2}^{(\lambda)}) \geq \sum_{i=1}^2 \inf_{P_{X_i},Q_{X_i}} D_\lambda(P_{Y_i}\|Q_{Y_i}),$$

如所声称。sup 的情况类似处理。

从(7.80)-(7.81)，我们通过取$\mathcal{X} = \Theta$并将inf和sup专门化为对角分布P_{X^n}和Q_{X^n}，即那些具有性质$P[X_1 = \cdots = X_n] = 1$和$Q[X_1 = \cdots = X_n] = 1$)的分布，得到了(7.82)-(7.83)。

□

7.13 f-散度的变分表示

在定理4.6中，我们得到了由Donsker和Varadhan提出的非常实用的KL散度的变分表示。本节我们将展示如何以系统化的方式为其他f散度推导出类似的表示。这些证明略显技术性，将在本章末尾的第7.14*节给出。

设$f:(0,+\infty)\to\mathbb{R}$为凸函数。$f$的凸共轭$f^*:\mathbb{R}\to\mathbb{R}\cup\{+\infty\}$定义为：

$$f^*(y)=\sup_{x\in\mathbb{R}_+} xy-f(x)\,,\qquad y\in\mathbb{R}\,. \tag{7.84}$$

将f^*的定义域记作$\mathrm{dom}(f^*)\triangleq\{y:f^*(y)<\infty\}$，凸共轭的两个重要性质是

1 f^*也是凸的（无论f是否为凸，这都成立）；
2 双共轭：$(f^*)^*=f$，这意味着

$$f(x)=\sup_y xy-f^*(y)$$

并且意味着以下内容（对于所有$x>0$和y）

$$f(x)+f^*(y)\geq xy\,.$$

类似地，我们可以定义任何在测度空间上定义的凸泛函$\Psi(P)$的凸共轭，通过设置

$$\Psi^*(g)=\sup_P \int gdP-\Psi(P)\,. \tag{7.85}$$

在适当条件下（例如有限$\mathcal{X}$），双共轭即可得到所寻求的变分表示

$$\Psi(P)=\sup_g \int gdP-\Psi^*(g)\,. \tag{7.86}$$

接下来我们将计算$\Psi(P)=D_f(P\|Q)$的这些共轭。事实证明，首先将$D_f(P\|Q)$的定义扩展到所有有限符号测度P，然后计算共轭，这样做是方便的。为此，令f_{ext}：$\mathbb{R}\to\mathbb{R}\cup\{+\infty\}$为$f$的一个扩展，使得对于$x\geq 0$，$f_{\mathrm{ext}}(x)=f(x)$成立，并且$f_{\mathrm{ext}}$在$\mathbb{R}$上是凸的。一般来说，我们总是可以选择对所有$x<0$取$f_{\mathrm{ext}}(x)=\infty$。在特殊情况下，例如$f(x)=|x-1|/2$或$f(x)=(x-1)^2$，我们可以直接对所有$x$取$f_{\mathrm{ext}}(x)=f(x)$。现在我们可以按照定义7.1中的相同方式，使用$f_{\mathrm{ext}}$代替$f$，对所有符号测度$P$定义$D_f(P\|Q)$。

对于每种f_{ext}的选择，我们都有f-散度的一个变分表示：

定理 7.26 *Let P and Q be probability measures on $\mathcal{X}$. Fix an extension f_{ext} of f and let f^*_{ext} is the conjugate of f_{ext}, i.e., $f^*_{\text{ext}}(y) = \sup_{x\in\mathbb{R}} xy - f_{\text{ext}}(x)$. Denote $\operatorname{dom}(f^*_{\text{ext}}) \triangleq \{y : f^*_{\text{ext}}(y) < \infty\}$. Then*

$$D_f(P\|Q) = \sup_{g:\mathcal{X}\to\operatorname{dom}(f^*_{\text{ext}})} \mathbb{E}_P[g(X)] - \mathbb{E}_Q[f^*_{\text{ext}}(g(X))]. \tag{7.87}$$

where the supremum can be taken over either (a) all simple g or (b) over all g satisfying $\mathbb{E}_Q[f^*\mathrm{e}_{\text{xt}}(g(X))] < \infty$.

我们注意到，当$P \ll Q$时，结果(a)和(b)同样适用于g：$\mathcal{X} \to \mathbb{R}$上的上确界，即不限制$g(x) \in \operatorname{dom}(f^*_{\text{ext}})$。

作为变分表征的结果，我们得到f-散度的以下性质：

1 *Convexity*：首先，注意$D_f(P\|Q)$表示为仿射函数的上确界（因为期望是一个线性运算）。因此，我们得到$(P, Q) \mapsto D_f(P\|Q)$是凸的，这在之前定理7.5中使用不同方法已证明。

2 *Weak lower semicontinuity*：回顾备注4.5中的例子，其中$\{X_i\}$是独立同分布的Rademacher变量（± 1），并且

$$\frac{\sum_{i=1}^n X_i}{\sqrt{n}} \xrightarrow{\mathrm{d}} \mathcal{N}(0,1)$$

根据中心极限定理；然而，根据命题7.2，对于所有 {v*},

$$D_f\left(\frac{P_{X_1+X_2+\ldots+X_n}}{\sqrt{n}}\middle\|\mathcal{N}(0,1)\right) = f(0) + f'(\infty) > 0,$$

由于前者分布是离散的，而后者是连续的。因此，类似于KL散度，我们对于f-散度所能期望的最佳性质是半连续性。实际上，如果$\mathcal{X}$是一个良好的空间（例如欧几里得空间），在(7.87)中我们可以将函数g限制为连续有界函数，在这种情况下，$D_f(P\|Q)$表示为弱连续泛函的上确界（注意，由于f^*是连续的，$f^* \circ g$也是连续且有界的），因此是弱下半连续的，即对于任何分布序列P_n和Q_n，使得$P_n \xrightarrow{w} P$和$Q_n \xrightarrow{w} Q$，我们有

$$\liminf_{n\to\infty} D_f(P_n\|Q_n) \geq D_f(P\|Q).$$

3 *Relation to DPI:* 如（4.15）所述，变分表示可以被视为DPI的扩展。作为练习，应当尝试推导估计

$$|P[A] - Q[A]| \leq \sqrt{Q[A] \cdot \chi^2(P\|Q)}$$

通过 DPI 和（7.91）两者。

例 7.3（全变差与 Hellinger）对于全变差，我们有 $f(x)=\frac{1}{2}|x-1|$。考虑对 $x\in\mathbb{R}$ 的扩展 $f_{\text{ext}}(x)=\frac{1}{2}|x-1|$。那么

$$f^*_{\text{ext}}(y)=\sup_x\left\{xy-\frac{1}{2}|x-1|\right\}=\begin{cases}+\infty & \text{if } |y|>\frac{1}{2}\\ y & \text{if } |y|\le\frac{1}{2}\end{cases}.$$

因此（7.87）给出

$$\mathrm{TV}(P,Q)=\sup_{g:|g|\le\frac{1}{2}}\mathbb{E}_P[g(X)]-\mathbb{E}_Q[g(X)], \tag{7.88}$$

它先前出现在 (7.18) 中。对平方 Hellinger 的计算得到 $f^*_{\text{ext}}(y)=\frac{y}{1-y}$，其中 $y\in(-\infty,1)$，因此，将 (7.87) 中的 g 改为 $h=1-g$ 后，我们得到

$$H^2(P,Q)=2-\inf_{h>0}\mathbb{E}_P[h]+\mathbb{E}_Q[\frac{1}{h}].$$

作为一个应用，考虑 $f\colon\ \mathcal{X}\to[0,1]$ 和 $\tau\in(0,1)$，因此 $h=1-\tau f$ 满足 $\frac{1}{h}\le 1+\frac{\tau}{1-\tau}f$。那么之前的特征描述意味着

$$\mathbb{E}_P[f]\le\frac{1}{1-\tau}\,\mathbb{E}_Q[f]+\frac{1}{\tau}H^2(P,Q)\qquad\forall f\colon\mathcal{X}\to[0,1],\ \forall\tau\in(0,1).$$

示例 7.4 (χ^2-散度) 对于 χ^2-散度，我们有 $f(x)=(x-1)^2$。取 $f_{\text{ext}}(x)=(x-1)^2$，其共轭为 $f^*_{\text{ext}}(y)=y+\frac{y^2}{4}$。应用 (7.87) 得到

$$\chi^2(P\|Q)=\sup_{g:\mathcal{X}\to\mathbb{R}}\mathbb{E}_P[g(X)]-\mathbb{E}_Q\left[g(X)+\frac{g^2(X)}{4}\right] \tag{7.89}$$

$$=\sup_{g:\mathcal{X}\to\mathbb{R}}2\mathbb{E}_P[g(X)]-\mathbb{E}_Q[g^2(X)]-1 \tag{7.90}$$

其中最后一步来自变量替换（$g\leftarrow\frac{1}{2}g-1$）。

为了得到另一个等价但更容易记住的表示，我们注意到(7.90)它不是尺度不变的。为了使其不变，设$g=\lambda h$并首先对$\lambda\in\mathbb{R}$进行优化，我们得到

$$\chi^2(P\|Q)=\sup_{h:\mathcal{X}\to\mathbb{R}}\frac{(\mathbb{E}_P[h(X)]-\mathbb{E}_Q[h(X)])^2}{\mathrm{Var}_Q(h(X))}. \tag{7.91}$$

对（7.91）的统计解释如下：如果检验统计量$h(X)$使得其在P和Q下的期望之间的差距远远超过其标准差，那么这表明这两个假设可以被可靠地区分。表示式（7.91）将在第29章的统计应用中有用，用于推导Hammersley-Chapman-Robbins（HCR）下界及其贝叶斯版本，见第29.1.2节，以及最终的Cramér-Rao和van Trees下界。

示例 7.5（Jensen-Shannon 散度与 GAN）对于 Jensen-Shannon 散度（7.8），我们有 $f(x)=x\log\frac{2x}{1+x}+\log\frac{2}{1+x}$。计算共轭得到 $f^*(s)=-\log(2-\exp(s))$，其定义域为 $s\in(-\infty,\log 2)$。由（7.87）我们得到刻画

$$\mathrm{JS}(P,Q)=\sup_{g:\mathcal{X}\to(-\infty,\log 2)}\mathbb{E}_P[g]+\mathbb{E}_Q[\log(2-\exp\{g(X)\})],$$

或者在将 $h = \exp\{g\}/2$ 重新参数化后，我们得到

$$\mathrm{JS}(P,Q) = \sup_{h:\mathcal{X}\to(0,1)} \log 2 + \mathbb{E}_P[\log(h)] + \mathbb{E}_Q[\log(1-h)]\,.$$

这种刻画是密度估计中一种有影响力的现代方法的基础，称为 *generative adversarial networks (GANs)* [193]。其核心思想如下。假设我们试图通过将 $\mathbb{R}^d$ 上一个非常复杂的分布 P 表示为作用在标准正态 $Z \sim \mathcal{N}(0, I_m)$ 上的生成映射 G: $\mathbb{R}^m \to \mathbb{R}^d$（的分布）来近似它。[193] 的思想是通过最小化 $\mathrm{JS}(P, P_{G(Z)})$ 来寻找一个好的 G 。由于变分刻画，我们可以等价地将这个问题表述为

$$\inf_G \sup_h \mathbb{E}_{X\sim P}[\log h(X)] + \mathbb{E}_{Z\sim\mathcal{N}}[\log(1-h(G(Z))]$$

(在此背景下，测试函数h被称为判别器，或较少见的，批评家)。由于分布P仅通过独立同分布观测样本$x_1, \ldots, x_n \sim P$供我们使用，我们通过以下方式近似这个极小极大问题:

$$\inf_G \sup_h \frac{1}{n}\sum_{i=1}^n \log h(x_i) + \mathbb{E}_{Z\sim\mathcal{N}}[\log(1-h(G(Z))]\,.$$

为了解决这个问题，参考文献[193]提出的另一个想法是通过对神经网络进行优化，来近似在G和h的无限维函数空间上难以处理的优化问题。这一方法通过在定义G和h神经网络的（有限维）参数空间上交替进行梯度上升/下降步骤来实现。继[193]的突破之后，他们想法的变体导致了找到能生成极其逼真的图像、音乐、视频、3D场景等的$G(Z)$。

例 7.6（KL 散度）在这种情况下，我们有 $f(x) = x\log x$。考虑对 $x < 0$ 的扩展 $f_{\mathrm{ext}}(x) = \infty$，其凸共轭为 $f^*(y) = \frac{\log e}{e}\exp$（$y$）。因此（7.87）给出

$$D(P\|Q) = \sup_{g:\mathcal{X}\to\mathbb{R}} \mathbb{E}_P[g(X)] - (\mathbb{E}_Q[\exp\{g(X)\}] - 1)\log e \tag{7.92}$$

注意，在最后一个例子中，我们针对KL散度得到的变分表示（7.92）与定理4.6中的Donsker-Varadhan恒等式并不相同，即，

$$D(P\|Q) = \sup_{g:\mathcal{X}\to\mathbb{R}} \mathbb{E}_P[g(X)] - \log\mathbb{E}_Q[\exp\{g(X)\}]\,. \tag{7.93}$$

事实上，(7.92) 在某种意义上弱于 (7.93)，即对于每个 g 的选择，在右侧得到的 $D(P\|Q)$ 的下界更小。此外，无论 f_{ext} 的选择如何，Donsker-Varadhan 表示永远不能从定理 7.26 中获得，因为与 (7.93) 不同，(7.87) 中的第二项总是关于 Q 线性的。事实证明，如果我们对所有非概率测度 P 定义 $D_f(P\|Q) = \infty$，并计算其凸共轭，我们将在下一个定理中得到一种不同类型的变分表示，当将其特化到例 7.6 中的 KL 散度时，恰好恢复了 Donsker-Varadhan 恒等式。

定理 7.27 *Consider the extension f_{ext} of f such that $f_{\text{ext}}(x) = \infty$ for $x < 0$. Let $S = \{x : q(x) > 0\}$ where q is as in* (7.2)*. Then*

$$D_f(P\|Q) = f'(\infty)P[S^c] + \sup_g \mathbb{E}_P[g1_S] - \Psi^*_{Q,P}(g)\,, \tag{7.94}$$

where

$$\Psi^*_{Q,P}(g) \triangleq \inf_{a\in\mathbb{R}} \mathbb{E}_Q[f^*_{\text{ext}}(g(X) - a)] + aP[S].$$

In the special case $f'(\infty) = \infty$, we have

$$D_f(P\|Q) = \sup_g \mathbb{E}_P[g] - \Psi^*_Q(g), \qquad \Psi^*_Q(g) \triangleq \inf_{a\in\mathbb{R}} \mathbb{E}_Q[f^*_{\text{ext}}(g(X) - a)] + a. \tag{7.95}$$

备注7.15（Marton散度）回顾定理7.7中，我们展示了TV的上确界和下确界特征。其他f散度是否也具有下确界特征呢？据我们所知，唯一的另一个例子归功于Marton。令

$$D_m(P\|Q) = \int dQ \left(1 - \frac{dP}{dQ}\right)^2_+ ,$$

这显然是一个f-散度，其中$f(x) = (1-x)^2_+$。我们有以下[69，引理8.3]:

$$D_m(P\|Q) = \inf\{\mathbb{E}[P[X \neq Y|Y]^2] : X \sim P, Y \sim Q\}\,,$$

其中下确界取遍 P 和 Q 的所有耦合。见练习 I.44。

Marton的D_m散度在测度集中理论中起着至关重要的作用[69, 第8章]。另请注意，虽然定理7.20由于缺乏二次连续可微性而不适用于D_m，但它适用于对称化的Marton散度 $D_{sm}(P\|Q) \triangleq D_m(P\|Q) + D_m(Q\|P)$。

我们以描述Fisher信息的一些性质来结束本节，这些性质类似于f-散度的性质。鉴于其在局部展开中的作用，我们预期Fisher信息会继承这些性质，如单调性、数据处理不等式和变分表示。实际上，前两者可以直接建立；参见练习I.46。在[220]中，Huber引入了以下关于密度在$\mathbb{R}$上的Fisher信息的变分扩展（在位置族中）(2.40)：对于任何$P \in \mathcal{P}(\mathbb{R})$，定义

$$J(P) = \sup_h \frac{\mathbb{E}_P[h'(X)]^2}{\mathbb{E}_P[h(X)^2]} \tag{7.96}$$

其中上确界取自所有连续可微且紧支撑的检验函数 $h \in C^1_c$，使得 $\mathbb{E}_P[h(X)^2] > 0$。Huber 证明了 $J(P) < \infty$ 当且仅当 P 具有绝对连续的密度 p 使得 $\int (p')^2/p < \infty$，此时 (7.96) 与通常的定义 (2.40) 一致。[6] 通过结合

[6] As an example in the reverse direction, $J(\text{Unif}(0,1)) = \infty$ which follows from choosing test functions such as $h(x) = \cos^2 \frac{x\pi}{\epsilon} 1\{|x| \le \epsilon/2\}$ and $\epsilon \to 0$.

χ^2-散度的变分表示（7.91）及其涉及Fisher信息的局部展开（7.68）。事实上，撇开正则性条件，通过泰勒展开我们得到

$$\chi^2(P_t\|P) = \sup \frac{(\mathbb{E}[h(X+t)-h(X)])^2}{\mathbb{E}[h^2(X)]} = \sup \frac{\mathbb{E}[h'(X)]^2}{\mathbb{E}[h^2(X)]} \cdot t^2 + o(t^2),$$

也就是$\chi^2(P_t\|P) = J(P)t^2 + o(t^2)$。可以通过分部积分和Cauchy-Schwarz给出直接证明：$(\int ph')^2 = (\int p'h)^2 \le \int h^2 p \int (p')^2/p$，这也表明最优测试函数由*score*函数$h = p'/p$给出；详情见[220，定理4.2]。

7.14* 技术证明：凸性、局部展开与变分表示

在本节中，我们汇集了本章一些技术定理的证明。

Proof of Theorem 7.23. 根据定义，我们有

$$L(t) \triangleq \frac{1}{\bar\epsilon^2 t^2}\chi^2(P_t\|\bar\epsilon P_0 + \epsilon P_t) = \frac{1}{t^2}\int_{\mathcal{X}} \mu(dx)\frac{(p_t(x)-p_0(x))^2}{\bar\epsilon p_0(x) + \epsilon p_t(x)} = \frac{1}{t^2}\int \mu(dx) g(t,x)^2\,, \tag{7.97}$$

其中

$$g(t,x) \triangleq \frac{p_t(x)-p_0(x)}{\sqrt{\bar\epsilon p_0(x) + \epsilon p_t(x)}} = \phi(h_t(x);x)\,, \qquad \phi(h;x) \triangleq \frac{h^2 - p_0(x)}{\sqrt{\bar\epsilon p_0(x) + \epsilon h^2}}\,.$$

由 (c_0)，函数 $t \mapsto h_t(x) \triangleq \sqrt{p_t(x)}$ 是绝对连续的（对于 μ-几乎处处 x）。下面我们将证明 $\|\phi(\cdot;\ x)\|_{\mathrm{Lip}} = \sup_{h\ge 0}|\phi'(h;\ x)| \le \frac{2-\epsilon}{(1-\epsilon)\sqrt{\epsilon}}$。这意味着 $t \mapsto g(t,x)$ 也是绝对连续的，因此几乎处处可微。因此，我们有

$$g(t,x) = t\int_0^1 du \dot g(tu,x), \qquad \dot g(t,x) \triangleq \phi'(h_t(x);x)\dot h_t(x)\,,$$

由于 $\phi'(\cdot;\ x)$ 与

$$\phi'(h_0(x);x) = \begin{cases} 2, & x: h_0(x) > 0, \\ \frac{1}{\sqrt{\epsilon}}, & x: h_0(x) = 0 \end{cases} \tag{7.98}$$

(我们在下面也验证这些事实)，我们得出结论：

$$\lim_{s\to 0}\dot g(s,x) = \dot g(0,x) = \dot h_0(x)\left(2\cdot 1\{h_0(x)>0\} + \frac{1}{\sqrt{\epsilon}}1\{h_0(x)=0\}\right), \tag{7.99}$$

其中我们还根据假设（c_0）使用了连续性$\dot h_t(x) \to \dot h_0(x)$。

将 $g(t,x)$ 的积分表达式代入 (7.97)，我们得到

$$L(t) = \int \mu(dx)\int_0^1 du_1 \int_0^1 du_2 \dot g(tu_1,x)\dot g(tu_2,x)\,. \tag{7.100}$$

由于某些 $C = C(\epsilon)$ 的 $|\dot{g}(s,x)| \le C|h_s(x)|$，我们从柯西-施瓦茨不等式得出

$$\int \mu(dx)|\dot{g}(s_1,x)\dot{g}(s_2,x)| \le C^2 \sup_t \int_{\mathcal{X}} \mu(dx)\dot{h}_t(x)^2 < \infty\,. \tag{7.101}$$

其中最后一个不等式由一致可积性假设（c_1）得出。这意味着Fubini定理适用于（7.100），我们得到

$$L(t) = \int_0^1 du_1 \int_0^1 du_2 G(tu_1, tu_2)\,, \qquad G(s_1,s_2) \triangleq \int \mu(dx)\dot{g}(s_1,x)\dot{g}(s_2,x)\,.$$

注意，如果函数族 $\{f_\alpha(x) : \alpha \in I\}$ 是一致平方可积的，那么函数族 $\{f_\alpha(x)f_\beta(x) : \alpha \in I, \beta \in I\}$ 就是一致可积的，只需应用 $|f_\alpha f_\beta| \le \frac{1}{2}(f_\alpha^2 + f_\beta^2)$ 即可。因此，从假设 (c_1) 可以看出，定义 $G(s_1,s_2)$ 的积分允许在积分内部对 s_1, s_2 取极限。由 (7.99) 可得，当 $t \to$ 趋于 0 时

$$G(tu_1,tu_2) \to G(0,0) = \int \mu(dx)\dot{h}_0(x)^2 \left(4 \cdot 1\{h_0 > 0\} + \frac{1}{\epsilon}1\{h_0 = 0\}\right) = J_F(0) + \frac{1-4\epsilon}{\epsilon}J^{\#}(0)\,.$$

由(7.101)可见，$G(s_1,s_2)$是有界的，因此有界收敛定理适用，并且

$$\lim_{t\to 0}\int_0^1 du_1 \int_0^1 du_2 G(tu_1,tu_2) = G(0,0)\,,$$

从而完成了在假设关于 ϕ 的事实下，对 $L(t) \to J_F(0)$ 及(7.75)的证明。让我们验证这些事实。

为简化起见，在下一段中，我们省略了$h_0(x)$和$\phi(\cdot$中的参数x；$x)$。直接求导得到

$$\phi'(h) = 2h\frac{h_0^2(1-\frac{\epsilon}{2}) + \frac{\epsilon}{2}h^2}{(\bar{\epsilon}h_0^2 + \epsilon h^2)^{3/2}}.$$

由于 $\frac{h}{\sqrt{\bar{\epsilon}h_0^2+\epsilon h^2}} \le \frac{1}{\sqrt{\epsilon}}$ 和 $\frac{h_0^2(1-\frac{\epsilon}{2})+\frac{\epsilon}{2}h^2}{\bar{\epsilon}h_0^2+\epsilon h^2} \le \frac{1-\epsilon/2}{1-\epsilon}$，我们得到 ϕ' 的有限性。对于 ϕ' 的连续性，注意到如果 $h_0 > = 0$，那么函数显然是连续的，而对于 $h_0 = \neq 0$，我们有 $\phi'(h) = \frac{1}{\sqrt{\epsilon}}$ 对于所有 h。

接下来我们转到Hellinger距离。正如上述论证中一样，我们定义

$$M(t) \triangleq \frac{1}{t^2}H^2(P_t,P_0) = \int \mu(dx)\int_0^1 du_1 \int_0^1 du_2 \dot{h}_{tu_1}(x)\dot{h}_{tu_2}(x)\,.$$

正是如上述由柯西-施瓦茨不等式及 sup{v*} 我们得出，Fubini 定理适用，因此

$$M(t) = \int_0^1 du_1 \int_0^1 du_2 H(tu_1,tu_2)\,, \qquad H(s_1,s_2) \triangleq \int \mu(dx)\dot{h}_{s_1}(x)\dot{h}_{s_2}(x)\,.$$

再次，族 $\{\dot{h}_{s_1}\dot{h}_{s_2} : s_1 \in [0,\tau), s_2 \in [0,\tau\}$ 是一致可积的，因此从 (c_0) 我们推出 $H(tu_1,tu_2) \to \frac{1}{4}J_F(0)$。此外，类似于 (7.101)，我们看到 $H(s_1,s_2)$ 是有界的

因此

$$\lim_{t\to 0} M(t) = \int_0^1 du_1 \int_0^1 du_2 \lim_{t\to 0} H(tu_1, tu_2) = \frac{1}{4} J_F(0)\,,$$

完成（7.76）的证明。 □

继续讨论变分表示，我们证明Gelfand-Yaglom-Perez定理4.5的对应版本，参见[185]。

Proof of Theorem 7.6. 下界$D_f(P\|Q) \geq D_f(P_{\mathcal{E}}\|Q_{\mathcal{E}})$由DPI得出。为了证明上界，首先我们通过命题7.2中的性质6将问题化简为$f \geq 0$的情形。然后定义集合$S = \mathrm{supp}Q$，$F_\infty = \{\frac{dP}{dQ} = 0\}$，并对固定的$\epsilon > 0$，令

$$F_m = \left\{\epsilon m \leq f\left(\frac{dP}{dQ}\right) < \epsilon(m+1)\right\}, m = 0, 1, \ldots\,.$$

我们拥有

$$\begin{aligned}\epsilon \sum_m mQ[F_m] \leq \int_S dQ f\left(\frac{dP}{dQ}\right) &\leq \epsilon \sum_m (m+1)Q[F_m] + f(0)Q[F_\infty] \\ &\leq \epsilon \sum_m mQ[F_m] + f(0)Q[F_\infty] + \epsilon\,. \end{aligned} \tag{7.102}$$

注意，在区间 $I_m^+ = \{x > 1 : \epsilon m \leq f(x) < \epsilon(m+1)\}$ 上，函数f是递增的，而在 $I_m^- = \{x \leq 1 : \epsilon m \leq f(x) < \epsilon(m+1)\}$ 上是递减的。因此，进一步将每个 F_m 划分为 $F_m^+ = \{\frac{dP}{dQ} \in I_m^+\}$ 和 $F_m^- = \{\frac{dP}{dQ} \in I_m^-\}$。然后，我们看到

$$f\left(\frac{P[F_m^\pm]}{Q[F_m^\pm]}\right) \geq \epsilon m\,.$$

接下来，定义由集合$\mathcal{E} = \{F_0^+, F_0^-, \ldots, F_n^+, F_n^-, F_\infty, S^c, \cup_{m>n} F_m\}$构成的划分。对于这个划分，根据之前的展示，我们有：

$$D(P_{\mathcal{E}}\|Q_{\mathcal{E}}) \geq \epsilon \sum_{m\leq n} mQ[F_m] + f(0)Q[F_\infty] + f'(\infty)P[S^c]\,. \tag{7.103}$$

接下来我们证明，当n足够大且ϵ足够小时，(7.103)的右侧趋近于$D_f(P\|Q)$。若$f(0)Q[F_\infty] = \infty$ (且因此$D_f(P\|Q) = \infty$)，那么显然(7.103)也是无穷的。因此，假设$f(0)Q[F_\infty] < \infty$。

如果 $\int_S dQ f\left(\frac{dP}{dQ}\right) = \infty$ 那么 (7.102) 式右侧对 m 的求和也是无限的，因此对于任意 $N > 0$，存在某个 n，使得 $\sum_{m\leq n} mQ[F_m] \geq N$，从而表明 (7.103) 式的右侧可以任意大。于是，假设 $\int_S dQ f\left(\frac{dP}{dQ}\right) < \infty$。考虑 (7.102) 式的左侧，我们得出结论：对于某个大的 n，我们有 $\sum_{m>n} mQ[F_m] \leq \frac{1}{2}$。那么，由 (7.102) 式我们必须再次得到

$$\epsilon \sum_{m\leq n} mQ[F_m] + f(0)Q[F_\infty] \geq \int_S dQ f\left(\frac{dP}{dQ}\right) - \frac{3}{2}\epsilon\,.$$

因此，我们已经证明对于任意 $\epsilon > 0$，(7.103) 的右侧可以变得大于 $D_f(P\|Q) - \frac{3}{2}\epsilon$。

□

Proof of Theorem 7.26. 首先，我们证明对于任意 $g : \mathcal{X} \to \mathrm{dom}(f^*_{\mathrm{ext}})$，必须有

$$\mathbb{E}_P[g(X)] \le D_f(P\|Q) + \mathbb{E}_Q[f^*_{\mathrm{ext}}(g(X))]\,. \tag{7.104}$$

令 $p(\cdot)$ 和 $q(\cdot)$ 分别为 P 和 Q 的密度。那么，根据 f^*_{ext} 的定义，对于每个满足 $q(x) > 0$ 的 x，我们有：

$$f^*_{\mathrm{ext}}(g(x)) + f_{\mathrm{ext}}(\frac{p(x)}{q(x)}) \ge g(x)\frac{p(x)}{q(x)}\,.$$

在将上述内容在限制于集合 $\{q > 0\}$ 上的 $dQ = q\,d\mu$ 进行积分后，我们得到

$$\mathbb{E}_Q[f^*_{\mathrm{ext}}(g(X))] + \int_{q>0} q(x) f_{\mathrm{ext}}(\frac{p(x)}{q(x)})\,d\mu \ge \mathbb{E}_P[g(X)1\{q(X) > 0\}]\,. \tag{7.105}$$

现在，请注意

$$\sup\{y : y \in \mathrm{dom}(f^*_{\mathrm{ext}})\} = \lim_{x\to\infty} \frac{f_{\mathrm{ext}}(x)}{x} = f'(\infty) \tag{7.106}$$

因此，$f'(\infty)P[q(X) = 0] \ge \mathbb{E}_P[g(X)1\{q(X) = 0\}]$。将后一不等式与(7.105)相加，我们得到(7.104)。

接下来我们证明(7.87)中对简单函数g取上确界确实得到$D_f(P\|Q)$，从而不等式(7.104)是紧的。借助定理7.6，只需证明有限$\mathcal{X}$情形下的(7.87)。事实上，对于一般的$\mathcal{X}$，给定$\mathcal{X}$的一个有限分割$\mathcal{E} = \{E_1, \ldots, E_n\}$，我们称函数$g$:$\mathcal{X} \to \mathbb{R}$是$\mathcal{E}$-相容的，如果$g$在每个$E_i \in \mathcal{E}$上为常数。对所有有限分割$\mathcal{E}$取上确界，我们得到

$$\begin{aligned} D_f(P\|Q) &= \sup_{\mathcal{E}} D_f(P_{\mathcal{E}}\|Q_{\mathcal{E}}) \\ &= \sup_{\mathcal{E}} \sup_{\substack{g:\mathcal{X}\to\mathrm{dom}(f^*_{\mathrm{ext}}) \\ g\ \mathcal{E}\text{-compatible}}} \mathbb{E}_P[g(X)] - \mathbb{E}_Q[f^*_{\mathrm{ext}}(g(X))] \\ &= \sup_{\substack{g:\mathcal{X}\to\mathrm{dom}(f^*_{\mathrm{ext}}) \\ g\ \text{simple}}} \mathbb{E}_P[g(X)] - \mathbb{E}_Q[f^*_{\mathrm{ext}}(g(X))], \end{aligned}$$

其中最后一步成立是因为两个上确界的组合等价于对所有简单（有限值）函数 g 的上确界。

接下来，考虑有限 $\mathcal{X}$。令 $S = \{x \in \mathcal{X} : Q(x) > 0\}$ 表示 Q 的支撑集。我们证明以下命题

$$D_f(P\|Q) = \sup_{g:S\to\mathrm{dom}(f^*_{\mathrm{ext}})} \mathbb{E}_P[g(X)] - \mathbb{E}_Q[f^*_{\mathrm{ext}}(g(X))] + f'(\infty)P(S^c), \tag{7.107}$$

根据(7.106)，这与(7.87)等价。根据定义，

$$D_f(P\|Q) = \underbrace{\sum_{x\in S} Q(x) f_{\mathrm{ext}}\left(\frac{P(x)}{Q(x)}\right)}_{\triangleq \Psi(P)} + f'(\infty)\cdot P(S^c),$$

考虑上面定义的泛函 $\Psi(P)$，其中 P 在 S 上的所有符号测度上取值，而 S 可与 $\mathbb{R}^S$ 等同。$\Psi(P)$ 的凸共轭如下：对于任意 $g\colon S\to\mathbb{R}$,

$$\begin{aligned}\Psi^*(g) &= \sup_P \sum_x P(x)g(x) - Q(x)\left\{\sup_{h\in\mathrm{dom}(f^*_{\mathrm{ext}})} \frac{P(x)}{Q(x)}h - f^*_{\mathrm{ext}}(h)\right\}\\ &= \sup_P \inf_{h:S\to\mathrm{dom}(f^*_{\mathrm{ext}})} \sum_x P(x)(g(x)-h(x)) + Q(x)f^*_{\mathrm{ext}}(h(x))\\ &\overset{(a)}{=} \inf_{h:S\to\mathrm{dom}(f^*_{\mathrm{ext}})} \sup_P \sum_x P(x)(g(x)-h(x)) + \mathbb{E}_Q[f^*_{\mathrm{ext}}(h)]\\ &= \begin{cases}\mathbb{E}_Q[f^*_{\mathrm{ext}}(g(X))] & g: S\to\mathrm{dom}(f^*_{\mathrm{ext}})\\ +\infty & \text{otherwise}\end{cases}.\end{aligned}$$

其中（a）来自于极小极大定理（由于$\mathcal{X}$的有限性而适用）。应用（7.86）中的凸对偶性即可证明所需的（7.107）。 □

Proof of Theorem 7.27. 首先，我们论证(7.94)式右侧的上确界可以取遍所有简单函数 g。然后，借助定理7.6，只需考虑有限字母表 $\mathcal{X}$ 即可。为此，固定任意 g。对于任意 δ，存在 a 使得 $\mathbb{E}_Q[f^*_{\mathrm{ext}}(g-a)] - aP[S] \le \Psi^*_{Q,P}(g) + \delta$。由于 $\mathbb{E}_Q[f^*_{\mathrm{ext}}(g-a_n)]$ 可以被简单函数任意好地逼近，我们得出结论：存在一个简单函数 $\tilde{g}$，使得同时有 $\mathbb{E}_P[\tilde{g}1_S] \ge \mathbb{E}_P[g1_S] - \delta$ 且

$$\Psi^*_{Q,P}(\tilde{g}) \le \mathbb{E}_Q[f^*_{\mathrm{ext}}(\tilde{g}-a)] - aP[S] + \delta \le \Psi^*_{Q,P}(g) + 2\delta\,.$$

这意味着在 (7.94) 中的上确界运算中限制为简单函数并不会改变右侧的值。

接下来考虑有限 $\mathcal{X}$。我们继续计算 Ψ 的共轭，其中若 P 是 $\mathcal{X}$ 上的概率测度，则 $\Psi(P) \triangleq D_f(P\|Q)$，否则 $+\infty$。那么对任意 $g\colon \mathcal{X}\to\mathbb{R}$，对所有概率测度 P 取最大值，我们有：

$$\begin{aligned}\Psi^*(g) &= \sup_P \sum_{x\in\mathcal{X}} P(x)g(x) - D_f(P\|Q)\\ &= \sup_P \sum_{x\in\mathcal{X}} P(x)g(x) - \sum_{x\in S^c} P(x)g(x) - \sum_{x\in S} Q(x) f\left(\frac{P(x)}{Q(x)}\right)\\ &= \sup_P \inf_{h:S\to\mathbb{R}} \sum_{x\in S} P(x)[g(x)-h(x)] + \sum_{x\in S^c} P(x)[g(x)-f'(\infty)] + \sum_{x\in S} Q(x)f^*_{\mathrm{ext}}(h(x))\\ &\overset{(a)}{=} \inf_{h:S\to\mathbb{R}} \left\{\sup_P \left(\sum_{x\in S} P(x)[g(x)-h(x)] + \sum_{x\in S^c} P(x)[g(x)-f'(\infty)]\right) + \mathbb{E}_Q[f^*_{\mathrm{ext}}(h(X))]\right\}\\ &\overset{(b)}{=} \inf_{h:S\to\mathbb{R}} \left\{\max\left(\max_{x\in S} g(x)-h(x), \max_{x\in S^c} g(x) - f'(\infty)\right) + \mathbb{E}_Q[f^*_{\mathrm{ext}}(h(X))]\right\}\\ &\overset{(c)}{=} \inf_{a\in\mathbb{R}} \left\{\max\left(a, \max_{x\in S^c} g(x) - f'(\infty)\right) + \mathbb{E}_Q[f^*_{\mathrm{ext}}(g(X)-a)]\right\}\end{aligned}$$

其中（a）由极大极小定理得出；（b）是因为P是一个概率测度；（c）成立是因为对于$x \in S$，我们可以限制到$h(x) = g(x) - a$，这得益于f^*_{ext}是非递减的（因为$\text{dom}(f_{\text{ext}}) = \mathbb{R}_+$）。

从凸对偶性我们已证明 $D_f(P\|Q) = \sup_g \mathbb{E}_P[g] - \Psi^*(g)$。注意，不失一般性，我们可以取 $g(x) = f'(\infty) + b$ 为 $x \in S^c$。将对 b 的优化与对 a 的优化互换，我们得到

$$\sup_b bP[S^c] - \max(a, b) = -aP[S]\,,$$

然后恢复(7.94)。要得到(7.95)，只需注意到如果$P[S^c] > 0$，则(7.95)的两边都是无穷大（因为$\Psi^*_Q(g)$不依赖于S之外的g的值）。否则，(7.95)与(7.94)一致。

□

8 Entropy method in combinatorics and geometry

组合数学中一种常用的从上方界定某些对象数量的方法涉及香农熵的巧妙应用。该方法通常如下进行：为了计算给定集合 $\mathcal{C}$ 的基数，我们从中均匀随机地抽取一个元素 $\mathcal{C}$，其熵由 $\log|\mathcal{C}|$ 给出。为了从上方界定 $|\mathcal{C}|$，我们用随机向量 $X=(X_1,\dots,X_n)$ 描述这个随机对象，然后通过以下方法之一计算或上界联合熵 $H(X_1,\dots,X_n)$：

• 边缘界：$H(X_1,\dots,X_n)\le\sum_{i=1}^n H(X_i)$ • 成对界（Shearer引理）及其推广参见定理1.8：$H(X_1,\dots,X_n)\ \le\frac{1}{n-1}\sum_{i<j}H(X_i,X_j)$ 链式法则（精确计算）：$H(X_1,\dots,X_n)=\sum_{i=1}^n H(X_i|X_1,\dots,X_{i-1})$

我们分别按难度递增的顺序，给出使用上述三种方法的三个应用：枚举给定平均权重的二进制向量、计数三角形和其他子图，以及Brégman定理。

最后，为了展示熵方法如何也能用于欧几里得空间中的问题，我们基于*differential*熵的类似性质（第2.3节）证明了Loomis-Whitney和Bollobás-Thomason定理。

8.1 平均权重的二进制向量

引理8.1（Massey [293]）*Let $\mathcal{C}\subset\{0,1\}^n$ and let p be the average fraction of 1's in $\mathcal{C}$, i.e.*

$$p=\frac{1}{|\mathcal{C}|}\sum_{x\in\mathcal{C}}\frac{w_{\mathrm{H}}(x)}{n},$$

where $w_{\mathrm{H}}(x)$ is the Hamming weight (number of 1's) of $x\in\{0,1\}^n$. Then $|\mathcal{C}|\le\exp\{nh(p)\}$.

我们强调，即使 $p>1/2$，这一结果仍然成立。

Proof. 令 $X=(X_1,\dots,X_n)$ 从 $\mathcal{C}$ 中均匀随机抽取。那么

$$\log|\mathcal{C}|=H(X)=H(X_1,\dots,X_n)\le\sum_i^n H(X_i)=\sum_{i=1}^n h(p_i),$$

其中 $p_i = \mathbb{P}[X_i = 1]$ 是第 i 位为 1 的顶点比例。注意

$$p = \frac{1}{n}\sum_{i=1}^{n} p_i,$$

因为我们可以先对$\mathcal{C}$中的向量求平均，也可以先对不同位求平均。根据Jensen不等式以及$x \mapsto h(x)$是凹函数的事实，

$$\sum_{i=1}^{n} h(p_i) \le nh\left(\frac{1}{n}\sum_{i=1}^{n} p_i\right) = nh(p).$$

因此我们证明了 $\log|\mathcal{C}| \le nh(p)$。 □

因此，我们得到了关于*Hamming ball*体积的以下界限，这在我们稍后讨论度量熵（第27章）时将起到关键作用。

定理 8.2

$$\sum_{j=0}^{k}\binom{n}{j} \le \exp\{nh(k/n)\}, \qquad k \le n/2.$$

Proof. 我们取 $\mathcal{C} = \{x \in \{0,1\}^n : w_{\mathrm{H}}(x) \le k\}$ 并调用先前的引理，该引理表明

$$\sum_{j=0}^{k}\binom{n}{j} = |\mathcal{C}| \le \exp\{nh(p)\} \le \exp\{nh(k/n)\},$$

其中最后一个不等式源于$x \mapsto h(x)$对$x \le 1/2$是递增的。 □

关于非二进制字母表的扩展，参见练习I.1和I.2。注意，定理8.2也可由第三部分的大偏差理论推出：

$$\frac{\mathrm{LHS}}{2^n} = \mathbb{P}(\mathrm{Bin}(n,1/2) \le k) \le \exp\left\{-nd\left(\frac{k}{n}\|\frac{1}{2}\right)\right\} = \exp\{-n(\log 2 - h(k/n))\} = \frac{\mathrm{RHS}}{2^n},$$

其中该不等式是二项分布的尾部上的切尔诺夫界（见例15.1中的(15.19)）。

8.2 Shearer引理与子图计数

回想一下，Shearer引理定理1.8（Han不等式）的一个特例表明：

$$H(X_1,X_2,X_3) \le \frac{1}{2}[H(X_1,X_2) + H(X_2,X_3) + H(X_1,X_3)].$$

这个结果的一个经典应用（见备注1.2）是在给定集合投影的基数时，界定$\mathbb{R}^3$中集合的基数。

对于图 H 和 G，定义 $N(H,G)$ 为 H 在 G 中的副本数。[1] 例如，

$$N(\triangle, \text{K}_4) = 4, \quad N(\text{P}_3, \text{K}_4) = 8.$$

如果我们知道 G 有 m 条边，那么包含在 G 中的 H 的最大数量是多少？为了研究这个量，我们定义

$$N(H,m) = \max_{G:|E(G)|\le m} N(H,G).$$

作为一个例子，我们证明了最大三角形数量满足

$$N(K_3,m) \asymp m^{3/2}. \tag{8.1}$$

为了表明 $N(H,m) \gtrsim m^{3/2}$，考虑具有 $m = |E(G)| = \binom{n}{2} \asymp n^2$ 和 $N(K_3,K_n) = \binom{n}{3} \asymp n^3 \asymp m^{3/2}$ 的 $G = K_n$。

为展示上界，固定一个具有m条边的图$G = (V,E)$。均匀随机地绘制一个带标记的三角形，并用(X_1,X_2,X_3)表示顶点。那么根据Shearer引理，

$$\log(3!N(K_3,G)) = H(X_1,X_2,X_3) \le \frac{1}{2}[H(X_1,X_2)+H(X_2,X_3)+H(X_1,X_3)] \le \frac{3}{2}\log(2m).$$

因此

$$N(K_3,G) \le \frac{\sqrt{2}}{3} m^{3/2}. \tag{8.2}$$

注8.1 有趣的是，线性代数论证得出的上界与(8.2)完全相同：设A为G的邻接矩阵，其特征值为$\{\lambda_i\}$。那么

$$2|E(G)| = \operatorname{tr}(A^2) = \sum \lambda_i^2$$
$$6N(K_3,G) = \operatorname{tr}(A^3) = \sum \lambda_i^3$$

根据闵可夫斯基不等式，$(6N(K_3,G))^{1/3} \le (2|E(G)|)^{1/2}$，从而得出 $N(K_3,G) \le \frac{\sqrt{2}}{3} m^{3/2}$。

使用Shearer引理（定理1.8），Friedgut和Kahn [173] 得到了任意H下(8.1)的对应结果；这一结果最初由Alon [13]证明。我们首先介绍图的*fractionalcovering number*。对于图 $H=(V,E)$，将分数覆盖数定义为以下线性规划（LP）的值：[2]

$$\rho^*(H) = \min_w \left\{ \sum_{e\in E} w(e) : \sum_{e\in E,\ v\in e} w(e) \ge 1, \forall v \in V, w(e) \in [0,1] \right\}. \tag{8.3}$$

定理 8.3

$$c_0(H) m^{\rho^*(H)} \le N(H,m) \le c_1(H) m^{\rho^*(H)}. \tag{8.4}$$

[1] To be precise, here $N(H,G)$ is the number of subgraphs of G (subsets of edges) isomorphic to H. If we denote by $\mathrm{inj}(H,G)$ the number of injective maps $V(H)\to V(G)$ mapping edges of H to edges of G, then $N(H,G) = \frac{1}{|\mathrm{Aut}(H)|}\mathrm{inj}(H,G)$.

[2] If the "$\in [0,1]$" constraints in (8.3) and (8.5) are replaced by "$\in \{0,1\}$", we obtain the covering number $\rho(H)$ and the independence number $\alpha(H)$ of H, respectively.

例如，对于三角形我们有$\rho^*(K_3) = 3/2$，而定理8.3与（8.1）一致。

Proof. *Upper bound*：令 $V(H) = [n]$，并令 $w^*(e)$ 为 $\rho^*(H)$ 的解。对于任意具有 m 条边的 G，从所有与 H 同构的子图中均匀随机地抽取 G 的一个子图。给定这样的随机子图，令 $X_i \in V(G)$ 为对应于 H 的第 i 个顶点的顶点，$i \in [n]$。现在通过以概率 $\frac{w^*(e)}{\rho^*(H)}$ 从 $E(H)$ 中抽取一条边 e，定义 $[n]$ 的一个随机 2-子集 S。根据 $\rho^*(H)$ 的定义，对于任意 $i \in [n]$，我们有 $\mathbb{P}[i \in S] \geq \frac{1}{\rho^*(H)}$。现在我们准备应用定理 1.8：

$$\log N(H,G) = H(X) \leq H(X_S|S)\rho^*(H) \leq \log(2m)\rho^*(H)\,,$$

其中最后一个不等式与之前一样：如果 $S = \{v,w\}$，那么 $X_S = (X_v, X_w)$ 取 $2m$ 个值之一。总的来说，我们得到[3] $N(H,G) \leq (2m)^{\rho^*(H)}$。

Lower bound：这相当于构造一个图 G，具有 m 条边，使得 $N(H,G) \geq c(H)|e(G)|^{\rho^*(H)}$。考虑 (8.3) 的对偶 LP

$$\alpha^*(H) = \max_{\psi} \left\{ \sum_{v \in V(H)} \psi(v) : \psi(v) + \psi(w) \leq 1, \forall (vw) \in E, \psi(v) \in [0,1] \right\} \tag{8.5}$$

即，*fractional packing number*。根据线性规划的对偶定理，我们有$\alpha^*(H) = \rho^*(H)$。图G构造如下：对于H的每个顶点v，将其复制$m(v)$次。对于H的每条边$e = (vw)$，将其替换为完全二部图$K_{m(v),m(w)}$。那么G的边总数为

$$|E(G)| = \sum_{(vw) \in E(H)} m(v)m(w).$$

此外，$N(G,H) \geq \prod_{v \in V(H)} m(v)$。为了最小化指数 $\frac{\log N(G,H)}{\log |E(G)|}$，固定一个大数 M 并令 $m(v) = \left\lceil M^{\psi(v)} \right\rceil$，其中 ψ 是 (8.5) 中的最大化者。那么

$$\begin{aligned} |E(G)| &\leq \sum_{(vw) \in E(H)} 4M^{\psi(v)+\psi(w)} \leq 4M|E(H)| \\ N(G,H) &\geq \prod_{v \in V(H)} M^{\psi(v)} = M^{\alpha^*(H)} \end{aligned}$$

我们完成了。 □

8.3 布雷格曼定理

在本节中，我们展示Radhakrishnan[351]对Brégman定理[74]的一个优雅的熵证明，该定理界定了二部图中*perfect matchings* (1-正则生成子图)的数量。

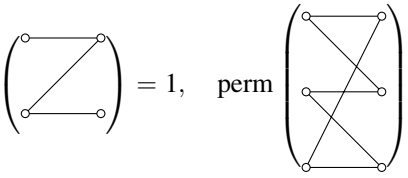
3 注意，对于 $H = K_3$ 这给出了比 (8.2) 更弱的界。为了恢复 (8.2)，我们需要取 $X = (X_1, \ldots, X_n)$ 在所有单射同态 $H \to G$ 上均匀分布。

我们首先给出一些定义。一个 $n \times n$ 矩阵 A 的 *permanent* 定义为

$$\operatorname{perm}(A) \triangleq \sum_{\pi \in S_n} \prod_{i=1}^{n} a_{i\pi(i)},$$

其中 S_n 表示 $[n]$ 的所有排列构成的群。对于左右两侧各含 n 个顶点的二分图 G，G 中完美匹配的数量由 perm(A) 给出，其中 A 是邻接矩阵。例如，

$$\operatorname{perm}\left(\quad\right) = 1, \quad \operatorname{perm}\left(\quad\right) = 2$$



定理 8.4（Brégman 定理）*For any $n \times n$ bipartite graph with adjacency matrix A,*

$$\operatorname{perm}(A) \leq \prod_{i=1}^{n} (d_i!)^{\frac{1}{d_i}},$$

where d_i is the degree of left vertex i (i.e. sum of the $i^{\text{第}}$ row of A).

作为示例，考虑 $G = K_{n,n}$。那么 perm(G) = $n!$，这与右侧 $[(n!)^{1/n}]^n = n!$ 一致。更一般地，如果 G 由 n/d 个 $K_{d,d}$ 的副本组成，则 Brégman 界是紧的，并且 perm = $(d!)^{n/d}$。

Proof. 如果 perm(A) = 0，则无需证明，因此我们转而假设 perm(A) > 0 且存在某些完美匹配。作为使用熵方法证明定理8.4的首次尝试，我们随机均匀地选择一个完美匹配，将 i^{th} 左侧顶点与 X_i^{th} 右侧顶点相匹配。令 $X = (X_1, \ldots, X_n)$。那么

$$\log \operatorname{perm}(A) = H(X) = H(X_1, \ldots, X_n) \leq \sum_{i=1}^{n} H(X_i) \leq \sum_{i=1}^{n} \log(d_i).$$

因此，perm(A) $\leq \prod_i d_i$。这比布雷格曼界的差了一个指数因子，因为根据斯特林公式（I.2）

$$\prod_{i=1}^{n} (d_i!)^{\frac{1}{d_i}} \sim \left(\prod_{i=1}^{n} d_i \right) e^{-n}.$$

这里是我们的第二次尝试。希望使用链式法则来展开联合熵，并更仔细地界定条件熵。让我们写出

$$H(X_1, \ldots, X_n) = \sum_{i=1}^{n} H(X_i | X_1, \ldots, X_{i-1}) \leq \sum_{i=1}^{n} \mathbb{E}[\log N_i].$$

其中 N_i 作为一个随机变量，表示在给定 $X_1, \ldots, X_{i-1}$ 的条件下 X_i 可能取值的数量，即在 $1, \ldots, i-1$ 的匹配结果给定的情况下，左侧顶点 i 有多少种可能的匹配方式。然而，从这一点出发很难继续推进，因为我们只知道度信息，而不知道图本身。事实上，由于我们不知道顶点的相对位置，我们没有理由按照从 1 到 n 的顺序进行。关键思想是 *label the vertices randomly*，在这个随机顺序下应用链式法则并取平均。

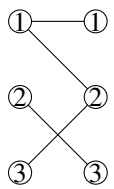
为此，从 S_n 中均匀随机选取 π，并且独立于 X。然后

$$\begin{aligned}
\log \operatorname{perm}(A) &= H(X) = H(X|\pi) \\
&= H(X_{\pi(1)}, \ldots, X_{\pi(n)}|\pi) \\
&= \sum_{k=1}^{n} H(X_{\pi(k)}|X_{\pi(1)}, \ldots, X_{\pi(k-1)}, \pi) \\
&= \sum_{k=1}^{n} H(X_k|\{X_j : \pi^{-1}(j) < \pi^{-1}(k)\}, \pi) \\
&\le \sum_{k=1}^{n} \mathbb{E} \log N_k,
\end{aligned}$$

其中 N_k 表示在给定 $\{X_j\colon\ \pi^{-1}(j) < \pi^{-1}(k)\}$ 的结果下，顶点 k 的可能匹配数，而期望是关于 (X, π) 的。关键观察是：

引理 8.5 *N_k is uniformly distributed on $[d_k]$.*

示例 8.1 作为引理 8.5 的一个具体例子，考虑右图中的图 G。对于顶点 $k = 1$，$d_k = 2$。根据随机排序，如果 $\pi = 1 * *$，则 $N_k = 2$ 以概率 $1/3$；如果 $\pi = * * 1$，则 $N_k = 1$ 以概率 $1/3$；如果 $\pi = 213$，则 $N_k = 2$ 以概率 $1/3$；如果 $\pi = 312$，则 $N_k = 1$ 以概率 $1/3$。综合所有情况，确实 N_k 等于 1 或 2 的可能性相同。



应用引理8.5,

$$\mathbb{E}_{(X,\pi)} \log N_k = \frac{1}{d_k} \sum_{i=1}^{d_k} \log i = \log (d_i!)^{\frac{1}{d_i}}$$

因此

$$\log \operatorname{perm}(A) \le \sum_{k=1}^{n} \log (d_i!)^{\frac{1}{d_i}} = \log \prod_{i=1}^{n} (d_i!)^{\frac{1}{d_i}}.$$

□

Proof of Lemma 8.5. 事实上，我们将证明，即使以X^n为条件，N_k的分布也是均匀的。实际上，如果$d = d_k$是第k个（右）节点的度数，那么令$J_1, \ldots, J_d$为在固定完美匹配下与k的邻居相匹配的那些右节点（J_i中的一个，比如J_1，等于

k）。随机排列 π 按照对应右节点被揭示的顺序重新排列 J_i。显然，J_i 的诱导顺序在 d 种可能选择上是均匀的！注意，如果 J_1 出现在位置 $\ell \in \{1,\dots,d\}$，则 $N_k = d - \ell + 1$。显然，ℓ 以及因此 N_k 在 $[d] = [d_k]$ 上是均匀的。

□

8.4 欧几里得几何：Bollobás-Thomason 与 Loomis-Whitney

以下著名结果表明，n 维矩形同时最小化所有坐标投影的体积：[4]

定理 8.6（Bollobás-Thomason 盒定理）*Let $K \subset \mathbb{R}^n$ be a compact set. For $S \subset [n]$, denote by $K_S \subset \mathbb{R}^S$ the projection of K onto those coordinates indexed by S. Then there exists a rectangle A s.t.* $\mathrm{Leb}(A) = \mathrm{Leb}(K)$ *and for all $S \subset [n]$:*

$$\mathrm{Leb}(A_S) \le \mathrm{Leb}(K_S)$$

因此，从最大化坐标投影体积的角度来看，矩形是极值对象。

Proof. 设 X^n 在 K 上均匀分布。则 $h(X^n) = \log \mathrm{Leb}(K)$。设 A 为一个大小为 $a_1 \times \cdots \times a_n$ 的矩形，其中

$$\log a_i = h(X_i|X^{i-1})\,.$$

然后，根据定理2.7(a)，我们有

$$h(X_S) \le \log \mathrm{Leb}(K_S).$$

另一方面，根据链式法则以及条件作用减少微分熵的事实（回顾定理2.7(a)和(c)），

$$\begin{aligned} h(X_S) &= \sum_{i=1}^{n} 1\{i \in S\} h(X_i|X_{[i-1]\cap S}) \\ &\ge \sum_{i\in S} h(X_i|X^{i-1}) \\ &= \log \prod_{i\in S} a_i \\ &= \log \mathrm{Leb}(A_S). \end{aligned}$$

□

以下结果是Shearer引理的连续对应形式（见定理1.8和注记1.2）：

4 注意，由于K是紧致的，其投影和切片也都是紧致的，因此是可测的。

推论 8.7（Loomis-Whitney）*Let K be a compact subset of $\mathbb{R}^n$ and let K_{j^c} denote the projection of K onto coordinates in $[n] \setminus j$. Then*

$$\mathrm{Leb}(K) \leq \prod_{j=1}^{n} \mathrm{Leb}(K_{j^c})^{\frac{1}{n-1}} . \tag{8.6}$$

Proof. 设 A 为一个与 K 体积相等的矩形。注意

$$\mathrm{Leb}(K) = \mathrm{Leb}(A) = \prod_{j=1}^{n} \mathrm{Leb}(A_{j^c})^{\frac{1}{n-1}}$$

根据前一定理，$\mathrm{Leb}(A_{j^c}) \leq \mathrm{Leb}(K_{j^c})$。 □

Loomis-Whitney 不等式的意义通过引入 K 在第 j 个方向上的平均宽度而得到最佳理解：$w_j \triangleq \frac{\mathrm{Leb}(K)}{\mathrm{Leb}(K_{j^c})}$。那么（8.6）等价于

$$\mathrm{Leb}(K) \geq \prod_{j=1}^{n} w_j ,$$

即K的体积大于平均宽度矩形的体积。

9 Random number generators

在本章中，我们探讨（一个简化版的）生成高质量随机数生成器的问题。给定一串独立的伯努利(p)比特流，其中*unknown* p，我们旨在将其转换为纯净随机比特，即独立的伯努利(1/2)比特。我们的目标是在不知道实际偏差p的情况下，从可能有偏的硬币翻转中尽可能多地提取公平的硬币翻转结果。

1951年，冯·诺依曼[442]提出了以下方案：将比特流分成比特对，如果是10则输出0，如果是01则输出1，否则不做任何操作并移至下一对。由于01和10出现的概率均为$p\bar{p}$ (，在此提醒$\bar{p} = 1 - p$)，无论p的值如何，我们都能在输出端获得公平的抛硬币结果。为了衡量冯·诺依曼方案的效率，请注意，平均而言，我们有$2n$比特输入和$2p\bar{p}n$比特输出。因此效率（速率）为$p\bar{p}$。问题是：我们能否做得更好?

在问题表述中有几个选择需要做出。*Universal vs non-universal*：源分布可以分别是未知的或部分已知的。*Exact vs approximately fair coin flips*：生成的硬币翻转是完全公平的还是近似的，依据第7章研究的一种f-散度来衡量（例如，总变差或KL散度）。在本章中，我们仅关注完全公平硬币的通用生成。在另一个极端，在第二部分我们将看到最优数据压缩器的输出由几乎纯随机的比特组成，然而这些压缩器是非通用的（需要知道源统计信息，例如偏差p）且是近似的。

为了方便起见，在本章中我们考虑以比特为单位的熵，即本章中的$\log = \log_2$。

9.1 设置

令 $\{0,1\}^* = \cup_{k\geq 0}\{0,1\}^k = \{\emptyset, 0, 1, 00, 01, \dots\}$ 表示所有有限长度二进制串的集合，其中 $\emptyset$ 表示空串。对于任意 $x \in \{0,1\}^*$，$l(x)$ 表示 x 的长度。

我们首先正式介绍随机数生成器的定义。如果输入向量为X，将输出（可变长度）向量记为$Y \in \{0,1\}^*$。那么Y的期望性质如下：在Y的长度为k的条件下，Y均匀分布在$\{0,1\}^k$上。

定义9.1（随机性提取器）我们说 $\Psi : \{0,1\}^* \to \{0,1\}^*$ 是一个 *extractor*，如果

1 如果 x 是 y 的前缀，则 $\Psi(x)$ 是 $\Psi(y)$ 的前缀。

对于任意 n 和任意 $p \in (0,1)$，如果 $X^n \overset{\text{i.i.d.}}{\sim} \text{Ber}(p)$，则在每个 $k \geq 1$ 的条件下，$\Psi(X^n) \sim \text{Ber}(1/2)^k$，条件是 $l(\Psi(X^n)) = k$。

提取器 Ψ 的效率由其 *rate* 衡量：

$$r_\Psi(p) = \limsup_{n\to\infty} \frac{\mathbb{E}[l(\Psi(X^n))]}{n}, \quad X^n \overset{\text{i.i.d.}}{\sim} \text{Ber}(p).$$

换句话说，Ψ消耗了一连串有偏的n硬币，其偏差为p，并平均输出$nr_\Psi(p)$个公平硬币。

注意，上述冯·诺依曼方案定义了一个有效的提取器 Ψ_{vN} (，其中 $\Psi_{\text{vN}}(x^{2n+1}) = \Psi_{\text{vN}}(x^{2n})$)，其速率为 $r_{\text{vN}}(p) = p\bar{p}$。显然这是浪费的，因为即使输入比特已经是公平的，我们只能得到25%的回报。

9.2 逆命题

我们证明，没有任何提取器的速率能高于二元熵函数 $h(p)$，即便允许提取器是非通用的（依赖于 p）。直观上，每个 Ber(p) 变量所含的“信息量”为 $h(p)$ 比特；因此，不可能提取出超过这个量的信息。通过熵的数据处理不等式（因为提取器是确定性函数），这一点很容易被精确表述。

定理 9.2 *For any extractor Ψ and any $p \in (0,1)$,*

$$r_\Psi(p) \geq h(p) = p\log_2\frac{1}{p} + \bar{p}\log_2\frac{1}{\bar{p}}.$$

Proof. 设 $L = \Psi(X^n)$。那么

$$nh(p) = H(X^n) \geq H(\Psi(X^n)) = H(\Psi(X^n)|L) + H(L) \geq H(\Psi(X^n)|L) = \mathbb{E}[L] \quad \texttt{bits},$$

其中最后一步源于关于 Ψ 的假设，即在给定 $L = k$ 的条件下，$\Psi(X^n)$ 在 $\{0,1\}^k$ 上均匀分布。 □

冯·诺依曼提取器的速率和熵的界限如图9.1所示。接下来，我们介绍两个分别由Elias [149]和Peres [327]提出的提取器，它们都达到了二元熵函数。（更准确地说，两者都是构造了一系列提取器，其速率趋近于熵的界限。）

9.3 基于数据压缩的Elias构造

Elias方案的直观解释如下：

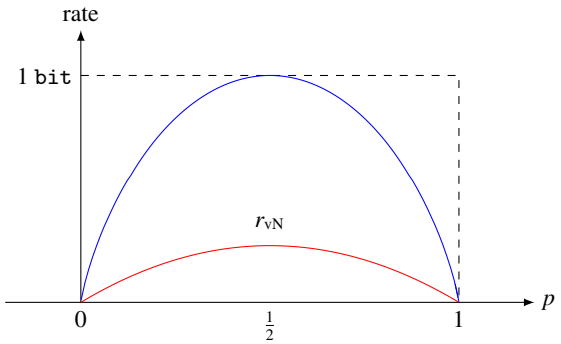


图9.1 冯·诺依曼提取器的率函数与二元熵函数。

1 对于独立同分布的 X^n，每个字符串的概率仅取决于其 *type*，即 1 的个数，参见习题 I.1 中的类型方法。因此，在 1 的个数为 qn 的条件下，X^n 在类型类 T_q 上均匀分布。这一观察对实际偏置 p 的任何值都普遍成立。

2 给定某个有限集上的均匀分布随机变量，我们可以轻松将其转化为 *variable-length* 公平抛硬币字符串。例如：

- 如果 U 在 $\{1,2,3\}$ 上均匀分布，我们可以将 $1\mapsto\emptyset, 2\mapsto 0$ 和 $3\mapsto 1$。• 如果 U 在 $\{1,2,\ldots,11\}$ 上均匀分布，我们可以将 $1\mapsto\emptyset, 2\mapsto 0$、$3\mapsto 1$，并将剩余的八个数 $4,\ldots,1$ 1 分配给 3 位字符串。

我们将在第10章中稍后研究这类变长编码器的性质。

引理 9.3 *Given U uniformly distributed on $[M]$, there exists $f:[M]\to\{0,1\}^*$ such that conditioned on $l(f(U))=k$, $f(U)$ is uniformly over $\{0,1\}^k$. Moreover,*

$$\log_2 M-4\le\mathbb{E}[l(f(U))]\le\log_2 M \quad \texttt{bits}.$$

Proof. 我们通过将 $[M]$ 划分为基数均为 2 的幂的子集，并将每个子集中的元素分配给该长度的二进制串，从而定义了 f。形式上，将 M 的二进制展开记为 $M=\sum_{i=0}^{n} m_i 2^i$，其中最高有效位 $m_n=$ 为 1，且 $n=\lfloor\log_2 M\rfloor+$ 为 1。取非零的 m_i，我们可以将 $M=2^{i_0}+\cdots 2^{i_t}$ 写成不同 2 的幂之和，从而定义一个划分 $[M]=\cup_{j=0}^{t}M_j$，其中 $|M_j|=2^{i_j}$。我们将 M_j 的元素映射到 $\{0,1\}^{i_j}$。最后注意，以任意子集为条件的均匀分布仍然是均匀的。

为了证明期望长度的界，上界由相同的熵论证 $\log_2 M = H(U)\ge H(f(U))\ge H(f(U)|l(f(U)))=\mathbb{E}[l(f(U))]$ 得出，而下界则由

$$\mathbb{E}[l(f(U))]=\frac{1}{M}\sum_{i=0}^{n} m_i 2^i\cdot i=n-\frac{1}{M}\sum_{i=0}^{n} m_i 2^i(n-i)\ge n-\frac{2^n}{M}\sum_{i=0}^{n}2^{i-n}(n-i)\ge n-\frac{2^{n+1}}{M}\ge n-4,$$

其中最后一步由$n\le\log_2 M+1$得出。 □

埃利亚斯的提取器 Fix $n \geq 1$. 令 $w_{\mathrm{H}}(x^n)$ 定义二进制串 x^n 的汉明重量（1 的个数）。令 $T_k = \{x^n \in \{0,1\}^n : \ w_{\mathrm{H}}(x^n) = k\}$ 定义半径为 k 的汉明球。对于每个 $0 \leq k \leq n$，我们将引理 9.3 中的函数 f 应用于每个 T_k。这定义了一个映射 $\Psi_{\mathrm{E}} : \ \{0,1\}^n \to \{0,1\}^*$，然后我们将其扩展为 $\Psi_{\mathrm{E}} : \ \{0,1\}^* \to \{0,1\}^*$，通过按 n 比特块应用该映射，并丢弃最后一个不完整的块。那么显然速率由 $\frac{1}{n}\mathbb{E}[l(\Psi_{\mathrm{E}}(X^n))]$ 给出。根据引理 9.3，我们有

$$\mathbb{E}\log\binom{n}{w_{\mathrm{H}}(X^n)} - 4 \leq \mathbb{E}[l(\Psi_{\mathrm{E}}(X^n))] \leq \mathbb{E}\log\binom{n}{w_{\mathrm{H}}(X^n)}$$

使用斯特林近似（参见练习I.1），我们可以证 w

$$\log\binom{n}{w_{\mathrm{H}}(X^n)} = nh(w_{\mathrm{H}}(X^n)/n) + O(\log n)\,.$$

由于 $\frac{1}{n}w_{\mathrm{H}}(X^n) = \frac{1}{n}\sum_{i=1}^n 1\{X_i = 1\}$，根据大数定律我们得出 $\frac{w_{\mathrm{H}}(X^n)}{n} \to p$，并且由于 h 是连续有界函数，我们也有

$$\frac{1}{n}\mathbb{E}[l(\Psi_{\mathrm{E}}(X^n))] = h(p) + O(\log n/n).$$

因此，当$n \to \infty$时，Ψ_{E}的提取率接近最优值$h(p)$。

9.4 佩雷斯迭代冯·诺依曼方案

主要思想是回收冯·诺依曼方案中被丢弃的比特并进行迭代。冯·诺依曼提取器丢弃的是：(a) 来自相等对的比特；(b) 不同对的位置。为了达到熵界，我们还需要从这两部分中提取随机性。

首先，一些符号说明：给定 x^{2n}，令 $k = l(\Psi_{\mathrm{vN}}(x^{2n}))$ 表示连续不同位对的数量。

• 令 $1 \leq m_1 < \ldots < m_k \leq n$ 表示满足 $x_{2m_j} \neq x_{2m_j-1}$ 的位置。• 令 $1 \leq i_1 < \ldots < i_{n-k} \leq n$ 表示满足 $x_{2i_j} = x_{2i_j-1}$ 的位置。• $y_j = x_{2m_j}$, $v_j = x_{2i_j}$, $u_j = x_{2j} \oplus x_{2j+1}$。

Here y^k 是冯·诺依曼方案输出的比特，而 v^{n-k} 和 u^n 都被丢弃。注意 u^n 很重要，因为它编码了 y^k 的位置并包含大量信息。因此，如果我们能从 v^{n-k} 和 u^n 中提取出随机性，冯·诺依曼方案就可以得到改进。

佩雷斯提取器 对于每个 $t \in \mathbb{N}$，递归地定义提取器 Ψ_t 如下：

• 将 Ψ_1 设为冯·诺依曼提取器 Ψ_{vN}，即 $\Psi_1(x^{2n+1}) = \Psi_1(x^{2n}) = y^k$。• 通过 $\Psi_t(x^{2n}) = \Psi_t(x^{2n+1}) = (\Psi_1(x^{2n}), \Psi_{t-1}(u^n), \Psi_{t-1}(v^{n-k}))$ 定义 Ψ_t。

例如，考虑输入 $x = 100111010011$，长度为 $2n = 12$。那么输出如下递归确定：

$$\overbrace{(\underline{011})}^{y}\overbrace{(110100)}^{u}\overbrace{(101)}^{v}$$
$$(\underline{1})(010)(10)(\underline{0})$$
$$(\underline{1})(\underline{0})$$

接下来我们 (a) 验证 Ψ_t 是有效的提取器；(b) 评估其效率（速率）。注意，进入迭代的比特不再独立同分布。为了计算 Ψ_t 的速率，引入可交换性的概念是方便的。我们称 X^n 是 *exchangeable*，如果联合分布在排列下不变，即对 $[n]$ 上的任意排列 π，有 $P_{X_1,\dots,X_n} = P_{X_{\pi(1)},\dots,X_{\pi(n)}}$。特别地，如果 X_i 是二元的，那么 X^n 可交换当且仅当联合分布仅依赖于汉明重量，即对某个函数 f，有 $P_{X^n}(x^n) = f(w_{\mathrm{H}}(x^n))$。例子：$X^n$ 是 iid $\mathrm{Ber}(p)$；X^n 在汉明球面 T_k 上均匀分布。

例如，如果 X^{2n} 是独立同分布的伯努利分布 $\mathrm{Ber}(p)$，那么在给定 $L = k$ 的条件下，V^{n-k} 是独立同分布的伯努利分布 $\mathrm{Ber}(p^2/(p^2+\bar{p}^2))$，因为 $L \sim$ 服从二项分布 $\mathrm{Binom}(n, 2p\bar{p})$，并且

$$\begin{aligned}\mathbb{P}[Y^k = y, U^n = u, V^{n-k} = v | L = k] &= \frac{p^{k+2m}\bar{p}^{n-k-2m}}{\binom{n}{k}(p^2+\bar{p}^2)^{n-k}(2p\bar{p})^k} \\ &= 2^{-k} \cdot \binom{n}{k}^{-1} \cdot \left(\frac{p^2}{p^2+\bar{p}^2}\right)^m \left(\frac{\bar{p}^2}{p^2+\bar{p}^2}\right)^{n-k-m} \\ &= \mathbb{P}[Y^k = y | L = k]\mathbb{P}[U^n = u | L = k]\mathbb{P}[V^{n-k} = v | L = k],\end{aligned}$$

其中 $m = w_{\mathrm{H}}(v)$。一般来说，当 X^{2n} 仅可交换时，我们有以下结果：

引理 9.4（Ψ_t 保持可交换性）*Let X^{2n} be exchangeable and $L = \Psi_1(X^{2n})$. Then conditioned on $L = k$, Y^k, U^n and V^{n-k} are independent, each having an exchangeable distribution. Furthermore, $Y^k \overset{i.i.d.}{\sim} \mathrm{Ber}(\frac{1}{2})$ and U^n is uniform over T_k.*

Proof. 只需证明 $\forall y, y' \in \{0,1\}^k, u, u' \in T_k$ 和 $v, v' \in \{0,1\}^{n-k}$ 使得 $w_{\mathrm{H}}(v) = w_{\mathrm{H}}(v')$，我们有

$$\mathbb{P}[Y^k = y, U^n = u, V^{n-k} = v | L = k] = \mathbb{P}[Y^k = y', U^n = u', V^{n-k} = v' | L = k],$$

这意味着对于某个函数 f，有 $\mathbb{P}[Y^k = y, U^n = u, V^{n-k} = v | L = k] = f(w_{\mathrm{H}}(v))$。注意，字符串 X^{2n} 与三元组 (Y^k, U^n, V^{n-k}) 之间存在一一对应关系。实际上，要重建 X^{2n}，只需从 Y 中读取 k 个不同的对，并根据 U 中 1 的位置填充它们，再从 V 填充剩余相等的对。[示例：$(y, u, v) = (01, 1100, 01) \Rightarrow x = (10010011)$，$(y, u, v) = (11, 1010, 10) \Rightarrow x' = (01110100)$。] 最后，注意 u, y, v 和 u', y', v' 对应于两个具有相同汉明重量（$w_{\mathrm{H}}(x) = k + 2w_{\mathrm{H}}(v)$）的输入字符串 x 和 x'，因此由于 X^{2n} 的可交换性，它们具有相同的概率。

□

引理 9.5 (Ψ_t 是一个提取器) *Let X^{2n} be exchangeable. Then $\Psi_t(X^{2n}) \overset{i.i.d.}{\sim} \mathrm{Ber}(1/2)$ conditioned on $l(\Psi_t(X^{2n})) = m$.*

Proof. 注意 $\Psi_t(X^{2n}) \in \{0,1\}^*$。等价于证明对于所有 $s^m \in \{0,1\}^m$,

$$\mathbb{P}[\Psi_t(X^{2n}) = s^m] = 2^{-m}\mathbb{P}[l(\Psi_t(X^{2n})) = m].$$

对 t 进行归纳。$t = 1$ 的基础情况由引理 9.4（Y 部分的分布）得出。假设 Ψ_{t-1} 是一个提取器。回忆 $\Psi_t(X^{2n}) = (\Psi_1(X^{2n}), \Psi_{t-1}(U^n), \Psi_{t-1}(V^{n-k}))$ 并将长度写为 $L = L_1 + L_2 + L_3$，其中 $L_2 \perp L_3 | L_1$ 由引理 9.4 得出。那么

$$\begin{aligned}
&\mathbb{P}[\Psi_t(X^{2n}) = s^m] \\
=& \sum_{k=0}^{m} \mathbb{P}[\Psi_t(X^{2n}) = s^m | L_1 = k]\mathbb{P}[L_1 = k] \\
\overset{\text{Lemma 9.4}}{=}& \sum_{k=0}^{m}\sum_{r=0}^{m-k} \mathbb{P}[L_1 = k]\mathbb{P}[Y^k = s^k | L_1 = k]\mathbb{P}[\Psi_{t-1}(U^n) = s_{k+1}^{k+r} | L_1 = k]\mathbb{P}[\Psi_{t-1}(V^{n-k}) = s_{k+r+1}^{m} | L_1 = k] \\
\overset{\text{induction}}{=}& \sum_{k=0}^{m}\sum_{r=0}^{m-k} \mathbb{P}[L_1 = k]2^{-k}2^{-r}\mathbb{P}[L_2 = r | L_1 = k]2^{-(m-k-r)}\mathbb{P}[L_3 = m-k-r | L_1 = k] \\
=& 2^{-m}\mathbb{P}[L = m].
\end{aligned}$$

□

接下来我们计算Ψ_t的速率。令$X^{2n} \overset{\text{i.i.d.}}{\sim} \mathrm{Ber}(p)$。那么根据强大数定律(SLLN), $\frac{1}{2n}l(\Psi_1(X^{2n})) \triangleq \frac{L_n}{2n}$几乎必然收敛到$p\bar{p}$。再次通过归纳法假设$\frac{1}{2n}l(\Psi_{t-1}(X^{2n})) \xrightarrow{\text{a.s.}} r_{t-1}(p)$，其中$r_1(p) = pq$。于是

$$\frac{1}{2n}l(\Psi_t(X^{2n})) = \frac{L_n}{2n} + \frac{1}{2n}l(\Psi_{t-1}(U^n)) + \frac{1}{2n}l(\Psi_{t-1}(V^{n-L_n})).$$

注意 $U^n \overset{\text{i.i.d.}}{\sim} \mathrm{Ber}(2p\bar{p})$, $V^{n-L_n}|L_n \overset{\text{i.i.d.}}{\sim} \mathrm{Ber}(p^2/(p^2+\bar{p}^2))$ 且 $L_n \xrightarrow{\text{a.s.}} \infty$。然后归纳假设意味着 $\frac{1}{n}l(\Psi_{t-1}(U^n)) \xrightarrow{\text{a.s.}} r_{t-1}(2p\bar{p})$ 和 $\frac{1}{2(n-L_n)}l(\Psi_{t-1}(V^{n-L_n})) \xrightarrow{\text{a.s.}} r_{t-1}(p^2/(p^2+\bar{p}^2))$。我们得到递推:

$$r_t(p) = p\bar{p} + \frac{1}{2}r_{t-1}(2p\bar{p}) + \frac{p^2+\bar{p}^2}{2}r_{t-1}\left(\frac{p^2}{p^2+\bar{p}^2}\right) \triangleq (Tr_{t-1})(p), \tag{9.1}$$

其中算子 T 将 $[0,1]$ 上的连续函数映射为另一个连续函数。此外，T 是单调的，即若逐点有 $f \le g$，则 $Tf \le Tg$。于是可以证明 r_t 从下方单调收敛到 T 的不动点，而该不动点恰好就是二元熵函数 h。与其直接验证 $Th = h$，这里给出一个简单证明：考虑 $X_1, X_2 \overset{\text{i.i.d.}}{\sim} \mathrm{Ber}(p)$。则 $2h(p) = H(X_1, X_2) = H(X_1 \oplus X_2, X_1) = H(X_1 \oplus X_2) + H(X_1 | X_1 \oplus X_2) = h(2p\bar{p}) + 2p\bar{p}h(\frac{1}{2}) + (p^2+\bar{p}^2)h(\frac{p^2}{p^2+\bar{p}^2})$。

r_t 收敛到 h 的过程如图 9.2 所示。

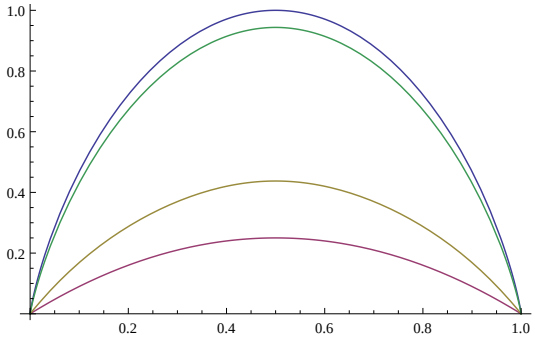


图9.2 迭代冯·诺依曼提取器t次)得到的Ψ_t (的速率函数r_t与二元熵函数的对比，对于$t = 1, 4, 10$。

9.5 伯努利工厂

给定一串未知 p 的 Ber(p) 比特流，对于何种函数 $f\colon [0,1] \to [0,1]$，我们可以模拟来自 Ber($f(p)$) 的独立同分布比特。我们上面的讨论涉及 $f(p) \equiv \frac{1}{2}$。最著名的例子是我们能否从 Ber(p) 模拟 Ber($2p$)，即 $f(p) = 2p$ 从。Keane 和 O'Brien [242] 表明，所有可以模拟的 f 要么是常数，要么是“多项式有界地远离 0 或 1”：对于所有 $0 < p < 1$，$\min\{f(p), 1-f(p)\} \geq \min\{p, 1-p\}^n$ 对于某个 $n \in \mathbb{N}$。特别地，将偏置加倍是不可能的。

上述结果涉及原则上可以模拟$f(p)$的情况。执行此类任务需要何种类型的计算设备？请注意，由于$r_1(p)$在p中是二次的，由迭代(9.1)产生的所有速率函数r_t都是有理函数（多项式的比值），如图9.2所示收敛到二元熵函数。事实证明，对于任何满足在$(0,1)$上$0 < f < 1$的有理函数f，我们可以使用以下任一有限内存方案从Ber(p)生成独立的Ber($f(p)$) [308]：

1 *Finite-state machine* (FSM)：初始状态（红色）、中间状态（白色）和最终状态（蓝色，输出 0 或 1 后重置为初始状态）。2 *Block simulation*：令 A_0, A_1 为 $\{0,1\}^k$ 的不相交子集。对于每个 k 位段，如果落入 A_0 则输出 0，如果落入 A_1 则输出 1。如果两者都不落入，则丢弃并移到下一个段。块大小至多为 f 的分母多项式的次数。

下表给出了可以用这两种架构实现的一些 f 示例。（练习：如何生成 $f(p) = 1/3$？）

事实证明，无论是使用FSM还是块模拟，唯一能够被模拟的f类型是理性函数。对于满足Keane-O'Brien表征的$f(p) = \sqrt{p}$，它无法通过FSM或块模拟来仿真，但可以通过所谓的下推自动机进行模拟，这是一种配备栈（无限内存）操作的FSM [308]。

目前尚不清楚如何找到具有最佳速率的最优伯努利工厂。显然，其逆命题是熵界$\frac{h(p)}{h(f(p))}$，这可能是平凡的（大于1）。

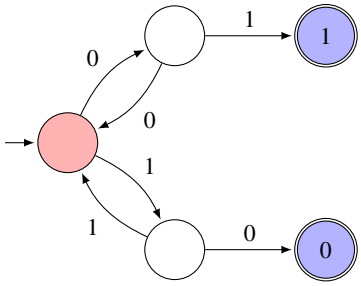
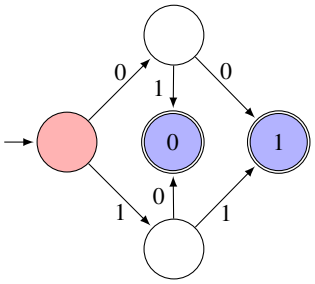
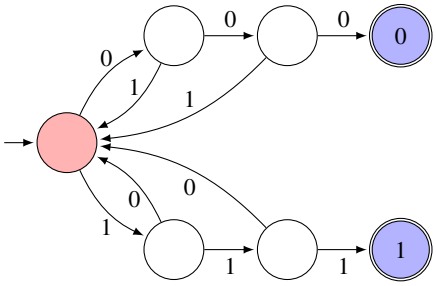
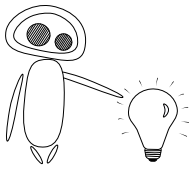
Goal	Block simulation	FSM
$f(p) = 1/2$	$A_0 = 10; A_1 = 01$	
$f(p) = 2pq$	$A_0 = 00, 11; A_1 = 01, 10$	
$f(p) = \frac{p^3}{p^3+\bar{p}^3}$	$A_0 = 000; A_1 = 111$	

表9.1 通过FSM或块模拟实现的伯努利工厂。

第一部分练习



I.1（熵的组合意义）

(a) 固定 $n \geq 1$ 和 $0 \leq k \leq n$。令 $p = \frac{k}{n}$，并定义 $T_p \subset \{0,1\}^n$ 为所有二进制序列的集合，其中 1 的比例为 p。证明如果 $k \in [1, n-1]$，则

$$\frac{\exp\{nh(p)\}}{\sqrt{8k(n-k)/n}} \leq |T_p| = \binom{n}{k} \leq \frac{\exp\{nh(p)\}}{\sqrt{2\pi k(n-k)/n}}\,. \tag{I.1}$$

其中 $h(\cdot)$ 是二元熵。得出结论：对于所有 $0 \leq k \leq n$，我们有

$$\log |T_p| = nh(p) + O(\log n)\,.$$

Hint: 斯特林近似：

$$e^{\frac{1}{12n+1}} \leq \frac{n!}{\sqrt{2\pi n}(n/e)^n} \leq e^{\frac{1}{12n}}, \quad n \geq 1 \tag{I.2}$$

() L 令 $Q^n = \mathrm{Ber}(q)^n$ 为 $\{0,1\}^n$ 上的独立同分布伯努利分布。证明

$$\log Q^n[T_p] = -nd(p\|q) + O(\log n)$$

(c*) 更一般地，设 $\mathcal{X}$ 为一个有限字母表，$\hat{P}, Q$ 为 $\mathcal{X}$ 上的分布，且 $T_{\hat{P}}$ 为 $\mathcal{X}^n$ 中所有具有组合 $\hat{P}$ 的字符串的集合。如果 $T_{\hat{P}}$ 非空（即，如果 $n\hat{P}(\cdot)$ 是整数），那么

$$\log |T_{\hat{P}}| = nH(\hat{P}) + O(\log n)$$
$$\log Q^n[T_{\hat{P}}] = -nD(\hat{P}\|Q) + O(\log n)$$

此外，两个 $O(\log n)$ 项都可以被界定为 $|O(\log n)| \leq |\mathcal{X}| \log(n+1)$。（提示：证明非空 T 的数量 $_P$ 是 $\leq (n+1)^{|\mathcal{X}|}$。）

I.2（精细类型方法）以下是对命题1.5的改进。设 $n_1, \ldots,$ 为非负整数，且 $\sum_i n_i = n$，令 k_+ 为非零 n_i 的数量。那么

$$\log \binom{n}{n_1, n_2, \ldots} = nH(\hat{P}) - \frac{k_+ - 1}{2}\log(2\pi n) - \frac{1}{2}\sum_{i:n_i>0}\log \hat{P}_i - C_{k_+}\,,$$

其中 $\hat{P}_i = \frac{n_i}{n}$ 和 $0 \leq C_{k_+} \leq \frac{\log e}{12}$。（提示：使用 (I.2)。）

I.3（条件熵与马尔可夫类型）

(a) 固定 $n \geq 1$，一个序列 $x^n \in \mathcal{X}^n$，并定义

$$N_{x^n}(a,b) = |\{(x_i, x_{i+1}) : x_i = a, x_{i+1} = b, i = 1, \ldots, n\}|\,,$$

其中我们定义 $x_{n+1} = x_1$ (循环延拓)。证明 $\frac{1}{n}N_{x^n}(\cdot,\cdot)$ 定义了 $\mathcal{X}\times\mathcal{X}$ 上的一个概率分布 $P_{A,B}$，且边缘分布 $P_A = P_B$ 相等。由此得出结论 $H(A|B) = H(B|A)$。那么，$P_{A|B} = P_{B|A}$ 是否成立?

(b) 令 $T^{(2)}_{x^n}$ (Markov 类型类 x^n) 定义为

$$T^{(2)}_{x^n} = \{\tilde{x}^n \in \mathcal{X}^n : N_{\tilde{x}^n} = N_{x^n}\}\,.$$

证明 $T^{(2)}_{x^n}$ 的元素可以与 $\mathcal{X}$ 上的完全有向图 G 中的环路相对应，使得对于每个 $(a,b) \in \mathcal{X}\times\mathcal{X}$，该环路经过边 (a,b) $N_{x^n}(a,b)$ 次。

(c) 证明每个这样的循环可以通过确定第一个节点以及在图的每个顶点选择出边的顺序来唯一指定。根据这一点以及斯特林近似，得出结论:

$$\log|T^{(2)}_{x^n}| = nH(x_{T+1}|x_T) + O(\log n)\,, \qquad T \sim \mathrm{Unif}([n])\,.$$

检查 $H(x_{T+1}|x_T) = H(A|B) = H(B|A)$。

(d) 证明对于任何时间齐次马尔可夫链 X^n，当 $P_{X_1,X_2}(a_1,a_2) > 0\ \forall a_1,a_2 \in \mathcal{X}$ 时，我们有

$$\log P_{X^n}(X^n \in T^{(2)}_{x^n}) = -nD(P_{B|A}\|P_{X_2|X_1}|P_A) + O(\log n)\,.$$

I.4（最大熵）证明对于任意在$\mathbb{N} = \{1,2,\ldots\}$上取值的$X$，使得$\mathbb{E}[X] < \infty$，

$$H(X) \le \mathbb{E}[X]h\left(\frac{1}{\mathbb{E}[X]}\right),$$

由几何分布唯一最大化。*Hint*：找到合适的Q，使得RHS - LHS = $D(P_X\|Q)$。

I.5（熵的有限性）在练习I.4中，我们已经证明了任何具有有限期望的$\mathbb{N}$值随机变量的熵是有限的。接下来，让我们改进这一结果。

(a) 证明 $\mathbb{E}[\log X] < \infty \Rightarrow H(X) < \infty$。此外，通过给出一个反例说明 X 取整数值的条件并非多余。(b) 证明如果 $k \mapsto P_X(k)$ 是一个递减序列，则 $H(X) < \infty \Rightarrow \mathbb{E}[\log X] < \infty$。此外，通过给出一个反例说明单调性假设并非多余。

I.6（最大熵的稳健版本）在所有支撑于$[-b,b]$上的密度中，最大微分熵由均匀分布达到。证明当$\epsilon \to 0+$时，我们有

$$\sup\{h(M+Z) : M \in [-b,b], \mathbb{E}[Z] = 0, \mathrm{Var}[Z] \le \epsilon\} = \log(2b) + o(1)\,.$$

其中上确界取遍所有（不一定独立的）随机变量 M、Z，使得 $M+Z$ 具有密度。（提示：[162，附录 C] 证明了 $o(1) = O(\epsilon^{1/3}\log\frac{1}{\epsilon})$ 界。）I.7（Hamming 重量约束下的最大熵）对于任意 $\alpha \le 1/2$ 和 $d \in \mathbb{N}$,

$$\max\{H(Y) : Y \in \{0,1\}^d, \mathbb{E}[w_{\mathrm{H}}(Y)] \le \alpha d\} = dh(\alpha),$$

通过乘积分布 $Y \sim \mathrm{Ber}(\alpha)^{\otimes d}$ 实现。*Hint*：找到一个合适的 Q，使得 RHS - LHS $= D(P_Y \| Q)$。

I.8（高斯散度）

(a) 关于 $\mathrm{m}_0, \Sigma_0, \mathrm{m}_1, \Sigma_1$ 在什么条件下有 $D(\mathcal{N}(\mathrm{m}_1, \Sigma_1) \,\|\, \mathcal{N}(\mathrm{m}_0, \Sigma_0)) < \infty$？ (b) 计算 $D(\mathcal{N}(\mathrm{m}, \Sigma) \| \mathcal{N}(0, I_n))$，其中 I_n 是 $n \times n$ 单位矩阵。 (c) 对于非奇异的 Σ_0，计算 $D(\mathcal{N}(\mathrm{m}_1, \Sigma_1) \,\|\, \mathcal{N}(\mathrm{m}_0, \Sigma_0))$。（提示：思考高斯分布在平移 $\mathrm{x} \mapsto \mathrm{x}+\mathrm{a}$ 和非奇异线性变换 $\mathrm{x} \mapsto \mathrm{A}\,\mathrm{x}$ 下如何变化。应用数据处理以减少到前一种情况。）

I.9（注水解法）设 {v*} 为一个固定矩阵，$X \perp\!\!\!\perp Z \sim \mathcal{N}(0, I_n)$。

(a) 设 $M = U\Lambda V^T$ 为奇异值分解，因此 U, V 是正交矩阵，而 $\Lambda =$ 是对角矩阵 diag($\lambda_1, \ldots, \lambda_n$)（其中 rank($M$) 非零的 λ_j）。证明

$$\max_{P_X : \mathbb{E}[\|X\|^2] \le s^2} I(X; MX + Z) = \max_{P_X : \mathbb{E}[\|X\|^2] \le s^2} I(X; \Lambda X + Z)\,.$$

(b) 得出结论

$$\max_{P_X : \mathbb{E}[\|X\|^2] \le s^2} I(X; MX + Z) = \frac{1}{2} \sum_{i=1}^{n} \log^+(\lambda_i^2 t)\,,$$

其中 $\log^+ x = \max(0, \log x)$ 且 t 由求解 $\sum_{i=1}^n |t - \lambda_i^{-2}|_+ = s^2$ 确定。
X 沿 M 的奇异向量的这种能量分布称为 *water-filling solution*，见第 20.4 节。

I.10（MIMO容量）令$M \in \mathbb{R}^{k \times n}$为一个*random, orthogonally invariant*矩阵（即对于任意正交矩阵U，$M \overset{(d)}{=} MU$）。令$X \perp\!\!\!\perp (Z, M)$和$Z \sim \mathcal{N}(0, I_n)$。证明

$$\max_{P_X : \mathbb{E}[\|X\|^2] \le s^2} I(X; MX + Z | M) = \frac{1}{2}\,\mathbb{E}\left[\log\det(I + \frac{s^2}{n} M^T M)\right] = \frac{1}{2} \sum_{i=1}^{n} \mathbb{E}\left[\log(1 + \frac{s^2}{n}\sigma_i^2(M))\right],$$

其中$\sigma_i(M)$是M的奇异值。（提示：按第6.2*节中的方式对旋转求平均）
Note: 在通信理论中，$M_{i,j} \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0, 1)$ (Ginibre 系综) 模拟了一个具有 n 个发射天线和 k 个接收天线的多输入多输出（MIMO）信道。矩阵 MM^T 是一个 Wishart 矩阵，当 n 和 k 成比例增长时，其谱趋近于 Marchenko-Pastur 分布。重要的实际推论是，MIMO 信道的容量在高信噪比下以 $\frac{1}{2}\min(n, k)$ log SNR 增长。这一著名观察 [418] 正是现代 WiFi 和蜂窝系统采用多天线的原因。

I.11（条件容量）考虑一个马尔可夫核 $P_{B,C|A}$：$\mathcal{A} \to \mathcal{B} \times \mathcal{C}$，我们也将把它理解为一组分布 $P_{B,C}^{(a)} \triangleq P_{B,C|A=a}$。证明

$$\inf_{Q_{C|B}} \sup_{a \in \mathcal{A}} D(P_{C|B}^{(a)} \| Q_{C|B} | P_B^{(a)}) = \sup_{P_A} I(A; C|B)\,,$$

当右侧的上确界是有限的且能被某个分布P_A^*达到时。在这种情况下，最优的 $Q_{C|B} = P_{C|B}^*$通过分解$P_{B,C}^* = \int P_{A^*}(da) P_{B,C}^{(a)}$找到。（*Hint:*遵循(5.1)的步骤。）

I.12 在 $X = x$ 的条件下，设 Y 为均值为 x 的泊松分布，即，

$$P_{Y|X}(k|x) = e^{-x}\frac{x^k}{k!}, \quad k = 0, 1, 2, \ldots$$

令 X 为单位均值的指数随机变量。求 $I(X; Y)$。

I.13（擦除中丢失的信息）设 X, Y 为一对随机变量，具有 $I(X; Y) < \infty$。设 Z 由 Y 通过擦除信道传递后者而得到，即 $X \to Y \to Z$，其中

$$P_{Z|Y}(z|y) = \begin{cases} 1-\delta, & z = y, \\ \delta, & z = ? \end{cases}$$

其中 ? 是 Y 字母表中没有的符号。求 $I(X; Z)$。

I.14（信息瓶颈）设 $X \to Y \to Z$，其中 Y 是在有限集合 $\mathcal{Y}$ 上取值的离散随机变量。证明

$$I(X; Z) \le \log |\mathcal{Y}|.$$

I.15 *Hewitt-Savage 0-1 law*指出某些对称事件没有随机性。 设$\{X_i\}_{i\ge 1}$为一个独立同分布随机变量序列。 设E为由该序列确定的事件。 若E在$\{X_i\}$序列的有限多个下标置换下保持不变，则称其为可交换的，例如，若我们置换（X_1, X_4, X_7）的值，E的发生不变，等等。

让我们通过以下步骤，从信息论的角度证明休伊特-萨维奇0-1定律：

(a)（预热）验证 $E = \{\sum_{i\ge 1} X_i$ 收敛于 $\}$ 且 $E = \{\lim_{n\to\infty} \frac{1}{n}\sum_{i=1}^n X_i = \mathbb{E}[X_1]\}$ 是可交换事件。

(b) 令 E 为一可交换事件，且 $W = 1_E$ 为其示性随机变量。证明对于任意 k，$I(W; X_1, \ldots, X_k) = 0$。（提示：利用张量化 (6.2) 证明对于任意 n，$nI(W; X_1, \ldots, X_k) \le 1$ `bit`。）

(c) 由于 E 由序列 $\{X_i\}_{i\ge 1}$ 决定，根据互信息的连续性，我们有：

$$H(W) = I(W; X_1, \ldots) = \lim_{k\to\infty} I(W; X_1, \ldots, X_k) = 0.$$

得出结论：E 没有随机性，即 $P(E) =$ 为 0 或 $P(E) =$ 为 1。

(d)（应用于随机游走）在应用Hewitt-Savage之后，通常需要进一步努力来确定概率是0还是1。例如，考虑X_i是独立同分布的± 1，且$S_n = \sum_{i=1}^n X_i$表示对称随机游走。验证事件$E = \{S_n = 0$ 有限次$\}$是可交换的。现在证明$P(E) = 0$。

（提示：考虑 $E^+ = \{S_n >$ 最终为 $0\}$，以及类似地 E^-。对它们应用 Hewitt-Savage 定理并利用对称性。）

I.16 设 (X, Y) 在单位 ℓ_p-球 $B_p \triangleq \{(x, y)$ 中均匀分布：$|x|^p + |y|^p \le 1\}$，其中 $p \in (0, \infty)$。同时定义 ℓ_∞-球 $B_\infty \triangleq \{(x, y)$：$|x| \le 1, |y| \le 1\}$。

(a) 计算 $I(X;$ 对于 $p = 1/2$、$p = 1$ 和 $p = \infty$，$Y)$。

(b*) 确定 $I(X$ 的极限；当 $p \to$ 趋近于 0 时，$Y)$。

I.17 假设 $Z_1, \ldots Z_n$ 是均值为 λ 的独立泊松随机变量。证明 $\sum_{i=1}^n Z_i$ 是 $(Z_1, \ldots Z_n)$ 对于 λ 的充分统计量。

I.18 假设$Z_1, \ldots Z_n$在区间$[0, \lambda]$上独立均匀分布。证明$\max_{1\le i\le n} Z_i$是$(Z_1, \ldots Z_n)$关于λ的充分统计量。

I.19（顺序统计量的散度）给定 $x^n = (x_1, \ldots, x_n) \in \mathbb{R}^n$，令 $x_{(1)} \le \ldots \le x_{(n)}$ 表示有序条目。设 P, Q 为 $\mathbb{R}$ 和 $P_{X^n} = P^n, Q_{X^n} = Q^n$ 上的分布。

(a) 证明

$$D(P_{X_{(1)},\ldots,X_{(n)}} \| Q_{X_{(1)},\ldots,X_{(n)}}) = nD(P\|Q). \tag{I.3}$$

(b) 证明

$$D(\mathrm{Bin}(n,p)\|\mathrm{Bin}(n,q)) = nd(p\|q).$$

I.20（有限字母表上熵的连续性）我们已经证明，在有限字母表上，熵是分布的连续函数。通过明确展示以下内容来量化这种连续性：

$$|H(P) - H(Q)| \le h(\mathrm{TV}(P,Q)) + \mathrm{TV}(P,Q)\log(|\mathcal{X}| - 1)$$

对于任何在 $\mathcal{X}$ 上支持的 P 和 Q。

Hint: 使用Fano不等式及定理7.7(a)中全变差的下确界表示（通过耦合）。

I.21 (a) 对于任意满足 $\mathbb{E}[|X|] < \infty$ 的 X，证明

$$D(P_X\|\mathcal{N}(0,1)) \ge \frac{(\mathbb{E}[X])^2}{2} \quad \texttt{nats}.$$

(b) 对于 $a > 0$，求最小值和最小值点：

$$\min_{P_X:\mathbb{E}X\ge a} D(P_X\|\mathcal{N}(0,1)).$$

最小值点唯一吗？为什么？

I.22 假设 {v*} 然后证明

$$\frac{d}{d\lambda}\Big|_{\lambda=0} D(\lambda P_1 + \bar{\lambda}Q\|\lambda P_0 + \bar{\lambda}Q) = 0\,.$$

这扩展了命题2.20。

I.23（度量熵与容量）设 $\{P_{Y|X=x}\colon\ x \in \mathcal{X}\}$ 为一组分布，并设 $C = \sup_{P_X} I(X;\ Y)$ 为其容量。对于每个 $\epsilon \ge 0$，定义[1]

$$N(\epsilon) = \min\{k : \exists Q_1 \ldots Q_k : \forall x \in \mathcal{X}, \min_j D(P_{Y|X=x}\|Q_j) \le \epsilon^2\}\,. \tag{I.4}$$

(a) 证明

$$C = \inf_{\epsilon\ge 0}\left(\epsilon^2 + \log N(\epsilon)\right)\,. \tag{I.5}$$

1 $N(\epsilon)$是覆盖集合$\{P_{Y|X=x}\colon\ x \in \mathcal{X}\}$的半径-$\epsilon$ (发散)球的最小数量。因此，对数$N(\epsilon)$是一个度量熵 – 见第27章。

(提示：$N(\epsilon)$ =何时为1？参见定理32.4。)

(b) 类似地，显示

$$I(X;Y) = \inf_{\epsilon \geq 0} \left(\epsilon + \log N(\epsilon; P_X)\right) ,$$

其中平均情况覆盖数为

$$N(\epsilon; P_X) = \min\{k : \exists Q_1 \dots Q_k : \mathbb{E}_{x\sim P_X}[\min_j D(P_{Y|X=x}\|Q_j)] \leq \epsilon\} \tag{I.6}$$

Comments: 这些估计是有用的，因为对于小的 ϵ，$N(\epsilon)$ 大致上依赖于映射 $x \mapsto P_{Y|X=x}$ 的局部（微分）性质，这与全局性的 C 不同。

I.24 考虑信道 $P_{Y^m|X} : [0,1] \mapsto \{0,1\}^m$，其中给定 $x \in [0,1]$，Y^m 是独立同分布的伯努利分布(x)。

(a) 使用习题I.23的上界证明

$$C(m) \triangleq \max_{P_X} I(X;Y^m) \leq \frac{1}{2}\log m + O(1) , \qquad m \to \infty .$$

Hint: 找到输入空间的一个覆盖。

(b) 展示一个下界以确立

$$C(m) \geq \frac{1}{2}\log m + o(\log m) , \qquad m \to \infty .$$

Hint: 证明对于任意 $\epsilon > 0$，存在 $K(\epsilon)$，使得对于所有 $m \geq 1$ 及所有 $p \in [\epsilon, 1-\epsilon]$，有 $|H(\mathrm{Bin}(m,p)) - \frac{1}{2}\log m| \leq K(\epsilon)$。

I.25 本练习展示了证明Fano不等式各种形式的一些其他方法。

(a) 证明(3.15)如下。给定任意 $P = (P_{\max}, P_2, \dots, P_M)$，对最后 $M-$ 个1原子施加随机置换 π，得到分布 P_π。通过比较 $H(P)$ 和 $H(Q)$，其中 Q 是 P_π 对所有置换的平均值，完成证明。

(b) 通过直接求解凸优化 $\max\{H(P) : 0 \leq p_i \leq P_{\max}, i = 1, \dots, M, \sum_i p_i = 1\}$ 来证明 (3.15)。

(c) 证明(3.19)如下。设$P_e = \mathbb{P}[X \neq \hat{X}]$。首先证明

$$I(X;Y) \geq I(X;\hat{X}) \geq \min_{P_{Z|X}} \{I(P_X, P_{Z|X}) : \mathbb{P}[X = Z] \geq 1 - P_e\}.$$

注意，除非 $P_e = P_{max}$，否则最小值非零。其次，解决所述的凸优化问题。（提示：寻找矩阵 $P_{Z|X}$ 在排列下必须满足的不变量（X, Z）$\mapsto (\pi(X), \pi(Z))$，然后应用 $I(P_X, \cdot)$ 的凸性）。

I.26 证明 $P_{Y_1 \dots Y_n|X_1 \dots X_n} = \prod_{i=1}^n P_{Y_i|X_i}$ 当且仅当马尔可夫链 $Y_i \to X_i \to (X_{\setminus i}, Y_{\setminus i})$ 对所有 $i = 1, \dots, n$ 成立，其中 $X_{\setminus i} = \{X_j, j \neq i\}$。

I.27（分布与图模型）

(a) 画出所有与 $X, Y, Z \in \{0,1\}$ 上以下分布兼容的有向无环图（DAG，或有向图模型）：

$$P_{X,Z}(x,z) = \begin{cases} 1/6, & x = 0, z \in \{0,1\} , \\ 1/3, & x = 1, z \in \{0,1\} \end{cases} \tag{I.7}$$

$$Y = X + Z \qquad (\mathrm{mod}2) \tag{I.8}$$

你可以只包含最小DAGs（回忆：对于给定分布，如果在移除任何边后导致图形模型与该分布不兼容，则该DAG是最小的）。[2]

(b) 绘制描述满足 $P_{Y^n|X^n} = \prod_{i=1}^n P_{Y_i|X_i}$ 的分布集 $P_{X^nY^n}$ 的 DAG。
(c) 回顾一下，如果两个有向无环图 G_1 和 G_2 具有相同的顶点集，并且每个分布关于 G_1 分解当且仅当它关于 G_2 分解，那么这两个图被称为等价的。例如，众所周知

$$X \to Y \to Z \quad \iff \quad X \leftarrow Y \leftarrow Z \quad \iff \quad X \leftarrow Y \to Z .$$

考虑以下两个具有可数多个顶点的DAG：

$$X_1 \to X_2 \to \cdots \to X_n \to \cdots$$
$$X_1 \leftarrow X_2 \leftarrow \cdots \leftarrow X_n \leftarrow \cdots$$

它们等价吗?

I.28 给出联合高斯(A, B, C)中$A \to B \to C$基于相关系数的充要条件。对于离散(A, B, C)，记 $x_{abc} = P_{ABC}(a, b, c)$，并将马尔可夫链条件写成$\{x_{abc}, a \in \mathcal{A}, b \in \mathcal{B}, c \in \mathcal{C}\}$中的一系列二次多项式方程。

I.29 设 A, B, C 为离散的，其中 $P_{C|B}(c|b) > 0 \; \forall b, c$。

(a) 显示

$$\begin{array}{l} A \to B \to C \\ A \to C \to B \end{array} \quad \Longrightarrow A \perp\!\!\!\perp (B, C)$$

讨论对充分统计量的影响。

(b*) 对于二进制(A, B, C)，刻画所有反例。

Comment: 因此，一个流行的非负性条件 $P_{A,B,C} > 0$ 允许推断条件独立关系，而这些关系在一般情况下并不成立。换句话说，满足某些（条件）独立关系的一组分布与其与 $\{P_{A,B,C} > 0\}$ 的交集的闭包并不一致，更多内容见 [366]。

I.30 考虑蕴含式

$$I(A; C) = I(B; C) = 0 \quad \Longrightarrow \quad I(A, B; C) = 0 . \tag{I.9}$$

(a) 针对联合高斯分布 (A, B, C) 展示 (I.9)。
(b) 寻找一般情形(A, B, C)的反例。(c) 证明或反驳：在正值条件 $P_{A,B,C}(a, b, c) > 0$ $\forall a, b, c$ 下，(I.9) 对于任意有限基数离散(A, B, C)也成立。

[2] Note: $\{X \to Y\}$, $\{X \leftarrow Y\}$ and $\{X \quad Y\}$ are the three possible directed graphical modelss for two random variables. For example, the third graph describes the set of distributions for which X and Y are independent: $P_{XY} = P_X P_Y$. In fact, $P_X P_Y$ factorizes according to any of the three DAGs, but $\{X \quad Y\}$ is the unique minimal DAG.

I.31 求具有转移概率矩阵的平稳遍历马尔可夫链的熵率

$$\mathbf{P} = \begin{bmatrix} \frac{1}{2} & \frac{1}{4} & \frac{1}{4} \\ 0 & \frac{1}{2} & \frac{1}{2} \\ 1 & 0 & 0 \end{bmatrix}$$

I.32（可解 HMM）与 Gilbert-Elliott 过程（例 6.3）类似，令 $S_j \in \{\pm 1\}$ 为一个平稳的两状态马尔可夫链，其 $\mathbb{P}[S_j = -S_{j-1}|S_{j-1}] = 1 - \mathbb{P}[S_j = S_{j-1}|S_{j-1}] = \tau$。令 $E_j \overset{iid}{\sim} \text{Ber}(\delta)$，其中 $E_j \in \{0, 1\}$，并令 $X_j = \text{BEC}_\delta(S_j)$ 为 S_j 通过具有擦除概率 δ 的二元擦除信道（BEC）的观测，即 $X_j = S_j E_j$。求 X_j (的熵率

I.33 考虑一个从零开始的在 $\mathbb{Z}$ 上的二进制对称随机游走 X_n。换句话说，$X_n = \sum_{j=1}^n B_j$，其中 $(B_1, B_2, \ldots)$ 是独立的，并且等概率地为 ± 1。

(a) 当 $n \gg$ 为1时　　了解X_{2n}是否提供有关X_n的任何信息？更确切地说　　y，证明

$$\liminf_{n\to\infty} I(X_n; X_{2n}) > 0.$$

(提示：下半连续性与中心极限定理)

(计算该极限 $\lim_{n\to\infty} I(X_n$ 的精确值；$X_{2n})$。

I.34（熵率与邻接性）定理2.2指出，若有限字母表$\mathcal{X}$上的分布几乎均匀，则其熵必须接近于 $\log|\mathcal{X}|$。本题将此观察扩展至随机过程。

(a) 令 Q_n 为 $\mathcal{X}^n$ 上的均匀分布。证明：若 $\{P_n\} \lhd \{Q_n\}$ (参见定义 7.9)，则 $H(P_n) = H(Q_n) + o(n) = n\log|\mathcal{X}| + o(n)$，或等价地，$D(P_n\|Q_n) = o(n)$。(b) 证明对于非均匀的 Q_n，$P_n \lhd\rhd Q_n$ 不蕴含 $H(P_n) = H(Q_n) + o(n)$。（提示：作为反例，考虑例 6.2(b) 中的混合源。）

I.35 设 $I_{\text{TV}}(X;\ Y) = \text{TV}(P_{X,Y}, P_X P_Y)$。设 $X \sim \text{Ber}(1/2)$ 并且在给定 X 的条件下，独立生成 A 和 B，分别以概率 $1-\delta$ 和 δ 将它们设为 X 或 $1-X$（即 $A \leftarrow X \rightarrow B$）。证明

$$I_{\text{TV}}(X; A, B) = I_{\text{TV}}(X; A) = |\frac{1}{2} - \delta|\,.$$

这意味着对X的第二次观测是“无信息量”的（在I_{TV}意义上）。

同样地，证明当$X \sim \text{Ber}(\delta)$对于$\delta < 1/2$存在联合分布$P_{X,Y}$，使得$\text{TV}(P_{Y|X=0}, P_{Y|X=1}) > 0$（因此$I_{\text{TV}}(X;\ Y)$和$I(X;\ Y)$严格为正），但同时$\min_{\hat{X}(Y)} \mathbb{P}[X \neq \hat{X}] = \delta$。换言之，观测$Y$对$X$具有信息性，但并未改善错误概率。

Note: 这种效应是羊群效应中一个有趣经济效应的基础[30]。

I.36 证明全变差的以下变分表示：

$$\text{TV}(P_0, P_1) = \frac{1}{2}\inf_Q \sqrt{\int dQ \left(\frac{d(P_0 - P_1)}{dQ}\right)^2}. \tag{I.10}$$

I.37 证明映射 $P \mapsto D(P\|Q)$ 是强凸的，即对于所有 $\lambda \in [0,1]$ 和所有 P_0, P_1, Q，我们有

$$\lambda D(P_1\|Q) + \bar{\lambda} D(P_0\|Q) - D(\lambda P_1 + \bar{\lambda} P_0\|Q) \geq 2\lambda\bar{\lambda}\mathrm{TV}(P_0, P_1)^2 \log e\,.$$

(提示：将 LHS 写为 $I(X;\ Y)$ 对于 $X \sim \mathrm{Ber}(\lambda)$) 用 Y)，并应用 Pinsker's。

I.38（Rényi 散度与 Blackwell 序）设 $p_\epsilon = \frac{e^\epsilon}{1+e^\epsilon}$。证明对于所有 $\epsilon > 0$ 和所有 $\alpha > 0$，我们有

$$D_\alpha(\mathrm{Ber}(p_\epsilon)\|\mathrm{Ber}(1-p_\epsilon)) < D_\alpha(\mathcal{N}(\epsilon,1)\|\mathcal{N}(0,1))\,.$$

然而，对于足够小的 ϵ，我们有

$$\mathrm{TV}(\mathrm{Ber}(p_\epsilon), \mathrm{Ber}(1-p_\epsilon)) > \mathrm{TV}(\mathcal{N}(\epsilon,1), \mathcal{N}(0,1))\,.$$

Note: 这表明，在所有Rényi散度下的支配关系并不意味着在其他f散度中有类似的比较[132]。另一方面，我们有以下等价关系[310]:

$$\begin{aligned} &\forall \alpha > 0 : D_\alpha(P_1\|P_0) \leq D_\alpha(Q_1\|Q_0) \\ \iff \quad &\exists n_0 \forall n \geq n_0 \forall f : D_f(P_1^{\otimes n}\|P_0^{\otimes n}) \leq D_f(Q_1^{\otimes n}\|Q_0^{\otimes n})\,. \end{aligned}$$

(后者也等价于存在一个核 K_n，使得 $K_n \circ P_i^{\otimes n} = Q_i^{\otimes n}$ – 这被称为测度对之间的布莱克威尔序，也称为信道退化)。

I.39（Rényi散度作为KL [383]）对于所有 $\alpha \in \mathbb{R}$ 展示:

$$(1-\alpha)D_\alpha(P\|Q) = \inf_R \left(\alpha D(R\|P) + (1-\alpha)D(R\|Q)\right)\,. \tag{I.11}$$

当左边有限时，推导出唯一极小值点 R 的显式形式。

I.40 对于 f-散度，考虑以下陈述:

(i) 如果 $I_f(X;\ Y) = 0$，则 $X \perp\!\!\!\perp Y$。(ii) 如果 $X - Y - Z$ 且 $I_f(X;\ Y) = I_f(X;\ Z) < \infty$，则 $X - Z - Y$。

回想一下，$f\colon (0,\infty) \to \mathbb{R}$ 是一个凸函数，且 $f(1) = 0$。

(a) 选择一个不是KL散度倍数的f散度（即f不能形如$c_1 x\log x + c_2(x-1)$对任何 $c_1, c_2 \in \mathbb{R}$）。证明I_f的两个陈述。

(b) 选择一个非线性的 f-散度（即，f 不能对任何 $c \in \mathbb{R}$ 表现为 $c(x-1)$ 的形式）并提供违反 (i) 和 (ii) 的例子。

(c) 选择一个f散度。证明(i)成立，并给出一个违反(ii)的例子。

I.41（Hellinger 与交互式协议 [31]）在交互式通信领域，Alice 可以访问 X 并输出比特 $A_i, i \geq 1$，而 Bob 可以访问 Y 并输出比特 $B_i, i \geq 1$。通信按轮次进行，因此在第 i 轮时，Alice 和 Bob 可以看到彼此先前的消息。这意味着 *protocol* 的条件分布由下式给出

$$P_{A^n,B^n|X,Y} = \prod_{i=1}^n P_{A_i|A^{i-1},B^{i-1},X} P_{B_i|A^{i-1},B^{i-1},Y}\,.$$

为方便起见，记$\Pi_{x,y} \triangleq P_{A^n,B^n|X=x,Y=y}$。证明

（a）（剪切粘贴引理）$H^2(\Pi_{x,y}, \Pi_{x',y'}) = H^2(\Pi_{x,y'}, \Pi_{x',y})$。是否有其他具有该性质的 f- 散度?

(b) $H^2(\Pi_{x,y},\Pi_{x',y})+H^2(\Pi_{x,y'},\Pi_{x',y'})\le 2H^2(\Pi_{x,y},\Pi_{x',y'})$

I.42（链式法则 I）

(a) 使用(I.11)和KL的链式法则证明

$$(1-\alpha)D_\alpha(P_{X^n}\|Q_{X^n})\ge\sum_{i=1}^n\inf_a(1-\alpha)D_\alpha(P_{X_i|X^{i-1}=a}\|Q_{X_i|X^{i-1}=a})$$

(b) 推导两个特殊情况：

$$1-\frac{1}{2}H^2(P_{X^n},Q_{X^n})\le\prod_{i=1}^n\sup_a(1-\frac{1}{2}H^2(P_{X_i|X^{i-1}=a},Q_{X_i|X^{i-1}=a}))$$

$$1+\chi^2(P_{X^n}\|Q_{X^n})\le\prod_{i=1}^n\sup_a(1+\chi^2(P_{X_i|X^{i-1}=a}\|Q_{X_i|X^{i-1}=a}))$$

I.43（链式法则 II）

(a) 证明散度的链式法则可以重述为 当

$$D(P_{X^n}\|Q_{X^n})=\sum_{i=1}^n D(P_i\|P_{i-1}),$$

其中 $P_i=P_{X^i}Q_{X_{i+1}^n|X^i}$，具有 $P_n=P_{X^n}$ 和 $P_0=Q_{X^n}$。上述恒等式展示了如何通过求和中间 P_i 之间的距离来遍历从 P_{X^n} 到 Q_{X^n} 的 KL 距离。

(b) 使用相同的路径和三角不等式证明

$$\mathrm{TV}(P_{X^n},Q_{X^n})\le\sum_{i=1}^n\mathbb{E}_{P_{X^{i-1}}}\mathrm{TV}(P_{X_i|X^{i-1}},Q_{X_i|X^{i-1}})$$

(c) 类似地，对于 Hellinger 距离 H:

$$H(P_{X^n},Q_{X^n})\le\sum_{i=1}^n\sqrt{\mathbb{E}_{P_{X^{i-1}}}H^2(P_{X_i|X^{i-1}},Q_{X_i|X^{i-1}})}$$

另见[230，定理7]以获取更深入的结果，其中对于通用$C>0$，证明了

$$H^2(P_{X^n},Q_{X^n})\le C\sum_{i=1}^n\mathbb{E}_{P_{X^{i-1}}}H^2(P_{X_i|X^{i-1}},Q_{X_i|X^{i-1}})\,.$$

I.44 (a) 定义 *Marton's divergence*

$$D_m(P\|Q)=\int dQ\left(1-\frac{dP}{dQ}\right)_+^2.$$

证明

$$D_m(P\|Q)=\inf_{P_{XY}}\{\mathbb{E}[P[X\ne Y|Y]^2]:P_X=P,P_Y=Q\}$$

其中下确界取遍所有耦合。（提示：对于一个方向，使用实现TV的相同耦合。对于另一个方向，注意 $\mathbb{P}[X\ne Y|Y]\ge 1-\frac{P(Y)}{Q(Y)}$。）

(b) 定义 *symmetrized Marton's divergence*

$$D_{sm}(P\|Q) = D_m(P\|Q) + D_m(Q\|P).$$

证明

$$D_{sm}(P\|Q) = \inf_{P_{XY}}\{\mathbb{E}[\mathbb{P}^2[X \neq Y|Y]] + \mathbb{E}[\mathbb{P}^2[X \neq Y|X]] : P_X = P, P_Y = Q\}.$$

I.45（f-散度下的重心）回顾推论4.2中的事实：$\min_{Q_Y} D(P_{Y|X}\|Q_Y|P_X) = I(X;\ Y)$在$Q_Y = P_Y$处达到。证明其他$f$-散度的以下版本：

(a) 假设对于 P_X-几乎处处 x，$P_{Y|X=x} \ll \mu$ 具有密度 $p(y|x)$。[3] 那么

$$\inf_{Q_Y} \chi^2(P_{Y|X}\|Q_Y|P_X) = \left(\int \mu(dy)\sqrt{\mathbb{E}[p_{Y|X}(y|X)^2]}\right)^2 - 1. \tag{I.12}$$

如果右侧是有限的，则最小值在$Q_Y(dy) \propto \sqrt{\mathbb{E}[p(y|X)^2]}\mu(dy)$处达到。(b) 证明

$$\inf_{Q_Y} \chi^2(Q_Y\|P_{Y|X}|P_X) = \left(\int \mu(dy)\frac{1}{g(y)}\right)^{-1} - 1\,, \tag{I.13}$$

其中 $g(y) \triangleq \mathbb{E}[p_{Y|X}(y|X)^{-1}]$，并且对于所有倒数我们使用约定 $1/0 = \infty$。如果右-左侧是有限的，则最小值由 $Q_Y(dy) \propto \frac{1}{g(y)}1\{g(y) < \infty\}\mu(dy)$ 取得。(c) 证明

$$\inf_{Q_Y} D(Q_Y\|P_{Y|X}|P_X) = -\log \int \mu(dy)\exp(\mathbb{E}[\log p(y|X)]). \tag{I.14}$$

如果右侧有限，最小值在 $Q_Y(dy) \propto \exp(\mathbb{E}[\log p(y|X)])\mu(dy)$ 处取得。*Note*：此练习表明，相对于其他 f-散度的重心不必是 P_Y，而是其重加权版本。对于统计应用，参见练习 VI.6、VI.9 和 VI.10，其中 (I.12) 和 (I.13) 用于确定贝叶斯估计量的形式。

I.46（Fisher信息的DPI）令$p_\theta(x,y)$为$\mathcal{X} \otimes \mathcal{Y}$ (上关于某参考测度$\mu_X \otimes \mu_Y$)的光滑参数化密度族，其中$\theta \in \mathbb{R}^d$。令$J_F^{X,Y}(\theta)$表示联合分布的Fisher信息矩阵，类似地，$J_F^X(\theta), J_F^Y(\theta)$表示边缘分布的Fisher信息矩阵。

(a)（单调性）假设导数与积分可交换，即对于每个 θ, y，$\nabla_\theta p_\theta(y) = \int \mu_X(dx)\nabla_\theta p_\theta(x,y)$。证明 $J_F^Y(\theta) \preceq J_F^{X,Y}(\theta)$。
(b)（数据处理不等式）假设另外有$\theta \to X \to Y$。（换言之，$p_\theta(y|x)$不依赖于θ。）那么 $J_F^Y(\theta) \preceq J_F^X(\theta)$，当$Y$是$X$对$\theta$的充分统计量时取等号。

[3] Note that the results do not depend on the choice of μ, so we can take for example $\mu = P_Y$, in view of Lemma 3.3.

I.47（Fisher信息不等式）考虑具有可微密度和有限（位置）Fisher信息$J(A)$、$J(B)$的实值$A \perp\!\!\!\perp B$。则Stam不等式[399]表明

$$\frac{1}{J(A+B)} \geq \frac{1}{J(A)} + \frac{1}{J(B)}\,. \tag{I.15}$$

(a) 证明 Stamm 不等式等价于 $(a+b)^2 J(A+B) \leq a^2 J(A) + b^2 J(B)$ 对所有 $a, b > 0$ 成立。(b) 令 $X_1 = a\theta + A$, $X_2 = b\theta + B$。这定义了 (X_1, X_2) 的一个分布族，由 $\theta \in \mathbb{R}$ 参数化。证明其 Fisher 信息由 $J_F(\theta) = a^2 J(A) + b^2 J(B)$ 给出。(c) 令 $Y = X_1 + X_2$ 并假设 Fisher 信息的 DPI 适用条件（练习 I.46）成立。完成 (I.15) 的证明。

注意：一个简单的充分条件蕴含（I.15），即A和B的密度在$\mathbb{R}$上处处严格为正。对于这种情况的直接证明，参见[58]。

I.48 *Ingster-Suslina formula* [225] 计算混合分布与简单分布之间的 χ^2-散度，利用了 χ^2 的二阶矩性质。设 P_θ 为 $\mathcal{X}$ 上由 $\theta \in \Theta$ 参数化的一族概率分布。Θ 上的每个分布（先验）π 诱导出一个混合分布 $P_\pi \triangleq \int P_\theta \pi(d\theta)$。假设 P_θ 具有共同的支配分布 Q。

(a) 证明

$$\chi^2(P_\pi \| Q) = \mathbb{E}[G(\theta, \tilde{\theta})] - 1,$$

其中 $\theta, \tilde{\theta}$ 是从 π 和 $G(\theta, \tilde{\theta}) \triangleq \int dQ \frac{dP_\theta}{dQ} \frac{dP_{\tilde{\theta}}}{dQ}$ 独立抽取的两个“副本”。

(b) 证明对于高斯混合模型（用 $*$ 表示卷积）

$$\chi^2(\pi * \mathcal{N}(0, I) \| \mathcal{N}(0, I)) = \mathbb{E}[e^{\langle \theta, \tilde{\theta} \rangle}] - 1, \quad \theta, \tilde{\theta} \overset{\text{i.i.d.}}{\sim} \pi.$$

从这一结果推导出（7.45）。

我们9（社区检测）Erdös-Rényi模型，记为ER(n,p)，是具有n个节点的随机图的分布，其中每一对节点以概率p独立连接。随机块模型（SBM），记为SBM(n,p,q)，将同质的Erdös-Rényi模型扩展以纳入社区结构：每个节点i被标记为$\sigma_i \in \{\pm 1\}$，表示其社区归属；在给定$\sigma = (\sigma_1, \ldots, \sigma_n)$的条件下，每一对节点$i$和$j$以概率$p$独立连接，如果$\sigma_i = \sigma_j$，否则以概率$q$连接。（例如，$p > q$的同配情形模拟了同一社区中的个体更可能成为朋友的情景。）社区检测问题询问当n很大时，SBM(n,p,q)是否可与其Erdös-Rényi对应物ER($n, \frac{p+q}{2}$)区分开来。考虑稀疏设置，其中$p = \frac{a}{n}$和$q = \frac{b}{n}$对于固定常数$a, b > 0$。

(a) 假设标签 σ_i 是独立且均匀的。应用练习 I.48 中的 Ingster-Suslina 公式，证明当 $n \to \infty$ 时，

$$\chi^2\left(\mathrm{SBM}(n,p,q) \middle\| \mathrm{ER}\left(n, \frac{p+q}{2}\right)\right) = \begin{cases} \frac{1}{\sqrt{1-\tau}} + o(1) & \tau < 1 \\ \infty & \tau \geq 1, \end{cases} \tag{I.16}$$

其中 $\tau \triangleq \frac{(a-b)^2}{2(a+b)}$。

(假设 n 是偶数，并且 σ 在二分划分集合 $\{z \in \{\pm 1\}^n : \sum_{i=1}^n z_i = 0\}$ 上均匀分布，使得两个社区大小相等。证明 (I.16) 仍然成立。

Note：作为(I.16)的结果，只要$\tau < 1$，我们就有连续性SBM$(n, p, q) \lhd$ ER$(n, \frac{p+q}{2})$。事实上，它们相互连续当且仅当$\tau < 1$。这个更为困难的结果可以使用[364, 227]开发的*small subgraph conditioning*方法来证明；参见[307，第5节]。

I.50（无放回抽样 I [400]）考虑生成随机向量 $X^n = (X_1, \ldots, X_n)$ 的两种方式：在 P 下，X^n 是从集合 $[n] = \{1, \ldots, n\}$ 中无放回抽取的；在 Q 下，X^n 是从 $[n]$ 中有放回抽取的。让我们比较前 k 次抽取 $X_1, \ldots, X_k$ 的联合分布，其中 $1 \le k \le n$。

(a) 证明

$$\mathrm{TV}(P_{X^k}, Q_{X^k}) = 1 - \frac{k!}{n^k}\binom{n}{k}$$
$$D(P_{X^k} \| Q_{X^k}) = -\log \frac{k!}{n^k}\binom{n}{k}.$$

总结 D 与 TV 为 $o(1)$ 当且仅当 $k = o(\sqrt{n})$。

(b) 通过找到一个显式测试来解释 $\sqrt{n}$ 的特殊性，该测试在 $k \gg \sqrt{n}$ 时能以高概率区分 P 和 Q。*Hint*：生日悖论。

I.51（无放回抽样 II [400]）设 $X_1, \ldots, X_k$ 为从包含 $i \in$ 种颜色 $[q]$ 的 a_i 个球的瓮中无放回抽取的随机样本，$\sum_{i=1}^q a_i = n$。设 $Q_X(i) = \frac{a_i}{n}$。证明

$$D(P_{X^k} \| Q_X^k) \le c\frac{k^2(q-1)}{(n-1)(n-k+1)}, \quad c = \frac{\log e}{2}.$$

设 R_{m,b_0,b_1} 为随机排列的具有 b_0 个零和 b_1 个一的二进制字符串的前 $m \le b_0 + b_1$ 个坐标中 1 的数量的分布。

(a) 证明

$$D(P_{X_{m+1}|X^m} \| Q_X | P_{X^m}) = \sum_{i=1}^q \mathbb{E}[\frac{a_i - V_i}{N-m} \log \frac{a_i - V_i}{p_i(N-m)}],$$

其中 $V_i \sim R_{m,N-a_i,a_i}$。

(b) 证明上述第i项也等于$p_i\, \mathbb{E}[\log \frac{a_i - \tilde{V}_i}{p_i(N-m)}]$，$\tilde{V}_i \sim R_{m,N-a_i,a_i-1}$。

(c) 使用琴生不等式证明第 i 项的上界为 $p_i \log \left(1 + \frac{m}{(n-1)(n-m)} \frac{1-p_i}{p_i}\right)$。

(d) 使用边界 $\log(1+x) \le x \log e$ 来完成证明。

I.52（有效德菲内蒂）我们将证明，对于任何对置换不变的分布 P_{X^n} 和 $k < n$，存在独立同分布分布的混合 Q_{X^k}，它近似于 P_{X^k}：

$$\mathrm{TV}(P_{X^k}, Q_{X^k}) \le c\sqrt{\frac{k^2 H(X_1)}{n-k+1}}, \quad Q_{X_k} = \sum_{i=1}^m \lambda_i Q_i^{\otimes k} \tag{I.17}$$

其中 $\sum_{i=1}^m \lambda_i = 1$，$\lambda_i \geq 0$ 且 Q_i 是 $\mathcal{X}$ 上的一些分布，并且 $c > 0$ 是一个通用常数。请遵循以下步骤：

(a) 展示恒等式（此处 P_{X^k} 是任意的）

$$D\Big(P_{X^k}\Big\|\prod_{j=1}^k P_{X_j}\Big) = \sum_{j=1}^{k-1} I(X^j; X_{j+1}).$$

(b) 证明一定存在某个 $t \in \{k, k+1, \ldots, n\}$ 使得

$$I(X^{k-1}; X_k | X_{t+1}^n) \leq \frac{H(X^{k-1})}{n-k+1}.$$

(提示：通过链式法则展开$I(X^{k-1};\ X_k^n)$。)

(c) 从1和2证明

$$D\Big(P_{X^k|T}\Big\|\prod P_{X_j|T}|P_T\Big) \leq \frac{kH(X^{k-1})}{n-k+1}$$

其中 $T = X_{t+1}^n$。

(d) 根据平斯克不等式

$$\mathbb{E}_T\left[\mathrm{TV}\Big(P_{X^k|T}, \prod P_{X_j|T}\Big)\right] \leq c\sqrt{\frac{kH(X^{k-1})|\mathcal{X}|}{n-k+1}}, \quad c = \frac{1}{\sqrt{2\log e}}.$$

由全变差的凸性得出（I.17）。

注意：另一个估计 [400, 123] 可以很容易地从练习 I.51 和练习 I.50 推导出来：存在 iid Q_{X^k} 的混合，使得

$$\mathrm{TV}(Q_{X^k}, P_{X^k}) \leq \frac{k}{n}\min(2|\mathcal{X}|, k-1).$$

界 (I.17) 仅当 $H(X_1) \lesssim 1$ 时改进了上述结果。

I.53（拧紧引理 [140, 419]）证明对于任意 $\delta > 0$ 和任意（U^n, V^n），存在一个大小为 $|I| \leq \frac{I(U^n;V^n)}{\delta}$ 的索引集 $I \subset [n]$，使得

$$I(U_t; V_t | U_I, V_I) \leq \delta \qquad \forall t \in [n].$$

当 $I(U^n;\ V^n) \ll n$ 时，这表明以（相对较少的）条目为条件，可以使各个坐标几乎独立。（提示：先证明 $I(A,B;\ C,D) \geq I(A;\ C) + I(B;\ D|A,C)$。然后从 $I = \emptyset$ 开始，如果存在任何索引 t 使得 $I(U_t;\ V_t|U_I, V_I) > \delta$，则将其加入 I 并重复。）

I.54（泛化差距=I_{SKL}，[18]）学习算法基于观测（不一定独立）$S_1, \ldots, S_n$选择参数W，其中所有S_i具有共同的边缘分布律P_S，目标是最小化新样本上的损失$= \mathbb{E}[\ell(W,S)]$，其中$S^n \perp\!\!\!\perp S \sim P_S$且$\ell$是任意损失函数[4]。考虑一个Gibbs采样器（见第4.8.2节），它选择

$$W \sim P_{W|S^n}(w|s^n) = \frac{1}{Z(s^n)}\pi(w)\exp\{-\frac{\alpha}{n}\sum_{i=1}^n \ell(w, s_i)\},$$

4 例如，如果$S = (X, Y)$，我们可能有$\ell(w,(x,y)) = 1\{f_w(x) \neq y\}$，其中$f_w$表示一个权重为$w$的神经网络。

其中 {v*} 是权重的固定先验，$Z(\cdot)$ 是归一化常数。证明该算法的泛化差距由下式给出

$$\mathbb{E}[\ell(W,S)] - \mathbb{E}[\frac{1}{n}\sum_{i=1}^{n}\ell(W,S_i)] = \frac{1}{\alpha}I_{\mathrm{SKL}}(W;S^n)\,,$$

其中 {v*} 是在 (7.49) 中定义的对称 KL-信息。

I.55 设 (X,Y) 为一些相关随机变量。假设对于每个 x，随机变量 $h(x,Y)$ 是 ϵ^2-亚高斯的。证明

$$\mathbb{E}_{P_{X,Y}}[h(X,Y)] - \mathbb{E}_{P_X\times P_Y}[h(X,Y)] \le \sqrt{2\epsilon^2 I(X;Y)}\,. \tag{I.18}$$

这允许通过以（互信息松弛的平方根）为代价，将因变量随机函数的期望替换为独立对，从而控制这些期望。

I.56（[369]）设 $A=\{A_j\colon j\in J\}$ 是一个可数随机变量集合，且 T 是一个取值于 J 的随机指标。证明：若每个 A_j 都是 ϵ^2-次高斯，则

$$|\,\mathbb{E}[A_T]| \le \sqrt{2\epsilon^2 I(A;T)}\,.$$

I.57（混合分布的散度 [216, 249]）设 $\bar{Q}=\sum_i \pi_i Q_i$ 为一个混合分布。

(a) 证明

$$D(P\|\bar{Q}) \le -\log\left(\sum_i \pi_i \exp(-D(P\|Q_i))\right)\,,$$

改进简单的凸性估计 $D(P\|\bar{Q}) \le \sum_i \pi_i D(P\|Q_i)$。（提示：证明函数 $Q\mapsto \exp\{-aD(P\|Q)\}$ 对每个 $a\le 1$ 都是凹的。）

(b) 此外，对于任何分布 $\{\tilde{\pi}_j\}$，任何 $\lambda\in[0,1]$，我们有 ve

$$\begin{aligned}\sum_j \tilde{\pi}_j D(Q_j\|\bar{Q}) + D(\pi\|\tilde{\pi}) &\ge -\sum_i \pi_i \log\sum_j \tilde{\pi}_j e^{-(1-\lambda)D_\lambda(P_i\|P_j)}\\ &\ge -\log\sum_{i,j}\pi_i\tilde{\pi}_j e^{-(1-\lambda)D_\lambda(P_i\|P_j)}\end{aligned}$$

(提示：通过Donsker-Varadhan定理证明 $D(P_{A|B=b}\|Q_A) \ge -\mathbb{E}_{A|B=b}[\log \mathbb{E}_{A'\sim Q_A}\frac{g(A',b)}{g(A,b)}]$。代入 $g(a,b)=P_{B|A}(b|a)^{1-\lambda}$，对 B 取平均，并利用Jensen不等式将外层的 $\mathbb{E}_{B|A}$ 移入对数内部。) I.58（互信息与成对距离 [216]）假设我们已知成对距离 $d_\lambda(x,x') \triangleq D_\lambda(P_{Y|X=x}\|P_{Y|X=x'})$，其中 D_λ 是阶数为 λ 的Rényi散度。关于 $I(X;Y)$ 能得出什么结论？令 $X,X'\overset{\text{i.i.d.}}{\sim}P_X$。利用练习I.57，证明

$$I(X;Y) \le -\mathbb{E}[\log\mathbb{E}[\exp(-d_1(X,X'))|X]]$$

对于每个 $\lambda\in[0,1]$

$$I(X;Y) \ge -\mathbb{E}[\log\mathbb{E}[\exp(-(1-\lambda)d_\lambda(X,X'))|X]].$$

有关应用，参见定理 32.5。

I.59（$D \lesssim H^2$对数$\frac{1}{H^2}$技巧）证明对于任意P, U, R，$\lambda > 1$，以及$0 < \epsilon < 2^{-5\frac{\lambda}{\lambda-1}}$，我们有

$$D(P\|\epsilon U + \bar{\epsilon} R) \le 8(H^2(P,R) + 2\epsilon)\left(\frac{\lambda}{\lambda-1}\log\frac{1}{\epsilon} + D_\lambda(P\|U)\right).$$

因此，一组P的Hellinger ϵ-网可以转换为KL $(\epsilon^2 \log\frac{1}{\epsilon})$-网；参见第32.2.4节定理32.6。

(a) 首先证明散度的尾部估计：对于任意 $\lambda > 1$ 和 $b > e^{(\lambda-1)^{-1}}$

$$\mathbb{E}_P\left[\log\frac{dP}{dQ}\cdot 1\{\frac{dP}{dQ} > b\}\right] \le \frac{\log b}{b^{\lambda-1}}\exp\{(\lambda-1)D_\lambda(P\|Q)\}$$

(b) 证明对于任意 $b > 1$，我们有

$$D(P\|Q) \le H^2(P,Q)\frac{b\log b}{(\sqrt{b}-1)^2} + \mathbb{E}_P\left[\log\frac{dP}{dQ}\cdot 1\{\frac{dP}{dQ} > b\}\right]$$

(提示：将 $D(P\|Q) = \mathbb{E}_P[h(\frac{dQ}{dP})]$ 写作 $h(x) = -\log x + x - 1$，并注意$\frac{h(x)}{(\sqrt{x}-1)^2}$在 $\mathbb{R}_+$ 上单调递减。)

(c) 设 $Q = \epsilon U + \bar{\epsilon} R$ 并证明对于每个 $\delta < e^{-\frac{1}{\lambda-1}} \wedge \frac{1}{4}$

$$D(P\|Q) \le \left(4H^2(P,R) + 8\epsilon + c_\lambda \epsilon^{1-\lambda}\delta^{\lambda-1}\right)\log\frac{1}{\delta},$$

where $c_\lambda = \exp\{(\lambda-1)D_\lambda(P\|U)$. (Notice $H^2(P,Q) \le H^2(P,R) + 2\epsilon$, $D_\lambda(P\|Q) \le D_\lambda(P\|U) + \log\frac{1}{\epsilon}$ and set $b = 1/\delta$.)

(d) 通过设置 $\delta^{\lambda-1} = \frac{4H^2(P,R)+2\epsilon}{c_\lambda \epsilon^{\lambda-1}}$ 来完成证明。

I.60 设 $G = (V, E)$ 为一个有限 *directed* 图。设

$$\triangle = \left|\left\{(x,y,z) \in V^3 : (x,y),(y,z),(z,x) \in E\right\}\right|,$$
$$\wedge = \left|\left\{(x,y,z) \in V^3 : (x,y),(x,z) \in E\right\}\right|.$$

证明 $\triangle \le \wedge$

Hint: 证明 $H(X,Y,Z) \le H(X) + 2H(Y|X)$ 对于均匀分布在有向三环集合上的随机变量 (X,Y,Z)，即子集 $X \to Y \to Z \to X$。

I.61（并封闭集猜想（UCSC））设 X 和 Y 是 $\{0,1\}^n$ 中的独立向量。证明 [88]

$$H(X \,\mathtt{OR}\, Y) \ge \frac{\bar{p}}{2\phi}(H(X) + H(Y)), \qquad \bar{p} \triangleq \min_i \min(\mathbb{P}[X_i = 0], \mathbb{P}[Y_i = 0]),$$

其中 OR 表示逐坐标逻辑或，$\phi = \frac{\sqrt{5}-1}{2}$。（提示：设 $Z = X \,\mathtt{OR}\, Y$，使用链式法则 $H(Z) \ge \sum_i H(Z_i|X^{i-1}, Y^{i-1})$，以及二元熵的不等式 $h(ab) \ge \frac{h(a)b+h(b)a}{2\phi}$）。注释：$\mathcal{F} \subset \{0,1\}^n$ 称为并封闭集，若 $x, y \in \mathcal{F} \implies (x \,\mathtt{OR}\, y) \in \mathcal{F}$。UCSC 表述为 $p = \max_i \mathbb{P}[X_i = 1] \ge 1/2$，其中 X 在 $\mathcal{F}$ 上均匀分布。Gilmer 的方法 [189] 将上述不等式应用于 Y，取其为 X 的独立副本，使得 $H(X \,\mathtt{OR}\, Y) \le H(X) = H(Y) = \log|\mathcal{F}|$，从而证明 $p \ge 1 - \phi \approx 0.382$。

I.62（回归压缩）设 $Y \in [-1;1]$ 和 $X \in \mathcal{X}$，其中 $\mathcal{X}$ 是有限的（为简化起见）。本练习中的辅助变量 U, U' 假定为 X 的确定性函数。为简化起见，假设 $\mathcal{X}$ 是有限的（但巨大）。令 cmp(U) 为一个复杂度度量，满足 cmp(U,U') $\le$ cmp(U) + cmp(U')，cmp(常数) = 0 且 cmp(Ber(p)) $\le \log 2$ 对于任意 p (可考虑 $H(U)$ 或 $\log|\mathcal{U}|$)。选择 U 为 $I(U$ 的最大化者；$Y) - \delta$cmp(U)。

(a) 证明 cmp(U) $\le \frac{I(X;Y)}{\delta}$b) 对于任意 U' 证明 $I(Y;U'|U) \le \delta$cmp(U')
(（提示：检查 $U'' = (U,U')$）(c) 对于任意事件 $S = \{X \in A\}$ 证明

$$|\mathbb{E}[(Y - \mathbb{E}[Y|U])1_S]| \le \sqrt{2\delta \ln 2} \tag{I.19}$$

(提示：由柯西-施瓦茨不等式，只需证明 $\mathbb{E}[|\,\mathbb{E}[Y|U,1_S] - \mathbb{E}[Y|U]|^2] \lesssim \delta$，这可通过在 b) 中取 $U' = 1_S$ 并应用陶哲轩不等式 (7.28) 得到）

(d) 通过选择合适的 S 并将其应用于 S 和 S^c，得出以下结论：

$$\mathbb{E}[|\,\mathbb{E}[Y|X] - \mathbb{E}[Y|U]|] \le 2\sqrt{2\delta \ln 2}\,.$$

(因此，任何高维复杂特征向量 X 都可以压缩为基数阶为 $I(Y$ 的 U；$X)$ (且独立于 $|\mathcal{X}|$) ，但在回归方面却基本上与 X 一样好；关于 *information distillation* 的其他结果见 [51]。)

I.63（Szemerédi正则性引理的IT版本[414]）固定 $\epsilon, m > 0$ 并考虑随机变量 $Y, X = (X_1, X_2)$，其中 $Y \in [-1,1]$，$\mathcal{X} = \mathcal{X}_1 \times \mathcal{X}_2$ 有限（但巨大）且 $I(X;Y) \le m$。在本练习中，所有辅助随机变量 U 都具有结构 $U = (f_1(X_1), f_2(X_2))$，对于某些确定性函数 f_1, f_2。因此 U 将 $\mathcal{X}$ 划分为乘积块，我们称块 $U = u_0$ ϵ-*regular* 为如果

$$|\mathbb{E}[(Y - \mathbb{E}[Y|U])1_S | U = u_0]| \le \epsilon \qquad \forall S = \{X_1 \in A_1, X_2 \in A_2\}\,.$$

我们将证明存在 $J = J(\epsilon, m)$，使得存在一个 U 满足 $|\mathcal{U}| \le J$，并且使得

$$\mathbb{P}[\text{block } U \text{ is not } \epsilon\text{-regular}] \le \epsilon\,. \tag{I.20}$$

(假设我们找到了随机变量 $Y \to X \to U' \to U$，使得 (i) $I(Y;U'|U) \le \epsilon^4$ 且 (ii) 对于上述所有 S，有 $I(Y;1_S|U') \le \frac{\epsilon^4}{|\mathcal{U}|^2}$。那么 (I.20) 成立，只需将 ϵ 替换为 $O(\epsilon)$。（提示：定义 $g(u_0) = \mathbb{E}[|\,\mathbb{E}[Y|U'] - \mathbb{E}[Y|U]|\,|U = u_0]$，并通过 (7.28) 证明 $\mathbb{E}[g(U)] \lesssim \epsilon^2$。如同 (I.19) 中那样论证 $\mathbb{E}[(Y - \mathbb{E}[Y|U'])1_S] \lesssim \frac{\epsilon^2}{|\mathcal{U}|}$。由三角不等式，当 $g(u_0) < \epsilon$ 且 $\mathbb{P}[U = u_0] > \frac{\epsilon}{|\mathcal{U}|}$ 时，任何 u_0-块都是 $O(\epsilon)$-正则的。最后，两次应用马尔可夫不等式以证明最后一个条件被违反的概率为 $O(\epsilon)$。）

(b) 证明这样的 U', U 确实存在。（提示：通过取 U_{j+1} 为 $I(Y$ 的最大化者，在所有 $Y \to X \to U \to U_j$ (中依次构造序列 $Y \to X \to \cdots U_j \to U_{j-1} \to \cdots U_0 = 0$；$U) - \delta_{j+1}$ log $|\mathcal{U}|$，比较练习 I.62) 和 $\delta_{j+1} = \frac{\epsilon^4}{|\mathcal{U}_j|^2}$。我们取 $U', U = U_{n+1}, U_n$ 作为第一个满足 $I(Y$ 的对；$U_{n+1}|U_n) \le \epsilon^4$。证明 $n \le \frac{m}{\epsilon^4}$ 并且 $|\mathcal{U}_n|$ 被从 $h = 1$ 开始的映射 $h \to h\exp\{mh^2/\epsilon^4\}$ 的第 n 次迭代所界定。）

Remark: 关键点在于 J 不依赖于 $P_{X,Y}$ 或 $|\mathcal{X}|$。对于Szemerédi正则引理，取 X_1, X_2 为二分图中均匀采样的顶点，$Y = 1\{X_1 \sim X_2\}$ 是关联关系。一个 ϵ-正则块对应于一个 ϵ-正则二分子图，而引理将任意图分解为有限个两两（几乎）正则的子图。

I.64（熵与二元卷积）二元卷积定义为 $(a,b)\in[0,1]^2$ 由 $a*b=a(1-b)+(1-a)b$ 并描述了 Ber(a) $\oplus$ Ber(b) 的规律，其中 $\oplus$ 表示模2加法。

(a)（Gerber 夫人引理，MGL[5]）令 $(U,X)\perp\!\!\!\perp Z\sim$ 服从 Ber(δ)，其中 $X\in\{0,1\}$。证明

$$h(h^{-1}(H(X|U))*\delta)\le H(X\oplus Z|U)\le H(X|U)+H(Z)-\frac{H(X|U)H(Z)}{\log 2}\,.$$

(提示：等价地 [457]，需要证明参数曲线 $(h(p),h(p*\delta)),p\in[0,1/2]$ 是凸的。)

(b) 证明对于任意 p,q，参数曲线 $((1-2r)^2,d(p*r\|q*r)),r\in[0,1/2]$ 是凸的。（提示：参见[367，附录A]）

MGL 有多种应用（示例 16.1 和练习 VI.21），它可以张量化（见练习 III.32），并且其无穷小版本（在 $\delta=0+$ 中的导数）正是超立方体的对数-Sobolev 不等式 [122, 第4.1节]。

I.65（对数-Sobolev 不等式，LSI）设 X 为一个 $\mathbb{R}^d$ 值随机变量，$\mathbb{E}[\|X\|^2]<\infty$，且 $X\perp\!\!\!\perp Z\sim\gamma$，其中 $\gamma=\mathcal{N}(0,I_d)$ 是标准高斯测度。回忆来自（2.40）的 Fisher 信息矩阵 $J(\cdot)$ 的记号。

(a) 显示 *de Bruijn's identity*:

$$\frac{d}{da}h(X+\sqrt{a}Z)=\frac{\log e}{2}\operatorname{tr}J(X+\sqrt{a}Z)$$

(提示：检查定理3.14)的证明

(b) 证明 EPI 意味着

$$\frac{d}{da}\exp\{2h(X+\sqrt{a}Z)/d\}\ge 2\pi e\,.$$

(c) 得出结论，在所有具有有界费舍尔信息$J(X)$的X中，高斯分布*minimize*具有最大微分熵，即[399]

$$h(X)\ge\frac{n}{2}\log\frac{2\pi en}{\operatorname{tr}J(X)}\,.$$

(显示Gross [200]的LSI：对于任何具有$\int f^2d\gamma=1$的f，我们有

$$\int f^2\ln(f^2)d\gamma\le 2\cdot\int\|\nabla f\|^2d\gamma\,.$$

(提示：$P_X(dx)=f^2(x)\gamma(dx)$，证明 $2\int(x^T\nabla f)f\gamma(dx)=\mathbb{E}[\|X\|^2]-d$ 并使用 $\ln(1+y)\le y$.) I.66（随机局部化 [148, 146]）考虑一个离散的 $X\sim\mu$，取值于 $\mathbb{R}^n$，并令 $\rho=\mathbb{E}[\|X-\mathbb{E}[X]\|^2]=\sum_{i=1}^n\operatorname{Var}[X_i]$。我们将证明，对于任意 $\epsilon>0$，存在 $\mu=\mathbb{E}_\theta\,\mu_\theta$ 的一个分解，表示为测度 μ_θ 的混合，这些测度具有相似的熵（$\mathbb{E}_\theta[H(\mu_\theta)]=H(\mu)-O(\rho/\epsilon)$），但几乎没有成对相关性（$\mathbb{E}_\theta[\operatorname{Cov}(\mu_\theta)]\preceq\epsilon I_n$ 和 $\mathbb{E}_\theta[\|\operatorname{Cov}(\mu_\theta)\|_{\mathrm{F}}^2]=O(\epsilon\rho)$）。这在伊辛模型的统计物理中有重要应用。

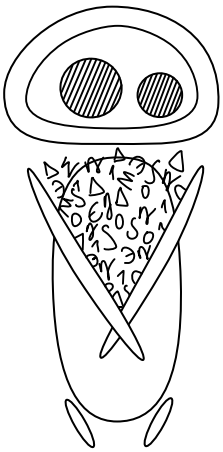
[5] Apparently, named after a landlady renting a house to Wyner and Ziv [457] at the time.

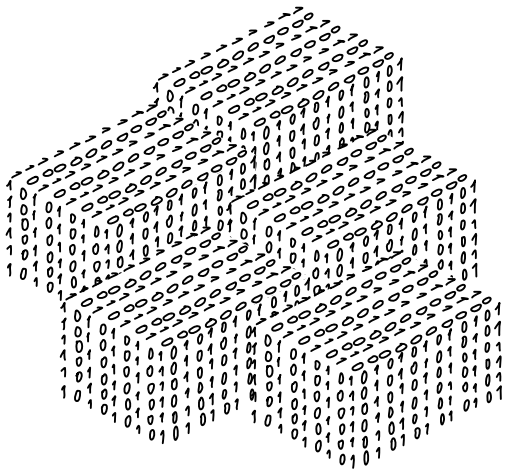
(a) 令 $Y_t = \sqrt{t}X + \sqrt{\epsilon}Z$，其中 $X \perp\!\!\!\perp Z \sim \mathcal{N}(0, I_d)$ 且 $t, \epsilon > 0$。证明 $\mathrm{Cov}(X|Y_t) \preceq \frac{\epsilon}{t} I_n$（提示：考虑次优估计量 $\hat{X}(Y_t) = Y_t/\sqrt{t}$）。(b) 证明 $0 \le H(X) - H(X|Y_t) \le \frac{n}{2}\log(1 + \frac{t}{\epsilon n}\rho)$ $\le \frac{t \log e}{2\epsilon}\rho$。（提示：使用 (5.22)）(c) 证明 $\rho \ge \mathsf{mmse}(X|Y_1) - \mathsf{mmse}(X|Y_2) = \frac{1}{\epsilon}\int_1^2 \mathbb{E}[\|\Sigma_t(Y_t)\|_{\mathrm{F}}^2]dt$，其中 $\Sigma_t(y) = \mathrm{Cov}[X|Y_t = y]$。（提示：使用 (3.23)）。因此我们得出结论：对于某个 $t \in [1, 2]$ 分解 $\mu = \mathbb{E}_{Y_t} P_{X|Y_t}$，满足所述断言。

Part II

无损数据压缩







数据压缩的主要工程目标是将源产生的给定序列 $a_1, a_2, \ldots, a_n$ 表示为在可能的算法约束下长度尽可能短的比特序列。当然，减少比特数通常是不可行的，除非源满足某些统计限制，也就是说，实际上只有一小部分序列会在实践中出现。（或者更准确地说，只有一小部分捕获了总体概率分布的大部分）对于现实世界的数据来说，情况是否如此?

作为一个简单的演示，可以取两本英文小说并计算每个字母的经验频率。结果会发现两本小说的频率（大致）相同。因此，我们可以看到英语文本中存在某种底层结构，限制了可能的输出序列。当然，这种结构超越了经验频率，进一步的实验（涉及双字母组合、词频等）可能会揭示这一点。因此，数据压缩可能性的主要原因是
experimental (empirical) law: Real-world sources produce very restricted sets of sequences.

我们如何对这些限制进行建模? 进一步的实验（涉及语言、音乐、图像）表明，如果我们假设序列是以概率方式生成的，那么其结构往往能得到很好的描述[378, 第III节]。香农的持久贡献之一是以下经验法则:
real-world sequences may be described probabilistically with increasing precision starting from i.i.d., first-order Markov, second-order Markov etc. 需要注意的是，有时我们需要找到一个合适的基，使得这一“法则”成立：对于语言，你可以选择字符或单词；对于图像，你可以选择像素和小波/局部傅里叶变换。确实，光栅化的像素序列并不展现出任何稳定的局部结构，而将基变换为小波和局部傅里叶变换则揭示了那种结构。[6] 找到正确的表示在实际中非常重要，但在本书中，我们假设这一步已经完成，我们面对的是一个简单的随机过程（独立同分布、马尔可夫或遍历）。我们如何用最少的比特数来表示它呢?

一开始，我们将进一步简化问题，并将注意力限制在用（最少数量的）比特表示一个随机变量 X 上。之后，X 将被视为目标过程中一个大的 n 字母块，即 $X = S^n = (S_1, \ldots, S_n)$。本书将考虑的压缩类型有:

- 可变长度无损压缩。这里我们要求 $\mathbb{P}[X \neq \hat{X}] = 0$，其中 $\hat{X}$ 是解码版本。为了使问题有趣，我们将 X 压缩为可变长度二进制字符串。结果表明，最优压缩长度为 $H(X) - O(\log(1 + H(X)))$。如果我们进一步将注意力限制在所谓的前缀无关或唯一可解码码上，那么最优压缩长度为 $H(X) + O(1)$。将这些结果应用于 n 字母变量 $X = S^n$，我们看到，由 n 归一化的最优压缩长度收敛于过程 $\{S_j\}$ 的熵率（第 6.3 节）。

[6] Of course, one should not take these “laws” too far. In regards to language modeling, (finite-state) Markov assumption is too simplistic to truly generate all proper sentences, cf. Chomsky [94]. However, astounding success of modern high-order Markov models, such as GPT-4 [320], shows that such models are very difficult to distinguish from true language.

• 定长、几乎无损压缩。在这里，我们允许极小的（或当$X = S^n$时随$n \to \infty$消失的）错误概率，即$\mathbb{P}[X \neq \hat{X}] \leq \epsilon$。事实证明，在对过程$\{S_j\}$的温和假设下，我们同样可以压缩至熵率，但不能更低。这种压缩模式在存在边信息（Slepian-Wolf等）时允许各种美妙的结果。• 有损压缩。在这里，我们仅要求$\mathbb{E}[d(X, \hat{X})] \leq \epsilon$，其中$d(\cdot, \cdot)$是某个损失函数。这类压缩问题正是第五部分的主题。

我们还注意到，考虑到$X = S^n$，更准确地说，前两种压缩类型应被称为“固定到可变”和“固定到固定”，因为它们接受固定数量的输入字母，并产生可变或固定数量的输出比特。还有其它类型的压缩算法，我们不讨论，例如Tunstall [425]的漂亮的可变到固定压缩器。

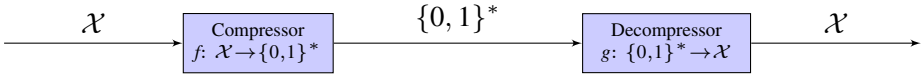
10 Variable-length compression

在本章中，我们考虑一个基本问题：如何用可变长度的比特串来描述一个离散随机变量$X \in \mathcal{X}$，使得描述尽可能短。这一基本思想在电报的摩尔斯电码中已有应用，且完全显而易见：较短的描述（比特串）应对应于更可能的符号。然而，稍后我们会看到，一旦我们将X视为一组符号，这一基本思想就变得更加微妙。香农的发现是，将*groups*个符号一起压缩（即使它们是独立同分布的！）可以显著节省压缩长度。也就是说，通过先将连续的10个字符分组再编码英文文本，比逐个字符编码要好得多。人们应当赞赏香农这一提议的大胆，因为将10个字母的英文片段的所有可能26^{10}种实现按频率递减排序显得相当困难。直到后来，随着霍夫曼编码、算术编码和Lempel-Ziv压缩器的发明（数十年之后），这些方法才变得实用且无处不在。

在本章中，我们发现X的最小压缩长度在单次、唯一可译码和无前缀码的情况下，本质上等于熵$H(X)$。这些结果是本书中*coding theorems*的首批示例，即连接操作问题与信息度量的结果。（因此，压缩在信息论中也称为*source coding*。）此外，我们还讨论了所谓的齐普夫定律，以及如何从信息论的角度描述其广泛出现。

10.1 变长无损压缩

无损数据压缩的设置如下图所示。



更正式地说，如果函数f: $\mathcal{X} \to \{0,1\}^*$满足以下性质，则它是随机变量$X$的变长单次无损压缩器：

1 它将每个符号$x \in \mathcal{X}$映射为$\{0,1\}^* \triangleq \cup_{k\geq 0}\{0,1\}^k = \{\emptyset, 0, 1, 00, 01, \dots\}$中的一个变长字符串$f(x)$。每个$f(x)$称为*codeword*，而码字的集合称为*codebook*。

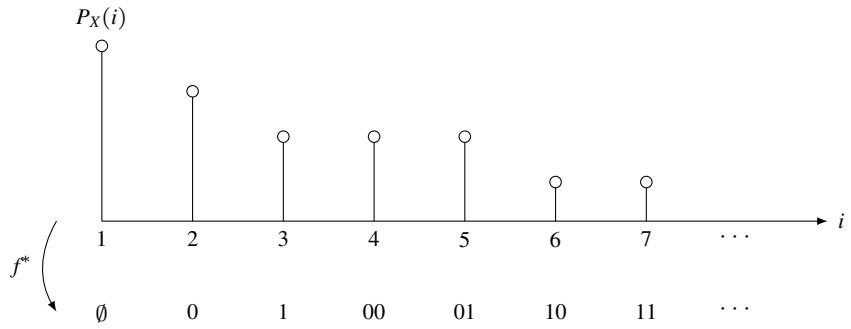


图10.1 最优可变长度无损压缩器f^*的示意图。

2 对于 X，它是 *lossless*：存在一个解压缩器 g：$\{0,1\}^* \to \mathcal{X}$，使得 $\mathbb{P}[X = g(f(X))] = 1$。换句话说，$f$ 在 P_X 的支撑集上是单射。

注意，由于 $\{0,1\}^*$ 是可数的，无损压缩仅对离散的 X 可能。此外，由于 $\mathcal{X}$ 的结构并不重要，我们可以重新标记 $\mathcal{X}$，使得 $\mathcal{X} = \mathbb{N} = \{1,2,\dots\}$，并将概率质量函数按降序排列：$P_X(1) \geq P_X(2) \geq \cdots$。在 *a single-shot compression* 设定中，参见 [251]，我们不对映射 f 施加任何额外约束。在后面的第 10.3 节中，我们将引入诸如无前缀性和唯一可译性等条件。

为了量化压缩器 f 的优劣，我们引入长度函数 l：$\{0,1\}^* \to \mathbb{Z}_+$，例如，$l(\emptyset) = 0, l(010\,01) = 5$。我们可以考虑选择最佳压缩器 f 的不同目标，例如，最小化 $\mathbb{E}[l(f(X))]$, 中的任何一个 esssup $l(f(X))$, 中位数$[l(f(X))]$ 似乎是合理的。事实证明，存在一个压缩器 f^*，它同时最小化所有目标。正如本章前言所述，主要思想是为较不可能的符号分配较长的码字，并为较可能的符号保留较短的码字。为了明确 f^* 的最优性，让我们回顾随机占优的概念。

定义 10.1（随机占优）对于实值随机变量 X 和 Y，我们说 Y 随机占优（或随机大于）X，记作 $X \overset{\text{st.}}{\leq} Y$，如果对于所有 $t \in \mathbb{R}$，有 $\mathbb{P}[Y \leq t] \leq \mathbb{P}[X \leq t]$。

根据定义，$X \overset{\text{st.}}{\leq} Y$当且仅当$X$的累积分布函数逐点大于$Y$的累积分布函数；换言之，$X$的分布比$Y$的分布赋予较低值更多的概率。特别地，如果$X$被$Y$随机占优，那么它们的均值、中位数、上确界等也如此。

定理 10.2（最优 f^*）*Consider the compressor f^* defined (for a down-sorted PMF P_X) by $f^*(1) = \emptyset, f^*(2) = 0, f^*(3) = 1, f^*(4) = 00$, etc, assigning strings with increasing lengths to symbols $i \in \mathcal{X}$. (See Figure 10.1 for an illustration.) Then*

1 Length of codeword:

$$l(f^*(i)) = \lfloor \log_2 i \rfloor.$$

2 $l(f^*(X))$ is stochastically the smallest: For any lossless compressor $f : \mathcal{X} \to \{0,1\}^*$,

$$l(f^*(X)) \overset{\text{st.}}{\leq} l(f(X))$$

i.e., for any k, $\mathbb{P}[l(f(X)) \leq k] \leq \mathbb{P}[l(f^*(X)) \leq k]$. As a result, $\mathbb{E}[l(f^*(X))] \leq \mathbb{E}[l(f(X))]$.

Proof. 请注意

$$|A_k| \triangleq |\{x : l(f(x)) \leq k\}| \leq \sum_{i=0}^{k} 2^i = 2^{k+1} - 1 = |\{x : l(f^*(x)) \leq k\}| \triangleq |A_k^*|.$$

这里的 f 是无损的，因此 $|A_k|$ 最多只能是长度不超过 k 的二进制串总数。那么

$$\mathbb{P}[l(f(X)) \leq k] = \sum_{x \in A_k} P_X(x) \leq \sum_{x \in A_k^*} P_X(x) = \mathbb{P}[l(f^*(X)) \leq k], \tag{10.1}$$

由于 $|A_k| \leq |A_k^*|$ 和 A_k^* 包含所有 $2^{k+1} - 1$ 个最可能的符号。 □

在确定了最优压缩器之后，接下来的问题是要理解其平均压缩长度 $\mathbb{E}[\ell(f^*(X))]$。事实上，我们可以将其精确地计算为一个无穷级数，参见习题II.1。然而，更重要的是，它实际上基本上等于$H(X)$。具体来说，我们有以下结果。

定理 10.3 (最优平均码长与熵 [14])

$$H(X) \texttt{ bits} - \log_2[e(H(X)+1)] \leq \mathbb{E}[l(f^*(X))] \leq H(X) \texttt{ bits}$$

备注 10.1（信源编码定理）定理 10.3 是本书中第一个 *coding theorem* 的示例，它将基本极限 $\mathbb{E}[l(f^*(X))]$（一个操作量）与熵 $H(X)$ (信息度量) 联系起来。

Proof. 定义 $L(X) = l(f^*(X))$）。对于上界，观察到由于假设 PMF 按降序排列，$P_X(m) \leq 1/m$，因此 $L(m) \leq \log_2 m \leq \log_2(1/P_X(m))$。取期望得到 $\mathbb{E}[L(X)] \leq H(X)$。

对于下界，

$$\begin{aligned} H(X) = H(X,L) = H(X|L) + H(L) &\overset{\text{(a)}}{\leq} \mathbb{E}[L] + H(L) \\ &\overset{\text{(b)}}{\leq} \mathbb{E}[L] + h\left(\frac{1}{1+\mathbb{E}[L]}\right)(1+\mathbb{E}[L]) \end{aligned}$$

$$= \mathbb{E}[L] + \log_2(1+\mathbb{E}[L]) + \mathbb{E}[L]\log_2\left(1+\frac{1}{\mathbb{E}[L]}\right) \tag{10.2}$$

$$\overset{\text{(c)}}{\leq} \mathbb{E}[L] + \log_2(1+\mathbb{E}[L]) + \log_2 e$$

$$\overset{\text{(d)}}{\leq} \mathbb{E}[L] + \log_2(e(1+H(X)))$$

其中 (a) 中我们利用了 $H(X|L=k) \leq k\,\texttt{bits}$，因为 f^* 是无损的，所以给定 $f^*(X) \in \{0,1\}^k$，X 最多可取 2^k 个值；(b) 由练习 I.4 得出；(c) 通过 $x\log(1+1/x) \leq \log e, \forall x > 0$ 得到；(d) 则依据先前展示的上界 $H(X) \leq \mathbb{E}[L]$。 □

为了说明，我们需要引入一种从*single-letter*源到*multi-letter*源的重要方法，这在序言中已经提及。假设$S_j \overset{\text{i.i.d.}}{\sim} P_S$ (这被称为*a memoryless source*)。我们可以将S_j的n个字母组合在一起，并将$X = S^n$视为一个超级字母。将我们的结果应用于随机变量X，我们得到：

$$nH(S) \geq \mathbb{E}[l(f^*(S^n))] \geq nH(S) - \log_2 n + O(1).$$

事实上，对于无记忆源，确切的渐近行为可在[408，定理4]中找到：

$$\mathbb{E}[l(f^*(S^n))] = \begin{cases} nH(S) + O(1)\,, & P_S = \text{Unif} \\ nH(S) - \frac{1}{2}\log_2 n + O(1)\,, & P_S \neq \text{Unif} \end{cases}.$$

对于$\log_2 \frac{1}{P_S}$具有非格分布的信源情况，[408，定理3]进一步表明：

$$\mathbb{E}[l(f^*(S^n))] = nH(S) - \frac{1}{2}\log_2(8\pi e V(S) n) + o(1)\,, \tag{10.3}$$

其中 $V(S)$ 是源 S 的 *varentropy*：

$$V(S) \triangleq \text{Var}\left[\log_2 \frac{1}{P_S(S)}\right]. \tag{10.4}$$

定理10.3将$l(f^*(X))$的*mean*与$\log_2 \frac{1}{P_X(X)}$ (熵)的*mean*联系起来。事实证明，这些随机变量的分布也密切相关。

定理 10.4（f^*的码长分布）$\forall \tau > 0, k \geq 0$,

$$\mathbb{P}\left[\log_2 \frac{1}{P_X(X)} \leq k\right] \leq \mathbb{P}\left[l(f^*(X)) \leq k\right] \leq \mathbb{P}\left[\log_2 \frac{1}{P_X(X)} \leq k+\tau\right] + 2^{-\tau+1}.$$

Proof. 下界（可达性）：使用 $P_X(m) \leq 1/m$。然后与定理10.3类似，$L(m) = \lfloor \log_2 m \rfloor \leq \log_2 m \leq \log_2 \frac{1}{P_X(m)}$。因此 $L(X) \leq \log_2 \frac{1}{P_X(X)}$ 几乎必然。

上界（逆）：考虑以下链

$$\mathbb{P}\left[L \leq k\right] = \mathbb{P}\left[L \leq k, \log_2 \frac{1}{P_X(X)} \leq k+\tau\right] + \mathbb{P}\left[L \leq k, \log_2 \frac{1}{P_X(X)} > k+\tau\right]$$

$$\leq \mathbb{P}\left[\log_2 \frac{1}{P_X(X)} \leq k+\tau\right] + \sum_{x\in\mathcal{X}} P_X(x) 1\left\{l(f^*(x)) \leq k\right\} 1\left\{P_X(x) \leq 2^{-k-\tau}\right\}$$

$$\leq \mathbb{P}\left[\log_2 \frac{1}{P_X(X)} \leq k+\tau\right] + (2^{k+1}-1)\cdot 2^{-k-\tau} \qquad \square$$

注10.2（可达性与逆定理）传统上，在信息论中，正面结果（“压缩长度小于...”）被称为*achievability*，而负面结果（“压缩长度不能小于...”）被称为*converse*。

目前我们的讨论适用于任意随机变量X。接下来，我们将信息源视为一个随机过程（$S_1, S_2, \ldots$），并引入*blocklength* n。我们将结果应用于$X = S^n$，即通过将前n个符号视为一个超符号。以下推论表明，$l(f^*(S^n))$和$\log \frac{1}{P_{S^n}(S^n)}$的极限行为总是相吻合的。

推论 10.5 *Let* $(S_1, S_2, \ldots)$ *be a random process and* U, V *real-valued random variable. Then*

$$\frac{1}{n}\log_2 \frac{1}{P_{S^n}(S^n)} \xrightarrow{\mathrm{d}} U \quad \Leftrightarrow \quad \frac{1}{n} l(f^*(S^n)) \xrightarrow{\mathrm{d}} U \tag{10.5}$$

and

$$\frac{1}{\sqrt{n}}\left(\log_2 \frac{1}{P_{S^n}(S^n)} - H(S^n)\right) \xrightarrow{\mathrm{d}} V \quad \Leftrightarrow \quad \frac{1}{\sqrt{n}}\left(l(f^*(S^n)) - H(S^n)\right) \xrightarrow{\mathrm{d}} V \tag{10.6}$$

Proof. 首先回忆，依分布收敛等价于累积分布函数在所有连续点处的收敛，即 $U_n \xrightarrow{\mathrm{d}} U \Leftrightarrow \mathbb{P}[U_n \leq u] \to \mathbb{P}[U \leq u]$ 对于所有 u，在这些点上 U 的累积分布函数是连续的（即，不是 U 的原子）。

要得到(10.5)，应用定理10.4于$k = un$和$\tau = \sqrt{n}$:

$$\mathbb{P}\left[\frac{1}{n}\log_2 \frac{1}{P_X(X)} \leq u\right] \leq \mathbb{P}\left[\frac{1}{n} l(f^*(X)) \leq u\right] \leq \mathbb{P}\left[\frac{1}{n}\log_2 \frac{1}{P_X(X)} \leq u + \frac{1}{\sqrt{n}}\right] + 2^{-\sqrt{n}+1}.$$

要得到(10.6)，应用定理10.4并使用$k = H(S^n) + \sqrt{n}u$和$\tau = n^{1/4}$:

$$\begin{aligned}\mathbb{P}\left[\frac{1}{\sqrt{n}}\left(\log \frac{1}{P_{S^n}(S^n)} - H(S^n)\right) \leq u\right] &\leq \mathbb{P}\left[\frac{l(f^*(S^n)) - H(S^n)}{\sqrt{n}} \leq u\right] \\ &\leq \mathbb{P}\left[\frac{1}{\sqrt{n}}\left(\log \frac{1}{P_{S^n}(S^n)} - H(S^n)\right) \leq u + n^{-1/4}\right] + 2^{-n^{1/4}+1}.\end{aligned} \tag{10.7}$$

$\square$

现在让我们将前述定理具体应用到独立同分布的S_j的无记忆源上。关键观察是，对数似然变成了独立同分布的和:

$$\log \frac{1}{P_{S^n}(S^n)} = \sum_{i=1}^{n} \underbrace{\log \frac{1}{P_S(S_i)}}_{i.i.d.}.$$

这立即暗示了几个结果：

1 根据弱大数定律（WLLN），我们知道 $\frac{1}{n}\log\frac{1}{P_{S^n}(S^n)} \xrightarrow{\mathbb{P}} \mathbb{E}\log\frac{1}{P_S(S)} = H(S)$。因此，在 (10.5) 中，极限分布 U 是退化的，即 $U = H(S)$，并且我们有以下具有根本重要性的结果：[1]

$$\frac{1}{n} l(f^*(S^n)) \xrightarrow{\mathbb{P}} H(S)\,.$$

也就是说，独立同分布过程的最优压缩率收敛于其熵率。这是香农信源编码定理的一个版本，我们将在后续章节中进一步讨论。

2 根据中心极限定理（CLT），如果变熵 $V(S) < \infty$，那么我们知道（10.6）中的 V 是高斯分布，即，

$$\frac{1}{\sqrt{nV(S)}}\left(\log\frac{1}{P_{S^n}(S^n)} - nH(S)\right) \xrightarrow{\mathrm{d}} \mathcal{N}(0,1).$$

因此，对于最优码长的概率分布，我们有以下高斯近似：

$$\frac{1}{\sqrt{nV(S)}}(l(f^*(S^n)) - nH(S)) \xrightarrow{\mathrm{d}} \mathcal{N}(0,1),$$

或者，简写为

$$l(f^*(S^n)) \approx nH(S) + \sqrt{nV(S)}\mathcal{N}(0,1) \text{ in distribution.}$$

高斯近似告诉我们收敛速度 $\frac{1}{n}l(f^*(S^n)) \to H(S)$，并且还给出了有限 n 下长度分布的良好近似。

示例 10.1（三元源）接下来，我们将我们的界应用于一个具体示例中，以近似 $l(f^*(S^n))$ 的分布。考虑一个无记忆三元源，其输出独立同分布的 n 符号，这些符号来自分布 $P_S = [0.445, 0.445, 0.11]$。我们首先在下表中比较关于最小期望长度 $\mathbb{E}[l(f^*(S^n))]$ 的不同结果：

Blocklength	Lower bound (10.3)	$\mathbb{E}[l(f^*(S^n))]$	$H(S^n)$ (upper bound)	asymptotics (10.3)
$n = 20$	21.5	24.3	27.8	$23.3 + o(1)$
$n = 100$	130.4	134.4	139.0	$133.3 + o(1)$
$n = 500$	684.1	689.2	695.0	$688.1 + o(1)$

在上述所有情况下，$\mathbb{E}[l(f^*(S))]$ 接近于边界之间的中点。

[1] Convergence to a constant in distribution is equivalent to that in probability.

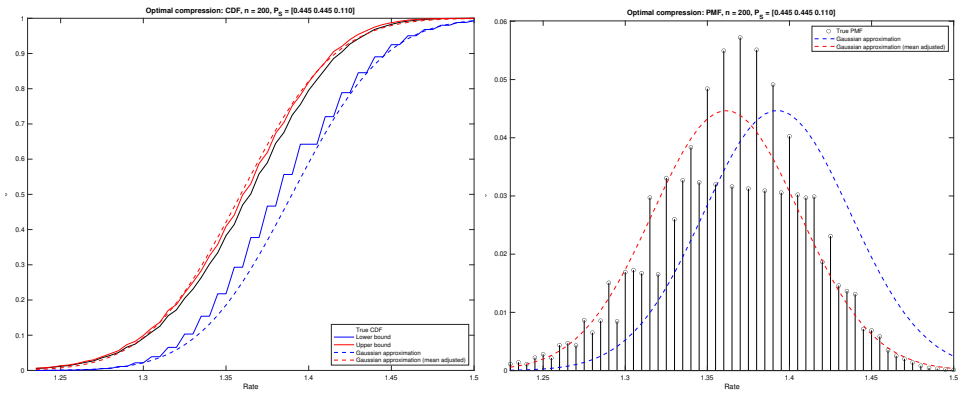


图10.2 左图：$l(f^*(S^n))$的真实CDF、定理10.4的边界（在τ上优化）以及在(10.8)和(10.9)中的高斯近似之间的比较。右图：最优压缩长度$l(f^*(S^n))$的PMF以及两种高斯近似。

接下来我们考虑 $l(f^*(S^n)$ 的分布。其高斯近似定义为

$$nH(S) + \sqrt{nV(S)}Z, \qquad Z \sim \mathcal{N}(0,1)\,. \tag{10.8}$$

然而，鉴于(10.3))，我们也将*mean-adjusted*高斯近似定义为

$$nH(S) - \frac{1}{2}\log_2(8\pi e V(S)n) + \sqrt{nV(S)}Z, \qquad Z \sim \mathcal{N}(0,1)\,. \tag{10.9}$$

图10.2比较了$l(f^*(S^n))$的真实分布与边界及两种高斯近似。

10.2 曼德博关于齐普夫（幂）定律普适性的论证

给定一个文本语料库，很自然地通过按词频的排名 $p_1 \geq p_2 \geq \cdots$ 排序来绘制其 *rank-frequency* 表。正如 Zipf [477] 所注意到的，所得的表对于某个 α 值满足 $p_r \asymp r^{-\alpha}$。值得注意的是，这在多种不同语言的各类文本语料库中都成立（并且有 $\alpha \approx 1$）——参见图 10.3 的示例。更令人惊讶的是，许多其他类似的表也具有幂律分布："城市人口、地震规模、月球陨石坑、太阳耀斑、计算机文件、战争、大多数文化中的个人姓名、科学家发表的论文数量、一篇论文收到的引用次数、网页点击量、书籍和音乐录音的销量、生物分类群中的物种数量、人们的收入"（引自 [315]，其中给出了每项研究的参考文献）。幂律这种惊人的普遍性不断促使许多学科的科学家为其出现提出解释；关于此类解释的综述见 [305]。最早的解释之一（在 Zipf 的自然语言背景下）由 Mandelbrot [291] 提出，并且实际上与本章的主题密切相关。

让我们回到源 X 表示的最小期望长度问题。我们已在定理10.3中展示了该量以 X 的熵为界的界限。让我们引入

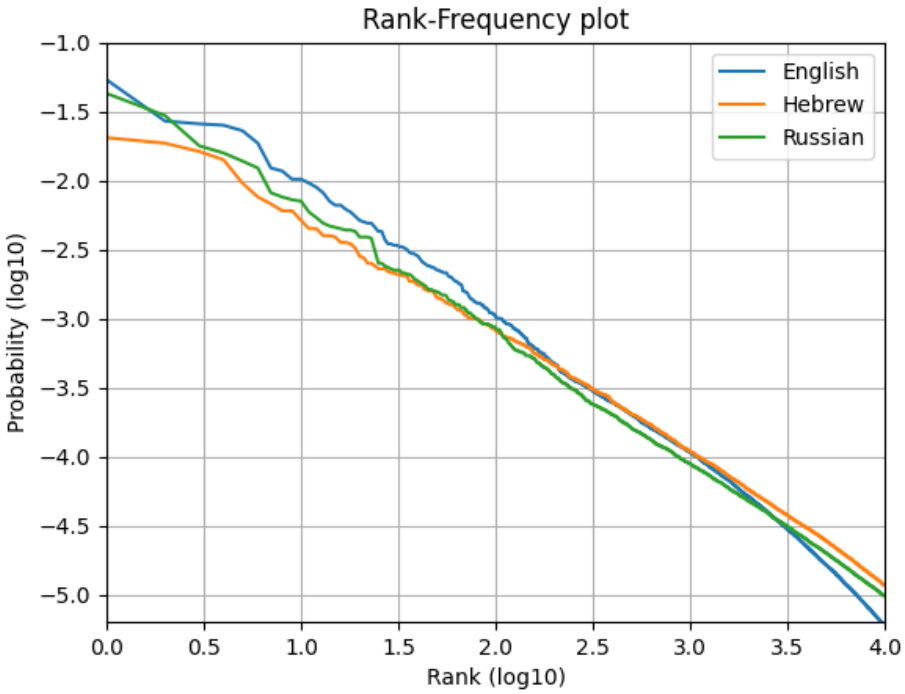


图10.3 各种语言中最常用词汇的对数-对数频率-排名图展现出幂律尾部，其指数接近1，这一现象由Zipf [477] 普及。数据来源自[398]。

以下函数

$$\mathcal{H}(\Lambda) = \sup_{f,P_X}\{H(X) : \mathbb{E}[l(f(X))] \le \Lambda\}\,,$$

其中优化是在无损编码器和概率分布 $P_X = \{p_j : j = 1, \ldots\}$ 上进行的。定理 10.3（或更准确地说，中间结果 (10.2)）表明

$$\Lambda \log 2 \le \mathcal{H}(\Lambda) \le \Lambda \log 2 + (1+\Lambda)\log(1+\Lambda) - \Lambda \log \Lambda\,.$$

事实证明，这个上界实际上是紧的。此外，在所有分布中，熵与最小压缩长度之间的最优权衡在幂律分布处达到。

为了说明这一点，请注意在计算$\mathcal{H}(\Lambda)$时，我们可以将注意力限制在排序后的PMF $p_1 \ge p_2 \ge \cdots$ (上，称之为类$\mathcal{P}^{\downarrow}$)，对于这类PMF，最优编码器满足$l(f(j)) = \lfloor \log_2 j \rfloor$ (定理10.2)。因此，我们已经证明了

$$\mathcal{H}(\Lambda) = \sup_{P \in \mathcal{P}^{\downarrow}} \{H(P) : \sum_j p_j \lfloor \log_2 j \rfloor \le \Lambda\}\,.$$

接下来，为了方便，我们将H对数的底数固定为2。（最后我们会转换为任意底数）。应用例5.2，我们得到：

$$\mathcal{H}(\Lambda) \leq \inf_{\lambda>0} \lambda\Lambda + \log_2 Z(\lambda)\,, \tag{10.10}$$

其中 $Z(\lambda) = \sum_{n=1}^{\infty} 2^{-\lambda\lfloor \log_2 n\rfloor} = \sum_{m=0}^{\infty} 2^{(1-\lambda)m} = \frac{1}{1-2^{1-\lambda}}$ 若 $\lambda > 1$，否则 $Z(\lambda) = \infty$。显然，对 $\lambda > 0$ 取下确界是在满足以下条件的值 $\lambda^* > 1$ 处取得的最小值

$$\Lambda = -\left.\frac{d}{d\lambda}\right|_{\lambda=\lambda^*} \log_2 Z(\lambda)\,.$$

定义分布

$$P_\lambda(n) \triangleq \frac{1}{Z(\lambda)} 2^{-\lambda\lfloor \log_2 n\rfloor}, \quad n \geq 1$$

并注意

$$\mathbb{E}_{P_\lambda}[\lfloor \log_2 X\rfloor] = -\frac{d}{d\lambda}\log_2 Z(\lambda) = \frac{2^{1-\lambda}}{1-2^{1-\lambda}}$$
$$H(P_\lambda) = \log_2 Z(\lambda) + \lambda\,\mathbb{E}_{P_\lambda}[\lfloor \log_2 X\rfloor]\,.$$

与（10.10）比较，我们发现（10.10）中的上界是紧致的，并由P_{λ^*}达到。从上述第一个方程，我们还发现$\lambda^* = \log_2 \frac{2+2\Lambda}{\Lambda}$。综上所述，这得出

$$\mathcal{H}(\Lambda) = \Lambda\log 2 + (\Lambda+1)\log(\Lambda+1) - \Lambda\log\Lambda\,,$$

并且极值分布 $P_{\lambda^*}(n) \asymp n^{-\lambda^*}$ 是幂律分布，其指数为 $\lambda^* \to 1$，作为 $\Lambda \to \infty$。

Mandelbrot[291]的论证 上述推导展示了幂律的一种特殊（极值）性质，但未能解释其在经验中的普遍性。以下是一种将优化问题$\mathcal{H}(\Lambda)$与自然语言演化联系起来的方法。假设存在一个可数集合$\mathcal{S}$，由基本概念组成，大脑将其用作感知和与外部世界交流的构建模块。作为近似，我们可以认为概念与语言词汇一一对应。现在，每个概念x在大脑内部被表示为某种模式，在最简单的情况下——一个长度为$l(f(x))$的零和一序列([291]考虑了更一般的表示)。现在我们已经看到，具有组成P的概念序列的数量以指数方式（在长度上）增长，其指数由$H(P)$给出，见命题1.5。因此，从长远来看，概念上的概率分布P导致信息传输速率等于$\frac{H(P)}{\mathbb{E}_P[l(f(X))]}$。Mandelbrot得出结论，为了每单位传输最大信息，
language and brain representation co-evolve in such away as to maximize this ratio。注意

$$\sup_{P,f} \frac{H(P)}{\mathbb{E}_P[l(f(X))]} = \sup_{\Lambda} \frac{\mathcal{H}(\Lambda)}{\Lambda}\,.$$

不难证明 $\mathcal{H}(\Lambda)$ 是凹的，因此上确界在 $\Lambda = 0+$ 处取得，并等于无穷大。这似乎并未被 Mandelbrot 观察到。为了解决这个问题，我们可以

假设由于某些未知的生理原因，还需要有一定的**最小熵** $H(P) \geq h_0$。在这种情况下

$$\sup_{P,f:H(P)\geq h_0} \frac{H(P)}{\mathbb{E}_P[l(f(X))]} = \frac{h_0}{\mathcal{H}^{-1}(h_0)}$$

并且在幂律分布 P 处达到最大值。因此，这意味着 *the frequency of word usage in human languages evolves until a power law is attained,* 在此时最大化大脑内部的信息传递。这就是 [291] 论证的要点。显然，这并不能解释幂律在其他领域的出现，对于这些领域，诸如优先连接模型等其它解释更为合理，参见 [305]。最后，我们提到 P_λ 分布取离散值 $2^{-\lambda m - \log_2 Z(\lambda)}, m = 0, 1, 2, \ldots$ 其中多重性为 2^m。因此，P_λ 在频率-秩图（如图 10.3）上呈现出相当不美观的阶梯状。这一人为现象可以通过考虑具有信号 *unequal lengths* 的非二值大脑表征来缓解。

10.3 唯一可译码、前缀码和霍夫曼码

在前面的章节中，我们研究了 f^*，它在所有可变长度无损压缩器中实现了随机（特别是在期望上）最短的码长。注意，f^* 是通过对概率质量函数进行排序并为更可能的符号分配更短的码字而获得的。在本节中，我们关注一类具有良好算法特性的特定压缩器，这些特性导致低复杂度的解码以及从压缩比特流中解码时的短延迟。这部分在本质上更具组合性。

我们首先给出几个定义。令 $\mathcal{A}^+ = \bigcup_{n\geq 1} \mathcal{A}^n$ 表示由字母表 $\mathcal{A}$ 中的符号组成的所有非空有限长度字符串。在本章中，$\mathcal{A}$ 是一个可数集合。

定义 10.6（码的扩展）$f: \mathcal{A} \to \{0,1\}^*$ 的（逐符号）扩展是 $f: \mathcal{A}^+ \to \{0,1\}^*$，其中 $f(a_1, \ldots, a_n) = (f(a_1), \ldots, f(a_n))$ 由比特串接定义。

定义 10.7（唯一可译码）f：$\mathcal{A} \to \{0,1\}^*$ 是 *uniquely decodable*，如果其扩展 f：$\mathcal{A}^+ \to \{0,1\}^*$ 是单射。

定义 10.8（前缀码）f：$\mathcal{A} \to \{0,1\}^*$ 是一个 *prefix code*[2]，如果没有任何码字是另一个码字的前缀（例如，010 是 0101 的前缀）。

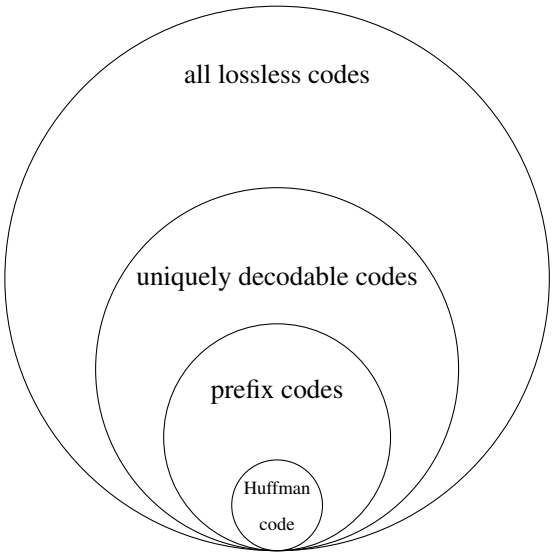
示例 10.2 $\mathcal{A} = \{a, b, c\}$。

[2] Also known as prefix-free/comma-free/self-punctuating/instantaneous code.

• $f(a) = 0, f(b) = 1, f(c) = 10$. 不唯一可解码，因为$f(ba) = f(c) = 10$. • $f(a) = 0, f(b) = 10$,$f(c) = 11$. 唯一可解码且为前缀码。 • $f(a) = 0, f(b) = 01, f(c) = 011, f(d) = 0111$ 唯一可解码但非前缀码，因为一旦出现0，我们就知道前一个码字已经结束。[3]

备注 10.3

1 前缀码是唯一可解码的，因此是无损的，如下图所示:



2 类似于无前缀码，可以定义无后缀码。它们也是唯一可解码的（应当从相反方向开始解码）。3 根据定义，任何唯一可解码的码都不以空字符串作为码字。因此，在定义10.7和定义10.8中，均有$f: \mathcal{X} \to \{0,1\}^+$。4 唯一可解码意味着可以从比特流中无歧义地解码，但可能需要向前看以确定码字的终止。（想想最后一个例子）。相比之下，前缀码允许解码器无需前瞻即可即时解码。5 前缀码与二叉树（码字位于叶节点）一一对应。它也等价于之前在1.1节末尾提到的询问“是/否”问题的策略。

定理 10.9（Kraft-McMillan）

3 在这个例子中，如果将0置于每个码字的末尾，该编码是唯一可解码的，称为*unary code*。

1 Let $f : \mathcal{A} \to \{0,1\}^*$ be uniquely decodable. Set $l_a = l(f(a))$. Then f satisfies the 克拉夫特不等式

$$\sum_{a\in\mathcal{A}} 2^{-l_a} \le 1. \tag{10.11}$$

2 Conversely, for any set of code length $\{l_a : a \in \mathcal{A}\}$ satisfying (10.11), there exists a prefix code f, such that $l_a = l(f(a))$. Moreover, such an f can be computed efficiently.

备注10.4 定理10.9的结果表明，就压缩效率而言，我们可以忽略那些非前缀码的唯一可解码。

Proof. 我们分别证明前缀码和唯一可译码的Kraft不等式。前者的证明是概率性的，遵循[15, 练习1.8, 第12页]中的思路。设f为一个前缀码。我们构造一个概率空间，使得(10.11)的左侧是某个事件的概率，该概率不能超过1。为此，考虑以下场景：生成独立的Ber($\frac{1}{2}$)比特。如果已经写出了一个码字，则停止，否则继续。该过程以概率$\sum_{a\in\mathcal{A}} 2^{-l_a}$终止。求和是有意义的，因为给定码字被写出的事件是互斥的，这得益于前缀条件。

现在令f为一个唯一可译码。该证明使用 *generating function* 作为计数的工具。（编码理论中的类比是重量枚举函数。）首先假设 $\mathcal{A}$ 是有限的。那么 $L = \max_{a\in\mathcal{A}} l_a$ 是有限的。令 $G_f(z) = \sum_{a\in\mathcal{A}} z^{l_a} = \sum_{l=0}^{L} A_l(f) z^l$，其中 $A_l(f)$ 表示 f 中长度为 l 的码字数量。对于 $k \ge 1$，定义 f^k：$\mathcal{A}^k \to \{0,1\}^+$ 为 f 的逐符号扩展。那么 $G_{f^k}(z) = \sum_{a^k\in\mathcal{A}^k} z^{l(f^k(a^k))} = \sum_{a_1}\cdots\sum_{a_k} z^{l_{a_1}+\cdots+l_{a_k}} = [G_f(z)]^k = \sum_{l=0}^{kL} A_l(f^k) z^l$。由 f 的唯一可译性，f^k 是无损的。因此 $A_l(f^k) \le 2^l$。所以我们有 $G_f(1/2)^k = G_{f^k}(1/2) \le kL$ 对所有 k 成立。那么 $\sum_{a\in\mathcal{A}} 2^{-l_a} = G_f(1/2) \le \lim_{k\to\infty}(kL)^{1/k} = 1$。如果 $\mathcal{A}$ 是可数无限的，对于任意有限子集 $\mathcal{A}' \subset \mathcal{A}$，重复相同的论证得到 $\sum_{a\in\mathcal{A}'} 2^{-l_a} \le 1$。由 $\mathcal{A}'$ 的任意性，证明完成。

相反，给定一组码长 $\{l_a :\ a \in \mathcal{A}\}$ 使得 $\sum_{a\in\mathcal{A}} 2^{-l_a} \le 1$，按如下方式构造前缀码 f：首先将 $\mathcal{A}$ 重新标记为 $\mathbb{N}$，并假设 $1 \le l_1 \le l_2 \le \ldots$。对于每个 i，定义

$$a_i \triangleq \sum_{k=1}^{i-1} 2^{-l_k}$$

其中 $a_1 = 0$。然后根据Kraft不等式，$a_i < 1$。因此，我们定义码字 $f(i) \in \{0,1\}^+$ 为 a_i 的二进制展开中的前 l_i 位。最后，我们通过反证法证明 f 是前缀码：假设对于某个 $j > i$，$f(i)$ 是 $f(j)$ 的前缀，因为 $l_j \ge l_i$。那么 $a_j - a_i \le 2^{-l_i}$，因为它们在最高有效的 l_i 位上一致。但 $a_j - a_i = 2^{-l_i} + 2^{-l_{i+1}} + \ldots > 2^{-l_i}$，这是一个矛盾。 □

注 10.5 Ahlswede 等人 [7] 的一个猜想指出，对于任意一组长度，若 $\sum 2^{-l_a} \le \frac{3}{4}$，则存在一个固定自由码（即同时为前缀自由和后缀自由的码）。迄今为止，仅在 Kraft 和为 $\le \frac{5}{8}$ 时证明了其存在性，参见 [466]。

鉴于定理 10.9，所有前缀码（或唯一可解码码）中的最优平均码长由以下优化问题给出

$$\begin{aligned} L^*(X) \triangleq \min \ & \sum_{a\in\mathcal{A}} P_X(a) l_a \\ \text{s.t.} \ & \sum_{a\in\mathcal{A}} 2^{-l_a} \le 1 \\ & l_a \in \mathbb{N} \end{aligned} \tag{10.12}$$

这是一个 *integer programming* (IP) 问题，通常计算上难以求解。值得注意的是，得益于霍夫曼算法，这个特定的IP可以在 *near-linear* 时间内解决。在描述霍夫曼码的构造之前，让我们用熵来给出 $L^*(X)$ 的界：

定理 10.10

$$H(X) \le L^*(X) \le H(X) + 1 \,\texttt{bit}. \tag{10.13}$$

Proof. 右不等式：考虑以下长度分配 $l_a = \lceil \log_2 \frac{1}{P_X(a)} \rceil$，[4]，它满足Kraft不等式，因为 $\sum_{a\in\mathcal{A}} 2^{-l_a} \le \sum_{a\in\mathcal{A}} P_X(a) = 1$。根据定理10.9，存在一个前缀码 f，使得 $l(f(a)) = \left\lceil \log_2 \frac{1}{P_X(a)} \right\rceil$ 和 $\mathbb{E}l(f(X)) \le H(X) + 1$。

轻不等式：我们给出这个逆命题的两种证明。处理组合优化常用的一种思路是 *relaxation*。我们的第一个思路是去掉 (10.12) 中的整数约束，并将其松弛为如下优化问题，这显然给出一个下界

$$\begin{aligned} L^*(X) \triangleq \min \ & \sum_{a\in\mathcal{A}} P_X(a) l_a \\ \text{s.t.} \ & \sum_{a\in\mathcal{A}} 2^{-l_a} \le 1 \end{aligned} \tag{10.14}$$

这是一个很好的 *convex optimization* 问题，具有仿射目标函数和凸可行集。通过拉格朗日乘子法求解（10.14）（习题！）可得，最小值等于 $H(X)$ (，在 $l_a = \log_2 \frac{1}{P_X(a)}$处取得。

另一个证明如下：对于任何码长 $\{l_a\}$ 满足 Kraft 不等式的 f，定义概率测度 $Q(a) = \frac{2^{-l_a}}{\sum_{a\in\mathcal{A}} 2^{-l_a}}$。那么

$$\mathbb{E}l(f(X)) - H(X) = D(P\|Q) - \log \sum_{a\in\mathcal{A}} 2^{-l_a} \ge 0.$$

□

[4] Such a code is called a Shannon code.

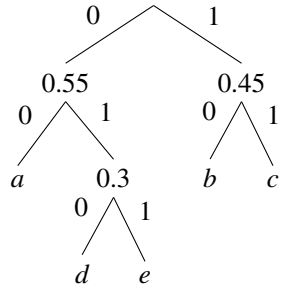
接下来我们描述霍夫曼编码，它在(10.12)中达到最优。鉴于前缀码和二叉树是一一对应的，霍夫曼编码的主要思想是自底向上构建二叉树：给定一个概率质量函数 $\{P_X(a): a \in \mathcal{A}\}$，

1 在字母表中选择两个概率最小的符号。2 删除这两个符号并添加一个新符号（其概率为两者之和）。在二叉树中，将新符号添加为前两个符号的父节点。

该算法在$|\mathcal{A}| - 1$步内终止。给定二叉树，通过为分支分配0/1可以获得代码分配。因此时间复杂度为$O(|\mathcal{A}|)$ (排序的PMF)或$O(|\mathcal{A}| \log |\mathcal{A}|)$ (未排序的PMF)。

示例 10.3 $\mathcal{A} = \{a, b, c, d, e\}, P_X = \{0.25, 0.25, 0.2, 0.15, 0.15\}$。

霍夫曼树：



Codebook:

$f(a) = 00$

$f(b) = 10$

$f(c) = 11$

$f(d) = 010$

$f(e) = 011$

定理 10.11（哈夫曼码的最优性）*The Huffman code achieves the minimal average code length (10.12) among all prefix (or uniquely decodable) codes.*

Proof. 参见[106，第5.8节]。 □

备注10.6（霍夫曼编码的缺点）

1 构建霍夫曼码需要知道信源分布。这带来了一个问题：是否有可能设计一种通用压缩器，能为一类信源分布达到熵？代价是什么？这些问题正是通用压缩的主题，将在第13章中讨论。

2 为了理解霍夫曼编码的主要局限性，我们回顾一下（正如香农所指出的），虽然摩尔斯电码已经利用了英文字母的非等概率性，但处理字母对（或更一般地，n元组）可以实现更高的压缩率，因为一对中的字母并非独立。换句话说，通过逐符号应用霍夫曼编码来压缩一个符号块$(S_1, \ldots, S_n)$，可以实现平均长度为$\sum_{i=1}^n H(S_i) + n$比特。但是，对整个块$(S_1, \ldots, S_n)$应用霍夫曼编码，即为$P_{S_1,\ldots,S_n}$设计的编码，可以利用信源中的记忆性并实现压缩长度$H(S_1, \ldots, S_n) + O(1)$。由于(1.3)，联合熵小于$\sum_i H(S_i)$ (，并且

通常*much*较小）。然而，这个想法的缺点在于构建霍夫曼码的复杂度为$|\mathcal{A}|^n$——随块长度呈指数增长。

为了解决这些问题，我们稍后将研究其他方法：

1 算术编码具有一种复杂度与块长度成线性的顺序编码算法，同时仍能达到$H(S_1^n)$长度——第13.1节。
2 Lempel-Ziv算法也具有低复杂度，甚至具有普适性，对于所有遍历源均可证明为最优——第13.8节。

作为本章的总结，我们了解了熵与各种编码压缩长度之间的以下关系：

$$H(X) - \log_2[e(H(X)+1)] \le \mathbb{E}[l(f^*(X))] \le H(X) \le \mathbb{E}[l(f_{\text{Huffman}}(X))] \le H(X)+1.$$

11 定长压缩与Slepian-Wolf定理

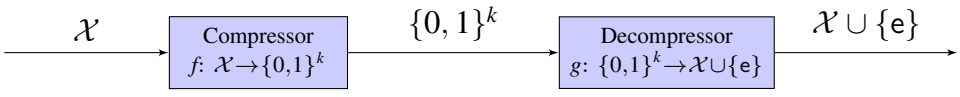
在前一章中，我们介绍了可变长压缩的概念，并研究了其在前缀无关条件下的基本限制。然而，在某些情况下，人们可能希望压缩器的输出总是固定长度，比如 k 比特。除非 k 大得不合理，否则这将需要放宽无损条件。这就是本章的重点：在存在（通常极小的）错误概率下的压缩。事实证明，即使允许非常小的错误，也能带来几种美妙的效果：

• 通过有限域上的矩阵乘法压缩数据的可能性（线性压缩或*hashing*）。• 如果在解压器处有边信息Y可用，则将压缩长度从$H(X)$减少到$H(X|Y)$的可能性（Slepian-Wolf）。• 如果在解压器处可访问边信息Y的压缩表示，则将压缩长度减少到$H(X)$以下的可能性（Ahlswede-Körner-Wyner）。

所有这些效应最终都基于许多高维概率分布的基本性质——渐近均分性（AEP），我们在独立同分布（iid）的背景下研究它。稍后，在第12章中，我们将这一性质扩展到所有遍历过程。

11.1 信源编码定理

本节中的编码范式如下所示：



注意，如果像第10章那样坚持$g(f(X)) = X$以概率一成立，那么$k \geq \log_2 |\mathrm{supp}(P_X)|$，就无法实现任何有意义的压缩。事实证明，通过容忍一个小的错误概率，我们可以在码长方面获得很大收益！因此，不是要求对所有$x \in \mathcal{X}$都有$g(f(x)) = x$，而只考虑对子集$\mathcal{S} \subset \mathcal{X}$的无损解压：

$$g(f(x)) = \begin{cases} x & x \in \mathcal{S} \\ \mathsf{e} & x \notin \mathcal{S} \end{cases}$$

错误概率为:

$$\mathbb{P}[g(f(X)) \neq X] = \mathbb{P}[g(f(X)) = \mathsf{e}] = \mathbb{P}[X \notin \mathcal{S}].$$

我们接下来正式总结这一点。

定义11.1 若一对压缩器-解压器(f,g)被称为$X \in \mathcal{X}$的固定长度几乎无损(k,ϵ)源代码，或简称(k,ϵ)-码，当满足以下条件:

$$f : \mathcal{X} \to \{0,1\}^k$$
$$g : \{0,1\}^k \to \mathcal{X} \cup \{\mathsf{e}\}$$

使得对于所有 $x \in \mathcal{X}$ 和 $\mathbb{P}[g(f(X)) = \mathsf{e}] \leq \epsilon$，有 $g(f(x)) \in \{x, \mathsf{e}\}$。固定长度压缩的基本极限就是最小错误概率，定义为

$$\epsilon^*(X,k) \triangleq \inf\{\epsilon : \exists (k,\epsilon)\text{-code for } X\}.$$

以下结果将固定长度几乎无损压缩和可变长度无损压缩的各自基本极限联系起来（第10.1节）:

定理 11.2（固定长度压缩的基本极限）*Recall the optimal variable-length compressor f^* defined in Theorem 10.2 and assume as before that $\mathcal{X} = \mathbb{N}$ and $P_X(1) \geq P_X(2) \geq \cdots$. Then*

$$\epsilon^*(X,k) = \mathbb{P}[l(f^*(X)) \geq k] = \sum_{x \geq 2^k} P_X(x).$$

Proof. 注意，由于假设 $\mathcal{X} = \mathbb{N}$，压缩器必须为错误消息保留一个 k 位字符串，即使 $P_X(1) = 1$。该证明本质上是同义反复。注意 $1+2+\cdots+2^{k-1} = 2^k - 1$。令 $\mathcal{S}$ 为最可能的 $2^k - 1$ 个（由 $P_X(x)$ 度量）元素 $x \in \mathcal{X}$ 的集合。则

$$\epsilon^*(X,k) = \mathbb{P}[X \notin \mathcal{S}] = \mathbb{P}[l(f^*(X)) \geq k].$$

最后一个等式由 (10.1) 得出。 □

比较定理10.2和11.2，我们可以看到这两种设置下的最优编码工作方式如下:

• 变长: f^* 将具有最高概率的 $2^k - 1$ 个符号编码为 $\{\phi, 0, 1, 00, \ldots, 1^{k-1}\}$。• 定长: 最优压缩器 f 将 $\mathcal{S}$ 中的元素映射为 $(00\ldots00), \ldots, (11\ldots10)$，其余元素在 $\mathcal{X}\backslash\mathcal{S}$ 中映射为 $(11\ldots11)$。解压器 g 能够完美解码，除非在接收到 $(11\ldots11)$ 时输出 e。

备注 11.1（可检测与不可检测错误） 在定义 11.1 中，我们要求错误始终为 *detectable*，即 $g(f(x)) = x$ 或 e。或者，我们可以放弃这一要求并允许 *undetectable* 错误，在这种情况下，由于我们有更多

在设计代码时的自由度。事实证明，这种放宽并没有给我们带来太多好处。实际上，如果我们定义

$$\tilde{\epsilon}^*(X,k) = \inf\{\mathbb{P}[g(f(X)) \neq X] : f : \mathcal{X} \to \{0,1\}^k, g : \{0,1\}^k \to \mathcal{X} \cup \{\mathsf{e}\}\},$$

然后 $\tilde{\epsilon}^*(X,k) = \sum_{x>2^k} P_X(x)$。这直接来自 $\mathbb{P}[g(f(X)) = X] = \sum_{x\in\mathcal{S}} P_X(x)$，其中 $\mathcal{S} \triangleq \{x : g(f(x)) = x\}$ 满足 $|\mathcal{S}| \le 2^k$，因为 f 取值不超过 2^k 个。与定理 11.2 相比，我们看到 $\tilde{\epsilon}^*(X,k)$ 和 $\epsilon^*(X,k)$ 仅相差 $P_X(2^k) \le 2^{-k}$。特别地，$\epsilon^*(X,k+1) \le \tilde{\epsilon}^*(X,k) \le \epsilon^*(X,k)$，并且在压缩字符串中我们最多只能节省一个比特。

这些简单的观察引导我们得出香农的第一个基本结果。

推论 11.3（香农信源编码定理）*Let S^n be i.i.d. discrete random variables. Then for any $R > 0$ and $\gamma \in \mathbb{R}$ asymptotically in blocklength n we have*

$$\lim_{n\to\infty} \epsilon^*(S^n, nR) = \begin{cases} 0 & R > H(S) \\ 1 & R < H(S) \end{cases}$$

If varentropy $V(S) < \infty$ then also

$$\lim_{n\to\infty} \epsilon^*(S^n, nH(S) + \sqrt{nV(S)}\gamma) = Q(\gamma)$$

where $Q(x) = \int_x^\infty \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt$ is the complementary CDF of $\mathcal{N}(0,1)$s.

Proof. 将定理11.2与推论10.5结合。 □

该结果表明，若要将独立同分布字符串 S^n 压缩至 $k = k(n)$ 比特，则使误差趋于零的最小可能 k 满足 $\frac{k}{n} = H(S)$，也就是说，我们可以将该独立同分布过程压缩到熵率 $\mathbb{S}$，而不能再低。此外，如果允许非零误差 ϵ，则压缩可低至

$$k = nH(S) + \sqrt{nV(S)}Q^{-1}(\epsilon)$$

比特。用现代信息论的语言来说，推论11.3既导出了渐近基本极限（最小k/n），也导出了在非消失误差条件下的*normal approximation*。

在理解渐近性之后，下一步是推导有限块长度保证，即用信息量表示对 $\epsilon^*(X,k)$ 的界。正如我们上面提到的，上界和下界通常分别称为可达性和逆定理界。在无损压缩的情况下，这样的界是定理 11.2 的相当平凡的推论，但为了完整性，我们接下来给出它们。对于本部分和其他部分中的其他问题，获得良好的有限块长度界要困难得多。

定理 11.4（有限块长度界限）*For all $\tau > 0$ and all $k \in \mathbb{Z}_+$ we have*

$$\mathbb{P}\left[\log_2 \frac{1}{P_X(X)} > k + \tau\right] - 2^{-\tau} \le \tilde{\epsilon}^*(X,k) \le \epsilon^*(X,k) \le \mathbb{P}\left[\log_2 \frac{1}{P_X(X)} \ge k\right].$$

Proof. 下界（逆）界的论证与定理10.4的逆命题相同。实际上，考虑最优（不可检测错误）码，令 $\mathcal{S} = \{x : g(f(x)) = x\}$，并注意

$$1 - \tilde{\epsilon}^*(X,k) = \mathbb{P}[X \in \mathcal{S}] \le \mathbb{P}\left[\log_2 \frac{1}{P_X(X)} \le k + \tau\right] + \mathbb{P}\left[X \in \mathcal{S}, \log_2 \frac{1}{P_X(X)} > k + \tau\right]$$

. 对于第二项，我们有

$$\mathbb{P}\left[X \in \mathcal{S}, \log_2 \frac{1}{P_X(X)} > k + \tau\right] = \sum_{x \in S} P_X(x) 1\{P_X(x) < 2^{-k-\tau}\} \le |\mathcal{S}| 2^{-k-\tau} \le 2^{-\tau},$$

其中我们使用了事实$|\mathcal{S}| \le 2^k$。结合这两个不等式得出下界。

对于上界，不失一般性，我们假设 $P_X(1) \ge P_X(2) \ge \cdots$。那么根据定理11.2，我们有

$$\epsilon^*(X,k) = \sum_{m \ge 2^k} P_X(m) \le \sum 1\left\{\frac{1}{P_X(m)} \ge 2^k\right\} P_X(m) = \mathbb{P}\left[\log_2 \frac{1}{P_X(X)} \ge k\right],$$

其中 $\le$ 由此事实得出：m^{th} 最大质量 $P_X(m) \le \frac{1}{m}$。 □

我们现在要做一些奇怪的事情。我们将证明一个比定理11.4更弱的上界，而且，证明过程要长得多。然而，这将是我们首次接触*random coding* (也被称为信息论之外的概型方法)的技术。[1]我们很快就会发现，在无损压缩的最简单设置之外，最优编码器f^*容易描述，而好的编码器却很难找到，因此随机编码变得不可或缺。特别是，Slepian-Wolf定理（下文第11.5节）、所有数据传输（第四部分）和有损数据压缩（第五部分）都将基于这种方法。

定理 11.5（随机编码可达性）*For any $k \in \mathbb{Z}_+$ and any $\tau > 0$ we have*

$$\tilde{\epsilon}^*(X,k) \le \mathbb{P}\left[\log_2 \frac{1}{P_X(X)} > k - \tau\right] + 2^{-\tau}, \quad \forall \tau > 0, \tag{11.1}$$

that is there exists a compressor-decompressor pair with the (possibly undetectable) error bounded by the right-hand side.

Proof. 我们首先从为给定的 f 构造一个次优解压器 g 开始。实际上，对于给定的压缩器 f ，最小化错误概率的最优解压器就是最大后验（MAP）解码器，即，

$$g^*(w) = \operatorname*{argmax}_x P_{X|f(X)}(x|w) = \operatorname*{argmax}_{x:f(x)=w} P_X(x).$$

1 这些方法分别由Shannon [378]和Erdös [153]同时发现。

然而，这个解码器的性能有点难以分析，因此，我们转而考虑以下（次优的）解压缩器 g：

$$g(w) = \begin{cases} x, & \exists!\, x \in \mathcal{X} \text{ s.t. } f(x) = w \text{ and } \log_2 \frac{1}{P_X(x)} \le k - \tau, \\ & \text{(exists unique high-probability } x \text{ that is mapped to } w) \\ \mathsf{e}, & \text{otherwise} \end{cases}$$

注意 $\log_2 \frac{1}{P_X(x)} \le k - \tau \iff P_X(x) \ge 2^{-(k-\tau)}$。我们将那些 x 称为“高概率”。（在 [106] 和 [115] 的术语中，这些被称为“典型”实现）。

记 $f(x) = c_x$，并将长向量 $\mathcal{C} = [c_x : x \in \mathcal{X}]$ 称为码本。将 $\mathcal{C}$ 视为哈希表是有启发性的：它接收一个对象 $x \in \mathcal{X}$ 并为其分配一个 k 位的哈希值。

为了分析错误概率，让我们定义

$$J(x, \mathcal{C}) \triangleq \left\{ x' \in \mathcal{X} : c_{x'} = c_x, x' \ne x, \log_2 \frac{1}{P_X(x')} \le k - \tau \right\}$$

为高概率输入集合，其哈希值与 x 的哈希值发生碰撞。于是我们得到以下错误概率估计：

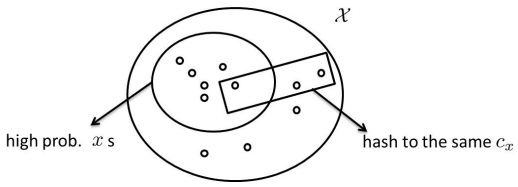
$$\begin{aligned} \mathbb{P}\left[g(f(X)) = \mathsf{e}\right] &= \mathbb{P}\left[\left\{\log_2 \frac{1}{P_X(X)} > k - \tau\right\} \cup \{J(X, \mathcal{C}) \ne \emptyset\}\right] \\ &\le \mathbb{P}\left[\log_2 \frac{1}{P_X(X)} > k - \tau\right] + \mathbb{P}\left[J(X, \mathcal{C}) \ne \phi\right] \end{aligned}$$

第一项不依赖于码本 $\mathcal{C}$，而第二项则依赖。现在的想法是对 $\mathcal{C}$ 进行随机化，并证明当对所有可能的码本选择取平均时，第二项小于 $2^{-\tau}$。因此，至少存在一个码本能达到所需的界。具体来说，让我们考虑通过将每个 $c_x \overset{\text{i.i.d.}}{\sim}$ 设为 $\text{Unif}[\{0,1\}^k]$ 且独立于 X 生成的 $\mathcal{C}$。等价地，由于 $\mathcal{C}$ 可以用一个 $|\mathcal{X}| \times k$ 二进制矩阵表示，其行对应码字，我们选择每个元素为独立的公平硬币投掷。对错误概率取平均（关于 $\mathcal{C}$ 和 X），我们有

$$\begin{aligned} \mathbb{E}_{\mathcal{C}}[\mathbb{P}\left[J(X, \mathcal{C}) \ne \phi\right]] &= \mathbb{E}_{\mathcal{C},X}\left[1\left\{\exists x' \ne X : \log_2 \frac{1}{P_X(x')} \le k - \tau, c_{x'} = c_X\right\}\right] \\ &\le \mathbb{E}_{\mathcal{C},X}\left[\sum_{x' \ne X} 1\left\{\log_2 \frac{1}{P_X(x')} \le k - \tau\right\} 1\left\{c_{x'} = c_X\right\}\right] \qquad \text{(联合界)} \\ &= 2^{-k}\mathbb{E}_X\left[\sum_{x' \ne X} 1\left\{P_X(x') \ge 2^{-k+\tau}\right\}\right] \\ &\le 2^{-k}\sum_{x' \in \mathcal{X}} 1\left\{P_X(x') \ge 2^{-k+\tau}\right\} \\ &\le 2^{-k}2^{k-\tau} = 2^{-\tau}, \end{aligned}$$

其中关键的倒数第二步利用了这样一个事实：最多存在 $2^{k-\tau}$ 个 x' 值满足 $P_X(x') > 2^{-k+\tau}$。 □

备注11.2（为何随机编码有效）压缩器$f(x) = c_x$可视为将$x \in \mathcal{X}$哈希为一个随机的k位字符串$c_x \in \{0,1\}^k$，如下图所示：



这里，x具有高概率$\Leftrightarrow \log_2 \frac{1}{P_X(x)} \le k - \tau \Leftrightarrow P_X(x) \ge 2^{-k+\tau}$。因此，那些高概率$x$的数量最多为$2^{k-\tau}$，这远小于$2^k$，即$k$位码字的总数。因此，高概率$x$之间发生碰撞的机会很小。

让我们再次强调，随机编码论证的本质如下。为了证明具有某种性质的物体的存在性，我们构造一个概率分布（随机化）并证明该性质平均而言是满足的。因此，至少存在一个具有所需性质的实现。这种论证的缺点是它不是构造性的，即它没有给我们找到该物体的算法。人们可能会想，我们是否能够实际地简单生成一个大的随机哈希表并将其用于压缩。问题在于，生成这样的表需要大量的随机性和大量的存储空间（两者都是重要的资源）。我们将在第11.3节中讨论这个问题，但就目前而言，让我们作出以下评论。

备注 11.3（码字的成对独立性）在证明中，我们选择随机码本为所有可能码本上的均匀分布：$c_x \overset{\text{i.i.d.}}{\sim} \text{Unif}$。但仔细检查（习题！）表明，我们只使用了成对独立性，即对于任意 $x \neq x'$，有 $c_x \perp\!\!\!\perp c_{x'}$。这表明，在生成该表时，我们或许可以使用远少于 $k|\mathcal{X}|$ 个随机比特。事实上，给定 2 个独立的随机比特 B_1, B_2，我们可以生成 3 个两两独立的比特：$B_1, B_2, B_1 \oplus B_2$。这一观察将引导我们进入第 11.3 节研究的线性压缩思想，其中码字不是独立同分布生成的，而是作为随机线性子空间的元素生成的。

11.2 渐近均分性质（AEP）

最后，我们探讨以下问题。我们的随机编码证明仅关注那些具有足够高概率$P_X(x) > 2^{-k+\tau}$的x。但事实证明，对于独立同分布源，我们本可以仅关注所谓的“典型”x。

命题 11.6（渐近均分性质 (AEP)）*Consider iid S^n and for any $\delta > 0$, define the so-called entropy δ-typical set*

$$T_n^\delta \triangleq \left\{ s^n : \left| \frac{1}{n} \log \frac{1}{P_{S^n}(s^n)} - H(S) \right| \le \delta \right\}.$$

Then the following properties hold:

1 $\mathbb{P}\left[S^n \in T_n^\delta\right] \to 1$ *as* $n \to \infty$. $\exp\{(H(S)+\delta)n\}$.
2 $|T_n^\delta| \leq$

例如，如果 $S^n \overset{\text{i.i.d.}}{\sim} \text{Ber}(p)$，那么 $P_{S^n}(s^n) = p^{w_{\text{H}}(s^n)}\bar{p}^{n-w_{\text{H}}(s^n)}$，其中 $w_{\text{H}}(s^n)$ 是字符串的汉明重量（1的个数）。因此，典型集对应于那些汉明重量 $\frac{1}{n}w_{\text{H}}(s^n)$ 接近 $p + O_p(\delta)$ 期望值的序列。

Proof. 根据弱大数定律，我们有

$$\frac{1}{n}\log\frac{1}{P_{S^n}(S^n)} \xrightarrow{\mathbb{P}} H(S). \tag{11.2}$$

因此，$\mathbb{P}[S^n \in T_n^\delta] \to 1$。另一方面，由于对于每个 $s^n \in T_n^\delta$，我们有 $P_{S^n}(s^n) > \exp\{-(H(S)+\delta)n\}$，因此 T_n^δ 中最多有 $\exp\{(H(S)+\delta)n\}$ 个元素。 □

要理解AEP的含义，请注意它表明巨大的空间$\mathcal{S}^n$几乎所有的概率P_{S^n}都集中在一个指数级更小的子集T_n^δ上。此外，在这个子集上，测度P_{S^n}近似均匀：$P_{S^n}(s^n) = \exp\{-nH(S) \pm n\delta\}$。

为了了解AEP与压缩的关系，让我们给出香农结果的第三个证明：

$$\lim_{n\to\infty} \epsilon^*(S^n, nR) = \begin{cases} 0 & R > H(S) \\ 1 & R < H(S) \end{cases}$$

确实，让我们考虑一个编码器 f，它枚举（通过 $\{0,1\}^{nR}$ 中的字符串）T_n^δ 的元素。那么，如果 $R > H(S) + \delta$ 解码错误发生的概率为 $\mathbb{P}[S^n \notin T_n^\delta] \to 0$。因此，任何速率 $R > H(S)$ 都会导致错误消失。另一方面，如果 $R < H(S)$，那么显然 2^{nR} 比特无法描述 $|T_n^\delta|$ 的任何显著部分，并且由于在其上测度 P_{S^n} 几乎是均匀的，错误概率必然收敛到 1（事实上是指数级快速）。这种证明信源编码定理的方式具有某种概念上的美感。例如，它解释了为什么最优压缩器的输出应该看起来几乎像 iid Ber(1/2)：[2] 毕竟它是在一个几乎均匀的集合 T_n^δ 上枚举。

11.3 线性压缩（哈希）

到目前为止，我们已经看到了香农定理（推论11.3）的三个证明，但不幸的是，每个证明所使用的方法在实践中都无法实现。第一种方法需要对输入数据块的所有$|\mathcal{S}|^n$种实现进行排序，第二种方法需要构建一个$|\mathcal{S}|^n \times k$哈希表，第三种方法则需要枚举熵典型集$|T_n^\delta| = \exp\{nH(S) + o(n)\}$。在本节中，我们将展示第四种方法，它在概念上很重要，并且还能得到一个非常简单的压缩器。（我们描述的解压缩器仍然会非常不实用，但可以通过利用线性纠错码的高效解码器来使其变得实用。）

[2] This is the intuitive basis why compressors can be used as random number generators; cf. Section 9.3.

在本节中，我们假设源的形式为 $X = S^n$，其中每个坐标都是有限域（伽罗瓦域）的元素，即 $S_i \in \mathbb{F}_q$，其中 q 是 $\mathbb{F}_q$ 的基数。（这只有在对于某个素数 p 和 $k \in \mathbb{N}$，有 $q = p^k$ 时才可能。）

定义 11.7（伽罗瓦域）F 是一个有限集合，其运算为 $(+, \cdot)$，其中

• 加法运算 $+$ 是可结合且可交换的。• 乘法运算 $\cdot$ 是可结合且可交换的。• 存在元素 $0, 1 \in F$ 使得 $0 + a = 1 \cdot a = a$。• $\forall a, \exists -a$，使得 $a + (-a) = 0$ • $\forall a \neq 0, \exists a^{-1}$，使得 $a^{-1}a = 1$ • 分配律：$a \cdot (b + c) = (a \cdot b) + (a \cdot c)$

有限域的简单例子：

• $\mathbb{F}_p = \mathbb{Z}/p\mathbb{Z}$，其中 p 是素数（“模 p 算术”）• $\mathbb{F}_4 = \{0, 1, x, x+1\}$，加法和乘法作为 $\mathbb{F}_2[x]$ 中的多项式，模 $x^2 + x + 1$。

线性压缩机是一个线性函数 $H : \mathbb{F}_q^n \to \mathbb{F}_q^k$ (由矩阵 $H \in \mathbb{F}_q^{k \times n}$)表示，它将每个 $x \in \mathbb{F}_q^n$ 映射到其码字 $w = Hx$，即

$$\begin{bmatrix} w_1 \\ \vdots \\ w_k \end{bmatrix} = \begin{bmatrix} h_{11} & \dots & h_{1n} \\ \vdots & & \vdots \\ h_{k1} & \dots & h_{kn} \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}$$

如果$k < n$，即H是一个胖矩阵，那么就能实现压缩，但这同样仅在几乎无损的意义下才可能。

定理 11.8（通过线性码的可实现性）*Let $X \in \mathbb{F}_q^n$ be a random vector. For all $\tau > 0$, there exists a linear compressor $H \in \mathbb{F}_q^{n \times k}$ and decompressor g: $\mathbb{F}_q^k \to \mathbb{F}_q^n \cup \{\mathsf{e}\}$, s.t. its undetectable error probability is bounded by*

$$\mathbb{P}[g(HX) \neq X] \leq \mathbb{P}\left[\log_q \frac{1}{P_X(X)} > k - \tau\right] + q^{-\tau}.$$

注11.4 考虑汉明空间 $q = 2$。与香农随机编码可达性相比，后者使用 $k2^n$ 比特构建一个完全随机的码本，在这里对于线性码，我们需要 kn 比特来随机生成矩阵 H，而码本是汉明空间的一个 k 维线性子空间。

Proof. 修改 τ。正如香农随机编码定理（定理11.5）的证明中所指出的，给定压缩器 H，最优解压器是MAP解码器，即 $g(w) = \operatorname{argmax}_{x:Hx=w} P_X(x)$，它输出与码字兼容的最可能符号

收到。相反，如前所述，我们考虑以下（次优）解码器：

$$g(w) = \begin{cases} x & \exists! x \in \mathbb{F}_q^n : w = Hx,\ x \text{ h.p.} \\ \mathsf{e} & \text{otherwise} \end{cases}$$

其中，正如在定理11.5的证明中那样，只要$\log_q \frac{1}{P_X(x)} \le k - \tau$，我们就将$x$表示为“h.p.”（高概率）。

请注意，此解码器与定理11.5证明中的相同。证明过程也大体相同，只是现在哈希碰撞在线性映射H下发生。具体来说，我们通过两次应用并集界限得到：

$$\begin{aligned} \mathbb{P}\left[g(HX) \neq X | H\right] &\le \mathbb{P}\left[x \text{ not h.p.}\right] + \mathbb{P}\left[\exists x' \text{ h.p.} : x' \neq X, Hx' = HX\right] \\ &\le \mathbb{P}\left[\log_q \frac{1}{P_X(x)} > k - \tau\right] + \sum_x P_X(x) \sum_{x' \text{ h.p.}, x' \neq x} 1\{Hx' = Hx\} \end{aligned}$$

现在我们使用随机编码来对所有可能的 H 选择求第二项的平均值。具体来说，选择 H 作为一个与 X 独立的矩阵，其中每个元素在 $\mathbb{F}_q$ 上独立同分布且均匀。对于不同的 x_0 和 x_1，碰撞概率为

$$\begin{aligned} \mathbb{P}[Hx_1 = Hx_0] &= \mathbb{P}[Hx_2 = 0] && (x_2 \triangleq x_1 - x_0 \neq 0) \\ &= \mathbb{P}[H_1 \cdot x_2 = 0]^k && (\text{iid rows}) \end{aligned}$$

其中 H_1 是矩阵 H 的第一行，且 H 的每一行都是独立的。这是 H_i 位于 x_2 的正交补中的概率。在 $\mathbb{F}_q^n$ 上，给定非零向量的正交补的基数为 q^{n-1}。因此，第一行位于该子空间中的概率为 $q^{n-1}/q^n = 1/q$，从而碰撞概率为 $1/q^k$。对 H 取平均得到

$$\mathbb{E}_H \left[\sum_{x' \text{ h.p.}, x' \neq x} 1\{Hx' = Hx\} \right] = |\{x' : x' \text{ h.p.}, x' \neq x\}| q^{-k} \le q^{k-\tau} q^{-k} = q^{-\tau}\,.$$

这就完成了证明。 □

我们注意到，定理11.5和11.8中的界限产生的压缩器具有不可检测的错误。然而，前者的非线性构造易于修改，以使所有错误均可检测（例如，通过将k增加1，并确保对于所有低概率的$x = s^n$，首位为1）。但对于线性压缩器，错误则无法被设为可检测。

请注意，我们将定理限制在 $\mathbb{F}_q$ 上的输入。我们能否放宽要求，在任意交换环上构造压缩器？一般来说，答案是否定的，因为交换环中可能存在零因子。零因子破坏了随机哈希中低碰撞概率这一关键证明要素。实际上，考虑以下在

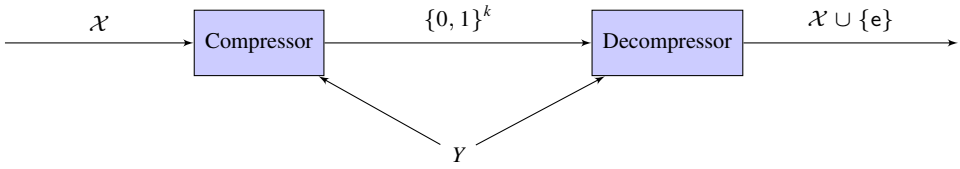
$\mathbb{Z}/6\mathbb{Z}$

$$\mathbb{P}\left[H\begin{bmatrix}1\\0\\\vdots\\0\end{bmatrix}=0\right]=6^{-k} \qquad \text{but} \qquad \mathbb{P}\left[H\begin{bmatrix}2\\0\\\vdots\\0\end{bmatrix}=0\right]=3^{-k},$$

since $0\cdot 2=3\cdot 2=0$ in $\mathbb{Z}/6\mathbb{Z}$。

11.4 压缩时在压缩器和解压器两端均具有边信息

现在我们来讨论当数据由相关对 $(X,Y)\sim P_{X,Y}$ 组成时，压缩问题的几种变体。第一个变体示意性地展示在下图中：



形式上，我们给出以下定义

定义 11.9（带边信息的压缩）给定 $P_{X,Y}$，我们定义

- 压缩器 $f\colon \mathcal{X}\times\mathcal{Y}\to\{0,1\}^k$ 解压器 $g:\{0,1\}^k\times\mathcal{Y}\to\mathcal{X}\cup\{\mathsf{e}\}$ • 错误概率 $\mathbb{P}[g(f(X,Y),Y)\neq X]<\epsilon$. 满足此性质的码称为 (k,ϵ)- s.i. 码 • 基本极限: $\epsilon^*(X|Y,k)=\inf\{\epsilon:\exists(k,\epsilon)\text{−s.i. 码}\}$

注意，这里与源 X 不同，边信息 Y 不必是离散的。在给定 $Y=y$ 的条件下，问题简化为第 11.1 节中研究的无边信息压缩，但源 X 按 $P_{X|Y=y}$ 分布。由于 Y 对压缩器和解压器均已知，它们可以使用针对该分布定制的最佳码。回顾定义 11.1 中定义的 $\epsilon^*(X,k)$，即使用 k 比特压缩 X 的最优错误概率，也可以记为 $\epsilon^*(P_X,k)$。于是我们有以下关系

$$\epsilon^*(X|Y,k)=\mathbb{E}_{y\sim P_Y}[\epsilon^*(P_{X|Y=y},k)],$$

这使我们能够应用之前开发的各种界限。特别地，我们显然有以下结果。

定理 11.10

$$\mathbb{P}\left[\log \frac{1}{P_{X|Y}(X|Y)} > k+\tau\right] - 2^{-\tau} \le \epsilon^*(X|Y,k) \le \mathbb{P}\left[\log_2 \frac{1}{P_{X|Y}(X|Y)} > k-\tau\right] + 2^{-\tau}, \quad \forall \tau > 0$$

推论 11.11 *Let* $(X,Y) = (S^n, T^n)$ *where the pairs* $(S_i, T_i) \overset{i.i.d.}{\sim} P_{S,T}$. *Then*

$$\lim_{n\to\infty} \epsilon^*(S^n|T^n, nR) = \begin{cases} 0 & R > H(S|T) \\ 1 & R < H(S|T) \end{cases}$$

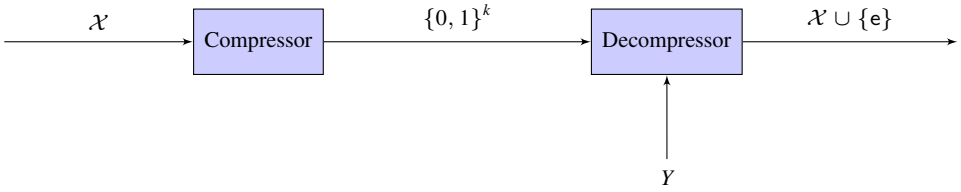
Proof. 事实上，注意由弱大数定律我们有

$$\frac{1}{n}\log\frac{1}{P_{S^n|T^n}(S^n|T^n)} = \frac{1}{n}\sum_{i=1}^{n}\log\frac{1}{P_{S|T}(S_i|T_i)} \xrightarrow{\mathbb{P}} H(S|T)$$

作为$n\to\infty$。因此，结果由前一个定理中设置$(X,Y) = (S^n, T^n)$得出。 □

11.5 Slepian-Wolf：仅在解压缩器处有边信息

在上一节中，我们了解到当压缩器和解压器均可访问边信息时，最优压缩率由条件熵$H(S|T)$给出。现在我们考虑压缩器无法获取边信息$Y = T^n$的情况，如下图所示：



形式上，我们给出如下定义。

定义 11.12（Slepian-Wolf 码）给定 $P_{X,Y}$，我们定义 Slepian-Wolf 编码问题为：

- 压缩器 $f\colon \mathcal{X} \to \{0,1\}^k$ 解压缩器 $g : \{0,1\}^k \times \mathcal{Y} \to \mathcal{X} \cup \{\mathsf{e}\}$ • 误差概率 $\mathbb{P}[g(f(X),Y) \neq X]$ $\le \epsilon$. 满足此性质的码称为 (k,ϵ)- Slepian-Wolf 码 • 基本极限： $\epsilon^*_{\mathrm{SW}}(X|Y,k) = \inf\{\epsilon : \exists (k,\epsilon)$-Slepian-Wolf 码$\}$

以下是Slepian和Wolf[3]的非常令人惊讶的结果，它表明压缩器无法获得边信息根本不会阻碍压缩率。

定理 11.13 (Slepian-Wolf [392])

$$\epsilon^*(X|Y,k) \le \epsilon^*_{\mathrm{SW}}(X|Y,k) \le \mathbb{P}\left[\log \frac{1}{P_{X|Y}(X|Y)} \ge k-\tau\right] + 2^{-\tau}$$

根据这个定理，我们将通过弱大数定律得到渐近结果：

推论 11.14（Slepian-Wolf [392]）

$$\lim_{n\to\infty} \epsilon^*_{\mathrm{SW}}(S^n|T^n, nR) = \begin{cases} 0 & R > H(S|T) \\ 1 & R < H(S|T) \end{cases}$$

我们注意到，旁信息（T-过程）甚至不需要是离散的，参见练习II.9。

Proof of the Theorem. 左边显然成立，因为压缩器和解压器处的边信息比仅在解压器处更好。

对于右侧，首先生成一个随机码本，其码字独立同分布于均匀分布：$\mathcal{C} = \{c_x \in \{0,1\}^k : x \in \mathcal{X}\}$独立于$(X,Y)$，然后定义压缩器和解码器为

$$f(x) = c_x$$
$$g(w,y) = \begin{cases} x & \exists! x : c_x = w, x \text{ h.p.}|y \\ 0 & \text{otherwise} \end{cases}$$

其中我们使用了简写 x h.p.$|y \Leftrightarrow \log_2 \frac{1}{P_{X|Y}(x|y)} < k-\tau$。这个方案的错误概率，作为码本 $\mathcal{C}$ 的函数，是

$$\begin{aligned}
\mathbb{P}[X \ne g(f(X))|\mathcal{C}] &= \mathbb{P}\left[\log \frac{1}{P_{X|Y}(X|Y)} \ge k-\tau \text{ or } J(X,\mathcal{C}|Y) \ne \emptyset|\mathcal{C}\right] \\
&\le \mathbb{P}\left[\log \frac{1}{P_{X|Y}(X|Y)} \ge k-\tau\right] + \mathbb{P}\left[J(X,\mathcal{C}|Y) \ne \emptyset|\mathcal{C}\right] \\
&= \mathbb{P}\left[\log \frac{1}{P_{X|Y}(X|Y)} \ge k-\tau\right] + \sum_{x,y} P_{X,Y}(x,y)1\left\{J(x,\mathcal{C}|y) \ne \emptyset\right\}.
\end{aligned}$$

其中 $J(x,\mathcal{C}|y) \triangleq \{x' \ne x\colon\ x' \text{ 马力}|y, c_x = c_{x'}\}$。

3 这个结果通常被非正式地称为“香农之后最令人惊讶的结果”。

现在对 $\mathcal{C}$ 求平均，我们得到

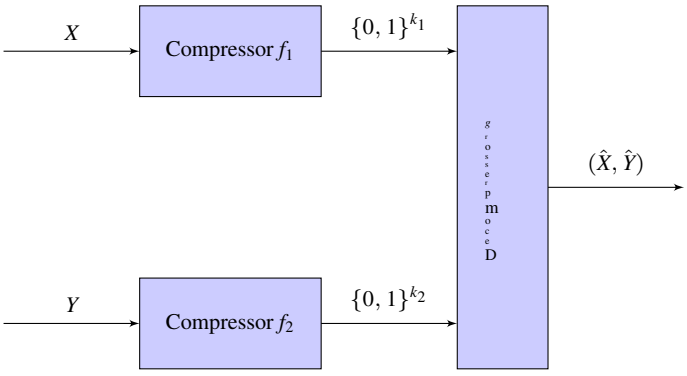
$$\begin{aligned}\mathbb{P}[J(x,\mathcal{C}|y)\neq\emptyset] &\overset{(a)}{\leq} \mathbb{E}_{\mathcal{C}}\left[\sum_{x'\neq x} 1\{x' \text{ h.p.}|y\}1\{c_{x'}=c_x\}\right]\\ &\overset{(b)}{\leq} 2^{k-\tau}\mathbb{P}[c_{x'}=c_x]\\ &\overset{(c)}{=} 2^{-\tau},\end{aligned}$$

其中 (a) 是并集界，(b) 由 $|\{x' : x' \text{ h.p.}|y\}| \leq 2^{k-\tau}$ 这一事实得出，(c) 来自 $\mathbb{P}[c_{x'}=c_x]=2^{-k}$ 对于任意 $x\neq x'$。 □

备注 11.5（不可检测错误）定义 11.12 允许出现未被检测到的错误。现在，我们已经看到，在所有先前的随机编码结果中（线性压缩除外），我们总是可以轻松修改压缩算法，使所有未被检测到的错误变为可检测。然而，Slepian-Wolf 的魔力关键在于不可检测错误。事实上，假设我们要求对于所有 x,y 且 $P_{X,Y}(x,y) > 0$ 的情况，$g(f(x),y) = x$ 成立。假设存在某个 $c\in\{0,1\}^k$ 使得 $f(x_1)=f(x_2)=c$。那么对于所有 y，$g(c,y)=\mathsf{e}$ 成立，并且对于这样的 c，不需要边信息。另一方面，如果 $c\in\{0,1\}^k$ 使得存在唯一的 x 满足 $f(x)=c$，那么我们可以设置 $g(c,y)=x$ 并再次忽略 y。总体来看，我们看到在两种情况下，边信息在解压器处都没有用，我们只能压缩到 $H(X)$ 而不是 $H(X|Y)$。类似地，可以证明 Slepian-Wolf 定理在可变长度无损压缩的设置中不成立：任何无损算法的最小平均压缩长度至少为 $H(X)$ (，而不是 $H(X|Y)$)。

11.6 Slepian-Wolf：压缩多个源

前一个结果的简单扩展还涵盖了数据压缩任务的另一种变体，其中两个相关源X和Y分别压缩（可能位于两个远程位置），但在目的地联合解压。然而，这一次的目标是同时再现X和Y。如下所示：



更正式地说，我们定义：

定义 11.15（多端压缩）给定 $P_{X,Y}$，令

• 压缩器 f_1： $\mathcal{X} \to \{0,1\}^{k_1}$， f_2： $\mathcal{Y} \to \{0,1\}^{k_2}$。 • 解压器 g： $\{0,1\}_1^k \times \{0,1\}_2^k \to \mathcal{X} \times \mathcal{Y} \cup \{e\}$ • 错误概率 $\mathbb{P}[g(f_1(X), f_2(Y)) \neq (X,Y)] \leq \epsilon$。满足此性质的码称为（$k_1, k_2, \epsilon$）-码（或多终端Slepian-Wolf码）。 • 基本极限：$\epsilon_{\mathrm{SW}}^*(X,Y,k_1,k_2) = \inf\{\epsilon : \exists(k_1,k_2,\epsilon)\text{-码}\}$。

这里的渐近基本极限如下所示。

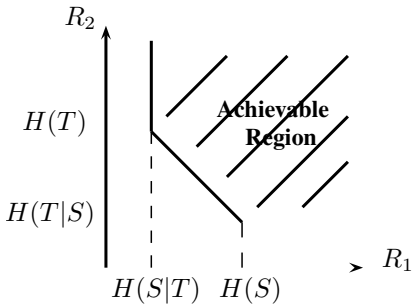
定理 11.16 *Let* $(X,Y) = (S^n, T^n)$ *with* $(S_i,T_i) \overset{i.i.d.}{\sim} P_{S,T}$. *Then*

$$\lim_{n\to\infty} \epsilon_{\mathrm{SW}}^*(S^n,T^n,nR_1,nR_2) = \begin{cases} 0 & (R_1,R_2) \in \mathrm{int}(\mathcal{R}_{\mathrm{SW}}) \\ 1 & (R_1,R_2) \notin \mathcal{R}_{\mathrm{SW}} \end{cases}$$

where $\mathcal{R}_{\mathrm{SW}}$ *denotes the Slepian-Wolf rate region*

$$\mathcal{R}_{\mathrm{SW}} = \left\{ (a,b): \begin{array}{l} a \geq H(S|T) \\ b \geq H(T|S) \\ a+b \geq H(S,T) \end{array} \right.$$

速率区域{v*}通常看起来像这样：

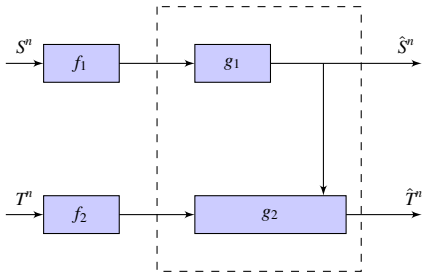


自 $H(T) - H(T|S) = H(S) - H(S|T) = I(S$ 起；$T)$，斜线的斜率为 -1。

Proof. *Converse*: 取 $(R_1,R_2) \notin \mathcal{R}_{\mathrm{SW}}$。那么必然发生以下三种情况之一：

1 $R1 < H(S|T)$。在这种情况下，即使 f_1 编码器和解码器能够访问完整的 T^n，我们仍然无法实现消失误差（推论 11.11）。
2 $R2 < H(T|S)$ (相同)。
3 $R1 + R_2 < H(S,T)$。如果这可行，那么我们就是以低于 $H(S,T)$ 的速率压缩联合 (S^n,T^n)，这违反了推论11.3。

Achievability：首先注意我们可以达到两个角点。点（$H(S), H(T|S)$）可以通过在熵处几乎无损地压缩 S 并在解码器处利用边信息 S 压缩 T 来逼近。为了使这一点严谨，令 $k_1 = n(H(S)+\delta)$ 和 $k_2 = n(H(T|S)+\delta)$。根据推论 11.3，存在 f_1：$\mathcal{S}^n \to \{0,1\}^{k_1}$ 和 g_1：$\{0,1\}^{k_1} \to \mathcal{S}^n$，使得 $\mathbb{P}\left[g_1(f_1(S^n)) \neq S^n\right] \leq \epsilon_n \to 0$。根据定理 11.13，存在 f_2：$\mathcal{T}^n \to \{0,1\}^{k_2}$ 和 g_2：$\{0,1\}^{k_1} \times \mathcal{S}^n \to \mathcal{T}^n$，使得 $\mathbb{P}\left[g_2(f_2(T^n), S^n) \neq T^n\right] \leq \epsilon_n \to 0$。既然 S^n 不可用，将 $g_1(f_1(S^n))$ 输入 S.W. 解压器，并通过 $g(w_1, w_2) = (g_1(w_1), g_2(w_2, g_1(w_1)))$（见下文）定义联合解压器：



应用并集界：

$$\begin{aligned}
&\mathbb{P}\left[g(f_1(S^n), f_2(T^n)) \neq (S^n, T^n)\right] \\
&= \mathbb{P}\left[g_1(f_1(S^n)) \neq S^n\right] + \mathbb{P}\left[g_2(f_2(T^n), g(f_1(S^n))) \neq T^n, g_1(f_1(S^n)) = S^n\right] \\
&\leq \mathbb{P}\left[g_1(f_1(S^n)) \neq S^n\right] + \mathbb{P}\left[g_2(f_2(T^n), S^n) \neq T^n\right] \\
&\leq 2\epsilon_n \to 0.
\end{aligned}$$

类似地，可以接近点$(H(S), H(T|S))$。

为了达到区域内的其他点，使用*time sharing*的思想：如果你能以消失的错误概率达到任意两点（R_1, R_2）和（R_1', R_2'），那么对于$\lambda \in [0,1]$，（$\lambda R_1 + \bar{\lambda} R_1', \lambda R_2 + \bar{\lambda} R_2'$），你可以通过将长度为$n$的块分成两个长度为$\lambda n$和$\bar{\lambda} n$的块，并分别应用这两个码来实现

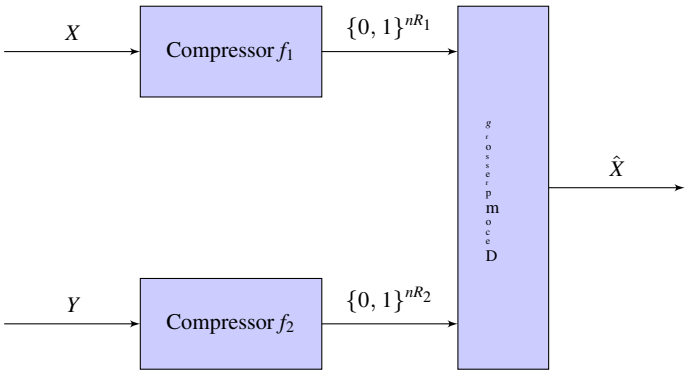
$$\begin{aligned}
(S_1^{\lambda n}, T_1^{\lambda n}) &\to \begin{bmatrix} \lambda n R_1 \\ \lambda n R_2 \end{bmatrix} \quad \text{using } (R_1, R_2) \text{ code} \\
(S_{\lambda n+1}^{n}, T_{\lambda n+1}^{n}) &\to \begin{bmatrix} \bar{\lambda} n R_1' \\ \bar{\lambda} n R_2' \end{bmatrix} \quad \text{using } (R_1', R_2') \text{ code}
\end{aligned}$$

因此，可实现区域内点的所有凸组合也是可实现的，所以可实现区域必须是凸的。

□

11.7* 带辅助源编码（Ahlswede-Körner-Wyner）

在Slepian-Wolf设定中，目标是压缩/解压缩X，解压器可以访问边信息Y。该问题的一个自然变体是考虑这样的情况：通过速率受限的链路可以访问Y本身，即我们有以下设定：



注意，与上一节不同的是，解压器只需产生X (的估计，而非Y)，因此本节问题的名称是：带有（速率受限）辅助的压缩。这次的难点在于，需要从Y通过该链路传送到解压器的不是关于Y的信息，而只是Y中对于解压X最有用的信息。尽管与前面几节相似，这一任务完全是新的，因此，在这种情况下，速率对R_1, R_2的刻画要微妙得多。这一问题在两篇独立工作中得到完成[9, 459]。

定理 11.17 (Ahlswede-Körner-Wyner) *Consider i.i.d. source $(X^n, Y^n) \sim P_{X,Y}$ with X discrete. Compressor produces message $W_1 = f_1(X^n)$ and helper produces a message $W_2 = f_2(Y^n)$, with W_i consisting of at most nR_i bits, $i \in \{1, 2\}$. Decompressor produces an estimate $\hat{X}^n = g(W_1, W_2)$. If rate pair (R_1, R_2) is achievable with vanishing probability of error $\mathbb{P}[\hat{X}^n \neq X^n] \to 0$, then there exists an auxiliary random variable U taking values on alphabet of cardinality $|\mathcal{Y}| + 1$ such that $P_{X,Y,U} = P_{X,Y}P_{U|Y}$ (i.e. $X \to Y \to U$) and*

$$R_1 \geq H(X|U), R_2 \geq I(Y;U)\,. \tag{11.3}$$

Furthermore, for every such random variable U the rate pair $(H(X|U), I(Y;U))$ is achievable with vanishing error.

换言之，这次可达对集合(R_1, R_2)属于$\mathbb{R}^2_+$的一个区域，该区域描述为$\cup\{[H(X|U), +\infty)\times[I(Y;U), +\infty)\}$，其中并集取遍所有可能的$P_{U|Y}$: $\mathcal{Y} \to \mathcal{U}$，此处$|\mathcal{U}| = |\mathcal{Y}| + 1$。最优$(R_1, R_2)$区域的边界由一条$F_I$曲线描绘，这个概念我们稍后会定义（定义16.5）。

Proof. 首先，注意到在无基数约束下遍历所有可能的随机变量 U (，满足(11.3)的配对集合(R_1, R_2)是凸的。接着，考虑一个压缩机 $W_1 = f_1(X^n)$ 及 $W_2 = f_2(Y^n)$。那么根据Fano不等式(3.19)，假设 $\mathbb{P}[X^n \neq \hat{X}^n] = o(1)$，我们得到

$$H(X^n|W_1, W_2)) = o(n)\,.$$

因此，根据链式法则以及条件作用会降低熵这一事实，我们得到

$$nR_1 \geq I(X^n; W_1|W_2) \geq H(X^n|W_2) - o(n) \tag{11.4}$$

$$= \sum_{k=1}^{n} H(X_k|W_2, X^{k-1}) - o(n) \tag{11.5}$$

$$\geq \sum_{k=1}^{n} H(X_k|\underbrace{W_2, X^{k-1}, Y^{k-1}}_{\triangleq U_k}) - o(n) \tag{11.6}$$

另一方面，由(6.2)我们得到

$$nR_2 \geq I(W_2; Y^n) = \sum_{k=1}^{n} I(W_2; Y_k|Y^{k-1}) \tag{11.7}$$

$$= \sum_{k=1}^{n} I(W_2, X^{k-1}; Y_k|Y^{k-1}) \tag{11.8}$$

$$= \sum_{k=1}^{n} I(W_2, X^{k-1}, Y^{k-1}; Y_k) \tag{11.9}$$

其中（11.8）由$I(W_2, X^{k-1};\ Y_k|Y^{k-1}) = I(W_2;\ Y_k|Y^{k-1}) + I(X^{k-1};\ Y_k|W_2, Y^{k-1})$及事实（$W_2, Y_k$）$\perp\!\!\!\perp X^{k-1}|Y^{k-1}$推出；（11.9）由$Y^{k-1} \perp\!\!\!\perp Y_k$推出。比较（11.6）和（11.9），我们注意到记$U_k = (W_2, X^{k-1}, Y^{k-1})$，则同时有$X_k \to Y_k \to U_k$和

$$(R_1, R_2) \geq \frac{1}{n} \sum_{k=1}^{n} (H(X_k|U_k), I(U_k; Y_k))$$

因此（根据凸性），速率对必须属于由所有对$(H(X|U), I(U;\ Y))$所张成的区域。

为了展示不失一般性，辅助随机变量U可以被选择至多取$|\mathcal{Y}|$+个1值，我们可以引用卡拉泰奥多里定理（见引理7.14）。具体细节在此省略。

接下来，我们展示对于每个 U，所提到的速率对是可实现的。为此，我们首先注意到，如果解压器处存在与 X^n 相关的独立同分布序列 U^n 形式的边信息，那么 Slepian-Wolf 定理意味着仅需速率 $R_1 = H(X|U)$ 就足以重构 X^n。因此，问题归结为通过使用最小速率 R_2 在解压器处生成相关序列 U^n。一种方法是花费 $nH(U)$ 比特精确地传达 U^n。然而，事实证明，借助 $nI(U;\ X)$ 比特，我们可以传达一个“伪造”的 $\hat{U}^n$，但其条件分布 $P_{X^n|\hat{U}^n} \approx P_{X^n|U^n}$（使得 $\hat{U}^n$ 与 X^n）被称为“联合典型”。生成此类 $\hat{U}^n$ 的可能性是一个独立显著的结果，称为覆盖引理，我们将在很久以后研究——见推论 25.6。这里我们展示如何在此情况下应用覆盖引理。

根据推论25.6和命题25.7，我们知道对于每个$\delta > 0$，存在足够大的m和$\hat{U}^m = f_2(Y^m) \in \{0, 1\}^{mR_2}$，使得

$$X^m \to Y^m \to \hat{U}^m$$

和 $I(X^m;\ \hat{U}^m) \geq m(I(X;\ U)-\delta)$。这意味着 $H(X^m|\hat{U}^m) \leq mH(X|U)+m\delta$。我们现在可以将 Slepian-Wolf 定理应用于块符号 $(X^m, \hat{U}^m)$。即，我们定义一个新的压缩问题，涉及 $\tilde{X} = X^m$ 和 $\tilde{U} = \hat{U}^m$。这些仍然在有限字母表上取值，因此必定存在（对于足够大的 ℓ）一个压缩器 $W_1 = f_1(\tilde{X}^\ell) \in \{0,1\}^{\ell\tilde{R}_1}$ 和一个解压缩器 $g(W_1, \tilde{U}^\ell)$，具有较低的错误概率和 $\tilde{R}_1 \leq H(\tilde{X}|\tilde{U}) + m\delta \leq mH(X|U) + 2m\delta$）。现在，由于实际块长度为 $n = \ell m$，我们得到该方案的有效速率为 $R_1 = \frac{\tilde{R}_1}{m} \leq H(X|U) + 2\delta$。由于 $\delta > 0$ 是任意的，证明完成。

□

12 Entropy of ergodic processes

到目前为止，我们研究了独立同分布序列$\{S_i\}$的压缩，我们证明了平均压缩长度（对于可变长度压缩器）收敛于熵$H(S)$，并且错误概率（对于固定长度压缩器）收敛于零或一，取决于压缩率$R \lessgtr H(S)$。在本章中，我们将对一大类具有记忆的过程（称为*ergodic processes*）考察类似的结果。我们以快速回顾遍历理论的主要概念开始本章，然后陈述我们的主要结果（Shannon-McMillan定理、压缩极限和AEP）。后续章节致力于Shannon-McMillan定理和遍历定理的证明。最后，在最后一节中，我们引入*Kolmogorov-Sinai entropy*，它将一个完全确定性的变换与它有多“混沌”的度量联系起来。这个概念在形式化一个明显的悖论中起着非常重要的作用：大型机械系统（如气体粒子的集合）一方面是完全可以确定的（由牛顿运动定律描述），另一方面具有许多概率性质（麦克斯韦速度分布、涨落等）。Kolmogorov-Sinai熵显示了这两个概念如何共存。此外，它还被用来解决动力系统中关于*Bernoulli shifts*同构的一个长期未决问题[387, 322]。

12.1 遍历理论的点滴

让我们从动力系统的视角来探讨随机过程。在本章中，我们假定所有随机变量都定义在一个共同的 elementary outcomes 空间 $(\Omega, \mathcal{F})$ 上。

定义12.1（保测变换）τ：若$\Omega \to \Omega$满足以下条件，则称为保测变换，也称为概率保持变换（p.p.t.）：

$$\forall E \in \mathcal{F}, P(E) = P(\tau^{-1}E).$$

集合 E 被称为 τ-不变的，如果 $E = \tau^{-1}E$。所有 τ-不变集合的集合构成一个 σ-代数（练习），记作 $\mathcal{F}_{inv}$。

定义 12.2（平稳过程）如果存在一个保测变换 $\tau : \Omega \to \Omega$ 使得以下条件成立，则过程 $\{S_n, n = 0, \ldots\}$ 是平稳的：

$$S_j = S_{j-1} \circ \tau = S_0 \circ \tau^j$$

因此，一个平稳过程可以由元组$(\Omega, \mathcal{F}, \mathbb{P}, \tau, S_0)$和$S_k = S_0 \circ \tau^k$来描述。

备注 12.1

1 或者，如果随机过程 $(S_0, S_1, S_2, \dots)$ 的联合分布相对于时间平移是不变的，即 $P_{S_n^m} = P_{S_{n+t}^{m+t}}$，$\forall n, m, t$，则该过程是平稳的。实际上，给定这样一个过程，我们可以设定 $\Omega = \mathcal{S}^\infty$并按如下方式定义m.p.t.:

$$(s_0, s_1, \dots) \xrightarrow{\tau} (s_1, s_2, \dots) \tag{12.1}$$

因此，τ是向左的偏移。

2 如果一个事件$E \in \mathcal{F}$是平移不变的，则

$$(s_1, s_2, \dots) \in E \iff (s_0, s_1, s_2, \dots) \in E, \quad \forall s_0$$

或者，等价地，$E = \tau^{-1}E$。因此，当τ被解释为(12.1)时，τ-不变事件也被称为平移不变。

3 平移不变事件的一些例子是 $\{\exists n\colon\ x_i = 0, \forall i \geq n\}$、$\{\limsup x_i < 1\}$ 等。一个非平移不变事件是 $A = \{x_0 = x_1 = \cdots = 0\}$，因为 $\tau(1, 0, 0, \dots) \in A$ 但 $(1, 0, \dots) \notin A$。

4 还要记得，尾部 {v*}-代数被定义为

$$\mathcal{F}_{tail} \triangleq \bigcap_{n \geq 1} \sigma\{S_n, S_{n+1}, \dots\}\,.$$

很容易验证所有平移不变事件都属于$\mathcal{F}_{tail}$。这种包含是严格的，例如事件$\{\exists n\colon\ x_i = 0, \forall$ 奇数$i \geq n\}$在$\mathcal{F}_{tail}$中，但不是平移不变的。

命题 12.3（庞加莱回归）*Let τ be measure-preserving for $(\Omega, \mathcal{F}, \mathbb{P})$. Then for any measurable A with $\mathbb{P}[A] > 0$ we have*

$$\mathbb{P}\left[\bigcup_{k \geq 1} \tau^{-k} A \,\middle|\, A\right] = \mathbb{P}[\tau^k(\omega) \in A \text{ occurs infinitely often} | A] = 1\,.$$

Proof. 设 $B = \bigcup_{k \geq 1} \tau^{-k} A$。只需证明 $\mathbb{P}[A \cap B] = \mathbb{P}[A]$，或等价地

$$\mathbb{P}[A \cup B] = \mathbb{P}[B]\,. \tag{12.2}$$

为此，请注意 $\tau^{-1}A \cup \tau^{-1}B = B$，因此

$$\mathbb{P}[\tau^{-1}(A \cup B)] = \mathbb{P}[B]\,,$$

但左侧根据τ的保测度性等于$\mathbb{P}[A \cup B]$，从而证明了(12.2)。 □

考虑τ将保守（哈密顿）机械系统的初始状态映射到经过给定时间后的状态。已知τ在相空间中保持勒贝格测度（刘维尔定理）。因此，庞加莱复现导致了一个相当反直觉的结论。例如，打开气缸中分隔两种气体的屏障使它们混合。庞加莱复现表明它们最终会回到原始分离状态

(每种气体大约占据气缸的一半)。当然，只要注意到这种情况发生所需的时间长得不合物理实际，“佯谬”就迎刃而解了。

定义 12.4（遍历性）如果 $\forall E \in \mathcal{F}_{inv}$ 我们有 $\mathbb{P}[E] = 0$ 或 1，则变换 τ 是遍历的。如果所有平移不变事件都是确定性的，即对于任何平移不变事件 E，$\mathbb{P}[S_1^\infty \in E] = 0$ 或 1，则过程 $\{S_i\}$ 是遍历的。

以下是一些示例:

• $\{S_k = k2\}$：遍历但非平稳。• $\{S_k = S_0\}$：平稳但非遍历（除非S_0为常数）。注意单点集$E = \{(s, s, \ldots)\}$是平移不变的，且$\mathbb{P}[S_1^\infty \in E] = \mathbb{P}[S_0 = s] \in (0, 1)$，不是确定性的。• $\{S_k\}$独立同分布是平稳且遍历的（根据Kolmogorov 0-1律，尾事件没有随机性）。• (遍历过程的滑动窗口构造)如果$\{S_i\}$是遍历的，那么$\{X_i = f(S_i, S_{i+1}, \ldots)\}$也是遍历的。这样的过程$\{X_i\}$被称为*B-process*，如果$S_i$是独立同分布的•。这里有一个重要的例子，展示了如何通过滑动窗口以两种方式看待一个简单的独立同分布过程S_i。取$S_i \overset{\text{i.i.d.}}{\sim} \text{Ber}(\frac{1}{2})$并设定$X_k = \sum_{n=0}^{\infty} 2^{-n-1} S_{k+n} = 2X_{k-1} \bmod 1$。$X_i$的边缘分布在[0, 1]上是均匀的。此外，*$X_k$'s behavior is completely deterministic:*给定X_0，所有未来的X_k都可以精确计算。这个例子表明，某些确定性映射在迭代应用下表现出遍历/混沌行为：尽管X_k的轨迹是完全确定的，但其时间平均收敛于期望，并且总体上“看起来随机”，因为只有在能够无限精确测量X_0时才能保证完全确定性。对X_k进行任何离散化都会导致具有正熵率的随机行为——更多内容参见第12.5*节。•还存在比遍历性更强的条件。即，我们说τ是混合的（或强

混合）如果

$$\mathbb{P}[A \cap \tau^{-n} B] \to \mathbb{P}[A]\mathbb{P}[B] .$$

如果 τ 是弱混合的，则

$$\sum_{k=1}^{n} \frac{1}{n} \left| \mathbb{P}[A \cap \tau^{-n} B] - \mathbb{P}[A]\mathbb{P}[B] \right| \to 0 .$$

强混合蕴含弱混合，而弱混合又蕴含遍历性（练习II.12）。

- $\{S_i\}$\{v*\}：具有常返状态（recurrent states）的有限不可约马尔可夫链是遍历的（事实上是强混合的），无论初始分布如何。
  作为一个玩具示例，考虑核 $P(0|1) = P(1|0) = 1$ 及其初始分布 $P(S_0 = 0) = 0.5$。该过程仅有两个样本路径：$\mathbb{P}[S_1^\infty = (010101\ldots)] = \mathbb{P}[S_1^\infty = (101010\ldots)] = \frac{1}{2}$。容易验证该过程是遍历的（在定义12.4的意义上）。然而请注意，在马尔可夫链文献中，若一个链是不可约、非周期且常返的，则称其为遍历的。本示例不满足这一 定义（这种术语冲突是混淆的常见来源）。

- $\{S_i\}$平稳零均值高斯过程，其自协方差函数为 $c(n) = \mathbb{E}[S_0 S_n^*]$。

$$\lim_{n\to\infty} \frac{1}{n+1} \sum_{t=0}^{n} c(t) = 0 \Leftrightarrow \{S_i\} \text{ ergodic} \Leftrightarrow \{S_i\} \text{ weakly mixing}$$

$$\lim_{n\to\infty} c(n) = 0 \Leftrightarrow \{S_i\} \text{ mixing}$$

直观地说，一个遍历过程通常可能具有无限记忆，但这种记忆是微弱的。实际上，我们看到对于平稳高斯过程而言，遍历性意味着相关性消失（在Cesáro平均意义下）。

spectral measure 被定义为自协方差序列 $\{c(n)\}$ 的（离散时间）傅里叶变换，即存在 $[-\pi, \pi]$ 上唯一的正测度 μ，使得 $c(n) = \frac{1}{2\pi}\int \exp(inx)\mu(dx)$。谱准则可以表述如下：

$\{S_i\}$ 是遍历的 $\Leftrightarrow$ 谱测度没有原子（累积分布函数连续）

$\{S_i\}$ 是一个B过程 $\Leftrightarrow$ 谱测度具有密度（功率谱密度，参见例6.4）

关于平稳高斯过程的详细阐述可见于[135，定理9.3.2，第474页，定理9.7.1，第493-494页]。

12.2 香农-麦克米伦、熵率及AEP

有了遍历性的定义，我们可以陈述本章的三个主要结果。首先是关于归一化对数似然的类似于大数定律的结果。

定理 12.5（Shannon-McMillan-Breiman） *Let $\mathbb{S} = \{S_1, S_2, \dots\}$ be a stationary and ergodic discrete process with entropy rate $\mathcal{H} \triangleq H(\mathbb{S})$. Then*

$$\frac{1}{n} \log \frac{1}{P_{S^n}(S^n)} \xrightarrow{\mathbb{P}} \mathcal{H}, \quad \textit{also a.s. and in } L_1 \tag{12.3}$$

推论 12.6 *Let $\{S_1, S_2, \dots\}$ be a discrete stationary and ergodic process with entropy rate $\mathcal{H}$ (in bits). Denote by f_n^* the optimal variable-length compressor for S^n and $\epsilon^*(S^n, nR)$ the optimal probability of error of its fixed-length compressor with R bits per symbol (Definition 11.1). Then we have*

$$\frac{1}{n} l(f_n^*(S^n)) \xrightarrow{\mathbb{P}} \mathcal{H} \quad \textit{and} \quad \lim_{n\to\infty} \epsilon^*(S^n, nR) = \begin{cases} 0 & R > \mathcal{H}, \\ 1 & R < \mathcal{H}. \end{cases} \tag{12.4}$$

Proof. 根据推论10.5，$\frac{1}{n} l(f_n^*(S^n))$和$\frac{1}{n}\log\frac{1}{P_{S^n}(S^n)}$的渐近分布重合。根据Shannon-McMillan-Breiman定理（我们只需要依概率收敛），后者收敛于一个常数$\mathcal{H}$。

□

在第 11 章中，我们学习了独立同分布（iid）源的渐近均分性质（AEP）。得益于香农-麦克米伦-布雷曼定理，我们对于独立同分布过程所做的相同证明也适用于一般的遍历过程。

推论 12.7（平稳遍历信源的 AEP） *Let $\{S_1, S_2, \dots\}$ be a stationary and ergodic discrete process. For any $\delta > 0$, define the set*

$$T_n^\delta = \left\{ s^n : \left| \frac{1}{n} \log \frac{1}{P_{S^n}(s^n)} - \mathcal{H} \right| \le \delta \right\}.$$

Then

1 $\mathbb{P}\left[S^n \in T_n^\delta\right] \to 1$ *as* $n \to \infty$. $\exp\{n(\mathcal{H}-\delta)\}(1+o(1)) \le |T_n^\delta| \le \exp\{(\mathcal{H}+\delta)n\}(1+o(1))$.
2

以下是一些历史注记。平稳遍历马尔可夫链的依概率收敛已在[378]中证明。对所有平稳遍历过程推广到L_1中的收敛由McMillan在[301]中给出，而几乎必然收敛则由Breiman在[75]中给出。[1] 一个现代证明见[11]。另请注意，对于马尔可夫链，典型序列的存在性和AEP可以通过将马尔可夫过程视为在每个状态选择转移的独立决策序列来预期。因此，马尔可夫过程的轨迹显然只是iid过程轨迹的变换，从而必须以类似方式集中。

12.3 香农-麦克米伦-布雷曼定理的证明

我们将展示 L_1-收敛性，这自动意味着依概率收敛。我们不会证明几乎处处收敛。为此，让我们首先介绍遍历过程的Birkhoff-Khintchine收敛定理，其证明将在下一小节中给出。这一结果的解释是时间平均收敛于系综平均。

定理12.8（伯克霍夫-欣钦遍历定理）*Let $\{S_i\}$ be a stationary and ergodic process. For any integrable function f, i.e., $\mathbb{E}|f(S_1, \dots)| < \infty$,*

$$\lim_{n\to\infty} \frac{1}{n} \sum_{k=1}^{n} f(S_k, \dots) = \mathbb{E} f(S_1, \dots) \quad \textit{a.s. and in } L_1.$$

In the special case where f depends on finitely many coordinates, say, $f = f(S_1, \dots, S_m)$,

$$\lim_{n\to\infty} \frac{1}{n} \sum_{k=1}^{n} f(S_k, \dots, S_{k+m-1}) = \mathbb{E} f(S_1, \dots, S_m) \quad \textit{a.s. and in } L_1.$$

[1] Curiously, both McMillan and Breiman left the field after these contributions. McMillan went on to head the US satellite reconnaissance program, and Breiman became a pioneer and advocate of machine learning approach to statistical inference.

例 12.1 考虑 $f = f(S_1)$。那么对于独立同分布过程，定理 12.8 即强大数定律。在极端情况下，如果 $\{S_i\}$ 具有常数轨迹，即对所有 $i \geq 1$ 有 $S_i = S_1$，则这样的过程是非遍历的，定理 12.8 的结论不成立（除非 S_1 几乎必然为常数）。

我们引入了马尔可夫链思想的扩展。

定义 12.9（有限阶马尔可夫链）$\{S_i\colon\ i \in \mathbb{N}\}$ 是一个 m^{th} 阶马尔可夫链，如果对于所有 $t \geq m$ 都有 $P_{S_{t+1}|S_1^t} = P_{S_{t+1}|S_{t-m+1}^t}$。如果 $P_{S_{t+1}|S_{t-m+1}^t} = P_{S_{m+1}|S_1^m}$，则称为时间齐次的。

注12.2 显示对于m^{th}阶时间齐性马尔可夫链$\{S_i\}$的(12.3)是Birkhoff-Khintchine定理的直接应用。实际上，我们有

$$\begin{aligned}\frac{1}{n}\log\frac{1}{P_{S^n}(S^n)} &= \frac{1}{n}\sum_{t=1}^{n}\log\frac{1}{P_{S_t|S^{t-1}}(S_t|S^{t-1})}\\ &= \frac{1}{n}\log\frac{1}{P_{S^m}(S^m)} + \frac{1}{n}\sum_{t=m+1}^{n}\log\frac{1}{P_{S_t|S_{t-m}^{t-1}}(S_t|S_{l-m}^{l-1})}\\ &= \underbrace{\frac{1}{n}\log\frac{1}{P_{S_1}(S_1^m)}}_{\to 0} + \underbrace{\frac{1}{n}\sum_{t=m+1}^{n}\log\frac{1}{P_{S_{m+1}|S_1^m}(S_t|S_{t-m}^{t-1})}}_{\to H(S_{m+1}|S_1^m)\text{ by Birkhoff-Khintchine}},\end{aligned} \tag{12.5}$$

其中我们应用了定理12.8，其中{v*}的对数为$\frac{1}{P_{S_{m+1}|S_1^m}(s_{m+1}|s_1^m)}$。

现在我们来证明一般平稳遍历过程 $\{S_i\}$ 的 (12.3)，该过程可能具有无限记忆。思路是首先将该遍历过程的分布用一个 m 阶马尔可夫链（有限记忆）来近似，并利用 (12.5)，然后令 $m \to \infty$ 使近似变得精确。这是香农对随机过程理论的一个极具影响力的贡献，称为 *Markov approximation*。

Proof of Theorem 12.5 in L_1. 为了证明(12.3)在L_1中收敛，我们需要证明

$$\mathbb{E}\left|\frac{1}{n}\log\frac{1}{P_{S^n}(S^n)} - \mathcal{H}\right| \to 0, \quad n \to \infty.$$

为此，固定一个 $m \in \mathbb{N}$. 为p定义以下辅助分布： 流程：

$$\begin{aligned}Q^{(m)}(S_1^\infty) &\triangleq P_{S_1^m}(S_1^m)\prod_{t=m+1}^{\infty}P_{S_t|S_{t-m}^{t-1}}(S_t|S_{t-m}^{t-1})\\ &= P_{S_1^m}(S_1^m)\prod_{t=m+1}^{\infty}P_{S_{m+1}|S_1^m}(S_t|S_{t-m}^{t-1}),\end{aligned}$$

其中第二行应用了平稳性。注意在$Q^{(m)}$下，$\{S_i\}$是一个m^{th}阶时间齐次马尔可夫链。

根据三角不等式，

$$\mathbb{E}\Big|\frac{1}{n}\log\frac{1}{P_{S^n}(S^n)}-\mathcal{H}\Big| \le \mathbb{E}\underbrace{\Big|\frac{1}{n}\log\frac{1}{P_{S^n}(S^n)}-\frac{1}{n}\log\frac{1}{Q^{(m)}_{S^n}(S^n)}\Big|}_{\triangleq A}+\mathbb{E}\underbrace{\Big|\frac{1}{n}\log\frac{1}{Q^{(m)}_{S^n}(S^n)}-H_m\Big|}_{\triangleq B}+\underbrace{|H_m-\mathcal{H}|}_{\triangleq C}$$

其中 $H_m \triangleq H(S_{m+1}|S_1^m)$。

接下来，我们分别讨论每个术语：

- $C = |H_m - \mathcal{H}| \to$ 根据定理5.4，0作为$m \to \infty$（回想对于平稳过程：$H(S_{m+1}|S_1^m) \to H$如上所述）。
- 如备注12.2所示，对于任何固定的m，$B \to 0$在L_1中随着$n \to \infty$趋向，这是Birkhoff-Khintchine定理的结果。因此，对于任何固定的m，$\mathbb{E}B \to 0$随着$n \to \infty$。
- 对于术语 A，应用下一个引理 12.10，

$$\mathbb{E}[A] = \frac{1}{n}\mathbb{E}_P\Big|\log\frac{dP_{S^n}}{dQ^{(m)}_{S^n}}\Big| \le \frac{1}{n}D(P_{S^n}\|Q^{(m)}_{S^n}) + \frac{2\log e}{en}$$

其中

$$\begin{aligned}\frac{1}{n}D(P_{S^n}\|Q^{(m)}_{S^n}) &= \frac{1}{n}\mathbb{E}\left[\log\frac{P_{S^n}(S^n)}{P_{S^m}(S^m)\prod_{t=m+1}^{n}P_{S_{m+1}|S_m^1}(S_t|S_{t-m}^{t-1})}\right]\\ &= \frac{1}{n}(-H(S^n)+H(S^m)+(n-m)H_m)\\ &\to H_m-\mathcal{H} \text{ as } n\to\infty,\end{aligned}$$

根据平稳性，第二个等式再次成立。

结合所有三项并发送 $n \to \infty$，对于任意 m，我们得到

$$\limsup_{n\to\infty}\mathbb{E}\Big|\frac{1}{n}\log\frac{1}{P_{S^n}(S^n)}-\mathcal{H}\Big| \le 2(H_m-\mathcal{H}).$$

发送 $m \to \infty$ 完成了 L_1-收敛性的证明。 □

引理 12.10

$$\mathbb{E}_P\left[\left|\log\frac{dP}{dQ}\right|\right] \le D(P\|Q) + \frac{2\log e}{e}.$$

Proof. $|x\log x| - x\log x \le \frac{2\log e}{e}, \forall x > 0$，因为如果 $x \ge 1$，则左侧为零，否则上界为 2 $\sup_{0\le x\le 1} x\log\frac{1}{x} = \frac{2\log e}{e}$。 □

12.4* Birkhoff-Khintchine定理的证明

Proof of Theorem 12.8. 对于任意函数 $\tilde{f} \in L_1$ 和任意 ϵ，存在一个分解 $\tilde{f} = f + h$，使得 f 有界，且 $h \in L_1$ 满足 $\|h\|_1 = \mathbb{E}\,|h(S_1^\infty)| \le \epsilon$。

首先，我们聚焦于有界函数f。注意在有界域$\mathcal{L}_1 \subset L_2$中，因此$f \in L_2$。此外，$L_2$是一个希尔伯特空间，其内积为$(f,g) = \mathbb{E}[f(S_1^\infty)\overline{g(S_1^\infty)}]$。

对于生成平稳过程 $\{S_i\}$ 的保测变换 τ，定义算子 $T(f) = f \circ \tau$。由于 τ 是保测的，我们知道 $\|Tf\|_2^2 = \|f\|_2^2$，因此 T 是一个酉有界算子。

定义运算符 {v*}

$$A_n(f) = \frac{1}{n}\sum_{k=1}^{n} f \circ \tau^k$$

直观地说：

$$A_n = \frac{1}{n}\sum_{k=1}^{n} T^k = \frac{1}{n}(I - T^n)(I - T)^{-1}$$

然后，如果f ⊥属于ker$(I - T)$，则应有$A_n f \to$为零，因为只有核中的分量才会爆炸。这一直觉在下面的证明中得到了形式化。

让我们进一步将f分解为两部分$f = f_1 + f_2$，其中$f_1 \in \ker(I-T)$ 和$f_2 \in \ker(I-T)^\perp$。我们做出以下观察：

- 如果 $g \in \ker(I - T)$，则 g 必须是常数函数。这是由遍历性导致的。考虑指示函数 1_A：如果 $1_A = 1_A \circ \tau = 1_{\tau^{-1}A}$，那么 $\mathbb{P}[A] = 0$ 或 1。对于一般情况，假设 $g = Tg$ 且 g 不是常数，那么至少某个集合 $\{g \in (a,b)\}$ 将是平移不变的并且具有非平凡测度，从而违反遍历性。
- $\ker(I - T) = \ker(I - T^*)$。这是由于$T$是酉的：

$$g = Tg \Rightarrow \|g\|^2 = (Tg, g) = (g, T^*g) \Rightarrow (T^*g, g) = \|g\|\|T^*g\| \Rightarrow T^*g = g$$

在最后一步中，我们使用了柯西-施瓦茨（f,g）$\le \|f\| \cdot \|g\|$仅对$g = cf$某个常数c取等号这一事实。• $\ker(I - T)^\perp = \ker(I - T^*)^\perp = [\mathrm{Im}(I - T)]$，其中[Im$(I - T)$]表示一个$L_2$闭包。
- $g \in \ker(I - T)^\perp \iff \mathbb{E}[g] = 0$。事实上，只有零均值函数与常数正交。

基于这些观察，我们知道$f_1 = m$是一个常数。此外，$f_2 \in [\mathrm{Im}(I - T)]$，因此我们进一步用$f_2 = f_0 + h_1$来近似它，其中$f_0 \in \mathrm{Im}(I - T)$，即对于某个函数$g \in L_2$，有$f_0 = g - g \circ \tau$，并且$\|h_1\|_1 \le \|h_1\|_2 < \epsilon$。因此，我们得到

$$A_n f_1 = f_1 = \mathbb{E}[f]$$
$$A_n f_0 = \frac{1}{n}(g - g \circ \tau^n) \to 0 \text{ a.s. and } L_1$$

由于 $\mathbb{E}[\sum_{n\ge1}(\frac{g\circ\tau^n}{n})^2] = \mathbb{E}[g^2]\sum \frac{1}{n^2} < \infty$，因此由 Borel-Cantelli 得 $\frac{1}{n} g \circ \tau^n \xrightarrow{\text{a.s.}} 0$。

证明通过展示以下内容完成：

$$\mathbb{P}\left[\limsup_n A_n(h+h_1) \geq \delta\right] \leq \frac{2\epsilon}{\delta}. \tag{12.6}$$

确实，那么通过取$\epsilon \to 0$，我们将已经展示

$$\mathbb{P}\left[\limsup_{n\to\infty} A_n(f) \geq \mathbb{E}[f] + \delta\right] = 0$$

根据需要，反向亦类似展示。 □

(12.6) 的证明利用了如下所述的最大遍历引理：

定理 12.11（最大遍历引理）*Let $(\mathbb{P},\tau)$ be a probability measure and a measure-preserving transformation. Then for any $f \in L_1(\mathbb{P})$ we have*

$$\mathbb{P}\left[\sup_{n\geq 1} A_n f > a\right] \leq \frac{\mathbb{E}[f1\left\{\sup_{n\geq 1} A_n f > a\right\}]}{a} \leq \frac{\|f\|_1}{a}$$

where $A_n f = \frac{1}{n}\sum_{k=0}^{n-1}$.

这是所谓的次线性算子 $\sup_n A_n(\cdot)$ 的“弱 L_1”估计。事实上，这个定理恰好等价于以下结果：

引理 12.12（平均值的最大值估计）*Let $\{Z_n\colon\ n = 1,\ldots\}$ be a stationary process with $\mathbb{E}[|Z_1|] < \infty$ then*

$$\mathbb{P}\left[\sup_{n\geq 1} \frac{Z_1 + \ldots + Z_n}{n} > a\right] \leq \frac{\mathbb{E}[|Z_1|]}{a} \qquad \forall a > 0.$$

Proof. 这个引理的论证原本相当复杂，直到A. Garsia发现了一个极为简洁的证明（见下文）[180, 定理2.2.2]。定义

$$\begin{aligned} S_n &= \sum_{k=1}^{n} Z_k, \\ L_n &= \max\{0, Z_1, \ldots, Z_1 + \cdots + Z_n\}, \\ M_n &= \max\{0, Z_2, Z_2 + Z_3, \ldots, Z_2 + \cdots + Z_n\}, \\ Z^* &= \sup_{n\geq 1} \frac{S_n}{n}. \end{aligned}$$

只需证明

$$\mathbb{E}[Z_1 1_{\{Z^*>0\}}] \geq 0. \tag{12.7}$$

确实，将（12.7）应用于$\tilde{Z}_1 = Z_1 - a$，并注意到$\tilde{Z}^* = Z^* - a$，我们得到

$$\mathbb{E}[Z_1 1_{\{Z^*>a\}}] \geq a\mathbb{P}[Z^* > a],$$

由此，通过对$\mathbb{E}[|Z_1|]$左侧进行上界估计，可得引理。

为了展示(12.7)，我们注意到

$$Z_1 + M_n = \max\{S_1, \ldots, S_n\}$$

此外

$$Z_1 + M_n = L_n \qquad \text{on } \{L_n > 0\}$$

因此，我们有

$$Z_1 1_{\{L_n>0\}} = L_n - M_n 1_{\{L_n>0\}}$$

其中我们不需要第一项中的指示符，因为在 $\{L_n > 0\}^c$ 上 $L_n = 0$。取期望得到

$$\begin{aligned} \mathbb{E}[Z_1 1_{\{L_n>0\}}] &= \mathbb{E}[L_n] - \mathbb{E}[M_n 1_{\{L_n>0\}}] \\ &\geq \mathbb{E}[L_n] - \mathbb{E}[M_n] \\ &= \mathbb{E}[L_n] - \mathbb{E}[L_{n-1}] = \mathbb{E}[L_n - L_{n-1}] \geq 0\,, \end{aligned} \tag{12.8}$$

其中我们使用了 $M_n \geq 0$，M_n 与 L_{n-1} 具有相同分布的事实，以及 $L_n \geq L_{n-1}$。在 (12.8) 中对 $n \to \infty$ 取极限，并注意到 $\{L_n > 0\} \nearrow \{Z^* > 0\}$，我们得到 (12.7)。

□

12.5* 西奈生成元定理

正如我们在本章引言中提到的，自然科学中存在一个经典的难题。我们对原子运动的微观描述是完全确定性的（即给定时间t时原子的位置和速度，存在一个算子τ给出它们在时间$t+1$时的位置）。另一方面，在许多方面，大型系统的行为是概率性的（如统计力学、吉布斯分布等所描述）。随着*Kolmogorov-Sinai entropy*的引入，一个重要的概念桥梁被建立起来，简而言之，它试图通过注意到我们在时间t描述系统的方式通常只涉及有限多个比特来解决这个难题，因此，虽然τ在作用于状态的完整描述时是确定性的，但从任何有限比特描述的角度来看，τ似乎表现为*stochastically*。

更正式地说，我们为每个保概率变换（p.p.t.）τ关联一个数，称为科尔莫戈罗夫-西奈熵。这个数在（适当定义的）p.p.t.同构下是不变的。西奈的生成元定理随后允许人们计算科尔莫戈罗夫-西奈熵。

定义12.13 固定一个概率保持变换 τ 作用于概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$。$\tau$ 的柯尔莫哥洛夫-西奈熵定义为

$$\mathcal{H}(\tau) \triangleq \sup_{X_0} \lim_{n\to\infty} \frac{1}{n} H(X_0, X_0 \circ \tau, \ldots, X_0 \circ \tau^{n-1})\,,$$

其中上确界取遍所有有限值随机变量 X_0: $\Omega \to \mathcal{X}$ 关于 $\mathcal{F}$ 可测。

注意，每个随机变量 X_0 生成一个适应于 τ 的平稳过程，即

$$X_k \triangleq X_0 \circ \tau^k .$$

这样，τ的柯尔莫哥洛夫-西奈熵等于所有适应于τ的平稳过程中的最大熵率。然而，这个量可能极难评估。这时，Y. Sinai的著名准则提供了一种帮助。在此之前，我们需要进一步阐述一些概念:

- σ-代数 $\mathcal{G} \subset \mathcal{F}$ 在 $\mathcal{F}$ 中是 $\mathbb{P}$-*dense*，有时我们也说 $\mathcal{G} = \mathcal{F} \bmod \mathbb{P}$ 甚至 $\mathcal{G} = \mathcal{F} \bmod 0$，如果对于每个 $E \in \mathcal{F}$ 存在 $E' \in \mathcal{G}$ 使得

$$\mathbb{P}[E \Delta E'] = 0 .$$

- 划分 $\mathcal{A} = \{A_i : \ i = 1, 2, \ldots\}$ 关于 $\mathcal{F}$ 可测，若

$$\bigvee_{n=0}^{\infty} \sigma\{\tau^{-n}\mathcal{A}\} = \mathcal{F} \mod \mathbb{P} .$$

- 随机变量 Y: $\Omega \to \mathcal{Y}$，带有 *countable* 字母表 $\mathcal{Y}$，如果满足以下条件，则称为 $(\Omega, \mathcal{F}, \mathbb{P}, \tau)$ 的 *generator*:

$$\sigma\{Y, Y \circ \tau, \ldots, Y \circ \tau^n, \ldots\} = \mathcal{F} \mod \mathbb{P}$$

定理 12.14（Sinai 生成元定理）*Let Y be the generator of a p.p.t. $(\Omega, \mathcal{F}, \mathbb{P}, \tau)$. Let $H(\mathbb{Y})$ be the entropy rate of the process $\mathbb{Y} = \{Y_k = Y \circ \tau^k : \ k = 0, \ldots\}$. If $H(\mathbb{Y})$ is finite, then $\mathcal{H}(\tau) = H(\mathbb{Y})$.*

Proof. 注意，由于 $H(\mathbb{Y})$ 是有限的，我们必须有 $H(Y_0^n) < \infty$，从而 $H(Y) < \infty$。首先，我们论证 $\mathcal{H}(\tau) \geq H(\mathbb{Y})$。如果 Y 具有有限字母表，那么这直接由定义得出。否则，令 Y 为 $\mathbb{Z}_+$ 值的。定义一个截断版本 $\tilde{Y}_m = \min(Y, m)$，那么由于 $\tilde{Y}_m \to Y$ 作为 $m \to \infty$，我们从互信息的下半连续性，参见 (4.28)，有

$$\lim_{m \to \infty} I(Y; \tilde{Y}_m) \geq H(Y) ,$$

因此对于任意小的 ϵ 和足够大的 m

$$H(Y|\tilde{Y}) \leq \epsilon ,$$

然后，考虑链

$$\begin{aligned} H(Y_0^n) &= H(\tilde{Y}_0^n, Y_0^n) = H(\tilde{Y}_0^n) + H(Y_0^n|\tilde{Y}_0^n) \\ &= H(\tilde{Y}_0^n) + \sum_{i=0}^{n} H(Y_i|\tilde{Y}_0^n, Y_0^{i-1}) \end{aligned}$$

$$\le H(\tilde{Y}_0^n) + \sum_{i=0}^{n} H(Y_i|\tilde{Y}_i)$$
$$= H(\tilde{Y}_0^n) + nH(Y|\tilde{Y}) \le H(\tilde{Y}_0^n) + n\epsilon$$

因此，有限字母表)上的$\tilde{\mathbb{Y}}$ (的熵率可以任意接近$\mathbb{Y}$的熵率，从而得出结论$\mathcal{H}(\tau) \ge \mathcal{H}(\mathbb{Y})$。

证明的主要部分是表明，对于任何适应于τ的平稳过程$\mathbb{X}$，熵率的上界为$H(\mathbb{Y})$。为此，考虑$X\colon\ \Omega \to \mathcal{X}$具有有限的$\mathcal{X}$，并如常定义过程$\mathbb{X} = \{X \circ \tau^k\colon\ k = 0, 1, \ldots\}$。根据$\mathbb{Y}$的生成性质，我们得知$X$ (——或许在一个测度为零的集合上经过修改后)——是Y_0^∞的函数。所有的X_k也是如此。因此

$$H(X_0) = I(X_0; Y_0^\infty) = \lim_{n\to\infty} I(X_0; Y_0^n)\,,$$

其中我们使用了互信息的σ-代数连续性性质，参见(4.30)。用不同方式重写后一个极限，我们有

$$\lim_{n\to\infty} H(X_0|Y_0^n) = 0\,.$$

修复 $\epsilon > 0$ 也选择 m 使得 $H(X_0|Y_0^m) \le \epsilon$。然后考虑以下 ing链:

$$H(X_0^n) \le H(X_0^n, Y_0^n) = H(Y_0^n) + H(X_0^n|Y_0^n)$$
$$\le H(Y_0^n) + \sum_{i=0}^{n} H(X_i|Y_i^n)$$
$$= H(Y_0^n) + \sum_{i=0}^{n} H(X_0|Y_0^{n-i})$$
$$\le H(Y_0^n) + m\log|\mathcal{X}| + (n-m)\epsilon\,,$$

其中我们利用了(X_k, Y_k)的平稳性以及$H(X_0|Y_0^{n-i}) < \epsilon$对于$i \le n - m$的事实。在除以$n$并取极限后，我们的论证表明

$$H(\mathbb{X}) \le H(\mathbb{Y}) + \epsilon\,.$$

在这里取 $\epsilon \to 0$ 即可完成证明。

Alternative proof: 假设 X_0 在一个有限字母表 $\mathcal{X}$ 和 $X_0 = f(Y_0^\infty)$ 上取值。那么（这是一个测度论事实）对于每个 $\epsilon > 0$，存在 $m = m(\epsilon)$ 和一个函数 $f_\epsilon\colon\ \mathcal{Y}^{m+1} \to \mathcal{X}$，使得

$$\mathbb{P}[f(Y_0^\infty) \ne f_\epsilon(Y_0^m)] \le \epsilon\,.$$

(这只是说 $\bigcup_n \sigma(Y_0^n)$ 在 $\sigma(Y_0^\infty)$ 中是 $\mathbb{P}$-稠密的另一种说法。) 将平稳过程 $\tilde{\mathbb{X}}$ 定义为

$$\tilde{X}_j \triangleq f_\epsilon(Y_j^{m+j})\,.$$

注意，由于$\tilde{X}_0^n$是Y_0^{n+m}的函数，我们有

$$H(\tilde{X}_0^n) \le H(Y_0^{n+m})\,.$$

除以 m 并取极限，我们得出熵率满足

$$H(\tilde{\mathbb{X}}) \le H(\mathbb{Y}) .$$

最后，为了将 $\tilde{\mathbb{X}}$ 与 $\mathbb{X}$ 联系起来，请注意根据构造对于每个 j

$$\mathbb{P}[\tilde{X}_j \neq X_j] \le \epsilon .$$

由于这两个过程都在一个固定的有限字母表上取值，由推论6.7我们推断

$$|H(\mathbb{X}) - H(\tilde{\mathbb{X}})| \le \epsilon \log |\mathcal{X}| + h(\epsilon) .$$

总之，我们已经证明了 $H(\mathbb{X}) \le H(\mathbb{Y}) + \epsilon \log |\mathcal{X}| + h(\epsilon)$。取 $\epsilon \to 0$ 即可完成证明。

□

定理 12.14 的一些示例如下:

- 令 $\Omega = [0,1]$，$\mathcal{F}$ 博雷尔 σ-代数，$\mathbb{P} =$ Leb 且

$$\tau(\omega) = 2\omega \mod 1 = \begin{cases} 2\omega, & \omega < 1/2 \\ 2\omega - 1, & \omega \ge 1/2 \end{cases}$$

很容易证明 $Y(\omega) = 1\{\omega < 1/2\}$ 是一个生成元，并且 $\mathbb{Y}$ 是一个独立同分布的 Bernoulli(1/2) 过程。因此，我们得到 Kolmogorov-Sinai 熵为 $\mathcal{H}(\tau) = \log 2$。
让我们理解这个例子和Sinai结果的意义。如果我们有系统初始状态的完全“微观”描述ω，那么系统的未来状态是完全确定的：$\tau(\omega), \tau(\tau(\omega)), \cdots$。然而，在实践中，我们不可能对初始状态有一个完整的描述，而应该满足于一些离散的（即有限的或可数无限的）测量结果$Y(\omega)$，$Y(\tau(\omega))$等。我们从之前的结果中推断出，无论我们的离散测量多么精细，它们仍然会生成一个具有有限熵率的过程（等于每次测量log 2比特）。
This reconciles the
*apparent paradox between Newtonian (dynamical) and Gibbsian (statistical) points of view on large mechanical systems.*用更通俗的话来说，我们可能会注意到Sinai定理告诉我们，更复杂的随机过程（例如由三值测量$Y'(\omega = 1\{\omega > 1/3\} + 1\{\omega > 2/3\})$生成的过程）仍然会具有与简单的iid Bernoulli(1/2)过程相同的熵率。

- 令 Ω 为单位圆 $\mathbb{S}^1$，$\mathcal{F}$ 为 Borel σ-代数，$\mathbb{P}$ 为归一化长度且

$$\tau(\omega) = \omega + \gamma$$

即 τ 是角度 γ 的旋转。（当 $\frac{\gamma}{2\pi}$ 为无理数时，这已知是一个遍历的 p.p.t.）。这里 $Y = 1\{|\omega| < 2\pi\epsilon\}$ 是任意小 ϵ 的生成元，因此

$$\mathcal{H}(\tau) \le H(\mathbb{X}) \le H(Y_0) = h(\epsilon) \to 0 \qquad \text{as } \epsilon \to 0 .$$

这是一个零熵p.p.t.的示例。

注12.3 若存在几乎处处定义的映射f_i：$\Omega_i \to \Omega_{1-i} \to \Omega_i \to \Omega_{1-i}$，满足以下条件，则称两个保测变换$(\Omega_1, \tau_1, \mathbb{P}_1)$和$(\Omega_0, \tau_0, \mathbb{P}_0)$是同构的：1）$\tau_{1-i} \circ f_i = f_{1-i} \circ \tau_i$；2）$f_i \circ f_{1-i}$在$\Omega_i$(上几乎处处等于恒等映射)；3）$\mathbb{P}_i[f_{1-i}^{-1}E] = = \mathbb{P}_{1-i}[E]$。易见同构的保测变换具有相同的Kolmogorov-Sinai熵。这一观察由Kolmogorov于1958年作出。它具有革命性意义，因为它使得证明对应于独立同分布Ber(1/2)和独立同分布Ber(1/3)过程的移位所对应的保测变换不同构成为可能。在此之前，已知的不变量仅来自于对酉算子谱的研究

$$U_\tau : L_2(\Omega, \mathbb{P}) \to L_2(\Omega, \mathbb{P}) \tag{12.9}$$

$$\phi(x) \mapsto \phi(\tau(x)) \,. \tag{12.10}$$

但是，任何非恒定独立同分布过程对应的τ的谱包含整个单位圆，因此无法区分Ber(1/2)和Ber(1/3)。[2]

[2] To see the statement about the spectrum, let X_i be iid with zero mean and unit variance. Then consider $\phi(x_1^\infty)$ defined as $\frac{1}{\sqrt{m}} \sum_{k=1}^m e^{i\omega k} x_k$. This ϕ has unit energy and as $m \to \infty$ we have $\|U_\tau \phi - e^{i\omega}\phi\|_{L_2} \to 0$. Hence every $e^{i\omega}$ belongs to the spectrum of U_τ.

13 Universal compression

不幸的是，迄今为止所发展的理论对于真正需要压缩英文文本文件的人来说并不十分有用。事实上，由于支配文本生成的概率规律并未给定，我们无法应用之前讨论的压缩结果。在本章中，我们将讨论如何生成不需要先验分布知识的压缩方案。例如，一个n字母输入压缩器映射$\mathcal{X}^n \to \{0,1\}^*$。在$\mathcal{X}^n$上不存在单一固定的概率分布$P_{X^n}$，而是存在一整类分布。因此，压缩问题与*distribution (density) estimation*问题交织在一起，我们将看到这两个问题的最优算法是等价的。

本章的计划如下:

1 我们将首先讨论通用压缩算法的最早例子（Fitingof的）。它根本不涉及概率分布。然而，事实证明，它同时对所有独立同分布分布渐近最优，并且对于所有有限阶马尔可夫链经过小修改后也是如此。

2 下一类通用压缩器基于假设真实分布 P_{X^n} 属于给定类别。这些方法通过选择一个好的模型分布 Q_{X^n} 作为该类中每个分布的极小极大近似来进行。然后，针对单个分布 Q_{X^n} 的压缩算法按照前几章的方式设计。3 最后，一种完全不同的思路是 Lempel-Ziv 类型的算法。这些算法自动适应源的分布，无需任何先验假设。

在本章中，所有对数均为二进制。我们不再描述每种压缩算法，而是仅指定一些分布Q_{X^n}，并应用以下构造之一:

- 将所有 x^n 按 $Q_{X^n}(x^n)$ 递减的顺序排序，并按定理 10.2 从 $\{0,1\}^*$ 赋值，该压缩器的长度满足

$$\ell(f(x^n)) \le \log \frac{1}{Q_{X^n}(x^n)}\,.$$

- 将长度设置为

$$\ell(f(x^n)) \triangleq \left\lceil \log \frac{1}{Q_{X^n}(x^n)} \right\rceil$$

并应用Kraft不等式定理10.9来构造一个前缀码。

- 使用算术编码（见下一节）。

重要的结论是，在所有这些情况下我们都有

$$\ell(f(x^n)) = \log \frac{1}{Q_{X^n}(x^n)} \pm \text{universal constant}\,,$$

因此，我们始终可以用对数$\frac{1}{Q_{X^n}(x^n)}$来代替长度。在这种架构中，通用压缩算法的唯一任务是指定 Q_{X^n}，在此上下文中称为 *universal probability assignment* 。

如果对$Q_{X^n} = \prod_{t=1}^{n} Q_{X_t|X_1^{t-1}}$进行因式分解，那么我们会得出一个至关重要的结论：在 log -loss 下，*universal compres- sion* 等价于 *sequential (online) prediction*，而这本身仅仅是学习理论中密度估计任务的一个版本。这种压缩与学习理论之间的激动人心的联系将在第13.6节中探讨，并且是本章的一个亮点。

反过来，机器学习也推动了通用压缩技术的进步。截至2022年，性能最佳的文本压缩算法（参见[289]的排行榜）采用的是从固定初始化开始的深度神经网络（具体而言，是变换器模型）。随着输入文本的处理，网络参数通过随机梯度下降不断更新，从而逐渐提升预测（进而压缩）性能。

因此，本章既可视为信息论领域（通用压缩）的一系列成果，也可视为机器学习领域（在线预测/密度估计）的一系列成果。

13.1 算术编码

如果 n 很大，从 Q_{X^n} 构建编码表可能需要大量资源。算术编码提供了一种便捷的变通方法，允许编码器按顺序输出比特。

Notice that to do so, it requires that not only Q_{X^n} but also its marginalizations $Q_{X^1}, Q_{X^2}, \cdots$ be easily computable. (例如，对于 Shtarkov 分布（13.12)-（13.14），它们对于不同的 n 并不兼容），情况并非如此。

让我们在字母表$\mathcal{X}$ (上约定某种顺序，例如$\mathsf{a} < \mathsf{b} < \cdots < \mathsf{z}$)，并将此顺序按字典序扩展到$\mathcal{X}^n$ (，即对于$x = (x_1, \ldots, x_n)$和$y = (y_1, \ldots, y_n)$，如果对于第一个满足$x_i \neq y_i$的i有$x_i < y_i$，我们说$x < y$，例如$\mathsf{baba} < \mathsf{babb}$)。然后令

$$F_n(x^n) = \sum_{y^n < x^n} Q_{X^n}(y^n)\,.$$

将每个 x^n 关联到一个区间 $I_{x^n} = [F_n(x^n), F_n(x^n) + Q_{X^n}(x^n))$。这些区间是 $[0, 1)$ 的不相交子区间。因此，每个 x^n 都可以由区间 I_{x^n} 中的任意一点唯一表示。一种具体的选择如下。编码

$$x^n \mapsto \text{largest dyadic interval } D_{x^n} \text{ contained in } I_{x^n} \tag{13.1}$$

并且当存在两种可能性时，我们同意选择最左边的二进区间。回顾一下，二进区间是形式为 $[m2^{-k}, (m+1)2^{-k})$ 的区间，其中 m 是整数。我们通过分数 $m2^{-k}$ 的 k 位（零填充）二进制展开来编码这样的区间。

$0.b1b_2\ldots b_k = \sum_{i=1}^{k} b_i 2^{-i}$。例如，$[3/4, 7/8) \mapsto 110$, $[3/4, 13/16) \mapsto 1100$。我们将码字$f(x^n)$设为该字符串。生成的代码是满足以下条件的前缀码：

$$\log_2 \frac{1}{Q_{X^n}(x^n)} \le \ell(f(x^n)) \le \left\lceil \log_2 \frac{1}{Q_{X^n}(x^n)} \right\rceil + 1\,. \tag{13.2}$$

(这是一个练习，见练习 II.13.)

注意

$$F_n(x^n) = F_{n-1}(x^{n-1}) + Q_{X^{n-1}}(x^{n-1}) \sum_{y<x_n} Q_{X_n|X^{n-1}}(y|x^{n-1})$$

因此，$F_n(x^n)$ 可以依次计算 *if* $Q_{X^{n-1}}$ *and* $Q_{X_n|X^{n-1}}$ *are easy to compute.*。在许多现代压缩算法中，这种方法是首选，因为它允许以更新 $Q_{X_n|X^{n-1}}$ (的形式动态融入关于数据流的已学信息，例如，如果算法检测到可执行文件包含一大段英文文本，它可以暂时切换到 $Q_{X_n|X^{n-1}}$ 对英语建模)。

我们注意到，算术编码器和解码器的高效实现是一个持续的研究领域。实际上，性能取决于分布分母的数论性质$Q_{X_t|X^{t-1}}$，因为随着编码器/解码器在字符串上的推进，它们需要周期性地将当前区间I_{x^t}重新归一化为[0, 1)，但这需要仔细地对齐二进制边界。J. Duda最近提出的一个想法，被称为*asymmetric numeral system (ANS)* [138]，带来了令人印象深刻的计算增益，以至于在不到十年的时间里，它被大多数处理多样化数据流的压缩库所采用（例如，Linux内核映像、Dropbox和Facebook流量等）。

13.2 菲廷戈夫的组合构造

Fitingof [170] 提出，序列$x^n \in \mathcal{X}^n$应被赋予信息量$\Phi_0(x^n)$，该信息量等于由x^n (所能获得的所有可能排列数的对数，即包含x^n)的类型类的对数大小。正如我们在命题1.5中所展示的：

$$\Phi_0(x^n) = nH(x_T) + O(\log n) \quad T \sim \mathrm{Unif}([n]) \tag{13.3}$$

$$= nH(\hat{P}_{x^n}) + O(\log n)\,, \tag{13.4}$$

其中 $\hat{P}_{x^n}$ 是序列 x^n 的经验分布：

$$\hat{P}_{x^n}(a) \triangleq \frac{1}{n} \sum_{i=1}^{n} 1\{x_i = a\}\,. \tag{13.5}$$

然后Fitingof认为，应该能够生成一个前缀码，其

$$\ell(f(x^n)) = \Phi_0(x^n) + O(\log n)\,. \tag{13.6}$$

这可以通过多种方式实现。本着后续内容的精神，让我们定义

$$Q_{X^n}(x^n) \triangleq \exp\{-\Phi_0(x^n)\} c_n\,, \tag{13.7}$$

其中归一化常数 c_n 由类型数量决定，即 $c_n = 1/\binom{n+|\mathcal{X}|-1}{|\mathcal{X}|-1}$。计算不同的经验分布（类型）的数量，我们得到

$$c_n = O(n^{-(|\mathcal{X}|-1)}),$$

因此，根据Kraft不等式，必定存在满足(13.6)的长度前缀码。[1] 现在对$X^n \overset{\text{i.i.d.}}{\sim} P_X$取期望，我们得到

$$\mathbb{E}[\ell(f(X^n))] = nH(P_X) + (|\mathcal{X}|-1)\log n + O(1),$$

对于$\mathcal{X}$上的每个独立同分布源。

通用压缩器，适用于所有有限阶马尔可夫链。Fitingof 的思想可以如下扩展。现在将一阶信息量 $\Phi_1(x^n)$ 定义为所有序列数量的对数，这些序列可通过置换 x^n 得到，并附加限制：新序列在双字母组上的统计量应相同。渐近地，Φ_1 正是条件熵

$$\Phi_1(x^n) = nH(x_T|x_{T-1}) + O(\log n), \quad T \sim \mathrm{Unif}([n]),$$

其中 $T-1$ 是在模 n 的意义下理解的。同样，可以证明存在一种码，使得长度

$$\ell(f(x^n)) = \Phi_1(x^n) + O(\log n).$$

这意味着对于每个一阶平稳马尔可夫链 $X_1 \to X_2 \to \cdots \to X_n$，我们有

$$\mathbb{E}[\ell(f(X^n))] = nH(X_2|X_1) + O(\log n).$$

这里可以进一步继续定义$\Phi_2(x^n)$，从而导出一个对所有二阶马尔可夫链渐近最优的通用代码，以此类推。

13.3 一类源的最优压缩器。冗余度。

因此我们已经看到，我们可以构造压缩器 $f\colon \mathcal{X}^n \to \{0,1\}^*$，它达到

$$\mathbb{E}[\ell(f(X^n))] \le H(X^n) + o(n),$$

同时对所有的独立同分布源（甚至所有r阶马尔可夫链）。接下来我们该做什么？Krichevsky [259] 提出，下一个障碍应是最小化遗憾，即 *redundancy*：

$$\mathbb{E}[\ell(f(X^n))] - H(X^n)$$

同时对于给定类别中的所有源。我们继续进行严格的定义。

[1] Explicitly, we can do a two-part encoding: first describe the type class of x^n (takes $(|\mathcal{X}|-1)\log n$ bits) and then describe the element of the class (takes $\Phi_0(x^n)$ bits).

给定一组 $\{P_{X^n|\theta}:\theta\in\Theta\}$ 的源，以及压缩器 $f:\mathcal{X}^n\to\{0,1\}^*$，我们将其冗余定义为

$$\sup_{\theta_0}\mathbb{E}[\ell(f(X^n))|\theta=\theta_0]-H(X^n|\theta=\theta_0)\,.$$

用对数 $\frac{1}{Q_{X^n}}$ 替换代码长度，我们将分布 Q_{X^n} 的冗余定义为

$$\sup_{\theta_0}D(P_{X^n|\theta=\theta_0}\|Q_{X^n})\,.$$

因此，设计最好的通用压缩器（在优化平均长度与熵的最坏情况偏差的意义上）的问题就变成了求解以下问题:

$$Q^*_{X^n}=\operatorname*{argmin}_{Q_{X^n}}\sup_{\theta_0}D(P_{X^n|\theta=\theta_0}\|Q_{X^n})\,.$$

因此，我们得到以下定义

定义 13.1（通用压缩中的冗余）给定一类源 $\{P_{X^n|\theta=\theta_0}:\ \theta_0\in\Theta,n=1,\dots\}$，我们定义其极小极大冗余为

$$\mathcal{R}^*_n\equiv\mathcal{R}^*_n(\Theta)\triangleq\min_{Q_{X^n}}\sup_{\theta_0\in\Theta}D(P_{X^n|\theta=\theta_0}\|Q_{X^n})\,.\tag{13.8}$$

假设$\mathcal{R}^*_n$的有限性，定理5.9给出了最大最小和容量表示

$$\mathcal{R}^*_n=\sup_{\pi}\min_{Q_{X^n}}D(P_{X^n|\theta}\|Q_{X^n}|\pi)\tag{13.9}$$

$$=\sup_{\pi}I(\theta;X^n)\,,\tag{13.10}$$

其中优化是在先验 $\pi\in\mathcal{P}(\Theta)$ 上对 θ 进行的。因此，冗余就是信道 $\theta\to X^n$ 的容量。这个结果事后看来显而易见，但在通用压缩的早期却相当令人惊讶。它被称为 *capacity-redundancy theorem*。

在(13.8)中找到精确的Q_{X^n}-极小化点，即使对于所有独立同分布的伯努利源这一简单类别（即$\Theta=[0,1]$，$P_{X^n|\theta}=\mathrm{Ber}^n(\theta)$）而言，也是一项艰巨的任务。事实上，对于光滑参数族，达到容量的输入分布相当繁琐：它是一个具有k_n个原子的离散分布，k_n随$n\to\infty$缓慢增长。物理学家[296, 2]提出了一个具有挑衅性的猜想，认为存在某种普适性关系:

$$\mathcal{R}^*_n=\frac{3}{4}\log k_n+o(\log k_n)$$

对所有参数族同时满足。对于伯努利例子，这意味着$k_n\asymp n^{2/3}$，但即使这一点也是未解决的。然而，如下所示，这些难以处理的能力达成输入分布随着$n\to\infty$收敛到一个美丽的极限定律，称为Jeffreys先验。

注13.1（Shtarkov、Fitingof与个体序列方法）Fitingof的组合方法与类最优性方法之间存在联系。实际上，

按照Shtarkov的方法，我们可能希望选择分布 Q_{X^n}，以便最小化最坏情况下的冗余度 *for each realization* x^n (而非平均值！)：

$$\mathcal{R}_n^{**}(\Theta) \triangleq \min_{Q_{X^n}} \max_{x^n} \sup_{\theta_0 \in \Theta} \log \frac{P_{X^n|\theta}(x^n|\theta_0)}{Q_{X^n}(x^n)} \tag{13.11}$$

该最小化在 *Shtarkov distribution* (处达到，也称为 *normalized maximal likelihood* (NML) 码)：

$$Q_{X^n}^{(\mathrm{S})}(x^n) = \frac{1}{Z} \sup_{\theta_0 \in \Theta} P_{X^n|\theta}(x^n|\theta_0)\,, \tag{13.12}$$

其中归一化常数

$$Z = \sum_{x^n \in \mathcal{X}^n} \sup_{\theta_0 \in \Theta} P_{X^n|\theta}(x^n|\theta_0)\,, \tag{13.13}$$

称为 *Shtarkov sum*。如果类 $\{P_{X^n|\theta}\colon \theta \in \Theta\}$ 被选为 $\mathcal{X}$ 上的所有乘积分布，那么

$$\text{(i.i.d.)} \quad Q_{X^n}^{(\mathrm{S})}(x^n) = \frac{\exp\{-nH(\hat{P}_{x^n})\}}{\sum_{x^n} \exp\{-nH(\hat{P}_{x^n})\}}\,, \tag{13.14}$$

其中 $H(\hat{P}_{x^n})$ 是 x^n 的经验熵。因此，相对于 $Q_{X^n}^{(\mathrm{S})}$ 进行压缩可以恢复 Fitingof 的构造 Φ_0，直到 $nH(\hat{P}_{x^n})$ 与 $\Phi_0(x^n)$ 之间的 $O(\log n)$ 差异。如果我们取 $P_{X^n|\theta}$ 为所有一阶马尔可夫链，那么我们就得到构造 Φ_1 等等。另请注意，问题 (13.11) 也可以写成在 log-loss 下，针对参数类 $P_{X^n|\theta}$)，对每个 *individual sequence* (的遗憾最小化：

$$\min_{Q_{X^n}} \max_{x^n} \left\{ \log \frac{1}{Q_{X^n}(x^n)} - \inf_{\theta_0 \in \Theta} \log \frac{1}{P_{X^n|\theta}(x^n|\theta_0)} \right\}. \tag{13.15}$$

总之，使用 Shtarkov 分布（即 (13.15) 的最小化者）可以确保任何单个实现 x^n (，无论它是否由 $P_{X^n|\theta=\theta_0}$ 对某个 θ_0) 生成，其压缩效果几乎与为该类 $P_{X^n|\theta}$ 定制的最佳压缩器一样好。因此，如果我们的模型类 $P_{X^n|\theta}$ 很好地近似了 x^n 的生成过程，我们就能实现近乎最优的压缩。在下面的第 13.7 节中，我们还将了解到，$Q_{X_n|X^{n-1}}$ 可以解释为对 x_j 分布的在线估计。

注 13.2（两种冗余）在通用压缩的文献中，量 $\mathcal{R}_n^{**}$ 被称为 *worst-case* 或 *pointwise* 极小极大冗余，与 (13.8) 中的 *average- case* 极小极大冗余 $\mathcal{R}_n^*$ 相比，后者将 (13.11) 中的 $\max_{x^n}$ 替换为 $\mathbb{E}_{x^n \sim P_{X^n|\theta_0}}$。已对于许多模型类，例如独立同分布和有限阶马尔可夫源，$\mathcal{R}_n^*$ 和 $\mathcal{R}_n^{**}$ 在 $n \to \infty$ 的主导项上一致。[2] 当 $\mathcal{R}_n^* \le \mathcal{R}_n^{**}$ 时，通常界定冗余的方法是通过对特定概率分配的点态冗余进行上界（借助组合手段）来上界 $\mathcal{R}_n^{**}$，并通过应用 (13.10) 以及界定互信息来下界 $\mathcal{R}_n^*$

[2] This, however, is not true in general. See Exercise **II.21** for an example where $\mathcal{R}_n^* < \infty$ but $\mathcal{R}_n^{**} = \infty$.

特定先验的信息；示例见练习II.15和II.16，更多内容参见[112，第6-7章]。

注 13.3（单次编码的冗余度） 我们注意到，任何前缀码 f：$\mathcal{X}^n \to \{0,1\}^*$ 定义了一个分布 $Q_{X^n}(x^n) = 2^{-\ell(f(x^n))}$。（我们假设该码的二叉树是满的，使得 Kraft 和等于一）。因此，我们在 (13.8) 中对冗余度的定义评估了前缀码的期望长度 $\mathbb{E}[\ell(f(X^n))]$ 相对于 $H(X^n)$ 的超额部分。然而，对于无前缀约束的单次编码（第 10.1 节），最优答案略有不同。例如，对于所有独立同分布源，最优通用码满足 $\mathbb{E}[\ell(f(X^n))] \approx H(X^n) + \frac{|\mathcal{X}|-3}{2}\log n$，而前缀码则为 $\frac{|\mathcal{X}|-1}{2}\log n$，参见 [41, 256]。

13.4* 渐近最大最小解：杰弗里斯先验

在本节中，我们仅考虑一类源的简单设置，这类源由给定有限字母表 $|\mathcal{X}| = d+1$ 上的所有独立同分布组成，它定义了一个 d 参数分布族。我们将证明，渐近达到容量 (13.10) 的先验由参数设置为 1/2 的狄利克雷分布给出。回想一下，参数为 $\alpha_j > 0$ 的狄利克雷分布 Dirichlet$(\alpha_0,\ldots,\alpha_d)$ 是概率向量 $(\theta_0,\ldots,\theta_d)$ 的分布，使得 $(\theta_1,\ldots,\theta_d)$ 具有联合密度

$$c(\alpha_0,\ldots,\alpha_d)\prod_{j=0}^{d}\theta_j^{\alpha_j-1} \tag{13.16}$$

和 $\theta_0 = 1-\sum_{j=1}^{d}\theta_j$，其中 $c(\alpha_0,\ldots,\alpha_d) = \frac{\Gamma(\alpha_0+\ldots+\alpha_d)}{\prod_{j=0}^{d}\Gamma(\alpha_j)}$ 是归一化常数。

首先，我们给出如下形式化设置：

- 固定一个大小为 $|\mathcal{X}| = d+1$ 的有限字母表 $\mathcal{X}$，我们将把它枚举为 $\mathcal{X} = \{0,\ldots,d\}$。
- 如同例2.6，让$\Theta = \{(\theta_1,\ldots,\theta_d)\colon \sum_{j=1}^{d}\theta_j \le 1, \theta_j \ge 0\}$参数化所有在$\mathcal{X}$上的概率分布集合。注意$\Theta$是一个$d$维单纯形。我们还将定义

$$\theta_0 \triangleq 1-\sum_{j=1}^{d}\theta_j\,.$$

- 源类是

$$P_{X^n|\theta}(x^n|\theta) \triangleq \prod_{j=1}^{n}\theta_{x_j} = \exp\left\{-n\sum_{a\in\mathcal{X}}\theta_a\log\frac{1}{\hat{P}_{x^n}(a)}\right\},$$

其中如前所述，$\hat{P}_{x^n}$ 是 x^n 的经验分布，参见（13.5）。

为了找到（接近）最优的 Q_{X^n}，我们需要在（13.10）中猜测一个（几乎）最优的先验 $\pi \in \mathcal{P}(\Theta)$，并取 Q_{X^n} 为 $P_{X^n|\theta}$ 的混合。我们将在平滑类中搜索 π

Θ 上的密度并设置

$$Q_{X^n}(x^n) \triangleq \int_\Theta P_{X^n|\theta}(x^n|\theta')\pi(\theta')d\theta' . \tag{13.17}$$

在进一步讨论之前，我们回顾一下近似指数积分的*Laplace method*。假设$f(\theta)$在Θ的内部点$\hat{\theta}$处有唯一的最小值，并且Hessian矩阵Hess$f$一致地被单位矩阵的倍数下界（特别地，$f(\theta)$是强凸的）。那么对π和f进行泰勒展开，我们得到

$$\int_\Theta \pi(\theta)e^{-nf(\theta)}d\theta = \int (\pi(\hat{\theta}) + O(\|t\|))e^{-n(f(\hat{\theta})-\frac{1}{2}t^T \text{Hess } f(\hat{\theta})t+o(\|t\|^2))}dt \tag{13.18}$$

$$= \pi(\hat{\theta})e^{-nf(\hat{\theta})} \int_{\mathbb{R}^d} e^{-x^T \text{Hess } f(\hat{\theta})x} \frac{dx}{\sqrt{n^d}}(1 + O(n^{-1/2})) \tag{13.19}$$

$$= \pi(\hat{\theta})e^{-nf(\hat{\theta})} \left(\frac{2\pi}{n}\right)^{\frac{d}{2}} \frac{1}{\sqrt{\det \text{Hess} f(\hat{\theta})}}(1 + O(n^{-1/2})) \tag{13.20}$$

其中在最后一步我们计算了高斯积分。

接下来，我们注意到

$$P_{X^n|\theta}(x^n|\theta') = \exp\{-n(D(\hat{P}_{x^n}\|P_{X|\theta=\theta'}) + H(\hat{P}_{x^n}))\} ,$$

因此，表示

$$\hat{\theta}(x^n) \triangleq \hat{P}_{x^n}$$

我们通过将(13.20)应用于(13.17)得出

$$\log Q_{X^n}(x^n) = -nH(\hat{\theta}) + \frac{d}{2}\log\frac{2\pi}{n\log e} + \log\frac{P_\theta(\hat{\theta})}{\sqrt{\det J_F(\hat{\theta})}} + O(n^{-\frac{1}{2}}) ,$$

其中我们利用了Hess $_{\theta'} D(\hat{P}\|P_{X|\theta=\theta'})|_{\theta'=\hat{\theta}} = \frac{1}{\log e}J_F(\hat{\theta})$，而$J_F$是先前在(2.34)中引入的Fisher信息矩阵。由此，利用在$X^n \sim P_{X^n|\theta=\theta'}$下随机变量$\hat{\theta} = \theta' + O(n^{-1/2})$这一事实，我们通过近似$J_F(\hat{\theta})$和$P_\theta(\hat{\theta})$得到

$$D(P_{X^n|\theta=\theta'}\|Q_{X^n}) = n(\mathbb{E}[H(\hat{\theta})] - H(X|\theta=\theta')) + \frac{d}{2}\log n - \log\frac{P_\theta(\theta')}{\sqrt{\det J_F(\theta')}} + C + O(n^{-\frac{1}{2}}) , \tag{13.21}$$

其中 C 是某个常数（独立于先验 P_θ 或 θ'）。第一项由下一个结果处理，该结果细化了推论 7.18。

引理 13.2 *Let $X^n \overset{i.i.d.}{\sim} P$ on a finite alphabet $\mathcal{X}$ such that $P(x) > 0$ for all $x \in \mathcal{X}$. Let $\hat{P} = \hat{P}_{X^n}$ be the empirical distribution of X^n, then*

$$\mathbb{E}[D(\hat{P}\|P)] = \frac{|\mathcal{X}|-1}{2n}\log e + o\left(\frac{1}{n}\right) .$$

In fact, $nD(\hat{P}\|P) \to$ 对数$_e$ 2 $\chi^2(|\mathcal{X}|-1)$ in distribution.

Proof. 根据中心极限定理，$\sqrt{n}(\hat{P}-P)$依分布收敛于$\mathcal{N}(0,\Sigma)$，其中$\Sigma=\mathrm{diag}(P)-PP^T$，这里$P$是一个$|\mathcal{X}|$乘1的列向量。因此，计算$D(\cdot\|P)$的二阶泰勒展开，参见(2.34)和(2.37)，我们得到结果。（为了交换极限和期望，更正式地，我们需要对所有$x\in\mathcal{X}$以事件$\hat{P}_n(x)\in(\epsilon,1-\epsilon)$为条件，以使被积函数有界。我们将这些技术细节留作练习。）

□

继续（13.21），我们最终得到

$$D(P_{X^n|\theta=\theta'}\|Q_{X^n})=\frac{d}{2}\log n-\log\frac{\pi(\theta')}{\sqrt{\det J_F(\theta')}}+\text{constant}+O(n^{-\frac{1}{2}}) \tag{13.22}$$

在假设先验π的平滑性以及θ'不在Θ的边界上的条件下，我们可以看出，为了使先验π成为鞍点解，我们应有

$$\pi(\theta')\propto\sqrt{\det J_F(\theta')}\,,$$

前提是右侧可积。与Fisher信息矩阵行列式的平方根成正比的先验被称为*Jeffreys prior*。在我们的情况下，利用Fisher信息的显式表达式(2.39)，发现Jeffreys先验π^*为Dirichlet$(1/2,1/2,\cdots,1/2)$，其密度为：

$$\pi^*(\theta)=c_d\frac{1}{\sqrt{\prod_{j=0}^d\theta_j}}\,, \tag{13.23}$$

其中 $c_d=\frac{\Gamma(\frac{d+1}{2})}{\Gamma(1/2)^{d+1}}$ 是归一化常数。相应的冗余度为

$$\mathcal{R}_n^*=\frac{d}{2}\log\frac{n}{2\pi e}-\log\frac{\Gamma(\frac{d+1}{2})}{\Gamma(1/2)^{d+1}}+o(1)\,. \tag{13.24}$$

使上述推导变得严谨绝非易事，这一工作已在[460]中完成。（在练习II.15和II.16中，我们分析了$d=1$情形，并展示了$\mathcal{R}_n^*=\frac{1}{2}\log n+O(1)$。）

总体而言，我们看到Jeffreys先验渐近最大化了$o(1)$内的$\sup_\pi I(\theta;X^n)$，因此被称为*asymptotically maximin solution*。令人惊讶的是[405]，相应的混合Q_{X^n}，我们记为$Q_{X^n}^{(\mathrm{KT})}$ (并在下一节详细研究)，然而，它并未给出渐近最优冗余。即对某些$c_1>c_2>0$不等式，我们有

$$\mathcal{R}_n^*+c_1+o(1)\le\sup_{\theta_0}D(P_{X^n|\theta=\theta_0}\|Q_{X^n}^{(\mathrm{KT})})\le\mathcal{R}_n^*+c_2+o(1)\,.$$

即$Q_{X^n}^{(\mathrm{KT})}$不是渐近极小极大（但它确实能达到最优冗余度，直至$O(1)$项）。然而，事实证明，在单纯形边界附近修补Jeffreys先验（或使用狄利克雷分布的混合）确实能导致渐近极小极大的通用概率分配 [460]。

推广到一般光滑参数族。Jeffreys先验$\theta \sim \pi$最大化互信息$I(\theta; X^n)$对于一般参数族这一事实在[46]中在贝叶斯推断中选择先验的背景下被猜想。该结果在[95, 96]中被严格证明。我们简要总结后者的结果。

设 $\{P_\theta : \theta \in \Theta_0\}$ 是一个光滑参数族，其 Fisher 信息矩阵 $J_F(\theta)$ 在 $\Theta_0 \subset \mathbb{R}^d$ 的内部处处连续且有界。那么对于包含在 Θ_0 内部的每个紧集 Θ，我们有

$$\mathcal{R}_n^*(\Theta) = \frac{d}{2}\log\frac{n}{2\pi e} + \log\int_\Theta \sqrt{\det J_F(\theta)}d\theta + o(1)\,. \tag{13.25}$$

尽管在 Θ 上的 Jeffreys 先验达到了 $\sup_\pi I(\theta; X^n)$ 的最优值（至多差 $o(1)$），然而，要生成近似达到容量的输出分布 Q_{X^n}，需要在稍大的集合 $\Theta_\epsilon = \{\theta$ 上关于 Jeffreys 先验取混合：$d(\theta, \Theta) \le \epsilon\}$，并随 $n \to \infty$ 缓慢取 $\epsilon \to 0$。这一 Q_{X^n} 序列确实达到了最优冗余度，至多差 $o(1)$。

注13.4（拉普拉斯继承法则）在统计学中，杰弗里斯先验因其对平滑重参数化的不变性而被证明是合理的，如(2.35)所示。例如，在回答“明天太阳会升起吗”[3]时，拉普拉斯提出通过将日出建模为独立同分布的伯努利过程，并在参数$\theta \in$[0,1]上采用均匀先验来估计概率。然而，这显然不太合乎逻辑，因为人们同样可以假设$\alpha = \theta^{10}$或$\beta = \sqrt{\theta}$的均匀性。杰弗里斯先验$\theta \sim \frac{1}{\sqrt{\theta(1-\theta)}}$在重参数化下是不变的，这意味着如果在$\alpha$参数化下计算$\sqrt{\det J_F(\alpha)}$，结果将恰好是$\frac{1}{\sqrt{\theta(1-\theta)}}$沿映射$\theta \mapsto \theta^{10}$的前推。

13.5 序列概率分配：Krichevsky-Trofimov

从(13.23)不难推导出（渐近）最优通用概率分配Q_{X^n}。为简化起见，我们考虑伯努利情形，即$d = 1$且$\theta \in [0, 1]$是一维参数。此时，杰弗里斯先验及由此产生的混合分布由[4]给出。

$$P_\theta^* = \frac{1}{\pi\sqrt{\theta(1-\theta)}} \tag{13.26}$$

$$Q_{X^n}^{(\mathrm{KT})}(x^n) = \frac{(2t_0-1)!!\cdot(2t_1-1)!!}{2^n n!}\,, \qquad t_a = \#\{j \le n : x_j = a\}. \tag{13.27}$$

现在可以使用这一赋值，通过本章开头概述的其中一种方法来创建一个通用压缩器。

[3] Interested readers should check *Laplace's rule of succession* and the sunrise problem; see [229, Chap. 18] for a historical and philosophical account.

[4] We remind $(2a-1)!! = 1\cdot 3\cdots(2a-1)$. The expression for Q_{X^n} is obtained from the identity $\int_0^1 \frac{\theta^a(1-\theta)^b}{\sqrt{\theta(1-\theta)}}d\theta = \pi\frac{(2a-1)!!(2b-1)!!}{2^{a+b}(a+b)!}$ for integer $a, b \ge 0$, which in turn is derived by change of variable $z = \frac{\theta}{1-\theta}$ and using the standard keyhole contour on the complex plane.

注意，$Q^{(\mathrm{KT})}_{X^{n-1}}$ 与将 $Q^{(\mathrm{KT})}_{X^n}$ 边缘化到前 $n-1$ 个坐标一致。这一性质并非 KT 分布所特有，对于任何以 $\int P_\theta(d\theta)P_{X^n|\theta}$ 形式给出且 P_θ 不依赖于 n 的 Q_{X^n} 都成立。然而，值得注意的是，条件分布 $Q^{(\mathrm{KT})}_{X_n|X^{n-1}}$ 具有相当优雅的形式：

$$Q^{(\mathrm{KT})}_{X_n|X^{n-1}}(1|x^{n-1}) = \frac{t_1+\frac{1}{2}}{n}, \qquad t_1 = \#\{j \le n-1 : x_j = 1\} \tag{13.28}$$

$$Q^{(\mathrm{KT})}_{X_n|X^{n-1}}(0|x^{n-1}) = \frac{t_0+\frac{1}{2}}{n}, \qquad t_0 = \#\{j \le n-1 : x_j = 0\} \tag{13.29}$$

这是Krichevsky和Trofimov [260]著名的“加1/2”规则。正如第13.1节所述，这种顺序分配对于实现算术编码器非常方便。

设 $f_{\mathrm{KT}} : \{0,1\}^n \to \{0,1\}^*$ 是分配长度为 $l(f_{\mathrm{KT}}(x^n)) = \left\lceil \log_2 \frac{1}{Q^{(\mathrm{KT})}_{X^n}(x^n)} \right\rceil$ 的编码器。现在由式 (13.24) 可知，我们

$$\sup_{0\le\theta\le 1} \{\mathbb{E}\,[l(f_{\mathrm{KT}}(S^n_\theta))] - nh(\theta)\} = \frac{1}{2}\log n + O(1)\,.$$

由于在练习II.15中未严格证明(13.24)，我们独立证明该主张的上界。

备注 13.5（拉普拉斯“加1”规则）稍逊最优的选择 Q_{X^n} 来自拉普拉斯先验（回想一下，拉普拉斯建议取 P_θ 在[0, 1]上均匀分布）。于是，在二元（伯努利）字母表的情况下，我们得到

$$Q^{(Lap)}_{X^n} = \frac{1}{\binom{n}{w}(n+1)}\,, \qquad w = \#\{j : x_j = 1\}\,. \tag{13.30}$$

相应的序贯概率分配由下式给出：

$$Q^{(Lap)}_{X_n|X^{n-1}}(1|x^{n-1}) = \frac{t_1+1}{n+1}\,, \quad t_1 = \#\{j \le n-1 : x_j = 1\}\,.$$

我们注意到两点。首先，分布（13.30）与Fitingof的（13.7）*exactly*相同。其次，该分布“几乎”达到了（13.24）中的最优一阶项。实际上，当X^n是独立同分布伯努利(θ)时，对于冗余度我们有：

$$\mathbb{E}\left[\log \frac{1}{Q^{(Lap)}_{X^n}(X^n)}\right] - H(X^n) = \log(n+1) + \mathbb{E}\left[\log \binom{n}{W}\right] - nh(\theta)\,, \quad W \sim \mathrm{Bin}(n,\theta)\,. \tag{13.31}$$

从斯特林展开式可知，当$n \to \infty$时，此冗余度一致地计算为$\frac{1}{2}\log n + O(1)$，在紧致子集(0, 1)上对θ一致成立。然而，对于$\theta = 0$或$\theta = 1$，拉普拉斯冗余度(13.31)显然等于$\log(n+1)$。因此，在$\theta \in [0,1]$上的上确界在接近端点处达到，并导致次优冗余度$\log n + O(1)$。杰弗里斯先验(13.26)及由此产生的KT压缩器解决了端点处的问题。

对于一般的（非二进制）字母表，KT分布同样简单：

$$Q^{(\mathrm{KT})}_{X_n|X^{n-1}}(a|x^{n-1}) = \frac{t_a + \frac{1}{2}}{n + \frac{|\mathcal{X}|-2}{2}}, \qquad t_a = \#\{j \le n-1 : x_j = a\} \tag{13.32}$$

总之，为了构建一个适用于给定有限字母表$\mathcal{X}$上所有独立同分布源的通用压缩器，我们可以采取以下步骤：

1 学习器：设置 $Q_{X_1} = \mathrm{Unif}[\mathcal{X}]$。2 算术编码器：使用 Q_{X_1} 细分 $[0,1]$ 区间。接收第一个字母 x_1 并选择分区 $Q_{X_1}(x_1)$。3 学习器：给定 x_1，根据 (13.32) 计算 $Q_{X_2|X_1=x_1}$。4 算术编码器：根据 $Q_{X_2|X_1=x_1}$ 细分当前选择的分区。接收下一个字母 x_2 并选择分区 $Q_{X_2|X_1=x_1}(x_2)$。

5 等。

对于压缩，我们仅利用算术编码器的状态来输出相应的$\{0,1\}$位。然而，在下一节中我们将看到，学习器的输出$Q_{X_n|X^{n-1}}$是一个极为相关的量：它是在KL损失下的（遗憾最优）在线密度估计器。

13.6 在线预测与密度估计

事实证明，通用压缩问题（更具体地说，是代表整个分布类的通用概率分配Q_{X^n}）自动解决了另外两个重要问题：一个是机器学习中的在线预测问题，另一个是统计学中的密度估计问题。因此，在信息论中，通用压缩问题有时也被称为“通用预测”。在接下来的两节中，我们将简要解释这一基本联系。关于完整的故事，我们推荐一本关于该主题的优秀教材[86]。

让我们固定 $\mathcal{X}$ 以及 $\mathcal{X}^n$ 上的一族测度 $P^{(\theta)}_{X^n}, \theta \in \Theta$，我们将其称为模型类 Θ。尽管连续 $\mathcal{X}$ 的情形更为有趣（我们将在第32.1节中探讨），但目前我们仅限于关注离散 $\mathcal{X}$，因此我们将 $P^{(\theta)}_{X^n}(\cdot)$ 理解为 $\mathcal{X}^n$ 上的概率质量函数。最直接的选择是令 $P^{(\theta)}_{X^n}(x_1,\ldots,x_n) = \prod_{i=1}^n P^{(\theta)}_{X_1}(x_i)$，这将对应于一族独立同分布源，但我们不作此限制。

在线预测。给定一个序列$X_1,\ldots,X_n \sim P^{(\theta^*)}_{X^n}$，学习器依次观察$X_1,\ldots,X_{t-1}$并输出其对下一个样本$X_t$的预测$Q_t(\cdot)$。当下一个样本被揭示后，学习器经历通过对数损失衡量的损失：

$$\ell(Q_t, X_t) \triangleq \log \frac{1}{Q_t(X_t)}\,.$$

给定一系列预测器 $\{Q_t\}$，我们可以如下为其分配平均 *cumulative* 损失：

$$\ell^{(a)}_n(\{Q_t\}, \theta^*) \triangleq \mathbb{E}_{P^{(\theta^*)}_{X^n}}\left[\sum_{t=1}^n \log \frac{1}{Q_t(X_t|X^{t-1})}\right].$$

这个在线预测问题与通用压缩之间的密切关联，通过以下几乎显而易见的观察得以揭示。注意到学习器在时间t输出的分布$Q_t(\cdot)$实际上是观测值$x_1,\dots x_{t-1}$的函数。因此，我们应更明确地将其写作$Q_t(\cdot;\ x^{t-1})$，以强调对（训练）数据的依赖。但随后我们也可以将$Q_t(x_t;\ x^{t-1})$视为一个马尔可夫核$Q_{X_t|X^{t-1}}(x_t|x^{t-1})$，并计算联合概率分布

$$Q_{X^n}(x^n) \triangleq \prod_{t=1}^{n} Q_t(x_t; x^{t-1})\,. \tag{13.33}$$

相反，任何 Q_{X^n} 我们都可以按 (13.33) 的形式顺序分解，并得到一个在线预测器。事实证明，最优 Q_{X^n} 的选择正是 (13.8) 中通用压缩所解决的同一个 *universal probability assignment* 问题。但在此之前，我们需要解释如何定义在线预测博弈中的最优性。

由于 $\ell_n^{(a)}(\{Q_t\},\theta^*)$ 取决于支配输入序列随机性的 θ^* 的值，我们的第一直觉可能是尝试最小化

$$\min_{\{Q_t\}} \sup_{\theta^*\in\Theta} \ell_n^{(a)}(\{Q_t\},\theta^*)\,.$$

然而，这种提出问题的方式并不理想。例如，如果$P_{X^n}^{(\theta)} = \mathrm{Unif}[\mathcal{X}^n]$ 中的某一个，那么没有预测器能够达到 $\ell_n^{(a)} \le n\log|\mathcal{X}|$。此外，一个总是输出 $Q_t = \mathrm{Unif}[\mathcal{X}]$ 的平凡预测器正好达到了这个上界。因此，在极小极大设置中，预测 $\mathrm{Unif}[\mathcal{X}]$ 是最优的。

要理解如何绕开这一问题，我们首先回顾推论2.4，如果我们有关于真实θ^*生成X_j的 *oracle knowledge*，那么我们的选择将是设Q_t为$P_{X^n}^{(\theta^*)}$的因式分解。这达到了损失

$$\ell_n^{(a)}(\{P_\theta^*\},\theta^*) = H(P_{X^n}^{(\theta^*)})\,.$$

因此，即使给定预言信息，我们也无法避免$H(P_{X^n}^{(\theta^*)})$损失（在机器学习中这也被称为贝叶斯损失）。注意对于iid模型类，我们有$H(P_{X^n}^{(\theta^*)}) = nH(P_{X_1}^{(\theta^*)})$，且预言损失的数量级为$n$。因此，学习算法的质量应通过在预言损失之上的超出损失量来衡量。这个量被称为 *average regret*，定义为

$$\mathrm{AvgReg}_n(\{Q_t\},\theta^*) \triangleq \mathbb{E}_{P_{X^n}^{(\theta^*)}}\left[\sum_{t=1}^{n}\log\frac{1}{Q_t(X_t|X^{t-1})}\right] - H(P_{X^n}^{(\theta^*)})\,.$$

因此，为了设计最优算法，我们希望最小化最坏遗憾，换句话说，即解决极小极大问题

$$\mathrm{AvgReg}_n^*(\Theta) \triangleq \inf_{\{Q_t\}}\sup_{\theta^*\in\Theta}\mathrm{AvgReg}_n(\{Q_t\},\theta^*)\,. \tag{13.34}$$

结果证明，这与通用压缩问题完全等价，如下所述。

定理 13.3 *Recall the definition of compression redundancy* $\mathcal{R}_n^*$ *in* (13.8)*. Then we have*

$$\mathrm{AvgReg}_n^*(\Theta) = \mathcal{R}_n^*(\Theta) \triangleq \min_{Q_{X^n}} \sup_{\theta^* \in \Theta} D(P_{X^n}^{(\theta^*)} \| Q_{X^n}) ,$$

where the minimum in the RHS is achieved and at a unique distribution $Q_{X^n}^*$*. The optimal predictor is given by setting* $Q_t(\cdot) = Q^*_{X_t|X^{t-}1_{=x^t-}1(\cdot)}$
. Furthermore, let $\theta \in \Theta$ *have a prior distribution* $\pi \in \mathcal{P}(\Theta)$*. Then*

$$\mathrm{AvgReg}_n^*(\Theta) = \sup_{\pi} I(\theta; X^n) .$$

If there exists a maximizer π^* *of the right-hand side maximization then the optimal estimator is found by factorizing* $Q_{X^n}^* = \int \pi^*(d\theta) \prod_{i=1}^n P_\theta(x_i)$*.*

Proof. 几乎没有什么需要证明的。我们只需要将平均遗憾的定义按照 Q_{X^n} 重写如下

$$\mathrm{AvgReg}_n(\{Q_t\}, \theta^*) = \mathbb{E}_{P_{X^n}^{(\theta^*)}} \left[\log \frac{P_{X^n}^{(\theta^*)}}{Q_{X^n}} \right] = D(P_{X^n}^{(\theta^*)} \| Q_{X^n}) .$$

其余主张可从定理5.9（回想$I(\theta;\ X^n) \le n \log |\mathcal{X}| < \infty$）和定理5.4推出。

□

作为该结果的一个应用，我们看到Krichevsky-Trofimov估计器对于任何独立同分布字符串$X^n \overset{\text{i.i.d.}}{\sim} P$达到对数损失

$$\sum_{t=1}^n \mathbb{E} \left[\log \frac{1}{Q^{(\mathrm{KT})}_{X_t|X^{t-1}}(X_t|X^{t-1})} \right] \le nH(P) + \frac{|\mathcal{X}| - 1}{2} \log n + c_{\mathcal{X}} ,$$

其中 $c_{\mathcal{X}} < \infty$ 是一个独立于 P 或 n 的常数。在所有可能的在线估计器中，超出 $nH(P)$ 的这一部分是最优的，可能相差一个常数 $c_{\mathcal{X}}$。

我们讨论的问题乍一看可能有些人为构造，特别是对于习惯了监督学习/预测任务的人来说。实际上，我们的预测问题没有任何特征可用于预测！然而，现代大型语言模型正是在解决这个任务：它们通过最小化对数损失（交叉熵损失）来训练预测单词序列，参见[320]。在这些情况下，由于序列的非独立同分布性质，学习任务变得可行。不过，独立同分布设定也相当有趣且具有实际相关性。但为此需要引入监督学习版本，其中预测任务是给定一个相关特征向量X_t来估计未知的（标签或量）Y_t。对于这种情况，也有定理13.3的类似物——见练习II.20和II.22。

批次遗憾。在机器学习中，我们上面定义的被称为累积（或在线）遗憾，因为我们坚持要求估计器在每个时间步t产生一些预测。然而，一个更常见的设定是预测，其中前$n-1$个观测值

可以作为训练数据使用，我们仅在新出现的未见样本（测试数据）上评估损失。这被称为*batch loss*，相应的极小极大遗憾是

$$\mathrm{BatchReg}_n^*(\Theta) \triangleq \inf_{Q_n(\cdot;x^{n-1})} \sup_{\theta^*\in\Theta} \underbrace{\mathbb{E}_{P_{X^n}^{(\theta^*)}}\left[\log\frac{1}{Q_n(X_n;X^{n-1})}\right] - H(P_{X_n|X^{n-1}}^{(\theta^*)})}_{D\left(P_{X_n|X^{n-1}}^{(\theta^*)}\middle\|Q_n(\cdot;X^{n-1})\right)} . \tag{13.35}$$

换句话说，这是通过估计给定过去条件下下一个符号的条件分布来预测下一个符号的最优KL损失，这是GPT等语言模型的核心任务[320]。与定理13.3类似，我们可以给出批量遗憾的最大信息公式（习题II.19）。然而，事实证明，这与通用压缩也存在联系。实际上，我们有以下不等式

$$\mathrm{AvgReg}_n^*(\Theta) - \mathrm{AvgReg}_{n-1}^*(\Theta) \le \mathrm{BatchReg}_n^*(\Theta) \le \frac{1}{n}\mathrm{AvgReg}_n^*(\Theta) , \tag{13.36}$$

其中上界仅在iid模型下得到保证。[5] 不等式(13.36)被称为*online-to-batch conversion*或*estimation-compression inequality* [159, 240]；其证明可参见引理32.3和命题32.7。达到上述上界的估计量非常简单：它接受一个概率分配$Q_{X^n}^*$，并将其预测器设置为

$$Q_n(x_n;x^{n-1}) \triangleq \frac{1}{n}\sum_{t=1}^{n} Q_{X_t|X^{t-1}}(x_n|x^{t-1}) . \tag{13.37}$$

然而，与累积遗憾不同，批量遗憾的最小化器与通用压缩中的最小化器不同。例如，对于包含 k 个符号上所有独立同分布分布的模型类，我们知道（渐近地）Krichevsky-Trofimov 的“add-1/2”估计器是最优的。然而，对于批量损失而言并非如此（参见练习 VI.10 末尾的注释）。我们还注意到，在这种情况下最优批量遗憾为 $O(\frac{k-1}{n})$，但在线到批量规则仅产生 $O(\frac{(k-1)\log n}{n})$。另一方面，对于具有 $k \ge$ 个状态的一阶马尔可夫链，在线到批量的上界结果在阶数上是最优的，因为我们有 $\mathrm{BatchReg}_n^* \asymp \frac{1}{n}\mathrm{AvgReg}_n^* \asymp \frac{k^2}{n}\log\frac{n}{k^2}$，前提是 $n \gg k^2$ [213]；然而，证明这一结果，尤其是下界，需要马尔可夫链固有的论证。

密度估计。现在考虑以下问题。给定一组在 $\mathcal{X}$ 和 $X_1,\dots,X_{n-1} \overset{\text{i.i.d.}}{\sim} P_X^{(\theta)}$ 上的（单字母）分布 $P_X^{(\theta)}$，我们希望产生一个密度估计 $\hat{P}$，使其在 KL 散度度量下的最坏情况误差最小，即我们寻求最小化

$$\sup_{\theta^*\in\Theta} \mathbb{E}_{X^{n-1}\overset{\text{i.i.d.}}{\sim}P_X^{(\theta^*)}}\left[D(\hat{P}\|P_X^{(\theta^*)})\right] .$$

5 对于平稳的 m 阶马尔可夫模型，分母中的 $n-m$ 使得（13.36）中的上界成立[213，引理6]。

为了与前面的讨论相衔接，我们只需注意到 $\hat{P}(\cdot)$ 在批量后悔问题中可以解释为 Q_n，并且我们有一个精确的等式

$$\inf_{\hat{P}} \sup_{\theta^* \in \Theta} \mathbb{E}_{X^{n-1} \overset{\text{i.i.d.}}{\sim} P_X^{(\theta^*)}} \left[D(\hat{P} \| P_X^{(\theta^*)}) \right] = \text{BatchReg}_n^*(\Theta) \le \frac{1}{n} \sup_{\pi} I(\theta; X^n) .$$

因此，我们通过某一信道的容量来界定极小极大（KL散度）密度估计速率。达到这一界限的估计量是非正常的（即对于任意θ，$\hat{P} \neq P_X^{(\theta)}$），并由(13.37)给出。这是Yang-Barron密度估计方法的基础，更多内容见第32.1节。

13.7 个体序列与最坏情况遗憾

在上一节中，我们解释了学习器如何预测随机生成的字符串X^n。尽管这种方法非常标准，但它常常受到批评：如果我们的模型类Θ对X^n的随机性描述不正确，且真实数据并非由类Θ中的任何过程生成，那该怎么办？在本节中，我们展示了一个有些令人惊讶的变通方法：事实证明，即使*any possible sequences* x^n是非随机的且由对抗性选择，也存在预测理论！这个令人兴奋的领域在信息论中被称为个体序列方法，我们接下来将对其进行描述。

考虑以下问题：序列 x^n 被顺序观察，我们的目标是在给定过去观察的情况下预测（通过做出软预测或概率预测）下一个符号。实验过程如下：

1 一个字符串 $x^n \in \mathcal{X}^n$ 由自然选择。2 观察到 $x_1, \ldots, x_{t-1}$ 后，我们的任务是在 $\mathcal{X}$ 上输出一个概率分布 $Q_t(\cdot|x^{t-1})$。3 此后，自然揭示下一个样本 x_t，而我们第 t 次预测的损失通过对数损失进行评估：

$$\log \frac{1}{Q_t(x_t|x^{t-1})} .$$

主要目标是找到一个预测器序列 $\{Q_t\}$，使其最小化 *cumulative* 损失：

$$\ell(\{Q_t\}, x^n) \triangleq \sum_{t=1}^{n} \log \frac{1}{Q_t(x_t|x^{t-1})} .$$

首先考虑最小化最坏情况损失的朴素目标：

$$\min_{\{Q_t\}_{t=1}^n} \max_{x^n} \ell(\{Q_t\}, x^n) .$$

这显然毫无希望。事实上，在任何步骤t，分布Q_t必须至少有一个原子的权重不超过$\frac{1}{|\mathcal{X}|}$，因此对于任何预测器

$$\max_{x^n} \ell(\{Q_t\}, x^n) \ge n \log |\mathcal{X}| ,$$

显然，当且仅当 $Q_t(\cdot) \equiv \frac{1}{|\mathcal{X}|}$ 时，即如果预测器仅进行均匀随机猜测，就能实现这一点。这种平凡性并不令人惊讶：在完全没有关于 x^n 的先验信息的情况下，是不可能预测任何事情的。

由Feder、Merhav和Gutman提出的激动人心的想法，参见[161, 303]，是用*regret*替换损失，即与最佳可能*static oracle*的差距。更准确地说，假设一个非因果预言机可以检查整个字符串x^n并输出一个常数$Q_t \equiv Q$。根据散度的非负性，这个非因果预言机实现了:

$$\ell_{\text{oracle}}(x^n) = \min_Q \sum_{t=1}^n \log \frac{1}{Q(x_t)} = nH(\hat{P}_{x^n}) .$$

因果（但时变）预测器能否接近这一性能？换句话说，我们将序贯预测器的 *regret* 定义为相对于静态 oracle 的超额风险

$$\text{reg}(\{Q_t\}, x^n) \triangleq \ell(\{Q_t\}, x^n) - nH(\hat{P}_{x^n})$$

并要求最小化最坏情况下的遗憾:

$$\text{Reg}_n^* \triangleq \min_{\{Q_t\}} \max_{x^n} \text{reg}(\{Q_t\}, x^n) . \tag{13.38}$$

令人兴奋的是，上述问题的解中出现了非平凡的预测器，而且这些预测器并不依赖于对x^n的任何假设。

接下来，为简化起见，我们考虑 $\mathcal{X} = \{0, 1\}$ 的情况。为了求解(13.38)，首先注意到设计序列 $\{Q_t(\cdot|x^{t-1}\}$ 等价于定义一个联合分布 Q_{X^n}，然后将后者分解为 $Q_{X^n}(x^n) = \prod_t Q_t(x_t|x^{t-1})$。于是，问题(13.38) 简化为

$$\text{Reg}_n^* = \min_{Q_{X^n}} \max_{x^n} \log \frac{1}{Q_{X^n}(x^n)} - nH(\hat{P}_{x^n}) .$$

首先，我们注意到通常情况下，最优的 Q_{X^n} 是 Shtarkov 分布（13.12），这意味着遗憾度与 Shtarkov 和（13.13）的对数一致。在我们考虑的独立同分布情况下，由（13.14）可得

$$\text{Reg}_n^* = \log \sum_{x^n} \max_Q \prod_{i=1}^n Q(x_i) = \log \sum_{x^n} \exp\{-nH(\hat{P}_{x^n})\} .$$

然而，这个表达式通常不太便于分析，因此我们转而考虑其上界和下界。我们可以用 $X^n \sim$ 上的平均值 $\text{Ber}(\theta)^n$ 来对 x^n 上的最大值求下界，并得到（同时应用引理13.2）：

$$\text{Reg}_n^* \geq \mathcal{R}_n^* + \frac{|\mathcal{X}| - 1}{2} \log e + o(1) ,$$

其中 $\mathcal{R}_n^*$ 是（13.8）中定义的通用压缩冗余度，其渐近性我们在（13.24）中推导得出。

另一方面，从Krichevsky-Trofimov (13.27)中取$Q_{X^n}^{(\text{KT})}$，经过一些代数运算和斯特林展开后，我们得到:

$$\max_{x^n} \log \frac{1}{Q_{X^n}^{(\text{KT})}(x^n)} - nH(\hat{P}_{x^n}) = \frac{1}{2} \log n + O(1) .$$

总之，我们得出结论，

$$\mathrm{Reg}_n^* = \mathcal{R}_n^* + O(1) = \frac{|\mathcal{X}|-1}{2}\log n + O(1)\,,$$

而且值得注意的是，每个字母的遗憾值 $\frac{1}{n}\mathrm{Reg}_n^*$ 收敛于零。即，*there exists a causal predictor that can predict (under the log-loss) almost as well as any constant one, even if it is adapted to a particular sequence x^n non-causally.*

显式（渐近最优）序贯预测规则由Krichevsky-Trofimov的“加1/2”规则给出（13.29）。我们注意到，所得到的规则也独立于n(“无 horizon”)。这是一个非常理想的性质，而从分解 Shtarkov 分布（13.12）推导出的最优序贯预测器并不具备这一性质。

一般参数族。模型类 $\{P_{X^n|\theta=\theta_0}\colon\ \theta_0\in\Theta\}$ 的（累积）个体序列（或最坏情况）遗憾的一般定义由下式给出

$$\mathrm{Reg}_n^*(\Theta) = \min_{Q_{X^n}}\sup_{x^n}\log\frac{1}{Q_{X^n}(x^n)} - \inf_{\theta_0\in\Theta}\log\frac{1}{P_{X^n|\theta=\theta_0}(x^n)}\,,$$

这种遗憾可以表示为给定估计器相对于类$P_{X^n|\theta}$中最佳可能估计器的最坏情况损失，其中后者是针对每个序列最优选择的。在这个意义上，遗憾给出了算法相对于类性能的一致（在x^n中）界限。

事实证明，与(13.25)类似，对于一般的d参数族（在光滑性条件下），个体序列冗余度可被证明满足[362]:

$$\mathrm{Reg}_n^*(\Theta) = \mathcal{R}_n^*(\Theta) + \frac{d}{2}\log e + o(1) = \frac{d}{2}\log\frac{n}{2\pi} + \log\int_\Theta\sqrt{\det J_F(\theta)}d\theta + o(1)\,.$$

在机器学习术语中，我们说（13.8）中的$\mathcal{R}_n^*(\Theta)$是在良好设定下的累积序列预测遗憾（即数据X^n是由模型类Θ内的分布生成的），而这里的$\mathrm{Reg}_n^*(\Theta)$对应于完全错误设定的情况（即数据完全是任意的）。在这两个极端之间还有一些有趣的设定，例如当数据是独立同分布但不是来自模型类Θ时，参见[162]。

13.8 Lempel-Ziv 压缩器

因此，给定一类源 $\{P_{X^n|\theta}\colon\ \theta\in\Theta\}$，我们已经展示了如何通过使用杰弗里斯先验来生成渐近最优压缩器。在独立同分布过程类的情况下，由此得到的Krichevsky-Trofimov序列概率，见(13.32)，具有非常简单的算法描述。然而，当扩展到更一般的类（如 r 阶马尔可夫链）时，序列概率规则变得相当复杂。Lempel-Ziv方法放弃了“设计 Q_{X^n}，转换为 $Q_{X_t|X^{t-1}}$，提取压缩器”的路径，而是尝试直接构建一个合理的序列压缩器，或者等价地，推导出一个算法上简单的序列估计器 $Q_{X_t|X^{t-1}}$。相应的联合分布 Q_{X^n} 难以想象，所达到的冗余也不容易推导，但算法变得非常透明。

原则上，问题相当直接：当我们观察一个平稳过程时，我们可以通过越来越精确地估计条件概率$\hat{P}_{X_n|X_{n-r}^{n-1}}$，然后将其作为算术编码的基础。只要$\hat{P}$收敛于实际条件概率，我们就能达到$H(X_n|X_{n-r}^{n-1})$的熵率。注意，Krichevsky-Trofimov分配（13.29）显然也在学习分布：随着n的增长，估计量$Q_{X_n|X^{n-1}}$收敛于真实的P_X(，前提是序列是独立同分布的)。因此在某种意义上，反过来也是成立的：*any good universal compression scheme is inherently learning the true distribution*。

先学习后压缩方法的主要缺点如下。一旦我们将源类别扩展到包括那些具有记忆的源，我们总是会遇到学习r块的联合分布$P_{X_0^{r-1}}$的问题。然而，获得$P_{X_0^{r-1}}$良好估计所需的样本量随r呈指数增长。因此学习过程可能相当缓慢。Lempel-Ziv系列算法以一种巧妙优雅的方式绕过了这个问题：

- 首先，估计稀有子串的概率耗时最长，但也是最少用的，因为这些子串几乎从不出现在输入中。
- 其次，*and the most crucial*，关键在于$P_{X^r}(x^r)$的无偏估计由数据流中自上次观察到x^r以来的时间的倒数给出。
- 第三，存在一个前缀码[6]，将任何整数n映射到长度约为$\log_2 n$的二进制串：

$$f_{int}: \mathbb{Z}_+ \to \{0,1\}^+, \qquad \ell(f_{int}(n)) = \log_2 n + O(\log\log n)\,. \tag{13.39}$$

因此，通过使用这样的编码来编码指向 x^r 最后观察结果的指针，我们自动获得长度大约为 $\log P_{X^r}(x^r)$ 的字符串。

这些基本思想有多种变体，因此我们仅尝试粗略解释其为何有效，而不分析任何特定算法。

我们接着进入形式细节。首先，我们需要建立Kac引理。

引理 13.4（Kac）*Consider a finite-alphabet stationary ergodic process* $\ldots, X_{-1}, X_0, X_1 \ldots$. *Let* $L = \inf\{t > 0 : X_{-t} = X_0\}$ *be the last appearance of symbol* X_0 *in the sequence* $X_{-\infty}^{-1}$. *Then for any* u *such that* $\mathbb{P}[X_0 = u] > 0$ *we have*

$$\mathbb{E}[L|X_0 = u] = \frac{1}{\mathbb{P}[X_0 = u]}\,.$$

In particular, mean recurrence time $\mathbb{E}[L] = |\text{支撑}(P_X)|$.

Proof. 注意，根据平稳性，以下概率

$$\mathbb{P}[\exists t \geq k : X_t = u]$$

不依赖于 $k \in \mathbb{Z}$。因此，根据概率的连续性，我们可以取 $k = -\infty$ 得到

$$\mathbb{P}[\exists t \geq 0 : X_t = u] = \mathbb{P}[\exists t \in \mathbb{Z} : X_t = u]\,.$$

6 对此只需注意 $\sum_{k\geq 1} 2^{-\log_2 k - 2\log_2\log(k+1)} < \infty$ 并使用 Kraft 不等式。另见练习 II.18。

然而，最后一个事件是平移不变的，因此根据遍历假设，其概率必须为零或一。但由于 $\mathbb{P}[X_0 = u] > 0$，它不可能为零。因此我们得出结论

$$\mathbb{P}[\exists t \geq 0 : X_t = u] = 1 \,. \tag{13.40}$$

接下来，我们有

$$\begin{aligned}
\mathbb{E}[L|X_0 = u] &= \sum_{t\geq 1} \mathbb{P}[L \geq t|X_0 = u] && (13.41)\\
&= \frac{1}{\mathbb{P}[X_0 = u]} \sum_{t\geq 1} \mathbb{P}[L \geq t, X_0 = u] && (13.42)\\
&= \frac{1}{\mathbb{P}[X_0 = u]} \sum_{t\geq 1} \mathbb{P}[X_{-t+1} \neq u, \ldots, X_{-1} \neq u, X_0 = u] && (13.43)\\
&= \frac{1}{\mathbb{P}[X_0 = u]} \sum_{t\geq 1} \mathbb{P}[X_0 \neq u, \ldots, X_{t-2} \neq u, X_{t-1} = u] && (13.44)\\
&= \frac{1}{\mathbb{P}[X_0 = u]} \mathbb{P}[\exists t \geq 0 : X_t = u] && (13.45)\\
&= \frac{1}{\mathbb{P}[X_0 = u]} \,, && (13.46)
\end{aligned}$$

其中（13.41）是对一个$\mathbb{Z}_+$值随机变量期望的标准表达，（13.44）来源于平稳性，（13.45）是因为对应不同t的事件是不相交的，（13.46）来自（13.40）。

□

以下结果有助于解释Lempel-Ziv方法运作的基本原理。

定理 13.5 *Consider a finite-alphabet stationary ergodic process* $\ldots, X_{-1}, X_0, X_1 \ldots$ *with entropy rate H. Suppose that* $X_{-\infty}^{-1}$ *is known to the decoder. Then there exists a sequence of prefix-codes* $f_n(x_0^{n-1}, x_{-\infty}^{-1})$ *with expected length*

$$\frac{1}{n}\, \mathbb{E}[\ell(f_n(X_0^{n-1}, X_{\infty}^{-1}))] \to H \,,$$

Proof. 令 L_n 为字符串 $x_{-\infty}^{-1}$ (中块 x_0^{n-1} 的最后一次出现，回想一下，后者对解码器) 是已知的，即

$$L_n = \inf\{t > 0 : x_{-t}^{-t+n-1} = x_0^{n-1}\} \,.$$

T然后，通过将Kac引理应用于过程 {v*}，我们得到　　我们有

$$\mathbb{E}[L_n|X_0^{n-1} = x_0^{n-1}] = \frac{1}{\mathbb{P}[X_0^{n-1} = x_0^{n-1}]} \,.$$

我们知道使用编码 (13.39) 对 L_n 进行编码。注意一个关键微妙之处：即使 $L_n < n$ 以及因此 $[-t, -t+n-1]$ 和 $[0, n-1]$ 重叠，子串 x_0^{n-1} 仍可以从 L_n 的知识中解码出来。

我们通过两次应用Jensen不等式，并注意到$\frac{1}{n}H(X_0^{n-1}) \searrow H$和$\frac{1}{n}\log H(X_0^{n-1}) \to 0$，得到

$$\frac{1}{n}\,\mathbb{E}[\ell(f_{int}(L_n))] \le \frac{1}{n}\,\mathbb{E}\left[\log \frac{1}{P_{X_0^{n-1}}(X_0^{n-1})}\right] + o(1) \to H\,.$$

从Kraft不等式我们知道，对于任何前缀码，我们必须有

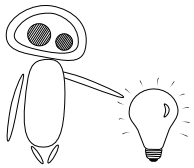
$$\frac{1}{n}\,\mathbb{E}[\ell(f_{int}(L_n))] \ge \frac{1}{n}H(X_0^{n-1}|X_{-\infty}^{-1}) = H\,.$$

□

上面显示的结果表明，LZ算法对每个平稳遍历过程具有渐近最优的压缩率。然而，回顾之前讨论的压缩器也具有非随机（单个序列）保证。例如，我们在第13.7节中看到，Krichevsky-Trofimov压缩器在*every input sequence*上达到的压缩比最多比使用最佳可能（对于这个序列！）静态概率分配构建的算术编码器差$O(\frac{\log n}{n})$。事实证明，LZ算法从这一角度看也是特殊的。在[331]中（另见[160，定理4]）表明，LZ压缩率在*every input sequence*上比任何有限状态机（FSM）达到的压缩率都好，直至校正项$O(\frac{\log\log n}{\log n})$。因此，通过LZ进行投资获得的资本增长可与任何可能的FSM投资者竞争[160]。

总的来说，我们可以看到LZ压缩在随机和个体序列意义上都享有一定的优化保证。

第二部分练习



II.1（最小压缩长度的精确值）假设 $X \in \mathbb{N}$ 和 $P_X(1) \geq P_X(2) \geq \ldots$。证明最优压缩器 f^* 的长度满足

$$\mathbb{E}[l(f^*(X))] = \sum_{k=1}^{\infty} \mathbb{P}[X \geq 2^k].$$

II.2（混合源）考虑 $\mathcal{S}$ 上分布的有限集合 $\Pi = \{P_1, \ldots, P_m\}$。混合源 $\{S_j\}$ 通过以概率 π_i 从 Π 中采样 P_i，然后生成 $S_j \overset{\text{i.i.d.}}{\sim} P_i$ 来产生。证明 $\frac{1}{n}\log\frac{1}{P^{s^n(S^n)}}$ 依分布收敛。计算 $\lim_{n\to\infty} \epsilon^*(S^n, nR)$。

II.3 回忆一下，过程 $\{X_j : j = 1, \ldots\}$ 的熵率在极限存在的情况下定义如下：

$$\mathcal{H} = \lim_{n\to\infty} \frac{1}{n} H(X^n).$$

考虑一个具有转移概率的4状态马尔可夫链 矩阵

$$\begin{bmatrix} 0.89 & 0.11 & 0 & 0 \\ 0.11 & 0.89 & 0 & 0 \\ 0 & 0 & 0.11 & 0.89 \\ 0 & 0 & 0.89 & 0.11 \end{bmatrix}$$

初始状态的分布为 $[p, 0, 0, 1-p]$。

(a) 是否 这样的马尔可夫链的熵率存在吗？如果存在，则 d 它。(b) 描述最优变长速率 $\frac{1}{n}\ell(f^*(X_1, \ldots, X_n))$ 的渐近行为。考虑依概率收敛和依分布收敛。

(c) 使用转移矩阵重复：

$$\begin{bmatrix} 0.89 & 0.11 & 0 & 0 \\ 0.11 & 0.89 & 0 & 0 \\ 0 & 0 & 0.5 & 0.5 \\ 0 & 0 & 0.5 & 0.5 \end{bmatrix}$$

II.4 考虑一个三态马尔可夫链 $S_1, S_2, \ldots$，其转移概率矩阵如下

$$\mathbf{P} = \begin{bmatrix} \frac{1}{2} & \frac{1}{4} & \frac{1}{4} \\ 0 & \frac{1}{2} & \frac{1}{2} \\ 1 & 0 & 0 \end{bmatrix}.$$

计算当$n \to \infty$时，$\frac{1}{n}\mathbb{E}[l(f^*(S^n))]$的极限。你的答案是否依赖于初始状态$S_1$的分布?

II.5 (a) 设 X 在一个有限字母表 $\mathcal{X}$ 上取值。证明

$$\epsilon^*(X,k) \geq \frac{H(X)-k-1}{\log(|\mathcal{X}|-1)}.$$

(b) 推导以下逆命题结果：对于有限字母表 $\mathcal{S}$ 上的平稳过程 $\{S_k : k \geq 1\}$，

$$\liminf_{n\to\infty} \epsilon^*(S^n, nR) \geq \frac{\mathcal{H}-R}{\log|\mathcal{S}|}.$$

其中 $\mathcal{H} = \lim_{n\to\infty} \frac{H(S^n)}{n}$ 是该过程的熵率。

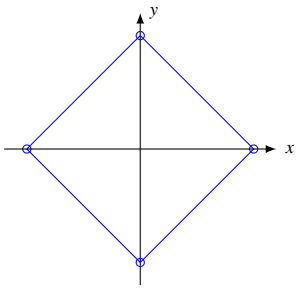
II.6 *Run-length encoding* 是一种流行的可变长度无损压缩器，用于传真机、图像压缩等。考虑使用游程编码对 S^n 进行压缩，这是一个独立同分布的 Ber(δ) 源，其中 $\delta = \frac{1}{128}$ 非常小：一段连续的 $r \leq 255$ 个零（或一）被编码为一个零（或一）后跟对 r (的 8 位二进制编码。如果有 > 255 个连续零，则将输出两个或更多 9 位块)。计算平均达到的压缩率

$$\lim_{n\to\infty} \frac{1}{n}\mathbb{E}[\ell(f(S^n)]$$

它与最优无损压缩器相比如何?

Hint：计算每块连续零/一块的期望9位块输出数；用该块的期望长度进行归一化。

II.7 从以下正方形的顶点独立且均匀地随机抽取 n 个点。



用（X_1, Y_1）, . . . , (X_n, Y_n)表示坐标。假设Alice只观测到X^n，Bob只观测到Y^n。他们希望分别使用每个符号R_X和R_Y比特来编码各自的观测值，并将码字发送给Charlie，而Charlie将能够重建这些对的序列。

(a) 求(R_X, R_Y)的最优速率区域。(b) 如果正方形旋转45°呢?

II.8 考虑一个粒子在练习II.7的图上随机行走（每条边被选中的概率相等；粒子不会停留在同一个节点上）。Alice观察X坐标，Bob观察Y坐标。长期来看，Bob每一步需要多少比特来

发送给Alice，以便Alice能够以几乎为零的错误概率重建粒子的轨迹？（提示：你需要将第11章的某个定理推广到遍历马尔可夫链的情况）

II.9 回忆定理11.13中关于Slepian-Wolf压缩至k比特时错误概率的上界：

$$\epsilon^*_{SW}(k) \le \min_{\tau>0} \mathbb{P}\left[\log_{|\mathcal{A}|} \frac{1}{P_{X^n|Y}(X^n|Y)} > k-\tau\right] + |\mathcal{A}|^{-\tau} \tag{II.1}$$

考虑以下情况，其中$X^n = (X_1, \ldots, X_n)$在$\{0,1\}^n$上均匀分布，并且

$$Y = (X_1, \ldots, X_n) + (N_1, \ldots, N_n)\,,$$

其中 N_i 是独立同分布的高斯分布，均值为零，方差为0.1。令 $n = 10$。提出一种方法，以数值方式计算或近似作为 $k = 1, \ldots 10$ 的函数的界限（II.1）。绘制结果。

II.10（不匹配压缩）令P, Q为某个离散字母表$\mathcal{A}$上的分布。

(a) 设 $f^*_P : \mathcal{A} \to \{0,1\}$ 表示 $X \sim P$ 的最优变长无损压缩器。证明在 Q 下，

$$\mathbb{E}_Q[l(f^*_P(X))] \le H(Q) + D(Q\|P).$$

() 的香农码是一个前缀码 f_P，其码长为 $l(f_P(a)) = \lceil \log_2 \frac{1}{P(a)} \rceil, a \in \mathcal{A}$。证明如果 X 按照 Q 分布，则

$$H(Q) + D(Q\|P) \le \mathbb{E}_Q[l(f_P(X))] \le H(Q) + D(Q\|P) + 1\,\mathtt{bit}.$$

Comments：这可以解释为模型误指定下压缩的一个鲁棒性结果：当为P设计的压缩器应用于分布实际上是Q的源时，这种不匹配导致的次优性可以与散度$D(Q\|P)$相关联。

II.11 考虑一个三进制固定长度（几乎无损）压缩 $\mathcal{X} \to \{0,1,2\}^k$，附加要求是 $w^k \in \{0,1,2\}^k$ 中的字符串应满足

$$\sum_{j=1}^{k} w_j \le \frac{k}{2} \tag{II.2}$$

例如，(0, 0, 0, 0)、(0, 0, 0, 2) 和 (1, 1, 0, 0) 满足约束，但 (0, 0, 1, 2) 不满足。令 $\epsilon^*(S^n, k)$ 表示在 $S^n = \{S_j, j = 1, \ldots, n\}$ 的所有可能压缩器中，具有有限熵 $H(S) < \infty$ 的独立同分布项的最小错误概率。计算

$$\lim_{n\to\infty} \epsilon^*(S^n, nR)$$

作为$R \ge 0$的函数。

*Hint*与 $\mathbb{P}[\ell(f^*(S^n)) \ge \gamma n]$ 相关，并使用斯特林公式 (I.2) 求 γ。

II.12 考虑一个概率测度 $\mathbb{P}$ 和一个保测变换 τ: $\Omega \to \Omega$。证明 τ 是遍历的当且仅当对于任何可测的 A, B，我们有

$$\frac{1}{n}\sum_{k=0}^{n-1} \mathbb{P}[A \cap \tau^{-k}B] \to \mathbb{P}[A]\mathbb{P}[B]\,.$$

Comment: 因此，遍历性是一个比*mixing*更弱的条件：$\mathbb{P}[A \cap \tau^{-n}B] \to \mathbb{P}[A]\mathbb{P}[B]$。

II.13（算术编码）我们分析由(13.1)定义的用于独立同分布源的编码器。令P为某个有序有限字母表上的分布，例如$\mathtt{a} < \mathtt{b} < \cdots < \mathtt{z}$。对于每个$n$，根据字典序定义 $p(x^n) = \prod_{i=1}^n P(x_i)$和$q(x^n) = \sum_{y^n<x^n} p(y^n)$，使得$F_n(x^n) = q(x^n)$和$|I_{x^n}| = p(x^n)$。

(a) 证明如果 $x^{n-1} = (x_1, \ldots, x_{n-1})$，那么

$$q(x^n) = q(x^{n-1}) + p(x^{n-1}) \sum_{\alpha<x_n} P(\alpha).$$

得出结论，$q(x^n)$ 可以顺序地在 $O(n)$ 步骤内计算得出。

(b) 证明区间 I_{x^n} 是 $[0, 1)$ 的不相交子区间。

(c) *Encoding*。证明 (13.1) 中定义的码长 $l(f(x^n))$ 满足约束 (13.2)，即 $\log_2 \frac{1}{p(x^n)} \le \ell(f(x^n)) \le \left\lceil \log_2 \frac{1}{p(x^n)} \right\rceil + 1$。此外，验证映射 $x^n \mapsto f(x^n)$ 定义了一个前缀码。（*Warning*：这不是检验 Kraft 不等式。）

(d) *Decoding*。收到码字后，我们可以重建区间 D_{x^n}。根据分布 P 划分单位区间，即将 $[0, 1)$ 分割为不相交的子区间 $I_{\mathtt{a}}, \ldots, I_{\mathtt{z}}$。输出包含 D_{x^n} 的索引。证明这给出了第一个符号 x_1。继续以这种方式将 I_{x_1} 划分为 $I_{x_1,\mathtt{a}}, \ldots, I_{x_1,\mathtt{z}}$ 等。论证 x^n 可以被无损解码。需要多少步?

(e) 假设 $P_X(\mathtt{e}) = 0.5, P_X(\mathtt{o}) = 0.3, P_X(\mathtt{t}) = 0.2$。编码 $\mathtt{etoo}$ (写出二进制码字)，并描述如何解码。

(f) 证明该编码的平均长度满足

$$nH(P) \le \mathbb{E}[l(f(X^n))] \le nH(P) + 2 \quad \mathtt{bits}.$$

(g) 假设 $X = (X_1, \ldots, X_n)$ 不是独立同分布的，但 $P_{X_1}, P_{X_2|X_1}, \ldots, P_{X_n|X^{n-1}}$ 是已知的。你会如何修改方案，以使得我们拥有

$$H(X^n) \le \mathbb{E}[l(f(X^n))] \le H(X^n) + 2 \quad \mathtt{bits}.$$

II.14（枚举编码）考虑以下用于二进制序列的简单通用压缩器：给定 $x^n \in \{0, 1\}^n$，用 $n_1 = \sum_{i=1}^n x_i$ 和 $n_0 = n - n_1$ 分别表示 x^n 中 1 和 0 的个数。首先使用 $\lceil \log_2(n+1) \rceil$ 比特编码 $n_1 \in \{0, 1, \ldots, n\}$，然后使用 $\left\lceil \log_2 \binom{n}{n_1} \right\rceil$ 比特编码 x^n 在所有具有 n_1 个 1 的字符串集合中的索引。将两个二进制字符串连接起来，我们得到 x^n 的码字。这定义了一个无损压缩器 f: $\{0, 1\}^n \to \{0, 1\}^*$。

(a) 验证 f 是否为前缀码。(b) 设 $\mathbb{E}_\theta$ 取自 $X^n \overset{\text{i.i.d.}}{\sim} \mathrm{Ber}(\theta)$。证明对于任意 $\theta \in [0, 1]$,

$$\mathbb{E}_\theta[l(f(X^n))] \le nh(\theta) + \log n + O(1),$$

其中 $h(\cdot)$ 是二元熵函数。得出结论：

$$\sup_{0\le\theta\le 1}\{\mathbb{E}_\theta[l(f(X^n))]-nh(\theta)\}\ge \log n+O(1).$$

[可选：解释为什么枚举编码无法达到最优冗余度。] *Hint*：斯特林近似（I.2）可能有用。

我15（Krichevsky-Trofimov 码）。考虑二进字母表的 K-T 概率分配（13.27）及其序列形式（13.29）。设 f_{KT} 为长度分配为 $l(f(x^n))=\left\lceil \log_2 \frac{1}{Q_{X^n}^{(\mathrm{KT})}(x^n)}\right\rceil$ 对所有 x^n 的编码器。

(a) 证明对于任意 n 和任意 $x^n\in\{0,1\}^n$，

$$Q_{X^n}^{(\mathrm{KT})}(x^n)\ge \frac{1}{2}\frac{1}{\sqrt{t_0+t_1}}\left(\frac{t_0}{t_0+t_1}\right)^{t_0}\left(\frac{t_1}{t_0+t_1}\right)^{t_1}.$$

其中 $t_i=t_i(x^n), i\in\{0,1\}$ 计算 x^{n-1} 中出现的 i 的数量。 *Hint:* 对 n 进行归纳。

(b) 得出结论，K-T 码长度满足：

$$l(f_{\mathrm{KT}}(x^n))\le nh\left(\frac{n_1}{n}\right)+\frac{1}{2}\log n+2,\quad \forall x^n\in\{0,1\}^n.$$

(c) 得出结论，对于K-T码，其冗余度受限于：在习题II.14b的记号中，

$$\sup_{0\le\theta\le 1}\{\mathbb{E}_\theta[l(f_{\mathrm{KT}}(X^n))]-nh(\theta)\}\le \frac{1}{2}\log n+O(1).$$

这确立了二进制字母表下 (13.24) 的 $O(1)$ 版本的上界部分。（实际上，部分 (b) 展示了更强结果，即 KT 码的逐点冗余度（参见 (13.11)）满足 $\max_{x^n\in\{0,1\}^n}\max_\theta \log \frac{P_{X^n|\theta}(x^n)}{Q_{X^n}^{(\mathrm{KT})}(x^n)}\le \frac{1}{2}\log n+O(1)$。）

II.16（冗余下界：二元字母表）在练习II.15中，我们展示了对于独立同分布伯努利模型，极小极大平均情况冗余，参见(13.8)，满足$\mathcal{R}_n^*([0,1])\le\frac{1}{2}\log n+O(1)$。我们通过计算$I(\theta;X^n)$对于$\theta\sim\mathrm{Unif}([0,1])$来证明该界限是紧的。因此，根据容量-冗余定理(13.10)，这提供了冗余的一个下界。

(a) 令 $\hat\theta=\frac{1}{n}\sum_{i=1}^n X_i$ 表示观测到的1的频率。证明

$$I(\theta;X^n)=I(\theta;\hat\theta).$$

(提示：第 3.5.) 节

(b) 证明贝叶斯风险满足 $\mathbb{E}[(\theta-\hat\theta)^2]=\frac{1}{6n}$。

(c) 计算微分熵 $h(\theta)$。

(d) 证明以下每一步

$$h(\theta|\hat\theta)=h(\theta-\hat\theta|\hat\theta)\le h(\theta-\hat\theta)\le\frac{1}{2}\log\frac{2\pi e}{6n}.$$

(提示：（2.20)。）

(e) 综合上述步骤，得出结论 $\mathcal{R}_n^*\ge\frac{1}{2}$ 记录 $n+c_1$，并计算 c_1 的值。

(f) 现在选择 π 作为 Beta($\frac{1}{2}$) 先验，并重做上一部分。你能得到一个更好的常数 c_1 吗?

Comments: 我们遵循了[118]中引入的策略，即通过猜测一个好的估计量 $\hat{\theta} = \hat{\theta}(X_1, \ldots, X_n)$并基于估计误差来界定$I(\theta; \hat{\theta})$，从而对$I(\theta; X^n)$进行下界估计。其基本原理是，如果$\theta$能够被很好地估计，那么$X^n$就需要提供大量的信息。我们将在第30章进一步探讨这一想法。

II.17 考虑以下依赖于参数 $\theta \in [0, 1]$ 的平稳遍历马尔可夫过程的集合。$X_1 \sim$ 服从 Ber($\frac{1}{2}$)，然后 $X_t = \begin{cases} X_{t-1} \text{ 以概率 } 1-\theta, \\ 1 - X_{t-1} \text{ 以概率 } \theta. \end{cases}$。将得到的马尔可夫核记为 $P_{X^n|\theta}$。

(a) 计算 $J_F(\theta)$。(b) 证明极小极大冗余 $\mathcal{R}_n^* = (\frac{1}{2} + o(1)) \log n$。

II.18（Elias编码）在这个问题中，我们为整数构造*universal*码。即，它们将任何整数值（无限字母表！）的随机变量几乎压缩至其熵。

(a) 考虑以下针对自然数的通用压缩器：对于$x \in \mathbb{N} = \{1, 2, \ldots\}$，令$k(x)$表示其二进制表示的长度。定义其码字$c(x)$为$k(x)$个零后跟$x$的二进制表示。计算$c(10)$。证明$c$是前缀码，并描述如何解码码字流。(b) 接下来，我们使用上述编码构造另一个编码：定义码字$c'(x)$为$c(k(x))$后跟x的二进制表示。计算$c'(10)$。证明c'是前缀码，并描述如何解码码字流。(c) 令X为$\mathbb{N}$上的一个随机变量，其概率质量函数递减。证明$\mathbb{E}[\log(X)] \le H(X)$。(d) 证明$c$的平均码长满足$\mathbb{E}[\ell(c(X))] \le 2H(X) + 2\texttt{bit}$。(e) 证明$c'$的平均码长满足$\mathbb{E}[\ell(c'(X))] \le H(X) + 2\log(H(X) + 1) + 3\texttt{bit}$。

Comments：这两种编码方案被称为 Elias γ 码和 δ 码。

II.19（批量损失）回顾第13.6节中在线预测的批量遗憾定义。证明当最大化者π^*存在时，我们有

$$\mathrm{BatchReg}_n^*(\Theta) = \max_{\pi \in \mathcal{P}(\Theta)} I(\theta; X_n | X^{n-1}),$$

其中优化是在$\theta \sim \pi$的分布上进行的。（提示：应用练习I.11。）

II.20（监督学习）考虑一个可能是非独立同分布的随机过程$X^n = (X_1, \ldots, X_n)$以及一个条件分布的参数集合$P_{Y|X}^{(\theta)}, \theta \in \Theta$，我们也将其理解为一个核$P_{Y|X,\theta}$。自然固定$\theta^*$并独立生成 $Y_i \sim P_{Y|X=X_i}^{(\theta^*)}$。这些样本被顺序地提供给学习器，学习器在观察到（$X^t, Y^{t-1}$）后输出 $\hat{Q}_t(\cdot) \in \mathcal{P}(\mathcal{Y})$并经历对数损失$-\log \hat{Q}_t(Y_t)$。监督学习的目标是最小化最坏情况

遗憾，即在以下式中找到最小化者

$$\mathrm{AvgReg}_n^*(\Theta) \triangleq \inf_{\{Q_t\}} \sup_{\theta^*\in\Theta} \mathbb{E}\left[\sum_{t=1}^n \log\frac{1}{\hat{Q}_t(Y_t)} - \log\frac{1}{P_{Y|X}^{(\theta^*)}(Y_t|X_t)}\right]$$

这里我们展示定理13.3的类似情况，即

$$\mathrm{AvgReg}_n^*(\Theta) = C_n \triangleq \max_{\pi} I(\theta; Y^n|X^n)\,,$$

在$\pi\in\mathcal{P}(\Theta)$上对$\theta$的先验进行优化。我们假设最大值在某个$\pi^*$处达到。

(a) 令 $D_n \triangleq \inf_{Q_{Y^n|X^n}} \sup_{\theta\in\Theta} D(P_{Y|X}^{(\theta)\otimes n}\|Q_{Y^n|X^n}|P_{X^n})$，其中下确界取遍所有条件核 $Q_{Y^n|X^n}$: $\mathcal{X}^n\to\mathcal{Y}^n$。证明$\mathrm{AvgReg}_n^*(\Theta)\le D_n$。(b) 证明 $C_n = D_n$，并且最优 $Q^*_{Y^n|X^n}(y^n|x^n) = \int \pi^*(d\theta)\prod_{t=1}^n P_{Y|X}^{(\theta)}(y_t|x_t)$ (提示：练习I.11.)c) 证明我们总能将 $Q^*_{Y^n|X^n} = \prod_{t=1}^n Q_{Y_t|X^t,Y^{t-1}}$ 分解。(d) 得出结论，$Q^*_{Y^n|X^n}$ 定义了一个最优学习器，该学习器同样在没有任何 P_{X^n} 知识的情况下运行。

Note: 这种刻画主要用于给出遗憾的上界（习题II.22）。实际上，最优学习器需要知道π^*，而这又通常取决于P_{X^n}，后者对学习器而言不可得。这说明了为什么监督学习比通用压缩要微妙得多。尽管如此，采用“自然”先验π并对混合$\int\pi(d\theta)P_{Y|X}^{(\theta)\otimes n}$进行因式分解，往往能得到非常有趣且常常近乎最优的算法（例如指数权重更新算法[445]）。

II.21（平均情况冗余度和最坏情况冗余度是不可比较的。）这个练习提供了一个例子，其中最坏情况下的极小极大冗余度（13.11）是无限的，而平均情况下的冗余度（13.8）是有限的。取 $n=1$ 并考虑分布类 $\mathcal{P}_1 = \{P\in\mathcal{P}(\mathbb{Z}_+) : \mathbb{E}_P[X]\le 1\}$。定义

$$\mathcal{R}^* = \min_Q \sup_{P\in\mathcal{P}_1} D(P\|Q), \quad \mathcal{R}^{**} = \min_Q \max_{x\in\mathbb{Z}_+}\sup_{P\in\mathcal{P}_1}\log\frac{P(x)}{Q(x)}.$$

(a) 应用容量-冗余定理，证明 $\mathcal{R}^*\le 2\log 2$。（提示：使用习题I.4来界定互信息。）

(b) 证明 $\mathcal{R}^{**} = \infty$ 当且仅当 Shtarkov 和 (13.13) 是无限的，即 $\sum_{x\in\mathbb{Z}_+}\sup_{P\in\mathcal{P}_1}P(x)=\infty$

(c) 验证

$$\sup_{P\in\mathcal{P}_1} P(x) = \begin{cases} 1 & x=0\\ 1/x & x\ge 1\end{cases}$$

并得出$\mathcal{R}^{**}=\infty$。(提示: 马尔可夫不等式。)

II.22（线性回归）设 $X_i \overset{\text{i.i.d.}}{\sim} P_X$ 在 $\mathbb{R}^p$ 上，且 P_X 具有旋转不变性（即对任意正交矩阵 U，有 $X\overset{(d)}{=}UX$）。固定 $\theta\in\mathbb{R}^p$，其中 $\|\theta\|\le s$，并给定 X_i 生成 $Y_i\sim\mathcal{N}(\theta^\top X_i,\sigma^2)$。在观测到 Y^{t-1},X^t (但未观测到 θ) 的情况下，学习器输出对 Y_t 的预测 $\hat{Y}_t$。

(a) 证明

$$\mathrm{AvgReg}_n \triangleq \sup_{\|\theta\|\le s} \sum_{t=1}^{n} \mathbb{E}[(\hat{Y}_t - Y_t)^2] - n\sigma^2 \le \sigma^2 \sum_{i=1}^{p} \mathbb{E}\left[\ln\left(1 + \frac{s^2 n}{p}\lambda_i(\hat{\Sigma}_X)\right)\right],$$

其中 $\hat{\Sigma}_X = \frac{1}{n}\sum_{i=1}^{n} X_i X_i^\top$ 是样本协方差矩阵。（*Hint:* 将左侧视为对数损失下的遗憾，并求解 $\max_{\pi_\theta} I(\theta;\, Y^n|X^n)$ 约束为 $\mathbb{E}[\|\theta\|^2] \le s^2$，通过练习 I.10。）

(b) 证明

$$\mathrm{AvgReg}_n \le \sigma^2 \ln\det\left(I_p + \frac{s^2 n}{p}\Sigma_X\right) \le p\sigma^2 \ln\left(1 + \frac{s^2 n}{p^2}\mathbb{E}[\|X\|^2]\right).$$

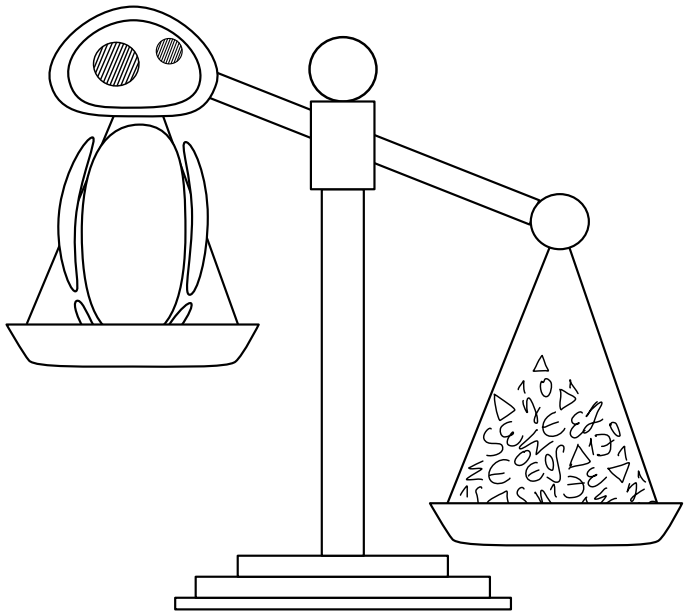
(提示：Jensen不等式。)

Remark: 注意，若$X_i \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0, BI_p)$，右侧为$p\sigma^2 \ln n + O(1)$。同时，对于$n \ge p+2$，普通最小二乘估计$\hat{Y}_t = \hat{\theta}^\top X_t$的预测误差已知恰为[7] $\mathbb{E}[(\hat{Y}_t - Y_t)^2] = \sigma^2(1 + \frac{p}{n-p-1})$，因此达到了最优的$p\sigma^2 \ln n + O(1)$累积遗憾。

[7] This can be shown by applying Exercise **VI.3b** and evaluating the expected trace using [444, Theorem 3.1].

Part III

假设检验与大偏差



在这一部分，我们探讨二元假设检验（BHT）的主题，该主题首次出现在第7.3节中。这是统计学的一个重要领域，[277]中给出了权威性的处理方法。历史上，关于如何处理这个问题存在两种学派。一种是卡尔·皮尔逊和罗纳德·费舍尔所谓的*significance testing*。这可能是现代生物医学和社会科学中最广泛使用的方法。零假设、p值、χ^2检验、拟合优度等概念都属于这一范畴。我们将*not*讨论这些内容。

另一学派由Jerzy Neyman和Egon Pearson开创，本部分我们将探讨这一主题。第一类错误和第二类错误的概念、似然比检验、切尔诺夫指数均源自这一领域。可以说，在工程学科中，这是看待该问题更为普遍的方式（或许可以解释为其在雷达和电子信号检测中的基础性作用）。

这两种方法的概念区别在于，在第一种方法中，完整的概率模型是在零假设下指定的*only*。（它仍然可以非常具体，例如$X_i \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0,1)$，包含未知参数，例如$X_i \overset{\text{i.i.d.}}{\sim} \mathcal{N}(\theta,1)$，其中$\theta \in \mathbb{R}$任意，或者是非参数的，例如$(X_i,Y_i) \overset{\text{i.i.d.}}{\sim} P_{X,Y} = P_X P_Y$表示可观测量$X$和$Y$在统计上独立）。在这种情况下，统计学家的主要目标是设计一种测试过程，能够发现与假定零行为有统计学意义的偏差。如果发现这样的偏差，则拒绝零假设，并且（在科学领域）宣布一项发现。备择假设的作用（如果指定了的话）是粗略地提示零假设的哪些特征最有可能被违反，并激发测试程序的选择。例如，如果在零假设下$X_i \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0,1)$，那么以下两者都是合理的测试：

$$\frac{1}{n}\sum_{i=1}^n X_i \overset{?}{\approx} 0 \qquad \frac{1}{n}\sum_{i=1}^n X_i^2 \overset{?}{\approx} 1\,.$$

然而，如果在备择假设下“数据具有非零均值”，则第一种更受青睐；而如果“数据均值为零但方差不等于一”，则第二种更合适。无论选择哪种备择假设，都不以任何方式暗示该备择假设的有效性。此外，检验的理论性质大多是在原假设而非备择假设下研究的。对于这种方法，两个假设中的原假设扮演着非常特殊的角色。

第二种方法完全对称地对待假设。对于两个假设，都需要精确指定概率分布，并且要在两种情况下分析所提出检验的精确度。这种设定对于我们在后续章节中处理信道编码（第四部分）和统计估计（第六部分）最为有用。

本部分的概要如下。首先，我们定义性能度量$\mathcal{R}(P,Q)$，给出BHT问题的完整描述。该理论中的一个关键结果，Neyman-Pearson引理确定了最优检验的形式，并同时刻画了$\mathcal{R}(P,Q)$。然后我们专门讨论iid观测的设置，并考虑两种类型的渐近性（当样本量n趋于无穷大时）：Stein机制（其中第一类错误保持恒定）和Chernoff机制（其中两类错误都要求指数衰减）。前一种机制中的基本极限只是一个标量（由$D(P\|Q)$给出），而在后一种机制中是一个区域。为了描述这个区域（正如我们在第16章中所做的那样），我们首先需要深入研究另一个基础主题：大偏差理论和信息投影（第15章）。

14 Neyman-Pearson lemma

在本章中，我们正式定义了两个简单假设之间的二元假设检验问题。我们以区域 $\mathcal{R}(P,Q) \subset [0,1]^2$ 的形式引入了该问题的基本极限，其边界被称为 *received operating characteristic (ROC) curve*。我们将展示如何精确计算该区域/曲线（Neyman-Pearson引理），并在此过程中证明似然比检验的最优性。然而，对于高维情况，该区域的精确计算仍然过于复杂，我们还将推导上界和下界（如前所述，我们分别称其为可达性和逆定理）。最后，我们将通过引入两种不同的渐近设置来结束：Stein机制和Chernoff机制。前者的答案将完全给出（对于独立同分布），而后者则需要后续章节的进一步展开。

14.1 奈曼-皮尔逊公式

考虑这样一种情况：在一个空间 $\mathcal{X}$ 上有两个分布 P 和 Q，其中一个生成了我们的观测 X。这两种可能性总结为一对假设：

$$H_0 \ : \ X \sim P$$
$$H_1 \ : \ X \sim Q,$$

该假设表明，在假设H_0 (下，*null hypothesis*) X根据P分布，并且在H_1 (下，*alternative hypothesis*) X根据Q分布。两种分布之间的*test* (或决策规则)基于数据X选择H_0或H_1。我们将考虑

• 确定性检验：$f: \mathcal{X} \to \{0,1\}$，或等价地，$f(x) = 1\{x \in E\}$，其中 E 被称为 *decision region*；更一般地，• 随机化检验：$P_{Z|X}: \mathcal{X} \to \{0,1\}$，因此 $P_{Z|X}(1|x) \in [0,1]$ 是在观察到 $X = x$ 时拒绝原假设的概率。

令 $Z = 0$ 表示检验选择 P (接受原假设)，而 $Z = 1$ 表示检验选择 Q (拒绝原假设)。

这个设置被称为“简单假设对简单假设的检验”。这里“简单”指的是在每个假设下，仅有一个分布可能生成了数据。相比之下，复合假设假定对于*some* P的$X \sim P$是一个给定的分布类；参见第16.4节和32.2.1节。

表14.1 假设检验常见性能指标的表达式

Term	Expression
type-I error, significance, size, false alarm rate, false positive	$1-\alpha$
specificity, selectivity, true negative	α
power, recall, sensitivity, true positive	$1-\beta$
type-II error, missed detection, false negative	β
accuracy	$\pi_1(1-\beta)+(1-\pi_1)\alpha$
F_1-score	$\frac{2\pi_1(1-\beta)}{1+\pi_1(1-\beta)-(1-\pi_1)\alpha}$
Bayesian error	$\pi_1\beta+(1-\pi_1)(1-\alpha)$
positive predictive value (PPV), precision	$\frac{\pi_1(1-\beta)}{1-\pi_1\beta-(1-\pi_1)\alpha}$

涉及 $\pi_1=\mathbb{P}[H_1]$ 的条目对应于贝叶斯设置，其中假定了 H_1 发生的先验概率。

为了量化测试的性能，我们关注两个指标。令$\pi_{i|j}$表示当正确假设为j时，测试选择i的概率，其中$i,j\in\{0,1\}$。对于每个测试$P_{Z|X}$，我们关联一对数字：

$$\alpha=\pi_{0|0}=P[Z=0]\quad(\text{Probability of success given } H_0 \text{ is true})$$
$$\beta=\pi_{0|1}=Q[Z=0]\quad(\text{Probability of error given } H_1 \text{ is true}),$$

其中 $P[Z=0]=\int P_{Z|X}(0|x)P(dx)$ 和 $Q[Z=0]=\int P_{Z|X}(0|x)Q(dx)$。根据研究领域的不同，已经定义了许多不同的名称（和变换），见表14.1。

由于我们有两个性能指标，因此很难理解应该将什么指定为“最佳测试”。因此，有几种方法：

- 贝叶斯：假设先验分布 $\mathbb{P}[H_0]=\pi_0$ 和 $\mathbb{P}[H_1]=\pi_1$，我们最小化平均错误概率：

$$P_b^*=\min_{P_{Z|X}:\mathcal{X}\to\{0,1\}}\pi_0\pi_{1|0}+\pi_1\pi_{0|1}. \tag{14.1}$$

- 最小值最大值：假设存在未知的先验分布，我们选择对最坏情况先验表现最好的测试

$$P_m^*=\min_{P_{Z|X}:\mathcal{X}\to\{0,1\}}\max\{\pi_{1|0},\pi_{0|1}\}.$$

- Neyman-Pearson：在零假设下成功概率至少为 α 的约束下，最小化第二类错误 β。

在本部分，我们选择了Neyman-Pearson表述。我们将基本性能极限形式化如下。

定义14.1 给定(P,Q)，奈曼-皮尔逊区域包含了所有随机检验可达的点。

$$\mathcal{R}(P,Q) = \{(P[Z=0], Q[Z=0]) : P_{Z|X} : \mathcal{X} \to \{0,1\}\} \subset [0,1]^2. \tag{14.2}$$

特别地，其下界定义为（示例参见图14.1）

$$\beta_\alpha(P,Q) \triangleq \inf_{P[Z=0]\geq\alpha} Q[Z=0] \tag{14.3}$$

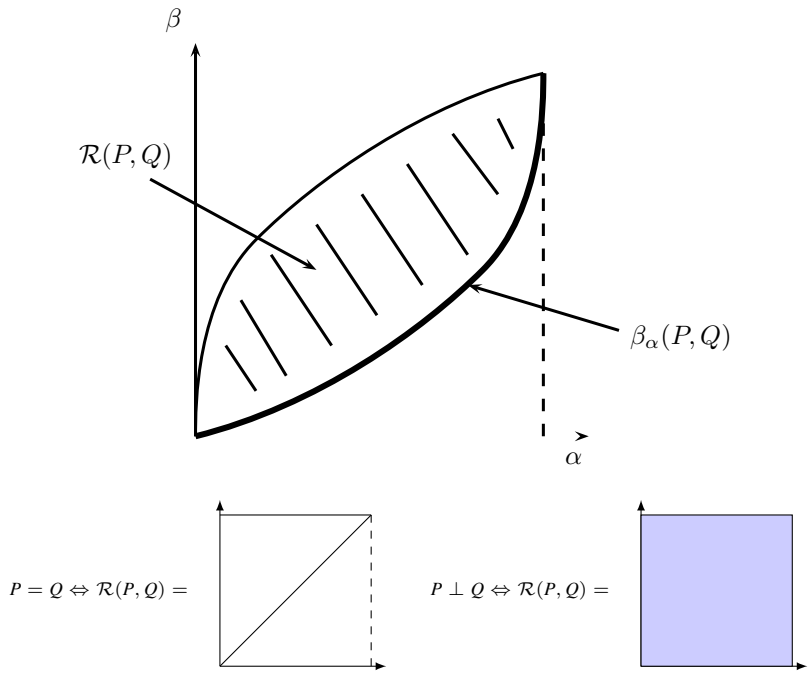


图14.1 Neyman-Pearson区域的示意图：典型情况（顶部图）和两种极端情况（底部行）。回想一下，如果存在某个 E 使得 $P[E]=0$ 且 $Q[E]=1$，则 P 关于 Q 相互奇异，记作 $P \perp Q$。

Neyman-Pearson区域编码了关于P和Q之间关系的大量有用信息。特别是，可以检测到互异性（见图14.1）。此外，每个f散度都可以从$\mathcal{R}(P,Q)$计算得出。例如，TV(P,Q)与包含在$\mathcal{R}(P,Q)$ (练习III.7)中的最长垂直段长度的一半一致。在机器学习中，用于表征$\mathcal{R}(P,Q)$质量的一些最流行的度量是曲线下面积（AUC）

$$\mathrm{AUC}(P,Q) \triangleq 1 - \int_0^1 \beta_\alpha(P,Q) d\alpha\,.$$

接下来我们证明$\mathcal{R}(P,Q)$的几个基本性质。

定理 14.2（$\mathcal{R}(P,Q)$ 的性质）

(b) $\mathcal{R}(P,Q)$ is a closed, convex subset of $[0,1]^2$.
(c) Symmetry: $(\alpha,\beta)\in\mathcal{R}(P,Q)\Leftrightarrow(1-\alpha,1-\beta)\in\mathcal{R}(P,Q)$.

Proof. (a) 对于凸性，假设$(\alpha_0,\beta_0),(\alpha_1,\beta_1)\in\mathcal{R}(P,Q)$，分别对应于测试$P_{Z_0|X},P_{Z_1|X}$。在这两个测试之间随机化，我们得到测试$\lambda P_{Z_0|X}+\bar{\lambda}P_{Z_1|X}$对于$\lambda\in[0,1]$，达到点$(\lambda\alpha_0+\bar{\lambda}\alpha_1,\lambda\beta_0+\bar{\lambda}\beta_1)\in\mathcal{R}(P,Q)$。
$\mathcal{R}(P,Q)$的封闭性将通过内曼-皮尔逊引理明确确定所有边界点而得出——参见注记14.1。在更复杂的情形下（例如针对复合假设进行检验时），类似内曼-皮尔逊引理那样的简单显式解并不可用，但区域的封闭性往往仍可论证。基本原因在于，有界函数集合$\{g\colon\ \mathcal{X}\to[0,1]\}$ (且$g(x)=P_{Z|X}(0|x)$)构成弱紧集，因此其在线性泛函$g\mapsto(\int gdP,\int gdQ)$下的像是闭的。

(b) 通过随机猜测进行测试，即 $Z\sim\mathrm{Ber}(1-\alpha)\perp\!\!\!\perp X$，达到点 (α,α)。
(c) 如果 $(\alpha,\beta)\in\mathcal{R}(P,Q)$ 由 $P_{Z|X}$ 达成，则 $P_{1-Z|X}$ 达成 $(1-\alpha,1-\beta)$。

□

区域$\mathcal{R}(P,Q)$由所有随机化测试的工作点组成，其中包括确定性测试作为特殊情况，即

$$\mathcal{R}_{\mathrm{det}}(P,Q)=\{(P(E),Q(E)):E\text{ measurable}\}. \tag{14.4}$$

如下一个结果表明，前者实际上是后者的闭凸包。回想一下，cl(E)（相应地，co(E)）表示集合 E 的闭包和凸包，即包含 E 的最小闭集（相应地，凸集）。一个有用的例子：对于欧几里得空间的一个子集 E，以及可测函数$f,g:\mathbb{R}\to E$，对于任意实值随机变量 X，我们有 $(\mathbb{E}[f(X)],\mathbb{E}[g(X)])\in\mathrm{cl}(\mathrm{co}(E))$。

定理14.3（随机化测试与确定性测试对比）

$$\mathcal{R}(P,Q)=\mathrm{cl}(\mathrm{co}(\mathcal{R}_{\mathrm{det}}(P,Q))).$$

Consequently, if P and Q are on a finite alphabet $\mathcal{X}$, then $\mathcal{R}(P,Q)$ is a polygon of at most $2^{|\mathcal{X}|}$ vertices.

Proof. “$\supset$”：比较（14.2）和（14.4），根据定义，$\mathcal{R}(P,Q)\supset\mathcal{R}_{\mathrm{det}}(P,Q)$），其中前者是闭凸的，由定理14.2。

“$\subset$”：给定任意随机化检验 $P_{Z|X}$，定义可测函数 $g\colon\ \mathcal{X}\to[0,1]$ 为 $g(x)=P_{Z|X}(0|x)$。那么

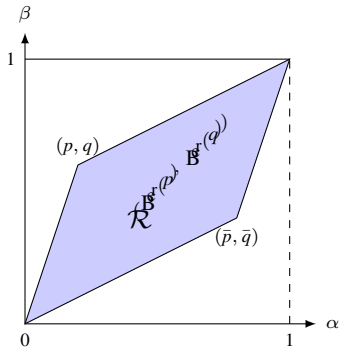
$$P[Z=0]=\sum_x g(x)P(x)=\mathbb{E}_P[g(X)]=\int_0^1 P[g(X)\geq t]dt$$

$$Q[Z=0]=\sum_x g(x)Q(x)=\mathbb{E}_Q[g(X)]=\int_0^1 Q[g(X)\geq t]dt$$

其中我们应用了“面积规则”，即对于任何非负随机变量 U，有 $E[U]=\int_{\mathbb{R}_+}\mathbb{P}[U\geq t]\,dt$。因此，点 $(P[Z=0],Q[Z=0])\in\mathcal{R}$ 是点 $(P[g(X)\geq t],Q[g(X)\geq t])\in\mathcal{R}_{\text{det}}$ 的混合，根据 t 在单位区间上均匀分布进行平均。因此 $\mathcal{R}\subset\text{cl}(\text{co}(\mathcal{R}_{\text{det}}))$。

最后一个断言成立，因为在(14.4)中至多有$2^{|\mathcal{X}|}$个子集。 □

例14.1（检验Ber(p)与Ber(q)）假设$p<\frac{1}{2}<q$。利用定理14.3，注意有$2^2=4$个事件$E=\emptyset,\{0\},\{1\},\{0,1\}$。则$\mathcal{R}(\text{Ber}(p),\text{Ber}(q))$由下式给出



14.2 似然比检验

为了定义最优假设检验，我们需要定义对数似然比（LLR）的概念。在 $P\ll Q$ 的简单情况下，我们可以通过考虑 $\log 0=-\infty$，将对数似然比 $T(x)=\log\frac{dP}{dQ}(x)$ 定义为函数 T: $\mathcal{X}\to\mathbb{R}\cup\{-\infty\}$。为了也处理 $P\not\ll Q$ 的情况，我们可以利用我们的 Log 函数概念，参见（2.10）。

定义 14.4（扩展对数似然比）假设 $dP=p(x)d\mu$ 和 $dQ=q(x)d\mu$ 对于某个优势测度 μ（，例如 $\mu=P+Q$。）回顾（2.10）中对 Log 的定义，我们将扩展 LLR 定义为

$$T(x)\triangleq\text{Log}\frac{p(x)}{q(x)}=\begin{cases}\log\frac{p(x)}{q(x)}, & p(x)>0,q(x)>0\\ +\infty, & p(x)>0,q(x)=0\\ -\infty, & p(x)=0,q(x)>0\\ 0, & p(x)=0,q(x)=0\end{cases},$$

定义 14.5（似然比检验 (LRT)）给定一个二元假设检验 H_0： $X \sim P$ 与 H_1： $X \sim Q$，阈值 $\tau \in \mathbb{R} \cup \{\pm\infty\}$ 下的似然比检验 (LRT) 是 $1\{x$： $T(x) \le \tau\}$，换言之，它决定

$$\mathrm{LRT}_\tau(x) = \begin{cases} \text{declare } H_0, & T(x) > \tau \\ \text{declare } H_1, & T(x) \le \tau \end{cases}.$$

当 $P \ll Q$ 时，显然 $T(x) = \log \frac{dP}{dQ}(x)$ 对于 P- 和 Q-几乎每一个 x。因此，在本部分中我们滥用记号，简单地写 $\log \frac{dP}{dQ}$ 来表示如上定义的 *extended* (!) LLR。注意 LRT 是一个确定性检验，并且它确实具有直观意义：在观察到 x 后，如果 $\frac{Q(x)}{P(x)}$ 很大，那么 Q 更可能，因此应当拒绝原假设 P。

注意，对于离散字母表 $\mathcal{X}$，并假设 $Q \ll P$，我们可以看到

$$Q[T = t] = \exp(-t)P[T = t] \qquad \forall t \in \mathbb{R} \cup \{+\infty\}.$$

事实上，这一点通过以下链条得以展示：

$$\begin{aligned} Q_T(t) &= \sum_{\mathcal{X}} Q(x) 1\{\log \frac{P(x)}{Q(x)} = t\} = \sum_{\mathcal{X}} Q(x) 1\{e^t Q(x) = P(x)\} \\ &= e^{-t} \sum_{\mathcal{X}} P(x) 1\{\log \frac{P(x)}{Q(x)} = t\} = e^{-t} P_T(t) \end{aligned}$$

我们看到，对 P 和 Q 取期望时，若将期望值乘以 $\exp(\pm T)$，则二者等价。下一个结果给出了一般情况下精确的细节。

定理 14.6（测度变换 $P \leftrightarrow Q$）*The following hold:*

1 For any $h : \mathcal{X} \to \mathbb{R}$ we have

$$\mathbb{E}_Q[h(X)1\{T > -\infty\}] = \mathbb{E}_P[h(X)\exp(-T)] \tag{14.5}$$
$$\mathbb{E}_P[h(X)1\{T < +\infty\}] = \mathbb{E}_Q[h(X)\exp(T)] \tag{14.6}$$

2 For any $f \ge 0$ and any $-\infty < \tau < \infty$ we have

$$\begin{aligned} &\mathbb{E}_Q[f(X)1\{T \ge \tau\}] \le \mathbb{E}_P[f(X)1\{T \ge \tau\}] \cdot \exp(-\tau) \\ &\mathbb{E}_Q[f(X)1\{T \le \tau\}] \ge \mathbb{E}_P[f(X)1\{T \ge \tau\}] \cdot \exp(-\tau) \end{aligned} \tag{14.7}$$

Proof. 我们首先观察到

$$Q[T = +\infty] = P[T = -\infty] = 0\,. \tag{14.8}$$

然后考虑链

$$\mathbb{E}_Q[h(X)1\{T > -\infty\}] \overset{(a)}{=} \int_{\{-\infty < T(x) < \infty\}} d\mu\ q(x)h(x) \overset{(b)}{=} \int_{\{-\infty < T(x) < \infty\}} d\mu\ p(x)\exp(-T(x))h(x)$$

$$\overset{(c)}{=} \int_{\{-\infty<T(x)\le\infty\}} d\mu\ p(x)\exp(-T(x))h(x) = \mathbb{E}_P[\exp(-T)g(T)]\,,$$

其中在 (a) 中，我们使用 (14.8) 来证明限制在 T 的有限值是合理的；在 (b) 中，我们对 $p,q>0$ 使用了 $\exp(-T(x))=\frac{q(x)}{p(x)}$；而 (c) 则源于以下事实：只要 $T=\infty$，就有 $\exp(-T(x))=0$。交换 P 和 Q 的角色即可证明 (14.6)。

最后一部分分别通过在（14.5）和（14.6）中取$h(x)=f(x)1\{T(x)\ge\tau\}$和$h(x)=f(x)1\{T(x)\le\tau\}$得出。 □

LLR的重要性在于，它是检验这两个假设的充分统计量（回想第3.5节，尤其是例3.9），如下结果所示。

推论 14.7 *$T=T(X)$ is a sufficient statistic for testing P versus Q.*

Proof. 对于第2部分，T的充分性将由$P_{X|T}=Q_{X|T}$暗示。对于$\mathcal{X}$为离散的情况，我们有：

$$\begin{aligned}P_{X|T}(x|t) &= \frac{P_X(x)P_{T|X}(t|x)}{P_T(t)} = \frac{P(x)1\{\frac{P(x)}{Q(x)}=e^t\}}{P_T(t)} = \frac{e^tQ(x)1\{\frac{P(x)}{Q(x)}=e^t\}}{P_T(t)}\\ &= \frac{Q_{XT}(xt)}{e^{-t}P_T(t)} = \frac{Q_{XT}}{Q_T} = Q_{X|T}(x|t).\end{aligned}$$ □

我们将一般情况留作练习。

由定理14.3可知，为了得到可达区域 $\mathcal{R}(P,Q)$，可以先遍历所有决策区域并计算区域 $\mathcal{R}_{\text{det}}(P,Q)$，然后取其闭凸包。但如果字母表很大或无限，这是一项艰巨的任务。另一方面，我们知道LLR是一个充分统计量。接下来，我们根据LLR的统计量给出区域 $\mathcal{R}(P,Q)$ 的界。通常，有两种类型的陈述：

• 逆向（外边界）：$\mathcal{R}(P,Q)$ 中的任何点都必须满足某些约束条件；• 可达性（内边界）：满足某些约束条件的点属于 $\mathcal{R}(P,Q)$。

14.3 关于$\mathcal{R}(P,Q)$的反向边界

定理 14.8（弱逆）$\forall(\alpha,\beta)\in\mathcal{R}(P,Q)$,

$$\begin{aligned}d(\alpha\|\beta) &\le D(P\|Q)\\ d(\beta\|\alpha) &\le D(Q\|P)\end{aligned}$$

where $d(\cdot\|\cdot)$ is the binary divergence function in (2.6).

Proof. 对KL散度使用数据处理不等式，其中 {v*}；参见推论2.19。 □

我们将借助以下结果来强化这一界限。

引理 14.9 *For any test Z and any $\gamma > 0$ we have*

$$P[Z=0] - \gamma Q[Z=0] \le P\big[T > \log\gamma\big]\,,$$

where $T =$ 日志 $\frac{dP}{dQ}$ is understood in the extended sense of Definition 14.4.

注意，我们不需要假设 {v*}，正是因为 $\pm\infty$ 是（扩展）对数似然比的允许值。

Proof. 定义 $\tau = \log\gamma$ 和 $g(x) = P_{Z|X}(0|x)$，我们从（14.7）得到：

$$P[Z=0, T\le\tau] - \gamma Q[Z=0, T\le\tau] \le 0\,.$$

分解 $P[Z=0] = P[Z=0, T\le\tau] + P[Z=0, T>\tau]$ 并类似地对 Q 进行分解，我们便得到

$$P[Z=0] - \gamma Q[Z=0] \le= P\left[T>\log\gamma, Z=0\right] - \gamma Q\left[T>\log\gamma, Z=0\right] \le P\left[T>\log\gamma\right]$$

□

定理 14.10（强逆）$\forall(\alpha,\beta)\in\mathcal{R}(P,Q), \forall\gamma>0$,

$$\alpha - \gamma\beta \le P\Big[\log\frac{dP}{dQ} > \log\gamma\Big] \tag{14.9}$$

$$\beta - \frac{1}{\gamma}\alpha \le Q\Big[\log\frac{dP}{dQ} < \log\gamma\Big] \tag{14.10}$$

Proof. 将引理14.9应用于(P,Q,γ)和$(Q,P,1/\gamma)$。 □

定理 14.10 以半平面的形式给出了区域 $\mathcal{R}(P,Q)$ 的外界。为看出这一点，固定 $\gamma>0$ 并考虑直线 $\alpha-\gamma\beta=c$，通过将 c 从零逐渐增大。存在一个最大的 c，记为 c^*，此时该直线触及区域的下边界。于是 (14.9) 表明 c^* 不能超过 $P[\log\frac{dP}{dQ} > \log\gamma]$。因此 $\mathcal{R}$ 必须位于该直线的左侧。类似地，(14.10) 为上边界提供了界。总之，定理 14.10 表明 $\mathcal{R}(P,Q)$ 包含在由 γ 索引的无限个半平面的交集中。

为了应用强逆定理14.10，我们需要知道对数似然比（LLR）的累积分布函数（CDF），而应用弱逆定理14.8时，我们仅需了解LLR的期望值，即散度。这是信息论中弱逆定理与强逆定理之间常见的模式。

14.4 $\mathcal{R}(P,Q)$ 上的可达性界

给定集合 $\mathcal{R}(P,Q)$ 的凸性，很自然地会尝试找出它的所有支撑直线（二维中的超平面），因为众所周知，闭凸集等于所有与支撑超平面相对应的半空间的交集。因此，我们被引向如下问题：对于 $t>0$,

$$\max\{\alpha - t\beta : (\alpha,\beta)\in\mathcal{R}(P,Q)\}\,,$$

这等价于在(14.1)中最小化平均错误概率，其中$t = \frac{\pi_1}{\pi_0}$。这可以轻松解决。为简化起见，考虑离散情况。那么

$$\alpha^* - t\beta^* = \max_{(\alpha,\beta)\in\mathcal{R}}(\alpha - t\beta) = \max_{P_{Z|X}} \sum_{x\in\mathcal{X}}(P(x) - tQ(x))P_{Z|X}(0|x) = \sum_{x\in\mathcal{X}}|P(x) - tQ(x)|^+$$

其中最后一个等式源于我们可以自由选择 $P_{Z|X}(0|x)$ 这一事实，而最佳选择显而易见：

$$P_{Z|X}(0|x) = 1\left\{\log\frac{P(x)}{Q(x)} \geq \log t\right\}.$$

因此，我们已经展示了所有支撑超平面都可由LRT参数化。除了对应于区域的面（平坦部分）的点之外，这完全恢复了区域$\mathcal{R}(P,Q)$。精确的结果陈述如下：

定理 14.11（内曼-皮尔逊引理）*For each α, β_α in (14.3) is attained by the following test:*

$$P_{Z|X}(0|x) = \begin{cases} 1 & \log\frac{dP}{dQ} > \tau \\ \lambda & \log\frac{dP}{dQ} = \tau \\ 0 & \log\frac{dP}{dQ} < \tau \end{cases} \tag{14.11}$$

where $\tau \in \mathbb{R}$ and $\lambda \in [0,1]$ are the unique solutions to $\alpha = P[\text{日志}\frac{dP}{dQ} > \tau] + \lambda P[\text{日志}\frac{dP}{dQ} = \tau]$.

Proof of Theorem 14.11. 令 $t = \exp(\tau)$。给定任意测试 $P_{Z|X}$，令 $g(x) = P_{Z|X}(0|x) \in [0,1]$。我们要证明

$$\alpha = P[Z=0] = \mathbb{E}_P[g(X)] = P\left[\frac{dP}{dQ} > t\right] + \lambda P\left[\frac{dP}{dQ} = t\right] \tag{14.12}$$

$$\Rightarrow \beta = Q[Z=0] = \mathbb{E}_Q[g(X)] \overset{\text{goal}}{\geq} Q\left[\frac{dP}{dQ} > t\right] + \lambda Q\left[\frac{dP}{dQ} = t\right] \tag{14.13}$$

利用简单事实，即对于任何 $f \geq \neq 0$，$\mathbb{E}_Q[f(X)1\left\{\frac{dP}{dQ} \leq t\right\}] \geq t^{-1}\mathbb{E}_P[f(X)1\left\{\frac{dP}{dQ} \leq t\right\}]$ 成立两次，我们有

$$\begin{aligned}
\beta &= \mathbb{E}_Q[g(X)1\left\{\frac{dP}{dQ} \leq t\right\}] + \mathbb{E}_Q[g(X)1\left\{\frac{dP}{dQ} > t\right\}] \\
&\geq \frac{1}{t}\underbrace{\mathbb{E}_P[g(X)1\left\{\frac{dP}{dQ} \leq t\right\}]}+\mathbb{E}_Q[g(X)1\left\{\frac{dP}{dQ} > t\right\}] \\
&\overset{(14.12)}{=} \frac{1}{t}\Big(\underbrace{\mathbb{E}_P[(1-g(X))1\left\{\frac{dP}{dQ} > t\right\}] + \lambda P\left[\frac{dP}{dQ} = t\right]}\Big) + \mathbb{E}_Q[g(X)1\left\{\frac{dP}{dQ} > t\right\}] \\
&\geq \mathbb{E}_Q[(1-g(X))1\left\{\frac{dP}{dQ} > t\right\}] + \lambda Q\left[\frac{dP}{dQ} = t\right] + \mathbb{E}_Q[g(X)1\left\{\frac{dP}{dQ} > t\right\}] \\
&= Q\left[\frac{dP}{dQ} > t\right] + \lambda Q\left[\frac{dP}{dQ} = t\right].
\end{aligned}$$

□

注14.1 根据内曼-皮尔逊引理，区域{v*}边界上的所有点都是可达的。因此

$$\mathcal{R}(P,Q) = \{(\alpha,\beta) : \beta_\alpha \le \beta \le 1-\beta_{1-\alpha}\}.$$

由于 $\alpha \mapsto \beta_\alpha$ 在 $[0,1]$ 上是凸的，因此是连续的，区域 $\mathcal{R}(P,Q)$ 是闭凸集，如定理14.2所述。因此，β_α 定义中的下确界实际上是最小值。

此外，区域$\mathcal{R}(P,Q)$的下半部分是以下两个集合并集的凸包：

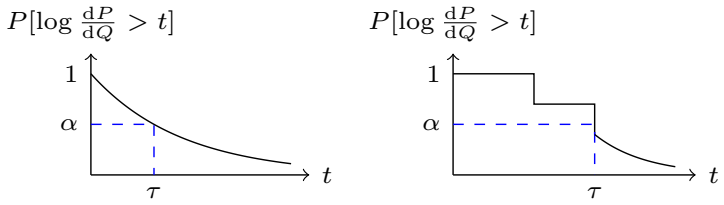
$$\begin{cases}\alpha = P\left[\log \frac{dP}{dQ} > \tau\right] \\ \beta = Q\left[\log \frac{dP}{dQ} > \tau\right]\end{cases} \qquad \tau \in \mathbb{R} \cup \{\pm\infty\}.$$

和

$$\begin{cases}\alpha = P\left[\log \frac{dP}{dQ} \ge \tau\right] \\ \beta = Q\left[\log \frac{dP}{dQ} \ge \tau\right]\end{cases} \qquad \tau \in \mathbb{R} \cup \{\pm\infty\}.$$

因此，将注意力限制在形式为 $1\{\log \frac{dP}{dQ} \ge \tau\}$ 或 $1\{\log \frac{dP}{dQ} > \tau\}$ 的检验上不会失去最优性。上述两种检验风格的凸组合（随机化）导出了 Neyman-Pearson 引理（定理 14.11）的可达性。

注14.2 Neyman-Pearson检验（14.11）与LRT[1]的关系如下：



• 左图：如果对某个 τ 有 $\alpha = P[\log \frac{dP}{dQ} > \tau]$，那么 $\lambda = 0$，并且（14.11）成为 LRT $Z = 1\left\{\log \frac{dP}{dQ} \le \tau\right\}$。 • 右图：如果对任意 τ 有 $\alpha \ne P[\log \frac{dP}{dQ} > \tau]$，那么我们有 $\lambda \in (0,1)$，并且（14.11）等价于在检验上随机化：以概率 $1-\lambda$ 有 $Z = 1\left\{\log \frac{dP}{dQ} \le \tau\right\}$，或以概率 λ 有 $1\left\{\log \frac{dP}{dQ} < \tau\right\}$。

推论 14.12 $\forall \tau \in \mathbb{R}$, *there exists* $(\alpha,\beta) \in \mathcal{R}(P,Q)$ *s.t.*

$$\alpha = P\left[\log \frac{dP}{dQ} > \tau\right]$$

1 请注意，在定义14.4中，似然比检验用的是≤而非<。

$$\beta \le \exp(-\tau) P\Big[\log \frac{dP}{dQ} > \tau\Big] \le \exp(-\tau)$$

Proof. 对于离散$\mathcal{X}$的情况，很容易给出显式证明

$$\begin{aligned} Q\Big[\log \frac{dP}{dQ} > \tau\Big] &= \sum Q(x) 1\Big\{\frac{P(x)}{Q(x)} > \exp(\tau)\Big\} \\ &\le \sum P(x) \exp(-\tau) 1\Big\{\frac{P(x)}{Q(x)} > \exp(tau)\Big\} = \exp(-\tau) P\Big[\log \frac{dP}{dQ} > \tau\Big]. \end{aligned}$$

一般情况只是（14.7）的应用。 □

14.5 渐近性：斯坦因体制

在理解了如何计算和界定$\mathcal{R}(P,Q)$之后，我们接下来进行渐近分析。我们将重点讨论大样本渐近中的独立同分布观测，也就是说，我们在这里将讨论$\mathcal{R}(P^{\otimes n}, Q^{\otimes n})$。换句话说，我们考虑

$$\begin{aligned} H_0 &: X_1, \dots, X_n \overset{\text{i.i.d.}}{\sim} P \\ H_1 &: X_1, \dots, X_n \overset{\text{i.i.d.}}{\sim} Q, \end{aligned} \tag{14.14}$$

其中 P 和 Q 不依赖于 n；这是我们一般设置的一个特例，将 P 和 Q 替换为其 n 重乘积分布。我们感兴趣的是在以下两种情形下，当 $n \to \infty$ 时错误概率 $\pi_{0|1}$ 和 $\pi_{1|0}$ 的渐近行为：

• Stein 机制：当 $\pi_{1|0}$ 被限制为至多 ϵ 时，$\pi_{0|1}$ 的最佳指数收敛速率是多少？• Chernoff 机制：当 $\pi_{1|0}$ 和 $\pi_{0|1}$ 都要求以指数速度趋于零时，它们指数之间的最优权衡是什么?

回想一下，我们处于独立同分布设置(14.14)中，并且对满足$1-\alpha = \pi_{1|0} \le \epsilon$和$\beta = \pi_{0|1} \le \exp(-nE)$的测试感兴趣，其中指数$E > 0$。这种非对称目标的动机在于，通常“漏检”（$\pi_{0|1}$）远比“虚警”（$\pi_{1|0}$）更具灾难性。例如，虚警可能仅仅导致额外的计算（当实际上只接收到噪声时尝试解码数据包），而漏检则会导致数据包完全丢失。最佳指数的正式定义如下。

定义 14.13 *ϵ-optimal exponent in Stein's regime* 是

$$V_\epsilon \triangleq \sup\{E : \exists n_0, \forall n \ge n_0, \exists P_{Z|X^n} \text{ s.t. } \alpha > 1-\epsilon, \beta < \exp(-nE)\}.$$

并且 *Stein's exponent* 被定义为 $V \triangleq \lim_{\epsilon \to 0} V_\epsilon$。

这是一个检查以下等价定义的练习

$$V_\epsilon = \liminf_{n\to\infty} \frac{1}{n} \log \frac{1}{\beta_{1-\epsilon}(P_{X^n}, Q_{X^n})}$$

其中 β_α 在 (14.3) 中定义。

以下是本节的主要结果。

定理 14.14（斯坦引理）*Consider the iid setting (14.14) where $P_{X^n} = P^n$ and $Q_{X^n} = Q^n$. Then*

$$V_\epsilon = D(P\|Q), \quad \forall \epsilon \in (0,1).$$

Consequently, $V = D(P\|Q)$.

在实践中使用这一结果的方法如下。假设要求 $\alpha \geq 0.999$，且 $\beta \leq 10^{-40}$，所需的样本量是多少？Stein引理提供了一个经验法则：$n \geq -\frac{\log 10^{-40}}{D(P\|Q)}$。

Proof. 我们首先假设 $P \ll Q$，以便 $\frac{dP}{dQ}$ 有明确定义。定义对数似然比

$$F_n = \log \frac{dP_{X^n}}{dQ_{X^n}} = \sum_{i=1}^n \log \frac{dP}{dQ}(X_i), \tag{14.15}$$

这在两种假设下都是独立同分布的和。因此，根据弱大数定律，在P下，当$n \to \infty$时，

$$\frac{1}{n} F_n = \frac{1}{n} \sum_{i=1}^n \log \frac{dP}{dQ}(X_i) \xrightarrow{\mathbb{P}} \mathbb{E}_P \left[\log \frac{dP}{dQ} \right] = D(P\|Q). \tag{14.16}$$

或者，在Q下，我们有

$$\frac{1}{n} F_n \xrightarrow{\mathbb{P}} \mathbb{E}_Q \left[\log \frac{dP}{dQ} \right] = -D(Q\|P). \tag{14.17}$$

注意，即使散度是无穷大，这两个收敛结果仍然成立。

(可达性) 我们证明对于任何 $\epsilon > 0$，有 $V_\epsilon \geq D(P\|Q) \equiv D$。首先假设 $D < \infty$。选取 $\tau = n(D-\delta)$ 对于某个小 $\delta > 0$。然后推论 14.12 得出

$$\begin{aligned} \alpha &= P(F_n > n(D-\delta)) \to 1, \text{ by (14.16)} \\ \beta &\leq e^{-n(D-\delta)} \end{aligned}$$

然后选取足够大的 n（取决于 ϵ, δ），使得 $\alpha \geq 1-\epsilon$，我们得到可实现的指数 $E = D - \delta$，$V_\epsilon \geq E$。令 $\delta \to 0$ 得到 $V_\epsilon \geq D$。最后，如果 $D = \infty$，上述论证对任意 $\tau > 0$ 成立，从而证明 $V_\epsilon = \infty$。

（逆向）我们证明对于任意 $\epsilon < 1$，$V_\epsilon \leq D$ 成立，为此只需考虑 $D < \infty$。作为热身，我们首先基于数据处理不等式应用定理14.8来展示一个弱逆向。对于任意 $(\alpha, \beta) \in \mathcal{R}(P_{X^n}, Q_{X^n})$，我们有

$$-h(\alpha) + \alpha \log \frac{1}{\beta} \leq d(\alpha\|\beta) \leq D(P_{X^n}\|Q_{X^n}) \tag{14.18}$$

对于任何可达到的指数$E < V_\epsilon$，根据定义，存在一系列测试使得$\alpha_n \geq 1-\epsilon$和$\beta_n \leq \exp(-nE)$。将此代入(14.18)并利用$h \leq \log 2$，我们得到$E \leq \frac{D(P\|Q)}{1-\epsilon} + \frac{\log 2}{n(1-\epsilon)}$。令$n \to \infty$趋于无穷，得到

$$V_\epsilon \leq \frac{D(P\|Q)}{1-\epsilon},$$

这比我们要证明的结论要弱；尽管如此，这个弱逆命题对于$\epsilon \to 0$来说是紧的，因此对于Stein指数，我们成功证明了$V = \lim_{\epsilon\to 0} V_\epsilon \geq D(P\|Q)$的期望结果。所以问题仍然存在：如果我们允许第一类错误为$\epsilon = 0.999$，第二类错误是否可能衰减得更快？接下来的强逆命题表明这是不可能的。

为此，请注意，在证明弱逆定理时，我们仅利用了(14.18)中F_n的*expectation*，为了获得更好的结果，我们需要利用*entire distribution* (CDF)。将强逆定理14.10应用于检验P_{X^n}与Q_{X^n}以及$\alpha = 1-\epsilon$和$\beta = \exp(-nE)$，我们有

$$1 - \epsilon - \gamma \exp(-nE) \leq \alpha_n - \gamma\beta_n \leq P_{X^n}[F_n > \log\gamma].$$

选择 $\gamma = \exp(n(D+\delta))$ 使得 $\delta > 0$，由WLLN (14.16)，右侧的概率趋于0，这意味着对于任意固定的 $\epsilon < 1$，我们有 $E \leq D + \delta$，从而 $V_\epsilon \leq D + \delta$。令 $\delta \to 0$ 完成证明。

最后，让我们讨论 $P \not\ll Q$ 的情况，此时 $D(P\|Q) = \infty$。根据定义，存在一个子集 A，使得 $Q(A) = 0$ 但 $P(A) > 0$。考虑这样一个检验：如果对某个 $i \in [n]$ 有 $X_i \in A$，则选择 P。显然，该检验达到 $\beta = 0$ 和 $1-\alpha = (1-P(A))^n$，而对于较大的 n，这可以变得小于任意 ϵ。这表明 $V_\epsilon = \infty$，正如所愿。 □

注14.3（非独立同分布数据）正如第12章关于数据压缩的内容，定理14.14可以扩展到平稳遍历过程。具体而言，可以证明斯坦因指数对应于*relative*熵率，即

$$V_\epsilon = \lim_{n\to\infty} \frac{1}{n} D(P_{X^n}\|Q_{X^n})$$

其中 $\{X_i\}$ 在 P 和 Q 下都是平稳且遍历的。事实上，基于 WLLN 的 (14.16) 的对应物——这是为遍历过程选择适当阈值 τ 的关键——是 Birkhoff-Khintchine 收敛定理（参见定理 12.8）。

Stein指数的理论重要性在于以下类型的蕴含：

$$\forall E \subset \mathcal{X}^n,\ P_{X^n}[E] \geq 1-\epsilon \ \Rightarrow Q_{X^n}[E] \geq \exp(-nV_\epsilon + o(n))$$

因此，了解斯坦因指数V_ϵ使我们能够证明任意集合概率的指数界；这一技巧被称为“测度变换”，将在第15章的大偏差分析中应用。

14.6 Chernoff 区域：预览

我们仍在考虑独立同分布（iid）设定（14.14），即检验

$$H_0 : X^n \sim P^n \qquad \text{versus} \qquad H_1 : X^n \sim Q^n,$$

但在切尔诺夫（Chernoff）机制中，目标是同时实现两种类型的指数级小错误概率。若存在一系列测试使得一对指数(E_0, E_1)可实现，则我们认为其是可达的。

$$\begin{aligned} 1-\alpha = \pi_{1|0} &\le \exp(-nE_0) \\ \beta = \pi_{0|1} &\le \exp(-nE_1). \end{aligned}$$

直观地说，可以使一个指数变大，代价是使另一个指数变小。因此，有趣的问题是，通过刻画(E_0, E_1)的可达区域来找到它们的最优权衡。这个问题已由[218, 61]解决，并且是第16章的主题。（关于最优(E_0, E_1)-权衡的图示，见图16.2。）

让我们解释一下我们已经了解的关于可实现的指数对区域(E_0, E_1)。首先，Stein的区域对应于这个可实现区域的角点。实际上，定理14.14告诉我们，当固定$\alpha_n = 1-\epsilon$，即$E_0 = 0$时，选择$\tau = D(P\|Q) - \delta\,(\delta \to 0)$会给出$\beta_n$的指数收敛速率，如$E_1 = D(P\|Q)$所示。类似地，交换$P$和$Q$的角色，我们可以达到点$(E_0, E_1) = (D(Q\|P), 0)$。

其次，我们在第7.3节中展示了所有测试中的最小总错误概率满足

$$\min_{(\alpha,\beta)\in\mathcal{R}(P^n,Q^n)} 1-\alpha+\beta = 1 - \mathrm{TV}(P^n, Q^n)\,.$$

随着 $n \to \infty$、P^n 和 Q^n 变得越来越可区分，并且它们的总变差以指数方式收敛到 1，其指数 E 由所有可达对上 $\max \min(E_0, E_1)$ 给出。根据界 (7.22) 以及 Hellinger 距离的张量化 (7.25)，我们得到

$$1 - \sqrt{1-\exp(-2nE_H)} \le 1 - \mathrm{TV}(P^n, Q^n) \le \exp(-nE_H)\,, \tag{14.19}$$

其中我们记

$$E_H \triangleq \log\left(1 - \frac{1}{2}H^2(P,Q)\right)\,.$$

因此，我们可以看到

$$E_H \le E \le 2E_H\,.$$

即使 P 和 Q 依赖于样本量 n，这一刻画仍然有效，这在后面 32.2.1 节研究 *composite hypothesis testing* 时将会很有用。然而，对于固定的 P 和 Q，这还不够精确。为了确定所有可实现的配对，我们需要

接下来我们将绕道讨论大偏差这一主题。要了解这种联系是如何产生的，请注意（最优）似然比检验为我们提供了两种错误概率的明确表达式：

$$1-\alpha_n = P\left[\frac{1}{n}F_n \le \tau\right], \quad \beta_n = Q\left[\frac{1}{n}F_n > \tau\right]$$

其中 F_n 是 (14.15) 中的 LLR。当 τ 落在 $(-D(Q\|P), D(P\|Q))$ 的范围内时，由于 WLLN，这两个概率都趋近于零——见 (14.16) 和 (14.17)——而我们关注的是它们的指数收敛速率。这属于大偏差理论的范畴。

15 Information projection and large deviations

在本章中，我们开发了分析假设检验（Chernoff 区域）中误差指数所需的工具。我们将首先介绍大偏差理论中的概念（对数矩生成函数（MGF）ψ_X，其凸共轭 ψ_X^*，称为速率函数，并重新审视倾斜的概念）。然后，我们展示经验均值的偏差概率由信息投影（也称为 I-投影）问题的解所支配：

$$\min_{Q:\mathbb{E}_Q[X]\geq\gamma} D(Q\|P) = \psi^*(\gamma).$$

配备了信息投影后，我们将证明Chernoff界的一个紧致版本。具体来说，对于{iid}副本 $X_1,\ldots,X_n$的X，我们展示

$$\mathbb{P}\left[\frac{1}{n}\sum_{k=1}^{n} X_k \geq \gamma\right] = \exp\left(-n\psi^*(\gamma) + o(n)\right).$$

在剩余章节中，我们将简单的信息投影问题扩展为测度凸集上的一般最小化问题，并将其与经验过程理论（Sanov定理）联系起来，同时也展示了如何在有限多个线性约束（指数族）下解决该问题。

在下一章中，我们将这些结果应用于描述可实现的 (E_0, E_1)-区域（如第14.6节所定义），以得到

$$(E_0(\theta) = \psi_P^*(\theta), \quad E_1(\theta) = \psi_P^*(\theta) - \theta),$$

其中 ψ_P^* 是 P) 下 $\log\frac{dP}{dQ}$ (的速率函数。这为我们提供了在 Chernoff 区域中两个指数之间所求权衡的完整（参数化）描述。

15.1 大偏差理论的基础

令 $X_1,\ldots,X_n$ 为从 P 中独立同分布抽取的序列，$\hat{P}_n = \frac{1}{n}\sum_{i=1}^{n}\delta_{X_i}$ 为其经验分布。大偏差理论专注于建立如下形式的精确指数估计：

$$\mathbb{P}[\hat{P}_n \in \mathcal{E}] = \exp\{-nE + o(n)\}.$$

对这类理论的完整阐述需要细致考虑 $\mathcal{E}$ 的拓扑性质，这是诸如[120]等经典论述的主题。在此，我们聚焦于一个简单的特殊情况，然而，这已足以用于在假设检验中确立切尔诺夫指数，

并且还展示了所有相关的信息论思想。我们最初的目标是展示以下结果：

定理 15.1 *Consider a random variable X whose log MGF* $\psi_X(\lambda) = \log \mathbb{E}[\exp(\lambda X)]$ *is finite for all* $\lambda \in \mathbb{R}$. *Let* $B =$ 本质上确界 X *and let* $\mathbb{E}[X] < \gamma < B$. *Then*

$$P\left[\sum_{i=1}^{n} X_i \geq n\gamma\right] = \exp\{-nE(\gamma) + o(n)\},$$

where $E(\gamma) = \sup_{\lambda \geq 0} \lambda\gamma - \psi_X(\lambda) = \psi_X^*(\gamma)$, *known as the rate function.*

对数矩生成函数（log MGF）和速率函数的概念将在后续章节中详细阐述。我们提供的证明应在阅读完本章其余部分后再次回顾。

Proof. 让我们回顾一下通常的切尔诺夫界：对于独立同分布的 X^n，对于任意 $\lambda \geq 0$，应用马尔可夫不等式可得

$$\begin{aligned}
\mathbb{P}\left[\sum_{i=1}^{n} X_i \geq n\gamma\right] &= \mathbb{P}\left[\exp\left(\lambda \sum_{i=1}^{n} X_i\right) \geq \exp(n\lambda\gamma)\right] \\
&\leq \exp(-n\lambda\gamma)\mathbb{E}\left[\exp\left(\lambda \sum_{i=1}^{n} X_i\right)\right] \\
&= \exp(-n\lambda\gamma + n\underbrace{\log \mathbb{E}\left[\exp(\lambda X)\right]}_{\psi_X(\lambda)}).
\end{aligned}$$

对 $\lambda \geq 0$ 进行优化得到以下 *non-asymptotic* 上界（集中不等式），对于任意 n 都成立：

$$\mathbb{P}\left[\sum_{i=1}^{n} X_i \geq n\gamma\right] \leq \exp\Big\{-n \sup_{\lambda \geq 0}(\lambda\gamma - \psi_X(\lambda))\Big\}. \tag{15.1}$$

这证明了定理15.1的上界部分。

为了展示下界，我们需要下面将要开发的更多工具。首先，我们将$E(\gamma)$表示为某个KL最小化问题（见定理15.9），称为信息投影。其次，我们将解决这个问题（见(15.26)），以获得$E(\gamma)$的期望值。在这个证明过程中，我们也将更深入地理解为什么朴素的Chernoff界结果是尖锐的。将会看到，不等式(15.1)执行了一个测度变换到新的分布Q，该分布被选择为在所有满足$\mathbb{E}_Q[X] \geq \gamma$的分布$Q$中，与$P$ (在KL散度)下最接近的。（这个新分布将是P的倾斜版本，记为P_λ。）

□

15.1.1 对数矩生成函数与速率函数

定义15.2 实数随机变量X的对数矩生成函数（log MGF，也称为*cumulant generating function*）为

$$\psi_X(\lambda) = \log \mathbb{E}[\exp(\lambda X)], \quad \lambda \in \mathbb{R}.$$

按照信息论中的惯例，如果 $X \sim P$，我们将记作 $\psi_P(\lambda) = \psi_X(\lambda)$。

例如，对于标准高斯分布 $Z \sim \mathcal{N}(0,1)$，我们有 $\psi_Z(\lambda) = \frac{\lambda^2}{2}$。取 $X = Z^3$ 产生一个随机变量，使得对于所有非零 λ，$\psi_X(\lambda)$ 都是无限的。

在本章的剩余部分，我们将作出以下简化假设，即所谓的Cramér条件。

假设 15.1 随机变量 X 使得对于所有 $\lambda \in \mathbb{R}$，有 $\psi_X(\lambda) < \infty$。

本章中我们讨论的大多数结果，在关于 ψ_X 的定义域具有非空内部的更弱假设下仍然成立。但如此一般性的证明极大地掩盖了主要思想的优雅性，故我们决定不予采用。我们注意到，假设15.1意味着 X 的所有矩都是有限的。

定理 15.3（ψ_X 的性质）*Under Assumption 15.1 we have:*

(a) ψ_X *is convex;*
(b) ψ_X *is continuous;*
(c) ψ_X *is infinitely differentiable and*

$$\psi_X'(\lambda) = \frac{\mathbb{E}[X\exp\{\lambda X\}]}{\mathbb{E}[\exp\{\lambda X\}]} = \exp\{-\psi_X(\lambda)\}\mathbb{E}[X\exp\{\lambda X\}].$$

In particular, $\psi_X(0) = 0, \psi_X'(0) = \mathbb{E}[X]$.
(d) If $a \le X \le b$ *a.s., then* $a \le \psi_X' \le b$;
(e) Conversely, if

$$A = \inf_{\lambda\in\mathbb{R}} \psi_X'(\lambda), \quad B = \sup_{\lambda\in\mathbb{R}} \psi_X'(\lambda),$$

then $A \le X \le B$ *a.s.;*
(f) If X is not a constant, then ψ_X *is strictly convex, and consequently,* ψ_X' *is strictly increasing.*
(g) Chernoff bound:

$$P(X \ge \gamma) \le \exp(-\lambda\gamma + \psi_X(\lambda)), \quad \lambda \ge 0. \tag{15.2}$$

注15.1 log MGF的斜率编码了X的范围。实际上，定理15.3(d)和(e)共同表明，包含P_X支撑的最小闭区间等于（闭包）

ψ_X'的范围。换句话说，A和B分别与X的本质下确界和上确界（概率意义下随机变量的最小值和最大值）重合，

$$A = \operatorname{essinf} X \triangleq \sup\{a : X \geq a \text{ a.s.}\}$$
$$B = \operatorname{esssup} X \triangleq \inf\{b : X \leq b \text{ a.s.}\}$$

参见图15.1的示例。

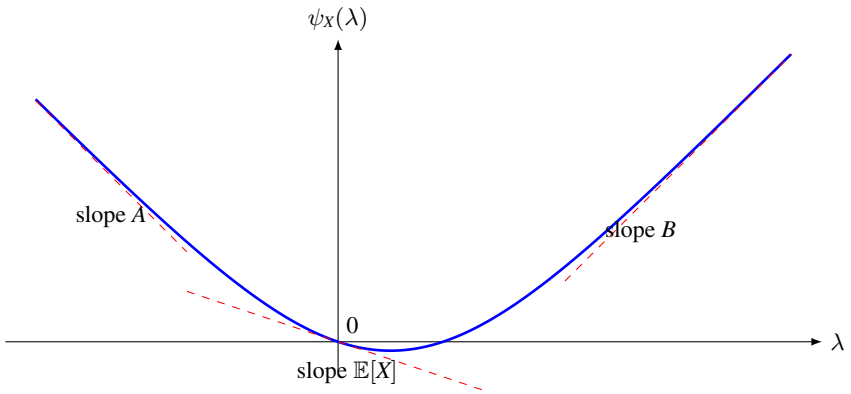


图15.1 对数矩生成函数 $\psi_X(\gamma)$ 的示例，其中 P_X 支撑在 $[A, B]$ 上。极限最大斜率和最小斜率分别为 A 和 B。在 $\gamma = 0$ 处的斜率为 $\psi_X'(0) = \mathbb{E}[X]$。此处我们绘制 $X = \pm 1$，其中 $\mathbb{P}[X = 1] = 1/3$。

Proof. 对于证明，我们假设log和exp的底数为e。注意，(g)已在(15.1)中证明。证明(e)–(f)依赖于定理15.8，可留待后续重新审视。

(a) 固定 $\theta \in (0, 1)$。回想 Hölder 不等式：

$$\mathbb{E}[|UV|] \leq \|U\|_p \|V\|_q, \quad \text{for } p, q \geq 1, \frac{1}{p} + \frac{1}{q} = 1$$

其中随机变量U的L_p-范数定义为$\|U\|_p = (\mathbb{E}|U|^p)^{1/p}$。应用于$\mathbb{E}[e^{(\theta\lambda_1 + \bar{\theta}\lambda_2)X}]$，当$p =$为1且$/\theta, q =$为1时，$/\bar{\theta}$，我们得到

$$\mathbb{E}[\exp((\lambda_1/p + \lambda_2/q)X)] \leq \|\exp(\lambda_1 X/p)\|_p \|\exp(\lambda_2 X/q)\|_q = \mathbb{E}[\exp(\lambda_1 X)]^{\theta} \mathbb{E}[\exp(\lambda_2 X)]^{\bar{\theta}},$$

即 $e^{\psi_X(\theta\lambda_1 + \bar{\theta}\lambda_2)} \leq e^{\psi_X(\lambda_1)\theta} e^{\psi_X(\lambda_2)\bar{\theta}}$。另一个证明是将 ψ_X'' 表示为某种方差；参见定理 15.8(c)。

(b) 根据我们对 X 的假设，ψ_X 的定义域是 $\mathbb{R}$。由于凸函数在其定义域内部必须是连续的，我们得出 ψ_X 在 $\mathbb{R}$ 上连续。

(c) 这里的微妙之处在于，当我们交换微分和期望的顺序时需要小心。

不失一般性，假设$\lambda \geq 0$。首先，我们证明$\mathbb{E}[|Xe^{\lambda X}|]$存在。由于

$$e^{|X|} \leq e^X + e^{-X}$$

$$|Xe^{\lambda X}| \le e^{|(\lambda+1)X|} \le e^{(\lambda+1)X} + e^{-(\lambda+1)X}$$

根据对 X 的假设，两个求和项在 X 中都是绝对可积的。因此，由控制收敛定理，$\mathbb{E}[|Xe^{\lambda X}|]$ 存在且在 λ 中连续。其次，由 $\mathbb{E}[|Xe^{\lambda X}|]$ 的存在性和连续性，$u \mapsto \mathbb{E}[|Xe^{uX}|]$ 在 $[0,\lambda]$ 上可积，我们可以如下交换积分和微分的顺序：

$$\begin{aligned} e^{\psi_X(\lambda)} = \mathbb{E}[e^{\lambda X}] = \mathbb{E}\left[1 + \int_0^\lambda Xe^{uX} du\right] &\overset{\text{Fubini}}{=} 1 + \int_0^\lambda \mathbb{E}\left[Xe^{uX}\right] du \\ \Rightarrow \psi_X'(\lambda) e^{\psi_X(\lambda)} &= \mathbb{E}[Xe^{\lambda X}] \end{aligned}$$

因此，$\psi_X'(\lambda) = e^{-\psi_X(\lambda)}\mathbb{E}[Xe^{\lambda X}]$ 存在并且在 $\mathbb{R}$ 上的 λ 中连续。
此外，通过类似地应用控制收敛定理，我们可以将其推广至$\lambda \in \mathbb{C}$，并证明$\lambda \mapsto \mathbb{E}[e^{\lambda X}]$是一个全纯函数。因此，它是无限可微的。

(d) $A \le X \le B \Rightarrow \psi_X'(\lambda) = \frac{\mathbb{E}[Xe^{\lambda X}]}{\mathbb{E}[e^{\lambda X}]} \in [A,B]$。
(e) 假设（反证法）$P_X[X > B] > 0$。那么对于某个小的 $\epsilon > 0$，有 $P_X[X > B + 2\epsilon] > 0$。但这样一来，对于 $\lambda \to \infty$ (参见下文定理 15.8.3)，有 $P_\lambda[X \le B+\epsilon] \to 0$。另一方面，我们从定理 15.8.2 知道 $\mathbb{E}_{P_\lambda}[X] = \psi_X'(\lambda) \le B$。这还不是矛盾，因为 P_λ 可能在一个非常负的值处仍然有一些非常小的质量。为了证明这不可能发生，我们首先假设 $B - \epsilon > 0$（否则只需将 X 替换为 $X - 2B$）。接下来注意

$$\begin{aligned} B \ge \mathbb{E}_{P_\lambda}[X] &= \mathbb{E}_{P_\lambda}[X1\{X < B-\epsilon\}] + \mathbb{E}_{P_\lambda}[X1\{B-\epsilon \le X \le B+\epsilon\}] + \mathbb{E}_{P_\lambda}[X1\{X > B+\epsilon\}] \\ &\ge \mathbb{E}_{P_\lambda}[X1\{X < B-\epsilon\}] + \mathbb{E}_{P_\lambda}[X1\{X > B+\epsilon\}] \\ &\ge -\mathbb{E}_{P_\lambda}[|X|1\{X < B-\epsilon\}] + (B+\epsilon)\underbrace{P_\lambda[X > B+\epsilon]}_{\to 1}. \end{aligned} \tag{15.3}$$

因此，如果我们能证明当 $\lambda \to \infty$ 时，$\mathbb{E}_{P_\lambda}[|X|1\{X < B-\epsilon\}] \to 0$，就会得到矛盾。为此，注意到 ψ_X 的凸性意味着 $\psi_X' \nearrow B$。因此，对于所有 $\lambda \ge \lambda_0$，我们有
$\psi_X'(\lambda) \ge B - \frac{\epsilon}{2}$。因此，对于所有 $\lambda \ge \lambda_0$，我们有

$$\psi_X(\lambda) \ge \psi_X(\lambda_0) + (\lambda - \lambda_0)(B - \frac{\epsilon}{2}) = c + \lambda(B - \frac{\epsilon}{2}), \tag{15.4}$$

对于某个常数c，那么，

$$\begin{aligned} \mathbb{E}_{P_\lambda}[|X|1\{X < B-\epsilon\}] &= \mathbb{E}[|X|e^{\lambda X - \psi_X(\lambda)}1\{X < B-\epsilon\}] \\ &\le \mathbb{E}[|X|e^{\lambda X - c - \lambda(B-\frac{\epsilon}{2})}1\{X < B-\epsilon\}] \\ &\le \mathbb{E}[|X|e^{\lambda(B-\epsilon) - c - \lambda(B-\frac{\epsilon}{2})}] \\ &= \mathbb{E}[|X|]e^{-\lambda\frac{\epsilon}{2} - c} \to 0 \quad \lambda \to \infty \end{aligned}$$

其中第一个不等式来自(15.4)，第二个来自$X < B - \epsilon$。因此，(15.3)中的第一项趋于0，从而得出所需的矛盾。
(f) 假设 ψ_X 不是严格凸的。由 (a) 部分可知 ψ_X 是凸的，因此 ψ_X 在某个点附近必定是“平坦”的（仿射的）。也就是说，存在某个 λ_0 的一个小邻域，使得 $\psi_X(\lambda_0 + u) =$

$\psi_X(\lambda$对于某个 $r \in \mathbb{R}$，有 $0) + ur$。那么对于零的某个小邻域内的所有 u，有 $\psi_{P_\lambda}(u) = ur$，或等价地，对于小的 u，有 $\mathbb{E}_{P_\lambda}[e^{u(X-r)}] = 1$。下面的引理15.4 推出 $P_\lambda[X = r] = 1$，但随后又有 $P[X = r] = 1$，这与假设 $X \neq$ 为常数相矛盾。

□

引理 15.4 $\mathbb{E}[e^{uS}] = 1$ *for all* $u \in (-\epsilon, \epsilon)$ *then* $S = 0$.

Proof. 在 $u = 0$ 附近展开为泰勒级数，得到 $\mathbb{E}[S] = 0$，$\mathbb{E}[S^2] = 0$。或者，我们可以扩展之前用于求导 $\psi_X(\lambda)$ 的论证，以表明函数 $z \mapsto \mathbb{E}[e^{zS}]$ 在整个复平面 [1] 上全纯。因此，由唯一性，对于所有 u，$\mathbb{E}[e^{uS}] = 1$。 □

定义 15.5（速率函数）速率函数 ψ_X^*：$\mathbb{R} \to \mathbb{R} \cup \{+\infty\}$ 由对数矩生成函数的 *Fenchel-Legendre conjugate* (凸共轭) 给出：

$$\psi_X^*(\gamma) = \sup_{\lambda \in \mathbb{R}} \lambda\gamma - \psi_X(\lambda) \tag{15.5}$$

注意，最大化 (15.5) 是一个凸优化问题，因为 ψ_X 是严格凸的，所以我们可以通过求导并找到驻点来找到最大值。事实上，ψ_X^* 正是 ψ_X 的凸共轭；参见 (7.84)。

下一个结果描述了速率函数的有用性质。关于示例，请参见图15.2。

定理 15.6 (ψ_X^* 的性质) *Assume that X is non-constant and satisfies Assump- tion 15.1.*

(a) Let $A = \operatorname{essinf} X$ *and* $B = \operatorname{esssup} X$. *Then*

$$\psi_X^*(\gamma) = \begin{cases} \lambda\gamma - \psi_X(\lambda) \text{ for } \lambda \text{ s.t. } \gamma = \psi_X'(\lambda), & A < \gamma < B \\ \log \frac{1}{P(X=\gamma)} & \gamma = A \text{ or } B \\ +\infty, & \gamma < A \text{ or } \gamma > B \end{cases}$$

(b) ψ_X^* *is strictly convex and strictly positive except* $\psi_X^*(\mathbb{E}[X]) = 0$.
(c) ψ_X^* *is decreasing when* $\gamma \in (A, \mathbb{E}[X])$, *and increasing when* $\gamma \in [\mathbb{E}[X], B)$

Proof. 根据定理15.3(d)，由于$A \le X \le B$几乎必然成立，我们得到$A \le \psi_X' \le B$。当$\gamma \in (A, B)$时，严格凹函数$\lambda \mapsto \lambda\gamma - \psi_X(\lambda)$有一个唯一的驻点，该驻点达到唯一的最大值。当$\gamma > B$ (分别$< A$)时，$\lambda \mapsto \lambda\gamma - \psi_X(\lambda)$无界增加（分别减少）。

[1] More precisely, if we only know that $\mathbb{E}[e^{\lambda S}]$ is finite for $|\lambda| \le 1$ then the function $z \mapsto \mathbb{E}[e^{zS}]$ is holomorphic in the vertical strip $\{z : |\mathrm{Re} z| < 1\}$.

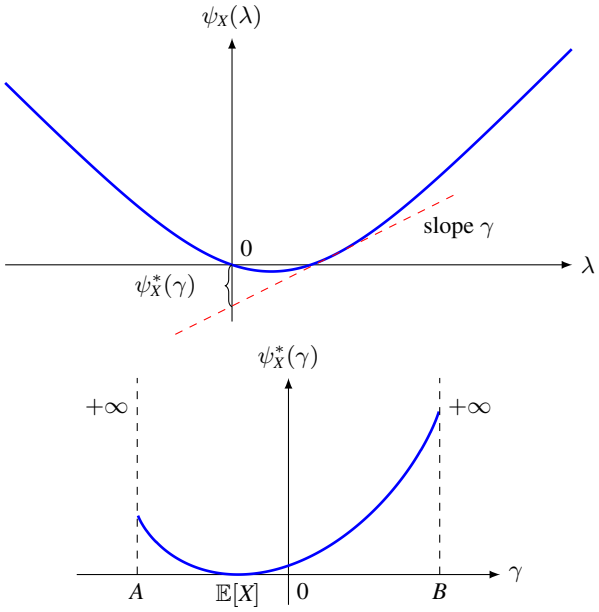


图15.2 对数矩生成函数ψ_X及其共轭(速率函数)ψ_X^*，对于X取值于$[A, B]$，继续图15.1中的例子。

当 $\gamma = B$ 时，由于几乎必然有 $X \le B$，我们有

$$\begin{aligned}\psi_X^*(B) &= \sup_{\lambda\in\mathbb{R}} \lambda B - \log(\mathbb{E}[\exp(\lambda X)]) = -\log \inf_{\lambda\in\mathbb{R}} \mathbb{E}[\exp(\lambda(X-B))] \\ &= -\log \lim_{\lambda\to\infty} \mathbb{E}[\exp(\lambda(X-B))] = -\log P(X=B),\end{aligned}$$

根据单调收敛定理。

根据定理15.3(f)，由于ψ_X是严格凸的，ψ_X和ψ_X^*的导数是互逆的。因此，ψ_X^*是严格凸的。由于$\psi_X(0) = 0$，我们得到$\psi_X^*(\gamma) \ge 0$。此外，$\psi_X^*(\mathbb{E}[X]) = 0$可由$\mathbb{E}[X] = \psi_X'(0)$推出。

□

15.1.2 倾斜分布

早在第4章，我们在Donsker-Varadhan关于散度的变分表征证明（定理4.6）中已经引入了*tilting*的概念。现在让我们正式定义它。

定义 15.7（倾斜）给定 $X \sim P$ 和 $\lambda \in \mathbb{R}$，倾斜测度 P_λ 定义为

$$P_\lambda(dx) = \frac{\exp\{\lambda x\}}{\mathbb{E}[\exp\{\lambda X\}]} P(dx) = \exp\{\lambda x - \psi_X(\lambda)\} P(dx) \tag{15.6}$$

特别地，如果P具有PDF p，那么P_λ的PDF由$p_\lambda(x) = e^{\lambda x - \psi_X(\lambda)} p(x)$给出。

由 λ 参数化的分布集合 $\{P_\lambda: \lambda \in \mathbb{R}\}$ 称为 *standard (one-parameter) exponential family*，这是统计学中的一个重要对象[77]。以下是一些例子：

• *Gaussian*: $P = \mathcal{N}(0,1)$，密度为 $p(x) = \frac{1}{\sqrt{2\pi}}\exp(-x^2/2)$。则 P_λ 的密度为 $\frac{\exp(\lambda x)}{\exp(\lambda^2/2)}\frac{1}{\sqrt{2\pi}}\exp(-x^2/2) = \frac{1}{\sqrt{2\pi}}\exp(-(x-\lambda)^2/2)$。因此 $P_\lambda = \mathcal{N}(\lambda, 1)$。• *Bernoulli*：$P = \mathrm{Ber}(\frac{1}{2})$。则 $P_\lambda = \mathrm{Ber}\left(\frac{e^\lambda}{e^\lambda+1}\right)$，当 $\lambda > 0$（或 < 0）时，在 1 上赋予更多（或更少）的质量。此外，若 $\lambda \to \infty$ 则 $P_\lambda \xrightarrow{\mathrm{d}} \delta_1$，或若 $\lambda \to -\infty$ 则 δ_0。• *Uniform*：令 P 为 $[0,1]$ 上的均匀分布。则 P_λ 也支撑在 $[0,1]$ 上，概率密度函数为 $p_\lambda(x) = \frac{\lambda\exp(\lambda x)}{e^\lambda - 1}$。因此随着 λ 增大，P_λ 越来越集中在 1 附近，且当 $\lambda \to \infty$ 时 $P_\lambda \to \delta_1$。类似地，当 $\lambda \to -\infty$ 时 $P_\lambda \to \delta_0$。

在上述示例中，我们看到当 $\lambda > 0$（相应地，< 0）时，P_λ 将 P 的均值向右（相应地，向左）移动。实际上，这是倾斜的一般性质。

定理 15.8（P_λ 的性质）*Under Assumption 15.1 we have:*

(a) Log MGF:

$$\psi_{P_\lambda}(u) = \psi_X(\lambda + u) - \psi_X(\lambda)$$

(b) Tilting trades mean for divergence:

$$\mathbb{E}_{P_\lambda}[X] = \psi_X'(\lambda) \gtrless \mathbb{E}_P[X] \text{ if } \lambda \gtrless 0. \tag{15.7}$$

$$D(P_\lambda \| P) = \psi_X^*(\psi_X'(\lambda)) = \psi_X^*(\mathbb{E}_{P_\lambda}[X]). \tag{15.8}$$

(c) Tilted variance: $\mathrm{Var}_{P_\lambda}(X) = \psi_X''(\lambda)$ 日志 *e.*

(d)

$$P(X > b) > 0 \Rightarrow \forall \epsilon > 0, P_\lambda(X \le b - \epsilon) \to 0 \text{ as } \lambda \to \infty;$$
$$P(X < a) > 0 \Rightarrow \forall \epsilon > 0, P_\lambda(X \ge a + \epsilon) \to 0 \text{ as } \lambda \to -\infty.$$

Therefore if $X_\lambda \sim P_\lambda$, *then* X_λ $\mathrm{d}\to$ 本質下确界 $X = A$ *as* $\lambda \to -\infty$ *and* $X_\lambda \xrightarrow{\mathrm{d}}$ 本質上确界 $X = B$ *as* $\lambda \to \infty$.

Proof. 再次为了证明，我们假设exp和log以*e*为底。

(a) 根据定义。(b) $\mathbb{E}_{P_\lambda}[X] = \frac{\mathbb{E}[X\exp(\lambda X)]}{\mathbb{E}[\exp(\lambda X)]} = \psi_X'(\lambda)$，在 λ 中严格递增，其中 $\psi_X'(0) = \mathbb{E}_P[X]$。$D(P_\lambda\|P) = \mathbb{E}_{P_\lambda}\log\frac{dP_\lambda}{dP} = \mathbb{E}_{P_\lambda}\log\frac{\exp(\lambda X)}{\mathbb{E}[\exp(\lambda X)]} = \lambda\mathbb{E}_{P_\lambda}[X] - \psi_X(\lambda) = \lambda\psi_X'(\lambda) - \psi_X(\lambda) = \psi_X^*(\psi_X'(\lambda))$，其中最后一个等式源自定理15.6(a)。(c) $\psi_X''(\lambda) = \frac{\mathbb{E}[X^2\exp(\lambda X)] - (\mathbb{E}[X\exp(\lambda X)])^2}{(\mathbb{E}[\exp(\lambda X)])^2} = \mathrm{Var}_{P_\lambda}(X)$。

(d)

$$\begin{aligned} P_\lambda(X \le b-\epsilon) &= \mathbb{E}_P[e^{\lambda X-\psi_X(\lambda)}1\{X \le b-\epsilon\}] \\ &\le \mathbb{E}_P[e^{\lambda(b-\epsilon)-\psi_X(\lambda)}1\{X \le b-\epsilon\}] \\ &\le e^{-\lambda\epsilon}e^{\lambda b-\psi_X(\lambda)} \\ &\le \frac{e^{-\lambda\epsilon}}{P[X>b]} \to 0 \text{ as } \lambda \to \infty \end{aligned}$$

其中最后一个不等式是由通常的切尔诺夫界（定理15.3(g)）得出的：$P[X > b] \le \exp(-\lambda b + \psi_X(\lambda))$。

□

15.2 大偏差指数与KL散度

Large deviations 问题通过陈述一系列分布的尾部概率来处理罕见事件。在这里，我们关注以下特殊情况：当γ超过均值时，独立同分布X_k的$P\left[\frac{1}{n}\sum_{k=1}^n X_k \ge \gamma\right]$衰减速度。

在(15.1)中，我们使用了切尔诺夫界来通过对数矩生成函数获得指数的上界。这里我们采用不同的方法，将指数表示为涉及KL散度的凸优化问题的公式。在随后的章节（信息投影）中。稍后在15.4节，我们计算了信息投影的值之后，将重新审视切尔诺夫界。

定理 15.9 *Let $X_1, X_2, \ldots \overset{i.i.d.}{\sim} P$. Then for any $\gamma \in \mathbb{R}$,*

$$\lim_{n\to\infty}\frac{1}{n}\log\frac{1}{P\left[\frac{1}{n}\sum_{k=1}^n X_k > \gamma\right]} = \inf_{Q:\ \mathbb{E}_Q[X]>\gamma} D(Q\|P) \tag{15.9}$$

$$\lim_{n\to\infty}\frac{1}{n}\log\frac{1}{P\left[\frac{1}{n}\sum_{k=1}^n X_k \ge \gamma\right]} = \inf_{Q:\ \mathbb{E}_Q[X]\ge\gamma} D(Q\|P) \tag{15.10}$$

Furthermore, for every n we have the firm upper bound

$$P\left[\frac{1}{n}\sum_{k=1}^n X_k \ge \gamma\right] \le \exp\left\{-n\cdot\inf_{Q:\ \mathbb{E}_Q[X]\ge\gamma} D(Q\|P)\right\} \tag{15.11}$$

and similarly for $>$ in place of $\ge$.

注 15.2（次可加性） 可以从基本原理出发论证极限 (15.9) 和 (15.10) 存在，而无需计算它们的值。事实上，注意序列 $p_n \triangleq \log\frac{1}{P}\left[\frac{1}{n}\sum_{k=1}^n X_k \ge \gamma\right]$ 满足 $p_{n+m} \ge p_n p_m$，因此 $\log\frac{1}{p_n}$ 是次可加的。因此，根据 Fekete 引理，$\lim_{n\to\infty}\frac{1}{n}\log\frac{1}{p_n} = \inf_n \log\frac{1}{p_n}$。

Proof. 首先注意，如果事件的概率为零，则两边都等于无穷大。事实上，如果 $P\left[\frac{1}{n}\sum_{k=1}^{n} X_k > \gamma\right] = 0$，则 $P[X > \gamma] = 0$。于是 $\mathbb{E}_Q[X] > \gamma \Rightarrow Q[X > \gamma] > 0 \Rightarrow Q \not\ll P \Rightarrow D(Q\|P) = \infty$，因此 (15.9) 平凡成立。对于 (15.10) 的情况类似。

在后续内容中，我们假设这两个概率均非零。我们首先证明(15.9)。设定$P[E_n] = P\left[\frac{1}{n}\sum_{k=1}^{n} X_k > \gamma\right]$。

下界 $P[E_n]$：固定一个 Q 使得 $\mathbb{E}_Q[X] > \gamma$。令 X^n 独立同分布。则由弱大数定律，

$$Q[E_n] = Q\left[\sum_{k=1}^{n} X_k > n\gamma\right] = 1 - o(1).$$

现在数据处理不等式（推论2.19）给出

$$d(Q[E_n]\|P[E_n]) \le D(Q_{X^n}\|P_{X^n}) = nD(Q\|P)$$

而二元散度的下界为

$$d(Q[E_n]\|P[E_n]) \ge -h(Q[E_n]) + Q[E_n]\log\frac{1}{P[E_n]}$$

结合 $d(Q[E_n]\|P[E_n])$ 上的两个界，可得

$$P[E_n] \ge \exp\left(\frac{-nD(Q\|P) - \log 2}{Q[E_n]}\right) \tag{15.12}$$

对 Q 进行优化以获得最佳边界：

$$\limsup_{n\to\infty}\frac{1}{n}\log\frac{1}{P[E_n]} \le \inf_{Q:\mathbb{E}_Q[X]>\gamma} D(Q\|P).$$

$P[E_n]$的上界：关键观察是，给定任意X和任意事件E，$P_X(E) > 0$可以通过条件分布与无条件分布之间的散度表示为：$\log\frac{1}{P_X(E)} = D(P_{X|X\in E}\|P_X)$。定义$\tilde{P}_{X^n} = P_{X^n|\sum X_i > n\gamma}$，在此条件下$\sum X_i > n\gamma$几乎必然成立。于是

$$\log\frac{1}{P[E_n]} = D(\tilde{P}_{X^n}\|P_{X^n}) \ge \inf_{Q_{X^n}:\mathbb{E}_Q[\sum X_i]>n\gamma} D(Q_{X^n}\|P_{X^n}) \tag{15.13}$$

我们现在展示最后一个问题“单字母化”，即简化 $n = 1$。注意，这是一个更一般现象的特例——参见练习III.12。考虑以下两个步骤：

$$\begin{aligned} D(Q_{X^n}\|P_{X^n}) &\ge \sum_{j=1}^{n} D(Q_{X_j}\|P) \\ &\ge nD(\bar{Q}\|P)\,, \qquad \bar{Q} \triangleq \frac{1}{n}\sum_{j=1}^{n} Q_{X_j}\,, \end{aligned} \tag{15.14}$$

其中第一步来自定理2.16中的(2.27)，在注意到$P_{X^n} = P^n$之后，第二步是基于散度的凸性(定理5.1)。由此论证，我们得出结论：

$$\inf_{Q_{X^n}:\mathbb{E}_Q[\sum X_i]>n\gamma} D(Q_{X^n}\|P_{X^n}) = n\cdot\inf_{Q:\mathbb{E}_Q[X]>\gamma} D(Q\|P) \tag{15.15}$$

$$\inf_{Q_{X^n}:\mathbb{E}_Q[\sum X_i]\geq n\gamma} D(Q_{X^n}\|P_{X^n}) = n\cdot \inf_{Q:\mathbb{E}_Q[X]\geq\gamma} D(Q\|P) \tag{15.16}$$

特别地，(15.13) 和 (15.15) 蕴含了 (15.9) 中所要求的下界。

接下来我们证明(15.10)。首先，注意到下界论证(15.13)同样适用，因此对于每个n，我们有

$$\frac{1}{n}\log\frac{1}{P\left[\frac{1}{n}\sum_{k=1}^n X_k\geq\gamma\right]} \geq \inf_{Q:\ \mathbb{E}_Q[X]\geq\gamma} D(Q\|P)\,.$$

为了得到匹配的上界，我们考虑两种情况：

- 情形一：$P[X>\gamma]=0$。若 $P[X\geq\gamma]=0$，则 (15.10) 式两端均为 $+\infty$。若 $P[X=\gamma]>0$，则 $P[\sum X_k\geq n\gamma]=P[X_1=\ldots=X_n=\gamma]=P[X=\gamma]^n$。对于右端，由于 $D(Q\|P)<\infty \implies Q\ll P \implies Q(X\leq\gamma)=1$，$\mathbb{E}_Q[X]\geq\gamma$ 的唯一可能是 $Q(X=\gamma)=1$，即 $Q=\delta_\gamma$。于是 $\inf_{\mathbb{E}_Q[X]\geq\gamma} D(Q\|P) = \log\frac{1}{P(X=\gamma)}$。
- 情况二：$P[X>\gamma]>0$。由于 $\mathbb{P}[\sum X_k\geq\gamma]\geq\mathbb{P}[\sum X_k>\gamma]$ 由(15.9)可知

$$\limsup_{n\to\infty}\frac{1}{n}\log\frac{1}{P\left[\frac{1}{n}\sum_{k=1}^n X_k\geq\gamma\right]} \leq \inf_{Q:\ \mathbb{E}_Q[X]>\gamma} D(Q\|P)\,.$$

我们接下来证明，在这种情况下

$$\inf_{Q:\ \mathbb{E}_Q[X]>\gamma} D(Q\|P) = \inf_{Q:\ \mathbb{E}_Q[X]\geq\gamma} D(Q\|P) \tag{15.17}$$

实际上，令 $\tilde{P}=P_{X|X>\gamma}$，由于 $P[X>\gamma]>0$，这个定义是合理的。对于任何满足 $\mathbb{E}_Q[X]\geq\gamma$ 的 Q，集合 $\tilde{Q}=\bar{\epsilon}Q+\epsilon\tilde{P}$ 满足 $\mathbb{E}_{\tilde{Q}}[X]>\gamma$。那么由凸性，$D(\tilde{Q}\|P)\leq\bar{\epsilon}D(Q\|P)+\epsilon D(\tilde{P}\|P)=\bar{\epsilon}D(Q\|P)+\epsilon\log\frac{1}{P[X>\gamma]}$。令 $\epsilon\to 0$，我们完成了(15.17)的证明。

□

注15.3 注意，上界（15.11）对于独立的 *non-identically* 分布的 X_i 也成立。实际上，我们只需将步骤（15.14）替换为 $D(Q_{X^n}\|P_{X^n}) \geq \sum_{i=1}^n D(Q_{X_i}\|P_{X_i}) \geq nD(\bar{Q}\|\bar{P})$，其中 $\bar{P}=\frac{1}{n}\sum_{i=1}^n P_{X_i}$。这样得到的一个界（15.11），在右侧以 $\bar{P}$ 替换了 P。

例 15.1（泊松-二项尾部）考虑 X，它是 n 个独立伯努利随机变量之和，因此 $\mathbb{E}[X]=np$。X 的分布被称为 *Poisson-Binomial* [330, 413]，其中包括 $\mathrm{Bin}(n,p)$ 作为特例。应用定理 15.9（或注 15.3），我们得到关于 X 的以下尾部界：

$$\mathbb{P}[X\geq k]\leq\exp\{-nd(k/n\|p)\},\quad \frac{k}{n}>p \tag{15.18}$$

$$\mathbb{P}[X\leq k]\leq\exp\{-nd(k/n\|p)\},\quad \frac{k}{n}<p \tag{15.19}$$

其中对于 (15.18)，我们利用了 $\min_{Q:\mathbb{E}_Q[X]\geq k/n} D(Q\|\mathrm{Ber}(p)) = \min_{q\geq k/n} d(q\|p) = d(\frac{k}{n}\|p)$ 这一事实，类似地对于 (15.19)。反过来，这些界限可用于推导出各种著名的估计：

- 与均值的乘法偏差（Bennett不等式）：我们有

$$\mathbb{P}[X \geq u\,\mathbb{E}[X]] \leq \exp\{-\mathbb{E}[X]f(u)\} \qquad \forall u > 1\,,$$
$$\mathbb{P}[X \leq u\,\mathbb{E}[X]] \leq \exp\{-\mathbb{E}[X]f(u)\} \qquad \forall 0 \leq u < 1\,,$$

其中 $f(u) \triangleq u\log u - (u-1)\log e \geq 0$。这些结论由(15.18)-(15.19)通过以下有用的估计得出：

$$d(up\|p) \geq pf(u) \qquad \forall p \in [0,1], u \in [0,1/p] \tag{15.20}$$

事实上，考虑基本不等式

$$x\log\frac{x}{y} \geq (x-y)\log e$$

对于所有 $x, y \in [0,1]$（因为左侧和右侧之间的差异在 $y = x$ 处对 y 取最小）。使用 $x = 1-up$ 和 $y = 1-p$ 可建立（15.20）。

- 伯恩斯坦不等式：

$$\mathbb{P}[X > np + t] \leq e^{-\frac{t^2}{2(t+np)}} \qquad \forall t > 0\,.$$

这由先前对 $u > 1$ 的界限得出，通过界定 $\frac{f(u)}{\log e} = \int_1^u \frac{u-x}{x}dx \geq \frac{1}{u}\int_1^u (u-x)dx = \frac{(u-1)^2}{2u}$。

- 冈本不等式：对于所有 $0 < p < 1$ 和 $t > 0$,

$$\mathbb{P}[\sqrt{X} - \sqrt{np} \geq t] \leq e^{-t^2}, \tag{15.21}$$
$$\mathbb{P}[\sqrt{X} - \sqrt{np} \leq -t] \leq e^{-t^2}. \tag{15.22}$$

这些直接由(7.33)中KL散度与Hellinger距离之间的不等式得出。实际上，我们得到 $d(x\|p) \geq H^2(\mathrm{Ber}(x), \mathrm{Ber}(p)) \geq (\sqrt{x} - \sqrt{p})^2$。将 $x = \frac{(\sqrt{np}+t)^2}{n}$ 代入(15.18)-(15.19)即可得到结果。我们注意到，[316，定理3]展示了(15.21)中 e^{-2t^2} 的一个更强界。

值得注意的是，(15.21)和(15.22)中的界限并不依赖于n或p。这是由于二项分布的平方根变换具有方差稳定效应：对于所有n, p，$\mathrm{Var}(\sqrt{X})$至多是一个常数。此外，$\sqrt{X} - \sqrt{np} = \frac{X-np}{\sqrt{X}+\sqrt{np}}$具有自归一化形式：分母与分子的标准差相当。关于自归一化和的更多内容，参见[69, 问题12.2]。

15.3 信息投影

定理15.9的结果促使我们研究以下一般信息投影问题：设$\mathcal{E}$为某抽象空间Ω上的凸分布集，那么对于Ω上的分布P，我们希望

$$\inf_{Q\in\mathcal{E}} D(Q\|P)$$

将最小化分布 Q 记作 Q^*。接下来的结果表明，直观上 P 与最优 Q^* 之间的“直线”与 $\mathcal{E}$ (参见图15.3)“正交”。

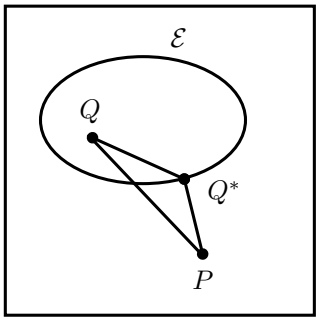


图15.3 信息投影与勾股定理的图解。

定理 15.10 *Let $\mathcal{E}$ be a convex set of distributions. If there exists $Q^* \in \mathcal{E}$ such that $D(Q^*\|P) = \min_{Q\in\mathcal{E}} D(Q\|P) < \infty$, then $\forall Q \in \mathcal{E}$*

$$D(Q\|P) \geq D(Q\|Q^*) + D(Q^*\|P)$$

Proof. 如果 $D(Q\|P) = \infty$，则无需证明。因此我们假设 $D(Q\|P) < \infty$，这也意味着 $D(Q^*\|P) < \infty$。对于 $\lambda \in [0,1]$，构成凸组合 $Q^{(\lambda)} = \bar{\lambda}Q^* + \lambda Q \in \mathcal{E}$。由于 Q^* 是 $D(Q\|P)$ 的最小化子，则

$$0 \leq \frac{d}{d\lambda}\bigg|_{\lambda=0} D(Q^{(\lambda)}\|P) = D(Q\|P) - D(Q\|Q^*) - D(Q^*\|P)$$

严格的分析需要一个交换导数和积分的论证（通过控制收敛定理），这与命题2.20的证明类似。详情见[114，定理2.2]。

□

注 15.4 如果我们在欧几里得环境中审视上图，由P、Q^*和Q (形成的“三角形”对于凸集中的Q^*, Q，集合外的P)总是钝角，仅当凸集具有“平坦面”时才是直角三角形。在这个意义上，散度类似于欧几里得距离的平方，上述定理有时被称为“毕达哥拉斯”定理。

我们接下来关注的相关集合 $\mathcal{E}$ 是由分布 Q 组成的“半空间” $\mathcal{E} = \{Q : \mathbb{E}_Q[X] \geq \gamma\}$，其中 $X : \Omega \to \mathbb{R}$ 是某个固定函数（随机变量）。这通过与定理15.9中的大偏差指数的关系得到证明。首先，我们显式地解决这个 I 投影问题。

定理 15.11 *Given a distribution P on Ω and X： $\Omega \to \mathbb{R}$ suppose Assumption 15.1 holds. We denote*

$$A = \inf \psi_X' = \operatorname{essinf} X \triangleq \sup\{a : X \geq a \ P\text{-a.s.}\} \tag{15.23}$$

$$B = \sup \psi_X' = \operatorname{esssup} X \triangleq \inf\{b : X \le b \ P\text{-a.s.}\} \tag{15.24}$$

1 The information projection problem over $\mathcal{E} = \{Q \ : \ \mathbb{E}_Q[X] \ge \gamma\}$ has solution

$$\min_{Q \,:\, \mathbb{E}_Q[X] \ge \gamma} D(Q\|P) = \begin{cases} 0 & \gamma < \mathbb{E}_P[X] \\ \psi_P^*(\gamma) & \mathbb{E}_P[X] \le \gamma < B \\ \log \frac{1}{P(X=B)} & \gamma = B \\ +\infty & \gamma > B \end{cases} \tag{15.25}$$

$$= \psi_P^*(\gamma) 1\{\gamma \ge \mathbb{E}_P[X]\} \tag{15.26}$$

2 Whenever the minimum is finite, the minimizing distribution is unique and equal to the tilting of P along X, namely[2]

$$dP_\lambda = \exp\{\lambda X - \psi(\lambda)\} \cdot dP \tag{15.27}$$

3 For all $\gamma \in [\mathbb{E}_P[X], B)$ we have

$$\min_{\mathbb{E}_Q[X] \ge \gamma} D(Q\|P) = \inf_{\mathbb{E}_Q[X] > \gamma} D(Q\|P) = \min_{\mathbb{E}_Q[X] = \gamma} D(Q\|P) \,.$$

注 15.5 定理 15.9 和定理 15.11 均针对右尾情况，即样本均值超过总体均值。对于左尾，只需将这些结果应用于 $-X_i$，即可得到 $\gamma < \mathbb{E}[X]$,

$$\lim_{n\to\infty} \frac{1}{n} \log \frac{1}{P\left[\frac{1}{n}\sum_{k=1}^n X_k < \gamma\right]} = \inf_{Q \,:\, \mathbb{E}_Q[X] < \gamma} D(Q\|P) = \psi_X^*(\gamma).$$

换句话说，大偏差指数仍由速率函数(15.5)给出，只是最优倾斜参数λ为负。

Proof. 我们首先证明（15.25）。

• 第一种情况：取 $Q = P$。• 第四种情况：若 $\mathbb{E}_Q[X] > B$，则对某个 $\epsilon > 0$ 有 $Q[X \ge B + \epsilon] > 0$，但根据定理15.3(e)，由于 $P(X \le B) = 1$，有 $P[X \ge B + \epsilon] = 0$。因此 $Q \not\ll P \implies D(Q\|P) = \infty$。• 第三种情况：若 $P(X = B) = 0$，则在 P 下几乎必然 $X < B$，且对于任何满足 $\mathbb{E}_Q[X] \ge B$ 的 Q 有 $Q \not\ll P$。此时最小值为 ∞。现在假设 $P(X = B) > 0$。由于 $D(Q\|P) < \infty \implies Q \ll P \implies Q(X \le B) = 1$。因此 $\mathbb{E}_Q[X] \ge B$ 的唯一可能是 $Q(X = B) = 1$，即 $Q = \delta_B$。于是 $D(Q\|P) = \log \frac{1}{P(X=B)}$。• 第二种情况：固定 $\mathbb{E}_P[X] \le \gamma < B$，并找到唯一的 λ 使得 $\psi_X'(\lambda) = \gamma = \mathbb{E}_{P_\lambda}[X]$，其中 $dP_\lambda = \exp(\lambda X - \psi_X(\lambda))dP$。这对应于将 P 向右倾斜到足够远以增加其

[2] Note that unlike the setting of Theorems 15.1 and 15.9 here P and P_λ are measures on an abstract space Ω, not necessarily on the real line.

从 $\mathbb{E}_P X$ 到 γ 的均值，特别是 $\lambda \geq 0$。此外，$\psi_X^*(\gamma) = \lambda\gamma - \psi_X(\lambda)$。取任意满足 $\mathbb{E}_Q[X] \geq \gamma$ 的 Q，则

$$\begin{aligned} D(Q\|P) &= \mathbb{E}_Q\left[\log \frac{dQdP_\lambda}{dPdP_\lambda}\right] \qquad (15.28)\\ &= D(Q\|P_\lambda) + \mathbb{E}_Q[\log \frac{dP_\lambda}{dP}] \\ &= D(Q\|P_\lambda) + \mathbb{E}_Q[\lambda X - \psi_X(\lambda)] \\ &\geq D(Q\|P_\lambda) + \lambda\gamma - \psi_X(\lambda) \\ &= D(Q\|P_\lambda) + \psi_X^*(\gamma) \\ &\geq \psi_X^*(\gamma), \qquad (15.29) \end{aligned}$$

其中最后一个不等式取等号当且仅当 $Q = P_\lambda$。此外，这表明极小化者是唯一的，从而证明了第二个论断。注意，即使在 $\gamma = B$ (假设 $P(X = B) > 0$) 的极端情况下，极小化者也是一个点质量 $Q = \delta_B$，它同样是一个倾斜测度（P_∞），因为当 $\lambda \to \infty$ 时 $P_\lambda \to \delta_B$，参见定理 15.8(d)。

根据定理15.6，可得表达式(15.26)所给出的解的另一种形式。
对于第三个断言，注意到$\gamma < \mathbb{E}_P[X]$无需证明，而对于$\gamma \geq \mathbb{E}_P[X]$我们刚刚展示了

$$\psi_X^*(\gamma) = \min_{Q:\mathbb{E}_Q[X]\geq\gamma} D(Q\|P)$$

而由下一条推论我们有

$$\inf_{Q:\mathbb{E}_Q[X]>\gamma} D(Q\|P) = \inf_{\gamma'>\gamma} \psi_X^*(\gamma')\,.$$

最后一步是注意到 ψ_X^* 根据定理15.6是递增且连续的，因此右侧的下确界等于 $\psi_X^*(\gamma)$。对于 $\min_{Q:\mathbb{E}_Q[X]=\gamma}$ 的情况处理方式类似。 □

推论 15.12 *For any Q with $\mathbb{E}_Q[X] \in (A, B)$, there exists a* 唯一 *$\lambda \in \mathbb{R}$ such that the tilted distribution P_λ satisfies*

$$\mathbb{E}_{P_\lambda}[X] = \mathbb{E}_Q[X]$$
$$D(P_\lambda\|P) \leq D(Q\|P)$$

and furthermore the gap in the last inequality equals $D(Q\|P_\lambda) = D(Q\|P) - D(P_\lambda\|P)$.

Proof. 按照定理15.11证明中的步骤进行，找到唯一的λ，使得$\mathbb{E}_{P_\lambda}[X] = \psi_X'(\lambda) = \mathbb{E}_Q[X]$。然后$D(P_\lambda\|P) = \psi_X^*(\mathbb{E}_Q[X]) = \lambda\mathbb{E}_Q[X] - \psi_X(\lambda)$。重复步骤(15.28)-(15.29)，得到 $D(Q\|P) = D(Q\|P_\lambda) + D(P_\lambda\|P)$。 □

对于任意 Q，前面的结果允许我们找到一个倾斜测度 P_λ，其均值与 Q 相同，但与 P 的散度距离更小（或相等）。我们将看到，在多个线性约束下也可以做到这一点（第15.6* 节）。

15.4 *I*-投影与KL测地线

以下图15.4描述了信息投影的许多性质，其中我们固定某个基线测度P。然后

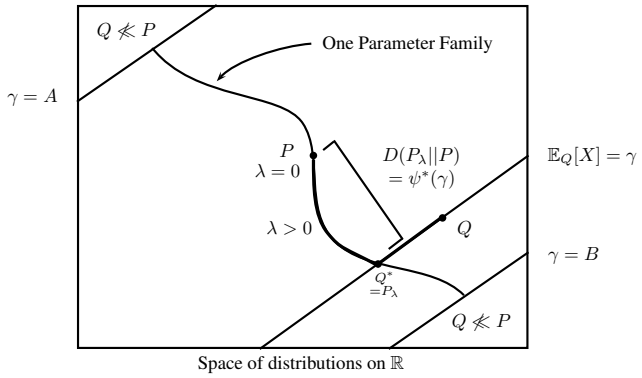


图 图15.4 信息投影、倾斜与速率函 函数。

• 每个集合 $\{Q : \mathbb{E}_Q[X] = \gamma\}$ 是 $\mathcal{P}(\mathbb{R})$ 的一个切片，即在 $\mathbb{R}$ 上的概率分布空间。当 γ 从 $-\infty$ 变化到 $+\infty$ 时，这些切片的并集填满了具有有限一阶矩的整个分布空间。• 当 $\gamma < A$ 或 $\gamma > B$ 时，切片内的任何分布 Q 都是 $Q \not\ll P$。• 当 γ 在 A 和 B 之间变化时，切片填满了所有 $\{Q : Q \ll P\}$ 的空间。根据推论15.12，在每个切片内部有一个特殊分布 P_λ，呈倾斜形式(15.6)，它最小化了到 P 的散度 $D(Q\|P)$。• 这些 P_λ 的集合在分布空间中描绘出一条曲线。从 P 到 P_λ 的“测地线”距离由 $\psi^*(\gamma) = D(P_\lambda\|P)$ 度量。这组分布是定义15.7中的一参数指数族。

这里的关键观察是，单参数族 $\{P_\lambda : \lambda \in \mathbb{R}\}$ 的曲线与每个 γ-切片 $\mathcal{E} = \{Q : \mathbb{E}_Q[X] = \gamma\}$ 在最小化点 $Q^* \in \mathcal{E}$ 处“正交”相交，并且从 P 到 Q^* 的距离由 $\psi^*(\lambda)$ 给出。要看到这一点，注意将定理 15.10 应用于凸集 $\mathcal{E}$ 可得到 $D(Q\|P) \geq D(Q\|Q^*) + D(Q^*\|P)$。现在凭借推论 15.12，我们实际上对某个倾斜测度有 *equality* $D(Q\|P) = D(Q\|Q^*) + D(Q^*\|P)$ 和 $Q^* = P_\lambda$。

让我们为称曲线 $\{P_\mu, \mu \in [0, \lambda]\}$ 为连接 $P = P_0$ 到 P_λ 的测地线给出一个直观（非严格）的论证。假设存在另一条曲线 $\{Q_\mu\}$ 连接 P 到 P_λ 并最小化 KL 距离。那么期望 $\mathbb{E}_{Q_\mu}[X]$ 应当从 $\mathbb{E}_P[X]$ 连续变化到 $\mathbb{E}_{P_\lambda}[X]$。现在取期望 $\mathbb{E}_{Q_\mu}[X]$ 的任意中间值 γ'。我们知道在切片 $\{Q : \mathbb{E}_Q[X] = \gamma'\}$ 上，最接近 P 的元素是某个 $\mu' \in [0, \lambda]$ 对应的 $P_{\mu'}$。因此，我们可以通过连接 P 到 $P_{\mu'}$ 而不是 Q_μ 来缩短距离。

我们上面的处理是针对 $\mathbb{R}$ 上的分布。我们如何在抽象可测空间 $\mathcal{X}$ 上找到两个任意分布 $\tilde{P}$ 和 $\tilde{Q}$ 之间的测地线？为了找到答案，我们注意到上述 P 和 P_λ 之间测地线的“内在”定义可以如下给出：

$$\frac{dP_\mu}{dP} = \frac{1}{Z(\mu)}\left(\frac{dP_\lambda}{dP}\right)^{\frac{\mu}{\lambda}},$$

其中 $Z(\mu) = \exp\{\psi(\mu)\}$ 是归一化常数。相应地，我们将 $\tilde{P}$ 与 $\tilde{Q}$ 之间的测地线定义为由下式给出的参数族 $\{\tilde{P}_\mu, \mu \in [0,1]\}$

$$\frac{d\tilde{P}_\mu}{d\tilde{P}} \triangleq \frac{1}{\tilde{Z}(\mu)}\left(\frac{d\tilde{Q}}{d\tilde{P}}\right)^{\mu}, \tag{15.30}$$

其中归一化常数 $\tilde{Z}(\mu) = \exp\{(\mu-1)D_\mu(\tilde{Q}\|\tilde{P})\}$ 根据Rényi散度给出。另见练习III.25。

Cencov在[85, Theorem 12.3]中，针对有限底层空间$\mathcal{X}$的情形，正式证明了(15.30)作为微分几何意义上的真实测地线。他的论证如下：为了讨论测地线，需要为空间$\mathcal{P}([k])$配备一个联络（或平行移动映射）。自然要求该联络关于某些映射$\mathcal{P}([k]) \to \mathcal{P}([k'])$是等变的（或可交换的）。Cencov列举了（a）元素置换（$k = k'$）；（b）通过将$[k]$的原子按指定比例分裂为$[k']$的多个原子，使得$k < k'$，从而将分布$P \in \mathcal{P}([k])$嵌入到更大的空间中；以及（c）对事件（$k > k'$）进行条件化。结果表明，存在满足（a）-（b）的单参数联络族，其中包括对应于Fisher-Rao度量(2.35)的黎曼（Levi-Civitta）联络。然而，满足所有（a）-（c）的联络是唯一的。它不同于Fisher-Rao联络，其测地线恰好由(15.30)给出。在此度量下的测地完备子流形正是指数族（Section 15.6*）。关于这一激动人心的领域，更多内容可参见Cencov [85]和Amari [17]。

15.5 萨诺夫定理

WLLN的一个推论是，从分布P中独立同分布抽取的n个观测值的经验分布$\hat{P}$弱收敛于P本身。以下由Sanov [370]提出的定理量化了这种收敛的大偏差行为。

定理 15.13（Sanov 定理）*Given $X_1, \ldots, X_n \overset{i.i.d.}{\sim} P$ on $\mathcal{X}$, denote the empirical distribution by $\hat{P} = \frac{1}{n}\sum_{j=1}^n \delta_{X_j}$. Let $\mathcal{E}$ be a convex set of distributions. Then under regularity conditions on $\mathcal{E}$ and P,*

$$\mathbb{P}[\hat{P} \in \mathcal{E}] = \exp\left\{-n \min_{Q\in\mathcal{E}} D(Q\|P) + o(n)\right\}.$$

上述定理中正则性条件的示例包括：(a) $\mathcal{X}$ 是有限的，P 完全支撑在 $\mathcal{X}$ 上，并且 $\mathcal{E}$ 是闭集且内部非空：完全证明见练习 III.23，其内容为

情形；(b) $\mathcal{X}$ 是一个波兰空间，且 $\inf_{Q\in\mathrm{int}(\mathcal{E})} D(Q\|P) = \inf_{Q\in\mathrm{cl}(\mathcal{E})} D(Q\|P)$：这是 [120，定理6.2.10] 的内容。参考文献 [120] 中包含了关于 Sanov 定理各种其他版本及其推广至无限维设置的全部细节。

15.6* 多重约束下的信息投影

到目前为止，我们已考虑了单个不等式 $\mathbb{E}[X] \geq \gamma$ 的例子。然而，整个理论可以扩展以容纳多个约束。设 P 为某空间 $\mathcal{X}$ 上的固定分布，并设 $\phi_1, \ldots, \phi_d : \mathcal{X} \to \mathbb{R}$ 为任意函数，我们将它们堆叠成一个向量值函数 $\phi : \mathcal{X} \to \mathbb{R}^d$。在本节中，我们讨论以下 I-投影问题的解，该问题被称为超平面上的 I-投影：

$$F(\gamma) \triangleq \inf\{D(Q\|P) : \mathbb{E}_Q[\phi(X)] = \gamma\}, \qquad \gamma \in \mathbb{R}^d. \tag{15.31}$$

这个问题出现在统计物理、吉布斯变分原理、指数族以及许多其他领域。注意，取P为均匀分布对应于最大熵问题。

在 $d = 1$ 的情况下，我们已经看到，只要最小化值是有限的，解 Q^* 就可以在 *tilted* 测度 P 的单参数族中寻找，参见 (15.27)。对于这个更一般的 $d > 1$ 的情况，我们将倾斜测度定义为

$$P_\lambda(dx) \triangleq \exp\{\lambda^\top \phi(x) - \psi(\lambda)\} P(dx), \quad \lambda \in \mathbb{R}^d$$

其中，关于 ϕ) 的 P (的多维对数矩生成函数定义为

$$\psi(\lambda) \triangleq \mathbb{E}_{X\sim P}[\exp\{\lambda^\top \phi(X)\}]. \tag{15.32}$$

为了讨论(15.31)的解，我们首先做出一个类似于推论15.12的简单观察：

命题 15.14 *If there exists λ such that $\psi(\lambda) < \infty$ and $\mathbb{E}_{X\sim P_\lambda}[\phi(X)] = \gamma$, then the unique minimizer of* (15.31) *is P_λ and for any Q with $\mathbb{E}_Q[\phi(X)] = \gamma$ we have*

$$D(Q\|P) = D(Q\|P_\lambda) + D(P_\lambda\|P). \tag{15.33}$$

Proof. 由于 $\log \frac{dP_\lambda}{dP} = \lambda^\top \phi(x) - \psi(\lambda)$ 处处有限，我们有 $D(P_\lambda\|P) = \lambda^\top \gamma - \psi(\lambda) < \infty$，因此 (15.31) 的解是有限的。$P_\lambda$ 是唯一极小值点这一事实可由我们接下来要证明的恒等式 (15.33) 推出。取命题中的 Q，并假设 $D(Q\|P)$ 或 $D(Q\|P_\lambda)$ 有限（否则无需证明）。由于 $P_\lambda \ll P$，这意味着 $Q \ll P$，因此让我们用 $f_Q = \frac{dQ}{dP}$ 表示。由 (2.11) 我们看到

$$\begin{aligned} D(Q\|P) - D(Q\|P_\lambda) &= \mathbb{E}_Q\left[\mathrm{Log}\frac{\exp\{\lambda^\top\phi(X) - \psi(\lambda)\}}{1}\right] = \mathbb{E}_Q\left[\log\exp\{\lambda^\top\phi(X) - \psi(\lambda)\}\right] \\ &= \lambda^\top\gamma - \psi(\lambda) = D(P_\lambda\|P), \end{aligned}$$

建立该主张。 □

遗憾的是，命题15.14远不能完全解决（15.31）问题，因为它没有说明对于约束条件的哪些值$\gamma \in \mathbb{R}^d$，能够找到所需的倾斜P_λ。对于$d=1$，我们有一个非常简单的刻画，即P_λ的均值可以达到的值集合。具体而言，定理15.8表明（在假设15.1下）

$$\{\mathbb{E}_{X\sim P_\lambda}[\phi(X)] : \lambda \in \mathbb{R}\} = (A, B)\,,$$

其中A, B是ϕ的支撑集的边界。为了对$d>1$的情况得到类似的刻画，我们令$\tilde{P}$为当$X\sim P$时$\phi(X)$在$\mathbb{R}^d$上的概率分布，即$\tilde{P}$是P沿ϕ的前推。此时，(A, B)的类似物由以下概念扮演：

定义 15.15（凸支撑） 设$\tilde{P}$为$\mathbb{R}^d$上的概率测度。我们回忆，支撑$\operatorname{supp}(\tilde{P})$被定义为所有具有全测度的闭集的交集。$\tilde{P}$的 *convex support* 被定义为所有具有全测度的闭凸集的交集：

$$\operatorname{csupp}(\tilde{P}) \triangleq \cap\{S : \tilde{P}[S] = 1, S \text{ is closed and convex}\}\,.$$

显然，csupp本身是一个闭凸集。此外，它可以通过取$\operatorname{supp}(\tilde{P})$的凸包，随后进行拓扑闭包$\operatorname{cl}(\cdot)$来获得，即

$$\operatorname{csupp}(\tilde{P}) = \operatorname{cl}(\operatorname{co}(\operatorname{supp}(\tilde{P})))\,. \tag{15.34}$$

(的确，$\operatorname{csupp}(\tilde{P}) \subset \operatorname{cl}(\operatorname{co}(\operatorname{supp}\tilde{P}))$，因为右侧的集合是凸且闭的。另一方面，对于任何满测度的闭半空间$H \supset \operatorname{csupp}(\tilde{P})$，即$\tilde{P}[H]=1$，我们必须有$\operatorname{supp}(\tilde{P}) \subset H$。对两边取凸包再取闭包，得到$\operatorname{cl}(\operatorname{co}(\operatorname{supp}(\tilde{P}))) \subset H$。对所有这样的$H$取交集表明$\operatorname{cl}(\operatorname{co}(\operatorname{supp}\tilde{P})) \subset \operatorname{csupp}(\tilde{P})$也是如此。）

我们现在准备陈述关于I-投影何时由倾斜测度求解的特征描述。

定理 15.16（超平面上的I-投影） *Suppose P and ϕ satisfy the following two assumptions: (a) The $d+1$ functions $(1, \phi_1, \ldots, \phi_d)$ are linearly independent P-a.s. and (b) the log MGF $\psi(\lambda)$ is finite for all $\lambda \in \mathbb{R}^d$. Then*

1 If there exist any Q such that $\mathbb{E}_Q[\phi] = \gamma$ and $D(Q\|P) < \infty$, we must have $\gamma \in \operatorname{csupp}(\tilde{P})$.

2 There is a solution λ to $\mathbb{E}_{P_\lambda}[\phi] = \gamma$ if and only if $\gamma \in \operatorname{int}(\operatorname{csupp}(\tilde{P}))$.

推论 15.17 *Whenever $\gamma \in \operatorname{int}(\operatorname{csupp}(\tilde{P}))$ the I-projection problem (15.31) is solved by P_λ for some λ and the identity (15.33) holds. Furthermore, $F(\gamma) = \psi^*(\gamma)$ and $\lambda = \nabla F(\gamma)$.*

备注 15.6 定理 15.16 的假设 (b) 可以放宽为仅要求对数矩母函数的定义域是开集（见 [85, 定理 23.1] 或 [77, 定理 3.6]）。应用定理 15.16，当$\gamma \in$属于$\operatorname{csupp}(\tilde{P})$的内部时，$I$-投影可以在倾斜族$P_\lambda$中寻找，且仅在这种情况下如此。如果$\gamma \notin$属于$\operatorname{csupp}(\tilde{P})$，则$I$-投影显然不可能，并且任何具有给定期望的$Q$都会产生$D(Q\|P) = \infty$。当$\gamma \in \partial$属于$\operatorname{csupp}(\tilde{P})$时，可能$I$-投影（即 (15.31) 的最小化子）存在、唯一且产生有限的散度，但该最小化子并非由P的λ-倾斜给出。也可能每个可行Q都产生$D(Q\|P) = \infty$。

作为一个具体例子，考虑 $X \sim P = \mathcal{N}(0,1)$ 和 $\phi(x) = (x, x^2)$。那么 csupp($\tilde{P}$) = $\{(\gamma_1, \gamma_2) \in \mathbb{R}^2 : \gamma_2 \geq \gamma_1^2\}$，由$\mathbb{R}$上分布的所有有效一阶和二阶矩（满足Cauchy-Schwarz）组成。于是，这个I-投影问题的解如下。

• $\gamma_2 > \gamma_2 1$：最优的 Q 是 $\mathcal{N}(\gamma_1, \gamma_2 - \gamma_1^2)$，它是 P 沿 ϕ 的倾斜版本。
• $\gamma_2 = \gamma_1^2$：唯一可行的 Q 是 δ_{γ_1}，这导致 $D(Q\|P) = \infty$。• $\gamma_2 < \gamma_1^2$：没有可行的 Q。

在给出定理的证明之前，我们回顾一些关于 *exponential families* 的标准且简单的事实，P_λ 就是其中的一个例子。在此背景下，ϕ 被称为统计向量，而 λ 是自然参数。注意所有 $P_\lambda \sim P$ 都是相互绝对连续的，因此根据线性无关性假设，我们有：

$$\mathrm{Cov}_{X\sim P_\lambda}[\phi(X)] \succ 0 \tag{15.35}$$

即协方差矩阵是（严格）正定的。与定理15.3类似，我们可以证明$\lambda \mapsto \psi(\lambda)$是一个凸的、无限可微的函数[77]。我们想要研究从自然参数λ到均值参数μ的映射：

$$\lambda \mapsto \mu(\lambda) \triangleq \mathbb{E}_{X\sim P_\lambda}[\phi(X)]\,,$$

具体来说，我们将展示图像 $\mu(\mathbb{R}^d) =$ 在 csupp($\tilde{P}$) 中。为此，请注意，类似于定理15.8(b)和(c)，前两个导数给出了 ϕ 的矩如下：

$$\mathbb{E}_{X\sim P_\lambda}[\phi(X)] = \nabla\psi(\lambda)\,, \quad \mathrm{Cov}_{X\sim P_\lambda}[\phi(X)] = \text{Hess }\psi(\lambda)\log e\,. \tag{15.36}$$

结合（15.35），我们看到这时 ψ 是严格凸的，因此对于任意 λ_1, λ_2，我们都有 $\nabla\psi$ 的严格单调性，即

$$(\lambda_1 - \lambda_2)^T(\nabla\psi(\lambda_1) - \nabla\psi(\lambda_2)) > 0\,. \tag{15.37}$$

此外，由(15.35)我们得到映射$\lambda \mapsto \mu(\lambda)$的雅可比行列式等于det Hess $\psi > 0$。因此，根据逆函数定理，像$\mu(\mathbb{R}^d)$是$\mathbb{R}^d$中的开集，并且在此集合上存在一个无限可微的逆映射 $\mu \mapsto \lambda = \mu^{-1}(\mu)$。因此，族$P_\lambda$可以等价地由$\mu$重新参数化。非平凡的是，像$\mu(\mathbb{R}^d)$是凸的，并且实际上与int csupp($\tilde{P}$)重合。

Proof of Theorem 15.16. 在整个证明中，我们记$C =$为csupp($\tilde{P}$)，$C_o =$为int(csupp($\tilde{P}$))。

假设存在一个 $Q \ll P$ 具有 $t = \mathbb{E}_Q[\phi(X)] \notin C$。那么存在一个（分离超平面）$b \in \mathbb{R}^d$ 和 $c \in \mathbb{R}$，使得对于任意 $p \in C$ 都有 $b^\top t < c \leq b^\top p$。由于 $P[\phi(X) \in C] = 1$，我们得出 $Q[b^\top\phi(X) \geq c] = 1$。但这与 $\mathbb{E}_Q[b^\top\phi(X)] < c$ 的事实相矛盾。这证明了第一个论断。

接下来，我们证明对于任意 λ，都有 $\mu(\lambda) = \mathbb{E}_{P_\lambda}[\phi] \in C_o$。事实上，根据前一段的内容，我们知道 $\mu(\lambda) \in C$。另一方面，正如我们所讨论的，映射 $\lambda \to \mu(\lambda)$ 是光滑的、一对一的，并且具有光滑的逆映射。因此，围绕 λ 的小球的像是开集，从而 $\mu(\lambda) \in \text{int}(C) = C_o$。

最后，我们证明主要蕴含关系：对于任意 $\gamma \in C_o$，必定存在一个 λ，使得 $\mu(\lambda) = \gamma$。为此，考虑无约束最小化问题

$$\inf_{\lambda} \psi(\lambda) - \lambda^\top \gamma \,. \tag{15.38}$$

如果我们可以证明最小值在某个 λ^* 处取得，那么根据一阶最优性条件，我们得出所需的 $\nabla\psi(\lambda^*) = \gamma$。由于目标函数连续，只需证明不失一般性，最小化可以限制在一个紧球 $\{\|\lambda\| \le R\}$ 内，对于某个大的 R。

为此，我们首先注意到，如果 $\gamma \in C_o$，那么对于某个 $\epsilon >> 0$，我们必须有

$$c_\epsilon \triangleq \inf_{v:\|v\|=1} P[v^\top(\phi(X) - \gamma) > \epsilon] > 0 \,. \tag{15.39}$$

事实上，假设情况并非如此。那么对于任意 $\epsilon > 0$，存在一个序列 v_k，使得

$$P[v_k^\top(\phi(X) - \gamma) > \epsilon] \to 0 \,.$$

现在，由球的紧致性，$v_k \to \tilde{v}_\epsilon$不失一般性，因此对于每个$\epsilon$，存在某个$\tilde{v}_\epsilon$使得

$$P[\tilde{v}_\epsilon^\top(\phi(X) - \gamma) > \epsilon] = 0 \,.$$

再次，由紧性可知，必定存在收敛子序列$\tilde{v}_\epsilon \to v_*$和$\epsilon \to 0$，使得

$$P[v_*^\top(\phi(X) - \gamma) > 0] = 0 \,.$$

因此，$\mathrm{supp}(\tilde{P}) \subset \{x : v_*^\top \phi(x) \le v_*^\top \gamma\}$，从而$\gamma$不可能是$C = \mathrm{csupp}(\tilde{P})$的内点。鉴于(15.39)，我们得到以下估计，其中我们记$v = \frac{\lambda}{\|\lambda\|}$:

$$\begin{aligned}
\exp\{\psi(\lambda) - \lambda^\top\gamma\} &= \mathbb{E}_P[\exp\{\lambda^\top(\phi(X) - \gamma)\}] \\
&\ge \mathbb{E}_P[\exp\{\lambda^\top(\phi(X) - \gamma)\}1\{v^\top(\phi(X) - \gamma) > \epsilon\}] \\
&\ge c_\epsilon \exp\{\epsilon\|\lambda\|\}
\end{aligned}$$

因此，回到最小化问题（15.38），我们看到目标函数满足一个下界

$$\psi(\lambda) - \lambda^\top\gamma \ge \log c_\epsilon + \epsilon\|\lambda\| \,.$$

那么显然，将最小化限制在一个足够大的球体 $\{\|\lambda\| \le R\}$ 内不失一般性。正如我们所解释的，这完成了证明。 □

例 15.2（Sinkhorn 问题）作为定理 15.16 的一个应用，考虑有限集 $\mathcal{X} \times \mathcal{Y}$ 上的联合分布 $P_{X,Y}$。我们的目标是解决一个耦合问题：

$$\min\{D(Q_{X,Y}\|P_{X,Y}) : Q_X = V_X, Q_Y = V_Y\} \,,$$

其中边缘分布 V_X 和 V_Y 已给出。正如我们在第5.6节所讨论的，Sinkhorn 发现了一种优雅的迭代算法，该算法收敛于最小化者。在这里，我们可以应用我们的通用 I-投影理论来证明最小化者具有形式

$$Q^*_{X,Y}(x,y) = A(x)P_{X,Y}(x,y)B(y)\,. \tag{15.40}$$

具体来说，假设 $P_{X,Y}(x,y) > 0$ 并考虑 $|\mathcal{X}| + |\mathcal{Y}|$ 函数 $\phi_a(x,y) = 1\{x = a\}$ 和 $\phi_b(x,y) = 1\{y = b\}$，$a \in \mathcal{X}$，$b \in \mathcal{Y}$。它们是线性无关的。在这种情况下，集合 $\text{csupp}(\tilde{P}) = \mathcal{P}(\mathcal{X}) \times \mathcal{P}(\mathcal{Y})$ 对应于所有边缘分布。因此，只要 V_X, V_Y 没有零点，它们就属于 $\text{int}(\text{csupp}(\tilde{P}))$，且 I-投影问题的解是 $P_{X,Y}$ 的一个倾斜版本，其形式恰好为 (15.40)。在这种情况下，事实证明 I-投影在边界上也存在，甚至当 $P_{X,Y}$ 允许有零点时也存在，但这些情况超出了定理 15.16 的范围，需要以不同方式处理，参见 [114]。

16 Hypothesis testing: error exponents

在本章中，我们的目标是确定当两个指数均为严格正时，在Chernoff区域中，Type-I和Type-II错误概率的指数对(E_0, E_1)的可达区域。我们的策略是结合第14章中的可达性和（强）逆界以及第15章中发展的大偏差理论。在刻画了完整的权衡之后，我们将讨论假设检验的自适应设置，其中不是提前决定基于n个样本进行检验，而是可以自适应地决定是请求更多样本还是停止。我们将发现自适应性极大地增加了可达误差指数的区域，并将了解Wald的序贯概率比检验（SPRT）。在最后几节中，我们将讨论与假设检验中更复杂设置的关系：一个涉及复合假设，另一个涉及通信约束。

16.1 (E_0, E_1) 权衡

回顾第14.6节介绍的Chernoff状态的设定，其目标在于设计满足以下条件的测试:

$$\pi_{1|0} = 1 - \alpha \le \exp(-nE_0), \quad \pi_{0|1} = \beta \le \exp(-nE_1).$$

为了找到 E_0 与 E_1 的最佳权衡，我们可以定义以下函数

$$\begin{aligned} E_1^*(E_0) &\triangleq \sup\{E_1 : \exists n_0, \forall n \ge n_0, \exists P_{Z|X^n} \text{ s.t. } \alpha > 1 - \exp(-nE_0), \beta < \exp(-nE_1)\} \\ &= \liminf_{n\to\infty} \frac{1}{n} \log \frac{1}{\beta_{1-\exp(-nE_0)}(P^n, Q^n)} \end{aligned}$$

应与定义14.13中的Stein指数进行比较。

定义

$$T_k = \log \frac{dQ}{dP}(X_k), \quad k = 1, \dots, n$$

它们是 $T = \log \frac{dQ}{dP}(X)$ 的独立同分布副本。那么 $\log \frac{dQ^n}{dP^n}(X^n) = \sum_{k=1}^n T_k$，在 P 和 Q 下都是独立同分布之和。

在P(下，T的对数矩生成函数再次假设为有限，并且T不是常数，因为$P \ne Q$)及其相应的速率函数是（参见定义15.2和15.5）：

$$\psi_P(\lambda) = \log \mathbb{E}_P[\exp(\lambda T)], \quad \psi_P^*(\theta) = \sup_{\lambda \in \mathbb{R}} \theta\lambda - \psi_P(\lambda).$$

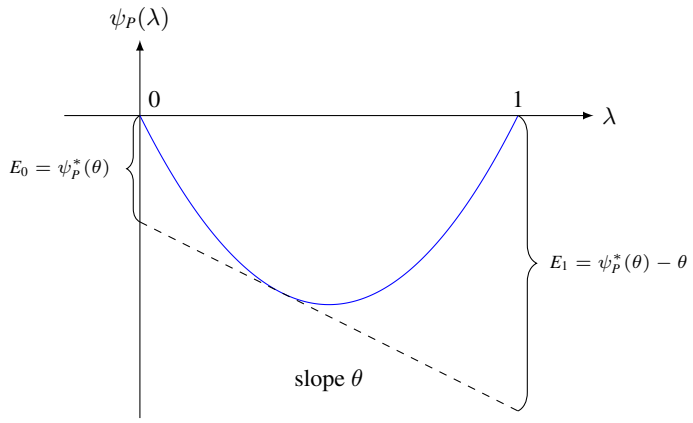


图16.1 定理16.1的几何解释依赖于$\psi_P(\lambda)$和$\psi_P^*(\theta)$的性质。注意，$\psi_P(0) = \psi_P(1) = 0$。此外，根据定理15.6，$\theta \mapsto E_0(\theta)$是递增的，$\theta \mapsto E_1(\theta)$是递减的。

对于离散分布，我们有 $\psi_P(\lambda) = \log \sum_x P(x)^{1-\lambda} Q(x)^\lambda$；一般来说，对于某个支配测度 μ，有 $\psi_P(\lambda) = \log \int d\mu (\frac{dP}{d\mu})^{1-\lambda} (\frac{dQ}{d\mu})^\lambda$。

注意，由于 $\psi_P(0) = \psi_P(1) = 0$，根据$\psi_P$ (定理15.3)的凸性，我们得出 $\psi_P(\lambda)$ 在$0 \le \lambda \le 1$上是有限的。此外，假设$P \ll Q$和$Q \ll P$，我们还有 $\lambda \mapsto \psi_P(\lambda)$ 在$[0, 1]$上处处连续。（在$(0, 1)$上的连续性由凸性得出，但对于边界点，我们需要更详细的论证。）尽管本节中的所有结果在$P \ll Q$和$Q \ll P$的（较弱的）条件下都适用，但我们将只给出在对所有λ对数矩生成函数存在的（更强的）条件下的证明，遵循前一章的约定。以下结果以参数形式确定了最优的(E_0, E_1)-权衡。具体例子见练习III.19，用于测试两个高斯分布。

定理 16.1 *Assume $P \ll Q$ and $Q \ll P$. Then*

$$E_0(\theta) = \psi_P^*(\theta), \qquad E_1(\theta) = \psi_P^*(\theta) - \theta, \tag{16.1}$$

parametrized by $-D(P\|Q) \le \theta \le D(Q\|P)$, characterizes the upper boundary of the region of all achievable (E_0, E_1)-pairs. (See Figure 16.1 for an illustration.)

备注 16.1（Rényi散度） 在定义 7.24 中，我们定义了Rényi散度 D_λ。事实证明，D_λ 与误差指数密切相关。实际上，我们有 $\psi_P(\lambda) = (\lambda - 1)D_\lambda(Q\|P) = -\lambda D_{1-\lambda}(P\|Q)$。这提供了另一个证明，说明为什么对于 0 到 1 之间的 λ，$\psi_P(\lambda)$ 为负，同时也恢复了端点的斜率：$\psi_P'(0) = -D(P\|Q)$ 和 $\psi_P'(1) = D(Q\|P)$。另见练习 I.39。

推论 16.2（贝叶斯准则）*Fix a prior* (π_0, π_1) *such that* $\pi_0 + \pi_1 = 1$ *and* $0 < \pi_0 < 1$ *. Denote the optimal Bayesian (average) error probability by*

$$P_e^*(n) \triangleq \inf_{P_{Z|X^n}} \pi_0 \pi_{1|0} + \pi_1 \pi_{0|1}$$

with exponent

$$E \triangleq \lim_{n\to\infty} \frac{1}{n} \log \frac{1}{P_e^*(n)}.$$

Then

$$E = \max_{\theta} \min(E_0(\theta), E_1(\theta)) = \psi_P^*(0)$$

regardless of the prior, and

$$\psi_P^*(0) = -\inf_{\lambda\in[0,1]} \psi_P(\lambda) = -\inf_{\lambda\in[0,1]} \log \int (dP)^{1-\lambda} (dQ)^{\lambda} \triangleq C(P,Q) \tag{16.2}$$

is called the 切尔诺夫指数 *or* 切尔诺夫信息 *.*

注意，从（14.19）我们总是有

$$\log\left(1 - \frac{1}{2}H^2(P,Q)\right) \le C(P,Q) \le 2\log\left(1 - \frac{1}{2}H^2(P,Q)\right)$$

因此，对于较小的 $H^2(P,Q)$，我们有 $C(P,Q) \asymp H^2(P,Q)$。

备注 16.2（巴塔查里亚距离） 有一个重要的特殊情况，其中切尔诺夫指数得以简化。不同于独立同分布观测，考虑独立但不同分布的观测。即，假设两个假设对应于有限字母表 $\mathcal{X}$ 上的两个不同字符串 x^n 和 $\tilde{x}^n$。假设检验器观察到 $Y^n = (Y_1, \ldots, Y_n)$，其通过将两个字符串之一应用于无记忆信道 $P_{Y|X}$ 的输入而获得；换言之，要么是 $Y^n \sim \prod_{t=1}^n P_{Y|X=x_t}$，要么是 $\prod_{t=1}^n P_{Y|X=\tilde{x}_t}$。（字母表 $\mathcal{Y}$ 不必是有限的，但我们在下面如此假设。）推广推论 16.2 可以表明，在这种情况下，最优（平均）错误概率 $P_e^*(x^n, \tilde{x}^n)$ 具有（切尔诺夫）指数 [1]

$$E = -\inf_{\lambda\in[0,1]} \frac{1}{n} \sum_{t=1}^{n} \log \sum_{y\in\mathcal{Y}} P_{Y|X}(y|x_t)^{\lambda} P_{Y|X}(y|\tilde{x}_t)^{1-\lambda}\,.$$

If $|\mathcal{X}| = 2$ *and if the compositions (types) of* x^n *and* $\tilde{x}^n$ *are equal (!)*，该表达式在$\lambda \leftrightarrow 1-\lambda$下不变，因此由$\lambda$中的凸性我们得出$\lambda = \frac{1}{2}$是最优的，[2]得出$E = \frac{1}{n} d_B(x^n, \tilde{x}^n)$，其中

$$d_B(x^n, \tilde{x}^n) = -\sum_{t=1}^{n} \log \sum_{y\in\mathcal{Y}} \sqrt{P_{Y|X}(y|x_t) P_{Y|X}(y|\tilde{x}_t)} \tag{16.3}$$

[1] In short, this is because the optimal tilting parameter λ does not need to be chosen differently for different values of $(x_t, \tilde{x}_t)$.

[2] For another example where $\lambda = \frac{1}{2}$ achieves the optimal in the Chernoff information, see Exercise **III.30**.

被称为码字 x^n 和 $\tilde{x}^n$ 之间的 *Bhattacharyya distance*。（请与 (7.5) 之后定义的 Bhattacharyya 系数进行比较。）若不做出上述两个假设，$d_B(\cdot,\cdot)$ 未必能给出最优误差指数。然而，我们始终有界，见 (14.19)：

$$\frac{1}{4}\exp\left(-2d_B(x^n,\tilde{x}^n)\right) \le P_e^*(x^n,\tilde{x}^n) \le \exp\left(-d_B(x^n,\tilde{x}^n)\right),$$

其中当 $(x^n,\tilde{x}^n)$ 的联合组成与 $(\tilde{x}^n,x^n)$ 的联合组成更接近时，上界变得更紧。

Proof of Theorem 16.1. 这个想法是将大偏差理论应用于独立同分布和 $\sum_{k=1}^n T_k$。具体来说，让我们根据 T 重写第14章中的可达性和逆界：

- 可达性（Neyman-Pearson）：应用定理14.11及$\tau = -n\theta$，似然比检验达到以下效果

$$\pi_{1|0} = P\left[\sum_{k=1}^n T_k \ge n\theta\right] \quad \pi_{0|1} = Q\left[\sum_{k=1}^n T_k < n\theta\right] \tag{16.4}$$

- 逆命题（强）：将定理14.10应用于 $\gamma = \exp(-n\theta)$，任何可实现的 $\pi_{1|0}$ 和 $\pi_{0|1}$ 满足

$$\pi_{1|0} + \exp(-n\theta)\,\pi_{0|1} \ge P\left[\sum_{k=1}^n T_k \ge n\theta\right]. \tag{16.5}$$

为了证明可达性，将定理15.9（及定理15.11）中的非渐近大偏差上界应用于(16.4)，我们得到对于任意n，

$$\pi_{1|0} = P\left[\sum_{k=1}^n T_k \ge n\theta\right] \le \exp\left(-n\psi_P^*(\theta)\right), \quad \text{for } \theta \ge \mathbb{E}_P T = -D(P\|Q)$$
$$\pi_{0|1} = Q\left[\sum_{k=1}^n T_k < n\theta\right] \le \exp\left(-n\psi_Q^*(\theta)\right), \quad \text{for } \theta \le \mathbb{E}_Q T = D(Q\|P)$$

注意，根据 $T = \log\frac{dQ}{dP}$ 的定义，我们有

$$\psi_Q(\lambda) = \log \mathbb{E}_Q[e^{\lambda T}] = \log \mathbb{E}_P[e^{(\lambda+1)T}] = \psi_P(\lambda+1)$$
$$\Rightarrow \psi_Q^*(\theta) = \sup_{\lambda\in\mathbb{R}} \theta\lambda - \psi_P(\lambda+1) = \psi_P^*(\theta) - \theta.$$

因此，(16.1)中的指数对（$E_0(\theta), E_1(\theta)$）是可实现的。

对于逆命题，我们的目标是证明任何可达的（E_0, E_1）对都必须位于上述Neyman-Pearson检验所达到的曲线下方，即由θ参数化的（$E_0(\theta), E_1(\theta)$）。假设$\pi_{1|0} = \exp(-nE_0)$和$\pi_{0|1} = \exp(-nE_1)$是可达的。结合强逆界(16.5)与大偏差下界，我们有：对于任意固定的$\theta \in [-D(P\|Q), \le D(Q\|P)]$,

$$\exp(-nE_0) + \exp(-n\theta)\exp(-nE_1) \ge \exp\left(-n\psi_P^*(\theta) + o(n)\right)$$
$$\Rightarrow \min(E_0, E_1+\theta) \le \psi_P^*(\theta)$$

$$\Rightarrow \text{either } E_0 \le \psi_P^*(\theta) \text{ or } E_1 \le \psi_P^*(\theta) - \theta,$$

证明所需结果。 □

16.2 定理16.1的等价形式

或者, 最优({v*})权衡可以用以下等式表示 有效形式:

定理 16.3 *(a) The optimal exponents are given (parametrically) in terms of* $\lambda \in [0, 1]$ *as*

$$E_0 = D(P_\lambda \| P), \qquad E_1 = D(P_\lambda \| Q) \tag{16.6}$$

where the distribution P_λ[3] *is tilting of* P *along* T *given in* (15.27)*, which moves from* $P_0 = P$ *to* $P_1 = Q$ *as* λ *ranges from* 0 *to* 1*:*

$$dP_\lambda = (dP)^{1-\lambda}(dQ)^\lambda \exp\{-\psi_P(\lambda)\}.$$

(b) Yet another characterization of the boundary is

$$E_1^*(E_0) = \min_{Q' : D(Q'\|P) \le E_0} D(Q'\|Q)\,, \qquad 0 \le E_0 \le D(Q\|P) \tag{16.7}$$

备注 16.3 这一观点的有趣推论在于，它也揭示了典型错误事件的面貌。具体而言，设想一个达到成对指数 (E_0, E_1) 的最优假设检验。那么，在错误事件条件下（无论是 P 还是 Q），样本的经验分布将接近于 P_λ。例如，若 $P =$ 服从 $\mathrm{Bin}(m, p)$ 且 $Q =$ 服从 $\mathrm{Bin}(m, q)$，则典型错误事件对应的样本，其经验分布 $\hat{P}_n$ 大约为 $\mathrm{Bin}(m, r)$，其中 $r = r(p, q, \lambda) \in (p, q)$ 为某一值，而非 $\{0, \dots, m\}$ 上的其他任何分布。

Proof. 第一部分可以轻松验证。实际上，如果我们固定λ并令$\theta(\lambda) \triangleq \mathbb{E}_{P_\lambda}[T]$，那么根据(15.8)式我们有

$$D(P_\lambda \| P) = \psi_P^*(\theta)\,,$$

而

$$D(P_\lambda \| Q) = \mathbb{E}_{P_\lambda}\left[\log \frac{dP_\lambda}{dQ}\right] = \mathbb{E}_{P_\lambda}\left[\log \frac{dP_\lambda}{dP}\frac{dP}{dQ}\right] = D(P_\lambda \| P) - \mathbb{E}_{P_\lambda}[T] = \psi_P^*(\theta) - \theta\,.$$

同样根据（15.7），我们知道当λ在$[0, 1]$范围内变化时，均值$\theta = \mathbb{E}_{P_\lambda}[T]$从$-D(P\|Q)$变化到$D(Q\|P)$。

为了证明第二个断言（16.7），关键的观察是：由于Q本身是P沿T(的一个倾斜，且$\lambda = 1$)，以下两个分布族

$$dP_\lambda = \exp\{\lambda T - \psi_P(\lambda)\} \cdot dP$$

[3] This is called a geometric mixture of P and Q.

$$dQ_{\lambda'} = \exp\{\lambda' T - \psi_Q(\lambda')\} \cdot dQ$$

实际上与$Q_{\lambda'} = P_{\lambda'+1}$属于同一族。

现在，假设Q^*在(16.7)中达到最小值，并且$Q^* \neq Q$、$Q^* \neq P$ (这些情况应分别验证)。请注意，我们尚未证明该最小值能够被达到，但显然我们的论证可以推广到Q'_n是一个达到下确界的序列的情况。那么，一方面，显然

$$D(Q^*\|Q) = \min_{Q':D(Q'\|P)\le E_0} D(Q'\|Q) \le D(P\|Q)$$

另一方面，自$E_0 \le D(Q\|P)$以来，我们也有

$$D(Q^*\|P) \le D(Q\|P)\,.$$

因此，

$$\mathbb{E}_{Q^*}[T] = \mathbb{E}_{Q^*}\left[\log \frac{dQ^*}{dP}\frac{dQ}{dQ^*}\right] = D(Q^*\|P) - D(Q^*\|Q) \in [-D(P\|Q), D(Q\|P)]\,. \tag{16.8}$$

接下来，根据推论15.12，存在一个*unique* P_λ，具有以下三个性质：[4]

$$\begin{aligned}\mathbb{E}_{P_\lambda}[T] &= \mathbb{E}_{Q^*}[T]\\ D(P_\lambda\|P) &\le D(Q^*\|P)\\ D(P_\lambda\|Q) &\le D(Q^*\|Q)\end{aligned}$$

因此，我们立即得出结论，(16.7)中的最小化可以限制在属于倾斜分布族$\{P_\lambda, \lambda \in \mathbb{R}\}$的$Q^*$上。此外，从(16.8)我们还可以得出结论，$\lambda \in [0,1]$。因此，由(16.6)给出的$E_1^*(E_0)$的特征与(16.7)给出的特征一致。

□

注 16.4 (16.7) 的几何解释见图 16.2：随着 λ 从 0 增加到 1，或等价地，θ 从 $-D(P\|Q)$ 增加到 $D(Q\|P)$，最优分布 P_λ 沿着从 P 和 Q 出发的虚线路径向下移动。请注意，在 P 和 Q 之间存在许多插值方式，例如取它们的（算术）混合 $(1-\lambda)P + \lambda Q$。相比之下，P_λ 是 P 和 Q 的 *geometric mixture*，这条特殊路径本质上是一条连接 P 到 Q 的测地线，而指数 E_0 和 E_1 分别度量了它到 P 和 Q 的距离。不过，与黎曼几何不同，这里从一个中间点 P_λ 到两个端点的距离之和实际上会沿着这条测地线变化。

[4] A subtlety: In Corollary 15.12 we ask $\mathbb{E}_{Q^*}[T] \in (A,B)$. But A, B – the essential range of T – depend on the distribution under which the essential range is computed, cf. (15.23). Fortunately, we have $Q \ll P$ and $P \ll Q$, so the essential range is the same under both P and Q. And furthermore (16.8) implies that $\mathbb{E}_{Q^*}[T] \in (A,B)$.

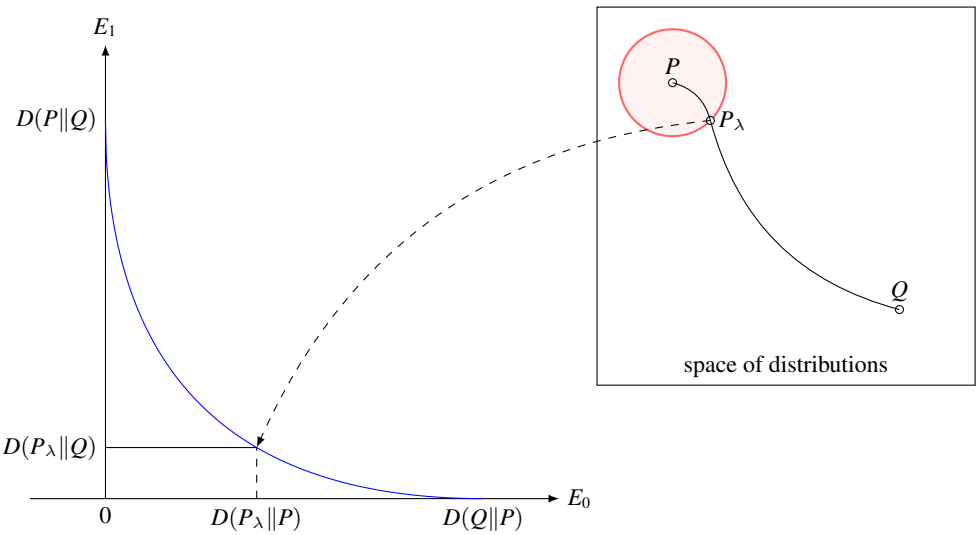


图16.2 (16.7)的几何解释。这里阴影圆表示$\{Q'\colon D(Q'\|P)\le E_0\}$，即以$P$为中心、半径为$E_0$的KL散度“球”。(16.7)中的最优$E_1^*(E_0)$由从$Q$到该球最近元素的散度给出，由某个倾斜分布$P_\lambda$达到。倾斜族$P_\lambda$是当$\lambda$从0增加到1时从$P$到$Q$的测地线。

16.3* 序贯假设检验

审查：过滤与停时

- 一个嵌套的 σ-代数序列 $\mathcal{F}_0 \subset \mathcal{F}_1 \subset \mathcal{F}_2 \cdots \subset \mathcal{F}_n \cdots \subset \mathcal{F}$ 被称为 $\mathcal{F}$ 的滤子。
- 一个随机变量 τ 被称为滤子 $\mathcal{F}_n$ 的停时，如果 (a) τ 取值于 $\mathbb{Z}_+$ 且 (b) 对于每个 $n\ge 0$，事件 $\{\tau\le n\}\in\mathcal{F}_n$。
- σ-代数 $\mathcal{F}_\tau$ 包含所有事件 E，使得 $E\cap\{\tau\le n\}\in\mathcal{F}_n$ 对所有 $n\ge 0$ 成立。
- 当 $\mathcal{F}_n=\sigma\{X_1,\dots,X_n\}$ 时，其解释是 τ 是一个可以通过因果观察序列 X_j 确定的时间，而关于 $\mathcal{F}_\tau$ 可测的随机变量正是那些其值可以在已知 $(X_1,\dots,X_\tau)$ 的基础上确定的随机变量。
- 令 M_n 为适应于 $\mathcal{F}_n$ 的鞅，即 M_n 是 $\mathcal{F}_n$-可测的且 $\mathbb{E}[M_n|\mathcal{F}_k]=M_{\min(n,k)}$。那么 $\tilde{M}_n=M_{\min(n,\tau)}$ 也是一个鞅。如果集合 $\{M_n\}$ 是一致可积的，那么

$$\mathbb{E}[M_\tau]=\mathbb{E}[M_0]\,.$$

- 有关更多详细信息，请参见[84，第五章]。

到目前为止，我们一直处理的是固定数量的观测值 n。然而，X^n 的不同实现提供的信息量不同，即在某些实现下，我们对宣布真实假设非常确定，而在其他一些实现下，我们则更加怀疑。在固定 n 的设置中，测试者不得不在后一种情况下做出猜测。在由 Wald [448] 开创的序贯设置中，测试者可以请求更多观测值。我们在本节中表明，该设置下的最优检验被称为序贯概率比检验（SPRT）[450]。同时还将表明，在序贯设置中，指数 E_0 和 E_1 之间由此产生的权衡得到了显著改善。

我们从一个序贯检验的概念开始。非正式地说，在每一时刻t，当收到观测值X_t时，序贯检验要么宣布H_0，要么宣布H_1，要么请求再获得一个观测值。严格定义如下：一个序贯假设检验由以下部分组成：(a) 关于过滤$\{\mathcal{F}_k, k \in \mathbb{Z}_+\}$的停时$\tau$，其中$\mathcal{F}_k \triangleq \sigma\{X_1, \ldots, X_n\}$由前$n$个观测值生成；(b) 一个随机变量（决策）$Z \in \{0, 1\}$关于$\mathcal{F}_\tau$可测。每个序贯检验都与以下性能指标相关联：

$$\alpha = \mathbb{P}[Z = 0], \qquad \beta = \mathbb{Q}[Z = 0] \tag{16.9}$$

$$l_0 = \mathbb{E}_{\mathbb{P}}[\tau], \qquad l_1 = \mathbb{E}_{\mathbb{Q}}[\tau] \tag{16.10}$$

最容易看出为什么序贯检验可能显著优于固定样本量检验的方法是通过以下例子：考虑$P = \frac{1}{2}\delta_0 + \frac{1}{2}\delta_1$和$Q = \frac{1}{2}\delta_0 + \frac{1}{2}\delta_{-1}$。由于$P \not\perp Q$，我们也有$P^n \not\perp Q^n$。因此，没有任何有限样本量检验能在两种假设下实现零错误。然而，一个明显的序贯检验（等待± 1首次出现）在两种假设下均能在期望有限次数（两次）的观察中实现零错误概率。这一优势在可达到的误差指数方面也很明显，如图16.3所示。

以下结果本质上归功于[450]，尽管那里仅对$E_0 = D(Q\|P)$和$E_1 = D(P\|Q)$的特殊情况进行了展示。下面的版本来自[339]。

定理 16.4 *Assume bounded LLR:*[5]

$$\left|\log \frac{P(x)}{Q(x)}\right| \le c_0, \forall x$$

where c_0 is some positive constant. Call a pair of exponents (E_0, E_1) achievable if there exist a test with $l_0, l_1 \to \infty$ and probabilities satisfy:

$$\pi_{1|0} \le \exp\left(-l_0 E_0(1 + o(1))\right), \qquad \pi_{0|1} \le \exp\left(-l_1 E_1(1 + o(1))\right)$$

Then the set of achievable exponents must satisfy

$$E_0 E_1 \le D(P\|Q)D(Q\|P).$$

Furthermore, any such (E_0, E_1) is achieved by the sequential probability ratio test SPRT(A, B) (A, B are large positive numbers) defined as follows:

$$\tau = \inf\{n : S_n \ge B \text{ or } S_n \le -A\}$$

5 这一假设对于例如在有限字母表上完全支持的离散分布对是成立的。

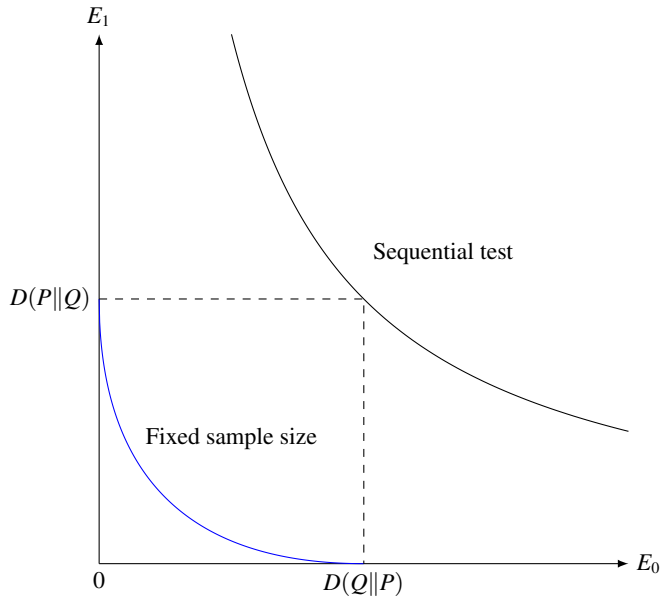


图16.3 I型错误与II型错误指数之间的权衡。底部曲线对应于样本量固定的最优检验（定理16.1），上方曲线对应于最优序贯检验（定理16.4）。

$$Z = \begin{cases} 0, & \text{if } S_\tau \geq B \\ 1, & \text{if } S_\tau < -A \end{cases}$$

where

$$S_n = \sum_{k=1}^{n} \log \frac{P(X_k)}{Q(X_k)}$$

is the log likelihood function of the first n observations.

注16.5（SPRT的解释）在假设检验的通常设定下，我们收集一个包含n个独立同分布观测值的样本，计算对数似然比S_n，并将其与阈值比较以给出最优检验。在序贯设定下，$\{S_n\colon\ n \geq 1\}$是一个*random walk*，在原假设（分别地，备择假设）下具有正（分别地，负）漂移$D(P\|Q)$（（分别地，$-D(Q\|P)$））！SPRT简单地宣布P，如果随机游走越过上边界B，或者宣布Q，如果随机游走越过上边界$-A$。参见图16.4的示例。

Proof. 作为准备，我们展示两个有用的恒等式：

- 对于任何具有 $\mathbb{E}_P[\tau] < \infty$ 的停时，我们有

$$\mathbb{E}_P[S_\tau] = \mathbb{E}_P[\tau] D(P\|Q) \tag{16.11}$$

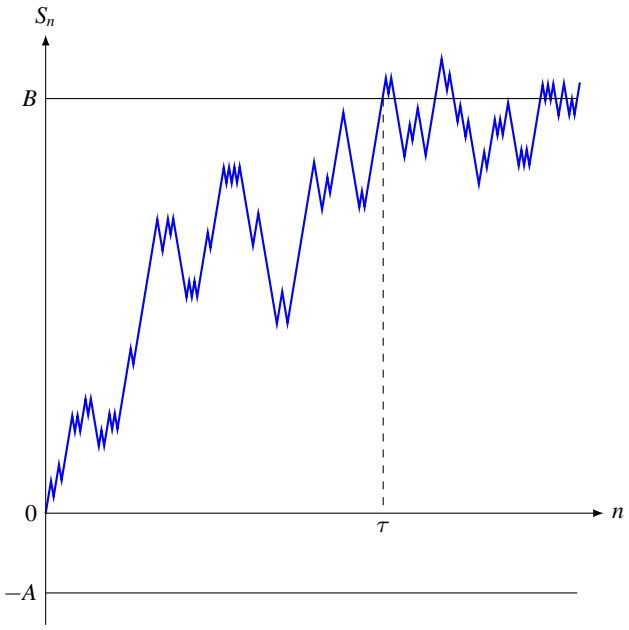


图16.4 SPRT(A,B) 测试示意图。在此，当停止时间 τ 时，LLR 过程 S_n 在达到 $-A$ 之前先达到 B，因此决策结果为 $Z=1$。

同样地，如果 $\mathbb{E}_Q[\tau]<\infty$ 那么

$$\mathbb{E}_Q[S_\tau] = -\,\mathbb{E}_Q[\tau]D(Q\|P)\,.$$

为了证明这些，请注意

$$M_n = S_n - nD(P\|Q)$$

显然是一个关于$\mathcal{F}_n$的鞅。因此，

$$\tilde{M}_n \triangleq M_{\min(\tau,n)}$$

也是一个鞅。因此

$$\mathbb{E}[\tilde{M}_n] = \mathbb{E}[\tilde{M}_0] = 0\,,$$

或者，等价地，{v*}

$$\mathbb{E}[S_{\min(\tau,n)}] = \mathbb{E}[\min(\tau,n)]D(P\|Q)\,. \tag{16.12}$$

这对每个 $n\geq 0$ 成立。由有界性假设，我们得到 $|S_n|\leq nc_0$，从而 $|S_{\min(n,\tau)}|\leq \tau c_0$，这意味着集合 $\{S_{\min(n,\tau)}: n\geq 0\}$ 是一致可积的。因此，我们可以取（16.12）中的 $n\to\infty$，并安全地交换期望与极限，从而得出（16.11）。

- 设 τ 为一个停时。回忆一下，随机变量 R 是 $\mathbb{P}$ 关于 $\mathbb{Q}$ 在 σ-代数 $\mathcal{F}_\tau$ 上的 Radon-Nikodym 导数，记作 $\frac{d\mathbb{P}|_{\mathcal{F}_\tau}}{d\mathbb{Q}|_{\mathcal{F}}}$ $_\tau$，如果

$$\mathbb{E}_P[1_E] = \mathbb{E}_Q[R1_E] \qquad \forall E \in \mathcal{F}_\tau\,. \tag{16.13}$$

我们将证明它事实上是由下式给出的

$$\frac{d\mathbb{P}|_{\mathcal{F}_\tau}}{d\mathbb{Q}|_{\mathcal{F}_\tau}} = \exp\{S_\tau\}\,.$$

事实上，我们需要验证的是(16.13)在$R = \exp\{S_\tau\}$以及任意事件$E \in \mathcal{F}_\tau$的情况下成立，我们将其分解为

$$1_E = \sum_{n\geq 0} 1_{E\cap\{\tau=n\}}\,.$$

通过对（16.13）两边应用单调收敛定理，只需验证对于每个n

$$\mathbb{E}_P[1_{E\cap\{\tau=n\}}] = \mathbb{E}_Q[\exp\{S_\tau\}1_{E\cap\{\tau=n\}}]\,. \tag{16.14}$$

然而，这源于$E\cap\{\tau=n\}\in\mathcal{F}_n$和$\frac{d\mathbb{P}|_{\mathcal{F}_n}}{d\mathbb{Q}|_{\mathcal{F}_n}}$ =根据S_n的定义就导出$\{S_n\}$这一事实。

我们现在开始证明。对于可达性，我们应用(16.13)推断

$$\pi_{1|0} = \mathbb{P}[S_\tau \leq -A] = \mathbb{E}_Q[\exp\{S_\tau\}1\{S_\tau \leq -A\}] \leq e^{-A}.$$

接下来，我们记 $\tau_0 =$ 为 $\inf\{n : S_n \geq B\}$，并注意到 $\tau \leq \tau_0$，而 τ_0 的期望可利用 (16.11) 式界定为:

$$\mathbb{E}_P[\tau] \leq \mathbb{E}_P[\tau_0] = \frac{\mathbb{E}_P[S_{\tau_0}]}{D(P\|Q)} \leq \frac{B+c_0}{D(P\|Q)}\,,$$

其中在最后一步中，我们利用了有界性假设来推断$S_{\tau_0} \leq B + c_0$。总体而言，

$$l_0 = \mathbb{E}_{\mathbb{P}}[\tau] \leq \mathbb{E}_{\mathbb{P}}[\tau_0] \leq \frac{B+c_0}{D(P\|Q)}\,.$$

类似地，我们可以展示 $\pi_{0|1} \leq e^{-B}$ 和 $l_1 \leq \frac{A+c_0}{D(Q\|P)}$。现在考虑边界上的一对指数 E_0, E_1，即 $E_0E_1 = D(P\|Q)D(Q\|P)$。令 $x = \frac{E_0}{D(P\|Q)} = \frac{D(Q\|P)}{E_1}$。设置 $A = xB$ 并令 $B \to \infty$。由上述论证我们得到 $\pi_{1|0} \leq e^{-xB} \leq e^{-xB\frac{l_0 D(P\|Q)}{B+c_0}} = e^{-l_0E_0(1+o(1))}$，类似地 $\pi_{0|1} \leq e^{-l_1E_1(1+o(1))}$。

逆命题：假设对于大的l_0, l_1，(E_0, E_1)是可达到的。回顾第4.6*节，当把P和Q视为σ-代数$\mathcal{F}_\tau$上的测度时，$D(\mathbb{P}_{\mathcal{F}_\tau}\|\mathbb{Q}_{\mathcal{F}_\tau})$表示它们之间的散度。我们应用散度的数据处理不等式得到:

$$d(\mathbb{P}(Z=1)\|\mathbb{Q}(Z=1)) \leq D(\mathbb{P}_{\mathcal{F}_\tau}\|\mathbb{Q}_{\mathcal{F}_\tau}) = \mathbb{E}_P[S_\tau] \overset{(16.11)}{=} \mathbb{E}_{\mathbb{P}}[\tau]D(P\|Q) = l_0D(P\|Q),$$

注意，对于较大的 l_0E_0 和 l_1E_1，我们有 $d(\mathbb{P}(Z=1)\|\mathbb{Q}(Z=1)) = l_1E_1(1+o(1))$，因此 $l_1E_1 \le (1+o(1))l_0D(P\|Q)$。同样地，我们可以证明 $l_0E_0 \le (1+o(1))l_1D(Q\|P)$。因此取 $\ell_0, \ell_1 \to \infty$，我们得出结论

$$E_0E_1 \le D(P\|Q)D(Q\|P)\,. \qquad \square$$

16.4 复合、稳健及拟合优度假设检验

在本章中，我们探讨了区分两种备择方案的情境，在这两种情况下，数据分布均已被完全指定。文献中还研究了多种其他情境，为了完整性，我们在此简要提及。

关键的偏离在于将我们在第14章开始时使用的简单假设替换为*composite*假设。即，我们假定

$$H_0 : X_i \overset{\text{i.i.d.}}{\sim} P, \quad P \in \mathcal{P} \qquad \text{vs} \qquad H_1 : X_i \overset{\text{i.i.d.}}{\sim} Q, \quad Q \in \mathcal{Q}\,,$$

其中 $\mathcal{P}$ 和 $\mathcal{Q}$ 是两个分布族。在这种情况下，对于给定的检验 $Z = Z(X_1,\dots,X_n) \in \{0,1\}$，我们如前定义两类错误，但需考虑分布中的最坏情况选择：

$$1-\alpha = \inf_{P\in\mathcal{P}} P^{\otimes n}[Z=0], \qquad \beta = \sup_{Q\in\mathcal{Q}} Q^{\otimes n}[Z=0]\,.$$

与检验简单假设（此时Neyman-Pearson检验是最优的，见定理14.11）不同，对于复合假设的最优检验，一般没有明确的描述（参见(32.28)）。普遍选择的是广义似然比检验（GLRT），它提出对GLR进行阈值化。

$$T(X^n) = \frac{\sup_{P\in\mathcal{P}} P^{\otimes n}(X^n)}{\sup_{Q\in\mathcal{Q}} Q^{\otimes n}(X^n)}\,.$$

关于GLRT在误差指数意义上的最优性的示例和反例，参见，例如[469]。

有时，族 $\mathcal{P}$ 和 $\mathcal{Q}$ 分别是围绕中心分布 P 和 Q 的小球（在某种度量下）。在这种情况下，将 $\mathcal{P}$ 与 $\mathcal{Q}$ 进行检验被称为 *robust hypothesis testing* (，因为该检验对数据分布的小偏差是稳健的)。在这种情况下，有一个值得注意的有限样本最优性结果，归功于 Huber [221]——见练习 III.31。渐近地，结果表明，如果 $\mathcal{P}$ 和 $\mathcal{Q}$ 在 Hellinger 距离下是分离的，那么错误概率可以做到指数级小：见定理 32.8。

在复合检验的设定中，有时 $\mathcal{P}$ 与 $\mathcal{Q}$ 之间的距离为零。例如，在最著名的 Student t 检验设定中就是这种情况：$\mathcal{P} = \{\mathcal{N}(0,\sigma^2) : \sigma^2 > 0\}$，$\mathcal{Q} = \{\mathcal{N}(\mu,\sigma^2) : \mu \neq 0, \sigma^2 > 0\}$。显然，在这种情况下，无法构造出具有 $\alpha+\beta<1$ 的检验，因为在 H_1 下的数据分布可以任意接近 P_0。因此，这里不是最小化最坏情况下的 β，而是试图找到一个检验统计量 $T(X_1,\dots,X_n)$，它 a) 是枢轴的，即其在 H_0 下的分布（渐近地）独立于选择 $P_0 \in \mathcal{P}$；并且

b) 一致的，即在任何 *fixed* $Q \in \mathcal{Q}$ 下 $T \to \infty$ 作为 $n \to \infty$。最优性问题通过最小化 β 作为 $Q \in \mathcal{Q}$ (（称为功效曲线)）的函数来研究。一致最强大检验是该领域的金标准[277，第3章]，尽管除了一些经典设置（如上所述）外，它们的存在性是未知的。

在其他设置中，称为 *goodness-of-fit testing* [277，第14章]，人们感兴趣的不是相对低复杂度的参数族 $\mathcal{P}$ 和 $\mathcal{Q}$，而是一个巨大的备择集合 $\mathcal{Q}$。例如，最简单的设置是区分 H_0: $X_i \overset{\text{i.i.d.}}{\sim} P_0$ 与 H_1: $X_i \overset{\text{i.i.d.}}{\sim} Q$, $\mathrm{TV}(P_0, Q) > \delta$。如果 $\delta = 0$，那么在这种情况下，对于任何检验，最坏情况又是 $\alpha + \beta = 1$，人们只能要求一个统计量 $T(X^n)$，其在 H_0 下具有已知分布，并且对于备择中的任何 Q，$T \to \infty$。对于 $\delta > 0$，该问题被称为非参数检测 [225，226]，并与属性测试 [192] 相关。

16.5* 通信约束下的假设检验

在本节中，我们考虑假设检验问题的一个变体，其中 Stein 指数的确定仍然是一个开放问题，除了在 [8] 中解决的特殊情况。具体来说，我们仍然考虑如 (14.14) 中那样的一对简单 iid 假设的情况，只不过这次 Y 样本对统计学家可用，而 X 样本需要通过一个（无噪声的）速率受限链路从远程位置传输:

$$\begin{aligned} H_0: &\ (X_1, Y_1), \dots, (Y_n, X_n) \overset{\text{i.i.d.}}{\sim} P_{X,Y} \\ H_1: &\ (X_1, Y_1), \dots, (Y_n, X_n) \overset{\text{i.i.d.}}{\sim} Q_{X,Y}, \end{aligned} \tag{16.15}$$

而测试器由一个X-压缩器$W = f(X^n)$组成，其中$W \in \{0,1\}^{nR}$和一个决策$P_{Z|W,Y^n}$。（设置的示意见图16.5。）我们的目标是确定Stein指数对速率R的依赖性，即

$$V_\epsilon(R) \triangleq \sup\{E : \exists n_0, \forall n \geq n_0, \exists (f, P_{Z|X^n}) \text{ s.t. } \alpha > 1 - \epsilon, \beta < \exp(-nE)\}.$$

满足上确界内约束的指数 E 被称为 ϵ-可达指数。

这个问题的重要性在于它强调了分布式统计问题中出现的一些新现象。尽管该问题仍未解决，且刻画Stein指数的主题已不再流行，但为这一问题开发的工具（即强数据处理不等式）非常重要，并在现代分布式推断问题中得到了许多应用（见第33章，特别是第33.11节以了解更多）。我们将在给出主要结果之后讨论这一点，为此我们引入一个关键的新概念。

定义 16.5（F_I-曲线[6]）给定一对随机变量（X, Y），我们定义它们的F_I曲线为

$$F_I(t; P_{X,Y}) \triangleq \sup\{I(U;Y) : I(U;X) \leq t, \quad U \to X \to Y\},$$

6 这个概念在[453]中被引入，关于“{v*}独立”版本，另见[136]和[345，第2.2节]。

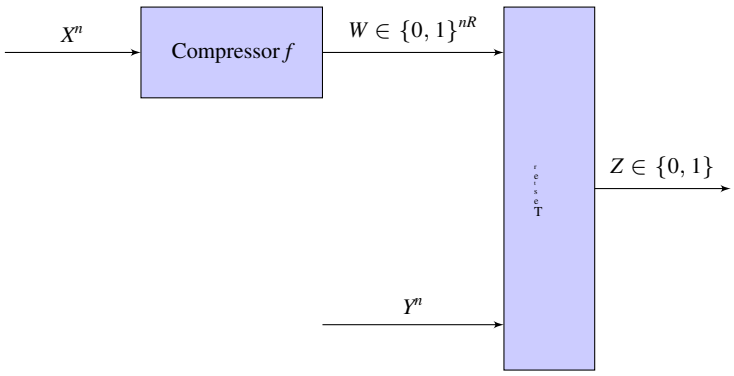


图16.5 通信约束下假设检验问题的示意图。

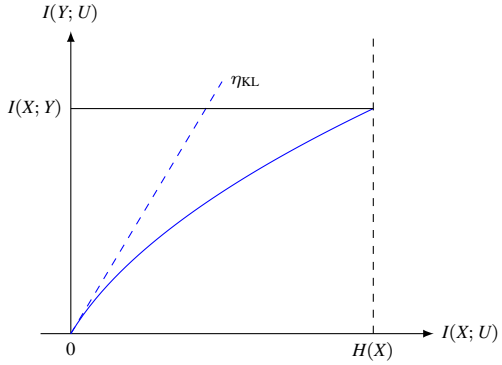


图16.6 一条典型的F_I曲线，其在零点的斜率为SDPI常数η_{KL}。

在所有满足$U \to X \to Y$马尔可夫关系的随机变量U上取上确界。

例16.1 一个典型的F_I曲线如图16.6所示。一般而言，计算F_I曲线是困难的。一个例外情况是$X \sim \mathrm{Ber}(1/2)$和$Y = \mathsf{BSC}_\delta(X)$。在这种情况下，应用练习I.64中的MGL，按照该练习的记号，我们得到

$$F_I(t) = \log 2 - h(h^{-1}(\log 2 - t) * \delta)$$

通过取 $U \sim \mathrm{Ber}(1/2)$ 和 $X = \mathsf{BSC}_p(U)$，并选择 p 使得 $h(p) = \log 2 - t$。

从DPI（3.12）我们知道，$F_I(t) \le t$ 和 F_I-曲线将DPI强化为 $I(U;X) \le F_I(I(U;$ 当 $U \to X \to Y$ 时，$Y))$。（注意 X 和 Y 的角色并不对称。）一般来说，如何计算这个函数并不清楚；然而，在练习III.32中我们表明，如果 X 在有限字母表上取值，那么只需考虑 $|\mathcal{U}| \le |\mathcal{X}| + 1$，因此 F_I 是有限维凸规划的一个值。关于 F_I-曲线的其他性质和应用可在练习III.32和III.33中找到。

本节的主要结果如下。

定理 16.6（Ahslwede-Csiszár [8]）*Suppose X, Y are ranging over the finite alphabets and $Q_{X,Y} = P_X P_Y$ (independence testing problem). Then $V_\epsilon(R) = F_I(R)$ for all $\epsilon \in (0, 1)$.*

该设置描述了检测两个序列之间相关性的问题。当 $R =$ 为0时，测试问题不可能解决，因为在两个假设下，Y 的边缘分布相同。如果仅有一个非常小的通信速率可用，则所需的样本量将会非常大（Stein指数很小）。

Proof. 让我们从一个上界开始。固定一个压缩器 W，并注意到对于任意 ϵ-可达指数 E，根据定理14.8，我们有

$$d(1-\epsilon\|\exp\{-nV_\epsilon\}) \le D(P_{W,Y^n}\|Q_{W,Y^n})\,.$$

但在定理条件下，我们有 $Q_{W,Y^n} = P_W P_{Y^n}$，从而如(14.18)中那样得到：

$$(1-\epsilon)nE \le D(P_{W,Y^n}\|P_W P_{Y^n}) + \log 2 = I(W;Y^n) + \log 2\,.$$

现在，从观察图16.5中我们得知$W \to X^n \to Y^n$，并且根据练习III.32（张量化）我们了解

$$I(W;Y^n) \le nF_I(\frac{1}{n}I(W;X^n)) \le nF_I(R)\,.$$

因此，我们已经证明对于所有足够大的 n

$$E \le \frac{F_I(R)}{1-\epsilon} + \frac{\log 2}{n}\,.$$

这表明了$\limsup_{\epsilon\to 0} V_\epsilon \le F_I(R)$。对于$V_\epsilon \le F_I(R)$的更强论断，即强逆定理，参见[8]。

现在，对于构造性部分，考虑任意 n_1 和任意压缩随机变量 $W_1 = f_1(X^{n_1})$，其中 $W_1 \in \{0,1\}^{n_1 R}$。给定块长度 n，我们可以通过独立压缩每个 n_1 块来重复发送 W_1（总共 n/n_1 “帧”）。然后解压器将观察到 n/n_1 个独立同分布的 W_1 副本以及 Y^{n_1} 向量观测。注意 $D(P_{W_1,Y^{n_1}}\|Q_{W_1,Y^{n_1}}) = I(W_1;\, Y^{n_1})$ 如上所述。因此，根据定理14.14，我们应该能够达到 $\alpha \ge 1-\epsilon$ 和 $\beta \le \exp\{-n/n_1 I(W_1;\, Y^{n_1})\}$。

因此，我们得到了以下下界（在优化了 W_1 的选择以及将 n_1 再次替换为更方便的块长度 n 之后）：

$$V_\epsilon \ge \tilde{F}_I(R) \triangleq \sup_{n,W_1}\{\frac{1}{n}I(W_1;Y^n) : W_1 \to X^n \to Y^n, W_1 \in \{0,1\}^{nR}\}\,. \tag{16.16}$$

这看起来与（张量化的）F_I曲线的定义非常相似，只是约束在于W_1的基数而非$I(W_1;\, X^n)$。事实证明这两个量是一致的，即$\tilde{F}_I(R) = F_I(R)$。我们只需为此证明$\tilde{F}_I(R) \ge F_I(R)$。

为此，考虑任意 $U \to X \to Y$ 和 $R > I(U;\, X)$。我们应用覆盖引理（推论 25.6）和马尔可夫引理（命题 25.7），其中我们设定 $A^n = X^n$、$B^n = U^n$、$X^n = Y^n$。

总体而言，我们得到当 $n \to \infty$ 时，存在编码器 $W_1 = f_1(X^n)$、$W_1 \in \{0,1\}^{nR}$ 使得 $W_1 \to X^n \to Y^n$ 且

$$I(W_1; Y^n) \geq nI(U;Y) + o(n)\,.$$

通过优化 U 的选择，这证明了 $\tilde{F}_I(R+) \geq F_I(R)$。由于（如我们上面所示）$\tilde{F}_I(R+) \leq F_I(R+)$ 和 $F_I(R+) = F_I(R)$ (练习 III.32)，我们得出 $\tilde{F}_I(R) = F_I(R)$。 □

上述定理对现代机器学习中的某些任务具有有趣的意义。考虑这样一种情况：样本量 n 巨大，但通信预算（或内存带宽）受限，因此我们最多只能从 X 个终端向测试器传递 k 比特。那么，最优检验的速率 $R = \frac{k}{n} \ll 1$ 和错误概率 β 大致为

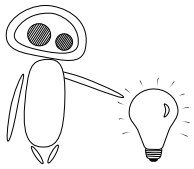
$$\beta \approx 2^{-nF_I(k/n)} \approx 2^{-kF_I'(0)}\,,$$

其中我们使用了 $F_I(k/n) \approx \frac{k}{n}F_I'(0)$ 这一事实。我们看到错误概率呈指数衰减 *with the number of communicated bits*，而非样本量。在许多方面，定理16.6预示了过去十年中关于分布式推断的各种结果。我们将在专门讨论强数据处理不等式（SDPI）的第33章回到这个话题。有一个简单的关系将经典结果（本节）与通过SDPI的现代方法（第33章）联系起来：斜率 $F_I'(0)$ 正是SDPI常数：

$$F_I'(0) = \eta_{\mathrm{KL}}(P_X, P_{Y|X})\,,$$

见 (33.14) 中 η_{KL} 的定义。本质上，SDPI 只是如图 16.6 所示的 F_I 曲线的线性化版本。

第三部分练习



III.1 设 P_0 和 P_1 是 $\mathcal{X}$ 上的分布。回忆一下，通过随机检验 $P_{Z|X}: \mathcal{X} \to \{0,1\}$ 可达到的配对 $(P_0[Z=0], P_1[Z=0])$ 的区域 被记为

$$\mathcal{R}(P_0, P_1) \triangleq \bigcup_{P_{Z|X}} (P_0[Z=0], P_1[Z=0]) \subseteq [0,1]^2 .$$

(a) 令 $P_{Y|X}$： $\mathcal{X} \to \mathcal{Y}$ 为一个马尔可夫核，它根据 $P_j \xrightarrow{P_{Y|X}} Q_j$，$j=0,1$将 P_j 映射到 Q_j。比较区域$\mathcal{R}(P_0,P_1)$ 和$\mathcal{R}(Q_0,Q_1)$。这对$\beta_\alpha(P_0,P_1)$ 与$\beta_\alpha(Q_0,Q_1)$有何说明?

(b*) 证明 $\mathcal{R}(P_0,P_1) \supset \mathcal{R}(Q_0,Q_1)$ 蕴含存在某个 $P_{Y|X}$ 将 P_0 映射到 Q_1，将 P_1 映射到 Q_1。换言之，$\mathcal{R}$ 的包含等价于退化或 Blackwell 序（见定义 33.15）。

Comment: 这是数据处理不等式最一般的形式，其他所有形式（散度、互信息、f-散度、全变差、Rényi散度等）都是它的推论。

III.2 考虑以下二元假设检验（BHT）问题。在两种假设下，X 和 Y 都在 $\{0,1\}$ 上均匀分布。然而，在 H_0 下，X 和 Y 是独立的，而在 H_1 下:

$$\mathbb{P}_1[X \neq Y] = \delta < 1/2 .$$

对于这个问题:

(a) 画出所有随机检验 $P_{Z|XY}$: $\mathcal{X} \times \mathcal{Y} \to \{0,1\}$ 下可实现值对 $(\mathbb{P}_0[Z=0], \mathbb{P}_1[Z=0])$ 的区域 $\mathcal{R}(P_0,P_1)$。

(b) 找出充分统计量，并在更小的字母表上定义一个等价的BHT问题。

(c) 令 P_{F_i}、$i \in \{0,1\}$ 为 $X \sim P_i$ 下对数 $\frac{P_0(X)}{P_1(X)}$ 的分布。分布 P_{F_0}, P_{F_1} 是什么? 如何从 $\mathcal{R}(P_0,P_1)$ 中读出它们?

(d) 当满足以下条件时，计算贝叶斯设置中的最小误差概率:

$$\mathbb{P}[H_1] = 1 - \mathbb{P}[H_0] = \pi_1 .$$

识别 $\mathcal{R}(P_0,P_1)$ 上的对应点。

(e) 计算非贝叶斯极小极大设置下的最小错误概率:

$$\min \max\{\mathbb{P}_0[\text{decide } H_1], \mathbb{P}_1[\text{decide } H_0]\} ,$$

其中最小值取自各测试，最大值取自花括号中的两个数之间。

识别出{v*}上的对应点。

III.3 考虑 [0,3] 上的分布 P 和 Q，其密度如图 16.7 所示。

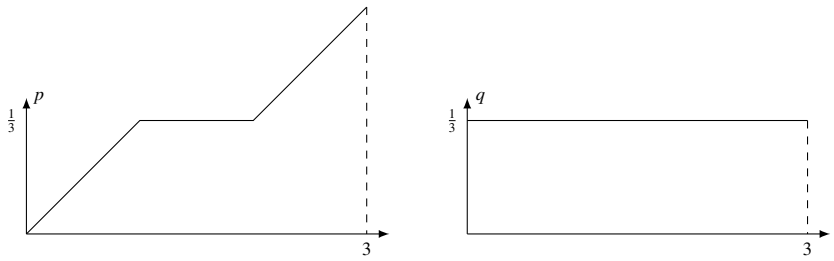


图16.7 练习III.3中P和Q的密度。

(a) 计算表达式 $\beta_\alpha(P,Q)$。(b) 绘制区域 $\mathcal{R}(P,Q)$。(c) 分别指定对于 $\alpha = 5/6$ 和 $\alpha = 1/2$ 实现 β_α 的测试。

III.4 令 P 为区间 $[0,1]$ 上的均匀分布。令 Q 为 $[0,1/2]$ 上的均匀分布与 1 处的点质量的等比例混合。

(a) 计算区域 $\mathcal{R}(P,Q)$。(b) 明确描述达到最优边界 $\beta_\alpha(P,Q)$ 的测试。

III.5 (a) 考虑二元假设检验:

$$H_0 : X \sim \mathcal{N}(0,1) \text{ vs } H_1 : X \sim \mathcal{N}(\mu,1).$$

计算并绘制Neyman-Pearson区域 $\mathcal{R}(\mathcal{N}(0,1),\mathcal{N}(\mu,1))$。

(b) 现在假设我们有 n 个样本，我们想要检验

$$H_0 : X_1,\dots,X_n \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0,1) \text{ vs } H_1 : X_1,\dots,X_n \overset{\text{i.i.d.}}{\sim} \mathcal{N}(\mu,1).$$

计算内曼-皮尔逊区域 $\mathcal{R}(\mathcal{N}(0,1)^n,\mathcal{N}(\mu,1)^n)$。随着样本量的增加，描述该区域如何演变并给出解释。*Hint: Consider sufficient statistics.*

三.6 (a) 考虑二元假设检验:

$$H_0 : X \sim \text{Exp}(1) \text{ vs } H_1 : X \sim \text{Exp}(\lambda),$$

其中 Exp(λ) 具有密度 $\lambda e^{-\lambda x}1\{x \ge 0\}$。计算区域 $\mathcal{R}(\text{Exp}(1), \text{Exp}(\lambda))$。实现 β_α 的最优检验是什么?

(b) 现在假设我们有n个样本，我们想要测试

$$H_0 : X_1,\dots,X_n \overset{\text{i.i.d.}}{\sim} \text{Exp}(1) \text{ vs } H_1 : X_1,\dots,X_n \overset{\text{i.i.d.}}{\sim} \text{Exp}(\lambda).$$

计算区域 $\mathcal{R}(\text{Exp}(1)^n, \text{Exp}(\lambda)^n)$。随着样本量的增加，描述该区域如何演变并给出解释。实现 β_α 的最佳检验是什么? III.7 (a) 证明 $\text{TV}(P,Q) = \sup_{0\le\alpha\le1}\{\alpha - \beta_\alpha(P,Q)\}$。解释如何从区域 $\mathcal{R}(P,Q)$ 读取值 $\text{TV}(P,Q)$。它是否等于 $\mathcal{R}(P,Q)$ 中最大垂直段的一半?

(b)（贝叶斯准则）固定一个先验 $\pi = (\pi_0,\pi_1)$，使得 $\pi_0 + \pi_1 = 1$ 且 $0 < \pi_0 < 1$。将最优平均错误概率记为 $P_e \triangleq \inf_{P_{Z|X}} \pi_0\pi_{1|0} + \pi_1\pi_{0|1}$。证明若 $\pi = (\frac{1}{2},\frac{1}{2})$，则 $P_e = \frac{1}{2}(1 - \text{TV}(P,Q))$。求最优检验。

(c) 对于一般先验 π (不一定等概率)，找到最优检验。
(d) 证明只需关注确定性测试即可最小化贝叶斯错误概率。

III.8 函数 $\alpha \mapsto \beta_\alpha(P,Q)$ 是单调的，因此根据勒贝格定理，它具有导数

$$\beta'_\alpha \triangleq \frac{d}{d\alpha}\beta_\alpha(P,Q)\,.$$

几乎处处在[0, 1]上。证明

$$D(P\|Q) = -\int_0^1 \log \beta'_\alpha \, d\alpha\,. \tag{III.1}$$

III.9 设 P, Q 为分布，使得对所有 $\alpha \in [0,1]$，我们有

$$\beta_\alpha(P,Q) \triangleq \min_{P_{Z|X}: P[Z=0]\geq\alpha} Q[Z=0] = \alpha^2\,.$$

求出TV(P,Q)、$D(P\|Q)$和$D(Q\|P)$。

III.10 我们已经证明，对于测试独立同分布产品及任意固定的 $\epsilon \in (0,1)$：

$$\log \beta_{1-\epsilon}(P^n, Q^n) = -nD(P\|Q) + o(n)\,, \qquad n \to \infty\,,$$

这等价于斯坦引理（定理14.14）。进一步证明，在假设$V(P\|Q) < \infty$下，我们有

$$\log \beta_{1-\epsilon}(P^n, Q^n) = -nD(P\|Q) + \sqrt{nV(P\|Q)}Q^{-1}(\epsilon) + o(\sqrt{n})\,, \tag{III.2}$$

其中 $Q^{-1}(\cdot)$ 是 $Q(x) = \int_x^\infty \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt$ 的函数逆，并且

$$V(P\|Q) \triangleq \mathrm{Var}_P\left[\log \frac{dP}{dQ}\right]\,.$$

III.11（似然比技巧）给定 $\mathcal{X}$ 上的两个分布 P 和 Q，我们如下生成独立同分布样本 (X_i, Y_i)：首先 $Y_i \sim$ 服从 Ber(1/2)，然后如果 $Y_i = 0$，我们采样 $X_i \sim Q$，否则采样 $X_i \sim P$。接下来我们训练一个分类器以最小化交叉熵损失：

$$\hat{p}^* = \operatorname*{argmin}_{\hat{p}:\mathcal{X}\to[0,1]} \frac{1}{n}\sum_{i=1}^n Y_i \log\frac{1}{\hat{p}(X_i)} + (1-Y_i)\log\frac{1}{1-\hat{p}(X_i)}\,.$$

证明 $\frac{1-\hat{p}^*(x)}{\hat{p}^*(x)} \to \frac{dP}{dQ}(x)$ 如同 $n \to \infty$。这个技巧在机器学习中用于近似复杂高维分布的 $\frac{dP}{dQ}$。

III.12 证明

$$\min_{Q_{Y^n}\in\mathcal{F}} D(Q_{Y^n}\|\prod_{j=1}^n P_{Y_j}) = \min\sum_{j=1}^n D(Q_{Y_j}\|P_{Y_j})$$

只要约束集 {v*} 基于边际，即：

$$Q_{Y^n} \in \mathcal{F} \quad \Longleftrightarrow \quad (Q_{Y_1}, \ldots, Q_{Y_n}) \in \mathcal{F}'$$

对于某个$\mathcal{F}'$。
得出结论：当$P_{Y_j} = P$且

$$\mathcal{F} = \left\{ Q_{Y^n} : \mathbb{E}_Q \left[\sum_{j=1}^{n} f(Y_j) \right] \geq n\gamma \right\}$$

我们有单字母化：

$$\min_{Q_{Y^n}} D(Q_{Y^n} \| P^n) = n \min_{Q_Y : \mathbb{E}_{Q_Y}[f(Y)] \geq \gamma} D(Q_Y \| P) \,,$$

的其中（15.15）是一个特例。提示：散度的凸性　　策。

III.13 在有限集 $\mathcal{X}$ 上固定一个分布 P_X 和一个信道 $P_{Y|X} : \mathcal{X} \to \mathcal{Y}$。考虑一个具有组成 P_X 的序列 x^n，即

$$\#\{j : x_j = a\} = nP_X(a) \pm 1 \qquad \forall a \in \mathcal{X} \,.$$

令 Y^n 根据 $P_{Y|X}^{\otimes n}(\cdot|x^n)$ 生成。证明

$$\log \mathbb{P}\left[\sum_{j=1}^{n} f(X_j, Y_j) \geq n\gamma \middle| X^n = x^n \right] = -n \min_{\mathbb{E}_Q[f(X,Y)] \geq \gamma} D(Q_{Y|X} \| P_{Y|X} | P_X) + o(n) \,,$$

其中最小值是在所有满足 $Q_X = P_X$ 的 $Q_{X,Y}$ 上取得的。

III.14（边界上的大偏差）回忆一下，$A = \inf_\lambda \psi_X'(\lambda)$ 和 $B = \sup_\lambda \psi_X'(\lambda)$ 被证明是 P_X 支撑集的边界，例如 $B = \sup\{b : \mathbb{P}[X > b] > 0\}$。

(a) 通过示例展示 $\psi_X^*(B)$ 可以是有限的或无限的。(b)
通过示例展示

$$\mathbb{P}\left[\frac{1}{n} \sum_{i=1}^{n} X_i \geq B \right] \,, \tag{III.3}$$

可能会因P_X的分布而有很大差异。

(c) 对于你的例子，比较 $\Psi_X^*(B)$ 和 (III.3) 中的指数。证明一个一般性陈述（你可以假设对于所有 $\lambda \in \mathbb{R}$，$\psi_X(\lambda) < \infty$）。

III.15（简易雷达）正在构建一个二进制信号检测器。当发送信号 A 时，接收到一个独立同分布的序列 $X_j \sim \mathcal{N}(-1, 1)$。当发送信号 B 时，接收到一个序列 $X_j \sim \mathcal{N}(+1, 1)$。给定极大量 n 的观测值（$X_1, \ldots, X_n$），提出一个用于在 A 和 B 之间进行判定的检测器。考虑两个不同的设计情形：

(a) 将 A 误检测为 B，或将 B 误检测为 A，两者的后果同样严重。
(b) 在10^{-3}个案例中，将A误判为B是可以接受的，但应尽可能避免相反的情况。

III.16（小球概率 I。）设 $Z \sim \mathcal{N}(0, I_d)$。不使用 χ^2-密度，证明关于 $\mathbb{P}[\|Z\|_2 \leq \epsilon]$ 的以下界。

(使用切尔诺夫界，证明对于所有 $\epsilon > \sqrt{d}$,

$$\mathbb{P}\left[\|Z\|_2 \le \epsilon\right] \le \left(\frac{e\epsilon^2}{d}\right)^{d/2} e^{-\epsilon^2/2}.$$

(b) 证明下界

$$\mathbb{P}\left[\|Z\|_2 \le \epsilon\right] \ge \left(\frac{\epsilon^2}{2\pi d}\right)^{d/2} e^{-\epsilon^2/2}.$$

(c) 将结果扩展到 $Z \sim \mathcal{N}(0, \Sigma)$。

关于无限维的一个例子，请参见练习V.30。

III.17 考虑假设检验问题：

$$H_0 : X_1, \ldots, X_n \overset{\text{i.i.d.}}{\sim} P = \text{Ber}(1/3)\,,$$
$$H_1 : X_1, \ldots, X_n \overset{\text{i.i.d.}}{\sim} Q = \text{Ber}(2/3)\,.$$

(a) 计算斯坦因指数。

(b) 使用特征描述 $E_0(\theta) = \psi_P^*(\theta)$ 和 $E_1(\theta) = \psi_P^*(\theta) - \theta$ 计算可实现误差指数对 (E_0, E_1) 的权衡区域 $\mathcal{E}$。以显式形式表示最优边界（消除参数）。

(c) 识别从 P 到 Q 的最小散度测地线 $P^{(\lambda)}$，$\lambda \in [0, 1]$。验证 (E_0, E_1) $= (D(P^{(\lambda)}\|P), D(P^{(\lambda)}\|Q))$, $0 \le \lambda \le 1$ 给出相同的权衡曲线。

(d) 计算切尔诺夫指数。

III.18 令 $\gamma(a, c)$ 表示具有形状参数 a 和尺度参数 c 的 Gamma 分布：

$$\gamma(a, c)(dx) = \frac{(cx)^{a-1}e^{-cx}}{\Gamma(a)} c\, dx\,.$$

考虑一个假设检验问题：

$$H_0 : X_1, \ldots, X_n \text{ -i.i.d. } \sim P_0 = \exp(1)\,, \tag{III.4}$$
$$H_1 : X_1, \ldots, X_n \text{ -i.i.d. } \sim P_1 = \gamma(a, c = 1)\,. \tag{III.5}$$

问题：

(a) 计算 Stein 指数 (b) 对于 $a = 3$，绘制可达误差指数对 (E_0, E_1) 的权衡区域 $\mathcal{E}$。

(c) 确定从 P_0 到 P_1，$\lambda \in [0, 1]$ 的散度最小化测地线 P_λ。

提示：为了简化计算，尝试在u中对以下恒等式进行微分

$$\int_0^\infty x^u e^{-x} dx = \Gamma(u + 1)\,.$$

III.19 考虑假设检验问题：

$$H_0 : X_1, \ldots, X_n \overset{\text{i.i.d.}}{\sim} P = \mathcal{N}(0, 1)\,,$$
$$H_1 : X_1, \ldots, X_n \overset{\text{i.i.d.}}{\sim} Q = \mathcal{N}(\mu, 1)\,.$$

((a) 证明斯坦因指数为 $V = \frac{\log e}{2}\mu^2$。(b) 证明可达到的错误指数对 (E_0, E_1) 之间的最优权衡由下式给出

$$E_1 = \frac{\log e}{2}(\mu - \sqrt{2E_0})^2, \quad 0 \le E_0 \le \frac{\log e}{2}\mu^2,$$

(c) 证明切尔诺夫指数是 $C(P, Q) = \frac{\log e}{8}\mu^2$。

III.20 设 U_j 在 [0, 1] 上独立同分布且均匀，证明/反驳

$$\mathbb{P}\left[\sum_{j=1}^{n} U_j \ge n\gamma\right], \qquad \gamma = \frac{1}{e-1} \approx 0.582$$

以指数速度快速收敛到零，随$n \to \infty$变化。如果确实如此，则找出指数。对$\gamma = 0.5$重复此过程。

III.21 令 X_j 为独立同分布的指数分布，均值为单位值。由于对数矩生成函数 $\psi_X(\lambda) \triangleq \log \mathbb{E}[\exp\{\lambda X\}]$ 在 $\lambda > 1$ 时不存在，因此大偏差结果见定理15.1

$$\mathbb{P}[\sum_{j=1}^{n} X_j \ge n\gamma] = \exp\{-n\psi_X^*(\gamma) + o(n)\} \tag{III.6}$$

不适用。通过以下步骤直接展示 (III.6):

(a) 直接应用切尔诺夫论证来证明一个上界。

(b) 固定任意 $c > 0$，并证明

$$\mathbb{P}[\sum_{j=1}^{n} X_j \ge n\gamma] \ge \mathbb{P}[\sum_{j=1}^{n} (X_j \wedge c) \ge n\gamma]\,. \tag{III.7}$$

(c) 应用第15章所示结果来研究(III.7)右侧的渐近性。(d) 通过取$c \to \infty$来完成(III.6)的证明。

III.22（Hoeffding引理）在本练习中，我们证明Hoeffding引理（在定义4.15后陈述）并推导Hoeffding集中不等式。设$X \in [-1, 1]$，其中$\mathbb{E}[X] = 0$。

(a) 证明对数矩生成函数 $\psi_X(\lambda)$ 满足 $\psi_X(0) = \psi_X'(0) = 0$ 且 $0 \le \psi_X''(\lambda) \le 1$。（提示：应用定理15.8(c)以及任何支撑在$[-1, 1]$上的分布的方差至多为1这一事实。）(b) 通过泰勒展开，证明 $\psi_X(\lambda) \le \lambda^2/2$。(c) 应用定理15.1，证明霍夫丁不等式：令 X_i 为 X 的独立同分布副本。对于任意 $\gamma > 0$，$\mathbb{P}\left[\sum_{i=1}^{n} X_i \ge n\gamma\right] \le \exp(-n\gamma^2/2)$。

III.23（离散 $\mathcal{X}$ 的 Sanov 定理）设 $\mathcal{X}$ 为一个有限集。设 $\mathcal{E}$ 为 $\mathcal{X}$ 上具有非空内部的一族概率分布。设 $X^n = (X_1, \ldots, X_n)$ 为从某个在 $\mathcal{X}$ 上完全支撑的分布 P 中独立同分布抽取的样本，并设 π_n 表示经验分布，即 $\pi_n = \frac{1}{n}\sum_{i=1}^{n} \delta_{X_i}$。我们的目标是证明

$$E \triangleq \lim_{n\to\infty} \frac{1}{n} \log \frac{1}{P(\pi_n \in \mathcal{E})} = \inf_{Q \in \mathcal{E}} D(Q\|P). \tag{III.8}$$

(a) 我们首先假设 $\mathcal{E}$ 是凸的。定义以下联合分布集合 $\mathcal{E}_n \triangleq \{Q_{X^n}\colon\ Q_{X_i} \in \mathcal{E}, i = 1, \ldots, n\}$。证明

$$\inf_{Q_{X^n} \in \mathcal{E}_n} D(Q_{X^n} \| P_{X^n}) = n \inf_{Q \in \mathcal{E}} D(Q\|P),$$

其中 $P_{X^n} = P^n$。

(b) 考虑条件分布 $\tilde{P}_{X^n} = P_{X^n|\pi_n \in \mathcal{E}}$。证明 $\tilde{P}_{X^n} \in \mathcal{E}_n$。

(c) 证明以下非渐近上界：对于任意凸的 $\mathcal{E}$,

$$P(\pi_n \in \mathcal{E}) \le \exp\Big(-n \inf_{Q \in \mathcal{E}} D(Q\|P)\Big), \quad \forall n.$$

(显示对于任意 $\mathcal{E}$ 的 d)：

$$P(\pi_n \in \mathcal{E}) \le \exp\Big(-n \inf_{Q \in \mathcal{E}} D(Q\|P) + o(n)\Big), \quad \forall n.$$

(提示：对每个 $\epsilon > > 0$，用有限个半径为 ϵ 的 N 电视球覆盖 $\mathcal{E}$；参见定理27.3。应用前一部分和并集界。)

(e) 对于 $\mathcal{E}$ 内部的任意 Q，证明

$$P(\pi_n \in \mathcal{E}) \ge \exp(-nD(Q\|P) + o(n)), \quad n \to \infty.$$

(提示：使用与证明大偏差定理15.9相同的数据处理方法。)

(f) 根据有限字母表上散度的连续性（命题4.8）得出结论(III.8)。

III.24（数据压缩的误差指数）设 X^n 根据 P 在有限字母表 $\mathcal{X}$ 上独立同分布。设 $\epsilon^*(X^n, nR)$ 表示对于压缩率 R (的 X^n，固定长度压缩器和解压缩器所达到的最小错误概率，参见定义11.1)。我们知道若 $R < H(P)$，则 $\epsilon^*(X^n, nR) \to 0$。这里我们证明它以指数速度收敛到零并求出该指数。

(a) 对任意序列 x^n，用 $\hat{P}_{x^n}$ 表示其经验分布，用 $H(\hat{P}_{x^n})$ 表示其经验熵，即经验分布的熵。例如，对于二元序列 $x^n = (010110)$，经验分布为 Ber(1/2)，经验熵为 1 bit。对每个 $R > 0$，定义集合 $T = \{x^n\colon\ H(\hat{P}_{x^n}) < R\}$。证明 $|T| \le \exp(nR)(n+1)^{|\mathcal{X}|}$。(b) 证明对任意 $R > H(P)$，$\epsilon^*(X^n, nR) \le \exp\Big(-n \inf_{Q: H(Q) > R} D(Q\|P)\Big)$。指定可达性方案。（提示：使用习题 III.23 中的 Sanov 定理。）(c) 证明上述指数是渐近最优的：

$$\limsup_{n \to \infty} \frac{1}{n} \log \frac{1}{\epsilon^*(X^n, nR)} \le \inf_{Q: H(Q) > R} D(Q\|P).$$

(提示：回想一下，对于无记忆源，任何速率低于熵的压缩方案失败的概率趋向于1。利用数据处理不等式。)

III.25（局部 KL 测地线）回顾第 2.6.1 节*中的局部展开 $D(\lambda Q + (1-\lambda)P\|P) = \frac{\lambda^2}{2}\chi^2(Q\|P) + o(\lambda^2)$，前提是 $\chi^2(Q\|P) < \infty$。代替线性混合，考虑几何混合 $P_\lambda \propto Q^\lambda P^{1-\lambda}$，我们在 (15.30) 中论证过它应被称为“KL 测地线”。证明

(a) $D(P_\lambda\|P) = -\psi_P(\lambda) + \lambda\psi_P'(\lambda)$，其中 $\psi_P(\lambda) =$ 记录 $\mathbb{E}_P[\exp(\lambda$ 记录 $\frac{dQ}{dP})]$。

(b) 陈述得出$D(P_\lambda\|P) = \frac{1}{2}\lambda^2\psi_P''(0)+o(\lambda^2)$的适当条件，其中$\psi_P''(0) = \mathrm{Var}_P[\log\frac{dQ}{dP}]$，这显然不同于$\chi^2(Q\|P) = \mathrm{Var}_P[\frac{dQ}{dP}]$。

III.26 用 $\mathcal{N}(\mu,\sigma^2)$ 表示均值为 μ、方差为 σ^2 的一维高斯分布。令 $a > 0$。以下所有对数均为自然对数。

(a) 证明

$$\min_{Q:\mathbb{E}_Q[X]\geq a} D(Q\|\mathcal{N}(0,1)) = \frac{a^2}{2}.$$

(b) 令 $X_1,\ldots,X_n$ 独立同分布地从 $\mathcal{N}(0,1)$ 中抽取。利用（a）部分证明

$$\lim_{n\to\infty}\frac{1}{n}\log\frac{1}{\mathbb{P}[X_1+\cdots+X_n\geq na]} = \frac{a^2}{2}. \tag{III.9}$$

(c) 令 $\bar{\Phi}(x) = \int_x^\infty \frac{1}{\sqrt{2\pi}}e^{-t^2/2}dt$ 表示标准高斯分布的互补累积分布函数。用 $\bar{\Phi}$ 函数表达 $\mathbb{P}[X_1+\cdots+X_n\geq na]$。利用 $\bar{\Phi}(x) = e^{-x^2/2+o(x^2)}$ 当 $x\to\infty$ (时的事实，参见练习 V.25) ，重新证明 (III.9)。

(d) （反向 *I*-投影）设 Y 为均值为零、方差为 1 的连续随机变量。证明

$$\min_{\mu,\sigma} D(P_Y\|\mathcal{N}(\mu,\sigma^2)) = D(P_Y\|N(0,1)).$$

III.27（为什么温度会均衡？）设 $\mathcal{X}$ 为有限字母表，$f:\ \mathcal{X}\to\mathbb{R}$ 为任意函数。设 $E_{\min} =$ 为 $f(x)$ 的最小值。

(a) 使用*I*-投影 证明对于任意$E\geq E_{\min}$，解为

$$H^*(E) = \max\{H(X) : \mathbb{E}[f(X)]\leq E\}$$

由 Gibbs 分布给出（参见（5.21））$P_X(x) = \frac{1}{Z(\beta)}e^{-\beta f(x)}$ 对于某个 $\beta = \beta(E)$。

Comment: 在统计物理中，x 是系统的状态（例如所有分子的位置和速度），$f(x)$ 是系统在状态 x 下的能量，P_X 是吉布斯分布，$\beta = \frac{1}{T}$ 是系统的逆温度。在热力学平衡下，$P_X(x)$ 给出系统处于状态 x 的时间占比。

(b) 证明 $\frac{dH^*(E)}{dE} = \beta(E)$。

(c) 接下来考虑两个函数 f_0, f_1 (，即两种具有不同状态-能量关系) 的分子类型。证明对于 $E\geq \min_{x_0} f_0(x_0) + \min_{x_1} f_1(x_1)$，我们有

$$\max_{\mathbb{E}[f0(X_0)+f_1(X_1)]\leq E} H(X_0,X_1) = \max_{E_0+E_1\leq E} H_0^*(E_0) + H_1^*(E_1) \tag{III.10}$$

其中 $H_j^*(E) =$ 最大值$_{\mathbb{E}[f_j(X)]\leq E} H(X)$。

(d) 进一步证明，在 (III.10) 中对于 E_0 和 E_1 的最优选择，我们有

$$\beta_0(E_0) = \beta_1(E_1) \tag{III.11}$$

或者等价地，最优分布P_{X_0,X_1}由下式给出

$$P_{X_0,X_1}(a,b) = \frac{1}{Z_0(\beta)Z_1(\beta)}e^{-\beta(f_0(a)+f_1(b))} \tag{III.12}$$

Remark: (III.12) 也只需通过取 $f(x_0, x_1) = f_0(x_0) + f_1(x_1)$ 从 (a) 部分得出。此处的要点是关系式 (III.11)：当两个热力学系统相互接触时，能量在它们之间以使得 β 参数（温度）相等的方式分布。

III.28（重要性采样[90]）设μ和ν为集合$\mathcal{X}$上的两个概率测度。假设$\nu \ll \mu$。设$L = D(\nu\|\mu)$和$\rho = \frac{d\nu}{d\mu}$为Radon-Nikodym导数。设f: $\mathcal{X} \to \mathbb{R}$为可测函数。我们希望利用来自$\mu$的数据来估计$\mathbb{E}_\nu f$。

令 $X_1, \ldots, X_n \overset{\text{i.i.d.}}{\sim} \mu$ 和 $I_n(f) = \frac{1}{n}\sum_{1\le i\le n} f(X_i)\rho(X_i)$。证明以下内容。

(a) 对于 $t \ge$ 为 0 时的 $n \ge \exp(L + t)$，我们有

$$\mathbb{E}\,|I_n(f) - \mathbb{E}_\nu f| \le \|f\|_{L^2(\nu)} \left(\exp(-t/4) + 2\sqrt{\mathbb{P}_\mu(\log\rho > L + t/2)}\right).$$

Hint: 设 $h = f1\{\rho \le \exp(L + t/2)\}$。分别使用三角不等式并给出 $\mathbb{E}\,|I_n(h) - \mathbb{E}_\nu h|$、$\mathbb{E}\,|I_n(h) - I_n(f)|$、$|\mathbb{E}_\nu f - \mathbb{E}_\nu h|$ 的界。

(b) 另一方面，对于 $n \le \exp(L - t)$，其中 $t \ge 0$，我们有

$$\mathbb{P}(I_n(1) \ge 1 - \delta)| \le \exp(-t/2) + \frac{\mathbb{P}_\mu(\log\rho \le L - t/2)}{1 - \delta},$$

对于所有$\delta \in (0, 1)$，其中 1 是常数 1 函数。

Hint: 根据 $\max_{1\le i\le n}\rho(X_i) \le$ 是否等于 $\exp(L - t/2)$ 分为两种情况。

这表明大小为 $\exp(D(\nu\|\mu) + \Theta(1))$ 的样本对于通过重要性采样进行准确估计既是必要的也是充分的。

III.29 (M元假设检验)[7] 以下结果[274]将关于检验两个假设的最佳平均错误概率的推论16.2推广至多个假设。

固定一组分布 $\{P_1, \ldots, P_M\}$。在给定 θ 的条件下，其以概率 $\pi_i >$ 取值为 i，对于 $i = 1, \ldots, M$ 为 0，令 $X_1, \ldots, X_n \overset{\text{i.i.d.}}{\sim} P_\theta$。将最优平均错误概率记为 $p_n^* = \inf \mathbb{P}[\hat\theta \ne \theta]$，其中下确界取自所有决策规则 $\hat\theta = \hat\theta(X_1, \ldots, X_n)$。

(a) 证明

$$\lim_{n\to\infty} \frac{1}{n} \log \frac{1}{p_n^*} = \min_{1\le i<j\le M} C(P_i, P_j), \tag{III.13}$$

其中 C 是 (16.2) 中定义的切尔诺夫信息。

(b) 显然，最优决策规则是最大后验概率（MAP）规则。最大似然规则是否也能达到最优指数（III.13）？ 证明或反驳。III.30 给定 n 个观测（X_1, Y_1）, ..., (X_n, Y_n)，其中每个观测由一对随机变量组成，我们要检验以下假设：

$$H_0 : (X_i, Y_i) \overset{\text{i.i.d.}}{\sim} P \otimes Q$$
$$H_1 : (X_i, Y_i) \overset{\text{i.i.d.}}{\sim} Q \otimes P$$

[7] Not to be confused with multiple testing in the statistics literature, which refers to testing multiple pairs of binary hypotheses simultaneously.

其中 $\otimes$ 像往常一样表示乘积分布。

(a) 证明 Stein 指数 $D(P\otimes Q\|Q\otimes P)$ 等于 $D(P\|Q)+D(Q\|P)$。

(b) 证明切尔诺夫指数（切尔诺夫信息）$C(P\otimes Q, Q\otimes P)$ 等于 $-2\log(1-\frac{H^2(P,Q)}{2}) = -2\log\int\sqrt{dPdQ}$，其中 $H(P,Q)$ 是 Hellinger 距离 —— 参见 (7.5)。*Comment:* 这类假设检验问题出现在社区检测的背景下，其中由 $i\in[n]$ 索引的 n 个节点被划分为两个社区（分别由 $\sigma_i=+$ 和 $\sigma_i=-$ 均匀且独立地标记），任务是根据成对观测 $W=(W_{ij}$ 对节点进行分类：在给定 σ_i 的条件下，$1\le i<j\le n)$ 是独立的，并且如果 $\sigma_i=\sigma_j$ 和 Q 则 $W_{ij}\sim P$，否则为其他情况。（之前在习题 I.49 中引入的随机块模型对应于 P 和 Q 为伯努利分布。）作为证明不可能性结果 [455] 的一种方法，考虑这样一种设定：一个预言机揭示除 σ_1 之外的所有标签。定义 $S_+=\{j=2,\dots,n:\sigma_j=+\}$，类似地定义 S_-。如果 $\sigma_1=+$，则 $\{W_{1,j}:j\in S_+\}\overset{\text{i.i.d.}}{\sim}P$ 且 $\{W_{1,j}:j\in S_-\}\overset{\text{i.i.d.}}{\sim}Q$，反之如果 $\sigma_1=-$。

III.31（随机占优与稳健似然比检验）设 $\mathcal{P}_0,\mathcal{P}_1$ 为 $\mathcal{X}$ 上的两个概率分布族。假设存在一个 *least favorable pair (LFP)* $(Q_0,Q_1)\in\mathcal{P}_0\times\mathcal{P}_1$，使得

$$Q_0[\pi>t]\ge Q_0'[\pi>t]$$
$$Q_1[\pi>t]\le Q_1'[\pi>t],$$

对于所有 $t\ge 0$ 和 $Q_i'\in\mathcal{P}_i$，其中 $\pi=dQ_1/dQ_0$。证明 (Q_0,Q_1) 同时最小化 $\mathcal{P}_0$ 和 $\mathcal{P}_1$ 之间的所有 f-散度，即

$$D_f(Q_1\|Q_0)\le D_f(Q_1'\|Q_0')\qquad\forall Q_0'\in\mathcal{P}_0, Q_1'\in\mathcal{P}_1\,. \tag{III.14}$$

Hint: 在(Q_0,Q_1)与(Q_0',Q_1')之间插值，并进行微分。

Remark: 对于两个 TV-球的情况，即 $\mathcal{P}_i=\{Q:\mathrm{TV}(Q,P_i)\le\epsilon\}$，LFP 的存在性已在 [221] 中给出，在这种情况下 $\pi=\min(c',\max(c'',\frac{dP_0}{dP_1}))$ 对某个 $0\le c'<c''\le\infty$ 成立，从而给出 *robust likelihood-ratio test.*

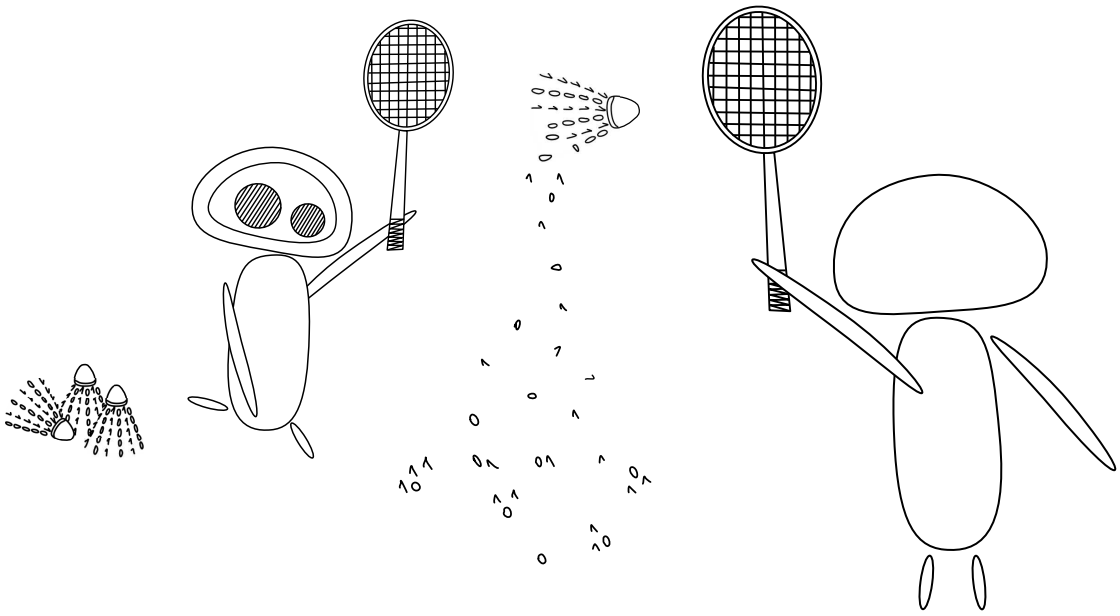
III.32 回忆定义16.5中的F_I曲线。假设$\mathcal{X}$和$\mathcal{Y}$是有限的，并证明以下内容：

a（张量化）$F_I(nt;\ P_{X,Y}^{\otimes n})=nF_I(t;\ P_{X,Y})$ (提示：定理 11.17) b（凹性）$t\mapsto F_I(t)$ 在其定义域 $t\in[0;H(X)]$ 上是凹且连续的。c（基数界）在 F_I 的定义中取 $|\mathcal{U}|\le|\mathcal{X}|+1$ 就足够了。（提示：考察定理 11.17）d 证明定义中的上确界是最大值，并且对于每个 t，存在一个随机变量 U，使得 $I(U;\ X)=t$ 且 $I(U;\ Y)=F_I(t)$。e（严格 DPI）如果 $P_{X,Y}(x,y)>0$，那么对于所有 $t>0$，有 $F_I(t)<t$。

III.33 Gács-Körner（GK）共同信息 [174] 定义为一对随机变量（X,Y）之间速率 R 的上确界，使得对于所有足够大的 n，存在函数 $f(X^n)$ 和 $g(Y^n)$，其中 $H(f(X^n))\ge nR$ 和 $\mathbb{P}[f(X^n)\ne g(X^n)]\to 0$，其中 $(X_i,Y_i)\overset{\text{i.i.d.}}{\sim}P_{X,Y}$ (即 GK 共同信息是从两个相关序列) 中提取随机性的最大速率。证明如果 $P_{X,Y}(x,y)>0$，则 GK 共同信息为零。（提示：证明 $I(Y^n;\ g(Y^n))=I(Y^n;\ f(X^n))+o(n)$ 并应用练习 III.32 中的张量化和严格 DPI。）

Part IV

信道编码



在本部分中，我们研究一类新的问题。信道编码的目标是通过有噪信道传输数字信息。从历史上看，这是信息论中第一个立即得到广泛部署应用的领域。香农[378]发现了以趋近于零的错误率和正的（即大于零的）每秒比特速率传输信息的可能性，这在理论上也相当令人惊讶和出乎意料。本部分的目标是理解这些论证。

为了解释本部分与其他部分的关系，让我们回顾一下到目前为止我们所研究的问题。在第一部分中，我们介绍了各种信息度量，并研究了它们的性质，而不考虑工程应用。然后，在第二部分中，我们的目标是数据压缩。那里的主要对象是单一分布 P_X，而基本极限 $\mathbb{E}[\ell(f^*(X))]$ 是最小压缩长度。主要结果（“编码定理”）建立了基本极限与一个信息量之间的联系，我们可以将其总结为

$$\mathbb{E}[\ell(f^*(X))] \approx H(X)$$

接下来，在第三部分中我们研究了二元假设检验。那里的主要研究对象是一对分布（P, Q），基本极限是奈曼-皮尔逊曲线 $\beta_{1-\epsilon}(P^n, Q^n)$，以及主要结果

$$\beta_{1-\epsilon}(P^n, Q^n) \approx \exp\{-nD(P\|Q)\}\,,$$

再次将操作量与信息度量联系起来。

在信道编码——本部分的主题——中，主要对象将是一个信道 $P_{Y|X}$。基本限制是 $M^*(\epsilon)$，即在错误概率至多为 ϵ 的情况下可以传输的最大消息数量，我们将在本章中严格定义这一点。本部分的主要结果是展示著名的香农噪声信道编码定理:

$$\log M^*(\epsilon) \approx \max_{P_X} I(X;Y)\,.$$

我们将展示以高可靠性发送信息的可能性，并且还将严格推导渐近（以及非渐近！）最高可达速率。然而，我们完全省略了*coding theory*中一个庞大而美丽的领域，该领域涉及如何构造低计算复杂度的发射机和接收机的问题。这一科学领域虽然与本书内容密切相关，但值得单独专门论述。我们推荐阅读[360]了解基于*sparse-graph*的编码，以及[372]了解更现代的*polar codes*的介绍。

本章的实际意义即使不给出明确的编码构造也是深远的。首先，在寻找信道容量的过程中，需要最大化互信息，而最大化分布揭示了最优码的性质（例如，注水解法规定了如何在频带之间最优分配功率，图3.2提示了何时使用二进制调制等）。其次，我们在本部分中推导的非渐近（有限块长度）界被常规用于评估所有新开发码的性能基准。其他意义还说明了如何利用信道中的记忆，或如何利用多天线（练习I.10），以及更多。总的来说，本部分的内容（至少截至本书写作时）在所有内容中产生了迄今为止最大的现实世界影响。

17 Error correcting codes

在本章中，我们介绍纠错码（ECC）的概念。我们将花时间讨论码具有低错误概率意味着什么，什么是最优（ML或MAP）解码器。在BSC编码的特殊情况下，我们展示了从香农之前到现代有限块长度对基本极限理解的演变。我们还简要回顾了ECC的历史。最后，我们以一个概念上重要的ECC性能弱逆（不可能性）界的证明作为结束。

17.1 编码与错误概率

我们从代码的简单定义开始。

定义17.1 一个针对$P_{Y|X}$的M码是一个（随机化）函数对（f, g）的编码器/解码器对[1]

- 编码器$f: [M] \to \mathcal{X}$解码器 $g: \mathcal{Y} \to [M] \cup \{\mathsf{e}\}$
-

在大多数情况下，f和 g 是确定性函数，此时我们可以等价地从码字、码本和解码区域的角度来思考它们（示例见图17.1）。

• $\forall i \in [M]$: $c_i \triangleq f(i)$是*codewords*，集合$\mathcal{C} = \{c_1, \ldots, c_M\}$称为*codebook*。• $\forall i \in [M]$,$D_i \triangleq g^{-1}(\{i\})$是$i$的*decoding region*。

给定一个 M 码，我们可以定义一个概率空间，作为本部分后续所有发展的基础。为此，我们将三个对象——消息 W、编码器和解码器——串联成以下马尔可夫链：

$$W \xrightarrow{f} X \xrightarrow{P_{Y|X}} Y \xrightarrow{g} \hat{W} \tag{17.1}$$

[1] 对于随机编码器/解码器，我们将f和g认定为概率转移核$P_{X|W}$和$P_{\hat{W}|Y}$。

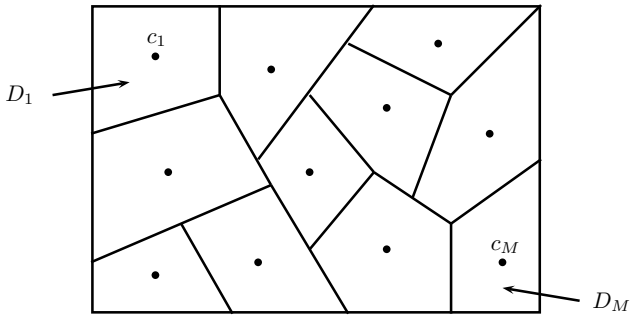


图17.1 当$\mathcal{X}=\mathcal{Y}$时，解码区域可以被视为空间的一种划分，每个区域包含一个码字。

其中我们设置 $W\sim \mathrm{Unif}([M])$。在离散空间的情况下，我们可以显式地写出这些变量的联合分布如下：

$$\text{(general)} \qquad P_{W,X,Y,\hat{W}}(m,a,b,\hat{m}) = \frac{1}{M}P_{X|W}(a|m)P_{Y|X}(b|a)P_{\hat{W}|Y}(\hat{m}|b)$$

$$\text{(deterministic } f,g) \qquad P_{W,X,Y,\hat{W}}(m,c_m,b,\hat{m}) = \frac{1}{M}P_{Y|X}(b|c_m)1\{b\in D_{\hat{m}}\}$$

在这些章节中，这些随机变量将按其传统名称来称呼：W – 原始（真实）消息，X - （诱导的）信道输入，Y - 信道输出，以及$\hat{W}$ - 解码后的消息。

尽管任何一对（f,g）都称为 M-码，但实际上我们只对满足某些“纠错”性质的码感兴趣。为了评估它们的质量，我们定义以下 *performance metrics*：

1 *Maximum error probability*：$P_{e,\max}(f,g)\triangleq \max_{m\in[M]}\mathbb{P}[\hat{W}\neq m|W=m$]。2 *Average error probability*：$P_e(f,g)\triangleq \mathbb{P}[W\neq\hat{W}]$。

注意，显然，$P_e\le P_{e,\max}$。因此，要求小的最大错误概率是一个更为严格的标准，并为所有码字提供了一致的保护。一些码（如线性码，见第18.6节）通过构造具有$P_e=P_{e,\max}$的性质，但通常这两个度量可能非常不同。

在定义了M码的概念和性能指标之后，我们终于可以为给定的信道$P_{Y|X}$定义 *fundamental limits*。

定义17.2 若$P_e(f,g)\le\epsilon$，则码(f,g)是关于$P_{Y|X}$的(M,ϵ)-码。类似地，一个$(M,\epsilon)_{\max}$-码必须满足$P_{e,\max}\le\epsilon$。信道编码的基本极限定义为

$$\begin{aligned}
M^*(\epsilon;P_{Y|X}) &= \max\{M:\exists(M,\epsilon)\text{-code}\}\\
M^*_{\max}(\epsilon;P_{Y|X}) &= \max\{M:\exists(M,\epsilon)_{\max}\text{-code}\}\\
\epsilon^*(M;P_{Y|X}) &= \inf\{\epsilon:\exists(M,\epsilon)\text{-code}\}\\
\epsilon^*_{\max}(M;P_{Y|X}) &= \inf\{\epsilon:\exists(M,\epsilon)_{\max}\text{-code}\}
\end{aligned}$$

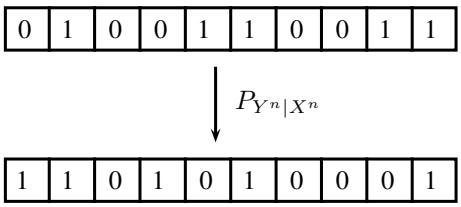
当$P_{Y|X}$在上下文中明确时，参数$P_{Y|X}$将被省略。

换句话说，量$\log_2 M^*(\epsilon)$给出了我们通过含噪变换$P_{Y|X}$所能推送的最大比特数，同时仍能保证在适当意义下的错误概率至多为ϵ。

例17.1 信道$\mathsf{BSC}_\delta^{\otimes n}$ (回忆例3.6中提到的BSC代表二进制对称信道)作用于$\mathcal{X} = \{0, 1\}^n$与$\mathcal{Y} = \{0, 1\}^n$之间，其中输入X^n受到与X^n独立的加性噪声$Z^n \overset{\text{i.i.d.}}{\sim} \text{Ber}(\delta)$的污染，导致信道输出

$$Y^n = X^n \oplus Z^n.$$

换句话说，$\mathsf{BSC}_\delta^{\otimes n}$ 信道接收长度为 n 的二进制序列，并以概率 δ 独立地翻转每一位；图示如下，



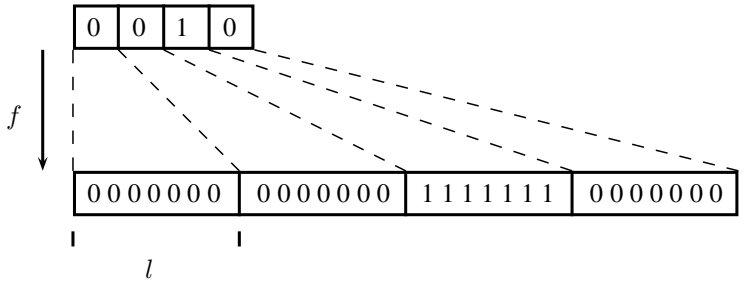
在 下一节我们讨论mor中BSC信道的编码 电子详情。

17.2 二进制对称信道的编码

为了理解编码器和解码器的设计问题，让我们考虑具有$\delta = 0.11$和$n = 1000$的BSC变换。研究$\log_2 M^*(\epsilon)$的问题试图回答，在$P_e \le \epsilon$的情况下，你最多可以发送多少位k? 具体而言，让我们固定$\epsilon = 10^{-3}$并讨论一些可能的方法。

也许我们的第一次尝试是尝试用每个数据比特映射到一个信道输入位置来发送 $k = 1000$ 比特。然而，简单计算表明，在这种情况下我们得到 $P_e = 1 - (1-\delta)^n \approx 1$。换句话说，*uncoded transmission* 不满足我们小 P_e 的目标，因此需要某种形式的编码。这带来一个基本权衡：减少要发送的比特数（并利用释放出的信道输入来发送冗余副本），以提高成功概率。

让我们考虑下一个自然的想法：*repetition coding*。我们将每个输入数据位重复ℓ次：



解码可以通过在每个 ℓ 块内进行多数投票来完成。因此，每个数据位的解码误码率为 $P_b = \mathbb{P}[\text{Binom}(l,\delta) > l/2]$。然而，该方案的块错误概率为 $P_e \le k\mathbb{P}[\text{Binom}(l,\delta) > l/2]$。（这个界在当前情况下基本是紧的）。因此，为了满足 $P_e \le 10^{-3}$，我们必须求解满足 $kl \le n = 1000$ 以及k 和 ℓ。

$$k\mathbb{P}[\text{Binom}(l,\delta) > l/2] \le 10^{-3}\,.$$

这给出了 $l = 21$，$k = 47$ 比特。因此我们可以看到，使用重复编码，我们可以通过 1000 次信道使用发送 47 个数据比特。

重复编码是一种自然的想法。它也具有一个非常自然的权衡：如果你想要更好的可靠性，那么数字 ℓ 需要增加，因此比率 $\frac{k}{n} = \frac{1}{\ell}$ 应该下降。在香农的开创性工作之前，几乎普遍认为 *this is fundamentally unavoidable:*
vanishing error probability should imply vanishing communication rate $\frac{k}{n}$.

在深入探讨最优编码之前，让我们先窥视一下比简单重复更为复杂的向信道输入n序列注入冗余的方法。为此，考虑所谓的一阶里德-穆勒码（$1, r$）。我们将r个数据比特 $a_0, \ldots, a_{r-1} \in \mathbb{F}_2^r$的序列解释为$(r-1)$个变量中的一次多项式：

$$a = (a_0, \ldots, a_{r-1}) \mapsto f_a(x) \triangleq \sum_{i=1}^{r-1} a_i x_i + a_0\,.$$

为了传输这 r 位数据，我们只需对所有可能的变量 $x^{r-1} \in \mathbb{F}_2^{r-1}$ 值计算 $f_a(\cdot)$。该编码将 r 位映射为 2^{r-1} 位，其最小距离为 $d_{min} = 2^{r-2}$。也就是说，对于两个不同的 $a \ne a'$，f_a 和 $f_{a'}$ 不一致的位置数至少为 2^{r-2}。用编码理论的记号 $[n, k, d_{min}]$ 来说，一阶 Reed-Muller 码 $(1, 7)$ 是一个 $[64, 7, 32]$ 码。可以证明，该码的最优译码器在 $\text{BSC}_{0.11}^{\otimes 64}$ 信道上达到的误码率至多为 $6{\cdot}10^{-6}$。因此，我们可以在 $\text{BSC}_{\delta}^{\otimes 1024}$ 上使用 16 个这样的块（每块携带 7 个数据位，在信道上占用 64 位），并且（通过联合界）仍然具有总体块错误概率 $P_e \lesssim 10^{-4} < 10^{-3}$。因此，借助 Reed-Muller 码，我们可以在 1024 次信道使用中发送 $7 \cdot 16 = 112$ 位，是重复码的两倍多。

香农噪声信道编码定理（定理19.9）——信息论的瑰宝——告诉我们，在无记忆信道 $P_{Y^n|X^n} = (P_{Y|X})^n$中，对于块长度$n$，基本极限满足

$$\log M^*(\epsilon; P_{Y^n|X^n}) = nC + o(n) \tag{17.2}$$

作为$n \to \infty$，并且对于任意$\epsilon \in (0,1)$。这里$C = \max_{P_{X_1}} I(X_1; Y_1)$是单字母信道的容量。在我们BSC的情况下，我们有

$$C = \log 2 - h(\delta) \approx \frac{1}{2} \text{ bit},$$

由于最优输入分布是对称的（来自对称性）——参见第19.3节。香农展开（17.2）可用于预测（当然，由于$o(n)$残差，这并非完全严谨），应该能够可靠地发送约500比特。事实证明，对于块长度$n = 1000$而言，这并不完全可能。

注意，精确计算 M^* 需要对所有可能的编码器和解码器进行迭代——即使对于较小的 n 值，这也是一个不可能完成的任务。然而，存在严格且计算上易于处理的有限块长度界 [334]，这些界证明，对于我们选择的 $n = 1000, \delta = 0.11, \epsilon = 10^{-3}$：

$$414 \le \log_2 M^*(\epsilon = 10^{-3}) \le 416 \quad \text{bits} \tag{17.3}$$

因此我们可以看到，香农的预测大约过于乐观20%。下面我们将看到一些这样的有限长度界限。然而，请注意，尽管这些界限保证了存在一个达到规定性能的编解码器对，构建一个能够用现代软件/硬件实现的f和g则是另一回事。

香农发现(17.2)之后大约60年，才构建出实际可实现的、达到该性能的编码。第一个接近$\log M^*$界限的编码被称为*turbo codes*[47]（得名于涡轮增压发动机，其中废气被反馈回发动机以提供动力）。这类编码被称为*sparse-graph codes*，其中由Gallager发明的低密度奇偶校验（LDPC）码得到了特别深入的研究[360]。根据经验法则，当$n \approx 10^3 \ldots 10^4$时，这些编码通常能达到$\log M^*$的80 . . . 90%。对于$n = 100 \ldots 1000$范围内较短的块长度，有一种令人兴奋的LDPC码替代方案：Ar kan的极化码[23]，它通常与Tal和Vardy的列表译码思想结合使用[409]。当然，随着新的信道模型变得相关以及新的硬件可能性不断涌现，这个故事至今仍在发展。

我们想指出一个微妙但非常重要的概念范式转变，这是由香农坚持对许多（信息）比特一起编码所引入的。的确，考虑上面讨论的情况，我们构建了一个强大的码，具有$M \approx 2^{400}$个码字和$n = 1000$。现在，人们可能会将这个码想象为精心排列在超立方体$\{0,1\}^{1000}$内的2^{400}个点的星座，以保证它们之间有一定程度的分离，参见(17.6)。接下来，假设一个人在宇宙的寿命期间（$\approx 10^{18}$秒）每秒都使用这个码。然而，即使经过这个费力的过程，她最多也只会探索到2^{60}个不同的码字，而码本的总量却庞大到2^{400}。因此，一个自然的问题出现了：如果这些众多码字中的大多数永远不会被任何人使用，为什么我们需要仔细放置所有这些码字？答案正是信息概念的核心：传输信息就是从一组可能性（$[M]$）中传达对一个元素（W）的选择。我们不知道哪个W会被选中，这一事实迫使我们必须先验地为每一种可能性做好准备。这个简单的想法在[378]的第一段中提出，现在已被每个人默认接受，但它是

香农彻底革新了信息交换研究的科学方法，其方式是微妙而深远的。

17.3 最优解码器

给定任意编码器 $f\colon [M] \to \mathcal{X}$，最小化 P_e 的解码器是 *Maximum A Posteriori (MAP)* 解码器，或者等价地，*Maximum Likelihood (ML)* 解码器，因为码字是等概率的（W 是均匀分布）：

$$\begin{aligned} g^*(y) &= \operatorname*{argmax}_{m\in[M]} \mathbb{P}[W=m|Y=y] \\ &= \operatorname*{argmax}_{m\in[M]} \mathbb{P}[Y=y|W=m]\,. \end{aligned} \tag{17.4}$$

注意，最优解码器是确定性的。对于确定性编码器的特殊情况，我们可以将编码器与其像 $\mathcal{C}$ 等同起来，码本 $\mathcal{C}$ 的最小（MAP）错误概率可以写成

$$P_{e,MAP}(\mathcal{C}) = 1 - \frac{1}{M}\sum_{y\in\mathcal{Y}} \max_{x\in\mathcal{C}} P_{Y|X}(y|x)\,, \tag{17.5}$$

带有对非离散 $\mathcal{Y}$ 的类似扩展。

注记 17.1 对于 $\mathsf{BSC}_\delta^{\otimes n}$ 的情况，MAP 解码器有一个很好的几何解释。事实上，如果 $d_{\mathrm{H}}(x^n,y^n) = |\{i\colon\ x_i \neq y_i\}|$ 表示汉明距离，且如果 f（编码器）是确定性的，其码字为 $\mathcal{C} = \{c_i, i\in[M]\}$ 那么

$$g^*(y^n) = \operatorname*{argmin}_{m\in[M]} d_H(c_m, y^n)\,. \tag{17.6}$$

因此，最优解码区域——见图17.1——成为在汉明空间$\{0,1\}^n$中划分出的*Voronoi cells*。类似地，AWGN信道的MAP解码器诱导出$\mathbb{R}^n$的Voronoi划分——见第20.3节。

因此，我们已经看到，最优解码器可以不失一般性地假定为确定性的。同样地，我们可以将任何随机编码器 f 表示为两个参数的函数：真实消息 W 和外部随机性 $U \perp\!\!\!\perp W$，因此 $X = f(W,U)$，此时 f 是一个确定性函数。于是我们有

$$\mathbb{P}[W\neq\hat{W}] = \mathbb{E}[\mathbb{P}[W\neq\hat{W}|U]]\,,$$

这意味着如果 $P[W\neq\hat{W}] \leq \epsilon$，那么必定存在某个选择 u_0，使得 $\mathbb{P}[W\neq\hat{W}|U=u_0] \leq \epsilon$。换句话说，如果我们仅将注意力限制在确定性编码器和解码器上，基本极限 $M^*(\epsilon)$ 保持不变。

但请注意，上述考虑均不适用于最大错误概率$P_{e,max}$。实际上，基本极限$M^*_{\max}(\epsilon)$确实需要考虑随机化的编码器和解码器。例如，当$M=$为2时，从解码的角度来看，我们又回到了

第三部分中二元假设检验的设置。最小化最大第一类和第二类错误概率的最优解码器（检验），即 $\max\{1-\alpha,\beta\}$，如果 $\max\{1-\alpha,\beta\}$ 未在 Neyman-Pearson 区域 $\mathcal{R}(P_{Y|W=1},P_{Y|W=2})$ 的顶点处取得，则不会是确定性的。

17.4 弱反界

信道编码的理论和实践的主要焦点在于证明存在（或构造显式的）具有大 M 和小 ϵ 的 (M,ϵ)码。为了理解所构造的码距离基本极限有多近，需要证明一个“不可能性结果”，即从上方界定 M 或从下方界定 ϵ。这类负面结果被称为“逆界”，其名称来源于经典情况下这些界紧跟在正面（存在性）结果之后，并以“反之，……”开头。下一个结果表明，M 永远不会（乘法地）超过容量 $\sup_{P_X} I(X;Y)$ 太多。

定理 17.3（弱逆）*Any (M,ϵ)-code for $P_{Y|X}$ satisfies*

$$\log M \le \frac{\sup_{P_X} I(X;Y)+h(\epsilon)}{1-\epsilon},$$

where $h(x)=H(\mathrm{Ber}(x))$ is the binary entropy function.

Proof. 这可以推导为Fano不等式（定理3.12）的一行应用，但我们略微不同地进行，以便在未来扩展到*meta-converse* (第22.3节)。

考虑一个具有错误概率 P_e 的 M 码及其相应的概率空间：$W\to X\to Y\to\hat{W}$。我们想要证明该码可以用作分布 $P_{X,Y}$ 和 P_XP_Y 之间的假设检验。实际上，给定一对 (X,Y)，我们可以从 $P_{W,\hat{W}|X,Y}=P_{W|X}P_{\hat{W}|Y}$ 中采样 $(W,\hat{W})$ 并计算二值 $Z=1\{W\neq\hat{W}\}$。（注意，在最有意思的情况下，当编码器和解码器都是确定性的且编码器是单射时，值 Z 是 (X,Y) 的确定性函数。）让我们在两个假设下计算这个二值假设检验的性能。首先，当 $(X,Y)\sim P_XP_Y$ 时，我们有 $\hat{W}\perp\!\!\!\perp W\sim\mathrm{Unif}([M])$，因此：

$$P_XP_Y[Z=1]=\frac{1}{M}.$$

其次，当$(X,Y)\sim P_{X,Y}$ 时，根据定义我们有

$$P_{X,Y}[Z=1]=1-P_e.$$

因此，我们现在可以应用散度的数据处理不等式来得出结论：由于 $W\to X\to Y\to\hat{W}$，我们有以下不等式链（参见Fano不等式定理3.12）：

$$\begin{aligned}D(P_{X,Y}\|P_XP_Y)&\overset{\text{DPI}}{\ge} d(1-P_e\|\frac{1}{M})\\&\ge -h(\mathbb{P}[W\neq\hat{W}])+(1-P_e)\log M\end{aligned}$$

注意到左边是$I(X;\ Y) \leq \sup_{P_X} I(X;\ Y)$，我们得到：

$$\log M \leq \frac{\sup_{P_X} I(X;Y) + h(P_e)}{1 - P_e},$$

并且通过检查 {v*} 单调递增，证明就完成了。 □

注17.2 在数据处理步骤中考虑其他散度度量，可以显著改进这一界限。特别是在下文中，我们将看到如何在第22.1节获得“强”逆定理（这里也解释了术语“弱”逆定理）。该证明技术被称为元逆定理；参见第22.3节。

18 Random and maximal coding

到目前为止，我们对信道编码的讨论主要遵循与统计学中M元假设检验(HT)相同的思路。在本章中，我们引入关键的偏离：信息论中最主要且最有趣的目标是设计编码器f: $[M] \to \mathcal{X}$或码本$\{c_i \triangleq f(i), i \in [M]\}$。一旦选择了码本，问题确实就变成了$M$元HT，可以用标准统计工具来处理。然而，选择编码器f的任务在统计理论中没有完全类似的问题(最接近的是实验设计)。每个f都会产生不同的HT问题，目标是选择这些M假设$P_{Y|X=c_1}, \ldots, P_{Y|X=c_M}$以确保最大的可检验性。事实证明，如果我们采用次优的方式来检验M元HT，选择好的f的问题将大大简化。粗略地说，我们将运行M个二元HT，检验$P_{Y|X=c_m}$对P_Y，试图区分由消息m引起的信道输出与“平均背景噪声”P_Y。正如我们从Neyman-Pearson定理(定理14.11)所知，这种最优检验会对以下量进行阈值化

$$\log \frac{P_{Y|X=x}}{P_Y}.$$

这解释了信息密度（下文定义）在本章中起到的核心作用。在引入信息密度之后，我们将给出若干结果，证明好码的存在性。我们从Shannon的原始界（用现代语言表述）开始，随后是其加强形式（DT、RCU和Gallager界）。这些属于*random coding*界这一类。Feinstein发展了一种完全不同的方法，称为*maximal coding*。我们将看到，这两种方法得到的结果惊人地相似。为什么这两种相当不同的方法会产生相似的结果，而且这些结果还相当接近最优可能（即“达到容量和色散”）？事实证明，答案在于信道编码任务的某种子模性质。最后，我们还将讨论一类基于线性代数构造的更具结构化的码。与压缩的情形类似，将证明线性码并不比一般码差，这解释了为什么几乎所有实用码都是线性的。

在阅读本章时，我们建议同时参考图22.2，其中比较了BSC的各种可达性界限。

在本章中，引入以下 *independent pairs* $(X, Y) \perp\!\!\!\perp (\bar{X}, \bar{Y})$ 及其联合分布将会很方便，其联合分布由下式给出：

$$P_{X,Y,\bar{X},\bar{Y}}(a, b, \bar{a}, \bar{b}) = P_X(a)P_{Y|X}(b|a)P_X(\bar{a})P_{Y|X}(\bar{b}|\bar{a}). \tag{18.1}$$

我们将经常称 X 为已发送码字，$\bar{X}$ 为未发送码字。

18.1 信息密度

后续发展的一个关键对象是信息密度。历史上，这一概念似乎起源于苏联信息理论家的早期工作。简而言之，我们希望设定{v*}；$y) = \log\frac{P_{X,Y}(x,y)}{P_X(x)P_Y(y)}$。然而，我们希望使这个定义足够一般，以便考虑到连续分布、$P_{X,Y} \not\ll P_X P_Y$ (的可能性，在这种情况下对数下的值可以等于$+\infty$)，以及对数的参数等于0的可能性。下面的定义类似于我们在定义14.4和(2.10)中使用Log函数所做的，但为了方便起见，我们在下面重复它。

定义 18.1（信息密度[1]）令$P_{X,Y} \ll \mu$和$P_X P_Y \ll \mu$对于某个主导测度μ，并分别用$f(x,y) = \frac{dP_{X,Y}}{d\mu}$和$\bar{f}(x,y) = \frac{dP_X P_Y}{d\mu}$表示$P_{X,Y}$和$P_X P_Y$关于$\mu$的Radon-Nikodym导数。然后回顾对数定义(2.10)，我们设定

$$i_{P_{X,Y}}(x;y) \triangleq \operatorname{Log}\frac{f(x,y)}{\bar{f}(x,y)} = \begin{cases} \log\frac{f(x,y)}{\bar{f}(x,y)}, & f(x,y) > 0, \bar{f}(x,y) > 0 \\ +\infty, & f(x,y) > 0, \bar{f}(x,y) = 0 \\ -\infty, & f(x,y) = 0, \bar{f}(x,y) > 0 \\ 0, & f(x,y) = \bar{f}(x,y) = 0\,. \end{cases} \tag{18.2}$$

在最常见的 $P_{X,Y} \ll P_X P_Y$ 特殊情况下，我们只需

$$i_{P_{X,Y}}(x;y) = \log\frac{dP_{X,Y}}{dP_X P_Y}(x,y)\,,$$

以对数 $0 = -\infty$。

注意，作为函数的信息密度依赖于底层的 $P_{X,Y}$。然而，在本部分中，$P_{Y|X}$ 将是一个固定信道（由当前问题固定），因此信息密度仅取决于 P_X 的选择。大多数情况下，P_X (以及相应地，用于定义信息密度的 $P_{X,Y}$) 将从上下文中显而易见。因此，为了读者的利益以及我们自己的方便，我们将写作 $i(x;\ y)$ 省略下标 $P_{X,Y}$。

我们继续展示信息密度的一些基本性质。下一个结果解释了“信息密度”这个名称。

命题 18.2 *The expectation* $\mathbb{E}[i(X;\ Y)]$ *is well-defined and non-negative (but possibly infinite). In any case, we have* $I(X;\ Y) = \mathbb{E}[i(X;\ Y)]$.

Proof. T这是从(2.12)以及$i(x$的定义得出的；$y)$作为对数 -比率。 □

由于定义为对数似然，信息密度具有后者的标准性质，参见定理14.6。然而，因为它是由两个变量（X, Y）定义的，所以存在

[1] We remark that in machine learning (especially natural language processing) information density is also called *pointwise mutual information (PMI)* [292].

同时，条件期望版本也非常有用。为了说明下一个命题的含义，让我们考虑离散X, Y和$P_{X,Y} \ll P_X P_Y$的情况。那么我们有*for every* x:

$$\sum_y f(x,y)P_X(x)P_Y(y) = \sum_y f(x,y)\exp\{-i(x;y)\}P_{X,Y}(x,y)\,.$$

一般情况需要更多的技巧。

命题 18.3（条件化-去条件化技巧） *Let* $\bar{X} \perp\!\!\!\perp (X,Y)$ *be a copy of* X. *We have the following:*

1 For any function $f : \mathcal{X} \times \mathcal{Y} \to \mathbb{R}$

$$\mathbb{E}[f(\bar{X},Y)1\{i(\bar{X};Y) > -\infty\}] = \mathbb{E}[f(X,Y)\exp\{-i(X;Y)\}]\,. \tag{18.3}$$

2 Let f_+ *be a non-negative function. Then for* P_X*-almost every* x *we have*

$$\mathbb{E}[f_+(\bar{X},Y)1\{i(\bar{X};Y) > -\infty\}|\bar{X} = x] = \mathbb{E}[f_+(X,Y)\exp\{-i(X;Y)\}|X = x] \tag{18.4}$$

Proof. 第一部分（18.3）只是对（14.5）的重新表述。对于第二部分，我们定义

$$a(x) \triangleq \mathbb{E}[f_+(\bar{X},Y)1\{i(\bar{X};Y) > -\infty\}|\bar{X} = x], \quad b(x) \triangleq \mathbb{E}[f_+(X,Y)\exp\{-i(X;Y)\}|X = x]$$

我们首先额外假设f是有界的。固定$\epsilon > 0$并记$S_\epsilon = \{x : a(x) \geq b(x) + \epsilon\}$。当$\epsilon \to 0$时，我们有$S_\epsilon \nearrow \{x : a(x) > b(x)\}$，因此如果我们证明$P_X[S_\epsilon] = 0$，这将意味着对于$P_X$-几乎处处$x$，有$a(x) \leq b(x)$。对称论证表明$b(x) \leq a(x)$并完成了等式的证明。

为了展示$P_X[S_\epsilon] = 0$，让我们将（18.3）应用于函数$f(x,y) = f_+(x,y)1\{x \in S_\epsilon\}$。于是我们得到

$$\mathbb{E}[f_+(X,Y)1\{X \in S_\epsilon\}\exp\{-i(X;Y)\}] = \mathbb{E}[f_+(\bar{X},Y)1\{i(\bar{X};Y) > -\infty\}1\{X \in S_\epsilon\}]\,.$$

让我们通过对Y取条件期望来重新表达这个等式的两边，得到:

$$\mathbb{E}[b(X)1\{X \in S_\epsilon\}] = \mathbb{E}[a(\bar{X})1\{\bar{X} \in S_\epsilon\}]\,.$$

但从 {v*} 的定义我们有

$$\mathbb{E}[b(X)1\{X \in S_\epsilon\}] \geq \mathbb{E}[(b(\bar{X}) + \epsilon)1\{\bar{X} \in S_\epsilon\}]\,.$$

回想一下，$X \overset{\mathrm{d}}{=} \bar{X}$因此

$$\mathbb{E}[b(X)1\{X \in S_\epsilon\}] \geq \mathbb{E}[b(X)1\{X \in S_\epsilon\}] + \epsilon P_X[S_\epsilon]\,.$$

由于假设f_+ (且因此 b) 是有界的，我们可以从两边约去公共项，并得出$P_X[S_\epsilon] = 0$，如所需。

最后，为了完整地展示(18.4)，给定一个无界的f_+，我们定义$f_n(x,y)$ =为$\min(f_+(x,y), n$)。由于(18.4)对f_n成立，我们可以对其两边取$n \to \infty$的极限:

$$\lim_{n\to\infty} \mathbb{E}[f_n(\bar{X},Y)1\{i(\bar{X};Y) > -\infty\}|\bar{X} = x] = \lim_{n\to\infty} \mathbb{E}[f_n(X,Y)\exp\{-i(X;Y)\}|X = x]$$

根据单调收敛定理（对于条件期望！），我们可以将极限取入期望内部，从而完成证明。□

推论 18.4（信息尾部）*For P_X-almost every x we have*

$$\mathbb{P}[i(x;Y) > t] \le \exp(-t), \tag{18.5}$$

$$\mathbb{P}[i(\overline{X};Y) > t] \le \exp(-t) \tag{18.6}$$

Proof. 选 $f_+(x,y) = 1\{i(x;\ \text{(18.4) 中的 } y) > t\}$。□

备注 18.1 我们之前已经多次使用过这个估计。在假设检验部分，我们使用了（推论 14.12）：

$$Q\Big[\log \frac{dP}{dQ} \ge t\Big] \le \exp(-t). \tag{18.7}$$

在数据压缩中，我们利用了这样一个事实：$|\{x:\ \text{对数 } P_X(x) \ge t\}| \le \text{指数}(-t)$，这也是形式(18.7)，其中 Q 为计数测度。

18.2 香农随机编码界

在本节中，我们将展示香农可能最为卓越的技术成果。正如我们之前所讨论的，优秀的纠错码应当是高维空间中几何上优雅的星座。其主要目标是将不同的码字尽可能拉开距离，以减少信道噪声的有害影响。然而，在20世纪40年代初，香农既没有可用的编码，也没有构建编码的工具。因此，面对理解纠错是否可能的问题，香农决定检验在空间中随机放置码字是否会以某种方式产生有利的几何排列。令所有人惊讶的是，这种方法不仅产生了合理的编码，而且事实上被证明是渐近最优的（并且在非渐近情况下几乎是优的[334]），这一发现至今仍在产生余震。正如我们之前提到的，通过随机选择来证明某些组合对象存在性的方法被称为Erdös的*probabilistic method*[15]，香农显然独立地发现了它，或许还更早。

在进入证明之前，我们需要解释为什么我们使用一个特定的次优解码器，以及在这种情况下信息密度是如何产生的。首先，为简单起见，考虑离散字母表和 $P_{X,Y} \ll P_X P_Y$ 的情况。然后我们有一个等价表达式

$$i(x;y) = \log \frac{P_{Y|X}(y|x)}{P_Y(y)}.$$

因此，最优（最大似然）解码器可以依据信息密度来表述：

$$g^*(y) = \operatorname*{argmax}_{m\in[M]} P_{X|Y}(c_m|y) = \operatorname*{argmax}_{m\in[M]} P_{Y|X}(y|c_m) = \operatorname*{argmax}_{m\in[M]} i(c_m;y). \tag{18.8}$$

注意，(18.8) 成立与用于定义 $i(x$ 的输入分布 P_X 无关；$y)$，特别是我们不必使用码诱导分布 $P_X = \frac{1}{M}\sum_{i=1}^{M}\delta_{c_i}$。然而，若要阈值化信息密度，不同的 P_X 选择会导致不同的解码器，因此我们需要证明 P_X 的选择合理性。

为此，回顾一下，为了区分两个码字 c_i 和 c_j，可以应用（正如我们在第三部分学到的二进制HT）似然比检验，即对LLR $\log\frac{P_{Y|X=c_i}}{P_{Y|X=c_j}}$ 进行阈值处理。正如本章开头所解释的，M 进制HT中的一种（可能次优的）方法是通过对每个信息密度 $i(c_i$ 进行阈值化来运行二进制测试；$y)$。粗略地说，这评估了 c_i 相对其他 $M-1$个码字的平均分布的似然性，我们将其近似为 P_Y(而不是更精确的形式$\frac{1}{M-1}\sum_{j\neq i}P_{Y|X=c_j}$)。将这些想法结合起来，我们可以提出解码器为

$$g(y) = \text{any } m \text{ s.t. } i(c_m; y) > \gamma\,,$$

其中 γ 是一个阈值旧的和P_X被明智地选择（以最大化$I(X;\ Y)$正如我们　很快就会看到）。

还有一种理解为什么阈值解码器（与ML解码器相对）是一个自然想法的方法是，直接相信这样一个事实：对于优秀的纠错码，最可能的（ML）码字的似然度（信息密度）远高于其他候选码字，以至于我们无需寻找最大值，只需选择那个（也是唯一的）超过预定阈值的码字即可。

基于这些初步论证，我们进入本节的主要结果。

定理 18.5 (香农可达界) *Fix a channel $P_{Y|X}$ and an arbitrary input distribution P_X. Then for every $\tau > 0$ there exists an (M,ϵ)-code with*

$$\epsilon \le \mathbb{P}[i(X;Y) \le \log M + \tau] + \exp(-\tau). \tag{18.9}$$

Proof. 回想一下，对于给定的码本 $\{c_1,\ldots,c_M\}$，最优解码器是 MAP，并且等价于最大化信息密度，参见 (18.8)。最大化 $i(c_m;\ Y)$ 的步骤使得分析错误概率变得困难。类似于我们在几乎无损压缩中所做的，参见定理 11.5，证明可达性界的第一个重要步骤是考虑一个次优解码器。在 Shannon 界中，我们考虑如下基于阈值的次优解码器 $g(y)$：

$$g(y) = \begin{cases} m, & \exists!\, c_m \text{ s.t. } i(c_m;y) \ge \log M + \tau \\ \mathrm{e}, & \text{otherwise} \end{cases} \tag{18.10}$$

简而言之，解码器g将m报告为解码消息，当且仅当码字c_m是信息密度超过阈值$\log M + \tau$的唯一一个。如果存在多个或没有这样的码字，那么解码器输出一个特殊值e，这总是导致错误，因为$W \neq \mathrm{e}$曾经。(我们本可以通过让解码器改为输出随机消息，或选择超过阈值的任何一个消息，或任何其他巧妙的想法来稍微降低错误概率。然而，关键在于，即使是输出e这种最简单的解决方案，也已经实现了所有定性目标，同时大大简化了分析。)

对于给定的码本 $(c_1, \ldots, c_M)$，错误概率为：

$$P_e(c_1, \ldots, c_M) = \mathbb{P}[\{i(c_W; Y) \le \log M + \tau\} \cup \{\exists \overline{m} \ne W, i(c_{\overline{m}}; Y) > \log M + \tau\}]$$

其中 W 在 $[M]$ 上均匀分布，且概率空间如 (17.1) 中所述。

香农提出的第二个（也是最巧妙的）步骤是放弃对码本的复杂离散优化。他的建议是随机生成码本（$c_1, \ldots, c_M$），其中 $c_m \sim P_X$ 对于 $m \in [M]$ 独立同分布，然后尝试对平均 $\mathbb{E}[P_e(c_1, \ldots, c_M)]$ 进行推理。根据对称性，如果我们以 $W = 1$ 为条件，这个在所有可能码本上的平均错误概率保持不变。同时考虑如（18.1）中的随机变量（$X, Y, \bar{X}$），我们得到以下链：

$$\begin{aligned}
&\mathbb{E}[P_e(c_1, \ldots, c_M)] \\
&= \mathbb{E}[P_e(c_1, \ldots, c_M)|W = 1] \\
&= \mathbb{P}[\{i(c_1; Y) \le \log M + \tau\} \cup \{\exists \overline{m} \ne 1, i(c_{\overline{m}}, Y) > \log M + \tau\}|W = 1] \\
&\le \mathbb{P}[i(c_1; Y) \le \log M + \tau|W = 1] + \sum_{\bar{m}=2}^{M} \mathbb{P}[i(c_{\bar{m}}; Y) > \log M + \tau|W = 1] \quad \text{(union bound)} \\
&\overset{\text{(a)}}{=} \mathbb{P}\left[i(X; Y) \le \log M + \tau\right] + (M - 1)\mathbb{P}\left[i(\overline{X}; Y) > \log M + \tau\right] \\
&\le \mathbb{P}\left[i(X; Y) \le \log M + \tau\right] + (M - 1)\exp(-(\log M + \tau)) \qquad \text{(by Corollary 18.4)} \\
&\le \mathbb{P}\left[i(X; Y) \le \log M + \tau\right] + \exp(-\tau),
\end{aligned}$$

其中关键步骤(a)基于以下事实：给定 $W = 1$ 和 $\bar{m} \ne 1$，我们得到

$$(c_1, c_{\bar{m}}, Y) \overset{d}{=} (X, \bar{X}, Y)$$

其中后一个三元组在 (18.1) 中定义。

最后一个表达式确实完成了(M, ϵ)码存在性的证明：它表明$P_e(c_1, \ldots, c_M)$的平均值满足所需的错误概率界限，因此必然存在至少*one*个$c_1, \ldots, c_M$的选择满足同样的界限。

□

备注 18.2（联合典型性） 稍后在第十九章中，我们将针对$P_X = P_{X_1}^{\otimes n}$ (独立同分布输入)和$P_{Y|X} = P_{Y_1|X_1}^{\otimes n}$ (无记忆信道)的情形应用此定理。传统上，参见[111]，此类设置中的解码器是借助所谓的“联合典型性”来定义的。给定 $y = y^n$，那些解码器搜索码字x^n (，二者均为n个字母的向量)，使得经验联合分布接近真实联合分布，即$\hat{P}_{x^n, y^n} \approx P_{X_1, Y_1}$，其中

$$\hat{P}_{x^n, y^n}(a, b) = \frac{1}{n} \cdot |\{j \in [n] : x_j = a, y_j = b\}|$$

是(x^n, y^n)的联合经验分布。该定义适用于随机编码在类型类$\{x^n$上以$c_j \sim$均匀分布进行的情况：$\hat{P}_{x^n} \approx P_X\}$。另一种选择是“熵典型性”，参见[106]，即寻找具有$\sum_{j=1}^{n} \log \frac{1}{P_{X_1, Y_1}(x_j, y_j)} \approx H(X, Y)$的码字。我们将我们的要求，$\{i(x^n;\ y^n) \ge n\gamma_1\}$，视为一种“联合典型性”的版本，它适用于更广泛的信道一般性（不一定基于乘积字母表或无记忆）。

18.3 依赖性测试(DT)界限

以下结果是定理18.5的一个微小改进，它产生了一个不依赖于辅助参数的界限，并且可证明更强。

定理 18.6（DT 界）*Fix a channel $P_{Y|X}$ and an arbitrary input distribution P_X. Then for every $\tau > 0$ there exists an (M, ϵ)-code with*

$$\epsilon \le \mathbb{E}\left[\exp\left\{-\left(i(X;Y) - \log\frac{M-1}{2}\right)^+\right\}\right] \tag{18.11}$$

where $x^+ \triangleq \max(x, 0)$.

Proof. 对于固定的 γ，考虑以下次优解码器：

$$g(y) = \begin{cases} m & \text{for the smallest } m \text{ s.t. } i(c_m; y) \ge \gamma \\ \mathsf{e} & \text{otherwise.} \end{cases}$$

设置 $\hat{W} = g(Y)$，我们注意到给定码本 $\{c_1, \ldots, c_M\}$，根据联合界我们有

$$\begin{aligned}\mathbb{P}[\hat{W} \ne j | W = j] &= \mathbb{P}[i(c_j;Y) \le \gamma | W = j] + \mathbb{P}[i(c_j;Y) > \gamma, \exists k \in [j-1], \text{ s.t. } i(c_k;Y) > \gamma] \\ &\le \mathbb{P}[i(c_j;Y) \le \gamma | W = j] + \sum_{k=1}^{j-1} \mathbb{P}[i(c_k;Y) > \gamma | W = j].\end{aligned}$$

对随机生成的码本取平均，期望错误概率的上界为：

$$\begin{aligned}\mathbb{E}[P_e(c_1, \ldots, c_M)] &= \frac{1}{M}\sum_{j=1}^{M} \mathbb{P}[\hat{W} \ne j | W = j] \\ &\le \frac{1}{M}\sum_{j=1}^{M}\left(\mathbb{P}[i(X;Y) \le \gamma] + \sum_{k=1}^{j-1}\mathbb{P}[i(\overline{X};Y) > \gamma]\right) \\ &= \mathbb{P}[i(X;Y) \le \gamma] + \frac{M-1}{2}\mathbb{P}[i(\overline{X};Y) > \gamma] \\ &= \mathbb{P}[i(X;Y) \le \gamma] + \frac{M-1}{2}\mathbb{E}[\exp(-i(X;Y))1\{i(X;Y) > \gamma\}] \quad \text{(by (18.3))} \\ &= \mathbb{E}\left[1\{i(X;Y) \le \gamma\} + \frac{M-1}{2}\exp(-i(X;Y))1\{i(X,Y) > \gamma\}\right]\end{aligned}$$

为了优化 γ，注意一个简单的观察：$U1_E + V1_{E^c} \ge \min\{U, V\}$。因此，对于任意 x, y，有 $1\{i(x;\ y) \le \gamma\} + \frac{M-1}{2}\exp\{-i(x;\ y)\}1\{i(x;\ y) > \gamma\} > \min(1, \frac{M-1}{2}\exp\{-i(x;\ y)\})$，这可通过 $\gamma = \log\frac{M-1}{2}$ 实现，无论 x, y 如何。因此，我们继续如下界定：

$$\begin{aligned}\inf_\gamma \mathbb{E}[P_e(c_1, \ldots, c_M)] &\le \inf_\gamma \mathbb{E}\left[1\{i(X;Y) \le \gamma\} + \frac{M-1}{2}\exp(-i(X;Y))1\{i(X,Y) > \gamma\}\right] \\ &= \mathbb{E}\left[\min\left(1, \frac{M-1}{2}\exp(-i(X;Y))\right)\right]\end{aligned}$$

$$= \mathbb{E}\left[\exp\left\{-\left(i(X;Y) - \log\frac{M-1}{2}\right)^+\right\}\right].$$

□

注18.3（依赖性检验解释）式(18.11)的右侧等于下述贝叶斯假设检验问题的最小错误概率的$\frac{M+1}{2}$倍：

$$H_0 : X, Y \sim P_{X,Y} \text{ versus } \quad H_1 : X, Y \sim P_X P_Y$$
$$\text{prior prob.: } \pi_0 = \frac{2}{M+1}, \pi_1 = \frac{M-1}{M+1}.$$

注意，$X, Y \sim P_{X,Y}$和$X, \bar{Y} \sim P_X P_Y$，其中X是发送的码字，X是未发送的码字。正如我们从二元假设检验中所知，似然比检验的最佳阈值（使加权错误概率最小）是$\log\frac{\pi_1}{\pi_0}$，正如我们确实发现的那样。

与定理18.5相比，定理18.6的即时优点之一正是我们无需在(18.9)中对τ进行繁琐的最小化，即可得到定理18.5中的最小上界。然而，可以证明，DT界比经过优化的τ下的香农界更紧。另见练习IV.5。

最后，我们指出（并将在下面对线性码的处理中进一步发展这一点），如果我们通过任何其他（非独立同分布）过程生成$\{c_i\}$，且该过程具有指定的边缘分布 *and pairwise independent codewords*，那么DT界和香农界均保持不变——见下文定理18.13。

18.4 费恩斯坦的最大编码界

之前的可达性结果是通过 *probabilistic* 方法（随机编码）获得的。相反，下面由 Feinstein 给出的可达性界采用了 *greedy* 构造。Feinstein 方法的一个直接优势在于，它展示了满足最大错误概率准则的码的存在性。[2]

定理 18.7（范斯坦引理） *Fix a channel $P_{Y|X}$ and an arbitrary input distribution P_X. Then for every $\gamma > 0$ and for every $\epsilon \in (0, 1)$ there exists an $(M, \epsilon)_{\max}$-code with*

$$M \geq \gamma(\epsilon - \mathbb{P}[i(X;Y) < \log\gamma]) \tag{18.12}$$

备注 18.4（与香农界的比较）我们还可以对（18.12）作另一种解释：对于任意固定的M，存在一个$(M, \epsilon)_{\max}$-码，其最大错误概率满足如下上界：

$$\epsilon \leq \mathbb{P}[i(X;Y) < \log\gamma] + \frac{M}{\gamma}$$

[2] Nevertheless, we should point out that this is not a serious advantage: from any (M, ϵ) code we can extract an $(M', \epsilon')_{\max}$-subcode with a smaller M' and larger ϵ' – see Theorem 19.4.

如果我们取 $\log\gamma = \log M + \tau$，这给出的界与香农的(18.9)式形式完全相同。颇为令人惊讶的是，两种如此不同的证明方法产生了本质上相同的界（模除最大错误概率与平均错误概率之间的差异）。我们将在第18.7节讨论这一现象的原因。

Proof. 根据 $(M,\epsilon)_{\max}$-码的定义，我们回顾目标是找到码字 $c_1,\dots,c_M \in \mathcal{X}$ 和不相交子集（解码区域）$D_1,\dots,D_M \subset \mathcal{Y}$，使得

$$P_{Y|X}(D_i|c_i) \geq 1-\epsilon, \forall i \in [M].$$

费恩斯坦的想法是以顺序贪婪的方式构建大小为M的码本。

对于每个 $x \in \mathcal{X}$，将其与如下定义的初步解码区域 E_x 关联起来：

$$E_x \triangleq \{y \in \mathcal{Y} : i(x;y) \geq \log\gamma\}$$

注意，初步解码区域 $\{E_x\}$ 可能重叠，我们将把它们修剪成最终解码区域 $\{D_x\}$，这些区域将是不相交的。接下来，我们应用推论18.4，并发现存在一个集合 $F \subset \mathcal{X}$ 具有两个性质：a) $P_X[F] = 1$ 以及 b) 对于每个 $x \in F$，我们有

$$P_Y(E_x) \leq \frac{1}{\gamma}. \tag{18.13}$$

我们可以假设 $\mathbb{P}[i(X;Y) < \log\gamma] \leq \epsilon$，否则 (18.12) 的右侧为负，没有什么需要证明的。我们首先断言存在某个 $c \in F$ 使得 $\mathbb{P}[Y \in E_c | X = c] = P_{Y|X}(E_c|c) \geq 1-\epsilon$。事实上，假设（为了推出矛盾）$\forall c \in F$，$\mathbb{P}[i(c;Y) \geq \log\gamma | X = c] < 1-\epsilon$。注意到由于 $P_X(F) = 1$，我们可以将这个不等式对 $c \sim P_X$ 取平均。然后我们得到 $\mathbb{P}[i(X;Y) \geq \log\gamma] < 1-\epsilon$，这是一个矛盾。

通过这些准备工作，我们按照以下方式构建码本：

1 选择 c_1 为 F 中的任意码字，使得 $P_{Y|X}(E_{c_1}|c_1) \geq 1-\epsilon$，并设置 $D_1 = E_{c_1}$；2 选择 c_2 为 F 中的任意码字，使得 $P_{Y|X}(E_{c_2}\backslash D_1|c_2) \geq 1-\epsilon$，并设置 $D_2 = E_{c_2}\backslash D_1$；...

3 选择 c_M 为 F 中任意满足 $P_{Y|X}(E_{c_M}\backslash \cup_{j=1}^{M-1} D_j | c_M] \geq 1-\epsilon$ 的码字，并设置 $D_M = E_{c_M}\backslash \cup_{j=1}^{M-1} D_j$。

如果找不到满足要求的 c_{M+1} 码字，我们就停止。因此，M 由停止条件确定：

$$\forall c \in F, P_{Y|X}(E_c \backslash \cup_{j=1}^{M} D_j | c) < 1-\epsilon$$

将停止条件对 $c \sim P_X$ (取平均（由于 $P_X(F) = 1$) 这是允许的），我们得到

$$\mathbb{P}\left[i(X;Y) \geq \log\gamma \text{ and } Y \notin \bigcup_{j=1}^{M} D_j\right] < 1-\epsilon,$$

或者，等价地，{v*}

$$\epsilon < \mathbb{P}\left[i(X;Y) < \log\gamma \text{ or } Y \in \bigcup_{j=1}^{M} D_j \right].$$

将并集界限应用于右侧得到

$$\begin{aligned}\epsilon &< \mathbb{P}[i(X;Y) < \log\gamma] + \sum_{j=1}^{M} P_Y(D_j) \\ &\le \mathbb{P}[i(X;Y) < \log\gamma] + \sum_{j=1}^{M} P_Y(E_{c_j}) \\ &\le \mathbb{P}[i(X;Y) < \log\gamma] + \frac{M}{\gamma}\end{aligned}$$

其中 最后一步利用了(18.13)。显然，这完成了 证明。 □

18.5 RCU与Gallager界

尽管我们目前展示的界对于后续恢复噪声信道编码定理已经足够，但它们并非最优。具体而言，对于给定的 M，人们可以证明错误概率的上界要小得多。其中两个这样的界是所谓的随机编码联合（RCU）界和 Gallager 界，我们在此证明。主要的新要素在于，我们将分析最优的最大似然译码器，而不是像之前那样使用次优的（阈值）译码器。

定理 18.8（RCU 界） *Fix a channel $P_{Y|X}$ and an arbitrary input distribution P_X. Then for every integer $M \ge 1$ there exists an (M,ϵ)-code with*

$$\epsilon \le \mathbb{E}\left[\min\left\{1,\ (M-1)\mathbb{P}\left[i(\bar{X};Y) \ge i(X;Y)\,\middle|\,X,Y\right]\right\}\right], \tag{18.14}$$

where the joint distribution of $(X,\bar{X},Y)$ is as in (18.1)*.*

Proof. 对于给定的码本（$c_1,\dots c_M$），最大似然解码器的平均错误概率，参见（18.8），上界为

$$\epsilon \le \frac{1}{M}\sum_{m=1}^{M}\mathbb{P}\left[\bigcup_{j=1;j\neq m}^{M}\{i(c_j;Y) \ge i(c_m;Y)\}\,|X=c_m\right].$$

注意，这里我们不一定有等式成立，因为最大似然解码器会在信息密度最大的多个码字之间打破平局（即那些使信息密度最大化的多个码字的情况）时倾向于正确的码字，而在上述表达式中，我们悲观地假设所有平局都被错误地解决。现在，类似于定理18.5中的香农界，我们通过对$c_j \overset{\text{i.i.d.}}{\sim} P_X$上的最后一个表达式取平均来证明好码的存在性。

为此，注意到求和中的每一项的期望值（由对称性）是相同的。为了计算这个期望值，让我们对 $W=1$ 取 $m=1$ 的条件，并观察到在这个条件下，我们有

$$(c_1, Y, c_2, \ldots, c_M) \sim P_{X,Y} \prod_{j=2}^{M} P_X \,.$$

考虑到这一观察，我们有以下链 :

$$\begin{aligned}
&\mathbb{P}\left[\bigcup_{j=2}^{M}\{i(c_j;Y) \geq i(c_1;Y)\} \,\middle|\, W=1\right] \\
&\overset{(a)}{=} \mathbb{E}_{(x,y)\sim P_{X,Y}}\left[\mathbb{P}\left[\bigcup_{j=2}^{M}\{i(c_j;Y) \geq i(c_1;Y)\} \,\middle|\, c_1=x, Y=y, W=1\right]\right] \\
&\overset{(b)}{\leq} \mathbb{E}\left[\min\{1, (M-1)\mathbb{P}\left[i(\bar{X};Y) \geq i(X;Y) \,\middle|\, X, Y\right]\}\right]
\end{aligned}$$

其中 (a) 只是通过首先以 (c_1, Y) 的值为条件来表达概率；(b) 对应于应用并集界，但将结果上限设为1。这完成了该界的证明。我们注意到步骤 (b) 是 RCU 界的本质，并对应于一个自明的事实：对于任何事件集合 E_j，我们有

$$\mathbb{P}[\cup E_j] \leq \min\{1, \sum_j \mathbb{P}[E_j]\} \,.$$

其应用巧妙之处在于，我们首先以(c_1, Y)为条件。如果从一开始就不加条件地应用联合界，那么对ϵ的估计将会弱得多（特别是，将无法达到容量）。

□

事实证明，香农界定理18.5仅是根据$i(X$是否成立来分割期望，并在$i(X$时以1为上界min$\{x, 1\}$，而在其他情况下以x为上界，从而从(18.14)得到的一个弱化形式。另一个这样的弱化形式是著名的加拉格尔界[176]，它实际上给出了无记忆信道中错误概率衰减指数的紧估计（第22.4*节）。

定理 18.9（加拉格尔界）*Fix a channel $P_{Y|X}$, an arbitrary input distribution P_X and $\rho \in [0, 1]$. Then there exists an (M, ϵ) code such that*

$$\epsilon \leq M^{\rho} \;\mathbb{E}\left[\left(\mathbb{E}\left[\exp \frac{i(\bar{X};Y)}{1+\rho} \,\middle|\, Y\right]\right)^{1+\rho}\right] \tag{18.15}$$

where again $(\bar{X}, Y) \sim P_X P_Y$ as in (18.1).

关于这种界限的经典写法，参见(22.13)。

Proof. 我们首先注意到，应用命题18.3，以$f_+(x,y) = \exp\{\frac{i(x;y)}{1+\rho}\}$，并交换$X$和$Y$，对于$P_Y$-几乎所有$y$，我们有

$$\mathbb{E}[\exp\{-i(X;Y)\frac{\rho}{1+\rho}\}|Y=y] = \mathbb{E}[\exp\{i(X;\bar{Y})\frac{1}{1+\rho}\}|\bar{Y}=y] = \mathbb{E}[\exp\{i(\bar{X};Y)\frac{1}{1+\rho}\}|Y=y]\,, \tag{18.16}$$

其中我们还利用了在(18.1)下$(X,\bar{Y}) \overset{d}{=} (\bar{X},Y)$这一事实。

现在，考虑约束(18.14)，并用边界替换最小值

$$\min\{t,1\} \le t^\rho \qquad \forall t \ge 0\,. \tag{18.17}$$

这导致 {v*}

$$\epsilon \le M^\rho\, \mathbb{E}\left[\mathbb{P}[i(\bar{X};Y) > i(X;Y)|X,Y]^\rho\right]\,. \tag{18.18}$$

我们应用切尔诺夫界

$$\mathbb{P}[i(\bar{X};Y) > i(X;Y)|X,Y] \le \exp\{-\frac{1}{1+\rho}i(X;Y)\}\,\mathbb{E}[\exp\{\frac{1}{1+\rho}i(\bar{X};Y)\}|Y]\,.$$

将此不等式提升到 ρ 次幂并取期望 $\mathbb{E}[\cdot|Y]$，我们得到

$$\mathbb{E}\left[\mathbb{P}[i(\bar{X};Y) > i(X;Y)|X,Y]^\rho|Y\right] \le \mathbb{E}^\rho[\exp\{\frac{1}{1+\rho}i(\bar{X};Y)|Y]\,\mathbb{E}[\exp\{-\frac{\rho}{1+\rho}i(X;Y)\}|Y]\,.$$

最后一项现在可以通过 (18.16) 重新表达为

$$\mathbb{E}\left[\mathbb{P}[i(\bar{X};Y) > i(X;Y)|X,Y]^\rho|Y\right] \le \mathbb{E}^{1+\rho}[\exp\{\frac{1}{1+\rho}i(\bar{X};Y)|Y]\,.$$

将此估计应用于(18.18)完成了证明。

□

Gallager 的关键创新，即步骤 (18.17)，后来被称为 ρ-技巧，对应于以下版本的并集界：对于任意事件 E_j 和 $0 \le \rho \le 1$，我们有

$$\mathbb{P}[\cup E_j] \le \min\left\{1, \sum_j \mathbb{P}[E_j]\right\} \le \left(\sum_j \mathbb{P}[E_j]\right)^\rho\,.$$

现在要正确理解加拉格尔界的意义，我们首先需要定义无记忆信道的概念（见下文(19.1)）。对于此类信道，并使用独立同分布输入，表达式(18.15)在对ρ进行优化后，变为

$$\epsilon \le \exp\{-nE_r(R)\}\,,$$

其中 $R = \frac{\log M}{n}$ 是速率，$E_r(R)$ 是 Gallager 随机编码指数。这表明不仅固定速率下的错误概率可以趋于零，而且实际上它可以随块长度指数级快速趋于零。我们将在第22.4*节中更详细地讨论这类指数估计。

18.6 线性码

到目前为止，在本章中，我们通过随机编码或极大编码展示了良好纠错码的存在性。所构造的码几乎没有结构。同时，实践中使用的大多数码是所谓的线性码，一个自然的问题是，限制在线性码是否会导致性能损失。在本节中，我们将展示存在良好的线性码。线性码的一个令人愉快的性质是 $P_e = P_{e,\max}$，因此，界定平均错误概率（如香农界中那样）也自动控制最大错误概率。

定义 18.10（线性码）让 $\mathbb{F}_q$ 表示基数为 q (的有限域，参见定义 11.7)。设信道的输入和输出空间为 $\mathcal{X} = \mathcal{Y} = \mathbb{F}_q^n$。如果 $\mathcal{C}$ 是 $\mathbb{F}_q^n$ 的一个 k 维 *linear subspace*，则我们称大小为 $M = q^k$ 的码本 $\mathcal{C} = \{c_u \colon u \in \mathbb{F}_q^k\}$ 为线性码。

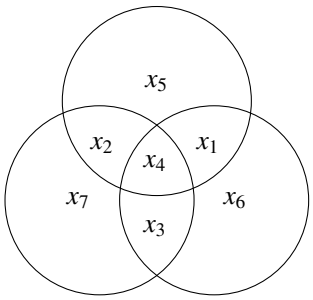
一个线性码可以等价地描述为：

• *Generator matrix* $G \in \mathbb{F}_q^{k\times n}$，因此每个 $u \in \mathbb{F}_q^k$ 的码字由 $c_u = uG$ (行向量约定) 给出，码本 $\mathcal{C}$ 是 G 的行张成空间，记作 $\mathrm{Im}(G)$；• *Parity-check matrix* $H \in \mathbb{F}_q^{(n-k)\times n}$，因此每个码字 $c \in \mathcal{C}$ 满足 $Hc^\top = 0$。因此 $\mathcal{C}$ 是 H 的零空间，记作 $\mathrm{Ker}(H)$。我们有 $HG^\top = 0$。

例 18.1（汉明码）在 $\mathbb{F}_2$ 上的 $[7, 4, 3]_2$ 汉明码是一个线性码，具有以下生成矩阵和奇偶校验矩阵：

$$G = \begin{bmatrix} 1 & 0 & 0 & 0 & 1 & 1 & 0 \\ 0 & 1 & 0 & 0 & 1 & 0 & 1 \\ 0 & 0 & 1 & 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & 1 & 1 & 1 & 1 \end{bmatrix}, \quad H = \begin{bmatrix} 1 & 1 & 0 & 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 1 & 0 & 1 & 0 \\ 0 & 1 & 1 & 1 & 0 & 0 & 1 \end{bmatrix}$$

特别是，G 和 H 具有形式 $G = [I; P]$ 和 $H = [-P^\top; I]$（系统码），因此 $HG^\top = 0$。下图有助于可视化奇偶校验操作：



请注意，每个圆圈中的四位（对应于 H 的一行）之和为零。可以验证，该码的最小距离为3位。因此，它能够纠正1位错误并检测2位错误。

线性码几乎总是与加性噪声信道一起研究，其精确定义如下：

定义 18.11（加性噪声） 如果信道 $P_{Y|X}$ 的输入和输出空间为 $\mathbb{F}_q^n$，则称为加性噪声信道，如果

$$P_{Y|X}(y|x) = P_Z(y-x)$$

对于某个随机向量 Z，其取值在 $\mathbb{F}_q^n$ 中。换句话说，$Y = X + Z$，其中 $Z \perp\!\!\!\perp X$。

给定一个线性码和一个加性噪声信道$P_{Y|X}$，事实证明存在一种最优的特殊“伴随式解码器”。

定理 18.12 *Any $[k,n]_{\mathbb{F}_q}$ linear code over an additive-noise $P_{Y|X}$ has a maximum likelihood (ML) decoder $g : \mathbb{F}_q^n \to \mathbb{F}_q^k$ such that:*

1. *$g(y) = y - g_{\text{synd}}(Hy^\top)$, i.e., the decoder is a function of the "syndrome" $Hy^\top$ only. Here $g_{\text{synd}} : \mathbb{F}_q^{n-k} \to \mathbb{F}_q^n$, defined by $g_{\text{synd}}(s) \triangleq \operatorname{argmax}_{z:Hz^\top = s} P_Z(z)$, is called the "syndrome decoder", which decodes the most likely realization of the noise.*
2. *(Geometric uniformity) Decoding regions are translates of $D_0 = \operatorname{Im}(g_{\text{synd}})$: $D_u = c_u + D_0$ for any $u \in \mathbb{F}_q^k$.*
3. *$P_{e,\text{最大}} = P_e$.*

换句话说，综合征是解码线性码的充分统计量（定义3.8）。

Proof. 1 线性码的最大似然译码器是

$$g(y) = \operatorname*{argmax}_{c\in\mathcal{C}} P_{Y|X}(y|c) = \operatorname*{argmax}_{c:Hc^\top=0} P_Z(y-c) = y - \operatorname*{argmax}_{z:Hz^\top=Hy^\top} P_Z(z) = y - g_{\text{synd}}(Hy^\top).$$

2 对于任何 u，解码区域

$$D_u = \{y : g(y) = c_u\} = \{y : y - g_{\text{synd}}(Hy^\top) = c_u\} = \{y : y - c_u = g_{\text{synd}}(H(y-c_u)^\top)\} = c_u + D_0,$$

其中我们使用了$Hc_u^\top = 0$和$c_0 = 0$。

3 对于任何 u，

$$\mathbb{P}[\hat{W} \neq u | W = u] = \mathbb{P}[g(c_u+Z) \neq c_u] = \mathbb{P}[c_u + Z - g_{\text{synd}}(Hc_u^\top + HZ^\top) \neq c_u] = \mathbb{P}[g_{\text{synd}}(HZ^\top) \neq Z].$$

□

注 18.5（BSC 例子）作为一个具体示例，考虑之前在第 17.1 节和 17.2 节中讨论过的二元对称信道 $\mathsf{BSC}_\delta^{\otimes n}$。这是 $\mathbb{F}_2^n$ 上的一个加性噪声信道，其中 $Y = X + Z$ 和 $Z = (Z_1, \ldots, Z_n) \overset{\text{i.i.d.}}{\sim} \text{Ber}(\delta)$。假设 $\delta < 1/2$，则校验子

解码器的目标是找到与接收到的码字兼容的翻转次数最少的噪声实现，即$g_{\text{synd}}(s) = \text{argmin}_{z:Hz^\top = s} w_{\text{H}}(z)$，其中$w_{\text{H}}$表示汉明重量。在这种情况下，$g_{\text{synd}}$的像中的元素，我们记作$D_0$，被称为“最小重量陪集首”。统计每个汉明重量下这些元素的数量，即使对于诸如里德-穆勒码这样研究得最为透彻的码来说，仍是一个未解决的难题。在汉明空间D_0中，看起来像是格的Voronoi区域，而D_u构成了$\mathbb{F}_q^n$的Voronoi镶嵌。

绝大多数实际使用的码实际上都是线性码。在编码理论的早期，线性被视为实现快速 *low-complexity encoding* (仅二进制矩阵乘法)及稍微降低最大似然解码复杂度（通过伴随式解码器）的途径。然而，随着码变得越来越长，伴随式解码变得不切实际，如今在实践中仅使用那些具有快速且低复杂度（次优）解码器的码。

定理 18.13（线性码的 DT 界）*Let $P_{Y|X}$ be an additive noise channel over $\mathbb{F}_q^n$. For all integers $k \geq 1$ there exists a linear code $f : \mathbb{F}_q^k \to \mathbb{F}_q^n$ with error probability:*

$$P_{e,\max} = P_e \leq \mathbb{E}\left[q^{-\left(n-k-\log_q \frac{1}{P_Z(Z)}\right)^+}\right]. \tag{18.19}$$

注18.6 上述界限与使用$P_X = \text{Unif}(\mathbb{F}_q^n)$评估的定理18.6相同。定理18.6与18.13之间的类比，犹如定理11.5与11.8之间的类比（完全随机编码与随机线性码）。

Proof. 回想一下，在证明DT界（定理18.6）时，我们选择了码字$c_1, \ldots, c_M \overset{\text{i.i.d.}}{\sim} P_X$，并证明了

$$\mathbb{E}[P_e(c_1, \ldots, c_M)] \leq \mathbb{P}[i(X;Y) \leq \gamma] + \frac{M-1}{2}\mathbb{P}[i(\overline{X};Y) \geq \gamma]$$

这里我们将采用相同的方法，取$P_X = \text{Unif}(\mathbb{F}_q^n)$ 和$M = q^k$。

根据定理18.12，最优解码区域具有平移不变性，即$D_u = c_u + D_0, \forall u$，因此：

$$P_{e,\max} = P_e = \mathbb{P}[\hat{W} \neq u | W = u], \forall u.$$

第1步：带抖动的随机线性编码：令码字为 cho 作为

$$c_u = uG + h, \quad \forall u \in \mathbb{F}_q^k$$

其中随机 G 和 h 的抽取方式如下：G 的 $k \times n$ 个条目和 h 的 $\times n$ 个条目独立同分布于 $\mathbb{F}_q$ 上的均匀分布。我们加入抖动以消除全零码字所起的特殊作用（因为它包含在任何线性码本中）。

步骤2：我们断言码字是成对独立且均匀的，即$\forall u \neq u'$，$(c_u, c_{u'}) \sim (X, \overline{X})$，其中$P_{X,\overline{X}}(x, \bar{x}) = 1/q^{2n}$。为了验证这一点，请注意

$$c_u \sim \text{uniform on } \mathbb{F}_q^n$$
$$c_{u'} = u'G + h = uG + h + (u' - u)G = c_u + (u' - u)G$$

我们断言 $c_u \perp\!\!\!\perp G$，因为在给定生成矩阵 $G = G_0$ 的条件下，由于抖动 h，$c_u \sim$ 在 $\mathbb{F}_q^n$ 上均匀分布。
我们还声称 $c_u \perp\!\!\!\perp c_{u'}$，因为条件于 c_u，$(u' - u)G \sim$ 在 $\mathbb{F}_q^n$ 上均匀分布。
因此，带有抖动的随机线性编码确实使得码字 $c_u, c_{u'}$ 成对独立且均匀分布。

步骤3：在证明对称且成对独立的码字的DT界时，重复相同的论证，我们得到

$$\mathbb{E}[P_e(c_1, \ldots, c_M)] \leq \mathbb{E}[\exp\{-\big(i(X;Y) - \log \frac{M-1}{2}\big)^+\}] = \mathbb{E}[q^{-\left(i(X;Y) - \log_q \frac{q^k - 1}{2}\right)^+}] \leq \mathbb{E}[q^{-\left(i(X;Y) - k\right)^+}]$$

其中我们使用了$M = q^k$，并选择对数的底数为q。
步骤4：计算 $i(X;\ Y)$：

$$i(a;b) = \log_q \frac{P_Z(b-a)}{q^{-n}} = n - \log_q \frac{1}{P_Z(b-a)}$$

因此

$$P_e \leq \mathbb{E}[q^{-\left(n - k - \log_q \frac{1}{P_Z(Z)}\right)^+}] \tag{18.20}$$

步骤5：去除抖动 h。我们声称存在一个无抖动的线性码，使得(18.20)得到满足。直观上，移动码本对其性能没有影响。实际上，

• 之前，通过抖动，编码器将 u 映射为 $uG+h$，信道添加噪声生成 $Y = uG + h + Z$，解码器 g 输出 $g(Y)$。• 现在，不进行抖动，我们将 u 编码为 uG，信道添加噪声生成 $Y = uG + Z$，并且我们应用由 $g'(Y) = g(Y + h)$ 定义的解码 g'。

通过这样做，我们在解码器端“模拟”了抖动，错误概率与之前相同。注意，这得益于噪声信道的加性特性。

□

我们看到，随机编码可以使用不同的码本集合来实现。例如，我们有

• 香农系综：$\mathcal{C} = \{c_1, \ldots, c_M\} \overset{\text{i.i.d.}}{\sim} P_X$ – 完全随机系综。• 埃利亚斯系综[150]：$\mathcal{C} = \{uG$: $u \in \mathbb{F}_q^k\}$，其中$k \times n$生成矩阵G是从所有矩阵集合中均匀随机抽取的。（此系综用于定理18.13的证明。）• 加拉格尔系综：$\mathcal{C} = \{c$: $Hc^\top = 0\}$，其中$(n-k) \times n$奇偶校验矩阵H是均匀随机抽取的。注意这与埃利亚斯系综不同。

- Elias 集成的一个问题是，以某种非零概率 G 可能无法满秩。（寻找 $\mathbb{P}[\mathrm{rank}(G) < k]$ 作为 n, k, q 的函数是一个很好的练习。）如果 G 不满秩，则存在两个相同的码字，因此 $P_{e,\max} \geq 1/2$。为了解决这个问题，可以令生成矩阵 G 在所有满（行）秩的 $k \times n$ 矩阵集合上均匀分布。
- 类似地，我们可以通过取校验矩阵 H 在全体 $n \times (n-k)$ 满秩矩阵上均匀分布，来修改 Gallager 的集合。

对于修改后的Elias和Gallager集合，我们仍然可以进行随机编码分析。一个小小的修改是注意到这一次$(X, \bar{X})$将具有分布

$$P_{X,\bar{X}} = \frac{1}{q^{2n} - q^n} 1\{X \neq X'\}$$

在所有*distinct*码字对上都均匀分布，并且是*not*两两独立的。

最后，我们注意到带有抖动的Elias集合，$c_u = uG + h$，具有成对独立性，其联合熵为 $H(c_1, \ldots, c_M) = H(G) + H(h) = (nk + n) \log q$。这比我们在定理18.5中使用的香农完全随机集合的熵要小得多。实际上，当$c_j \overset{\text{i.i.d.}}{\sim}$服从Unif$(\mathbb{F}_q^n)$分布时，我们有$H(c_1, \ldots, c_M) = q^k n \log q$。因此，一个有趣的问题是寻找

$$\min H(c_1, \ldots, c_M)$$

其中最小值是在所有满足 $P[c_i = a, c_j = b] = q^{-2n}$ 的分布上取得，当 $i \neq j$ (为成对独立、均匀码字)时。注意 $H(c_1, \ldots, c_M) \geq H(c_1, c_2) = 2n \log q$。类似地，我们可以要求 (c_i, c_j) 在所有 *distinct* 个元素的配对上是均匀的。在这种情况下，针对 $n = 2k$ 情形的 Wozencraft 集合（见练习 IV.7）达到了 $H(c_1, \ldots, c_{q^k}) \approx 2n \log q$，这基本上就是我们的下界。

18.7 为何随机编码和最大编码效果良好?

正如我们稍后将看到的，本章所推导的界限在渐近和非渐近情况下都非常紧凑。也就是说，通过随机选择码字或贪婪增长码本这些看似相当朴素的过程所构造的码，在许多方面被证明基本上是优的。另一个谜团是，我们通过这两个相当不同的过程得到的界限几乎是相同的。自信息论早期以来，这些问题一直困扰着研究人员。

一个相当令人满意的理由最终在Barman和Fawzi的一篇优雅著作[36]中给出。在深入细节之前，我们想明确指出我们想要探讨的两个问题:

1 为什么贪心过程接近最优? 2 为什么随机编码过程（使用简单的 P_X）接近最优?

简而言之，我们将看到，对于子模函数最大化问题，这两种方法众所周知（几乎）都是最优的，而这正是信道编码的核心所在。

在继续之前，我们注意到在第二个问题中，重要的是要限定P_X是简单的，因为将P_X取为支持在最优的$M^*(\epsilon)$实现码本上当然会带来非常好的性能。然而，相反地，我们将看到选择相当简单的P_X已经能在$M^*(\epsilon)$上达到相当好的下界。更明确地说，所谓简单，我们指的是无记忆信道的乘积分布。或者，作为一个更好的例子来考虑，设想一个加性噪声向量信道：

$$Y^n = X^n + Z^n$$

在产品阿贝尔群上加法运算，以及任意（甚至非无记忆）噪声Z^n的情况下。在这种情况下，随机编码界中选择均匀P_X是可行的，并且绝对是“简单”的。

[36]的关键观察是函数将码本$\mathcal{C} \subset \mathcal{X}$映射到$|\mathcal{C}|(1 - P_{e,MAP}(\mathcal{C}))$的*submodularity*，其中$P_{e,MAP}(\mathcal{C})$是MAP解码器（17.5）下的错误概率。（回顾（1.8）关于子模性的定义。）更明确地说，考虑一个离散的$\mathcal{Y}$并定义

$$S(\mathcal{C}) \triangleq \sum_{y\in\mathcal{Y}} \max_{x\in\mathcal{C}} P_{Y|X}(y|x)\,, \qquad S(\emptyset) = 0$$

显然，$S(\mathcal{C})$ 作为子模非递减函数 max 的和（即对于任意 ϕ，$T \mapsto \max_{x\in T}\phi(x)$ 是子模的）是子模非递减的。另一方面，$P_{e,MAP}(\mathcal{C}) = 1 - \frac{1}{|\mathcal{C}|}S(\mathcal{C})$，因此寻找最小误差码本等价于最大化集合函数 S。

找到 {v*} 的问题

$$S^*(M) \triangleq \max_{|\mathcal{C}|\le M} S(\mathcal{C})$$

在[313]的一项开创性工作中，算法上解决了这一问题，展示了贪婪过程的（近似）最优性。考虑以下构建一系列优良集$\mathcal{C}_t$的自然贪婪过程。从$\mathcal{C}_0 = \emptyset$开始。在每一步找到任意

$$x_{t+1} \in \operatorname*{argmax}_{x\notin\mathcal{C}_t} S(\mathcal{C}_t \cup \{x\})$$

并设置 {v*}

$$\mathcal{C}_{t+1} = \mathcal{C}_t \cup \{x_{t+1}\}\,.$$

他们证明了

$$S(\mathcal{C}_t) \ge (1 - 1/e)\max_{|\mathcal{C}|=t} S(\mathcal{C})\,.$$

换句话说，对于贪心构造的码本，成功（MAP）解码的概率与具有相同基数的所有码本中可能的最大成功概率之间的差距至多是一个因子 $(1 - 1/e)$。由于我们主要关注非常接近 1 的成功概率，这个结果可能看起来并不令人兴奋。然而，对该论证稍作修改即可得到以下结果（证明见 [257, 定理 1.5]）：

定理 18.14 ([313]) *For any non-negative submodular set-function f and a greedy sequence $\mathcal{C}_t$ we have for all ℓ, t:*

$$f(\mathcal{C}_\ell) \geq (1 - e^{-\ell/t}) \max_{|\mathcal{C}|=t} f(\mathcal{C}) .$$

将这个应用到$f(\cdot) = S(\cdot)$的特殊情况，我们得到[36]的结果：贪婪构造的码本$\mathcal{C}'$，包含M'个码字，满足

$$1 - P_{e,MAP}(\mathcal{C}') \geq \frac{M}{M'}(1 - e^{-M'/M})(1 - \epsilon^*(M)) .$$

特别是，使用$M' = M2^{-10}$贪婪构造的码达到的成功概率为$\geq 0.9995(1-\epsilon^*(M))$。换句话说，与最佳可能的码相比，携带少10位数据的贪婪码在最坏情况下错误概率仅差$5 \cdot 10^{-4}$。*This is a very compelling evidence for why greedy construction is so good.* 然而，我们确实注意到，Feinstein的界并不是用MAP解码器进行贪婪构造，而是用次优解码器。

接下来我们讨论*random coding*的问题。回顾一下，我们的目标是解释为什么从“简单”分布P_X中均匀随机选择码字会有任何好处。关键思想同样包含在[313]中。集合函数$S(\mathcal{C})$也可以理解为定义域为$\{0,1\}^{|\mathcal{X}|}$的函数。下面给出该函数到整个实心超立方体$[0,1]^{|\mathcal{X}|}$的一个自然推广：

$$S_{LP}(\pi) = \sup\{\sum_{x,y} P_{Y|X}(y|x) r_{x,y} : 0 \leq r_{x,y} \leq \pi_x, \sum_x r_{x,y} \leq 1\} . \tag{18.21}$$

事实上，很容易看出$S_{LP}(1_{\mathcal{C}}) = S(\mathcal{C})$且$S_{LP}$是一个凹函数。[3]

由于 S_{LP} 是 S 的扩展，显然

$$S^*(M) \leq S^*_{LP}(M) \triangleq \max\{S_{LP}(\pi) : 0 \leq \pi_x \leq 1, \sum_x \pi_x \leq M\} . \tag{18.22}$$

实际上，我们将在第22.3节中看到，这个界限与被称为元逆的界限相吻合。令人惊讶的是，[313]表明，贪婪构造不仅实现了$S^*(M)$的大倍数，而且还实现了$S^*_{LP}(M)$：

$$S(\mathcal{C}_M) \geq (1 - e^{-1}) S^*_{LP}(M) . \tag{18.23}$$

这个结果的重要性（它特定于子模函数$\mathcal{C} \mapsto \sum_y \max_{x \in \mathcal{C}} g(x,y)$）在于，它给出了最早将组合优化$S^*(M)$的值与线性规划松弛$S^*_{LP}(M)$的值联系起来的整性间隙结果之一：$(1 - e^{-1}) S^*_{LP}(M) \leq S^*(M) \leq S^*_{LP}(M)$。

也可以证明（18.23）的一个类似于前述定理的扩展：对于所有 M', M，我们有

$$S(\mathcal{C}_{M'}) \geq (1 - e^{-M'/M}) S^*_{LP}(M) .$$

[3] There are a number of standard extensions of a submodular function f to a hypercube. The largest convex interpolant f_+, also known as Lovász extension, the least concave interpolant f_-, and multi-linear extension [80]. However, S_{LP} does not coincide with any of these and in particular strictly larger (in general) than f_-.

不过，要将其与随机编码的概念联系起来，我们需要以下[36]的结果：[4]

定理 18.15 *Fix* $\pi \in [0,1]^{|\mathcal{X}|}$ *and let* $M = \sum_{x\in\mathcal{X}} \pi_x$. *Let* $\mathcal{C} = \{c_1, \ldots, c_{M'}\}$ *with* $c_j \overset{i.i.d.}{\sim} P_X(x) = \frac{\pi_x}{M}$. *Then we have*

$$\mathbb{E}[S(\mathcal{C})] \geq (1 - e^{-M'/M}) S_{LP}(\pi) .$$

该结果的证明可平凡地从应用以下引理得出，其中 $g(x) = P_{Y|X}(y|x)$，对 y 求和，并回顾 (18.21) 中 S_{LP} 的定义。

引理 18.16 *Let* π *and* $\mathcal{C}$ *be as in Theorem. Let* $g : \mathcal{X} \to \mathbb{R}$ *be any function and denote* $T(\pi, g) =$ 最大值$\{\sum_x r_x g(x) : 0 \leq r_x \leq \pi_x, \sum_x r_x = 1\}$. *Then*

$$\mathbb{E}[\max_{x\in\mathcal{C}} g(x)] \geq (1 - e^{-M'/M}) T(\pi, g) .$$

Proof. 不失一般性，我们取 $\mathcal{X} = [m]$ 和 $g(1) \geq g(2) \geq \cdots \geq g(m) \geq g(m+1) \triangleq 0$。为方便起见，记 $a = 1 - (1 - \frac{1}{M})^{M'} \geq 1 - e^{-M'/M}$，$b(j) \triangleq \mathbb{P}[\{1, \ldots, j\} \cap \mathcal{C} \neq \emptyset]$。则

$$\mathbb{P}[\max_{x\in\mathcal{C}} g(x) = g(j)] = b(j) - b(j-1) ,$$

并且通过分部求和我们得到

$$\mathbb{E}[\max_{x\in\mathcal{C}} g(x)] = \sum_{j=1}^{m} (g(j) - g(j+1)) b(j) . \tag{18.24}$$

另一方面，记$c(j) =$为$\min(\sum_{i\leq j} \pi_i, 1)$。现在根据$b(j)$的定义，我们有

$$b(j) = 1 - (1 - \frac{\pi_1 + \ldots \pi_j}{M})^{\ell} \geq 1 - (1 - \frac{c(j)}{M})^{M'} .$$

从简单不等式 $(1 - \frac{x}{M})^{M'} \leq 1 - ax$ (对任意 $x \in [0,1]$) 成立，我们得到

$$b(j) \geq a c(j) .$$

将其代入(18.24)中，我们通过注意到$r_j = c(j) - c(j-1)$在$T(\pi, g)$的定义中达到最大值来完成证明。 □

定理 18.15 完成了本节的目标，并表明随机编码（以及贪婪/极大编码）达到了 $S^*(M)$ 的几乎最优值。另请注意，我们应该使用的随机编码分布是达到 $S^*_{LP}(M)$ 定义的分布。对于输入对称信道（如加性噪声信道），很容易证明最优的 $\pi \in [0,1]^{\mathcal{X}}$ 是一个常数向量，因此码字应在 $\mathcal{X}$ 上独立同分布均匀生成。

[4] There are other ways of doing "random coding" to produce an integer solution from a fractional one. For example, see the multi-linear extension based one in [80].

19 Channel capacity

在本章中，我们运用前几章所发展的方法（即弱逆定理与随机/最大编码可达性）来计算信道容量。后者这一概念量化了在多次使用信道的极限情况下，能够可靠通信的最大（数据）比特量*per single channeluse*。形式化后一陈述需要引入通信信道的概念。随后，对于特殊类型的信道（无记忆信道与信息稳定信道），我们将证明计算信道容量归结为最大化（序列的）互信息。这一结果被称为香农噪声信道编码定理，是本书中编码定理的第三个例子。它将定义在码本上的操作型（离散、组合）优化问题的值与定义在信息度量上的（凸）优化问题的值联系起来。它在信息度量的抽象（第一部分）与信道编码的实际工程问题之间架起了一座桥梁。

信息论作为一门学科，有时被指责为“渐近乐园”，即痴迷于渐近结果和计算各种极限。尽管在本书中我们试图避免渐近乐园，但本章的主题要求犯下这一罪过*ipso facto*。在证明了各种设置下的容量定理后，我们以香农分离定理结束本章，该定理表明，任何（平稳遍历）源都可以在（信息稳定）信道上传输，当且仅当其熵率小于信道容量。此外，这样做可以通过首先将源压缩为纯比特，然后使用信道编码将这些比特匹配到信道输入来实现。在转换为比特的过程中没有性能损失这一事实，在巩固*bits*作为数字时代的通用货币方面具有重要的历史意义。

19.1 信道与信道容量

正如我们在第17章中讨论的，数据传输的主要信息论问题如下：如果允许使用给定的噪声信道n次，能够可靠地传输多少比特？每信道使用所对应的消息比特数的归一化量被称为*rate*，而*capacity*指的是在小的解码错误概率下可达到的最高速率。然而，“多次使用信道”意味着什么？我们如何形式化信道使用的概念？为此，我们需要改变“信道”这一术语的含义。到目前为止，在本书中我们一直将术语*channel*用作马尔可夫核（定义2.10）的同义词。然而，更准确地说，这个术语应该用来指代以下概念。

定义 19.1 固定一个输入字母表 $\mathcal{A}$ 和一个输出字母表 $\mathcal{B}$。一个由整数 $n = 1, 2 \ldots$ 索引的马尔可夫核序列 $P_{Y^n|X^n} : \mathcal{A}^n \to \mathcal{B}^n$ 被称为 *channel*。输入 n 的长度被称为 *blocklength*。

为了赋予这个抽象概念更具体的形式，我们应回顾第17.2节，其中我们描述了BSC信道。然而，请注意，尽管有这个定义，习惯上使用术语*channel*来指代单个马尔可夫核（正如我们在本书之前所做的那样）。更糟糕但更常见的术语滥用是将序列中的第n个元素，即核$P_{Y^n|X^n}$，称为n字母信道。

尽管我们未对核序列$P_{Y^n|X^n}$施加任何要求，但在如此泛化的层面上，人们通常并不关注信道。多数情况下，信道输入$X^n = (X_1, \ldots, X_n)$的元素被视为按时间索引。即X_t对应在整体块长度为n的时间t发送的字母，而Y_t是在时间t接收到的字母。信道的作用是对X_t添加噪声并输出Y_t。然而，先前定义的广泛性允许建模信道具有内部状态的情况，因此对X_t添加的噪声的量和类型依赖于之前的输入，原则上甚至依赖于未来的输入。不过，将t解释为时间并非唯一。在存储（磁性、非易失性或闪存）中，t索引空间。在这些应用中，噪声可能具有相当复杂的结构，其变换$X_t \to Y_t$同时取决于“过去” $X_{<t}$和“未来” $X_{>t}$。

几乎所有感兴趣的通道都满足我们接下来列出的一项或多项限制：

• 如果一个信道具有以下扩展性质，则称为 *non-anticipatory*。在 n 字母核 $P_{Y^n|X^n}$ 下，前 k 个输出符号 Y^k 的条件分布仅取决于 X^k (，而不取决于 X_{k+1}^n)，并且与核 $P_{Y^k|X^k}$ (（信道序列的第 k 个元素)，即序列中的第 k 个信道转移核）一致。这一要求建模了信道输出因果地依赖于输入的情景。• 如果 $\mathcal{A}$ 和 $\mathcal{B}$ 是有限的，则信道是 *discrete*。• 如果 $\mathcal{A} = \mathcal{B}$ 是阿贝尔群且对于某个独立于 X^n (的 Z^n，有 $Y^n = X^n + Z^n$（见定义 18.11 ））， 则信道是 *additive-noise*。因此

$$P_{Y^n|X^n}(y^n|x^n) = P_{Z^n}(y^n - x^n).$$

• 如果一个信道是 *memoryless*，当且仅当 $P_{Y^n|X^n}$ 可分解为乘积分布。即，

$$P_{Y^n|X^n} = \prod_{k=1}^{n} P_{Y_k|X_k}. \tag{19.1}$$

其中每个 $P_{Y_k|X_k}$: $\mathcal{A} \to \mathcal{B}$; 特别是，$P_{Y^n|X^n}$ 在不同块长度 n 下是兼容的。

• 若(19.1)式满足且$P_{Y_k|X_k}$不依赖于k，则称信道为*stationary memoryless*，通常记作$P_{Y|X}$。换言之，

$$P_{Y^n|X^n} = (P_{Y|X})^{\otimes n}. \tag{19.2}$$

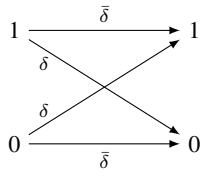
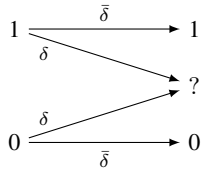
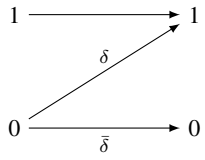
Channel	Bipartite graph	Channel matrix
BSC_δ		$\begin{bmatrix} \bar{\delta} & \delta \\ \delta & \bar{\delta} \end{bmatrix}$
BEC_δ		$\begin{bmatrix} \bar{\delta} & \delta & 0 \\ 0 & \delta & \bar{\delta} \end{bmatrix}$
Z-channel		$\begin{bmatrix} 1 & 0 \\ \delta & \bar{\delta} \end{bmatrix}$

表19.1 DMC示例。

因此，在离散情况下，我们有

$$P_{Y^n|X^n}(y^n|x^n) = \prod_{k=1}^{n} P_{Y|X}(y_i|x_i). \tag{19.3}$$

解释是，传输码字 X^n 的每个坐标都独立地受到具有相同噪声统计特性的噪声影响。

- 离散无记忆平稳信道（DMC）：DMC 是一种既离散又平稳无记忆的信道。它可以通过两种方式来指定：

  – 一个 $|\mathcal{A}| \times |\mathcal{B}|$ 维（行随机）矩阵 $P_{Y|X}$，其元素指定转移概率；

  – 一种二分图，其边权重指定了非零转移概率。表19.1列出了一些常见的二进制输入二进制输出离散无记忆信道：二进制对称信道(BSC)、二进制擦除信道(BEC)和Z信道。

再举一个例子，让我们回顾一下例3.3中的AWGN信道：字母表$\mathcal{A} = \mathcal{B} = \mathbb{R}$和 $Y^n = X^n + Z^n$，其中$X^n \perp\!\!\!\perp Z^n \sim \mathcal{N}(0, \sigma^2 I_n)$。这个信道是一个非离散、平稳无记忆的加性噪声信道。

在定义了信道的概念之后，我们接下来可以定义通信工程师在面临通过信道建立数据链路任务时所面临的操作问题。由于信道存在噪声，数据不会无扰地传输，因此纠错码是

自然会采用。为了以低错误概率发送 $M=$ 个 2^k 消息（或 k 个数据比特），通常希望使用尽可能短的输入序列长度。这一愿望解释了以下定义，这些定义将定义 17.2 中的基本极限扩展为涉及块长度 n。

定义 19.2（信道编码的基本极限）

• 一个 (n,M,ϵ) 码是 $P_{Y^n|X^n}$ 的 (M,ϵ) 码，由一个编码器 $f:[M]\to\mathcal{A}^n$ 和一个解码器 $g:\mathcal{B}^n\to[M]\cup\{\mathsf{e}\}$ 组成。• 一个 $(n,M,\epsilon)_{\max}$ 码类似地根据最大错误概率定义。

（非渐近）基本极限是

$$\begin{aligned} M^*(n,\epsilon) &= \max\{M:\exists\ (n,M,\epsilon)\text{-code}\}, && (19.4)\\ M^*_{\max}(n,\epsilon) &= \max\{M:\exists\ (n,M,\epsilon)_{\max}\text{-code}\} \\ \epsilon^*(n,M) &= \inf\{\epsilon:\exists(n,M,\epsilon)\text{-code}\} && (19.5)\\ \epsilon^*_{\max}(n,M) &= \inf\{\epsilon:\exists(n,M,\epsilon)_{\max}\text{-code}\}\,. \end{aligned}$$

我们将主要关注理解 $M^*(n,\epsilon)$ 以及一个称为速率的关联量。回想一下，块长度 n 衡量了编码所使用的时间或空间资源的量。因此，自然地，我们会最大化传输数据与所使用资源的比率，这就引出了 *the transmission rate* 的概念，定义为 $R=\frac{\log_2 M}{n}$，等于每次信道使用传输的比特数。因此，与其研究 $M^*(n,\epsilon)$，人们被引导去研究 $\frac{1}{n}\log M^*(n,\epsilon)$。一个自然的第一个问题是确定该量的一阶渐近性，这促使了本节的最终定义。

定义 19.3（信道容量）ϵ-*capacity* C_ϵ 和 *Shannon capacity* C 定义如下

$$\begin{aligned} C_\epsilon &\triangleq \liminf_{n\to\infty}\frac{1}{n}\log M^*(n,\epsilon);\\ C &= \lim_{\epsilon\to 0+} C_\epsilon. \end{aligned}$$

信道容量以每次信道使用的信息单位来衡量，例如“比特/信道使用”。

C_ϵ (分别是C)的操作意义是：在错误概率至多为ϵ (（分别地，$o(1)$)）的情况下，通过有噪信道进行通信所能达到的最大速率。换言之，对于任意$R<C$，存在一个$(n,\exp(nR),\epsilon_n)$-码，使得$\epsilon_n\to 0$。就此而言，C_ϵ和C可以等价地定义如下：

$$\begin{aligned} C_\epsilon &= \sup\{R:\forall\delta>0,\exists n_0(\delta),\forall n\ge n_0(\delta),\exists(n,\exp(n(R-\delta)),\epsilon)\text{-code}\}\\ C &= \sup\{R:\forall\epsilon>0,\forall\delta>0,\exists n_0(\delta,\epsilon),\forall n\ge n_0(\delta,\epsilon),\exists(n,\exp(n(R-\delta)),\epsilon)\text{-code}\} \end{aligned}$$

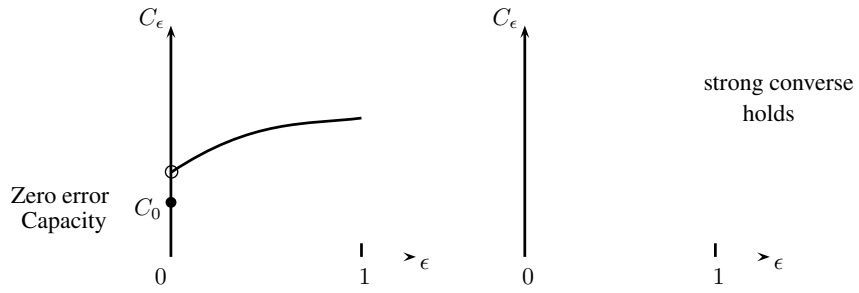
将容量定义为大-n极限（而不是n上的上确界）的原因在于，我们关注的是无差错传输大量数据（如通信和存储中）的速率限制。

零错误（$\epsilon = 0$）的情形与$\epsilon > 0$如此不同，以至于$\epsilon = 0$的主题构成了一个独立的子领域（参见综述[252]）。该值由香农于1956年引入[379],

$$C_0 \triangleq \liminf_{n\to\infty} \frac{1}{n} \log M^*(n, 0) \tag{19.6}$$

被称为 *zero-error capacity*，表示在完全没有错误的情况下可达到的最大速率。刻画 C_0 的值通常是一个困难的组合问题。然而，对于许多实际相关的信道，证明 $C_0 = 0$ 是相当平凡的。例如，对于我们之前考虑过的 DMC：BSC 或 BEC，就是这种情况。事实上，对于它们，我们有 $\log M^*(n, 0) = 0$ 对所有 n 成立，这意味着要在这些信道上传输任意数量的信息，都需要接受一定的（也许是极其微小的）错误概率。尽管如此，仍存在某些有趣且重要的信道，其 C_0 为正，更多内容参见第 23.3.1 节。

作为ϵ的函数，C_ϵ可能（最一般地）表现得像下面左侧的图一样。它可能在$\epsilon = 0$处不连续，并且在ϵ中可能单调递增（甚至可能有跳跃不连续）。然而，通常C_ϵ在$\epsilon = 0$处为零，并且对于所有$0 < \epsilon < 1$保持恒定，因此与C (一致{见右侧的图v25}。在这种情况下，我们说*strong converse*成立（更多内容见后面第22.1节）。



在定义19.3中，容量C_ϵ和C是相对于平均错误概率定义的。通过将M^*替换为$M^*_{\max}$，我们可以类似地定义相对于最大错误概率的容量$C_\epsilon^{(\max)}$和$C^{(\max)}$。事实证明，这两种定义是等价的，如下一个定理所示。

定理 19.4 $\forall \tau \in (0, 1)$,

$$\tau M^*(n, \epsilon(1-\tau)) \le M^*_{\max}(n, \epsilon) \le M^*(n, \epsilon)$$

Proof. 第二个不等式是显然的，因为任何达到最大错误概率 ϵ 的代码也达到平均错误概率 ϵ。

对于第一个不等式，取一个 $(n, M, \epsilon(1-\tau))$-码，并将第 j^{th} 个码字的错误概率定义为

$$\lambda_j \triangleq \mathbb{P}[\hat{W} \neq j | W = j]$$

然后

$$M(1-\tau)\epsilon \geq \sum \lambda_j = \sum \lambda_j 1\{\lambda_j \leq \epsilon\} + \sum \lambda_j 1\{\lambda_j > \epsilon\} \geq \epsilon |\{j : \lambda_j > \epsilon\}|.$$

因此 $|\{j:\ \lambda_j > \epsilon\}| \leq (1-\tau)M$。（注意这正是马尔可夫不等式。）现在通过移除那些 λ_j 超过 ϵ 的码字 [1]，我们可以提取出一个 $(n, \tau M, \epsilon)_{\max}$-码。最后，取 $M = M^*(n, \epsilon(1-\tau))$ 来完成证明。 □

推论 19.5（最大错误概率下的容量）$C_\epsilon^{(\max)} = C_\epsilon$ *for all* $\epsilon > 0$ *such that* $C_\epsilon = C_{\epsilon-}$. *In particular,* $C^{(\max)} = C$.

Proof. 使用 M^* 的定义及前一定理，对于任意固定的 $\tau > 0$

$$C_\epsilon \geq C_\epsilon^{(\max)} \geq \liminf_{n\to\infty} \frac{1}{n} \log \tau M^*(n, \epsilon(1-\tau)) \geq C_{\epsilon(1-\tau)}$$

发送 $\tau \to 0$ 得到 $C_\epsilon \geq C_\epsilon^{(\max)} \geq C_{\epsilon-}$。 □

19.2 香农噪声信道编码定理

既然我们已经有了香农容量的基本定义，现在定义另一种类型的容量，并证明对于 *stationary memoryless*信道，这两种容量概念（“操作”和“信息”）是相同的。

定义19.6 一个信道的*information capacity*是

$$C^{(\mathrm{I})} = \liminf_{n\to\infty} \frac{1}{n} \sup_{P_{X^n}} I(X^n; Y^n),$$

其中对于每个 n，上确界取自 $\mathcal{A}^n$ 上的所有联合分布 P_{X^n}。

注意，如此定义的信息容量 $C^{(\mathrm{I})}$ 与定义 19.3 中的香农容量 C 并不相同；因此，从基本原理来看，它没有直接的解释为与编码相关的操作量。尽管如此，它们通过以下 *coding theorems* 相关联。我们从一个逆定理结果开始：

定理 19.7（C_ϵ 的上界）*For any channel,* $\forall \epsilon \in [0, 1)$, $C_\epsilon \leq \frac{C^{(\mathrm{I})}}{1-\epsilon}$ *and* $C \leq C^{(\mathrm{I})}$.

[1] This operation is usually referred to as *expurgation* which yields a smaller code by killing part of the codebook to reach a desired property.

Proof. 将定理17.3中的一般弱 converse 界应用于 $P_{Y^n|X^n}$ 得到

$$\log M^*(n,\epsilon) \le \frac{\sup_{P_{X^n}} I(X^n;Y^n)+h(\epsilon)}{1-\epsilon}$$

将其按 n 归一化并取 $n\to\infty$ 时的下极限，我们有

$$C_\epsilon = \liminf_{n\to\infty}\frac{1}{n}\log M^*(n,\epsilon) \le \liminf_{n\to\infty}\frac{1}{n}\frac{\sup_{P_{X^n}} I(X^n;Y^n)+h(\epsilon)}{1-\epsilon} = \frac{C^{(\mathrm{I})}}{1-\epsilon}.$$

□

接下来给出一个可达性界：

定理 19.8 （C_ϵ 的下界） *For a stationary memoryless channel, $C_\epsilon \ge \sup_{P_X} I(X;Y)$, for any $\epsilon\in(0,1]$.*

Proof. 固定 $\mathcal{A}$ 上任意一个 P_X，并令 $P_{X^n}=P_X^{\otimes n}$ 为单字母分布 P_X 的 iid 乘积。回顾香农可达性界定理 18.5（或第 18 章中的任何其他定理也同样适用)。从该结果可知，对于任意 n,M 和任意 $\tau>0$，存在一个 (n,M,ϵ_n)-码，其

$$\epsilon_n \le \mathbb{P}[i(X^n;Y^n)\le \log M+\tau]+\exp(-\tau)$$

这里的信息密度是相对于分布 $P_{X^n,Y^n}=P_{X,Y}^{\otimes n}$ 定义的，因此，

$$i(X^n;Y^n)=\sum_{k=1}^n \log\frac{dP_{X,Y}}{dP_XP_Y}(X_k,Y_k)=\sum_{k=1}^n i(X_k;Y_k),$$

其中 $i(x;y)=i_{P_{X,Y}}(x;y)$ 和 $i(x^n;y^n)=i_{P_{X^n,Y^n}}(x^n;y^n)$。重要的是，在 P_{X^n,Y^n} 下，随机变量 $i(X^n;Y^n)$ 是均值为 $I(X;Y)$ 的独立同分布随机变量之和。因此，根据弱大数定律，我们有

$$\mathbb{P}[i(X^n;Y^n)<n(I(X;Y)-\delta)]\to 0$$

对于任何 $\delta>0$。

考虑到这一点，我们设 $\log M = n(I(X;$ 对于某个 $\delta>0$，有 $Y)-2\delta)$，并在香农界中取 $\tau=\delta n$。那么对于误差界，我们得到

$$\epsilon_n \le \mathbb{P}\left[\sum_{k=1}^n i(X_k;Y_k)\le nI(X;Y)-\delta n\right]+\exp(-\delta n)\xrightarrow{n\to\infty}0, \tag{19.7}$$

由于该界收敛到0，我们已经证明了存在一个（n,M_n,ϵ_n）码序列，其中$\epsilon_n\to 0$且$\log M_n = n(I(X;Y)-2\delta)$。因此，对于所有满足$\epsilon_n\le\epsilon$的$n$

$$\log M^*(n,\epsilon)\ge n(I(X;Y)-2\delta)$$

因此

$$C_\epsilon=\liminf_{n\to\infty}\frac{1}{n}\log M^*(n,\epsilon)\ge I(X;Y)-2\delta$$

由于这对所有 P_X 和所有 $\delta>$ 为 0 都成立，我们得出 $C_\epsilon\ge\sup_{P_X} I(X;Y)$。 □

以下结果来自将C_ϵ的上界和下界进行配对。

定理 19.9（香农信道编码定理 [378]）*For a stationary memory- less channel,*

$$C = C^{(\mathrm{I})} = \sup_{P_X} I(X;Y). \tag{19.8}$$

正如我们已经多次提到的，这一结果在信息论中是最重要的成果之一。从工程的角度来看，主要的惊奇之处在于 $C > 0$，即对于任意小的错误概率，都可以以严格正速率在信道上进行通信。实现这一点的方法是对输入数据进行联合编码（即同时对许多输入比特一起编码）。这与1948年之前逐字母操作的方法（如摩尔斯电码）截然不同。这一理论结果为实用通信系统的发展提供了推动力（并且至今仍具有指导意义）——对于一个渐近数学事实而言，这是相当罕见的成就。

Proof. 陈述（19.8）包含两个等式。第一个等式自动由第二个等式以及定理19.7和19.8推出。为了证明第二个等式 $C^{(\mathrm{I})} = \sup_{P_X} I(X;\ Y)$，我们注意到对于平稳无记忆信道，$C^{(\mathrm{I})}$ 实际上是容易计算的。确实，与其解决一系列优化问题（每个 n 对应一个）并取 $n \to \infty$ 的极限，信道的无记忆性意味着只需解决 $n = 1$ 问题。这类结果在信息论中被称为 *single-letterization* (或张量分解)，我们将在以下命题中正式展示，从而完成证明。

□

命题 19.10（容量的张量积化）

- *For memoryless channels,*

$$\sup_{P_{X^n}} I(X^n;Y^n) = \sum_{i=1}^{n} \sup_{P_{X_i}} I(X_i;Y_i).$$

- *For stationary memoryless channels,*

$$C^{(\mathrm{I})} = \sup_{P_X} I(X;Y).$$

Proof. 回想定理6.1，我们知道对于乘积核$P_{Y^n|X^n} = \prod P_{Y_i|X_i}$，互信息满足$I(X^n;\ Y^n) \le \sum_{k=1}^{n} I(X_k;\ Y_k)$，且当$X_i$独立时等号成立。于是

$$C^{(\mathrm{I})} = \liminf_{n\to\infty} \frac{1}{n} \sup_{P_{X^n}} I(X^n;Y^n) = \liminf_{n\to\infty} \sup_{P_X} I(X;Y) = \sup_{P_X} I(X;Y).$$

□

香农的有噪信道定理表明，通过采用大块长度的编码，我们可以任意接近信道容量。鉴于这一结果的渐近性质（或任何

其他渐近结果），一个自然的问题是理解达到容量所需付出的代价。这可以从两个方面来理解：

1 实现容量的*complexity*：是否有可能找到低复杂度的编码器和解码器，其操作次数在块长度n中呈多项式增长，从而实现容量？这个问题由Forney [172]解决，他证明了在*linear*时间内，这是可能的，且错误概率呈指数级小。

请注意，如果我们满足于多项式小的错误概率，例如$P_e = O(n^{-100})$，那么我们可以按如下方式构造多项式时间可解码的编码。首先，可以证明，当码率严格低于容量时，最优编码的错误概率随块长度指数衰减。现在，将长度为n的块划分为长度为$c\log n$的较短块，并对块长度$c\log n$应用最优编码，错误概率为n^{-101}。根据联合界，整个块的错误概率至多为n^{-100}。编码和穷举搜索解码显然是多项式时间的。

2 实现容量。假设我们满足于达到容量的90%。那么问题在于，为了使这一目标成为可能，我们需要采用多大的块长度？（块长度直接与延迟相关，因此，等价地，我们可能会问，为了追求90%的容量，会带来多少延迟。）换句话说，我们想知道随着块长度的增长，与容量之间的差距消失得有多快。香农定理表明，差距 $C-\frac{1}{n}\log M^*(n,\epsilon)=o(1)$。接下来的定理表明，在适当条件下，$o(1)$ 项实际上是 $O(\frac{1}{\sqrt{n}})$。

定理19.8证明中的主要工具是大数定律。定理19.8中的下界$C_\epsilon \geq C^{(\mathrm{I})}$表明，$\log M^*(n,\epsilon) \geq nC + o(n)$ (这仅仅是重申了通过n归一化并取lim inf必然导致的结果为$\geq C$)。如果我们改用中心极限定理（CLT）进行更细致的分析，我们将得到以下改进的达成性结果。

定理 19.11 *Consider a stationary memoryless channel with a capacity-achieving input distribution. Namely,* $C = \max_{P_X} I(X;Y) = I(X_*;Y_*)$ *is attained at* P_X^**, which induces* $P_{X^*Y^*} = P_{X^*}P_{Y|X}$*. Assume that* $V = \mathrm{Var}[i(X^*;Y^*)] < \infty$*. Then*

$$\log M^*(n,\epsilon) \geq nC - \sqrt{nV}Q^{-1}(\epsilon) + o(\sqrt{n}),$$

where $Q(\cdot)$ *is the complementary Gaussian CDF and* $Q^{-}1(\cdot)$ *is its functional inverse.*

Proof. 用lim inf来表示little-o记号，我们的目标是

$$\liminf_{n\to\infty} \frac{\log M^*(n,\epsilon) - nC}{\sqrt{nV}} \geq -Q^{-1}(\epsilon) = \Phi^{-1}(\epsilon),$$

其中 $\Phi(t)$ 是标准正态累积分布函数。

回想 Feinstein 界

$$\exists(n,M,\epsilon)_{\max}: \quad M \geq \beta\left(\epsilon - \mathbb{P}[i(X^n;Y^n) \leq \log\beta]\right)$$

取对数 $\beta = nC + \sqrt{nV}t$，然后应用中心极限定理可得

$$\begin{aligned}
&\log M \geq nC + \sqrt{nV}t + \log\left(\epsilon - \mathbb{P}\left[\sum i(X_k; Y_k) \leq nC + \sqrt{nV}t\right]\right) \\
&\implies \log M \geq nC + \sqrt{nV}t + \log\left(\epsilon - \Phi(t)\right) \quad \forall \Phi(t) < \epsilon \\
&\implies \frac{\log M - nC}{\sqrt{nV}} \geq t + \frac{\log(\epsilon - \Phi(t))}{\sqrt{nV}},
\end{aligned}$$

其中 $\Phi(t)$ 是标准正态累积分布函数。对两边取下极限

$$\liminf_{n\to\infty} \frac{\log M^*(n,\epsilon) - nC}{\sqrt{nV}} \geq t,$$

对于所有满足 $\Phi(t) < \epsilon$ 的 t。最后，取 $t \nearrow \Phi^{-1}(\epsilon)$，并将下极限写成小 o 记号，从而完成证明

$$\log M^*(n,\epsilon) \geq nC - \sqrt{nV}Q^{-1}(\epsilon) + o(\sqrt{n}).$$

□

注 19.1 定理 19.9 意味着对于任意 $R < C$，存在一列 $(n, \exp(nR), \epsilon_n)$-码，使得错误概率 ϵ_n 随 $n \to \infty$ 趋于零。考察上界 (19.7)，我们看到错误概率实际上以指数速度趋于零，因为第一项中的事件属于大偏差类型（回忆第 15 章），因此两项都是指数小的。寻找最优指数值（甚至其存在性）在信息论中有着悠久的历史（但一般仍未解决），见第 22.4* 节。然而，最近人们认识到，一个实际更相关、也更容易分析的体制是固定（非消失）错误 ϵ，在这种情况下，主要问题是界定 $R \to C_\epsilon = C$ 的收敛速度。前一定理给出了关于这种收敛速度的一个界。最优的 $\frac{1}{\sqrt{n}}$ 系数被称为信道色散，更多内容见第 22.5 和 22.6 节。特别地，我们将证明定理 19.11 中对 $\sqrt{n}$ 项的界通常是紧的。

19.3 容量计算示例

我们计算表19.1中简单DMC的容量，并在图19.1中绘制它们。首先，对于BSC_δ，我们有以下输入输出律的描述：

$$Y = X + Z \mod 2, \quad Z \sim \mathrm{Ber}(\delta) \perp\!\!\!\perp X.$$

为了计算容量，让我们注意

$$I(X; X+Z) = H(X+Z) - H(X+Z|X) = H(X+Z) - H(Z) \leq \log 2 - h(\delta)$$

当且仅当 $X \sim \mathrm{Ber}(1/2)$ 时取等号。因此我们已经证明

$$C = \sup_{P_X} I(X;Y) = \log 2 - h(\delta).$$

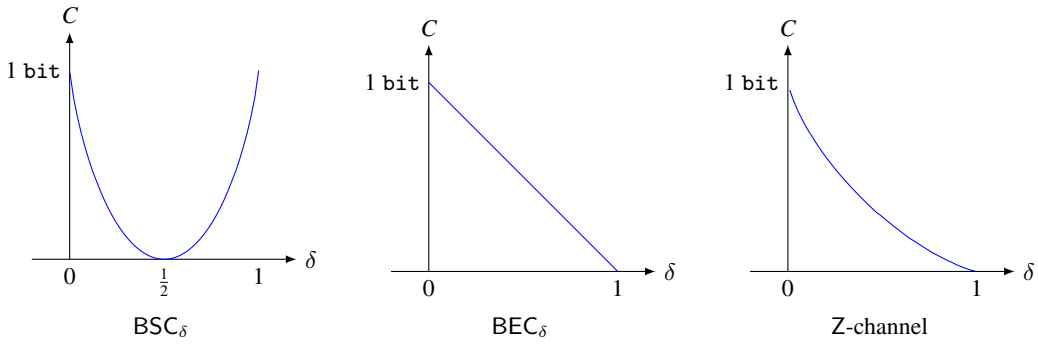


图19.1 三个简单DMC的容量。

更一般地，回顾例3.7，对于有限阿贝尔群G上的任何加性噪声信道，我们有$C = \sup_{P_X} I(X;\ X+Z) = \log|G| - H(Z)$，由$X \sim \mathrm{Unif}(G)$达到。类似地，对于通过$x \mapsto x \circ Z$作用在非阿贝尔群$G$上的群噪声信道$Z \sim P_Z$，我们也具有容量等于$\log|G| - H(Z)$，并由$X \sim \mathrm{Unif}(G)$达到。

接着我们考虑BEC_δ。这是一个*multiplicative*信道。实际上，如果我们等价地重新定义输入$X \in \{\pm 1\}$和输出$Y \in \{\pm 1, 0\}$，那么BEC关系可以表示为

$$Y = XZ, \qquad Z \sim \mathrm{Ber}(\delta) \perp\!\!\!\perp X .$$

为了计算容量，我们首先注意到，即使不评估香农公式，也可以清楚地看出 $C \le 1-\delta$ (比特)，因为对于较大的块长度 n，大约 δ 比例的消息会被完全丢失（即使编码器事先知道擦除将发生在哪里，速率仍然不能超过 $1-\delta$）。更正式地说，我们注意到 $\mathbb{P}[X=1|Y=0] = \frac{\mathbb{P}[X=1]\delta}{\delta} = \mathbb{P}[X=1]$，因此

$$I(X;Y) = H(X) - H(X|Y) = H(X) - H(X|Y=\mathsf{e}) \le (1-\delta)H(X) \le (1-\delta)\log 2 ,$$

当且仅当 $X \sim$ 服从 $\mathrm{Ber}(1/2)$ 时等号成立。因此我们已经证明

$$C = \sup_{P_X} I(X;Y) = 1-\delta \quad \mathtt{bits}.$$

最后，Z-信道也可以被视为一个具有转移律的乘法信道

$$Y = XZ, \qquad X \in \{0,1\} \perp\!\!\!\perp Z \sim \mathrm{Ber}(1-\delta) ,$$

使得 $\mathbb{P}[Z=0] = \delta$。对于该信道，若 $X \sim \mathrm{Ber}(p)$，我们有

$$I(X;Y) = H(Y) - H(Y|X) = h(p(1-\delta)) - ph(\delta) .$$

在 p 上优化，我们得到最优输入由下式给出：

$$p^*(\delta) = \frac{1}{1-\delta}\frac{1}{1+\exp\{\frac{h(\delta)}{1-\delta}\}} .$$

达到容量的输入分布 $p^*(\delta)$ 从当 $\delta =$ 为0时的 $\frac{1}{2}$ 单调递减至当 $\delta \to$ 为1时的 $\frac{1}{e}$。（臭名昭著的是，对于后一个极限值没有“解释”。）关于容量，

因此，我们得到

$$C = h(p^*(\delta)(1-\delta)) - p^*(\delta)h(\delta)\,.$$

19.4* 对称信道

定义 19.1 2 一对可测映射 $f=(f_i,f_o)$ 是...的对称 $P_{Y|X}$ 如果

$$P_{Y|X}(f_o^{-1}(E)|f_i(x)) = P_{Y|X}(E|x)\,,$$

对于所有可测的$E\subset\mathcal{Y}$和$x\in\mathcal{X}$。两个对称性f和g可以复合产生另一个对称性，即

$$(g_i,g_o)\circ(f_i,f_o)\triangleq(g_i\circ f_i, f_o\circ g_o)\,. \tag{19.9}$$

一个$P_{Y|X}$的对称群G是任何在群运算（19.9）下封闭的可逆对称（自同构）的集合。

注意，自同构 $f=(f_i,f_o)$ 的两个分量都是双可测双射，即 $f_i,f_i^{-1},f_o,f_o^{-1}$ 全是可测且定义良好的函数。

当然，每个对称 etry群G在$\mathcal{X}\times\mathcal{Y}$上具有一个典范左作用 定义为

$$g\cdot(x,y)\triangleq(g_i(x),g_o^{-1}(y))\,. \tag{19.10}$$

由于对$\mathcal{X}\times\mathcal{Y}$的作用分解为对$\mathcal{X}$和$\mathcal{Y}$的作用，我们将稍微滥用记号，写作

$$g\cdot(x,y)\triangleq(gx,gy)\,.$$

让我们额外假设我们的群 G 可以配备一个 σ-代数 $\sigma(G)$，使得映射 $h\mapsto hg$ 和 $h\mapsto gh$ 对于每个 $g\in G$ 都是可测的。我们说 $(G,\sigma(G))$ 上的概率测度 μ 是一个 *left-invariant Haar measure*，如果当 $H\sim\mu$ 时，对于任意 $g\in G$，我们也有 $gH\sim\mu$。（另见练习 V.23。）Haar 测度的存在性对于有限（和紧）群来说是平凡的，但一般来说是一个困难的课题。为了继续，我们需要对对称群 G 做一个假设，我们称之为正则性。（当 $\mathcal{X}$ 和 $\mathcal{Y}$ 有限时，这个条件平凡地满足，因此这几段中所有的复杂性只与非离散信道相关。）

定义 19.13 如果一个对称群 G 拥有一个左不变 Haar 概率测度 ν，使得群作用 (19.10)，则称该群为 *regular*。

$$G\times\mathcal{X}\times\mathcal{Y}\to\mathcal{X}\times\mathcal{Y}$$

是可测量的。

注意，在正则性假设下，作用量（19.10）根据下式也定义了G在$\mathcal{P}(\mathcal{X})$和$\mathcal{P}(\mathcal{Y})$上的左作用

$$(gP_X)[E]\triangleq P_X[g^{-1}E]\,, \tag{19.11}$$

$$(gQ_Y)[E] \triangleq Q_Y[g^{-1}E]\,, \tag{19.12}$$

或者，用言语表达，如果$X \sim P_X$那么$gX \sim gP_X$，对于Y和gY也是类似。对于每个分布P_X，我们定义平均分布$\bar{P}_X$为

$$\bar{P}_X[E] \triangleq \int_G P_X[g^{-1}E]\nu(dg)\,, \tag{19.13}$$

这是随机变量 gX 在 $g \sim \nu$ 和 $X \sim P_X$ 条件下的分布。测度 $\bar{P}_X$ 是 G-不变的，即 $g\bar{P}_X = \bar{P}_X$ 。事实上，由 ν 的左不变性，对于每个有界函数 f，我们有

$$\int_G f(g)\nu(dg) = \int_G f(hg)\nu(dg) \qquad \forall h \in G\,,$$

因此

$$\bar{P}_X[h^{-1}E] = \int_G P_X[(hg)^{-1}E]\nu(dg) = \bar{P}_X[E]\,.$$

类似地，定义$\bar{Q}_Y$:

$$\bar{Q}_Y[E] \triangleq \int_G Q_Y[g^{-1}E]\nu(dg)\,, \tag{19.14}$$

它也是G-不变的：$g\bar{Q}_Y = \bar{Q}_Y$。

G 作用的主要性质可以重新表述如下：对于任意 ϕ：$\mathcal{X}\times\mathcal{Y} \to \mathbb{R}$，我们有

$$\begin{aligned}&\int_{\mathcal{X}}\int_{\mathcal{Y}} \phi(x,y)P_{Y|X}(dy|x)(gP_X)(dx)\\ &= \int_{\mathcal{X}}\int_{\mathcal{Y}} \phi(gx,gy)P_{Y|X}(dy|x)P_X(dx)\,.\end{aligned} \tag{19.15}$$

换言之，如果对 (X,Y) 这一对是通过取 $X \sim P_X$ 并应用 $P_{Y|X}$ 生成的，那么 (gX,gY) 这一对具有边缘分布 gP_X，但条件核仍然是 $P_{Y|X}$。对于有限的 $\mathcal{X},\mathcal{Y}$，这等价于

$$P_{Y|X}(gy|gx) = P_{Y|X}(y|x)\,, \tag{19.16}$$

这也可以作为自同构的定义。就G对$\mathcal{P}(\mathcal{Y})$的作用而言，我们也可以说：

$$gP_{Y|X=x} = P_{Y|X=gx} \qquad \forall g \in G, x \in \mathcal{X}\,. \tag{19.17}$$

不难证明，对于任何信道及一个正规对称群G，达到容量的输出分布必须是G-不变的，而达到容量的输入分布则可选择为G-不变的。即，鞍点方程

$$\inf_{P_X}\sup_{Q_Y} D(P_{Y|X}\|Q_Y|P_X) = \sup_{Q_Y}\inf_{P_X} D(P_{Y|X}\|Q_Y|P_X)\,,$$

可以在 G-不变分布类中求解。通常，G 在 $\mathcal{X}$ ($\mathcal{Y}$) 上的作用是传递的，在这种情况下，容量可达的输入（输出）分布可以取为均匀分布。

下面我们系统化了许多流行的信道对称性概念，并解释了它们之间的关系。

• $P_{Y|X}$ 若存在一个正则对称群 G 传递作用于 $\mathcal{X}$ ($\mathcal{Y}$)，则称其为输入对称（输出对称）。• 一个具有二进制 $\mathcal{X}$ 的输入对称信道被称为 BMS（二进制无记忆对称）。这些信道拥有丰富的理论；参见 [360, 第4.1节] 和练习 VI.21。• $P_{Y|X}$ 若存在一个 $x_0 \in \mathcal{X}$ 和一个信道 T_x: $\mathcal{B} \to \mathcal{B}$，对于每个 $x \in \mathcal{X}$，使得 $T_x \circ P_{Y|X=x_0} = P_{Y|X=x}$ 和 $T_x \circ P_Y^* = P_Y^*$，其中 P_Y^* 是达到容量的输出分布，则称其为弱输入对称。在 [333, 第3.4.5节] 中表明，允许随机映射 T_x 是必要的，并且并非所有 $P_{Y|X}$ 都是弱输入对称的。• 若 $\mathcal{X} = \mathcal{Y}$ 是一个群且 $P_{Y|X}$ 通过将 X 与噪声变量 Z 复合来作用，则 DMC $P_{Y|X}$ 是一个 *group-noise channel*:

$$Y = X \circ Z,$$

其中 $\circ$ 是一个群操作，且 Z 与 X 独立。

• DMC $P_{Y|X}$ 被称为 *Dobrushin-symmetric*，如果 $P_{Y|X}$ 的每一行都是第一行的排列，且 $P_{Y|X}$ 的每一列都是第一列的排列；见 [131]。• DMC $P_{Y|X}$ 被称为 *Gallager-symmetric*，如果输出字母表 $\mathcal{Y}$ 可以分割成不相交的子字母表的并集，使得限制在每个子字母表上 $P_{Y|X}$ 具有 Dobrushin性质：每一行（每一列）都是第一行（第一列）的排列；见 [177, 第4.5节]。

• 为方便起见，若 $|\mathcal{X}| = |\mathcal{Y}|$，则称该信道为*square*。

我们展示了这些不同对称性概念之间的一些关系:

• 注意，根据定义容易得出，对于任何输入对称（或输出对称）信道，信道矩阵$P_{Y|X}$ (的所有行（或列)）都是第一行（或第一列）的排列。因此,

$$\text{input-symmetric, output-symmetric} \Longrightarrow \text{Dobrushin} \tag{19.18}$$

• 群噪声信道满足对称性的所有其他定义:

$$\text{group-noise} \Longrightarrow \text{square, input/output-symmetric} \tag{19.19}$$

$$\Longrightarrow \text{Dobrushin, Gallager} \tag{19.20}$$

• 由于Gallager对称性意味着所有行都是第一行的排列，而输出对称性意味着列也满足同样的陈述，我们有

$$\text{Gallager, output-symmetric} \Longrightarrow \text{Dobrushin}$$

• 显然，并非每个多布林对称信道都是方形的。然而，人们可能会好奇，是否每个方形多布林信道都是群噪声信道。事实并非如此。实际上，根据

到[390]那些是凯莱表的拉丁方正是这样的：其中两行（作为排列）的复合给出另一行。一个不是凯莱表的拉丁方的例子如下：

$$\begin{pmatrix} 1 & 2 & 3 & 4 & 5 \\ 2 & 5 & 4 & 1 & 3 \\ 3 & 1 & 2 & 5 & 4 \\ 4 & 3 & 5 & 2 & 1 \\ 5 & 4 & 1 & 3 & 2 \end{pmatrix} . \tag{19.21}$$

T因此，通过将此矩阵乘以$\frac{1}{15}$，我们得到一个反例。 示例：

$$\text{Dobrushin, square} \not\Longrightarrow \text{group-noise}$$

事实上，这个信道甚至不是输入对称的。确实，假设存在 $g \in G$ 使得 $g4 = 1$（在 $\mathcal{X}$ 上）。那么，应用（19.16）式，取 $x = 4$，我们可以推断出在 $\mathcal{Y}$ 上，g 的作用必定是：

$$1 \mapsto 4, 2 \mapsto 3, 3 \mapsto 5, 4 \mapsto 2, 5 \mapsto 1 .$$

但接下来我们有

$$gP_{Y|X=1} = \begin{pmatrix} 5 & 4 & 2 & 1 & 3 \end{pmatrix} \cdot \frac{1}{15} ,$$

通过简单检查，它并不匹配（19.21）中的任何行。因此，对于 $x = 1$，（19.17）不能成立。我们得出结论：

$$\text{Dobrushin, square} \not\Longrightarrow \text{input-symmetric}$$

同样地，如果存在$g \in G$使得$g2 = 1$（在$\mathcal{Y}$上），那么在$\mathcal{X}$上它将表现为

$$1 \mapsto 2, 2 \mapsto 5, 3 \mapsto 1, 4 \mapsto 3, 5 \mapsto 4 ,$$

这意味着通过(19.16)，$P_{Y|X}(g1|x)$不是(19.21)的一列。因此：

$$\text{Dobrushin, square} \not\Longrightarrow \text{output-symmetric}$$

- 显然，并非每个输入对称信道都是Dobrushin的（例如，BEC）。甚至在方阵信道类中也能找到反例：

$$\begin{pmatrix} 1 & 2 & 3 & 4 \\ 1 & 3 & 2 & 4 \\ 4 & 2 & 3 & 1 \\ 4 & 3 & 2 & 1 \end{pmatrix} \cdot \frac{1}{10} \tag{19.22}$$

这展示了：

$$\text{input-symmetric, square} \not\Longrightarrow \text{Dobrushin}$$

- 通道（19.22）也展示了：

$$\text{Gallager-symmetric, square} \not\Longrightarrow \text{Dobrushin} .$$

- 示例（19.22）自然提出了一个问题：是否每个输入对称信道都是Gallager对称的。答案是肯定的：通过将$\mathcal{Y}$拆分为G的轨道，我们看到子信道$\mathcal{X} \to \{\text{轨道}\}$是输入和输出对称的。因此由（19.18）我们有：

$$\text{input-symmetric} \Longrightarrow \text{Gallager-symmetric} \Longrightarrow \text{weakly input-symmetric} \tag{19.23}$$

(第二个含义是显而易见的)。
- 然而，并非所有弱输入对称信道都是Gallager对称的。事实上，考虑以下信道

$$W = \begin{pmatrix} 1/7 & 4/7 & 1/7 & 1/7 \\ 4/7 & 1/7 & 0 & 4/7 \\ 0 & 0 & 4/7 & 2/7 \\ 2/7 & 2/7 & 2/7 & 0 \end{pmatrix} . \tag{19.24}$$

由于 $\det W \neq 0$，达到容量的输入分布是唯一的。由于 $H(Y|X = x)$ 独立于 x 和 $P_X = [1/4, 1/4, 3/8, 1/8]$ 达到均匀 P_Y^*，因此它必须是唯一的最优解。显然，任何置换 T_x 固定一个均匀 P_Y^*，因此该信道是弱输入对称的。同时，它不是 Gallager 对称的，因为没有一行是另一行的置换。

- 关于弱输入对称信道的更多性质，请参见 [333, 第3.4.5节]。

这些对称概念之间关系的图解表示在图19.2中示意性地给出。

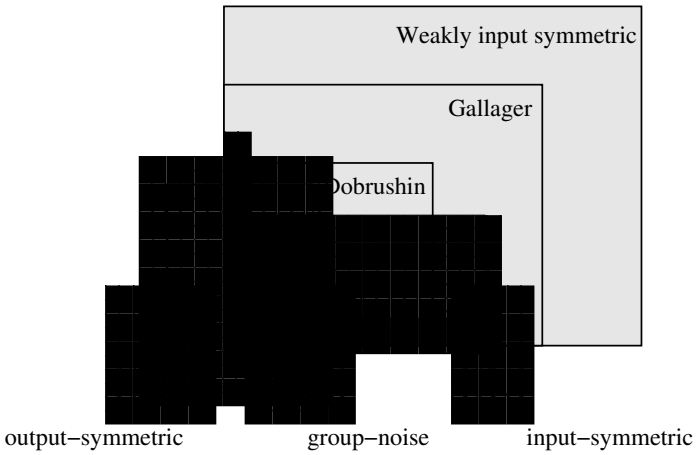


图19.2 各类通道内含物的示意图。

19.5* 信息稳定性

我们看到对于平稳无记忆信道的情况是$C = C^{(\mathrm{I})}$，但对于其他信道呢？非平稳信道又如何？为了回答这个问题，我们引入了*information stability*的概念。

定义 19.14 一个信道称为 *information stable*，如果存在输入分布序列 $\{P_{X^n}, n = 1, 2, \ldots\}$ 使得

$$\frac{1}{n} i(X^n; Y^n) \xrightarrow{\mathbb{P}} C^{(\mathrm{I})} .$$

例如，对于无记忆平稳信道，我们可以选择 $P_{X^n} = (P_X^*)^n$ 作为例子。因此，无记忆平稳信道是信息稳定的。

定义信息稳定性的目的是以下定理。

定理 19.15 *For an information stable channel, $C = C^{(\mathrm{I})}$.*

Proof. 与平稳无记忆情况类似，上界来自一般逆定理17.3，下界使用与定理19.8相似的策略，只是用信息稳定性的定义替代了弱大数定律。

□

下一个定理给出了检查无记忆信道中信息稳定性的条件，这些信道 *not* 必然是平稳的。

定理 19.16 *A memoryless channel is information stable if there exists $\{X_k^* : k \geq 1\}$ such that both of the following hold:*

$$\frac{1}{n} \sum_{k=1}^{n} I(X_k^*; Y_k^*) \to C^{(\mathrm{I})} \tag{19.25}$$

$$\sum_{n=1}^{\infty} \frac{1}{n^2} Var[i(X_n^*; Y_n^*)] < \infty . \tag{19.26}$$

In particular, this is satisfied if

$$|\mathcal{A}| < \infty \ \ or \ \ |\mathcal{B}| < \infty \tag{19.27}$$

Proof. 为了展示第一部分，证明以下内容就足够了

$$\mathbb{P}\left[\frac{1}{n}\left|\sum_{k=1}^{n} i(X_k^*; Y_k^*) - I(X_k^*, Y_k^*)\right| > \delta\right] \to 0$$

因此，$\frac{1}{n} i(X^n;$ 依概率$Y^n) \to C^{(\mathrm{I})}$。我们通过切比雪夫不等式对此进行界定

$$\mathbb{P}\left[\frac{1}{n}\left|\sum_{k=1}^{n} i(X_k^*; Y_k^*) - I(X_k^*, Y_k^*)\right| > \delta\right] \leq \frac{\frac{1}{n^2}\sum_{k=1}^{n} \mathrm{Var}[i(X_k^*; Y_k^*)]}{\delta^2} \to 0 ,$$

其中收敛到0可由应用$b_n = n^2, x_n = \mathrm{Var}[i(X_n^*; Y_n^*)]/n^2$的Kronecker引理（即将给出的引理19.17）得出。

第二部分由第一部分推出。事实上，注意到

$$C^{(\mathrm{I})} = \liminf_{n\to\infty} \frac{1}{n} \sum_{k=1}^{n} \sup_{P_{X_k}} I(X_k; Y_k)\,.$$

现在选择$P_{X_k^*}$，使得

$$I(X_k^*; Y_k^*) \geq \sup_{P_{X_k}} I(X_k; Y_k) - 2^{-k}\,.$$

(注意，每个 $\sup_{P_{X_k}} I(X_k;\ Y_k) \leq \log \min\{|\mathcal{A}|, |\mathcal{B}|\} < \infty$。) 那么，我们有

$$\sum_{k=1}^{n} I(X_k^*; Y_k^*) \geq \sum_{k=1}^{n} \sup_{P_{X_k}} I(X_k; Y_k) - 1\,,$$

因此，通过n进行归一化，我们得到(19.25)。接下来我们证明，对于任何联合分布$P_{X,Y}$，我们有

$$\mathrm{Var}[i(X;Y)] \leq 2\log^2(\min(|\mathcal{A}|, |\mathcal{B}|))\,. \tag{19.28}$$

该论证在 X 和 Y 中是对称的，因此为了具体起见，假设 $|\mathcal{B}| < \infty$。那么

$$\begin{aligned}
&\mathbb{E}[i^2(X;Y)] \\
&\triangleq \int_{\mathcal{A}} dP_X(x) \sum_{y\in\mathcal{B}} P_{Y|X}(y|x) \left[\log^2 P_{Y|X}(y|x) + \log^2 P_Y(y) - 2\log P_{Y|X}(y|x)\cdot \log P_Y(y)\right] \\
&\leq \int_{\mathcal{A}} dP_X(x) \sum_{y\in\mathcal{B}} P_{Y|X}(y|x) \left[\log^2 P_{Y|X}(y|x) + \log^2 P_Y(y)\right] \qquad (19.29) \\
&= \int_{\mathcal{A}} dP_X(x) \left[\sum_{y\in\mathcal{B}} P_{Y|X}(y|x)\log^2 P_{Y|X}(y|x)\right] + \left[\sum_{y\in\mathcal{B}} P_Y(y)\log^2 P_Y(y)\right] \\
&\leq \int_{\mathcal{A}} dP_X(x)\, g(|\mathcal{B}|) + g(|\mathcal{B}|) \qquad (19.30) \\
&= 2g(|\mathcal{B}|)\,,
\end{aligned}$$

其中(19.29)是因为$2\log P_{Y|X}(y|x)\cdot\log P_Y(y)$总是非负的，而(19.30)之所以成立，是因为方括号中的每一项都可以通过以下优化问题得到上界：

$$g(n) \triangleq \sup_{a_j\geq 0:\sum_{j=1}^n a_j = 1} \sum_{j=1}^{n} a_j \log^2 a_j\,. \tag{19.31}$$

由于 $x\log^2 x$ 在原点处的导数无界，所以 (19.31) 的解始终位于 $[0,1]^n$ 的内部。那么，可以直截了当地证明，对于 $n > e$，解实际上是 $a_j = \frac{1}{n}$。

对于 $n=2$，可以直接发现 $g(2)=0.5629\log^2 2<\log^2 2$。无论如何，

$$2g(|\mathcal{B}|)\le 2\log^2|\mathcal{B}|\,.$$

最后，由于对称性，可以用$|\mathcal{A}|$替换{v*}进行类似的论证。 □

引理 19.17（克罗内克引理）*Let a sequence* $0<b_n\nearrow\infty$ *and a non-negative sequence* $\{x_n\}$ *such that* $\sum_{n=1}^{\infty}x_n<\infty$*, then*

$$\frac{1}{b_n}\sum_{j=1}^{n}b_jx_j\to 0$$

Proof. 由于b_n严格递增，我们可以将求和拆分并给出其上界

$$\sum_{k=1}^{n}b_kx_k\le b_m\sum_{k=1}^{m}x_k+\sum_{k=m+1}^{n}b_kx_k$$

现在把求和中剩余的 x_k 也加进去

$$\begin{aligned}&\Longrightarrow\ \frac{1}{b_n}\sum_{k=1}^{n}b_kx_k\le\frac{b_m}{b_n}\sum_{k=1}^{\infty}x_k+\sum_{k=m+1}^{n}\frac{b_k}{b_n}x_k\le\frac{b_m}{b_n}\sum_{k=1}^{\infty}x_k+\sum_{k=m+1}^{\infty}x_k\\&\Longrightarrow\ \lim_{n\to\infty}\frac{1}{b_n}\sum_{k=1}^{n}b_kx_k\le\sum_{k=m+1}^{\infty}x_k\to 0\end{aligned}$$

由于这对任何 m 都成立，我们可以使最后一项任意小。 □

如何展示信息稳定性？一类重要的具有记忆的信道，其信息稳定性易于展示，即高斯信道。详细内容将在下文展示（参见第20.5*节和第20.6*节），但此处我们展示一个关键事实。

对于联合高斯分布（X,Y），我们始终有界方差：

$$\mathrm{Var}[i(X;Y)]=\rho^2(X,Y)\log^2 e\le\log^2 e\,,\qquad\rho(X,Y)=\frac{\mathrm{cov}[X,Y]}{\sqrt{\mathrm{Var}[X]\,\mathrm{Var}[Y]}}\,.\tag{19.32}$$

的确，首先注意到我们总是可以用$\tilde{X}=aX\perp\!\!\!\perp Z$来表示$Y=\tilde{X}+Z$。另一方面，我们有

$$i(\tilde{x};y)=\frac{\log e}{2}\left[\frac{\tilde{x}^2+2\tilde{x}z}{\sigma_Y^2}-\frac{\sigma^2}{\sigma_Y^2\sigma_Z^2}z^2\right],\qquad z\triangleq y-\tilde{x}\,.$$

从这里使用 $\mathrm{Var}[\cdot]=\mathrm{Var}[\mathbb{E}[\cdot|\tilde{X}]]+\mathrm{Var}[\cdot|\tilde{X}]$，我们需要分别计算两项：

$$\mathbb{E}[i(\tilde{X};Y)|\tilde{X}]=\frac{\log e}{2}\left[\frac{\tilde{X}^2-\frac{\sigma_{\tilde{X}}^2}{\sigma_Z^2}}{\sigma_Y^2}\right],$$

因此

$$\mathrm{Var}[\mathbb{E}[i(\tilde{X};Y)|\tilde{X}]] = \frac{2\log^2 e}{4\sigma_Y^4}\sigma_{\tilde{X}}^4 .$$

另一方面，

$$\mathrm{Var}[i(\tilde{X};Y)|\tilde{X}] = \frac{2\log^2 e}{4\sigma_Y^4}[4\sigma_{\tilde{X}}^2\sigma_Z^2 + 2\sigma_{\tilde{X}}^4] .$$

综合以上所述，我们得到(19.32)。不等式(19.32)证实了各类高斯信道（无记忆和有记忆）的信息稳定性，正如我们稍后将看到的。

19.6 比特误码率下的容量

在大多数感兴趣的情况下，消息空间$[M]$可以通过识别$[M] = \{0,1\}^k$来赋予额外的结构，当然，这仅对$M = 2^k$可能。在这些情况下，除了P_e和$P_{e,max}$之外，每个代码(f,g)还有另一个重要的品质因数——所谓的*Bit Error Rate (BER)*，记为P_b，并在第6.4节中定义：

$$P_b \triangleq \frac{1}{k}\sum_{j=1}^{k}\mathbb{P}[S_j \neq \hat{S}_j] = \frac{1}{k}\,\mathbb{E}[d_{\mathrm{H}}(S^k,\hat{S}^k)] , \tag{19.33}$$

其中我们将 W 和 $\hat{W}$ 表示为 k 元组：$W = (S_1,\ldots,S_k), \hat{W} = (\hat{S}_1,\ldots,\hat{S}_k)$，而 d_{H} 表示汉明距离（6.6）。换言之，P_b 是解码后的 k 位块中错误的平均比例。

除了像我们上面研究的那样构造最小化块错误概率P_e或$P_{e,max}$的编码之外，最小化BER P_b的问题也具有实际相关性。在此，我们讨论关于此设定的一些简单事实。特别地，我们将看到，即使仅要求P_b趋于零——与P_e趋于零相比是一个弱得多的准则——无记忆信道的容量值也不会增加。

首先，我们给出了平均错误概率（块错误率）与误比特率之间关系的上界。

定理 19.18 *For all* (f,g), $M = 2^k \implies P_b \le P_e \le kP_b$

Proof. 回想一下，$M = 2^k$ 给出了对 $W = S^k$ 比特序列的解释。

$$\frac{1}{k}\sum_{i=1}^{k}1\{S_i \neq \hat{S}_i\} \le 1\{S^k \neq \hat{S}^k\} \le \sum_{i=1}^{k}1\{S_i \neq \hat{S}_i\},$$

其中第一个不等式是显然的，第二个由并集界限得出。对上式取期望即得定理。

□

接下来，以下这对结果通常对于某些特定码的下界 P_b 是有用的。

定理 19.19 (Assouad 引理) *If $M = 2^k$ then*

$$P_b \geq \min\{\mathbb{P}[\hat{W} = c'|W = c] : c, c' \in \{0,1\}^k, d_{\mathrm{H}}(c, c') = 1\}.$$

Proof. 设 e_i 为一个长度为 k 的向量，在第 i 个位置为 1，其他位置均为零。则

$$\sum_{i=1}^{k} 1\{S_i \neq \hat{S}_i\} \geq \sum_{i=1}^{k} 1\{S^k = \hat{S}^k + e_i\}$$

除以k并取期望得到

$$\begin{aligned} P_b &\geq \frac{1}{k}\sum_{i=1}^{k} \mathbb{P}[S^k = \hat{S}^k + e_i] \\ &\geq \min\{\mathbb{P}[\hat{W} = c'|W = c] : c, c' \in \{0,1\}^k, d_{\mathrm{H}}(c, c') = 1\}. \end{aligned}$$

□

同样地，我们可以证明以下推广：

定理 19.20 *If $A, B \in \{0,1\}^k$ (with arbitrary marginals!) then for every $r \geq 1$ we have*

$$P_b = \frac{1}{k}\mathbb{E}[d_{\mathrm{H}}(A,B)] \geq \binom{k-1}{r-1} P_{r,\min} \tag{19.34}$$

$$P_{r,\min} \triangleq \min\{\mathbb{P}[B = c'|A = c] : c, c' \in \{0,1\}^k, d_{\mathrm{H}}(c, c') = r\} \tag{19.35}$$

Proof. 首先，观察到

$$\mathbb{P}[d_{\mathrm{H}}(A,B) = r|A = a] = \sum_{b: d_{\mathrm{H}}(a,b)=r} P_{B|A}(b|a) \geq \binom{k}{r} P_{r,\min}.$$

接下来，请注意

$$d_{\mathrm{H}}(x,y) \geq r1\{d_{\mathrm{H}}(x,y) = r\}$$

并对$x \sim A$、$y \sim B$取期望。 □

在统计学中，{v*} Assouad引理是获取估计量极小极大风险下界的一个有用工具（第31.2节）。

以下是BER约束下信道编码的逆界。

定理 19.21（BER 下的逆定理）*Any M-code with $M = 2^k$ and bit-error rate P_b satisfies*

$$\log M \leq \frac{\sup_{P_X} I(X;Y)}{\log 2 - h(P_b)}.$$

Proof. 注意，$S^k \to X \to Y \to \hat{S}^k$，其中 $S^k \overset{\text{i.i.d.}}{\sim} \text{Ber}(\frac{1}{2})$。回想定理 6.1，对于 iid S^n，$\sum I(S_i ; \hat{S}_i) \le I(S^k; \hat{S}^k)$。这给出了我们

$$\begin{aligned}\sup_{P_X} I(X;Y) \ge I(X;Y) &\ge \sum_{i=1}^{k} I(S_i;\hat{S}_i) \\ &\ge k\frac{1}{k}\sum d\left(\mathbb{P}[S_i=\hat{S}_i]\middle\|\frac{1}{2}\right) \\ &\ge kd\left(\frac{1}{k}\sum_{i=1}^{k}\mathbb{P}[S_i=\hat{S}_i]\middle\|\frac{1}{2}\right) \\ &= kd\left(1-P_b\middle\|\frac{1}{2}\right) = k(\log 2 - h(P_b))\end{aligned}$$

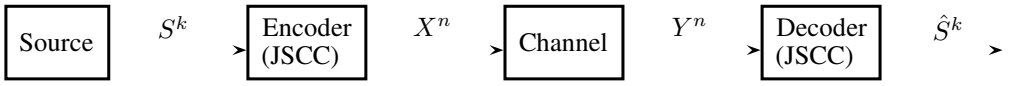
其中第二行使用了二元随机变量的Fano不等式（定理3.12）（或散度的数据处理不等式），而第三行利用了散度的凸性。需要注意的是，这最后一系列不等式与命题6.6的证明相似。 □

将此界限与命题19.10结合表明，对于无记忆信道，任何满足 $P_b \to 0$ 的码序列，其速率必为 $R < C$。换言之，将约束条件从 P_e 放宽至 P_b 并不能获得更高的速率。

稍后在26.3节中我们将看到，在BER约束下的信道编码是被称为有损联合源信道编码的更一般范式的一个特例，因此定理19.21可以从定理26.5推导得出。此外，这个逆界对于平稳无记忆信道实际上是渐近可达的。

19.7 联合信源信道编码

现在我们将研究一种略有不同的数据传输场景，称为*Joint Source ChannelCoding* (JSCC)：



形式上，JSCC 码由一个编码器 $f: \mathcal{A}^k \to \mathcal{X}^n$ 和一个解码器 $g: \mathcal{Y}^n \to \mathcal{A}^k$ 组成。目标是在确保错误概率 $\mathbb{P}[S^k \neq \hat{S}^k]$ 较小的同时，最大化传输速率 $R = \frac{k}{n}$ (每信道使用符号数)。基本极限（最优错误概率）定义为

$$\epsilon^*_{\text{JSCC}}(k,n) = \inf_{f,g} \mathbb{P}[S^k \neq \hat{S}^k]$$

在信道编码中，我们关注的是传输M条消息，并且所有消息都是等概率的。在这里，我们希望传递源实现，而这些源实现可能不是等概率的（存在冗余）。实际上，如果S^k均匀分布在，比如说，$\{0,1\}^k$上，那么我们就回到了信道编码的设置。

在平均错误概率下，用$M = 2^k$，并且$\epsilon^*_{\text{JSCC}}(k,n)$与第22.1节中定义的$\epsilon^*(n, 2^k)$一致。

在这里，我们寻找一种巧妙的方案，将 $\mathcal{A}$ 中的 k 个符号直接编码为长度为 n 的信道输入，从而在信道上实现较小的错误概率。这感觉像是我们已见过的两个问题的混合：压缩信源和在信道上编码。以下定理表明，将压缩和信道编码分开进行是最优的。这让人松了一口气，因为它意味着我们不需要开发任何新的理论或架构来解决联合信源信道编码问题。就渐近式中的主导项而言，以下两阶段方案是最优的：首先使用最优压缩器消除信源中的所有冗余，然后使用最优信道码添加冗余，以对抗数据传输中的噪声。

该结果被称为 *separation theorem*，因为它将压缩器和信道编码的工作分开，两个模块以比特为接口进行交互。请注意，信源生成的符号集可以与信道的输入符号集完全不同。然而，由信源代码（压缩器）产生的比特流通过信道码与信道相匹配。这个结果还有一个更一般的版本（第26.3节）。

定理19.22（香农分离定理）*Let the source $\{S_k\}$ be stationary memoryless on a finite alphabet with entropy H. Let the channel be stationary memoryless with finite capacity C. Then*

$$\epsilon^*_{\text{JSCC}}(nR,n)\begin{cases}\to 0 & R<C/H\\ \not\to 0 & R>C/H\end{cases}\quad n\to\infty.$$

这一结果的解释如下：每个信源符号携带的信息量（熵）为H比特。每次信道使用可以传输C比特。因此，要在n次信道使用中可靠地传输k个符号，我们需要$kH \le nC$。

Proof. (可达性。) 其思路是分别压缩信源并编码以进行传输。由于这是解决 JSCC 问题的一种可行方法，因此它给出了一个可达性界。这种分离式架构是

$$S^k \xrightarrow{f_1} W \xrightarrow{f_2} X^n \xrightarrow{P_{Y^n|X^n}} Y^n \xrightarrow{g_2} \hat{W} \xrightarrow{g_1} \hat{S}^k$$

在我们使用最优压缩器（f_1, g_1）和最优信道码（*maximum*错误概率）（f_2, g_2）的情况下。设W表示压缩器的输出，其最多取M_k个值。那么由推论11.3和定理19.9可得：

(From optimal compressor) $\frac{1}{k}\log M_k > H+\delta \implies \mathbb{P}[\hat{S}^k \neq S^k(W)] \le \epsilon \quad \forall k \ge k_0$

(从最优信道码) $\frac{1}{n}\log M_k < C-\delta \implies \mathbb{P}[\hat{W}\neq m|W=m] \le \epsilon \quad \forall m, \forall k \ge k_0$利用这两者，

$$\mathbb{P}[S^k \neq \hat{S}^k(\hat{W})] \le \mathbb{P}[S^k \neq \hat{S}^k, W=\hat{W}] + \mathbb{P}[W\neq\hat{W}]$$

$$\leq \mathbb{P}[S^k \neq \hat{S}^k(W)] + \mathbb{P}[W \neq \hat{W}] \leq \epsilon + \epsilon$$

因此，若 $R(H+\delta) < C - \delta$，则 $\epsilon^* \to 0$。由 $\delta > 0$ 的任意性，我们得出对任意 $R > C/H$ 的弱逆命题。

(逆命题.) 为了证明逆命题，注意到任何JSCC编码器/解码器都会诱导出一个马尔可夫链

$$S^k \to X^n \to Y^n \to \hat{S}^k.$$

对互信息进行数据处理

$$I(S^k; \hat{S}^k) \leq I(X^n; Y^n) \leq \sup_{P_{X^n}} I(X^n; Y^n) = nC.$$

另一方面，由于$\mathbb{P}[S^k \neq \hat{S}^k] \leq \epsilon_n$，Fano不等式（定理3.12）给出

$$I(S^k; \hat{S}^k) = H(S^k) - H(S^k|\hat{S}^k) \geq kH - \epsilon_n \log |\mathcal{A}|^k - \log 2.$$

结合两者可得

$$nC \geq kH - \epsilon_n \log |\mathcal{A}|^k - \log 2. \tag{19.36}$$

由于 $R = \frac{k}{n}$，将两边同时除以 n 并令 $n \to \infty$，得到

$$\liminf_{n\to\infty} \epsilon_n \geq \frac{RH - C}{R \log |\mathcal{A}|}.$$

因此，如果 $R > C/H$，则 ϵ_n 不会消失。

□

我们指出，如果不使用Fano不等式，我们可以按照定理17.3的证明中那样，通过定义 $Q_{S^k\hat{S}^k} = U_{S^k} P_{\hat{S}^k}$(，其中$U_{S^k}$ =均匀分布于{0, 1}，并对映射$(S^k, \hat{S}^k) \mapsto \{S^k = \hat{S}^k\}$应用数据处理不等式，来下界$I(S^k$和$\hat{S}^k)$:

$$D(P_{S^k\hat{S}^k} \| Q_{S^k\hat{S}^k}) = D(P_{S^k} \| U_{S^k}) + D(P_{\hat{S}|S^k} \| P_{\hat{S}} | P_{S^k}) \geq d(1 - \epsilon_n \| |\mathcal{A}|^{-k})$$

重排各项得到（19.36）。正如我们在备注17.2中讨论的，将D替换为其他f-散度可能会非常有成效。

以非常相似的方式，通过引用推论12.6和定理19.15，我们得到:

定理 19.23 *Let source $\{S_k\}$ be ergodic on a finite alphabet, and have entropy rate H. Let the channel have capacity C and be information stable. Then*

$$\lim_{n\to\infty} \epsilon^*_{\text{JSCC}}(nR, n) \begin{cases} = 0 & R > H/C \\ > 0 & R < H/C \end{cases}$$

我们将证明留作练习。

20 Channels with input constraints. Gaussian channels.

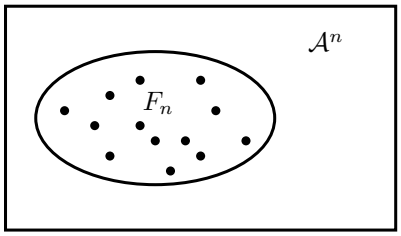
在本章中，我们研究信道输入受限条件下的数据传输问题。具体而言，在上一章中，对于块长度为n的编码，编码器被允许产生任意序列的信道输入（即编码器的值域可以是整个$\mathcal{A}^n$）。然而，在许多实际问题中，仅允许使用$\mathcal{A}^n$的一个子集。此类情况的主要例子是AWGN信道示例3.3。如果允许编码器产生$\mathbb{R}^n$中的任意元素作为输入，则信道容量为无穷大：$\sup_{P_X} I(X;\ X+Z) = \infty$ (例如，取$X \sim \mathcal{N}(0,P)$和$P \to \infty$)。也就是说，通过选择具有巨大两两距离的$\mathbb{R}^n$中的元素，可以以任意小的错误概率传输任意多的消息。然而在实际中，允许的信道输入受到可用[1]功率的限制，编码器只能使用满足条件的$x^n \in \mathbb{R}^n$。

$$\frac{1}{n}\sum_{t=1}^{n} x_t^2 \le P\,,$$

其中 $P > 0$ 被称为功率约束。在这个码字约束下，每次信道使用我们可以传输多少比特？为了在一般情况下回答这个问题，我们需要将设置和编码定理扩展到 *channels with input constraints.*。完成之后，我们将应用这些结果来计算各种高斯信道（无记忆、存在符号间干扰以及受衰落影响）的容量。

20.1 带输入约束的信道编码

我们说一个（n, M, ϵ）码满足输入约束 $F_n \subset \mathcal{A}^n$，如果编码器将 $[M]$ 映射到 F_n 中，即 f: $[M] \to F_n$，如下图所示。



码字全部落在 $\mathcal{A}^n$ 的一个子集中

[1] or allowed by regulatory bodies, such as the FCC in the US.

什么类型的约束集 F_n 具有实际意义？在高斯信道的背景下，我们有 $\mathcal{A}=\mathbb{R}$。接着，人们常常讨论以下约束：

- 平均功率约束：

$$\frac{1}{n}\sum_{i=1}^{n}|x_i|^2 \le P \quad \Leftrightarrow \quad \|x^n\|_2 \le \sqrt{nP}.$$

换句话说，码字必须位于半径 $\sqrt{nP}$ 的球内。
- 峰值功率约束：

$$\max_{1\le i\le n}|x_i| \le A \quad \Leftrightarrow \quad \|x^n\|_\infty \le A$$

注意，第二类约束不会引入任何新问题：我们可以简单地将输入空间从 $\mathcal{A}=\mathbb{R}$ 限制为 $\mathcal{A}=[-A,A]$，从而回到输入无约束编码的设定。第一类约束被称为 *separable cost-constraint*。从现在起，我们将仅关注这一类。

定义 20.1 一个带有*separable*成本约束的信道由下式指定：

- 输入空间 $\mathcal{A}$ 和输出空间 $\mathcal{B}$；- 马尔可夫核序列 $P_{Y^n|X^n}:\mathcal{A}^n\to\mathcal{B}^n$，由块长度 $n=1,2,\ldots$ - (每字母)成本函数 $\mathsf{c}:\mathcal{A}\to\mathbb{R}\cup\{\pm\infty\}$ 索引。

我们将每字母成本扩展到 n-序列，如下所示：

$$\mathsf{c}(x^n)\triangleq\frac{1}{n}\sum_{k=1}^{n}\mathsf{c}(x_k)$$

接下来，我们将信道编码的概念扩展到这类信道。

定义 20.2 - 一个码是 (n,M,ϵ,P)-码，如果它是一个满足输入约束 $F_n\triangleq\{x^n:\frac{1}{n}\sum_{k=1}^{n}\mathsf{c}(x_k)\le P\}$ 的 (n,M,ϵ)-码
- 有限 n 基本极限：

$$M^*(n,\epsilon,P) = \max\{M:\exists(n,M,\epsilon,P)\text{-code}\}$$
$$M^*_{\max}(n,\epsilon,P) = \max\{M:\exists(n,M,\epsilon,P)_{\max}\text{-code}\}$$

- ϵ-容量和香农容量

$$C_\epsilon(P) = \liminf_{n\to\infty}\frac{1}{n}\log M^*(n,\epsilon,P)$$
$$C(P) = \lim_{\epsilon\downarrow 0}C_\epsilon(P)$$

- 信息容量

$$C^{(\mathrm{I})}(P) = \liminf_{n\to\infty} \frac{1}{n} \sup_{P_{X^n}:\mathbb{E}[\sum_{k=1}^n \mathsf{c}(X_k)]\le nP} I(X^n;Y^n)$$

- 信息稳定性：如果对于所有（容许的）P，都存在一个信道输入分布序列 P_{X^n}，使得以下两个性质成立，则该信道是信息稳定的：

$$\frac{1}{n} i_{P_{X^n},Y^n}(X^n;Y^n) \xrightarrow{\mathbb{P}} C^{(\mathrm{I})}(P) \tag{20.1}$$

$$\mathbb{P}[\mathsf{c}(X^n) > P+\delta] \to 0 \qquad \forall \delta > 0\,. \tag{20.2}$$

这些定义与定义19.3和19.6中无输入约束的信道定义明显平行。一个显著且关键的区别在于信息容量$C^{(\mathrm{I})}(P)$的定义。实际上，在有输入约束的情况下，我们不是在F_n上支持的分布上最大化$I(X^n;\ Y^n)$，而是将最大化扩展到一个更丰富的分布集合，即那些满足

$$\mathbb{E}\left[\sum_{k=1}^n \mathsf{c}(X_k)\right] \le nP\,.$$

这对于不久后$C^{(\mathrm{I})}(P)$的单字母化将是至关重要的。

定义 20.3（容许约束） 若存在 $\exists x_0 \in \mathcal{A}$ 使得 $\mathsf{c}(x_0) \le P$，或者等价地，$\exists P_X$：$\mathbb{E}[\mathsf{c}(X)] \le P$，则称 P 为容许约束。容许的 P 的集合记为 $\mathcal{D}_{\mathsf{c}}$，其形式可以是 (P_0,∞) 或 $[P_0,\infty)$，其中 $P_0 \triangleq$ 为 $_{x\in\mathcal{A}}\,\mathsf{c}(x)$ 的下确界。

显然，如果$P \notin \mathcal{D}_{\mathsf{c}}$，则不存在满足输入约束的代码（即使是无用的，仅有一个码字的代码）。因此在后续内容中，我们总是假设$P \in \mathcal{D}_{\mathsf{c}}$。

命题20.4（容量-成本函数） *Define the capacity-cost function* $\phi(P) \triangleq \sup_{P_X:\mathbb{E}[\mathsf{c}(X)]\le P} I(X;\ Y)$. *Then*

1 ϕ *is concave and non-decreasing. The domain of* ϕ *is* $\operatorname{dom}\phi \triangleq \{x:\ f(x) > -\infty\} = \mathcal{D}_{\mathsf{c}}$.
2 One of the following is true: $\phi(P)$ *is continuous and finite on* (P_0,∞), *or* $\phi = \infty$ *on* (P_0,∞).

Both of these properties extend to the function $P \mapsto C^{(\mathrm{I})}(P)$.

Proof. 在第一部分，所有陈述都是显而易见的，除了凹性，它源自 $P_X \mapsto I(X$ 的凹性；$Y)$。对于任意满足 $\mathbb{E}\,[\mathsf{c}(X_i)] \le P_i, i = 0, 1$ 的 P_{X_i}，令 $X \sim \bar{\lambda}P_{X_0} + \lambda P_{X_1}$。那么 $\mathbb{E}\,[\mathsf{c}(X)] \le \bar{\lambda}P_0 + \lambda P_1$ 且 $I(X;\ Y) \ge \bar{\lambda}I(X_0;\ Y_0) + \lambda I(X_1;\ Y_1)$。因此 $\phi(\bar{\lambda}P_0 + \lambda P_1) \ge \bar{\lambda}\phi(P_0) + \lambda\phi(P_1)$。第二个结论源自 $\phi(\cdot)$ 的凹性。

为了将这些结果扩展到 $C^{(\mathrm{I})}(P)$，观察到对于每个 n

$$P \mapsto \frac{1}{n} \sup_{P_{X^n}:\mathbb{E}[\mathsf{c}(X^n)]\le P} I(X^n;Y^n)$$

是凹的。然后取 $\liminf_{n\to\infty}$，同样适用于 $C^{(\mathrm{I})}(P)$。 □

一个直接结果是，对于具有可分离成本的无记忆信道，无记忆输入是最优的，这给出了信息容量的单字母公式：

推论 20.5（单字母化） *The information capacity of a stationary memoryless channel with separable cost is given by*

$$C^{(\mathrm{I})}(P) = \phi(P) = \sup_{\mathbb{E}[\mathsf{c}(X)]\le P} I(X;Y).$$

Proof. $C^{(\mathrm{I})}(P) \ge \phi(P)$通过使用$P_{X^n} = (P_X)^{\otimes n}$是显而易见的。对于“$\le$”，固定任何满足成本约束的$P_{X^n}$。考虑链

$$I(X^n;Y^n) \overset{\text{(a)}}{\le} \sum_{j=1}^n I(X_j;Y_j) \overset{\text{(b)}}{\le} \sum_{j=1}^n \phi(\mathbb{E}[\mathsf{c}(X_j)]) \overset{\text{(c)}}{\le} n\phi\left(\frac{1}{n}\sum_{j=1}^n \mathbb{E}[\mathsf{c}(X_j)]\right) \le n\phi(P)\,,$$

其中 (a) 由定理6.1得出；(b) 由 ϕ 的定义得出；(c) 由Jensen不等式和 ϕ 的凹性得出。

□

20.2 可分离成本约束下的信道容量

我们首先将弱逆定理直接推广到输入约束的情况。

定理 20.6（弱逆定理）

$$C_\epsilon(P) \le \frac{C^{(\mathrm{I})}(P)}{1-\epsilon}$$

Proof. 论证与定理17.3中所用的相同。取任意(n, M, ϵ, P)-码，$W \to X^n \to Y^n \to \hat{W}$。应用Fano不等式及数据处理，我们得到

$$-h(\epsilon) + (1-\epsilon)\log M \le I(W;\hat{W}) \le I(X^n;Y^n) \le \sup_{P_{X^n}:\mathbb{E}[\mathsf{c}(X^n)]\le P} I(X^n;Y^n)$$

将两边除以 n 并取 $\liminf_{n\to\infty}$，我们得到结果。

□

接下来，我们需要将其中一个编码定理扩展到输入约束的情形。我们以费恩斯坦引理（定理18.7）为例进行说明。注意，当$F = \mathcal{X}$时，它就退化为原始版本。

定理 20.7（扩展的 Feinstein 引理） *Fix a Markov kernel $P_{Y|X}$ and an arbitrary P_X. Then for any measurable subset $F \subset \mathcal{X}$, every$\gamma > 0$ and any integer $M \ge 1$, there exists an $(M,\epsilon)_{\max}$-code such that*

- *Encoder satisfies the input constraint: $f : [M] \to F \subset \mathcal{X}$;*

- *Probability of error bound:*

$$\epsilon P_X(F) \le \mathbb{P}[i(X;Y) < \log\gamma] + \frac{M}{\gamma}$$

Proof. 类似于原始 Feinstein 引理的证明，定义初步译码区域 $E_c = \{y\colon\ i(c;\ y) \ge \log\gamma\}$ 对所有 $c \in \mathcal{X}$。接下来，我们应用推论 18.4 并发现存在一个集合 $F_0 \subset \mathcal{X}$ 具有两个性质：a）$P_X[F_0] = 1$ 和 b）对于每个 $x \in F_0$，我们有 $P_Y(E_x) \le \frac{1}{\gamma}$。现在我们令 $F' = F \cap F_0$ 并注意到 $P_X[F'] = P_X[F]$。

我们依次从集合 F' (!) 中选取码字 $\{c_1, \ldots, c_M\}$，并定义译码区域 $\{D_1, \ldots, D_M\}$ 为 $D_j \triangleq E_{c_j} \setminus \cup_{k=1}^{j-1} D_k$。停止准则是 M 最大，即

$$\begin{aligned} &\forall x_0 \in F', P_Y[E_{x_0} \setminus \cup_{j=1}^{M} D_j \big| X = x_0] < 1-\epsilon \\ \Leftrightarrow\ &\forall x_0 \in \mathcal{X}, P_Y[E_{x_0} \setminus \cup_{j=1}^{M} D_j \big| X = x_0] < (1-\epsilon)1[x_0 \in F'] + 1[x_0 \in F'^c] \end{aligned}$$

现在对最后一个不等式关于 $x_0 \sim P_X$ 求平均，得到

$$\mathbb{P}[\{i(X;Y) \ge \log\gamma\} \setminus \cup_{j=1}^{M} D_j] \le (1-\epsilon)P_X[F'] + P_X[F'^c] = 1 - \epsilon P_X[F]$$

从这里开始，我们通过遵循原 Feinstein 引理（定理 18.7）证明中的相同步骤来完成证明。 □

给定编码定理，我们可以建立容量的下界。

定理 20.8（可达性界）*For any information stable channel with input constraints and $P > P_0$ we have*

$$C(P) \ge C^{(\mathrm{I})}(P). \tag{20.3}$$

Proof. 让我们考虑无记忆平稳信道的一个特例（对于一般信息稳定信道的证明类似）。因此，我们假设 {v*}。

修复 $n \ge 1$. 选择一个 P_X 使得 $\mathbb{E}[\mathsf{c}(X)] < P$，取对数 $M = n(I(X;\ Y) - 2\delta)$ 和对数 $\gamma = n(I(X;\ Y) - \delta)$。

在输入约束集 $F_n = \{x^n\colon\ \frac{1}{n}\sum \mathsf{c}(x_k) \le P\}$，以及独立同分布输入分布 $P_{X^n} = P_X^{\otimes n}$ 的情况下，我们应用扩展的Feinstein引理。这表明存在一个 $(n, M, \epsilon_n, P)_{\max}$-码，其编码器满足输入约束 F_n 并且（最大）错误概率趋于零。

$$\epsilon_n \underbrace{P_{X^n}[F_n]}_{\to 1} \le \underbrace{\mathbb{P}[i(X^n;Y^n) \le n(I(X;Y)-\delta)]}_{\to 0 \text{ as } n\to\infty \text{ by WLLN and stationary memoryless assumption}} + \underbrace{\exp(-n\delta)}_{\to 0}$$

事实上，第一项根据弱大数定律趋于零：由于$\mathbb{E}[\mathsf{c}(X)] < P$，我们有$P_{X^n}(F_n) = \mathbb{P}[\frac{1}{n}\sum \mathsf{c}(x_k) \le P] \to 1$。由于$\epsilon_n \to 0$，这意味着对于每个$\epsilon > 0$，我们有

$$\begin{aligned} &C_\epsilon(P) \ge \frac{1}{n}\log M = I(X;Y) - 2\delta,\ \ \forall \delta > 0, \forall P_X \text{ s.t. } \mathbb{E}[\mathsf{c}(X)] < P \\ \Rightarrow\ &C_\epsilon(P) \ge \sup_{P_X:\mathbb{E}[\mathsf{c}(X)]<P} \lim_{\delta\to 0}(I(X;Y) - 2\delta) \end{aligned}$$

$$\Rightarrow C_\epsilon(P) \geq \sup_{P_X:\mathbb{E}[\mathsf{c}(X)]<P} I(X;Y) = C^{(\mathrm{I})}(P-) = C^{(\mathrm{I})}(P)$$

其中最后一个等式是由命题20.4中$C^{(\mathrm{I})}$在(P_0,∞)上的连续性得出的。

对于一般的信息稳定信道，我们只需使用定义来证明 $P[i(X^n;Y^n) \leq n(C^{(\mathrm{I})}-\delta)] \to 0$，其余的证明也类似。 □

定理 20.9（成本约束下的信道容量）*For an information stable channel with cost constraint and for any admissible constraint P we have*

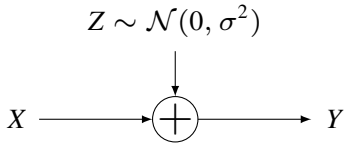
$$C(P) = C^{(\mathrm{I})}(P).$$

Proof. $P = P_0$ 的边界情况在习题 IV.23 中处理，该题表明即使 $C^{(\mathrm{I})}(P)$ 在 P_0 处可能不连续，$C(P_0) = C^{(\mathrm{I})}(P_0)$ 仍然成立。因此接下来假设 $P > P_0$。定理 20.6 表明 $C_\epsilon(P) \leq \frac{C^{(\mathrm{I})}(P)}{1-\epsilon}$，因此 $C(P) \leq C^{(\mathrm{I})}(P)$。另一方面，由定理 20.8 我们有 $C(P) \geq C^{(\mathrm{I})}(P)$。

□

20.3 静止AWGN信道

我们从也许是最重要的信道开始我们的应用（从通信工程的角度来看）。



定义 20.10（平稳 AWGN 信道）加性白高斯噪声（AWGN）信道是一种平稳无记忆加性噪声信道，具有可分离代价约束：$\mathcal{A} = \mathcal{B} = \mathbb{R}$、$\mathsf{c}(x) = x^2$，以及由 $Y = X+Z$ 给出的单字母核 $P_{Y|X}$，其中 $Z \sim \mathcal{N}(0,\sigma^2) \perp\!\!\!\perp X$。$n$-字母核由乘积扩展给出，即 $Y^n = X^n + Z^n$，其中 $Z^n \sim \mathcal{N}(0, I_n)$。当功率约束为 $\mathbb{E}[\mathsf{c}(X)] \leq P$ 时，我们说信噪比（SNR）等于 $\frac{P}{\sigma^2}$。请注意，我们早先的非正式定义（例 3.3）缺少代价约束函数的说明，没有它定义就不完整。

术语白噪声是指噪声变量在时间上不相关这一事实。这使得过程 $\{Z_j\}$ 的功率谱密度在频率上恒定（或“白色”）。在提到这个信道时，我们通常会省略“平稳”一词。我们上面给出的定义更准确地说应该被称为 *real* AWGN 或 $\mathbb{R}$-AWGN 信道。复 AWGN 或 $\mathbb{C}$-信道类似地定义为：$\mathcal{A} = \mathcal{B} = \mathbb{C}$、$\mathsf{c}(x) = |x|^2$ 和 $Y^n = X^n + Z^n$，其中 $Z^n \sim \mathcal{N}_c(0, I_n)$ 是圆对称复高斯。

定理 20.11 *For the stationary AWGN channel, the channel capacity is equal to information capacity, and is given by:*

$$C(P) = C^{(\mathrm{I})}(P) = \frac{1}{2}\log\left(1+\frac{P}{\sigma^2}\right) \quad \textit{for } \mathbb{R}\textit{-AWGN} \tag{20.4}$$
$$C(P) = C^{(\mathrm{I})}(P) = \log\left(1+\frac{P}{\sigma^2}\right) \quad \textit{for } \mathbb{C}\textit{-AWGN}$$

Proof. 根据推论20.5,

$$C^{(\mathrm{I})} = \sup_{P_X:\mathbb{E}X^2\le P} I(X;X+Z)$$

然后使用定理5.11（高斯鞍点）来断定$X\sim\mathcal{N}(0,P)$ (或$\mathcal{N}_c(0,P)$)是唯一的达到容量的输入分布。 □

此时，重新审视第6.2*节也是有益的，该节表明高斯容量实际上本质上无需解决互信息最大化就能推导出来：欧几里得旋转对称性意味着最优输入应该是高斯分布。

在香农公式（20.4）看似简单的形式中，蕴含着大量深奥的知识。首先，从工程角度来看，我们立刻就能看出，要更快地（单位时间内）传输信息，就需要以更高的功率发射作为代价，但传输速度的提升仅呈对数关系。优秀的纠错码波形应当看起来像白高斯过程的样本。

其次，通过求解最小化每传输信息比特所消耗的能量

$$\inf_{P>0}\frac{P\log 2}{C(P)} = 2\sigma^2\log_e 2 \tag{20.5}$$

并通过取 $P\to 0$ 来实现。（我们将在第21.1节进一步讨论每比特能量的概念。）因此，我们看到，为了最大化通信 *rate*，我们需要发送强大的高功率波形。但为了最小化每比特能量，我们需要以非常安静的“耳语”和非常低的通信速率发送。[2] 此外，当以非常低的功率（因此速率也很低）进行信号传输时，通过查看图3.2，我们可以看到可以限制为仅二进制 $\pm\sqrt{P}$ 符号（所谓的BPSK调制）。这几乎不会导致容量损失。

第三，从数学角度来看，公式（20.4）揭示了高维欧几里得几何的某些性质如下。由于$Z^n\sim\mathcal{N}(0,\sigma^2)$，那么$\|Z^n\|_2$很可能集中在$\sqrt{n\sigma^2}$附近。类似地，由于功率约束以及$Z^n\perp\!\!\!\perp X^n$的事实，我们有$\mathbb{E}\left[\|Y^n\|^2\right]=\mathbb{E}\left[\|Y^n\|^2\right]+\mathbb{E}\left[\|Z^n\|^2\right]\le n(P+\sigma^2)$，接收向量$Y^n$位于半径约为$\sqrt{n(P+\sigma^2)}$的$\ell_2$-球内。由于噪声在欧几里得距离上对码字的扰动最多为$\sqrt{n\sigma^2}$，如果我们能将M个半径为$\sqrt{n\sigma^2}$的球装入以原点为中心的半径为$\sqrt{n(P+\sigma^2)}$的ℓ_2-球中，这将产生一个良好的码本和解码区域——参见图20.1的示例。那么M可以有多大？注意，在$\mathbb{R}^n$中半径为r的ℓ_2-球的体积由下式给出

[2] This explains why, for example, the deep space probes communicate with earth via very low-rate codes and very long blocklengths.

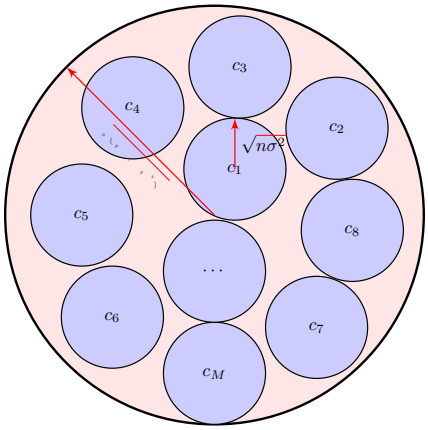


图20.1 将AWGN容量公式解释为“软”填充。

$c_n r^n$ 对于某个常数 c_n。然后 $\frac{c_n(n(P+\sigma^2))^{n/2}}{c_n(n\sigma^2)^{n/2}} = \left(1+\frac{P}{\sigma^2}\right)^{n/2}$。取对数并除以 n，我们得到 $\frac{1}{n}\log M^* \approx \frac{1}{2}\log\left(1+\frac{P}{\sigma^2}\right)$。然而，这个看似极具说服力的推理至少存在两个缺陷。(a) 计算体积比只能给出不相交球体最大数量的上界(关于此主题的广泛讨论，请参见第27.2节)。(b) 码字不必对应于 *disjoint* ℓ_2 球的中心。事实上，我们允许一定的消失(但非零)错误概率，这意味着 $\sqrt{n\sigma^2}$ 球略微重叠，而香农公式确立了我们可以打包此类部分重叠球的最大数量，使得它们(大部分)位于一个更大的球内。

由于定理 20.11 适用于高斯噪声，自然会问：如果噪声是非高斯的，容量公式 $\frac{1}{2}\log(1+\mathrm{SNR})$ 对高斯假设有多敏感？回想定理 5.11 中的高斯鞍点结果，它表明在相同方差下，高斯噪声是最差的，这表明任何非高斯噪声的容量至少为 $\frac{1}{2}\log(1+\mathrm{SNR})$。反过来，容量的增加可以通过噪声的非高斯程度（以 KL 散度衡量）来控制。以下结果归功于 Ihara [223]。

定理 20.12（加性非高斯噪声）*Let Z be a real-valued random variable independent of X and $\mathbb{E}Z^2 < \infty$. Let $\sigma^2 =$ 方差 Z. Then*

$$\frac{1}{2}\log\left(1+\frac{P}{\sigma^2}\right) \le \sup_{P_X:\mathbb{E}X^2\le P} I(X;X+Z) \le \frac{1}{2}\log\left(1+\frac{P}{\sigma^2}\right) + D(P_Z\|\mathcal{N}(\mathbb{E}Z,\sigma^2)). \tag{20.6}$$

Proof. 参见练习 IV.24。 □

注20.1 量$D(P_Z\|\mathcal{N}(\mathbb{E}Z,\sigma^2))$有时被称为*non-Gaussianness*的$Z$，其中$\mathcal{N}(\mathbb{E}Z,\sigma^2)$是具有与$Z$相同均值和方差的高斯分布。因此，如果$Z$具有非高斯密度，例如$Z$在[0, 1]上均匀分布，那么容量只能与……相差一个常数。

AWGN，在高信噪比 regime 下，其仍然按 $\frac{1}{2}\log \mathrm{SNR}$ 进行缩放。另一方面，如果 Z 是离散的，那么 $D(P_Z\|\mathcal{N}(\mathbb{E}Z,\sigma^2)) = \infty$，并且在这种情况下，人们可以证明容量是无限的，因为噪声“过于微弱”。

20.4 并行AWGN信道

定义 20.13（并行 AWGN） 一个具有 L 个分支的并行 AWGN 信道是一个平稳无记忆信道，其单字母核定义如下：字母表 $\mathcal{A} = \mathcal{B} = \mathbb{R}^L$，代价 $\mathsf{c}(x) = \sum_{k=1}^L |x_k|^2$；以及核 $P_{Y^L|X^L}$：$Y_k = X_k + Z_k$，对于 $k = 1,\dots,L$，且 $Z_k \sim \mathcal{N}(0, \sigma_k^2)$ 对每个分支独立。

定理 20.14（注水法） *The capacity of L-parallel AWGN channel is given by*

$$C = \frac{1}{2}\sum_{j=1}^{L} \log^+ \frac{T}{\sigma_j^2}$$

where $\log^+(x) \triangleq \max(\log x, 0)$*, and* $T \geq 0$ *is determined by*

$$P = \sum_{j=1}^{L} |T - \sigma_j^2|^+$$

Proof.

$$\begin{aligned} C^{(\mathrm{I})}(P) &= \sup_{P_{X^L}:\sum \mathbb{E}[X_i^2]\leq P} I(X^L;Y^L) \\ &\leq \sup_{\sum P_k \leq P, P_k \geq 0} \sum_{k=1}^{L} \sup_{\mathbb{E}[X_k^2]\leq P_k} I(X_k;Y_k) \\ &= \sup_{\sum P_k \leq P, P_k \geq 0} \sum_{k=1}^{L} \frac{1}{2}\log(1+\frac{P_k}{\sigma_k^2}) \end{aligned}$$

如果 $X_k \sim \mathcal{N}(0, P_k)$ 是独立的，则等号成立。因此问题归结为最后一个最大化问题，即最优 *power allocation* 问题。将约束 $\sum P_k \leq P$ 的拉格朗日乘子记为 λ，约束 $P_k \geq 0$ 的拉格朗日乘子记为 μ_k。我们希望求解 $\max \sum \frac{1}{2}\log(1+\frac{P_k}{\sigma_k^2}) - \mu_k P_k + \lambda(P - \sum P_k)$。关于 P_k 的一阶条件给出

$$\frac{1}{2}\frac{1}{\sigma_k^2 + P_k} = \lambda - \mu_k, \quad \mu_k P_k = 0$$

因此最优解是

$$P_k = |T - \sigma_k^2|^+, \quad T \text{ is chosen such that } P = \sum_{k=1}^{L} |T - \sigma_k^2|^+$$

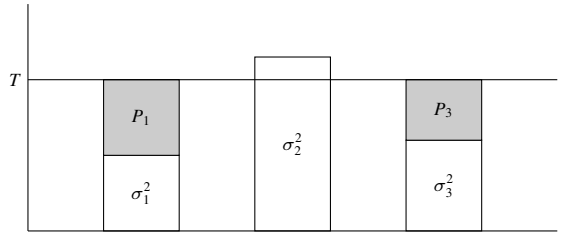


图20.2 通过注水法在三个并行信道上的功率分配。在此情形下，第二分支因噪声过大（σ_2过大），超出了可用功率P的范围，最优编码策略应完全舍弃（向该分支输入零）这一分支。

□

图20.2展示了注水解法。该方案有几个具有实际重要性的结论。首先，它给出了在不同频段上如何精确分配功率的方法。这一简洁而优雅的解决方案，实际上对于通过有线调制解调器或ADSL将高速互联网带入众多家庭起到了关键作用：起初，在信息理论家发表意见之前，功率分配是基于对真实编码进行昂贵且不精确的仿真来选定的。注水方案的简洁性使得功率分配具有动态性，并能够即时应对不断变化的噪声环境。

其次，对于多天线（MIMO）通信而言，有一个非常重要的结果。给定n_r个接收天线和n_t个发射天线，通常可以得到一个具有$L = \min(n_r, n_t)$分支的并行AWGN（见练习I.9和I.10）。对于单天线系统，随着功率的增加，其容量按$\frac{1}{2}\log P$的比例增长（定理20.11），而MIMO AWGN信道的容量在P较大时近似为$\frac{L}{2}\log(\frac{P}{L}) \approx \frac{L}{2}\log P$。这导致在高信噪比下容量增加$L$倍。这是MIMO中空间复用这一强大技术的基础，也是4G、5G蜂窝（3GPP）和post-802.11n WiFi系统取得诸多进展的主要推动力。

请注意，空间分集（要求同时具备接收和发射天线）与所谓多径分集（即使仅在一侧增加天线也能起作用）不同。实际上，如果同一数据流通过每个并行信道同时发送，那么充分的统计量将是所有接收向量的平均值，从而使有效噪声水平降低$\frac{1}{L}$因子。这导致容量从$\frac{1}{2}\log P$增加到$\frac{1}{2}\log(LP)$——这与空间复用的L倍增长相去甚远。这些激动人心的主题在优秀的教科书[423, 268]中有所探讨。

20.5* 非平稳AWGN

定义 20.15（非平稳 AWGN）非平稳 AWGN 信道是一个无记忆信道，具有单字母表 $\mathcal{A} = \mathcal{B} = \mathbb{R}$ 和可分离代价 $\mathsf{c}(x) = x^2$。该信道通过加法 $Y^n = X^n + Z^n$ 作用于输入向量 X^n，其中 $Z_j \sim \mathcal{N}(0, \sigma_j^2)$ 是独立的。

定理 20.16 *Assume that for every $T > 0$ the following limits exist:*

$$\tilde{C}^{(\mathrm{I})}(T) = \lim_{n\to\infty} \frac{1}{n} \sum_{j=1}^{n} \frac{1}{2} \log^+ \frac{T}{\sigma_j^2}$$
$$\tilde{P}(T) = \lim_{n\to\infty} \frac{1}{n} \sum_{j=1}^{n} |T - \sigma_j^2|^+ .$$

Then the capacity of the non-stationary AWGN channel is given by the parameterized form: $C(T) = \tilde{C}^{(\mathrm{I})}(T)$ with input power constraint $\tilde{P}(T)$.

Proof. 固定 $T >$ = 0。然后，从定理20.14中的注水解决方案可以明显看出，

$$\sup I(X^n; Y^n) = \sum_{j=1}^{n} \frac{1}{2} \log^+ \frac{T}{\sigma_j^2}, \tag{20.7}$$

其中上确界取遍所有满足下式的 P_{X^n}

$$\mathbb{E}[\mathsf{c}(X^n)] \le \frac{1}{n} \sum_{j=1}^{n} |T - \sigma_j^2|^+ . \tag{20.8}$$

现在，根据假设，(20.8) 式的左侧收敛到 $\tilde{P}(T)$。因此，对于每个 $\delta > 0$，我们有

$$C^{(\mathrm{I})}(\tilde{P}(T) - \delta) \le \tilde{C}^{(\mathrm{I})}(T)$$
$$C^{(\mathrm{I})}(\tilde{P}(T) + \delta) \ge \tilde{C}^{(\mathrm{I})}(T)$$

取 $\delta \to 0$ 并利用 $P \mapsto C^{(\mathrm{I})}(P)$ 的连续性，我们从定理 19.15 得到信息容量满足

$$C^{(\mathrm{I})}(\tilde{P}(T)) = \tilde{C}^{(\mathrm{I})}(T)$$

前提是信道是信息稳定的。事实上，从（19.32）

$$\mathrm{Var}(i(X_j; Y_j)) = \frac{\log^2 e}{2} \frac{P_j}{P_j + \sigma_j^2} \le \frac{\log^2 e}{2}$$

因此

$$\sum_{j=1}^{n} \frac{1}{n^2} \mathrm{Var}(i(X_j; Y_j)) < \infty .$$

由此，根据定理19.16可推出信息稳定性。 □

由于非平稳AWGN与下一节中加性有色高斯噪声信道的关系，它主要受到关注。

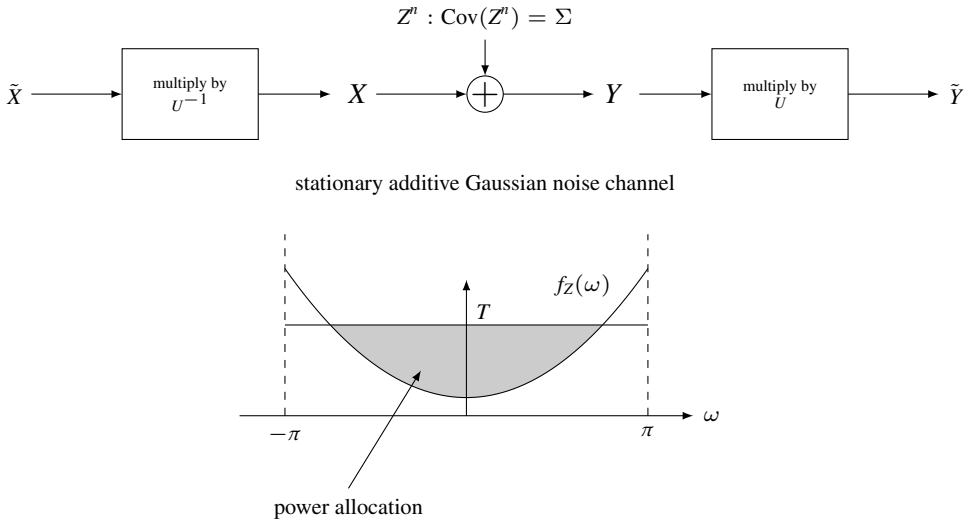


图20.3 ACGN信道：容量证明中使用的“白化”过程以及跨频谱的注水功率分配。

20.6* 加性有色高斯噪声信道

定义 20.17 加性有色高斯噪声（ACGN）信道是一个具有如下定义的记忆信道。单字母表为 $\mathcal{A} = \mathcal{B} = \mathbb{R}$，可分成本为 $\mathsf{c}(x) = x^2$。该信道通过加法 $Y^n = X^n + Z^n$ 作用于输入向量 X^n，其中 $\{Z_j : j \geq 1\}$ 是一个具有功率谱密度 $f_Z(\omega) \geq 0, \omega \in [-\pi, \pi]$ 的平稳高斯过程（回想例 6.4）。

定理 20.18 *The capacity of the ACGN channel with $f_Z(\omega) > 0$ for almost every $\omega \in [-\pi, \pi]$ is given by the following parametric form:*

$$C(T) = \frac{1}{2\pi} \int_{-\pi}^{\pi} \frac{1}{2} \log^+ \frac{T}{f_Z(\omega)} d\omega,$$
$$P(T) = \frac{1}{2\pi} \int_{-\pi}^{\pi} |T - f_Z(\omega)|^+ d\omega.$$

Proof. 对于$n \geq 1$，考虑协方差矩阵的对角化 Z^n 的 x:

$$\mathrm{Cov}(Z^n) = \Sigma = U^\top \widetilde{\Sigma} U, \text{ such that } \widetilde{\Sigma} = \mathrm{diag}(\sigma_1, \ldots, \sigma_n),$$

其中 U 是一个正交矩阵。（因为 $\mathrm{Cov}(Z^n)$ 是半正定的，所以这种对角化总是可能的。）定义 $\widetilde{X}^n = UX^n$ 和 $\widetilde{Y}^n = UY^n$，因此 $\widetilde{X}^n$ 与 $\widetilde{Y}^n$ 之间的信道是

$$\widetilde{Y}^n = \widetilde{X}^n + UZ^n,$$

$$\mathrm{Cov}(UZ^n) = U \cdot \mathrm{Cov}(Z^n) \cdot U^\top = \widetilde{\Sigma}$$

因此，我们得到如下的等效信道：

$$\widetilde{Y}^n = \widetilde{X}^n + \widetilde{Z}^n, \quad \widetilde{Z}_j \sim \mathcal{N}(0, \sigma_j^2) \text{ independent across } j.$$

注意，由于 U 和 $U^\top$ 是正交的，映射 $\tilde{X}^n = UX^n$ 和 $X^n = U^\top \tilde{X}^n$ 保持范数 $\|\tilde{X}^n\| = \|X^n\|$。因此，两个信道的容量相等：$C = \tilde{C}$。但后者由定理 20.16 得出。事实上，我们有

$$\widetilde{C} = \lim_{n\to\infty} \frac{1}{n} \sum_{j=1}^{n} \log^+ \frac{T}{\sigma_j^2} = \frac{1}{2\pi} \int_{-\pi}^{\pi} \frac{1}{2} \log^+ \frac{T}{f_Z(\omega)} d\omega. \quad \text{(Szegö's theorem, see (6.12))}$$

$$\lim_{n\to\infty} \frac{1}{n} \sum_{j=1}^{n} |T - \sigma_j^2|^+ = P(T). \qquad \square$$

证明中使用的思想以及注水功率分配如图20.3所示。注意，大多数情况下，影响现实世界系统的噪声实际上是“天生”白色的（因为它是热噪声）。然而，在其注入点和处理之间通常有多个电路元件。如果我们线性地对它们建模，那么它们的作用可以等效地描述为ACGN信道，因为所添加的有效噪声变成了有色噪声。事实上，这种滤波可以故意插入，以便将实际信道转换为加性噪声信道。这是下一节的内容。

20.7* 具有符号间干扰的AWGN信道

在无线通信系统中，信号常常通过丰富的散射环境传播。因此，到达接收端的是初始信号的多个延迟和衰减副本。这种情况正式称为*intersymbol interference (ISI)*。类似效应也发生在电缆调制解调器尝试通过电话线或电视线发送信号时，这是由于各种线性滤波器、变压器和继电器的存在。此类信道的数学模型如下。

定义 20.19（带 ISI 的 AWGN）带 ISI 的 AWGN 信道是一种有记忆信道，其定义如下：字母表为 $\mathcal{A} = \mathcal{B} = \mathbb{R}$，可分代价为 $\mathsf{c}(x) = x^2$。信道律 $P_{Y^n|X^n}$ 由下式给出

$$Y_k = \sum_{j=1}^{n} h_{k-j} X_j + Z_k, \qquad k = 1, \ldots, n$$

其中 $Z_k \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma^2)$ 是白高斯噪声，$\{h_k, k \in \mathbb{Z}\}$ 是离散时间信道滤波器的系数。

系数 $\{h_k\}$ 描述了环境的作用。它们通常由接收方在建立通信链路的“握手”过程中学习获得。

定理 20.20 *Suppose that the sequence $\{h_k\}$ is the inverse Fourier transform of a frequency response $H(\omega)$:*

$$h_k = \frac{1}{2\pi}\int_{-\pi}^{\pi} e^{i\omega k} H(\omega) d\omega\,.$$

Assume also that $H(\omega)$ is a continuous function on $[0, 2\pi]$. Then the capacity of the AWGN channel with ISI is given by

$$C(T) = \frac{1}{2\pi}\int_{-\pi}^{\pi} \frac{1}{2}\log^+(T|H(\omega)|^2)d\omega$$

$$P(T) = \frac{1}{2\pi}\int_{-\pi}^{\pi} \left|T - \frac{1}{|H(\omega)|^2}\right|^+ d\omega$$

Proof sketch. 在解码器处，应用具有频率响应 $\omega \mapsto \frac{1}{H(\omega)}$ 的逆滤波器。等效信道由此变为一个平稳有色噪声高斯信道：

$$\tilde{Y}_j = X_j + \tilde{Z}_j\,,$$

其中 $\tilde{Z}_j$ 是一个具有谱密度的平稳高斯过程

$$f_{\tilde{Z}}(\omega) = \frac{1}{|H(\omega)|^2}\,.$$

然后将定理20.18应用于所得到的信道。

为了使上述论证严谨，必须仔细分析将去卷积滤波器截断为有限n时所引入的非零误差。这将大大超出本书的范围。

□

20.8* 具有幅度约束的高斯信道

我们已考察了加性高斯噪声信道的一些经典结果。在下文中，我们将不加证明地列出一些较新的结果。

定理 20.21（幅度受限的AWGN信道容量）*For an AWGN channel $Y_i = X_i + Z_i$ with amplitude constraint $|X_i| \le A$, we denote the capacity by:*

$$C(A) = \max_{P_X:|X|\le A} I(X; X+Z).$$

The capacity achieving input distribution P_X^* is discrete, with finitely many atoms on $[-A, A]$. The number of atoms is $\Omega(A)$ and $O(A^2)$ as $A \to \infty$. Moreover,

$$\frac{1}{2}\log\left(1 + \frac{2A^2}{e\pi}\right) \le C(A) \le \frac{1}{2}\log\left(1 + A^2\right)$$

定理 20.22（幅度和功率约束的AWGN信道容量）
For an AWGN channel $Y_i = X_i + Z_i$ with amplitude constraint $|X_i| \le A$ and power constraint $\sum_{i=1}^n X_i^2 \le nP$, we denote the capacity by:

$$C(A,P) = \max_{P_X:|X|\le A, \mathbb{E}|X|^2 \le P} I(X; X+Z).$$

Capacity achieving input distribution P_X^* is discrete, with finitely many atoms on $[-A, A]$. Moreover, the convergence speed of $\lim_{A\to\infty} C(A,P) = \frac{1}{2}\log(1+P)$ is of the order $e^{-O(A^2)}$.

有关细节，请参见[396]、[343，第III节]和[144, 348]关于原子数量上的$O(A^2)$界限。

20.9* 具有衰落的加性高斯信道

到目前为止，我们假设信道要么是加性的（如AWGN或ACGN），要么具有已知的乘性增益（如ISI）。然而，在实际中，信道增益是一个随机变量。这种情况被称为“衰落”，常用于建模具有多径或阴影效应的城市信号传播。在时间i接收到的信号Y_i受到乘性衰落系数H_i和加性噪声Z_i的影响，如下所示：

$$Y_i = H_i X_i + Z_i, \quad Z_i \sim \mathcal{N}(0, \sigma^2)$$

这在图20.4中进行了说明。

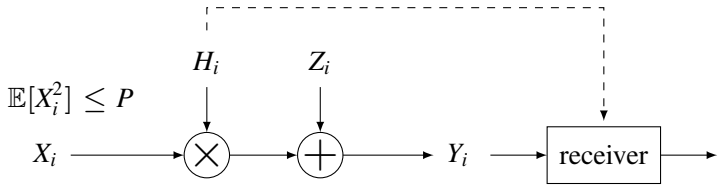


图20.4 具有衰落的AWGN信道。

根据图20.4中虚线链路的有无，衰落信道存在两种截然不同的情况。在第一种情况下，称为*coherent case*或*CSIR case* (针对接收端信道状态信息)，假设接收端在每个时刻i都能完美估计信道状态信息H_i。换言之，信道输出实际上是（Y_i, H_i）。这种情况例如发生在周期性发送导频信号并在接收端用于估计信道时。在某些情况下，索引i指代OFDM帧的不同频率或子信道。

每当 H_j 是一个平稳遍历过程时，我们得到的信道容量由下式给出：

$$C(P) = \mathbb{E}\left[\frac{1}{2}\log\left(1 + \frac{P|H|^2}{\sigma^2}\right)\right]$$

而实现容量的输入分布是通常的 $P_X = \mathcal{N}(0, P)$。注意，容量 $C(P)$ 的量级为 $\log P$，我们将该信道称为“能量高效”的。

在第二种情况下，称为*non-coherent*或*no-CSIR*，接收器对系数H_i没有任何了解。在这种情况下，信道容量没有简单的表达式。大多数已知结果是在H_i根据瑞利分布独立同分布的情况下展示的。在这种情况下，达到容量的输入分布是离散的[3]，并且容量按[415, 269]缩放。

$$C(P) = O(\log\log P), \qquad P \to \infty \tag{20.9}$$

该信道被称为“能效低下”，因为提高通信速率需要大幅增加功率消耗。

高斯信道模型的进一步推广需要引入多个输入和输出天线（称为MIMO信道）。在这种情况下，单字母输入$X_i \in \mathbb{C}^{n_t}$与输出$Y_i \in \mathbb{C}^{n_r}$之间的关系为

$$Y_i = H_i X_i + Z_i\,, \tag{20.10}$$

其中 $Z_i \overset{\text{i.i.d.}}{\sim} \mathcal{CN}(0, \sigma^2 I_{n_r})$、$n_t$ 和 n_r 是发射天线和接收天线的数量，而 $H_i \in \mathbb{C}^{n_t \times n_r}$ 是一个矩阵值信道增益过程。关于在 CSIR 下该信道的容量，请参见习题 I.10。20 世纪 90 年代和 2000 年代，信息论和通信理论的研究人员投入了惊人的努力来理解这一信道模型。其中的一些亮点包括：

• 一种优美的发射分集2x2 Alamouti码 [10] • Alamouti码的推广导致了空时编码的发现 [417, 416] • Telatar的结果 [418] 表明，在相干衰落条件下，容量按 $\min(n_t, n_r)\log P$（缩放，出现在 log 前的系数被称为信道的 *pre-log* 或 *degrees- of-freedom*) Zheng和Tse的结果 [474] 表明，在非相干（块衰落）情况下，缩放中的预对数因子不同。

很遗憾，此处无法对MIMO通信中的这些以及许多其他基本成果进行全面公正的介绍。我们推荐教科书[423]作为进入这一深奥而激动人心领域的入门读物。

21 Capacity per unit cost

在本章中，我们将考虑信道编码问题的一个有趣变体。不同于限制块长度（即信道使用次数），我们将限制码字所产生的总代价。该问题最重要的特例是AWGN信道与二次（能量）代价约束。此设定下的标准动机如下。考虑一个深空探测器，它有一条k比特的消息需要传送到地球（或环绕地球的卫星）。对于探测器而言，传输时长几乎无需担忧，真正受限的是其电池中储存的能量。在本章中，我们将学习如何抽象地研究这一问题，如何通过对大量比特$k \to \infty$进行编码来降低（每比特）能耗，以及这一基本极限与连续时间信道通信之间的关系。

21.1 每位元能量

在本章中，我们将考虑作用于两个无限序列空间之间的马尔可夫核$P_{Y^\infty|X^\infty}$。典型的例子仍然是AWGN信道：

$$Y_i = X_i + Z_i, \quad Z_i \sim \mathcal{N}(0, N_0/2). \tag{21.1}$$

请注意，在本章中，我们将Z_i的噪声水平记为$\frac{N_0}{2}$。这种记法有着悠久的传统。实际上，通信系统中的大多数噪声是接收端的热白噪声。该噪声的功率谱密度是平坦的，用N_0 (表示，单位为焦耳每秒每赫兹)。然而，请记住，接收信号是复值的，因此每个实部的功率为$\frac{N_0}{2}$。另请注意，热力学表明$N_0 = kT$，其中$k = 1.38 \times 10^{-23}$是玻尔兹曼常数，T是开尔文绝对温度。

在前一章中，我们分析了在给定n次信道使用次数和功率约束P下，通过该信道可发送的最大信息消息数（$M^*(n, \epsilon, P)$）。我们也在(20.5)中暗示了发送每个（数据）比特存在一个基本的最小所需成本。本章中，我们将更严格地探讨这一问题。在本章的每一处，对于$v \in \mathbb{R}^\infty$

$$\|v\|_2^2 \triangleq \sum_{j=1}^{\infty} v_j^2 .$$

定义 21.1（$(E, 2^k, \epsilon)$-码）给定输入空间为 $\mathbb{R}^\infty$ 的马尔可夫核，我们定义 $(E, 2^k, \epsilon)$-码为一个编码器-解码器对，$f: [2^k] \to \mathbb{R}^\infty$ 和 $g: \mathbb{R}^\infty \to [2^k]$（或类似的随机化版本），使得对于所有消息 $m \in [2^k]$，我们有 $\|f(m)\|_2^2 \le E$ 和

$$\mathbb{P}[g(Y^\infty) \neq W] \le \epsilon\,,$$

其中照常，概率空间为$W \to X^\infty \to Y^\infty \to \hat{W}$，具有$W \sim \mathrm{Unif}([2^k])$、$X^\infty = f(W)$和$\hat{W} = g(Y^\infty)$。基本极限定义为

$$E^*(k,\epsilon) = \min\{E : \exists (E, 2^k, \epsilon)\ \text{code}\}$$

$E^*(k,\epsilon)$ 的操作意义应当显而易见：它是太空探测器为了发送 k 比特数据所需从电池中提取的最小能量。

定理 21.2（$(E_b/N_0)_{min} = -1.6dB$）*For the AWGN channel we have*

$$\lim_{\epsilon\to 0} \limsup_{k\to\infty} \frac{E^*(k,\epsilon)}{k} = \frac{N_0}{\log_2 e}\,. \tag{21.2}$$

备注 21.1 这一结果最早由香农 [378] 获得，俗称：最小 E_b/N_0（读作“ee bee over enzero”或“ebno”）为 −1.6 dB。后一个值就是 $10\log_{10}(\frac{1}{\log_2 e}) \approx -1.592$。达到这个 ebno 值是编码理论的终极追求，最早由 Turbo 码 [47] 解决。关于这一漫长征服过程的综述见 [101]。我们还注意到，如果用 $\mathbb{C}$-AWGN 信道代替实值 AWGN 信道，基本极限不变。

$$Y_i = X_i + Z_i, \qquad Z_i \sim \mathcal{CN}(0, N_0)$$

以及能量约束$\sum_{i=1}^\infty |X_i|^2 \le E$。实际上，这个信道的单一输入可以简单地转换为$\mathbb{R}$-AWGN信道的一对输入。这使得块长度加倍，但无论如何它被认为是无限的。

Proof. 我们从一个下界（或“逆命题”部分）开始。像往常一样，我们有工作概率空间

$$W \to X^\infty \to Y^\infty \to \hat{W}\,.$$

然后考虑以下链：

$$\begin{aligned}
-h(\epsilon) + \bar{\epsilon}k &\le d\Big((1-\epsilon)\|\frac{1}{M}\Big) && \text{Fano's inequality}\\
&\le I(W;\hat{W}) && \text{data processing for divergence}\\
&\le I(X^\infty; Y^\infty) && \text{data processing for mutual information}\\
&\le \sum_{i=1}^\infty I(X_i;Y_i) && \lim_{n\to\infty} I(X^n;U) = I(X^\infty;U)\ \text{by (4.30)}
\end{aligned}$$

$$
\begin{aligned}
&\leq \sum_{i=1}^{\infty} \frac{1}{2} \log\left(1+\frac{\mathbb{E}X_i^2}{N_0/2}\right) && \text{Gaussian capacity, Theorem 5.11}\\
&\leq \frac{\log e}{2} \sum_{i=1}^{\infty} \frac{\mathbb{E}X_i^2}{N_0/2} && \text{linearization of log}\\
&\leq \frac{E}{N_0} \log e.
\end{aligned}
$$

因此，我们已经展示了

$$\frac{E^*(k,\epsilon)}{k} \geq \frac{N_0}{\log e}\left(\bar{\epsilon} - \frac{h(\epsilon)}{k}\right)$$

并在 $n \to \infty$ 中取双重极限，然后在 $\epsilon \to$ 中取 0，即完成证明。

接下来，对于上界（“可达性”部分），我们首先给出一个传统的存在性证明。注意到，对于AWGN信道的一个$(n, 2^k, \epsilon, P)$-码同时也是无时间约束的能量问题的一个$(nP, 2^k, \epsilon)$-码。因此，

$$\log_2 M^*(n,\epsilon,P) \geq k \Rightarrow E^*(k,\epsilon) \leq nP.$$

取 $k_n = \lfloor \log_2 M^*(n,\epsilon,P) \rfloor$，于是对所有 $n \geq 1$ 都有 $\frac{E^*(k_n,\epsilon)}{k_n} \leq \frac{nP}{k_n}$。取极限后我们得到

$$
\begin{aligned}
\limsup_{n\to\infty} \frac{E^*(k_n,\epsilon)}{k_n} &\leq \limsup_{n\to\infty} \frac{nP}{\log M^*(n,\epsilon,P)}\\
&= \frac{P}{\liminf_{n\to\infty} \frac{1}{n}\log M^*_{\max}(n,\epsilon,P)}\\
&= \frac{P}{\frac{1}{2}\log(1+\frac{P}{N_0/2})},
\end{aligned}
$$

其中最后一步我们应用了定理20.11。现在上述陈述对每个$P>>0$都成立，因此我们对其进行优化以获得最佳界：

$$
\begin{aligned}
\limsup_{n\to\infty} \frac{E^*(k_n,\epsilon)}{k_n} &\leq \inf_{P\geq 0} \frac{P}{\frac{1}{2}\log(1+\frac{P}{N_0/2})}\\
&= \lim_{P\to 0} \frac{P}{\frac{1}{2}\log(1+\frac{P}{N_0/2})}\\
&= \frac{N_0}{\log_2 e} \qquad (21.3)
\end{aligned}
$$

请注意，最小每比特能量在$P \to 0$处取得这一事实意味着，为了在$-1.6dB$的香农极限下可靠地发送信息，需要无限多个时隙。换句话说，信息速率（也称为频谱效率）应当趋近于零。反过来说，为了获得非零的频谱效率，就必然要偏离$-1.6\ dB$。这种权衡被称为频谱效率与每比特能量之间的权衡。

接下来，我们可以给出一个更简单且更明确的码构造方法，不依赖于定理20.11中隐含的随机编码。令$M = 2^k$，并考虑如下码，称为

脉冲位置调制（PPM）：

$$\text{PPM encoder: } \forall m, f(m) = \mathbf{c}_m \triangleq (0, 0, \ldots, \underbrace{\sqrt{E}}_{m\text{-th location}}, \ldots) \tag{21.4}$$

不难推导出该码可达到的错误概率的上界 [337，定理2]:

$$\epsilon \le \mathbb{E}\left[\min\left\{MQ\left(\sqrt{\frac{2E}{N_0}} + Z\right), 1\right\}\right], \qquad Z \sim \mathcal{N}(0,1). \tag{21.5}$$

确实，我们在最大似然解码器下的正交码本，其错误概率等于

$$P_e = 1 - \frac{1}{\sqrt{\pi N_0}} \int_{-\infty}^{\infty} \left[1 - Q\left(\sqrt{\frac{2}{N_0}} z\right)\right]^{M-1} e^{-\frac{(z-\sqrt{E})^2}{N_0}} dz, \tag{21.6}$$

这是通过观察到在 $(W = j, Z_j)$ 条件下，事件 $\{||\mathsf{c}_j + \mathsf{z}||^2 \le ||\mathsf{c}_j + \mathsf{z} - \mathsf{c}_i||^2\}$, $i \ne j$ 是独立的而得到的。变量替换 $x = \sqrt{\frac{2}{N_0}} z$ 并应用界限 $1 - (1-y)^{M-1} \le \min\{My, 1\}$ 将 (21.6) 弱化为 (21.5)。

为了看出(21.5)蕴含(21.3)，固定$c > 0$并在(21.5)中对$|Z| \le c$进行条件化，将其放松为

$$\epsilon \le MQ(\sqrt{\frac{2E}{N_0}} - c) + 2Q(c).$$

回想 Q-函数的展开式 [435, (3.53)]:

$$\log Q(x) = -\frac{x^2 \log e}{2} - \log x - \frac{1}{2}\log 2\pi + o(1), \quad x \to \infty \tag{21.7}$$

因此，选择 $\tau > 0$ 并设置 $E = (1+\tau)k\frac{N_0}{\log_2 e}$，我们得到 在

$$2^k Q(\sqrt{\frac{2E}{N_0}} - c) \to 0$$

作为 $k \to \infty$。因此，选择足够大的 $c > 0$，我们得到对于每个 $\tau > 0$，$\limsup_{k\to\infty} E^*(k,\epsilon) \le (1+\tau)\frac{N_0}{\log_2 e}$。取 $\tau \to 0$ 意味着 (21.3)。 □

备注 21.2（单纯形猜想） 代码（21.4）实际上达到了 $E^*(k,\epsilon)$ 的大 k 展开式中的前三项，参见 [337，定理 3]。事实上，该代码可以通过减去共同重心（$2^{-k}\sqrt{E}, \ldots, 2^{-k}\sqrt{E}\ldots$）并重新缩放每个码字以满足功率约束来进一步略微优化。由此得到的星座图被称为 *simplex code*。据猜想，它是在固定 k 和 ϵ 下实现 $E^*(k,\epsilon)$ 的实际最优代码；更多内容参见 [105，第 3.16 节] 和 [401]。

21.2 单位成本容量

将前一节中每位能量的设置进行推广，我们得到 *capacity per unit cost* 的问题。

定义 21.3 给定一个信道 $P_{Y^\infty|X^\infty}: \mathcal{X}^\infty \to \mathcal{Y}^\infty$ 和一个成本函数 $\mathsf{c}: \mathcal{X} \to \mathbb{R}_+$，我们定义 (E, M, ϵ)-码为一个编码器 $f: [M] \to \mathcal{X}^\infty$ 和一个解码器 $g: \mathcal{Y}^\infty \to [M]$，使得 a) 对于每个 m，编码器 $x^\infty \triangleq f(m)$ 的输出满足

$$\sum_{t=1}^{\infty} \mathsf{c}(x_t) \le E\,. \tag{21.8}$$

并且 b) 误差概率很小

$$\mathbb{P}[g(Y^\infty) \neq W] \le \epsilon\,,$$

其中，一如往常，我们在空间$W \to X^\infty \to Y^\infty \to \hat{W}$上操作，其中$W \sim$服从Unif($[M]$)。我们令

$$M^*(E, \epsilon) = \max\{M : (E, M, \epsilon)\text{-code}\}\,,$$

并将每单位成本的能力定义为

$$C_{puc} \triangleq \lim_{\epsilon \to 0} \liminf_{E \to \infty} \frac{1}{E} \log M^*(E, \epsilon)\,. \tag{21.9}$$

设 $C(P)$ 为信道的容量代价函数（在通常的容量意义下，如（20.1）中所定义）。假设 $P_0 = 0$ 且 $C(0) = 0$，不难证明（基本上遵循定理21.2的步骤）：

$$C_{puc} = \sup_P \frac{C(P)}{P} = \lim_{P \to 0} \frac{C(P)}{P} = \left.\frac{d}{dP}\right|_{P=0} C(P)\,.$$

Verdú [434] 的惊人发现是，人们可以避免计算 $C(P)$ 而直接推导出 C_{puc}。这是一个重大的帮助，因为对于许多实际信道而言，$C(P)$ 是未知的。此外，这赋予了 KL 散度又一个根本性的意义。

定理 21.4 *For a stationary memoryless channel $P_{Y^\infty|X^\infty} = \prod P_{Y|X}$ with $P_0 = \mathsf{c}(x_0) = 0$ (i.e. there is a symbol of zero cost), we have*

$$C_{puc} = \sup_{x \neq x_0} \frac{D(P_{Y|X=x} \| P_{Y|X=x_0})}{\mathsf{c}(x)}\,.$$

In particular, $C_{puc} = \infty$ if there exists $x_1 \neq x0$ with $\mathsf{c}(x1) = 0$.

Proof. 让

$$C_V = \sup_{x \neq x_0} \frac{D(P_{Y|X=x} \| P_{Y|X=x_0})}{\mathsf{c}(x)}\,.$$

Converse: 考虑一个(E,M,ϵ)-码 $W \to X^\infty \to Y^\infty \to \hat{W}$。引入一个辅助分布 $Q_{W,X^\infty,Y^\infty,\hat{W}}$，其中信道是无用的

$$Q_{Y^\infty|X^\infty} = Q_{Y^\infty} \triangleq P_{Y|X=x_0}^\infty .$$

也就是说，整体因式分解为

$$Q_{W,X^\infty,Y^\infty,\hat{W}} = P_W P_{X^\infty|W} Q_{Y^\infty} P_{\hat{W}|Y^\infty} .$$

然后，按照常规，我们从数据处理的角度来探讨散度

$$\begin{aligned}(1-\epsilon)\log M + h(\epsilon) &\le d(1-\epsilon\|\frac{1}{M}) \\ &\le D(P_{W,X^\infty,Y^\infty,\hat{W}}\|Q_{W,X^\infty,Y^\infty,\hat{W}}) \\ &= D(P_{Y^\infty|X^\infty}\|Q_{Y^\infty}|P_{X^\infty}) \\ &= \mathbb{E}\left[\sum_{t=1}^\infty d(X_t)\right], \end{aligned} \tag{21.10}$$

其中我们为方便起见记作$d(x) \triangleq D(P_{Y|X=x}\|P_{Y|X=x_0})$。根据$C_V$的定义，我们有

$$d(x) \le \mathsf{c}(x) C_V .$$

因此，继续(21.10)，我们得到

$$(1-\epsilon)\log M + h(\epsilon) \le C_V \mathbb{E}\left[\sum_{t=1}^\infty c(X_t)\right] \le C_V \cdot E,$$

其中最后一步由成本约束（21.8）得出。因此，除以 E 并取极限，我们得到

$$C_{puc} \le C_V .$$

Achievability: 我们将PPM代码（21.4）进行推广。对于每个$x_1 \in \mathcal{X}$和$n \in \mathbb{Z}_+$，我们如下定义编码器f:

$$\begin{aligned} f(1) &= (\underbrace{x_1, x_1, \ldots, x_1}_{n\text{-times}}, \underbrace{x_0, \ldots, x_0}_{n(M-1)\text{-times}}) \\ f(2) &= (\underbrace{x_0, x_0, \ldots, x_0}_{n\text{-times}}, \underbrace{x_1, \ldots, x_1}_{n\text{-times}}, \underbrace{x_0, \ldots, x_0}_{n(M-2)\text{-times}}) \\ &\cdots \\ f(M) &= (\underbrace{x_0, \ldots, x_0}_{n(M-1)\text{-times}}, \underbrace{x_1, x_1, \ldots, x_1}_{n\text{-times}}) \end{aligned}$$

现在，根据斯坦因引理（定理14.14），存在一个子集$S \subset \mathcal{Y}^n$，具有以下性质:

$$\begin{aligned} &\mathbb{P}[Y^n \in S | X^n = (x_1, \ldots, x_1)] \ge 1 - \epsilon_1 \\ &\mathbb{P}[Y^n \in S | X^n = (x_0, \ldots, x_0)] \le \exp\{-nD(P_{Y|X=x_1}\|P_{Y|X=x_0}) + o(n)\} . \end{aligned}$$

因此，我们提出以下（次优！）解码器：

$$\begin{aligned} Y^n \in S \quad &\Longrightarrow \quad \hat{W}=1 \\ Y_{n+1}^{2n} \in S \quad &\Longrightarrow \quad \hat{W}=2 \\ &\cdots \end{aligned}$$

根据联合界，我们发现总体错误概率的上界为

$$\epsilon \leq \epsilon_1 + M \exp\{-nD(P_{Y|X=x_1} \| P_{Y|X=x_0}) + o(n)\}\,.$$

同时，每个码字的总成本由$n\mathsf{c}(x_1)$给出。因此，取$n \to \infty$并经过直接运算后，我们得出结论：

$$C_{puc} \geq \frac{D(P_{Y|X=x_1} \| P_{Y|X=x_0})}{\mathsf{c}(x_1)}\,.$$

这对任何符号 $x_1 \in \mathcal{X}$ 都成立，因此我们可以自由地在 x_1 上取上确界，从而得到所需的 $C_{puc} \geq C_V$。 □

21.3 衰落信道的每比特能量

注意，当定理21.4应用于AWGN信道时，似乎并无实际意义：因为容量-代价函数$C(P)$已知，直接计算 $\lim_{P\to 0} \frac{C(P)}{P}$ 并不困难。定理21.4的真正威力在于将其应用于容量-代价函数未知的信道时。

具体而言，我们考虑一个接收端未知衰落H_j的平稳无记忆高斯信道（即非相干衰落信道，参见第20.9*节）：

$$Y_j = H_j X_j + Z_j, \qquad H_j \sim \mathcal{N}_c(0,1) \perp\!\!\!\perp Z_j \sim \mathcal{N}_c(0, N_0).$$

(我们这里使用一个更方便的 $\mathbb{C}$ 值衰落信道，其 $H_j \sim \mathcal{N}_c$，被称为瑞利衰落)。代价函数是通常的二次函数 $\mathsf{c}(x) = |x|^2$。正如我们之前讨论的，参见(20.9)，容量-代价函数 $C(P)$ 没有闭式解，但已知其行为与非衰落AWGN（即当 $H_j = 1$时）的情况截然不同。因此这里定理21.4派上了用场。让我们进行所需的简单计算，参见(2.9)：

$$\begin{aligned} C_{puc} &= \sup_{x\neq 0} \frac{D(\mathcal{N}_c(0, |x|^2+N_0) \| \mathcal{N}_c(0, N_0))}{|x|^2} \\ &= \frac{1}{N_0} \sup_{x\neq 0} \left(\log e - \frac{\log(1+\frac{|x|^2}{N_0})}{\frac{|x|^2}{N_0}} \right) \\ &= \frac{\log e}{N_0} \end{aligned} \tag{21.11}$$

与定理21.2相比，我们惊奇地发现，单位成本容量并未受到衰落的影响。换言之，那如此随机的乘性噪声

在高信噪比下有害，在低信噪比下似乎要温和得多（回想$C_{puc} = C'(0)$，因此计算C_{puc}对应于在$P \to 0$处计算$C(P)$）。有一个重要的区别：(21.11)中对x的上确界化在$x = \infty$处求解。遵循逆界的证明，我们得出结论，任何希望达到最优C_{puc}的码都必须满足一个奇怪的约束：

$$\sum_t |x_t|^2 1\{|x_t| \geq A\} \approx \sum_t |x_t|^2 \qquad \forall A > 0$$

即每个码字消耗的总能量必须几乎完全集中在非常大的尖峰中。这种编码方法被称为“闪光信号”。因此，我们可以看到，与非衰落AWGN信道不同（由于旋转对称性，所有码字都可以做得相对非尖峰化），在存在衰落的情况下，实现完整C_{puc}的唯一希望是通过短能量突发进行信号传输。因此，尽管AWGN信道或衰落信道的最终最小每比特能量相同，但最优编码方案的性质却相当不同。

两个信道之间的另一个根本差异体现在$E^*(k,\epsilon)$的有限块长度行为中。具体来说，对于每比特能量$\frac{E^*(k,\epsilon)}{k}$，我们有以下不同的渐近展开：

$$\frac{E^*(k,\epsilon)}{k} = (-1.59\ dB) + \sqrt{\frac{\text{constant}}{k}} Q^{-1}(\epsilon) \qquad \text{(AWGN)}$$

$$\frac{E^*(k,\epsilon)}{k} = (-1.59\ dB) + \sqrt[3]{\frac{\log k}{k}\,(Q^{-1}(\epsilon))^2} \qquad \text{(non-coherent fading.)}$$

也就是说，我们看到在衰落条件下，收敛到香农极限的速度要慢得多。图21.1通过绘制衰落信道和非衰落信道的$E^*(k,\epsilon)$的评估值（上下界）以数值方式展示了这一效应。我们看到，对于衰落信道，需要编码的数据比特数k大约是非衰落AWGN信道的10^3倍。详见[463]。

21.4 连续时间AWGN信道的容量

我们现在简要讨论连续时间信道的话题。我们希望将信道定义为对波形$x(t), t \geq 0$作用，通过如下方式加入白高斯噪声：

$$Y(t) = X(t) + N(t)\,,$$

其中$N(t)$是一个具有协方差函数的（广义）高斯过程

$$\mathbb{E}[N(t)N(s)] = \frac{N_0}{2}\delta(t-s)\,,$$

并且δ是狄拉克δ-函数。以这种方式定义信道需要仔细理解$N(t)$(的本质，特别是，它不是一个通常的随机过程，因为它在任意点$N(t) = \infty$)处的值，但工程师们更喜欢这样。数学家们更倾向于定义连续时间

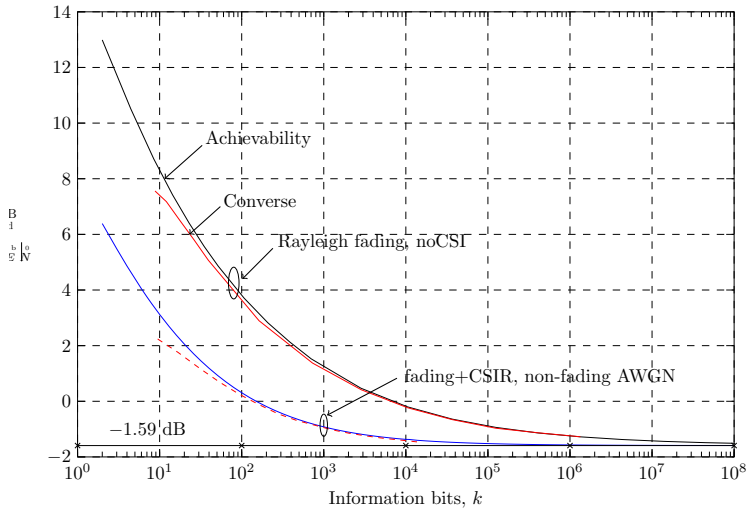


图21.1比较了在不同信道模型下发送一个k比特数据包所需的每比特能量（曲线表示未知最优值$\frac{E^*(k,\epsilon)}{k}$的上下界）。作为对比：要达到$-1.5$ dB，当信道是非衰落AWGN或衰落AWGN且在接收端完全已知H_j时，必须对超过$6\cdot 10^4$个数据比特进行编码。对于衰落AWGN且没有H_j (无CSI)知识的情况，要达到相同的-1.5 dB，必须至少对$7\cdot 10^7$个数据比特进行编码。图表使用[397]生成。

通过引入标准维纳过程（布朗运动）W_t并设置

$$Y_{int}(t) = \int_0^t X(\tau)d\tau + \sqrt{\frac{N_0}{2}}W_t\,,$$

其中 W_t 是均值为零的高斯过程，其协方差函数为

$$\mathbb{E}[W_s W_t] = \min(s,t)\,.$$

用 $L_2([0,T])$ 表示 $[0,T]$ 上所有平方可积函数的空间。设 $M^*(T,\epsilon,P)$ 为通过该信道可发送的最大消息数，使得给定一个编码器 $f\colon [M]\to L_2[0,T]$，对于每个 $m\in[M]$，波形 $x(t)\triangleq f(m)$

1 仅在 $[0,T]$ 上非零；2 输入能量约束为 $\int_{t=0}^{T} x^2(t)\le TP$；

以及解码错误概率 $P[\hat{W}\neq W]\le\epsilon$。这是先前定义的对数 M^* 函数到连续时间设置的自然扩展。

我们接下来证明该信道的容量结果。

定理 21.5 *The maximal reliable rate of communication across the continuous-time AWGN channel is* $\frac{P}{N_0}$ 对数 *e (per unit of time). More formally, we have*

$$\lim_{\epsilon\to 0}\liminf_{T\to\infty}\frac{1}{T}\log M^*(T,\epsilon,P) = \frac{P}{N_0}\log e \tag{21.12}$$

Proof. 注意，空间 $L_2[0,T]$ 具有可数基（例如正弦波）。因此，通过将输入和输出波形在该基上展开，我们得到等价的信道模型:

$$\tilde{Y}_j = \tilde{X}_j + \tilde{Z}_j\,, \qquad \tilde{Z}_j \sim \mathcal{N}\left(0, \frac{N_0}{2}\right),$$

以及能量约束（取决于持续时间 T）：

$$\sum_{j=1}^{\infty} \tilde{X}_j^2 \le PT\,.$$

但随后问题就等价于（离散时间）AWGN信道的每比特能量问题（见定理21.2），因此

$$\log_2 M^*(T,\epsilon,P) = k \iff E^*(k,\epsilon) = PT\,.$$

因此，

$$\lim_{\epsilon\to 0}\liminf_{n\to\infty}\frac{1}{T}\log_2 M^*(T,\epsilon,P) = \frac{P}{\lim_{\epsilon\to 0}\limsup_{k\to\infty}\frac{E^*(k,\epsilon)}{k}} = \frac{P}{N_0}\log_2 e\,,$$

其中最后一步由定理21.2得出。 □

21.5* 连续时间带限AWGN信道的容量

一位工程师看到之前定理会立刻指出纠错码定义中的一个问题。即，我们允许波形 $x(t)$ 具有有限时长和有限功率，但未限制其频率内容。实际上，波形还要求占据一定的有限频带 B 赫兹。在同时受功率 p 和带宽 B 约束的情况下，AWGN 信道的容量是多少?

遗憾的是，严谨地回答这个问题需要对泛函分析和长球面函数进行冗长而微妙的探讨。因此，我们仅概述主要结果，而不将其作为严谨的定理陈述。对于完整的论述，请参阅Ihara的专著[224]。

让我们再次定义$M^*_{CT}(T,\epsilon,P,B)$为在时间T、功率P以及每个波形除这两个约束外还具有完全包含在$[f_c-B/2, f_c+B/2]$中的傅里叶频谱的条件下，能够以错误概率ϵ发送的最大波形数，其中f_c是某个“载波”频率。[1]

我们声称

$$C_B(P) \triangleq \lim_{\epsilon\to 0}\liminf_{n\to\infty}\frac{1}{T}\log M^*_{CT}(T,\epsilon,P,B) = B\log(1+\frac{P}{N_0 B})\,, \tag{21.13}$$

[1] Here we already encounter a major issue: the waveform $x(t)$ supported on a finite interval $(0,T]$ cannot have spectrum supported on a compact. The requirements of finite duration and finite spectrum are only satisfied by the zero waveform. Rigorously, one should relax the bandwidth constraint to requiring that the signal have a vanishing out-of-band energy as $T\to\infty$. As we said, rigorous treatment of this issue lead to the theory of prolate spheroidal functions [391].

换句话说，该信道的容量为 $B\log(1+\frac{P}{N_0B})$。为了理解证明的思路，我们首先需要回顾调制的概念。任何需要在 $[f_c-B/2, f_c+B/2]$ 频带内存在的信号 $X(t)$ 都可以通过从一个频率成分位于 $[-B/2, B/2]$ 内的 *complex* 值信号 $X_B(t)$ 开始，并通过调制将其映射到 $X(t)$ 来获得：

$$X(t) = Re(X_B(t)\sqrt{2}e^{j\omega_c t}),$$

其中 $\omega_c = 2\pi f_c$。在接收到信号与白噪声 $N(t)$ 之和 $Y(t) = X(t) + N(t)$ 后，我们可以通过计算来解调 Y

$$Y_B(t) = \sqrt{2}\mathrm{LPF}(Y(t)e^{j\omega_c t}),,$$

其中LPF是一个低通滤波器，去除所有超过$[-B/2, B/2]$的频率。重要的是，从$Y(t)$转换到$Y_B(t)$不会丢失信息。

总体而言，我们有以下输入-输出关系：

$$Y_B(t) = X_B(t) + \widetilde{N}(t),$$

其中所有过程均为 $\mathbb{C}$ 值，且 $\widetilde{N}(t)$ 是复高斯白噪声，并且

$$\mathbb{E}[\widetilde{N}(t)\widetilde{N}(s)^*] = N_0\delta(t-s).$$

(注意，解调后噪声的功率谱密度为$N_0/2$，其中实部为$N_0/4$，虚部为$N_0/4$，而经过$\sqrt{2}$放大器后，噪声的谱密度在实部和虚部均恢复为$N_0/2$。)

接下来，我们进行奈奎斯特采样，将连续时间转换为离散时间。具体来说，输入波形$X_B(t)$将由其在一系列等间隔时间点上的值来表示，这些时间点之间的间隔为$\frac{1}{B}$。对$Y_B(t)$也进行类似的表示。再次众所周知，这两个操作既不会限制输入波形的空间（因为每个带限信号都可以通过其在奈奎斯特速率下的样本唯一表示），也不会导致$Y_B(t)$ (中信息内容的损失——同样，奈奎斯特样本完全代表信号Y_B)。从数学上讲，我们所做的是

$$X_B(t) = \sum_{i=-\infty}^{\infty} X_i \mathrm{sinc}_B(t - \frac{i}{B})$$
$$Y_i = \int_{t=-\infty}^{\infty} Y_B(t)\mathrm{sinc}_B(t-\frac{i}{B})dt,$$

其中 $\mathrm{sinc}_B(x) = \frac{\sin(Bx)}{x}$ 和 $X_i = X_B(i/B)$。对 X_B 和 Y_B 进行奈奎斯特采样后，我们得到以下等效的输入-输出关系：

$$Y_i = X_i + Z_i, \qquad Z_i \sim \mathcal{N}_c(0, N_0) \tag{21.14}$$

其中噪声 $Z_i = \int_{t=-\infty}^{\infty} \widetilde{N}(t)\mathrm{sinc}_B(t-\frac{i}{B})dt$。最后，鉴于 $X_B(t)$ 仅在 $t \in (0,T]$ 时非零，我们看到 $\mathbb{C}$-AWGN 信道（21.14) 仅允许用于 $i = 1, \ldots, TB$。这一事实在通信理论中被称为“带宽 B 和持续时间 T 信号具有 BT 复自由度”。

让我们总结一下目前所获得的结果：

- 对等效信道模型进行采样后，得到的是离散时间$\mathbb{C}$-AWGN模型。
- 给定时间 T 和带宽 B，离散时间等效信道具有块长度 $n = BT$。
- 离散时间模型中的功率约束对应于:

$$\sum_{i=1}^{BT} |X_i|^2 = \|X(t)\|_2^2 \le PT,$$

因此，有效离散时间功率约束变为 $P_d = \frac{P}{B}$。

因此，我们确立了以下事实:

$$\frac{1}{T}\log M^*_{CT}(T,\epsilon,P,B) = \frac{1}{T}\log M^*_{\mathbb{C}-\mathrm{AWGN}}(BT,\epsilon,P_d),$$

其中 $M^*_{\mathbb{C}-\mathrm{AWGN}}$ 表示定理20.11中 $\mathbb{C}$-AWGN 信道的基本极限。因此，取 $T\to\infty$ 我们得到(21.13)。

另请注意　在大带宽极限B下，容量公式（21.13　) 产生

$$C_{B=\infty}(P) = \lim_{B\to\infty} B\log(1+\frac{P}{N_0B}) = \frac{P}{N_0}\log e,$$

与 (21.12) 一致。

22 Strong converse. Channel dispersion. Error exponents. Finite blocklength.

在前几章中，我们的主要研究对象是块长度-{v*}编码的基本极限:

$$M^*(n,\epsilon) = \max\{M : \exists(n,M,\epsilon)\text{-code}\}$$

等价地，我们可以根据给定{v*}下的最小错误概率来定义它:

$$\epsilon^*(n,M) = \inf\{\epsilon : \exists(n,M,\epsilon)\text{-code}\}$$

到目前为止，我们了解到对于平稳无记忆信道，我们有

$$\lim_{\epsilon\to 0}\liminf_{n\to\infty}\frac{1}{n}\log M^*(n,\epsilon) = C\,,$$

或者，等价地，{v*}

$$\limsup_{n\to\infty}\epsilon^*(n,\exp\{nR\}) = \begin{cases}0, & R<C\\ >0, & R>C\,.\end{cases}$$

这些结果由香农在75年前证明。在随后的75年中发生的事情是，我们获得了关于M^*和ϵ^*更为详尽的信息。例如，强逆定理表明，在先前的极限中，>0可以被替换为1。误差指数显示，$\epsilon^*(n,\exp\{nR\})$趋向于零或一的过程是指数速度的（部分指数已知）。信道色散将进一步细化渐近描述为

$$\log M^*(n,\epsilon) = nC - \sqrt{nV}Q^{-1}(\epsilon) + O(\log n)\,.$$

最后，有限块长度信息论致力于在有限n下证明$\log M^*(n,\epsilon)$的最紧可能*computa- tional*界，这使得能够在考虑延迟n的情况下评估实际代码的性能。本章对这些结果进行了综述。

22.1 强逆定理

我们首先陈述主要定理。

定理 22.1 *For any stationary memoryless channel with either $|\mathcal{A}|<\infty$ or $|\mathcal{B}|<\infty$ we have $C_\epsilon = C$ for $0<\epsilon<1$. Equivalently, for every $0<\epsilon<1$ we have*

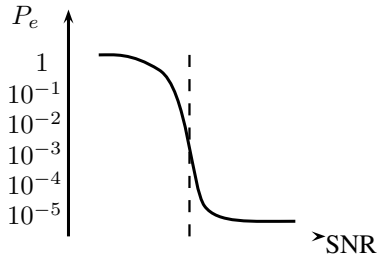
$$\log M^*(n,\epsilon) = nC + o(n)\,,\qquad n\to\infty\,.$$

之前在定理19.7中，我们展示了{v*}。现在我们要断言对于每一个ϵ，等号成立。我们之前基于Fano不等式的逆向论证（定理17.3）表明，只有在使用速率$R < C$时，通信才可能具有任意小的错误概率。强逆定理则表明，当以高于容量$R > C$的任何速率进行通信时，错误概率实际上会趋近于1。（Arimoto更详细的结果刻画了其以n指数速度趋近于1的过程，并给出了指数的精确表达式。）换句话说，

$$\epsilon^*(n, \exp(nR)) \to \begin{cases} 0 & R < C \\ 1 & R > C \end{cases} \tag{22.1}$$

其中 $\epsilon^*(n, M)$ 是 (19.5) 中定义的 $M^*(n, \epsilon)$ 的逆。

在实践中，工程师们对这一效应的观察方式有所不同。他们并不改变编码速率，而是固定一种编码，然后让信道参数（对于AWGN信道是SNR，对于BSC_δ是δ）变化。这通常导致错误概率出现*waterfall plot*：



换句话说，在某个临界信噪比以下，错误概率迅速趋近于1，因此接收机无法解码出任何有意义的信息。在临界信噪比以上，错误概率迅速趋近于0（除非存在称为*error floor*的效应，在这种情况下，错误概率会下降至该底限值，并且无论信噪比进一步增加多少，都保持在该值）。因此，长块长码具有类似于(22.1)的阈值式错误概率行为。除了用信噪比代替速率外，瀑布图和(22.1)之间还有另一个重要区别。前者仅适用于单个（也许相当次优的）码，而后者是关于每个(n, R)对的最佳可能码的陈述。

Proof. 我们将改进定理17.3证明中使用的方法。取一个(n, M, ϵ)码，并考虑通常的概率空间

$$W \to X^n \to Y^n \to \hat{W},$$

其中 $W \sim \mathrm{Unif}([M])$。注意，$P_{X^n}$ 是由编码器在信道输入端诱导出的经验分布。我们将以此方式在 $(W, X^n, Y^n, \hat{W})$ 上诱导出的联合测度记为 $\mathbb{P}$。我们的目标是将这个概率空间替换为另一个概率空间，其中真实信道 $P_{Y^n|X^n} = P_{Y|X}^{\otimes n}$ 被替换为一个 *auxiliary* 信道（在本例中它是一个“虚拟”信道）：

$$Q_{Y^n|X^n} = (Q_Y)^{\otimes n}.$$

我们将把这个新信道在 $(W, X^n, Y^n, \hat{W})$ 上诱导的测度记为 $\mathbb{Q}$。注意，对于通信目的而言，$Q_{Y^n|X^n}$ 是一个无用的信道，因为它忽略输入，并根据 $Y_i \overset{\text{i.i.d.}}{\sim} Q_Y$ 随机选择输出空间中的一个成员，因此 X^n 和 Y^n 是独立的（在 $\mathbb{Q}$ 下）。因此，对于每个信道下的成功概率，我们有

$$\mathbb{Q}[\hat{W} = W] = \frac{1}{M}$$
$$\mathbb{P}[\hat{W} = W] \geq 1 - \epsilon$$

因此，随机变量 $1\left\{\hat{W} = W\right\}$ 在 $\mathbb{P}$ 下很可能为 1，而在 $\mathbb{Q}$ 下很可能为 0。因此，它看起来是区分两个分布 $P_{W,X^n,Y^n,\hat{W}}$ 和 $Q_{W,X^n,Y^n,\hat{W}}$ 的二元假设检验统计量的一个相当好的选择。由于没有假设检验能超过最优（Neyman-Pearson）检验，我们得到上界

$$\beta_{1-\epsilon}(P_{W,X^n,Y^n,\hat{W}}, Q_{W,X^n,Y^n,\hat{W}}) \leq \frac{1}{M} \tag{22.2}$$

(回想一下(14.3))中对β的定义。似然比是这个假设检验的充分统计量，所以我们来计算它：

$$\frac{P_{W,X^n,Y^n,\hat{W}}}{Q_{W,X^n,Y^n,\hat{W}}} = \frac{P_W P_{X^n|W} P_{Y^n|X^n} P_{\hat{W}|Y^n}}{P_W P_{X^n|W} (Q_Y)^{\otimes n} P_{\hat{W}|Y^n}} = \frac{P_{W|X^n} P_{X^n,Y^n} P_{\hat{W}|Y^n}}{P_{W|X^n} P_{X^n} (Q_Y)^{\otimes n} P_{\hat{W}|Y^n}} = \frac{P_{X^n,Y^n}}{P_{X^n}(Q_Y)^{\otimes n}}$$

因此，上述不等式变为

$$\beta_{1-\epsilon}(P_{X^n,Y^n}, P_{X^n}(Q_Y)^{\otimes n}) \leq \frac{1}{M} \tag{22.3}$$

计算该界的左侧（LHS）似乎是不可能的，因为分布P_{X^n}依赖于未知的代码。然而，事实证明，明智地选择Q_Y将使了解P_{X^n}变得不必要。在给出正式论证之前，让我们考虑BSC_δ信道的一个特殊情况。它将表明，对于对称信道，我们可以选择Q_Y为实现容量的输出分布（回想一下，根据推论5.5，它是唯一的）。为了稍后处理一般情况，我们将（本质上）将信道分解为对称子信道（对应于输入的“组合”）。

特殊情况：BSC_δ。因此，我们取 $P_{Y^n|X^n} = \mathsf{BSC}_\delta^{\otimes n}$，而对于 Q_Y，我们将采用达到容量的输出分布，即 $Q_Y = \text{Ber}(1/2)$。

$$P_{Y^n|X^n}(y^n|x^n) = P_Z^n(y^n - x^n), \quad Z^n \sim \text{Ber}(\delta)^n$$
$$(Q_Y)^{\otimes n}(y^n) = 2^{-n}$$

根据内曼-皮尔逊引理，最优假设检验的形式为

$$\beta_\alpha(\underbrace{P_{X^nY^n}}_{\mathbb{P}}, \underbrace{P_{X^n}(Q_Y)^{\otimes n}}_{\mathbb{Q}}) = \mathbb{Q}\left[\log \frac{P_{X^nY^n}}{P_{X^n}(Q_Y)^{\otimes n}} \geq \gamma\right] \quad \text{where} \quad \alpha = \mathbb{P}\left[\log \frac{P_{X^nY^n}}{P_{X^n}(Q_Y)^{\otimes n}} \geq \gamma\right]$$

对于BSC，这变为

$$\log \frac{P_{X^nY^n}}{P_{X^n}(P_Y^*)^n} = \log \frac{P_{Z^n}(y^n - x^n)}{2^{-n}}\,.$$

注意，未知的 P_{X^n} 的影响完全消失了，因此我们可以计算 β_α:

$$\beta_\alpha(P_{X^nY^n}, P_{X^n}(Q_Y)^{\otimes n}) = \beta_\alpha(\mathrm{Ber}(\delta)^{\otimes n}, \mathrm{Ber}(\frac{1}{2})^{\otimes n}) \tag{22.4}$$

$$= \exp\{-nD(\mathrm{Ber}(\delta)\|\mathrm{Ber}(\frac{1}{2})) + o(n)\} \quad \text{(by Stein's Lemma: Theorem 14.14)}$$

将其与我们的主要界限（22.3）结合起来，我们可以看到，对于BSC的任何（n, M, ϵ）编码都满足

$$\log M \le nD(\mathrm{Ber}(\delta)\|\mathrm{Ber}(\frac{1}{2})) + o(n) = nC + o(n)\,.$$

显然，这意味着BSC的强逆定理。（对于略有不同但等价的证明，参见练习IV.32，对于AWGN信道，参见练习IV.33）。

对于一般信道，让我们用P_Y^*表示达到容量的输出分布。回顾推论5.5，它是唯一的，并且根据(5.1)，对于每个$x \in \mathcal{A}$，我们有:

$$D(P_{Y|X=x}\|P_Y^*) \le C\,. \tag{22.5}$$

这个性质将非常有用。接下来我们分别考虑两种情况:

1 如果我们取 $|\mathcal{B}| < \infty$ 并注意到由 (19.31) 我们有

$$\sum_y P_{Y|X}(y|x_0)\log^2 P_{Y|X}(y|x_0) \le \log^2|\mathcal{B}| \qquad \forall x_0 \in \mathcal{A}$$

并且由于 $\min_y P_Y^*(y) > 0$（不失一般性），我们得出结论，对于某个常数 $K > 0$ 以及所有 $x_0 \in \mathcal{A}$，我们有

$$\mathrm{Var}\left[\log\frac{P_{Y|X}(Y|X=x_0)}{Q_Y(Y)}|X=x_0\right] \le K < \infty\,.$$

因此，如果我们令

$$S_n = \sum_{i=1}^n \log\frac{P_{Y|X}(Y_i|X_i)}{P_Y^*(Y_i)}\,,$$

然后我们有

$$\mathbb{E}[S_n|X^n] \le nC, \qquad \mathrm{Var}[S_n|X^n] \le Kn\,. \tag{22.6}$$

他 由切比雪夫不等式（以X^n为条件应用），我们有

$$\mathbb{P}[S_n > nC + \lambda\sqrt{Kn}] \le \mathbb{P}[S_n > \mathbb{E}[S_n|X^n] + \lambda\sqrt{Kn}] \le \frac{1}{\lambda^2}\,. \tag{22.7}$$

2 如果 $|\mathcal{A}| < \infty$，那么首先我们回顾，不失一般性，编码器可以取为确定性的。然后对于每个码字 $c \in \mathcal{A}^n$，我们将其 *composition* (也称为 *type*) 简单地定义为其经验分布

$$\hat{P}_c(x) \triangleq \frac{1}{n}\sum_{j=1}^n 1\{c_j = x\}\,.$$

通过简单计数[1]可以清楚地看出，从任何(n, M, ϵ)码中，都可以选择一个(n, M', ϵ)子码，使得 a) 所有码字具有相同的组成P_0；并且 b) $M' > \frac{M}{(n+1)^{|\mathcal{A}|-1}}$。注意，$\log M = \log M' + O(\log n)$，因此我们可以用$M'$替换$M$，并将重点放在所选子码的分析上。然后我们设定$Q_Y = P_{Y|X} \circ P_0$。从现在起，我们还假设对于所有$x \in \mathcal{A}$ (都有$P_0(x) > 0$，否则只需减小$\mathcal{A}$)。令$i(x; y)$表示相对于$P_0 P_{Y|X}$的信息密度。如果$X \sim P_0$那么$I(X; Y) = D(P_{Y|X}\|Q_Y|P_0) \le \log |\mathcal{A}| < \infty$，我们得出结论：对于每个$x$都有$P_{Y|X=x} \ll Q_Y$，因此

$$i(x; y) = \log \frac{dP_{Y|X=x}}{dQ_Y}(y) .$$

从(19.28)我们有

$$\operatorname{Var}[i(X; Y)|X] \le \operatorname{Var}[i(X; Y)] \le K < \infty$$

此外，我们还有

$$\mathbb{E}[i(X; Y)|X] = D(P_{Y|X}\|Q_Y|P_0) = I(X; Y) \le C \qquad X \sim P_0 .$$

因此，如果我们定义

$$S_n = \sum_{i=1}^{n} \log \frac{dP_{Y|X=X_i}(Y_i|X_i)}{dQ_Y}(Y_i) = \sum_{i=1}^{n} i(X_i; Y_i) ,$$

我们再次首先得到估计值(22.6)，然后是(22.7)。

为了继续(22.3)的推导，我们应用来自(14.9)的β的下界：

$$\gamma\beta_{1-\epsilon}(P_{X^n,Y^n}, P_{X^n}(Q_Y)^{\otimes n}) \ge 1 - \epsilon - \mathbb{P}\left[S_n > \log\gamma\right] ,$$

其中 {v*} 是任意的。我们设定 $\log\gamma = nC + \lambda\sqrt{Kn}$ 和 $\lambda^2 = \frac{2}{1-\epsilon}$ 以得到（通过 (22.7)）：

$$\gamma\beta_{1-\epsilon}(P_{X^n,Y^n}, P_{X^n}(Q_Y)^{\otimes n}) \ge \frac{1-\epsilon}{2} ,$$

这进而意味着

$$\log\beta_{1-\epsilon}(P_{X^nY^n}, P_{X^n}(Q_Y)^n) \ge -nC + O(\sqrt{n}) .$$

因此，由(22.3)我们得出

$$\log M \le nC + O(\sqrt{n}) ,$$

暗示强逆命题。 □

我们从该证明中注意到几点经验。首先，我们基本上遵循了弱逆定理证明中的相同方法，区别在于我们没有引用散度的数据处理不等式，而是显式分析了假设检验问题。其次，信息密度方差的界很重要。因此，尽管AWGN信道被以下假设排除：

[1] This kind of reduction from a general code to a constant-composition subcode is the essence of the method of types [115].

定理，其强逆定理同样成立（见练习 IV.33）。第三，这种证明方法也被称为“球填充”，如果稍微不同地处理 BSC 的例子，原因就会变得清晰（见练习 IV.32）。

22.2 无强逆定理的平稳无记忆信道

在上述证明中，我们基本上只利用了独立随机变量之和集中在其期望附近这一事实（我们使用了二阶矩来展示这一点，但在二阶矩不存在时，也可以更一般地完成）。因此，人们可能会问，强逆定理是否应该对*all*平稳无记忆信道成立（仅在定理22.1中对那些具有有限输入或输出空间的信道进行了证明）。在本节中，我们构造一个反例。

令输出字母表为 $\mathcal{B} = [0,1]$。输入 $\mathcal{A}$ 将是可数无限的。将其定义为

$$\mathcal{A} = \{(j,m) : j,m \in \mathbb{Z}_+, 0 \le j \le m\}\,.$$

单字母信道 $P_{Y|X}$ 通过概率密度函数定义为

$$p_{Y|X}(y|(j,m)) = \begin{cases} a_m, & \frac{j}{m} \le y \le \frac{j+1}{m}, , \\ b_m, & \text{otherwise}\,, \end{cases}$$

其中选择 a_m, b_m 以满足

$$\frac{1}{m}a_m + (1-\frac{1}{m})b_m = 1 \tag{22.8}$$

$$\frac{1}{m}a_m \log a_m + (1-\frac{1}{m})b_m \log b_m = C\,, \tag{22.9}$$

其中 $C > 0$ 是一个任意固定常数。请注意，对于大的 {v*} w我们有

$$a_m = \frac{mC}{\log m}(1 + O(\frac{1}{\log m}))\,, \tag{22.10}$$

$$b_m = 1 - \frac{C}{\log m} + O(\frac{1}{\log^2 m}) \tag{22.11}$$

很容易看出，$P_Y^* = \text{Unif}(0,1)$ 是达到容量的输出分布，并且

$$\sup_{P_X} I(X;Y) = C\,.$$

因此由定理19.9，相应的平稳无记忆信道的容量为C。接下来我们展示尽管如此，ϵ-容量可以严格大于C。

确实，固定块长度 n，并考虑一个 *single letter* 分布 P_X，对所有原子 (j,m) 赋予相同权重，其中 $m = \exp\{2nC\}$。可以证明，在这种情况下，一个

单字母信息密度由下式给出

$$i(X;Y) = \begin{cases} \log a_m, & \text{w.p. } \frac{a_m}{m} \\ \log b_m, & \text{w.p. } 1-\frac{a_m}{m} \end{cases} = \begin{cases} 2nC + O(\log n), & \text{w.p. } \frac{a_m}{m} \\ O(\frac{1}{n}), & \text{w.p. } 1-\frac{a_m}{m} \end{cases} .$$

因此，对于块长度-{v*}密度，我们有

$$\frac{1}{n} i(X^n;Y^n) = \frac{1}{n}\sum_{i=1}^{n} i(X_i;Y_i) \overset{d}{=} O(\frac{1}{n}) + (2C + O(\frac{1}{n}\log n)) \cdot \mathrm{Bin}(n, \frac{a_m}{m}) \overset{\mathrm{d}}{\to} 2C \cdot \mathrm{Poisson}(1/2)\,,$$

其中我们利用了$\frac{a_m}{m} = (1+o(1))\frac{1}{2n}$这一事实，并运用了二项分布的泊松极限定理。因此，根据定理18.5，我们得到对于$\epsilon > e^{-1/2}$，存在(n, M, ϵ)-码，其

$$\log M \geq 2nC(1+o(1))\,.$$

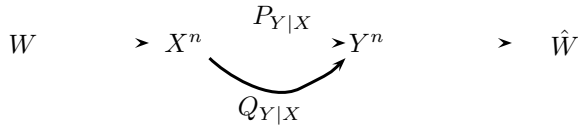
特别是，

$$C_\epsilon \geq 2C \quad \forall \epsilon > e^{-1/2}$$

22.3 元逆

我们已经看到多种推导基本极限（如 $\log M^*(n,\epsilon)$）上界（不可能性或逆定理界）的方法。在定理 17.3 中，我们使用了数据处理不等式和 Fano 不等式。在定理 22.1 的证明中，我们将问题化归为假设检验问题。多年来还发展出了许多其他的逆定理界。事实证明，存在一种非常通用的方法，能够涵盖所有这些界。由于其通用性，它有时被称为“元逆定理”。

为了描述它，让我们固定一个马尔可夫核 $P_{Y|X}$ (，通常，它将是 n 字母信道 $P_{Y^n|X^n}$，但本着“一次性”方法的精神，我们避免引入块长度)。我们还给定了一个特定的（M,ϵ）码，目标是展示 M 的上界可以用 $P_{Y|X}$ 和 ϵ 来表示。元逆的本质由下图描述：



这里的 $W \to X$ 和 $Y \to \hat{W}$ 分别代表我们固定(M,ϵ)码的编码器和解码器。上方的箭头 $X \to Y$ 对应于实际信道，我们正分析其基本极限。下方的箭头是一个 *auxiliary channel*，我们可以自由选择。

$P_{Y|X}$ 或 $Q_{Y|X}$ 与由代码) 诱导的 P_X (分布一起定义了两个分布：$P_{X,Y}$ 和 $Q_{X,Y}$。考虑由编码器和解码器对定义的一个映射 $(X,Y) \mapsto Z \triangleq 1\{W \neq \hat{W}\}$（如果解码器是随机的或 $W \to X$ 不是单射，我们改为考虑一个马尔可夫核 $P_{Z|X,Y}(1|x,y) = \mathbb{P}[Z=1|X=x,Y=y]$）。我们有

$$P_{X,Y}[Z=0] = 1-\epsilon, \qquad Q_{X,Y}[Z=0] = 1-\epsilon'\,,$$

其中 ϵ 和 ϵ' 分别是给定代码在 $P_{Y|X}$ 和 $Q_{Y|X}$ 下的平均错误概率。这意味着对于测试 $P_{X,Y}$ 与 $Q_{X,Y}$ 的二元 HT 问题，有以下关系：

$$\beta_{1-\epsilon}(P_{X,Y}, Q_{X,Y}) \le 1-\epsilon' .$$

元逆的高层思想是选择一个方便的$Q_{Y|X}$，从上方界定$1-\epsilon'$（即为$Q_{Y|X}$证明一个逆结果），然后使用Neyman-Pearson β-函数来*lift the Q-channel converse to P-channel*。

如何选择$Q_{Y|X}$是一门艺术。例如，在定理22.1情况2的证明中，我们使用了简化为恒定组成子码的技巧。这也可以通过取$Q_{Y^n|X^n=c} = (P_{Y|X}\circ \hat{P}_c)^{\otimes n}$来完成。由于最多有$(n+1)^{|\mathcal{A}|-1}$不同的输出分布，我们可以看到

$$1-\epsilon' \le \frac{(n+1)^{\|\mathcal{A}|-1}}{M},$$

而 β 的界定可以类似于定理 22.1 中情况 2 的证明来完成。对于具有 $|\mathcal{A}| = \infty$ 的信道，归约到恒组成码的技术不可用，但元逆定理仍然可以应用。例子包括并行 AWGN 信道色散 [333，定理 78] 的证明以及好码性质的研究 [340，定理 21]。

然而，使用元逆定理最常见的方式是将其应用于平凡信道 $Q_{Y|X} = Q_Y$。我们已经在第22.1节中看到了这一思路。实际上，通过这种选择，Q信道的逆定理证明变得平凡，因为我们总是有：$1-\epsilon' = \frac{1}{M}$。因此，我们得出结论，任何 (M,ϵ) 码都必须满足

$$\frac{1}{M} \ge \beta_{1-\epsilon}(P_{X,Y}, P_X Q_Y) . \tag{22.12}$$

或者，经过优化后我们得到

$$\frac{1}{M^*(\epsilon)} \ge \inf_{P_X}\sup_{Q_Y} \beta_{1-\epsilon}(P_{X,Y}, P_X Q_Y) .$$

这是称为*minimax meta-converse*的元逆定理的一个特例。它具有许多有趣的性质。首先，所讨论的极小极大问题存在一个鞍点，并且是凸-凹类型的[341]。因此，它可以被视为定理5.4中关于散度的容量鞍点结果的一个更强版本。

其次，由极小极大元逆给出的界与之前通过线性规划松弛（18.22）得到的界一致，正如[295]所发现的。要看出这种联系，不是将元逆写成给定 ϵ) 的上界 M (，而是将其视为给定 M) 的 $1-\epsilon$ (的上界。

我们已经看到，对于 $P_{Y|X}$ 存在一个 (M,ϵ)-码意味着存在一个（随机）映射 $(X,Y) \mapsto Z \in \{0,1\}$，记作 $P_{Z|X,Y}$，具有以下性质：

$$P_{X,Y}[Z=0] \ge 1-\epsilon, \quad \text{and} \quad P_X Q_Y[Z=0] \le \frac{1}{M} \forall Q_Y .$$

即 $P_{Z|X,Y}$ 是对任意 Q_Y 的简单原假设（X,Y）$\sim P_{X,Y}$ 与复合备择假设（X,Y）$\sim P_XQ_Y$ 的检验。换言之，每个（M,ϵ）代码必须满足

$$1-\epsilon \le \tilde{\alpha}(M;P_X)\,,$$

其中（为简单起见，我们假设 $\mathcal{X},\mathcal{Y}$ 是有限的）

$$\tilde{\alpha}(M;P_X) \triangleq \sup_{P_{Z|X,Y}} \{\sum_{x,y} P_{X,Y}(x,y)P_{Z|X,Y}(0|x,y) : \sum_{x,y} P_X(x)Q_Y(y)P_{Z|X,Y}(0|x,y) \le \frac{1}{M} \quad \forall Q_Y\}\,.$$

我们可以通过将其重写为以下形式来简化约束条件:

$$\sup_{Q_Y} \sum_{x,y} P_X(x)Q_Y(y)P_{Z|X,Y}(0|x,y) \le \frac{1}{M}\,,$$

并将其进一步简化为

$$\sum_x P_X(x)P_{Z|X,Y}(0|x,y) \le \frac{1}{M}\,, \qquad \forall y \in \mathcal{Y}\,.$$

现在让我们用$\pi_x \triangleq MP_X(x), x \in \mathcal{X}$替换$P_X$。显然，$\pi \in [0,1]^{\mathcal{X}}$。我们也将优化变量替换为$r_{x,y} \triangleq MP_{Z|X,Y}(0|x,y)P_X(x)$。经过这些符号更改，我们得到

$$\tilde{\alpha}(M;P_X) = \frac{1}{M}\sup\{\sum_{x,y} P_{Y|X}(y|x)r_{x,y} : 0 \le r_{x,y} \le \pi_x, \sum_x r_{x,y} \le 1\}\,.$$

显然，$\tilde{\alpha}(M;\ P_X) = S_{LP}(\pi)$ 定义于 (18.21)。对 P_X (的选择进行优化，或者等价地，在 $\sum_x \pi_x \le M$) 下针对 π 进行优化，我们得到

$$1-\epsilon \le \frac{1}{M}S_{LP}(\pi) \le \frac{1}{M}\sup\{S_{LP}(\pi) : \sum_x \pi_x \le M\} = \frac{S^*_{LP}(M)}{M}\,.$$

现在回忆一下，在(18.23)中我们展示了一个贪婪过程（本质上与我们在Feinstein界定理18.7中使用的过程相同）产生了一个成功概率为的码。

$$1-\epsilon \ge (1-\frac{1}{e})\frac{S^*_{LP}(M)}{M}\,.$$

这表明，在固定 ϵ 的情形下，基于极小极大元逆的界应当非常精确。当然，前提是我们能在应用它时选择最佳的 Q_Y。幸运的是，对于对称信道，最优的 Q_Y 可以相当容易地猜测得到，参见 [341] 了解更多。

22.4* 误差指数

我们之前已经研究过假设检验中的最优误差指数问题（第16章）。而信道编码中的相应主题则要困难得多，并且充满了未解决的问题。

我们通过试图理解强逆定理（22.1）中收敛速度来引出这个问题。如果我们回顾定理19.9的证明，即步骤（19.7），我们可以看到，通过应用大偏差定理15.9，我们可以证明对于某个 $\tilde{E}(R)$ 和任意 $R < C$，我们有

$$\epsilon^*(n, \exp\{nR\}) \le \exp\{-n\tilde{E}(R)\}\,.$$

对于每个R，$\tilde{E}(R)$的最佳值是什么？这或许是整个信道编码领域中最著名的未解之谜。让我们进一步详细探讨。

我们将处理两种情形 $R < C$ 和 $R > C$。信道的 *reliability function* $E(R)$ 定义如下：

$$E(R) = \begin{cases} \lim_{n\to\infty} -\frac{1}{n}\log \epsilon^*(n, \exp\{nR\}) & R < C \\ \lim_{n\to\infty} -\frac{1}{n}\log(1-\epsilon^*(n, \exp\{nR\})) & R > C\,. \end{cases}$$

如果极限不存在，我们将$E(R)$视为未定义。遗憾的是，没有普遍的论证表明这个极限存在。证明其存在的唯一方法是证明可达性界限。

$$\liminf_{n\to\infty} -\frac{1}{n}\log \epsilon^*(n, \exp\{nR\}) \ge E_{lower}(R)\,,$$

一个逆界

$$\limsup_{n\to\infty} -\frac{1}{n}\log \epsilon^*(n, \exp\{nR\}) \le E_{upper}(R)\,,$$

并且得出结论，只要$E_{lower} = E_{upper}$存在，极限就存在。通常滥用记号，将这样的一对界写作

$$E_{lower}(R) \le E(R) \le E_{upper}(R)\,,$$

即使如我们所说，除非两个边界匹配，否则$E(R)$并不为人所知存在。

从现在开始，我们将讨论限定在DMC的情形。一个重要的定义对象是Gallager的E_0函数，它正是Gallager界(18.15)的右侧部分。对于DMC，其表达式如下：

$$\begin{aligned} E_0(\rho, P_X) &= -\log \sum_{y\in\mathcal{B}} \left(\sum_{x\in\mathcal{A}} P_X(x) P_{Y|X}^{\frac{1}{1+\rho}}(y|x)\right)^{1+\rho} \\ E_0(\rho) &= \max_{P_X} E_0(\rho, P_X)\,, \qquad \rho \ge 0 \\ E_0(\rho) &= \min_{P_X} E_0(\rho, P_X)\,, \qquad \rho \le 0\,. \end{aligned}$$

该表达式是依据单字母信道 $P_{Y|X}$ 定义的。不难发现，对于 n 字母扩展的 E_0 函数，在 $P_X^{\otimes n}$ 下评估时，恰好等于 $nE_0(\rho, P_X)$，即其张量性质与互信息相似。[2] 基于这一观察，我们可以应用 Gallager 的随机编码

[2] There is one more very pleasant analogy with mutual information: the optimization problems in the definition of $E_0(\rho)$ also tensorize. That is, the optimal distribution for the n-letter channel is just $P_X^{\otimes n}$, where P_X is optimal for a single-letter one.

用 $P_X^{\otimes n}$ 界定（定理 18.9）以得到

$$\epsilon^*(n, \exp\{nR\}) \le \exp\{n(\rho R - E_0(\rho, P_X))\} \qquad \forall P_X, \rho \in [0,1]\,. \tag{22.13}$$

通过优化{v*}的选择，我们得到了关于可靠性函数的第一个估计

$$E(R) \le E_r(R) \triangleq \sup_{\rho\in[0,1]} E_0(\rho) - \rho R\,.$$

一项分析，例如[177, 第5.6节]，表明函数$E_r(R)$在$0 \le R < C$上是凸的、递减且严格正的。因此，Gallager的界为容量以下的所有速率范围提供了可靠性函数的非平凡估计。在速率$R \to C$时，$\rho \to 0$的最优选择。随着R进一步远离容量，最优ρ在某一速率$R = R_{cr}$处达到1，该速率称为临界速率，因此对于$R < R_{cr}$，我们有$E_r(R) = E_0(1) - R$表现为线性。$E_r(R)$界在图22.1中由标记为“随机码集合”的曲线展示。

在达到上界时，将 Q_Y 取为 (22.12) 中的独立同分布乘积分布并进行优化，得到被称为球填充界的界 [381]:

$$E(R) \le E_{sp}(R) \triangleq \sup_{\rho\ge 0} E_0(\rho) - \rho R\,. \tag{22.14}$$

比较 E_{sp} 和 E_r 的定义，我们可以看到对于 $R_{cr} < R < C$，我们有

$$E_{sp}(R) = E(R) = E_r(R)$$

从而为高码率建立了可靠性函数值。然而，对于$R < R_{cr}$我们有$E_{sp}(R) > E_r(R)$，因此$E(R)$仍然未知。$E_{sp}(R)$界在图22.1中由标有“球填充（体积）”的曲线示出。

上下界都有经典的改进。随机编码界可以通过称为 *expurgation* 的技术改进，表明

$$E(R) \ge E_{ex}(R)\,,$$

以及 $E_{ex}(R) > E_r(R)$ 对于速率 $R < R_x$，其中 $R_x \le R_{cr}$ 是第二临界速率；见练习 IV.31。$E_{ex}(R)$ 界在图 22.1 中用标记为“典型随机线性码（又称 expurgation）”的曲线展示。（关于命名的解释见下文。）

球填充界在低速率下也可以通过分析一个组合填充问题来改进，方法是证明任何码必定有一对接近的码字（就诱导输出分布之间的 Hellinger 距离而言），并由此得出结论：混淆这两个码字会导致错误概率的下界（通过 (16.3)）。这类界被称为基于“最小距离”的界，图 22.1 中展示了其中几个，其中最强的一个标记为“MRRW + mindist”，对应于目前已知的最佳最小距离上界，由 [299] 给出。（这个界也被称为线性规划界或 JPL 界，60 年来一直没有改进，而改进它是组合数学中一个长期未解决的问题。）

直线界 [177, 定理 5.8.2] 允许在任何最小距离界与 $E_{sp}(R)$ 之间进行插值。遗憾的是，这些（经典）改进严格地将 $E(R)$ 限制在

只有一个额外的速率点 $R = 0$:

$$E(0+) = E_{ex}(0)\,.$$

自1967年Shannon、Gallager和Berlekamp的基础性工作以来，（对于一般的DMC）这一状况仍未改变。据我们所知，普遍认为$E_{ex}(R)$实际上就是$E(R)$在所有速率下的真实值。正如我们上面提到的，这也许是经典信息论中最著名的未解决问题之一。

我们在图22.1中针对BSC_δ的情况展示了可靠度函数上的这些界（直线界除外）。对于该信道，删余界有一个有趣的解释。为了解释它，让我们回顾第18.6节中讨论的不同随机码集。特别地，我们有香农集（如定理18.5中所用）和随机线性码（Elias或Gallager集，这里我们无需区分）。

对于任一集成，已知[178]中$E_r(R)$不仅是估计值，实际上是集成中代码的平均错误概率（在集成上平均）的指数的确切值。然而，对于任一集成，在低速率下，平均值由少数不良代码主导，而代码的典型（高概率）实现具有更好的错误指数。对于香农集成，这发生在$R < \frac{1}{2}R_x$，而对于线性集成，则发生在$R < R_x$。此外，典型的线性代码实际上其错误指数正好等于删减指数$E_{ex}(R)$，见[34]。

组合数学中有一个著名的猜想，指出码率为R的码的最佳可能最小成对汉明距离由Gilbert-Varshamov界给出（定理27.5）。如果这个猜想成立，那么它将意味着对于$R < R_x$，$E(R) = E_{ex}(R)$，参见例如[283]。

自1967年以来，误差指数方面最突出的进展是从[283]开始的一系列论文，这些论文提出了一种新的技术来从上方界定$E(R)$。Litsyn的想法是首先证明一个几何结果（即任何给定速率的码在给定距离上都有大量的码字对），然后利用de Caen不等式将其转换为错误概率的下界。所得出的界非常繁琐。因此，当Barg和MacGregor[35]能够证明新的上界$E(R)$在某些小的$\epsilon > 0$时与$E_r(R)$对于$R_{cr} - \epsilon < R < R_{cr}$相匹配时，这相当令人惊讶。这是自[381]以来首次扩展了可靠性函数的知识范围。他们惊人的结果（连同Gilbert-Varshamov猜想）强化了这样一种信念，即典型的线性码在整个$0 \le R \le C$范围内都能达到最优误差指数。

关于 $E(R)$ 对应于 $R > C$ 的情况要简单得多。我们有

$$E(R) = \sup_{\rho\in(-1,0)} E_0(\rho) - \rho R\,.$$

这里给出的下界（可达性）由Dueck [141]得出（另见[319]），而更难的（逆定理）部分则由Arimoto [25]完成。后来发现，Arimoto的逆定理界可以通过对弱逆定理（定理17.3）进行简单修改来导出：不是对KL散度应用数据处理，而是使用阶数为$\alpha = \frac{1}{1+\rho}$的Rényi散度；参见[338]

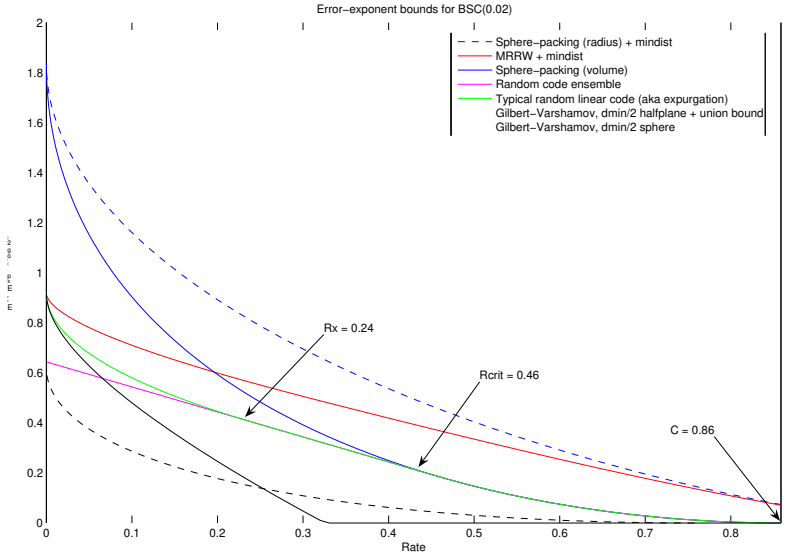


图22.1 BSC错误指数的界限对比。MRRW代表码的最小距离的上界[299]，而Gilbert-Varshamov则是一个下界（参见定理27.5）。

详见。这表明一个普遍猜想：将香农信息度量替换为Rényi信息度量，可将（弱）逆定理证明升级为强逆定理。

22.5 信道色散

历史上，最初纠错码的码率相当低R，远低于信道容量。正如我们在第22.4*节所看到的，在任何码率$R < C$下，最佳码的错误概率表现为

$$P_e = \exp\{-nE(R) + o(n)\}\,.$$

因此，在一段时间内，对$\log M^*(n,\epsilon)$和$\epsilon^*(n,M)$的非渐近特征问题等同于确定误差指数$E(R)$的精确值。然而，随着编码技术的进步和速率逐渐接近信道容量，问题转变为理解在固定ϵ和大n(的情况下$\log M^*(n,\epsilon)$的行为，进而涉及速率$R \to C$)。不久之后，[334]发现log M^*的渐近展开中的下一阶项对$\log M^*$的真实值给出了惊人的精确估计。自此以后，信道编码的工作集中于为有限n (确定$\log M^*(n,\epsilon)$的精确上下界——这是第22.6节的主题)，并精炼了关于渐近展开的经典结果，我们在此进行讨论。

我们已经看到，强逆定理（定理22.1）可以渐近展开的形式表述为：对于每个固定的 $\epsilon \in (0,1)$，

$$\log M^*(n,\epsilon) = nC + o(n), \qquad n \to \infty.$$

直观上，ϵ 的较小值应该会使收敛到容量更慢。这表明 $o(n)$ 项隐藏了对 ϵ 的某种有趣依赖。那是什么?

这一主题自20世纪60年代以来就得到了研究，参见[130, 402, 334, 333]，并由此产生了*channel dispersion.*的概念。我们首先给出该结果的严格表述，然后解释其实际用途。

定理 22.2 *Consider one of the following channels:*

1 DMC
2 DMC with cost constraint
3 AWGN
4 Parallel AWGN

Let (X^*, Y^*) *be the input-output of the channel under the capacity achieving input distribution, and* $i(x;y)$ *be the corresponding (single-letter) information density. The following expansion holds for a fixed* $0 < \epsilon < 1/2$ *and* $n \to \infty$

$$\log M^*(n,\epsilon) = nC - \sqrt{nV}Q^{-1}(\epsilon) + O(\log n) \tag{22.15}$$

where Q^{-1} *is the inverse of the complementary standard normal CDF, the channel capacity is* $C = I(X^*;Y^*) = \mathbb{E}[i(X^*;Y^*)]$*, and the channel dispersion*[3] *is* $V = \mathrm{Var}[i(X^*;Y^*)|X^*]$.

Proof. 这些结果的完整证明即便对于DMC来说也颇为技术性。[4]此处我们仅概述细节。

首先，在没有成本约束的情况下，可达性（$\log M^*$ 的下界）部分已由我们在定理19.11中完成，我们通过改进噪声信道编码定理的证明并使用CLT，证明了 $\log M^*(n,\epsilon) \geq nC - \sqrt{nV}Q^{-1}(\epsilon) + o(\sqrt{n})$。将CLT替换为其非渐近版本（Berry-Esseen不等式[165，定理2，第XVI.5章]）将 $o(\sqrt{n})$ 改进为 $O(\log n)$。在存在成本约束的情况下，人们倾向于尝试使用适当版本的可达性界，如定理20.7。然而，对于AWGN，这将需要使用球面上均匀的输入分布。由于该分布是非乘积的，信息密度不再是独立同分布之和，且CLT更难证明。相反，存在一个不同的可达性界，称为 κ-β 界[334，定理25]，它已成为具有连续输入空间的成本约束信道可达性证明的主力工具。

[3] There could be multiple capacity-achieving input distributions, in which case P_{X^*} should be chosen as the one that minimizes $\mathrm{Var}[i(X^*;Y^*)|X^*]$. See [334] for more details.

[4] Recently, subtle gaps in [402] and [334] in the treatment of DMCs with non-unique capacity-achieving input distributions were found and corrected in [81].

上界（逆定理）需要根据信道采用不同的特殊方法。然而，高层思路始终是应用(22.12)中的元逆界，并适当选择{v*}。最常见的情况是将{v*}取为信道容量达到输出分布的{v*}次幂。我们以BSC的特殊情况为例说明细节。在(22.4)中我们已经证明

$$\log M^*(n,\epsilon) \le -\log \beta_\alpha(\mathrm{Ber}(\delta)^{\otimes n}, \mathrm{Ber}(\frac{1}{2})^{\otimes n})\,. \tag{22.16}$$

另一方面，练习III.10表明

$$-\log \beta_{1-\epsilon}(\mathrm{Ber}(\delta)^{\otimes n}, \mathrm{Ber}(\frac{1}{2})^{\otimes n}) = nd(\delta\|\frac{1}{2}) + \sqrt{nv}Q^{-1}(\epsilon) + o(\sqrt{n})\,,$$

其中 {v*} 只是（单字母）对数似然比的方差:

$$v = \mathrm{Var}_{Z\sim\mathrm{Ber}(\delta)}\left[Z\log\frac{\delta}{\frac{1}{2}} + (1-Z)\log\frac{1-\delta}{\frac{1}{2}}\right] = \mathrm{Var}[Z\log\frac{\delta}{1-\delta}] = \delta(1-\delta)\log^2\frac{\delta}{1-\delta}\,.$$

仔细检查后，我们注意到 $v = V$ ——BSC 的信道色散，这完成了上界的证明:

$$\log M^*(n,\epsilon) \le nC - \sqrt{nV}Q^{-1}(\epsilon) + o(\sqrt{n})$$

通过应用Berry-Esseen不等式代替中心极限定理，改进了$o(\sqrt{n})$到$O(\log n)$，这与上界处理相似。关于这些证明的更多细节，可参阅[333]。 □

注22.1（零色散）我们注意到$V = 0$是完全可能的。例如，考虑某个阿贝尔群G上的加性噪声信道$Y = X + Z$，其中Z在G的某个子集上均匀分布，如习题IV.7中的信道。在零色散信道中，有一类*exotic*信道[334]，对于$\epsilon > 1/2$，其渐近展开形式为[333，定理51]:

$$\log M^*(n,\epsilon) = nC + \Theta_\epsilon(n^{\frac{1}{3}})\,.$$

这种特殊情况的存在正是我们将上述定理限制在$\epsilon < \frac{1}{2}$的原因。

注22.2 展开式(22.15)仅适用于特定频道（如定理所述）。例如，若$\mathrm{Var}[i(X^*;Y^*)] = \infty$，则定理未必成立，并且可能存在其他稳定的（非高斯）分布，使得n字母信息密度会收敛于此。此外，注意到在没有成本约束的情况下，我们有以下情况:

$$\mathrm{Var}[i(X^*;Y^*)|X^*] = \mathrm{Var}[i(X^*;Y^*)]$$

由于根据容量鞍点（推论5.7），$\mathbb{E}[i(X^*;Y^*)|X^* = x] = C$ 对于几乎所有的P_{X^*}有 x。

例如，对于到目前为止我们讨论过的常见通道，我们有以下色散公式:

$$\mathsf{BEC}_\delta:\quad V(\delta) = \delta\bar{\delta}\log^2 2$$

$$\begin{aligned}
\mathsf{BSC}_\delta: &\quad V(\delta) = \delta\bar{\delta}\log^2\frac{\bar{\delta}}{\delta}\\
\text{AWGN (real):} &\quad V_{\text{AWGN}}(P) = \frac{P(P+2)}{2(P+1)^2}\log^2 e\\
\text{AWGN (complex):} &\quad V(P) = \frac{P(P+2)}{(P+1)^2}\log^2 e\\
\text{BI-AWGN:} &\quad V(P) = \mathrm{Var}[\log(1+e^{-2P+2\sqrt{P}Z})]\,, \quad Z\sim\mathcal{N}(0,1)
\end{aligned}$$

其中对于 AWGN 和 BI-AWGN，P 是信噪比。我们还提醒，参见例 3.4，对于 BI-AWGN，我们有 $C(P) = \log 2 - \mathbb{E}[\log(1+e^{-2P+2\sqrt{P}Z})]$。对于并行 AWGN，参见第 20.4 节，我们有

$$\text{Parallel AWGN:}\qquad V(P,\{\sigma_j^2, j\in[L]\}) = \frac{\log^2 e}{2}\sum_{j=1}^{L}\left|1-\left(\frac{\sigma_j^2}{T}\right)^2\right|^+\,,$$

其中 T 是 *water-filling* 解中的最优阈值，即 $\sum_{j=1}^{L}|T-\sigma_j^2|^+ = P$。我们注意到，通过观察其等于 $\sum_{j=1}^{L} V_{\text{AWGN}}(\frac{P_j}{\sigma_j^2})$，可以猜出并行 AWGN 信道的表达式。使用 $P_j = |T-\sigma_j^2|^+$ —— 最优功率分配。

其他信道的信道色散又如何呢？具有记忆的离散信道在[335]中已取得一些有限的成功，其中色散以信息密度过程的傅里叶谱来表示。复合DMC（例IV.19）有一个更为精细的色散公式（其余项不是$O(\log n)$，而是$O(n^{1/4})$），参见[342]。对于非离散信道（除AWGN和泊松信道外），在逆定理部分的证明中会出现新的困难。例如，（相干）衰落信道的色散只有在额外限制输入码字具有有限峰值时才已知，参见[98，注1]。特别地，以下*Gaussian erasure channel*的色散尚不清楚：

$$Y_i = H_i(X_i + Z_i)\,,$$

其中我们有$\mathcal{N}(0,1)\sim Z_i \perp\!\!\!\perp H_i \sim \mathrm{Ber}(1/2)$以及通常的二次成本约束$\sum_{i=1}^{n} x_i^2 \le nP$。

多天线（MIMO）信道（20.10）也带来了有趣的新挑战。例如，对于相干信道，达到容量的输入分布是非唯一的[98]。准静态信道与衰落信道相似，但$H_1 = H_2 = \cdots$，即（20.10）中的信道增益矩阵不随时间变化。这种信道模型常用于对蜂窝网络进行建模。通过利用数量出乎意料的微分几何，文献[462]表明它们具有*zero-dispersion*，或者更具体地说：

$$\log M^*(n,\epsilon) = nC_\epsilon + O(\log n)\,,$$

其中，ϵ容量C_ϵ在这种情况下被称为中断容量（并且依赖于ϵ）。主要含义是，C_ϵ是这些实际相关信道的最终性能极限的良好预测指标（例如，比C对AWGN信道更好）。然而，在近似$\log M^*(n,\epsilon) \approx nC_\epsilon$时仍需谨慎。例如，在$H$的情况下

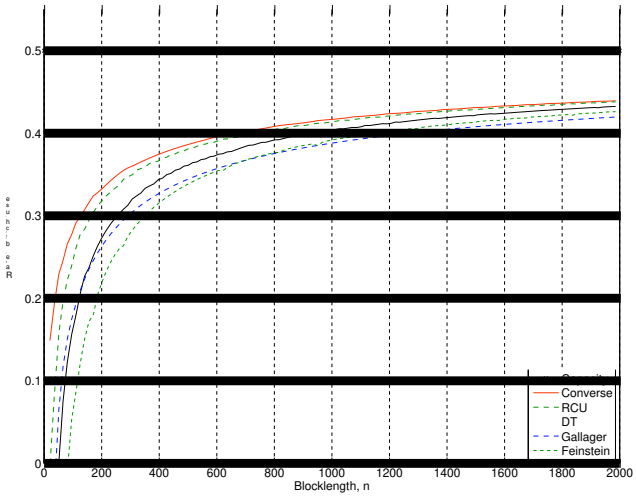


图22.2 比较BSC_δ信道（$\delta = 0.11, \epsilon = 10^{-3}$）上$\frac{1}{n}$对数$M^*(n,\epsilon)$的各种下界（可达性）。

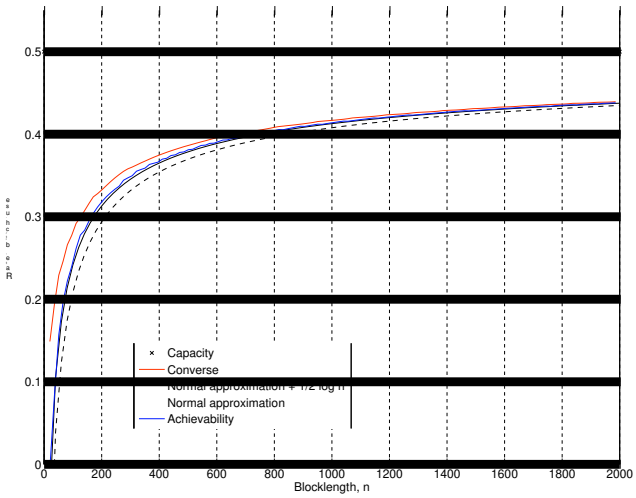


图22.3 比较正态近似与$\frac{1}{n}$通道中$M^*(n,\epsilon)$对数的最佳上下界（$\delta = 0.11, \epsilon = 10^{-3}$）。

当矩阵在发射端已知时，同一篇论文证明了，使 C_ϵ 最大化的标准注水功率分配（定理20.14）在有限 n 情况下相当次优。

22.6 有限块长度界限与正态近似

如前所述，通过穷举搜索直接计算 $M^*(n,\epsilon)$ 的复杂度是双指数的，因此在大多数情况下是不可行的。然而，我们迄今为止所建立的界限通常能够帮助我们将未知值夹逼得相当紧凑。不那么严格地说，我们也可以评估 *normal approximation*，这简单地表明在展开式（22.15）中忽略未知项：

$$\log M^*(n,\epsilon) \approx nC - \sqrt{nV}Q^{-1}(\epsilon)$$

(在(22.15)中，对数项n对于BEC等于$O(1)$，对于BSC、AWGN和二进制输入AWGN等于$\frac{1}{2}$对数n。对于后几种信道，正态近似通常定义为在前述表达式上加上$+\frac{1}{2}$对数n。

例如，考虑 $\mathsf{BEC}_{1/2}$ 信道，我们可以轻松计算出容量和色散分别为 $C=(1-\delta)$ 和 $V=\delta(1-\delta)$ (，单位分别为比特和比特^2。Ex. IV.4 中的详细计算得出以下严格估计：

$$213 \le \log_2 M^*(500,10^{-3}) \le 217\,.$$

同时，正态近似得出

$$\log M^*(500,10^{-3}) \approx n\bar{\delta} - \sqrt{n\delta\bar{\delta}}Q^{-1}(10^{-3}) \approx 215.5 \text{ bits}$$

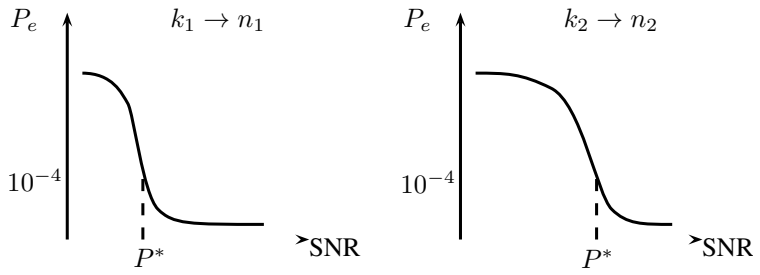
这种紧密性在广泛的n,ϵ,δ范围内得以保持。

再举一个例子，我们可以考虑BSC_δ信道。我们已经在(17.3)中给出了该信道的数值结果。在这里，我们评估第18章中讨论的所有下界。我们在图22.2中展示了结果，并附上了上界(22.16)。我们得出结论（毫不意外地），RCU界是最紧的，并且令人印象深刻地接近于逆界，正如我们在(17.3)中已经看到的那样。正态近似（带和不带$1/2\log n$项）与图22.3中的严格界进行了比较。该近似的极佳精度应与误差指数近似（与图22.2中的“Gallager”曲线重合）所产生的相当宽松的估计形成对比。

我们可以看到，对于BEC和BSC的简单情况，通过考虑展开式(22.15)中的前几项，可以相当好地近似解决极其复杂的组合优化问题$\log M^*(n,\epsilon)$。这为计算信道色散并为其他信道建立此类展开提供了进一步的研究动力。

22.7 标准化率

假设我们正在考虑两种不同的编码。一种是 $M=2^{k_1}$，块长度为 n_1 (，因此在工程语言中是一个 k_1-到-n_1 编码)，另一种是 k_2-到-n_2 编码。我们如何公平地比较这两者？展示编码性能的传统方式是通过“瀑布图”，显示错误概率对信道SNR（或交叉概率）的依赖关系。这两种编码可能有如下类型的瀑布图：



在查看这些图后，人们可能会认为 $k_1 \to n_1$ 码更好，因为它需要较小的信噪比就能达到相同的错误概率。然而，这忽略了这样一个事实：该码 $\frac{k_1}{n_1}$ 的速率也可能小得多。*normalized rate* 的概念使我们能够比较不同块长度和编码速率的码。

具体而言，假设给定一个 $k \to n$ 码。固定 $\epsilon > 0$ 并找出该码达到错误概率 ϵ (时的 SNR P 值，例如通过在瀑布图上取水平截距 ϵ 于水平)。归一化速率定义为

$$R_{\text{norm}}(\epsilon) = \frac{k}{\log_2 M^*(n,\epsilon,P)} \approx \frac{k}{nC(P) - \sqrt{nV(P)}Q^{-1}(\epsilon)},$$

其中log M^*、容量和色散对应于进行评估的信道（最常见的是AWGN、BI-AWGN或衰落信道）。我们还注意到，当然，log M^*的值无法精确计算，因此在实践中，我们使用正态近似来评估它。

这个想法使我们能够清楚地看到，几十年来编码理论中不同的思想是如何推动归一化速率的值向1上升的。这种比较展示在图22.4中。简短总结是，在与蜂窝网络中的“数据流”信道相对应的块长度（$n \sim 10^4$）上，LDPC码和非二进制LDPC码已经达到信息论极限的95%。在与“控制平面”相对应的块长度（$n \lesssim 10^3$）上，极化码和LDPC码具有相似的性能，并达到基本极限的90%。

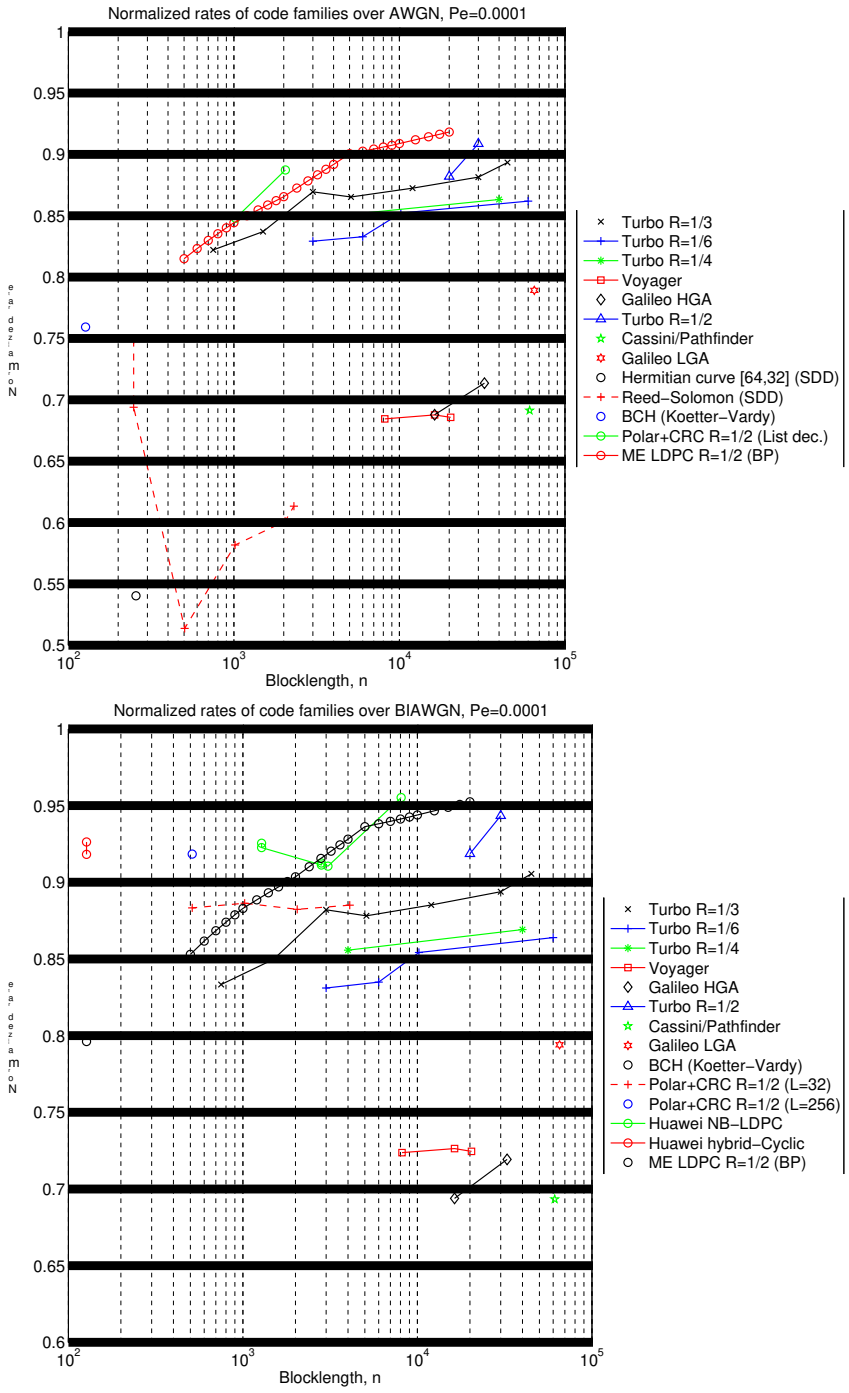


图22.4 归一化 各种代码的ed率。使用[397]生成的图表（彩色版本 n 推荐）

23 Channel coding with feedback

到目前为止，我们一直聚焦于单向通信的范式：数据被映射为码字并传输，随后根据接收到的含噪观测进行解码。在大多数实际场景中（存储除外），通信往往是双向的，因此接收端可以向发送端提供一定的*feedback*。作为一个启发性的例子，考虑卫星到地球的下行传输通信信道。下行传输非常昂贵（卫星端的功率限制），但从地球到卫星的上行传输却很廉价，这使得发送端（卫星）几乎可以无噪声地获得反馈。一般而言，当上行与下行之间存在这种不对称性时，具有无噪声反馈的信道就值得关注。即使在不太理想的场景中，含噪或部分反馈也通常可用，这有可能提升通信的可靠性或降低复杂度。

在我们讨论的前半部分，我们将遵循Shannon的理论，展示即使在无噪声反馈的情况下，传统设置中也无法（就容量而言）获得任何增益。在此过程中，我们还将引入Massey的有向信息概念。在本章的后半部分，我们将探讨反馈极为有益的情况：低错误概率、可变传输长度和可变传输功率。

23.1 反馈不会增加无记忆平稳信道的容量

定义 23.1（带反馈的码）带反馈的 (n, M, ϵ)-码由编码器-解码器对 (f, g) 如下指定：

- 编码器：（时变）

$$\begin{aligned} f_1 &: [M] \to \mathcal{A} \\ f_2 &: [M] \times \mathcal{B} \to \mathcal{A} \\ &\vdots \\ f_n &: [M] \times \mathcal{B}^{n-1} \to \mathcal{A} \end{aligned}$$

- 解码器：

$$g : \mathcal{B}^n \to [M]$$

使得 $\mathbb{P}[W \neq \hat{W}] \leq \epsilon$。

在时间 t 发送的符号既取决于消息，也取决于已接收符号的历史（因果性约束）：

$$X_t = f_t(W, Y_1^{t-1}).$$

因此概率空间如下：

$$\begin{aligned} &W \sim \text{ uniform on } [M] \\ &X_1 = f_1(W) \xrightarrow{P_{Y|X}} Y_1 \\ &\vdots \\ &X_n = f_n(W, Y_1^{n-1}) \xrightarrow{P_{Y|X}} Y_n \end{aligned} \Bigg\} \longrightarrow \hat{W} = g(Y^n)$$

图23.1比较了无反馈和理想全反馈下的信道编码设置：

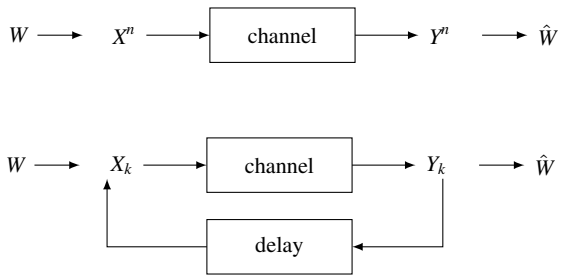


图23.1 无反馈（左）和全无噪反馈（右）的编码示意图。

定义23.2（根本极限）

$$\begin{aligned} M_{fb}^*(n,\epsilon) &= \max\{M : \exists(n, M, \epsilon) \text{ 带反馈的编码。}\} \\ C_{fb,\epsilon} &= \text{下极限}_{n\to\infty} \frac{1}{n} \text{对数 } M_{fb}^*(n,\epsilon) \text{ 极限} \\ \underset{\epsilon\to 0}{C_{fb,\epsilon}} & \\ C_{fb} &= \underline{\quad} \end{aligned}$$

(带反馈的香农容量)

定理 23.3 (Shannon 1956) *For a stationary memoryless channel,*

$$C_{fb} = C = C^{(\mathrm{I})} = \sup_{P_X} I(X;Y).$$

Proof. Achievability: 虽然显然$C_{fb} \geq C$，但我们想要证明实际上构造达到*full feedback*容量的代码可以直接完成，无需借助

到一个（难得多的）非反馈码问题。设 $\pi_t(\cdot) \triangleq P_{W|Y^t}(\cdot|Y^t)$ 为经过 t 步后的（随机）后验分布。显然，由于两端都知道 Y^t，发送端和接收端对 π_t 具有完全同步的知识。现在考虑传输如何进行：

1 初始化 $\pi_0(\cdot) = \frac{1}{M}$。 2 在第 $(t+1)$ 步，编码器发送 $X_{t+1} = f_{t+1}(W, Y^t)$。注意，选择 f_{t+1} 等价于将消息空间 $[M]$ 划分为类 $\mathcal{P}_a$ 的任务，即

$$\mathcal{P}_a \triangleq \{j \in [M] : f_{t+1}(j, Y^t) = a\} \qquad a \in \mathcal{A}\,.$$

如何最优地进行这种分区，是我们很快将要讨论的内容。
3 通道将 X_{t+1} 扰动为 Y_{t+1}，双方计算更新后的后验概率：

$$\pi_{t+1}(j) \triangleq \pi_t(j) B_{t+1}(j)\,, \qquad B_{t+1}(j) \triangleq \frac{P_{Y|X}(Y_{t+1}|f_{t+1}(j, Y^t))}{\sum_{a\in\mathcal{A}} \pi_t(\mathcal{P}_a)}\,.$$

请注意（这是关键部分！）随机乘数满足：

$$\mathbb{E}[\log B_{t+1}(W)|Y^t] = \sum_{a\in\mathcal{A}} \sum_{y\in\mathcal{B}} \pi_t(\mathcal{P}_a) \log \frac{P_{Y|X}(y|a)}{\sum_{a\in\mathcal{A}} \pi_t(\mathcal{P}_a) a} = I(\tilde{\pi}_{t+1}, P_{Y|X}) \tag{23.1}$$

其中 $\tilde{\pi}_{t+1}(a) \triangleq \pi_t(\mathcal{P}_a)$ 是 $\mathcal{A}$ 上的一个（随机）分布，由编码器在第 $(t+1)$ 轮的信道输入端诱导产生。注意，尽管 π_t 是在第 $(t+1)$ 步之前决定的，分区 $\mathcal{P}_a$ (以及因此 $\tilde{\pi}_{t+1}$) 的设计都掌握在编码器手中。

代码设计者的目标是提出这样一种划分$\{\mathcal{P}_a\colon\ a \in \mathcal{A}\}$，使得$\pi_t(W)$的增长速度最大。现在，分析随机乘法过程的增长速度最好通过对数来进行：

$$\log \pi_t(j) = \sum_{s=1}^{t} \log B_s + \log \pi_0(j)\,.$$

直观上，我们预期过程日志 $\pi_t(W)$ 类似于从 $-$ 日志 M 开始的随机游走，并具有正漂移。因此，为了估计该过程达到值0所需的时间，我们需要估计上升漂移。借助直觉和大数定律（更准确地说，是鞅论），我们近似

$$\log \pi_t(W) - \log \pi_0(W) \approx \sum_{s=1}^{t} \mathbb{E}[\log B_s]\,.$$

最后，从(23.1)我们得出结论，最佳策略是在每一步选择划分，使得$\tilde{\pi}_{t+1} \approx P_X^*$ (容量达到输入分布)，这得到

$$\log \pi_t(W) \approx tC - \log M\,,$$

意味着传输在时间 $\approx \frac{\log M}{C}$ 内终止。这里的重要教训是：
The optimal transmission scheme should map messages to channel inputs in such a way that

the induced input distribution $P_{X_{t+1}|Y^t}$ *is approximately equal to the one maximizing* $I(X;Y)$.这个想法被称为*posterior matching*，并在[384]中详细探讨。[1]

虽然我们上面的论证并不严谨，但通过援引鞅收敛理论使其严谨并不困难，这与我们在第16.3*节中分析SPRT时使用的方式非常相似。由于该结果原则上对于定理的证明并非必需，我们省略这些细节（参见[384]）。

Converse: 我们需要证明 $C_{fb} \le C^{(\mathrm{I})}$。回想在没有反馈的信道编码中证明弱逆定理的关键：Fano 不等式加上图模型

$$W \to X^n \to Y^n \to \hat{W}. \tag{23.2}$$

然后

$$-h(\epsilon) + \bar{\epsilon} \log M \le I(W;\hat{W}) \le I(X^n;Y^n) \le nC^{(\mathrm{I})}.$$

在有反馈时，概率图景变得更加复杂，如图23.2所示，对于n =^3（额外的波浪箭头引入了依赖性）：

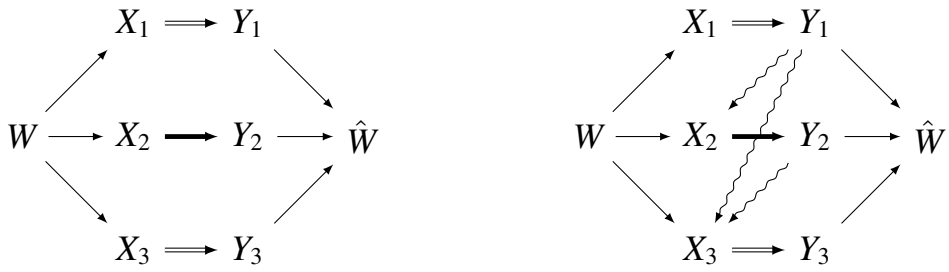


图23.2 信道编码与{<0xC2><0xA0>v15}3的图形模型，含反馈与无反馈情形。双箭头{<0xC2><0xA0>v16}对应信道链接。

注意，d-分离准则表明我们不再拥有马尔可夫链（23.2），即在给定X^n的情况下，W和Y^n不是独立的。[2]此外，输入-输出关系也不再是无记忆的

$$P_{Y^n|X^n}(y^n|x^n) \ne \prod_{j=1}^{n} P_{Y|X}(y_j|x_j)$$

1 这个简单（但可达容量）的反馈编码方案也帮助我们更充分地体会香农（无反馈）编码定理的神奇之处，该定理表明（几乎）最优的划分可以以一种完全无视实际信道输出的方式完成。也就是说，我们可以预先选择与π_t (无关但依赖于t)的划分$\mathcal{P}_a$，并且使得在绝大多数情况下以及对于几乎所有$t \in [n]$，$\pi_t(\mathcal{P}_a) \approx P_X^*(a)$。

2 例如，假设我们在 BSC 上传输 $W \sim \mathrm{Ber}(1/2)$ 并设定 $X_1 = 0, X_2 = W \oplus Y_1$。那么给定 X_1, X_2，我们可以看到 Y_2 和 W 可以相互精确确定。

(例如，令 $X_2 = Y_1$，因此 $P_{Y_1|X_1X_2} = \delta_{X_1}$ 是一个点质量)。尽管如此，信道中仍然存在很大程度的独立性。即，我们有

$$(Y^{t-1}, W) \to X_t \to Y_t, \quad t = 1, \ldots, n \tag{23.3}$$

$$W \to Y^n \to \hat{W} \tag{23.4}$$

然后

$$\begin{aligned}
-h(\epsilon) + \bar{\epsilon} \log M &\le I(W; \hat{W}) && \text{(Fano)} \\
&\le I(W; Y^n) && \text{(Data processing applied to (23.4))} \\
&= \sum_{t=1}^{n} I(W; Y_t | Y^{t-1}) && \text{(Chain rule)} \\
&\le \sum_{t=1}^{n} I(W, Y^{t-1}; Y_t) && (I(W; Y_t|Y^{t-1}) = I(W, Y^{t-1}; Y_t) - I(Y^{t-1}; Y_t)) \\
&\le \sum_{t=1}^{n} I(X_t; Y_t) && \text{(Data processing applied to (23.3))} \\
&\le nC && \square
\end{aligned}$$

与定理22.2相比，以下结果表明，在固定长度块编码中，反馈不仅未能提高接近容量的速度，而且最多只能改善至第三阶对数项 $\log n$。

定理 23.4（带反馈的分散 [131, 336]） *For weakly input-symmetric DMC (e.g. additive noise, BSC, BEC) we have:*

$$\log M^*_{fb}(n, \epsilon) = nC - \sqrt{nV} Q^{-1}(\epsilon) + O(\log n)$$

23.2* 马西的有向信息

在本节中，我们展示定理23.3逆命题部分的另一种证明，它更符合我们在本书中强调的“信道替换”思想（元逆定理），参见第3.6、17.4和22.3节。此外，它还将引导我们定义由Massey [294]引入的定向信息 $\vec{I}(X^n; Y^n)$ 的概念。定向信息是因果推断领域的重要工具，尽管我们不会深入探讨这些联系 [294]。

Proof. 让我们重新审视展示弱逆定理$C \le C^{(1)}$的步骤，这次采用元逆定理的风格来表述。我们取一个任意(n, M, ϵ)码，并定义两个具有相应图模型的分布：

$$\mathbb{P} : W \to X^n \to Y^n \to \hat{W} \tag{23.5}$$

$$\mathbb{Q} : W \to X^n \quad Y^n \to \hat{W} \tag{23.6}$$

然后我们得出两个关键观察：

1 在$\mathbb{Q}$下，$W \perp\!\!\!\perp \hat{W}$，使得 $\mathbb{Q}[W=\hat{W}]=\frac{1}{M}$ 而 $\mathbb{P}[W=\hat{W}]\geq 1-\epsilon$。
2 这两个图模型给出了分解：

$$P_{W,X^n,Y^n,\hat{W}} = P_{W,X^n}P_{Y^n|X^n}P_{\hat{W}|Y^n}, \qquad Q_{W,X^n,Y^n,\hat{W}} = Q_{W,X^n}Q_{Y^n}Q_{\hat{W}|Y^n}\,.$$

我们可以自由选择因子Q_{W,X^n}、Q_{Y^n}和$Q_{\hat{W}|Y^n}$。然而，正如我们很快会看到的，最好选择它们以最小化$D(\mathbb{P}\|\mathbb{Q})$，这给出我们（参见(4.6)后关于*information flow*的讨论）

$$\min_{Q_{W,X^n},Q_{Y^n},Q_{\hat{W}|Y^n}} D(\mathbb{P}\|\mathbb{Q}) = I(X^n;Y^n) \tag{23.7}$$

并且通过将这些因子取为它们在 $\mathbb{P}$ 下的值，即 $Q_{W,X^n}=P_{W,X^n}$、$Q_{Y^n}=P_{Y^n}$ 和 $Q_{\hat{W}|Y^n}=P_{\hat{W}|Y^n}$ 来实现。（通过写出散度（2.26）的链式法则来证明这一点是一个很好的练习。）正如我们所知，$D(\mathbb{P}\|\mathbb{Q})$ 的这个最小值衡量了通过图模型中排除的链接的信息流，即通过 $X^n \to Y^n$。

从这里开始，我们通过数据处理不等式和无记忆信道的容量张量化的方式进行如下推导：

$$-h(\epsilon)+\bar{\epsilon}\log M = d(1-\epsilon\|\frac{1}{M}) \overset{\text{DPI}}{\leq} D(\mathbb{P}\|\mathbb{Q}) = I(X^n;Y^n) \overset{(*)}{\leq} \sum_{i=1}^n I(X_i;Y_i) \leq nC^{(\mathrm{I})} \tag{23.8}$$

其中（$*$）源于 $X^n \to Y^n$ 是无记忆信道（（6.1））这一事实。

现在让我们回到带反馈信道的情形。对先前论证进行改造存在几个问题。首先，当存在反馈时，由于传输协议的影响，$X^n \to Y^n$ 并非无记忆的（例如，即使对于 DMC，已知 X_1 和 X_2 会影响 Y_1 的规律，即 $P_{Y_1|X_1} \neq P_{Y_1|X_1,X_2}$，以及 $P_{Y^n|X^n} \neq \prod_{j=1}^n P_{Y_j|X_j}$）。然而，通过尝试复现先前的证明，一个更大的问题被揭示出来。

假设我们再次尝试像(23.6)中那样诱导一个辅助概率空间{v*}。那么在$\mathbb{P}$ (下由于缺少马尔可夫链，即(23.5))，问题(23.7)的解这次可以证明等于

$$\min D(\mathbb{P}\|\mathbb{Q}) = I(W,X^n;Y^n)\,.$$

这个值可能远高于容量。例如，考虑一个极其嘈杂（实际上无用）的信道$\mathsf{BSC}_{1/2}$和一个反馈传输方案$X_{t+1}=Y_t$。我们看到$I(W,X^n;\ Y^n)\geq H(Y^{n-1})=(n-1)\log 2$，而容量$C=0$。这种情况下出了什么问题?

为了进行解释，我们应当回顾如图23.2（右图）所示的$\mathbb{P}$下的图形模型。当$\mathbb{Q}$按(23.6)定义时，值 $\min D(\mathbb{P}\|\mathbb{Q})=I(W,X^n;\ Y^n)$衡量通过$\Rightarrow$和$\rightsquigarrow$两条链路的信息流。

这促使我们为 {v*} 寻找一个图模型，使得 $\min D(\mathbb{P}\|\mathbb{Q})$ 仅捕获了仅通过 $\Rightarrow$ 链接 $\{X_i \to Y_i\colon i=1,\ldots,n\}$ (的信息流，并且使得 $\min D(\mathbb{P}\|\mathbb{Q}) \leq nC^{(\mathrm{I})}$)，同时仍然保证 $W \perp\!\!\!\perp \hat{W}$，从而 $\mathbb{Q}[W=\hat{W}]=\frac{1}{M}$。

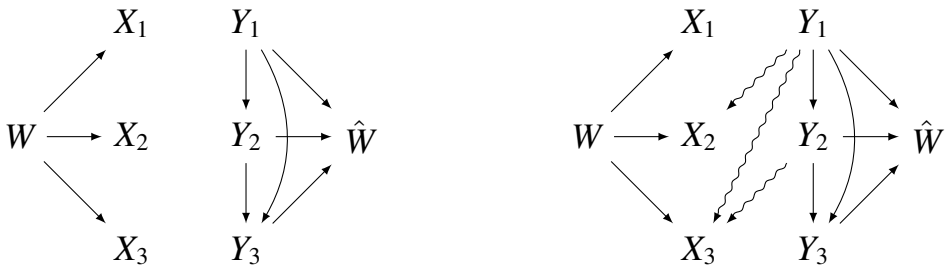


图23.3 辅助分布Q下$n = 3$的图形模型。与图23.2在实际分布P下的情况相比。

这样的图模型在图23.3（右图）中展示。[3] 形式化地，我们将限制$Q_{W,X^n,Y^n,\hat{W}} \in \mathcal{Q}$，其中$\mathcal{Q}$是可以按以下方式分解的分布集合：

$$Q_{W,X^n,Y^n,\hat{W}} = Q_W Q_{X_1|W} Q_{Y_1} Q_{X_2|W,Y_1} Q_{Y_2|Y_1} \cdots Q_{X_k|W,Y^{k-1}} Q_{Y_k|Y^{k-1}} \cdots Q_{X_n|W,Y^{n-1}} Q_{Y_n|Y^{n-1}} Q_{\hat{W}|Y^n}$$

使用d-分离准则（见(3.11)），我们可以验证对于任意$Q \in \mathcal{Q}$，我们有$W \perp\!\!\!\perp W$：W和$\hat{W}$被X^n所d-分离。（更直接地，可以清楚地看到，对$W = w$的任意固定值进行条件化确实会影响$X_1, \ldots, X_n$的分布，但不会影响Y^n和$\hat{W}$。）

注意，在$\mathbb{Q}$的图模型中，当我们移除$\Rightarrow$时，我们还在Y_i之间添加了有向链接，这些链接旨在最大程度地保留变量间的依赖关系，即使$\Rightarrow$被移除，从而使得$\mathbb{Q}$能更接近于$\mathbb{P}$，同时仍保持$W \perp\!\!\!\perp W$。我们注意到，这些链接在非反馈情形中也是隐含存在的（参见图23.3左侧图中该情形下的$\mathbb{Q}$模型）。

现在，既然根据我们在$\mathbb{Q}$下的约定，我们仍然有$\mathbb{Q}[W = \hat{W}] = \frac{1}{M}$，我们可以使用通常的发散数据处理来得出结论$d(1 - \epsilon \| \frac{1}{M}) \le D(\mathbb{P} \| \mathbb{Q})$。

假设关于这个 Q-图形模型的关键事实将在随后的引理23.6中展示，我们则有如下链：

$$\begin{aligned} d(1-\epsilon\|\frac{1}{M}) &\le \inf_{Q\in\mathcal{Q}} D(P_{W,X^n,Y^n,\hat{W}} \| Q_{W,X^n,Y^n,\hat{W}}) \\ &= \sum_{t=1}^{n} I(X_t; Y_t | Y^{t-1}) \quad \text{(Lemma 23.6)} \\ &= \sum_{t=1}^{n} \mathbb{E}_{Y^{t-1}}[I(P_{X_t|Y^{t-1}}, P_{Y|X})] \end{aligned}$$

3这种单向链接的移除被称为*causal conditioning*。

$$\begin{aligned}
&\le \sum_{t=1}^{n} I(\mathbb{E}_{Y^{t-1}}[P_{X_t|Y^{t-1}}], P_{Y|X}) \quad (\text{concavity of } I(\cdot, P_{Y|X})) \\
&= \sum_{t=1}^{n} I(P_{X_t}, P_{Y|X}) \\
&\le nC^{(\mathrm{I})}.
\end{aligned}$$

因此，我们完成了证明

$$-h(\epsilon) + \bar{\epsilon}\log M \le nC^{(\mathrm{I})} \Rightarrow \log M \le \frac{nC + h(\epsilon)}{1-\epsilon} \Rightarrow C_{fb,\epsilon} \le \frac{C}{1-\epsilon} \Rightarrow C_{fb} \le C.$$

我们注意到，该证明本质上也可以几乎无需修改地适应于具有成本约束的信道以及单位成本容量设定，参见[337]。 □

现在我们继续展示上述证明中被省略的关键步骤。在此之前，让我们定义一种有趣的新信息类型。

定义 23.5（Massey 的有向信息 [294]）对于一对块长度为 n 的随机变量 X^n 和 Y^n，我们定义

$$\vec{I}(X^n; Y^n) \triangleq \sum_{t=1}^{n} I(X^t; Y_t|Y^{t-1})$$

注意，定向信息不是对称的。正如[294]（以及后续工作，例如[412]）所示$\vec{I}(X^n;\ Y^n)$量化了从X-过程到Y-过程的信息转移量。在反馈通信的背景下，引入这一概念的正式理由是以下结果。

引理 23.6 *Consider communication with feedback over a non-anticipatory channel given by a sequence of Markov kernels $P_{Y_t|X^t,Y^{t-1}}, t \in [n]$, i.e. we have a probability distribution $\mathbb{P}$ on $(W, X^n, Y^n, \hat{W})$ described by factorization*

$$P_{W,X^n,Y^n,\hat{W}} = P_W \prod_{t=1}^{n} P_{X_t|W,X^{t-1},Y^{t-1}} P_{Y_t|X^t,Y^{t-1}}\,. \tag{23.9}$$

Denote by $\mathcal{Q}$ all distributions factorizing with respect to the graphical models on Figure 23.3 (right graph), that is those satisfying

$$Q_{W,X^n,Y^n,\hat{W}} = Q_W \prod_{t=1}^{n} Q_{X_k|W,Y^{k-1}} Q_{Y_k|Y^{k-1}} \tag{23.10}$$

Then we have

$$\inf_{Q\in\mathcal{Q}} D(P_{W,X^n,Y^n,\hat{W}} \| Q_{W,X^n,Y^n,\hat{W}}) = \vec{I}(X^n; Y^n)\,. \tag{23.11}$$

In addition, if the channel is memoryless, i.e. $P_{Y_t|X^t,Y^{t-}}1 = P_{Y_t|X_t}$ *for all* $t \in [n]$*, then we have*

$$\vec{I}(X^n;Y^n) = \sum_{t=1}^{n} I(X_t;Y_t|Y^{t-1})\,.$$

Proof. 通过比较因式分解(23.9)和(23.10)，并应用链式法则(2.26)，我们可以立即优化几个项（我们将此论证留作练习）：

$$\begin{aligned} Q_{X,W} &= P_{X,W},\\ Q_{X_t|W,Y^{t-1}} &= P_{X_t|W,Y^{t-1}}\\ Q_{\hat{W}|Y^n} &= P_{W|Y^n}. \end{aligned}$$

由此我们得出结论：

$$\begin{aligned} &\inf_{Q\in\mathcal{Q}} D(P_{W,X^n,Y^n,\hat{W}}\|Q_{W,X^n,Y^n,\hat{W}})\\ &= \inf_{Q\in\mathcal{Q}} D(P_{Y_1|X_1}\|Q_{Y_1}|X_1) + D(P_{Y_2|X^2,Y_1}\|Q_{Y_2|Y_1}|X^2,Y_1) + \cdots + D(P_{Y_n|X^n,Y^{n-1}}\|Q_{Y_n|Y^{n-1}}|X^n,Y^{n-1})\\ &= I(X_1;Y_1) + I(X^2;Y_2|Y_1) + \cdots + I(X^n;Y_n|Y^{n-1})\,, \end{aligned}$$

其中最后一步我们仅应用了推论4.2的（条件）版本。

为了证明无记忆信道的声明，我们只需注意到

$$I(X^t;Y_t|Y^{t-1}) = I(X_t;Y_t|Y^{t-1}) + I(X^{t-1};Y_t|Y^{t-1},X_t)\,,$$

并且最后一项为零。后者可以通过d-分离准则来证明。实际上，在没有通道记忆的情况下，从X^{t-1}到Y_t的每一条无向路径都必须经过X_t，而X_t是一个非碰撞点且被条件化。

□

总结来说，我们可以看出，香农关于反馈通信的结果最好被理解为信道编码中标准弱逆定理的一个简单修改：而不是使用

23.3 反馈何时真正有用?

定理23.3和23.4指出，反馈既不会在渐近情况下也不会在中等块长度下提高通信速率。在本节中，我们将探讨三个反馈极为有用的案例。

23.3.1 错误概率极小（例如为零）的代码

定理 23.7 (Shannon [379]) *For any DMC* $P_{Y|X}$*,*

$$C_{fb,0} = \max_{P_X} \min_{y\in\mathcal{B}} \log \frac{1}{P_X(S_y)} \tag{23.12}$$

where

$$S_y = \{x \in \mathcal{A} : P_{Y|X}(y|x) > 0\}$$

denotes the set of input symbols that can lead to the output symbol y.

注23.1 对于平稳无记忆信道，我们有

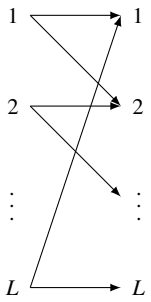
$$C_0 \overset{\text{(a)}}{\le} C_{fb,0} \overset{\text{(b)}}{\le} C_{fb} = \lim_{\epsilon\to 0} C_{fb,\epsilon} \overset{\text{(c)}}{=} C = \lim_{\epsilon\to 0} C_\epsilon \overset{\text{(d)}}{=} C^{(\mathrm{I})} = \sup_{P_X} I(X;Y)$$

其中 (a) 和 (b) 根据定义得出，(c) 由定理 23.3 推出，(d) 归因于定理 19.9。上述所有容量量均基于（固定长度）分组码定义。

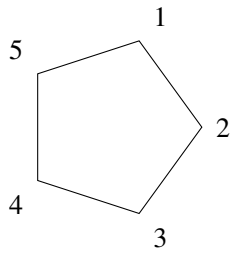
注 23.2 1 在 DMC 中，对于两种零错误容量（C_0 和 $C_{fb,0}$），只有转移矩阵 $P_{Y|X}$ 的支撑集，即 $P_{Y|X}(b|a) >$ 是否为 0，是重要的；那些非零 $P_{Y|X}(b|a)$ 的取值无关紧要。也就是说，C_0 和 $C_{fb,0}$ 由输入字母表 $\mathcal{A}$ 与输出字母表 $\mathcal{B}$ 之间的二分图表示决定。此外，C_0（而非 $C_{fb,0}$！）是 *confusability graph* 的函数——一个在 $\mathcal{A}$ 上的简单无向图，其中 $a \neq a'$ 由一条边连接当且仅当存在 $\exists b \in \mathcal{B}$ 使得 $P_{Y|X}(b|a)P_{Y|X}(b|a') >$ 为 0。

2 $C_{fb,0}$ 不仅仅是混淆图函数这一点，通过比较多边形通道（下一个例子）与$L = 3$（其中 $C_{fb,0} = \log\frac{3}{2}$）以及无用通道，后者的$\mathcal{A} = \{1,2,3\}$ 和$\mathcal{B} = \{1\}$ (，其$C_{fb,0} = 0$)，即可轻易看出。显然，在这两种情况下，混淆图是相同的——一个三角形。

3 通常 C_0 很难计算，但 $C_{fb,0}$ 可以如（23.12）那样以闭合形式获得。作为一个例子，考虑以下以其混淆图命名的 *polygon channel* ()：



二部图



易混淆图（$L = 5$）

关于多边形信道的零错误容量C_0，已知以下内容：

• $L = 3$： $C_0 = 0$。 • $L = 5$： $C_0 = \frac{1}{2}\log 5$。这是一个著名的“五边形容量”问题。对于可达性，当块长度为1时，可以使用$\{1,3\}$达到1比特的速率；当块长度为2时，码本 $\{(1,1),(2,3),(3,5),(4,2),(5,4)\}$达到$\frac{1}{2}\log 5$比特的速率，正如香农所指出的。

在他1956年的原始论文[379]中。二十多年后，Lovász利用现称为半定规划松弛的技术[286]证明了其最优性。

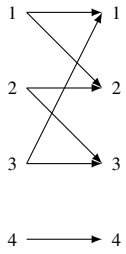
• 即使 L：$C_0 = \log \frac{L}{2}$ (练习 IV.36)。• $L = 7$：$3/5 \log 7 \le C_0 \le \log 3.32$。求任意奇数 $L \ge 7$ 的精确值是一个著名的组合数学开放问题。• 奇数的渐近性质 L：尽管一般情况下未知 C_0 有一个已知的渐近展开：对于奇数 L，$C_0 = \log \frac{L}{2} + o(1)$ [66]。

相比之下，带有反馈的零错误容量（练习IV.36）等于$C_{fb,0} = \log \frac{L}{2}$对于任何$L$，因此，可以严格超过$C_0$。

4 注意 $C_{fb,0}$ 不一定等于 $C_{fb} = \lim_{\epsilon \to 0} C_{fb,\epsilon} = C$。这里有一个例子：

$$C_0 < C_{fb,0} < C_{fb} = C.$$

考虑一个具有以下二分图表示的通道：



然后可以验证

$$\begin{aligned} C_0 &= \log 2 \\ C_{fb,0} &= \max_{\delta} -\log \max\left(\frac{2}{3}\delta, 1-\delta\right) && (P_X^* = (\delta/3, \delta/3, \delta/3, \bar{\delta})) \\ &= \log \frac{5}{2} > C_0 && (\delta^* = \frac{3}{5}) \end{aligned}$$

另一方面，通过令交叉概率任意接近于零，香农容量 $C = C_{fb}$ 可以任意接近于 $\log 4$，而混淆图保持不变。

Proof of Theorem 23.7. 1 固定任意$(n, M, 0)$-码。对于每个$t = 0, 1, \ldots, n$，将通过以下方式表示所有可能产生接收信号$y^t = (y_1, \ldots, y_t)$的消息的混淆集：

$$E_t(y^t) \triangleq \{m \in [M] : f_1(m) \in S_{y_1}, f_2(m, y_1) \in S_{y_2}, \ldots, f_n(m, y^{t-1}) \in S_{y_t}\}$$

注意，零误差意味着没有歧义：

$$\epsilon = 0 \Leftrightarrow \forall y^n \in \mathcal{B}^n, |E_n(y^n)| = 1 \text{ or } 0. \tag{23.13}$$

2 证明中的关键量定义如下:

$$\theta_{fb} \triangleq \min_{P_X} \max_{y\in\mathcal{B}} P_X(S_y), \quad P_X^* \triangleq \operatorname*{argmin}_{P_X} \max_{y\in\mathcal{B}} P_X(S_y)$$

目标是展示

$$C_{fb,0} = \log \frac{1}{\theta_{fb}}.$$

根据定义，我们有

$$\forall P_X, \exists y \in \mathcal{B}, \text{ such that } P_X(S_y) \geq \theta_{fb} \tag{23.14}$$

注意，通常情况下，最小值点 P_X^* 并非传统意义上的容量达到输入分布（回想定理5.4）。这一-定义还揭示了编码和解码应如何进行，并有助于界定解码方案每个阶段不确定性减少的下限。

3 “$\leq$”（逆）：令 P_{X^n} 为码字的联合分布。用 $E_0 = [M]$ 表示原始消息集。

$t = 1$: 对于 P_{X_1}，由 (23.14)，$\exists y_1^*$ 使得:

$$P_{X_1}(S_{y_1^*}) = \frac{|\{m : f_1(m) \in S_{y_1^*}\}|}{|\{m \in [M]\}|} = \frac{|E_1(y_1^*)|}{|E_0|} \geq \theta_{fb}.$$

$t = 2$：对于 $P_{X_2|X_1\in S_{y_1^*}}$，根据（23.14），存在 $\exists y_2^*$ 使得:

$$P_{X_2}(S_{y_2^*}|X_1 \in S_{y^*}) = \frac{|\{m : f_1(m) \in S_{y_1^*}, f_2(m, y_1^*) \in S_{y_2^*}\}|}{|\{m : f_1(m) \in S_{y_1^*}\}|} = \frac{|E_2(y_1^*, y_2^*)|}{|E_1(y_1^*)|} \geq \theta_{fb},$$

$t = n$继续选择过程，直至满足以下条件的 y_n^*:

$$P_{X_n}(S_{y_n^*}|X_t \in S_{y_t^*} \text{ for } t = 1, \ldots, n-1) = \frac{|E_n(y_1^*, \ldots, y_n^*)|}{|E_{n-1}(y_1^*, \ldots, y_{n-1}^*)|} \geq \theta_{fb}.$$

最后，由（23.13）及上述选择过程，我们有

$$\frac{1}{M} \geq \frac{|E_n(y_1^*, \ldots, y_n^*)|}{|E_0|} \geq \theta_{fb}^n.$$

因此 $M \leq -n \log \theta_{fb}$，并且我们已经证明了 $C_{fb,0} \leq -\log \theta_{fb}$。

4 “$\geq$”（可实现性）：让我们构造一个达到 $(M, n,$ 的代码 $0)$.

作为一个例子，考虑图23.4中具有$|\mathcal{A}| = |\mathcal{B}| = 3$的特定信道。作为第一阶段，编码器$f_1$将所有$M$消息的空间划分为三个组，其大小与权重$P_X^*(a_i)$成比例，然后将每组中的消息映射到对应于$i = 1, 2, 3$的$a_i$。假设信道输出为$y_1$。由于在此示例中$S_{y_1} = \{a_1, a_2\}$，解码器可以在本轮中消除总共$MP_X^*(a_3)$个候选消息。之后，“可混淆集”仅包含剩余的$MP_X^*(S_{y_1})$条消息。根据$P_X^*$的定义，我们知道$MP_X^*(S_{y_1}) \leq M\theta_{fb}$。在第二轮中，编码器$f_2$将剩余消息划分为三个组，发送组索引并重复。

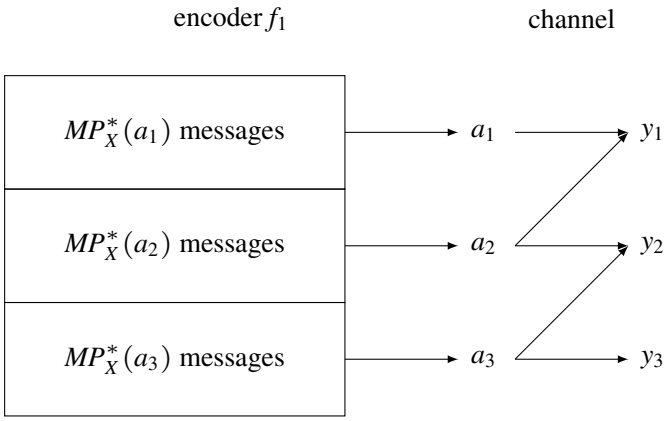


图23.4 带反馈的零错误容量可达方案。

通过类似的论证，每次交互都会将不确定性减少一个因子*at least* θ_{fb}。经过n次迭代后，“混淆集”的大小上限为$M\theta_{fb}^n$，如果$M\theta_{fb}^n \le 1$，[4]则为零错误概率。这通过选择$\log M = -n\log\theta_{fb}$得到保证。因此，我们已经证明，在有反馈的情况下，$-n\log\theta_{fb}$比特可以通过$n + O(1)$次信道使用可靠地传输，从而$C_{fb,0} \ge -\log\theta_{fb}$。

□

上述定理展示了反馈在零差错通信中的可能优势。然而，对于一般的离散无记忆信道（例如BSC_δ，其中$\delta \in (0,1)$），我们有$C_0 = C_{fb,0} = 0$。我们能否证明反馈对此类信道有任何优势？显然，为此我们需要理解当$\epsilon > 0$时$\log M_{fb}^*(n,\epsilon)$的行为。结果表明，对于弱输入对称信道（第19.4*节），我们有

$$\log M_{fb}^*(n,\epsilon) = nC - \sqrt{nV}Q^{-1}(\epsilon) + O(\log n)\,,$$

因此，至少在二阶之前，基础极限的行为在存在反馈的情况下保持不变。接下来，我们通过定义来讨论误差指数渐近性（第22.4节*）

$$E_{fb}(R) \triangleq \lim_{n\to\infty} -\frac{1}{n}\log\epsilon_{fb}^*(n,\exp\{nR\})\,,$$

如果极限存在，并以$\epsilon_{fb}^*(n,M)$表示块长度n的反馈码的最小可能误差。

首先，已知球填充界(22.14)在存在反馈的情况下仍然成立[312]，即

$$E_{fb}(R) \le E_{sp}(R)\,,$$

[4] Some rounding-off errors need to be corrected in a few final steps (because P_X^* may not be closely approximable when very few messages are remaining). This does not change the asymptotics though.

因此，对于速率 $R \in (R_{cr}, C)$，误差指数 $E_{fb}(R) = E(R)$ 表明由于反馈的可用性没有变化。那么反馈的优势是什么呢？事实证明，在低于临界速率时，误差指数确实会改善。例如，对于 BEC_δ，一种简单的传输方案，即每个比特被重传直到成功接收，在所有速率下都能达到误差指数 $E_{sp}(R)$（因为这里的错误概率由 $\mathbb{P}[\mathrm{Bin}(n,\delta) > n(1-R/\log 2)]$ 给出）：

$$\mathrm{BEC}: \qquad E_{fb}(R) = E_{sp}(R) \qquad 0 < R < C,$$

对于$R < R_{cr}$，这严格高于$E(R)$。

对于 BSC_δ，Berlekamp 的一个漂亮结果表明

$$E_{fb}(0+) = -\log((1-\delta)^{1/3}\delta^{2/3} + (1-\delta)^{2/3}\delta^{1/3}) > E(0+) = E_{ex}(0) = -\frac{1}{4}\log(4\delta(1-\delta)).$$

换言之，大小为$M = \exp\{o(n)\}$的最优码的错误概率在存在反馈的情况下确实有了显著改善（至少在BSC和BEC上）。

23.3.2 变长编码

考虑具有反馈的BEC_δ信道的例子。我们可以定义一种简单的通信策略，以如下方式发送k个数据比特。重复发送每个数据比特，直到它无擦除地通过信道。利用反馈，发送端可以确切地知道这何时发生，并在此时切换到发送下一个数据比特。发送k个比特所需的期望信道使用次数由下式给出

$$\ell = \mathbb{E}[n] = \frac{k}{1-\delta}.$$

因此，值得注意的是，通过允许可变长度传输，即使对每个数据比特独立编码，也能达到容量，从而完全避免了任何有限块长度的惩罚。虽然这种巧妙的编码方案是 BEC_δ 特有的，但事实证明 *zero-dispersion* 的一般事实是普遍适用的。为此，我们正式定义以下概念。

定义23.8 一个(ℓ, M, ϵ)变长反馈（VLF）码，其中ℓ为正实数，M为正整数，且$0 \le \epsilon \le 1$，其定义为：

1 一个空间 $\mathcal{U}$ [5] 及其上的概率分布 P_U，定义了一个随机变量 U，在传输开始前向发送端和接收端双方揭示；即 U 充当公共随机性，用于在传输开始前初始化编码器和解码器。

2 编码器序列 f_n：$\mathcal{U} \times \{1,\dots,M\} \times \mathcal{B}^{n-1} \to \mathcal{A}$，$n \ge 1$，定义信道输入

$$X_n = f_n(U, W, Y^{n-1}), \tag{23.15}$$

其中 $W \in \{1,\dots,M\}$ 是等概率消息。

3 解码器序列 g_n：$\mathcal{U} \times \mathcal{B}^n \to \{1,\dots,M\}$ 在时间 n 提供 W 的最佳估计。

可以证明，不失一般性，我们可以假设 $|\mathcal{U}| \le 3$，参见[336，附录]。

4 一个非负整数值随机变量 τ，是过滤 $\mathcal{G}_n = \sigma\{U, Y_1, \ldots, Y_n\}$ 的停时，满足

$$\mathbb{E}[\tau] \le \ell\,. \tag{23.16}$$

最终决策 $\hat{W}$ 在时刻 τ 计算得出：

$$\hat{W} = g_\tau(U, Y^\tau)\,, \tag{23.17}$$

并且必须满足

$$\mathbb{P}[\hat{W} \neq W] \le \epsilon\,. \tag{23.18}$$

有反馈的信道编码的基本极限由以下量给出：

$$M^*_{\rm VLF}(\ell, \epsilon) = \max\{M : \exists(\ell, M, \epsilon)\text{-VLF code}\}\,. \tag{23.19}$$

在t他的语言，我们上面的例子表明对于 BEC_δ w 我们有

$$\log M^*_{\rm VLF}(\ell, 0) \ge (1-\delta)\ell \log 2 + O(1)\,, \qquad \ell \to \infty$$

注意，与无反馈的方案相比，由于在 $\log M^*(n, \epsilon)$ 的展开中，项 $\sqrt{nV}Q^{-1}(\epsilon)$ 现在被去掉了，因此有了显著的改进。出于这个原因，这样的结果被称为 *zero-dispersion* 结果。

事实证明，只要允许存在一定的 $\epsilon > 0$误差，这种效应对于所有DMC都是普遍适用的。

定理 23.9（VLF 零色散[336]）*For any DMC with capacity C we have*

$$\log M^*_{\rm VLF}(l, \epsilon) = \frac{lC}{1-\epsilon} + O(\log l) \tag{23.20}$$

我们省略该结果的证明，仅提及可达性部分依赖于类似于第16.3*节的SPRT的思想：消息持续传输，直到某个码字的信息密度$i(c_j;\ Y^n)$超过$\log M$。详见[336]。我们还提到，存在另一种称为VLFT编码的VLF编码变体，其中停止时间τ不是由接收方决定，而是允许由发送方决定（见习题IV.35(d)）。展开式(23.20)对VLFT码同样成立[336]。

例 23.1 对于无反馈的信道 $\mathsf{BSC}_{0.11}$，达到容量 C 的 90% 所需的最小 n = 为 3000，而存在一种具有 $\ell = \mathbb{E}[n] = 200$ 的 VLF 码可以达到该目标 [336]。这展示了反馈能多大程度地改善延迟和解码复杂度。

VLF码不仅能消除色散项，还能显著改善误差指数。我们已在第22.4*节（无反馈）和上一节末尾（有反馈）中，在固定长度码的背景下讨论过它们。这里我们提及Burna-shev [79]的一个深刻结果，他证明了速率为R (、即具有$\log M = \ell R$)的VLF码的最优错误概率满足*for every DMC*

$$\epsilon^*_{\rm VLF}(\ell, \exp\{\ell R\}) = \exp\{-\ell E_{\rm VLF}(R) + o(\ell)\}\,,$$

其中Burnashev的误差指数有一个特别简单的表达式

$$E_{\mathrm{VLF}}(R) = \frac{C_1}{C}(C-R)_+\,, \qquad C_1 = \max_{x_1,x_2} D(P_{Y|X=x_1}\|P_{Y|X=x_2})\,.$$

与无反馈或固定长度反馈误差指数相关的复杂（且在很大程度上仍未解决！）情况相比，这一表达的简洁性引人注目。

23.3.3 变功率编码

在前面的章节中，我们讨论了反馈对DMC的优势。对于AWGN信道，事实证明，要释放反馈的潜力需要放宽代价约束。回想一下，在第20.1节中，我们假设每个码字$x^n \in \mathbb{R}^n$都应满足一个固定的功率约束P，即$\sum_{j=1}^n x_j^2 \le nP$。事实证明，在这样的功率约束下，可以证明反馈在色散、有限块长度或误差指数意义上都没有太大帮助。然而，如果将功率约束放宽到

$$\mathbb{E}[\sum_{j=1}^n X_j^2] \le nP\,,$$

其中这里的期望既是对信道噪声的，也是对发射机基于消息W和$Y_1,\dots,Y_{j-1}$确定X_j时可能采用的随机性的。接下来，我们将演示如何有效地利用这一新的自由度。

Elias的方案 考虑通过以下一组AWGN信道发送一个标准高斯随机变量A：

$$\begin{aligned} &Y_k = X_k + Z_k, \quad Z_k \sim \mathcal{N}(0,\sigma^2) \text{ i.i.d.}\\ &\mathbb{E}[X_k^2] \le P. \end{aligned}$$

我们假设如图23.1所示存在完全无噪声反馈。请注意，关键在于，功率约束以期望形式施加*in expectation*，这并不会增加信道容量（回忆定理20.6中的逆定理），但使得诸如下文中的Elias方案这样简单的算法成为可能。相反，如果我们像第20.1节那样坚持每个码字几乎必然满足功率约束，而不是期望，即几乎必然满足$\sum_{k=1}^n X_k^2 \le nP$，那么Elias方案将不起作用。

仅使用 *linear processing*，Elias 的方案按照图23.5所示进行。

根据 *orthogonality principle*，在接收端对于所有 $t = 1,\dots,n$，我们有

$$A = \hat{A}_t + N_t, \quad N_t \perp\!\!\!\perp Y^t.$$

此外，由于所有操作都是线性的，所有随机变量联合高斯分布，因此残差误差满足$N_t \perp\!\!\!\perp Y^t$。由于$X_t \propto N_{t-1} \perp\!\!\!\perp Y^{t-1}$，我们在每个时间隙发送的码字与信道输出的历史（“创新”）独立，以最大化信息传输。

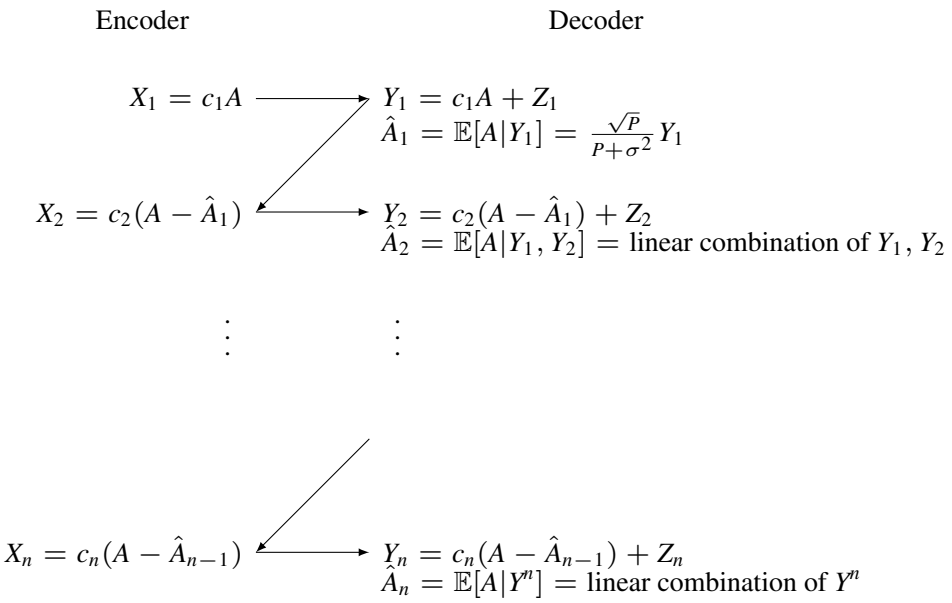


图23.5 Elias针对具有可变功率的AWGN信道的方案。在此，每个系数c_i的选择使得$\mathbb{E}[X_i^2] = P$。

注意，$Y^n \to \hat{A}_n \to A$，且由于高斯性，最优估计量$\hat{A}_n$（即Y^n）的线性组合）是Y^n对于A的充分统计量。那么

$$\begin{aligned} I(A;Y^n) =& I(A;\hat{A}_n, Y^n) \\ =& I(A;\hat{A}_n) + I(A;Y^n|\hat{A}_n) \\ =& I(A;\hat{A}_n) \\ =& \frac{1}{2}\log\frac{\mathrm{Var}(A)}{\mathrm{Var}(N_n)}, \end{aligned}$$

其中最后一个等式应用了$\hat{A}_n \perp\!\!\!\perp N_n$以及例3.3中的高斯互信息公式。虽然$\mathrm{Var}(N_n)$可以使用标准的线性MMSE结果轻松计算，但接下来我们从信息论角度确定它：请注意，我们还有

$$\begin{aligned} I(A;Y^n) &= I(A;Y_1) + I(A;Y_2|Y_1) + \cdots + I(A;Y_n|Y^{n-1}) \\ &= I(X_1;Y_1) + I(X_2;Y_2|Y_1) + \cdots + I(X_n;Y_n|Y^{n-1}) \\ &\overset{\text{key}}{=} I(X_1;Y_1) + I(X_2;Y_2) + \cdots + I(X_n;Y_n) \\ &= \frac{n}{2}\log(1+P) = nC, \end{aligned}$$

其中关键步骤对所有 t 应用 $X_t \perp\!\!\!\perp Y^{t-1}$。因此，采用 Elias 的发送方案 $A \sim \mathcal{N}(0,1)$，在第 n 次使用带反馈且期望功率为 P 的 AWGN 信道后，我们得到

$$\operatorname{Var} N_n = \operatorname{Var}(\hat{A}_n - A) = 2^{-2nC} \operatorname{Var} A = \left(\frac{P}{P+\sigma^2}\right)^n,$$

这表明估计中不确定性的降低在 n 中呈指数级快速。

Schalkwijk-Kailath 方案 Elias 的方案也可用于发送数字数据。令 $W \sim$ 在 $[-1,1]$ 中的 M-PAM（脉冲幅度调制）星座上均匀分布，即 $\{-1, -1+\frac{2}{M}, \cdots, -1+\frac{2k}{M}, \cdots, 1\}$。在第一步中，发送 W（在缩放以满足功率约束之后）：

$$X_0 = \sqrt{P}W, \quad Y_0 = X_0 + Z_0$$

由于Y_0和X_0在编码器处均已知，编码器可以计算Z_0。因此，为了描述W，编码器只需描述噪声实现Z_0。这通过采用Elias方案（$n-1$次）来实现。经过$n-1$次信道使用和MSE估计后，等效信道输出：

$$\widetilde{Y}_0 = X_0 + \widetilde{Z}_0, \quad \operatorname{Var}(\widetilde{Z}_0) = 2^{-2(n-1)C}$$

鳍 ally，解码器将$\widetilde{Y}_0$量化为最近的PAM点。不 冰那

$$\epsilon \le \mathbb{P}\left[|\widetilde{Z}_0| > \frac{1}{2M}\right] = \mathbb{P}\left[2^{-(n-1)C}|Z| > \frac{\sqrt{P}}{2M}\right] = 2Q\left(\frac{2^{(n-1)C}\sqrt{P}}{2M}\right)$$

以便

$$\log M \ge (n-1)C + \log\frac{\sqrt{P}}{2} - \log Q^{-1}(\frac{\epsilon}{2}) = nC + O(1).$$

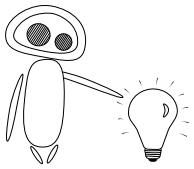
因此，如果速率严格小于容量，错误概率会随着 n 的增加而以 *doubly exponentially* 的速率衰减。更重要的是，我们在 $\log M$ 方面获得了一个 $\sqrt{n}$ 项，因为在没有反馈的情况下，我们有（根据定理22.2）

$$\log M^*(n,\epsilon) = nC - \sqrt{nV}Q^{-1}(\epsilon) + O(\log n)\,.$$

例如，考虑$P=1$，则信道容量为$C=0.5$比特每信道使用。要达到错误概率10^{-3}，$2Q\left(\frac{2^{(n-1)C}}{2M}\right) \approx 10^{-3}$，因此$\frac{e^{(n-1)C}}{2M} \approx 3$，且$\frac{\log M}{n} \approx \frac{n-1}{n}C - \frac{\log 8}{n}$。注意，仅需$n=50$次信道使用即可达到容量的99%以内，而无反馈的最佳分组码需要$n \approx 2800$次才能达到容量的90%。

本章的 *take-away message* 如下：反馈最好通过 *adaptive*策略来利用。尽管在分组编码下它并不能增加容量，但反馈可以极大地提高可靠性并降低编码复杂度。

第四部分练习



IV.1 考虑AWGN信道 $Y^n = X^n + Z^n$，其中 Z_i 是独立同分布的 $\mathcal{N}(0,1)$，并且 $X_i \in [-1,1]$（幅度约束）。回想 $\epsilon^*(n,2)$ 表示在该信道上传输1比特信息的最优 *average* 错误概率。

(a) 用 $Q(x) = \int_x^\infty \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt$ 表示 $\epsilon^*(n,2)$ 的值。(b) 计算指数 $r = \lim_{n\to\infty} \frac{1}{n} \log \frac{1}{\epsilon^*(n,2)}$。（提示：当 $x \to \infty$ 时 $Q(x) = e^{-x^2(1/2+o(1))}$，参见练习 V.25）(c) 使用假设检验的渐近性以不同方式计算 r，并检查两个值是否一致。（提示：标准高斯 $Z \sim \mathcal{N}(0,1)$ 的矩母函数由 $\mathbb{E}[e^{tZ}] = e^{t^2/2}$ 给出。）

IV.2 随机编码器和解码器可能有助于最大化错误概率：

(a) 考虑一个由 $P_{Y|X=0} = \text{Ber}(1/2)$ 和 $P_{Y|X=1} = \text{Ber}(1/3)$ 指定的二进制非对称信道 $P_{Y|X} : \{0,1\} \to \{0,1\}$。编码器 f: $[M] \to \{0,1\}$ 试图传输 1 比特信息，即 $M = 2$，其中 $f(1) = 0, f(2) = 1$。证明最小化最大错误概率的最优解码器必然是随机的。找出最优解码器和最优 $P_{e,\max}$。（提示：回忆二进制假设检验。）

(b) 给出一个$P_{Y|X}$的例子：$\mathcal{X} \to \mathcal{Y}$，$M >$为1，$\epsilon >$为0，使得存在具有随机化编解码器的 $(M,\epsilon)_{max}$码，但不存在具有确定性编解码器的此类码。

IV.3（糟糕的打字员）设 $\mathcal{X} = \mathcal{Y} = \{A, S, D, F, G, H, J, K, L\}$。如果 α 和 β 是键盘上相邻的字母，则设 $P_{Y|X}(\alpha|\beta) = 0.1$，如果 $\alpha \neq \beta$ 且它们不相邻，则设 $P_{Y|X}(\alpha|\beta) = 0$。求最小的 ϵ，使得你可以保证存在一个 $(4,\epsilon)_{avg}$-码。

IV.4（BEC的有限块长度界）。考虑一个具有$M = 2^k$的码，在块长度n的二元擦除信道（BEC）上运行，擦除概率为$\delta \in [0,1)$。

(a) 证明无论编码器-解码器对如何：

$$\mathbb{P}[\text{error}|\#\text{erasures} = z] \geq \left|1 - 2^{n-z-k}\right|^+$$

(b) 通过对 z 的分布取平均得出错误概率 ϵ 必须满足

$$\epsilon \geq \sum_{\ell=n-k+1}^{n} \binom{n}{\ell} \delta^\ell (1-\delta)^{n-\ell} \left(1 - 2^{n-\ell-k}\right), \tag{IV.1}$$

(通过应用均匀P_X的DT界，证明存在满足以下条件的码

$$\epsilon \leq \sum_{t=0}^{n} \binom{n}{t} \delta^t (1-\delta)^{n-t} 2^{-|n-t-k+1|^+}. \tag{IV.2}$$

(d) 修正 $n = 500$，$\delta = 1/2$。计算使得 (IV.1) 右侧大于10^{-3} 的最小 k。

(e) 修复 $n = 500$，$\delta = 1/2$。找到最大的 k，使得 (IV.2) 的右侧小于 10^{-3}。

(f) 将你的结果表示为 $\log M^*(500, 10^{-3})$ 的下界和上界。

IV.5 回忆一下，在DT界（定理18.6）的证明中，我们使用的解码器（对于给定的信道输出y）会输出第一个满足以下条件的c_m:

$$\{i(c_m; y) > \log \beta\}\,. \tag{IV.3}$$

可以考虑以下推广。固定 $E \subset \mathcal{X} \times \mathcal{Y}$，并让解码器输出满足以下条件的第一个 c_m

$$(c_m, y) \in E$$

通过重复随机编码证明步骤（如DT界中所示），证明平均错误概率满足

$$\mathbb{E}[P_e] \le \mathbb{P}[(X,Y) \notin E] + \frac{M-1}{2}\mathbb{P}[(\bar{X},Y) \in E]\,,$$

其中

$$P_{XY\bar{X}}(a,b,\bar{a}) = P_X(a)P_{Y|X}(b|a)P_X(\bar{a})\,.$$

得出结论：最优的 E 由 (IV.3) 与 $\beta = \frac{M-1}{2}$ 给出。

IV.6 在第18.6节中，我们展示了对于加性噪声，随机线性码能够达到与香农集合（完全随机编码）相同的性能。所有可能的生成矩阵总数为 q^{nk}，这虽然远小于双指数级，但仍相当庞大。现在，我们证明在不降低性能的前提下，通过限制为 *Toeplitz* 生成矩阵 G，即对所有 $i, j > 1$，有 $G_{ij} = G_{i-1,j-1}$，我们可以将此数量减少至 q^n。

证明定理18.13的以下加强版本：设$P_{Y|X}$为$\mathbb{F}_q^n$上的加性噪声。对于任意$1 \le k \le n$，存在一个线性码f: $\mathbb{F}_q^k \to \mathbb{F}_q^n$，其生成矩阵为*Toeplitz*，使得

$$P_{e,\max} = P_e \le \mathbb{E}\left[q^{-\left(n-k-\log_q \frac{1}{P_{Z^n}(Z^n)}\right)^+}\right]$$

有多少个Toeplitz生成矩阵?

Hint: 类似于定理15.2的证明，首先考虑随机线性码字加上随机抖动，然后论证抖动可以在不改变码性能的情况下被移除。证明码字是两两独立且均匀的。

IV.7（Wozencraft 集合）设 $\mathcal{X} = \mathcal{Y} = \mathbb{F}_q^2$，一个在具有 q 个元素的伽罗瓦域上的二维向量空间。码率为 1/2 的 Wozencraft 码是由 $0 \neq u \in \mathbb{F}_q$ 参数化的映射，表示为 $a \mapsto (a, a \cdot u)$，其中 $a \in \mathbb{F}_q$ 对应于原始消息，乘法在 $\mathbb{F}_q$ 上进行，且 $(\cdot,\cdot)$ 表示 $\mathbb{F}_q^2$ 中的一个二维向量。我们将证明存在 u 产生一个 $(q, \epsilon)_{avg}$ 码，其

$$\epsilon \le \mathbb{E}\left[\exp\left\{-\left|i(X;Y) - \log\frac{q^2}{2(q-1)}\right|^+\right\}\right] \tag{IV.4}$$

对于信道 $Y = X + Z$，其中 X 在 $\mathbb{F}_q^2$ 上均匀分布，噪声 $Z \in \mathbb{F}_q^2$ 具有分布 P_Z，并且

$$i(a;b) \triangleq \log \frac{P_Z(b-a)}{q^{-2}}\,.$$

(a) 证明编码 $a \mapsto (av, au) + h$ 的错误概率与 $a \mapsto (a, auv^{-1})$ 相同。

(b) 令 $\{X_a, a \in \mathbb{F}_q\}$ 为一个随机码本，定义为

$$X_a = (aV, aU) + H\,,$$

其中 V, U 在 $\mathbb{F}_q$ 的非零元素上均匀分布，H 在 $\mathbb{F}_q^2$ 上均匀分布，且三者相互独立。证明对于 $a \neq a'$，我们有

$$P_{X_a, X_a'}(x_1^2, \tilde{x}_1^2) = \frac{1}{q^2(q-1)^2} 1\{x_1 \neq \tilde{x}_1, x_2 \neq \tilde{x}_2\}.$$

(c) 证明对于 $a \neq a'$

$$\begin{aligned}\mathbb{P}[i(X_a'; X_a + Z) > \log\beta] &\leq \frac{q^2}{(q-1)^2}\mathbb{P}[i(\bar{X}; Y) > \log\beta] - \frac{1}{(q-1)^2}\mathbb{P}[i(X;Y) > \log\beta] \\ &\leq \frac{q^2}{(q-1)^2}\mathbb{P}[i(\bar{X}; Y) > \log\beta]\,,\end{aligned}$$

其中 $P_{\bar{X}XY}(\bar{a}, a, b) = \frac{1}{q^2} P_Z(b-a)$。

(d) 按照 DT 界的证明，以 $M = q$ 得出结论：在随机码本 $\{X_a\}$ 上平均的错误概率满足 (IV.4)。

IV.8（通用码）固定有限字母表 $\mathcal{X}$ 和 $\mathcal{Y}$。

a 设 $\mathcal{C}$ 为一有限信道集合 $P_{Y|X}$：$\mathcal{X} \to \mathcal{Y}$。证明对于任意 P_X 和任意 $R > 0$，存在一列编码 (f_n, g_n) 使得无论选择哪个 DMC $P_{Y|X} \in \mathcal{C}$，只要 $I(P_X, P_{Y|X}) > R$，我们都有 $\mathbb{P}[f_n(W) \neq g_n(Y^n)] \to 0$。（提示：对 $\mathcal{C}$ 取并集界）

b 将该思想推广以证明存在 (f_n, g_n) 使得对于具有 $I(P_X, P_{Y|X} > R$ 的 *any* DMC，我们有 $\mathbb{P}[f_n(W) \neq g_n(Y^n)] \to 0$。（提示：离散化 $\mathcal{X} \times \mathcal{Y}$ 随机矩阵的集合）

IV.9（信息密度与类型。）设 $P_{Y|X}$：$\mathcal{A} \to \mathcal{B}$ 为一个 DMC，并设 P_X 为某个输入分布。取 $P_{X^nY^n} = P_{XY}^n$ 并针对该 $P_{X^nY^n}$ 定义 $i(a^n; b^n)$。

(a) 证明 $i(x^n; y^n)$ 仅是 (x^n, y^n) 的“联合类型” $\hat{P}_{XY}$ 的函数，其中 $\hat{P}_{XY}$ 是定义在 $\mathcal{A} \times \mathcal{B}$ 上的一个分布，定义为

$$\hat{P}_{XY}(a,b) = \frac{1}{n}\#\{i : x_i = a, y_i = b\}\,,$$

其中 $a \in \mathcal{A}$ 和 $b \in \mathcal{B}$。因此，在香农随机编码界中使用的解码器（18.10）里，形式为 $\{\frac{1}{n} i(x^n; y^n) \geq \gamma\}$ 的条件可以解释为对 (x^n, y^n) 的联合类型的约束。

(b) 假设输入 x^n 满足 $\hat{P}_X = P_X$。证明

$$\frac{1}{n} i(x^n; y^n) \leq I(\hat{P}_X, \hat{P}_{Y|X})\,.$$

数量 $I(\hat{P}_X, \hat{P}_{Y|X})$，有时写作 $I(x^n \wedge y^n)$，是一个 *empirical mutual informa- tion*。[6] 提示：

$$\mathbb{E}_{Q_{XY}}\left[\log \frac{P_{Y|X}(Y|X)}{P_Y(Y)}\right] = D(Q_{Y|X}\|Q_Y|Q_X) + D(Q_Y\|P_Y) - D(Q_{Y|X}\|P_{Y|X}|Q_X).$$

IV.10（Fitingof-Goppa通用码）考虑一个有限阿贝尔群 $\mathcal{X}$。定义 *Fitingof norm* 为

$$\|x^n\|_\Phi \triangleq nH(\hat{P}_{x^n}) = nH(x_T), \quad T \sim \mathrm{Unif}([n])\,,$$

其中 $\hat{P}_{x^n}$ 是 x^n 的经验分布。

(a) 证明 $\|x^n\|_\Phi = \|-x^n\|_\Phi$ 和三角不等式

$$\|x^n - y^n\|_\Phi \le \|x^n\|_\Phi + \|y^n\|_\Phi$$

得出$d_\Phi(x^n, y^n) \triangleq \|x^n - y^n\|_\Phi$是$\mathcal{X}^n$中等价类集合上的平移不变（Fitingof）度量，其中等价关系$x^n \sim y^n \iff \|x^n - y^n\|_\Phi =$为0。

(b) 定义 Fitingof 球 $B_r(x^n) \triangleq \{y^n\colon\ d_\Phi(x^n, y^n) \le r\}$。证明

$$\log |B_{\lambda n}(x^n)| = \lambda n + O(\log n)$$

对于所有 $0 \le \lambda \le \log |\mathcal{X}|$。

(c) 证明对于 $\mathcal{X}^n$ 上的任意乘积测度 $P_{Z^n} = P_Z^n$，我们有

$$\lim_{n\to\infty} P_{Z^n}[B_{\lambda n}(0^n)] = \begin{cases} 1, & H(Z) < \lambda \\ 0, & H(Z) > \lambda \end{cases}$$

(得出)码$\mathcal{C} \subset \mathcal{X}^n$在菲廷戈夫最小距离$d_{min,\Phi}(\mathcal{C}) \triangleq \min_{c\neq c'\in\mathcal{C}} d_\Phi(c, c') \ge 2^{\wedge}\lambda n$时，只要$H(Z) < \lambda$，就能够以消失的错误概率*on any additive-noise channel* $Y = X + Z$进行解码。

Comment: 通过类似Feinstein引理的论证可以证明，存在大小为$\mathcal{X}^{n(1-\lambda)}$的码，使得以码字为中心、半径为$\lambda n$的球几乎不相交。这样的码对于$\mathcal{X}$上的所有无记忆加性噪声信道都是普遍可达容量的。通过引入$d_\Phi(x^n, y^n) = nH(x_T|y_T)$可推广到一般（非加性）信道，而通过引入马尔可夫型范数$\|x^n\|_{\Phi_1} = nH(x_T|x_{T-1})$可推广到具有马尔可夫记忆的信道。参见[196, 第3章]。

IV.11 一位魔术师正在舞台上表演纸牌魔术。每一轮，他取出一副洗好的52张牌，请某人从牌堆中随机抽取一张牌 N，随后向观众展示。假设魔术师可以（在每轮之前）任意安排牌堆中卡片的顺序，并且 N 服从 $\{0, \ldots, 51\}$ 上的二项分布，均值为 $\frac{51}{2}$。

(a) 在无限多轮的极限情况下，他最多能向房间里的同伴发送多少个*bits per round*?

[6] Invented by V. Goppa for his maximal mutual information (MMI) decoder [195]: $\hat{W} = \mathrm{argmax}_i\, I(c_i \wedge y^n)$.

(如果N在$\{0,\dots,51\}$上均匀分布，通信是否可能？（然而，在实践中，没有人会选择最顶端或最底端的。）

IV.12（有记忆信道）考虑阶为2的$\mathcal{A}=\mathcal{B}=\mathbb{F}_2$ (伽罗瓦域)和$P_{Y^n|X^n}$：$\mathbb{F}_2^n\to\mathbb{F}_2^n$所指定的加性噪声信道，其规定为

$$Y^n = X^n + Z^n\,,$$

其中$Z^n=(Z_1,\dots,Z_n)$是一个平稳马尔可夫链，其转移概率矩阵为$P_{Z_2|Z_1}(0|1)=P_{Z_2|Z_1}(1|0)=\tau$。证明信息稳定性并求出容量。（提示：你的证明应对任意平稳遍历噪声过程$Z^\infty=(Z_1,\dots)$都成立。）线性码能否达到该容量?

IV.13 考虑一个DMC $P_{Y^n|X^n}=P_{Y|X}^n$，其中单字母$P_{Y|X}:\mathcal{A}\to\mathcal{B}$由$\mathcal{A}=\mathcal{B}=\{0,1\}^7$给出，并且

$$P_{Y|X}(\mathbf{y}|\mathbf{x})=\begin{cases}1-p & \mathbf{y}=\mathbf{x}\\ p/7 & d_H(\mathbf{y},\mathbf{x})=1\end{cases}$$

其中d_H表示汉明距离。换句话说，对于每个7位字符串，信道要么保持原样，要么随机翻转恰好一个比特。

(a) 计算香农容量C作为p的函数并绘图。

(b) 考虑$p=\frac{7}{8}$的特殊情况。证明零误差容量C_0与C一致。

此外，C_0可以在块长度$n=1$下实现，并给出一个达到容量的编码。IV.14 找出具有信道矩阵的擦除错误信道（图23.6）的容量。

$$W=\begin{bmatrix}1-2\delta & \delta & \delta\\ \delta & \delta & 1-2\delta\end{bmatrix}$$

其中$0\le\delta\le 1/2$。

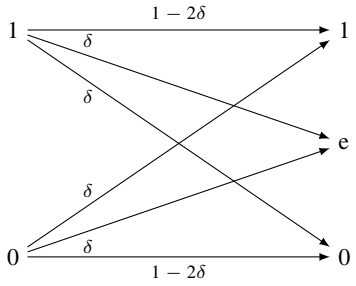


图23.6 二进制擦除错误信道。

IV.15（重排序的容量）路由器A和B正在建立一个隐蔽通信信道，其中数据通过数据包的排序进行编码。形式上，路由器A接收n个数据包，每个数据包具有两种类型之一，Ack或Data，其概率分别为p和$1-p$（并且是独立同分布的）。它通过重新排序这些数据包来编码k比特的秘密数据。A和B之间的网络按顺序传递数据包，丢包率为δ。（注意：数据包具有序列号，因此每次丢包都能被B检测到）。

可实现渐近可靠通信的最大速率是多少?

IV.16（信道之和）设 W_1 和 W_2 分别表示容量为 C_1 和 C_2 的离散无记忆信道（DMC）$P_{Y_1|X_1}$ 和 $P_{Y_2|X_2}$ 的信道矩阵。这两个信道之和是另一个信道矩阵为 $\left[\begin{smallmatrix} W_1 & 0 \\ 0 & W_2 \end{smallmatrix}\right]$ 的 DMC。证明和信道的容量由下式给出

$$C = \log(\exp(C_1) + \exp(C_2)).$$

IV.17（信道乘积）对于 $i = 1, 2$，设 $P_{Y_i|X_i}$ 为一个（平稳无记忆）信道，其输入空间为 $\mathcal{A}_i$，输出空间为 $\mathcal{B}_i$，容量为 C_i。它们的乘积信道是一个输入空间为 $\mathcal{A}_1 \times \mathcal{A}_2$、输出空间为 $\mathcal{B}_1 \times \mathcal{B}_2$、转移核为 $P_{Y_1Y_2|X_1X_2} = P_{Y_1|X_1}P_{Y_2|X_2}$ 的信道。证明乘积信道的容量由 $C = C_1 + C_2$ 给出。

IV.18（DMC的混合）考虑两个DMC $U_{Y|X}$和$V_{Y|X}$，它们具有共同的容量达到输入分布和容量 $C_U < C_V$。设$T = \{0, 1\}$为均匀分布，并考虑一个信道$P_{Y^n|X^n}$，如果$T =$为0则使用U，如果$T =$为1则使用V，或者更正式地:

$$P_{Y^n|X^n}(y^n|x^n) = \frac{1}{2}U^n_{Y|X}(y^n|x^n) + \frac{1}{2}V^n_{Y|X}(y^n|x^n)\,. \tag{IV.5}$$

显示:

(a) 该信道$\{P_{Y^n|X^n}\}_{n\geq 1}$是平稳的吗? 无记忆的吗? (b) 证明该信道的香农容量C不大于C_U。(c) 最大互信息速率是

$$C^{(I)} = \lim_{n\to\infty}\frac{1}{n}\sup_{X^n} I(X^n; Y^n) = \frac{C_U + C_V}{2}$$

(d) 得出结论，$C < C^{(I)}$ 和强逆不成立。 old.

IV.19（复合 DMC [59]）复合 DMC 是一类具有共同输入和输出字母表 $P_{Y_s|X} : \mathcal{A} \to \mathcal{B}, s \in \mathcal{S}$ 的 DMC。一个（n, M, ϵ）码是一个编码器-解码器对，其在族中任意信道 $P_{Y_s|X}$ 上的错误概率为 $\leq \epsilon$（注意，对于每个 $s \in \mathcal{S}$ 使用相同的编码器和相同的解码器）。证明容量由下式给出

$$C = \sup_{P_X}\inf_s I(X; Y_s)\,.$$

然而，化合物DMC的分散更为微妙[342]。

IV.20 考虑以下（无记忆）信道。它有一个侧边开关 U，可以处于位置 ON 和 OFF。如果 U 开启，则从 X 到 Y 的信道是 BSC_δ；如果 U 关闭，则无论 X 如何，Y 都是伯努利(1/2)。接收方能看到 Y 但看不到 U。一个设计约束是 U 处于 ON 位置的时间不应超过所有信道使用次数的比例 s，$0 \leq s \leq 1$。

(a) 一种策略是在前 sn 个时间单位内将 U 放入 ON 中，并忽略 Y 的其余 $(1-s)n$ 个读数。使用这种策略可达到的最大速率（以每信道使用比特数为单位）是多少? (b) 如果允许编码器在满足 U) 上的 s 约束的同时，将 U 开关与输入 X (一起调制，我们能否提高通信速率?

(c) 现在假设没有人能够访问 U，它与 X 独立且服从 iid Ber(s)。求容量。

IV.21 Alice 有 n 个橙子和极多（本质上是无限）的空托盘。她想通过在（按顺序编号的）托盘中放置橙子来向 Bob 传达一条消息，每个托盘最多放一个橙子。不幸的是，在 Bob 看到这些托盘之前，Eve 检查了它们，并以概率 $0 < \delta < 1$ 独立地吃掉每个橙子。在 $n \to \infty$ 的极限下，证明可以实现任意高的速率（以每橙子比特数计）。

证明如果 Eve 从不吃任何橘子，但以概率 δ (iid) 将橘子放入每个空托盘中，则容量变为每个橘子 $\log_2 \frac{1}{\delta}$ 比特。

IV.22（非平稳信道 [106，问题 9.12]）一列火车以恒定速度驶出车站。因此，接收信号能量随时间以$1/i^2$衰减。在时间i接收到的总信号为

$$Y_i = \left(\frac{1}{i}\right) X_i + Z_i,$$

其中 $Z_1, Z_2, \ldots \overset{\text{i.i.d.}}{\sim} N(0, \sigma^2)$。对于块长度 n，发射机成本约束为 $\sum_i^n |x_i^2| \le nP$。证明该信道的容量 C 等于零。

IV.23（边界处的容量-成本函数。）回忆推论20.5，我们已经证明对于平稳无记忆信道，$P > P_0$容量等于$f(P)$：

$$C(P) = f(P)\,, \tag{IV.6}$$

其中

$$P_0 \triangleq \inf_{x \in \mathcal{A}} \mathsf{c}(x) \tag{IV.7}$$

$$f(P) \triangleq \sup_{X:\mathbb{E}[c(X)] \le P} I(X;Y)\,. \tag{IV.8}$$

显示：

(a) 如果 P_0 不可接受，即对所有 $x \in \mathcal{A}$ 都有 $c(x) > P_0$，那么 $C(P_0)$ 是未定义的（甚至 $M = 1$ 也不可能）

(b) 如果存在唯一的 x_0 使得 $\mathsf{c}(x_0) = P_0$ 成立，那么

$$C(P_0) = f(P_0) = 0\,.$$

(c) 如果有多个 x 且其 $\mathsf{c}(x) = P_0$ 满足条件，那么我们仍然有

$$C(P_0) = f(P_0)\,.$$

(d) 给出一个在$P = P_0$处$C(P)$不连续的通道示例。（提示：为通道$Y = (-1)^Z \cdot \mathrm{sign}(X)$ 选择一个合适的成本函数，其中Z是伯努利分布，且sign：$\mathbb{R} \to \{-1, 0, 1\}$。）

IV.24 考虑一个平稳无记忆加性 *non-Gaussian* 噪声信道：

$$Y_i = X_i + Z_i\,, \qquad \mathbb{E}[Z_i] = 0, \quad \mathrm{Var}[Z_i] = 1$$

在标准输入约束 $\sum_{i=1}^n x_i^2 \le nP$ 下。

(a) 证明该信道的容量 $C(P)$ 满足 (20.6)。（提示：高斯鞍点定理 5.11 和黄金公式 $I(X;Y) \le D(P_{Y|X}\|Q_Y|P_X)$。）

(如果 $D(P_Z\|\mathcal{N}(0,1)) = \infty$ (Z 非常非高斯)，那么容量可能是无限的。考虑 Z 以等概率为 ± 1。通过以下方式证明容量是无限的：a) 证明最大互信息是无限的；b) 给出一个显式方案来实现无限容量。

IV.25（输入-输出成本）设 $P_{Y|X}: \mathcal{X} \to \mathcal{Y}$ 为一个 DMC，并考虑成本函数 $\mathsf{c}: \mathcal{X} \times \mathcal{Y} \to \mathbb{R}$ (，注意对于某个 L) 有 $\mathsf{c}(x,y) \le L < \infty$。考虑一个信道编码问题，其中错误事件定义为

$$\{\text{error}\} \triangleq \{\hat{W} \neq W\} \cup \left\{ \sum_{k=1}^{n} \mathsf{c}(X_k, Y_k) > nP \right\},$$

其中 P 是一个固定参数。定义运行容量 $C(P)$，并证明它由下式给出

$$C^{(I)}(P) = \max_{P_X: \mathbb{E}[\mathsf{c}(X,Y)] \le P} I(X;Y)$$

对于所有 $P > P_0 \triangleq$ 的最小值 $_{x_0} \mathbb{E}[\mathsf{c}(X,Y)|X = x_0]$。给 $P = P_0$ 提供一个反例。（提示：直接进行逆向操作，并且对于可达性，简化为适当选择的成本函数 $\mathsf{c}'(x)$）。

IV.26（高斯-马尔可夫噪声）设 $\{Z_j, j = 1, 2, \ldots\}$ 是一个平稳遍历高斯过程，方差为 1，使得 Z_j 构成一个马尔可夫链 $Z_1 \to \ldots \to Z_n \to \ldots$。考虑一个加性信道：

$$Y^n = X^n + Z^n$$

在功率约束 $\sum_{j=1}^{n} |x_j|^2 \le nP$ 下。假设 $I(Z_1;\ Z_2) = \epsilon \ll$ 为 1，则容量-成本函数

$$C(P) = \frac{1}{2}\log(1+P) + B\epsilon + o(\epsilon)$$

as $\epsilon \to 0$。计算 B 并解释你的答案。

随着ϵ的增加，最优信号的频谱如何变化?

IV.27 一家半导体公司提供了一种随机数生成器，它输出一块随机的 n 比特 $Y_1, \ldots, Y_n$。该公司想要在每个芯片中秘密嵌入一个签名。为此，它决定将 k 比特的签名编码为 n 个实数 $X_j \in [0,1]$。给定一个单独的签名，芯片的制造使其产生输出 $Y_j \sim \text{Ber}(X_j)$。为了使嵌入不显眼，平均偏差 p 应该很小：

$$\frac{1}{n}\sum_{j=1}^{n} \left| X_j - \frac{1}{2} \right| \le p\,.$$

作为 p 的函数，以这种方式每个输出（k/n）可以可靠嵌入多少个签名字节？是否存在一个简单的编码方案能达到这种性能?

IV.28（打喷嚏的容量）一个生病的学生每分钟以概率p (iid)想要打喷嚏。他决定通过调制喷嚏来向朋友发送k比特。为此，每当他意识到自己即将打喷嚏时，他选择抑制或不抑制。一个朋友听了n分钟，然后尝试解码k比特。

(a) 求每分钟的容量（以比特为单位）。（提示：思考如何定义信道，使得在时间t的信道输入不依赖于时间t打喷嚏的到来。为了排除依赖于过去喷嚏到来的策略，你可以引用练习IV.34。）

(b) 假设发送方最多能抑制 E 个喷嚏，而接收方可以无限期等待（$n = \infty$）。证明发送方能够以 $E \to \infty$ 的形式可靠地传输 $C_{puc}E + o(E)$ 比特，并求出单位成本容量 C_{puc}。奇怪的是，无论 p 如何，$C_{puc} \geq 1.44$ 比特/喷嚏。（提示：这与练习 IV.25 类似。）

(d*) 对于一位能预知未来喷嚏何时发生的预言学生，重做(a)和(b)。（这是所谓的Gelfand-Pinsker问题[183]的一个简单示例。）

IV.29 一家数据存储公司正在考虑将其100 Tb档案从波士顿发送到纽约的两种方案：通过（物理）邮件或通过无线传输。让我们分析这些选项：

(a) 给定辐射功率 P_t，在距离 r 处，以频率 f 通信时的接收功率 P_r 由 $P_r = G\left(\frac{c}{4\pi rf}\right)^2 P_t$ 给出，其中 G 是天线到天线的耦合增益，c – 光速 [7]。假设在波士顿和纽约之间传输，计算能量传输系数 η (，取 $G = 15$ dB 和 $f = 4$ GHz)。(b) 接收器的放大器添加功率谱密度为 N_0 (W/Hz 或 J) 的白高斯噪声。基于每比特所需能量，计算仍能使无线电传输在经济上合理的最小 N_0，假设进行了最优信道编码（假设每千瓦时0 .07 美元，每次运输20美元）。(c) 将此 N_0 与热噪声功率 $N_{0,thermal} = kT$ 进行比较，其中 k – 玻尔兹曼常数，T – 以开尔文为单位的温度。得出结论：$T \leq 10^3$ K 应该可行。(d) 原则上达到香农最小 E_b/N_0 的码不对接收器SNR（一个信道样本中的信噪比）施加限制，然而同步和其他问题将此SNR限制为 ≥ -10 dB。假设通信带宽为 $B = 20$ Mhz，计算发射器无线电所需的最小功率（以W为单位）。(提示：接收SNR = $\frac{P_r}{BN_0}$，答案应该是几瓦）。(e) 在此带宽和SNR下发送归档需要多长时间？(提示：答案在几天到几年之间）。

IV.30（ARQ 下的最优 ϵ）一个包含 k 比特的数据包需通过具有给定 SNR 的 AWGN 信道传输。为此，使用一个 k 到 n 的纠错码，其错误概率为 ϵ。该系统采用自动重传请求（ARQ）在每次发生错误时重发该数据包。[8] 假设达到以下条件的最优 k 到 n 码

$$k \approx nC - \sqrt{nV}Q^{-1}(\epsilon) + \frac{1}{2}\log n$$

[7] This formula is known as Friis transmission equation and it simply reflects the fact that the receiving antenna captures a plane wave at the effective area of $\frac{\lambda^2}{4\pi}$.

[8] Assuming there is a way for receiver to verify whether his decoder produced the correct packet contents or not (e.g. by finding HTML tags).

可用。目标是优化 ϵ 以获得最高的平均吞吐量：ϵ 过小需要过多的冗余，ϵ 过大会导致大量重传。计算以下四种情况下的最优 ϵ 和最优块长度 n：SNR=0 dB 或 20 dB；$k = 10^3$ 或 10^4 比特。

（这给出了一个关于在实践中你应该以什么样的ϵ为目标的概念。）

IV.31（删减随机编码界）

(a) 对于任何代码 $\mathcal{C}$，展示以下错误概率的界限

$$P_e(\mathcal{C}) \le \frac{1}{M}\sum_{c\neq c'} 2^{-d_B(c,c')}\,,$$

其中回忆（16.3）中的巴塔查里亚距离 $d_B(x^n,\tilde{x}^n) = \sum_{j=1}^n d_B(x_j,\tilde{x}_j)$ 和

$$d_B(x,\tilde{x}) = -\log_2 \sum_{y\in\mathcal{Y}} \sqrt{W(y|x)W(y|\tilde{x})}\,.$$

(b) 固定 P_X，令 $E_{0,x}(\rho,P_X) \triangleq -\rho\log_2 \mathbb{E}[2^{-\frac{1}{\rho}d_B(X,X')}]$，其中 $X \perp\!\!\!\perp X' \sim P_X$。通过随机编码证明，总存在一个码率为 R 的码 $\mathcal{C}$，满足

$$P_e(\mathcal{C}) \le 2^{n(E_{0,x}(1,P_X)-R)}\,.$$

(c) 我们按如下方式改进先前界限。仍通过随机编码生成 $\mathcal{C}$。但这次我们剔除所有满足 $f(c,\mathcal{C}) > \text{med}(f(c,\mathcal{C}))$ 的码字，其中 $\text{med}(\cdot)$ 表示中位数且 $f(c) = \sum_{c'\neq c} 2^{-d_B(c,c')}$。利用该界限

$$\text{med}(V) \le 2^{\rho}\,\mathbb{E}[V^{1/\rho}]^{\rho} \qquad \forall \rho \ge 1$$

证明

$$\text{med}(f(c,\mathcal{C})) \le 2^{n(\rho R - E_{0,x}(\rho,P_X))}\,.$$

(d) 得出结论，必定存在一个码率 $R - O(1/n)$ 和 $P_e(\mathcal{C}) \le 2^{-nE_{ex}(R)}$ 的码，其中

$$E_{ex}(R) \triangleq \max_{\rho\ge 1} -\rho R + \max_{P_X} E_{0,x}(\rho,P_X)\,.$$

IV.32（BSC 的强逆定理）在本练习中，我们给出二进制对称信道的强逆定理的组合证明。对于 BSC_δ，其中 $0 < \delta < \frac{1}{2}$，

(a) 给定任何 $(n,M,\epsilon)_{\max}$-码，具有确定性编码器 f 和解码器 g，回忆解码区域 $\{D_i = g^{-1}(i)\}_{i=1}^M$ 构成输出空间的一个划分。证明对于所有 $i \in [M]$，

$$|D_i| \ge \sum_{j=0}^{L}\binom{n}{j}$$

其中 L 是使得 $\mathbb{P}[\text{二项式}(n,\delta) \le L] \le 1-\epsilon$ 成立的最大整数。

(b) 得出结论

$$M \le 2^{n(1-h(\delta))+o(n)}. \tag{IV.9}$$

(c) 证明(IV.9)对于平均错误概率成立。（提示：如何从最大错误概率推导到平均错误概率？）（d）得出结论，强逆定理对于BSC成立。（提示：论证要求确定性编码器/解码器不会改变渐近性。）

IV.33（AWGN 的强逆定理）回想一下，AWGN 信道由下式指定

$$Y^n = X^n + Z^n\,, \qquad Z^n \sim \mathcal{N}(0, I_n)\,, \quad \mathsf{c}(x^n) = \frac{1}{n}\|x^n\|^2$$

通过以下步骤证明AWGN的强逆定理：

(a) 令 $c_i = f(i)$ 和 $D_i = g^{-1}(i), i = 1, \ldots, M$ 为 $(n, M, P, \epsilon)_{max}$ 码的码字和解码区域。令

$$Q_{Y^n} = \mathcal{N}(0, (1+P)I_n)\,.$$

证明必须存在一个码字 c 和一个解码区域 D，使得

$$P_{Y^n|X^n=c}[D] \geq 1 - \epsilon \tag{IV.10}$$

$$Q_{Y^n}[D] \leq \frac{1}{M}\,. \tag{IV.11}$$

(b) 证明那么

$$\beta_{1-\epsilon}(P_{Y^n|X^n=c}, Q_{Y^n}) \leq \frac{1}{M}\,. \tag{IV.12}$$

(c) 展示该假设检验问题

$$P_{Y^n|X^n=c} \quad \text{vs} \quad Q_{Y^n}$$

等价于

$$P_{Y^n|X^n=Uc} \quad \text{vs} \quad Q_{Y^n}$$

其中 $U \in \mathbb{R}^{n\times n}$ 是一个正交矩阵。（提示：利用白高斯分布的球对称性。）

(d) 选择 U 使得

$$P_{Y^n|X^n=Uc} = P^n\,,$$

where P^n是均值的独立同分布高斯分布，该均值取决于o n $\|c\|2$.

(e) 应用斯坦引理（定理14.14）证明对于某个值$E = E(P) > 0$，我们有

$$\beta_{1-\epsilon}(P_{Y^n|X^n=c}, Q_{Y^n}) = \exp\{-nE + o(n)\}$$

(f) 通过 (IV.12) 得出

$$\log M \leq nE + o(n) \quad \Longrightarrow \quad C_\epsilon \leq \frac{1}{2}\log(1+P)\,.$$

IV.34 考虑一个具有两个输出 $P_{Y,U|X}$ 的DMC。假设接收器仅观测到 Y，而 U（因果地）反馈给发送器。我们知道，当 $Y = U$ 时，容量并未增加。

(a) 证明容量一般不会增加（即使当$Y \neq U$时）。
(b) 假设现在有一个成本函数 c 和 $\mathsf{c}(x_0) = 0$。证明单位成本容量（其中 U 被反馈）仍然由下式给出

$$C_V = \max_{x \neq x_0} \frac{D(P_{Y|X=x} \| P_{Y|X=x_0})}{\mathsf{c}(x)}$$

IV.35 考虑一个交叉概率为$\delta \in (0, 1)$的二进制对称信道：

$$Y = X + Z \mod 2, Z \sim \mathrm{Ber}(\delta).$$

假设除了Y之外，接收方还通过一个擦除概率为$\delta_e \in (0, 1)$的二元擦除信道观察到噪声Z。计算：

(a) 信道容量 C。(b) 信道的零错误容量 C_0。(c) 存在反馈时的零错误容量 $C_{fb,0}$。

(d*) 现在考虑除了反馈外，还允许带有反馈和终止的可变长度通信(VLFT)的设置。在这种情况下，零错误容量（以平均信道使用次数为单位，比特）是多少？（在VLFT模型中，发射器可以发送一个特殊符号T，该符号无误差接收，但发送T后信道失效；参见第23.3.2节）

IV.36 考虑备注23.2中讨论的*polygon channel*，其中输入和输出字母表均为$\{1, \ldots, L\}$，且$P_{Y|X}(b|a) >$为0当且仅当$b = a$或$b = (a$模$L) +$为1。混淆图是一个包含L个顶点的*cycle*。*Rigorously*证明以下内容：

(a) 对于所有 L，带反馈的零错误容量为 $C_{fb,0} = \log \frac{L}{2}$。(b) 对于偶数 L，无反馈的零错误容量为 $C_0 = \log \frac{L}{2}$。
(c) 现在考虑以下信道，其中输入和输出字母表均为 $\{1, \ldots, L\}$，且 $P_{Y|X}(b|a) > 0$ 当且仅当 $b = a$ 或 $b = a+1$。在这种情况下，混淆图是 L 个顶点的 *path*。证明零错误容量由下式给出

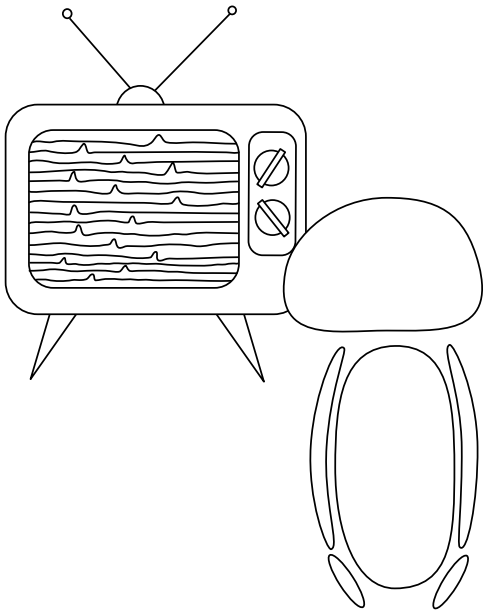
$$C_0 = \log \left\lceil \frac{L}{2} \right\rceil$$

什么是$C_{fb,0}$?

IV.37（带反馈的BEC）考虑具有擦除概率δ和无噪声反馈的平稳无记忆二进制擦除信道。设计一个实现容量的*fixed*块长度编码方案，即找到一个方案，在无噪声反馈下通过n次信道使用发送k比特，使得当$n \to \infty$时速率$\frac{k}{n}$趋近于容量$1 - \delta$，且最大错误概率趋于零。还要证明对于任意速率$R < (1 - \delta)$比特，误差指数与球填充界相匹配。

Part V

率失真理论与度量熵



在第二部分中，我们研究了无损数据压缩（源编码），其目标是将一个随机变量（源）X 平均（或精确地）压缩为最少数量的比特，以便使用这些比特可以精确（或以高概率）重建 X。在这两种情况下，基本极限由源的熵 X 给出。显然，这一范式仅限于离散随机变量。

在这一部分中，我们将解决连续随机变量压缩的问题，这被称为*lossy data compression*。给定一个随机变量X，我们需要将其编码为最少数量的比特，使得解码版本$\hat{X}$是X的忠实重构，这严格理解为X和$\hat{X}$之间的*distortion metric*在平均意义上或以高概率被规定的保真度所限制。

研究有损压缩的动机至少有两个方面：

1 许多自然信号（例如音频、图像或视频）是连续取值的。因此，需要使用有限数量的比特来表示这些实值随机变量或过程，这些比特可以馈送给下游数字处理；见图23.7的图示。

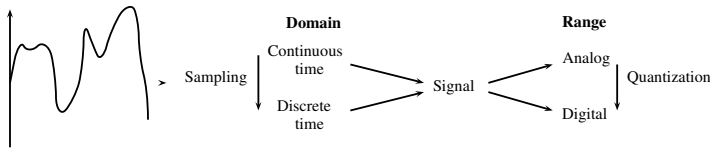


图23.7 工程实践中的采样与量化。

2 如果我们允许一些重建误差，压缩可以获得很多好处。这在某些错误(例如自然音频和视觉信号中的高频成分)对人类来说是不可察觉的应用中尤为重要。这一观察是许多在实践中广泛部署的重要压缩算法和标准的基础，包括用于图像的JPEG、用于视频的MPEG和用于音频的MP3。

将（自然产生的）连续时间/模拟信号映射为（电子设备友好的）离散/数字信号的操作被称为*quantization*，这本身就是信号处理中的一个重要课题（参见百科全书式的综述[197]）。在信息论中，对最优量化的研究被称为*rate-distortion theory*，由香农于1959年提出[380]。首先，我们将在第24.1节中仔细研究量化，然后在第24.2节中给出信息论的表述。第24.3节给出了一个简单（且紧致）的逆定理界，而匹配的可达性界推迟到下一章。

在第25章中，我们展示了率失真定理的困难方向：量化器的随机编码构造。这一方法被扩展用于发展覆盖引理和软覆盖引理，从而引出了Cuff的精确结果，表明信道模拟的基本极限是由Wyner的共信息给出的。我们还推导了（增强形式的）Han-Verdú关于在KL中近似输出分布的结果。

第26章评估了高斯源和汉明源的率失真函数。我们还讨论了最优(有损)压缩器与最优

纠错码共同构成了一种最优的端到端通信方案（称为联合信源信道编码分离原理）。这一原理解释了为什么“比特”是数字时代的自然货币。

最后，在第27章中，我们研究Kolmogorov的*metric entropy*，这是一种针对度量空间中集合的非概率量化理论。传统的率失真理论试图压缩固定分布的样本，而度量熵则试图压缩度量空间中的任何元素。这两个主题之间的联系在于，度量熵可以被视为应用于空间上“最坏情况”分布的率失真理论（这一思想在第27.6节中进一步展开）。除了与前几章中的概率量化理论的联系之外，这一概念在概率论（例如经验过程、小球概率）和统计学习（例如估计的熵上界和下界）中都有深远的影响，这些将在第六部分中进一步探讨。练习部分探讨了在布朗运动（练习V.30）、随机矩阵（练习V.29）等方面的应用。

24 Rate-distortion theory

在本章中，我们介绍最优量化理论。在24.1节中，我们探讨了*fixed dimension and high rate*的经典量化理论，讨论了均匀与非均匀量化、固定速率与可变速率、Lloyd量化算法与聚类以及最优量化误差的渐近性等各个方面。在24.2节中，我们转向量化的信息论表述，即率失真理论，该理论针对*high dimension and fixed rate*以及重构点数随维度指数增长的 regime。24.3节介绍了率失真函数和主要逆界。最后，在24.4*节中，我们讨论了如何将平均失真（我们所关注的）与超额失真联系起来，后者针对的是高概率下的重构误差，而非期望中的误差。

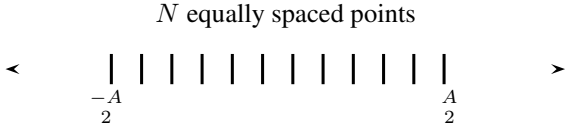
24.1 标量与矢量量化

在进入信息论框架之前，有必要通过介绍一些经典的香农之前关于量化的观点来奠定基础。在本节及各个小节中，我们关注连续信号处于相对低维空间的设定（本节大部分内容仅讨论标量信号）。我们从最基本但最常用的标量均匀量化情形开始。

24.1.1 标量均匀量化

将本质上连续值信号进行量化的思想，在A. Reeves为脉冲编码调制（PCM）申请专利时得到了最为明确的阐述；有关一些有趣的历史注释，参见[355]。他的论点是，与AM和FM调制不同，量化（数字）信号可以沿长路径传输而不会有害地累积噪声。1948年，Oliver、Pierce和Shannon对PCM进行了一些初步的理论分析[318]。

对于随机变量 $X \in [-A/2, A/2] \subset \mathbb{R}$，具有 N 个量化点的标量均匀量化器 $q_U(X)$ 将区间 $[-A/2, A/2]$ 均匀划分

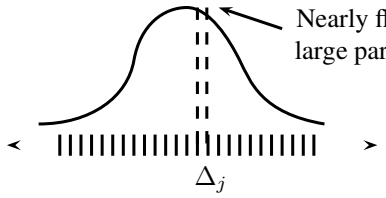


其中点位于 $\{\frac{-A}{2}+\frac{kA}{N}, k=0,\ldots,N-1\}$ 中。

这种量化的*quality* (保真度)是多少？大多数时候，均方误差被用作质量标准:

$$D(N)=\mathbb{E}|X-q_U(X)|^2$$

其中 D 表示 *distortion* 的平均值。通常使用 $R=\log_2 N$ 来代替 N，这样我们考虑的是可用于量化的比特数，而不是点数。为了分析这个标量均匀量化器，我们将考察高比特率情形（$R\gg 1$）。高比特率情形下的关键思想是（假设密度 P_X 是平滑的），每个量化区间 Δ_j 看起来几乎是平坦的，因此在给定 Δ_j 的条件下，该分布可以被均匀分布准确地近似。



设 c_j 为第 j 个量化点，Δ_j 为第 j 个量化区间。这里我们有

$$D_U(R)=\mathbb{E}|X-q_U(X)|^2=\sum_{j=1}^{N}\mathbb{E}[|X-c_j|^2|X\in\Delta_j]\mathbb{P}[X\in\Delta_j] \tag{24.1}$$

$$\text{(high rate approximation)}\quad \approx\sum_{j=1}^{N}\frac{|\Delta_j|^2}{12}\mathbb{P}[X\in\Delta_j] \tag{24.2}$$

$$=\frac{(\frac{A}{N})^2}{12}=\frac{A^2}{12}2^{-2R}, \tag{24.3}$$

其中我们使用了 Unif$(-a,a)$ 的方差为 $a^2/3$ 这一事实。

每比特我们能获得多少收益?

$$\begin{aligned}10\log_{10}SNR&=10\log_{10}\frac{\mathrm{Var}(X)}{\mathbb{E}|X-q_U(X)|^2}\\&=10\log_{10}\frac{12Var(X)}{A^2}+(20\log_{10}2)R\\&=\text{constant}+(6.02dB)R\end{aligned}$$

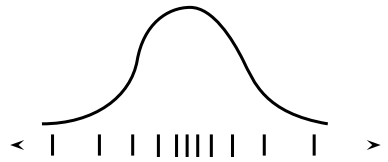
例如，当X在$[-\frac{A}{2},\frac{A}{2}]$上均匀分布时，常数为0。每个工程师都知道“每比特6dB”的经验法则；增加一个量化比特可使信噪比提高6dB。然而，在这里我们可以看到，这一经验法则仅在高码率情况下有效。（因此，诸如“16位PCM（CD质量）提供96dB信噪比”这类广泛流传的说法应持保留态度。）

上述讨论涉及具有有界支撑的 X。当 X 无界时，明智的做法是将量化点分配给更可能出现的那些值，并将大值饱和在

量化器的动态范围，导致量化误差有两种类型的贡献，分别称为颗粒失真和过载失真。这引出了我们的问题：也许均匀量化并非最优?

24.1.2 标量非均匀量化

由于我们的源具有密度 p_X，一个好的想法可能是在 p_X 较大的地方分配更多的量化点，而在 p_X 较小的地方分配更少的量化点，如下图所示:

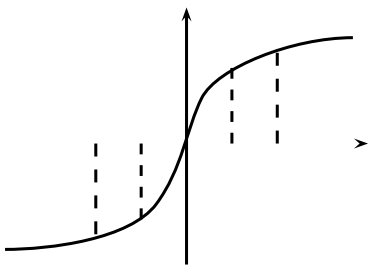


通常，这类量化器的实现方式是对源信号 $f(X)$ 进行单调变换，执行均匀量化，然后取其逆函数:

$$\begin{array}{ccc} X & \xrightarrow{\quad f \quad} & U \\ \vdots q & & \downarrow q_U \\ \hat{X} & \xleftarrow[f^{-1}]{} & q_U(U) \end{array} \tag{24.4}$$

即，$q(X) = f^{-1}(q_U(f(X)))$。函数 f 通常被称为 *compander* (压缩器+扩展器)。f 的一种选择是 X 的CDF，它将 X 映射到 [0, 1] 上的均匀分布。实际上，这种压扩器架构在高码率 regime（精细量化）下是最优的，但最优的 f 不是CDF（！）。我们将这一讨论推迟到第24.1.4节。

在实际考虑方面，例如，人耳能够检测到音量低至0分贝的声音，而痛苦且损伤耳朵的声音大约在140分贝左右。这一能力的实现是因为人耳本质上使用了对数压扩函数。此外，许多自然信号（如语音或音乐中连续样本的*differences*（但不是样本本身！））具有近似拉普拉斯分布。由于这两个因素，对于f，一个非常流行且合理的选择是μ压扩函数。



$$f(X) = \text{符号}(X)\,\frac{\ln(1+\mu|X|)}{\ln(1+\mu)}$$

这压缩了动态范围，对较小的$|X|$使用更多比特，例如在人类听觉范围内的$|X|$，而在这一范围之外则使用较少的量化比特。这导致了所谓的μ律，该律在美国的数字电信系统中得到应用，而在欧洲则使用一种略有不同的压扩器，称为A律。

24.1.3 最优量化器

现在我们寻找在给定R位用于重建时的最优标量量化器。形式化地，这为

$$D_{scalar}(R) = \min_{q:|\mathrm{Im}\ q|\leq 2^R} \mathbb{E}|X - q(X)|^2 \tag{24.5}$$

直观上，我们认为最优量化区域应是连续的；否则，给定点 c_j，我们的重构误差将会更大。因此，在一维情况下，量化器是分段常数：

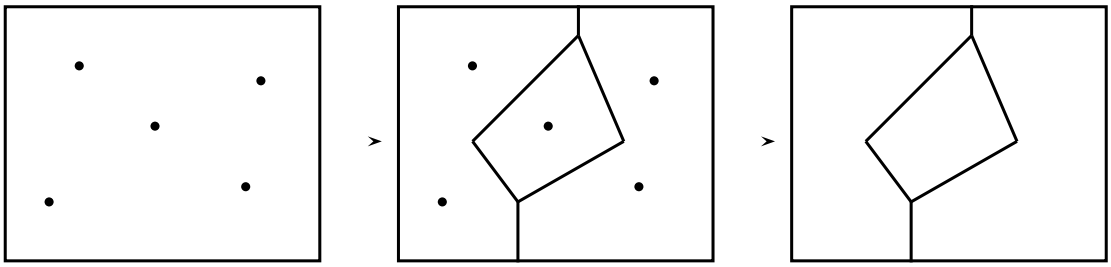
$$q(x) = c_j 1\{T_j \leq x \leq T_{j+1}\}$$

对于某些 $c_j \in [T_j, T_{j+1}]$。

例24.1 作为一个简单的例子，考虑$X \sim \mathcal{N}(0, \sigma^2)$的一比特量化。那么最优量化点是$c_1 = \mathbb{E}[X|X \geq 0] = \mathbb{E}[|X|] = \sqrt{\frac{2}{\pi}}\sigma$, $c_2 = \mathbb{E}[X|X \leq 0] = -\sqrt{\frac{2}{\pi}}\sigma$，量化误差等于Var$(|X|) = \left(1 - \frac{2}{\pi}\right)\sigma^2$。

有了这样的想法，1957年S. Lloyd开发了一种算法（称为*Lloyd's algorithm*或*Lloyd's Method I*），用于迭代寻找最优量化区域和点。[1]该方法适用于标量和向量情况，其过程如下：首先初始化选择$N = 2^k$个量化点，然后算法在以下两个步骤之间迭代：

1 绘制围绕所选量化点的Voronoi区域（即最小距离剖分，或最接近c_j的点集），这构成了空间的一个划分。
2 使用每个Voronoi区域D的质心$\mathbb{E}[X|X \in D]$更新量化点。



劳埃德算法的步骤

[1] This work at Bell Labs remained unpublished until 1982 [284].

Lloyd的巧妙观察是，每个Voronoi区域的质心（通常情况下）与原始量化点不同。因此，通过这一过程反复迭代得到*CentroidalVoronoi Tessellation* (CVT——它们本身就是非常美丽的对象)，可视为该迭代映射的不动点。以下定理给出了Lloyd算法的结果。

定理 24.1（Lloyd）

1 Lloyd's algorithm always converges to a Centroidal Voronoi Tessellation.
2 The optimal quantization strategy is always a CVT.
3 CVT's need not be unique, and the algorithm may converge to non-global optima.

注 24.1 第三点告诉我们，Lloyd 算法并不总能保证给出最优的量化策略。[2] 唯一性 CVT 的一个充分条件是 X 密度的对数凹性 [171]，例如高斯分布。另一方面，即使对于高斯分布 P_X 和 $N > 3$，最优量化点也没有已知的封闭形式。因此，拥有任何有意义的最优量化器理论似乎都非常困难。然而，正如我们接下来将看到的，当 N 变得非常大时，最优量化点的位置可以被刻画。在本节中，我们将在固定维度的情形下这样做，而在本部分的其余部分，我们将考虑让 N 随维度呈指数增长的 regime。

备注 24.2（k-means）一种流行的聚类方法称为 *k-means*，其内容如下：给定 n 个数据点 $x_1, \dots, x_n \in \mathbb{R}^d$，目标是找到 k 个中心 $\mu_1, \dots, \mu_k \in \mathbb{R}^d$ 以最小化目标函数

$$\sum_{i=1}^{n} \min_{j \in [k]} \|x_i - \mu_j\|^2.$$

这等价于求解类似于(24.5)式的最优向量量化问题：

$$\min_{q:|\mathrm{Im}(q)| \le k} \mathbb{E}\|X - q(X)\|^2$$

其中 X 根据数据集中的 *empirical distribution* 分布，即 $\frac{1}{n}\sum_{i=1}^{n} \delta_{x_i}$。在最坏情况下，求解 k-均值问题是 NP-hard 的，而 Lloyd 算法是一种常用的启发式方法。

24.1.4 精细量化

遵循Panter-Dite[324]的研究，我们现在探讨小量化误差的渐近性质。为此，引入一个概率密度函数$\lambda(x)$，它表示量化点的密度。

[2] As a simple example one may consider $P_X = \frac{1}{3}\phi(x-1) + \frac{1}{3}f(x) + \frac{1}{3}f(x+1)$ where $f(\cdot)$ is a very narrow pdf, symmetric around 0. Here the CVT with centers $\pm\frac{2}{3}$ is not optimal among binary quantizers (just compare to any quantizer that quantizes two adjacent spikes to same value).

在给定区间内，并使我们可以通过积分来近似求和。[3] 那么，任何区间 $[a,b]$ 内的量化点数量是 $\approx N\int_a^b \lambda(x)dx$。对于任何点 x，记包含 x 的量化区间大小为 $\Delta(x)$。那么

$$N\int_x^{x+\Delta(x)} \lambda(t)dt \approx N\lambda(x)\Delta(x) \approx 1 \implies \Delta(x) \approx \frac{1}{N\lambda(x)}.$$

通过这种近似，重建的质量为

$$\begin{aligned}\mathbb{E}|X-q(X)|^2 &= \sum_{j=1}^N \mathbb{E}[|X-c_j|^2|X\in\Delta_j]\mathbb{P}[X\in\Delta_j]\\ &\approx \sum_{j=1}^N \mathbb{P}[X\in\Delta_j]\frac{|\Delta_j|^2}{12} \approx \int p(x)\frac{\Delta^2(x)}{12}dx\\ &= \frac{1}{12N^2}\int p(x)\lambda^{-2}(x)dx,\end{aligned}$$

为了找到在 X 具有密度 p 时给出最佳重建（最小MSE）的最优密度 λ，我们使用Hölder不等式：$\int p^{1/3} \le (\int p\lambda^{-2})^{1/3}(\int\lambda)^{2/3}$。因此 $\int p\lambda^{-2} \ge (\int p^{1/3})^3$，等式成立当且仅当 $p\lambda^{-2}\propto\lambda$。因此优化器为 $\lambda^*(x) = \frac{p^{1/3}(x)}{\int p^{1/3}dx}$。因此当 $N=2^R$ 时，[4]

$$D_{scalar}(R) \approx \frac{1}{12}2^{-2R}\left(\int p^{1/3}(x)dx\right)^3$$

因此，在高码率条件下，我们的最优量化器密度与源密度的立方根成正比。这个近似称为 *Panter-Dite approximation*。例如，

- 当$X\in[-\frac{A}{2},\frac{A}{2}]$时，再次利用Hölder不等式$\langle 1, p^{1/3}\rangle \le \|1\|_{\frac{3}{2}}\|p^{1/3}\|_3 = A^{2/3}$，我们得到

  $$D_{scalar}(R) \le \frac{1}{12}2^{-2R}A^2 = D_U(R)$$

  其中右侧是(24.1)中给出的均匀量化误差。因此，只要源分布不均匀，就有严格的改进。对于均匀分布，均匀量化无疑是最优的。

- 当 $X\sim\mathcal{N}(0,\sigma^2)$ 时，这给出

  $$D_{scalar}(R) \approx \sigma^2 2^{-2R}\frac{\pi\sqrt{3}}{2} \tag{24.6}$$

备注24.3 实际上，在*scalar*情形下，最优非均匀量化器可以通过我们在第24.1.2节讨论过的压扩器架构(24.4)来实现：作为练习，使用泰勒

[3] This argument is easy to make rigorous. We only need to define reconstruction points c_j as the solution of $\int_{-\infty}^{c_j}\lambda(x)\,dx = \frac{j}{N}$ (quantile).

[4] In fact when $R\to\infty$, "$\approx$" can be replaced by "$=1+o(1)$" as shown by Zador [467, 468].

扩展以分析 (24.4) 在 $N \to \infty$ 时的量化误差。最优压扩器 $f: \mathbb{R} \to [0,1]$ 结果为 $f(x) = \frac{\int_{-\infty}^{t} p^{1/3}(t)dt}{\int_{-\infty}^{\infty} p^{1/3}(t)dt}$ [44, 395]。

24.1.5 精细量化与可变速率

到目前为止，我们一直关注的是在限制 $q(\cdot)$ 的像的基数下的量化。然而，如果意图进一步无损压缩值 $q(X)$，一个更自然的约束是限定 $H(q(X))$。

Koshelev [253] 在1963年发现，在高码率情况下，均匀量化在熵约束下是渐近最优的。实际上，如果q_Δ是一个单元大小为Δ的均匀量化器，那么在适当的假设下，我们有（回忆(2.21)）

$$H(q_\Delta(X)) = h(X) - \log \Delta + o(1)\,, \tag{24.7}$$

其中 $h(X) = -\int p_X(x) \log p_X(x)\, dx$ 是 X 的微分熵。因此，具有 $H(q(X)) = R$ 的均匀量化器可实现

$$D = \frac{\Delta^2}{12} \approx 2^{-2R} \frac{2^{2h(X)}}{12}\,.$$

另一方面，任何具有未归一化点密度函数 $\Lambda(x)$ (即满足 $\int_{-\infty}^{c_j} \Lambda(x)dx = j$) 的光滑函数的量化器都可以证明达到（假设逐点有 $\Lambda \to \infty$）

$$D \approx \frac{1}{12} \int p_X(x) \frac{1}{\Lambda^2(x)} dx$$
$$H(q(X)) \approx \int p_X(x) \log \frac{\Lambda(x)}{p_X(x)}\, dx.$$

现在，由詹森不等式我们有

$$\frac{1}{12} \int p_X(x) \frac{1}{\Lambda^2(x)} dx \geq \frac{1}{12} \exp\{-2 \int p_X(x) \log \Lambda(x)\, dx\} \approx 2^{-2H(q(X))} \frac{2^{2h(X)}}{12}\,,$$

得出均匀量化器是渐近最优的结论。

此外，对于任何信源而言，即便是最优的矢量量化器（接下来将讨论），也无法实现优于$2^{-2R}\frac{2^{2h(X)}}{2\pi e}$的失真度。这意味着，对于任何独立同分布信源，它们能获得的最大改进仅为1.53分贝（或0.255比特/样本）。这也是为什么在实际应用中，标量均匀量化器配合无损压缩成为极为普遍的解决方案的原因之一。

24.2 信息论表述

在描述最优量化的数学表述之前，让我们先看两个具体的例子。

汉明游戏。给定100个无偏比特，要求我们检查它们并在最多能存储50比特的纸上写下一些东西。之后，我们会要求猜测原始的100个比特，目标是最大化正确猜测的比特数。最佳策略是什么？直观上，最优策略似乎是存储一半的比特，然后对其余的随机猜测，这给出了25%的误比特率（BER）。然而，正如我们将在本章中展示的（定理26.1），最优策略惊人地达到了11%的BER。这怎么可能？毕竟我们是在猜测独立的比特，而损失函数（BER）对所有比特一视同仁。

高斯示例。给定 $(X_1,\dots,X_n)$ 从 $\mathcal{N}(0,\sigma^2)$ 中独立抽取，我们每符号有一个比特的预算用于压缩，因此解码版本 $(\hat{X}_1,\dots,\hat{X}_n)$ 具有较小的均方误差 $\frac{1}{n}\sum_{i=1}^n \mathbb{E}[(X_i-\hat{X}_i)^2]$。

为此，一个简单的策略是将每个坐标量化为1比特。如例24.1所示，最佳的一位量化误差为$(1-\frac{2}{\pi})\sigma^2 \approx 0.36\sigma^2$。相比之下，我们稍后将展示（定理26.2），存在一种方案，当n较大时，每个坐标的MSE可达$\frac{\sigma^2}{4}$；此外，这是最优的。更一般地，给定每个符号R比特，通过在高维度进行最优向量量化（即将$(X_1,\dots,X_n)$联合压缩为nR比特），率失真理论将告诉我们，当n很大时，我们可以实现每个坐标的MSE：

$$D_{vec}(R) = \sigma^2 2^{-2R}$$

与(24.6)相比，这获得了4.35 dB（或0.72比特/样本）的增益。

来自伯努利和高斯例子的结论都相当令人惊讶：即使$X_1,\dots,X_n$是独立同分布的，联合量化这些坐标仍有收获。对这一高维现象的一些直观解释如下：

1 逐分量应用标量量化会导致量化区域为超立方体，这在高维覆盖中可能并非最优。

2 测度的集中有效地去除了许多非典型的源实现。例如，当量化单个高斯分布 X 时，我们需要覆盖 $\mathbb{R}$ 的大部分，以应对 X 与 0 的显著偏差。然而，当我们将许多（$X_1,\dots,X_n$）一起量化时，大数定律确保了众多 X_j 无法共同作用并全部产生大值。事实上，（$X_1,\dots,X_n$）集中在一个球面附近。因此，我们可以将空间 $\mathbb{R}^n$ 的大部分排除在考虑之外。

数学表述 有损压缩器是一个编码器/解码器对（{v*}），它诱导了以下马尔可夫链

$$X \xrightarrow{f} W \xrightarrow{g} \hat{X}$$

其中 $X \in \mathcal{X}$ 被称为源，$W = f(X)$ 是压缩后的离散数据，而 $\hat{X} = g(W)$ 是在某个字母表$\hat{\mathcal{X}}$ 中取值的重构，该字母表不必与 $\mathcal{X}$ 相同。

一个 *distortion metric* (或损失函数)是一个可测函数 $d : \mathcal{X} \times \hat{\mathcal{X}} \to \mathbb{R} \cup \{+\infty\}$。有损压缩问题有多种表述方式：

1 固定长度（固定速率），*average distortion*：$W \in [M]$，最小化 $\mathbb{E}[d(X,\hat{X})]$。2 固定长度，*excess distortion*：$W \in [M]$，最小化 $\mathbb{P}[d(X,\hat{X}) > D]$。3 可变长度，*max distortion*：$W \in \{0,1\}^*$，$d(X,\hat{X}) \le D$ 几乎必然，最小化平均长度 $\mathbb{E}[l(W)]$ 或熵 $H(W)$。

在本书中，我们关注固定长度的有损压缩，并且主要关心平均失真（除了第26.3节中的联合源信道编码，那里将需要超额失真）。平均失真与超额失真之间的差异类似于统计学和机器学习中的平均风险界与高概率风险界。事实证明，在温和假设下，这两种表述会导致相同的渐近基本极限（参见注25.2）。然而，收敛到该极限的速度非常不同：超额失真版本的收敛如$O(\frac{1}{\sqrt{n}})$具有丰富的离散理论[255]，我们不讨论。超额失真下的收敛要快得多，如$O(\frac{\log n}{n})$；参见练习V.3。

和往常一样，特别令人感兴趣的是当源取随机向量$S^n = (S_1,\dots,S_n) \in \mathcal{S}^n$的形式，并且重构为$\hat{S}^n = (S_1,\dots,S_n) \in \hat{\mathcal{S}}^n$时的情况。我们将重点讨论所谓的*separable*失真度量，它针对n字母向量通过平均单个字母的失真来定义：

$$d(s^n,\hat{s}^n) \triangleq \frac{1}{n}\sum_{i=1}^{n} d(s_i,\hat{s}_i). \tag{24.8}$$

定义 24.2 一个 (n,M,D)-码由一个编码器 $f: \mathcal{A}^n \to [M]$ 和一个解码器 $g: [M] \to \hat{\mathcal{A}}^n$ 组成，使得平均失真满足 $\mathbb{E}[d(S^n, g(f(S^n)))] \le D$。非渐近和渐近基本极限定义如下：

$$M^*(n,D) = \min\{M : \exists (n,M,D)\text{-code}\} \tag{24.9}$$

$$R(D) = \limsup_{n\to\infty} \frac{1}{n}\log M^*(n,D). \tag{24.10}$$

注意，对于平稳无记忆（iid）信源，(24.10) 中的大块长度极限实际上存在，并且与所有块长度上的下确界一致。这是平均失真准则和失真度量可分性的结果——见练习 V.2。

24.3 逆向界限

现在我们已经有了定义，我们给出一个（令人惊讶地简单的）一般逆命题。

定理 24.3（一般逆定理）*Suppose* $X \to W \to \hat{X}$, *where* $W \in [M]$ *and* $\mathbb{E}[d(X,\hat{X})] \le D$. *Then*

$$\log M \ge \phi_X(D) \triangleq \inf_{P_{Y|X}:\mathbb{E}[d(X,Y)]\le D} I(X;Y).$$

Proof.

$$\log M \geq H(W) \geq I(X;W) \geq I(X;\hat{X}) \geq \phi_X(D)$$

其中最后一个不等式源于$P_{\hat{X}|X}$是一个可行解（根据假设）。 □

定理 24.4（ϕ_X 的性质）

(a) ϕ_X is convex, non-increasing.
(b) ϕ_X continuous on (D_0, ∞), where $D_0 =$ 无限$\{D\colon\ \phi_X(D) < \infty\}$.
(c) Suppose $\mathcal{X} = \hat{\mathcal{X}}$ and the distortion metric satisfies $d(x,x) = D_0$ for all x and $d(x,y) > D_0$ for all $x \neq y$. Then $\phi_X(D_0) = I(X;\ X)$.
(d) If d is a proper metric and $\mathcal{X}$ is a complete metric space, we have $D_0 = 0$ and $\phi_X(D_0+) = \phi_X(D_0) = I(X;\ X)$.
(e) Let

$$D_{\max} = \inf_{\hat{x}\in\hat{\mathcal{X}}} \mathbb{E}d(X,\hat{x}).$$

Then $\phi_X(D) = 0$ for all $D > D_{\max}$. If $D_0 > D_{\max}$ then also $\phi_X(D_{\max}) = 0$.

注 24.4（D_0 和 $D_{\max}$ 的作用）根据定义，$D_{\max}$ 是在没有任何信息的情况下可达到的失真。实际上，如果对某个固定的 $\hat{x}$ 有 $D_{\max} = \mathbb{E}d(X,\hat{x})$，那么这个 $\hat{x}$ 就是 X 的“默认”重构，即当我们对 X 没有任何信息时的最佳估计。因此 $D \geq D_{\max}$ 可以免费达到。这就是尽管 $D_{\max}$ 被定义为下确界，仍采用该记号的原因。另一方面，D_0 应被理解为人们所能期望达到的最小失真。实际上，假设 $\hat{\mathcal{X}} = \mathcal{X}$ 且 d 是 $\mathcal{X}$ 上的一个度量。在这种情况下，我们有 $D_0 = 0$，因为我们可以选择 Y 作为 X 的有限值近似。

以高斯信源和MSE失真为例，即$X \sim \mathcal{N}(0,\sigma^2)$和$d(x,\hat{x}) = (x-\hat{x})^2$。我们稍后将展示 $\phi_X(D) = \frac{1}{2}\log^+ \frac{\sigma^2}{D}$。在这种情况下，$D_0 = 0$，并且定义它的下确界并未达到；$D_{\max} = \sigma^2$，如果$D \geq \sigma^2$，我们可以简单地输出0作为重建，这需要零比特。

Proof.

(a) 凸性由 $P_{Y|X} \mapsto I(P_X, P_{Y|X})$ (定理5.3) 的凸性推出。(b) 定义域内部的连续性由凸性推出，因为 $D_0 \quad = \inf_{P_{\hat{X}|X}} \mathbb{E}[d(X,\hat{X})] = \inf\{D : \phi_S(D) < \infty\}$。(c) 满足约束的唯一方式是取 $X = Y$。(d) 显然，$D_0 = d(x,x) = 0$。我们同样显然有 $\phi_X(D_0) \geq \phi_X(D_0+)$。考虑一个 Y_n 的序列，使得 $\mathbb{E}[d(X,Y_n)] \leq 2^{-n}$ 且 $I(X;\ Y_n) \to \phi_X(D_0+)$。由 Borel-Cantelli 可得，以概率1有 $d(X,Y_n) \to 0$，因此 $(X,Y_n) \to (X,X)$。然后由互信息的下半连续性(4.28)可得 $I(X;\ X) \leq \lim I(X;\ Y_n) = \phi_X(D_0+)$。(e) 对于任意 $D > D_{\max}$，我们可以确定性地设置 $\hat{X} = \hat{x}$。因此 $I(X;\ \hat{x}) = 0$。第二个断言由连续性推出。

□

在信道编码中，主要结果将香农容量这一操作量与信息容量关联起来。此处我们以类似方式引入*information rate-distortion function*，其本身即为*not*一个操作量。

定义 24.5 源 $\{S_i\}$ 的 *information rate-distortion function* 是

$$R^{(\mathrm{I})}(D) = \limsup_{n\to\infty} \frac{1}{n}\phi_{S^n}(D), \quad \text{where} \quad \phi_{S^n}(D) = \inf_{P_{\hat{S}^n|S^n}:\mathbb{E}[d(S^n,\hat{S}^n)]\le D} I(S^n;\hat{S}^n).$$

定义 $R^{(\mathrm{I})}(D)$ 的原因在于，从定理24.3我们立即得到：

推论 24.6 $\forall D$, $R(D) \ge R^{(\mathrm{I})}(D)$.

自然，信息率失真函数继承了定理24.4中ϕ的性质：

定理 24.7（$R^{(\mathrm{I})}$ 的性质）

(a) $R^{(\mathrm{I})}(D)$ *is convex, non-increasing. (b)* $R^{(\mathrm{I})}(D)$ *is continuous on* (D_0,∞)*, where* $D_0 \triangleq \inf\{D : R^{(\mathrm{I})}(D) < \infty\}$.
(c) Assume the same assumption on the distortion function as in Theorem 24.4(c)*. For stationary ergodic* $\{S^n\}$, $R^{(\mathrm{I})}(D) = \mathcal{H}$ *(entropy rate) or* $+\infty$ *if* S_k *is not discrete.*
(d) $R^{(\mathrm{I})}(D) = 0$ *for all* $D > D_{\max}$*, where*

$$D_{\max} \triangleq \limsup_{n\to\infty} \inf_{\hat{x}^n\in\hat{\mathcal{X}}} \mathbb{E}d(X^n,\hat{x}^n)\,.$$

If $D_0 < D_{\max}$*, then* $R^{(\mathrm{I})}(D_{\max}) = 0$ *too.*

Proof. 所有属性直接源自定理24.4中应用于ϕ_{S^n}的相应属性。

□

接下来我们展示，对于平稳无记忆（iid）源，无需通过多字母优化问题即可轻松计算{v*}。这与信道容量（具有可分代价函数）的推论20.5相平行。

定理 24.8（单字母化）*For stationary memoryless source* $S_i \overset{\text{i.i.d.}}{\sim} P_S$ *and separable distortion d in the sense of (24.8), we have for every n,*

$$\phi_{S^n}(D) = n\phi_S(D).$$

Thus

$$R^{(\mathrm{I})}(D) = \phi_S(D) = \inf_{P_{\hat{S}|S}:\mathbb{E}[d(S,\hat{S})]\le D} I(S;\hat{S}).$$

Proof. 根据定义，我们通过选择乘积信道：$P_{\hat{S}^n|S^n} = P_{\hat{S}|S}^{\otimes n}$得到 $\phi_{S^n}(D) \le n\phi_S(D)$。因此，$R^{(\mathrm{I})}(D) \le \phi_S(D)$。

对于逆命题，对于任何满足约束 $\mathbb{E}[d(S^n, \hat{S}^n)] \le D$ 的 $P_{\hat{S}^n|S^n}$，我们有

$$\begin{aligned} I(S^n; \hat{S}^n) &\ge \sum_{j=1}^n I(S_j, \hat{S}_j) && (S^n \text{ independent}) \\ &\ge \sum_{j=1}^n \phi_S(\mathbb{E}[d(S_j, \hat{S}_j)]) \\ &\ge n\phi_S\left(\frac{1}{n}\sum_{j=1}^n \mathbb{E}[d(S_j, \hat{S}_j)]\right) && (\text{convexity of } \phi_S) \\ &\ge n\phi_S(D) && (\phi_S \text{ non-increasing}) \end{aligned}$$

在第一步中，我们利用了互信息的关键超可加性性质（6.2）。 □

关于对无记忆但非平稳源的推广，参见练习V.10。

24.4* 将超额失真转换为平均值

最后，我们讨论在已有过量失真压缩器的情况下，如何构建平均失真压缩器，而后者正是我们的关注焦点。

定理 24.9（超额到平均）*Suppose that there exists (f, g) such that $W = f(X) \in [M]$ and $\mathbb{P}[d(X, g(W)) > D] \le \epsilon$. Assume for some $p \ge 1$ and $\hat{x}_0 \in \hat{\mathcal{X}}$ that $(\mathbb{E}[d(X, \hat{x}_0)^p])^{1/p} = D_p < \infty$. Then there exists (f', g') such that $W' = f'(X) \in [M+1]$ and*

$$\mathbb{E}[d(X, g(W'))] \le D(1-\epsilon) + D_p\epsilon^{1-1/p}. \tag{24.11}$$

注24.5 此结果仅对 $p > 1$ 有用，因为当 $p = 1$ 时，(24.11) 的右侧不会随着 $\epsilon \to 0$ 收敛到 D。然而，另一种方法（正如我们在定理25.1的证明中将看到的）表明，仅在 $D_{\max} = D_1 < \infty$ 条件下，(24.11) 中第二项的模拟量随着 $\epsilon \to 0$ 而消失，尽管速率未具体说明。

Proof. 我们将第一个码转换为第二个码，方法是添加一个码字：

$$f'(x) = \begin{cases} f(x) & d(x, g(f(x))) \le D \\ M+1 & \text{otherwise} \end{cases}$$

$$g'(j) = \begin{cases} g(j) & j \le M \\ \hat{x}_0 & j = M+1 \end{cases}$$

然后根据 Hölder 不等式，

$$\mathbb{E}[d(X, g'(W'))] \le \mathbb{E}[d(X, g(W))|\hat{W} \ne M+1](1-\epsilon) + \mathbb{E}[d(X, \hat{x}_0)1\{\hat{W} = M+1\}]$$

$$\leq D(1-\epsilon) + D_p \epsilon^{1-1/p} \qquad \square$$

25 Rate distortion: achievability bounds

在本章中，我们证明一个可达性界，并（结合上一章的反向结果）对平稳无记忆源确立恒等式$R(D) = \inf_{\hat{S}:\mathbb{E}[d(S,\hat{S})]\le D} I(S;\hat{S})$。其核心思想仍然是随机编码，即通过从精心选择的分布独立生成重构点，以概率方式构造量化器。在严格证明这一结果之前，我们首先通过联系大偏差理论（第15章）并解释互信息的约束最小化如何与随机编码集合的优化相关联，来传达伯努利源情形下的主要直觉。随后在第25.2*–25.4*节中，我们扩展这一随机编码构造，以建立覆盖引理和软覆盖引理，它们是信道模拟问题的核心。

我们首先回顾上一章介绍的关键概念：

$$R(D) = \limsup_{n\to\infty} \frac{1}{n}\log M^*(n,D), \qquad \text{(rate-distortion function)}$$

$$R^{(\mathrm{I})}(D) = \limsup_{n\to\infty} \frac{1}{n}\phi_{S^n}(D), \qquad \text{(information rate-distortion function)}$$

其中

$$\phi_S(D) \triangleq \inf_{P_{\hat{S}|S}:\mathbb{E}[d(S,\hat{S})]\le D} I(S;\hat{S}) \tag{25.1}$$

$$\phi_{S^n}(D) = \inf_{P_{\hat{S}^n|S^n}:\mathbb{E}[d(S^n,\hat{S}^n)]\le D} I(S^n;\hat{S}^n) \tag{25.2}$$

并且 $d(S^n,\hat{S}^n) = \frac{1}{n}\sum_{i=1}^n d(S_i,\hat{S}_i)$ 采取可分离形式。

我们已在定理24.3中展示了以下一般逆定理：对于任何压缩方案：$[M] \ni W \to X \to \hat{X}$，使得$\mathbb{E}[d(X,\hat{X})] \le D$，我们必须有$\log M \ge \phi_X(D)$，这在$X = S^n$的特殊情况下意味着$\log M^*(n,D) \ge \phi_{S^n}(D)$，因此在$n$趋于无穷的极限下，$R(D) \ge R^{(\mathrm{I})}(D)$。对于平稳无记忆源$S_i \overset{\text{i.i.d.}}{\sim} P_S$，定理24.8表明$\phi_{S^n}$单字母化为$\phi_{S^n}(D) = n\phi_S(D)$。因此，我们得到逆定理

$$R(D) \ge R^{(\mathrm{I})}(D) = \phi_S(D).$$

正如我们所说，本章的目标是展示$R(D) = R^{(\mathrm{I})}(D)$。

25.1 香农率失真定理

以下结果（本质上）由Shannon在其1959年的论文[380]中证明。

定理 25.1 *Consider a stationary memoryless source $S^n \overset{i.i.d.}{\sim} P_S$. Suppose that the distortion metric d and the target distortion D satisfy:*

1 $d(s^n, \hat{s}^n)$ is non-negative and separable.
2 $D > D_0$, where $D0 = \inf\{D :$
$\phi_S(D) < \infty\}$. 3 $D_{\max}$ is finite, i.e.

$$D_{\max} \triangleq \inf_{\hat{s}} \mathbb{E}[d(S, \hat{s})] < \infty. \tag{25.3}$$

Then

$$R(D) = R^{(\mathrm{I})}(D) = \phi_S(D) = \inf_{P_{\hat{S}|S}: \mathbb{E}[d(S,\hat{S})] \le D} I(S; \hat{S}). \tag{25.4}$$

备注 25.1

- 注意，$D_{\max} < \infty$并不要求$d(\cdot,\cdot)$仅取$\mathbb{R}$中的值。也就是说，定理25.1允许$d(s, \hat{s}) = \infty$。
- 当 $D_{\max} = \infty$ 时，通常对于所有 D 都有 $R(D) = \infty$。事实上，假设 $d(\cdot,\cdot)$ 是一个度量（即实值且满足三角不等式）。那么，对于任意 $x_0 \in \mathcal{A}^n$，我们有

  $$d(X, \hat{X}) \ge d(X, x_0) - d(x_0, \hat{X}) .$$

  因此，对于任何有限码本 $\{c_1, \ldots, c_M\}$，我们有 $\max_j d(x_0, c_j) < \infty$，因此

  $$\mathbb{E}[d(X, \hat{X})] \ge \mathbb{E}[d(X, x_0)] - \max_j d(x_0, c_j) = \infty .$$

  因此，对于任何有限的 D，$R(D) = \infty$。然而，这一观察不应被解释为绝对无法压缩此类源；只是固定长度编码无法做到这一点。例如，对于二次失真和柯西分布的 S，$D_{\max} = \infty$，因为 S 具有无限二阶矩。但很容易看出，对于任意 $D \in (0, \infty)$，*information* 率失真函数 $R^{(\mathrm{I})}(D) < \infty$ 满足 [1]。实际上，在这种情况下，$R^{(\mathrm{I})}(D)$ 是一条永远不会触及任一轴的类双曲线。使用可变长度编码，S^n 可以非平凡地压缩为具有有界熵（但无界基数）的 W $H(W)$。一个开放问题：$H(W) = nR^{(\mathrm{I})}(D) + o(n)$ 是否可达?

- 我们将定理限制在 $D > D_0$，因为有可能 $R(D_0) \neq R^{(\mathrm{I})}(D_0)$。例如，考虑一个独立同分布的非均匀源 $\{S_j\}$，其中 $\mathcal{A} = \hat{\mathcal{A}}$ 是一个具有度量 $d(\cdot,\cdot)$ 的有限度量空间。那么 $D_0 = 0$，并且由练习 V.5 我们有 $R(D_0+) < R(D_0)$。同时，由定理 24.4(d) 我们知道 $R^{(\mathrm{I})}$ 在 D_0 处连续：$R^{(\mathrm{I})}(D_0+) = \phi_S(D_0+) = \phi_S(D_0) = R^{(\mathrm{I})}(D_0)$。

[1] Indeed, if we take W to be a quantized version of S with small quantization error D and notice that differential entropy of the Cauchy S is finite, we get from (24.7) that $R^{(\mathrm{I})}(D) \le H(W) < \infty$.

- 对于无记忆源的(25.4)证明技巧，通过做出与我们在无损压缩（第12章）中讨论过的相似修改，可以扩展到平稳遍历源。

在给出正式证明之前，我们先给出一个启发式推导，强调与第15章大偏差估计的联系。

25.1.1 直观理解

让我们通过根据乘积分布$Q_{\hat{S}}^n$独立生成M个随机点$\mathcal{C} = \{c_1, \ldots, c_M\}$投入空间$\hat{\mathcal{A}}^n$，其中$Q_{\hat{S}}$是$\hat{\mathcal{A}}$上待优化的某个分布。考虑以下简单的编码策略：

$$\text{Encoder} : f(s^n) = \operatorname*{argmin}_{j\in[M]} d(s^n, c_j) \tag{25.5}$$

$$\text{Decoder} : g(j) = c_j \tag{25.6}$$

基本思想如下：由于码字是独立于信源生成的，给定码字与信源实现接近的概率（指数级地）很小，例如，ϵ。然而，由于我们有许多码字，存在一个好的码字的概率可能很高。更准确地说，不存在好码字的概率大约为$(1-\epsilon)^M$，只要$M \gg \frac{1}{\epsilon}$，就可以使其接近于零。

为了进一步解释这一直觉，考虑一个离散无记忆源 $S^n \overset{\text{i.i.d.}}{\sim} P_S$，并让我们评估这个随机码的过量失真：$\mathbb{P}[d(S^n, f(S^n)) > D]$，其中概率是在所有随机码字 $c_1, \ldots, c_M$ 和源 S^n 上取的。定义

$$P_{\text{failure}} \triangleq \mathbb{P}[\forall c \in \mathcal{C}, d(S^n, c) > D] = \mathbb{E}_{S^n}[\mathbb{P}[d(S^n, c_1) > D|S^n]^M],$$

其中最后一个等式来自假设 $c_1, \ldots, c_M$ 是独立同分布且独立于 S^n。为简化记号，令 $\hat{S}^n \overset{\text{i.i.d.}}{\sim} Q_{\hat{S}}^n$ 独立于 S^n，因此 $P_{S^n,\hat{S}^n} = P_S^n Q_{\hat{S}}^n$。那么

$$\mathbb{P}[d(S^n, c_1) > D|S^n] = \mathbb{P}[d(S^n, \hat{S}^n) > D|S^n]. \tag{25.7}$$

为了评估失败概率，我们考虑$P_S = \text{Ber}(\frac{1}{2})$的特殊情况，并选择$Q_{\hat{S}} = \text{Ber}(\frac{1}{2})$来生成随机码字，旨在达到至多$D < \frac{1}{2}$的归一化汉明失真。由于对于任何$s^n$，有$nd(S^n, \hat{S}^n) = \sum_{i:s_i=1}(1 - \hat{S}_i) + \sum_{i:s_i=0} \hat{S}_i \sim \text{Bin}(n, \frac{1}{2})$，条件概率(25.7)不依赖于$S^n$，由下式给出：

$$\mathbb{P}[d(S^n, \hat{S}^n) > D|S^n] = \mathbb{P}\left[\text{Bin}\left(n, \frac{1}{2}\right) \geq nD\right] \approx 1 - 2^{-n(1-h(D))+o(n)}, \tag{25.8}$$

在最后一步中，我们应用了定理15.9和例15.1中的大偏差估计。（请注意，这里我们实际上需要对这些指数级小概率进行下界估计。）因此，

$P_{\text{失败}} = (1 - 2^{-n(1-h(D))+o(n)})^M$，如果对于任意 $\delta > 0$，$M = 2^{n(1-h(D)+\delta)}$，则该失败消失。[2] 正如我们将在定理26.1中计算的，$P_S = \text{Ber}(\frac{1}{2})$ 的率失真函数恰好是 $\phi_S(D) = 1 - h(D)$，因此我们在这个特殊情况下有最优可达性的严格证明。

对于一般分布P_S（，甚至对于$P_S = \text{Ber}(p)$（其选择$Q_{\hat{S}}$作为$\text{Ber}(\frac{1}{2})$是次优的）而言，情况更为复杂，因为条件概率(25.7)通过其经验分布（类型）依赖于源实现S^n。设T_n为其经验分布接近P_S的典型实现集合。我们有

$$\begin{aligned} P_{\text{failure}} \approx & \mathbb{P}[d(S^n, \hat{S}^n) > D | S^n \in T_n]^M \\ = & (1 - \underbrace{\mathbb{P}[d(S^n, \hat{S}^n) \le D | S^n \in T_n]}_{\approx 0, \text{ since } S^n \perp\!\!\!\perp \hat{S}^n})^M \\ \approx & (1 - 2^{-nE(Q_{\hat{S}})})^M, \end{aligned} \tag{25.9}$$

其中可以证明（使用类似于第15章中信息投影的大偏差分析）

$$E(Q_{\hat{S}}) = \min_{P_{\hat{S}|S}: \mathbb{E}[d(S,\hat{S})] \le D} D(P_{\hat{S}|S} \| Q_{\hat{S}} | P_S) \tag{25.10}$$

因此我们得出结论，对于任意选择的 $Q_{\hat{S}}$（（随机码字从中抽取））以及任意的 $\delta > 0$，上述具有 $M = 2^{n(E(Q_{\hat{S}})+\delta)}$ 的编码实现了消失的过剩失真

$$P_{\text{failure}} = \mathbb{P}[\forall c \in \mathcal{C}, d(S^n, c) > D] \to 0 \text{ as } n \to \infty.$$

最后，我们优化 $Q_{\hat{S}}$ 以获得尽可能小的 M:

$$\begin{aligned} \min_{Q_{\hat{S}}} E(Q_{\hat{S}}) &= \min_{Q_{\hat{S}}} \min_{P_{\hat{S}|S}: \mathbb{E}[d(S,\hat{S})] \le D} D(P_{\hat{S}|S} \| Q_{\hat{S}} | P_S) \\ &= \min_{P_{\hat{S}|S}: \mathbb{E}[d(S,\hat{S})] \le D} \min_{Q_{\hat{S}}} D(P_{\hat{S}|S} \| Q_{\hat{S}} | P_S) \\ &= \min_{P_{\hat{S}|S}: \mathbb{E}[d(S,\hat{S})] \le D} I(S; \hat{S}) \\ &= \phi_S(D) \end{aligned}$$

其中第三个等式来源于互信息的变分表示（推论4.2）。这一启发式推导解释了受限互信息最小化是如何产生的。下面我们采用不同的方法，再次通过随机编码使其严格化。

25.1.2 定理25.1的证明

定理25.2（平均失真随机编码界）*Fix P_X and suppose $d(x, \hat{x}) \ge 0$ for all $x, \hat{x}$. For any $P_{Y|X}$ and any $y_0 \in \hat{\mathcal{A}}$, there exists a code $X \to W \to \hat{X}$ with*

[2] In fact, this argument shows that $M = 2^{n(1-h(D))+o(n)}$ codewords suffice to cover the *entire* Hamming space within distance Dn. See (27.9) and Exercise **V.26**.

$W \in [M+1]$, *such* $d(X,\hat{X}) \le d(X,y_0)$ *almost surely and for any* $\gamma > 0$,

$$\mathbb{E}[d(X,\hat{X})] \le \mathbb{E}[d(X,Y)] + \mathbb{E}[d(X,y_0)]e^{-M/\gamma} + \mathbb{E}[d(X,y_0)1\{i(X;Y) > \log\gamma\}].$$

Here the first and the third expectations are over $(X,Y) \sim P_{X,Y} = P_X P_{Y|X}$ *and the information density* $i(\cdot;\cdot)$ *is defined with respect to this joint distribution (cf. Definition 18.1).*

需要作出一些说明:

- 定理25.2表明，从任意满足$\mathbb{E}[d(X,Y)] \le D$的$P_{Y|X}$出发，我们可以提取出一个好码，其平均失真为D加上一些额外项，这些额外项在无记忆源的渐近 regime 下将消失。
- 该证明使用了随机编码论证，码字独立地从 P_Y 中抽取，P_Y 是由源分布 P_X 和辅助信道 $P_{Y|X}$ 诱导的边缘分布。因此，$P_{Y|X}$ 在码构造中不起作用，仅在分析中使用（通过定义 P_X 与 P_Y 之间的耦合）。
- 确定性y_0的作用是“故障安全”码字（将y_0视为带有$D_{\max} = \mathbb{E}[d(X,y_0)]$的默认重构）。我们将$y_0$添加到随机码本中以进行“损害控制”，以对冲我们最终得到糟糕码本的（极不可能）事件。

Proof. 与第25.1.1节中概述的直观论证类似，我们采用随机编码，并独立于源随机生成码字:

$$\mathcal{C} = \{c_1,\dots,c_M\} \overset{\text{i.i.d.}}{\sim} P_Y \perp\!\!\!\perp X$$

并添加“故障安全”码字$c_{M+1} = y_0$。我们采用相同的编码器-解码器对(25.5) – (25.6)，并令$\hat{X} = g(f(X))$。那么根据定义，

$$d(X,\hat{X}) = \min_{j\in[M+1]} d(X,c_j) \le d(X,y_0).$$

为简化符号，令 Y 为 $Y\overline{(}$ 的独立副本，类似于在信道编码中引入未发送码字 X 的想法——见第18章):

$$P_{X,Y,\bar{Y}} = P_{X,Y}P_{\bar{Y}}$$

其中 $P_{\bar{Y}} = P_Y$。回想一下计算随机变量 $U \in [0,a]$ 期望值的公式：$\mathbb{E}[U] = \int_0^a \mathbb{P}[U \ge u]du$。那么平均失真为

$$\begin{aligned}
\mathbb{E}d(X,\hat{X}) &= \mathbb{E}\min_{j\in[M+1]} d(X,c_j) \\
&= \mathbb{E}_X\mathbb{E}\Big[\min_{j\in[M+1]} d(X,c_j)\Big|X\Big] \\
&= \mathbb{E}_X\int_0^{d(X,y_0)} \mathbb{P}\Big[\min_{j\in[M+1]} d(X,c_j) > u\Big|X\Big]du \\
&\le \mathbb{E}_X\int_0^{d(X,y_0)} \mathbb{P}\Big[\min_{j\in[M]} d(X,c_j) > u\Big|X\Big]du
\end{aligned}$$

$$
\begin{aligned}
&= \mathbb{E}_X \int_0^{d(X,y_0)} \mathbb{P}[d(X,\overline{Y}) > u|X]^M du \\
&= \mathbb{E}_X \int_0^{d(X,y_0)} (1 - \mathbb{P}[d(X,\overline{Y}) \le u|X])^M du \\
&\le \mathbb{E}_X \int_0^{d(X,y_0)} (1 - \underbrace{\mathbb{P}[d(X,\overline{Y}) \le u, i(X,\overline{Y}) > -\infty|X]}_{\triangleq \delta(X,u)})^M du. \qquad (25.11)
\end{aligned}
$$

接下来，我们按如下方式对 $(1-\delta(X,u))^M$ 进行上界估计：

$$
\begin{aligned}
(1-\delta(X,u))^M &\le e^{-M/\gamma} + |1 - \gamma\delta(X,u)|^+ && (25.12)\\
&= e^{-M/\gamma} + |1 - \gamma\mathbb{E}[\exp\{-i(X;Y)\}1\{d(X,Y) \le u\}|X]|^+ && (25.13)\\
&\le e^{-M/\gamma} + \mathbb{P}[i(X;Y) > \log\gamma|X] + \mathbb{P}[d(X,Y) > u|X] && (25.14)
\end{aligned}
$$

其中

- (25.12) 在处理 $(1-\delta)^M$ 时使用了以下技巧，针对 $\delta \ll 1$ 和 $M \gg 1$。首先，回忆一下标准经验法则：

$$
(1-\delta)^M \approx \begin{cases} 0, & \delta M \gg 1 \\ 1, & \delta M \ll 1 \end{cases}
$$

  为了获得类似性质的确定界，对于任意 {v*} > 0，我们应用

$$
(1-\delta)^M \le e^{-\delta M} \le e^{-M/\gamma} + (1-\gamma\delta)_+.
$$

- (25.13) 仅是命题18.3的一个测度变换论证。即我们应用(18.4)使用 $f(x,y) = 1\{d(x,y) \le u\}$
。 • 对于 (25.14)，考虑链：

$$
\begin{aligned}
1 - \gamma\,\mathbb{E}[\exp\{-i(X;Y)\}1\{d(X,Y) \le u\}|X] &\le 1 - \gamma\,\mathbb{E}[\exp\{-i(X;Y)\}1\{d(X,Y) \le u, i(X;Y) \le \log\gamma\}|X] \\
&\le 1 - \mathbb{E}[1\{d(X,Y) \le u, i(X;Y) \le \log\gamma\}|X] \\
&= \mathbb{P}[d(X,Y) > u \text{ or } i(X;Y) > \log\gamma|X] \\
&\le \mathbb{P}[d(X,Y) > u|X] + \mathbb{P}[i(X;Y) > \log\gamma|X]
\end{aligned}
$$

将 (25.14) 代入 (25.11)，我们得到

$$
\begin{aligned}
\mathbb{E}[d(X,\hat{X})] &\le \mathbb{E}_X \left[\int_0^{d(X,y_0)} (e^{-M/\gamma} + \mathbb{P}[i(X;Y) > \log\gamma|X] + \mathbb{P}[d(X,Y) > u|X]) du \right] \\
&\le \mathbb{E}[d(X,y_0)]e^{-M/\gamma} + \mathbb{E}[d(X,y_0)\mathbb{P}[i(X;Y) > \log\gamma|X]] + \mathbb{E}_X \int_0^{\infty} \mathbb{P}[d(X,Y) > u|X]) du \\
&= \mathbb{E}[d(X,y_0)]e^{-M/\gamma} + \mathbb{E}[d(X,y_0)1\{i(X;Y) > \log\gamma\}] + \mathbb{E}[d(X,Y)].
\end{aligned}
$$

□

作为一个附带产物，我们得到了关于超额失真的以下可达性结果。

定理 25.3（超额失真的随机编码界）*For any $P_{Y|X}$, there exists a code $X \to W \to \hat{X}$ with $W \in [M]$, such that for any $\gamma > 0$,*

$$\mathbb{P}[d(X,\hat{X}) > D] \le e^{-M/\gamma} + \mathbb{P}[\{d(X,Y) > D\} \cup \{i(X;Y) > \log\gamma\}]$$

Proof. 完全按照定理25.2的证明进行（不使用额外的码字y_0），将(25.11)替换为$\mathbb{P}[d(X,\hat{X}) > D] = \mathbb{P}[\forall j \in [M], d(X,c_j) > D] = \mathbb{E}_X[(1-\mathbb{P}[d(X,\bar{Y}) \le D|X])^M]$，并继续类似操作。 □

最后，我们通过将定理25.2应用于iid源$X = S^n \overset{\text{i.i.d.}}{\sim} P_S$和$n \to \infty$，给出了定理25.1的严格证明：

Proof of Theorem 25.1. 我们的目标是可实现性：$R(D) \le R^{(\mathrm{I})}(D) = \phi_S(D)$。

不失一般性，我们可以假设 $D_{\max} = \mathbb{E}[d(S,\hat{s}_0)]$ 在某个固定的 $\hat{s}_0$ 处取得——这是我们的默认重构；否则，只需取任何其他固定符号，使得期望是有限的。对于 S^n，默认重构为 $\hat{s}_0^n = (\hat{s}_0,\dots,\hat{s}_0)$ 和 $\mathbb{E}[d(S^n,\hat{s}_0^n)] = D_{\max} < \infty$，因为失真是可分离的。

修复一些小的 $\delta > 0$。取任意 $P_{\hat{S}|S}$ 使得 $\mathbb{E}[d(S,\hat{S})] \le D - \delta$；这样的 $P_{\hat{S}|S}$ 存在，因为根据假设 $D > D_0$。将定理25.2应用于 $(X,Y) = (S^n,\hat{S}^n)$，其中

$$\begin{aligned}
P_X &= P_{S^n}\\
P_{Y|X} &= P_{\hat{S}^n|S^n} = (P_{\hat{S}|S})^n\\
\log M &= n(I(S;\hat{S}) + 2\delta)\\
\log\gamma &= n(I(S;\hat{S}) + \delta)\\
d(X,Y) &= \frac{1}{n}\sum_{j=1}^n d(S_j,\hat{S}_j)\\
y_0 &= \hat{s}_0^n
\end{aligned}$$

我们得出结论，存在一个压缩器 $f\colon \mathcal{A}^n \to [M+1]$ 和 $g\colon [M+1] \to \hat{\mathcal{A}}^n$，使得

$$\begin{aligned}
\mathbb{E}[d(S^n,g(f(S^n)))] &\le \mathbb{E}[d(S^n,\hat{S}^n)] + \mathbb{E}[d(S^n,\hat{s}_0^n)]e^{-M/\gamma} + \mathbb{E}[d(S^n,\hat{s}_0^n)1\left\{i(S^n;\hat{S}^n) > \log\gamma\right\}]\\
&\le D - \delta + \underbrace{D_{\max}\, e^{-\exp(n\delta)}}_{\to 0} + \underbrace{\mathbb{E}[d(S^n,\hat{s}_0^n)1_{E_n}]}_{\to 0 \text{ (later)}}, \qquad (25.15)
\end{aligned}$$

其中

$$E_n = \{i(S^n;\hat{S}^n) > \log\gamma\} = \left\{\frac{1}{n}\sum_{j=1}^n i(S_j;\hat{S}_j) > I(S;\hat{S}) + \delta\right\} \quad \xRightarrow{\text{WLLN}} \quad \mathbb{P}[E_n] \to 0$$

如果我们能证明（25.15）中的期望为零，则存在一个具有以下特性的 $(n,M,\overline{D})$-码：

$$M = 2^{n(I(S;\hat{S})+2\delta)}, \quad \overline{D} = D - \delta + o(1) \le D.$$

总之，$\forall P_{\hat{S}|S}$ 使得 $\mathbb{E}[d(S,\hat{S})] \le D-\delta$ 时，我们已经证明了 $R(D) \le I(S;\ \hat{S})$。令 $\delta\downarrow$ 趋于 0，由 $\phi_S(D)$ 在 $(D_0\,\infty)$ 中的连续性（回顾定理 24.4），我们有 $R(D) \le \phi_S(D-) = \phi_S(D)$。

还需要证明(25.15)中的期望为零。这是序列$\{d(S^n,\hat{s}_0^n)\}$一致可积性的一个简单推论。我们需要以下引理。

引理 25.4 *For any positive random variable U, define $g(\delta)=\sup_{H:\mathbb{P}[H]\le\delta}\mathbb{E}[U1_H]$, where the supremum is over all events measurable with respect to U. Then*[3] $\mathbb{E}U<\infty\Rightarrow g(\delta)\xrightarrow{\delta\to 0}0$.

Proof. 对于任意 $b>0$，$\mathbb{E}[U1_H]\le\mathbb{E}[U1\{U>b\}]+b\delta$，其中由控制收敛定理得 $\mathbb{E}[U1\{U>b\}]\xrightarrow{b\to\infty}0$。然后通过令 $b=1/\sqrt{\delta}$，证明完成。 □

现在 $d(S^n,\hat{s}_0^n)=\frac{1}{n}\sum_{j=1}^n U_j$，其中 U_j 是 $U\triangleq d(S,\hat{s}_0)$ 的独立同分布副本。由于根据假设 $\mathbb{E}[U]=D_{\max}<\infty$，应用引理 25.4 可得 $\mathbb{E}[d(S^n,\hat{s}_0^n)1_{E_n}]=\frac{1}{n}\sum\mathbb{E}[U_j1_{E_n}]\le g(\mathbb{P}[E_n])\to 0$，因为 $\mathbb{P}[E_n]\to 0$。这证明了该定理。 □

注 25.2（超额失真的基本极限） 尽管定理 25.1 是针对平均失真陈述的，但在某些温和的额外条件下，它对于超额失真也成立，此时目标是以任意接近于 1 的概率达到 $d(S^n,\hat{S}^n)\le D$，而不是在期望意义下。事实上，定理 25.1 的可达性证明已经是以高概率陈述的。对于逆定理，除 (25.3) 外，假设对于某个 $\hat{s}\in\hat{S}$ 和 $p>1$，有 $D_p\triangleq\mathbb{E}[d(S,\hat{s})^p]^{1/p}<\infty$。应用 Rosenthal 不等式 [368, 235]，我们得到 $\mathbb{E}[d(S,\hat{s}^n)^p]=\mathbb{E}[(\sum_{i=1}^n d(S_i,\hat{s}))^p]\le CD_p^p$，其中 $C=C(p)$ 为某个常数。然后我们可以应用定理 24.9 将超额失真的码转换为平均失真的码，并调用后者的逆定理。

为了结束本节，我们注意到在第25.1.1节和定理25.1中，似乎我们应用了不同的证明技巧。为何两者最终得出相同的*tight*渐近结果？这是因为两个证明的关键都是估计(25.9)和(25.11)中下划线概率的指数（大偏差）。为了得到正确的指数，如我们所知，关键在于对解决信息投影问题(25.10)的分布应用倾斜（测度变换）。当$P_{\overline{Y}}=(Q_{\hat{S}})^n=(P_{\hat{S}})^n$且$P_{\hat{S}}$选择为率失真优化(25.1)解的输出分布时，得到的指数正好由$2^{-i(X;Y)}$给出。

25.2* 覆盖引理与联合典型性

在本节中，我们考虑以下有趣的问题，即 *channel simulation/syn- thesis* 的一个版本。我们希望通过接下来描述的协议来模拟一系列独立同分布的相关字符串 $(A_i,B_i)\overset{\text{i.i.d.}}{\sim}P_{A,B}$。首先，在一个终端生成一个序列 $A^n\overset{\text{i.i.d.}}{\sim}P_A$。然后，我们可以查看它，生成一个速率受限的消息 $W\in[2^{nR}]$，该消息被（无噪声地）传送到远程目的地。收到消息后，远程解码器从中生成一个字符串 B^n。目标是能够欺骗检查 (A^n,B^n) 并试图验证它确实是由 $(A_i,B_i)\overset{\text{i.i.d.}}{\sim}P_{A,B}$ 生成的 *tester*。参见图 25.1 的图示。

需要多大的速率R取决于我们如何准确理解“欺骗测试者”这一要求。如果测试者是预先固定的（这仅仅意味着我们知道集合F，使得

[3] In fact, $\Rightarrow$ is $\Leftrightarrow$.

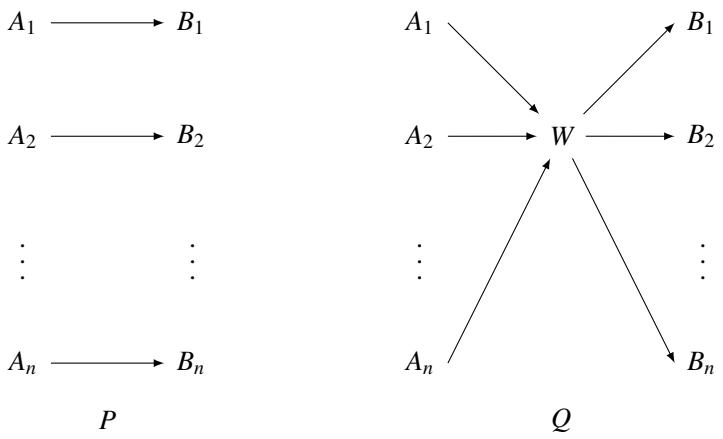


图25.1 信道模拟博弈的描述。分布 P (left) 将通过最小速率 R 下的分布 Q (right) 进行模拟。根据具体公式，我们需要$R = I(A;B)$ (覆盖引理)或$R = C(A;B)$ (软覆盖引理)。

若声明了 $(A_i, B_i) \overset{\text{i.i.d.}}{\sim} P_{A,B}$，每当 $(A^n, B^n) \in F$)，那么这正是 *covering lemma* 起作用的情形。在下一节中，我们将展示，如果 F 不是事先已知的，那么就需要更高的速率 $R = C(A;B)$。我们省略了 Bennett 和 Shor [43] 的著名定理，该定理表明即使 F 未知，但如果编码器和解码器能够访问一个公共随机比特源（当然，独立于 A^n），速率 $R = I(A;B)$ 也是可以达到的。

在继续之前，我们注意到一些简单的边界情况：

1 如果 $R = H(A)$，我们可以压缩 A^n 并将其发送给“B 侧”，B 侧可以完美重建 A^n，并利用该信息通过 $P_{B^n|A^n}$ 生成 B^n。2 如果 $R = H(B)$，“A 侧”可以根据 $P^n_{A,B}$ 生成 B^n，并将该 B^n 序列发送给“B 侧”。3 如果 $A \perp B$，我们知道 $R = 0$，因为“B 侧”可以独立生成 B^n。

我们之前关于实现率失真速率的论证，对于F-已知情况，给出了一个明确的答案（即$R = I(A;B)$是充分的），如下所示。

定理 25.5（覆盖引理）*Fix $P_{A,B}$ and let $(A_j, B_j) \overset{i.i.d.}{\sim} P_{A,B}$, $R > I(A;B)$. We generate a random codebook $\mathcal{C} = \{c_1, \ldots, c_M\}$,* log
$M = nR$, with each codeword c_j drawn i.i.d. from distribution P_B^n. Then we have for all sets F

$$\mathbb{P}[\exists c : (A^n, c) \in F] \geq \mathbb{P}[(A^n, B^n) \in F] + \underbrace{o_R(1)}_{\text{uniform in } F} \tag{25.16}$$

注25.3 “覆盖”这一名称来源于其在定理25.1证明中的应用。在该情境下，我们将$A = S$和$B = \hat{S}$设定为源和最优重构（在

最小化 $R^{(I)}(D)$ 的意义）。然后取 $F = \{(a^n, b^n) : d(a^n, b^n) \le D+\delta\}$，我们看到不等式右侧的两项都是 $o(1)$。因此，采样 2^{nR} 个重建点，我们 *covered* 源实现的这种空间，使得以高概率我们总能找到具有低失真的重建。

Proof. 令 $\gamma > M$ 并遵循定理 25.2 证明中的类似论证，我们有

$$\begin{aligned}\mathbb{P}[\forall c \in \mathcal{C} : (A^n, c) \notin F] &\le e^{-M/\gamma} + \mathbb{P}[\{(A^n, B^n) \notin F\} \cup \{i(A^n; B^n) > \log\gamma\}] \\ &= \mathbb{P}[(A^n, B^n) \notin F] + o(1) \\ \Rightarrow \mathbb{P}[\exists c \in \mathcal{C} : (A^n, c) \in F] &\ge \mathbb{P}[(A^n, B^n) \in F] + o(1)\end{aligned}$$

□

正如我们解释的，我们所陈述的覆盖引理版本展示了如何仅应用一个固定测试集F来“愚弄测试者”。然而，如果A和B都取有限字母表上的值，那么可以陈述更强的结果。这个覆盖引理的原始版本[111]正是复杂分布式压缩论证中所使用的，例如定理11.17。在陈述结果之前，我们提醒对于两个序列a^n, b^n，我们将其联合经验分布记为

$$\hat{P}_{a^n,b^n}(\alpha,\beta) \triangleq \frac{1}{n}\sum_{i=1}^{n} 1\{a_i = \alpha, b_i = \beta\}\,, \qquad \alpha \in \mathcal{A}, \beta \in \mathcal{B}\,.$$

回顾备注18.2中关于联合典型性的讨论也是有益的。在本节中，我们称一对向量序列(a^n, b^n)为*jointly typical with respect to* $P_{A,B}$，如果

$$\mathrm{TV}(\hat{P}_{a^n,b^n}, P_{A,B}) = o(1)\,.$$

固定一个分布 $P_{A,B}$ 和任意由元素 $c_j \in \mathcal{B}^n$ 组成的码本 $\mathcal{C} = \{c_1, \ldots, c_M\}$。对于任意固定的输入字符串 a^n，我们定义

$$W = \operatorname*{argmin}_{j\in[M]} \mathrm{TV}(\hat{P}_{a^n,c_j}, P_{A,B})\,, \qquad \hat{B}^n = c_W\,. \tag{25.17}$$

下一个推论表明，为了生成联合典型对$(A^n, \hat{B}^n)$，码本必须具有比率$R > I(A; B)$，而这正是最优的。

推论 25.6 *Fix $P_{A,B}$ on a pair of finite alphabets $\mathcal{A}, \mathcal{B}$. For any $R > I(A; B)$ we generate a random codebook $\mathcal{C} = \{c_1, \ldots, c_M\}$,* 对数
$M = nR$, where each codeword c_j is drawn i.i.d. from distribution P_B^n. With $\hat{B}^n$ defined as in (25.17) *we have that pair $(A^n, \hat{B}^n)$ is jointly typical with high probability*

$$\mathbb{E}[\mathrm{TV}(\hat{P}_{A^n,\hat{B}^n}, P_{A,B})] = o_R(1)\,. \tag{25.18}$$

Furthermore, no codebook with rate $R < I(A, B)$ can achieve (25.18).

Proof. 首先，在这种情况下$i(A^n; B^n)$是有界独立同分布项的和，因此(25.16)中的$o_R(1)$项实际上是$e^{-\Omega(n)}$。固定任意$\epsilon > 0$并应用定理到

$$F = \left\{(a^n, b^n) : \left|\hat{P}_{a^n,b^n}(\alpha,\beta) - P_{A,B}(\alpha,\beta)\right| \le \epsilon\right\}$$

对于所有可能的 $\alpha \in \mathcal{A}$ 和 $\beta \in \mathcal{B}$，我们得出结论：

$$\mathbb{P}[\mathrm{TV}(P_{A^n,\hat{B}^n}, P_{A,B}) \le \epsilon] \ge 1 - |\mathcal{A}||\mathcal{B}|e^{-\Omega(n)} = 1 + o(1)\,.$$

由于 ϵ 的任意性，(25.18) 成立。

这个证明也可以从组合角度来理解（如经典文献[111]中所做的那样）。事实上，速率 $R \approx I(A;B)$是充分的，因为一个独立同分布的B^n在大约$2^{nH(B)}$个高概率序列上取值（参见命题1.5）。将同一命题以典型的A^n序列为条件进行应用，大约有$2^{nH(B|A)}$个B^n序列具有相同的联合分布。因此，虽然我们需要$nH(B)$比特来描述整个B^n，但直观上很清楚，对于每个A^n序列，我们只需要描述一类B^n，而大约有$\frac{2^{nH(B)}}{2^{nH(B|A)}} =$个$2^{nI(A;B)}$类。我们可以用一个二分图来表示这种情况，左侧是（典型的）A^n序列，右侧是（典型的）B^n序列，边对应于具有联合典型性的序列对；这个图是正则的，度数分别为$2^{nH(A|B)}$和$2^{nH(A|B)}$。因此，为了将我们的直觉转化为如上所述的严格证明，我们需要证明$2^{nI(A;B)}$个右顶点的随机子集覆盖所有左顶点。（这个替代证明的优点在于，它表明了（25.18）在以任何典型A^n为条件下成立。）

接下来我们证明 $R \ge I(A;$ 实际上 $B)$ 对于模拟联合典型 B^n 是必要的。考虑任意码本 $\mathcal{C}$ 使得（25.18）成立。一方面，我们有

$$nR = \log M \ge I(A^n;\hat{B}^n) = H(A^n) - H(A^n|\hat{B}^n) = nH(A) - H(A^n|\hat{B}^n)\,.$$

因此，如果我们证明

$$H(A^n|\hat{B}^n) \le nH(A|B) + o(n)\,.$$

为此，我们定义$A^n|\hat{B}^n$的一个随机条件类型为

$$\hat{Q}(\alpha|\beta) \triangleq \frac{\#\{i : \hat{A}_i = \alpha, \hat{B}_i = \beta\}}{\#\{i : \hat{B}_i = \beta\}}\,.$$

对于任意小的 $\epsilon > 0$，我们定义二进制 $T = 1$ 当且仅当对于某个 α 或 β，以下不等式之一被违反

$$\left|\frac{1}{n}\#\{i : \hat{B}_i = \beta\} - P_B(\beta)\right| > \epsilon\,,$$
$$\left|\hat{Q}(\alpha|\beta) - P_{A|B}(\alpha|\beta)\right| > \epsilon\,.$$

根据马尔可夫不等式（并假设不失一般性，对于所有 β，$P_B(\beta) >$ 为0），我们得到

$$\mathbb{P}[T = 1] = o(1)\,.$$

因此，我们有

$$H(A^n|\hat{B}^n) \le H(A^n, T|\hat{B}^n) \le \log 2 + n\log|\mathcal{A}|\mathbb{P}[T = 1] + H(A^n|\hat{B}^n, T = 0)\,.$$

前两项是$o(n)$，所以我们关注最后一项。由于$\hat{Q}$是一个具有多项式多个可能值的随机变量，参见练习I.2，我们有

$$H(A^n|\hat{B}^n, T = 0) \le H(A^n, \hat{Q}|\hat{B}^n, T = 0) \le H(A^n|\hat{Q}, \hat{B}^n, T = 0) + O(\log n)\,.$$

假设存在 n_β 个位置，对应 $\hat{B}_i = \beta$。在给定 $\hat{Q}$ 的条件下，随机变量 A^n 取值范围为 $\binom{n_\beta}{n_\beta Q(\alpha_1|\beta)\cdots n_\beta Q(\alpha_{|A|}|\beta)}$。由于在 $T=$ 为 0 时有 $\hat{Q} \to P_{A|B}$，且 $\frac{n_\beta}{n} \to P_B(\beta)$ 作为 $n \to \infty$，我们由命题 1.5 和熵的连续性命题 4.8 推断出

$$H(A^n|\hat{Q}, \hat{B}^n, T=0) \le n(H(A|B)+\delta)$$

对于某个 $\delta = \delta(\epsilon) > 0$，其随着 $\epsilon \to 0$ 而消失。 □

推论25.6的应用包括分布式压缩（定理11.17）和假设检验（定理16.6）。现在，这些应用利用速率受限的$\hat{B}^n$来创建不仅与A^n而且与其他随机变量所需的关联（联合典型性）。这些应用将需要以下简单的观察。

命题 25.7 *Fix some $P_{X,A,B}$ on finite alphabets and consider a pair of random variables $(A^n, \hat{B}^n)$ which are jointly typical on average (specifically,* (25.18) *holds as $n \to \infty$). Given $A^n, \hat{B}^n$ suppose that X^n is generated $\sim P_{X|A,B}^{\otimes n}$. Then we have*

$$\mathbb{E}[\mathrm{TV}(\hat{P}_{X^n,A^n,\hat{B}^n}, P_{X,A,B})] = o(1)\,.$$

And, furthermore we have

$$I(X^n;\hat{B}^n) \ge nI(X;B) + o(n)\,. \tag{25.19}$$

备注 25.4（马尔可夫引理）此结果被称为 *Markov lemma*，例如 [106，引理 15.8.1]，因为在标准应用设置中，考虑的是联合分布 $P_{X,A,B} = P_{X,A}P_{B|A}$，即 $X \to A \to B$。在此应用中，进一步有 $(X^n, A^n) \overset{\text{i.i.d.}}{\sim} P_{X,A}$ 由自然生成，仅 A^n 被观测到。给定 A^n，可以构造一个联合典型向量 $\hat{B}^n$（，例如通过覆盖引理推论 25.6）。现在，由于 (X^n, A^n) 以高概率是联合典型的，人们容易自动推断 $(X^n, \hat{B}^n)$ 也会是联合典型的。遗憾的是，联合典型性关系通常不具有传递性。[4] 然而，在上述结果中，解决这一问题的关键在于，X^n 可以被视为在 *after* $(A^n, \hat{B}^n)$ 已经被选定的情况下生成的。因此，按照这一顺序来看待过程，我们甚至可以允许 X^n 依赖于 $\hat{B}^n$，这正是我们所做的。关于 $P_{X|A,B} = P_{X|A}$ 经典设置下的更强结果，请参见 [147，引理 12.1]。

Proof. 注意，由条件（25.18）和马尔可夫不等式我们得到 $\mathrm{TV}(\hat{P}_{A^n,\hat{B}^n}, P_{A,B}) = o(1)$，其概率为 $1-o(1)$。固定任意 $a,b,x \in \mathcal{A}\times\mathcal{B}\times\mathcal{X}$ 并考虑 $m = n\hat{P}_{A^n,\hat{B}^n}(a,b)$ 个坐标 $i \in [n]$，其中 $A_i = a, \hat{B}_i = b$。在这些坐标中有 $m' \le m$ 个坐标 i 也满足 $X_i = x$。标准集中估计表明 $|m' - mP_{X|A,B}(x|a,b)| = o(m)$ 的概率为 $1-o(1)$。因此，通过 m 归一化，我们（由并集界）得到，以概率 $1-o(1)$ 我们有

$$|\hat{P}_{X^n,A^n,\hat{B}^n}(x,a,b) - P_{X,A,B}(x,a,b)| = o(1)\,.$$

[4] Let $P_{X,A,B} = P_X P_A P_B$ with $P_X = P_A = P_B = \mathrm{Ber}(1/2)$. Take a^n to be any binary string in $\{0,1\}^n$ with $n/2$ ones. Set $x_j = b_j = a_j$ for $j \le n/2$ and $x_j = b_j = 1 - a_j$, otherwise. Then (x^n, a^n) and (a^n, b^n) are jointly typical, but (x^n, b^n) is not.

这意味着第一个陈述成立。注意，通过对 $a \in \mathcal{A}$ 求和，我们得到

$$\mathbb{E}[|\mathrm{TV}(\hat{P}_{X^n,\hat{B}^n}, P_{X,B}) = o(1)\,.$$

但接着重复推论25.6第二部分的步骤，我们得到$I(X^n;\ \hat{B}^n) \geq nI(X;\ B) + o(n)$，如所需。

□

注25.5 尽管在(25.19)中我们仅证明了一个下界（这对于本书的应用来说是足够的），但在马尔可夫假设$X \to A \to B$下，已知不等式(25.19)实际上在等式情况下成立[111，第15章]。这一结论是作为深奥的熵表征问题的一个附带结果得出的，对此我们推荐参阅所提及的参考文献。

让我们回到本节开头的讨论。我们已经学会了如何“欺骗”使用一个固定测试集的测试器F (定理25.5)。然后，对于有限字母表，我们已经展示了我们也可以“欺骗”计算经验平均值的测试器，因为

$$\frac{1}{n}\sum_{j=1}^{n} f(A_j, \hat{B}_j) \approx \mathbb{E}_{A,B\sim P_{A,B}}[f(A,B)]\,,$$

对于任何有界函数 f。更强的要求是要求联合分布 $P_{A^n,\hat{B}^n}$ 欺骗任何置换不变的测试器，即

$$\sup |P_{A^n,\hat{B}^n}(F) - P^n_{A,B}(F)| \to 0$$

其中上确界取遍所有置换不变子集 $F \subset \mathcal{A}^n \times \mathcal{B}^n$。这并不由推论 25.6 保证。事实上，注意到置换不变检验的一个充分统计量是联合类型 $\hat{P}_{A^n,\hat{B}^n}$，而推论确实表明 $\hat{P}_{A^n,\hat{B}^n} \approx P_{A,B}$ (在向量) 的 L_1 距离意义下。然而，仍可能发生 $\hat{P}_{A^n,\hat{B}^n}$ 尽管接近 $P_{A,B}$，其取值与 $\hat{P}_{A^n,B^n}$ 的取值高度不同。例如，如果我们限制所有 $c \in \mathcal{C}$ 具有固定组成 P_0，检验器可以轻易检测到问题，因为所有组成为 P_0 的字符串的 P_B^n-测度不能超过 $O(1/\sqrt{n})$。形式上，为了欺骗置换不变检验器，我们需要 $\hat{P}_{A^n,\hat{B}^n}$ 的 *the distribution* 与 $\hat{P}_{A^n,B^n}$ 之间具有小的总变差。

We conjecture, 然而，即便如此，速率 $R = I(A;\ B)$ 应当足以达成这一更为严格的要求。在下一节中，我们将展示如果移除置换不变性约束，则需要更大的速率 $R = C(A;\ B)$。

25.3* 维纳的共同信息

我们继续讨论上一节中的信道模拟设置。我们现在想要确定为实现较小的总变差所需的最小可能通信速率（即 $W \in [2^{nR}]$ 的基数）：

$$\mathrm{TV}(P_{A^n,\hat{B}^n}, P^n_{A,B}) \leq \epsilon \tag{25.20}$$

在模拟输出与真实输出之间（见图25.1）。

定理 25.8 (Cuff [116]) *Let $P_{A,B}$ be an arbitrary distribution on the finite space $\mathcal{A}\times\mathcal{B}$. Consider a coding scheme where Alice observes $A^n \overset{i.i.d.}{\sim} P_A^n$, sends a message $W\in[2^{nR}]$ to Bob, who given W generates a (possibly random) sequence $\hat{B}^n$. If* (25.20) *is satisfied for all $\epsilon>0$ and sufficiently large n, then we must have*

$$R \geq C(A;B) \triangleq \min_{A\to U\to B} I(A,B;U)\,, \tag{25.21}$$

where $C(A;B)$ is known as the Wyner's common information [458]. Furthermore, for any $R>C(A;B)$ and $\epsilon>0$ there exists $n_0(\epsilon)$ such that for all $n\geq n_0(\epsilon)$ there exists a scheme satisfying (25.20)*.*

注意，条件(25.20)保证了任何测试者（无论是否具有置换不变性）都会被欺骗，以概率$\geq 1-\epsilon$相信他看到的是真正独立同分布的(A^n,B^n)。然而，与定理25.5相比，这要求更高的通信速率，因为$C(A;B)\geq I(A;B)$，这是显而易见的。

Proof. 证明Wyner的共同信息是一个下界并不困难。首先，由于$P_{A^n,\hat{B}^n}\approx P_{A,B}^n$ (在TV)中，我们有

$$I(A_t,\hat{B}_t;A^{t-1},\hat{B}^{t-1})\approx I(A_t,B_t;A^{t-1},B^{t-1})=0$$

(这里需要利用 A 和 B 字母表的有限性以及将 $H(P)-H(Q)$ 与 $\mathrm{TV}(P,Q)$) 相联系的界（参见 (7.20) 和推论 6.7）。接下来，我们有

$$\begin{aligned} nR=H(W) &\geq I(A^n,\hat{B}^n;W) && (25.22)\\ &\geq \sum_{t=1}^n I(A_t,\hat{B}_t;W)-I(A_t,\hat{B}_t;A^{t-1},\hat{B}^{t-1}) && (25.23)\\ &\approx \sum_{t=1}^n I(A_t,\hat{B}_t;W) && (25.24)\\ &\gtrsim nC(A;B) && (25.25)\end{aligned}$$

其中在最后一步中我们使用了关键观察，即

$$A_t\to W\to \hat{B}_t$$

并且Wyner的公共信息$P_{A,B}\mapsto C(A;B)$应当在$P_{A,B}$上的总变差距离中是连续的。

为了展示可实现性，我们注意到该问题等价于构造三个随机变量（$\hat{A}^n,W,\hat{B}^n$），使得a）$W\in[2^{nR}]$，b）马尔可夫关系

$$\hat{A}^n\leftarrow W\to\hat{B}^n \tag{25.26}$$

保持且 c) $\mathrm{TV}(P_{\hat{A}^n,\hat{B}^n},P_{A,B}^n)\leq\epsilon/2$。实际上，给定这样一个三元组，我们可以利用 TV 的耦合特征（7.20）以及 $\mathrm{TV}(P_{\hat{A}^n},P_A^n)\leq\epsilon/2$ 这一事实来扩展概率空间至

$$A^n\to\hat{A}^n\to W\to\hat{B}^n$$

并且 $\mathbb{P}[A^n = \hat{A}^n] \geq 1 - \epsilon/2$。再次根据(7.20)，我们得出 $\mathrm{TV}(P_{A^n,\hat{B}^n}, P_{\hat{A}^n,\hat{B}^n}) \leq \epsilon/2$，并依据三角不等式得出(25.20)成立。

最后，满足a)-c)的三元组的构造遵循软覆盖引理（推论25.10），其中$V = (A, B)$和W在x_i所在的集合上均匀分布。 □

25.4* 输出统计的近似与软覆盖引理

在本节中，我们的目标是证明定理 25.8 的证明所需的剩余组成部分（软覆盖引理）。为此，回顾在第 7.9 节中我们已经表明，生成独立同分布的 $X_i \overset{\text{i.i.d.}}{\sim} P_X$ 并将其经验分布 $\hat{P}_n$ 通过信道 $P_{Y|X}$ 传递，会得到 $P_Y = P_{Y|X} \circ P_X$ 的良好近似，即

$$D(P_{Y|X} \circ \hat{P}_n \| P_Y) \to 0\,.$$

一个自然的问题是，为了使近似$P_{Y|X} \circ \hat{P}_n \approx P_Y$成立，$n$应当有多大。本节我们确立的一个显著事实是，答案是$n \approx 2^{I(X;Y)}$，假设$I(X;\ Y) \gg 1$且$i(X;\ Y)$围绕$I(X;\ Y)$具有一定的集中性质。这一事实源自Wyner [458]，并在[212]中得到了显著加强。

在这里，我们通过加强命题7.17中简单的χ^2-信息界（对应于$\lambda = 2$），展示了这类结果的一个新变体。

定理 25.9 *Fix $P_{X,Y}$ and for any $\lambda \in \mathbb{R}$ define the* Rényi 互信息 *of order λ*

$$I_\lambda(X;Y) \triangleq D_\lambda(P_{X,Y} \| P_X P_Y)\,,$$

where D_λ is the Rényi-divergence, cf. Definition 7.24. We have for every $1 < \lambda \leq 2$

$$\mathbb{E}[D(P_{Y|X} \circ \hat{P}_n \| P_Y)] \leq \frac{1}{\lambda - 1} \log(1 + \exp\{(\lambda - 1)(I_\lambda(X;Y) - \log n)\})\,. \tag{25.27}$$

Proof. 由于 $\lambda \mapsto D_\lambda$ 是非递减的，只需证明 $\mathbb{E}[D_\lambda(P_{Y|X} \circ P_n \| P_Y)]$ 的一个等价上界。由 Jensen 不等式可知

$$\begin{aligned}\mathbb{E}[D_\lambda(P_{Y|X} \circ \hat{P}_n \| P_Y)] &\triangleq \frac{1}{\lambda - 1} \mathbb{E}_{X^n} \log \mathbb{E}_{Y \sim P_Y}\left[\left\{\frac{P_{Y|X} \circ \hat{P}_n}{P_Y}\right\}^\lambda\right] \qquad (25.28)\\ &\leq \frac{1}{\lambda - 1} \log \mathbb{E}_{X^n}\, \mathbb{E}_{Y \sim P_Y}\left[\left\{\frac{P_{Y|X} \circ \hat{P}_n}{P_Y}\right\}^\lambda\right] = I_\lambda(X^n; \bar{Y})\,,\end{aligned}$$

其中与(7.56)类似，我们引入了通道 $P_{\bar{Y}|X^n} = \frac{1}{n}\sum_{i=1}^n P_{Y|X=X_i}$。为了分析 $I_\lambda(X^n;\ \bar{Y})$，我们需要界定

$$\mathbb{E}_{(X^n,\bar{Y}) \sim P_X^n \times P_Y}\left[\left\{\frac{1}{n}\sum_i \frac{P_{Y|X}(Y|X_i)}{P_Y(Y)}\right\}^\lambda\right]\,. \tag{25.29}$$

请注意，在给定 Y 的条件下，我们可以分析独立同分布随机变量之和的 λ 阶矩。这将我们置于著名的 Rosenthal 型不等式框架中。特别地，对于任意独立同分布的非负 B_j，只要 $1 \le \lambda \le 2$，我们有 [5]，

$$\mathbb{E}\left[\left(\sum_{i=1}^{n} B_i\right)^{\lambda}\right] \le n\,\mathbb{E}[B^{\lambda}] + (n\,\mathbb{E}[B])^{\lambda}\,. \tag{25.30}$$

现在使用(25.30)，我们可以将(25.29)过度界定为

$$\le 1 + n^{1-\lambda}\,\mathbb{E}_{(X,\bar{Y})\sim P_X\times P_Y}\left[\left\{\frac{P_{Y|X}(Y|X_i)}{P_Y(Y)}\right\}^{\lambda}\right],$$

这意味着

$$I_\lambda(X^n;\bar{Y}) \le \frac{1}{\lambda-1}\log\left(1 + n^{1-\lambda}\exp\{(\lambda-1)I_\lambda(X;Y)\}\right),$$

它与(25.28)一起恢复了主要结果(25.27)。 □

注25.6 Hayashi [217] 将(25.27)式的左侧上界设定为

$$\frac{\lambda}{\lambda-1}\log(1+\exp\{\frac{\lambda-1}{\lambda}(K_\lambda(X;Y)-\log n)\}),$$

其中 $K_\lambda(X;\ Y) = \inf_{Q_Y} D_\lambda(P_{X,Y}\|P_X Q_Y)$ 是所谓的Sibson-Csiszár信息量，参见[338]。然而，这个界在$n\to\infty$时并没有正确的收敛速率，至少对于$\lambda = 1$，这一点通过与命题7.17的比较即可明了。

我们注意到，[217, 212]中也包含了关于

$$\mathbb{E}[\mathrm{TV}(P_{Y|X}\circ\hat{P}_n, P_Y)]$$

这些界限不假定对于 $\lambda > 1$ 存在 $\frac{P_{Y|X}}{P_Y}$ 的 λ 阶矩，而是依赖于 $i(X$ 的分布；$Y)$。然而，我们在此不讨论这些界限，因为为了讨论有限字母表，下一个推论已经足够。

推论 25.10（软覆盖引理）*Suppose $X = (U_1,\dots,U_d)$ and $Y = (V_1,\dots,V_d)$ are vectors with $(U_i,V_i)\overset{i.i.d.}{\sim} P_{U,V}$ and $I_{\lambda_0}(U;\ V) < \infty$ for some $\lambda_0 > 1$ (e.g. if one of U or V is over a finite alphabet). Then for any $R > I(U;\ V)$ there exists $\epsilon > 0$, so that for all $d \ge 1$ there exists $x_1,\dots,x_n$, $n = \lceil\exp\{dR\}\rceil$, such that*

$$D\Big(\frac{1}{n}\sum_{i=1}^{n} P_{Y|X=x_i}\|P_Y\Big) \le \frac{1}{\epsilon}\exp\{-d\epsilon\}\,.$$

[5] The inequality (25.30), which is known to be essentially tight [374], can be shown by applying $(a+b)^{\lambda-1} \le a^{\lambda-1} + b^{\lambda-1}$ and Jensen's to get $\mathbb{E}\,B_i(B_i + \sum_{j\ne i} B_j)^{\lambda-1} \le \mathbb{E}[B^\lambda] + \mathbb{E}[B]((n-1)\,\mathbb{E}[B])^{\lambda-1}$. Summing the left side over i and bounding $(n-1) \le n$ we get (25.30).

注25.7 “软覆盖”一名的由来是因为与选择单一x_i(努力使$P_{Y|X=x_i}$尽可能接近P_Y的覆盖引理（定理25.5）不同，此处我们均匀地混合了n种选择。

Proof. 根据Rényi散度的张量积性质，参见第7.12节，我们有

$$I_\lambda(X;Y) = dI_\lambda(U;V)\,.$$

对于每个 $1 < \lambda < \lambda_0$，我们有 $\lambda \mapsto I_\lambda(U;\ V)$ 是连续的且收敛到 $I(U;\ V)$ 当 $\lambda \to 1$ 时。因此，我们可以找到足够小的 λ，使得 $R > I_\lambda(U;\ V)$。应用定理 25.9 与此 λ 完成了证明。 □

26 Evaluating rate-distortion function. Lossy Source-Channel separation.

在前几章中，我们建立了有损数据压缩的主要编码定理：对于平稳无记忆（独立同分布）信源和可分失真，在假设 $D_{\max} < \infty$ 下，操作率失真函数与信息率失真函数一致，即，

$$R(D) = R^{(\mathrm{I})}(D) = \inf_{P_{\hat{S}|S}:\mathbb{E}d(S,\hat{S})\le D} I(S;\hat{S}).$$

此外，我们已经展示了关于率失真函数的各种性质（参见定理24.4）。在本章中，我们通过评估互信息的这种约束最小化来计算几个重要源分布的率失真函数。我们在第26.1节中应用来评估这些特殊情况的常用技术，然后在第26.2*节中形式化为一种鞍点性质，类似于第5.2节和第5.4*节中关于互信息最大化（容量）的性质。接下来，我们在第19.7节中将联合信源信道编码的范式扩展到有损设置；这一推理随后将在第六部分的统计应用中发现有用（参见第30章）。最后，在第26.4节中，我们讨论了有损压缩和联合信源信道编码的经典理论在理论和实践上的若干局限性。

26.1 $R(D)$ 的评估

26.1.1 伯努利源

令 $S \sim$ 属于 Ber(p)，具有汉明失真 $d(S,\hat{S}) = 1\{S \neq \hat{S}\}$ 和字母表 $\mathcal{S} = \hat{\mathcal{S}} = \{0,1\}$。那么 $d(s^n,\hat{s}^n) = \frac{1}{n}d_{\mathrm{H}}(s^n,\hat{s}^n)$ 是误码率（错误解码比特的比例）。根据对称性，我们可以假设 $p \le 1/2$。

定理 26.1

$$R(D) = (h(p) - h(D))_+. \tag{26.1}$$

例如，当$p = 1/2$，$D = .11$时，我们有$R(D) \approx 1/2$比特。在24.2节描述的汉明博弈中，我们的目标是将100比特压缩到50比特，实际上我们可以在达到11%平均失真的同时做到这一点，相比之下，存储一半字符串并猜测另一半的朴素方案则达到25%的平均失真。注意，我们也可以得到非常紧的非渐近界，参见练习V.3。

Proof. 自$D_{\max} = p$以来，在后续讨论中我们可以假设$D < p$，否则无需证明。

对于反向命题，考虑任意 $P_{\hat{S}|S}$ 使得 $P[S \neq \hat{S}] \leq D \leq p \leq \frac{1}{2}$。那么

$$\begin{aligned} I(S;\hat{S}) &= H(S) - H(S|\hat{S}) \\ &= H(S) - H(S+\hat{S}|\hat{S}) \\ &\geq H(S) - H(S+\hat{S}) \\ &= h(p) - h(P[S \neq \hat{S}]) \\ &\geq h(p) - h(D). \end{aligned}$$

为了实现这个界，我们需要使上述不等式链达到饱和，特别地，选择$P_{\hat{S}|S}$使得差$S+\hat{S}$独立于$\hat{S}$。令$S = \hat{S} + Z$，其中$\hat{S} \sim \text{Ber}(p') \perp Z \sim \text{Ber}(D)$，且$p'$使得卷积恰好给出Ber($p$)，即，

$$p' * D = p'(1-D) + (1-p')D = p,$$

即，$p' = \frac{p-D}{1-2D}$。换句话说，后向信道 $P_{S|\hat{S}}$ 正是 BSC(D)，而由此得到的 $P_{\hat{S}|S}$ 即为我们选择的前向信道 $P_{\hat{S}|S}$。于是，$I(S;\ \hat{S}) = H(S) - H(S|\hat{S}) = H(S) - H(Z) = h(p) - h(D)$，从而得到上界 $R(D) \leq h(p) - h(D)$。 □

备注26.1 这里有一个更通用的策略（我们将在高斯情形中 later实现）。将从可达性证明中得到的最优前向信道记为$P^*_{\hat{S}|S}$，并将相关的后向信道（即BSC(D)）记为$P^*_{S|\hat{S}}$。我们需要证明不存在更好的$P_{\hat{S}|S}$，使得$P[S \neq \hat{S}] \leq D$且互信息更小。那么

$$\begin{aligned} I(P_S, P_{\hat{S}|S}) &= D(P_{S|\hat{S}} \| P_S | P_{\hat{S}}) \\ &= D(P_{S|\hat{S}} \| P^*_{S|\hat{S}} | P_{\hat{S}}) + \mathbb{E}_P\left[\log \frac{P^*_{S|\hat{S}}}{P_S}\right] \\ &\geq H(S) + \mathbb{E}_P[\log D 1\{S \neq \hat{S}\} + \log \bar{D} 1\{S = \hat{S}\}] \\ &\geq h(p) - h(D) \end{aligned}$$

其中最后一个不等式使用了 $P[S \neq \hat{S}] \leq D \leq \frac{1}{2}$。

注 26.2 根据大数定律，随着 n 增大，分布 $P_S^n =$ 伯(p)^n 集中在半径为 np 的汉明球附近。回想在证明香农率失真定理时，最优码本是从 $P_{\hat{S}}^n =$ 伯(p')^n 独立抽取的，其中 $p' = \frac{p-D}{1-2D}$。注意若 $p = 1/2$ 则 $p' = 1/2$，但若 $p < 1/2$ 则 $p' < p$。在后一种情况下，重构点集中在一个半径为 np' 的较小球面上，其中 $none$ 个是典型源实现，如图 26.1 所示。

关于将该结果推广到m元均匀源，见练习V.6。

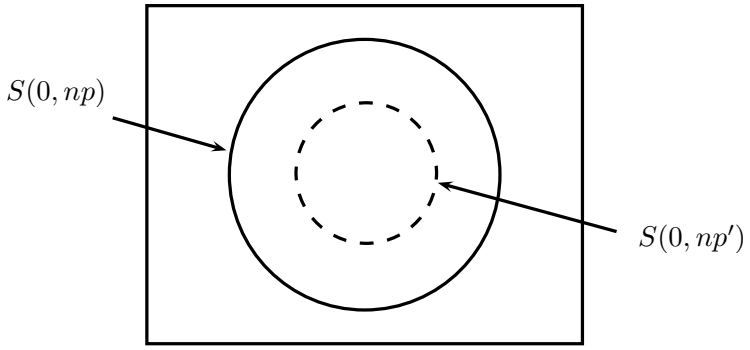


图26.1 压缩汉明源时的源实现（实心球）与码字（虚线球）对比。

26.1.2 高斯源

以下结果计算了标量和向量情形下二次失真下的高斯率失真函数。（关于一般协方差，见练习V.21。）

定理 26.2 *Let $S \sim \mathcal{N}(0, \sigma^2)$ and $d(s, \hat{s}) = (s - \hat{s})^2$ for $s, \hat{s} \in \mathbb{R}$. Then*

$$R(D) = \frac{1}{2} \log^+ \frac{\sigma^2}{D}. \tag{26.2}$$

In the vector case of $S \sim \mathcal{N}(0, \sigma^2 I_d)$ and $d(s, \hat{s}) = \|s - \hat{s}\|_2^2$,

$$R(D) = \frac{d}{2} \log^+ \frac{d\sigma^2}{D}. \tag{26.3}$$

Proof. 从$D_{\max} = \sigma^2$开始，后续我们可以假设$D < \sigma^2$，否则就没有什么可展示的了。

(可实现性) 选择 $S = \hat{S} + Z$，其中 $\hat{S} \sim \mathcal{N}(0, \sigma^2 - D) \perp\!\!\!\perp Z \sim \mathcal{N}(0, D)$。换言之，后向信道 $P_{S|\hat{S}}$ 是噪声功率为 D 的AWGN，且前向信道可容易地确定为 $P_{\hat{S}|S} = \mathcal{N}(\frac{\sigma^2 - D}{\sigma^2} S, \frac{\sigma^2 - D}{\sigma^2} D)$。然后

$$I(S; \hat{S}) = \frac{1}{2} \log \frac{\sigma^2}{D} \implies R(D) \le \frac{1}{2} \log \frac{\sigma^2}{D}$$

(逆命题) 形式上，我们可以模仿定理26.1的证明，用微分熵替换香农熵，并应用定理2.8中的最大熵结果；需要注意的是，对于$\hat{S}$ (可能是离散的)，微分熵可能未定义。因此，我们采用注26.1中给出的另一种证明方法。设$P_{\hat{S}|S}$为任意条件分布，满足$\mathbb{E}_P[(S - \hat{S})^2] \le D$。将上述可达性中的前向信道表示为$P^*_{\hat{S}|S}$。那么

$$I(P_S, P_{\hat{S}|S}) = D(P_{S|\hat{S}} \| P^*_{S|\hat{S}} | P_{\hat{S}}) + \mathbb{E}_P \left[\log \frac{P^*_{S|\hat{S}}}{P_S} \right]$$

$$
\begin{aligned}
&\geq \mathbb{E}_P\left[\log \frac{P^*_{S|\hat{S}}}{P_S}\right] \\
&= \mathbb{E}_P\left[\log \frac{\frac{1}{\sqrt{2\pi D}} e^{-\frac{(S-\hat{S})^2}{2D}}}{\frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{S^2}{2\sigma^2}}}\right] \\
&= \frac{1}{2}\log\frac{\sigma^2}{D} + \frac{\log e}{2}\mathbb{E}_P\left[\frac{S^2}{\sigma^2} - \frac{(S-\hat{S})^2}{D}\right] \\
&\geq \frac{1}{2}\log\frac{\sigma^2}{D}.
\end{aligned}
$$

最后，对于向量情形，(26.3) 由 (26.2) 以及定理 24.8 中相同的单字母化论证得出，利用了定理 24.4(a) 中率失真函数的凸性。 □

高斯情形下最优重建点的解释与之前在第26.2节备注中讨论的汉明源类似：随着n的增长，高斯随机向量集中在欧几里得空间中的$S(0,\sqrt{n\sigma^2})$ (n-球面上，而非汉明)上，但从$(P^*_{\hat{S}})^n$中抽取的每个重建点都接近$S(0,\sqrt{n(\sigma^2-D)})$。因此，图景再次与图26.1中的两个嵌套球面相似。

我们也可以理解最优压缩器误差的几何结构。事实上，假设我们有一系列量化器 $X^n \to W \to \hat{X}^n$，其中 $\frac{1}{n}\log M \to R(D)$。正如我们所知，不失一般性，我们可以假设 $\hat{X}^n = \mathbb{E}[X^n|W]$。让我们用 $\Sigma = \mathrm{Cov}[X^n|W]$ 表示重建误差的协方差矩阵。我们知道，由失真约束可得 $\frac{1}{n}\operatorname{tr}\Sigma \leq D$。现在让我们用微分熵来表示互信息，从而得到

$$\log M = I(X^n; W) = h(X^n) - h(X^n|W)\,.$$

将最大熵原理（2.19）应用于第二项（并通过Jensen不等式和推论2.9，在log det内部对{v *}取期望），我们得到

$$\log M \geq \frac{n}{2}\log\sigma^2 - \frac{1}{2}\log\det\Sigma\,.$$

令 $\{\lambda_j, j\in[n]\}$ 表示 Σ 的频谱。除以 n 并回忆量化器是最优的，我们得到

$$\frac{1}{2}\log\frac{\sigma^2}{D} + o(1) \geq \frac{1}{n}\sum_{j=1}^{n}\frac{1}{2}\log\frac{\sigma^2}{\lambda_j}\,.$$

根据 $\lambda \mapsto \frac{1}{2}\log\frac{\sigma^2}{\lambda}$ 的严格凸性，我们得出结论：特征值的经验分布，即 $\frac{1}{n}\sum_j \delta_{\lambda_j}$，必须收敛到一个点，即 δ_D。在这个意义上，$\Sigma \approx D\cdot I_n$ 以及（给定消息的）不确定性区域应近似为球形。

请注意，定理26.2中的确切表达式依赖于源的高斯性假设。速率-失真公式对这一假设的敏感度如何？以下比较结果是定理20.12关于信道容量的对应版本：

定理 26.3 *Assume that* $\mathbb{E}S = 0$ *and* $\mathrm{Var}\ S = \sigma^2$. *Consider the MSE distortion. Then*

$$\frac{1}{2}\log^+\frac{\sigma^2}{D} - D(P_S\|\mathcal{N}(0,\sigma^2)) \le R(D) = \inf_{P_{\hat{S}|S}:\mathbb{E}(\hat{S}-S)^2\le D} I(S;\hat{S}) \le \frac{1}{2}\log^+\frac{\sigma^2}{D}.$$

注26.3 定理26.3的一个简单推论是，对于具有密度的源分布，在低失真区域，只要$D(P_S\|\mathcal{N}(0,\sigma^2))$是有限的，率失真函数就会按照$\frac{1}{2}$对数$\frac{1}{D}$增长。实际上，第一个不等式，被称为*Shannon lower bound* (SLB)，是渐近紧的，意味着

$$R(D) = \frac{1}{2}\log\frac{\sigma^2}{D} - D(P_S\|\mathcal{N}(0,\sigma^2)) + o(1), \quad D\to 0 \tag{26.4}$$

在关于P_S的适当条件下[281，247]。因此，通过比较(2.21)和(26.4)，我们可以看到，对于小失真，均匀标量量化(第24.1节)实际上在$\frac{1}{2}\log(2\pi e) \approx 2.05$ bits内是渐近最优的。

稍后在30.1节中，我们将应用SLB来推导统计估计的下界。为此，我们需要SLB的以下一般形式（证明见练习V.22）：设$\|\cdot\|$为$\mathbb{R}^d$上的一个*arbitrary*范数，且$r>0$。令X为一个d维连续随机向量，其微分熵$h(X)$有限。那么

$$\inf_{P_{\hat{X}|X}:\mathbb{E}[\|\hat{X}-X\|^r]\le D} I(X;\hat{X}) \ge h(X) + \frac{d}{r}\log\frac{d}{Dre} - \log\left(\Gamma\left(\frac{d}{r}+1\right)V\right), \tag{26.5}$$

其中 $V = \mathrm{vol}(\{x\in\mathbb{R}^d : \|x\|\le 1\})$ 是单位 $\|\cdot\|$-球的体积。

Proof. 再次假设$D < D_{\max} = \sigma^2$。令$S_G\sim\mathcal{N}(0,\sigma^2)$。

“$\le$”：在高斯率失真函数的可实现性证明中使用相同的$P^*_{\hat{S}|S} = \mathcal{N}(\frac{\sigma^2-D}{\sigma^2}S, \frac{\sigma^2-D}{\sigma^2}D)$:

$$\begin{aligned}
R(D) &\le I(P_S, P^*_{\hat{S}|S}) \\
&= I(S; \frac{\sigma^2-D}{\sigma^2}S + W) && W\sim\mathcal{N}(0,\frac{\sigma^2-D}{\sigma^2}D) \\
&\le I(S_G; \frac{\sigma^2-D}{\sigma^2}S_G + W) && \text{by Gaussian saddle point (Theorem 5.11)} \\
&= \frac{1}{2}\log\frac{\sigma^2}{D}.
\end{aligned}$$

“$\ge$”：对于任意满足 $\mathbb{E}(\hat{S}-S)^2 \le D$ 的 $P_{\hat{S}|S}$。令 $P^*_{S|\hat{S}} = \mathcal{N}(\hat{S}, D)$ 表示噪声功率为 D 的 AWGN 信道。则

$$\begin{aligned}
I(S;\hat{S}) &= D(P_{S|\hat{S}}\|P_S|P_{\hat{S}}) \\
&= D(P_{S|\hat{S}}\|P^*_{S|\hat{S}}|P_{\hat{S}}) + \mathbb{E}_P\left[\log\frac{P^*_{S|\hat{S}}}{P_{S_G}}\right] - D(P_S\|P_{S_G}) \\
&\ge \mathbb{E}_P\left[\log\frac{\frac{1}{\sqrt{2\pi D}}e^{-\frac{(S-\hat{S})^2}{2D}}}{\frac{1}{\sqrt{2\pi\sigma^2}}e^{-\frac{S^2}{2\sigma^2}}}\right] - D(P_S\|P_{S_G})
\end{aligned}$$

$$\geq \frac{1}{2}\log\frac{\sigma^2}{D} - D(P_S\|P_{S_G}).$$

□

26.2* 率失真中鞍点性质的类比

在计算汉明源和高斯源的$R(D)$时，我们猜测了率失真函数的正确形式。在它们的逆论证中，我们都使用了相同的技巧来证明任何其他可行的$P_{\hat{S}|S}$都会给出更大的$R(D)$值。在本节中，我们将这一技巧形式化，类似于信道容量的鞍点性质（回忆定理5.4和5.4*节）。注意，通常我们不需要任何技巧来计算$R(D)$，因为我们可以以参数形式获得无约束凸优化的解。

$$\min_{P_{\hat{S}|S}} I(S;\hat{S}) + \lambda\,\mathbb{E}[d(S,\hat{S})].$$

实际上，我们在第5.6节中讨论了计算$R(D)$的迭代算法（Blahut-Arimoto）。然而，为了安心，了解一些普遍原因是有益的，这些原因解释了为什么我们在汉明或高斯案例中使用的技巧实际上是有保证的。

定理 26.4

1 *Suppose P_{Y^*} and $P_{X|Y^*} \ll P_X$ are such that $\mathbb{E}[d(X,Y^*)] \leq D$ and for any $P_{X,Y}$ with $\mathbb{E}[d(X,Y)] \leq D$ we have*

$$\mathbb{E}\left[\log\frac{dP_{X|Y^*}}{dP_X}(X|Y)\right] \geq I(X;Y^*)\,. \tag{26.6}$$

Then $R(D) = I(X;Y^*)$.

2 *Suppose that $I(X;Y^*) = R(D)$. Then for any regular branch of conditional probability $P_{X|Y^*}$ and for any $P_{X,Y}$ satisfying*

- $\mathbb{E}[d(X,Y)] \leq D$ *and*; $Y) < \infty$,
- $P_Y \ll P_{Y^*}$ *and*
- $I(X$

the inequality (26.6) *holds.*

关于前述定理的一些评述如下：

1 第一部分是给定 P_{XY^*} 最优性的充分条件。第二部分给出了一个便于缩小搜索范围的必要条件。实际上，通常满足这些条件的 $P_{X,Y}$ 集合足够丰富，可以从 (26.6) 推断出：

$$\log\frac{dP_{X|Y^*}}{dP_X}(x|y) = R(D) - \theta[d(x,y) - D]\,,$$

对于正的 $\theta > 0$。

2 注意，第二部分在不假设 $P_Y \ll P_{Y^*}$ 的情况下不成立。对此以及其他各种错误（但经常遇到）的推广的一个反例是：$\mathcal{A} = \{0, 1\}$，$P_X = \mathrm{Ber}(1/2)$, $\hat{\mathcal{A}} = \{0, 1, 0', 1'\}$ 和

$$d(0,0) = d(0,0') = 1 - d(0,1) = 1 - d(0,1') = 0\,.$$

$R(D) = |1 - h(D)|^+$，但存在多个非等价的最优选择$P_{Y|X}$、$P_{X|Y}$和P_Y。

Proof. 第一部分只是对汉明和高斯情况上述证明的重复，因此我们关注第二部分。假设存在一个反例$P_{X,Y}$达到

$$I_1 = \mathbb{E}\left[\log \frac{dP_{X|Y^*}}{dP_X}(X|Y)\right] < I^* = R(D)\,.$$

请注意，当 $I(X;\ Y) < \infty$ 时，我们有

$$I_1 = I(X;Y) - D(P_{X|Y}\|P_{X|Y^*}|P_Y)\,,$$

因此

$$D(P_{X|Y}\|P_{X|Y^*}|P_Y) < \infty\,. \tag{26.7}$$

在进入实际证明之前，我们先描述主要思想。对于每个{v*}，我们可以定义一个联合分布

$$P_{X,Y_\lambda} = \lambda P_{X,Y} + (1-\lambda)P_{X,Y^*}\,.$$

然后，我们可以计算

$$\begin{aligned} I(X;Y_\lambda) &= \mathbb{E}\left[\log \frac{P_{X|Y_\lambda}}{P_X}(X|Y_\lambda)\right] = \mathbb{E}\left[\log \frac{P_{X|Y_\lambda}}{P_{X|Y^*}}\frac{P_{X|Y^*}}{P_X}\right] \\ &= D(P_{X|Y_\lambda}\|P_{X|Y^*}|P_{Y_\lambda}) + \mathbb{E}\left[\frac{P_{X|Y^*}(X|Y_\lambda)}{P_X}\right] \\ &= D(P_{X|Y_\lambda}\|P_{X|Y^*}|P_{Y_\lambda}) + \lambda I_1 + (1-\lambda)I_*\,. \end{aligned}$$

从这里我们将得出结论，类似于命题2.20，第一项为$o(\lambda)$，因此对于足够小的λ，我们应该有$I(X;\ Y_\lambda) < R(D)$，这与耦合P_{X,Y^*}的最优性矛盾。我们继续详细说明。对于每一个$\lambda \in [0,1]$ 定义

$$\begin{aligned} \rho_1(y) &\triangleq \frac{dP_Y}{dP_{Y^*}}(y) \\ \lambda(y) &\triangleq \frac{\lambda\rho_1(y)}{\lambda\rho_1(y) + \bar{\lambda}} \\ P^{(\lambda)}_{X|Y=y} &= \lambda(y)P_{X|Y=y} + \bar{\lambda}(y)P_{X|Y^*=y} \\ dP_{Y_\lambda} &= \lambda dP_Y + \bar{\lambda}dP_{Y^*} = (\lambda\rho_1(y) + \bar{\lambda})dP_{Y^*} \\ D(y) &= D(P_{X|Y=y}\|P_{X|Y^*=y}) \\ D_\lambda(y) &= D(P^{(\lambda)}_{X|Y=y}\|P_{X|Y^*=y})\,. \end{aligned}$$

注意:

$$\text{On } \{\rho_1 = 0\}: \quad \lambda(y) = D(y) = D_\lambda(y) = 0$$

否则 $\lambda(y) >$ 为0。由散度的凸性

$$D_\lambda(y) \le \lambda(y) D(y)$$

因此

$$\frac{1}{\lambda(y)} D_\lambda(y) 1\{\rho_1(y) > 0\} \le D(y) 1\{\rho_1(y) > 0\}\,.$$

注意，由（26.7），函数 $\rho_1(y)D(y)$ 是非负且 P_{Y^*}-可积的。然后，应用控制收敛定理我们得到

$$\lim_{\lambda\to 0} \int_{\{\rho_1>0\}} dP_{Y^*} \frac{1}{\lambda(y)} D_\lambda(y)\rho_1(y) = \int_{\{\rho_1>0\}} dP_{Y^*}\rho_1(y) \lim_{\lambda\to 0} \frac{1}{\lambda(y)} D_\lambda(y) = 0 \tag{26.8}$$

其中在最后一步我们应用了第5章的结果

$$D(P\|Q) < \infty \qquad \Longrightarrow \qquad D(\lambda P + \bar\lambda Q\|Q) = o(\lambda)$$

由于对于集合 $\{\rho_1 > 0\}$ 上的每个 y，当 $\lambda \to$ 趋于 0 时，我们有 $\lambda(y) \to$ 趋向 0。

另一方面，注意

$$\begin{aligned}
\int_{\{\rho_1>0\}} dP_{Y^*} \frac{1}{\lambda(y)} D_\lambda(y)\rho_1(y) 1\{\rho_1(y) > 0\} &= \frac{1}{\lambda} \int_{\{\rho_1>0\}} dP_{Y^*}(\lambda\rho_1(y) + \bar\lambda) D_\lambda(y) \\
&= \frac{1}{\lambda} \int_{\{\rho_1>0\}} dP_{Y_\lambda} D_\lambda(y) \\
&= \frac{1}{\lambda} \int_{\mathcal{Y}} dP_{Y_\lambda} D_\lambda(y) = \frac{1}{\lambda} D(P^{(\lambda)}_{X|Y}\|P_{X|Y^*}|P_{Y_\lambda})\,,
\end{aligned}$$

其中在倒数第二步我们使用了$D_\lambda(y) = 0$在$\{\rho_1 = 0\}$上。因此，(26.8)表明

$$D(P^{(\lambda)}_{X|Y}\|P_{X|Y^*}|P_{Y_\lambda}) = o(\lambda)\,, \qquad \lambda \to 0\,.$$

最后，由于

$$P^{(\lambda)}_{X|Y} \circ P_{Y_\lambda} = P_X\,,$$

我们有

$$\begin{aligned}
I(X;Y_\lambda) &= D(P^{(\lambda)}_{X|Y}\|P_{X|Y^*}|P_{Y_\lambda}) + \lambda\,\mathbb{E}\left[\log \frac{dP_{X|Y^*}}{dP_X}(X|Y)\right] + \bar\lambda\,\mathbb{E}\left[\log \frac{dP_{X|Y^*}}{dP_X}(X|Y^*)\right] \\
&= I^* + \lambda(I_1 - I^*) + o(\lambda)\,,
\end{aligned}$$

与假设矛盾

$$I(X;Y_\lambda) \ge I^* = R(D)\,.$$

□

26.3 有损联合信源信道编码

扩展第19.7节中研究的无损联合信源信道编码问题，本节我们研究其有损版本：如何通过有噪信道传输信源，使得接收端能够在规定的失真范围内重建原始信源?

有损联合信源信道编码问题的设置如下。对于每个 k 和 n，给定一个在 $\mathcal{S}$ 上取值的信源 $S^k = (S_1, \ldots, S_k)$、一个失真度量 d: $\mathcal{S}^k \times \hat{\mathcal{S}}^k \to \mathbb{R}$，以及一个从 $\mathcal{A}^n$ 作用到 $\mathcal{B}^n$ 的信道 $P_{Y^n|X^n}$。有损联合信源信道码（JSCC）由一个编码器 f: $\mathcal{S}^k \to \mathcal{A}^n$ 和一个解码器 g: $\mathcal{B}^n \to \hat{\mathcal{S}}^k$ 组成，使得信道输入为 $X^n = f(S^k)$，且重构 $\hat{S}^k = g(Y^n)$ 满足 $\mathbb{E}[d(S^k, \hat{S}^k)] \le D$。根据定义，我们有马尔可夫链

$$S^k \xrightarrow{f} X^n \xrightarrow{P_{Y^n|X^n}} Y^n \xrightarrow{g} \hat{S}^k$$

这样的一对 (f, g) 被称为 (k, n, D)-JSCC，它通过 n 次信道使用传输 k 个符号，使得端到端失真在期望上至多为 D。我们的目标是优化编码器/解码器对，以最大化传输速率（每次信道使用的符号数）$R = \frac{k}{n}$。[1] 因此，我们将渐近基本极限定义为

$$R_{\mathrm{JSCC}}(D) \triangleq \liminf_{n\to\infty} \frac{1}{n} \max\{k : \exists (k, n, D)\text{-JSCC}\}.$$

为了简化说明，我们将重点讨论针对平稳无记忆源$S^k \sim P_S^{\otimes k}$的JSCC，该源通过受可分离失真函数$d(s^k, \hat{s}^k) = \frac{1}{k}\sum_{i=1}^k d(s_i, \hat{s}_i)$约束的平稳无记忆信道$P_{Y^n|X^n} = P_{Y|X}^{\otimes n}$传输。

26.3.1 逆命题

JSCC的逆定理相当简单，它基于数据处理不等式，并遵循使用Fano不等式无损JSCC的弱逆定理。

定理 26.5（逆定理）

$$R_{\mathrm{JSCC}}(D) \le \frac{C}{R(D)},$$

where $C = \sup_{P_X} I(X;\ Y)$ *is the capacity of the channel and* $R(D) = \inf_{P_{\hat{S}|S}:\mathbb{E}[d(S,\hat{S})]\le D} I(S; \hat{S})$ *is the rate-distortion function of the source.*

这个结果的解释很清楚：由于我们每个符号至少需要$R(D)$比特才能在失真D以内重建信源，而每次信道使用最多能传输C比特，因此总体传输速率不能超过$C/R(D)$。注意，上述定理显然对有代价约束的信道也成立，其相应容量见第20章。

[1] Or equivalently, minimize the *bandwidth expansion factor* $\rho = \frac{n}{k}$.

Proof. 考虑一个（k,n,D）码，它诱导出马尔可夫链 $S^k \to X^n \to Y^n \to \hat{S}^k$，使得 $\mathbb{E}[d(S^k,\hat{S}^k)] = \frac{1}{k}\sum_{i=1}^k \mathbb{E}[d(S_i,\hat{S}_i)] \le D$。那么

$$kR(D) \overset{\text{(a)}}{=} \inf_{P_{\hat{S}^k|S^k}:\mathbb{E}[d(S^k,\hat{S}^k)]\le D} I(S^k;\hat{S}^k) \overset{\text{(b)}}{\le} I(S^k;\hat{S}^k) \le I(X^n;Y^n) \le \sup_{P_{X^n}} I(X^n;Y^n) \overset{\text{(c)}}{=} nC$$

其中 (b) 应用了互信息的数据处理不等式，(a) 和 (c) 分别由有损压缩和信道编码的单字母化结果（定理24.8和命题19.10）得出。

□

注26.4 考虑源为Ber(1/2)且具有汉明失真的情况。此时，定理26.5与(19.33)中基于误比特率P_b的信道编码逆定理相吻合：

$$R = \frac{k}{n} \le \frac{C}{1-h(P_b)}$$

这在之前定理19.21中已给出，并使用了特定技巧进行证明。对于具有成本约束的信道，例如，具有C(信噪比) $= \frac{1}{2}\log(1+$ 信噪比)的AWGN信道，我们得到

$$P_b \ge h^{-1}\left(1 - \frac{C(\text{SNR})}{R}\right)$$

这通常被称为香农极限，在比较实际码的误码率的图表中经常被提及。（例如，参见[359]中关于BIAWGN（二进制输入）信道的图2。）*This is erroneous*，因为上面的p_b指的是数据位（或系统位）的误码率，而不是所有码字位的误码率。后者在编码理论文献中通常被称为BER（见(19.33)）。

26.3.2 通过分离实现可达性

证明策略与 *separately* 第19.7节中的无损JSCC类似，通过构造信道编码方案和有损压缩方案，而不是联合优化JSCC编码器/解码器对。具体来说，首先将数据压缩成比特，然后用信道码进行编码；解码时，应用信道解码器，随后是源解压器。在适当的假设下，这种单独设计的方案达到了定理26.5中的最优速率。

定理 26.6 *For any stationary memoryless source $(P_S,\mathcal{S},\hat{\mathcal{S}},d)$ with rate-distortion function $R(D)$ satisfying Assumption 26.1 (below), and for any stationary memoryless channel $P_{Y|X}$ with capacity C,*

$$R_{\text{JSCC}}(D) = \frac{C}{R(D)}.$$

关于源端的假设26.1（这一假设较为技术性，初次阅读时可跳过）旨在控制由信道解码器出错所引起的失真。尽管这是一个低概率事件，但在没有对失真度量作出任何假设的情况下，我们无法对其在端到端平均失真中的贡献做出太多说明。（请注意，这一问题在无损

JSCC）。假设26.1对于有界失真（例如汉明失真）而言是显然成立的，并且可以证明更一般地成立，比如对于高斯源和MSE失真。

Proof. 鉴于定理26.5，我们仅证明可达性。我们按照以下方式构建了一种分离的压缩/信道编码方案：

- 令 (f_s, g_s) 为压缩 S^k 的 $(k, 2^{kR(D)+o(k)}, D)$-码，使得 $\mathbb{E}[d(S^k, g_s(f_s(S^k))] \le D$。根据引理 26.8（下文），我们可以假设所有重建点与某个固定字符串相距不远，即：

$$d(s_0^k, g_s(i)) \le L \tag{26.9}$$

  对于所有 i 和某个常数 L，其中 $s_0^k = (s_0, \ldots, s_0)$ 来自下面的假设26.1。
- 设 (f_c, g_c) 是一个关于信道 $P_{Y^n|X^n}$ 的 $(n, 2^{nC+o(n)}, \epsilon_n)_{\max}$-码，使得 $kR(D) + o(k) \le nC + o(n)$，并且最大错误概率 $\epsilon_n \to$ 当 $n \to \infty$ 时趋近于 0。由于定理19.9和推论19.5，这样的码存在。

设JSCC编码器和解码器分别为$f = f_c \circ f_s$和$g = g_s \circ g_c$。因此，整个系统是

$$S^k \xrightarrow{f_s} W \xrightarrow{f_c} X^n \longrightarrow Y^n \xrightarrow{g_c} \hat{W} \xrightarrow{g_s} \hat{S}^k.$$

注意，这里我们需要控制信道码的*maximal*错误概率，因为当我们把这两种方案级联时，信道输入端的W是信源压缩器的输出，它不一定是均匀的。

为了分析平均失真，我们根据信道解码是否成功来考虑两种情况：

$$\mathbb{E}[d(S^k, \hat{S}^k)] = \mathbb{E}[d(S^k, g_s(W))1\{W = \hat{W}\}] + \mathbb{E}[d(S^k, g_s(\hat{W}))1\{W \ne \hat{W}\}].$$

根据我们对有损码的假设，第一项最多为D。对于第二项，根据我们对信道码的假设，我们有$\mathbb{P}[W \ne \hat{W}] \le \epsilon_n = o(1)$。然后

$$\begin{aligned}
\mathbb{E}[d(S^k, g_s(\hat{W}))1\{W \ne \hat{W}\}] &\overset{(a)}{\le} \mathbb{E}[1\{W \ne \hat{W}\}\lambda(d(S^k, \hat{s}_0^k) + d(s_0^k, g_s(\hat{W})))] \\
&\overset{(b)}{\le} \lambda \cdot \mathbb{E}[1\{W \ne \hat{W}\}d(S^k, \hat{s}_0^k)] + \lambda L \cdot \mathbb{P}[W \ne \hat{W}] \\
&\overset{(c)}{=} o(1),
\end{aligned}$$

其中(a)由下文假设26.1(a)中的广义三角不等式得出；(b)源自(26.9)；在(c)中，我们应用了引理25.4，该引理先前用于证明(25.15)中期望的消失。

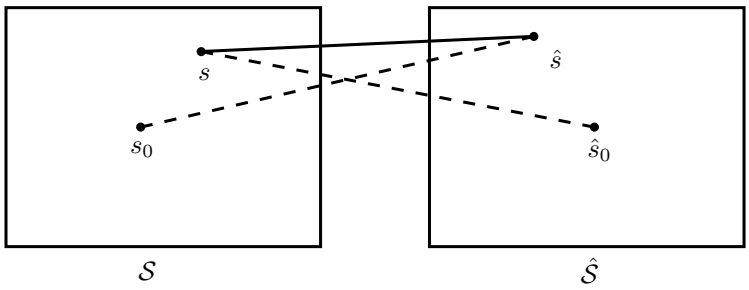
总之，我们的方案满足平均失真约束。由此我们得出结论，对于所有$R > C/R(D)$，存在一个$(k, n, D + o(1))$-JSCC码序列。 □

先前定理需要以下假设：

假设 26.1 固定 D。对于源 $(P_S, \mathcal{S}, \hat{\mathcal{S}}, d)$，存在 $\lambda \ge 0, s_0 \in \mathcal{S}, \hat{s}_0 \in \hat{\mathcal{S}}$ 使得

(a) 广义三角不等式：$d(s,\hat{s}) \le \lambda(d(s,\hat{s}_0) + d(s_0,\hat{a}))\ \forall a,\hat{a}$。 (b) $\mathbb{E}[d(S,\hat{s}_0)] < \infty$ (，使得 $D_{\max} < \infty$ 也)。 (c) $\mathbb{E}[d(s_0,\hat{S})] < \infty$ 对于任何达到率失真函数 $R(D)$ 的输出分布 $P_{\hat{S}}$。 (d) $d(s_0,\hat{s}_0) < \infty$。

该假设的解释是，空间 $\mathcal{S}$ 和 $\hat{\mathcal{S}}$ 拥有“良好的中心” s_0 和 $\hat{s}_0$，这意味着任意两点之间的距离被中心到每个点的距离的常数倍所上界（见下图）。



注意，假设26.1并不容易验证。接下来我们给出一些更方便的充分条件。首先，对于有界失真函数，假设26.1自动成立。换句话说，对于有限字母表$\mathcal{S}$上的离散源、有限重构字母表$\hat{\mathcal{S}}$和有限失真函数$d(s,\hat{s}) < \infty$，假设26.1是满足的。更一般地，我们有以下准则。

定理 26.7 *If $\mathcal{S} = \hat{\mathcal{S}}$ and $d(s,\hat{s}) = \rho(s,\hat{s})^q$ for some metric ρ and $q \ge 1$, and $D_{\max} \triangleq \inf_{\hat{s}_0} \mathbb{E}[d(S,\hat{s}_0)] < \infty$, then Assumption 26.1 holds.*

Proof. 取 $s_0 = \hat{s}_0$ 使得有限 $D_{\max} = \mathbb{E}[d(S,\hat{s}_0)]$ 成立。（实际上，在度量空间中任何点都可以作为中心）。应用三角不等式和 Jensen 不等式，我们得到

$$\left(\frac{1}{2}\rho(s,\hat{s})\right)^q \le \left(\frac{1}{2}\rho(s,s_0) + \frac{1}{2}\rho(s_0,\hat{s})\right)^q \le \frac{1}{2}\rho^q(s,s_0) + \frac{1}{2}\rho^q(s_0,\hat{s}).$$

因此 $d(s,\hat{s}) \le 2^{q-1}(d(s,s_0) + d(s_0,\hat{s}))$。取 $\lambda = 2^{q-1}$ 验证了假设 26.1 中的 (a) 和 (b)。为了验证 (c)，我们可以应用这个广义三角不等式得到 $d(s_0,\hat{S}) \le 2^{q-1}(d(s_0,S) + d(S,\hat{S}))$。然后对两边取期望得到

$$\begin{aligned}\mathbb{E}[d(s_0,\hat{S})] &\le 2^{q-1}(\mathbb{E}[d(s_0,S)] + \mathbb{E}[d(S,\hat{S})]) \\ &\le 2^{q-1}(D_{\max} + D) < \infty.\end{aligned}$$

□

因此我们看到，度量被提升到幂次（例如平方范数）满足假设26.1。最后，我们给出定理26.6证明中使用的引理。

引理 26.8 *Fix a source satisfying Assumption 26.1 and an arbitrary $P_{\hat{S}|S}$. Let $R > I(S;\hat{S})$, $L > \max\{\mathbb{E}[d(s_0,\hat{S})], d(s_0,\hat{s}_0)\}$ and $D > \mathbb{E}[d(S,\hat{S})]$. Then, there exists a $(k, 2^{kR}, D)$-code such that $d(s_0^k,\hat{s}^k) \le L$ for every reconstruction point $\hat{s}^k$, where $s_0^k = (s_0,\dots,s_0)$.*

Proof. 令 $\mathcal{X} = \mathcal{S}^k$、$\hat{\mathcal{X}} = \hat{\mathcal{S}}^{\otimes k}$ 和 $P_X = P_S^k, P_{Y|X} = P_{\hat{S}|S}^{\otimes k}$。我们将定理 25.3 中关于超额失真的可达性界，取 $\gamma = 2^{k(R+I(S;\hat{S}))/2}$，应用于以下 *non-separable* 失真函数

$$d_1(x,\hat{x}) = \begin{cases} d(x,\hat{x}) & d(s_0^k,\hat{x}) \le L \\ +\infty & \text{otherwise.} \end{cases}$$

对于任意 $D' \in (\mathbb{E}[d(S,\hat{S})], D)$，存在 $M =$ 个 2^{kR} 重建点（$c_1,\dots,c_M$），使得

$$\mathbb{P}\left[\min_{j\in[M]} d(S^k,c_j) > D'\right] \le \mathbb{P}[d_1(S^k,\hat{S}^k) > D'] + o(1),$$

其中在右侧（$S^k,\hat{S}^k$）$\sim P_{S,\hat{S}}^{\otimes k}$。注意，在$d_1$-失真没有任何变化的情况下，我们可以移除所有（如果有的话）满足$d(s_0^k,c_j) > L$的重构点c_j。此外，根据弱大数定律，我们有

$$\mathbb{P}[d_1(S,\hat{S}) > D'] \le \mathbb{P}[d(S^k,\hat{S}^k) > D'] + \mathbb{P}[d(s_0^k,\hat{S}^k) > L] \to 0$$

由于 $k \to \infty$ (，因为 $\mathbb{E}[d(S,\hat{S})] < D'$ 以及 $\mathbb{E}[d(s_0,\hat{S})] < L$)。因此我们有

$$\mathbb{P}\left[\min_{j\in[M]} d(S^k,c_j) > D'\right] \to 0$$

以及$d(s_0^k,c_j) \le L$。最后，通过添加另一个重建点$c_{M+1} = \hat{s}_0^k = (\hat{s}_0,\dots,\hat{s}_0)$，我们得到

$$\mathbb{E}\left[\min_{j\in[M+1]} d(S^k,c_j)\right] \le D' + \mathbb{E}\left[d(S^k,\hat{s}_0^k)1\left\{\min_{j\in[M]} d(S^k,c_j) > D'\right\}\right] = D' + o(1),$$

其中最后的估计遵循与证明 (25.15) 中期望消失相同的论证。因此，对于足够大的 n，期望失真至多为 D，正如所需。 □

26.4 经典有损压缩中缺失了什么?

让我们讨论经典压缩理论中的一些问题和未解决的问题。首先，对于*compression*，无损压缩的标准结果非常适用于文本文件。然而，有损压缩理论依赖于独立性假设和可分离的失真度量。因此，尽管标量量化理论在实践中已被广泛使用（以模数转换器ADC的形式），但向量量化器（率失真）理论迄今为止尚未被采用。在压缩数字图像的情况下，率失真理论的假设尤其成问题，因为数字图像显然具有非常强的

与一维信号相比，空间相关性更为显著。（例如，托尔斯泰小说的第一句和最后一句几乎不相关。但一幅图像的左上角和右下角区域却可能高度相关。同时，小说和图像的未压缩大小可能很容易相等。）因此，对于视频和图像的有损压缩实践而言，关键问题在于提出一种良好的“白化”基，这仍然是一门不断精进的艺术。

对于联合信源信道编码，分离原理无疑是整个数字信息技术发展的指路明灯。但如今，香农分离原理所宣称的这种无处不在的解决方案，导致了一个相当不受欢迎的特性：当信噪比低于某一阈值时，蜂窝通话会掉线（与旧式模拟电话质量缓慢下降相反），或者电视上会出现“雪花屏”。也就是说，分离系统可能非常不稳定，或者说缺乏 *graceful degradation*。为了勾勒这一效应，考虑一个JSCC的例子，其中源分布为Ber($\frac{1}{2}$)，率失真函数为$R(D) = 1 - h(D)$，信道为BSC_δ，容量为$C(\delta) = 1 - h(\delta)$。考虑两种解决方案：

1. 分离方案：针对某一可接受的失真水平 D^*，我们以速率 $R(D^*)$ 压缩信源。然后我们可以使用速率为 $R(D^*)$ 的信道编码，只要 $R(D^*) < C(\delta)$，即 $\delta < D^*$，就能实现误差趋于零。总体而言，该方案的带宽扩展因子为 $\rho = \frac{n}{k} = 1$。注意存在对所有 $\delta < \delta^* = D^*$ 都工作于 *simultaneously* 的信道编码（练习 IV.8 和 IV.10）。2. 一种简单的 JSCC，其 $\rho =$ 为 1，传输“未编码”数据，即设置 $X_i = S_i$。

对于大块长度，所实现的失真在图26.2中显示为δ的函数。我们现在可以看出为什么分离解决方案，尽管在某种意义上是优化的，但并不是理想的。首先，在

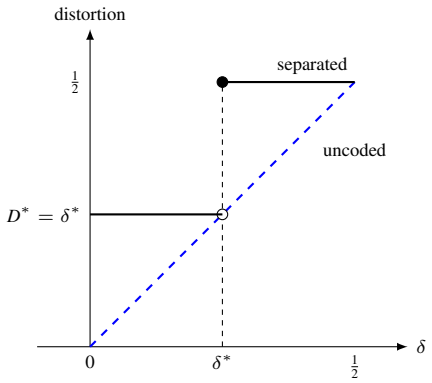


图26.2 分别设计的源信道码（黑色实线）与未编码传输（蓝色虚线）相比，未展现出优雅降级。

$\delta < \delta^*$ 分离方案确实达到了可接受的失真度D^*，但与未编码系统不同的是，即使信道改善，它也不会有所提升，即失真度保持在D^*不变。其次，也是更为重要的一点，是 $\delta > \delta^*$的问题。在此情况下，分离方案经历了一个

灾难性故障和失真变成1/2（也就是说，我们观察到纯噪声，或者用电视术语来说就是“雪花”）。与此同时，简单的“未编码”JSCC的失真也在恶化，但*gracefully*如此。遗憾的是，这种优雅的方案仅在极少数情况下已知，需要$\rho = 1$以及信道噪声与源（失真度量）之间的某些“完美匹配”条件[2]。寻找对一般源信道对和一般ρ表现出非灾难性退化的方案，是信息论中一个长期存在的（实践和理论上的）开放问题。

即使从纯理论角度来看，JSCC 的问题仍然包含许多谜团。例如，在第 22.5 节中，我们描述了信道编码速率作为块长度的函数的精细展开。特别地，我们已经看到，向信道容量的收敛以$\frac{1}{\sqrt{n}}$的速率发生，这是相当慢的。与此同时，向率失真函数的收敛几乎以$\frac{1}{n}$(的速率发生，见练习 V.3 和 V.4)。因此，JSCC 的收敛速率可能是什么并不清楚。不幸的是，这里精确的结果仍处于萌芽阶段。事实上，即使对于二进制源和BSC_δ信道的最典型设置，也只是最近才表明 [248]，最优速率$\frac{k}{n}$以$\Theta(1/\sqrt{n})$的速度收敛到$\frac{C}{R(D)}$的最终极限，除非满足 Gastpar 条件$R(D) = C(\delta)$。分析其他源-信道对或任何此类一般结果，是另一个重要的 *open problem*。

[2] Often informally called “Gastpar conditions” after [181].

27 Metric entropy

在本部分的先前章节中，我们讨论了随机向量在固定维度和高维下的最优量化。作为对平均情况视角的补充，本章的主题是量化的确定性（最坏情况）理论。我们关注的主要对象是集合的 *metric entropy*，它使我们能够回答两个关键问题：(a) 覆盖数：以给定精度覆盖一个集合所需的最少点数；(b) 填充数：给定集合中具有指定最小成对距离的最大元素数量。

度量熵的基础理论由柯尔莫哥洛夫提出，他与他的学生一起，还确定了有限维和无限维各种问题中度量熵的行为。柯尔莫哥洛夫最初对这个主题的兴趣源于希尔伯特的第13个问题，该问题涉及将多变量函数表示为较少变量函数的复合的可能性或不可能性。事实证明，度量熵理论可以为这类问题提供出奇简单而有力的解决。多年来，度量熵在逼近论、经验过程、小球概率、数理统计和机器学习等其他领域中发现了众多联系和应用。特别地，度量熵将在本书的第六部分中显著体现，我们在其中讨论其在证明统计估计的下界和上界方面的应用。

本章的结构如下。第27.1节提供了基本定义，并解释了覆盖数与填充数之间的基本联系。这些基础由柯尔莫哥洛夫和季霍米罗夫在[250]中奠定，至今仍是该主题的权威参考。在第27.2节中，我们研究有限维空间中的度量熵，以及一种称为体积界的用于界定度量熵的常用方法。为了展示体积方法的局限性及与之相关的高维现象，在第27.3节中我们通过具体例子讨论了几种其他方法。接下来，第27.4节处理光滑函数的无限维空间（其中我们还讨论了在希尔伯特第13问题上的应用），第27.3.2节处理希尔伯特空间（其中我们还讨论了在经验过程中的应用）。第27.5节阐述了度量熵与概率论中小球问题之间的联系。最后，在第27.6节中我们回到率失真理论，讨论它与度量熵的关系，以及信息论方法如何对后者有用。

27.1 覆盖与填充

定义27.1 设 (V, d) 为度量空间，$\Theta \subset V$。

- 如果 $\Theta \subset \cup_{i=1}^{N} B(v_i, \epsilon)$，则称 $\{v_1, ..., v_N\} \subset V$ 是 Θ 的 ϵ-*covering* (或 ϵ-*net*)，其中 $B(v, \epsilon) \triangleq \{u \in V : d(u, v) \leq \epsilon\}$ 是以 v 为中心、半径为 ϵ 的（闭）球；或等价地，$\forall \theta \in \Theta$、$\exists i \in [N]$ 使得 $d(\theta, v_i) \leq \epsilon$。
- 如果 $\min_{i \neq j} \|\theta_i - \theta_j\| > \epsilon$;[1]，则称 $\{\theta_1, ..., \theta_M\} \subset \Theta$ 是 Θ 的一个 ϵ-*packing*；等价地，球 $\{B(\theta_i, \epsilon/2) : j \in [M]\}$ 是不相交的。

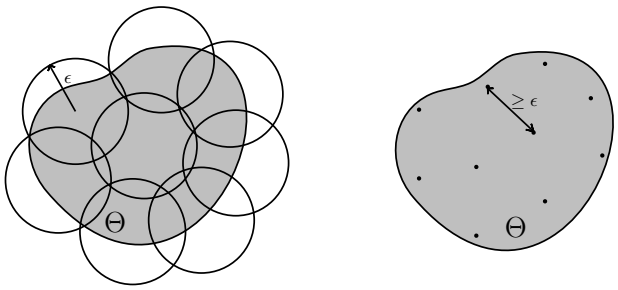


图27.1 ϵ-覆盖和ϵ-包装的示意图。

在定义了 ϵ-覆盖和 ϵ-填充之后，一个自然的问题涉及最优覆盖和填充的大小，从而引出了 *covering* 和 *packing numbers* 的定义：

$$N(\Theta, d, \epsilon) \triangleq \min\{n : \exists\ \epsilon\text{-covering of } \Theta \text{ of size } n\} \tag{27.1}$$

$$M(\Theta, d, \epsilon) \triangleq \max\{m : \exists\ \epsilon\text{-packing of } \Theta \text{ of size } m\} \tag{27.2}$$

其中 $\min \emptyset$ 被理解为 ∞；为简洁起见，我们有时会将这些缩写为 $N(\epsilon)$ 和 $M(\epsilon)$。与体积和宽度类似，覆盖数和填充数为集合的“庞大程度”提供了有意义的度量。本章的主要重点是理解它们在有限维和无限维空间中的行为，以及它们的统计应用。

需要作几点说明。

• 单调性：$N(\Theta, d, \epsilon)$ 和 $M(\Theta, d, \epsilon)$ 是 ϵ 的非递减且右连续函数。此外，二者关于集合包含关系对 Θ 均非递减。• 有限性：若对所有 $\epsilon > 0$ 有 $N(\Theta, d, \epsilon) < \infty$，则 Θ 是全有界的（例如紧致的）。对于欧几里得空间，这等价于 Θ 有界，即 $\text{diam}(\Theta) < \infty$ (参见 (5.4))。• 覆盖数与填充数的对数通常被称为 *metric entropy*。特别地，$\log M(\epsilon)$ 和 $\log N(\epsilon)$ 在 [250] 中分别称为 ϵ-*entropy* 和 ϵ-*capacity*。度量熵与其他信息度量之间的定量联系将在第27.6节探讨。• 在泛函分析文献 [329, 285] 中广泛使用的 *entropy numbers* 概念，本质上指的是度量熵的逆：Θ 的第 k 个熵数是 $e_k(\Theta) \triangleq \inf\{\epsilon : N(\Theta, d, \epsilon) \leq 2^{k-1}\}$。特别地，$e_1(\Theta) = \text{rad}(\Theta)$，即 (5.3) 中定义的 Θ 的半径。

[1] Notice we imposed strict inequality for convenience.

注27.1 与填充数$M(\Theta, d, \epsilon)$不同，(27.1)中定义的覆盖数$N(\Theta, d, \epsilon)$隐含地依赖于周围空间$V \supset \Theta$，因为根据定义27.1，一个ϵ-覆盖需要是V的子集而非Θ。然而，如下一个定理27.2所示，这种对V的依赖几乎不影响覆盖数的性质。

作为(27.1)的替代方案，我们可以将$N'(\Theta, d, \epsilon)$定义为Θ的最小ϵ-覆盖的大小，该覆盖同时也是Θ的子集，这与原始定义密切相关，如同

$$N(\Theta, d, \epsilon) \leq N'(\Theta, d, \epsilon) \leq N(\Theta, d, \epsilon/2) \tag{27.3}$$

在此，左侧的不等式是显而易见的。为了理解右侧的不等式，[2] 设 $\{\theta_1, \ldots, \theta_N\}$ 为 Θ 的一个 $\frac{\epsilon}{2}$ 覆盖。我们可以通过定义 $\theta_i' =$ 为 $\operatorname{argmin}_{u \in \Theta} d(\theta_i, u)$，将每个 θ_i 投影到 Θ 上。于是，$\{\theta_1', \ldots, \theta_N'\} \subset \Theta$ 构成了一个 ϵ 覆盖。事实上，对于任意的 $\theta \in \Theta$，存在某个 θ_i 使得 $d(\theta, \theta_i) \leq \epsilon/ \leqslant 2$，进而 $d(\theta, \theta_i') \leq d(\theta, \theta_i) + d(\theta_i, \theta_i') \leq \leqslant 2d(\theta, \theta_i) \leq \epsilon$。另一方面，$N'$ 覆盖数关于集合包含关系未必是单调的。

覆盖数与填充数之间的关系由以下基本结果描述。

定理 27.2（Kolomogrov-Tikhomirov [250]）

$$M(\Theta, d, 2\epsilon) \leq N(\Theta, d, \epsilon) \leq M(\Theta, d, \epsilon). \tag{27.4}$$

Proof. 为了证明右不等式，固定一个极大填充 $E = \{\theta_1, ..., \theta_M\}$。那么 $\forall \theta \in \Theta \backslash E$，$\exists i \in [M]$，使得 $d(\theta, \theta_i) \leq \epsilon$ (，否则我们可以通过添加 θ) 得到一个更大的填充。因此 E 必须是一个 ϵ-覆盖（同时也是 Θ 的子集）。由于 $N(\Theta, d, \epsilon)$ 是所有可能覆盖的最小大小，我们有 $M(\Theta, d, \epsilon) \geq N(\Theta, d, \epsilon)$。

我们接下来用反证法证明左边的不等式。假设存在一个2ϵ-填充$\{\theta_1, ..., \theta_M\}$和一个$\epsilon$-覆盖$\{x_1, ..., x_N\}$，使得$M \geq N + 1$。那么根据鸽巢原理，存在不同的$\theta_i$和$\theta_j$属于同一个$\epsilon$-球$B(x_k, \epsilon)$。根据三角不等式，$d(\theta_i, \theta_j) \leq 2\epsilon$，这与$d(\theta_i, \theta_j) > 2\epsilon$对于$2\epsilon$-填充相矛盾。因此，任何$2\epsilon$-填充的大小至多等于任何$\epsilon$-覆盖的大小，即$M(\Theta, d, 2\epsilon) \leq N(\Theta, d, \epsilon)$。

□

(27.4)的意义在于它表明覆盖数和填充数的小{vt63}行为本质上是相同的。此外，其中的右不等式，即$N(\epsilon) \leq M(\epsilon)$，值得特别提及。正如我们接下来将看到的，证明负面结果（最小覆盖的下界或最大填充的上界）通常比需要显式构造的正面结果更容易。当与不等式$N(\epsilon) \leq M(\epsilon)$结合使用时，这些逆命题转化为可实现性陈述，[3]从而导出许多有用的度量熵界（例如定理27.3中的体积界和Gilbert-Varshamov界

[2] Another way to see this is from Theorem 27.2: Note that the right inequality in (27.4) yields a ϵ-covering that is included in Θ. Together with the left inequality, we get $N'(\epsilon) \leq M(\epsilon) \leq N(\epsilon/2)$.

[3] This is reminiscent of duality-based argument in optimization: To bound a minimization problem from above, instead of constructing an explicit feasible solution, a fruitful approach is to equate it with the dual problem (maximization) and bound this maximum from above.

下一节的定理27.5）。回顾定理27.2的证明，我们发现这一逻辑实际上对应于 *greedy construction* (贪心地增加填充，直到无法再添加点为止)。

27.2 有限维空间与体积界

在有限维中，约束度量熵的一种常用方法是通过*volume ratio*来表示。考虑d维欧几里得空间$V = \mathbb{R}^d$，其度量由任意范数$d(x,y) = \|x-y\|$给出。我们得到以下结果。

定理27.3 *Let $\|\cdot\|$ be an arbitrary norm on $\mathbb{R}^d$ and $B = \{x \in \mathbb{R}^d\colon \|x\| \le 1\}$ the corresponding unit norm ball. Then for any $\Theta \subset \mathbb{R}^d$,*

$$\left(\frac{1}{\epsilon}\right)^d \frac{\mathrm{vol}(\Theta)}{\mathrm{vol}(B)} \overset{(a)}{\le} N(\Theta, \|\cdot\|, \epsilon) \le M(\Theta, \|\cdot\|, \epsilon) \overset{(b)}{\le} \frac{\mathrm{vol}(\Theta + \frac{\epsilon}{2}B)}{\mathrm{vol}(\frac{\epsilon}{2}B)} \overset{(c)}{\le} \left(\frac{3}{\epsilon}\right)^d \frac{\mathrm{vol}(\Theta)}{\mathrm{vol}(B)}.$$

where (c) holds under the extra condition that Θ is convex and contains ϵB.

Proof. 为了证明 (a)，考虑一个 ϵ-覆盖 $\Theta \subset \cup_{i=1}^N B(\theta_i, \epsilon)$。应用并集界可得

$$\mathrm{vol}(\Theta) \le \mathrm{vol}\Big(\cup_{i=1}^N B(\theta_i, \epsilon)\Big) \le \sum_{i=1}^N \mathrm{vol}(B(\theta_i, \epsilon)) = N\epsilon^d \mathrm{vol}(B),$$

其中最后一步由体积的平移不变性和缩放性质得出。

为了证明 (b)，考虑一个 ϵ-填充 $\{\theta_1, \dots, \theta_M\} \subset \Theta$，使得球 $B(\theta_i, \epsilon/2)$ 互不相交。由于 $\cup_{i=1}^{M(\epsilon)} B(\theta_i, \epsilon/2) \subset \Theta + \frac{\epsilon}{2}B$，对两边取体积得到

$$\mathrm{vol}\Big(\Theta + \frac{\epsilon}{2}B\Big) \ge \mathrm{vol}\Big(\cup_{i=1}^M B(\theta_i, \epsilon/2)\Big) = M\mathrm{vol}\Big(\frac{\epsilon}{2}B\Big).$$

这证明了(b)。

最后，(c) 可由以下两个陈述推出：(1) 若 $\epsilon B \subset \Theta$，则 $\Theta + \frac{\epsilon}{2}B \subset \Theta + \frac{1}{2}\Theta$；以及 (2) 若 Θ 是凸的，则 $\Theta + \frac{1}{2}\Theta = \frac{3}{2}\Theta$。我们只证明 (2)。首先，$\forall \theta \in \frac{3}{2}\Theta$，我们有 $\theta = \frac{1}{3}\theta + \frac{2}{3}\theta$，其中 $\frac{1}{3}\theta \in \frac{1}{2}\Theta$ 和 $\frac{2}{3}\theta \in \Theta$。因此 $\frac{3}{2}\Theta \subset \Theta + \frac{1}{2}\Theta$。另一方面，对于任意 $x \in \Theta + \frac{1}{2}\Theta$，我们有 $x = y + \frac{1}{2}z$ 及 $y, z \in \Theta$。由 Θ 的凸性，$\frac{2}{3}x = \frac{2}{3}y + \frac{1}{3}z \in \Theta$。因此 $x \in \frac{3}{2}\Theta$，蕴含 $\Theta + \frac{1}{2}\Theta \subset \frac{3}{2}\Theta$。 □

备注27.2 类似于定理27.3中(a)的证明，我们可以从$\Theta + \frac{\epsilon}{2}B \subset \cup_{i=1}^N B(\theta_i, \frac{3\epsilon}{2})$出发得出结论：

$$(2/3)^d \le \frac{N(\Theta, \|\cdot\|, \epsilon)}{\mathrm{vol}(\Theta + \frac{\epsilon}{2}B)/\mathrm{vol}(\epsilon B)} \le 2^d.$$

换言之，膨胀集$\Theta + \frac{\epsilon}{2}$的体积在只依赖于维度的常数范围内决定了度量熵。我们将在第27.5节重新审视这一推理，以将体积估计适应于无限维情形，在此情形下，膨胀步骤变得必要。

接下来我们讨论定理27.3的几个应用。

推论 27.4（球与球面的度量熵）*Let $\|\cdot\|$ be an arbitrary norm on $\mathbb{R}^d$. Let $B \equiv B_{\|\cdot\|} = \{x \in \mathbb{R}^d\colon\ \|x\| \le 1\}$ and $S \equiv S_{\|\cdot\|} = \{x \in \mathbb{R}^d\colon\ \|x\| \le 1\}$ be the corresponding unit ball and unit sphere. Then for $\epsilon < 1$,*

$$\left(\frac{1}{\epsilon}\right)^d \le N(B, \|\cdot\|, \epsilon) \le \left(1 + \frac{2}{\epsilon}\right)^d \tag{27.5}$$

$$\left(\frac{1}{2\epsilon}\right)^{d-1} \le N(S, \|\cdot\|, \epsilon) \le 2d\left(1 + \frac{1}{\epsilon}\right)^{d-1} \tag{27.6}$$

where the left inequality in (27.6) holds under the extra assumption that $\|\cdot\|$ is an absolute norm (invariant to sign changes of coordinates).

Proof. 对于球，估计（27.5）直接由定理27.3得出，因为$B+\frac{\epsilon}{2}B = (1+\frac{\epsilon}{2})B$。接下来我们考虑球面。应用定理27.3中的(b)得到

$$\begin{aligned} N(S, \|\cdot\|, \epsilon) \le M(S, \|\cdot\|, \epsilon) &\le \frac{\mathrm{vol}(S + \epsilon B)}{\mathrm{vol}(\epsilon B)} \le \frac{\mathrm{vol}((1+\epsilon)B) - \mathrm{vol}((1-\epsilon)B)}{\mathrm{vol}(\epsilon B)} \\ &= \frac{(1+\epsilon)^d - (1-\epsilon)^d}{\epsilon^d} = \frac{d}{\epsilon^d}\int_{-\epsilon}^{\epsilon}(1+x)^{d-1}dx \le 2d\left(1+\frac{1}{\epsilon}\right)^{d-1}. \end{aligned}$$

其中第三个不等式通过三角不等式应用 $S + \epsilon B \subset ((1+\epsilon)B)\backslash((1-\epsilon)B)$。

最后，我们证明绝对范数 $\|\cdot\|$ 的下界（27.6）。为此，不能直接引用定理27.3中的下界，因为球的体积为零。注意 $\|\cdot\|' \triangleq \|(\cdot, 0)\|$ 定义了 $\mathbb{R}^{d-1}$ 上的一个范数。我们断言，对于单位 $\|\cdot\|'$-球，$\|\cdot\|'$ 中的每个 ϵ-填充都会诱导出单位 $\|\cdot\|$-球面在 $\|\cdot\|$ 中的一个 ϵ-填充。固定 $x \in \mathbb{R}^{d-1}$，使得 $\|(x,0)\| \le 1$，并通过 $f(y) = \|(x,y)\|$ 定义 $f\colon \mathbb{R}_+ \to \mathbb{R}_+$。利用 $\|\cdot\|$ 是绝对范数这一事实，容易验证 f 是一个连续递增函数，且 $f(0) \le 1$ 以及 $f(\infty) = \infty$。根据中值定理，存在 y_x，使得 $\|(x, y_x)\| = 1$。最后，对于单位球 $B_{\|\cdot\|'}$ 关于 $\|\cdot\|'$ 的任意 ϵ-填充 $\{x'_1, \ldots, x'_M\}$，令 $x'_i = (x_i, y_{x_i})$，我们有 $\|x'_i - x'_j\| \ge \|(x_i - x_j, 0)\| = \|x_i - x_j\|' \ge \epsilon$。这证明了

$$M(S_{\|\cdot\|}, \|\cdot\|, \epsilon) \ge M(B_{\|\cdot\|'}, \|\cdot\|', \epsilon).$$

然后 t(27.6) 的左不等式由 (27.4) 和 {v*} 的不等式推出。 (27.5)。 □

关于推论27.4的几点说明如下：

(a) 使用(27.5)，我们看到对于任何具有非空内部的紧致 Θ，我们有

$$N(\Theta, \|\cdot\|, \epsilon) \asymp M(\Theta, \|\cdot\|, \epsilon) \asymp \frac{1}{\epsilon^d} \tag{27.7}$$

对于小的 ϵ，比例常数依赖于 Θ 和范数。事实上，已知尖锐常数也存在。[250，定理 IX] 中证明了存在一个

仅依赖于 $\|\cdot\|$ 和维度的常数 τ，使得

$$M(\Theta, \|\cdot\|, 2\epsilon) = (\tau + o(1))\frac{\mathrm{vol}(\Theta)}{\mathrm{vol}(B)}\frac{1}{\epsilon^d}$$

对于任何体积为正的 Θ 都成立。这个常数 τ 是 *maximal sphere packing density*，在 $\mathbb{R}^d$ (填充中球体覆盖整个空间的比例——正式定义见 [365，第1章])；类似的结果和解释也适用于覆盖数。计算或界定 τ 的值极为困难，并且除了一些特殊情况外仍然未解决。[4] 关于此主题的更多内容，请参阅专著 [365, 99]。

(b) 球体的结果 (27.6) 表明，人们可能期望光滑流形 Θ 的度量熵表现为 $(\frac{1}{\epsilon})^{\dim}$，其中 dim 表示 Θ 的维数，而非环境维数。这在许多情况下确实成立，例如，在矩阵背景下，对于正交群 $O(d)$、酉群 $U(d)$ 和格拉斯曼流形 [406, 407]，此时 dim 对应于“自由度”（例如 ，对于 $O(d)$，$\dim = d(d-1)/2$）。更一般地，对于任意集合 Θ，可以将极限 $\lim_{\epsilon\to 0}\frac{\log N(\Theta,\|\cdot\|,\epsilon)}{\log\frac{1}{\epsilon}}$ 定义为其维数（称为 *Minkowski dimension* 或 *box-counting dimension*）。对于具有分形性质的集合，该维数可以是非整数（例如，康托集的 $\log_2 3$）。

(c) 由于欧几里得空间上的所有范数都是等价的（取决于维数的乘法常数因子内），只要维数 d 固定，(27.7) 中的小 ϵ 行为对任何范数都成立。然而，当允许 ϵ 依赖于 d 时，这一结果并未捕捉到 *high dimensions* 中的全貌。理解这些高维现象需要我们超越体积方法。详见第 27.3 节。

接下来我们将注意力转向汉明空间的离散情形。以下定理给出了其填充数 $M(\mathbb{F}_2^d, d_{\mathrm{H}}, r) \equiv M(\mathbb{F}_2^d, r)$ 的界，即长度为 d、具有指定最小距离 $r+1$.[5] 的二进制码字的最大数量。这是编码理论中的一个核心问题，其中下面的下界和上界分别称为 *Gilbert-Varshamov bound* 和 *Hamming bound*。

定理 27.5 *For any integer* $1 \le r \le d-1$,

$$\frac{2^d}{\sum_{i=0}^{r}\binom{d}{i}} \le M(\mathbb{F}_2^d, r) \le \frac{2^d}{\sum_{i=0}^{\lfloor r/2\rfloor}\binom{d}{i}}. \tag{27.8}$$

Proof. (27.8)中的两个不等式都遵循与定理27.3相同的论证，其中$\mathbb{R}^d$被$\mathbb{F}_2^d$替换，体积由计数测度（平移不变）替代。 □

编码理论特别感兴趣的是对于某个常数$\rho \in (0,1)$，$d\to\infty$和$r=\rho d$的渐近区域。利用二项式系数的渐近性（参见命题1.5），该

[4] For example, it is easy to show that $\tau = 1$ for both ℓ_∞ and ℓ_1 balls in any dimension since cubes can be subdivided into smaller cubes; for ℓ_2-ball in $d=2$, $\tau = \frac{\pi}{\sqrt{12}}$ is the famous result of L. Fejes Tóth on the optimality of hexagonal arrangement for circle packing [365].

[5] Recall that the packing number in Definition 27.1 is defined with a strict inequality.

汉明界和吉尔伯特-瓦尔沙莫夫界转化为

$$2^{d(1-h(\rho)+o(d)} \le M(\mathbb{F}_2^d, \rho d) \le 2^{d(1-h(\rho/2))+o(d)}.$$

确定精确指数是编码理论中最重要的未解问题之一。迄今为止，最好的上界是由McEliece、Rodemich、Rumsey和Welch [299]利用线性规划松弛技术得出的。

相反，Hamming 空间中相应的覆盖问题要简单得多，因为我们有如下紧致结果

$$N(\mathbb{F}_2^d, \rho d) = 2^{dR(\rho)+o(d)}, \tag{27.9}$$

其中 $R(\rho) = (1 - h(\rho))_+$ 是定理26.1中的Ber($\frac{1}{2}$)的率失真函数。尽管这并不自动遵循率失真理论，但可以通过类似的论证来证明——见练习V.26。

最后，我们陈述汉明球填充数的一个下界，这对于后续在稀疏估计中的应用（习题 VI.12）是必要的，并且对于在更复杂环境中计算度量熵作为基本构建块也是有用的（定理 27.7）。

定理27.6（Hamming球的Gilbert-Varshamov界）*Denote by*

$$S_k^d = \{x \in \mathbb{F}_2^d : w_{\mathrm{H}}(x) = k\} \tag{27.10}$$

the Hamming sphere of radius $0 \le k \le d$. *Then*

$$M(S_k^d, r) \ge \frac{\binom{d}{k}}{\sum_{i=0}^{r}\binom{d}{i}}. \tag{27.11}$$

In particular,

$$\log M(S_k^d, k/2) \ge \frac{k}{2}\log\frac{d}{2ek}. \tag{27.12}$$

Proof. 再次，(27.11) 由体积论证得出。为了验证 (27.12)，注意对于 $r \le d/2$，我们有 $\sum_{i=0}^{r}\binom{d}{i} \le \exp(dh(\frac{r}{d}))$（见定理 8.2 或 (15.19)，其中 $p = 1/2$）。利用 $h(x) \le x\log\frac{e}{x}$ 和 $\binom{d}{k} \ge (\frac{d}{k})^k$，我们从 (27.11) 得出 (27.12)。 □

27.3 超越体积界限

定理 27.3 中的体积界为研究欧几里得空间中的度量熵提供了一个有用的工具。因此，当 $\epsilon \to$ 趋于 0 时，任何具有非空内部的集合的覆盖数总是以 $(\frac{1}{\epsilon})^d$ 的形式随 d 呈指数增长——参见 (27.7)。然而，这一渐近结果有其局限性，并且当维度 d 很大且 ϵ 随 d 缩放时不适用。事实上，人们预期存在某个依赖于维度 d 的 ϵ 的临界阈值，低于该阈值时指数渐近是紧的，而高于该阈值时覆盖数可以随 d 呈多项式增长。这种高维现象并未被体积方法完全捕捉。

作为一个例子，考虑单位ℓ_1球内半径为ϵ的ℓ_2球的最大数量，即$M(B_1, \|\cdot\|_2, \epsilon)$。（回想一下，$B_p$表示$\mathbb{R}^d$中的单位$\ell_p$球，具有1个$\leq p \leq \infty$。）我们在推论27.4中研究了同一范数下任意范数球的度量熵，其中体积的特定值从体积比中抵消了。在这里，尽管ℓ_1和ℓ_2范数在$\|x\|_2 \leq \|x\|_1 \leq \sqrt{d}\|x\|_2$的意义上是等价的，但当$d$很大时，这种关系过于宽松。

让我们首先应用定理27.3中的体积方法：

$$\frac{\mathrm{vol}(B_1)}{\mathrm{vol}(\epsilon B_2)} \leq N(B_1, \|\cdot\|_2, \epsilon) \leq M(B_1, \|\cdot\|_2, \epsilon) \leq \frac{\mathrm{vol}(B_1 + \frac{\epsilon}{2}B_2)}{\mathrm{vol}(\frac{\epsilon}{2}B_2)}.$$

在$\mathbb{R}^d$中应用单位ℓ_q-球的体积公式：

$$\mathrm{vol}(B_q) = \frac{\left[2\Gamma\left(1+\frac{1}{q}\right)\right]^d}{\Gamma\left(1+\frac{d}{q}\right)}, \tag{27.13}$$

我们得到[6] $\mathrm{vol}(B_1) = 2^d/d!$ 以及 $\mathrm{vol}(B_2) = \frac{\pi^d}{\Gamma(1+d/2)}$，根据斯特林近似，

$$\mathrm{vol}(B_1)^{1/d} \asymp \frac{1}{d}, \quad \mathrm{vol}(B_2)^{1/d} \asymp \frac{1}{\sqrt{d}}. \tag{27.14}$$

然后对于某个绝对常数 C，

$$M(B_1, \|\cdot\|_2, \epsilon) \leq \frac{\mathrm{vol}(B_1 + \frac{\epsilon}{2}B_2)}{\mathrm{vol}(\frac{\epsilon}{2}B_2)} \leq \frac{\mathrm{vol}((1+\frac{\epsilon\sqrt{d}}{2})B_1)}{\mathrm{vol}(\frac{\epsilon}{2}B_2)} \leq \left(C\left(1+\frac{1}{\epsilon\sqrt{d}}\right)\right)^d, \tag{27.15}$$

其中第二个不等式由 $B_2 \subset \sqrt{d}B_1$ 通过 Cauchy-Schwarz 不等式得出。（这一步是紧的，因为 $\mathrm{vol}(B_1 + \frac{\epsilon}{2}B_2)^{1/d} \gtrsim \max\{\mathrm{vol}(B_1)^{1/d}, \frac{\epsilon}{2}\mathrm{vol}(B_2)^{1/d}\} \asymp \max\{\frac{1}{d}, \frac{\epsilon}{\sqrt{d}}\}$。）另一方面，对于某个绝对常数 c，

$$M(B_1, \|\cdot\|_2, \epsilon) \geq \frac{\mathrm{vol}(B_1)}{\mathrm{vol}(\epsilon B_2)} = \left(\frac{1}{\epsilon}\right)^d \frac{\mathrm{vol}(B_1)}{\mathrm{vol}(B_2)} = \left(\frac{c}{\epsilon\sqrt{d}}\right)^d. \tag{27.16}$$

总体而言，对于$\epsilon \leq \frac{1}{\sqrt{d}}$，我们有$M(B_1, \|\cdot\|_2, \epsilon)^{1/d} \asymp \frac{1}{\epsilon\sqrt{d}}$；然而，下界变得平凡，而上界（在$d$中呈指数增长）在$\epsilon \gg \frac{1}{\sqrt{d}}$的情形下变得宽松，这需要采用不同于体积计算的方法。以下结果描述了该度量熵的完整行为。鉴于定理27.2，我们将在论证中在覆盖数和填充数之间来回切换。

定理 27.7 *For* $0 < \epsilon < 1$ *and* $d \in \mathbb{N}$,

$$\log M(B_1, \|\cdot\|_2, \epsilon) \asymp \begin{cases} d\log\frac{e}{\epsilon^2 d} & \epsilon \leq \frac{1}{\sqrt{d}} \\ \frac{1}{\epsilon^2}\log(e\epsilon^2 d) & \epsilon \geq \frac{1}{\sqrt{d}} \end{cases}.$$

6 对于B_1，这可以直接证明，注意到B_1由2^d个不相交的“副本”组成，这些副本是体积为$1/d$的单纯形！通过对d进行归纳。

Proof. $\epsilon \le \frac{1}{\sqrt{d}}$ 的情况可从先前的体积计算 (27.15)–(27.16) 得出。接下来我们关注$\frac{1}{\sqrt{d}} \le \epsilon < 1$.

对于上界，我们通过在 ℓ_2 中对每个坐标进行量化来构造一个 ϵ 覆盖。不失一般性，假设 $\epsilon < 1/4$。固定某个 $\delta < 1$。对于每个 $\theta \in B_1$，存在 $x \in (\delta\mathbb{Z}^d) \cap B_1$ 使得 $\|x-\theta\|_\infty \le \delta$。那么 $\|x-\theta\|_2^2 \le \|x-\theta\|_1 \|x-\theta\|_\infty \le 2\delta$。此外，$x/\delta$ 属于集合

$$\mathcal{Z} = \left\{ z \in \mathbb{Z}^d : \sum_{i=1}^d |z_i| \le k \right\} \tag{27.17}$$

其中$k = \lfloor 1/\delta \rfloor$。注意每个$z \in \mathcal{Z}$至多有$k$个非零元。通过枚举非负解的数量（隔板法计算）和符号模式，我们有[7] $|\mathcal{Z}| \le 2^{k\wedge d}\binom{d-1+k}{k}$。最后，选取$\delta = \epsilon^2/2$，我们得出 $N(B_1, \|\cdot\|_2, \epsilon) \le |\mathcal{Z}| \le (\frac{2e(d+k)}{k})^k$如所需。（注意，此方法也恢复了$\epsilon \le \frac{1}{\sqrt{d}}$的体积界，在这种情况下$k \le d$。）

对于下界，注意通过考虑 $\pm e_1, \dots, \pm e_d$ 可得 $M(B_1, \|\cdot\|_2, \sqrt{2}) \ge 2d$。因此只需考虑 $d \ge 8$。我们基于汉明球的填充构造一个 B_1 的填充。不失一般性，假设 $\epsilon > \frac{1}{4\sqrt{d}}$。固定某个 $1 \le k \le d$。应用定理27.6中的Gilbert-Varshamov界，特别是(27.12)，存在一个 $k/2$-填充 $\{x_1, \dots, x_M\} \subset S_k^d = \{x \in \{0,1\}^d : \sum_{i=1}^d x_i = k\}$ 且 $\log M \ge \frac{k}{2}\log\frac{d}{2ek}$。通过设置 $\theta_i = x_i/k$，缩放汉明球以适配 ℓ_1-球。于是对所有 $i \ne j$ 有 $\theta_i \in B_1$ 和 $\|\theta_i - \theta_j\|_2^2 = \frac{1}{k^2} d_{\mathrm{H}}(x_i, x_j) \ge \frac{1}{2k}$。选择满足 $k \le d/8$ 的 $k = \lfloor \frac{1}{\epsilon^2} \rfloor$，我们得出结论：$\{\theta_1, \dots, \theta_M\}$ 是 $\|\cdot\|_2$ 中 B_1 的一个 $\frac{\epsilon}{2}$-填充，正如所需。

□

上述初等证明可以推广，给出以下更一般的结果（参见习题V.27）：令$1 \le p < q \le \infty$。对于所有$0 < \epsilon < 1$和$d \in \mathbb{N}$,

$$\log M(B_p, \|\cdot\|_q, \epsilon) \asymp_{p,q} \begin{cases} d \log \frac{e}{\epsilon^s d} & \epsilon \le d^{-1/s} \\ \frac{1}{\epsilon^s} \log(e\epsilon^s d) & \epsilon \ge d^{-1/s} \end{cases}, \qquad \frac{1}{s} \triangleq \frac{1}{p} - \frac{1}{q}. \tag{27.18}$$

在本节的剩余部分，我们将讨论与定理27.7相关的一些通用结果，特别是通过*Sudakov minorization*和*Maurey's empiricalmethod*给出的度量熵上界，以及欧几里得空间中度量熵的对偶性。

27.3.1 苏达科夫极小化

定理27.8（S 乌达科夫极小化 *Define the* 高斯宽度 *of* $\Theta \subset \mathbb{R}^d$ *as*[8]

$$w(\Theta) \triangleq \mathbb{E} \sup_{\theta \in \Theta} \langle \theta, Z \rangle, \quad Z \sim \mathcal{N}(0, I_d). \tag{27.19}$$

7 通过枚举支撑集并计算正解的数量，可以很容易地证明 $|\mathcal{Z}| = \sum_{i=0}^d 2^{d-i}\binom{d}{i}\binom{k}{d-i}$。 [8] 为了避免可测性困难，$w(\Theta)$ 应理解为 $\sup_{T \subset \Theta, |T| < \infty} \mathbb{E} \max_{\theta \in T} \langle \theta, Z \rangle$。

For any $\Theta \subset \mathbb{R}^d$*,*

$$w(\Theta) \gtrsim \sup_{\epsilon>0} \epsilon \sqrt{\log M(\Theta, \|\cdot\|_2, \epsilon)}. \tag{27.20}$$

作为一个快速推论，将定理27.3中关于填充数的体积下界应用于(27.20)，并对ϵ进行优化，我们得到*Urysohn's inequality*：[9]

$$w(\Theta) \gtrsim \sqrt{d} \left(\frac{\mathrm{vol}(\Theta)}{\mathrm{vol}(B_2)} \right)^{1/d} \overset{(27.14)}{\asymp} d \cdot \mathrm{vol}(\Theta)^{1/d}. \tag{27.21}$$

苏达科夫定理将高斯宽度与度量熵联系起来，二者都是集合庞大程度的有意义度量。关键在于 (27.20) 中的比例常数与维度无关。事实证明，苏达科夫下界在 $\log(d)$ 因子范围内是紧的 [438，定理 8.1.13]。以下补充结果被称为达德利链式不等式（证明见练习 V.28 ）。

$$w(\Theta) \lesssim \int_0^\infty \sqrt{\log M(\Theta, \|\cdot\|_2, \epsilon)} d\epsilon. \tag{27.22}$$

理解高斯过程的最大值本身就是一个研究领域；参见专著[411]。在本节中，我们关注下界(27.20)，以便利用高斯宽度来建立度量熵的上界。

定理27.8的证明依赖于Slepian的下述高斯比较引理（我们在定理11.13中已经遇到过Slepian）。关于自包含的证明，参见[89]。对于较弱版本 $\mathbb{E} \max X_i \le 2\mathbb{E} \max Y_i$ 的更简单证明，也请参见[329, 引理5.7, 第70页]，这已足够满足我们的需求。

引理 27.9 (Slepian 引理) *Let* $X = (X_1, \ldots, X_n)$ *and* $Y = (Y_1, \ldots, Y_n)$ *be Gaussian random vectors. If* $\mathbb{E}(Y_i - Y_j)^2 \le \mathbb{E}(X_i - X_j)^2$ *for all* i, j*, then* $\mathbb{E} \max Y_i \le \mathbb{E} \max X_i$*.*

我们还需要一个结果，来界定n个高斯随机变量最大值的期望。

引理 27.10 *Let* $Z_1, \ldots, Z_n$ *be distributed as* $\mathcal{N}(0, 1)$*. Then*

$$\mathbb{E}\left[\max_{i \in [n]} Z_i \right] \le \sqrt{2 \log n}. \tag{27.23}$$

In addition, if $Z_1, \ldots, Z_n \overset{i.i.d.}{\sim} \mathcal{N}(0, 1)$*, then*

$$\mathbb{E}\left[\max_{i \in [n]} Z_i \right] = \sqrt{2 \log n}(1 + o(1)). \tag{27.24}$$

[9] For a sharp form, see [329, Corollary 1.4], which states that for all symmetric convex Θ, $w(\Theta) \ge \mathbb{E}[\|Z\|_2] (\frac{\mathrm{vol}(\Theta)}{\mathrm{vol}(B_2)})^{1/d}$; in other words, balls minimize the Gaussian width among all symmetric convex bodies of the same volume.

Proof. 首先，令$T = \operatorname{argmax}_j Z_j$。由于$Z_j$是1-次高斯分布（回想定义4.15），根据练习I.56，我们有

$$|\mathbb{E}[\max_i Z_i]| = |\mathbb{E}[Z_T]| \le \sqrt{2I(Z^n;T)} = \sqrt{2H(T)} \le \sqrt{2\log n}\,.$$

接下来，假设 Z_i 是独立同分布的。对于任意 $t>0$,

$$\begin{aligned}\mathbb{E}[\max_i Z_i] &\ge t\,\mathbb{P}[\max_i Z_i \ge t] + \mathbb{E}[\max_i Z_i 1\{Z_1<0\}1\{Z_2<0\}\dots 1\{Z_n<0\}] \\ &\ge t(1-(1-\Phi^c(t))^n) + \mathbb{E}[Z_1 1\{Z_1<0\}1\{Z_2<0\}\dots 1\{Z_n<0\}].\end{aligned}$$

其中 $\Phi^c(t) = \mathbb{P}[Z_1 \ge t]$ 是正态尾概率。第二项等于 $2^{-(n-1)}\mathbb{E}[Z_1 1\{Z_1<0\}] = o(1)$。对于第一项，回忆 $\Phi^c(t) \ge \frac{t}{1+t^2}\varphi(t)$ (练习 V.25)。选择 $t = \sqrt{(2-\epsilon)\log n}$ 对于小的 $\epsilon > 0$，使得 $\Phi^c(t) = \omega(\frac{1}{n})$，从而 $\mathbb{E}[\max_i Z_i] \ge \sqrt{(2-\epsilon)\log n}(1+o(1))$。由 $\epsilon > 0$ 的任意性，(27.24) 的下界部分得证。

□

Proof of Theorem 27.8. 设 $\{\theta_1,\dots,\theta_M\}$ 为 Θ 的最优 ϵ-填充。设 $X_i = \langle \theta_i, Z\rangle$ 对应 $i\in[M]$，其中 $Z\sim\mathcal{N}(0,I_d)$。设 $Y_i \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0,\epsilon^2/2)$。则

$$\mathbb{E}(X_i-X_j)^2 = (\theta_i-\theta_j)^\top \mathbb{E}[ZZ^\top](\theta_i-\theta_j) = \|\theta_i-\theta_j\|_2^2 \ge \epsilon^2 = \mathbb{E}(Y_i-Y_j)^2.$$

然后

$$\mathbb{E}\sup_{\theta\in\Theta}\langle\theta,Z\rangle \ge \mathbb{E}\max_{1\le i\le M} X_i \ge \mathbb{E}\max_{1\le i\le M} Y_i \asymp \epsilon\sqrt{\log M}$$

其中第二步和第三步分别由引理27.9和引理27.10得出。 □

重新审视 ℓ_1-球的填充数，我们对 $\Theta = B_1$ 应用 Sudakov 小化。利用对偶性并应用引理27.10,

$$w(B_1) = \mathbb{E}\sup_{x:\,\|x\|_1\le 1}\langle x,Z\rangle = \mathbb{E}\|Z\|_\infty \le \sqrt{2\log d}.$$

然后定理 27.8 给出

$$\log M(B_1,\|\cdot\|_2,\epsilon) \lesssim \frac{\log d}{\epsilon^2}. \tag{27.25}$$

当 $\epsilon \gtrsim 1/\sqrt{d}$ 时，这比体积界（27.15）紧得多，并且几乎是最优的（与 $\frac{\log(d\epsilon^2)}{\epsilon^2}$ 相比）；然而，当 $\epsilon \asymp 1/\sqrt{d}$ 时，（27.25）给出 $d\log d$，但我们知道（即使从体积界来看）正确的行为是 d。在 27.3.3 节中，我们讨论另一种一般方法，它在这种情况下给出了最优界。

27.3.2 希尔伯特球的度量熵 $\frac{1}{\epsilon^2}$

我们考虑一个希尔伯特球 $B_2 = \{x\in\mathbb{R}^\infty : \sum_i x_i^2 \le 1\}$。在通常的度量 $\ell_2(\mathbb{R}^\infty)$ 下，这个集合不是紧的，并且对于所有 ϵ 都不能有有限的 ϵ-网。然而，在许多情况下感兴趣的度量是

应用通常是不同的。具体来说，让我们固定B_2上的某个概率分布P，使得$\mathbb{E}_{X\sim P}[\|X\|_2^2] \le 1$，并定义

$$d_P(\theta,\theta') \triangleq \sqrt{\mathbb{E}_{X\sim P}[|\langle \theta-\theta', X\rangle|^2]}$$

对于$\theta,\theta' \in B_2$。该度量的重要性在于它允许分析一类线性函数$\theta \mapsto \langle \theta, X\rangle$对于任意单位范数的随机变量$X$的复杂性，并在学习理论中有应用[302, 471]。

定理 27.11 *For some universal constant c we have for all $\epsilon > 0$*

$$\log N(B_2, d_P, \epsilon) \le \frac{c}{\epsilon^2}\,.$$

Proof. 首先，我们展示在不失一般性的情况下，可以假设X除第一个n外的所有坐标均为零。确实，取n足够大，使得$\mathbb{E}[\sum_{j>n} X_j^2] \le \frac{\epsilon^2}{4}$。我们记$\tilde{\theta}$为由$\theta$通过将所有坐标$j>n$置零得到的向量。然后根据柯西-施瓦茨不等式，我们可以看到$d_P(\theta,\tilde{\theta}) \le \frac{\epsilon}{2}$，因此任何对$\tilde{B}_2 = \{\tilde{\theta}$的$\frac{\epsilon}{2}$覆盖：$\theta \in B_2\}$将成为$B_2$的$\epsilon$覆盖。因此，从现在起，我们假设球$B_2$实际上是有限维的。

我们可以用更明确的方式重新定义距离 d_P，如下所示

$$d_P(\theta,\theta')^2 = (\theta-\theta')^\top \Sigma (\theta-\theta')\,,$$

其中 $\Sigma = \mathbb{E}[XX^\top]$ 是 $X \sim P$ 的二阶矩的半正定矩阵。设 $D = \sqrt{\Sigma}$ 为 Σ 的对称平方根。对每个 θ，我们关联 $v(\theta) = D\theta$，并令 $V = D(B_2)$ 为 B_2 在 D 下的像。注意 $d_P(\theta,\theta') = \|v(\theta) - v(\theta')\|_2$。因此，根据 Sudakov 微小化定理 27.8，我们得到

$$\log M(V, \|\cdot\|_2, \epsilon) \le \frac{c}{\epsilon^2}\,\mathbb{E}[\sup_{v\in V}\langle v, Z\rangle] \qquad Z \sim \mathcal{N}(0, I_d)\,.$$

由于 V 是一个椭球，我们可以显式计算出上确界，实际上

$$\mathbb{E}[\sup_{v\in V}\langle v, Z\rangle] = \mathbb{E}[\sup_{\theta\in B_2}\langle D\theta, Z\rangle] = \mathbb{E}[\|DZ\|_2] \le \sqrt{\mathbb{E}[\|DZ\|_2^2]} = \sqrt{\operatorname{tr}\Sigma} \le 1\,.$$

□

要了解该结果的一个简单含义，回忆经验过程的标准界：通过赋予任何函数集合 $\{f_\theta, \theta\in\Theta\}$ 一个度量 $d_{\hat{P}_n}(\theta,\theta')^2 = \mathbb{E}_{\hat{P}_n}[(f_\theta(X) - f_{\theta'}(X))^2]$，我们有

$$\mathbb{E}\left[\sup_\theta \mathbb{E}[f_\theta(X)] - \hat{\mathbb{E}}_n[f_\theta(X)]\right] \lesssim \mathbb{E}\left[\inf_{\delta>0}\delta + \int_\delta^\infty \sqrt{\frac{\log N(\Theta, d_{\hat{P}_n}, \epsilon)}{n}}\,d\epsilon\right]\,.$$

可以看出，当熵表现为 ϵ^{-p} 时，我们得到速率 $n^{-\min(1/p,1/2)}$，除了 $p=2$ 的情况，其上界给出 $n^{-\frac{1}{2}}\log n$。前一个定理的意义在于，希尔伯特球恰好处于从参数速率到非参数速率的“相变点”。

作为合理性检查，我们取单位（可能是无限维）球 B 上的任意 P_X，满足 $\mathbb{E}[X]=0$，并令 $\Theta = B$。我们有

$$\mathbb{E}[\|\bar{X}_n\|] = \mathbb{E}\left[\sup_\theta \frac{1}{n}\sum_{i=1}^n \langle \theta, X_i\rangle\right] \lesssim \sqrt{\frac{\log n}{n}},$$

其中 $\bar{X}_n = \frac{1}{n}\sum_{i=1}^n X_i$ 是经验均值。在这种特殊情况下，通过显式计算很容易界定 $\mathbb{E}[\|\bar{X}_n\|] \le \sqrt{\mathbb{E}[\|\bar{X}_n\|^2]} \le \frac{1}{\sqrt{n}}$。

27.3.3 莫雷的经验方法

在本节中，我们讨论由 B. Maurey 提出的一种强大的概率方法，用于构造良好的覆盖。该方法在逼近论中找到了应用，尤其是在神经网络方面 [237, 37]。以下结果给出了希尔伯特空间中凸包覆盖数的一个无维数界：

定理 27.12 *Let H be an inner product space with the norm $\|x\| \triangleq \sqrt{\langle x,x\rangle}$. Let $T \subset H$ be a finite set, with radius $r = \mathrm{rad}(T) = \inf_{y\in H}\sup_{x\in T}\|x-y\|$ (recall (5.3)). Denote the convex hull of T by $\mathrm{co}(T)$. Then for any $0 < \epsilon \le r$,*

$$N(\mathrm{co}(T), \|\cdot\|, \epsilon) \le \binom{|T| + \lceil \frac{r^2}{\epsilon^2}\rceil - 2}{\lceil \frac{r^2}{\epsilon^2}\rceil - 1}. \tag{27.26}$$

Proof. 令 $T = \{t_1, t_2, \ldots, t_m\}$，并将 T 的切比雪夫中心记为 $c \in H$，使得 $r = \max_{i\in[m]}\|c - t_i\|$。对于 $n \in \mathbb{Z}_+$，令

$$\mathcal{Z} = \left\{ \frac{1}{n+1}\left(c + \sum_{i=1}^m n_i t_i\right) : n_i \in \mathbb{Z}_+, \sum_{i=1}^m n_i = n \right\}.$$

对于任意 $x = \sum_{i=1}^m x_i t_i \in \mathrm{co}(T)$，其中 $x_i \ge 0$ 且 $\sum x_i = 1$，设 Z 是一个离散随机变量，使得 $Z = t_i$ 以概率 x_i 成立。那么 $\mathbb{E}[Z] = x$。设 $Z_0 = c$ 和 $Z_1, \ldots, Z_n$ 是 Z 的独立同分布副本。设 $\bar{Z} = \frac{1}{n+1}\sum_{i=0}^m Z_i$，其取值在集合 $\mathcal{Z}$ 中。由于

$$\begin{aligned}\mathbb{E}\|\bar{Z}-x\|_2^2 &= \frac{1}{(n+1)^2}\mathbb{E}\left\|\sum_{i=0}^n (Z_i - x)\right\|^2 = \frac{1}{(n+1)^2}\left(\sum_{i=0}^n \mathbb{E}\|Z_i - x\|^2 + \sum_{i\ne j}\mathbb{E}\langle Z_i - x, Z_j - x\rangle\right)\\ &= \frac{1}{(n+1)^2}\sum_{i=0}^n \mathbb{E}\|Z_i - x\|^2 = \frac{1}{(n+1)^2}\left(\|c-x\|^2 + n\mathbb{E}[\|Z-x\|^2]\right) \le \frac{r^2}{n+1},\end{aligned}$$

其中最后一个不等式由 $\|c-x\| \le \sum_{i=1}^m x_i\|c-t_i\| \le r$（得出，换言之，$\mathrm{rad}(T) = \mathrm{rad}(\mathrm{co}(T))$）且 $\mathbb{E}[\|Z-x\|^2] \le \mathbb{E}[\|Z-c\|^2] \le r^2$。设 $n = \lceil r^2/\epsilon^2\rceil - 1$，使得 $r^2/(n+1) \le \epsilon^2$。存在某个 $z \in N$，使得 $\|z-x\| \le \epsilon$。因此，$\mathcal{Z}$ 是 $\mathrm{co}(T)$ 的一个 ϵ-覆盖。与 (27.17) 类似，我们有

$$|\mathcal{Z}| \le \binom{n+m-1}{n} = \binom{m + \lceil r^2/\epsilon^2\rceil - 2}{\lceil r^2/\epsilon^2\rceil - 1}.$$

□

我们现在应用定理27.12来恢复定理27.7中单位ℓ_1-球B_1在$\mathbb{R}^d$中的结果：注意$B_1 = \text{co}(T)$，其中$T = \{\pm e_1, \dots, \pm e_d, 0\}$满足$\text{rad}(T) = 1$。那么

$$N(B_1, \|\cdot\|_2, \epsilon) \le \binom{2d + \lceil \frac{1}{\epsilon^2} \rceil - 1}{\lceil \frac{1}{\epsilon^2} \rceil - 1}, \tag{27.27}$$

这在小的和大的尺度下都恢复了定理27.7中的最优上界。

27.3.4 度量熵的对偶性

首先我们定义一个更一般的覆盖数概念。对于$K, T \subset \mathbb{R}^d$，使用$T$的平移来定义$K$的覆盖数为

$$N(K, T) = \min\{N : \exists x_1, \dots, x_N \in \mathbb{R}^d \text{ such that } K \subset \cup_{i=1}^N T + x_i\}.$$

那么，定义27.1中通常的覆盖数满足$N(K, \|\cdot\|, \epsilon) = N(K, \epsilon B)$，其中$B$是对应的单位范数球。

Artstein、Milman 和 Szarek [28] 的一个深刻结果确立了度量熵的以下对偶性：存在绝对常数 α 和 β，使得对于任何对称凸体 K,[10]

$$\frac{1}{\beta} \log N\left(B_2, \frac{\epsilon}{\alpha} K^\circ\right) \le \log N(K, \epsilon B_2) \le \log N(B_2, \alpha \epsilon K^\circ), \tag{27.28}$$

其中 B_2 是通常的单位 ℓ_2-球，而 $K^\circ = \{y\colon \sup_{x \in K} \langle x, y\rangle \le 1\}$ 是 K 的极体。

例如，考虑 $p < 2 < q$ 和 $\frac{1}{p} + \frac{1}{q} = 1$。根据对偶性，$B_p^\circ = B_q$。然后（27.28）表明 $N(B_p, \|\cdot\|_2, \epsilon)$ 和 $N(B_2, \|\cdot\|_q, \epsilon)$ 具有本质上相同的行为，正如（27.18）所验证的。

27.4 无限维空间：光滑函数

与欧几里得空间不同，在无限维空间中，度量熵可以任意快速增长[250，定理XI]。研究函数空间中的度量熵（例如，在形状或平滑性约束下）是泛函分析中的一个兴趣领域（参见[441]），并且在非参数统计、经验过程和学习理论中具有重要应用[139]。为了对有限维空间和无限维空间之间的根本区别有所了解，让我们来做一个具体的例子，这个例子稍后将在第32.4节中用于密度估计的应用。关于更一般和更精确的结果（包括一些等式的情况），请参见[250，第4和第7节]。考虑紧致区间$[0, A]$上所有L-Lipschitz概率密度的类$\mathcal{F}(A, L)$。

[10] A convex body K is a compact convex set with non-empty interior. We say K is symmetric if $K = -K$.

定理 27.13 *Assume that $L, A > 0$ and $p \in [1, \infty]$ are constants. Then*

$$\log N(\mathcal{F}(A, L), \|\cdot\|_p, \epsilon) = \Theta\left(\frac{1}{\epsilon}\right). \tag{27.29}$$

Furthermore, for the sup-norm we have the sharp asymptotics:

$$\log_2 N(\mathcal{F}(A, L), \|\cdot\|_\infty, \epsilon) = \frac{LA}{\epsilon}(1 + o(1)), \quad \epsilon \to 0. \tag{27.30}$$

Proof. 通过将$f(x)$替换为$\frac{1}{\sqrt{L}} f(\frac{x}{\sqrt{L}})$，我们得到

$$N(\mathcal{F}(A, L), \|\cdot\|_p, \epsilon) = N(\mathcal{F}(\sqrt{L}A, 1), \|\cdot\|_p, L^{\frac{1-p}{2p}}\epsilon). \tag{27.31}$$

因此，只需考虑$\mathcal{F}(A,1) \triangleq \mathcal{F}(A)$，即$[0, A]$上的1-Lipschitz密度集合即可。接下来观察到，任何此类密度函数f都是有上界的。事实上，由于$f(x) \geq (f(0) - x)_+$和$\int_0^A f = 1$，我们得出$f(0) \leq \max\{A, \frac{A}{2} + \frac{1}{A}\} \triangleq m$。

为了证明(27.29)，只需证明$p = \infty$的上界和$p = 1$的下界。具体而言，我们旨在通过显式构造来证明，

$$N(\mathcal{F}(A), \|\cdot\|_\infty, \epsilon) \leq \frac{C}{\epsilon} 2^{\frac{A}{\epsilon}} \tag{27.32}$$

$$M(\mathcal{F}(A), \|\cdot\|_1, \epsilon) \geq 2^{\frac{c}{\epsilon}} \tag{27.33}$$

这根据定理27.2蕴含了所需的(27.29)。这里及以下，c, C是依赖于A的常数。我们从较简单的(27.33)开始。我们通过扰动均匀密度来构造一个填充。定义一个函数T，由 $T(x) = x\,1\{x \leq \epsilon\} + (2\epsilon - x)1\{x \geq \epsilon\} + \frac{1}{A}$ 在 $[0, 2\epsilon]$ 上给出，其他地方为零。令 $n = \lceil \frac{A}{4\epsilon} \rceil$ 和 $a = 2n\epsilon$。对于每个 $y \in \{0, 1\}^n$，在 $[0, A]$ 上定义一个密度 f_y，使得

$$f_y(x) = \sum_{i=1}^{n} y_i T(x - 2(i-1)\epsilon), \quad x \in [0, a],$$

并且我们将 f_y 线性延拓到 $[a, A]$，使得 $\int_0^A f_y = 1$；参见图 27.2。对于足够小的 ϵ，所得的 f_y 是 1-Lipschitz 的，因为 $\int_0^a f_y = \frac{1}{2} + O(\epsilon)$，从而线性延拓的斜率为 $O(\epsilon)$。

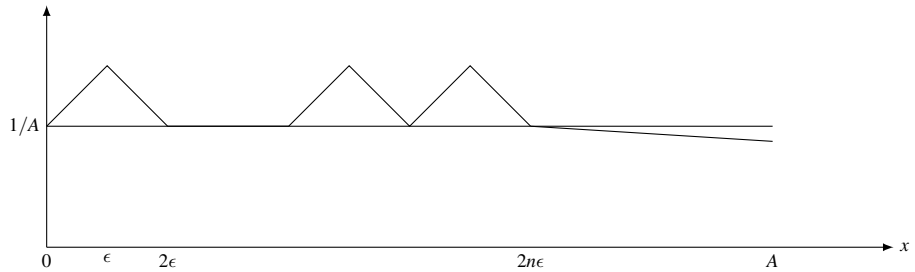


图27.2 实现（(27.33)）的填充。实线表示一个这样的密度 $f_y(x)$，其中 $y = (1, 0, 1, 1)$。虚线是 Unif$(0, A)$ 的密度。

因此，我们得出结论，每个 f_y 都是 $\mathcal{F}(A)$ 的有效成员。此外，对于 $y, z \in \{0,1\}^n$，我们有 $\|f_y - f_z\|_1 = d_{\mathrm{H}}(y,z)\|T\|_1 = \epsilon^2 d_{\mathrm{H}}(y,z)$。引用 Gilbert-Varshamov 界定理 27.5，我们得到汉明空间 $\{0,1\}^n$ 的一个 $\frac{n}{2}$-填充 $\mathcal{Y}$，其中 $|\mathcal{Y}| \geq 2^{cn}$，对于某个绝对常数 c。因此，$\{f_y : y \in \mathcal{Y}\}$ 构成了 $\mathcal{F}(A)$ 关于 L_1-范数的一个 $\frac{n\epsilon^2}{2}$-填充。这就是所需的 (27.33)，因为 $\frac{n\epsilon^2}{2} = \Theta(\epsilon)$。

为了构造一个覆盖，设置 $J = \lceil \frac{m}{\epsilon} \rceil$、$n = \lceil \frac{A}{\epsilon} \rceil$ 和 $x_k = k\epsilon$ 对于 $k = 0, \ldots, n$。令 $\mathcal{G}$ 是从坐标 $(0, j\epsilon)$ 出发的，步数为 n（网格大小为 ϵ）的所有格路径的集合，其中对于某个 $j \in \{0, \ldots, J\}$。换句话说，$\mathcal{G}$ 中的每个元素 g 是每个子区间 $I_k = [x_k, x_{k+1})$ 上的连续分段线性函数，其斜率要么是 $+1$ 要么是 -1。显然，这样的路径的数量最多为 $(J+1)2^n = O(\frac{1}{\epsilon} 2^{A/\epsilon})$。为了证明 $\mathcal{G}$ 是一个 ϵ-覆盖，对于每个 $f \in \mathcal{F}(A)$，我们证明存在 $g \in \mathcal{G}$ 使得对于所有 $x \in [0, A]$，$|f(x) - g(x)| \leq \epsilon$。这可以通过简单的归纳法来证明。假设存在 g 使得对于所有 $x \in [0, x_k]$，$|f(x) - g(x)| \leq \epsilon$，这在 $k = 0$ 的基例中显然成立。我们证明 g 可以扩展到 I_k，使得这对于 $k+1$ 成立。由于 $|f(x_k) - g(x_k)| \leq \epsilon$ 和 f 是 1-Lipschitz 的，要么 $f(x_{k+1}) \in [g(x_k), g(x_k) + 2\epsilon]$ 要么 $[g(x_k) - 2\epsilon, g(x_k)]$，在这种情况下我们分别向上或向下扩展 g。得到的 g 在 I_k 上满足 $|f(x) - g(x)| \leq \epsilon$，完成了归纳。

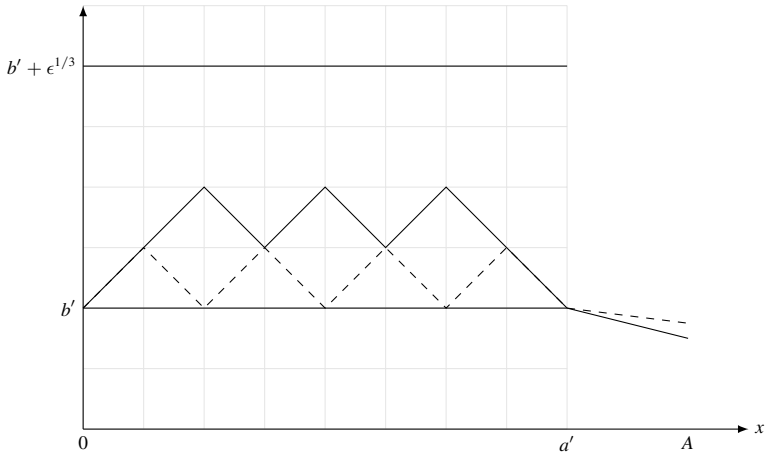


图27.3 改进后的打包方案，针对(27.34)。在此图中，实线和虚线分别代表了从$(0, b')$出发，在尺寸为ϵ的网格上，保持于$[b', b' + \epsilon^{1/3}]$范围内，且各自具有线性延伸的两条格点路径。

最后，我们证明关于$p = \infty$的精确界(27.30)。上界直接从(27.32)加上比例关系(27.31)得出。对于下界，我们应用定理27.2，将问题转化为构建2ϵ-包装。遵循相同的格路径思想，接下来我们给出一个改进的包装构造，使得

$$M(\mathcal{F}(A), \|\cdot\|_\infty, 2\epsilon) \geq \exp(\epsilon^{3/2} 2^{\frac{a}{\epsilon}}). \tag{27.34}$$

对于任意 $a < A$。选择任意 b 使得 $\frac{1}{A} < b < \frac{1}{A} + \frac{(A-a)^2}{2A}$。令 $a' = \epsilon \lfloor \frac{a}{\epsilon} \rfloor$ 和 $b' = \epsilon \lfloor \frac{b}{\epsilon} \rfloor$。考虑 $[0, A]$ 上的一个密度 f，其形式如下（参见图27.3）：在 $[0, a']$ 上，f 是从 $(0, b')$ 出发的格路径

到 (a',b')，其保持在 $[b',b'+\epsilon^{1/3}]$ 的垂直范围内；在 $[a',A]$ 上，f 是选择的线性延拓，使得 $\int_0^A f=1$。这是可能的，因为根据 1-Lipschitz 约束，我们可以线性延拓 f，使得 $\int_{a'}^A f$ 取区间 $[b'(A-a')-\frac{(A-a')^2}{2}, b'(A-a')+\frac{(A-a')^2}{2}]$ 中的任意值。由于 $\int_0^{a'} f = ab+o(1)$，我们需要 $\int_{a'}^A f = 1-\int_0^{a'} f = 1-ab+o(1)$，这由于 b 的选择而是可行的。所有此类函数的集合 $\mathcal{G}$ 在 sup 范数下构成一个 2ϵ-packing（对于两条不同的路径，考虑它们首次不同的第一个子区间）。最后，我们通过计算此类路径的数量来界定该 packing 的基数。这可以通过随机游走的标准估计来完成（参见例如 [164, Chap. III]）。对于任意常数 $c>0$，一个在 $\mathbb{Z}$ 上的对称随机游走在 n (even) 步内返回零并保持在 $[0,n^{1+c}]$ 范围内的概率为 $\Theta(n^{-3/2})$；这意味着所需的 (27.34)。最后，由于 $a<A$ 是任意的，鉴于定理 27.2，(27.30) 的下界部分随之成立。

□

以下结果由 Birman 和 Solomjak [57] 给出（有关阐述可参见 [285，第15.6节]），它是定理27.13对更一般的 Hölder 类的推广。

定理 27.14 *Fix positive constants A, L and $d \in \mathbb{N}$. Let $\beta > 0$ and write $\beta = \ell + \alpha$, where $\ell \in \mathbb{Z}_+$ and $\alpha \in (0,1]$. Let $\mathcal{F}_\beta(A,L)$ denote the collection of ℓ-times continuously differentiable densities f on $[0,A]^d$ whose ℓth derivative is (L,α)-Hölder continuous, namely, $\|D^{(\ell)}f(x)-D^{(\ell)}f(y)\|_\infty \le L\|x-y\|_\infty^\alpha$ for all $x,y\in[0,A]^d$. Then for any $1\le p\le\infty$,*

$$\log N(\mathcal{F}_\beta(A,L), \|\cdot\|_p, \epsilon) = \Theta\left(\epsilon^{-\frac{d}{\beta}}\right). \tag{27.35}$$

前一个定理的主要信息是，如果维数减小或光滑度增加，函数类的熵增长得更慢。因此，对于非常光滑的函数，度量熵可以在$\frac{1}{\epsilon}$中呈次多项式增长。例如，Vitushkin（参见[250, 方程(129))]）表明，对于单位复圆盘D上具有到更大圆盘rD的解析延拓（其中$r>1$）的解析函数类，度量熵（关于D上的上确界范数）为$\Theta((\log \frac{1}{\epsilon})2)$；更多此类结果见[250，第7和第8节]。

正如本章开头所述，度量熵这一主题的构想与发展，特别是定理27.14，其灵感源自希尔伯特第13问题的研究，并在其中扮演了重要角色。1900年，希尔伯特猜想存在多变量函数，它们不能表示为有限个较少变量函数的叠加（复合）。这一猜想在20世纪50年代被柯尔莫哥洛夫和阿诺德推翻，他们证明了每个d变量的连续函数都可以通过单变量函数的和与叠加来表示；然而，当要求组成函数具有特定光滑性时，他们的构造不再适用。随后，针对光滑函数的希尔伯特猜想被维图什金[439]正面解决，他证明了在β-赫尔德类（根据定理27.14的意义）中存在d变量的函数，如果$d/\beta > d'/\beta'$，这些函数不能表示为d'个变量在β'-赫尔德类中的函数的有限次叠加。维图什金的原始证明极为复杂。后来，柯尔莫哥洛夫通过证明并应用定理27.14的$\|\cdot\|_\infty$版本，给出了一个大大简化的证明。如(27.35)所示，指标d/β为函数类提供了一种复杂度度量；这使得不可能性的证明成为可能。

通过熵比较论证的叠加。为具体起见，让我们证明以下更简单的版本：存在一个在$[0,1]^3$上的三变量1-Lipschitz函数$f(x,y,z)$，它不能写成$g(h_1(x,y),h_2(y,z))$的形式，其中g,h_1,h_2是$[0,1]^2$上的二变量1-Lipschitz函数。假设为了矛盾，这是可能的。固定一个基数为$\exp(O(\frac{1}{\epsilon^2}))$的$[0,1]^2$上1-Lipschitz函数的$\epsilon$-覆盖，并用它来近似这些函数$g,h_1,h_2$，我们通过叠加$g(h_1,h_2)$得到一个基数为$\exp(O(\frac{1}{\epsilon^2}))$的$[0,1]^3$上1-Lipschitz函数的$O(\epsilon)$-覆盖；然而，这是矛盾的，因为任何这样的覆盖的大小必须为$\exp(\Omega(\frac{1}{\epsilon^3}))$。关于这一方向的更强和更一般的结果，参见[250，附录I]。

27.5 度量熵与小球的概率

概率论中的小球问题关注函数的行为

$$\phi(\epsilon) \triangleq \log \frac{1}{\mathbb{P}\left[\|X\| \le \epsilon\right]}$$

当 $\epsilon \to 0$时，其中 X 是一个取值于某个实可分巴拿赫空间 $(V, \|\cdot\|)$ 上的随机变量。例如，对于标准正态分布 $X \sim \mathcal{N}(0, I_d)$ 和 ℓ_2-球，一个简单的大偏差计算（练习III.16）表明

$$\phi(\epsilon) \asymp d \log \frac{1}{\epsilon}.$$

更有趣的是高斯过程的无穷维情形。例如，对于单位区间上的标准布朗运动与上确界范数，初等地可证明（练习V.30）

$$\phi(\epsilon) \asymp \frac{1}{\epsilon^2}. \tag{27.36}$$

我们向读者推荐该领域优秀的综述[279]。

小概率与度量熵之间存在深刻的联系，这使得人们能够以富有成效的方式将一个领域的结果转换到另一个领域。为了识别这种联系，起点是定理27.3中的体积论证。一方面，众所周知，在无限维空间中不存在勒贝格测度（平移不变）的类似物。因此，对于函数空间，人们经常使用高斯测度。另一方面，定理27.3和注27.2中的“体积”论证可以适应于一个不需要平移不变的测度 γ，从而得到

$$\frac{\gamma\left(\Theta + B\left(0,\epsilon\right)\right)}{\max_{\theta\in V}\gamma\left(B\left(\theta,2\epsilon\right)\right)} \le N(\Theta,\|\cdot\|,\epsilon) \le M(\Theta,\|\cdot\|,\epsilon) \le \frac{\gamma\left(\Theta + B\left(0,\epsilon/2\right)\right)}{\min_{\theta\in\Theta}\gamma\left(B\left(\theta,\epsilon/2\right)\right)}, \tag{27.37}$$

其中我们回顾 $B(\theta,\epsilon)$ 表示以 θ 为中心、半径为 ϵ 的范数球。从这里我们已经看到小球概率的自然出现。利用高斯测度固有的性质，这可以进一步分析并简化为以零为中心的球。

确切地说，令γ为V上的零均值高斯测度，使得$\mathbb{E}_{X\sim\gamma}[\|X\|^2] < \infty$。令$H \subset V$为由$\gamma$生成的再生核希尔伯特空间（RKHS），$K$为单位球，在

H. 我们请读者参考，例如，[262, 第2节]和[314, III.3.2]，以获取该对象的精确定义。[11] 就本节而言，考虑以下示例就足够了（更多内容请参见[262]）：

- 有限维度。设 $\gamma = \mathcal{N}(0, \Sigma)$。那么

$$K = \{\Sigma^{1/2} x : \|x\|_2 \le 1\} \tag{27.38}$$

是一个重新缩放的欧几里得球，其内积为$\langle x, y\rangle_H = x^\top \Sigma^{-1} y$。
- 布朗运动：令 γ 为单位区间 $[0, 1]$ 上标准布朗运动的分布。则

$$K = \left\{ f(t) = \int_0^t f'(s) ds : \|f'\|_2 \le 1 \right\} \tag{27.39}$$

与内积 $\langle f, g\rangle_H = \langle f', g'\rangle \equiv \int_0^1 f'(t) g'(t) dt$。

以下是由Kuelbs和Li [263]提出的基本结果（另见Goodman [194]的早期工作）描述了小球概率函数$\phi(\epsilon)$与单位Hilbert球$N(K, \|\cdot\|, \epsilon) \equiv N(\epsilon)$的度量熵之间的精确联系。

定理 27.15 *For all* $\epsilon > 0$,

$$\phi(2\epsilon) - \log 2 \le \log N\left(\frac{\epsilon}{\sqrt{2\phi(\epsilon/2)}} \right) \le 2\phi(\epsilon/2) \tag{27.40}$$

Proof. 我们证明对于任意 {v*} 0,

$$\phi(2\epsilon) + \log \Phi(\lambda + \Phi^{-1}(e^{-\phi(\epsilon)})) \le \log N(\lambda K, \epsilon) \le \log M(\lambda K, \epsilon) \le \frac{\lambda^2}{2} + \phi(\epsilon/2) \tag{27.41}$$

为了推导 (27.40)，选择 $\lambda = \sqrt{2\phi(\epsilon/2)}$，并注意通过缩放 $N(\lambda K, \epsilon) = N(K, \epsilon/\lambda)$。应用正态尾部界 $\Phi(-t) = \Phi^c(t) \le e^{-t^2/2}$ (练习 V.25) 得到 $\Phi^{-1}(e^{-\phi(\epsilon)}) \ge -\sqrt{2\phi(\epsilon)} \ge -\lambda$，因此 $\Phi(\Phi^{-1}(e^{-\phi(\epsilon)}) + \lambda) \ge \Phi(0) = 1/2$。

我们仅在有限维中给出证明，因为结果与维数无关，且自然推广到无限维空间。令 $Z \sim \gamma = \mathcal{N}(0, \Sigma)$ 在 $\mathbb{R}^d$ 上，使得 $K = \Sigma^{1/2} B_2$ 由 (27.38) 给出。将 (27.37) 应用于 λK，并注意到 γ 是一个概率测度，我们有

$$\frac{\gamma(\lambda K + B(0, \epsilon))}{\max_{\theta \in \mathbb{R}^d} \gamma(B(\theta, 2\epsilon))} \le N(\lambda K, \epsilon) \le M(\lambda K, \epsilon) \le \frac{1}{\min_{\theta \in \lambda K} \gamma(B(\theta, \epsilon/2))}. \tag{27.42}$$

接下来，我们利用高斯测度的固有性质进一步约束（27.42）。

[11] In particular, if γ is the law of a Gaussian process X on $C([0,1])$ with $\mathbb{E}[\|X\|_2^2] < \infty$, the kernel $K(s,t) = \mathbb{E}[X(s)X(t)]$ admits the eigendecomposition $K(s,t) = \sum \lambda_k \psi_k(s) \psi_k(t)$ (Mercer's theorem), where $\{\phi_k\}$ is an orthonormal basis for $L_2([0,1])$ and $\lambda_k > 0$. Then H is the closure of the span of $\{\phi_k\}$ with the inner product $\langle x, y\rangle_H = \sum_k \langle x, \psi_k\rangle \langle y, \psi_k\rangle / \lambda_k$.

- 对于上界，对于任意 *symmetric* 集 $A = -A$ 和任意 $\theta \in \lambda K$，通过测度变换

$$\begin{aligned}\gamma(\theta + A) &= \mathbb{P}\left[Z - \theta \in A\right] \\ &= e^{-\frac{1}{2}\theta^\top \Sigma^{-1}\theta}\mathbb{E}\left[e^{\langle \Sigma^{-1}\theta, Z\rangle} 1\left\{Z \in A\right\}\right] \\ &\geq e^{-\lambda^2/2}\mathbb{P}\left[Z \in A\right],\end{aligned}$$

  其中最后一步由$\theta^\top \Sigma^{-1}\theta \leq \lambda^2$得出，并根据Jensen不等式$\mathbb{E}\left[e^{\langle \Sigma^{-1}\theta, Z\rangle} | Z \in A\right] \geq e^{\langle \Sigma^{-1}\theta, \mathbb{E}[Z|Z\in A]\rangle} = 1$，关键利用了对称性$\mathbb{E}\left[Z|Z \in A\right] = 0$。将上述应用于$A = B(0, \epsilon/2)$得到(27.41)中的右侧不等式。
- 对于下界，回顾安德森引理（引理28.10），该引理表明当球以零为中心时，高斯测度达到最大，因此对所有 θ，有 $\gamma(B(\theta, 2\epsilon)) \leq \gamma(B(0, 2\epsilon))$。为了给分子设定界限，回顾高斯等周不等式（例如参见[69，定理10.15]）：[12]

$$\gamma(A + \lambda K) \geq \Phi(\Phi^{-1}(\gamma(A)) + \lambda). \tag{27.43}$$

  将它与$A = B(0, \epsilon)$一起应用，证明了(27.41)中的左不等式和定理。

□

定理27.15的含意如下。若$\phi(\epsilon) \asymp \phi(\epsilon/2)$，那么我们应预期大约

$$\log N\left(\frac{\epsilon}{\sqrt{\phi(\epsilon)}}\right) \asymp \phi(\epsilon)$$

通过更多的努力，这可以在无条件的情况下变得精确（例如参见[279，定理3.3]，结合[278]后来的改进），从而在度量熵和小球概率之间建立了*very precise*联系，例如：对于固定的$\alpha > 0, \beta \in \mathbb{R}$,

$$\phi(\epsilon) \asymp \epsilon^{-\alpha}\left(\log\frac{1}{\epsilon}\right)^{\beta} \iff \log N(\epsilon) \asymp \epsilon^{-\frac{2\alpha}{2+\alpha}}\left(\log\frac{1}{\epsilon}\right)^{\frac{2\beta}{2+\alpha}} \tag{27.44}$$

作为一个具体例子，考虑由标准布朗运动生成的RKHS中的单位球（27.39），它类似于Sobolev球。[13]利用（27.36）和（27.44），我们得出$\log N(\epsilon) \asymp \frac{1}{\epsilon}$，这重现了[420]中确定的Sobolev球的度量熵。这一结果也与定理27.14中Lipschitz球的度量熵一致，后者要求导数处处有界，而非L_2中的平均有界。关于小概率球在度量熵上的更多应用（以及反之），参见[263, 278]。

[12] The connection between (27.43) and isoperimetry is that if we interpret $\lim_{\lambda\to 0}(\gamma(A + \lambda K) - \gamma(A))/\lambda$ as the surface measure of A, then among all sets with the same Gaussian measure, the half space has maximal surface measure.

[13] The Sobolev norm is $\|f\|_{W^{1,2}} \triangleq \|f\|_2 + \|f'\|_2$. Nevertheless, it is simple to verify a priori that the metric entropy of (27.39) and that of the Sobolev ball share the same behavior (see [263, p. 152]).

27.6 度量熵与率失真理论

在本节中，我们探讨度量熵与率失真函数之间的联系。注意，前者是一个非概率量，而后者则是依赖于源分布的信息度量；然而，若考虑由“最不利”源分布诱导的率失真函数，其行为竟与度量熵相似。

为了精确起见，考虑一个度量空间$(\mathcal{X},d)$。对于取值于$\mathcal{X}$的随机变量X，记作

$$\phi_X(\epsilon)=\inf_{P_{\hat{X}|X}:\mathbb{E}[d(X,\hat{X})]\le\epsilon} I(X;\hat{X}) \tag{27.45}$$

其率失真函数（回忆第24.3节）。将$\mathcal{X}$上的*worst-case*率失真函数记作

$$\phi_{\mathcal{X}}(\epsilon)=\sup_{P_X\in\mathcal{P}(\mathcal{X})}\phi_X(\epsilon). \tag{27.46}$$

下一个定理将 $\phi_{\mathcal{X}}$ 与 $\mathcal{X}$ 的覆盖数和填充数联系起来。下界简单地由“贝叶斯”论证得出，它通过平均情况来下界最坏情况，类似于极小极大风险与贝叶斯风险之间的关系（见第28.3节）。上界在[241]中利用率失真函数的对偶表示给出；这里我们通过Fano不等式给出一个更简单的证明。

定理 27.16 *For any* $0<c<1/2$,

$$\phi_{\mathcal{X}}(\epsilon)\le\log N(\mathcal{X},d,\epsilon)\le\log M(\mathcal{X},d,\epsilon)\le\frac{\phi_{\mathcal{X}}(c\epsilon)+\log 2}{1-2c}. \tag{27.47}$$

Proof. 固定一个大小为 N 的 d 中对 $\mathcal{X}$ 的 ϵ-覆盖。令 $\hat{X}$ 表示覆盖中最接近 X 的元素。那么 $d(X,\hat{X})\le\epsilon$ 几乎必然成立。因此 $\phi_X(\epsilon)\le I(X;\hat{X})\le\log N$。对 P_X 进行优化证明了左侧不等式。

对于右侧不等式，令 X 均匀分布于 $\mathcal{X}$ 的最大 ϵ-填充上。对于任意 $P_{\hat{X}|X}$，满足 $\mathbb{E}[d(X,\hat{X})]\le c\epsilon$。令 $\tilde{X}$ 表示填充中距离 $\hat{X}$ 最近的点。于是我们得到马尔可夫链 $X\to\hat{X}\to\tilde{X}$。根据定义，$d(X,\tilde{X})\le d(\hat{X},\tilde{X})+d(\hat{X},X)\le 2d(\hat{X},X)$，因此 $\mathbb{E}[d(X,\tilde{X})]\le 2c\epsilon$。由于要么 $X=\tilde{X}$ 要么 $d(X,\tilde{X})>\epsilon$，我们有 $\mathbb{P}[X\neq\tilde{X}]\le 2c$。另一方面，Fano 不等式（推论 3.13）给出 $\mathbb{P}[X\neq\tilde{X}]\ge 1-\frac{I(X;\hat{X})+\log 2}{\log M}$。综上，$I(X;\hat{X})\ge(1-2c)\log M-\log 2$，从而证明了上界。□

注27.4 (a) 显然，定理27.16可以推广到失真函数等于度量的幂的情况，即，将(27.45)替换为

$$\phi_{X,r}(\epsilon)\triangleq\inf_{P_{\hat{X}|X}:\mathbb{E}[d(X,\hat{X})^r]\le\epsilon^r} I(X;\hat{X}).$$

那么(27.47)式继续成立，只要将$1-2c$替换为$1-(2c)^r$。这在诸如即将来临的应用中特别有用，因为处理二阶矩约束更为简便。

(b) 在早期文献中，还考虑了率失真函数的一个变体，称为ϵ-*entropy of* X，其约束条件为概率为1的$d(X,\hat{X}) \le \epsilon$，而非期望意义下（参见例如[250，附录II]和[349]）。根据此定义，自然可以推测，在$\mathcal{X}$上的所有分布中，最大ϵ熵与度量熵$\log N(\mathcal{X},\epsilon)$一致；然而，这未必成立（反例见[300，备注，第1708页]）。

定理 27.16 指出了通过最坏情况率失真函数 (27.46) 来界定度量熵的信息论途径。[14] 然而，求解该最大化问题并不容易，因为 $P_X \mapsto \phi_X(D)$ 通常既不是凸的也不是凹的 [6]。[15] 幸运的是，对于某些空间，可以通过对称性论证表明“均匀”分布在每个失真级别上最大化率失真函数；正式表述见练习 V.24。因此，我们有：

• 对于汉明空间 $\mathcal{X} = \{0,1\}^d$ 及汉明失真，$\phi_{\mathcal{X}}(D)$ 由 $\mathrm{Ber}(\frac{1}{2})^d$ 达到。（我们从定理26.1和定理24.8已知这一点。）• 对于单位球面 $\mathcal{X} = S^{d-1}$ 及由欧几里得距离定义的失真函数，$\phi_{\mathcal{X}}(D)$ 由 $\mathrm{Unif}(S^{d-1})$ 达到。• 对于正交群 $\mathcal{X} = O(d)$ 或酉群 $U(d)$ 及由弗罗贝尼乌斯范数定义的失真函数，$\phi_{\mathcal{X}}(D)$ 由 Haar 测度达到。类似的陈述也适用于格拉斯曼流形（线性子空间的集合）。

接下来，我们通过计算均匀分布$\theta \sim \mathrm{Unif}(S^{d-1})$ 的率失真函数来给出一个具体示例：

定理 27.17 *Let* θ *be uniformly distributed over the unit sphere* S^{d-1}. *Then for all* $0 < \epsilon < 1$,

$$(d-1)\log\frac{1}{\epsilon} - C \le \inf_{P_{\hat{\theta}|\theta}:\mathbb{E}[\|\hat{\theta}-\theta\|_2^2]\le\epsilon^2} I(\theta;\hat{\theta}) \le (d-1)\log\left(1+\frac{1}{\epsilon}\right) + \log(2d)$$

for some universal constant C.

注意，随机向量 θ 具有相关分量，因此我们无法引用定理24.8中的单字母化技术。然而，我们有 $Z \sim \mathcal{N}(0, I_d)$ 的表示 $\theta \overset{\mathrm{d}}{=} Z/\|Z\|_2$，这使我们能够将 θ 的率失真函数与定理26.2中发现的高斯分布联系起来。所得的下界与推论27.4中球体的度量熵一致，其尺度为 $(d-1)\log\frac{1}{\epsilon}$。使用类似的归约论证（见[275，定理VIII.18]），可以得到正交群 $O(d)$ 和酉群 $U(d)$ 的度量熵的紧下界，其尺度分别为 $\frac{d(d-1)}{2}\log\frac{1}{\epsilon}$ 和 $d^2\log\frac{1}{\epsilon}$，前置因子为

[14] A striking parallelism between the metric entropy of Sobolev balls and the rate-distortion function of smooth Gaussian processes has been observed by Donoho in [133]. However, we cannot apply Theorem 27.16 to formally relate one to the other since it is unclear whether the Gaussian rate-distortion function is maximal.

[15] As a counterexample, consider Theorem 26.1 for the binary source.

与它们各自的自由度相称。正如备注27.3(b）所述，这些结果是Szarek在[406]中利用Haar测度的体积论证得到的；相比之下，信息论方法更为基础，因为我们可以再次简化为高斯率失真计算。

Proof. 上界由定理27.16和注27.4(a)得出，应用推论27.4中球面的度量熵界。

为了证明下界，令 $Z \sim \mathcal{N}(0, I_d)$。定义 $\theta = \frac{Z}{\|Z\|}$ 和 $A = \|Z\|$，其中后文均用 $\|\cdot\| \equiv \|\cdot\|_2$ 表示。于是 $\theta \sim \mathrm{Unif}(S^{d-1})$ 与 $A \sim \chi_d$ 相互独立。固定 $P_{\hat{\theta}|\theta}$ 使得 $\mathbb{E}[\|\hat{\theta} - \theta\|^2] \le \epsilon^2$。由于 $\mathrm{Var}(A) \le 1$，香农下界（定理 26.3）表明 A 的率失真函数被标准高斯分布的率失真函数所优超。因此对于每个 $\delta \in (0,1)$，存在 $P_{\hat{A}|A}$ 使得 $\mathbb{E}[(\hat{A} - A)^2] \le \delta^2$、$I(A, \hat{A}) \le \log \frac{1}{\delta}$，且 $\mathbb{E}[A] = \mathbb{E}[\hat{A}]$。令 $\hat{Z} = \hat{A}\hat{\theta}$。则

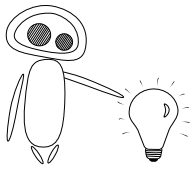
$$I(Z; \hat{Z}) = I(\theta, A; \hat{Z}) \le I(\theta, A; \hat{\theta}, \hat{A}) = I(\theta; \hat{\theta}) + I(A, \hat{A}).$$

此外，$\mathbb{E}[\hat{A}^2] = \mathbb{E}[(\hat{A} - A)^2] + \mathbb{E}[A^2] + 2\mathbb{E}[(\hat{A} - A)(A - \mathbb{E}[A])] \le d + \delta^2 + 2\delta \le d + 3\delta$。类似地，$|\mathbb{E}[\hat{A}(\hat{A} - A)]| \le 2\delta$ 和 $\mathbb{E}[\|Z - \hat{Z}\|^2] \le d\epsilon^2 + 7\delta\epsilon + \delta$。选择 $\delta = \epsilon$，我们有 $\mathbb{E}[\|Z - \hat{Z}\|^2] \le (d+8)\epsilon^2$。将定理24.8与定理26.2中的高斯率失真函数结合，我们有 $I(Z;\ \hat{Z}) \ge \frac{d}{2} \log \frac{d}{(d+8)\epsilon^2}$，因此应用 $\log(1+x) \le x$ 得到

$$I(\theta; \hat{\theta}) \ge (d-1) \log \frac{1}{\epsilon^2} - 4 \log e.$$

□

第五部分的练习



V.1 令 $\mathcal{S} = \hat{\mathcal{S}} = \{0, 1\}$。考虑由公平硬币投掷组成的源 X^{10}。构造一个简单的（次优的）压缩器，实现平均汉明失真$\frac{1}{20}$使用512个码字。

V.2 假设一种可分离的失真损失。证明表示无记忆源 X^n 所需的码字 $M^*(n, D)$ 的最小数量，其平均失真为 D (，回顾(24.9))，满足

$$\log M^*(n_1 + n_2, D) \le \log M^*(n_1, D) + \log M^*(n_2, D)\,.$$

得出结论：

$$\lim_{n\to\infty} \frac{1}{n} \log M^*(n, D) = \inf_n \frac{1}{n} \log M^*(n, D)\,. \tag{V.1}$$

也就是说，通过使用更长的块长度，人们总能实现更好的压缩率。对于（19.4）中定义的信道编码中的$\log M^*(n, \epsilon)$，这两种说法都不成立。解释为什么会出现这种不同的行为。

V.3（非渐近率失真）我们的目标是表明，向 $R(D)$ 的收敛速度远快于信道编码中向容量的收敛速度。考虑二进制均匀分布 $X \sim \mathrm{Ber}(1/2)$，采用汉明失真。

(a) 显示 t 帽子存在一个有损码 $X^n \to W \to \hat{X}^n$ 具有 M 码字 ds 和

$$\mathbb{P}[d(X^n, \hat{X}^n) > D] \le (1 - p(nD))^M\,,$$

其中

$$p(s) = 2^{-n} \sum_{j=0}^{s} \binom{n}{j}\,.$$

(b) 证明存在一个具有 M 个码字且

$$\mathbb{E}[d(X^n, \hat{X}^n)] \le \frac{1}{n} \sum_{s=0}^{n-1} (1 - p(s))^M\,. \tag{V.2}$$

(c) 证明存在一个具有 M 个码字的有损码 a nd

$$\mathbb{E}[d(X^n, \hat{X}^n)] \le \frac{1}{n} \sum_{s=0}^{n-1} e^{-Mp(s)}\,. \tag{V.3}$$

(注意：对于$M \approx 2^{nR}$，当n很大时，(V.2))的数值评估颇具挑战。同时，(V.3)仅稍显宽松。)

(d) 对于 $n = 10, 50, 100$ 和 200，通过(V.3)计算 $\log M^*(n, 0.11)$ 的上界。与下界进行比较

$$\log M^*(n, D) \geq nR(D)\,. \tag{V.4}$$

V.4 C继续练习V.3，使用斯特林公式和(V.3)-(V.4) t 显示

$$\log M^*(n, D) = nR(D) + O(\log n)\,.$$

Note: 因此，最优压缩率以$O(\log n/n)$的快速率收敛到其渐近基本极限$R(D)$，而信道编码则为$O(1/\sqrt{n})$（参见定理22.2）。这一结果对大多数无记忆源都成立。

V.5 设 $S_j \overset{\text{i.i.d.}}{\sim} P_S$ 是有限字母表 $\mathcal{A}$ 上的独立同分布源，且对所有 $a \in \mathcal{A}$，$P_S(a) > 0$。假设失真度量满足 $d(x, y) = D_0 \implies x = y$。证明 $R(D_0) = \log |\mathcal{A}|$，而 $R(D_0+) = H(X)$。

V.6 考虑一个无记忆源 X 在 $\mathcal{X} = \hat{\mathcal{X}} = [m]$ 上均匀分布，具有汉明失真：$d(x, \hat{x}) = 1\{x \neq \hat{x}\}$。证明

$$R(D) = \begin{cases} \log m - h(D) - D\log(m-1) & D \leq \frac{m-1}{m} \\ 0 & \text{otherwise.} \end{cases}$$

(提示：应用Fano不等式定理3.12。)

V.7 设 X 和 Y 为取值于 $\{1, 2, 3\}$ 的随机变量，且满足 $\mathbb{P}[X = Y] = \frac{1}{2}$。如果 Y 是均匀分布，你能找到的关于 $I(X;\ Y)$ 的最佳上界和下界是什么?

V.8（删除失真度量）考虑伯努利(1/2)源$S \in \{0, 1\}$，再现字母表$\hat{\mathcal{A}} = \{0, ?, 1\}$以及失真度量

$$d(a, \hat{a}) = \begin{cases} 0, a = \hat{a}, \\ 1, \hat{a} = ?, \\ \infty, a \neq \hat{a}, \hat{a} \neq ?\,. \end{cases}$$

$D_{\max}$ 是有限的吗? 求率失真函数 $R(D)$。

V.9 设 $X \sim \text{Unif}[\pm 1]$，并利用 $d(x, \hat{x}) = (x - \hat{x})^2$ 对 $\hat{X} \in \mathbb{R}$ 进行重构。证明率失真函数由下式以参数形式给出

$$R = \log 2 - h(p), \qquad D = 4p(1-p), \qquad p \in [0, 1/2]$$

并且对于任何失真水平，最优向量量化器仅取值为 $\pm(1-2p)$ (提示：您可能会发现练习 I.64(b) 很有用）。与 $\hat{X} \in \{\pm 1\}$ 的情况进行比较，对于该情况我们已经展示了 $R(D) = \log 2 - h(D/4), D \in [0, 2]$。

V.10（乘积源）考虑两个独立的平稳无记忆源 $X \in \mathcal{X}$ 和 $Y \in \mathcal{Y}$，其再现字母表分别为$\hat{\mathcal{X}}$ 和$\hat{\mathcal{Y}}$，失真度量分别为 d_1：$\mathcal{X} \times \hat{\mathcal{X}} \to \mathbb{R}_+$ 和 d_2：$\mathcal{Y} \times \hat{\mathcal{Y}} \to \mathbb{R}_+$，率失真函数分别为 R_X 和 R_Y。现在考虑平稳无记忆乘积源 $Z = (X, Y)$，其再现字母表为$\hat{\mathcal{X}} \times \hat{\mathcal{Y}}$，失真度量为 $d(z, \hat{z}) = d_1(x, \hat{x}) + d_2(y, \hat{y})$。

(a) 证明

$$I(X,Y;\hat{X},\hat{Y}) \geq I(X;\hat{X}) + I(Y;\hat{Y})$$

如果 X 和 Y 独立。

(b) 证明Z的率失真函数通过*inf-convolution*与X和Y的率失真函数相关，即

$$R(D) = \inf_{0\leq D_1\leq D} R_X(D_1) + R_Y(D-D_1).$$

(c) 你如何使用 X 和 Y 的最优有损压缩器来构建 Z 的最优有损压缩器?

V.11（带输出约束的压缩）计算Ber(p)信源的率失真函数$R(D;\ a,p)$，在额外约束下重构点$\hat{X}^n$应具有平均汉明重量$\mathbb{E}[w_H(\hat{X}^n)] \leq an$的汉明失真，其中$0 < a,p \leq \frac{1}{2}$。（提示：证明一个更一般的结果，即给定两个失真度量d_1, d_2，我们有$R(D_1,D_2) = \min\{I(S;\ \hat{S}):\ \mathbb{E}[d_i(S,\hat{S})] \leq D_i, i\in\{1,2\}\}$。）

V.12 商业（单声道）调频广播将带宽限制在15kHz的音频信号调制为200kHz带宽的射频信号。该系统大致实现了

$$\mathsf{SNR}_{audio} \approx 40\text{ dB} + \mathsf{SNR}_{channel}$$

在AWGN信道上，当$\mathsf{SNR}_{channel} \gtrsim$为12 dB时。因此，对于12 dB信道，我们得到FM收音机的失真为52 dB。证明信息论极限约为160 dB。*Hint:*假设输入信号经过低通滤波至15 kHz，为白噪声、零均值高斯分布，并针对给定的带宽扩展比和固定的$\mathsf{SNR}_{channel}$使用最优联合信源信道编码(JSSC)。同时回忆，重建信噪比$\hat{S}^n$以dB表示定义为

$$\mathsf{SNR}_{audio} \triangleq 10\log_{10}\frac{\sum_{j=1}^k \mathbb{E}[S_j^2]}{\sum_{j=1}^k \mathbb{E}[(S_j-\hat{S}_j)^2]}\,.$$

V.13 考虑一个无记忆高斯源 $X\sim\mathcal{N}(0,1)$，重构字母表$\hat{\mathcal{A}}=\{\pm 1\}$ 和二次失真 $d(a,\hat{a})=(a-\hat{a})^2$。计算 D_0、$R(D_0+)$、$D_{\max}$。然后得到 $R(D)$ 的参数公式。

V.14（Erokhin 的率失真 [155]）令 $d(a^k,b^k)=1\{a^k\neq b^k\}$ 为有限字母表 $\mathcal{S}=\hat{\mathcal{S}}$ 上 k 串的一个（不可分离的）失真度量。证明对于任意源 S^k，我们有

$$\varphi_{S^k}(\epsilon) \triangleq \min_{\mathbb{P}[S^k\neq\hat{S}^k]\leq\epsilon} I(S^k;\hat{S}^k) \geq H(S^k) - \epsilon k\log|\mathcal{S}| - h(\epsilon)\,, \tag{V.5}$$

并且该界仅在 S^k 在 $\mathcal{S}^k$ 上均匀分布时达到紧致。接下来，假设 S^k 是独立同分布源。证明

$$\phi_{S^k}(\epsilon) = (1-\epsilon)kH(S) - \sqrt{\frac{kV(S)}{2\pi}}e^{-\frac{(Q^{-1}(\epsilon))^2}{2}} + O(\log k)\,,$$

其中 $V(S)$ 是 *varentropy* (10.4)。（提示：令 $T=\hat{P}_{S^k}$ 为具体实现 S^k 的经验分布（类型）。则 $I(S^k;\ \hat{S}^k) = I(S^k,T;\ \hat{S}^k) = I(S^k;\ \hat{S}^k|T) + O(\log k)$。记 $\epsilon_T \triangleq \mathbb{P}[S^k\neq\hat{S}^k|T]$

并给定ϵ_T，通过(V.5)优化第一项。然后在所有$\mathbb{E}[\epsilon_T] \le \epsilon$上优化分配$\epsilon_T$。对于$Z \sim \mathcal{N}(0,1)$，也使用$\mathbb{E}[Z1\{Z>c\}] = \frac{1}{\sqrt{2\pi}} e^{-c^2/2}$。完整细节见[254，引理1]。

V.15 考虑一个源 $S^n \overset{\text{i.i.d.}}{\sim} \text{Ber}(\frac{1}{2})$。回答以下问题 *when n is large*。

(a) 假设目标是将 S^n 压缩为 k 比特，以便能够以最多一个比特的错误重建 S^n。也就是说，解码版本 $\hat{S}^n$ 满足 $\mathbb{E}[d_{\text{H}}(\hat{S}^n, S^n)] \le 1$。证明这可以在某个常数 C 下用 $k = n - C\log n$ 比特实现（如果可能，请给出显式算法）。它是最优的吗？(b) 假设我们被要求将 S^n 压缩为仅 1 比特。证明可以实现（如果可能，请给出显式算法）重建误差 $\mathbb{E}[d_{\text{H}}(\hat{S}^n, S^n)] \le \frac{n}{2} - C\sqrt{n}$，其中某个常数 C。它是最优的吗？*Warning:* 我们不能盲目地应用渐近率失真理论来证明可达性，因为这里的失真水平随 n 变化。然而，逆命题直接适用。

V.16 考虑一个标准高斯向量 S^n 和二次失真度量。我们将讨论 *zero- rate* 量化。

(a) 令 $S_{\max} = \text{为}_{1\le i\le n} S_i$ 的最大值。证明当 $n\to\infty$ 时，$\mathbb{E}[(S_{\max} - \sqrt{2\ln n})^2] \to 0$。证明当 $n\to\infty$ 时，$\mathbb{E}[(S_{\max} - \sqrt{2\ln n})^2] \to 0$。 (b) 假设给定一个 $\log_2 n$ 比特的预算。考虑以下方案：令 i^* 表示最大坐标的索引。压缩器存储索引 i^*，这需要 $\log_2 n$ 比特，解压器输出 $\hat{S}^n$，其中当 $i = i^*$ 时 $\hat{S}_i = \sqrt{2\ln n}$，否则 $S_i = 0$。证明以均方误差衡量的失真满足：当 $n\to\infty$ 时，$\mathbb{E}[\|\hat{S}^n - S^n\|_2^2] = n - 2\ln n + o(1)$。 (c) 证明对于任何压缩器（使用 $\log_2 n$ 比特），必须有 $\mathbb{E}[\|\hat{S}^n - S^n\|_2^2] \ge n - 2\ln n + o(1)$。

V.17（含噪信源编码；亦称远程信源编码[126]）考虑在可分离失真度量d下压缩独立同分布序列X^n的问题。然而，此时压缩器无法直接访问X^n，只能获取其经过平稳无记忆信道$P_{Y|X}$（传输后的含噪版本Y^n，即（对于固定$P_{X,Y}$，$X_i, Y_i) \overset{\text{i.i.d.}}{\sim} P_{X,Y}$，且编码器为映射$f$：$\mathcal{Y}^n \to [M]$）。证明率失真函数为

$$R(D) = \min\left\{ I(Y;\hat{X}) : \mathbb{E}[d(X,\hat{X})] \le D, X \to Y \to \hat{X} \right\},$$

其中最小化是在所有 $P_{\hat{X}|Y}$ 上进行的。（提示：定义 $\tilde{d}(y,\hat{x}) \triangleq \mathbb{E}[d(X,\hat{x})|Y=y]$。）

V.18（噪声/远程源编码；特殊情况）设 $Z^n \overset{\text{i.i.d.}}{\sim} \text{Ber}(\frac{1}{2})$ 以及 $X^n = \text{BEC}_\delta(Z^n)$。压缩器需要以速率 R 编码 X^n，以便我们能以误码率 D 重建 Z^n。令 $R(D)$ 表示最优速率。

(a) 假设 X^n 中擦除位置作为边信息提供给解压器。证明 $R(\delta/2) = \frac{\bar{\delta}}{2}$ (提示：压缩器非常简单)。 (b) 令人惊讶的是，在不知道擦除位置的情况下也能达到相同的速率。利用练习 V.17 证明 $R(D) = H(\bar{\delta}/2, \bar{\delta}/2, \delta) - H(1 - D - \frac{\delta}{2}, D - \frac{\delta}{2}, \delta)$ 对于 $D \in [\frac{\delta}{2}, \frac{1}{2}]$。

V.19（对数损失）考虑率失真问题，其中重建字母表$\hat{\mathcal{X}}_n = \mathcal{P}(\mathcal{X}^n)$ 是所有概率质量函数在 $\mathcal{X}^n$ 上的空间。我们定义两个损失函数。第一个

不可分离（！）

$$d_{\text{nonsep}}(x^n, \hat{P}) = \frac{1}{n} \log \frac{1}{\hat{P}(x^n)} \tag{V.6}$$

第二个是可分离的:

$$d_{\text{sep}}(x^n, \hat{P}_{X^n}) = \frac{1}{n} \sum_{j=1}^{n} \log \frac{1}{\hat{P}_{X_j}(x_j)} .$$

设 $\{X_i, i \geq 1\}$ 为熵率为 $\mathcal{H}$ 的过程。

(a) 证明任何用于 d_{sep} 的 (n, M, D)-码可以转换为用于 d_{nonsep} 的 (n, M, D)-码。因此

$$R_{\text{sep}}(D) \geq R_{\text{nonsep}}(D) .$$

(b) 证明在d_{nonsep}下的信息率失真函数由下式给出

$$R^{(\text{I})}_{\text{nonsep}}(D) = |\mathcal{H} - D|^+ .$$

(c) 证明如果量化器 $U = f(X^n)$ 使得 U 的分布是均匀的，那么它必然对于非可分离的对数损失（即 $U = R^{(\text{I})}_{\text{nonsep}}(D)$ 的对数基数）是最优的。

(d) 假设 $\{X_i\}$ 是平稳且遍历的。证明速率 $R_{i,nonsep}(D)$ 是可实现的，即

$$R_{\text{nonsep}}(D) = R^{(\text{I})}_{\text{nonsep}}(D) .$$

(提示：使用 AEP (11.2)。)

(e) 假设 $\{X_i\}$ 是独立同分布的。证明

$$R^{(\text{I})}_{\text{sep}}(D) = R_{\text{sep}}(D) = R_{\text{nonsep}}(D) = |H(X) - D|^+ .$$

(由一般率失真定理可得第二个等式。)

V.20（信息瓶颈与对数损失）给定 $P_{X,Y}$ 信息瓶颈（IB）[421] 提出，W 是 Y 对 X 的最优 *approximate* 充分统计量，如果它满足

$$F_I(t) \triangleq \max\{I(X;W) : I(Y;W) \leq t, X \to Y \to W\} ,$$

其中 F_I-曲线已在前面的定义16.5中定义。这里我们解释，在对数损失失真下，IB等价于噪声源编码。

(a)（对数损失，信息）考虑率失真问题（练习 V.19），其中$\hat{\mathcal{X}}_n = \mathcal{P}(\mathcal{X}^n)$ 以及 (V.6) 中的（不可分离）损失函数 d_{nonsep}。证明有噪信源编码的解（参见练习 V.17）对所有 n 满足:

$$\inf\left\{\mathbb{E}[d_{\text{nonsep}}(X^n, \hat{P}_{X^n})] : I(Y^n; \hat{P}_{X^n}) \leq nR\right\} = n\left(H(X) - F_I(R)\right) .$$

() (对数损失，操作性的) 将操作失真率函数定义为

$$D(R) \triangleq \limsup_{n\to\infty} \inf\{D : \exists(n, \exp(nR), nD)\text{-code}\} .$$

证明

$$D(R) = H(X) - F_I(R) .$$

(提示：对于可达性，将重建限制在 $\hat{P}_{X^n} = \prod \hat{P}_{X_i}$，这使失真具有可加性，然后应用练习 V.17；对于逆命题，使用练习 III.32) 中 F_I-曲线的张量性质

V.21 (a) 设$0 \prec \Delta \preceq \Sigma$ 为正定矩阵。对于 $S \sim \mathcal{N}(0, \Sigma)$，证明

$$\inf_{P_{\hat{S}|S}: \mathbb{E}[(S-\hat{S})(S-\hat{S})^\top] \preceq \Delta} I(S; \hat{S}) = \frac{1}{2} \log \frac{\det \Sigma}{\det \Delta}.$$

(提示：对于可达性，考虑 $S = \hat{S} + Z$ 且 $\hat{S} \sim \mathcal{N}(0, \Sigma - \Delta) \perp\!\!\!\perp Z \sim \mathcal{N}(0, \Delta)$，并应用例3.5；对于逆命题，遵循定理26.2的证明。)

(b) 证明以下(26.3)的扩展：令$\sigma_1^2, \ldots, \sigma_d^2$为$\Sigma$的特征值。那么

$$\inf_{P_{\hat{S}|S}: \mathbb{E}[\|S-\hat{S}\|_2^2] \le D} I(S; \hat{S}) = \frac{1}{2} \sum_{i=1}^{d} \log^+ \frac{\sigma_i^2}{\lambda}$$

其中 $\lambda > 0$ 使得 $\sum_{i=1}^{d} \min\{\sigma_i^2, \lambda\} = D$。这是定理 20.14 中解法的对应物。

（提示：首先，利用畸变度量的正交不变性，我们可以假设Σ是对角矩阵。接着，对(26.3)应用相同的单字母化论证，并求解最小化$\sum D_i = D \frac{1}{2} \sum_{i=1}^{d}$的对数$^+ \frac{\sigma_i^2}{D_i}$。）

V.22（香农下界）设 $\|\cdot\|$ 为 $\mathbb{R}^d$ 上的 *arbitrary* 范数，且 $r > 0$。设 X 为一个取值于 $\mathbb{R}^d$ 的随机向量，其概率密度函数为 p_X。记率失真函数

$$\phi_X(D) \triangleq \inf_{P_{\hat{X}|X}: \mathbb{E}[\|\hat{X}-X\|^r] \le D} I(X; \hat{X})$$

证明香农下界（26.5），即

$$\phi_X(D) \ge h(X) + \frac{d}{r} \log \frac{d}{Dre} - \log \left(\Gamma\left(\frac{d}{r} + 1\right) V \right), \tag{V.7}$$

其中微分熵 $h(X) = \int_{\mathbb{R}^d} p_X(x) \log \frac{1}{p_X(x)} dx$ 假定为有限，且 $V = \mathrm{vol}(\{x \in \mathbb{R}^d : \|x\| \le 1\})$。

(a) 证明 $0 < V < \infty$。 (b)
证明对于任意 $s > 0$,

$$Z(s) \triangleq \int_{\mathbb{R}^d} \exp(-s\|w\|^r) dw = \Gamma\left(\frac{d}{r} + 1\right) V s^{-\frac{d}{r}}.$$

(提示：对 $\int_{\mathbb{R}^d} \exp(-s\|w\|^r) dw = \int_{\mathbb{R}^d} \int_{\|w\|^r}^{\infty} s \exp(-sx) dx dw$ 应用富比尼定理，并使用 $\Gamma(x) = \int_0^\infty t^{x-1} e^{-t} dt$。）

(c) 证明对于任何可行的 $P_{X|\hat{X}}$，使得 $\mathbb{E}[\|X - \hat{X}\|^r] \le D$ ，

$$I(X; \hat{X}) \ge h(X) - \log Z(s) - sD.$$

(提示：定义一个辅助反向信道 $Q_{X|\hat{X}}(dx|\hat{x}) = q_s(x - \hat{x}) dx$，其中 $q_s(w) = \frac{1}{Z(s)} \exp(-s\|w\|^r)$。那么 $I(X; \hat{X}) = \mathbb{E}_P[\log \frac{Q_{X|\hat{X}}}{P_X}] + D(P_{X|\hat{X}} \| Q_{X|\hat{X}} \| P_{\hat{X}})$。）

(d) 对 $s>0$ 进行优化以得出 (V.7)。
(e) 验证定理26.3的下界是(V.7)的一个特例。
Note: 或者，SLB也可以写成以下形式：

$$\phi_X(D) \geq h(X) - \sup_{P_W:\mathbb{E}[\|W\|^r]\leq D} h(W)$$

并且这个熵最大化可以按照示例5.2中的论证来解决。

V.23（均匀分布最小化凸对称泛函。）设 G 是作用在集合 $\mathcal{X}$ 上的群，使得每个 $g\in G$ 将 $x\in\mathcal{X}$ 映射到 $gx\in\mathcal{X}$。假设 G 作用为 *transitively*，即对每个 $x,x'\in\mathcal{X}$，存在 $g\in G$ 使得 $gx=x'$。设 g 是 G 的一个具有不变分布的随机元素，即对任意 $h\in G$ 有 $h\mathsf{g}\overset{\mathrm{d}}{=}\mathsf{g}$。（这样的分布称为 Haar 测度，对于紧拓扑群存在。）

(a) 证明对于任意 $x\in\mathcal{X}$，$\mathsf{g}x$ 具有相同的分布律，记为 Unif($\mathcal{X}$)，即 $\mathcal{X}$ 上的均匀分布。

(b) 设 $f:\mathcal{P}(\mathcal{X})\to\mathbb{R}$ 为凸且 G-不变的，即对于任意 $\mathcal{X}$ 值随机变量 X 和任意 $g\in G$，有 $f(P_{gX})=f(P_X)$。证明 $\min_{P_X\in\mathcal{P}(\mathcal{X})}f(P_X)=f(\mathrm{Unif}(\mathcal{X}))$。

V.24（均匀分布最大化率失真函数。）继续练习V.23的设置，设$d:\mathcal{X}\times\mathcal{X}\to\mathbb{R}$是一个$G$-不变的失真函数，即对于任意$g\in G$，有$d(gx,gx')=d(x,x')$。将一个$\mathcal{X}$-值的$X$的率失真函数记为$\phi_X(D)=\inf_{P_{\hat{X}|X}:\mathbb{E}[d(X,\hat{X})]\leq D} I(X;\hat{X})$。假设对于所有$X$和所有$D>0$，有$\phi_X(D)<\infty$。

(a) 令 $\phi_X^*(\lambda)=\sup_D\{\lambda D-\phi_X(D)\}$ 表示 ϕ_X 的共轭。应用定理24.4和Fenchel-Moreau的双共轭定理得出 $\phi_X(D)=\sup_\lambda\{\lambda D-\phi_X^*(\lambda)\}$。
(b) 证明

$$\phi_X^*(\lambda)=\sup_{P_{\hat{X}|X}}\{\lambda\mathbb{E}[d(X,\hat{X})]-I(X;\hat{X})\}.$$

因此，对于ea第 λ 章，$P_X\mapsto\phi_X^*(\lambda)$ 是凸的且 G-不变。（提示：定理 5.3.）
(c) 应用练习 V.23 得出 $\phi_U^*(\lambda)\leq\phi_X^*(\lambda)$ 对于 $U\sim\mathrm{Unif}(\mathcal{X})$ 成立，并且

$$\phi_X(D)\leq\phi_U(D),\quad\forall D>0.$$

V.25（正态尾部界。）用 $\varphi(x)=\frac{1}{\sqrt{2\pi}}e^{-x^2/2}$ 和 $\Phi^c(t)=\int_t^\infty\varphi(x)dx$ 表示标准正态密度和尾部概率。证明对所有 $t>0$,

$$\frac{t}{1+t^2}\varphi(t)\leq\Phi^c(t)\leq\min\left\{\frac{\varphi(t)}{t},e^{-t^2/2}\right\}. \tag{V.8}$$

(提示：对于 $\Phi^c(t)\leq e^{-t^2/2}$，应用切尔诺夫界（15.2）；对于其余部分，注意通过分部积分 $\Phi^c(t)=\frac{\varphi(t)}{t}-\int_t^\infty\frac{\varphi(x)}{x^2}dx$。）

V.26（汉明空间中的覆盖半径）在本练习中，我们证明（27.9），即对于任意固定的 $0\leq D\leq 1$，当 $n\to\infty$ 时,

$$N(\mathbb{F}_2^n,d_{\mathrm{H}},Dn)=2^{n(1-h(D))_+ +o(n)},$$

其中 $h(\cdot)$ 是二元熵函数。

(a) 利用定理27.3中的体积界限和例15.1中的大偏差估计来证明下界。

(b) 使用概率构造法和与(25.8)类似的论证来证明上界。

(c) 证明对于 $D \geq \frac{1}{2}$, $N(\mathbb{F}_2^n, d_{\mathrm{H}}, Dn) \leq 2$ – 参见练习 V.15a。

V.27（用 ℓ_q-球覆盖 ℓ_p-球）

(a) 对于$1 \leq p < q \leq \infty$，证明单位ℓ_p-球相对于ℓ_q-范数的度量熵的界(27.18)（提示：对于较小的ϵ，应用(27.15)–(27.16)中的体积计算以及(27.13)中的公式；对于较大的ϵ，按照定理27.7的证明方法，应用量化论证和Hamming球的Gilbert-Varshamov界。）

(b) 当 $p > q$ 时会发生什么?

V.28 在本练习中，我们证明达德利的链式不等式（27.22）。鉴于定理27.2，证明以下带有覆盖数的版本是等价的:

$$w(\Theta) \lesssim \int_0^\infty \sqrt{\log N(\epsilon)}\, d\epsilon. \tag{V.9}$$

其中 $N(\epsilon) \equiv N(\Theta, \|\cdot\|_2, \epsilon)$ 是 Θ 的 ℓ_2-覆盖数，$w(\Theta) = \mathbb{E}_{Z\sim\mathcal{N}(0,I_d)} \sup_{\theta\in\Theta} \langle \theta, Z\rangle$ 是其高斯宽度。

证明如果Θ不是完全有界的，则两边都是无限的。

b 接下来，假设 $\mathrm{rad}(\Theta) < \infty$，令 T_i 为 Θ 的最优 ϵ_i 覆盖，其中 $\epsilon_i = \mathrm{rad}(\Theta)2^{-i}, i \geq 0$，因此 $T_0 = \{\theta_0\}$，即 Θ 的切比雪夫中心。证明

$$\sup_{\theta\in\Theta} \langle Z, \theta\rangle \leq \langle Z, \theta_0\rangle + \sum_{i\geq 1} M_i$$

其中 $M_i \triangleq$ 最大$\{\langle Z, s_i - s_{i-1}\rangle : \ s_i \in T_i, s_{i-1} \in T_{i-1}\}$。（提示：对于任何 $\theta \in \Theta$，令 θ_i 表示其在 T_i 中的最近邻。则 $\langle Z, \theta\rangle = \langle Z, \theta_0\rangle + \sum_{i\geq 1}\langle Z, \theta_i - \theta_{i-1}\rangle$。）

c 证明 $\mathbb{E}[M_i] \lesssim \epsilon_i\sqrt{\log N(\epsilon_i)}$ (提示：$\|\theta_i - \theta_{i-1}\| \leq \|\theta_i - \theta\| + \|\theta_{i-1} - \theta\| \leq 3\epsilon_i$。然后应用引理 27.10 和有界收敛定理。)

d 得出结论:

$$w(\Theta) \lesssim \sum_{i\geq 0} \epsilon_i \sqrt{\log N(\epsilon_i)}$$

并与积分版本（V.9）进行比较。

V.29（随机矩阵）设A为一个$m \times n$矩阵，其元素为独立同分布的$\mathcal{N}(0, 1)$。记其算子范数为 $\|A\|_{\mathrm{op}} = \max_{v\in S^{n-1}} \|Av\|$，这也是$A$的最大奇异值。

(a) 证明

$$\|A\|_{\mathrm{op}} = \max_{u\in S^{m-1}, v\in S^{n-1}} \langle A, uv'\rangle\,. \tag{V.10}$$

(b) 设 $\mathcal{U} = \{u_1, \ldots, u_M\}$ 和 $\mathcal{V} = \{v_1, \ldots, v_M\}$ 分别是球面 S^{m-1} 和 S^{n-1} 的 ϵ-*net*。证明

$$\|A\|_{\mathrm{op}} \leq \frac{1}{(1-\epsilon)^2} \max_{u\in\mathcal{U}, v\in\mathcal{V}} \langle A, uv'\rangle\,.$$

(将推论27.4和引理27.10应用于得出结论：

$$\mathbb{E}[\|A\|] \lesssim \sqrt{n} + \sqrt{m} \tag{V.11}$$

(通过巧妙地选择(V.10)中的u和v，展示一个匹配的下界，并得出结论：

$$\mathbb{E}[\|A\|] \asymp \sqrt{n} + \sqrt{m} \tag{V.12}$$

(e) 使用苏达科夫最小化定理（定理27.8）证明一个匹配的下界。（提示：使用(27.6)）

V.30（小球概率 II。）在本练习中我们证明 (27.36)。设 $\{W_t : t \geq 0\}$ 为标准布朗运动。证明对于小的 ϵ，[16]

$$\phi(\epsilon) = -\log \mathbb{P}\left[\sup_{t\in[0,1]} |W_t| \leq \epsilon\right] \asymp \frac{1}{\epsilon^2}$$

(a) 通过重新缩放空间和时间，证明 $\mathbb{P}\left[\sup_{t\in[0,1]} |W_t| \leq \epsilon\right] = \mathbb{P}\left[\sup_{t\in[0,T]} |W_t| \leq 1\right] \triangleq p_T$，其中 $T = 1/\epsilon^2$。要证明 $p_T = e^{-\Theta(T)}$，可以不失一般性地假设 T 是一个整数。

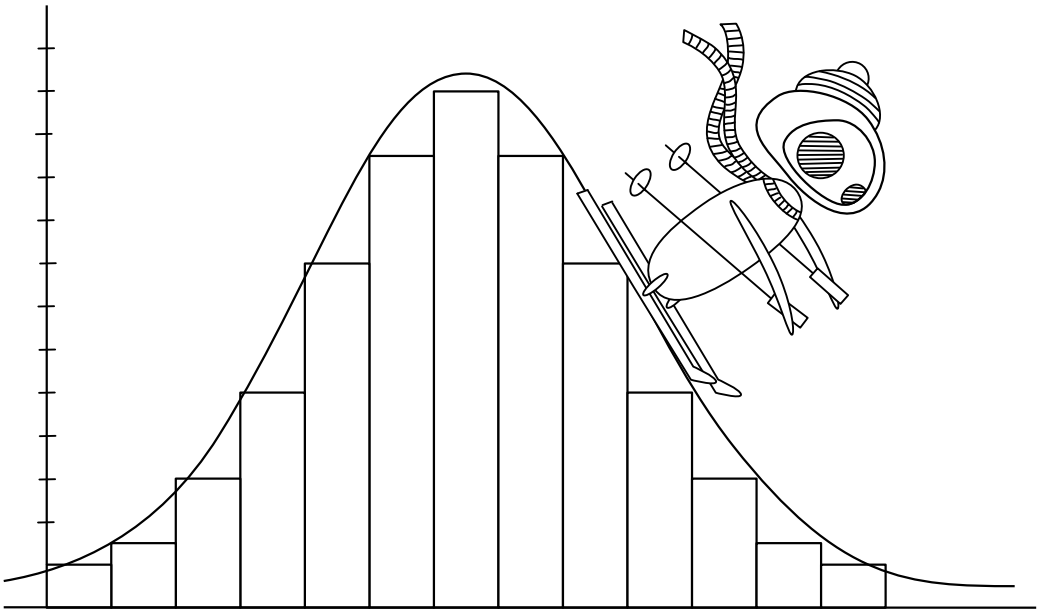
(b)（上界）利用独立增量性质，证明 $p_{T+1} \leq a p_T$，其中 $a = \mathbb{P}[|Z| \leq 1]$，且 $Z \sim \mathcal{N}(0,1)$。（提示：对于 $z \in [-1,1]$，$g(z) \triangleq \mathbb{P}[|Z - z| \leq 1]$ 在 $z = 0$ 处取最大值，在 $z = \pm 1$ 处取最小值。）

(c)（下界）同样通过缩放，它等价于展示 $\mathbb{P}\left[\sup_{t\in[0,T]} |W_t| \leq C\right] \geq C^{-T}$ 对于某个常数 C。令 $q_T \triangleq \mathbb{P}\left[\sup_{t\in[0,T]} |W_t| \leq 2, \max_{t=1,\dots,T} |W_t| \leq 1\right]$。证明 $q_{T+1} \geq b q_T$，其中 $b = \mathbb{P}[|Z-1| \leq 1]\,\mathbb{P}[\sup_{t\in[0,1]} |B_t| \leq 1]$，且 $B_t = B_t - tB_1$ 是一个布朗桥。（提示：$\{W_t : t \in [0,T]\}$，$W_{T+1} - W_T$，和 $\{W_{T+t} - (1-t)W_T - tW_{T+1} : t \in [0,1]\}$ 是相互独立的，且后者分布为布朗桥。）

[16] Using the large deviations theory developed by Donsker-Varadhan, the sharp constant can be found to be $\lim_{\epsilon\to 0} \epsilon^2 \phi(\epsilon) = \frac{\pi^2}{8}$; see for example [279, Sec. 6.2].

Part VI

统计应用



本部分阐述了信息论原理和方法在数理统计中的应用；我们通过讨论一系列专题来进行。首先，第28章介绍了统计估计的基本决策论框架以及作为基本极限的*Bayes risk*和*minimax risk*。第29章阐述了固定维度下光滑参数模型的经典大样本渐近理论，重点强调了第2章引入的Fisher信息的角色。特别是，我们讨论了如何从第7章中χ^2-散度的变分刻画和数据处理不等式（DPI）推导经典下界（Hammersley-Chapman-Robbins、Cramér-Rao、van Trees）。

进入高维，第30章介绍了*the mutual information method*用于统计下界，基于互信息的DPI以及第四和第五部分中的容量和率失真函数理论。这种原则性方法包括三种证明极小极大下界的流行方法（Le Cam、Assouad和Fano）作为特例，第31章详细讨论了这些方法，同时也借鉴了第27章中的度量熵结果。

作为第30章和第31章中关于下界的论述的补充，在第32章中，我们基于度量熵提出了统计估计的三个上界。这些上界看似惊人地相似，但源自完全不同的方法论。非参数密度估计的应用被用作主要示例。

第33章介绍*strong data processing inequalities* (SDPI)，这是第一部分中DPI的定量强化。作为应用，我们展示了如何应用SDPI来推导图或分布式设置中各种估计问题的下界。

28 Basics of statistical decision theory

在本章中，我们讨论统计估计的决策理论框架，并介绍几个重要的例子。第28.1节介绍统计实验和统计估计的基本要素。第28.3节介绍贝叶斯风险（平均情况）和极小极大风险（最坏情况），分别作为贝叶斯和频率学派设定下统计估计的基本极限，其中后者是本部分的重点。我们讨论极小极大定理的几个版本（并证明一个简单的版本），该定理将极小极大风险等同于最坏情况贝叶斯风险。接下来介绍两种变体，它们将基本统计实验扩展到大样本量或高维情形：第28.4节关于独立观测，第28.5节关于实验的张量化。贯穿本部分，第28.2节引入的高斯位置模型（GLM）作为贯穿始终的例子，在不同地方关注不同方面（如损失函数的作用、参数空间、低维与高维等）。在第28.6节中，我们讨论一个称为安德森引理的关键结果，用于确定（无约束）GLM在任何维度下对一大类损失函数的精确极小极大风险，这为后续章节中引入的各种更一般的技术提供了基准。

28.1 基本设置

我们首先介绍统计决策理论的基本要素。关于系统性的论述，可参考经典文献[166, 273, 404]。

一个 *statistical experiment* 或 *statistical model* 指的是概率分布的一个集合 $\mathcal{P}$（在同一可测空间 $(\mathcal{X}, \mathcal{F})$ 上）。具体来说，让我们考虑

$$\mathcal{P} = \{P_\theta : \theta \in \Theta\}, \tag{28.1}$$

其中每个分布都由一个取值于*parameter space* Θ中的*parameter* θ来索引。

在决策理论框架中，我们进行以下博弈：自然选择某个参数 $\theta \in \Theta$ 并生成一个随机变量 $X \sim P_\theta$。统计学家观察到数据 X，并希望推断参数 θ 或其某些属性。具体来说，考虑某个泛函 $T\colon \Theta \to \mathcal{Y}$，目标是在观测 X 的基础上估计 $T(\theta)$。这里 *estimand* $T(\theta)$ 可以是参数 θ 本身，或其某个函数（例如 $T(\theta) = 1\{\theta > 0\}$ 或 $\|\theta\|$）。

一个*estimator* (决策规则)是一个函数$\hat{T}\colon \mathcal{X} \to \hat{\mathcal{Y}}$。注意，类似于第五部分中的率失真理论，动作空间$\hat{\mathcal{Y}}$不必与$\mathcal{Y}$ (相同，例如$\hat{T}$可能是一个旨在包含标量T)的置信区间。这里$\hat{T}$可以是*deterministic*，即$\hat{T} = \hat{T}(X)$，或者*randomized*，即通过条件概率分布（马尔可夫）传递X获得的$\hat{T}$。

转移核）$P_{\hat{T}|X}$，或者用第一部分的语言来说，一个通道。在实际应用中，我们可以写为 $\hat{T} = \hat{T}(X, U)$，其中 U 表示在$[0, 1]$上均匀且独立于 X 的外部随机性。

为了衡量估计量 $\hat{T}$ 的质量，我们引入一个 *loss function* ℓ：$\mathcal{Y} \times \hat{\mathcal{Y}} \to \mathbb{R}$，使得 $\ell(T, \hat{T})$ 是 $\hat{T}$ 在估计 T 时的风险。由于我们处理的是损失（而非奖励），所有否定（逆向）结果都是下界，而所有肯定（可达）结果都是上界。注意 X 是一个随机变量，$\hat{T}$ 和 $\ell(T, \hat{T})$ 也是。因此，为了理解“最小化损失”的含义，我们考虑期望风险：

$$R_\theta(\hat{T}) = \mathbb{E}_\theta[\ell(T, \hat{T})] = \int P_\theta(dx) P_{\hat{T}|X}(d\hat{t}|x) \ell(T(\theta), \hat{t}), \tag{28.2}$$

我们称之为在θ处的$\hat{T}$的*risk*。$\mathbb{E}_\theta$中的下标表示期望所针对的分布。注意，期望风险取决于估计器以及真实值。

备注 28.1 我们注意到，假设检验和推断问题可以作为估计范式的特殊情况来涵盖。正如之前在16.4节中所讨论的，检验有三种表述形式：

- 简单假设与简单假设

$$H_0 : \theta = \theta_0 \quad \text{vs} \quad H_1 : \theta = \theta_1, \qquad \theta_0 \neq \theta_1$$

- 简单假设与复合假设

$$H_0 : \theta = \theta_0 \quad \text{vs} \quad H_1 : \theta \in \Theta_1, \qquad \theta_0 \notin \Theta_1$$

- 复合假设与复合假设

$$H_0 : \theta \in \Theta_0 \quad \text{vs} \quad H_1 : \theta \in \Theta_1, \qquad \Theta_0 \cap \Theta_1 = \emptyset.$$

对于每种情况，都可以引入相应的参数空间和损失函数。例如，在最后（最一般）的情况下，我们可以取

$$\Theta = \Theta_0 \cup \Theta_1, \quad T(\theta) = \begin{cases} 0 & \theta \in \Theta_0 \\ 1 & \theta \in \Theta_1 \end{cases}, \quad \hat{T} \in \{0, 1\}$$

并使用零一损失 $\ell(T, \hat{T}) = 1\left\{T \neq \hat{T}\right\}$，使得期望风险 $R_\theta(\hat{T}) = P_\theta\{\theta \notin \Theta_{\hat{T}}\}$ 即为错误概率。

对于推断问题，目标是输出一个以高概率覆盖真实参数的置信区间（或区域）。在这种情况下，$\hat{T}$ 是 Θ 的一个子集，我们可以选择损失函数 $\ell(\theta, \hat{T}) = 1\left\{\theta \notin \hat{T}\right\} + \lambda \cdot$ 长度$(\hat{T})$ 对于某个 $\lambda > 0$，以平衡置信区间的覆盖率和大小。

注28.2（随机化与确定性估计量）尽管实践中使用的大多数估计量都是确定性的，但考虑随机化估计量有若干理由：

- 对于某些表述，如最小化最坏情况风险（极小极大方法），确定性估计器并非最优，需要随机化。另一方面，如果目标是最小化平均风险（贝叶斯方法），那么限制为确定性估计器并不会丧失一般性。

- 随机估计量空间（被视作马尔可夫核）是凸的，它是确定性估计量的凸包。这种凸化处理，例如对于极小极大定理的处理是必要的。

有关详细讨论和示例，请参见第28.3节。

一个众所周知的事实是，对于凸损失函数（即$\hat{T} \mapsto \ell(T, \hat{T})$为凸），随机化并无助益。实际上，对于任何随机估计量$\hat{T}$，我们可以通过考虑其条件期望$\mathbb{E}[\hat{T}|X]$来去随机化，这是一个确定性估计量，其风险在每个θ处都优于原始$\hat{T}$，即根据Jensen不等式，$R_\theta(\hat{T}) = \mathbb{E}_\theta \ell(T, \hat{T}) \geq \mathbb{E}_\theta \ell(T, \mathbb{E}[\hat{T}|X])$。

28.2 高斯位置模型（GLM）

请注意，不失一般性，所有统计模型都可以表示为(28.1)的参数形式（因为我们可以取θ为分布本身）。在统计学文献中，如果θ取值于有限维欧几里得空间（因此每个分布由有限多个参数指定），则习惯上将模型称为*parametric*；如果θ取值于某个无限维空间（例如密度估计或序列模型），则称为*nonparametric*。

也许最基本的参数模型是高斯位置模型（GLM），也称为正态均值模型，它对应于我们在例3.3中熟悉的高斯信道。这将是我们本书这一部分的贯穿示例。在这个模型中，我们有

$$\mathcal{P} = \{\mathcal{N}(\theta, \sigma^2 I_d) : \theta \in \Theta\}$$

其中 I_d 是 d 维单位矩阵，参数空间为 $\Theta \subset \mathbb{R}^d$。等价地，我们可以将数据表示为未知向量 θ 的含噪观测：

$$X = \theta + Z, \quad Z \sim \mathcal{N}(0, \sigma^2 I_d).$$

d =为1和d >为1的情况分别指代单变量（标量）和多变量（向量）情况。（同样值得关注的是θ为$d_1 \times d_2$矩阵的情况，该情况可以通过向量化转换为$d = d_1 d_2$维向量。）

参数空间Θ的选择代表了我们对于未知参数θ的先验知识，例如，

• $\Theta = \mathbb{R}^d$，在这种情况下，对 θ 没有假设。• $\Theta = \ell_p$-范数球。• $\Theta = \{$所有 k-稀疏向量$\} = \{\theta \in \mathbb{R}^d\colon \|\theta\|_0 \leq k\}$，其中 $\|\theta\|_0 \triangleq |\{i\colon \theta_i \neq 0\}|$ 表示支撑集的大小，非正式地称为 ℓ_0-“范数”。• $\Theta = \{\theta \in \mathbb{R}^{d_1 \times d_2}\colon$ 秩$(\theta) \leq r\}$，低秩矩阵的集合。

根据定义，更多的结构（更小的参数空间）总是使估计任务更容易（更小的最坏情况风险），但在计算方面则不一定如此。

为了估计 θ 本身（去噪），通常使用由某些范数定义的损失函数，例如，对于某个 $1 \leq p \leq \infty$ 和 $\alpha > 0$，$\ell(\theta, \hat{\theta}) = \|\theta - \hat{\theta}\|_p^\alpha$，其中 $\|\theta\|_p \triangleq (\sum |\theta_i|^p)^{\frac{1}{p}}$，而 $p = \alpha = 2$ 对应常用的 *quadratic loss* (平方误差)。一些著名的估计器包括最大似然估计器（MLE）

$$\hat{\theta}_{\mathrm{ML}} = X \tag{28.3}$$

以及基于收缩的James-Stein估计量

$$\hat{\theta}_{\mathrm{JS}} = \left(1 - \frac{(d-2)\sigma^2}{\|X\|_2^2}\right) X. \tag{28.4}$$

估计器的选择取决于目标和参数空间。例如，如果已知 θ 是稀疏的，那么将观察到的 X 中较小的项设为零（阈值处理）以更好地去噪 θ (cf. 第30.2节)是有意义的。

除了估计向量 θ 本身之外，估计其某些泛函 $T(\theta)$ 也很有意义，例如 $T(\theta) = \|\theta\|_p$、$\max\{\theta_1, \ldots, \theta_d\}$，或在矩阵情形下的特征值。此外，GLM 中的假设检验问题已得到充分研究。例如，可以考虑通过检验 $H_0 : \theta = 0$ 对立于 $H_1 : \|\theta\| \geq \epsilon$ 来检测信号的存在，或检验弱信号 $H_0 : \|\theta\| \leq \epsilon_0$ 与强信号 $H_1 : \|\theta\| \geq \epsilon_1$，无论是否对 θ 有进一步的结构性假设。我们请读者参阅专门讨论这些问题的专著 [225]。

28.3 贝叶斯风险、极小极大风险与极小极大定理

本书这一部分的主要目标之一是理解统计估计的基本极限，即确定最佳估计器的性能。如同(28.2)所示，估计器$\hat{T}$对于$T(\theta)$的风险$R_\theta(\hat{T})$取决于真实情况θ。要有意义地比较不同估计器的风险曲线，需要一番思考。作为一个简单的例子，图28.1描绘了三个估计器的风险函数。显然，$\hat{\theta}_1$在某种意义上优于$\hat{\theta}_2$，即前者的风险逐点低于后者。（在统计文献中，我们说$\hat{\theta}_2$是不可接受的。）然而，$\hat{\theta}_1$和$\hat{\theta}_3$之间的比较就不那么明确了。尽管$\hat{\theta}_3$的风险峰值大于$\hat{\theta}_1$，但其平均风险（曲线下面积）较小。实际上，这两种观点都是有效且有意义的，它们分别对应于最坏情况（极小极大）和平均情况（贝叶斯）方法。在极小极大表述中，我们将风险函数概括为一个标量量，即最坏情况风险，并寻求使这一目标最小化的估计器。在贝叶斯表述中，目标则是平均风险。接下来，我们将讨论这两种方法及其联系。为了符号简洁，我们考虑估计$T(\theta) = \theta$的任务。

28.3.1 贝叶斯风险

贝叶斯方法是一种平均情况下的表述，其中统计学家假设参数 θ 是随机的，具有已知的分布。具体来说，设 π 为一个概率分布（先验）

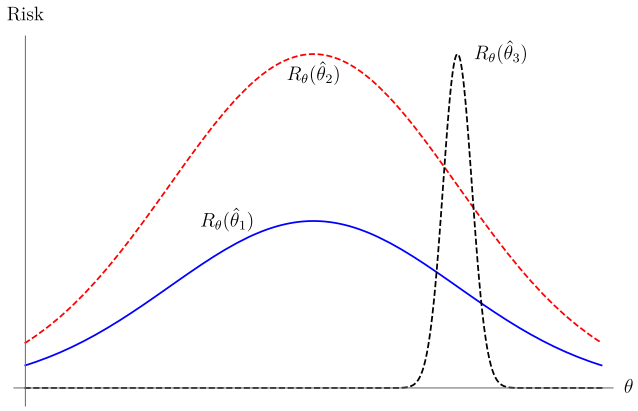


图28.1 三种估计量的风险概览。

在Θ上。那么估计量$\hat{\theta}$相对于π)的*average risk* (定义为

$$R_\pi(\hat{\theta}) = \mathbb{E}_{\theta\sim\pi}[R_\theta(\hat{\theta})] = \mathbb{E}_{\theta,X}[\ell(\theta,\hat{\theta})]. \tag{28.5}$$

给定一个先验 π，其 *Bayes risk* 是最小平均风险，即

$$R_\pi^* = \inf_{\hat{\theta}} R_\pi(\hat{\theta}).$$

一个估计量 $\hat{\theta}^*$ 如果达到贝叶斯风险，即 $R_\pi^* = \mathbb{E}_{\theta\sim\pi}[R_\theta(\hat{\theta}^*)]$，则称为 *Bayes estimator*。

注28.3 贝叶斯估计量总是确定性的，这一事实对任何损失函数都成立。要理解这一点，请注意对于任何随机化估计量，比如$\hat{\theta} = \hat{\theta}(X,U)$，其中$U$是独立于$X$和$\theta$的某种外部随机性，其风险下界为

$$R_\pi(\hat{\theta}) = \mathbb{E}_{\theta,X,U}[\ell(\theta,\hat{\theta}(X,U))] = \mathbb{E}_U[R_\pi(\hat{\theta}(\cdot,U))] \geq \inf_u R_\pi(\hat{\theta}(\cdot,u)).$$

注意，对于任何 u，$\hat{\theta}(\cdot,u)$ 都是一个确定性估计器。这表明我们可以找到一个平均风险不逊于随机估计器的确定性估计器。

对这一事实的另一种解释如下：注意，在(28.5)中定义的平均风险$R_\pi(\hat{\theta})$是随机估计量（理解为马尔可夫核$P_{\hat{\theta}|X}$）的仿射函数，其最小值在极值点处取得。在这种情况下，马尔可夫核的极值点就是德尔塔测度，对应于确定性估计量。

在某些情况下，可以显式地找到贝叶斯估计量。考虑估计来自先验 π 的 $\theta \in \mathbb{R}^d$ 的问题。在二次损失 $\ell(\theta,\hat{\theta}) = \|\hat{\theta}-\theta\|_2^2$ 下，贝叶斯估计量是条件均值 $\hat{\theta}(X) = \mathbb{E}[\theta|X]$，而贝叶斯风险是 *minimum mean-square error (MMSE)*，我们之前在3.7*节中在I-MMSE关系的背景下遇到过：

$$R_\pi^* = \mathbb{E}[\|\theta - \mathbb{E}[\theta|X]\|_2^2] = \mathbb{E}[\mathrm{Tr}(\mathrm{Cov}(\theta|X))],$$

其中 $\mathrm{Cov}(\theta|X=x)$ 是给定 $X=x$ 时 θ 的条件协方差矩阵。

作为一个具体示例，让我们考虑第28.2节中具有高斯先验的高斯位置模型。

例 28.1（GLM 中的贝叶斯风险）考虑标量情形，其中 $X = \theta + Z$ 与 $Z \sim \mathcal{N}(0, \sigma^2)$ 独立于 θ。考虑高斯先验 $\theta \sim \pi = \mathcal{N}(0, s)$。可以验证后验分布 $P_{\theta|X=x}$ 为 $\mathcal{N}(\frac{s}{s+\sigma^2}x, \frac{s\sigma^2}{s+\sigma^2})$。因此，贝叶斯估计量为 $\mathbb{E}[\theta|X] = \frac{s}{s+\sigma^2}X$，而贝叶斯风险为

$$R_\pi^* = \frac{s\sigma^2}{s+\sigma^2}. \tag{28.6}$$

同样地，对于多变量GLM：$X = \theta + Z, Z \sim \mathcal{N}(0, I_d)$，若$\theta \sim \pi = \mathcal{N}(0, sI_d)$，则有

$$R_\pi^* = \frac{s\sigma^2}{s+\sigma^2}d. \tag{28.7}$$

28.3.2 极小极大风险

对贝叶斯方法的一个常见批评是所选先验的任意性。与此相关但在本例中未讨论的一个框架是经验贝叶斯方法 [363, 470]，即从数据中“估计”先验，而不是先验地选择先验。相反，我们通过考虑最坏情况采取频率学派视角。*minimax risk* 定义为

$$R^* = \inf_{\hat{\theta}} \sup_{\theta \in \Theta} R_\theta(\hat{\theta}). \tag{28.8}$$

如果存在 $\hat{\theta}$ 使得 $\sup_{\theta\in\Theta} R_\theta(\hat{\theta}) = R^*$，则估计量 $\hat{\theta}$ 是极小极大（极小极大最优）的。

找到极小极大风险值 R^* 需要证明两件事，即，

- 一个极小极大上界，通过展示一个估计量 $\hat{\theta}^*$，使得对于所有 $\theta \in \Theta$，有 $R_\theta(\hat{\theta}^*) \le R^* + \epsilon$；
- 一个极小极大下界，通过证明对于任意估计量 $\hat{\theta}$，存在某个 $\theta \in \Theta$，使得 $R_\theta(\hat{\theta}) \ge R^* - \epsilon$,

其中 $\epsilon > 0$ 是任意的。这个任务通常很困难，尤其是在高维情况下。代替精确的极小极大风险，找到常数因子近似 Ψ 往往是有用的，我们称之为 *minimax rate*，使得

$$R^* \asymp \Psi, \tag{28.9}$$

即，对于某个通用常数 $c, C \ge 0$，有 $c\Psi \le R^* \le C\Psi$。确立 Ψ 是极小极大率仍然需要证明极小极大上界和下界，尽管是在乘性常数因子范围内。

在实践中，极小极大下界很少按照原始定义来确定。接下来的结果证明了贝叶斯风险始终低于极小极大风险。在本书中，所有下界技巧实质上归结为对精心挑选的先验进行贝叶斯风险评估。

定理 28.1 *Let $\mathcal{P}(\Theta)$ denote the collection of probability distributions on Θ. Then*

$$R^* \geq R^*_{\text{Bayes}} \triangleq \sup_{\pi \in \mathcal{P}(\Theta)} R^*_\pi. \tag{28.10}$$

(If the supremum is attained for some prior, we say it is 最不利*.)*

Proof. 证明这一事实的两种（等价）方法:

1 “最大 $\geq$ 平均”：对于任意 $\hat{\theta}$，$R_\pi(\hat{\theta}) = \mathbb{E}_{\theta\sim\pi} R_\theta(\hat{\theta}) \leq$ 上确界 $_{\theta\in\Theta} R_\theta(\hat{\theta})$。对 $\hat{\theta}$ 取下确界即完成证明;
2 “最小最大 $\geq$ 最大最小”：

$$R^* = \inf_{\hat{\theta}} \sup_{\theta\in\Theta} R_\theta(\hat{\theta}) = \inf_{\hat{\theta}} \sup_{\pi\in\mathcal{P}(\Theta)} R_\pi(\hat{\theta}) \geq \sup_{\pi\in\mathcal{P}(\Theta)} \inf_{\hat{\theta}} R_\pi(\hat{\theta}) = \sup_{\pi} R^*_\pi,$$

其中不等式源于一般事实 $\min_x \max_y f(x,y) \geq \max_y \min_x f(x,y)$。

□

注28.4 与贝叶斯估计器不同，如注28.3所示，贝叶斯估计器总是确定性的，为了最小化最坏情况风险，有时需要随机化，例如在假设检验的上下文中（第14章）。具体来说，考虑一个简单的实验，其中$\theta \in \{0,1\}$且X缺失，因此我们被迫在零一损失$\ell(\theta,\hat{\theta}) = 1\left\{\theta \neq \hat{\theta}\right\}$下猜测$\theta$的值。显然，在这种情况下，最小最大风险为$\frac{1}{2}$，通过随机猜测$\hat{\theta} \sim \text{Ber}(\frac{1}{2})$实现，而不是通过任何确定性$\hat{\theta}$。

作为定理28.1的一个应用，我们来确定在二次损失函数下高斯位置模型的极小极大风险。

示例 28.2（GLM 的极小极大二次风险）考虑无结构假设的高斯位置模型，其中 $X \sim \mathcal{N}(\theta, \sigma^2 I_d)$，$\theta \in \mathbb{R}^d$。我们证明

$$R^* \equiv \inf_{\theta\in\mathbb{R}^d} \sup_{\theta\in\mathbb{R}^d} \mathbb{E}_\theta[\|\hat{\theta}(X) - \theta\|_2^2] = d\sigma^2. \tag{28.11}$$

通过缩放，只需考虑$\sigma = 1$。对于上界，我们考虑$\hat{\theta}_{\text{ML}} = X$，它对所有$\theta$都达到$R_\theta(\hat{\theta}_{\text{ML}}) = d$。为了得到匹配的极小极大下界，我们考虑先验$\theta \sim \mathcal{N}(0, s)$。利用先前在(28.6)中计算的贝叶斯风险，我们有$R^* \geq R^*_\pi = \frac{sd}{s+1}$。令$s \to \infty$趋于无穷，得到$R^* \geq d$。

注 28.5（极小极大估计量的非唯一性） 一般来说，达到极小极大风险的估计量不必唯一。例如，如例 28.2 所示，MLE $\hat{\theta}_{\text{ML}} = X$ 对于任意维度的无约束 GLM 都是极小极大的。另一方面，已知当 $d \geq 3$ 时，James-Stein 估计量 (28.4) 的风险处处小于 MLE 的风险（见图 28.2），因此也是极小极大的。事实上，存在一个连续统的估计量对于 (28.11) 是极小极大的 [276, Theorem 5.5]。

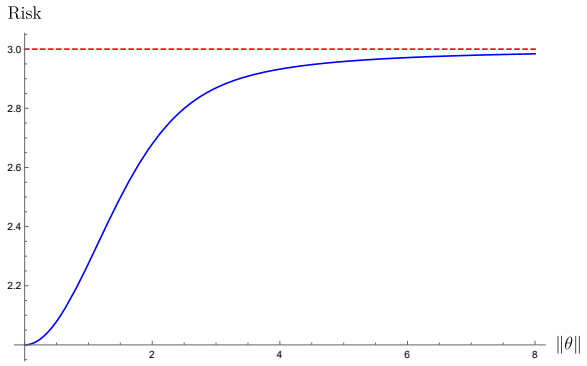


图28.2 James-Stein估计量(28.4)在维度d =为3和σ =为1时的风险作为$\|\theta\|$的函数。

对于大多数统计模型，定理28.1实际上是以等号成立；这样的结果被称为 *minimax theorem*。在讨论这个重要话题之前，这里有一个例子，其中最小最大风险严格大于最坏情况下的贝叶斯风险。

例28.3 设 $\theta, \hat{\theta} \in \mathbb{N} \triangleq \{1, 2, ...\}$ 和 $\ell(\theta, \hat{\theta}) = 1\left\{\hat{\theta} < \theta\right\}$，即如果自然的选择超过统计学家的猜测，统计学家损失一美元，否则不损失。考虑盲猜的极端情况（即没有可用数据，比如 $X = 0$）。那么对于任何 $\hat{\theta}$ 可能随机化，我们有 $R_\theta(\hat{\theta}) = \mathbb{P}(\hat{\theta} < \theta)$。因此 $R^* \geq \lim_{\theta\to\infty} \mathbb{P}(\hat{\theta} < \theta) = 1$，这显然是可以实现的。另一方面，对于 $\mathbb{N}$ 上的任何先验 π，$R_\pi(\hat{\theta}) = \mathbb{P}(\hat{\theta} < \theta)$，当 $\hat{\theta} \to \infty$ 时趋于零。因此，我们有 $R^*_\pi = 0$。所以在这种情况下 $R^* = 1 > R^*_{\text{Bayes}} = 0$。

作为一个练习，可以证明参数空间为 $\theta \geq 0$ 的 GLM $X \sim \mathcal{N}(\theta, 1)$ 的极小极大二次风险与无约束情形相同。（这可能有点令人惊讶，因为阈值估计器 $X_+ = \max(X, 0)$ 在每个 $\theta \geq 0$ 处都实现了逐点更好的风险；然而，就像 James-Stein 估计器（参见图 28.2）一样，在最坏情况下，增益渐近消失。）

28.3.3 极小极大与贝叶斯风险：对偶视角

回忆定理28.1中的不等式

$$R^* \geq R^*_{\text{Bayes}}.$$

这个结果可以从优化的角度来解释。更准确地说，R^* 是一个凸优化问题（原问题）的值，而 R^*_{Bayes} 恰好是其对偶问题的值。因此，不等式 (28.10) 简单地就是 *weak duality*。如果 *strong duality* 成立，那么 (28.10) 实际上是一个等式，在这种情况下，极小极大定理成立。

为简单起见，我们考虑Θ为有限集的情况。那么

$$R^* = \min_{P_{\hat{\theta}|X}} \max_{\theta\in\Theta} \mathbb{E}_\theta[\ell(\theta, \hat{\theta})]. \tag{28.12}$$

这是一个凸优化问题。实际上，$P_{\hat{\theta}|X} \mapsto \mathbb{E}_\theta[\ell(\theta,\hat{\theta})]$ 是仿射的，而仿射函数的逐点上确界是凸的。为了写出它的对偶问题，首先让我们将(28.12)重写为增广形式。

$$\begin{aligned} R^* = \min_{P_{\hat{\theta}|X},t} \quad & t \\ \text{s.t} \quad & \mathbb{E}_\theta[\ell(\theta,\hat{\theta})] \le t, \quad \forall \theta \in \Theta. \end{aligned} \tag{28.13}$$

令 $\pi_\theta \ge 0$ 表示每个不等式约束的拉格朗日乘子（对偶变量）。 (28.13) 的拉格朗日函数为

$$L(P_{\hat{\theta}|X},t,\pi) = t + \sum_{\theta\in\Theta} \pi_\theta \left(\mathbb{E}_\theta[\ell(\theta,\hat{\theta})] - t\right) = \left(1 - \sum_{\theta\in\Theta}\pi_\theta\right) t + \sum_{\theta\in\Theta} \pi_\theta \mathbb{E}_\theta[\ell(\theta,\hat{\theta})].$$

根据定义，我们有 $R^* \ge \min_{t,P_{\hat{\theta}|X}} L(\hat{\theta},t,\pi)$。注意，除非 $\sum_{\theta\in\Theta}\pi_\theta = 1$，否则 $\min_{t\in\mathbb{R}} L(\hat{\theta},t,\pi)$ 为 $-\infty$。因此，$\pi = (\pi_\theta : \theta \in \Theta)$ 必须是一个概率测度，对偶问题为

$$\max_{\pi} \min_{P_{\hat{\theta}|X},t} L(P_{\hat{\theta}|X},t,\pi) = \max_{\pi\in\mathcal{P}(\Theta)} \min_{P_{\hat{\theta}|X}} R_\pi(\hat{\theta}) = \max_{\pi\in\mathcal{P}(\Theta)} R^*_\pi.$$

因此，$R^* \ge R^*_{\text{Bayes}}$。

总之，极小极大风险和贝叶斯最坏情况风险通过凸对偶性相关联，其中原变量是（随机化）估计量，对偶变量是先验。这种视角实际上是可以操作化的。例如，[238, 346]表明，对于某些问题，将对 Le Cam 的两点下界（定理31.1）进行对偶化可导出最优的极小极大上界；参见练习VI.17。

28.3.4 极小极大定理

在第五章的早期部分，我们已经见识了强极小极大对偶性的一个例子。也就是说，我们发现容量满足$C = \min_{P_X}\max_{Q_Y} D(P_{Y|X}\|Q_Y|P_X) = \max_{Q_Y}\min_{P_X} D(P_{Y|X}\|Q_Y|P_X)$，并且最优对$(P^*_X, Q^*_Y)$构成了一个鞍点。这里，我们将展示一个类似极小极大定理的例子，但这次是针对统计风险。具体来说，我们希望明确确保(28.10)式等号成立的条件。为简化起见，我们考虑估计θ本身的情形，其中估计量$\hat{\theta}$取值于动作空间$\hat{\Theta}$，并配备损失函数ℓ:
$\Theta \times \hat{\Theta} \to \mathbb{R}$。一个非常普遍的结果（参见[404，定理46.6]）断言，只要满足以下条件，$R^* = R^*_{\text{Bayes}}$便成立:

• 该实验是被支配的，即在 $\mathcal{X}$ 上对于某个 ν，$P_\theta \ll \nu$ 对所有 $\theta \in \Theta$ 成立。• 动作空间 $\hat{\Theta}$ 是一个具有可数基的局部紧拓扑空间（例如欧几里得空间）。• 损失函数是水平紧的（即对于每个 $\theta \in \Theta$，$\ell(\theta,\cdot)$ 有下界，且对于每个 a，下水平集 $\{\hat{\theta}: \ell(\theta,\hat{\theta}) \le a\}$ 是紧的）。

这一结果表明，对于实践中遇到的几乎所有问题，极小极大风险与最不利的贝叶斯风险一致。任何极小极大定理的核心都有一个

分离超平面定理的应用。下面我们给出一个特殊情况的证明，以说明这种类型的论证。

定理 28.2（极小极大定理）

$$R^* = R^*_{\text{Bayes}}$$

in either of the following cases:

- Θ *is a finite set and the data* X *takes values in a finite set* $\mathcal{X}$.
- Θ *is a finite set and the loss function* ℓ *is bounded from below, i.e.,* 下确界$_{\theta,\hat{\theta}}\, \ell(\theta,\hat{\theta}) > -\infty$.

Proof. 第一种情况直接源自第28.3.3节中的对偶解释以及有限维线性规划中强对偶性成立的事实（例如参见[376, 第7.4节]）。

对于第二种情况，我们首先展示如果$R^* = \infty$，则$R^*_{\text{Bayes}} = \infty$。为此，考虑$\Theta$上的均匀先验$\pi$。那么对于任何估计量$\hat{\theta}$，存在$\theta \in \Theta$使得$R(\theta,\hat{\theta}) = \infty$。于是$R_\pi(\hat{\theta}) \geq \frac{1}{|\Theta|} R(\theta,\hat{\theta}) = \infty$。

接下来我们假设 $R^* < \infty$。那么由于假设 ℓ 下有下界（例如，由 a），有 $R^* \in \mathbb{R}$。给定估计量 $\hat{\theta}$，记其风险向量为 $R(\hat{\theta}) = (R_\theta(\hat{\theta}))_{\theta\in\Theta}$。则其相对于先验 π 的平均风险由内积 $\langle R(\hat{\theta}), \pi\rangle = \sum_{\theta\in\Theta} \pi_\theta R_\theta(\hat{\theta})$ 给出。定义

$$S = \{R(\hat{\theta}) \in \mathbb{R}^\Theta : \hat{\theta} \text{ 是一个随机估计器}\} = \text{所有可能风险向量的集合},$$
$$T = \{t \in \mathbb{R}^\Theta :\ t_\theta < R^*, \theta \in \Theta\}.$$

注意，根据 R^* 的定义，S 和 T 都是欧几里得空间 $\mathbb{R}^\Theta$ 和 $S \cap T = \emptyset$ 的凸子集（为什么？）。根据分离超平面定理，存在非零的 $\pi \in \mathbb{R}^\Theta$ 和 $c \in \mathbb{R}$，使得 $\inf_{s\in S}\langle \pi, s\rangle \geq c \geq \sup_{t\in T}\langle \pi, t\rangle$。显然，$\pi$ 必须按分量正，否则 $\sup_{t\in T}\langle \pi, t\rangle = \infty$。因此，通过归一化，我们可以假设 π 是一个概率向量，即 Θ 上的先验。那么 $R^*_{\text{Bayes}} \geq R^*_\pi = \inf_{s\in S}\langle \pi, s\rangle \geq \sup_{t\in T}\langle \pi, t\rangle \geq R^*$，完成证明。 □

28.4 多重观测与样本复杂度

给定一个实验 $\{P_\theta : \theta \in \Theta\}$，考虑如下实验

$$\mathcal{P}_n = \{P_\theta^{\otimes n} : \theta \in \Theta\}, \quad n \geq 1. \tag{28.14}$$

我们将其称为 *independent sampling model*，其中我们观察一个由来自 P_θ 的独立观测组成的样本 $X = (X_1, \ldots, X_n)$，对于某个 $\theta \in \Theta \subset \mathbb{R}^d$。给定损失函数 ℓ: $\mathbb{R}^d \times \mathbb{R}^d \to \mathbb{R}^+$，极小极大风险表示为

$$R^*_n(\Theta) = \inf_{\hat{\theta}} \sup_{\theta\in\Theta} \mathbb{E}_\theta[\ell(\theta,\hat{\theta})]. \tag{28.15}$$

显然，$n \mapsto R^*_n(\Theta)$是非递增的，因为我们总能舍弃额外的观测值。通常，当Θ是$\mathbb{R}^d$的固定子集时，$R^*_n(\Theta)$随$n \to \infty$消失。因此，一个自然的问题是

R_n^*以何种速率收敛到零。等价地，可以考虑*sample complexity*，即即使在最坏情况下，达到预定误差ϵ所需的最小样本量：

$$n^*(\epsilon) \triangleq \min\{n \in \mathbb{N} : R_n^*(\Theta) \le \epsilon\}. \tag{28.16}$$

在经典的大样本渐近理论中（第29章），二次风险的收敛速率通常为$\Theta(\frac{1}{n})$，这通常被称为“参数速率”。相比之下，在本书中，我们侧重于非渐近地理解对维度及其他结构参数的依赖性。

作为一个具体示例，让我们重新审视第28.2节中的GLM，样本量为n，在这种情况下，我们观察到$X = (X_1, \ldots, X_n) \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma^2 I_d), \theta \in \mathbb{R}^d$。此时，最小最大二次风险为[1]

$$R_n^* = \frac{d\sigma^2}{n}. \tag{28.17}$$

要看到这一点，请注意在这种情况下，$\bar{X} = \frac{1}{n}(X_1 + \ldots + X_n)$ 是 X 对 θ 的充分统计量（参见第3.5节）。因此，模型简化为 $\bar{X} \sim \mathcal{N}(\theta, \frac{\sigma^2}{n} I_d)$，而（28.17）式由单一观测的极小极大风险（28.11）推出。

从(28.17)中，我们得出结论：样本复杂度为$n^*(\epsilon) = \lceil \frac{d\sigma^2}{\epsilon} \rceil$，它随维度$d$线性增长。这就是“样本复杂度与参数数量成比例”的普遍认知，也称为“计算自由度”。实际上，在高维情况下，我们通常预期样本复杂度会随环境维度增长；然而，确切的依赖关系不一定是线性的，因为它取决于损失函数和估计目标。例如，考虑矩阵情况$\theta \in \mathbb{R}^{d \times d}$，其中$n$是高斯噪声下的独立观测值。设$\epsilon$为一个小的常数。那么我们有

• 对于二次损失，即 $\|\theta - \hat{\theta}\|_{\mathrm{F}}^2$，我们有 $R_n^* = \frac{d^2}{n}$，因此 $n^*(\epsilon) = \Theta(d^2)$；• 如果损失函数是 $\|\theta - \hat{\theta}\|_{\mathrm{op}}^2$，那么 $R_n^* \asymp \frac{d}{n}$，因此 $n^*(\epsilon) = \Theta(d)$ (例28.4)；• 与 θ 本身相反，假设我们满足于仅估计标量泛函 $\theta_{\max} = \max\{\theta_1, \ldots, \theta_d\}$ 达到精度 ϵ，那么 $n^*(\epsilon) = \Theta(\sqrt{\log d})$ (练习VI.14)。

在最后两个示例中，样本复杂度 *sublinearly* 与维度成比例。

28.5 实验的张量积

张量积是一种从低维模型定义高维模型的方法。给定统计实验 $\mathcal{P}_i = \{P_{\theta_i} : \theta_i \in \Theta_i\}$ 和相应的损失函数 ℓ_i，对于 $i \in [d]$，它们的张量积指的是以下统计实验：

$$\mathcal{P} = \left\{ P_\theta = \prod_{i=1}^d P_{\theta_i} : \theta = (\theta_1, \ldots, \theta_d) \in \Theta \triangleq \prod_{i=1}^d \Theta_i \right\},$$

1 关于该结果在非参数位置模型中的扩展，参见练习VI.11。

$$\ell(\theta, \hat{\theta}) \triangleq \sum_{i=1}^{d} \ell_i(\theta_i, \hat{\theta}_i), \forall \theta, \hat{\theta} \in \Theta.$$

在这个模型中，观测值$X = (X_1, \ldots, X_d)$由独立的（非同分布的）$X_i \overset{\text{ind}}{\sim} P_{\theta_i}$组成，损失函数呈现*separable*形式，这让人联想到(24.8)中的可分离失真函数。这一点应与(28.14)中的多观测值模型形成对比，在那里给出的是从同一分布中独立同分布抽取的n个观测值。

张量化实验的极小极大风险与各个独立实验的极小极大风险 $R^*(\mathcal{P}_i)$ 和最坏情况贝叶斯风险 $R^*_{\text{Bayes}}(\mathcal{P}_i) \triangleq \sup_{\pi_i \in \mathcal{P}(\Theta_i)} R_{\pi_i}(\mathcal{P}_i)$ 之间存在如下关系：

定理 28.3（张量积的极小极大风险）

$$\sum_{i=1}^{d} R^*_{\text{Bayes}}(\mathcal{P}_i) \le R^*(\mathcal{P}) \le \sum_{i=1}^{d} R^*(\mathcal{P}_i). \tag{28.18}$$

Consequently, if minimax theorem holds for each experiment, i.e., $R^*(\mathcal{P}_i) = R^*_{\text{贝叶斯}(\mathcal{P}_i)}$ *, then it also holds for the product experiment and, in particular,*

$$R^*(\mathcal{P}) = \sum_{i=1}^{d} R^*(\mathcal{P}_i). \tag{28.19}$$

Proof. (28.18) 的右侧不等式可通过分别基于 X_i 估计 θ_i 直接得出，即 $\hat{\theta} = (\hat{\theta}_1, \ldots, \hat{\theta}_d)$，其中 $\hat{\theta}_i$ 仅依赖于 X_i。对于左侧不等式，考虑一个乘积先验 $\pi = \prod_{i=1}^{d} \pi_i$，在此先验下 θ_i 相互独立，X_i 也相互独立。考虑基于 X 的 θ_i 的任意随机估计量 $\hat{\theta}_i = \hat{\theta}_i(X, U_i)$，其中 U_i 是独立于 X 的某种辅助随机性。我们可以将其重写为 $\hat{\theta}_i = \hat{\theta}_i(X_i, \tilde{U}_i)$，其中 $\tilde{U}_i = (X_{\setminus i}, U_i) \perp\!\!\!\perp X_i$。因此，$\hat{\theta}_i$ 可被视为仅基于 X_i 的随机估计量，其平均风险必须满足 $R_{\pi_i}(\hat{\theta}_i) = \mathbb{E}[\ell(\theta_i, \hat{\theta}_i)] \ge R^*_{\pi_i}$。对 i 求和并对先验 π_i 取上确界，即得到 (28.18) 的左侧不等式。

□

作为一个例子，我们注意到具有二次损失的无结构 d 维 GLM $\{\mathcal{N}(\theta, \sigma^2 I_d) \colon \theta \in \mathbb{R}^d\}$ 不过是一维 GLM 的 d 重张量积。由于极小极大定理对 GLM 成立（参见第 28.3.4 节），定理 28.3 表明极小极大风险之和为 $\sigma^2 d$，这与例 28.2 一致。然而，一般情况下，张量化实验的极小极大风险可能小于各个极小极大风险之和，(28.19) 的右侧不等式可能是严格的。这可能看起来令人惊讶，因为 X_i 仅携带关于 θ_i 的信息，并且仅基于 X_i 来估计 θ_i 在直觉上是合理的。尽管如此，以下是一个反例：

备注 28.6 考虑 $X = \theta Z$，其中 $\theta \in \mathbb{N}, Z \sim \text{Ber}(\frac{1}{2})$。估计量 $\hat{\theta}$ 也在 $\mathbb{N}$ 中取值，损失函数为 $\ell(\theta, \hat{\theta}) = 1\left\{\hat{\theta} < \theta\right\}$，即猜中较大数字者获胜。该实验的极小极大风险等于 $\mathbb{P}[Z = 0] = \frac{1}{2}$。要理解这一点，请注意若 $Z = 0$，则关于 θ 的所有信息都被抹去。因此对于任何（随机化）估计量 $P_{\hat{\theta}|X}$，风险下界为 $R_\theta(\hat{\theta}) = \mathbb{P}[\hat{\theta} < \theta] \ge \mathbb{P}[\hat{\theta} < \theta, Z = 0] = \frac{1}{2}\mathbb{P}[\hat{\theta} < \theta | X = 0]$。因此

发送 $\theta \to \infty$ 得到 $\sup_\theta R_\theta(\hat{\theta}) \geq \frac{1}{2}$。这可以通过 $\hat{\theta} = X$ 实现。显然，这是极小极大定理不成立的一个例子，与之前的例28.3非常相似。

接下来考虑本实验的两个副本的张量积，损失函数为 $\ell(\theta, \hat{\theta}) = 1\left\{\hat{\theta}_1 < \theta_1\right\} + 1\left\{\hat{\theta}_2 < \theta_2\right\}$。我们证明极小极大风险严格小于一。对于 $i = 1, 2$，令 $X_i = \theta_i Z_i$，其中 $Z_1, Z_2 \overset{\text{i.i.d.}}{\sim} \text{Ber}(\frac{1}{2})$。考虑以下估计量

$$\hat{\theta}_1 = \hat{\theta}_2 = \begin{cases} X_1 \vee X_2 & X_1 > 0 \text{ or } X_2 > 0 \\ 1 & \text{otherwise.} \end{cases}$$

然后对于任何 $\theta_1, \theta_2 \in \mathbb{N}$，对 Z_1, Z_2 求平均，我们得到

$$\mathbb{E}[\ell(\theta, \hat{\theta})] \leq \frac{1}{4}\left(1\left\{\theta_1 < \theta_2\right\} + 1\left\{\theta_2 < \theta_1\right\} + 1\right) \leq \frac{3}{4}.$$

本节最后，我们考虑非二次损失下GLM的极小极大风险。以下结果扩展了例28.2：

定理 28.4 *Consider the Gaussian location model $X_1, \ldots, X_n \overset{i.i.d.}{\sim} \mathcal{N}(\theta, I_d)$. Then for $1 \leq q < \infty$,*

$$\inf_{\hat{\theta}} \sup_{\theta \in \mathbb{R}^d} \mathbb{E}_\theta[\|\theta - \hat{\theta}\|_q^q] = \frac{\mathbb{E}[\|Z\|_q^q]}{n^{q/2}}, \qquad Z \sim \mathcal{N}(0, I_d).$$

Proof. 注意，$\mathcal{N}(\theta, I_d)$ 是乘积分布，且损失函数是可分离的：$\|\theta - \hat{\theta}\|_q^q = \sum_{i=1}^d |\theta_i - \hat{\theta}_i|^q$。因此，该实验是一维版本的 d 重张量积。由定理28.3，只需考虑 $d = 1$。上界由样本均值 $\bar{X} = \frac{1}{n}\sum_{i=1}^n X_i \sim \mathcal{N}(\theta, \frac{1}{n})$，这是一个充分统计量。

对于下界，根据例28.2，考虑一个高斯先验 $\theta \sim \pi = \mathcal{N}(0, s)$。那么后验分布也是高斯分布：$P_{\theta|X} = \mathcal{N}(\mathbb{E}[\theta|X], \frac{s}{1+sn})$。以下引理表明，贝叶斯估计量就是条件均值：

引理 28.5 *Let $Z \sim \mathcal{N}(0, 1)$. Then $\min_{y \in \mathbb{R}} \mathbb{E}[|y + Z|^q] = \mathbb{E}[|Z|^q]$.*

因此，贝叶斯风险为

$$R_\pi^* = \mathbb{E}[|\theta - \mathbb{E}[\theta|X]|^q] = \left(\frac{s}{1+sn}\right)^{q/2} \mathbb{E}|Z|^q.$$

发送 $s \to \infty$ 证明了匹配的下界。 □

Proof of Lemma 28.5. 写

$$\mathbb{E}|y + Z|^q = \int_0^\infty \mathbb{P}\left[|y + Z|^q > c\right] dc \geq \int_0^\infty \mathbb{P}\left[|Z|^q > c\right] dc = \mathbb{E}|Z|^q,$$

其中该不等式源于这样一个简单观察：对于任意 $a > 0$，$\mathbb{P}[|y + Z| \leq a] \leq \mathbb{P}[|Z| \leq a]$，这是由正态密度的对称性和单峰性所决定的。 □

28.6 对数凹性、安德森引理与GLM中的精确极小极大风险

正如第28.3.2节所述，计算精确的极小极大风险往往很困难，特别是在高维情况下。然而，对于（无约束）GLM这一特殊情况，对于大量损失函数，在任意维度下，极小极大风险是确切已知的。[2] 我们之前在定理28.4中已经看到，对于形式为$\ell(\theta,\hat{\theta}) = \|\theta - \hat{\theta}\|_q^q$的损失函数，这是可能的。审视该结果的证明，我们注意到主要局限在于它仅适用于可分离损失函数，因此张量化允许我们将问题降至一维。这不适用于（实际上也不成立）非可分离损失，因为若定理28.3适用，则意味着风险随维度线性增长，而这并不总是成立。接下来，我们将讨论一个超越可分离损失的更普遍结果。

定义 28.6 一个函数 $\rho : \mathbb{R}^d \to \mathbb{R}_+$ 被称为 *bowl-shaped*，如果其次水平集 $K_c \triangleq \{x : \rho(x) \le c\}$ 是凸且对称的（即对所有 $c \in \mathbb{R}$ 有 $K_c = -K_c$）。

定理 28.7 *Consider the d-dimensional GLM where $X_1, \dots, X_n \sim \mathcal{N}(0, I_d)$ are observed. Let the loss function be $\ell(\theta,\hat{\theta}) = \rho(\theta - \hat{\theta})$, where $\rho\colon \mathbb{R}^d \to \mathbb{R}_+$ is bowl-shaped and lower-semicontinuous. Then the minimax risk is given by*

$$R^* \triangleq \inf_{\hat{\theta}} \sup_{\theta\in\mathbb{R}^d} \mathbb{E}_\theta[\rho(\theta - \hat{\theta})] = \mathbb{E}\rho\left(\frac{Z}{\sqrt{n}}\right), \qquad Z \sim \mathcal{N}(0, I_d).$$

Furthermore, the upper bound is attained by $\bar{X} = \frac{1}{n}\sum_{i=1}^n X_i$.

以下推论将定理 28.4 推广到任意范数。

推论 28.8 *Let $\rho(\cdot) = \|\cdot\|^q$ for some $q > 0$, where $\|\cdot\|$ is an arbitrary norm on $\mathbb{R}^d$. Then*

$$R^* = \frac{\mathbb{E}\|Z\|^q}{n^{q/2}}. \tag{28.20}$$

例28.4 推论28.8的一些应用：

• 对于 $\rho = \|.\|_2^2$、$R^* = \frac{1}{n}\mathbb{E}\|Z\|^2 = \frac{d}{n}$，已在 (28.17) 中展示。• 对于 $\rho = \|.\|_\infty$，$\mathbb{E}\|Z\|_\infty \asymp \sqrt{\log d}$ (引理 27.10) 和 $R^* \asymp \sqrt{\frac{\log d}{n}}$。• 对于矩阵 $\theta \in \mathbb{R}^{d\times d}$，令 $\rho(\theta) = \|\theta\|_{\mathrm{op}}$ 表示算子范数（最大奇异值）。练习 V.29 中已证明 $\mathbb{E}\|Z\|_{\mathrm{op}} \asymp \sqrt{d}$，因此 $R^* \asymp \sqrt{\frac{d}{n}}$；对于 $\rho(\cdot) = \|\cdot\|_{\mathrm{F}}$，$R^* \asymp \frac{d}{\sqrt{n}}$。

我们也可以用(28.16)中定义的样本复杂度$n^*(\epsilon)$来表述推论28.8的结果。例如，对于$q = 2$，我们有$n^*(\epsilon) = \lceil \mathbb{E}[\|Z\|^2]/\epsilon \rceil$。上述例子

[2] Another example is the multinomial model with squared error; cf. Exercises **VI.7** and **VI.9**.

证明 $n^*(\epsilon)$ 随维度的缩放取决于损失函数，并且“经验法则”中采样复杂度与参数数量成正比的规律并不总是成立。

最后，为了得到高概率（而非平均）风险界，考虑 $\rho(\theta-\hat{\theta}) = 1\{\|\theta - \hat{\theta}\| > \epsilon\}$，它是下半连续且碗形的。那么精确表达式 $R^* = \mathbb{P}\left[\|Z\| \geq \epsilon\sqrt{n}\right]$。这个结果更强，因为样本均值对所有 ϵ 同时最优，因此对 ϵ 积分可恢复 (28.20)。

Proof of Theorem 28.7. 我们仅证明下界。我们通过贝叶斯风险 R^*_π 在先验 $\pi = \mathcal{N}(0, sI_d)$ 下从下方界定极小极大风险 R^*：

$$\begin{aligned} R^* \geq R^*_\pi &= \inf_{\hat{\theta}} \mathbb{E}_\pi[\rho(\theta - \hat{\theta})] \\ &= \mathbb{E}\left[\inf_{\hat{\theta}} \mathbb{E}[\rho(\theta - \hat{\theta})|X]\right] \\ &\overset{\text{(a)}}{=} \mathbb{E}[\mathbb{E}[\rho(\theta - \mathbb{E}[\theta|X])|X]] \\ &\overset{\text{(b)}}{=} \mathbb{E}\left[\rho\left(\sqrt{\frac{s}{1+sn}}Z\right)\right]. \end{aligned}$$

其中(a)由下文关键的引理28.9得出；(b)利用在高斯先验下 $\theta - \mathbb{E}[\theta|X] \sim \mathcal{N}(0, \frac{s}{1+sn}I_d)$ 这一事实。由于 $\rho(\cdot)$ 是下半连续的，令 $s \to \infty$ 并应用法图引理，我们得到匹配的下界：

$$R^* \geq \lim_{s\to\infty} \mathbb{E}\left[\rho\left(\sqrt{\frac{s}{1+sn}}Z\right)\right] \geq \mathbb{E}\left[\rho\left(\frac{Z}{\sqrt{n}}\right)\right]. \qquad \square$$

以下引理确立了条件均值作为所有碗形损失下高斯先验的贝叶斯估计量，将之前一维情况下的引理28.5进行了扩展：

引理 28.9 (Anderson [21]) *Let $X \sim \mathcal{N}(0, \Sigma)$ for some $\Sigma \succ 0$ and $\rho : \mathbb{R}^d \to \mathbb{R}_+$ be a bowl-shaped loss function. Then*

$$\min_{y\in\mathbb{R}^d} \mathbb{E}[\rho(y + X)] = \mathbb{E}[\rho(X)].$$

为了证明引理28.9，只需考虑ρ为指示函数的情形。这将在下一个引理中完成，我们稍后证明。

引理 28.10 *Let $K \in \mathbb{R}^d$ be a symmetric convex set and $X \sim \mathcal{N}(0, \Sigma)$. Then* 最大值$_{y\in\mathbb{R}^d} \mathbb{P}(X + y \in K) = \mathbb{P}(X \in K)$.

Proof of Lemma 28.9. 记子水平集 $K_c = \{x \in \mathbb{R}^d\colon\ \rho(x) \leq c\}$。由于 ρ 是碗状的，K_c 是凸且对称的，满足引理28.10的条件。因此，

$$\begin{aligned} \mathbb{E}[\rho(y + x)] &= \int_0^\infty \mathbb{P}(\rho(y + x) > c)dc, \\ &= \int_0^\infty (1 - \mathbb{P}(y + x \in K_c))dc, \end{aligned}$$

$$\begin{aligned}
&\geq \int_0^\infty (1 - \mathbb{P}(x \in K_c))dc, \\
&= \int_0^\infty \mathbb{P}(\rho(x) \geq c)dc, \\
&= \mathbb{E}[\rho(x)].
\end{aligned}$$

因此，$\min_{y\in\mathbb{R}^d} \mathbb{E}[\rho(y+x)] = \mathbb{E}[\rho(x)]$。 □

在进入引理28.10的证明之前，我们需要以下定义。

定义 28.11 称 $\mathbb{R}^d$ 上的测度 μ 为 *log-concave*，如果

$$\mu(\lambda A + (1-\lambda)B) \geq \mu(A)^\lambda \mu(B)^{1-\lambda}$$

对于所有可测的 $A, B \subset \mathbb{R}^d$ 以及任意的 $\lambda \in [0,1]$。

以下结果由Prékopa [350]给出，它通过密度函数的对数凹性来刻画测度的对数凹性；其证明也可参见[361]（或[179，定理4.2]）。

定理 28.12 *Suppose that μ has a density f with respect to the Lebesgue measure on $\mathbb{R}^d$. Then μ is log-concave if and only if f is log-concave.*

例28.5 对数凹测度的示例：

- 勒贝格测度：令 $\mu = \mathrm{vol}$ 为 $\mathbb{R}^d$ 上的勒贝格测度，它满足定理 28.12（$f \equiv 1$）。那么

$$\mathrm{vol}(\lambda A + (1-\lambda)B) \geq \mathrm{vol}(A)^\lambda \mathrm{vol}(B)^{1-\lambda}, \tag{28.21}$$

这意味着[3] *Brunn-Minkowski inequality*：

$$\mathrm{vol}(A+B)^{\frac{1}{d}} \geq \mathrm{vol}(A)^{\frac{1}{d}} + \mathrm{vol}(B)^{\frac{1}{d}}. \tag{28.22}$$

- 高斯分布：令$\mu = \mathcal{N}(0,\Sigma)$，其对数凹密度为$f$，因为$\log f(x) = -\frac{p}{2}\log(2\pi) - \frac{1}{2}\log\det(\Sigma) - \frac{1}{2}x^\top \Sigma^{-1} x$ 在x中是凹的。

Proof of Lemma 28.10. 根据定理28.12，X的分布是对数凹的。那么

$$\begin{aligned}
\mathbb{P}[X \in K] &\overset{(a)}{=} \mathbb{P}\Big[X \in \frac{1}{2}(K+y) + \frac{1}{2}(K-y)\Big] \\
&\overset{(b)}{\geq} \sqrt{\mathbb{P}[X \in K-y]\mathbb{P}[X \in K+y]} \\
&\overset{(c)}{=} \mathbb{P}[X+y \in K],
\end{aligned}$$

3 将 (28.21) 应用于 $A' = \mathrm{vol}(A)^{-1/d}A$、$B' = \mathrm{vol}(B)^{-1/d}B$（（两者均具有单位体积））以及 $\lambda = \mathrm{vol}(A)^{1/d}/(\mathrm{vol}(A)^{1/d} + \mathrm{vol}(B)^{1/d})$，得到 (28.22)。

其中 (a) 由 $\frac{1}{2}(K+y)+\frac{1}{2}(K-y)=\frac{1}{2}K+\frac{1}{2}K=K$ 得出，因为 K 是凸的；(b) 由定义 28.11 中对数凹性的定义得出，其中 $\lambda=\frac{1}{2}$，$A=K-y=\{x-y\colon\ x\in K\}$ 和 $B=K+y$；(c) 由 $\mathbb{P}[X\in K+y]=\mathbb{P}[X\in -K-y]=\mathbb{P}[X+y\in K]$ 得出，因为 X 具有对称分布且 K 是对称的（$K=-K$）。 □

29 Classical large-sample asymptotics

在本章中，我们将在第28.4节中概述在独立同分布观测设定下的经典大样本理论，再次聚焦于极小极大风险(28.15)。这些结果涉及固定维度下的光滑参数模型，唯一的渐近性是样本量趋于无穷大。主要结果是，在适当条件下，基于$X_1, \dots, X_n \overset{\text{i.i.d.}}{\sim} P_\theta$估计$\theta$的极小极大平方误差满足

$$\inf_{\hat{\theta}} \sup_{\theta \in \Theta} \mathbb{E}_\theta[\|\hat{\theta} - \theta\|_2^2] = \frac{1 + o(1)}{n} \sup_{\theta \in \Theta} \operatorname{Tr} J_F^{-1}(\theta). \tag{29.1}$$

其中 {v*} 是第2章(2.32)中引入的Fisher信息矩阵。这是具有精确常数的极小极大风险的渐近刻画。在后续章节中，我们将进入高维情形，此时如此精确的结果既困难又罕见。

在本章中，我们关注二次风险，并假设Θ是欧几里得空间$\mathbb{R}^d$的一个开集。在阅读本章时，建议读者参考练习VI.7，以理解在估计伯努利模型参数的简单设定下的极小极大风险。

29.1 数据处理中的统计下界

在本节中，我们通过数据处理论证推导出几个统计下界。具体来说，我们将采用实验比较的方法，将实际模型与扰动模型进行比较。给定估计器的性能可以通过数据处理不等式和变分表示（第7章）与 f-散度相关联。

我们首先讨论Hammersley-Chapman-Robbins下界，它蕴含了著名的Cramér-Rao下界。由于这些结果局限于无偏估计量，我们还将讨论它们的贝叶斯版本；特别是，贝叶斯Cramér-Rao下界负责证明(29.1)中的下界。我们着重解释如何从信息论推理中预见这些结果，并将贝叶斯Cramér-Rao界的精确陈述和假设推迟到第29.2节。

29.1.1 Hammersley-Chapman-Robbins (HCR) 下界

以下结果源自[210, 87]，是7.13节中χ^2-散度的变分表示的直接推论，该表示将其与测试函数的均值和方差联系起来。

定理29.1（HCR下界）*The quadratic loss of any estimator $\hat{\theta}$ at $\theta \in \Theta \subset \mathbb{R}^d$ satisfies*

$$R_\theta(\hat{\theta}) = \mathbb{E}_\theta[(\hat{\theta}-\theta)^2] \geq \mathrm{Var}_\theta(\hat{\theta}) \geq \sup_{\theta' \neq \theta} \frac{(\mathbb{E}_\theta[\hat{\theta}] - \mathbb{E}_{\theta'}[\hat{\theta}])^2}{\chi^2(P_{\theta'} \| P_\theta)}. \tag{29.2}$$

Proof. 设 $\hat{\theta}$ 为一个基于 X 的（可能随机化的）估计量。固定 $\theta' \neq \theta \in \Theta$。分别用 P 和 Q 表示真实参数为 θ 或 θ' 时的概率分布。即，$P_X = P_\theta$ 和 $Q_X = P_{\theta'}$。那么

$$\chi^2(P_X \| Q_X) \geq \chi^2(P_{\hat{\theta}} \| Q_{\hat{\theta}}) \geq \frac{(\mathbb{E}_\theta[\hat{\theta}] - \mathbb{E}_{\theta'}[\hat{\theta}])^2}{\mathrm{Var}_\theta(\hat{\theta})} \tag{29.3}$$

其中第一个不等式应用了数据处理不等式（定理7.4），第二个不等式应用了χ^2-散度的变分表示（7.91）。 □

接下来，我们将定理29.1应用于满足条件$\mathbb{E}_\theta[\hat{\theta}] = \theta$（对所有$\theta \in \Theta$）的无偏估计量$\hat{\theta}$。于是

$$\mathrm{Var}_\theta(\hat{\theta}) \geq \sup_{\theta' \neq \theta} \frac{(\theta-\theta')^2}{\chi^2(P_{\theta'} \| P_\theta)}.$$

将上确界用 $\theta' \to \theta$ 的极限来下界，并回忆定理 7.22 中关于 Fisher 信息的 χ^2-散度的渐近展开，在定理 7.22 的正则性条件下，我们得到著名的 Cramér-Rao (CR) 下界 [108, 354]:

$$\mathrm{Var}_\theta(\hat{\theta}) \geq \frac{1}{J_F(\theta)}. \tag{29.4}$$

还有几点说明如下:

- 注意，HCR下界定理29.1基于χ^2散度。对于基于Hellinger距离且同样蕴含CR下界的版本，请参见练习VI.5。
- HCR 下界和 CR 下界都按如下方式推广到多变量情形。设 $\hat{\theta}$ 是 $\theta \in \Theta \subset \mathbb{R}^d$ 的一个无偏估计量。假设其协方差矩阵 $\mathrm{Cov}_\theta(\hat{\theta}) = \mathbb{E}_\theta[(\hat{\theta}-\theta)(\hat{\theta}-\theta)^\top]$ 是正定的。固定 $a \in \mathbb{R}^d$。将定理 29.1 应用于 $\langle a, \hat{\theta}\rangle$，我们得到

$$\chi^2(P_\theta \| P_{\theta'}) \geq \frac{\langle a, \theta-\theta'\rangle^2}{a^\top \mathrm{Cov}_\theta(\hat{\theta}) a}.$$

在a上进行优化得到[1]

$$\chi^2(P_\theta \| P_{\theta'}) \geq (\theta-\theta')^\top \mathrm{Cov}_\theta(\hat{\theta})^{-1}(\theta-\theta').$$

发送 $\theta' \to \theta$ 并应用渐近展开 $\chi^2(P_\theta \| P_{\theta'}) = (\theta-\theta')^\top J_F(\theta)(\theta-\theta')(1+o(1))$ (见注 7.13)，我们得到 CR 下界的多元版本:

$$\mathrm{Cov}_\theta(\hat{\theta}) \succeq J_F^{-1}(\theta). \tag{29.5}$$

1 对于 $\Sigma \succ 0$，$\sup_{x \neq 0} \frac{\langle x,y\rangle^2}{x^\top \Sigma x} = y^\top \Sigma^{-1} y$，在 $x = \Sigma^{-1} y$ 处达到。

- 对于 n 个独立同分布观测的样本，根据可加性性质（2.36），Fisher信息矩阵等于 $nJ_F(\theta)$。对两边取迹，我们得出任何无偏估计量的平方误差满足

$$\mathbb{E}_\theta[\|\hat{\theta}-\theta\|_2^2] \geq \frac{1}{n}\mathrm{Tr}(J_F^{-1}(\theta)).$$

这已经非常接近(29.1)，除了无偏估计量的基本限制之外。

29.1.2 贝叶斯CR与HCR

HCR和CR下界的缺点在于它们仅限于无偏估计量。对于(29.1)中的极小极大设置，没有充分的理由限制使用无偏估计量；实际上，为了达到更小的总体风险，通常明智的做法是以偏差换取方差。

接下来我们讨论一个下界，称为贝叶斯克拉美-罗（BCR）下界[188]或范特里斯不等式[433]，适用于*all*估计量的贝叶斯设定；为了应用于极小极大设定，鉴于定理28.1，只需选择适当的先验。确切的陈述及其在极小极大风险中的应用将推迟到下一节。在此，我们继续先前的思路，并从数据处理论证中推导出它。

在 Θ 上固定一个先验 π 和一个（可能随机的）估计量 $\hat{\theta}$。那么我们有马尔可夫链 $\theta \to X \to \hat{\theta}$。考虑 (θ, X) 的两个联合分布：

- 在Q下，θ是从π和$X \sim P_\theta$中抽取的，以θ为条件；•在P下，θ从$T_\delta\pi$中抽取，其中T_δ表示按δ平移的前推，即$T_\delta\pi(A) = \pi(A-\delta)$，并且$X \sim P_{\theta-\delta}$以$\theta$为条件。

与（29.3）类似，应用数据处理和χ^2-散度的变分表示可得

$$\chi^2(P_{\theta X}\|Q_{\theta X}) \geq \chi^2(P_{\theta\hat{\theta}}\|Q_{\theta\hat{\theta}}) \geq \chi^2(P_{\theta-\hat{\theta}}\|Q_{\theta-\hat{\theta}}) \geq \frac{(\mathbb{E}_P[\theta-\hat{\theta}]-\mathbb{E}_Q[\theta-\hat{\theta}])^2}{\mathrm{Var}_Q(\hat{\theta}-\theta)}.$$

请注意，按设计，$P_X = Q_X$，因此 $\mathbb{E}_P[\hat{\theta}] = \mathbb{E}_Q[\hat{\theta}]$；另一方面，$\mathbb{E}_P[\theta] = \mathbb{E}_Q[\theta] + \delta$。此外，$\mathbb{E}_\pi[(\hat{\theta}-\theta)^2] \geq \mathrm{Var}_Q(\hat{\theta}-\theta)$。由于这适用于任何估计量，我们得出结论，贝叶斯风险 R_π^* (，因此极小极大风险) 满足

$$R_\pi^* \triangleq \inf_{\hat{\theta}} \mathbb{E}_\pi[(\hat{\theta}-\theta)^2] \geq \sup_{\delta\neq 0} \frac{\delta^2}{\chi^2(P_{X\theta}\|Q_{X\theta})}, \tag{29.6}$$

这被称为 *Bayesian HCR* 下界，与（29.2）相比。

类似于从HCR推导CR下界，我们可以通过评估小-δ极限进一步下推这个上确界。首先注意以下χ^2-散度的链式法则：

$$\chi^2(P_{X\theta}\|Q_{X\theta}) = \chi^2(P_\theta\|Q_\theta) + \mathbb{E}_Q\left[\chi^2(P_{X|\theta}\|Q_{X|\theta})\cdot\left(\frac{dP_\theta}{dQ_\theta}\right)^2\right].$$

在定理7.22的适当正则性条件下，再次应用χ^2-散度的局部展开得到

• $\chi 2(P_\theta \| Q_\theta) = \chi^2(T_\delta \pi \| \pi) = (J(\pi) + o(1))\delta^2$，其中 $J(\pi) \triangleq \int \frac{\pi'^2}{\pi}$ 是先验的 Fisher 信息（见例 2.7）；• $\chi^2(P_{X|\theta} \| Q_{X|\theta}) = [J_F(\theta) + o(1)]\delta^2$。

因此，从（29.6）我们得到

$$R_\pi^* \geq \frac{1}{J(\pi) + \mathbb{E}_{\theta\sim\pi}[J_F(\theta)]}. \tag{29.7}$$

我们通过重新审视例28.1中的高斯位置模型(GLM)来结束本节。

例29.1 设 $X^n = (X_1, \ldots, X_n) \overset{\text{i.i.d.}}{\sim} \mathcal{N}(\theta, 1)$，并考虑先验 $\theta \sim \pi = \mathcal{N}(0, s)$。为了应用贝叶斯HCR界（29.6），注意

$$\begin{aligned}
\chi^2(P_{\theta X^n} || Q_{\theta X^n}) &\overset{\text{(a)}}{=} \chi^2(P_{\theta \bar{X}} || Q_{\theta \bar{X}}) \\
&= \chi^2(P_\theta || Q_\theta) + \mathbb{E}_Q \left[\left(\frac{dP_\theta}{dQ_\theta} \right)^2 \chi^2(P_{\bar{X}|\theta} || Q_{\bar{X}|\theta}) \right] \\
&\overset{\text{(b)}}{=} e^{\delta^2/s} - 1 + e^{\delta^2/s}(e^{n\delta^2} - 1) \\
&= e^{\delta^2(n+\frac{1}{s})} - 1.
\end{aligned}$$

其中 (a) 由 $\bar{X} = \frac{1}{n}\sum_{i=1}^n X_i$ 的充分性得出；(b) 由 $Q_\theta = \mathcal{N}(0, s), Q_{\bar{X}|\theta} = \mathcal{N}(\theta, \frac{1}{n})$、$P_\theta = \mathcal{N}(\delta, s), P_{\bar{X}|\theta} = \mathcal{N}(\theta - \delta, \frac{1}{n})$ 以及高斯分布的 (7.43) 式得出。因此，

$$R_\pi^* \geq \sup_{\delta \neq 0} \frac{\delta^2}{e^{\delta^2(n+\frac{1}{s})} - 1} = \lim_{\delta \to 0} \frac{\delta^2}{e^{\delta^2(n+\frac{1}{s})} - 1} = \frac{s}{sn+1}.$$

鉴于在例28.1中发现的贝叶斯风险，我们注意到在这种情况下，贝叶斯HCR与贝叶斯克拉美-罗下界为*exact*。

29.2 贝叶斯CR下界及其扩展

在本节中，我们将严谨地陈述贝叶斯克拉美-罗下界，并讨论其扩展与应用。为了证明，我们采取了一种更为直接的方法，不同于第29.1节中基于χ^2散度的渐近展开的数据处理论证。

定理 29.2 (BCR 下界) *Let π be a differentiable prior density on the interval $[\theta_0, \theta_1]$ such that $\pi(\theta_0) = \pi(\theta_1) = 0$ and*

$$J(\pi) \triangleq \int_{\theta_0}^{\theta_1} \frac{\pi'(\theta)^2}{\pi(\theta)} d\theta < \infty. \tag{29.8}$$

Let $P_\theta(dx) = p_\theta(x)\mu(dx)$, where the density $p_\theta(x)$ is differentiable in θ for μ-almost every x. Assume that for π-almost every θ,

$$\int \mu(dx)\partial_\theta p_\theta(x) = 0. \tag{29.9}$$

Then the Bayes quadratic risk $R_\pi^* \triangleq \inf_{\hat\theta} \mathbb{E}[(\theta - \hat\theta)^2]$ satisfies

$$R_\pi^* \geq \frac{1}{\mathbb{E}_{\theta\sim\pi}[J_F(\theta)] + J(\pi)}. \tag{29.10}$$

Proof. 鉴于备注28.3，假设估计量$\hat\theta = \hat\theta(X)$为确定性并不会失去一般性。对于每个$x$，通过分部积分可得

$$\int_{\theta_0}^{\theta_1} d\theta(\hat\theta(x) - \theta)\partial_\theta(p_\theta(x)\pi(\theta)) = \int_{\theta_0}^{\theta_1} p_\theta(x)\pi(\theta)d\theta.$$

在$\mu(dx)$上对两边积分得到

$$\mathbb{E}[(\hat\theta - \theta)V(\theta, X)] = 1.$$

其中 $V(\theta,x) \triangleq \partial_\theta(\log(p_\theta(x)\pi(\theta))) = \partial_\theta \log p_\theta(x) + \partial_\theta \log \pi(\theta)$，期望是关于 (θ, X) 的联合分布。应用柯西-施瓦茨不等式，我们有 $\mathbb{E}[(\hat\theta - \theta)^2]\mathbb{E}[V(\theta,X)^2] \geq 1$。注意到 $\mathbb{E}[V(\theta,X)^2] = \mathbb{E}[(\partial_\theta \log p_\theta(X))^2] + \mathbb{E}[(\partial_\theta \log \pi(\theta))^2] = \mathbb{E}[J_F(\theta)] + J(\pi)$，这得益于假设 (29.9)，证明完成。 □

定理29.2的多变量版本如下。

定理 29.3 (多元 BCR) *Consider a product prior density $\pi(\theta) = \prod_{i=1}^d \pi_i(\theta_i)$ over the box $\prod_{i=1}^d [\theta_{0,i}, \theta_{1,i}]$, where each π_i is differentiable on $[\theta_{0,i}, \theta_{1,i}]$ and vanishes on the boundary. Assume that for π-almost every θ,*

$$\int \mu(dx)\nabla_\theta p_\theta(x) = 0. \tag{29.11}$$

Then

$$R_\pi^* \triangleq \inf_{\hat\theta} \mathbb{E}_\pi[\|\hat\theta - \theta\|_2^2] \geq \mathrm{Tr}((\mathbb{E}_{\theta\sim\pi}[J_F(\theta)] + J(\pi))^{-1}), \tag{29.12}$$

where the Fisher information matrices are given by $J_F(\theta) = \mathbb{E}_\theta[\nabla_\theta \text{对数}\, p_\theta(X) \nabla_\theta \text{对数}\, p_\theta(X)^\top]$ and $J(\pi) = \text{对角}(J(\pi_1), \ldots, J(\pi_d))$.

Proof. 固定估计量 $\hat\theta = (\hat\theta_1, \ldots, \hat\theta_d)$ 和非零 $u \in \mathbb{R}^d$。对于每个 $i, k = 1, \ldots, d$，分部积分给出

$$\int_{\theta_{0,i}}^{\theta_{1,i}} (\hat\theta_k(x) - \theta_k)\partial_{\theta_i}(p_\theta(x)\pi(\theta))d\theta_i = 1\{k = i\} \int_{\theta_{0,i}}^{\theta_{1,i}} p_\theta(x)\pi(\theta)d\theta_i.$$

在 $\prod_{j\neq i} d\theta_j$ 和 $\mu(dx)$ 上对两边进行积分，乘以 u_i，并对 i 求和，我们得到

$$\mathbb{E}[(\hat\theta_k(X) - \theta_k)\langle u, \nabla \log(p_\theta(X)\pi(\theta))\rangle] = \langle u, e_k\rangle$$

其中 e_k 表示第 k 个标准基。应用柯西-施瓦茨不等式并对 u 进行优化可得

$$\mathbb{E}[(\hat{\theta}_k(X)-\theta_k)^2] \geq \sup_{u\neq 0} \frac{\langle u, e_k\rangle^2}{u^\top \Sigma u} = \Sigma^{-1}_{kk},$$

其中 $\Sigma \equiv \mathbb{E}[\nabla \log(p_\theta(X)\pi(\theta))\nabla \log(p_\theta(X)\pi(\theta))^\top] = \mathbb{E}_{\theta\sim\pi}[J_F(\theta)] + J(\pi)$，得益于 (29.11)。对 k 求和完成了 (29.12) 的证明。 □

有几点需要说明:

- 上述版本的BCR界假设先验密度在边界处消失。如果我们选择均匀先验，同样的推导会得到一个类似的下界，称为Chernoff-Rubin-Stein不等式（见练习VI.4），这也足以证明(29.1)中的最优极小极大下界。

- 为了下界的目的，选择一个具有最小Fisher信息的先验密度是有利的。已知具有紧凑支撑的最优密度为平方余弦密度[219, 426]:

$$\min_{g \text{ on } [-1,1]} J(g) = \pi^2,$$

获得的 {v*}

$$g(u) = \cos^2 \frac{\pi u}{2}. \tag{29.13}$$

- 假设目标是估计未知参数 θ 的光滑函数 *functional* $T(\theta)$，其中 $T: \mathbb{R}^d \to \mathbb{R}^s$ 可微，其 $s \times d$ 雅可比矩阵为 $\nabla T(\theta) = (\frac{\partial T_i(\theta)}{\partial \theta_j})$。则在定理 29.3 的相同条件下，对于函数估计，我们有以下贝叶斯克拉美-罗下界:

$$\inf_{\hat{T}} \mathbb{E}_\pi[\|\hat{T}(X) - T(\theta)\|_2^2] \geq \mathrm{Tr}(\mathbb{E}[\nabla T(\theta)](\mathbb{E}[J_F(\theta)] + J(\pi))^{-1}\mathbb{E}[\nabla T(\theta)]^\top), \tag{29.14}$$

其中右侧的期望是基于$\theta \sim \pi$的。

作为BCR界的结果，我们证明了(29.1)中渐近极小极大风险的下界部分。

定理 29.4 *Assume that $\theta \mapsto J_F(\theta)$ is continuous. Denote the minimax squared error $R_n^* \triangleq \inf_{\hat{\theta}} \sup_{\theta\in\Theta} \mathbb{E}_\theta[\|\hat{\theta}-\theta\|_2^2]$, where $\mathbb{E}_\theta$ is taken over $X_1, \ldots, X_n \overset{i.i.d.}{\sim} P_\theta$. Then as $n \to \infty$,*

$$R_n^* \geq \frac{1+o(1)}{n} \sup_{\theta\in\Theta} \mathrm{Tr} J_F^{-1}(\theta). \tag{29.15}$$

Proof. 修正 $\theta \in \Theta$。然后对于所有足够小的 δ，$B_\infty(\theta,\delta) = \theta + [-\delta,\delta]^d \subset \Theta$。令 $\pi_i(\theta_i) = \frac{1}{\delta} g(\frac{\theta-\theta_i}{\delta})$，其中 g 是 (29.13) 中的先验密度。那么乘积分布 $\pi = \prod_{i=1}^d \pi_i$ 满足定理 29.3 的假设。根据 Fisher 信息的缩放规则（见 (2.35)），$J(\pi_i) = \frac{1}{\delta^2} J(g) = \frac{\pi^2}{\delta^2}$。因此 $J(\pi) = \frac{\pi^2}{\delta^2} I_d$ 。

已知（见 [68, 定理 2, 附录 V]）$\theta \mapsto J_F(\theta)$ 的连续性蕴含 (29.11)。因此我们已准备好应用定理 29.3 中的 BCR 界。通过贝叶斯风险对极小极大风险取下界，并应用 Fisher 信息的可加性 (2.36)，我们得到

$$R_n^* \geq \frac{1}{n} \cdot \mathrm{Tr}\left(\left(\mathbb{E}_{\theta\sim\pi}[J_F(\theta)] + \frac{\pi^2}{n\delta^2} I_d\right)^{-1}\right).$$

最后，选择 $\delta = n^{-1/4}$ 并利用 θ 中 $J_F(\theta)$ 的连续性，即可得到所需的 (29.15)。

□

类似地，为了估计光滑泛函 $T(\theta)$，应用（29.14）并使用相同的论证可得

$$\inf_{\hat{T}} \sup_{\theta\in\Theta} \mathbb{E}_\theta[\|\hat{T} - T(\theta)\|_2^2] \geq \frac{1+o(1)}{n} \sup_{\theta\in\Theta} \mathrm{Tr}(\nabla T(\theta) J_F^{-1}(\theta) \nabla T(\theta)^\top). \tag{29.16}$$

29.3 最大似然估计与渐近效率

定理 29.4 表明，在每个参数 θ 的小邻域内，当样本量 n 增长时，最佳估计误差至多为 $\frac{1}{n}($ $\mathrm{Tr}J_F^{-1}(\theta) + o(1))$；这被称为由 Fisher 信息矩阵确定的 *information bound*。达到此界的估计量称为 *asymptotic efficient*。经典大样本理论的一个基石是 *maximum likelihood estimator* (MLE) 的渐近有效性。严格陈述这一结果需要一长串技术条件，而要使误差一致以达到定理 29.4 中的极小极大下界，则需要更长的条件列表。在本节中，我们给出 MLE 渐近分析的概要，重点介绍主要思想以及 Fisher 信息如何从似然优化中产生。

假设我们观察到一个样本 $X^n = (X_1, X_2, \cdots, X_n) \overset{\text{i.i.d.}}{\sim} P_{\theta_0}$，其中 θ_0 代表真实参数。MLE 定义为：

$$\hat{\theta}_{\mathrm{MLE}} \in \arg\max_{\theta\in\Theta} L_\theta(X^n), \tag{29.17}$$

其中

$$L_\theta(X^n) = \sum_{i=1}^n \log p_\theta(X_i)$$

是总对数似然，而 $p_\theta(x) = \frac{dP_\theta}{d\mu}(x)$ 是 P_θ 关于某个共同支配测度 μ 的密度。对于离散分布 P_θ，MLE 也可以写成经验分布 $\hat{P}_n$ 到模型类的 KL 投影[2]：$\hat{\theta}_{\mathrm{MLE}} \in \arg\min_{\theta\in\Theta} D(\hat{P}_n \| P_\theta)$。

[2] Note that this is the reverse of the information projection studied in Section 15.3.

MLE 有效的主要直觉如下。假设模型是可辨识的，即 $\theta \mapsto P_\theta$ 是单射。那么对于任意 $\theta \neq \theta_0$，由 KL 散度的非负性（定理 2.3），我们有

$$\mathbb{E}_{\theta_0}[L_\theta - L_{\theta_0}] = \mathbb{E}_{\theta_0}\left[\sum_{i=1}^n \log \frac{p_\theta(X_i)}{p_{\theta_0}(X_i)}\right] = -nD(P_{\theta_0}||P_\theta) < 0.$$

换句话说，$L_\theta - L_{\theta_0}$ 是一个独立同分布和，其均值为负，因此对于较大的 n，它以高概率为负。由此，在假设适当的正则条件（其中包括 Wald 可积性条件 $\mathbb{E}_{\theta_0}[\sup_{\|\theta-\theta_0\|\le\epsilon} \log \frac{p_\theta}{p_{\theta_0}}(X)] < \infty$ [449, 454]）下，MLE 的一致性随之成立。

假设更多条件，我们可以得到MLE的渐近正态性和有效性。这源自对数似然函数的局部二次近似。定义 $V(\theta, x) \triangleq \nabla_\theta \log p_\theta(x)$ (score) 和 $H(\theta, x) \triangleq \nabla_\theta^2 \log p_\theta(x)$。通过泰勒展开，

$$\begin{aligned} L_\theta =& L_{\theta_0} + (\theta-\theta_0)^\top \left(\sum_{i=1}^n V(\theta_0, X_i)\right) + \frac{1}{2}(\theta-\theta_0)^\top \left(\sum_{i=1}^n H(\theta_0, X_i)\right)(\theta-\theta_0) \\ &+ o(n(\theta-\theta_0)^2). \end{aligned} \tag{29.18}$$

回想第2.6.2节*所述，在适当的正则条件下，我们得出

$$\mathbb{E}_{\theta_0}[V(\theta_0, X)] = 0, \quad \mathbb{E}_{\theta_0}[V(\theta_0, X)V(\theta_0, X)^\top] = -\mathbb{E}_{\theta_0}[H(\theta_0, X)] = J_F(\theta_0).$$

因此，根据中心极限定理和大数定律，我们有：

$$\frac{1}{\sqrt{n}}\sum_{i=1}^n V(\theta_0, X_i) \xrightarrow{\mathrm{d}} \mathcal{N}(0, J_F(\theta_0)), \quad \frac{1}{n}\sum_{i=1}^n H(\theta_0, X_i) \xrightarrow{\mathbb{P}} -J_F(\theta_0).$$

将这些量代入(29.18)中，我们得到对数似然的以下随机近似：

$$L_\theta \approx L_{\theta_0} + \langle \sqrt{nJ_F(\theta_0)}Z, \theta-\theta_0\rangle - \frac{n}{2}(\theta-\theta_0)^\top J_F(\theta_0)(\theta-\theta_0),$$

其中 $Z \sim \mathcal{N}(0, I_d)$。最大化右侧得到：

$$\hat{\theta}_{\mathrm{MLE}} \approx \theta_0 + \frac{1}{\sqrt{n}} J_F(\theta_0)^{-1/2} Z.$$

从这种渐近正态性，我们可以得到 $\mathbb{E}_{\theta_0}[\|\hat{\theta}_{\mathrm{MLE}} - \theta_0\|_2^2] \le \frac{1}{n}(\mathrm{Tr} J_F(\theta_0)^{-1} + o(1))$，并且对于光滑泛函，通过在 θ_0 (delta方法) 处对 T 进行泰勒展开，$\mathbb{E}_{\theta_0}[\|T(\hat{\theta}_{\mathrm{MLE}}) - T(\theta_0)\|_2^2] \le \frac{1}{n}(\mathrm{Tr}(\nabla T(\theta_0) J_F(\theta_0)^{-1} \nabla T(\theta_0)^\top) + o(1))$，与信息界 (29.15) 和 (29.16) 相符。

当然，上述启发式推导需要额外的假设来证明其合理性（例如，Cramér条件，参见[168，定理18]和[375，定理7.63]）。为了在定理29.4中达到极小极大下界，需要更强的假设以确保误差在θ中一致；确切的条件和陈述，例如，可参见[68]的定理34.4（以及第36-37章）。关于MLE及信息界达到的更一般和抽象的理论由Hájek和Le Cam发展；参见[209, 273]。

尽管最大似然估计（MLE）具有广泛的适用性和强大的最优性，但该方法并非没有局限性。本节最后，我们将就此提出一些看法。

- 即使对于简单的参数模型，MLE也可能不存在。例如，考虑从两个高斯分布的位置-尺度混合中独立同分布抽取的$X_1,\dots,X_n$，其中$(\mu_1,\mu_2,\sigma_1,\sigma_2)$是未知参数。那么，通过设置例如$\mu_1 = X_1$和$\sigma_1 \to 0$，似然函数可以变得任意大。

- MLE 可能不一致；参见 [375, 例 7.61] 和 [167] 中的例子，二者均在一维参数族中。- 在高维情况下，MLE 可能无法达到极小极大速率（练习 VI.15）。

29.4 应用：估计离散分布和熵

作为本节的一个应用，我们考虑基于独立同分布观测估计离散分布或其性质（如香农熵）的具体问题。当然，本章发展的渐近理论仅适用于固定字母表和样本量大的经典设定。在此过程中，我们还将讨论大字母表的扩展以及经典理论可能出现的问题。

在本节中，令 $X_1,\cdots,X_n \overset{\text{i.i.d.}}{\sim} P \in \mathcal{P}_k$，其中 $\mathcal{P}_k \equiv \mathcal{P}([k])$ 表示定义在 $[k]=\{1,\dots,k\}$ 上的概率分布集合。我们首先考虑在平方损失下对 P 的估计。

定理 29.5 *Fox fixed k, the minimax squared error of estimating P satisfies*

$$R^*_{\text{sq}}(k,n) \triangleq \inf_{\widehat{P}} \sup_{P\in\mathcal{P}_k} \mathbb{E}[\|\widehat{P}-P\|_2^2] = \frac{1}{n}\left(\frac{k-1}{k}+o(1)\right), \quad n\to\infty. \tag{29.19}$$

Proof. 令 $P=(P_1,\dots,P_k)$ 按照例2.6中的方式由 $\theta=(P_1,P_2,\cdots,P_{k-1})$ 和 $P_k = 1-P_1-\cdots-P_{k-1}$ 参数化。那么 $P=T(\theta)$，其中 T: $\mathbb{R}^{k-1}\to\mathbb{R}^k$ 是一个仿射泛函，使得 $\nabla T(\theta) = \left[\begin{smallmatrix} I_{k-1} \\ -1^\top \end{smallmatrix}\right]$，其中 1 是全一（列）向量。

费舍尔信息矩阵及其逆矩阵已在(2.37)和(2.38)中计算得出：我们有$J_F^{-1}(\theta) = \text{diag}(\theta) - \theta\theta^\top$ 和

$$\nabla T(\theta) J_F^{-1}(\theta) \nabla T(\theta)^\top = \begin{bmatrix} \text{diag}(\theta)-\theta\theta^\top & -P_k\theta \\ -P_k\theta^\top & P_k(1-P_k). \end{bmatrix}$$

因此 $\text{Tr}(\nabla T(\theta)J_F^{-1}(\theta)\nabla T(\theta)^\top) = \sum_{i=1}^k P_i(1-P_i) = 1-\sum_{i=1}^k P_i^2$，在均匀分布时达到最大值 $1-\frac{1}{k}$。应用 (29.16) 中 BCR 界 的函数形式，我们得出 $R^*_{\text{sq}}(k,n) \ge \frac{1}{n}(1-\frac{1}{k}+o(1))$。

对于上界，考虑MLE，在此情形下与经验分布$\hat{P} = (\hat{P}_i)$ (习题VI.8)一致。注意到 $n\hat{P}_i = \sum_{j=1}^n 1\{X_j=i\} \sim \text{Bin}(n,P_i)$。那么对于任意$P$，
$\mathbb{E}[\|\hat{P}-P\|_2^2] = \frac{1}{n}\sum_{i=1}^k P_i(1-P_i) \le \frac{1}{n}(1-\frac{1}{k})$. □

关于定理29.5的一些说明是必要的：

• 实际上，对于任意 k,n，我们有精确结果：$R^*_{\mathrm{sq}}(k,n) = \frac{1-1/k}{(1+\sqrt{n})^2}$ —— 参见练习 VI.7h。这可以通过考虑 Dirichlet 先验 (13.16) 并应用相应的 Bayes 估计量来证明，该估计量是一个加性平滑的经验分布（第 13.5 节）。• 注意 $R^*_{\mathrm{sq}}(k,n)$ 并不随字母表大小 k 增长；这是因为平方损失对于估计概率向量来说太弱了。更有意义的损失函数包括第 7 章中的 f-散度，例如全变差、KL 散度、χ^2-散度。这些极小极大率在练习 VI.8 和练习 VI.10 中针对小字母表和大字母表都进行了推导，并且它们确实依赖于字母表大小 k。例如，极小极大 KL 风险在 $k \le n$ 时满足 $\Theta(\frac{k}{n})$，而在 $k \gg n$ 时以 $\Theta(\log \frac{k}{n})$ 增长。这与经验法则一致，即一致估计要求样本量的增长速度超过维度。

作为一个最终应用，让我们考虑信息论和统计学中经典的*entropy estimation*问题[304, 128, 215]，其目标是估计香农熵，即P的非线性泛函。以下结果源自泛函BCR下界(29.16)以及对MLE（在此情况下为经验熵）的分析[39]。

定理 29.6 *For fixed k, the minimax quadratic risk of entropy estimation satisfies*

$$R^*_{\mathrm{ent}}(k,n) \triangleq \inf_{\widehat{H}} \sup_{P\in\mathcal{P}_k} \mathbb{E}[(\widehat{H}(X_1,\dots,X_n) - H(P))^2] = \frac{1}{n}\left(\max_{P\in\mathcal{P}_k} V(P) + o(1)\right), \quad n\to\infty$$

where $H(P) = \sum_{i=1}^k P_i \log\frac{1}{P_i} = \mathbb{E}[\log\frac{1}{P(X)}]$ *and* $V(P) = \mathrm{Var}[\log\frac{1}{P(X)}]$ *are the Shannon entropy and varentropy (cf. (10.4)) of* P.

让我们分析定理29.6的结果，并探讨它如何扩展到大字母表。可以证明[3] $\max_{P\in\mathcal{P}_k} V(P) \asymp \log^2 k$，这表明即使字母表大小$k$随$n$增长，$R^*_{\mathrm{ent}} \equiv R^*_{\mathrm{ent}}(k,n)$也可能满足$R^*_{\mathrm{ent}} \asymp \frac{\log^2 k}{n}$；然而，这一结果仅对足够小的字母表成立。事实上，在引理13.2中我们已经表明，对于达到定理29.6中界的经验熵，其偏差量级为$\frac{k}{n}$，在大字母表上不再可忽略。利用多项式逼近技术[456, 233]，可以将此偏差降低至$\frac{k}{n\log k}$，并进一步表明，一致的熵估计仅当且仅当$n \gg \frac{k}{\log k}$时才可能[428]，在这种情况下，极小极大速率满足

$$R^*_{\mathrm{ent}} \asymp \left(\frac{k}{n\log k}\right)^2 + \frac{\log^2 k}{n}$$

总之，将经典大样本结果推广到高维时需谨慎，尤其是当偏差成为主导因素时。

[3] Indeed, $\max_{P\in\mathcal{P}_k} V(P) \le \log^2 k$ for all $k \ge 3$ [334, Eq. (464)]. For the lower bound, consider $P = (\frac{1}{2}, \frac{1}{2(k-1)}, \dots \frac{1}{2(k-1)})$.

30 Mutual information method

在本章中，我们描述了一种证明统计下界的策略，我们称之为*Mutual Information Method* (MIM)，这涉及比较数据提供的信息量与达到特定估计精度所需的最小信息量。与第29.2节类似，主要的信息论要素是数据处理不等式，这次是针对互信息而非f-散度。

MIM的核心思想如下：在Θ上固定某个先验π，我们的目标是相对于某个损失函数ℓ，在基于X估计$\theta \sim \pi$时，对贝叶斯风险R^*_π进行下界估计。设$\hat{\theta}$为一个估计量，满足$\mathbb{E}[\ell(\theta, \hat{\theta})] \le D$。于是我们得到马尔可夫链$\theta \to X \to \hat{\theta}$。应用数据处理不等式（定理3.7），我们有

$$\inf_{P_{\tilde{\theta}|\theta}: \mathbb{E}\ell(\theta,\tilde{\theta}) \le D} I(\theta;\hat{\theta}) \le I(\theta;\hat{\theta}) \le I(\theta;X). \tag{30.1}$$

请注意

- 最左侧的量可以解释为达到给定估计精度所需的最小信息量。这正是率失真函数$\phi(D) \equiv \phi_\theta(D)$(回顾第24.3节)。
- 最右边的量可以解释为数据提供的关于潜在参数的信息量。有时，只需通过在所有先验上最大化，进一步用信道容量$P_{X|\theta}$来上界它（第5章）：

$$I(\theta;X) \le \sup_{\pi \in \mathcal{P}(\Theta)} I(\theta;X) \triangleq C. \tag{30.2}$$

因此，我们得到贝叶斯风险及由此推导的极小极大风险的以下下界

$$R^*_\pi \ge \phi^{-1}(I(\theta;X)) \ge \phi^{-1}(C). \tag{30.3}$$

互信息方法的推理让人联想到第26.3节中联合信源信道编码的逆定理证明。因此，这里的论证保留了“信源-信道分离”的特点，即(30.1)中的下界仅取决于先验(信源)和损失函数，而容量上界(30.2)仅取决于统计模型(信道)。

在接下来的几节中，我们将通过一系列示例来说明MIM及其执行过程：

• 在高斯噪声中对向量进行去噪，其中我们将计算精确的极小极大风险；• 对稀疏向量进行去噪，其中我们确定精确的极小极大速率；• 社区检测，其目标是在更大的Erd s-Rényi图中恢复一个植入的稠密子图。

在下一章中，我们将讨论三种流行的方法，分别是*Le Cam's method*、*Assouad's lemma*和*Fano's method*。如图30.1所示，这三种方法都源自

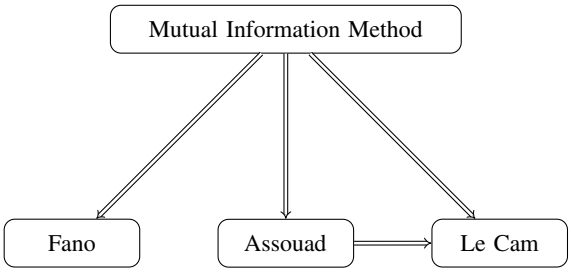


图30.1 作为互信息方法结果的三种下界技术。

互信息方法，对应于不同的先验π选择，即两点集$\{\theta_0, \theta_1\}$上的均匀分布、超立方体$\{0,1\}^d$以及一个packing（回顾第27.1节）。虽然这些方法在确定许多问题的极小极大率时非常有用，但与MIM相比，它们往往在常数因子上较为宽松。在本章最后一节中，我们讨论如何以及何时可以通过应用MIM实现非平凡估计的问题；为此，下一章中的三种方法均不适用。

30.1 重新审视GLM及香农下界

考虑 d 维 GLM，其中我们观测到 $X = (X_1, \ldots, X_n) \overset{\text{i.i.d.}}{\sim} \mathcal{N}(\theta, I_d)$，而 $\theta \in \Theta$ 是参数。记 $R^*(\Theta)$ 为关于二次损失 $\ell(\theta, \hat{\theta}) = \|\hat{\theta} - \theta\|_2^2$ 的极小极大风险。

首先，让我们考虑$\Theta = \mathbb{R}^d$的无约束模型。使用样本均值$\bar{X} = \frac{1}{n}\sum_{i=1}^n X_i \sim \mathcal{N}(\theta, \frac{1}{n} I_d)$进行估计，我们达到了上界$R^*(\mathbb{R}^d) \le \frac{d}{n}$。如例28.2所示，通过计算高斯先验的贝叶斯风险，这恰好是精确的极小极大风险。接下来，我们应用互信息方法，在不评估贝叶斯风险的情况下获得相同的匹配下界。再次，让我们考虑对于某个$s > 0$的$\theta \sim \mathcal{N}(0, sI_d)$。根据高斯率失真函数（定理26.2），我们知道

$$\phi(D) = \inf_{P_{\hat{\theta}|\theta}: \mathbb{E}[\|\hat{\theta}-\theta\|_2^2] \le D} I(\theta; \hat{\theta}) = \begin{cases} \frac{d}{2} \log \frac{sd}{D} & D < sd \\ 0 & \text{otherwise.} \end{cases}$$

使用$\bar{X}$的充分性以及高斯信道容量公式（参见定理5.11或定理20.11），参数与数据之间的互信息可以计算为

$$I(\theta; X) = I(\theta; \bar{X}) = \frac{d}{2}\log(1 + sn).$$

然后由（30.3）可得 $R^*_\pi \geq \frac{sd}{1+sn}$，这实际上与（28.7）中的精确贝叶斯风险相符。令 $s \to \infty$，我们便得到（28.17）中的结果，即

$$R^*(\mathbb{R}^d) = \frac{d}{n}. \tag{30.4}$$

在上述无约束GLM中，应用互信息方法时，我们能够以闭式形式计算所有内容。此类精确表达式在更复杂的模型中很少可用，在这种情况下，互信息的各种界将证明是有用的。接下来，让我们考虑具有有界均值的GLM，其中参数空间$\Theta = B(\rho) = \{\theta: \|\theta\|_2 \leq \rho\}$是以零为中心、半径为$\rho$的$\ell_2$-球。在这种情况下，即使在一维中，也没有已知的极小极大二次风险的闭式公式。[1]然而，下一个结果确定了精确的极小极大速率，该速率将极小极大风险刻画到通用常数因子。

定理 30.1（有界 GLM）

$$R^*(B(\rho)) \asymp \frac{d}{n} \wedge \rho^2. \tag{30.5}$$

注30.1 将(30.5)与(30.4)对比，我们发现如果$\rho \gtrsim \sqrt{d/n}$，忽略有界范数约束是速率最优的；如果$\rho \lesssim \sqrt{d/n}$，我们可以丢弃所有观测值并以零进行估计，因为数据提供的分辨率并不优于先验信息。

Proof. 上界 $R^*(B(\rho)) \leq \frac{d}{n} \wedge \rho^2$ 由考虑估计量 $\hat{\theta} = \bar{X}$ 和 $\hat{\theta} = 0$ 得出。为了证明下界，我们采用互信息方法，使用均匀先验 $\theta \sim \mathrm{Unif}(B(r))$，其中 $r \in [0, \rho]$ 需要被优化。互信息可以使用 AWGN 容量按如下方式上界：

$$I(\theta; X) = I(\theta; \bar{X}) \leq \sup_{P_\theta: \mathbb{E}[\|\theta\|_2^2] \leq r} I(\theta; \theta + \frac{1}{\sqrt{n}}Z) = \frac{d}{2}\log\left(1 + \frac{nr^2}{d}\right) \leq \frac{nr^2}{2}, \tag{30.6}$$

其中 $Z \sim \mathcal{N}(0, I_d)$。或者，我们可以利用推论5.8，通过KL直径来界定容量（作为信息半径），由此得到的界在常数因子范围内是相同的：

$$I(\theta; X) \leq \sup_{P_\theta: \|\theta\| \leq r} I(\theta; \theta + \frac{1}{\sqrt{n}}Z) \leq \max_{\theta, \theta' \in B(r)} D(\mathcal{N}(\theta, I_d/n) \| \mathcal{N}(\theta, I_d/n)\|) = 2nr^2. \tag{30.7}$$

[1] It is known that there exists some ρ_0 depending on d/n such that for all $\rho \leq \rho_0$, the uniform prior over the sphere of radius ρ is *exactly* least favorable (see [82] for $d = 1$ and [48] for $d > 1$.)

对于下界，由于欧几里得球上均匀分布的率失真函数缺乏闭式公式，我们应用第26.1节中的*Shannon lower bound* (SLB)。由于θ具有各向同性分布，应用定理26.3可得

$$\inf_{P_{\hat\theta|\theta}:\mathbb{E}\|\theta-\hat\theta\|^2\le D} I(\theta;\hat\theta) \ge h(\theta) + \frac{d}{2}\log\frac{2\pi e d}{D} \ge \frac{d}{2}\log\frac{cr^2}{D},$$

对于某个通用常数 c，其中最后一个不等式成立是因为对于 $\theta\sim\mathrm{Unif}(B(r))$，有 $h(\theta)=\log \mathrm{vol}(B(r)) = d\log r + \log\mathrm{vol}(B(1))$，并且 d 维单位欧几里得球的体积满足（回顾 (27.14)）$\mathrm{vol}(B(1))^{1/d}\asymp\frac{1}{\sqrt{d}}$。

最后，应用（30.3）得到 $\frac{1}{2}\log\frac{cr^2}{R^*}\le\frac{nr^2}{2}$，即 $R^*\ge cr^2e^{-nr^2/d}$。对 r 进行优化，并利用 $\sup_{0<x<1} xe^{-ax}=\frac{1}{ea}$ 若 $a\ge 1$ 以及 e^{-a} 若 $a<1$ 的事实，我们有

$$R^* \ge \sup_{r\in[0,\rho]} cr^2e^{-nr^2/d} \asymp \frac{d}{n}\wedge\rho^2. \quad \square$$

作为最后一个例子，让我们考虑一个非二次损失$\ell(\theta,\hat\theta)=\|\theta-\hat\theta\|^r$，即$\mathbb{R}^d$上任意范数的$r$次幂。回想一下，我们在推论28.8中已经利用安德森引理确定了精确的极小极大风险，即，

$$\inf_{\hat\theta}\sup_{\theta\in\mathbb{R}^d}\mathbb{E}_\theta[\|\hat\theta-\theta\|^r] = n^{-r/2}\mathbb{E}[\|Z\|^r],\quad Z\sim\mathcal{N}(0,I_d). \tag{30.8}$$

为了应用互信息方法，再次考虑高斯先验$\theta\sim\mathcal{N}(0,sI_d)$。假设$\mathbb{E}[\|\hat\theta-\theta\|^r]\le D$。根据数据处理不等式，

$$\frac{d}{2}\log(1+ns)\ge I(\theta;X)\ge I(\theta;\hat\theta)\ge\frac{d}{2}\log(2\pi es)-\log\left\{V_{\|\cdot\|}\left(\frac{Dre}{d}\right)^{\frac{d}{r}}\Gamma\left(1+\frac{d}{r}\right)\right\},$$

其中最后一个不等式由一般SLB（26.5）得出。整理项并令$s\to\infty$趋于，得到

$$\inf_{\hat\theta}\sup_{\theta\in\mathbb{R}^d}\mathbb{E}_\theta[\|\hat\theta-\theta\|^r]\ge\frac{d}{re}\left(\frac{2\pi e}{n}\right)^{r/2}\left[V_{\|\cdot\|}\Gamma\left(1+\frac{d}{r}\right)\right]^{-r/d}\asymp n^{-r/2}V_{\|\cdot\|}^{-r/d}\gtrsim\left(\frac{d}{\sqrt{n}\mathbb{E}[\|Z\|_*]}\right)^r, \tag{30.9}$$

其中中间的不等式应用了斯特林近似$\Gamma(x)^{1/x}\asymp x$于$x\to\infty$，而右边应用了乌雷松的体积不等式(27.21)，其中$\|x\|_*=\sup\{\langle x,y\rangle:\|y\|\le 1\}$ 表示$\|\cdot\|$的对偶范数。

为了评估SLB下界与精确结果(30.8)相比的紧致性，考虑$r=2$和ℓ_q范数 $\|x\|_q=\left(\sum_{i=1}^d|x_i|^q\right)^{1/q}$且$1\le q\le\infty$的例子。回顾(27.13)中给出的单位$\ell_q$球的体积。在$q=2$的特殊情况下，(30.9)中的(第一个)下界实际上是精确的，并且与(30.4)一致。对于一般的$q\in[1,\infty)$，(30.9)给出了紧致的极小极大速率$\frac{d^{2/q}}{n}$；然而，对于$q=\infty$，我们得到的极小极大下界是$1/n$，与维度d无关。相比之下，由(30.8)我们得到了精确的速率$\frac{\log d}{n}$，因为$\mathbb{E}\|Z\|_\infty\asymp\sqrt{\log d}$ (参见引理27.10)。我们将在第31.4节重新讨论这个例子，并展示如何获得对维度的最优依赖性。

注 30.2（SLB 与体积法） 回顾第 27.6 节中率失真函数与度量熵之间的联系。正如我们在第 27.2 节中所见，度量熵的一个常用下界是通过体积界得到的。事实上，SLB 可以被解释为率失真函数的一个基于体积的下界。为了看清这一点，考虑 $r = 1$ 并设 θ 均匀分布于某个紧集 Θ 上，从而 $h(\theta) = \log \mathrm{vol}(\Theta)$（定理 2.7(a)）。应用 Stirling 近似，(26.5) 中的下界变为 $\log \frac{\mathrm{vol}(\Theta)}{\mathrm{vol}(B_\|\cdot\|(c\epsilon))}$，其中 c 为某个常数，其形式与定理 27.3 中度量熵的体积比相同。我们将在后面的第 31.4 节中看到，在统计应用中，应用 SLB 得到的下界与对由体积界得到的填充应用 Fano 方法所得到的下界基本相同，尽管 SLB 并不显式依赖于填充。

30.2 具有稀疏均值的GLM

在本节中，我们考虑稀疏向量去噪的问题。具体而言，再次考虑高斯位置模型$\mathcal{N}(\theta, I_d)$，其中均值向量θ已知为k-稀疏，取值于“ℓ_0-球”

$$B_0(k) = \{\theta \in \mathbb{R}^d : \|\theta\|_0 \le k\}, \quad k \in [p],$$

其中 $\|\theta\|_0 = |\{i \in [d] : \theta_i \neq 0\}|$ 是 θ 的非零元素个数，表示 θ 的稀疏性。我们的目标是刻画极小极大二次风险

$$R_n^*(B_0(k)) = \inf_{\hat{\theta}} \sup_{\theta \in B_0(k)} \mathbb{E}_\theta \|\hat{\theta} - \theta\|_2^2.$$

接下来，我们利用MIM证明一个最优下界。（关于在第31.4节使用Fano方法的不同证明，参见练习VI.12。）

定理 30.2

$$R_n^*(B_0(k)) \gtrsim \frac{k}{n} \log \frac{ed}{k}. \tag{30.10}$$

有几点需要说明：

注30.3 • 下界（30.10）是紧致的，可由最大似然估计达到

$$\hat{\theta}_{\mathrm{MLE}} = \arg \min_{\|\theta\|_0 \le k} \|\bar{X} - \theta\|_2, \tag{30.11}$$

这等价于保留$\bar{X}$中绝对值最大的k个条目，并将其余的设为零，或者使用以下硬阈值估计量$\hat{\theta}^\tau$，其中τ (选择得当，参见练习VI.13)：

$$\hat{\theta}_i^\tau = X_i 1\{|X_i| \ge \tau\}. \tag{30.12}$$

- 尖锐渐近性：对于次线性稀疏度 $k = o(d)$，我们有 $R_n^*(B_0(k)) = (2 + o(1))\frac{k}{n}\log\frac{d}{k}$（练习 VI.13）；对于线性稀疏度 $k = (\eta + o(1))d$ 且 $\eta \in (0, 1)$，$R_n^*(B_0(k)) = (\beta(\eta) + o(1))d$ 对于某个常数 $\beta(\eta)$。关于后者及更精细的结果，我们请读者参阅专著 [236, 第 8 章]。

Proof. 首先，注意到$B_0(k)$是$\mathbb{R}^d$的线性子空间的并集，因此是齐次的。于是通过缩放，我们有

$$R_n^*(B_0(k)) = \frac{1}{n}R_1^*(B_0(k)) \triangleq \frac{1}{n}R^*(k, d). \tag{30.13}$$

因此, t足以考虑$n = 1$。用$X =$表示观测值 $\theta + Z$。

接下来，注意以下预言机下界：

$$R^*(k, d) \geq k,$$

给定关于 θ 支撑集的额外信息，根据（30.4），这是最优风险。因此，为了证明（30.10），下面只需考虑 $k \leq d/4$。

我们现在应用互信息方法。回忆(27.10)中，S_k^d表示汉明球，即，

$$S_k^d = \{b \in \{0, 1\}^d : w_{\mathrm{H}}(b) = k\},$$

其中 $w_{\mathrm{H}}(b)$ 表示 b 的汉明权重。令 b 均匀分布于 S_k^d 上，并令 $\theta = \tau b$，其中 $\tau = \sqrt{\log\frac{d}{k}}$。给定任意估计量 $\hat{\theta} = \hat{\theta}(X)$，定义 b 的估计量 $\hat{b} \in \{0, 1\}^d$ 为

$$\hat{b}_i = \begin{cases} 0 & \hat{\theta}_i \leq \tau/2 \\ 1 & \hat{\theta}_i > \tau/2 \end{cases}, \quad i \in [d].$$

Th使用 $\hat{b}$ 的汉明损失可以与平方损失相关联 将 $\hat{\theta}$ 表示为

$$\|\theta - \hat{\theta}\|_2^2 \geq \frac{\tau^2}{4}d_{\mathrm{H}}(b, \hat{b}). \tag{30.14}$$

令 $\mathbb{E}d_{\mathrm{H}}(b, \hat{b}) = \delta k$。假设 $\delta \leq \frac{1}{4}$，否则我们已完成。

注意以下马尔可夫链$b \to \theta \to X \to \hat{\theta} \to \hat{b}$，因此，根据互信息的数据处理不等式，

$$I(b; \hat{b}) \leq I(\theta; X) \leq \frac{d}{2}\log\left(1 + \frac{k\tau^2}{d}\right) \leq \frac{k\tau^2}{2} = \frac{k}{2}\log\frac{d}{k}.$$

其中第二个不等式由$\|\theta\|_2^2 = k\tau^2$和高斯信道容量得出。

相反，

$$\begin{aligned} I(\hat{b}; b) &\geq \min_{\mathbb{E}d_{\mathrm{H}}(b,\hat{b}) \leq \delta d} I(\hat{b}; b) \\ &= H(b) - \max_{\mathbb{E}d_{\mathrm{H}}(b,\hat{b}) \leq \delta k} H(b|\hat{b}) \end{aligned}$$

$$\geq \log \binom{d}{k} - \max_{\mathbb{E} w_{\mathrm{H}}(b \oplus \hat{b}) \leq \delta k} H(b \oplus \hat{b}) = \log \binom{d}{k} - dh\left(\frac{\delta k}{d}\right), \tag{30.15}$$

其中最后一步由练习 I.7 得出。

结合互信息的下界和上界，并利用 $\binom{d}{k} \geq (\frac{d}{k})^k$，我们得到 $dh(\frac{\delta k}{d}) \geq \frac{k}{2} k \log \frac{d}{k}$。由于对于 $p \in [0,1]$ 有 $h(p) \leq -p \log p + p$，且根据假设有 $k/d \leq \frac{1}{4}$，我们得出对于某个绝对常数 c 有 $\delta \geq ck/d$，鉴于 (30.14)，这完成了 (30.10) 的证明。

□

30.3 社区检测

作为互信息方法的另一个应用，让我们考虑以下统计问题：在随机图中检测单个隐藏社区，也称为*planted dense subgraph model*。（读者应将其与练习I.49中引入的具有两个社区的随机块模型进行比较。）令C^*从$[n]$的所有基数为k $\geq$的子集中均匀随机抽取。令G表示顶点集$[n]$上的随机图，使得对于每个$i \neq j$，如果i和j都属于C^*，则它们以概率p独立连接，否则以概率q连接。假设$p > q$，集合C^*表示一个密集连接的社区，它形成了一个Erdös-Rényi图ER(k,p)，植入在更大的ER(n,q)图中。在观察到G后，目标是尽可能准确地重建C^*。特别地，给定一个估计器$\hat{C} = \hat{C}(G)$，如果$\mathbb{E}|C \triangle \hat{C}| = o(k)$，我们说它达到了*almost exact recovery*。以下结果给出了关于参数(p,q,n,k)的必要条件：

定理 30.3 *Assume that k/n is bounded away from one. If almost exact recovery is possible, then*

$$d(p\|q) \geq \frac{2+o(1)}{k-1} \log \frac{n}{k}. \tag{30.16}$$

备注 30.4 除定理30.3之外，另一个必要条件 就是

$$d(p\|q) = \omega\left(\frac{1}{k}\right), \tag{30.17}$$

这可以通过归约为在给定其余节点的情况下测试两个节点的成员资格来证明。事实证明，条件(30.16)和(30.17)是最优的，即只要(30.17)成立且对于任意常数$\epsilon > 0$有$d(p\|q) \geq \frac{2+\epsilon}{k-1} \log \frac{n}{k}$，就可以(通过最大似然)实现几乎精确恢复。详情请参阅[208]。

Proof. 假设 $\hat{C}$ 几乎精确恢复了 C^*。令 $\xi^*, \hat{\xi} \in \{0,1\}^n$ 分别表示它们的指示向量，例如，对于每个 $i \in [n]$，$\xi_i^* = 1\{i \in C^*\}$。那么对于某个 $\epsilon_n \to 0$，有 $\mathbb{E}[d_{\mathrm{H}}(\xi, \hat{\xi})] = \epsilon_n k$。像之前一样应用互信息方法，我们得到

$$I(G;\xi^*) \geq I(\hat{\xi};\xi^*) \overset{\text{(a)}}{\geq} \log \binom{n}{k} - nh\left(\frac{\epsilon_n k}{n}\right) \overset{\text{(b)}}{\geq} k \log \frac{n}{k}(1+o(1)),$$

其中 (a) 的推导方式与练习 I.7 中的 (30.15) 相同；(b) 则源于对某个常数 c 存在 $k/n \le 1 - c$ 的假设。

另一方面，隐藏社区与图之间的互信息可以被上界为：

$$I(G;\xi^*) \overset{\text{(a)}}{=} \min_Q D(P_{G|\xi^*}\|Q|P_{\xi^*}) \overset{\text{(b)}}{\le} D(P_{G|\xi^*}\|\mathrm{Ber}(q)^{\otimes\binom{n}{2}}|P_{\xi^*}) \overset{\text{(c)}}{=} \binom{k}{2} d(p\|q),$$

其中 (a) 依据推论4.2中互信息的变分表示；(b) 通过选择 Q 为 Erdös-Rényi 图 ER(n,q) 的分布得出；(c) 利用了乘积分布的KL散度的张量化性质（定理2.16(d)）。结合最后两式即可完成证明。

□

30.4 优于随机猜测的估计

与其刻画随着数据量增长最小最大风险收敛到零的速率，假设我们处于由于样本量有限、信噪比差或高维性而无法实现这一点的情形；相反，我们关注的是一个较为温和的目标，即实现严格优于平凡误差（无数据）的估计误差。在聚类的背景下，这被称为弱恢复或相关恢复，其目标不是实现消失的误分类率，而是严格优于随机猜测标签。事实证明，MIM特别适合这种情形。（事实上，我们将在下一章中看到，MIM的三种流行的进一步松弛都因常数因子的损失而表现不佳。）

例如，让我们继续定理30.1的设定，目标是根据带有噪声的观测数据估计高维单位球内的一个向量。由于参数空间的半径为1，平凡平方误差等于1。以下定理表明，在高维情况下，非平凡估计可实现当且仅当样本量n与维度d成比例增长；否则，当$d \gg n \gg 1$时，最优估计误差为$1 - \frac{n}{d}(1+o(1))$。

定理 30.4（有界 GLM 续）*Suppose* $X_1,\dots,X_n \overset{i.i.d.}{\sim} \mathcal{N}(\theta, I_d)$, *where* θ *belongs to B, the unit* ℓ_2*-ball in* $\mathbb{R}^d$. *Then for some universal constant* C_0,

$$e^{-\frac{n+C_0}{d-1}} \le \inf_{\hat\theta}\sup_{\theta\in B} \mathbb{E}_\theta[\|\hat\theta-\theta\|^2] \le \frac{d}{d+n}.$$

Proof. 不失一般性，假设观察值为$X = \theta + \frac{Z}{\sqrt{n}}$，其中$Z \sim \mathcal{N}(0, I_d)$。对于上界，应用收缩估计量[2] $\hat\theta = \frac{1}{1+d/n}X$得到$\mathbb{E}[\|\hat\theta-\theta\|^2] \le \frac{d}{n+d}$。

对于下界，我们应用定理30.1证明中的MIM方法，采用先验$\theta \sim \mathrm{Unif}(S^{d-1})$。我们仍然应用(30.6)中的AWGN容量来得到$I(\theta;\ X) \le n/2$。（这里

[2] This corresponds to the Bayes estimator (Example 28.1) when we choose $\theta \sim \mathcal{N}(0, \frac{1}{d}I_d)$, which is approximately concentrated on the unit sphere for large d.

常数 1/2 很重要，因此基于直径的界（30.7）过于宽松。对于球面均匀分布的率失真函数，应用定理 27.17 可得 $I(\theta;\hat{\theta}) \geq \frac{d-1}{2}\log\frac{1}{\mathbb{E}[\|\hat{\theta}-\theta\|^2]} - C$。因此，$\mathbb{E}[\|\hat{\theta}-\theta\|^2]$ 的下界可由数据处理不等式推出。

□

类似的现象也出现在根据 n 个独立同分布观测估计 k 个元素上的离散分布 P 的问题中，该问题已在第29.4节中针对小字母表在大样本渐近情形下进行了研究，并在练习VI.7–VI.10中推广到大字母表。特别地，考虑总变差损失，其至多为1。练习VI.10f表明，若 $n \ll k$，则任意估计器的TV误差为 $1 - o(1)$；相反，练习VI.10b展示了一个估计器 $\hat{P}$，使得 $\mathbb{E}[\chi^2(P\|\hat{P})] \leq \frac{k-1}{n+1}$。应用TV与 χ^2 之间的联合范围(7.32)以及Jensen不等式，我们有

$$\mathbb{E}[\mathrm{TV}(P,\hat{P})] \leq \begin{cases} \frac{1}{2}\sqrt{\frac{k-1}{n+1}} & n \geq k-2 \\ \frac{k-1}{k+n} & n \leq k-2 \end{cases}$$

只要 $n = \Omega(k)$，它就远离 1。总之，全变差意义下的非平凡估计可能当且仅当 n 至少与 k 成比例缩放。

最后，我们提及随机块模型中的*correlated recovery*问题（参见习题I.49），该问题涉及以优于随机的方式估计社区标签。此问题的最优信息论阈值可通过界定相应的互信息来确定；关于高斯版本（尖峰Wigner模型），请参见第33.9节。

31 Lower bounds via reduction to hypothesis testing

在本章中，我们研究三种常用于证明极小极大下界的技巧，即*Le Cam's method*、*Assouad's lemma*和*Fano's method*。与第29章针对光滑参数模型的大样本渐近结果相比，这里的方法更为通用，较少依赖于均方误差，并且适用于非渐近情形，如非参数或高维问题。

三种方法的共同基本原理是将统计估计归结为假设检验。具体而言，为了给出参数空间 Θ 的极小极大风险 $R^*(\Theta)$ 的下界，第一步是注意到对于任意子集 $\Theta' \subset \Theta$ 有 $R^*(\Theta) \geq R^*(\Theta')$，而 Le Cam、Assouad 和 Fano 方法分别相当于选择 Θ' 为两点集、超立方体或填充。特别地，Le Cam 方法将估计问题归结为二元假设检验。该方法也许是最容易评估的；然而，其缺点是在估计高维参数时通常较为宽松。为了正确捕捉对维度的依赖关系，Assouad 和 Fano 方法都依赖于归结为多重假设检验。

如图30.1所示，这三种方法实际上都遵循第30章中互信息方法（MIM）的共同原理，对应于不同的先验选择。与MIM相比，这些方法的局限性在于，由于常数因子的宽松性，它们对某些问题（如第30.4节中讨论的优于随机的估计）无效。

31.1 勒卡姆的两点法

定理 31.1 *Suppose the loss function* ℓ : $\Theta \times \Theta \to \mathbb{R}_+$ *satisfies* $\ell(\theta,\theta) = 0$ *for all* $\theta \in \Theta$ *and the following* α*-triangle inequality for some* $\alpha > 0$*: For all* $\theta_0, \theta_1, \theta \in \Theta$*,*

$$\ell(\theta_0,\theta_1) \leq \alpha(\ell(\theta_0,\theta) + \ell(\theta_1,\theta)). \tag{31.1}$$

Then

$$\inf_{\hat{\theta}} \sup_{\theta\in\Theta} \mathbb{E}_\theta \ell(\theta,\hat{\theta}) \geq \sup_{\theta_0,\theta_1\in\Theta} \frac{\ell(\theta_0,\theta_1)}{2\alpha}(1 - \mathrm{TV}(P_{\theta_0}, P_{\theta_1})) \tag{31.2}$$

Proof. 修复 $\theta_0, \theta_1 \in \Theta$。给定任意估计量 $\hat{\theta}$，我们将其转换为以下（随机化）检验：

$$\tilde{\theta} = \begin{cases} \theta_0 & \text{with probability } \frac{\ell(\theta_1,\hat{\theta})}{\ell(\theta_0,\hat{\theta})+\ell(\theta_1,\hat{\theta})}, \\ \theta_1 & \text{with probability } \frac{\ell(\theta_0,\hat{\theta})}{\ell(\theta_0,\hat{\theta})+\ell(\theta_1,\hat{\theta})}. \end{cases}$$

由 α-三角不等式，我们有

$$\mathbb{E}_{\theta_0}[\ell(\tilde{\theta},\theta_0)] = \ell(\theta_0,\theta_1)\mathbb{E}_{\theta_0}\left[\frac{\ell(\theta_0,\hat{\theta})}{\ell(\theta_0,\hat{\theta})+\ell(\theta_1,\hat{\theta})}\right] \geq \frac{1}{\alpha}\mathbb{E}_{\theta_0}[\ell(\hat{\theta},\theta_0)],$$

对于 θ_1 也同样。考虑先验 $\pi = \frac{1}{2}(\delta_{\theta_0} + \delta_{\theta_1})$ 并令 $\theta \sim \pi$。对两边取期望，得到贝叶斯风险的以下下界：

$$\mathbb{E}_\pi[\ell(\hat{\theta},\theta)] \geq \frac{\ell(\theta_0,\theta_1)}{\alpha}\mathbb{P}\left[\tilde{\theta} \neq \theta\right] \geq \frac{\ell(\theta_0,\theta_1)}{2\alpha}(1 - \mathrm{TV}(P_{\theta_0}, P_{\theta_1}))$$

其中最后一步来自二元假设检验中的最小平均错误概率（定理7.7）。

□

注记31.1 作为界(31.2)紧致（至多相差常数）的一个例子，考虑一个二元假设检验问题，其中 $\Theta = \{\theta_0, \theta_1\}$ 和汉明损失 $\ell(\theta,\hat{\theta}) = 1\{\theta \neq \hat{\theta}\}$，这里 $\theta, \hat{\theta} \in \{\theta_0, \theta_1\}$ 和 $\alpha = 1$。那么左侧是最小最大错误概率，右侧是最优平均错误概率（参见(7.19)）。这两个量可以一致（例如对于高斯位置模型）。

另一个值得关注的特别情形是二次损失 $\ell(\theta,\hat{\theta}) = \|\theta - \hat{\theta}\|_2^2$，其中 $\theta, \hat{\theta} \in \mathbb{R}^d$，它满足 α-三角不等式，且 $\alpha =$ 为 2。在这种情况下，(31.2) 中的主导常数 $\frac{1}{4}$ 是有意义的，因为在 TV $=$ 为 0 的极端情形下，即 P_{θ_0} 与 P_{θ_1} 无法区分时，最佳估计就是 $\frac{\theta_0+\theta_1}{2}$。此外，不等式 (31.2) 可以基于 f-散度及其联合范围的性质（第 7 章）推导出来。为此，将 P_{θ_i} 简记为 P_i，其中 $i =$ 为 0，，为 1，并考虑先验 $\pi = \frac{1}{2}(\delta_{\theta_0} + \delta_{\theta_1})$。于是贝叶斯估计量（后验均值）为 $\frac{\theta_0 dP_0 + \theta_1 dP_1}{dP_0 + dP_1}$，贝叶斯风险为

$$\begin{aligned} R_\pi^* &= \frac{\|\theta_0 - \theta_1\|^2}{2}\int \frac{dP_0 dP_1}{dP_0 + dP_1} \\ &= \frac{\|\theta_0 - \theta_1\|^2}{4}(1 - \mathrm{LC}(P_0, P_1)) \geq \frac{\|\theta_0 - \theta_1\|^2}{4}(1 - \mathrm{TV}(P_0, P_1)), \end{aligned}$$

其中 $\mathrm{LC}(P_0, P_1) = \int \frac{(dP_0 - dP_1)^2}{dP_0 + dP_1}$ 是 (7.7) 中定义的 Le Cam 散度，且满足 $\mathrm{LC} \leq \mathrm{TV}$。

例31.1 作为一个具体示例，考虑样本量为n的一维广义线性模型。通过考虑充分统计量$\bar{X} = \frac{1}{n}\sum_{i=1}^n X_i$，模型简化为$\{\mathcal{N}(\theta, \frac{1}{n})\colon\ \theta \in \mathbb{R}\}$。应用定理31.1得到

$$\begin{aligned} R^* &\geq \sup_{\theta_0,\theta_1 \in \mathbb{R}} \frac{1}{4}|\theta_0 - \theta_1|^2 \left\{1 - \mathrm{TV}\left(N\left(\theta_0, \frac{1}{n}\right), N\left(\theta_1, \frac{1}{n}\right)\right)\right\} \\ &\overset{\text{(a)}}{=} \frac{1}{4n}\sup_{s>0} s^2(1 - \mathrm{TV}(\mathcal{N}(0,1), \mathcal{N}(s,1))) \overset{\text{(b)}}{=} \frac{c}{n} \end{aligned} \tag{31.3}$$

其中 (a) 由全变差在移位与尺度变换下的不变性得出；在 (b) 中，$c \approx 0.083$ 是某个绝对常数，通过应用来自 (7.40) 的公式 $\mathrm{TV}(\mathcal{N}(0,1),\mathcal{N}(s,1)) = 2\Phi(\frac{s}{2}) - 1$ 得到。另一方面，由例 28.2 可知极小极大风险等于 $\frac{1}{n}$，因此两点法在此情形下是速率最优的。

在上述例子中，对于由 $\Theta(\frac{1}{\sqrt{n}})$ 分隔的两个点，相应的假设无法以趋于零的错误概率进行检验，因此所得到的估计风险（比如在平方误差中）不能小于 $\frac{1}{n}$。这种收敛速度通常被称为“参数速率”，我们在第29章中针对光滑参数族进行了研究，重点关注Fisher信息作为精确常数。更一般地，对于具有局部二次行为的模型，$\frac{1}{n}$ 速率是不可改进的。

$$H^2(P_{\theta_0}, P_{\theta_0+t}) \asymp t^2, \quad t \to 0. \tag{31.4}$$

(回想定理 7.23 给出了这种行为的一个充分条件。) 实际上，在参数空间的内部选取 θ_0 并设置 $\theta_1 = \theta_0 + \frac{1}{\sqrt{n}}$，从而借助（31.4）得到 $H^2(P_{\theta_0}, P_{\theta_1}) = \Theta(\frac{1}{n})$。根据定理 7.8，我们有 $\mathrm{TV}(P_{\theta_0}^{\otimes n}, P_{\theta_1}^{\otimes n}) \le 1 - c$ 对于某个常数 c，因此定理 31.1 给出了平方误差的下界 $\Omega(1/n)$。此外，稍后我们将证明，同样的局部二次行为实际上保证了 $1/n$ 速率的可达性；参见推论 32.12。

例31.2 另一个不同的例子，考虑一族均匀分布Unif(0,,θ)。请注意，与二次行为（31.4）相反，我们有

$$H^2(\mathrm{Unif}(0,1), \mathrm{Unif}(0,1+t)) = 2(1 - 1/\sqrt{1+t}) \asymp t.$$

因此，应用定理31.1可以得到一个$\Omega(1/n^2)$下界。这一速率不是由经验均值估计量（仅达到$1/n$速率）实现的，而是由最大似然估计量$\hat{\theta} = \max\{X_1, \ldots, X_n\}$实现的。在$t$中可能出现其他类型的行为，因此即使在紧支撑的位置族中，收敛速率也可能不同——参见例7.1。

Le Cam两点方法的局限性在于它无法捕捉到对维数的正确依赖关系。为了说明这一点，让我们重新审视例31.1中{v*}维的情况。

例31.3 考虑推论28.8中的d维GLM。同样，考虑简化模型$\{\mathcal{N}(\theta, \frac{1}{n}) : \theta \in \mathbb{R}^d\}$是等价的。我们从例28.2（另见定理28.4）得知，对于二次风险$\ell(\theta, \hat{\theta}) = \|\theta - \hat{\theta}\|_2^2$，对于任意$d$和$n$，精确的极小极大风险为$R^* = \frac{d}{n}$。让我们将此与最佳两点下界进行比较。应用定理31.1，其中α =2,

$$\begin{aligned} R^* &\ge \sup_{\theta_0,\theta_1 \in \mathbb{R}^d} \frac{1}{4}\|\theta_0 - \theta_1\|_2^2 \left\{1 - \mathrm{TV}\left(N\left(\theta_0, \frac{1}{n} I_d\right), N\left(\theta_1, \frac{1}{n} I_d\right)\right)\right\} \\ &= \sup_{\theta \in \mathbb{R}^d} \frac{1}{4n}\|\theta\|_2^2 \left\{1 - \mathrm{TV}\left(N(0, I_d), N(\theta, I_d)\right)\right\} \\ &= \frac{1}{4n} \sup_{s>0} s^2 (1 - \mathrm{TV}(\mathcal{N}(0,1), \mathcal{N}(s,1))), \end{aligned}$$

其中第二步应用了全变差的平移和尺度不变性；在最后一步中，通过各向同性高斯分布的旋转不变性，我们可以旋转向量 θ 使其与坐标向量（例如，$e_1 = (1, 0 \ldots, 0)$）对齐，这将问题化简为一维，即，

$$\begin{aligned}\mathrm{TV}(\mathcal{N}(0, I_d), \mathcal{N}(\theta, I_d)) &= \mathrm{TV}(\mathcal{N}(0, I_d), \mathcal{N}(\|\theta\| e_1, I_d) \\ &= \mathrm{TV}(\mathcal{N}(0, 1), \mathcal{N}(\|\theta\|, 1)).\end{aligned}$$

将上述展示与(31.3)比较，我们发现在d维中最佳的Le Cam两点下界与一维中的情况相吻合。

顺便提一下，尽管Le Cam的两点方法在估计高维参数θ时通常并非最优，但对于高维函数估计（例如估计标量函数$T(\theta)$），Le Cam方法更为有效，有时甚至是最优的。微妙之处在于，与检验一对简单假设H_0：$\theta = \theta_0$对比H_1：$\theta = \theta_1$不同，我们需要检验H_0：$T(\theta) = t_0$对比H_1：$T(\theta) = t_1$，两者都是复合假设，并且需要明智地选择先验。参见练习VI.14中的示例。

31.2 阿苏阿德引理

从例31.3中我们可以看出，Le Cam的两点法实际上仅扰动了d坐标中的一个，而其余$d-1$个坐标则未被探讨；这是其非最优性的根源。为了得到一个随维度缩放的下界，必须对所有d坐标进行随机化处理。我们接下来的主题——Assouad引理，正是朝着这个方向的一个扩展。

定理31.2（阿苏阿德引理）*Assume that the loss function ℓ satisfies the α-triangle inequality (31.1). Suppose Θ contains a subset $\Theta' = \{\theta_b : b \in \{0,1\}^d\}$ indexed by the hypercube, such that $\ell(\theta_b, \theta_{b'}) \geq \beta \cdot d_{\mathrm{H}}(b, b')$ for all b, b' and some $\beta > 0$. Then*

$$\inf_{\hat{\theta}} \sup_{\theta \in \Theta} \mathbb{E}_\theta \ell(\theta, \hat{\theta}) \geq \frac{\beta d}{4\alpha} \left(1 - \max_{d_{\mathrm{H}}(b,b')=1} \mathrm{TV}(P_{\theta_b}, P_{\theta_{b'}})\right) \tag{31.5}$$

Proof. 我们用 Θ' 上的均匀先验来下界贝叶斯风险。给定任意估计量 $\hat{\theta} = \hat{\theta}(X)$，定义 $\hat{b} \in \operatorname{argmin} \ell(\hat{\theta}, \theta_b)$。则对任意 $b \in \{0,1\}^d$，

$$\beta d_{\mathrm{H}}(\hat{b}, b) \leq \ell(\theta_{\hat{b}}, \theta_b) \leq \alpha(\ell(\theta_{\hat{b}}, \hat{\theta}_b) + \ell(\hat{\theta}, \theta_b)) \leq 2\alpha \ell(\hat{\theta}, \theta_b).$$

令 $b \sim$ 服从均匀分布 $\mathrm{Unif}(\{0,1\}^d)$，我们有 $b \to \theta_b \to X$。那么

$$\begin{aligned}\mathbb{E}[\ell(\hat{\theta}, \theta_b)] &\geq \frac{\beta}{2\alpha} \mathbb{E}[d_{\mathrm{H}}(\hat{b}, b)] \\ &= \frac{\beta}{2\alpha} \sum_{i=1}^{d} \mathbb{P}\left[\hat{b}_i \neq b_i\right] \\ &\geq \frac{\beta}{4\alpha} \sum_{i=1}^{d} (1 - \mathrm{TV}(P_{X|b_i=0}, P_{X|b_i=1})),\end{aligned}$$

其中最后一步同样由定理7.7得出，正如定理31.1的证明中那样。每个总变差可按以下方式上界估计：

$$\mathrm{TV}(P_{X|b_i=0}, P_{X|b_i=1}) \overset{\text{(a)}}{=} \mathrm{TV}\left(\frac{1}{2^{d-1}}\sum_{b:b_i=1} P_{\theta_b}, \frac{1}{2^{d-1}}\sum_{b:b_i=0} P_{\theta_b}\right) \overset{\text{(b)}}{\le} \max_{d_{\mathrm{H}}(b,b')=1} \mathrm{TV}(P_{\theta_b}, P_{\theta_{b'}})$$

其中 (a) 由贝叶斯规则得出，(b) 由全变差的凸性（定理 7.5）得出。这就完成了证明。

□

例31.4 让我们继续讨论例31.3中的d维GLM。首先考虑二次损失。为了应用定理31.2，考虑超立方体$\theta_b = \epsilon b$，其中$b \in \{0,1\}^d$。于是$\|\theta_b - \theta'_b\|_2^2 = \epsilon^2 d_{\mathrm{H}}(b,b')$。应用定理31.2可得

$$\begin{aligned} R^* &\ge \frac{\epsilon^2 d}{4}\left\{1 - \max_{b,b'\in\{0,1\}^d, d_{\mathrm{H}}(b,b')=1} \mathrm{TV}\left(N\left(\epsilon b, \frac{1}{n}I_d\right), N\left(\epsilon b', \frac{1}{n}I_d\right)\right)\right\} \\ &= \frac{\epsilon^2 d}{4}\left\{1 - \mathrm{TV}\left(N\left(0, \frac{1}{n}\right), N\left(\epsilon, \frac{1}{n}\right)\right)\right\}, \end{aligned}$$

其中最后一步应用了（7.11）来求解仅在某一坐标上不同的乘积分布之间的f散度。设定$\epsilon = \frac{1}{\sqrt{n}}$，并利用TV的尺度不变性，我们得到了所需的$R^* \gtrsim \frac{d}{n}$。

接下来，让我们考虑损失函数 $\|\theta_b - \theta'_b\|_\infty$。在相同的设置下，我们仅 $\|\theta_b - \theta'_b\|_\infty \ge \frac{\epsilon}{d} d_{\mathrm{H}}(b,b')$。然后Assouad引理得出 $R^* \gtrsim \frac{1}{\sqrt{n}}$，这不依赖于 d。事实上，如推论28.8所示，$R^* \asymp \sqrt{\frac{\log d}{n}}$。在下一节中，我们将讨论能解决这一缺陷的Fano方法。

31.3 从互信息方法导出阿苏阿德引理

可以将 Assouad 的想法整合到互信息方法中。考虑定理 31.2 的贝叶斯设定，其中 $b^d = (b_1, \ldots, b_d) \overset{\text{i.i.d.}}{\sim} \mathrm{Ber}(\frac{1}{2})$。由伯努利源的率失真函数（第 26.1.1 节），我们知道对于任意 $\hat{b}^d$ 和 $\tau > 0$，存在某个 $\tau' > 0$，使得

$$I(b^d; X) \le d(1-\tau)\log 2 \quad \Longrightarrow \quad \mathbb{E}[d_{\mathrm{H}}(\hat{b}^d, b^d)] \ge d\tau' . \tag{31.6}$$

这里，τ' 通过 $\tau \log 2 = h(\tau')$ 与 τ 相关。因此，使用相同的“超立方体嵌入 $b \to \theta_b$”，一旦我们能够将 $I(b^d; X)$ 限制在远离 $d \log 2$ 的范围，类似于（31.5）的界限就会随之而来。我们能使用(31.5)中的成对全变分界限来实现这一点吗？可以！注意，由于b_i的独立性，我们得到[1]

$$I(b_i; X|b^{i-1}) = I(b_i; X, b^{i-1}) \le I(b_i; X, b_{\setminus i}) = I(b_i; X|b_{\setminus i}) .$$

1 等价地，这也可以从信道中互信息的凸性得出（参见定理 5.3）。

应用链式法则可得到上界

$$I(b^d;X)=\sum_{i=1}^{d} I(b_i;X|b^{i-1}) \le \sum_{i=1}^{d} I(b_i;X|b_{\setminus i}) \le d\log 2 \max_{d_H(b,b')=1} \mathrm{TV}(P_{X|b^d=b}, P_{X|b^d=b'}), \quad (31.7)$$

w最后一步中，我们用到了这样一个事实：只要 $B\sim$ 属于$(1/2)$,

$$I(B;X) \le \mathrm{TV}(P_{X|B=0}, P_{X|B=1})\log 2, \quad (31.8)$$

由(7.39)得出，注意到互信息表达为Jensen-Shannon散度即$2I(B;\ X)=\mathrm{JS}(P_{X|B=0}, P_{X|B=1})$。结合(31.6)和(31.7)，互信息方法意味着以下版本的Assouad引理：在定理31.2的假设下,

$$\inf_{\hat\theta}\sup_{\theta\in\Theta} \mathbb{E}_\theta \ell(\theta,\hat\theta) \ge \frac{\beta d}{4\alpha}\cdot f\left(\max_{d_{\mathrm{H}}(\theta,\theta')=1} \mathrm{TV}(P_\theta, P_{\theta'})\right), \quad f(t)\triangleq h^{-1}\left(\frac{(1-t)\log 2}{2}\right) \quad (31.9)$$

其中 $h^{-1}:[0,\log 2]\to[0,1/2]$ 是二元熵函数的反函数。注意，(31.9) 比 (31.5) 略弱。然而，如例 31.4 所示，Assouad 引理通常应用于成对全变差被常数限制远离一的情况，此时 (31.9) 和 (31.5) 仅相差一个常数因子。

总之，我们可以将阿苏阿德引理总结为一种便捷方法，用于基于相邻b^d对应的$P_{X|b^d}$之间的距离，将$I(b^d$、$X)$远离全熵（d比特）进行界定。

31.4 法诺方法

在本节中，我们讨论另一种通过归约到多假设检验来证明极小极大下界的方法。为此，假设损失函数是一个度量。其思路是考虑参数空间的一个ϵ-填充（第27章），即一个有限参数集合，其最小间隔为ϵ。假设我们能够证明，给定数据无法可靠地区分这些假设。那么最佳估计误差至少与ϵ成正比。检验的不可能性通常通过应用Fano不等式（推论3.13）来证明，该不等式用第3.6节中的互信息来界定检验的错误概率。因此，我们将此方案称为*Fano's method*。以下是精确的陈述。

定理 31.3 *Let d be a metric on Θ. Fix an estimator $\hat\theta$. For any $T\subset\Theta$ and $\epsilon>0$,*

$$\mathbb{P}\left[d(\theta,\hat\theta)\ge\frac{\epsilon}{2}\right] \ge 1-\frac{C(T)+\log 2}{\log M(T,d,\epsilon)}, \quad (31.10)$$

*where $C(T)\triangleq\sup I(\theta;$
$X)$ is the capacity of the channel from θ to X with input space T, with the supremum taken over all distributions (priors) on T. Consequently,*

$$\inf_{\hat\theta}\sup_{\theta\in\Theta}\mathbb{E}_\theta[d(\theta,\hat\theta)^r] \ge \sup_{T\subset\Theta,\epsilon>0}\left(\frac{\epsilon}{2}\right)^r\left(1-\frac{C(T)+\log 2}{\log M(T,d,\epsilon)}\right), \quad (31.11)$$

Proof. 只需证明(31.10)。固定$T \subset \Theta$。考虑一个ϵ-填充$T' = \{\theta_1, \dots, \theta_M\} \subset T$使得$\min_{i \neq j} d(\theta_i, \theta_j) \geq \epsilon$。设$\theta$在该填充上均匀分布，且$X \sim P_\theta$以$\theta$为条件。给定任意估计量$\hat{\theta}$，通过将$\hat{\theta}$舍入到$\tilde{\theta} = \operatorname{argmin}_{\theta \in T'} d(\hat{\theta}, \theta)$构造一个检验。由三角不等式，$d(\theta, \tilde{\theta}) \leq 2d(\theta, \hat{\theta})$。因此$\mathbb{P}[\theta \neq \tilde{\theta}] \leq \mathbb{P}[d(\theta, \tilde{\theta}) \geq \epsilon/2]$。另一方面，应用Fano不等式（推论3.13）可得

$$\mathbb{P}[\theta \neq \tilde{\theta}] \geq 1 - \frac{I(\theta; X) + \log 2}{\log M}.$$

(31.10)的证明通过注意到$I(\theta;\ X) \leq C(T)$而完成。 □

在应用Fano方法时，由于容量$C(T)$往往难以评估，回顾定理5.9可知，$C(T)$与分布集$\{P_\theta$的KL半径一致：$\theta \in T\}$，即$C(T) \triangleq \inf_Q \sup_{\theta \in T} D(P_\theta \| Q)$。因此，选择任意$Q$都会导致容量的上界。作为一个应用，我们在1-$\leq q \leq \infty$损失（$\ell_q$损失）下重新审视推论28.8中的$d$维GLM，特别关注其对维度的依赖性。（关于稀疏设置中的另一个应用，请参见练习VI.12。）

例31.5 考虑样本量为n的GLM，其中$P_\theta = \mathcal{N}(\theta, I_d)^{\otimes n}$。在此及下文取自然对数，我们得到

$$D(P_\theta \| P_{\theta'}) = \frac{n}{2} \|\theta - \theta'\|_2^2;$$

换言之，KL 邻域是 ℓ_2-球。因此，让我们将定理 31.3 应用于 $T = B_2(\rho)$，其中 $\rho > 0$ 有待指定。然后 $C(T) \leq \sup_{\theta \in T} D(P_\theta \| P_0) = \frac{n\rho^2}{2}$。为了从下方界定填充数，我们应用定理 27.3 中的体积界，

$$M(B_2(\rho), \|\cdot\|_q, \epsilon) \geq \frac{\rho^d \mathrm{vol}(B_2)}{\epsilon^d \mathrm{vol}(B_q)} \geq \left(\frac{c_q \rho d^{1/q}}{\epsilon \sqrt{d}} \right)^d$$

对于某个常数 c_q，其中最后一步遵循 ℓ_q-球的体积公式(27.13)。选择 $\rho = \sqrt{d/n}$ 和 $\epsilon = \frac{c_q}{e^2} \rho d^{1/q - 1/2}$，应用定理31.3可得到极小极大下界

$$R_q \equiv \inf_{\hat{\theta}} \sup_{\theta \in \mathbb{R}^d} \mathbb{E}_\theta[\|\hat{\theta} - \theta\|_q] \geq C_q \frac{d^{1/q}}{\sqrt{n}} \tag{31.12}$$

对于某个依赖于q的常数C_q。这与通过互信息方法加上香农下界（同样是基于体积的）在(30.9)中得到的下界相同。

对于任意 $q \geq 1$，(31.12) 是速率最优的，因为我们可以应用 MLE $\hat{\theta} = \bar{X}$。（请注意，在 $q = \infty$ 处，常数 C_q 仍然是有限的，因为 $\mathrm{vol}(B_\infty) = 2^d$。）然而，对于 $q = \infty$ 的特殊情况，(31.12) 完全不依赖于维度，这与推论 28.8 中所示的正确依赖关系 $\sqrt{\log d}$ 相反。事实上，先前在例 31.4 中，Assouad 引理的应用产生了相同的次优结果。那么，是否有可能用 Fano 方法来修正这种不紧性？事实证明，答案是肯定的，而次优性源于度量熵的体积界，正如我们在第 27.3 节中所看到的，如果 ϵ 随维度缩放，该界可能无效。确实，如果

我们在（27.18）中应用了$M(B_2, \|\cdot\|_\infty, \epsilon)$的紧界，[2]伴随$\epsilon = \sqrt{\frac{c \log d}{n}}$和$\rho = \sqrt{c' \frac{\log d}{n}}$对于某些绝对常数$c, c'$，正如期望的那样，我们确实得到了$R_\infty \gtrsim \sqrt{\frac{\log d}{n}}$。

我们以关于定理31.3应用的一些评论结束本节：

- 有时用KL直径进一步界定KL半径更为方便，因为$C(T) \le \mathrm{diam}_{\mathrm{KL}}(T) \triangleq \sup_{\theta,\theta' \in T} D(P_{\theta'} \| P_\theta)$ (cf. 推论5.8)。这对于例31.5来说是足够的。
- 在定理31.3中，我们实际上通过限制在参数子空间$T \subset \Theta$上的全局极小极大风险来下界全局极小极大风险，目的是控制互信息，这通常难以计算。对于示例31.5中考虑的GLM，KL散度与ℓ_2距离的平方成正比，并且T自然选择为欧几里得球。对于其他模型，如协方差模型（练习VI.16），其中KL散度更为复杂，KL邻域T需要谨慎选择。稍后在32.4节中，我们将应用相同的Fano方法来解决估计平滑密度的无限维问题。

[2] In fact, in this case we can also choose the explicit packing $\{\epsilon e_1, \ldots, \epsilon e_d\}$.

32 Entropic bounds for statistical estimation

到目前为止，我们关于信息论方法的讨论主要集中在统计下界（不可能性结果）上，而在具体情形中则获得匹配的上界。在本章中，我们将讨论统计估计的三个信息论上界。这三个结果适用于不同的损失函数，并且是通过完全不同的方法得到的。然而，它们的形式完全相同，都涉及模型的相应度量熵。

具体而言，假设我们独立地从分布P_θ中抽取观测值$X_1, \ldots, X_n$，其中参数$\theta \in \Theta$未知，目标是为真实分布P_θ生成一个估计$\hat{P}$。我们有以下熵极小极大上界：

- KL损失（Yang-Barron [464]）：

$$\inf_{\hat{P}} \sup_{\theta\in\Theta} \mathbb{E}_\theta[D(P_\theta\|\hat{P})] \lesssim \inf_{\epsilon>0} \left\{ \epsilon^2 + \frac{1}{n} \log N_{\mathrm{KL}}(\mathcal{P}, \epsilon) \right\}. \tag{32.1}$$

- Hellinger损失（Le Cam-Birgé [273, 53]）：

$$\inf_{\hat{P}} \sup_{\theta\in\Theta} \mathbb{E}_\theta[H^2(P_\theta, \hat{P})] \lesssim \inf_{\epsilon>0} \left\{ \epsilon^2 + \frac{1}{n} \log N_H(\mathcal{P}, \epsilon) \right\}. \tag{32.2}$$

- 总变差损失（Yatracos [465]）：

$$\inf_{\hat{P}} \sup_{\theta\in\Theta} \mathbb{E}_\theta[\mathrm{TV}^2(P_\theta\|\hat{P})] \lesssim \inf_{\epsilon>0} \left\{ \epsilon^2 + \frac{1}{n} \log N_{\mathrm{TV}}(\mathcal{P}, \epsilon) \right\}. \tag{32.3}$$

这里的 $N(\mathcal{P}, \epsilon)$ 指的是模型类 $\mathcal{P} = \{P_\theta\colon\ \theta \in \Theta\}$ 在各种距离下的度量熵（参见第27章），我们将在此过程中对此进行形式化。

特别地，我们将看到这些方法在平滑性约束下，对于经典的*density estimation*问题达到了极小极大最优速率。为了将这些结果置于更广阔的背景下，我们提醒读者，我们已经讨论了基于机器学习思想的现代密度估计方法（例4.2和7.5）。然而，那些方法尽管优美且在经验上成功，但并未已知能在任何合理的类上达到最优性。而如上所述的度量熵方法，则能够且应当被用来推导机器学习方法所针对的类的基本极限。因此，存在一个丰富的现代应用领域，本章希望能引领读者去探索。

我们注意到，对于统计估计还存在其他熵上界，特别是最大似然估计和其他M估计量。这要求不同类型的度量熵（括号熵，即

类似于上确界范数下的度量熵），并且分析风格在精神上更接近经验过程理论（例如Dudley的熵积分（27.22））。关于细节，我们请读者参阅专著[332, 429, 431]。在本章中，我们关注更具信息论风格的结果。

32.1 Yang-Barron的构造

设 $\mathcal{P} = \{P_\theta : \theta \in \Theta\}$ 为空间 $\mathcal{X}$ 上的参数分布族。给定 $X^n = (X_1, \ldots, X_n) \overset{\text{i.i.d.}}{\sim} P_\theta$ 对于某个 $\theta \in \Theta$，我们得到一个估计 $\hat{P} = \hat{P}(\cdot|X^n)$，它是一个依赖于 X^n 的分布。损失函数是 KL 散度 $D(P_\theta\|\hat{P})$。[1] 因此平均风险为

$$\mathbb{E}_\theta D(P_\theta\|\hat{P}) = \int D\left(P_\theta\|\hat{P}(\cdot|X^n)\right) P^{\otimes n}(dx^n).$$

如果该族有一个共同的支配测度μ，则该问题等价于估计密度$p_\theta = \frac{dP_\theta}{d\mu}$，在统计学文献中通常称为*density estimation*问题。

我们的目标是证明极小极大KL风险的上界(32.1)

$$R^*_{\mathrm{KL}}(n) \triangleq \inf_{\hat{P}} \sup_{\theta\in\Theta} \mathbb{E}_\theta D(P_\theta\|\hat{P}), \tag{32.4}$$

其中下确界取遍所有估计量 $\hat{P} = \hat{P}(\cdot|X^n)$，该估计量是 $\mathcal{X}$ 上的一个分布；换句话说，我们允许 *improper* 估计，意思是指 $\hat{P}$ 可以超出模型类 $\mathcal{P}$。事实上，我们将在本节中使用的构造（例如预测密度估计量（贝叶斯）或它们的混合）不必是 $\mathcal{P}$ 的成员。稍后我们将在第32.2节和第32.3节中看到，对于全变差损失和 Hellinger 损失，我们总是可以限制在 *proper* 估计量上；[2] 然而这些损失函数弱于 KL 散度。

本节的主要结果如下。

定理 32.1 *Let C_n denotes the capacity of the channel $\theta \mapsto X^n \sim P_\theta^{\otimes n}$, namely*

$$C_n = \sup I(\theta; X^n), \tag{32.5}$$

where the supremum is over all distributions (priors) of θ taking values in Θ. Denote by

$$N_{\mathrm{KL}}(\mathcal{P}, \epsilon) \triangleq \min\left\{N : \exists Q_1, \ldots, Q_N \; s.t. \; \forall\theta \in \Theta, \exists i \in [N], D(P_\theta\|Q_i) \le \epsilon^2\right\}. \tag{32.6}$$

the KL covering number for the class $\mathcal{P}$. Then

$$R^*_{\mathrm{KL}}(n) \le \frac{C_{n+1}}{n+1} \tag{32.7}$$

[1] Note the asymmetry in this loss function. Alternatively the loss $D(\hat{P}\|P)$ is typically infinite in nonparametric settings, because it is impossible to estimate the support of the true density exactly.

[2] This is in fact a generic observation: Whenever the loss function satisfies an approximate triangle inequality, any improper estimate can be converted to a proper one by its project on the model class whose risk is inflated by no more than a constant factor.

$$\leq \inf_{\epsilon>0}\left\{\epsilon^2 + \frac{1}{n+1}\log N_{\mathrm{KL}}(\mathcal{P},\epsilon)\right\}. \tag{32.8}$$

Conversely,

$$\sum_{t=0}^{n} R^*_{\mathrm{KL}}(t) \geq C_{n+1}. \tag{32.9}$$

注意，容量 C_n 正是控制泛化压缩中极小极大遗憾的冗余度（13.10）；它能够界定KL风险这一事实可归因于个体风险与累积风险之间的一般关系，我们将在第32.1.4节中对此进行解释。正如第13章所述，即使对于像伯努利（$P_\theta = \mathrm{Ber}(\theta)$）这样简单的模型，计算 C_n 的精确值通常也是困难的。这正是（32.8）发挥作用的地方：可以利用度量熵和第27章中的工具来界定此容量，从而得到有用（甚至最优）的风险界。我们将讨论该结果的两类应用。

有限维模型考虑一族光滑参数化密度 $\mathcal{P} = \{P_\theta : \theta \in \Theta\}$，其中 $\Theta \subset \mathbb{R}^d$ 是某个紧集。假设 KL 散度表现为平方范数，即对于任意 $\theta, \theta' \in \Theta$ 和 $\mathbb{R}^d$ 上的某个范数 $\|\cdot\|$，有 $D(P_\theta \| P_{\theta'}) \asymp \|\theta - \theta'\|^2$。（例如，对于 $P_\theta = \mathcal{N}(\theta, I_d)$ 的 GLM，我们有 $D(P_\theta \| P_{\theta'}) = \frac{1}{2}\|\theta - \theta'\|_2^2$。）在这种情况下，KL 覆盖数继承了有限维空间中度量熵的通常行为（参见定理 27.3 和推论 27.4），并且我们有

$$N_{\mathrm{KL}}(\mathcal{P},\epsilon) \lesssim \left(\frac{1}{\epsilon}\right)^d.$$

然后 (32.8) 得出

$$C_n \lesssim \inf_{\epsilon>0}\left\{n\epsilon^2 + d\log\frac{1}{\epsilon}\right\} \asymp d\log n, \tag{32.10}$$

这与冗余度 $C_n = \frac{d}{2}\log n + o(\log n)$ (recall 的典型渐近行为一致（参见 (13.24) 和 (13.25)）。

应用上界(32.7)或(32.8)得到

$$R^*_{\mathrm{KL}}(n) \lesssim \frac{d\log n}{n}.$$

与在 d 维中通常的参数速率 $\frac{d}{n}$（例如 GLM）相比，这个上界仅因一个对数因子而次优。

无限维模型 与第27.4节的结果类似，对于非参数模型，$N_{\mathrm{KL}}(\epsilon)$通常随$\frac{1}{\epsilon}$呈超多项式增长，进而容量$C_n$呈超对数增长。事实上，只要对于某个$\alpha > 0$，有$C_n = n^\alpha \mathrm{polylog}(n)$，其中$(\log n)^{c_0} \leq \mathrm{polylog}(n) \leq (\log n)^{c_1}$，对于某个绝对$c_0, c_1$，定理32.1表明极小极大KL速率满足

$$R^*_{\mathrm{KL}}(n) = n^{\alpha-1}\mathrm{polylog}(n) \tag{32.11}$$

这很容易通过结合(32.7)和(32.8)得出——详情见(32.27)。具体示例，参见第32.4节关于估计光滑密度的应用。

接下来，我们解释定理32.1背后的直觉及其证明。

32.1.1 贝叶斯风险作为条件互信息与容量界

为了获得一些洞察，我们首先考虑带有先验 π 在 Θ 上的贝叶斯设定。在给定 $\theta \sim \pi$ 的条件下，数据 $X^n = (X_1, \ldots, X_n) \overset{\text{i.i.d.}}{\sim} P_\theta$。[3] 任何估计量 $\hat{P} = \hat{P}(\cdot|X^n)$ 都是依赖于 $\mathcal{X}$ 的关于 X^n 的分布。因此，$\hat{P}$ 可以与一个 *conditional distribution*（比如 $Q_{X_{n+1}|X^n}$）等同起来，此后我们将这样做。为方便起见，让我们引入一个（未见的）观测 X_{n+1}，它来自相同的 P_θ，并且在给定 θ 的条件下独立于 X^n。从这个角度看，估计量的作用是 *predict* 未见的 X_{n+1} 的分布。

以下引理表明，贝叶斯 KL 风险等于条件互信息，并且贝叶斯估计量恰好是 $P_{X_{n+1}|X^n}$（，相对于由先验) 导出的联合分布，这在统计学文献中被称为 *predictive density estimator*。

引理 32.2 *The Bayes risk for prior π is given by*

$$R^*_{\mathrm{KL,Bayes}}(\pi) \triangleq \inf_{\hat{P}} \int \pi(d\theta) P_\theta^{\otimes n}(dx^n) D(P_\theta \| \hat{P}(\cdot|x^n)) = I(\theta; X_{n+1}|X^n),$$

where $\theta \sim \pi$ and $(X_1, \ldots, X_{n+1}) \overset{\text{i.i.d.}}{\sim} P_\theta$ conditioned on θ. The Bayes estimator achieving this infi- mum is given by $\hat{P}$贝叶斯$(\cdot|x^n) = P_{X_{n+1}|X^n=x^n}$. If each P_θ has a density p_θ with respect to some common dominating measure μ, the Bayes estimator has density:

$$\hat{p}_{\mathrm{Bayes}}(x_{n+1}|x^n) = \frac{\int \pi(d\theta) \prod_{i=1}^{n+1} p_\theta(x_i)}{\int \pi(d\theta) \prod_{i=1}^{n} p_\theta(x_i)}. \tag{32.12}$$

Proof. 贝叶斯风险可计算如下：

$$\begin{aligned}
\inf_{Q_{X_{n+1}|X^n}} \mathbb{E}_{\theta,X^n}\left[D(P_\theta \| Q_{X_{n+1}|X^n})\right] &= \inf_{Q_{X_{n+1}|X^n}} D(P_{X_{n+1}|\theta} \| \hat{P}_{X_{n+1}|X^n} | P_{\theta,X^n}) \\
&= \mathbb{E}_{X^n}\left[\inf_{Q_{X_{n+1}|X^n}} D(P_{X_{n+1}|\theta} \| \hat{P}_{X_{n+1}|X^n} | P_{\theta|X^n})\right] \\
&\overset{\text{(a)}}{=} \mathbb{E}_{X^n}\left[D(P_{X_{n+1}|\theta} \| P_{X_{n+1}|X^n} | P_{\theta|X^n})\right] \\
&= D(P_{X_{n+1}|\theta} \| P_{X_{n+1}|X^n} | P_{\theta,X^n}) \\
&\overset{\text{(b)}}{=} I(\theta; X_{n+1}|X^n).
\end{aligned}$$

其中 (a) 由互信息的变分表示得出（定理 4.1 和推论 4.2）；(b) 引用了条件互信息的定义（第 3.4 节）并且

[3] Throughout this chapter, we continue to use the conventional notation P_θ for a parametric family of distributions and use π to stand for the distribution of θ.

$X^n \to \theta \to X_{n+1}$构成马尔可夫链这一事实，因此$P_{X_{n+1}|\theta,X^n} = P_{X_{n+1}|\theta}$。此外，贝叶斯最优估计器由$P_{X_{n+1}|X^n}$给出。 □

注意，$I(\theta;\ X_{n+1}|X^n)$的操作意义在于，在已经获得n个观测值的情况下，通过一次额外观测所提供的关于θ的信息。在大多数情况下，由于X^n已经允许将θ一致估计为$n \to \infty$，X_{n+1}的额外有用性趋于消失。以下结果精确地说明了这一点。

引理 32.3（信息边际效用递减） $n \mapsto I(\theta;\ X_{n+1}|X^n)$ *is a decreasing sequence. Furthermore,*

$$I(\theta; X_{n+1}|X^n) \le \frac{1}{n+1} I(\theta; X^{n+1}). \tag{32.13}$$

Proof. 鉴于互信息的链式法则（定理3.7）：$I(\theta;\ X^{n+1}) = \sum_{i=1}^{n+1} I(\theta;\ X_i|X^{i-1})$，（32.13）由单调性得出。为了证明后者，我们考虑一个“采样信道”，其输入为θ，输出为从P_θ中采样的X。令$I(\pi)$表示当输入分布为π时的互信息，这是π (定理5.3)中的一个凹函数。那么

$$I(\theta; X_{n+1}|X^n) = \mathbb{E}_{X^n}[I(P_{\theta|X^n})] \le \mathbb{E}_{X^{n-1}}[I(P_{\theta|X^{n-1}})] = I(\theta; X_n|X^{n-1})$$

其中该不等式由Jensen不等式得出，因为$P_{\theta|X^{n-1}}$是$P_{\theta|X^n}$的混合。 □

引理32.3使我们能够证明逆界(32.9)：固定任意先验π。由于极小极大风险支配任何贝叶斯风险（定理28.1），结合引理32.2，我们有

$$\sum_{t=0}^{n} R^*_{\mathrm{KL}}(t) \ge \sum_{t=0}^{n} I(\theta; X_{t+1}|X^t) = I(\theta; X^{n+1}).$$

回忆（32.5），$C_{n+1} = \sup_{\pi\in\mathcal{P}(\Theta)} I(\theta;\ X^{n+1})$。对先验$\pi$进行优化得到（32.9）。

现在 *suppose* 极小极大定理对 (32.4) 成立，因此 $R^*_{\mathrm{KL}} = \sup_{\pi\in\mathcal{P}(\Theta)} R^*_{\mathrm{KL,Bayes}}(\pi)$。引理32.2然后允许我们将极小极大风险表示为在先验 π 上最大化的条件互信息：

$$R^*_{\mathrm{KL}}(n) = \sup_{\pi\in\mathcal{P}(\Theta)} I(\theta; X_{n+1}|X^n).$$

因此，引理32.3 推出了所期望的

$$R^*_{\mathrm{KL}}(n) \le \frac{1}{n+1} C_{n+1}.$$

接下来，我们直接证明这一点，而不通过贝叶斯途径或假设极小极大定理。这一主要思想源自Yang和Barron [464]，即考虑形如(32.12)的贝叶斯估计量，但在*worst case*中进行分析。固定$\mathcal{X}^{n+1}$上的任意联合分布$Q_{X^{n+1}}$，其分解为$Q_{X^{n+1}} = \prod_{i=1}^{n-1} Q_{X_i|X^{i-1}}$。（此联合分布是仅用于构造估计量的辅助对象。）对于每个i，条件分布$Q_{X_i|X^{i-1}}$定义了一个估计量

以大小为i的样本X^i作为输入。取其Cesàro均值，得到以下基于全样本X^n的估计量：

$$\hat{P}(\cdot|X^n) \triangleq \frac{1}{n+1}\sum_{i=1}^{n+1} Q_{X_i|X^{i-1}}. \tag{32.14}$$

让我们界定该估计量的最坏情况KL风险。设$Fix\ \theta \in \Theta$和X^{n+1}独立地从P_θ中抽取，使得$P_{X^{n+1}} = P_\theta^{\otimes(n+1)}$。根据该分布取期望，我们得到

$$\begin{aligned}\mathbb{E}_\theta[D(P_\theta\|\hat{P}(\cdot|X^n))] &= \mathbb{E}\left[D\left(P_\theta\middle\|\frac{1}{n+1}\sum_{i=1}^{n+1}Q_{X_i|X^{i-1}}\right)\right]\\ &\overset{(a)}{\le} \frac{1}{n+1}\sum_{i=1}^{n+1} D(P_\theta\|Q_{X_i|X^{i-1}}|P_{X^{i-1}})\\ &\overset{(b)}{=} \frac{1}{n+1}D(P_\theta^{\otimes(n+1)}\|Q_{X^{n+1}}),\end{aligned}$$

其中(a)和(b)分别由凸性（定理5.1）和KL散度的链式法则（定理2.16(c)）得出。对$\theta\in\Theta$取上确界，界定了最坏情况下的风险为

$$R^*_{\mathrm{KL}}(n) \le \frac{1}{n+1}\sup_{\theta\in\Theta} D(P_\theta^{\otimes(n+1)}\|Q_{X^{n+1}}).$$

在$Q_{X^{n+1}}$的选择上进行优化，我们得到

$$R^*_{\mathrm{KL}}(n) \le \frac{1}{n+1}\inf_{Q_{X^{n+1}}}\sup_{\theta\in\Theta} D(P_\theta^{\otimes(n+1)}\|Q_{X^{n+1}}) = \frac{C_{n+1}}{n+1},$$

其中最后一个等式应用了Kemperman的定理5.9，完成了(32.7)的证明。此外，定理5.9断言最优的$Q_{X^{n+1}}$存在且由达到容量的输出分布$P^*_{X^{n+1}}$唯一给出。因此，上述极小极大上界可以通过取$P^*_{X_1}, P^*_{X_2|X_1}, \ldots, P^*_{X_{n+1}|X^n}$的Cesàro平均来达到，即，

$$\hat{P}^*(\cdot|X^n) = \frac{1}{n+1}\sum_{i=1}^{n+1} P^*_{X_i|X^{i-1}}. \tag{32.15}$$

注意，通常这是一个*improper*估计，因为它超出了类$\mathcal{P}$的范围。

在容量达到输入分布 π^* 存在的特殊情况下，容量达到输出分布可以表示为乘积分布上的混合，即 $P^*_{X^{n+1}} = \int \pi^*(d\theta)P_\theta^{\otimes(n+1)}$。因此，估计量 $\hat{P}^*(\cdot|X^n)$ 实际上是在先验 π^* 下的 *average of Bayes estimators* (32.12)，适用于样本大小从0到 n 的范围。

最后，如下一节将阐明的那样，为了在KL覆盖数方面达到进一步的上界(32.8)，即 $R^*_{\mathrm{KL}}(n) \le \epsilon^2 + \frac{1}{n+1}\log N_{\mathrm{KL}}(\mathcal{P},\epsilon)$，只需选择以下$Q_{X^{n+1}}$，而非精确达到容量的输出分布：选取一个大小为$N = N_{\mathrm{KL}}(\mathcal{P},\epsilon)$的$\epsilon$-KL覆盖$Q_1,\ldots,Q_N$对于$\mathcal{P}$，并选择$\pi$为均匀分布，定义 $Q_{X^{n+1}} = \frac{1}{N}\sum_{j=1}^N Q_j^{\otimes(n+1)}$——这是[464]中的原始构造。在这种情况下，

应用贝叶斯规则（32.12），我们看到估计量实际上是中心 $Q_1,\dots,Q_N$ 的凸组合 $\hat{P}(\cdot|X^n)=\sum_{j=1}^N w_j Q_j$，其数据驱动的权重由下式给出

$$w_j=\frac{1}{n+1}\sum_{i=1}^{n+1}\frac{\prod_{t=1}^{i-1}Q_j(X_t)}{\sum_{j=1}^N\prod_{t=1}^{i-1}Q_j(X_t)}.$$

再次，除了 $\mathcal{P}$ 为凸且中心 Q_j 属于 $\mathcal{P}$ 的特殊情况外，估计 $\hat{P}(\cdot|X^n)$ 是不恰当的。

32.1.2 通过KL覆盖数得到的容量上界

如前所述，求解容量 C_n 需要解决(32.5)中的困难优化问题。在本小节中，我们证明(32.8)，它通过度量熵来界定该容量。从概念上讲，度量熵和容量都衡量模型类的复杂度。以下结果适用于比(32.5)更一般的情形，它精确刻画了它们之间的关系。

定理 32.4 *Let $\mathcal{Q}=\{P_{B|A=a}:a\in\mathcal{A}\}$ be a collection of distributions on some space $\mathcal{B}$ and denote the capacity $C=\sup_{P_A\in\mathcal{P}(\mathcal{A})}I(A;B)$. Then*

$$C=\inf_{\epsilon>0}\{\epsilon^2+\log N_{\mathrm{KL}}(\mathcal{Q},\epsilon)\},\tag{32.16}$$

where N_{KL} is the KL covering number defined in (32.6).

Proof. 固定 ϵ 并令 $N=N_{\mathrm{KL}}(\mathcal{Q},\epsilon)$。则存在 $Q_1,\dots,Q_N$ 构成一个 ϵ-KL 覆盖，使得对于任意 $a\in\mathcal{A}$，存在 $i(a)\in[N]$ 使得 $D(P_{B|A=a}\|Q_{i(a)})\le\epsilon^2$。固定任意 P_A。则

$$\begin{aligned}I(A;B)=I(A,i(A);B)&=I(i(A);B)+I(A;B|i(A))\\&\le H(i(A))+I(A;B|i(A))\le\log N+\epsilon^2.\end{aligned}$$

其中最后一个不等式源于 $i(A)$ 最多取 N 个值，并且根据定理4.1的应用，

$$I(A;B|i(A))\le D\left(P_{B|A}\|Q_{i(A)}|P_{i(A)}\right)\le\epsilon^2.$$

对于下界，注意如果 $C=\infty$，那么鉴于上述上界，对于任意 ϵ，$N_{\mathrm{KL}}(\mathcal{Q},\epsilon)=\infty$，并且 (32.16) 式等号成立。如果 $C<\infty$，定理 5.9 表明 C 是 $\mathcal{Q}$ 的 KL 半径，即存在 P_B^*，使得 $C=\sup_{P_A\in\mathcal{P}(\mathcal{A})}D(P_{B|A}\|P_B^*|P_A)=\sup_{x\in\mathcal{A}}D(P_{B|A}\|P_B^*|P_A)$。换言之，对于任意 $\delta>0$，$N_{\mathrm{KL}}(\mathcal{Q},\sqrt{C+\delta})=1$。令 $\delta\to0$ 即证明了 (32.16) 的等式。

□

接下来，我们将定理32.4应用于统计设定（32.5）中，其中输入A为θ，输出B为$X^n\overset{\text{i.i.d.}}{\sim}P_\theta$。回想$\mathcal{P}=\{P_\theta:\ \theta\in\Theta\}$。令$\mathcal{P}_n\triangleq\{P_\theta^{\otimes n}:\ \theta\in\Theta\}$。根据KL散度的张量积性质（定理2.16(d)），$D(P_\theta^{\otimes n}\|P_{\theta'}^{\otimes n})=nD(P_\theta\|P_{\theta'})$。因此

$$N_{\mathrm{KL}}(\mathcal{P}_n,\epsilon)\le N_{\mathrm{KL}}\left(\mathcal{P},\frac{\epsilon}{\sqrt{n}}\right).$$

将其与定理32.4结合，我们得到关于容量C_n的上界，该上界以（单字母）族$\mathcal{P}$的KL度量熵表示:

$$C_n \le \inf_{\epsilon>0} \left\{ n\epsilon^2 + \log N_{\mathrm{KL}}(\mathcal{P}, \epsilon) \right\}. \tag{32.17}$$

这证明了（32.8），从而完成了定理32.1的证明。

32.1.3 使用Hellinger熵界定容量与KL覆盖数

回想一下，为了从(32.9)推导出关于极小极大KL风险的具体界，例如(32.11)，需要具有匹配容量C_n的上界和下界。尽管定理32.4以KL覆盖数来刻画容量，但使用后者并不方便，因为它不是度量，因此第27章中发展的结果如定理27.2不适用。接下来，我们利用关于Hellinger距离的度量熵，给出KL覆盖数和容量C_n的界，在温和条件下这些界在对数因子范围内是紧的。

定理 32.5 *Let $\mathcal{P} = \{P_\theta : \ \theta \in \Theta\}$ and $M_H(\epsilon) \equiv M(\mathcal{P}, H, \epsilon)$ the Hellinger packing number of the set $\mathcal{P}$, cf. (27.2). Then C_n defined in (32.5) satisfies*

$$C_n \ge \min\left(\frac{\log e}{2} n\epsilon^2, \log M_H(\epsilon) \right) - \log 2 \tag{32.18}$$

Proof. 证明的想法很简单。给定一个打包 $\theta_1, \dots, \theta_M \in \Theta$，其两两距离为 $H^2(Q_i, Q_j) \ge \epsilon^2$，对于 $i \ne j$，其中 $Q_i \equiv P_{\theta_i}$，我们知道可以用误差 $e^{-\frac{n\epsilon^2}{2}}$ 来检验 $Q_i^{\otimes n}$ 与 $Q_j^{\otimes n}$，参见定理 7.8 和定理 32.8。然后由联合界，如果 $Me^{-\frac{n\epsilon^2}{2}} < \frac{1}{2}$，我们可以以误差 $< \frac{1}{2}$ 区分这 M 个假设。令 $\theta \sim \mathrm{Unif}(\theta_1, \dots, \theta_M)$。然后由 Fano 不等式我们得到 $I(\theta; X^n) \gtrsim \log M$。

为了得到更精确的常数，我们将通过练习I.58中展示的不等式来进行。在那个练习的符号表示中，我们取 $\lambda = 1/2$，根据定义7.24，我们得到

$$D_{1/2}(Q_i, Q_j) = -2\log(1 - \frac{1}{2}H^2(Q_i, Q_j)) \ge H^2(Q_i, Q_j)\log e \ge \epsilon^2 \log e \qquad i \ne j.$$

根据Rényi散度的张量化性质（7.79），$D_{1/2}(Q_i^{\otimes n}, Q_j^{\otimes n}) = nD_{1/2}(Q_i, Q_j)$，并且由练习I.58我们得到

$$\begin{aligned} I(\theta; X^n) &\ge -\sum_{i=1}^M \frac{1}{M} \log \left(\sum_{j=1}^M \frac{1}{M} \exp\left\{ -\frac{n}{2} D_{1/2}(Q_i, Q_j) \right\} \right) \\ &\overset{\text{(a)}}{\ge} -\sum_{i=1}^M \frac{1}{M} \log \left(\frac{M-1}{M} e^{-\frac{n\epsilon^2}{2}} + \frac{1}{M} \right) \\ &\ge -\sum_{i=1}^M \frac{1}{M} \log \left(e^{-\frac{n\epsilon^2}{2}} + \frac{1}{M} \right) = -\log \left(e^{-\frac{n\epsilon^2}{2}} + \frac{1}{M} \right), \end{aligned}$$

其中在 (a) 中我们使用了成对距离均为 $\geq n\epsilon^2$ 这一事实，除非 $i = j$。最后，由于 $\frac{1}{A} + \frac{1}{B} \leq \frac{2}{\min(A,B)}$，我们得出结论。 □

请注意，从联合范围 (7.33) 中的 $D(P\|Q) \geq H^2(P,Q)$ 出发，根据下文第 32.2.4 节，关于 KL 风险的另一个（更弱的）下界也由此得出。

接下来我们转向定理32.5的逆命题。KL和Hellinger覆盖数总是满足

$$N_{\mathrm{KL}}(\mathcal{P},\epsilon) \geq N_H(\epsilon) \equiv N(\mathcal{P},H,\epsilon). \tag{32.19}$$

接下来我们证明，假设类 $\mathcal{P}$ 在Rényi散度中具有有限半径，则(32.19)式以及定理32.5中的容量界在对数因子范围内是紧致的。在后面的第32.4节中，我们将这些结果应用于光滑密度类，该类具有有限的 χ^2 半径（通过选择均匀分布作为中心）。

定理 32.6 *Suppose that the family $\mathcal{P}$ has a finite D_λ radius for some $\lambda > 1$, i.e.*

$$R_\lambda(\mathcal{P}) \triangleq \inf_U \sup_{P\in\mathcal{P}} D_\lambda(P\|U) < \infty\,, \tag{32.20}$$

where D_λ is the Rényi divergence of order λ (see Definition 7.24). Then there exist ϵ_0 and c depending only on λ and R_λ, such that for all $\epsilon \leq \epsilon_0$,

$$N_{\mathrm{KL}}\left(\mathcal{P}, c\epsilon\sqrt{\log\frac{1}{\epsilon}}\right) \leq N_H(\epsilon) \tag{32.21}$$

and, consequently,

$$C_n \leq \inf_{\epsilon\leq\epsilon_0}\left\{cn\epsilon^2\log\frac{1}{\epsilon} + \log N_H(\epsilon)\right\}. \tag{32.22}$$

Proof. 令 $Q_1,\ldots,Q_M$ 为 $\mathcal{P}$ 的 ϵ-覆盖，使得对于任意 $P\in\mathcal{P}$，存在 $i\in[M]$ 使得 $H^2(P,Q_i) \leq \epsilon^2$。固定任意 U 并令 $P_i = \epsilon^2 U + (1-\epsilon^2)Q_i$。应用练习 I.59 可得

$$D(P\|P_i) \leq 24\epsilon^2\left(\frac{2\lambda}{\lambda-1}\log\frac{1}{\epsilon} + D_\lambda(P\|U)\right).$$

通过对 {v*} 进行优化以接近 (32.20)，证明了 (32.21)。最后，将 (32.21) 应用于 (32.17) 即可得出 (32.22)。 □

32.1.4 累积风险与个体（一步）风险之间的一般界限

总之，我们可以看出Yang-Barron方法之美在于两个想法:

• 不是直接研究风险 $R^*_{\mathrm{KL}}(n)$，(32.7) 将其与累积风险 C_n • 相关联。累积风险等于一个容量，该容量可以方便地根据覆盖数来界定。

在本小节中，我们想要指出，虽然第二步对于KL（对数损失）非常特殊，但第一个想法具有一般性。即，我们有以下个体风险（也称为批量损失）与累积风险（也称为在线损失）之间的关系，这些之前在第13.6节中关于通用压缩的背景下介绍过。

命题 32.7（在线到批量转换） *Fix a loss function* $\ell\colon \mathcal{P}(\mathcal{X})\times\mathcal{P}(\mathcal{X})\to\bar{\mathbb{R}}$ *and a class* Π *of distributions on* $\mathcal{X}$*. Define the cumulative and one-step minimax risks as follows:*[4]

$$C_n = \inf_{\{\hat{P}_t(\cdot)\}}\sup_{P\in\Pi}\mathbb{E}\left[\sum_{t=1}^{n}\ell(P,\hat{P}_t(X^{t-1}))\right] \tag{32.23}$$

$$R_n^* = \inf_{\hat{P}(\cdot)}\sup_{P\in\Pi}\mathbb{E}\left[\ell(P,\hat{P}(X^{n-1}))\right] \tag{32.24}$$

where both infima are over measurable (possibly randomized) estimators $\hat{P}_t : \mathcal{X}^{t-1}\to\mathcal{P}(\mathcal{X})$*, and the expectations are over* $X_i\overset{i.i.d.}{\sim}P$ *and the randomness of the estimators. Then we have*

$$nR_n^* \le C_n \le C_{n-1}+R_n^* \le \sum_{t=1}^{n}R_t^*\,. \tag{32.25}$$

Thus, if the sequence $\{R_n^*\}$ *satisfies* $R_n^*\asymp \frac{1}{n}\sum_{t=0}^{n-1}R_t^*$ *then* $C_n\asymp nR_n^*$*. Conversely, if* $n^{\alpha_-}\lesssim C_n\lesssim n^{\alpha_+}$ *for all* n *and some* $\alpha_+\ge\alpha_->0$*, then*

$$n^{(\alpha_--1)\frac{\alpha_+}{\alpha_-}}\lesssim R_n^*\lesssim n^{\alpha_+-1}\,. \tag{32.26}$$

备注 32.1 上述内容的含义是，$R_n^*\approx\frac{1}{n}C_n$ 在常数因子或多项式对数因子范围内，对于大多数感兴趣的情形。

Proof. 为了展示(32.25)中的第一个不等式，给定预测变量 $\{\hat{P}_t(X^{t-1}):t\in[n]\}$ 对 C_n，考虑一个随机预测变量 $\hat{P}(X^{n-1})$ 对 R_n^*，它以相等的概率等于 $\hat{P}_t(X^{t-1})$ 中的每一个。第二个不等式来自于通过以下方式交换 $\sup_P$ 和 $\sum_t$:

$$\sup_{P\in\Pi}\mathbb{E}\left[\sum_{t=1}^{n}\ell(P,\hat{P}_t(X^{t-1}))\right]\le\sup_{P\in\Pi}\mathbb{E}\left[\sum_{t=1}^{n-1}\ell(P,\hat{P}_t(X^{t-1}))\right]+\sup_{P\in\Pi}\mathbb{E}\left[\ell(P,\hat{P}_n(X^{n-1}))\right]\,.$$

(换句话说，通过在前$n-$轮1中使用C_{n-1}最优在线学习器，并在最后一轮中使用R_n^*最优批量学习器，C_n是有界的。) (32.25)中的第三个不等式由第二个不等式通过归纳法得出，且$C_1=R_1^*$。

为了推导出（32.26），请注意R_n^*的上界由（32.25）得出。对于下界，注意到序列R_n^*是非增的，因此对于任意$n<m$，我们有

$$C_m\le\sum_{t=0}^{m-1}R_t^*\le\sum_{t=0}^{n-1}\frac{C_t}{t}+(m-n)R_n^*\,. \tag{32.27}$$

4 注意，对于KL损失，C_n和R_n^*分别与(13.34)和(13.35)中定义的AvgReg_n^*和$\mathrm{BatchReg}_n^*$一致。

将 $m = an^{\frac{\alpha_+}{\alpha_-}}$ 设置为某个合适的常数 a，可以得到下界。 □

32.2 类似 Le Cam-Birgé 的成对比较

当我们在定理31.3中证明下界时，我们运用了这样的推理：如果参数空间Θ的ϵ-覆盖无法被测试，那么$\theta \in \Theta$的估计精度不能超过ϵ，从而根据KL度量熵建立了一个极小极大*lower bound*。反过来，我们可以提出以下问题：

是否可能基于测试构造一个估计器，并根据度量熵产生一个极小极大的*upper bound*?

对于Hellinger损失，答案是肯定的，尽管涉及的度量熵是关于Hellinger距离而非KL散度的。基本的构造归功于Le Cam，并由Birgé进一步发展。主要思想如下：固定分布集合$\mathcal{P}$的一个ϵ覆盖$\{P_1, \ldots, P_N\}$。给定从$P \in \mathcal{P}$抽取的n个观测值，我们检验P属于哪个球；这允许我们在Hellinger损失ϵ范围内估计P。这可以通过成对比较论证来实现，即检验（复合）假设$P \in B(P_i, \epsilon)$与$P \in B(P_j, \epsilon)$。此方案可以进一步细化，以涉及模型的局部熵。

32.2.1 复合假设检验与Hellinger距离

回顾第16.4节中介绍的复合假设检验问题。设 $\mathcal{P}$ 和 $\mathcal{Q}$ 为两（*not* 未必凸的）分布类。给定从某个分布 P 中抽取的 iid 观测 $X_1, \ldots, X_n$，我们想根据某个决策规则 $\phi = \phi(X_1, \ldots, X_n) \in \{0, 1\}$ 来检验 $P \in \mathcal{P}$ (由 $\phi = 0$) 指示还是 $P \in \mathcal{Q}$ (由 $\phi = 1$) 指示。由极小极大定理，最优误差由最坏情况混合之间的总变差给出：

$$\min_{\phi} \left\{ \sup_{P \in \mathcal{P}} P(\phi = 1) + \sup_{Q \in \mathcal{Q}} Q(\phi = 0) \right\} = 1 - \mathrm{TV}(\mathrm{co}(\mathcal{P}^{\otimes n}), \mathrm{co}(\mathcal{Q}^{\otimes n})), \tag{32.28}$$

其中符号说明如下：

- $\mathcal{P}^{\otimes n} \triangleq \{P^{\otimes n} : P \in \mathcal{P}\}$ 由 $\mathcal{P}$ 中分布的所有 n 重乘积组成；
- $\mathrm{co}(\cdot)$ 表示凸包，即所有混合物的集合。例如，对于参数族，$\mathrm{co}(\{P_\theta : \theta \in \Theta\}) = \{P_\pi : \pi \in \mathcal{P}(\Theta)\}$，其中 $P_\pi = \int P_\theta \pi(d\theta)$ 是混合分布 π 下的混合物，而 $\mathcal{P}(\Theta)$ 表示 Θ 上所有分布（先验）的集合。

实现（32.28）的最优检验是由最坏情况混合所给出的似然比，即最接近的混合对（P_n^*, Q_n^*），使得$\mathrm{TV}(P_n^*, Q_n^*) = \mathrm{TV}(\mathrm{co}(\mathcal{P}^{\otimes n}), \mathrm{co}(\mathcal{Q}^{\otimes n}))$。

[5] In case the closest pair does not exist, we can replace it by an infimizing sequence.

精确结果(32.28)颇为复杂，因为其右侧涉及在n重积空间上寻找最不利的先验分布。然而，已知有若干实例，其中可获得更为简洁且明确的结果。当$\mathcal{P}$和$\mathcal{Q}$分别是围绕P_0和Q_0的TV球时，Huber [221]证明了极小极大最优检验的形式为

$$\phi(x^n) = 1\left\{\sum_{i=1}^{n} \min\left(c', \max\left(c'', \log\frac{dP_0}{dQ_0}(X_i)\right)\right) > t\right\}.$$

(另见练习 III.31.) 然而，显式已知极小极大最优检验的其他例子很少。幸运的是，正如 L e Cam 所证明的，关于 $\mathcal{P}$ 和 $\mathcal{Q}$ 之间的 Hellinger 分离度，存在一个一般的“单字母”上界。这是命题 7.25 中 Rényi 散度更一般的张量化性质的推论（Hellinger 是其中的一个特例）。

定理 32.8

$$\min_{\phi}\left\{\sup_{P\in\mathcal{P}} P(\phi=1) + \sup_{Q\in\mathcal{Q}} Q(\phi=0)\right\} \le e^{-\frac{n}{2}H^2(\mathrm{co}(\mathcal{P}),\mathrm{co}(\mathcal{Q}))}, \tag{32.29}$$

注32.2 对于$\mathcal{P}$和$\mathcal{Q}$分别是以P_0和Q_0 (为中心、半径r的Hellinger球的情况（这在下文定理32.9的证明中出现)），Birgé [56]构造了一个明确的检验。即在假设$H(P_0,Q_0) > 2.01r$下，存在形式为$\phi(x^n) = 1\left\{\sum_{i=1}^{n}\log\frac{\alpha+\beta\psi(X_i)}{\beta+\alpha\psi(X_i)} > t\right\}$的检验，其误差为$e^{-\Omega(nr^2)}$，其中$\psi(x) = \sqrt{\frac{dP_0}{dQ_0}(x)}$和$\alpha,\beta > 0$仅依赖于$H(P_0,Q_0)$。

注 32.3 这里有一个例子，其中定理32.8是（非常）宽松的。考虑 $\mathcal{P} = \{\mathrm{Ber}(1/2)\}$ 和 $\mathcal{Q} = \{\mathrm{Ber}(0), \mathrm{Ber}(1)\}$。那么 $\mathrm{co}(\mathcal{P}) \subset \mathrm{co}(\mathcal{Q})$，因此（32.29）中的上界是平凡的。另一方面，如果我们将所有0或所有0都视为声明，那么测试的错误概率是指数级小的。

Proof. 我们首先重述命题7.25的特殊情况：

$$1 - \frac{1}{2}H^2\left(\mathrm{co}\left(\bigotimes_{i=1}^{n}\mathcal{P}_i\right), \mathrm{co}\left(\bigotimes_{i=1}^{n}\mathcal{Q}_i\right)\right) \le \prod_{i=1}^{n}\left(1 - \frac{1}{2}H^2(\mathrm{co}(\mathcal{P}_i),\mathrm{co}(\mathcal{Q}_i))\right). \tag{32.30}$$

然后从(32.28)我们得到

$$\begin{aligned} 1 - \mathrm{TV}(\mathrm{co}(\mathcal{P}^{\otimes n}), \mathrm{co}(\mathcal{Q}^{\otimes n})) &\overset{(a)}{\le} 1 - \frac{1}{2}H^2(\mathrm{co}(\mathcal{P}^{\otimes n}), \mathrm{co}(\mathcal{Q}^{\otimes n})) \\ &\overset{(b)}{\le} \left(1 - \frac{1}{2}H^2(\mathrm{co}(\mathcal{P}), \mathrm{co}(\mathcal{Q}))\right)^n \le e^{-\frac{n}{2}H^2(\mathrm{co}(\mathcal{P}),\mathrm{co}(\mathcal{Q}))} \end{aligned}$$

其中 (a) 由 (7.22) 得出；(b) 由 (32.30) 得出。 □

接下来，我们将定理32.8应用于两个不相交的Hellinger球（两者均为凸）。

32.2.2 Le Cam-Birgé成对比较估计量的Hellinger保证

基于成对检验构造估计量的想法归功于 Le Cam（[273]，另见 [430, 第10节]）和 Birgé [53]。给定 n 个独立同分布观测 $X_1, \cdots, X_n$，其生成自 P，其中 $P \in \mathcal{P}$ 是待估计的分布。这里需要强调的是，$\mathcal{P}$ 需要 *not* 是一个凸集。设真实分布 P 与估计分布 $\hat{P}$ 之间的损失函数为它们的平方 Hellinger 距离，即

$$\ell(P, \hat{P}) = H^2(P, \hat{P}).$$

然后，我们得到以下结果：

定理 32.9（Le Cam-Birgé）*Denote by $N_H(\mathcal{P}, \epsilon)$ the ϵ-covering number of the set $\mathcal{P}$ under the Hellinger distance (cf. (27.1)). Let ϵ_n be such that*

$$n\epsilon_n^2 \geq \log N_H(\mathcal{P}, \epsilon_n) \vee 1.$$

Then there exists an estimator $\hat{P} = \hat{P}(X_1, \ldots, X_n)$ taking values in $\mathcal{P}$ such that for any $t \geq 1$,

$$\sup_{P \in \mathcal{P}} P[H(P, \hat{P}) > 4t\epsilon_n] \lesssim e^{-t^2} \tag{32.31}$$

and, consequently,

$$\sup_{P \in \mathcal{P}} \mathbb{E}_P[H^2(P, \hat{P})] \lesssim \epsilon_n^2 \tag{32.32}$$

Proof of Theorem 32.9. 只需证明高概率界(32.31)。缩写 $\epsilon = \epsilon_n$ 和 $N = N_H(\mathcal{P}, \epsilon_n)$。令 $P_1, \cdots, P_N$ 为 $\mathcal{P}$ 在Hellinger距离下的最大 ϵ-填充，它也作为一个 ϵ-覆盖（参见定理27.2）。因此，$\forall i \neq j$,

$$H(P_i, P_j) \geq \epsilon,$$

并且对于 $\forall P \in \mathcal{P}$、$\exists i \in [N]$，使得

$$H(P, P_i) \leq \epsilon,$$

记 $B(P, \epsilon) = \{Q : H(P, Q) \leq \epsilon\}$ 表示以 P 为中心的 ϵ-Hellinger 球。至关重要的是，*Hellinger ball is convex* 得益于 *squared* Hellinger 距离作为 f-散度的凸性；参见定理 7.5。（相反，回顾（7.6）可知，Hellinger 距离本身并非凸的。）事实上，对于任意 $P', P'' \in B(P, \epsilon)$ 和 $\alpha \in [0, 1]$,

$$H^2(\bar{\alpha}P' + \alpha P'', P) \leq \bar{\alpha}H^2(P', P) + \alpha H^2(P'', P) \leq \epsilon^2.$$

接下来，考虑以下*pairwise comparison problem*，其中我们测试两个Hellinger球（复合假设）相互之间的对比：

$$H_i : P \in B(P_i, \epsilon) \qquad \text{vs} \qquad H_j : P \in B(P_j, \epsilon)$$

对于所有 $i \neq j$，满足 $H(P_i, P_j) \geq \delta = 4\epsilon$。

由于 $B(P_i,\epsilon)$ 和 $B(P_j,\epsilon)$ 均为凸，应用定理32.8得到一个检验 $\psi_{ij} = \psi_{ij}(X_1,\ldots,X_n)$，其中 $\psi_{ij}=0$ 对应于声明 $P\in B(P_i,\epsilon)$，而 $\psi_{ij}=1$ 对应于声明 $P\in B(P_j,\epsilon)$，使得 $\psi_{ij}=1-\psi_{ji}$，并且以下大偏差界成立：对于所有满足 $H(P_i,P_j)\ge\delta$ 的 i,j，

$$\sup_{P\in B(P_i,\epsilon)} P(\psi_{ij}=1)\le e^{-\frac{n}{8}H(P_i,P_j)^2}, \tag{32.33}$$

其中我们使用了Hellinger距离的三角不等式：对于任意$P\in B(P_i,\epsilon)$和任意$Q\in B(P_j,\epsilon)$，

$$H(P,Q)\ge H(P_i,P_j)-2\epsilon\ge H(P_i,P_j)/2\ge 2\epsilon.$$

对于 $i\in[N]$，定义随机变量

$$T_i \triangleq \begin{cases} \max_{j\in[N]} H^2(P_i,P_j) & \text{s.t. } \psi_{ij}=1,\quad H(P_i,P_j)>\delta;\\ 0, & \text{no such } j \text{ exists.}\end{cases}$$

基本上，T_i记录了从P_i到那些在P_i的δ邻域之外，且在当前样本下与P_i易混淆的P_j之间的最大距离。我们的密度估计器定义为

$$\hat{P}=P_{i^*},\quad \text{where}\quad i^*\in\operatorname*{argmin}_{i\in[N]} T_i. \tag{32.34}$$

现在进行正确性证明，假设 $P\in B(P_1,\epsilon)$。直觉上，我们通常应该预期 $T_1=0$，并且对于所有满足 $H(P_1,P_j)\ge\delta$ 的 j，有 $T_j\ge\delta^2$。注意，根据 T_i 的定义和 Hellinger 距离的对称性，对于任意满足 $H(P_i,P_j)\ge\delta$ 的一对 i,j，我们有

$$\max\{T_i,T_j\}\ge H(P_i,P_j).$$

因此，

$$\begin{aligned} H(\hat{P},P_1)1\left\{H(\hat{P},P_1)\ge\delta\right\} &= H(P_{i_*},P_1)1\left\{H(P_{i_*},P_1)\ge\delta\right\}\\ &\le \max\{T_{i_*},T_1\}1\left\{\max\{T_{i_*},T_1\}\ge\delta\right\}=T_1 1\left\{T_1\ge\delta\right\}, \end{aligned}$$

其中最后一个等式是由 (32.34) 中 i_* 作为全局最小值的定义得出的。因此，对于任何 $t\ge 1$，

$$\begin{aligned} P[H(\hat{P},P_1)\ge t\delta] &\le P[T_1\ge t\delta]\\ &\le N(\epsilon)e^{-2n\epsilon^2t^2} &(32.35)\\ &\lesssim e^{-t^2}, &(32.36)\end{aligned}$$

其中 (32.35) 如下从(32.33)和(32.36)得出结论，利用了$n\epsilon^2$的假设 ≥ 1 和 $N\le e^{n\epsilon^2}$。

□

32.2.3 使用局部熵的精化

就像定理32.1一样，尽管它们对于具有超对数度量熵的非参数问题往往很紧，但对于有限维模型，直接应用定理32.9会导致一个对数因子的松弛。例如，对于一个d维参数族，例如高斯位置模型或其有限混合，度量熵通常表现为$\log N_H(\epsilon) \asymp d \log \frac{1}{\epsilon}$。因此，当$n \gtrsim d$时，定理32.9要求选择$\epsilon_n^2 \asymp \frac{d}{n} \log \frac{n}{d}$，这低于参数速率$\mathbb{E}[H^2(\hat{P}, P)] \lesssim \frac{d}{n}$这些通常是可实现的。

像往常一样，这样的对数因子可以通过局部熵论证移除。为此，定义局部Hellinger熵：

$$N_{\mathrm{loc}}(\mathcal{P}, \epsilon) \triangleq \sup_{P \in \mathcal{P}} \sup_{\eta \geq \epsilon} N_H(B(P, \eta) \cap \mathcal{P}, \eta/2). \tag{32.37}$$

定理 32.10（Le Cam-Birgé：局部熵版本）*Let ϵ_n be such that*

$$n\epsilon_n^2 \geq \log N_{\mathrm{loc}}(\mathcal{P}, \epsilon_n) \vee 1. \tag{32.38}$$

Then there exists an estimator $\hat{P} = \hat{P}(X_1, \ldots, X_n)$ taking values in $\mathcal{P}$ such that for any $t \geq 2$,

$$\sup_{P \in \mathcal{P}} P[H(P, \hat{P}) > 4t\epsilon_n] \leq e^{-t^2} \tag{32.39}$$

and hence

$$\sup_{P \in \mathcal{P}} \mathbb{E}_P[H^2(P, \hat{P})] \lesssim \epsilon_n^2 \tag{32.40}$$

注 32.4（倍增维数）假设对于某个 $d > 0$，$\log N_{\mathrm{loc}}(\mathcal{P}, \epsilon) \leq d \log \frac{1}{\epsilon}$ 对所有充分大的小 ϵ 成立；对于有限维模型，其中 Hellinger 距离通过通常的体积论证（定理 27.3）与向量范数相当，情况就是如此。那么我们说 *doubling dimension* (也称为 *Le Cam dimensionLe Cam dimension|see doubling dimension* [430])（属于 $\mathcal{P}$）最多为 d；这个术语来源于以下事实：局部熵关注的是用半径减半的球来覆盖 Hellinger 球。于是定理 32.10 表明，可以实现“参数速率”$O(\frac{d}{n})$。在这个意义上，倍增维数充当模型 $\mathcal{P}$ 的有效维数。

引理 32.11 *For any $P \in \mathcal{P}$ and $\eta \geq \epsilon$ and $k \geq \mathbb{Z}_+$,*

$$N_H(B(P, 2^k\eta) \cap \mathcal{P}, \eta/2) \leq N_{\mathrm{loc}}(\mathcal{P}, \epsilon)^k \tag{32.41}$$

Proof. 我们通过对k进行归纳来推进。基础情况$k = 0$由定义(32.37)得出。对于$k \geq 1$，假设(32.41)对于所有$P \in \mathcal{P}$的$k-1$成立。为了证明k的情况，我们构造$B(P, 2^k\eta) \cap \mathcal{P}$的一个覆盖如下：首先用$2^{k-1}\eta$-球覆盖它，然后用$\eta/2$-球覆盖每个球。根据归纳假设，球的总数最多为

$$N_H(B(P, 2^k\eta) \cap \mathcal{P}, 2^{k-1}\eta) \cdot \sup_{P' \in \mathcal{P}} N_H(B(P', 2^{k-1}\eta) \cap \mathcal{P}, \eta/2) \leq N_{\mathrm{loc}}(\epsilon) \cdot N_{\mathrm{loc}}(\epsilon)^{k-1}$$

完成证明。 □

我们现在证明定理32.10：

Proof. 我们按照定理32.9的证明来分析相同的估计量(32.34)，只是估计(32.35)被改进如下：定义Hellinger壳$A_k \triangleq \{P\colon 2^k\delta \le H(P_1,P) < 2^{k+1}\delta\}$和$G_k \triangleq \{P_1,\dots,P_N\}\cap A_k$。回想$\delta = 4\epsilon$。给定$t \ge 2$，让$\ell = \lfloor \log_2 t \rfloor$使得$2^\ell \le t < 2^{\ell+1}$。那么

$$\begin{aligned} P[T_1 \ge t\delta] &\le \sum_{k\ge\ell} P[2^k\delta \le T_1 < 2^{k+1}\delta] \\ &\overset{\text{(a)}}{\le} \sum_{k\ge\ell} |G_k| e^{-\frac{n}{8}(2^k\delta)^2} \\ &\overset{\text{(b)}}{\le} \sum_{k\ge\ell} N_{\mathrm{loc}}(\epsilon)^{k+3} e^{-2n\epsilon^2 4^k} \\ &\overset{\text{(c)}}{\lesssim} e^{-4^\ell} \le e^{-t^2} \end{aligned}$$

其中(a)由(32.33)得出；(c)由假设$\log N_{\mathrm{loc}} \le n\epsilon^2$和$k \ge \ell \ge \log_2 t \ge 1$得出；(b)由以下推理得出：由于$\{P_1,\dots,P_N\}$是一个$\epsilon$-packing，我们有

$$|G_k| \le M(A_k,\epsilon) \le N(A_k,\epsilon/2) \le N(B(P_1,2^{k+1}\delta)\cap\mathcal{P},\epsilon/2) \le N_{\mathrm{loc}}(\epsilon)^{k+3}$$

其中第一个和最后一个不等式分别由定理27.2和引理32.11得出。

□

作为定理32.10的应用，我们展示了对于局部二次行为的模型，例如那些光滑参数模型（参见第7.11节，特别是定理7.23），参数速率（即维度除以样本量）是可以达到的。

推论 32.12 *Consider a parametric family $\mathcal{P} = \{P_\theta\colon \theta\in\Theta\}$, where $\Theta\subset\mathbb{R}^d$ and $\mathcal{P}$ is totally bounded in Hellinger distance. Suppose that there exists a norm $\|\cdot\|$ and constants t_0, c, C such that for all $\theta_0,\theta_1\in\Theta$ with $\|\theta_0-\theta_1\|\le t_0$,*

$$c\|\theta_0-\theta_1\| \le H(P_{\theta_0},P_{\theta_1}) \le C\|\theta_0-\theta_1\|. \tag{32.42}$$

Then there exists an estimator $\hat\theta$ based on $X_1,\dots,X_n \overset{i.i.d.}{\sim} P_\theta$, such that

$$\sup_{\theta\in\Theta}\mathbb{E}_\theta[H^2(P_\theta,P_{\hat\theta})] \lesssim \frac{d}{n}.$$

Proof. 只需在 (32.37) 中界定局部熵$N_{\mathrm{loc}}(\mathcal{P},\epsilon)$。固定$\theta_0\in\Theta$。实际上，对于任意$\eta > t_0$，我们有$N_H(B(P_{\theta_0},\eta)\cap\mathcal{P},\eta/2) \le N_H(\mathcal{P},t_0) \lesssim 1$。对于$\epsilon\le\eta\le t_0$，

$$\begin{aligned} N_H(B(P_{\theta_0},\eta)\cap\mathcal{P},\eta/2) &\overset{\text{(a)}}{\le} N_{\|\cdot\|}(B_{\|\cdot\|}(\theta_0,\eta/c),\eta/(2C)) \\ &\overset{\text{(b)}}{\le} \frac{\mathrm{vol}(B_{\|\cdot\|}(\theta_0,\eta/c+\eta/(2C)))}{\mathrm{vol}(B_{\|\cdot\|}(\theta_0,\eta/(2C)))} = \left(1+\frac{2C}{c}\right)^d \end{aligned}$$

其中 (a) 和 (b) 分别由 (32.42) 和定理 27.3 得出。这表明 $\log N_{\mathrm{loc}}(\mathcal{P},\epsilon) \lesssim d$，通过应用定理 32.10 完成了证明。 □

32.2.4 使用局部 Hellinger 打包的下界

结果表明，在某些正则性假设下，我们能够证明Hellinger风险的一个几乎匹配的下界（通常在对数项范围内）。首先，我们如下定义局部填充数:

$$M_{\mathrm{loc}}(\epsilon) \equiv M_{\mathrm{loc}}(\mathcal{P},H,\epsilon) = \max\left\{M : \exists R, P_1,\ldots,P_M \in \mathcal{P} : H(P_i,R) \le \epsilon, H(P_i,P_j) \ge \frac{\epsilon}{2} \quad \forall i \ne j\right\}.$$

局部填充数与全局填充数 $M(\epsilon) \equiv M(\mathcal{P},H,\epsilon)$ 通过以下对任何度量都成立的一般引理相关联。这一结果表明，只要增长在 $1/\epsilon$ (中是超多项式的，例如对于第 27.4) 节中考虑的那些非参数类，局部和全局填充数的表现相似。

引理 32.13

$$\frac{M(\epsilon/2)}{M(\epsilon)} \le M_{\mathrm{loc}}(\epsilon) \le M(\epsilon)$$

Proof. 上界是显然的。对于下界，设 $P_1,\ldots,P_M$ 是 $\mathcal{P}$ 的一个极大 ϵ-填充，且 $M = M(\epsilon)$ 。设 $Q_1,\ldots,Q_{M'}$ 是 $\mathcal{P}$ 的一个极大 $\epsilon/2$-填充，且 $M' = M(\epsilon/2)$。将 $E = \{P_1,\ldots,P_M\}$ 划分为以每个 Q_i 为中心的 Voronoi 单元，即 $E_i \triangleq \{P_j : \ H(P_j,Q_i) = \min_{k\in[M]} H(P_k,Q_i)\}$ (，任意打破平局)，因此 $E_1,\ldots,E_{M'}$ 互不相交且 $E = \cup_{i\in[M']} E_i$。于是 $\max|E_i| \ge M/M'$。最后，注意每个 $E_i \subset B(Q_i,\epsilon)$，因为 E 也是一个 ϵ-覆盖。 □

注意，与(32.37)中N_{loc}的定义不同，我们并未在尺度$\eta \ge \epsilon$上取上确界。因此，我们通常不能应用定理27.2来得出$N_{\mathrm{loc}}(\epsilon) \ge M_{\mathrm{loc}}(\epsilon)$。在我们所知的所有实例中，都有$\log N_{\mathrm{loc}} \asymp \log M_{\mathrm{loc}}$，在这种情况下，以下一般性结果提供了一个极小极大下界，该下界与定理32.10中的上界在对数因子范围内相匹配。

定理 32.14 *Suppose that the D_λ radius $R_\lambda(\mathcal{P})$ of the family $\mathcal{P}$ is finite for some $\lambda > 1$; cf. (32.20). There exists constants $c = c(\lambda)$ and $\epsilon < \epsilon_0(\lambda)$ such that whenever n and $\epsilon < \epsilon_0$ are such that*

$$c(\lambda) n\epsilon^2 \left(\log\frac{1}{\epsilon^2} + R_\lambda(\mathcal{P})\right) + 2\log 2 < \log M_{\mathrm{loc}}(\epsilon), \tag{32.43}$$

any estimator $\hat{P} = \hat{P}(\cdot; X^n)$ must satisfy

$$\sup_{P\in\mathcal{P}} \mathbb{E}_P[H^2(P,\hat{P})] \ge \frac{\epsilon^2}{32},$$

where $\mathbb{E}_P$ is taken with respect to $X^n \overset{i.i.d.}{\sim} P$.

Proof. 令 $M = M_{\mathrm{loc}}(\mathcal{P}, \epsilon)$。根据定义，存在某个 Hellinger 球 $B(R, \epsilon)$ 中的 $\epsilon/2$-填充 $P_1, \ldots, P_M$。

设 $\theta \sim$ 服从 Unif([M]) 且 $X^n \overset{\text{i.i.d.}}{\sim} P_\theta$ 在给定 θ 的条件下。然后由定理 31.3 形式的 Fano 不等式可得

$$\sup_{P\in\mathcal{P}} \mathbb{E}[H^2(P,\hat{P})] \geq \left(\frac{\epsilon}{4}\right)^2 \left(1 - \frac{I(\theta; X^n) + \log 2}{\log M}\right)$$

仍然需要证明

$$\frac{I(\theta; X^n) + \log 2}{\log M} \leq \frac{1}{2}\,. \tag{32.44}$$

为此，对于任意分布U，定义

$$Q = \epsilon^2 U + (1-\epsilon^2)R\,.$$

我们首先注意到，由例I.59可知，对于所有$i \in$，有[M]

$$D(P_i\|Q) \leq 8(H^2(P_i,R) + 2\epsilon^2)\left(\frac{\lambda}{\lambda-1}\log\frac{1}{\epsilon^2} + D_\lambda(P_i\|U)\right)$$

前提是 $\epsilon < 2^{-\frac{5\lambda}{2(\lambda-1)}} \triangleq \epsilon_{0}$。由于 $H^2(P_i,R) \leq \epsilon^2$，通过将 U (优化为 $\mathcal{P}$) 的 D_λ-中心，我们得到

$$\inf_U \max_{i\in[M]} D(P_i\|Q) \leq 24\epsilon^2\left(\frac{\lambda}{\lambda-1}\log\frac{1}{\epsilon^2} + R_\lambda\right) \leq \frac{c(\lambda)}{2}\epsilon^2\left(\log\frac{1}{\epsilon^2} + R_\lambda\right)\,.$$

根据定理4.1，我们有

$$I(\theta; X^n) \leq \max_{i\in[M]} D(P_i^{\otimes n}\|Q^{\otimes n}) \leq \frac{nc(\lambda)}{2}\epsilon^2\left(\log\frac{1}{\epsilon^2} + R_\lambda\right)\,.$$

这个最终界限和条件（32.43）进而推导出（32.44）及定理的陈述。 □

最后，我们提到，对于{!v28!}模型，其中KL散度和平方Hellinger距离是可比较的，定理32.10中基于局部熵的上界给出了{!v29!}极小极大速率。这类模型包括GLM以及更一般地在任意维度中具有有界中心的高斯混合模型[232]。

推论 32.15 *Assume that*

$$H^2(P,P') \asymp D(P\|P'), \quad \forall P, P' \in \mathcal{P}.$$

Then

$$\inf_{\hat{P}} \sup_{P\in\mathcal{P}} \mathbb{E}_P[H^2(P,\hat{P})] \asymp \epsilon_n^2$$

where ϵ_n was defined in (32.38).

Proof. 根据假设，KL邻域与Hellinger球在常数因子范围内一致。因此，下界通过将定理31.3中的Fano方法应用于半径为$O(\epsilon_n)$的Hellinger球得出。

□

32.3 Yatracos 类与最小距离估计量

在本节中，我们证明(32.3)，这是关于统计风险的第三个熵上界。与Yang-Barron的结果(32.1)（针对KL散度）和Le Cam-Birgé的结果(32.2)（针对Hellinger距离）相呼应，以下结果利用参数空间在全变差下的度量熵，给出了最小最大全变差风险的上界：

定理 32.16（Yatracos [465]）*There exists a universal constant C such that the following holds. Let $X_1, \ldots, X_n \overset{i.i.d.}{\sim} P \in \mathcal{P}$, where $\mathcal{P}$ is a collection of distributions on a common measurable space $(\mathcal{X}, \mathcal{E})$. For any $\epsilon > 0$, there exists a proper estimator $\hat{P} = \hat{P}(X_1, \ldots, X_n) \in \mathcal{P}$, such that*

$$\sup_{P \in \mathcal{P}} \mathbb{E}_P[\mathrm{TV}(\hat{P}, P)^2] \le C\left(\epsilon^2 + \frac{1}{n}\log N(\mathcal{P}, \mathrm{TV}, \epsilon)\right) \tag{32.45}$$

对于作为距离的损失函数，获得适当估计量的一个自然想法是 *minimum distance estimator*。在当前情境下，我们计算经验分布到模型类 $\mathcal{P}$：[6] 上的最小距离投影。

$$P_{\text{min-dist}} = \operatorname*{argmin}_{P \in \mathcal{P}} \mathrm{TV}(\hat{P}_n, P)$$

其中 $\hat{P}_n = \frac{1}{n}\sum_{i=1}^n \delta_{X_i}$ 是经验分布。然而，由于经验分布是离散的，如果 $\mathcal{P}$ 的元素具有密度，这种策略就没有意义。这种退化的原因在于总变差距离过强。关键思想是用一个代理来替换 TV，该代理只检查“低复杂度”的集合族，而不是比较所有可测集上的两个分布。

为此，令$\mathcal{A} \subset \mathcal{E}$为一个稍后指定的可测集的有限集合。定义一个伪距离

$$\mathsf{dist}(P, Q) \triangleq \sup_{A \in \mathcal{A}} |P(A) - Q(A)|. \tag{32.46}$$

(注意，如果 $\mathcal{A} = \mathcal{E}$，那么这仅仅是 TV。) 可以验证 dist 满足三角不等式。因此，估计量

$$\tilde{P} \triangleq \operatorname*{argmin}_{P \in \mathcal{P}} \mathsf{dist}(P, \hat{P}_n), \tag{32.47}$$

作为最小化器，满足

$$\mathsf{dist}(\tilde{P}, P) \le \mathsf{dist}(\tilde{P}, \hat{P}_n) + \mathsf{dist}(P, \hat{P}_n) \le 2\mathsf{dist}(P, \hat{P}_n). \tag{32.48}$$

6 在此处及下文，若最小值不存在，我们可以用下确界序列替代。

此外，应用二项式尾部界限和联合界限，我们有

$$\mathbb{E}[\mathsf{dist}(P,\hat{P}_n)^2] \le \frac{C_0 \log |\mathcal{A}|}{n}. \tag{32.49}$$

对于某个绝对常数 C_0。

Yatracos [465] 的主要思想归结为对 $\mathcal{A}$ 的以下选择：考虑 TV 中 $\mathcal{P}$ 的 ϵ-覆盖 $\{Q_1,\dots,Q_N\}$。定义集合

$$A_{ij} \triangleq \left\{x : \frac{dQ_i}{d(Q_i+Q_j)}(x) \ge \frac{dQ_j}{d(Q_i+Q_j)}(x)\right\}$$

以及该集合（称为 *Yatracos class*）

$$\mathcal{A} \triangleq \{A_{ij} : i \ne j \in [N]\}. \tag{32.50}$$

然后相应的 dist 在 $\mathcal{P}$ 上近似 TV，其意义是

$$\mathsf{dist}(P,Q) \le \mathrm{TV}(P,Q) \le \mathsf{dist}(P,Q) + 4\epsilon, \qquad \forall P,Q \in \mathcal{P}. \tag{32.51}$$

要验证这一点，我们只需证明上界。对于任意 $P,Q \in \mathcal{P}$，存在 $i,j \in [N]$，使得 $\mathrm{TV}(P,P_i) \le \epsilon$ 且 $\mathrm{TV}(Q,Q_j) \le \epsilon$。根据关键观察 $\mathsf{dist}(Q_i,Q_j) = \mathrm{TV}(Q_i,Q_j)$，我们有

$$\begin{aligned}
\mathrm{TV}(P,Q) &\le \mathrm{TV}(P,Q_i) + \mathrm{TV}(Q_i,Q_j) + \mathrm{TV}(Q_j,Q)\\
&\le 2\epsilon + \mathsf{dist}(Q_i,Q_j)\\
&\le 2\epsilon + \mathsf{dist}(Q_i,P) + \mathsf{dist}(P,Q) + \mathsf{dist}(Q,Q_j)\\
&\le 4\epsilon + \mathsf{dist}(P,Q).
\end{aligned}$$

最后，我们分析估计量(32.47)，其中$\mathcal{A}$由(32.50)给出。应用(32.51)和(32.48)可得

$$\begin{aligned}
\mathrm{TV}(\tilde{P},P) &\le \mathsf{dist}(P,\tilde{P}) + 4\epsilon\\
&\le 2\mathsf{dist}(P,\hat{P}_n) + 4\epsilon.
\end{aligned}$$

将两边平方，取期望值并应用(32.49)，我们得到

$$\mathbb{E}[\mathrm{TV}(\tilde{P},P)^2] \le 32\epsilon^2 + 8\mathbb{E}[\mathsf{dist}(P,\hat{P}_n)^2] \le 32\epsilon^2 + \frac{8C_0\log|N|}{n}.$$

选择最优的TV覆盖完成了(32.45)。

注32.5（稳健版本）注意，即使模型被错误指定，即数据生成分布P位于$\mathcal{P}$之外（但接近），Yatracos的方案思想仍然有效。实际上，记Q^* =为argmin $_{Q\in\{Q_i\}}$ TV(P,Q)，并注意到

$$\mathsf{dist}(Q^*,\hat{P}_n) \le \mathsf{dist}(Q^*,P) + \mathsf{dist}(P,\hat{P}_n) \le \mathrm{TV}(P,Q^*) + \mathsf{dist}(P,\hat{P}_n)\,,$$

由于对于任意一对分布都有 $\mathsf{dist}(Q,Q') \le \mathrm{TV}(Q,Q')$。然后我们有：

$$\mathrm{TV}(\tilde{P},P) \le \mathrm{TV}(\tilde{P},Q^*) + \mathrm{TV}(Q^*,P) = \mathsf{dist}(\tilde{P},Q^*) + \mathrm{TV}(Q^*,P)$$

$$\begin{aligned}
&\le \mathsf{dist}(\tilde{P}, \hat{P}_n) + \mathsf{dist}(\hat{P}_n, P) + \mathsf{dist}(P, Q^*) + \mathrm{TV}(Q^*, P) \\
&\le \mathsf{dist}(Q^*, \hat{P}_n) + \mathsf{dist}(\hat{P}_n, P) + 2\mathrm{TV}(P, Q^*) \\
&\le 2\mathsf{dist}(P, \hat{P}_n) + 3\mathrm{TV}(P, Q^*) .
\end{aligned}$$

由于 $3\mathrm{TV}(P, Q^*) \le 3\epsilon + 3 \min_{P' \in \mathcal{P}} \mathrm{TV}(P, P')$，我们可以看到该估计量在“误设定情形”下也有效。出乎意料的是，如果要求估计量是正常的（在 $\mathcal{P}$ 内），乘数 3 无法改进，参见 [70]。

32.4 Hölder类上的密度估计

本节我们将讨论光滑性约束下的非参数密度估计这一经典问题。根据定理27.14，为简洁起见，记$\mathcal{F} \equiv \mathcal{F}_\beta(1,1)$为在单位立方体$[0,1]^d$上$\beta$-光滑密度$f$的集合，其中$d$为某常数。（在这种情况下，参数就是密度$f$本身，因此我们将不再写出参数化形式。）给定 $X_1, \cdots, X_n \overset{\text{i.i.d.}}{\sim} f \in \mathcal{F}$，未知密度$f$的估计量是一个函数$\hat{f}(\cdot) = \hat{f}(\cdot;\ X_1, \ldots, X_n)$。我们首先考虑传统的二次风险$\|f - \hat{f}\|_2^2 = \int_0^1 (f(x) - \hat{f}(x))^2$。然后我们将陈述Hellinger风险、KL风险和全变差风险的结果。

定理 32.17 *Given $X_1, \cdots, X_n \overset{i.i.d.}{\sim} f \in \mathcal{F}$, the minimax quadratic risk over $\mathcal{F}$ satisfies*

$$R^*_{L_2}(n; \mathcal{F}) \triangleq \inf_{\hat{f}} \sup_{f \in \mathcal{F}} \mathbb{E} \|f - \hat{f}\|_2^2 \asymp n^{-\frac{2\beta}{2\beta + d}}. \tag{32.52}$$

利用第27.4节中研究的平滑密度的度量熵，我们将通过应用定理32.1中的熵上界和基于Fano不等式的定理31.3中的极小极大下界来证明这一结果。然而，定理32.17涉及的是L_2风险而非KL风险。这可以通过一个简单的归约来修正。

引理 32.18 *Let $\mathcal{F}'$ denote the collection of $f \in \mathcal{F}$ which is bounded from below by $1/2$. Then*

$$R^*_{L_2}(n; \mathcal{F}') \le R^*_{L_2}(n; \mathcal{F}) \le 4R^*_{L_2}(n; \mathcal{F}').$$

Proof. 左侧不等式成立是因为 $\mathcal{F}' \subset \mathcal{F}$。对于右侧不等式，我们采用模拟论证。固定某个 $f \in \mathcal{F}$，我们观察到 $X_1, \ldots, X_n \overset{\text{i.i.d.}}{\sim} f$。让我们从 $[0,1]^d$ 中独立且均匀地采样 $U_1, \ldots, U_n$。定义

$$Z_i = \begin{cases} U_i & \text{w.p. } \frac{1}{2}, \\ X_i & \text{w.p. } \frac{1}{2}. \end{cases}$$

然后 $Z_1, \ldots, Z_n \overset{\text{i.i.d.}}{\sim} g = \frac{1}{2}(1 + f) \in \mathcal{F}'$。令 $\hat{g}$ 为一个在 $\mathcal{F}'$ 上达到极小极大风险 $R^*_{L_2}(n;\ \mathcal{F}')$ 的估计量。考虑估计量 $\hat{f} = 2\hat{g} - 1$。则 $\|f - \hat{f}\|_2^2 = 4\|g - \hat{g}\|_2^2$。对 $f \in \mathcal{F}$ 取上确界证明 $R^*_{L_2}(n;\ \mathcal{F}) \le 4R^*_{L_2}(n;\ \mathcal{F}')$。 □

引理32.18允许我们关注子集合$\mathcal{F}'$，其中每个密度下界为1/2。此外，$\mathcal{F}$中的每个β平滑密度也上界为一个绝对常数。因此，KL散度和平方L_2距离在$\mathcal{F}'$上实际上是等价的，即，

$$D(f\|g) \asymp \|f-g\|_2^2, \quad f,g \in \mathcal{F}', \tag{32.53}$$

如下引理所示：

引理 32.19 *Suppose both $f = \frac{dP}{d\mu}$ and $g = \frac{dQ}{d\mu}$ are upper and lower bounded by absolute constants c and C respectively. Then*

$$\frac{1}{4C}\int d\mu (f-g)^2 \le H^2(P,Q) \le D(P\|Q) \le \chi^2(P\|Q) \le \frac{1}{c}\int d\mu (f-g)^2.$$

Proof. 对于上界，应用(7.34)，$D(P\|Q) \le \chi^2(P\|Q) = \int d\mu \frac{(f-g)^2}{g} \le \frac{1}{c}\int d\mu \frac{(f-g)^2}{g}$。对于下界，应用(7.33)，$D(P\|Q) \ge H^2(P,Q) = \int d\mu \frac{(f-g)^2}{(\sqrt{f}+\sqrt{g})^2} \ge \frac{1}{4C}\int d\mu (f-g)^2$。

□

我们现在证明定理32.17：

Proof. 鉴于引理32.18，只需考虑$R^*_{L_2}(n;\mathcal{F}')$。对于上界，我们有

$$\begin{aligned} R^*_{L_2}(n;\mathcal{F}') &\overset{\text{(a)}}{\asymp} R^*_{\mathrm{KL}}(n;\mathcal{F}') \\ &\overset{\text{(b)}}{\lesssim} \inf_{\epsilon>0}\left\{\epsilon^2 + \frac{1}{n}\log N_{\mathrm{KL}}(\mathcal{F}',\epsilon)\right\} \\ &\overset{\text{(c)}}{\asymp} \inf_{\epsilon>0}\left\{\epsilon^2 + \frac{1}{n}\log N(\mathcal{F}',\|\cdot\|_2,\epsilon)\right\} \\ &\overset{\text{(d)}}{\asymp} \inf_{\epsilon>0}\left\{\epsilon^2 + \frac{1}{n\epsilon^{d/\beta}}\right\} \asymp n^{-\frac{2\beta}{2\beta+d}}. \end{aligned}$$

其中 (a) 和 (c) 均适用（32.53），因此对于 KL 和 L_2 距离，风险和度量熵都是等价的；(b) 由定理 32.1 得出；(d) 应用了定理 27.14 中 Lipschitz 类的度量熵（在 L_2 下），以及子类 $\mathcal{F}'$ 的度量熵至多为全类 $\mathcal{F}$ 的度量熵这一事实。

对于下界，我们应用Fano不等式。应用定理27.14以及定理27.2中覆盖数与填充数之间的关系，我们得到$\log N(\mathcal{F},\|\cdot\|_2,\epsilon) \asymp \log M(\mathcal{F},\|\cdot\|_2,\epsilon) \asymp \epsilon^{-d/\beta}$。固定$\epsilon$待定，并令$f_1,\dots,f_M$为$\mathcal{F}$中的一个$\epsilon$-填充，其中$M \ge \exp(C\epsilon^{-d/\beta})$。那么$g_1,\dots,g_M$是$\mathcal{F}'$中的一个$\frac{\epsilon}{2}$-填充，且有$g_i = (f_i+1)/2$。应用定理31.3中的Fano不等式，我们得到

$$R^*_{L_2}(n;\mathcal{F}') \gtrsim \epsilon^2\left(1 - \frac{C'_n}{\log M}\right) \tag{32.54}$$

其中 C_n' 是从 $f \in \mathcal{F}'$ 到 $X_1, \ldots, X_n \overset{\text{i.i.d.}}{\sim} f$ 的容量（或 KL 半径）。利用 (32.17) 和引理 32.19，我们有

$$C_n' \le \text{下确界}_{\epsilon>0}(n\epsilon^2 + \text{对数} N_{\text{KL}}(\mathcal{F}', \epsilon)) \asymp \text{下确界}_{\epsilon>0}(n\epsilon^2 + \text{对数} N(\mathcal{F}', \|\cdot\|_2, \epsilon)) \lesssim \text{下确界}_{\epsilon>0}(n\epsilon^2 + \epsilon^{-\beta}) \asymp n^{\frac{2\beta}{2\beta+d}}.$$

因此，选择 $\epsilon = cn^{-\frac{\beta}{2\beta+d}}$ 使得 c 足够小，可确保 $C_n' \le \frac{1}{2}\log M$，从而 $R^*_{L_2}(n;\ \mathcal{F}') \gtrsim \epsilon^2 \asymp n^{-\frac{2\beta}{2\beta+d}}$。 □

注32.6 上述基于Fano不等式及小互信息意味着大估计误差这一直观理解的下界证明，需要我们为子集合$\mathcal{F}'$的容量C_n'设定上界。另一方面，正如早前在(32.11)中暗示（并在接下来展示），风险预期与$\frac{C_n'}{n}$成正比，这表明应使用度量熵来下界容量。确实，这是可行的：应用定理32.5,

$$\begin{aligned} C_n' &\gtrsim \min\{n\epsilon^2, \log M(\mathcal{F}', H, \epsilon)\} - 2 \\ &\asymp \min\{n\epsilon^2, \log M(\mathcal{F}', \|\cdot\|_2, \epsilon)\} - 2 \\ &\asymp \min\{n\epsilon^2, \epsilon^{-d/\beta}\} - 2 \asymp n^{d/(2\beta+d)}, \end{aligned}$$

其中我们选取了与前一证明中相同的 ϵ。因此 $C_n' \asymp n^{d/(2\beta+d)}$。最后，应用命题 32.7 中的在线到批量转换 (32.26)（或等价地，结合 (32.7) 与 (32.9)）得到 $R^*_{\text{KL}}(n;\ \mathcal{F}') \asymp \frac{C_n'}{n} \asymp n^{-\frac{2\beta}{2\beta+d}}$。

注 32.7 上述定理 32.17 的证明依赖于熵风险界(32.1)，尽管该界是速率最优的，但并未被计算有效的估计量所达到。（同样的批评也适用于 Hellinger 距离和全变差距离下的 (32.2) 和 (32.3)。）为弥补这一点，对于平方损失，一个经典的想法是应用核密度估计（KDE）——参见第 7.9 节。具体而言，人们计算经验分布 $\hat{P}_n = \frac{1}{n}\sum_{i=1}^n \delta_{X_i}$ 与核函数 $K(\cdot)$ 的卷积，其形状和带宽根据平滑约束来选择。例如，对于 Lipschitz 密度，定理 32.17 中的最优速率可以通过带宽为 $h = n^{-1/3}$ (的盒核 $K(\cdot) = \frac{1}{2h}1\{|\cdot| \le h\}$ 达到，参见例如 [424, 第 1.2 节])。

密度估计的经典文献主要关注 L_2 损失，这主要是因为损失函数具有方便的二次性质，使得偏差-方差分解成为可能，并便于分析 KDE。然而，密度之间的 L_2 距离没有明确的 operational 含义。接下来我们考虑本章开头引入的三种 f 散度损失。与定理 32.17 平行地，我们有

$$R^*_{\text{TV}}(n;\mathcal{F}) \triangleq \inf_{\hat{f}}\sup_{f\in\mathcal{F}} \mathbb{E}\,\text{TV}(f,\hat{f}) \asymp n^{-\frac{\beta}{2\beta+d}} \tag{32.55}$$

$$R^*_{H^2}(n;\mathcal{F}) \triangleq \inf_{\hat{f}}\sup_{f\in\mathcal{F}} \mathbb{E}\,H^2(f,\hat{f}) \asymp n^{-\frac{\beta}{\beta+d}} \tag{32.56}$$

$$n^{-\frac{\beta}{\beta+d}} \lesssim R^*_{\text{KL}}(n;\mathcal{F}) \triangleq \inf_{\hat{f}}\sup_{f\in\mathcal{F}} \mathbb{E}\,D(f\|\hat{f}) \asymp n^{-\frac{\beta}{\beta+d}}(\log n)^{\frac{d}{\beta+d}} \tag{32.57}$$

对于TV损失，上界由定理32.17中的L_2速率和$\|f-\hat{f}\|_1 \le \|f-\hat{f}\|_2$通过柯西-施瓦茨不等式得出；另外，我们也可以应用定理32.16中的Yatracos估计量。

利用基于Fano方法的相同论证，可以展示匹配的下界，因为在{v*}-距离下的度量熵行为相同（定理27.14）。

回想一下，对于 L_2/L_1，率是通过考虑一个子类 $\mathcal{F}'$ 得出的，该子类具有相同的估计率，但在该子类上 $L_p \asymp H \asymp \mathrm{KL}$，参见引理 32.18。因此，当 Birgé [54] 发现全族 $\mathcal{F}$ 上的 Hellinger 率不同时，令人惊讶。

为了推导 H^2 结果（32.56），首先注意，无论是上界还是下界，都不能由 (7.22) 中的通用比较不等式 $\frac{H^2}{2} \le \mathrm{TV} \le H$ 推出。相反，有效的方法是通过第一个不等式来比较熵数。具体而言，我们有

$$\log N(\mathcal{F}, H, \epsilon) \le \log N(\mathcal{F}, \mathrm{TV}, \epsilon^2/2) \lesssim \epsilon^{-\frac{2d}{\beta}}, \tag{32.58}$$

其中在最后一步我们应用了定理27.14。将此与Le Cam-Birgé方法（定理32.9）结合，证明了(32.56)的上界部分。[7]

下界遵循与定理32.17证明中类似的论证，尽管构造更为复杂。下面$c_0, c_1, \ldots$是绝对常数。固定一个小量ϵ，并考虑密度下界为ϵ的子集$\mathcal{F}' = \{f \in \mathcal{F}: f \ge \epsilon\}$。我们首先构造$\mathcal{F}'$的一个Hellinger填充。应用引理32.13中的相同论证，得到L_∞-局部球内的一个L_2-填充：存在$f_0, f_1, \ldots, f_M \in \mathcal{F}$，使得对于所有$i \ne j$有$\|f_i - f_j\|_2 \ge c_0\epsilon$，对于所有$i$有$\|f_i - f_0\|_\infty \le \epsilon$，且$M \ge M(\mathcal{F}, \|\cdot\|_2, c_0\epsilon)/M(\mathcal{F}, \|\cdot\|_\infty, \epsilon) \ge \exp(c_1\epsilon^{-d/\beta})$，最后一步对充分小的$c_0$应用定理32.17。令$h_i = f_i - f_0$，并定义$f_i$为$f_i(x) = \epsilon + h_i(2x)$，对于$x \in [0, \frac{1}{2}]^d$，并在其他地方光滑地延拓$f_i$，使其成为$\mathcal{F}'$中的有效密度。于是$f_1, \ldots, f_M$构成$\mathcal{F}'$的一个Hellinger $\Omega(\sqrt{\epsilon})$-填充，因为$H^2(f_i, f_j) \ge \int_{[0,\frac{1}{2}]^d} \frac{(f_i - f_j)^2}{(\sqrt{f_i} + \sqrt{f_j})^2} \ge c_2\epsilon$。（这一构造也表明度量熵界(32.58)是紧的。）接下来需要将$\mathcal{F}'$的容量C_n'界定为n和ϵ的函数。注意对于任意$f, g \in \mathcal{F}'$，如引理32.19中那样有$D(f\|g) \le \chi^2(f\|g) \le \|f - g\|_2^2/\epsilon$。因此$N_{\mathrm{KL}}(\mathcal{F}', \delta^2/\epsilon) \le N(\mathcal{F}', \|\cdot\|_2, \delta)$。应用(32.17)和引理32.19，$C_n' \lesssim \inf_{\delta > 0}(n\delta^2/\epsilon + \delta^{-d/\beta}) \asymp (n/\epsilon)^{d/(2\beta+d)}$。如(32.54)中那样应用Fano不等式，得到平方Hellinger意义下的一个$\Omega(\epsilon)$下界，只要$\log M \ge 2C_n'$。这通过选择$\epsilon = c_3 n^{-\frac{\beta}{\beta+d}}$实现，从而完成(32.56)的证明。

对于KL损失，(32.57)的下界由(32.56)得出，因为$D \ge H^2$。对于上界，应用定理32.1中的(32.7)，我们得到$R^*_{\mathrm{KL}}(n; \mathcal{F}) \le \frac{C_{n+1}}{n+1}$，其中$C_n$是$f$与$X^n \overset{\text{i.i.d.}}{\sim} f \in \mathcal{F}$之间信道的容量(32.5)。这个容量可以依次通过Hellinger熵利用定理32.6来界定。结合(32.22)应用(32.58)，我们得到$C_n \le \inf_\epsilon(n\epsilon^2 \log\frac{1}{\epsilon} + \epsilon^{-2d/\beta}) \asymp (n \log n)^{d/(d+\beta)}$，证明了上界(32.57)。[8] 据我们所知，解决(32.57)中的对数差距仍然是一个开放问题。

[7] Comparing (32.56) with (32.52), we see that the Hellinger rate coincides with the L_2 rate upon replacing the smoothness parameter β by $\beta/2$. Note that Hellinger distance is the L_2 between root-densities. For $\beta \le 1$, one can indeed show that $\sqrt{f}$ is $\beta/2$-Hölder continuous, which explains the result in (32.56). However, this interpretation fails for general β. For example, Glaeser [191] constructs an infinitely differentiable f such that $\sqrt{f}$ has points with arbitrarily large second derivative.

[8] This capacity bound is tight up to logarithmic factors. Note that the construction in the proof of the lower bound in (32.56) shows that $\log M(\mathcal{F}, H, \epsilon) \gtrsim \epsilon^{-2d/\beta}$, which, via Theorem 32.5, implies that $C_n \ge n^{d/(d+\beta)}$.

33 Strong data processing inequality

在本章中，我们探讨以下效应的统计学意义。对于任意马尔可夫链

$$U \to X \to Y \to V \tag{33.1}$$

我们从数据处理不等式（DPI，定理3）可知 .7）那个

$$I(U;Y) \le I(U;X), \qquad I(X;V) \le I(Y;V)\,.$$

然而，通常可以得出更强的结论。即，如果马尔可夫链(33.1)通过一个 *known* 噪声信道 $P_{Y|X}: \mathcal{X} \to \mathcal{Y}$ 分解，那么我们往往可以证明强数据处理不等式(SDPI):

$$I(U;Y) \le \eta I(U;X), \qquad I(X;V) \le \eta^{(p)} I(Y;V)\,,$$

其中系数 $\eta = \eta(P_{Y|X}), \eta^{(p)} = \eta^{(p)}(P_{Y|X}) < 1$ 仅取决于信道，而不依赖于（通常未知或非常复杂的）$P_{U,X}$ 或 $P_{Y,V}$。对于噪声很大的信道，系数 η 和 $\eta^{(p)}$ 趋近于0（例如，η 总是等于信道的 Hellinger 平方直径乘以一个常数因子）。

本章的目的有两个。首先，我们想要介绍SDPI系数的一般性质。其次，我们想要展示SDPI如何帮助证明统计估计问题上的尖锐下界（不可能性）。本章中统计问题的风格与本书其余部分不同，因为在这里，关于未知参数 θ 的信息在高维观测向量上要么比经典 $X = \theta + Z$ 类型任务更“*thinly spread*”（参见尖峰Wigner和树着色示例），要么分布在不同的终端上（如相关性和均值估计示例）。

我们指出，SDPIs 是当前研究的一个领域，而本文的简短阐述并未涵盖多个主题。欲了解更多，我们推荐综述 [345] 和 [352]，其中后者探讨了 SDPIs 的函数论方面及其与对数 Sobolev 不等式的密切关系——这是我们在书中完全省略的主题。

33.1 使用噪声门计算布尔函数

一个具有n个输入的布尔函数被定义为f: $\{0,1\}^n \to \{0,1\}$。请注意，布尔函数可以描述为图33.1所示的三种基本逻辑门构成的网络。

1938年，香农展示了如何用图33.1顶行的原始逻辑门[377]来表示任何布尔函数f。20世纪50年代，约翰·冯·诺依曼正在奠定

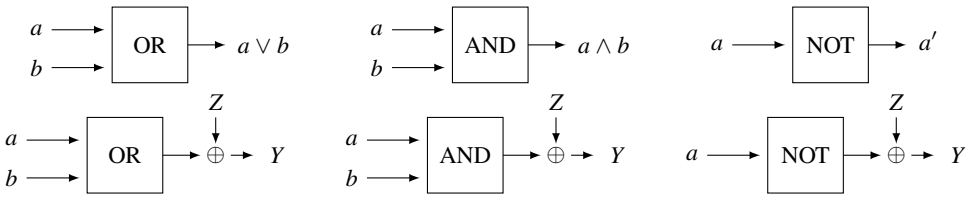


图 33.1 任何布尔电路的基本构建模块。顶行展示了经典的（香农）无噪声门。底行展示了有噪声的（冯·诺依曼）门。这里假设 $Z \sim \mathrm{Ber}(\delta)$ 与输入独立。

为数字计算机奠定了基础，而他被以下问题所困扰。既然真实的物理（和生物）网络由不完美的元素组成，如果组成的基础门实际上是有噪声的，我们能否计算任何布尔函数f？他对δ-噪声门（图33.1底行）的模型是取一个原始无噪声门，并对输出施加（模2）加性噪声。

在这种情况下，我们有一个噪声门网络，这样的网络必然具有噪声（非确定性）输出。因此，当我们说一个噪声门电路 C 计算 f 时，我们要求存在某个不能依赖于 f) 的 $\epsilon_0 = \epsilon_0(\delta)$ (，使得

$$\mathbb{P}[C(x_1,\ldots,x_n) \neq f(x_1,\ldots,x_n)\big) \leq \frac{1}{2} - \epsilon_0 \tag{33.2}$$

其中 $C(x_1,\ldots,x_n)$ 是输入为 $x_1,\ldots,x_n$ 的噪声电路的输出。如果我们按照经典（香农）方法构建电路，显然会出现灾难性的误差累积，以至于深电路必然有 $\epsilon_0 \to 0$。与此同时，冯·诺伊曼被这样一个事实所困扰：显然我们的大脑使用非常嘈杂的门进行操作，却能够进行非常长的计算而不出错。他的思考最终得出了以下开创性的结果。

定理 33.1 (冯·诺依曼 [443]) *There exists $\delta^* > 0$ such that for all $\delta < \delta^*$ it is possible to compute every boolean function f via δ-noisy 3-majority gates.*

von Neumann 最初的估计 $\delta^* \approx 0.087$ 后来被 Pippenger 改进。该领域的主要（仍然未解决的）问题是找到上述定理成立的最大 δ^*。

(33.2)中的条件意味着输出应与输入相关。这要求输入（如果它们是随机的）与输出之间的互信息大于零。我们现在给出Evans和Schulman的一个定理，该定理给出了任何输入与输出之间互信息的上界。我们将在第33.3节中作为更一般的 *directed information percolation*理论的结果来证明该定理。

定理 33.2 ([158]) *Suppose an n-input noisy boolean circuit composed of gates with at most K inputs and with noise components having at most δ probability of error. Then, the mutual*

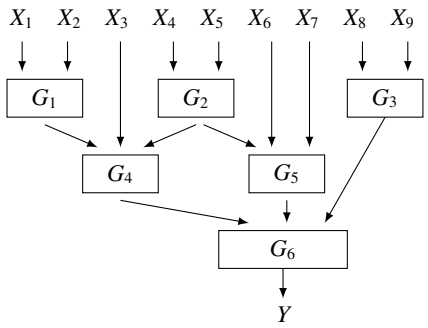


图33.2 一个9输入布尔电路的例子

information between any input X_i and output Y is upper bounded as

$$I(X_i;Y) \leq \left(K(1-2\delta)^2\right)^{d_i} \log 2$$

where d_i is the minimum length between X_i and Y (i.e, the minimum number of gates required to be passed through until reaching Y).

定理 33.2 表明，噪声计算仅在 $\delta < \frac{1}{2} - \frac{1}{2\sqrt{K}}$ 的情况下可行。这是已知的最佳阈值。为说明这一结果，考虑图 33.2 中的电路。该电路有 9 个输入，由至多 3 个输入的门组成。3 输入门为 G_4、G_5 和 G_6。X_3 与 Y 之间的最小距离为 $d_3 = 2$，X_5 与 Y 之间的最小距离为 $d_5 = 3$。若 G_i 为 δ 噪声门，则我们可以在任意输入与输出之间应用定理 33.2。

现在，定理33.2的主要概念意义在于证明，除非δ足够小，否则某些电路无法用δ-噪声门计算。例如，取$f(X_1,\ldots,X_n) = \mathrm{XOR}(X_1,\ldots,X_n)$。注意函数$f$本质上依赖于每个输入$X_i$，因为$\mathrm{XOR}(X_1,\ldots,X_n) = \mathrm{XOR}\left(\mathrm{XOR}(X_1,\ldots,X_{i-1},X_{i+1},\ldots,X_n),X_i\right)$。因此，任何忽略任何一个输入$X_i$的电路都无法满足要求（33.2）。由于我们通过$K$-输入门组合电路，这意味着必须存在至少一个输入$X_i$，其中$d_i \geq \frac{\log n}{\log K}$(确实，从$Y$向上，我们在每个门处做出$K$-元选择，因此在高度$d$处我们最多可以达到$d^K$个输入)。现在，当$n \to \infty$我们从定理33.2看到$I(X_i;Y) \to 0$除非

$$\delta \leq \delta^*_{ES} = \frac{1}{2} - \frac{1}{2\sqrt{K}}\,.$$

正如我们论证的 $I(X_i;\ Y) \to 0$ 与满足(33.2)不相容。因此，δ^*_{ES} 的值给出了（目前最严格的）噪声上限，在此限制下，使用 K 输入门进行可靠计算是可能的。

使用公式进行计算 请注意，图33.2中给出的图结构包含一些无向环。*formula*是一种不含任何无向环的布尔电路类型，与图33.2的情况不同。换句话说，对于公式而言，其底层图结构形成一棵树。例如，移除图33.2中G_2的一个输出，我们便得到了图33.3所示的公式。

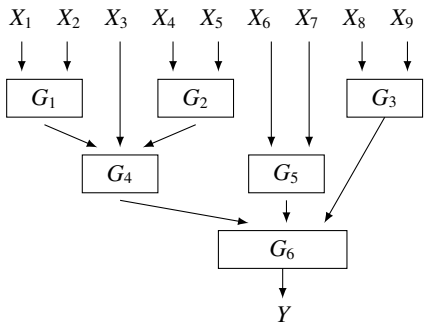


图33.3 一个9输入布尔公式的示例

对于使用公式的计算，可获得更强的结果。例如，对于任意奇数 K，阈值从 [157, 定理1] 中精确已知。具体而言，那里展示了如果 $\delta < \delta_f^*$，我们可以可靠地计算任何由 K-输入 δ-噪声门（其中 K 为奇数）组成的公式所表示的布尔函数 f，而对于 $\delta > \delta_f^*$ 则不可能进行此类计算，其中

$$\delta_f^* = \frac{1}{2} - \frac{2^{K-1}}{K\binom{K-1}{\frac{K-1}{2}}}$$

由于每个公式也是一个电路，我们当然有 $\delta_f^* < \delta_{ES}^*$，因此与定理33.2没有矛盾。然而，比较阈值使我们能够认识到定理33.2对于一般布尔电路的紧致性。实际上，对于大的 K，我们有一个近似

$$\delta_f^* \approx \frac{1}{2} - \frac{\sqrt{\pi/2}}{2\sqrt{K}}, K \gg 1,$$

而Evans-Schulman $\delta_{ES}^* \approx \frac{1}{2} - \frac{1}{2\sqrt{K}}$的估计。因此我们可以看到，对于大的$K$，它至少具有收敛到$1/2$的正确速率。

33.2 强数据处理不等式

定义 33.3（$P_{Y|X}$ 的收缩系数）对于一个固定的条件分布（或核）$P_{Y|X}$，定义

$$\eta_f(P_{Y|X}) = \sup \frac{D_f(P_Y\|Q_Y)}{D_f(P_X\|Q_X)}, \tag{33.3}$$

其中 $P_Y = P_{Y|X} \circ P_X$、$Q_Y = P_{Y|X} \circ Q_X$ 且上确界取遍所有满足 $0 < D_f(P_X\|Q_X) < \infty$ 的配对 (P_X, Q_X)。

回忆一下，定理7.4中的数据加工不等式（DPI）表明 $D_f(P_X\|Q_X) \geq D_f(P_Y\|Q_Y)$。上述引入的强DPI概念量化了两个$f$-散度之间的乘法衰减。

我们注意到，通常情况下$\eta_f(P_{Y|X})$的计算是困难的。然而，全变分是一个例外。

定理 33.4 ([127]) $\eta_{\mathrm{TV}} = \sup_{x\neq x'} \mathrm{TV}(P_{Y|X=x}, P_{Y|X=x'})$.

Proof. 我们分别考虑两个方向。

- η电视 $\geq$ 上标$_{x_0\neq x_0'}$ 电视$(P_{Y|X=x_0}, P_{Y|X=x_0'})$:

  这种情况是显而易见的。取 $P_X = \delta_{x_0}$ 和 $Q_X = \delta_{x_0'}$。[1] 那么根据 η_{TV} 的定义，我们有 $\eta_{\mathrm{TV}} \geq \mathrm{TV}(P_{Y|X=x_0}, P_{Y|X=x_0'})$ 对于任何 x_0 和 x_0'，$x_0 \neq x_0'$。
- $\eta_{\mathrm{TV}} \leq \sup_{x_0\neq x_0'} \mathrm{TV}(P_{Y|X=x_0}, P_{Y|X=x_0'})$:

  定义 $\tilde{\eta} \triangleq$ 的上确界 $_{x_0\neq x_0'}$ 为 $\mathrm{TV}(P_{Y|X=x_0}, P_{Y|X=x_0'})$。为简化起见，我们考虑离散字母表情形。固定任意 P_X、Q_X 及 $P_Y = P_X \circ P_{Y|X}$、$Q_Y = Q_X \circ P_{Y|X}$。观察到对于任意 $E \subseteq \mathcal{Y}$

$$P_{Y|X=x_0}(E) - P_{Y|X=x_0'}(E) \leq \tilde{\eta} 1\{x_0 \neq x_0'\}. \tag{33.4}$$

  现在假设有随机变量 X_0 和 X_0' 分别具有某些边缘分布 P_X 和 Q_X。考虑任何耦合 $\pi_{X_0,X_0'}$，其边缘分布分别为 P_X 和 Q_X。然后对 (33.4) 取平均并在 E 上取上确界，我们得到

$$\sup_{E\subseteq\mathcal{Y}} P_Y(E) - Q_Y(E) \leq \tilde{\eta}\pi[X_0 \neq X_0']$$

  现在，根据定理7.7(a)，左侧等于$\mathrm{TV}(P_Y, Q_Y)$。对耦合π取下确界，右侧根据定理7.7(b)计算得出$\mathrm{TV}(P_X, Q_X)$。

□

例33.1（二元对称信道的η_{TV}）BSC_δ的η_{TV}由下式给出

$$\begin{aligned}\eta_{\mathrm{TV}}(\mathsf{BSC}_\delta) =& \mathrm{TV}(\mathrm{Bern}(\delta), \mathrm{Bern}(1-\delta))\\ =& \frac{1}{2}\big(|\delta - (1-\delta)| + |1-\delta-\delta|\big) = |1-2\delta|.\end{aligned}$$

有时我们希望将η_f与f-信息（第7.8节）联系起来，而不是f-散度。这个关系在以下定理中给出。

定理 33.5

$$\eta_f(P_{Y|X}) = \sup_{P_{UX}:\ U\to X\to Y} \frac{I_f(U;Y)}{I_f(U;X)}.$$

[1] δ_{x_0} 是概率分布，$\mathbb{P}(X = x_0) = 1$

回想一下，对于任何马尔可夫链 $U \to X \to Y$，DPI 表明 $I_f(U;\ Y) \le I_f(U;\ X)$，并且定理33.5给出了更强的界限

$$I_f(U;Y) \le \eta_f(P_{Y|X}) I_f(U;X). \tag{33.5}$$

Proof. 首先，注意到对于任意 u_0，我们有 $D_f(P_{Y|U=u_0}\|P_Y) \le \eta_f D_f(P_{X|U=u_0}\|P_X)$。将上述表达式对任何 P_U 取平均，我们得到

$$I_f(U;Y) \le \eta_f I_f(U;X)$$

其次，固定$\tilde{P}_X$、$\tilde{Q}_X$并令$U \sim \text{Bern}(\lambda)$对于某个$\lambda \in [0,1]$。定义条件分布$P_{X|U}$为 $P_{X|U=1} = \tilde{P}_X$，$P_{X|U=0} = \tilde{Q}_X$。取$\lambda \to 0$，则（技术细节见[345]）

$$I_f(U;X) = \lambda D_f(\tilde{P}_X\|\tilde{Q}_X) + o(\lambda)$$
$$I_f(U;Y) = \lambda D_f(\tilde{P}_Y\|\tilde{Q}_Y) + o(\lambda)$$

比率 $\frac{I_f(U;Y)}{I_f(U;X)}$ 将收敛到 $\frac{D_f(\tilde{P}_Y\|\tilde{Q}_Y)}{D_f(\tilde{P}_X\|\tilde{Q}_X)}$。因此，通过对 $\tilde{P}_X$ 和 $\tilde{Q}_X$ 进行优化，我们可以得到任意接近 η_f 的 I_f 的比例。 □

我们接下来陈述收缩系数的一些基本性质。

定理 33.6 *In the statements below η_f (and others) corresponds to $\eta_f(P_{Y|X})$ for some fixed $P_{Y|X}$ from $\mathcal{X}$ to $\mathcal{Y}$.*

(a) For any f, $\eta_f \le \eta_{TV}$.

(b) $\eta_{\text{KL}} = \eta_{\chi^2}$. More generally, for any operator-convex and twice continuously differentiable f we have $\eta_f = \eta_{\chi^2}$.

(c) η_{χ^2} equals the squared maximal correlation: Denote by $\rho(A,B) \triangleq \frac{\text{Cov}(A,B)}{\sqrt{\text{Var}[A]\,\text{Var}[B]}}$ the correlation coefficient between scalar random variables A and B. Then $\eta_{\chi^2} = \sup_{P_X, f, g} \rho^2(f(X), g(Y))$, where the supremum is over all distributions P_X on $\mathcal{X}$, all functions $f: \mathcal{X} \to \mathbb{R}$ and $g: \mathcal{Y} \to \mathbb{R}$.

(d) For binary-input channels, denote $P_0 = P_{Y|X=0}$ and $P_1 = P_{Y|X=1}$. Then

$$\eta_{\text{KL}} = \text{LC}_{\max}(P_0, P_1) \triangleq \sup_{0<\beta<1} \text{LC}_\beta(P_0\|P_1)$$

where (recall $\bar{\beta} \triangleq 1-\beta$)

$$\text{LC}_\beta(P\|Q) = D_f(P\|Q), \quad f(x) = \bar{\beta}\beta\frac{(1-x)^2}{\bar{\beta}x + \beta}$$

is the Le Cam divergence of order β (recall (7.7) for $\beta = 1/2$).

(e) Consequently,

$$\frac{1}{2}H^2(P_0,P_1) \le \eta_{\text{KL}} \le H^2(P_0,P_1) - \frac{H^4(P_0,P_1)}{4}. \tag{33.6}$$

(f) If a binary-input channel $P_{Y|X}$ is also input-symmetric (or BMS, see Section 19.4), then $\eta_{\text{KL}}(P_{Y|X}) = I_{\chi^2}(X;\ Y)$ for $X \sim$ Bern(1/2).*

(g) *For any channel $P_{Y|X}$, the supremum in* (33.3) *can be restricted to P_X, Q_X with a common binary support. In other words, $\eta_f(P_{Y|X})$ coincides with that of the least contractive binary subchannel. Consequently, from* (e) *we conclude*

$$\frac{1}{2}\mathrm{diam}_{H^2} \le \eta_{\mathrm{KL}}(P_{Y|X}) = \mathrm{diam}_{\mathrm{LC}_{\max}} \le \mathrm{diam}_{H^2} - \frac{\mathrm{diam}_{H^2}}{4}\,,$$

(in particular $\eta_{\mathrm{KL}} \asymp$ 直径$_{H^2}$), where 直径$_{H^2}(P_{Y|X})$ $=$ 上确界$_{x,x'\in\mathcal{X}}$ $H^2(P_{Y|X=x}, P_{Y|X=x'})$, 直径$_{\mathrm{LC}_{\max}}$ $=$ 上确界$_{x,x'}$ $\mathrm{LC}_{\max}(P_{Y|X=x}, P_{Y|X=x'})$ *are the squared Hellinger and Le Cam diameters of the channel.*

Proof. 大多数完全一般性的证明可以在 [345] 中找到。对于(a)，首先证明对应于 $f(x) = |x-\gamma|_+ - |1-\gamma|_+$ 的所谓 $\mathcal{E}_\gamma$ 散度有 $\eta_f \le \eta_{\mathrm{TV}}$，这一点不难相信，因为 $\mathcal{E}_\gamma$ 是分段线性的。然后一般结果由以下事实得出：任意凸函数 f 可以按如下形式近似（作为 $N\to\infty$ ）

$$\sum_{j=1}^{N} a_j|x-c_j|_+ + a_0 x + c_0\,.$$

关于 (b)，参见 [93，定理 1] 和 [97，命题 II.6.13 及推论 II.6.16]。 此证明的思路如下：

• $\eta_{\mathrm{KL}} \ge \eta_{\chi^2}$ 通过限制于局部扰动。回顾KL散度局部表现为 χ^2 – 命题2.21。 • 利用恒等式 $D(P\|Q) = \int_0^\infty \chi^2(P\|Q_t)dt$ 其中 $Q_t = \frac{tP+Q}{1+t}$，我们有

$$D(P_Y\|Q_Y) = \int_0^\infty \chi^2(P_Y\|Q_{Y_t})dt \le \eta_{\chi^2}\int_0^\infty \chi^2(P_X\|Q_{X_t})dt = \eta_{\chi^2} D(P_X\|Q_X).$$

对于(c)，我们固定Q_X (进而固定$Q_{X,Y} = Q_X P_{Y|X}$)。若$g = \frac{dP_X}{dQ_X}$，则$Tg(y) = \frac{dP_Y}{dQ_Y} = \mathbb{E}_{Q_{X|Y}}[g(X)|Y=y]$是一个线性算子。此时，$\eta_{\chi^2}(P_{Y|X})$不过是$T$: $L_2(Q_X) \to L_2(Q_Y)$在限制于线性子空间$\{h\colon \mathbb{E}_{Q_X}[h]=0\}$时的最大奇异值（谱范数的平方）。$T$的伴随是$T^* h(x) = \mathbb{E}_{P_{Y|X}}[h(Y)|X=x]$。一个算子及其伴随的谱范数相等，而$T^*$的谱范数恰好是最大相关性的平方。这两个事实结合便得出结果。（参见定理33.12(c)，它对于固定的P_X强化了这一结果。）

第(d)部分由$\eta_{\chi^2} = \sup_{\alpha,\beta} \frac{\chi^2(\alpha P_1 + \bar\alpha P_0\|\beta P_1 + \bar\beta P_0)}{\chi^2(\mathrm{Ber}(\alpha)\|\mathrm{Ber}(\beta))}$的定义及一些代数运算得出。

接下来，(e) 可由借助柯西-施瓦茨不等式等对 $\mathrm{LC}_{\max}$ 以 H^2 为界的界定得出；参见 [345，附录 B]。

第(f)部分源于这样一个事实：每个BMS信道都可以表示为$X \mapsto Y = (Y_\Delta, \Delta)$，其中$\Delta \in [0, 1/2]$与$X$和$Y_\delta = \mathsf{BSC}_\delta(X)$独立。换言之，每个BMS信道都是BSC的混合；参见[360, 第4.1节]。因此，对于任意$U \to X \to Y = (Y_\Delta, \Delta)$和$\Delta \perp\!\!\!\perp (U, X)$，我们有以下链

$$I(U;Y) = I(U;Y|\Delta) \le \mathbb{E}_{\delta\sim P_\Delta}[(1-2\delta)^2 I(U;X|\Delta=\delta)] = \mathbb{E}[(1-2\Delta)^2] I(U;X),$$

其中我们使用了$I(U;\ X|\Delta=\delta)=I(U;\ X)$以及下面的例33.2。对于(g),
见练习VI.20。 □

例 33.2（计算 $\eta_{\mathrm{KL}}(\mathsf{BSC}_\delta)$）考虑 BSC_δ 信道。在例 33.1 中我们计算了 η_{TV}。这里我们有 $\mathrm{diam}_{H^2}=2-4\sqrt{\delta(1-\delta)}$，因此由界 (33.6) 我们得到 $\eta_{\mathrm{KL}}\le(1-2\delta)^2$。另一方面，取 $U=\mathrm{Ber}(1/2)$ 和 $P_{X|U}=\mathrm{Ber}(\alpha)$，我们得到

$$\eta_{\mathrm{KL}}\ge\frac{I(U;Y)}{I(U;X)}=\frac{\log 2-h(\alpha+(1-2\alpha)\delta)}{\log 2-h(\alpha)}\to(1-2\delta)^2\qquad\alpha\to\frac{1}{2}\,.$$

因此我们已经证明:

$$\eta_{\mathrm{KL}}(\mathsf{BSC}_\delta)=\eta_{H^2}(\mathsf{BSC}_\delta)=\eta_{\chi^2}=(1-2\delta)^2.$$

这个例子对于KL散度几何具有以下影响。

命题 33.7 *Consider any distributions P_0 and P_1 on $\mathcal{X}$ and let us consider the interval in $\mathcal{P}(\mathcal{X})$: $P_\lambda=\lambda P_1+(1-\lambda)P_0$ for $\lambda\in[0,1]$. Then divergence (with respect to the midpoint) behaves subquadratically:*

$$D(P_\lambda\|P_{1/2})+D(P_{1-\lambda}\|P_{1/2})\le(1-2\lambda)^2\{D(P_0\|P_{1/2})+D(P_1\|P_{1/2}))\,.$$

The same statement holds with D replaced by $\chi 2$ (and any other D_f satisfying Theorem 33.6(b)*).*

Proof. 令 $X\sim$ 服从 $\mathrm{Ber}(1/2)$ 且 $Y=\mathsf{BSC}_\lambda(X)$。令 $U\leftarrow X\to Y$ 的定义为，若 $X=$ 为 0 则取 $U\sim P_0$，若 $X=$ 为 1 则取 $U\sim P_1$。那么

$$I_f(U;Y)=\frac{1}{2}D_f(P_\lambda\|P_{1/2})+\frac{1}{2}D_f(P_\lambda\|P_{1/2})\,.$$

因此，应用SDPI (33.5) 即完成了证明。 □

注33.1 让我们引入$d_{\mathrm{JS}}(P,Q)=\sqrt{\mathrm{JS}(P,Q)}$和$d_{\mathrm{LC}}=\sqrt{\mathrm{LC}(P,Q)}$——即Jensen-Shannon(7.8)和Le Cam(7.7)度量。那么命题可重述为

$$d_{\mathrm{JS}}(P_\lambda,P_{1-\lambda})\le|1-2\lambda|d_{\mathrm{JS}}(P_0,P_1)$$
$$d_{\mathrm{LC}}(P_\lambda,P_{1-\lambda})\le|1-2\lambda|d_{\mathrm{LC}}(P_0,P_1)\,.$$

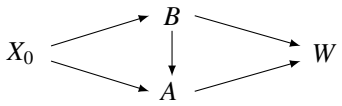
注意，对于由所有带符号测度向量空间$\mathcal{M}(\mathcal{X})$上的范数（如TV）在$\mathcal{P}(\mathcal{X})$上诱导出的任何度量$d(P,Q)$，我们必然有$d(P_\lambda,P_{1-\lambda})=|1-2\lambda|d(P_0,P_1)$。因此，产生该不等式的$\eta_{\mathrm{KL}}(\mathsf{BSC}_\lambda)=(1-2\lambda)^2$是相当自然的。

33.3 定向信息渗透

在本节中，我们关注的是有向无环图（DAG）$G=(V,E)$中所经历的信息衰减量。在以下上下文中，顶点集V指的是一个顶点集合v，每个顶点关联一个随机变量X_v，而边集E指的是一个有向边集合

其配置允许我们通过以下方式对X_V上的联合分布进行因式分解。在本节中，我们考虑香农互信息，即$f = x \log x$。下面给出一个详细的例子。

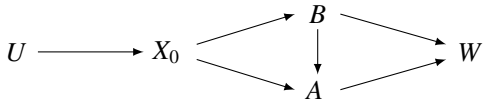
例 33.3 假设我们有一个如图所示的图 $G = (V, E)$。



这意味着我们有一个联合分布，其因式分解为：

$$P_{X_0,A,B,W} = P_{X_0} P_{B|X_0} P_{A|B,X_0} P_{W|A,B}\,.$$

然后每个节点都有一个从父节点到自身的信道，例如W对应于一个有噪信道$P_{W|A,B}$，我们可以定义$\eta \triangleq \eta_{\mathrm{KL}}(P_{W|A,B})$。现在，在开头添加另一个随机变量$U \sim \mathrm{Bern}(\lambda)$，新图$G' = (V', E')$如下所示：



我们想要验证关系

$$I(U; B, W) \le \bar{\eta} I(U; B) + \eta I(U; A, B). \tag{33.7}$$

回想由链式法则我们有 $I(U;\ B, W) = I(U;\ B) + I(U;\ W|B) \ge I(U;\ B)$。因此，如果 (33.7) 正确，则 $\eta \to 0$ 意味着 $I(U;\ B, W) \approx I(U;\ B)$ 并且对称地 $I(U;\ A, W) \approx I(U;\ A)$。因此对于小的 δ，观察 W, A 或 W, B 并不比分别仅观察 A 或 B 更有优势。

注意，G' 形成一个马尔可夫链 $U \to X_0 \to (A, B) \to W$，这允许我们将 E' 上的联合分布分解为

$$P_{U,X_0,A,B,W} = P_U P_{X_0|U} P_{A,B|X_0} P_{W|A,B}.$$

现在考虑以$B = b$为条件的联合分布，即$P_{U,X_0,A,W|B}$。我们断言条件马尔可夫链 $U \to X_0 \to A \to W|B = b$成立。事实上，给定$B$和$A$，$X_0$独立于$W$，即 $P_{X_0|A,B} P_{W|A,B} = P_{X_0,W|AB}$，由此可得所述条件马尔可夫链。利用该条件马尔可夫链，SDPI 对任意b给出，

$$I(U; W|B = b) \le \eta I(U; A|B = b).$$

对 b 取平均并加上 $I(U;$ 两边同时加上 $B)$，我们得到

$$\begin{aligned} I(U; W, B) &\le \eta I(U; A|B) + I(U; B) \\ &= \eta I(U; A, B) + \bar{\eta} I(U; B). \end{aligned}$$

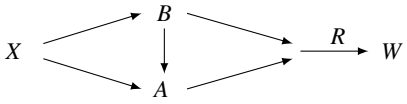


图33.4 例33.4的示意图。

根据定理33.5中对η_f的描述，我们得出

$$\eta_{\mathrm{KL}}(P_{W,B|X_0}) \le \eta \cdot \eta_{\mathrm{KL}}(P_{A,B|X_0}) + (1-\eta) \cdot \eta_{\mathrm{KL}}(P_{B|X_0}) . \tag{33.8}$$

现在，我们提供另一个例子，其在某种意义上与例33.3有类似的设置。

例 33.4（渗流）对例 33.3 中的图 $G = (V, E)$ 稍作修改。见图 33.4。现在，假设 X、A、B、W 是一些城市，边集 E 表示这些城市之间的道路。令 R 为一个随机变量，表示与 W 相连的道路的状态，其中 $\mathbb{P}(R \text{ 是开通的}) = \eta$，而 $\mathbb{P}[R \text{ 是封闭的}] = \bar{\eta}$。对于任意 $Y \in V$，令事件 $\{X \to Y\}$ 表示可以从 X 行驶到 Y。那么

$$\mathbb{P}[X \to B \text{ or } W] = \eta \mathbb{P}[X \to A \text{ or } B] + \bar{\eta}\mathbb{P}[X \to B]. \tag{33.9}$$

观察(33.8)和(33.9)之间的相似之处。

现在我们将给出一个定理，它在如下设定下将η_{KL}与DAG上的渗流概率联系起来：考虑一个DAG $G = (V, E)$。

• 所有边都是开放的 • 每个顶点以概率 $p(v) = \eta_{\mathrm{KL}}\left(P_{X_v|X_{\mathrm{Pa}(v)}}\right)$ 开放，其中 $\mathrm{Pa}(v)$ 表示 v 的父节点集合。

在该模型下，对于两个子集$T, S \subset V$，我们定义 $\mathrm{perc}[T \to S] = \mathbb{P}[\exists \text{ 开放路径 } T \to S]$。

注意，$P_{X_v|X_{\mathrm{Pa}(v)}}$描述了基于其父变量生成$X_v$的随机过程。我们假设除了DAG之外，我们还被给出了所有这些组成通道（或至少是它们η_{KL}系数的界限）。

定理 33.8（[345]） *Let $G = (V, E)$ be a DAG and let 0 be a node with in-degree equal to zero (i.e. a source node). Note that for any $\emptyset \neq S \subset V$ we can inductively stitch together constituent channels $P_{X_v|X_{Pa(v)}}$ and obtain $P_{X_S|X_0}$. Then we have*

$$\eta_{\mathrm{KL}}(P_{X_S|X_0}) \le perc(0 \to S). \tag{33.10}$$

Proof. 为方便起见，我们记 $\eta(T) = \eta_{\mathrm{KL}}(P_{X_T|X_0})$ 和 $\eta_v = \eta_{\mathrm{KL}}(P_{X_v|X_{\mathrm{Pa}(v)}})$。证明通过对 G 的大小进行归纳。对于 $|V(G)| = 1$，命题显然成立，因为 $S = \emptyset$ 或 $S = \{X_0\}$。现在假设对于所有小于 G 的图，命题已成立。设 v 为 G 中出度为 0 的节点。若 $v \notin S$，则可将其从 G 中排除，命题由归纳假设得证。否则，定义 $S_A = \mathrm{Pa}(v) \setminus S$ 和 $S_B = S \setminus \{v\}$，

$A = X_{S_A}, B = X_{S_B}, W = X_v$。（如果 $0 \in A$，那么我们可以用 $X_{0'} = X_0$ 创建一个伪造的 $0'$，并保留 $0' \in A$，同时将 0 移出 A。因此，不失一般性，$0 \notin A$。）将任意的 U 作为 $U \to X_0$ 前置到图中，随机变量 (X_0, A, B, W) 的联合 DAG 恰好由 (33.7) 中的图给出。因此，我们从 (33.8) 得到估计

$$\eta(S) \le \eta_v \eta(S_A \cup S_B) + (1 - \eta_v)\eta_{\mathrm{KL}}(S_B)\,. \tag{33.11}$$

根据归纳假设 $\eta(S_A \cup S_B) \le \mathrm{perc}(0 \to S_A)$ 和 $\eta(S_B) \le \mathrm{perc}(0 \to S_B)$（它们位于图 $G \setminus \{v\}$ 上）。因此，由计算 (33.9) 可知，(33.11) 的右侧恰好是 $\mathrm{perc}(0 \to S)$，从而如所声称的 $\eta(S) \le \mathrm{perc}(S)$。 □

我们现在可以完成之前推迟的证明了。

Proof of Theorem 33.2. 首先观察到含噪布尔电路是一种DAG形式。由于门是DAG中组成信道η_v的δ-噪声收缩系数，其可以被$(1-2\delta)^2$所界定。因此，在渗流问题中，所有顶点都以概率$(1-2\delta)^2$开放。

从SDPI，对于每个 i，我们有 $I(X_i;\ Y) \le \eta_{\mathrm{KL}}(P_{Y|X_i})H(X_i)$。由定理33.8，我们知道 $\eta_{\mathrm{KL}}(P_{Y|X_i}) \le \mathrm{perc}(X_i \to Y)$。我们现在想要给出 $\mathrm{perc}(X_i \to Y)$ 的上界。回顾 X_i 与 Y 之间的最小距离是 d_i。因此，对于从 X_i 到 Y 的任意长度为 $\ell(\pi)$ 的路径 π，它开放的概率为 $\le (1-2\delta)^{2\ell(\pi)}$。因此我们可以界定

$$\mathrm{perc}(X_i \to Y) \le \sum_{\pi: X_i \to Y} (1-2\delta)^{2\ell(\pi)}\,. \tag{33.12}$$

现在让我们从 Y 开始向后构建路径，这使我们能够将路径 $X \to Y_i$ 表示为以 Y_i 为根的 K 叉树的顶点。通过标记 K 叉树上对应于路径 $X \to Y_i$ 的所有顶点，我们观察到两个事实：标记集 V 是无前缀的（两个标记顶点从不存在祖先关系），且每个标记集的深度至少为 d_i。容易看出，$\sum_{u \in V} c^{\mathrm{depth}(u)} \le (Kc)^{d_i}$ 在 $Kc \le 1$ 的条件下成立，并通过取 V 为树中深度为 d_i 的所有顶点的集合来实现。我们得出结论：当 $K(1-2\delta)^2 \le 1$ 时，(33.12) 的右侧被 $(K(1-2\delta)^2)^{d_i}$ 所界，这通过将 $H(X_i) \le \log 2$ 上界为以下形式完成了证明：

$$I(X_i; Y) \le \eta_{\mathrm{KL}}(P_{Y|X_i})H(X_i) \le K^{d_i}(1-2\delta)^{2d_i}\log 2$$

□

作为定理33.8的另一个（简单）应用，我们展示以下内容。

推论 33.9 *Consider a channel $P_{Y|X}$ and its n-letter memoryless extension $P_{Y|X}^{\otimes n}$. Then we have*

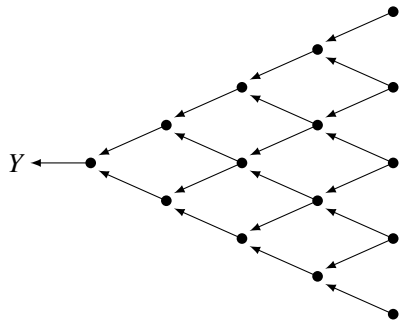
$$\eta_{\mathrm{KL}}(P_{Y|X}^{\otimes n}) \le 1 - (1 - \eta_{\mathrm{KL}}(P_{Y|X}))^n \le n\eta_{\mathrm{KL}}(P_{Y|X})\,.$$

第一个不等式对于某些信道可以取等。例如，当 $P_{Y|X}$ 是二元或 q 元擦除信道（在下面例33.6中定义）时，它可以取等。这一事实在[345，定理17]中得到证明。

Proof. 这里的图由n条平行线$X_i \to Y_i$组成。定理33.8表明，$\eta_{\mathrm{KL}}(P_{Y|X}^{\otimes n}) \le \mathrm{perc}(\{X_1,\dots,X_n\} \to \{Y_1,\dots,Y_n\})$。后者简单地等于$1-(1-\eta)^n$，其中$\eta = \eta(P_{Y|X})$是一条边开放的概率。 □

本节最后给出定理 33.8 的一个更复杂的应用，强调与定理 33.2 相比，它如何能给出更强的界。

例 33.5 假设我们对门的放置有拓扑限制（即每个门的输入必须来自左侧的最近邻），从而得到以下由 2 输入 δ 噪声门组成的电路。



请注意，每个门可以是简单的直通（即充当路由器）或恒定输出。定理33.2指出，如果$(1-2\delta)^2 < \frac{1}{2}$，则在任意拓扑结构内进行噪声计算是不可能的。定理33.8将其改进为$(1-2\delta)^2 < p_c$，其中p_c是我们所讨论特定图的有向站点渗流阈值。即，如果每个顶点以概率$p < p_c$开放，则从任意给定节点出发（并向右延伸）的连通分量以概率1是有限的。对于上述例子，站点渗流阈值估计为$p_c \approx 0.705$（即所谓的Stavskaya自动机）。

33.4 输入相关的SDPI。马尔可夫链的混合

之前我们已经定义了收缩系数 $\eta_f(P_{Y|X})$，作为在所有输入分布上的 f-散度的最大收缩。现在我们针对固定输入分布 P_X 定义一个类似的概念。

定义 33.10（输入相关的收缩系数）对于任何输入分布 P_X、马尔可夫核 $P_{Y|X}$ 和凸函数 f，我们定义

$$\eta_f(P_X, P_{Y|X}) \triangleq \sup \frac{D_f(Q_Y\|P_Y)}{D_f(Q_X\|P_X)}$$

其中 $P_Y = P_{Y|X}\circ P_X$、$Q_Y = P_{Y|X}\circ Q_X$，且上确界取遍满足 $0 < D_f(Q_X\|P_X) < \infty$ 的 Q_X。

我们将 $\eta_f(P_X, P_{Y|X})$ 称为输入依赖的收缩系数，与输入无关的收缩系数 $\eta_f(P_{Y|X})$ 形成对比。显然，

$$\eta_f(P_X, P_{Y|X}) \le \eta_f(P_{Y|X})$$

但如下文所示，该不等式通常是严格的，其差异可在应用中带来显著改进（例33.10）。在定理33.6中我们已经看到，对于大多数有趣的f，我们有$\eta_f(P_{Y|X}) = \eta_{\chi^2}(P_{Y|X})$。遗憾的是，对于依赖于输入的版本，这一点并不成立：我们仅有一个单边比较，即对于任何二阶连续可微的f，且满足$f''(1) > 0$（特别是对于KL散度），有[345，定理2]

$$\eta_{\chi^2}(P_X, P_{Y|X}) \le \eta_f(P_X, P_{Y|X})\,. \tag{33.13}$$

例如，对于联合高斯分布 X, Y，我们实际上有 $\eta_{\chi^2} = \eta_{\mathrm{KL}}$ (参见接下来的例33.7)；然而，一般情况下我们仅有 $\eta_{\chi^2} < \eta_{\mathrm{KL}}$ (参见[19]中的一个例子)。因此，与输入无关的情形不同，这里 f 的选择非常重要。一个通用规则是 $\eta_{\chi^2}(P_X, P_{Y|X})$ 最容易界定，并且根据(33.13)，它收缩得最快。然而，由于各种原因，其他 f 在应用中更为有用。因此，依赖于输入的收缩系数理论要复杂得多（参见[201]以了解许多近期结果和参考文献）。在本节中，我们试图总结 $\eta_f(P_X, P_{Y|X})$ 和 $\eta_f(P_{Y|X})$ 之间的一些重要相似之处和区别。

首先，正如定理33.5中那样，我们可以类似地证明$\eta_{\mathrm{KL}}(P_X, P_{Y|X})$的互信息特征描述如下[352, 定理V.2]:

$$\eta_{\mathrm{KL}}(P_X, P_{Y|X}) = \sup_{P_{U|X}: U\to X\to Y} \frac{I(U;Y)}{I(U;X)}.$$

特别地，我们看到 $\eta_{\mathrm{KL}}(P_X, P_{Y|X})$ 也是 F_I 曲线的斜率（参见定义 16.5）：

$$\eta_{\mathrm{KL}}(P_X, P_{Y|X}) = \left.\frac{d}{dt}\right|_{t=0+} F_I(t; P_{X,Y})\,. \tag{33.14}$$

(事实上，从练习III.32我们知道$F_I(t)$是凹的，因此$\sup_{t\ge 0}\frac{F_I(t)}{t} = F_I'(0)$.)

输入依赖型SDPIs的下一个性质强调了与输入无关型对应物相比的关键差异。回顾推论33.9（及其后的讨论）表明，通常$\eta_{\mathrm{KL}}(P_{Y|X}^{\otimes n}) \to$以指数速度趋于1。同时，$\eta_{\mathrm{KL}}(P_X^{\otimes n}, P_{Y|X}^{\otimes n})$保持不变。

命题 33.11（η_{KL} 的张量积化）

$$\eta_{\mathrm{KL}}(P_X^{\otimes n}, P_{Y|X}^{\otimes n}) = \eta_{\mathrm{KL}}(P_X, P_{Y|X})$$

In particular, if $(X_i, Y_i) \overset{i.i.d.}{\sim} P_{X,Y}$, *then* $\forall P_{U|X^n}$

$$I(U; Y^n) \le \eta_{\mathrm{KL}}(P_X, P_{Y|X}) I(U; X^n)$$

请注意，并非所有η_f都满足张量性。我们将在下文（定理33.12）展示η_{χ^2}确实满足该性质。另一方面，$\eta_{\mathrm{TV}}(P_X^{\otimes n}, P_{Y|X}^{\otimes n}) \to$以指数速度1增长（这可由(7.21)推出）。

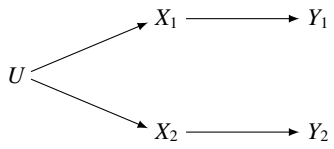


图33.5 命题33.11证明中概率空间的图示。

Proof. 这个结果由(33.14)和练习III.32暗示，但一个简单的直接证明是有用的。不失一般性（通过归纳法），足以证明$n = 2$的命题。始终记住图33.5中的图表是有用的。让 $\eta = \eta_{\mathrm{KL}}(P_X, P_{Y|X})$

$$\begin{aligned} I(U;Y_1,Y_2) &= I(U;Y_1) + I(U;Y_2|Y_1) \\ &\le \eta\,[I(U;X_1) + I(U;X_2|Y_1)] && (33.15)\\ &= \eta\,[I(U;X_1) + I(U;X_2|X_1) + I(U;X_1|Y_1) - I(U;X_1|Y_1,X_2)] && (33.16)\\ &\le \eta\,[I(U;X_1) + I(U;X_2|Y_1)] && (33.17)\\ &= \eta I(U;X_1,X_2) \end{aligned}$$

其中（33.15）是由于在给定Y_1的条件下，$U \to X_2 \to Y_2$仍然是一个马尔可夫链，（33.16）是因为$U \to X_1 \to Y_1$是一个马尔可夫链，而（33.17）则源于即使在给定Y_1的条件下，$X_2 \to U \to X_1$也是一个马尔可夫链这一事实。 □

作为示例，让我们分析擦除信道。

示例 33.6（擦除信道的 $\eta_{\mathrm{KL}}(P_X, P_{Y|X})$） 我们将 EC_τ 定义为以下信道

$$Y = \begin{cases} X & \text{w.p. } 1-\tau \\ ? & \text{w.p. } \tau. \end{cases}$$

考虑任意 $U \to X \to Y$，并定义辅助随机变量 $B = 1\{Y =?\}$。我们有

$$I(U;Y) = I(U;Y,B) = \underbrace{I(U;B)}_{=0,\ \text{since } B \perp\!\!\!\perp U} + I(U;Y|B) = (1-\tau) I(U;X),$$

其中最后一个等式是由于$I(U;\ Y|B=1) = 0$和$I(U;\ Y|B=0) = I(U;\ X)$. 根据$\eta_{\mathrm{KL}}(P_X, P_{Y|X})$的互信息表征，我们有$\eta_{\mathrm{KL}}(P_X, \mathsf{EC}_\tau) = 1-\tau$。注意，通过张量积，我们也有$\eta_{\mathrm{KL}}(P_X^{\otimes n}, \mathsf{EC}_\tau^{\otimes n}) = 1-\tau$。然而，对于非乘积输入测度$\mu$，对$\eta_{\mathrm{KL}}(\mu, \mathsf{EC}_\tau^{\otimes n})$的研究本质上与对$\mu$的Glauber动力学混合的研究一样困难——参见练习VI.26。

关于擦除信道的另一个有趣观察是，即使对于均匀输入分布，我们也可能有

$$\eta_{\mathrm{KL}}(P_Y, P_{X|Y}) > \eta_{\mathrm{KL}}(P_X, P_{Y|X}) = 1-\tau$$

(至少对于 $\tau > 0.74$，参见例33.14)。因此，即使对于这样简单的信道，η_{KL}也不是对称的。这与η_{χ^2}形成对比，如下所示。

在依赖于输入的η_f中，最优雅的是η_{χ^2}理论。这些性质对一般的$P_{X,Y}$成立，但为简单起见，我们仅陈述有限情形。

定理 33.12 ($\eta_{\chi^2}(P_X, P_{Y|X})$ 的性质) *Consider finite $\mathcal{X}$ and $\mathcal{Y}$. Then, we have*

(a) (Spectral characterization) Let $M_{x,y} = \frac{P_{X,Y}(x,y)}{\sqrt{P_X(x)P_Y(y)}}$ be an $|\mathcal{X}| \times |\mathcal{Y}|$ matrix. Let $1 = \sigma 1(M) \geq \sigma_2(M) \geq \cdots \geq 0$ be the singular values of M, i.e. $\sigma_j(M) = \sqrt{\lambda_j(M^T M)}$. Then $\eta_{\chi^2}(P_X, P_{Y|X}) = \sigma_2^2(M)$.

(b) (Symmetry) $\eta_{\chi^2}(P_X, P_{Y|X}) = \eta_{\chi^2}(P_Y, P_{X|Y})$.

(c) (Maximal correlation) $\eta_{\chi^2}(P_X, P_{Y|X}) = \sup_{g_1, g_2} \rho(g_1(X), g_2(Y))$, where the supremum is over all functions $g_1 : \mathcal{X} \to \mathbb{R}$ and $g_2 : \mathcal{Y} \to \mathbb{R}$.

(d) (Tensorization) $\eta_{\chi^2}(P_X^{\otimes n}, P_{Y|X}^{\otimes n}) = \eta_{\chi^2}(P_X, P_{Y|X})$

Proof. 我们关注谱特征，因为它蕴含了其余部分。用 $\mathbb{E}_{X|Y}$ 表示作用于函数 g 的线性算子，其作用为 $\mathbb{E}_{X|Y} g(y) = \sum_x P_{X|Y}(x|y) g(x)$。对于任意 Q_X，令 $g(x) = \frac{Q_X(x)}{P_X(x)}$，则有 $\frac{Q_Y(y)}{P_Y(y)} = \mathbb{E}_{X|Y} g$。因此，我们有

$$\eta_{\chi^2}(P_X, P_{Y|X}) = \sup_g \frac{\mathrm{Var}_{P_Y}[\mathbb{E}_{X|Y} g]}{\mathrm{Var}_{P_X}[g]}$$

在所有 $g \geq 0$ 和 $\mathbb{E}_{P_X}[g] = 1$ 上取上确界。我们断言这个上确界也等于

$$\eta_{\chi^2}(P_X, P_{Y|X}) = \sup_h \frac{\mathbb{E}_{P_Y}[\mathbb{E}_{X|Y}^2 h]}{\mathbb{E}_{P_X}[h^2]},$$

对所有 h 取 $\mathbb{E}_{P_X} h = 0$。事实上，对于任何这样的 h，我们可以取 $g = 1 + \epsilon h$，对于某个足够小的 ϵ (以满足 $g \geq 0$)，反之，对于任何 g，我们可以设定 $h = g - 1$。最后，让我们重新参数化 $\phi_x \triangleq \sqrt{P_X(x)} h(x)$，在这种情况下我们得到

$$\eta_{\chi^2}(P_X, P_{Y|X}) = \sup_\phi \frac{\phi^T M^T M \phi}{\phi^T \phi},$$

其中 ϕ 遍历 $\mathbb{R}^{\mathcal{X}}$ 中所有与向量 ψ 正交的向量，且满足 $\psi_x = \sqrt{P_X(x)}$。最后，我们注意到 M 的最大奇异值对应于奇异向量 ψ，因此限制 $\phi \perp \psi$ 可以得到第二大奇异向量。

对称性来自于注意到，当我们交换X和Y时，矩阵M被M^T所替代。最大相关性的刻画源于这样一个事实：$\sup_{g_2} \frac{\mathbb{E}[g_1(X)g_2(Y)]}{\sqrt{\mathrm{Var}[g_2(Y)]}}$在$g_2 = \mathbb{E}_{X|Y} g_1$处达到。张量化则源自这样一个事实：克罗内克积$M^{\otimes n}$的奇异值仅仅是$M$奇异值的所有可能的$n$元组乘积。

□

例33.7（联合高斯的SDPI常数）设X, Y为相关系数ρ的联合高斯分布。那么

$$\eta_{\chi^2}(P_X, P_{Y|X}) = \eta_{\mathrm{KL}}(P_X, P_{Y|X}) = \rho^2.$$

事实上，众所周知，X与Y的最大相关性简单地为$|\rho|$。（这可通过找到定理33.12(a)中定义的(Mehler)核的特征值来证明；参见例如[266]。）应用定理33.12(c)可得$\eta_{\chi^2}(P_X, P_{Y|X}) = \rho^2$。

接下来，鉴于 (33.13)，只需证明 $\eta_{\mathrm{KL}} \le \rho^2$，这是 EPI 的一个简单推论。不失一般性，让我们考虑 $Y = X + Z$，其中 $X \sim P_X = \mathcal{N}(0,1)$ 且 $Z \sim \mathcal{N}(0, \sigma^2)$。然后 $P_Y = \mathcal{N}(0, 1+\sigma^2)$ 和 $\rho^2 = \frac{1}{1+\sigma^2}$。设 $\tilde{X}$ 具有有限二阶矩和有限微分熵，并令 $\tilde{Y} = \tilde{X} + Z$。应用 Lieb 的 EPI (3.36)，其中 $U_1 = \tilde{X}, U_2 = Z/\sigma$ 和 $\cos^2\alpha = \frac{1}{1+\sigma^2}$，我们得到

$$h(\tilde{Y}) \ge \frac{1}{1+\sigma^2} h(\tilde{X}) + \frac{\sigma^2}{2(1+\sigma^2)} \log(2\pi e) + \frac{1}{2}\log(1+\sigma^2)$$

这意味着$D(P_{\tilde{Y}} \| P_Y) \le \frac{1}{1+\sigma^2} D(P_{\tilde{X}} \| P_X)$符合要求。

在进入统计应用之前，我们提到一个非常重要的概率应用。

例 33.8（马尔可夫链的混合）输入依赖的收缩系数找到大量应用的一个领域是估计马尔可夫链的混合时间（达到平衡的时间）。实际上，假设 $K = P_{Y|X}$ 是时间齐次马尔可夫链 $X_0 \to X_1 \to \cdots$ 的核，其平稳分布为 π (，即 $K = P_{X_{t+1}|X_t}$)。那么对于任何初始分布 q，SDPI 给出以下界限：

$$D_f(qP^n \| \pi) \le \eta_f(\pi, K)^n D_f(q\|\pi)\,,$$

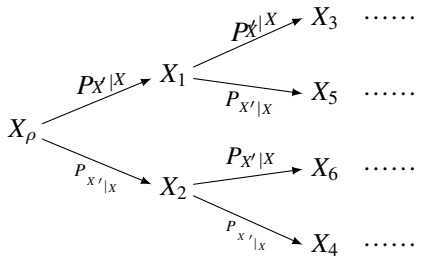
显示 D_f 的指数衰减，只要 $\eta_f(\pi, K) < 1$。对于大多数有趣的链，TV 版本是无用的，但 χ^2 和 KL 相当有效（这两种分别称为谱隙和 *modified log-Sobolev inequality* 方法）。例如，对于可逆马尔可夫链，我们有 [124，命题 3]

$$\chi^2(P_{X_n} \| \pi) \le \gamma_*^{2n} \chi^2(P_{X_0} \| \pi) \tag{33.18}$$

其中γ_*是P的绝对谱隙。参见练习VI.19。用于界定η_{KL}的最有效现代方法被称为 *spectral independence*，参见练习VI.26。

33.5 应用：树上的广播与着色

考虑一棵无限的 b 叉树 $G = (\mathcal{V}, \mathcal{E})$。我们为每个 $v \in \mathcal{V}$ 分配一个随机变量 X_v。这些随机变量 X_v 定义在同一个字母表 $\mathcal{X}$ 上。在这个模型中，联合分布由根顶点 π 上的分布诱导，即 $X_\rho \sim \pi$，以及边核 $P_{X'|X}$，即 $\forall (p,c) \in \mathcal{E}, P_{X_c|X_p} = P_{X'|X}$。



为了简化我们的讨论中，我们将假设 π 是 k 上的可逆测度 ernal $P_{X'|X}$，即，

$$P_{X'|X}(a|b)\pi(b) = P_{X'|X}(b|a)\pi(a). \tag{33.19}$$

根据马尔可夫链的标准结果，这也意味着 π 是反向马尔可夫核 $P_{X|X'}$ 的一个平稳分布。

这个被称为 {v*} 的模型实际上相当深奥。它最初出现在统计物理学中，作为晶格上伊辛模型的一种简化（在物理学中，树被称为贝特晶格）[63]。随后，人们发现它与计算生物学中的系统发育重建问题密切相关[306]，并且几乎同时出现在随机约束满足问题[261]和稀疏图编码理论中。我们自己的兴趣是由树上的重建与随机块模型中的 *community detection* 之间存在某种等价性的发现所引发的[307, 119]。

我们做出以下观察：

- 我们可以将此模型视为一个广播场景，其中根节点通过噪声信道$P_{X'|X}$向其叶节点广播消息X_ρ。此处条件(33.19)仅是为了避免定义反向信道。通常，只需π是$P_{X'|X}$的一个平稳分布，在这种情况下，(33.21)应替换为$\eta_{\mathrm{KL}}(\pi, P_{X|X'})b < 1$。

- 在假设(33.19)下，这棵树的联合分布也可以写成吉布斯分布

$$P_{X_{all}} = \frac{1}{Z}\exp\left(\sum_{(p,c)\in\mathcal{E}} f(X_p, X_c) + \sum_{v\in\mathcal{V}} g(X_v)\right), \tag{33.20}$$

  其中 Z 是归一化常数，$f(x_p, x_c) = f(x_c, x_p)$ 是对称的。当 $\mathcal{X} = \{0, 1\}$ 时，此模型被称为（树上的）Ising模型。然而请注意，并非每个如(33.20)那样分解（具有对称的 f）的测度都能表示为某些 P 和 π 的广播过程。

broadcasting on trees 是一个推断问题，我们希望根据观测 $X_{L_d} = \{X_v\colon\ v \in L_d\}$ 重构根变量 X_ρ，其中 $L_d = \{v\colon\ v \in \mathcal{V}, \text{深度}(v) = d\}$。一个自然的问题是为此问题中任何推断算法的性能设定上界。以下定理表明，存在一个相变，取决于分支因子 b 和核的收缩系数 $P_{X'|X}$。

定理 33.13 *Consider the broadcasting problem on infinite b-ary tree ($b > 1$), with root distribution π and edge kernel $P_{X'|X}$. If π is a reversible measure of $P_{X'|X}$ such that*

$$\eta_{\mathrm{KL}}(\pi, P_{X'|X})b < 1, \tag{33.21}$$

then $I(X_\rho; X_{L_d}) \to 0$ as $d \to 0$.

Proof. 对于每个 $v \in L_1$，我们定义集合 $L_{d,v} = \{u\colon\ u \in L_d, v \in \mathrm{ancestor}(u)\}$。我们可以给出根顶点与深度为 d 的叶子之间互信息的上界

$$I(X_\rho; X_{L_d}) \le \sum_{v \in L_1} I(X_\rho; X_{L_{d,v}}).$$

对于求和中的每一项，我们考虑马尔可夫链

$$X_{L_{d,v}} \to X_v \to X_\rho.$$

由于我们对π和$P_{X'|X}$的假设，我们得到$P_{X_\rho|X_v} = P_{X'|X}$和$P_{X_v} = \pi$。根据压缩系数的定义，我们得出

$$I(X_{L_{d,v}}; X_\rho) \le \eta_{\mathrm{KL}}(\pi, P_{X'|X}) I(X_{L_{d,v}}; X_v).$$

注意，因为 $P_{X_v} = \pi$ 以及所有边具有相同的核，所以 $I(X_{L_{d,v}};\ X_v) = I(X_{L_{d-1}};\ X_\rho)$。这给出了不等式

$$I(X_\rho; X_{L_d}) \le \eta_{\mathrm{KL}}(\pi, P_{X'|X}) b I(X_\rho; X_{L_{d-1}}),$$

这意味着

$$I(X_\rho; X_{L_d}) \le (\eta_{\mathrm{KL}}(\pi, P_{X'|X})b)^d H(X_\rho).$$

因此，若 $\eta_{\mathrm{KL}}(\pi, P_{X'|X})b < 1$，则 $I(X_\rho;\ X_{L_d}) \to$ 以指数速度趋近于 0，当 $d \to \infty$。 □

注意，该定理的一个较弱版本（当 $\eta_{\mathrm{KL}}(P_{X'|X})b \le 1$ 时无法重建）可由有向信息渗透定理推出。k 着色示例（见下文）表明这种强化是必要的；详情见 [203]。

例 33.9 (BSC 树上的广播。) 考虑在 b 叉树上的广播问题，顶点字母表为 $\mathcal{X} = \{0, 1\}$，边核为 $P_{X'|X} = \mathsf{BSC}_\delta$，且 $\pi = \mathrm{Unif}$。注意均匀分布是 BSC_δ 的可逆测度。在例 33.2 中，我们计算了 $\eta_{\mathrm{KL}}(\mathsf{BSC}_\delta) = (1-2\delta)^2$。因此，利用定理 33.13，我们可以推断，如果

$$b(1-2\delta)^2 < 1$$

那么随着树的深度趋于无穷大，没有任何推理算法能够恢复根节点。这一结果最初在[63]中得到证明。

示例 33.10（树上的 k-着色）给定一棵 b-叉树，我们通过从所有有效 k-着色的集合中均匀采样来分配一个 k-着色 $X_{v_{all}}$。对于这个模型，我们可以定义一个相应的推断问题，即给定某一深度所有叶子的颜色，即 X_{L_d}，确定根节点的颜色，即 X_ρ。

该问题可以建模为树上的广播问题，其中根分布 π 由 k 种颜色上的均匀分布给出，边核 $P_{X'|X}$ 定义为

$$P_{X'|X}(a|b) = \begin{cases} \frac{1}{k-1} & a \neq b \\ 0, & a = b. \end{cases}$$

可以证明（见练习VI.24），对于大的k，$\eta_{\mathrm{KL}}(\mathrm{Unif}, P_{X'|X}) = \frac{1}{k \log k(1+o(1))}$。根据定理33.13，这意味着如果$b < k \log k(1+o(1))$，则根节点的可靠重构是不可能的。这一结果最初在[393]和[50]中得到证明。

另一个方向 $b > k \log k(1+o(1))$ 可以通过观察得出：如果 $b > k \log k(1+o(1))$，那么一个节点的子节点取所有可用颜色（除了它自己的颜色）的概率接近 1。因此，推断算法总是可以通过找到一个未分配给任何子节点的颜色来确定该节点的颜色。类似地，当 $b > (1+\epsilon)k \log k$ 时，即使只观察节点子节点的 $(1-\epsilon)$ 比例，也足以精确重建其颜色。从下往上递归进行，这种重建算法将以高概率成功。在这种情形下，以正概率（关于叶子变量），根节点颜色的后验分布是一个点质量（确定性的）。这种效应被称为在给定边界时根节点的“冻结”。

我们还可以考虑另一种重建方法，它简单地计算叶子的多数，即对于叶子中出现次数最多的颜色j，取$\hat{X}_\rho = j$。根据Kesten和Stigum[244]的一个著名结果，当且仅当$d > (k-1)^2$时，这种方法的成功概率严格高于$\frac{1}{k}$。虽然阈值并非最优，但该方法相当*robust*，因为它在我们只能访问一小部分叶子ϵ（其余被抹去）的情况下也适用。

现在让我们考虑$\eta_{\chi^2}(\mathrm{Unif}, P_{X'|X})$。转移矩阵是对称的，其特征值为$\{1, -\frac{1}{k-1}\}$，因此根据定理33.12，我们有

$$\eta_{\chi^2}(\mathrm{Unif}, P_{X'|X}) = \frac{1}{(k-1)^2} \ll \eta_{\mathrm{KL}}(\mathrm{Unif}, P_{X'|X}) = \frac{1}{k \log k(1+o(1))}\,.$$

因此，如果定理33.13可以用I_{χ^2}而不是I_{KL}来证明，我们就能够证明对于$d < (k-1)^2$的非重构性，这与上一段的结果相矛盾。问题在于I_{χ^2}不满足次可加性，参见(7.47)。然而，根据[202，引理26]，它是局部次可加的（例如当$I_{\chi^2}(X; A) \ll 1$时）。因此，对于叶子通过非常嘈杂的信道（例如，仅留下ϵ-比例叶子的擦除信道）观察的情况，可以重复定理33.13中的论证。 consequently，着色的鲁棒重构阈值恰好等于$d = (k-1)^2$。关于鲁棒重构阈值的更多内容，请参见[228]。

33.6 应用：分布式相关性估计

张量化性质可用于相关性估计。假设 Alice 观察到 $\{X_i\}_{i\geq 1} \overset{\text{i.i.d.}}{\sim} B(1/2)$，Bob 观察到 $\{Y_i\}_{i\geq 1} \overset{\text{i.i.d.}}{\sim} B(1/2)$，使得 (X_i, Y_i) 是独立同分布的，且 $\mathbb{E}[X_i Y_i] = \rho \in [-1, 1]$。目标是 Bob 用 $H(W) = B$ 比特将 W 发送给 Alice，并且

Alice 用目标估计 $\hat{\rho} = \hat{\rho}(X^\infty, W)$

$$R^*(B) = \inf_{W,\hat{\rho}} \sup_{\rho} \mathbb{E}[(\rho - \hat{\rho})^2].$$

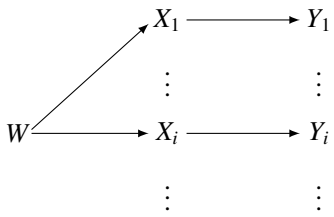
请注意，在这个问题中我们不受样本限制（每一方都有无限多的观察值），但受通信限制（只能交换 B 比特）。

这是一个简单的尝试来解决它。注意，如果Bob发送$W = (Y_1, \ldots, Y_B)$，那么最优估计量是$\hat{\rho}(X^\infty, W) = \frac{1}{n}\sum_{i=1}^{B} X_i Y_i$，其最小最大误差为$\frac{1}{B}$，因此$R^*(B) \le \frac{1}{B}$。令人惊讶的是，这还可以改进。

定理 33.14 ([207]) *The optimal rate when $B \to \infty$ is given by*

$$R^*(X^\infty, W) = \frac{1 + o(1)}{2 \ln 2} \cdot \frac{1}{B}$$

Proof. 修正 {v*}，我们得到以下分解



注意，一旦消息 W 固定，我们就有一个参数估计问题 $\{Q_\rho, \rho \in [-1, 1]\}$，其中 Q_ρ 是 (X^∞, W) 的分布，当 A^∞, B^∞ 是 ρ-相关时。由于我们最小化均方误差，根据 van Trees 不等式（定理 29.2）[2]，我们知道 $R^*(B) \ge \frac{1+o(1)}{\min_\rho J_F(\rho)} \ge \frac{1+o(1)}{J_F(0)}$，其中$J_F(\rho)$是族$\{Q_\rho\}$的Fisher信息。

回想一下，我们还从局部近似中得知

$$D(Q_\rho \| Q_0) = \frac{\rho^2 \log e}{2} J_F(0) + o(\rho^2)$$

此外，请注意在 $\rho = 0$ 下，X^∞ 和 W 是独立的，因此

$$\begin{aligned} D(Q_\rho \| Q_0) &= D(P^\rho_{X^\infty, W} \| P^0_{X^\infty, W}) \\ &= D(P^\rho_{X^\infty, W} \| P^\rho_{X^\infty} \times P^\rho_W) \\ &= I(W; X^\infty) \\ &\le \rho^2 I(W; Y^\infty) \\ &\le \rho^2 B \log 2 \end{aligned}$$

因此$J_F(0) \le (2 \ln 2)B + o(1)$，这又意味着该定理成立。详细内容及Alice与Bob之间交互通信的扩展，请参见[207]。

[2] This requires some technical justification about smoothness of the Fisher information $J_F(\rho)$.

接下来我们转向上界。首先，注意到通过取连续 $m \to \infty$ 位的块并设置 $\tilde{X}_i = \frac{1}{\sqrt{m}} \sum_{j=(i-1)m}^{im-1} X_j$，同样地对 $\tilde{Y}_i$ 进行操作，Alice 和 Bob 可以将 ρ-相关的比特替换为 ρ-相关的标准高斯分布 $(\tilde{X}_i, \tilde{Y}_i) \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0, \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix})$。接着，固定一个非常大的 N 并令

$$W = \operatorname*{argmax}_{1 \le j \le N} Y_j \,.$$

(关于这个想法背后的动机，请参见练习V.16。) 根据标准集中结果，我们知道 $\mathbb{E}[Y_W] = \sqrt{2 \ln N}(1 + o(1))$ (引理27.10) 以及 $\mathrm{Var}[Y_W] = O(\frac{1}{\ln N})$。因此，知道 W 爱丽丝可以估计

$$\hat{\rho} = \frac{X_W}{\mathbb{E}[Y_W]} \,.$$

这是一个无偏估计量，且$\mathrm{Var}_\rho[\hat{\rho}] = \frac{1-\rho^2+o(1)}{2 \ln N}$。最后，设定$N = 2^B$即完成了论证。

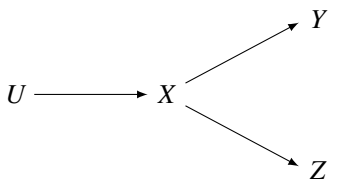
□

33.7 渠道比较：降级、更少噪声、更强大

事实证明，η_{KL} 系数与信道的less noisy偏序概念密切相关。我们将几种这样的偏序一起定义。

定义 33.15（通道上的偏序）设 $P_{Y|X}$ 和 $P_{Z|X}$ 是两个通道。

- 我们称 $P_{Y|X}$ 是 $P_{Z|X}$ 的一个 *degradation*，记作 $P_{Y|X} \le_{\deg} P_{Z|X}$，如果存在 $P_{Y|Z}$ 使得 $P_{Y|X} = P_{Y|Z} \circ P_{Z|X}$。
- 我们称 $P_{Z|X}$ 比 $P_{Y|X}$ 更 *less noisy*，记作 $P_{Y|X} \le_{\ln} P_{Z|X}$，如果对于以下马尔可夫链上的每个 $P_{U,X}$



我们有 $I(U;\ Y) \le I(U;\ Z)$。
- 我们说 $P_{Z|X}$ 比 $P_{Y|X}$ 更 *more capable*，记为 $P_{Y|X} \le_{\mathrm{mc}} P_{Z|X}$，如果对任意 P_X，我们有 $I(X;\ Y) \le I(X;\ Z)$。

我们就这些定义作一些说明，并参考[345]中的证明：: We make some remarks on these definitions and refer to

- $P_{Y|X} \leq_{\deg} P_{Z|X} \implies P_{Y|X} \leq_{\ln} P_{Z|X} \implies P_{Y|X} \leq_{\mathrm{mc}} P_{Z|X}$。反向推演的反例可在 [111，问题 15.11] 中找到。
- 噪声较少关系可以用散度等价地定义，即 $P_{Y|X} \leq_{\ln} P_{Z|X}$ 当且仅当对于所有 P_X, Q_X 我们有 $D(Q_Y\|P_Y) \leq D(Q_Z\|P_Z)$。关于噪声较少序的其他有用刻画，我们参考 [290, Sections I.B, II.A] 和 [345, Section 6]。
- 对于 BMS 信道（见第 19.4* 节），结果表明，在给定 $I_{\chi^2}(X$ 的所有信道中；$Y) = \eta$ (且 $X \sim$ 为 Ber$(1/2)$) 时，BSC 和 BEC 是 $\leq_{\ln}$ 偏序集中的最小元和最大元；详见练习 VI.21。

命题 33.16 $\eta_{\mathrm{KL}}(P_{Y|X}) \leq 1-\tau$ *if and only if* $P_{Y|X} \leq_{\ln} \mathsf{EC}_\tau$*, where* EC_τ *was defined in Example 33.6.*

Proof. 对于 EC_τ，我们始终有

$$I(U;Z) = (1-\tau)I(U;X).$$

根据 η_{KL} 的互信息特征，我们有，

$$I(U;Y) \leq (1-\tau)I(U;X).$$

将这两个不等式结合起来，我们得到

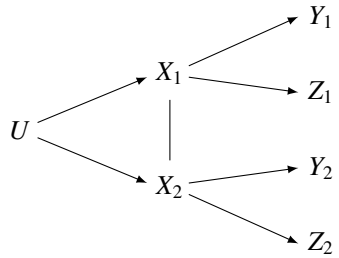
$$I(U;Y) \leq I(U;Z).$$

□

这个命题为我们提供了收缩系数的直观解释，即仍然支配该信道的最差擦除信道。

命题 33.17（噪声更小和性能更强的张量化）*If for all* $i \in [n]$ $, P_{Y_i|X_i} \leq_{ln} P_{Z_i|X_i}$*, then* $\bigotimes_{i\in[n]} P_{Y_i|X_i} \leq_{ln} \bigotimes_{i\in[n]} P_{Z_i|X_i}$.[3] *If for all* $i \in [n], P_{Y_i|X_i} \leq_{mc} P_{Z_i|X_i}$*, then* $\bigotimes_{i\in[n]} P_{Y_i|X_i} \leq_{mc} \bigotimes_{i\in[n]} P_{Z_i|X_i}$.

Proof. 通过归纳，只需考虑 $n=2$ 即可。考虑以下马尔可夫链：



3 我们提醒，$\otimes P_{Y_i|X_i}$ 指的是与 $x^n \mapsto Y^n \sim \prod_i P_{Y_i|X_i=x_i}$ 的乘积（无记忆）信道。

考虑以下不等式，

$$\begin{aligned} I(U;Y_1,Y_2) &= I(U;Y_1) + I(U;Y_2|Y_1) \\ &\le I(U;Y_1) + I(U;Z_2|Y_1) \\ &= I(U;Y_1,Z_2). \end{aligned}$$

因此 $I(U;\ Y_1,Y_2) \le I(U;\ Y_1,Z_2)$ 对于任意 $P_{X_1,X_2,U}$。应用相同的论证，我们可以将 Y_1 替换为 Z_1，得到 $I(U;\ Y_1,Z_2) \le I(U;\ Z_1,Z_2)$，从而完成证明。

关于第二个断言，请注意

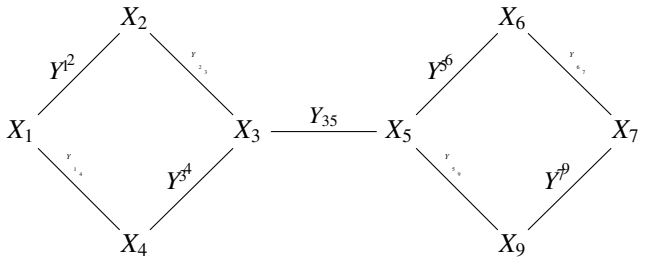
$$\begin{aligned} I(X^2;Y^2) &= I(X_2;Y^2) + I(X_1;Y^2|X_2) \\ &\overset{\text{(a)}}{=} I(X_2;Y_1) + I(X_2;Y_2|Y_1) + I(X_1;Y_1|X_2) \\ &\le I(X_2;Y_1) + I(X_2;Z_2|Y_1) + I(X_1;Z_1|X_2) \\ &= I(X_2;Y_1,Z_2) + I(X_1;Z^2|X_2) \\ &= I(X_2;Z_2) + I(X_2|Y_1|Z_2) + I(X_1;Z^2|X_2) \\ &\le I(X_2;Z_2) + I(X_2|Z_1|Z_2) + I(X_1;Z^2|X_2) = I(X^2;Z^2)\,, \end{aligned}$$

其中等式只是链式法则的应用（在（a）和（b）中，我们还注意到在给定 X_2 的条件下，Y_2 或 Z_2 不提供信息），而两个不等式都是将最强能力关系应用于条件分布。例如，对于每个 y，我们有 $I(X_2;\ Y_2|Y_1=y) \le I(X_2;\ Z_2|Y_1=y)$，因此我们可以对 $y \sim P_{Y_1}$ 求平均。

□

33.8 无向信息渗透

在本节中，我们将研究无向图上的推断问题。考虑一个无向图 $G=(\mathcal{V},\mathcal{E})$。我们为每个顶点 v 分配一个在字母表 $\mathcal{X}$ 上的随机变量 X_v。对于每个 $e=(u,v)\in\mathcal{E}$，我们根据带有 $X_e=(X_u,X_v)$ 的核 $P_{Y_e|X_e}$ 来采样分配 Y_e。该推断模型的目标是在给定 Y_e 的值的情况下确定 X_v 的值。作为直观的说明，我们可以考虑以下图：



例 33.11（社区检测）在这个模型中，我们考虑一个具有 n 个顶点的完全图，即 K_n，以及表示每个顶点所属成员的随机变量 X_v

到 m 社区之一。我们假设 X_v 是从 $[m]$ 中均匀采样，并且与其他顶点独立。观测 $Y_{u,v}$ 定义为

$$Y_{uv} \sim \begin{cases} \mathrm{Ber}(a/n) & X_u = X_v \\ \mathrm{Ber}(b/n) & X_u \neq X_v. \end{cases}$$

例 33.12（$\mathbb{Z}_2$ 同步）对于任意图 G，我们从 $\{-1,+1\}$ 和 $Y_e = \mathsf{BSC}_\delta(X_u X_v)$ 中均匀采样 X_v。

示例 33.13（尖峰 Wigner 模型）我们考虑在给定观测 $(Y_{ij})_{i,j\in[n],i\le j}$ 的情况下估计向量 $(X_i)_{i\in[n]}$ 的推断问题。X_i 和 Y_{ij} 之间的关系由

$$Y_{ij} = \sqrt{\frac{\lambda}{n}} X_i X_j + W_{ij},$$

其中 $\mathrm{X} = (X_1, \ldots, X_n)^\top$ 从 $\{\pm 1\}^n$ 和 $W_{i,j} = W_{j,i} \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0,1)$ 中均匀采样，使得 W 构成一个 Wigner 矩阵（对称高斯矩阵）。该模型也可以写成矩阵形式为

$$\mathbf{Y} = \sqrt{\frac{\lambda}{n}} \mathbf{X}\mathbf{X}^\top + \mathbf{W}$$

作为Wigner矩阵W的秩一扰动，因此得名该模型。它被用作主成分分析的概率模型。

此问题也可以视为无向图上的推断问题。在这种情况下，底层图是一个完全图，我们将X_i分配给第i个顶点。在此模型下，边观测值由$Y_{ij} = \mathsf{BIAWGN}_{\lambda/n}(X_i X_j)$给出，参见例3.4。

尽管表面上看似不同，这些问题都具有以下共同特征，即:

假设33.1 • 每个 X_v 都是均匀分布的。
• 定义辅助随机变量 $B = 1\{X_u \neq X_v\}$ 对于任意边 $e = (u,v)$，以下马尔可夫链成立

$$(X_u, X_v) \to B \to Y_e.$$

换言之，每条边上的观察仅取决于其端点上的随机变量是否相似。

由于假设 33.1，重建的 X_v 在 $\mathcal{X}$ 的任意置换下是对称的。在字母表 $\mathcal{X} = \{-1,+1\}$ 的情况下，这意味着对于任何实现 σ，则 $P_{X_{\text{all}}|Y_{\text{all}}}(\sigma|b) = P_{X_{\text{all}}|Y_{\text{all}}}(-\sigma|b)$。因此，我们的重建度量也需要适应这种对称性。对于 $\mathcal{X} = \{-1,+1\}$，这导致使用 $\frac{1}{n}|\sum_{i=1}^n X_i \hat{X}_i|$ 作为我们的重建指标。

我们关于无向推断问题的主要定理可以看作是有向无环图（DAG）信息渗流定理（定理33.8）的类似物。然而，不同于控制

收缩系数，渗流概率被用来直接控制图中任意顶点子集之间的条件互信息。

在阐述我们的主要定理之前，我们需要为无向图上的推断定义一个相应的渗流模型。对于任何无向图$G = (\mathcal{V}, \mathcal{E})$，我们按以下方式定义其上的渗流模型:

• 每条边 $e \in \mathcal{E}$ 以概率 $\eta_{\mathrm{KL}}(P_{Y_e|X_e})$ 开放，与其他边独立，• 对于任意 $v \in \mathcal{V}$ 和 $S \subset \mathcal{V}$，我们定义 $v \leftrightarrow S$ 为存在从 v 到 S 中任意顶点的开放路径的事件，• 对于任意 $S_1, S_2 \subset \mathcal{V}$，我们定义函数 $\mathrm{perc}_u(S_1, S_2)$ 为

$$\mathrm{perc}_u(S_1, S_2) \triangleq \sum_{v \in S_1} P(v \leftrightarrow S_2).$$

注意，此函数不同于DAG中信息渗透的渗透函数。最重要的是，此函数并不等同于精确的渗透概率。相反，它是通过对S_1进行并集界定得到的渗透概率的一个上界。因此，此函数不对称是自然的，即$\mathrm{perc}_u(S_1, S_2) \neq \mathrm{perc}_u(S_2, S_1)$。

定理 33.18（无向信息渗透 [347]）*Consider an inference problem on undirected graph $G = (\mathcal{V}, \mathcal{E})$. For any $S_1, S_2 \subset \mathcal{V}$, then*

$$I(X_{S_1}; X_{S_2}|Y) \leq \mathrm{perc}_u(S_1, S_2) \log |\mathcal{X}|.$$

我们没有证明定理33.18的完全一般性，而是将在假设33.1下证明该定理。证明的主要步骤利用了这样一个事实：我们可以用任何信道的较不嘈杂上界来上界其互信息。

定理 33.19 *Consider the problem of inference on undirected graph $G = (\mathcal{V}, \mathcal{E})$ with $X_1, ..., X_n$ not necessarily independent. If $P_{Y_e|X_e} \leq_{LN} P_{Z_e|X_e}$, then for any $S_1, S_2 \subset \mathcal{V}$ and $E \subset \mathcal{E}$*

$$I(X_{S_1}; Y_E|X_{S_2}) \leq I(X_{S_1}; Z_E|X_{S_2})$$

Proof. 根据我们的假设以及“较少噪声”排序的张量化性质（命题33.17），我们有 $P_{Y_E|X_{S_1},X_{S_2}} \leq_{ln} P_{Z_E|X_{S_1},X_{S_2}}$。这意味着对于作为$X_{S_2}$的有效实现的$\sigma$，我们将有

$$I(X_{S_1}; Y_E|X_{S_2} = \sigma) = I(X_{S_1}, X_{S_2}; Y_E|X_{S_2} = \sigma) \leq I(X_{S_1}, X_{S_2}; Z_E|X_{S_2} = \sigma) = I(X_{S_1}; Z_E|X_{S_2} = \sigma).$$

由于该不等式对X_{S_2}的所有实现都成立，因此以下不等式也成立

$$I(X_{S_1}; Y_E|X_{S_2}) \leq I(X_{S_1}; Z_E|X_{S_2}).$$

□

Proof of Theorem 33.18. 我们仅在假设33.1下，且仅针对情况$S_1 = \{i\}$给出证明。对于完整的证明（通过归纳法进行，并未利用低噪声的想法），请参见[347]。我们有以下等式

$$I(X_i; X_{S_2}|Y_E) = I(X_i; X_{S_2}, Y_E) = I(X_i; Y_E|X_{S_2}) \tag{33.22}$$

其中第一个不等式源于S.C下的$B_E \perp\!\!\!\perp X_i$，第二个不等式源于假设33.1下的$X_i \perp\!\!\!\perp X_{S_2}$。

由于我们之前的结果，如果 $\eta_{\mathrm{KL}}(P_{Y_e|X_e}) = 1 - \tau$ 那么 $P_{Y_e|X_e} \le_{LN} P_{Z_e|X_e}$ 其中 $P_{Z_e|X_e} = \mathsf{EC}_\tau$。根据张量积性质，这种排序对于通道 $P_{Y_E|X_E}$ 也成立，因此我们有：

$$I(X_i; Y_E|X_{S_2}) \le I(X_j; Z_E|X_{S_2}).$$

让我们定义另一个辅助随机变量 $D = 1\{i \leftrightarrow S_2\}$，即它表示从 i 到 S_2 存在开放路径的指示变量。注意 D 完全由 Z_E 决定。通过与（33.22）中相同的论证，我们有

$$\begin{aligned}
I(X_i; Z_E|X_{S_2}) &= I(X_i; X_{S_2}|Z_E) \\
&= I(X_i; X_{S_2}|Z_E, D) \\
&= (1 - \mathbb{P}[i \leftrightarrow S_2]) \underbrace{I(X_i; X_{S_2}|Z_E, D = 0)}_{0} + \mathbb{P}[i \leftrightarrow S_2] \underbrace{I(X_i; X_{S_2}|Z_E, D = 1)}_{\le \log|\mathcal{X}|} \\
&\le \mathbb{P}[i \leftrightarrow S_2] \log|\mathcal{X}| \\
&= \mathrm{perc}_u(i, S_2)
\end{aligned}$$

□

33.9 应用：尖峰维格纳模型

以下定理展示了无向信息渗透概念如何使我们能够推导出尖峰维格纳模型的一个逆结果，我们在例33.13中对此进行了描述。为了重新表述该问题，我们给定一个观测

$$\mathbf{Y} = \sqrt{\frac{\lambda}{n}}\mathbf{X}\mathbf{X}^T + \mathbf{W},$$

其中 W 是高斯 Wigner 矩阵，$\mathrm{X} = (X_1, \ldots, X_n)^T$ 由独立同分布均匀 ± 1 元素组成。如同许多现代问题（参见第30.4节），我们这里的目标不是完全恢复 X，而是仅实现优于随机猜测的性能（“弱恢复”）。也就是说，如果我们找到一个估计量，其

$$\frac{1}{n}\mathbb{E}\left[\left|\sum_{i=1}^{n} X_i \hat{X}_i\right|\right] \ge \epsilon_0 > 0 \tag{33.23}$$

作为 $n \to \infty$。现在，事实证明，在诸如此类的问题中存在一个所谓的 *BBP phase transition*，首次在[29, 326]中被发现。具体而言，众所周知，$\frac{1}{\sqrt{n}}\mathrm{W}$ 的特征值遵循 *Wigner's*。

semicircle law 在区间 $(-2,2)$ 上支撑。同时，秩一矩阵 $\frac{\sqrt{\lambda}}{n}\mathrm{X}\mathrm{X}^T$ 只有一个非零特征值，等于 $\sqrt{\lambda}$。事实证明，对于 $\lambda<1$，这种“尖峰”效应不可检测，且 $\mathrm{Y}/\sqrt{n}$ 的谱不受影响。对于 $\lambda>1$，事实证明 $\mathrm{Y}/\sqrt{n}$ 的顶部特征值移动到半圆律边缘之上，达到 $\lambda+\frac{1}{\lambda}>2$。此外，计算顶部特征向量并取其坐标的符号，在 (33.23) 的意义下实现了对真实 X 的相关恢复。然而请注意，无法改变谱（当 $\lambda<1$ 时）并不意味着无法通过其他方法重建 X。不过，在本节中我们将证明，确实对于 $\lambda\le 1$，没有任何方法能够实现 (33.23)。因此，结合所提到的针对 $\lambda>1$ 的谱算法，我们可以得出结论：$\lambda^*=1$ 是分离该问题两个阶段的临界阈值。

定理 33.20 *Consider the spiked Wigner model. If $\lambda\le 1$, then for any sequence of estimators $\hat{X}^n(Y)$,*

$$\frac{1}{n}\mathbb{E}\left[\left|\sum_{i=1}^n X_i\hat{X}_i\right|\right]\to 0 \tag{33.24}$$

as $n\to\infty$.

Proof of Theorem 33.20. 根据柯西-施瓦茨不等式，对于(33.24)，只需证明

$$\sum_{i\neq j}\mathbb{E}[X_iX_j\hat{X}_i\hat{X}_j]=o(n^2)\,.$$

接下来，显然我们可以通过允许分别用 $\hat{T}_{i,j}$ 估计每个 X_iX_j 来简化最大化任务（在 $\hat{X}^n$ 上），即：

$$\max_{\hat{X}^n}\sum_{i\neq j}\mathbb{E}[X_iX_j\hat{X}_i\hat{X}_j]\le\sum_{i\neq j}\max_{\hat{T}_{i,j}}\mathbb{E}[X_iX_j\hat{T}_{i,j}]\,.$$

后者最大化由 MAP 解码器求解：

$$\hat{T}_{i,j}(\mathbf{Y})=\arg\max_{\sigma\in\{\pm1\}}\mathbb{P}[X_iX_j=\sigma|\mathbf{Y}]\,.$$

由于每个 $X_i\sim\mathrm{Ber}(1/2)$，很容易看出

$$I(X_i;X_j|\mathbf{Y})\to 0\quad\iff\quad\max_{\hat{T}_{i,j}}\mathbb{E}[X_iX_j\hat{T}_{i,j}]\to 0\,.$$

(例如，我们可能会注意到$I(X_i;\,X_j|\mathrm{Y})=I(X_i,X_j;\,\mathrm{Y})\ge I(X_iX_j;\,\mathrm{Y})$并应用Fano不等式)。因此，由问题的对称性，只需证明当$n\to\infty$时，$I(X_1;\,X_2|Y)\to 0$。

通过使用无向信息渗透定理，我们有

$$I(X_2;X_1|\mathbf{Y})\le\mathrm{perc}_u(\{1\},\{2\})\,.$$

现在，为了计算perc，我们需要计算存在开放边的概率，在本例中它直接等于$\eta_{\mathrm{KL}}(\mathsf{BIAWGN}_{\lambda/n})$。根据定理33.6，我们知道后者等于$I_{\chi^2}(X;\,Y)$

其中 $X \sim \text{Ber}(1/2)$ 且 $Y = \mathsf{BIAWGN}_{\lambda/n}(X)$。一个简短的计算因此表明

$$\eta_{\text{KL}}(\mathsf{BIAWGN}_{\lambda/n}) = \frac{\lambda}{n}(1 + o(1)) .$$

假设 $\lambda < 1$。在这种情况下，我们可以通过 $\frac{\lambda'}{n}$ 以 $\lambda' < 1$ 来超出 $\frac{\lambda+o(1)}{n}$ 的上界。此时，渗流随机图等价于具有 n 个顶点和 λ'/n 边概率的 Erdös-Rényi 随机图，即 $\text{ER}(n, \lambda'/n)$。利用这一观察，不等式可以重写为

$$I(X_2; X_1|\mathbf{Y}) \le P(\text{Vertex 1 and 2 is connected in ER}(n, \lambda'/n)).$$

随机图论中的一个经典结果是，如果$\lambda' < 1$，则$\text{ER}(n, \lambda'/n)$中最大的连通分量包含$O(\log n)$个顶点[154]。这意味着两个特定顶点相连的概率为$o(1)$，因此$I(X_2$；当$n \to \infty$时，$X_1|\text{Y}) \to 0$。

为了处理 $\lambda = 1$ 的情况，我们需要关于 $\eta_{\text{KL}}(\mathsf{BIAWGN}_{\lambda/n})$ 以及 $\text{ER}(n, \frac{1+o(1)}{n})$ 图巨型组件行为的稍微更精细的信息；完整细节见 [347]。

□

注 33.2（稠密-稀疏对应） 上述证明改变了图的底层结构。也就是说，信息渗流方法不再处理完全图，而是将其替换为 Erdös-Rényi 随机图。此外，如果 η_{KL} 足够小，那么底层渗流图往往非常稀疏，并具有局部树状结构。这展示了现代统计学中一个普遍存在且被积极研究的效果：具有极弱信号（$\eta_{\text{KL}} \approx 1$）的稠密推断（例如尖峰 Wigner 模型、稀疏回归、稀疏 PCA 等）类似于具有中等信号（$\eta_{\text{KL}} \in (\epsilon, 1-\epsilon)$）的稀疏推断（树上的广播）。信息渗流方法在这两个世界之间提供了一定的桥梁，或许部分解释了为什么这两个世界中的结果常常彼此平行。（例如，关于信念传播（稀疏推断）的最优性和相变的结果，常常与关于近似消息传递（AMP，稠密推断）的结果平行。）然而，我们确实想提醒，信息渗流方法给出的归约通常并不紧（尖峰 Wigner 是一个幸运的例外）。例如 [347]，对于具有 k 个社区、边概率为 a/n 和 b/n 的 SBM 中的相关恢复，它产生了一个不可能性结果（$\sqrt{a} - \sqrt{b}$）$^2 \le \frac{k}{2}$，弱于 [203] 的最佳已知上界。

33.10 强数据后处理不等式（后-SDPI）

对于分布式估计中的应用，以下版本的SDPI是有用的。

定义33.21（后SDPI常数）给定条件测度$P_{Y|X}$，定义输入相关和输入无关的收缩系数为

$$\eta_{\text{KL}}^{(p)}(P_X, P_{Y|X}) = \sup_{P_{U|Y}} \left\{ \frac{I(U;X)}{I(U;Y)} : X \to Y \to U \right\}$$

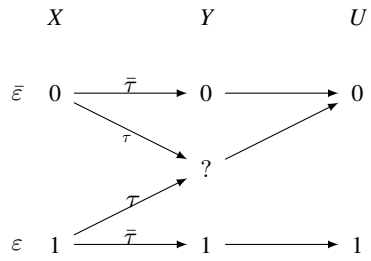


图33.6 BEC的SDPI后系数等于1。

$$\eta_{\mathrm{KL}}^{(p)}(P_{Y|X}) = \sup_{P_X, P_{U|Y}} \left\{ \frac{I(U;X)}{I(U;Y)} : X \to Y \to U \right\}$$

为了用KL散度来描述，我们只需注意到

$$\eta_{\mathrm{KL}}^{(p)}(P_X, P_{Y|X}) = \eta_{\mathrm{KL}}(P_Y, P_{X|Y}) \tag{33.25}$$

$$\eta_{\mathrm{KL}}^{(p)}(P_X, P_{Y|X}) = \sup_{P_X} \eta_{\mathrm{KL}}(P_Y, P_{X|Y}), \tag{33.26}$$

其中 $P_Y = P_{Y|X} \circ P_X$ 和 $P_{X|Y}$ 是对应于 $P_X P_{Y|X}$ 的条件测度。由（33.25）和命题33.11，我们也得到输入依赖的后SDPI的张量化性质：

$$\eta_{\mathrm{KL}}^{(p)}(P_X^{\otimes n}, (P_{Y|X})^{\otimes n}) = \eta_{\mathrm{KL}}^{(p)}(P_X, P_{Y|X}). \tag{33.27}$$

很容易看出，根据数据处理不等式，$\eta_{\mathrm{KL}}^{(p)}(P_{Y|X}) \le 1$。与 η_{KL} 系数不同，$\eta_{\mathrm{KL}}^{(p)}$ 即使对于有噪信道 $P_{Y|X}$ 也可以等于 1。

例 33.14（擦除信道的 $\eta_{\mathrm{KL}}^{(p)} = 1$）设 $P_{Y|X} = \mathsf{BEC}_\tau$ 和 $X \to Y \to U$ 如 图 33.6 所定义。然后我们可以计算 $I(Y; U) = H(U) = h(\varepsilon\bar{\tau})$ 和 $I(X; U) = H(U) - H(U|X) = h(\varepsilon\bar{\tau}) - \varepsilon h(\tau)$ 因此

$$\begin{aligned}\eta_{\mathrm{KL}}^{(p)}(P_{Y|X}) &\ge \frac{I(X;U)}{I(Y;U)} \\ &= 1 - h(\tau)\frac{\varepsilon}{h(\varepsilon\bar{\tau})}\end{aligned}$$

当ε趋近于0时，最后一项趋于1，因此

$$\eta_{\mathrm{KL}}^{(p)}(\mathsf{BEC}_\tau) = 1$$

即使Y不是X的一对一函数。

请注意，此示例还表明，即使对于 $\eta_{\mathrm{KL}}^{(p)}$ 的输入受限版本，自然猜想 $\eta_{\mathrm{KL}}^{(p)}(\text{Unif}, \text{BMS}) = \eta_{\mathrm{KL}}(\text{BMS})$ 是 *incorrect*。实际上，通过取 $\varepsilon = \frac{1}{2}$，我们得到对于 $\tau \to 1$，有 $\eta_{\mathrm{KL}}^{(p)}(\text{Unif}, \mathsf{BEC}_\tau) > 1 - \tau$。

然而，SDPI之后的常数通常并非平凡，最重要的是对于BSC：

定理 33.22

$$\eta_{\mathrm{KL}}^{(p)}(\mathsf{BSC}_\delta) = (1-2\delta)^2.$$

为了证明这个定理，以下引理是有用的。

引理 33.23 *If for any X and Y in* $\{0,1\}$ *we have*

$$p_{X,Y}(x,y) = f(x)\left(\frac{\delta}{1-\delta}\right)^{1(x\neq y)} g(Y)$$

for some functions f and g, then $\eta_{\mathrm{KL}}(P_{Y|X}) \le (1-2\delta)^2$.

Proof. 从（33.6）我们知道对于二进制输入信道

$$\eta_{\mathrm{KL}}(P_{Y|X}) \le H^2(P_{Y|X=0}, P_{Y|X=1}) - \frac{H^4(P_{Y|X=0}, P_{Y|X=1})}{4}$$

如果我们令 $\phi = \frac{g(0)}{g(1)}$，那么我们有 $p_{Y|X=0} = B\left(\frac{\lambda}{\phi+\lambda}\right)$ 和 $p_{Y|X=1} = B\left(\frac{1}{1+\phi\lambda}\right)$，并且一个简单的检查表明

$$\max_\phi H^2(P_{Y|X=0}, P_{Y|X=1}) - \frac{H^4(P_{Y|X=0}, P_{Y|X=1})}{4} \overset{\phi=1}{=} (1-2\delta)^2$$

现在观察到定理33.22中的$P_{X,Y}$满足引理的性质，其中X和Y互换，因此$\eta_{\mathrm{KL}}(P_Y, P_{X|Y}) \le (1-2\delta)^2$，这意味着$\eta_{\mathrm{KL}}^{(p)}(P_{Y|X}) = \sup_{P_X} \eta_{\mathrm{KL}}(P_Y, P_{X|Y}) \le (1-2\delta)^2$，当$P_X$均匀时取等号。 □

定理 33.24 (BI-AWGN 的 Post-SDPI) *Let* $0 \le \epsilon \le 1$ *and consider the channel* $P_{Y|X}$ *with* $X \in \{\pm 1\}$ *given by*

$$Y = \epsilon X + Z, \qquad Z \sim \mathcal{N}(0,1)\,.$$

Then for any $\pi \in (0,1)$ *taking* $P_X = \mathrm{Ber}(\pi)$ *we have for some absolute constant K the estimate*

$$\eta_{\mathrm{KL}}^{(p)}(P_X, P_{Y|X}) \le K\frac{\epsilon^2}{\pi(1-\pi)}\,.$$

Proof. 在此证明中，我们假设所有信息度量均采用底数-e。首先，注意到

$$v(y) \triangleq P[X=1|Y=y] = \frac{1}{1+\frac{1-\pi}{\pi}e^{-2y\epsilon}}\,.$$

然后，定义 {v*} 的优化可以写为

$$\eta_{\mathrm{KL}}^{(p)}(P_X, P_{Y|X}) \le \sup_{Q_Y} \frac{d(\mathbb{E}_{Q_Y}[v(Y)]\|\pi)}{D(Q_Y\|P_Y)}\,. \tag{33.28}$$

从（7.34）我们有

$$\eta_{\mathrm{KL}}^{(p)}(P_X, P_{Y|X}) \le \frac{1}{\pi(1-\pi)} \sup_{Q_Y} \frac{(\mathbb{E}_{Q_Y}[v(Y)]-\pi)^2}{D(Q_Y\|P_Y)}\,. \tag{33.29}$$

为了继续，我们需要引入一个新的概念。由K. Marton首次引入的T_1-运输不等式，对于测度P_Y，陈述如下：对于每一个Q_Y，我们都有对于某个$c = c(P_Y)$

$$W_1(Q_Y, P_Y) \le \sqrt{2cD(Q_Y\|P_Y)}\,, \tag{33.30}$$

其中 $W_1(Q_Y, P_Y)$ 是定义为如下的 1-瓦瑟斯坦距离

$$\begin{aligned} W_1(Q_Y, P_Y) &= \sup\{\mathbb{E}_{Q_Y}[f] - \mathbb{E}_{P_Y}[f] : f \text{ 1-Lipschitz}\} \\ &= \inf\{\mathbb{E}[|A - B|] : A \sim Q_Y, B \sim P_Y\}\,. \end{aligned} \tag{33.31}$$

(33.30)中的常数$c(P_Y)$已在[64, 125]中根据P_Y的性质得到了表征。其中一个这样的估计如下:

$$c(P_Y) \le \frac{2}{\delta}\sup_{k\ge 1}\left(\frac{G(\delta)}{\binom{2k}{k}}\right)^{1/k}\,,$$

其中 $G(\delta) = \mathbb{E}[e^{\delta(Y-Y')^2}]$，其中 $Y, Y' \overset{\text{i.i.d.}}{\sim} P_Y$。利用估计 $\binom{2k}{k} \ge \frac{4^k}{\sqrt{\pi(k+1/2)}}$ 以及 $\frac{1}{k}\ln(k+1/2) \le \frac{1}{2}$ 这一事实，我们得到进一步的界

$$c(P_Y) \le \frac{2}{\delta}G(\delta)\frac{\pi\sqrt{e}}{4} \le \frac{6G(\delta)}{\delta}\,.$$

接着注意到 $Y - Y' \overset{d}{=} B_\epsilon + \sqrt{2}Z$，其中 $B_\epsilon \perp\!\!\!\perp Z \sim \mathcal{N}(0,1)$ 且 B_ϵ 是对称的，并且 $|B_\epsilon| \le 2\epsilon$。因此，我们得出结论：对于任意 $\delta < 1/4$，我们有 $\bar{c} \triangleq \frac{6}{\delta}\sup_{\epsilon\le 1} G(\delta) < \infty$。最终，我们得到不等式 (33.30)，其常数 $c = \bar{c}$ 对所有 $0 \le \epsilon \le 1$ 一致成立。

现在，请注意 $\left|\frac{d}{dy}v(y)\right| \le \frac{\epsilon}{2}$，因此 v 是 $\frac{\epsilon}{2}$-Lipschitz。由(33.30)和(33.31)我们得到

$$|\mathbb{E}_{Q_Y}[v(Y)] - \mathbb{E}_{P_Y}[v(Y)]| \le \frac{\epsilon}{2}\sqrt{2\bar{c}D(Q_Y\|P_Y)}\,.$$

将此不等式平方并代回(33.29)便完成了证明。 □

注 33.3 注意，我们也可以通过留意以下事实来计算 $\eta_{\mathrm{KL}}^{(p)}(P_X, P_{Y|X})$ 的精确值。由 (33.28) 显然可见，在所有具有给定 $\mathbb{E}_{Q_Y}[v(Y)]$ 值的测度 Q_Y 中，我们感兴趣的是使 $D(Q_Y\|P_Y)$ 最小化的那一个。由定理 15.11 我们知道，这样的 Q_Y 由 $dQ_Y = e^{bv(y)-\psi_v(b)}dP_Y$ 给出，其中 $\psi_V(b) \triangleq \ln \mathbb{E}_{P_Y}[e^{bv(Y)}]$。因此，通过定义凸对偶 $\psi_V^*(\lambda)$，我们可以根据以下单变量优化得到精确值:

$$\eta_{\mathrm{KL}}^{(p)}(P_X, P_{Y|X}) = \sup_{\lambda\in[0,1]}\frac{d(\lambda\|\pi)}{\psi_V^*(\lambda)}\,.$$

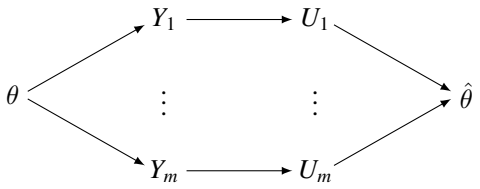
在数值上，对于$\pi = 1/2$，最优值为$\lambda \to \frac{1}{2}$，这证实了我们将d上界设为χ^2的做法，并惊人地得出

$$\eta_{\mathrm{KL}}^{(p)}(\mathrm{Ber}(1/2), P_{Y|X}) = 4\,\mathbb{E}_{P_Y}[\tanh^2(\epsilon Y)] = \eta_{\mathrm{KL}}(P_{Y|X})\,,$$

其中在最后一个等式中，我们使用了定理33.6(f)。

33.11 应用：分布式均值估计

我们希望估计 $\theta \in [-1,1]^d$，并且有 m 台机器独立观测 $Y_i = \theta + \sigma Z_i$，其中对于 $i = 1,\dots,m$，$Z_i \sim \mathcal{N}(0, I_d)$ 独立成立。它们总共可以向远程估计器发送 B 比特，该估计器产生 $\hat{\theta}$，目标是最小化最坏情况风险 $\sup_\theta \mathbb{E}[\|\theta - \hat{\theta}\|^2]$。如果我们用 $U_i \in \mathcal{U}_i$ 表示这些消息，则我们有通信约束 $\sum_i \log_2 |\mathcal{U}_i| \le B$，其示意图如下：



最后，将估计的极小极大风险表示为

$$R^*(m,d,\sigma^2,B) = \inf_{U_1,\dots,U_m,\hat{\theta}} \sup_\theta \mathbb{E}[\|\theta - \hat{\theta}\|^2].$$

我们从一些简单的观察开始：

- 在没有约束 $\theta \in [-1,1]^d$ 的情况下，我们可以取 $\theta \sim \mathcal{N}(0, bI_d)$，并根据率失真迅速地得出结论：要在风险 R 内估计 θ，至少需要传达 $\frac{d}{2}\log\frac{bd}{R}$ 比特，而这会随着 $b \to \infty$ 而发散。因此，为了使 θ 可以通过有限比特通信进行估计，限制其幅度是必要的。

- 在没有通信约束的情况下，通过取 $U_i = Y_i$ 和 $\hat{\theta} = \frac{1}{m}\sum_i U_i$，容易建立 $R^*(m,d,\sigma^2,\infty) = \mathbb{E}\left[\left\|\frac{\sigma}{m}\sum_i Z_i\right\|^2\right] = \frac{d\sigma^2}{m}$，这与非分布式设置中的极小极大风险(28.17)相匹配。
- 为了实现阶数为 $\frac{d}{m}$ 的风险，我们可以采用如下粗糙量化器。令 $U_i = \text{sign}(Y_i)$（逐坐标符号）。这产生 $B = md$，且容易证明可达到的风险为 $O_\sigma(\frac{d}{m})$。事实上，注意到通过取 $V = \frac{1}{m}\sum_{i=1}^m U_i$，我们看到每个坐标 V_j、$j \in [d]$，估计（在 $O_p(\frac{1}{\sqrt{m}})$ 范围内）量 $\Phi(\theta_j/\sigma)$，其中 Φ 表示 $\mathcal{N}(0,1)$ 的 CDF。由于 Φ 的导数在 $[-1/\sigma, 1/\sigma]$ 上有界远离 0，我们得到估计 $\hat{\theta}_j \triangleq \sigma\Phi^{-1}(V_j)$ 的均方误差为 $O(1/m)$ (，对 σ 的依赖较差，然而)，这给出了如所声称的总体误差 $O(d/m)$。

  我们的主要结果如下所示，表明之前的简单策略在通信比特数方面是阶最优的。这简化了[137, 73]的证明。
- 我们注意到，这些结果也隐含在信息论文献中关于所谓*Gaussian CEO problem*的长期研究中。我们建议参考[156]；特别是其中的定理3蕴含了我们将在下文展示的$B \gtrsim dm$下界。然而，高斯CEO的工作使用了更为复杂的工具（熵功率不等式及相关结果），而我们的SDPI证明则更为初等。

我们的目标是证明 $R^* \lesssim \frac{d}{m}$ 蕴含 $B \gtrsim md$。

首先请注意，对于 $d = 1$ 来说，这一点完全显而易见。事实上，如果 $B \le \tau m$，那么进行通信的机器少于 τm 台，因此对于某个通用常数 K 有 $R^* \ge \frac{K}{\tau m}$(，而它不等于 1，因为 θ 被限制在 $[-1, 1]$) 中。然而，对于 $d \gg 1$，并不清楚每台机器是否都需要通信 $\Omega(d)$ 比特。也许发送在不同正交基下取得的 $\ll d$ 个单比特测量值可能可行？希望这个（错误的）猜测能说明为什么以下结果既有趣又非平凡。

定理 33.25 *There exists a constant $c_1 > 0$ such that if $R^*(m, d, \sigma^2, B) \le \frac{d\epsilon^2}{9}$ then $B \ge \frac{c_1 d}{\epsilon^2}$.*

Proof. 令 $X \sim$ 服从 Unif$(\{\pm 1\}^d)$ 并设 $\theta = \epsilon X$。给定估计 $\hat{\theta}$，我们可以通过 $\hat{X} = \text{sign}(\hat{\theta})$（逐坐标）将其转换为 X 的估计量。那么，显然

$$\mathbb{E}[d_H(X, \hat{X})]\frac{\epsilon^2}{4} \le \mathbb{E}[\|\hat{\theta} - \theta\|^2] \le \frac{d\epsilon^2}{9}\,.$$

因此，我们有一个在汉明距离 $\frac{4}{9}d$ 内的 X 估计量。根据率失真定理（定理26.1），我们得出对于某个常数 $c > 0$，有 $I(X; \hat{X}) \ge cd$。另一方面，根据标准DPI，我们有

$$cd \le I(X; \hat{X}) \le I(X; U_1, \ldots, U_m) \le \sum_{j=1}^{m} I(X; U_j)\,, \tag{33.32}$$

其中我们还应用了定理6.1。接下来，我们通过应用Post-SDPI来估计$I(X;$ 通过$I(Y_j$估计$U_j)$; 通过$U_j)$估计。为此，我们需要注意，对于每个j，信道$X \to Y_j$仅仅是具有SNR ϵ的二进制输入AWGN信道的无记忆扩展。由于X的每个坐标是均匀的，我们可以应用定理33.24（其中$\pi = 1/2$）结合张量积（33.27）得出

$$I(X; U_j) \le 4K\epsilon^2 I(Y_j; U_j) \le 4K\epsilon^2 \log |\mathcal{U}_j|$$

结合（33.32），我们因此得到

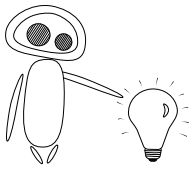
$$cd \le I(X; \hat{X}) \le 4K\epsilon^2 B \log 2 \tag{33.33}$$

□

我们注意到，在这个简短的章节中，我们仅考虑了*non-interactive*设置，即消息U_i由机器i独立生成，除了其私有测量值Y_i外不参考任何其他信息。更一般地，我们可以允许机器通过公共广播信道通信其比特，使得每个通信的比特都被所有其他机器看到。我们仍然可以限制所有机器发送的总比特数为B，并寻求最佳的*interactive*估计速率。虽然[137, 73]声称适用于此设置的下界，但这些界包含微妙的错误（详见[5, 4]）。存在适用于非交互设置的下界，但它们在某些对数项上较弱。例如，[5, 定理4]表明，在有限交互设置中，要达到风险$\lesssim d\epsilon^2$，需要$B \gtrsim \frac{d}{\epsilon^2 \log(dm)}$，其中$U_i$可能依赖于$U_1^{i-1}$，但没有其他交互（即第$i$台机器发送其全部

消息一次性发送，而不是先发送部分消息并等待其他节点广播各自的消息之后才完成自己的传输，正如完全交互式协议所允许的那样）。

第六部分练习



VI.1 令 $X_1, \ldots, X_n \overset{\text{i.i.d.}}{\sim}$ 服从指数分布 Exp(exp(θ))，其中 θ 服从参数为 s 的柯西分布 π，其概率密度函数由 $p(\theta) = \frac{1}{\pi s(1+\frac{\theta^2}{s^2})}$ 给出，对于 $\theta \in \mathbb{R}$。证明贝叶斯风险

$$R_\pi^* \triangleq \inf_{\hat{\theta}} \mathbb{E}_{\theta\sim\pi}\mathbb{E}(\hat{\theta}(X^n) - \theta)^2$$

满足 $R_\pi^* \geq \frac{2s^2}{2ns^2+1}$.

VI.2（系统辨识）设 $\theta \in \mathbb{R}$ 为动力系统的一个未知参数:

$$X_t = \theta X_{t-1} + Z_t, \quad Z_t \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0,1), \quad X_0 = 0\,.$$

学习动力系统的参数被称为“系统辨识”。将对应于 θ 的 $(X_1, \ldots, X_n)$ 的规律记为 P_θ。

1. 计算 $D(P_\theta \| P_{\theta_0})$。（提示：链式法则能节省大量精力。）
2. 证明费舍尔信息

$$J_F(\theta) = \sum_{1\leq t\leq n-1} \theta^{2t-2}(n-t).$$

3. 论证系统识别中最困难的 regime 是当 $\theta \approx 0$ 时，而不稳定性（$|\theta| > 1$）实际上是有帮助的。

VI.3（线性回归）考虑模型

$$Y = X\beta + Z$$

其中设计矩阵 $X \in \mathbb{R}^{n\times d}$ 已知，且 $Z \sim \mathcal{N}(0, I_n)$。定义基于 X 和 Y 估计回归系数 $\beta \in \mathbb{R}^d$ 的极小极大均方误差如下:

$$R_{\mathsf{est}}^* = \inf_{\hat{\beta}} \sup_{\beta\in\mathbb{R}^d} \mathbb{E}\|\hat{\beta} - \beta\|_2^2. \tag{VI.1}$$

(a) 证明如果秩$(X) < d$，那么 $R_{\mathsf{est}}^* = \infty$;
(b) 证明如果秩$(X) = d$，那么

$$R_{\mathsf{est}}^* = \mathrm{tr}((X^\top X)^{-1})$$

并确定哪个估计量达到了极小极大风险。
(c) 与(VI.1)中的估计误差相反，考虑*prediction error*:

$$R_{\mathsf{pred}}^* = \inf_{\hat{\beta}} \sup_{\beta\in\mathbb{R}^d} \mathbb{E}\|X\hat{\beta} - X\beta\|_2^2. \tag{VI.2}$$

重做(a)和(b)，通过找到R^*_{pred}的值并识别极小极大估计量。直观地解释为什么即使d超过n，R^*_{pred}也总是有限的。

VI.4（切尔诺夫-鲁宾-斯坦下界。）设 $X_1,\dots,X_n \overset{\text{i.i.d.}}{\sim} P_\theta$ 和 $\theta \in [-a,a]$。

(a) 给出适当的正则性条件，并证明以下极小极大下界：

$$\inf_{\hat\theta}\sup_{\theta\in[-a,a]} \mathbb{E}_\theta[(\theta-\hat\theta)^2] \ge \min_{0<\epsilon<1} \max\left\{\epsilon^2 a^2, \frac{(1-\epsilon)^2}{n\bar J_F}\right\},$$

其中 $\bar J_F = \frac{1}{2a}\int_{-a}^{a} J_F(\theta)d\theta$ 是平均费舍尔信息。（提示：考虑在 $[-a,a]$ 上的均匀先验，并按照定理 29.2 的证明，通过分部积分法进行。）

(b) 简化上述边界并证明

$$\inf_{\hat\theta}\sup_{\theta\in[-a,a]} \mathbb{E}_\theta[(\theta-\hat\theta)^2] \ge \frac{1}{(a^{-1}+\sqrt{n\bar J_F})^2}. \tag{VI.3}$$

(c) 假设 $\theta \mapsto J_F(\theta)$ 的连续性，证明上述结果同样导出定理 29.4 中由贝叶斯克拉美-罗获得的最优局部极小极大下界：

$$\inf_{\hat\theta}\sup_{\theta\in[\theta_0\pm n^{-1/4}]} \mathbb{E}_\theta[(\theta-\hat\theta)^2] \ge \frac{1+o(1)}{nJ_F(\theta_0)}.$$

Note：(VI.3) 是 [92, Lemma 1] 中给出的不等式的改进，该不等式未经证明，归功于 Rubin 和 Stein。

VI.5 在本练习中，我们给出一个基于 Hellinger 的下界，类似于定理29.1中基于χ^2的HCR下界。设$\hat\theta$为$\theta\in\Theta\subset\mathbb{R}$的无偏估计量。

(a) 对于任意 $\theta,\theta'\in\Theta$，证明 [386]

$$\frac{1}{2}(\mathrm{Var}_\theta(\hat\theta)+\mathrm{Var}_{\theta'}(\hat\theta)) \ge \frac{(\theta-\theta')^2}{4}\left(\frac{1}{H^2(P_\theta,P_{\theta'})}-1\right). \tag{VI.4}$$

(提示：对于任意 c、$\theta-\theta' = \int(\hat\theta-c)(\sqrt{p_\theta}+\sqrt{p_{\theta'}})(\sqrt{p_\theta}-\sqrt{p_{\theta'}})$。应用柯西-施瓦茨不等式，并在 c 上优化。)

() 证明

$$H^2(P_\theta,P_{\theta'}) \le \frac{1}{4}(\theta-\theta')^2\bar J_F \tag{VI.5}$$

其中$\bar J_F = \frac{1}{\theta'-\theta}\int_\theta^{\theta'} J_F(u)du$是平均费舍尔信息。

(c) 陈述所需的 Regularity Conditions，并从 (VI.4) 和 (VI.5) 结合 $\theta'\to\theta$ 推导出 Cramér-Rao 下界。

(d) 将前几部分推广到多变量情况。

VI.6（贝叶斯分布估计。）令 $\{P_\theta\colon \theta\in\Theta\}$ 为 $\mathcal{X}$ 上的一族分布，具有共同的优势测度 μ 和密度 $p_\theta(x) = \frac{dP_\theta}{d\mu}(x)$。给定样本 $X^n = (X_1,\dots,X_n)\overset{\text{i.i.d.}}{\sim} P_\theta$（对于某个 $\theta\in\Theta$），目标是通过某个估计量 $\hat P(\cdot) = \hat P(\cdot$ 来估计数据生成分布 P_θ；相对于某个损失函数 $\ell(P,\hat P)$，$X^n)$。假设我们处于

在一个贝叶斯设定中，θ是从先验π中抽取的。让我们找出贝叶斯估计量的形式及贝叶斯风险。

(a) 为方便起见，设 X_{n+1} 表示从 P_θ 中抽取且独立于观测数据 X^n 的一个测试数据点（未见过的）。请确信，每个估计量 $\hat{P}$ 都可以形式上被识别为条件分布 $Q_{X_{n+1}|X^n}$。(b) 考虑 KL 损失 $\ell(P,\hat{P}) = D(P\|\hat{P})$。利用推论 4.2，证明最小化平均 KL 风险的贝叶斯估计量是后验（条件均值），即其 μ 密度由下式给出

$$q_{X_{n+1}|X^n}(x_{n+1}|x^n) = \frac{\mathbb{E}_{\theta\sim\pi}[\prod_{i=1}^{n+1} p_\theta(x_i)]}{\mathbb{E}_{\theta\sim\pi}[\prod_{i=1}^{n} p_\theta(x_i)]}. \tag{VI.6}$$

(c) 得出结论，贝叶斯KL风险等于 $I(\theta;\ X_{n+1}|X^n)$。将其与练习II.19的结论以及(13.35)中批量遗憾的KL风险解释进行比较。

(d) 现在，考虑 χ^2 损失 $\ell(P,\hat{P}) = \chi^2(P\|\hat{P})$。利用练习I.45中的(I.12)，证明最优风险由下式给出：

$$\inf_{\hat{P}} \mathbb{E}_{\theta,X^n}[\chi^2(P_\theta\|\hat{P})] = \mathbb{E}_{X^n}\left[\left(\int \mu(dx_{n+1})\sqrt{\mathbb{E}_\theta[p_\theta(x_{n+1})^2|X^n]}\right)^2\right] - 1. \tag{VI.7}$$

获得的 {v*}

$$q_{X_{n+1}|X^n}(x_{n+1}|x^n) \propto \sqrt{\mathbb{E}_\theta[p_\theta(x_{n+1})^2|X^n = x^n]} \tag{VI.8}$$

(现在，考虑逆向-χ^2损失$\ell(P,\hat{P}) = \chi^2(\hat{P}\|P)$，一种加权二次损失。利用练习I.45中的(I.13)证明最优风险由下式达到：

$$q_{X_{n+1}|X^n}(x_{n+1}|x^n) \propto \left(\mathbb{E}_\theta[p_\theta(x_{n+1})^{-1}|X^n = x^n]\right)^{-1} \tag{VI.9}$$

(f) 考虑离散字母表 $[k]$ 和 $X^n \overset{\text{i.i.d.}}{\sim} P$，其中 $P = (P_1,\dots,P_k)$ 取自 Dirichlet$(\alpha,\dots,\alpha)$ 先验。应用先前的结果（以 μ 为计数测度），证明 KL 损失和反向-χ^2 损失的贝叶斯估计量由 Krichevsky-Trofimov 加-β 估计量给出（第 13.5 节）

$$\widehat{P}(j) = \frac{n_j+\beta}{n+k\beta}, \qquad n_j \triangleq \sum_{i=1}^{n} 1\{X_i = j\}, \tag{VI.10}$$

其中，对于KL散度，$\beta = \alpha$；对于反向χ^2 (，$\beta = \alpha -$为1，假设$\alpha \geq$为1)。*Hint*：后验分布为$(P_1,\dots,P_k)|X^n \sim$ Dirichlet$(n_1+\alpha,\dots,n_k+\alpha)$，且$P_j|X^n \sim$ Beta$(n_j+\alpha, n-n_j+(k-1)\alpha)$。(g) 对于$\chi^2$损失，证明贝叶斯估计量为

$$\widehat{P}(j) = \frac{\sqrt{(n_j+\alpha)(n_j+\alpha+1)}}{\sum_{j=1}^{k}\sqrt{(n_j+\alpha)(n_j+\alpha+1)}}. \tag{VI.11}$$

VI.7（抛硬币）给定 $X_1,\dots,X_n \overset{\text{i.i.d.}}{\sim}$ Ber(θ)，其中 $\theta \in \Theta = [0,1]$，我们的目标是相对于二次损失函数 $\ell(\theta,\hat{\theta}) = (\theta-\hat{\theta})^2$ 来估计 θ。将极小极大风险记为 R_n^*。

(a) 使用经验频率 $\hat{\theta}_{\mathsf{emp}} = \bar{X}$ 估计 θ。计算并绘制风险 $R_\theta(\hat{\theta})$，并展示

$$R_n^* \le \frac{1}{4n}.$$

(计算$P_\theta = \mathrm{Ber}(\theta)^{\otimes n}$和$Q_\theta = \mathrm{Bin}(n,\theta)$的Fisher信息。解释它们为什么相等。

(c) 调用贝叶斯克拉美-罗下界定理29.2来证明

$$R_n^* = \frac{1+o(1)}{4n}.$$

(d) 注意，风险 $\hat{\theta}_{\mathsf{emp}}$ 在1/2（公平硬币）时达到最大，这表明可能通过以下随机估计器来对冲这种情况。

$$\hat{\theta}_{\mathsf{rand}} = \begin{cases} \hat{\theta}_{\mathsf{emp}}, & \text{with probability } \delta \\ \frac{1}{2} & \text{with probability } 1-\delta \end{cases} \tag{VI.12}$$

找出$\hat{\theta}_{\mathsf{rand}}$的最坏情况风险作为$\delta$的函数。对$\delta$进行优化，展示改进的上界：

$$R_n^* \le \frac{1}{4(n+1)}.$$

({e27} 如备注28.3所述，若损失函数为凸，随机估计量总能得到改进；因此，我们应当通过考虑估计量来消除(VI.12)中的随机性，即

$$\hat{\theta}^* = \mathbb{E}[\hat{\theta}_{\mathsf{rand}}|X] = \bar{X}\delta + \frac{1}{2}(1-\delta). \tag{VI.13}$$

通过优化 δ 来最小化最坏情况风险，找到得到的估计量 $\hat{\theta}^*$ 及其风险，证明它是常数（独立于 θ），并得出结论

$$R_n^* \le \frac{1}{4(1+\sqrt{n})^2}.$$

(接下来我们展示在(e)部分中找到的$\hat{\theta}^*$恰好是极小极大值，因此

$$R_n^* = \frac{1}{4(1+\sqrt{n})^2}.$$

考虑以下先验 $\mathrm{Beta}(a,b)$，其密度为：

$$\pi(\theta) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)}\theta^{a-1}(1-\theta)^{b-1}, \quad \theta \in [0,1],$$

其中 $\Gamma(a) \triangleq \int_0^\infty x^{a-1}e^{-x}dx$。证明如果 $a = b = \frac{\sqrt{n}}{2}$，$\hat{\theta}^*$ 与该先验下的贝叶斯估计量一致，因此该先验是最不利的。（提示：利用充分统计量 $S = X_1 + \ldots + X_n$。）

(g) 证明最不利先验并非唯一；事实上，存在一个连续统。（提示：考虑贝叶斯估计量 $\mathbb{E}[\theta|X]$，并展示它仅依赖于 π 的前 $n+$ 阶矩。）

(h) (*k*-元字母表) 假设 $X_1, \ldots, X_n \overset{\text{i.i.d.}}{\sim} P$ 在 $[k]$ 上。证明对于任意 k, n，定理 29.5 中估计 P 的极小极大平方风险恰好为

$$R^*_{\text{sq}}(k,n) = \inf_{\widehat{P}} \sup_{P \in \mathcal{P}_k} \mathbb{E}[\|\widehat{P} - P\|_2^2] = \frac{1}{(\sqrt{n}+1)^2} \frac{k-1}{k}, \tag{VI.14}$$

通过将* v *相加实现[r] 估计器。（提示：对于下界，证明平方损失和KL损失的贝叶斯估计器是一致的，然后应用练习VI.6中的(VI.10)。）

VI.8（TV 中的分布估计）延续（VI.14），我们证明，在总变差损失下估计 P 的极小极大速率为

$$R^*_{\text{TV}}(k,n) \triangleq \inf_{\hat{P}} \sup_{P \in \mathcal{P}_k)} \mathbb{E}_P[\text{TV}(\hat{P}, P)] \asymp \sqrt{\frac{k}{n}} \wedge 1, \qquad \forall k \geq 2, n \geq 1, \tag{VI.15}$$

(a) 证明极大似然估计与经验分布一致。(b) 证明极大似然估计在常数因子范围内达到(VI.15)的右侧。(提示：可应用(7.58)加上Pinsker不等式，或直接使用经验频率的方差。)
(c) 建立极小极大下界。(提示：应用Assouad引理，或Fano不等式(使用体积法或显式构造填充)，或直接使用互信息方法。)

VI.9（反向-χ^2下的分布估计）考虑从 $X^n \overset{\text{i.i.d.}}{\sim} P$ 的反向-χ^2 散度中估计 $[k]$ 上的离散分布 P，这是 (VI.14) 中二次损失的加权版本。我们证明极小极大风险由下式给出

$$R^*_{\text{rev}\chi^2}(k,n) \triangleq \inf_{\hat{P}} \sup_{P \in \mathcal{P}([k])} \mathbb{E}_P[\chi^2(\hat{P}\|P)] = \frac{k-1}{n}.$$

(a) 证明取 $\hat{P}(j) = \frac{1}{n}\sum_{i=1}^n 1\{X_i = j\}$ 为经验分布时，我们总有 $\mathbb{E}[\chi^2(\hat{P}\|P)] = \frac{k-1}{n}$。

(b) 给定 $P \sim$ 服从 Dirichlet$(\alpha, \ldots, \alpha)$，证明当 $\alpha =$ 等于 1 时，贝叶斯最优估计量正是经验分布。（提示：(VI.9)）

(c) 得出结论，关于 $\mathcal{P}([k])$ 上的均匀先验是最不利的，而经验分布恰好是极小极大最优的。

VI.10（KL 与 χ^2 中的分布估计）考虑在 KL 与 χ^2 散度下估计 $[k]$ 上的离散分布 P，它们是无界损失的例子（KL 损失在机器学习中也称为 *cross-entropy* 或 *log-loss*）。由于这些散度不对称，我们定义（回忆反向 χ^2 已在习题 VI.9 中讨论过）

$$R^*_{\text{KL}}(k,n) \triangleq \inf_{\hat{P}} \sup_{P \in \mathcal{P}_k} \mathbb{E}_P[D(P\|\hat{P})] \qquad R^*_{\text{revKL}}(k,n) \triangleq \inf_{\hat{P}} \sup_{P \in \mathcal{P}_k} \mathbb{E}_P[D(\hat{P}\|P)]$$
$$R^*_{\chi^2}(k,n) \triangleq \inf_{\hat{P}} \sup_{P \in \mathcal{P}_k} \mathbb{E}_P[\chi^2(P\|\hat{P})]$$

对于所有 k, n，我们有（至多相差全局常数因子）：

$$R^*_{\text{KL}}(k,n) \asymp R^*_{\text{revKL}}(k,n) \asymp \log\left(1 + \frac{k}{n}\right) \asymp \begin{cases} \frac{k}{n} & k \leq 1.1n \\ \log \frac{k}{n} & k > 1.1n \end{cases} \tag{VI.16}$$

$$R^*_{\chi^2}(k,n) \asymp \frac{k}{n}. \tag{VI.17}$$

(a) 证明TV损失（练习VI.8）下的最优经验分布蕴含了所声称的逆KL损失上界（提示：(7.58)）。另一方面，证明对于KL和χ^2，其导致无限损失。

(b) 为了展示 χ^2 的上界，考虑 (VI.10) 中带有 $\alpha = 1$ 的加-α 估计量 $\hat{P}$。证明

$$\mathbb{E}[\chi^2(P\|\hat{P})] \le \frac{k-1}{n+1}.$$

使用 (7.34) 推导出 (VI.16) 的上界部分。(提示：$\mathbb{E}_{N\sim\mathrm{Bin}(n,p)}[\frac{1}{N+1}] \frac{1}{(n+1)p}(1-\bar{p}^{n+1})$。

(c) 证明在 $k \lesssim n$ 的小字母表情形下，所有下界都可由 (VI.15) 推出。

(d) 接下来假设 $k \ge 4n$。考虑 (13.16) 中的 Dirichlet($\alpha,\dots,\alpha$) 先验。应用 (VI.11) 和 (VI.7) 于贝叶斯 χ^2 风险，并选择 $\alpha = n/k$，展示下界 $R^*_{\chi^2}(k,n) \gtrsim \frac{k}{n}$。

(e) 考虑这样一种先验：P 在支撑集 S 上均匀分布，而 S 是从 $[k]$ 的所有 s 子集中随机均匀选出的，其中 $s < k$ 需要指定。应用 (VI.6)，证明对于该先验，KL 损失下的贝叶斯估计量具有一种自然形式：

$$\hat{P}_j = \begin{cases} \frac{1}{s} & i \in \hat{S} \\ \frac{1-\hat{s}/s}{k-\hat{s}} & i \notin \hat{S} \end{cases}$$

其中 $\hat{S} = \{i : n_i \ge 1\}$ 是经验分布的支持集，且 $\hat{s} = |\hat{S}|$。

(f) 选择$s = \sqrt{nk}$，得出结论 $\mathbb{E}[\mathrm{TV}(P,\hat{P})] \ge 1 - 2\sqrt{\frac{n}{k}}$。（提示：证明 $\mathrm{TV}(P,\hat{P}) \ge (1-\frac{\hat{s}}{s})(1-\frac{s}{k})$ 和$\hat{s} \le n$。）

(g) 利用(7.31)，证明 $\mathbb{E}[D(\hat{P}\|P)], \mathbb{E}[D(P\|\hat{P})] \ge \Omega(\log\frac{k}{n})$，从而得出(VI.16)中的下界。（提示：(7.31)关于TV是凸的。）

Note: 对于 $k \asymp 1$，[258] 发现最佳的加-α 估计器具有 $\alpha^* \approx 0.509$（不同于第13.5节中累积损失的最优 $\alpha = 1/2$），并且其损失为 $\alpha^* \frac{k-1+o(1)}{n}$。在这种情况下，最优风险仅略小，等于 $R^*_{\mathrm{KL}}(k,n) = \frac{k-1+o(1)}{2n}$，这在 [72, 71] 中通过多项式逼近的深刻结果得到证明（最优估计器是加-c 估计器，但 c 根据每个箱中的经验计数而变化）。对于 $k \gg n$，Paninski [323] 通过对 Dirichlet 先验的仔细分析证明了 $R^*_{\mathrm{KL}}(k,n) = \log\frac{k}{n}(1+o(1))$。

VI.11（非参数模型）在本练习中，我们考虑高斯位置模型和伯努利模型的一些非参数扩展。观测到$X_1,\dots,X_n \overset{\text{i.i.d.}}{\sim} P$对于某个$P \in \mathcal{P}$，其中$\mathcal{P}$是实数轴上分布的集合，我们的目标是估计分布$P$的*mean*：$\mu(P) \triangleq \int xP(dx)$，这是$P$的线性泛函。将极小极大二次风险记为

$$R^*_n = \inf_{\hat{\mu}} \sup_{P\in\mathcal{P}} \mathbb{E}_P[(\hat{\mu}(X_1,\dots,X_n) - \mu(P))^2].$$

(a) 令 $\mathcal{P}$ 表示实数线上方差至多为 σ^2 的分布类（不必须具有密度）。证明 $R^*_n = \frac{\sigma^2}{n}$。

(b) 令 $\mathcal{P} = \mathcal{P}([0,1])$ 表示 $[0,1]$ 上所有概率分布的集合。证明 $R_n^* = \frac{1}{4(1+\sqrt{n})^2}$。（提示：对于上界，利用对任意取值于 $[0,1]$ 的随机变量 Z，有 $\mathrm{Var}(Z) \le \mathbb{E}[Z](1-\mathbb{E}[Z])$，并模仿习题 VI.7e 中对估计量 (VI.13) 的分析。）

VI.12 使用Fano方法证明定理30.2。（提示：应用定理31.3于$T = \epsilon \cdot S_k^d$，其中S_k^d表示d维空间中半径为k的汉明球。适当选择ϵ，并应用定理27.6中关于S_k^d的打包数的Gilbert-Varshamov界。）

VI.13（稀疏去噪中的锐极小极大率）继续定理30.2，在本练习中，我们确定高维稀疏向量去噪的锐极小极大风险。在（30.13）的记号中，我们证明，对于d维GLM模型$X \sim \mathcal{N}(\theta, I_d)$，以下极小极大风险满足：当$d \to \infty$和$k/d \to$趋于0时，

$$R^*(k,d) \triangleq \inf_{\hat{\theta}} \sup_{\|\theta\|_0 \le k} \mathbb{E}_\theta[\|\hat{\theta} - \theta\|_2^2] = (2+o(1))k \log \frac{d}{k}. \tag{VI.18}$$

(a) 我们首先考虑1-稀疏向量并证明

$$R^*(1,d) \triangleq \inf_{\hat{\theta}} \sup_{\|\theta\|_0 \le 1} \mathbb{E}_\theta[\|\hat{\theta} - \theta\|_2^2] = (2+o(1)) \log d, \qquad d \to \infty. \tag{VI.19}$$

对于下界，考虑先验 π，在该先验下 θ 均匀分布于 $\{\tau e_1, \ldots, \tau e_d\}$，其中 e_i 表示标准基。令 $\tau = \sqrt{(2-\epsilon)\log d}$。证明对于任意 $\epsilon > 0$，贝叶斯风险为

$$\inf_{\hat{\theta}} \mathbb{E}_{\theta \sim \pi}[\|\hat{\theta} - \theta\|_2^2] = \tau^2(1+o(1)), \qquad d \to \infty.$$

(提示：要么应用互信息方法，要么通过计算条件均值和条件方差直接计算贝叶斯风险。)

(b) 展示一个估计量 $\hat{\theta}$，其渐近地达到(VI.19)的右侧。(提示：考虑硬阈值估计量(30.13)或最大似然估计(30.11)。)

(c) 为了证明(VI.18)的下界部分，证明以下一般性结果

$$R^*(k,d) \ge kR^*\left(1, \frac{d}{k}\right)$$

然后应用(VI.19)。（提示：考虑一个由d/k个块组成的先验，每个块都是1-稀疏的。）(d) 类似于1-稀疏情况，展示一个渐近达到(VI.18)右侧的估计量$\hat{\theta}$。

注意：对于上界和下界，练习V.25中的正态尾界都是有帮助的。

VI.14 考虑GLM中的以下函数估计问题。观察到 $X \sim \mathcal{N}(\theta, I_d)$，我们打算估计 θ 的最大坐标：$T(\theta) = \theta_{\max} \triangleq \max\{\theta_1, \ldots, \theta_d\}$。证明最小最大速率：

$$\inf_{\hat{T}} \sup_{\theta \in \mathbb{R}^d} \mathbb{E}_\theta(\hat{T} - \theta_{\max})^2 \asymp \log d. \tag{VI.20}$$

(a) 通过考虑$\hat{T} = X_{\max}$，即带有MLE的插件估计器，证明上界。

(b) 对于下界，考虑两个假设：

$$H_0 : \theta = 0, \qquad H_1 : \theta \sim \mathrm{Unif}\{\tau e_1, \tau e_2, \ldots, \tau e_d\}.$$

其中 e_i 是标准基，且 $\tau > 0$。那么在 H_0 下，$X \sim P_0 = \mathcal{N}(0, I_d)$；在 H_1 下，$X \sim P_1 = \frac{1}{d}\sum_{i=1}^{d} \mathcal{N}(\tau e_i, I_d)$。证明 $\chi^2(P_1 \| P_0) = \frac{e^{\tau^2}-1}{d} - 1$。（提示：练习 I.48）

(c) 应用联合范围(7.32)（或(7.38)）来限制TV(P_0, P_1)，通过Le Cam方法（定理31.1）得出(VI.20)的下界部分。

(d) 通过改进上界和下界，证明其精确版本：

$$\inf_{\hat{T}} \sup_{\theta \in \mathbb{R}^d} \mathbb{E}_\theta (\hat{T} - \theta_{\max})^2 = \left(\frac{1}{2} + o(1)\right) \log d, \quad d \to \infty. \tag{VI.21}$$

VI.15（高维中MLE的次优性[55]）考虑d维GLM：$X \sim \mathcal{N}(\theta, I_d)$，其中$\theta$属于参数空间

$$\Theta = \left\{\theta \in \mathbb{R}^d : |\theta_1| \le d^{1/4}, \|\theta_{\setminus 1}\|_2 \le 2(1 - d^{-1/4}|\theta_1|)\right\}$$

使用 $\theta_{\setminus 1} \equiv (\theta_2, \ldots, \theta_d)$。对于平方损失，证明以下内容在 d 足够大时成立。

(a) 极小极大风险是有界的：

$$\inf_{\hat{\theta}} \sup_{\theta \in \Theta} \mathbb{E}_\theta [\|\hat{\theta} - \theta\|_2^2] \lesssim 1.$$

() 最大似然估计的最坏情况风险

$$\theta_{\mathrm{MLE}} \triangleq \operatorname*{argmin}_{\tilde{\theta} \in \Theta} \|X - \tilde{\theta}\|_2$$

是无界的：

$$\sup_{\theta \in \Theta} \mathbb{E}_\theta [\|\hat{\theta}_{\mathrm{MLE}} - \theta\|_2^2] \gtrsim \sqrt{d}.$$

VI.16（协方差模型）令 $X_1, \ldots, X_n \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0, \Sigma)$，其中 Σ 是一个 $d \times d$ 协方差矩阵。让我们证明，使用 $X_1, \ldots, X_n$ 估计 Σ 的极小极大二次风险满足

$$\inf_{\hat{\Sigma}} \sup_{\|\Sigma\|_{\mathrm{F}} \le r} \mathbb{E}[\|\hat{\Sigma} - \Sigma\|_{\mathrm{F}}^2] \asymp \left(\frac{d}{n} \wedge 1\right) r^2, \qquad \forall r > 0, d, n \in \mathbb{N}. \tag{VI.22}$$

其中 $\|\hat{\Sigma} - \Sigma\|_{\mathrm{F}}^2 = \sum_{ij} (\hat{\Sigma}_{ij} - \Sigma_{ij})^2$。

(a) 证明与位置模型不同，对于 Σ 若不限制在紧致参数空间内，(VI.22) 中的极小极大风险是无限的。

(b) 考虑样本协方差矩阵 $\hat{\Sigma} = \frac{1}{n}\sum_{i=1}^{n} X_i X_i^\top$。证明

$$\mathbb{E}[\|\hat{\Sigma} - \Sigma\|_{\mathrm{F}}^2] = \frac{1}{n}\left(\|\Sigma\|_{\mathrm{F}}^2 + \mathrm{Tr}(\Sigma)^2\right)$$

并使用此推导出(VI.22)中的极小化极大上界。

(c) 为了证明极小极大下界，我们可以分几步进行。证明对于任意半正定（PSD）$\Sigma_0, \Sigma_1 \succeq 0$，KL散度满足

$$D(\mathcal{N}(0, I_d + \Sigma_0) \| \mathcal{N}(0, I_d + \Sigma_1)) \le \frac{1}{2} \|\Sigma_0^{1/2} - \Sigma_1^{1/2}\|_{\mathrm{F}}^2, \tag{VI.23}$$

其中 I_d 是 $d \times d$ 单位矩阵。（提示：应用（2.8）。）

(d) 令 $B(\delta)$ 表示以零矩阵为中心、半径为 δ 的 Frobenius 球。令 $\mathsf{PSD} = \{X : X \succeq 0\}$ 表示 $d \times d$ 个 PSD 矩阵的集合。证明

$$\frac{\mathrm{vol}(B(\delta) \cap \mathsf{PSD})}{\mathrm{vol}(B(\delta))} = \mathbb{P}[Z \succeq 0], \tag{VI.24}$$

其中 Z 是一个根据高斯正交系综（GOE）分布的随机矩阵，即 Z 是对称的，具有独立的对角元素 $Z_{ii} \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0, 2)$ 和非对角元素 $Z_{ij} \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0, 1)$。

(e) 证明对于某个绝对常数 c，有 $\mathbb{P}[Z \succeq 0] \ge c^{d^2}$。[4]

(f) 证明以下关于半正定矩阵集合上装填数的下界：

$$M(B(\delta) \cap \mathsf{PSD}, \|\cdot\|_{\mathrm{F}}, \epsilon) \ge \left(\frac{c'\delta}{\epsilon}\right)^{d^2/2} \tag{VI.25}$$

对于某个绝对常数c'。（提示：利用体积界以及（d）和（e）部分的结果。）

(g) 完成(VI.22)下界的证明。（提示：不失一般性，我们可以考虑$r \asymp \sqrt{d}$，并瞄准下界$\Omega(\frac{d^2}{n} \wedge d)$。取(VI.25)中的填充，并通过单位矩阵$I$进行平移。然后应用Fano方法并使用(VI.23)。）

VI.17 对于一族概率分布 $\mathcal{P}$ 和一个泛函 T：$\mathcal{P} \to \mathbb{R}$，将其 χ^2-连续模定义为

$$\delta_{\chi^2}(t) = \sup_{P_1, P_2 \in \mathcal{P}} \{T(P_1) - T(P_2) : \chi^2(P_1 \| P_2) \le t\}.$$

当泛函 T 是仿射的、连续的，且 $\mathcal{P}$ 是紧的[5] 时，可以证明[346]

$$\frac{1}{7}\delta_{\chi^2}(1/n)^2 \le \inf_{\hat{T}_n} \sup_{P \in \mathcal{P}} \mathbb{E}_{X_i \overset{\text{i.i.d.}}{\sim} P}(T(P) - \hat{T}_n(X_1, \ldots, X_n))^2 \le \delta_{\chi^2}(1/n)^2. \tag{VI.26}$$

考虑以下问题（区间删失模型）：一个实验室用n只小鼠进行实验。在第i只小鼠中，肿瘤在时间$A_i \in [0, 1]$发展，具有$A_i \overset{\text{i.i.d.}}{\sim} \pi$，其中$\pi$是$[0, 1]$上的一个概率密度函数，且逐点有界于$\frac{1}{2} \le \pi \le 2$。对于每个$i$，在另一个随机时间$B_i \overset{\text{i.i.d.}}{\sim} \mathrm{Unif}(0, 1)$检查肿瘤的存在，具有$B_i \perp\!\!\!\perp A_i$。给定观测值$X_i = (1\{A_i \le B_i\}, B_i)$，人们试图估计$T(\pi) = \pi[A \le 1/2]$。证明

$$\inf_{\hat{T}_n} \sup_{\pi} \mathbb{E}[(T(\pi) - \hat{T}_n(X_1, \ldots, X_n))^2] \asymp n^{-2/3}.$$

[4] Getting the exact exponent is a difficult result (cf. [26]). Here we only need some crude estimate.

[5] Both under the same, but otherwise arbitrary topology on $\mathcal{P}$.

VI.18（收缩系数之间的比较。）证明 $\eta_f = \eta_{\mathrm{KL}}$ 的 (33.13)。

Hint: 使用 f-散度的局部行为（命题2.21）。

VI.19（马尔可夫链的谱隙与χ^2-压缩。）在本练习中，我们证明（33.18）。令$P = (P(x,y))$表示一个时间可逆马尔可夫链的转移矩阵，该链具有有限状态空间$\mathcal{X}$和平稳分布π，因此对所有$x, y \in \mathcal{X}$有$\pi(x)P(x,y) = \pi(y)P(y,x)$。已知$P$的$k = |\mathcal{X}|$个特征值满足1 $= \lambda_1 \geq \lambda_2 \geq \ldots \geq \lambda_k \geq -1$。通过$\gamma_* \triangleq \max\{\lambda_2, |\lambda_k|\}$定义绝对谱隙。

(a) 证明

$$\chi^2(P_{X_1}\|\pi) \leq \chi^2(P_{X_0}\|\pi)\gamma_*^2.$$

由此可得（33.18）。

(b) 得出结论，对于任意初始状态 x,

$$\chi^2(P_{X_n|X_0=x}\|\pi) \leq \frac{1-\pi(x)}{\pi(x)}\gamma_*^{2n}.$$

(c) 计算 BSC_δ 通道的 γ_*，并与 η_{χ^2} 收缩系数进行比较。

关于连续时间版本，请参见 [124]。

VI.20（通过二值输入实现输入无关的收缩系数 [321]）设 $K : \mathcal{X} \to \mathcal{Y}$ 是一个具有可数 $\mathcal{X}$ 的马尔可夫核。证明对于所有 f 散度，我们有

$$\eta_f(K) = \sup_{\substack{P,Q:|\mathrm{supp}(P)\cup\mathrm{supp}(Q)|\leq 2 \\ 0<D_f(P\|Q)<\infty}} \frac{D_f(K\circ P\|K\circ Q)}{D_f(P\|Q)}.$$

Hint: 定义函数

$$L_\lambda(P,Q) = D_f(K\circ P\|K\circ Q) - \lambda D_f(P\|Q)$$

并证明$\hat{Q} \mapsto L_\lambda(\frac{P}{Q}\hat{Q}, \hat{Q})$ 在集合上是凸的

$$\left\{\hat{Q} \in \mathcal{P}(\mathcal{X}) : \mathrm{supp}(\hat{Q}) \subseteq \mathrm{supp}(Q), \frac{P}{Q}\hat{Q} \in \mathcal{P}(\mathcal{X})\right\}.$$

VI.21（BMS信道比较[371，367]）下面$X \sim \mathrm{Ber}(1/2)$且$P_{Y|X}$是一个输入对称信道（BMS）。事实证明，BSC和BEC对于各种偏序是极端的。证明以下陈述。

(a) 如果 $I_{\mathrm{TV}}(X;Y) = \frac{1}{2}(1-2\delta)$，那么

$$\mathsf{BSC}_\delta \leq_{deg} P_{Y|X} \leq_{deg} \mathsf{BEC}_{2\delta}.$$

(b) 如果 $I(X;\ Y) = C$，那么

$$\mathsf{BSC}_{h^{-1}(\log 2 - C)} \leq_{mc} P_{Y|X} \leq_{mc} \mathsf{BEC}_{1-C/\log 2}.$$

(如果 $I_{\chi^2}(X;\ Y) = \eta$，那么

$$\mathsf{BSC}_{1/2-\sqrt{\eta}/2} \leq_{ln} P_{Y|X} \leq_{ln} \mathsf{BEC}_{1-\eta}.$$

(提示：应用练习 I.64.)

VI.22（在BSC上的树广播[204]）我们在例33.9中已经看到，在BSC_δ下，树上的广播（BOT）在$b(1-2\delta)^2<1$时具有非重构性。在本练习中，我们使用信道比较来证明可达性界（称为Kesten-Stigum界[244]）。我们研究一个具有BSC_δ边信道的无限b叉树。设ρ为根，L_k为距离k到ρ处的节点集合。设M_k表示信道$X_\rho \to X_{L_k}$。

以下内容中，假设 $b(1-2\delta)^2>1$。

(a) 证明存在 $\tau<\frac{1}{2}$ 使得

$$\mathsf{BSC}_\tau \le_{ln} \mathsf{BSC}_\tau^{\otimes b}\circ M_1.$$

Hint: 使用练习VI.21。

(b) 通过对 k 的归纳法证明 $\mathsf{BSC}_\tau \le_{ln} M_k$。得出结论：重构成立。

Hint: 使用较少噪声排序的张量化。

VI.23（在二维网格上广播）考虑以下二维网格上的广播模型：

• 节点用 (i,j) 标记为 $i,j\in\mathbb{Z}$；当 $i<0$ 或 $j<0$ 时，• $X_{i,j}=0$；• $X_{0,0}\sim \mathrm{Ber}(\frac{1}{2})$；对于 $i,j\ge 0$ 和 $(i,j)\neq(0,0)$，其中 $Z_{i,j,k}\overset{\text{i.i.d.}}{\sim}\mathrm{Ber}(\delta)$，$f_{i,j}$ 是任意函数 $\{0,1\}\times\{0,1\}\to\{0,1\}$，则 • $X_{i,j}=f_{i,j}(X_{i-1,j}\oplus Z_{i,j,1}, X_{i,j-1}\oplus Z_{i,j,2})$。

设 $L_n=\{(n-i,i):\ 0\le i\le n\}$ 为第 n 层节点集合。设 p_c 为从 $(0,0)$ 到 L_n 的有向 *bond* 渗流阈值，对 $n\to\infty$。应用定理33.8证明对于 $(1-2\delta)^2<p_c$，我们有

$$\lim_{n\to\infty} I(X_{0,0};X_{L_n})=0.$$

已知 $p_c\approx 0.645$（例如 [231]）。

Note: 我们也可以不同地使用定理33.8。上文我们将每条有向边替换为BSC_δ。我们也可以考虑信道 $(X_{i-1,j},X_{i,j-1})\mapsto X_{i,j}$，并将其收缩系数与*directed site percolation*阈值p_c'关联起来。这样，只要

$$1-2\delta+4\delta^3-2\delta^4-2\delta(1-\delta)\sqrt{\delta(1+\delta)(1-\delta)(2-\delta)}<p_c'.$$

由于 $p_c'\approx 0.705$，结果表明键渗流结果更强。

VI.24（用于着色通道的输入相关收缩系数 [203]）固定一个整数 $q\ge 3$，并令 $\mathcal{X}=[q]$。考虑以下着色通道 K：$\mathcal{X}\to\mathcal{X}$:

$$K(y|x)=\begin{cases}0 & y=x,\\ \frac{1}{q-1} & y\neq x.\end{cases}$$

让 π 为 $\mathcal{X}$ 上的均匀分布。

(a) 计算 $\eta_{\mathrm{KL}}(\pi,K)$。

(b) 得出结论：存在一个函数 $f(q)=(1-o(1))q\log q$ 当 $q\to\infty$ 时，使得对于所有 $d<f(q)$，在 d 叉树上使用着色信道的 BOT 具有非重建性。

Note: 该界在一阶范围内是紧的：存在函数$g(q) = (1 + o(1))q \log q$，使得对于所有$d > g(q)$，在$d$叉树上的具有着色信道的BOT具有重构。

VI.25（[203]）固定整数 $q \geq 2$，并令 $\mathcal{X} = [q]$。设 $\lambda \in [-\frac{1}{q-1}, 1]$ 为实数。我们通过取 P_λ: $\mathcal{X} \to \mathcal{X}$为，来定义一种特殊的 q 元对称信道，称为 Potts 信道：

$$P_\lambda(y|x) = \begin{cases} \lambda + \frac{1-\lambda}{q} & y = x, \\ \frac{1-\lambda}{q} & y \neq x. \end{cases}$$

证明

$$\eta_{\mathrm{KL}}(P_\lambda) = \frac{q\lambda^2}{(q-2)\lambda + 2}.$$

VI.26（谱独立性[20]）称一个支撑在$[q]^n$上的概率分布$\mu = \mu_{X^n}$是c-两两独立的，如果对每个$T \subset [n]$，$\sigma_T \in [q]^T$，条件测度$\mu^{(\sigma_T)} \triangleq \mu_{X_{T^c}|X_T=\sigma_T}$对每个$\nu_{X_{T^c}}$满足，

$$\sum_{i \neq j \in T^c} D(\nu_{X_i,X_j} || \mu^{(\sigma_T)}_{X_i,X_j}) \geq (2 - \frac{c}{n - |T| - 1}) \sum_{i \in T^c} D(\nu_{X_i} || \mu^{(\sigma_T)}_{X_i}) .$$

证明对于这样的测度 μ，我们有

$$\eta_{\mathrm{KL}}(\mu, \mathrm{EC}_\tau^{\otimes n}) \leq 1 - \tau^{c+1},$$

其中EC_τ是删除信道，参见例33.6。（*Hint:* 定义$f(\tau) = D(\mathrm{EC}_\tau^{\otimes n} \circ \nu || \mathrm{EC}_\tau^{\otimes n} \circ \mu)$ 并证明 $f'(\tau) \geq \frac{c}{\tau} f'(\tau)$。）

Remark: 将上述内容应用于 $\tau = \frac{1}{n}$ 表明，一个被称为 μ 的（小块）Glauber 动力学的马尔可夫链 G_τ 在 $O(n^{c+1} \log n)$ 时间内混合。实际上，G_τ 包括首先应用 $\mathsf{EC}_\tau^{\otimes n}$，然后从条件分布 $\mu_{X_S|X_{S^c}}$ 中对集合 S 中的擦除进行“填补”。还已知，在所有 $\mu^{(\sigma_T)}$ (的协方差矩阵的算子范数一致有界的情况下（在 μ 和 $q = 2$ 的一些额外条件下），c-成对独立性得以蕴含，详见 [91])。因此，关于界定 $\eta_{\mathrm{KL}}(\mu, G_\tau)$ 的难题首先被简化为 $\eta_{\mathrm{KL}}(\mu, \mathsf{EC}_\tau^{\otimes n})$，然后转化为对协方差矩阵谱的研究。

参考文献

[1] E. Abbe and E. B. Adserà, “超越树结构的次可加性与卡方互信息”，载于 *2019 IEEE International Symposium on Information Theory (ISIT)*。IEEE，2019年，第697–701页。（第135页）[2] M. C. Abbott and B. B. Machta, “低噪声极限下信道容量问题从离散到连续解的标度律”，*Journal of Statistical Physics*，第176卷，第1期，第214–227页，2019年。（第248页）[3] I. Abou-Faycal, M. Trott, and S. Shamai, “离散时间无记忆瑞利衰落信道的容量”，*IEEE Transac- tion Information Theory*，第47卷，第4期，第1290 – 1301页，2001年。（第409页）[4] J. Acharya, C. L. Canonne, Y. Liu, Z. Sun, and H. Tyagi, “信息约束下的交互式推断”，*IEEE Transactions on Information Theory*，第68卷，第1期，第502–516页，2021年。（第658页）[5] J. Acharya, C. L. Canonne, Z. Sun, and H. Tyagi, “信息约束下交互式高维估计的统一下界”，*arXiv preprint arXiv:2010.06562*，2020年。（第658页）[6] R. Ahlswede, “率失真函数的极值性质”，*IEEE transactions on information theory*，第36卷，第1期，第166–171页，1990年。（第543页）[7] R. Ahlswede, B. Balkenhol, and L. Khachatrian, “关于固定自由码的一些性质”，载于 *Proceedings First INTAS International Seminar on Coding Theory and Combinatorics*，亚美尼亚察赫卡佐尔，1996年，第20–33页。（第208页）[8] R. Ahlswede and I. Csiszár, “通信约束下的假设检验”，*IEEE transactions on information theory*，第32卷，第4期，第533–542页，1986年。（第325页和第327页）[9] R. Ahlswede和J. Körner, “带有边信息的源编码及退化广播信道的逆定理，”*IEEE Transactions on Information Theory*，第21卷，第6期，第629–637页，1975年。（第227页）[10] S. M. Alamouti, “一种用于无线通信的简单发射分集技术，”*IEEE Journal on selected areas in communications*，第16卷，第8期，第1451–1458页，1998年。（第409页）[11] P. H. Algoet和T. M. Cover, “香农-麦克米伦-布雷曼定理的三明治证明，”*The annals of probability*，第899–909页，1988年。（第234页）[12] C. D. Aliprantis和K. C. Border, *Infinite Dimensional Analysis: a Hitchhiker’s Guide*，第3版。柏林：Springer-Verlag，2006年。（第130页）[13] N. Alon, “关于给定边数的图中指定类型子图的数量，”*Israel J. Math.*，第38卷，第1-2期，第116–130页，1981年。（第160页）[14] N. Alon和A. Orlitsky, “一对一码期望长度的下界，”*IEEE Transactions on Information The- ory*，第40卷，第5期，第1670–1672页，1994年。（第199页）[15] N. Alon和J. H. Spencer, *The Probabilis- tic Method*，第3版。John Wiley & Sons，2008年。（第208页和第353页）[16] P. Alquier, “PAC-Bayes界用户友好介绍，”*arXiv preprint arXiv:2110.11216*，2021年。（第83页）[17] S.-I. Amari和H. Nagaoka, *Methods of information geometry*。美国数学学会，2007年，第191卷。（第40页和第307页）

[18] G. Aminian、Y. Bu、L. Toni、M. R. Rodrigues 和 G. Wornell，“用对称化KL信息刻画Gibbs算法的泛化误差”，*arXiv preprint arXiv:2107.13656*，2021年。（第187页）[19] V. Anantharam、A. Gohari、S. Kamath 和 C. Nair，“关于Erkip和Cover研究的最大相关性、超收缩性与数据处理不等式”，*arXiv preprint arXiv:1304.6133*，2013年。（第638页）[20] N. Anari、K. Liu 和 S. O. Gharan，“高维扩展器中的谱独立性与硬核模型的应用”，*SIAM Journal on Computing*，第0期，第FOCS20–1页，2021年。（第671页）[21] T. W. Anderson，“对称单峰函数在对称凸集上的积分及一些概率不等式”，*Proceedings of the American Mathematical Society*，第6卷，第2期，第170–176页，1955年。（第572页）[22] A. Antos 和 I. Kontoyiannis，“离散分布函数估计的收敛性质”，*Random Structures & Algorithms*，第19卷，第3-4期，第163–193页，2001年。（第138页）[23] E. Ar kan，“信道极化：一种为对称二进制输入无记忆信道构造达到容量码的方法”，*IEEE Transactions on information Theory*，第55卷，第7期，第3051–3073页，2009年。（第346页）[24] S. Arimoto，“一种计算任意离散无记忆信道容量的算法”，*IEEE Transactions on Infor- mation Theory*，第18卷，第1期，第14–20页，1972年。（第102页）[25] ——，“关于离散无记忆信道编码定理的逆定理（通讯）”，*IEEE Transactions on Information Theory*，第19卷，第3期，第357–359页，1973年。（第433页）[26] G. B. Arous 和 A. Guionnet，“Wigner定律和Voiculescu非交换熵的大偏差”，*Probability Theory and Related fields*，第108卷，第4期，第517–542页，1997年。(第668页) [27] S. Artstein、K. Ball、F. Barthe和A. Naor，“关于熵单调性的香农问题的解”，*Journal of the American Mathematical Society*，第975–982页，2004年。(第64页) [28] S. Artstein、V. Milman和S. J. Szarek，“度量熵的对偶性”，*Annals of math- ematics*，第1313–1328页，2004年。(第535页) [29] J. Baik、G. Ben Arous和S. Péché，“非零复数样本协方差矩阵最大特征值的相变”，*The Annals of Probability*，第33卷，第5期，第1643–1697页，2005年。(第651页) [30] A. V. Banerjee，“一个简单的羊群行为模型”，*The Quarterly Journal of Eco- nomics*，第107卷，第3期，第797–817页，1992年。(第135和181页) [31] Z. Bar-Yossef、T. S. Jayram、R. Kumar和D. Sivakumar，“数据流与通信复杂性的一种信息统计方法”，*Journal of Computer and System Sciences*，第68卷，第4期，第702–732页，2004年。(第182页) [32] B. Bárány和I. Kolossváry，“关于Blackwell测度的绝对连续性”，*Journal of Statistical Physics*，第159卷，第158–171页，2015年。(第111页) [33] B. Bárány、M. Pollicott和K. Simon，“射影变换的平稳测度：Blackwell与Furstenberg测度”，*Journal of Statistical Physics*，第148卷，第393–421页，2012年。(第111页) [34] A. Barg和G. D. Forney，“随机码：最小距离与误差指数”，*IEEE Transactions on Information Theory*，第48卷，第9期，第2568–2573页，2002年。(第433页) [35] A. Barg和A. McGregor，“二元码的距离分布与译码错误概率”，*IEEE Transactions on Information Theory*，第51卷，第12期，第4237–4246页，2005年。(第433页) [36] S. Barman和O. Fawzi，“最优信道编码的算法方面”，*IEEE Transactions on Information Theory*，

第64卷，第2期，第1038–1045页，2017年。（第366、367、368和369页）[37] A. R. Barron，“S形函数叠加的通用逼近界”，*IEEE Trans. Inf. Theory*，第39卷，第3期，第930–945页，1993年。（第534页）[38] P. L. Bartlett和S. Mendelson，“Rademacher和高斯复杂度：风险界和结构结果”，*Journal of Machine Learning Research*，第3卷，第Nov期，第463–482页，2002年。（第86页）[39] G. Basharin，“关于独立随机变量序列熵的统计估计”，*Theory of Probability & Its Applications*，第4卷，第3期，第333–336页，1959年。（第584页）[40] A. Beck，*First-order methods in optimiza- tion*。SIAM，2017年。（第92页）[41] A. Beirami和F. Fekri，“参数源通用无损一对一压缩的基本限制”，载于*Informa- tion Theory Workshop (ITW)*。IEEE，2014年，第212–216页。（第250页）[42] C. H. Bennett，“关于Landauer原理、可逆计算和麦克斯韦妖的注释”，*Studies In History and Philosophy of Science Part B: Studies In History and Philosophy of Modern Physics*，第34卷，第3期，第501–510页，2003年。（第xix页）[43] C. H. Bennett、P. W. Shor、J. A. Smolin和A. V. Thapliyal，“噪声量子信道的纠缠辅助经典容量”，*Physical Review Letters*，第83卷，第15期，第3081页，1999年。（第498页）[44] W. R. Bennett，“量化信号的频谱”，*The Bell System Technical Journal*，第27卷，第3期，第446–472页，1948年。（第483页）[45] P. Bergmans，“加性白高斯噪声广播信道的简单逆定理（通信）”，*IEEE Transactions on Information Theory*，第20卷，第2期，第279–280页，1974年。（第65页）[46] J. M. Bernardo，“贝叶斯推断的参考后验分布”，*Journal of the Royal Statistical Society: Series B (Methodological)*，第41卷，第2期，第113–128页，1979年。（第253页）[47] C. Berrou、A. Glavieux 和 P. Thitimajshima，“接近香农限的纠错编码与解码：Turbo码。1”，载于 *Proceedings of ICC'93-IEEE International Conference on Communications*，第2卷。IEEE，1993年，第1064–1070页。（第346页和第411页）[48] J. C. Berry，“有界正态均值向量的极小极大估计”，*Journal of Multivariate Analysis*，第35卷，第1期，第130–139页，1990年。（第587页）[49] D. P. Bertsekas、A. Nedi 和 A. E. Ozdaglar，*Convex analysis and optimiza- tion*。Belmont, MA, USA: Athena Scientific，2003年。（第93页）[50] N. Bhatnagar、J. Vera、E. Vigoda 和 D. Weitz，“树上着色的重构”，*SIAM Journal on Discrete Mathe- matics*，第25卷，第2期，第809–826页，2011年。（第644页）[51] A. Bhatt、B. Nazer、O. Ordentlich 和 Y. Polyanskiy，“信息蒸馏量化器”，*IEEE Transactions on Information Theory*，第67卷，第4期，第2472–2487页，2021年。（第190页）[52] A. Bhattacharyya，“关于由概率分布定义的两个统计总体间散度的一个度量”，*Bull. Calcutta Math. Soc.*，第35卷，第99–109页，1943年。（第117页）[53] L. Birgé，“度量空间中的逼近与估计理论”，*Zeitschrift für Wahrscheinlichkeitstheorie und Verwandte Gebiete*，第65卷，第2期，第181–237页，1983年。（第xxii、602和614页）[54] ——，“使用Hellinger距离估计密度及其他一些奇特事实”，*Probability theory and related fields*，第71卷，第2期，第271–291页，1986年。（第625页）[55] L. Birgé，“通过检验进行模型选择：对（惩罚）最大似然估计量的一种替代”，*Annales de l'I.H.P. Prob- abilités et statistiques*，第42卷，第3期，第273–325页，2006年。（第667页）[56] L. Birgé，“用于模型选择的稳健检验”，*From probability to statistics and back: high-dimensional models and processes–A*

Festschrift in honor of Jon A. Wellner, IMS Collections, Volume 9，第47–64页，2013年。（第613页）[57] M. . Birman和M. Solomjak，“函数类的分段多项式逼近，”*Mathematics of the USSR- Sbornik*，第2卷，第3期，第295页，1967年。（第538页）[58] N. Blachman，“熵幂的卷积不等式，”*IEEE Transactions on Information theory*，第11卷，第2期，第267–271页，1965年。（第185页）[59] D. Blackwell、L. Breiman和A. Thomasian，“一类信道的容量，”*The Annals of Mathematical Statistics*，第1229–1241页，1959年。（第465页）[60] D. H. Blackwell，“有限状态马尔可夫链函数的熵，”*Transactions of the first Prague conference on information theory, statistical decision functions, random processes*，第13–20页，1956年。（第111页）[61] R. E. Blahut，“假设检验与信息论，”*IEEE Trans. Inf. Theory*，第20卷，第4期，第405–417页，1974年。（第289页）[62] R. Blahut，“信道容量和率失真函数的计算，”*IEEE transactions on Information Theory*，第18卷，第4期，第460–473页，1972年。（第102页）[63] P. M. Bleher、J. Ruiz和V. A. Zagrebnov，“关于Bethe格上Ising模型极限吉布斯态的纯度，”*Jour- nal of Statistical Physics*，第79卷，第1期，第473–482页，1995年4月。（第642和643页）[64] S. G. Bobkov和F. Götze，“与对数Sobolev不等式相关的指数可积性和运输成本，”*Journal of Functional Analysis*，第163卷，第1期，第1–28页，1999年。（第656页）[65] S. Bobkov和G. P. Chistyakov，“Rényi熵的熵幂不等式。”*IEEE Transactions on Information Theory*，第61卷，第2期，第708–714页，2015年。（第27页）[66] T. Bohman，“奇环的Shannon容量极限定理I，”*Proceedings of the American Mathematical Society*，第131卷，第11期，第3559–3569页，2003年。（第452页）[67] H. F. Bohnenblust，“Minkowski空间中的凸区域与投影”，*Ann. Math.*，第39卷，第2期，第301–308页，1938年。（第96页）[68] A. Borovkov，*Mathematical Statistics*。CRC出版社，1999年。（第xxii、141、581和582页）[69] S. Boucheron、G. Lugosi和P. Massart，*Concentration Inequalities: A Nonasymptotic Theory of Independence*。牛津大学出版社，2013年。（第85、151、302和541页）[70] O. Bousquet、D. Kane和S. Moran，“密度估计中的最优逼近因子”，载于*Conference on Learn- ing Theory*。PMLR，2019年，第318–341页。（第622页）[71] D. Braess和T. Sauer，“Bernstein多项式与学习理论”，*Journal of Approximation Theory*，第128卷，第2期，第187–206页，2004年。（第665页）[72] D. Braess、J. Forster、T. Sauer和H. U. Simon，“如何从未知有限分布实现极小极大期望Kullback-Leibler距离”，载于*Algorithmic Learning Theory*。Springer，2002年，第380–394页。（第665页）[73] M. Braverman、A. Garg、T. Ma、H. L. Nguyen和D. P. Woodruff，“通过分布式数据处理不等式研究统计估计问题的通信下界”，载于*Proceedings of the forty-eighth annual ACM symposium on Theory of Computing*。ACM，2016年，第1011–1020页。（第657和658页）[74] L. M. Bregman，“非负矩阵及其积和式的一些性质”，*Soviet Math. Dokl.*，第14卷，第4期，第945–949页，1973年。（第161页）[75] L. Breiman，“信息论的个体遍历定理”，*Ann. Math. Stat.*，第28卷，第3期，第809–811页，1957年。（第234页）[76] L. Brillouin，*Science and information the- ory, 2nd Ed.* 学术出版社，1962年。（第xvii页）[77] L. D. Brown，“统计指数族的基础及其应用

在统计决策理论中，”载于 *Lecture Notes-Monograph Series*，S. S. Gupta 编。Hayward, CA: 数理统计学会，1986，第 9 卷。（第 298、309 和 310 页）[78] P. Bühlmann 和 S. van de Geer，*Statistics for high-dimensional data: methods, theory and applications*。Springer Science & Business Media，2011。（第 xxii 页）[79] M. V. Burnashev，“带反馈的离散信道上的数据传输。随机传输时间，”*Prob. Peredachi Inform.*，第 12 卷，第 4 期，第 10–30 页，1976。（第 456 页）[80] G. Calinescu、C. Chekuri、M. Pal 和 J. Vondrák，“在拟阵约束下最大化单调子模函数，”*SIAM Journal on Computing*，第 40 卷，第 6 期，第 1740–1766 页，2011。（第 368 和 369 页）[81] M. X. Cao 和 M. Tomamichel，“关于‘有限块长度区域中的信道编码速率’的评论：论信息速率函数的二次衰减性质，”*IEEE Transactions on Information Theory*，第 69 卷，第 9 期，2023。（第 435 页）[82] G. Casella 和 W. E. Strawderman，“估计有界正态均值，”*The Annals of Statistics*，第 9 卷，第 4 期，第 870–878 页，1981。（第 587 页）[83] O. Catoni，“PAC-贝叶斯监督分类：统计学习的热力学，”*Lecture Notes-Monograph Series. IMS*，第 1277 卷，2007。（第 83 页）[84] E. Çinlar，*Probability and Stochastics*。New York: Springer，2011。（第 20、29、30、31、32、80 和 319 页）[85] N. N. Cencov，*Statistical decision rules and optimal inference*。American Mathematical Soc.，2000，第 53 期。（第 40、307 和 309 页）[86] N. Cesa-Bianchi 和 G. Lugosi，*Prediction, learning, and games*。Cambridge university press，2006。（第 255 页）[87] D. G. Chapman 和 H. Robbins，“无正则性条件下的最小方差估计假设，”*The Annals of Mathematical Statistics*，第 22 卷，第 4 期，第 581–586 页，1951 年。（第 575 页）[88] Z. Chase 和 S. Lovett，“近似并集封闭猜想，”*arXiv preprint arXiv:2211.11689*，2022 年。（第 189 页）[89] S. Chatterjee，“Sudakov-Fernique 不等式中的一个误差界，”*arXiv preprint arXiv:0510424*，2005 年。（第 531 页）[90] S. Chatterjee 和 P. Diaconis，“重要性采样中所需的样本量，”*The Annals of Applied Probability*，第 28 卷，第 2 期，第 1099–1135 页，2018 年。（第 337 页）[91] Z. Chen、K. Liu 和 E. Vigoda，“Glauber 动力学的最优混合：通过高维展开的熵分解，”载于 *Proceedings of the 53rd Annual ACM SIGACT Symposium on Theory of Comput- ing*，2021 年，第 1537–1550 页。（第 671 页）[92] H. Chernoff，“大样本理论：参数情形，”*The Annals of Mathematical Statistics*，第 27 卷，第 1 期，第 1–22 页，1956 年。（第 661 页）[93] M. Choi、M. Ruskai 和 E. Seneta，“某些熵收缩系数的等价性，”*Linear algebra and its applications*，第 208 卷，第 29–36 页，1994 年。（第 632 页）[94] N. Chomsky，“语言描述的三种模型，”*IRE Trans. Inform. Th.*，第 2 卷，第 3 期，第 113–124 页，1956 年。（第 195 页）[95] B. S. Clarke 和 A. R. Barron，“Bayes 方法的信息论渐近性，”*IEEE Trans. Inf. Theory*，第 36 卷，第 3 期，第 453–471 页，1990 年。（第 253 页）[96] ——，“Jeffreys 先验在熵风险下渐近最不利，”*Journal of Statistical planning and Inference*，第 41 卷，第 1 期，第 37–60 页，1994 年。（第 253 页）[97] J. E. Cohen、J. H. B. Kemperman 和 G. Zb ganu，*Comparisons of Stochastic Matrices with Applications in Information Theory, Statistics, Economics and Popula- tion*。Springer，1998 年。（第 632 页）[98] A. Collins 和 Y. Polyanskiy，“有限块长度下的相干多天线块衰落信道，”*IEEE Transactions on*

Information Theory，第 65 卷，第 1 期，第 380–405 页，2018 年。（第 437 页）[99] J. H. Conway 和 N. J. A. Sloane，*Sphere packings, lattices and groups*。Springer Science & Business Media，1999 年，第 290 卷。（第 527 页）[100] M. Costa，“一种新的熵功率不等式，”*IEEE Transactions on Information Theory*，第 31 卷，第 6 期，第 751–760 页，1985 年。（第 64 页）[101] D. J. Costello 和 G. D. Forney，“信道编码：通往信道容量之路，”*Pro- ceedings of the IEEE*，第 95 卷，第 6 期，第 1150–1177 页，2007 年。（第 411 页）[102] T. A. Courtade，“熵与费舍尔信息的单调性：通过最大相关性的快速证明，”*Communications in Information and Systems*，第 16 卷，第 2 期，第 111–115 页，2017 年。（第 64 页）[103] ——，“一种强熵功率不等式，”*IEEE Transactions on Information Theory*，第 64 卷，第 4 期，第 2173–2192 页，2017 年。（第 64 页）[104] T. M. Cover，“通用数据压缩与投资组合选择，”载于 *Proceedings of 37th Conference on Foundations of Computer Science*。IEEE，1996 年，第 534–538 页。（第 xx 页）[105] T. M. Cover 和 B. Gopinath，*Open problems in communication and computation*。Springer Science & Business Media，2012 年。（第 413 页）[106] T. M. Cover 和 J. A. Thomas，*Elements of information theory, 2nd Ed.* 纽约，纽约州，美国：Wiley-Interscience，2006 年。（第 xvii、xx、xxi、65、210、216、355、466 和 501 页）[107] H. Cramér，“关于正态分布函数的一个性质，”*Mathematische Zeitschrift*，第 41 卷，第 1 期，第 405–414 页，1936 年。（第 101 页）[108] ——，*Mathematical methods of statistics*。普林斯顿大学出版社，1946 年。（第 576 页）[109] I. Csiszár，“概率分布差异的信息型度量与间接观测，”*Studia Sci. Math. Hungar.*，第 2 卷，第 229–318 页，1967 年。（第 115 页）

[110] I. Csiszár 和 J. Körner，“图分解：编码定理的新钥匙，”*IEEE Trans. Inf. Theory*，第27卷，第1期，第5-12页，1981年。（第47页）[111] ——，*Information Theory: Coding Theorems for Discrete Memoryless Systems*。纽约：学术出版社，1981年。（第xvii, xx, xxi, 355, 499, 500, 502和647页）[112] I. Csiszár 和 P. C. Shields，“信息论与统计学：教程，”*Foundations and Trends in Communications and Information Theory*，第1卷，第4期，第417-528页，2004年。（第104和250页）[113] I. Csiszár 和 G. Tusnády，“信息几何与交替最小化问题，”*Statistics & Decision, Supplement Issue No*，第1卷，1984年。（第102和103页）[114] I. Csiszár，“*I*-概率分布的散度几何与最小化问题，”*The Annals of Probability*，第146-158页，1975年。（第303和312页）[115] I. Csiszár 和 J. Körner，*Information Theory: Coding Theorems for Discrete Memoryless Systems*，第二版。剑桥大学出版社，2011年。（第xx, xxi, 13, 216和426页）[116] P. Cuff，“分布式信道合成，”*IEEE Transactions on Information The- ory*，第59卷，第11期，第7071-7096页，2013年。（第503页）[117] M. Cuturi，“Sinkhorn距离：最优传输的快速计算，”*Advances in neural information processing systems*，第26卷，第2292-2300页，2013年。（第105页）[118] L. Davisson, R. McEliece, M. Pursley 和 M. Wallace，“高效通用无噪声源码，”*IEEE Transactions on Information Theory*，第27卷，第3期，第269-279页，1981年。（第270页）[119] A. Decelle, F. Krzakala, C. Moore 和 L. Zdeborová，“模块化网络随机块模型的渐近分析及其算法应用，”*Physical review E*，第84卷，第6期，第066106页，2011年。（第642页）

[120] A. Dembo 和 O. Zeitouni，*Large deviations techniques and applications*。纽约：Springer Verlag，2009年。（第291页和第308页）[121] A. P. Dempster、N. M. Laird 和 D. B. Rubin，“通过EM算法从不完整数据中求最大似然估计”，*Journal of the royal statistical society. Series B (methodological)*，第1–38页，1977年。（第103页）[122] P. Diaconis 和 L. Saloff-Coste，“有限马尔可夫链的对数Sobolev不等式”，*Ann. Probab.*，第6卷，第3期，第695–750页，1996年。（第133页和第191页）[123] P. Diaconis 和 D. Freedman，“有限可交换序列”，*The Annals of Probability*，第8卷，第4期，第745–764页，1980年。（第187页）[124] P. Diaconis 和 D. Stroock，“马尔可夫链特征值的几何界”，*The Annals of Applied Probability*，第1卷，第1期，第36–61页，1991年。（第641页和第669页）[125] H. Djellout、A. Guillin 和 L. Wu，“运输成本-信息不等式及其在随机动力系统和扩散中的应用”，*The Annals of Probabil- ity*，第32卷，第3B期，第2702–2732页，2004年。（第656页）[126] R. Dobrushin 和 B. Tsybakov，“带附加噪声的信息传输”，*IRE Transactions on Information Theory*，第8卷，第5期，第293–304页，1962年。（第548页）[127] R. L. Dobrushin，“非平稳马尔可夫链的中心极限定理，I”，*Theory Probab. Appl.*，第1卷，第1期，第65–80页，1956年。（第630页）[128] ——，“一种通过实验评估平稳序列熵的简化方法”，*Theory of Probability & Its Applications*，第3卷，第4期，第428–430页，1958年。（第584页）[129] ——，“信息论中香农基本定理的一般表述”，*Uspekhi Mat. Nauk*，第14卷，第6期，第3–104页，1959年，英文翻译见 *Eleven Papers in Analysis: Nine Papers on Differential Equations, Two on Information Theory*，美国数学学会翻译丛刊：第2辑，第33卷，1963年。（第83页）[130] ——，“信息最优编码香农理论中的数学问题”，载于 *Proc. 4th Berkeley Symp. Mathematics, Statistics, and Probability*，第1卷，美国加利福尼亚州伯克利，1961年，第211–252页。（第435页）[131] ——，“具有对称转移概率的DMC上传输错误概率的渐近界”，*Theor. Probability Appl.*，第7卷，第283–311页，1962年。（第383页和第446页）[132] J. Dong、A. Roth和W. J. Su，“高斯差分隐私”，*Journal of the Royal Statistical Society Series B: Statistical Methodology*，第84卷，第1期，第3–37页，2022年。（第182页）[133] D. L. Donoho，“Wald讲座I：与Kolmogorov和Shannon一起数比特”，*Note for the Wald Lectures, IMS Annual Meeting*，1997年7月。（第543页）[134] M. D. Donsker和S. S. Varadhan，“某些马尔可夫过程期望在大时间下的渐近评估。IV”，*Communications on Pure and Applied Mathematics*，第36卷，第2期，第183–212页，1983年。（第72页）[135] J. L. Doob，*Stochastic Processes*。纽约Wiley，1953年。（第233页）[136] F. du Pin Calmon、Y. Polyanskiy和Y. Wu，“输入受限加性噪声信道的强数据处理不等式”，*IEEE Transactions on Information Theory*，第64卷，第3期，第1879–1892页，2017年。（第325页）[137] J. C. Duchi、M. I. Jordan、M. J. Wainwright和Y. Zhang，“分布式统计估计的最优性保证”，*arXiv preprint arXiv:1405.0782*，2014年。（第657页和第658页）[138] J. Duda，“非对称数字系统：结合Huffman编码速度与压缩率的熵编码

算术编码，”*arXiv preprint arXiv:1311.2540*，2013年。(第246页) [139] R. M. Dudley，*Uniform central limit theo- rems*。剑桥大学出版社，1999年，第63期。(第86和535页) [140] G. Dueck，“多址信道的编码定理的强逆定理，”*J. Comb. Inform. Syst. Sci*，第6卷，第3期，第187–196页，1981年。(第187页) [141] G. Dueck和J. Körner，“离散无记忆信道在高于容量速率下的可靠性函数（通讯），”*IEEE Transactions on Information Theory*，第25卷，第1期，第82–85页，1979年。(第433页) [142] N. Dunford和J. T. Schwartz，*Linear operators, part 1: general theory*。John Wiley & Sons，1988年，第10卷。(第80页) [143] R. Durrett，*Probability: Theory and Exam- ples*，第4版。剑桥大学出版社，2010年。(第125页) [144] A. Dytso, S. Yagli, H. V. Poor和S. S. Shitz，“幅度受限加性高斯信道的容量实现分布：关于质点数的上界，”*IEEE Transactions on Information Theory*，第66卷，第4期，第2006–2022页，2019年。(第408页) [145] H. G. Eggleston，*Convexity*，数学与数学物理丛书。剑桥大学出版社，1958年，第47卷。(第129页) [146] A. El Alaoui和A. Montanari，“随机局部化的信息论视角，”*IEEE Transactions on Information Theory*，第68卷，第11期，第7423–7426页，2022年。(第191页) [147] A. El Gamal和Y.-H. Kim，*Network infor- mation theory*。剑桥大学出版社，2011年。(第xxi和501页) [148] R. Eldan，“通过熵高效测度分解驯服相关性及其在平均场近似中的应用，”*Probability Theory and Related Fields*，第176卷，第3-4期，第737–755页，2020年。(第191页) [149] P. Elias，“高效构造无偏随机序列，”*Annals of Mathematical Statistics*，第43卷，第3期，第865–870页，1972年。（第167页）[150] ——，“噪声信道的编码，”*IRE Convention Record*，第3卷，第37–46页，1955年。（第365页）[151] E. O. Elliott，“关于突发噪声信道中码的错误率的估计，”*Bell Syst. Tech. J.*，第42卷，第1977–1997页，1963年9月。（第111页）[152] D. M. Endres和J. E. Schindelin，“概率分布的新度量，”*IEEE Transactions on Information theory*，第49卷，第7期，第1858–1860页，2003年。（第117页）[153] P. Erdös，“关于图论的一些评论，”*Bulletin of the American Mathe- matical Society*，第53卷，第4期，第292–294页，1947年。（第215页）[154] P. Erdös和A. Rényi，“论随机图，I，”*Publicationes Mathematicae (Debrecen)*，第6卷，第290–297页，1959年。（第653页）[155] V. Erokhin，“离散随机变量的ε-熵，”*Theory of Probability & Its Appli- cations*，第3卷，第1期，第97–100页，1958年。（第547页）[156] K. Eswaran和M. Gastpar，“高斯噪声下的远程源编码：功率与熵功率的双重作用，”*IEEE Transactions on Information Theory*，2019年。（第657页）[157] W. Evans和N. Pippenger，“关于通过公式进行可靠计算的最大可容忍噪声，”*IEEE Transactions on Information Theory*，第44卷，第3期，第1299–1305页，1998年5月。（第629页）[158] W. S. Evans和L. J. Schulman，“信号传播与噪声电路，”*IEEE Transactions on Information Theory*，第45卷，第7期，第2367–2373页，1999年11月。（第627页）[159] M. Falahatgar，A. Orlitsky，V. Pichapati和A. Suresh，“学习马尔可夫分布：估计能否胜过压缩？”见*2016 IEEE International Symposium on Information Theory (ISIT)*。IEEE，2016年7月，第2689–2693页。（第258页）

[160] M. Feder, “使用有限状态机进行赌博”，*IEEE Transactions on Informa- tion Theory*，第37卷，第5期，第1459–1465页，1991年。（第264页） [161] M. Feder、N. Merhav和M. Gutman, “个体序列的通用预测”，*IEEE Trans. Inf. Theory*，第38卷，第4期，第1258–1270页，1992年。（第260页） [162] M. Feder和Y. Polyanskiy, “对数损失和误指定下的序贯预测”，载于*Conference on Learning Theory*。PMLR，2021年，第1937–1964页。（第175和261页） [163] A. A. Fedotov、P. Harremoës和F. Topøe, “Pinsker不等式的改进”，*Information Theory, IEEE Transactions on*，第49卷，第6期，第1491–1498页，2003年6月。（第131页） [164] W. Feller, *An Introduction to Probability Theory and Its Applications*，第3版。New York: Wiley，1970年，第I卷。（第538页） [165] ——，*An Introduction to Probability Theory and Its Applications*，第2版。New York: Wiley，1971年，第II卷。（第435页） [166] T. S. Ferguson，*Mathematical Statistics: A Decision Theoretic Approach*。New York, NY: Academic Press，1967年。（第558页） [167] ——，“一个不一致的最大似然估计”，*Journal of the American Statistical Association*，第77卷，第380期，第831–834页，1982年。（第583页） [168] ——，*A course in large sample theory*。CRC Press，1996年。（第582页） [169] R. A. Fisher, “归纳推断的逻辑”，*Journal of the royal statistical soci- ety*，第98卷，第1期，第39–82页，1935年。（第xvii页） [170] B. M. Fitingof, “离散信息的压缩”，*Problemy Peredachi Informatsii*，第3卷，第3期，第28–36页，1967年。（第246页） [171] P. Fleisher, “在量化器中实现最小失真的充分条件”，*IEEE Int. Conv. Rec.*，第104–111页，1964年。（第481页）

[172] G. D. Forney, “级联码”，*MIT RLE Technical Rep.*，第440卷，1965年。（第378页） [173] E. Friedgut 和 J. Kahn, “关于一个超图在另一个超图中的副本数量”，*Israel J. Math.*，第105卷，第251–256页，1998年。（第160页） [174] P. Gács 和 J. Körner, “共同信息远少于互信息”，*Problems of Control and Information Theory*，第2卷，第2期，第149–162页，1973年。（第338页） [175] A. Galanis、D. tefankovi 和 E. Vigoda, “反铁磁Ising模型和硬核模型配分函数的不可近似性”，*Combinatorics, Probability and Computing*，第25卷，第4期，第500–559页，2016年。（第75页） [176] R. G. Gallager, “编码定理的一个简单推导及一些应用”，*IEEE Trans. Inf. Theory*，第11卷，第1期，第3–18页，1965年。（第360页） [177] ——，*Information Theory and Reliable Communication*。纽约：Wiley，1968年。（第xvii、xxi、383和432页） [178] R. Gallager, “随机编码界对平均码是紧的（通讯）”，*IEEE Transactions on Information Theory*，第19卷，第2期，第244–246页，1973年。（第433页） [179] R. Gardner, “Brunn-Minkowski不等式”，*Bulletin of the American Mathematical Society*，第39卷，第3期，第355–405页，2002年。（第573页） [180] A. M. Garsia，*Topics in almost everywhere convergence*。芝加哥：Markham Publishing Company，1970年。（第238页） [181] M. Gastpar、B. Rimoldi 和 M. Vetterli, “编码，还是不编码：有损信源—信道通信再探”，*IEEE Transactions on Information The- ory*，第49卷，第5期，第1147–1158页，2003年。（第521页） [182] I. M. Gel’fand、A. N. Kolmogorov 和 A. M. Yaglom, “关于信息量的通用定义”，*Dokl. Akad. Nauk. SSSR*，第11卷，第745–748页，1956年。（第70页）

[183] S. I. Gelfand 和 M. Pinsker, “具有随机参数的信道编码，” *Probl. Contr. Inform. Theory*，第 9 卷，第 1 期，第 19–31 页，1980 年。（第 468 页）[184] Y. Geng 和 C. Nair, “具有私有和公共消息的双接收机高斯向量广播信道的容量区域，” *IEEE Transactions on Information Theory*，第 60 卷，第 4 期，第 2087–2104 页，2014 年。（第 109 页）[185] G. L. Gilardoni, “关于 *f*-散度的 Gel’fand-Yaglom-Peres 定理，” *arXiv preprint arXiv:0911.1934*，2009 年。（第 154 页）[186] ——, “关于 Csiszár 散度的 Pinsker 型和 Vajda 型不等式，” *Information Theory, IEEE Transactions on*，第 56 卷，第 11 期，第 5377–5386 页，2010 年。（第 133 页）[187] E. N. Gilbert, “突发噪声信道的容量，” *Bell Syst. Tech. J.*，第 39 卷，第 1253–1265 页，1960 年 9 月。（第 111 页）[188] R. D. Gill 和 B. Y. Levit, “van Trees 不等式的应用：贝叶斯 Cramér-Rao 界，” *Bernoulli*，第 1 卷，第 1–2 期，第 59–79 页，1995 年。（第 577 页）[189] J. Gilmer, “并集闭集猜想的一个常数下界，” *arXiv preprint arXiv:2211.09055*，2022 年。（第 189 页）[190] C. Giraud, *Introduction to High-Dimensional Statistics*。Chapman and Hall/CRC，2014 年。（第 xxii 页）[191] G. Glaeser, “可微函数的平方根，” *Annales de l’institut Fourier*，第 13 卷，第 2 期，第 203–210 页，1963 年。（第 625 页）[192] O. Goldreich, *Introduction to property test- ing*。Cambridge University Press，2017 年。（第 325 页）[193] I. Goodfellow、J. Pouget-Abadie、M. Mirza、B. Xu、D. Warde-Farley、S. Ozair、A. Courville 和 Y. Bengio, “生成对抗网络，” *Advances in neural information processing systems*，第 27 卷，2014 年。（第 150 页）[194] V. Goodman, “正态样本的特征，” *The Annals of Probability*，第16卷，第3期，第1281–1290页，1988年。（第540页）[195] V. D. Goppa, “带记忆的非概率互信息”，*Probl. Contr. Inf. Theory*，第4卷，第97–102页，1975年。（第463页）[196] ——, “编码与信息”，*Russian Mathematical Surveys*，第39卷，第1期，第87页，1984年。（第463页）[197] R. M. Gray和D. L. Neuhoff, “量化”，*IEEE Trans. Inf. Theory*，第44卷，第6期，第2325–2383页，1998年。（第475页）[198] R. M. Gray, *Entropy and Information The- ory*。纽约：Springer-Verlag，1990年。（第xxi页）[199] U. Grenander和G. Szegö, *Toeplitz forms and their applications*，第2版。纽约：Chelsea Publishing Company，1984年。（第114页）[200] L. Gross, “对数Sobolev不等式”，*American Journal of Mathematics*，第97卷，第4期，第1061–1083页，1975年。（第107和191页）[201] Y. Gu, “信道比较方法与图上的统计问题”，博士论文，麻省理工学院，剑桥，马萨诸塞州，02139，美国，2023年。（第638页）[202] Y. Gu和Y. Polyanskiy, “Potts模型BP不动点的唯一性及其在社区检测中的应用”，载于*Conference on Learning Theory (COLT)*，2023年。（第135和644页）[203] ——, “Potts半群的非线性对数-Sobolev不等式及其在重建问题中的应用”，*Comm. Math. Physics*，（待发表），亦见arXiv:2005.05444。（第643、653、670和671页）[204] Y. Gu、H. Roozbehani和Y. Polyanskiy, “临界附近树上的广播”，载于*2020 IEEE International Symposium on Information Theory (ISIT)*。IEEE，2020年，第1504–1509页。（第670页）[205] D. Guo、S. Shamai (Shitz)和S. Verdú, “高斯信道中的互信息与最小均方误差”，*IEEE*

Trans. Inf. Theory，第 51 卷，第 4 期，第 1261 – 1283 页，2005 年 4 月。（第 59 页）[206] D. Guo, Y. Wu, S. S. Shamai, 和 S. Verdú，“高斯噪声中的估计：最小均方误差的性质，”*IEEE Transactions on Information Theory*，第 57 卷，第 4 期，第 2371–2385 页，2011 年。（第 63 页）[207] U. Hadar, J. Liu, Y. Polyanskiy, 和 O. Shayevitz，“估计相关性的通信复杂度，”载于 *Proceedings of the 51st Annual ACM SIGACT Symposium on Theory of Computing*。ACM，2019 年，第 792–803 页。（第 645 页）[208] B. Hajek, Y. Wu, 和 J. Xu，“恢复隐藏社区的信息极限，”*IEEE Trans. on Information Theory*，第 63 卷，第 8 期，第 4729 – 4745 页，2017 年。（第 591 页）[209] J. Hájek，“估计中的局部渐近极小极大与容许性，”载于 *Proceedings of the sixth Berkeley symposium on mathematical statistics and probability*，第 1 卷，1972 年，第 175–194 页。（第 582 页）[210] J. M. Hammersley，“关于受限参数的估计，”*Journal of the Royal Statistical Society. Series B (Methodolog- ical)*，第 12 卷，第 2 期，第 192–240 页，1950 年。（第 575 页）[211] T. S. Han, *Information-spectrum methods in information theory*。Springer Science & Business Media，2003 年。（第 xix 和 xxi 页）[212] T. S. Han 和 S. Verdú，“输出统计的近似理论，”*IEEE Transac- tions on Information Theory*，第 39 卷，第 3 期，第 752–772 页，1993 年。（第 504 和 505 页）[213] Y. Han, S. Jana, 和 Y. Wu，“有和没有谱隙的马尔可夫链的最优预测，”*IEEE Transactions on Information Theory*，第 69 卷，第 6 期，第 3920– 3959 页，2023 年。（第 258 页）[214] P. Harremoës 和 I. Vajda，“关于 *f*-散度对及其联合范围，”*IEEE Trans. Inf. Theory*，第 57 卷，第 6 期，第 3230– 3235 页，2011 年 6 月。（第 115、128 和 129 页）[215] B. Harris，“非参数情况下的熵的统计估计，”载于 *Topics in Information Theory*，I. Csiszár 和 P. Elias 编，Springer Netherlands，1975 年，第 16 卷，第 323–355 页。（第 584 页）[216] D. Haussler 和 M. Opper，“互信息、度量熵与累积相对熵风险”，*The Annals of Statistics*，第 25 卷，第 6 期，第 2451–2492 页，1997 年。（第 xxii 和 188 页）[217] M. Hayashi，“信道可分辨性与辨识容量的通用非渐近与渐近公式及其在窃听信道中的应用”，*IEEE Transactions on Information The- ory*，第 52 卷，第 4 期，第 1562–1575 页，2006 年。（第 505 页）[218] W. Hoeffding，“多项分布的渐近最优检验”，*The Annals of Mathematical Statistics*，第 369–401 页，1965 年。（第 289 页）[219] P. J. Huber，“Fisher 信息与样条插值”，*Annals of Statistics*，第 1029–1033 页，1974 年。（第 580 页）[220] ——，*Robust Statistics*。New York, NY: Wiley-Interscience，1981 年。（第 151 和 152 页）[221] ——，“概率比检验的稳健版本”，*The Annals of Mathematical Statistics*，第 1753–1758 页，1965 年。（第 324、338 和 613 页）[222] I. A. Ibragimov 和 R. Z. Khas’minsk，*Statistical Estimation: Asymptotic Theory*。Springer，1981 年。（第 xxii 和 143 页）[223] S. Ihara，“关于加性非高斯噪声信道的容量”，*Information and Control*，第 37 卷，第 1 期，第 34–39 页，1978 年。（第 401 页）[224] ——，*Information theory for continuous systems*。World Scientific，1993 年，第 2 卷。（第 419 页）[225] Y. I. Ingster 和 I. A. Suslina, *Nonparametric goodness-of-fit testing under Gaussian models*。New York, NY: Springer，2003 年。（第 134、185、325 和 561 页）[226] Y. I. Ingster，“L_p 度量下分布密度的非参数假设的极小极大检验”，*Theory of Probability & Its Applications*，第 31 卷，第 2 期，第 333–337 页，1987 年。（第 325 页）

[227] S. Janson, “随机正则图：渐近分布与毗连性”，*Combinatorics, Probability and Computing*，第4卷，第4期，第369–405页，1995年。（第186页）[228] S. Janson 和 E. Mossel，“树上的稳健重建由第二特征值决定”，*Ann. Probab.*，第32卷，第1A期，第2630–2649页，2004年。（第644页）[229] E. T. Jaynes，*Probability theory: The logic of science*。剑桥大学出版社，2003年。（第253页）[230] T. S. Jayram，“Hellinger 反击：关于 AND 的多方信息复杂性的注记”，载于 *International Workshop on Approximation Algorithms for Combinatorial Optimization*，2009年，第562–573页。（第183页）[231] I. Jensen 和 A. J. Guttmann，“有向正方和蜂窝晶格渗流概率的级数展开”，*Journal of Physics A: Mathematical and General*，第28卷，第17期，第4813页，1995年。（第670页）[232] Z. Jia、Y. Polyanskiy 和 Y. Wu，“学习高斯混合模型最优速率的熵刻画”，载于 *Conference on Learning Theory (COLT)*。PMLR，2023年。（第619页）[233] J. Jiao、K. Venkat、Y. Han 和 T. Weissman，“离散分布泛函的极小极大估计”，*IEEE Transactions on Information Theory*，第61卷，第5期，第2835–2885页，2015年。（第584页）[234] C. Jin、Y. Zhang、S. Balakrishnan、M. J. Wainwright 和 M. I. Jordan，“高斯混合模型似然中的局部极大值：结构结果与算法后果”，载于 *Advances in neural information processing systems*，2016年，第4116–4124页。（第105页）[235] W. B. Johnson、G. Schechtman 和 J. Zinn，“独立与可交换随机变量线性组合矩不等式中的最佳常数”，*The Annals of Probability*，第13卷，第1期，第234–253页，1985年。（第497页）

[236] I. Johnstone，*Gaussian estimation: Sequence and wavelet models*，2011，可在 http://www-stat.stanford.edu/~imj/ 获取。（第590页）[237] L. K. Jones，“希尔伯特空间中贪婪近似的一个简单引理及投影寻踪回归和神经网络训练的收敛速率”，*The Annals of Statistics*，第608–613页，1992。（第534页）[238] A. B. Juditsky 和 A. S. Nemirovski，“通过凸规划的非参数估计”，*The Annals of Statistics*，第37卷，第5A期，第2278–2300页，2009。（第566页）[239] S. M. Kakade、K. Sridharan 和 A. Tewari，“论线性预测的复杂度：风险界、间隔界和正则化”，*Advances in neural information processing systems*，第21卷，2008。（第87页）[240] S. Kamath、A. Orlitsky、D. Pichapati 和 A. Suresh，“从样本中学习分布”，载于 *Conference on Learning Theory*，2015年6月，第1066–1100页。（第258页）[241] T. Kawabata 和 A. Dembo，“集合与测度的率失真维数”，*IEEE Trans. Inf. Theory*，第40卷，第5期，第1564–1572页，1994年9月。（第542页）[242] M. Keane 和 G. O’Brien，“伯努利工厂”，*ACM Transactions on Modeling and Computer Simulation*，第4卷，第2期，第213–219页，1994。（第172页）[243] J. Kemperman，“论任意信道的香农容量”，载于 *Indagationes Mathematicae (Proceedings)*，第77卷，第2期。North-Holland，1974，第101–115页。（第97页）[244] H. Kesten 和 B. P. Stigum，“不可分解多维 Galton-Watson 过程的补充极限定理”，*The Annals of Mathematical Statistics*，第37卷，第6期，第1463–1481页，1966。（第644和670页）[245] D. P. Kingma 和 M. Welling，“自编码变分贝叶斯”，*arXiv preprint arXiv:1312.6114*，2013。（第76和77页）[246] D. P. Kingma、M. Welling *et al.*，“变分自编码器导论”，*Foun- dations and Trends® in Machine Learning*，第12卷，第4期，第307–392页，2019。（第77页）

[247] T. Koch, “香农下界是渐近紧的”，*IEEE Transactions on Information Theory*，第62卷，第11期，第6155–6161页，2016年。（第511页）[248] Y. Kochman、O. Ordentlich和Y. Polyanskiy，“联合信源信道编码期望失真的下界”，*IEEE Transactions on Information The- ory*，第66卷，第8期，第4722–4741页，2020年。（第521页）[249] A. Kolchinsky和B. D. Tracey，“利用成对距离估计混合熵”，*Entropy*，第19卷，第7期，第361页，2017年。（第188页）[250] A. N. Kolmogorov和V. M. Tikhomirov，“函数空间中集合的ε-熵和ε-容量”，*Uspekhi Matematicheskikh Nauk*，第14卷，第2期，第3–86页，1959年，重印于Shiryayev, A. N.编，*Selected Works of AN Kolmogorov: Volume III: Information Theory and the Theory of Algorithms*，第27卷，Springer Netherlands，1993年，第86–170页。（第522、523、524、526、535、538、539和543页）[251] I. Kontoyiannis和S. Verdú，“最优无损数据压缩：非渐近与渐近”，*IEEE Trans. Inf. Theory*，第60卷，第2期，第777–795页，2014年。（第198页）[252] J. Körner和A. Orlitsky，“零误差信息论”，*IEEE Transactions on Information Theory*，第44卷，第6期，第2207–2229页，1998年。（第374页）[253] V. Koshelev，“最小熵量化”，*Probl. Pered. Inform*，第14卷，第151–156页，1963年。（第483页）[254] V. Kostina、Y. Polyanskiy和S. Verdú，“允许错误的可变长度压缩”，*IEEE Transactions on Information Theory*，第61卷，第8期，第4316–4330页，2015年。（第548页）[255] V. Kostina和S. Verdú，“有限块长度机制下的固定长度有损压缩”，*IEEE Transactions on Information Theory*，第58卷，第6期，第3309–3338页，2012年。（第485页）

[256] O. Kosut 和 L. Sankar，“通用固定到可变源编码的渐近与非渐近特性”，*IEEE Transactions on Information Theory*，第 63 卷，第 6 期，第 3757–3772 页，2017 年。（第 250 页）[257] A. Krause 和 D. Golovin，“子模函数最大化”，*Tractability*，第 3 卷，第 71–104 页，2014 年。（第 367 页）[258] R. Krichevskiy，“拉普拉斯继承法则与通用编码”，*IEEE Trans- actions on Information Theory*，第 44 卷，第 1 期，第 296–303 页，1998 年 1 月。（第 665 页）[259] R. Krichevsky，“关于源信息合理性与编码冗余之间的关系”，*Problems Inform. Transmission*，第 4 卷，第 3 期，第 48–57 页，1968 年。（第 247 页）[260] R. Krichevsky 和 V. Trofimov，“通用编码的性能”，*IEEE Trans. Inf. Theory*，第 27 卷，第 2 期，第 199–207 页，1981 年。（第 254 页）[261] F. Krzaka a、A. Montanari、F. Ricci-Tersenghi、G. Semerjian 和 L. Zdeborová，“吉布斯态与随机约束满足问题的解集”，*Proceedings of the National Academy of Sciences*，第 104 卷，第 25 期，第 10 318–10 323 页，2007 年。（第 642 页）[262] J. Kuelbs，“Banach 空间值随机变量的强收敛定理”，*The Annals of Probability*，第 4 卷，第 5 期，第 744–771 页，1976 年。（第 540 页）[263] J. Kuelbs 和 W. V. Li，“度量熵与高斯测度的小球问题”，*Journal of Functional Analysis*，第 116 卷，第 1 期，第 133–157 页，1993 年。（第 540 和 541 页）[264] S. Kullback，*Information theory and statis- tics*。Mineola, NY: Dover publications，1968 年。（第 xxi 页）[265] C. Külske 和 M. Formentin，“Galton-Watson 树上 Markov 链非重构机制的对称熵界”，*Electronic Communications in Probability*，第 14 卷，第 587–596 页，2009 年。（第 135 页）

[266] H. O. Lancaster, “以列联表形式考虑的双变量正态分布的一些性质”, *Biometrika*, 第44卷, 第1/2期, 第289–292页, 1957年。（第641页）[267] R. Landauer, “计算过程中的不可逆性与热生成”, *IBM journal of research and development*, 第5卷, 第3期, 第183–191页, 1961年。（第xix页）[268] A. Lapidoth, *A foundation in digital communication*。剑桥大学出版社, 2017年。（第403页）[269] A. Lapidoth和S. M. Moser, “通过对偶性得到的容量界及其在平坦衰落信道上的多天线系统中的应用”, *IEEE Transactions on Informa- tion Theory*, 第49卷, 第10期, 第2426–2467页, 2003年。（第409页）[270] B. Laurent和P. Massart, “通过模型选择对二次泛函进行自适应估计”, *The Annals of Statistics*, 第28卷, 第5期, 第1302–1338页, 2000年。（第85页）[271] S. L. Lauritzen, *Graphical models*。Clarendon Press, 1996年, 第17卷。（第50和51页）[272] L. Le Cam, “维度限制下估计量的收敛性”, *Annals of Statistics*, 第1卷, 第1期, 第38–53页, 1973年。（第xxii页）[273] ——, *Asymptotic methods in statistical decision theory*。New York, NY: Springer-Verlag, 1986年。（第117、133、558、582、602和614页）[274] C. C. Leang和D. H. Johnson, “关于m假设贝叶斯检测的渐近性”, *IEEE Transactions on Informa- tion Theory*, 第43卷, 第1期, 第280–282页, 1997年。（第337页）[275] K. Lee、Y. Wu和Y. Bresler, “通过稀疏功率分解对稀疏秩一矩阵进行近最优压缩感知”, *IEEE Transactions on Information Theory*, 第64卷, 第3期, 第1666–1698页, 2018年3月。（第543页）[276] E. L. Lehmann和G. Casella, *Theory of Point Estimation*, 第2版。New York, NY: Springer, 1998年。（第xxii和564页）[277] E. Lehmann 和 J. Romano, *Testing Statistical Hypotheses*, 第3版。Springer, 2005年。（第275页和第325页）[278] W. V. Li 和 W. Linde, “高斯测度的逼近、度量熵和小球估计”, *The Annals of Proba- bility*, 第27卷, 第3期, 第1556-1578页, 1999年。（第541页）[279] W. V. Li 和 Q.-M. Shao, “高斯过程：不等式、小球概率及应用”, *Handbook of Statistics*, 第19卷, 第533-597页, 2001年。（第539、541和553页）[280] E. H. Lieb, “Wehrl熵猜想的证明”, *Communications in Mathematical Physics*, 第62卷, 第1期, 第35-41页, 1978年。（第64页）[281] T. Linder 和 R. Zamir, “关于香农下界的渐近紧性”, *IEEE Transactions on Information The- ory*, 第40卷, 第6期, 第2026-2031页, 1994年。（第511页）[282] R. S. Liptser, F. Pukel'sheim 和 A. N. Shiryaev, “概率测度的接近性和完全渐近分离的充要条件”, *Russian Mathematical Surveys*, 第37卷, 第6期, 第107页, 1982年。（第126页）[283] S. Litsyn, “错误指数的新上界”, *IEEE Transactions on Informa- tion Theory*, 第45卷, 第2期, 第385-398页, 1999年。（第433页）[284] S. Lloyd, “PCM中的最小二乘量化”, *IEEE transactions on information theory*, 第28卷, 第2期, 第129-137页, 1982年。（第480页）[285] G. G. Lorentz, M. v. Golitschek 和 Y. Makovoz, *Constructive approximation: advanced problems*。Springer, 1996年, 第304卷。（第523页和第538页）[286] L. Lovász, “关于图的香农容量”, *IEEE Transactions on Informa- tion theory*, 第25卷, 第1期, 第1-7页, 1979年。（第452页）[287] D. J. MacKay, *Information theory, inference and learning algorithms*。剑桥大学出版社, 2003年。（第xxi页）

[288] M. Madiman和P. Tetali, “联合分布的信息不等式及其解释与应用”, *IEEE Trans. Inf. Theory*, 第56卷, 第6期, 第2699-2713页, 2010年。(第18页) [289] M. Mahoney, “大型文本压缩基准”, http://www.mattmahoney.net/dc/text.html, 2021年8月。(第245页) [290] A. Makur和Y. Polyanskiy, “信道比较: 对称信道支配准则”, *IEEE Transactions on Information Theory*, 第64卷, 第8期, 第5704-5725页, 2018年。(第647页) [291] B. Mandelbrot, “语言统计结构的信息理论”, *Communication theory*, 第84卷, 第486-502页, 1953年。(第203、205和206页) [292] C. Manning和H. Schutze, *Foundations of statistical natural language processing*。MIT出版社, 1999年。(第351页) [293] J. Massey, “关于不同二进制n元组的分数权重(通讯)”, *IEEE Transactions on Information Theory*, 第20卷, 第1期, 第131-131页, 1974年。(第158页) [294] ——, “因果性、反馈与有向信息”, 载于*Proc. Int. Symp. Inf. Theory Applic.(ISITA-90)*, 1990年, 第303-305页。(第446和449页) [295] W. Matthews, “通过非信号码的Polyanskiy-Poor-Verdú有限块长度逆定理的线性规划”, *IEEE Transactions on Information Theory*, 第58卷, 第12期, 第7036-7044页, 2012年。(第429页) [296] H. H. Mattingly、M. K. Transtrum、M. C. Abbott和B. B. Machta, “最大化从有限数据中学习到的信息选择简单模型”, *Proceedings of the National Academy of Sciences*, 第115卷, 第8期, 第1760-1765页, 2018年。(第248页) [297] A. Maurer, “关于PAC贝叶斯定理的注记”, *arXiv preprint cs/0411099*, 2004年。(第83页) [298] D. A. McAllester, “一些PAC-贝叶斯定理”, 载于*Proceedings of the eleventh annual conference on Computational learning theory*, 1998, 第230–234页。(第83和88页) [299] R. McEliece、E. Rodemich、H. Rumsey和L. Welch, “通过Delsarte-Macwilliams不等式得到的码率新上界,” *IEEE transactions on Infor- mation Theory*, 第23卷, 第2期, 第157–166页, 1977年。(第432、434和528页) [300] R. J. McEliece和E. C. Posner, “捉迷藏、数据存储与熵,” *The Annals of Mathematical Statistics*, 第42卷, 第5期, 第1706–1716页, 1971年。(第543页) [301] B. McMillan, “信息论的基本定理,” *Ann. Math. Stat.*, 第196–219页, 1953年。(第234页) [302] S. Mendelson, “Rademacher平均与Glivenko-Cantelli类中的相变,” *IEEE Transactions on Informa- tion Theory*, 第48卷, 第1期, 第251–263页, 2002年。(第533页) [303] N. Merhav和M. Feder, “通用预测,” *IEEE Trans. Inf. Theory*, 第44卷, 第6期, 第2124–2147页, 1998年。(第260页) [304] G. A. Miller, “关于信息估计偏差的注记,” *Information theory in psychology: Problems and methods*, 第2卷, 第95–100页, 1955年。(第584页) [305] M. Mitzenmacher, “幂律和对数正态分布生成模型简史,” *Internet mathematics*, 第1卷, 第2期, 第226–251页, 2004年。(第203和206页) [306] E. Mossel, “系统发育中的相变,” *Transactions of the American Mathematical Society*, 第356卷, 第6期, 第2379–2404页, 2004年。(第642页) [307] E. Mossel、J. Neeman和A. Sly, “植入划分模型中的重构与估计,” *Probability Theory and Related Fields*, 第162卷, 第3-4期, 第431–461页, 2015年。(第186和642页) [308] E. Mossel和Y. Peres, “旧币新币: 未知偏差下的计算,” *Com- binatorica*, 第25卷, 第6期, 第707–724页, 2005年。(第172页) [309] J. Mourtada, “线性最小二乘的精确极小极大风险, 以及样本

协方差矩阵,” *The Annals of Statis- tics*, 第50卷, 第4期, 第2157–2178页, 2022年. (第86页) [310] X. Mu, L. Pomatto, P. Strack, 和 O. Tamuz, “从大样本中的Blackwell优势到Rényi散度及其回归,” *Econometrica*, 第89卷, 第1期, 第475–506页, 2021年. (第145页和第182页) [311] N. Mukhanova, “专注于儿童书籍的插画家,” https://nastyamukhanova.com/, 2023年. (第xvi页) [312] B. Nakibo lu, “通过Augustin方法的球填充界,” *IEEE Transactions on Information Theory*, 第65卷, 第2期, 第816–840页, 2018年. (第454页) [313] G. L. Nemhauser, L. A. Wolsey, 和 M. L. Fisher, “最大化子模集函数近似分析–I,” *Mathematical programming*, 第14卷, 第1期, 第265–294页, 1978年. (第367页和第368页) [314] J. Neveu, *Mathematical foundations of the calculus of probability*. Holden-day, 1965年. (第540页) [315] M. E. Newman, “幂律、帕累托分布与齐普夫定律,” *Contemporary physics*, 第46卷, 第5期, 第323–351页, 2005年. (第203页) [316] M. Okamoto, “关于二项概率部分和的一些不等式,” *Annals of the institute of Statistical Mathematics*, 第10卷, 第1期, 第29–35页, 1959年. (第302页) [317] R. I. Oliveira, “随机二次型的下尾及其在普通最小二乘法中的应用,” *Probability Theory and Related Fields*, 第166卷, 第1175–1194页, 2016年. (第86页) [318] B. Oliver, J. Pierce, 和 C. Shannon, “PCM的哲学,” *Proceedings of the IRE*, 第36卷, 第11期, 第1324–1331页, 1948年. (第477页) [319] Y. Oohama, “关于离散无记忆信道的两个强逆定理,” *IEICE Transactions on Fundamentals of Electronics, Communications and Computer Sciences*，第98卷，第12期，第2471–2475页，2015年。（第433页）[320] OpenAI，“GPT-4技术报告”，*arXiv preprint arXiv:2303.08774*，2023年。（第xix、110、195、257和258页）[321] O. Ordentlich和Y. Polyanskiy，“强数据处理常数由二进制输入实现”，*IEEE Trans. Inf. Theory*，第68卷，第3期，第1480–1481页，2022年3月。（第669页）[322] D. Ornstein，“具有相同熵的伯努利移位是同构的”，*Advances in Math- ematics*，第4卷，第3期，第337–352页，1970年。（第xix和230页）[323] L. Paninski，“KL损失下离散分布的变分极小极大估计”，*Advances in Neural Information Processing Systems*，第17卷，2004年。（第665页）[324] P. Panter和W. Dite，“非均匀电平间隔脉冲计数调制中的量化失真”，*Proceedings of the IRE*，第39卷，第1期，第44–48页，1951年。（第481页）[325] M. Pardo和I. Vajda，“关于满足信息论数据处理定理的离散分布的距离”，*IEEE transactions on information the- ory*，第43卷，第4期，第1288–1293页，1997年。（第121页）[326] S. Péché，“Hermitian随机矩阵小秩扰动的主特征值”，*Probability Theory and Related Fields*，第134卷，第127–173页，2006年。（第651页）[327] Y. Peres，“迭代冯·诺依曼的随机比特提取过程”，*Annals of Statistics*，第20卷，第1期，第590–597页，1992年。（第167页）[328] M. S. Pinsker，“高斯噪声中平方可积信号的最优滤波”，*Prob- lemy Peredachi Informatsii*，第16卷，第2期，第52–68页，1980年。（第xxii页）[329] G. Pisier，*The volume of convex bodies and Banach space geometry*。剑桥大学出版社，1999年。（第523和531页）

[330] J. Pitman, “仅有实零点的多项式系数的概率界”，*Journal of Combinatorial Theory, Series A*，第77卷，第2期，第279–303页，1997年。（第301页）[331] E. Plotnik、M. J. Weinberger和J. Ziv，“有限状态源发出序列概率的上界及Lempel-Ziv算法冗余度的上界”，*IEEE transactions on informa- tion theory*，第38卷，第1期，第66–72页，1992年。（第264页）[332] D. Pollard，“经验过程：理论与应用”，*NSF-CBMS Regional Conference Series in Probability and Statis- tics*，第2卷，第i–86页，1990年。（第603页）[333] Y. Polyanskiy，“信道编码：非渐近基本极限”，博士学位论文，普林斯顿大学，美国新泽西州普林斯顿，2010年。（第109、383、385、429、435和436页）[334] Y. Polyanskiy、H. V. Poor和S. Verdú，“有限块长度机制下的信道编码速率”，*IEEE Trans. Inf. Theory*，第56卷，第5期，第2307–2359页，2010年5月。（第346、353、434、435、436和584页）[335] ——，“Gilbert-Elliott信道的色散”，*IEEE Trans. Inf. Theory*，第57卷，第4期，第1829–1848页，2011年4月。（第437页）[336] ——，“非渐近机制中的反馈”，*IEEE Trans. Inf. Theory*，第57卷，第4期，第4903–4925页，2011年4月。（第446、454、455和456页）[337] ——，“在有和无反馈情况下发送k比特的最小能量”，*IEEE Trans. Inf. Theory*，第57卷，第8期，第4880–4902页，2011年8月。（第413和449页）[338] Y. Polyanskiy和S. Verdú，“Arimoto信道编码逆定理与Rényi散度”，载于*Proceedings of the Forty-eighth Annual Allerton Conference on Communication, Control, and Computing*，2010年9月，第1327–1333页。（第121、433和505页）[339] Y. Polyanskiy和S. Verdu，“带反馈的二元假设检验”，载于*Information Theory and Applications Workshop (ITA)*，2011年。（第320页）

[340] Y. Polyanskiy 和 S. Verdú，“具有非消失错误概率的良好信道码的经验分布”，*IEEE Trans. Inf. Theory*，第 60 卷，第 1 期，第 5–21 页，2014 年 1 月。（第 429 页）[341] Y. Polyanskiy，“信道编码的极小极大逆定理中的鞍点”，*IEEE Transactions on Information Theory*，第 59 卷，第 5 期，第 2576–2595 页，2012 年。（第 429 和 430 页）[342] ——，“关于复合 DMC 的色散”，载于*2013 51st Annual Allerton Conference on Communication, Control, and Computing (Allerton)*。IEEE，2013 年，第 26–32 页。（第 437 和 465 页）[343] Y. Polyanskiy 和 Y. Wu，“高斯信道下良好码的峰均功率比”，*IEEE Trans. Inf. Theory*，第 60 卷，第 12 期，第 7655–7660 页，2014 年 12 月。（第 408 页）[344] ——，“熵的 Wasserstein 连续性与干扰信道的外界”，*IEEE Transactions on Information Theory*，第 62 卷，第 7 期，第 3992–4002 页，2016 年。（第 60 和 64 页）[345] ——，“信道和贝叶斯网络的强数据处理不等式”，载于*Convexity and Concentration. The IMA Volumes in Mathematics and its Applications, vol 161*，E. Carlen、M. Madiman 和 E. M. Werner 编。纽约：Springer，2017 年，第 211–249 页。（第 325、626、631、632、635、636、638、646 和 647 页）[346] ——，“对偶化 Le Cam 方法用于泛函估计及其在估计未见项中的应用”，*arXiv preprint arXiv:1902.05616*，2019 年。（第 566 和 668 页）[347] ——，“信息渗透方法在图上的重构问题中的应用”，*Mathematical Statistics and Learning*，第 2 卷，第 1 期，第 1–24 页，2020 年。（第 650、651 和 653 页）[348] ——，“混合模型中非参数最大似然估计的自正则化性质”，*arXiv preprint arXiv:2008.08244*，2020 年。（第 408 页）[349] E. C. Posner 和 E. R. Rodemich，“Epsilon 熵与数据压缩”，*Annals of*

Mathematical Statistics, 第 42 卷, 第 6 期, 第 2079–2125 页, 1971 年 12 月. (第 543 页) [350] A. Prékopa, “对数凹测度及其在随机规划中的应用,” *Acta Scientiarum Mathemati- carum*, 第 32 卷, 第 301–316 页, 1971. (第 573 页) [351] J. Radhakrishnan, “Bregman 定理的熵证明,” *J. Combin. Theory Ser. A*, 第 77 卷, 第 1 期, 第 161–164 页, 1997. (第 161 页) [352] M. Raginsky, “离散信道的强数据处理不等式与 ϕ-Sobolev 不等式,” *IEEE Transactions on Information Theory*, 第 62 卷, 第 6 期, 第 3355–3389 页, 2016. (第 626 和 638 页) [353] M. Raginsky 和 I. Sason, “信息论、通信与编码中的测度集中不等式,” *Foundations and Trends® in Communications and Information Theory*, 第 10 卷, 第 1-2 期, 第 1–246 页, 2013. (第 xxi 页) [354] C. R. Rao, “信息与统计参数估计中可达到的精度,” *Bull. Calc. Math. Soc.*, 第 37 卷, 第 81–91 页, 1945. (第 576 页) [355] A. H. Reeves, “PCM 的过去、现在与未来,” *IEEE Spectrum*, 第 2 卷, 第 5 期, 第 58–62 页, 1965. (第 477 页) [356] A. Rényi, “论熵与信息的度量,” 载于 *Proc. 4th Berkeley Symp. Mathematics, Statistics, and Probability*, 第 1 卷, 美国加利福尼亚州伯克利, 1961, 第 547–561 页. (第 13 页) [357] ——, “论概率分布的维数与熵,” *Acta Mathemat- ica Hungarica*, 第 10 卷, 第 1 – 2 期, 1959 年 3 月. (第 29 页) [358] Z. Reznikova 和 B. Ryabko, “用信息论方法分析蚂蚁的语言,” *Prob- lemi Peredachi Informatsii*, 第 22 卷, 第 3 期, 第 103–108 页, 1986, 英文翻译: http://reznikova.net/R-R-entropy-09.pdf. (第 9 页) [359] T. J. Richardson, M. A. Shokrollahi 和 R. L. Urbanke, “逼近容量非规则低密度奇偶校验码,” *IEEE Transactions on Information Theory*, 第47卷, 第2期, 第619–637页, 2001年。(第516页) [360] T. Richardson和R. Urbanke, *Modern Coding Theory*。剑桥大学出版社, 2008年。(第xxi、63、341、346、383和632页) [361] Y. Rinott, “论测度的凸性,” *Annals of Probability*, 第4卷, 第6期, 第1020–1026页, 1976年。(第573页) [362] J. J. Rissanen, “Fisher信息与随机复杂性,” *IEEE transactions on information theory*, 第42卷, 第1期, 第40–47页, 1996年。(第261页) [363] H. Robbins, “统计学的经验贝叶斯方法,” 载于*Proceedings of the Third Berkeley Symposium on Mathematical Statistics and Probability, Volume 1: Contributions to the Theory of Statistics*。加利福尼亚大学董事会, 1956年。(第563页) [364] R. W. Robinson和N. C. Wormald, “几乎所有三次图都是哈密顿图,” *Random Structures & Algorithms*, 第3卷, 第2期, 第117–125页, 1992年。(第186页) [365] C. Rogers, *Packing and Covering*, 丛书: 剑桥数学与数学物理论丛。剑桥大学出版社, 1964年。(第527页) [366] H. Roozbehani和Y. Polyanskiy, “分类有向图模型的代数方法,” *arXiv preprint arXiv:1401.5551*, 2014年。(第180页) [367] ——, “低密度多数码与优雅降级问题,” *arXiv preprint arXiv:1911.12263*, 2019年。(第191和669页) [368] H. P. Rosenthal, “关于由独立随机变量序列张成的$L^p(p > 2)$的子空间,” *Israel Journal of Mathematics*, 第8卷, 第3期, 第273–303页, 1970年。(第497页) [369] D. Russo和J. Zou, “利用信息论控制自适应数据分析中的偏差,” 载于 *Artificial Intelligence and Statis- tics*。PMLR, 2016年, 第1232–1240页。(第90和188页)

[370] I. N. Sanov, “关于随机量的大偏差概率，” *Matem- aticheskii Sbornik*，第84卷，第1期，第11–44页，1957年。（第307页） [371] E. a o lu, “离散系统的极化编码定理，” EPFL，技术报告，2011年。（第669页） [372] ——, “极化和极化码，” *Foundations and Trends® in Communications and Information Theory*，第8卷，第4期，第259–381页，2012年。（第341页） [373] I. Sason 和 S. Verdú, “*f*-散度不等式，” *IEEE Transactions on Infor- mation Theory*，第62卷，第11期，第5973–6006页，2016年。（第132页） [374] G. Schechtman, “独立正随机变量和的矩的极值构型，” 载于 *Banach Spaces and their Applications in Analysis*。De Gruyter，2011年，第183–192页。（第505页） [375] M. J. Schervish, *Theory of statistics*。Springer-Verlag New York，1995年。（第582和583页） [376] A. Schrijver, *Theory of linear and integer programming*。John Wiley & Sons，1998年。（第567页） [377] C. E. Shannon, “继电器和开关电路的符号分析，” *Electrical Engineering*，第57卷，第12期，第713–723页，1938年12月。（第626页） [378] C. E. Shannon, “通信的数学理论，” *Bell Syst. Tech. J.*，第27卷，第379–423页和第623–656页，1948年7月/10月。（第xvii, 41, 195, 215, 234, 341, 346, 377和411页） [379] ——, “噪声信道的零错误容量，” *IRE Transactions on Informa- tion Theory*，第2卷，第3期，第8–19页，1956年。（第374, 450和452页） [380] ——, “具有保真度准则的离散信源的编码定理，” *IRE Nat. Conv. Rec*，第4卷，第142-163期，第1页，1959年。（第475和490页） [381] C. E. Shannon, R. G. Gallager, 和 E. R. Berlekamp, “离散无记忆信道上编码的错误概率下界信道 i，” *Inf. Contr.*，第 10 卷，第 65–103 页，1967 年。（第 432 和 433 页）[382] J. Shawe-Taylor 和 R. C. Williamson, “贝叶斯估计器的 PAC 分析”，载于 *Proceedings of the tenth annual conference on Computational learning theory*，1997 年，第 2–9 页。（第 83 页）[383] O. Shayevitz, “论 Rényi 测度与假设检验”，载于 *2011 IEEE International Symposium on Information Theory Proceedings*。IEEE，2011 年，第 894–898 页。（第 182 页）[384] O. Shayevitz 和 M. Feder, “通过后验匹配的最优反馈通信”，*IEEE Trans. Inf. Theory*，第 57 卷，第 3 期，第 1186–1222 页，2011 年。（第 445 页）[385] A. N. Shiryaev, *Probability-1*。Springer，2016 年，第 95 卷。（第 126 页）[386] G. Simons 和 M. Woodroofe, “Cramér-Rao 不等式几乎处处成立”，载于 *Recent Advances in Statistics: Papers in Honor of Herman Chernoff on his Sixtieth Birthday*。Academic，New York，1983 年，第 69–93 页。（第 661 页）[387] Y. G. Sinai, “论动力系统的熵概念”，载于 *Doklady of Russian Academy of Sciences*，第 124 卷，第 3 期，1959 年，第 768–771 页。（第 xix 和 230 页）[388] R. Sinkhorn, “任意正矩阵与双随机矩阵之间的关系”，*Ann. Math. Stat.*，第 35 卷，第 2 期，第 876–879 页，1964 年。（第 105 页）[389] M. Sion, “论一般极小极大定理”，*Pacific J. Math*，第 8 卷，第 1 期，第 171–176 页，1958 年。（第 93 页）[390] M.-K. Siu, “哪些拉丁方是凯莱表？” *Amer. Math. Monthly*，第 98 卷，第 7 期，第 625–627 页，1991 年 8 月。（第 384 页）[391] D. Slepian 和 H. O. Pollak, “长椭球波函数、傅里叶分析与不确定性–I”，*Bell System Technical Journal*，第 40 卷，第 1 期，第 43–63 页，1961 年。（第 419 页）[392] D. Slepian 和 J. Wolf, “相关信源的无噪声编码”，*IEEE Transactions on information Theory*，第 19 卷，第 4 期，第 471–480 页，1973 年。（第 223 页）

[393] A. Sly, “随机着色的重构，” *Communications in Mathematical Physics*，第 288 卷，第 3 期，第 943–961 页，2009 年 6 月。（第 644 页） [394] A. Sly 和 N. Sun, “在 *d* -正则图上的双自旋模型中的计数，” *The Annals of Probability*，第 42 卷，第 6 期，第 2383–2416 页，2014 年。（第 75 页） [395] B. Smith, “量化信号的瞬时压扩，” *Bell System Technical Journal*，第 36 卷，第 3 期，第 653–709 页，1957 年。（第 483 页） [396] J. G. Smith, “幅度和方差受限的标量高斯信道的信息容量，” *Information and Control*，第 18 卷，第 203 – 219 页，1971 年。（第 408 页） [397] Spectre, “SPECTRE：短包通信工具箱，” https://github.com/yp-mit/spectre，2015 年，GitHub 仓库。（第 418 和 441 页） [398] R. Speer, J. Chin, A. Lin, S. Jewett, 和 L. Nathan, “Luminosoinsight/wordfreq: v2.2，” 2018 年 10 月。[在线]。可用：https://doi.org/10.5281/zenodo.1443582（第 204 页） [399] A. J. Stam, “Fisher 和 Shannon 信息量满足的一些不等式，” *Information and Control*，第 2 卷，第 2 期，第 101–112 页，1959 年。（第 64、185 和 191 页） [400] ——, “有放回与无放回抽样之间的距离，” *Statistica Neer- landica*，第 32 卷，第 2 期，第 81–91 页，1978 年。（第 186 和 187 页） [401] M. Steiner, “强单纯形猜想是错误的，” *IEEE Transactions on Information Theory*，第 40 卷，第 3 期，第 721–731 页，1994 年。（第 413 页） [402] V. Strassen, “Shannon 信息论中的渐近估计，” 载于 *Trans. 3d Prague Conf. Inf. Theory*，布拉格，1962 年，第 689–723 页。（第 435 页） [403] ——, “具有给定边缘的概率测度的存在性，” *Annals of Mathematical Statistics*，第 36 卷，第 2 期，第 423–439 页，1965 年。（第 122 页） [404] H. Strasser, *Mathematical theory of statistics: Statistical experiments and asymptotic decision theory*. Berlin, Germany: Walter de Gruyter, 1985. (第558页和第566页) [405] J. Suzuki, “关于通用无噪声编码的一些注记，” *IEICE transactions on fundamentals of electronics, communications and computer sciences*, 第78卷, 第12期, 第1840–1847页, 1995. (第252页) [406] S. Szarek, “Grassmann流形和正交群的网，” 见 *Proceedings of Banach Space Workshop*. University of Iowa Press, 1982, 第169–185页. (第527页和第544页) [407] ——, “齐性空间的度量熵，” *Banach Center Publications*, 第43卷, 第1期, 第395–410页, 1998. (第527页) [408] W. Szpankowski 和 S. Verdú, “无前缀约束的定长到变长无损压缩的最小期望长度，” *IEEE Trans. Inf. Theory*, 第57卷, 第7期, 第4017–4025页, 2011. (第200页) [409] I. Tal 和 A. Vardy, “极化码的列表译码，” *IEEE Transactions on Information Theory*, 第61卷, 第5期, 第2213–2226页, 2015. (第346页) [410] M. Talagrand, “Parisi公式，” *Annals of mathematics*, 第221–263页, 2006. (第63页) [411] ——, *Upper and lower bounds for stochastic processes*. Springer, 2014. (第531页) [412] T. Tanaka, P. M. Esfahani, 和 S. K. Mitter, “具有最小有向信息的LQG控制：半定规划方法，” *IEEE Transactions on Automatic Control*, 第63卷, 第1期, 第37–52页, 2017. (第449页) [413] W. Tang 和 F. Tang, “泊松二项分布——老与新，” *Statistical Science*, 第38卷, 第1期, 第108–119页, 2023. (第301页) [414] T. Tao, “Szemerédi正则引理再探，” *Contributions to Discrete Mathematics*, 第1卷, 第1期, 第8–28页, 2006. (第127页和第190页) [415] G. Taricco 和 M. Elia, “无边信息的衰落信道容量，” *Electronics Letters*, 第33卷, 第16期, 第1368–1370页, 1997. (第409页)

[416] V. Tarokh、H. Jafarkhani 和 A. R. Calderbank，“来自正交设计的空时分组码”，*IEEE Transactions on Infor- mation theory*，第45卷，第5期，第1456–1467页，1999年。（第409页） [417] V. Tarokh、N. Seshadri 和 A. R. Calderbank，“高速数据率无线通信的空时码：性能准则与码构造”，*IEEE transactions on information theory*，第44卷，第2期，第744–765页，1998年。（第409页） [418] E. Telatar，“多天线高斯信道的容量”，*European trans. tele- com.*，第10卷，第6期，第585–595页，1999年。（第176和409页） [419] ——，“绞合引理与多描述”，2016年，未发表手稿。（第187页） [420] V. N. Temlyakov，“关于ϵ-熵的估计以及具有有界混合导数或差分的函数类的宽度”，*Doklady Akademii Nauk*，第301卷，第2期，第288–291页，1988年。（第541页） [421] N. Tishby、F. C. Pereira 和 W. Bialek，“信息瓶颈方法”，*arXiv preprint physics/0004057*，2000年。（第549页） [422] F. Topsøe，“关于信息散度及相关判别度量的一些不等式”，*IEEE Transactions on Infor- mation Theory*，第46卷，第4期，第1602–1609页，2000年。（第133页） [423] D. Tse 和 P. Viswanath，*Fundamentals of wireless communication*。剑桥大学出版社，2005年。（第xxi、403和409页） [424] A. B. Tsybakov，*Introduction to Nonparametric Estimation*。纽约：Springer Verlag，2009年。（第xxi、xxii、132和624页） [425] B. P. Tunstall，“无噪声压缩码的合成”，博士学位论文，佐治亚理工学院，1967年。（第196页） [426] E. Uhrmann-Klingen，“具有紧支撑的最小Fisher信息分布”，*Sankhȳ: The Indian Journal of Statistics, Series A*，第360–374页，1995年。（第580页）

[427] I. Vajda，“关于判别信息与变异的注记（通信）”，*IEEE Transactions on Information Theory*，第16卷，第6期，第771–773页，1970年。（第131页） [428] G. Valiant 和 P. Valiant，“估计未见之物：一种用于熵与支撑大小的 $n/\log(n)$ 样本估计量，并通过新的 CLTs 证明其最优性”，载于*Proceedings of the 43rd annual ACM symposium on Theory of com- puting*，2011年，第685–694页。（第584页） [429] S. van de Geer，*Empirical Processes in M-Estimation*。剑桥大学出版社，2000年。（第86和603页） [430] A. van der Vaart，“Lucien Le Cam 的统计工作”，*Annals of Statistics*，第631–682页，2002年。（第614和616页） [431] A. W. van der Vaart 和 J. A. Well-ner，*Weak Convergence and Empirical Pro- cesses*。Springer Verlag New York, Inc.，1996年。（第86和603页） [432] T. Van Erven 和 P. Harremoës，“Rényi 散度与 Kullback-Leibler 散度”，*IEEE Trans. Inf. Theory*，第60卷，第7期，第3797–3820页，2014年。（第145页） [433] H. L. Van Trees，*Detection, Estimation, and Modulation Theory*。Wiley，New York，1968年。（第577页） [434] S. Verdú，“关于单位成本的信道容量”，*IEEE Trans. Inf. Theory*，第36卷，第5期，第1019–1030页，1990年9月。（第414页） [435] ——，*Multiuser Detection*。Cambridge, UK: Cambridge Univ. Press，1998年。（第413页） [436] ——，“信息论，第一部分”，草稿（个人通信），2017年。（第xv页） [437] S. Verdú 和 D. Guo，“熵功率不等式的一个简单证明”，*IEEE Transac- tions on Information Theory*，第52卷，第5期，第2165–2166页，2006年。（第64页） [438] R. Vershynin，*High-dimensional probability: An introduction with applications in data science*。剑桥大学出版社，2018年，第47卷。（第86和531页） [439] A. G. Vitushkin，“论希尔伯特第13问题”，*Dokl. Akad. Nauk SSSR*，第95卷，第4期，第701–704页，1954年。（第538页）

[440] ——, “关于希尔伯特第十三问题及相关问题”, *Russian Mathematical Surveys*, 第59卷, 第1期, 第11页, 2004年。(第xviii页)[441] ——, *Theory of the Transmission and Processing of Information*。Pergamon出版社, 1961年。(第535页)[442] J. von Neumann, “与随机数字相关的各种技术”, *Monte Carlo Method, National Bureau of Standards, Applied Math Series*, 第12期, 第36–38页, 1951年。(第166页)[443] ——, “概率逻辑及由不可靠组件合成可靠生物体”, 载于 *Automata Studies.(AM- 34), Volume 34*, C. E. Shannon与J. McCarthy编。Princeton University Press, 1956年, 第43–98页。(第627页)[444] D. Von Rosen, “逆Wishart分布的矩”, *Scandinavian Jour- nal of Statistics*, 第97–109页, 1988年。(第272页)[445] V. G. Vovk, “聚合策略”, *Proc. of Computational Learning Theory, 1990*, 1990年。(第xx页和第271页)[446] M. J. Wainwright, *High-dimensional statistics: A non-asymptotic viewpoint*。Cambridge University Press, 2019年, 第48卷。(第xxii页)[447] M. J. Wainwright与M. I. Jordan, “图模型、指数族与变分推断”, *Foundations and Trends® in Machine Learning*, 第1卷, 第1–2期, 第1–305页, 2008年。(第74页和第75页)[448] A. Wald, “统计假设的序贯检验”, *The Annals of Mathematical Statistics*, 第16卷, 第2期, 第117–186页, 1945年。(第320页)[449] ——, “关于最大似然估计相合性的注记”, *The Annals of Mathematical Statistics*, 第20卷, 第4期, 第595–601页, 1949年。(第582页)[450] A. Wald与J. Wolfowitz, “序贯概率比检验的最优特性”, *The Annals of Mathematical Statistics*, 第326–339页, 1948年。(第320页)[451] M. M. Wilde, *Quantum information theory*。Cambridge University Press, 2013年。(第xxi页)

[452] R. J. Williams, “用于连接主义强化学习的简单统计梯度跟随算法, ” *Machine learning*, 第 8 卷, 第 229–256 页, 1992 年。(第 77 页)[453] H. Witsenhausen 和 A. Wyner, “一对离散随机变量的条件熵界, ” *IEEE Transactions on Information Theory*, 第 21 卷, 第 5 期, 第 493–501 页, 1975 年。(第 325 页)[454] J. Wolfowitz, “关于 Wald 对最大似然估计一致性证明的探讨, ” *The Annals of Mathematical Statis- tics*, 第 20 卷, 第 4 期, 第 601–602 页, 1949 年。(第 582 页)[455] Y. Wu 和 J. Xu, “具有植入结构的统计问题: 信息论与计算极限, ” 载于 *Information-Theoretic Methods in Data Science*, Y. Eldar 和 M. Rodrigues 编。剑桥大学出版社, 2020 年, arXiv:1806.00118。(第 338 页)[456] Y. Wu 和 P. Yang, “通过最佳多项式逼近实现大字母表上熵估计的极小极大率, ” *IEEE Transactions on Information Theory*, 第 62 卷, 第 6 期, 第 3702–3720 页, 2016 年。(第 584 页)[457] A. Wyner 和 J. Ziv, “关于某些二进制序列熵的定理及其应用–I, ” *IEEE Transactions on Information Theory*, 第 19 卷, 第 6 期, 第 769–772 页, 1973 年。(第 191 页)[458] A. Wyner, “两个相依随机变量的共同信息, ” *IEEE Transactions on Information Theory*, 第 21 卷, 第 2 期, 第 163–179 页, 1975 年。(第 503 页和第 504 页)[459] ——, “关于解码器处具有边信息的信源编码, ” *IEEE Transactions on Information Theory*, 第 21 卷, 第 3 期, 第 294–300 页, 1975 年。(第 227 页)[460] Q. Xie 和 A. R. Barron, “无记忆信源类的极小极大冗余度, ” *IEEE Transactions on Information Theory*, 第 43 卷, 第 2 期, 第 646–657 页, 1997 年。(第 252 页)

[461] A. Xu 和 M. Raginsky，“学习算法泛化能力的信息论分析”，*Advances in Neural Information Processing Systems*，第30卷，2017年。（第90页）[462] W. Yang、G. Durisi、T. Koch 和 Y. Polyanskiy，“有限块长度下的准静态多天线衰落信道”，*IEEE Transactions on Information Theory*，第60卷，第7期，第4232–4265页，2014年。（第437页）[463] W. Yang、G. Durisi 和 Y. Polyanskiy，“通过多天线衰落信道发送 k 比特的最小能量”，*IEEE Transactions on Information The- ory*，第62卷，第12期，第6831–6853页，2016年。（第417页）[464] Y. Yang 和 A. R. Barron，“最小最大收敛速率的信息论确定”，*Annals of Statistics*，第27卷，第5期，第1564–1599页，1999年。（第xxii、602、606和607页）[465] Y. G. Yatracos，“最小距离估计量的收敛速率与Kolmogorov熵”，*The Annals of Statis- tics*，第768–774页，1985年。（第602、620和621页）[466] S. Yekhanin，“无固定前缀码冗余度的改进上界”，*IEEE Trans. Inf. Theory*，第50卷，第11期，第2815–2818页，2004年。（第208页）[467] P. L. Zador，“多变量分布量化程序的开发与评估”，博士学位论文，斯坦福大学统计系，1963年。（第482页）[468] ——，“连续信号的渐近量化误差与量化维数”，*IEEE Transactions on Informa- tion Theory*，第28卷，第2期，第139–149页，1982年。（第482页）[469] O. Zeitouni、J. Ziv 和 N. Merhav，“广义似然比检验何时最优？”*IEEE Transactions on Information Theory*，第 38 卷，第 5 期，第 1597–1602 页，1992 年。（第 324 页）[470] C.-H. Zhang，“复合决策理论与经验贝叶斯方法，”*The Annals of Statistics*，第 31 卷，第 2 期，第 379–390 页，2003 年。（第 563 页）[471] T. Zhang，“某些正则化线性函数类的覆盖数界，”*Journal of Machine Learning Research*，第 2 卷，第 Mar 期，第 527–550 页，2002 年。（第 533 页）[472] Z. Zhang 和 R. W. Yeung，“信息量的非香农型条件不等式，”*IEEE Trans. Inf. Theory*，第 43 卷，第 6 期，第 1982–1986 页，1997 年。（第 17 页）[473] ——，“通过信息不等式刻画熵函数，”*IEEE Trans. Inf. Theory*，第 44 卷，第 4 期，第 1440–1452 页，1998 年。（第 17 页）[474] L. Zheng 和 D. N. C. Tse，“Grassmann 流形上的通信：非相干多天线信道的几何方法，”*IEEE transactions on Information Theory*，第 48 卷，第 2 期，第 359–383 页，2002 年。（第 409 页）[475] N. Zhivotovskiy，“通过变分原理得到的独立矩阵和简单张量和的无维数界，”*arXiv preprint arXiv:2108.08198*，2021 年。（第 85 页）[476] W. Zhou, V. Veitch, M. Austern, R. P. Adams, 和 P. Orbanz，“ImageNet 规模下的非空泛化界：一种 PAC-贝叶斯压缩方法，”载于 *International Conference on Learning Representations (ICLR)*，2018 年。（第 89 和 90 页）[477] G. Zipf，*Selective Studies and the Principle of Relative Frequency in Language*。剑桥 MA：哈佛大学出版社，1932 年。（第 203 和 204 页）

索引

F_1-curve, 325, 338, 549, 638 I-投影, *see* 信息投影 Log 函数, 25 ϵ-覆盖, 523 ϵ-网, *see* ϵ-覆盖 ϵ-填充, 523 $\mathbb{Z}_2$ 同步, 649 σ-代数, 79 稠密性, 240 单调极限, 79 f-散度, 115, 631 下确界刻画, 151 上确界刻画, 121, 147 比较, 127, 132 条件, 117 凸性, 120 数据处理, 119 有限划分, 121 局部行为, 138 下半连续性, 148 单调性, 118 操作意义, 122 SDPI, 629 f-信息, 134, 182, 630, 631 χ^2, 136 可加性, 135 定义, 134 次可加性, 135, 644 对称 KL, 135, 187 g-散度, 121 k-均值, 481 3GPP, 403

Alon, N., 160 交替最小化算法, 102 Amari, S.-I., 307 安德森引理, 541, 572 Anderson, T. W., 572 近似消息传递(AMP), 653 面积定理, 63 曲线下面积(AUC), 278 Arimoto, S., 102, 433 算术编码, 245, 268 Artstein, S., 535 阿苏阿德引理, 389, 597, 664 通过互信息方法, 598 非对称数字系统(ANS), 246 渐近效率, 581 渐近均分性质(AEP), 217, 234 渐近分离性, 125 自协方差函数, 114 自动重传请求(ARQ), 468 辅助信道, 423, 428 辅助随机变量, 227

BEC, 181, 372, 380, 439, 455, 460, 471, 639, 654, 669 置信传播, 653 贝尔实验室, 480 Berlekamp, E., 432 伯努利工厂, 172 伯努利移位, 230 Bernoulli, D., 143 Berry-Esseen 不等式, 435 Bhattacharyya 距离, 315 二元散度, 1, 22, 56 二元熵函数, 1, 9 二进制对称信道, *see* BSC 二项尾部, 159 二分图, 161 Birgé, L., 613, 614, 625 Birkhoff-Khintchine 定理, 234 Birman, M. , 538 生日悖论, 186 误码率 (BER), 389 Blackwell 测度, 111 Blackwell 序, 182, 329 Blackwell, D., 111, 182 Blahut, R., 102 Blahut-Arimoto 算法, 102 块长度, 370 BMS, 383, 631, 669 混合表示, 632 Bollobás, B., 164 玻尔兹曼, 15 玻尔兹曼常数, 410 Bonami-Beckner 半群, 132 布尔函数, 626 碗形, 571 盒计数维数, *see* Minkowski 维数 Brégman 定理, 162 Breiman, L., 234 网格上的广播, 670 树上的广播, 642 布朗运动, 417

B-过程，232 球与瓮模型，186 Barg, A.，433 Barron, A. R.，64, 606 批量损失，270, 611 贝叶斯风险，662 GLM，563 贝叶斯克拉美-罗，661 贝叶斯克拉美-罗（BCR）下界，577 贝叶斯克拉美-罗下界，663 贝叶斯网络，633 BCR 下界，578 函数估计，580 多变量，579

绝对连续性，21，42，43 绝对范数，526 可达性，201 可加集函数，79 ADSL，403 Ahlswede，R.，208，227，326 Ahlswede-Csisár，326 Alamouti码，409

BSC, 49, 53, 111, 344, 347, 363, 372, 379, 436, 439, 455, 469, 471, 630, 643, 655, 669, 670 信道编码, 344 收缩系数, 633 SDPI, 633 强逆, 424 Burnashev误差指数, 456 {v*}

容量, 49, 91, 94, 96, 102, 178, 179, 256, 345, 348 ϵ-容量, 373, 395 Z-信道, 380 ACGN, 405 加性非高斯噪声, 401 幅度受限AWGN, 407 AWGN, 399 BEC, 380 误码率, 390 BSC, 379 复合DMC, 465 连续时间AWGN, 418 擦除错误信道, 464 高斯信道, 100, 107 群信道, 379 信息容量, 375, 395 信息稳定信道, 386, 399 最大错误概率, 375 无记忆信道, 377 MIMO信道, 176 混合DMC, 465 非平稳AWGN, 403 并行AWGN, 402 每单位成本, 414, 470 乘积信道, 465 香农容量, 373, 395 DMC之和, 465 带反馈, 443, 471 零错误, 374, 464, 471 带反馈零错误, 450 容量可达输出分布, 425 容量与Hellinger熵 下界, 609 上界, 610 容量与KL覆盖数, 603, 608 容量可达输入分布, 94, 444 离散, 407

不存在, 98 达到容量的输出分布, 94, 96, 253 唯一性, 94, 97 容量-代价函数, 396, 466, 467 容量-冗余定理, 248, 269, 270, 604 卡诺循环, 14 载波频率, 419 Catoni, O., 83 因果条件, 448 因果推断, 446 Cencov, N. N., 307 重心, 67, 184 中心极限定理, 78, 148, 181, 202 质心Voronoi剖分 (CVT), 481 链式法则 χ^2, 183 微分熵, 27 散度, 32, 33, 183 熵, 12, 158 Hellinger, 183 互信息, 52, 63, 187 Rényi散度, 183 全变差, 183 链式方法, 86 信道, 29 信道自同构, 381 信道容量, *see* 容量 信道编码 (M, ϵ)-码, 343 κ-β 界, 435 容许约束, 396 BSC, 344 容量, 345 单位代价容量, 414 容量-代价, 396, 466 代价函数, 395 代价约束码, 395, 467 自由度, 409 色散, *see* 色散 DT界, 356, 460, 461 DT界, 线性码, 364 Elias方案, 457 每比特能量, *see* 每比特能量误差指数, 430, 460, 469, 471 带反馈误差指数, 454 删除随机编码, 469 反馈码, 442, 471

有限块长度, 346 基本极限, 373, 395 Gallager界, 360, 431 信息密度, 351 线性码, 362, 461 正态近似, 439 归一化速率, 439 最优解码器, 347 后验匹配, 444 功率约束, 394 错误概率, 343 随机编码器, 460 RCU界, 359, 439 实际编码, 440 可靠性函数, 431 Schalkwijk-Kailath方案, 459 已发送码字, 350 香农随机编码, 354 球填充界, 427, 432, 454, 471 直线界, 432 强逆定理, 422, 465, 469, 470 子模性, 367 阈值解码器, 353 传输速率, 373 通用, 463 未发送码字, 350 可变长度, 455, 471 弱逆定理, 348, 397 零速率, 432 信道比较, 646, 669, 670 信道色散, 434 信道滤波器, 406 信道状态信息, 408 信道对称群, 381 信道对称关系, 385 信道, OR信道, 189 信道, Z信道, 372 信道, q元删除, 639 信道, q元对称, 670, 671 信道, Z信道, 380 信道, ACGN, 405 信道, 加性噪声, 50, 363, 464 信道, 加性非高斯噪声, 466 信道, 加性噪声, 371, 467 信道, AWGN, 48, 98, 100, 372, 399, 436, 457, 460, 470 信道, 带ISI的AWGN, 406 信道, 带限AWGN, 419 信道, BI-AWGN, 48, 436, 655

信道，二进制擦除，*see* BEC 信道，二进制输入，631 信道，二进制无记忆，*see* BMS 信道，二进制对称，*see* BSC 信道，二进制输入 AWGN（BI-AWGN），649 信道，块衰落，409 信道，着色，643，670 信道，复合，465 信道，连续时间，417 信道，成本受限，395 信道，定义，370 信道，离散无记忆，*see*

DMC信道，Dobrushin对称，383信道，擦除，177，647，671信道，擦除错误，464信道，奇异，436信道，衰落，408信道，衰落（非相干），416信道，Gallager对称，383信道，高斯，388信道，高斯广播，65信道，高斯擦除，437信道，信息稳定，386，393信道，输入对称，369，383，631信道，MIMO，176，403，409，437信道，混合DMC，465信道，非预测性，371，449信道，非平稳AWGN，403，466信道，并行AWGN，176，402，436信道，泊松，177信道，多边形，451，471信道，Potts，671信道，乘积信道，465信道，准静态衰落，437信道，平稳无记忆，371信道，信道之和，465信道，弱输入对称，383，446信道，带反馈，455，457信道，带记忆，464Chapman，D. G.，575Chebyshev半径，96Chernoff界，159，292Chernoff信息，123，315，337Chernoff-Rubin-Stein下界，661

克劳修斯，14 码本，342 码字，342 编码定理 AWGN，399 单位成本容量，414 容量-成本，399 信道编码，345，377 压缩，199 信息稳定信道，386 非平稳 AWGN，403 并行 AWGN，402 编码理论，341 组合学，15，174，432，452，471 公共信息，338 社区检测，126，185，337，642，648 单社区，591 压扩器，479 信息度量比较，57 复合假设检验 Hellinger 上界，613 元逆，429 极小极大风险，612 电视球，338，613 压缩 几乎无损，213 算术编码，245，268 块长度，201 Elias 码，270 枚举码，268 遍历过程，233，393 误差指数，335 有限块长度，214 Fitingof，246 固定长度，213 霍夫曼码，209 iid 源，214 Lempel-Ziv，263 线性码，218 极大极小与极小极大解，252 失配，267 多终端，225，266 正态近似，214 归一化最大似然，248 最优，198，265 冗余，*see* 冗余 游程长度，266 边信息，221 单次，198

Slepian-Wolf, 222, 267 时间共享，226 通用, 245 可变长度, 168, 233, 265 可变长度无损, 197 通过公式计算, 628 使用噪声门计算, 627 测度集中, 151 高斯信道中的条件期望, 60 条件独立, 50, 180, 182 条件作用增加散度, 33, 121 置信区间, 559 混淆图, 451, 471 恒定组成码, 426 邻近性, 125, 186 信息度量的连续性, 66 收缩系数, 629 收缩系数, 669 χ^2, 669 χ^2, 631, 638, 640, 644 f-散度, 629, 637 f-信息, 630 KL, 53, 326, 636, 638, 654, 655, 669, 671 张量化, 638 总变差, 629 依分布收敛, 78, 82 逆定理, 201, 348 误码率, 390 凸体, 535 极体, 535 对称, 535 凸共轭, 147, 296 凸对偶, 73, 147, 157 凸包, 279, 309 凸优化, 209 测度的凸支撑, 309 凸性, 双共轭, 147 凸性, 严格, 92, 121, 295, 510 凸性, 强, 92 卷积, 2, 59 二进制, 191 函数, 2 高斯, 59 概率测度, 2 相关恢复, 593 相关系数, 180, 388, 631, 644

相关系数, 最大值, 640 代价函数, 395 Costa, M., 64 耦合, 122, 151, 178, 183 协方差矩阵, 49, 59, 114, 510 协方差矩阵估计, 85, 667 覆盖引理, 228, 327, 499 CR下界, 576, 661 多元, 576 Cramér条件, 293 Cramér, H., 576 Cramér-Rao下界, *see* CR下界 密码学, 14 Csisár, I., 326 Cuff, P., 503 累积量生成函数, *see* 对数矩生成函数 累积风险, 611 数据处理不等式, *see* DPI de Bruijn恒等式, 60, 191 de Finetti定理, 186 分贝 (dB), 48 解码器 最大互信息 (MMI), 463 最大后验 (MAP), 347 最大似然 (ML), 347, 353 解码区域, 342, 400 去卷积滤波器, 407 信道退化, 182, 329, 646 密度估计, 244, 602, 661, 664 贝叶斯 χ^2 风险, 662 贝叶斯KL风险, 605, 662 离散情形, 137 散度的导数, 36 互信息的导数, 59 集合的直径, 96 微分熵, 26, 47, 61, 158, 164, 175, 191 有向无环图 (DAG), 50, 633 有向无环图 (DAGs), 179, 180 有向图, 189 有向信息, 446 Dirichlet先验, 662, 665 概率测度的分解, 29 离散度, 379

在反馈条件下，446 零色散信道，436、437、455 失真度量，484 可分离，485 分布式估计，325、644、657 分布估计 χ^2 风险，664 二进制字母表，662 KL 风险，664 二次风险，583、664 全变差风险，664 分布，伯努利，9、48、269、333 分布，二项，174 分布，狄利克雷，250、252 分布，离散，40 分布，指数，177、330 分布，伽马，333 分布，高斯，47、49、59、64、98、133、330、333、336 分布，几何，9、175 分布，Marchenko-Pastur，176 分布，乘积混合，146 分布，混合，36 分布，泊松，178 分布，泊松-二项，301 分布，乘积，55 分布，混合的乘积，146 分布，次高斯，*see* 次高斯分布，均匀，11、27、175、178 分布，Zipf，203 Dite, W.，481 散度，20 χ^2，184、185、668、669 χ^2，36、116、122、126、132、133、136、145、148、149、631、638、640、641、644 下确界表示，123 上确界刻画，70、71 条件，42 连续性，78 σ-代数中的连续性，80 凸对偶，73 凸性，91 有限划分，70 测地线，306、333、335 Hellinger，见 Hellinger 距离117 Jeffreys，135 Jensen-Shannon，117、133、149

KL，36，37，116，131，133，150，633 Le Cam，117，133，631 局部行为，36，39，137，335 下半连续性，78，99 Marton，123，151，183 测度论性质，80 在集合代数上，79 参数族，38，140 Rényi，*see* Rényi 散度，314 实高斯，23 强凸性，92，182 对称 KL，135 全变差，*see* 混合分布的全变差散度，36 DMC，372，456 Dobrushin 压缩，629 控制收敛定理，138

，

141 Donsker, M. D., 71 Donsker-Varadhan, 71, 83, 147, 150, 297 Doob, 31 倍增维度, 616 DPI, 42, 154, 426 χ^2, 148 f-散度, 119 f-信息, 134 散度, 34, 36, 53, 56, 57, 73, 348 Fisher信息, 184 互信息, 51, 53 Neyman-Pearson区域, 329 Rényi散度, 433 Duda, J., 246 Dudley熵积分, 531, 552 Dudley, R., 531 Dueck, G., 187, 433 动力系统, 230 ebno, *see* 每比特能量 ECC, 342 特征值, 114 Elias系综, 365 Elias提取器, 168 Elias, P., 167, 270 Elliott, E. O., 111 EM算法, 77, 104 凸, 103 经验贝叶斯, 563 经验分布, 137 经验互信息, 462

经验过程，86 经验风险，87 经验风险最小化（ERM），87 每比特能量，400，410 衰落信道，416 有限块长度，417 熵中心极限定理，64 熵风险界，602 Hellinger损失，602，614 Hellinger损失，参数速率，617 Hellinger下界，618 KL损失，602，603 局部Hellinger熵，616 精确速率，619 TV损失，602，620 TV损失，误指定，621 熵，8 蚂蚁侦察，9 作为符号测度，46 公理，13 凹性，92 条件，10，46，57 连续性，78，178 微分，*see* 微分熵，48 经验，138 隐马尔可夫模型，111 信息表示，24 无限，10 Kolmogorov-Sinai，16 马尔可夫链，110 最大熵，99，175 Rényi，13，57 热力学，14 维恩图，46 熵特征，502 熵估计，584 大字母表，584 小字母表，584 熵方法，158 熵功率，64 熵功率不等式，41，64 Costa的，64 Lieb的，64 熵率，109，181，265 相对，288 熵与条件熵，46 熵功率不等式，191 Erdös，P.，215 Erdös-Rényi图，185

遍历定理，268 伯克霍夫-辛钦，234 极大，238 遍历性，232, 393, 467 纠错码 见 ECC，342 错误本底，423 误差指数，123, 144, 286, 335, 430, 454, 456, 460, 469 估计量，558 泛函，580 估计 熵，138 估计 优于随机 有界 GLM，592 分布估计，593 高斯噪声中的估计，58 离散参数估计，55 信息度量估计，66 估计-压缩不等式，*see* 在线到批处理转换 估计量，559 贝叶斯，562 确定性，558 非正常，603 正常，603 随机化，558 埃文斯与舒尔曼定理，627 证据下界 (ELBO)，76 可交换分布，170, 186 可交换事件，177 期望最大化，*see* EM 算法 指数族，310 自然参数，310 标准（单参数），298, 306 指数权重更新算法，271

有限块长度，214，341，346，417，460 有限群，50 有限状态机（FSM），172，264 Fisher缺陷，143 Fisher信息，38，140，252，576，645，660，661 连续性，141 数据处理不等式，184 矩阵，38，142，184 最小值，紧支撑，580 单调性，184 密度的，40，151，191，578 变分表示，151 Fisher信息不等式，185 Fisher因子分解定理，54 Fisher, R.，54，275 Fisher-Rao度量，40，307 Fitingof，B. M.，246 Fitingof, B. M.，463 Fitingof-Goppa码，463 闪通信令，417 傅里叶谱，419 傅里叶变换，114，406 分数覆盖数，160 分数填充数，161 频率派统计，54 Friedgut，E.，160 Friis传输方程，468 Fubini定理，45 泛函估计，580，666，668

Fano不等式，41, 57, 179, 664 张量积，112 Fano, R., 41 Fatou引理，38, 99, 142 Feder, M., 260 Feinstein 引理，357, 397 Feinstein, A., 357 Fekete引理，299 Fenchel-Eggleston-Carathéodory定理，129 Fenchel-Legendre共轭，73, 296 过滤，319

Gács-Körner信息，338 Gallager系综，365 Gallager界，360 Gallager, R.，360，431 伽罗瓦域，219 二十问游戏，13 猜测游戏，55 Gastpar条件，521 Gastpar, M.，521 高斯CEO问题，657 高斯比较，531 高斯分布，23 复数，23 高斯等周不等式，541 高斯位置模型，*see* GLM高斯混合，59，76，104，134，185，619

高斯正交系综（GOE），668 高斯宽度，530 盖尔范德，I.M.，70 盖尔范德-平斯克问题，468 盖尔范德-雅格洛姆-佩雷斯特征，70，121 泛化界，87 泛化误差，88，187 泛化风险，87 生成对抗网络（GANs），149，602 吉布斯，15 吉布斯分布，100，242，336 吉布斯采样器，87，187 吉布斯变分原理，74，83，178 吉尔伯特，E. N.，111，527 吉尔伯特-埃利奥特HMM，111，181 吉尔伯特-瓦尔沙莫夫界，433，527，666 吉尔默方法，189 吉尼布雷系综，176 GLM，140，560，666，667 黄金公式，67，97，466 戈帕，V.，463 图着色，643，670 图划分，190 图模型有向，447 图模型 *d*-连通，51 *d*-分离，51，445 碰撞点，51 有向，41，50，69，179，180，633 非碰撞点，51 无向，74，648 格罗斯，L.，65 格拉插值，63 古特曼，M.，260

Haar测度，381，543，551 哈密顿动力系统，231 Hammersley，J. M.，575 Hammersley-Chapman-Robbins下界，*see* HCR下界 汉明球，159 汉明界，527 汉明码，362 汉明距离，112，123，389，464 汉明空间，219，347 汉明球，169，170 汉明重量，158，169，170，175 Han, T. S., 475 Harremoës, P., 128 Haussler-Opper估计，188 HCR下界 基于Hellinger的，661 多元的，576 Hellinger距离，116，117，124，131

，

133, 153, 182, 289, 302, 315, 631, 661 上特征化，148 位置族，142 张量化，124 Hellinger 熵在 KL 覆盖数上的界，189, 610 覆盖数，614 局部覆盖数，616 局部填充数，618 填充数，609 海森矩阵，60, 251 Hewitt-Savage 0-1 律，177 隐马尔可夫模型 (HMM)，110 高维概率，83 希尔伯特第13问题，522, 538 霍夫丁引理，86, 88, 334 Huber, P. J., 151, 324, 613 哈夫曼算法，209 假设检验，122 准确率、精确率、召回率，277 渐近性，286 贝叶斯，277, 314, 330 切尔诺夫区域，314 通信约束，325 复合，289, *see* 复合假设检验误差指数，123, 144 误差指数，289, 314 拟合优度，275, 325 独立性检验，326 似然比检验 (LRT)，280, 424 零假设，275 功效，277 稳健，324, 338 ROC 曲线，276 序贯，319 SPRT，320 斯坦因指数，286 强逆，283 第一类、第二类错误，277 弱逆，282

I-MMSE，59 恒等 de Bruijn，191 Ihara，S.，401，419 独立性，50，55 个体（单步）风险，611 个体序列，248，259 不等式 Bennett，301 Bernstein，301 Brunn-Minkowski，573 de Caen，433 熵功率，*see* 熵功率不等式，191 Fano，*see* Fano 不等式 Han，17，28，160 Hoeffding，86，334 Jensen，11 对数 Sobolev，*see* 对数 Sobolev 不等式（LSI），191 Loomis-Whitney，164 非香农，17 Okamoto，301 Pinsker，*see* Pinsker 不等式 Shearer，18 Stam，185 Tao，58，127，190 传输，656 van Trees，645 Young-Fenchel，73 下卷积，547 信息瓶颈，177，549 信息密度，351 条件-去条件，352 信息蒸馏，190 信息流，69，447 信息几何，40，307 信息不等式，24 信息渗透 有向，627，635 无向，650 信息投影，91，178 定义，302 高斯，336 边缘，331 勾股定理，303 信息半径，91，96 信息稳定性，386，393，396，399，464

信息尾部，285，353 Ingster-Suslina公式，185 整数规划，209 积分概率度量，123 交互通信，182，658 符号间干扰（ISI），406 区间删失，668 伊辛模型，74，191，642

James-Stein 估计器，561 Jeffreys 先验，252 联合熵，9 联合范围，115，127 χ^2 与 TV 对比，665 χ^2 与 TV 对比，132 Harremoës-Vajda 定理，128 Hellinger 与 TV，124 Hellinger 与 TV 对比，131 Jensen-Shannon 与 TV 对比，133 KL 与 χ^2 对比，133 KL 与 Hellinger 对比，132, 189, 302 KL 与 TV 对比，131, 665 Le Cam 与 Hellinger，133 Le Cam 与 Jensen-Shannon，133 联合信源信道编码，*see* JSCC 联合类型，462 联合典型性，228, 355, 499 JSCC，391 遍历信源，393 优雅降级，520 无损，392 有损，515 有损，可达性，516 有损，逆定理，515 信源信道分离，392, 516 统计应用，585

Körner, J.，227 Kac引理，262 Kahn, J.，160 Kakutani二分法，125 Kelvin，14 核密度估计器（KDE），136, 624 Kesten-Stigum界，670 KL覆盖数，603, 608 Kolmogorov恒等式，51 Kolmogorov 0-1律，83, 125, 232 Kolmogorov, A. N.，239, 522, 524 Kolmogorov-Sinai熵，239 Koshelev, V.，483 Kraft不等式，207 Krein-Milman定理，130 Krichevsky, R. E.，253 Krichevsky-Trofimov算法，253, 269 Krichevsky-Trofimov估计器，662 Kronecker引理，388

拉普拉斯方法，251 拉普拉斯继承法则，253 拉普拉斯算子，59 大偏差，35，290，291，299 高斯，332 乘性偏差，301 非独立同分布，332 边界上，332 速率函数，296 大偏差理论，159 大语言模型，110，257 大数定律，202 强大数定律，235 Le Cam距离，117 Le Cam引理，146 Le Cam方法，666 Le Cam两点法，594 高维中的松弛性，596 Le Cam，L.，614 Le Cam-Birgé估计量，614 最不利对，338 最不利先验，564 非唯一性，663 Lempel-Ziv算法，263 较少噪声信道，646 Lieb，E.，64 似然比技巧，331 线性码，218，362 陪集首，364 误差指数，433 生成矩阵，362 几何均匀性，363 奇偶校验矩阵，362 伴随式译码器，363 线性规划，368 线性规划对偶性，161 线性回归，271，660 刘维尔定理，231 列表译码，346 Litsyn，S.，433 Lloyd算法，480 Lloyd，S.，480 位置族，40

紧支撑，142 位置参数，40 对数矩生成函数，293 性质，293 对数凹分布，573 对数似然比，280 对数索伯列夫不等式（LSI），65, 132, 191 对数索伯列夫不等式，修正的（MLSI），641 Loomis, L. H.，164 损失函数，559 批量，611 交叉熵，*see* 对数损失累积，259 对数损失，24, 259, 548, 664 二次，561, 575 可分离，569 检验，87 损失函数 对数损失，331 低密度奇偶校验（LDPC），346 下半连续性，148 Mandelbrot, B., 203 马尔可夫近似，235 马尔可夫链，179–181, 232, 265 有限阶，235 马尔可夫链，110, 464 k 阶，110 遍历，266 有限阶，247 混合，641, 669, 671 马尔可夫核，29, 42 复合，30 马尔可夫引理，228, 327, 501 马尔可夫类型，174 鞅收敛定理，80 马尔顿传输不等式，656 梅西有向信息，449 见有向信息，446 Massey, J., 158, 446 矩阵求逆引理，40 Mauer, A., 83 莫雷经验方法，534 Maurey, B., 534 最大编码，357, 367, 397 最大相关，631, 640 最大球堆积密度，527 圆堆积，527

立方体，527 最大熵，100 高斯，28 最大熵，99，336 连续均匀，27 离散均匀，11 高斯，64 几何，175 汉明权重约束，175 多重约束，308 鲁棒版本，175 最大似然估计，*see* MLE 最大后验（MAP），57 McAllester, D. A.，83 McMillan, B.，234 平均场近似，74 保测变换，230 无记忆信道，106 无记忆信源，106，110，200 梅塞尔定理，540 Merhav, N.，260 元逆定理，57，348，368，428，435 极小极大，429 类型方法，15，168，174，425，462，463 度量熵，159，178，189，523 ℓ_q-覆盖 ℓ_p 球，552 ℓ_2-覆盖 ℓ_1 球，529 ℓ_q-覆盖 ℓ_p 球，530 ϵ-容量，523 ϵ-熵，523 凸零，534 覆盖数，523，524，535 汉明空间覆盖，528，551 对偶性，535 熵数，523 有限维球与球面，526 有限性，523 全局到局部，618 Hölder 类，538 希尔伯特球，533 利普希茨类，536 局部到全局，616 单调性，523 填充数，401，523，524 汉明空间填充，527 汉明球填充，528

率失真函数，542 Sobolev球，541 体积界，525，539 体积界，精确常数，527 度量空间，78 Milman, V.，535 最小熵，14，57 极小极大估计量非唯一性，564 极小极大下界 Assouad引理，*see* Assouad引理 渐近，580 优于随机，592 Fano方法，599 Le Cam两点法，*see* Le Cam两点法 互信息方法，*see* 互信息方法 极小极大速率，563 极小极大风险 二项模型，663 协方差模型，667 精确渐近，575 GLM，有界均值，587 GLM，估计最大值，666 GLM，非二次损失，570，571 GLM，二次损失，564，568，587 GLM，稀疏均值，589，666 线性回归，估计，660 线性回归，预测，661 多项模型，664 非参数位置模型，665 极小极大定理，565，566 反例，565 对偶性，565 最小距离，432 最小距离估计量，620 最小均方误差 见MMSE，58 Minkowski维数，527 Minkowski不等式，65 镜像下降，92 MIT，41 混合分布，59 混合过程，232，268 强混合，232 弱混合，232 混合模型 χ^2，185

德菲内蒂，186 散度，188 海林格距离，146 勒卡姆引理，146 雷尼散度，146 最大似然估计，76，91，143，581，667 高维中的次优性，667 最小均方误差，58，562 连续模，668 单调收敛定理，36 信息的单调性，33，42，118 更强信道，646 MRRW (JPL) 界，432 MRRW 界，528 格伯夫人引理 (MGL)，191，326 多项式系数，16 多径分集，403 互信息，41 下确界刻画，68，103 上确界刻画，69，103 凹性，92 连续性，81 凸性，92 有限划分，83 高斯，47 下半连续，82，181 单调极限，83 置换不变性，52 鞍点，94 单字母化，106 随机过程，113 变分刻画，82 韦恩图，46 通过香农下界的互信息方法，586 互信息方法，664 互信息与熵，44 牛顿力学，242 奈曼，J.，275 奈曼-皮尔逊引理，275，284，424 奈曼-皮尔逊区域，278，348，424 噪声门，626 非高斯性，401 正态近似，214 信道编码，439，468

压缩，202 正态尾界，551 奈奎斯特采样，420

在线学习, 245 在线到批量转换, 258, 611 开放问题, 111, 208, 248, 380, 413, 432, 433, 452, 521 算子凸函数, 631 最优传输, 656 预言机不等式, 260 顺序统计量, 178 奥恩斯坦距离, 106, 112 过拟合, 87

PAC-Bayes，188 Panter, P.，481 Panter-Dite 近似，482 参数空间，558 参数族，38, 140 位置族见位置族，40 多维，142 正则，140 平滑，252 参数化族，*see* 参数族 Pearson, E.，275 Pearson, K.，275 渗流，635 Peres 提取器，169 Peres, Y.，169 完美匹配，161 积和式，161 透视函数，92 相变，643 BBP，651 Pinsker 不等式，23, 98, 126, 131, 187 反向，132 植入密集子图模型，591 插件估计器，138, 666 庞加莱回归，231 点互信息（PMI），351 极化码，341, 346 波兰空间，72 阳性预测值（PPV），277 功率分配，402 功率约束，394 功率谱密度，405

Prékopa定理，573 Prékopa，A.，573 预测密度估计器，605 前缀码，206 概率方法，*see* 随机编码，215，353 误码率，389 错误概率，57 保概率变换，230 可能近似正确(PAC)，83 长椭球函数，419 脉冲幅度调制，459 脉冲编码调制(PCM)，477 脉冲位置调制(PPM)，413

量化，477 熵约束，483 最优，480 最优渐近性，481 标量非均匀，479 标量均匀，477 可变速率，483 零速率，548

Rényi散度，126，144，182，188，307，504 凸性，145 张量积，145 Rényi熵，13，57，145 Rényi互信息，504 Rényi, A.，13 Rademacher 复杂度，86 Radhakrishnan, J.，161 集合的半径，96 Radon-Nikodym导数，21，115，322，351 Radon-Nikodym定理，31 随机编码，161，215，353，368，461，493 剔除，432，469 随机矩阵理论，176，552，651，668 随机数生成器，166 随机变换，*see* 马尔可夫核 随机游走，181，266，321，444 随机性提取器，166 秩-频率图，203 Rao, C. R.，576

速率区域, 225, 227 率失真函数, 91, 103, 485 伯努利, 507 离散均匀, 546 擦除度量, 546 埃罗欣, 547 高斯, 509, 550 哈尔测度, 544 信息率失真函数

，

487 非高斯，511 乘积源，546 性质，486 单字母化，487 球面均匀分布，543 最坏情况，542，551 率失真理论渐近，491 平均失真，485 平均失真的收敛速率，546 超额失真，485 超额到平均，488 一般逆定理，485 最大失真，485 多重失真度量，547 输出约束，547 随机编码界，平均失真，493 随机编码界，超额失真，496 瑞利衰落，416 冗余，179，247，261，269 平均情况极小极大，249 最坏情况极小极大，249 里德-穆勒码，345，364 Reeves, A.，477 回归，190 遗憾，247，256，260 有限状态机，264 监督学习，270 正则测度，72 正则化项，88 相对密度，21 可靠计算，626 重复码，345 再生核希尔伯特空间（RKHS），539 反向 Pinsker 不等式，132 黎曼度量，40 风险，559

平均, 562 贝叶斯, 562 极小极大, 563 罗宾斯, H., 575 游程编码, 266

鞍点，94，176 高斯，100，107，466 样本复杂度，568 样本协方差矩阵，85，667 无放回抽样，186 Sanov定理，307，334 Sanov, I. N., 307 得分函数，152 参数化族，39 SDPI，53，328，626，629，669，671 χ^2，640 BSC，633 擦除信道，639 联合高斯，640 后处理，653 张量化，638 自归一化和，302 可分离成本约束，395 序贯预测，245 序贯概率比检验（SPRT），320 香农布尔电路，构造，626 香农熵，8 香农下界，511，586，588 任意范数，511，550 二次失真，511 香农信道编码定理，345，377 香农率失真定理，491 香农信源编码定理，202，214 香农，C. E.，1–672 香农-麦克米兰-布莱曼定理，233 Shawe-Taylor, J.，83 Shearer引理，18，158，160 平移不变事件，231 收缩估计量，561 Shtarkov分布，245，248，260 Shtarkov和，249，260 信噪比（SNR），48 显著性检验，275 单纯形猜想，413 西奈生成元定理，240 西奈，Y.，239 单字母化，106 奇异值分解（SVD），176 奇异值，640 辛克霍恩算法，105，311 位点渗流阈值，637 SLB，*see* 香农下界斯莱皮安，D.，223，531 斯莱皮安-沃尔夫定理，223，225，228 小子图调节，186 小球概率，539 布朗运动，553 有限维，332 平滑密度估计，622 L_2 损失，622 赫林格损失，625 KL 损失，625 TV 损失，624 软覆盖引理，137，505 索洛米亚克，M.，538 源马尔可夫，110 无记忆，*see* 无记忆源混合，110，265 源编码见压缩，197 源编码有噪，548 远程，548 空时编码，409 稀疏估计，589，666 稀疏图码，341，346 稀疏性，666 空间分集，403 谱隙，641，669 谱独立性，641，671 谱测度，233 尖峰维格纳模型，649 平方误差，561 斯塔姆，A. J.，64，186 标准博雷尔空间，20，29，30，42，43，51 平稳高斯过程，114，233 自协方差函数，233 B-过程，233 遍历，233，467

功率谱密度，114，233，405 谱测度，233 平稳过程，109，230 统计实验，*see* 统计模型 统计学习理论，83，87 统计模型，558 非参数，560 参数，560 Stavskaya自动机，637 Stein引理，287，415，470 Stirling近似，16，162，174，260，588 随机块模型，*see* 社区检测，642 随机占优，338 随机局部化，58，191 过滤的停时，319，455 强逆，283，374，422，470 失败，427，465 强数据处理不等式，*see* SDPI 信息次可加性，135 次高斯，85，188 子图计数，160 子模函数，16，27，367 Sudakov最小化，530 充分统计量，41，54，178，180，282，363 监督学习，257，270 支撑，3，309 对称KL信息参见f-信息 对称KL，135 对称群，381 系统辨识，660 Szarek, S. J., 527, 535 Szegö定理，114，406 Szemerédi正则引理，127，190 尾部σ-代数，83，231 Telatar, E., 187, 409 温度，336 实验的张量积，568 极小极大风险，569 张量化，33，55，63，106，107，112，124，145，636，638，640，647，670 F_I-曲线，338 I-投影，331

χ2, 145 容量, 377 容量-成本, 397 Hellinger, 124 极小极大风险, 569 测试误差, 87 热力学, 9, 14, 410 Thomason, A. G., 164 阈值化, 561, 589, 590 Tikhomirov, V. M., 522, 524 倾斜, 72, 297 时间共享, 226 Toeplitz 矩阵, 114 全变差, 98, 116, 122, 131, 132, 330, 629 下确界表示, 181 下确界表示, 122 上确界刻画, 148 上确界表示, 122 训练误差, 87 训练样本, 87 转移概率核, *see* 马尔可夫核 发射分集, 409 Trofimov, V. K., 253 Tunstall 码, 196 涡轮码, 346 类型, *see* 类型方法, 174

不可检测错误，213，224 一致收敛，85，86 一致可积性，153 一致量化，29 一致可积鞅，80 并集封闭集猜想，189

唯一可解码码，206 酉算子，243 通用码，462 通用压缩，179, 210, 270 通用预测，255 通用概率分配，245, 255 乌雷松引理，72 乌雷松，P. S.，72 瓦伊达，I., 128 范·特里斯不等式，*see* 贝叶斯克拉美-罗（BCR）下界 范·特里斯，H. L., 577 瓦拉丹，S. S., 71 变熵，200, 547, 584 变长码，168, 455 变分自编码器（VAE），76, 602 变分推断，74 变分表示，70, 71, 123, 147, 154 χ^2, 149 费舍尔信息，151 海林格距离，148 全变差，122, 148 瓦尔沙莫夫，R. R., 527 维恩图，46 贝尔杜，S., 414 贝尔杜，S., 475 变换内容，14 维图什金，A. G., 538 VLF码，455 VLFT码，471 体积比，525

冯·诺依曼，J.，166，626 沃罗诺伊单元，347 沃夫克，V. G.，271

Wald，A.，319 Wasserstein距离，105，123，151，656 注水解法，114，176，341，402，406，437，438 瀑布图，423，439 弱逆定理，282，348，397 Whitney，H.，164 维纳过程，417 WiFi，403 维格纳半圆律，652 Williamson，R. C.，83 Wishart矩阵，176 Wolf，J.，223 Wozencraft系综，366 绞拧引理，187 Wyner共同信息，502 Wyner，A.，227，502

Yaglom, A. M., 70 Yang, Y., 606 Yang-Barron 估计量, 607 Yatracos 类, 621 Yatracos 估计量, 620 Yatracos, Y. G., 620 Young-Fenchel 对偶, 73

Zador, P. L., 482 齐普夫定律, 203