Introduction to Derivative-Free Optimization

Andrew R. Conn
Katya Scheinberg
Luis N. Vicente

MPS-SIAM Series on Optimization

Derivative-Free Optimization 简介

MPS-SIAM优化系列

本系列由数学规划学会与工业与应用数学学会联合出版。它涵盖研究专著、应用类书籍、各级别教材以及教程。除了具备高科学质量外，本系列书籍还必须推动优化领域的理解和实践。它们还必须表述清晰，且适合相应层次的读者。

总编辑

菲利普·托因特，*University of Namur (FUNDP)*

编辑委员会

Oktay Gunluk, *IBM T.J. Watson Research Center* Ma
tthias Heinkenschloss, *Rice University* C.T. Kelley,
North Carolina State University Adrian S. Lewis,
Cornell University Pablo Parrilo,
Massachusetts Institute of Technology Daniel Ralph
, *University of Cambridge* Mike Todd,
Cornell University Laurence Wolsey,
Université Catholique de Louvain Yinyu Ye,
Stanford University

系列卷

Conn, Andrew R.， Scheinberg, Katya， 和 Vicente, Luis N.，
Introduction to Derivative-Free Optimization Ferris, Michael C.， Mangasarian, Olvi L.， 和
Wright, Stephen J.， *Linear Programming with MATLAB* Attouch, Hedy， Buttazzo, Giuseppe， 和 Michaille, Gérard， *Variational Analysis in Sobolev and* BV
Spaces: Applications to PDEs and Optimization Wallace, Stein W. 和 Ziemba, William T.，
编辑， *Applications of Stochastic Programming* Grötschel, Martin， 编辑，
The Sharpest Cut: The Impact of Manfred Padberg and His Work Renegar, James，
A Mathematical View of Interior-Point Methods in Convex Optimization Ben-Tal, Aharon
和 Nemirovski, Arkadi， *Lectures on Modern Convex Optimization:*
Analysis, Algorithms, and Engineering Applications Conn, Andrew R.， Gould, Nicholas I. M
.， 和 Toint, Phillippe L.， *Trust-Region Methods*

Derivative-Free Optimization 简介

安德鲁·R·康 卡佳·沙因伯格 IBM
Yorktown Heights, New York

路易斯·N·维森特
Universidade de Coimbra
Coimbra, Portugal

siam®
工业与应用数学学会 费城

mps Mathematical Programming Society
数学规划学会 费城

版权所有 © 2009 工业与应用数学学会及数学规划学会

10 9 8 7 6 5 4 3 2 1

版权所有。在美国印刷。未经出版商书面许可，不得以任何方式复制、存储或传播本书的任何部分。如需信息，请致函：Society for Industrial and Applied Mathematics, 3600 Market Street, 6th Floor, Philadelphia, PA 19104-2688 USA。

本书中使用的商标名称可能未附带商标符号。这些名称仅用于编辑语境；无意侵犯商标权。

MATLAB 是 The MathWorks, Inc. 的注册商标。如需 MATLAB 产品信息，请联系 The MathWorks, Inc.，地址：3 Apple Hill Drive, Natick, MA 01760-2098 USA，电话：508-647-7000，传真：508-647-7101，*info@mathworks.com*，*www.mathworks.com*。

美国国会图书馆在版编目数据

康恩，安德鲁·R.
无导数优化导论 / Andrew R. Conn, Katya Scheinberg, Luis N. Vicente. p. cm. —（MPS-SIAM优化丛书；8）包含参考文献和索引。ISBN 978-0-898716-68-9

1. 数学模型。2. 数学优化——工业应用。3. 工程数学。4. 工业工程——数学。5. 搜索理论。6. 非线性理论。I. Scheinberg, Katya. II. Vicente, Luis N. III. 标题。

TA342.C67 2008
519.6—dc22

2008038005

关于封面

封面艺术 © Masha Ryskin，咖啡、石墨、墨水于板上，61厘米 x 61厘米（24英寸 x 24英寸）。
标题：*Inside*. 私人收藏。摄影师：Masha Ryskin。

玛莎·雷斯基是一位出生于俄罗斯的画家、版画家和装置艺术家，生活和工作在美国。她拥有罗德岛设计学院和密歇根大学的学位。她的作品曾在国内外展出，并曾在美国、欧洲、哥斯达黎加和印度尼西亚工作。她的艺术通过风景及其元素，探讨地方感、历史与记忆。*Inside*论述了将景观视为碎片拼合而成一个完整整体的概念。

Cover art reprinted with permission from the artist.

siam is a registered trademark. mps Mathematical Programming Society is a registered trademark.

致奥斯卡，他向我介绍了许多重要的事物。(Andrew) 致我的父母，他们在每一项事业中都支持我。(Katya) 致我的父母，纪念我的父亲和一直支持我的母亲。(Luis)

目录

前言 **xi**

1 引言 1
1.1 为什么无导数优化 . . . . . 1 1.2 导数不可得问题的示例 . . . . . 3 1.3 无导数优化的局限性 . . . . . 5 1.4 无导数算法应如何工作 . . . . . 7 1.5 本书简要总结 11

I 采样与建模 13

2 抽样与线性模型 15
2.1 正生成集与正基 . . . . . 15 2.2 直接搜索中使用的梯度估计 . . . . . 21 2.3 线性插值与回归模型 . . . . . 24 2.4 线性插值与回归的误差界 . . . . . 26 2.5 其他几何概念 . . . . . 29 2.6 单纯形梯度 . . . . . 32 2.7 练习 33

3 插值非线性模型 35
3.1 插值中的基本概念 . . . . . 36 3.2 拉格朗日多项式 . . . . . 39 3.3 Λ-良好姿态性及其他良好姿态性的度量 . . . . . 42 3.4 条件数作为良好姿态性的度量 . . . . . 48 3.5 练习 56

4 回归非线性模型 57
4.1 多项式最小二乘回归中的基本概念 . . . . . 58 4.2 回归意义下的拉格朗日多项式 . . . . . 60 4.3 回归意义下的Λ适定性 . . . . . 62 4.4 条件数作为良适定性的度量 . . . . . 68 4.5 注释与参考文献 . . . . . 70 4.6 练习 72

5 欠定插值模型 73
5.1 欠定模型的选择 . . . . . 74 5.2 拉格朗日多项式与欠定插值的 Λ 适定性 . . . . . 76 5.3 最小弗罗贝尼乌斯范数模型 . . . . . 80 5.4 注释与参考文献 . . . . . 87 5.5 练习 87

6 确保良好平衡性和合适的无导数模型 89
6.1 完全线性与完全二次模型 . . . . . 90 6.2 利用拉格朗日多项式确保良好平衡性 . . . . . 93 6.3 利用主元算法确保良好平衡性 . . . . . 99 6.4 几何改进算法的实际考虑 . . . . . 107 6.5 确保回归和最小弗罗贝尼乌斯范数模型的良好平衡性 . . . . . 108 6.6 其他注释和参考文献 . . . . . 110 6.7 练习 112

二 框架与算法 113

7 方向直接搜索法 115
7.1 坐标搜索法 . . . . . 115 7.2 方向直接搜索框架 . . . . . 118 7.3 连续可微情形下的全局收敛性 . . . . . 120 7.4 非光滑情形下的全局收敛性 . . . . . 124 7.5 整数格点上的简单下降 . . . . . 127 7.6 网格自适应直接搜索法 . . . . . 132 7.7 施加充分下降 . . . . . 134 7.8 其他注释与参考文献 . . . . . 135 7.9 练习 139

8 单纯形直接搜索方法 141
8.1 Nelder–Mead 单纯形法 . . . . . 141 8.2 Nelder–Mead 单纯形法的性质 . . . . . 148 8.3 Nelder–Mead 方法的一个全局收敛变体 . . . . . 149 8.4 其他注释与参考文献 . . . . . 161 8.5 练习 161

9 基于单纯形导数的线搜索方法 163
9.1 线搜索框架 . . . . . 163 9.2 一阶临界点的全局收敛性 . . . . . 165 9.3 噪声分析 . . . . . 167 9.4 隐式过滤算法 . . . . . 168 9.5 其他单纯形导数 . . . . . 169 9.6 其他注释和参考 . . . . . 170 9.7 练习 171

10 基于无导数模型的信赖域方法 173
10.1 信赖域框架基础 . . . . . 173 10.2 信赖域模型的条件 . . . . . 179 10.3 无导数信赖域方法（一阶） . . . . . 181 10.4 一阶临界点的全局收敛性 . . . . . 185 10.5 无导数信赖域方法（二阶） . . . . . 191 10.6 二阶临界点的全局收敛性 . . . . . 194 10.7 较大同心球中的模型精度 . . . . . 200 10.8 信赖域子问题 . . . . . 202 10.9 其他注释与参考文献 . . . . . 204 10.10 习题 205

11 基于信赖域插值的方法 207
11.1 共同特征与考量 . . . . . 207 11.2 “DFO”方法 . . . . . 208 11.3 鲍威尔方法 . . . . . 211 11.4 楔形方法 . . . . . 215 11.5 其他说明与参考文献 225

三、其他主题的回顾 227

12 代理模型管理综述 229
12.1 代理模型构建 . . . . . 229 12.2 处理代理模型的严格优化框架 . . . . . 235 12.3 练习 240

13 约束及其他扩展的无导数优化综述 241
13.1 方向直接搜索方法 . . . . . 242 13.2 基于信赖域插值的方法 . . . . . 248 13.3 全局优化、混合整数规划及其他问题的无导数方法 249

附录 无导数优化软件 251

参考文献 255

索引 271

前言

多年来，我们三人一直对无导数优化抱有浓厚兴趣，并努力为之做出贡献。撰写本书的动机源自多种情况。我们有机会与该领域的杰出贡献者密切合作，特别是约翰·丹尼斯、迈克尔·鲍威尔、菲利普·图安特和弗吉尼亚·托克松。我们对该领域近期发展的各个方面有所了解，但仍感到需要一个统一的视角，并希望通过此举能更深入地理解这一领域。此外，日益增长的应用数量也吸引了我们。我们强烈感受到，特别是一本关于无导数优化的教科书需求甚大，尤其是在过去十年里，其基础、算法和应用都有了显著丰富。最后，尽管该主题依赖于许多关于带导数优化的真理，并且是为其开发的，但所出现的问题是全新的。无法计算导数自然禁止了泰勒模型的使用——这在基于导数的优化中极为常见。典型应用涉及昂贵的函数评估这一事实，将重点从线性代数的成本或其他影响迭代复杂度的因素转移到了单纯的函数评估次数上。同时，函数值中的噪声影响了局部收敛预期。因此，该领域既因预期降低而显得更简单，又因试图在信息量大大减少的情况下达成目标而变得更为困难。它无疑既有趣又充满挑战，而且，绝非偶然，非常实用。

尽管我们付出了相当的努力来呈现当前的最新进展，但我们并不试图对该领域的所有工作进行全面的论述。部分原因是我们认为该主题尚未成熟到足以进行全面论述的程度。出于类似的原因，我们的重点放在无约束问题上，尽管我们也回顾了迄今为止在约束无导数优化方面所做的工作。约束问题在应用中实际上非常重要，但迄今为止发表的文献中对约束问题无导数方法的理论研究非常有限，因此，至少对于本卷而言，我们满足于集中讨论无约束情况。

本书旨在做到相对自足，面向具有微积分、线性代数和数值分析背景的研究生或高年级本科生水平的读者。具备一些优化基本概念会有所帮助，但并非必要。我们当然希望实践者能够发现所涵盖的材料既易于理解，又在他们的需求范围内相当完整，无论他们侧重算法还是应用。我们还努力在适当的地方加入了图表和练习。主要目标包括让任何感兴趣的读者充分了解无导数优化的最新进展，并详细讨

对基础理论的描述应达到这样的程度：读者能够充分理解确保收敛所需的条件、这如何影响算法设计，以及可以预期何种成功、在何处取得成功。因此，我们的目标当然是使这些材料对希望在该领域进行研究的人具有吸引力。

正如我们在引言中所述，由于计算机模拟及其他应用的日益成熟和高效，越来越多的情形下，人们希望对复杂系统进行优化，而由此产生的目标函数的导数信息却不可得。本书旨在帮助读者研究并在必要时选择合适的方法来实现这一目标。同时，本书也致力于提炼并强调现代无导数算法所共有的理论特征，并突出它们之间的差异。

如果我们在序言结束时没有指出这一领域未来的发展方向，那就有所疏忽了。仍有许多未知等待被发现。毫无疑问，研究人员和实践者，或许不久之后，将发现处理更大规模问题的方法，无论是通过使用大规模并行架构，还是通过尚未实现的硬件进步，或是理论上的突破，或者很可能是这三者的结合。约束无导数优化理论在不久的将来也可能取得显著进展。当然，尤其是由于困难和重要应用的广泛存在，这预示着在未来许多年里，这将是一个令人兴奋、有趣且充满挑战的领域。

除本前言第一段提到的同事外，我们还要感谢许多其他人，他们在本书的特定部分提供了宝贵的反馈，特别包括Natalia Alexandrov、Charles Audet和Paul Tseng。我们非常感谢Ana Luísa Custódio对手稿的不懈校对。我们还要感谢最初提交给SIAM版本的审稿人，特别是Tim Kelley和Jorge Nocedal，感谢他们提出的许多有趣评论和建议。

第1章

简介

1.1 为什么无导数优化

众所周知，待优化函数的导数中蕴含着大量有用的信息。毕竟，对于连续可微函数而言，局部最小值的“标准”数学刻画由一阶必要条件给出，要求一阶导数为零。然而，出于种种原因，总有许多情形下（至少部分）导数不可得或不可靠。尽管如此，在此类情况下，开展优化仍然可能是可取之举。因此，一类被称为无导数优化方法的非线性优化技术一直有其需求。事实上，我们认为无导数优化是计算科学与工程中最为重要、开放且具有挑战性的领域之一，并且具有巨大的实际应用潜力。其之所以具有挑战性，是因为从优化的角度来看，不利用导数便舍弃了大量信息。其当前实际重要性的根源在于，求解由那些导数不可得或获取代价高得难以承受的函数所定义的优化问题的需求日益增长。数学建模日益复杂、科学计算精密度不断提高，以及大量遗留代码的存在，都是无导数优化当前需求旺盛的部分原因。

在非线性优化的早期，使用无导数方法最常见的原因之一或许是用户缺乏经验或毅力。用户知道他们想要改进当前的“解决方案”，但他们希望使用一些他们能理解的简单方法，因此他们使用（不幸的是，有时继续使用）非导数方法，如Nelder和Mead [177]的方法，即使有更合适的算法可用。为实践者辩护，我们应该记住，直到相对最近，计算导数一直是应用优化软件时用户错误的最常见来源（例如，见[104，第8章，第297页]）。随着应用规模和难度的增加，更复杂的基于导数的优化方法变得更加必要。随着基于导数的非线性优化方法的成长和发展，很明显，大规模问题可以高效解决，但前提是有准确的导数信息。

手头的信息。用户开始要么提供这样的导数（通过手工编码或对其软件应用自动微分工具），要么通过有限差分来估计导数。一些优化软件包在内部执行有限差分梯度评估，但通常最好将此留给用户，因为有限差分步长的理想大小可能取决于应用。

然而，在某些情况下，上述获取导数的任何一种方法都无法奏效。例如，对于遗留代码或专有代码，即过去编写且未经原作者维护的代码，现在重写此类代码，或向其添加提供一阶导数所需的内容，可能是一项极其耗时的工作。问题还可能取决于某公司拥有的代码，而该公司仅能访问二进制文件。自动微分技术（例如，参见[111, 112]）也并非在所有情况下都能应用。特别是，如果目标函数是使用黑箱模拟软件包计算的，自动微分通常是不可能的，即使在计算更易访问的情况下，遗留或专有问题也可能使这种方法不可接受。

在应用有限差分导数近似时，还有两种不适宜的情况：函数评估代价高昂及评估结果含噪声。在第一种情况下，进行必要数量的函数评估（通常不少于变量数量加一）以提供单个梯度估计可能是不可行的。在第二种情况下，梯度估计可能完全无用武之地。具有讽刺意味的是，随着计算机硬件、数学算法和软件的日益精进，这类情况非但没有减少，反而变得更加频繁。原因很简单，以往模拟复杂系统是一项困难且成本高昂的任务，不足以成为优化的理想环境，而如今此类模拟正变得越来越常规，也越来越精确；因此，对复杂系统进行优化逐渐成为可能。对高级无导数优化方法日益增长的需求推动了多种方法的相对广泛发展。近年来，该领域经历了重大变革，理论与实践不断进步，在非线性优化界的关注度也不断提升。通过撰写本书，我们希望能为当今现有的无导数方法提供一个统一的理论视角。我们简要讨论实际性能及可预期成果，但本书的主要目的是全面展示这些算法为何有效及如何运作。

我们将考虑的方法不依赖于目标函数或约束的导数信息，也不 explicit 设计为近似这些导数。相反，它们基于样本函数值构建函数模型，或者直接利用一组样本函数值而不构建显式模型。正如我们之前所暗示的，缺乏导数信息会带来相当大的不利影响，因此不能期望无导数方法的性能与基于导数的方法相当。特别是，目前无导数方法能够有效解决的问题规模仍然相对较小，即使在简单情况下也不超过几百个变量。在函数评估存在噪声和/或成本高昂的情况下，缺乏导数时停止准则也是一个挑战。因此，假设导数信息可用，无导数方法获得的近似最优解往往不如基于导数的方法获得的解准确。尽管如此，对于当今存在的许多应用，这些限制是可以接受的。

1.2 导数不可用问题的示例

实际上存在大量这样的问题：其中导数不可得，但出于实际需要，人们又有迫切的实际理由希望进行某种优化。一个几乎自然而然的悖论是，当今的实际问题往往复杂、非线性，并且没有被足够明确地定义，以至于无法给出可靠的导数。确实，这类问题一直很多，但30年前，当非线性优化技术相对于今天还较为幼稚时，即使是最乐观的实践者也不会尝试优化如此复杂的问题。2008年则不然！应用的多样性包括工程、数学、物理、化学、经济学、金融、医学、交通、计算机科学、商业和运筹学中的问题。

作为示例，我们包括已知应用和参考文献的一个子集。我们首先介绍一些示例（如算法参数调优和自动错误分析），这些示例可能不是无导数优化的典型应用，但容易理解。

算法参数的调整与自动误差分析

无导数优化的一个有趣（且可能有用）的应用在[22]中被探索，用于调整非线性优化方法的参数，并取得了有前景的结果。大多数数值代码（用于模拟、优化、估计或其他任何用途）都依赖于若干参数。所有实现数值算法的人都知道这些参数的选择有多关键，以及它们对求解器性能的影响有多大。通常，这些参数被设置为要么具有某种数学依据的值，要么是代码开发者发现表现良好的值。自动化选择参数（以寻找可能的最优值）的一种方法是考虑一个优化问题，其变量是参数，其目标函数衡量在给定参数选择下求解器的性能（通过CPU时间或求解器所采取的迭代次数等其他指标来衡量）。这类问题可能有诸如求解器参数值的上下界等约束，并且看起来像

$$\min_{p\in\mathbb{R}^{n_p}} f(p) = CPU(solver; p) \quad \text{s.t.} \quad p \in P,$$

其中 n_p 是待调优的参数数量，而 P 的形式为 $\{p \in \mathbb{R}^{n_p}\colon\ \ell \le p \le u\}$。不仅很难为这样的函数 f 计算导数，而且很可能会出现数值噪声和某种形式的不可微性。

无导数优化也被用于自动误差分析[126, 127]，这一过程利用计算机来分析数值计算的准确性或稳定性。自动误差分析的一个例子是分析对于特定的主元策略，高斯消元法的增长因子最大能有多大。这类研究的相关性源于增长因子对高斯消元法稳定性的影响。给定一种主元策略和固定的矩阵维度n，所提出的优化问题是确定一个矩阵，使得增长因子对于

高斯消元法:

$$\max_{A\in\mathbb{R}^{n\times n}} f(A) = \frac{\max_{i,j,k} |a_{ij}^{(k)}|}{\max_{i,j} |a_{ij}|},$$

其中 $a_{ij}^{(k)}$ 是消元过程中生成的中间元素。一个起点可以是阶数为 n 的单位矩阵。当未选择主元时，f 在所有消元不发生中断的点上都有定义且连续。当定义增长因子表达式的最大值处出现并列时，可能会出现不可微性。对于部分主元法，函数 f 在所有地方都有定义（因为消元不会中断），但当主元元素的选择出现并列时，它可能是不连续的。使用无导数优化的自动误差分析的其他示例包括矩阵条件数的估计以及快速矩阵求逆和多项式求根的数值稳定性分析 [126, 127]。

工程设计

无导数优化的一个案例研究是直升机旋翼叶片设计问题[38, 39, 206]。目标是找到旋翼叶片的结构设计，以最小化传递到毂的振动。变量包括旋翼叶片各段的质量、重心和刚度。仿真代码是多学科的，涉及动态结构、空气动力学以及尾流建模与控制。问题包含变量的上下界，并且考虑了一些线性约束，如质量总和的上界。每次函数评估都需要进行仿真，可能需要几分钟到几天的CPU时间。基于直接搜索方法的代理管理框架（见第12.2节）取得了令人鼓舞的结果。其他多学科或复杂设计问题已被报道可通过无导数优化方法和/或代理管理框架成功解决，例如机翼平台设计[16]、气动声学形状设计[164, 165]和流体动力设计[87]。

电路设计

无导数方法也被用于相对较小电路的参数调优。特别是在时钟分配网络的调优中得到了应用。芯片上的操作按周期进行（例如，每个操作八个周期），芯片的每个部分必须在每个周期开始时同步。时钟分配网络通过向每个部分发送信号来同步芯片，尽管总是存在一定的失真和延迟，但信号必须以最小的失真和延迟到达所有地方。由此产生的优化问题包括可能的参数：线长、线宽、线屏蔽和缓冲器大小。考虑的可能的约束和目标包括延迟、功率、转换速率过冲/下冲、占空比和转换速率。函数值由PowerSpice包[2]计算，这是一个众所周知的精确电路仿真包，然而它不提供导数计算。无导数优化被应用于协助电路设计者优化其（小型）电路。在时钟分配网络的特定情况下，它使电路设计者能够相对快速地尝试不同的目标函数和约束组合，而无需手动调优。这导致对问题有更好的理解，从而能够发现替代设计。

分子几何结构

另一个使用我们所关注的这类无导数方法并不罕见的问题是分子几何优化及相关问题。这方面的一个例子是考虑一个由N个原子组成的团簇的几何结构（这相当于3$N-6$个变量）。目标则是通过底层动力学的数值模拟来计算团簇总能量的无约束最小化。我们指出，对于这类问题，存在多个局部极小值（尽管总能量的计算越现实，局部极小值的数量越少），因此在使用本书所涵盖的这类无导数方法时必须谨慎（关于全局优化的扩展，见第13.3节）。梯度可能是可用的，但它可能计算代价高昂，或受噪声影响，甚至由于非凸性的存在而不宜使用。无导数优化方法，特别是直接搜索方法（见第7章），已被适当调整以处理这类问题（见[10, 170]）。

其他应用

近期许多其他无导数优化的应用也 可以在地下水社区问题[99, 174, 233]、医学图像配准 [179, 180] 和动态定价 [150] 等多个领域中被引用。

1.3 无导数优化的局限性

也许无导数方法的局限性中最重要的是，在串行机器上，通常不适合尝试优化超过几十个变量的问题，尽管一些最新的技术可以处理数百个变量的无约束问题（例如，见[192]）。此外，即使在相对简单且条件良好的问题上，通常也无法期望得到精确解。收敛速度通常相当慢。例如，为了最终实现类似二次局部收敛速率，需要隐式或显式的局部模型，这些模型在当前邻域内是二阶泰勒级数模型的合理近似。如果有100个变量，若使用插值，一个局部二次函数将需要5151次函数评估（见表1.1）。正如在基于导数的情况下，通过使用Hessian矩阵的近似（如拟牛顿法[76, 178]）可以实现良好的收敛，有理由假设在无导数的情况下，通过使用不完全二次模型或仅基于一阶近似的二次模型，也可以实现类似的快速收敛。这些思想在[52, 59, 61, 191, 192]中得到了成功应用。例如，NEWUOA算法[192]通常使用2{v*} + 1次函数评估来构建其模型。然而，除非函数在最优解附近看起来非常像二次函数，为了取得进展，随着步长和采样半径趋近于零，模型必须频繁地重新计算。即使在线性模型的情况下，当函数评估代价高昂时，这也可能是不可行的。因此，通常可以预期局部收敛速率更接近线性而非二次，并且可能倾向于提前终止。

至于只能处理大约20个或稍多变量的情况（目前，串行机器上能够解决的最大无约束问题似乎

表1.1。*Number of points needed to build a "fully quadratic" polynomial interpolant model.*

n	10	20	50	100	200
$(n+1)(n+2)/2$	66	231	1326	5151	20301

（可能有数百个变量），通常的补救方法是使用统计方法，如方差分析（参见，例如，[203]）来确定，比如，最关键的20个变量，并仅对这些变量进行优化。利用一些无导数算法的相对简单性也可能是合理的，比如方向直接搜索方法（在第7章中解释），并在并行甚至大规模并行的环境中进行计算。

无导数优化的另一个局限性可能出现在最小化非凸函数时。然而，尽管尚无证据支持这一说法，但人们普遍认为无导数优化方法具有以下意义上的找到"良好"局部最优解的能力。如果一个函数表面上拥有大量局部最优解，或许是由于噪声所致，那么无导数方法由于其相对粗糙性，在早期迭代中倾向于首先进入普遍较低的区域（因为它们的短视，甚至可以说是近乎盲目），而在后期迭代中它们仍然倾向于平滑函数，而更精细的方法则很可能找到距离起始点最近的局部最优解。倾向于"平滑"函数也是它们对适度噪声函数有效的原因。在许多情况下，无导数方法是唯一合适的方法，能够比启发式或其他"最后手段"算法做得更好，并提供支持性的收敛理论。

然而，存在一些问题类别，对于这些问题，我们在此讨论的无导数方法并不适用。通常，针对这类问题的严谨方法需要极其庞大的工作量，且随着问题规模的增大呈指数级增长。这一类别的问题包括：有导数或无导数的中大规模通用全局优化问题；不仅没有可用导数，而且远非光滑问题的问题；含离散变量的通用大型非线性问题，包括许多组合优化问题（即所谓的NP难问题）；以及随机优化问题。尽管相对专门的算法能够为许多组合优化问题充分找到良好的解，但对于含整数变量的通用大型非线性问题而言，情况并非如此。我们不讨论专为组合优化或随机优化问题设计的算法方法。

对于上述提到的一些极端情况，经常采用启发式方法，如模拟退火[143]、遗传及其他进化算法[108, 129]、人工神经网络[122]、禁忌搜索法[107]以及粒子群或基于种群的方法[142]，包括（常常是非常复杂的变体）枚举技术。作者认为这些方法是最后的手段（即适用于搜索空间必然庞大、复杂或理解不足，且更复杂的数学分析不适用的问题），只有在没有更好的方法时才会使用。本书不讨论这类方法。然而，有时这些方法会与我们所讨论的方法结合使用；例如，参见[13, 135, 222]和本书第13.3节。

人们有时认为无导数优化方法应该简单且易于实现。然而，这类方法在理论和实践中通常较为逊色。不过，Nelder-Mead算法可以表现得非常好，并且预计会长期存续。尽管如此，它仍存在严重缺陷：它几乎从不是最优方法，而且确实没有一般的收敛结果，因为它很容易不收敛（尽管其改进版本已被证明具有收敛性，正如我们将在书中解释的那样）。由于作者们在优化领域的合计研究经验超过60年，我们相信，一旦此类方法的全面描述广泛可用，最终更复杂且更成功的方法将在实际应用中赢得其应有的地位。这在一定程度上是本书的动机所在。

最后，我们要强调一个经常反对使用无导数方法的观点：如果你能获得干净的导数（即使需要付出相当大的努力），并且定义问题的函数是平滑且无噪声的，那么你就不应该使用无导数方法。

1.4 无导数算法应如何工作

本书主要致力于研究无约束优化问题的无导数算法，我们将以如下形式表示：

$$\min_{x\in\mathbb{R}^n} f(x). \tag{1.1}$$

我们感兴趣的是全局收敛到驻点（一阶或二阶类型）的算法，换句话说，这些算法无论起始点如何，都能生成渐近逼近驻点的迭代序列。

一些主要成分

也许这过于简化了，但可以说所有全局收敛的无导数算法都具有三个特征：

1. 它们采用某种机制来施加远离稳定点的下降。基于导数的算法也采取同样的做法来确保全局收敛，因此这种施加并不新鲜。关键在于施加方式的不同。例如，方向型直接搜索方法通过使用*positive bases or spanning sets* (见第7章)并沿函数值最佳的模式点方向移动来实现这一目标。基于单纯形的方法（第8章）通过从函数值最差的点沿*away*方向移动，确保从*simplex operations*如*reflections*的下降。诸如隐式过滤法（第9章）旨在沿负的*simplex gra- dients*获得下降，这与多项式模型密切相关。信赖域方法则最小化由*fully linear*或*fully quadratic models*定义的信赖域子问题，这些通常由多项式插值或回归构建——见第10章和第11章。

在每种情况下，通过结合此类机制与相应步长参数可能的缩减，保证了远离稳定点的下降。这样的参数可以是网格尺寸参数（方向直接搜索）、单纯形直径（单纯形直接搜索）、线搜索参数或信赖域半径。

2. 它们必须确保对函数评估样本集几何形态的某种控制。本质上，这类操作确保了任何平稳性迹象（如模型平稳性）确实是真实的。未能实施良好的几何控制解释了原始Nelder-Mead方法缺乏收敛性的原因。

几何度量的例子包括：(i) 正生成集的余弦度量；(ii) 单纯形的正规化体积（两者均需远离零）；(iii) Λ稳定常数，在构建插值模型和单纯形导数时，应保持适度小并上方有界。

3. 他们必须将步长参数驱动至零。我们知道，大多数优化代码在步长参数低于给定的很小阈值时停止执行。在基于导数的优化中，这样的终止可能为时过早，并且是失败的迹象，也许是因为导数要么不够准确，要么编码错误。当导数可用时，最佳的停止准则基于由一阶必要条件所表明的某种形式的平稳性。

在无导数优化中，步长具有双重作用：除了限制最小化步骤的大小外，它还控制着在当前迭代点周围采样函数的局部区域大小。例如，在直接搜索方法中，步长与定义模式的网格大小相同，或是彼此的常数倍。在基于模型的无导数方法中，信赖域或线搜索步长的大小通常与样本集的半径紧密相关。显然，为了确保目标函数表示的准确性，样本集的半径或网格大小必须趋近于零。尽管可以将步长与样本集大小解耦，但迄今为止，大多数无导数方法（原始Nelder-Mead方法除外）都将这两个量联系起来。实际上，本书将要展示的无导数方法的收敛理论表明，步长参数序列（或其子序列）确实会趋近于零（参见定理7.1或引理10.9）。这是有效算法机制的隐含结果，不应（或不必）显式强制执行。因此，基于步长大小的停止准则是一种自然的选择。

上面列出的成分的细节——希望——在接下来的章节中会对读者更加清晰。

使用当前最先进的无导数优化方法，可以期望成功解决的问题包括：(i) 变量数不超过大约一百个；(ii) 具有合理的光滑性；(iii) 函数评估成本高昂和/或带有噪声（并且对于这些问题，精确的有限差分导数估计是不可行的）；(iv) 快速渐近收敛并非首要考虑。

典型行为的一个指示

我们选择了两个简单问题来说明上述评论的部分有效性，以及不同类型的无导数优化方法的优缺点。我们不想报告不同方法表现的全面比较，因为在无导数优化中，鉴于应用问题的极大差异性，这样的数值研究即使要做到充分，也并非易事。然而，如果我们聚焦于

一个特定的应用。另一种可能性是选择一组已知导数的测试问题，并像导数不可用一样对待它们。Moré和Wild [173] 建议使用数据概览来在一组测试集上比较一组无导数算法。无论如何，我们将此类比较留给其他人。

第一个问题涉及Rosenbrock函数的最小化

$$\min_{(x_1,x_2)\in\mathbb{R}^2} 100(x_1^2 - x_2)^2 + (1 - x_1)^2,$$

它在 (1, 1) 处有唯一的最小值点。该函数的等值线描绘了一条两侧陡峭、强烈弯曲的山谷（见图1.1）。根据所选起点的不同，不探索函数曲率的方法可能会极其缓慢。例如，如果从 $(-1, 1)$ 附近开始，则必须沿着一条两侧相对陡峭的弯曲山谷前进，才能达到最小值。

第二个问题涉及最小化一个看似简单的扰动二次函数。该扰动包含周期为$2\pi/70$和$2\pi/100$的余弦函数：

$$\begin{aligned}\min_{(x_1,x_2)\in\mathbb{R}^2} \quad & 10(x_1^2)(1 + 0.75\cos(70x_1)/12) + \cos(100x_1)^2/24 \\ & + 2(x_2^2)(1 + 0.75\cos(70x_2)/12) + \cos(100x_2)^2/24 + 4x_1x_2.\end{aligned}$$

唯一的极小值点位于 (0, 0)（见图 1.1）。与 Rosenbrock 函数相比，这里的潜在平滑函数曲率平缓。然而，扰动后的函数已被噪声污染，这将对算法构成不同的困难。

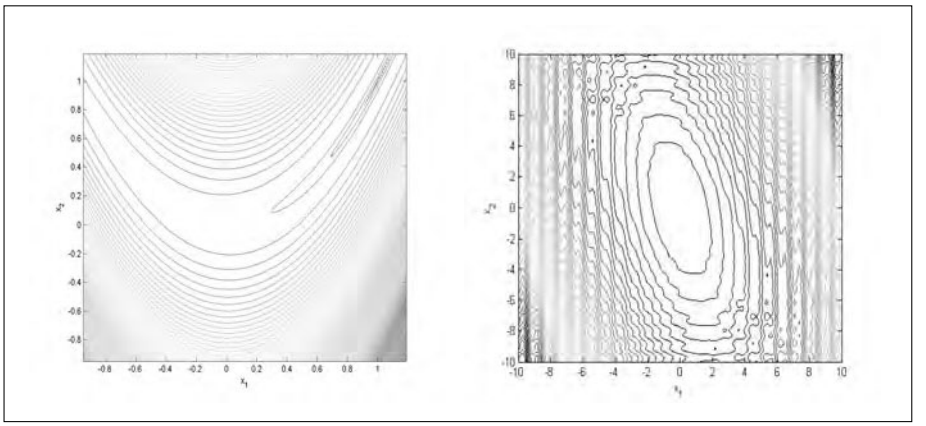


图 1.1. *Level curves of the Rosenbrock function (left) and a perturbed quadratic (right).*

我们选择了四种方法来运行这两个问题，作为本书所讨论的四大类方法的代表（参见第7至10章）。第一种方法是坐标搜索，可能是所有方向型直接搜索方法中最简单的一种（参见第7章）。在其最简单的形式中，它会在当前迭代点周围评估函数，这些点通过沿坐标方向及其负方向的位移定义，总共为$2n$个点。

和一个步长参数（这一过程称为*polling*）。这组方向构成了一个*posi- tive basis*。该方法虽然速度较慢，但稳健且能有效处理目标函数中的噪声。所使用的实现方式报告于文献[70]中。第二种选择是Nelder-Mead方法[177]，这是一种单纯形直接搜索方法（见第8章）。基于单纯形的反射、扩张和收缩（内部或外部）等操作，Nelder-Mead方法尝试替换具有最差函数值的单纯形顶点。Nelder-Mead生成的单纯形可能很好地适应函数的曲率。然而，原始的、未加保护的Nelder-Mead版本（如我们在测试中使用的MATLAB® [1]例程所编码）并不稳健或可靠，因为单纯形的形状可能会任意恶化。相反，坐标搜索则保证全局收敛。

另外两种方法采用了不同的途径。其中之一是隐式过滤算法（见第9章）。这是一种沿拟牛顿方向施加*sufficientdecrease*的线搜索算法。与基于导数的方法的主要区别在于，真实梯度被单纯形梯度所替代。因此，在某种程度上，隐式过滤方法类似于基于目标函数梯度的有限差分近似的拟牛顿方法。然而，该方法及其实现[141]特别适合处理噪声函数。最后一种方法是基于信赖域的算法，其中二次模型由多项式插值或回归构建。我们使用了Scheinberg的DFO代码中的实现（见第11章和附录）。这两种方法都能很好地适应函数的曲率，隐式过滤方法虽然效率低于信赖域方法，但更能过滤噪声（可能是由于使用了单纯形梯度，它对应于线性插值或回归模型的梯度，以及不精确的线搜索）。

结果在图1.2中针对图1.1的两个函数进行了报告，并遵循了这些方法类别的已知趋势。图1.2中的图表类型在无导数优化中广泛使用。横轴标记了随着优化过程演进的函数评估次数。纵轴对应函数值，通常呈下降趋势。我们将所有四种方法的停止容差设为10^{-3} (，这与用于控制步长的不同参数有关)。

在Rosenbrock函数上，信赖域方法表现最佳，因为它能够将曲率信息融入模型中（从迭代过程的开始到结束）。我们为所有方法选择了初始点(1.2, 0)。正如预期，坐标搜索在初期相当快速，但在收敛时较为缓慢。尝试使其更快（如改进轮询过程）在这个以曲率为主要因素的问题中并不十分成功（其他更复杂的、属于轮询类型的定向直接搜索方法也同样如此）。如果我们从$(1, -1)$（曲率更有利）开始坐标搜索，坐标搜索会表现得更好。但如果我们从$(-1, 1)$开始，则表现会差得多。其他两种方法表现相对良好。实际上，像Nelder-Mead这样的*direct-search*方法表现如此之好，并且似乎能够利用此问题中的曲率，这一点非常引人注目。

扰动二次函数的结果不那么清晰，这在无导数优化中经常发生。Nelder-Mead方法对于所选的初始点(0.1, 0.1)失败了，尽管如果我们不从如此接近解的地方开始，它会做得更好（但并非总是如此...）。该方法进行了许多内部收缩，这是其缺乏收敛性的原因（更多细节见第8章）。隐式过滤方法做

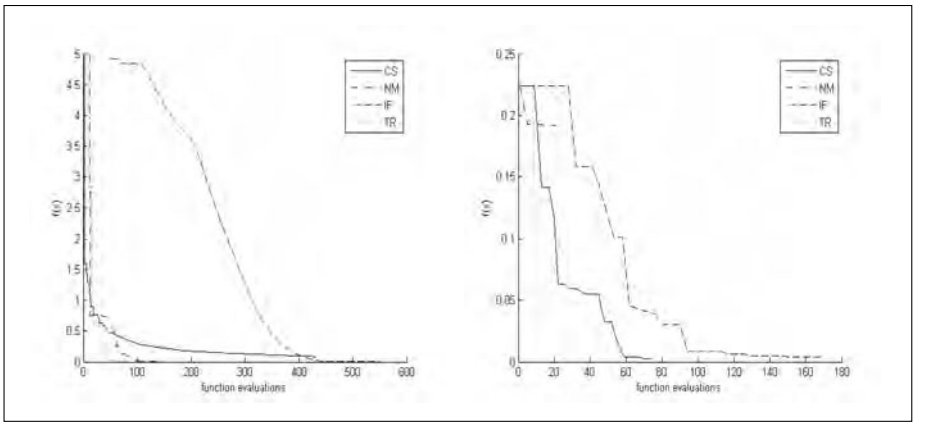


图 1.2. *Results of coordinate-search, Nelder–Mead, implicit-filtering, and trust-region interpolation-based methods for the Rosenbrock function (left) and a perturbed quadratic (right).*

在这个问题上，很好地过滤了噪声并向解决方案推进（而且其性能不受起始点的影响）。基于插值的信赖域方法在开始时非常高效，但很快就会停滞——在这种情况下，降低容差也无济于事。坐标搜索表现相对较好（记住曲率是温和的），似乎不受噪声影响。

总之，我们可以说基于模型的方法（如带信赖域的插值）更为高效。当函数光滑且曲率不利时，直接搜索法相形见绌，但它为含有噪声或非光滑问题提供了可行的替代方案，并能与基于模型的技术成功结合。易于并行化也是其最强优势之一。当然，还有空间容纳其他方法，比如改良的、带防护措施的Nelder-Mead方法，以及特别针对噪声问题设计且易于并行化的方法，如隐式过滤法。

1.5 本书简介

因此，或许已经使你信服，确实需要优秀的无导数方法，我们也希望这能为该领域的研究提供一些智力上的鼓励，或者至少能促使你继续阅读本书。这些基本思想相当简单，却能带来新的有趣结果。因此，除了实用之外，它还很有趣。

在本章引言之后，我们开始本书致力于 {v*} 的第一部分。因此，第2章向读者介绍正生成集与基、线性插值与回归模型、单纯形梯度以及几何的重要性。它还包括线性情形下的误差界。第3、4和5章则分别考虑确定形式、回归形式和欠定形式的非线性多项式插值模型。它们适当考虑了良定姿态性、拉格朗日多项式、相应矩阵的条件数以及泰勒-

类型误差界。第6章致力于确保证良态性成立的建设性方法，并为基于模型的算法（如信赖域算法）准备无导数模型的相关材料。

本书关于 *Frameworks and Algorithms* 的第二部分从第 7 章开始，该章讨论直接搜索方法，其中采样由期望的方向集指导。内容包括整数格上的全局收敛性和充分下降。下一章涵盖基于单纯形及单纯形上操作的直接搜索方法，其中的经典例子是前面提到的 Nelder–Mead 方法，我们为其纳入了一个全局收敛的变体。第 9 章致力于基于单纯形导数的线搜索方法，建立与隐式过滤方法的联系。第 10 章介绍基于信赖域的方法，包括与基于导数方法的关系、向完全线性与完全二次模型的抽象，以及全面的全局收敛分析。无导数信赖域方法更实际的方面，特别是对现有方法修改版本的示例，在第 11 章中结合第 6 章的材料进行讨论。

最后，第12章和第13章（本书的第三部分）涉及一些未详尽覆盖的相关主题。在第12章中，我们回顾了采用不同于多项式插值或回归技术构建的代理模型，并描述了处理代理模型的严格优化框架。第13章介绍了约束无导数优化的综述，其中我们还讨论了对其他类别问题的扩展，特别是全局优化。本书以一个附录结束，回顾了现有的无导数优化软件。

读者还可参考多篇关于无导数优化的综述论文，即较近期的Conn、Scheinberg和Toint [60]、Kelley [141]、Kolda、Lewis和Torczon [145]、Lewis、Torczon和Trosset [156]、Nocedal和Wright [178，第9章]、Powell [187]以及Wright [231]，还有较早的Brent [47]、Fletcher [94]和Shawn [207]。

符号

在本书中，我们尝试使用直观的标记法以简化阅读。这不可避免地意味着某些滥用，但我们希望读者仍能清楚理解其意。例如，向量可根据上下文被视为行向量或列向量，而无需总是改变标记或使用转置。

大写字母通常表示集合或矩阵。有几个常数用 κ 加上下标缩写来表示；例如，κ_{bhm} 表示模型 Hessian 的常数上界。每个缩写下标旨在帮助读者记住该常数的含义。

使用大$\mathcal{O}$符号是以直观的方式进行的，其含义应从文本中明确。书中所有球体均视为闭合。除非另有说明，所有范数均为ℓ_2-范数。

第一部分

采样与建模

第2章

抽样与线性模型

2.1 正张成集与正基

正生成集和正基用于方向直接搜索方法。正如我们稍后将看到的，研究正生成集 $D \subset \mathbb{R}^n$ 的主要动机是保证：给定 $\mathbb{R}^n$ 中的任意非零向量 v，至少存在 D 中的一个向量 d，使得 v 和 d 形成锐角。这在优化中的含义显而易见。假设非零向量 v 是连续可微函数 f 在给定点 x 处的负梯度 $-\nabla f(x)$。任何与 $-\nabla f(x)$ 形成锐角的向量 d 都是下降方向。[1] 为了减小 $f(x)$，可能需要对所有 $d \in D$) 评估点 $x + \alpha d$ (，其中 $\alpha > 0$，并对更小的正参数值 α 重复此评估。但是，由于梯度 $\nabla f(x)$ 非零，存在一个正参数值 α 和 D 中的一个向量 d，使得 $f(x + \alpha d) < f(x)$，这表明此类方案应在参数 α 经过有限次缩减后终止。

在本节中，我们将回顾正生成集和正基的一些基本性质，并展示如何构造简单的正基。关于正生成集的大部分基本性质摘自Davis [74]发展的正线性相关理论（另见Lewis和Torczon的论文[153]）。

定义与性质

向量集 $[v_1 \cdots v_r]$ 在 $\mathbb{R}^n$ 中的 *positive span*[2] 是凸锥

$$\left\{v \in \mathbb{R}^n : \; v = \alpha_1 v_1 + \cdots + \alpha_r v_r, \quad \alpha_i \geq 0, \, i = 1, \ldots, r\right\}.$$

(在本书中，很多时候我们将一组向量视为一个矩阵，其列即为该组中的向量。)

[1] By a descent direction for f at x we mean a direction d for which there exists an $\bar{\alpha} > 0$ such that $f(x + \alpha d) < f(x)$ for all $\alpha \in (0, \bar{\alpha}]$.

[2] Strictly speaking we should have written *nonnegative* instead of positive, but we decided to follow the notation in [74, 153]. We also note that by *span* we mean *linear span*.

定义 2.1。 *A positive spanning set in $\mathbb{R}^n$ is a set of vectors whose positive span is $\mathbb{R}^n$. The set $[v_1 \cdots v_r]$ is said to be positively dependent if one of the vectors is in the convex cone positively spanned by the remaining vectors, i.e., if one of the vectors is a positive combination of the others; otherwise, the set is positively independent.*

A positive basis in $\mathbb{R}^n$ is a positively independent set whose positive span is $\mathbb{R}^n$.

等价地，$\mathbb{R}^n$ 的一个正基可以定义为 $\mathbb{R}^n$ 中一组非零向量的集合，其正向组合张成 $\mathbb{R}^n$，但没有任何真子集具有相同的性质。

以下定理出自[74]，表明正生成集在$\mathbb{R}^n$中至少包含$n+$个1向量。

定理 2.2。 *If $[v_1 \cdots v_r]$ spans $\mathbb{R}^n$ positively, then it contains a subset with $r-1$ elements that spans $\mathbb{R}^n$.*

Proof. 集合 $[v_1 \cdots v_r]$ 必然线性相关（否则，就有可能构造出一个基 $\mathbb{R}^n$，它会正向张成 $\mathbb{R}^n$）。因此，存在不全为零的标量$\bar{a}_1$、…、$\bar{a}_r$ ()，使得$\bar{a}_1 v_1 + \cdots + \bar{a}_r v_r = 0$。于是，存在一个 $i \in \{1、\ldots、r\}$，使得$\bar{a}_i \neq 0$。

现在令 v 为 $\mathbb{R}^n$ 中的任意向量。由于 $[v_1 \cdots v_r]$ 正张成 $\mathbb{R}^n$，存在非负标量 a_1、…、a_r，使得 $v = a_1 v_1 + \cdots + a_r v_r$。

结果，我们得到

$$v = \sum_{j=1}^{r} a_j v_j = \sum_{\substack{j=1 \\ j \neq i}}^{r} \left(a_j - \frac{\bar{a}_j}{\bar{a}_i} a_i \right) v_j .$$

由于 v 是任意的，我们已经证明了 $\{v_1、\ldots、v_r\} \backslash \{v_i\}$ 张成 $\mathbb{R}^n$。 □

还可以证明，正基不能包含超过2n个元素（见[74]）。含有$n+1$和2n个元素的正基分别被称为*minimal*和*maximal*正基。

由标准基向量及其相反向量构成的正基是人们能想到的最简单的最大正基。在$\mathbb{R}^2$中，这个正基由矩阵的列定义。

$$D_1 = \begin{bmatrix} 1 & 0 & -1 & 0 \\ 0 & 1 & 0 & -1 \end{bmatrix}.$$

在本书的后续部分，我们将用$D_{\oplus}$来表示这个基础。

一个简单的极小基在$\mathbb{R}^2$中由规范基的向量及其和的负向量构成：

$$\begin{bmatrix} 1 & 0 & -1 \\ 0 & 1 & -1 \end{bmatrix}.$$

为方便起见，我们对第三个向量进行归一化，并写出

$$D_2 = \begin{bmatrix} 1 & 0 & -\sqrt{2}/2 \\ 0 & 1 & -\sqrt{2}/2 \end{bmatrix}.$$

如果我们向这个正基中再添加一个向量，我们会得到一个非正基的正生成集：

$$D_3 = \begin{bmatrix} 1 & 0 & -\sqrt{2}/2 & 0 \\ 0 & 1 & -\sqrt{2}/2 & -1 \end{bmatrix}.$$

在图2.1中，我们绘制了正基 D_1 和 D_2 以及正生成集 D_3。

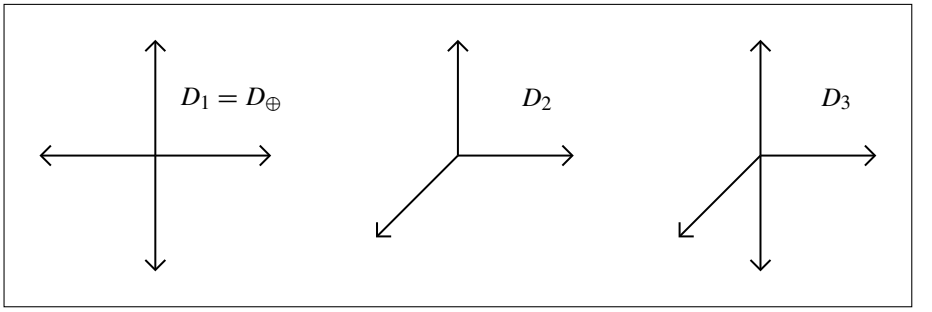


图2.1。*A maximal positive basis (left), a minimal positive basis (center), and a positive spanning set that is not a positive basis (right).*

我们现在给出三个充分必要条件，用于判断一个张成 $\mathbb{R}^n$ 的集合是否也正张成 $\mathbb{R}^n$（另见[74]）。

定理 2.3. *Let* $[v_1 \cdots v_r]$*, with* $v_i \neq 0$ *for all* $i \in \{1, \ldots, r\}$*, span* $\mathbb{R}^n$*. Then the following are equivalent:*

(i) $[v_1 \cdots v_r]$ *spans* $\mathbb{R}^n$ *positively.*

(ii) *For every* $i = 1, \ldots, r$*, the vector* $-v_i$ *is in the convex cone positively spanned by the remaining* $r - 1$ *vectors.*

(iii) *There exist real scalars* $\alpha_1, \ldots, \alpha_r$ *with* $\alpha_i > 0$, $i \in \{1, \ldots, r\}$*, such that* $\sum_{i=1}^{r} \alpha_i v_i = 0$.

(iv) *For every nonzero vector* $w \in \mathbb{R}^n$*, there exists an index* i *in* $\{1, \ldots, r\}$ *for which* $w^\top v_i > 0$.

Proof. 证明通过展示以下蕴含关系完成：(i) ⇒ (ii)，(ii) ⇒ (iii)，(iii) ⇒ (i)，(i) ⇒ (iv)，以及(iv) ⇒ (i)。

(i) ⇒ (ii) 由于 $[v_1 \cdots v_r]$ 正张成 $\mathbb{R}^n$，向量 $-v_i$ 与 {1 中的 i，…，r}，可以写成

$$-v_i = \sum_{j=1}^{r} \lambda_{ij} v_j,$$

whe标量 λ_{i1}、…、λ_{ir} 是非负的。因此，w 我们得到

$$-v_i - \lambda_{ii} v_i \;=\; \sum_{\substack{j=1\\ j\neq i}}^{r} \lambda_{ij} v_j$$

和

$$-v_i \;=\; \sum_{\substack{j=1\\ j\neq i}}^{r} \frac{\lambda_{ij}}{1+\lambda_{ii}} v_j \;=\; \sum_{\substack{j=1\\ j\neq i}}^{r} \tilde{\lambda}_{ij} v_j,$$

其中 $\tilde{\lambda}_{ij} = \frac{\lambda_{ij}}{1+\lambda_{ii}} \geq 0$ 对所有 $j \in \{1、\ldots、r\}\backslash\{i\}$ 成立。这表明 $-v_i$ 位于由其余 $r-1$ 个向量正生成的凸锥中。

(ii) $\Rightarrow$ (iii) 根据假设(ii)，存在非负标量 $\bar{\lambda}_{ij}$、i、$j = 1$、…、r，使得

$$\begin{aligned} v_1 \;+\; \bar{\lambda}_{12} v_2 \;+\cdots+\; \bar{\lambda}_{1r} v_r \;&=\; 0,\\ \bar{\lambda}_{21} v_1 \;+\; v_2 \;+\cdots+\; \bar{\lambda}_{2r} v_r \;&=\; 0,\\ &\vdots\\ \bar{\lambda}_{r1} v_1 \;+\; \bar{\lambda}_{r2} v_2 \;+\cdots+\; v_r \;&=\; 0. \end{aligned}$$

通过添加这些 r 等式，我们得到

$$\left(1+\sum_{i=2}^{r} \bar{\lambda}_{i1}\right) v_1 + \cdots + \left(1+\sum_{i=1}^{r-1} \bar{\lambda}_{ir}\right) v_r \;=\; 0,$$

可以改写为

$$\alpha_1 v_1 + \cdots + \alpha_r v_r \;=\; 0,$$

with $\alpha_j = 1 + \sum_{\substack{i=1\\ i\neq j}}^{r} \bar{\lambda}_{ij} > 0$, $j \in \{1,\ldots,r\}$.

(iii) $\Rightarrow$ (i) 设 α_1、…、α_r 为正标量，使得 $\alpha_1 v_1 + \cdots + \alpha_r v_r = 0$，并设 v 为 $\mathbb{R}^n$ 中的任意向量。由于 $[v_1 \cdots v_r]$ 张成 $\mathbb{R}^n$，存在标量 λ_1、…、λ_r 使得 $v = \lambda_1 v_1 + \cdots + \lambda_r v_r$。通过在该等式的右侧加上 $\alpha_1 v_1 + \cdots + \alpha_r v_r$ 的足够大的倍数，可以证明 v 可表示为 v_1、…、v_r 的正线性组合。因此，$[v_1 \cdots v_r]$ 正向张成 $\mathbb{R}^n$。

(i) $\Rightarrow$ (iv) 设 w 为 $\mathbb{R}^n$ 中的非零向量。由假设 (i)，存在非负标量 λ_1、…、λ_r 使得

$$w \;=\; \lambda_1 v_1 + \cdots + \lambda_r v_r.$$

由于 $w \neq 0$，我们得到

$$\begin{aligned} 0 \;<\; w^\top w &= (\lambda_1 v_1 + \cdots + \lambda_r v_r)^\top w\\ &= \lambda_1 v_1^\top w + \cdots + \lambda_r v_r^\top w, \end{aligned}$$

由此我们得出结论，至少有一个标量$w^\top v_1$、…、$w^\top v_r$必须是正数。

(iv) $\Rightarrow$ (i) 如果由 v_1、…、v_r 正张成的凸锥不是 $\mathbb{R}^n$，则存在一个超平面 $H = \{v \in \mathbb{R}^n\colon\ v^\top h = 0\}$，其中 $h \neq 0$，使得该凸锥（因此其所有生成元）包含在 $\{v \in \mathbb{R}^n\colon\ v^\top h \geq 0\}$ 或 $\{v \in \mathbb{R}^n\colon\ v^\top h \leq 0\}$ 中；参见 [200, 推论 11.7.3]。然后该假设将与 $w = h$ 或 $w = -h$ 中的任一个相矛盾。□

如前所述，定理2.3的性质(iv)是方向直接搜索方法的核心。它意味着，给定一个连续可微函数 f 在某个给定点 x 处，其中 $\nabla f(x) \neq 0$，必定总是存在一个向量 d 在一个给定的正生成集（或正基）中，使得

$$-\nabla f(x)^\top d \ > \ 0.$$

换句话说，在这样的集合中必须始终存在一个下降方向。在图2.2中，我们为之前给出的三个生成集D_1、D_2和D_3确定了这样一个向量d。

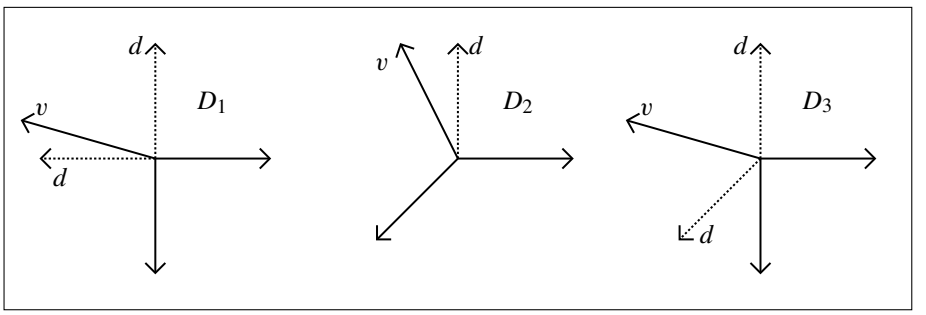


图2.2。*Given a positive spanning set and a vector $v = -\nabla f(x)$ (dashed), there exists at least one element d (dotted) of the set such that $v^\top d > 0$.*

简单的正基

现在我们将注意力转向正基的构造。以下结果（见[153]）提供了一种生成不同正基的简单机制。

定理2.4。 *Suppose $[v_1 \cdots v_r]$ is a positive basis for $\mathbb{R}^n$ and $W \in \mathbb{R}^{n\times n}$ is a nonsingular matrix. Then $[Wv_1 \cdots Wv_r]$ is also a positive basis for $\mathbb{R}^n$.*

Proof. 显然，$[v_1 \cdots v_r]$ 张成 $\mathbb{R}^n$，因为它是正向张成的。由于 W 非奇异，$[Wv_1 \cdots Wv_r]$ 也张成 $\mathbb{R}^n$。因此，我们可以对 $[v_1 \cdots v_r]$ 和 $[Wv_1 \cdots Wn_r]$ 应用定理2.3。

现在令 w 为 $\mathbb{R}^n$ 中的一个非零向量。由于 $[v_1 \cdots v_r]$ 正生成 $\mathbb{R}^n$ 且 W 非奇异，由定理2.3中的(iv)可得

$$(W^\top w)^\top v_i \ > \ 0$$

对于 {1 中的某个 i, …,r}。换句话说,

$$w^\top (W v_i) > 0$$

对于 {1、…、r} 中的某个 i，由此我们得出 $[Wv_1 \cdots Wv_r]$ 也正张成 $\mathbb{R}^n$。

根据正依赖的定义，如果 $[Wv_1 \cdots Wv_r]$ 是正依赖的，那么 $[v_1 \cdots v_r]$ 也必然是正依赖的，这就完成了定理的证明。

□

可以很容易地证明 $D_\oplus = [I \ -I]$ 是一个（极大）正基。定理2.4中刚刚陈述的结果使我们能够说，对于任何非奇异矩阵 $W \in \mathbb{R}^{n\times n}$ 的选择，$[W \ -W]$ 也是一个（极大）正基。

从定理2.3和2.4，我们可以轻松推导出以下推论。证明留作练习。

推论2.5。

(i) $[I \ -e]$ *is a (minimal) positive basis.*

(ii) *Let* $W = [w_1 \cdots w_n] \in \mathbb{R}^{n\times n}$ *be a nonsingular matrix. Then* $[W \ -\sum_{i=1}^n w_i]$ *is a (minimal) positive basis for* $\mathbb{R}^n$.

正基具有均匀角度

考虑 $n+1$ 个向量 v_1, …, v_{n+1} 在 $\mathbb{R}^n$ 中，其中所有成对 v_i, $v_j\,(i \neq j)$ 之间的角度都具有相同的幅度 α。假设 $n+1$ 个向量是归一化的，这个要求表示为

$$a = \cos(\alpha) = v_i^\top v_j, \qquad i, j \in \{1, \ldots, n+1\},\ i \neq j, \tag{2.1}$$

其中 $a \neq 1$. 可以证明 $a = -1/n$ (见习题)。

现在我们寻找一组$n+1$个归一化向量$[v_1 \cdots v_{n+1}]$，满足具有$a = -1/n$的性质(2.1)。让我们首先计算v_1、…、v_n；即，让我们计算一个矩阵$V = [v_1 \cdots v_n]$，使得

$$V^\top V = A,$$

其中 {v*} 是矩阵，由下式给出

$$A = \begin{bmatrix} 1 & -1/n & -1/n & \cdots & -1/n \\ -1/n & 1 & -1/n & \cdots & -1/n \\ \vdots & & \ddots & & \\ \vdots & & & \ddots & \\ -1/n & -1/n & -1/n & \cdots & 1 \end{bmatrix}. \tag{2.2}$$

矩阵 A 是对称且对角占优的，主对角线元素均为正，因此它是正定的 [109]。于是，我们可以利用其 Cholesky 分解

$$A = CC^\top,$$

其中 $C \in \mathbb{R}^{n\times n}$ 是一个阶数为 n 且具有正对角元素的下三角矩阵。给定这种分解，可以容易地看出，V 的一个选择由下式决定

$$V = [v_1 \cdots v_n] = C^\top.$$

然后通过以下方式计算向量 v_{n+1}：

$$v_{n+1} = -\sum_{i=1}^{n} v_i. \tag{2.3}$$

开 可以很容易地展示 $v_i^\top v_{n+1} = -1/n$、$i = 1$、…、n 和 $v_{n+1}^\top v_{n+1} = 1$.

由于 V 是非奇异的，且 v_{n+1} 由 (2.3) 确定，我们可以应用推论 2.5(ii) 来证明 $[v_1 \cdots v_{n+1}]$ 是一个（极小）正基。该正基中任意两个向量之间的夹角具有相同的幅度。我们将这一结果总结如下。

推论 2.6。 *Let $V = C^\top = [v_1 \cdots v_n] \in \mathbb{R}^{n\times n}$, where $A = CC^\top$ and A is given by* (2.2). *Let $v_{n+1} = -\sum_{i=1}^{n} v_i$.*

Then $[v1 \cdots v_{n+1}]$ is a (minimal) positive basis for $\mathbb{R}^n$ satisfying $v_i^\top v_j = -1/n$, i, $j \in \{1, \ldots, n+1\}$, $i \neq j$, and $\|v_i\| = 1$, $i = 1, \ldots, n+1$.

一个具有均匀角度的最小正基如图2.3所示，按照推论2.6计算得出。

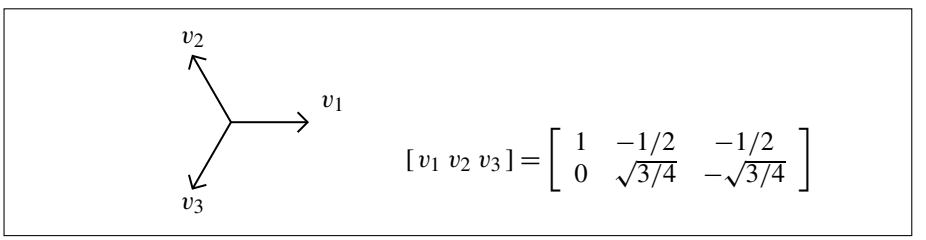


图2.3。*A minimal positive basis with uniform angles.*

2.2 直接搜索中使用的梯度估计

我们现在展示的是，如果我们在由正基 D 定义的 $x + \alpha d$ 形式的 $n+1$ 个点上进行采样，并且它们的函数值不优于 x 处的函数值，那么函数在 x 处的梯度大小（视为Lipschitz连续）与 x 和样本点 $x + \alpha d$ 之间的距离同阶，此外，阶常数仅取决于 f 的非线性性和样本集的几何形状。

为了证明这一结果，它用于方向直接搜索方法的收敛性理论中，我们必须首先引入正生成集的余弦测度概念。

定义 2.7。 *The cosine measure of a positive spanning set (with nonzero vectors) or of a positive basis D is defined by*

$$\mathrm{cm}(D) = \min_{0 \neq v \in \mathbb{R}^n} \max_{d \in D} \frac{v^\top d}{\|v\| \|d\|}.$$

给定任何正生成集，必然有

$$\mathrm{cm}(D) > 0.$$

余弦度量值接近于零表明正生成性质恶化。例如，最大正基$D_\oplus = [I \; -I]$的余弦度量等于$1/\sqrt{n}$。当$n = 2$时，我们有$\mathrm{cm}(D_\oplus) = \sqrt{2}/2$。

现在让我们考虑以下例子。设θ为$(0, \pi/4]$中的一个角，且D_θ为由下式定义的正基

$$D_\theta = \begin{bmatrix} 1 & 0 & -\cos(\theta) \\ 0 & 1 & -\sin(\theta) \end{bmatrix}.$$

注意，$D_{\frac{\pi}{4}}$正是之前考虑的正基D_2。D_θ的余弦度量由$\cos((\pi - \theta)/2)$给出，并且当θ趋近于零时，它收敛于零。图2.4描绘了这一情况。

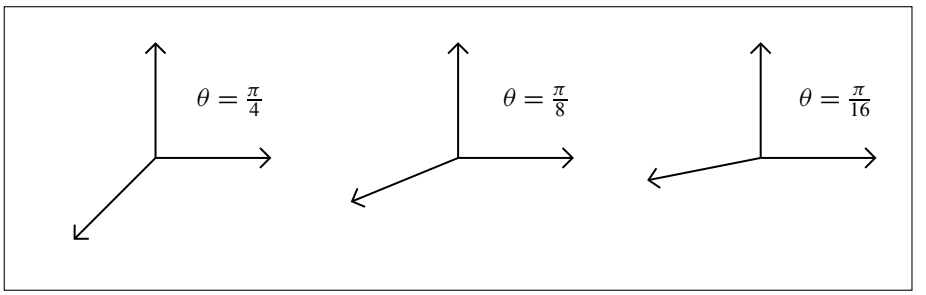


图 2.4. *Positive bases D_θ for three values of θ. The cosine measure is approaching zero.*

另一个关键点，与正生成集的下降性质相关，是对于任意向量$v \neq 0$，我们有

$$\mathrm{cm}(D) \leq \max_{d \in D} \frac{v^\top d}{\|v\| \|d\|}.$$

因此，必须存在一个$d \in D$，使得

$$\mathrm{cm}(D) \leq \frac{v^\top d}{\|v\| \|d\|}$$

或者，等价地，{v*}

$$\mathrm{cm}(D)\|v\|\|d\| \;\le\; v^\top d.$$

给定一个正生成集 D、一个点 x 以及参数 α 的一个正值，我们感兴趣的是考察所有 $d \in D$ 对应的形如 $x+\alpha d$ 的点。这些点位于以 x 为球心、半径为 Δ 的球内，该球由下式定义

$$\Delta \;=\; \alpha \max_{d\in D} \|d\|.$$

我们指出，如果在算法中仅使用有限个正生成集，那么Δ趋于零当且仅当α趋于零。以下结果摘自[80, 145]。

定理 2.8. *Let D be a positive spanning set and $\alpha > 0$ be given. Assume that ∇f is Lipschitz continuous (with constant $\nu > 0$) in an open set containing the ball $B(x;\Delta)$. If $f(x) \le f(x+\alpha d)$, for all $d \in D$, then*

$$\|\nabla f(x)\| \;\le\; \frac{\nu}{2}\,\mathrm{cm}(D)^{-1} \max_{d\in D} \|d\|\,\alpha.$$

Proof. 让 d 为 D 中的一个向量，使得

$$\mathrm{cm}(D)\|\nabla f(x)\|\|d\| \;\le\; -\nabla f(x)^\top d.$$

现在，根据积分形式的均值定理以及事实 $f(x) \le f(x+\alpha d)$，对于所有 $d \in D$，我们得到

$$0 \;\le\; f(x+\alpha d) - f(x) \;=\; \int_0^1 \nabla f(x+t\alpha d)^\top (\alpha d)\,dt.$$

将第一个不等式乘以 α 并与第二个不等式相加，我们得到

$$\mathrm{cm}(D)\|\nabla f(x)\|\|d\|\alpha \;\le\; \int_0^1 \left(\nabla f(x+t\alpha d) - \nabla f(x)\right)^\top (\alpha d)\,dt \;\le\; \frac{\nu}{2}\|d\|^2\alpha^2,$$

并且证明完成。 □

如果一个方向直接搜索方法能够生成满足定理2.8条件的点序列x，且对于该序列有α (，从而Δ)趋于零，那么显然目标函数的梯度沿此序列收敛于零。

定理2.8中证明的界限可以重写为形式

$$\|\nabla f(x)\| \;\le\; \kappa_{eg}\,\Delta,$$

其中 $\kappa_{eg} = \nu\,\mathrm{cm}(D)^{-1}/2$。我们指出，该界与其他无导数方法中使用的界具有相同的结构。该界基本上由 Δ 乘以一个常数给出，该常数取决于函数的非线性程度（用 Lipschitz 常数 ν 表示）以及样本集的几何特性（用 $\mathrm{cm}(D)^{-1}$ 度量）。

2.3 线性插值与回归模型

现在我们将注意力转向不一定由预定义方向集形成的样本集。考虑 $\mathbb{R}^n$ 中的样本集 $Y = \{y^0、y^1、\ldots、y^p\}$。基于 $n+1$ 个样本点（$p=n$）我们能想到的最简单模型是插值模型。

线性插值

令 $m(x)$ 表示一个在 Y 中的点上插值 f 的次数为 $d=1$ 的多项式，即满足插值条件

$$m(y^i) = f(y^i), \quad i = 0,\ldots,n. \tag{2.4}$$

我们可以将 $m(x)$ 表示为

$$m(x) = \alpha_0 + \alpha_1 x_1 + \cdots + \alpha_n x_n,$$

以空间$\mathcal{P}_n^1$（由次数为1的线性多项式构成）为例，我们采用多项式基$\bar{\phi} = \{1、x_1、\ldots、x_n\}$作为基础。然而，我们指出也可以使用其他基，例如$\{1、1+x_1、1+x_1+x_2、\ldots、1+x_1+x_2+\cdots+x_n\}$。因此，我们可以将(2.4)重写为

$$\begin{bmatrix} 1 & y_1^0 & \cdots & y_n^0 \\ 1 & y_1^1 & \cdots & y_n^1 \\ \vdots & \vdots & \vdots & \vdots \\ 1 & y_1^n & \cdots & y_n^n \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \vdots \\ \alpha_n \end{bmatrix} = \begin{bmatrix} f(y^0) \\ f(y^1) \\ \vdots \\ f(y^n) \end{bmatrix}.$$

该线性系统的矩阵记为

$$M = M(\bar{\phi}, Y) = \begin{bmatrix} 1 & y_1^0 & \cdots & y_n^0 \\ 1 & y_1^1 & \cdots & y_n^1 \\ \vdots & \vdots & \vdots & \vdots \\ 1 & y_1^n & \cdots & y_n^n \end{bmatrix}. \tag{2.5}$$

在本书中，我们将M写作$M(\bar{\phi},\ Y)$，以突出M对基$\bar{\phi}$和样本集Y的依赖关系。

定义 2.9. *The set $Y = \{y^0, y^1, \ldots, y^n\}$ is poised for linear interpolation in $\mathbb{R}^n$ if the corresponding matrix $M(\bar{\phi}, Y)$ is nonsingular.*

poisedness 的定义与所选择的基无关。换句话说，如果 Y 对基 ϕ 是 poised 的，那么它对 $\mathcal{P}_n^1$ 中的任何其他基也是 poised 的。$m(x)$ 的定义也与所选择的基无关。这些问题在第3章中详细讨论。容易看出，样本集 Y 对线性插值是 poised 的当且仅当线性插值多项式 $m(x) = \alpha_0 + \alpha_1 x_1 + \cdots + \alpha_n x_n$ 是唯一确定的。

线性回归

当样本集中点的数量$p+1$ 超过采样空间的维度n 超过1时，可能无法拟合线性多项式。在这种情况下，

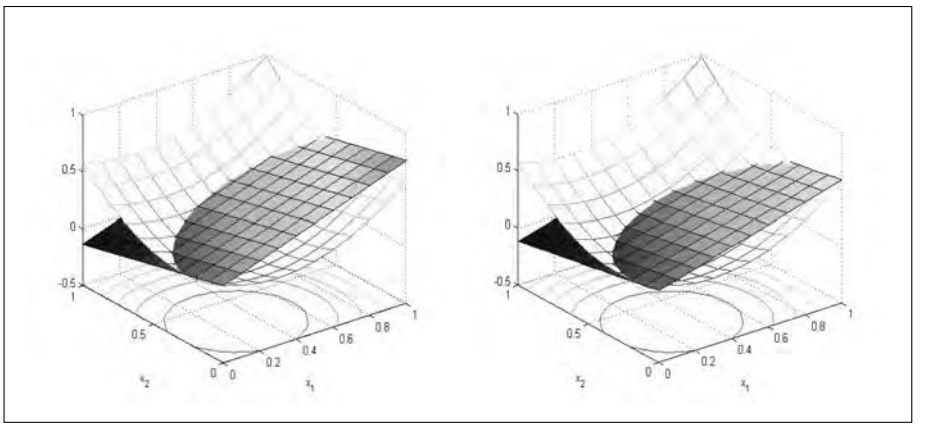


图2.5。*At the left, the linear interpolation model of* $f(x_1,\ x_2) = (x_1 - 0.3)^2 + (x_2 - 0.3)^2$ *at* $y^0 = (0,\ 0)$, $y^1 = (0.2,\ 0.6)$, *and* $y^2 = (0.8,\ 0.7)$. *At the right, the linear regression model of* $f(x_1,\ x_2) = (x_1 - 0.3)^2 + (x_2 - 0.3)^2$ *at* $y^0 = (0,\ 0)$, $y^1 = (0.2,\ 0.6)$, $y^2 = (0.8,\ 0.7)$, *and* $y^3 = (0.5,\ 0.5)$. *The inclusion of* y^3 *pushes the model down.*

一种选择是使用线性回归，并计算线性（最小二乘）回归多项式 $m(x) = \alpha_0 + \alpha_1 x_1 + \cdots + \alpha_n x_n$的系数作为该系统的最小二乘解。

$$\begin{bmatrix} 1 & y_1^0 & \cdots & y_n^0 \\ 1 & y_1^1 & \cdots & y_n^1 \\ \vdots & \vdots & \vdots & \vdots \\ \vdots & \vdots & \vdots & \vdots \\ 1 & y_1^p & \cdots & y_n^p \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \vdots \\ \alpha_n \end{bmatrix} = \begin{bmatrix} f(y^0) \\ f(y^1) \\ \vdots \\ \vdots \\ f(y^p) \end{bmatrix}. \tag{2.6}$$

再次，我们将这个（可能是超定的）线性方程组的矩阵表示为 $M = M(\bar{\phi}、\ Y)$。

平衡性的定义很容易从线性插值推广到线性回归。

定义2.10. *The set* $Y = \{y^0、\ y^1、\ \ldots、\ y^p\}$, *with* $p > n$, *is poised for linear regression in* $\mathbb{R}^n$ *if the corresponding matrix* $M(\bar{\phi}、\ Y)$ *has full (column) rank.*

在回归情形下，还可以证明，如果一个集合 Y 对于一组基 ϕ 是 poised 的，那么它对于 $\mathcal{P}_n^1$ 中的任何其他基也是 poised 的，并且 $m(x)$ 与所选择的基无关。最后，我们指出，样本集对于线性回归是 poised 的，当且仅当线性回归多项式 $m(x)$ 被唯一确定。这些问题在第 4 章中有详细讨论。

2.4 线性插值与回归的误差界

线性插值的误差界

让我们将线性插值多项式重写为以下形式

$$m(y) = c + g^\top y$$

通过设置 $\alpha_0 = c$ 和 $\alpha_i = g_i,\ i = 1, \ldots, n$。

插值中自然会出现的问题之一是如何衡量$m(y)$作为$f(y)$近似值的质量。我们首先考察模型的梯度$g = \nabla m(y)$作为$\nabla f(y)$近似值的质量。我们认为插值点y^0、y^1、…、y^n位于以y^0为中心、半径为Δ的球内。在实践中，可以设定

$$\Delta = \Delta(Y) = \max_{1 \le i \le n} \|y^i - y^0\|.$$

我们关注以 y^0 为中心、半径为 Δ 的球内 $\nabla m(y)$ 和 $m(y)$ 的质量。该结果所需的假设总结如下。

假设 2.1。*We assume that $Y = \{y^0、y^1、\ldots、y^n\} \subset \mathbb{R}^n$ is a poised set of sample points (in the linear interpolation sense) contained in the ball $B(y^0; \Delta(Y))$ of radius $\Delta = \Delta(Y)$. Further, we assume that the function f is continuously differentiable in an open domain Ω containing $B(y^0; \Delta)$ and ∇f is Lipschitz continuous in Ω with constant $\nu > 0$.*

正如我们可以从下文定理2.11的证明中观察到，误差界的推导基于对矩阵 $M = M(\bar{\phi}、Y)$在(2.5)式中应用一步高斯消元法。执行此步骤后，我们得到矩阵

$$\begin{bmatrix} 1 & y_1^0 & \cdots & y_n^0 \\ 0 & y_1^1 - y_1^0 & \cdots & y_n^1 - y_n^0 \\ \vdots & \vdots & \vdots & \vdots \\ 0 & y_1^n - y_1^0 & \cdots & y_n^n - y_n^0 \end{bmatrix},$$

可以用块表示为

$$\begin{bmatrix} 1 & y_0^\top \\ 0 & L \end{bmatrix},$$

使用

$$L = \begin{bmatrix} y^1 - y^0 \cdots y^n - y^0 \end{bmatrix}^\top = \begin{bmatrix} (y^1 - y^0)^\top \\ \vdots \\ (y^n - y^0)^\top \end{bmatrix} = \begin{bmatrix} y_1^1 - y_1^0 & \cdots & y_n^1 - y_n^0 \\ \vdots & \vdots & \vdots \\ y_1^n - y_1^0 & \cdots & y_n^n - y_n^0 \end{bmatrix}.$$

显然，L 是非奇异的当且仅当 M 是非奇异的，因为 $\det(L) = \det(M)$。注意，这些点在 L 中按行列出，这有利于按行进行因式分解。

结果表明，我们推导出的近似误差界是以缩放矩阵的形式表示的。

$$\hat{L} = \frac{1}{\Delta}L = \frac{1}{\Delta}\left[y^1 - y^0 \cdots y^n - y^0\right]^\top = \begin{bmatrix} \frac{y_1^1 - y_1^0}{\Delta} & \cdots & \frac{y_n^1 - y_n^0}{\Delta} \\ \vdots & \vdots & \vdots \\ \frac{y_1^n - y_1^0}{\Delta} & \cdots & \frac{y_n^n - y_n^0}{\Delta} \end{bmatrix}.$$

该矩阵$\hat{L}$对应于一个缩放样本集

$$\hat{Y} = \{y^0/\Delta, y^1/\Delta, \ldots, y^n/\Delta\} \subset B(y^0/\Delta; 1),$$

它包含在一個以y^0/Δ為中心、半徑為1的球體內。

定理 2.11。*Let Assumption* 2.1 *hold. The gradient of the linear interpolation model satisfies, for all points* y *in* $B(y^0;\ \Delta)$*, an error bound of the form*

$$\|\nabla f(y) - \nabla m(y)\| \leq \kappa_{eg}\,\Delta, \tag{2.7}$$

where $\kappa_{eg} = \nu(1 + \frac{1}{2}\sqrt{n}\,\|\hat{L}^{-1}\|/2)$ *and* $\hat{L} = L/\Delta$.

Proof. 如果集合 Y 是稳定的，则 $(n+1)\times(n+1)$ 矩阵 $M = M(\bar{\phi}、Y)$ 是非奇异的，且 $n \times n$ 矩阵 L 也是如此。

我们首先观察点y^0处f的梯度。从剩余的n中减去第一个插值条件，我们得到

$$(y^i - y^0)^\top g = f(y^i) - f(y^0), \quad i = 1, \ldots, n.$$

然后，如果我们使用中值定理的积分形式

$$f(y^i) - f(y^0) = \int_0^1 (y^i - y^0)^\top \nabla f(y^0 + t(y^i - y^0))dt,$$

根据 ∇f 的利普希茨连续性，我们得到:

$$(y^i - y^0)^\top (\nabla f(y^0) - g) \leq \frac{\nu}{2}\|y^i - y^0\|^2, \quad i = 1, \ldots, n.$$

然后，从这最后的n个不等式中，我们推导出

$$\|L(\nabla f(y^0) - g)\| \leq (n^{\frac{1}{2}}\nu/2)\,\Delta^2,$$

由此我们得出结论

$$\|\nabla f(y^0) - g\| \leq (n^{\frac{1}{2}}\|\hat{L}^{-1}\|\nu/2)\,\Delta.$$

球 $B(y^0$ 内任意点 y 的误差界；$\Delta)$ 可轻易地从 f 的梯度的 Lipschitz 连续性推导出来:

$$\|\nabla f(y) - g\| \leq \|\nabla f(y) - \nabla f(y^0)\| + \|\nabla f(y^0) - g\| \leq (\nu + n^{\frac{1}{2}}\|\hat{L}^{-1}\|\nu/2)\,\Delta. \quad \square$$

假设 $\|\hat{L}^{-1}\|$ 独立于 Δ 具有一致界，则梯度误差与 Δ 成线性关系。还可以看出，插值模型 $m(x)$ 本身的误差与 Δ 成二次关系。

定理2.12。 *Let Assumption* 2.1 *hold. The interpolation model satisfies, for all points* y *in* $B(y^0;\ \Delta)$*, an error bound of the form*

$$|f(y)-m(y)| \ \leq\ \kappa_{ef}\,\Delta^2, \tag{2.8}$$

where $\kappa_{ef}=\kappa_{eg}+\nu/2$ *and* κ_{eg} *is given in Theorem* 2.11.

Proof. 我们使用与定理2.11证明中相同的论证来得到

$$f(y)-f(y^0)\ \leq\ \nabla f(y^0)^\top(y-y^0)+\frac{\nu}{2}\|y-y^0\|^2.$$

由此我们得到

$$f(y)-f(y^0)-g^\top(y-y^0)\ \leq\ (\nabla f(y^0)-g)^\top(y-y^0)+\frac{\nu}{2}\|y-y^0\|^2.$$

误差界 (2.8) 来自将该不等式与 (2.7) 结合，并注意到模型中的常数项可以写成 $c=f(y^0)-g^\top y^0$。 □

线性回归的误差界

在回归情况下，我们考虑一个样本集 $Y=\{y^0、\ y^1、\ \ldots、\ y^p\}$，其中球 $B(y^0$ 内包含超过 $n+$ 个点；$\Delta(Y))$ 的半径为

$$\Delta\ =\ \Delta(Y)\ =\ \max_{1\leq i\leq p}\|y^i-y^0\|.$$

我们首先将线性回归多项式重写为以下形式

$$m(y)\ =\ c+g^\top y,$$

其中 $c=\alpha_0$ 和 $g_i=\alpha_i$，$i=1,\ \ldots,\ n,$ 是系统（2.6）最小二乘解的分量。

假设 2.2. *We assume that* $Y=\{y^0,\ \ y^1,\ \ \ldots,\ \ y^p\}\subset\mathbb{R}^n$*, with* $p>n$*, is a poised set of sample points (in the linear regression sense) contained in the ball* $B(y^0;$ $\Delta(Y))$ *of radius* $\Delta=\Delta(Y)$*.*

Further, we assume that the function f *is continuously differentiable in an open domain* Ω *containing* $B(y0;\ \Delta)$ *and* ∇f *is Lipschitz continuous in* Ω *with constant* $\nu>0$*.*

近似误差界也以缩放矩阵的形式推导出来

$$\hat{L}\ =\ \frac{1}{\Delta}L\ =\ \frac{1}{\Delta}\left[y^1-y^0\cdots y^p-y^0\right]^\top,$$

其对应于包含在中心为y^0/Δ、半径为1的球内的缩放样本集，即，

$$\hat{Y} = \{y^0/\Delta, y^1/\Delta, \ldots, y^p/\Delta\} \subset B(y^0/\Delta; 1).$$

该界限的证明完全遵循与线性插值情形证明相同的步骤。例如，对于梯度近似，一旦在证明中达到如下步骤：

$$\|L(\nabla f(y^0) - g)\| \leq (p^{\frac{1}{2}}\nu/2)\,\Delta^2,$$

或者，等价地，{v*}

$$\|\hat{L}(\nabla f(y^0) - g)\| \leq (p^{\frac{1}{2}}\nu/2)\,\Delta, \tag{2.9}$$

我们通过其左逆$\hat{L}^\dagger$将$\hat{L}$“传递”到右侧。[3] 然后，我们可以按以下格式陈述边界。

定理 2.13。 *Let Assumption* 2.2 *hold. The gradient of the linear regression model satisfies, for all points* y *in* $B(y^0;\ \Delta)$*, an error bound of the form*

$$\|\nabla f(y) - \nabla m(y)\| \leq \kappa_{eg}\,\Delta,$$

where $\kappa_{eg} = \nu(1 + \frac{1}{2}\|\hat{L}^\dagger\|/2)$ *and* $\hat{L} = L/\Delta$.

The linear regression model satisfies, for all points y *in* $B(y^0;\ \Delta)$*, an error bound of the form*

$$|f(y) - m(y)| \leq \kappa_{ef}\,\Delta^2,$$

where $\kappa_{ef} = \kappa_{eg} + \nu/2$.

2.5 其他几何概念

线性插值的平衡概念与凸分析中的仿射独立概念密切相关。

仿射独立性

我们将遵循Rockafellar [200]来介绍仿射独立性以及从凸分析中借用的其他基本概念。

给定集合 $S \subset \mathbb{R}^n$ 的仿射包是包含 S (的最小仿射集，意味着它是所有包含 S) 的仿射集的交集。集合的仿射包总是唯一确定的，并且由 S 中元素的所有线性组合构成，其标量和为1（见[200]）。

定义 2.14. *A set of* $m+1$ *points* $Y = \{y^0,\ y^1,\ \ldots,\ y^m\}$ *is said to be affinely independent if its affine hull* $\mathrm{aff}(y^0,\ y^1,\ \ldots,\ y^m)$ *has dimension* m.

仿射集的维数是与其平行的线性子空间的维数。因此，在 $\mathbb{R}^n$ 中不能存在超过 $n+1$ 个点的仿射无关集。

[3] $A^\dagger$ denotes the Moore–Penrose generalized inverse of a matrix A, which can be expressed by the singular value decomposition of A for any real or complex matrix A. In the current context, where L has full column rank, we have $\hat{L}^\dagger = (\hat{L}^\top\hat{L})^{-1}\hat{L}^\top$.

给给定仿射无关点集 $\{y^0、y^1、\ldots、y^m\}$，我们有　　证明

$$\text{aff}(y^0, y^1, \ldots, y^m) = y^0 + \mathcal{L}(y^1 - y^0, \ldots, y^m - y^0),$$

其中 $\mathcal{L}(y^1 - y^0、\ldots、y^m - y^0)$ 是由向量 $y^1 - y^0、\ldots、y^m - y^0$ 生成的 m 维线性子空间。

我们将与仿射无关的点集 $\{y^0、y^1、\ldots、y^m\}$ 关联矩阵

$$\left[y^1 - y^0 \cdots y^m - y^0 \right] \in \mathbb{R}^{n \times m},$$

其秩必须等于 m。这个矩阵恰好是矩阵 L 的转置，该矩阵出现在我们在集合 $Y = \{y^0、y^1、\ldots、y^n\}$ 上对函数 f 进行线性插值时，其中 $m = n$，为 $\mathbb{R}^n$ 中次数为 1 的线性多项式空间 $\mathcal{P}_n^1$ 选择了适当的基。

单纯形

类似地，给定集合$S \subset \mathbb{R}^n$的凸包是包含S的最小凸集(，意味着它是所有包含S)的凸集的交集。一个集合的凸包总是唯一定义的，并由S中元素的所有凸组合组成，即S中元素的所有线性组合，其标量非负且总和为一（见[200]）。

定义 2.15. *Given an affinely independent set of points $Y = \{y^0、y^1、\ldots、y^m\}$, its convex hull is called a simplex of dimension m.*

0 维单形是一个点，1 维单形是一条闭线段，2 维单形是一个三角形，3 维单形是一个四面体。

单纯形的顶点是 Y 的元素。$\mathbb{R}^n$ 中的单纯形不能有超过 $n+$ 个1顶点。当有 $n+$ 个1顶点时，其维数是 n。在这种情况下，

$$\left[y^1 - y^0 \cdots y^n - y^0 \ -(y^1 - y^0) \cdots -(y^n - y^0) \right] \tag{2.10}$$

在 $\mathbb{R}^n$ 中形成一个（极大）正基。我们在图 2.6 中展示了这个极大正基。

由顶点$y^0、y^1、\ldots、y^m$构成的单纯形Y的直径定义为

$$\text{diam}(Y) = \max_{0 \le i < j \le m} \|y^i - y^j\|.$$

在y^0处近似diam(Y)的一种方法是计算成本较低的

$$\Delta(Y) = \max_{1 \le i \le n} \|y^i - y^0\|.$$

显然，我们可以写出 $\Delta(Y) \le \text{diam}(Y) \le 2\Delta(Y)$。

我们用单纯形的形状来表示其在相似变换下的等价类：顶点为 Y 和 $\lambda Y、\lambda > 0$ 的单纯形具有相同的形状。一个包含 $n+1$ 个顶点 $Y = \{y^0、y^1、\ldots、y^n\}$ 的单纯形的体积定义为

$$\text{vol}(Y) = \frac{|\det(L)|}{n!},$$

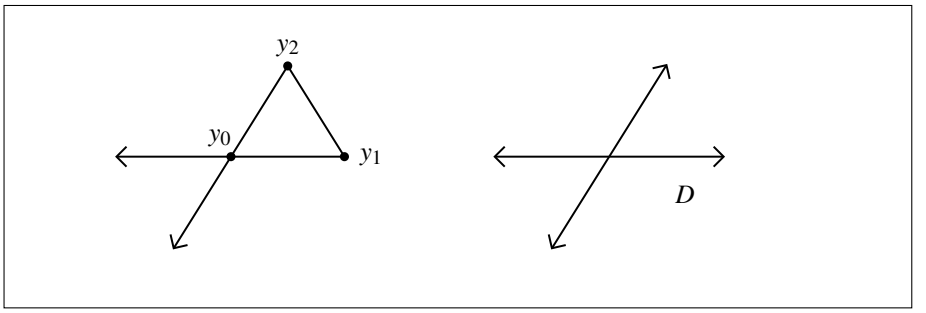


图2.6。*How to compute a maximal positive basis from the vertices of a simplex.*

其中

$$L = L(Y) = \left[y^1 - y^0 \cdots y^n - y^0\right]^\top.$$

由于单纯形的顶点构成一个仿射无关集，显然有 $\mathrm{vol}(Y) > 0$。同样留作练习的是，L 中中心点的选择与单纯形体积的定义无关。

单纯形的体积并不是衡量其几何质量的好指标，因为它并不具备缩放独立性。为了说明这一点，令

$$Y_t = \left\{\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} t \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ t \end{bmatrix}\right\},$$

当 $t >$ 为 0 时。容易看出，当 $t \to$ 为 0 时，$\mathrm{vol}(Y_t) \to$ 为 0。然而，对于所有正的 t (值，由顶点形成的向量之间的夹角是相同的，或者换句话说，所有这些单纯形都具有相同的形状)。

单纯形几何质量的一个度量必须独立于单纯形的尺度，该尺度由$\Delta(Y)$或$\mathrm{diam}(Y)$给出。一个这样的度量由

$$\|[L(Y)/\Delta(Y)]^\dagger\|,$$

这简化为

$$\|[L(Y)/\Delta(Y)]^{-1}\|$$

对于 $n+1$ 个顶点的单纯形，当有 $n+1$ 个顶点时的一个替代方案是使用归一化体积

$$\mathrm{von}(Y) = \mathrm{vol}\left(\frac{1}{\mathrm{diam}(Y)}Y\right) = \frac{|\det(L(Y))|}{n!\,\mathrm{diam}(Y)^n}.$$

适度性和正向生成

另一个自然产生的问题是，平衡插值与回归集的概念与正生成集或正基之间的关系。为了研究这种关系，让我们假设有一个由非零向量组成的正生成集D。回想一下，因此余弦测度$\mathrm{cm}(D)$必然是正的。对于

为了在这个讨论中简化，我们假设 {v*} 中的元素范数为1。那么

$$\mathrm{cm}(D) = \min_{\|v\|=1} \max_{d\in D} v^\top d \le \min_{\|v\|=1} \max_{d\in D} |v^\top d| \le \min_{\|v\|=1} \|D^\top v\|. \tag{2.11}$$

我们立即得出 D 具有行满秩。

因此，给定一个点y^0及一个正生成集D，其中$\mathrm{cm}(D) > 0$，我们知道样本集 $\{y^0\} \cup \{y^0 + d\colon\ d \in D\}$为线性回归做好了准备。见图2.7。

然而，反之则不成立。给定线性回归的稳定集$Y = \{y^0、\ y^1、\ \ldots、\ y^p\}$，方向集 $\{y^1 - y^0、\ \ldots、\ y^p - y^0\}$可能不是正生成集。构造反例是平凡的。例如，让我们取 $n = 2, p = 3, y^0 = (0, 0)$，以及

$$\begin{bmatrix} y^1 & y^2 & y^3 \end{bmatrix} = \begin{bmatrix} 1 & 0 & -1 \\ 0 & 1 & 0 \end{bmatrix}.$$

另请参见图2.7。

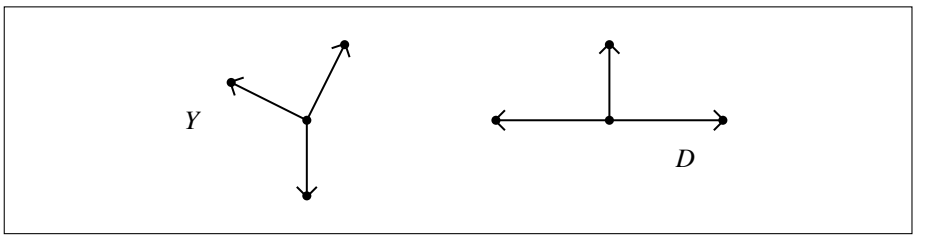


图2.7。 *For the positive spanning set on the left, the set Y marked by the bullets is poised for linear regression. However, given the poised set on the right, we see that the set of directions D marked by the arrows is not a positive spanning set.*

根据奇异值的 Courant–Fischer 型不等式（见 [131]），我们从 (2.11) 中得出

$$\mathrm{cm}(D) \le \min_{\|v\|=1} \|D^\top v\| = \sigma_{min}(D^\top),$$

其中 $\sigma_{min}(D^\top)$ 表示 $D^\top$ 的最小奇异值。因此，

$$\|(D^\top)^\dagger\| = \frac{1}{\sigma_{min}(D^\top)} \le \frac{1}{\mathrm{cm}(D)},$$

这表明，如果D的余弦测度充分远离零，那么集合$\{y^0\} \cup \{y^0 + d\colon\ d \in D\}$就充分“姿态良好”。

2.6 单纯形梯度

给定一个包含 1 个样本点的集合 $Y = \{y^0、\ y^1、\ \ldots、\ y^n\}$，且已为线性插值做好准备，则 y^0 处的单纯形梯度在优化文献中（见 Kelley [141]）定义为

$$\nabla_s f(y^0) = L^{-1} \delta f(Y),$$

其中

$$L = \left[y^1 - y^0 \cdots y^n - y^0 \right]^\top$$

和

$$\delta f(Y) = \begin{bmatrix} f(y^1) - f(y^0) \\ \vdots \\ f(y^n) - f(y^0) \end{bmatrix}.$$

然而，不难看出单纯形梯度无非就是线性插值模型$m(x) = c + g^\top x$的梯度：

$$\nabla_s f(y^0) = g.$$

当样本点数量超过 $n+1$ 时，单纯形梯度在回归意义上定义为 $L\nabla_s f(y^0) = \delta f(Y)$ 的最小二乘解，其中

$$L = \left[y^1 - y^0 \cdots \cdots y^p - y^0 \right]^\top$$

和

$$\delta f(Y) = \begin{bmatrix} f(y^1) - f(y^0) \\ \vdots \\ \vdots \\ f(y^p) - f(y^0) \end{bmatrix}.$$

再次指出，以这种方式定义的单纯形梯度是线性回归模型 $m(x) = c + g^\top x$ 的梯度 g 。我们注意到，当 $p > n$ 时，单纯形梯度也被称为模板梯度（参见 C. T. Kelley 的论文）。集合 $\{y^1、\ldots、y^p\}$ 是以 y^0 为中心的模板。例如，模板可以采取形式 $\{y^0 \pm he_i、\ i = 1、\ldots、\ n\}$，其中 h 是模板半径，而 $e_i、\ i = 1、\ldots、\ n$ 是坐标向量。

显然，根据线性插值和线性回归的假设条件，单纯形梯度满足形式为

$$\|\nabla f(y^0) - \nabla_s f(y^0)\| \leq \kappa_{eg}\,\Delta,$$

在 κ_{eg} 处 $= p^{1\!2}{}_{v}\|\hat{L}^{\dagger}\|/2$ 和 $\hat{L} = L/\Delta$。在 $p = n$ 的情况下，有 $\|\hat{L}^{\dagger}\| = \|\hat{L}^{-1}\|$。

2.7 练习

1. 证明一组非零向量构成$\mathbb{R}^n$的正基，当且仅当它们的正组合张成$\mathbb{R}^n$，且没有任何真子集具有相同的性质。

2. 证明 $[I\ -I]$ 是 $\mathbb{R}^n$ 的一个（极大）正基，其余弦测度为 $1/\sqrt{n}$。

3. 证明推论2.5。

4. 证明(2.1)中a的值必须等于$-1/n$。

5. 证明正生成集的余弦测度必然为正。

6. 除上一练习外，证明反向蕴含；即，如果一个集合的余弦测度为零，则该集合不能正生成{v*}。7. 证明在$\mathbb{R}^n$中具有均匀角度的最小正基的余弦测度为$1/n$。8. 证明，对于线性插值和回归，如果Y对某个基是平衡的，那么它对$\mathcal{P}_n^1$中的任何其他基也是平衡的。证明线性插值和回归中$m(x)$的定义也独立于所选的基。9. 证明(2.10)形成一个（最大）正基。10. 由(2.9)，完成定理2.13的证明。11. 证明对于顶点为Y的任何单纯形，$\Delta(Y) \leq \text{diam}(Y) \leq 2\Delta(Y)$ 且 $\text{vol}(Y) > 0$。

第3章

插值非线性模型

前一章讨论的采样和线性模型之所以吸引人，是因为它们构建和分析起来都很简单。但正如任何线性模型一样，它们无法捕捉所近似函数的曲率信息（除非函数是平坦的）。为了在一般情况下实现更好的局部收敛速率，考虑非线性模型是至关重要的。

二次多项式模型可以被视为最简单的非线性模型，但往往也是最高效的。在本章中，我们将介绍二次插值模型的性质。二次回归模型将在第4章以类似方式讨论。非多项式模型，如径向基函数，也可以有效地用于无导数优化。我们将在第12章简要介绍这些模型。

本章讨论的所有内容都适用于任意次数的多项式插值。但二次情形对我们最为重要，因此所有示例和图示都仅限于二次情形。

本章的目标是为在无导数优化算法中使用插值模型作为真实目标函数的近似建立理论基础。为确保使用目标函数模型的优化算法具有全局收敛性，通常需要保证该模型具有一定质量。当模型是一阶或二阶截断泰勒级数展开时，模型的质量很容易从泰勒展开的误差界推导出来。在多项式插值的情况下，存在类似的界，但与泰勒展开的界不同，它们不仅依赖于展开的中心和所近似的函数，还依赖于插值点集。（我们在第2章中已经看到了线性插值的情况。）因此，为了保持插值模型的质量，有必要理解并保持插值集的质量。在本章中，我们将考察几个刻画插值集质量的常数。我们将研究这些常数之间的关系，以及它们在多项式插值与真实函数之间的误差界（以及它们的导数之间）中所起的作用。

3.1 插值的基本概念

多项式基

让我们考虑 $\mathcal{P}_n^d$，即在 $\mathbb{R}^n$ 中次数小于或等于 d 的多项式空间。设 $p_1 = p+1$ 为该空间的维数。已知对于 $d=1$，$p_1 = n+1$，并且对于 $d=2$，$p_1 = (n+1)(n+2)/2$。

$\mathcal{P}_n^d$的一组基$\phi = \{\phi_0(x)、\phi_1(x)、\ldots、\phi_p(x)\}$是一组次数小于或等于$d$的多项式$p_1$，它们张成$\mathcal{P}_n^d$。由于$\phi$是$\mathcal{P}_n^d$中的一组基，因此任何多项式$m(x) \in \mathcal{P}_n^d$都可以写成$m(x) = \sum_{j=0}^{p} \alpha_j \phi_j(x)$，其中$\alpha_j$是一些实数系数。

有许多多项式基在不同的应用中值得考虑。我们将仅关注那些在本书背景下感兴趣的基。最简单且最常见的多项式基是单项式基，即*natural basis*。

自然基$\bar{\phi}$可以通过使用 *multiindices* 来方便地描述。令向量 $\alpha^i = (\alpha_1^i、\ldots、\alpha_n^i) \in \mathbb{N}_0^n$ 称为多重指标，并且对于任意 $x \in \mathbb{R}^n$，定义 x^{α^i} 为

$$x^{\alpha^i} = \prod_{j=1}^{n} x_j^{\alpha_j^i}.$$

此外，定义

$$|\alpha^i| = \sum_{j=1}^{n} \alpha_j^i \quad \text{and} \quad (\alpha^i)! = \prod_{j=1}^{n} (\alpha_j^i!).$$

那么自然基的元素是

$$\bar{\phi}_i(x) = \frac{1}{(\alpha^i)!} x^{\alpha^i}, \quad i = 0, \ldots, p, \quad |\alpha^i| \le d.$$

自然基可以写成如下形式：

$$\bar{\phi} = \{1, x_1, x_2, \ldots, x_n, x_1^2/2, x_1x_2, \ldots, x_{n-1}^{d-1}x_n/(d-1)!, x_n^d/d!\}. \tag{3.1}$$

例如，当 $n=3$ 且 $d=2$ 时，我们有

$$\bar{\phi} = \{1, x_1, x_2, x_3, x_1^2/2, x_1x_2, x_2^2/2, x_1x_3, x_2x_3, x_3^2/2\}.$$

自然基是多项式在泰勒展开中出现时的基。例如，假设适当的平滑性，在 $\mathbb{R}^3$ 中阶数为 $d=2$、以点 y 为中心的泰勒模型是以下关于 z_1、z_2 和 z_3 (的多项式，我们为了更好识别将自然基的元素写在方括号内)：

$$\begin{aligned} &f(y)[1] + \tfrac{\partial f}{\partial x_1}(y)[z_1] + \tfrac{\partial f}{\partial x_2}(y)[z_2] + \tfrac{\partial f}{\partial x_3}(y)[z_3] \\ &+ \tfrac{\partial^2 f}{\partial x_1^2}(y)[z_1^2/2] + \tfrac{\partial^2 f}{\partial x_1 x_2}(y)[z_1z_2] + \tfrac{\partial^2 f}{\partial x_2^2}(y)[z_2^2/2] \\ &+ \tfrac{\partial^2 f}{\partial x_1 x_3}(y)[z_1z_3] + \tfrac{\partial^2 f}{\partial x_2 x_3}(y)[z_2z_3] + \tfrac{\partial^2 f}{\partial x_3^2}(y)[z_3^2/2]. \end{aligned}$$

当 $d=1$ 时，我们有$\bar{\phi} = \{1、x_1、\ldots、x_n\}$，这些已在第 2 章中出现过。在那里我们已经看到，自然基为仿射独立性和正基等几何概念提供了直接联系。

本章感兴趣的其他多项式基是拉格朗日和牛顿基本多项式的基。我们将在本章后面讨论它们的定义和性质。

多项式插值

我们说多项式 $m(x)$ 在给定点 y 处插值函数 $f(x)$，如果 $m(y)=f(y)$。假设给定一组插值点 $Y=\{y^0、y^1、\ldots、y^p\}\subset\mathbb{R}^n$，并令 $m(x)$ 表示一个次数小于或等于 d 的多项式，该多项式在 Y 中的点处插值给定函数 $f(x)$。通过确定系数 $\alpha_0、\ldots、\alpha_p$，我们确定插值多项式 $m(x)$。系数 $\alpha_0、\ldots、\alpha_p$ 可由插值条件确定

$$\left(m(y^i)=\right)\quad \sum_{j=0}^{p}\alpha_j\phi_j(y^i)\;=\;f(y^i),\quad i=0,\ldots,p. \tag{3.2}$$

条件（3.2）构成了关于插值系数的线性系统，我们将以矩阵形式表示它为

$$M(\phi,Y)\alpha_\phi\;=\;f(Y),$$

其中

$$M(\phi,Y)\;=\;\begin{bmatrix}\phi_0(y^0)&\phi_1(y^0)&\cdots&\phi_p(y^0)\\ \phi_0(y^1)&\phi_1(y^1)&\cdots&\phi_p(y^1)\\ \vdots&\vdots&\vdots&\vdots\\ \phi_0(y^p)&\phi_1(y^p)&\cdots&\phi_p(y^p)\end{bmatrix},$$

$$\alpha_\phi\;=\;\begin{bmatrix}\alpha_0\\ \alpha_1\\ \vdots\\ \alpha_p\end{bmatrix},\quad\text{and}\quad f(Y)\;=\;\begin{bmatrix}f(y^0)\\ f(y^1)\\ \vdots\\ f(y^p)\end{bmatrix}.$$

例如，当 $n=d=2$ 且 $p=5$ 时，矩阵 $M(\bar{\phi}、Y)$ 变为

$$\begin{bmatrix}1&y_1^0&y_2^0&(y_1^0)^2/2&y_1^0y_2^0&(y_2^0)^2/2\\ 1&y_1^1&y_2^1&(y_1^1)^2/2&y_1^1y_2^1&(y_2^1)^2/2\\ 1&y_1^2&y_2^2&(y_1^2)^2/2&y_1^2y_2^2&(y_2^2)^2/2\\ 1&y_1^3&y_2^3&(y_1^3)^2/2&y_1^3y_2^3&(y_2^3)^2/2\\ 1&y_1^4&y_2^4&(y_1^4)^2/2&y_1^4y_2^4&(y_2^4)^2/2\\ 1&y_1^5&y_2^5&(y_1^5)^2/2&y_1^5y_2^5&(y_2^5)^2/2\end{bmatrix}.$$

对于上述系统具有唯一解，矩阵$M(\phi,\ Y)$必须是非奇异的。

定义 3.1. *The set $Y=\{y^0,y^1,\ldots,y^p\}$ is poised for polynomial interpolation in $\mathbb{R}^n$ if the corresponding matrix $M(\phi,Y)$ is nonsingular for some basis ϕ in $\mathcal{P}_n^d$.*

Poisedness 在文献中还有其他术语（例如，文献[53]的作者将 poised 集称为 *d-unisolvent* 集）。正如我们在第2.5节中所见，在线性情形（$d = 1$）下，poisedness 的概念与仿射独立性相同。

很容易看出，如果对于某个基 ϕ，$M(\phi、Y)$ 是非奇异的，那么对于 $\mathcal{P}_n^d$ 的任意基，它都是非奇异的。在这种情况下，还可以证明插值多项式 $m(x)$ 存在且唯一。

给定多项式空间 $\mathcal{P}_n^d$ 和一组基 ϕ，令

$$\phi(x) = [\phi_0(x), \phi_1(x), \ldots, \phi_p(x)]^\top$$

是 $\mathbb{R}^{p_1}$ 中的一个向量，其元素是多项式基在 x (处的值，可以将 ϕ 视为从 $\mathbb{R}^n$ 到 $\mathbb{R}^{p_1}$) 的映射。

引理 3.2. *Given a function $f : \mathbb{R}^n \to \mathbb{R}$ and a poised set $Y \in \mathbb{R}^n$, the interpolating polynomial $m(x)$ exists and is unique.*

Proof. 显然，对于给定的基 $\phi(x)$，$m(x)$ 存在且唯一，因为 Y 是平衡的。我们现在需要证明的是 $m(x)$ 与 $\phi(x)$ 的选择无关。考虑另一个基 $\psi(x) = P^\top \phi(x)$，其中 P 是某个非奇异 $p_1 \times p_1$ 矩阵。显然，我们有 $M(\psi、Y) = M(\phi、Y)P$。设 α_ϕ 是基 ϕ 下 (3.2) 的解，设 α_ψ 是基 ψ 下 (3.2) 的解。那么，对于任意右端项 $f(Y)$，我们有 $\alpha_\psi = P^{-1}(M(\phi、Y))^{-1} f(Y)$ 以及

$$\begin{aligned} \alpha_\psi^\top \psi(x) &= f(Y)^\top (M(\phi, Y))^{-\top} P^{-\top} P^\top \phi(x) \\ &= f(Y)^\top (M(\phi, Y))^{-\top} \phi(x) = \alpha_\phi^\top \phi(x). \end{aligned}$$

我们得出结论：对于任意 x，$m(x) = \alpha_\psi^\top \psi(x) = \alpha_\phi^\top \phi(x)$□

矩阵 $M(\phi、Y)$ 是奇异的当且仅当存在 $\gamma \in \mathbb{R}^{p_1}$ 使得 $\gamma \neq 0$ 且 $M(\phi、Y)\gamma = 0$，这意味着存在一个次数最多为 d 的多项式，表示为

$$m(x) = \sum_{j=0}^{p} \gamma_j \phi_j(x),$$

使得对于所有 $y \in Y$，$m(y) = 0$。换言之，$M(\phi, Y)$ 是奇异的当且仅当 Y 中的点位于一个次数不超过 d 的“多项式流形”上。例如，在 $\mathbb{R}^2$ 中位于二次曲线上的六个点，比如一条曲线上的点，构成一个不适合用于二次插值的非恰当集。[4]

既然我们已经为插值集的平衡性建立了代数和几何准则，那么自然会问：这些条件能否被扩展以刻画一个*well- poised*插值集。例如，既然$M(\phi、Y)$的非奇异性是平衡性的指标，那么$M(\phi、Y)$的*condition number*是否会是*well poisedness*的指标？一般而言，答案是否定的，因为$M(\phi、Y)$的条件数取决于ϕ的选择。此外，对于任何给定的平衡插值集Y，人们可以选择基ϕ，使得

[4]The fact that the points lie on a second-order curve trivially implies that columns of $M(\phi, Y)$ can be combined with some coefficients, not all of them zero, to obtain a zero vector.

$M(\phi、Y)$的条件数可以等于1到$+\infty$之间的任何数。此外，对于ϕ的任何固定选择，$M(\phi、Y)$的条件数取决于Y的缩放。因此，$M(\phi、Y)$的条件数不被认为是点集 poised ness 水平的良好表征。然而，我们将回到这个问题，并展示对于ϕ的特定选择，即对于自然基，以及对于$\hat{Y}$，即Y的缩放版本，$M(\bar{\phi}、\hat{Y})$的条件数是良好 poisedness 的有意义度量。

3.2 拉格朗日多项式

在多变量多项式插值文献中，最常用的良好平衡性度量是基于拉格朗日多项式的。

定义 3.3. *Given a set of interpolation points $Y = \{y^0, y^1, \ldots, y^p\}$, a basis of $p_1 = p + 1$ polynomials $\ell_j(x)$, $j = 0, \ldots, p$, in $\mathcal{P}_n^d$ is called a basis of Lagrange polynomials if*

$$\ell_j(y^i) = \delta_{ij} = \begin{cases} 1 & \text{if } i = j, \\ 0 & \text{if } i \neq j. \end{cases}$$

如果Y是恰当的，拉格朗日多项式存在、唯一，并具有许多有用的性质。

引理 3.4. *If Y is poised, then the basis of Lagrange polynomials exists and is uniquely defined.*

Proof. 证明源于以下事实：每个拉格朗日多项式$\lambda_j(x)$是一个插值多项式（该函数在Y中除y^j处等于1外，在其他所有点处均为零），并且依据引理3.2。 □

拉格朗日多项式的存在性反过来意味着采样集的适定性。事实上，如果拉格朗日多项式存在，则存在一个矩阵 A_ϕ (，其列是这些多项式在基 ϕ) 中的系数，使得 $M(\phi，Y)A_\phi = I$，因此，矩阵 $M(\phi，Y)$ 是非奇异的。

为了证明上述定义的拉格朗日多项式集合构成 $\mathcal{P}_n^d$ 的一组基，我们需要证明 $\mathcal{P}_n^d$ 中的任意多项式 $m(x)$ 都是拉格朗日多项式的线性组合。我们知道，由于 Y 是适定的，任意多项式由其于 Y 中点的值唯一确定。如下面的引理所示，这些值实际上是 $m(x)$ 通过拉格朗日多项式线性表达式的系数。

引理3.5。*For any function f: $\mathbb{R}^n \to \mathbb{R}$ and any poised set $Y = \{y^0，y^1，\ldots，y^p\} \subset \mathbb{R}^n$, the unique polynomial $m(x)$ that interpolates $f(x)$ on Y can be expressed as*

$$m(x) = \sum_{i=0}^{p} f(y^i)\ell_i(x),$$

where $\{\ell_i(x), i = 0, \ldots, p\}$ is the basis of Lagrange polynomials for Y.

最后一个结果的证明留作练习。为了在$\mathbb{R}^2$中说明拉格朗日多项式，考虑对下式给出的三次函数进行插值：

$$f(x_1,x_2) = x_1+x_2+2x_1^2+3x_2^3$$

在六个插值点$y^0=(0,0)$, $y^1=(1,0)$, $y^2=(0,1)$, $y^3=(2,0)$, $y^4=(1,1)$ 和 $y^5=(0,2)$ 处。显然，$f(y^0)=0, f(y^1)=3, f(y^2)=4, f(y^3)=10, f(y^4)=7$, 和 $f(y^5)=26$。容易看出，相应的拉格朗日多项式 $\ell_j(x_1,x_2), j=0,\ldots,5$, 由下式给出

$$\begin{aligned}
\ell_0(x_1,x_2) &= 1-\tfrac{3}{2}x_1-\tfrac{3}{2}x_2+\tfrac{1}{2}x_1^2+\tfrac{1}{2}x_2^2+x_1x_2,\\
\ell_1(x_1,x_2) &= 2x_1-x_1^2-x_1x_2,\\
\ell_2(x_1,x_2) &= 2x_2-x_2^2-x_1x_2,\\
\ell_3(x_1,x_2) &= -\tfrac{1}{2}x_1+\tfrac{1}{2}x_1^2,\\
\ell_4(x_1,x_2) &= x_1x_2,\\
\ell_5(x_1,x_2) &= -\tfrac{1}{2}x_2+\tfrac{1}{2}x_2^2.
\end{aligned}$$

也很容易验证

$$\begin{aligned}
m(x_1,x_2) &= 0\ell_0(x_1,x_2)+3\ell_1(x_1,x_2)+4\ell_2(x_1,x_2)+10\ell_3(x_1,x_2)\\
&\quad +7\ell_4(x_1,x_2)+26\ell_5(x_1,x_2)
\end{aligned}$$

满足插值条件。

为给定集合 Y 计算拉格朗日多项式的整个基需要 $\mathcal{O}(p^3)$ 次运算，这与计算一个任意插值多项式 $m(x)$ 所需的运算次数处于同一数量级。如果已有一组拉格朗日多项式，并且集合 Y 通过一个点更新，那么更新该拉格朗日多项式集合需要 $\mathcal{O}(p^2)$。我们将在第6章进一步讨论这一点。

拉格朗日多项式在本书中最有用的特性之一是，在一个区域B内其绝对值的上界是Y在B中适定性的经典度量。特别地，在[53]中表明，对于凸包Y中的任意x

$$\|\mathcal{D}^r f(x)-\mathcal{D}^r m(x)\| \le \frac{1}{(d+1)!}v_d\sum_{i=0}^{p}\|y^i-x\|^{d+1}\|\mathcal{D}^r\ell_i(x)\|,$$

其中 $\mathcal{D}^r$ 表示函数的 r 阶导数，v_d 是 $\mathcal{D}^{d+1}f(x)$ 的上界。注意，这个误差界要求 $f(x)$ 具有有界的 $(d+1)$ 阶导数。关于此界中每个元素的精确含义，请参见 [53]。当 $r=0$ 时，函数值的界简化为

$$|f(x)-m(x)| \le \frac{1}{(d+1)!}p_1v_d\Lambda_\ell\Delta^{d+1},$$

其中

$$\Lambda_\ell = \max_{0\le i\le p}\max_{x\in B(Y)}|\ell_i(x)|,$$

而 Δ 是包含 Y 的最小球体 $B(Y)$ 的直径。关于此界限的一个简单推导，另见 [188]。Λ_ℓ 与 Y (的勒贝格常数密切相关，参见 [53])。

拉格朗日多项式的等价定义

拉格朗日多项式在单变量和多变量多项式插值理论中起着重要作用。从上述性质可以看出，它们在基于模型的无导数优化中也非常有用。由于插值模型通过拉格朗日多项式基可以简单地表达，并且这样的基可以相当高效地计算和更新，因此通过维护拉格朗日多项式基来维护插值模型是实用的。从上一小节末尾给出的插值误差界可以明显看出，拉格朗日多项式对于构建选择良好插值集的标准也很有用。因此，更好地理解拉格朗日多项式的性质对我们来说很重要。这里我们讨论定义拉格朗日多项式的两种替代方法。

给定已就位的集合 $Y = \{y^0、\ y^1、\ \ldots、\ y^p\} \subset \mathbb{R}^n$ 和 $x \in \mathbb{R}^n$，因为矩阵 $M(\phi、\ Y)$ 是非奇异的，我们可以将向量 $\phi(x)$ 唯一地用向量 $\phi(y^i)、\ i = 0、\ \ldots、\ p$ 表示为

$$\sum_{i=0}^{p} \lambda_i(x)\phi(y^i) \ = \ \phi(x) \tag{3.3}$$

或以矩阵形式表示，

$$M(\phi, Y)^\top \lambda(x) \ = \ \phi(x), \quad \text{where } \lambda(x) \ = \ [\lambda_0(x), \ldots, \lambda_p(x)]^\top. \tag{3.4}$$

由(3.4)显然，$\lambda(x)$是一个在$\mathcal{P}_n^d$中的多项式向量。我们也可以直接从(3.3)看出，$\lambda_i(x)$是对于Y的第i个拉格朗日多项式。因此，拉格朗日多项式在给定点x的值是向量$\phi(y^i)$在构成$\phi(x)$的线性组合中的贡献权重。

定义拉格朗日多项式的第二种替代方法如下。给定集合 Y 和一点 x，考虑集合 $Y_i(x) = Y \setminus \{y^i\} \cup \{x\}、\ i = 0、\ \ldots、\ p$。将克拉默法则应用于方程组 (3.4)，我们看到

$$\lambda_i(x) \ = \ \frac{\det(M(\phi, Y_i(x)))}{\det(M(\phi, Y))}. \tag{3.5}$$

从这个表达式可以清楚地看出，$\lambda(x)$ 是 $\mathcal{P}_n^d$ 中的多项式，并且它满足定义 3.3。因此，$\{\lambda_i(x)、\ i = 0、\ \ldots、\ p\}$ 正是拉格朗日多项式的集合。由此可知，只要多项式空间 $\mathcal{P}_n^d$ 固定，$\lambda(x)$ 实际上并不依赖于 ϕ 的选择。

为了进一步理解(3.5)的含义，考虑集合$\phi(Y) = \{\phi(y^i),\ i = 0,\ \ldots,\ p\}$在$\mathbb{R}^{p_1}$中。设vol($\phi(Y)$)为$\phi(Y)$中顶点单纯形的体积，由下式给出：

$$\text{vol}(\phi(Y)) \ = \ \frac{|\det(M(\phi, Y))|}{p_1!}.$$

(这样一个单纯形是 $\phi(Y)$.) Th 的 p_1 维凸包。 {v*}

$$|\lambda_i(x)| \ = \ \frac{\text{vol}(\phi(Y_i(x)))}{\text{vol}(\phi(Y))}. \tag{3.6}$$

换句话说，在给定点x处，第i个拉格朗日多项式的绝对值是当y^i被x替换时，$\phi(Y)$（的p_1维凸包）体积的变化。

3.3 Λ {v*} 平衡度及其他良好表现指标 {v*}

那么，毕竟我们应该如何定义一种良好 poised 性的度量呢？给定一个插值集合 Y，poised 性的度量应反映该集合在插值感兴趣区域中“张成”的程度。与线性情形不同，在线性情形中“良好张成”表示 Y 中各点的仿射无关性，而在非线性情形中，我们考虑向量 $\phi(y^i)$、$i = 0$、…、p 在感兴趣区域内张成所有 $\phi(x)$ 的集合的程度。

显然，这样的测度将依赖于 Y 以及所考虑的区域。例如，在线性插值的情况下，集合 $Y = \{(0, 0), (0, 1), (1, 0)\}$ 在 $B(0; 1)$——以原点为中心、半径为1的球体——中是一个良置集合，但在 $B(0; 10^6)$——以原点为中心、半径为10^6的球体——中则不是良置集合。

Y的良好平衡性（以及平衡性）还必须取决于选择插值多项式的多项式空间。例如，$\mathbb{R}^2$中圆上的六个点对于用二次多项式进行插值并不处于平衡状态，但它们对于插值是平衡的，例如，在没有二次项和常数项的三次多项式的子空间中。

Λ-平衡性

我们将使用以下关于良平衡集的等价定义。

定义3.6。*Let $\Lambda > 0$ and a set $B \in \mathbb{R}^n$ be given. Let $\phi = \{\phi_0(x),\ \phi_1(x),\ \ldots,\ \phi_p(x)\}$ be a basis in $\mathcal{P}_n^d$. A poised set $Y = \{y^0,\ y^1,\ \ldots,\ y^p\}$ is said to be Λ-poised in B (in the interpolation sense) if and only if*

1. *for the basis of Lagrange polynomials associated with Y*

$$\Lambda \ \geq \ \max_{0\leq i\leq p}\ \max_{x\in B} |\ell_i(x)|,$$

or, equivalently,

2. *for any $x \in B$ there exists $\lambda(x) \in \mathbb{R}^{p_1}$ such that*

$$\sum_{i=0}^{p} \lambda_i(x)\phi(y^i) \ = \ \phi(x) \qquad \textit{with} \qquad \|\lambda(x)\|_\infty \ \leq \ \Lambda,$$

or, equivalently,

3. *replacing any point in Y by any $x \in B$ can increase the volume of the set $\{\phi(y^0)$、$\phi(y^1)$、…、$\phi(y^p)\}$ at most by a factor Λ.*

注意，该定义并不暗示或要求样本集 Y 包含在拉格朗日多项式绝对值最大化的集合 B 中。实际上，只要所有拉格朗日多项式在 B 上的绝对值有界，集合 Y 可以任意远离 B。然而，正如我们稍后将看到的，为了保证构造 Λ-poised 集合的算法的有效性，我们必须在 B 中生成点（直至整个集合 Y）。

第二个和第三个定义为我们提供了对Λ- poisedness的一些几何直觉。如前所述，我们可以考虑映射$x \to \phi(x)$和$\phi(Y)$，并且

$\phi(B)$——在该映射下 Y 和 B 的像。第二个定义表明，Λ 是衡量 $\phi(Y)$ 如何良好地张成 $\phi(B)$ 的一个度量。如果 $\phi(Y)$ 良好地张成 $\phi(B)$，那么 $\phi(B)$ 中的任何向量都可以表示为 $\phi(Y)$ 中向量的线性组合，且系数相当小。第三个定义有类似的解释，但它通过单纯形的体积来表达。如果 $\phi(Y)$ 良好地张成 $\phi(B)$，那么通过将 Y 中的一个点替换为 B 中的任何点，都不可能显著增大 $\phi(Y)$ 的体积。

图3.1–3.4展示了在B中若干组六个点——即以(0.5, 0.5)为中心、半径为1/2的“平方”球内的点集，该中心位于$\mathbb{R}^2$。这些点集列于图下方，并且对于每一组这样的点集，相应的$\Lambda = \max_{0\le i\le 5} \max_{x\in B} |\ell_i(x)|$也被列出。所有数值的列出均具有足够的精度，以说明良定与病态点集的情况。对于每个插值点集，我们还展示了在该点集上插值函数$\cos(x_1) + \sin(x_2)$的模型。从图中可以明显看出，随着Λ变大，插值模型的质量显著下降。

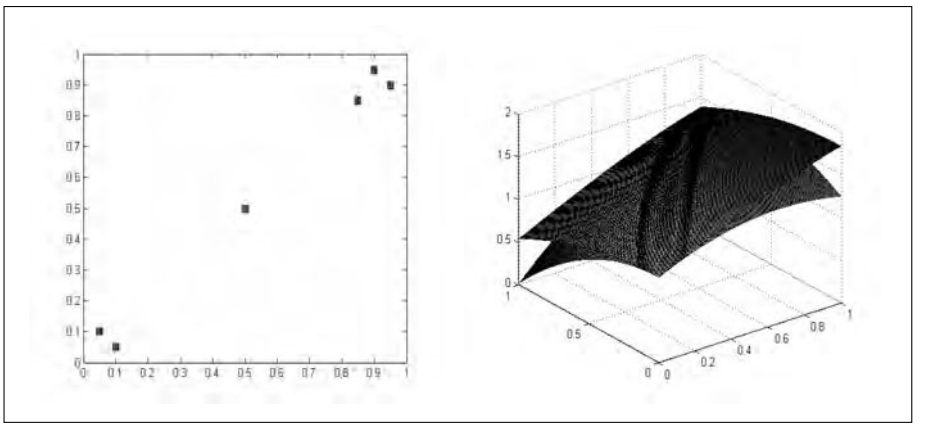


图3.1。*A nonpoised set perturbed by about* 0.1*:* $Y = \{(0.05,\ 0.1),\ (0.1,\ 0.05),\ (0.5,\ 0.5),\ (0.95,\ 0.9),\ (0.9,\ 0.95),\ (0.85,0.85)\}$ *and* $\Lambda = 440$.

Λ{-}姿态性作为到线性无关的距离

常数 Λ 可以被解释为到一个非平衡集合的实际距离度量。给定一个插值集合 Y，令 $B(y^0;\ \Delta(Y))$ 为以插值点 y^0 为中心且包含 Y 的最小闭球。假设对于给定的 Λ，集合 Y 在 $B(y^0$ 中不是 Λ-平衡的；$\Delta(Y))$。那么存在一个 $z \in B(y^0;\ \Delta(Y))$ 使得

$$\sum_{i=0}^{p} \lambda_i(z)\phi(y^i) \;=\; \phi(z) \quad \text{and} \quad \|\lambda(z)\|_\infty \;>\; \Lambda,$$

因此，不失一般性，$\lambda_1(z) > \Lambda$。然后，将此表达式除以Λ，我们得到

$$\sum_{i=0}^{p} \frac{\lambda_i(z)}{\Lambda}\phi(y^i) \;=\; \sum_{i=0}^{p} \gamma_i(z)\phi(y^i) \;=\; \frac{\phi(z)}{\Lambda} \quad \text{and} \quad \gamma_1(z) \;>\; 1.$$

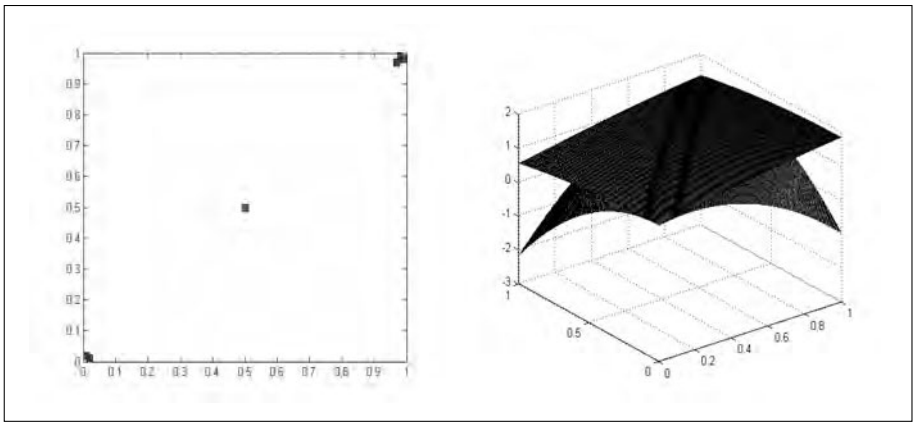


图3.2。*A nonpoised set of points perturbed by about* 0.01*:* $Y = \{(0.01, 0.02), (0.02, 0.01), (0.5, 0.5), (0.99,0.98),(0.98,0.98), (0.97, 0.97)\}$ *and* $\Lambda = 21296$.

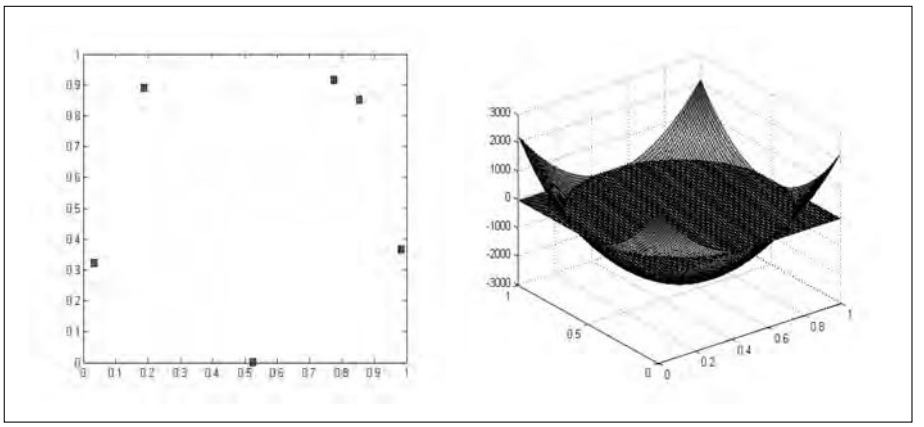


图3.3。*A poised set, but the points nearly lie on a circle:* $Y = \{(0.524, 0.0006), (0.032, 0.323), (0.187, 0.890), (0.854, 0.853), (0.982, 0.368), (0.774, 0.918)\}$ *and* $\Lambda = 524982$.

因此，

$$\left\| \sum_{i=0}^{p} \gamma_i(z)\phi(y^i) \right\|_\infty \leq \frac{\max_{x \in B(y^0;\Delta(Y))} \|\phi(x)\|_\infty}{\Lambda}.$$

例如，如果$\bar{\phi}$是自然基，$y^0 = 0$，并且$B(y^0$的半径$\Delta(Y)$；$\Delta(Y))$是1，那么

$$\max_{x \in B(0;1)} \|\bar{\phi}(x)\|_\infty \leq 1$$

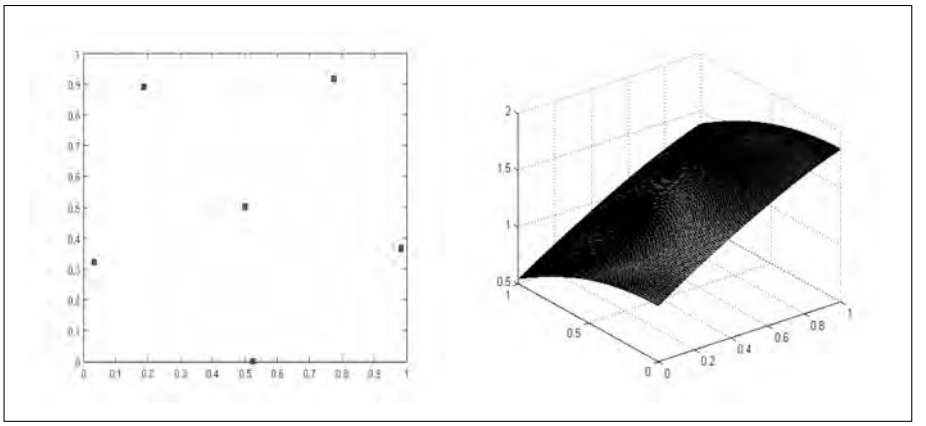


图3.4。*An "ideal" set:* $Y = \{(0.524,\ 0.0006),\ (0.032,\ 0.323),\ (0.187,\ 0.890),\ (0.5,\ 0.5),\ (0.982,\ 0.368),\ (0.774,\ 0.918)\}$ *and* $\Lambda = 1$.

和

$$\left\| \sum_{i=0}^{p} \gamma_i(z)\bar{\phi}(y^i) \right\|_\infty \leq \frac{1}{\Lambda} \quad \text{with} \quad \gamma_1(z) > 1.$$

现在很容易看出，$1/\Lambda$在某种意义上界定了向量$\bar{\phi}(y^i)$、$i = 0$、…、p线性相关性的距离。随着Λ的增长，这些向量所代表的系统越来越线性相关。但实际到奇点的距离取决于ϕ的选择。

Λ平衡性的性质

从现在起，我们将省略关于 Y 相对于某个给定的 $\mathcal{P}_n^d$ 是 Λ- poised 的说法。除非另有说明，否则将假定空间 $\mathcal{P}_n^d$ 根据给定的上下文保持不变。

我们将陈述几个基本结果，希望能有助于增强对平衡常数Λ的理解。证明留作练习。

引理 3.7。

1. *If B contains a point in Y and Y is Λ-poised in B, then $\Lambda \geq 1$.*

2. *If Y is Λ-poised in a given set B, then it is Λ-poised (with the same constant) in any subset of B.*

3. *If Y is Λ-poised in B for a given constant Λ, then it is $\tilde{\Lambda}$-poised in B for any $\tilde{\Lambda} \geq \Lambda$.*

4. *For any $x \in \mathbb{R}^n$, if $\lambda(x)$ is the solution of* (3.3)*, then*

$$\sum_{i=0}^{p} \lambda_i(x) = 1.$$

现在我们将证明平衡常数Λ不依赖于样本集的缩放。

引理 3.8。 *Let* $Y = \{y^0、\ y^1、\ \ldots、\ y^p\}$ *be an interpolation set and* $\lambda_i(x)$, $i = 0、\ \ldots、$ *p, be the set of solutions to* (3.3) *for the given* Y. *Then, for any* $\Delta > 0$, $\lambda_i(x/\Delta)$, $i = 0、$ $\ldots、$ *p, is the set of solutions to* (3.3) *for* $\hat{Y}$, *where* $\hat{Y} = \{y^0/\Delta、\ y^1/\Delta、\ \ldots、\ y^p/\Delta\}$.

Proof. 由于(3.3)的解$\lambda(x)$不依赖于基的选择，我们可以考虑$\bar{\phi}(x)$ (自然基)。我们知道，$\lambda_i(x)$、$i = 0$、$\ldots$、p满足

$$\sum_{i=0}^{p} \lambda_i \bar{\phi}(y^i) \ = \ \bar{\phi}(x).$$

如果我们将每个 y^i 和 x 按 $1/\Delta$ 缩放，这相当于将上述方程按不同的标量（$1, 1/\Delta, 1/\Delta^2$ 等）缩放。显然，$\lambda(x/\Delta)$ 满足缩放后的方程组（3.3）。 □

该引理的一个直接推论是，如果Y在B中是Λ- poised的，那么$\hat{Y} = Y/\Delta$在$\hat{B} = B/\Delta$中是Λ-poised的。

我们的下一步是证明Λ- poisedness在坐标平移下是不变的。

引理 3.9. *Let* $Y = \{y^0、\ y^1、\ \ldots、\ y^p\}$ *be an interpolation set and* $\lambda_i(x)$, $i = 0、\ \ldots、$ *p, be the solution to* (3.3) *for a given* x. *Then, for any* $a \in \mathbb{R}^n$, *it is also the solution to* (3.3) *for* $Y_a = \{y^0 + a、\ y^1 + a、\ \ldots、\ y^p + a\}$ *and* $x_a = x + a$.

Proof. 由于(3.3)的解$\lambda(x)$不依赖于基的选择，我们可以考虑$\bar{\phi}(x)$ (自然基)。让我们回顾多重指标记法：$\bar{\phi}_j(x) = \frac{1}{(\alpha_j)!} x^{\alpha_j}$。容易证明，对于任意$j = 0$，$\ldots$，$p$，

$$\bar{\phi}_j(x + a) \ = \ \bar{\phi}_j(x) + \bar{\phi}_j(a) + \sum_{k:\,|\alpha_k| < |\alpha_j|} \gamma_k(a) \bar{\phi}_k(x), \tag{3.7}$$

其中 $\gamma_k(a)$ 是一些系数，取决于 a 的选择，但与 x 无关。从 (3.7) 容易看出，$\bar{\phi}(x + a)$ 定义了 $\mathcal{P}_n^d$ 中的一组基。而且，同样由于 (3.3) 的解不依赖于基的选择，

$$\sum_{i=0}^{p} \lambda_i(x) \bar{\phi}(y^i + a) \ = \ \bar{\phi}(x + a). \quad \square$$

牛顿基本多项式

牛顿基本多项式（NFPs）在性质上与拉格朗日多项式相似。我们在此简要介绍它们，因为与拉格朗日多项式一样，它们已被用于无导数优化框架中，以保持插值模型的质量（见 [59, 60]）。

对于拉格朗日多项式，NFPs构成一组基，且基中的每个成员对应于插值集中的一个点。与拉格朗日多项式基的不同之处在于：插值点及其相应的NFPs被分组为块，每块对应一个从0到d的多项式次数。每个次数为ℓ的块包含的点数和多项式数恰好等于满足条件$|\alpha| = \ell$的多重指标α的数量。NFPs的构造方式使得对应于前ℓ个块的元素构成了次数不超过ℓ的多项式空间的NFP基。

更具体地说，第ℓ块中的点数是

$$|Y^{[\ell]}| = \begin{pmatrix} \ell+n-1 \\ \ell \end{pmatrix},$$

其中右侧是一个二项式系数。注意$|Y^{[0]}| = 1$。对应于每个点$y_i^{[\ell]} \in Y^{[\ell]}$，存在一个满足条件的次数为$\ell$的单一NFP $n_i^{[\ell]}(x)$

$$n_i^{[\ell]}(y_j^{[m]}) = \delta_{ij}\delta_{\ell m} \quad \forall y_j^{[m]} \in Y^{[m]} \quad \text{with} \quad m \le \ell. \tag{3.8}$$

插值多项式 $m(x)$ 则表示为

$$m(x) = \sum_{y_i^{[\ell]} \in Y} \gamma_i^{[\ell]}(Y, f) n_i^{[\ell]}(x),$$

其中系数$\gamma_i^{[\ell]}(Y、f)$是应用于f的广义有限差分。更多细节请参见[205]。

为了举例说明NFP，我们考虑在$\mathbb{R}^2$中进行二次插值，并使用与第3.2节中计算拉格朗日多项式基相同的点集。所选的六个插值点被分成三个块（$d = 2$）：

$$Y^{[0]} = \{(0,0)\}, \quad Y^{[1]} = \{(1,0),(0,1)\}, \quad \text{and} \quad Y^{[2]} = \{(2,0),(1,1),(0,2)\}.$$

NFP 由以下给出

$$n_1^{[0]} = 1, \quad n_1^{[1]} = x_1, \quad n_2^{[1]} = x_2,$$

$$n_1^{[2]} = \frac{1}{2}(x_1^2 - x_1), \quad n_2^{[2]} = x_1 x_2, \quad \text{and} \quad n_3^{[2]} = \frac{1}{2}(x_2^2 - x_2),$$

对于这些条件（3.8）可能很容易验证。

正如拉格朗日多项式的情况一样，非固定点（NFPs）存在当且仅当集合 Y 已准备就绪。该值

$$\Lambda_n = \max_{0 \le i \le p} \max_{x \in B(Y)} |n_i(x)|$$

作为集合Y (在$B(Y)$)中的准备度的度量。以下界是[205]中找到的界的简化：

$$|f(x) - m(x)| \le \frac{2^d}{(d+1)!} p_1 v_d \Lambda_n \Delta^{d+1},$$

其中 v_d 再次是 $\mathcal{D}^{d+1} f(x)$ 的上界，而 Δ 是 $B(Y)$ 的半径。

NFP相对于拉格朗日多项式的一个优势在于，与较低次数块相关联的多项式独立于更高次数的块。注意，在上面的例子中，前三个NFP为线性插值提供了一个基，并且不像第3.2节中讨论的同一组点的拉格朗日多项式那样包含二次项。

当存在几个中等大小的块时，NFP基最为有利，即当维度n较小且阶数d相对较大时。这种情况在无导数优化中很少出现。然而，当Y包含的点不足以构造完整的二次模型时，选择一个样本点块进行线性插值并基于该块构造线性基可能是有用的。剩余的点则可用于生成一组二阶多项式，这些多项式不构成基，但仍满足条件(3.8)。我们将在第5章简要讨论这一点。

3.4 条件数作为衡量适定性的指标

正如我们之前所总结的，插值条件矩阵$M(\phi、Y)$的条件数并不能很好地衡量Y的适定性，因为通过改变ϕ或缩放Y，它可被任意增大。

我们现在考虑对$\phi = \bar{\phi}$ (自然基)的一个特定选择。我们将研究$M(\bar{\phi}、\hat{Y})$的条件数，其中$\hat{Y}$是Y经过平移和缩放后的版本，使得

$$\hat{Y} = \{0, \hat{y}^1, \ldots, \hat{y}^p\} \subset B(0;1)$$

和

$$\max_{1\le i\le p} \|\hat{y}^i - \hat{y}^0\| = \max_{1\le i\le p} \|\hat{y}^i\| = 1.$$

然后我们将建立$M(\bar{\phi}、\hat{Y})$的条件数与 poisedness 度量之间的关系。这将使我们能够直接在无导数算法中使用插值条件和矩阵$M(\bar{\phi}、\hat{Y})$，而无需计算拉格朗日多项式或NFP基，并且仍然能够保持插值集的充分poisedness（从而保证插值误差的适度界）。

平移和缩放

出于数值原因，考虑一个集合 Y 通常很有用，其中它的一个点（不失一般性，y^0）位于原点。如果 Y 不是这样的集合，则进行坐标平移以将 y^0 移动到原点。在基于插值的无导数优化中，当前最佳迭代点通常是插值的中心，并且它总是可以被视为原点。正如我们所见，插值集合 Y 的稳定常数 Λ 和 Y 上的插值质量在坐标平移下都不会改变。

我们已经确定，Λ- poisedness 也与缩放无关，尽管它确实依赖于考虑 poisedness 的区域 B。矩阵 $M(\phi、Y)$ 的条件数取决于 Y 的缩放，但“独立”于任何区域 B。为了将这两个概念联系起来，我们将区域固定为 $B(0；\Delta(Y))$——即包含 Y 的最小球（以 $y^0 = 0$ 为中心）。然后我们缩放 $B = B(0；\Delta(Y))$ 和 Y，使得 $B(0；\Delta(Y))$ 的半径等于1。我们将这样的球记为 $B(0；1)$。

因此，给定任意样本集写为

$$Y = \{y^0, y^1, \ldots, y^p\},$$

我们首先将其平移 $-y^0$，使新集合以原点为中心：

$$\{0, y^1 - y^0, \ldots, y^p - y^0\}.$$

然后我们考虑

$$\Delta = \Delta(Y) = \max_{1 \le i \le p} \|y^i - y^0\|$$

并用 Δ 缩放该集合：

$$\hat{Y} = \{0, \hat{y}^1, \ldots, \hat{y}^p\} = \{0, (y^1 - y^0)/\Delta, \ldots, (y^p - y^0)/\Delta\} \subset B(0;1).$$

得到的样本集$\hat{Y}$包含在以原点为中心、半径为1的球内，并且至少有一个点位于球面上。除非另有说明，第6章中讨论的用于分解 $M(\bar{\phi}、Y)$ 以实现良好平衡性的算法，将针对这种形式的采样集进行陈述和分析。如果原始样本集 Y 不满足此要求，我们首先对其进行平移，然后进行缩放，使其满足$\hat{Y} \subset B(0;1)$。

一些辅助结果

令 $\phi(x)$ 为次数不超过 d 的多项式空间 $\mathcal{P}_n^d$ 的某一基底。我们将证明，任何通过 $\phi(x)$ 表示且系数不太小的多项式，在单位球上不可能为零（或接近为零）。

引理 3.10。*There exists a number $\sigma_\infty > 0$ such that, for any choice of v satisfying $\|v\|_\infty = 1$, there exists a $y \in B(0;1)$ such that $|v^\top \phi(y)| \ge \sigma_\infty$.*

Proof. 考虑

$$\psi(v) = \max_{x \in B(0;1)} |v^\top \phi(x)|. \tag{3.9}$$

很容易证明，$\psi(v)$ 是向量空间中的范数，v (其维数为 $\mathcal{P}_n^d$，由 $p_1 = p + 1$ 在我们的记号中给出)。由于有限维空间中任意两个范数的比值可以被一个常数一致地界定，因此存在一个 $\sigma_\infty > 0$，使得 $\psi(v) \ge \sigma_\infty \|v\|_\infty$。常数 σ_∞ 被定义为

$$\sigma_\infty = \min_{\|v\|_\infty = 1} \psi(v).$$

因此，如果v的ℓ_∞-范数为1，则$\psi(v) \ge \sigma_\infty$且存在一个$y \in B(0;1)$，使得 $|v^\top \phi(y)| \ge \sigma_\infty$。 □

如果我们只关注ϕ为自然基且$d \le$为2的情况，那么我们可以很容易地给出σ_∞的一个明确下界。我们从$d =$为1且$\sigma_\infty \ge$为1的情况开始。

引理 3.11。 *Let $v^\top \bar{\phi}(x)$ be a linear polynomial, where $\|v\|_\infty = 1$ and $\bar{\phi}$ is the natural basis (defined by* (3.1) *when $d = 1$). Then*

$$\max_{x \in B(0;1)} |v^\top \bar{\phi}(x)| \;\geq\; 1.$$

证明在第6章给出。对于 $d = 2$，我们有以下结果。证明也推迟到第6章，因为它提出了一种算法，该算法可以作为提高样本集良好位姿性的整体策略的一部分。

引理 3.12。 *Let $v^\top \bar{\phi}(x)$ be a quadratic polynomial, where $\|v\|_\infty = 1$ and $\bar{\phi}$ is the natural basis (defined by* (3.1) *when $d = 2$). Then*

$$\max_{x \in B(0;1)} |v^\top \bar{\phi}(x)| \;\geq\; \frac{1}{4}.$$

然后，对于任何满足 $\|\bar{v}\| =$ 为 1 的 $\bar{v}$，我们可以将 $\bar{v}$ 最多缩放 $\sqrt{p_1}$倍至 $v = \alpha \bar{v}$，$0 < \alpha \leq \sqrt{p_1}$，使得 $\|v\|_\infty =$ 为 1。因此，

$$\sigma_2 \;=\; \min_{\|\bar{v}\|=1} \max_{x \in B(0;1)} |\bar{v}^\top \bar{\phi}(x)| \;\geq\; \frac{1}{\sqrt{p_1}} \min_{\|v\|_\infty = 1} \max_{x \in B(0;1)} |v^\top \bar{\phi}(x)| \;\geq\; \frac{1}{4\sqrt{p_1}}. \tag{3.10}$$

最后一个不等式是由于将引理3.12应用于形式为$\hat{v}^\top \bar{\phi}(x)$的多项式。对于更高次的多项式，指定$\sigma_\infty$或$\sigma_2$上的界也是可能的，但这超出了本书的范围。

Λ-稳健性以及 $M(\bar{\phi}, \hat{Y})$ 的条件数

我们将展示 Λ-平衡性如何与以下矩阵的条件数相关：

$$\hat{M} \;=\; \begin{bmatrix} 1 & 0 & \cdots & 0 & 0 & 0 & \cdots & 0 & 0 \\ 1 & \hat{y}_1^1 & \cdots & \hat{y}_n^1 & \frac{1}{2}(\hat{y}_1^1)^2 & \hat{y}_1^1 \hat{y}_2^1 & \cdots & \frac{1}{(d-1)!}(\hat{y}_{n-1}^1)^{d-1} \hat{y}_n^1 & \frac{1}{d!}(\hat{y}_n^1)^d \\ \vdots & \vdots & & \vdots & \vdots & \vdots & & \vdots & \vdots \\ 1 & \hat{y}_1^p & \cdots & \hat{y}_n^p & \frac{1}{2}(\hat{y}_1^p)^2 & \hat{y}_1^p \hat{y}_2^p & \cdots & \frac{1}{(d-1)!}(\hat{y}_{n-1}^p)^{d-1} \hat{y}_n^p & \frac{1}{d!}(\hat{y}_n^p)^d \end{bmatrix}.$$

当 ϕ 是自然基$\bar{\phi}$ 时，这个矩阵恰好是矩阵 $M(\phi, \hat{Y})$。

Λ- poisedness 的定义在 $B(y^0;\ \Delta(Y))$ 在使用自然基时意味着，对于所有 $x \in B(y^0;\ \Delta(Y))$，存在一个 $\lambda(x)$ 使得

$$M^\top \lambda(x) \;=\; \bar{\phi}(x) \quad \text{with} \quad \|\lambda(x)\|_\infty \;\leq\; \Lambda.$$

根据引理3.8和3.9，我们知道这等价于断言，对于所有 $x \in B(0;\ 1)$，存在一个 $\lambda(x)$ ，使得

$$\hat{M}^\top \lambda(x) \;=\; \bar{\phi}(x) \quad \text{with} \quad \|\lambda(x)\|_\infty \leq \Lambda.$$

另外，由于 {v*}0; 1{v*} 且至少有一个 {v*} 的范数为1（回忆 {v*}0; 1{v*} 是以原点为中心的最小包围球），因此该矩阵的范数总是被限制在

$$1 \;\le\; \|\hat{M}\| \;\le\; p_1^{\frac{3}{2}}. \tag{3.11}$$

$\hat{M}$ 的条件数记为 cond($\hat{M}$) $= \|\hat{M}\|\|\hat{M}^{-1}\|$。为了用 Λ 来界定 cond($\hat{M}$)，只需界定 $\|\hat{M}^{-1}\|$；反过来，为了用 cond($\hat{M}$) 来界定 Λ，只需用 $\|\hat{M}^{-1}\|$ 来界定它。下面的定理 3.14 建立了这一关系。其证明需要以下（易于证明，见习题）辅助结果。

引理 3.13. *Let w be a (normalized) right-singular vector of (a nonsingular square) matrix A corresponding to its largest singular value. Then, for any vector r of the appropriate size,*

$$\|Ar\| \;\ge\; |w^\top r|\,\|A\|.$$

定理 3.14. *If $\hat{M}$ is nonsingular and $\|\hat{M}^{-1}\| \le \Lambda$, then the set $\hat{Y}$ is $\sqrt{p_1}\Lambda$-poised in the unit ball $B(0;1)$ centered at 0. Conversely, if the set $\hat{Y}$ is Λ-poised in the unit ball $B(0;1)$ centered at 0, then*

$$\|\hat{M}^{-1}\| \;\le\; \theta p_1^{\frac{1}{2}}\Lambda, \tag{3.12}$$

where $\theta > 0$ is dependent on n and d but independent of $\hat{Y}$ and Λ.

Proof. 由于 ℓ_2-范数在转置下保持不变，我们可以在证明中使用$\hat{M}^\top$。如果$\hat{M}$ 是非奇异的且 $\|\hat{M}^{-1}\| \le \Lambda$，那么

$$\|\lambda(x)\|_\infty \;\le\; \|\hat{M}^{-\top}\|_\infty\|\bar{\phi}(x)\|_\infty \;\le\; p_1^{\frac{1}{2}}\|\hat{M}^{-\top}\|\|\bar{\phi}(x)\|_\infty \;\le\; p_1^{\frac{1}{2}}\Lambda,$$

由于 $\max_{x\in B(0;1)}\|\bar{\phi}(x)\|_\infty \le 1$。

为了证明反向关系，设 $\bar{v}$ 为对应于其最大奇异值的$\hat{M}^{-\top}$ 的（归一化）右奇异向量。由于 $\|\bar{v}\| = 1$，我们从引理3.10得知存在一个 $y \in B(0;1)$，使得

$$|\bar{v}^\top\bar{\phi}(y)| \;\ge\; \sigma_2 \;\ge\; \frac{\sigma_\infty}{\sqrt{p_1}}.$$

通过应用引理3.13，使用$A = \hat{M}^{-\top}$、$w = \bar{v}$和$r = \bar{\phi}($ $y)$,

$$\|\hat{M}^{-\top}\bar{\phi}(y)\| \;\ge\; |\bar{v}^\top\bar{\phi}(y)|\,\|\hat{M}^{-\top}\|,$$

结果很容易通过 {v**} 得到。 □

常数 θ 可以针对 d 的特定值进行估计，例如 $d = 1$ 和 $d = 2$。事实上，它与 σ_2 成反比关系，其中

$$\sigma_2 \;=\; \min_{\|\bar{v}\|=1}\max_{x\in B(0;1)}|\bar{v}^\top\bar{\phi}(x)|.$$

因此，正如我们之前所述，容易看出当$d = 1$时，$\theta \leq 1$。对于$d = 2$，我们可以将定理3.14中的常数θ替换为一个上界($\theta \leq 4\sqrt{p_1}$)，这利用引理3.12可以很容易地推导出来。

需要注意的是，θ 取决于 ϕ 的选择。例如，如果我们将$\bar{\phi}$ 的每个元素缩放2倍，那么相应的 θ 将减少2倍。这里我们关注的是在我们算法中出现的特定矩阵 $\hat{M} = M(\bar{\phi},\hat{Y})$ 的条件数，因此也关注 ϕ 的特定选择。

以下定理3.14的推论在第六章中将很有用。为了清晰起见，我们强调所涉及的常数对自然基$\bar{\phi}$的依赖性。

推论 3.15. *If $\hat{Y}$ is Λ-poised in $B(0; 1)$, then* $\mathrm{vol}(\bar{\phi}(\hat{Y})) \geq \Theta(p,\bar{\phi}) > 0$, *where* $\Theta(p,\bar{\phi})$ *depends only on p (i.e., on n and d) and* $\bar{\phi}$.

Proof. 定理3.14保证了存在一个仅依赖于p和$\bar{\phi}$的常数θ，使得$\|M(\bar{\phi}, \hat{Y})^{-1}\| \leq \theta\sqrt{p_1}\Lambda$。由于矩阵行列式的绝对值等于其奇异值的乘积，我们得到

$$\mathrm{vol}(\bar{\phi}(\hat{Y})) = \frac{1}{p_1!\,|\det(M(\bar{\phi},\hat{Y})^{-1})|} \geq \frac{1}{p_1!(\theta\sqrt{p_1}\Lambda)^{p_1}}. \quad \square$$

基于条件数的误差界推导

在关于拉格朗日与牛顿基本多项式基的章节中，我们已经看到了插值多项式与被插值函数之间的误差界限，它们的梯度之间，以及可能的黑塞矩阵之间，这些界限以这些多项式在感兴趣区域的最大绝对值的界来表示。现在，我们将通过$M(\bar{\phi}、\hat{Y})$的条件数来呈现类似的界。由于我们已经展示，$M(\bar{\phi}、\hat{Y})$的条件数与Λ- poisedness有关，我们可以直接利用定理3.14中的界，并以p、θ以及$\|M(\bar{\phi}、\hat{Y})^{-1}\|$来表达误差界，而非$\Lambda$。然而，[53]中界的推导相当复杂，需要逼近论的知识。相比之下，下面所呈现的界的推导非常简单，除微积分外无需其他知识。

我们考虑使用自然基将一个函数$f(y)$用多项式$m(y)$进行插值，表示为：

$$m(y) = \sum_{k=0}^{p} \gamma_k \bar{\phi}_k(y).$$

插值集满足 $Y = \{y^0、y^1、\ldots、y^p\} \subset B(y^0;\ \Delta(Y))$，其中 $B(y^0;\ \Delta(Y))$ 是以 y^0 为中心、半径为 $\Delta = \Delta(Y)$ 且包含 Y 的最小闭球。系数 γ_k、$k = 0$、$\ldots$、p 由插值条件 (3.2) 所导出的线性系统定义。

我们将详细考虑二次情况（$d = 2$）。线性情况（$d = 1$）已在第2.4节中涵盖。在以下假设下，对二次情况下的误差界进行了估计。

假设 3.1。*We assume that $Y = \{y^0、y^1、\ldots、y^p\} \subset \mathbb{R}^n$, with $p_1 = p + 1 = (n + 1)(n + 2)/2$, is a poised set of sample points (in the quadratic interpolation sense, $d = 2$) contained in the ball $B(y^0;\ \Delta(Y))$ of radius $\Delta = \Delta(Y)$.*

Further, we assume that the function f is twice continuously differentiable in an open domain Ω containing $B(y^0;\ \Delta)$ and $\nabla^2 f$ is Lipschitz continuous in Ω with constant $\nu_2 > 0$.

在 th 下 在这些假设下，可以构建二次插值 n 个模型

$$m(y) = c + g^\top y + \frac{1}{2} y^\top H y = c + \sum_{1 \le k \le n} g_k y_k + \frac{1}{2} \sum_{1 \le k,\ell \le n} h_{k\ell} y_k y_\ell, \tag{3.13}$$

其中 H 是一个 n 阶对称矩阵。未知系数 c、g_1、…、g_n 和 $h_{k\ell}$，$1 \le \ell \le k \le n$，由插值条件 (3.2) 唯一确定，因为样本集是适定的。

我们暂时假设，不失一般性，$y^0 = 0$。之后，我们将取消这一假设，并为任何 y^0建立插值界。

我们现在考虑球 B(0 中的一点y；$\Delta(Y)$)，对此我们将尝试估计函数值中的误差

$$m(y) = f(y) + e^f(y), \tag{3.14}$$

在梯度中

$$\nabla m(y) = Hy + g = \nabla f(y) + e^g(y), \tag{3.15}$$

-其次，由于我们正在考虑二次情形，也在 Hes 中 西安

$$H = \nabla^2 f(y) + E^H(y).$$

由于 f 和 m 的海森矩阵是对称的，我们只需考虑对角线元素及对角线下方元素的二阶导数误差：

$$h_{k\ell} = \nabla^2_{k\ell} f(y) + E^H_{k\ell}(y), \quad 1 \le \ell \le k \le n.$$

利用 (3.13) 并从 (3.2) 中的所有 $p_1 = p + 1$ 个等式中减去 (3.14)，我们得到

$$\begin{aligned}(y^i - y)^\top g + \frac{1}{2}(y^i - y)^\top H (y^i - y) + (y^i - y)^\top H y \\ = f(y^i) - f(y) - e^f(y), \quad i = 0, \ldots, p.\end{aligned}$$

将(3.15)中g的表达式代入，重新组合各项，并应用二阶泰勒展开公式，我们得到

$$\begin{aligned}(y^i - y)^\top e^g(y) + \frac{1}{2}(y^i - y)^\top [H - \nabla^2 f(y)](y^i - y) \\ = \mathcal{O}(\Delta^3) - e^f(y), \quad i = 0, \ldots, p.\end{aligned} \tag{3.16}$$

下一步是从其他方程中减去（3.16）中的第一个方程，消去$e^f(y)$并得到（注意$y^0 = 0$）

$$(y^i)^\top (e^g(y) - E^H(y) y) + \frac{1}{2}(y^i)^\top [H - \nabla^2 f(y)](y^i) = \mathcal{O}(\Delta^3), \quad 1 \le i \le p.$$

因此，在这种二次情形下，我们需要分析的线性系统可以写为

$$\begin{aligned}\sum_{1 \le k \le n} y^i_k t_k(y) + \frac{1}{2} \sum_{1 \le k \le n} (y^i_k)^2 E^H_{kk}(y) + \sum_{1 \le \ell < k \le n} [y^i_k y^i_\ell] E^H_{k\ell}(y) \\ = \mathcal{O}(\Delta^3), \quad 1 \le i \le p,\end{aligned}$$

或者，以矩阵形式表示，为

$$Q\begin{bmatrix} t(y) \\ e^H(y) \end{bmatrix} = \mathcal{O}(\Delta^3), \tag{3.17}$$

使用

$$t(y) = e^g(y) - E^H(y)y = e^g(y) - [H - \nabla^2 f(y)]y. \tag{3.18}$$

这里 $e^H(y)$ 是维度为 $n + n(n-1)/2$ 的向量，存储元素 $E^H_{kk}(y)$、$k = 1$、…、n 和 $E^H_{k\ell}(y)$，$1 \le \ell < k \le n$。

注意，当 $d =$ 为 2（二次）且 $y^0 =$ 为 0 时，矩阵 Q 与由 $M(\bar{\phi}$ 的最后 p 行和列形成的矩阵相同，即 Y)，前提是 $e^H(y)$ 被适当地排序，我们此后将假定如此。

我们将估计(3.17)中右侧向量的上界。该向量的每个元素是两个项的差，这两个项分别可由$\nu_2\|y^i - y\|^3/6$和$\nu_2\|y\|^3/6$界定，其中ν_2是$\nabla^2 f$在Ω (中的Lipschitz常数，参见[76, 引理4.1.14])。由于$\|y^i - y\| \le 2\Delta$和$\|y\| \le \Delta$，该差可由$3\Delta^3/2$界定。因此，右侧向量的ℓ_∞-范数可由该量界定，而ℓ_2-范数的上界为

$$\left\| Q\begin{bmatrix} t(y) \\ e^H(y) \end{bmatrix} \right\| \le \frac{3}{2} p^{\frac{1}{2}} \nu_2 \Delta^3. \tag{3.19}$$

为了消除Q对Δ的依赖，我们需要考虑缩放矩阵

$$\hat{Q} = Q\begin{bmatrix} D_\Delta^{-1} & 0 \\ 0 & D_{\Delta^2}^{-1} \end{bmatrix}, \tag{3.20}$$

其中 D_Δ 是一个维度为 n 的对角矩阵，对角元为 Δ，而 D_{Δ^2} 是一个维度为 $p-n$ 的对角矩阵，对角元为 Δ^2。这个缩放后的矩阵与对应于缩放集$\hat{Y} = Y/\Delta \subset B(0;1)$ 的矩阵 Q 相同。

下一个定理给出了二次情形下的误差界。正如人们所预料的那样，误差界对于二阶导数是关于 Δ 线性的，对于一阶导数是关于 Δ 二次的，而对于函数值则是关于 Δ 三次的，其中 $\Delta = \Delta(Y)$ 是包含 Y 的最小球的半径。$\|\hat{Q}^{-1}\|$ 越小，Y 的适定性就越好，误差界也越好。

定理 3.16。*Let Assumption* 3.1 *hold. Then, for all points* y *in* $B(y^0;\ \Delta(Y))$*, we have that*

- *the error between the Hessian of the quadratic interpolation model and the Hessian of the function satisfies*

$$\|\nabla^2 f(y) - \nabla^2 m(y)\| \le \kappa_{eh}\,\Delta,$$

- *the error between the gradient of the quadratic interpolation model and the gradient of the function satisfies*

$$\|\nabla f(y) - \nabla m(y)\| \le \kappa_{eg}\,\Delta^2,$$

- *the error between the quadratic interpolation model and the function satisfies*

$$|f(y) - m(y)| \le \kappa_{ef}\,\Delta^3,$$

where κ_{eh}, κ_{eg}, and κ_{ef} are given by

$$\begin{aligned}\kappa_{eh} &= 3\sqrt{2}p^{\frac{1}{2}}\nu_2\|\hat{Q}^{-1}\|/2,\\ \kappa_{eg} &= 3(1+\sqrt{2})p^{\frac{1}{2}}\nu_2\|\hat{Q}^{-1}\|/2,\\ \kappa_{ef} &= (6+9\sqrt{2})p^{\frac{1}{2}}\nu_2\|\hat{Q}^{-1}\|/4+\nu_2/6.\end{aligned}$$

Proof. 让我们首先假设 $y^0 = 0$，并将系统（3.17）的左侧写成如下形式：

$$Q\begin{bmatrix} D_{\Delta}^{-1} & 0 \\ 0 & D_{\Delta^2}^{-1}\end{bmatrix}\begin{bmatrix} D_{\Delta}t(y) \\ D_{\Delta^2}e^H(y)\end{bmatrix}.$$

然后，利用界(3.19)和记号(3.20)，我们得到

$$\left\|\begin{bmatrix} D_{\Delta}t(y) \\ D_{\Delta^2}e^H(y)\end{bmatrix}\right\| \leq \frac{3}{2}p^{\frac{1}{2}}\nu_2\|\hat{Q}^{-1}\|\Delta^3, \tag{3.21}$$

从中我们得到

$$\|D_{\Delta^2}e^H(y)\| \leq \frac{3}{2}p^{\frac{1}{2}}\nu_2\|\hat{Q}^{-1}\|\Delta^3,$$

得到界 $\|e^H(y)\| \leq (3/2)p^{\frac{1}{2}}\nu_2\|\hat{Q}^{-1}\|\Delta$。因此 Hessian 矩阵中的误差由下式给出

$$\|E^H(y)\| \leq \|E^H(y)\|_F \leq \sqrt{2}\|e^H(y)\| \leq \frac{3\sqrt{2}}{2}p^{\frac{1}{2}}\nu_2\|\hat{Q}^{-1}\|\Delta,$$

其中 $\|\cdot\|_F$ 表示矩阵的 Frobenius 范数，由所有元素的平方和的平方根给出。

现在我们想推导出$\|e^g(y)\|$的界限。由(3.21)我们同样有

$$\|D_{\Delta}t(y)\| \leq \frac{3}{2}p^{\frac{1}{2}}\nu_2\|\hat{Q}^{-1}\|\Delta^3$$

和

$$\|t(y)\| \leq \frac{3}{2}p^{\frac{1}{2}}\nu_2\|\hat{Q}^{-1}\|\Delta^2,$$

因此，从 (3.18) 出发，

$$\begin{aligned}\|e^g(y)\| &\leq \|t(y)\| + \|E^H(y)\|\|y\|\\ &\leq \tfrac{3}{2}p^{\frac{1}{2}}\nu_2\|\hat{Q}^{-1}\|\Delta^2 + \left(\tfrac{3\sqrt{2}}{2}p^{\frac{1}{2}}\nu_2\|\hat{Q}^{-1}\|\Delta\right)\Delta\\ &= \tfrac{3(1+\sqrt{2})}{2}p^{\frac{1}{2}}\nu_2\|\hat{Q}^{-1}\|\Delta^2.\end{aligned}$$

这里我们使用了这样一个事实：y 位于以原点为中心的球 $B(0;\, \Delta(Y))$ 内。

最后，从（3.16）的详细版本中，对于$i=0$以及$\|e^g(y)\|$和$\|E^H(y)\|$的界限，我们得到

$$\begin{aligned}|e^f(y)| &\leq \|e^g(y)\|\Delta+\tfrac{1}{2}\|E^H(y)\|\Delta^2+\tfrac{\nu_2}{6}\Delta^3\\ &\leq \tfrac{6+9\sqrt{2}}{4}p^{\frac{1}{2}}\nu_2\|\hat{Q}^{-1}\|\Delta^3+\tfrac{\nu_2}{6}\Delta^3.\end{aligned}$$

如果$y^0\neq 0$，我们将进行变量替换并考虑一个函数$\hat{f}(z)=f(z+y^0)$与$z=y-y^0$。然后我们可以应用之前证明的结果，因为平移后的插值集$\{0、y^1-y^0、\ldots、y^p-y^0\}$现在以原点为中心，并且$\hat{f}$具有适当的平滑性，从而推导出$\|\nabla^2\hat{f}(z)-\nabla^2\hat{m}(z)\|$、$\|\nabla\hat{f}(z)-\nabla\hat{m}(z)\|$和$|\hat{f}(z)-\hat{m}(z)|$的界限。现在我们定义$m(y)=\hat{m}(y^0+z)$并将函数和多项式模型改回原始变量。很容易看出，由于$\nabla^2\hat{m}(z)=\nabla^2m(y)$、$\nabla^2\hat{f}(z)=\nabla^2f(y)$、$\nabla\hat{m}(z)=\nabla m(y)$和$\nabla\hat{f}(z)=\nabla f(y)$，我们得到了所需的界限。 □

由于$\|\hat{Q}^{-1}\|\leq\|\hat{M}^{-1}\|$ (参见习题)，可以利用定理3.14，将上述定理中给出的误差界用Λ- poisedness定义中所使用的常数Λ来表示。

这里给出的二次插值的误差界可以推广到任意次数的插值（关于三次情形的推广见[63]）。

3.5 练习题

1. 证明如果对于某个基ϕ，$M(\phi, Y)$是非奇异的，那么对于$\mathcal{P}_n^d$的任意基，它也是非奇异的。

2. 证明对于任何给定的平衡插值集Y，可以选择基ϕ，使得$M(\phi、Y)$的条件数可以等于1到$+\infty$之间的任何数。

3. 在$\mathbb{R}^2$中为集合$y^0=(0,0), y^1=(1,0), y^2=(0,1), y^3=(-1,0), y^4=(1,1)$和$y^5=(0,-1)$构造一组拉格朗日多项式。将该集合的$\Lambda$- poisedness常数与3.2节中提到的集合相关的常数进行比较。

4. 证明圆上六点在$\mathbb{R}^2$中对于二次多项式插值不是稳定的，但对于不含二次项和常数项的三次多项式子空间中的插值是稳定的。

5. 给定$\mathcal{P}_n^d$，证明(3.3)中的$\lambda(x)$不依赖于ϕ的选择。

6. 证明引理3.5。

7. 证明引理3.7。

8. 证明由(3.9)给出的$\psi(v)$是向量空间v中的一个范数。9. 证明对于$\|\hat{M}\|$，界(3.11)成立。10. 证明引理3.13。11. 证明$\|\hat{Q}^{-1}\|\leq\|\hat{M}^{-1}\|$。

第4章

回归非线性模型

让我们再次考虑 $\mathcal{P}_n^d$，即 $\mathbb{R}^n$ 中次数小于或等于 d 的多项式空间。设 $q_1 = q + 1$ 为该空间的维数，并设 $\phi = \{\phi_0(x)、\phi_1(x)、\ldots、\phi_q(x)\}$ 为 $\mathcal{P}_n^d$ 的一组基。给定多项式基 ϕ，我们像之前一样定义 $\phi(x) = [\phi_0(x), \phi_1(x), \ldots, \phi_q(x)]^\top$ 为 $\mathbb{R}^{q_1}$ 中的一个向量。如前所述，$Y = \{y^0、y^1、\ldots、y^p\} \subset \mathbb{R}^n$ 表示 $p_1 = p + 1$ 个采样点的集合。设 $f(Y)$ 表示其元素为 $f(y^i)、i = 0、\ldots、p$ 的向量。我们将考虑多项式空间的维数 q_1 固定但采样点数量 p_1 可以变化的背景。

已知无导数优化应用中有很大一部分存在噪声函数。在某种程度上，大多数无导数方法都是基于在若干相距足够远的点上对目标函数进行采样。这种方法本身使得许多无导数方法能够对噪声具有合理的容忍度。然而，人们可能更倾向于在设计算法时考虑到噪声的存在。

处理噪声数据的第一种、也许也是最自然的方法是用最小二乘回归代替目标函数的插值。在这种情况下，前一章中描述的插值条件，

$$M(\phi, Y)\alpha \;=\; f(Y),$$

以最小二乘意义求解，即找到一个解 α，使得 $\|M(\phi、Y)\alpha - f(Y)\|^2$ 最小化。

如果函数求值相对便宜但仍然有噪声，那么在更多的局部样本点（即更接近模型“中心”的点）上对目标函数进行采样可能比完全插值所需的点更有效。在这种情况下，$p_1 > q_1$，这意味着矩阵$M(\phi、Y)$中的行数大于列数，插值系统是超定的。随着样本点数量的增加，对噪声问题的最小二乘回归解（在某种意义下并在合理假设下）会收敛到潜在真实函数的最小二乘回归。

具体而言，设噪声函数为 $f(x) = f_{smooth}(x) + \varepsilon$，其中 $f_{smooth}(x)$ 是我们试图优化的真实且最可能平滑的函数，ε 是一个随机变量，独立于 x，并从均值为零的某个分布中抽取。假设多项式基 ϕ 是固定的，并考虑一个样本集 Y^p，其大小 $|Y^p| = p +$ 为 1

变种 le. 设随机向量 α^p 为以下的最小二乘解：th 电子系统

$$M(\phi, Y^p)\alpha \;=\; f(Y^p)$$

而实向量 α^p_{smooth} 是该系统的最小二乘解

$$M(\phi, Y^p)\alpha \;=\; f_{smooth}(Y^p).$$

现在假设样本集 Y^p 的大小趋于无穷大，并且满足以下条件：

$$\liminf_{p\to+\infty} \lambda_{min}\left(\frac{1}{p+1} M(\phi, Y^p)^\top M(\phi, Y^p)\right) \;>\; 0, \tag{4.1}$$

其中 λ_{min} 表示矩阵的最小特征值。那么，下述一致性结果的证明就很简单了（参见本章末的习题以及书籍[116, 224]以获取更多细节）。

定理 4.1。*If condition* (4.1) *holds and the sequence* $\{Y^p\}$ *is bounded, then*

$$\mathbf{E}(\alpha^p) \;=\; \alpha^p_{smooth} \quad \forall p \geq q$$

and

$$\lim_{p\to+\infty} \mathbf{Var}(\alpha^p - \alpha^p_{smooth}) \;=\; 0.$$

关于集合序列 Y^p 的条件 (4.1) 意味着数据是以均匀良好平衡的方式采样的。我们将在研究超定集合 Y 的平衡性质时回到这一点。

当函数评估成本高昂时，很少能承担得起积累足够多的局部样本点，以超过完整二次插值所需的点数，即$((n+1)(n+2)/2)$。在这种情况下，最小二乘回归与插值将产生相同的结果。但即便如此，放宽插值条件也可能是有益的。如果目标函数噪声很大，那么插值模型可能会显得不必要的“不平滑”。此时，可以采用正则化回归，它试图同时权衡优化最小二乘拟合与插值多项式的“平滑度”。我们将在本章末尾进一步探讨这些想法。

本章完全致力于讨论 {v*} 的情形。首先，我们将讨论最小二乘模型的性质以及相应的适定样本集。

4.1 多项式最小二乘回归的基本概念

令 $m(x)$ 表示次数不超过 d 的多项式，该多项式通过在 Y 中的点处对给定函数 $f(x)$ 进行最小二乘回归来近似。由于 ϕ 是 $\mathcal{P}^d_n$ 中的一组基，因此 $m(x) = \sum_{k=0}^q \alpha_k \phi_k(x)$，其中 α_k 是未知系数。系数 α 可由最小二乘回归条件确定

$$M(\phi, Y)\alpha \overset{\ell.s.}{=} f(Y) \tag{4.2}$$

或者，等价地，{v*}

$$\min_{\alpha} \|M(\phi, Y)\alpha - f(Y)\|^2.$$

上述系统具有唯一解，如果矩阵

$$M(\phi, Y) = \begin{bmatrix} \phi_0(y^0) & \phi_1(y^0) & \cdots & \phi_q(y^0) \\ \phi_0(y^1) & \phi_1(y^1) & \cdots & \phi_q(y^1) \\ \vdots & \vdots & \vdots & \vdots \\ \vdots & \vdots & \vdots & \vdots \\ \phi_0(y^p) & \phi_1(y^p) & \cdots & \phi_q(y^p) \end{bmatrix} \tag{4.3}$$

具有满列秩。

容易看出，如果 $M(\phi、Y)$ 是方阵且非奇异，那么上述问题就变成了插值问题。在许多方面，回归的性质恰好或密切地模仿了插值的性质。正如插值的情形一样，如果对于 ϕ 的某个选择，$M(\phi、Y)$ 具有满列秩，那么对于 $\mathcal{P}_n^d$ 的任意基都是如此。因此，以下关于适定性的定义与所选的基无关。

定义 4.2。*The set* $Y = \{y^0, y^1, \ldots, y^p\}$ *is poised for polynomial least-squares regression in* $\mathbb{R}^n$ *if the corresponding matrix* $M(\phi, Y)$ *has full column rank for some basis* ϕ *in* $\mathcal{P}_n^d$.

我们现在证明，如果 Y 已就位，则最小二乘回归多项式是唯一的，且独立于 ϕ 的选择。

引理 4.3。*Given a function* $f\colon \mathbb{R}^n \to \mathbb{R}$ *and a poised set* $Y \in \mathbb{R}^n$ *with respect to polynomial least-squares regression, the least-squares regression polynomial* $m(x)$ *exists and is unique.*

Proof. 由于该集合是稳定的，显然对于给定的基选择，最小二乘回归多项式$m(x)$存在且唯一。现在考虑两个不同的基$\psi(x)$和$\phi(x)$，它们通过$\psi(x) = P^\top \phi(x)$相关联，其中P是$q_1 \times q_1$且非奇异。那么$M(\psi, Y) = M(\phi, Y)P$。

设 α_ϕ（分别为基 $\phi(x)$（和 $\psi(x)$）的最小二乘回归多项式的系数向量，α_ψ）亦然。由于 α_ϕ 是系统 $M(\phi、Y)\alpha = f(Y)$ 的最小二乘解，则

$$\begin{aligned} \alpha_\phi &= [M(\phi, Y)^\top M(\phi, Y)]^{-1} M(\phi, Y)^\top f(Y) \\ &= [P^{-\top} M(\psi, Y)^\top M(\psi, Y) P^{-1}]^{-1} P^{-\top} M(\psi, Y)^\top f(Y) \\ &= P[M(\psi, Y)^\top M(\psi, Y)]^{-1} M(\psi, Y)^\top f(Y) = P\alpha_\psi. \end{aligned}$$

最后一个等式源于这样一个事实：α_ψ 是系统 $M(\psi、Y)\alpha = f(Y)$ 的最小二乘解。那么，对于任何 x，

$$\alpha_\psi^\top \psi(x) = \alpha_\psi^\top \left(P^\top \phi(x)\right) = \left(P\alpha_\psi\right)^\top \phi(x) = \alpha_\phi^\top \phi(x). \quad \square$$

4.2 回归意义上的拉格朗日多项式

平衡条件及回归多项式的存在性，在实际算法中，或是推导用于无导数算法收敛性分析的“统一”误差界时，并不充分。正如插值情形，需要一种以常数为特征的“良好平衡”条件。我们将把Λ-平衡性和拉格朗日多项式的概念扩展到多项式最小二乘回归的情形。

拉格朗日多项式

定义4.4。*Given a set of sample points* $Y = \{y^0, \ y^1, \ \ldots, \ y^p\}$, *with* $p > q$, *a set of* $p_1 = p + 1$ *polynomials* $\ell_j(x)$, $j = 0, \ \ldots,$
p, in $\mathcal{P}_n^d$ *is called a set of regression Lagrange polynomials if*

$$\ell_j(y^i) \overset{\ell.s.}{=} \delta_{ij} \ = \ \begin{cases} 1 & \text{if } \ i = j, \\ 0 & \text{if } \ i \neq j. \end{cases} \tag{4.4}$$

这组多项式是传统拉格朗日多项式向 $p > q$ 情形的扩展。显然，这些多项式不再线性无关，因为它们的数量太多了。然而，如下所示，插值拉格朗日多项式的许多其他性质仍然保持。引理4.3蕴含以下结果。

引理 4.5. *If* Y *is poised for polynomial least-squares regression, then the set of regression Lagrange polynomials exists and is uniquely defined.*

拉格朗日多项式的另一个基本性质也适用于回归情形。[5]

引理 4.6. *For any function* f: $\mathbb{R}^n \to \mathbb{R}$ *and any poised set* $Y = \{y^0, \ y^1, \ \ldots,$
$y^p\} \subset \mathbb{R}^n$ *for*
polynomial least-squares regression, the unique polynomial $m(x)$ *that approximates* $f(x)$
via least-squares regression at the points in Y *can be expressed as*

$$m(x) \ = \ \sum_{i=0}^{p} f(y^i)\ell_i(x),$$

where $\{\ell_i(x), \ i = 0, \ \ldots, \ p\}$ *is the set of regression Lagrange polynomials for* Y.

Proof. 多项式 $m(x)$ 可以写成

$$\sum_{i=0}^{q} \alpha_i \phi_i(x) \ = \ \alpha^\top \phi(x),$$

其中 α 是该系统的最小二乘解

$$M(\phi, Y)\alpha \ = \ f(Y).$$

[5] It is interesting to note that the extension of Lagrange polynomials applies only to the case of least-squares regression. In the case of ℓ_1-norm regression, for instance, the uniqueness property fails and $m(x) = \sum_{i=0}^{p} f(y^i)\ell_i(x)$ may fail to hold for any choice of $\ell_i(x)$, $i = 0, \ldots, p$.

由于 Y 是 预备好，从最小二乘解的表达式，我们知 现在那个

$$\alpha \;=\; [M(\phi,Y)^\top M(\phi,Y)]^{-1} M(\phi,Y)^\top f(Y). \tag{4.5}$$

我们可以使用基 ϕ 和某个系数向量 $a_\phi^j \in \mathbb{R}^{q_1}$ 来表示第 j 个拉格朗日多项式:

$$\ell_j(x) \;=\; \phi(x)^\top a_\phi^j.$$

然后，拉格朗日回归条件（4.4），在最小二乘意义下，可以写成以下矩阵形式:

$$M(\phi,Y)a_\phi^j \overset{\ell.s.}{=} e_{j+1}, \quad j=0,\ldots,p,$$

其中 e_{j+1} 是阶为 $p+1$ 的单位矩阵的第 $(j+1)$ 列。用矩阵表示法表示，我们有

$$M(\phi,Y)A_\phi \overset{\ell.s.}{=} I,$$

其中 A_ϕ 是列为 a_ϕ^j、$j=0$、…、p 的矩阵。由这些最小二乘问题的解，我们有

$$A_\phi \;=\; [M(\phi,Y)^\top M(\phi,Y)]^{-1} M(\phi,Y)^\top. \tag{4.6}$$

因此，由（4.5）中α的表达式,

$$\alpha^\top \phi(x) \;=\; f(Y)^\top A_\phi^\top \phi(x) = f(Y)^\top \ell(x),$$

其中 $\ell(x) = [\ell_0(x)、\ldots、\ell_p(x)]^\top$。 □

为了说明回归拉格朗日多项式，我们考虑与第3.2节示例中相同的六个插值点 $y^0=(0,0)$，$y^1=(1,0)$，$y^2=(0,1)$，$y^3=(2,0)$，$y^4=(1,1)$，和$y^5=(0,2)$，并添加一个额外的点$y^6=(0.5,0.5)$，使插值成为超定。手动验证回归拉格朗日多项式的正确性是困难的，因为它们在对应点上的值不再必须等于1或0。以下是相应的回归拉格朗日多项式$\ell_j(x_1,\ x_2)$，$j=0,\ \ldots,\ 6$，其系数是借助MATLAB® [1]软件计算的:

$$\begin{aligned}
\ell_0(x_1,x_2) &= 1-\tfrac{3}{2}x_1-\tfrac{3}{2}x_2+\tfrac{1}{2}x_1^2+\tfrac{1}{2}x_2^2+x_1x_2,\\
\ell_1(x_1,x_2) &= \tfrac{5}{3}x_1-\tfrac{1}{3}x_2-0.823x_1^2+0.176x_2^2-0.764x_1x_2,\\
\ell_2(x_1,x_2) &= -\tfrac{1}{3}x_1+\tfrac{5}{3}x_2+0.176x_1^2-0.823x_2^2-0.764x_1x_2,\\
\ell_3(x_1,x_2) &= -\tfrac{5}{12}x_1+\tfrac{1}{12}x_2+0.455x_1^2-0.044x_2^2-0.588x_1x_2,\\
\ell_4(x_1,x_2) &= -\tfrac{1}{6}x_1-\tfrac{1}{6}x_2+0.088x_1^2+0.088x_2^2+1.117x_1x_2,\\
\ell_5(x_1,x_2) &= \tfrac{1}{12}x_1-\tfrac{5}{12}x_2-0.044x_1^2+0.455x_2^2-0.588x_1x_2,\\
\ell_6(x_1,x_2) &= \tfrac{2}{3}x_1+\tfrac{2}{3}x_2-0.352x_1^2-0.352x_2^2-0.47x_1x_2.
\end{aligned}$$

这些回归拉格朗日多项式在其对应回归点处的值分别为 $\ell_0(y^0)=1$、$\ell_1(y^1)=0.84$、$\ell_2(y^2)=0.84$、$\ell_3(y^3)=0.99$、$\ell_4(y^4)=0.96$、$\ell_5(y^5)=0.99$ 和 $\ell_6(y^6)=0.37$。

等效去 回归中拉格朗日多项式的定义 离子情况

回忆第3章(3.3)中给出的(插值)拉格朗日多项式的另一种定义。我们将展示这种替代定义如何扩展到回归拉格朗日多项式。

给定一个处于平衡位置的集合 $Y = \{y^0、y^1、\ldots、y^p\} \subset \mathbb{R}^n$，以及 $p > q$ 和 $x \in \mathbb{R}^n$，我们可以将向量 $\phi(x)$ 用向量 $\phi(y^i)$、$i = 0$、…、p 表示为

$$\sum_{i=0}^{p} \lambda_i(x)\phi(y^i) \;=\; \phi(x) \tag{4.7}$$

或者，等价地，{v*}

$$M(\phi, Y)^\top \lambda(x) = \phi(x), \quad \text{where } \lambda(x) = [\lambda_0(x), \ldots, \lambda_p(x)]^\top.$$

与第3章中的类似系统不同，这个新系统是欠定的，因此可能有多个解。为了确立唯一性，我们考虑最小ℓ_2-范数解。因此，我们关注最小范数解$\lambda(x)$以及该范数的界限。正如在插值情形中，满足(3.3)的$\lambda(x)$恰好是对应的（插值）拉格朗日多项式，在回归意义上也是如此，满足(4.7)最小ℓ_2-范数解的$\lambda(x)$是对应的（回归）拉格朗日多项式。事实上，当Y处于平衡状态时，矩阵$M(\phi、Y)$具有满列秩，并且根据(4.7)最小范数解的定义，我们有

$$\lambda(x) \;=\; M(\phi, Y)[M(\phi, Y)^\top M(\phi, Y)]^{-1}\phi(x),$$

并且，正如我们在引理4.6的证明中所见，回归拉格朗日多项式满足

$$\lambda(x) \;=\; M(\phi, Y)[M(\phi, Y)^\top M(\phi, Y)]^{-1}\phi(x) \;=\; \ell(x).$$

然而，请注意，由(3.6)给出的替代定义——通过集合Y和$Y_i(x) = Y \setminus \{y^i\} \cup \{x\}$的体积比来定义拉格朗日多项式的值——似乎不能直接扩展到回归情形。

4.3 回归意义下的 $\mathbf{\Lambda}$ 稳定性

与插值情形一样，区域B中Lagrange多项式绝对值的上界是Y在B中经典poisedness度量，并且是回归近似误差界中出现的一个常数。[53]中的结果可推广到最小二乘回归多项式，并且已知对于凸包Y中的任意x

$$|f(x) - m(x)| \;\le\; \frac{1}{(d+1)!} v_d \sum_{i=0}^{p} \|y^i - x\|^{d+1} |\ell_i(x)|, \tag{4.8}$$

其中 v_d 是 f 和 $\ell_i(x)$ 的 $d+1$ 阶导数的上界，$i = 0$，…，p 是回归拉格朗日多项式。如第 3 章所述并在 [53] 中给出的相应导数误差界也适用于回归情形。就本章而言，我们将界 (4.8) 重写为两种可能形式。

Λ-平衡性

首先，如第3章所述，我们有

$$|f(x)-m(x)| \leq \frac{1}{(d+1)!} v_d p_1 \Lambda_\ell \Delta^{d+1}, \tag{4.9}$$

其中

$$\Lambda_\ell = \max_{0\leq i\leq p} \max_{x\in B(Y)} |\ell_i(x)|,$$

¬πd Δ 是包含 Y 的最小球的直径 $B(Y)$。

这一界限表明，平衡性的度量应涉及对 Λ_ℓ 的界限，类似于插值情况。然而，请注意，在回归情况下，Λ_ℓ 并非界限中唯一依赖于样本集的元素。点数 p_1 也可能变化。一个简单的解决方案是对 p_1 加以界定；然而，正是通过使 p_1 变得很大，我们才能为含噪问题建立更精确的模型，正如本章开头所讨论的。因此，即使现实中拥有大样本集并不实际，对样本点数量引入人为界限或许也不合适。另一方面，有些情况下这种界限会自然出现。由于函数评估的成本，除了常规插值集之外，可能只有少量额外样本点可用。虽然人们可能希望利用这些点来提高模型的精度，但可能不想担心这些额外点的平衡性。因此，我们将讨论 Λ-平衡性的两种定义：一种针对 p 固定、因而只需对 Λ_ℓ 加以界限的情况，另一种针对允许 p 增大的情况。我们从 p 固定的情况开始。

定义 4.7. *Let $\Lambda > 0$ and a set $B \in \mathbb{R}^n$ be given. Let $\phi = \{\phi_0(x), \phi_1(x), \ldots, \phi_q(x)\}$, with $p > q$, be a basis in $\mathcal{P}_n^d$. A poised set $Y = \{y^0, y^1, \ldots, y^p\}$ is said to be Λ-poised in B (in the regression sense) if and only if*

1. *for the set of regression Lagrange polynomials associated with Y*

$$\Lambda \geq \max_{0\leq i\leq p} \max_{x\in B} |\ell_i(x)|,$$

or, equivalently,

2. *for any $x \in B$ the minimum ℓ_2-norm solution $\lambda(x) \in \mathbb{R}^{p_1}$ of*

$$\sum_{i=0}^{p} \lambda_i(x)\phi(y^i) = \phi(x)$$

satisfies $\|\lambda(x)\|_\infty \leq \Lambda$。

注意，如同第3章插值的Λ- poisedness定义中那样，集合B并不要求包含样本集Y。当$p = q$时，插值和回归的Λ-poisedness定义一致。当$p > q$时，容易看出，如果集合Y包含一个由q_1个点组成的子集，该子集是Λ- poised，那么整个集合Y至少是$\sqrt{q_1}$Λ- poised。以下定理确立了Λ- poised回归集Y与Y子集的Λ-poisedness之间的反向关系。

定理 4.8. *Given a set* $Y = \{y^0、\ y^1、\ \ldots、\ y^p\}$*, which is* Λ*-poised in the regression sense, there is a subset of* $q_1 = q + 1$ *points in* Y *which is* $(p_1 - q_1 + 1$ $)\Lambda$*-poised in the interpola- tion sense.*

定理4.8的证明依据插值与回归意义下Λ- poisedness的定义，以及本章末尾给出的引理4.14。

大多数在插值意义下的Λ- poisedness 性质很容易推广到回归情形。

引理 4.9. *If* Y *is* Λ*-poised in a given set* B*, then*

1. *it is* Λ*-poised (with the same constant) in any subset of* B*,*
2. *it is* $\tilde{\Lambda}$*-poised in* B *for any* $\tilde{\Lambda} \geq \Lambda$*,*
3. *for any* $x \in \mathbb{R}^n$*, if* $\lambda(x)$ *is a solution of* (4.7)*, then*

$$\sum_{i=0}^{p} \lambda_i(x) \ = \ 1,$$

4. $\hat{Y} = Y/\Delta$ *is* Λ*-poised in* $\hat{B} = B/\Delta$ *for any* $\Delta > 0$ *,*
5. $Y_a = \{y^0 + a、\ y^1 + a、\ \ldots、\ y^p + a\}$ *is* Λ*-poised in* $B_a = B + \{a\}$ *for any* $a \in \mathbb{R}^n$*.*

然而，对于回归情况，如果 B 包含 Y 中的一个点，并且 Y 在 B 中是 Λ 稳定的，那么 $\Lambda \geq 1$，这不再成立。

强$\boldsymbol{\Lambda}$- poisedness

当优化算法所使用的每个回归模型的样本点数量是有界的（且为中等规模）时，上述集合上的Λ- poisedness条件足以建立类似泰勒的误差界，从而确保收敛性质（见第10章）。但当p允许任意增大时，为了使误差界(4.9)有用，我们需要对任何我们希望考虑用于精确逼近的样本集的乘积$p_1\Lambda_\ell$有一个统一的界限。这样的界限不仅出于理论目的需要，而且作为一个实用条件，以防止回归多项式与真实函数之间的误差增长。

因此，Λ- poisedness 的定义需要加强，当样本点数量变得过大时，需将其纳入考量。由于通过 $\lambda(x)$ 定义拉格朗日多项式涉及到最小化 $\lambda(x)$ 的 ℓ_2-范数，而非 ℓ_∞-范数，我们发现将误差界(4.8)重写为以下形式更为便捷：

$$|f(x) - m(x)| \ \leq \ \frac{1}{(d+1)!} \nu_d \sqrt{p_1} \Lambda_{\ell,2} \Delta^{d+1},$$

其中

$$\Lambda_{\ell,2} \ = \ \max_{x \in B(Y)} \|\ell(x)\|.$$

与其限制$p_1\Lambda_\ell$，为了保持误差界限受控，等价于限制$\sqrt{p_1}\Lambda_{\ell,2}$。如果$p$增长，我们需要考虑这样的样本集，其拉格朗日多项式的ℓ_2-范数按比例减小至$1/\sqrt{p_1}$。让我们首先研究这样的集合是否存在。

为简化起见，我们仅考虑点数 p_1 为多项式空间维度 q_1 的整数倍的样本集。我们可以将这样的样本集 Y 划分为 $l = p_1/q_1$ 个大小为 q_1 的子集，例如 Y_1、Y_2、…、Y_l。每个子集都可以视为一个插值集，因为它具有正确的点数。现在假设每个这样的集合在给定区域 B 中对于某个 $\Lambda > 1$ 是 Λ- poised 的。这意味着，对于任何 $x \in B$ 和任何 $j = 1$，…、l，我们有

$$\sum_{i=0}^{q} \lambda_i^j(x)\phi(y_j^i) = \phi(x), \quad \|\lambda^j(x)\| \le \sqrt{q_1}\|\lambda^j(x)\|_\infty \le \sqrt{q_1}\Lambda,$$

其中 y_j^i 是集合 Y_j 的第 i 个点，而 $\lambda_i^j(x)$ 是插值集 Y_j (的拉格朗日多项式基的第 i 个元素{见第3.2节)}。现在，让我们将这些表达式分别除以 l 并相加。我们得到的结果是

$$\sum_{j=1}^{l}\sum_{i=0}^{q} \frac{1}{l}\lambda_i^j(x)\phi(y_j^i) = \phi(x), \quad \|\lambda^j(x)/l\| \le \frac{\sqrt{q_1}}{l}\Lambda.$$

因此，对于整个样本集 Y，存在 (4.7) 的一个解 $\bar{\lambda}_i(x)$、$i = 0$、…、p_1，它是通过拼接向量 $\lambda^j(x)$、$j = 1$、…、l，并将每个分量除以 l 得到的，使得

$$\|\bar{\lambda}(x)\| \le \sqrt{l}\left(\frac{\sqrt{q_1}}{l}\Lambda\right) = \frac{q_1}{\sqrt{p_1}}\Lambda.$$

我们关注的是(4.7)的解$\lambda(x)$，其ℓ_2-范数最小；因此，对于这样的解

$$\|\lambda(x)\| \le \|\bar{\lambda}(x)\| \le \frac{q_1}{\sqrt{p_1}}\Lambda.$$

由于这个解确实是集合 Y 的回归拉格朗日多项式集，这意味着我们已经证明乘积 $\sqrt{p_1}\Lambda_{\ell,2}$ 在 B 上被 $q_1\Lambda$ 所界定。

我们通过坚持集合 Y 可以被划分为 $l = p_1/q_1$ 个大小为 q_1 的子集，且这些子集对于插值是 Λ- poised 的，从而推导出这一性质。如果 p_1 不是 q_1 的整数倍，那么我们将 Y 划分为 $l = \lfloor p_1/q_1 \rfloor$ 个子集（Λ-poised）以及额外一个包含少于 q_1 个点的子集。我们只需指出，分数 p_1/q_1 的情形是此数为整数情形的简单扩展，并且为了避免进一步复杂化符号表示，这里我们不详细讨论。

我们引入以下关于回归集 Y 的 *strong* Λ- poised性的定义。

定义4.10。 *Let $\Lambda > 0$ and a set $B \in \mathbb{R}^n$ be given. Let $\phi = \{\phi_0(x), \ \phi_1(x), \ \ldots, \ \phi_q(x)\}$, with $p > q$, be a basis in $\mathcal{P}_n^d$. A poised set $Y = \{y^0, \ y^1, \ \ldots, \ y^p\}$ is said to be strongly Λ-poised in B (in the regression sense) if and only if*

1. *for the set of regression Lagrange polynomials associated with Y*

$$\frac{q_1}{\sqrt{p_1}}\Lambda \ge \max_{x\in B}\|\ell(x)\|,$$

or, equivalently,

2. *for any* $x \in B$ *the minimum* ℓ_2*-norm solution* $\lambda(x) \in \mathbb{R}^{p_1}$ *of*

$$\sum_{i=0}^{p} \lambda_i(x)\phi(y^i) \;=\; \phi(x)$$

satisfies $\|\lambda(x)\| \;\leq\; \frac{q_1}{1}\sqrt{p}$
$1\ \Lambda_{\circ}$

暂时考虑 $p_1 = q_1$。如果 Y 在插值意义下是 Λ 稳定的，那么 $\|\lambda(x)\|_\infty \leq \Lambda$，并且由于 $\|\lambda(x)\| \leq \sqrt{q_1}\|\lambda(x)\|_\infty$，我们有 $\|\lambda(x)\| \leq \sqrt{q_1}\Lambda$。我们可以看到，当 $p = q$ 时，强 Λ 稳定性的定义不等同于插值的 Λ 稳定性定义，而是由后者蕴含。为了诱导等价性，可以在第3章的插值情况下，通过拉格朗日多项式的 ℓ_2 范数界来定义 Λ 稳定性。这不会从根本上改变本书中与多项式逼近相关的任何结果，但会稍微复杂化表述，并改变与多项式插值相关的各种界中的几个常数。

Λ-稳定姿态定义的图示

借助以下两个示例，我们试图说明Λ- poisedness的两种定义，以及它们之间如何相互关联，并与插值意义下的Λ- poisedness有何关系。我们考虑以下回归集：

$$Y_1 \;=\; \{(0,0),(1,0),(0,1),(2,0),(1,1),(0,2)\}$$

并令 $Y_g = \{Y_1、Y_1、\ldots、Y_1\} + z$，其中包含 31 份 Y_1，并受到一个适当大小的随机向量 z 的轻微扰动，其元素均匀分布于 0 到 0.05 之间。在图 4.1 的左侧进行了说明。

让我们考虑一个我们在MATLAB [1]软件中生成并测试的典型随机集。插值集Y_1本身是Λ平衡的（在插值意义上），其Λ =为4.121，而在Y_1的31个扰动副本中，最大的Λ平衡常数为4.541。整个回归集Y是Λ平衡的（在回归意义上），其Λ =为0.152。首先，我们注意到整个回归集的Λ平衡常数远小于六个点任何子集的Λ平衡常数。还注意到我们可以将集合Y_g划分为31个Λ平衡集，其Λ $\leq$为4.541。尽管人们可能预期如此，但Y_g的常数Λ_ℓ并不比这些子集中任何一个的最大Λ_ℓ小31倍，因为$0.15 2 \times 31 = 4.721 > 4.541$。然而，在我们的实验中，$\Lambda$平衡常数确实随着我们包含在$Y_g$中的$Y_1$扰动副本的数量成比例地减少。因此，我们期望这个集合是强Λ平衡的。

为了分析强 Λ- poisedness，我们需要估计 Y_g 的强 Λ- poisedness 常数。由于需要最大化非二次函数，这个值在 MATLAB [1] 软件中计算并不简单。然而，与其考虑

$$\Lambda_{\ell,2} \;=\; \max_{x \in B(Y_g)} \|\ell(x)\|$$

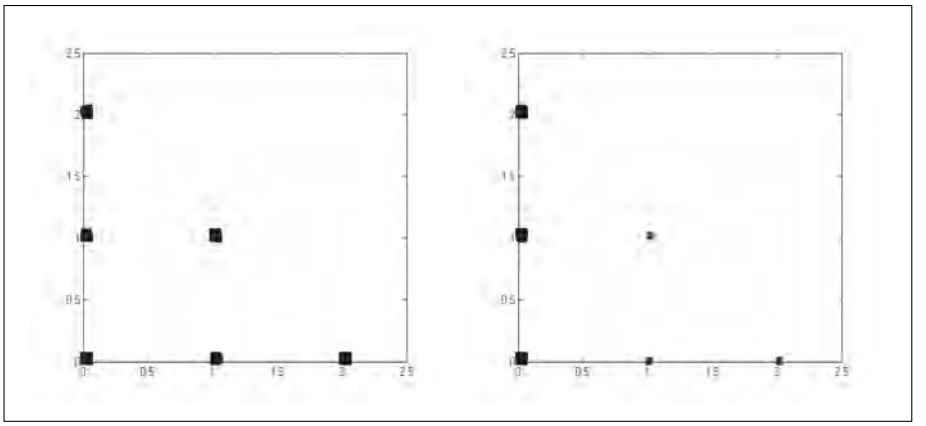


图 4.1. *A strongly well-poised regression set Y_g (left) and a well-poised (but not strongly poised) regression set Y_b (right). The thick squares are collections of slightly perturbed identical points. The thin squares are single points.*

我们可以轻松计算上界

$$\sqrt{\sum_{i=0}^{p}\left[\max_{x\in B(Y_g)}|\ell_i(x)|\right]^2},$$

对于集合 {v*}，该值等于 1.122。现在我们可以看到，对于这种情况，

$$\Lambda_{\ell,2} \le 1.122 \le \frac{q_1}{\sqrt{p_1}}4.541 = \frac{6}{13.64}4.541 = 1.998,$$

这意味着集合 Y_g 是强 Λ-平衡的，且 Λ ≤ 为4.541。此处我们展示了一个子集集合的示例，这些子集具有大致相同的 Λ-平衡常数，它们共同构成一个具有相似常数的强 Λ-平衡回归集。

现在让我们考虑一个不同的样本集 Y_b，它由 $Y_b = \{Y_1、Y_2、\ldots、Y_2\} + z$ 组成，其中 Y_1 与上述集合相同，并且

$$Y_2 = \{(0,0),(0,1),(0,1),(0,0),(0,2),(0,2)\}.$$

这个集合 Y_2 是通过重复第一、第三和第六个点从 Y_1 得到的，因此仅在第二个参数上有变化。因此，集合 Y_b 包含一个良好平衡集合 Y_1 的扰动副本以及30个不良平衡集合 Y_2 (的扰动副本，注意 z 又是一个随机扰动向量)。集合 Y_b 在图4.1的右侧展示。这个 Y_b 的 Λ-平衡常数是3.046，如预期那样小于 Y_1 的 Λ-平衡常数，但与它相当，而不是像第一种情况那样小约30倍。很明显，当使用不良平衡子集时，Λ-平衡常数并不会随 p 显著减小。现在让我们证明，当 Λ 接近 Y_1 的平衡常数时，集合 Y_b 不是强 Λ-平衡的。为了避免计算 $\Lambda_{\ell,2}$，我们利用任何向量的 ℓ_2-范数大于或等于其 ℓ_∞-范数这一事实。由此可得 $\Lambda_{\ell,2} \ge \Lambda_\ell$，因此很明显 Y_b 是

对于任何 $\Lambda \leq \frac{13.64}{6} 3.046 = 6.925$，并不强 Λ- poised。由于 $\Lambda_{\ell,2}$ 实际上可能比 Λ_ℓ 大最多 $\sqrt{p_1}$ 倍，集合 Y_b 的强 Λ-poisedness 常数可能高达 $\Lambda = 13.64 \times 6.925 \simeq 94$。

这两个例子旨在说明，强平衡性反映了样本点在空间中分布的优良程度，以形成平衡子集。从统计学的角度来看，也很清楚的是，第一种情况下的强平衡集Y是用于获得噪声函数精确模型的更优样本集，因为第二个样本集将导致模型对第二个变量x_2的变化产生强烈偏差。

4.4 条件数作为良态性的度量

我们回忆一下，尽管矩阵$M(\phi、Y)$的条件数并不能可靠地衡量任意ϕ和Y的平衡性，但我们已在第3章中看到，对于$\phi = \bar{\phi}$ (自然基)的选择，以及对于从Y平移和缩放得到的集合$\hat{Y}$ (，使得y^0与Y中任何其他点之间的最大距离等于1)，Λ-平衡常数与$\|M(\bar{\phi}、\hat{Y})^{-1}\|$ (，因此矩阵$M(\bar{\phi}、\hat{Y})$)的条件数仅相差一个常数因子。

在回归情形中，这一事实可能尤为重要，因为它支持最小二乘回归在噪声问题中的一致性。回想一下，要使定理4.1成立，我们需要条件(4.1)为真。这意味着对于样本集序列Y^p，其中$p \to +\infty$，矩阵$M(\phi、Y^p)^\top M(\phi、Y^p)$的最小特征值必须以至少$p$的速率增长。让我们尝试建立一些关于这个条件的直观理解。如前一节那样，让我们假设点数p_1等于lq_1，其中l是一个整数。让我们将集合Y^p划分为l个子集，比如Y_1^p、Y_2^p、…、Y_l^p。那么矩阵$M(\phi、Y^p)^\top M(\phi、Y^p)$可以写成$\sum_{i=1}^{l} M(\phi、Y_i^p)^\top M(\phi、Y_i^p)$。$M(\phi、Y^p)^\top M(\phi、Y^p)$的最小特征值大于或等于$M(\phi、Y_i^p)^\top M(\phi、Y_i^p)$、$i = 1$、…、$l$的最小特征值之和。因此，如果$M(\phi、Y_i^p)^\top M(\phi、Y_i^p)$中每一个的最小特征值都被一个常数$\sigma^2 > 0$限制在远离零的位置（或者等价地说，$M(\phi、Y^i)$的最小奇异值从下方被$\sigma > 0$所限制），那么和的最小特征值就从下方被$l\sigma^2$ (所限制，等价地说，整个矩阵的最小奇异值从下方被$\sqrt{l}\sigma$)所限制。由这一论证和定理3.14，我们得到以下结果的第二部分。第一部分已在上一节中给出。

定理4.11。 *If a set Y^p of p_1 sample points can be partitioned into $l = p_1/q_1$ sets which are Λ-poised for interpolation, then the entire set is strongly Λ-poised for regression. If $Y^p = \hat{Y}^p \subset B(0; 1)$, then the inverse of the smallest singular value of $M(\bar{\phi}$, $Y^p)$ is bounded by $\sqrt{q_1/p_1}\Lambda$.*

因此，我们可以看到，有可能确保矩阵 $M(\bar{\phi}、Y^p)^\top M(\bar{\phi}、Y^p)$ 的最小特征值至少以 p 的速率增长，这意味着满足最小二乘回归模型一致性所需的条件（4.1）。

为了将回归意义下的强 Λ-位姿性与 $M(\bar{\phi}、\hat{Y})$ 的条件数界直接联系起来，我们需要一个类似于定理 3.14 的结论。为此，让我们考虑$\hat{M} = M(\bar{\phi}、\hat{Y}) = \hat{U}\hat{\Sigma}\hat{V}^\top$ (的简化奇异值分解，这意味着$\hat{U}$ 是一个具有正交列的 $p_1 \times q_1$ 矩阵，$\hat{\Sigma}$ 是一个由非零奇异值组成的 $q_1 \times q_1$ 矩阵，而$\hat{V}$ 是一个 $q_1 \times q_1$ 正交矩阵)。设$\hat{\sigma}_1$ (（分别地，$\hat{\sigma}_{q_1}$)）表示$\hat{M}$ 的最大（分别地，最小）奇异值。那么 $\|\hat{M}\| = \|\hat{\Sigma}\| = \hat{\sigma}_1$ 且

$\|\hat{\Sigma}^{-1}\| = 1/\hat{\sigma}_{q_1}$。注意 $\mathrm{cond}(\hat{M}) = \hat{\sigma}_1/\hat{\sigma}_{q_1}$。为了用 Λ 来界定 $\mathrm{cond}(\hat{M})$，只需界定 $\|\hat{\Sigma}^{-1}\|$ 即可。以下定理的证明及相关细节可在 [64] 中找到。

定理4.12。 *If $\hat{\Sigma}$ is nonsingular and $\|\hat{\Sigma}^{-1}\| \le \sqrt{q_1/p_1}\Lambda$, then the set $\hat{Y}$ is strongly Λ-poised in the unit ball $B(0;1)$ centered at 0*
. Conversely, if the set $\hat{Y}$ is strongly Λ-poised in the unit ball $B(0;1)$ centered at 0, then

$$\|\hat{\Sigma}^{-1}\| \le \frac{\theta q_1}{\sqrt{p_1}}\Lambda, \tag{4.10}$$

where $\theta > 0$ is dependent on n and d (i.e., on q_1) but independent of $\hat{Y}$ and Λ.

基于条件数的误差界

现在我们将注意力转向多项式最小二乘回归误差界的推导。与多项式插值情形一样，我们得到线性和二次最小二乘回归的类泰勒界，以 poisedness 常数 Λ 和 $\hat{\Sigma}^{-1}$ 的范数表示。以 Λ 表示的界已在第4.3节中给出。由于 $\hat{\Sigma}^{-1}$ 和 Λ 之间的关系，该界也可以用 $\hat{\Sigma}^{-1}$ 表示。然而，使用 $\hat{\Sigma}^{-1}$ 的界可以像第3章那样直接推导。这里我们给出二次情形下的结果界。关于推导和其他细节，参见[64]。注意线性情形已在第2.4节中涵盖。

假设 4.1。 *We assume that $Y = \{y^0, y^1, \ldots, y^p\} \subset \mathbb{R}^n$, with $p_1 = p+1 > (n+1)(n+2)/2$, is a poised set of sample points (in the quadratic regression sense, $d = 2$) contained in the ball $B(y^0;$ $\Delta(Y))$ of radius $\Delta = \Delta(Y)$. Further, we assume that the function f is twice continuously differentiable in an open domain Ω containing $B(y^0;$ $\Delta)$ and $\nabla^2 f$ is Lipschitz continuous in Ω with constant $\nu_2 > 0$.*

定理 4.13。 *Let Assumption 4.1 hold. Then, for all points y in $B(y^0;\ \Delta(Y))$, we have that*

- *the error between the Hessian of the quadratic regression model and the Hessian of the function satisfies*
$$\|\nabla^2 f(y) - \nabla^2 m(y)\| \le \kappa_{eh}\,\Delta,$$
- *the error between the gradient of the quadratic regression model and the gradient of the function satisfies*
$$\|\nabla f(y) - \nabla m(y)\| \le \kappa_{eg}\,\Delta^2,$$
- *the error between the quadratic regression model and the function satisfies*
$$|f(y) - m(y)| \le \kappa_{ef}\,\Delta^3,$$

where κ_{eh}, κ_{eg}, and κ_{ef} are given by

$$\begin{aligned}
\kappa_{eh} &= 3\sqrt{2}p^{\frac{1}{2}}\nu_2\|\hat{\Sigma}^{-1}\|/2,\\
\kappa_{eg} &= 3(1+\sqrt{2})p^{\frac{1}{2}}\nu_2\|\hat{\Sigma}^{-1}\|/2,\\
\kappa_{ef} &= (6+9\sqrt{2})p^{\frac{1}{2}}\nu_2\|\hat{\Sigma}^{-1}\|/4 + \nu_2/6.
\end{aligned}$$

注意，根据定理4.12，如果集合 Y 是强 Λ- poised 的，那么 $p^{\frac{1}{2}}\|\hat{\Sigma}^{-1}\|$-是一致有界的，与 p_1 和 Y 无关。

4.5 注释和参考文献

在本章中，我们已经确立了回归模型在逼近精度方面享有与插值模型相似的性质，这些性质通过相应的拉格朗日多项式或适当矩阵的逆或伪逆的范数的界来表达。这些性质对于构建可证明收敛的无导数算法是有用的，这些算法使用最小二乘回归来建模目标函数。

现在让我们把注意力转向本章引言中提到的其他回归近似方法。例如，在函数评估昂贵但存在噪声的情况下，使用正则化回归而不是插值可能是有用的。这将通过在一定程度上放宽插值条件，使近似函数更加“平滑”。具体来说，设α为我们的插值/回归条件$M(\phi、Y)\alpha = f(Y)$的解，并设H_α为模型的最终Hessian矩阵

$$m(x) = \sum_{i=0}^{q} \alpha_i \phi_i(x).$$

当 $\phi = \bar{\phi}$ 是自然基时，H_α 是一个对称矩阵，其下三角部分仅包含与二次单项式相对应的 α 的元素。现在我们选择一个正则化参数 ρ，并考虑以下问题：

$$\min_{\alpha} \rho\|H_\alpha\|^2 + \|M(\phi,Y)\alpha - f(Y)\|^2.$$

假设我们正在考虑包含 $p_1 \geq q_1$ 的完整二次模型。我们知道，如果 $\rho \to 0$，那么我们就恢复了最小二乘回归模型，该模型对于均衡样本集满足二阶泰勒型误差界。如果 $\rho \to +\infty$，那么在这种情况下，我们恢复了线性最小二乘回归，它也满足一阶泰勒型误差界。为了保持二阶近似，我们需要限制 ρ 的大小。事实上，可以从最小二乘回归模型的泰勒型误差界推导出，对于足够小的 ρ 值，正则化回归问题的解也满足二阶泰勒型误差界。以下是论证的粗略概述。

让 $m(x)$ 为正则化回归模型，$m^{\ell s}(x)$ 为最小二乘回归模型。考虑一个半径为 Δ 的球 B 和一个强良置样本集 $Y \subset B$。令 $m^{\ell s}(x) = (\alpha^{\ell s})^\top \phi(x)$ 和 $m(x) = \alpha^\top \phi(x)$。根据最小二乘回归误差的界，我们知道对于适当选择的 Y

$$\|m^{\ell s}(Y) - f(Y)\| = \|M(\phi,Y)\alpha^{\ell s} - f(Y)\| = \mathcal{O}(\Delta^3).$$

这反过来意味着，通过选择足够小的ρ（并且如果$\|[M(\phi, Y)^\top M(\phi, Y)]^{-1}\|$是有界的），我们可以使正则化回归模型满足

$$\|M(\phi,Y)\alpha - f(Y)\| = \mathcal{O}(\Delta^3).$$

这意味着

$$\|M(\phi,Y)\alpha - M(\phi,Y)\alpha^{\ell s}\| = \mathcal{O}(\Delta^3).$$

如果 $\|[M(\phi, Y)^\top M(\phi, Y)]^{-1}\|$ 是有界的，那么我们可以得出结论 $\|\alpha - \alpha^{\ell s}\| = O(\Delta^3)$，因此 $|m^{\ell s}(x) - m(x)| = \mathcal{O}(\Delta^3)$。由于对于任意 $x \in B$，我们知道 $|m^{\ell s}(x) - f(x)| = \mathcal{O}(\Delta^3)$，我们有 $|m(x) - f(x)| = \mathcal{O}(\Delta^3)$；换句话说，我们已经证明，如果最小二乘回归模型是准确的，那么通过保持 ρ 足够小，我们可以确保正则化回归模型也是准确的。我们得出结论，本章讨论的结果不仅适用于简单的最小二乘回归，还适用于各种近似函数的应用。

我们以证明之前用来推导定理4.8的简单引理来结束本章。

引理 4.14. *Consider a poised set* $Z = \{z^1、\ \ldots、\ z^m\} \subset \mathbb{R}^n$, *with* $m > n$. *Let* $I \subset \{1、\ \ldots、\ m\}$
be a subset of indices with $|I| = n$. *It is possible to choose* I *so that, for any* $x \in \mathbb{R}^n$ *such that*

$$x \ = \ \sum_{i=1}^{m} \lambda_i z^i, \quad |\lambda_i| \ \leq \ \Lambda,$$

for some $\Lambda > 0$, *we can write*

$$x \ = \ \sum_{i \in I} \gamma_i z^i, \quad |\gamma_i| \ \leq \ (m - n + 1)\Lambda.$$

Proof. 考虑一个$n \times n$矩阵A，其列向量为z^i、$i \in I$。在所有可能的集合I中，选择对应于行列式绝对值最大的矩阵A的那一个。我们将证明这个I满足引理的陈述。

令 $\bar{I} = \{1、\ \ldots、\ m\} \backslash I$，并令 $Z_{\bar{I}}$ 为 Z 的子集，其中包含索引位于 $\bar{I}$ 中的点。首先，我们将证明对于任意 z^j、$j \in \bar{I}$，

$$z^j \ = \ \sum_{i \in I} \alpha_i^j z^i, \quad |\alpha_i^j| \ \leq \ 1.$$

根据克莱姆法则 $\alpha_i^j = \det(A_{z^j, i})/\det(A)$，其中 $A_{z^j, i}$ 对应于矩阵 A 将其第 i 列替换为向量 z^j。由于通过选择 I，$|\det(A)| \geq |\det(A_{z^j, i})|$ 对于任意 $j \in \bar{I}$，我们有 $|\alpha^j_i| \leq 1$.

现在考虑任何 x，使得

$$x \ = \ \sum_{i=1}^{m} \lambda_i z^i, \quad |\lambda_i| \ \leq \ \Lambda.$$

我们拥有

$$x \ = \ \sum_{i \in I} \lambda_i z^i + \sum_{j \in \bar{I}} \lambda_j \left(\sum_{i \in I} \alpha_i^j z^i \right) \ = \ \sum_{i \in I} \gamma_i z^i, \quad |\gamma_i| \ \leq \ (m - n + 1)\Lambda, \ i \in I. \quad \square$$

4.6 练习

1. 证明定理4.1来自

$$\alpha^p - \alpha^p_{smooth} = \left[\frac{1}{p+1}M(\phi, Y^p)^\top M(\phi, Y^p)\right]^{-1} \frac{1}{p+1}M(\phi, Y^p)^\top \varepsilon^p,$$

其中 ε^p 是从均值为 0 的相同分布中抽取的独立随机变量的适当向量。

2. 证明如果对于某个基 ϕ，$M(\phi、Y)$ 具有满列秩，那么对于 $\mathcal{P}_n^d$ 的任意基，它都具有满列秩。

3. 证明(4.7)中的$\lambda(x)$不依赖于$\mathcal{P}_n^d$中ϕ的选择。

4. 证明如果一个含有 p_1 个点（$p_1 > q_1$）的集合 Y 包含一个由 q_1 个点组成的子集，且该子集是 Λ- poised 的，则该集合也是 $\sqrt{q_1}\Lambda$-poised 的。

5. 证明引理4.9。

6. 证明定理4.13。

第5章

欠定插值模型

我们现在考虑 Y 中插值点数量小于多项式基 ϕ ($p < q$ 中元素数量的情况，或 $p_1 < q_1$ 与 $p_1 = p + 1$ 和 $q_1 = q + 1$) 的情况。在这种情况下，定义插值条件（见 (4.3)）的矩阵 $M(\phi、Y)$ 的列数多于行数，并且由下式定义的插值多项式

$$m(y^i) = \sum_{k=0}^{q} \alpha_k \phi_k(y^i) = f(y^i), \quad i = 0, \ldots, p, \tag{5.1}$$

不再唯一。

这种情况在基于模型的无导数优化方法中极其常见。大多数无导数应用基于计算成本高昂的目标函数。成本因应用而异，并且与问题的维度或多或少相关。例如，对于一个有3个变量的问题，需要10次函数评估来构建一个确定的二次多项式插值模型。如果每次这样的评估需要1小时，那么即使10次评估也可能过于昂贵而难以坚持。但如果每次评估需要2秒，那么在任何需要时构建准确的二次模型似乎是合理的。此外，在存在噪声的情况下，每个模型使用超过10个点并应用回归可能是个好主意，正如前一章所讨论的。然而，对于一个有100个变量的问题，要构建一个确定的二次多项式插值模型，我们需要超过5000个点（见表1.1）。即使每次函数评估需要2秒，评估样本集也需要数小时。当然，一个高效的无导数方法不会试图为每个新模型从头生成所有这些点，而是会尝试重用已知值的现有样本点。为了使其有用，通常样本点必须相当接近当前迭代点。除非算法长时间没有进展，这显然是不可取的，否则通常会出现已经评估的有用样本点数量低于或远低于多项式基中元素数量的情况。

一种节省构建样本集成本的简单方法是使用线性模型；然而，众所周知，当不利用曲率时，收敛速度会显著减慢。解决这一难题的方法是使用欠定二次插值。

模型，使用的点比完整二次插值模型所需的要少，但比定义线性插值的点要多。通过纳入这些额外的点，人们希望捕捉到函数的部分曲率，并观察到局部收敛的经验超线性速率。对于这种方法，模型的选择和样本集的选择起着至关重要的作用。我们将在本章讨论这些问题。

5.1 欠定模型的选择

首先，我们需要确保所构建的模型由样本集唯一确定。限制(5.1)使其具有唯一解的最简单方法是从系统中去除$M(\phi, Y)$的最后$q-p$列。这导致解α的最后$q-p$个元素为零。这种方法近似了α的某些元素，而仅根据基ϕ中元素的顺序将其他元素设为零。显然，如果不知道例如函数f的梯度和海森矩阵的稀疏结构，这种方法并不十分理想。还有一个更根本的缺点：$M(\phi, Y)$的前p_1列可能是线性相关的。在后一种情况下，一个自然的结论是我们的样本点（在某种意义上）不处于良好配置状态，我们必须改变它们。然而，如果我们选择了$M(\phi, Y)$的不同子集的p列，它可能在不改变任何点的情况下处于良好配置状态。我们将使用基ϕ的*subbasis*这一概念来表示基ϕ的p_1个元素的子集。因此，选择$M(\phi, Y)$的p_1列对应于选择适当的子基$\tilde{\phi}$。让我们考虑以下例子。

令 $\phi = \{1, x_1, x_2, \frac{1}{2}x_1^2, x_1x_2, \frac{1}{2}x_2^2\}$，$Y = \{y^0, y^1, y^2, y^3\}$，并令 $y^0 = (0, 0)$，$y^1 = (0, 1)$，$y^2 = (0, -1)$，以及 $y^3 = (1, 0)$。矩阵 $M(\phi, Y)$ 由下式给出：

$$M(\phi, Y) = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 0.5 \\ 1 & 0 & -1 & 0 & 0 & 0.5 \\ 1 & 1 & 0 & 0.5 & 0 & 0 \end{bmatrix}.$$

如果我们选择$M(\phi、Y)$的前四列，那么系统仍然没有良好定义，因为矩阵是奇异的。因此，集合Y相对于子基$\tilde{\phi} = \{1、x_1、x_2、\frac{1}{2}x_1^2\}$不是 poised 的，需要一组新的样本点。注意，如果选择了另一个子基，例如$\tilde{\phi} = \{1、x_1、x_2、\frac{1}{2}x_2^2\}$，那么集合$Y$是良 poised 的，由$M(\phi、Y)$的第一、第二、第三和第六列组成的矩阵是良条件的，并且存在唯一解。如果f的 Hessian 恰好形如

$$\begin{bmatrix} 0 & 0 \\ 0 & \frac{\partial^2 f}{\partial x_2^2}(x) \end{bmatrix},$$

那么这个简化系统实际上产生了 f 的完整二次模型。

如果f的导数稀疏结构事先已知，那么可以通过从系统(5.1)中删除相应的列来利用这一优势。这一思想的更复杂版本在[56]中针对组部分可分函数进行了利用，并且当Hessian和梯度元素的结构已知时，在实践中效果良好。如果这样的结构未知，那么除了*geometry considerations*之外，没有理由选择一组列而非另一组。因此，选择那些

能产生最佳几何结构的列。给定样本集 Y，这可以通过选择子基$\tilde{\phi}$来实现，使得 poised ness 常数 Λ 最小化。以下示例展示了这种方法在计算多项式模型时可能存在的缺点。

为简化起见，我们考虑$\mathbb{R}^3$中的纯线性情况。二次情形的例子可以类似地构造。考虑$\phi = \{1、x_1、x_2、x_3\}$和$Y = \{y^0、y^1、y^2\}$，其中，一如既往，$y^0 = (0, 0, 0)$，并且$y^1 = (1, 0, 0)$，以及$y^2 = (0, 1, 1-\epsilon)$。假设$f(Y) = (0, b_1, b_2)$。系统(5.1)于是变为

$$\begin{bmatrix} 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 1-\epsilon \end{bmatrix} \alpha = \begin{bmatrix} 0 \\ b_1 \\ b_2 \end{bmatrix}.$$

Y 的最佳子基是$\tilde{\phi} = \{1、x_1、x_2\}$。如果我们选择 $M(\phi、Y)$ 的适当列并求解简化后的系统，则得到 $m(x)$ 的系数的以下解：

$$\alpha = \begin{bmatrix} 0 \\ b_1 \\ b_2 \\ 0 \end{bmatrix}.$$

现在，如果我们考虑 $y^2 = (0, 1-\epsilon, 1)$，那么最佳子基是$\tilde{\phi} = \{1, x_1, x_3\}$，而我们将通过这种方法找到的解是

$$\alpha = \begin{bmatrix} 0 \\ b_1 \\ 0 \\ b_2 \end{bmatrix}.$$

注意，这两个可能的解彼此之间差异很大，然而随着ϵ趋近于零，两组样本点逐点收敛于彼此。因此，我们看出子基方法对样本集中的微小扰动缺乏鲁棒性。我们还注意到，在第一种（第二种）情况下，系数向量的第四个（第三个）元素被设为零，而第三个（第四个）元素被设为b_2 (b_2)。因此，每个解都偏向于基分量之一（x_2 或x_3），而没有利用关于f结构的任何实际信息。更为合适的方法应是在某种意义上平等对待所有此类分量。这可以通过（5.1）的最小范数解来实现。

对于此示例，第一种情况下的最小范数解 是

$$\alpha^{mn} = M(\phi, Y)^\top [M(\phi, Y) M(\phi, Y)^\top]^{-1} f(Y) = \begin{bmatrix} 0 \\ b_1 \\ \frac{b_2}{2-2\epsilon+\epsilon^2} \\ \frac{(1-\epsilon)b_2}{2-2\epsilon+\epsilon^2} \end{bmatrix}$$

在第二种情况下是

$$\alpha^{mn} = \begin{bmatrix} 0 \\ b_1 \\ \frac{(1-\epsilon)b_2}{2-2\epsilon+\epsilon^2} \\ \frac{b_2}{2-2\epsilon+\epsilon^2} \end{bmatrix}.$$

这两个解在ϵ趋近于零时收敛于$(0, b_1, b_2/2, b_2/2)$。因此，最小范数解不仅对数据的小扰动具有鲁棒性，而且在x_2和x_3基分量上“均衡”了梯度的元素。

鉴于上述原因，考虑系统(5.1)的最小范数解是有益的。最小范数解表示为

$$M(\phi, Y)^\top [M(\phi, Y) M(\phi, Y)^\top]^{-1} f(Y)$$

并且可以通过$M(\phi、Y)$的QR分解或约化奇异值分解来计算。众所周知，欠定线性方程组的最小范数解在线性变换下不是不变的。在我们的情况下，这一事实意味着最小范数解取决于ϕ的选择。很容易证明，所得插值多项式也取决于系统(5.1)中ϕ的选择。

因此，根据ϕ的选择，我们可以通过计算最小范数插值多项式来获得对f更好或更差的近似。理想情况下，我们希望对于每个集合Y，能够识别出“最佳”基ϕ，从而生成“最佳”最小范数插值多项式。然而，定义这样的基并非易事。首先，需要定义最佳插值多项式。自然的选择是相对于函数f具有最小近似误差的多项式。但最佳基（以及因此最佳多项式）的定义应仅依赖于Y。此外，最佳子基模型的选择显然也取决于基的初始选择。我们尚未发现有任何工作能解答这些问题；因此，我们采取了看起来最自然的做法——我们考虑自然基$\bar{\phi}$下的最小范数欠定插值。正如我们稍后将观察到的，这原来是一个合理的选择。

5.2 拉格朗日多项式与欠定插值的$\mathbf{\Lambda}$- poisedness

我们将考虑由(3.1)定义的自然基底$\bar{\phi}$以及相应的矩阵$M(\bar{\phi}, Y)$。我们将从引入欠定插值中拉格朗日多项式集合的一个特定定义开始。

定义 5.1。 *Given a set of interpolation points* $Y = \{y^0、 y^1、 \ldots、 y^p\}$, *with* $p < q$, *where* $q_1 = q+1$ *is the dimension of* $\mathcal{P}_n^d$, *a set of* $p_1 = p+1$ *polynomials* $\ell_j(x) = \sum_{i=0}^{q} (\alpha_j)_i \bar{\phi}_i(x)$, $j = 0, \ldots、$
p, is called a set of minimum-norm Lagrange polynomials for the basis $\bar{\phi}$ *if it is a minimum-norm solution of*

$$\ell_j(y^i) \overset{\text{m.n.}}{=} \delta_{ij} = \begin{cases} 1 & \text{if } i = j, \\ 0 & \text{if } i \neq j. \end{cases}$$

最小范数拉格朗日多项式因此由下式的最小范数解给出

$$M(\bar{\phi}, Y)\alpha_j \overset{\text{m.n.}}{=} e_{j+1}, \quad j = 0, \ldots, p,$$

其中 e_{j+1} 是 $q+$ 阶单位矩阵的第 $(j+1)$ 列。这组多项式是传统拉格朗日多项式在 $p < q$ 情形下的推广。显然，这些多项式不再构成基，因为它们的数量不够。然而，与回归情形一样，拉格朗日插值多项式的许多其他性质得以保留。

最小范数拉格朗日多项式集合存在且唯一，如果矩阵$M(\bar{\phi}、Y)$具有满行秩。在这种情况下，我们将称Y是适定的。我们再次注意到，这里的拉格朗日多项式通常依赖于基ϕ的选择，因此良适定性的程度也是如此，但很容易看出，Y的适定性并不依赖于此，因为$M(\bar{\phi}、Y)$的秩不依赖于基的选择。

正如在标准拉格朗日多项式的情形中一样，欠定情况下的最小范数插值多项式 $m(x)$ 可以用最小范数拉格朗日多项式简单地表示出来。

引理 5.2。*For any function* $f\colon \mathbb{R}^n \to \mathbb{R}$ *and any poised set* $Y = \{y^0, y^1, \ldots, y^p\} \subset \mathbb{R}^n$, *the minimum-norm interpolating polynomial* $m(x)$ *(in terms of the basis* $\bar{\phi}$*) that interpolates* $f(x)$ *on* Y *can be expressed as*

$$m(x) = \sum_{i=0}^{p} f(y^i)\ell_i(x),$$

where $\{\ell_i(x), i = 0, \ldots, p\}$ *is the set of minimum-norm Lagrange polynomials for* Y.

我们现在将展示，如同多项式插值和回归的情况一样，拉格朗日多项式的替代解释可以轻松推导出来。因此，我们也将得到Λ- poisedness的一个类似定义。

给定一个平衡集 $Y = \{y^0、y^1、\ldots、y^p\} \subset B \subset \mathbb{R}^n$ 和 $x \in B$，我们尝试用向量 $\bar{\phi}(y^i)、i = 0、\ldots、p$ 来表示向量$\bar{\phi}(x)$。由于向量$\bar{\phi}(x)$ 的维数是 $q_1 > p_1$，可能不再能将其表示为 p_1 个向量$\bar{\phi}(y^i)、i = 0、\ldots、p$ 的线性组合。相反，我们将寻找以下系统的最小二乘解：

$$\sum_{i=0}^{p} \lambda_i(x)\bar{\phi}(y^i) \overset{\ell.s.}{=} \bar{\phi}(x). \tag{5.2}$$

我们在系统 (4.7) 中观察到一种对偶性，即该系统的最小 ℓ_2-范数解 $\lambda(x)$ 对应于最小二乘回归拉格朗日多项式，而在当前情况下，最小二乘解 $\lambda(x)$ 对应于最小 ℓ_2-范数拉格朗日多项式。

为了将(3.6)中给出的定义推广到欠定情形，我们采用与完全插值情形相同的方法。给定一个集合Y和一个点x，我们再次定义一个集合$Y_i(x) = Y \setminus \{y^i\} \cup \{x\}$，$i = 0$，…，$p$。根据克莱姆法则以及(5.2)中给出的$\lambda_i(x)$的定义，我们得到

$$\lambda_i(x) = \frac{\det(M(\bar{\phi}, Y)M(\bar{\phi}, Y_i(x)^\top))}{\det(M(\bar{\phi}, Y)M(\bar{\phi}, Y)^\top)}. \tag{5.3}$$

让我们用$\bar{M}$表示$M(\bar{\phi}、Y)$，并考虑集合$\phi_{\bar{M}}(Y)=\{\bar{M}\phi(y^i)、i=0、\ldots、p\}$在$\mathbb{R}^{p_1}$中。该集合的第$i$个元素是通过与$\bar{M}$的行计算内积而“投影”到$p_1$维空间中的向量$\phi(y^i)\in\mathbb{R}^{q_1}$。令$\mathrm{vol}(\phi_{\bar{M}}(Y))$为$\phi_{\bar{M}}(Y)$中顶点单纯形的体积，由下式给出

$$\mathrm{vol}(\phi_{\bar{M}}(Y)) \;=\; \frac{|\det(\bar{M}M(\bar{\phi},Y)^\top)|}{p_1!}.$$

(这样的单纯形是$\phi_{\bar{M}}(Y)$.)的p_1维凸包。那么

$$|\lambda_i(x)| \;=\; \frac{\mathrm{vol}(\phi_{\bar{M}}(Y_i(x)))}{\mathrm{vol}(\phi_{\bar{M}}(Y))}. \tag{5.4}$$

换句话说，给定点x上第i个拉格朗日多项式的绝对值，就是当y^i被x替换时，$\phi_{\bar{M}}(Y)$（的p_1维凸包）体积的变化。

以下关于良态的定义与定义3.6和4.7类似。

定义 5.3. *Let $\Lambda>0$ and a set $B\in\mathbb{R}^n$ be given. Let $\bar{\phi}$ be the natural basis of monomials of $\mathcal{P}_n^d$. A poised set $Y=\{y^0,y^1,\ldots,y^p\}$, with $p<q$, where $q_1=q+1$ is the dimension of $\mathcal{P}_n^d$, is said to be Λ-poised in B (in the minimum-norm sense) if and only if*

1. *for the set of minimum-norm Lagrange polynomials associated with Y*

$$\Lambda \;\geq\; \max_{0\leq i\leq p}\max_{x\in B}|\ell_i(x)|,$$

or, equivalently,

2. *for any $x\in B$ there exists $\lambda(x)\in\mathbb{R}^{p_1}$ such that*

$$\sum_{i=0}^{p}\lambda_i(x)\bar{\phi}(y^i) \;\overset{\ell.s.}{=}\; \bar{\phi}(x) \qquad \textit{with} \qquad \|\lambda(x)\|_\infty \;\leq\; \Lambda,$$

or, equivalently,

3. *replacing any point in Y by any $x\in B$ can increase the volume of the set $\{\bar{M}\phi(y^0)$、$\bar{M}\phi(y^1)$、$\ldots$、$\bar{M}\phi(y^p)\}$ at most by a factor Λ.*

在 [64] 中证明了，如果一个集合在最小范数意义下是良态的，那么它在最佳子基（插值）意义下也是良态的，反之亦然。

基于条件数的误差界推导

就泰勒型误差界而言，欠定模型通常根本不提供任何精度。首先，[53]中的界不适用，因为它们仅涵盖多项式模型本身即为多项式的情况。对于欠定插值，这通常并非如此，因为多项式通常不是由插值条件唯一确定的。

可以证明，在欠定情况下，对于最小范数模型，误差在适当线性子空间上的投影遵循与插值或回归模型相似的误差界限，但这样的结果显然是不充分的（见[64]）。

正如我们将在下文定理5.4中看到的，当样本集线性平衡时，欠定二次插值能提供与线性插值或回归相似的精度。然而，这些误差界限不仅取决于线性平衡常数，还取决于整个插值集的平衡常数。实际上，在定理5.4中，我们将看到误差界限依赖于模型Hessian矩阵的范数。Hessian矩阵的范数又可受整体平衡常数（在二次欠定意义下，或如下一节讨论的最小Frobenius范数意义下）的限制。需要注意的是，这些误差界限的推导适用于任何基于线性插值或回归平衡集的欠定二次插值模型。

我们首先给出这些界的推导。像往常一样，我们首先陈述我们的假设。

假设 5.1. *We assume that* $Y = \{y^0、\ y^1、\ \ldots、\ y^p\} \subset \mathbb{R}^n$ *is a set of sample points poised in the linear interpolation sense (or in the linear regression sense if* $p > n$*) contained in the ball* $B(y^0;\ \Delta(Y))$ *of radius* $\Delta = \Delta(Y)$*.*

Further, we assume that the function f *is continuously differentiable in an open domain* Ω *containing* $B(y0;\ \Delta)$ *and* ∇f *is Lipschitz continuous in* Ω *with constant* $\nu > 0$*.*

我们在此回顾第2章中关于以下内容的定义：

$$\hat{L} \ = \ \frac{1}{\Delta} L \ = \ \frac{1}{\Delta}\Big[y^1 - y^0 \cdots y^p - y^0\Big]^\top$$

以及$\hat{L}^\dagger = (\hat{L}^\top \hat{L})^{-1} \hat{L}^\top$。误差界限是根据 L 的这个缩放版本的条理性来表述的。

定理 5.4。*Let Assumption* 5.1 *hold. Then, for all points* y *in* $B(y^0;\ \Delta(Y))$*, we have that*

- *the error between the gradient of a quadratic underdetermined interpolation model and the gradient of the function satisfies*

$$\|\nabla f(y) - \nabla m(y)\| \ \leq \ \frac{5\sqrt{p}}{2} \|\hat{L}^\dagger\| (\nu + \|H\|)\, \Delta,$$

- *the error between a quadratic underdetermined interpolation model and the function satisfies*

$$|f(y) - m(y)| \ \leq \ \frac{5\sqrt{p}}{2} \|\hat{L}^\dagger\| (\nu + \|H\|)\, \Delta^2 + \frac{1}{2}(\nu + \|H\|)\, \Delta^2,$$

where H *is the Hessian of the model.*

Proof. 让我们将二次欠定插值模型写为(3.13)中的形式，并分别用(3.14)和(3.15)中的$e^f(x)$和$e^g(x)$表示函数值和梯度中的误差。

与我们在定理3.16证明中所做的一样，我们首先从插值条件中减去(3.14)，得到

$$(y^i - y)^\top g + \frac{1}{2}(y^i - y)^\top H(y^i - y) + (y^i - y)^\top Hy = f(y^i) - f(y) - e^f(y), \quad i = 0, \ldots, p.$$

现在，我们不再像定理3.16中那样使用二阶泰勒展开，而是采用一阶论证并写为：

$$(y^i - y)^\top e^g(y) + \frac{1}{2}(y^i - y)^\top H(y^i - y) = \mathcal{O}(\Delta^2) - e^f(y), \quad i = 0, \ldots, p. \tag{5.5}$$

下一步是从其他方程中减去第一个方程，消去项$e^f(y)$，得到

$$(y^i - y^0)^\top e^g(y) + \frac{1}{2}(y^i - y)^\top H(y^i - y) - \frac{1}{2}(y^0 - y)^\top H(y^0 - y) = \mathcal{O}(\Delta^2), \quad i = 1, \ldots, p.$$

现在可以很容易地利用假设5.1和这些等式的矩阵形式推导出梯度误差的界。

最后，由带有 $y = y^0$ 的（5.5）式以及梯度的误差界，我们得到函数值的误差界。 □

5.3 最小弗罗贝尼乌斯范数模型

需要注意的是，并非任何一组适合最小范数或最佳子基插值的$p_1 \geq n + 1$个点都适合线性插值。一个简单的例子是集合$Y = \{(0, 0, 0), (1, 0, 0), (0, 1, 0), (1,1, 0)\}$，它适合子基$\{1, x_1, x_2, x_1x_2\}$，但不适合子基$\{1, x_1, x_2, x_3\}$。

通常，在使用不完全插值的无导数优化框架中，构建精确的线性模型并利用曲率信息进行增强是可取的，希望模型的实际精度优于纯线性模型。因此，构建适用于线性插值或回归的样本集非常重要。正如我们从定理5.4中所见，这些集合至少能为我们提供线性精度。我们还从该结果中了解到，构建Hessian范数适中的模型是相关的。

让我们考虑欠定二次插值（$q = (n + 1)(n + 2)/2$），并将自然基$\bar{\phi}$ 分为线性部分和二次部分：$\bar{\phi}_L = \{1、 x_1、 \ldots、 x_n\}$ 和$\bar{\phi}_Q = \{\frac{1}{2}x_1^2、 x_1x_2、 \ldots、 \frac{1}{2}x_n^2\}$。因此，插值模型可以写成

$$m(x) = \alpha_L^\top \bar{\phi}_L(x) + \alpha_Q^\top \bar{\phi}_Q(x),$$

其中 α_L 和 α_Q 是系数向量 α 的相应部分。让我们定义 *minimum Frobenius norm* 解 α^{mfn} 为以下优化问题的解

在 α_L 和 α_Q 中:

$$\begin{aligned} \min \quad & \tfrac{1}{2}\|\alpha_Q\|^2 \\ \text{s.t.} \quad & M(\bar{\phi}_L, Y)\alpha_L + M(\bar{\phi}_Q, Y)\alpha_Q \;=\; f(Y). \end{aligned} \tag{5.6}$$

我们将这样的解称为最小 Frobenius 范数解，因为由于我们特定选择的$\bar{\phi}(x)$ 以及分离 $\alpha = (\alpha_L、\ \alpha_Q)$，最小化 α_Q 的范数等价于最小化 $m(x)$ 的 Hessian 的 Frobenius 范数[6]。

最小Frobenius范数模型存在且唯一的条件是该矩阵为非奇异（见习题）：

$$F(\bar{\phi}, Y) \;=\; \begin{bmatrix} M(\bar{\phi}_Q, Y)M(\bar{\phi}_Q, Y)^\top & M(\bar{\phi}_L, Y) \\ M(\bar{\phi}_L, Y)^\top & 0 \end{bmatrix}. \tag{5.7}$$

因此，我们说样本集Y在最小Frobenius范数意义下是稳定的，如果矩阵(5.7)非奇异。最小Frobenius范数意义下的稳定性意味着线性插值或回归意义下的稳定性，因此也意味着最小范数意义下二次欠定插值的稳定性。注意，矩阵(5.7)非奇异当且仅当$M(\bar{\phi}_L, Y)$具有满列秩，且$M(\bar{\phi}_Q, Y)M(\bar{\phi}_Q, Y)^\top$在$M(\bar{\phi}_L, Y)^\top$ (的零空间中是正定的，并且后一个条件可以保证，例如，如果$M(\bar{\phi}_Q, Y)$具有满行秩)。另请注意，最小Frobenius范数模型的Hessian矩阵H可以很容易地计算为（见习题）

$$H \;=\; \sum_{i=0}^{p} \mu_i \left((y^i)(y^i)^\top - \frac{1}{2} D^i \right),$$

其中 D^i 是对角矩阵，对角元素为 $[y^i_j]^2$、$j = 1$、…、n 和 μ_i，$i = 0$、…、p 是与 (5.6) 中等式约束相关的拉格朗日乘子。

我们可以按如下方式定义最小Frobenius范数Lagrange多项式。

定义 5.5。*Given a set of interpolation points $Y = \{y^0、\ y^1、\ \ldots、\ y^p\}$, with $n < p < q$, where $q + 1$ is the dimension of $\mathcal{P}^d_n$ with $d = 2$, a set of $p_1 = p + 1$ polynomials $\ell_i(x) = \sum_{j=0}^{q} (\alpha_i)_j \bar{\phi}_j(x)$, $i = 0,\ \ldots,$*
p, is called a set of minimum Frobenius norm Lagrange polynomials for the basis $\bar{\phi}$ if the ith Lagrange polynomial is a solution of (5.6) *with the function f equal to the indicator function for y^i, for each $i = 0,\ \ldots,\ p$.*

对于这类最小 Frobenius 范数 Lagrange 多项式，还有一种替代定义，即将 {v* } 定义为以下问题的解

$$\begin{aligned} \min \quad & \|M(\bar{\phi}_Q, Y)^\top \lambda(x) - \bar{\phi}_Q(x)\|^2 \\ \text{s.t.} \quad & M(\bar{\phi}_L, Y)^\top \lambda(x) \;=\; \bar{\phi}_L(x). \end{aligned} \tag{5.8}$$

F或集合 Y 处于最小 Frobenius 范数，$\lambda(x)$ 满　　西班牙语

$$F(\bar{\phi}, Y) \begin{bmatrix} \lambda(x) \\ \mu(x) \end{bmatrix} = \begin{bmatrix} M(\bar{\phi}_Q, Y)\bar{\phi}_Q(x) \\ \bar{\phi}_L(x) \end{bmatrix} \tag{5.9}$$

[6]The Frobenius matrix norm is defined for squared matrices by $\|A\|_F^2 \;=\; \sum_{1 \le i,j \le n} a_{ij}^2$. The Frobenius norm is the norm defined by the trace matrix inner product $\|A\|_F^2 = \langle A, A \rangle_{\text{tr}} = \text{tr}(A^\top A)$ (recall from linear algebra that the trace of a squared matrix is the sum of its diagonal entries).

对于某个（乘子）向量 $\mu(x)$，该问题解向量 $\lambda(x)$ 的每个元素都是相应的最小 Frobenius 范数拉格朗日多项式，即 $\lambda(x) = \ell(x)$。同样成立的是，最小 Frobenius 范数模型可以通过最小 Frobenius 范数拉格朗日多项式来表示：

$$m^{\text{mfn}}(x) \;=\; \sum_{i=0}^{p} f(y^i)\ell_i(x). \tag{5.10}$$

这些事实的证明留作练习。

也可以将（3.6）中给出的定义扩展到最小Frobenius范数情形。给定集合 Y 和点 x，我们再次考虑 $Y_i(x) = Y \setminus \{y^i\} \cup \{x\}$、$i = 0$、…、$p$。由Cramer法则以及（5.9）中给出的 $\lambda_i(x)$ 的定义，我们得到

$$\lambda_i(x) \;=\; \frac{\det(F_{\bar{M}}(\bar{\phi}, Y_i(x)))}{\det(F_{\bar{M}}(\bar{\phi}, Y))},$$

其中（使用$\bar{M} = M(\bar{\phi}、\ Y) = [\bar{M}_L\ \bar{M}_Q\ ]$）

$$F_{\bar{M}}(\bar{\phi}, Y_i(x)) \;=\; \begin{bmatrix} \bar{M}_Q M(\bar{\phi}_Q, Y_i(x))^\top & \bar{M}_L \\ M(\bar{\phi}_L, Y_i(x))^\top & 0 \end{bmatrix}.$$

因此，我们也可以将拉格朗日多项式$\lambda_i(x)$的绝对值视为两个体积之比，其意义在于

$$|\lambda_i(x)| \;=\; \frac{\text{vol}(\bar{\phi}_{\bar{M}}(Y_i(x)))}{\text{vol}(\bar{\phi}_{\bar{M}}(Y))}$$

以最小Frobenius范数意义)定义的Y (体积为

$$\text{vol}(\bar{\phi}_{\bar{M}}(Y)) \;=\; \frac{|\det(F_{\bar{M}}(\bar{\phi}, Y))|}{(p_1 + n + 1)!}.$$

现在我们可以按照本书的风格给出Λ- poisedness的定义。

定义5.6。 *Let $\Lambda > 0$ and a set $B \in \mathbb{R}^n$ be given. Let $\bar{\phi}$ be the natural basis of monomials of $\mathcal{P}_n^d$ with $d = 2$. A poised set $Y = \{y^0,\ y^1,\ \ldots,\ y^p\}$, with $p < q$, where $q_1 = q + 1$ is the dimension of $\mathcal{P}_n^d$, is said to be Λ-poised in B (in the minimum Frobenius norm sense) if and only if*

1. *for the set of minimum Frobenius norm Lagrange polynomials associated with Y*

$$\Lambda \;\geq\; \max_{0 \leq i \leq p} \max_{x \in B} |\ell_i(x)|,$$

or, equivalently,

2. *for any $x \in B$ the solution $\lambda(x) \in \mathbb{R}^{p_1}$ of (5.8) is such that*

$$\|\lambda(x)\|_\infty \;\leq\; \Lambda,$$

or, equivalently,

3. *replacing any point in Y by any $x \in B$ can increase the volume* $\mathrm{vol}(\bar{\phi}_{\bar{M}}(Y))$ *at most by a factor* Λ.

这种在最小 Frobenius 范数意义下的 Λ- poisedness 定义自动蕴含了线性回归的 $\sqrt{p_1}\Lambda$- poisedness 定义。这一点很容易看出，因为线性回归中的 $\lambda_r(x)$ 是 (5.8) 中约束的最小范数解，因此 $\|\lambda_r(x)\|_\infty \le \|\lambda_r(x)\| \le \|\lambda(x)\| \le \sqrt{p_1}\|\lambda(x)\|_\infty \le \sqrt{p_1}\Lambda$。特别地，由于线性情形下 $\theta \le 1$（参见定理3.14后的讨论），我们得到 $\|M(\bar{\phi}_L, Y)^\dagger\| \le \sqrt{p_1}\Lambda$，这随后可用于定理5.4。

为了证明基于Λ-平衡集的最小Frobenius范数模型在最小Frobenius范数意义下能产生定理5.4所述类型的一阶泰勒式误差，还需展示模型的Hessian是有界的。

定理 5.7。*Let Assumption* 5.1 *hold, and assume further that Y is Λ-poised in the minimum Frobenius norm sense. Given an upper bound Δ_{max} on Δ, we have that the Hessian H of the minimum Frobenius norm model satisfies*

$$\|H\| \le \frac{4p_1\sqrt{q_1}\nu\Lambda}{c(\Delta_{max})},$$

where $c(\Delta_{max}) =$ 最小$\{1, 1/\Delta_{max}, 1/\Delta_{max}^2\}$.

Proof. 注意，不失一般性，我们可以假设 $y^0 = 0$。由引理3.10可知，存在一个常数 $\sigma_\infty > 0$，它与拉格朗日多项式集无关，使得对于任意 $i \in \{0, \ldots, p\}$，有 $\ell_i(y) = a_i^\top \bar{\phi}(y)$ 并且（其中 $x = y/\Delta$ 和 $a_i(\Delta)$——由 a_i 通过将$\bar{\phi}$ 中线性分量对应的项除以 Δ，以及将$\bar{\phi}$ 中二次分量对应的项除以 Δ^2 所得到的向量）

$$\begin{aligned}\max_{y\in B(0;\Delta)} |a_i^\top \bar{\phi}(y)| &= \|a_i(\Delta)\|_\infty \max_{x\in B(0;1)} |(a_i(\Delta)/\|a_i(\Delta)\|_\infty)^\top \bar{\phi}(x)| \\ &\ge \|a_i(\Delta)\|_\infty \sigma_\infty \\ &\ge \|a_i\|_\infty c(\Delta_{max})\Delta^2\sigma_\infty.\end{aligned}$$

σ_∞的一般定义在引理3.10中给出，并且从引理3.12可知，在二次情形下$\sigma_\infty \ge 1/4$。因此，根据Λ平衡性假设，我们得到

$$\|a_i\|_\infty \le \frac{4\Lambda}{c(\Delta_{max})\Delta^2}.$$

另一方面，我们也知道

$$\begin{aligned}\|\nabla^2\ell_i(y)\| &\le \|\nabla^2\ell_i(y)\|_F \le \sqrt{2}\|a_i^Q\| \le \sqrt{2}(\|a_i^L\| + \|a_i^Q\|) \\ &\le 2\|a_i\| \le 2\sqrt{q_1}\|a_i\|_\infty,\end{aligned}$$

其中 $\ell_i(y) = a_i^\top \bar{\phi}(y) = (a_i^L)^\top \bar{\phi}_L(y) + (a_i^Q)^\top \bar{\phi}_Q(y)$。

不失一般性，我们也可以假设$f(y^0) = 0$和$\nabla f(y^0) = 0$。这样的假设要求从f中减去一个线性多项式。如果我们现在从m^{mfn}中减去相同的多项式，这个新模型将保持最小弗罗贝尼乌斯范数。

变换后的 f 的模型，而 m^{mfn} 的 Hessian 保持不变。但随后我们可以得出结论，在 y^0 附近展开并利用假设 5.1 中所述的 f 的性质，有

$$\max_{y\in B(y^0;\Delta)} |f(y)| \le \frac{\nu}{2}\Delta^2.$$

最后，从（5.10）和上述不等式，我们得到 t

$$\|H\| = \|\nabla^2 m^{\text{mfn}}(y)\| \le \sum_{i=0}^{p} |f(y^i)|\|\nabla^2 \ell_i(y)\| \le \frac{4p_1\sqrt{q_1}\nu\Lambda}{c(\Delta_{max})}. \quad \square \tag{5.11}$$

注意，稳定常数 Λ 在定理5.4的误差界中出现了两次：一次作为线性回归的界，另一次在模型Hessian的界中。

如同定理3.14，我们可以证明，在最小Frobenius范数意义下，对于 poised 集合，$F(\bar{\phi}、Y)$的条件数以及Λ- poisedness 常数彼此之间是相互关联的。为了建立这一结果，我们考虑通过平移和缩放Y得到的一个集合$\hat{Y}$，使其紧致地包含在$B(0;1)$ (内；这意味着$\hat{Y} \subset B(0;1)$，并且$\hat{Y}$中至少有一个点位于$B(0;1)$)的边界上，并在此基础上研究$\hat{F} = F(\bar{\phi}、\hat{Y})$。

定理 5.8. *If $\hat{F}$ is nonsingular and $\|\hat{F}^{-1}\| \le \Lambda$, then the set $\hat{Y}$ is $\kappa\Lambda$-poised in the unit ball $B(0;1)$ centered at 0, where κ depends only on n and p. Conversely, if the set $\hat{Y}$ is Λ-poised in the unit ball $B(0;1)$ centered at 0, then*

$$\|\hat{F}^{-1}\| \le \max\{\theta_0, \theta_2(\Lambda), \theta_4(\Lambda)\}, \tag{5.12}$$

where θ_0, $\theta_2(\Lambda)$, and $\theta_4(\Lambda)$ are polynomials in Λ of degrees 0, 2, and 4, respectively, with nonnegative coefficients dependent only on n and p.

Proof. 如果 $\psi(x) = (\hat{M}_Q\bar{\phi}_Q(x)、\bar{\phi}_L(x))$ 和 $p_F = p_1 + n +$ 均为 1。若$\hat{F}$ 非奇异且 $\|\hat{F}^{-1}\| \le \Lambda$，则由 (5.9) 及 $\max_{x\in B(0;1)}\|\bar{\phi}(x)\|_\infty \le 1$,

$$\|\lambda(x)\|_\infty \le \|\hat{F}^{-1}\|_\infty\|\psi(x)\|_\infty \le p_F^{\frac{1}{2}}\|\hat{F}^{-1}\|\|\psi(x)\|_\infty \le \kappa\Lambda,$$

使用

$$\kappa = p_F^{\frac{1}{2}}\left\|\begin{bmatrix} \hat{M}_Q & 0 \\ 0 & I \end{bmatrix}\right\|.$$

为了证明反向关系，令$\bar{v}$为$\hat{F}^{-1}$的一个归一化特征向量，对应于其绝对值最大的特征值。通过应用引理3.13，取$A = \hat{F}^{-1}$，$w = \bar{v}$，以及对于某个$y \in B(0;1)$的 $r = \psi(y)$，我们得到

$$\|\hat{F}^{-1}\psi(y)\| \ge |\bar{v}^\top\psi(y)|\,\|\hat{F}^{-1}\|.$$

现在注意 {v*} 与 $v_F = (\hat{M}_Q^\top\bar{v}_\lambda、\bar{v}_\mu)$ 以及 $\bar{v} = (\bar{v}_\lambda、\bar{v}_\mu)$。因此，

$$\|\hat{F}^{-1}\psi(y)\| \ge |v_F^\top\bar{\phi}(y)|\,\|\hat{F}^{-1}\|. \tag{5.13}$$

我们知道 $\bar{v}$ 也是$\hat{F}$ 的一个特征向量，对应其绝对值最小的特征值 e_{min}（注意 $|e_{min}|=1/\|\hat{F}^{-1}\|$）。因此，利用$\hat{F}\bar{v}=e_{min}\bar{v}$ 可以推导出

$$\|\hat{M}_Q^\top \bar{v}_\lambda\|^2+e_{min}\|\bar{v}_\mu\|^2 \;=\; e_{min}\|\bar{v}_\lambda\|^2, \tag{5.14}$$

这进而意味着

$$\|v_F\|^2 \;=\; e_{min}\|\bar{v}_\lambda\|^2+(1-e_{min})\|\bar{v}_\mu\|^2. \tag{5.15}$$

现在我们将证明，要么 $|e_{min}|\geq 1/2$（在这种情况下 $\|\hat{F}^{-1}\|\leq 2=\theta_0$），要么有 v_F 使得 $\|v_F\|^2\geq 1/4$ 或 $\|v_F\|^2\geq|e_{min}|$。事实上，如果 $|e_{min}|<1/2$，那么由 (5.15),

$$\|v_F\|^2 \;\geq\; e_{min}\|\bar{v}_\lambda\|^2+|e_{min}|\|\bar{v}_\mu\|^2.$$

因此，当 $e_{min}>0$ 时，因为 $\|\bar{v}\|=1$，

$$\|v_F\|^2 \;\geq\; |e_{min}|\left(\|\bar{v}_\lambda\|^2+\|\bar{v}_\mu\|^2\right) \;=\; |e_{min}|.$$

如果 $e_{min}<0$，那么我们从 (5.14) 知道必定是 $\|\bar{v}_\lambda\|^2\leq\|\bar{v}_\mu\|^2$ 的情况。现在注意到，由于 $\|\bar{v}\|=1$，要么 $\|\bar{v}_\mu\|^2\geq 1/4$，要么 $\|\bar{v}_\lambda\|^2\geq 1/4$；在后一种情况下也会得到 $\|\bar{v}_\mu\|^2\geq\|\bar{v}_\lambda\|^2\geq 1/4$。然后，作为 v 定义的结果 $_F$，我们得到 $\|_p\|2\geq 1/4$。

从引理 3.10，我们可以选择 $y\in B(0;1)$ 以便在适当的情况下 $\sigma_2>0$,

$$|v_F^\top\bar{\phi}(y)| \;\geq\; \sigma_2\|v_F\|.$$

因此，要么

$$|v_F^\top\bar{\phi}(y)| \;\geq\; \frac{\sigma_2}{2},$$

在这种情况下，由(5.13)我们得到$\|\hat{F}^{-1}\psi(y)\|\geq(\sigma_2/2)\|\hat{F}^{-1}\|$，即

$$|v_F^\top\bar{\phi}(y)| \;\geq\; \sigma_2|e_{min}|^{\frac{1}{2}} \;=\; \sigma_2\frac{1}{\|\hat{F}^{-1}\|^{\frac{1}{2}}},$$

在这种情况下，我们有$\|\hat{F}^{-1}\psi(y)\|\geq\sigma_2\|\hat{F}^{-1}\|^{\frac{1}{2}}$，再次使用(5.13)。因此，使用(5.9),

$$\left\|\begin{bmatrix}\lambda(y)\\ \mu(y)\end{bmatrix}\right\| \;=\; \|\hat{F}^{-1}\psi(y)\| \;\geq\; \sigma_2\min\left\{\frac{\|\hat{F}^{-1}\|}{2},\|\hat{F}^{-1}\|^{\frac{1}{2}}\right\}. \tag{5.16}$$

最后，我们利用（5.9）将$\mu(y)$表示为$\lambda(y)$的函数：

$$\hat{M}_L\mu(y) \;=\; \hat{M}_Q\bar{\phi}_Q(y)-\hat{M}_Q\hat{M}_Q^\top\lambda(y).$$

正如我们在定义5.6之后立即看到的，最小弗罗贝尼乌斯范数意义下的Λ-平衡意味着线性（插值或回归）意义下的Λ-平衡。因此，考虑到我们考虑的是单位球，我们可以将$\|\mu(y)\|$用关于Λ的二次多项式来界定：

$$\|\mu(y)\| \;\leq\; \sqrt{p_1}\|\hat{M}_Q\|\Lambda+p_1\|\hat{M}_Q\hat{M}_Q^\top\|\Lambda^2.$$

然后，从$\|\lambda(y)\|_\infty\leq\Lambda$中我们可以看到

$$\left\|\begin{bmatrix}\lambda(y)\\ \mu(y)\end{bmatrix}\right\| \;\leq\; \|\lambda(y)\|+\|\mu(y)\| \;\leq\; \sqrt{p_1}(\|\hat{M}_Q\|+1)\Lambda+p_1\|\hat{M}_Q\hat{M}_Q^\top\|\Lambda^2.$$

由于这个界限并使用（5.16），我们看到要么

$$\|\hat{F}^{-1}\| \leq \frac{2\sqrt{p_1}}{\sigma_2}(\|\hat{M}_Q\|+1)\Lambda + \frac{2p_1}{\sigma_2}\|\hat{M}_Q\hat{M}_Q^\top\|\Lambda^2 = \theta_2(\Lambda)$$

或

$$\|\hat{F}^{-1}\| \leq \left(\frac{\sqrt{p_1}}{\sigma_2}(\|\hat{M}_Q\|+1)\Lambda + \frac{p_1}{\sigma_2}\|\hat{M}_Q\hat{M}_Q^\top\|\Lambda^2\right)^2 = \theta_4(\Lambda),$$

证明完毕。 □

以下定理5.8的推论在第六章中将会很有用。为了清晰起见，我们强调所涉及的常数对自然基底{v*}的依赖性。

推论5.9。*If $\hat{Y}$ is Λ-poised in $B(0;1)$ in the minimum Frobenius norm sense, then* $|\det(F(\bar{\phi},\hat{Y}))| \geq \Theta(n,p,\bar{\phi}) > 0$, *where $\Theta(n,p,\bar{\phi})$ depends only on n, p, and $\bar{\phi}$.*

Proof. 定理5.8保证了仅依赖于n、p和$\bar{\phi}$的常数$\max\{\theta_0, \theta_2(\Lambda), \theta_4(\Lambda)\}$的存在性，使得$\|F(\bar{\phi},\hat{Y})^{-1}\| \leq \max\{\theta_0, \theta_2(\Lambda), \theta_4(\Lambda)\}$。由于对称矩阵行列式的绝对值是其所有特征值的乘积，我们得到

$$|\det(F(\bar{\phi},\hat{Y})| = \frac{1}{|\det(F(\bar{\phi},\hat{Y})^{-1})|} \geq \frac{1}{(\max\{\theta_0,\theta_2(\Lambda),\theta_4(\Lambda)\})^{p_1+n+1}}. \quad \square$$

二次模型的最小Frobenius范数更新

Powell [191] 建议选择欠定插值系统 (5.1) 的解，该解在 Frobenius 范数意义下提供与先前计算的 Hessian 模型 H^{old} 最接近的 Hessian 模型 H。在本章的符号中，这样的模型是以下问题的解：

$$\begin{aligned} \min \quad & \tfrac{1}{2}\|\alpha_Q - \alpha_Q^{old}\|^2 \\ \text{s.t.} \quad & M(\bar{\phi}_L, Y)\alpha_L + M(\bar{\phi}_Q, Y)\alpha_Q = f(Y). \end{aligned} \tag{5.17}$$

与其直接求解 (5.17)，人们可以在 $\alpha_Q^{dif} = \alpha_Q - \alpha_Q^{old}$ 上求解一个移位问题，然后计算 α_Q 作为 $\alpha_Q^{dif} + \alpha_Q^{old}$ (，对于 α_L) 也是如此。移位问题表述如下：

$$\begin{aligned} \min \quad & \tfrac{1}{2}\|\alpha_Q^{dif}\|^2 \\ \text{s.t.} \quad & M(\bar{\phi}_L, Y)\alpha_L^{dif} + M(\bar{\phi}_Q, Y)\alpha_Q^{dif} = f^{dif}(Y), \end{aligned} \tag{5.18}$$

其中 $f^{dif}(Y) = f(Y) - m^{old}(Y)$。问题 (5.18) 则属于 (5.6) 中给出的类型。

可以证明（见[191]或下面的练习），如果f本身是一个二次函数，那么

$$\|H - \nabla^2 f\| \leq \|H^{old} - \nabla^2 f\|, \tag{5.19}$$

其中 $\nabla^2 f$ 是 f 的常数海森矩阵。这一性质表明了鲍威尔最小弗罗贝尼乌斯更新的良好表现（正如我们将在第11章讨论的那样）。

5.4 注释和参考文献

构造具有保证线性精度的“拟牛顿”模型的另一个有效思路是采用我们在第3章讨论过的NFP。首先，选取$n+1$个仿射无关点作为Y的子集，并构造线性NFP集合。然后对于剩余的点，NFP集合是欠定的。如上文对拉格朗日多项式所述，我们可以考虑二次块的最小Frobenius范数NFP。NFP随后可以作为样本集适定性的度量、选择样本点的准则，并用于构造插值模型。关于NFP使用的进一步参考文献可见于[59, 205]。

迄今为止，最小弗罗贝尼乌斯范数模型已被证明是基于插值的信赖域方法中最成功的二阶模型。它们至少在两种软件实现中得到应用。在DFO代码中（参见第11章及附录），它们被用于为任何$n+1<p<q$构建模型，其中海森矩阵具有最小的弗罗贝尼乌斯范数，并且样本集的选择基于NFPs。如上所述，[191, 192]中的模型被构造为最小化不是海森矩阵本身的弗罗贝尼乌斯范数，而是模型的海森矩阵从一次迭代到下一次迭代的变化的弗罗贝尼乌斯范数。这一巧妙的想法在$p_1=2n+1$时非常成功地起作用，并且是一种以拟牛顿方法风格重建二阶信息的尝试。样本集的选择基于最小弗罗贝尼乌斯范数拉格朗日多项式。我们将在第11章中更详细地讨论这两种方法。

5.5 练习题

1. 证明如果矩阵 $M(\bar{\phi}、Y)$ 具有满行秩，则与$\bar{\phi}$ 关联的最小范数拉格朗日多项式集合存在且唯一。

2. 给定一个平衡集 Y，证明由 (5.2) 的最小二乘解定义的函数 $\lambda_i(x)、i=0、\ldots、p$ 构成定义 5.1 中给出的 Y 的最小范数拉格朗日多项式集合。

3. 证明最小弗罗贝尼乌斯范数多项式存在且唯一，当且仅当矩阵 (5.7) 非奇异。（表述问题 (5.6) 的一阶必要和充分条件，消去 α_Q，并将这些条件用拉格朗日乘子和 α_L 表示。）

4. 证明最小Frobenius范数模型的Hessian矩阵H为

$$H=\sum_{i=0}^{p}\mu_i\left((y^i)(y^i)^\top-\frac{1}{2}D^i\right),$$

其中 D^i 是对角矩阵，其对角元素为 $[y^i_j]^2、j=1、\ldots、n、\mu_i$，而 $i=0、\ldots、p$ 是与 (5.6) 中等式约束相关的拉格朗日乘子。（根据之前的练习，容易看出 $[\alpha_Q]_1=\sum_{i=0}^{p}\frac{1}{2}\mu_i[y^i_1]^2、[\alpha_Q]_2=\sum_{i=0}^{p}\mu_i y^i_1 y^i_2、\ldots、[\alpha_Q]_{q-n}=\sum_{i=0}^{p}\frac{1}{2}\mu_i[y^i_n]^2$。）

5. 假设Y在最小Frobenius范数意义下处于平衡状态。证明(5.8)的解是定义5.5中给出的（唯一）最小Frobenius范数拉格朗日多项式集合。（陈述一阶必要和充分条件

对于与y^i相关联的第$(i+1)$个指示函数，将(5.6)式表达为(5.7)式逆矩阵第i列的函数，并对$\lambda(x)$的第i个分量做同样处理。）

6. 假设 Y 在最小 Frobenius 范数意义下处于平衡状态。利用上一题的推导，证明(5.10)。

7. 假设 Y 是在最小 Frobenius 范数意义下最优的。证明定义5.5中给出的最小 Frobenius 范数拉格朗日多项式是与以下问题的等式约束相关的拉格朗日乘子：

$$\begin{aligned} \min \quad & \tfrac{1}{2}\|\alpha_Q\|^2 + (\bar{\phi}_L(x))^\top \alpha_L \\ \text{s.t.} \quad & M(\bar{\phi}_L, Y)\alpha_L + M(\bar{\phi}_Q, Y)\alpha_Q \;=\; M(\bar{\phi}_Q, Y)\bar{\phi}_Q(x). \end{aligned}$$

8. 证明当f为二次时（5.19），通过以下步骤进行。首先，考虑函数

$$h(\theta) \;=\; \|(H - H^{old}) + \theta(\nabla^2 f - H)\|$$

并证明其在 $\theta = 0$ 处取得极小值点。然后，写出 $h'(0) = 0$，并看到 $H - H^{old}$ 和 $\nabla^2 f - H$ 在迹矩阵内积下正交。基本上，你已经证明了 H 是 H^{old} 在由插值条件定义的二次函数仿射集上的投影，该投影使用 H 中的 Frobenius 范数。

第6章

确保良好的平衡性和合适的无导数模型

在第3–5章中，样本集Y通常被认为是给定且固定的，我们探讨了与这类集合相关的多项式基和模型的性质。相反，在本章中，我们将考虑修改集合Y以提高模型的质量。从第3–5章可知，模型的质量与样本集的适定性有关。为了激发本章的内容，我们首先汇总无导数模型所需的条件和误差界，这些是无导数算法（如第10章的信任域方法）所要求的。我们从模型函数的具体细节中抽象出来，陈述这些模型的一般要求。特别是对于多项式插值和回归模型，这些要求意味着样本集Y必须具有Λ适定性，并且对于无导数算法使用的所有样本集，Λ的上界是固定的。事实证明，这一性质实际上不必对无导数算法使用的*all*模型成立，但必须在必要时进行检查并强制执行。为了强制执行这一点，我们需要能够执行检查和强制执行的算法，并且这些算法可以在无导数框架内高效使用（例如，第10章中描述的框架）。

我们将讨论构造平衡插值或回归集的算法，以及那些改进并维持这些集的平衡常数的算法。回忆一下，Λ-平衡性的定义要求与样本集相关的拉格朗日多项式的最大绝对值不超过Λ。我们在此讨论的算法基于构造拉格朗日或其他（类似）多项式基，并将这些作为修改样本集Y的指南。

我们将讨论两种主要的算法方法来更新集合 Y。一种方法是直接控制拉格朗日多项式的绝对值。这将在第6.2节中讨论。另一种方法通过应用枢轴算法来“间接”控制 Λ 的平衡性，以控制矩阵 $M(\phi, Y)$ (的缩放版本 $M(\bar{\phi}, \hat{Y})$ 的条件数，见第3-5章)，该矩阵定义了拉格朗日多项式系统。在第6.3节中，我们将描述这样一种枢轴算法。

在本章中，我们将始终把样本集称为 Y，并且应当理解，随着算法推进，该集合会不断更新。为了使符号简洁，我们不会按迭代次数或算法步骤来区分不同的插值集合。每次使用 Y 符号的含义都应能从上下文中明确看出。当

并非如此，我们采用了一些额外的记号。还需提及的是，在本章中Y中点的顺序很重要，因为Y中的点可能被每种算法按一定顺序考虑、接受、拒绝或替换。自然，一旦集合Y确定，点的顺序对插值或回归模型没有影响。我们将考虑任意集合Y以及我们记为$\hat{Y}$的集合，后者是通过平移和缩放Y得到的，使得包含$\hat{Y}$的最小外接球为$B(0;1)$——即以原点为中心、半径为1的球。

6.1 完全线性与完全二次模 els

在本节中，我们将从所用模型的具体细节中抽象出来。我们仅对模型施加那些对于重现泰勒模型的性质至关重要的要求，这些性质是保证基于插值的无导数方法（如第10章的信任域方法）全局收敛所必需的。我们将展示，特别是多项式插值和回归模型，能够满足这些要求。

在一个无导数算法框架中（如第10章所描述的那样），必须确保在需要时能够构建出具有一致良好局部精度的目标函数模型。在线性逼近的情况下，我们将称这样的模型必须属于*fully linear*类。这一概念要求以下假设。

假设 6.1. *Suppose that a set S and a radius Δ_{max} are given. Assume that f is continuously differentiable with Lipschitz continuous gradient in an appropriate open domain containing the Δ_{max} neighborhood $\bigcup_{x\in S} B(x;\Delta_{max})$ of the set S.*

在基于模型的方法的算法背景下，通常会给定一个点 x_0，并在形式为 $S = L(x_0) = \{x \in \mathbb{R}^n$ 的水平集上施加函数 f 的平滑性条件：$f(x) \le f(x_0)\}$。通常还会对模型所考虑的球的大小施加上限 Δ_{max}。*fully linear* 类模型的定义如下。

定义 6.1。 *Let a function $f:\mathbb{R}^n \to \mathbb{R}$, that satisfies Assumption 6.1, be given. A set of model functions $\mathcal{M} = \{m : \mathbb{R}^n \to \mathbb{R}, m \in C^1\}$ is called a fully linear class of models if the following hold:*

1. *There exist positive constants κ_{ef}, κ_{eg}, and ν_1^m such that for any $x \in S$ and $\Delta \in (0, \Delta_{max}]$ there exists a model function $m(y)$ in $\mathcal{M}$, with Lipschitz continuous gradient and corresponding Lipschitz constant bounded by ν_1^m, and such that*

   - *the error between the gradient of the model and the gradient of the function satisfies*
   $$\|\nabla f(y) - \nabla m(y)\| \le \kappa_{eg}\,\Delta \quad \forall y \in B(x;\Delta), \tag{6.1}$$
   and
   - *the error between the model and the function satisfies*
   $$|f(y) - m(y)| \le \kappa_{ef}\,\Delta^2 \quad \forall y \in B(x;\Delta). \tag{6.2}$$

Such a model m is called fully linear on $B(x;\ \Delta)$.

2. *For this class $\mathcal{M}$ there exists an algorithm, which we will call a "model-improvement" algorithm, that in a finite, uniformly bounded (with respect to x and Δ) number of steps can*

- *either establish that a given model $m \in \mathcal{M}$ is fully linear on $B(x;\ \Delta)$ (we will say that a certificate has been provided and the model is certifiably fully linear),*
- *or find a model $\tilde{m} \in \mathcal{M}$ that is fully linear on $B(x;\ \Delta)$.*

在二次逼近的情况下，我们将要求模型属于 *fully quadratic* 类，为此我们需要更高的光滑度。

假设 6.2. *Suppose that a set S and a radius Δ_{max} are given. Assume that f is twice continuously differentiable with Lipschitz continuous Hessian in an appropriate open domain containing the Δ_{max} neighborhood $\bigcup_{x\in S} B(x;\ \Delta_{max})$ of the set S.*

下面定义的完全二次模型类具有均匀良好的局部二阶精度。

定义 6.2。 *Let a function f, that satisfies Assumption 6.2, be given. A set of model functions $\mathcal{M} = \{m :\ \mathbb{R}^n \to \mathbb{R}$, $m \in C^2\}$ is called a fully quadratic class of models if the following hold:*

1. *There exist positive constants κ_{ef}, κ_{eg}, κ_{eh}, and ν_2^m, such that for any $x \in S$ and $\Delta \in (0, \Delta_{max}]$ there exists a model function $m(y)$ in $\mathcal{M}$, with Lipschitz continuous Hessian and corresponding Lipschitz constant bounded by ν_2^m, and such that*

- *the error between the Hessian of the model and the Hessian of the function satisfies*
$$\|\nabla^2 f(y) - \nabla^2 m(y)\| \ \le\ \kappa_{eh}\,\Delta \quad \forall y \in B(x;\Delta), \tag{6.3}$$
- *the error between the gradient of the model and the gradient of the function satisfies*
$$\|\nabla f(y) - \nabla m(y)\| \ \le\ \kappa_{eg}\,\Delta^2 \quad \forall y \in B(x;\Delta), \tag{6.4}$$
and
- *the error between the model and the function satisfies*
$$|f(y) - m(y)| \ \le\ \kappa_{ef}\,\Delta^3 \quad \forall y \in B(x;\Delta). \tag{6.5}$$

Such a model m is called fully quadratic on $B(x;\ \Delta)$.

2. *For this class $\mathcal{M}$ there exists an algorithm, which we will call a "model-improvement" algorithm, that in a finite, uniformly bounded (with respect to x and Δ) number of steps can*

- *either establish that a given model $m \in \mathcal{M}$ is fully quadratic on $B(x;\ \Delta)$ (we will say that a certificate has been provided and the model is certifiably fully quadratic),*

- *or find a model* $\tilde{m} \in \mathcal{M}$ *that is fully quadratic on* $B(x; \Delta)$.

注意，完全二次（或完全线性）类的定义并不意味该类中包含的*all*模型对给定的Δ和x满足(6.3)–(6.5)（或(6.1)–(6.2)）。为了使类的定义独立于Δ和x的选择，情况必须如此。仅要求对于任何特定选择的Δ和x，存在满足(6.3)–(6.5)（或(6.1)–(6.2)）的类成员。

由于定义6.1和6.2的灵活性，符合其框架的一些模型类通常对实用算法不感兴趣。例如，考虑$\mathcal{M} = \{f\}$——一个由函数f本身组成的类。显然，根据定义6.2，这样的$\mathcal{M}$是一个完全二次模型类，因为对于任何x和Δ，f都是其自身的完全二次模型，并且验证f是否为完全二次的算法是平凡的。

线性的或完全二次类的另一个不切实际之处在于模型改进算法的选择具有灵活性。在完全线性情况下，其定义要求存在一个有限过程，该过程要么证明模型是完全线性的，要么生成这样的模型。例如，基于适当选择的有限差分梯度评估的泰勒模型是一类完全线性模型，但模型改进算法需要为每个新的x和Δ“从头开始”构建此类模型。在具有昂贵（且通常有噪声）函数评估的无导数算法中，这种方法通常是不切实际的。然而，只要满足所有必要的假设，完全线性模型的框架仍然支持这种方法并保证其收敛性。

完全线性和完全二次模型抽象的目的是，允许使用可能不同于多项式插值和回归的模型，只要这些模型符合定义6.1和6.2。我们认为，这种抽象突出了获取基于插值的信赖域算法或其他基于采样的算法相应全局收敛结果的基本要求，其中模型预期再现泰勒模型的局部一致行为。

多项式模型的情况

人们可以立即观察到，可以选择线性与二次、插值与回归、多项式模型来满足定义6.1和6.2的误差界。事实上，给定$\Lambda > 1$，任何基于Λ- poised集的线性（分别地，二次）多项式插值模型，或基于强Λ- poised集的多项式回归模型，都是同一完全线性（分别地，完全二次）类的元素，其中常数κ_{ef}和κ_{eg} (分别，κ_{ef}、κ_{eg}和κ_{eh})仅依赖于Λ、样本集的基数p_1、多项式空间的维数q_1，以及假设6.1（分别地，假设6.2）中∇f (分别地，$\nabla^2 f$)的Lipschitz常数。从第5.3节的讨论中我们也知道，基于Λ- poised集（在最小Frobenius范数意义下）的最小Frobenius范数模型是完全线性的，其中κ_{ef}和κ_{eg}仅依赖于Λ、p_1和多项式空间的q_1，以及∇f的Lipschitz常数。注意，由于线性多项式模型的梯度和二次多项式模型的Hessian是常数，它们对于任何正的Lipschitz常数都是平凡Lipschitz连续的。

也可以在某些条件下（见练习）保证，基于 Λ- poised 集的二次多项式模型的梯度是 Lipschitz 连续的——并且

因此，（插值或回归）二次多项式模型也满足完全线性类定义中所需的边界。

在本章剩余部分，我们将展示多项式插值及回归模型如何能提供完全线性及完全二次的模型类别。为此，我们需要解决定义6.1和6.2所要求的有限模型改进算法的存在问题。

6.2 使用拉格朗日多项式确保良好姿态

我们从第3章了解到，给定一组插值点，拉格朗日多项式$\ell(x)$（见定义3.3）在感兴趣区域内的绝对值最大值定义了插值集在该区域内的Λ平衡性（见定义3.6）。因此，直接监控并控制$\ell(x)$的大小作为保持插值集良好平衡性的一种方法是很自然的。回归集（见第4章）和欠定插值集（见第5章）的情况有所不同；因此，目前我们将专注于完全确定的插值。

在我们讨论通过拉格朗日多项式维持插值集合的Λ-平衡性的方法之前，让我们先讨论一下，给定一个插值集合，如何计算和更新拉格朗日多项式。

计算并更新拉格朗日多项式

给定插值集 $Y = \{y^0、y^1、\ldots、y^p\}$，其基数等于多项式空间 $\mathcal{P}_n^d$ 的维数，以下过程生成拉格朗日多项式基。

算法6.1（计算拉格朗日多项式）。

初始化：首先选择拉格朗日多项式基的一个初始近似，例如由单项式基（3.1），$\ell_i(x) = \bar{\phi}_i(x)$，$i = 0, \ldots, p$ 给出。

对于 $i = 0, \ldots, p$

1. 点选择：找到 $j_i =$ 的 $\operatorname{argmax}_{i \le j \le p} |\ell_i(y^j)|$。若 $\ell_i(y^{j_i}) =$ 为 0，则停止（集合 Y 不是 poised 的）。否则，在集合 Y 中交换点 y^i 和 y^{j_i}。

2. 归一化：

$$\ell_i(x) \leftarrow \ell_i(x)/\ell_i(y^i). \tag{6.6}$$

3. 正交化：对于 $j = 0, \ldots, p, j \neq i$,

$$\ell_j(x) \leftarrow \ell_j(x) - \ell_j(y^i)\ell_i(x). \tag{6.7}$$

很容易验证该算法确实生成了拉格朗日多项式基。经过第一次迭代后，我们得到

$$\ell_0(y^0) = 1 \quad \text{and} \ell \quad _j(y^0) = 0,\ j = 1, \ldots, p. \tag{6.8}$$

第二次迭代后，我们得到

$$\ell_1(y^1) = 1 \quad \text{and} \quad \ell_j(y^1) = 0,\ j = 0,\ldots,p,\ j \neq 1.$$

然而，第二次迭代并未破坏(6.8)，因为$\ell_1(y^0) \leftarrow \ell_1(y^0)/\ell_1(y^1)$和
$\ell_j(y^0) \leftarrow \ell_j(y^0) - \ell_j(y^1)\ell_1(y^0)$，$j =$为0，…，$p$，$j \neq$为1。剩下的证明留作练习。

每个拉格朗日多项式最多可以有 $p_1 = p+1$ 个系数；因此，计算公式(6.6)和(6.7)中每个多项式的求值和更新需要 $\mathcal{O}(p)$ 次运算。这样的多项式共有 $p+1$ 个，而在算法的每次迭代中，最多有 $p+1$ 个这样的多项式被求值和更新。由于算法总是执行 $p+1$ 步，从头计算拉格朗日多项式集合需要 $\mathcal{O}(p^3)$ 次运算。

现在假设拉格朗日多项式基已经可得。问题是，如果插值集合$Y = \{y^0$、y^1、…、$y^p\}$中的一个点，比如说y^k，被一个新的点，比如说y_*^k所替换，它将如何变化。新的插值集合变为

$$Y^* = Y \cup \{y_*^k\} \setminus \{y^k\}.$$

用 $\ell_j^*(x)$、$j = 0$、…、p 表示对应于 Y^* 的新拉格朗日多项式。如果 $\ell_k(y_*^k) \neq 0$，那么我们只需对 $i = k$ 执行上述算法的归一化和正交化步骤。特别地，

$$\ell_k^*(x) = \ell_k(x)/\ell_k(y_*^k), \tag{6.9}$$

$$\ell_j^*(x) = \ell_j(x) - \ell_j(y_*^k)\ell_k^*(x) \quad \forall j \in \{0,\ldots,p\},\ j \neq k. \tag{6.10}$$

如果发生$\ell_k(y_*^k) = 0$的情况，则我们有一个非平凡多项式在所有Y^*点上消失，因此得到的集合Y^*不是平衡的，上述步骤无效。

现在从(6.9)和(6.10)容易看出，更新拉格朗日多项式的努力为$\mathcal{O}(p^2)$，因为它等同于执行算法6.1的一次迭代。在线性插值的情况下，$p = \mathcal{O}(n)$，计算整个拉格朗日多项式集的成本并不高。另一方面，在二次插值的情况下，$p = \mathcal{O}(n^2)$，计算整个拉格朗日多项式集的成本为$\mathcal{O}(n^6)$，如果频繁使用，除了小规模n外，这可能会变得难以承受。因此，将插值集的变化限制为简单的单点更新，就拉格朗日多项式计算而言，可以意味着显著的节省。现在我们可以回忆，插值模型可以表示为具有已知系数的拉格朗日多项式的简单线性组合。因此，插值模型的计算简化为计算拉格朗日多项式集，故而具有相同的复杂度。特别地，如果可以在$\mathcal{O}(n^2)$步内重新计算一组新的拉格朗日多项式，那么新模型也可以如此。

几何检查算法

为了使 Λ 平衡性要求变得实用，我们需要有一个程序，当给定一个插值集合 Y 时，该程序能够验证该集合在给定的闭球 B 中是否是 Λ 平衡的，或者，如果验证失败，能够以这样的方式进行改进步骤，使得经过有限次这些步骤后，集合 Y 保证成为 Λ 平衡的。

需要考虑两种情况。第一种情况是 Y 既未准备好，或者其包含的点少于 p_1 个。这种情况由算法6.1的点选择步骤检测出来（实际中，零测试会用绝对值上的适当容差来代替）。为了在这种情况下改进集合 Y，我们考虑对算法6.1进行以下修改。（稍后我们将考虑第二种情况，即给定的集合 Y 至少包含 p_1 个点且已准备好。）

算法6.2（通过拉格朗日多项式补全非平衡集 {v*}）。

初始化：首先选择拉格朗日多项式基的初始近似，例如由单项式基 (3.1) 给出，$\ell_i(x) = \bar{\phi}_i(x)$，$i = 0, \ldots, p$。令 $p_{ini} + 1$ 为初始集合 Y 中给定点的数量。

对于 $i = 0, \ldots, p$

1. 点选择：找到 $j_i = \text{argmax}_{i \le j \le p_{ini}} |\ell_i(y^j)|$。如果 $|\ell_i(y^{j_i})| > 0$ 且 $i \le p_{ini}$，则交换集合 Y 中的点 y^i 和 y^{j_i}。否则，计算（或如果 $i \le p_{ini}$，则重新计算）y^i 如下：
$$y^i \in \operatorname*{argmax}_{x \in B} |\ell_i(x)|.$$
2. 归一化：
$$\ell_i(x) \leftarrow \ell_i(x)/\ell_i(y^i).$$
3. 正交化：对于 $j = 0, \ldots, p, j \ne i$，
$$\ell_j(x) \leftarrow \ell_j(x) - \ell_j(y^i)\ell_i(x).$$

该算法首先会将那些使集合成为适定集的点包含在Y中。一旦用完这样的点，它就会丢弃任何剩余的点（那些使集合非适定的点）。然后，它通过最大化下一个合适的拉格朗日多项式，一次生成一个点，直到Y包含p_1个点。该算法的复杂度取决于在B中对拉格朗日多项式进行全局优化的复杂度。

现在让我们关注 Y 已就位且恰好有 p_1 个点的情况（它可能有更多点，但我们只需忽略未使用的点）。我们希望有一个算法，对于给定的 $\Lambda > 1$，检查 Y 是否为 Λ-就位，如果不是，则使其成为就位。为了检查 Y 是否为 Λ-就位，我们可以计算 B 上拉格朗日多项式的最大绝对值。如果这样的最大绝对值低于给定的 Λ，那么 Y 是 Λ-就位的。如果它不低于 Λ，那么与具有最大最大绝对值的拉格朗日多项式对应的插值点将被替换为在该球面上使该拉格朗日多项式最大化的点。

算法6.3（通过拉格朗日多项式改善良态性）。

初始化：选择某个常数 $\Lambda > 1$。假设已给定一个处于平衡状态的插值集合 Y，其基数为 p_1 (若未给定，则应用算法6.2生成这样的集合)。若未

已可用，计算与$Y(=Y_0)$相关的拉格朗日多项式$\ell_i(x)$、$i=0$、…、p。

关于 $k=1$、2、…

1. 估计

$$\Lambda_{k-1} \;=\; \max_{0\le i\le p}\ \max_{x\in B} |\ell_i(x)|.$$

Λ_k-可以通过在B上最大化所有拉格朗日多项式的绝对值来精确计算1, 或通过上下界进行估计。确保Λ_{k-1}的已知精度足以保证$\Lambda_{k-1} > \Lambda$或 $\Lambda_{k-1} \le \Lambda$。

2. 如果 $\Lambda_{k-1} > \Lambda$，则令 $i_k \in \{0,\ \ldots,\ p\}$ 为一个索引，其中

$$\max_{x\in B} |\ell_{i_k}(x)| \;>\; \Lambda,$$

并令 $y_*^{i_k} \in B$ 为在 B (中使 $|\ell_{i_k}(x)|$ 达到最大值的点，这取决于步骤 1) 中执行的优化，近似或精确地成立。
通过执行点交换来更新 $Y(=Y_k)$

$$Y \;\leftarrow\; Y \cup \{y_*^{i_k}\} \setminus \{y^{i_k}\}.$$

否则（即，$\Lambda_{k-1} \le \Lambda$），$Y$处于$\Lambda$准备状态并停止。

3. 更新所有拉格朗日多项式系数。

假设二次多项式在B上的全局最大化可以实现（例如，如[172]中所述），让我们证明对于任何$\Lambda > 1$，上述算法将在有限且一致有界的步骤后停止。

首先，让我们回顾拉格朗日多项式在平移和缩放方面的性质。因此，给定一个位于球 Y 中的集合 B，我们观察到算法6.3的行为与将其应用于 Y 的平移和缩放版本时完全相同，该版本紧密位于 $B(0;\ 1)$ (中，这意味着它是 $B(0;\ 1)$ 的子集，并且其至少一个点位于 $B(0;\ 1))$ 的边界上。所谓行为完全相同，我们指的是该算法将替换相同的点序列，并且所得到的新样本集在平移和缩放意义下是相同的。

定理 6.3。 *For any given $\Lambda > 1$, a closed ball B, and a fixed polynomial basis ϕ, Algorithm* 6.3 *terminates with a Λ-poised set Y after at most $N = N(\Lambda, \phi)$ iterations, where N is a constant which depends on Λ and ϕ.*

Proof. 我们将定理的证明分为三部分。

第1部分。回想 $\ell(x) = \lambda(x)$、(3.6) 关于拉格朗日多项式，以及对于某个固定多项式基 ϕ 的 $\phi(Y) = M(\phi、\ Y)$ 的定义。方程 (3.6) 表明 $|\ell_{i_k}(y_*^{i_k})|$ 是

等于在$\phi(Y^*)$中顶点的单纯形体积与在$\phi(Y)$中顶点的单纯形体积之比，其中$Y^* = Y \cup \{y_*^{i_k}\} \setminus \{y^{i_k}\}$：

$$|\ell_{i_k}(y_*^{i_k})| = \frac{\text{vol}(\phi(Y^*))}{\text{vol}(\phi(Y))} > \Lambda > 1.$$

这意味着，每当一个点y^{i_k}被新点$y_*^{i_k}$替换，使得$|\ell_{i_k}(y_*^{i_k})| > \Lambda > 1$时，相应的单纯形体积至少增加$\Lambda$倍。

所有点都被认为在闭球B内，因此$\phi(B)$是$\mathbb{R}^{p_1}$中的紧集。这意味着由$\phi(Y)$定义的单纯形的体积不能以常数因子$\Lambda > 1$无限增加。设$V_{max} = V(\phi、Y_{max})$为对于$Y \subset B$，由$\phi(Y)$形成的所有单纯形的最大体积，并设$V(\phi、Y_0)$为对于初始集合$Y_0$，由$\phi(Y_0)$中的顶点定义的单纯形体积。算法6.3的步数不能超过$\lfloor \log_\Lambda(V_{max}/V(\phi、Y_0))\rfloor$。注意这个量与尺度无关。

第2部分。我们现在将证明，经过最多p_1步后，算法6.3计算出一个集合Y，使得单纯形体积满足$V(\phi, Y) \geq \Theta(p, \phi) > 0$。首先，我们将展示，在最多$p_1$次迭代后，算法获得一个集合$Y$，该集合是$2^p$- poised的。

假设执行了一次需要更新的算法6.3迭代，点y^{i_1}被替换，拉格朗日多项式得到更新。更新后，由于ℓ_{i_1}除以其最大值，我们有$\max_{x\in B}|\ell_{i_1}(x)| \leq 1$。然后，在下一步需要替换点时，$i_2 \neq i_1$，因为我们选择一个在$B$上值大于1的多项式。第二步之后，我们再次有$\max_{x\in B}|\ell_{i_2}(x)| \leq 1$，同时$\max_{x\in B}|\ell_{i_1}(x)| \leq 2$，因为$\ell_{i_1}(x) \leftarrow \ell_{i_1}(x) - \ell_{i_1}(y^{i_2})\ell_{i_2}(x)$。在第三步，我们要么有一个2- poised集，要么有$i_3 \notin \{i_1, i_2\}$。按照上述相同的逻辑，在第三步之后我们有$\max_{x\in B}|\ell_{i_3}(x)| \leq 1$，$\max_{x\in B}|\ell_{i_2}(x)| \leq 2$，以及$\max_{x\in B}|\ell_{i_1}(x)| \leq 4$。通过扩展这一论证并应用数学归纳法，我们很容易得出，在经过p_1步之后，我们将得到一个2^p-poised集Y。

第3部分。根据本定理之前的注释，我们知道如果算法运行p_1步，那么它将产生与应用于$B(0$中的平移和缩放后的$\hat{Y}$；$1)$相同的集合（在平移和缩放意义下）。这意味着我们可以应用推论3.15，该推论指出，经过p_1步后获得的顶点为Y的单纯形的体积$V(\phi、Y)$一致地远离零有界：$V(\phi、\hat{Y}) \geq \Theta(p、\phi) > 0$，其中$\Theta(p、\phi)$仅依赖于$p$和$\phi$。（推论3.15是针对自然基$\phi$陈述的，但通过相应重新定义$\theta$，对任何$\phi$都成立。）因此，$\lfloor \log_\Lambda(V_{\max}/V(\phi、Y))\rfloor$一致地由上界常数$N_1$所界，该常数仅依赖于$\Lambda$、$p$和$\phi$。令$N = N_1 + p_1$即可完成证明。 □

请注意，证明的第一部分，即步骤数被证明是有限的（但不一定一致有界），如果仅使用每一步新点上拉格朗日多项式的绝对值大于Λ这一事实，仍然成立。然而，证明步骤数不仅有限而且一致有界需要初始集合Y_0体积的一致下界。这在证明的第二和第三部分中得以完成。注意，在证明的第二部分，为了展示经过p_1步后我们可以获得一个2^p- poised集合，我们需要在每次迭代中找到B上拉格朗日多项式的全局最大绝对值。如果找到一种不同的方法来确保初始集合Y_0体积的一致下界，这样的要求可以被规避。

我们现在概述如何修改算法6.3，以避免在每一步对所有多项式进行全局优化。算法6.3的每个改进步骤都会更新拉格朗日多项式，我们知道这需要$\mathcal{O}(p^2)$步。因此，每一步对所有拉格朗日多项式在B上的全局优化可能主导整体计算量。这种优化可能是必要的，以查明是否存在任何多项式的最大绝对值超过Λ。通过查看拉格朗日多项式的系数，而不是其实际最大绝对值，有可能减少计算量。这将消除在每一步优化所有多项式的必要性。

通过了解 B 和多项式系数，可以估计其最大绝对值的上界。例如，一个关于 $\mathbb{R}^2$ 的二次多项式，其系数不超过100，在原点周围半径为1的球体内，其绝对值不可能超过600，因为它的值是六个单项式之和，每个单项式的绝对值都不超过100。任意球体内多项式值的上界可以类似地推导：根据多项式在球心处的值和球体的半径，可以估计球体内多项式值的最大变化。可以利用这些上界来估计 Λ 稳定常数的上界，并选择需要优化的拉格朗日多项式。

为了尽可能避免多项式的全局优化，我们还需要对拉格朗日多项式的最大绝对值使用特定的下界。这可以通过例如下文引理6.7证明中概述的枚举方法来实现。证明中的过程是针对至少有一个系数的绝对值不小于1的多项式概述的。显然，同样的过程可以应用于系数最大绝对值的任何正下界。例如，在二次多项式的情况下，如果$b > 0$是这样的一个界，那么多项式本身最大绝对值的下界保证至少为$b/4$（而不是$1/4$）。然而，重要的是要记住，当拉格朗日多项式的全局优化被构造上界和下界的过程所取代时，定理6.3的应用并不是直接的。

在本章中我们展示的算法6.3性能示例中，我们执行所有拉格朗日多项式的全局优化，并选取绝对值最大的多项式索引作为i_k。在第11章（见11.3节）介绍的一个算法中，我们考虑根据插值点y^{i_k}到B中心的距离来选择i_k。如果所选拉格朗日多项式的最大绝对值不超过Λ，则可以考虑下一个最远点的索引。这种方法符合算法6.3的框架，并且具有节省拉格朗日多项式全局优化及在点选择过程中提供灵活性的优点。

一个例子

为了说明算法6.3的逐步结果，我们提供了一个示例，其中该算法应用于图3.2中姿态不佳的集合，其$\Lambda =$为21296。为了简化表示和计算，我们在此对集合进行了平移和缩放，使其位于以原点为中心的单位球内或附近。这涉及将点按比例因子二进行缩放；因此，Λ常数减少了4倍，变为$\Lambda =$5324。我们正在计算姿态性。

在原点周围的单位球内，即$B = B(0; 1)$ (尽管Y不是B)的子集。下面我们列出初始集合Y_0以及由算法6.3的前五次迭代计算得到的集合Y_1、...、Y_5，这些也在图6.1中展示。在每次迭代中，集合中的一个点被一个更好的点替换，且 poisedness 得到改善。

$$Y_0 = \begin{bmatrix} -0.98 & -0.96 \\ -0.96 & -0.98 \\ 0 & 0 \\ 0.98 & 0.96 \\ 0.96 & 0.98 \\ 0.94 & 0.94 \end{bmatrix}, \quad Y_1 = \begin{bmatrix} -0.98 & -0.96 \\ -0.96 & -0.98 \\ & 0 \\ 0.98 & 0.96 \\ 0.96 & 0.98 \\ 0.707 & -0.707 \end{bmatrix},$$

$$Y_2 = \begin{bmatrix} -0.848 & 0.528 \\ -0.96 & -0.98 \\ 0 & \\ 0.98 & 0.96 \\ -0.96 & -0.98 \\ 0.707 & -0.707 \end{bmatrix}, \quad Y_3 = \begin{bmatrix} 0.848 & 0.528 \\ -0.96 & -0.98 \\ 0 & 0 \\ 0.98 & 0.96 \\ -0.89 & 0.996 \\ 0.707 & -0.707 \end{bmatrix}, \tag{6.11}$$

$$Y_4 = \begin{bmatrix} -0.967 & 0.254 \\ -0.96 & -0.98 \\ 0 & 0 \\ 0.98 & 0.96 \\ -0.089 & 0.996 \\ 0.707 & -0.707 \end{bmatrix}, \quad Y_5 = \begin{bmatrix} -0.967 & 0.254 \\ -0.96 & -0.98 \\ 0 & 0 \\ 0.98 & 0.96 \\ -0.199 & 0.979 \\ 0.707 & -0.707 \end{bmatrix}.$$

如我们所见，该算法在五步内几乎达到了最优稳定度。这些步骤迫使算法几乎完全替换了插值集。然而，我们注意到，在三步之后，已接近最优稳定度，这恰好反映了在这种情况下，为补救近仿射依赖性所需替换的点的数量。相反，如果我们考虑图3.3中严重失衡的集合，其中六个点几乎位于一个圆上，从图6.2我们可以看到，只需执行算法6.3的一步，我们就能达到最优稳定度。

6.3 使用主元算法确保良好的稳定性

我们回忆一下，在第3章中我们已经看到，插值集的稳定性可以通过矩阵$M(\bar{\phi}, \hat{Y})$的条件数来表达，其中$\hat{Y}$是Y的缩放和平移版本。事实证明，可以表述一个与算法6.2等价的算法，该算法明确考虑了这个条件数，而不是拉格朗日多项式值的界。回想一下，算法6.2的引入是为了检查一个集合Y在给定区域B中是否是稳定的，并在必要时修改/补全Y以使其成为稳定集。下面的算法通过对矩阵$M(\bar{\phi}, Y)$应用带行主元的高斯消元并监控主元，达到了相同的结果。在高斯消元过程中的第i个主元是从修改后的$M(\bar{\phi}, Y)$的第i列中选取的，这是在因式分解应用于前$i-1$列之后。修改后的$M(\bar{\phi}, Y)$的第i列的元素实际上是在样本处计算的某个多项式的值

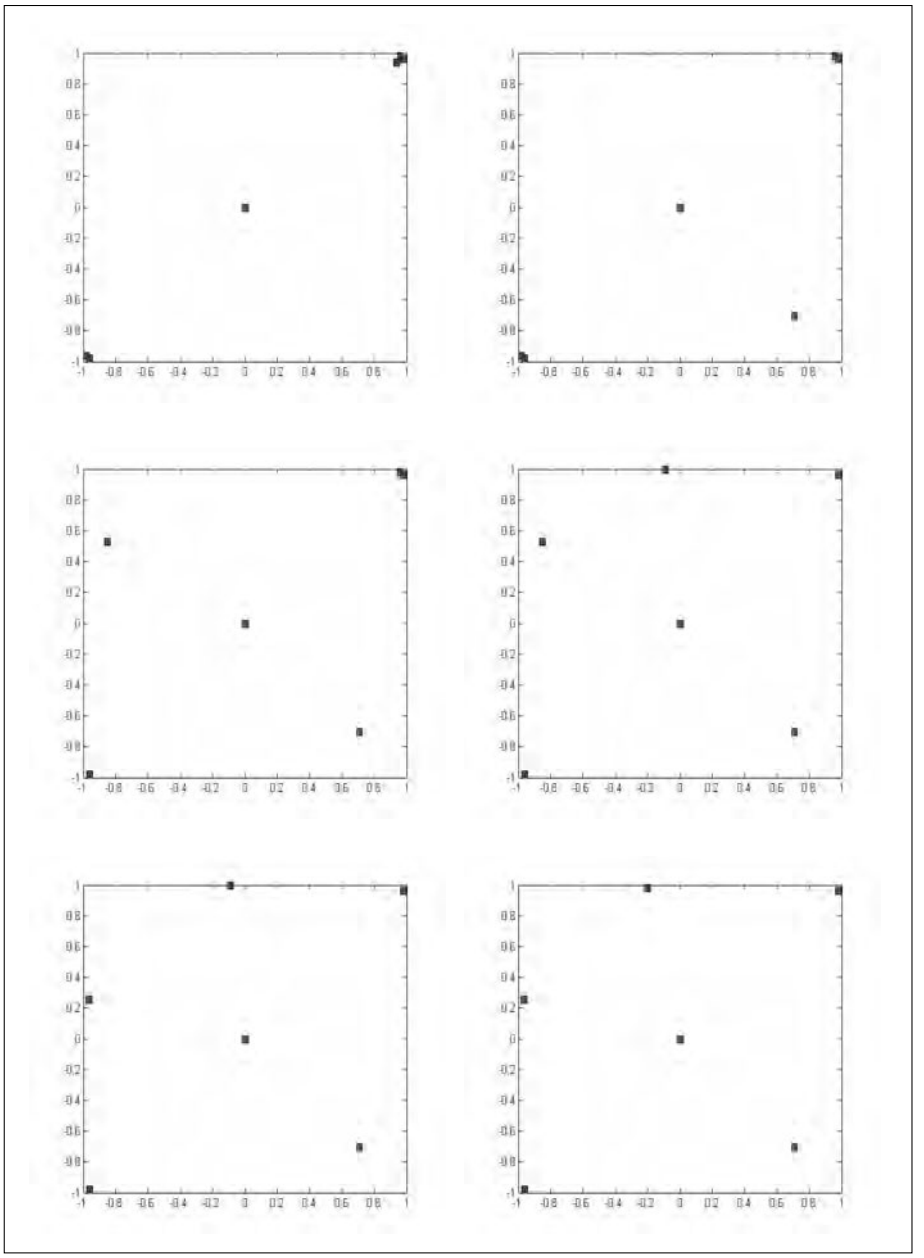


图6.1。 *Result of the application of Algorithm* 6.3 *starting from* Y_0 *in* (6.11). *The corresponding poisedness constants are the following:* $\Lambda_0 = 5324$, $\Lambda_1 = 36.88$, $\Lambda_2 = 15.66$, $\Lambda_3 = 1.11$, $\Lambda_4 = 1.01$, *and* $\Lambda_5 = 1.001$.

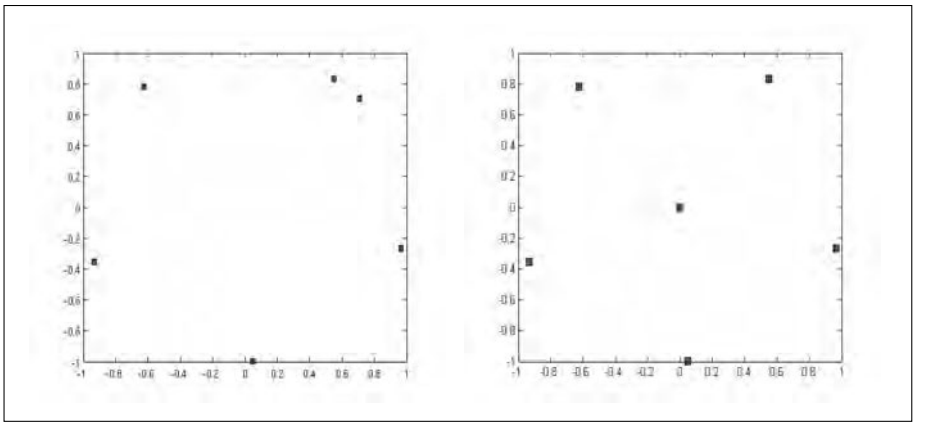


图6.2。*Result of the application of Algorithm* 6.3 *starting from a set of points that nearly lie on a circle. Changing only one point reduces the poisedness constant* $\Lambda_0 = 524982$ *to* $\Lambda_1 = 1$.

Y 中的点。我们将这些多项式称为 *pivot polynomials*，并用 $u_i(x)$、$i = 0$、…、p 表示。正如我们稍后将看到的，枢轴多项式与拉格朗日多项式密切相关。

算法6.4（通过LU分解完成非平衡集$\boldsymbol{Y}$）。

初始化：首先选择枢轴多项式基的初始近似，例如由单项式基(3.1)，$u_i(x) = \bar{\phi}_i(x)$，$i = 0$，…，p给出。令$p_{ini} + 1$为初始集合Y中给定点的数量。

对于 $i = 0$，…，p

1. 点选择：找到 $j_i = \text{argmax}_{i \le j \le p_{ini}} |u_i(y^j)|$。如果 $|u_i(y^{j_i})| > 0$ 且 $i \le p_{ini}$，则交换集合 Y 中的点 y^i 和 y^{j_i}。否则，计算（如果 $i \le p_{ini}$，则重新计算）y^i，如下

$$y^i \in \operatorname*{argmax}_{x \in B} |u_i(x)|.$$

2. 高斯消元法：对于 $j = i + 1, \ldots, p$

$$u_j(x) \leftarrow u_j(x) - \frac{u_j(y^i)}{u_i(y^i)} u_i(x).$$

让我们观察算法6.2和6.4之间的差异。后者算法不对主元多项式进行归一化处理。实际上，很容易看出，在算法终止后，我们得到一组主元多项式$u = \{u_0(x)$、$u_1(x)$、…、$u_p(x)\}$，以及

相应的矩阵 $M(u、Y)$ 不是别的，正是 $M(\phi、Y)$ 的 LU 分解的上三角因子。

除这些差异外，我们注意到这两种算法具有相同的复杂度，并产生完全相同的点集。

引理 6.4。*Given the same, possibly not poised, starting set Y, the same region B, and the same initial basis $\bar{\phi}$, Algorithms* 6.2 *and* 6.4 *produce identical poised sets Y.*

Proof. 我们将使用归纳法来证明这一命题。显然，在两个算法的第零步（$i=0$），点选择步骤将为 y^0 产生相同的点。现在我们假设两个算法的前 k 步产生了相同的集合 $\{y^0、\ldots、y^{k-1}\}$。事实上，在算法 6.4 的第 k 步（我们从第零步开始），第 k 个枢轴多项式具有以下性质：它是基$\bar{\phi}$ 的前 $k+1$ 个元素的线性组合，并且其值在前 k 个点 $y^0、\ldots、y^{k-1}$ 处为零，这些点属于 Y (——即枢轴算法已纳入的点)。对于算法 6.2 第 k 步开始时的第 k 个拉格朗日多项式 $\ell_k(x)$，情况也是如此。由于根据归纳假设，两个算法产生的前 k 个点是相同的，这意味着在两个算法各自第 k 步开始时，我们考虑的是两个多项式，它们 (i) 位于同一个 $(k+1)$ 维多项式子空间中（由 $\phi_0(x)、\phi_1(x)、\ldots、\phi_k(x)$ 张成的子空间），并且 (ii) 在给定的 k 个点的适配子集上取值为零。因此，这两个多项式必须相差一个常数因子。由此立即得出，当 $i=k$ 时，算法 6.2 和 6.4 的点选择步骤产生相同的点 y^k。由归纳法，该引理得证。

□

现在让我们考虑使用枢轴多项式来改善已平衡集合Y的平衡性的可能算法。自然地对算法6.4引入以下修改。在点选择步骤中，我们应用一个阈值ξ来接受下一个枢轴。

算法6.5（通过LU分解提高Y的平衡性）。

初始化：用某一基初始化枢轴多项式基，例如单项式基 (3.1)，$u_i(x)=\bar{\phi}_i(x)$，$i=0$，$\ldots$，p。选取枢轴阈值 $\xi>0$。

对于 $i=0$，$\ldots$，p

1. 点选择：如果可能，选择 $j_i\in\{i、\ldots、|Y|-1\}$，使得 $|u_i(y^{j_i})|\geq\xi$。如果找到这样的 j_i，则交换集合 Y 中点 y^i 和 y^{j_i} 的位置。否则，重新计算 y^i 为

$$y^i \in \operatorname*{argmax}_{x\in B}|u_i(x)|$$

如果$|u_i(y^i)|<\xi$ (枢轴阈值太大)，则停止。

2. 高斯消元法：对于 $j=i+1$，$\ldots$，p

$$u_j(x) \leftarrow u_j(x)-\frac{u_j(y^i)}{u_i(y^i)}u_i(x).$$

改进算法的结果是一个平衡集合 Y，使得当对 $M(\bar{\phi}、Y)$ 应用高斯消元法时，所有主元的绝对值都不小于 ξ。在这种情况下，可以证明（见习题）$M(\bar{\phi}、Y)$ 的逆的范数有界，上界为

$$\|M(\bar{\phi},Y)^{-1}\| \leq \frac{\sqrt{p_1}\,\varepsilon_{growth}}{\xi}, \tag{6.12}$$

其中 ε_{growth} 可以视为在因式分解过程中出现的增长因子的估计（参见，例如，[127, 第9.3节和第9.4节]），而 ξ 是算法所施加的关于主元绝对值的下界。注意，在选择索引 j_i 时有一定的自由度，只要对应的主元足够大即可。为了保持增长因子较低，理想情况下应选择提供最大主元值的索引（这对应于高斯消元中的部分选主元）。另一方面，在优化算法中，可能会根据点与当前迭代点的接近程度来给予偏好。在实际算法中，通常平衡这两种策略能提供最佳方法。

上述界对于任何矩阵 $M(\bar{\phi}、Y)$ 以及由算法6.5生成的任何集合 Y 都成立。然而，为了有一个简单的选主策略和 $\|M(\bar{\phi}、Y)^{-1}\|$ 上有意义的界，我们需要对 $Y = \{y^0、y^1、\ldots、y^p\}$ 进行平移和缩放，以得到

$$\hat{Y} = \{0,\hat{y}^1,\ldots,\hat{y}^p\} = \{0,(y^1-y^0)/\Delta,\ldots,(y^p-y^0)/\Delta\} \subset B(0;1),$$

其中

$$\Delta = \Delta(Y) = \max_{1\leq i\leq p}\|y^i-y^0\|.$$

可以看出，$\hat{Y}$ 紧密地位于以原点为中心、半径为1的球内。然后将算法6.5应用于平移和缩放后的集合 $\hat{Y}$。与算法6.3不同，后者拉格朗日多项式可能事先可得，因此对集合 Y 进行平移和缩放可能导致计算复杂度增加，而算法6.5总是从头构建枢轴多项式集，因此对 Y 进行平移和缩放不会造成显著的额外工作。

从定理3.14我们知道，如果 $\|M(\bar{\phi}、\hat{Y})^{-1}\|$ 是有界的，那么集合 Y 是 Λ- poised的，其中 Λ 在常数因子范围内接近于 $\|M(\bar{\phi}、\hat{Y})^{-1}\|$。我们的结论是，为了验证或保证给定插值集 Y 的 Λ-poisedness，我们应用缩放和平移来获得适当的集合 $\hat{Y}$。然后我们应用算法6.5，它通过计算枢轴多项式并将它们分配给插值点来计算 $M(\bar{\phi}、\hat{Y})$ 的因式分解。如果在因式分解过程中遇到小枢轴，则用“可接受”的点替换“不可接受”的点。因式分解完成后，得到的集合 $\hat{Y}$ 可以变换回 Y，对于某个独立于原始插值集 Y 的常数 Λ，它是 Λ-poised的。

阈值 ξ 用于在维持更好的 poised 集合与不必丢弃 Y 中许多现有点之间进行权衡。如果 ξ 选择得非常小，那么枢轴值很容易通过此阈值，从而使点被接受进入插值集合。但由于如 (6.12) 所示，所得的 poisedness 常数与 ξ 成反比，所得集合可能不会很好地 poised。另一方面，如果 ξ 的值选择得太高，则可能需要替换 Y 中的几乎所有点以满足阈值条件。如果不小心，甚至可能无法找到能提供足够大枢轴值的点。幸运的是，存在一个相当大的

ξ 的上界，对于该上界，我们保证算法将始终成功。我们知道第 $(k+1)$ 个枢轴多项式 $u_k(x)$ 可以表示为 $(v^k)^\top \bar{\phi}(x)$，其中 $v^k = (v_0、\ \ldots、\ v_{k-1}、\ 1、0、\ \ldots、0)$，因此 $\|v^k\|_\infty \geq 1$。根据下文引理 6.7，存在一个 $\theta > 0$，使得如果枢轴阈值被选为 0 与 θ 之间的任意数，则算法 6.5 将始终成功。注意，当 $d = 1$ 时，θ 可以设为 1，当 $d = 2$ 时可以设为 1/4。因此，我们可以陈述以下结果。

定理 6.5. *For any given $\xi \in (0, 1)$ and $p_1 = n + 1$ in the linear case, and any given $\xi \in (0, 1/4)$ and $p_1 = (n + 1)(n + 2)/2$ in the quadratic case, Algorithm* 6.5 *computes a set $\hat{Y}$ of $p_1 = p + 1$ points in the unit ball $B(0; 1)$ for which the pivots of the Gaussian elimination of $\hat{M} = M(\bar{\phi}, \hat{Y})$ satisfy*

$$\left|u_i(y^i)\right| \geq \xi, \quad i = 0, \ldots, p.$$

为了保证Λ平衡性，算法6.5依赖于界(6.12)。由于增长因子通常未知且理论上可能非常大（但有限），因此理论上，枢轴算法的结果可能是一个具有极大Λ平衡常数的插值集。就理论目的而言，重要的是在这种情况下Λ被一个常数所界定，无论这个常数有多大。从实际角度来看，增长因子在几乎所有情况下都是适度的，只有对于人为构造的例子才会呈指数级增长。

在二次情形下，一次高斯消元所需的计算量约为$\mathcal{O}(n^6)$次浮点运算。然而，该算法并不要求在某个球内对枢轴多项式的绝对值进行全局最大化。尽管这种优化会有所帮助，且如果可能应当使用，但严格来说，我们只需保证能确定一个点，使得枢轴多项式的绝对值大于或等于ξ。这可以通过使用引理6.7证明中对缩放和平移集合所用的论证来实现。它表明，通过简单枚举，对于任何满足$\theta > \xi > 0$（其中θ为某个正常数，在二次插值情形下等于1/4）的ξ值，我们都能找到这样的点。这种枚举的复杂度为$\mathcal{O}(p)$，且至多需要执行$\mathcal{O}(p)$次；因此，它对整体复杂度$\mathcal{O}(p^3)$没有显著贡献。

通过关键算法实现增量改进

算法6.3以渐进方式改进Λ- poisedness，每次替换一个点并减少拉格朗日多项式绝对值的上界。另一方面，算法6.5先验地选择阈值，并根据需要替换尽可能多的点以满足阈值条件。可以重复应用算法6.5并逐渐减小阈值，以促进poisedness的逐步改善。然而，选择一个好的阈值序列并非易事。可能阈值ξ下降得太慢，经过多次算法应用后仍未获得任何改进；或者阈值下降得太快，导致不得不替换过多的点。在某些情况下，逐步更新阈值在算法上是有意义的，例如，当记住并利用上次应用算法6.5得到的枢轴值作为指导时。这些考虑应在开发特定无导数优化算法时予以解决（见第11章）。

以下小节的示例应用阈值缩减思想，以展示算法6.5生成的集合的 poisedness 可能取得的进展。我们将看到，在这种情况下，算法6.5的工作方式与算法6.3类似，但每次运行可能替换多于一个点。在实际的无导数优化框架中，当确实需要替换少数几个点以获得良好的几何结构时，这一性质可能是有利的——算法6.5或许能在一次运行中识别出所有这些点。另一方面，它也可能不必要地替换某些点，从而仅获得 poisedness 的微小改进，却浪费了宝贵的函数评估。

如果我们想要使用枢轴方法，但每次运行只替换一个点，那么可以使用接下来描述的方案。本质上，我们运行算法6.5时不设置阈值（即将阈值设为零）。假设初始集合 {v*5} 是适定的，并且包含 {v*6} 个点，算法将运行到最后一次迭代，此时我们可以优化最后一个枢轴多项式，并替换 {v*7} 中的最后一个点。

算法6.6（通过LU分解逐步改善$\boldsymbol{Y}$的平衡性）。

我初始化：首先选择枢轴多项式基的初始近似，例如由单项式基 (3.1)、$u_i(x) = \bar{\phi}_i(x)$、$i = 0$、…、p 给出。假设 Y 包含 p_1 个准备点。

对于 $i = 0, \ldots, p-1$

1. **Point selection:** Find $j_i = \operatorname{argmax}_{i \le j \le |Y|} |u_i(y^j)|$ and swap points y^i and y^{j_i} in set Y.
2. 高斯消元法：对于 $j = i+1, \ldots, p$

$$u_j(x) \leftarrow u_j(x) - \frac{u_j(y^i)}{u_i(y^i)} u_i(x).$$

改进步骤：

$$y^p_{\text{new}} \in \operatorname*{argmax}_{x \in B} |u_p(x)|.$$

该算法试图找出最佳候选点进行替换。由于LU过程是基于行（即基于点）进行主元选择的，导致产生不良主元值的数据点被推移至底部行。因此，通过替换最末尾的点，我们有望获得 poisedness 的最佳改进。

请注意，如果所考虑的集合相同，且算法6.6的LU分解中的最后一个点对应于算法6.3中绝对值最大的拉格朗日多项式，则算法6.6生成的新点与算法6.3某次迭代生成的点相同——因为在这种情况下，第p个枢轴多项式与刚才提到的拉格朗日多项式相同（相差一个常数因子）（见引理6.4的证明）。应用算法6.6所涉及的工作量为$\mathcal{O}(p^3)$，但它不需要优化所有拉格朗日多项式。

算法6.6构成了改进过程的一次迭代。为了确定下一个要替换的点，应从头再次重复算法6.6。如果

在应用算法6.6之后，如果最后一个点已经是相应枢轴多项式的最优点，则通过此策略无法获得进一步的改进。无法保证由算法6.3替换的点序列与由顺序应用算法6.6的策略替换的点序列完全相同。然而，只要这些序列相同，即如果在每次迭代中产生拉格朗日多项式绝对值最大的点和产生最小（因此是最后）枢轴的点相同，那么得到的插值集就是相同的（因为，回想一下，第p个枢轴多项式在相差一个常数的意义下是对应的拉格朗日多项式）。

一个例子

让我们再次转向用于说明算法6.3的示例，其中$\Lambda = 5324$，以展示算法6.5的效果。我们希望表明算法6.5能够生成与算法6.3所生成的质量相当的插值集。为此，我们将对ξ进行以下调整：我们运行算法6.5三次，分别应用阈值$\xi = 0.01$、0.1、0.5。

下面我们列出了初始集以及算法6.5三次运行的结果，这些也展示在图6.3中：

$$Y_0 = \begin{bmatrix} -0.98 & -0.96 \\ -0.96 & -0.98 \\ 0 & 0 \\ 0.98 & 0.96 \\ 0.96 & 0.98 \\ 0.94 & 0.94 \end{bmatrix}, \quad Y_1 = \begin{bmatrix} -0.98 & -0.96 \\ -0.96 & -0.98 \\ 0 & 0 \\ 0.98 & 0.96 \\ 0.96 & 0.98 \\ 0.707 & -0.707 \end{bmatrix}, \tag{6.13}$$

$$Y_2 = \begin{bmatrix} -0.98 & -0.96 \\ -0.135 & -0.99 \\ -0.0512 & 0.0161 \\ 0.98 & 0.96 \\ -0.14 & 0.99 \\ 6.99 & -7.14 \end{bmatrix}, \quad Y_3 = \begin{bmatrix} -0.98 & -0.96 \\ 0.943 & -0.331 \\ 0.0281 & 0.0235 \\ 0.98 & 0.96 \\ -0.14 & 0.99 \\ 0.699 & -0.714 \end{bmatrix}.$$

在每一步中，集合中的一些点被更好的点替换，且 poisedness 得到改善。此外，在相同示例上，Algorithm 6.5 的三次应用中 poisedness 的进展略优于 Algorithm 6.3 前三次迭代的进展（见图 6.1）。然而，前者平均每次运行替换 2 个点，而后者每次迭代替换一个点。在第二步中，原点被点 $(-0.0512, 0.0161)$ 替换，实际上是一个浪费样本点以获得相对可忽略的 poisedness 改善的例子。注意，两种情况下最终集合非常相似。我们使用枢轴多项式的全局优化来说明其行为类似于使用 Lagrange 多项式。

如果我们将算法6.6应用于相同的集合，那么它将产生的集合序列与算法6.3的前四次迭代完全相同；也就是说，它将产生第3.3节中给出的拉格朗日多项式示例中的前四个集合，如图6.1所示。经过四次迭代后，它将停止，无法进一步改进集合Y。

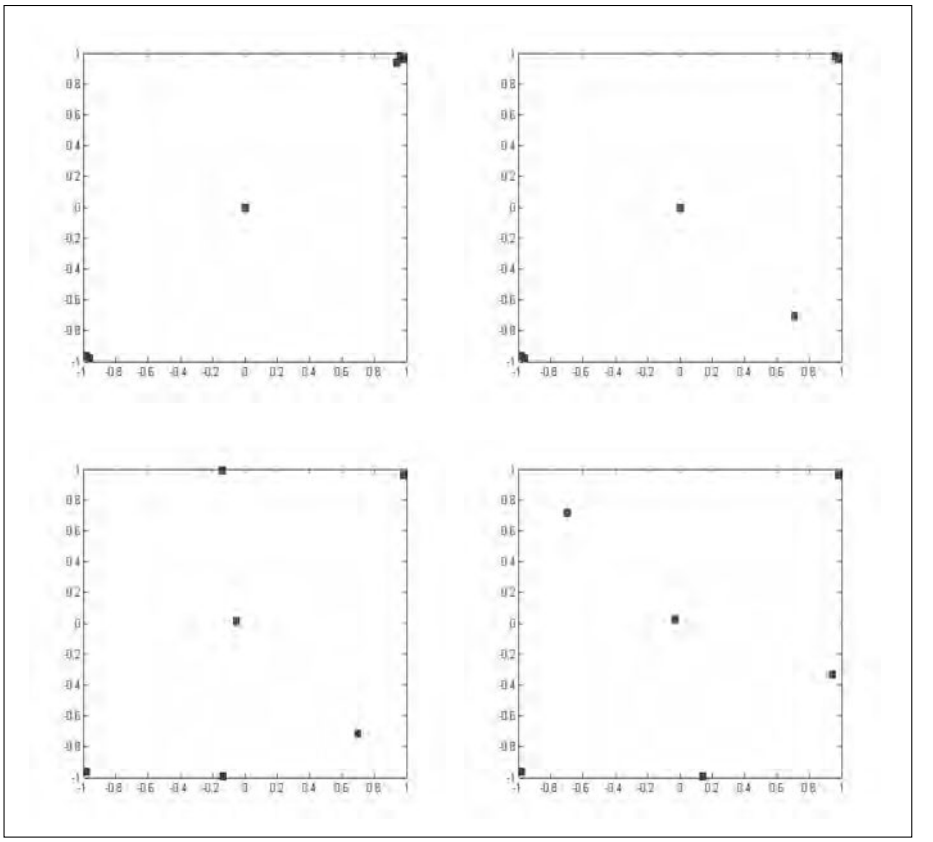


图6.3。 *Result of applying Algorithm* 6.6 *four times starting from* Y_0 *in* (6.13). *The corresponding poisedness constants are the following:* $\Lambda_0 = 5324$, $\Lambda_1 = 36.88$, $\Lambda_2 = 1.699$, *and* $\Lambda_3 = 1.01$.

6.4 几何改进算法的实际考虑因素

让我们讨论所提出的过程是否“实用”。无导数优化问题通常处理评估代价高昂的函数；因此，一种实用的方法应试图节省函数评估。关于关键算法的第一个问题是，在基于模型的无导数优化算法的每次迭代中，是否需要替换过多的插值点。次要考虑是模型改进算法的线性代数成本。

在基于模型的无导数算法过程中会出现几种情况。首先，随着迭代的进行，样本集中的某些点可能会与当前最佳迭代点相距过远。在这种情况下，它们不再属于一个认为处于稳定状态的区域 B。这些点只需用更接近当前迭代点的点来替换即可。这些正是算法6.2和6.4有用的情况。如果拉格朗日多项式基可用，那么对应于

被移除的点在 B 上进行优化。最优的点随后替代被移除的点。其余多项式随之更新。此过程的成本为 $\mathcal{O}(p^2)$ 加上优化拉格朗日多项式的成本。如果找到一个使拉格朗日多项式绝对值足够大（大于1）的点，则不需要全局优化，因为我们知道适定性会改善。如果拉格朗日多项式集合不可用，或者使用了主元方法，则复杂度为 $\mathcal{O}(p^3)$。

当插值点需要被替换的另一种情况是，当发现一个新的优化迭代点且需要将其纳入插值集合时。在这种情况下，拉格朗日多项式算法会识别在新点上其值最大的多项式，并用新点替换Y中对应于该多项式的点。这一过程需要$\mathcal{O}(p^2)$次运算。而关键算法则直接选取新的优化迭代点来生成首个枢轴，随后通过选择能产生最佳枢轴值的点继续，直至因式分解完成。未被使用的剩余点将被替换。这种方法需要$\mathcal{O}(p^3)$次运算，但它能确保维持Λ平衡性，而拉格朗日多项式方法仅当新点处的拉格朗日多项式绝对值至少为1时才能做到这一点。

最后，如果怀疑某个模型配置得不够好，那么可以使用算法6.3或重复应用算法6.6。在这种情况下，尽管不是必需的，但对应多项式的全局优化是可取的，此时两种策略的复杂度相当。[7]

6.5 确保回归模型和最小 Frobenius 范数模型的良好稳定性

现在让我们考虑当 Y 中的点数 p_1 不等于多项式空间的维数 q_1 时的情况。

回归模型

首先，我们回顾回归情况，$p_1 > q_1$，以及第4章讨论的回归拉格朗日多项式。用于计算和更新插值拉格朗日多项式的算法6.1不适用于回归情况。回归拉格朗日多项式可以从系数矩阵的表达式(4.6)中计算得出

$$A_\phi = [M(\phi, Y)^\top M(\phi, Y)]^{-1} M(\phi, Y)^\top.$$

此计算所涉及的工作量为 $\mathcal{O}(q^2 p)$。如果在集合 Y 中仅替换一个点，则矩阵 $M(\phi, Y)$ 中仅替换一行。为更新回归拉格朗日多项式集合，可以通过以下方式对 $[M(\phi, Y)^\top M(\phi, Y)]^{-1}$ 应用秩二更新：

[7] The optimization of a quadratic polynomial over an ellipsoid is a particular trust-region subproblem. Even in the nonconvex case it is known that the first-order necessary conditions for such trust-region subproblems are sufficient (see Section 10.8). These problems have some form of *hidden convexity* in the sense that the necessary conditions are sufficient (or the duality gap is zero) or there exist convex reformulations. For more details on the complexity bounds and convex reformulations for ellipsoidal trust-region subproblems see [32, 98, 232].

Sherman–Morrison–Woodbury 公式（例如参见 [109, 178]）。更新回归拉格朗日多项式所需的总体工作量为 $\mathcal{O}(pq)$。

然而，计算回归拉格朗日多项式集合是否有用尚不清楚。回想一下，对于强Λ- poisedness，当p足够大时，我们要求拉格朗日多项式的最大值小于1。无法保证基于回归拉格朗日多项式的算法6.3的类似物能在有限次迭代后终止，因为不存在定理6.3的类似物。此外，甚至不清楚如何借助回归拉格朗日多项式来修正非poised集。如果集合Y不是poised的，那么就无法求逆矩阵$M(\phi, Y)^\top M(\phi, Y)$。遗憾的是，与算法6.1不同，所提出的计算回归拉格朗日多项式的方法没有自然的方式来检测导致集合非poised的点并替换这些点。通过考虑$M(\phi, Y)$的行的线性无关性，可以做到这一点，这将我们引向枢轴算法。

我们可以将算法6.4应用于集合Y，并选择或生成一个包含q_1个点的 poised 子集。现在，剩余未使用的点可以直接加入，因为它们的存在不会破坏集合的 poised 性。同样的论证也适用于生成一个Λ-poised 回归集合。算法6.5可用于选择或生成一个包含q_1个点的子集，该子集在插值意义下是$(1/\sqrt{p})$Λ-poised 的。然后，剩余的点可以加入该集合，根据定义4.7中关于回归的Λ-poisedness 的性质（第2点），该集合在回归意义下将是Λ-poised 的。

也可以应用算法6.2和6.3，分别在插值意义上选择Y的poised和$(1/\sqrt{p})$Λ-poised子集。得到的插值拉格朗日多项式是这些子集的插值多项式，并且与Y的回归多项式没有直接关系。

为了提供具有任意大样本集的完全线性与完全二次回归模型，我们需要能够根据定义4.10确立强Λ-平衡性。依据定理4.11，我们知道如果能将集合Y分割成每个包含q_1个点的Λ-平衡子集，就能保证强Λ-平衡性。显然，这可以通过重复应用算法6.3或6.5来选择或生成Y的Λ-平衡子集来实现。

算法6.7（计算一个强$\mathbf{\Lambda}$-平衡集$\boldsymbol{Y}$）。

我们初始化：令$\bar{Y} = Y$ 和 $i = 1$. 选择 $\Lambda > 1$ 或阈值 ξ > 0.

当$|\bar{Y}| \geq q_1$时

1. 选择一个$\mathbf{\Lambda}$平衡子集：应用算法6.3或6.5于$\bar{Y}$，以选择或生成一个Λ平衡子集Y^i。

2. 移除子集：

$$\bar{Y} \leftarrow \bar{Y} \setminus Y^i, \quad i \leftarrow i+1.$$

重置 $Y = \bigcup_i Y^i$。

当算法终止时，我们得到可能更小的集合 Y，因为我们不包括落入最后一个不完整子集的点。另一种可能是

为了将这些点包含在Y中，或是通过向Y添加更多点来生成另一个处于Λ态势的子集。当考虑较大的p值时，所有这些选项都是可接受的，并且理论上没有显著差异。因此，只有实际考虑因素才能决定如何处理剩余的点。

很容易看出，该算法生成一个强 Λ-平衡集Y (参见定义4.10之前的讨论)。由于根据前几节的讨论，我们知道算法6.3或6.5将在有限步数后终止，因此算法6.7也将如此。

最小 Frobenius 范数模型

对于第5章中讨论的最小Frobenius范数模型，拉格朗日多项式集合也是通过解线性方程组来计算的。当这个系统的矩阵，

$$\begin{bmatrix} M(\bar{\phi}_Q, Y)M(\bar{\phi}_Q, Y)^\top & M(\bar{\phi}_L, Y) \\ M(\bar{\phi}_L, Y)^\top & 0 \end{bmatrix},$$

是奇异的，那么再次更新插值集以生成一个适定的插值集就不像完全插值情形那样直接。通过应用算法6.2或6.4，无法生成最小Frobenius范数拉格朗日多项式，但可以在最小Frobenius范数意义下检查并强制Y的适定性（细节省略）。

然而，更自然的做法是直接利用最小Frobenius范数拉格朗日多项式集合来维持Y的良好平衡性。文献[191]中提出了一种针对这些多项式的高效更新方法。我们可以采用算法6.3的类似方式来更新样本集，并在最小Frobenius范数意义下保持Λ的平衡性。需要注意的是，在算法6.3中，更新拉格朗日多项式的步骤需作调整，以适应最小Frobenius范数多项式。为了证明该过程同样具有有限性，可以引用定理6.3的一个类似结论。

定理 6.6. *For any given $\Lambda > 1$, a closed ball B, and a fixed polynomial basis ϕ, Algorithm* 6.3 *for minimum Frobenius norm Lagrange polynomials terminates with a Λ-poised set Y after at most $N = N(\Lambda,$*
$\phi)$ iterations, where N is a constant which depends on Λ and ϕ.

该定理的证明实质上与定理6.3的证明相同，并利用了最小Frobenius范数Lagrange多项式的行列式（或体积）比解释以及推论5.9。

我们不再对此问题进行深入讨论，仅得出结论：基于相应的误差界及有限模型改进算法的存在，最小Frobenius范数模型构成了一类完全线性的模型类别。

6.6 其他说明和引用

这里我们给出该引理的陈述及其证明，我们在本章以及第3至5章中多次使用了这一引理。

引理 6.7. *Let $v^\top \bar{\phi}(x)$ be a quadratic polynomial of degree at most d, where $\|v\|_\infty = 1$ and $\bar{\phi}$ is the natural basis (defined by* (3.1)*). Then there exists a constant $\sigma_\infty > 0$ independent of v such that*

$$\max_{x \in B(0;1)} |v^\top \bar{\phi}(x)| \ \geq \ \sigma_\infty.$$

For $d = 1$, $\sigma_\infty \geq 1$, and for $d = 2$, $\sigma_\infty \geq \frac{1}{4}$.

Proof. 第一部分（一般情况）已在引理3.10中证明。

当 $d = 1$ 时，我们有$\bar{\phi}(x) = [1, x_1, \ldots, x_n]^\top$。令 $w = [v_2, \ldots, v_{n+1}]^\top$。容易看出，问题 $\max_{x \in B(0;1)} |v^\top \bar{\phi}(x)|$ 的最优解要么由 $w/\|w\|$ (给出，最优值为 $v_1 + \|w\|$)，要么由 $-w/\|w\|$ (给出，最优值为 $-v_1 + \|w\|$)。因此，最优值为 $|v_1| + \|w\| \geq 1$。

让我们考虑 $d = 2$ 的情况。由于 $\|v\|_\infty = 1$，v 的元素中至少有一个是 1 或 -1，因此多项式 $q(x) = v^\top \bar{\phi}(x)$ 的系数中有一个等于 1、-1、1/2 或 $-1/2$。我们只考虑 $q(x)$ 的系数中有一个是 1 或 1/2 的情况。情况 -1 或 $-1/2$ 将类似地分析。

在v中绝对值最大的系数对应于一个项，该项要么是常数项、线性项x_i，要么是二次项$x_i^2/2$或$x_i x_j$。让我们将所有未出现在此项中的变量限制为零。我们将通过考虑对应最大系数的不同项的四种情况来证明多项式的最大绝对值至少为1/4。在每种情况下，我们将在一系列单位球内的点上评估受限多项式，并展示至少在这些点之一，多项式的绝对值至少达到1/4。显然，由此可知无限制多项式的最大绝对值也同样被下界限制为不低于1/4。

- $q(x) = 1$. 这种情况是微不足道的。
- $q(x) = x2_i/2 + \alpha x_i + \beta$。在这种情况下，我们有$q(1) = 1/2 + \alpha + \beta$，$q(-1) = 1/2 - \alpha + \beta$，以及$q(0) = \beta$。如果$|q(1)| \geq 1/4$或$|q(-1)| \geq 1/4$，我们已有期望的结果。如果$|q(1)| < 1/4$且$|\ q(-1)| < 1/4$，那么，通过将这些不等式相加，我们推导出$-1/2 < 1 + 2\beta < 1/2$。但随后我们得到$q(0) = \beta < -1/4$。
- $q(x) = \alpha x2_i/2 + x_i + \beta$。这次我们有$q(1) = 1 + \alpha/2 + \beta$和$q(-1) = -1 + \alpha/2 + \beta$，因此
$$\max\{|q(-1)|, |q(1)|\} \ \geq \ 1.$$
- $q(x) = \alpha x2_i/2 + \beta x_j^2/2 + x_i x_j + \gamma x_i + \delta x_j + \epsilon$。在这种情况下，我们考虑二维球面上的二次函数。通过考虑球面上的四个点，$p_1 = (1/\sqrt{2}、1/\sqrt{2})$、$p_2 = (1/\sqrt{2}、-1/\sqrt{2})$、$p_3 = (-1/\sqrt{2}、1/\sqrt{2})$，以及$p_4 = (-1/\sqrt{2}、-1/\sqrt{2})$，我们得到

$$q(p_1) = \frac{\alpha+\beta}{4} + \frac{1}{2} + \frac{\gamma+\delta}{\sqrt{2}} + \epsilon,$$

$$q(p_2) = \frac{\alpha+\beta}{4} - \frac{1}{2} + \frac{\gamma-\delta}{\sqrt{2}} + \epsilon,$$

$$q(p_3) = \frac{\alpha+\beta}{4} - \frac{1}{2} - \frac{\gamma-\delta}{\sqrt{2}} + \epsilon,$$

$$q(p_4) = \frac{\alpha+\beta}{4} + \frac{1}{2} - \frac{\gamma+\delta}{\sqrt{2}} + \epsilon.$$

因此，我们得到$q(p_1) - q(p_2) = 1 + \sqrt{2}\delta$ 和 $\bar{q}(p_3) - q(p_4) = -1 + \sqrt{2}\delta$。在 $\delta \geq 0$ 的情况下，我们有 $q(p_1) - q(p_2) \geq 1$。因此，如果 $|q(p_1)| < 1/2$，那么 $q(p_2) \leq -1/2$。情形 $\delta < 0$ 可类似证明。□

6.7 练习

1. 证明算法6.1计算了适配插值集的拉格朗日多项式基。

2. 证明二次插值（或回归）多项式模型的梯度是Lipschitz连续的，即

$$\|\nabla m(y_1) - \nabla m(y_2)\| \leq \kappa \|y_1 - y_2\| \quad \forall y_1, y_2 \in B(x; \Delta),$$

其中 κ 依赖于样本集的 Λ- poisedness常数、用于构建模型的点数 p_1、Δ 的上界 Δ_{max}、f 值的上界，以及 $M(\phi$ 的逆的上界，$Y)$ (或 $M(\phi$ 的奇异值对角矩阵的逆 $Y))$。

3. 证明当ε_{growth}由$M(\bar{\phi}$、$Y)$的LDU分解中L和U因子的逆的范数乘积给出时，界(6.12)成立。

第二部分

框架和算法

第7章

方向性直接搜索方法

直接搜索方法是无导数方法，它们在每次迭代中对目标函数在有限数量的点上进行采样，并仅根据这些函数值决定下一步采取什么行动，而不进行任何显式或隐式的导数近似或模型构建。在本书中，我们将直接搜索方法的介绍分为两章。在下一章中，我们将介绍基于单纯形及单纯形上的操作（如反射、扩展或收缩）的直接搜索方法。单纯形直接搜索算法的一个经典例子是Nelder-Mead方法。

在本章中，我们探讨直接搜索方法，其中采样由具有适当特征的方向集引导。本章的核心在于正生成集和正基的概念（参见第2.1节）。本书考虑的两种直接搜索方法类别（方向性和单纯形）相互关联。例如，回顾第2.5节内容，可以轻松地从任意$n+1$个顶点的单纯形构造最大正基。反之，给定任何正基，直接识别出$n+1$个顶点的单纯形也颇为直观。尽管这两个概念（正生成与仿射独立性）关系密切，但所考虑的两种直接搜索方法类的哲学差异显著，足以证明需分别对待。

所考虑的问题是一个实值函数的无约束优化问题，表述在(1.1)中。针对各种类型的无导数约束优化问题，方向直接搜索方法的扩展在13.1节中总结。

7.1 坐标搜索法

最简单的方向性直接搜索方法之一称为坐标搜索或罗盘搜索。该方法利用最大正基$D_\oplus$：

$$D_\oplus = \begin{bmatrix} I & -I \end{bmatrix} = [\, e_1 \cdots e_n \; -e_1 \cdots -e_n \,]. \tag{7.1}$$

设x_k为当前迭代点，α_k为步长或网格参数的当前值。坐标搜索在以下集合中的点处计算函数f

$$P_k = \{x_k + \alpha_k d : d \in D_\oplus\},$$

按照某种指定的顺序，试图在 P_k 中找到一个使目标函数值下降的点。在本章的术语中，我们说 P_k 是一组轮询点，$D_\oplus$ 是一组轮询向量或方向。这种评估目标函数的过程称为轮询。我们在图 7.1 中展示了坐标搜索的轮询过程。

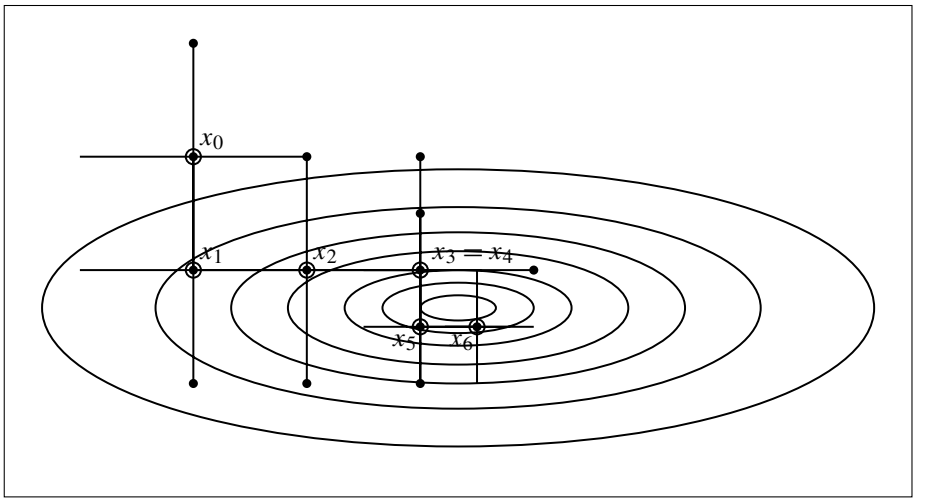


图7.1。 *First six iterations of coordinate search with opportunistic polling (following the order North/South/East/West). Function evaluations (a total of* 14*) occur at circles, but only the bigger circles are iterates. The ellipses depict the level sets of the function.*

当 P_k 中的某个点在 f 的值方面优于当前迭代点 x_k 时，轮询即成功。此时，该方法定义一个新的迭代点 $x_{k+1} = x_k + \alpha_k d_k \in P_k$，使得目标函数中 $f(x_{k+1}) < f(x_k)$ (a *simple decrease*)。在这种成功的情况下，要么保持参数 α_{k+1} 不变，要么将其增大（例如增大 2 倍）。如果 P_k 中没有任何点导致 f 减小，则参数 α_k 会减小（例如减小为原来的 1/2），并且下一次迭代在同一点（$x_{k+1} = x_k$）进行轮询。轮询可以是有机会式的，即移动到遇到的第一个更优点；也可以是完整的，在这种情况下会评估所有轮询点并选取最优点（如果比当前迭代点更好）。完整轮询特别适合在并行环境中运行。

算法 7.1（坐标搜索法）。

初始化：选择 x_0 和 $\alpha_0 >$ 为 0。

对于 $k = 0$、1、2，…

1. 轮询步骤：对轮询集 $P_k = \{x_k + \alpha_k d$ 进行排序：$d \in D_\oplus\}$。按照确定的顺序，在轮询点开始评估 f。如果某个轮询点 $x_k + \alpha_k d_k$ 是

发现使得 $f(x_k+\alpha_k d_k) < f(x_k)$，然后停止轮询，设置 $x_{k+1} = x_k + \alpha_k d_k$，并声明迭代和轮询步骤成功。否则，声明迭代（和轮询步骤）失败并设置 $x_{k+1} = x_k$。

2. 参数更新：如果迭代成功，则设置 $\alpha_{k+1} = \alpha_k$ (或 $\alpha_{k+1} =$ 为 $2\alpha_k$)。否则，设置 $\alpha_{k+1} = \alpha_k /$ 为 2。

为了说明后续内容，我们还为坐标搜索引入以下集合（称为网格，或格点）：

$$M_k = \left\{ x_k + \alpha_k \left(\sum_{i=1}^{n} u_i e_i + \sum_{i=1}^{n} u_{n+i}(-e_i) \right) : u \in \mathbb{Z}_+^{|2n|} \right\}, \tag{7.2}$$

其中 $\mathbb{Z}_+$ 是非负整数集。网格的一个例子如图7.2所示。网格仅是概念性的。在这类方法中，从未尝试枚举网格中的点（无论是否通过计算）。

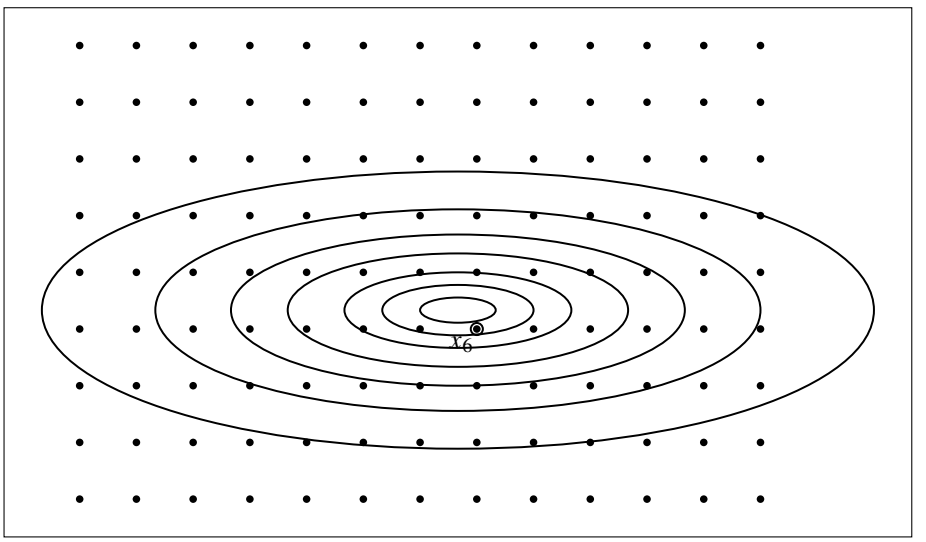


图7.2。*The mesh in coordinate search at* x_6.

出于实际效率考虑，在上述坐标搜索框架中引入一定的灵活性是有益的。这种灵活性可以通过所谓的搜索步骤来实现，[8] 该步骤是可选的，并且在制定时紧接在轮询之前应用。基本上，搜索步骤包括在 M_k 中的有限个点上评估目标函数，试图找到一个点 $y \in M_k$ 使得 $f(y) < f(x_k)$。我们在图7.3中说明了这一过程。当搜索步骤成功时，迭代也成功（跳过轮询步骤，并在 $x_{k+1} = y$ 处开始新的迭代）。搜索步骤完全是可选的，不仅在方法的实现中如此，在证明其收敛性质时也是如此。当

[8] We should remark that coordinate search is often described in the literature without a search step.

搜索步骤被应用时，它不会干扰方法的收敛性质，因为点被要求位于网格M_k上。在下一节中，我们将描述一类方向性直接搜索方法，其中坐标搜索作为一种特殊情况被包含在内。

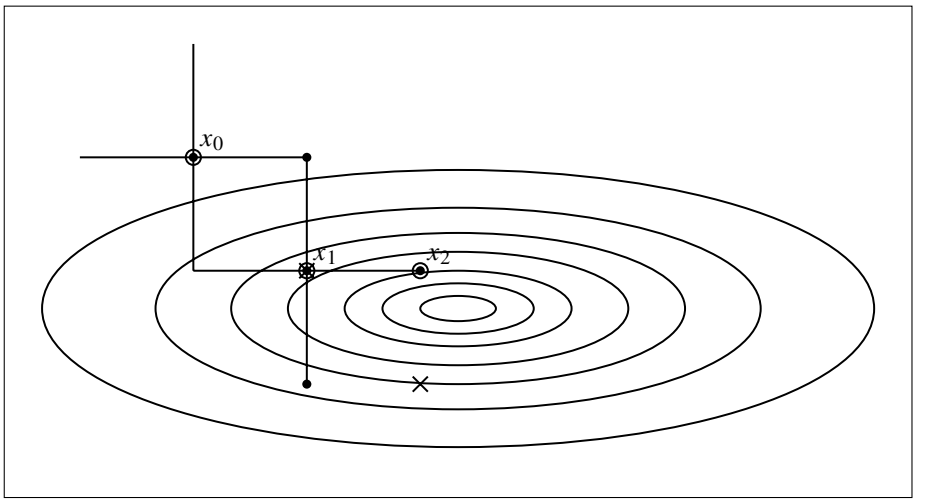


图 7.3。 *Three iterations of coordinate search with a search step (consisting of trying the South-East point) and opportunistic polling (following the order North/South/East/West). Function evaluations occur at crosses (search step) and circles (a total of* 6*). Only the bigger circles are iterates. The ellipses depict the level sets of the function.*

7.2 定向直接搜索框架

我们现在介绍一类全局收敛的方向直接搜索方法。本介绍的大部分内容基于Audet和Dennis[18]引入的广义模式搜索框架，并广泛利用了围绕搜索步骤和投票步骤组织的迭代结构。

为了开始演示，让我们考虑当前迭代点 x_k 以及步长或网格参数 α_k 的当前值。此处介绍的直接搜索方法中，迭代 k 的目标是确定一个新的点 x_{k+1}，使得 $f(x_{k+1}) < f(x_k)$。

寻找新迭代点x_{k+1}的过程可以分为两个阶段（通常称为搜索步和 poll 步）。

搜索步骤是可选的，对于方法的收敛性质而言并非必要。它包括在有限个点上评估目标函数。这些点的选择完全是任意的，只要它们的数量保持有限即可（稍后我们会看到，如果仅施加简单下降条件，这些点必须在网格 M_k 中，但为了尽可能保持概念性的表述，我们跳过这个问题）。[9] 例如，这些点

[9] It is obvious that descent in the search step must be controlled in some form. The reader can think of what a sequence of points of the form $x_k = 2 + 1/k$ does to the minimization of $f(x) = x^2$.

可能根据特定应用属性或遵循某种启发式算法来选择。搜索步骤可以利用代理模型的存在来改进直接搜索方法的效率，f(见第12章)。如果找到新点 x_{k+1} 使得 $f(x_{k+1}) < f(x_k)$，则搜索步骤和当前迭代被宣布为成功。

轮询步骤仅在搜索步骤未成功时执行。它由围绕当前迭代点的局部搜索组成，探索由步长参数 α_k 和正基 D_k 定义的一组点：[10]

$$P_k = \{x_k + \alpha_k d : d \in D_k\}. \tag{7.3}$$

点 $x_k + \alpha_k d \in P_k$ 称为轮询点，向量 $d \in D_k$ 称为轮询向量或方向。稍后我们会看到，如果仅施加简单下降条件，轮询点也必须位于网格 M_k 中，但同样地，我们跳过这个问题，专注于这些方法的几何性质（这些性质与其他无导数方法的性质相关）。

轮询步骤的目的是确保在足够小的步长参数α_k下目标函数下降。正如我们在第2.2节中所见，只要目标函数保持一定的可微性，并且除非当前迭代点是一个驻点，我们知道轮询步骤最终必定成功（在有限次减小步长参数之后）。这里的关键因素是，在每个正基D_k中至少存在一个下降方向。

如果找到一个新点 $x_{k+1} \in P_k$ 满足 $f(x_{k+1}) < f(x_k)$，则 poll 步和当前迭代被宣布成功。如果 poll 步未能在 P_k 中产生一个目标函数值低于 $f(x_k)$ 的点，那么 poll 步和迭代都被宣布失败。在这种情况下，步长参数 α_k 通常会减小。

如果迭代成功（即在搜索步骤或轮询步骤中找到新的迭代点，使得目标函数值下降），则步长参数保持不变（或可能增大）。

在这类方向直接搜索方法中，可以考虑使用多个正基，同时仍能保证全局收敛到驻点。当基于目标函数的 *simple decrease* 来接受新迭代点时（正如我们刚刚描述的），正基的数量要求是有限的。正如我们稍后将指出的，如果对新迭代点的接受施加 *sufficient decrease* 条件，这一要求可以放宽。尽管如此，在这种情况下，也只能使用余弦测度一致有界远离零的无限多个正基。

本书分析的方向性直接搜索方法类在算法7.2中描述。我们的描述遵循[18]中给出的广义模式搜索，分别考虑搜索和投票步骤。目前我们未指定算法中使用的正基集合$\mathcal{D}$。投票是机会主义的，移动到首次遇到的更优点。在投票步骤中，投票向量（或点）根据某种标准排序。在许多论文和实现中，这种排序是它们最初存储的顺序，并且在迭代过程中从不改变。因此，我们对方向性直接搜索的表述认为，在（机会主义）投票开始之前，投票方向已按某种给定形式排序。从理论角度来看，这种排序无关紧要，且可能在每次

[10] The application of this class of direct-search methods and its convergence properties is valid both for positive spanning sets and positive bases (satisfying some properties mentioned later).

迭代。高效地对轮询方向进行排序的程序包括：按照与负单纯形梯度的角度接近程度排序、随机排序，以及按照原始顺序排序但在新的轮询迭代中避免重新开始（以及这些策略的组合）。

算法7.2（方向直接搜索法）。

初始化：选择x_0、$\alpha_0 > 0$、$0 < \beta_1 \leq \beta_2 < 1$和$\gamma \geq 1$。令$\mathcal{D}$为一组正基。

对于 $k = 0, 1, 2, \ldots$

1. 搜索步骤：尝试通过有限数量的点评估函数 f 来计算一个含有 $f(x) < f(x_k)$ 的点。如果找到这样的点，则设置 $x_{k+1} = x$，宣布迭代和搜索步骤成功，并跳过轮询步骤。

2. 探测步骤：从集合 $\mathcal{D}$ 中选择一个正基 D_k。对探测集 $P_k = \{x_k + \alpha_k d$ 进行排序：$d \in D_k\}$。按照所选顺序在探测点开始评估 f。如果找到一个探测点 $x_k + \alpha_k d_k$ 使得 $f(x_k + \alpha_k d_k) < f(x_k)$ 成立，则停止探测，设定 $x_{k+1} = x_k + \alpha_k d_k$，并宣布该迭代和探测步骤成功。否则，宣布该迭代（以及探测步骤）失败，并设定 $x_{k+1} = x_k$。

3. 网格参数更新：如果迭代成功，则保持或增加步长参数：$\alpha_{k+1} \in [\alpha_k, \gamma\alpha_k]$。否则，减小步长参数：$\alpha_{k+1} \in [\beta_1\alpha_k, \beta_2\alpha_k]$。

轮询步骤最多进行$|D_k|$ (次函数评估，其中$|D_k| \geq n + 1$)，并且在所有不成功的迭代中恰好进行那么多次。

方向直接搜索中的自然停止准则是当 $\alpha_k < \alpha_{tol}$ 时终止运行，对于选定的容差 $\alpha_{tol} > 0$（例如，$\alpha_{tol} = 10^{-5}$）。

7.3 连续可微情形下的全局收敛性

首先，我们指出这类方向直接搜索方法传统上是在所有迭代点都位于一个紧致集的假设下进行分析的。给定迭代序列 $\{x_k\}$ 使得 $\{f(x_k)\}$ 单调递减，施加这一假设的一种便捷方式是假定水平集 $L(x_0) = \{x \in \mathbb{R}^n : f(x) \leq f(x_0)\}$ 是紧致的。

假设 7.1。*The level set* $L(x_0) = \{x \in \mathbb{R}^n : f(x) \leq f(x_0)\}$ *is compact.*

我们关注分析这些方法的全局收敛性质，即从任意初始点收敛到驻点。在直接搜索中，我们将仅处理一阶驻点。

步长参数的行为

对于这些直接搜索方法的全局收敛性分析，首先依赖于证明存在一个步长参数子序列收敛于零。为此，我们必须能够确保以下假设。

假设7.2。*If there exists an $\alpha > 0$ such that $\alpha_k > \alpha$, for all k, then the algorithm visits only a finite number of points.*

在第7.5节和第7.7节中，我们将讨论在直接搜索的实际实现中如何确保这一假设。我们将在第7.5节中看到，当正基的数量有限时，对这些基的构造以及步长参数的更新施加某种整数/有理结构就足以达到此目的。当允许任意数量的基时，则需要其他条件来实现假设7.2（即接受新迭代点的充分下降条件，正如我们将在第7.7节中证明的那样）。

基于假设7.2，可以证明步长参数趋向于零。

T定理 7.1. *Let Assumption* 7.2 *hold. Then the sequence of step size parameters satisfies*

$$\liminf_{k \longrightarrow +\infty} \alpha_k = 0.$$

Proof. 让我们反证法假设存在一个$\alpha > 0$，使得对于所有k都有$\alpha_k > \alpha$。那么根据假设7.2可知，算法访问的点的数量是有限的。另一方面，只有当目标函数出现下降时，算法才会移动到不同的点。将上述两个论点结合起来，我们得出结论：必然存在一个迭代$\bar{k}$，使得对于所有$k \geq \bar{k}$都有$x_k = x_{\bar{k}}$。根据在不成功迭代中α_k的更新方式，可以得出$\lim_{k \longrightarrow +\infty} \alpha_k = 0$，这与我们在证明开始时所假设的相矛盾。

□

以下推论由假设 7.1 得出。

推论 7.2。 *Let Assumptions* 7.1 *and* 7.2 *hold. There exist a point x_* and a subsequence $\{k_i\}$ of unsuccessful iterates for which*

$$\lim_{i \longrightarrow +\infty} \alpha_{k_i} = 0 \qquad \textit{and} \qquad \lim_{i \longrightarrow +\infty} x_{k_i} = x_*. \tag{7.4}$$

Proof. 定理7.1说明了迭代序列中存在一个无限子序列，使得步长参数趋向于零。因此，必然存在对应于不成功轮询步骤的无限迭代子序列，因为步长参数仅在此类迭代中减小。令K_u^1表示所有不成功的轮询步骤的索引子序列。

由更新步长参数的方案及上述观察还可推知，必定存在一个子序列 $K_u^2 \subset K_u^1$ 使得 $\alpha_{k+1} \to 0$ 对于 $k \in K_u^2$。由于 $\alpha_k \leq (1/\beta_1)\alpha_{k+1}$ 对于 $k \in K_u^2$，我们得到 $\alpha_k \to 0$ 对于 $k \in K_u^2$。

由于 $\{x_k\}_{K_u^2}$ 是有界的，它包含一个收敛的子序列 $\{x_k\}_{K_u^3}$。令 $x_* = \lim_{k \in K_u^3} x_k$。因为 $K_u^3 \subset K_u^2$，同样有 $\lim_{k \in K_u^3} \alpha_k = 0$，通过设置 $\{k_i\} = K_u^3$，证明完成。

□

方向直接搜索的全局收敛性分析的其余部分依赖于正基的几何性质以及f在水平集$L(x_0)$上或推论7.2中确定的极限点x_*处的可微性性质。接下来我们将考虑最相关的情况。

任意正基集合

方向性直接搜索方法可以利用无限多的正基，只要它们不退化为退化状态，即只要它们的余弦测度一致地远离零。接下来我们阐述这一假设。此外，还需要限制所使用的所有正基中所有向量的大小。

假设 7.3。*Let $\xi_1, \xi_2 > 0$ be some fixed positive constants. The positive bases D_k used in the algorithm are chosen from the set*

$$\mathcal{D} = \left\{ \bar{D} \text{ positive basis} : \operatorname{cm}(\bar{D}) > \xi_1, \ \|\bar{d}\| \leq \xi_2, \bar{d} \in \bar{D} \right\}.$$

此外，当使用无限数量的基时，我们要求f的梯度在水平集$L(x_0)$上是Lipschitz连续的。

假设 7.4。*The gradient ∇f is Lipschitz continuous in an open set containing $L(x_0)$ (with Lipschitz constant $\nu > 0$).*

我们稍后将看到，如果使用有限数量的正基，这一假设并非必要。通过假设Lipschitz连续性，我们可以利用定理2.8的结果，从而将此类型直接搜索的全局收敛性与基于线搜索或信赖域的无导数方法的全局收敛性联系起来。

在这个假设下，我们得出了关于所考虑的直接搜索方法类的首个全局收敛结果。

定理 7.3。*Let Assumptions 7.1, 7.2, 7.3, and 7.4 hold. The n*

$$\liminf_{k \longrightarrow +\infty} \|\nabla f(x_k)\| = 0,$$

and the sequence of iterates $\{x_k\}$ has a limit point x_* (given in Corollary 7.2) for which

$$\nabla f(x_*) = 0.$$

Proof. 推论7.2表明了存在一个不成功迭代（或不成功轮询步骤）的子序列$\{k_i\}$，使得(7.4)成立。

由定理2.8（该定理可应用于不成功的投票步骤，并且对于足够大的k_i），我们得到

$$\|\nabla f(x_{k_i})\| \leq \frac{\nu}{2} \operatorname{cm}(D_{k_i})^{-1} \max_{d \in D_{k_i}} \|d\| \alpha_{k_i}. \tag{7.5}$$

作为假设7.3的结果，我们得到

$$\|\nabla f(x_{k_i})\| \leq \frac{\nu \xi_2}{2\xi_1} \alpha_{k_i}.$$

因此，我们得出结论：

$$\lim_{i \longrightarrow +\infty} \|\nabla f(x_{k_i})\| = 0,$$

这显示了定理的第一部分。由于 ∇f 是连续的，$x_* = \lim_{i \longrightarrow +\infty} x_{k_i}$ 使得 $\nabla f(x_*) = 0$ 。 □

也可以通过假设 ∇f 在 x_* (附近是利普希茨连续的来获得定理7.3的结果，这里的意义是在包含 x_*) 的球内，其中 x_* 是推论7.2中确定的点。注意，为了获得这一结果，仅假设 ∇f 在 f 的所有驻点附近是利普希茨连续的还不够，因为正如我们将在第7.4节中看到的，如果缺乏光滑性，推论7.2中的点 x_* 可能不是驻点。

步长参数为方向直接搜索方法提供了一个自然的停止准则，因为不仅存在一个步长参数子序列收敛于零（定理7.1），而且在连续可微的情况下，人们还有（在一次不成功的迭代之后）$\nabla f(x_k) = \mathcal{O}(\alpha_k)$（再次参见定理2.8或上文(7.5)）。一般而言，α_k似乎是平稳性的一个合理度量（即使在非光滑情况下）。Dolan、Lewis和Torczon [80]详细研究了这一问题。[11]他们报告的结果表明，在实践中人们还观察到 $\alpha_k = \mathcal{O}(\nabla f(x_k))$，这一假设得到了我们数值经验的证实。

正基的有限集

现在我们将证明在正基数量有限的假设下全局收敛性，采用的论证方法与定理7.3的证明不同。

定理7.3的证明在所有正基集合为无限时仍然成立，只要$\mathrm{cm}(D_k)^{-1}$是一致有界的。然而，下面定理7.4中所使用的论证严重依赖于有限数量的不同D_k。

两个证明各有其优势。定理7.4的证明易于推广至非光滑情形，正如我们接下来将看到的。定理7.3的证明不仅更接近本书中分析其他方法时所采用的风格，还允许使用无限多个正基（只要其余弦测度一致有界远离零）。

假设 7.5。*The set $\mathcal{D}$ of positive bases used by the algorithm is finite.*

在这种情况下，只需要求f的梯度连续即可。以下假设是关于目标函数连续可微性的假设，与假设7.4相对应。

假设 7.6。*The function f is continuously differentiable in an open set containing $L(x_0)$.*

[11] In their paper it is also shown that *pattern-search methods* (directional direct-search methods based on integer lattices, as explained in Section 7.5) produce sequences of iterates for which the subsequence of unsuccessful iterates converges r-linearly to x_* (in the case where α_k is not increased at successful iterations after some finite iteration).

现在我们证明，对于连续可微函数 f，与定理7.3相同的结果，但采用不同的证明方法。

定理 7.4。 *Let Assumptions* 7.1, 7.2, 7.5, *and* 7.6 *hold. Then the sequence of iterates* $\{x_k\}$ *has a limit point* x_* *(given in Corollary* 7.2*) for which*

$$\nabla f(x_*) = 0.$$

Proof. 回想投票集 P_k 和不成功迭代（包括不成功的投票步骤）的定义。对于任何不成功的迭代 k (，若 f 在 x_k) 处连续可微，则以下成立：

$$\begin{aligned} f(x_k) \le \min_{x\in P_k} f(x) &= \min_{x\in\{x_k+\alpha_k d : d\in D_k\}} f(x) \\ &= \min_{d\in D_k} f(x_k+\alpha_k d) \\ &= \min_{d\in D_k} f(x_k) + \nabla f(x_k + t_{k,d}\alpha_k d)^\top(\alpha_k d) \\ &= f(x_k) + \alpha_k \min_{d\in D_k} \nabla f(x_k + t_{k,d}\alpha_k d)^\top d, \end{aligned}$$

其中 $t_{k,d} \in (0, 1)$ 取决于 k 和 d，因此

$$0 \le \min_{d\in D_k} \nabla f(x_k + t_{k,d}\alpha_k d)^\top d.$$

推论7.2表明了存在一个失败迭代的子序列$\{k_i\}$，使得(7.4)成立。上述不等式对于这个子序列$\{k_i\}$同样成立。由于正基的数量是有限的，因此存在至少一个$D_* \subset \mathcal{D}$，在$\{k_i\}$中被无限次使用。于是，

$$0 \le \min_{d\in D_*} \nabla f(x_*)^\top d. \tag{7.6}$$

不等式 (7.6) 和定理 2.3(iv) 中给出的生成集的性质必然意味着 $\nabla f(x_*) = 0$。 □

也可以通过假设 ∇f 在包含 x_*) 的球内接近 x_* (的意义下连续来得到定理7.4的结果，其中 x_* 是推论7.2中指出的点。

7.4 非光滑情形下的全局收敛性

在非光滑情况下，不能期望方向直接搜索全局收敛到平稳点。图7.4中我们描绘了二维实函数的等值线：

$$f(x) = \frac{1}{2}\max\left\{\|x-c_1\|^2, \|x-c_2\|^2\right\}, \tag{7.7}$$

其中$c_1 = (1、-1)$和$c_2 = -c_1$。这个函数在[145]中被引入，是Dennis-Woods函数[78]的一个变体。该函数处处连续且严格凸，但其梯度在直线$x_1 = x_2$上不连续。该函数在(0, 0)处有一个严格极小值点。

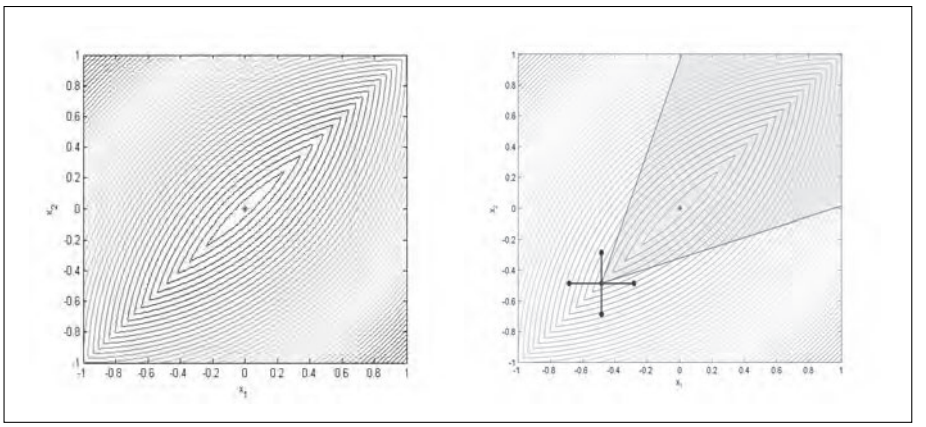


图7.4。*Contours of the Dennis–Woods-type function* (7.7) *for* $c_1 = (1, -1)$ *and* $c_2 = -c_1$. *The cone of descent directions at the poll center is shaded.*

还有文献[145]指出，坐标搜索在该函数上可能无法收敛。读者可以立即看出，在形式为(a, a)的任意点，当$a \neq 0$时，坐标搜索会产生无限次不成功的迭代，且没有任何进展。事实上，$D_{\oplus} = [e_1\ e_2\ -e_1\ -e_2]$中的任何元素都不是下降方向（见图7.4）。在$(a, a)$处，当$a \neq 0$时，$f$的下降方向在图中阴影区域标出。我们的数值经验并未导致观察到（文献[145]中报道的）坐标搜索经常倾向于收敛到这种形式的点，从而容易发生停滞。事实上，我们发现只有当起始点过于接近这条线上的点时才会发生停滞，如图7.5所示。

不过，可以证明，在假设7.1、7.2和7.5下，方向直接搜索能够生成一个迭代序列，该序列有一个极限点，其中沿正基中所有方向的方向导数非负。这样的陈述可能并不是任何类型的平稳性（最优性的必要条件）的证明，正如上面的例子会立即显示的那样。

让我们考虑推论7.2中指出的点x_*。我们将假设f在x_* (附近是Lipschitz连续的，即在x_*)的邻域内，因此广义方向导数（在Clarke意义[54]下）可以采取如下形式

$$f^\circ(x;d) \;=\; \limsup_{y \to x, t \downarrow 0} \frac{f(y+td)-f(y)}{t}$$

对于所有方向$d \in \mathbb{R}^n$。由于f在x_*附近是利普希茨连续的，因此该极限是良定义的，广义次微分（或次梯度）也是如此。

$$\partial f(x_*) \;=\; \{s \in \mathbb{R}^n :\; f^\circ(x_*;v) \geq v^\top s \quad \forall v \in \mathbb{R}^n\}.$$

此外，

$$f^\circ(x_*;d) \;=\; \max\{d^\top s :\; s \in \partial f(x_*)\}.$$

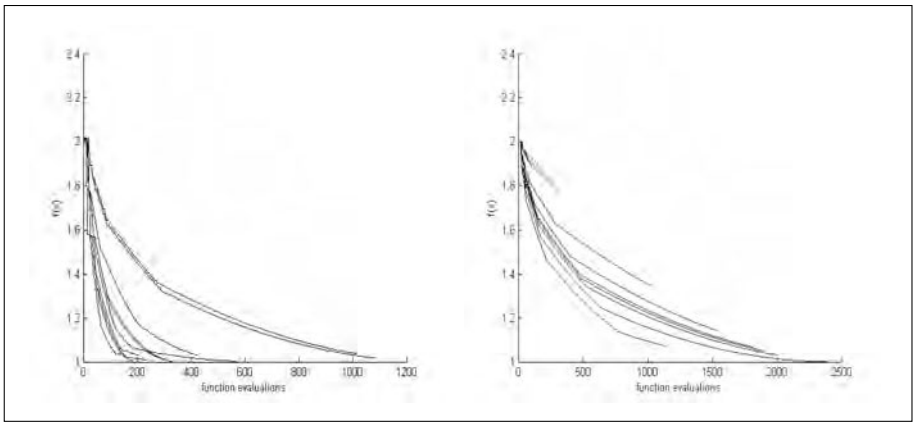


图7.5。*Application of the coordinate-search method to the Dennis–Woods function* (7.7) *starting around the point* $x_0 = (1, 1)$. *The plots on the left (resp., right) correspond to* 10 *starting points randomly generated in a box of* ℓ_∞ *radius* 10^{-2} *(resp.,* 10^{-3}*) around the point* (1, 1).

假设 7.7。*Let* x_* *be the point identified in Corollary* 7.2*, and let the function* f *be Lipschitz continuous near* x_*.

定理 7.5. *Let Assumptions* 7.1*,* 7.2*,* 7.5*, and* 7.7 *hold. Then the sequence of iterates* $\{x_k\}$ *has a limit point* x_* *(given in Corollary* 7.2*) for which*

$$f^\circ(x_*; d) \geq 0 \quad \forall d \in D_*,$$

where D_* *is one of the positive bases in* $\mathcal{D}$.

Proof. 推论 7.2 展示了存在一个失败迭代的子序列 $\{k_i\}$，使得(7.4)成立。由于所用的正基数量有限，存在一个正基 $D_* \subset \mathcal{D}$，对此

$$f(x_{k_i} + \alpha_{k_i} d) \geq f(x_{k_i})$$

对于所有 $d \in D_*$ (和所有充分大的 i)。

根据广义方向导数的定义，对于所有 $d \in D_*$，我们得到

$$f^\circ(x_*; d) = \limsup_{y \to x_*, t \downarrow 0} \frac{f(y + td) - f(y)}{t} \geq \limsup_{k \in \{k_i\}} \frac{f(x_k + \alpha_k d) - f(x_k)}{\alpha_k} \geq 0.$$

证明完毕。 □

如果除假设7.7之外，函数f在x_* (处是正则的，意味着方向导数$f'(x_*;\ v)$存在且与广义方向导数$f^\circ(x_*;\ v)$对所有$v \in \mathbb{R}^n$一致；参见[54])，那么定理7.5的结果变为

$$f'(x_*; d) \geq 0 \quad \forall d \in D_*,$$

其中 D_* 是 $\mathcal{D}$ 中的正基之一。定理7.5的结果以及针对正则函数的这一特例均不意味着在 x_* 处具有平稳性，这正如所料，因为 $D_* \neq \mathbb{R}^n$ 且如上述示例所示。

此外，若函数f在x_* (处是所谓的严格可微，这等价于说f在x_*附近是Lipschitz连续的，并且存在一个向量$w = \nabla f(x_*)$——“梯度”——使得

$$f^\circ(x_*; v) \;=\; w^\top v$$

对于所有 $v \in \mathbb{R}^n$；参见 [54])，则定理 7.5 的结果变为对所有 $d \in D_*$ 的 $\nabla f(x_*)^\top d \geq 0$。那么，定理 2.3(iv) 中给出的关于正生成集的性质意味着 $\nabla f(x_*) = 0$，这与我们在连续可微情形（定理 7.4）中得到的结果相似。

注意，如果不假设推论7.2中的点x_*处严格可微，坐标搜索仍可能无法收敛。在[145]中，作者给出了例子

$$\hat{f}(x) \;=\; \left(1 - e^{-10^3\|x\|^2}\right) f(x),$$

其中 $f(x)$ 是 (7.7) 中定义的改良 Dennis–Woods 函数。函数$\hat{f}(x)$ 与 $f(x)$ 仅略有不同，但现在在极小值点 (0, 0) 处是严格可微的（但在 (a, a) 处仍不是严格可微的，其中 $a \neq$ 为 0）。然而，之前同样的问题仍可能出现：坐标搜索可能找到形如 (a, a) 的点，其中 $a \neq$ 为 0，并因 $D_\oplus$ 中没有任何方向在轮询步骤中提供下降而停止，无论步长参数多么小。

7.5 整数格中的简单递减

我们首先刻画用于轮询的$\mathcal{D}$中的方向。我们假设$\mathcal{D}$是有限的，且$\mathcal{D} = D$。正如本书前面所指出的，将D_k视为一个$n \times |D_k|$矩阵，其列是D_k中的向量，会很方便；同样地，我们将有限集合D视为一个$n \times |D|$矩阵，其列是D中的向量。

假设 7.8。 *The set $\mathcal{D} = D$ of positive bases used by the algorithm is finite. In addition, the columns of D are of the form $G\bar{z}_j$, $j = 1, \ldots, |D|$, where $G \in \mathbb{R}^{n\times n}$ is a nonsingular matrix and each $\bar{z}_j$ is a vector in $\mathbb{Z}^n$.*

令$\bar{Z}$ 表示列向量为$\bar{z}_j$、$j = 1$、…、$|D|$ 的矩阵。因此我们可以写出 $D = G\bar{Z}$。矩阵 G 称为网格或模式生成器。

在本节中，我们将要求算法生成的所有点都位于一个由 D 中向量的所有可能非负整数组合所定义的网格 M_k 上：

$$M_k \;=\; \left\{x_k + \alpha_k Du : u \in \mathbb{Z}_+^{|D|}\right\}, \tag{7.8}$$

其中 $\mathbb{Z}_+$ 是非负整数集合。网格 M_k 以当前迭代点 x_k 为中心，其离散化尺寸由步长或网格尺寸参数 α_k 定义。容易看出，为坐标搜索引入的网格 (7.2) 是 M_k 在 $D = D_\oplus$ 时的特例。

请注意，在 M_k 的定义中，u 的取值范围允许选取 $\mathbb{R}^{|D|}$ 的规范基中的向量。因此，所有形如 $x_k + \alpha_k d$、$d \in D_k$ 的点对于任意都属于 M_k

$D_k \subset \mathcal{D}$很明显，$P_k \subset M_k$，因此我们只需对搜索步骤施加以下条件。

假设 7.9。*The search step in Algorithm* 7.2 *evaluates only points in* M_k *defined by* (7.8) *for all iterations* k.

将方向性直接搜索型方法全局化的一种标准方式是迫使迭代点位于整数格上。这一意图通过施加假设7.8和7.9以及以下附加假设来实现。

假设 7.10. *The step size parameter is updated as follows: Choose a rational number* $\tau > 1$, *a nonnegative integer* $m^+ \geq 0$, *and a negative integer* $m^- \leq -1$. *If the iteration is successful, the step size parameter is maintained or increased by taking* $\alpha_{k+1} = \tau^{m_k^+} \alpha_k$, *with* $m_k^+ \in \{0, \ldots, m^+\}$. *Otherwise, the step size parameter is decreased by setting* $\alpha_{k+1} = \tau^{m_k^-} \alpha_k$, *with* $m_k^- \in \{m^-, \ldots, -1\}$.

请注意，这些规则通过设置 $\beta_1 = \tau^{m^-}$、$\beta_2 = \tau^{-1}$ 和 $\gamma = \tau^{m^+}$ 来遵循算法 7.2 的规则。

首先，我们证明来自[18]的一个辅助结果，该结果本身也颇具意义。这一结果表明，网格M_k中任意两个不同点之间的最小距离由网格参数α_k的倍数从下方界定。

莱姆马 7.6。*Let Assumption* 7.8 *hold. For any integer* $k \geq 0$, *one has that*

$$\min_{\substack{y,w \in M_k \\ y \neq w}} \|y - w\| \geq \frac{\alpha_k}{\|G^{-1}\|}.$$

Proof. 令 $y = x_k + \alpha_k D u_y$ 和 $w = x_k + \alpha_k D u_w$ 为 M_k 中两个不同的点，其中 u_y、$u_w \in \mathbb{Z}_+^{|D|}$ (且 $u_y \neq u_w$)。则

$$\begin{aligned} 0 \neq \|y - w\| &= \alpha_k \|D(u_y - u_w)\| \\ &= \alpha_k \|G\bar{Z}(u_y - u_w)\| \\ &\geq \alpha_k \frac{\|\bar{Z}(u_y - u_w)\|}{\|G^{-1}\|} \\ &\geq \frac{\alpha_k}{\|G^{-1}\|}. \end{aligned}$$

最后一个不等式成立是因为一个非全零整数向量，如$\bar{Z}(u_y - u_w)$，其范数永远不会小于一。 □

需要指出的是，这一结果是在假设7.8下得到的，其中网格生成的整数性要求起到了关键作用。例如，$\{-1、+\pi\}$中方向的所有正整数组合在实数线上是稠密的，而$\{-1、+1\}$则不具备这一性质。重要的是，对于步长参数的固定值，要保证分离度有界且远离零，而整数性是一种保证这种分离的便捷方式。

现在 我们证明步长或网格参数的序列是b 被包围了。

引理 7.7. *Let Assumptions* 7.1, 7.8, 7.9, *and* 7.10 *hold. There exists a positive integer* r^+ *such that* $\alpha_k \le \alpha_0 \tau^{r^+}$ *for any* $k \in \mathbb{N}_0$.

Proof. 由于 $L(x_0)$ 是紧致的，可以考虑

$$\theta \;=\; \max_{y,w \in L(x_0)} \|y - w\|.$$

现在假设对于某个 $k \in \mathbb{N}_0$，有 $\alpha_k > \theta \|G^{-1}\|$。那么引理 7.6，取 $w = x_k$，将向我们表明任何不同于 x_k 的 $y \in M_k$ 都不属于 $L(x_0)$。因此，如果 $\alpha_k > \theta \|G^{-1}\|$，则迭代 k 将不会成功，并且 $x_{k+1} = x_k$。

步长参数在低于边界 $\theta \|G^{-1}\|$ 时可能越过它。当发生这种情况时，必须在成功迭代时发生，且不能超过 $\tau^{m^+} \theta \|G^{-1}\|$，其中 m^+ 是 m_k^+ 的上界。因此，序列 $\{\alpha_k\}$ 必须以 $\tau^{m^+} \theta \|G^{-1}\|$ 为界。令 r^+ 为满足 $\tau^{m^+} \theta \|G^{-1}\| \le \alpha_0 \tau^{r^+}$ 的整数，即完成证明。 □

由于 α_{k+1} 是通过将 α_k 乘以 τ 的整数次幂得到的，对于任意 $k \in \mathbb{N}_0$，我们可以写出

$$\alpha_k \;=\; \alpha_0 \tau^{r_k} \tag{7.9}$$

对于 $\mathbb{Z}$ 中的某个 r_k。我们现在展示，在本节所施加的假设下，算法 7.2 满足之前用于全局收敛的假设。

定理 7.8。 *Let Assumptions* 7.1, 7.8, 7.9, *and* 7.10 *hold. If there exists an* $\alpha > 0$ *such that* $\alpha_k > \alpha$, *for all* k, *then the algorithm visits only a finite number of points. (In other words, Assumption* 7.2 *is satisfied.)*

Proof. 步长参数的形式为（7.9），因此为了展示结果，我们定义一个负整数r^-，使得对于所有的$k \in \mathbb{N}_0$，都有$0 < \alpha_0 \tau^{r^-} \le \alpha_k$。于是，根据引理7.7，我们得出结论，对于所有的$k \in \mathbb{N}_0$，$r_k$必须在集合$\{r^-,\ r^- + 1,\ \ldots,\ r^+\}$中取整数值。

已知对于成功的迭代 k，x_{k+1} 可以写成 $x_k + \alpha_k D u_k$，其中 $u_k \in \mathbb{Z}_+^{|D|}$ 为某值。在不成功的迭代中，$x_{k+1} = x_k$ 和 $u_k = 0$。将 α_k 替换为 $\alpha_0 \tau^{r_k}$，对于任意整数 $\ell \ge 1$，我们得到，

$$\begin{aligned} x_\ell &= x_0 + \sum_{k=0}^{\ell-1} \alpha_k D u_k \\ &= x_0 + \alpha_0 G \sum_{k=0}^{\ell-1} \tau^{r_k} \bar{Z} u_k \\ &= x_0 + \frac{p^{r^-}}{q^{r^+}} \alpha_0 G \sum_{k=0}^{\ell-1} p^{r_k - r^-} q^{r^+ - r_k} \bar{Z} u_k, \end{aligned}$$

wh其中 p 和 q 是满足 $\tau = p/q$ 的正整数。S ince

$$\sum_{k=0}^{\ell-1} p^{r_k - r^-} q^{r^+ - r_k} \bar{Z} u_k$$

是一个整数向量，对于所有 $\ell \in \mathbb{N}$，我们已经证明了迭代序列 $\{x_k\}$ 位于形式为（一个整数格）的集合中

$$\mathcal{L} = \{x_0 + G_0 z : z \in \mathbb{Z}^n\},$$

其中

$$G_0 = \frac{p^{r^-}}{q^{r^+}} \alpha_0 G$$

是一个非奇异$n \times n$矩阵。现在注意，$\mathcal{L}$与紧致集$L(x_0)$的交集必然是有限集，这表明算法必定只访问有限数量的点。 □

需要强调的是，定理7.8中并未特别要求f具有任何特定属性。

本节其余部分聚焦于所提出的直接搜索框架的特定情形，以及一些保持步长参数渐近行为的扩展。对于不熟悉这些方向直接搜索方法收敛性质的读者，可将本节其余部分留待日后阅读。

完整性和合理性要求的严格性

假设7.8和7.10是定理7.1和7.8成立的必要条件，当使用有限数量的正基且仅施加简单下降时。

可以证明，假设7.8中关于正基的整数性要求不能取消。Audet [12] 构造的一个例子展示了算法7.2的一个实例，该实例不满足假设7.8中关于正基的整数性要求，并且当应用于某个光滑函数 f 时，步长参数 α_k 一致地远离零有界。

Audet [12] 还证明了关于 τ 的有理数要求是严格的。他给出了算法7.2的一个实例，其中 τ 选择无理数，对于给定的函数 f 生成一致远离零的步长参数 α_k。我们指出，此反例中使用的函数 f 是不连续的，这在本节的假设下是可以接受的。

当 $\tau > 1$ 是整数（而不仅仅是有理数）时，上述分析可以进一步简化。实际上，很容易看出定理7.8证明中的 $q = 1$ 以及 r_k 上的上界 r^+ 不再必要。

网格的其他定义

网格 M_k 可以更一般地定义为，而不是如 (7.8) 中那样

$$M_k = \{x_k + \alpha_k D u : u \in \mathcal{Z}\}$$

只要集合 $\mathcal{Z} \subset \mathbb{Z}^{|D|}$ 包含 $\mathbb{R}^{|D|}$ (的标准基的所有向量，从而 $P_k \subset M_k$)。另一种可能的推广在习题中略述。

例如可以设置

$$M_k \;=\; \{x_k + \alpha_k(jd) \colon\; d \in D,\; j \in \mathbb{Z}_+\},$$

这将相当于只考虑沿向量$d \in D$的网格点。图7.6展示了当n =2时，对于D包含一个和三个最大正基的情况下的两个网格M_k。

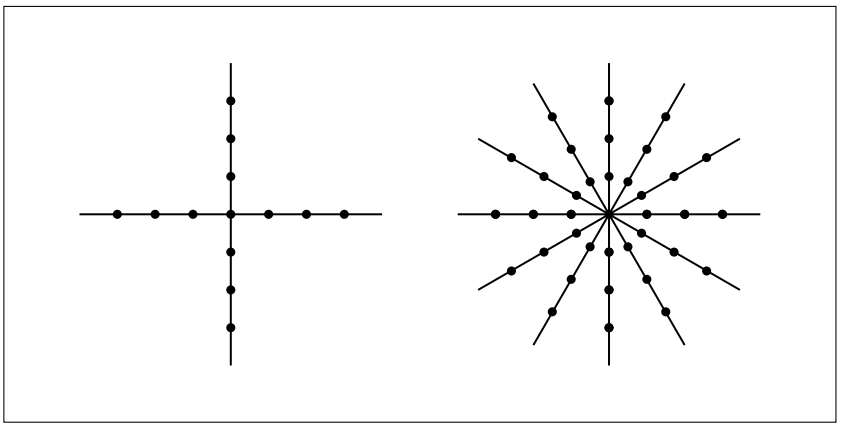


图7.6。 *Two pointed meshes, when D has one maximal positive basis (left) and three maximal positive bases (right).*

完整的轮询和渐近结果

另一个例子由Audet [12]提供，展示了在假设7.8下应用算法7.2的一个实例于连续可微函数时，能够生成无限多个极限点，其中一个并非驻点。因此，该结果

$$\liminf_{k \longrightarrow +\infty} \|\nabla f(x_k)\| \;=\; 0$$

无法扩展至

$$\lim_{k \longrightarrow +\infty} \|\nabla f(x_k)\| \;=\; 0, \tag{7.10}$$

在没有进一步假设或对算法7.2中的直接搜索方案进行修改的情况下。这一观察结果与Yuan[236]指出的无约束非线性优化信赖域算法中的类似情况一致。该作者构造了一个例子，其中基于简单下降来接受新点（而非充分下降条件——见第10章）的信赖域方法生成的迭代序列也不满足(7.10)。

能够获得（7.10）的条件已由Torczon [217]分析（另见[145]）。在方向直接搜索框架中的修改基本上有两个。

首先，要求

$$\lim_{k \longrightarrow +\infty} \alpha_k = 0.$$

根据定理7.1，保证这一条件的一种方法是在成功迭代时永不增加步长参数。

其次，是在所有成功迭代中实施所谓的完整轮询。完整轮询要求轮询步骤生成的新迭代点使函数在轮询集内达到最小：

$$f(x_{k+1}) = f(x_k + \alpha_k d_k) \leq f(x_k + \alpha_k d) \quad \forall d \in D_k.$$

完整的轮询在每一步轮询时必然需要$|D_k|$ (次函数评估，其中$|D_k| \geq n+1$)，而不仅仅是在常规轮询那样的不成功轮询步骤中。新的迭代点x_{k+1}也可以在搜索步骤中计算，只要对于所有$d \in D_k$都有$f(x_{k+1}) \leq f(x_k + \alpha_k d)$，这意味着搜索步骤随后必须跟随（完整的）轮询步骤。

(7.10) 在这两种修改下的证明被省略了。它可以分两个阶段完成。在第一阶段，证明对于任意 $\epsilon > 0$，存在 $\alpha^-, \eta > 0$，使得若 $\|\nabla f(x_k)\| > \epsilon$ 且 $\alpha_k < \alpha^-$，则 $f(x_k + \alpha_k d_k) \leq f(x_k) - \eta \alpha_k \|\nabla f(x_k)\|$。这个不等式可以解释为一种充分下降型条件（见第9章和第10章）。第二阶段包括应用 Thomas 论证 [214]，该论证以导出信赖域方法的 lim 型结果（即整个迭代序列的收敛结果；另见第10章）而闻名。细节见 [145]。

7.6 网格自适应直接搜索方法

Audet 和 Dennis 在 [19] 中引入了一类直接搜索算法，该类算法能够在非光滑情况下实现全局收敛。这类方法被称为网格自适应直接搜索（MADS），可视为算法 7.2 的一个实例。

通过整数格点的简单缩减实现全局化。因此，设网格M_k (，例如如(7.8)中给出的那样，但始终通过有限集D，由假设7.8和7.9定义。同时，让α_k按照假设7.10进行更新。MADS的关键在于允许$\mathcal{D}$为无限，从而与有限集D不同——这对于在非光滑情况下允许某种形式的极限稳定性很重要——而(7.3))中定义的投票集P_k (仍被定义为网格M_k的子集。（早期为捕捉丰富方向集而开发的方法可见于[10]。）

因此，MADS首先通过在网格 M_k 中的有限个点上评估目标函数来执行搜索步骤。如果搜索步骤失败或被跳过，则尝试投票集，即在由正基 D_k 定义的投票集 P_k 上评估目标函数，该正基 D_k 选自一组正基 $\mathcal{D}$ (，这组正基 $\mathcal{D}$ (不一定是显式给出的)。然而，现在定义这组 $\mathcal{D}$，使得元素 $d_k \in D_k$ 满足以下条件：

- d_k 是D各列的非负整数组合。

- 距离 在 x_k 和点 $x_k+\alpha_k d_k$ 之间趋于零，当且仅当 α_k 执行:

$$\lim_{k\in K}\alpha_k\|d_k\| = 0 \iff \lim_{k\in K}\alpha_k = 0 \tag{7.11}$$

对于任何无限子序列 K。

- $\bar{D}_k = \{d_k/\|d_k\|\colon\ d_k \in D_k\}$的所有收敛子序列的极限都是正基。

本着[19]中表述的精神，我们现在定义细化子序列和细化方向的概念。

定义 7.9。 *A subsequence $\{x_k\}_{k\in K}$ of iterates corresponding to unsuccessful poll steps is said to be a refining subsequence if $\{\alpha_k\}_{k\in K}$ converges to zero.*

Let x be the limit point of a convergent refining subsequence. If the limit $\lim_{k\in L} d_k/\|d_k\|$ exists, where $L \subseteq K$ and $d_k \in D_k$, then this limit is said to be a refining direction for x.

收敛加细子序列的存在性只不过是推论7.2的另一种表述。留给读者作为练习来确认这一结果对于MADS仍然成立。下一个定理指出，对于推论7.2的极限点，克拉克广义导数沿任何加细方向都是非负的。

定理 7.10。 *Let Assumptions* 7.1*,* 7.7*,* 7.8*,* 7.9*, and* 7.10 *hold. Then the sequence of iterates $\{x_k\}$ generated by MADS has a limit point x_* (given in Corollary* 7.2*) for which*

$$f^\circ(x_*; v) \geq 0$$

for all refining directions v for x_*.

Proof. 令 $\{x_k\}_{k\in K}$ 为由推论 7.2 保证的收敛到 x_* 的加细子序列，并令 $v = \lim_{k\in L} d_k/\|d_k\|$ 为 x_* 的一个加细方向，对所有 $k \in L$ 有 $d_k \in D_k$。由于 f 在 x_* 附近 Lipschitz 连续，且 $d_k/\|d_k\| \to v$ 和 $\alpha_k\|d_k\| \to 0$，对所有 $k \in L$,

$$f^\circ(x_*; v) \geq \limsup_{k\in L} \frac{f(x_k + \alpha_k\|d_k\|\frac{d_k}{\|d_k\|}) - f(x_k)}{\alpha_k\|d_k\|}. \tag{7.12}$$

由于x_k是一个不成功的轮询步骤,

$$\limsup_{k\in L} \frac{f(x_k+\alpha_k d_k) - f(x_k)}{\alpha_k\|d_k\|} \geq 0,$$

并且证明完成。 □

Audet 和 Dennis [19]（另见 [15]）提出了一种计算正基 D_k 的方案，称为基于下三角矩阵的网格自适应直接搜索（LTMADS），该方案为 x_* 生成一组细化方向，其并集在 $\mathbb{R}^n$ 中以概率一渐近稠密。根据这一点和定理 7.10，MADS 因此能够收敛到一个点，在该点处，Clarke 广义方向导数对于在 $\mathbb{R}^n$ 中几乎处处稠密的一组方向是非负的，而不仅仅是像定理 7.5 中那样对于一个有限方向集。并且

最近，Abramson等人[8]提出了一种替代方案来生成正基D_k (，这也与[10])相关，称为OrthoMADS。该策略同样生成一个渐近密集的方向集，但以确定性的方式，并且每个正基D_k都是从一个正交基构造而来，从而相对高效地确定未探索区域的缩减。

7.7 强制充分下降

对于假设7.8中整数性要求的一种替代方案，该方案仍能为方向直接搜索提供全局收敛性，即仅当新的迭代点满足充分下降条件时才接受。在本节中，我们将假设新的点 $x_{k+1} \neq x_k$ 仅当满足

$$f(x_{k+1}) < f(x_k) - \rho(\alpha_k), \tag{7.13}$$

其中 *forcing function* ρ： $\mathbb{R}_+ \to \mathbb{R}_+$ 是连续、正的，并且满足

$$\lim_{t \longrightarrow 0^+} \frac{\rho(t)}{t} = 0 \qquad \text{and} \qquad \rho(t_1) \leq \rho(t_2) \quad \text{if} t_1 < t_2.$$

一个简单的强迫函数示例是$\rho(t) = t^2$。形如$\rho(t) = t^{1+a}$的函数，对于$a > 0$，也属于这一类。

定理 7.11。*Suppose Algorithm* 7.2 *is modified in order to accept new iterates only if* (7 .13) *holds.*

Let Assumption 7.1 *hold. If there exists an* $\alpha > 0$ *such that* $\alpha_k > \alpha$*, for all k, then the algorithm visits only a finite number of points. (In other words, Assumption* 7.2 *is satisfied.)*

Proof. 由于 ρ 是单调递增的，我们知道对于所有 $k \in \mathbb{N}_0$，有 $0 < \rho(\alpha) \leq \rho(\alpha_k)$。假设存在一个成功迭代的无限子序列。由不等式 (7.13) 可得，对于所有成功迭代，

$$f(x_{k+1}) < f(x_k) - \rho(\alpha_k) \leq f(x_k) - \rho(\alpha).$$

回忆一下，在不成功的迭代中$f(x_{k+1}) = f(x_k)$。因此，序列 $\{f(x_k)\}$ 必须收敛到 $-\infty$，这显然与假设 7.1 矛盾。 □

为了在(7.13)给出的修改下，针对算法7.2证明类似定理7.3的结果，我们首先需要证明对于不成功的轮询步骤k_i，有

$$\|\nabla f(x_{k_i})\| \leq \left(\frac{\nu}{2} \text{cm}(D_{k_i})^{-1} \max_{d \in D_{k_i}} \|d\| \right) \alpha_{k_i} + \frac{\text{cm}(D_{k_i})^{-1}}{\min_{d \in D_{k_i}} \|d\|} \frac{\rho(\alpha_{k_i})}{\alpha_{k_i}}, \tag{7.14}$$

这留作练习。现在，给定强制函数 ρ 的性质，很明显，当 $\alpha_{k_i} \to 0$ 时，$\nabla f(x_{k_i}) \to 0$，前提是 D_k 中向量的最小尺寸不趋近于零。

当施加充分下降时，实际上可以证明整个步长参数序列收敛于零。

定理 7.12。*Suppose Algorithm* 7.2 *is modified in order to accept new iterates only if* (7.13) *holds.*

Let Assumption 7.1 *hold. Then the sequence of step size parameters satisfies*

$$\lim_{k \longrightarrow +\infty} \alpha_k = 0.$$

证明也留作练习。注意，假设7.1超出了证明定理7.11和7.12所需。实际上，只要假设f在$L(x_0)$上有下界就足够了。

7.8 其他注释和参考文献

文献中关于直接搜索的首次提及被归因于1952年费米和Metropolis的一份报告[90]，其形式类似于坐标搜索（见Davidon[73]的前言）。20世纪50年代，Box[42]以及Box和Wilson[44]引入了与坐标搜索相关的直接搜索算法，使用了$D_{\oplus}$的正整数组合。他们的算法在M_k中评估点，但不一定在P_k中。当时使用的一些词汇（如*two-level factorial and composite designs*[44]）受到统计学的启发，而直接搜索的许多早期工作正是在统计学领域发展起来的。[12]

Hooke和Jeeves[130]似乎是首先使用术语*direct-search methods*的人。Hooke和Jeeves[130]也被认为是首先认识到直接搜索中模式或整数格这一基本概念的人，随后其他作者对此进行了探索，特别是Berman[35]。Hooke和Jeeves的*exploratorymoves*方案是搜索步骤的前身。后来，在20世纪90年代，Torczon[216, 217]展示了如何在*pattern-search meth-ods* (的全局化中严格使用整数格，这可以定义为基于此类格的方向直接搜索方法，如第7.5节所解释的)。Audet和Dennis[18]通过基本上将这些方法的分析集中在不成功迭代的子序列上，为该领域做出了贡献。Booker等人[40]的论文应该因搜索-投票框架的正式陈述而获得大部分赞誉。

但直接搜索的早期工作并不局限于基于固定方向集生成的模式的方向性方法。事实上，一些最早的方向性直接搜索方法在每次迭代结束时通过以某种形式组合先前计算的方向集来修改搜索方向。这类方法中包括Powell [183]使用共轭方向的方法（另见Zangwill [237]引入的修改以及Toint和Callier [215]中的分析）和Rosenbrock [201]的方法。最近，Frimannslund和Steihaug [100] pursued了一种新方法，通过显式旋转基于从函数值中提取的曲率信息的方向集。

在直接搜索中引入充分下降条件（涉及步长）最早由Yu [235]于1979年提出。其他作者也探索了在有向直接搜索方法中使用此类条件，如Grippo、Lampariello和Lucidi [115]、Lucidi和Sciandrone [160]以及García-Palomares和Rodríguez [103]。特别是Lucidi和Sciandrone [160]的工作涉及算法框架的开发，探索在有向直接搜索中使用线搜索技术。

[12] J. A. Nelder and R. Mead were also statisticians.

方法。他们的收敛理论包括在合理假设下推导出的一阶 lim 型结果。[103, 160] 中方法的一个特点是考虑沿不同方向的不同步长。Diniz-Ehrhardt、Martínez 和 Raydan [79] 在设计非单调算法时使用了充分下降条件。

在整数格上方向直接搜索方法的全球化背景下（见第7.5节），在适当的情况下，可以放宽方向从有限集合{v*}中提取的假设。库珀和普赖斯[66]在他们的基于网格的方法中对此进行了探索。他们观察到，在一次不成功的迭代之后，可以改变 D (，只要它仍然满足假设7.8)，因此，在尝试捕捉函数的曲率时获得更大的灵活性。然而，这是有代价的，即应当施加$\alpha_k \to 0$，例如，在定理7.1和7.8的背景下，通过永不允许α_k增加可以保证这一点。

在尝试开发模式搜索方法的高效串行实现方面，已有一些努力，这些努力考虑了能够有效利用问题结构的特定情况。Price和Toint [195] 研究了如何利用部分可分性。Alberto等人 [10] 展示了结合用户提供函数评估的方法。Abramson、Audet和Dennis [6] 探讨了存在某些不完全梯度信息的情况。Custódio和Vicente [70] 提出了几种针对一般目标函数的程序，旨在利用单纯形导数提高模式搜索方法的效率。特别是，他们证明了在机会主义轮询中，根据负单纯形梯度对轮询方向进行排序，可以显著减少总体函数评估次数（参见[68, 70]）。

定向直接搜索方法的一个吸引人的特点是，在轮询步骤中评估函数的过程易于并行化。许多作者尝试了这些方法的不同并行版本；参见[10, 21, 77, 103, 132]。García-Palomares和Rodríguez [103]以及Hough、Kolda和Torczon [132]提出并分析了这些方法的异步并行形式（另见Gray和Kolda [110]开发的软件）。

另一个吸引人的特点是探索方向性方面，以设计具有理想性质的非光滑函数算法。我们在第7.6节中提到，MADS方法能够以概率一收敛到一阶驻点的非光滑点。[3]中展示了如何将此结果推广到具有连续一阶导数但二阶导数非光滑的二阶驻点。最近，针对非光滑函数的其他直接搜索方法已被提出[24, 37]，但仅针对特定类型的不不可微性。

生成搜索集（GSS）框架

Kolda、Lewis和Torczon [145] 引入了另一种全局收敛的方向直接搜索方法框架。这些作者在其算法描述中并未明确区分搜索步和轮询步。在其GSS框架中，成功的迭代形式为 $x_k + \alpha_k d_k$，其中 d_k 属于方向集合 $G_k \cup H_k$。在GSS中，G_k 扮演了我们轮询步中 D_k（所使用的）的角色。搜索步通过额外的方向集合 H_k（来容纳，正如第7.2节所呈现的框架中那样，该集合可能为空）。当仅基于目标函数的简单下降来接受迭代点时，类似于

必须对包含所有 $G_k \cup H_k$ 对于所有 $k \in \mathbb{Z}_+$ 的选择的有限方向集施加假设 7.8（或等效条件）。

多向搜索方法

另一种直接搜索的发展方向是单纯形方法（如Nelder和Mead单纯形法[177]）。尽管单纯形直接搜索方法与方向性直接搜索有共同特点，但它们有着自己的动机，因此将在第8章中单独讨论。

Dennis和Torczon [77]的多方向搜索（MDS）方法，接下来将进行描述，可以被视为既有方向性又基于单纯形的直接搜索方法。我们选择在书中包含MDS主要是出于历史原因，并且因为它有助于我们构建必要的修改框架，以使Nelder-Mead方法全局收敛。

如同Nelder-Mead方法（其细节此刻无需赘述），MDS从一个由$n+$个顶点 $Y = \{y^0、y^1、\ldots、y^n\}$构成的单纯形开始。每次迭代均以函数值最低的单纯形顶点 y^0为中心（与Nelder-Mead方法特别关注函数值最高的顶点形成对比）。随后，通过将顶点y^i、$i=$、…、n围绕y^0 (旋转180°度，形成旋转后的单纯形，参见图7.7)。（读者可能已识别出最大正基……）若旋转后顶点的最佳目标值低于$f(y^0)$，则沿旋转方向形成扩展单纯形（见图7.7）。根据哪个单纯形更优，下一次迭代将从旋转或扩展后的单纯形开始。如果旋转后顶点的最佳目标值不优于$f(y^0)$，则如同Nelder-Mead方法一样采取收缩步骤（见图7.7），并从收缩后的单纯形开始下一次迭代。现在，我们详细介绍MDS算法。

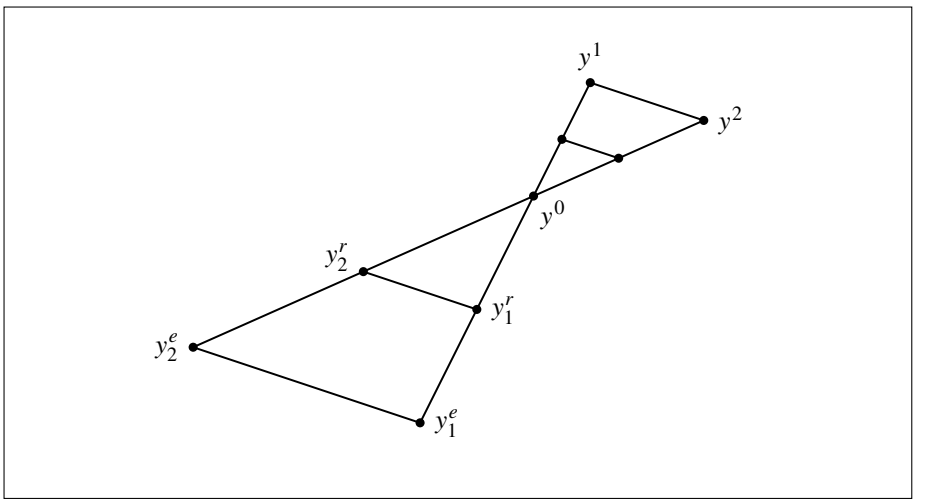


图 7.7. *Original simplex, rotated vertices, expanded vertices, shrunken vertices, corresponding to an MDS iteration.*

算法7.3（MDS方法）。

初始化：选择一个初始单纯形，其顶点为 $Y_0 = \{y_0^0、y_0^1、\ldots、y_0^n\}$。在 Y_0 中的点处计算 f。选择常数：

$$0 < \gamma^s < 1 < \gamma^e.$$

对于 $k = 0、1、2、\ldots$

0. 设置$Y = Y_k$。

1. 寻找最佳顶点：对 $Y = \{y^0、y^1、\ldots、y^n\}$ 的 $n+1$ 个顶点进行排序，使得 $f^0 = f(y^0) \le f(y^i)、i = 1、\ldots、n$。

2. 旋转：围绕最佳顶点y^0旋转单纯形：

$$y_i^r = y^0 - (y^i - y^0), \quad i = 1,\ldots,n.$$

计算 $f(y_i^r)、i = 1、\ldots、n$，并设置 $f^r = \min\{f(y_i^r) : i = 1、\ldots、n\}$。如果 $f^r < f^0$，则尝试扩展（然后取旋转或扩展单纯形中的最优者）。否则，收缩单纯形。

3. 扩展：扩展旋转后的单纯形：

$$y_i^e = y^0 - \gamma^e(y^i - y^0), \quad i = 1,\ldots,n.$$

评估 $f(y_i^e)、i = 1、\ldots、n$，并设置 $f^e = \min\{f(y_i^e) : i = 1、\ldots、n\}$。若 $f^e < f^r$，则接受扩展单纯形并终止迭代：$Y_{k+1} = \{y^0、y_1^e、\ldots、y_n^e\}$。否则，接受旋转单纯形并终止迭代：$Y_{k+1} = \{y^0、y_1^r、\ldots、y_n^r\}$。

4. 收缩：在点 $y^0 + \gamma^s(y^i - y^0)、i = 1、\ldots、n$ 处评估 f，并将 $y^1、\ldots、y^n$ 替换为这些点，终止迭代：$Y_{k+1} = \{y^0 + \gamma^s(y^i - y^0)、i = 0、\ldots、n\}$。

对于 γ^s 和 γ^e，典型值分别是 1/2 和 2。停止准则可以是当单纯形的直径小于选定容差 $\Delta_{tol} > 0$ 时终止运行（例如，$\Delta_{tol} = 10^{-5}$）。

Torczon [216] 指出，只要 γ^s 和 γ^e 是有理数，算法访问的所有可能顶点都位于一个整数格中。这一性质与每个单纯形中最佳顶点所处的位置无关。此外，请注意 MDS 算法强制要求简单下降才能接受新的迭代点（否则，单纯形会被收缩，并且最佳顶点保持不变）。因此，一旦证明了整数格命题，以下定理的证明就可由第7.3节的材料直接得出。

定理 7.13. *Suppose that $\gamma^s, \gamma^e \in \mathbb{Q}$, and let the initial simplex be of the form $Y_0 = G\bar{Z}$, where $G \in \mathbb{R}^{n\times n}$ is nonsingular and the components of $\bar{Z} \in \mathbb{R}^{n\times(n+1)}$ are integers. Assume that $L(y_0^0) = \{x \in \mathbb{R}^n : f(x) \le f(y_0^0)\}$ is compact and that f is continuously differentiable in $L(y_0^0)$. Then the sequence of iterates $\{y_k^0\}$ generated by the MDS method (Algorithm* 7.3*) has one stationary limit point x_*.*

Proof. 我们需要说服读者，我们可以将MDS构建为方向直接搜索（算法7.2）的形式。首先注意到，扩展步可以看作是一个搜索步。轮询是完整的，并且涉及与初始单纯形相关的最大正基{v*}，该基选自于由以下集合形成的集合D:

$$\left\{y_0^j - y_0^i,\ j = 0,\ldots,n,\ j \neq i\right\} \cup \left\{-(y_0^j - y_0^i),\ j = 0,\ldots,n,\ j \neq i\right\},$$

$i = 0, \ldots, n$。然后很容易看出整数格要求（见第7.5节），即假设7.8、7.9和7.10，均得到满足。 □

鉴于算法7.3生成的网格具有指向性，Y_0不必采取定理7.13中给出的形式。实际上，[216]中的原始证明并未强加这一假设。我们本可以在此处也放宽这一假设，但那样就需要对第7.5节的网格/格架框架进行修改。

另一种使MDS全局收敛至驻点的方法是在接受条件中施加充分下降，如第8章中对修改后的Nelder-Mead方法所做的那样。

7.9 练习

在具有整数格点的简单下降的方向直接搜索方法（算法7.2）的全局化背景下（第7.5节），证明由(7.8)定义的网格 M_k 可以推广为

$$M_k = \bigcup_{x \in \mathcal{E}_k} \{x + \alpha_k Du : u \in \mathbb{Z}_+^{|D|}\}, \tag{7.15}$$

其中 $\mathcal{E}_k$ 是目标函数 f 在迭代 k (开始时已评估过的点集，而 $\mathbb{Z}_+$ 是非负整数集)。

2. 设网格由假设7.8和7.9针对MADS方法定义。令α_k按照假设7.10进行更新。在假设7.1下证明推论7.2的结果成立（换言之，存在一个收敛的细化子序列）。

3. 证明(7.12)。你需要添加并减去一个项，并利用f在x_*附近的利普希茨连续性。

4. 对于当满足形式为(7.13)的充分下降条件时的不成功轮询步骤，推广定理2.8。证明你所得到的正是界(7.14)。

5. 证明定理7.12。

第8章

单纯形直接搜索法

Nelder–Mead 算法 [177] 是最流行的无导数方法之一。它已在工程界得到广泛应用，并且可能是直接搜索方法中被引用最多的一种（Nelder 和 Mead 于 1965 年发表的论文 [177] 正式属于 *Science Citation Classic*）。其成功的原因包括简单性以及能够适应所最小化函数的曲率。在本章中，我们将描述用于求解 (1.1) 的原始 Nelder–Mead 方法及其一些特点。我们将展示它为何可能失败，以及如何修正它以全局收敛到驻点。

8.1 Nelder-Mead单纯形法

Nelder–Mead 算法 [177] 是一种直接搜索方法，即它在每次迭代中在有限数量的点上评估目标函数，并仅基于这些函数值决定下一步采取何种行动，而不进行任何显式或隐式的导数近似或模型构建。$\mathbb{R}^n$ 中的每次迭代都基于 $n+1$ 个顶点 $Y = \{y^0$、y^1、…、$y^n\}$ 构成的单纯形，这些顶点按 f 的递增值排序。单纯形的定义和基本性质见第 2.5 节。

最常见的Nelder-Mead迭代执行反射、扩展或收缩（后者可在单纯形内部或外部进行）。在此类迭代中，最差顶点y^n被连接y^n和y^c的直线上的一个点所取代，

$$y \;=\; y^c + \delta(y^c - y^n), \quad \delta \in \mathbb{R},$$

其中 $y^c = \sum_{i=0}^{n-1} y^i/n$ 是最佳 n 个顶点的质心。δ 的值表示迭代类型。例如，当 $\delta = 1$ 时，我们有一个（真实或等距）反射，当 $\delta = 2$ 时是扩展，当 $\delta = 1/2$ 时是外部收缩，当 $\delta = -1/2$ 时是内部收缩。在图 8.1 中，我们绘制了这四种情况。

Nelder–Mead 迭代还可以执行单纯形收缩，这在实际中很少发生。当执行收缩时，Y 中的所有顶点除最佳顶点 y^0 外都被丢弃。然后通过收缩 y^0 处的单纯形来计算 n 个新顶点，即，例如计算 $y^0 + 1/2(y^i - y^0)$，$i = 1$，…，n。见图 8.2。我们注意到，除非发生收缩，否则所得单纯形的“形状”可以通过拉伸或收缩而改变——我们将在后面详细研究。

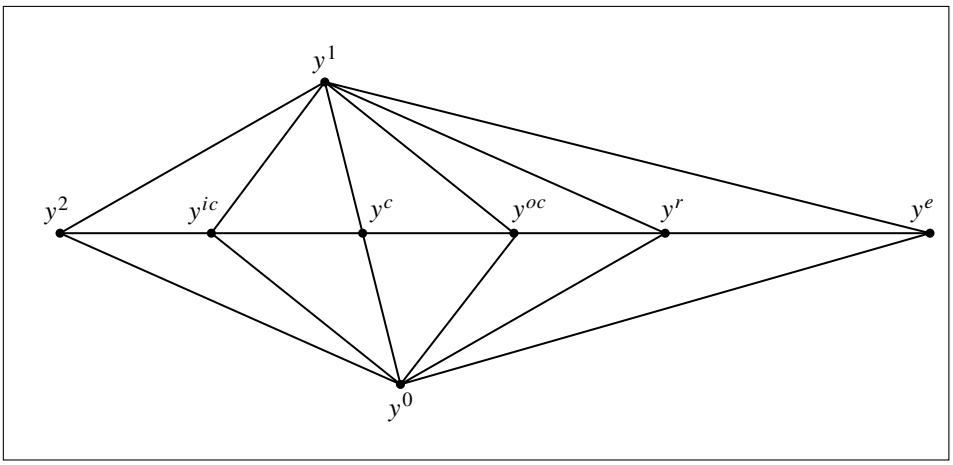


图8.1。*Reflection, expansion, outside contraction, and inside contraction of a simplex, used by the Nelder–Mead method.*

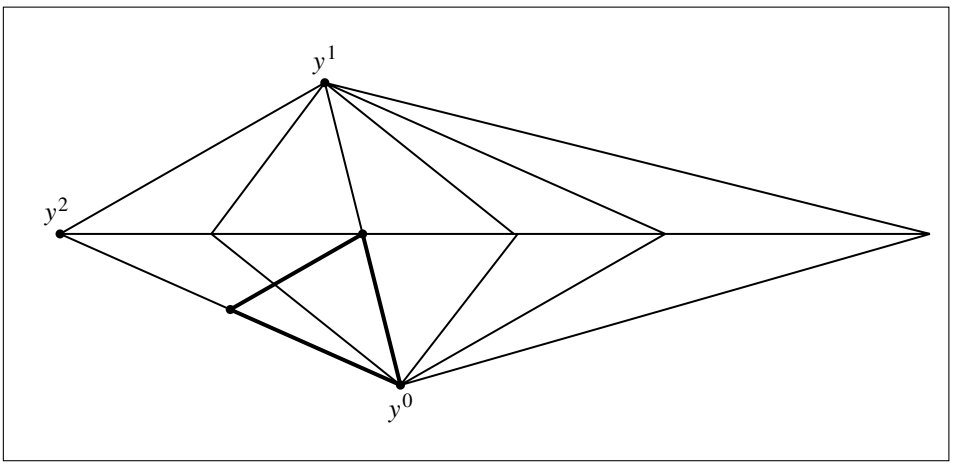


图8.2。*Shrink of a simplex, used by the Nelder–Mead method.*

Nelder-Mead方法在算法8.1中描述。所使用的系数的标准选择是：

$$\gamma^s = \frac{1}{2}, \quad \delta^{ic} = -\frac{1}{2}, \quad \delta^{oc} = \frac{1}{2}, \quad \delta^r = 1, \quad \text{and} \quad \delta^e = 2. \tag{8.1}$$

注意，除了收缩操作外，重点在于替换较差的顶点而非改进最佳顶点。还需提及的是，Nelder-Mead方法由于采样过程本质上是顺序的（除收缩阶段外），因此并行化效果不佳。

算法8.1（Nelder–Mead方法）。

初始化：选择一个初始单纯形，其顶点为 $Y_0 = \{y_0^0、\ y_0^1、\ \ldots、\ y_0^n\}$。在 Y_0 中的点处计算 f。选择常数：

$$0 \ < \ \gamma^s \ < \ 1, \qquad -1 \ < \ \delta^{ic} \ < \ 0 \ < \ \delta^{oc} \ < \ \delta^r \ < \ \delta^e.$$

对于 $k = 0、\ 1、\ 2、\ \ldots$

0. 设置$Y = Y_k$。

1. 排序：将$Y = \{y^0、\ y^1、\ \ldots、\ y^n\}$的$n+1$个顶点排序，使得

$$f^0 = f(y^0) \ \leq \ f^1 = f(y^1) \ \leq \ \cdots \ \leq \ f^n = f(y^n).$$

2. 反射：将最差点 y^n 关于其余 n 个顶点的质心 $y^c = \sum_{i=0}^{n-1} y^i / n$ 进行反射：

$$y^r \ = \ y^c + \delta^r (y^c - y^n).$$

计算$f^r = f(y^r)$。如果$f^0 \leq f^r < f^{n-1}$，则用反射点 y^r 替换 y^n 并终止迭代：$Y_{k+1} = \{y^0, y^1, \ldots, y^{n-1}, y^r\}$。

3. 扩展：如果 {v*}，则计算扩展点

$$y^e \ = \ y^c + \delta^e (y^c - y^n)$$

并计算$f^e = f(y^e)$。如果$f^e \leq f^r$，则用扩张点 y^e 替换 y^n 并终止迭代：$Y_{k+1} = \{y^0、\ y^1、\ \ldots、\ y^{n-1}、\ y^e\}$。否则，用反射点 y^r 替换 y^n 并终止迭代：$Y_{k+1} = \{y^0、\ y^1、\ \ldots、\ y^{n-1}、\ y^r\}$。

4. 收缩：如果$f^r \geq f^{n-1}$，则在 y^r 和 y^n 中的最佳者之间执行收缩。

(a) 外部收缩：如果$f^r < f^n$，则执行外部收缩

$$y^{oc} \ = \ y^c + \delta^{oc} (y^c - y^n)$$

并计算$f^{oc} = f(y^{oc})$。如果$f^{oc} \leq f^r$，则用外部收缩点 y_k^{oc} 替换 y^n 并终止迭代：$Y_{k+1} = \{y^0,\ y^1,\ \ldots,\ y^{n-1},\ y^{oc}\}$。否则，执行收缩。

(b) 内部收缩：如果$f^r \geq f^n$，执行内部收缩

$$y^{ic} \ = \ y^c + \delta^{ic} (y^c - y^n)$$

并计算$f^{ic} = f(y^{ic})$。若$f^{ic} < f^n$，则将 y^n 替换为内收缩点 y^{ic} 并终止迭代：$Y_{k+1} = \{y^0、\ y^1、\ \ldots、\ y^{n-1}、\ y^{ic}\}$。否则，执行收缩。

5. 收缩：在点 $y^0 + \gamma^s (y^i - y^0)$、$i = 1、\ \ldots、\ n$ 处评估 f，并用这些点替换 $y^1、\ \ldots、\ y^n$，终止迭代：$Y_{k+1} = \{y^0 + \gamma^s (y^i - y^0),\ i = 0,\ \ldots,\ n\}$。

停止准则可以包括当单纯形的直径小于选定的容差 $\Delta_{tol} > 0$ 时终止运行（例如，$\Delta_{tol} = 10^{-5}$）。

这种算法描述即我们可称之为原始Nelder-Mead算法[177]的“现代解读”，该算法在不等式严格性及平局处理上存在若干模糊之处。算法8.1与原始的Nelder-Mead方法[177]之间唯一显著的区别在于，原版中若y^e满足条件$f^e < f^0$ (则接受扩张点，否则接受反射点y^r)。如今的标准做法[149, 169]是，如果y^r和y^e均优于y^0，则接受二者中的较优者，正如算法8.1所做的那样。

Nelder-Mead算法在每次迭代中执行以下数量的函数评估：

1 如果迭代是反射,2 如果迭代是扩张或收缩,$n+2$
如果迭代是收缩。

非收缩迭代中的字典序下降

现在我们关注算法8.1中当函数值相等时，如何打破平局。当出现平局时，初始点的原始排序方式与接下来的内容无关。在收缩步骤中计算出的n个新点之间如何打破这些平局也无关紧要。

然而，如果我们想明确定义在迭代k和$k+1$之间不同的顶点的最小索引k^*，我们需要平局决胜规则，

$$k^* = \min\left\{i \in \{0,1,\ldots,n\} : y_k^i \neq y_{k+1}^i\right\}.$$

显然，这样的打破平局规则仅涉及接下来两段中报告的情况。

当一个新点通过反射、扩展或收缩步骤被引入单纯形时，单纯形中可能已存在具有相同目标函数值的点。我们需要定义打破平局的规则，以避免对变化索引 k^* 进行不必要的修改。我们在此采用文献[149]中提出的自然规则。如果一个新接受的点（y_k^r、y_k^e、y_k^{oc} 或 y_k^{ic}）产生的目标函数值等于点 y_k^0、…、y_k^{n-1} 中的一个（或多个）的值，则将其插入 Y^{k+1} 时赋予比该点（或这些点）更大的索引。这样，当连续迭代中生成具有相同函数值的点时，变化索引 k^* 保持不变。

另一种需要进行平局打破以避免在变化索引k^*上偶然修改的情况出现在收缩步骤中，当值$f(y_k^0+\gamma^s(y_k^i-y_k^0))$、$i=1$、…、$n$中的最小值等于$f(y^0$时。$_k)$在这种情况下，我们将 y_{k+1}^0 设置为 y_k^0。

因此，k^* 取以下值：

$1 \le k^* \le n-1$	if the iteration ends at a reflection step,
$k^* = 0$	if the iteration ends at an expansion step,
$0 \le k^* \le n$	if the iteration ends at a contraction step,
$k^* = 0$ or 1	if the iteration ends at a shrink step.

此外，在上述两种打破平局规则下，变化指数k^*的定义意味着在非收缩迭代中

$$\begin{aligned} f_{k+1}^j &= f_k^j \quad \text{and} \quad y_{k+1}^j = y_k^j \quad \text{if } j < k^*, \\ f_{k+1}^j &< f_k^j \quad \text{and} \quad y_{k+1}^j \neq y_k^j \quad \text{if } j = k^*, \\ f_{k+1}^j &= f_k^{j-1} \quad \text{and} \quad y_{k+1}^j = y_k^{j-1} \quad \text{if } j > k^*. \end{aligned}$$

我们观察到向量 $(f_k^0, \ldots, f_k^n)$ 在非收缩迭代中按字典序递减。由这些陈述可知，在非收缩迭代中，

$$\sum_{j=0}^{n} f_{k+1}^j < \sum_{j=0}^{n} f_k^j.$$

Nelder–Mead 算法的这一性质已被多位作者探讨。Kelley [140] 在 Nelder–Mead 方法的背景下利用它来检测和补救停滞现象。Tseng [220] 提出了一类单纯形型方法，其中包括一种修正的 Nelder–Mead 方法，在该方法中这一不等式起着重要作用（见第 8.3 节）。

请注意，最坏顶点函数值在非收缩迭代后未必会下降。例如，假设 $n = 4$ 且顶点函数值为 $(f_k^0, f_k^1, f_k^2, f_k^3, f_k^4) = (1, 2, 2, 3, 3)$ 在非收缩迭代 k。还假设新顶点的函数值为 2。那么在第 $k+1$ 次迭代时顶点函数值为 $(f_{k+1}^0, f_{k+1}^1, f_{k+1}^2, f_{k+1}^3, f_{k+1}^4) = (1, 2, 2, 2, 3)$。从这个例子可以清楚地看出，最坏顶点函数并未改善。然而，不难看出，除非已经达到最优值，否则最坏函数值必然在至多 $n+1$ 次连续非收缩迭代后下降。

Nelder–Mead单纯形

Nelder-Mead算法的设计初衷是使单纯形能够自适应“局部地形”[177]。事实上，我们可以看到Nelder-Mead移动允许逼近任何单纯形形状。Nelder-Mead算法在有效时的良好实际性能，直接归因于其能够良好拟合函数曲率的这一能力。

然而，单纯形可能会变得任意扁平或针状，这就是为什么Nelder-Mead算法无法建立到稳定点的全局收敛的原因（正如第8.2节中McKinnon给出的例子所示）。当今实践者常用的一种程序是，每当单纯形顶点的几何形状或良好平衡性恶化时，就重启Nelder-Mead算法。

监控 $Y = \{y^0、y^1、\ldots、y^n\}$ 的几何结构的一种方法是检查它是否为 Λ- poised（对于某个预先固定的常数 $\Lambda > 0$），即检查是否

$$\|\hat{L}(Y)^{-1}\| \leq \Lambda, \tag{8.2}$$

其中

$$\hat{L}(Y) = \frac{1}{\Delta(Y)} L(Y) = \frac{1}{\Delta(Y)} \left[y^1 - y^0 \cdots y^n - y^0 \right] \tag{8.3}$$

以及$\Delta(Y)=$中的最大值$_{1\le i\le n}\|y^i-y^0\|$。不难看出，这样的单纯形测度与线性$\Lambda$-稳定性的定义是一致的（见第2.5节、3.3节和4.3节）。

现在从第2.5节回顾单纯形直径的定义：$\operatorname{diam}(Y)=\max_{0\le i<j\le n}\|y^i-y^j\|$。由于 $\Delta(Y)\le\operatorname{diam}(Y)\le 2\Delta(Y)$ (，另见第2.5节)，Y的缩放度量是由$\Delta(Y)$还是由diam(Y)给出，在实践和收敛性分析中都是无关紧要的。在Nelder–Mead等单纯形型方法中，我们选择使用diam(Y)，因为它不像$\Delta(Y)$那样依赖于中心点。我们将使用归一化体积（见第2.5节），而不是Λ- poisedness。

$$\operatorname{von}(Y) \;=\; \operatorname{vol}\left(\frac{1}{\operatorname{diam}(Y)}Y\right) \;=\; \frac{|\det(L(Y))|}{n!\operatorname{diam}(Y)^n}.$$

选择 diam(Y) 和 von(Y) 在数学上会便于通过反射或收缩来操作单纯形。Tseng [220] 忽略了分母中的因子 $n!$，我们在这里也可以这样做。

我们以关于Nelder-Mead单纯形的体积和归一化体积的一些基本事实来结束本节[149]。回想第2.5节，顶点为 $Y_k=\{y_k^0、\ y_k^1、\ \ldots、\ y_k^n\}$ 的单纯形的体积由（始终为正的）量定义：

$$\operatorname{vol}(Y_k) \;=\; \frac{|\det(L_k)|}{n!},$$

其中

$$L_k \;=\; \left[y_k^0-y_k^n\cdots y_k^{n-1}-y_k^n\right].$$

定理 8.1。

- *If iteration k performs a nonshrink step (reflection, expansion, or contraction), then*

$$\operatorname{vol}(Y_{k+1}) \;=\; |\delta|\operatorname{vol}(Y_k).$$

- *If iteration k performs a shrink step, then*

$$\operatorname{vol}(Y_{k+1}) \;=\; (\gamma^s)^n\operatorname{vol}(Y_k).$$

Proof. 让我们仅证明第一个陈述。第二个陈述可以平凡地证明。不妨假设 $y_k^n=0$。在这种情况下，在非收缩步骤中计算出的顶点可以写成以下形式

$$L_k\,t_k(\delta),\quad \text{where}\quad t_k(\delta) \;=\; \left[\frac{1+\delta}{n},\ldots,\frac{1+\delta}{n}\right]^\top.$$

由于新的单纯形 Y_{k+1} 的体积与顶点的顺序无关，我们假设新顶点 $L_kt_k(\delta)$ 在 Y_{k+1} 中是最后一个。因此，回想 $y_k^n=0$,

$$|\det(L_{k+1})| \;=\; \left|\det\left(L_k-L_kt_k(\delta)e^\top\right)\right| \;=\; |\det(L_k)|\left|\det\left(I-t_k(\delta)e^\top\right)\right|,$$

表 8.1. *Number of times where the diameter of a simplex increased and the normalized volume decreased by isometric reflection. Experiments made on* 10^5 *simplices in* $\mathbb{R}^3$ *with* $y^0 = 0$ *and remaining vertex components randomly generated in* $[-1, 1]$*, using MATLAB®* [1] *software. The notation used is such that* $Y = \{y^0, y^1, y^2, y^3\}$ *and* $Y^r = \{y^0, y^1, y^2, y^r\}$.

Difference (power k)	0	2	4	6	8
$\text{diam}(Y^r) > \text{diam}(Y) + 10^{-k}$	0%	24%	26%	26%	26%
$\text{von}(Y^r) < \text{von}(Y) - 10^{-k}$	0%	1%	23%	26%	26%

其中 e 是一个维度为 n 的全1向量。$I - t_k(\delta)e^\top$ 的特征值为 1（重数为 $n-1$）和 $-\delta$。因此，$|\det(I - t_k(\delta)e^\top)| = |\delta|$，证明完成。 □

该结果的一个简单推论是，Nelder-Mead算法的所有迭代都会生成单纯形，即对于所有k (，$\text{vol}(Y_k) > 0$，前提是Y_0的顶点构成一个单纯形)。定理8.1还允许我们从代数上说明，等距反射($\delta = 1$)保持单纯形的体积，收缩和缩小会减小体积，而扩展则会增大体积。

同样重要的是要理解这些操作如何影响单形的归一化体积。当发生收缩步骤时，有

$$\text{von}(Y_{k+1}) \;=\; \text{von}(Y_k). \tag{8.4}$$

对于等距反射（当$n = 2$或当n任意但单纯形为等边时，$\delta = 1$）也是如此。我们将这些简单的事实留作练习。尽管违反直觉，但当$n > 2$时，等距反射通常不保持归一化体积，特别地，它们可能导致该测度的减小。[13] 由上文可知，在等距反射中体积保持不变。然而，直径可能增大，因此归一化体积可能减小。例如，读者可以通过取顶点为$y^0 = (0, 0, 0)$、$y^1 = (1, 1, 0)$、$y^2 = (0, 1, 0)$和$y^3 = (0, 0, 1)$的单纯形来确信这一点。直径从1.7321增大到1.7951，归一化体积从0.0321减小到0.0288。我们使用MATLAB [1]软件进行了一个简单的实验，报告在表8.1中，以观察归一化体积变化的频率。

可以证明，由等距反射引起的归一化体积的减少不亚于

$$\text{von}(Y_{k+1}) \;\geq\; \frac{\text{von}(Y_k)}{2^n}. \tag{8.5}$$

在实践中，等距反射后归一化体积的减少在整个优化过程中并不显著，且很少影响Nelder-Mead方法的性能。

[13] It is unclear whether one could perform an isometric reflection using a centroid point of the form $y^c = \sum_{i=0}^{n-1} \alpha^i y^i$, with $\sum_{i=0}^{n-1} \alpha^i = 1$ and $\alpha^i > 0$, $i = 0, \ldots, n-1$, that would preserve the normalized volume for values of α^i, $i = 0, \ldots, n-1$, bounded away from zero.

8.2 Nelder-Mead单纯形法的性质

Nelder-Mead算法最一般的性质在下一个定理中陈述。

定理 8.2. *Consider the application of the Nelder–Mead method (Algorithm* 8.1*) to a function f which is bounded from below on $\mathbb{R}^n$.*

1. *The sequence $\{f_k^0\}$ is convergent.*

2. *If only a finite number of shrinks occur, then all the $n+1$ sequences $\{f_k^i\}$, $i = 0, \ldots, n$, converge and their limits satisfy $f_*^0 \le f_*^1 \le \cdots \le f_*^n$.*

   Moreover, if there is an integer $j \in \{0, \ldots, n-1\}$ for which $f_*^j < f_*^{j+1}$ (a property called broken convergence), then for sufficiently large k the change index is such that $k^* > j$.

3. *If only a finite number of nonshrinks occur, then all the simplex vertices converge to a single point.*

Proof. 第一和第二个断言的证明本质上基于这样一个事实：有下界的单调递减序列是收敛的。第三个断言的证明也很直接，留作练习。 □

注意，$\{f_k^0\}$ 收敛并不意味着它收敛到驻点处 f 的值。*broken convergence* 的一个推论是，如果变化指数无限次等于零，那么 $f_*^0 = f_*^1 = \cdots = f_*^n$ (假设 f 有下界且不采取收缩步长)。

如果函数是严格凸的，可以证明不会发生收缩步骤。

定理 8.3. *No shrink steps are performed when the Nelder–Mead method (Algorithm* 8.1*) is applied to a strictly convex function f.*

Proof. 仅当尝试并失败于外部或内部收缩时，才采取收缩步骤。让我们关注外部收缩，它仅在 $f_k^{n-1} \le f_k^r < f_k^n$ 时被尝试。现在，根据 f 的严格凸性以及 y_k^{oc} 是 y_k^c 和 y_k^r 对于某参数 $\lambda \in (0, 1)$ 的凸组合这一事实，

$$f(y_k^{oc}) = f(\lambda y_k^c + (1-\lambda) y_k^r) < \lambda f(y_k^c) + (1-\lambda) f(y_k^r) \le \max\left\{f_k^c, f_k^r\right\}.$$

但 $\max\left\{f_k^c, f_k^r\right\} = f_k^r$，因为 $f_k^{n-1} \le f_k^r$ 和 $f_k^c \le f_k^{n-1}$ (，后者再次是 f) 严格凸性的结果。因此，$f_k^{oc} < f_k^r$，并且应用外部收缩（且不执行收缩步骤）。

如果考虑的是内部收缩，那么可以应用类似的论证，基于 y_k^{ic} 是 y_k^n 和 y_k^c 的凸组合这一事实。注意，这一论证需要严格凸性。 □

Lagarias 等人 [149] 证明了当 $n =$ 为 1 时，Nelder-Mead 方法（算法 8.1）是全局收敛的。在练习中简要给出了 [145] 中提到的针对标准选择（8.1）的另一种更短的证明。

Nelder-Mead方法收敛到非平稳点

Woods [230] 构造了一个二元非凸可微函数，据称 Nelder-Mead 方法在该函数上会失败。失败的原因是该方法会连续向一个非极小值点进行收缩。

McKinnon [169] 推导出了一系列严格凸的例子，其中Nelder–Mead方法（算法8.1）收敛到一个非平稳点。根据定理8.3，收缩步骤立即被排除。在这些例子中，内部收缩步骤被反复应用，最佳顶点保持不变。McKinnon将这种行为称为 *repeated focused inside contraction* (RFIC)。在[169]中显示，在这些例子中没有采取其他类型的步骤。由Nelder–Mead方法生成的单纯形沿垂直于最速下降方向的方向塌陷。这些函数在$\mathbb{R}^2$中定义如下：

$$f(x_1,x_2) = \begin{cases} \theta\phi|x_1|^\tau + x_2 + x_2^2 & \text{if } x_1 \le 0, \\ \theta x_1^\tau + x_2 + x_2^2 & \text{if } x_1 > 0. \end{cases} \tag{8.6}$$

如果 $\tau > 1$，则该函数是严格凸的。如果 $\tau > 1$，它具有连续一阶导数；如果 $\tau > 2$，它具有连续二阶导数；如果 $\tau > 3$，它具有连续三阶导数。注意，$(0, -1)$ 是从原点出发的下降方向。Nelder–Mead 算法以下列顶点构成的单纯形开始

$$y_0^0 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \quad y_0^1 = \begin{bmatrix} \lambda_1^0 \\ \lambda_2^0 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \text{and} \quad y_0^2 = \begin{bmatrix} \lambda_1^1 \\ \lambda_2^1 \end{bmatrix}, \tag{8.7}$$

其中 $\lambda_1^1 = (1+\sqrt{33})/8 \simeq 0.84$，且 $\lambda_2^1 = (1-\sqrt{33})/8 \simeq -0.59$。对于满足特定条件的 τ、θ 和 ϕ 值，可以证明该方法收敛到原点，而原点不是驻点。满足这些条件的 τ、θ 和 ϕ 的一个示例是 $\tau = 2$、$\theta = 6$ 和 $\phi = 60$。对于这些 τ、θ 和 ϕ 值，函数 (8.6) 的等高线如图 8.3 所示。这种反例成立的另一组参数值是 $\tau = 3$、$\theta = 6$ 和 $\phi = 400$。RFIC 行为生成一系列单纯形，其顶点并非一致地 Λ-poised（对于任何固定的 $\Lambda > 0$）。

我们运行了Nelder–Mead方法的MATLAB [1]实现，以针对选择$\tau = 2$、$\theta = 6$和$\phi = 60$的情况最小化McKinnon函数(8.6)。首先，我们按照(8.7)选择了初始单纯形。正如预期，从图8.3中可以看出，该方法从未将最佳顶点从原点移开。随后，我们将初始单纯形改为

$$y_0^0 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \quad y_0^1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \text{and} \quad y_0^2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}, \tag{8.8}$$

可以观察到，Nelder-Mead方法能够远离原点，并收敛到极小值点($x_* = (0, -0.5)$, $f(x_*) = -0.25$)。

8.3 Nelder–Mead 方法的一种全局收敛变体

在Nelder-Mead方法（算法8.1）中，为了使其全局收敛到驻点，必须解决若干问题。

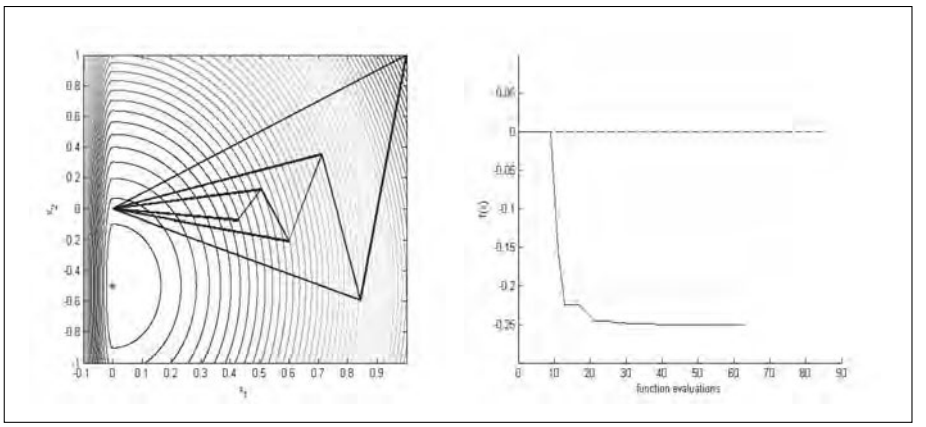


图8.3。*The left plot depicts the contours of the McKinnon function* (8.6) *for* $\tau = 2$, $\theta = 6$, *and* $\phi = 60$ *and illustrates the RFIC when starting from the initial simplex* (8.7). *The right plot describes the application of the Nelder–Mead method to this function. The dashed line corresponds to the initial simplex* (8.7) *and the solid line to* (8.8).

首先，必须对所有操作监测单纯形的几何质量，但收缩除外，因为已知收缩保持归一化体积（见(8.4)）。因此，当发生收缩时，如果Y_k的归一化体积满足von(Y_k) $\geq \xi$，其中常数$\xi > 0$与k无关，则Y_{k+1}的归一化体积亦然。然而，对于反射（即使是等距反射）、扩展和收缩，无法保证这一点。因此，在这些步骤中必须施加类似von(Y_{k+1}) $\geq \xi$的阈值条件。

然后，由于无法确定通过几何阈值的扩张或收缩单纯形，可能会跳过扩张或收缩。然而，必须对反射采取特殊规定，因为由于其正跨越效应，反射对于确保全局收敛至关重要。必须保证某种形式的反射始终可行，即不会恶化单纯形的几何形状（即不会导致其归一化体积减小）。遗憾的是，等距反射不足以实现此目的，因为它们可能会减小归一化体积。于是有几种策略可供选择。为简化问题，我们将假设总是首先尝试等距反射。如果等距反射点满足 diam $\left(\{y^0、y^1、\ldots、y^{n-1}\}\cup\{y^r\}\right) \leq \gamma^e\Delta$ 和 von $\left(\{y^0、y^1、\ldots、y^{n-1}\}\cup\{y^r\}\right) \geq \xi$，则不采取特殊规定，方法继续通过在 y^r 处评估函数来进行。否则，我们尝试一个保护步骤，通过将顶点 y^i、$i = 1、\ldots、n$ 围绕 y^0 旋转180°。这种旋转与MDS方法所应用的旋转相同（见第7章末尾）。与MDS一样，我们也可以考虑通过扩大这个旋转后的单纯形来进行扩张步骤，但为简洁起见，我们将跳过它。

另一方面，从第7章我们知道，避免几何退化对于那些仅基于简单下降来接受新迭代点的直接搜索方法来说是不够的。在第7章中，我们描述了两种加强目标函数下降的方法：(i)要求迭代点位于定义为整数格的网格序列上，

其中网格点的最小间隔与步长 α_k 成正比；(ii) 要求迭代点满足类型为 $f(x_{k+1}) < f(x_k) - \rho(\alpha_k)$ 的充分下降条件。（回想 $\rho : (0, +\infty) \to \mathbb{R}_+$ 被称为 *forcing function*，并且要求它是连续且正的，并满足

$$\lim_{t \longrightarrow 0^+} \frac{\rho(t)}{t} = 0 \qquad \text{and} \rho \qquad (t_1) \leq \rho(t_2) \quad \text{if} \quad t_1 < t_2.$$

一个呈现的强迫函数的简单示例是 $\rho(t) = t^2$。）

强制迭代点位于整数格点上，在Nelder-Mead框架中对于$n > 1$而言，鉴于作用于单纯形上的步骤多样性，这似乎是一项难以处理的任务。因此，本书针对一种改进的Nelder-Mead方法所采取的策略是基于施加充分下降条件。然而，在Nelder-Mead框架中，我们并没有像第7章中的方向直接搜索方法那样的情形，其中当前迭代点是迄今为止找到的最佳点。在Nelder-Mead算法中，需比较多个目标函数值，并且充分下降必须应用于不同情形。此外，第7章充分下降条件中使用的步长参数α_k，现在被当前单纯形的直径$\Delta_k = \text{diam}(Y_k)$所替代——但正如我们之前提到的，我们本可以选择$\Delta_k = \Delta(Y_k)$。

算法8.2中描述的改进Nelder-Mead方法本质上是由Tseng [220]提出并分析的一个实例。为简化起见，两个收缩步骤（内部和外部）已被重新表述为单一的收缩步骤。与原始的Nelder-Mead方法相比，在收缩步骤上也存在相关差异。我们已经看到，算法8.1中的收缩步骤保证不会增加最小单纯形值（$f_{k+1}^0 \leq f_k^0$），这直接源于Y_k的最佳顶点保留在Y_{k+1}中这一事实。现在这还不够，因为我们需要足够的减少；换句话说，我们需要类似于$f_{k+1}^0 \leq f_k^0 - \rho(\Delta_k)$的东西，其中$\Delta_k = \text{diam}(Y_k)$。当这种足够减少的条件不满足时，迭代会重复，但使用的是收缩后的单纯形。因此，我们必须考虑到在一个迭代中通过反复应用收缩步骤而可能出现无限循环的情况。当这种情况发生时，我们将证明算法返回一个平稳极限点。

算法8.2（改进的Nelder-Mead方法）。

初始化：选择 $\xi > 0$。选择一个初始单纯形，其顶点为 $Y_0 = \{y_0^0、y_0^1、\ldots、y_0^n\}$，使得 $\text{von}(Y_0) \geq \xi$。在 Y_0 中的点处计算 f。选择常数：

$$0 < \gamma^s < 1 < \gamma^e, \qquad -1 < \delta^{ic} < 0 < \delta^{oc} < \delta^r < \delta^e。$$

对于 $k = 0、1、2、\ldots$

0. 设置 $Y = Y_k$。
1. 排序：将 $Y = \{y^0、y^1、\ldots、y^n\}$ 的 $n+1$ 个顶点排序，使得

$$f^0 = f(y^0) \leq f^1 = f(y^1) \leq \cdots \leq f^n = f(y^n).$$

设置 $\Delta = \text{diam}(Y)$。

2. 反射：根据算法8.1，使用$\delta^r = 1$)计算等距反射点y^r（。如果

$$\begin{aligned} \operatorname{diam}\left(\{y^0, y^1, \ldots, y^{n-1}\} \cup \{y^r\}\right) &\leq \gamma^e \Delta, \\ \operatorname{von}\left(\{y^0, y^1, \ldots, y^{n-1}\} \cup \{y^r\}\right) &\geq \xi, \end{aligned} \tag{8.9}$$

然后计算$f^r = f(y^r)$。如果$f^r \leq f^{n-1} - \rho(\Delta)$，则尝试扩展（然后接受反射点或扩展点）。否则，尝试收缩。

保护旋转：如果等距反射未能满足（8.9），则围绕最佳顶点 y^0 旋转单纯形：

$$y^{rot,i} = y^0 - (y^i - y^0), \quad i = 1, \ldots, n.$$

评估$f(y^{rot,i})$、$i = 1$、…、n，并设置$f^{rot} = \min\{f(y^{rot,i})$：$i = 1$、…、$n\}$。如果$f^{rot} \leq f^0 - \rho(\Delta)$，则终止迭代并取旋转后的单纯形：$Y_{k+1} = \{y^0$、$y^{rot,1}$、…、$y^{rot,n}\}$。否则，尝试收缩。

3. 扩展：计算一个扩展点 y^e（，例如，如算法8.1) 所示。如果

$$\begin{aligned} \operatorname{diam}\left(\{y^0, y^1, \ldots, y^{n-1}\} \cup \{y^e\}\right) &\leq \gamma^e \Delta, \\ \operatorname{von}\left(\{y^0, y^1, \ldots, y^{n-1}\} \cup \{y^e\}\right) &\geq \xi, \end{aligned}$$

然后计算$f^e = f(y^e)$，如果$f^e \leq f^r$，则用扩展点 y^e 替换 y^n，并终止迭代：$Y_{k+1} = \{y^0$、y^1、…、y^{n-1}、$y^e\}$。否则，用反射点 y^r 替换 y^n，并终止迭代：$Y_{k+1} = \{y^0$、y^1、…、y_k^{n-1}、$y^r\}$。

4. 收缩：在算法8.1)中计算一个收缩点y^{cc}（，如外部或内部收缩。如果

$$\begin{aligned} \operatorname{diam}\left(\{y^0, y^1, \ldots, y^{n-1}\} \cup \{y^{cc}\}\right) &\leq \Delta, \\ \operatorname{von}\left(\{y^0, y^1, \ldots, y^{n-1}\} \cup \{y^{cc}\}\right) &\geq \xi, \end{aligned}$$

然后计算$f^{cc} = f(y^{cc})$，如果$f^{cc} \leq f^n - \rho(\Delta)$，则用收缩点 y^{cc} 替换 y^n 并终止迭代：$Y_{k+1} = \{y^0$、y^1、…、y^{n-1}、$y^{cc}\}$。否则，执行收缩。

5. 收缩：在n个点$y^0 + \gamma^s(y^i - y^0)$、$i = 1$、…、$n$处计算$f$，并令$f^s$为这些值中的最小值。如果$f^s \leq f^0 - \rho(\Delta)$，则接受收缩后的单纯形并终止迭代：$Y_{k+1} = \{y^0 + \gamma^s(y^i - y^0)$，$i = 0$，…，$n\}$。否则，令$Y = \{y^0 + \gamma^s(y^i - y^0)$，$i = 0$，…，$n\}$，返回步骤0。

在实践中，我们可以选择接近于1的γ^e进行反射，而扩张时约取2，这与原始的Nelder-Mead方法相似。还需注意，在安全旋转和收缩之后，单纯形的标准化体积保持不变。在安全旋转中，单纯形的直径不变，而在收缩时，其直径会按γ^s的比例减小。再次强调，停止准则可以是当单纯形的直径Δ_k小于选定的容差$\Delta_{tol} > 0$（例如，$\Delta_{tol} = 10^{-5}$）时终止运行。

我们定义一个索引n_k，取决于迭代终止时所执行的操作：

$n_k = n$ 对于（等距的）反射、扩展和收缩，$n_k = 0$ 对于收缩和安全旋转。

然后，由修正的Nelder-Mead方法（算法8.2）生成的单纯形序列满足

$$f_{k+1}^i \le f_k^i, \quad i = 0, \ldots, n_k, \tag{8.10}$$

和

$$\sum_{i=0}^{n_k} f_{k+1}^i \le \sum_{i=0}^{n_k} f_k^i - \rho(\Delta_k). \tag{8.11}$$

定理8.4在下文对修正的Nelder-Mead方法的分析中起着核心作用，其本质上基于条件(8.10)-(8.11)，因此对于其他（可能更为精细的）基于单纯形的直接搜索方法，只要它们对任意$n_k \in \{0, \ldots, n\}$满足这些条件，该定理同样成立。

在非线性优化算法的收敛性分析中，通常做法是对f在如下形式的水准集上施加光滑性和有界性要求：

$$L(x_0) = \{x \in \mathbb{R}^n : f(x) \le f(x_0)\}.$$

在修改后的Nelder-Mead方法中，x_0的一个自然候选是y_0^n。然而，尽管（等距）反射、旋转、扩张和收缩步骤生成的单纯形顶点对应的目标函数值低于f_0^n，但收缩步骤未必如此。可以定义一个值f^{max}使得所有单纯形顶点位于$\{x \in \mathbb{R}^n$中：$f(x) \le f^{max}\}$，但这样的定义会使表述不必要地复杂化。我们将在$\mathbb{R}^n$中对f施加假设；特别地，在接下来的内容中，我们假设f在$\mathbb{R}^n$中是有下界的且一致连续。

下一个定理说明，在关于f的这些假设下，由 Nelder–Mead 算法生成的单纯形的直径收敛到零。其证明归功于 Tseng [220]——而且它出奇地复杂。困难来自这样一个事实：对于等距反射、扩张或收缩等步骤，充分下降条件是在不同于具有最佳目标函数值的单纯形顶点处施加的。请注意，对于一个生成点序列 $\{x_k\}$ 且满足 $f(x_{k+1}) < f(x_k) - \rho(\Delta_k)$ 的算法，这样的结果会以相对直接的方式得到证明。在单纯形类型方法的背景下，这将对应于，例如，具有 $x_k = y_k^0$ 和 $f(y_{k+1}^0) < f(y_k^0) - \rho(\Delta_k)$ (一个我们仅在修正 Nelder–Mead 方法中对收缩和安全保障旋转施加的条件)。

定理 8.4。 *If f is bounded from below and uniformly continuous in $\mathbb{R}^n$, then the modified Nelder–Mead method (Algorithm 8.2) generates a sequence $\{Y_k\}$ of simplices whose diameters converge to zero:*

$$\lim_{k \to +\infty} \operatorname{diam}(Y_k) = 0.$$

Proof. 证明是通过反证法完成的，假设Δ_k不收敛于零。对于每个$i \in \{0, 1, \ldots, n\}$，我们定义

$$K_i = \left\{k \in \{0, 1, \ldots\} : f_{k+1}^i \le f_k^i - \rho(\Delta_k)/(n_k + 1)\right\}.$$

$n_k \le n$ 和 (8.11) 在每次迭代时都成立，這一事實在所有 k 下保證了至少存在一個 $i \in \{0, 1, \ldots, n\}$ 使得 $k \in K_i$。因此，$\cup_{i=0}^{n} K_i = \{0, 1, \ldots\}$，且以下索引是明確定義的：

$$i_{min} \;=\; \min\left\{ i \in \{0,1,\ldots,n\} : \; |K_i| = +\infty, \; \lim_{k \in K_i} \Delta_k \neq 0 \right\}.$$

现在，由于在 $K_{i_{min}}$ 中 $\Delta_k \not\to 0$，存在一个子序列 $K \subset K_{i_{min}}$ 和一个正常数 κ，使得对于所有 $k \in K$ 都有 $\rho(\Delta_k) \ge \kappa$。由此，

$$f_{k+1}^{0} \;\le\; f_{k+1}^{i_{min}} \;\le\; f_{k}^{i_{min}} - \kappa/(n+1) \quad \forall k \in K. \tag{8.12}$$

对于每个 k，现在令 ℓ_k 为满足 $f_{\ell}^{i_{min}} > f_{\ell-1}^{i_{min}}$ (的最大索引 $\ell \in \{1、\ldots、k\}$，若不存在这样的 ℓ，则 $\ell_k =$ 为 0)。注意 ℓ_k 必须趋于无穷；否则，$\{f_k^{i_{min}}\}$ 将有一个非递增尾部；也就是说，会存在一个索引 k_{tail} 使得 $\{f_k^{i_{min}}\}_{k \ge k_{tail}}$ 非递增。那么 $\{f_k^{i_{min}}\}_{k \ge k_{tail}, k \in K}$ 也将非递增，从而收敛（因为 f 有下界）。在（8.12）中取极限将导致矛盾。

关系（8.12）和定义ℓ_k平凡地意味着

$$f_{k+1}^{0} \;\le\; f_{\ell_k}^{i_{min}} - \kappa/(n+1) \quad \forall k \in K. \tag{8.13}$$

ℓ_k 的定义还意味着，对于充分大的k，使得 $\ell_k > 0$)，有$f_{\ell_k}^{i_{min}} > f_{\ell_k - 1}^{i_{min}}$ (。因此 $\ell_k - 1 \notin K_{i_{min}}$。另一方面，我们之前已经看到，$\ell_k - 1$ 必定属于某个 j 的 K_j，这必须满足 $j < i_{min}$。由于当 $k \to +\infty$ 时 $\ell_k \to +\infty$，必要时通过取子序列，我们可以假设这个指标 j 对于所有指标 $\ell_k - 1$ 都是相同的。出于同样的原因，我们也有 $|K_j| = +\infty$。由 i_{min} 的选择以及 $i_{min} \neq j$ 这一事实，我们必然有对于 $k \in K$，$\Delta_{\ell_k - 1} \to 0$。由于对于所有 k，$\Delta_{k+1} \le \gamma_k^e \Delta_k$，结果得到 $\Delta_k \to 0$ 对于 $k \in K$。

现在可以通过得出一个与(8.13)矛盾的陈述来完成证明。首先，我们写出

$$f_{k+1}^{0} - f_{\ell_k}^{i_{min}} \;=\; \left(f_{k+1}^{0} - f_{\ell_k}^{0}\right) + \left(f_{\ell_k}^{0} - f_{\ell_k}^{i_{min}}\right).$$

注意，第一项收敛到零，因为 f_{k+1}^{0} 和 $f_{\ell_k}^{0}$ 都收敛到相同的值（这里我们利用了 $\{f_k^0\}$ 递减且 f 有下界，同时也利用了 ℓ_k 趋于无穷的事实）。第二项也收敛到零，因为 f 一致连续，并且对于 $k \in K$，$\mathrm{diam}(Y_k) \to 0$。因此，$f_{k+1}^{0} - f_{\ell_k}^{i_{min}}$ 在 K 中收敛到零，这与 (8.13) 矛盾。

□

在下一个定理中，我们证明如果单纯形顶点的序列是有界的，那么它至少有一个极限点是驻点。该结果的证明依赖于以下事实：向量集合 $y^n - y^i$、$i = 0$、…、$n-1$ 以及 $y^r - y^i$、$i = 0$、…、$n-1$ 合在一起构成一个正生成集（实际上是一个极大正基；见图8.4）。容易看出，这个集合（线性）生成 $\mathbb{R}^n$。也可以平凡地验证

$$\sum_{i=0}^{n-1} (y^n - y^i) + \sum_{i=0}^{n-1} (y^r - y^i) \;=\; 0, \tag{8.14}$$

因此，根据定理2.3(iii)，我们得出这个集合正向张成$\mathbb{R}^n$。

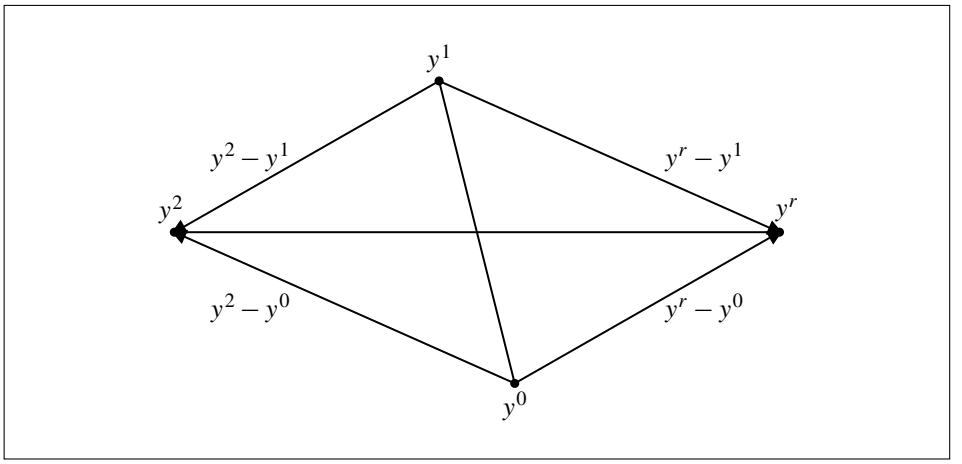


图8.4。*The vectors* $y^r - y^0$、$y^r - y^1$ *(right) and* $y^2 - y^0$、$y^2 - y^1$ *(left). (This picture is misleading in the sense that isometric reflections are guaranteed only to preserve the diameter and the normalized volume of simplices when* $n = 2$ *or the simplices are equilateral.)*

当我们说单纯形顶点序列 $\{Y_k\}$ 有一个极限点 x_* 时，我们的意思是存在一个形如 $\{x_k\}$ 的顶点序列，其中 $x_k \in Y_k$，它有一个子序列收敛到 x_*。

定理 8.5. *Let* f *be bounded from below, uniformly continuous, and continuously differentiable in* $\mathbb{R}^n$*. Assume that the sequence of simplex vertices* $\{Y_k\}$ *generated by the modified Nelder–Mead method (Algorithm* 8.2*) lies in a compact set. Then* $\{Y_k\}$ *has at least one stationary limit point* x_**.*

Proof. 根据定理的假设以及$\Delta_k \to 0$ 的事实（见定理8.4），存在一个由收缩或缩减步骤组成的迭代子序列K_1，对于该子序列，Y_k的所有顶点都收敛到一点x_*。

从单纯形中顶点的排序，我们可知

$$f(y_k^n) \;\geq\; f(y_k^i), \quad i = 0, \ldots, n-1,$$

进而意味着

$$\nabla f(a_k^i)^\top (y_k^n - y_k^i) \;\geq\; 0, \quad i = 0, \ldots, n-1, \tag{8.15}$$

对于连接 y_k^n 和 y_k^i 的线段中的某个 a_k^i。由于序列 $\{(y_k^n - y_k^i)/\Delta_k\}$ 有界，必要时通过取嵌套子序列，我们可以确保存在一个子序列 $K_2 \subseteq K_1$，使得 $(y_k^n - y_k^i)/\Delta_k \to z^i$，$i = 0, \ldots, n-1$。因此，将 (8.15) 除以 Δ_k 并在 K_2 中取极限得到

$$\nabla f(x_*)^\top z^i \;\geq\; 0, \quad i = 0, \ldots, n-1. \tag{8.16}$$

在t 另一方面，仅在w时尝试收缩或缩小步骤 当 {v*} 时

$$f(y_k^r) > f(y_k^{n-1}) - \rho(\Delta_k) \tag{8.17}$$

或

$$f_k^{rot} > f(y_k^0) - \rho(\Delta_k). \tag{8.18}$$

因此，存在K_3的子序列K_2，使得(8.17)或(8.18)成立。

在（8.17）情况下，对于 $k \in K_3$，我们得到

$$f(y_k^r) > f(y_k^i) - \rho(\Delta_k), \quad i = 0, \ldots, n-1. \tag{8.19}$$

因此，对于 $k \in K_3$，

$$\nabla f(b_k^i)^\top (y_k^r - y_k^i) > -\rho(\Delta_k), \quad i = 0, \ldots, n-1,$$

对于连接 y_k^r 和 y_k^i 的线段上的某个 b_k^i。再次，由于序列 $\{(y_k^r - y_k^i)/\Delta_k\}$ 是有界的，必要时通过取嵌套子序列，我们可以确保存在一个子序列 $K_4 \subseteq K_3$，使得 $(y_k^r - y_k^i)/\Delta_k \to w^i$，$i = 0$，…，$n-1$。此外，从强制函数 ρ 的性质可知，$\rho(\Delta_k)/\Delta_k$ 在 K_4 中趋于零。如果我们现在将 (8.19) 除以 Δ_k 并在 K_4 中取极限，我们得到

$$\nabla f(x_*)^\top w^i \geq 0, \quad i = 0, \ldots, n-1. \tag{8.20}$$

我们现在指出，$[z^0 \cdots z^{n-1} w^0 \cdots w^{n-1}]$ 是一个正生成集。一个可能的论证如下。首先，我们指出 $[z^0 \cdots z^{n-1}]$ 和 $[w^0 \cdots w^{n-1}]$ 都（线性）生成 $\mathbb{R}^n$，因为它们是均匀线性无关集的极限。然后我们将 (8.14) 除以 Δ_k 并取极限，得到

$$z^0 + \cdots + z^{n-1} + w^0 + \cdots + w^{n-1} = 0.$$

因此，根据定理2.3(iii)，$[z^0 \cdots z^{n-1} w^0 \cdots w^{n-1}]$是一个正生成集。定理2.3(iv)中给出的关于生成集的性质以及不等式(8.16)和(8.20)进而表明$\nabla f(x_*) = 0$。

在（8.18）的情况下，对于所有 $k \in K_3$，我们有，

$$f(y_k^{rot,i}) > f(y_k^0) - \rho(\Delta_k), \quad i = 1, \ldots, n.$$

从单纯形中顶点的排序，我们同样得知，对于所有 {v*}，

$$f(y_k^i) > f(y_k^0), \quad i = 1, \ldots, n.$$

因此，对于 $k \in K_3$，

$$\nabla f(c_k^i)^\top (y_k^{rot,i} - y_k^0) > -\rho(\Delta_k), \quad i = 1, \ldots, n, \tag{8.21}$$

和

$$\nabla f(c_k^i)^\top (y_k^i - y_k^0) \geq 0, \quad i = 1, \ldots, n, \tag{8.22}$$

对于连接$y_k^{rot,i}$和y_k^0的线段中的某个c_k^i，以及连接y_k^i和y_k^0的线段中的某个d_k^i。由于序列$\{(y_k^{rot,i} - y_k^0)/\Delta_k\}$和$\{(y_k^i - y_k^0)/\Delta_k\}$

有界，必要时通过取嵌套子序列，我们可以确保存在子序列 $K_4 \subseteq K_3$，使得 ($y_k^{rot,i} - y_k^0)/\Delta_k \to -u^i$, $i = 1, \ldots, n$, 和 $(y_k^i - y_k^0)/\Delta_k \to u^i$, $i = 1, \ldots, n$。因此，将 (8.21) 和 (8.22) 除以 Δ_k 并在 K_3 中取极限，得到

$$\nabla f(x_*)^\top(-u^i) \geq 0 \quad \text{and} \quad \nabla f(x_*)^\top u^i \geq 0, \quad i = 1, \ldots, n. \tag{8.23}$$

现在注意，由于$[u^1 \cdots u^n]$是均匀线性无关集的极限，它（线性）张成$\mathbb{R}^n$。因此，根据定理2.4之后所述，我们知道$[u^1 \cdots u^n - u^1 \cdots - u^n]$是一个正生成集。定理2.3(iv)与不等式(8.23)共同意味着$\nabla f(x_*) = 0$。

还需要分析在迭代中发生无限多次循环（通过连续应用收缩步骤）时会发生什么。使用与上述相同的论证，可以证明收缩单纯形的顶点收敛到一个稳定点。

□

实际上可以证明，顶点序列的所有极限点都是稳定的。在[220]中，这一结果对更广泛的单纯形直接搜索方法类进行了证明。为此，需要额外施加一个条件来接受等距反射或扩张。[14]如同[220]中所述，如果满足以下两个条件，则执行等距反射或扩张：

$$f^r \leq f^{n-1} - \rho(\Delta) \quad \text{and} \quad f^r \leq f^{n-1} - \left(f^n - \frac{1}{n} \sum_{i=0}^{n-1} f^i \right) + \rho(\Delta). \tag{8.24}$$

因此，在等距反射或膨胀情形下，我们既有关于 $n_k = n$ 的（8.11），又有

$$\sum_{i=0}^{n} f_{k+1}^i \leq \sum_{i=0}^{n} f_k^i - \left(f_k^n - \frac{1}{n} \sum_{i=0}^{n-1} f_k^i \right) + \rho(\Delta_k). \tag{8.25}$$

定理 8.6。*Let f be bounded from below, uniformly continuous, and continuously differentiable in $\mathbb{R}^n$. Assume that the sequence of simplex vertices $\{Y_k\}$ generated by the modified Nelder–Mead method (Algorithm* 8.2*, further modified to accept only isometric reflections or expansions if* (8.24) *occurs) lies in a compact set. Assume that isometric reflections always satisfy* (8.9)*. Then all the limit points of $\{Y_k\}$ are stationary.*

Proof. 证明的第一部分包括展示在由(8.24)引入的修改下，定理8.5仍然成立。现在，由于(8.17)或...，可以尝试收缩或缩减步骤。

$$f_k^r > f_k^{n-1} - \left(f_k^n - \frac{1}{n} \sum_{i=0}^{n-1} f_k^i \right) + \rho(\Delta_k). \tag{8.26}$$

如果对于K_2的一个无限子序列，条件(8.17)成立，那么通过首先必要时转至K_2的子序列，定理8.5的证明依然有效。

[14]The need for additional conditions arises in other direct-search methods too (see, for instance, Section 7.5, where it is pointed out that it is possible to prove (7.10) for complete polling).

因此，我们只需考虑K_2或K_2的子序列满足(8.26)的情况。然而，这种情况的处理方式类似。首先，我们写出

$$f(y_k^r) > f(y_k^i) - \left(f_k^n - \frac{1}{n}\sum_{i=0}^{n-1} f_k^i \right) + \rho(\Delta_k), \quad i = 0, \ldots, n-1.$$

因此，对于$k \in K_2$,

$$\nabla f(b_k^i)^\top (y_k^r - y_k^i) > \frac{1}{n}\left(\sum_{i=0}^{n-1} \nabla f(a_k^i)^\top (y_k^i - y_k^n) \right) + \rho(\Delta_k), \quad i = 0, \ldots, n-1, \quad (8.27)$$

其中 a_k^i 位于连接 y_k^n 和 y_k^i 的线段上，而 b_k^i 位于连接 y_k^r 和 y_k^i 的线段上。我们已知对于 $i = 0$、…、$n-1$，$\{(y_k^n - y_k^i)/\Delta_k\}$ 在 K_2 中收敛到 z_i。再次，由于序列 $\{(y_k^r - y_k^i)/\Delta_k\}$ 有界，必要时通过取嵌套子序列，我们可以保确存在子序列 $K_3 \subseteq K_2$，使得 $(y_k^r - y_k^i)/\Delta_k \to w^i$，$i = 0$，…，$n-1$。因此，通过在（8.27）中对 $k \in K_3$ 取极限，我们得到

$$\nabla f(x_*)^\top w^i \geq \nabla f(x_*)^\top \left(\frac{1}{n}\sum_{i=0}^{n-1} (-z_i) \right), \quad i = 0, \ldots, n-1,$$

或者，等价地，{v*}

$$\nabla f(x_*)^\top \left(w_i + \frac{1}{n}\sum_{i=0}^{n-1} z_i \right) \geq 0, \quad i = 0, \ldots, n-1. \quad (8.28)$$

从(8.16)和(8.28)我们可以得出结论，$\nabla f(x_*) = 0$（此处使用的论证与之前提出的类似）。

现在假设存在一个非驻点的极限点 x_∞。那么，根据 f 的连续可微性，存在一个以 x_∞ 为中心、半径为 $\Delta_\infty > > 0$ 的球 $B(x_\infty;\ \Delta_\infty)$，其中没有驻点。

我们将注意力集中在一个（必然是无限的）子序列 $\{x_k\}_{k \in K_\infty}$ 上，其中 $x_k \in Y_k$，且该子序列位于这个球内。注意，我们可以保证对于足够大的 k，在 K_∞ 中不存在收缩或缩减迭代，因为否则我们将应用类似于定理8.5证明的思路，并得出结论：在 $B(x_\infty$ 中存在一个不动点；$\Delta_\infty)$。因此，我们可以不失一般性地假设 K_∞ 是由必然发生等距反射或扩张的迭代构成的。于是，我们可以假设对于所有 $k \in K_\infty$，不等式 (8.25) 成立。

我们指出，必定存在一个常数$\kappa > > 0$，使得对于充分大的$k \in K_\infty$,

$$\frac{f_k^n - \frac{1}{n}\sum_{i=0}^{n-1} f_k^i}{\Delta_k} \geq 2\kappa. \quad (8.29)$$

(否则，我们将应用与定理8.5相似的论证，并得出$\nabla f(x_\infty)^\top (-z_i) \geq 0$、$i = 0$、…、$n-1$，结合$\nabla f(x_\infty)^\top z_i \geq 0$、$i = 0$、…、$n-1$，将意味着$\nabla f(x_\infty) = 0$。)因此，通过应用不等式（8.29）和

{v*} 的性质　将函数 ρ 强制为 (8.25)，对于足够大的 k，我们可以确保 该

$$\sum_{i=0}^{n} f_{k+1}^{i} - \sum_{i=0}^{n} f_{k}^{i} \;\leq\; -\kappa\,\Delta_k.$$

现在我们将球 $B(x_\infty;\ \Delta_\infty)$ 分成三个互斥的集合：

$$\begin{aligned} R_1 &= \{x \in \mathbb{R}^n :\ 2\Delta_\infty/3 < \|x - x_\infty\| \leq \Delta_\infty\}, \\ R_2 &= \{x \in \mathbb{R}^n :\ \Delta_\infty/3 < \|x - x_\infty\| \leq 2\Delta_\infty/3\}, \\ R_3 &= \{x \in \mathbb{R}^n :\ \|x - x_\infty\| \leq \Delta_\infty/3\}. \end{aligned}$$

由于根据定理8.4，$\Delta_k \to$不等于0，我们知道收缩或缩小的次数必须是无限的。因此，顶点序列$\{x_k\}$进入并离开球$B(x_\infty$的次数是无限的。由于$\Delta_k \to$不等于0，这意味着顶点序列$\{x_k\}$必须在R_1和R_3之间通过R_2交叉，也是无限次。所以，必然存在K_∞的子序列$\{k_j\}$和$\{k_\ell\}$，使得

$$x_{k_j} \in R_1, \quad x_{k_j+1} \in R_2, \ldots, x_{k_\ell-1} \in R_2, \quad \text{and} \quad x_{k_\ell} \in R_3.$$

然后，由 $\|x_{k+1} - x_k\| \leq \Delta_{k+1} + \Delta_k \leq (1+\gamma^e)\Delta_k$ 这一事实以及 R_1 和 R_3 中点之间的距离至少为 $\Delta_\infty/3$，我们得到

$$\begin{aligned} \sum_{i=0}^{n} f_{k_\ell}^{i} - \sum_{i=0}^{n} f_{k_j}^{i} &= \left\{\sum_{i=0}^{n} f_{k_\ell}^{i} - \sum_{i=0}^{n} f_{k_\ell-1}^{i}\right\} + \cdots + \left\{\sum_{i=0}^{n} f_{k_j+1}^{i} - \sum_{i=0}^{n} f_{k_j}^{i}\right\} \\ &\leq -\kappa\left(\Delta_{k_\ell-1} + \cdots + \Delta_{k_j}\right) \\ &\leq -\tfrac{\kappa}{1+\gamma^e}\left(\|x_{k_\ell} - x_{k_\ell-1}\| + \cdots + \|x_{k_j+1} - x_{k_j}\|\right) \\ &\leq -\tfrac{\kappa}{1+\gamma^e}\|x_{k_\ell} - x_{k_j}\| \\ &\leq -\tfrac{\kappa\Delta_\infty}{3(1+\gamma^e)}. \end{aligned}$$

现在可以得出矛盾。由上述不等式，单调递减子序列 $\{\sum_{i=0}^{n} f_k^i\}_{k\in K_\infty}$ 不可能收敛，这与事实矛盾。实际上，由（8.10）–（8.11）可知，在 f 有界的条件下，$\{f_k^0\}_{k\in K_\infty}$ 必须收敛。由于 $\Delta_k \to 0$ 且 f 一致连续，则对于 $i = 1$、…、n 而言，子序列 $\{f_k^i\}_{k\in K_\infty}$ 也收敛，并且 $\{\sum_{i=0}^{n} f_k^i\}_{k\in K_\infty}$ 收敛。 □

当始终尝试进行保护旋转时，可以证明一个相似的结果（参见练习）。

对Nelder–Mead方法的其他修改

我们知道，Nelder-Mead方法可能会由于单纯形几何形状的恶化或缺乏足够的下降而停滞不前，无法收敛到驻点。一些作者采取的方法是在确保某种形式的足够下降的情况下，让Nelder-Mead相对自由地运行，并且仅在识别到无法满足这种条件时才采取行动。

例如，Price、Coope 和 Byatt [194] 的改进 Nelder–Mead 方法属于这一类。基本上，他们让 Nelder–Mead 运行（不进行收缩），只要最差顶点相对于 Y_k 的大小产生足够的下降，例如，$f_{k+1}^n < f_k^n - \rho(\text{diam}(Y_k))$，其中 ρ 是一个强制函数。这些内部 Nelder–Mead 迭代不计为常规迭代。经过有限数量的这些内部 Nelder–Mead 步骤后，要么找到一个新的顶点单纯形 Y_{k+1}，产生足够的下降 $f_{k+1}^0 < f_k^0 - \rho(\text{diam}(Y_k))$，在这种情况下，从 Y_{k+1} 开始新的迭代，要么算法尝试围绕顶点 y_{k+1}^0 形成一个 *quasi-minimal frame* (见下文)，对于该顶点，我们知道 $f^0_{k+1} \le f_k^0$。

识别这个偏离Nelder-Mead行动过程的准最小框架的过程。根据Coope和Price的术语，准最小框架是一种形式如下的轮询集：

$$P_k = \{x_k + \alpha_k d : d \in D_k\},$$

其中 D_k 是一个正基或正张成集，且 $f(x_k + \alpha_k d) + \rho(\alpha_k) \ge f(x_k)$，对所有 $d \in D_k$。在上述上下文中，我们有 $x_k = y_{k+1}^0$ 和 α_k 的量级为 $\text{diam}(Y_k)$。对于 D_k 的一种选择是由 $y_{k+1}^i - y_{k+1}^0$、$i = 1$、…、n 的正倍数及其负对应物构成的最大正基，如果余弦测度 $\text{cm}(D_k)$ 高于一个一致正阈值，或者否则采用合适的替代。在 Nelder–Mead 单纯形几何中，其他选择也是可能的。注意，尝试识别 *quasi-minimal frame* 的过程要么成功，要么生成一个新点 y_{k+1}^0，使得 $f_{k+1}^0 < f_k^0 - \rho(\text{diam}(Y_k))$。文献 [194] 基于 Coope 和 Price [65] 的先前工作表明，所得到的算法生成一个迭代序列，其所有极限点都是稳定的，前提是这些迭代点包含在一个适当的水平集中，其中 f 连续可微且具有 Lipschitz 连续梯度。然而，他们的分析要求通过算法强制 $\alpha_k \to 0$，这在 Nelder–Mead 环境中等价于强制 $\text{diam}(Y_k) \to 0$。

在Nelder-Mead方法的背景下，Kelley [140] 在充分下降型条件中使用了单纯形梯度来检测停滞，以及确定新单纯形的方向以重新开始过程。更精确地说，他建议在以下情况重启Nelder-Mead：

$$\sum_{j=0}^{n} f_{k+1}^j < \sum_{j=0}^{n} f_k^j$$

成立但

$$\sum_{j=0}^{n} f_{k+1}^j < \sum_{j=0}^{n} f_k^j - \eta \|\nabla_s f(y_k^0)\|^2$$

失败，其中 η 是一个小的正数，而 $\nabla_s f(y_k^0)$ 是使用 Y_k 计算得到的单纯形梯度（见第2.6节）。对于重启，顶点 y_k^1、…、y_k^n 被替换为 $y_k^0 \pm (0.5 \min_{1 \le i \le n} \|y_k^i - y_k^0\|) e_i$、$i = 1$、…、$n$，其中 e_i 是阶数为 n 的单位矩阵的第 i 列。符号 $\pm$ 根据 $\nabla_s f(y_k^0)$ 的第 i 个分量的符号来选择。（在同一思路但不同背景下，Mifflin [171] 曾建议使用中心单纯形梯度的符号作为下降指示符。）

8.4 其他说明与参考文献

Nelder和Mead的工作[177]受益于Spendley、Hext和Himsworth[210]在1962年的早期贡献，当时首次引入了基于单纯形的操作以用于优化目的。在他们的方法中，Spendley、Hext和Himsworth试图通过将单纯形的最差顶点（根据目标函数的值）相对于其他n个顶点的质心进行等距反射来改进它，或者通过重复此类操作但这次反射第二差的顶点。Nelder-Mead算法[177]包含了类似类型的反射，但通过允许非等距反射（可视为扩展和收缩），并因此允许任意的单纯形形状，对Spendley-Hext-Himsworth方法进行了“改进”。当然，正是这种额外的灵活性使得收敛性更难以考量。在Nelder-Mead论文发表的那一年，Box[45]发表了一种基于将最差顶点相对于其余顶点的质心进行反射的“单纯形”方法。该方法允许$n+1$到$2n$之间的多个点，并考虑了变量的简单边界。

Nelder和Mead[177]以及Spendley、Hext和Himsworth[210]原始方法的若干其他变体已被提出并分析，特别是在俄罗斯文献中。Dambrauskas[71]建议对Spendley–Hext–Himsworth方法进行扩展，其中单纯形也可以向其质心收缩。Yu[234]证明了Spendley–Hext–Himsworth方法的一个修改版本（其中接受反射的条件已经基于充分下降条件）全局收敛到一个稳定点。Rykov（见[202]及其中的参考文献）提出了基于单纯形的反射、扩展和收缩的直接搜索算法。Tseng[220]详细列出了他的通用单纯形框架与Rykov的差异。一个根本区别是Rykov的分析要求目标函数是凸的。Woods[230]以及Nazareth和Tseng[176]也在凸性形式下证明了修改的Nelder–Mead算法的性质。

Hvattum和Glover[135]开发了一种受单纯形和方向型直接搜索方法启发的方法，该方法适用于不同大小的样本集，并通过散点搜索技术增强以处理样本集的选择。

MDS方法已被多位作者测试和应用。例如，Hough和Meza [133] 将MDS方法应用于基于导数的信赖域框架内修正信赖域子问题的无导数求解。Buckley和Ma [48] 通过算法生成的样本集上的二次插值研究了MDS的实际改进。

8.5 练习

1. Nelder–Mead 方法在仿射变换下是不变的 [149]。为了证明这一性质，考虑 $g(x) = Ax + b$，其中 $b \in \mathbb{R}^n$ 和 $A \in \mathbb{R}^{n\times n}$ 是非奇异矩阵。证明将 Nelder–Mead 方法（算法 8.1）应用于从初始单纯形 Y_0 出发的 $f(x)$，以及应用于从初始单纯形 $g^{-1}(Y_0) = A^{-1}Y_0 - b$ 出发的 $f(g(x))$，会生成相同的单纯形顶点序列。

2. 证明收缩步骤保持单纯形的归一化体积不变。

3. 证明当$n=$为2或者单形是等边的（意味着顶点间距离恒定）时，等距反射保持单形的归一化体积不变。

4. 证明等距反射通常产生

$$\operatorname{diam}(Y_{k+1}) \leq \left(\frac{2n-1}{n}\right)\operatorname{diam}(Y_k).$$

使用此界限来展示（8.5）。

5. 证明MDS方法中的旋转与扩张（参见第7章末尾）保持单纯形的归一化体积不变。

6. 证明定理8.2的三个断言均成立。

7. 将Nelder–Mead方法（算法8.1）在$n=1$且参数由标准值(8.1)给出时，构造为算法7.2类型的方向直接搜索方法。通过证明假设7.8、7.9和7.10得到满足（通过整数格上的简单下降进行全局化），Nelder–Mead方法生成一个迭代序列$\{x_k\}$，其中$\{\|\nabla f(x_k)\|\} = \{|f'(x_k)|\}$的子序列收敛到零。

8. 为什么序列$\{a_k^i\}$、$\{b_k^i\}$和$\{c_k^i\}$收敛到x_* (定理8.5的证明)?

9. 使用与定理8.5证明中类似的论证，证明如果在算法8.2的某个迭代中发生无限循环，则收缩单纯形的顶点会收敛到一个稳定点。

10. 在定理8.6的证明上下文中，证明(8.16)和(8.28)意味着$\nabla f(x_*) = 0$。

11. 解释为什么仅考虑等距反射和收缩的修正Nelder-Mead方法的简化版本，如果从等边单纯形开始，则具有全局收敛性（在定理8.5和8.6的意义上）。

12. 证明定理8.6的以下替代：设f在$\mathbb{R}^n$中有下界、一致连续且连续可微。假设由修改的Nelder-Mead方法（算法8.2）生成的单纯形顶点序列$\{Y_k\}$位于一个紧集中。假设总是尝试受保护的旋转（意味着反射步骤将仅由受保护的旋转组成）。那么$\{Y_k\}$的所有极限点都是稳定的。（证明遵循定理8.6的证明思路，但更简单，因为不需要(8.24)，并且$f(y_{k+1}^0) > f(y_k^0) - \rho(\Delta_k)$可以直接用于矛盾论证中。）

第9章

基于单纯形导数的线搜索方法

Kelley等人在[229]中提出的隐式过滤方法（另见[141]）可视为基于单纯形梯度的线搜索方法。在本章中，我们介绍一种改进版的隐式过滤方法，该方法保证全局收敛到(1.1)的一阶驻点。主要修改依赖于应用回溯方案以实现充分下降，可以证明该方案最终会成功。在这种修改下，这种无导数算法可以看作第10章中考虑的信任域无导数方法的线搜索对应物。

9.1 线搜索框架

为简化起见，我们考虑在算法的每次迭代 k 中，一个样本集 $Y_k = \{y_k^0, \ y_k^1, \ \ldots, \ y_k^n\}$，由 $n+1$ 个点组成。我们将假设该集合在线性插值的意义上是适定的。换句话说，点 $y_k^0, \ y_k^1, \ \ldots, \ y_k^n$ 被假定为单纯形集的顶点。

现在我们考虑基于y_k^0并根据该样本集计算得到的单纯形梯度。这样的单纯形梯度由下式给出：

$$\nabla_s f(x_k) \ = \ L_k^{-1} \delta f(Y_k),$$

其中

$$L_k \ = \ \left[y_k^1 - y_k^0 \cdots y_k^n - y_k^0 \right]^\top$$

和

$$\delta f(Y_k) \ = \ \begin{bmatrix} f(y_k^1) - f(y_k^0) \\ \vdots \\ f(y_k^n) - f(y_k^0) \end{bmatrix}.$$

让我们也定义

$$\Delta_k \ = \ \max_{1 \le i \le n} \| y_k^i - y_k^0 \|.$$

正如我们将在本章后面看到的，可以采用回归方法（另见第2章和第4章）或中心差分方案，使用其他更精细的单纯形梯度。

无论选择哪种单纯形梯度计算方法，我们只需确保能满足以下误差界限：

$$\|\nabla f(x_k) - \nabla_s f(x_k)\| \leq \kappa_{eg}\,\Delta_k, \tag{9.1}$$

其中，正如我们在第2章和第3章中所看到的，κ_{eg}是一个取决于样本点几何结构的正常数。第6章中提出的算法框架可用于改进样本集的几何结构。为了使算法的陈述既严谨又接近实际实现，我们引入以下假设，其中单纯形几何结构的改进步骤是指重新计算集合$\{y_k^1$、…、$y_k^n\}$中的一个点。

假设 9.1。 *We assume that* (9.1) *can be satisfied for some fixed positive* $\kappa_{eg} > 0$ *and for any value of* $\Delta_k > 0$ *in a finite, uniformly bounded number of improvement steps of the sample set.*

基本上，一个几何改进步骤包括应用第6章中描述的算法来替换单纯形中的一个顶点。因此，在插值情况下（$n+1$个样本点），对于Δ_k的任何正值，误差界(9.1)可以通过最多n次改进步骤达到。

在随后的线搜索无导数方法的每次迭代中，计算新点时都施加了充分下降条件。当使用单纯形梯度$\nabla_s f(x_k)$，其中$x_k = y_k^0$时，此充分下降条件的形式为

$$f(x_k - \alpha\nabla_s f(x_k)) - f(x_k) \leq -\eta\alpha\|\nabla_s f(x_k)\|^2, \tag{9.2}$$

其中 η 是区间 (0, 1) 内的常数，对于所有 k 和 $\alpha > 0$。新点 x_{k+1} 是形式为 $x_{k+1} = x_k - \alpha_k\nabla_s f(x_k)$ 的 *in principle*，其中 α_k 通过回溯过程选择以确保 (9.2) 在 $\alpha = \alpha_k$ 下成立。然而，这里分析的方法的线搜索版本考虑了接受不同于 $x_k - \alpha_k\nabla_s f(x_k)$ 的点的可能性，只要它提供较低的目标值。

下面介绍了线搜索无导数方法，并包含一个标准的回溯方案。然而，这种线搜索可能会失败。当它失败时，Δ_k的大小会相对于$\|\nabla_s f(x_k)\|$ (的大小减小，这涉及若干改进步骤以及单纯形梯度)的重新计算，并且线搜索从同一点重新开始（可能具有更精确的单纯形梯度）。

算法9.1（基于单纯形梯度的线搜索无导数方法）。

初始化：选择一个初始点 x_0 和一个初始平衡样本集 $\{y_0^0(=x_0)$、y_0^1、…、$y_0^n\}$。在 (0, 1) 中选择 β、η 和 ω。选取 $j_{max} \in \mathbb{N}$。

对于 $k = 0$、1、2，…

> 1. 单纯形梯度计算：计算一个单纯形梯度 $\nabla_s f(x_k)$，使得 $\Delta_k \leq \|\nabla_s f(x_k)\|$ (应用下面的算法9.2)。设置 $j_{current} = j_{max}$ 和 $\mu =$ 为1。

2. 线搜索：对于 $j = 0, 1, 2, \ldots, j_{current}$

(a) 设置 $\alpha = \beta^j$。在 $x_k - \alpha \nabla_s f(x_k)$ 处评估 f。(b) 如果对 α 满足充分下降条件 (9.2)，则以 $\alpha_k = \alpha$ (停止此步骤并转到步骤 4)。

3. 线搜索失败：如果线搜索失败，则将 μ 除以二，重新计算单纯形梯度 $\nabla_s f(x_k)$，使得 $\Delta_k \leq \mu \|\nabla_s f(x_k)\|$ (应用下方的算法 9.2)，将 $j_{current}$ 增加一，并重复线搜索（返回步骤 2）。

4. 新点：设置

$$x_{k+1} = \underset{x \in \mathcal{X}_k}{\operatorname{argmin}} \{ f(x_k - \alpha_k \nabla_s f(x_k)), f(x) \},$$

其中 $\mathcal{X}_k$ 是 f 在步骤 1 和 3 过程中可能已被评估的点集。设 $y_{k+1}^0 = x_{k+1}$。通过丢弃这些点中的一个，从 y_k^0、y_k^1、…、y_k^n 更新 y_{k+1}^1、…、y_{k+1}^n。

一种可能的停止准则是当Δ_k变得小于选定的容差$\Delta_{tol} > 0$（例如$\Delta_{tol} = 10^{-5}$）时终止运行。

在x_k处重新计算样本集以及对应的单纯形梯度，使得$\Delta_k \leq \mu \|\nabla_s f(x_k)\|$的算法接下来描述。

算法9.2（关键性步骤）。*This algorithm is applied only when* $\Delta_k > \mu \|\nabla_s f(x_k)\|$. *The constant* $\omega \in (0, 1)$ *should be chosen in the initialization of Algorithm* 9.1.

初始化：设定 $i =$ 为 0。设定 $\nabla_s f(x_k)^{(0)} = \nabla_s f(x_k)$。

将 i 增加一。根据一个包含 x_k 且被包含在 $B($$x_k$ 中的样本集计算新的单纯形梯度 $\nabla_s f(x_k)^{(i)}$；$\omega^i \mu \|\nabla_s f(x_k)^{(0)}\|$) 使得

$$\|\nabla f(x_k) - \nabla_s f(x_k)^{(i)}\| \leq \kappa_{eg} \left(\omega^i \mu \|\nabla_s f(x_k)^{(0)}\| \right)$$

(注意这可以在有限且一致有界的步骤数内完成)。设置$\Delta_k = \omega^i \mu \|\nabla_s f(x_k)^{(0)}\|$和$\nabla_s f(x_k) = \nabla_s f(x_k)^{(i)}$。

直到$\Delta_k \leq \mu \|\nabla_s f(x_k)^{(i)}\|$。

9.2 一阶临界点的全局收敛性

我们需要假设 ∇f 在水平集（迭代点必然位于其中）上是利普希茨连续的：

$$L(x_0) = \{ x \in \mathbb{R}^n : f(x) \leq f(x_0) \}.$$

然而，我们还需要考虑到，单纯形梯度计算中使用的点可能位于 $L(x_0)$ 之外，尤其是在该方法的早期迭代中。因此，我们

需要放大 $L(x_0)$。如果我们强制 Δ_k 永远不超过给定的正常数 Δ_{max}，那么算法使用的所有点都将位于以下集合中：

$$L_{enl}(x_0) = L(x_0) \cup \bigcup_{x \in L(x_0)} B(x; \Delta_{max}) = \bigcup_{x \in L(x_0)} B(x; \Delta_{max}).$$

我们将假设 f 是在包含 $L_{enl}(x_0)$ 的开集内连续可微的函数，并且 ∇f 在 $L_{enl}(x_0)$ 上利普希茨连续，其常数为 $\nu > 0$。

第一个引理的目的是表明算法9.1的步骤1和3是明确定义的，即算法9.2将采取有限数量的步骤。

引理 9.1。*If $\nabla f(x_k) \neq 0$, Steps 1 and 3 of Algorithm 9.1 will satisfy $\Delta_k \leq \mu \|\nabla_s f(x_k)\|$ in a finite number of improvement steps (by applying Algorithm 9.2).*

Proof. 证明推迟到第10章（参见引理10.5），在那里是在信赖域环境中进行的，背景稍微更一般一些。单纯形梯度$\nabla_s f(x_k)$在这里扮演的角色，与那里的模型梯度g_k所扮演的角色相同。 □

现在我们需要分析在什么条件下能够实现充分下降（9.2），并确保算法9.1第2步中的线搜索在有限次减少α和μ之后能够完成。换句话说，我们将证明，除非该点是稳定点，否则不可能在第2步和第3步之间无限循环。

引理 9.2。*Let f be a continuously differentiable function in an open set containing $L_{enl}(x_0)$. Assume that ∇f is Lipschitz continuous on $L_{enl}(x_0)$ with constant $\nu > 0$. Let x_k be such that $\nabla f(x_k) \neq 0$. The sufficient decrease condition (9.2) is satisfied for all α and μ such that*

$$0 < \alpha \leq \frac{2(1 - \eta - \kappa_{eg}\mu)}{\nu} \tag{9.3}$$

and

$$\mu < \frac{1 - \eta}{\kappa_{eg}}. \tag{9.4}$$

Proof. 首先，我们知道（例如，参见定理2.8的证明）

$$\begin{aligned} & f(x_k + \alpha d) - f(x_k) \\ \leq\ & \alpha \nabla f(x_k)^\top d + \tfrac{\nu\alpha^2}{2}\|d\|^2 \\ =\ & \alpha(\nabla f(x_k) - \nabla_s f(x_k))^\top d + \alpha \nabla_s f(x_k)^\top d + \tfrac{\nu\alpha^2}{2}\|d\|^2. \end{aligned}$$

通过将d替换为$-\nabla_s f(x_k)$并利用(9.1)和α >=0，我们得到

$$\begin{aligned} & f(x_k - \alpha \nabla_s f(x_k)) - f(x_k) \\ \leq\ & \alpha(\kappa_{eg}\Delta_k / \|\nabla_s f(x_k)\| - 1 + \nu\alpha/2)\|\nabla_s f(x_k)\|^2. \end{aligned}$$

将此不等式与 {v*} 和 {v*} 0 结合可得

$$f(x_k - \alpha \nabla_s f(x_k)) - f(x_k) \leq \alpha(\kappa_{eg}\mu - 1 + \nu\alpha/2)\|\nabla_s f(x_k)\|^2.$$

因此，如果满足充分下降条件（9.2），则有

$$\kappa_{eg}\mu - 1 + \frac{\nu\alpha}{2} \leq -\eta,$$

并且证明完成。 □

根据引理9.2和步骤2中更新α的方案，可以保证α_k的下界为

$$\alpha_k \geq \bar{\alpha} = \frac{2(1-\eta-\kappa_{eg}\bar{\mu})\beta}{\nu}, \tag{9.5}$$

其中 {v*} 是任意数，使得

$$0 < \bar{\mu} < \frac{1-\eta}{\kappa_{eg}}.$$

算法9.1对稳定点的全局收敛性由以下定理表述。

定理 9.3。*Let f be a continuously differentiable function in an open set containing $L_{enl}(x_0)$. Assume that f is bounded from below in $L(x_0)$ and that ∇f is Lipschitz continuous on $L_{enl}(x_0)$ with constant $\nu > 0$. Then the sequence of iterates generated by Algorithm* 9.1 *satisfies*

$$\lim_{k \longrightarrow +\infty} \|\nabla f(x_k)\| = 0. \tag{9.6}$$

Proof. 的证明

$$\lim_{k \longrightarrow +\infty} \|\nabla_s f(x_k)\| = 0 \tag{9.7}$$

遵循线搜索方法的经典论证。序列 $\{f(x_k)\}$ 在 $L(x_0)$ (中递减（由构造保证），并且根据假设) 有下界。因此，(9.2) 中的左侧（其中 $\alpha = \alpha_k$）收敛到零。极限 (9.7) 随后可从下式推出

$$f(x_{k+1}) - f(x_k) \leq f(x_k - \alpha_k \nabla_s f(x_k)) - f(x_k) \leq -\eta\bar{\alpha}\|\nabla_s f(x_k)\|_{\|}2,$$

其中$\bar{\alpha}$ 在 (9.5) 中给出，且第一个不等式来自算法的第4步。

由于 $\nabla_s f(x_k)$ 收敛到零，我们从（9.1）以及算法的步骤1和步骤3可知，对于足够大的 k,

$$\|\nabla f(x_k) - \nabla_s f(x_k)\| \leq \kappa_{eg}\|\nabla_s f(x_k)\|.$$

该不等式与(9.7)一起推导出(9.6)。 □

9.3 噪声分析

在许多应用中，目标函数中的噪声水平并非为零，实际评估的结果可以表示为

$$f(x) = f_{smooth}(x) + \varepsilon(x), \tag{9.8}$$

其中 f_{smooth} 是一个基础平滑函数，而 $\varepsilon(x)$ 表示其评估中的噪声。

我们有兴趣将线搜索无导数方法的分析扩展到形式为(9.8)的含噪函数f。因此，让我们考虑将算法9.1应用于(9.8)中f的最小化。

为了保持全局收敛到一阶临界点，我们要求目标函数中的噪声水平满足

$$\max_{0\le i\le n} |\varepsilon(y_k^i)| \;\le\; c\,\Delta_k^2 \tag{9.9}$$

对于所有迭代，其中 $c > 0$ 独立于 k。此外，由于为了充分下降的目的，需要在可能不用于单纯形梯度计算的点上评估 f，我们还要求噪声水平满足

$$\varepsilon(x_k - \alpha\nabla_s f(x_k)) \;\le\; c\,\Delta_k^2 \tag{9.10}$$

对于回溯方案中考虑的所有 α 值。

当噪声水平满足上述两个条件时，类似于定理9.3，可以证明底层函数f_{smooth}的梯度极限收敛于零。

9.4 隐式过滤算法

Kelley 等人在 [229] 中提出的隐式过滤方法（另见 [141]）在多个方面与算法 9.1 不同。首先，样本集并非在每次迭代时动态更新。相反，为了计算单纯形梯度，每次迭代都会选择一个新的样本集。这种选择可能使该算法对并行计算具有吸引力，但可能会损害其在串行环境中的效率。

没有规定将单纯形梯度的准确性和样本集几何质量与线搜索方案本身联系起来，如同算法9.1那样。因此，无法保证线搜索的成功（该过程可能在预定的有限步数j_{max}后不成功地终止）。

除基本线搜索方案外，隐式过滤还纳入了基于正在计算的单纯形梯度的拟牛顿更新（参见例如[76, 178]）以逼近海森矩阵。当线搜索失败时，拟牛顿矩阵重置为初始选择。该方法已应用于含噪声函数的问题，并被证明具有数值鲁棒性。我们特别考虑到f具有形式(9.8)且噪声遵循(9.9)和(9.10)的情况，将其呈现在下方。

算法9.3（隐式过滤方法）。

初始化：选择 (0, 1) 内的 β 和 η。选择初始点 x_0 和初始 Hessian 近似 H_0 (，例如单位矩阵)。选择 $j_{max} \in \mathbb{N}$。

对于 $k = 0, 1, 2, \ldots$

1. 单纯形梯度计算：计算单纯形梯度 $\nabla_s f(x_k)$，使得 $\Delta_k \le \|\nabla_s f(x_k)\|$。计算 $d_k = -H_k^{-1}\nabla_s f(x_k)$。

2. 线搜索：对于 $j = 0, 1, 2, \ldots, j_{max}$

(a) 设置 $\alpha = \beta^j$。在 $x_k + \alpha d_k$ 处评估 f
。(b) 如果充分下降条件

$$f(x_k + \alpha d_k) - f(x_k) \leq \eta \alpha \nabla_s f(x_k)^\top d_k$$

若对α满足，则以$\alpha_k = \alpha$停止此步骤。

3. 新点：如果线搜索成功，则 $x_{k+1} = x_k + \alpha$ $_k d_k$。

4. Hessian 更新：如果线搜索失败，设置 $H_{k+1} = H_0$。否则，根据 $x_{k+1} - x_k$ 和 $\nabla_s f(x_{k+1}) - \nabla_s f(x_k)$ 使用拟牛顿法从 H_k 更新 H_{k+1}。

当线搜索失败时，可能需要其他措施来使该算法实用。例如，可能需要重新计算采样点（通过将它们朝x_k缩放，以便对于某个小于1的$\mu >$满足
$\Delta_k \leq \mu \|\nabla_s f(x_k)\|$，如算法9.1中所示），并在一次线搜索失败后重复迭代。

9.5 其他单纯形导数

存在基于 $n+1$ 个点计算单纯形梯度的替代方法。例如，如果函数在超过 $n+1$ 个点上被评估，可以按照第2章所述，在回归意义上计算单纯形梯度。在这两种情况下，精度阶数在包含这些点的球的Δ (大小)上是线性的。

中心单纯形梯度

当点的数量为 $2n+1$ 且采样集 Y 的形式为

$$\left\{y^0, y^0 + (y^1 - y^0), \ldots, y^0 + (y^n - y^0), y^0 - (y^1 - y^0), \ldots, y^0 - (y^n - y^0)\right\}$$

可以计算出具有Δ^2精度的中心单纯形梯度。首先，注意上面给出的采样集是通过保留原始点并加上它们关于y^0的反射得到的。这种几何结构以前已经见过：

$$\left[\, y^1 - y^0 \;\cdots\; y^n - y^0 \;\; -(y^1 - y^0) \;\cdots\; -(y^n - y^0) \,\right]$$

形成一个（极大）正基（见第2.1节）。当{v*} 0时，该采样集简化为

$$\left\{0, y^1, \ldots, y^n, -y^1, \ldots, -y^n\right\}.$$

再次考虑矩阵 $L = \left[y^1 - y^0 \cdots y^n - y^0\right]^\top$。中心单纯形梯度定义为

$$\nabla_{cs} f(y^0) = L^{-1} \delta_{cs} f(Y),$$

其中

$$\delta_{cs} f(Y) = \frac{1}{2}\begin{bmatrix} f(y^0+(y^1-y^0))-f(y^0-(y^1-y^0)) \\ \vdots \\ f(y^0+(y^n-y^0))-f(y^0-(y^n-y^0)) \end{bmatrix}.$$

可以很容易地证明，如果$\nabla^2 f$在一个包含球体$B(y^0$的开集中是Lipschitz连续的，且常数为$\nu > 0$；$\Delta)$，其中

$$\Delta = \max_{1\le i\le n} \|y^i - y^0\|,$$

然后

$$\|\nabla f(y^0) - \nabla_{cs} f(y^0)\| \le \kappa_{eg}\,\Delta^2,$$

其中 $\kappa_{eg} = n^{\frac{1}{2}}\nu\|\hat{L}^{-1}\|$ 和 $\hat{L} = L/\Delta$。需要强调的是，梯度近似精度阶数的这一改进对二阶近似没有影响。事实上，一般情况下，仅给定与 n 成线性关系的若干点，是不可能计算出一个单纯形海森矩阵（见后续段落）使其以 Δ 阶的误差逼近真实海森矩阵的。

单纯形海森矩阵

给定样本集 $Y = \{y^0、y^1、\ldots、y^p\}$，其中 $p = (n+1)(n+2)/2 - 1$，在二次插值意义下处于平衡状态，可以从线性方程组计算出单纯形梯度 $\nabla_s f(y^0)$ 和单纯形（对称）Hessian 矩阵 $\nabla_s^2 f(y^0)$

$$(y^i - y^0)^\top \nabla_s f(y^0) + \frac{1}{2}(y^i - y^0)^\top \nabla_s^2 f(y^0)(y^i - y^0) = f(y^i) - f(y^0), \qquad (9.11)$$

$i = 1、\ldots、p$。

可以观察到，上述定义的单纯形梯度和单纯形海森矩阵无非是二次插值模型 $m(x) = c + g^\top x + (1/2)x^\top H x$ 的系数：

$$\nabla_s f(y^0) = g \quad \text{and} \quad \nabla_s^2 f(y^0) = H.$$

当$p = 2n$时，可以忽略Hessian矩阵的所有非对角元素，并计算单纯形梯度和对角单纯形Hessian。

9.6 其他注释和参考

隐式过滤算法最早在已引用的论文[229]中描述，后来在Stoneking等人[212]以及Gilmore和Kelley[105]的期刊发表中得到了更详细的阐述。该方法的全局收敛性质由Bortz和Kelley[41]分析。Choi和Kelley[52]研究了局部收敛速率。

Mifflin [171] 在1975年提出了一种基于中心单纯形梯度和近似单纯形Hessian的线搜索算法，他证明了该算法全局收敛到一阶驻点，并研究了局部收敛速率。Mifflin的算法是一种混合方法，兼具直接搜索方法（使用坐标搜索方向计算单纯形导数）和线搜索算法的特点。

9.7 练习

1. 证明当算法9.1应用于(9.8)中给出的f，且满足条件(9.9)和(9.10)时，定理9.3对于f_{smooth}仍然成立。

第10章

基于无导数模型的信赖域方法

信赖域方法是求解非线性规划问题的一类被广泛研究的算法[57, 178]。这些方法具有许多吸引人的特点。它们本质上基于二次模型，这一事实使得它们特别适合处理曲率信息。它们的鲁棒性部分归因于在预定大小的区域上最小化二次模型的正则化效果。对求解信赖域子问题及相关数值问题的广泛研究已带来了高效的实现和商业代码。另一方面，信赖域方法的收敛理论既全面又优雅，因为它涵盖了许多问题类，并以自然的方式从一个问题类细化到一个子类。许多扩展已被开发和分{ v*}析，以处理不同的算法适应或问题特征（见[57]）。

在本章中，我们讨论无约束无导数优化的信赖域方法。这些方法维护仅基于样本点处计算的目标函数值的二次（或线性）模型。相应的模型可以通过多项式插值或回归或任何其他近似技术来构建。本章所采取的方法抽象了模型构建的具体细节。事实上，甚至不要求这些模型是多项式函数，只要能从信赖域子问题中提取适当的下降量（如柯西下降量和特征步下降量）即可。相反，要求无导数模型具有一致的局部行为（可能在对样本集进行有限次修改后），类似于在存在导数时泰勒模型所观察到的行为。在第6章中，我们根据其精度称这样的模型为*fully linear*和*fully quadratic*。在第3–6章中已经严格证明了如何在多项式插值或回归的背景下构造这样的*fully linear*和*fully quadratic*模型。

再次考虑的问题是(1.1)，其中f是一个实值函数，假设其一次（或两次）连续可微且下有界。

10.1 信赖域框架基础

信赖域方法的基本原理相当简单。与传统基于导数的信赖域方法一样，其主要思想是使用一个目标函数的模型，该模型

一，希望能够在当前点的邻域内被信任。为了有用，在邻域内优化模型必须比解决原始问题显著更容易。所考虑的邻域称为信赖域。模型必须完全线性，以确保全局收敛到一阶临界点。人们还希望有接近完全二次模型的东西，以允许全局收敛到二阶临界点（并加速局部收敛）。通常，模型是二次的，写为形式

$$m_k(x_k+s) \;=\; m_k(x_k)+s^\top g_k+\frac{1}{2}s^\top H_k s. \tag{10.1}$$

该二次模型关于 s 变量的导数由 $\nabla m_k(x_k+s)=H_k s+g_k$、$\nabla m_k(x_k)=g_k$ 和 $\nabla^2 m_k(x_k)=H_k$ 给出。显然，g_k 是模型在 $s=0$ 处的梯度。

如果 m_k 是一阶泰勒模型，则 $m_k(x_k)=f(x_k)$ 和 $g_k=\nabla f(x_k)$，而如果它是二阶泰勒模型，则还有 $H_k=\nabla^2 f(x_k)$。一般来说，即使在导数情形中，H_k 也是 $\nabla^2 f(x_k)$ 的对称近似。在无导数情形中，我们使用的模型中 $H_k \neq \nabla^2 f(x_k)$、$g_k \neq \nabla f(x_k)$，并且在无插值的情况下，$m_k(x_k) \neq f(x_k)$。

在每次迭代 k 中，我们考虑模型 $m_k(x_k+s)$，其旨在 x_k 的一个合适邻域——信赖域内逼近真实目标函数 f。为简单起见，该区域取为所有点的集合

$$B(x_k;\Delta_k) \;=\; \{x\in\mathbb{R}^n:\ \|x-x_k\|\le\Delta_k\},$$

其中 Δ_k 称为信赖域半径，而 $\|\cdot\|$ 可以是依赖于迭代的范数，但通常是固定的，在我们的情况下将取为标准欧几里得范数。图 10.1 展示了信赖域（一个简单的球）中非线性函数的线性模型和二次模型，两者都是通过插值构建的。正如预期的那样，二次模型捕捉到了函数的曲率。

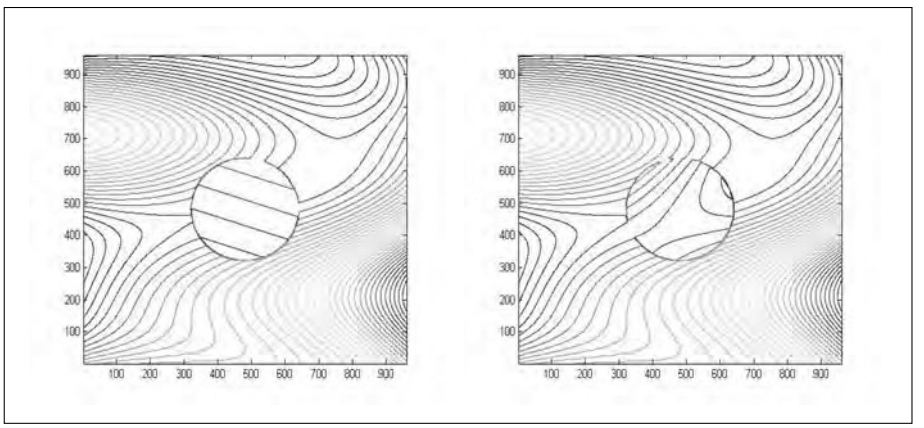


图10.1。*Contours of a linear model (left) and a quadratic model (right) of a nonlinear function in a trust region.*

因此，在无约束情况下，我们所考虑的局部模型问题（称为信赖域子问题）表述为

$$\min_{s\in B(0;\Delta_k)} m_k(x_k+s), \tag{10.2}$$

其中 $m_k(x_k+s)$ 是（10.1）中给出的目标函数模型，且 $B(0;\ \Delta_k)$ 是我们的信赖域，半径为 Δ_k，现在以0为中心并用 $s=x-x_k$ 表示。

柯西步

在某种意义上，所有优化技术的驱动力都是最速下降，因为它定义了局部最佳下降方向。从全局收敛的角度来看，至关重要的是，至少要与最速下降相关的某种方法一样好地最小化模型。在此基础上，定义了一个称为柯西步长 s_k^{C} 的东西，它实际上是在信赖域内沿最速下降方向使模型达到最小的步长。因此，如果我们定义

$$t_k^{\mathrm{C}} = \operatorname*{argmin}_{t\geq 0: x_k - t g_k \in B(x_k;\Delta_k)} m_k(x_k - t g_k),$$

那么柯西步是由以下给出的一个步骤

$$s_k^{\mathrm{C}} = -t_k^{\mathrm{C}} g_k. \tag{10.3}$$

一个基本结果，它驱使信赖域方法达到一阶临界性，下面将予以陈述并证明。

定理 10.1。 *Consider the model* (10.1) *and the Cauchy step* (10.3)*. Then*

$$m_k(x_k) - m_k(x_k + s_k^C) \ \geq\ \frac{1}{2}\|g_k\| \min\left\{\frac{\|g_k\|}{\|H_k\|}, \Delta_k\right\}, \tag{10.4}$$

where we assume that $\|g_k\|/\|H_k\| = +\infty$ *when* $H_k = 0$*.*

Proof. 我们首先注意到

$$m_k(x_k - \alpha g_k) \ =\ m_k(x_k) - \alpha\|g_k\|^2 + \frac{1}{2}\alpha^2 g_k^\top H_k g_k. \tag{10.5}$$

在模型沿最陡下降方向$-g_k$的曲率为正的情况下，即当$g_k^\top H_k g_k > 0$时，我们知道模型沿该方向是凸的，因此驻点必然是该方向上的全局极小值点。将最优参数表示为 α_k^*，我们有$-\|g_k\|^2 + \alpha_k^* g_k^\top H_k g_k = 0$且

$$\alpha_k^* = \frac{\|g_k\|^2}{g_k^\top H_k g_k}.$$

因此，如果 $\|-\alpha_k^* g_k\| = \|g_k\|^3/g_k^\top H_k g_k \leq \Delta_k$，则唯一极小值点位于信任域内，我们可以得出结论：

$$m_k(x_k + s_k^{\mathrm{C}}) - m_k(x_k) \ =\ -\frac{1}{2}\frac{\|g_k\|^4}{g_k^\top H_k g_k},$$

因此,

$$m_k(x_k) - m_k(x_k + s_k^C) \;\geq\; \frac{1}{2}\|g_k\|^2 / \|H_k\|. \tag{10.6}$$

如果 $\|-\alpha_k^* g_k\| > \Delta_k$，那么我们取 $\|-t_k^C g_k\| = \Delta_k$；即我们走向信赖域的边界。在这种情况下

$$m_k(x_k + s_k^C) - m_k(x_k) \;=\; -\frac{\Delta_k \|g_k\|^2}{\|g_k\|} + \frac{1}{2}\frac{\Delta_k^2 \|g_k\|}{\|g_k\|^3} g_k^\top H_k g_k.$$

但是 $\|g_k\|^3 / g_k^\top H_k g > \Delta_k$ (由于最优步长位于信赖域)之外, n 给出

$$m_k(x_k) - m_k(x_k + s_k^C) \;\geq\; \frac{1}{2}\Delta_k \|g_k\|. \tag{10.7}$$

还需考虑α中的一维问题非凸的情况。在这种情况下，我们同样知道将在信任区域的边界处终止（因为(10.5)右侧的第二项和第三项对所有正的α均为负）。此外，$g_k^\top H_k g_k \leq 0$ 意味着

$$m_k(x_k + s_k^C) - m_k(x_k) \;\leq\; -t_k^C \|g_k\|^2 \;=\; -\Delta_k \|g_k\| \;<\; -\frac{1}{2}\Delta_k \|g_k\|. \tag{10.8}$$

推导出的模型变化边界（10.6）、（10.7）和（10.8）意味着（10.4）成立。 □

事实上，无需实际找到柯西步来实现全局收敛到一阶稳定点。只需将计算出的步长与柯西步关联起来，因此所需的假设如下。

假设 10.1。*For all iterations k,*

$$m_k(x_k) - m_k(x_k + s_k) \;\geq\; \kappa_{fcd}\left[m_k(x_k) - m_k(x_k + s_k^C)\right] \tag{10.9}$$

for some constant $\kappa_{fcd} \in (0, 1]$.

在假设10.1下计算的步骤因此将提供一部分柯西下降，根据定理10.1，这可以有下界，即

$$m_k(x_k) - m_k(x_k + s_k) \;\geq\; \frac{\kappa_{fcd}}{2}\|g_k\| \min\left\{\frac{\|g_k\|}{\|H_k\|}, \Delta_k\right\}. \tag{10.10}$$

如果$m_k(x_k + s)$不是线性函数或二次函数，则定理10.1不能直接应用。在这种情况下，例如，可以通过在$s = 0$处沿$-g_k$对模型$m_k(x_k + s)$应用线搜索来定义柯西步，当满足某种类型的充分下降条件时停止（参见[57, 第6.3.3节]或第12.2)节）。计算一个比柯西下降更好的下降步骤，可以通过近似求解信赖域子问题来实现，该子问题现在涉及在信赖域内最小化一个非线性函数。

假设10.1是求解(10.2)以达到全局收敛到一阶临界点所需满足的最低要求。如果我们希望保证更多，那么我们必须用不仅仅是梯度下降方向来驱动算法。我们将在接下来考虑这种情况。

特征步

在考虑二次模型以及全局收敛到二阶临界点时，所需的模型约简可以沿与最大负曲率相关的方向实现。让我们假设 H_k 至少有一个负特征值，并令 $\tau_k = \lambda_{min}(H_k)$ 为 H_k 的最负特征值。在这种情况下，我们可以确定一个负曲率步 s_k^{E}，使得

$$(s_k^{\mathrm{E}})^\top (g_k) \leq 0, \quad \|s_k^{\mathrm{E}}\| = \Delta_k, \quad \text{and} \quad (s_k^{\mathrm{E}})^\top H_k (s_k^{\mathrm{E}}) = \tau_k \Delta_k^2. \tag{10.11}$$

我们将 s_k^{E} 称为特征步。

特征步 s_k^{E} 是 H_k 对应于最负特征值 τ_k 的特征向量，其符号和尺度被选择以确保（10.11）的前两部分得到满足。注意，由于负曲率的存在，s_k^{E} 是信赖域内沿该方向的二次函数的最小化点。特征步引起模型中的以下下降。

引理 10.2。*Suppose that the model Hessian H_k has negative eigenvalues. Then we have that*

$$m_k(x_k) - m_k(x_k + s_k^E) \geq -\frac{1}{2}\tau_k \Delta_k^2. \tag{10.12}$$

Proof. 只需指出

$$\begin{aligned} m_k(x_k) - m_k(x_k + s_k^{\mathrm{E}}) &= -(s_k^{\mathrm{E}})^\top (g_k) - \tfrac{1}{2}(s_k^{\mathrm{E}})^\top H_k (s_k^{\mathrm{E}}) \\ &\geq -\tfrac{1}{2}(s_k^{\mathrm{E}})^\top H_k (s_k^{\mathrm{E}}) \\ &= -\tfrac{1}{2}\tau_k \Delta_k^2. \quad \square \end{aligned}$$

特征步的作用类似于柯西步，即，如果模型中存在负曲率，我们现在要求 $x_k + s_k$处的模型下降满足

$$m_k(x_k) - m_k(x_k + s_k) \geq \kappa_{fed}[m_k(x_k) - m_k(x_k + s_k^{\mathrm{E}})]$$

对于某个常数 $\kappa_{fed} \in (0, 1]$，由于我们还希望步长能产生一定比例的Cauchy下降，我们将考虑以下假设。

假设 10.2。*For all iterations k,*

$$m_k(x_k) - m_k(x_k + s_k) \geq \kappa_{fod}\left[m_k(x_k) - \min\{m_k(x_k + s_k^C), m_k(x_k + s_k^E)\}\right] \tag{10.13}$$

for some constant $\kappa_{fod} \in (0, 1]$.

满足此假设的一个步长通过计算柯西步以及在模型中出现负曲率时的特征步，并选择在模型中提供更大缩减的那个来给出。通过结合(10.4)、(10.12)和(10.13)，我们得到

$$m_k(x_k) - m_k(x_k + s_k) \geq \frac{\kappa_{fod}}{2} \max\left\{\|g_k\| \min\left\{\frac{\|g_k\|}{\|H_k\|}, \Delta_k\right\}, -\tau_k \Delta_k^2\right\}. \tag{10.14}$$

在一些信赖域文献中，全局收敛到二阶临界点所需的是由最优信赖域步骤（即(10.2)的最优解）获得的下降量的一小部分。注意，对于相同的{v*}值，最优下降量的一小部分条件比(10.14)更强。

如果 $m_k(x_k+s)$ 不是二次函数，则定理10.1和引理10.2不能直接应用。与柯西步骤情形类似，这里可以通过对模型 $m_k(x_k+s)$ 应用线搜索来定义特征步，在 $s=0$ 处并沿 H_k 的负（或最负）曲率方向，当某种类型的充分下降条件满足时停止（参见[57, 第6.6.2节]或第12.2节）。通过近似求解信赖域子问题，可以得到比柯西步和特征步下降更好的步长，而这同样涉及在信赖域内最小化非线性函数。

信赖域半径的更新

信赖域方法的另一个关键要素是所谓的信赖域管理。其基本思想是将真实情况，即目标函数的实际下降量，与模型预测的下降量进行比较。如果比较结果良好，我们接受新步长，并（可能）增大信赖域半径。如果比较结果不佳，我们拒绝新步长并减小信赖域半径。形式上，这一过程可以表述如下。我们引入目标函数中简单下降与充分下降之间的区别。在前一种情况下，当 $\eta_0 = > 0$ 时，只要步长能带来目标函数的简单下降，就被接受，这在函数评估代价高昂的无导数优化中可能是自然而然的做法。

假设当前迭代值为 x_k，且下一次迭代的候选值为 x_k+s_k。再假设给定常数 η_0、η_1 和 γ，满足 $\gamma \in (0、1)$ 和 $0 \le \eta_0 \le \eta_1 < 1$（其中 $\eta_1 \neq 0$）。

真相与预测：定义

$$\rho_k = \frac{f(x_k)-f(x_k+s_k)}{m_k(x_k)-m_k(x_k+s_k)}.$$

步长接受（充分下降）：若$\rho_k \ge \eta_1$，则接受新点x_k+s_k；否则拒绝新的候选点（并如下文所述减小信赖域半径）。

步长接受（可能基于简单下降）：如果 $\rho_k \ge \eta_0$，则接受新点 x_k+s_k (，但若 $\rho_k < \eta_1$，则如下方)那样减小信赖域半径；否则，拒绝新候选点（并如下方所述减小信赖域半径）。

信赖域管理：设置

$$\Delta_{k+1} \in \begin{cases} [\Delta_k, +\infty) & \text{if } \rho_k \ge \eta_1, \\ \{\gamma \Delta_k\} & \text{if } \rho_k < \eta_1. \end{cases}$$

一个确保收敛性的重要性质如下：如果模型基于，例如，（对）截断泰勒级数展开的（某种合理近似），那么我们知道随着信赖域半径变小，模型必然

会变得更好。这保证了信赖域半径远离零，且远离驻点。在后续内容中，我们不使用泰勒模型，因为我们关注的是即使导数可能存在但不可用的情况。

10.2 对信任域模型的条件

在无导数情况下，远离驻点时，必须确保信赖域半径保持远离零的有界性。对于基于泰勒级数近似的模型，这一点由以下事实保证：随着邻域（信赖域）变小，模型逐渐变得更优。信赖域半径的管理确保只要当前迭代点不是驻点，它就一直远离零有界。像多项式插值或回归模型这样的模型，当信赖域半径减小时，并不一定会变得更好。因此，我们必须确保只有在确定当前步的失败是由于信赖域的大小而非模型本身质量差时，才减小信赖域半径。有了这种保护措施，我们可以再次证明，当邻域变小时，预测变得良好，从而信赖域半径保持远离零有界，并且通过假设10.1和10.2，可以获得与有导数情况下类似的结果。正如我们从第3-6章所知，在这些情况下所需要的是具有一致有界常数的类泰勒误差界，该常数刻画了样本集的几何特征。

在本节剩余部分，我们将阐述本章用于证明无导数信赖域算法全局收敛性的函数与模型假设。我们将仅对模型施加收敛理论所必需的要求。这些模型未必如第10.1节所述的二次函数。（我们将在第12.2节讨论信赖域方法中非线性模型的使用。）

为了收敛到一阶临界点，我们假设函数f及其梯度在算法所考虑的区域内是Lipschitz连续的。为了更好地定义这个区域，我们假设给定初始迭代点)且新的迭代点对应于目标函数值的减小。因此，迭代点必然属于水平集

$$L(x_0) = \left\{x \in \mathbb{R}^n : f(x) \leq f(x_0)\right\}.$$

然而，当考虑基于采样的模型时，特别是在迭代初期，函数f可能会在$L(x_0)$之外进行评估。假设采样被限制在形式为$B(x_k$的区域；$\Delta_k)$，并且Δ_k永远不会超过给定的（可能很大的）正常数Δ_{max}。在这种情形下，f被采样的区域位于集合内

$$L_{enl}(x_0) = L(x_0) \cup \bigcup_{x \in L(x_0)} B(x; \Delta_{max}) = \bigcup_{x \in L(x_0)} B(x; \Delta_{max}).$$

因此，我们需要的是假设6.1中已陈述的要求，但要确保那里提到的开放域包含更大的集合$L_{enl}(x_0)$。

假设 10.3。 *Suppose x_0 and Δ_{max} are given. Assume that f is continuously differentiable with Lipschitz continuous gradient in an open domain containing the set $L_{enl}(x_0)$.*

将在第10.3节中描述的基于插值的信赖域方法的算法框架，同样需要选择一个完全线性类$\mathcal{M}$——见定义6.1。我们在下面用本章的记号重述这一 定义（其中y由$x+s$给出，集合S为$L(x_0)$）。

定义 10.3。 *Let a function $f:\mathbb{R}^n \to \mathbb{R}$, that satisfies Assumption* 10.3*, be given. A set of model functions $\mathcal{M} = \{m : \mathbb{R}^n \to \mathbb{R}, m \in C^1\}$ is called a fully linear class of models if the following hold:*

1. *There exist positive constants κ_{ef}, κ_{eg}, and ν_1^m such that for any $x \in L(x_0)$ and $\Delta \in (0, \ \Delta_{max}]$ there exists a model function $m(x+s)$ in $\mathcal{M}$, with Lipschitz continuous gradient and corresponding Lipschitz constant bounded by ν_1^m, and such that*

   - *the error between the gradient of the model and the gradient of the function satisfies*

   $$\|\nabla f(x+s) - \nabla m(x+s)\| \ \leq \ \kappa_{eg}\,\Delta \quad \forall s \in B(0;\Delta), \tag{10.15}$$

   and

   - *the error between the model and the function satisfies*

   $$|f(x+s) - m(x+s)| \ \leq \ \kappa_{ef}\,\Delta^2 \quad \forall s \in B(0;\Delta). \tag{10.16}$$

   Such a model m is called fully linear on $B(x;\ \Delta)$.

2. *For this class $\mathcal{M}$ there exists an algorithm, which we will call a "model-improvement" algorithm, that in a finite, uniformly bounded (with respect to x and Δ) number of steps can*

   - *either establish that a given model $m \in \mathcal{M}$ is fully linear on $B(x;\ \Delta)$ (we will say that a certificate has been provided and the model is certifiably fully linear),*

   - *or find a model $\tilde{m} \in \mathcal{M}$ that is fully linear on $B(x;\ \Delta)$.*

在本章的剩余部分，我们将不失一般性地假设，在我们的算法框架中使用的任何完全线性类 $\mathcal{M}$ 的常数 κ_{ef}、κ_{eg} 和 ν_1^m 都满足下文引理10.25。通过这种方式，我们确保如果一个模型在一个球内是完全线性的，那么在任何更大的同心球内也将如此，正如由一阶导数定义的泰勒模型一样。

为了分析收敛到二阶临界点的情况，我们额外要求f的海森矩阵满足利普希茨连续性。整体的光滑性要求已在假设6.2中说明，但此处我们需要考虑到，那里提到的开域现在包含更大的集合$L_{enl}(x_0)$。

假设 10.4。 *Suppose x_0 and Δ_{max} are given. Assume that f is twice continuously differentiable with Lipschitz continuous Hessian in an open domain containing the set $L_{enl}(x_0)$.*

第10.5节将描述的基于插值的信赖域方法的算法框架也需要选择一个完全二次类$\mathcal{M}$——参见定义6.2。我们使用本章的符号在下面重复这一定义（其中y由$x+s$给出，集合S为$L(x_0)$）。

定义 10.4。*Let a function f, that satisfies Assumption* 10.4*, be given. A set of model functions $\mathcal{M} = \{m\colon \mathbb{R}^n \to \mathbb{R}$, $m \in C^2\}$ is called a fully quadratic class of models if the following hold:*

1. *There exist positive constants κ_{ef}, κ_{eg}, κ_{eh}, and v_2^m such that for any $x \in L(x_0)$ and $\Delta \in (0, \Delta_{max}]$ there exists a model function $m(x+s)$ in $\mathcal{M}$, with Lipschitz continuous Hessian and corresponding Lipschitz constant bounded by v_2^m, and such that*

   - *the error between the Hessian of the model and the Hessian of the function satisfies*

$$\|\nabla^2 f(x+s) - \nabla^2 m(x+s)\| \leq \kappa_{eh}\,\Delta \quad \forall s \in B(0;\Delta), \tag{10.17}$$

   - *the error between the gradient of the model and the gradient of the function satisfies*

$$\|\nabla f(x+s) - \nabla m(x+s)\| \leq \kappa_{eg}\,\Delta^2 \quad \forall s \in B(0;\Delta), \tag{10.18}$$

   and

   - *the error between the model and the function satisfies*

$$|f(x+s) - m(x+s)| \leq \kappa_{ef}\,\Delta^3 \quad \forall s \in B(0;\Delta). \tag{10.19}$$

   Such a model m is called fully quadratic on $B(x;\Delta)$.

2. *For this class $\mathcal{M}$ there exists an algorithm, which we will call a "model-improvement" algorithm, that in a finite, uniformly bounded (with respect to x and Δ) number of steps can*

   - *either establish that a given model $m \in \mathcal{M}$ is fully quadratic on $B(x;\Delta)$ (we will say that a certificate has been provided and the model is certifiably fully quadratic),*
   - *or find a model $\tilde{m} \in \mathcal{M}$ that is fully quadratic on $B(x;\Delta)$.*

在本章剩余部分，我们将不失一般性地假设，算法框架中所使用的任意完全二次类$\mathcal{M}$的常数κ_{ef}、κ_{eg}、κ_{eh}和v_2^m均满足下文引理10.26。通过这种方式，我们保证如果一个模型在一个球内完全二次，则它在任何更大的同心球内也保持完全二次（如由一阶和二阶导数)定义的泰勒模型）。

10.3 无导数信赖域方法（一阶）

无导数信赖域方法大致可分为两类：一类旨在获得良好的实际性能，例如文献[163, 190]中的方法（见

第11章）；以及那些显示了全局收敛性但以实用性为代价的方法，如[57, 59]中所述。在本书中，我们试图通过描述一个算法框架来弥合这一差距，该框架秉承第一类方法的精神，同时保留第二类方法的所有全局收敛性质。接下来，我们列出了使该算法框架与[57, 59]中的方法相比更接近实用的特性。

我们将使用的信赖域维护方法与基于导数的方法中的方法不同[57]。在基于导数的方法中，在适当条件下，当迭代收敛到局部极小值时，信赖域半径会远离零[57]；因此，在最优性附近，其半径可以保持不变或增大。在信赖域无导数方法中情况并非如此。这些方法的信赖域有两个目的：它将步长限制在模型被认为良好的邻域内，并且还定义了为构建模型而采样点的邻域。Powell在[190]中建议使用两个不同的信赖域，这使方法及其实现更加复杂。我们选择仅维护一个信赖域。然而，重要的是使信赖域的半径与某种平稳性度量相当，以便当平稳性度量接近零时（即当前迭代可能接近稳定点），模型变得更加准确，这一过程由所谓的*criticality step*完成。在关键性步骤中对信赖域半径的更新迫使其收敛到零，从而为这类方法定义了一个自然的停止准则。

该算法框架的另一个特点是接受能够使目标函数简单下降的新迭代点，而不是充分下降。这一特点在无导数背景下尤为重要，特别是当函数评估代价高昂时。如导数情形[184]中一样，对于一般的信赖域半径更新方案（如第10.1节中描述的简单方案），可获得标准的liminf型结果。特别地，可以在成功迭代结束时自由更新信赖域半径（只要不减小即可）。然而，为了在导数情形中推导经典的lim型全局收敛结果[214]，需要对成功迭代时信赖域半径的更新施加额外要求，以避免[236]中描述的那种循环效应。但是，正如我们将看到的，由于上一段提到的临界步中信赖域半径的更新，即使基于简单下降接受迭代点，也不需要这些额外规定来实现对一阶临界点的lim型全局收敛。[15]

在我们的框架中，可以采取措施，并让算法推进，而不必坚持模型在*every*迭代上完全线性或完全二次。与[57, 59]相比，我们仅要求(i)模型能够在有限且一致有界的迭代次数内被变为完全线性或完全二次，以及(ii)如果在给定的迭代中模型不是完全线性或完全二次（取决于所需最优性的阶数），那么只要新的迭代点能提供目标函数的下降（对于lim-结果，需为充分下降），就可以接受它。这一修改略微增加了收敛分析的复杂性，但它更好地反映了无导数信赖域算法的典型实现。

[15] We point out that a modification to derivative-based trust-region algorithms based on a criticality step would produce a similar lim-type result. However, forcing the trust-region radius to converge to zero may jeopardize the fast rates of local convergence under the presence of derivatives.

我们现在正式陈述我们所考虑的一阶版本算法。该算法通过选择 $\eta_0 = 0$，基于简单下降来接受新的迭代点。我们已经指出，在无导数优化中，当函数评估代价高昂时，基于简单下降来接受新的迭代点尤为合适。我们还指出，模型 m_k 和信赖域半径 Δ_k 仅在关键步（步骤1）结束时设定。迭代结束时定义下一次迭代的当前模型 m_{k+1}^{icb} 和当前信赖域半径 Δ_{k+1}^{icb}，随后这些可能会或可能不会被关键步改变。

算法 10.1（无导数信赖域方法（一阶））。

步骤 0（初始化）：选择一个完全线性的模型类 $\mathcal{M}$ 以及相应的模型改进算法（例如，参见第 6 章）。选择一个初始点 x_0 和 $\Delta_{max} > 0$。我们假设给定一个初始模型 $m_0^{icb}(x_0 + s)$ (，其在 $s = 0$ 处的梯度以及可能的 Hessian 分别由 g_0^{icb} 和 H_0^{icb} 给出)，并且给定信赖域半径 $\Delta_0^{icb} \in (0, \Delta_{max}]$。常数 η_0、η_1、γ、γ_{inc}、ϵ_c、β、μ 和 ω 也给定，并满足条件 $0 \leq \eta_0 \leq \eta_1 < 1$（其中 $\eta_1 \neq 0$），$0 < \gamma < 1 < \gamma_{inc}$，$\epsilon_c > 0$，$\mu > \beta > 0$，以及 $\omega \in (0, 1)$。置 $k = 0$。

步骤 1（关键步骤）：如果 $\|g_k^{icb}\| > \epsilon_c$，则 $m_k = m_k^{icb}$ 和 $\Delta_k = \Delta_k^{icb}$。

如果 $\|g_k^{icb}\| \leq \epsilon_c$，则按如下步骤进行。调用模型改进算法，尝试证明模型 m_k^{icb} 在 $B(x_k$ 上是否完全线性；$\Delta_k^{icb})$。如果至少满足以下条件之一，

- 模型 m_k^{icb} 在 $B(x_k$ 上不可证明完全线性；$\Delta_k^{icb})$，
- $\Delta_k^{icb} > \mu\|g_k^{icb}\|$，

然后应用算法10.2（如下所述）来构造一个模型$\tilde{m}_k(x_k + s)$ (，其梯度以及可能在 $s = 0$ 处的海森矩阵分别由$\tilde{g}_k$ 和$\tilde{H}_k$ 给出)，该模型在球 $B(x_k$ 上完全线性（对于某些常数 κ_{ef}、κ_{eg} 和 ν_1^m，这些常数在算法10.1的所有迭代中保持不变）；$\tilde{\Delta}_k)$，对于某个$\tilde{\Delta}_k \in (0,\ \mu\|\tilde{g}_k\|]$ 由算法10.2给出。在这种情况下，设置[16]

$$m_k = \tilde{m}_k \text{ and } \Delta_k = \min\{\max\{\tilde{\Delta}_k, \beta\|\tilde{g}_k\|\}, \Delta_k^{icb}\}.$$

否则，设置$m_k = m_k^{icb}$和$\Delta_k = \Delta_k^{icb}$。

步骤2（步长计算)：计算一个步长s_k，使得在(10.9))的意义下充分减少模型m_k (，并且满足$x_k + s_k \in B(x_k;\ \Delta_k)$。

第3步（试验点的接受）：计算$f(x_k + s_k)$并定义

$$\rho_k = \frac{f(x_k) - f(x_k + s_k)}{m_k(x_k) - m_k(x_k + s_k)}.$$

16注意，Δ_k被选为[$\tilde{\Delta}_k$,Δ_k^{icb}]中最接近$\beta\|\tilde{g}_k\|$的数。

如果 $\rho_k \geq \eta_1$，或者如果 $\rho_k \geq \eta_0$ 成立且模型在 $B(x_k$ 上完全线性（对于正常数 κ_{ef}、κ_{eg} 和 ν_1^m）；$\Delta_k)$，则 $x_{k+1} = x_k + s_k$，并且模型会更新，将新的迭代点纳入样本集，从而得到一个在 $s =$ 处梯度为 0 且可能包含 Hessian 矩阵的新模型 $m_{k+1}^{icb}(x_{k+1}+s)$ (，分别由 g_{k+1}^{icb} 和 H_{k+1}^{icb} 给出)；否则，模型和迭代点保持不变（$m_{k+1}^{icb} = m_k$ 和 $x_{k+1} = x_k$）。

步骤4（模型改进）：如果 $\rho_k < \eta_1$，则使用模型改进算法来

- 尝试证明 m_k 在 $B(x_k$ 上完全线性；$\Delta_k)$，
- 如果未能获得这样的证书，我们说m_k不是可证明完全线性的，并采取一个或多个适当的改进步骤。

定义 m_{k+1}^{icb} 为（可能改进的）模型。

步骤 5（信赖域半径更新）：设置

$$\Delta_{k+1}^{icb} \in \begin{cases} [\Delta_k, \min\{\gamma_{inc}\Delta_k, \Delta_{max}\}] & \text{if } \rho_k \geq \eta_1, \\ \{\gamma\Delta_k\} & \text{if } \rho_k < \eta_1 \text{ and } m_k \text{ is fully linear}, \\ \{\Delta_k\} & \text{if } \rho_k < \eta_1 \text{ and } m_k \\ & \text{is not certifiably fully linear.} \end{cases}$$

将 k 增加一并转到步骤1。

在关键性步骤（算法10.1的第1步）中调用的过程在以下算法中描述。

算法10.2（关键性步骤：一阶）。*This algorithm is applied only if* $\|g_k^{icb}\| \leq \epsilon_c$ *and at least one of the following holds: the model* m_k^{icb} *is not certifiably fully linear on* $B(x_k; \Delta_k^{icb})$ *or* $\Delta_k^{icb} > \mu\|g_k^{icb}\|$. *The constant* $\omega \in (0, 1)$ *is chosen at Step* 0 *of Algorithm* 10.1.

初始化：设置 {v*} 为 0。设置 {v*}。

重复增量 i 加一。使用模型改进算法改进前一个模型 $m_k^{(i-1)}$，直到它在 $B(x_k$ 上完全线性；$\omega^{i-1}\Delta_k^{icb})$ (注意，给定算法 10.1 第 0 步中模型改进算法的选择，这可以在有限且一致有界的步骤数内完成)。将新模型记为 $m_k^{(i)}$。设置$\tilde{\Delta}_k = \omega^{i-1}\Delta_k^{icb}$ 和 $\tilde{m}_k = m_k^{(i)}$。

直到$\tilde{\Delta}_k \leq \mu\|g_k^{(i)}\|$。

我们将在下一节证明，如果$\|\nabla f(x_k)\| \neq 0$，算法10.2在有限步骤后终止。如果 $\|\nabla f(x_k)\| = 0$，那么我们将在临界步中循环，直到满足某个停止准则。

注意，如果在算法 10.1 和算法 10.2 的临界性步骤中调用了 $\|g_k^{icb}\| \leq \epsilon_c$，则模型 m_k 在 $B(x_k$ 上是完全线性的；$\tilde{\Delta}_k)$ 带有$\tilde{\Delta}_k \leq \Delta_k$。那么，根据引理 10.25，$m_k$ 在 $B(x_k$ 上也是完全线性的；$\Delta_k)$ (以及在 $B(x_k$ 上；$\mu\|g_k\|))$。

在算法10.1的第3步之后，我们在每次迭代时可能遇到以下情况：

1. $\rho_k \geq \eta_1$；因此，新迭代被接受，信赖域半径保持不变或增大。我们将这样的迭代称为成功迭代。我们将所有成功迭代的索引集合记作 $\mathcal{S}$。

2. $\eta_1 > \rho_k \geq \eta_0$ 和 m_k 是完全线性的。因此，新的迭代被接受，并且信赖域半径减小。我们将这类迭代称为可接受的。（当 $\eta_0 = \eta_1 \in (\text{属于 } 0, 1)$ 时，不存在可接受的迭代。）

3. $\eta_1 > \rho_k$和m_k并非可证明完全线性。因此，模型得到改进。新点可能被纳入样本集，但未被接受为新的迭代点。我们将此类迭代称为模型改进迭代。

4. $\rho_k < \eta_0$ 和 m_k 完全线性。这种情况下，没有得到（可接受的）下降，且模型无需改进。信任域半径减小，其他一切不变。我们将此类迭代称为不成功的。

10.4 一阶临界点的全局收敛性

首先，我们将展示除非当前迭代点是一阶驻点，否则算法在算法10.1（算法10.2）的临界步中不会无限循环。证明与[59]中的证明非常相似，但为了完整性，我们在此重复细节。

引理 10.5. *If* $\nabla f(x_k) \neq 0$*, Step* 1 *of Algorithm* 10.1 *will terminate in a finite number of improvement steps (by applying Algorithm* 10.2*).*

Proof. 假设算法10.2中的循环是无限的。我们将证明在这种情况下$\nabla f(x_k)$必须为零。开始时，我们知道我们没有一个可验证的全线性模型m_k^{icb}，或者半径Δ_k^{icb}超过了$\mu\|g_k^{icb}\|$。然后我们定义$m_k^{(0)} = m_k^{icb}$，模型被改进直到它在球$B(x_k$上完全线性；$\omega^0\Delta_k^{icb})$ (在有限数量的改进步骤中)。如果得到的模型$m_k^{(1)}$的梯度$g_k^{(1)}$满足$\mu\|g_k^{(1)}\| \geq \omega^0\Delta_k^{icb}$，则过程停止，此时

$$\tilde{\Delta}_k^{icb} \;=\; \omega^0\Delta_k^{icb} \;\leq\; \mu\|g_k^{(1)}\|.$$

否则，即如果 $\mu\|g_k^{(1)}\| < \omega^0\Delta_k^{icb}$，则改进模型直至其在球 $B(x_k$ 上完全线性；$\omega\Delta_k^{icb})$。然后，再次，要么过程停止，要么半径再次乘以 ω，以此类推。

这个过程唯一可能无限进行（并需要无限次改进步骤）的情况是，如果

$$\mu\|g_k^{(i)}\| \;<\; \omega^{i-1}\Delta_k^{icb},$$

对于所有 $i \geq 1$，其中 $g_k^{(i)}$ 是模型 $m_k^{(i)}$ 的梯度。该论证表明 $\lim_{i\to+\infty}\|g_k^{(i)}\| = 0$。由于每个模型 $m_k^{(i)}$ 在 $B(x_k$ 上完全线性；$\omega^{i-1}\Delta_k^{icb})$，(10.15) 中 $s = 0$ 且 $x \;= x_k$ 意味着

$$\|\nabla f(x_k) - g_k^{(i)}\| \;\leq\; \kappa_{eg}\omega^{i-1}\Delta_k^{icb}$$

对于aeh $i \geq 1$。因此，利用三角不等式，对所有 $i \geq$ 都成立 1 那个

$$\|\nabla f(x_k)\| \leq \|\nabla f(x_k) - g_k^{(i)}\| + \|g_k^{(i)}\| \leq \left(\kappa_{eg} + \frac{1}{\mu}\right)\omega^{i-1}\Delta_k^{icb}.$$

由于 $\omega \in (0, 1)$，这意味着 $\nabla f(x_k) = 0$。 □

我们现在将证明与全局收敛到一阶临界点相关的结果。对于最小化，我们需要假设 f 有下界。

假设 10.5. *Assume that f is bounded from below on $L(x_0)$; that is, there exists a constant κ_* such that, for all $x \in L(x_0)$, $f(x) \geq \kappa_*$.*

我们将利用关于f下方有界性的假设，以及f (梯度的Lipschitz连续性假设，即假设10.5和10.3)，以及完全线性模型的存在性（定义10.3）。为了表述的简洁性，我们还要求模型的海森矩阵$H_k = \nabla^2 m_k(x_k)$一致有界。通常，完全线性模型仅需具有连续的一阶导数（此时，下文的κ_{bhm}可视为这些模型梯度Lipschitz常数的界）。

假设 10.6. *There exists a constant $\kappa_{bhm} > 0$ such that, for all x_k generated by the algorithm,*

$$\|H_k\| \leq \kappa_{bhm}.$$

我们以以下关键引理开始分析的主要部分。

引理 10.6. *If m_k is fully linear on $B(x_k; \Delta_k)$ and*

$$\Delta_k \leq \min\left\{\frac{\|g_k\|}{\kappa_{bhm}}, \frac{\kappa_{fcd}\|g_k\|(1-\eta_1)}{4\kappa_{ef}}\right\},$$

then the kth iteration is successful.

Proof. 由于

$$\Delta_k \leq \frac{\|g_k\|}{\kappa_{bhm}},$$

柯西下降条件（10.9）–（10.10）的分数立即给出

$$m_k(x_k) - m_k(x_k + s_k) \geq \frac{\kappa_{fcd}}{2}\|g_k\| \min\left\{\frac{\|g_k\|}{\kappa_{bhm}}, \Delta_k\right\} = \frac{\kappa_{fcd}}{2}\|g_k\|\Delta_k. \tag{10.20}$$

另一方面，由于当前模型在 $B(x_k$ 上完全是线性的；$\Delta_k)$，那么根据函数与模型之间误差的界限(10.16)以及(10.20)，我们有

$$\begin{aligned} |\rho_k - 1| &\leq \left|\frac{f(x_k + s_k) - m_k(x_k + s_k)}{m_k(x_k) - m_k(x_k + s_k)}\right| + \left|\frac{f(x_k) - m_k(x_k)}{m_k(x_k) - m_k(x_k + s_k)}\right| \\ &\leq \frac{4\kappa_{ef}\Delta_k^2}{\kappa_{fcd}\|g_k\|\Delta_k} \\ &\leq 1 - \eta_1, \end{aligned}$$

其中我们使用了假设 $\Delta_k \leq \kappa_{fcd}\|g_k\|(1-\eta_1)/(4\kappa_{ef})$ 来推导最后一个不等式。因此，$\rho_k \geq \eta_1$，迭代 k 成功。 □

由此可见，如果模型的梯度在零点以外有界，那么信赖域半径也同样有界。

引理 10.7. *Suppose that there exists a constant $\kappa_1 > 0$ such that $\|g_k\| \geq \kappa_1$ for all k. Then there exists a constant $\kappa_2 > 0$ such that*

$$\Delta_k \geq \kappa_2$$

for all k.

Proof. 我们从算法10.1的第1步了解到（不论算法10.2是否已被调用）

$$\Delta_k \geq \min\{\beta\|g_k\|, \Delta_k^{icb}\}.$$

因此，

$$\Delta_k \geq \min\{\beta\kappa_1, \Delta_k^{icb}\}. \tag{10.21}$$

根据引理10.6，并且假设对于所有k，$\|g_k\| \geq \kappa_1$成立，每当Δ_k低于由下式给出的特定值时

$$\bar{\kappa}_2 = \min\left\{\frac{\kappa_1}{\kappa_{bhm}}, \frac{\kappa_{fcd}\kappa_1(1-\eta_1)}{4\kappa_{ef}}\right\},$$

第k次迭代必须要么成功，要么改进模型（当它不成功且m_k不能确证为完全线性时），因此，从第5步，$\Delta_{k+1}^{icb} \geq \Delta_k$。由此，(10.21)以及第5步的规则，我们得出$\Delta_k \geq \min\{\Delta_0^{icb}, \beta\kappa_1, \gamma\bar{\kappa}_2\} = \kappa_2$。 □

我们现在考虑成功迭代次数为有限的情况。

引理 10.8。*If the number of successful iterations is finite, then*

$$\lim_{k\to+\infty} \|\nabla f(x_k)\| = 0.$$

Proof. 让我们考虑最后一次成功迭代之后的迭代。我们知道，在模型变得完全线性之前，只能有有限个（一致有界的，比如由 N 界定的）模型改进迭代，因此，存在无限个要么可接受要么不成功的迭代，并且在任一情况下信赖域都会缩小。由于不再有成功的迭代，对于足够大的 k，Δ_k 永远不会增加。此外，Δ_k 至少每 N 次迭代就会以因子 γ 减少一次。因此，Δ_k 收敛到零。

现在，对于每个 j，令 i_j 为第 j 次迭代之后模型 m_j 完全线性的第一次迭代的索引。那么

$$\|x_j - x_{i_j}\| \leq N\Delta_j \to 0$$

当 j 趋向于 $+\infty$。

让我们现在观察到

$$\|\nabla f(x_j)\| \leq \|\nabla f(x_j) - \nabla f(x_{i_j})\| + \|\nabla f(x_{i_j}) - g_{i_j}\| + \|g_{i_j}\|.$$

还需要证明的是，右侧三项均收敛于零。第一项收敛于零，归因于∇f的利普希茨连续性以及$\|x_{i_j} - x_j\| \to 0$这一事实。第二项收敛于零，是因为全线性模型与函数f的梯度误差有界（10.15），并且m_{i_j}是完全线性的。最后，根据引理10.6，第三项可以证明收敛于零，因为如果对某个子序列它远离零有界，那么对于足够小的Δ_{i_j}（，回忆$\Delta_{i_j} \to 0$），i_j将成为一个成功的迭代，从而产生矛盾。

□

我们现在证明另一个有用的引理，即信赖域半径收敛到零，这在无导数背景下尤其相关。

引理 10.9。

$$\lim_{k \to +\infty} \Delta_k = 0. \tag{10.22}$$

Proof. 当 $\mathcal{S}$ 为有限时，结果在引理10.8的证明中给出。让我们考虑 $\mathcal{S}$ 为无限的情况。对于任何 $k \in \mathcal{S}$，我们有

$$f(x_k) - f(x_{k+1}) \geq \eta_1 [m_k(x_k) - m_k(x_k + s_k)].$$

通过使用柯西下降分数上界（10.10），我们得到

$$f(x_k) - f(x_{k+1}) \geq \eta_1 \frac{\kappa_{fcd}}{2} \|g_k\| \min\left\{ \frac{\|g_k\|}{\|H_k\|}, \Delta_k \right\}.$$

由于算法10.1的步骤1，我们有$\|g_k\| \geq \min\{\epsilon_c, \mu^{-1}\Delta_k\}$；因此

$$f(x_k) - f(x_{k+1}) \geq \eta_1 \frac{\kappa_{fcd}}{2} \min\{\epsilon_c, \mu^{-1}\Delta_k\} \min\left\{ \frac{\min\{\epsilon_c, \mu^{-1}\Delta_k\}}{\|H_k\|}, \Delta_k \right\}.$$

由于 $\mathcal{S}$ 是无限的且 f 有下界，并且利用假设 10.6，上述表达式的右侧必须收敛到零。因此，$\lim_{k \in \mathcal{S}} \Delta_k = 0$，如果所有迭代都成功，则证明完成。现在回想一下，信赖域半径只能在成功迭代期间增加，并且其增加比例至多为 γ_{inc}。设 $k \notin \mathcal{S}$ 为某个迭代（在第一次成功迭代之后）的索引。那么 $\Delta_k \leq \gamma_{inc}\Delta_{s_k}$，其中 s_k 是 k 之前最后一次成功迭代的索引。由于 $\Delta_{s_k} \to 0$，则对于 $k \notin \mathcal{S}$，$\Delta_k \to 0$。

□

以下引理现在很容易得出。

引理 10.10。

$$\liminf_{k \to +\infty} \|g_k\| = 0. \tag{10.23}$$

Proof. 为了推导出矛盾，假设 f 或所有 k,

$$\|g_k\| \geq \kappa_1 \tag{10.24}$$

对于某个 $\kappa_1 > 0$。根据引理10.7，我们得到对于所有 k 有 $\Delta_k \geq \kappa_2$。这与引理10.9产生矛盾。 □

我们现在证明，如果模型梯度$\|g_k\|$在某个子序列上收敛到零，那么真实梯度$\|\nabla f(x_k)\|$也如此。

引理 10.11。 *For any subsequence* $\{k_i\}$ *such that*

$$\lim_{i \to +\infty} \|g_{k_i}\| = 0 \tag{10.25}$$

it also holds that

$$\lim_{i \to +\infty} \|\nabla f(x_{k_i})\| = 0. \tag{10.26}$$

Proof. 首先，我们注意到，由(10.25)可知，当i充分大时，$\|g_{k_i}\| \leq \epsilon_c$成立。因此，临界步（步骤1）的机制确保了模型$m_{k_i}$在球$B(x_{k_i}$上是完全线性的；对于所有充分大的$i$（如果$\nabla f(x_{k_i}) \neq 0$），有$\Delta_{k_i})$且$\Delta_{k_i} \leq \mu\|g_{k_i}\|$。然后，利用函数与模型梯度之间误差的界限(10.15)，我们有

$$\|\nabla f(x_{k_i}) - g_{k_i}\| \leq \kappa_{eg}\Delta_{k_i} \leq \kappa_{eg}\mu\|g_{k_i}\|.$$

因此，我们有

$$\|\nabla f(x_{k_i})\| \leq \|\nabla f(x_{k_i}) - g_{k_i}\| + \|g_{k_i}\| \leq (\kappa_{eg}\mu + 1)\|g_{k_i}\|$$

对于所有足够大的 i。但由于 $\|g_{k_i}\| \to 0$，因此这意味着 (10.26)。 □

引理10.10和10.11立即给出以下全局收敛结果。

定理 10.12。 *Let Assumptions* 10.3*,* 10.5*, and* 10.6 *hold. Then*

$$\liminf_{k \to +\infty} \nabla f(x_k) = 0.$$

如果迭代序列有界，则该结果意味着存在一个极限点是一阶临界的。事实上，我们能证明迭代序列的所有极限点都是一阶临界的。

定理 10.13。 *Let Assumptions* 10.3*,* 10.5*, and* 10.6 *hold. Then*

$$\lim_{k \to +\infty} \nabla f(x_k) = 0.$$

Proof. 我们已由引理10.8确立，在$\mathcal{S}$为有限的情况下，该定理成立。因此，我们将假设$\mathcal{S}$为无限。假设，为了确立

矛盾，即存在一个成功或可接受迭代的子序列 $\{k_i\}$，使得

$$\|\nabla f(x_{k_i})\| \geq \epsilon_0 > 0 \tag{10.27}$$

对于某个 $\epsilon_0 > 0$ 以及所有 i (，我们可以忽略其他类型的迭代，因为在这样的迭代过程中 x_k 不会改变)。然后，根据引理10.11，我们得到

$$\|g_{k_i}\| \geq \epsilon > 0$$

对于某个 $\epsilon > 0$ 以及所有充分大的 i。不失一般性，我们选取 ϵ 使得

$$\epsilon \leq \min\left\{\frac{\epsilon_0}{2(2+\kappa_{eg}\mu)}, \epsilon_c\right\}. \tag{10.28}$$

引理10.10随后保证了，对于子序列中的每个k_i，存在一个首次迭代$\ell_i > k_i$，使得$\|g_{\ell_i}\| < \epsilon$。通过从$\{k_i\}$中移除元素，在不失一般性且不改变符号的情况下，我们由此得到存在另一个由$\{\ell_i\}$索引的子序列，使得

$$\|g_k\| \geq \epsilon \text{ for } k_i \leq k < \ell_i \text{ and } \|g_{\ell_i}\| < \epsilon \tag{10.29}$$

对于足够大的 i。

我们现在将注意力限制在集合 {v*} 上，该集合对应于索引位于以下集合中的迭代子序列：

$$\bigcup_{i\in\mathbb{N}_0} \{k \in \mathbb{N}_0 : k_i \leq k < \ell_i\},$$

其中 k_i 和 ℓ_i 属于上述在 (10.29)。

我们知道，对于 $k \in \mathcal{K}$，有 $\|g_k\| \geq \epsilon$。根据引理10.9，$\lim_{k\to+\infty} \Delta_k = 0$，并且根据引理10.6，我们得出结论：对于任何足够大的 $k \in \mathcal{K}$，迭代 k 要么是成功的（如果模型完全线性），要么是模型改进的（否则）。

此外，对于每个 $k \in \mathcal{K} \cap \mathcal{S}$ 我们有

$$f(x_k) - f(x_{k+1}) \geq \eta_1[m_k(x_k) - m_k(x_k + s_k)] \geq \eta_1 \frac{\kappa_{fcd}}{2}\|g_k\| \min\left\{\frac{\|g_k\|}{\kappa_{bhm}}, \Delta_k\right\}, \tag{10.30}$$

并且，对于任何足够大的 k，有 $\Delta_k \leq \frac{\epsilon}{\kappa_{bhm}}$。因此，对于足够大的 $k \in \mathcal{K} \cap \mathcal{S}$，我们有

$$\Delta_k \leq \frac{2}{\eta_1 \kappa_{fcd} \epsilon}[f(x_k) - f(x_{k+1})].$$

由于对于任何足够大的 $k \in \mathcal{K}$，迭代要么成功，要么是模型改进的，并且由于对于模型改进的迭代 $x_k = x_{k+1}$，对于所有足够大的 i，我们有

$$\|x_{k_i} - x_{\ell_i}\| \leq \sum_{\substack{j=k_i \\ j\in\mathcal{K}\cap\mathcal{S}}}^{\ell_i - 1} \|x_j - x_{j+1}\| \leq \sum_{\substack{j=k_i \\ j\in\mathcal{K}\cap\mathcal{S}}}^{\ell_i - 1} \Delta_j \leq \frac{2}{\eta_1 \kappa_{fcd} \epsilon}[f(x_{k_i}) - f(x_{\ell_i})].$$

由于序列 $\{f(x_k)\}$ 下有界（假设10.5）且单调递减，我们可知该不等式右侧必须收敛于零，因此我们得到

$$\lim_{i\to+\infty} \|x_{k_i} - x_{\ell_i}\| = 0.$$

现在

$$\|\nabla f(x_{k_i})\| \;\le\; \|\nabla f(x_{k_i}) - \nabla f(x_{\ell_i})\| + \|\nabla f(x_{\ell_i}) - g_{\ell_i}\| + \|g_{\ell_i}\|.$$

由于f (假设10.3)中梯度的Lipschitz连续性，右侧的第一项趋于零，因此对于足够大的i，它被ϵ所界定。根据(10.29)，第三项被ϵ所界定。对于第二项，我们利用从(10.28)和迭代ℓ_i时的临界步骤机制（步骤1）可知，模型m_{ℓ_i}在$B(x_{\ell_i}$上完全线性；$\mu\|g_{\ell_i}\|)$。因此，利用(10.15)和(10.29)，我们同样推断出对于足够大的i，第二项被$\kappa_{eg}\mu\epsilon$ (所界定)。由此，根据这些界和(10.28)，我们得到

$$\|\nabla f(x_{k_i})\| \;\le\; (2+\kappa_{eg}\mu)\epsilon \;\le\; \frac{1}{2}\epsilon_0$$

对于足够大的i，这与(10.27)矛盾。因此，我们最初的假设必定是错误的，定理得证。 □

最后这个定理是我们唯一需要利用在模型改进迭代中 $x_k = x_{k+1}$ 这一事实的结果。因此，如果仅需一个 liminf 类型的结果，这一要求可以从算法中去除。这样做的好处是，即使模型不是完全线性的，也可以接受函数值的简单下降。缺点除了收敛结果较弱之外，还在于当每个这样的模型必须完全线性的区域在每次迭代中可能发生变化时，在最多 N 次连续模型改进步骤后生成完全线性模型本身存在的固有困难。

10.5 无导数信赖域方法（二阶）

为了实现全局收敛到二阶临界点，算法必须尝试将表达二阶稳定性的量驱动至零。根据[57，第9.3节]，一种可能的方法是使用

$$\sigma_k^m \;=\; \max\{\|g_k\|, -\lambda_{min}(H_k)\},$$

它衡量模型的二阶平稳性。

该算法主要遵循与算法10.1相同的论点。一个根本区别在于，σ_k^m现在扮演了$\|g_k\|$的角色。另一个区别是需要处理完全二次模型。第三个主要修改是能够更好地解决信赖域子问题，以便在存在负曲率时，步长既能产生柯西下降的一部分，也能产生特征步下降的一部分。最后，为了在二阶情况下证明lim型收敛结果，我们还需要在一些成功的迭代中增加信赖域半径，而在一阶情况下这是可选的。与传统信赖域方法寻求二阶收敛结果[57]的情况不同，我们不在*every*成功的迭代中增加信赖域半径。

迭代。只有当信赖域半径的大小与平稳性度量相比很小时，我们才坚持这样的增加。

我们陈述我们希望考虑的算法版本。

算法 10.3（无导数信赖域方法（二阶））。

步骤0（初始化）：选择一个完全二次模型类 $\mathcal{M}$ 以及相应的模型改进算法（例如，参见第6章）。选择一个初始点 x_0 和 $\Delta_{max} > 0$。我们假设初始模型 $m_0^{icb}(x_0+s)$ (在 $s=0$ 处的梯度和Hessian分别由 g_0^{icb} 和 H_0^{icb} 给出)，其中 $\sigma_0^{m,icb} = \max\{\|g_0^{icb}\|$、$-\lambda_{min}(H_0^{icb})\}$，以及一个信赖域半径 $\Delta_0^{icb} \in (0$、$\Delta_{max}]$ 都已给定。

常数 η_0、η_1、γ、γ_{inc} ϵ_c、β、μ 和 ω 也已给出，并满足条件 $0 \le \eta_0 \le \eta_1 < 1$（其中 $\eta_1 \neq 0$)，$0 < \gamma < 1 < \gamma_{inc}$，$\epsilon_c > 0$，$\mu > \beta > 0$，以及 $\omega \in (0,\ 1)$。设定 $k = 0$。

步骤 1（关键步骤）：如果 $\sigma_k^{m,icb} > \epsilon_c$，则 $m_k = m_k^{icb}$ 和 $\Delta_k = \Delta_k^{icb}$。

如果 $\sigma_k^{m,icb} \le \epsilon_c$，则按如下进行。调用模型改进算法，尝试证明模型 m_k^{icb} 在 $B(x_k$ 上是否完全二次；$\Delta_k^{icb})$。如果以下条件中至少有一个成立，

- 模型 m_k^{icb} 在 $B(x_k$ 上不可证明是完全二次的；$\Delta_k^{icb})$，
- $\Delta_k^{icb} > \mu\sigma^{m}$ ^{icb}，

然后应用算法 10.4（如下所述）构造一个模型$\tilde{m}_k(x_k+s)$ (，其在 $s=0$ 处的梯度和 Hessian 分别由 $\tilde{g}_k$ 和$\tilde{H}_k$ 给出)，且$\tilde{\sigma}_k^m = \max\{\|\tilde{g}_k\|$，$-\lambda_{min}(\tilde{H}_k)\}$，该模型在球 $B(x_k$ 上完全二次（对于某些常数 κ_{ef}、κ_{eg}、κ_{eh} 和 ν_2^m，这些常数在算法 10.3 的所有迭代中保持不变）；对于某个$\tilde{\Delta}_k \in (0$，$\mu\tilde{\sigma}_k^m]$ 由算法 10.4 给出。在这种情况下，令[17]

$$m_k = \tilde{m}_k \text{ and } \Delta_k = \min\{\max\{\tilde{\Delta}_k, \beta\tilde{\sigma}_k^m\}, \Delta_k^{icb}\}.$$

否则，设置 $m_k = m_k^{icb}$ 和 $\Delta_k = \Delta_k^{icb}$。

步骤2（)步长计算）：计算一个步长s_k，使其在(10.13))的意义下能充分减小模型 m_k (，并且满足$x_k + s_k \in B(x_k;\ \Delta_k)$。

步骤3（试验点的接受）：计算 $f(x_k+s_k)$ 并定义

$$\rho_k = \frac{f(x_k) - f(x_k+s_k)}{m_k(x_k) - m_k(x_k+s_k)}.$$

如果$\rho_k \ge \eta_1$，或者如果$\rho_k \ge \eta_0$且模型在$B(x_k$上完全二次（对于正常数κ_{ef}、κ_{eg}、κ_{eh}和ν_2^m）；$\Delta_k)$，则$x_{k+1} = x_k + s_k$，并且模型被更新以将新的迭代点纳入样本集，从而产生一个新的模型$m_{k+1}^{icb}(x_{k+1}+s)$ (，其在s =处的梯度和Hessian分别为0，由g_{k+1}^{icb}和H_{k+1}^{icb}给出，分别为)，其中$\sigma_{k+1}^{m,icb} = \max\{\|g_{k+1}^{icb}\|$，$-\lambda_{min}(H_{k+1}^{icb})\}$；否则，模型和迭代点保持不变（$m_{k+1}^{icb} = m_k$和$x_{k+1} = x_k$）。

[17] Note that Δ_k is selected to be the number in $[\tilde{\Delta}_k, \Delta_k^{icb}]$ closest to $\beta\|\tilde{\sigma}_k^m\|$.

步骤 4（model删除改进）：如果 $\rho_k < \eta_1$，则使用模型改进 a 算法到

- 尝试证明 m_k 在 $B(x_k$ 上完全二次；$\Delta_k)$，
- 如果没有获得这样的证书，我们就说m_k不能可验证地完全二次化，并采取一个或多个适当的改进步骤。

将 m_{k+1}^{icb} 定义为（可能改进的）模型。

步骤 5（信赖域半径更新）：设置

$$\Delta_{k+1}^{icb} \in \begin{cases} \{\min\{\gamma_{inc}\Delta_k, \Delta_{max}\}\} & \text{if } \rho_k \geq \eta_1 \text{ and } \Delta_k < \beta\sigma_k^m, \\ [\Delta_k, \min\{\gamma_{inc}\Delta_k, \Delta_{max}\}] & \text{if } \rho_k \geq \eta_1 \text{ and } \Delta_k \geq \beta\sigma_k^m, \\ \{\gamma\Delta_k\} & \text{if } \rho_k < \eta_1 \text{ and } m_k \\ & \text{is fully quadratic,} \\ \{\Delta_k\} & \text{if } \rho_k < \eta_1 \text{ and } m_k \\ & \text{is not certifiably fully quadratic.} \end{cases}$$

将 k 增加一，然后转到步骤 1。

我们需要回顾算法10.3中成功、可接受、模型改进和不成功迭代的定义，这些定义我们在算法10.1生成的迭代序列中已经阐述过。这里我们将使用相同的定义，但针对完全二次模型进行调整。我们用$\mathcal{S}$表示所有成功迭代的集合，以及当$\Delta_k < \beta\sigma^m$时所有此类迭代的集合。

k 由$\mathcal{S}_+$。

与一阶情况一样，在模型改进步骤中，Δ_k和x_k保持不变；因此，在获得完全二次模型之前，只能有有限数量的模型改进步骤。定理10.13之后关于在任意模型改进迭代中可能改变x_k的评论，经过适当修改后，同样适用于完全二次情况。

关键性步骤可以按照与算法10.2中描述相似的过程来实现，主要是通过将$\|g_k\|$替换为σ_k^m，并使用完全二次模型而非完全线性模型。

算法 10.4（关键性步骤：二阶）。*This algorithm is applied only if* $\sigma_k^{m,icb} \leq \epsilon_c$ *and at least one the following holds: the model* m_k^{icb} *is not certifiably fully quadratic on* $B(x_k;\ \Delta_k^{icb})$ *or* $\Delta_k^{icb} > \mu\sigma_k^{m,icb}$. *The constant* $\omega \in (0, 1)$ *is chosen at Step* 0 *of Algorithm* 10.3.

初始化：设置 $i =$ 为0。设置 $m_k^{(0)} = m_k^{icb}$。

将增量 i 重复一次。改进先前的模型 $m_k^{(i-1)}$，直到其在 $B(x_k$ 上完全二次；$\omega^{i-1}\Delta_k^{icb})$ (注意到，给定算法10.3第0步中模型改进算法的选择，这可以在有限且一致有界的步数内完成)。将新模型记为 $m_k^{(i)}$。设置$\tilde{\Delta}_k = \omega^{i-1}\Delta_k^{icb}$ 和$\tilde{m}_k = m_k^{(i)}$。

直到$\tilde{\Delta}_k \leq \mu(\sigma_k^m)^{(i)}$。

注意，如果在算法10.3和算法10.4的关键步骤中调用了$\sigma_k^{m,icb} \leq \epsilon_c$，则新模型$m_k$在$B(x_k$上是完全二次的；$\tilde{\Delta}_k)$带有$\tilde{\Delta}_k \leq \Delta_k$。然后，根据引理10.26，$m_k$在$B(x_k$上以及$B(x_k$上都是完全二次的；$\mu\sigma_k^m))$。

10.6 二阶临界点的全局收敛性

为了全局收敛到二阶临界点，我们需要更高一阶的光滑性，即关于 f 的 Hessian 矩阵 Lipschitz 连续性的假设10.4。同样必要的是假设函数 f 有下界（假设10.5）。自然地，我们也将假定存在完全二次模型。

我们首先引入记号

$$\sigma^m(x) \;=\; \max\left\{\|\nabla m(x)\|, -\lambda_{min}(\nabla^2 m(x))\right\}$$

和

$$\sigma(x) \;=\; \max\left\{\|\nabla f(x)\|, -\lambda_{min}(\nabla^2 f(x))\right\}.$$

重要的是要对真实 $\sigma(x)$ 与模型 $\sigma^m(x)$ 之间的差异进行界定。为此，我们首先推导出一个关于函数的最小特征值与相应的完全二次模型之间的差异的界限。

命题 10.14。 *Suppose that Assumption* 10.4 *holds and m is a fully quadratic model on $B(x;\ \Delta)$. Then we have that*

$$|\lambda_{min}(\nabla^2 f(x)) - \lambda_{min}(\nabla^2 m(x))| \;\leq\; \kappa_{eh}\Delta.$$

Proof. 证明直接源自（10.17）中关于m和f的Hessian矩阵之间误差的界，以及一个简单的观察：如果v是对应于$\nabla^2 m(x)$最小特征值的归一化特征向量，那么

$$\begin{aligned}\lambda_{min}(\nabla^2 f(x)) - \lambda_{min}(\nabla^2 m(x)) &\leq v^\top[\nabla^2 f(x) - \nabla^2 m(x)]v\\ &\leq \|\nabla^2 f(x) - \nabla^2 m(x)\|\\ &\leq \kappa_{eh}\,\Delta.\end{aligned}$$

类似地，令v为对应于$\nabla^2 f(x)$最小特征值的归一化特征向量，我们将得到

$$\lambda_{min}(\nabla^2 m(x)) - \lambda_{min}(\nabla^2 f(x)) \;\leq\; \kappa_{eh}\,\Delta,$$

结果随之而来。 □

以下引理表明，真实的 $\sigma(x)$ 与模型 $\sigma^m(x)$ 之间的差异是 Δ 阶的。

引理 10.15。 *Let Δ be bounded by Δ_{max}. Suppose that Assumption* 10.4 *holds and m is a fully quadratic model on $B(x;\ \Delta)$. Then we have, for some $\kappa_\sigma > 0$, that*

$$|\sigma(x) - \sigma^m(x)| \;\leq\; \kappa_\sigma\Delta. \tag{10.31}$$

Proof. 因此

$$\begin{aligned}|\sigma(x)-\sigma^m(x)| &= \big|\max\left\{\|\nabla f(x)\|,\max\{-\lambda_{min}(\nabla^2 f(x)),0\}\right\}\\ &\quad -\max\left\{\|\nabla m(x)\|,\max\{-\lambda_{min}(\nabla^2 m(x)),0\}\right\}\big|\\ &\leq \max\{|\,\|\nabla f(x)\|-\|\nabla m(x)\|\,|,\\ &\quad \big|\max\{-\lambda_{min}(\nabla^2 f(x)),0\}-\max\{-\lambda_{min}(\nabla^2 m(x)),0\}\big|\right\}.\end{aligned}$$

第一个参数 $|\,\|\nabla f(x)\|-\|\nabla m(x)\|\,|$ 从上方被 $\kappa_{eg}\Delta_{max}\Delta$ 所界，这是由于 f 和 m 的梯度之间的误差界(10.18)，以及界 $\Delta\leq\Delta_{max}$ 所致。第二个参数显然由 $|\lambda_{min}(\nabla^2 f(x))-\lambda_{min}(\nabla^2 m(x))|$ 主导，而根据命题10.14，$|\lambda_{min}(\nabla^2 f(x))-\lambda_{min}(\nabla^2 m(x))|$ 从上方被 $\kappa_{eh}\Delta$ 所界。最后，我们只需写出 $\kappa_\sigma=\max\{\kappa_{eg}\Delta_{max},\kappa_{eh}\}$，结论便随之成立。 □

收敛理论将需要已经提到的假设（假设10.4和10.5），以及二次模型Hessian矩阵的一致上界（假设10.6）。

对于一阶情况，我们首先注意到临界性步骤可以在有限数量的改进步骤中成功执行。

引理 10.16. *If $\sigma(x_k)\neq 0$, Step 1 of Algorithm 10.3 will terminate in a finite number of improvement steps (by applying Algorithm 10.4).*

Proof. 该证明与引理10.5的证明几乎完全相同，只需将$\|g_k^{(i)}\|$替换为$(\sigma_k^m)^{(i)}$，将$\nabla f(x_k)$替换为$\sigma(x_k)$。 □

我们现在证明，如果当前模型是完全二次的，并且信赖域半径相对于σ_k^m足够小，那么迭代必定成功。

引理10.17。*If m_k is fully quadratic on $B(x_k;\Delta_k)$ and*

$$\Delta_k \leq \min\left\{\frac{\sigma_k^m}{\kappa_{bhm}},\frac{\kappa_{fod}\sigma_k^m(1-\eta_1)}{4\kappa_{ef}\Delta_{max}},\frac{\kappa_{fod}\sigma_k^m(1-\eta_1)}{4\kappa_{ef}}\right\},$$

then the kth iteration is successful.

Proof. 证明与一阶情形下的引理10.6的证明相似；不过，现在我们需要考虑二阶项。

首先，我们回顾柯西分数和特征步下降（10.14），

$$m_k(x_k)-m_k(x_k+s_k)\geq\tfrac{\kappa_{fod}}{2}\max\left\{\|g_k\|\min\left\{\tfrac{\|g_k\|}{\kappa_{bhm}},\Delta_k\right\},-\tau_k\Delta_k^2\right\}.$$

根据 σ_k^m 的表达式，必须满足以下两种情况之一：要么 $\|g_k\|=\sigma_k^m$，要么 $-\tau_k=-\lambda_{min}(H_k)=\sigma_k^m$。

在第一种情况下，利用$\Delta_k\leq\sigma_k^m/\kappa_{bhm}$这一事实，我们得出结论：

$$m_k(x_k)-m_k(x_k+s_k)\geq\frac{\kappa_{fod}}{2}\|g_k\|\Delta_k=\frac{\kappa_{fod}}{2}\sigma_k^m\Delta_k. \tag{10.32}$$

另一方面，由于当前模型在 $B(x_k;\ \Delta_k)$ 上是完全二次的，我们可以从（10.32）和模型 m_k 与 f 之间误差的界限（10.19）推断出

$$\begin{aligned} |\rho_k - 1| &\leq \left|\frac{f(x_k+s_k)-m_k(x_k+s_k)}{m_k(x_k)-m_k(x_k+s_k)}\right| + \left|\frac{f(x_k)-m_k(x_k)}{m_k(x_k)-m_k(x_k+s_k)}\right| \\ &\leq \frac{4\kappa_{ef}\Delta_k^3}{(\kappa_{fod}\sigma_k^m)\Delta_k} \\ &\leq \frac{4\kappa_{ef}\Delta_{max}}{\kappa_{fod}\sigma_k^m}\Delta_k \\ &\leq 1-\eta_1. \end{aligned}$$

当 $-\tau_k = \sigma_k^m$ 时，我们首先写出

$$m_k(x_k) - m_k(x_k+s_k) \ \geq\ -\tfrac{\kappa_{fod}}{2}\tau_k\Delta_k^2 \ =\ \tfrac{\kappa_{fod}}{2}\sigma_k^m\Delta_k^2. \tag{10.33}$$

但是，由于当前模型在$B(x_k;\ \Delta_k)$上是完全二次的，我们从(10.33)以及关于m_k和f之间误差的界限(10.19)推导出

$$\begin{aligned} |\rho_k - 1| &\leq \left|\frac{f(x_k+s_k)-m_k(x_k+s_k)}{m_k(x_k)-m_k(x_k+s_k)}\right| + \left|\frac{f(x_k)-m_k(x_k)}{m_k(x_k)-m_k(x_k+s_k)}\right| \\ &\leq \frac{4\kappa_{ef}\Delta_k^3}{(\kappa_{fod}\sigma_k^m)\Delta_k^2} \\ &\leq 1-\eta_1. \end{aligned}$$

无论哪种情况，$\rho_k \geq \eta_1$ 和迭代 k 因此都是成功的。 □

与一阶情况一样，以下结果可直接从引理10.17得出。

引理 10.18。*Suppose that there exists a constant $\kappa_1 > 0$ such that $\sigma_k^m \geq \kappa_1$ for all k. Then there exists a constant $\kappa_2 > 0$ such that*

$$\Delta_k \ \geq\ \kappa_2$$

for all k.

Proof. 该证明由引理10.17和引理10.7的证明直接组合得出。 □

我们现在能够证明，如果只有有限多个成功迭代，那么我们就会逼近一个二阶驻点。

引理 10.19. *If the number of successful iterations is finite, then*

$$\lim_{k\to+\infty} \sigma(x_k) \ =\ 0.$$

Proof. 该引理的证明与一阶情况下的引理10.8几乎相同，只需将$\|g_k\|$替换为σ_k^m，将$\|\nabla f(x_k)\|$替换为$\sigma(x_k)$，并利用引理10.15和10.17。 □

我们证明整个信赖域半径序列收敛 归零。

引理 10.20。

$$\lim_{k\to+\infty} \Delta_k \;=\; 0. \tag{10.34}$$

Proof. 当 $\mathcal{S}$ 有限时，证明与引理 10.8 的证明相同（论证完全一样）。让我们考虑 $\mathcal{S}$ 无限的情况。对于任意 $k \in \mathcal{S}$，我们有

$$\begin{aligned} f(x_k) - f(x_{k+1}) \;&\geq\; \eta_1[m(x_k) - m(x_k + s_k)] \\ &\geq\; \eta_1 \tfrac{\kappa_{fod}}{2} \max\left\{ \|g_k\| \min\left\{ \tfrac{\|g_k\|}{\kappa_{bhm}}, \Delta_k \right\}, -\tau_k \Delta_k^2 \right\}. \end{aligned}$$

由于算法10.3的第1步，我们有$\sigma_k^m \geq \min\{\epsilon_c,\ \mu^{-1}\Delta_k\}$。如果在迭代$k$中我们有$\|g_k\| \geq \max\{-\tau_k,\ 0\} = \{-\lambda_{min}(H_k),\ 0\}$，那么$\sigma_k^m = \|g_k\|$并且

$$f(x_k) - f(x_{k+1}) \;\geq\; \eta_1 \frac{\kappa_{fod}}{2} \min\{\epsilon_c, \mu^{-1}\Delta_k\} \min\left\{ \frac{\min\{\epsilon_c, \mu^{-1}\Delta_k\}}{\kappa_{bhm}}, \Delta_k \right\}. \tag{10.35}$$

另一方面，如果 $\|g_k\| < -\tau_k$，那么 $\sigma_k^m = -\tau_k$ 且

$$f(x_k) - f(x_{k+1}) \;\geq\; \eta_1 \frac{\kappa_{fod}}{2} \min\{\epsilon_c, \mu^{-1}\Delta_k\} \Delta_k^2. \tag{10.36}$$

存在两个成功迭代的子序列，可能重叠，$\{k_i^1\}$，其中（10.35）成立，以及$\{k_i^2\}$，其中（10.36）成立。这些子序列的并集包含所有成功迭代。由于$\mathcal{S}$是无限的且f有下界，那么要么相应的子序列$\{k_i^1\}$（（分别地，$\{k_i^2\}$））是有限的，要么（10.35）（分别地，（10.36））的右侧必须收敛到零。因此，$\lim_{k\in\mathcal{S}} \Delta_k = 0$，如果所有迭代都成功，则证明完成。现在回忆一下，信赖域半径只能在成功迭代期间增加，并且其增加比例至多为γ_{inc}。令$k \notin \mathcal{S}$为迭代的索引（在第一次成功迭代之后）。那么 $\Delta_k \leq \gamma_{inc}\Delta_{s_k}$，其中$s_k$是$k$之前最后一次成功迭代的索引。由于$\Delta_{s_k} \to 0$，则对于 $k \notin \mathcal{S}$，$\Delta_k \to 0$。 □

我们得到以下引理作为一个简单的推论。

引理 10.21。

$$\liminf_{k\to+\infty} \sigma_k^m \;=\; 0.$$

Proof. 假设，为了推导出矛盾，对于所有k，

$$\sigma_k^m \;\geq\; \kappa_1$$

对于某个 $\kappa_1 > 0$，根据引理10.18，存在一个常数 κ_2，使得对于所有 k，$\Delta_k \geq \kappa_2$ 成立。由此与引理10.20产生矛盾。 □

我们现在验证，临界性步骤（算法10.3的第1步）通过以下辅助结果确保迭代序列的一个子序列趋近于二阶稳定点。

引理 10.22. *For any subsequence* $\{k_i\}$ *such that*

$$\lim_{i\to+\infty} \sigma_{k_i}^m = 0 \tag{10.37}$$

it also holds that

$$\lim_{i\to+\infty} \sigma(x_{k_i}) = 0. \tag{10.38}$$

Proof. 由(10.37)可知，当i充分大时，$\sigma_{k_i}^m \le \epsilon_c$。临界步(步骤1)的机制随后确保模型$m_{k_i}$在球$B(x_{k_i}$上完全二次；对于所有充分大的$i$，有$\Delta_{k_i})$；$\Delta_{k_i} \le \mu\sigma_{k_i}^m$（若$\sigma_{k_i}^m \neq 0$）。现在，利用(10.31),

$$\sigma(x_{k_i}) = \left(\sigma(x_{k_i}) - \sigma_{k_i}^m\right) + \sigma_{k_i}^m \le (\kappa_\sigma\mu + 1)\sigma_{k_i}^m.$$

极限（10.37）和这个最后界一起给出了（10.38）。 □

引理10.21和10.22直接给出了以下全局收敛结果。

定理 10.23。 *Let Assumptions* 10.4*,* 10.5*, and* 10.6 *hold. Then*

$$\liminf_{k\to+\infty} \sigma(x_k) = 0.$$

如果迭代序列有界，则该结果表明至少存在一个二阶临界极限点。事实上，我们能够证明迭代序列的所有极限点都是二阶临界的。在证明中，我们利用了算法10.3第5步的额外要求，该要求在成功迭代中，如果信赖域半径Δ_k相对于σ_k^m过小，则强制增大它。

定理 10.24。 *Let Assumptions* 10.4*,* 10.5*, and* 10.6 *hold. Then*

$$\lim_{k\to+\infty} \sigma(x_k) = 0.$$

Proof. 根据引理10.19，我们已经确定，在$\mathcal{S}$有限的情况下，定理成立。因此，我们将假设$\mathcal{S}$是无限的。为了导出矛盾，假设存在一个由成功或可接受的迭代组成的子序列$\{k_i\}$，使得

$$\sigma(x_{k_i}) \ge \epsilon_0 > 0 \tag{10.39}$$

对于某个 $\epsilon_0 > 0$ 以及所有 i (，如同在一阶情形中那样，我们可以忽略其他迭代，因为 x_k 在此类迭代期间不会改变)。然后，根据引理 10.22，我们得到

$$\sigma_{k_i}^m \ge \epsilon > 0$$

对于某个 $\epsilon > > 0$，且对于所有足够大的 i。不失一般性，我们选取 ϵ 使得

$$\epsilon \leq \min\left\{\frac{\epsilon_0}{2(2+\kappa_\sigma\mu)}, \epsilon_c\right\}. \tag{10.40}$$

引理10.21随后确保了，对于子序列中的每个k_i，存在一个首次成功或可接受的迭代$\ell_i > k_i$，使得$\sigma_{\ell_i}^m < \epsilon$成立。通过从$\{k_i\}$中移除元素，不失一般性且不改变记号，我们因此得到存在另一个由$\{\ell_i\}$索引的子序列，使得

$$\sigma_k^m \geq \epsilon \text{ for } k_i \leq k < \ell_i \text{ and } \sigma_{\ell_i}^m < \epsilon \tag{10.41}$$

对于足够大的 i。

我们现在将注意力限制在集合 $\mathcal{K}$ 上，该集合定义为索引位于以下集合中的迭代子序列：

$$\bigcup_{i\in\mathbb{N}_0} \{k \in \mathbb{N}_0 : k_i \leq k < \ell_i\},$$

其中k_i和ℓ_i属于上文（10.41）中定义的两个子序列。

根据引理10.17和10.20，正如定理10.13的证明中那样，可以得出对于足够大的 $k \in \mathcal{K}$，第k次迭代要么成功——如果模型完全线性——要么模型改进——否则，即在$\mathcal{K}$中只有有限数量的可接受迭代。

现在让我们考虑索引 k 位于 $\mathcal{K} \cap \mathcal{S} \setminus \mathcal{S}_+$ 中的情形。在这种情况下，$\Delta_k \geq \beta\sigma_k^m \geq \beta\epsilon$。由 $\Delta_k \to 0$ 对 $k \in \mathcal{K}$ 成立可直接推出，$\mathcal{K} \cap \mathcal{S} \setminus \mathcal{S}_+$ 仅包含有限次迭代。因此，当 k 足够大时，$k \in \mathcal{K} \cap \mathcal{S}$ 也在 $\mathcal{S}_+$ 中。

现在让我们证明，对于足够大的 $k \in \mathcal{K} \cap \mathcal{S}_+$，当 $[k_i\,, \ell_i - 1]$ 中最后一次成功迭代发生在 $\ell_i - 1$) 之前时，有 $\Delta_{k+1} = \gamma_{inc}\Delta_k$ (。我们知道，由于 $k \in \mathcal{S}_+$，因此在执行步骤 5 之后有 $\Delta_{k+1}^{icb} = \gamma_{inc}\Delta_k$。然而，$\Delta_{k+1}^{icb}$ 可能在第 $(k+1)$ 次迭代（或任何后续迭代）的步骤 1 期间被减小。通过检查步骤 1 末尾的赋值，我们看到在任何迭代 $k+1 \in \mathcal{K}$ 中，半径 Δ_{k+1}^{icb} 仅在 $\Delta_{k+1} \geq \beta\tilde{\sigma}_{k+1}^m = \beta\sigma_{k+1}^m \geq \beta\epsilon$ 时被减小，但由于 $\Delta_k \to 0$，这只能发生有限次。因此，对于足够大的 $k \in \mathcal{K} \cap \mathcal{S}_+$，我们得到 $\Delta_{k+1} = \gamma_{inc}\Delta_k$。

设 $\mathcal{S}_+^i = [k_i\,, \ell_i - 1] \cap \mathcal{S}_+ = \{j_i^1\,, j_i^2\,, \ldots, j_i^*\}$ 为落在区间 $[k_i\,, \ell_i - 1]$ 内的所有成功迭代的索引集合。根据在成功迭代时更新 Δ_k 的方案，以及模型改进步骤中 $x_k = x_{k+1}$ 和 $\Delta_{k+1} = \Delta_k$ 的事实，我们可以推断出，对于足够大的 i，

$$\|x_{k_i} - x_{\ell_i}\| \leq \sum_{j\in\mathcal{S}_+^i} \Delta_j \leq \sum_{j\in\mathcal{S}_+^i} \left(\frac{1}{\gamma_{inc}}\right)^{j_i^*-j} \Delta_{j_i^*} \leq \frac{\gamma_{inc}}{\gamma_{inc}-1}\Delta_{j_i^*}.$$

因此，从 $\Delta_{j_i^*} \to 0$ 这一事实，我们得出 $\|x_{k_i} - x_{\ell_i}\| \to 0$。由此我们得到

$$\lim_{i\to+\infty} \|x_{k_i} - x_{\ell_i}\| = 0.$$

现在

$$\sigma(x_{k_i}) = \big(\sigma(x_{k_i}) - \sigma(x_{\ell_i})\big) + \Big(\sigma(x_{\ell_i}) - \sigma_{\ell_i}^m\Big) + \sigma_{\ell_i}^m.$$

由于$\sigma(x)$的利普希茨连续性，右侧第一项趋于零，因此对于足够大的i，它被ϵ所界。根据(10.41)，第三项被ϵ所界。对于第二项，我们利用这样一个事实：由(10.40)和迭代ℓ_i处的临界步（步骤1）的机制，模型m_{ℓ_i}在$B(x_{\ell_i}$上完全二次；$\mu\sigma^m_{\ell_i})$。利用(10.31)和(10.41)，我们还推导出对于足够大的i)，第二项被$\kappa_\sigma\mu\epsilon$ (所界。因此，从这些界和(10.40)我们得到

$$\sigma(x_{k_i}) \le (2+\kappa_\sigma\mu)\epsilon \le \frac{1}{2}\epsilon_0$$

对于足够大的 i，这与(10.39)矛盾。因此，我们最初的假设必定是错误的，定理得证。 □

10.7 较大同心球体中的模型精度

接下来我们将证明，如果模型在关于某些（足够大的）常数κ_{ef}、κ_{eg}、ν_1^m，以及对于某些$\bar\Delta \in (0, \Delta_{max}]$下，在$B(x;\bar\Delta)$上完全线性，那么对于任意$\Delta \in [\bar\Delta, \Delta_{max}]$，它也在$B(x;\Delta)$上完全线性，且具有相同的常数。这一结果在本章分析信赖域方法的全局收敛性质时是必需的。这样的性质再现了泰勒模型的已知情况，并清楚地表明了完全线性模型定义的恰当性。

引理 10.25。*Consider a function f satisfying Assumption* 6.1 *and a model m fully linear, with respect to constants κ_{ef}, κ_{eg}, and ν_1^m on $B(x;\bar\Delta)$, with $x \in L(x0)$ and $\bar\Delta \le \Delta_{max}$.*

Assume also, without loss of generality, that κ_{eg} is no less than the sum of $\nu_1^m$and the Lipschitz constant of the gradient of f, and that $\kappa_{ef} \ge (1/2)\kappa_{eg}$.

Then m is fully linear on $B(x;\Delta)$, for any $\Delta \in [\bar\Delta, \Delta_{max}]$, with respect to the same constants κ_{ef}, κ_{eg}, and ν_1^m.

Proof. 我们首先考虑任意的 $\Delta \in [\bar\Delta, \Delta_{max}]$。然后我们考虑一个 s，使得 $\bar\Delta \le \|s\| \le \Delta$，并令 $\theta = \bar\Delta/\|s\|$。由于 $x+\theta s \in B(x;\bar\Delta)$ 以及模型在 $B(x$ 上完全线性；$\bar\Delta)$，我们得到

$$\|\nabla f(x+\theta s) - \nabla m(x+\theta s)\| \le \kappa_{eg}\bar\Delta.$$

通过利用 ∇f和 ∇m 的利普希茨连续性，以及假设 κ_{eg} 不小于相应利普希茨常数之和，我们推导出

$$\|\nabla f(x+s) - \nabla f(x+\theta s) - \nabla m(x+\theta s) + \nabla m(x+s)\| \le \kappa_{eg}(\|s\| - \bar\Delta).$$

因此，通过结合上述表达式，我们得到

$$\|\nabla f(x+s) - \nabla m(x+s)\| \le \kappa_{eg}\|s\| \le \kappa_{eg}\Delta. \tag{10.42}$$

在证明的第二部分，我们考虑函数 $\phi(\alpha) = f(x+\alpha s) - m(x+\alpha s),\ \alpha \in [0,1]$。我们要界定 $|\phi(1)|$。由 m 是 $B(x$ 上的完全线性模型；$\bar\Delta)$，我们得到 $|\phi(\theta)| \le \kappa_{ef}\bar\Delta^2$。为了界定 $|\phi(1)|$，我们先通过以下方式界定 $|\phi(1) - \phi(\theta)|$：

使用（10.42）：

$$\left|\int_\theta^1 \phi'(\alpha)d\alpha\right| \le \int_\theta^1 \|s\|\|\nabla f(x+\alpha s)-\nabla m(x+\alpha s)\|\,d\alpha$$
$$\le \int_\theta^1 \alpha\kappa_{eg}\|s\|^2 d\alpha \;=\; (1/2)\kappa_{eg}(\|s\|^2-\bar\Delta^2).$$

使用假设$\kappa_{ef} \ge (1/2)\kappa_{eg}$，我们最终得到

$$|f(x+s)-m(x+s)| \;\le\; |\phi(1)-\phi(\theta)|+|\phi(\theta)| \;\le\; \kappa_{ef}\|s\|^2 \;\le\; \kappa_{ef}\Delta^2. \quad \square$$

与线性情况类似，我们现在将证明，如果模型在 $B(x;\ \bar\Delta)$ 上关于某些（足够大的）常数 κ_{ef}、κ_{eg}、κ_{eh} 和 ν_2^m 以及某些$\bar\Delta \in (0、\ \Delta_{max}]$ 是完全二次的，那么它在 $B(x;\ \ \Delta)$ 上对于任意 $\Delta \in [\bar\Delta, \Delta_{max}]$ 也是完全二次的，且常数相同。

引理 10.26. *Consider a function f satisfying Assumption* 6.2 *and a model m fully quadratic, with respect to constants κ_{ef}, κ_{eg}, κ_{eh}, and ν_2^m on $B(x;$ $\bar\Delta)$, with $x \in L(x_0)$ and $\bar\Delta \le \Delta_{max}$.*

Assume also, without loss of generality, that κ_{eh} is no less than the sum of ν_2^m and the Lipschitz constant of the Hessian of f, and that $\kappa_{eg} \ge (1/2)\kappa_{eh}$ and $\kappa_{ef} \ge (1/3)\kappa_{eg}$.

Then m is fully quadratic on $B(x;\ \Delta)$, for any $\Delta \in [\bar\Delta, \Delta_{max}]$, with respect to the same constants κ_{ef}, κ_{eg}, κ_{eh}, and ν_2^m.

Proof. 让我们考虑任意 $\Delta \in [\bar\Delta, \Delta_{max}]$。同时考虑一个 s，使得$\bar\Delta \le \|s\| \le \Delta$，并令 $\theta = (\bar\Delta/\|s\|)$。由于 $x+\theta s \in B(x;\ \bar\Delta)$，那么，由于模型在 $B(x$ 上完全二次；$\bar\Delta)$，我们知道

$$\|\nabla^2 f(x+\theta s)-\nabla^2 m(x+\theta s)\| \;\le\; \kappa_{eh}\bar\Delta.$$

由于$\nabla^2 f$和$\nabla^2 m$是Lipschitz连续的，且κ_{eh}不小于相应Lipschitz常数之和，我们有

$$\|\nabla^2 f(x+s)-\nabla^2 f(x+\theta s)-\nabla^2 m(x+\theta s)+\nabla^2 m(x+s)\| \;\le\; \kappa_{eh}(\|s\|-\bar\Delta).$$

因此，通过结合上述表达式，我们得到

$$\|\nabla^2 f(x+s)-\nabla^2 m(x+s)\| \;\le\; \kappa_{eh}\|s\| \;\le\; \kappa_{eh}\Delta. \tag{10.43}$$

现在让我们考虑向量函数 $g(\alpha) = \nabla f(x+\alpha s)-\nabla m(x+\alpha s)$、$\alpha \in [0,1]$。由 m 在 $B(x$ 上是一个完全二次模型这一事实；$\bar\Delta)$ 我们有 $\|g(\theta)\| \le \kappa_{eg}\bar\Delta^2$。我们感兴趣的是界定 $\|g(1)\|$，这可以通过首先界定 $\|g(1)-g(\theta)\|$ 来实现。通过逐分量应用积分中值定理，我们得到

$$\|g(1)-g(\theta)\| \;=\; \left\|\int_\theta^1 g'(\alpha)d\alpha\right\| \;\le\; \int_\theta^1 \|g'(\alpha)\|d\alpha.$$

现在使用(10.43)，我们有

$$\int_\theta^1 \|g'(\alpha)\|d\alpha \le \int_\theta^1 \|s\|\|\nabla^2 f(x+\alpha s) - \nabla^2 m(x+\alpha s)\|\, d\alpha$$
$$\le \int_\theta^1 \alpha\kappa_{eh}\|s\|^2 d\alpha \;=\; (1/2)\kappa_{eh}(\|s\|^2 - \bar{\Delta}^2).$$

因此，从 $\kappa_{eg} \ge 1/2\kappa_{eh}$ 我们得到

$$\|\nabla f(x+s) - \nabla m(x+s)\| \;\le\; \|g(1) - g(\theta)\| + \|g(\theta)\| \;\le\; \kappa_{eg}\|s\|^2 \;\le\; \kappa_{eg}\Delta^2. \quad (10.44)$$

最后，我们考虑函数 $\phi(\alpha) = f(x+\alpha s) - m(x+\alpha s), \alpha \in [0,1]$。由 m 是 $B(x$ 上的完全二次模型这一事实；$\bar{\Delta})$，我们有 $|\phi(\theta)| \le \kappa_{ef}\bar{\Delta}^3$。我们感兴趣的是界定 $|\phi(1)|$，这可以通过首先使用（10.44）界定 $|\phi(1) - \phi(\theta)|$ 来实现：

$$\left|\int_\theta^1 \phi'(\alpha)d\alpha\right| \le \int_\theta^1 \|s\|\|\nabla f(x+\alpha s) - \nabla m(x+\alpha s)\|\, d\alpha$$
$$\le \int_\theta^1 \alpha^2\kappa_{eg}\|s\|^3 d\alpha \;=\; (1/3)\kappa_{eg}(\|s\|^3 - \bar{\Delta}^3).$$

因此，从$\kappa_{ef} \ge (1/3)\kappa_{eg}$我们得到

$$|f(x+s) - m(x+s)| \;\le\; |\phi(1) - \phi(\theta)| + |\phi(\theta)| \;\le\; \kappa_{ef}\|s\|^3 \;\le\; \kappa_{ef}\Delta^3.$$

证明完毕。 □

10.8 信赖域子问题

关于当模型函数为二次函数时，信赖域子问题(10.2)如何在 ℓ_∞ 和 ℓ_2 信赖域范数下或多或少精确求解的广泛而详细的分析，见[57，第7章]。当然，与近似解(例如满足假设10.1和10.2的解)相比，这会带来一定的计算成本，但特别是在维度适中的领域背景下，如在无导数优化中可能预期的那样，由于期望更快的收敛速度，额外的工作有时很可能是值得的。尽管我们不会深入到同样详细的程度，但至少指出如何求解更流行的 ℓ_2-范数信赖域子问题似乎是合适的。

基本的驱动因素，正如对于这样一个相对简单的问题所预期的那样，是最优性条件。然而，对于这个特别结构化的问题，我们拥有的远不止一阶必要条件，我们能够刻画一个（可能）非凸问题的全局解。

定理 10.27。*Any global minimizer s_* of $m(x+s) = m(x) + s^\top g + \frac{1}{2}s^\top Hs$, subject to $\|s\| \le \Delta$, satisfies the equation*

$$[H + \lambda_* I]s_* \;=\; -g, \quad (10.45)$$

where $H+\lambda_* I$ is positive semidefinite, $\lambda_* \geq 0$, and

$$\lambda_*(\|s_*\| - \Delta) \;=\; 0. \tag{10.46}$$

If $H+\lambda_* I$ is positive definite, then s_* is unique.

如果 Δ 足够大且 H 正定，则互补条件 (10.46) 在 $\lambda_* = 0$ 时得到满足，且无约束最小值位于信赖域内。在所有其他情况下，解位于信赖域的边界上且 $\|s_*\| = \Delta$。假设 H 有一个特征分解

$$H \;=\; QEQ^\top,$$

其中 E 是特征值 $\lambda_1 \leq \lambda_2 \leq \cdots \leq \lambda_n$ 的对角矩阵，而 Q 是相关特征向量的正交矩阵。那么

$$H+\lambda I \;=\; Q(E+\lambda I)Q^\top.$$

定理10.27表明，我们所寻求的λ的值必须满足$\lambda \geq -\lambda_1$ (，因为只有这样$H+\lambda I$才是半正定的)，并且，如果$\lambda > -\lambda_1$，模型最小化点是唯一的（因为这确保了$H+\lambda I$是正定的）。

假设 $\lambda > -\lambda_1$。那么 $H+\lambda I$ 是正定的，因此 (10.45) 有唯一解，

$$s(\lambda) \;=\; -[H+\lambda I]^{-1} g = -Q(E+\lambda I)^{-1}Q^\top g.$$

然而，我们所寻找的解依赖于非线性不等式

$$\|s(\lambda)\| \;\leq\; \Delta.$$

现在

$$\|s(\lambda)\|^2 \;=\; \|Q(E+\lambda I)^{-1}Q^\top g\|^2 \;=\; \|(E+\lambda I)^{-1}Q^\top g\|^2 \;=\; \sum_{i=1}^{n} \frac{\gamma_i^2}{(\lambda_i+\lambda)^2},$$

其中 γ_i 是 $(Q^\top g)_i$，即 $Q^\top g$ 的第 i 个分量。现在显然，如果 $\lambda > -\lambda_1$，那么 $\|s(\lambda)\|$ 是 $(-\lambda_1, +\infty)$ 上关于 λ 的连续非增函数，且当 λ 趋于 $+\infty$ 时趋于零。此外，若 $\gamma_j \neq 0$，则 $\lim_{\lambda \to -\lambda_j} \|s(\lambda)\| = +\infty$。因此，若 $\gamma_1 \neq 0$，则对于唯一的 $\lambda \in (-\lambda_1$ 值，有 $\|s(\lambda)\| = \Delta$，即 $+\infty)$。

当 H 是正定的且 $\|H^{-1}g\| \leq \Delta$ 解对应于 $\lambda = 0$ 时，正如我们已经提到的。否则，当 H 是正定的且 $\|H^{-1}g\| > \Delta$ 时，在 $(0, +\infty)$ 中存在 (10.45) 的唯一解。

当 H 非正定且 $\gamma_1 \neq 0$ 时，我们需要找到一个满足 $\lambda > -\lambda_1$ 的 (10.45) 的解。由于 $-\lambda_1$ 邻域内的高度非线性，求解所谓的久期方程变得更为可取

$$\frac{1}{\|s(\lambda)\|} \;=\; \frac{1}{\Delta},$$

在最优 {v*} 附近近似线性。由于感兴趣区域内的近似线性，期望牛顿法快速收敛是合理的。

但是，众所周知，未加保护的牛顿法可能无法收敛，因此必须谨慎和巧妙地保护该方法。

当 H 不是正定的且 $\gamma_1 =$ 为 0 时，我们称之为硬情况，因为当 $\Delta > \| s(-\lambda_1)\|$ 时，在 $(-\lambda_1, +\infty)$ 中 (10.45) 无解。然而，在 $\lambda = -\lambda_1$ 处存在一个解，但它包含 H 对应于特征值 λ_1 的特征向量，因此必须对其进行估计。

读者可参考[57]了解所有（大量的）细节。一个更易于获取但不太完整的参考文献是[178，第4章]。

10.9 其他注释与参考文献

信赖域方法从其发展之初就是为了处理二阶偏导数缺失的情况并融合拟牛顿技术而设计的。在 *region of validity* 内最小化二次插值模型的想法可以追溯到1969年的Winfield [227, 228]。Glad和Goldstein [106]也提出通过由 $D_{\oplus}$ 的正整数组合定义的集合上的采样来获得回归二次模型并最小化，正如方向直接搜索方法那样。然而，当一阶和二阶偏导数都不可用且难以直接近似时，针对无导数优化的信赖域方法的设计与分析是一个相对较新的课题。Powell在1994年第五届斯德哥尔摩优化日和1996年第五届SIAM优化会议上首次提出了这些方向上的尝试，使用了二次插值。Conn和Toint [58]在1996年报告了二次插值模型令人鼓舞的数值结果。大约在同一时间，Elster和Neumaier [88]开发并分析了一种基于在箱型网格上采样构建的信赖域内最小化二次回归模型的算法，同样报告了良好的数值结果。

Conn、Scheinberg 和 Toint [59]（另见 [57]）引入了临界性步骤，并设计并分析了首个基于插值的无导数信赖域方法，该方法全局收敛到一阶临界点。本章中讨论的大多数其他问题，包括完全线性与完全二次模型的适当引入、当迭代点接受基于目标函数的简单下降时的全局收敛性，以及二阶临界点的全局收敛性，均由 Conn、Scheinberg 和 Vicente [62] 处理。该论文首次全面分析了信赖域无导数方法收敛到二阶稳定点的全局收敛性。[57] 中提到，此类分析可以简单地从基于导数情形的经典分析推导而来。然而，正如本章中所指出的，[57, 59] 中的算法并不像本章所描述的算法那样接近实用算法，而且，将“经典”基于导数的收敛性分析调整到无导数情形的细节并不像人们预想的那样简单，即使不考虑算法中额外的“实用”改动。正如我们在第 10.5 节和第 10.6 节中所见，并不需要在每次成功迭代时都增大信赖域半径，而经典基于导数的方法正是这样做的，以确保到二阶临界点的 lim 型全局收敛性（即使迭代点基于目标函数的简单下降而被接受）。事实上，正如这些章节所描述的，在二阶分析的情形中，信赖域仅当其远小于平稳性度量时才需要增大，以便在当前迭代点远离稳定点且信赖域半径较小时允许较大的步长。

其他作者也已探讨相关问题。Colson [55]以及Colson和Toint [56]展示了如何在基于插值的信赖域方法的开发与实现中利用函数的部分可分离性。Marazzi和Nocedal [163]的楔形算法以及Powell [191]的最小Frobenius范数更新算法将在第11章详细讨论。

最后，我们要指出，基于导数的信赖域方法已在梯度值的非精确性[51, 57]和函数值的非精确性[57]的影响下进行了分析。特别是在无导数情况下，函数值的非精确性的影响也是相关的，因为目标函数可能受到噪声或不精确性的影响。

10.10 练习

1. 证明当H_k具有负特征值时，s_k^{E}是二次模型$m_k(x_k+s)$沿该方向且在信任区域B(0内的最小化点； Δ_k)。

2. 证明如果 s_k 满足最优下降条件的一部分，

$$m_k(x_k) - m_k(x_k + s_k) \geq \kappa_{fod}[m_k(x_k) - m_k(x_k + s_k^*)],$$

其中 $\kappa_{fod} \in (0, 1]$，且 s_k^* 是 (10.2)) 的最优解，那么它也满足 (10.14)。

3. 证明当迭代序列有界时，定理10.12（相应地，定理10.23）意味着迭代序列 $\{x_k\}$存在一个极限点，该极限点是一阶（相应地，二阶）驻点。

4. 证明引理10.16。

第11章

基于信赖域插值的方法

11.1 常见特性与考量

在本章中，我们介绍几种基于第10章所述信赖域框架的无导数优化的实用算法。尽管原始算法与这里所呈现的内容有所不同，但我们力求保留我们认为的主要区别性思想，同时将算法塑造成尽可能接近第10章中收敛框架的形式。这些算法的共同点是使用信赖域以及基于多项式插值的二次模型。算法之间的差异主要在于样本（插值）集的处理以及相应模型的构建。

以下是设计基于信赖域插值的无导数方法时需要回答的问题列表。我们将看到本章讨论的不同方法如何回答这些问题。

1. 样本集中应包含多少个点？我们知道，二次模型是理想的，但基于多项式插值的完全确定的二次模型需要（$n+1$）（$n+2$）/2 次函数评估。每一步都要求如此高的精度可能过于昂贵；因此，如第5章所述，基于较少的插值点构建模型可能是可取的。自然而然，另一个问题出现了：样本集中的点数应该在算法过程中保持静态还是应该动态变化？例如，第11.2节描述的算法允许点数动态变化，而第11.3节描述的算法要求样本集在每次迭代时恰好有 $p_1 \in [n+2,$（$n+1$）（$n+2$）/2] 个点，其中 p_1 在所有迭代中固定。

2. 样本集是否应在 $B(x_k$ 中保持 Λ 姿态；每次迭代时是否应保持 $\Delta_k)$ 姿态，如果不是，这一要求应如何放宽？为了强制满足 Λ 姿态性，即使只是偶尔，也需要制定一个接受点到样本集中的准则。该准则通常基于某个阈值。应选择什么阈值，以及如果选择不当，应在何时、如何改进？如果阈值选择得过于严格，可能无法找到合适的样本集，而如果它

选择得过于宽松的话，得到的集合可能位置不佳。这里我们将依赖于第6章的内容。

3. 样本集是否应始终包含在 $B(x_k;\, \Delta_k)$ 中？第10章中的框架假定如此，[18] 但每当迭代点变化或信赖域半径减小时，这可能要求重新计算过多的样本点。因此，在实际算法中，样本集位于当前信赖域内的要求可以放宽。在这种情况下，它可以被限制在 $B(x_k; r\Delta_k)$ 内，并带有某个固定的 $r \geq 1$，或者可以完全不受限制，但以这样的方式更新：每当适当时，远离 x_k 的点被 $B(x_k;\, \Delta_k)$ 中的点替换。

4. 第10章的框架允许我们接受新的迭代点，只要达到任何程度的减少且模型足够好，通过在第10.1和10.3算法的记号中设置$\eta_0 = 0$。在本章讨论的所有算法中，我们将允许基于简单减少条件接受新的迭代点，因为这是无导数算法普遍希望具备的特性。然而，这些算法中的每一个都可以轻易修改为仅基于充分减少条件接受新的迭代点。

11.2 “DFO”方法

本节描述的算法利用了书中为证明全局收敛性而开发的机制。它将依赖于第6章和第10章的材料。以下是该算法的主要区别特征，由Conn、Scheinberg和Toint [59, 61]开发，被称为“DFO”（无导数优化）。

1. 它利用了尽可能多的样本点（最多可达$(n+1)(n+2)/2$）满足Λ- poisedness准则（如下所述）。换言之，样本集Y_k中的点数是动态变化的。

2. 该模型是第5.3节（开头）描述的最小 Frobenius 范数二次插值模型。

3. 它始终在 $B(x_k$ 中维护一个 Λ 平衡的样本点集；$r\Delta_k)$ (在线性或最小 Frobenius 范数插值意义下或二次插值意义下)，其中 r 是大于或等于 1 的小缩放因子。将 $r \geq$ 设为 2 使算法更实用，因为它允许样本点在当前迭代移动或信赖域半径减小时仍保留在当前样本集中若干次后续迭代。

4. [59]中描述的原始算法依赖于NFP来测量并维持样本集的Λ-平衡性。但所使用的模型改进算法与第6章描述的枢轴算法非常相似。在本节中，我们讨论一种依赖枢轴算法来维护其样本集的全局收敛版本。

[18] The presentation of Chapter 10 could have been adapted to handle the case where the sample set is contained in $B(x_k; r\Delta_k)$, with $r > 0$ a constant fixed across all iterations.

5. 在每次迭代中，“DFO”算法通过以下步骤更新样本集 {v*}，这些步骤依赖于第6.3节中描述的关键算法（算法6.4、6.5和6.6）：

(i) 在算法开始时，选择两个不同的阈值：$0 < \xi_{\text{acc}} < 1/4$ 用于将一个点接受到插值集中，$\xi_{\text{imp}} > 1$ 用于改进当前插值集。ξ_{acc} 的值通常小于0.1。主元多项式被优化的区域是一个以当前迭代点为中心、半径为 Δ_k 的球体。如果我们用单项式基启动算法6.4、6.5和6.6，那么第一个主元的值总是1；因此，与第一个主元关联的是哪个插值点无关紧要。给定任何包含当前迭代点 x_k 的插值点集合（可能不是 poised 的），算法可以将 x_k 分配给第一个主元，然后选择剩余的点，使得结果集合是 Λ-poised 的。这保证了当前迭代点（以及信赖域的中心）总是可以被包含在良好 poised 的样本集中。

(ii) 考虑在信赖域最小化步骤中生成的一个样本点 $x_k + s_k$。如果该点使得目标函数减小（参见下文算法11.1的第3步），那么它将成为新的迭代点。信赖域的中心被移动，并且算法6.5被应用（阈值为 ξ_{acc}）于所有位于以 $x_k + s_k$ 为中心、半径为 $r\Delta_k$ 的球内的可用样本点。此过程将要么选择一组最多包含 $(n+1)(n+2)/2$ 个点的良好分布集，要么因缺乏合适的样本点而提前终止。

(iii) 如果新点 $x_k + s_k$ 没有使目标函数下降（参见下文算法11.1的第3步），那么将其加入插值集可能仍然是可取的，因为它带来了旧模型显然未能提供的信息。此外，可能代价高昂的函数求值已经完成。因此，我们只需将 $x_k + s_k$ 加入 Y_k 并应用算法6.5。如果最终新的 Y_k 中有些点未被使用，则将这些点丢弃。注意，可能会出现 $x_k + s_k$ 被丢弃且所得的 Y_k 与之前相同的情况。从算法全局收敛性的角度来看，这是可以接受的。从实践的角度来看也是可以接受的，因为这种情况极少发生。为避免此类情况，可以在算法6.5中应用一些启发式方法。例如，当某个枢轴多项式在多个点上具有相近的绝对值时，可以对更接近当前迭代点的点给予一定的偏好。

(iv) 在计算了信赖域步骤后，若需进行模型改进步骤，则仅根据样本集的稳定性来计算新点。如果当前的插值集Y_k不完整（对于线性或最小Frobenius范数插值或二次插值，取决于所需精度），则应用算法6.4的一步来最大化相应枢轴多项式的绝对值，并通过增加一个点来扩大插值集的大小。否则，我们应用算法6.6的一步来替换Y_k中的一个点。仅当最后一个枢轴多项式的值至少增加因子ξ_{imp}时，才接受替换。否则，认为模型改进步骤失败。

6. 关键算法假定插值点集总是经过平移和缩放，使其位于以原点为中心、半径为1的球内。因此，每当信赖域的中心或半径发生变化时，都必须引入新的平移和缩放，并针对新的平移和缩放后的集合计算枢轴多项式。然而，在实践中，每隔几次迭代才改变平移和缩放就足够了。这样，只要不发生平移和缩放，就可以简单地更新枢轴多项式集合，从而在插值集合规模较大时节省大量计算。

现在我们介绍修改后的“DFO”算法，适用于希望实现全局收敛到一阶驻点或二阶驻点的两种情况。根据第3至6章的理论，我们知道，如果一个模型基于至少包含 $n+1$ 个点（或 $(n+1)(n+2)/2$ 个点）在 $B(x_k;\ r\Delta_k)$ 中的 Λ- poised 集合，那么在 $B(x_k;\ r\Delta_k)$ 中，该模型是完全线性的（FL），或完全二次的（FQ）——定义6.1和6.2需要考虑信赖域半径因子 r。当我们能够保证一个模型是FL或FQ时，我们称该模型为可证明完全线性（CFL）或可证明完全二次（CFQ）。

算法11.1（改进的“DFO”算法）。

步骤 0（初始化）：选择一个初始点 x_0，一个最大半径 $\Delta_{max} > > 0$，以及一个初始信赖域半径 $\Delta_0 \in (\in (0, \Delta_{max}]$。选择一个集合 Y_0 并计算初始模型 $m_0(x)$。

常数 η_1、γ、γ_{inc}、ϵ_c、β 和 μ 也经过选择并满足条件 $\eta_1 \in (0,\ 1),\ 0 < \gamma < 1 < \gamma_{inc},\ \epsilon_c > 0$, 以及 $\mu > \beta > 0$。选择正的主元阈值 ξ_{acc} 和 ξ_{imp} 以及信赖域半径因子 $r \geq 1$。设 $k = 0$。

步骤1（关键步骤)）：此步骤与算法10.2或10.4中的相同，取决于所需的收敛结果。请注意，m_k、Y_k和Δ_k在此步骤过程中可能会发生变化。

步骤2（步长计算）：此步骤与算法10.1或10.3中相同。

步骤 3（试验点的接受）：检查 $m_k(x)$ 是否为 CFL/CFQ，若 Y_k 在 $B(x_k;r\Delta_k)$ 中至少包含 $n+1$ 个点，分别是 $(n+1)(n+2)/2$ 个点，则同样得到保证。

计算 $f(x_k+s_k)$ 并定义

$$\rho_k = \frac{f(x_k) - f(x_k+s_k)}{m_k(x_k) - m_k(x_k+s_k)}.$$

如果 $\rho_k \geq \eta_1$ 或如果 $\rho_k > 0$ 且模型为 CFL/CFQ，则 $x_{k+1} = x_k + s_k$。否则，模型和迭代保持不变（$x_{k+1} = x_k$）。应用上述第5(ii)项和第5(iii)项中描述的过程，以包含 $x_k + s_k$ 并更新样本集。令新的模型和样本集分别为 m_{k+1} 和 Y_{k+1}。

步骤4（模型改进）：如果$\rho_k < \eta_1$，则通过适当的改进步骤尝试模型改进（如上文5(iv)所述）。将m_{k+1}和Y_{k+1}定义为（可能改进后的）模型和样本集。

步骤5（信赖域半径更新）：此步骤与算法10.1或10.3相同。将k增加一，并转到步骤1。

算法说明

由于使用了算法6.4、6.5和6.6，并且Y_k仅包含那些在这些算法中提供可接受枢轴值的点，我们知道只要Y_k位于$B(x_k;\ r\Delta_k)$中，它总是对于某个未知但固定的Λ是Λ稳定的。不难观察到，模型改进过程在有限且一致有界的步骤数内生成一个插值集，该插值集对于线性或最小Frobenius范数插值或二次插值（取决于所需精度的选择）是Λ稳定的。根据第3-6章的内容，我们知道所使用的模型是FL或FQ，算法的其余部分与第10章讨论的框架紧密契合。对一阶或二阶稳定点的全局收敛性作为简单结论随之成立。

在算法的每次迭代中，仅生成一两个新样本点；因此至多需要进行两次函数评估。

该算法在每次迭代可使用的样本点数量方面非常灵活。事实上，很容易修改该算法以允许使用最小二乘回归模型。

除了函数求值和信赖域步之外，主要的计算工作在于计算枢轴多项式。通常，如果使用 $\mathcal{O}(n^2)$ 个点，那么枢轴算法可能需要 $\mathcal{O}(n^6)$ 次运算。通过尽可能保留和重用枢轴多项式，我们可以降低许多迭代的经验复杂度；然而，某些迭代仍可能需要大量的数值计算。对于较小的 n 值，这种计算量与一次函数求值的开销相比通常可以忽略不计。对于较大的 n 值，将每个模型的点数限制为 $\mathcal{O}(n)$ 是合理的。基于模型 Hessian 变化的最小 Frobenius 范数的模型在固定点数为 $\mathcal{O}(n)$ 时表现良好。在此类模型的背景下，自然使用最小 Frobenius 范数 Lagrange 多项式，这正是下一节所述算法所采用的方法。

11.3 鲍威尔方法

我们现在描述一种算法，它是对Powell在[188, 189, 190, 191, 192]中开发的算法的改进。我们将把Powell在实践中最为成功的算法的特点与第10章的信任域框架结合起来。Powell使用的信任域管理与本书所遵循的不同。特别是，信任域半径和插值集半径不相同，也不通过常数倍数相关联。虽然插值集的半径最终会收敛到零（理论上），但信任域半径允许保持远离零。在某些方面，双区域方法更接近于基于导数的优化的经典信任域方法（见[57]）。信任域半径保持远离零的原因是允许在接近最优时采取相对较大的步长，以实现超线性的局部收敛速度。这种选择对我们框架的理论含义是，要获得如定理10.13中的lim型全局收敛结果，需要对信任域步长施加充分下降条件。

接受。可以针对信赖域半径不收敛于零的情况陈述和分析第10章的框架，但我们将此留给感兴趣的读者。

事实上，Powell方法中的信赖域管理比简单地保持两个不同的半径更为复杂。两个半径中较小的一个还用于强制插值点之间保持足够远的距离，以避免函数值中噪声的影响。此外，信赖域更新步骤也比第10章框架中的步骤更为复杂。这些额外的机制是为了提高算法的实际性能而开发的。它们不会显著影响主要的全局收敛结果，但会使分析变得相当复杂。我们在此介绍Powell通过嵌入第10章框架中的最小Frobenius范数Lagrange多项式来处理插值集的方法。模型改进算法通过一个测试和一个可能的额外步骤得到增强，这有助于确保FL模型能够在有限且一致有界的步数内构造出来。关于原始Powell方法的完整细节，我们请读者参阅[188, 189, 190, 191, 192]，特别是他的UOBYQA [189]和NEWUOA [192]方法。以下是该算法的显著特征：

1. 所有迭代中的所有样本集包含 $p_1 \in [n+2, (n+1)(n+2)/2]$ 个点。值 $p_1 = 2n+1$ 是自然选择，也是 NEWUOA 软件包中的默认值 [192]。2. 模型是二次插值模型，其余自由度通过最小化模型 Hessian 中 *change* 的 Frobenius 范数来确定，相对于前一次迭代中使用的模型，如第 5.3 节（最后部分）所述。3. 样本集维护基于算法 6.3 修改而来，以处理第 6 章讨论的最小 Frobenius 范数拉格朗日多项式。

4. 无需涉及缩放，因为拉格朗日多项式会自动缩放。平移也没有任何影响。然而，相对于当前信任区域的中心平移点对于数值精度有重要影响，因此需要定期执行。

5. 原始鲍威尔算法中样本集的更新通过以下步骤进行：

(i) 最小 Frobenius 范数拉格朗日多项式集 $\ell_i(x), i = 0, \ldots, p$ 在每次迭代中保持不变。

(ii) 如果第k次迭代的信赖域最小化产生的步长s_k与样本点和当前迭代点之间的最大距离相比不算太短，则函数f在$x_k + s_k$处求值，并且如果f的减少量足够，或者只是正的且模型保证为FL，则新点成为下一次迭代x_{k+1}。模型m_k的质量在前一次迭代结束时确定。如果新点$x_k + s_k$被接受为新的迭代点，则通过移除点y^i将其包含到Y_k中，使得距离$\|x_k - y^i\|$和值$|\ell_i(x_k + s_k)|$在如下意义上都尽可能大。这两个目标之间的权衡通过最大化加权绝对值$w_i|\ell_i(x_k + s_k)|$来实现，其中w_i反映

距离 $\|x_k - y^i\|$。事实上，在[191]中，Powell提出优化定义Lagrange多项式的系统的秩二更新的系数，而不是最大化$|\ell_i(x_k + s_k)|$，以显式改善该系统的条件数。然而，使用Lagrange多项式的值可以达到相同的目的，并且使我们更容易使用第5章和第6章中发展的理论。

(iii) 当步骤 s_k 被拒绝时，新点 $x_k + s_k$ 仍然可以被接受进入 Y_k，通过移除使得值 $w_i|\ell_i(x_k + s_k)|$ 最大化的点 y^i，其中 w_i 反映了距离 $\|x_k - y^i\|$，只要满足 $|\ell_i(x_k + s_k)| > 1$ 或 $\|y^i - x_k\| > r\Delta_k$。

(iv) 如果目标函数的改进不够充分，并且认为模型需要改进，那么算法会在 Y_k 中选择一个离 x_k 最远的点，并尝试用信赖域（或在更小的插值集区域中，如 [188, 189, 190, 191, 192] 所做的那样）中相应拉格朗日多项式绝对值最大的点来替换它。

对于全局收敛性，我们需要临界步（见第10章），其中可能需要构建FL模型。这一步的类似做法可以在Powell的工作中找到，并且与当步长s_k远小于Δ_k时改进几何有关，这种情况发生在模型的梯度相对于Hessian较小时。这里我们使用与第10章全局收敛框架中所使用的相同步骤；也就是说，我们使用梯度的大小作为临界性检验。只要不允许任意小或任意大的缩放因子，也可以根据Hessian的大小进行缩放。修改后的算法如下所示。

算法11.2（基于最小Frobenius范数拉格朗日多项式的算法）。

步骤 0（初始化）：选择 $p_1 \in [n + 2, (n + 1)(n + 2)/2]$。选择一个初始点 x_0，一个最大半径 $\Delta_{max} > 0$，以及一个初始信赖域半径 $\Delta_0 \in (0, \Delta_{max}]$。选择信赖域半径因子 $r \geq 1$。选择一个具有基数 p_1 的良好平衡集 Y_0。计算与 Y_0 相关的最小 Frobenius 范数 Lagrange 多项式 $\ell_i(x), i = 0, \ldots, p$，以及相应的二次模型 m_0。为改进步骤选择一个正阈值，$\Lambda > \max\{|\ell_i(x)| : i = 0, \ldots, p, x \in B(x_0; \Delta_0)\}$。常数 $\eta_1, \gamma, \gamma_{inc}, \epsilon_c, \tau, \beta,$ 和 μ 也已给出，并满足条件 $\eta_1 \in (0, 1), 0 < \gamma < 1 < \gamma_{inc}, \epsilon_c > 0, 0 < \tau < 1,$ 和 $\mu > \beta > 0$。设置 $k = 0$。

步骤1（关键性步骤)：此步骤与算法10.1相同（模型改进算法依赖于最小Frobenius范数拉格朗日多项式）。注意，m_k、Y_k和Δ_k在此步骤过程中可能发生变化。

步骤2（步长计算）：该步骤与算法10.1中相同。

步骤3（试验点的接受）：如果$\|s_k\| \geq \tau \max\{\|y^j - x_k\|: y^j \in Y_k\}$，则计算$y^i$，其中$i \in \operatorname{argmax}_j\{w_j|\ell_j(x_k+s_k)|: y^j \in Y_k\}$和$w_j > 0$是权重，选择这些权重是为了优先考虑离$x_k$更远的点。

计算 $f(x_k+s_k)$ 并定义

$$\rho_k = \frac{f(x_k)-f(x_k+s_k)}{m_k(x_k)-m_k(x_k+s_k)}.$$

如果 $\rho_k \geq \eta_1$，或者如果 $\rho_k >$ 为0且已知 m_k 在 $B(x_k;\ r\Delta_k)$ 中是CFL，则设置 $x_{k+1}=x_k+s_k$。通过替换 y^i 将 x_k+s_k 包含到样本集 Y_{k+1} 中。否则，$x_{k+1}=x_k$，并且如果 $\|y^i-x_k\|>r\Delta_k$ 或 $|\ell_i(x_k+s_k)|>$ 为1，则通过替换 y^i 将 x_k+s_k 接受进样本集 Y_{k+1} 中。

步骤 4（模型改进）：（仅当步骤 3 之后的 $x_{k+1}=x_k$ 满足条件时执行此步骤。）选择 $y^i \in \operatorname{argmax}_j\{\|y^j-x_k\|:\ y^j \in Y_k\}$ 并找到一个新的 $y^i_* \in \operatorname{argmax}\{|\ell_i(x)|:\ x\in B(x_k;\ \Delta_k)\}$。如果 $\|y^i-x_k\|>r\Delta_k$ 或如果 $|\ell_i(y^i_*)|>\Lambda$，则将 Y_{k+1} 中的 y^i 替换为 y^i_*。否则，考虑距离 x_k 次远的点并重复该过程。如果最终在 Y_{k+1} 中找到一点 y^i，使得 $\max\{|\ell_i(x)|:\ x\in B(x_k;\ \Delta_k)\}>\Lambda$，则替换该点。如果未找到这样的点，则无需改进，因为 Y_k 在 $B(x_k;\ r\Delta_k)$ 中是 Λ-poised。因此，我们得出结论：基于 Y_{k+1} 的 m_{k+1} 在 $B(x_k;\ r\Delta_k)$ 中是 CFL。

步骤5（信赖域半径更新）：此步骤与算法10.1中相同。更新模型m_k以获得m_{k+1}，并重新计算最小Frobenius范数Lagrange多项式。将k增加1并转至步骤1。

算法说明

上述更新插值集的步骤足以保证FL模型可以在有限且一致有界的步数内构建，正如第10章收敛性分析所要求的那样。不难看出，模型改进步骤首先尝试替换任何距离当前迭代点过远的插值点（在$r\Delta_k$半径之外）。显然，这最多可在p步内完成。一旦所有插值点都足够接近，模型改进步骤就通过逐个最大化最小Frobenius范数拉格朗日多项式的绝对值来检查插值集的Λ-poisedness。如果该集合已经是Λ-poised的，则没有什么可改进的。如果该集合不是Λ-poised的，则替换集合中的一个点。我们从第6章和定理6.3可知，在经过有限且一致有界的步数之后，会在$B(x_k;\ r\Delta_k)$中获得一个Λ-poised集，因此也就获得了一个FL模型。注意，步骤3可能会改变插值集，但在信赖域步骤成功的情况下，（从理论角度看）这种改变对模型的影响并不重要。另一方面，当当前迭代点不改变时，步骤3所允许的Y_k变化可能只会改善Y_k的poisedness，或者用x_k+s_k替换Y_k中一个较远的点。因此，如果在不成功的步骤3开始时模型m_k是FL的，那么在步骤3结束时m_{k+1}也是如此；也就是说，不成功的步骤3只可能改进模型，而步骤4保证会在有限次迭代内产生一个FL模型。因此，我们得出结论：第10章（关于一阶稳定点）的全局收敛理论适用于算法11.2。

在Powell [189, 192]最初提出的方法中，模型改进步骤并没有显式检查$|\ell_i(y^i_*)|>\Lambda>1$；相反，模型改进步骤要复杂得多，但其目的是用位于以下范围内的点来替换旧插值点：

对相应的拉格朗日多项式给出大值的信赖域。此过程的特点之一是避免拉格朗日多项式的精确全局优化。现在考虑将一个插值点替换为另一个点，使得相应的拉格朗日多项式的绝对值超过 $\Lambda > 1$，而不是寻求该绝对值的精确全局最大值。从定理6.3证明后的讨论可知，这样的步骤能改善插值集的 poisedness。另一方面，我们不知道这样的替换步骤是否会导致模型改进算法在一致有界的有限步数内终止。可以修改模型改进算法，允许若干这样的“廉价”改进步骤，并仅当连续廉价步骤的最大次数被超过时才切换到全局优化。

在原始的Powell方法中，简单的下降步骤总是被接受为新的迭代点。在算法11.2中，我们也允许这样做，但仅当我们能保证构建模型m_k所基于的样本集Y_k在$B(x_k ; r\Delta_k)$中是Λ- poised时。因此，我们可能需要有一个额外的检查或一个标志，该标志可由步骤4设置，以表明手头有一个Λ- poised集。在多久执行一次这样的检查与多久可以接受一次简单下降之间存在权衡。确切实现是实际选择的问题。

虽然不能保证，但预期插值集在整个算法过程中只要能保持在 $B(x_k;\ r\Delta_k)$ 中，就能保持良好的平衡状态。实际上，可以从一个简单的良好平衡的插值集开始，例如 Powell 所使用的：

$$Y_0 = \{x_0, x_0 + \Delta e_1, \ldots, x_0 + \Delta e_n, x_0 - \Delta e_1, \ldots, x_0 - \Delta e_n\},$$

其中 e_i 是恒等式的第 i 个向量（注意这无非是使用正基 $D_\oplus$ 的（完全）轮询）。该集合的优点是，由于其特殊结构，构造最小 Frobenius 范数 Lagrange 多项式的初始集合需要 $\mathcal{O}(n^2)$ 次运算 [192]。

11.4 楔形方法

到目前为止，本章中我们考虑的两种方法密切相关，因为它们生成两种样本点：一种旨在降低函数值，另一种旨在提高样本集的平衡性。一个自然的问题是：是否有可能通过生成一种点同时实现这两个目标？这两个目标可能相互冲突，但是否有可能找到一个点，既能改善模型的值，又能保持可接受的平衡水平？基于这一思想，Marazzi和Nocedal在[163]中提出了一种算法。该算法遵循的方法是尝试生成点，这些点*simultaneously*为模型提供充分的下降（因此，希望为目标函数提供下降），并满足Λ-平衡条件。在每次迭代中，信任域子问题最小化通过一个额外约束得到增强，该约束不允许新点位于某个流形附近。这个流形由样本集的一个子集定义，该子集在给定迭代中是固定的，并允许所有包含固定样本点子集的可能的非平衡集。在原始方法中，定义与这种流形接近程度（在线性情况下）的约束具有楔形形状，因此该方法得名。为了为该方法的理论保证，我们必须替换

用“条形”约束代替“楔形”约束。我们将使用术语“楔形方法”来指代其来源。

令 Y_k 为迭代 k 时的插值集，并令 $m_k(x_k+s)$ 为基于 Y_k 的模型，

$$m_k(x_k+s) \;=\; m_k(x_k)+g_k^\top s+\frac{1}{2}s^\top H_k s.$$

在采取信赖域步之前，我们需要确定Y_k中的哪个点将被新点替换。注意，本章的另外两种方法先进行信赖域步，然后再决定用新点替换Y_k中的哪个点（如果合适的话）。为了选择要离开Y_k的点，我们使用以下算法，该算法是算法6.5和6.6的组合。

算法11.3（在$\boldsymbol{Y_k}$中选择出站点）。

我初始化：平移和缩放 Y_k，并考虑新集合$\hat{Y}_k=\{(y^i-x_k)/\Delta_k$、$i=0$、…、$p\}$。设置 $u_i(x)=\bar{\phi}_i(x)$、$i=0$、…、p。选择 $\xi>0$ 和 $r\geq 1$。假设$\hat{Y}_k$ 包含 p_1 个平衡点。设置 $i_k=p$。

对于 $i=0,\ \ldots,\ p-1$

1. 选择点：找到 $j_i=\operatorname{argmax}_{j\in\{i,\ldots,p\}:\,\|\hat{y}^j\|\leq r}|u_i(\hat{y}^j)|$。2. 接受点：如果 $|u_i(\hat{y}^{j_i})|<\xi$，那么 $i_k=i$ 并停止。否则，在集合$\hat{Y}_k$ 中交换点 $\hat{y}^i$ 和 $\hat{y}^{j_i}$。

3. 高斯消元法：对于 $j=i+1,\ \ldots,\ p$

$$u_j(x)\;\leftarrow\; u_j(x)-\frac{u_j(\hat{y}^i)}{u_i(\hat{y}^i)}u_i(x).$$

该算法选择$\hat{Y}_k$中位于$B(0;r)$内且主元值至少为ξ的点。它还计算前i_k个主元多项式。索引i_k是需要替换的第一个点的索引。根据算法的逻辑，这样的点要么不在$B(0;r)$内，要么不给出足够大的主元值。如果这样的点不存在，则$i_k=p$，并且算法11.3的结果类似于算法6.6一轮的结果；在这种情况下，$\hat{y}^p$只是一个适合被替换的好点。

算法11.3的目的是找出应当被替换的点，这些点要么是因为它们距离当前迭代点较远，要么是因为替换它们可能使$\hat{Y}_k$的平衡性更好。一旦确定了这样的点$\hat{y}^{i_k}$并计算出相应的枢轴多项式，就求解以下问题以产生信赖域步长：

$$\begin{aligned}\min_{s\in\mathbb{R}^n}\quad & m_k(x_k)+g_k^\top s+\tfrac{1}{2}s^\top H_k s\\ \text{s.t.}\quad & \|s\|\;\leq\;\Delta_k,\\ & |u_{i_k}(s/\Delta_k)|\geq\xi.\end{aligned}\tag{11.1}$$

上述问题对于足够小的ξ是可行的；因此存在最优解。然而，我们感兴趣的是近似解，该解是可行的并且满足柯西下降条件的分数（10.9）。我们将展示这样的解

对于足够小的 ξ，在楔形算法分析部分也存在。实际（近似）解决此类问题的方法可以在 [163] 中找到。我们在此不再重复细节，仅假设如果这样的解存在，那么它就能被找到。这可能需要大量的计算努力，但不需要对 f 进行任何函数评估，而这通常是无导数算法的主要关注点。

回想图3.4中展示的“理想”插值集示例。我们将该集合平移和缩放，使其位于$B(0; 1)$内。让我们应用算法6.5来构造枢轴多项式，然后考虑最后一个二次枢轴多项式的约束$|u_p(s/\Delta_k)| \geq \xi$。在图11.1中，我们可以看到当$\xi = 0.01$和$\xi = 0.1$时，该约束所丢弃的信任域区域。

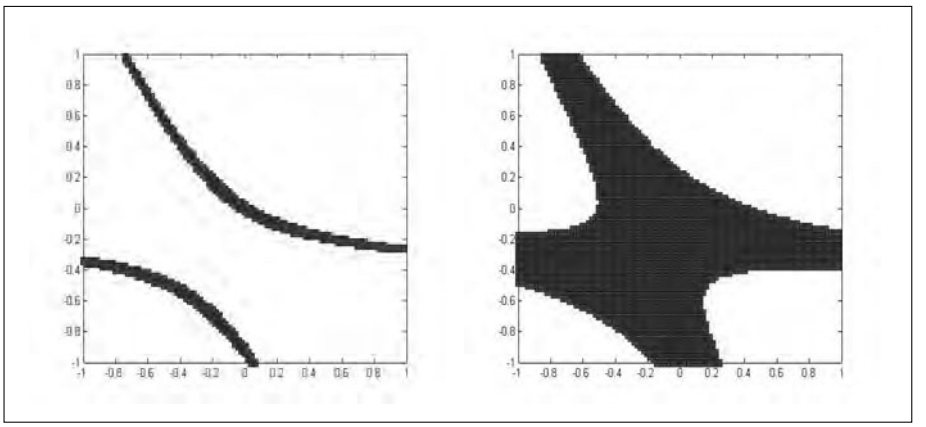


图 11.1. *Areas of the (squared) trust region which are forbidden by the wedge constraint* $|u_p(s/\Delta_k)| \geq \xi$ *for the cases* $\xi = 0.01$ *(left) and* $\xi = 0.1$ *(right). The example refers to the sample set of Figure* 3.4.

以下是该算法主要区别特征的总结。

1. 该算法最初在[163]中提出时，线性情况下恰好使用 $n+1$ 个点，而二次情况下使用 $(n+1)(n+2)/2$ 个点。虽然可以将其扩展至使用最小 Frobenius 范数模型，但此处我们不予展开。

2. 与前几节讨论的两种方法不同，在这种情况下，每次信赖域最小化步骤中，将离开Y_k的点被选择为*before*。

3. 我们在此提出的算法旨在保持一个 Λ 平衡的样本点集，只要这些点位于 $B(x_k$ ；$r\Delta_k)$ 中，且 $r \geq$ 为 1。由于使用了算法 11.3，并假设信任域子问题 (11.1) 能够成功求解，我们可以证明这样的步长可以在有限次迭代后获得（见下文第 5 点）。

原始楔形算法并不采用算法11.3；它只是选择离当前迭代点最远的点作为应被替换的点。为了使全局收敛理论适用，我们需要确保插值集在有限次迭代后能在$B(x_k;r\Delta_k)$中成为Λ- poised。

在可以减小信赖域半径之前（如果信赖域step不成功）的改进步骤。如果我们坚持所有插值点都位于$B(x_k;\ \Delta_k)$中，以便考虑模型FL或FQ，那么每次迭代点改变或信赖域减小时，我们都必须替换很多点。使r变大，例如$r \geq 2$，会使算法更实用。

4. 没有直接尝试改进几何形状，但有一种启发式方法可以更新样本集所需的平衡状态与模型中充分减少所需比例之间的平衡（见[163]）。

5. 如果算法11.3产生的i_k小于p，那么在带楔形约束的信任域步骤之后，新的Y_k可能不会在$B(x_k$中保持Λ平衡；$\Delta_k)$。然而，如果楔形信任域子问题被成功求解（即对于当前ξ_k的值找到了(11.1)的解，并且它满足柯西下降的一小部分），那么，如果x_k和Δ_k保持不变，则在下一次迭代中i_k增加1。因此，最终要么实现成功的信任域步骤，要么i_k等于p。在这种情况下，我们知道如果楔形信任域子问题(11.1)被成功求解，那么得到的新模型在$B(x_k$中是CFL或CFQ（取决于p）；$\Delta_k)$。注意在$B(x_{k+1}$中可能不是这样；$\Delta_{k+1})$，但是，除非通过信任域步骤获得目标函数的充分下降，$B(x_{k+1};\ \Delta_{k+1}) = B(x_k;\ \Delta_k)$并且确定获得CFL/CFQ模型。

6. 临界步对于全局收敛性质至关重要，正如本章中描述的其他两种算法的情况一样。临界步需要在当前迭代点周围足够小的球内提供一个FL/FQ模型。通过反复求解问题(11.1)可以构造这样的集合。然而，由于可能需要替换许多插值点，中间模型很可能不准确。一种更实用的方法是直接生成一个Λ平衡集，而不考虑模型下降，例如通过应用算法6.5。

我们提出了用于二次插值情形的改进楔形算法，但后续分析主要关注到一阶驻点的全局收敛性。

算法11.4（改进的楔形算法）。

步骤0（初始化）：选择一个初始点x_0，一个最大半径$\Delta_{max} > 0$，以及一个初始信赖域半径$\Delta_0 \in (0, \Delta_{max}]$。选择一个集合$Y_0$并计算初始模型$m_0(x)$。

常数 η_1、γ、γ_{inc}、ϵ_c、β 和 μ 也已给定，并且满足条件 $\eta_1 \in (0、1)$、$0 < \gamma < 1 < \gamma_{inc}$、$\epsilon_c > 0$ 和 $\mu > \beta > 0$。选择一个正的主元阈值 ξ_0、一个柯西下降系数 $0 < \kappa_{fcd} < 1$ 以及一个信赖域半径因子 $r \geq 1$。设 $k = 0$。

第1步（关键步骤)：此步骤与算法10.1相同（注意m_k、Y_k和Δ_k在此步骤过程中可能发生变化）。

步骤2（步长计算）：对Y_k应用算法11.3，以选择枢轴多项式$u_{i_k}(x)$。解决问题(11.1)以获得s_k。

步骤3（楔形管理）：检查新解是否满足柯西下降分数条件：

$$m_k(x_k) - m_k(x_k + s_k) \geq \frac{\kappa_{fcd}}{2} \|g_k\| \min\left\{ \frac{\|g_k\|}{\|H_k\|}, 1 \right\}.$$

如果是这样，令$y^{i_k} = x_k + s_k$并继续下一步。否则，通过减少$\xi_k \leftarrow \xi_k/2$来放宽楔形约束并返回步骤2。

步骤4（接受试验点）：计算$f(x_k + s_k)$并定义

$$\rho_k = \frac{f(x_k) - f(x_k + s_k)}{m_k(x_k) - m_k(x_k + s_k)}.$$

如果 $\rho_k \geq \eta_1$ 或如果 $\rho_k > 0$ 且 $Y_k \subset B(x_k;\ r\Delta_k)$，则 $x_{k+1} = x_k + s_k$。否则，$x_{k+1} = x_k$。

步骤 5（信赖域半径更新）：此步骤与算法 10.1 中相同。根据新的样本集 Y_k 更新模型 m_k。将 k 增加一，然后转到步骤 1。

算法说明

算法11.4每次迭代的计算工作量对于每个步骤2为$\mathcal{O}(p^3)$，此外还需加上解决楔形子问题的计算工作量。解决楔形子问题可能代价高昂。如果总的函数评估次数减少，那么这是合理的。Marazzi和Nocedal[163]报告了计算结果，显示该方法与其他无导数方法相当，但并没有特别显著的优势，而其他无导数方法，特别是Powell[192]的方法，最近有了显著改进。然而，我们注意到Marazzi和Nocedal的实现依赖于构建完整的二次模型，而不是最小Frobenius范数模型。后者在DFO和NEWUOA中使用，并且常常给基于信赖域插值的算法带来优势。因此，楔形方法的另一种实现可能会有更好的表现。

与其他我们上文讨论过的算法一样，楔形算法也有多种改进方式。例如，可以考虑替换Y_k中的多个不同点，并求解多个楔形信赖域子问题（11.1）实例，以在几何形状与模型下降之间获得最佳权衡。这会增加每次迭代的成本，但可能减少总体迭代次数，从而减少总体函数评估次数。

楔形算法在一阶情况下的有效性

我们描述了一种使用二次插值模型的楔形方法版本。然而，步骤1和步骤3表明，该方法仅试图实现全局收敛到一阶驻点。根据第10章的结果，我们可以得出结论，为了建立这样的收敛性，我们所需展示的仅仅是在有限且一致有界的失败迭代次数后能够达到FL模型。下面我们将展示，如果仅要求近似

(11.1) 的解，那么情况确实如此。此外，我们可以证明，在保持柯西下降比例要求的同时，也可以在有限且均匀有界的失败迭代次数内实现 FQ 模型。

然而，为了建立到二阶驻点的全局收敛性，仅满足柯西下降的比例是不够的，必须考虑最优下降比例(10.13)。因此，在步骤1和步骤3中必须应用二阶准则。这增加了证明的复杂性，并且正如我们将在本章末尾讨论的那样，需要在算法中引入额外的保障步骤。

考虑算法11.3的一步（这是第6章中描述的算法6.5的修改版）。回顾向量v，即在枢轴计算过程中计算的多项式$u_i(x)$的系数向量（相对于自然基$\bar{\phi}$）。我们知道$\|v\|_\infty \geq 1$。一般来说，我们知道对于任何$0 < \xi < 1/4$，存在$\hat{s}_k$使得$\|\hat{s}_k\| \leq 1$，并且$|v^\top \bar{\phi}(\hat{s}_k)| \geq \xi$ (见引理3.10和3.12)。下面分析的目的是证明存在一个常数$\xi > 0$，使得对于所有迭代，都能找到一个步长s_k同时满足以下条件：

- $\|s_k\| \leq \Delta_k$,
- s_k 提供至少固定比例的柯西下降量，对于 模型，
- $|v^\top \bar{\phi}(s_k/\Delta_k)| \geq \xi$。

由此可知，在经过有限且一致有界的失败迭代次数后，通过楔形方法可以使模型成为FL或FQ。

让我们考虑未缩放的信任域子问题，不考虑楔形约束。我们用“u”来索引未缩放问题的元素，并从此省略索引k：

$$\begin{aligned} \min_{s_u \in \mathbb{R}^n} \quad & c + g_u^\top s_u + \tfrac{1}{2} s_u^\top H_u s_u \;=\; m_u(s_u) \\ \text{s.t.} \quad & \|s_u\| \;\leq\; \Delta. \end{aligned}$$

如果我们将信赖域缩放到半径为1，则有

$$\begin{aligned} \min_{s \in \mathbb{R}^n} \quad & c + g^\top s + \tfrac{1}{2} s^\top H s \;=\; m(s) \\ \text{s.t.} \quad & \|s\| \;\leq\; 1, \end{aligned}$$

其中 $s = s_u/\Delta$、$g = \Delta g_u$ 和 $H = \Delta^2 H_u$。

注意，如果s满足形式为以下的分数阶柯西递减型条件的一部分

$$m(0) - m(s) \;\geq\; \frac{\kappa_{fcd}}{2} \|g\| \min\left\{ \frac{\|g\|}{\|H\|}, 1 \right\}, \tag{11.2}$$

那么 $s_u = \Delta s$ 也满足形式为

$$m_u(0) - m_u(s_u) \;\geq\; \frac{\kappa_{fcd}}{2} \|g_u\| \min\left\{ \frac{\|g_u\|}{\|H_u\|}, \Delta \right\}.$$

柯西步本身（定义为在 $-g$ 方向上并在信赖域内使 $m(s)$ 最小化的点）满足不等式 (11.2)，其中 $\kappa_{fcd} = 1$。

我们想要表明存在一个近似解对于该问题 问题

$$\begin{aligned} \min_{s\in\mathbb{R}^n} \quad & m(s) \\ \text{s.t.} \quad & \|s\| \le 1, \\ & |\phi(s)^\top v| \ge \xi > 0, \end{aligned} \tag{11.3}$$

使得 $m(s)$ 的减少量与 Cauchy 步获得的减少量的一个固定比例相当。ξ 的值尚未确定，但对于所有考虑的问题数据（即 v、g 和 H），它必须远离零有界。

让我们暂时转而考虑对于固定 $\kappa_{fcd} \in (0,1)$ 的以下问题：

$$\begin{aligned} \max_{s\in\mathbb{R}^n} \quad & |\phi(s)^\top v| \\ \text{s.t.} \quad & \|s\| \le 1, \\ & m(0) - m(s) \ge \tfrac{\kappa_{fcd}}{2}\|g\| \min\left\{\tfrac{\|g\|}{\|H\|}, 1\right\}. \end{aligned} \tag{11.4}$$

如果我们可以证明该问题的最优值始终高于一个正阈值$\xi_* > 0$，对于所有满足$\|v\|_\infty \ge 1$的向量v，以及对于所有向量g和对称矩阵H，那么我们就证明了对于问题(11.3)存在一个近似解，该解在$\xi > 0$足够小时满足柯西下降的一定比例。为此，我们需要证明多项式$\phi(s)^\top v$在(11.4)的可行集上几乎不消失。困难在于，当$\|g\|/\|H\| \to 0$时，(11.4)的可行集可能收敛到一个奇异点，在该点上适当选择的多项式可能会消失。我们将要证明的是，对于楔形算法过程中出现的问题(11.3)，始终有$0 < g_{min} \le \|g\|/\|H\|$，其中$g_{min} \in (0,1)$是一个固定常数。

回想$g = g_u\Delta$和$H = H_u\Delta^2$，这意味着

$$\frac{\|g\|}{\|H\|} = \frac{\|g_u\|}{\Delta\|H_u\|}.$$

根据模型海森矩阵有界性的标准假设，我们知道$\|H_u\| \le \kappa_{bhm}$。还要记得$\Delta \le \Delta_{max}$。修正楔形算法的关键性步骤确保每次在第2步求解楔形信赖域子问题时，我们都有$\|g_u\| \ge \min\{\epsilon_c,\ \mu^{-1}\Delta\}$，以及

$$\frac{\|g\|}{\|H\|} = \frac{\|g_u\|}{\Delta\|H_u\|} \ge g_{min}, \tag{11.5}$$

其中

$$g_{min} = \min\left\{\frac{\epsilon_c}{\Delta_{max}\kappa_{bhm}}, \frac{1}{\mu\kappa_{bhm}}\right\}.$$

现在我们证明，对于所有满足$g_{min}\|H\| \le \|g\|$的g和H，其中$g_{min} \in$(属于$0,1$)，同时实现良好的均匀几何形状和一定比例的Cauchy下降是可能的。

定理 11.1. *Let $g_{min} \in (0,1)$ be a given constant. There exists a positive constant ξ_* depending on both g_{min} and κ_{fcd} such that the optimal value of* (11.4) *satisfies*

$$\xi(v; g, H) \ge \xi_* > 0$$

for all vectors $v \in \mathbb{R}^p$ such that $\|v\|_\infty \geq 1$ and for all vectors $g \in \mathbb{R}^n$ and symmetric matrices $H \in \mathbb{R}^{n\times n}$ such that

$$g_{min} \leq \frac{\|g\|}{\|H\|}.$$

Proof. 我们首先定义

$$a(v;g,H) = \max\left\{|\phi(s)^\top v| : \|s\| \leq 1, \quad m(0)-m(s) \geq \frac{\kappa_{fcd}}{2}\|g\|\right\}$$

当 $\|g\| \geq \|H\|$ 和

$$b(v;g,H) = \max\left\{|\phi(s)^\top v| : \|s\| \leq 1, \quad m(0)-m(s) \geq \frac{\kappa_{fcd}}{2}\frac{\|g\|^2}{\|H\|}\right\}$$

当$g_{min}\|H\| \leq \|g\| \leq \|H\|$时。(11.4)的最优值由下式给出

$$\xi(v;g,H) = \begin{cases} a(v;g,H) & \text{when } \|g\| \geq \|H\|, \\ b(v;g,H) & \text{when } g_{min}\|H\| \leq \|g\| \leq \|H\|. \end{cases}$$

我们将证明以下最小值是可以达到的:

$$\min_{(v;g,H):\|v\|_\infty\geq 1,\ \|g\|\geq\|H\|} a(v;g,H) > 0.$$

我们可以进行变量替换$g' = g/\|g\|$和$H' = H/\|g\|$。因此，最小化$a(v;$ 在g中的g、$H)$，以及H，其中$\|g\| \geq \|H\|$，等价于最小化$a'(v;$ 在g'中的g'、$H')$，以及H'，其中$\|g'\| = 1$和$\|H'\| \leq 1$，这里

$$a'(v;g',H') = \max\left\{|\phi(s)^\top v| : \|s\| \leq 1, \quad -{g'}^\top s - \frac{1}{2}s^\top H's \geq \frac{\kappa_{fcd}}{2}\right\}.$$

由于 $-s^\top H's \geq -\|s\|^2$ 当 $\|H'\| \leq 1$ 且$\kappa_{fcd} < 1$ 时，对于任何 g' 和 H' 使得 $\|g'\| = 1$ 且 $\|H'\| \leq 1$，总是可以通过设置 $s = -tg'$ 来找到 s (，其中 t 略小于 1)，使得定义 $a'(v$ 的两个约束；g'，$H')$ 被严格满足。因此，可行集始终具有内部；从而可以在这个可行区域内内切一个球，其正半径连续依赖于 g 和 H。由于 g 和 H 在一个紧集上变化，内切球的半径也是如此。因此，存在一个最小正半径 r_a^*，使得定义 $a'(v;$ g'，$H')$ 的可行集始终包含一个该半径的球，比如 $B(x;\ r^*_a)$，对于某个依赖于 g' 和 H' 的 $x \in B(0;1)$。

与引理3.10的证明类似，我们可以证明存在$\xi_*^a > > 0$，使得

$$\min_{x\in B(0;1)} \max_{s\in B(x;r_a^*)} |v^\top\phi(s)| \geq \xi_*^a,$$

通过声称上述量是v上的范数。因此，$a'(v;\ g',\ H') \geq \xi_*^a$对于任意$v$，$g'$和$H'$，满足$\|v\|_\infty \geq 1$，$\|g'\| = 1$，且$\|H'\| \leq 1$。

我们还需要证明以下最小值是可以达到的:

$$\min_{(v;g,H):\|v\|_\infty\geq 1,\ g_{min}\|H\|\leq\|g\|\leq\|H\|} b(v;g,H) > 0.$$

再一次地，问题的结构似乎是有利的，因为 $m(0)-m(s)\geq(\kappa_{fcd}/2)\,\|g\|^2/\|H\|$ 等价于

$$-\left(\frac{g}{\|H\|}\right)^{\top}s-\frac{1}{2}s^{\top}\left(\frac{H}{\|H\|}\right)s\;\geq\;\frac{\kappa_{fcd}}{2}\frac{\|g\|^2}{\|H\|^2}.$$

在这种情况下，变量变换为 $g'=g/\|H\|$ 和 $H'=H/\|H\|$。因此，在 v、g 和 H 中最小化 $b(v,\ g,\ H)$，其中 $g_{min}\|H\|\leq\|g\|\leq\|H\|$，等价于在 v、g' 和 H' 中最小化 $b'(v,\ g',\ H')$，此时 $g_{min}\leq\|g'\|\leq 1$ 且 $\|H'\|=1$，其中

$$b'(v;g',H')\;=\;\max\left\{|\phi(s)^{\top}v|:\ \|s\|\;\leq\;1,\quad -{g'}^{\top}s-\frac{1}{2}s^{\top}H's\;\geq\;\frac{\kappa_{fcd}}{2}\|g'\|^2\right\}.$$

由于 $-s^{\top}H's\geq-\|s\|^2$ 当 $\|H'\|=1$ 且 $\kappa_{fcd}<1$ 时，对于任何满足 $g_{min}\leq\|g'\|\leq 1$ 和 $\|H'\|=1$ 的 g' 和 H'，总是可以通过设置 $s=-tg'$ 来找到 s (，其中 t 略小于 1) ，使得定义 $b'(v$ 的两个约束条件；g'、$H')$ 被严格满足。因此，定义 $b'(v;\ g'$、$H')$ 的问题的可行集总是有内点。因此存在一个最小半径 r_b^*，使得可行域总是包含至少具有该半径的球。对 $a'(v;\ g'$、$H')$ 重复上述论证，我们得出结论：存在 $\xi_*^b>0$，使得对于所有 v、g' 和 H'，满足 $\|v\|_\infty\geq 1$、$g_{min}\leq\|g'\|\leq 1$ 和 $\|H'\|=1$ 时，$b'(v;\ g'$、$H')\geq\xi_*^b$。

我们要找的ξ_*的值因此是

$$\xi_*\;=\;\min\left\{\xi_*^a,\xi_*^b\right\}\;>\;0.\quad\square$$

二阶情况下楔形算法的有效性

为了能够证明楔形方法的全局收敛性达到二阶临界点，首先需要将柯西下降比例要求加强为特征步下降比例要求。回顾缩放和未缩放的信赖域子问题，我们可以看出，如果 {v*} 满足形式如下的特征步下降类型的比例条件

$$m(0)-m(s)\;\geq\;\frac{\kappa_{fed}}{2}\max\{-\lambda_{\min}(H),0\},\tag{11.6}$$

则$s_u=\Delta s$也满足形如下的特征步长下降型条件的一部分

$$m_u(0)-m_u(s_u)\;\geq\;\frac{\kappa_{fed}}{2}\max\{-\lambda_{\min}(H_u),0\}\,\Delta^2.$$

当 $\lambda_{min}(H)\geq 0$ 时，任何满足 $m(0)\geq m(s)$ 的步 s，特别是柯西步，对于 $\kappa_{fed}>0$ 满足不等式 (11.6)。当 $\lambda_{min}(H)<0$ 时，特征步（定义为与 H 的最小特征值相关联的 H 的特征向量 u，适当缩放使得 $\|u\|=1$ 和 $u^{\top}g\leq 0$）满足不等式 (11.6)，其中 $\kappa_{fed}=1$。

二阶情况下问题(11.4)的类似形式是

$$\begin{aligned}\max_{s\in\mathbb{R}^n}\quad & |\phi(s)^{\top}v|\\ \text{s.t.}\quad & \|s\|\;\leq\;1,\\ & m(0)-m(s)\;\geq\;\tfrac{\kappa_{fcd}}{2}\|g\|\min\left\{\tfrac{\|g\|}{\|H\|},1\right\},\\ & m(0)-m(s)\;\geq\;\tfrac{\kappa_{fed}}{2}\max\{-\lambda_{min}(H),0\},\end{aligned}\tag{11.7}$$

带 $\kappa_{fcd},\ \kappa_{fed}\in(0,\ 1)$。

我们c一个展示定理11.1对二阶情况的扩展结果 您好，我注意到您的请求似

定理 11.2. *Let $\sigma_{min} \in (0, 1)$ be a given constant. There exists a positive constant ξ_* depending on σ_{min}, κ_{fcd}, and κ_{fed} such that the optimal value of* (11.7) *satisfies*

$$\xi(v; g, H) \geq \xi_* > 0$$

for all vectors $v \in \mathbb{R}^p$ such that $\|v\|_\infty \geq 1$ and for all vectors $g \in \mathbb{R}^n$ and symmetric matrices $H \in \mathbb{R}^{n\times n}$ such that

$$\sigma_{min} \leq \max\left\{\frac{\|g\|}{\|H\|}, \frac{-\lambda_{min}(H)}{\|H\|}\right\}. \tag{11.8}$$

然而，这个结果已经不够了，因为与一阶情况不同，无法保证定理11.2中的界 σ_{min} 存在。我们知道，在一阶情况下，由于临界步，缩放量 $\|g\|/\|H\|$ 被有界地远离零。在二阶情况下，我们从临界步得到的是

$$\max\left\{\frac{\|g\|}{\|H\|}, \frac{1}{\Delta}\frac{-\lambda_{min}(H)}{\|H\|}\right\} = \frac{\sigma_u^m}{\Delta\|H_u\|} \geq \min\left\{\frac{\epsilon_c}{\Delta_{max}\kappa_{bhm}}, \frac{1}{\mu\kappa_{bhm}}\right\}. \tag{11.9}$$

遗憾的是，涉及Δ的量，由$\max\{\|g\|/\|H\|, -\lambda_{\min}(H)/(\Delta\|H\|)\}$给出，其远离零的有界性并不意味着$\max\{\|g\|/\|H\|, -\lambda_{\min}(H)/\|H\|\}$的远离零有界性，而后者是定理11.2中所需要的。当Δ很小时，$\|g\|/\|H\|$和$H/\|H\|$的最负特征值可能同时趋近于零。在这种情况下，能够获得部分特征步下降的信赖域部分可能会缩小到内部为空的区域。这意味着多项式在这样的区域上可能几乎消失，因此，无法保证可以达到的枢轴值阈值。因此，算法11.4的步骤2中可能无法计算出任何能够实现部分特征步下降的步长。

为了更详细地展示这一点，我们假设在关键性步骤之后，有

$$g_u = \begin{bmatrix} 0 \\ \Delta^{\frac{3}{2}} \end{bmatrix} \quad \text{and} \quad H_u = \begin{bmatrix} -\Delta^{\frac{1}{2}} & 0 \\ 0 & 1 \end{bmatrix}.$$

我们可以看到，对于足够小的 Δ，$\Delta \leq \mu\sigma_u^m$ 成立，因为

$$\Delta \leq \mu \max\{\|g_u\|, -\lambda_{min}(H_u)\} = \mu\Delta^{\frac{1}{2}}.$$

由于 $\|H_u\| \leq$ 最大$\{\Delta_{max}^{\frac{1}{2}}, 1\}$，我们看到模型海森矩阵是有界的。现在，当我们考虑缩放量 $\|g\|$ 和 $\|H\|$ 时，对于 $\Delta \leq 1$，我们得到，

$$\frac{\|g\|}{\|H\|} = \frac{\|g_u\|}{\Delta\|H_u\|} = \Delta^{\frac{1}{2}}$$

和

$$\frac{-\lambda_{min}(H)}{\|H\|} = \Delta^{\frac{1}{2}},$$

因此，当 Δ 趋近于零时，(11.8) 的右侧收敛到零。因此，当前的临界步骤不能保证 $\max\{\|g\|/\|H\|, -\lambda_{min}(H)/\|H\|\}$ 存在正的下界。注意，如果 f 的 Hessian 矩阵在最优解处非奇异，那么在最优解附近的所有模型 Hessian 矩阵也是非奇异的，这种情况就不会发生。对于 Hessian 矩阵奇异的情况，可能需要设计一种不同的临界步骤，以提供必要的界，同时保持全局收敛所需的所有其他性质。

11.5 其他说明与参考文献

[59, 61]中描述的DFO算法由Scheinberg实现为一个开源软件包。UOBYQA [189]和NEWUOA [192]由Powell实现，并由作者分发。WEDGE是Marazzi的MATLAB® [1]实现的Wedge方法[163]，可免费下载。Berghen [33]和Berghen与Bersini [34]在并行环境中实现了Powell的UOBYQA算法[189]的一个版本。他们的代码称为CONDOR。这些软件包的网址在附录中给出。论文[34]还包含了UOBYQA、CONDOR和DFO之间的数值比较。Uğur等人[221]报告了CONDOR和DFO在实际应用中的数值结果。

Fasano、Morales和Nocedal [89] 研究了一种基于信赖域插值的算法性能，该算法不对样本点几何位置进行任何控制。他们报告称，当两种算法均使用由$(n+1)(n+2)/2$个点构建的二次模型时，与NEWUOA相比，数值结果良好。似乎尽管插值系统矩阵的条件数在迭代过程中显著增长，但它趋于稳定在可容忍的水平，算法能够朝着解的方向取得进展。然而，需要进一步研究以更好地理解这种行为，并且需要更多的测试，特别是在模型构建点数与n成线性关系的更实际场景中。

该领域仍然相当活跃，新的论文很可能不久就会出现（参见例如 Custódio、Rocha 和 Vicente [69] 以及 Wild [225]）。

第三部分

其他主题的回顾

第12章

代理模型管理综述

第12章和第13章简要介绍了与无导数优化相关但本书尚未涉及的问题。主要目的是系统地组织一系列相关主题，并提供一系列指向文献中适当深入描述这些材料的指针。为了简洁起见，我们必然会对一些问题过度简化。偶尔会提供稍多的细节，特别是当技术细节允许我们轻松说明我们希望强调的要点时。本章讨论代理建模和处理代理模型的严格优化框架。

12.1 代理建模

在工程建模中，经常遇到待优化函数的评估代价高昂的情况。待（近似）求解的问题可能需要对微分方程组进行大量模拟，这些方程组可能涉及不同学科，也可能涉及其他耗时的数值计算。在本书的记号中，真实函数用 $f(x)$ 表示，其中 $f\colon \mathbb{R}^n \to \mathbb{R}$ 。

工程师经常考虑真实函数的模型，实际上他们往往将问题本身视为一个模型，并用“真实模型”一词来指代我们所称的真实函数，然后将模型的模型视为代理模型。为了避免混淆各种模型，我们通常会继续使用“真实函数”这一术语来指代底层问题函数，而不是称它们为真实模型。代理模型可以有多种用途；特别是，它可以仅用于建模和分析，以便在无需大量昂贵评估的情况下获得对问题特征和行为的洞察。在我们的语境中更有趣的是，代理模型可以替代真实函数用于优化目的。一些无导数优化方法基于选择适当的、在某些方面本质上简单的模型作为真实函数的代理模型。代理模型通常不如真实函数准确或质量较低，但其评估成本更低或消耗的计算资源更少。对代理模型进行多次评估仍然可能比一次评估真实函数（真实模型）更便宜。我们将使用符号$sm(x)$表示代理模型，其中$sm\colon \mathbb{R}^n \to \mathbb{R}$。

按照其他作者的建议（特别是Serafini[206]和Søndergaard[209]在其博士论文中所采纳的），我们将采用（必然简化的）观点，将代理模型分类为*functional*或*physical*。接下来，我们将总结构建物理代理模型和功能代理模型的各种方法。更全面的综述见Keane和Nair[139]以及Søndergaard[209]。

物理替代模型

物理代理模型是指基于真实问题函数的物理或数值简化而构建的代理模型。例如，在数值偏微分方程中采用较粗的网格离散化，或对项源或方程进行线性化，都是获得物理代理模型的方式。另一种流行的方法是降基方法（参见，例如，[139]）。物理代理模型在许多情况下基于对被建模的物理系统或现象的一些知识，因此任何特定的此类模型都难以在不同问题之间加以利用。一些作者[43, 175]将其称为*mechanistic models*。

还有其他并非直接基于简化物理过程的方法，用于从具有物理意义的真实函数构建物理代理模型。这些方法通常涉及使用真实函数的信息（函数值或梯度）对可用代理模型进行某种形式的校正、缩放或对齐。一个例子是ρ相关法[118]。另一个更严谨的例子是空间映射法，将在第12.2节中简要描述。多点法[219]是一种通过将系统划分为多个独立子系统来生成物理代理模型的过程。

如果在物理代理模型中不使用真实函数的导数或导数的近似值，这些模型可能无法展现真实函数的趋势。在这种情况下，可能需要转而优化可能昂贵的无导数真实函数，这由于维数灾难而在计算上可能存在问题。

函数代理模型

另一方面，函数型代理模型是真实问题函数的代数表示。插值模型和回归多项式模型（见第3-5章）可归类为函数模型。可以说，函数模型通常基于以下组成部分：一类基函数、采样真实函数的过程、回归或拟合准则，以及一些确定性或随机性的数学技术来将它们综合起来。函数型代理模型具有与真实原始函数不同的数学本质。“真相”的知识并不直接体现在其数学结构中，而是隐含在其系数值中。因此，函数型代理模型是通用且经验性的，并非（至少不完全）特定于某一类问题。它们强烈依赖于真实函数的样本，并适用于各种各样的问题。

基于泰勒的模型可以被视为物理模型或功能模型，或者是两者的结合。实际上，如果梯度是通过例如有限差分来近似的，那么泰勒模型显然是功能性的。但如果梯度需要一些内在过程，比如伴随方程的模拟，那么它们的性质可能是物理的。还要注意，大多数

物理模型并非绝对纯粹，因为它们可能包含一些经验性元素，比如根据实验数据调整的参数。

用于构建函数代理模型的最常见基函数类别包括低阶多项式（见第3-5章）、径向基函数（见[49, 50]及下文综述）、自适应回归样条（见[121]）以及小波（见[72]）。拟合数据最广泛使用的准则基于最小二乘回归。在统计学界，回归模型常用于响应曲面方法学。而人工神经网络无非就是非线性回归模型[121]。

还有一些单点技术，专门用于从给定点已知信息（如真实函数的值及其梯度）中提取尽可能多的信息。泰勒模型是这些方法中最明显的，但还有其他方法，如倒数、修正倒数、保守和正项式近似模型（参见[11]及其中的参考文献）。

径向基函数

到目前为止，在本书中，我们仅详细讨论了多项式（线性和二次）插值与回归模型。现在，我们将详细介绍由径向基函数给出的模型类别，这些模型在无导数优化中经常被使用[179, 181, 226]。关于径向基函数的最早参考文献似乎是Duchon [86]，但它们在逼近理论中目前是一个活跃的研究领域（例如，参见[49, 50, 185]）。

径向基函数的一个吸引人的特点是它们能够很好地模拟底层函数的曲率。另一个关键特性是，在相对较弱的条件下，由插值条件定义的系数矩阵是非奇异的（参见下面的讨论）。事实上，人们可以保证插值矩阵的范数估计和条件数的有用界（例如，参见[27]和[50，第5.3节]）。使用径向基函数建模时出现的插值线性系统通常是稠密的，并且已经研究了通过迭代算法求解它们。然而，这仅在插值点数量很大时才相关，而在我们的上下文中这并不是真正的问题。

为了插值一个函数f，其在集合$Y = \{y^0、\ldots、y^p\} \subset \mathbb{R}^n$上的值是已知的，可以使用形式如下的径向基函数代理模型

$$sm(x) = \sum_{i=0}^{p} \lambda_i \phi(\|x - y^i\|), \tag{12.1}$$

其中 ϕ： $\mathbb{R}_+ \to \mathbb{R}$ 和 λ_0， …， $\lambda_p \in \mathbb{R}$。项 *radial basis* 源于 $\phi(\|x\|)$ 在 $\mathbb{R}^n$ 中以原点为中心的任何球面上都是常数这一事实。为了使 $sm(x)$ 二次连续可微，径向基函数 $\phi(x)$ 必须既二次连续可微，又具有在原点的导数为零（见习题）。

一些最流行的（二阶连续可微的）径向基函数如下：

- cubic $\phi(r) = r^3$,
- Gaussian $\phi(r) = e^{-\frac{r^2}{\rho^2}}$,

- 形式为 $\phi(r) = (r^2 + \rho^2)^{\frac{3}{2}}$ 的多二次函数,
- 逆多元二次形式 $\phi(r) = (r^2 + \rho^2)^{-\frac{1}{2}}$,

其中 ρ^2 是任意正常数。

由于在许多应用中，希望由基函数张成的线性空间包含常数函数（而当n有限时，标准的径向基选择并不具备这一性质），因此通过添加常数项来增强(12.1)式中的径向基函数模型被证明是有用的。类似地，若希望包含线性函数（和/或其他合适的低阶多项式函数），则可添加一个次数为$d-1$的低阶*polynomial tail*，其可表示为$\sum_{j=0}^{q} \gamma_j p_j(x)$，其中$p_j \in \mathcal{P}_n^{d-1}$，$j = 0, \ldots, q$为多项式基函数，$\gamma_0, \ldots, \gamma_q \in \mathbb{R}$。新的代理模型现在具有如下形式：

$$sm(x) = \sum_{i=0}^{p} \lambda_i \phi(\|x - y^i\|) + \sum_{j=0}^{q} \gamma_j p_j(x).$$

此外，系数λ需满足

$$\sum_{i=0}^{p} \lambda_i p_j(y^i) = 0, \quad j = 0, \ldots, q.$$

T这些，加上插值条件 $sm(y^i) = f(y^i)$、$i = 0$、…、p，给出线性系统

$$\begin{bmatrix} \Phi & P \\ P^\top & 0 \end{bmatrix} \begin{bmatrix} \lambda \\ \gamma \end{bmatrix} = \begin{bmatrix} f(Y) \\ 0 \end{bmatrix}, \tag{12.2}$$

其中 $\Phi_{ij} = \phi(\|y^i - y^j\|)$ 和 $P_{ij} = p_j(y^i)$ 对于 i，$j \in \{0$、…、$p\}$ 和 $f(Y)$ 是由值 $f(y^0)$、…、$f(y^p)$ 构成的向量。

对称系统(12.2)对于上述给出的ϕ示例具有唯一解，前提是P具有满秩且$d \geq 2$。这一性质源于以下事实：对于上述示例，ϕ是阶数为d的*conditionally positive definite*，且$d = 2$（见习题）。当对于所有满足$\sum_{i=0}^{p} \lambda_i p_j(y^i) = 0$、$j = 0$、…、$q$的不同点$y^0$、…、$y^p$和$\lambda \neq 0$，$\sum_{i,j=0}^{p} \phi(\|y^i - y^j\|)\lambda_i \lambda_j$均为正时，其中$p$代表$\mathcal{P}_n^{d-1}$的一组基，则称$\phi$是阶数为$d$的*conditionally positive definite*。若ϕ是阶数为d的条件正定，则对任何更大的阶数亦然。例如，在高斯和反多二次径向基函数的情况下，矩阵Φ已经是正定矩阵（因此自然是阶数为2的条件正定）。

Oeuvray [179] 以及 Oeuvray 和 Bierlaire [181]，还有 Wild、Regis 和 Shoemaker [226] 针对无导数优化的方法使用了三次径向基函数和线性多项式尾部：

$$sm(x) = \sum_{i=0}^{p} \lambda_i \|x - y^i\|^3 + c + g^\top x. \tag{12.3}$$

在这种情况下，平衡性等价于插值集中存在$n+$个仿射独立（因此也是不同的）点。如果插值点的数量是$p+1$，那么

模型有 $p+n+2$ 个参数，其中 $p+1$ 个用于径向基项，$n+1$ 个用于线性多项式项。然而，当点数为 $n+1$（或更少）时，插值系统的解会产生一个线性多项式，因为所有参数 λ_i、$i=0$、…、p 都为零（见 (12.2) 中的第二个块方程）。因此，形式为 (12.3) 的最简单非线性模型 $sm(x)$ 基于 $n+2$ 个插值点，并且有 $2n+3$ 个参数。

很容易证明，基于包含在半径为Δ的球内的平衡样本集构建的模型(12.3)，在函数值上提供的误差阶为Δ^2，在梯度上提供的误差阶为Δ，这与线性多项式插值或回归的情况相同，且上界中的常数取决于λ的大小。Wild、Regis和Shoemaker[226]研究了如何严格管理由系统(12.2)产生的矩阵的条件数，以推导出λ的一致上界。

克里金模型

函数模型可能包含随机成分，这使其更适合全局优化目的。一个流行的例子是克里金法。粗略地说，克里金模型被分解为两个部分。第一部分通常是一个简单模型，旨在捕捉数据中的趋势。另一部分衡量简单模型与真实函数之间的偏差。

在下面的例子中，为便于说明，我们假设简单模型为一个常数。再假设真实函数的形式为

$$f(x) = \beta + z(x),$$

其中 $z(x)$ 遵循均值为 0、方差为 σ^2 的平稳高斯过程。设两个样本点 y 和 w 之间的协方差建模如下：

$$R(y,w) = \mathbf{Cov}(z(y), z(w)),$$

其中 $R(y、w)$ 使得对于任何由不同样本点组成的集合 Y，$R(Y、Y)$ 都是正定的。一种流行的选择是用径向基函数 $R(y、w) = \phi(\|y-w\|)$ 来建模协方差。

给定一组不同的样本点 Y，Kriging 模型 $ksm(x)$ 被定义为在观测值 $f(Y)$ 给定的情况下，真实函数的期望值：

$$ksm(x) = E(f(x)\,|\,Y).$$

可以证明 $ksm(x)$ 具有如下形式（参见本章末尾的练习）

$$ksm(x) = \hat{\beta} + R(Y,x)^\top R(Y,Y)^{-1}(f(Y) - \hat{\beta}e), \tag{12.4}$$

其中 {v*} 是一个全1向量，并且

$$\hat{\beta} = \frac{e^\top R(Y,Y)^{-1} f(Y)}{e^\top R(Y,Y)^{-1} e}.$$

将$\hat{\beta}$视为β的近似值，将$R(Y、x)^\top R(Y、Y)^{-1}(f(Y)-\hat{\beta}e)$视为对$z(x)$的某种平均近似值，这是有用的。

克里金方法最初是在地质统计学领域发展起来的（见 Matheron [166]），并首次由 Currin 等人 [67] 用于计算机实验。许多研究者引用的一篇优秀综述文章是 [203]。

得 实验设计与响应面方法 技术

针对函数代理模型的构建，已推导出多种采样程序，这些程序取决于真实函数的来源、其评估成本以及模型的平滑度等问题。

本书第一部分所开发的技术，例如，为插值和回归多项式模型提供了一种严谨且高效的确定性采样程序。事实上，我们已在第3至5章中了解到样本集的适定度或条件数如何影响多项式模型的质量。我们引入了一种衡量良好适定度的指标（称为Λ-适定度），并在第6章中展示了在构建和更新这些多项式模型的样本集时，如何确保Λ-适定度（其中$\Lambda > 1$不太大）。

在统计文献中，确定采样空间中点位置的过程被称为*design of experiments*，其主要目标之一在于减少实验噪声。样本集通过拉丁方或析因设计等技术得出，这些方法通常将点置于超立方体类型的顶点，以良好地分布于采样空间中。用本书的语言来说，这样的采样集很可能非常适合线性插值或回归。选择采样位置有更精细的标准，如D-最优性，其中样本集Y的选择使得与$|\det((Y^\top Y)^{-1})|$相关的量最小化（参见Driessen等人[85]基于此类采样类型的信赖域方法）。

实验设计的一般参考文献为 [144, 203, 204, 208]。特别是，*design and analysis of computer experiments* (DACE) [203] 是一个广泛使用的统计框架，用于在基于仿真的实验中使用Kriging模型，正如我们之前提到的，它通常使用径向基函数来表示采样点之间的相关性。DACE还代表一个MATLAB® [1]工具箱 [159]，它提供了用于采样（通过拉丁超立方体）和构建Kriging代理模型的工具。拉丁超立方体采样由McKay、Conover和Beckman [168] 开发（另见 [211]）。另一种具有有趣的散布型采样特性的技术称为正交阵列，其动机源自Rao在1940年代的一系列论文（例如，参见论文 [182, 213]、书籍 [124] 及其中的参考文献）。

响应面方法（RSM）是一种通过顺序构建并最小化功能替代模型来最小化函数（源于系统响应）的框架。最早的RSM由Box和Wilson在论文[44]中提出。RSM通常首先通过应用方差分析来选择最重要和相关变量或参数。对响应变异贡献较小的变量可能被排除。随后开始一些启发式优化迭代过程，在每次迭代中构建一个功能替代模型$sm_k(x)$（例如，通过Kriging），并用于生成真实函数f潜在的下降方向。然后可以通过沿此方向最小化真实函数来改进当前迭代点。当迭代点接近某点x时，这种迭代过程终止。RSM可以通过在局部围绕x最小化一个可能更准确的功能替代模型（如二阶多项式模型）来结束，无需担心噪声。关于RSM的全面介绍，请参阅Box和Draper的书[43]、Myers和Montgomery的书[175]以及Simpson等人的综述论文[208]。

可以将其他RSM视为一次性优化方法，其中首先构建一个功能性代理模型，然后将其最小化以确定最优解（见[203]）。然而，这类方法很可能需要密集采样才能产生有意义的结果。然而，许多应用的统计特性允许使用诸如

克里金法用于为生成的模型分配置信区间，并识别异常值和拟合不足。一篇综述论文考虑了在全球优化背景下使用响应面的现有方法，见[137]。

12.2 处理代理模型的严格优化框架

为了优化目的，代理模型通常以某种形式纳入模型管理框架中。上文提到的RSM是一种流行的代理模型管理框架。接下来，我们将回顾严格的优化框架，这些框架纳入了代理模型，同时保持了基础算法的全局收敛性质。

处理直接搜索中的代理模型

Booker等人[40]在方向直接搜索算法的背景下，引入了一个严谨的框架来处理代理模型。这一想法简单明了，基于这些算法搜索步骤的灵活性，该步骤不受更严格的轮询要求限制。

假设有一个真实函数 $f(x)$ 的代理模型 $sm(x)$。我们考虑的情况是 $sm(x)$ 比 $f(x)$ 精度更低且评估成本更小。还假设，除了有构建这种初始代理模型 $sm(x) = sm_0(x)$ 的方法外，还有在优化过程中可能改进或 *recalibrating* 代理模型的方法。可以考虑一个过程，其中通过连续重新校准构建一系列代理模型 $\{sm_k(x)\}$。每当 f 在新点处被评估时，这些值可用于重新校准并因此提高代理模型的质量。在第11章中，我们已经看到了在基于信赖域插值方法的框架内更新插值和回归多项式模型的多种方法。这些多项式模型和更新技术也可以应用于方向直接搜索中搜索步骤的背景中。

我们现在描述一种可能的框架，以遵循[40]的精神处理方向直接搜索中的代理模型（见下文算法12.1）。在搜索步骤中使用代理模型给出了两种可行的替代方案，但还有其他几种可能，并且根据手头问题的具体情况，它们可能更为合适。注意，轮询步骤本身可能从代理建模中受益，例如，按照$sm_k(\cdot)$的递增顺序对真实函数在$P_k = \{x_k + \alpha_k d : d \in D_k\}$中的评估进行排序。

算法12.1（处理方向直接搜索框架中的代理模型）。

初始化：按照算法 7.2 *and, in addition, form an initial surrogate model* $sm_0(\cdot)$. 进行初始化

对于 $k = 0, 1, 2, \ldots$

1. 搜索步骤：尝试通过有限次评估函数 f 来计算具有 $f(x) < f(x_k)$ 的点 x，例如采用以下两种替代方案之一：

(a) 在一组点 $Y_k = \{y_k^1, \ldots, y_k^{p_k}\}$ 上评估 $sm_k(\cdot)$。按值递增对 Y_k 排序: $sm(y_k^1) \leq \cdots \leq sm(y_k^{p_k})$。按此顺序在 Y_k 中开始评估 f。(b) 应用某种有限优化过程来最小化 $sm_k(\cdot)$，可能是在某个可行集内。令 y_k 为近似极小值点。评估 $f(y_k)$。如果找到这样的点 x，则设置 $x_{k+1} = x$，宣布该迭代和搜索步骤成功，并跳过 poll 步骤。

2. 轮询步骤：如算法7.2中那样轮询。
(The surrogate model $sm_k(\cdot)$ could be used to order the poll set just before polling.)
3. 模型校准：*Form $sm_{k+1}(\cdot)$, possibly by recalibrating $sm_k(\cdot)$*。

4. 网格参数更新：按照算法7.2更新网格大小参数。

现在自然出现的一个问题是，如何保证这样的代理模型管理框架能够产生一个全局收敛算法，换句话说，一个无论起始点如何都能收敛到一阶稳定点的算法。幸运的是，我们已经具备了正确回答这个问题的条件。事实上，在第7章中我们已经看到了两种保证方向直接搜索方法全局收敛的方式。

一种方法是要求迭代点位于整数格点上（见第7.5节）。这样的全局化方案允许算法基于目标函数的简单下降来采取步骤。算法所使用的正基（或正生成集）集合必须满足假设7.8的要求，且步长参数必须遵循假设7.10的规则。但在代理模型管理的背景下，相关的是假设7.9中所述的要求，该假设将这类算法的搜索步骤限制为仅评估网格M_k (中的点，例如由(7.8)或(7.15)定义的网格。在算法12.1的背景下，可以通过不同方式实现这一条件。例如，如果在搜索步骤中选择第一种替代方案，那么Y_k必须被选为M_k的子集，即使我们希望以某种随机性生成Y_k，这似乎也完全不是问题。在第二种可能性中，我们可以将y_k投影到网格M_k上。对于某些正基的选择，这种投影可能在计算上代价高昂，但对于其他选择则是轻而易举的任务。例如，如果我们选择$\mathcal{D} = \{D_\oplus\}$，其中$D_\oplus$是(7.1)中给出的单位坐标向量集合，那么投影到$M_k$上是轻而易举的。注意，即使$y_k$能够提供形式为$f(x) < f(x_k)$的下降，也不能保证投影点，比如$x$，能够提供这种下降。如果$f(x) \geq f(x_k)$且$f(y_k) < f(x_k)$，那么要么该迭代被视为不成功，要么采用$y_k$，并忽略收敛所需的几何考量。

强制方向直接搜索方法实现全局收敛的另一种方式是对新点的接受施加充分下降条件，无论是在搜索步骤还是轮询步骤中（见第7.7节）。在这种情况下，算法在轮询步骤中使用的正基集合（或正生成集）仅需满足假设7.3。为了施加充分下降，算法12.1必须进行相应的修改。特别地，搜索步骤只有在$f(x) < f(x_k) - \rho(\alpha_k)$成立时才会接受点$x$，其中$\rho(\cdot)$是一个强制函数（例如，考虑$\rho(t) = t^{1+a}$，其中$a > 0$，或者参见第7.7节给出的严格定义）。

我们在算法12.1中描述的是一种处理方向直接搜索中代理模型的简化但可能有效的方法。对此主题感兴趣的读者可参阅Booker等人[40]，以及Abramson、Audet和Dennis[7]、Marsden等人[165]、Serafini[206]和Torczon与Trosset[218]，他们在这些文献中开发并测试了其他算法机制。Audet等人[14]提出了此框架在约束优化方面的一个扩展。

尽管我们主要关注的是方向直接搜索（第7章），但也可能考虑通过探索代理建模的可用性来增强单纯形直接搜索（第8章）的方法，尽管这些方法可能不那么有效。例如，我们可以通过首先评估当前的代理模型来测试扩展点的“质量”。如果代理模型预测真实函数*f*在此点上的表现不佳，可以立即忽略该点。此外，还可以最小化当前的代理模型，并将该点作为（可能需要）单纯形重启的中心。

在信赖域方法中处理非线性模型

在第10章中，我们探讨了基于无导数信赖域模型的信赖域方法。我们那时假设信赖域模型是形式为（见(10.1)）的二次（或线性）函数。

$$m_k(x_k+s) \;=\; m_k(x_k)+s^\top g_k+\frac{1}{2}s^\top H_k s, \tag{12.5}$$

以便我们可以轻松计算柯西步，并保证它满足(10.10)：

$$m_k(x_k)-m_k(x_k+s_k) \;\geq\; \frac{\kappa_{fcd}}{2}\|g_k\|\min\left\{\frac{\|g_k\|}{\|H_k\|},\Delta_k\right\}, \tag{12.6}$$

带有 $\kappa_{fcd}=1$（见定理10.1）。因此，任何达到柯西下降分数 $\kappa_{fcd}\in(0,1)$ 的步骤（见假设10.1中的(10.9)）必然验证(12.6)。

一个自然产生的问题是，当信赖域模型不是二次模型，即模型不具有形式（12.5）时，会发生什么。众所周知，（12.6）是一个非常温和的条件，但当$\kappa_{fcd}\in(0,1)$在所有迭代中固定时，仍可能发生由非线性模型定义的信赖域子问题（10.2）的近似解不满足（12.6）的情况。

如果 $m_k(x_k+s)$ 在 s 中不是二次函数，那么定理 10.1 不能直接适用。另一方面，柯西步的基础是它确定了模型沿模型最速下降方向的最小值，因此自然地会关注为更一般的模型确定定理 10.1 的等价形式。实现这一点的一种方法是沿模型最速下降方向使用回溯算法，其中回溯从信任域的边界开始（如 Conn、Gould 和 Toint [57, 第 6.3.3 节] 所建议）。在这种方法中，考虑选择最小的（非负整数）j，使得

$$x_{k+1} \;=\; x_k+\beta^j s, \;\text{ where }\; s \;=\; -\frac{\Delta_k}{\|g_k\|}g_k \;\text{ and }\; \beta\in(0,1), \tag{12.7}$$

从而获得形式为{v*}的充分下降

$$m_k(x_{k+1}) \;\leq\; m_k(x_k)+\kappa_c\beta^j s^\top g_k, \tag{12.8}$$

其中 $\kappa_c \in (0,1)$。该证明相对直接，基于标准的线搜索条件。如果考虑 (12.8) 的右侧且 $\kappa_c = 1$，那么这只是模型的一阶近似。因此，更一般地，(12.8) 中的右侧是一个线性近似，其斜率介于梯度模型和水平（斜率为零）之间。从 (12.7) 我们可以看到 (12.8) 变为

$$m_k(x_{k+1}) - m_k(x_k) \;\leq\; -\kappa_c \beta^j \Delta_k \|g_k\|. \tag{12.9}$$

对左侧使用中值定理，这等价于

$$-\beta^j \Delta_k \|g_k\| + \frac{1}{2}\beta^{2j}\Delta_k^2 g_k^\top \nabla^2 m_k(y_{k,j}) g_k / \|g_k\|^2 \;\leq\; -\kappa_c \beta^j \Delta_k \|g_k\|$$

对于某些 $y_{k,j} \in [x_k, x_k + \beta^j s]$。因此，假设 $\|\nabla^2 m_k(y_{k,j})\| \leq \kappa_{bhm}$，我们得出结论：(12.9) 成立，前提是

$$\frac{\beta^j \Delta_k}{\|g_k\|} \;\leq\; \frac{2(1-\kappa_c)}{\kappa_{bhm}}.$$

因此，我们确实找到了一个满足(12.9)的j_k，使得$\beta^{j_k} > 2(1-\kappa_c)\beta\|g_k\|/(\kappa_{bhm}\Delta_k)$。通过定义$s_k^{\mathrm{AC}} = \beta^{j_k} s$为近似的柯西步长，我们得到

$$m_k(x_k) - m_k(x_k + s_k^{\mathrm{AC}}) \geq \kappa_c \beta^{j_k} \Delta_k \|g_k\|.$$

另一方面，如果近似的 Cauchy 步将我们带到边界，我们立即从(12.8)推导出模型的下降量超过或等于$\kappa_c \Delta_k \|g_k\|$，因此我们可以得出结论：

$$m_k(x_k) - m_k(x_k + s_k^{\mathrm{AC}}) \;\geq\; \bar{\kappa}_c \|g_k\| \min\left\{\frac{\|g_k\|}{\kappa_{bhm}}, \Delta_k\right\}$$

对于适当定义的$\bar{\kappa}_c > 0$。

最后，我们指出，对于非二次信赖域模型，在计算满足特征步下降一部分的步长时，可以做类似的事情（如[57，第6.6.2节]所建议的）。在这种情况下，计算形式为$s_k^{\mathrm{AE}} = \beta^j s_k^{\mathrm{E}}$、$\beta \in (0,1)$的阻尼特征步，使得
$m_k(x_k + s_k^{\mathrm{AE}}) \leq m_k(x_k) + \kappa_e \tau_k \beta^{2j} \|s_k^{\mathrm{E}}\|^2$，其中$\kappa_e \in (0, 1/2)$，且$\tau_k$是模型在$x_k$处的Hessian的最小（假定为负）特征值。容易证明，这样的条件可以在有限次回溯步骤（按β缩减）中得到满足，并且所选的j_k产生形式为$\beta^{j_k} \geq (2\kappa_e - 1)\beta\tau_k/(\nu\Delta_k)$的下界，其中$\nu$是模型Hessian的Lipschitz常数。由此可以容易地证明，近似特征步s_k^{AE}对给定常数$\bar{\kappa}_e > 0$满足形式为(10.12)的条件。

处理非二次信赖域模型的另一种方法由Alexandrov等人[11]提出。他们的想法简单且与前述方法相关。在这种方法中，人们将一个信赖域方法应用于一个辅助约束问题，该问题涉及在变量s中最小化$h(s) = m_k(x_k + s)$，并受限于$\|s\| \leq \Delta_k$。在此类算法的每次迭代中，我们会遇到一个信赖域子问题，它包括在满足两个ℓ_2范数约束（一个是辅助问题约束$\|s\| \leq \Delta_k$，另一个是应用于辅助问题的算法内部信赖域限制）的情况下最小化$h(s)$的二次模型。值得注意的是，对于这样的信赖域子问题，仍能保证柯西下降的一部分（见Heinkenschloss[125]）。我们

同样在标准假设下得到保证，即在运行此类算法的第一次迭代时（从初始迭代点 $s^0 = 0$和信赖域半径$\delta^0 = \Delta_k$开始），可获得一个成功步s^j。随后可以证明，这样的步长为原问题产生了适当比例的柯西下降。

通过空间映射处理代理模型

在许多工程应用中，经常遇到的情况是，考虑优化的函数 $f(x)$ 具有形式 $H(F(x))$，其中 $F : \mathbb{R}^n \to \mathbb{R}^m$ 描述系统的响应，而 $H : \mathbb{R}^m \to \mathbb{R}$ 是某种评价函数，例如范数。类似地，假设我们有一个针对 $F(x)$ 的代理模型 $S(x)$，从而有一个针对 $f(x)$ 的代理模型 $sm(x) = H(S(x))$。更一般地，可以有一族由某些 $p \in \mathbb{R}^p$ 参数化的针对 $F(x)$ 的代理模型 $S(x; p)$，以及相应的针对 $f(x)$ 的一族代理模型 $sm(x; p) = H(S(x; p))$。

然后，可以考虑一个迭代优化过程来近似最小化$f(x)$，该过程包括通过将$S(x$、$p)$对齐到$F(x)$来提取更好的参数p，随后对提取的参数最小化$sm(x$、$p)$。提取的参数称为空间映射参数。现在总结这一过程。

算法12.2（空间映射方法）。

初始化：选择 $x^{(0)}$。

对于 $k = 0$、1、2、…

1. 参数提取：计算 $p^{(k)}$ 作为以下方程的解

$$\min_p \|S(x^{(k)}; p) - F(x^{(k)})\|. \tag{12.10}$$

2. 最小化替代目标：计算 $x^{(k+1)}$ 作为以下问题的解 r

$$\min_x sm(x; p^{(k)}) = H(S(x; p^{(k)})). \tag{12.11}$$

在上述表述中，为简化起见，我们假设x (在S和F)中的定义域以及p的定义域均不受限制。可以考虑将F限制在$\Omega_F \subset \mathbb{R}^n$，$S$限制在$\Omega_S \subset \mathbb{R}^n$，以及$p$限制在$\Omega_p \subset \mathbb{R}^p$的情况，此时（12.10）和（12.11）中的最小化分别限制在Ω_p和$\Omega_F \cap \Omega_S$。我们还可以考虑Ω_S依赖于参数$p^{(k)}$。另一个自然的推广是将（12.10）中的拟合扩展到所有先前的迭代：

$$\min_p \sum_{i=0}^{k} \omega_i^k \|S(x^{(i)}; p) - F(x^{(i)})\|,$$

其中 $\omega_k^k = 1$ 和 ω_i^k，$i = 0$，…，$k - 1$，是非负因子，用于加权当前空间映射参数提取中先前代理模型的贡献。

如果(12.10)和(12.11)中最优映射的利普希茨常数足够小（分别关于变量 x 和参数 p 而言），则可以证明算法12.2中给出的过程生成一个收敛序列 {($x^{(k)}$、$p^{(k)}$)}

(参见 Koziel、Bandler 和 Madsen [148])。此外，如果施加其他条件，包括空间映射参数提取在极限点处是精确的（x^*，p^*），这意味着 $S(x^*;\ p^*) = F(x^*)$，那么 x^* 是最小化真实函数 $f(x) = H(F(x))$ (的原始问题的最优解，另见 [148])。

上述方法对应于所谓的*implicit*空间映射，因为S隐含地依赖于空间映射参数p。名称*space-mapping*与由下式定义的映射P：$\Omega_F \to \Omega_S$相关联，

$$P(x_f) \in \underset{x\in\Omega_S}{\operatorname{argmin}} \|S(x) - F(x_f)\|. \tag{12.12}$$

原始的空间映射方法包括对空间映射代理模型 $smsm(x) = sm(P(x)) = H(S(P(x)))$ 的最小化。在实践中，需要正则化空间映射的定义，以保证（12.12）中解的存在性和唯一性。基于系统响应（即 F 的评估）已推导出割线更新以近似 $P(x)$ 的雅可比矩阵。因此，可以形成如下形式的代理模型：

$$S(x; B^{(k)}) \ = \ S[P(x^{(k)}) + B^{(k)}(x - x^{(k)})],$$

其中$B^{(k)}$是P (的雅可比矩阵的割线更新，例如Broyden更新；见[29]以及[128])中建议的修改。通过考虑$p^{(k)} \equiv B^{(k)}$并将割线更新视为近似求解(12.10)的一种形式，可以将原始的空间映射方法纳入算法12.2的框架中。问题(12.11)不是精确求解，而是局部求解，即通过构造$H(S($x的二次模型；$B^{(k)}))$以$x^{(k)}$为中心，并在信赖域内最小化它。其结果是一个基于空间映射的信赖域框架，用于最小化$smsm(x)$ (，最初在[25]中提出，其全局收敛性质已在[162, 223])中分析。

空间映射技术最早由Bandler等人[28]于1994年提出，并沿着不同方向发展并推广到多种情境，其中一些我们已讨论过（其他一些是*input*和*output*空间映射方法）。关于该主题的综述可见于Søndergaard的论文[209]以及Bakr等人[26]和Bandler、Koziel与Madsen[30]的述评文章中。有兴趣的读者还可参阅由Bandler和Madsen[31]编辑的关于代理建模与空间映射的专刊。

12.3 练习

1. 证明如果$\phi(r)$是二次连续可微的，且$\phi'(0) = 0$，则$h(x) = \phi(\|x\|)$也是二次连续可微的。特别地，有$\nabla h(0) = 0$和$\nabla^2 h(0) = \phi''(0)I$。2. 证明当径向基函数$\phi$是条件正定序$d$且$P$满秩时，系统(12.2)的矩阵是非奇异的。3. 证明基于半径为Δ的球内一个平衡样本集构建的模型(12.3)，在函数值上产生的误差阶为Δ^2，在梯度上的误差阶为Δ (上界中的常数应依赖于λ)的大小。4. 为了得到表达式(12.4)，考虑$ksm(x) = \beta + R(Y、x)^\top\gamma$，并针对$\beta$和$\gamma$解$ksm(Y) = f(Y)$和$e^\top\gamma = 0$。

第13章

回顾无导数优化的约束及其他扩展

在本章中，我们简要考虑约束非线性优化问题的情形，其形式为

$$\begin{aligned} \min_{x\in\mathbb{R}^n} \quad & f(x) \\ \text{s.t.} \quad & x \in \Omega, \\ & h_i(x) \le 0, \quad i = 1,\ldots,m_h, \end{aligned} \tag{13.1}$$

其中 f、h_i：$\Omega \subseteq \mathbb{R}^n \to \mathbb{R}\cup\{+\infty\}$ 是定义在集合或域 Ω 上的函数。我们将简要回顾求解形如 (13.1) 问题的现有方法，这些方法不计算或直接估计函数 f 和 h_i、$i = 1$、…、m_h 的导数，但假设代数定义 Ω 的函数的导数是可用的。

我们强调定义Ω的约束与由函数h_i、$i = 1$、…、m_h定义的约束具有不同的性质。第一类约束通常是形式为$l \le x \le u$的简单边界，或形式为$Ax \le b$的线性约束。例如，直升机旋翼叶片某段的质量必须非负，或者电路上使用的导线宽度必须基于可制造性考虑而有上下界。此外，还可能存在线性约束，如直升机叶片总质量的界限。

目标函数 f（以及在某些情况下的约束函数 h_i）通常未在 Ω 之外定义；因此，在评估目标函数（和/或某些 h_i）的算法框架中，定义 Ω 的约束（的某个可能子集）必须在所有迭代中满足。这类约束不是 *relaxable*。相比之下，*relaxable* 约束只需近似或渐近地满足。[19]

如果 Ω 由线性约束或简单边界定义，那么通常很容易将定义 Ω 的任何约束视为不可松弛约束。理论上，Ω 也可能包含一般非线性约束，其导数是可用的。我们将定义 Ω 的所有约束称为“导数可用的约束”。是否将这些约束视为可松弛的，通常取决于应用和算法方法。

[19] Other authors refer to relaxable and unrelaxable constraints as soft and hard constraints, or as open and closed constraints, respectively.

在许多应用中，存在形式为 $h_i(x) \leq 0$、$i = 1$、…、m_h 的约束，其中函数 h_i 的计算方式与 f 相同，即通过一个不提供导数的黑箱来计算。例如，在电路调优中，对延迟或电路功率的界限可能就是这样的约束。我们将此类约束称为“无导数”约束。显然，这些约束的形式足够通用，可以建模任何类型的约束，包括可以转换为两个符号相反的不等式的等式约束，尽管在实际操作中这可能并不是一个好主意（见下文）。

无导数优化问题中，用户试图优化的多个函数经常出现这种情况，即在给定点x处，所有这些函数的值都是通过调用同一个黑箱模拟器计算得出的。在这些函数中，通常有一个被用作特定公式中的目标函数，而其他函数则作为带有值约束的约束条件处理。此时，这些约束通常是可放宽的。然而，也存在需要将无导数约束视为不可放宽的可能情形。这类情形要求有一个可行的起始点，通常情况下处理起来相当困难，但幸运的是，在实际应用中较为罕见。

在实际应用中确实会出现的一类无导数不可松弛约束的极端情况是所谓的“隐藏”约束。隐藏约束并非问题规格/表述的一部分，其表现形式为某些指示目标函数无法被评估。例如，目标函数$f(x)$可能由仿真软件包计算，而该软件包对于某些（事先未知的）输入参数值可能不收敛，从而无法给出目标函数值。迄今为止，在实际实现中，这些约束通过启发式方法或使用极端障碍函数方法来处理。

大多数关于约束情况的理论工作都是在方向直接搜索的框架内完成的（无约束情况参见第7章），该领域仍然是密集研究的主题。

13.1 方向直接搜索法

相当数量的用于约束问题的无导数方法是可行方法，这意味着所产生的迭代点始终保持在可行域内。可行方法可能因几个原因而受到青睐。一方面，问题的约束可能不可放宽，目标函数值无法在可行区域之外进行评估。另一方面，生成一系列可行点允许迭代过程提前终止，这一过程在目标函数评估成本极高时常常被采用。在这种情况下，可以保证到目前为止测试的最佳点具有可行性。

有几种方法可以解决约束非线性优化问题。20世纪60年代和70年代处理约束的一种流行方法是使用惩罚函数和障碍函数，最初分别称为外惩罚函数和内惩罚函数。（外）惩罚函数通常包括在目标函数中加上一个不可行性的度量乘以惩罚参数。由此产生的惩罚方法允许不可行的迭代点。障碍函数具有不同的性质：它们通过向目标函数添加一个函数（乘以障碍参数）来确保可行性，当（严格）可行点接近可行域的边界时，该函数趋近于$+\infty$。因此，采用适当步长的障碍方法能够保持迭代点的可行性。

由于可能希望无导数算法生成可行迭代点，障碍方法特别有吸引力。可行性可能仅针对 Ω 强制执行，或针对问题 (13.1) 的整个可行域强制执行：

$$X = \{x \in \Omega : h_i(x) \leq 0,\ i = 1, \ldots, m_h\}.$$

无导数算法（特别是方向直接搜索法）可以不直接应用于 f，而应用于 *extreme barrier* 函数 f_Ω 或 f_X，其中对于任意 S，f_S 定义为

$$f_S(x) = \begin{cases} f(x) & \text{if } x \in S, \\ +\infty & \text{otherwise.} \end{cases} \tag{13.2}$$

不必（在许多现有方法中）在不可行点处计算 f。相反，在这些点处，极端障碍函数的值被设为 $+\infty$——这里我们应当回顾，直接搜索方法比较的是函数值，而不是构建模型。显然，这种方法可能不适用于基于插值或回归的方法。

当所有约束导数都可用时

我们现考虑 当 $X = \Omega$ 时的情况，即不存在无导数构造子 traint:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & f(x) \\ \text{s.t.} \quad & x \in \Omega. \end{aligned} \tag{13.3}$$

第7章中描述的无约束优化方向直接搜索方法可直接应用于f_Ω的最小化。然而，使用任意正生成集时，极端障碍技术无法应用。事实上，对于目标函数的下坡方向（例如，与连续可微函数的负梯度成锐角的方向）可能不可行。为了在约束条件下保证全局收敛，因此所选方向必须正确反映当前迭代点附近可行域的几何特征。

当约束仅仅是变量取值的简单边界时，

$$\Omega = \left\{x \in \mathbb{R}^n : l \leq x \leq u\right\}, \tag{13.4}$$

其中 $l \in (\{-\infty\} \cup \mathbb{R})^n$ 和 $u \in (\mathbb{R} \cup \{+\infty\})^n$，那么 (7.1)) 中给出的正生成集 $D_\oplus$ (的（一个子集）充分反映了任何可行点附近的可行域。作为这一简单事实的结果，应用于 (13.2) 且在其用于轮询的向量中包括 $D_\oplus$ 的方向直接搜索方法，当 f 连续可微时，对于一阶驻点具有全局收敛性（例如，参见 Lewis 和 Torczon [152]）。当 Ω 具有 (13.4) 中给出的形式时，(13.3) 的一阶驻点是一个点 $x \in \Omega$，使得如果 $l_i < x_i < u_i$，则 $(\nabla f(x))_i = 0$；如果 $x_i = l_i$，则 $(\nabla f(x))_i \geq 0$；如果 $x_i = u_i$，则 $(\nabla f(x))_i \leq 0$。

为了说明所得坐标搜索方法的简洁性，我们在算法13.1中正式描述它。本可以包含一个搜索步骤，但为了保持表述的简洁，将其省略了。

算法13.1（带边界的坐标搜索法）。

初始化：令 $\Omega = \{x \in \mathbb{R}^n : l \le x \le u\}$ 和 $D_\oplus = [I - I] = [e_1 \cdots e_n - e_1 \cdots - e_n]$。选择 $x_0 \in \Omega$ 和 $\alpha_0 > 0$。

对于 $k = 0$、1、2、…

> 1. 轮询步骤：对轮询集 $P_k = \{x_k + \alpha_k d$ 进行排序：$d \in D_\oplus\}$。按照确定的顺序，在轮询点开始评估 f_Ω。如果找到一个轮询点 $x_k + \alpha_k d_k$，使得 $f_\Omega(x_k + \alpha_k d_k) < f_\Omega(x_k) = f(x_k)$，则停止轮询，设置 $x_{k+1} = x_k + \alpha_k d_k$，并宣布该迭代和轮询步骤成功。否则，宣布该迭代（以及轮询步骤）不成功，并设置 $x_{k+1} = x_k$。
>
> 2. 参数更新：如果迭代成功，则设置$\alpha_{k+1} = \alpha_k$ (或α_{k+1} =为α_k)的2倍。否则，设置$\alpha_{k+1} = \alpha_k$/为2。

请注意，在简单有界的情况下，检查一个点是否位于Ω之外非常容易。在这些情况下，可立即将f_Ω设置为$+\infty$，从而省去对f的一次求值。

在存在导数已知的更一般约束的情况下，为了构造一组适当的正生成元，需要识别活跃约束集，或者更准确地说，拟活跃约束集。就当前讨论而言，假设

$$\Omega = \left\{x \in \mathbb{R}^n : c_i(x) \le 0, i = 1, \ldots, m_c\right\}. \tag{13.5}$$

(当等式约束包含在原始问题表述中时，可以将其转换为两个不等式。然而，这种处理方式可能引入退化现象，并使可行点的计算复杂化。一种替代方案是通过消去部分问题变量来消除等式约束。针对特定情况还有其他方法，例如在线性约束情形下[151]。)给定点$x \in \Omega$和参数$\epsilon > 0$，ϵ-活跃约束的指标集定义为$I(x; \epsilon) = \{i \in \{1, \ldots, m_c\} : c_i(x) \ge -\epsilon\}$。注意，当约束为线性（$c_i(x) = a_i^\top x + b_i$）时，可以对其进行适当缩放，使得其在点$x$处为$\epsilon$-活跃，当且仅当从$x$到超平面$\{x \in \mathbb{R}^n : a^\top$的距离

$_i\ x + b_i = 0\}$不超过ϵ (见[9])。

给定$x \in \Omega$，我们称$N(x; \epsilon)$是由向量$\nabla c_i(x)$对于$i \in I(x$正生成锥；$\epsilon)$:

$$N(x;\epsilon) = \left\{ \sum_{i \in I(x;\epsilon)} \lambda_i \nabla c_i(x) : \lambda_i \ge 0, i \in I(x;\epsilon) \right\}.$$

极锥 $T(x; \epsilon) = N(x; \epsilon)^\circ$ 随后由下式定义

$$T(x;\epsilon) = \left\{v \in \mathbb{R}^n : w^\top v \le 0 \ \forall w \in N(x;\epsilon)\right\}.$$

对于ϵ的适当选择以及在约束限定条件下，$x + T(x; \epsilon)$能很好地近似x (附近可行域的局部几何形状，参见例如[178])。这一性质允许算法从x沿$T(x$中选择的任意方向进行可行位移；$\epsilon)$。注意，在非线性规划中，$T(x; 0)$和$N(x; 0)$分别是Ω在x (处的切锥和法锥，同样，在存在诸如以下约束限定条件的情况下，

例如，活跃约束的线性性或定义活跃约束的函数梯度的线性无关性）。

如果在给定的迭代中 k、$N(x_k;\ \epsilon)=\{0\}$，那么 $T(x_k;\ \epsilon)=\mathbb{R}^n$，这使得问题可以在局部被视为无约束的。在有方向直接搜索方法的背景下，这种情况表明在轮询步骤中应使用 $\mathbb{R}^n$ 的正生成集。在 $N(x_k;\ \epsilon)\neq\{0\}$ 的情况下，轮询方向的集合必须很好地反映迭代点 x_k 附近的局部可行域，因此必须包含 $T(x_k;\ \epsilon)$ 的正生成元。为简单起见，让我们只考虑非退化情形，其中 $N(x_k;\ \epsilon)$ 有一组线性无关的生成元（由矩阵 N_k 的列表示）。我们还假设已对矩阵 N_k 进行了完全 QR 分解：

$$N_k = \begin{bmatrix} Y_k & Z_k \end{bmatrix} \begin{bmatrix} R_k \\ 0 \end{bmatrix},$$

其中 Y_k 构成 N_k 的值域的标准正交基，且 Z_k 构成 $N_k^\top$ 的零空间的标准正交基。矩阵 R_k 是上三角矩阵且非奇异。那么以下是 $T(x_k$ 的正生成元集合；$\epsilon)$ (May [167])：

$$\begin{bmatrix} Z_k & -Z_k & Y_k R_k^{-\top} & -Y_k R_k^{-\top} \end{bmatrix}.$$

注意，$[\,Z_k\ -Z_k\,]$ 正生成 $N_k^\top$ 的零空间。实际上，也可以使用 $N_k^\top$ 零空间的其他正基或正生成集。

在线性约束的情况下，Lewis和Torczon[154]已证明，此类构造能为所有形式为$T(x_k$的锥提供正生成元；对于所有$\varepsilon\in[0,\epsilon]$，$\varepsilon)$亦然。此外，他们指出，若线性代数通过高斯消元法进行，且N_k具有有理数项，则正生成元也具有有理数项（这使得可以考虑整数格）。Lewis、Shepherd和Torczon[151]考虑了等式与不等式线性约束的扩展情况。线性退化约束的情形已被Abramson等人[9]、Lewis、Shepherd和Torczon[151]以及Price和Coope[193]研究。当非冗余约束数量较多时，退化情形会带来额外的计算困难。

在线性约束情况下，已研究了多种方向直接搜索方法，特别是以下三种：

- 集合 D_k 包含所有锥体 $T(x_k$ 的正生成元；$\varepsilon)$ 包含所有 $\varepsilon\in[0,\epsilon_*]$ 的正生成元，其中 $\epsilon_*>0$ 与迭代计数器 k 无关，不可行的轮询点通过极端障碍函数处理（见 Lewis 和 Torczon [154]）。在这种情况下，通过整数格上的简单下降即可实现全局收敛。

- 集合 D_k 是锥 $T(x_k$ 的正生成集；$\epsilon_k)$，参数 ϵ_k 在不成功的迭代中减小，在可行点处的轮询通过投影到可行集来强制执行，并且施加了充分下降条件以接受新的迭代点（参见 Lucidi、Sciandrone 和 Tseng [161] 的算法1）。

- 集合 D_k 是锥 $T(x_k$ 的一个正生成集；$\epsilon_k)$，参数 ϵ_k 被设定为 $\mathcal{O}(\alpha_k)$，其中 α_k 是步长或网格参数，施加了充分下降条件以接受新的迭代点，而不可行的轮询点则通过极端障碍函数处理（参见 Kolda、Lewis 和 Torczon [147] 的算法 5.1）。

初始点必须位于 Ω 中，这在线性约束情况下相对容易实现。对于所有这些算法框架，可以证明当（13.5）中的约束为线性时（$c_i(x) = a_i^\top x + b_i$，$i = 1, \ldots, m_c$），所生成的迭代序列有一个极限点满足问题（13.3）的一阶必要条件（一阶Karush–Kuhn–Tucker条件；例如参见[178]）。如果存在一个非负的Lagrange乘子向量 $\lambda \in \mathbb{R}^{m_c}$，使得在点 $x \in \Omega$ 处满足这些条件，则

$$\nabla f(x) + \sum_{i=1}^{m_c} \lambda_i \nabla c_i(x) = 0, \quad \lambda_i c_i(x) = 0,\ i = 1, \ldots, m_c.$$

其他方法可以追溯到May [167]的工作，他将Mifflin的算法[171]（参见第9章的注释）扩展到了线性约束问题，证明了在非退化情况下全局收敛到一阶和二阶驻点。May探索了沿切线锥正生成元的单形梯度和Hessian矩阵，如[171]中所考虑的类型，证明了收敛到一阶和二阶驻点。

对于目标函数约束的导数已知的一般非线性约束情况，Lucidi、Sciandrone 和 Tseng [161] 进行了研究。他们提出了两种全局收敛算法（其中一种已在上文提及），具有以下共同特点：(i) 采用充分下降准则来接受新的迭代点；(ii) 将试探点投影到可行集上（当 Ω 非凸时，这一操作可能代价高昂）；(iii) 将搜索方向投影到邻近点的切锥上；(iv) 要求初始点可行；(v) 允许使用魔法步 [57]，即任何能够计算出目标函数值小于或等于已接受点目标函数值的点的步骤。在第一种算法中，集合 D_k 是锥 $T(x_k$ 的正生成集；$\epsilon_k)$，且参数 ϵ_k 在不成功迭代时减小。在第二种算法中，D_k 包含所有锥 $T(x_k$ 的正生成元；$\varepsilon)$，对于所有 $\varepsilon \in [0, \epsilon_*]$，其中 $\epsilon_* > 0$ 与迭代计数器 k 无关。收敛性理论要求约束满足一定的正则性条件，例如在线性约束情形下，或者在每个可行点处 Mangasarian–Fromovitz 约束规范（参见，例如，[178]）成立时，该条件即得到满足。对于第二种算法（显然是两者中更高效的一种），作者能够证明迭代序列的所有极限点均满足一阶必要条件。

最近，Dreisigmeyer [81, 82, 84] 通过将（二次连续可微的）约束视为隐含定义黎曼流形，研究了等式约束问题的方向型和单纯型直接搜索方法。在 [83] 中，他研究了约束导数不可用的情况，通过将其隐含地视为Lipschitz流形。

当存在无导数约束时

现在我们关注存在无导数约束的情况，其类型为 $h_i(x) \le 0$，$i = 1, \ldots, m_h$。这里报道的方向直接搜索方法将无导数约束视为可松弛的（除非另有说明）。

Lewis和Torczon [155] 提出了一种基于增广拉格朗日方法的方法。他们方法中的增广拉格朗日函数仅包含对应于非线性约束的函数（见 [146, 155]）。增广拉格朗日

然后，该方法考虑一系列子问题的求解，其中增广拉格朗日函数在剩余约束（变量边界或更一般的线性约束）下被最小化。原始非线性不等式约束必须通过松弛变量转换为等式。每个问题随后可以使用适当的方向直接搜索方法近似求解。这种增广拉格朗日方法的应用产生了与在导数存在情况下获得的相同类型的一阶驻点全局收敛结果（见[146, 155]）。

Liuzzi和Lucidi [157]开发并分析了一种针对不等式约束问题的算法，该算法基于非光滑精确罚函数和充分下降条件的施加。线性约束通过使用正生成元单独处理。他们证明了迭代序列的极限点集合的一个子集满足原问题的一阶必要条件。

我们指出，对于一般的不可松弛约束，除了线性约束外，增广拉格朗日或精确罚方法如何处理尚不清楚。然而，这些方法允许在可松弛约束方面从不可行点开始。

Audet 和 Dennis [16] 提出在方向直接搜索的框架内使用滤波技术来求解 (13.1) 的非光滑实例。滤波方法最近由 Fletcher 和 Leyffer [96] 提出（参见 Fletcher、Leyffer 和 Toint [97] 的综述），作为一种有效的技术来全局化约束非线性优化算法。粗略地说，滤波方法将原始问题视为一个双目标优化问题，试图同时最小化目标函数和不可行性的度量，但后者具有某种形式的优先级。Audet 和 Dennis [16] 的算法单独处理线性不等式，并对所有不可松弛约束应用极端障碍方法。利用 Clarke [54] 的非光滑分析，作者证明了他们的滤波方向直接搜索方法生成一个迭代子序列，收敛到修改后问题的一阶稳定点，当约束的导数无法使用时，该修改后问题可能不同于原始非光滑问题。这种差异源于使用有限个正生成集。在定义约束的函数连续可微的特殊情况下，Dennis、Price 和 Coope [75] 考虑了使用无限个正生成集进行轮询。他们的滤波方法在目标函数于极限点处严格可微的条件下，保证全局收敛到原始问题的一阶稳定点。这里，滤波器周围包络的概念被用作衡量充分下降的手段。

在方向直接搜索的背景下，当定义约束的函数导数不可用时，最通用的方法之一是Audet和Dennis [19]的网格自适应直接搜索（MADS）方法，该方法已在第7.6节针对无约束优化进行了描述，它使用一组投票方向，其并集在$\mathbb{R}^n$中渐近稠密。该算法适用于具有一般无导数约束的问题，包括约束隐藏的情况。MADS将所有约束视为不可松弛的，并要求一个可行的起始点。通过整个可行集的极端障碍排除了不可行性。该理论保证了满足原始（可能非光滑）问题的一阶必要条件的极限点。这些作者最近提出的一种方法称为带渐进障碍的网格自适应直接搜索（见[20]），具有类似于MADS的全局收敛性质。它允许处理两类约束，通过将MADS技术与不可松弛约束的极端障碍相结合，并使用非支配过滤器-

可松弛约束的类型概念。一个有趣的特点是，约束在变得可行之前可被视为可松弛的，随后它会被转移到不可松弛约束的集合中。

我们还指出，基于生成集搜索框架[145]的异步并行方向直接搜索方法，已由Griffin、Kolda和Lewis[114]针对线性约束优化问题提出，并由Griffin和Kolda[113]针对更一般的非线性无导数优化问题提出。

13.2 基于信赖域插值的方法

对约束优化无导数方法的分析大多是在方向直接搜索的框架内完成的。几种实用的方法被开发出来，通过基于信赖域插值的方法处理约束（在第10章和第11章中针对无约束优化进行了概述）。为简化起见，在本节中我们假设所有无导数约束都是可松弛的，而所有其他约束都是不可松弛的，这在实际中通常是这种情况。

从概念上讲，对于具有可用导数的不可松弛约束（$x \in \Omega$），这些方法在处理约束方面的扩展相对直接。最简单的方法是将Ω与信赖域$B(x_k$相交；$\Delta_k)$并仅生成可行的样本点。根据Ω的形状，相应的信赖域子问题可能会变得困难。如第6章和第11章所讨论的，对拉格朗日多项式进行全局优化可能特别具有挑战性。一般来说，在存在约束的情况下，维持一个Λ平衡样本集需要额外的注意。然而，当Ω由线性或箱式约束定义时，理论应该相当容易适应。

在实践中，简单地使用局部解来解决受约束的信任区域子问题通常是足够的[61]。针对受约束信任区域子问题的一种谨慎实用的方法在[33, 34]中被发展出来。迄今为止，对于具有可用导数的不可松弛约束情况，尚无具体的收敛理论。

对于无导数可松弛约束的情况，现有的基于模型的方法处理方式有所不同。首先，我们注意到可松弛约束对适定集问题没有影响，因为计算适定集时无需考虑可松弛约束。其次，将目标函数与可松弛约束结合成一个价值函数（如惩罚函数）的简单想法，使得无约束情况下的收敛理论可以直接应用。此外，当无导数约束函数h_i实际上是额外的目标函数，并且用户对于如何将f和h_i结合成一个合理的惩罚函数有良好的直觉时，这种简单直接的方法往往非常有用。然而，这种方法可能无法生成真正可行的解，即使是在渐近意义上也是如此。

一种理论上可能更为严谨的方法是采用例如序列二次规划（SQP）框架。在SQP中，需要为拉格朗日函数构建二次模型（因此也需要为定义约束的函数构建二次模型）。这些模型随后在信赖域内被最小化，并受到某种形式的约束模型制约。约束模型可以是线性的，这使得信赖域子问题更易于求解；或者如果对f使用二次模型，则它们也可以是二次的。在这种情况下，信赖域子问题变得显著更难，但

约束表示变得更加准确。对于昂贵的函数评估，这可能是一个合理的权衡。

需要注意的是，约束的二次模型通常可以以极小的额外成本获得。在实际应用中，通常的情况是，约束函数的值通过与目标函数值相同的黑箱调用计算得出。这意味着，如果我们有一个基于Λ- poised集Y的f模型，并且我们拥有Y的拉格朗日多项式集，那么我们也就拥有了Y所有点上所有约束函数的值，并且我们可以利用拉格朗日多项式的基本性质（如引理3.5所述）来计算约束的二次模型。

使用约束的二次模型所带来的显著额外成本可能来自信赖域子问题。取决于底层算法、约束的形状以及函数评估的成本，这可能是可接受的，也可能是不可接受的。此外，由于迭代点可能相对于无导数约束的模型不可行，受约束的信赖域子问题可能是不可行的。当迭代点相对于无导数约束的模型不可行时，可以优化模型价值函数或采用模型过滤方法。无论使用哪种方法，都必须与用于原始问题的方法一致。

Scheinberg 的基于信赖域插值的代码（见 [59, 61]），称为 DFO，是基于上述类型的方法。DFO 允许信赖域子问题包含无导数约束的二次模型。通过使用 f 作为评价函数来处理全局化。Powell [186] 提出了一种方法，通过线性插值对目标函数和约束函数进行建模（他的 COBYLA 软件包就是基于此方法）。Berghen [33] 的 CONDOR 代码（另见 [34]）基于 Powell [189] 的 UOBYQA 算法，并且也能处理约束。在其博士论文中，Colson [55] 应用了过滤技术来避免评价函数和罚参数的管理。他的基于信赖域插值的方法遵循了在 [95] 中提出并分析的信赖域 SQP 过滤算法，其中每个 SQP 步被分解为法向和切向分量。我们所知的另一种方法是由 Brekelmans 等人 [46] 提出的。他们的算法框架包括求解一系列非线性（不一定是二次的）信赖域子问题，为所有导数不可用的函数建立线性插值模型。全局化策略基于过滤机制。目前，还没有针对基于信赖域插值方法的收敛性理论。

13.3 全局优化、混合整数规划及其他问题的无导数方法

方向直接搜索方法已被适配用于无导数全局优化 [13, 123, 222]。事实上，利用算法7.2的搜索-轮询框架中的搜索步骤来融入一种用于全局优化的传播方法或启发式方法，是一个有吸引力的想法，因为此类方案可以提供对变量域或可行区域的更广泛探索，而不会干扰收敛理论。Vaz和Vicente [222]为此选择了一种粒子群方法。与其他全局优化求解器相比，所得算法在边界约束问题上（在效率和鲁棒性方面）已被证明具有竞争力。在这种情况下，轮询步骤作用于最佳粒子，并有助于提高整体方法的效率

通过允许粒子随着搜索聚焦于某一点而被剔除。Audet、Béchard 和 Le Digabel [13] 遵循了类似的思想，在 MADS [19] 的搜索步骤中融入了变量邻域搜索，以在全球最优性方面更好地探索可行域。模式搜索方法也已与进化技术相结合（参见 Hart [119, 120] 的工作），由此产生的进化模式搜索方法在与进化算法的比较中表现良好。

Ferris和Deng在[92]中提出了一种在存在噪声情况下，针对无导数无约束问题全局优化的新方法。他们借鉴机器学习中的分类思想，选择有潜力的区域作为局部无导数搜索的起始点。

DIviding RECTangles（DIRECT）是一种优化算法，旨在在受边界约束的定义域内搜索函数的全局最小值，其动机源于对Lipschitz优化的修改，并由Jones、Perttunen和Stuckman[136]提出。该算法不使用目标函数的导数，并且依赖迭代历史来确定未来的采样位置。在每次迭代中，DIRECT首先尝试识别可能包含全局最小值的超矩形，然后将这些超矩形划分为更小的超矩形。目标函数在新超矩形的中心处进行评估。DIRECT试图平衡全局和局部搜索。另见[91, 93, 101, 102]。

多级坐标搜索（MCS）是为在无导数的情况下，于有界约束域内进行函数全局优化而开发的另一种方法。MCS 由 Huyer 和 Neumaier [134] 提出，其灵感也来源于 DIRECT 方法[136]。该算法包含基于二次插值模型最小化的局部增强策略。

基于径向基函数的无导数全局优化方法也已被多位作者提出（参见[36, 117, 138]以及Regis和Shoemaker的一系列论文[196, 197, 198, 199]，其中包括对有约束和并行情况的扩展）。

最后，我们要指出，定向直接搜索方法也被Audet等人应用于混合整数变量问题，无论是否有约束，见文献[4, 5, 17]；Liuzzi、Lucidi和Sciandrone将其应用于线性约束的有限极小极大问题[158]；Audet、Savard和Zghal将其应用于多目标优化[23]。

附录

无导数优化软件

我们在下面列出了为无导数优化开发的一些软件包。

第一章：简介

无导数优化算法的基准测试 http://www.mcs.anl.gov/~more/dfo

第7章：方向直接搜索法

APPSPACK 异步并行模式搜索 http://software.sandia.gov/appspack

优化迭代方法：MATLAB® 代码Hooke-Jeeves和多方向搜索方法 http://www4.ncsu.edu/~ctk/matlab_darts.html

矩阵计算工具箱 多方向搜索与交替方向法 http://www.maths.manchester.ac.uk/~higham/mctoolbox

NOMAD 通用模式搜索和网格自适应直接搜索 http://www.gerad.ca/NOMAD http://www.afit.edu/en/ENC/Faculty/MAbramson/NOMADm.html

SID-PSM 基于单纯形导数的广义模式搜索 http://www.mat.uc.pt/sid-psm

第8章：单纯形直接搜索方法

fminsearch Nelder–Mead 方法的 MATLAB 实现 http://www.mathworks.com/access/helpdesk/help/techdoc/ref/ fminsearch.html

优化迭代方法：MATLAB代码 Nelder–Mead方法 http://www4.ncsu.edu/~ctk/matlab_darts.html

矩阵计算工具箱 Nelder–Mead 方法 http://www.maths.manchester.ac.uk/~higham/mctoolbox

第9章：基于单纯形导数的线搜索方法

隐式过滤 隐式过滤方法 http://www4.ncsu.edu/~ctk/iffco.html

第11章：基于信赖域插值的方法

BOOSTERS 基于信赖域插值的方法（基于径向基函数） http://roso.epfl.ch/rodrigue/boosters.htm

CONDOR 基于信赖域插值的方法（UOBYQA 的并行版本） http://www.applied-mathematics.net/optimization/ CONDORdownload.html

DFO基于信赖域插值的方法（参见第11.2节） http://www.coin-or.org/projects.html

基于信赖域插值的方法（基于径向基函数） http://www.mcs.anl.gov/~wild/orbit

UOBYQA，NEWUOA 基于信赖域插值的方法（见第11.3节）mjdp@cam.ac.uk

WEDGE 基于信赖域插值的方法（参见第11.4节） http://www.ece.northwestern.edu/~nocedal/wedge.html

C第12章：代理模型管理综述 nt

DACE 计算机实验的设计与分析 http://www2
.imm.dtu.dk/~hbn/dace

第13章：无导数优化的约束及其他扩展综述

第13.1节：方向直接搜索法；以及第13.2节：基于信赖域插值的方法

软件包APPSPACK、CONDOR、DFO和NOMAD也处理带约束的无导数优化问题。SID-PSM同样能解决约束问题，但需要约束的导数信息。

第13.3节：用于全局优化、混合整数规划及其他问题的无导数方法

DIRECT DIRECT – 全局优化算法 http://www4.ncsu.ed
u/~ctk/Finkel_Direct

MATLAB 工具箱 2.4，The MathWorks^{TM} 遗传算法与
直接搜索工具箱 2.4 http://www.mathworks.com/produ
cts/gads

通过多级坐标搜索进行MCS全局优化 http://www.mat.univie.ac.at/
~neum/software/mcs/

PSwarm 坐标搜索与粒子群用于全局优化（包括并行版本）http://www.norg.uminho.
pt/aivaz/pswarm

参考文献

[1] *MATLAB®, The MathWorks™*。

[2] *Powerspice simulates circuits faster and more accurately*，电子学，(1985)，第50−51页。

[3] M. A. ABRAMSON 和 C. AUDET, *Convergence of mesh adaptive direct search to second-order stationary points*, SIAM J. Optim., 17 (2006), pp. 606−619.

[4] M. A. ABRAMSON, C. AUDET, J. W. CHRISSIS, 和 J. G. WALSTON, *Mesh adaptive direct search algorithms for mixed variable optimization*, 优化快报, (2008, 即将出版).

[5] M. A. ABRAMSON, C. AUDET, 和 J. E. DENNIS, JR., *Filter pattern search algorithms for mixed variable constrained optimization problems*, Pac. J. Optim., 3 (2004), pp. 477−500.

[6] ,~~ *Gen*~~*eralized pattern searches with derivative information*，Math. Program.，100 (2004)，第3−25页。

[7] ,~~ *Bla*~~*ckbox Optimization*，即将出现。

[8] M. A. ABRAMSON, C. AUDET, J. E. DENNIS, JR., 和 S. LE DIGABEL, *OrthoMADS: A deterministic MADS instance with orthogonal directions*, 技术报告 G-2008-15, GERAD, 蒙特利尔理工学院, 加拿大, 2008.

[9] M. A. ABRAMSON, O. A. BREZHNEVA, J. E. DENNIS, JR., 和 R. L. PINGEL, *Pattern search in the presence of degenerate linear constraints*, Optim. Methods Softw., 23 (2008), 第297−319页。

[10] P. ALBERTO、F. NOGUEIRA、H. ROCHA 和 L. N. VICENTE，*Pattern search methods for user-provided points: Application to molecular geometry problems*，SIAM J. Optim.，14 (2004)，第 1216−1236 页。

[11] N. M. ALEXANDROV, J. E. DENNIS, R. M. LEWIS, 和 V. TORCZON, *A trust region framework for managing the use of approximation models in optimization*, 结构优化, 15 (1998), 第16−23页。

[12] C. AUDET，*Convergence results for pattern search algorithms are tight*，Optim. Eng.，5 (2003)，第101−122页。

[13] C. AUDET, V. BÉCHARD, AND S. LE DIGABEL,
Nonsmooth optimization through
mesh adaptive direct search and variable neighborhood search, J. Global Optim., 41 (2008), 第299–318页。

[14] C. AUDET, A. J. BOOKER, J. E. DENNIS, JR., P. D. FRANK, 和 D. W. MOORE, *A surrogate-model-based method for constrained optimization*, 在 AIAA Paper 2000-4891 中, AIAA/USAF/NASA/ISSMO 多学科分析与优化研讨会, 2000年9月。

[15] C. AUDET, A. L. CUSTÓDIO, 和 J. E. DENNIS, JR., *Erratum: Mesh adaptive direct search algorithms for constrained optimization*, SIAM J. Optim., 18 (2008), 第1501–1503页。

[16] C. AUDET 和 J. E. DENNIS, JR., *A pattern search filter method for nonlinear programming without derivatives*, SIAM J. Optim., 14 (2004), 第980–1010页。

[17] , *~~Pat~~tern search algorithms for mixed variable programming*, SIAM J. Optim., 11 (2000), 第573–594页。

[18] , *~~Ana~~lysis of generalized pattern searches*, SIAM J. Optim., 13 (2003), 第889–903页。

[19] , *~~Mes~~h adaptive direct search algorithms for constrained optimization*, SIAM J. Optim., 17 (2006), 第188–217页。

[20], *~~A M~~ADS algorithm with a progressive barrier for derivative-free nonlinear programming*, 技术报告 G-2007-37, GERAD, 蒙特利尔理工学院, 加拿大, 2007年。

[21] C. AUDET, J. E. DENNIS, JR., 和 S. LE DIGABEL, *Parallel space decomposition of the mesh adaptive direct search algorithm*, 技术报告 G-2007-81, GERAD, 蒙特利尔理工学院, 加拿大, 2007.

[22] C. AUDET 和 D. ORBAN, *Finding optimal algorithmic parameters using derivative-free optimization*, SIAM J. Optim., 17 (2006), 第642–664页。

[23] C. AUDET, G. SAVARD, AND W. ZGHAL,
Multiobjective optimization through a series of single-objective formulations, SIAM J. Optim., 19 (2008), pp. 188–210.

[24] A. M. BAGIROV, B. KARASÖZEN, 和 M. SEZER, *Discrete gradient method: Derivative-free method for nonsmooth optimization*, J. Optim. Theory Appl., 137 (2008), 第317–334页。

[25] M. H. BAKR, J. W. BANDLER, R. M. BIERNACKI, S. H. CHEN, 和 K. MAD-SEN, *A trust region aggressive space mapping algorithm for EM optimization*, IEEE Trans. Microwave Theory Tech., 46 (1998), pp. 2412–2425.

[26] M. H. BAKR, J. W. BANDLER, K. MADSEN, AND J. SØNDERGAARD, *Review of the space mapping approach to engineering optimization and modeling*, Optim. Eng., 1 (2000), pp. 241–276.

[27] K. BALL、N. SIVAKUMAR 和 J. D. WARD,
On the sensitivity of radial basis in- terpolation to minimal data separation distance，Co nstr. Approx.，8 (1992)，第 401–426 页。

[28] J. W. BANDLER，R. M. BIERNACKI，S. H. CHEN，P. A. GROBELNY，和 R . H. HEMMERS，*Space mapping technique for electromagnetic optimization*，IEEE Tr ans. Microwave Theory Tech.，42 (1994)，第2536–2544页。

[29] J. W. BANDLER, R. M. BIERNACKI, S. H. CHEN, R. H. HEMMERS, 和 K. MA DSEN, *Electromagnetic optimization exploiting aggressive space mapping*, IEEE Trans . Microwave Theory Tech., 43 (1995), 第2874–2882页。

[30] J. W. BANDLER、S. KOZIEL 和 K. MADSEN，*Space mapping for engineering optimization*，SIAM SIAG/OPT 观点与新闻，17 (1) (2006)，第19–26页。

[31] J. W. BANDLER 和 K. MADSEN,
Editorial—surrogate modelling and space map- ping for engineering optimization，Opti m. Eng.，2 (2002)，第 367–368 页。
[32] A. BECK 和 M. TEBOULLE, *A convex optimization approach for minimizing the ratio of indefinite quadratic functions over an ellipsoid*, 数学规划, (2008, 即将出版)。

[33] F. V. BERGHEN,
CONDOR: A Constrained, Non-Linear, Derivative-Free Parallel Optimizer for Continuous, High Computing Load, Noisy Objective Functions，博士论文，布鲁塞尔自由大学，比利时，2004年。
[34] F. V. BERGHEN 和 H. BERSINI, *CONDOR, a new parallel, constrained extension of Powell's UOBYQA algorithm: Experimental results and comparison with the DFO algorithm*, 计算与应用数学杂志, 181 (2005), 第157–175页。

[35] G. BERMAN,
Lattice approximations to the minima of functions of several variables，J. ACM，16 (19 69)，第286–294页。
[36] M. BJÖRKMAN 和 K. HOLMSTRÖM，*Global optimization of costly nonconvex functions using radial basis functions*，Optim. Eng.，1 (2000)，第373–397页。

[37] C. BOGANI, M. G. GASPARO, 和 A. PAPINI, *Generalized pattern search methods for a class of nonsmooth problems with structure*, 预印本, 2006.

[38] A. J. BOOKER, J. E. DENNIS, JR., P. D. FRANK, D. W. MOORE, AND D. B. SE RAFINI, *Managing surrogate objectives to optimize a helicopter rotor design—further experiments*, 载于 AIAA Paper 1998–4717, 第8届AIAA/ISSMO多学科分析与优化研讨会, 密苏里州圣路易斯, 1998年。

[39] A. J. BOOKER, J. E. DENNIS, JR., P. D. FRANK, D. B. SERAFINI, AND V. TO R-CZON, *Optimization using surrogate objectives on a helicopter test example*, 载于《最优设计与控制的计算方法》，J. T. Borggaard, J. Burns, E. Cliff, 和 S. Schreck 编，Birkhäuser, Boston, 1998, 第49–58页。

[40] A. J. BOOKER, J. E. DENNIS, JR., P. D. FRANK, D. B. SERAFINI, V. TORCZO N, AND M. W. TROSSET, *A rigorous framework for optimization of expensive functions by surrogates*, Struct. Multidiscip. Optim., 17 (1998), pp. 1–13.

[41] D. M. BORTZ 和 C. T. KELLEY, *The simplex gradient and noisy optimization problems*, 见《优化设计与控制中的计算方法》, J. T. Borggaard, J. Burns, E. Cliff, 和 S. Schreck 编, 系统控制理论与进展 第24卷, Birkhäuser, 波士顿, 1998年, 第77–90页。

[42] G. E. P. BOX,
Evolutionary operation: A method for increasing industrial produc- tivity, Appl. Statist., 6 (1957), 第81–101页。
[43] G. E. P. BOX 和 N. R. DRAPER, *Empirical Model-Building and Response Surfaces*, John Wiley & Sons, 纽约, 1987年。

[44] G. E. P. BOX 和 K. B. WILSON, *On the experimental attainment of optimum conditions*, J. Roy. Statist. Soc. Ser. B., 13 (1951), 第1-45页。[45] M. J. BOX,
A new method for constrained optimization and a comparison with other methods, Comput. J., 8 (1965), 第42-52页。

[46] R. BREKELMANS, L. DRIESSEN, H. HAMERS, AND D. DEN HERTOG, *Constrained optimization involving expensive function evaluations: A sequential approach*, 《欧洲运筹学杂志》, 160 (2005), 第121–138页。

[47] R. P. BRENT, *Algorithms for Minimization without Derivatives*, Prentice–Hall, Englewood Cliffs, NJ, 1973年。由多佛出版社（Dover Publications）于2002年在纽约州米尼奥拉重新发行。
[48] A. G. BUCKLEY 和 H. MA, *A derivative-free algorithm for parallel and sequential optimization*, 技术报告, 计算机科学系, 维多利亚大学, 加拿大, 1994年。

[49] M. D. BUHMANN, *Radial basis functions: The state-of-the-art and new results*, Acta Numer., 9 (2000), 第1–37页。[50] , *Radial Basis Functions*, 剑桥大学出版社, 英国剑桥, 2003年。[51] R. G. CARTER,
On the global convergence of trust region algorithms using inexact gradient information, SIAM J. Numer. Anal., 28 (1991), 第251–265页。[52] T. D. CHOI 和 C. T. KELLEY, *Superlinear convergence and implicit filtering*, SIAM J. Optim., 10 (2000), 第1149–1162页。

[53] P. G. CIARLET 和 P. A. RAVIART,
General Lagrange and Hermite interpolation in R^n with applications to finite element methods, 理性力学与分析档案, 46 (1972), 第 177–199 页。
[54] F. H. CLARKE, *Optimization and Nonsmooth Analysis*, John Wiley & Sons, 纽约, 1983. 由 SIAM, 费城, 1990 年重新发行.

[55] B. COLSON, *Trust-Region Algorithms for Derivative-Free Optimization and Nonlinear Bilevel Programming*, 博士论文, 数学系, FUNDP, 比利时那慕尔, 2003年.

[56] B. COLSON AND PH. L. TOINT,
Optimizing partially separable functions without derivatives, Optim. Methods Softw., 20 (2005), pp. 493–508.

[57] A. R. CONN, N. I. M. GOULD, AND PH. L. TOINT, *Trust-Region Methods*, MPS-SIAM优化系列，SIAM，费城，2000年。

[58] A. R. CONN 和 PH. L. TOINT，*An algorithm using quadratic interpolation for unconstrained derivative free optimization*，见《非线性优化及其应用》，G. D. Pillo 和 F. Gianessi 编，Plenum，纽约，1996年，第27–47页。

[59] A. R. CONN, K. SCHEINBERG, AND PH. L. TOINT, *On the convergence of derivative-free methods for unconstrained optimization*，载于《逼近论与优化：致敬 M. J. D. Powell》，M. D. Buhmann 和 A. Iserles 编，剑桥大学出版社，英国剑桥，1997年，第83–108页。

[60], *Recent progress in unconstrained nonlinear optimization without derivatives*，Math. Program.，79 (1997)，第397–414页。

[61], *A derivative free optimization algorithm in practice*，发表于第7届AIAA/USAF/NASA/ISSMO多学科分析与优化研讨会论文集，密苏里州圣路易斯，1998年9月。

[62] A. R. CONN, K. SCHEINBERG, AND L. N. VICENTE, *Global convergence of general derivative-free trust-region algorithms to first and second order critical points*, SIAM J. Optim., (2009, 待出版)。

[63], *Geometry of interpolation sets in derivative free optimization*，数学规划，111 (2008)，第141–172页。

[64] , *Geometry of sample sets in derivative-free optimization: Polynomial regression and underdetermined interpolation*，IMA J. Numer. Anal.，28 (2008)，第721–748页。

[65] I. D. COOPE 和 C. J. PRICE，*Frame based methods for unconstrained optimization*，J. Optim. Theory Appl.，107 (2000)，第 261–274 页。

[66], *On the convergence of grid-based methods for unconstrained optimization*，SIAM J. Optim.，11 (2001)，第859–869页。

[67] C. CURRIN, T. MITCHELL, M. MORRIS, 和 D. YLVISAKER, *A Bayesian approach to the design and analysis of computer experiments*, 技术报告 ORNL–6498, 橡树岭国家实验室, 田纳西州橡树岭, 1988.

[68] A. L. CUSTÓDIO, J. E. DENNIS, JR., 和 L. N. VICENTE, *Using simplex gradients of nonsmooth functions in direct search methods*, IMA J. Numer. Anal., 28 (2008), 第770–784页。

[69] A. L. CUSTÓDIO, H. ROCHA, 和 L. N. VICENTE, *Incorporating minimum Frobenius norm models in direct search*, 技术报告 08-51, 数学系, 科英布拉大学, 葡萄牙, 2008.

[70] A. L. CUSTÓDIO 和 L. N. VICENTE，*Using sampling and simplex derivatives in pattern search methods*，SIAM J. Optim.，18 (2007)，第537–555页。

[71] A. P. DAMBRAUSKAS, *The simplex optimization method with variable step*, En grg. Cybernet., 1 (1970), 第28–36页。

[72] I. DAUBECHIES, *Ten Lectures on Wavelets*, SIAM, 费城, 1992年。

[73] W. C. DAVIDON, *Variable metric method for minimization*, SIAM J. Optim., 1 (1991), 第1–17页。

[74] C. DAVIS, *Theory of positive linear dependence*, Amer. J. Math., 76 (1954), 第733–746页。

[75] J. E. DENNIS, JR., C. J. PRICE, AND I. D. COOPE, *Direct search methods for nonlinearly constrained optimization using filters and frames*, Optim. Eng., 5 (2004), pp. 123–144.

[76] J. E. DENNIS, JR. 和 R. B. SCHNABEL, *Numerical Methods for Unconstrained Optimization and Nonlinear Equations*, Prentice–Hall, Englewood Cliffs, NJ, 1983。由 SIAM 重新发行, Philadelphia, 1996。

[77] J. E. DENNIS, JR., AND V. TORCZON,
Direct search methods on parallel machines, SIAM J. Optim., 1 (1991), pp. 448–474.

[78] J. E. DENNIS, JR. 和 D. J. WOODS, *Optimization on microcomputers: The Nelder–Mead simplex algorithm*, 在《新计算环境：大规模计算中的微型计算机》中, A. Wouk 编, SIAM, 费城, 1987年, 第116-122页。

[79] M. A. DINIZ-EHRHARDT, J. M. MARTÍNEZ, 和 M. RAYDAN, *A derivative-free nonmonotone line search technique for unconstrained optimization*, 《计算与应用数学杂志》, 219 (2008), 第383–397页。

[80] E. D. DOLAN, R. M. LEWIS, 和 V. TORCZON, *On the local convergence of pattern search*, 《SIAM 优化杂志》, 14 (2003), 第567–583页。

[81] D. W. DREISIGMEYER, *Direct search algorithms over Riemannian manifolds*, 技术报告 LA-UR-06-7416, 洛斯阿拉莫斯国家实验室, 新墨西哥州洛斯阿拉莫斯, 2006年。[82], *Equality constraints, Riemannian manifolds and direct search methods*, 技术报告 LA-UR-06-7406, 洛斯阿拉莫斯国家实验室, 新墨西哥州洛斯阿拉莫斯, 2006年。[83], *Direct search algorithms over Lipschitz manifolds*, 技术报告 LA-UR-07-1073, 洛斯阿拉莫斯国家实验室, 新墨西哥州洛斯阿拉莫斯, 2007年。[84], *A simplicial continuation direct search method*, 技术报告 LA-UR-07-2755, 洛斯阿拉莫斯国家实验室, 新墨西哥州洛斯阿拉莫斯, 2007年。[85] L. DRIESSEN, R. C. M. BREKELMANS, H. HAMERS, AND D. DEN HERTOG,
On D-optimality based trust regions for black-box optimization problems, 结构与多学科优化, 31 (2006), 第40–48页。

[86] J. DUCHON, *Splines minimizing rotation-invariant semi-norms in Sobolev spaces*, 载于《多变量函数的构造理论》, W. Schempp 与 K. Zeller 编, Springer-Verlag, 柏林, 1977年, 第85–100页。

[87] R. DUVIGNEAU 和 M. VISONNEAU, *Hydrodynamic design using a derivative-free method*, 结构与多学科优化, 28 (2004), 第195–205页。

[88] C. ELSTER 和 A. NEUMAIER, *A grid algorithm for bound constrained optimization of noisy functions*, IMA J. Numer. Anal., 15 (1995), 第585–608页。

[89] G. FASANO, J. L. MORALES, 和 J. NOCEDAL, *On the geometry phase in model-based algorithms for derivative-free optimization*, 技术报告, 优化中心, 西北大学, 埃文斯顿, 伊利诺伊州, 2008年。

[90] E. FERMI 和 N. METROPOLIS, 技术报告, 洛斯阿拉莫斯非机密报告 LA–1492, 洛斯阿拉莫斯国家实验室, 新墨西哥州洛斯阿拉莫斯, 1952年。

[91] M. C. FERRIS 和 G. DENG, *Extension of the DIRECT optimization algorithm for noisy functions*, 载于2007年冬季模拟会议论文集, B. Biller, S. Henderson, M. Hsieh, 和 J. Shortle 编, 华盛顿特区, 2007年。

[92], *—Classification-based global search: An application to a simulation for breast cancer*, 载于2008年NSF工程研究与创新会议论文集, 田纳西州诺克斯维尔, 2008年。

[93] D. E. FINKEL 和 C. T. KELLEY, *Additive scaling and the DIRECT algorithm*, J. Global Optim., 36 (2006), pp. 597–608.

[94] R. FLETCHER, *Function minimization without derivatives—a review*, Comput. J., 8 (1965), 第33–41页。

[95] R. FLETCHER, N. I. M. GOULD, S. LEYFFER, PH. L. TOINT, 和 A. WÄCHTER, *Global convergence of trust-region SQP-filter algorithms for general nonlinear programming*, SIAM J. Optim., 13 (2002), 第635–659页。

[96] R. FLETCHER 和 S. LEYFFER, *Nonlinear programming without a penalty function*, 数学规划, 91 (2002), 第239–269页. [97] R. FLETCHER, S. LEYFFER, 和 PH. L. TOINT, *A brief history of filter methods*, SIAM SIAG/OPT 观点与新闻, 18 (1) (2006), 第2–12页.

[98] C. FORTIN 和 H. WOLKOWICZ, *The trust region subproblem and semidefinite programming*, 优化方法软件, 19 (2004), 第41-67页。

[99] K. R. FOWLER, J. P. REESE, C. E. KEES, J. E. DENNIS, JR., C. T. KELLEY, C. T. MILLER, C. AUDET, A. J. BOOKER, G. COUTURE, R. W. DARWIN, M. W. FARTHING, D. E. FINKEL, J. M. GABLONSKY, G. GRAY, AND T. G. KOLDA, *A comparison of derivative-free optimization methods for groundwater supply and hydraulic capture community problems*, Adv. in Water Resources, 31 (2007), pp. 743– 757.

[100] L. "Type ABstract, Content STILLMAN, 和 T. "Type ABstract, Content STILLMAN, *A generating set search method using cur- vature information*, Comput. Optim. Appl., 38 (2007), 第105–121页。

[101] J. "Type ABstract, Content MYCIELSKI, 和 S. "Type ABstract, Content ULAM, *Modification of the Monte Carlo method*, 罗来纳州立大学, 罗利, 北卡罗来纳州, 2001年。

从传感器 $t=0$ 时的数据库中选择一个近似观测值 z_{t}。

从传感器 $t=0$ 时的数据库中选择论文近似观测值 z_{t}。

[102] J. M. GABLONSKY 和 C. T. KELLEY, *A locally-biased form of the DIRECT algorithm*, J. Global Optim., 21 (2001), pp. 27−37.

[103] U. M. GARCÍA-PALOMARES 和 J. F. RODRÍGUEZ,
New sequential and paral- lel derivative-free algorithms for unconstrained optimization , SIAM J. Optim., 13 (2002), 第79−96页。

[104] P. E. GILL, W. MURRAY, AND M. H. WRIGHT, *Practical Optimization*, Academ ic Press, San Diego, 1981. [105] P. GILMORE AND C. T. KELLEY,
An implicit filtering algorithm for optimization of functions with many local minima, SIA M J. Optim., 5 (1995), pp. 269−285. [106] T. GLAD AND A. GOLDSTEIN,
Optimization of functions whose values are subject to small errors, BIT, 17 (1977), pp. 16 0−169. [107] F. GLOVER, *Tabu search—Part* I, ORSA J. Comput., 1 (1989), pp. 190−20 6.

[108] D. E. GOLDBERG,
Genetic Algorithms in Search, Optimization and Machine Learn- ing, Addison−Wesley L ongman, 波士顿, 1989年。
[109] G. H. GOLUB 和 C. F. VAN LOAN, *Matrix Computations*, 约翰·霍普金斯大学出版社, 巴尔的摩, 伦敦, 第三版, 1996年。

[110] G. A. GRAY 和 T. G. KOLDA, *Algorithm* 856*: APPSPACK* 4.0*: Asynchronous parallel pattern search for derivative-free optimization*, ACM Trans. Math. Soft- ware , 32 (2006), 第 485−507 页。

[111] A. GRIEWANK,
Evaluating Derivatives: Principles and Techniques of Algorithmic Differentiation, SIAM, 费城, 2000.
[112] A. GRIEWANK 和 G. F. CORLISS 编, *Automatic Differentiation of Algorithms: Theory, Implementation, and Application*, SIAM, 费城, 1991年。

[113] J. D. GRIFFIN 和 T. G. KOLDA, *Nonlinearly-constrained optimization using asynchronous parallel generating set search*, 技术报告 SAND2007-3257, 桑迪亚国家实验室, 新墨西哥州阿尔伯克基, 加利福尼亚州利弗莫尔, 2007年。

[114] J. D. GRIFFIN, T. G. KOLDA, 和 R. M. LEWIS, *Asynchronous parallel gener- ating set search for linearly constrained optimization*, SIAM J. Sci. Comput., 30 (2008), pp. 1892−1924.

[115] L. GRIPPO, F. LAMPARIELLO, AND S. LUCIDI,
Global convergence and stabiliza- tion of unconstrained minimization methods without derivatives, J. Optim. Theory Appl., 56 (1998), pp. 385−406.
[116] D. N. GUJARATI, *Basic Econometrics*, McGraw−Hill 国际版, 新加坡, 第三版, 1995年。

[117] H.-M. GUTMANN, *A radial basis function method for global optimization*, 《全局优化杂志》, 19 (2001), 第201−227页。

[118] R. T. HAFTKA, *Combining global and local approximations*, AIAA J., 29 (1991), 第1523–1525页。

[119] W. E. HART, *A generalized stationary point convergence theory for evolutionary algorithms,* 于第7届国际遗传算法会议论文集，旧金山，1997年，第127–134页。

[120] W. E. HART, *Comparing evolutionary programs and evolutionary pattern search algorithms: A drug docking application*, 载于《遗传与进化计算会议论文集》，佛罗里达州奥兰多，1999年，第855–862页。

[121] T. HASTIE, R. TIBSHIRANI, AND J. FRIEDMAN,
The Elements of Statistical Learn- ing: Data Mining, Inference, and Prediction, Springer-Verlag, 纽约, 2001.
[122] S. HAYKIN, *Neural Networks: A Comprehensive Foundation*, Prentice–Hall, 新泽西州上 saddle river, 1994 年。

[123] A.-R. HEDAR 与 M. FUKUSHIMA, *Heuristic pattern search and its hybridization with simulated annealing for nonlinear global optimization,* 优化方法软件, 19 (2004), 第291–308页。

[124] A. S. HEDAYAT, N. J. A. SLOANE, AND J. STUFKEN,
Orthogonal Arrays: Theory and Applications, Springer-Verlag，纽约，1999年。

[125] M. HEINKENSCHLOSS, *On the solution of a two ball trust region subproblem*, Math. Program., 64 (1994), 第249–276页。

[126] N. J. HIGHAM, *Optimization by direct search in matrix computations*, SIAM J. 矩阵分析与应用, 14 (1993), 第317–333页。

[127] ,*~~Acc~~uracy and Stability of Numerical Algorithms*, SIAM，费城，第二版，2002年。

[128] H. HINTERMÜLLER 和 L. N. VICENTE, *Space mapping for optimal control of partial differential equations*, SIAM J. Optim., 15 (2005), 第1002–1025页。

[129] J. H. HOLLAND, *Adaptation in Natural and Artificial Systems: Introductory Analysis with Applications to Biology, Control, and Artificial Intelligence,* MIT出版社, 剑桥, 马萨诸塞州, 1992.

[130] R. HOOKE 和 T. A. JEEVES, *"Direct search" solution of numerical and statistical problems*, J. ACM, 8 (1961), 第 212–229 页。[131] R. A. HORN 和 C. R. JOHNSON, *Topics in Matrix Analysis*, 剑桥大学出版社，英国剑桥，1999 年。[132] P. D. HOUGH、T. G. KOLDA 和 V. J. TORCZON, *Asynchronous parallel pattern search for nonlinear optimization*, SIAM J. Sci. Comput., 23 (2001), 第 134–156 页。[133] P. D. HOUGH 和 J. C. MEZA,
A class of trust-region methods for parallel opti- mization, SIAM J. Optim., 13 (2002)，第 264–282 页。

[134] W. HUYER 和 A. NEUMAIER，*Global optimization by multilevel coordinate search*，J. Global Optim.，14 (1999)，第 331–355 页。

[135] L. M. HVATTUM 和 F. GLOVER，
Finding local optima of high-dimensional func- tions using direct search methods，欧洲运筹学杂志，(2008，即将出版)。[136] D. JONES, C. PERTTUNEN, 和 B. STUCKMAN，*Lipschitzian optimization without the Lipschitz constant*，优化理论与应用杂志，79 (1993)，第157–181页。[137] D. R. JONES，
A taxonomy of global optimization methods based on response sur- faces，全局优化杂志，21 (2001)，第345–383页。[138] J.-E. KÄCK，
Constrained global optimization with radial basis functions，研究报告 MdH-IMa-2004，数学与物理系，梅拉达伦大学，韦斯特罗斯，瑞典，2004年。[139] A. J. KEANE 和 P. NAIR，*Computational Approaches for Aerospace Design: The Pursuit of Excellence*，约翰威立父子出版公司，纽约，2006年。[140] C. T. KELLEY，*Detection and remediation of stagnation in the Nelder–Mead algorithm using a sufficient decrease condition*，SIAM优化杂志，10 (1999)，第43–55页。[141]，*Iterative Methods for Optimization*，SIAM，费城，1999年。

[142] J. KENNEDY 和 R. EBERHART，*Particle swarm optimization*，见 1995 年 IEEE 国际神经网络会议论文集，澳大利亚珀斯，IEEE 服务中心，新泽西州皮斯卡塔韦，第 1942–1948 页。

[143] S. KIRKPATRICK, C. D. GELATT, JR., AND M. P. VECCHI,
Optimization by simu- lated annealing, Science, 220 (1983), pp. 671–680.

[144] J. R. KOEHLER 和 A. B. OWEN，*Computer experiments*，见《统计学手册》，S. Ghosh 和 C. R. Rao 编，第13卷，Elsevier Science，纽约，1996年，第261–308页。

[145] T. G. KOLDA, R. M. LEWIS, 和 V. TORCZON, *Optimization by direct search: New perspectives on some classical and modern methods*, SIAM Rev., 45 (2003), 第385–482页。

[146], *~~A ge~~nerating set direct search augmented Lagrangian algorithm for optimization with a combination of general and linear constraints*，技术报告 SAND2006-5315，桑迪亚国家实验室，新墨西哥州阿尔伯克基，加利福尼亚州利弗莫尔，2006年。

[147] ,*~~Stat~~ionarity results for generating set search for linearly constrained optimization*，SIAM J. Optim.，17 (2006)，第 943–968 页。

[148] S. KOZIEL、J. W. BANDLER 和 K. MADSEN，
Quality assessment of coarse mod- els and surrogates for space mapping optimization，Optim. Eng.，9 (2008)，第375–391页。

[149] J. C. LAGARIAS, J. A. REEDS, M. H. WRIGHT, AND P. E. WRIGHT,
Convergence properties of the Nelder–Mead simplex method in low dimensions, SIAM J. Optim., 9 (1998), pp. 112–147.

[150] T. LEVINA, Y. LEVIN, J. MCGILL, 和 M. NEDIAK, *Dynamic pricing with on-line learning and strategic consumers: An application of the aggregation algorithm*, 运筹学, (2008, 待出版).

[151] R. M. LEWIS, A. SHEPHERD, AND V. TORCZON, *Implementing generating set search methods for linearly constrained optimization*, SIAM J. Sci. Comput., 29 (2007), pp. 2507–2530.

[152] R. M. LEWIS 和 V. TORCZON, *Pattern search algorithms for bound constrained minimization*, SIAM J. Optim., 9 (1999), 第1082–1099页。

[153], *~~Rank~~ ordering and positive bases in pattern search algorithms*, 技术报告 TR96-71, ICASE, NASA 兰利研究中心, 弗吉尼亚州汉普顿, 1999年。

[154], *~~Pattern~~ search methods for linearly constrained minimization*, SIAM J. Optim., 10 (2000), 第917–941页。

, *A glo~~bally~~ convergent augmented Lagrangian pattern search algorithm for optimization with general constraints and simple bounds*, SIAM J. Optim., 12 (2002), 第1075–1089页。

[156] R. M. LEWIS, V. TORCZON, AND M. TROSSET,
Direct search methods: Then and now, J. Comput. Appl. Math., 124 (2000), pp. 191–207.

[157] G. LIUZZI 和 S. LUCIDI, *A derivative-free algorithm for inequality constrained nonlinear programming*, 技术报告 659, 系统分析与信息学研究所“安东尼奥·鲁贝蒂”, CNR, 罗马, 意大利, 2007年。

[158] G. LIUZZI, S. LUCIDI, AND M. SCIANDRONE, *A derivative-free algorithm for linearly constrained finite minimax problems*, SIAM J. Optim., 16 (2006), pp. 1054– 1075
.

[159] S. N. LOPHAVEN, H. B. NIELSEN, AND J. SØNDERGAARD,
DACE: A MATLAB Kriging toolbox, 技术报告 IMM-TR-2002-12, 丹麦技术大学信息与数学建模系, 丹麦林比, 2003年。

[160] S. LUCIDI 和 M. SCIANDRONE, *On the global convergence of derivative-free methods for unconstrained optimization*, SIAM J. Optim., 13 (2002), 第97–116页。
[161] S. LUCIDI, M. SCIANDRONE, 和 P. TSENG,
Objective-derivative-free methods for constrained optimization, Math. Program., 92 (2002), 第37–59页。

[162] K. MADSEN 和 J. SØNDERGAARD,
Convergence of hybrid space mapping algo- rithms, Optim. Eng., 5 (2004), 第145–156页。
[163] M. MARAZZI 和 J. NOCEDAL, *Wedge trust region methods for derivative free optimization*, Math. Program., 91 (2002), 第289–305页。

[164] A. L. MARSDEN, *Aerodynamic Noise Control by Optimal Shape Design*, 博士论文, 斯坦福大学, 加利福尼亚州斯坦福, 2004年。

[165] A. L. MARSDEN, M. WANG, J. E. DENNIS, JR., 以及 P. MOIN, *Optimal aeroacoustic shape design using the surrogate management framework*, Optim. Eng., 5 (2004) , pp. 235–262.

[166] G. MATHERON, *Principles of geostatistics*, 经济地质学, 58 (1963), 第1246–1266页。

[167] J. H. MAY,
Linearly Constrained Nonlinear Programming: A Solution Method That Does Not Require Analytic Derivatives, 博士论文, 耶鲁大学, 康涅狄格州纽黑文, 1974年。

[168] M. D. MCKAY, W. J. CONOVER, 和 R. J. BECKMAN, *A comparison of three methods for selecting values of input variables in the analysis of output from a computer code*, Technometrics, 21 (1979), pp. 239–245.

[169] K. I. M. MCKINNON,
Convergence of the Nelder–Mead simplex method to a non- stationary point, SIAM J. O ptim., 9 (1998), 第148–158页。[170] J. C. MEZA 和 M. L. MARTINEZ,
On the use of direct search methods for the molecular conformation problem, J. Compu t. Chem., 15 (1994), 第627–632页。[171] R. MIFFLIN,
A superlinearly convergent algorithm for minimization without evalu- ating derivatives, Math. Program., 9 (1975), 第100–117页。

[172] J. J. MORÉ 和 D. C. SORENSEN, *Computing a trust region step*, SIAM J. Sci. Statist. Comput., 4 (1983), 第 553–572 页。

[173] J. J. MORÉ 和 S. M. WILD, *Benchmarking derivative-free optimization algorithms*, 技术报告 ANL/MCS-P1471-1207, 数学与计算机科学部, 阿贡国家实验室 , 伊利诺伊州阿贡, 2007年。

[174] P. MUGUNTHAN, C. A. SHOEMAKER, 和 R. G. REGIS, *Comparison of function approximation, heuristic and derivative-based methods for automatic calibration of computationally expensive groundwater bioremediation models*, Water Resour. Res., 41 (2 005), W11427.

[175] R. H. MYERS 和 D. C. MONTGOMERY, *Response Surface Methodology: Process and Product in Optimization Using Designed Experiments*, John Wiley & Sons, 纽约, 第二版, 2002年。

[176] L. NAZARETH 和 P. TSENG,
Gilding the lily: A variant of the Nelder–Mead algo- rithm based on golden-section search , Comput. Optim. Appl., 22 (2002), 第133–144页。

[177] J. A. NELDER 和 R. MEAD, *A simplex method for function minimization*, 计算机杂志, 7 (1965), 第308–313页. [178] J. NOCEDAL 和 S. J. WRIGHT,
Numerical Optimization, 施普林格出版社, 柏林, 第二版, 2006. [179] R. OEUVRAY,
Trust-Region Methods Based on Radial Basis Functions with Application to Biomedical Imaging, 博士论文, 数学研究所, 洛桑联邦理工学院, 瑞士, 2005.

[180] R. OEUVRAY 和 M. BIERLAIRE,
A new derivative-free algorithm for the medical image registration problem，国际建模与仿真杂志，27 (2007)，第115–124页。

[181] ,*—BOOSTERS: A derivative-free algorithm based on radial basis functions*，《国际建模与仿真杂志》，（2008年，即将出版）。

[182] A. B. OWEN, *Orthogonal arrays for computer experiments, integration and visualization*, 统计学期刊, 2 (1992), 第 439–452 页。

[183] M. J. D. POWELL，*An efficient method for finding the minimum of a function of several variables without calculating derivatives*，Comput. J.，7 (1964)，第155–162页。

[184], *—A new algorithm for unconstrained optimization*，载于《非线性规划》，J. B. Rosen、O. L. Mangasarian 和 K. Ritter 编，Academic Press，纽约，1970年，第31–65页。

[185], *The theory of radial basis function approximation in 1990*, 载于《数值分析进展》第二卷：小波、细分算法与径向基函数，W. A. Light 主编，牛津大学出版社，英国剑桥，1992年，第105–210页。

[186], *—A direct search optimization method that models the objective and constraint functions by linear interpolation*，载于《优化与数值分析进展：第六届优化与数值分析研讨会论文集》，墨西哥瓦哈卡，S. Gomez 与 J.-P. Hennart 编，Math. Appl. 系列第 275 卷，Kluwer Academic Publishers，荷兰多德雷赫特，1994年，第51–67页。

[187] ,*—Direct search algorithms for optimization calculations*，Acta Numer.，7 (1998)，第287–336页。

[188], *On the Lagrange functions of quadratic models that are defined by interpola- tion*，优化方法软件，16 (2001)，第289–309页。

[189], *—UOBYQA: Unconstrained optimization by quadratic approximation*，Math. Program.，92 (2002)，第555–582页。

[190], *—On trust region methods for unconstrained minimization without derivatives*，Math. Program.，97 (2003)，第605–623页。

[191], *—Least Frobenius norm updating of quadratic models that satisfy interpolation conditions*，Math. Program.，100 (2004)，第183–215页。

[192] ,*—The NEWUOA software for unconstrained optimization without derivatives*，技术报告 DAMTP 2004/NA08，剑桥大学应用数学与理论物理系，英国，2004年。

[193] C. J. PRICE 和 I. D. COOPE，*Frames and grids in unconstrained and linearly constrained optimization: A nonsmooth approach*，SIAM J. Optim.，14 (2003)，第415–438页。

[194] C. J. PRICE, I. D. COOPE, AND D. BYATT, *A convergent variant of the Nelder-Mead algorithm*, J. Optim. Theory Appl., 113 (2002), pp. 5–19.

[195] C. J. PRICE 和 PH. L. TOINT, *Exploiting problem structure in pattern-search methods for unconstrained optimization*, Optim. Methods Softw., 21 (2006), pp. 479–491.

[196] R. G. REGIS 和 C. A. SHOEMAKER, *Constrained global optimization of expensive black box functions using radial basis functions*, J. Global Optim., 31 (2005), pp. 153–171.

[197] , *Improved strategies for radial basis function methods for global optimization*, J. Global Optim., 37 (2007), 第 113–135 页。[198] , *Parallel radial basis function methods for the global optimization of expensive functions*, European J. Oper. Res., 182 (2007), 第 514–535 页。[199] , *A stochastic radial basis function method for the global optimization of expensive functions*, INFORMS J. Comput., 19 (2007), 第 497–509 页。[200] R. T. ROCKAFELLAR, *Convex Analysis*, Princeton University Press, Princeton, NJ, 1970。[201] H. H. ROSENBROCK, *An automatic method for finding the greatest or least value of a function*, Comput. J., 3 (1960), 第 175–184 页。

[202] A. S. RYKOV, *Simplex algorithms for unconstrained optimization*, Problems Con- trol Inform. Theory, 12 (1983), 第195–208页。

[203] J. SACKS, W. J. WELCH, T. J. MITCHELL, 和 H. P. WYNN, *Design and analysis of computer experiments*, 统计科学, 4 (1989), 第409–423页.

[204] T. J. SANTNER, B. J. WILLIAMS, AND W. I. NOTZ, *The Design and Analysis of Computer Experiments*, Springer-Verlag, 纽约, 2003. [205] T. SAUER AND Y. XU, *On multivariate Lagrange interpolation*, Math. Comp., 64 (1995), pp. 1147–1170.

[206] D. B. SERAFINI, *A Framework for Managing Models in Nonlinear Optimization of Computationally Expensive Functions*, 博士论文, 计算与应用数学系, 莱斯大学, 休斯顿, 德克萨斯州, 1998年。

[207] W. H. SHAWN, *Direct search methods*, 见《无约束优化的数值方法》, W. Murray 编, Academic Press, 伦敦, 1972年, 第13–28页。

[208] T. W. SIMPSON, J. D. POPLINSKI, P. N. KOCH, 和 J. K. ALLEN, *Metamodels for computer-based engineering design: Survey and recommendations*, Engineering with Computers, 17 (2001), 第129–150页。

[209] J. SØNDERGAARD, *Optimization Using Surrogate Models—by the Space Mapping Technique*, 博士论文, 丹麦技术大学信息与数学建模系, 丹麦林比, 2003年。

[210] W. SPENDLEY、G. R. HEXT 和 F. R. HIMSWORTH，*Sequential application of simplex designs in optimisation and evolutionary operation*，《技术计量学》，4 (1962)，第 441–461 页。

[211] M. STEIN，
Large sample properties of simulations using Latin hypercube sampling，Technometrics，29（1987），第143–151页。

[212] D. E. STONEKING, G. L. BILBRO, R. J. TREW, P. GILMORE, AND C. T. KELLEY, *Yield optimization using a GaAs process simulator coupled to a physical device model,* IEEE Trans. Microwave Theory Tech., 40 (1992), pp. 1353–1363.

[213] B. TANG, *Orthogonal array-based Latin hypercubes,* J. Amer. Statist. Assoc., 88 (1993), pp. 1392–1397.

[214] S. W. THOMAS，*Sequential Estimation Techniques for Quasi-Newton Algorithms*，博士论文，康奈尔大学，纽约州伊萨卡，1975年。

[215] PH. L. TOINT 和 F. M. CALLIER, *On the accelerating property of an algorithm for function minimization without calculating derivatives*, J. Optim. Theory Appl., 23 (1978), 第531–547页。 参见同期刊26 (1978)，第465–467页。

[216] V. TORCZON，*On the convergence of the multidirectional search algorithm*，SIAM J. Optim.，1 (1991)，第123–145页。[217] ,
On the convergence of pattern search algorithms，SIAM J. Optim.，7 (1997)，第1–25页。

[218] V. TORCZON 和 M. W. TROSSET, *Using approximations to accelerate engineering design optimization*，第七届AIAA/USAF/NASA/ISSMO多学科分析与优化研讨会论文集，密苏里州圣路易斯，1998年9月。

[219] V. V. TOROPOV，*Simulation approach to structural optimization*，Struct. Multi discip. Optim.，1 (1989)，第 37–46 页。

[220] P. TSENG，*Fortified-descent simplicial search method: A general approach*，SIAM J. Optim.，10 (1999)，第269–288页。

[221] Ö. U ̈GUR, B. KARASÖZEN, M. SCHÄFER, AND K. YAPICI,
Derivative free opti- mization of stirrer configurations, 见《数值数学与高级应用》，Springer-Verlag，柏林，2006年，第1031–1039页。

[222] A. I. F. VAZ 和 L. N. VICENTE，*A particle swarm pattern search method for bound constrained global optimization*，J. Global Optim.，39 (2007)，第197–219页。

[223] L. N. VICENTE, *Space mapping: Models, sensitivities, and trust-regions methods,* Optim. Eng., 4 (2003), pp. 159–175.

[224] H. WHITE，*Asymptotic Theory for Econometricians*，学术出版社，伦敦，1984年。

[225] S. M. WILD, *MNH: A derivative-free optimization algorithm using minimal norm Hessians*, 技术报告 ORIE-1466, 康奈尔大学运筹学与信息工程学院, 纽约州伊萨卡, 2008年。

[226] S. M. WILD、R. G. REGIS 和 C. A. SHOEMAKER, *ORBIT: Optimization by radial basis function interpolation in trust-regions*, SIAM J. Sci. Comput., 30 (2008), 第3197–3219页。

[227] D. WINFIELD,
Function and Functional Optimization by Interpolation in Data Ta- bles, 博士学位论文, 哈佛大学, 剑桥, 马萨诸塞州, 1969年。
[228] , *~~Fun~~ction minimization by interpolation in a data set*, J. Inst. Math. Appl., 12 (1973), 第339–347页。

[229] T. A. WINSLOW, R. J. TREW, P. GILMORE, AND C. T. KELLEY,
Doping profiles for optimum class B performance of GaAs MESFET amplifiers, 载于《IEEE/康奈尔高速器件与电路高级概念会议论文集》, 1991年, 第188–197页。

[230] D. J. WOODS, *An Interactive Approach for Solving Multi-objective Optimization Problems*, 博士论文, 莱斯大学数学科学系, 德克萨斯州休斯顿, 1985年。

[231] M. H. WRIGHT, *Direct search methods: Once scorned, now respectable*, 载于《1995年数值分析》（1995年邓迪双年数值分析会议论文集）, D. F. Griffiths 和 G. A. Watson 编, Pitman Res. Notes Math. Ser. 第344卷, CRC Press, 博卡拉顿, 佛罗里达州, 1996年, 第191–208页。

[232] Y. YE, *A new complexity result on minimization of a quadratic function with a sphere constraint*, 载于《全局优化最新进展》, C. A. Floudas 和 P. M. Pardalos 编, 普林斯顿大学出版社, 新泽西州普林斯顿, 1992年, 第19–31页。

[233] J.-H. YOON 和 C. A. SHOEMAKER, *Comparison of optimization methods for ground-water bioremediation*, 水资源规划与管理杂志, 125 (1999), 第54–63页。

[234] W.-C. YU, *The convergent property of the simplex evolutionary techniques*, Sci. Sinica, 1 (1979), 第269–288页. [235] ,
Positive basis and a class of direct search techniques, Sci. Sinica, 1 (1979), 第53–67页.

[236] Y.-X. YUAN, *An example of non-convergence of trust region algorithms*, 非线性规划进展, Y.-X. Yuan, 编, Kluwer学术出版社, 多德雷赫特, 荷兰, 1998, 第205–215页.

[237] W. I. ZANGWILL, *Minimizing a function without calculating derivatives*, Comput. J., 10（1967）, 第293–296页。

索引

仿射维数, 29 凸包, 29 独立性, 29 算法参数（调优）, 3 方差分析, 6, 234 自动微分, 2 自动误差分析, 3 回溯（线搜索）, 163, 164, 168 障碍 极端障碍函数, 242, 243, 245, 247 基准测试, *see* 数据剖面 黑箱, 2, 242, 249 柯西步, *see* 步 电路设计, 4 克拉克 广义方向导数, 125 非光滑分析, 125, 127, 247 严格可微性, 127 组合优化, 6 通过拉格朗日多项式补全非平衡集, 95, 101–102 通过LU分解, 99–102 条件数, 4, 99, 225, 231 作为良平衡性的度量, 38–39, 48–52, 68–69, 84–86 在误差界中, 52, 54, 69, 79
锥法, 下降方向的 244, 极 125, 由向量正张成的 244, 15–19, 244 切 244, 246 约束 ϵ-活跃, 244 活跃, 244, 245 隐藏, 242, 247 线性, 241, 244–248 可松弛, 241–242, 246–248 简单界, 241, 243–244, 247 不可松弛, 241–242, 247, 248 含导数, 243–246, 248 不含导数, 246–249 收敛 全局（定义）, 120 全局（结果）, 122, 124, 126, 131, 133, 155, 157, 167, 189, 211, 214, 219 全局（二阶临界点结果）, 198, 211, 225 缺乏（Nelder–Mead）, 8, 10, 149 局部, xi, 5, 35, 74, 182 凸, *see also* 锥包, 30, 41 坐标搜索, *see* 方法 余弦测度, *see* 正张成集 克莱姆法则, 41, 71, 77, 82 临界步, 165, 166, 183–185, 192–193, 195

曲率，9–11，35，73，74，80，135，136，141，145，173，174，231 负，177，178，191 正，175

数据剖面，9 分解，*see* 因式分解减小 在方向直接搜索中施加充分减小，134–135 在线搜索中施加充分减小，164 在修改的Nelder–Mead中施加充分减小，150–153 字典序（Nelder–Mead），144–145 简单，116，119，131，132，139，150，162，178，182，183，191，204，208，215，236，245 充分，119，121，135，136，139，159–161，163，165–169，176，178，182，208，211，218，236，237，245–247，*see also* Cauchy减小比例；特征步减小比例；最优减小比例 导数，*see also* 自动微分；单纯形导数；单纯形梯度；单纯形Hessian 有限差分，2，230 广义有限差分，47 下降方向，15 动态定价，5

特征步长，*see* 步工程设计，中心单纯形梯度的4个误差界，多项式插值 一般情况为170，线性情况为56，二次情况为26–28，52–56

对于多项式回归线性情况，28–29 二次情况，69–70 对于单纯形梯度，33 对于欠定二次多项式插值（一般），78–80 对于欠定二次多项式插值（在最小 Frobenius 范数意义下），83–84 在较大同心球中，200–202 类泰勒，35, 64, 69–70, 78, 83, 179 按行分解，26 Cholesky，20 特征值分解，203 高斯消元，*see* LU 分解增长因子，103, 104, 112 LDU，112 LU，99, 101–103, 105, 108 增长因子最小化，3–4 QR，76, 245 奇异值分解（SVD），29, 68, 76 有限差分，*see* 导数强制函数，134, 151, 156, 159, 160, 236 Cauchy 下降比例，176, 220, 237–239 特征步下降比例，177, 223, 238 最优下降比例，178, 205 完全线性（FL），*see also* 模型证书/可证明，91, 180 类，90, 180 完全二次（FQ），*see also* 模型证书/可证明，91, 181 类，91, 181 函数评估，5, 10, *see also* 噪声廉价或低成本，57, 229, 235

昂贵或高成本, xi, 2, 4, 5, 8, 58, 70, 73, 92, 107, 178, 182, 183, 209, 229, 230, 242, 249 噪声, 2, 8, 57, 70, 92

广义模式搜索（GPS），*see*方法
生成集搜索，136–137几何，
*see also*完成；改进；改进；平衡性免除控制，225全局优化，249–250梯度，*see*导数；单纯形地下水社区问题，5组部分可分性，74

黑塞矩阵，*see* 导数；单纯形启发式方法 人工神经网络，6，231 枚举技术，6 进化算法，6 遗传算法，6 粒子群，6，249 基于种群的算法，6 模拟退火，6 禁忌搜索，6 可变邻域搜索，250

隐式过滤，*see* 方法改进，*see* 模型改进算法；模型改进迭代；模型改进步骤改善良好平衡的最小 Frobenius 范数模型，110 回归模型，108–110 通过拉格朗日多项式，95–98 通过拉格朗日多项式（示例），98–99 通过 LU 分解，104–106 通过 LU 分解（示例），106

整数格，123，139，151，236，245
通过全局化，127–130，132，135，136，139，162，245 整数性和合理性要求的严格性，130 插值，*see also* 误差界；拉格朗日多项式；模型；牛顿基本多项式；适定性；唯一性条件，24，37，73

克里金，*see*模型的拉格朗日多项式插值基，39 计算与更新，40，93–94 定义，39 等价定义，41 唯一性，39 体积定义，41 缩放不变性，46，212 平移不变性，46，212 最小Frobenius范数 计算与更新，110 定义，81 等价定义，81 唯一性，87 体积定义，82 最小范数基，77 定义，76 等价定义，77 唯一性，77，87 体积定义，78 回归基，60 计算与更新，108–109 定义，60 等价定义，62 唯一性，60 格，*see* 整数格 勒贝格常数，40

函数在点附近的Lipschitz连续性作为假设，126 梯度的Lipschitz连续性作为假设，23, 26, 28, 79, 90, 122, 166, 167, 179 Hessian的Lipschitz连续性作为假设，52, 69, 91, 170, 180 模型梯度的Lipschitz连续性，92, 112 作为假设，90, 180 模型Hessian的Lipschitz连续性作为假设，91, 181 Lipschitz优化，250

流形Lipschitz，246多项式，38黎曼，246医学图像，5网格自适应直接搜索（MADS），*see*方法网格或网格假设（整数格），128坐标搜索，117一般，127点间最小空间，128其他定义，130–131，139轮询和搜索步骤，128，132搜索步骤，118，132方法增广拉格朗日，246–247坐标搜索，9–11，115–118，125，127，135方向直接搜索，115–139，235–237，242–248分割矩形（DIRECT），250滤波器，247–249广义模式搜索，118，119隐式过滤，7，10–11，163，168–170基于插值的信赖域，10–11，204–205，207–225，248–249

最后手段，6 MADS（网格自适应直接搜索），132–134，136，139，247–248，250 修正的Nelder–Mead方法，149–162 多方向搜索（MDS），137–139，150，161，162 多级坐标搜索（MCS），250 Nelder–Mead方法，1，7，8，10–11，141–149，161 并行，136，168，225，248，250 模式搜索，118，123，135，136 拟牛顿法，5，10，87，168，169，204 序列二次规划（SQP），248–249 单纯形直接搜索，137–139，141–162，237 信赖域，173，225，237–240，248–249 使用线搜索和单纯形导数，163–167 楔形（信赖域），215–225 极小极大优化，250 混合整数规划，250 基于空间映射的模型，239–240 完全线性（FL），90，180，200–201，210–214，218–220 完全二次（FQ），91，181，201–202，210–211，218–220 二次模型的最小Frobenius范数更新，86，212 模型改进算法，91–93，107，110，180，181，183，184，192，193，208，211–213，215 模型改进迭代，185，187，191，193 模型改进步骤，191，193，209，214 代理，229 功能，230 物理，230

Taylor，5，35，36，90，92，173–174，178–181，200，230–231 使用Kriging，233，240 在Frobenius最小范数意义下使用多项式插值，80–81 在最小范数意义下，74–76 线性，24 任意次数，37–38 使用多项式回归 线性，24–25 任意次数，58–59 使用径向基函数，231–233，240 分子几何优化，5 多学科，4 多指标，36 多目标优化，250 自然基（单项式）定义，36 Nelder–Mead方法，*see* 方法 Newton基本多项式（NFPs）定义，46 在DFO中使用，87, 208 噪声，3，5–11，167–168，171，234 一致性，58, 68, 72 含噪函数，*see* 噪声 含噪问题，*see* 噪声 非凸性，5, 6, 108, 149, 202, 246 不可微性，3, 136 非单调，136 非光滑性，11, 58, 123–127, 132, 136, 247 数值比较，10–11，*see also* 数据分布 最优性条件 不等式约束的一阶必要条件，246 简单边界的一阶必要条件，243

并行化难度, 142 并行化容易度, 11, 136, 168 环境, xii, 6, 116, 225 参数, *see also* 单纯形直径; 信赖域半径 网格尺寸, 115, 118 有界, 129 收敛至零, 135 子序列收敛至零, 121, 123 步长, 115, 118, 164 有界, 129 收敛至零, 135 子序列收敛至零, 121, 123 模式, *see also* 整数格; 网格或网格生成器, 127 枢轴多项式, 101, 209–211, 216–218 枢轴算法, 89, 99–109, 209–211 平衡性, *see also* 完成; 条件数; 改进; 拉格朗日多项式; 牛顿基本多项式 Λ-平衡性 多项式插值, 42 多项式回归, 63 多项式回归（强）, 65 欠定多项式插值（最小范数意义）, 78 欠定二次多项式插值（最小Frobenius范数意义）, 82 多项式插值线性, 24 多项式回归线性, 25 轮询, *see also* 轮询步骤 轮询向量或方向, 116

并行，*see also* 方法异步，136，248

多项式，*see also* 流形；模型；自然基（单项式的）；枢轴基，36 空间，36 尾部，232 正，*see also* 正基；正生成集依赖性，16 生成元，244–247 独立性，16 张成，15 正基，*see also* 正生成集定义，16 示例，19–21，30 最大，16 最小，16 均匀，21 正生成集的特征，17 余弦测度，22 定义，16 下降特征的含义，19 径向基函数（RBF），*see also* 全局优化；模型；唯一性 条件正定，232，240 回归，*see also* 误差界；拉格朗日多项式；模型；适定性；唯一性 ℓ_1，60 条件，25，58 正则化，70–71 响应曲面法（RSM），234–235 采样，*see also* 补全；改进；插值；模型；适定性；回归；起始；欠定插值 D-最优性，234 密集，234

计算机实验设计与分析（DACE），234 实验设计，234 拉丁超立方体，234 正交阵列，234 矩阵缩放，27，28，54，79 系统，46 串行环境或机器，5，136，168 样本集的平移与缩放，48–49，68，84，90，96–99，103–104，210，217 单纯形 中心单纯形 梯度，169 导数，136，169，170 其直径，30 其直径（收敛至零），153 梯度（作为插值模型的梯度），33 梯度（作为回归模型的梯度），33 梯度（定义），32 梯度（误差界），33 Hessian（定义），170 其归一化体积，31 重启，160 集合，30 其形状，30 起始，150，161 其顶点，30 其体积，30 仿真，*see also* 黑箱 PowerSpice，4 起始，*see also* 起始单纯形 可行点，242，247 点，120，125，126，236，239 样本集，100–102，107 模板梯度，33 半径，33 集合，33 步长 Cauchy，175–176

临界性，165，183，184，192，193，210，213，218，221，224，225 特征步，177–178 轮询步，*see also* 网格或网格完全轮询，116，131–132，139，157，215 误差界（不成功轮询），23，122，134 机会主义轮询，116，118，119，136 搜索步，*see also* 网格或网格使用代理，235–237 随机优化，6 停止准则，8，10，120，123，138，144，152，165，182 代理，*see also* 模型严格优化框架，4，235–240 泰勒，*see* 误差界；模型提前或过早终止，5，8，242 信赖域，*see* 方法半径，174 收敛到零，188，197 更新，178–179，184，193 子问题，175，202–204，220，223，238–239，248–249 子问题（楔形），216，221，223

条件，73 在最佳子基意义下，74–76 一致有界远离零余弦测度，119，122，123 步长，130 体积，97 范数等价中的常数，49 独立于样本点数量，70 模型 Hessian，83，186 改进步数，91，96，164，165，180，181，184，193，211，212，214，215 迭代次数，182，187 不成功迭代次数，219，220 平衡常数，179 唯一性，*see also* 拉格朗日多项式插值多项式，38 缺乏（在空间映射模型中），240 径向基函数模型，232 回归多项式，59 欠定最小 Frobenius 范数多项式，81，87 唯一可解，*see also* 平衡集，38

欠定插值，*see also* 误差界；拉格朗日多项式；模型；适定性；唯一性

楔形法，*see also* 方法；信赖域子问题约束，215–220