Jonas Peters, Dominik Janzing, and Bernhard Schölkopf

Elements of Causal Inference

Foundations and Learning Algorithms

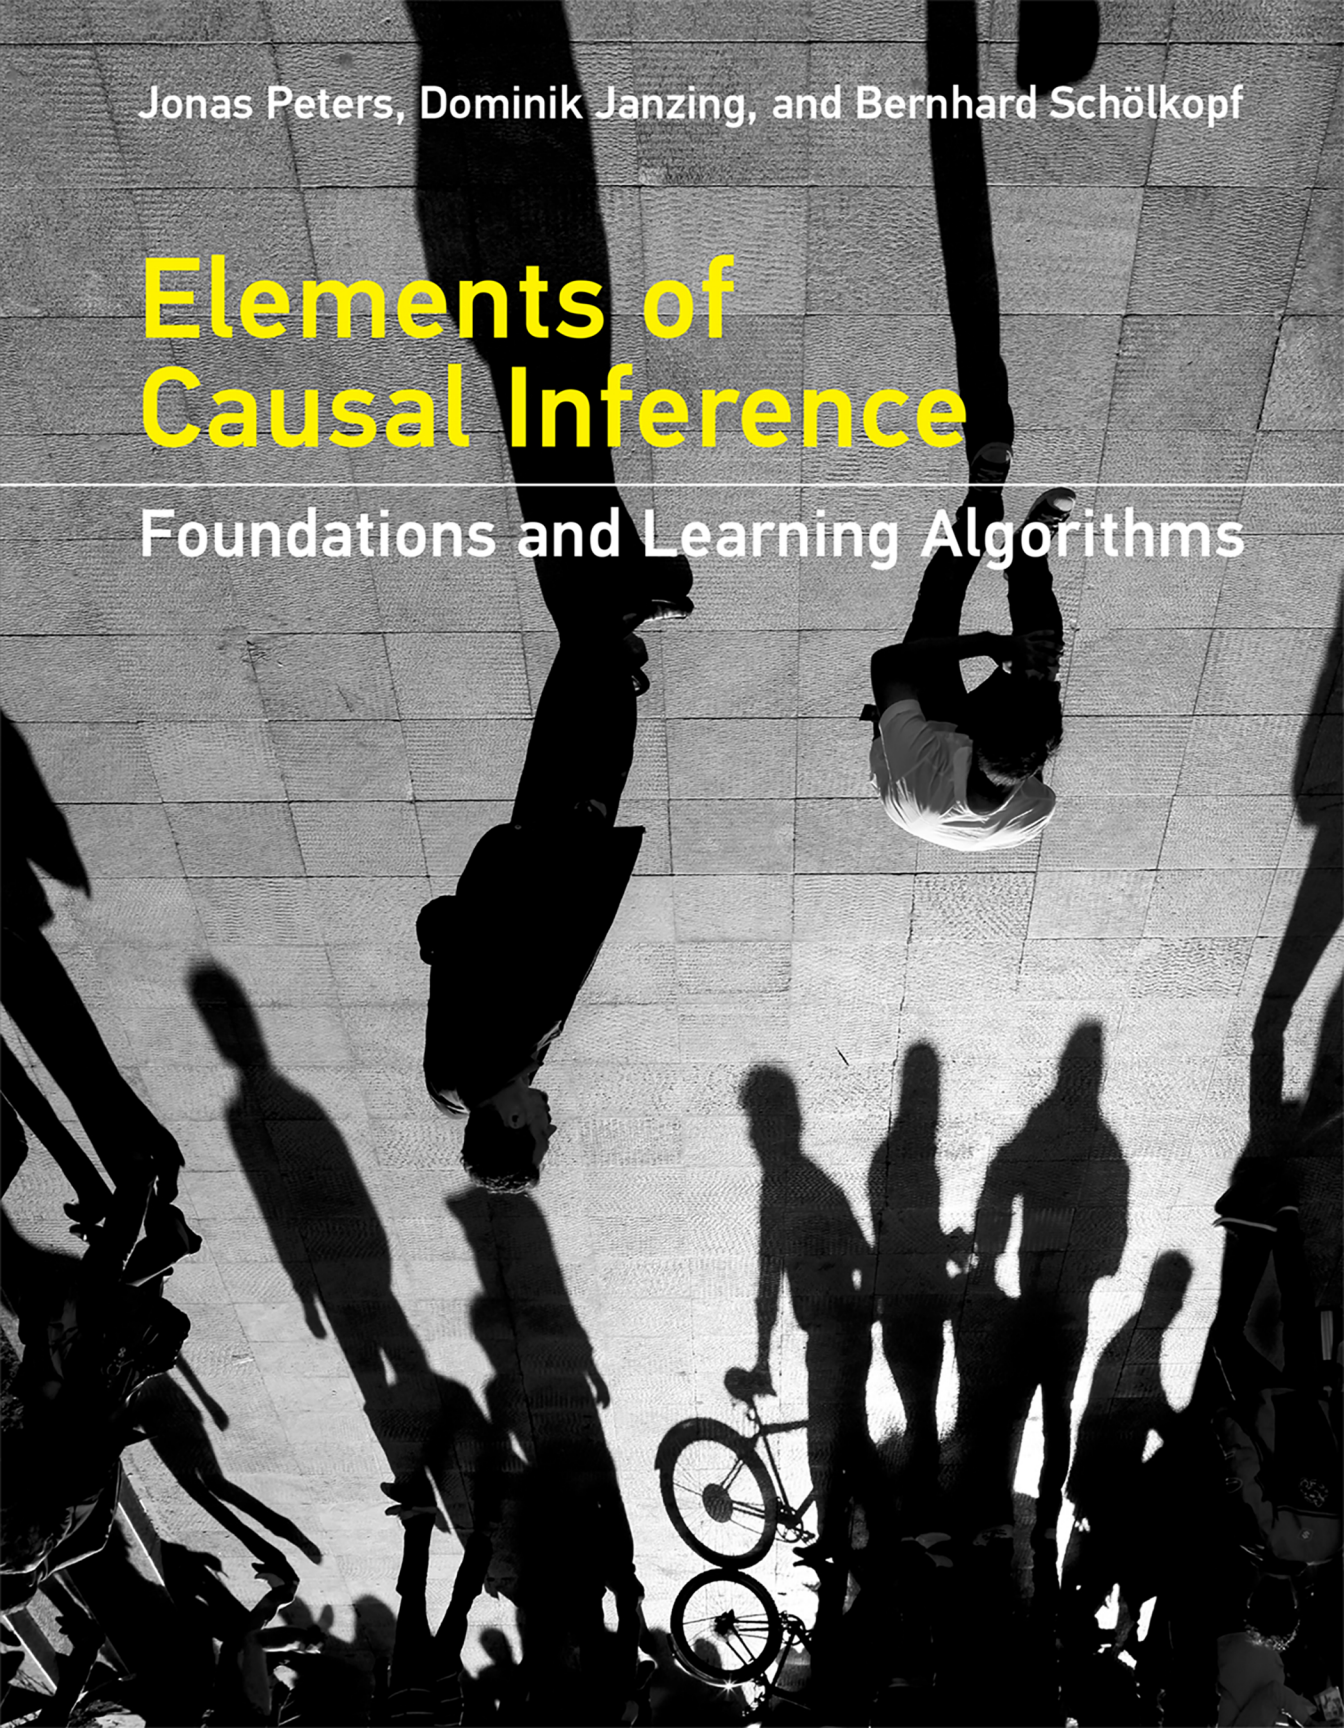

因果推断的要素

Foundations and Learning Algorithms

自适应计算与机器学习
Francis Bach，编辑

Christopher Bishop、David Heckerman、Michael Jordan 和 Michael Kearns，副主编

《自适应计算与机器学习》系列已出版书籍的完整列表出现在本书末尾。

因果推断的要素

基础与学习算法

Jonas Peters、Dominik Janzing 和 Bernhard Schölkopf

The MIT Press
Cambridge, Massachusetts
London, England

© 2017 Massachusetts Institute of Technology

本作品依据知识共享署名-非商业性-禁止演绎 4.0 国际许可协议向公众授权：http://creativecommons.org/licenses/by-nc-nd/4.0/

除根据上文所标识的知识共享许可协议授权的内容外，保留所有权利。任何未经上述授权的复制或其他使用，无论通过任何电子或机械手段（包括但不限于影印、公开分发、在线展示以及数字信息的存储与检索），均须获得出版商的书面许可。

本书由作者使用 LaTeX 排版。

在美国印刷并装订。

美国国会图书馆编目出版数据　姓名Peters, Jonas。| Janzing, Dominik。| Schölkopf, Bernhard。书名：Elements of causal inference：foundations and learning algorithms / Jonas Peters, Dominik Janzing, and Bernhard Schölkopf。出版说明：Cambridge, MA：MIT Press，2017。| 丛书：Adaptive computation and machine learning series | 包含参考文献和索引。标识符：LCCN 2017020087 | ISBN 9780262037310（精装：alk. paper）主题：LCSH：Machine learning。| Logic, Symbolic and mathematical。| Causa- tion。| Inference。| Computer algorithms。分类：LCC Q325.5 .P48 2017 | DDC 006.3/1–dc23 LC 记录可在 https://lccn.loc.gov/2017020087

10 9 8 7 6 5 4 3 2 1

To all those who enjoy the pursuit of causal insight

目录

前言 xi

符号与术语 xv

1 统计与因果模型 1
1.1 概率论与统计学 . . . . . 1 1.2 学习理论 . . . . . 3 1.3 因果建模与学习 . . . . . 5 1.4 两个例子 7

2 因果推断的假设 15
2.1 独立机制原理 . . . . . 16 2.2 历史注释 . . . . . 22 2.3 因果模型底层的物理结构 26

3 因果模型 33
3.1 结构因果模型 . . . . . 33 3.2 干预 . . . . . 34 3.3 反事实 . . . . . 36 3.4 结构因果模型的规范表示 . . . . . 37 3.5 习题 39

4 学习因果模型 43
4.1 结构可辨识性 . . . . . 44 4.2 结构辨识方法 . . . . . 62 4.3 问题 69

5 与机器学习的联系，I 71
5.1 半监督学习 . . . . . 715.2 协变量偏移 . . . . . 775.3 问题 79

6 多元因果模型 81
6.1 图论术语 . . . . . 816.2 结构因果模型 . . . . . 836.3 干预 . . . . . 886.4 反事实 . . . . . 966.5 马尔可夫性质、忠实性与因果最小性 . . . . . 1006.6 通过协变量调整计算干预分布 . 1096.7 Do-演算 . . . . . 1186.8 因果模型的等价性与可证伪性 . . . . . 1206.9 潜在结果 . . . . . 1226.10 关联单个对象的广义结构因果模型 . . 1266.11 条件的算法独立性 . . . . . 1296.12 习题 132

7 学习多元因果模型 135
7.1 结构可辨识性 . . . . . 136 7.2 结构辨识方法 . . . . . 142 7.3 问题 155

8 与机器学习的联系，II 157
8.1 半同胞回归 . . . . . 157 8.2 因果推断与情节强化学习 . . . . . 159 8.3 领域适应 . . . . . 167 8.4 习题 169

9 隐变量 171
9.1 干预充分性 . . . . . 1719.2 辛普森悖论 . . . . . 1749.3 工具变量 . . . . . 1759.4 条件独立性与图形表示 . . . . . 1779.5 超越条件独立性的约束 . . . . . 1859.6 习题 195

10 时间序列 197
10.1 预备知识与术语 . . . . . 197 10.2 结构因果模型与干预 . . . . . 199 10.3 学习因果时间序列模型 . . . . . 201 10.4 动态因果建模 . . . . . 210 10.5 习题 211

附录

附录 A 一些概率与统计 213
A.1 基本定义 . . . . . 213 A.2 独立性与条件独立性检验 . . . . . 216 A.3 函数类容量 219

Ap附录 B 因果顺序与邻接矩阵 第221页

附录 C 证明 225
C.1 定理 4.2 的证明 . . . . . 225C.2 命题 6.3 的证明 . . . . . 226C.3 注 6.6 的证明 . . . . . 226C.4 命题 6.13 的证明 . . . . . 226C.5 命题 6.14 的证明 . . . . . 228C.6 命题 6.36 的证明 . . . . . 228C.7 命题 6.48 的证明 . . . . . 228C.8 命题 6.49 的证明 . . . . . 229C.9 命题 7.1 的证明 . . . . . 230C.10 命题 7.4 的证明 . . . . . 230C.11 命题 8.1 的证明 . . . . . 230C.12 命题 8.2 的证明 . . . . . 231C.13 命题 9.3 的证明 . . . . . 231C.14 定理 10.3 的证明 . . . . . 232C.15 定理 10.4 的证明 232

参考文献 235

Index **263**

前言

因果性是一个引人入胜的研究主题。其数学化仅在相对较近的时期才开始，许多概念性问题仍在被激烈辩论——常常伴随着相当大的强度。

尽管本书总结了我们花费十年时间研究因果关系的成果，但其他人研究这一问题的时间远比我们长，且关于因果关系的书籍已存在，包括 Pearl [2009]、Spirtes et al. [2000] 以及 Imbens and Rubin [2015] 的全面论述。我们希望本书能够在两个方面补充现有工作。

首先，本书对因果性的一子问题存在偏向，这一子问题可被视为既最为根本又最不现实。这就是因果问题：所分析的系统仅包含两个可观测量。在过去十年中，我们对这一问题进行了较为详细的研究。我们报告了这项工作的许多内容，并试图将其嵌入到一个更大的背景中，这一背景是我们认为对于获得对因果问题的选择性但深刻理解至关重要的。尽管按照章节顺序先研究双变量情况可能具有启发性，但也可以直接开始阅读多变量章节；见图 I。

其次，我们的论述受机器学习与计算统计学领域的激励与影响。我们关注这些方法如何帮助因果结构的推断，更关注因果推理能否指导我们开展机器学习的方式。事实上，我们认为，机器学习中一些最深刻的开放问题，若不以由概率分布描述的随机实验为起点，而是考虑分布背后的因果结构，则能得到最佳理解。

我们试图对该主题提供系统介绍，使熟悉概率论、统计学或机器学习基础的读者能够理解。

学习（为完整起见，最重要的概念总结在附录 A.1 和 A.2 中）。

尽管我们在 Pearl [2009] 和 Spirtes et al. [2000] 所代表的因果关系图形方法基础上构建，但个人偏好影响了主题的选择。为保持本书易读并聚焦概念问题，我们不得不遗憾地将极少篇幅留给因果关系中的若干重要议题，无论是特定情境下的高级理论洞见，还是各种具有实际重要性的方法。我们已尽量为一些最明显的遗漏提供文献参考，但可能仍遗漏了重要主题。

本书存在若干不足。其中一些源于该领域本身，例如理论结果往往仅限于数据量无限的情形。尽管我们为有限数据情形提供了算法与方法，但未讨论此类方法的统计性质。此外，在某些地方我们忽略了测度论问题，常通过假设密度存在来简化处理。我们认为所有这些问题都既相关又有趣，但做出这些取舍是为了保持本书简洁，并使其易于广泛读者理解。

另一个免责声明在此提出。计算因果方法仍处于起步阶段，特别是，从数据中学习因果结构只在相当有限的情况下才可行。我们已尽可能地包含具体算法，但我们深刻意识到，许多因果推断问题比典型的机器学习问题更难，因此我们不承诺这些算法是否能解决读者的问题。请不要因为这句话而感到气馁——因果学习是一个迷人的话题，我们希望阅读本书能说服你开始从事这方面的工作。

没有众多人的支持，我们不可能完成这本书。

我们衷心感谢为三位作者在 Mathematisches Forschungsinstitut Oberwolfach 进行的“Research in Pairs”访问提供的支持，期间本书的很大一部分内容得以完成。

我们感谢 Michel Besserve、Peter Bühlmann、Rune Christiansen、Frederick Eberhardt、Jan Ernest、Philipp Geiger、Niels Richard Hansen、Alain Hauser、Biwei Huang、Marek Kaluba、Hansruedi Künsch、Steffen Lauritzen、Jan Lemeire、David Lopez-Paz、Marloes Maathuis、Nicolai Meinshausen、Søren Wengel Mogensen、Joris Mooij、Krikamol Muandet、Judea Pearl、Niklas Pfister、Thomas Richardson、Mateo Rojas-Carulla、Eleni Sgouritsa、Carl Johann Simon-Gabriel、Xiaohai Sun、Ilya Tolstikhin、Kun Zhang 和 Jakob Zscheischler 在本书撰写期间提供的许多有益评论和有趣讨论。特别是，

Weather dependent processes
Figure 6.2: Path with segmented regression that predicts the number of bicycles rented depending on weather, day and time.
Bicycle Rentals
Temperature
Humidity
Wind Speed
Days since 2011
Trend
Seasonal
Misc
Predictors
Contribution to Predictions

Joris 和 Kun 参与了本文所呈现的大部分研究。

我们感谢卡尔斯鲁厄理工学院、Eidgenössische Technische Hochschule Zürich 和 University of Tübingen 的多位学生校对本书早期版本，并提出了许多启发性问题。

最后，我们感谢匿名评审人以及 Westchester Publishing Services 的校对团队提出的宝贵意见，也感谢 MIT Press 的工作人员，特别是 Marie Lufkin Lee 和 Christine Bridget Savage，在整个过程中给予的热情支持。

哥本哈根和Tübingen，2017年8月

Jonas Peters
Dominik Janzing
Bernhard Schölkopf

符号与术语

X, Y, Z 随机变量；对于噪声变量，我们使用 N、N_X、N_j、…、x 随机变量 X 的值 P 概率测度 P_X X $X^1, \ldots, X^n \overset{\text{iid}}{\sim} P_X$ 的概率分布 大小为 n 的独立同分布样本；样本索引通常为 i $P_{Y|X=x}$ Y 在给定 $X = x$ $P_{Y|X}$ 下的条件分布 对所有 x 的 $P_{Y|X=x}$ 的集合；简称：X 条件下的 Y 密度（概率质量函数或概率密度函数）p_X P_X $p(x)$ 的密度 在点 x $p(y|x)$ （处评估的 P_X 的密度 在 y $\mathbb{E}$ 处评估的 $P_{Y|X=x}$ 的条件)密度 $[X]$ X 的期望 var$[X]$ X 的方差 cov$[X, Y]$ X, Y $X \perp\!\!\!\perp Y$ 的协方差 随机变量 X 和 Y $X \perp\!\!\!\perp Y \mid Z$ 之间的独立性 条件独立性 $\mathbf{X} = (X_1, \ldots, X_d)$ 长度为 d 的随机向量；维度索引通常为 j $\mathfrak{C}$ 结构因果模型 $P_Y^{\mathfrak{C};do(X:=3)}$ 干预分布 $P_Y^{\mathfrak{C}|Z=2,X=1;do(X:=3)}$ 反事实分布 $\mathcal{G}$ 图 $\text{PA}_X^{\mathcal{G}}$、$\text{DE}_X^{\mathcal{G}}$、$\text{AN}_X^{\mathcal{G}}$ 图 $\mathcal{G}$ 中节点 X 的父母、后代和祖先

1

统计与因果模型

利用统计学习，我们试图从观测数据中推断随机变量之间依赖关系的性质。例如，基于两个随机变量的联合观测样本，我们可以构建一个预测器：在仅给定其中一个的新值时，它能对另一个提供良好的估计。这类预测背后的理论已相当成熟，尽管它适用于简单场景，但已为从数据中学习提供了深刻的洞见。出于两个原因，我们将在本章描述其中一些洞见。首先，这将帮助我们理解*causal*推断问题要困难得多：其底层模型不再是固定的随机变量联合分布，而是蕴含多种此类分布的结构。其次，尽管因果估计的有限样本结果稀缺，但重要的是要记住，当转向更复杂的因果设定时，基本的统计估计问题并不会消失，即使与纯统计学习中未出现的因果问题相比，它们看起来微不足道。在前述基础上，本章还通过两个例子（其中一个在机器学习中广为人知）温和地介绍了因果性的基本概念。

1.1 概率论与统计学

概率论与统计学基于随机实验或概率空间（$\Omega, \mathcal{F}, P$）的模型。在这里，Ω 是一个集合（包含所有可能的结果），$\mathcal{F}$ 是事件的集合 $A \subseteq \Omega$，而 P 是一个为每个事件分配概率的测度。概率论使我们能够根据前述数学结构推理随机实验的结果。统计学习，在

另一方面，本质上处理的是逆问题：我们被给出实验的结果，并由此推断底层数学结构的性质。例如，假设我们已经观测到数据

$$(x_1, y_1), \ldots, (x_n, y_n), \tag{1.1}$$

其中 $x_i \in \mathcal{X}$ 是输入（有时称为协变量或案例），而 $y_i \in \mathcal{Y}$ 是输出（有时称为目标或标签）。我们现在可以假设每个 (x_i, y_i)，$i = 1, \ldots, n$，都是由同一个未知的随机实验独立生成的。更精确地说，这种模型假设观测值 (x_1, y_1) $, \ldots, (x_n, y_n)$ 是随机变量 $(X_1, Y_1), \ldots, (X_n, Y_n)$ 的实现，这些随机变量是独立同分布（i.i.d.）的，联合分布为 $P_{X,Y}$。这里，X 和 Y 是取值于度量空间 $\mathcal{X}$ 和 $\mathcal{Y}$ 的随机变量。[1] 统计学和机器学习几乎全部建立在 i.i.d. 数据之上。在实践中，i.i.d. 假设可能以各种方式被违反，例如分布发生偏移或系统中发生干预。正如我们稍后将看到的，其中一些与因果关系密切相关。

我们现在可能对 $P_{X,Y}$ 的某些性质感兴趣，例如：

(i) 在给定输入条件下输出的期望，$f(x) = \mathbb{E}[Y \,|\, X = x]$，称为回归，其中通常 $\mathcal{Y} = \mathbb{R}$，

(ii) 一个二分类器，将每个 x 分配到更可能的类别，$f(x) = \operatorname{argmax}_{y \in \mathcal{Y}} P(Y = y \,|\, X = x)$，其中 $\mathcal{Y} = \{\pm 1\}$，

(iii) $P_{X,Y}$ (的密度 $p_{X,Y}$，假设它存在)。

在实践中，我们试图从有限数据集估计这些性质，即基于样本 (1.1)，或等价地基于经验分布 $P^n_{X,Y}$，它在每个观测值上放置等权重的点质量。

这构成了一个逆问题：我们希望估计一个无法直接观测的对象的属性（底层分布），基于通过对该底层对象施加操作（在本例中：从未知分布中采样）所获得的观测结果。

[1] A random variable X is a measurable function $\Omega \to \mathcal{X}$, where the metric space $\mathcal{X}$ is equipped with the Borel σ-algebra. Its distribution P_X on $\mathcal{X}$ can be obtained from the measure P of the underlying probability space $(\Omega, \mathcal{F}, P)$. We need not worry about this underlying space, and instead we generally start directly with the distribution of the random variables, assuming the random experiment directly provides us with values sampled from that distribution.

1.2 学习理论

现在假设，就像我们可以从 $P_{X,Y}$ 获得 f 一样，我们使用经验分布来推断经验估计 f^n。这被证明是一个不适定问题 [例如，Vapnik, 1998]，因为对于我们在样本中未见过的任何 x 值 $(x_1, y_1), \ldots, (x_n, y_n)$，条件期望是未定义的。然而，我们可以在观测样本上定义函数 f，并根据任意固定规则将其扩展（例如，在样本外将 f 设为 $+1$，或选择一个连续分段线性的 f）。但对于任何这样的选择，输入的微小变化，即经验分布的微小变化，都可能导致输出的巨大变化。无论我们有多少观测值，经验分布通常不会完美近似真实分布，而这种近似中的微小误差可能导致估计中的巨大误差。这意味着，如果没有关于我们选择经验估计 f^n 所来自的函数类的额外假设，我们无法保证这些估计在适当意义上近似最优量 f。在统计学习理论中，这些假设以容量度量的形式被形式化。如果我们使用的函数类足够丰富，能够拟合大多数可想象的数据集，那么我们能够拟合手头的数据也就不足为奇了。然而，如果函数类被先验地限制为具有小容量，那么（在所有可能数据集的空间中）只有少数数据集可以用该类中的函数解释。如果事实证明我们仍然能够解释手头的数据，那么我们有理由相信我们发现了数据背后的规律性。在这种情况下，我们可以对从同一分布 $P_{X,Y}$ 中抽取的未来数据上的解的准确性给出概率保证。

另一种理解方式是，我们的函数类已融入了先验知识（例如函数的平滑性），这些知识与观测数据底层的正则性一致。这类知识可以通过多种方式融入，不同的机器学习方法在处理这一问题上存在差异。在贝叶斯方法中，我们在函数类和噪声模型上指定先验分布。在正则化理论中，我们构造合适的正则化项，并将其纳入优化问题，以偏向我们的解。

统计学习的复杂性主要源于这样一个事实：我们试图基于经验数据解决一个逆问题——如果给定完整的概率模型，那么所有这些问题都会消失。当我们讨论因果模型时，我们将看到，从某种意义上说，因果学习问题更难，因为它是不适定的 *on two levels*。除了统计上的不适定性——这本质上是因为任意大小的有限样本永远不会包含关于底层分布的所有信息——还有由于

即使完全掌握观测分布，通常也无法确定底层因果模型这一事实

让我们更详细地考察统计学习问题，重点关注二元模式识别或分类的情况 [例如，Vapnik, 1998]，其中 $\mathcal{Y} = \{\pm 1\}$。我们试图根据由未知 $P_{X,Y}$ 独立同分布生成的观测值 (1.1) 学习 $f: \mathcal{X} \to \mathcal{Y}$。我们的目标是最小化期望误差或风险[2]

$$R[f] = \int \frac{1}{2} |f(x) - y| \, dP_{X,Y}(x,y) \tag{1.2}$$

对某类函数 $\mathcal{F}$。注意，这是一对测度 $P_{X,Y}$ 的积分；然而，如果 $P_{X,Y}$ 允许存在相对于勒贝格测度的密度 $p(x,y)$，则积分简化为 $\int \frac{1}{2} |f(x) - y| \, p(x,y) \, dxdy$。

由于 $P_{X,Y}$ 未知，我们无法计算 (1.2)，更不用说将其最小化。相反，我们诉诸归纳原理，例如经验风险最小化。我们返回最小化训练误差或经验风险的函数

$$R^n_{\text{emp}}[f] = \frac{1}{n} \sum_{i=1}^{n} \frac{1}{2} |f(x_i) - y_i| \tag{1.3}$$

在 $f \in \mathcal{F}$ 上。从渐近角度来看，重要的是要问这样一个过程是否一致，这本质上意味着它产生一个函数序列，其风险收敛到给定函数类 $\mathcal{F}$ (内的最小可能值，依概率)，当 n 趋于无穷大时。在附录 A.3 中，我们表明这只有在函数类“较小”时才可能。Vapnik-Chervonenkis (VC) 维度 [Vapnik, 1998] 是衡量函数类容量或大小的一种可能性。它还允许我们推导出有限样本保证，表明以高概率，风险 (1.2) 不大于经验风险加上一个随函数类 $\mathcal{F}$ 大小增长的项。

该理论与关于通用一致性的现有结果并不矛盾，这些结果指的是学习算法收敛到最低可达风险，使用 *any* 函数。存在通用一致的学习算法，例如最近邻分类器和支持向量机 [Devroye et al., 1996, Vapnik, 1998, Schölkopf and Smola, 2002, Steinwart and Christmann, 2008]。虽然通用一致性本质上告诉我们一切都可以被学习

[2] This notion of risk, which does not always coincide with its colloquial use, is taken from statistical learning theory [Vapnik, 1998] and has its roots in statistical decision theory [Wald, 1950, Ferguson, 1967, Berger, 1985]. In that context, $f(x)$ is thought of as an action taken upon observing x, and the loss function measures the loss incurred when the state of nature is y.

无限数据的极限并不意味着每个问题都能从有限数据中学得很好，这源于慢速率现象。对于任何学习算法，都存在学习速率任意慢的问题 [Devroye et al., 1996]。然而，它确实告诉我们，如果我们固定分布，并收集足够的数据，那么最终我们可以任意接近最低风险。

实际上，机器学习系统近期的成功似乎表明，我们确实有时已经处于这种渐近状态，且常常取得惊人的结果。人们投入了大量思考来设计最数据高效的方法，以从给定数据集获得最佳可能结果，同时也付出了大量努力来构建大型数据集，使我们能够训练这些方法。然而，在所有这些场景中，至关重要的是底层分布在训练和测试之间不会发生差异，无论是由于干预还是其他变化。正如我们将在本书中论证的那样，仅将底层规律描述为概率分布，而不引入额外结构，并不能为我们提供描述可能发生变化的正确手段。

1.3 因果建模与学习

因果建模从另一个、可能更为根本的结构开始。因果结构 *entails* 概率模型，但它包含了后者所包含的额外信息 *not*（参见第 1.4 节中的示例）。根据本书所使用的术语，因果推理指的是从因果模型中得出结论的过程，类似于概率论使我们能够推理随机实验的结果。然而，由于因果模型包含比概率模型更多的信息，因果推理比概率推理更强大，因为因果推理使我们能够分析干预或分布变化的效果。

正如统计学习表示概率论的逆问题，我们可以思考如何从其经验含义中推断因果结构。这些经验含义可以是纯粹观察性的，但也可以包括干预下的数据（例如随机试验）或分布变化。研究人员使用各种术语来指代这些问题，包括结构学习和因果发现。我们将与之密切相关的问题——即因果结构的哪些部分原则上可以从联合分布中推断出来——称为结构可识别性。与第1.2节描述的标准统计学习问题不同，即使完全了解P也无法使解法变得平凡，我们需要额外的假设（见第2、4和7章）。这种困难应当

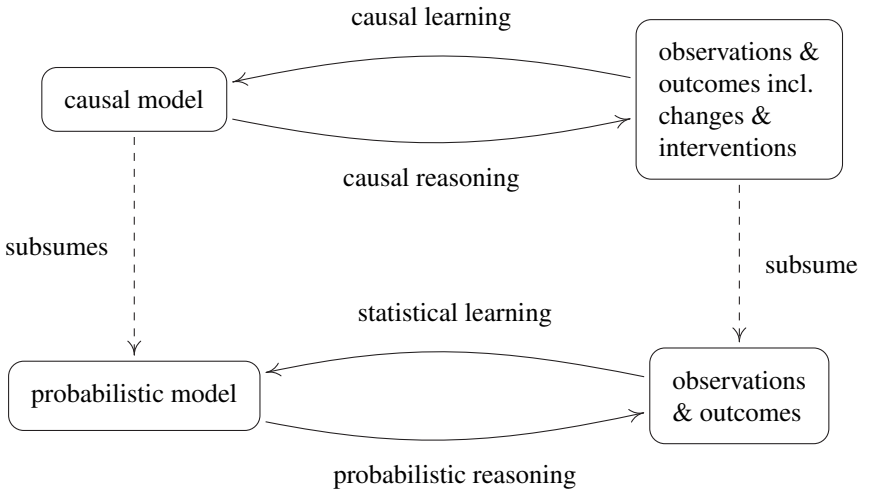

图1.1：本书对各种概率推断问题（下）和因果推断问题（上）所使用的术语；参见第1.3节。注意，我们使用术语“推断”来包括学习和推理。

然而，这并不能让我们忽视这样一个事实：常规统计问题的不适定性仍然存在（因此，在因果关系中关注函数类的容量也很重要，例如通过使用加性噪声模型——见下文第4.1.4节），只是由于我们试图估计比单纯概率结构更丰富的结构，这带来了额外的困难。我们将把这个整体问题称为因果学习。图1.1总结了前述问题与模型之间的关系。

要从观测分布中学习因果结构，我们需要理解因果模型与统计模型之间的关系。我们将在第4章和第7章回到这个问题，但现在先给出一个例子。一个众所周知的命题认为 *correlation does not imply causation*；换句话说，仅靠统计性质无法确定因果结构。较少为人所知的是，人们可以假设：虽然我们无法推断出具体的因果结构，但至少可以从统计依赖中推断出因果联系的存在。这一点最早由 Reichenbach [1956] 理解；我们现在来形式化他的洞见（参见图 1.2）。[3]

[3]For clarity, we formulate some important assumptions as *principles*. We do not take them for granted throughout the book; in this sense, they are not axioms.

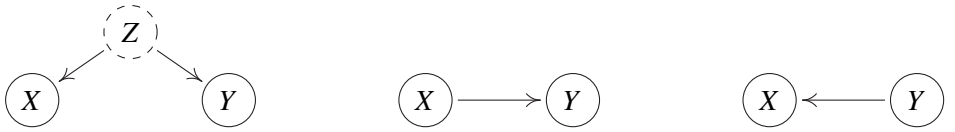

图 1.2：Reichenbach 的共同原因原理建立了统计性质与因果结构之间的联系。两个可观测量 X 和 Y 之间的 *statistical* 依赖表明，它们被变量 Z 所 *caused*，该变量通常被称为混杂因素（左）。在此，Z 可能与 X 或 Y 重合，在这种情况下图形简化（中/右）。该原理进一步论证，X 和 Y 在条件 Z 下是统计独立的。在本图中，直接因果关系由箭头表示；参见第 3 章和第 6 章。

原理 1.1（Reichenbach 的共同原因原理）*If two random variables X and Y are statistically dependent ($X \not\perp\!\!\!\perp Y$), then there exists a third variable Z that* 因果地 *influences both. (As a special case, Z may coincide with either X or Y.) Furthermore, this variable Z screens X and Y from each other in the sense that given Z, they become independent, $X \perp\!\!\!\perp Y \,|\, Z$.*

实际中，依赖关系也可能由于与共同原因原则中提到的原因不同的原因而产生，例如：(1) 我们观察到的随机变量受其他变量的条件约束（通常是由于选择偏差隐含地造成的）。我们将回到这个问题；见备注 6.29。(2) 随机变量仅 *appear* 是依赖的。例如，它们可能是对大量随机变量对进行搜索程序的结果，且该程序未进行多重检验校正。在这种情况下，推断变量之间存在依赖关系不能满足所需的 I 类错误控制；见附录 A.2。(3) 同样，两个随机变量可能继承时间依赖性，并遵循简单的物理规律，例如指数增长。变量随后 *look*，仿佛它们彼此依赖，但由于独立同分布假设被违反，没有理由应用标准独立性检验。特别是，当报告随机变量之间的“虚假相关性”时（正如许多热门网站所做的那样），应牢记论点 (2) 和 (3)。

1.4 两个例子

1.4.1 模式识别

作为第一个例子，我们考虑 *optical character recognition*，这是机器学习中一个被充分研究的问题。这不是因果结构的普通例子，但对于熟悉机器学习的读者来说，它可能具有启发性。我们

描述两个因果模型，它们产生两个随机变量之间的依赖关系，我们将假设这两个随机变量分别是手写数字 X 和类别标签 Y。这两个模型将导致相同的统计结构，但使用不同的底层因果结构。

模型 (i) 假设我们通过向人类书写者提供一系列类别标签 y 来生成每对观测，并指示其始终生成对应的手写数字图像 x。我们假设书写者尽力做好，但在感知类别标签和执行绘制图像的运动程序时可能存在噪声。我们可以将图像 X 建模为类别标签 Y (（建模为随机变量)）和某些独立噪声 N_X (的函数（或机制）f，参见图 1.3 左)。然后我们可以从 P_Y、P_{N_X} 和 f 计算 $P_{X,Y}$。这被称为观测分布，其中“观测”一词指的是我们在不干预的情况下被动观察系统这一事实。X 和 Y 将是依赖的随机变量，我们将能够从观测中学习从 x 到 y 的映射，并从图像 x 预测正确标签 y，其准确率优于随机猜测。

在这个因果结构中有两种可能的干预，它们会产生干预分布。[4] 如果我们对生成的图像 X (进行干预，通过操纵它，或在其生成后将其替换为另一张图像)，那么这对提供给写作者并记录在数据集中的类别标签没有影响。形式上，改变 X 对 Y 没有影响，因为 $Y := N_Y$。另一方面，对 Y 进行干预相当于改变提供给写作者的类别标签，这显然会对生成的图像产生强烈影响。形式上，改变 Y 对 X 有影响，因为 $X := f(Y, N_X)$。这种方向性在图中的箭头中可见，我们将这条箭头视为代表直接因果关系。

在替代模型（ii）中，我们假设我们 *do not* 向书写者提供类别标签。相反，书写者被要求自己决定写哪些数字，并将类别标签一并记录。在这种情况下，图像 X 和记录的类别标签 Y 都是书写者意图（称之为 Z，并将其视为随机变量）的函数。为了通用性，我们假设不仅生成图像的过程存在噪声，而且记录类别标签的过程也存在噪声，同样具有独立的噪声项（见图 1.3，右）。注意，如果函数和噪声项选择得当，我们可以确保该模型蕴含的观测分布 $P_{X,Y}$ 与模型（i）所蕴含的观测分布完全相同。[5]

[4] We shall see in Section 6.3 that a more general way to think of interventions is that they change functions and random variables.

[5] Indeed, Proposition 4.1 implies that *any* joint distribution $P_{X,Y}$ can be entailed by both models.

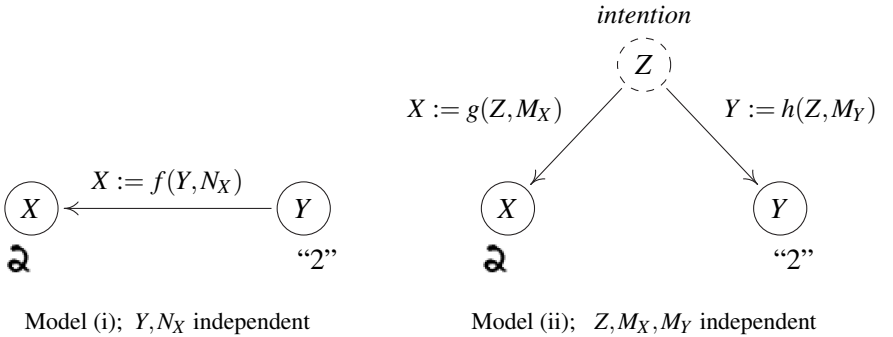

图 1.3：手写数字数据集的两个结构因果模型。在左侧模型（i）中，向人提供类别标签 Y，并生成图像 X。在右侧模型（ii）中，人决定写哪个类别（Z），并生成图像和类别标签。对于合适的函数 f, g, h 和噪声变量 N_X, M_X, M_Y, Z，这两个模型产生相同的可观测分布 $P_{X,Y}$，但它们在干预上不同；参见第 1.4.1 节。

现在让我们讨论模型 (ii) 中可能的干预。如果我们对图像 X 进行干预，那么情况与我们刚才讨论的一样，类别标签 Y 不受影响。然而，如果我们对类别标签 Y (进行干预，即我们改变作者记录的类别标签)，那么与之前不同，这将 *not* 影响图像。

总结来说，在不限制所涉及函数和分布的类别的情况下，(i) 和 (ii) 中描述的因果模型在 X 和 Y 上诱导出相同的观测分布，但干预分布不同。这种差异在纯概率描述中不可见（其中一切都源于 $P_{X,Y}$）。然而，通过纳入关于 $P_{X,Y}$ 如何产生的结构知识，特别是图结构、函数和噪声项，我们能够讨论这一点。

模型 (i) 和 (ii) 是结构因果模型（SCMs）的示例，有时被称为结构方程模型 [例如，Aldrich, 1989, Hoover, 2008, Pearl, 2009, Pearl et al., 2016]。在 SCM 中，所有依赖关系均由从其他变量计算变量的函数生成。至关重要的是，这些函数应被理解为赋值，即计算机科学意义上的函数，而非数学方程。我们通常将它们视为对物理机制的建模。一个 SCM 蕴含所有可观测量上的联合分布。我们已看到，同一分布可由不同的 SCM 生成，因此，当我们从 SCM 转向对应的概率模型时，关于干预效果的信息（以及，正如我们将在第 6.4 节看到的，关于反事实的信息）可能会丢失。在本书中，我们将 SCM 视为

我们的出发点，并试图从那里发展出一切。

我们以与示例相关的两点作结：

首先，图1.3很好地阐明了Reichenbach的共同原因原理。X和Y之间的依赖关系存在多种因果解释，而在右侧图中，若以Z为条件，X和Y变得独立：图像和标签之间没有任何信息是意图中未包含的。

其次，有时有人说，因果关系只有在考虑时间概念时才能讨论。确实，时间在前面的例子中起着作用，例如通过排除对 X 进行干预会影响类别标签的可能性。然而，这完全没问题，而且事实上，统计数据集由随时间发生的过程生成是相当常见的。例如，在模型 (i) 中，X 和 Y 之间统计依赖的根本原因是一个动态过程。书写者读取标签并规划动作，这涉及大脑中复杂的过程，最终使用肌肉和笔执行动作。这一过程只被部分理解，但它是一个随时间发生的物理动态过程，其最终结果导致 X 和 Y 的非平凡联合分布。当我们进行统计学习时，我们只关心最终结果。因此，不仅因果结构，而且纯粹的概率结构也可能通过随时间发生的过程产生——事实上，人们可以认为这最终是它们产生的唯一方式。然而，在这两种情况下，忽略时间通常是有启发性的。在统计学中，讨论统计依赖等概念时通常不需要时间。在因果模型中，讨论干预的效果时通常也不需要时间。但这两种描述层次都可以被视为底层更准确的物理模型的抽象，该模型比任何一种都更完整地描述现实；参见表 1.1。此外，注意模型中的变量不一定指代定义明确的时间实例。例如，如果一位心理学家研究学生动机与表现之间的统计或因果关系，这两个变量都不容易被分配到特定的时间实例。指代定义明确的时间实例的测量在物理学和化学等“硬”科学中相当典型。

1.4.2 基因扰动

我们在第 1.4.1 节中已经看到，不同的因果结构会导致不同的干预分布。有时，我们确实对预测在这种干预下随机变量的结果感兴趣。考虑以下来自遗传学的、在某些方面过于简化的例子。假设我们获得了基因 A 的活性数据，以及相应的表型测量；参见

Model	Predict in i.i.d. setting	Predict under changing distr. or intervention	Answer counterfactual questions	Obtain physical insight	Learn from data
Mechanistic/ physical, e.g., Sec. 2.3	yes	yes	yes	yes	?
Structural causal model, e.g., Sec. 6.2	yes	yes	yes	?	?
Causal graphical model, e.g., Sec. 6.5.2	yes	yes	no	?	?
Statistical model, e.g., Sec. 1.2	yes	no	no	no	yes

表 1.1：模型的简单分类。最详细的模型（顶部）是机制性或物理模型，通常涉及微分方程组。在谱系的另一端（底部），我们有纯粹的统计模型；该模型可以从数据中学习，但通常除了对伴随现象之间的关联进行建模外，提供的洞察很少。因果模型可以被视为介于两者之间的描述，在抽象化物理现实的同时，保留回答某些干预或反事实问题的能力。有关物理模型与结构因果模型之间联系的讨论，参见 Mooij et al. [2013]，以及第 6.3 节关于干预的讨论。

图1.4（左上）用于一个玩具数据集。显然，两个变量高度相关。这种相关性可用于经典预测：如果我们*observe*基因A的活性大约为6，我们期望表型以高概率落在12到16之间。同样，对于基因B（左下）。另一方面，我们可能也对预测在*deleting*基因A之后的表型感兴趣，即将其活性设为0.[6]然而，如果没有因果结构的任何知识，提供非平凡的答案是不可能的。如果基因A对表型有因果影响，我们期望在干预后看到急剧变化（见右上）。事实上，我们可能仍然可以使用从观测数据中学到的同一个线性模型。如果相反，存在一个共同原因，可能是第三个基因C，同时影响基因B的活性和表型，那么对基因B的干预将对表型没有影响（见右下）。

[6]Let us for simplicity assume that we have access to the true activity of the gene without measurement noise.

与模式识别示例一样，模型再次被选择，使得基因 A 与表型的联合分布等于基因 B 与表型的联合分布。因此，仅凭观察数据无法区分上方和下方的情况，即使样本量趋于无穷大。总结来说，如果我们不愿意采用因果性概念，那么对于预测删除基因后的表型这一问题，我们必须回答“我不知道”。

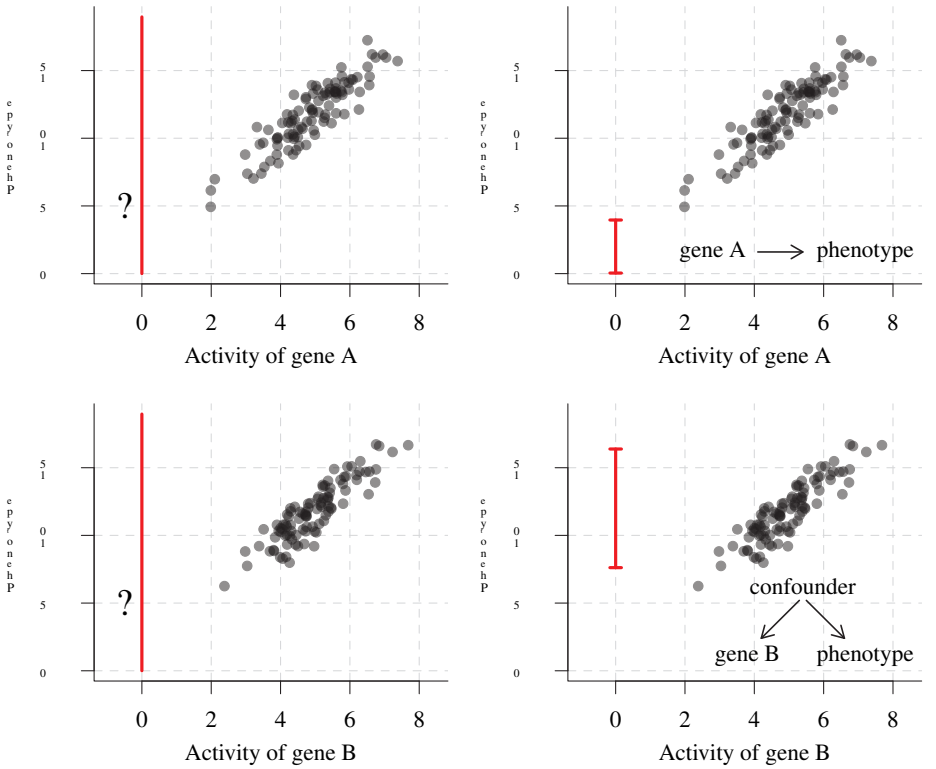

图 1.4：两个基因（上：基因 A；下：基因 B）的活性与表型（黑点）高度相关。然而，当 *deleting the gene* 时，即将其活性设为 0（左图），对表型的最佳预测取决于因果结构（右图）。如果基因与表型之间的相关性是由共同原因引起的，我们期望在干预下表型表现得与通常一样（右下），而如果表型受基因的因果影响，则干预会明显改变表型的值（右上）。该图的构思基于 Peters et al. [2016]。

2

因果推断的假设

现在我们已经接触到 SCMs 的基本组成部分，这正是暂停并思考我们所见过的一些假设，以及这些假设对因果推理和学习目的意味着什么的好时机。

我们讨论中的一个关键概念是一种独立性形式，我们可以借助一种被称为布谢椅（Beuchet chair）的光学幻觉来非正式地引入它。当我们看到图2.1左侧的物体时，我们的大脑会假设该物体与其光信息传递到大脑的机制是独立的。我们可以通过从一个非常特定的视角观察该物体来打破这一假设。如果这样做，感知就会出错：我们会感知到一个三维椅子结构，而实际上它并不存在。然而，大多数情况下，独立性假设确实成立。当我们观察物体时，我们的大脑假设物体与我们的观察点和光照是独立的。因此不应出现不太可能的巧合、没有独立的三维结构在二维中对齐，或阴影边界与纹理边界重合。这被称为视觉中的*generic viewpoint assumption* [Freeman, 1994]。

独立性假设比这更一般，不过。我们将在下面的第 2.1 节看到，因果生成过程由自主模块组成，这些模块彼此不提供信息或相互影响。正如我们将在下面描述的，这意味着虽然一个模块的输出可能影响另一个模块的输入，但模块本身彼此独立。

在前面的例子中，尽管整体感知是物体、光照和视角的函数，但物体和光照不会因为我们移动而改变——换句话说，整体因果生成模型的某些组成部分保持 *invariant*，我们可以从这种不变性中推断出三维信息。

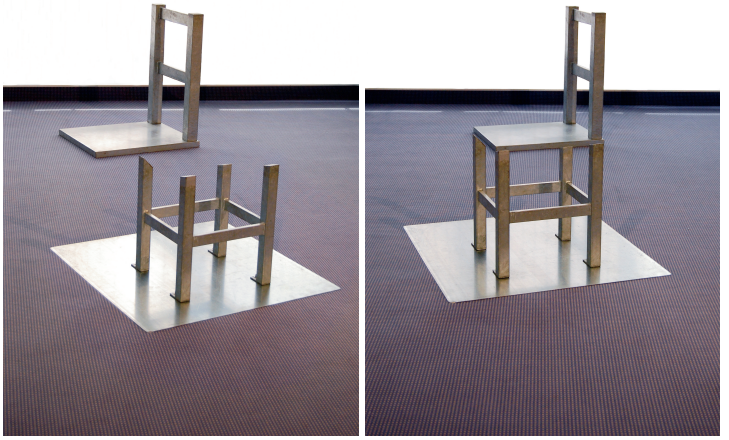

图 2.1：左图显示构成 *Beuchet chair* 的各个（独立）部分的通用视图。右图显示如果从一个单一的、非常特殊的视角观察这些部分时，所产生的椅子幻觉感知。从这个 *accidental viewpoint*，我们感知到一把椅子。（图片由 Markus Elsholz 提供。）

这是 *structure from motion* [Ullman, 1979] 的基本思想，它在生物视觉和计算机视觉中都起着核心作用。

2.1 独立机制原理

我们现在描述一个简单的因果问题，并指出若干观察。随后，我们将尝试提供这些观察如何相互关联的统一视角，并论证它们源于一个共同的独立性原理。

假设我们已估计出某国家一组城市的海拔 A 和年平均气温 T 的联合密度 $p(a,t)$（见第 65 页图 4.6）。考虑表达 $p(a,t)$ 的以下方式：

$$\begin{aligned} p(a,t) &= p(a|t)\ p(t) \\ &= p(t|a)\ p(a) \end{aligned} \tag{2.1}$$

第一个分解描述了T和条件$A|T$。它对应于根据图$T \to A$对$p(a,t)$的因子分解。[1]第二种分解对应于根据$A \to T$ (的因子分解，参见定义6.21)。我们能否

1注意到条件 itional density $p(a|t)$ allows us to compute $p(a,t)$ (and thus also $p(a)$) 来自

决定这两种结构中哪一种是 *causal* 结构（即，在哪种情况下我们可以将箭头视为因果关系）？

一个初步的想法（见图 2.2，左）是考虑干预的效果。想象我们可以通过某种假设机制改变城市的海拔 A，该机制抬高城市所建的地面。假设我们发现平均温度下降。接下来让我们想象，我们设计另一个干预实验。这次，我们不改变海拔，而是围绕城市建造一个大型供暖系统，将平均温度提高几度。假设我们发现城市的海拔不受影响。对 A 进行干预改变了 T，但对 T 进行干预没有改变 A。因此，我们合理地倾向于将 $A \to T$ 作为因果结构的描述。

为什么我们认为这种对干预效果的描述是合理的，即使假设的干预在实践中难以或不可能执行?

如果我们改变海拔 A，则假设产生平均温度的 *physical mechanism* $p(t|a)$（例如大气的化学成分、压力随海拔下降的物理规律、风的气象机制）仍然存在，并导致改变的 T。这与我们抽取城市的分布无关，因此也与 $p(a)$ 无关。奥地利人可能在与瑞士人略有不同的位置建立了城市，但机制 $p(t|a)$ 在两种情况下均适用。[2]

另一方面，如果我们改变 T，那么我们很难将 $p(a|t)$ 视为仍然存在的机制——我们可能一开始就不相信存在这样的机制。给定一组不同的城市分布 $p(a,t)$，虽然我们可以将它们全部写作 $p(a|t)\,p(t)$，但我们会发现无法用一个不变量 $p(a|t)$ 来解释它们全部。

我们的直觉可以重新表述并以两种方式假设：如果 $A \to T$ 是正确的因果结构，那么

(i) 原则上可以对 A 进行局部干预，换句话说，可以在不改变 $p(t|a)$ 的情况下改变 $p(a)$，并且

(ii) $p(a)$ 和 $p(t|a)$ 是世界中自主、模块化或不变的机制或对象。

$p(t)$, which may serve to motivate the direction of the arrow in $T \to A$ for the time being. This will be made precise in Definition 6.21.

[2] This is an idealized setting — no doubt counterexamples to these general remarks can be constructed.

有趣的是，尽管我们最初通过假设的干预实验来推导因果结构，但我们的推理最终表明，实际干预可能并非获得因果结构的唯一途径。我们也可以通过检查数据源 $p(a,t)$，判断两种分解（2.1）中哪一种会产生自主或不变的项，从而识别因果结构。继续使用前面的例子，我们将奥地利和瑞士的海拔与温度的联合分布分别表示为 $p^{\text{o}}(a,t)$ 和 $p^{\text{s}}(a,t)$。由于奥地利人和瑞士人在不同的地方建立了城市（即 $p^{\text{o}}(a)$ 和 $p^{\text{s}}(a)$ 不同），这些分布可能不同。然而，因果分解可能仍然使用相同的条件，即 $p^{\text{o}}(a,t) = p(t|a)\ p^{\text{o}}(a)$ 和 $p^{\text{s}}(a,t) = p(t|a)\ p^{\text{s}}(a)$。

接下来我们描述一个想法（见图 2.2，中间），它与前面的例子密切相关，但不同之处在于它也适用于 *individual* 分布。在因果分解 $p(a,t) = p(t|a)\ p(a)$ 中，我们期望条件密度 $p(t|a)$ (作为 t 和 a) 的函数，不提供关于边际密度函数 $p(a)$ 的信息。如果 $p(t|a)$ 是一个物理机制的模型，它不在乎我们输入什么分布 $p(a)$，这就成立。换句话说，该机制不受我们应用它的城市集合的影响。

另一方面，如果我们写成 $p(a,t) = p(a|t)p(t)$，则前述因果与机制的独立性不再适用。相反，我们会注意到，为了将观测到的 $p(t)$ 和 $p(a,t)$ 联系起来，机制 $p(a|t)$ 需要呈现出一种由方程 $p(a,t) = p(a|t)p(t)$ 约束的相当奇特的形状。在给定一组城市和温度的情况下，这可以通过经验检验。[3]

我们此前已探讨过与独立性、自主性和不变性相关的若干概念，它们均可为因果推断提供启示。现在我们转向最后一个（见图 2.2，右），它与噪声项的独立性相关，因此当将 (2.1) 重写为由图 $A \to T$ 的 SCM 所蕴含的分布时，最能解释清楚：将效应 T 实现为原因 A 的含噪函数，

$$\begin{aligned} A &:= N_A, \\ T &:= f_T(A, N_T), \end{aligned}$$

其中 N_T 和 N_A 是统计独立的噪声 $N_T \perp\!\!\!\perp N_A$。对 f_T (的函数形式施加适当限制（见第 4.1.3–4.1.6 节和 7.1.2 节），使我们能够识别出两种因果结构（$A \to T$ 或 $T \to A$）中哪一种导致了观测到的 $p(a,t)$ (；然而，没有这些限制时，我们总是可以实现两者

[3] We shall formalize this idea in Section 4.1.7.

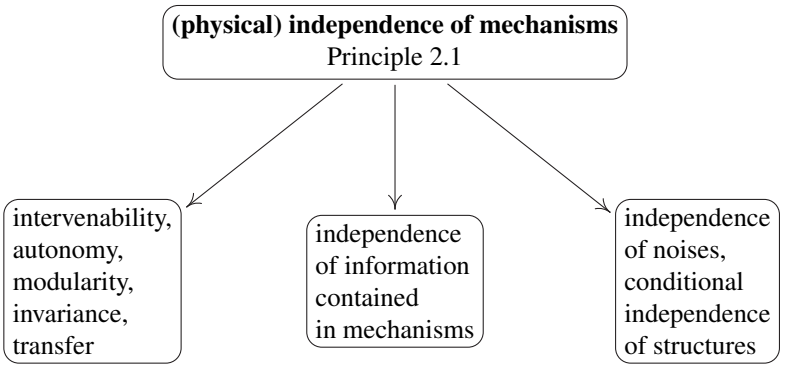

图 2.2：独立机制原理及其对因果推断的含义（原理 2.1）。

分解（2.1））。此外，在多变量设定下且在适当条件下，联合独立噪声的假设允许通过条件独立性检验识别因果结构（参见第7.1.1节）。

我们喜欢将所有这些观察视为一个一般
principle of (physically) independent mechanisms 的紧密相连的实例化。

原理 2.1（独立机制）*The causal generative process of a system's variables is composed of autonomous modules that do not inform or influence each other.*

In the probabilistic case, this means that the conditional distribution of each variable given its causes (i.e., its mechanism) does not inform or influence the other conditional distributions. In case we have only two variables, this reduces to an independence between the cause distribution and the mechanism producing the effect distribution.

如果我们将系统理解为由模块构成，这些模块包含（变量集合），且这些模块代表世界上物理上独立的机制，那么该原理是合理的。两个变量的特殊情况被称为 *independence of cause and mechanism* (ICM) [Daniušis et al., 2010, Shajarisales et al., 2015]。它是通过将输入视为由一个与将输入转化为输出的机制独立的机制所执行的 *preparation* 的结果而获得的。

在深入讨论该原理之前，我们应当指出，并非所有系统都能满足它。例如，如果构成整体系统的机制通过设计或进化相互调适，则这种独立性可能被违反。

我们将接下来论证，该原理足够宽泛，足以涵盖因果推理与因果学习的主要方面（见图 2.2）。让我们讨论三个方面，它们从左到右分别对应图 2.2 中树的三个分支。

1. 将这些模块视为具有输入-输出行为的物理机器是思考它们的一种方式。这一假设意味着我们可以改变一个机制而不影响其他机制——或者，用因果术语来说，我们可以在一个机制上*intervene*而不影响其他机制。改变一个机制将改变其输入-输出行为，从而改变下游其他机制可能接收到的输入，但我们假设物理机制本身不受此变化的影响。这类假设通常是隐含的，以证明干预的可能性，但也可以将其视为因果推理和因果学习的更一般基础。如果系统允许这种局部干预，则不存在物理路径可以通过“元机制”以定向方式将机制相互连接。后者使得我们可以合理地期望机制在所考虑的系统内的变化以及可能来自系统外部的一些变化方面保持*invariant*的趋势（见第7.1.6节）。这种机制的*autonomy*有望帮助将从一个领域学到的知识*trans- fer*到相关领域，其中一些*modules*与源领域重合（见第5.2节和第8.3节）。

2. 虽然对第一个方面的讨论侧重于独立性的物理层面及其衍生，但上述内容也蕴含了信息论的一个维度。涉及多个耦合对象与机制的时间演化可以产生统计依赖。这与我们在第10页的讨论相关，当时我们考虑了类别标签与手写数字图像之间的依赖关系。同样，物理耦合的机制往往会生成可用统计或算法信息度量来量化的信息（参见下文第4.1.9节和第6.10节）。

在此，区分信息的两个层次至关重要：显然，效应包含关于其原因的信息，但——根据独立性原理——从其原因生成效应的机制不包含关于生成该原因的机制的信息。对于具有多于两个节点的因果结构，独立性原理——

ple 指出，从每个节点的直接原因生成该节点的机制之间不包含彼此的信息。[4]

3. 最后，我们应讨论结构方程建模中常见的独立噪声项假设与独立机制原理之间的联系。这种联系并不明显。为此，考虑一个变量 $E := f(C,N)$，其中噪声 N 是离散的。对于 N 取的每个值 s，赋值 $E := f(C,N)$ 归约为一个确定性机制 $E := f^s(C)$，它将输入 C 转化为输出 E。实际上，这意味着噪声在若干机制 f^s（之间随机选择，其中机制的数量等于噪声变量 N）取值范围的基数。现在假设顶点 X_j 和 X_k 处两个机制的噪声变量在统计上是依赖的。[5] 这种依赖可以确保，例如，每当节点 j 处机制 f_j^s 被激活时，我们就知道节点 k 处机制 f_k^t 被激活。这将违反我们独立机制的原理。

前一段采用了将噪声变量视为机制之间选择器的某种极端观点（参见第 3.4 节）。在实践中，噪声的作用可能不那么明显。例如，如果噪声是可加的（即 $E := f(C) + N$），则其对机制的影响受到限制。在这种情况下，它只能 *shift* 机制的输出上调或下调，因此它在一组彼此非常相似的机制之间进行选择。这与将噪声变量视为我们试图描述的系统之外的变量的观点一致，代表了系统永远无法完全与其环境隔离这一事实。在这种观点下，人们会认为噪声之间的弱依赖可能是可能的，而不会使独立机制原理失效。

上述原则 2.1 的所有方面均可能有助于因果学习问题，换言之，它们可能提供关于因果结构的信息。然而，可以设想，在某些情况下，这些信息可能存在冲突，这取决于在任何特定情境下哪些假设成立。

---

[4] There is an intuitive relation between this aspect of independence and the one described under 1.: whenever the mechanisms change independently, the change of one mechanism does not provide information on how the others have changed. Despite this overlap, the second independence contains an aspect that is not strictly contained in the first one because it is also applicable to a scenario in which none of the mechanisms has changed; for example, it refers also to homogeneous data sets.

[5] Although we have so far focused on the two-variable case, we phrase this argument such that it also applies for causal structures with more than two variables.

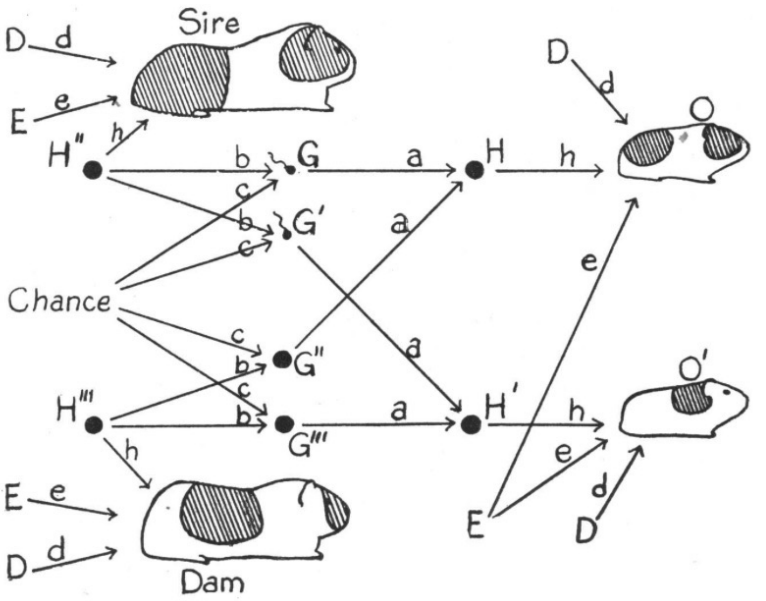

FIG. 5.

Diagram illustrating the casual relations between litter mates (O, O′) and between each of them and their parents. H, H′, H″, H,‴ represent the genetic constitutions of the four individuals, G, G′, G″, and G‴ that of four germ cells. E represents such environmental factors as are common to litter mates. D represents other factors, largely ontogenetic irregularity. The small letters stand for the various path coefficients.

图 2.3：早期路径图；dam 和 sire 分别是豚鼠的母本和父本。路径系数捕捉了给定路径的重要性，定义为
the ratio of the variability of the effect to be found when all causes are constant except the one in question, the variability of which is kept unchanged, to the total variability. (转载自 Wright [1920]。)

2.2 历史注释

自主性与不变性的思想深深植根于结构方程模型（SEMs）或 SCMs 的概念之中。我们更倾向于后者，因为 SEM 这一术语已在多种语境中被使用，其中结构赋值被当作代数方程而非赋值来使用。文献范围广泛，综述由 Aldrich [1989]、Hoover [2008] 和 Pearl [2009] 提供。

SEMs 的学术前驱是 Wright [1918, 1920, 1921] 开创的路径模型概念（见图 2.3）。尽管 Wright 是一位生物学家，但 SEMs 如今与计量经济学联系最为紧密。根据 Hoover [2008]，结构计量经济模型的开创性工作是在

1930年代由Jan Tinbergen完成，概率计量经济学的概念基础在Trgyve Haavelmo的著作[Haavelmo, 1944]中奠定。早期经济学家试图概念化这样一个事实：与相关性不同，回归具有自然方向。*Y*对*X*的回归得到的解通常是*not X*对*Y*的回归的逆。[6]但是数据如何告诉我们应该在哪个方向进行回归呢？这是一个*observational equivalence*问题，并且它与计量经济学家所称的*identification*问题密切相关。

许多早期研究发现，使一组方程或关系 *structural* [Frisch and Waugh, 1933] 成立的要素与 *invariance* 和 *autonomy* 的性质之间存在联系——根据 Aldrich [1989]，这确实是 Frisch et al. [1948] 开创性工作的核心概念。在这里，*structural* 关系的目标不仅仅是对观测数据分布进行建模——它试图捕捉连接模型变量的底层结构。

当时，Cowles 委员会是一个主要的经济研究机构，在计量经济学领域的创立中发挥了重要作用。其工作将因果关系与结构计量经济模型的不变性性质联系起来 [Hoover, 2008]。Pearl [2009] 将结构方程在系统某些变化下保持不变的思想归功于 Marschak 在 1950 年 Cowles 专著开篇章节的论述 [Marschak, 1950]。Cowles 工作强调的一个关键区别是 *endogenous* 和 *exogenous variables* 之间的区别。内生变量是模型构建者试图理解的变量，而外生变量则由模型外部的因素决定，并被视为给定的。Koopmans [1950] 提出了两个原则来确定什么应被视为外生变量。*de- partmental principle* 认为学科范围之外的变量是外生的（例如，天气对经济学而言是外生的）。（更优的）*causal principle* 将那些影响其余（内生）变量但（几乎）不受其影响的变量称为外生变量。

Haavelmo [1943] 将结构方程解释为关于假设控制实验的陈述。他考虑了循环随机方程模型，并讨论了不变性以及政策干预的作用。Pearl [2015] 对 Haavelmo 在政策干预问题研究和因果推断领域发展中的作用进行了评价。在因果性描述中

[6] As an aside, while most of the early works were using linear equations only, there have also been attempts to generalize to nonlinear SEMs [Hoover, 2008].

经济学与计量经济学，Hoover [2008] 讨论了如下形式的系统

$$X^i := N_X^i$$
$$Y^i := \theta\, X^i + N_Y^i,$$

其中误差 N_X^i, N_Y^i 是独立同分布的，且 θ 是一个参数。他将（不需要任何时间顺序的）观点归于 Simon [1953]，即 X^i 可以被称为导致 Y^i，因为人们可以在不了解 Y^i 的情况下完全了解 X^i，但反之则不然。这些方程还允许我们预测干预的效果。Hoover 进一步论证，可以重写系统，交换 X^i 和 Y^i 的角色，同时保持误差项不相关的性质。[7] 因此他指出，我们无法仅凭单一组数据（“观察等价性”）推断出正确的因果方向。实验，无论是受控的还是自然的，都可以帮助我们做出判断。例如，如果一个实验可以改变 Y^i 在给定 X^i 条件下的条件分布，而不改变 X^i 的边际分布，那么 X^i 必定导致 Y^i。Hoover 将此称为 *Simon's invariance criterion*：真正的因果顺序是那种在正确类型的干预下保持不变的顺序。[8] Hurwicz [1962] 认为，一个方程系统由于对一类修改的不变性而成为 *structural*。这样的系统随后与自然法则相似。Hurwicz 认识到，可以利用这类修改来确定结构，并且虽然结构对因果性是必要的，但对预测并非必要。

Aldrich [1989] 对自主性在结构方程建模中的作用作了阐述。他认为自主关系比其他关系更可能保持稳定。他将 Haavelmo 的 *autonomous variables* 与随后被称为外生变量的概念等同起来。自主变量是由外部力量固定的参数，或被视为随机独立的。[9] 根据 Aldrich [1989，第 30 页]，“限定词 *autonomous* 和短语 *forces exter- nal to the sector under consideration* 的使用表明……该模型的参数对部门参数的变化是不变的。”他还将不变性与一个被称为 *super-exogeneity* 的概念联系起来 [Engle et al., 1983]。

尽管结构方程建模的早期倡导者在其因果基础方面已经有了一些深刻的洞察，但计算机科学领域的发展——

[7] We shall revisit this topic in more detail in Section 4.1.3.

[8] We would argue that this may not hold true if interventions are coupled to each other, for example, to keep the *anticausal* conditional (which describes the cause, given its effect) invariant. This could be seen as a violation of Principle 2.1 *on the level of interventions*. We return to this point in Section 2.3.4.

[9] This is akin to the independence of noise terms we use in SCMs.

这种融合最初是分别发生的。Pearl [2009, 第104页] 讲述了他与同事如何开始将贝叶斯网络与结构方程模型联系起来：“我突然想到，经济学家与统计学家之间长达一个世纪的紧张关系源于简单的语义混淆：统计学家将结构方程理解为关于 $\mathbb{E}[Y|x]$ 的陈述，而经济学家将它们理解为 $\mathbb{E}[Y|do(x)]$。这可以解释为什么统计学家声称结构方程没有意义，而经济学家则反驳说统计学没有实质内容。”Pearl [2009, 第22页] 将独立性原理表述如下：“网络中的每一个父子关系都代表一种稳定且自主的物理机制——换句话说，可以设想改变某一个这样的关系 *without* 改变其他关系。”

值得注意的是，这确实是撰写本书的动机之一：在图 2.2 所示的原理 2.1 的不同推论中，使用因果贝叶斯网络的大多数工作仅利用了噪声项的独立性。[10] 这导致了丰富的条件独立结构 [Pearl, 2009, Spirtes et al., 2000, Dawid, 1979, Spohn, 1980]，最终源于 Reichenbach 的原理 1.1。独立性的其他方面受到了明显较少的关注 [Hausman and Woodward, 1999, Lemeire and Dirkx, 2006]，但最近有一条研究线旨在将它们形式化并加以利用。这的一个主要动机是因果效应问题，其中条件独立性无用，因为我们只有两个变量（见第 4.1.2 节和第 6.10 节）。Janzing 和 Schölkopf [2010] 从算法信息论的角度将机制独立性形式化（第 4.1.9 节）。他们将 SCM 中的函数视为代表独立的因果机制，这些机制在操纵输入分布或其他机制后仍然持续存在。更具体地说，在因果贝叶斯网络的背景下，他们假设所有节点在给定其父节点条件下的条件分布在算法上是独立的。特别是，对于因果贝叶斯网络 $X \to Y$，P_X 和 $P_{Y|X}$ 彼此之间不包含任何算法信息——意味着对其中一个的知识不会允许对另一个给出更简短的描述。无关机制是 *algorithmically* 独立的这一思想源于将 SCM 从随机变量推广到个体对象，其中 *sta- tistical* 依赖被 *algorithmic* 依赖所取代。

Schölkopf 等人 [2012，例如，第 2.1.1 节] 讨论了对原因分布变化的鲁棒性问题（在双变量设—

[10] Certain Bayesian structure learning methods [Heckerman et al., 1999] can be viewed as implementing the independence principle by assigning *independent* priors to the conditional probabilities of each variable given its causes.

ting)，并将其与机器学习问题联系起来；参见第5章。在结构因果模型（SCM）内，他们分析函数或噪声在不同学习场景（例如迁移学习、概念漂移）下的不变性。他们采用了一种机制与输入独立性的概念，该概念涵盖了变化下的独立性和信息论独立性（我们在讨论方框时将其称为图2.2中第一和第二独立性之间的“重叠”）：“$P_{E|C}$ 不包含关于 P_C 的信息，反之亦然；特别是，如果 $P_{E|C}$ 在某个时间点发生变化，没有理由认为 P_C 在同一时间发生变化。”

与迁移学习及相关机器学习问题的进一步联系由 Bareinboim 和 Pearl [2016]、Rojas-Carulla et al. [2016]、Zhang et al. [2013] 以及 Zhang et al. [2015] 进行了讨论。Peters et al. [2016] 利用环境间的不变性来学习多元 SCM（第 7.1.6 节）底层图结构的部分内容。

2.3 因果模型的底层物理结构

我们以一些关于与物理学联系的注释结束本章。对于兴趣仅限于数学和统计结构的读者，可能更愿意跳过这部分。

2.3.1 时间的作用

第 2.1 节中明显缺失的一个方面是时间的作用。事实上，物理学通过排除从未来到过去的因果关系，将因果性纳入其基本定律。[11] 然而，这并未消除因果推断的所有问题。早在 Simon [1953] 就已认识到，虽然时间顺序可以提供有用的不对称性，但重要的是不对称性，而非时间序列。

微观上，经典系统和量子力学系统的时间演化被广泛认为是可逆的。这似乎与我们直觉上认为世界以定向方式演化的观点相矛盾——我们相信如果时间倒流，我们能够察觉到。该矛盾可通过两种方式解决。其中一种是，假设我们有一个状态的复杂度度量 [Bennett, 1982, Zurek, 1989]，并且我们从一个复杂度非常低的状态开始。在那

[11] More precisely, an event can only influence events lying in its light cone since no signal can travel faster than the speed of light in a vacuum, according to the theory of relativity.

在这种情况下，时间演化（假设其足够遍历）将倾向于增加复杂性。另一方面，我们假设考虑的是开放系统。即使闭合系统的时间演化是可逆的（例如，在量子力学中，幺正时间演化），与环境相互作用的开放子系统的时间演化在一般情况下也不必是可逆的。

2.3.2 物理定律

一个经常被讨论的因果问题可以通过以下例子来说明。理想气体定律规定，压力 p、体积 V、物质的量 n 和绝对温度 T 满足方程

$$p \cdot V = n \cdot R \cdot T, \tag{2.2}$$

其中 R 是理想气体常数。例如，如果我们改变分配给一定量气体的体积 V，那么压力 p 和/或温度 T 会发生变化，具体情况取决于干预的精确设置。另一方面，如果我们改变 T，那么 V 和/或 p 会发生变化。如果我们保持 p 恒定，那么我们至少可以近似地构造一个涉及 T 和 V 的循环。那么是什么导致了什么？有时有人认为，这些定律表明，除非系统是时间性的，否则谈论因果关系没有意义。在下一段中，我们认为这具有误导性。气体定律（2.2）指的是底层动力系统的 *equilibrium state*，将其写为简单方程并不能提供足够的信息，说明原则上可能进行哪些干预以及它们的效果。SCMs 及其对应的有向无环图确实为我们提供了这些信息，但在非平衡系统的一般情况下，判断给定的动力系统是否以及如何导向 SCM 是一个难题。

2.3.3 循环赋值

我们将 SCMs 视为底层过程在时间中发生的抽象。对于这些底层过程，反馈循环并无问题，因为在足够快的时间尺度上，这些循环会在时间中展开，假设不存在瞬时相互作用，而这可以被光速的有限性所排除。

尽管时间依赖过程没有循环，但由这些过程导出的 SCM（例如，通过下文 Remarks 6.5 和 6.7 中提到的方法）仅涉及不再依赖时间的量，却可能具有循环。在这种 SCM 中，定义一般干预变得更困难

系统，但某些类型的干预仍然应该是可行的。例如，一种硬干预，即将一个变量的值设为固定值，可能是可行的（并且可以通过底层微分方程组中的强制项在物理上实现；参见 Remark 6.7）。这打破了循环，然后我们可以推导出蕴含的 *intervention* 分布。

然而，从一组循环的结构赋值中可能无法推导出蕴含的 *observational* 分布。让我们考虑这两个赋值

$$X := f_X(Y, N_X)$$
$$Y := f_Y(X, N_Y)$$

和噪声变量 $N_X \perp\!\!\!\perp N_Y$。与无环模型的情况一样，我们将噪声和函数视为给定，并试图计算 X 和 Y 的蕴含联合分布。为此，让我们从第一个赋值 $X := f_X(Y, N_X)$ 开始，并将某个初始的 Y 代入其中。这产生了一个 X，然后我们可以将其代入另一个赋值。假设我们迭代这两个赋值并收敛到某个固定点。该点将对应于 X, Y 的联合分布，同时满足两个结构赋值作为随机变量的等式。[12] 注意，这里我们假设在每一步都使用相同的 N_X, N_Y，而不是它们的独立副本。

然而，X, Y 的这种均衡并不总是存在；即使存在，也未必能通过迭代找到。在线性情形下，这已由 Lacerda et al. [2008] 和 Hyttinen et al. [2012] 进行了分析；另参见 Lauritzen and Richardson [2002]。更多细节见 Remark 6.5。

这一观察，即人们并不总是能够获得满足两个循环结构赋值的蕴含分布，与将SCMs视为底层物理过程的*abstractions*的观点是一致的——这些抽象作为因果模型的有效域是有限的。如果我们希望理解一般的循环系统，可能不得不研究微分方程系统而非SCMs。另一方面，对于某些受限设置，停留在SCMs这一现象学上更为表层的层面仍然是有意义的；例如，参见Mooij et al. [2013]。人们可以推测，SCMs（或SEMs）内在的这一困难是计量经济学界最初将SEMs视为

[12] The fact that the assignments are satisfied as equalities of random variables means that we are considering an ensemble of systems that differ in the realizations of the noise variables. Each realization leads to a (possibly different) realization for X, Y, and thus the distribution of the noises implies a distribution over X, Y.

因果模型，但后来社区的一部分决定放弃这种解释，转而将结构方程视为纯粹的代数方程。

2.3.4 干预的可行性

我们已利用独立机制原理来论证仅一次影响一个机制（或结构赋值）的干预。虽然真实系统可能允许这类干预，但也存在同时替换多个赋值的干预。前者在直观物理意义上可被视为更基础的。如果多个基础干预被结合，那么原则上可能以它们相互协调的方式发生，我们会将这视为违反我们独立性原理 2.1 的某种形式；参见第 24 页脚注 8。人们可能希望“自然”的组合干预不会违反独立性。然而，要判断干预在此意义上是否“自然”需要因果结构的知识，而我们在试图使用这些原理一开始就进行因果学习时并不具备这种知识。最终，人们可以尝试诉诸物理学来评估什么是基础的或自然的。

哪些对物理系统的操作是基本操作的问题在现代量子信息理论中起着至关重要的作用。在那里，这个问题与分析物理相互作用的结构密切相关。[13]同样，我们认为理解因果关系背后的物理机制有时可以解释为什么某些干预是自然的，而其他干预是复杂的，这本质上定义了由不同结构方程给出的“模块”。

2.3.5 原因与机制的独立性与热力学时间箭头

我们提供了讨论以及一个玩具模型，说明独立机制原理如何可被视为物理学原理。为此，我们

[13]For the interested reader: A system consisting of n two-level quantum systems is described by the 2^n-dimensional Hilbert space $\mathbb{C}^2 \otimes \cdots \otimes \mathbb{C}^2$. Unitary operators acting on this Hilbert space correspond to physical processes. For several such systems, researchers have shown how to implement “basic” unitaries that act on at most two of the n tensor components [Nielsen and Chuang, 2000] and act trivially on the remaining $n-2$ ones. Then one can generate any other unitary [DiVincenzo, 1995] approximately by concatenation. Although this is by no means the only possible choice for the set of “basic” unitary operations, the choice seems natural given the structure of physical interactions.

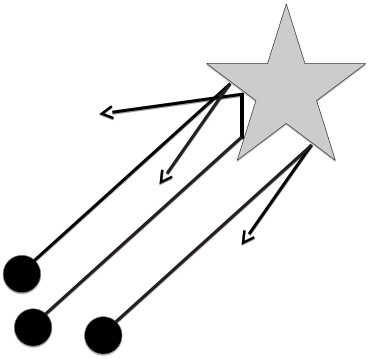

图 2.4：初始状态与动力学定律独立性的简单示例：一束被物体散射的粒子。出射粒子包含关于物体的信息，而入射粒子则不包含。

考虑两个变量的特殊情况，并将以下内容作为原理 2.1 的特化提出：

原理 2.2（初始状态与动力学定律）*If s is the initial state of a physical system and M a map describing the effect of applying the system dynamics for some fixed time, then s and M are independent. Here, we assume that the initial state, by definition, is a state that has not interacted with the dynamics before.*

在此，“初始”状态 s 和“最终”状态 $M(s)$ 被视为“原因”与“结果”。因此，M 是关联原因与结果的机制。原则 2.2 的最后一句需要一些解释，以避免错误结论。我们现在通过一个直观的例子来讨论其含义。

图2.4展示了一个场景，其中初始状态与动力学的独立性如此自然，以至于我们将其视为理所当然：一束沿完全相同方向传播的n粒子正在接近某个物体，在那里它们被散射到各个方向。出射粒子的方向包含关于该物体的信息，而*incoming*粒子束则不包含关于它的信息。粒子初始时沿完全相同方向传播的假设当然可以被放宽。即使入射束中存在一些无序，出射束仍然可以包含关于该物体的信息。事实上，视觉和摄影之所以成为可能，正是因为光子包含了它们被散射的物体的信息。

我们可以通过“手动设计”一束入射光束轻松地对场景进行时间反演，使得所有粒子都沿着与散射过程相同的方向 *after* 传播。现在我们来论证在这种情况下如何理解原理 2.2。显然，这样的

光束只能由机器或知晓物体形状并据此引导粒子的主体制备。事实上，未曾与物体接触的粒子无法先验地包含关于它的信息。因此，若将引导粒子的过程视为机制的一部分，并拒绝将手动设计光束的状态称为 *initial* 状态，则原理 2.2 可得以维持。此时，初始状态指的是粒子被赋予精细调节动量之前的瞬间。

摄影图像显示的是过去发生的事情而非未来将发生的事情，这一事实是过去与未来之间最明显的不对称之一。前面的讨论表明，这种不对称可被视为原理 2.2 的推论。因此，该原理将因果之间的不对称与我们视为理所当然的过去与未来之间的不对称联系起来。

在非正式层面解释了原理2.1与物理学中过去与未来之间的不对称性之间的关系后，我们简要提及这一联系已由Janzing等人[2016]通过算法信息论更正式地建立。正如原理4.13将P_C与$P_{E|C}$的独立性形式化为算法独立性一样，原理2.2也可以被解释为s与M的算法独立性。Janzing等人[2016，定理1]表明，对于任意双射M，原理2.2意味着：只要接受柯尔莫哥洛夫复杂度（见第4.1.9节）作为物理熵的正确形式化（如Bennett [1982]和Zurek [1989]所提出的），则$M(s)$的物理熵不能小于s (的熵，至多相差一个加法常数)。因此，原理2.2意味着熵在物理学标准时间箭头意义上不减。

3

因果模型

本章针对因果模型仅包含两个变量的情况，形式化了因果关系的一些基本概念。假设这两个变量存在非平凡关系，且它们的依赖性不仅仅源于共同原因，则构成了一个因果-效应模型。我们简要介绍结构因果模型（SCMs）、干预和反事实。所有这些概念在多变量因果模型（第6章）的语境下被重新定义，我们希望先在两个变量的情境下接触它们，能使这些概念更易于理解。

3.1 结构因果模型

SCMs 是将因果陈述与概率陈述联系起来的重要工具。

定义 3.1（结构因果模型）*An SCM* $\mathfrak{C}$ *with graph* $C \to E$ *consists of two* ***assignments***

$$C := N_C, \tag{3.1}$$
$$E := f_E(C, N_E), \tag{3.2}$$

where $N_E \perp\!\!\!\perp N_C$*, that is,* N_E *is independent of* N_C*.*

在这个模型中，我们将随机变量 C 称为原因，E 称为结果。此外，我们将 C 称为 E 的直接原因，并将 $C \to E$ 称为因果图。这种表示法有望澄清并与读者在讨论干预时的直觉一致，例如在例 3.2 中。

如果同时给定函数 f_E 以及噪声分布 P_{N_C} 和 P_{N_E}，我们可以通过以下方式从该模型中采样数据：我们采样噪声值

N_E, N_C，然后评估 (3.1)，接着评估 (3.2)。因此 SCM 蕴含 C 和 E (上的联合分布 $P_{C,E}$，正式证明见命题 6.3)。

3.2 干预措施

如第 1.4.2 节所述，我们常常对系统在干预下的行为感兴趣。干预后的系统诱导出另一个分布，这通常与观测分布不同。如果任何类型的干预都可能导致系统发生任意变化，这两个分布将变得无关，与其联合研究这两个系统，我们可能将它们视为两个独立的系统。这激发了以下想法：干预后只有数据生成过程的部分发生变化。例如，我们可能对以下情况感兴趣：变量 E 被设置为值 4（无论 C 的值如何），而不改变生成 C 的机制 (3.1)。也就是说，我们将赋值 (3.2) 替换为 $E := 4$。这称为（硬）干预，记为 $do(E := 4)$。修改后的 SCM，其中 (3.2) 被替换，蕴含了 C 上的分布，我们将其记为 $P_C^{do(E:=4)}$ 或 $P_C^{\mathfrak{C};do(E:=4)}$，后者明确表示 SCM $\mathfrak{C}$ 是我们的起点。对应的密度记为 $c \mapsto p^{do(E:=4)}(c)$ 或，在略微滥用记号的情况下，$p^{do(E:=4)}(c)$.[1] 然而，操作可以更为一般。例如，干预 $do\left(E := g_E(C) + \tilde{N}_E\right)$ 保持了对 C 的函数依赖，但改变了噪声分布。这是软干预的一个例子。我们可以替换这两个方程中的任意一个。

以下示例阐明了“原因”和“结果”这两个命名的由来：

示例 3.2（因果干预）假设分布 $P_{C,E}$ 由结构因果模型 $\mathfrak{C}$ 蕴含

$$\begin{aligned} C &:= N_C \\ E &:= 4 \cdot C + N_E, \end{aligned} \tag{3.3}$$

设 $N_C, N_E \overset{\text{iid}}{\sim} \mathcal{N}(0,1)$，以及图 $C \to E$。则，

$$\begin{aligned} P_E^{\mathfrak{C}} = \mathcal{N}(0,17) &\neq \mathcal{N}(8,1) = P_E^{\mathfrak{C};do(C:=2)} = P_{E|C=2}^{\mathfrak{C}} \\ &\neq \mathcal{N}(12,1) = P_E^{\mathfrak{C};do(C:=3)} = P_{E|C=3}^{\mathfrak{C}}. \end{aligned}$$

[1] In the literature, the notation $p(c \,|\, do\,(E := 4))$ is also commonly used. We prefer $p^{do(E:=4)}$ since interventions are conceptually different from conditioning, and $p(c \,|\, do\,(E := 4))$ resembles the usual notation for the latter, $p(c \,|\, E = 4)$.

干预 C 会改变 E 的分布。但另一方面，

$$P_C^{\mathfrak{C};do(E:=2)} = \mathcal{N}(0,1) = P_C^{\mathfrak{C}} = P_C^{\mathfrak{C};do(E:=314159265)} \left(\neq P_{C|E=2}^{\mathfrak{C}} \right). \tag{3.4}$$

无论我们对 E 施加多强烈的干预，C 的分布仍然与之前一样。这种模型行为与我们对 C“导致”E 的直觉高度吻合：例如，无论我们多大程度地美白某人的牙齿，都不会对这个人的吸烟习惯产生任何影响。（重要的是，给定 $E =$ 为 2 时 C 的条件分布与干预并将 E 设为 2 后 C 的分布不同。）

因果之间的不对称性也可以表述为独立性陈述。当我们将赋值 (3.3) 替换为 $E := \tilde{N}_E$ (考虑随机化 E) 时，我们打破了 C 和 E 之间的依赖关系。在

$$P_{C,E}^{\mathfrak{C};do\left(E:=\tilde{N}_E\right)}$$

我们发现 $C \perp\!\!\!\perp E$。当随机化 C 时，这种独立性不成立。只要 $\text{var}[\tilde{N}_C] \neq 0$，我们发现 $C \not\perp\!\!\!\perp E$ 在

$$P_{C,E}^{\mathfrak{C};do\left(C:=\tilde{N}_C\right)};$$

C 与 E 之间的相关性仍然非零。 □

代码片段 3.3 来自示例 3.2 所描述的 SCM 的代码样本。

```
set.seed(1)
# generates a sample from the distribution entailed by the SCM
C <- rnorm(300)
E <- 4*C + rnorm(300)
c(mean(E), var(E))
# [1] 0.1236532 16.1386767
#
# generates a sample from the intervention distribution do(C:=2);
# this changes the distribution of E
C <- rep(2,300)
E <- 4*C + rnorm(300)
c(mean(E), var(E))
# [1] 7.936917 1.187035
#
# generates a sample from the intervention distribution do(E:=N~);
# this breaks the dependence between C and E
C <- rnorm(300)
E <- rnorm(300)
cor.test(C,E)$p.value
# [1] 0.2114492
```

3.3 反事实

SCM 的另一种可能修改会改变其所有噪声分布。这种变化可以由观测诱导，并使我们能够回答反事实问题。为了说明这一点，想象以下假设情景：

示例 3.4（眼病）存在一种相当有效的眼病治疗方法。对于 99% 的患者，治疗有效，患者可被治愈（$B=0$）；若不治疗，这些患者会在一天内失明（$B=1$）。对于剩余的 1%，治疗效果相反，他们会在一天内失明（$B=1$）。若不治疗，他们会恢复正常视力（$B=0$）。

患者属于哪个类别由一种罕见病症（$N_B=1$）控制，该病症医生未知，因此医生是否施加治疗（$T=1$）的决定与 N_B 独立。我们将其写作噪声变量 N_T。

假设底层 SCM

$$\mathfrak{C}:\ \begin{array}{lcl} T &:=& N_T \\ B &:=& T\cdot N_B+(1-T)\cdot(1-N_B) \end{array} \tag{3.5}$$

具有伯努利分布的 $N_B \sim \text{Ber}(0.01)$；注意对应的因果图为 $T \to B$。

现在想象一位视力不佳的特定患者来到医院，在医生施行治疗（$T=1$）后失明（$B=1$）。我们现在可以提出反事实问题

"What would have happened had the doctor admin- istered treatment $T=0$?"

。令人惊讶的是，这可以被回答。观察 $B=T=1$ 根据（3.5）意味着对于该患者，我们有 $N_B=1$。这反过来让我们能够计算 $do(T:=0)$ 的效应。

为此，我们首先以观测为条件来更新噪声变量的分布。如前所述，在条件 $B=T=1$ 下，N_B 的分布以及 N_T 的分布坍塌为 1 上的点质量，即 δ_1。这导致了一个修改后的 SCM：

$$\mathfrak{C}|B=1,T=1:\ \begin{array}{lcl} T &:=& 1 \\ B &:=& T\cdot 1+(1-T)\cdot(1-1)=T \end{array} \tag{3.6}$$

注意，我们只更新噪声分布；条件化不会改变赋值本身的结构。其思想是物理机制未变（在我们的情况中，什么导致治愈、什么导致失明），但我们已获得了关于先前未知噪声变量 *for the given patient* 的知识。

接下来，我们计算该患者的 $do(T=0)$ 效应：

$$\mathfrak{C}|B=1,T=1;do(T:=0):\ \begin{array}{lcl} T & := & 0 \\ B & := & T \end{array} \tag{3.7}$$

显然，蕴含分布将所有质量放在 $(0,0)$ 上，因此

$$P^{\mathfrak{C}|B=1,T=1;do(T:=0)}(B=0)=1\,.$$

这意味着，如果医生没有给他治疗，患者因此本会被治愈（$B=0$），换句话说，$do(T:=0)$。由于

$$P^{\mathfrak{C};do(T:=1)}(B=0)=0.99 \quad \text{and}$$
$$P^{\mathfrak{C};do(T:=0)}(B=0)=0.01,$$

然而，我们仍然可以认为医生的行为是最优的（根据现有知识）。

□

有趣的是，示例 3.4 表明，我们可以使用反事实陈述来证伪底层的因果模型（参见第 6.8 节）。假设罕见条件 N_B 可以被检测，但检测结果需要超过一天。在这种情况下，我们可能观察到与 N_B 的测量结果相矛盾的反事实陈述。Pearl [2009, p.220, point (2)] 也给出了同样的论点。由于反事实的科学内容已被广泛争论，应强调的是，这里的反事实陈述是可证伪的，因为噪声变量并非原则上不可观测，而仅在医生必须做出决策的时刻不可观测。

3.4 结构因果模型的规范表示

我们已讨论了由SCMs蕴含的两类因果陈述：第一，系统在潜在干预下的行为；第二，反事实陈述。为进一步理解它们之间的差异，我们引入SCM的以下“规范表示”。[2] 根据结构赋值

$$E=f_E(C,N_E),$$

[2]This representation has been used in the literature in various places, for example, [Pearl, 2009] although we have not found the term “canonical representation.”

对于噪声 N_E 的每个固定值 n_E，E 是 C 的确定性函数：

$$E = f_E(C, n_E). \tag{3.8}$$

换句话说，如果 C 和 E 分别在 $\mathcal{C}$ 和 $\mathcal{E}$ 中取值，则噪声 N_E 在从 $\mathcal{C}$ 到 $\mathcal{E}$ 的不同函数之间切换。因此，不失一般性，我们可以假设 N_E 在从 $\mathcal{C}$ 到 $\mathcal{E}$ 的函数集合中取值，记为 $\mathcal{E}^{\mathcal{C}}$。利用这一约定，我们还可以将 (3.8) 改写为

$$E = n_E(C), \tag{3.9}$$

并称此为关联 C 和 E 的结构方程的规范表示。

现在让我们解释为什么两个具有不同规范表示的SCM可能诱导出相同的干预概率，尽管它们在反事实陈述上存在差异。为此，我们将注意力限制在C取值于有限集合$\mathcal{C} = \{1, \ldots, k\}$的情况。然后，从$\mathcal{C}$到$\mathcal{E}$的函数集合由$k$重笛卡尔积给出

$$\mathcal{E}^k := \underbrace{\mathcal{E} \times \cdots \times \mathcal{E}}_{k \text{ times}},$$

其中第j个分量描述了E对$C = j$所取的值。因此，分布P_{N_E}由$\mathcal{E}^k$上的联合分布给出，其第j个分量的边际分布决定了条件$P_{E|C=j}$。由于C是原因而E是结果，我们有$P_E^{do(C:=j)} = P_{E|C=j}$；换句话说，这里干预概率与观测条件概率一致。因此，SCM的干预因果含义完全由向量值噪声变量N_E的每个分量的边际分布决定，尽管SCM包含对P_{N_E}的精确规定，即所有分量的联合分布。虽然噪声变量N_E中与结果相关的分量之间的统计依赖性对干预因果陈述无关，但它们对*counterfactual*陈述确实重要。为了说明这一点，设C和E为二元的，即$\mathcal{C} = \mathcal{E} = \{0, 1\}$。从$\{0, 1\}$到$\{0, 1\}$的函数集合为$\mathcal{E}^{\mathcal{C}} = \{0, 1, \mathrm{ID}, \mathrm{NOT}\}$，其中0, 1分别表示取值为0和1的常数函数，ID和NOT分别表示恒等和取反。为了构造两个不同的分布$P^1_{N_E}$和$P^2_{N_E}$，它们诱导出相同的条件$P_{E|C=0}$，$P_{E|C=1}$，首先选择0和1的均匀混合，其次选择ID和NOT的均匀混合。在这两种情况下，C和E在统计上独立，且E的分布不受对C的干预影响，因为无论C如何，E始终是一个无偏的硬币抛掷。在笛卡尔积表示中，这四个

函数读取 $\mathcal{E}^{\mathcal{C}} = \{(0,0),(1,1),(0,1),(1,0)\}$，第一个和第二个分量分别表示 $C=0$ 和 $C=1$ 的像。显然，(0, 0) 和 (1, 1) 的均匀混合，以及 (0, 1) 和 (1, 0) 的均匀混合，都在笛卡尔积的第一个和第二个分量上诱导出相同的边际分布——这与我们此前的 remark 一致，即它们诱导出相同的干预分布。然而，反事实陈述“E 如果 C 被设置为不同的值，就会取得不同的值”仅对 ID 和 NOT 的混合成立，而对 0 和 1 的混合不成立。因此，反事实陈述不仅依赖于噪声变量 N_E 的分量的边际分布，还依赖于笛卡尔积分量之间的统计依赖关系。

注意，两个形式上不同的SCMs不仅可能诱导出相同的干预分布，甚至还可能蕴含相同的反事实陈述：给定赋值

$$E := f_E(C, N_E),$$

N_E 的重参数化显然无关。更明确地说，我们可以设

$$E := \tilde{f}_E(C, \tilde{N}_E) = f_E(C, g^{-1}(\tilde{N}_E)),$$

对于 N_E 值域上的某个双射 g，并将噪声变量重新定义为$\tilde{N}_E := g(N_E)$。利用规范表示（3.9），我们消除了这一额外自由度，否则它会混淆关于反事实的讨论。

3.5 习题

问题 3.5（从 SCM 中采样）*Consider the SCM*

$$X := Y^2 + N_X \tag{3.10}$$
$$Y := N_Y \tag{3.11}$$

with $N_X, N_Y \overset{iid}{\sim} \mathcal{N}(0,1)$. *Generate an i.i.d. sample of size* 200 *from the joint distri- bution* (X,Y).

问题 3.6（条件分布）*Show that* $P^{\mathfrak{C}}_{C|E=2}$ *in Equation* (3.4) *is a Gaussian distribution:*

$$C \,|\, E = 2 \;\sim\; \mathcal{N}\left(\frac{8}{17}, \sigma^2 = \frac{1}{17}\right).$$

问题 3.7（干预）*Assume that we know that a process either follows the SCM*

$$X := Y + N_X$$
$$Y := N_Y,$$

where $N_X \sim \mathcal{N}(\mu_X, \sigma^2_X)$ *and* $N_Y \sim \mathcal{N}(\mu_X, \sigma^2_Y)$ *with unknown* μ_X, μ_Y *and* $\sigma_X, \sigma_Y > 0$*, or it follows the SCM*

$$X := M_X$$
$$Y := X + M_Y,$$

where $M_X \sim \mathcal{N}(\nu_X, \tau^2_X)$ *and* $M_Y \sim \mathcal{N}(\nu_Y, \tau^2_Y)$ *with unknown* ν_X, ν_Y *and* $\tau_X, \tau_Y > 0$*.*
Is there a single intervention distribution that lets you distinguish between the two SCMs?

问题 3.8（循环 SCMs）*We have mentioned that if the assignments inherit a cyclic structure, the SCM does not necessarily induce a unique distribution over the observed variables. Sometimes there is no solution and sometimes it is not unique.*

a) We first look at an example that induces a unique solution. Consider the SCM

$$X := 2 \cdot Y + N_X \tag{3.12}$$
$$Y := 2 \cdot X + N_Y \tag{3.13}$$

with $(N_X, N_Y) \sim P$ *for an arbitrary distribution* P*. Compute* $\alpha, \beta, \gamma, \delta$ *such that*

$$X := \alpha N_X + \beta N_Y$$
$$Y := \gamma N_X + \delta N_Y$$

yields a solution (X, Y, N_X, N_Y) *of the SCM; that is, the vector satisfies Equations* (3.12) *and* (3.13)*. The solution can be seen as a special case of Equation* (6.2)*.*

b) Consider the SCM

$$X := Y + N_X$$
$$Y := X + N_Y$$

with $(N_X, N_Y) \sim P$. *Show that if* P *allows for a density with respect to Lebesgue measure and factorizes, that is,* $N_X \perp\!\!\!\perp N_Y$, *then there is no solution* (X, Y, N_X, N_Y) *of the SCM.*

Furthermore, construct a distribution P, *and a vector* (X, Y, N_X, N_Y) *that solves the SCM.*

4

学习因果模型

熟悉基于条件统计独立性的观测数据因果发现方法 [Pearl, 2009, Spirtes et al., 2000] 的读者，可能会对讨论仅有两个观测变量情况下因果推断的章节感到惊讶，也就是说，这种情况下无法存在非平凡的条件独立性。本章介绍了在仅有两个观测变量的情况下，因果推断成为可能的假设。

其中一些假设可能看起来过于强烈而不现实，但应牢记，经验推断即使不涉及因果问题，也需要强假设。这在处理高维数据和小样本量时尤其如此。因此，过度简化的模型无处不在，且已被证明在许多学习场景中有帮助。

假设列表多种多样，我们也确信它同样不完整。当前研究仍处于探索假设巨大空间的阶段，这些假设能在原因与结果之间产生可识别性。我们希望本章能激励读者，读者随后可能会添加其他——希望是现实的——假设，这些假设可用于学习因果结构。

我们在第4.1节提供假设和理论可识别性结果；第4.2节说明在有限数据情况下如何利用这些结果进行结构识别。

4.1 结构可识别性

4.1.1 为什么需要额外假设

在第3章中，我们介绍了SCMs，其中效应E通过函数赋值由原因C计算得出。人们可能会想，这种数据生成过程的不对称性（即E由C计算得出，而非反之）是否仅从观察$P_{C,E}$就能显现出来。也就是说，两个变量X,Y的联合分布$P_{X,Y}$是否能告诉我们，它是由从X到Y的SCM诱导而来，还是由从Y到X的SCM诱导而来？换句话说，结构是否可从联合分布中识别？以下已知结果表明，如果允许一般的SCMs，答案是“否”。

命题 4.1（图结构的非唯一性）*For every joint distribution $P_{X,Y}$ of two real-valued variables, there is an SCM*

$$Y = f_Y(X, N_Y), \quad X \perp\!\!\!\perp N_Y,$$

where f_Y is a measurable function and N_Y is a real-valued noise variable.

证明。类似于 Peters [2012, 命题 2.6 的证明]，定义条件累积分布函数

$$F_{Y|x}(y) := P(Y \le y \,|\, X = x).$$

然后定义

$$f_Y(x, n_Y) := F^{-1}_{Y|x}(n_Y),$$

其中 $F^{-1}_{Y|x}(n_Y) := \inf\{x \in \mathbb{R} : F_{Y|x}(x) \ge n_Y\}$。然后，设 N_Y 在 $[0,1]$ 上均匀分布，且与 X 独立。 □

该结果可应用于 $X = C$ 和 $Y = E$ 的情况，以及 $X = E$ 和 $Y = C$ 的情况，因此每个联合分布 $P_{X,Y}$ 在两个方向上都存在 SCM。为此，人们常常认为，仅凭被动观察无法推断出仅两个观测变量之间的因果方向。我们将在第 7 章看到，这一论断适用于一个框架，其中因果推断仅基于（条件）统计独立性 [Spirtes et al., 2000, Pearl, 2009]。于是，因果结构 $X \to Y$ 和 $Y \to X$ 是不可区分的。对于仅两个变量，唯一可能的（条件）独立性将条件于空集，这不会使 X 和 Y 独立，除非因果

影响是非通用的。[1] 近年来，这一观点受到了挑战，这些方法不仅利用条件独立性，还使用联合分布的其他信息。这些方法依赖于关于概率分布与因果性之间关系的额外假设。

第4.1节的其余部分讨论了在何种假设下图结构可以从联合分布中恢复（结构可识别性）。第4.2节随后描述了从有限数据集估计图的方法（结构识别）。这些统计方法不需要以可识别性结果的证明为动机。与证明紧密结合的方法在利用数据方面往往效率低下。

4.1.2 假设类型概述

模型类的先验限制 一种区分因果与结果的可能方法是定义一类“特别自然”的条件分布[2] $P_{E|C}$和边际分布P_C。对于若干这样的类，理论结果表明，“通用”的边际分布P_X与条件分布$P_{Y|X}$组合会诱导出联合分布，当X与Y交换时，这些联合分布无法由同一类描述。这类陈述也被称为*identifiability*结果，我们将在4.1节的其余部分看到此类示例。

例如，可以通过限制函数类 f_E 来定义条件分布类 $P_{E|C}$ 和边际分布类 P_C；参见 (3.2)，以及/或限制 (3.1) 和 (3.2) 中的噪声分布类，这将在第 4.1.3–4.1.6 节中讨论。从机器学习的角度来看，这种方法似乎特别自然，因为在标准任务（如回归和分类）中，限制函数复杂度随处可见。注意，通过受限函数类推断因果方向隐含地假设噪声变量仍然独立，这与 SCM 的定义一致（见定义 3.1）。在此意义上，可以说这些方法根据图 2.2 使用了噪声的独立性，但请记住，只有在限制函数类之后，噪声的独立性才使因果方向可识别（见命题 4.1）。

另一种类别选项可见于 Sun et al. [2006]、Janzing et al. [2009b],

[1] Note that this non-generic case should not be called “trivial” because non-trivial counterfactual influence can be consistent with $X \perp\!\!\!\perp Y$ (see Section 3.4).

[2] We use the notation $P_{E|C}$ as a shorthand for the collection $(P_{E|C=c})_c$ of conditional distributions and implicitly assume the existence of a density, in other words, that $P_{E,C}$ is absolutely continuous with respect to a product measure.

以及 Comley 和 Dowe [2003]。例如，Sun 等 [2006] 和 Janzing 等 [2009b] 考虑了二阶指数模型，其中 $P_{E|C}$ 和 P_C 的对数密度分别是 e 和 c（中的二阶多项式，至多相差一个配分函数），或在 c 中。

我们以两个问题结束本部分：首先，如何定义描述现实生活中经验数据合理比例的模型类别？其次，既然经验分布恰好在一个方向上承认这样的模型，为什么这应该是因果方向？第一个问题实际上并不特定于因果推断问题；构造描述观测变量之间关系的函数总是要求我们从“合理”的类别中拟合函数。第二个问题似乎是关于概率与因果性之间关系的最深刻问题之一。我们只能给出一些直觉且模糊的想法，接下来将介绍这些想法。

我们首先提供一个直观的动机，这与通常的机器学习依赖受限模型类的原因有关。每当我们从一个小函数类中找到一个模型来拟合我们有限数量的数据时，我们期望该模型也能拟合未来的观测，正如第1章所论述的。因此，从小类中找到拟合数据的模型对于泛化到未来观测的能力至关重要。形式上，学习*causal*模型与通常的学习场景有实质性差异，因为它旨在推断描述系统在干预下行为的模型，而不仅仅是从同一分布中获得的观测。因此，没有直接的方法采用统计学习理论的论证来获得因果关系的学习理论。尽管如此，我们相信从小类中找到模型表明——在某种错误概率下——该模型在不同的背景条件下也将成立。我们进一步相信，在许多不同背景条件下成立的模型比仅仅拟合单一数据集观测的模型更可能是因果的（参见第7.1.6节“Different Environments”）。这样，通过限制模型类进行因果推断与统计学习理论的思想有模糊的联系，尽管精确的联系必须留给未来。前面关于使用小类因果模型的非正式论证不应被误解为断言自然界中的因果关系确实简单。我们是否经常成功地用*simple*函数拟合数据的问题是一个完全不同的问题。我们只是论证这样一种信念：*if*存在一个简单函数拟合数据，它更可能描述一个*causal*关系。此外，我们将在第4.1.9节中建立受限模型类与因果与机制独立性之间的一个联系。为了准备这些相当正式的推导，我们首先...

提供了一个相当不现实的玩具模型，我们认为它更像是隐喻而非严肃的例子。

原因与机制的独立性 第2.1节描述了P_C和$P_{E|C}$对应于自然界两个独立机制的思想。因此，它们通常彼此不包含信息（参见原理2.1和图2.2中的中间框）。自然地，假设P_C和$P_{E|C}$在它们不包含彼此信息的意义上独立，这引出了所指信息类型的问题。没有明显的意义可以将该假设形式化为一个可通过*statistical*独立性检验检查的条件。这是因为我们讨论的是一个场景，其中一个固定的联合分布$P_{C,E}$是可见的，而不是一组分布，在这组分布中我们可以检查假设原因的分布和假设效应的分布（给定原因）是否以依赖的方式变化（这本质上是图2.2左框与中间框之间的差异）。为了将原因与机制的独立性翻译成SCMs的语言，我们假设原因的分布应与表示因果机制的函数和噪声分布独立。注意，这再次是先验的，而非关于*statistical*独立性的陈述。相反，它表明f_E和P_{N_E}不包含关于P_C的信息，反之亦然。只有当描述从E到C的$P_{C,E}$的所有结构模型都违反独立性时，这一事实才能用于因果推断。

第4.1.7节和第4.1.8节描述了两个玩具场景，对于这两个场景，可以给出独立性与依赖性定义明确的概念。最后，在第4.1.9节中，我们描述了P_C和$P_{E|C}$的独立性形式化，该形式化适用于更一般的场景，而非仅限于第4.1.7节和第4.1.8节中的简单玩具场景。在此，依赖性通过*algorithmic*互信息来度量，这一概念基于柯尔莫哥洛夫复杂性意义上的描述长度。由于后者不可计算，它应被视为一种哲学原理而非*method*。其实际意义是双重的。首先，它可能激发新方法的开发；其次，现有方法的合理性可以基于它。例如，独立性原理可以为基于模型类先验限制的推断方法提供合理性；具体示例见第4.1.9节。为了对独立性如何与受限模型类相关获得粗略直觉，考虑一个思想实验：P_C从一类包含k个不同边际分布的集合中随机选取。同样，假设$P_{E|C}$从另一类包含ℓ个不同条件分布的集合中选取。这诱导出$k \cdot \ell$个不同的联合分布$P_{C,E}$。在一般情况下

(除非这些类以一种相当特殊的方式定义)，否则这将产生$k \cdot \ell > k$个不同的边际P_E和$k \cdot \ell > \ell$个不同的条件$P_{C|E}$。因此，*typical*种P_C和$P_{E|C}$的组合诱导出联合分布$P_{E,C}$，对于这些联合分布，“反向边际和条件”P_E和$P_{C|E}$不会在原始类中，而是需要更大的模型类。换句话说，无论如何选择可能的P_C和$P_{E|C}$的集合，诱导出的$P_{C|E}$和P_E的集合甚至更大。这一思想实验更像是一个隐喻，因为它基于从有限集合中随机选择的朴素图景。然而，它激励了这样一种信念：在*causal*方向上，边际和条件更可能从先验选定的小集合中获得描述，前提是后者以合理的方式构造。

第 4.1.3 至 4.1.6 节描述了带有模型类别先验限制的模型假设，而第 4.1.7 至 4.1.9 节则将独立性假设形式化。然而，第 4.1.9 节具有特殊地位，因为它应被视为一项基础原则，而非其本身的推断方法。

4.1.3 具有非高斯加性噪声的线性模型

虽然带有高斯噪声的线性结构方程已被广泛研究，但最近 [Kano and Shimizu, 2003, Shimizu et al., 2006, Hoyer et al., 2008a] 观察到线性 *non-Gaussian* 无环模型（LiNGAMs）为因果推断提供了新方法。特别是，从观测数据中区分 X 原因 Y 和 Y 原因 X 变得可行。假设是效应 E 是原因 C 的线性函数，至多加上一个加性噪声项：

$$E = \alpha C + N_E, \quad N_E \perp\!\!\!\perp C,$$

与$\alpha \in \mathbb{R}$ (，它是第4.1.4节)引入的加性噪声模型的一个特例。以下结果表明，该假设足以识别因果关系。

定理 4.2（线性非高斯模型的可识别性）*Assume that $P_{X,Y}$ admits the linear model*

$$Y = \alpha X + N_Y, \quad N_Y \perp\!\!\!\perp X, \tag{4.1}$$

with continuous random variables X, N_Y, and Y. Then there exist $\beta \in \mathbb{R}$ and a random variable N_X such that

$$X = \beta Y + N_X, \quad N_X \perp\!\!\!\perp Y, \tag{4.2}$$

if and only if N_Y and X are Gaussian.

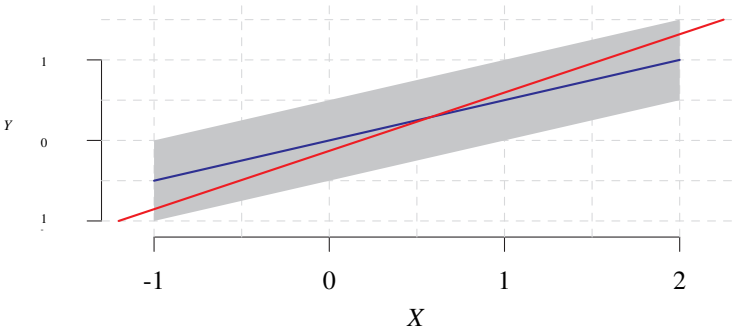

图 4.1：可识别示例中 X 和 Y 的联合密度。蓝线是对应于前向模型 $Y := 0.5 \cdot X + N_Y$ 的函数，其中 X 和 N_Y 均匀分布；灰色区域表示 (X,Y) 密度的支撑。定理 4.2 指出，由于 (X,N_Y) 的分布为非高斯分布，因此不存在任何有效的反向模型。由 (b,c) 表征的红线是最小化 $\mathbb{E}[X - bY - c]^2$ 的最小二乘拟合。这不是有效的反向模型 $X = bY + c + N_X$，因为产生的噪声 N_X 不会与 Y（独立，且 N_X 的支撑大小会随 Y）的不同取值而不同。

因此，只要 C 或 N_E 中有一个是非高斯的，就足以使因果方向可识别；参见图 4.1 的示例。

让我们更详细地探讨这个结果的证明过程。定理4.2是Shimizu等人[2006]引入的LiNGAM模型类的双变量情形，他们利用独立成分分析（ICA）[Common, 1994, Theorem 11]证明了定理4.2的多变量版本。ICA的证明基于高斯分布的一个特征，该特征由Skitovič和Darmois独立证明[Skitovič, 1954, 1962, Darmois, 1953]，我们现在将其陈述。

定理 4.3（Darmois-Skitovič）*Let $X_1,\dots,X_d$ be independent, non-degenerate random variables (see Appendix A.1). If there exist non-vanishing coefficients $a_1,\dots,a_d$ and $b_1,\dots,b_d$ (that is, for all i, $a_i \neq 0 \neq b_i$) such that the two linear combinations*

$$l_1 = a_1X_1 + \dots + a_dX_d,$$
$$l_2 = b_1X_1 + \dots + b_dX_d$$

are independent, then each X_i is normally distributed.

结果表明，定理 4.2 中陈述的双变量版本可作为 Darmois-Skitovič 定理的简短直接推论加以证明；为说明起见，我们将此证明附在附录 C.1 中。此外，可以表明双变量 SCM 的可识别性推广至多变量 SCM 的可识别性 [Peters et al., 2011b]。据此，LiNGAM 的多变量可识别性随后由定理 4.2 得出。

具有非高斯加性噪声的线性模型也可应用于一个从机器学习角度看似乎不常见、但从理论物理角度看却很有趣的问题：根据数据估计时间箭头。Peters 等人 [2009b] 表明，自回归模型是时间可逆的，当且仅当噪声变量服从正态分布。为了探索经验时间序列的不对称性，他们通过拟合两个自回归模型来推断时间方向：一个从过去到未来（标准方向），另一个从未来到过去。在他们的实验中，前者方向的噪声变量确实倾向于比反转时间方向更独立（参见第 4.2.1 节）。Bauer 等人 [2016] 将这一思想扩展到多元时间序列。Janzing [2010] 将这种观察到的不对称性与热力学时间箭头联系起来，这表明本书中讨论的因果关系之间的不对称性也与统计物理学中的基本问题相关。

4.1.4 非线性加性噪声模型

我们现在描述加性噪声模型（ANMs），这是对结构因果模型（SCMs）类别的一种不那么极端的限制，但仍然足够强大，使得因果推断可行。

定义 4.4 (ANMs) *The joint distribution $P_{X,Y}$ is said to admit an ANM from X to Y if there is a measurable function f_Y and a noise variable N_Y such that*

$$Y = f_Y(X) + N_Y, \quad N_Y \perp\!\!\!\perp X. \tag{4.3}$$

By overloading terminology, we say that $P_{Y|X}$ admits an ANM if (4.3) *holds.*

以下定理表明，“一般地”地，一个分布不会同时在两个方向上都存在ANM。

定理 4.5（ANMs 的可识别性）*For the purpose of this theorem, let us call the ANM* (4.3) *smooth if N_Y and X have strictly positive densities p_{N_Y} and p_X, and f_Y, p_{N_Y}, and p_X are three times differentiable.*

Assume that $P_{Y|X}$ admits a smooth ANM from X to Y, and there exists a $y \in \mathbb{R}$ such that

$$(\log p_{N_Y})''(y - f_Y(x)) f_Y'(x) \neq 0 \tag{4.4}$$

for all but countably many values x. Then, the set of log densities 对数
p_X *for which*
the obtained joint distribution $P_{X,Y}$ *admits a smooth ANM from* Y *to* X *is contained in a* 3*-dimensional affine space.*

证明。（思路概述。详见 Hoyer et al. [2009]）从 Y 到 X 的 ANM，由

$$p(x,y) = p_Y(y)p_{N_X}(x - f_X(y)), \tag{4.5}$$

蕴含

$$\log p(x,y) = \log p_Y(y) + \log p_{N_X}(x - f_X(y)).$$

可以证明，$\log p(x,y)$ 满足以下微分方程：

$$\frac{\partial}{\partial x}\left(\frac{\partial^2 \log p(x,y)/\partial x^2}{\partial^2 \log p(x,y)/(\partial x \partial y)}\right) = 0. \tag{4.6}$$

另一方面，从 X 到 Y 的 ANM 读作

$$p(x,y) = p_{N_X}(x)p_{N_Y}(y - f_Y(x)). \tag{4.7}$$

对(4.7)取对数得到

$$\log p(x,y) = \log p_X(x) + \log p_{N_Y}(y - f_Y(x)). \tag{4.8}$$

将 (4.6) 应用于 (4.8) 得到关于 $\log p_X$ 三阶导数的微分方程，其以 f_X 和 $\log p_{N_Y}$ 的（一阶、二阶和三阶）导数表示。因此，f_X 和 p_{N_E}（（它们是条件 $P_{Y|X}$) 的性质）将 $\log p_X$ 确定到三个自由参数 $\log p_{N_X}(v)$、$(\log p_{N_X})'(v)$ 和 $(\log p_{N_X})''(v)$ 为止，对于任意点 v。□

定理4.5阐述了“一般”情况下的可识别性，其中“一般”由复杂条件表征，例如(4.4)和三维子空间。当p_X和p_{N_Y}为高斯分布时，存在一个更简单的可识别性表述，指出只有线性函数f生成的分布才允许在反向方向存在ANM[参见Hoyer et al., 2009, Corollary 1]。图4.2可视化了两个双变量分布的“非一般”示例，这些分布在两个方向上都允许加性噪声模型。首先是双变量高斯分布的明显情况，其次是需要在p_X和N_X之间进行精细调节的复杂情况[Mooij et al., 2016]。

为了将定理 4.5 与因果语义联系起来，首先假设我们先验知道原因和结果的联合分布 $P_{X,Y}$ 允许从 C 到 E 的 ANM，但我们

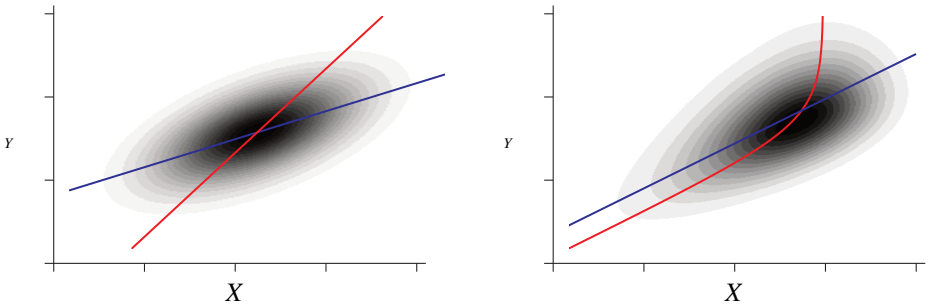

图 4.2：两个不可识别示例的 X 和 Y 联合密度。左面板显示线性高斯情形，右面板显示一个略复杂的示例，函数、输入和噪声分布具有“精细调节”参数（后者图基于核密度估计）。蓝色函数 f_Y 对应前向模型 $Y := f_Y(X) + N_Y$，红色函数 f_X 对应后向模型 $X := f_X(Y) + N_X$。

不知道 $X = C$ 和 $Y = E$ 还是反过来。定理 4.5 接着指出，一般情况下不会存在从 E 到 C 的 ANM，因此我们可以轻松地判断哪个变量是原因 C。

然而，一般来说，自然界中的条件分布 $P_{E|C}$ 并没有受到如此强烈的限制，以至于它们必然存在 ANM。但 P_C 和 $P_{E|C}$ 是否可能诱导出一个联合分布 $P_{C,E}$，使得从 E 到 C 存在 ANM？（在这种情况下，我们会推断出错误的因果方向。）我们在第 4.1.9 节论证，如果 P_C 和 $P_{E|C}$ 是独立选择的，这种情况不太可能发生。

4.1.5 离散加性噪声模型

加性噪声不仅可以为实值变量定义，还可以为任何在环中取值的变量定义。Peters 等人 [2010, 2011a] 为环 [3] $\mathbb{Z}$ 和 $\mathbb{Z}/m\mathbb{Z}$ 引入了 ANMs。即整数集和模 $m \in \mathbb{Z}$ 的整数集。在后者中，我们将除以 m 后余数相同的数视为同一。例如，整数 132 和 4 除以 8 后的余数均为 4（即 4），我们写作 $132 \equiv 4 \bmod 8$。当某个领域具有循环结构时，这种模运算可能是合适的。例如，如果考虑一年中的日期，我们可能希望 12 月 31 日和 1 月 1 日之间的距离与 8 月 25 日和 8 月 26 日之间的距离相同。

[3] In a ring, we can perform addition and multiplication. The latter operation does not necessarily have an inverse, though.

与连续情形一样，我们可以证明，在一般情况下，联合分布至多在一个方向上具有ANM。以下结果考虑环$\mathbb{Z}$的例子。

定理 4.6（离散 ANM 的可识别性）*Assume that a distribution $P_{X,Y}$ allows for an ANM $Y = f(X) + N_Y$ from X to Y and that either X or Y has finite support. $P_{X,Y}$ allows for an ANM from Y to X if and only if there exists a disjoint decomposition $\bigcup_{i=0}^{l} C_i = \text{supp}$ X, such that the following conditions a), b), and c) are satisfied:*

a) The C_i's are shifted versions of each other

$$\forall i \, \exists d_i \geq 0 : C_i = C_0 + d_i$$

and f is piecewise constant: $f|_{C_i} \equiv c_i \, \forall i$.

b) The probability distributions on the C_is are shifted and scaled versions of each other with the same shift constant as above: For $x \in C_i$, $P(X = x)$ satisfies

$$P(X = x) = P(X = x - d_i) \cdot \frac{P(X \in C_i)}{P(X \in C_0)}.$$

c) The sets $c_i +$ 支撑 $N_Y := \{c_i + h : P(N_Y = h) > 0\}$ are disjoint sets.

(根据对称性，满足相同条件的这种分解也存在于 Y 的支撑上。) 图 4.3 展示了一个在两个方向上都允许 ANM 的示例 [Peters et al., 2011a]。

对于模 m 的离散 ANM 也有类似结果；详细内容请参见 Peters et al. [2011a]，但我们想指出的是，均匀噪声分布起着特殊作用：当噪声变量在 $\{0, \ldots, m-1\}$ 上均匀分布时，$Y \equiv f(X) + N_Y \bmod m$ 会使 X 和 Y 独立，因此也允许从 Y 到 X 的 ANM。

离散ANM对底层过程施加了强假设，这些假设在实践中经常被违反。与连续情况一样，我们想论证*if*：如果过程在一个方向上允许离散ANM，那么将该方向推断为因果方向可能是合理的（参见第4.1.9节）。

4.1.6 后非线性模型

比第4.1.4节所介绍的模型类别更一般的模型类别已由Zhang和Hyvärinen [2009]分析；另见Zhang和Chan [2006]的早期参考文献。

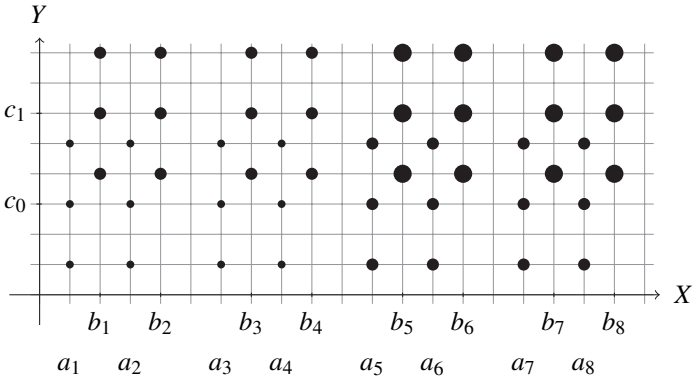

图 4.3：只有精心选择的参数才能允许双向 ANM（半径对应概率值）；见定理 4.6 。定理描述的集合是 $C_0 = \{a_1, a_2, \ldots, a_8\}$ 和 $C_1 = \{b_1, b_2, \ldots, b_8\}$。函数 f 在 C_0 和 C_1 上分别取值 c_0 和 c_1。

定义 4.7（后非线性模型）*The distribution $P_{X,Y}$ is said to admit a post-nonlinear model if there are functions f_Y, g_Y and a noise variable N_Y such that*

$$Y = g_Y(f_Y(X) + N_Y), \quad N_Y \perp\!\!\!\perp X. \tag{4.9}$$

以下结果本质上表明，除了某些“罕见”的非通用情形外，后非线性模型至多在一个方向上存在。[4]

定理 4.8（后非线性模型的可识别性）*Let $P_{X,Y}$ admit a post-nonlinear model from X to Y as in* (4.9) *such that p_X, f_Y, g_Y are three-times differentiable. Then it admits a post-nonlinear model from Y to X only if p_X, f_Y, g_Y are adjusted to each other in the sense that they satisfy a differential equation described in Zhang and Hyvärinen [2009].*

4.1.7 信息几何因果推断 e

为了提供如何将 $P_{E|C}$ 和 P_C 之间的独立性形式化的思路，本节描述信息几何因果推断（IGCI）。IGCI，特别是这里描述的简单版本，是一个高度理想化的玩具场景，它很好地说明了单向独立性如何意味着

4在这里，“罕见”should not be mistaken as saying that there are only finitely many e异常。

反方向 [Daniušis et al., 2010, Janzing et al., 2012]。它依赖于（诚然很强的）假设，即X与Y在两个方向上存在确定性关系；即，

$$Y = f(X) \quad \text{and} \quad X = f^{-1}(Y).$$

换句话说，(3.2) 中的噪声变量是常数。于是，第 4.1.2 节所描述的因果与机制独立性原理简化为 P_X 和 f 的独立性。值得注意的是，这种独立性意味着 P_Y 和 f^{-1} 之间存在依赖关系。为了说明这一点，我们考虑 Daniušis et al. [2010] 更一般设定的以下特例。

定义 4.9（IGCI 模型）*Here, $P_{X,Y}$ is said to satisfy an IGCI model from X to Y if the following conditions hold: $Y = f(X)$ for some diffeomorphism*[5] *f of* $[0, 1]$ *that is strictly monotonic and satisfies $f(0) = 0$ and $f(1) = 1$. Moreover, P_X has the strictly positive continuous density p_X, such that the following "independence condition" holds:*

$$\operatorname{cov}[\log f', p_X] = 0, \tag{4.10}$$

where $\log f'$ *and p_X are considered as random variables on the probability space* $[0, 1]$ *endowed with the uniform distribution.*[6]

注意到 (4.10) 中的协方差被显式地给出为

$$\begin{aligned}\operatorname{cov}[\log f', p_X] &= \int_0^1 \log f'(x) p_X(x) dx - \int_0^1 \log f'(x) dx \int_0^1 p_X(x) dx \\ &= \int_0^1 \log f'(x) p_X(x) dx - \int_0^1 \log f'(x) dx.\end{aligned}$$

以下结果见于 Daniušis 等 [2010] 和 Janzing 等 [2012]。

定理 4.10（IGCI 模型的可识别性）*Assume the distribution $P_{X,Y}$ admits an IGCI model from X to Y. Then the inverse function f^{-1} satisfies*

$$\operatorname{cov}[\log f^{-1'}, p_Y] \geq 0, \tag{4.11}$$

with equality if and only if f is the identity.

---

[5] A function is called a diffeomorphism if it is differentiable and bijective and it has a differentiable inverse.

[6] This view may be unexpected, but recall that random variables are defined as measurable functions on a probability space. Here, both $\log f'$ and p_X are functions of $x \in [0,1]$, thus they are random variables on the common probability space $[0,1]$. Therefore, any distribution on $[0,1]$ defines a joint distribution of these random variables.

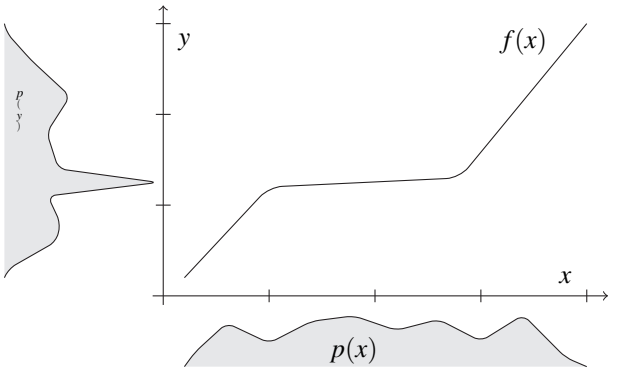

图 4.4：IGCI 思想的可视化：p_Y 的峰值往往出现在 f 斜率较小且 f^{-1} 斜率较大的区域（前提是 p_X 独立于 f 选择）。因此 p_Y 包含关于 f^{-1} 的信息。IGCI 可以推广到不可微函数 f [Janzing et al., 2015]。

换句话说，$\log f'$ 和 p_X 的不相关性意味着 $\log f^{-1'}$ 和 p_Y 之间存在正相关，除了平凡情况 $f = id$。这在图 4.4 中有所说明。可以证明 [Janzing and Schölkopf, 2015]，f' 和 p_X (的不相关性，即 (4.10) 不带对数的类似形式)，意味着 $f^{-1'}$ 和 p_Y 之间存在正相关，但 IGCI 使用对数导数，因为这允许多种信息论解释 [Janzing et al., 2012]。作为 (4.10) 的论证，Janzing et al. [2012] 描述了一个模型，其中 f 独立于 P_X 随机生成，并表明 (4.10) 在高概率下近似成立。然而，应该强调的是，这种论证总是指过于简化的模型，这些模型不太可能描述现实情况。注意，IGCI 可以轻松扩展到向量值变量之间的双射关系（如 Daniušis et al. [2010, Section 3] 已描述的那样），但双射确定性关系在经验数据中很少见。因此，IGCI 仅提供了一个玩具场景，在这个场景中，因果推断可以通过近似独立性假设实现。IGCI 的假设也被用于 [Janzing and Schölkopf, 2015] 解释为什么半监督学习的性能依赖于因果方向，如第 5.1 节所述。绝非意味着 (4.10) 是 *the* 因果与机制独立性的正确形式化，我们也不认为存在唯一的形式化。例如，Sgouritsa et al. [2015] 提出了一种“无监督逆回归”技术，试图从 P_X 预测 $P_{Y|X}$，并从 P_Y 预测 $P_{X|Y}$；然后他们建议性能较差的方向是因果方向。因此，这种方法将“独立性”解释为使这类无监督预测不可能。

4.1.8 追踪方法

Janzing et al. [2010] 和 Zscheischler et al. [2011] 描述了 P_C 和 $P_{E|C}$ 之间与 IGCI 相关的独立性，适用于 C 和 E 是由线性 SCM 耦合的高维变量的情况：

定义 4.11（迹条件）*Let* X *and* Y *be variables with values in* $\mathbb{R}^d$ *and* $\mathbb{R}^e$*, respectively, satisfying the linear model*

$$\mathbf{Y} = A\mathbf{X} + N_{\mathbf{X}}, \quad N_{\mathbf{X}} \perp\!\!\!\perp \mathbf{X}, \tag{4.12}$$

where A is an $e \times d$ *matrix of structure coefficients. Then* $P_{\mathrm{X},\mathrm{Y}}$ *is said to satisfy the trace condition from* X *to* Y *if the covariance matrix* $\Sigma_{\mathbf{XX}}$ *and A are "independent" in the sense that*

$$\tau_e(A\Sigma_{\mathbf{XX}}A^T) = \tau_d(\Sigma_{\mathbf{XX}})\tau_e(AA^T), \tag{4.13}$$

where $\tau_k(B) := \mathrm{tr}(B)/k$ *denotes the renormalized trace of a matrix B.*

一个违反迹条件的简单情况可以由矩阵 A 给出，该矩阵将 $\Sigma_{\mathbf{XX}}$ 对应于大特征值的所有特征向量缩小，并将对应于小特征值的特征向量拉伸。这无疑表明 A 并非独立于 $\Sigma_{\mathbf{XX}}$ 选择的。粗略地说，(4.13) 描述了 $\Sigma_{\mathbf{XX}}$ 的特征值与 A 改变对应特征向量长度的因子之间的不相关性。更正式地说，(4.13) 可以通过一个具有大 d, e 的生成模型来证明，其中 $\Sigma_{\mathbf{XX}}$ 和 A 根据适当的（旋转不变的）先验概率独立随机选择。然后它们以高概率近似满足 (4.13) [Besserve et al., in preparation]。对于确定性可逆关系，因果方向是可识别的。

定理 4.12（通过迹条件的可识别性）*Let both variables* X *and* Y *be d-dimensional with* $\mathrm{Y} = A\mathrm{X}$*, where A is invertible. If the trace condition* (4.13) *from* X *to* Y *is fulfilled, then the backward model*

$$\mathbf{X} = A^{-1}\mathbf{Y}$$

satisfies

$$\tau_d(A^{-1}\Sigma_{\mathbf{YY}}A^{-T}) \leq \tau_d(\Sigma_{\mathbf{YY}})\tau_d(A^{-1}A^{-T}),$$

with equality if and only if all singular values of A have the same absolute value.

证明。该证明通过将 Janzing et al. [2010] 中的定理 2 应用于情形 $n := m := d$ 并观察到，当 Z 是严格正的随机变量且几乎必然非常数时，$\mathrm{cov}[\mathrm{Z}, 1/\mathrm{Z}]$ 为负，从而得证。□

因此，在一般情况下，迹条件在反向方向被违反，且对等式的违反始终具有相同的符号。

对于含噪关系，目前尚无类似定理 4.12 的结论。仍可检查（4.13）是否在某一方向上近似成立，并由此推断该方向为因果方向。此时，从 Y 到 X 的因果模型的结构矩阵不再由 A^{-1} 给出。在这种情况下，我们引入记号 $A_{\mathbf{X}}$ 表示从 X 到 Y 的模型，以及 $A_{\mathbf{Y}}$ 表示从 Y 到 X 的模型。确定性情形之所以特别好，是因为商

$$\frac{\tau(A_{\mathbf{X}}\Sigma_{\mathbf{YY}}A_{\mathbf{X}}^T)}{\tau(A_{\mathbf{X}}A_{\mathbf{X}}^T)\tau(\Sigma_{\mathbf{YY}})}$$

已知其为*smaller*于1，因为$A_{\mathbf{X}} = A_{\mathbf{Y}}^{-1}$。

本书中提到的独立性条件（如 (4.10)、(4.13) 等）的理论论证依赖于高度理想化的生成模型（例如，(4.13) 已被一个模型所论证，其中原因的协方差矩阵由旋转不变先验生成 [Janzing et al., 2010]）。然而，有理由希望理想化假设的违反并不一定破坏因果推断方法。Beuchet 椅子的隐喻或许有助于阐明这一点。首先，考虑观察视角在球面上均匀选取的情景。显然，这不包含关于物体方向的任何信息。在此意义上，均匀先验形式化了“独立性”假设。随后，椅子幻觉仅发生在可忽略的一小部分角度上。显然，观察点选择的严格均匀性并非得出此结论所必需；相反，只要先验不集中在这小部分特殊角度内，任意随机选择都将产生相同结果。换言之，关于 *typical* 主体所见内容的结论对底层独立性假设的违反具有鲁棒性。因此，关于因果推断理想化假设的讨论应聚焦于：违反假设在多大程度上破坏推断方法，而非解释它们为何过于理想化。

4.1.9 A 算法信息论作为可能的基础 赠与

本节描述了一个独立性原理，尽管它依赖于定义良好的数学形式体系，但在实践中尚不清楚如何应用。因此，它在一方面是第2.1节中关于因果推断基础的非正式哲学讨论，另一方面是 con- 之间起着中间作用。

另一方面，第4.1.3至4.1.8节关于因果之间可能存在的不对称性的具体结果依赖于相当具体的模型假设。

要将 P_E 和 $P_{C|E}$ 不包含彼此信息这一点形式化，对于比第 4.1.7 节和第 4.1.8 节所考虑的更一般的模型而言是具有挑战性的。这需要一种信息概念，该概念指代的对象不仅仅是随机变量。这是因为 P_E 和 $P_{C|E}$ 本身并非随机变量，而是描述随机变量的分布。一个有趣的信息概念由柯尔莫哥洛夫复杂度给出，我们现在简要解释一下。

算法信息论概念 我们首先介绍柯尔莫哥洛夫复杂度：考虑一台通用图灵机 T，即一种计算机抽象，其理想之处在于拥有无限的内存空间访问能力。对于任意二进制字符串 s，我们将 $K_T(s)$ 定义为最短程序[7]的长度，记为 s^*，其中 T 输出 s 并随后停止 [Solomonoff, 1964, Kolmogorov, 1965, Chaitin, 1966, Li and Vitányi, 1997]。人们可以将 s^* 称为 s 的最短压缩，但请记住 s^* 包含了 T 运行解压缩所需的所有信息。因此，

$$K_T(s) := |s^*|,$$

其中 $|\cdot|$ 表示二进制字的位数。这定义了相对于给定图灵机 T 的无概率信息内容概念。在下文中，我们将参考某个固定的 T，因此省略下标。尽管 $K(s)$ 是不可计算的，即不存在从 s 计算 $K(s)$ 的算法 [Li and Vitányi, 1997]，但它可用于形式化概念性思想，正如本节所做的那样。

s 在给定 t 的条件下的条件算法信息记为 $K(s|t)$，定义为从输入字符串 t 生成输出 s 并随后停止的最短程序的长度。然后可以将互信息定义为[8]

$$I(s:t) := K(s) - K(s|t^*).$$

特别地，我们有 [Chaitin, 1966]：

$$I(s:t) \stackrel{+}{=} K(s) + K(t) - K(s,t), \tag{4.14}$$

[7] The program is given by a binary word using prefix-free encoding; that is, no program code is the prefix of another one. Otherwise one would need an extra symbol indicating the end of the code.

[8] Note that conditioning on t^* instead of t makes a difference since there is no algorithm that computes t^* from t (but vice versa); t^* can thus be more valuable as input than t. It turns out that $K(s|t^*)$ shows closer analogies to conditional Shannon entropy than $K(s|t)$.

其中符号 $\stackrel{+}{=}$ 表示该等式仅在常数意义下成立；即存在一个误差项，其长度可独立于 s 和 t 的长度而被界定。为了在 *pair* (s,t) 上定义柯尔莫哥洛夫复杂度 $K(s,t)$，通过首先使用字符串的某种枚举，再使用 $\mathbb{N}$ 与 $\mathbb{N}\times\mathbb{N}$ 之间的标准双射，构造字符串与字符串对之间的简单双射。

(4.14)的一个简单解释是，算法互信息因此量化了在联合压缩s,t而非独立压缩它们时所节省的内存空间量。Janzing和Schölkopf [2010]认为，两个对象的二进制描述s,t具有显著的互信息，则它们很可能存在因果关系。换句话说，就像*random variables*之间的统计依赖表明因果关系（见原理1.1）一样，对象之间的算法依赖表明*objects*之间的因果关系。例如，观察到不同公司生产的两件设计相似的T恤可能表明其中一家公司抄袭了另一家。事实上，现实生活中模式的相似性可以通过算法互信息来描述，前提是首先就将模式编码为二进制字的“适当”方式达成一致，然后就“适当”的图灵机达成一致。关于“适当”意味着什么这一困难问题，另见Janzing et al. [2016]引言中对“相对因果性”的简要讨论。

条件的算法独立性　算法独立条件原理已由Janzing 和 Schölkopf [2010] 以及 Lemeire 和 Janzing [2013] 针对多变量因果结构提出，但它在双变量情形下已产生非平凡的推论。

对于作为因果关系的两个变量 C 和 E，我们假设 P_C 和 $P_{E|C}$ 可以由二进制字符串 s 和 t 给出有限描述。在参数设置中，s 和 t 可能描述对应参数空间中的点。或者，可以将 s 和 t 看作程序，它们对所有具有有限描述长度的值 c,e 计算 $p(c)$ 和 $p(e|c)$。然后我们使用 $I(P_C : P_{E|C})$ 表示 $I(s:t)$，并假设：

原理 4.13（算法独立条件）*P_C and $P_{E|C}$ are algorithmically independent, that is,*

$$I(P_C : P_{E|C}) \stackrel{+}{=} 0, \tag{4.15}$$

or, equivalently,

$$K(P_{C,E}) \stackrel{+}{=} K(P_C) + K(P_{E|C}). \tag{4.16}$$

(4.15) 和 (4.16) 的等价性是显而易见的，因为描述对 $(P_C, P_{E|C})$ 等价于描述联合 $P_{C,E}$。原理 4.13 的思想是 P_C 和 $P_{E|C}$ 是自然界中因果无关的对象。这当然是一种理想化假设，但对于 X 导致 Y 或 Y 导致 X 的情境，当 P_X 和 $P_{Y|X}$ 之间的算法依赖性弱于 $P_{X|Y}$ 和 P_Y 之间时，建议推断 $X \to Y$。然而，将这应用于经验数据会引出一个问题：$P_{X,Y}$ 无法从有限数据中确定，此外算法互信息是不可计算的。

尽管存在这些问题，原则 4.13 有助于为实际的因果推断方法提供合理性，正如我们现在对 ANM 的例子所描述的那样。Janzing 和 Steudel [2010] 认为，SCM $Y := f_Y(X) + N_Y$ 意味着 $y \mapsto \log p(y)$ 的二阶导数由 $(x,y) \mapsto \log p(x|y)$ 的偏导数决定。因此，知道 $P_{X|Y}$ 允许在精度) 内对 P_Y (给出简短描述。每当 $K(P_Y)$ 大于这小量信息时，Janzing 和 Steudel [2010] 得出结论：应拒绝 $Y \to X$，因为 P_Y 和 $P_{X|Y}$ 在算法上是依赖的。对于任何给定的数据集，我们无法保证仅仅因为存在从 Y 到 X 的 ANM，$K(P_Y)$ 就足够大到可以拒绝 $Y \to X$。然而，当将基于 ANM 原理的推断应用于大量不同分布时，我们知道大多数分布 P_Y 足够复杂（因为低复杂度分布的集合很小），足以拒绝在相反方向诱导 ANM 的因果模型。此外，图 5.4 左右两侧显示了两个简单的玩具示例，其中仅看 P_X 就能对联合分布 $P_{X,Y}$ 给出简单猜测。事实上，可以证明这相当于 P_X 和 $P_{Y|X}$ 之间的算法依赖，正如 Janzing 和 Schölkopf [2010, Equation (27) 之后的注释] 对左侧情况所示。

我们还应指出，(4.15) 意味着

$$K(P_C) + K(P_{E|C}) \stackrel{+}{=} K(P_{C,E}) \stackrel{+}{\leq} K(P_E) + K(P_{C|E}). \tag{4.17}$$

等式成立是因为描述 $P_{C,E}$ 等价于描述对 $(P_C, P_{E|C})$，这并不比分别描述边际分布和条件分布更短。不等式成立是因为 P_E 和 $P_{C|E}$ 也确定了 $P_{C,E}$。换句话说，条件独立性意味着联合分布在因果方向上的描述比在反因果方向上更短。[9]

[9] Checking whether the left-hand side of inequality (4.17) is smaller than the right-hand side is not the only option to test independence: whenever two strings are algorithmically independent, applying functions of complexity $\mathcal{O}(1)$ to each of them generates again two (possibly simpler) algorithmically

这一蕴含从最小描述长度原理 [Grünwald, 2007] 的角度看也很自然，并且符合奥卡姆剃刀的精神。然而，需要注意的是，条件 $K(P_C) + K(P_{E|C}) \stackrel{+}{\leq} K(P_E) + K(P_{C|E})$ 严格弱于 (4.15)，因为 $P_{C,E}$ 的最短描述可能不使用两种可能的分解中的任何一种，这可能发生，例如，当存在隐藏的共同原因时 [Janzing and Schölkopf, 2010, p. 16]。

原理 6.53 将原理 4.13 推广到多元情形。

4.2 结构识别方法

我们现在介绍如何利用第4.1节获得的可识别性结果来进行因果发现的不同思路。也就是说，这些方法从有限数据集中估计图。这些是具有挑战性的统计问题，可以通过多种不同方式加以处理。我们试图聚焦于方法论思想，并不声称我们所介绍的方法对数据的利用最为高效。未来的研究完全可能产生新颖且成功的方法。我们将注意力限制在少数几个例子上，主要是那些我们对其性能有合理经验的例子。

4.2.1 加性噪声模型

对于基于定理 4.5 中 ANM 可识别性的因果学习方法，我们主要参考多变量章节（第 7.2 节）。在此，我们简要介绍两种方法，不声称其最优性。第一种方法检验残差的独立性，是回归后独立性检验（RESIT）算法的特例（见第 7.2 节）。

1. 对 Y 进行 X 的回归；即，使用某种回归技术将 Y 写成 X 的函数 $\hat{f}_Y$ 加上一些噪声。 2. 检验 $Y - \hat{f}_Y(X)$ 是否与 X 独立。 3. 交换 X 和 Y 的角色，重复该过程。 4. 如果在一个方向上接受独立性而在另一个方向上拒绝，则将前者推断为因果方向。

图4.5展示了在模拟数据集上的过程；底层分布见图4.1。至少在连续设定下，前两个步骤是标准的—

---

independent strings [Janzing and Schölkopf, 2010, Lemma 6]. This way, one can in principle reject algorithmic independence without knowing the complexities of the strings to start with.

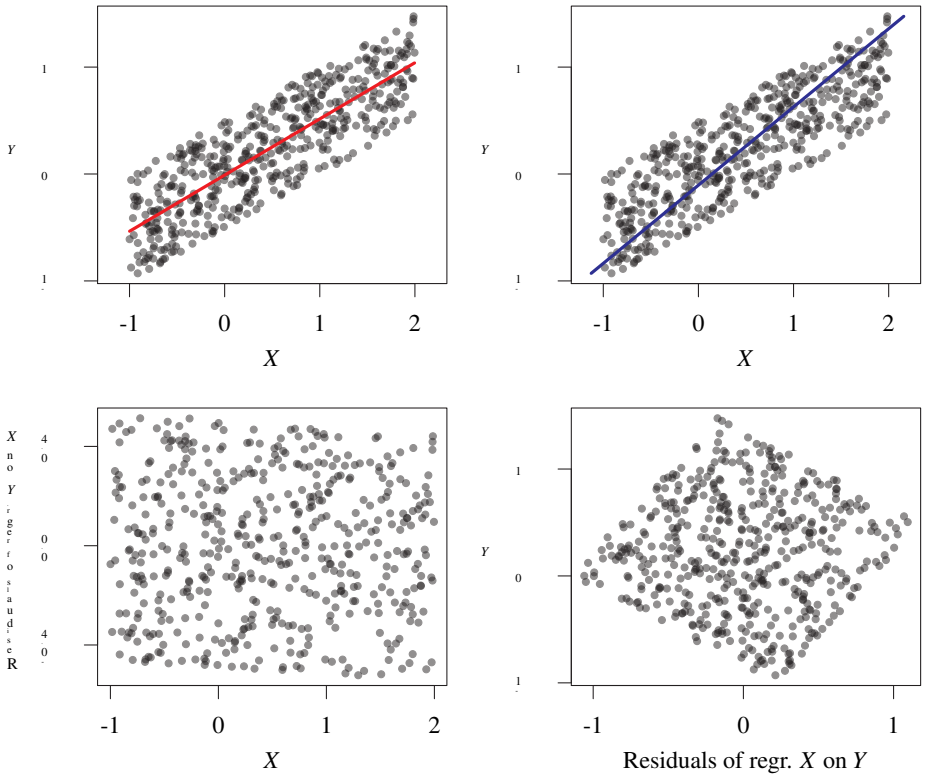

图 4.5：我们从底层分布中获得一个样本，并在方向 $X \to Y$ (left) 和 $Y \to X$ (right) 上执行线性回归。拟合函数显示在上行，对应的残差显示在下行。只有方向 $X \to Y$ 产生独立的残差；另见图 4.1。

机器学习和统计学的标准问题（见附录 A.1 和 A.2），其额外挑战在于它们是耦合的：$\hat{f}_Y$ 偏离 f_Y 可能会隐藏或产生噪声与输入变量之间的依赖关系。一般而言，基于 *estimated* 残差的任何检验都可能失去对 I 类错误的控制。作为一种可能的解决方案，可以使用样本分割 [Kpotufe et al., 2014]。此外，重要的是选择考虑高阶统计量而非仅测试相关性的独立性检验。任何最小化二次误差的回归技术

包含线性分量和截距会产生不相关的噪声。[10] 在实践中，例如可以使用希尔伯特-施密特独立性准则（HSIC）[Gretton et al., 2008]，我们在附录 A.2 中简要介绍了它。Mooij et al. [2016, Theorem 20] 利用 HSIC 的连续性性质表明，即使不进行样本分割，在数据无限的极限下也能获得 HSIC 的正确值（然而，关于该检验的 p 值没有任何断言）。最后，最后一步值得我们特别关注，因为它涉及概率与因果关系之间的联系。根据拒绝和接受独立性的显著性水平，可能在两个方向上得到 ANM，在没有方向上得到，或在一个方向上得到。为了做出决策，只需推断该方向为因果方向，其中拒绝独立性的 p 值更高。

近期研究提供了一些证据表明，该方法在真实数据上的成功率高于随机水平 [Mooij et al., 2016]。图 4.6 展示了真实世界数据[11]的散点图，其中 ANM 仅在因果方向上合理成立。关于离散数据的修改，我们参考相应的文献 [Peters et al., 2011a]。请注意，后非线性模型（4.9）在实践中比更标准的非线性回归模型（4.3）难以拟合得多。

作为前述方法的替代方案，也可以采用基于最大似然的方法。例如，考虑一个具有加性高斯误差项的非线性SCM。然后可以通过比较两个模型的似然得分来区分$X \to Y$和$X \leftarrow Y$。为此，我们首先从Y对X执行非线性回归，以获得残差$R_Y := Y - \hat{f}_Y(X)$。然后比较

$$L_{X\to Y} = -\log \widehat{\mathrm{var}}[X] - \log \widehat{\mathrm{var}}[R_Y] \tag{4.18}$$

与类似版本

$$L_{X\leftarrow Y} = -\log \widehat{\mathrm{var}}[R_X] - \log \widehat{\mathrm{var}}[Y] \tag{4.19}$$

当交换 X 和 Y 的角色时所得到的结果。不难证明（见习题 4.16），当不执行回归而是使用真实条件均值时，这确实对应于对似然的比较

[10] This can easily be seen using the following standard geometric picture: $\mathrm{cov}[.,.]$ defines an inner product in the space of centred random variables with finite variance. Then the length of the vector $Y - \alpha X$ is minimal when it is orthogonal to X.

[11] This is pair001 in the database of cause-effect pairs `https://webdav.tuebingen.mpg.de/cause-effect/`; see also [Mooij et al., 2016].

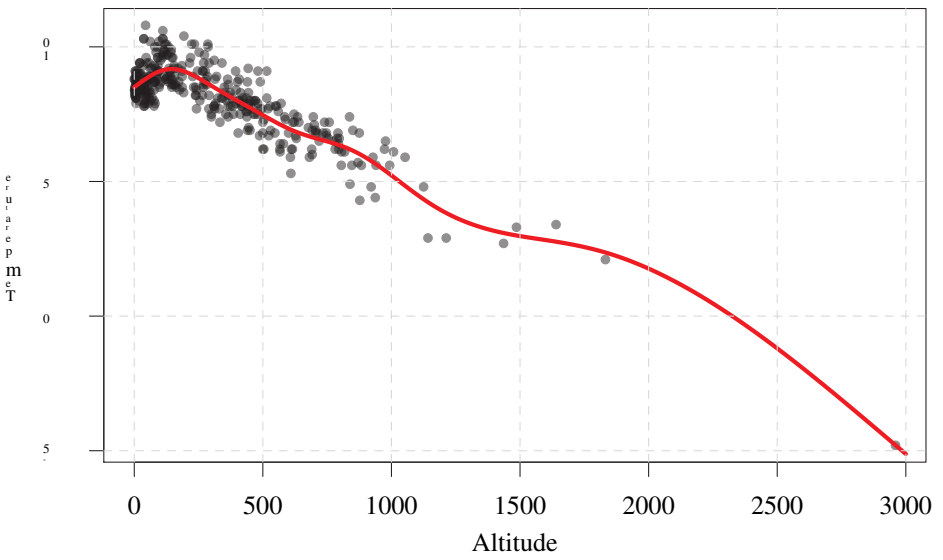

图 4.6：德国各地平均气温（摄氏度，Y）与海拔（米，X）之间的关系。数据来自“Deutscher Wetterdienst”，另见 Mooij et al. [2016]。一个非线性函数（在远离海平面的区域接近线性）加上加性噪声能合理拟合这些经验观测。

$\hat{f}_Y(x) = \mathbb{E}[Y \,|\, X = x]$（$\hat{f}_X$ 亦同）。然而，与之前一样，这种先执行回归再计算样本方差的两步程序需要论证。Bühlmann 等人 [2014] 使用经验过程理论 [van de Geer, 2009] 证明了一致性。如果噪声不一定服从高斯分布，我们必须通过将残差经验方差的对数替换为误差项的微分熵估计来调整评分函数 [Nowzohour 和 Bühlmann, 2016]。

代码片段 4.14 以下代码展示了一个有限数据集的示例。它使用了代码包 `dHSIC` [Pfister et al., 2017] 和 `mgcv` [Wood, 2006]。前者包含函数 `dhsic.test`，即 [Gretton et al., 2008] 提出的独立性检验的实现；后者包含函数 `gam`，我们在第 10 行和第 11 行将其用作非线性回归方法（见 A.1 节）。仅在反向方向上，残差与输入之间的独立性被拒绝，见第 15 行和第 17 行。在第 21 行和第 23 行，我们看到高斯似然得分也倾向于正向方向；另见公式 (4.18) 和 (4.19)。

```
library(dHSIC)
library(mgcv)
#
# generate data set
set.seed(1)
X <- rnorm(200)
Y <- X^3 + rnorm(200)
#
# fit models
modelforw <- gam(Y ~ s(X))
modelbackw <- gam(X ~ s(Y))
#
# independence tests
dhsic.test(modelforw$residuals, X)$p.value
# [1] 0.7628932
dhsic.test(modelbackw$residuals, Y)$p.value
# [1] 0.004221031
#
# computing likelihoods
- log(var(X)) - log(var(modelforw$residuals))
# [1] 0.1420063
- log(var(modelbackw$residuals)) - log(var(Y))
# [1] -1.014013
```

4.2.2 信息几何因果推断

我们简要概述 IGCI 的实现，并参考 Mooij et al. [2016] 以了解细节。理论基础由定理 4.10 中的可识别性结果及其一些简单推论给出。可以证明，独立性条件 (4.10) 蕴含

$$C_{X\to Y} \le C_{Y\to X}$$

若定义

$$C_{X\to Y} := \int_0^1 \log f'(x)p(x)dx,$$

以及 $C_{Y\to X}$ 同理。这里使用了以下直接估计量：

$$\hat{C}_{X\to Y} := \frac{1}{N-1}\sum_{j=1}^{N-1} \log \frac{|y_{j+1}-y_j|}{|x_{j+1}-x_j|},$$

其中 $x_1 < x_2 < \cdots < x_N$ 是按递增顺序排列的观测 x 值。如果 Y 是 X 的递增函数，则 y 值也是有序的，但对于真实数据，通常情况并非如此。估计量 $\hat{C}_{Y\to X}$ 相应地被定义，并且每当$\hat{C}_{X\to Y} < \hat{C}_{Y\to X}$ 时推断出 $X \to Y$。除了所谓的 *slope-based* 方法之外，

还有基于熵的方法。可以证明(4.10)也意味着

$$H(X) \leq H(Y),$$

其中 H 表示微分香农熵

$$H(X) := -\int_0^1 p(x) \log p(x) dx.$$

直观地说，原因在于将非线性函数 f 应用于 p_X 会产生额外的不规则性（除非 f 的非线性相对于 p_X 进行调节），从而使 p_Y 比 p_X 更不均匀。因此，熵更大的变量被假设为原因。要估计 H，可以使用文献中任意标准的熵估计器。

4.2.3 迹方法

回顾一下，这种方法依赖于高维变量 X 和 Y 之间的线性关系。首先假设样本量足够大（与 X 和 Y 的维度相比），以便通过标准线性回归估计协方差矩阵 $\Sigma_{\mathbf{XX}}$ 和 $\Sigma_{\mathbf{YY}}$ 以及结构矩阵 $A_{\mathbf{Y}}$ 和 $A_{\mathbf{X}}$。为了应用定理 4.12 中的可识别性结果，可以计算迹依赖比

$$r_{X \to Y} := \frac{\tau(A_{\mathbf{Y}} \Sigma_{\mathbf{XX}} A_{\mathbf{Y}}^T)}{\tau(A_{\mathbf{Y}} A_{\mathbf{Y}}^T) \tau(\Sigma_{\mathbf{XX}})},$$

同理$r_{Y \to X}$ (通过交换 X 和 Y 的角色)，并推断出更接近 1 的那个对应于因果方向 [Janzing et al., 2010]。

Zscheischler 等人 [2011] 描述了一种方法，用于评估偏离 1 是否显著，该方法在一个生成模型下进行：在该模型中，两个矩阵 A 和 $\Sigma_{\mathbf{XX}}$ 的独立性通过某个随机正交映射将它们相互旋转来模拟。利用自由概率理论 [Voiculescu, 1997] 的思想，这是一种描述大随机矩阵渐近行为的数学框架，Zscheischler 等人 [2011] 构造了迹条件在维度大于样本量的情形下的实现。他们表明，在无噪声情况下，$r_{X \to Y}$ 仍然可以被估计（尽管没有足够的数据来估计 $\Sigma_{\mathbf{XX}}$ 和 A），前提是 A 与 X 的经验协方差矩阵满足额外的独立性假设。因此，只要估计量显著偏离 1，就可以拒绝假设 $\mathrm{X} \to \mathrm{Y}$。于是，要么额外的独立性假设是错误的，要么 $r_{X \to Y}$ 显著偏离 1。

4.2.4 监督学习方法

最后，我们描述了一种从更偏向机器学习的角度来接近因果学习的方法。原则上，它具有利用受限函数类或独立性条件的能力。假设，我们被给定形式为 $(\mathcal{D}_1, A_1), \ldots, (\mathcal{D}_n, A_n)$ 的标记训练数据。这里，每个 $\mathcal{D}_i$ 是一个数据集。

$$\mathcal{D}_i = \{(X_1, Y_1), \ldots, (X_{n_i}, Y_{n_i})\}$$

包含实现 $(X_1, Y_1), \ldots, (X_{n_i}, Y_{n_i}) \overset{\text{iid}}{\sim} P^i_{X,Y}$，且每个标签 $A_i \in \{\rightarrow, \leftarrow\}$ 描述数据集 $\mathcal{D}_i$ 对应 $X \rightarrow Y$ 还是 $X \leftarrow Y$。然后，因果学习成为经典的预测问题，可训练分类器，期望其从已知真实标签的数据集良好泛化到未见测试数据集。

据我们所知，Guyon [2013] 是第一个以挑战形式系统研究该方法的人（提供混合的合成与真实数据集作为已知真实数据）。显然，该方法无法通过利用对称特征（如相关性或协方差）来取得成功。

挑战中许多竞争性分类器基于手工设计的特征；例如，边际分布的熵估计，或由将 X 对 Y 进行回归、或将 Y 从 X 进行回归所得到的残差分布的熵估计。有趣的是，这些特征可与 ANM 的概念相关联。例如，对于高斯分布变量，熵是方差对数的线性函数，因此这些特征具有足够的表达能力来重构得分 (4.18) 和 (4.19)。考虑熵而非方差的对数，相当于放宽高斯性假设 [Nowzohour and Bühlmann, 2016]。

Lopez-Paz et al. [2015] 旨在自动构建此类特征。其思想是将联合分布 $P^i_{X,Y}$，$i = 1, \ldots, n$ 映射到再生核希尔伯特空间（见附录 A.2）并在该空间中执行分类。实际上，人们无法访问完整分布 $P^i_{X,Y}$，而是使用经验分布作为近似。（类似方法已被用于区分时间反转的时间序列与其原始版本 [Peters et al., 2009a]。）由于因果分类似乎依赖于联合分布的相对复杂性质，因此训练集需要较大的样本量 n。为了添加有用的模拟数据集，这些数据必须由可识别的情况生成。例如，Lopez-Paz et al. [2015] 使用来自 ANM 的额外样本。

监督学习 ng 方法尚不能作为独立方法用于 因果的

学习。然而，它们可能被证明是有用的统计工具，能够有效利用已知的可识别性性质或其组合。

4.3 问题

习题 4.15（ANMs）*a) Consider the SCM*

$$X := N_X$$
$$Y := 2X + N_Y$$

with N_X uniformly distributed between 1 and 3 and N_Y uniformly distributed between -0.5 and 0.5 and independent of N_X. The distribution $P_{X,Y}$ admits an ANM from X to Y. Draw the support of the joint distribution of X, Y and convince yourself that $P_{X,Y}$ does not admit an ANM from Y to X, that is there is no function g and independent noise variables M_X and M_Y such that

$$X = g(Y) + M_X$$
$$Y = M_Y$$

with M_X independent of M_Y.

b) Similarly as in part a), consider the SCM

$$X := N_X$$
$$Y := X^2 + N_Y$$

with N_X uniformly distributed between 1 and 3 and N_Y uniformly distributed between -0.5 and 0.5 and independent of N_X. Again, draw the support of $P_{X,Y}$ and convince yourself that there is no ANM from Y to X.

问题 4.16（最大似然）*Assume that we are given an i.i.d. data set $(X_1, Y_1), \ldots, (X_n, Y_n)$ from the model*

$$Y = f(X) + N_Y, \text{ with } X \sim \mathcal{N}(\mu_X, \sigma_X^2), \text{ and } N_Y \sim \mathcal{N}(\mu_{N_Y}, \sigma_{N_Y}^2) \text{ independent},$$

where the function f is supposed to be known.

a) Prove that $f(x) = \mathbb{E}[Y \mid X = x]$.

b) Write $\mathrm{x} := (x_1, \ldots, x_n)$, $\mathrm{y} := (y_1, \ldots, y_n)$ *and consider the log-likelihood func- tion*

$$\ell_\theta(\mathbf{x}, \mathbf{y}) = \ell_\theta\left((x_1, y_1), \ldots, (x_n, y_n)\right) = \sum_{i=1}^{n} \log p_\theta(x_i, y_i),$$

where p_θ *is the joint density over* (X, Y) *and* $\theta := (\mu_X, \mu_{N_Y}, \sigma^2_X, \sigma^2_{N_Y})$. *Prove that for some* $c_1, c_2 \in \mathbb{R}$ *with* $c_2 > 0$

$$\max_\theta \ell_\theta(\mathbf{x}, \mathbf{y}) = c_2 \cdot \left(c_1 - \log \widehat{\mathrm{var}}[\mathbf{x}] - \log \widehat{\mathrm{var}}\left[\mathbf{y} - f(\mathbf{x})\right]\right), \tag{4.20}$$

where 変量$[\mathrm{z}] := \frac{1}{n}\sum_{i=1}^{n}(z_i - \frac{1}{n}\sum_{k=1}^{n} z_k)^2$ *estimates the variance.*

Equation (4.20) *motivates the comparison of expressions* (4.18) *and* (4.19). *The main difference is that in this exercise, we have used the conditional mean and not the outcome of the regression method. One can show that, asymptotically, the latter still produces correct results [Bühlmann et al., 2014].*

5

与机器学习的联系，I

正如第1章所论述的，标准机器学习与统计学建立在同一基础上：我们使用从某个未知底层分布中独立同分布（i.i.d.）采样的数据，并试图推断该分布的性质。相比之下，因果推断假设存在更强的底层结构，包括有向依赖关系。这使得从数据中学习该结构更为困难，但一旦完成，也能做出新的陈述，包括关于分布变化和干预效果的陈述。如果我们将机器学习视为推断超越纯统计关联的规律（或“自然法则”）的过程，那么因果性起着至关重要的作用。本章对这一点提出了一些思考，仅关注两个变量的情况。第8章将重新探讨这一主题，并考察多变量情况。

5.1 半监督学习

让我们考虑一个回归任务，其中我们的目标是从一个d维的预测变量X预测目标变量Y。对于许多损失函数，知道条件分布$P_{Y|\mathbf{X}}$足以解决该问题。例如，回归函数

$$f^0(\mathbf{x}) := \mathbb{E}[Y \,|\, \mathbf{X} = \mathbf{x}]$$

最小化 L_2 损失，

$$f^0 \in \operatorname*{argmin}_{f:\mathbb{R}^d \to \mathbb{R}} \mathbb{E}\left[(Y - f(\mathbf{X}))^2\right].$$

在监督学习中，我们从联合分布接收 n 个独立同分布（i.i.d.）数据点：$(\mathrm{X}_1, Y_1), \ldots, (\mathrm{X}_n, Y_n) \overset{\text{iid}}{\sim} P_{\mathbf{X},Y}$。因此，回归估计（采用 L_2 损失）相当于从联合分布的 n 个数据点中估计条件均值。然而，在（归纳式）半监督学习（SSL）中，我们接收 m 个额外的无标签数据点 $\mathrm{X}_{n+1}, \ldots, \mathrm{X}_{n+m} \overset{\text{iid}}{\sim} P_{\mathbf{X}}$。希望这些额外数据点提供关于 $P_{\mathbf{X}}$ 的信息，而这本身告诉我们关于 $\mathbb{E}[Y|\mathrm{X}]$ 或更一般地关于 $P_{Y|\mathbf{X}}$.[1] 许多支撑 SSL 技术的假设 [参见 Chapelle et al., 2006，综述] 关注 $P_{\mathbf{X}}$ 与 $P_{Y|\mathbf{X}}$ 之间的关系。例如，*cluster assumption* 规定，位于 $P_{\mathbf{X}}$ 同一簇中的点具有相同或相似的 Y；这类似于 *low-density separation* 假设，即分类器的决策边界（即 $P(Y = 1|\mathrm{X} = \mathrm{x})$ 穿过 0.5 的点 x）应位于 $P_{\mathbf{X}}$ 较小的区域中。*semi- supervised smoothness* 假设指出，条件均值 $\mathrm{x} \mapsto \mathbb{E}[Y|\mathrm{X} = \mathrm{x}]$ 应在 $P_{\mathbf{X}}$ 较大的区域中是平滑的。

5.1.1 SSL 与因果方向

在最简单的设定中，当因果图仅包含两个变量（原因和结果）时，机器学习问题可以是因果的（若从原因预测结果），也可以是反因果的（若从结果预测原因）。从业者通常不关心给定学习问题背后的因果结构（见图 5.1）。然而，正如我们在此所论证的，该结构对机器学习具有重要意义。

在第2.1节中，我们假设因果条件句彼此之间是*independent*（原理2.1及后续讨论）。Schölkopf等人[2012]意识到这一原理对SSL具有直接的含义。由于后者依赖于$P_{\mathbf{X}}$与$P_{Y|\mathbf{X}}$之间的关系，且原理声称P_{cause}与$P_{\text{effect}|\text{cause}}$不包含彼此的信息，我们可以得出结论：如果X对应于原因而Y对应于结果（即对于一个*causal*学习问题），SSL将无法工作。在这种情况下，额外的x值只会告诉我们更多关于$P_{\mathbf{X}}$的信息——这无关紧要，因为预测需要关于独立对象$P_{Y|\mathbf{X}}$的信息。另一方面，如果X是结果而Y是原因，关于$P_{\mathbf{X}}$的信息可能告诉我们关于$P_{Y|\mathbf{X}}$的一些信息。

一项分析 SSL 结果的荟萃研究支持了我们的假设。所有案例

[1] Again, we use the notation $P_{Y|\mathbf{X}}$ as a shorthand for the collection $(P_{Y|\mathbf{X}=\mathbf{x}})_{\mathbf{x}}$ of conditional distributions.

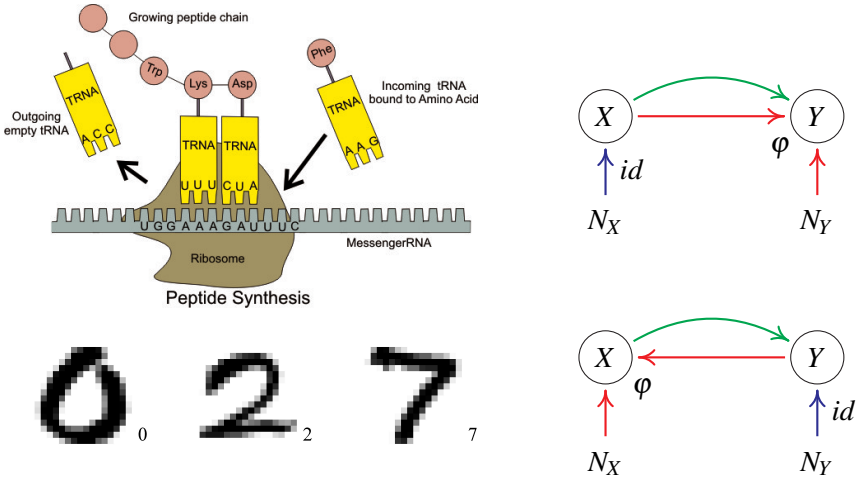

图5.1：*Top:* 一个复杂的机制 φ 称为核糖体将mRNA信息 X 翻译成蛋白质链 Y 。[2] 从mRNA预测蛋白质是一个*causal*学习问题的例子，其中预测方向（绿色箭头）与因果方向（红色）一致。*Bottom:* 在手写数字识别中，我们试图从书写者产生的图像 X 中推断类别标签 Y (，即书写者的意图)。这是一个*anticausal*问题。

SSL 有帮助的情况是反因果的、存在混杂的，或因果结构不清楚的例子（见图 5.2）。

在双射确定性因果关系的玩具场景中（见第4.1.7节），Janzing 和 Schölkopf [2015] 证明，当 P_{cause} 和 $P_{\text{effect}|\text{cause}}$ 在 (4.10) 的意义下独立时，SSL 确实在反因果方向上优于监督学习，但在因果方向上并不如此。其思想是 SSL 利用依赖关系 (4.11) 来改进插值算法。

Sgouritsa et al. [2015] 开发了一种因果学习方法，该方法利用了 SSL 只能在反因果方向上工作的事实。

最后，注意到 SSL 包含无监督学习的某些版本作为特殊情况（无标注数据）。例如在聚类中，Y 通常是表示聚类索引的离散值。与前面的推理类似，我们可以论证，如果 X 是原因而 Y 是结果，聚类不应工作良好。在

[2] By user “Boumphreyfr”, https://commons.wikimedia.org/wiki/File:Peptide_syn.png, [CC BY-SA 3.0 (http://creativecommons.org/licenses/by-sa/3.0) or GFDL (http://www.gnu.org/copyleft/fdl.html)]

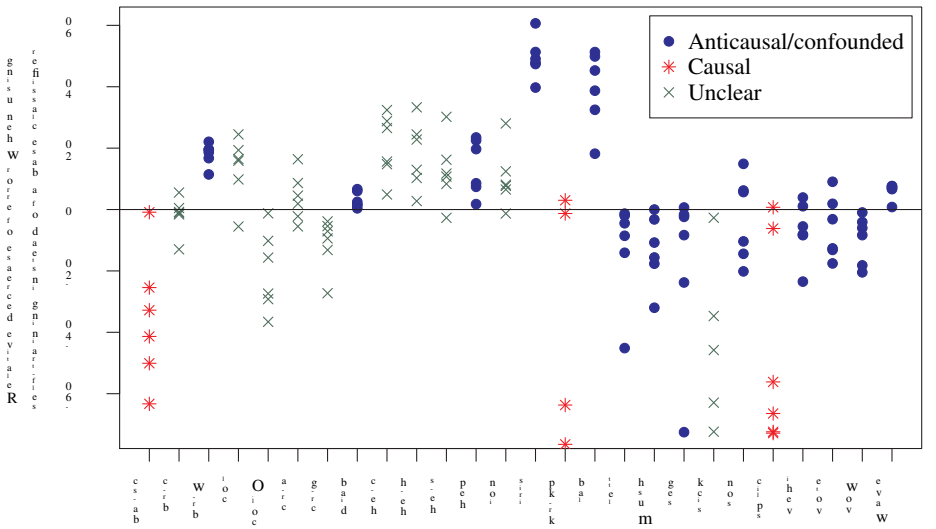

图 5.2：SSL 的收益取决于因果结构。每列点对应于 UCI 仓库中的一个基准数据集，展示了六种不同的基础分类器在使用自训练（一种通用的 SSL 方法）增强后的性能。性能以相对于基础分类器的错误率下降百分比来衡量，即 (error(base) − error(self-train))/error(base)。总体而言，自训练对因果数据集没有帮助，但对某些反因果/混淆数据集有帮助 [来自 Schölkopf et al., 2012]。

然而，在真实数据的许多聚类应用中，聚类索引与其说是特征的结果，不如说是特征的原因。

尽管图 5.2 的实证结果令人鼓舞，但“SSL 在因果方向上不起作用”这一论断（始终假设原因与机制独立，参见原理 2.1）需要更精确地表述。这将在下一节中完成；对关注 SSL 与协变量偏移的读者而言，这可能具有兴趣，但其他读者在首次阅读时可以跳过。

5.1.2 因果方向中 SSL 的一个备注 n

关于 SSL 的预测的更精确形式如下：如果任务是预测某个特定 x 的 y，当 $X \to Y$ 是因果方向时，知道 P_X 没有帮助。然而，即使由于 $X \to Y$），P_X 无法告诉我们关于 $P_{Y|X}$（的任何信息，知道 P_X 仍然可以帮助我们更好地估计 Y，在以下意义上：

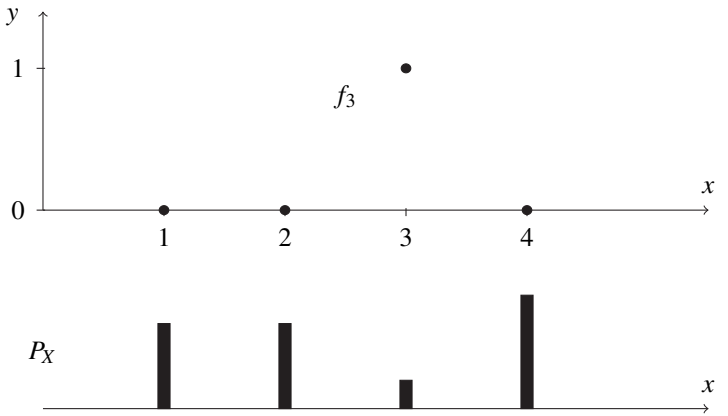

图 5.3：在此示例中，SSL 甚至在因果方向上也降低了损失。由于对于每个 x，标签 0 先验上比标签 1 更可能，因此当选择一个函数，使其在 $p(x)$ 最小的点 x 处取值为 1 时，预期错误数量被最小化（这里：$x = 3$）。

在学习场景中获得更低风险。

为了说明这一点，考虑一个玩具示例，其中 X 与 Y 之间的关系由确定性函数给出，即 $Y = f(X)$，其中 f 已知来自某类函数 $\mathcal{F}$。设 X 取值于 $\{1,\dots,m\}$，其中 $m \geq 3$，设 Y 为二元标签，取值于 $\{0,1\}$。我们通过 $f_j(j) = 1$ 和 $f_j(k) = 0$ 对于 $k \neq j$ 定义函数类 $\mathcal{F} := \{f_1,\dots,f_m\}$。换句话说，$\mathcal{F}$ 由在恰好一点上取值为一的函数集合组成。图 5.3 上部显示了 $m = 4$ 时的函数 f_3。假设我们的学习算法推断出 f_j，而真实函数是 f_i。对于 $i \neq j$，风险，即预期错误数（见式 (1.2)），等于

$$R_i(f_j) := \sum_{x=1}^{m} |f_j(x) - f_i(x)| p(x) = p(j) + p(i), \tag{5.1}$$

其中 p 表示 X 的概率质量函数。现在我们对集合 $\mathcal{F}$ 上的 $R_i(f_j)$ 取平均，并假设每个 f_i 等可能。这得到期望风险（其中期望是关于 $\mathcal{F}$ 上的均匀先验取的）

$$\mathbb{E}[R_i(f_j)] = \frac{1}{m} \sum_{i=1}^{m} \sum_{x=1}^{m} |f_j(x) - f_i(x)| p(x) \tag{5.2}$$

$$= \frac{1}{m} \sum_{i \neq j} (p(j) + p(i)) = \frac{m-2}{m} p(j) + \frac{1}{m}. \tag{5.3}$$

为了最小化 (5.3)，我们因此应选择 f_k，使得 k 最小化函数 p。这很合理，因为对于任意点 $x = 1,\ldots,m$，标签 $y = 0$ 比 $y = 1$ 更可能（概率 $(m-1)/m$ 对比 $1/m$）。因此，我们实际上希望在所有地方推断为零，但由于零函数不包含在 $\mathcal{F}$ 中，我们被迫选择一个 x 值并将其标签设为零。因此，我们选择最不可能的 x 值之一，以获得最小期望损失（对于图 5.3 底部的分布，这为 $x = 3$）。显然，无标签观测有助于识别最不可能的 x 值，因此 SSL 可以提供帮助。此示例不需要任何 (x,y) 对（有标签实例）；无标签数据 x 就足够了。因此，这实际上是 *un*监督学习的一个例子，而不是典型的 SSL 场景。然而，额外考虑少量有标签实例并不会改变本质思想。通常，如果 m 足够大，这些少量实例不会包含任何带有 $y = 1$ 的实例。因此，观测到的 (x,y) 对仅有助于将 $\mathcal{F}$ 略微缩小到更小的类 $\mathcal{F}'$，对于该类分析基本保持不变，我们仍然得出结论：无标签实例有助于。

虽然我们尚未将监督学习场景作为基线指定（即不使用P_X知识的场景），但我们知道它一定比最佳半监督场景更差，因为最优估计依赖于P_X，正如我们刚才所论证的。

在此，机制的独立性未被违反（因此，X 可被视为 Y 的原因）：假设 f 在 $\mathcal{F}$ 中均匀选取，且知道 P_X 无法提供关于 f 的任何信息。知道 P_X 仅有助于最小化损失，因为 $p(x)$ 在 (5.2) 中作为权重因子出现。

前面的例子在精神上接近贝叶斯分析，因为它涉及对 $\mathcal{F}$ 中函数的平均。然而，它可以被修改以应用于最坏情况分析，其中真实函数 f 由对手选择以最大化 (5.1) [参见 Kääriäinen, 2005]。给定函数 f_j，对手选择 f_i，使得 i 是一个与 j 不同的 x 值，且具有最大概率质量。因此，最坏情况风险为 $\max_{x\neq j}\{p(x)\} + p(j)$，这再次在 j 被选为最小化概率质量函数 $p(x)$ 的 x 值时被最小化。因此，我们得出结论，只有当考虑 P_X 时，才能获得最优性能。

另一个例子可以基于 Urner et al. [2011, Theorem 4 的证明] 在非因果性背景下给出的论证来构造。他们构造了一个模型误设定的情况；其中真实函数 f_0 不包含在被优化的类 $\mathcal{F}$ 中。在他们的例子中，关于边际 P_X 的额外信息有助于降低风险，尽管条件 $P_{Y|X}$ 可以被认为与边际独立。我们上面的例子并非基于

关于同类模型误设定。每个可能的（未知）真实值 f_i 确实包含在函数类中；然而，我们希望在先验上最小化风险的 *expectation*，而我们的函数类不包含具有零期望风险的函数。因此，对于期望风险而言，这类似于模型误设定的情况。

最后，我们试图对 Urner et al. [2011] 的例子提供一些进一步的直觉。由于 f_0 不在函数类 $\mathcal{F}$ 中，我们需要找到一个函数 $\hat{f} \in \mathcal{F}$，使得距离 $d(f, f_0)$（定义为 f 的风险）在 $f \in \mathcal{F}$ 上最小化；我们说 f_0 被投影到 $\mathcal{F}$ 上。粗略地说，关于 P_X 的额外信息使我们对这个投影有更好的理解。[3]

5.2 协变量偏移

正如第 2.1 节所解释的，P_{cause} 与 $P_{\text{effect}|\text{cause}}$ (原理 2.1) 之间的独立性可以有两种不同的解释：在上面的第 5.1 节中，我们论证了在给定固定联合分布的情况下，这两个对象彼此不包含任何信息（见图 2.2 中间的方框）。或者，假设联合分布 $P_{\text{cause,effect}}$ 在不同数据集之间发生变化；那么 P_{cause} 的变化不会告诉我们关于 $P_{\text{effect}|\text{cause}}$ (的变化的任何信息，这对应于图 2.2 中的左方框)。知道 X 是原因而 Y 是结果，因此对预测场景具有重要意义，其中 Y 从 X 预测。假设我们已使用一个数据集中的示例学习了 X 与 Y 之间的统计关系，并且我们需要将这些知识用于在第二个数据集上从 X 预测 Y。进一步假设，我们观察到第二个数据集中的 x 值遵循分布 P'_X，这与第一个数据集的分布 P_X 不同。我们如何利用这些信息？根据机制的独立性，P'_X 与 P_X 不同的事实不会告诉我们 $P_{Y|X}$ 是否也在数据集之间发生了变化。因此，条件 $P_{Y|X}$ 可能仍然对第二个数据集成立。其次，即使条件确实变为 $P'_{Y|X} \neq P_{Y|X}$，仍然使用 $P_{Y|X}$ 进行预测也是自然的。毕竟，独立性原理指出，边际分布从 P_X 到 P'_X 的新变化不会告诉我们关于 *how* 条件已改变的任何信息。因此，在没有更好的候选者的情况下，我们使用 $P_{Y|X}$。尽管 P_X 已经发生变化，但使用相同的条件 $P_{Y|X}$ 通常被称为

[3] We are grateful to several people who contributed to this discussion: Sebastian Nowozin, Ilya Tolstikhin, and Ruth Urner.

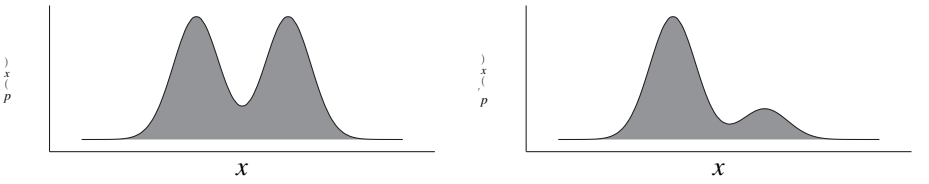

图 5.4：P_X 变化为 P'_X 的方式表明 P_Y 已发生变化，而 $P_{X|Y}$ 保持不变。当 Y 是二元的，并且已知是 X 的原因时，观察到 P_X 是两个高斯分布的混合，使得两个模式对应于两个不同标签 $y = 0, 1$ 是合理的。然后，Y 对 X 的影响仅仅在于移动高斯分布的均值（这相当于 ANM —— 见第 4.1.4 节），这无疑是对联合分布的简单解释。此外，观察到混合权重从一个数据集变化到另一个数据集，使得这种变化很可能是由于 P_Y 的变化。

协变量偏移。同时，这在机器学习中是一个被充分研究的假设 [Sugiyama and Kawanabe, 2012]。认为这仅在 *causal* 情景下是合理的论点，即如果 X 是原因而 Y 是结果，已由 Schölkopf 等人 [2012] 提出。

为进一步说明这一点，考虑以下 *anti- causal* 场景的玩具示例，其中 X 是效应。设 Y 为二元变量，以加法方式影响实值变量 X:

$$X = Y + N_X, \tag{5.4}$$

其中假设 N_X 为高斯噪声，与 Y 独立。图 5.4 左图显示了对应的概率密度 p_X。

如果其宽度足够小，分布 P_X 是双峰的。即使完全不了解生成模型，P_X 也可以被识别为两个宽度相等的高斯分布的混合。在这种情况下，因此可以仅从 P_X 推测联合分布 $P_{X,Y}$，因为自然假设 Y 的影响仅在于移动 X 的均值。在此假设下，我们不需要任何 (x, y) 对来学习 X 和 Y 之间的关系。现在假设在第二个数据集中，我们观察到相同的两个高斯分布的混合，但权重不同（见图 5.4，右）。那么，最自然的结论是权重发生了变化，因为同一个方程（5.4）仍然成立，但只有 P_Y 发生了变化。因此，我们不再使用相同的 $P_{Y|X}$ 进行预测，而是从 P'_X 重构 $P'_{Y|X}$。该示例说明在反因果场景中，P_X 和 $P_{Y|X}$ 的变化可能相关，这种关系可能是由于 P_Y 发生了变化而 $P_{X|Y}$ 保持不变所致。在其他

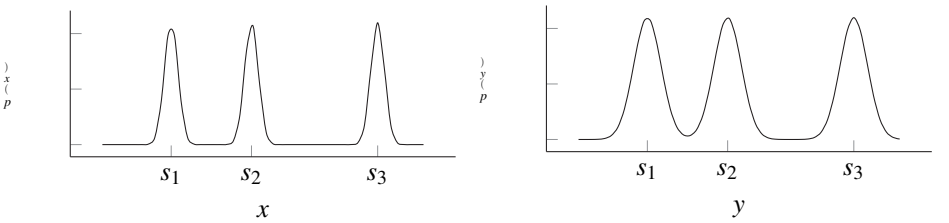

图 5.5：X 引起 Y 的示例，因此 P_Y 和 $P_{X|Y}$ 相互包含信息。左：P_X 是位置 s_1, s_2, s_3 处尖锐峰的混合。右：P_Y 由 P_X 与零均值高斯噪声卷积得到，因此在相同位置 s_1, s_2, s_3 处由较不尖锐的峰组成。于是 $P_{X|Y}$ 也包含关于 s_1, s_2, s_3 (的信息，参见问题 5.1)。

词语，P_{effect} 和 $P_{\text{cause|effect}}$ 通常以依赖的方式变化，因为 P_{cause} 和 $P_{\text{effect|cause}}$ 独立变化。

前面的例子引出了一个特定场景。构思利用 P_{effect} 和 $P_{\text{cause|effect}}$ 以依赖方式变化这一事实的通用方法是一个难题。这可能是进一步研究的一个有趣方向，我们认为因果关系在领域适应和迁移问题中可能发挥重要作用；另见 Bareinboim and Pearl [2016]、Rojas-Carulla et al. [2016]、Zhang et al. [2013] 和 Zhang et al. [2015]。

5.3 问题

问题 5.1（机制的独立性）*Let P_X be the mixture of k sharp Gaussian peaks at positions $s_1, \ldots, s_k$ as shown in Figure 5.5, left. Let Y be obtained from X by adding some Gaussian noise N with zero mean and a width σ_N such that the separate peaks remain visible as in Figure 5.5, right.*

a) Argue intuitively why $P_{X|Y}$ also contains information about the positions $s_1, \ldots, s_k$ of the peaks and thus $P_{X|Y}$ and P_Y share this information.

b) The transition between P_X and P_Y can be described by convolution (from P_X to P_Y) and deconvolution (from P_Y to P_X). If $P_{Y|X}$ is considered as the linear map converting the input P_X to the output P_Y then $P_{Y|X}$ coincides with the convolution map. Argue why $P_{X|Y}$ does not coincide with the deconvolution map (as one may think at first glance).

6

多变量因果模型

在第3章中，我们讨论了两个变量的因果模型。虽然一些基本概念在双变量情况下可以更容易地解释，但因果推断的大部分结构源于多变量关系，这涉及至少三个变量。现在我们考虑更一般的$d \geq 2$个变量的因果模型。

许多概念直接适用，我们希望读者凭借第3章获得的直觉，能够轻松理解SCMs（第6.2节）、干预（第6.3节）和反事实（第6.4节）的定义。但与双变量情况相比，也存在根本性差异。在第6.5节中，我们将看到图结构蕴含的条件独立性陈述在双变量情况下是平凡的。此外，在多变量环境下计算干预分布需要更多思考：我们将在第6.6节讨论调整公式和do-calculus [Pearl, 2009]。

我们首先引入一些图论术语。大多数定义不言自明，可在 Spirtes et al. [2000]、Koller and Friedman [2009] 和 Lauritzen [1996] 等文献中找到。例如，已经熟悉图模型的读者可能希望跳过本节。本书最重要的术语是有向无环图（DAGs）、v-结构以及 *d*-分离。

6.1 图论术语

考虑有限多个随机变量 $\mathrm{X} = (X_1, \ldots, X_d)$，其指标集为 $\mathrm{V} := \{1, \ldots, d\}$，联合分布 $P_{\mathbf{X}}$，密度 $p(\mathrm{x})$。图 $\mathcal{G} = (\mathrm{V}, \mathcal{E})$ 由...组成

由（有限多个）节点或顶点 V 和边 $\mathcal{E} \subseteq \mathrm{V}^2$，其中 $(v,v) \notin \mathcal{E}$ 对任意 $v \in \mathrm{V}$。我们进一步有以下定义：

设 $\mathcal{G} = (\mathrm{V}, \mathcal{E})$ 是一个图，其顶点集为 $\mathrm{V} := \{1,\ldots,d\}$，对应的随机变量为 $\mathbf{X} = (X_1,\ldots,X_d)$。图 $\mathcal{G}_1 = (\mathrm{V}_1, \mathcal{E}_1)$ 若满足 $\mathrm{V}_1 = \mathrm{V}$ 且 $\mathcal{E}_1 \subseteq \mathcal{E}$，则称为 $\mathcal{G}$ 的子图，记作 $\mathcal{G}_1 \leq \mathcal{G}$。若进一步满足 $\mathcal{E}_1 \neq \mathcal{E}$，则 $\mathcal{G}_1$ 是 $\mathcal{G}$ 的真子图。

节点 i 称为 j 的父节点，若 $(i,j) \in \mathcal{E}$ 且 $(j,i) \notin \mathcal{E}$；称为子节点，若 $(j,i) \in \mathcal{E}$ 且 $(i,j) \notin \mathcal{E}$。j 的父节点集合记为 $\mathrm{PA}_j^{\mathcal{G}}$，其子节点集合记为 $\mathrm{CH}_j^{\mathcal{G}}$。若 $(i,j) \in \mathcal{E}$ 或 $(j,i) \in \mathcal{E}$，则节点 i 与 j 相邻。若所有节点对均相邻，则称 $\mathcal{G}$ 完全连通。若 $(i,j) \in \mathcal{E}$ 且 $(j,i) \in \mathcal{E}$，则称两个相邻节点 i 与 j 之间存在无向边。若两个相邻节点之间的边不是无向的，则称其为有向边。我们随后将 $(i,j) \in \mathcal{E}$ 记为 $i \to j$。若 $\mathcal{G}$ 的所有边均为有向的，则称 $\mathcal{G}$ 为有向图。[1] 三个节点称为不道德结构或 v-结构，若其中一个节点是另外两个节点的子节点，且这两个节点本身不相邻。$\mathcal{G}$ 的骨架不考虑边的方向。它是图 $(\mathrm{V}, \tilde{\mathcal{E}})$，其中 $(i,j) \in \tilde{\mathcal{E}}$，若 $(i,j) \in \mathcal{E}$ 或 $(j,i) \in \mathcal{E}$。

在 $\mathcal{G}$ 中，一条路径是（至少两个）不同顶点 $i_1,\ldots,i_m$ 的序列，使得对于所有 $k = 1,\ldots,m-1$，i_k 与 i_{k+1} 之间存在边。若 $i_{k-1} \to i_k$ 且 $i_{k+1} \to i_k$，则 i_k 称为相对于该路径的对撞节点。若对所有 k 均有 $i_k \to i_{k+1}$，则称从 i_1 到 i_m 为有向路径，并称 i_1 是 i_m 的祖先，i_m 是 i_1 的后代。在本工作中，i 的所有祖先记为 $\mathrm{AN}_i^{\mathcal{G}}$，且 i 不是自身的祖先。此外，i 既不是自身的后代，也不是自身的非后代。我们将 i 的所有后代记为 $\mathrm{DE}_i^{\mathcal{G}}$，将 i 的所有非后代（不包括 i）记为 $\mathrm{ND}_i^{\mathcal{G}}$。在本书中，$\mathrm{ND}_i^{\mathcal{G}}$ 包含图 $\mathcal{G}$ 中 i 的父节点。没有父节点的节点称为源节点，没有子节点的节点称为汇节点。一个排列 π，即双射函数 $\pi : \{1,\ldots,d\} \to \{1,\ldots,d\}$，若满足 $\pi(i) < \pi(j)$ 当 $j \in \mathrm{DE}_i^{\mathcal{G}}$ (，则称为拓扑序或因果序；参见附录 B)。

图 $\mathcal{G}$ 称为部分有向无环图（PDAG），如果不存在有向环，即不存在一对（j，k），使得从 j 到 k 和从 k 到 j 存在有向路径。$\mathcal{G}$ 称为有向无环图（DAG），如果它是 PDAG 且所有边都是有向的。

由于我们将在本文多处使用它，我们将d-分离的图形概念[Pearl, 1985, 1988]形式化为一个定义。

[1]号 te that this excludes cycles of length 2, but it does not excludes longer 个周期。

定义 6.1（Pearl 的 d-分离）*In a DAG $\mathcal{G}$, a path between nodes i_1 and i_m is* ***blocked by a set*** S *(with neither i_1 nor i_m in* S*) whenever there is a node i_k, such that one of the following two possibilities holds:*

(i) $i_k \in$ S *and*

$$\begin{aligned} & i_{k-1} \to i_k \to i_{k+1} \\ \textit{or}\ \ & i_{k-1} \leftarrow i_k \leftarrow i_{k+1} \\ \textit{or}\ \ & i_{k-1} \leftarrow i_k \to i_{k+1} \end{aligned}$$

(ii) neither i_k nor any of its descendants is in S *and*

$$i_{k-1} \to i_k \leftarrow i_{k+1}.$$

Furthermore, in a DAG $\mathcal{G}$, we say that two disjoint subsets of vertices A *and* B *are* ***d-separated*** *by a third (also disjoint) subset* S *if every path between nodes in* A *and* B *is blocked by* S*. We then write*

$$\mathbf{A} \perp\!\!\!\perp_{\mathcal{G}} \mathbf{B} \,|\, \mathbf{S}.$$

读者可以查看图 6.5，并确信对于这个 DAG，我们有 $C \perp\!\!\!\perp_{\mathcal{G}} G \,|\, X$ 但 $C \not\perp\!\!\!\perp_{\mathcal{G}} G \,|\, (X, H)$。

6.2 结构因果模型

SCM 已在农业、社会科学和计量经济学等领域长期应用 [Wright, 1921, Haavelmo, 1944, Bollen, 1989]；参见第 2 章。例如，模型选择通过拟合在系统先验知识下被认为合理的不同结构来完成。这些候选结构随后通过拟合优度检验进行比较。在本章中，我们介绍 SCM 的语义，并学习如何使用它们计算干预分布，例如。在整个章节中，我们将假设 SCM 或至少其结构已给定。我们在第 7 章讨论识别结构的问题。

定义 6.2（结构因果模型）*A* ***structural causal model (SCM)*** $\mathfrak{C} := (\mathrm{S}, P_{\mathbf{N}})$ *consists of a collection* S *of d* ***(structural) assignments***

$$X_j := f_j(\mathbf{PA}_j, N_j), \qquad j = 1, \ldots, d, \tag{6.1}$$

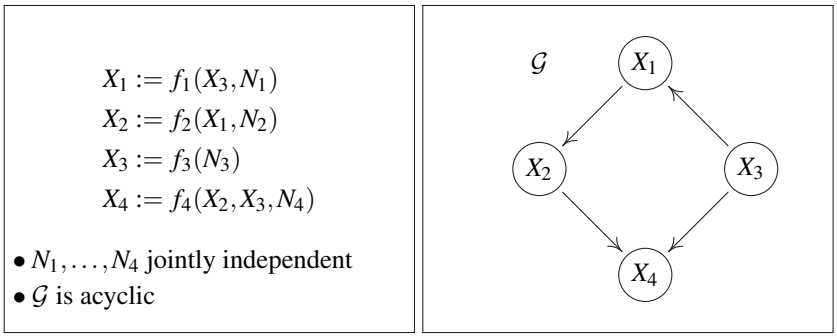

图 6.1：SCM 示例（左）及其对应图（右）。只有一个因果顺序 π (满足 $3 \mapsto 1$, $1 \mapsto 2$, $2 \mapsto 3$, $4 \mapsto 4$)。

where $\mathrm{PA}_j \subseteq \{X_1, \ldots, X_d\} \setminus \{X_j\}$ *are called* ***parents of*** X_j*; and a joint distribution* $P_{\mathbf{N}} = P_{N_1,\ldots,N_d}$ *over the noise variables, which we require to be jointly independent; that is,* $P_{\mathbf{N}}$ *is a product distribution.*

The graph $\mathcal{G}$ *of an SCM is obtained by creating one vertex for each* X_j *and drawing directed edges from each parent in* PA_j *to* X_j*, that is, from each variable* X_k *occurring on the right-hand side of equation* (6.1) *to* X_j *(see Figure 6.1). We henceforth assume this graph to be acyclic.*

We sometimes call the elements of PA_j *not only parents but also* ***direct causes*** *of* X_j*, and we call* X_j *a* ***direct effect*** *of each of its direct causes. SCMs are also called (nonlinear) SEMs.*

尽管部分术语具有因果性（“直接原因”和“直接效应”），但定义6.2纯粹是数学的。我们在第6.8节讨论它作为真实系统模型的作用。

SCM 是形式化因果推理与因果学习的关键。我们首先证明，SCM 蕴含观测分布。但与常规的概率模型不同，它们还额外蕴含干预分布（第 6.3 节）和反事实（第 6.4 节）；参见图 6.2。

命题 6.3（蕴含分布）*An SCM* $\mathfrak{C}$ *defines a unique distribution over the variables* $\mathrm{X} = (X_1, \ldots, X_d)$ *such that* $X_j = f_j(\mathrm{PA}_j, N_j)$*, in distribution, for* $j = 1, \ldots, d$*. We refer to it as the entailed distribution* $P_{\mathbf{X}}^{\mathfrak{C}}$ *and sometimes write* $P_{\mathbf{X}}$*.*

证明可在附录 C.2 中找到。它将我们如何从联合分布中采样 n 个数据点的过程形式化（“祖先采样”）：我们首先生成一个 i.i.d. 样本 $\mathrm{N}^1, \ldots, \mathrm{N}^n \sim P_{\mathbf{N}}$，然后随后使用结构

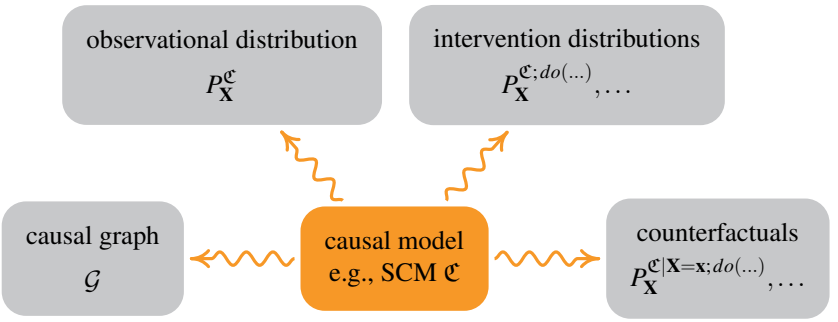

图 6.2：作为 SCM 的因果模型不仅对观测分布 P (命题 6.3) 进行建模，还对干预分布（第 6.3 节）和反事实（第 6.4 节）进行建模。

赋值（从源节点开始，接着是至多有一个父节点的节点，依此类推）用于生成独立同分布的数据点 $\mathbf{X}^1,\ldots,\mathbf{X}^n \sim P_{\mathbf{X}}$。结构赋值（6.1）应被视为一组赋值或函数（而非一组数学方程），它表明某些变量如何决定其他变量。这就是为什么我们倾向于避免使用“结构方程”这一术语的原因，该术语在文献中被广泛使用。

代码片段 6.4 以下代码从图 6.1 所示形式的 SCM 中生成一个 i.i.d. 样本：结构赋值 $f_1(x_3,n) = 2x_3 + n$、$f_2(x_1,n) = (0.5x_1)^2 + n$、$f_3(n) = n$ 和 $f_4(x_2,x_3,n) = x_2 + 2\sin(x_3 + n)$，以及分别服从正态、卡方、均匀和正态分布的联合独立噪声变量。

```
# generate a sample from the distribution entailed by the SCM
set.seed(1)
X3 <- runif(100)-0.5
X1 <- 2*X3 + rnorm(100)
X2 <- (0.5*X1)^2 + rnorm(100)^2
X4 <- X2 + 2*sin(X3 + rnorm(100))
```

备注 6.5（线性循环赋值）在本书中，我们主要关注无环结构。现在我们简要讨论具有导致循环结构的赋值的线性 SCM；这些内容已被充分理解 [Laur itzen and Richardson, 2002, Lacerda et al., 2008, Hyttinen et al., 2012]。我们侧重于直觉，不提供正式处理。线性情况的更多细节由 Hyttinen et al. [2012] 提供，非线性情况由 Mooij et al. [2011] 和 Bongers et al. [2016] 讨论。

记 $\mathbf{X} = (X_1, \ldots, X_d)$，并考虑赋值

$$\mathbf{X} := B\mathbf{X} + \mathbf{N},$$

具有 $d \times d$ 矩阵 B，其允许循环结构以及某个噪声向量 $\mathbf{N} = (N_1, \ldots, N_d) \sim P_{\mathbf{N}}$。形式上，若 $I - B$ 是可逆的，对于每个 N 的值，前述方程诱导出 X 的唯一解，即

$$\mathbf{X} = (I - B)^{-1}\mathbf{N} \tag{6.2}$$

(参见问题 3.8)。式（6.2）明确地定义了 X 上的联合分布。但它的（因果）解释是什么?

一种可能性是将其解释为平衡过程的结果。考虑随机变量序列 $\mathbf{X}^t$，它们作为迭代的解出现

$$\mathbf{X}^t := B\mathbf{X}^{t-1} + \mathbf{N},\ t = 1, 2, \ldots. \tag{6.3}$$

序列 $\mathbf{X}^t$ 收敛，若 $B^t \to 0$ 当 $t \to \infty$ 时，这等价于 B 的特征值位于单位圆内。这比 $I - B$ (的可逆性严格更强，参见问题 6.60)。若满足，则极限分布与由式 (6.2) 诱导的分布完全相同；参见问题 6.61。

在 (6.3) 中，我们在每个时间步中添加了相同的噪声实现。若改为在每一步中更新噪声，则 $\mathbf{X}^t$ 的极限分布会发生变化：

$$\mathbf{X}^t := B\mathbf{X}^{t-1} + \mathbf{N}^{t-1},\ t = 1, 2, \ldots \tag{6.4}$$

其中 $\mathbf{N}^1$,、$\mathbf{N}^2, \ldots$ 是 $\mathbf{N}^t$ 的独立同分布副本。这可视为时间序列设定，并将在第 10.2 节讨论。 □

命题6.3表明，每个SCM都蕴含一个分布。反方向如何？任意分布是否都由SCM蕴含？事实上，我们稍后将看到（命题7.1），每个分布都可以由图结构为完全DAG的任意SCM诱导（若任意一对顶点之间都有边，则称DAG为完全的）。这意味着SCM的（观测）模型类，即可以由SCM诱导的分布集合，是*all*分布的集合。

SCM 的定义允许存在这样的可能性：一个变量出现在结构赋值的右侧，而不影响左侧的变量。尽管这种父子关系在某种意义上是“无效的”，它仍然作为一条边出现在对应的图中。形式上，我们通过以下备注将其排除：

Remark 6.6（SCMs 的结构极小性）定义 6.2 可以被理解为区分这两个 SCMs

$$\begin{aligned}\mathbf{S}_1 &: X := N_X,\ Y := 0 \cdot X + N_Y \quad \text{and}\\ \mathbf{S}_2 &: X := N_X,\ Y := N_Y,\end{aligned}$$

尽管明显 $0 \cdot X = 0$。这与我们的直觉相矛盾。因此，我们添加了要求，即函数 f_j 依赖于其所有输入参数。从数学上讲，每当存在 $k \in \{1,\dots,d\}$ 和函数 g 使得

$$f_k(\mathbf{pa}_k, n_k) = g(\mathbf{pa}_k^*, n_k), \qquad \forall \mathbf{pa}_k, \forall n_k \text{ with } p(n_k) > 0, \tag{6.5}$$

当 $\mathrm{PA}_k^* \subsetneq \mathrm{PA}_k$ 时，我们选择后者的表示。在前面的例子中，因此我们会选择表示 S_2 而非 S_1。我们稍后将看到，这两个 SCM 确实可以被识别，因为它们蕴含相同的观测分布、干预分布、[2] 和反事实（见第 6.8 节）。

此外，存在唯一的表示，其中每个函数的输入数量最少。尽管这一陈述看起来合理，我们在附录 C.3 中正式证明了它。我们称这样的（最小）SCM 满足结构最小性。[3] 从现在起，我们假设结构最小性成立。例如，与忠实性（第 6.5 节）不同，这不是关于底层世界的假设，而是一种避免冗余描述的约定。

□

Remark 6.7（与常微分方程的关系）在 Remark 6.5 中，我们已经看到了 SCM 与离散时间模型之间的关系，现在想对连续时间模型做一些评论。在物理系统中，我们通常期望因果关系由一组耦合的微分方程支配。微分方程系统 $\dot{\mathrm{X}} = f(\mathrm{X})$ 可以近似表示为赋值 $\mathrm{X}_{t+\Delta t} := \mathrm{X}_t + \Delta t \cdot f(\mathrm{X}_t)$，其中 $\Delta t >$ 很小，因此它包含了细粒度时间尺度下的因果结构信息。干预可以物理上实现为一个强制项，将变量拉向期望值。在某些稳定性假设下，我们可以通过分析平衡状态的行为，以与时间无关的方式评估干预的效果。这意味着需要一个 SCM 来描述平衡状态如何

[2] We do not allow for interventions that keep the function in the structural assignment fixed and change only the noise distribution; see (6.5).

[3] This term does not coincide with causal minimality (Definition 6.33). Causal minimality implies structural minimality (Proposition 6.49) but not vice versa; see Problem 6.57.

此类动力系统对可观测量的物理干预的反应 [Mooij et al., 2013]。在 SCM 中，变量不再描述特定时间点的测量。在这一现象学层面上，原有的时间结构消失了。该框架原则上也适用于循环结构，但尚未处理随机情况；该理论仅限于确定性关系。这一缺陷意义重大，因为不确定性可能源于多种因素，包括对微分方程参数或初始条件的不完全了解，以及——一如既往——混杂。我们不会进一步讨论从微分方程推导现象学结构方程的细节，而是参考一些文献 [参见，例如，Dash, 2005, Hansen and Sokol, 2014]。

我们做此说明的主要动机是避免一种常见的误解。有人认为，通过精确指定变量所指的时间，因果推断任务的一部分就会过时。这种观点在物理学中得到了特别的支持，因为在物理学中，通常每次测量都可以唯一地对应到它被执行的时空点。然而，这些论点表明，即使是物理学中的变量也并不总是指在时间上定义良好的观测——例如，因为它们源于平衡情境。

□

6.3 干预措施

我们现在准备对系统中的干预进行建模。直观地说，当我们对变量 X_2 进行干预，例如将其设为硬币翻转的二元结果时，我们期望这种干预会改变系统的分布，与之前未干预时的行为相比。此外，即使变量 X_2 之前受其他变量的因果影响，现在它也只受硬币翻转的影响：其因果父节点已发生改变。

形式上，我们从 SCM $\mathfrak{C}$ 构造干预分布。它们通过对 $\mathfrak{C}$ 进行修改并考虑新的蕴含分布而获得。一般来说，干预分布与观测分布不同。

定义 6.8（干预分布）*Consider an SCM* $\mathfrak{C} := (\mathrm{S}, P_{\mathbf{N}})$ *and its entailed distribution* $P^{\mathfrak{C}}_{\mathbf{X}}$*. We replace one (or several) of the structural assignments to obtain a new SCM* $\tilde{\mathfrak{C}}$*. Assume that we replace the assignment for* X_k *by*

$$X_k := \tilde{f}(\widetilde{\mathbf{PA}}_k, \tilde{N}_k).$$

We then call the entailed distribution of the new SCM an intervention distribution

and say that the variables whose structural assignment we have replaced have been ***intervened*** *on. We denote the new distribution by*[4]

$$P_{\mathbf{X}}^{\tilde{\mathfrak{C}}} =: P_{\mathbf{X}}^{\mathfrak{C};do\left(X_k:=\tilde{f}(\widetilde{\mathbf{PA}}_k,\tilde{N}_k)\right)}.$$

The set of noise variables in $\tilde{\mathfrak{C}}$ *now contains both some "new"* $\tilde{N}$*'s and some "old" N's, all of which are required to be jointly independent.*

When $\tilde{f}(\widetilde{\mathrm{PA}}_k,\tilde{N}_k)$ *puts a point mass on a real value a, we simply write* $P_{\mathbf{X}}^{\mathfrak{C};do(X_k:=a)}$ *and call this an* ***atomic*** *intervention.*[5] *An intervention with* $\widetilde{\mathrm{PA}}_k = \mathrm{PA}_k$*, that is, where direct causes remain direct causes, is called* ***imperfect****.*[6] *This is a special case of a* ***stochastic*** *intervention [Korb et al., 2004], in which the marginal distribution of the intervened variable has positive variance.*

We require that the new SCM $\tilde{\mathfrak{C}}$ *have an acyclic graph; the set of allowed interventions thus depends on the graph induced by* $\mathfrak{C}$*.*

代码片段 6.9 以下代码从干预分布中采样。我们考虑代码片段 6.4 中的 SCM $\mathfrak{C}$ 并执行干预 $do(X_2 := 3)$；即，我们从分布 $P_{\mathbf{X}}^{\mathfrak{C};do(X_2:=3)}$ 生成一个 i.i.d. 样本。

```
# generate a sample from the intervention distribution
set.seed(1)
X3 <- runif(100)-0.5
X1 <- 2*X3 + rnorm(100)
# old:
# X2 <- (0.5*X1)^2 + rnorm(100)^2
X2 <- rep(3,100)
X4 <- X2 + 2*sin(X3 + rnorm(100))
```

事实表明，干预的概念是建模分布差异并理解因果关系的强大工具。我们试图通过一些例子来说明这一点。

[4] Although the set of parents can change arbitrarily as long as they are not introducing cycles, we mainly consider interventions, for which the new set of parents $\widetilde{\mathbf{PA}}_k$ is either empty or equals $\mathbf{PA}_k$.

[5] This is also referred to as an **ideal**, **structural** [Eberhardt and Scheines, 2007], **surgical** [Pearl, 2009], **independent**, or **deterministic** [Korb et al., 2004] intervention.

[6] This is also referred to as a **parametric** [Eberhardt and Scheines, 2007] or **dependent** intervention [Korb et al., 2004] or simply as a **mechanism change** [Tian and Pearl, 2001]. For the term **soft** intervention, see Eberhardt and Scheines [2007] , Eaton and Murphy [2007], and Markowetz et al. [2005].

例 6.10（预测变量与干预目标）本例考虑预测问题。它表明，尽管某些变量可能是目标变量 Y 的良好预测变量，但对它们进行干预可能不会影响目标变量。考虑 SCM $\mathfrak{C}$

$$\begin{aligned} X_1 &:= N_{X_1} \\ Y &:= X_1 + N_Y \\ X_2 &:= Y + N_{X_2} \end{aligned}$$

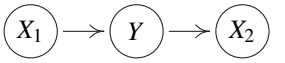

其中 $N_{X_1}, N_Y \overset{\text{iid}}{\sim} \mathcal{N}(0,1)$ 和 $N_{X_2} \sim \mathcal{N}(0, 0.1)$ 联合独立。假设我们对来自 X_1 和 X_2 的 *predicting* Y 感兴趣。显然，X_2 是 Y 的比 X_1 更好的预测器；例如，不包含 X_2 的线性模型会导致（显著）更大的均方误差，而不包含 X_1 的线性模型则不会。如果我们想要 *change* Y，然而，对 X_2 的干预是无用的：

$$P_Y^{\mathfrak{C};do\left(X_2:=\tilde{N}\right)} = P_Y^{\mathfrak{C}} \quad \text{for all variables } \tilde{N};$$

换句话说，无论我们对 X_2 进行多强烈的干预，Y 的分布都保持不变。然而，对 X_1 的干预确实会改变 Y 的分布：

$$P_Y^{\mathfrak{C};do\left(X_1:=\tilde{N}\right)} = \mathcal{N}\left(\mathbb{E}[N_Y] + \mathbb{E}[\tilde{N}], \operatorname{var}[N_Y] + \operatorname{var}[\tilde{N}]\right) \neq P_Y^{\mathfrak{C}}$$

如果 $P_{\tilde{N}} \neq P_{N_{X_1}}$。 □

这个例子还可以用来说明，干预通常与条件化不同：

$$p_Y^{\mathfrak{C};do(X_2:=x)}(y) \;=\; p_Y^{\mathfrak{C}}(y) \;\neq\; p_Y^{\mathfrak{C}}(y|X_2 = x).$$

示例 6.11（近视）以下案例研究是众多例子之一，其中统计依赖被误解为直接的因果关系。当缺乏背景知识时，人类似乎特别容易做出这种错误的因果结论。一项研究发现，儿童房间使用夜灯与近视的发生之间存在依赖关系 [Quinn et al., 1999, 第 113 页]。尽管作者谨慎地指出该研究“并未建立因果联系”，但他们补充说，“这种关联的统计强度……确实表明，幼儿时期缺乏每日黑暗时段可能是近视发展的潜在诱发因素”。基于这些发现，一项专利被申请 [Peterson, 2005]。它

这表明，如果我们对变量 *night light* 进行干预，这将改变发展近视的概率。

随后，Gwiazda et al. [2000] 和 Zadnik et al. [2000] 发现，这种相关性是由于孩子的父母是否患有近视所致。他们认为，近视父母更可能在孩子的房间里放置夜灯，同时孩子继承该病症的风险也增加。因此，假设底层（“正确”）的 SCM 具有以下形式

$$\mathbf{S}: \quad \begin{aligned} PM &:= N_{PM} \\ NL &:= f(PM, N_{NL}) \\ CM &:= g(PM, N_{CM}) \end{aligned}$$

其中 PM 代表父母近视，NL 代表夜间灯光，CM 代表儿童近视。对应的图是

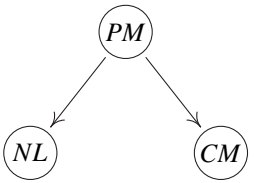

在他们的论文中，Quinn 等人 [1999] 发现 $NL \not\perp\!\!\!\perp CM$，这与模型一致（假设忠实性——见定义 6.33）。现在我们将 NL 的结构赋值替换为 $NL := \tilde{N}_{NL}$，其中 $\tilde{N}_{NL}$ 可以以相等的概率随机分配三种夜间光照条件之一（“黑暗”、“夜灯”、“室内灯光”）。在相应的干预分布中

$$P_{NL,CM}^{\mathfrak{C};do\left(NL:=\tilde{N}_{NL}\right)},$$

我们将发现 $NL \perp\!\!\!\perp CM$，因为 $CM := g(N_{PM}, N_{CM})$。这与 $\tilde{N}_{NL}$ 的分布无关。我们说从 NL 到 CM 没有因果效应。 □

受例6.11最后一句话的启发，我们定义总因果效应的存在[cf. Pearl, 2009, “total causal effect”]。

定义 6.12（总因果效应）*Given an SCM $\mathfrak{C}$, there is a total causal effect from X to Y if and only if*

$$X \not\perp\!\!\!\perp Y \quad \text{in } P_{\mathbf{X}}^{\mathfrak{C};do\left(X:=\tilde{N}_X\right)}$$

for some random variable $\tilde{N}_X$.

除了定义6.12中的概念外，还有其他直观描述总因果效应存在的概念。然而，事实表明，人们可能想到的大多数陈述都是等价的。以下命题在附录C.4中得到证明。

命题 6.13（总因果效应）*Given an SCM $\mathfrak{C}$, the following statements are equivalent:*

(i) There is a total causal effect from X to Y.

(ii) There are $x^{\triangle}$ and $x^{\square}$ such that $P_Y^{\mathfrak{C};do(X:=x^{\triangle})} \neq P_Y^{\mathfrak{C};do(X:=x^{\square})}$.

(iii) There is $x^{\triangle}$ such that $P_Y^{\mathfrak{C};do(X:=x^{\triangle})} \neq P_Y^{\mathfrak{C}}$.

(iv) $X \not\perp\!\!\!\perp Y$ in $P_{X,Y}^{\mathfrak{C};do(X:=\tilde{N}_X)}$ for any $\tilde{N}_X$ whose distribution has full support.

毫不意外，总因果效应的存在与相应图中有向路径的存在相关。然而，这种对应并非一一对应。虽然有向路径是总因果效应的必要条件，但它并不充分。

命题 6.14（总因果效应的图形判据）*Assume we are given an SCM $\mathfrak{C}$ with corresponding graph $\mathcal{G}$.*

(i) If there is no directed path from X to Y, then there is no total causal effect.

(ii) Sometimes there is a directed path but no total causal effect.

证明可在附录 C.5 中找到。

示例 6.15（随机试验）因果效应的定义在随机试验中得以实现。在这些研究中，研究者根据$\tilde{N}_T$ 随机将治疗 T 分配给患者，并例如观察（二元）恢复变量 R。假设 T 取三个可能值（$T=0$：无药物，$T=1$：安慰剂，$T=2$：感兴趣的药物），且$\tilde{N}_T$ 随机选择这三种可能性之一：$P(\tilde{N}_T=0)=P(\tilde{N}_T=1)=P(\tilde{N}_T=2)=1/3$。在 SCM 中，这种随机化通过观察来自该分布的数据来建模

$$P_{\mathbf{X}}^{\mathfrak{C};do(T:=\tilde{N}_T)}.$$

(这里，$\mathfrak{C}$ 表示未进行随机化的原始 SCM。) 如果我们仍然发现治疗与恢复之间存在依赖关系，我们得出结论，T 具有总

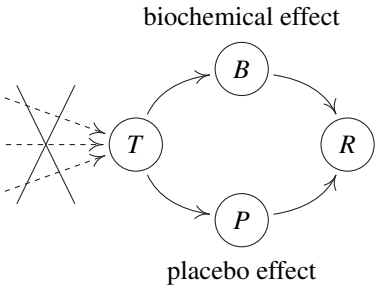

图 6.3：随机研究的简化描述。T 表示治疗，P 和 B 表示患者的心理状态和某些生化状态，R 表示患者是否恢复。对 T 的随机化消除了任何其他变量对 T 的影响，因此 T 和 R 之间不可能存在隐藏的共同原因。我们区分两种不同的效应：通过 P 的安慰剂效应和通过 B 的生化效应。

对恢复的因果效应。然而，可能存在与药物类型无关的总因果效应。简化描述见图6.3。患者的心理状态（P）在服用药丸时发生变化，且与药丸内容无关，随后影响恢复。假设安慰剂效应对安慰剂和所关注的药物是相同的。即，P 的结构赋值满足

$$f_P(T=0,N_P) \neq f_P(T=1,N_P) = f_P(T=2,N_P).$$

在制药研究中，我们更关注生化效应而非安慰剂效应。因此，我们将随机化限制在安慰剂和目标药物上，即 $P(\tilde{N}_T = 0) = 0$。如果我们仍然观察到治疗 T 与恢复 R 之间存在依赖关系，这必定是由生化效应引起的。

利用随机试验进行因果学习的思想（使用不同的数学语言）由 Peirce [1883] 和 Peirce 与 Jastrow [1885] 描述，后来由 Neyman [参见 Splawa-Neyman et al., 1990，原文的翻译与编辑版本] 和 Fisher [1925] 描述。大部分这项工作涉及农业应用。

随机试验的早期例子由 James Lind 完成。在18世纪，英国士兵死于坏血病的人数多于死于敌军行动的人数；维生素C及其与坏血病的关系当时仍然未知。这位苏格兰医生 James Lind（1716–1794）在船上担任外科医生，并如下报告了该试验[引自 Bhatt, 2010]：

> 1747年5月20日，我在海上萨利斯伯里号船上选出了十二名患坏血病的病人。他们的病情尽可能相似，我所能做到的那样。

> 拥有它们。它们普遍都有腐烂的牙龈、斑点和倦怠，以及膝盖无力……两人被每人每日开出一夸脱苹果酒。另两人每日三次服用二十五滴硫酸酊……另两人每日三次服用两匙醋……最严重的两名患者被安排服用海水疗法……另两人每日各给两个橙子和一个柠檬……剩下的两名患者服用了……一位医院外科医生推荐的糖膏……结果是，使用橙子和柠檬产生了最迅速且明显的良好效果；其中一名服用者在六天后已能胜任工作。

读者会注意到该试验并非完全随机化，但历史上的好奇心弥补了这一不足。 □

例 6.16（肾结石）表 6.1 展示了肾结石恢复的一个著名数据集 [Charig et al., 1986]。在 700 名患者中，一半接受开放手术（治疗 $T = a$，恢复率 78%），另一半接受经皮肾镜取石术（$T = b$，恢复率 83%），这是一种通过小穿刺伤口去除肾结石的手术方法。如果除了总体恢复率外我们一无所知，并且忽略副作用，例如，许多人在必须做出决定时会更倾向于治疗 b。进一步观察数据，我们可以将肾结石分为小结石和大结石。我们发现开放手术在两个类别中都表现更好。我们如何处理这种结论的反转?

我们首先给出直观解释。大结石比小结石更严重（见表6.1），而治疗a必须处理更多这类困难病例（尽管分配到a和b的患者总数相同）。这就是为什么治疗a在整个群体上看起来比b差，但在两个亚组中都更好。分配的不平衡可能例如源于：医生期望治疗a比治疗b更好，因此以更高概率将困难病例分配给治疗a。

作为另一种观点，我们建议使用干预的语言来精确表述我们感兴趣的问题。这并不是问在这项特定研究中治疗 $T = a$ 还是治疗 $T = b$ 更成功，而是问当我们强制所有患者分别接受治疗 a 或治疗 b 时，这些治疗如何比较，或者当每位患者被随机分配到其中一种治疗时，我们比较恢复率。这三种情况涉及的干预分布与观察分布 $P_{\mathbf{X}}$ 不同。在

	Overall	Patients with small stones	Patients with large stones
Treatment a: Open surgery	78% (273/350)	**93%** (81/87)	**73%** (192/263)
Treatment b: Percutaneous nephrolithotomy	**83%** (289/350)	87% (234/270)	69% (55/80)

表 6.1：辛普森悖论的经典示例。该表报告了两种肾结石治疗方法的成功率 [Bottou et al., 2013, Charig et al., 1986, tables I and II]。尽管治疗 b 的总体成功率看起来更好（任何粗体数字在其列中都是最大的），但治疗 b 在小肾结石患者和大肾结石患者上的表现都比治疗 a 差（见示例 6.37 和第 9.2 节）。

特别是，它们对应于 $P^{\mathfrak{C};do(T:=a)}$、$P^{\mathfrak{C};do(T:=b)}$ 或 $P^{\mathfrak{C};do\left(T:=\tilde{N}_T\right)}$。我们将在示例 6.37 中计算这些干预分布，并将看到为什么我们应优先选择治疗 a 而非治疗 b。该数据集是辛普森悖论 [Simpson, 1951]（第 9.2 节）的著名例子。事实上，它远非悖论，而是混杂影响的结果，即一个隐藏的共同原因。

如果你对数据进行显著性检验（例如，使用比例检验或χ^2独立性检验），则发现方法之间的差异在5%显著性水平下并不显著。然而，这并非本示例的重点。若将表6.1中的每个条目乘以10，结果将具有统计显著性。此外，我们关注恢复R，并忽略可能影响我们治疗决策的副作用。

□

干预变量 我们现在描述一种形式化干预的替代方法；例如，参见 Dawid [2015] 或 Pearl [2009, 第 3.2.2 章]。人们将 SCM $\mathfrak{C}$ 及其 DAG 扩展为无父节点 $I_1, I_2, \ldots, I_d$，称为“干预变量”，分别指向 $X_1, \ldots, X_d$。为简单起见，我们在此仅讨论对单个节点的干预。每个 I_j 取值为 `idle` 或 X_j 可取的可能值 x_j 之一。于是 $I_j = x_j$ 表示 X_j 被设置为值 x_j，而 $I_j = \texttt{idle}$ 表示 X_j 未被干预。因此，人们将结构赋值替换为

$$X_j := f_j(\mathbf{PA}_j, N_j)$$

使用

$$X_j := \begin{cases} f_j(\mathbf{PA}_j, N_j) & \text{if } I_j = \texttt{idle} \\ I_j & \text{otherwise} \end{cases}$$

并为 $I_1,\dots,I_d$ 添加赋值，所有这些都仅由噪声变量决定。在为 I_j 的所有可能值分配非零概率（或概率密度）后，由原始 SCM $\mathfrak{C}$ 蕴含的干预概率在扩展 SCM $\mathfrak{C}^*$ 中转变为通常的条件概率：

$$P_Y^{\mathfrak{C};do\left(X_j:=x_j\right)} = P_{Y\,|\,I_j=x_j}^{\mathfrak{C}^*},$$

参见 Remark 6.40。此外，关于干预某个变量是否改变特定目标变量分布的陈述转化为一个常规的统计独立性陈述。

6.4 反事实

反事实的定义和解释在文献中受到了广泛关注。它们涉及以下情境：假设你正在玩扑克牌，起手牌是♣J和♣3（有时称为“lumberjack”——树和J）；你停止游戏（“弃牌”），因为你估计获胜概率太小，不想再输更多钱。三张牌面朝上发到桌面（“翻牌”）。它们是♣4、♣Q和♣2。反应是一个典型的反事实陈述：“如果我当时继续玩，我的机会会很好。”（同花色的五张牌是第五高的牌型，称为“同花”；甚至还有机会获得“同花顺”，这是第二高的牌型。）该陈述将观测数据（手牌和翻牌）纳入模型，然后分析干预分布（继续游戏），其中环境的其余部分保持不变（相同的牌）。形式上，这对应于更新SCM的噪声分布（通过条件化）然后执行干预。

定义 6.17（反事实）*Consider an SCM* $\mathfrak{C}:=(\mathrm{S},P_{\mathbf{N}})$ *over nodes* X . *Given some observations* x*, we define a* 反事实 SCM *by replacing the distribution of noise variables:*

$$\mathfrak{C}_{\mathbf{X}=\mathbf{x}} := \left(\mathbf{S}, P_{\mathbf{N}}^{\mathfrak{C}|\mathbf{X}=\mathbf{x}}\right),$$

where $P^{\mathfrak{C}|\mathrm{X}=\mathrm{x}}\,\mathrm{N}:$
$= P_{\mathbf{N}|\mathbf{X}=\mathbf{x}}$.[7] *The new set of noise variables need not be jointly independent anymore. Counterfactual statements can now be seen as do-statements in the new counterfactual SCM.*

7在连续的 c ase, this definition comes with measure theoretic problems since usu盟友

该定义可以推广，使得我们观察到的不是完整向量 $\mathbf{X} = \mathbf{x}$，而仅是其中的一些变量。

例 6.18（计算反事实）考虑以下 SCM：

$$\begin{aligned} X &:= N_X \\ Y &:= X^2 + N_Y \\ Z &:= 2 \cdot Y + X + N_Z \end{aligned}$$

其中 $N_X, N_Y, N_Z \overset{\text{iid}}{\sim} \mathrm{U}(\{-5, -4, \ldots, 4, 5\})$ 在 -5 与 5 之间的整数上均匀分布。现在，假设我们观测到 $(X, Y, Z) = (1, 2, 4)$。那么 $P_{\mathbf{N}}^{\mathfrak{C}|\mathbf{X}=\mathbf{x}}$ 在 $(N_X, N_Y, N_Z) = (1, 1, -1)$ 上放置点质量，因为在此所有噪声项均可由观测唯一重构。因此，我们得到反事实陈述（在 $(X, Y, Z) = (1, 2, 4)$ 的语境下）：“Z 本应为 11，若 X 为 2。”在本书中，这样的句子被解释为：“Z 本应为 11，若 X 为 *set to* 2。”数学上，这意味着 $P_Z^{\mathfrak{C}|\mathbf{X}=\mathbf{x};do(X:=2)}$ 在 11 上具有点质量。同样地，我们得到“Y 本应为 5，若 X 为 2”，以及“Z 本应为 10，若 Y 为 5。”

□

由于反事实的构造涉及多个步骤，其记法看起来相当复杂。[8] 我们希望下图能提供进一步的说明。

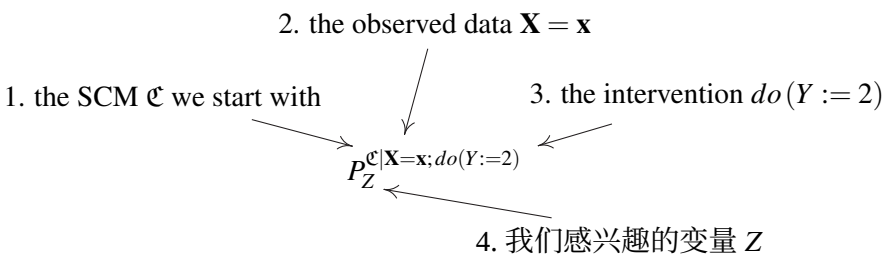

conditional distribution is only defined up to null sets. To make our life easier, we restrict counterfactuals to the discrete case, that is, when the noise distribution has a probability mass function. In the case of continuous variables with density, we condition not on $\mathbf{X} = \mathbf{x}$ but on $\mathbf{X} \in A$ with $P(\mathbf{X} \in A) > 0$ instead.

[8] Pearl [2009] uses the somewhat simpler notation $Z_y(\mathbf{u})$, where the subscript y denotes the intervention $do(Y := y)$ and $\mathbf{u}$ represents the additional information about the error terms, which he calls $\mathbf{u}$, that may be implied by $\mathbf{X} = \mathbf{x}$, for example.

反事实陈述强烈依赖于 SCM 的结构。例 6.19 展示了两个 SCM，它们诱导出相同的图、观测分布和干预分布，但蕴含不同的反事实陈述。稍后，我们将称这些 SCM 为“概率与干预等价”，但不是“反事实等价”（见定义 6.47）。

示例 6.19 设 $N_1, N_2 \sim \text{Ber}(0.5)$，且 $N_3 \sim \text{U}(\{0,1,2\})$，使得三个变量联合独立。即，$N_1, N_2$ 服从参数为 0.5 的伯努利分布，且 N_3 在 $\{0,1,2\}$ 上均匀分布。我们定义两个不同的 SCM。首先考虑 $\mathfrak{C}_A$：

$$
\begin{aligned}
X_1 &:= N_1 \\
X_2 &:= N_2 \\
X_3 &:= (1_{N_3>0} \cdot X_1 + 1_{N_3=0} \cdot X_2) \cdot 1_{X_1 \neq X_2} + N_3 \cdot 1_{X_1 = X_2}.
\end{aligned}
$$

如果 X_1 和 X_2 的值不同，则根据 N_3 选择 $X_3 = X_1$ 或 $X_3 = X_2$。否则为 $X_3 = N_3$。现在，$\mathfrak{C}_B$ 仅在后一种情况下与 $\mathfrak{C}_A$ 不同：

$$
\begin{aligned}
X_1 &:= N_1 \\
X_2 &:= N_2 \\
X_3 &:= (1_{N_3>0} \cdot X_1 + 1_{N_3=0} \cdot X_2) \cdot 1_{X_1 \neq X_2} + (2 - N_3) \cdot 1_{X_1 = X_2}.
\end{aligned}
$$

两个SCM蕴含相同的观测分布；并且对于任何可能的干预，它们也蕴含相同的干预分布。[9] 但是这两个模型在反事实陈述上存在差异。假设，我们已经做了一个观测 $(X_1, X_2, X_3) = (1,0,0)$，并且我们对反事实问题“如果$X_1$为0，$X_3$会是什么？”感兴趣。从两个SCM中可以得出$N_3 =$为0，因此这两个SCM $\mathfrak{C}_A$ 和 $\mathfrak{C}_B$ 在X_1 (的反事实变化下对X_3“预测”不同的值，即分别为0和2)。 □

前述示例的含义有两方面：(1) 两个SCM对应同一个因果图模型（见第6.5.2节），从这个意义上说，因果图模型不足以预测反事实；(2) 在第6.8节中，我们将干预分布与真实世界的随机实验联系起来。

[9] In this example, the observational distribution satisfies causal minimality with respect to the underlying graph (here $X_1 \to X_3 \leftarrow X_2$); see Definition 6.33. Another example can be found in Section 3.4; it is less complex but violates causal minimality.

对于这个例子，我们无法使用随机试验或观察数据来区分 $\mathfrak{C}_A$ 或 $\mathfrak{C}_B$。因此，如果我们对反事实陈述感兴趣，我们需要额外假设来区分 $\mathfrak{C}_A$ 或 $\mathfrak{C}_B$。

我们现在总结反事实的一些性质。

备注 6.20 (i) 反事实陈述不具有传递性。在例 6.18 中，我们发现给定观测 $(X, Y, Z) = (1, 2, 4)$，

> “Y 本应为 5，若 X 为 2，”“Z 本应为 10，若 Y 为 5，”以及“Z 本不会为 10，若 X 为 2。”

因此，我们不能简单地引入新变量 $\tilde{X}$ 和 $\tilde{Y}$，例如，并将“Y 本应为 5，若 X 为 2”解释为形式“$\tilde{X} = 2 \Rightarrow \tilde{Y} = 5$”的逻辑蕴含。在前面的例子中，非传递性是由于从 X 到 Z 的直接链接，即存在一条从 X 到 Z 的路径，该路径不经过 Y。类似的反例对干预分布也成立。

(ii) 人类常常以反事实方式思考：“我本该坐火车。”、“你还记得我们2000年9月11日飞往纽约的航班吗？想想如果我们晚一年坐这趟航班！”或“我们本该在2014年12月投资CHF！”仅仅是几个例子。有趣的是，这有时甚至涉及我们基于当时可获得的信息做出最优决策的情境。假设有人向你提供$10,000，要求你预测抛硬币的结果；你猜“正面”并输了。之后，有些人可能会想，“为什么我没说‘反面’？”尽管他们不可能知道结果。Roese [1997]、Byrne [2007] 等人阐述了反事实思维的心理学含义。讨论反事实陈述是否包含有助于我们未来做出更好决策的信息是有趣的，但这超出了本工作的范围；另见 Pearl [2009, Chapter 4]。

(iii) 我们也不讨论反事实在法律体系中的作用；反事实是否以及如何应被作为判决依据是一个有趣的问题（见例 3.4）。

(iv) 人们对反事实的思考由来已久；它是历史学家的一种流行工具。例如，提图斯·利维乌斯在公元前25年讨论了如果亚历山大大帝没有死在亚洲并攻击罗马会发生什么 [Geradin and Girgenson, 2011]。保罗的《哥林多前书》（7:29–7:31）写道：“但我对你们说，弟兄们：时间短暂，

> 从今以后，有妻子的，要像没有妻子一样；/ 哀哭的，要像不哀哭一样；喜乐的，要像不喜乐一样；买的，要像没有一样；/ 使用这世界的，要像没有充分使用它一样。

(v) 我们可以将干预陈述视为（随机化）实验的数学构造。对于反事实陈述，现实世界中没有可比的对应关系。有人可能推测，许多反事实陈述无法被证伪，因此不应在科学探究中使用 [cf. Popper, 2002]。然而，值得注意的是，有时我们可以提出可证伪的反事实陈述（例如，当样本中相应实例的噪声项的实际值在事后变得明显时；见示例 3.4）。此外，我们上面描述的反事实是设定 SCM 的后果。因此，证伪的另一个目标也可以是 SCM 而非给定的反事实陈述。这可能可行，也可能不可行，例如，使用 SCM 所指的科学领域的方法。[10]

□

这些 remarks 可视为引发思考的内容。我们不进一步深入探讨反事实陈述的解释及其在法庭案件中应如何或可以被使用，例如。许多此类思考超出了我们的专业领域。相反，我们参考 Halpern [2016]，其讨论了某一事件是另一事件的“实际原因”意味着什么。

6.5 马尔可夫性质、忠实性与因果最小性

6.5.1 马尔可夫性质

马尔可夫性质是一种常用假设，构成了图模型的基础。当分布相对于图具有马尔可夫性时，该图编码了分布中的某些独立性，我们可利用这些独立性实现高效计算或数据存储。马尔可夫性质适用于有向图和无向图，且这两类图编码了不同的独立性集合。

10注意， freedom of reparametrization, as described in Section 3.4, always r电子邮件。

[Koller and Friedman, 2009]。然而，在因果推断中，我们主要关注有向图。许多因果推断的入门介绍都从假设马尔可夫性质开始。相反，在本书中，我们假设存在一个底层的 SCM。我们将在命题 6.31 中看到，这足以证明马尔可夫性质。但首先，让我们定义它。

定义 6.21（马尔可夫性质）*Given a DAG $\mathcal{G}$ and a joint distribution $P_{\mathbf{X}}$, this distribution is said to satisfy*

*(i) the **global Markov property** with respect to the DAG $\mathcal{G}$ if*

$$\mathbf{A} \perp\!\!\!\perp_{\mathcal{G}} \mathbf{B} \,|\, \mathbf{C} \;\Rightarrow\; \mathbf{A} \perp\!\!\!\perp \mathbf{B} \,|\, \mathbf{C}$$

for all disjoint vertex sets A, B, C
(the symbol $\perp\!\!\!\perp_{\mathcal{G}}$ denotes d-separation — see Definition 6.1),

*(ii) the **local Markov property** with respect to the DAG $\mathcal{G}$ if each variable is independent of its non-descendants given its parents, and*

*(iii) the **Markov factorization property** with respect to the DAG $\mathcal{G}$ if*

$$p(\mathrm{x}) = p(x1, \ldots, x_d) = \prod_{j=1}^{d} p(x_j \,|\, 段落_j^{\mathcal{G}}).$$

*For this last property, we have to assume that P_{X} has a density p; the factors in the product are referred to as **causal Markov kernels** describing the conditional distributions $P_{X_j|\mathrm{PA}_j^{\mathcal{G}}}$.*

事实表明，只要联合分布具有密度，[11] 这三个定义是等价的。

定理 6.22（马尔可夫性质的等价性）*If $P_{\mathbf{X}}$ has a density p, then all Markov properties in Definition 6.21 are equivalent.*

例如，该证明可在 Lauritzen [1996] 的定理 3.27 中找到。

例 6.23 如果根据 (i) 或 (ii)，分布 P_{X_1,X_2,X_3,X_4} 关于第 84 页图 6.1 所示的图 $\mathcal{G}$ 是马尔可夫的，

$$X_2 \perp\!\!\!\perp X_3 \,|\, X_1 \quad \text{and} \quad X_1 \perp\!\!\!\perp X_4 \,|\, X_2, X_3,$$

[11] In this book, we always consider densities with respect to a product m度量。

或根据（iii），

$$p(x_1,x_2,x_3,x_4) = p(x_3)p(x_1\,|\,x_3)p(x_2\,|\,x_1)p(x_4\,|\,x_2,x_3).$$

我们将在后文的命题 6.31 中看到，由 SCM 蕴含的分布对该 SCM 的图是马尔可夫的。因此，这些条件确实满足由 SCM 蕴含的分布 P_{X_1,X_2,X_3,X_4}，如图 6.1 左所示。直观上，$X_2 \perp\!\!\!\perp X_3\,|\,X_1$ 是合理的。考虑路径 $X_2 \leftarrow X_1 \leftarrow X_3$，如果我们已经知道 X_1，则 X_3 不会提供关于 X_2 的任何新信息。在这个意义上，SCM 的图结构在联合分布中留下了一些“痕迹”。

□

马尔可夫条件将图分离的陈述与条件独立性联系起来。然而，不同的图可能编码完全相同的条件独立性集合。

定义 6.24（图的马尔可夫等价）*We denote by $\mathcal{M}(\mathcal{G})$ the set of distributions that are Markovian with respect to $\mathcal{G}$:*

$$\mathcal{M}(\mathcal{G}) := \{P : P \text{ satisfies the global (or local) Markov property with respect to } \mathcal{G}\}.$$

Two DAGs $\mathcal{G}_1$ and $\mathcal{G}_2$ are Markov equivalent if $\mathcal{M}(\mathcal{G}_1) = \mathcal{M}(\mathcal{G}_2)$. This is the case if and only if $\mathcal{G}_1$ and $\mathcal{G}_2$ satisfy the same set of d-separations, which means the Markov condition entails the same set of (conditional) independence conditions.

*The set of all DAGs that are Markov equivalent to some DAG is called **Markov equivalence class** of $\mathcal{G}$. It can be represented by a completed PDAG that is denoted by $CPDAG(\mathcal{G}) = (V,\mathcal{E})$; it contains the (directed) edge $(i,j) \in \mathcal{E}$ if and only if one member of the Markov equivalence class does; see Figure 6.4.*

从这个定义出发，判断两个 DAG 是否马尔可夫等价似乎是一个非平凡的问题。幸运的是，Verma 和 Pearl [1991] 提供了一个简洁的刻画，参见 Frydenberg [1990]。

引理 6.25（马尔可夫等价的图形判据）*Two DAGs $\mathcal{G}_1$ and $\mathcal{G}_2$ are Markov equivalent if and only if they have the same skeleton and the same immoralities.*

此处，DAG 中的三个节点 A、B 和 C 如果 $A \to B \leftarrow C$、A 和 C 没有直接连接，则构成一个不道德结构（immorality）或 v-结构（v-structure）（参见第 6.1 节）。

图 6.4 展示了两个马尔可夫等价图（中间和左侧）的示例。这些图共享相同的骨架，且它们都只有一个不道德结构：

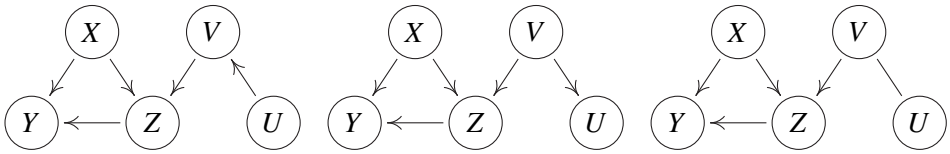

图 6.4：两个马尔可夫等价 DAG（左和中）；它们是对应马尔可夫等价类中仅有的两个可由右侧 CPDAG 表示的 DAG。

$X \to Z \leftarrow V$. 在对应的 CPDAG（见图 6.4，右）中，并非所有有向边都属于非道德结构。例如，边 $Z \to Y$ 是为了避免 v-结构 $Y \to Z \leftarrow V$ 而必需的。此外，$X \to Y$ 防止了有向循环的存在。

我们现在引入马尔可夫毯（Markov blanket）的图形概念 [Pearl, 1988]，它在试图根据所有其他变量的观测值预测目标变量 Y 的值时变得相关。随后，人们可能会想，什么是最小的变量集合，其知识使得其余变量对预测任务无关。

定义 6.26（马尔可夫毯）*Consider a DAG* $\mathcal{G} = (\mathrm{V}, \mathcal{E})$ *and a target node* Y. *The Markov blanket of* Y *is the smallest set* M *such that*

$$Y \perp\!\!\!\perp_{\mathcal{G}} \mathbf{V} \setminus (\{Y\} \cup M) \text{ given } M.$$

若 $P_{\mathbf{X}}$ 相对于 $\mathcal{G}$ 是马尔可夫的，则

$$Y \perp\!\!\!\perp \mathbf{V} \setminus (\{Y\} \cup M) \text{ given } M.$$

换句话说，给定 M，其他变量不会提供关于 Y 的任何额外信息。在理想化的回归设定中，因此我们只需包含 M 中的变量来预测 Y。这并不意味着在有限样本设定中，其他变量无用。如果 Y 对其马尔可夫毯 M 的依赖与所给回归方法使用的先验或函数类不完全匹配，添加 M 以外的变量可能会提高对 Y 的预测。

对于 DAG，我们知道马尔可夫毯是什么样的。它不仅包含父节点，还包含子节点以及子节点的父节点 [Pearl, 1988]。

命题 6.27（马尔可夫毯）*Consider a DAG* $\mathcal{G}$ *and a target node* Y. *Then, the Markov blanket* M *of* Y *includes its parents, its children, and the parents of its children*

$$M = \mathbf{PA}_Y \cup \mathbf{CH}_Y \cup \mathbf{PA}_{\mathbf{CH}_Y}.$$

到目前为止，我们已将马尔可夫性质讨论为分布与图之间的关系。现在，我们想讨论它的一些因果含义。马尔可夫性质可用于论证赖希恩巴赫的共同原因原理（原理 1.1）。回想一下，它指出当随机变量 X 和 Y 相依时，这种依赖必须有一个“因果解释”：

(i) X（可能间接地）导致 Y，或 (ii) Y（可能间接地）导致 X，或 (iii) 存在一个（可能未观测到的）共同原因 Z，其（可能间接地）同时导致 X 和 Y。

这里，我们没有进一步明确“causing”一词的含义。下述命题就“causing”的弱概念（即存在有向路径）而言，证明了Reichenbach原理。

命题 6.28（Reichenbach 的共同原因原理）*Assume that any pair of variables X and Y can be embedded into a larger system in the following sense. There exists a correct SCM over the collection $\mathbf{X}$ of random variables that contains X and Y with graph $\mathcal{G}$. Then Reichenbach's common cause principle follows from the Markov property. If X and Y are (unconditionally) dependent, then there is*

(i) either a directed path from X to Y, or

(ii) from Y to X, or

(iii) there is a node Z with a directed path from Z to X and from Z to Y.

证明。根据马尔可夫性质，这种依赖意味着 $\mathcal{G}$ 包含 X 和 Y 之间的一条无阻断路径。该路径不能包含碰撞节点，否则它将被空集阻断。由于 X 和 Y 之间任何不含碰撞节点的路径必须具有 $X \to \ldots \to Y$、$X \leftarrow \ldots \leftarrow Y$ 或 $X \leftarrow \ldots \leftarrow Z \to \ldots \to Y$ 的形式，结论得证。□

Remark 6.29（选择偏差）在 Reichenbach 原理中，我们从两个相依的随机变量出发，得到一个有效的结论。然而在实际应用中，我们可能隐式地以第三个变量为条件（选择偏差）。如例 6.30 所示，这可能导致 X 与 Y 之间产生依赖，尽管三个条件都不成立（参见第 1.3 节最后一段的讨论）。

□

示例 6.30（Berkson 悖论）以下示例“为什么帅哥都是混蛋？”取自 Ellenberg [2014]，是 Berkson 悖论 [Berkson, 1946] 的一个实例。假设男性是否处于关系中

($R=1$) 仅由他们是否帅气（$H=1$）和是否友好（$F=1$）决定。更准确地说，假设正确的 SCM 具有以下形式：

$$\begin{aligned} H &:= N_H, \\ F &:= N_F, \\ R &:= \min(H,F) \oplus N_R, \end{aligned}$$

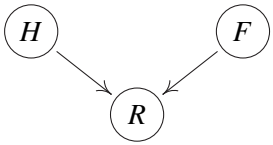

其中 $N_H, N_F \overset{\text{iid}}{\sim} \text{Ber}(0.5)$ 且 $N_R \sim \text{Ber}(0.1)$。符号 $\oplus$ 表示模 2 加法。在此模型中，如果一名男性英俊且友好，他非常可能处于一段关系中；否则，他很可能是单身。正如我们从 SCM 中看到的，H 和 F 被假设为独立的。然而，如果你考虑那些 *not in a relationship* 的男性，即你以 $R=0$ 为条件，这些特征——男性是否友好或英俊——变得负相关。如果某人英俊，他更可能不友好（否则他会处于一段关系中）。我们有

$$F \not\perp\!\!\!\perp H \,|\, R=0$$

因此，给定 R，F 不独立于 H。 □

正如我们之前提到的，Pearl [2009] 在定理 1.4.1 中表明，由 SCM 诱导的分布 $P_{\mathbf{X}}$ 对其图具有马尔可夫性 [参见 Verma 和 Pearl, 1988]。

命题 6.31（SCMs 蕴含马尔可夫性质）*Assume that $P_{\mathbf{X}}$ is induced by an SCM with graph $\mathcal{G}$. Then, $P_{\mathbf{X}}$ is Markovian with respect to $\mathcal{G}$.*

假设分布相对于因果图是马尔可夫的，这有时被称为因果马尔可夫条件；这需要因果图的概念。对我们而言，因果图由底层的 SCM 诱导产生。另一方面，因果图模型的概念则将它们作为因果推断的出发点。

6.5.2 因果图模型

我们将在第 6.6 节看到，在定义干预分布时，通常只需要了解观测分布和图结构。因此，我们将因果图模型定义为由图和观测分布组成的一对，使得该分布相对于

图（因果马尔可夫条件）。然而，这里存在一个微妙的技术细节。形式上，我们需要访问完整的条件分布。如果 $p(x_2|x_1=3)$ 未定义，例如，因为 $p(x_1=3)=0$，我们可能无法定义 $p^{do(X_1:=3)}(x_2)$。这引出了以下定义：

定义 6.32（因果图模型）*A causal graphical model over ran- dom variables* $\mathrm{X}=(X_1,\ldots,X_d)$ *contains a graph* $\mathcal{G}$ *and a collection of functions* $f_j(x_j,x_{\mathbf{PA}_j^{\mathcal{G}}})$ *that integrate to* 1*:*

$$\int f_j(x_j,x_{\mathbf{PA}_j^{\mathcal{G}}})\,dx_j=1.$$

These functions induce a distribution P_{X} *over* X *via*

$$p(x_1,\ldots,x_d)=\prod_{j=1}^{d} f_j(x_j,x_{\mathbf{PA}_j^{\mathcal{G}}}),$$

and thus play the role of conditionals: $f_j(x_j,x_{\mathrm{PA}_j^{\mathcal{G}}})=p(x_j|x_{\mathrm{PA}_j^{\mathcal{G}}})$*. A causal graphical model induces intervention distribution according to Equations* (6.8) *and* (6.9) *in Section 6.6. In the most general form, we can define*

$$p^{do\left(X_k:=q(\cdot\,|\,x_{\widetilde{\mathbf{PA}}_k})\right)}(x_1,\ldots,x_d)=\prod_{j\neq k} f_j(x_j,x_{\mathbf{PA}_j^{\mathcal{G}}})\;q(\cdot\,|\,x_{\widetilde{\mathbf{PA}}_k}),$$

with $q(\cdot\,|\,x_{\widetilde{\mathrm{PA}}_k})$ *integrating to* 1 *and the new parents not leading to a cycle.*

若分布 $P_{\mathbf{X}}$ 在 X 上关于图 $\mathcal{G}$ 是马尔可夫的，且允许严格正的连续密度 p，则对 $(P_{\mathbf{X}},\mathcal{G})$ 由 $f_j(x_j,x_{\mathbf{PA}_j^{\mathcal{G}}}):=p(x_j|x_{\mathbf{PA}_j^{\mathcal{G}}})$ 定义了一个因果图模型。

为什么我们主要使用 SCMs 而不仅仅是图和马尔可夫条件，即因果图模型？形式上，SCMs 包含比其对应图和分布（例如，反事实陈述）严格更多的信息，因此也比所有干预分布的族与观测分布的组合包含更多信息。不过，这些额外信息是否有用是值得商榷的。可能更重要的是，限制 SCMs 中的函数类可以导致因果结构的可识别性（见第 4.1.3–4.1.6 节和第 7.1.2 节）。这些假设在 SCMs 的语言中比在图模型的语言中更容易表述。

6.5.3 忠实性与因果最小性

在上一小节中，我们讨论了马尔可夫假设，它使我们能够从图结构中读出独立性。忠实性使我们能够从图结构中推断出依赖性。

定义 6.33（忠实性与因果最小性）*Consider a distribution $P_{\mathbf{X}}$ and a DAG $\mathcal{G}$.*

(i) $P_{\mathbf{X}}$ is faithful to the DAG $\mathcal{G}$ if

$$\mathbf{A} \perp\!\!\!\perp \mathbf{B} \,|\, \mathbf{C} \;\Rightarrow\; \mathbf{A} \perp\!\!\!\perp_{\mathcal{G}} \mathbf{B} \,|\, \mathbf{C}$$

for all disjoint vertex sets A, B, C.

(ii) A distribution satisfies causal minimality with respect to $\mathcal{G}$ if it is Markovian with respect to $\mathcal{G}$, but not to any proper subgraph of $\mathcal{G}$.

第(i)部分假设了与全局马尔可夫条件相反的推论 版本

$$\mathbf{A} \perp\!\!\!\perp_{\mathcal{G}} \mathbf{B} \,|\, \mathbf{C} \;\Rightarrow\; \mathbf{A} \perp\!\!\!\perp \mathbf{B} \,|\, \mathbf{C},$$

参见定义 6.21。忠实性在初看时并不直观。现在我们给出一个相对于给定 DAG $\mathcal{G}_1$ 是马尔可夫的但不忠实的分布的例子。这通过使两条路径相互抵消并创造出图结构未蕴含的独立性来实现。

例 6.34（违反忠实性）考虑下图。

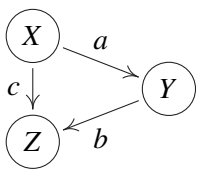

$\mathcal{G}_1$

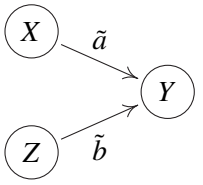

$\mathcal{G}_2$

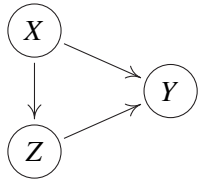

$\mathcal{H}$

我们首先查看一个与左图 $\mathcal{G}_1$ 对应的线性高斯 SCM。

$$\begin{aligned} X &:= N_X, \\ Y &:= aX + N_Y, \\ Z &:= bY + cX + N_Z, \end{aligned}$$

具有正态分布的噪声变量 $N_X \sim \mathcal{N}(0, \sigma_X^2)$、$N_Y \sim \mathcal{N}(0, \sigma_Y^2)$ 和 $N_Z \sim \mathcal{N}(0, \sigma_Z^2)$，它们联合独立。这是一个具有图 $\mathcal{G}_1$ (见定义6.2)的线性高斯 SCM 的例子。现在，如果

$$a \cdot b + c = 0, \tag{6.6}$$

该分布相对于 $\mathcal{G}_1$ 不忠实，因为我们得到 $X \perp\!\!\!\perp Z$，这并未被图结构蕴含。[12] 读者可以轻易验证，存在一个具有 DAG $\mathcal{G}_2$ 的 SCM 诱导出相同的分布。 □

为了在前面的例子中获得额外的独立性，我们必须“调节”系数，使得两条路径在 (6.6) 中相互抵消。Spirtes et al. [2000, Theorem 3.2] 对线性模型表明，如果假设系数是从正密度中随机抽取的，则这种情况发生的概率为零。

示例 6.34 中的分布对 $\mathcal{G}_2$ 是忠实的，但对 $\mathcal{G}_1$ 不是。然而，对于两个模型，若所有参数均不为零，则因果最小性得到满足。换句话说，该分布对 $\mathcal{G}_1$ 或 $\mathcal{G}_2$ 的任何真子图都不是马尔可夫的，因为删除任意边都会对应一个新的（条件）独立性，而该独立性在分布中不成立；注意 $\mathcal{G}_2$ 不是 $\mathcal{G}_1$ 的真子图。然而，它是 $\mathcal{H}$ 的真子图，因此，该分布对 $\mathcal{H}$ 不满足因果最小性。一般而言，因果最小性比忠实性更弱。

命题 6.35（忠实性蕴含因果最小性）*If $P_{\mathbf{X}}$ is faithful and Markovian with respect to $\mathcal{G}$, then causal minimality is satisfied.*

证明。论证过程如下：如果 $P_{\mathbf{X}}$ 对 $\mathcal{G}$ 的真子图$\tilde{\mathcal{G}}$ 是马尔可夫的，则存在两个节点在 $\mathcal{G}$ 中直接相连，但在$\tilde{\mathcal{G}}$ 中不直接相连。因此，它们可以在$\tilde{\mathcal{G}}$ 中被 d 分离，但在 $\mathcal{G}$ (中不能，参见问题 6.62)。马尔可夫条件意味着 $P_{\mathbf{X}}$ 中对应的条件独立性陈述，因此 $P_{\mathbf{X}}$ 对 $\mathcal{G}$ 不可能是忠实的。□

以下表述与因果最小性等价，并有望进一步帮助理解该条件。一个分布关于 $\mathcal{G}$ 是最小的，当且仅当不存在节点在给定其余父节点的条件下与其任一父节点条件独立。在某种意义上，所有父节点都是“活跃的”。

[12] More precisely, it is not triangle-faithful [Zhang and Spirtes, 2008].

命题 6.36（因果最小性的等价性）*Consider the random vec- tor* $\mathbf{X} = (X_1, \ldots, X_d)$ *and assume that the joint distribution has a density with respect to a product measure. Suppose that* $P_{\mathbf{X}}$ *is Markovian with respect to* $\mathcal{G}$*. Then* $P_{\mathbf{X}}$ *satisfies causal minimality with respect to* $\mathcal{G}$ *if and only if* $\forall X_j \, \forall Y \in \mathrm{PA}_j^{\mathcal{G}}$ *we have that* $X_j \not\perp\!\!\!\perp Y \mid \mathrm{PA}_j^{\mathcal{G}} \setminus \{Y\}$.

证明。参见附录 C.6。 □

我们已看到，尽管忠实性是将条件独立性陈述与因果语义联系起来的强假设，但因果最小性是一个弱得多的条件。假设给定一个因果图模型，例如其中违反了因果最小性。那么，其中一条边在命题 6.36 的意义下是“不活跃的”。若移除这条边，这两个模型在定义 6.47 的意义下不必是反事实等价或干预等价的。然而，若所有密度严格为正（或若我们仅允许对 X_k 施加支持在 X_k 支持子集上的干预），则它们在干预意义上是等价的；参见问题 6.58。因此，因果最小性可被解释为在干预模型描述中避免冗余的约定。在大多数模型类中，若没有因果最小性，则无法从观测数据中获得可识别性。例如，若 f 仅被允许在 X 的支持之外与 c 不同，则我们无法区分 $Y := f(X) + N_Y$ 和 $Y := c + N_Y$；另见备注 6.6 和命题 6.49。

6.6 通过协变量调整计算干预分布

在本节中，我们将利用一个看似平凡但非常强大的不变性陈述。给定 SCM $\mathfrak{C}$，并记 $pa(j) := \mathrm{PA}_j^{\mathcal{G}}$，我们有

$$p^{\tilde{\mathfrak{C}}}(x_j \,|\, x_{pa(j)}) = p^{\mathfrak{C}}(x_j \,|\, x_{pa(j)}) \tag{6.7}$$

对于由 $\mathfrak{C}$ 通过干预（部分）X_k 但不干预 X_j 构造的任意 SCM $\tilde{\mathfrak{C}}$。式（6.7）表明因果关系在干预下是自主的；因此这一性质有时被称为“自主性”。如果我们干预一个变量，则其他机制保持不变（见图 2.2 左框）。

我们从 (6.7) 推导出一个公式，该公式以三个不同的名称为人所知：截断因子分解 [Pearl, 1993]，*G*-计算公式 [Robins, 1986],

以及操纵定理 [Spirtes et al., 2000]。其重要性源于以下事实：尽管我们从未见过干预分布的数据，但它允许我们计算关于干预分布的陈述。

考虑一个具有结构赋值的 SCM $\mathfrak{C}$

$$X_j := f_j(X_{pa(j)}, N_j), \qquad j = 1, \ldots, d,$$

和密度 $p^{\mathfrak{C}}$。由于马尔可夫性质，我们有[13]

$$p^{\mathfrak{C}}(x_1, \ldots, x_d) = \prod_{j=1}^{d} p^{\mathfrak{C}}(x_j \,|\, x_{pa(j)}).$$

现在考虑 SCM $\tilde{\mathfrak{C}}$，它在 $do\left(X_k := \tilde{N}_k\right)$ 之后从 $\mathfrak{C}$ 演化而来，其中 $\tilde{N}_k$ 允许密度 $\tilde{p}$。同样，根据马尔可夫假设

$$\begin{aligned} p^{\mathfrak{C};do\left(X_k:=\tilde{N}_k\right)}(x_1, \ldots, x_d) &= \prod_{j \neq k} p^{\mathfrak{C};do\left(X_k:=\tilde{N}_k\right)}(x_j \,|\, x_{pa(j)}) \cdot p^{\mathfrak{C};do\left(X_k:=\tilde{N}_k\right)}(x_k) \\ &= \prod_{j \neq k} p^{\mathfrak{C}}(x_j \,|\, x_{pa(j)}) \tilde{p}(x_k). \end{aligned} \tag{6.8}$$

在最后一步中，我们利用了强大的不变性 (6.7)。方程 (6.8) 使我们能够从观测量（右侧）计算干预陈述（左侧）。作为特例，我们得到

$$p^{\mathfrak{C};do(X_k:=a)}(x_1, \ldots, x_d) = \begin{cases} \prod_{j \neq k} p^{\mathfrak{C}}(x_j \,|\, x_{pa(j)}) & \text{if } x_k = a \\ 0 & \text{otherwise.} \end{cases} \tag{6.9}$$

通常，条件化与对 $do()$ 进行干预是不同的操作（参见示例 6.10 后的讨论）。我们现在可以证明，对于没有任何父节点的变量，这两种操作是相同的。不失一般性，假设 X_1 是这样一个源节点。然后我们有

$$\begin{aligned} p^{\mathfrak{C}}(x_2, \ldots, x_d \,|\, x_1 = a) &= \frac{p(x_1 = a) \prod_{j=2}^{d} p^{\mathfrak{C}}(x_j \,|\, x_{pa(j)})}{p(x_1 = a)} \\ &= p^{\mathfrak{C};do(X_1:=a)}(x_2, \ldots, x_d). \end{aligned} \tag{6.10}$$

式（6.8）和式（6.9）应用广泛，但有时使用起来有些繁琐。现在我们将学习一些实用的替代方法。因此，我们首先回顾示例 6.16（肾结石），随后将其推广。

13注意，条件句 $p^{\mathfrak{C}}(x_j \,|\, x_{pa(j)})$ 甚至可以对满足 $p^{\mathfrak{C}}(x_{pa(j)}) = 0$ 的值 $x_{pa(j)}$ 进行定义。

例 6.37（肾结石，续）假设真实的底层 SCM 允许该图

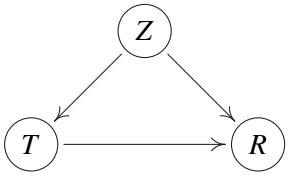

在此，Z 是结石大小，T 是治疗，R 是恢复（均为二元）。我们看到恢复受治疗和结石大小的影响。治疗本身也依赖于大小。此外，大部分困难病例被分配到治疗 A。进一步考虑在将 T 的结构赋值分别替换为 $T := A$ 和 $T := B$ 后得到的两个 SCM $\mathfrak{C}_A$ 和 $\mathfrak{C}_B$。将对应的结果概率分布分别称为 $P^{\mathfrak{C}_A}$ 和 $P^{\mathfrak{C}_B}$。假设我们被诊断出患有肾结石 *without knowing its size*，我们应依据之间的比较来选择治疗方法

$$\mathbb{E}^{\mathfrak{C}_A} R = P^{\mathfrak{C}_A}(R=1) = P^{\mathfrak{C};do(T:=A)}(R=1)$$

和

$$\mathbb{E}^{\mathfrak{C}_B} R = P^{\mathfrak{C}_B}(R=1) = P^{\mathfrak{C};do(T:=B)}(R=1).$$

鉴于我们已从 $\mathfrak{C}$ 观测到数据，如何估计这些量？考虑以下计算：

$$\begin{aligned}
P^{\mathfrak{C}_A}(R=1) &= \sum_{z=0}^{1} P^{\mathfrak{C}_A}(R=1, T=A, Z=z) \\
&= \sum_{z=0}^{1} P^{\mathfrak{C}_A}(R=1 \,|\, T=A, Z=z)\, P^{\mathfrak{C}_A}(T=A, Z=z) \\
&= \sum_{z=0}^{1} P^{\mathfrak{C}_A}(R=1 \,|\, T=A, Z=z)\, P^{\mathfrak{C}_A}(Z=z) \\
&\overset{(6.7)}{=} \sum_{z=0}^{1} P^{\mathfrak{C}}(R=1 \,|\, T=A, Z=z)\, P^{\mathfrak{C}}(Z=z). \qquad (6.11)
\end{aligned}$$

最后一步包含关键思想。再次，我们利用了不变性（6.7）。我们可以根据表6.1所示的经验数据估计 $P^{\mathfrak{C}_A}(R=1)$ 并得到

$$P^{\mathfrak{C}_A}(R=1) \approx 0.93 \cdot \frac{357}{700} + 0.73 \cdot \frac{343}{700} = 0.832.$$

同理，我们得到

$$P^{\mathfrak{C}_B}(R=1) \approx 0.87 \cdot \frac{357}{700} + 0.69 \cdot \frac{343}{700} \approx 0.782,$$

因此我们得出结论，我们宁愿选择治疗 A。（如前所述，我们忽略统计显著性问题，这在我们需要在 A 和 B 之间做出决定时似乎是合理的。）该量

$$P^{\mathfrak{C}_A}(R=1) - P^{\mathfrak{C}_B}(R=1) \approx 0.832 - 0.782 \tag{6.12}$$

有时被称为二元处理的平均因果效应（ACE）。重要的是要认识到，这与简单条件化不同：

$$P^{\mathfrak{C}}(R=1 \,|\, T=A) - P^{\mathfrak{C}}(R=1 \,|\, T=B) = 0.78 - 0.83,$$

在这个例子中，它甚至与 ACE 的符号相反。 □

这个三节点示例很好地突出了干预与条件化之间的区别。就密度而言，它表示为：

$$p^{\mathfrak{C};do(T:=t)}(r) = \sum_z p^{\mathfrak{C}}(r|z,t)p^{\mathfrak{C}}(z) \neq \sum_z p^{\mathfrak{C}}(r|z,t)p^{\mathfrak{C}}(z|t) = p^{\mathfrak{C}}(r|t).$$

公式 (6.11) 称为对变量 Z 的“调整”。它表示一个在实践中经常使用的重要概念，我们在定义 6.38 中正式定义了它。它再次使我们能够从观测量计算干预陈述。注意，调整公式 (6.11) 的推导有时基于截断分解 (6.9)，但我们将在命题 6.41 中看到，使用不变性 (6.11) 的替代计算方法可以很好地推广到更复杂的设置中。

定义 6.38（有效调整集）*Consider an SCM* $\mathfrak{C}$ *over nodes* V *and let* $Y \notin \mathrm{PA}_X$ *(otherwise we have* $p^{\mathfrak{C};do(X:=x)}(y) = p^{\mathfrak{C}}(y)$*). We call a set* $\mathrm{Z} \subseteq \mathrm{V} \setminus \{X,Y\}$ *a valid adjustment set for the ordered pair* (X,Y) *if*

$$p^{\mathfrak{C};do(X:=x)}(y) = \sum_{\mathbf{z}} p^{\mathfrak{C}}(y \,|\, x,\mathbf{z})\, p^{\mathfrak{C}}(\mathbf{z}). \tag{6.13}$$

Here, the sum (could also be an integral) is over the range of Z*, that is, over all values* z *that* Z *can take.*

在例 6.37 中，$\mathbf{Z} = \{Z\}$ 是 (T,R) 的有效调整集。为了计算平均因果效应，调整 Z 是必要的。我们已经看到，简单条件化会导致错误结论。换句话说，空集不是有效调整集。在这种情况下，我们说从 T 到 R 的因果效应存在混杂。

定义 6.39（混杂）*Consider an SCM $\mathfrak{C}$ over nodes $\mathbf{V}$ with a directed path from X to Y, $X,Y \in \mathbf{V}$. The causal effect from X to Y is called confounded if*

$$p^{\mathfrak{C};do(X:=x)}(y) \neq p^{\mathfrak{C}}(y|x). \tag{6.14}$$

Otherwise, the causal effect is called "unconfounded."

有时人们认为应将调整集尽可能扩大，以减少潜在混杂因素的影响。然而，这并不总是好主意，正如 Berkson 悖论 [Berkson, 1946] 在例 6.30 中所示。它表明并非所有集合都是有效调整集，有时不将协变量纳入调整集反而更好。让我们尝试研究哪些集合可用于调整。我们采用与例 6.37 相同的思路，并写出（对任意集合 $\mathbf{Z}$）

$$\begin{aligned} p^{\mathfrak{C};do(X:=x)}(y) &= \sum_{\mathbf{z}} p^{\mathfrak{C};do(X:=x)}(y,\mathbf{z}) \\ &= \sum_{\mathbf{z}} p^{\mathfrak{C};do(X:=x)}(y|x,\mathbf{z})\, p^{\mathfrak{C};do(X:=x)}(\mathbf{z}). \end{aligned}$$

如果我们有

$$p^{\mathfrak{C};do(X:=x)}(y|x,\mathbf{z}) = p^{\mathfrak{C}}(y|x,\mathbf{z}) \text{ and } p^{\mathfrak{C};do(X:=x)}(\mathbf{z}) = p^{\mathfrak{C}}(\mathbf{z}), \tag{6.15}$$

与之前一样，这意味着 $\mathbf{Z}$ 是一个有效的调整集。性质（6.15）表明，即使在对 X 进行干预后，条件分布仍然保持不变；我们称它们为不变的。因此，我们需要解决在干预 $do(X := x)$ 下哪些条件分布保持不变的问题。

备注 6.40（不变条件的刻画）考虑一个具有结构赋值的 SCM $\mathfrak{C}$

$$X_j := f_j(\mathbf{PA}_j, N_j)$$

以及干预 $do(X_k := x_k)$。例如，类似于 Pearl [2009, 第 3.2.2 章] 中所做的，我们现在可以构造一个新的 SCM $\mathfrak{C}^*$，使其等于 $\mathfrak{C}$

但多了一个变量I，表示干预是否发生（另见第95页第6.3节“干预变量”段落）。更准确地说，I是X_k的父节点，且没有其他邻居。相应的结构分配是

$$\begin{aligned} I &:= N_I \\ X_j &:= f_j(\mathbf{PA}_j, N_j) \quad \text{for } j \neq k \\ X_k &:= \begin{cases} f_k(\mathbf{PA}_k, N_k) & \text{if } I = 0 \\ x_k & \text{otherwise} \end{cases}, \end{aligned}$$

其中 N_I 具有伯努利分布，例如 $P(I=0) = P(I=1) = 0.5$（其他分布也适用）。因此，$I=0$ 对应于观测设定，$I=1$ 对应于干预设定。更准确地说，使用方程 (6.10)，我们得到

$$\begin{aligned} p^{\mathfrak{C}^*}(x_1,\ldots,x_d \,|\, I=0) &= p^{\mathfrak{C}^*;do(I:=0)}(x_1,\ldots,x_d) \\ &= p^{\mathfrak{C}}(x_1,\ldots,x_d) \end{aligned}$$

同样地

$$p^{\mathfrak{C}^*}(x_1,\ldots,x_d \,|\, I=1) = p^{\mathfrak{C};do(X_k:=x_k)}(x_1,\ldots,x_d). \tag{6.16}$$

使用 $\mathfrak{C}^*$ 的马尔可夫条件，因此对于变量 A 和一组变量 B，有

$$\begin{aligned} A \perp\!\!\!\perp_{\mathcal{G}^*} I \,|\, \mathbf{B} \quad &\Longrightarrow \quad p^{\mathfrak{C}^*}(a \,|\, \mathbf{b}, I=0) = p^{\mathfrak{C}^*}(a \,|\, \mathbf{b}, I=1) \\ &\Longrightarrow \quad p^{\mathfrak{C}}(a \,|\, \mathbf{b}) = p^{\mathfrak{C};do(X_k:=x_k)}(a \,|\, \mathbf{b}). \end{aligned}$$

右侧指出，在干预 X_k 的情况下，条件 A 在给定 B 时的分布 $P_{A|\mathbf{B}}$ 保持不变。□

我们现在能够继续之前的论证。方程(6.15)对于集合Z是满足的，对此我们有

$$Y \perp\!\!\!\perp_{\mathcal{G}^*} I \,|\, X, \mathbf{Z} \qquad \text{and} \qquad \mathbf{Z} \perp\!\!\!\perp_{\mathcal{G}^*} I. \tag{6.17}$$

下标 $\mathcal{G}^*$ 表示要求在 $\mathcal{G}^*$ 中成立 d 分离语句。我们的讨论立即推导出以下命题的前两个陈述：

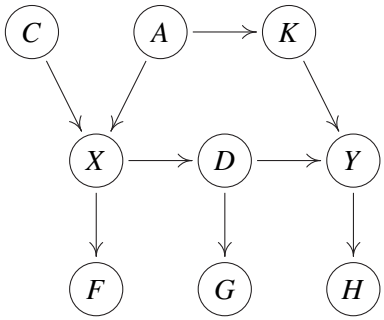

图6.5：只有路径$X \leftarrow A \rightarrow K \rightarrow Y$是$X$到$Y$的“后门路径”。集合$\mathrm{Z} = \{K\}$满足后门准则（见命题6.41(ii)）；但$\mathrm{Z} = \{F, C, K\}$也是$(X, Y)$的有效调整集；见命题6.41(iii)。

命题 6.41（有效调整集）*Consider an SCM over variables* X *with* $X, Y \in \mathrm{X}$ *and* $Y \notin \mathrm{PA}_X$. *Then, the following three statements are true.*

(i) ***“parent adjustment”****:*

$$\mathbf{Z} := \mathbf{PA}_X$$

is a valid adjustment set for (X, Y).

(ii) ***“backdoor criterion”****: Any* $\mathrm{Z} \subseteq \mathrm{X} \setminus \{X, Y\}$ *with*

- Z *contains no descendant of* X *AND*
- Z *blocks all paths from* X *to* Y *entering* X *through the backdoor* $(X \leftarrow \ldots,$ *see Figure 6.5*$)$

is a valid adjustment set for (X, Y).

(iii) ***“toward necessity”****: Any* $\mathrm{Z} \subseteq \mathrm{X} \setminus \{X, Y\}$ *with*

- Z *contains no descendant of any node on a directed path from* X *to* Y *(except for descendants of* X *that are not on a directed path from* X *to* Y*) AND*
- Z *blocks all non-directed paths from* X *to* Y

is a valid adjustment set for (X, Y).

只有第三个陈述[Shpitser等人，2010年，Perkovic等人，2015年]需要一些解释。让我们从一个有效的调整集Z开始，例如，通过后门准则获得的。然后我们可以将任何满足以下条件的节点Z_0添加到Z中

$Z_0 \perp\!\!\!\perp Y \mid X, \mathbf{Z}$ 因为那时

$$\sum_{\mathbf{z},z_0} p(y \mid x, \mathbf{z}, z_0) p(\mathbf{z}, z_0) = \sum_{\mathbf{z}} p(y \mid x, \mathbf{z}) \sum_{z_0} p(\mathbf{z}, z_0)$$
$$= \sum_{\mathbf{z}} p(y \mid x, \mathbf{z}) p(\mathbf{z}).$$

事实上，命题6.41 (iii) 描述了 *all* 有效调整集的特征 [Shpitser et al., 2010]。

例 6.42（线性高斯系统中的调整）考虑一个在变量 V 上的 SCM $\mathfrak{C}$，其中 $\{X, Y\}, \mathbf{Z} \subseteq \mathbf{V}$。有时，我们希望用一个单一的实数来概括从 X 到 Y 的因果效应，而不是对所有 x 查看 $p^{\mathfrak{C};do(X:=x)}(y)$。我们已经在二元处理 X (的情况下看到了一个例子，参见方程（6.12)）。但在连续随机变量的情况下可以做什么呢？作为第一近似，我们可以查看该分布的期望，然后对 x 求导:

$$\frac{\partial}{\partial x} \mathbb{E}^{\mathfrak{C};do(X:=x)}[Y]. \tag{6.18}$$

一般来说，这仍然是 x 的函数。然而，在线性高斯系统中，该函数结果是常数。假设 Z 是 (X, Y) 的有效调整集。如果 V 服从高斯分布，则条件 $Y \mid X = x, \mathbf{Z} = \mathbf{z}$ 也服从高斯分布；其均值为

$$\mathbb{E}[Y \mid X = x, \mathbf{Z} = \mathbf{z}] = ax + \mathbf{b}^t \mathbf{z} \tag{6.19}$$

对于某些 a 和 b。由(6.13)可知（见习题6.63）

$$\frac{\partial}{\partial x} \mathbb{E}^{\mathfrak{C};do(X:=x)}[Y] = a. \tag{6.20}$$

可以通过两种不同的方式获得（6.19）中a的值。（1）可以使用路径系数的方法：如果从X到Y恰好有一条有向路径，那么a等于路径系数的乘积。如果没有有向路径，则$a =$为0；如果有不同的路径，则a可以使用Wright公式[Wright, 1934]计算。（2）可以直接计算条件均值（6.19）。如果我们得到的不是联合分布，而是从联合分布中抽取的样本，我们可以通过将Y对X和Z进行回归，然后读取X (的回归系数来估计（6.20），另见代码片段6.43)。

□

代码片段 6.43 以下代码从图6.5所示结构的SCM中生成了一个大小为$n=100$的独立同分布样本（系数参见代码）。由于我们知道潜在的SCM，量(6.20)的真实值可以通过路径$X \to D \to Y$的路径系数相乘得到；在我们的例子中，它等于$(-2)\cdot(-1)=2$（见代码第8行和第10行）。现在我们可以假设结构分配的具体形式，即系数集合未知，但我们已经得到了数据样本和SCM的图结构（见图6.5）。然后，我们可以通过将Y对X和一个调整集Z进行回归来估计(6.20)的值。如果Z是一个有效的调整集，我们将得到一个无偏估计量。在代码中，调整集$Z=/0$导致有偏估计量（见第15行）；只有调整集$Z=\{K\}$和$Z=\{F,C,K\}$是有效的（分别见第19行和第23行）。

```
1  # generate a sample from the distribution entailed by the SCM
2  set.seed(1); n <- 100
3  C <- rnorm(n)
4  A <- 0.8*rnorm(n)
5  K <- A + 0.1*rnorm(n)
6  X <- C - 2*A + 0.2*rnorm(n)
7  F <- 3*X + 0.8*rnorm(n)
8  D <- -2*X + 0.5*rnorm(n)
9  G <- D + 0.5*rnorm(n)
10 Y <- 2*K - D + 0.2*rnorm(n)
11 H <- 0.5*Y + 0.1*rnorm(n)
12 #
13 lm(Y~X)$coefficients
14 # (Intercept)---------X
15 # 0.09724282 1.27941073
16 #
17 lm(Y~X+K)$coefficients
18 # (Intercept)---------X----------K
19 # 0.01428974 2.07038809 2.16964827
20 #
21 lm(Y~X+F+C+K)$coefficients
22 # (Intercept)---------X----------F-----------C----------K
23 # 0.01687018 1.90495456 0.05901385 -0.02260164 2.18276488
```

我们现在简要评论倾向得分匹配 [Rosenbaum and Rubin, 1983]。以下备注重复了 Pearl [2009, 11.3.5] 给出的论证。

备注 6.44（倾向得分匹配）考虑一个关于变量 $X=(X,Y,Z)$ 的 SCM，其中 $Z=(Z_1,Z_2,Z_3)$ 以及以下图形。

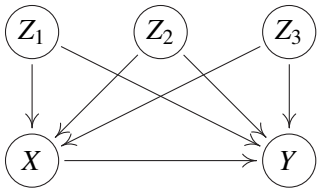

可以看到，集合 $\{Z_1, Z_2, Z_3\}$ 是一个有效的调整集，例如，通过父节点调整（见命题6.41）。即，

$$p^{\mathfrak{C};do(X:=x)}(y) = \sum_{z_1,z_2,z_3} p^{\mathfrak{C}}(y \,|\, x, z_1, z_2, z_3)\, p^{\mathfrak{C}}(z_1, z_2, z_3). \tag{6.21}$$

然而，有时 X 的值并不“直接”依赖于 Z，而只是通过一个（实值）倾向得分 $L := L(\mathrm{Z}) = L(Z_1, Z_2, Z_3)$ 来依赖。这意味着“$X \perp\!\!\!\perp \mathrm{Z} \,|\, L(\mathrm{Z})$”，或者更正式地说，对于所有 z, x 和 $\ell = L(\mathrm{z})$，我们有

$$p(\mathbf{z} \,|\, \ell, x) = p(\mathbf{z} \,|\, \ell).$$

如果X是一个二元选择，表示接受治疗或不接受治疗，那么例如可以选择$L(\mathrm{z}) = p(x = 1 \mid \mathrm{Z} = \mathrm{z})$。但接下来，根据(6.21)可得

$$\begin{aligned} p^{\mathfrak{C};do(X:=x)}(y) &= \sum_{\mathbf{z}} p^{\mathfrak{C}}(y \,|\, x, \mathbf{z})\, p^{\mathfrak{C}}(\mathbf{z}) = \sum_{\mathbf{z}} \sum_{\ell} p^{\mathfrak{C}}(y \,|\, x, \mathbf{z})\, p^{\mathfrak{C}}(\ell) p^{\mathfrak{C}}(\mathbf{z} \,|\, \ell) \\ &= \sum_{\mathbf{z}} \sum_{\ell} p^{\mathfrak{C}}(y \,|\, \ell, x, \mathbf{z})\, p^{\mathfrak{C}}(\ell) p^{\mathfrak{C}}(\mathbf{z} \,|\, \ell, x) \\ &= \sum_{\ell} p^{\mathfrak{C}}(y \,|\, \ell, x)\, p^{\mathfrak{C}}(\ell). \end{aligned} \tag{6.22}$$

在总体设置中，干预分布的计算（6.21）和（6.22）都是正确的。然而，关键在于，对于有限数据，（6.22）可能会比（6.21）产生更好的估计：尽管需要估计函数L，但由此得到的条件$p^{\mathfrak{C}}(y \,|\, x, \ell)$可能比$p^{\mathfrak{C}}(y \,|\, x, \mathrm{z})$的维度更低。在实践中，人们通常将实现值与“相似”的ℓ值匹配来计算（6.22）。重要的实际细节包括估计函数L和匹配过程。该想法适用于任意数量的协变量。

在这个意义上，倾向得分匹配可以是一个提高统计性能的优秀且有用的技巧。它对于群体考量是无关紧要的。 □

6.7 因果微积分

再次考虑变量 V 上的 SCM。有时，我们可以通过调整公式 (6.13) 以外的方式计算干预分布 $p^{\mathfrak{C};do(X:=x)}$。设

因此，如果某个干预分布可以从观察分布和图形结构计算得出，我们称之为$p^{\mathfrak{C};do(X:=x)}(y)$ *identifiable*。如果对于(X,Y)存在一个有效的调整集，例如，$p^{\mathfrak{C};do(X:=x)}(y)$肯定是可识别的。Pearl [2009，定理3.4.1]发展了所谓的do-演算，它包含三条规则。给定一个图$\mathcal{G}$和不相交的子集X, Y, Z，以及W，我们有

1. “观测的插入/删除”：

$$p^{\mathfrak{C};do(\mathbf{X}:=\mathbf{x})}(\mathbf{y}\,|\,\mathbf{z},\mathbf{w}) = p^{\mathfrak{C};do(\mathbf{X}:=\mathbf{x})}(\mathbf{y}\,|\,\mathbf{w})$$

   如果Y和Z被X,W中的d分隔在一个已移除X中入边的图中。

2. “行动/观察交换”：

$$p^{\mathfrak{C};do(\mathbf{X}:=\mathbf{x},\mathbf{Z}=\mathbf{z})}(\mathbf{y}\,|\,\mathbf{w}) = p^{\mathfrak{C};do(\mathbf{X}:=\mathbf{x})}(\mathbf{y}\,|\,\mathbf{z},\mathbf{w})$$

   如果Y和Z在一个图中由X, W分隔，且图中X的入边和Z的出边已被移除。

3. “操作的插入/删除”：

$$p^{\mathfrak{C};do(\mathbf{X}:=\mathbf{x},\mathbf{Z}=\mathbf{z})}(\mathbf{y}\,|\,\mathbf{w}) = p^{\mathfrak{C};do(\mathbf{X}:=\mathbf{x})}(\mathbf{y}\,|\,\mathbf{w})$$

   如果Y和Z在从图$\mathcal{G}$中移除所有进入X的边后得到的图中，通过X,W被d-分离，其中X和Z(W)中的入边已被移除。在此，Z(W)是Z中节点的子集，这些节点在从$\mathcal{G}$移除所有指向X的边后得到的图中，不是W中任何节点的祖先。

定理 6.45（Do-演算）*The following statements hold.*

(i) The rules are complete; that is, all identifiable intervention distributions can be computed by an iterative application of these three rules [Huang and Valtorta, 2006, Shpitser and Pearl, 2006].

(ii) In fact, there is an algorithm, proposed by Tian [2002] that is guaranteed [Huang and Valtorta, 2006, Shpitser and Pearl, 2006] to find all identifiable intervention distributions.

(iii) There is a necessary and sufficient graphical criterion for identifiability of intervention distributions [Shpitser and Pearl, 2006, Corollary 3], based on so-called hedges [see also Huang and Valtorta, 2006].

作为do演算的推论，我们得到前门调整（见习题6.65）。

示例 6.46（前门调整）设 $\mathfrak{C}$ 为一个具有相应图的 SCM

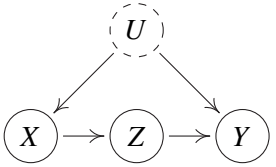

如果我们不观察 U，我们就无法应用后门准则。事实上，不存在有效的调整集。但即便如此，只要 $p^{\mathfrak{C}}(x,z) > 0$，$do$-演算就为我们提供了

$$p^{\mathfrak{C};do(X:=x)}(y) \;=\; \sum_{z} p^{\mathfrak{C}}(z\,|\,x) \sum_{\tilde{x}} p^{\mathfrak{C}}(y\,|\,\tilde{x},z)\; p^{\mathfrak{C}}(\tilde{x}). \tag{6.23}$$

通过在此处除了观察 X 和 Y 之外还观察 Z 便能揭示因果信息这一事实很好地表明了，因果关系也可以通过观察携带从 X 到 Y 的“信号”的“通道”（此处为 Z）来探索。 □

Bareinboim 和 Pearl [2014] 考虑了可移植性问题。他们同样关注干预分布，但允许纳入在某些结构赋值上与目标 SCM 一致而在其他方面不同的 SCM 中所获得的知识（即观测分布和干预分布）。

6.8 因果模型的等价性与可证伪性

到目前为止，SCMs一直是数学对象。为了将它们与现实联系起来，我们将其视为数据生成过程的模型。然而，这可能是一类复杂的模型。与“仅仅”建模联合分布（例如，我们可以用泊松过程来建模物理过程）不同，我们现在可以同时对系统在观测状态和扰动下的情况进行建模。我们已经看到，甚至可以将SCMs视为反事实陈述的模型。

更正式地说，考虑随机变量的向量$\mathbf{X} = (X_1, \ldots, X_d)$。X的概率模型预测观测分布$P_{\mathbf{X}}$。如果模型额外预测某些变量$X_j$被设置为（独立）变量$\tilde{N}_j$的干预分布，我们称这样的模型为干预模型。最后，反事实模型额外预测反事实陈述的结果。例如，传统的机器学习方法构建概率模型；

因果图模型（定义6.32）可用作干预模型，而SCM可用作反事实模型。如果两个模型在相应预测上一致，我们称它们为等价的[参见Bongers等人，2016]对于类似的构造。

定义 6.47（因果模型的等价性）*Two models are called*

$$\{\textbf{\textit{probabilistically}} \mid \textbf{\textit{interventionally}} \mid \textbf{\textit{counterfactually}}\}\ \textbf{\textit{equivalent}}$$

if they entail the same $\{$*obs.* $\mid$ *obs. and int.* $\mid$ *obs., int., and counterf.*$\}$ *distributions.*

显然，干预等价的概念仅适用于例如干预模型和反事实模型。命题7.1意味着对于每个概率模型，都存在一个观测等价的SCM。

如果 X 具有严格正的密度，命题 6.48 表明我们可以将概念限制在对单个节点的干预上，即变量 X_j 已被设置为变量$\tilde{N}_j$ 的干预，其中$\tilde{N}_j$ 的分布具有完全支撑。如果两个模型在这个干预子类上一致，那么它们在所有其他干预上也一致。其理由是，对单个节点的干预对应于随机实验的标准版本。

对于给定的数据生成过程，如果相应的分布与该过程观测到的数据不一致，我们现在就可以证伪一个概率模型或干预模型。也就是说，如果一个干预模型正确预测了观测分布，但未能预测随机实验中的结果，该模型仍被视为已被证伪。这一概念包含了一个假设，即对于随机实验应当是什么样子存在共识。当不清楚如何在现实中随机化所涉及的变量（或对它们进行干预）时，写下SCM时应谨慎。可证伪性的概念进一步要求（统计）显著性的概念，此处不予讨论。我们不包括反事实模型，因为它们通常难以证伪。我们可以基于它们对观测分布和干预分布的蕴含来证伪它们（参见Shpitser and Pearl [2008a]及其中的参考文献）。在某些特定的实验设置中，还可以构造可证伪的反事实陈述（参见例3.4）。然而，例6.19展示了两个SCM，它们蕴含相同的观测分布和干预分布，但蕴含不同的反事实陈述。

上述对干预子类的限制（将单个变量设置为噪声变量）具有实际目的。为了检验

我们必须将随机实验的结果与模型的预测进行比较。对于更复杂的干预，现实中相应的实验似乎实施起来更为复杂。以下命题表明这并不会失去一般性：如果因果模型在所有单节点干预上一致，则它们在干预意义上是等价的。证明可见附录C.7。

命题 6.48（干预等价）*Assume that two SCMs (or causal graphical models) $\mathfrak{C}_1$ and $\mathfrak{C}_2$ induce strictly positive, continuous conditional densities $p(x_j|x_{pa(j)})$, where $pa(j) :=$ PA$_j$, and satisfy causal minimality. Assume further that they entail the same intervention distributions, in which some variable X_j has been set to a variable $\tilde{N}_j$ with full support:*

$$P_{\mathbf{X}}^{\mathfrak{C}_1;do(X_j:=\tilde{N}_j)} = P_{\mathbf{X}}^{\mathfrak{C}_2;do(X_j:=\tilde{N}_j)} \quad \forall j\, \forall \tilde{N}_j \text{ with full support.}$$

Then, $\mathfrak{C}_1$ and $\mathfrak{C}_2$ are interventionally equivalent; that is, they agree on any possible intervention, including atomic interventions or interventions in which the set of parents is altered (without creating a cycle).

如果密度不是严格正的，这种情况就不一定成立。此时可能需要考虑对多个节点同时进行干预（例如双基因敲除实验）；参见习题6.59。

此外，我们现在能够证明SCM结构最小性概念（见备注6.6）的合理性。我们已经论证，如果SCM的结构赋值中的函数不依赖于其中一个输入，我们可以选择更稀疏的表示。以下命题形式化了这些表示在何种意义上是等价的。

命题 6.49（反事实等价性）*Consider two SCMs $\mathfrak{C}$ and $\mathfrak{C}^*$ that share the same noise distribution $P_{\mathbf{N}}$ and that differ only in the kth structural assignment:*

$$f_k(\mathbf{pa}_k, n_k) = f_k^*(\mathbf{pa}_k^*, n_k), \qquad \forall \mathbf{pa}_k, \forall n_k \text{ with } p(n_k) > 0, \tag{6.24}$$

with $\mathrm{PA}_k^* \subsetneq \mathrm{PA}_k$. Then, both SCMs are counterfactually equivalent.

证明见附录 C.8。

6.9 潜在结果

我们现在介绍一种不基于结构因果模型（SCM）的因果推断替代方法。该框架通常被称为潜在结果或鲁宾

因果模型，在社会科学中广泛应用。其思想可追溯至Neyman [1923]和Fisher [1925]，他们主要讨论了随机实验。Rubin [1974]将这些思想扩展到观察性研究。Rubin [2005]、Morgan和Winship [2007]以及Imbens和Rubin [2015]对该主题提供了更详尽的介绍。

6.9.1 定义与示例

为了解释潜在结果，我们重新审视例3.4（眼科医生）并在此框架下重新表述。现在我们不是从随机变量开始，而是从一组n患者（或单位）$u = 1, \ldots, n$开始，每个患者可能接受或不接受治疗。我们为每位患者分配两个潜在结果u：$B_u(t = 1)$表示如果患者接受治疗（$T = 1$），她是否会失明（$B = 1$）或得到治愈（$B = 0$）。类似地，$B_u(t = 0)$编码未接受治疗（$T = 0$）时的情况。这两个潜在结果都被假定为确定性的。对于每位患者，治疗要么有帮助，要么没有帮助：不涉及随机性。如果$B_u(t = 1) = 0$且$B_u(t = 0) = 1$，我们说该治疗对单位u有正效应。

然而，在实践中，我们无法检验这些条件。因果推断的“根本问题”[Holland, 1986]指出，对于每个单位u，我们只能观察到$B_u(t = 1)$或$B_u(t = 0)$，而永远无法同时观察到两者。原因在于，一旦我们选择对某人进行治疗，就无法回到过去撤销该治疗。反之亦然。如果我们决定不给予治疗，之后仍可在时间上实施治疗，但这不能再被解释为变量$B_u(t = 1)$的结果。例如，患者可能在此期间自行康复了。因此，我们只能观察到潜在结果中的一个；未观察到的量成为反事实。

表6.2展示了前一个例子的（假设）数据集。实际上，数据点是根据例3.4中描述的模型采样得到的。为了证明表6.2中的呈现是合理的，我们通常隐含地假设稳定单位处理价值假设（SUTVA）[Rubin, 2005]。该假设指出，单位之间不会相互干扰（例如，一个单位的潜在结果不取决于任何其他单位接受的治疗）[Cox, 1958]；此外，它要求潜在结果不依赖于*how*或*why*接受的治疗。我们将在第6.9.2节中看到，当数据由SCM生成时（如本例所示），SUTVA是满足的。

潜在结果告诉我们处理对个体的效应；我们将单元级因果效应定义为$B_u(t = 1) - B_u(t = 0)$，以及平均因果

Unit u	Treatment T	Pot. Outcome $B_u(t=0)$	Pot. Outcome $B_u(t=1)$	Unit-Level Causal Effect $B_u(t=1)-B_u(t=0)$
1	1	1	0	-1
2	0	1	0	-1
3	1	1	0	-1
⋮				
43	1	1	0	-1
44	0	0	1	1
45	0	1	0	-1
⋮				
119	1	1	0	-1
120	1	0	1	1
121	0	1	0	-1
⋮				
200	0	1	0	-1

表6.2：本表使用潜在结果展示例3.4。对于每位患者（或单元），我们仅观测到两个潜在结果中的一个。观测到的信息以灰色背景标记。治疗T对几乎所有患者都有益。仅在200例中的2例中，治疗对患者有害并使其致盲$B=1$。尽管在大多数情况下分配治疗（$T=1$）是个好主意，但对于患者$u=120$来说，这恰恰是错误的决定。

效果

$$CE = \frac{1}{n}\sum_{u=1}^{n} B_u(t=1) - B_u(t=0). \tag{6.25}$$

“因果推断的基本问题”阻碍了我们直接计算 (6.25)。假设在一个完全随机实验中，有 $u \in U_0 \subset \{1,\dots,n\}$ 个单位接受了处理 $T=0$，另有 $u \in U_1 = U_0^C$ 个单位接受了处理 $T=1$。Neyman [1923] 表明

$$\widehat{CE} := \frac{1}{\#U_0}\sum_{u\in U_0} B_u(t=1) \;-\; \frac{1}{\#U_1}\sum_{u\in U_1} B_u(t=0) \tag{6.26}$$

是(6.25)的一个无偏估计量。在这里，$\widehat{CE}$中的随机性来自于决定我们观察到单元两个潜在结果中哪一个的随机分配；结果本身被视为隐藏的，而非随机的。注意，(6.26)仅包含观测到的量，因此可以在研究进行后计算。

关于这两种方法中哪一种更适合实际应用，存在着广泛的争论 [参见，例如， Pearl, 1995, Imbens and Rubin, 1995, Rubin,

2004，Lauritzen，2004]。我们不打算积极参与这一讨论，而是提及以下三个结果：(1) 我们描述了如何将潜在结果表示为反事实[Pearl, 2009, 第3.6.3节]；(2) 两个框架之间存在逻辑等价性[Galles and Pearl, 1998, Halpern, 2000]；(3) 我们对最近提出的一个框架[Richardson and Robins, 2013]进行了评论，该框架使两个世界更加接近。

6.9.2 潜在结果与SCMs之间的关系

在SCM中，我们可以使用反事实的语言来表示潜在结果（第6.4节）。在眼科医生的例子中，SCM $\mathfrak{C}$ 满足 $T = N_T$ 和 $B = T \cdot N_B + (1-T)\cdot(1-N_B)$。因此，我们可以通过 N_B 和 N_T 的具体值来表示每位患者。例如，在表6.2中，患者43的特征是 $N_T = 1, N_B = 0$，而患者44满足 $N_T = 0, N_B = 1$。那么，$t = 0$ 和 $t = 1$ 这两个术语对应于对 T 的干预。总结起来，我们有

$$\underbrace{B_u(t=\tilde{t})}_{\text{potential outcome}} \quad = \quad \underbrace{B \text{ in the SCM } \mathfrak{C}|\mathbf{N}=\mathbf{n}_u; do(T:=\tilde{t})}_{\text{counterfactual SCM}}, \tag{6.27}$$

其中 n_u 表示单位 u [Pearl, 2009, 方程 (3.51)]。因为在反事实 SCM 中所有噪声项都是确定性的，B 的蕴含分布也是退化的，并且 B 是确定性的（如所需）。在表 6.2 所示的例子中，我们使用伯努利分布 $N_T \sim \mathrm{Ber}(0.6)$ 和 $N_B \sim \mathrm{Ber}(0.01)$ 抽样了 200 个独立同分布的单位。在这种情况下，SUTVA 是满足的。独立同分布假设意味着这些单位之间不相互干扰，而模块性（对 T 进行干预仅改变 T 的结构赋值）使得处理的方式不影响结果。

我们现在讨论一个结果，该结果展示了（6.27）中的两种表示在何种意义上等价。为此，我们主要遵循Pearl [2009, 7.3.1]和Halpern [2000]的表述。主要论证基于以下步骤：

1. 定义属性（公理）：（C0）–（C5）和（MP）[Halpern, 2000, 第3节]。例如，属性（C4）表明

$$T_u(t=\tilde{t}, w=\tilde{w}) = t;$$

它假定将单位 u 的变量 T 设置为 t 是“有效的”。

2. 这些公理在两种表示中均得到满足（“可靠性”）。3. 可以证明，这些属性对于反事实结构因果模型是完备的。任何反事实陈述都可以从这些公理之一推导得出。

4. 我们可以得出结论，任何适用于反事实SCM的定理在潜在结果的世界中也成立，反之亦然。[14] 此外，从第3步可以得出，任何满足这三个公理的数据集（如表6.2中的数据）都可以用反事实SCM来建模。[15]

然而，这两个世界在语言上存在差异。即便每个定理在两种框架下都成立，某些定理在其中一个世界中可能比在另一个世界中更“容易”证明。同样地，定理中出现的任何假设都会对底层的数据生成过程施加限制；根据应用的不同，某种表述可能简化对这些限制的评估。对于那些平均因果效应为零但个体因果效应非零的设定，使用潜在结果框架似乎更为简便。另一方面，结构因果模型（SCMs）的图形表示可能有利于利用关于随机变量之间因果关系的假设。

Richardson和Robins [2013]提出使用单一世界干预图。这些图允许我们将变量设定为特定值，从而构建与反事实变量相对应的图形表示。通过这些修改后的图，我们可以直接读出涉及事实变量和反事实变量的条件独立性陈述。因此，我们可以将这些图视为一种有用的工具，用于将图形假设转化为潜在结果分析者常使用的反事实陈述。

6.10 关联单一对象的广义结构因果模型

到目前为止，我们研究了 *random variables* $X_1,\dots,X_d$ 之间的因果关系，并仅关注了一个情景，即数据是从 $P_{\mathbf{X}}$ 中独立同分布抽取的观测值。我们现在考虑因果DAG中节点集合 $\mathrm{v} = \{x_1,\dots,x_d\}$，这些节点由任何数学对象 $x_1,\dots,x_d$ 组成，形式化了观测的概念。例如，在观察到不同作者所写文本 $x_1,\dots,x_d$ 之间的相似性后，人们可能对因果关系感兴趣，即哪位作者受到了哪位作者的影响。遵循 Steudel 等人 [2010] 的做法，我们现在详细-

[14] Strictly speaking, the “vice versa” requires that the potential outcome framework does not assume more than the axioms mentioned.

[15] If no SCM could possibly generate this data set, this would mean that counterfactuals from SCMs would satisfy another property not implied by the three axioms, namely the property that this data set cannot be generated.

scribe在其中意义上，底层DAG也蕴含条件独立陈述，给定适当的*information*概念，而不涉及统计抽样。为此，我们假设给定了一些信息函数

$$R : 2^{\mathbf{V}} \to \mathbb{R}_0^+,$$

其中在某种意义上是单调的，即一组节点所包含的信息量不会超过其任何超集。那么，对于任意两个节点集合 x, y $\subseteq$ v，表达式 $R(\mathrm{x}, \mathrm{y}) - R(\mathrm{y})$ 是非负的，并且可以解释为在给定 y 的条件下衡量 x 的条件信息量。此外，我们假设 R 满足：对于任意三个不相交的节点集合 x, y, z，表达式

$$I(\mathbf{x} : \mathbf{y} \,|\mathbf{z}) := R(\mathbf{x}, \mathbf{z}) + R(\mathbf{y}, \mathbf{z}) - R(\mathbf{x}, \mathbf{y}, \mathbf{z}) - R(\mathbf{z}) \tag{6.28}$$

非负，当且仅当R是子模的（见第9.5.2节）。那么，我们可以将(6.28)解释为在给定z的情况下x和y之间的广义条件互信息，因为$R(\mathrm{x}, \mathrm{z}) - R(\mathrm{z})$衡量的是在给定z时x的信息，而$R(\mathrm{x}, \mathrm{y}, \mathrm{z}) - R(\mathrm{y}, \mathrm{z})$是给定y和z时x的信息。同样，随机变量之间的条件互信息可以写成香农熵的差[Cover and Thomas, 1991]。如果(6.28)消失，我们称x和y在给定z的条件下是条件独立的。

为了定义广义 SCM，我们为每个观测节点 x_j 引入一个未观测的噪声对象 n_j，并假设以下陈述。

原则 6.50（无附加信息）*A node x_j contains no additional information on top of the information contained in its parent nodes* pa_j *and the unobserved node n_j, that is,*

$$R(x_j, \mathbf{pa}_j, n_j) = R(\mathbf{pa}_j, n_j).$$

这将每个随机变量X_j由其父节点和噪声变量*determined*的假设推广开来，对于离散随机变量而言，这相当于说X_j, PA_j,N_j的香农熵与PA_j,N_j的香农熵相同。

SCM 的第二个关键假设是噪声项的统计独立性。该假设的广义版本如下：

原则6.51（未观察对象的独立性）*The unobserved nodes n_j do not contain information about each other, that is,*

$$R(n_1, \ldots, n_d) = \sum_{j=1}^{d} R(n_j).$$

Steudel等人[2010]证明了以下定理。

定理 6.52（广义因果马尔可夫条件）*If both Principles 6.50 and 6.51 hold, then* x *and* y *are conditionally independent, given* z *for any three set of nodes for which* x *and* y *are d-separated by* z.

为了将这些概念应用于文本示例，我们将文本视为其有意义词汇的集合，并令其信息 R 为不同词汇的数量。假设 d 文本 $x_1,\dots,x_d$ 之间的影响由以下简化机制给出：x_j 的作者从 x_j 的父文本中提取一些词汇，并添加一些来自他自己想法的词汇。这些附加词汇由 n_j 给出。那么，根据 n_j 的定义，原则 6.50 得到满足。根据原则 6.51，不同作者添加的词汇被假定为不同。两个文本在给定第三个文本的条件下条件独立，如果它们仅共享已出现在后者中的词汇。该示例表明，对于比随机变量广泛得多的对象类别，可以定义合理的条件独立概念。为了确保因果马尔可夫条件相对于该特定独立性概念成立，底层信息度量需要根据原则 6.50 和 6.51，对所考虑的相应因果机制类别是适当的。

Janzing和Schölkopf [2010]使用Kolmogorov复杂度K相对于某个固定的图灵机T(见第4.1.9节)来量化二进制字符串之间的信息。函数K近似子模，误差项为$\mathcal{O}(1)$，即误差不随所考虑字符串的大小增长。然后，Janzing和Schölkopf [2010]定义了一种“因果性的算法模型”，其中T从其父节点和一个噪声字符串n_j计算每个x_j，这确保了原则6.50。每个n_j也可以解释为从其父节点计算x_j的程序，即从其直接原因生成x_j的机制。然后，原则6.51等价于机制的独立性（见原则2.1）。[16]将定理6.52应用于$R = K$得到“算法马尔可夫条件”[Janzing和Schölkopf, 2010]：当x和y被z d-分离时，知道y不允许相对于获得z作为免费背景信息的图灵机对x进行更短的描述。

在更高层次上，这解决了因果推理的一个深层问题：即“观察之间的依赖关系只有在它们具有因果关联时才会发生”这一论断。

[16]This way, the second and the third branch of Figure 2.2 can be seen to coincide. The string n_j encodes the mechanism (i.e., the program running on the Turing machine), and at the same time it is the analog of the noise term in the statistical setting.

(对原则1.1)的推广仅在依赖度量适合于所考虑的观测类别及潜在因果机制类别时成立。例如，观察到孩子身高在过去十年间增长，同时某股票价值上升，并不能据此推断两者有因果关系，因为增长是许多时间序列共有的属性，并不必然意味着因果联系。只有当两个时间序列展现出更为复杂的共同增长（和/或减少）模式时，我们才会探究这种相似性背后的共同原因。鉴于非平稳时间序列无处不在，寻找那些我们认为能指示因果关系的依赖信息度量就显得尤为重要（尤其是在通过大规模数据库搜索发现时间序列时，需充分处理多重检验问题）。从更偏向应用机器学习的视角来看，这一问题引导我们构建合适的*features*，使特征空间中的相似性成为因果关系的指示。

6.11 条件语句的算法独立性

第 6.10 节表明，因果结构不仅蕴含统计（条件）独立性，还蕴含相对于其他（非统计）信息度量的独立性。我们进一步看到，马尔可夫条件也可以针对 *algorithmic* 信息来陈述。那么，算法马尔可夫条件最基本的推论是关于算法依赖性的赖兴巴赫原理的类比。两个对象只有在具有共同原因或其中一个影响另一个时，才可能在算法上依赖 [Janzing and Schölkopf, 2010]。这是因为否则它们会被空集 d-分离，从而是独立的。同样，因果无关的 d 对象 $x_1,\ldots,x_d$ 在算法上联合独立，即，

$$K(x_1,\ldots,x_d) \stackrel{+}{=} \sum_{j=1}^{d} K(x_j). \tag{6.29}$$

也可以将左右两边的差称为多信息（类比于统计信息论中的相应术语），并将联合独立性写为

$$I(x_1,x_2,\cdots,x_d) \stackrel{+}{=} 0. \tag{6.30}$$

然后，联合独立性也意味着每个子集的独立性。例如，如果x_1,x_2的联合描述比x_1的单独描述更短，并且

^{x}然后，$x_1,\dots,x_d$ 的联合描述自动地比所有 x_j 的单独描述更短，因此 (6.30) 意味着

$$I(x_1 : x_2) \stackrel{+}{=} 0.$$

如果我们现在假设因果图模型中的条件[17] $P_{X_j|\mathbf{PA}_j}$是“由自然独立选择的”，那么我们得出结论，它们在算法上是联合独立的[Janzing and Schölkopf, 2010 , Lemeire and Janzing, 2013]，并陈述了原则4.13的多变量版本。

原理 6.53（条件作用的算法独立性（AIC））*The causal conditionals described by the Markov kernels in a causal Bayesian network as in Definition 6.21 (iii) are algorithmically independent, that is,*

$$I(P_{X_1|\mathbf{PA}_1}, P_{X_2|\mathbf{PA}_2}, \cdots, P_{X_d|\mathbf{PA}_d}) \stackrel{+}{=} 0, \tag{6.31}$$

or equivalently,

$$K(P_{X_1,\dots,X_d}) \stackrel{+}{=} \sum_{j=1}^{d} K(P_{X_j|PA_j}). \tag{6.32}$$

注意，原则6.53不应与第6.10节讨论的算法马尔可夫条件混淆。后者指的是n单个对象之间的因果关系，不涉及统计抽样，而前者仍假设传统的独立同分布设定，涉及n随机变量，仅陈述了一个额外的推理原则。

对于双变量情形，(6.31) 与 (6.32) 的等价性是显而易见的，因为描述联合分布等价于描述所有因果马尔可夫核。换言之，AIC 表明，联合分布的最短描述由因果马尔可夫核的各自描述给出。

因果忠实性与AIC在精神上是相关的，且往往得出相似的结论。为了讨论它们的异同，我们重新审视例6.34。由于参数a描述了$P_{Y|X}$，而参数(b,c)描述了条件分布$P_{Z|X,Y}$，我们有

$$I(P_{Y|X} : P_{Z|X,Y}) \stackrel{+}{\geq} I(a : (b,c)). \tag{6.33}$$

这是因为，通过将注意力限制在它们某些“方面”上，无法增加两个对象之间的算法互信息；例如，参见

[17] As stated before, we use the notation $P_{Y|\mathbf{X}}$ as a shorthand for the collection $(P_{Y|\mathbf{X}=\mathbf{x}})_{\mathbf{x}}$ of conditional distributions.

Janzing 和 Schölkopf [2010，引理6]。当线性模型的结构系数满足以下条件时，会出现“非通用”独立性 $X \perp\!\!\!\perp Z$:

$$a \cdot b + c = 0. \tag{6.34}$$

然后 $K(a|b,c) \stackrel{+}{=} 0$，因为 a 可以通过长度为 $\mathcal{O}(1)$ 的程序从 b,c 计算得出。因此，

$$I(a:(b,c)) \stackrel{+}{=} K(a) - K(a|(b,c)^*) \stackrel{+}{=} K(a).$$

我们得出结论，只要 $K(a)$ 显著大于0，AIC就会被违反。对于任意实数 a，$K(a)$ 会随着所需（相对）精度的提高而对数增长。因此，AIC会拒绝相应的因果有向无环图，因为(6.34)被认为是不太可能的巧合。

我们必须解释“当 $K(a)$ 显著大于0时”这一表述，因为它涉及到AIC与忠实性之间的概念差异。假设，例如，$b = c$ 和 $a = -1$，则满足（6.34），然而，当已知 b 和 c 时，a 的描述并不会变得更短，因为 $K(a)$ 已经可以忽略不计。因此，尽管满足（6.34），AIC并未被违反，这似乎表明了参数的微调。根据Lemeire和Janzing[2013]的观点，我们现在解释为何我们认为不拒绝 *this* 类型的调整是AIC的一个 *feature* 而非缺陷。这个想法是，结构系数 ± 1（达到某个给定精度）在自然界中出现的频率远高于某些“更通用”的值，如2.36724 ...。例如，花费一些钱 S 会使可用金额 A 减少 $-S$。因此，S 和 A 之间的因果关系由结构系数 -1 描述。隐含地，AIC和我们的论点基于一个先验，即认为描述长度短的值更可能（与Solomonoff的归纳推理理论[Solomonoff, 1964]一致）。

AIC 的另一个特点是，它也会拒绝不同路径的 *almost* 抵消：例如，假设 a 非常接近 $-c/b$。为了在这种情况下估计 $I(a:(b,c))$，我们观察到

$$I(a:(b,c)) \stackrel{+}{\geq} I(a:(c/b))$$

并使用以下想法。两个彼此接近的整数n,m的算法互信息通常约为$\log n/|m-n|$，因为描述

[18]The example suggests that structure coefficients being simple is often a result of how we define variables rather than being a property of “nature.” In general, one may wonder to what extent we *define* variables in a way that yields *simple* causal relations.

n 在 m 已知后，需要大约 $\log|n-m|$ 比特，而在其他情况下需要大约 $\log n$ 比特。经过任意精细的离散化后，我们可以用整数表示 a 和 c/b，并将 $\log[a/(a+c/b)]$ 作为 $P_{Y|X}$ 和 $P_{Z|X,Y}$ 之间算法互信息的粗略估计。

6.12 问题

问题 6.54 (DAGs) *Table B.1 on page 223 states that for three nodes there are* 25 *DAGs. Why is this the case?*

问题 6.55（多变量SCMs）*Consider the following SCM* $\mathfrak{C}$

$$\begin{aligned} V &:= N_V \\ W &:= -2V + 3Y + 5Z + N_W \\ X &:= 2V + N_X \\ Y &:= -X + N_Y \\ Z &:= \alpha X + N_Z \end{aligned}$$

with $N_V, N_W, N_X, N_Y, N_Z \overset{iid}{\sim} \mathcal{N}(0,1)$.

a) *Draw the graph corresponding to the SCM.*

b) *Set* $\alpha = 2$ *and simulate 200 i.i.d. data points from the joint distribution; plot the values of* X *and* W *to visualize the distribution* $P^{\mathfrak{C}}_{X,W}$.

c) *Again, set* $\alpha = 2$ *and sample 200 i.i.d. data points from the intervention distribution*

$$P^{\mathfrak{C};do(X:=3)}_{X,W}$$

in which we have intervened on X. *Again, plot the sample and compare with the plot from part b.*

d) *A directed path from one node to another does not necessarily imply that the former node has a causal effect on the latter. Choose a value of* α *and prove that for this value* X, *has no causal effect on* W.

e) *For any given* α, *compute*

$$\frac{\partial}{\partial x}\mathbb{E}^{\mathfrak{C};do(X:=x)}[W].$$

问题6.56（干预措施）*Consider the SCM*

$$\begin{aligned} X &:= N_X \\ Y &:= (X-4)^2 + N_Y \\ Z &:= X^2 + Y^2 + N_Z \end{aligned}$$

with $N_X, N_Y, N_Z \overset{iid}{\sim} \mathcal{N}(0, 1)$. *You may intervene on either* X *or* Y. *Which hard intervention yields the smallest expected value of* Z*?*

问题 6.57（最小性）*We have stated in Remark 6.6 that causal minimality (Definition 6.33) implies structural minimality.*

a) *Convince yourself that this is shown by Proposition 6.49.*
b) *Provide an example of an SCM that satisfies structural minimality but violates causal minimality.*

问题6.58（因果最小性）*Consider a causal graphical model with a distribution that has a strictly positive, continuous density and for which causal minimality is violated. According to Proposition 6.36, we can then remove an "inactive" edge from the graph and obtain a new causal graphical model. Prove that the two models are interventionally equivalent.*

问题 6.59（干预等价）*Consider two SCMs* $\mathfrak{C}_1$ *and* $\mathfrak{C}_2$ *of the form*

$$\begin{aligned} X &:= N_X \\ Y &:= X + N_Y \\ Z &:= f_j(X, Y) + N_Z \end{aligned}$$

with $N_X, N_Y, N_Z \overset{iid}{\sim} \mathcal{U}(-1, 1)$, *a continuous uniform distribution between* -1 *and* 1. *Choose the functions* f_1 *and* f_2 *such that* $\mathfrak{C}_1$ *and* $\mathfrak{C}_2$ *are observationally equivalent, and agree on all single node interventions, but disagree on simultaneous interventions on several nodes. This problem shows that Proposition 6.48 does not need to be true if the density is not strictly positive.*

问题 6.60（循环 SCMs）*Prove that whenever the absolute values of the eigenvalues of a square matrix* B *are strictly smaller than* 1 *(i.e., the spectral radius of* B *is strictly smaller than* 1*), then* $I - B$ *is invertible.*

问题 6.61（循环 SCM）*Consider the assignment* $\mathrm{X} := B\mathrm{X} + \mathrm{N}$, *as described in Remark 6.5. Prove that if the spectral radius of* B *is strictly smaller than* 1, *then* X^t *defined by* $\mathrm{X}^t := B\mathrm{X}^{t-1} + \mathrm{N}$ *in Equation* (6.3) *converges in distribution against* $\mathrm{X} := (I - B)^{-1}\mathrm{N}$ *as defined in Equation* (6.2).

问题 6.62（d-分离）*Prove that one can* d*-separate any two nodes in a DAG* $\mathcal{G}$ *that are not directly connected by an edge. Use this statement to prove Proposition 6.35.*

问题 6.63（协变量调整）*Assume that* Z *is a valid adjustment set for the causal effect from* X *to* Y *and that* $(Y, \mathrm{X}, \mathrm{Z})$ *has a (zero mean) Gaussian distribution with*

$$\mathbb{E}[Y \,|\, X = x, \mathbf{Z} = \mathbf{z}] = ax + \mathbf{b}^t\mathbf{z}.$$

Prove that

$$\frac{\partial}{\partial x}\,\mathbb{E}^{\mathfrak{C};do(X:=x)}[Y] \;=\; a;$$

in other words, prove Equation (6.20) *using Equations* (6.19) *and* (6.13). *This result allows us to consistently estimate the causal effect a by regressing* Y *on* X *and* Z.

问题 6.64（协变量调整）*Prove the parent adjustment and the back-door criterion Proposition 6.41 (i) and (ii) using Equation* (6.17).

问题 6.65（协变量调整）*Prove the frontdoor criterion* (6.23) *start- ing with*

$$p^{\mathfrak{C};do(X:=x)}(y) = \sum_z p^{\mathfrak{C};do(X:=x)}(y \,|\, z, x)\, p^{\mathfrak{C};do(X:=x)}(z)$$

and then using rules 2 and 3 from do-calculus (Section 6.7).

7

学习多元因果模型

正如第 4 章所述，我们现在转向学习因果模型的问题。我们首先在 7.1 节（“结构可识别性”）中讨论可以从联合分布中恢复（部分）图结构的不同假设。其中一些结果可以沿用之前讨论的双变量设定。与双变量情形一样，目前还没有对可识别性假设的完整刻画，未来研究可能会揭示有前景的替代方案。在 7.2 节中，我们随后介绍方法和算法，例如基于独立性和基于评分的方法，这些方法从有限数据集中估计图（“结构识别”）。

与双变量设置中一样，我们再次面临SCMs类别过于灵活的问题。给定随机变量$\mathrm{X} = (X_1, \ldots, X_d)$上的分布$P_{\mathbf{X}}$，不同的SCMs能否蕴含这一分布？以下命题回答了这个问题：实际上，通常对于许多不同的图结构，都存在一个SCM诱导出分布$P_{\mathbf{X}}$。[1]

命题7.1（图结构的非唯一性）*Consider a random vec- tor* $\mathrm{X} = (X_1, \ldots, X_d)$ *with distribution* $P_{\mathbf{X}}$ *that has a density with respect to Lebesgue measure and assume it is Markovian with respect to* $\mathcal{G}$*. Then there exists an SCM* $\mathfrak{C} = (\mathrm{S}, P_{\mathbf{N}})$ *with graph* $\mathcal{G}$ *that entails the distribution* $P_{\mathbf{X}}$*.*

证明。见附录 C.9。 □

特别地，给定任何完全DAG，我们都能找到一个相应的SCM，使其蕴含当前的分布。正如在双变量情形中一样，由此可见

[1] Statements similar to Proposition 7.1 can be found in Druzdzel and Simon [1993] and Druzdzel and van Leijen [2001].

我们需要进一步的假设来获得可识别性结果。下一节将讨论其中的一些假设。

7.1 结构可识别性

7.1.1 忠实度

如果分布 $P_{\mathbf{X}}$ 关于底层有向无环图 $\mathcal{G}^0$ 是马尔可夫且忠实的，则图 $\mathcal{G}^0$ 中的 *d*-分离陈述与分布中相应的条件独立陈述之间存在一一对应关系。因此，$\mathcal{G}^0$ 的正确马尔可夫等价类之外的所有图都可以被拒绝，因为它们施加的 *d*-分离集合不等于 $P_{\mathbf{X}}$ 中的条件独立集合。由于马尔可夫条件和忠实性都对联合分布中的条件独立施加了限制 *only*，因此也很清楚，我们无法区分两个马尔可夫等价的图，即两个蕴含完全相同条件独立集合的图（例如参见第103页的图6.4）。总之，在马尔可夫条件和忠实性下，$\mathcal{G}^0$ 的马尔可夫等价类，由 CPDAG($\mathcal{G}^0$) 表示，可以从 $P_{\mathbf{X}}$ 中识别出来 [例如，Spirtes et al., 2000]。

引理 7.2（马尔可夫等价类的可识别性）*Assume that $P_{\mathbf{X}}$ is Markovian and faithful with respect to $\mathcal{G}^0$. Then, for each graph $\mathcal{G} \in CPDAG(\mathcal{G}^0)$, we find an SCM that entails the distribution $P_{\mathbf{X}}$. Furthermore, there is no graph $\mathcal{G}$ with $\mathcal{G} \notin CPDAG(\mathcal{G}^0)$, such that $P_{\mathbf{X}}$ is Markovian and faithful with respect to $\mathcal{G}$.*

证明。第一个陈述直接由命题7.1推出，第二个陈述依据马尔可夫等价的定义，见定义6.24。□

基于独立性的方法（也称为基于约束的方法）假定分布相对于底层图是马尔可夫且忠实的，然后估计正确的马尔可夫等价类；参见第7.2.1节。

我们已在例6.42中看到，对于高斯分布，因果效应可由单个数值（6.20）概括。若我们仅知该图的马尔可夫等价类而非正确图，该量便不再可识别。但可以提供界限[Maathuis等，2009]。

7.1.2 加性噪声模型

命题7.1表明，一个给定的分布可能源自多个具有不同图的SCM。然而，对于许多这些图结构而言，结构分配中出现的函数f_j相当复杂。我们发现，如果不允许任意复杂的函数，即如果我们限制函数类别，就能获得非平凡的可识别性结果。正如我们在第4章已经看到的，在接下来的7.1.4节和7.1.5节中，我们将假设噪声以加法方式作用。

定义 7.3 (ANMs) *We call an SCM $\mathfrak{C}$ an ANM if the structural assignments are of the form*

$$X_j := f_j(\mathbf{PA}_j) + N_j, \qquad j = 1, \ldots, d, \tag{7.1}$$

that is, if the noise is additive. For simplicity, we further assume that the functions f_j are differentiable and the noise variables N_j have a strictly positive density.[2]

以下一些可识别性结果假设因果最小性（定义6.33）。对于ANMs，这意味着每个函数f_j在其任何参数上都不是常数。直观上，该函数应当真正“依赖于”其参数。以下命题的证明见附录C.10。

命题 7.4（因果最小性与加性噪声模型）*Consider a distribution induced by a model* (7.1) *and assume that the functions f_j are not constant in any of its arguments, that is, for all j and $i \in \mathrm{PA}_j$ there is some value $\mathrm{pa}_{j,-i}$ of the variables $\mathrm{PA}_j \setminus \{i\}$ and some $x_i \neq x_i'$ such that*

$$f_j(\mathbf{pa}_{j,-i}, x_i) \neq f_j(\mathbf{pa}_{j,-i}, x_i').$$

Then the joint distribution satisfies causal minimality with respect to the corresponding graph. Conversely, if there are nodes j and i such that for all $\mathrm{pa}_{j,-i}$ the function $f_j(\mathrm{pa}_{j,-i}, \cdot)$ is constant, causal minimality is violated.

我们在注6.6中已经论证过，我们可以限制自己于那些在其某个参数中不是常数的函数；见命题6.49。我们现在已经看到，对于具有完全支持噪声的ANMs，这一限制意味着因果最小性。

给定(7.1)中描述的受限SCM类，我们是否可以获得完整结构可识别性？答案仍然是否定的。定理4.2和问题7.13

[2] These two conditions guarantee that the joint distribution over $X_1, \ldots, X_d$ allows for a strictly positive density, for example.

Type of structural assignment		Condition on funct.	DAG identif.	See
(General) SCM:	$X_j := f_j(X_{\mathbf{PA}_j}, N_j)$	—	✗	Prop. 7.1
ANM:	$X_j := f_j(X_{\mathbf{PA}_j}) + N_j$	nonlinear	✓	Thm. 7.7(i)
CAM:	$X_j := \sum_{k\in\mathbf{PA}_j} f_{jk}(X_k) + N_j$	nonlinear	✓	Thm. 7.7(ii)
Linear Gaussian:	$X_j := \sum_{k\in\mathbf{PA}_j} \beta_{jk} X_k + N_j$	linear	✗	Problem 7.13
Lin. G., eq. error var.:	$X_j := \sum_{k\in\mathbf{PA}_j} \beta_{jk} X_k + N_j$	linear	✓	Prop. 7.5

表7.1：高斯噪声下已知可辨识性结果概览。对于非高斯噪声的可辨识性结果同样存在，但它们更为技术性。

证明如果分布是由线性高斯 SCM 诱导的，例如，我们不一定能恢复正确的图。然而，事实证明这种情况在以下意义上是例外的。对于几乎所有其他函数和分布的组合，我们都能获得可识别性。所有不可识别的情况都已被刻画 [Zhang and Hyvärinen, 2009, Peters et al., 2014]。另一个不同于线性高斯情形的不可识别示例见图4.2右侧图。其细节可见于 Peters et al. [2014, Example 25]。表7.1展示了一些已知的可识别性结果。

再次提一下，ANM框架有几种扩展。例如，Zhang和Hyvärinen [2009]允许对变量进行后非线性变换，而Peters等人[2011a]则考虑了离散变量的ANM。

通常，非线性 ANM 在边缘化下并不封闭。也就是说，如果 $P_{X,Y,Z}$ 允许从 X 到 Y 以及从 Y 到 Z 的 ANM，则 $P_{X,Z}$ 不一定允许从 X 到 Z 的 ANM。这可能限制 ANM 在实践中的适用性，因为人们可能无法观察到因果路径上的中间变量。对于物理实验，可以认为每一种影响都是通过无限多个中间变量传播的。因此，不存在直接或间接效应的绝对概念（相反，它必须始终相对于观测集而言）。在这个意义上，ANM 只能被视为良好的近似。

在接下来的三个小节中，我们将更详细地探讨三个具体的可识别示例：误差方差相等的线性高斯情形（第7.1.3节）、线性非高斯情形（第7.1.4节）以及非线性高斯情形（第7.1.5节）。尽管存在更一般的结果[Peters等人，2014]，但我们专注于这两个例子，因为它们能容易地给出精确条件。我们省略证明，集中于陈述。大部分证明可以基于Peters等人[2011b]中发展的技术。这些技术使得我们在第4章中发展的许多双变量可识别性结果能够推广到多变量环境。

7.1.3 具有相等误差方差的线性高斯模型

还有另一种偏离线性高斯结构方程模型（SEMs）的方式，使得图变得可识别。Peters 和 Bühlmann [2014] 显示，限制噪声变量具有相同的方差足以恢复图结构。证明可在 Peters 和 Bühlmann [2014] 中找到。

命题 7.5（等误差方差下的可识别性）*Consider an SCM with graph $\mathcal{G}_0$ and assignments*

$$X_j := \sum_{k \in \mathbf{PA}_j^{\mathcal{G}_0}} \beta_{jk} X_k + N_j, \qquad j = 1, \ldots, d,$$

where all N_j are i.i.d. and follow a Gaussian distribution. In particular, the noise variance σ^2 does not depend on j. Additionally, for each $j \in \{1, \ldots, p\}$ we require $\beta_{jk} \neq 0$ for all $k \in \mathrm{PA}_j^{\mathcal{G}_0}$. Then, the graph $\mathcal{G}_0$ is identifiable from the joint distribution.

为了估计系数 β_{jk} (，从而估计图结构)，Peters 和 Bühlmann [2014] 提出使用基于贝叶斯信息准则（BIC）的惩罚最大似然评分；另见第7.2.2节，以及在DAG空间中的贪婪搜索算法。重新缩放变量会改变误差项的方差。因此，在许多应用中，模型（7.2）无法合理地应用。然而，BIC允许我们将该方法的评分与使用更多参数且不假设误差方差相等的线性高斯SCM的评分进行比较。

7.1.4 线性非高斯无环模型

Shimizu等人[2006]利用独立成分分析(ICA)[Comon, 1994, 定理11]证明了以下陈述，而该定理本身又是通过Darmois-Skitovič定理证明的。

定理 7.6（LiNGAMs 的可识别性）*Consider an SCM with graph $\mathcal{G}_0$ and assignments*

$$X_j := \sum_{k \in \mathbf{PA}_j^{\mathcal{G}_0}} \beta_{jk} X_k + N_j, \qquad j = 1, \ldots, d, \tag{7.2}$$

where all N_j are jointly independent and non-Gaussian distributed with strictly

positive density.[3] *Additionally, for each* $j \in \{1,\dots,p\}$*, we require* $\beta_{jk} \neq 0$ *for all* $k \in \mathrm{PA}_j^{\mathcal{G}_0}$*. Then, the graph* $\mathcal{G}_0$ *is identifiable from the joint distribution.*

作者将该模型称为LiNGAM。如第4.1.3节所述，定理7.6有一个替代证明：Peters等人[2014]中的定理28将诸如定理4.2的双变量可识别性结果扩展到多变量情况。这一技巧也用于非线性加性模型（通过扩展定理4.5）。

7.1.5 非线性高斯加性噪声模型

我们已经看到，如果赋值是线性的且噪声变量是非高斯的，ANM 的图结构就变得可识别。另外，我们也可以利用非线性。结果在高斯噪声下最容易表述：

定理7.7（非线性高斯ANM的可识别性）

(i) Let $P_{\mathbf{X}} = P_{X_1,\dots,X_d}$ *be induced by an SCM with*

$$X_j := f_j(\mathbf{PA}_j) + N_j,$$

with normally distributed noise variables $N_j \sim \mathcal{N}(0, \sigma_j^2)$ *and three times differentiable functions* f_j *that are not linear in any component in the following sense. Denote the parents* PA_j *of* X_j *by* $X_{k_1},\dots,X_{k_\ell}$*, then the function* $f_j(x_{k_1},\dots,x_{k_{a-1}},\cdot,x_{k_{a+1}},\dots,x_{k_\ell})$ *is assumed to be nonlinear for all* a *and some* $x_{k_1},\dots,x_{k_{a-1}},x_{k_{a+1}},\dots,x_{k_\ell} \in \mathbb{R}^{\ell-1}$*.*

(ii) As a special case, let $P_{\mathbf{X}} = P_{X_1,\dots,X_d}$ *be induced by an SCM with*

$$X_j := \sum_{k \in \mathbf{PA}_j} f_{j,k}(X_k) + N_j, \tag{7.3}$$

with normally distributed noise variables $N_j \sim \mathcal{N}(0, \sigma_j^2)$ *and three times differentiable, nonlinear functions* $f_{j,k}$*. This model is known as a causal additive model (CAM).*

In both cases (i) and (ii), we can identify the corresponding graph $\mathcal{G}_0$ *from the distribution* $P_{\mathbf{X}}$*. The statements remain true if the noise distributions for source nodes, that is, nodes without parents, are allowed to have a non-Gaussian density with full support on the real line* $\mathbb{R}$ *(the proof remains identical).*

该证明可在Peters等人[2014，推论31]中找到。

[3] The condition of a strictly positive density can be weakened (see details of the proof of ICA), but it is certainly necessary to assume that the noise variables are non-degenerate, for example.

7.1.6 观察与实验数据

我们在第6.3节已经看到，了解因果关系有助于在基础分布发生变化时改进预测。现在我们将反过来思考这个想法，并展示如何通过在不同环境中观察系统来学习因果关系。因此，我们转向以下设置，在其中我们观察来自不同环境{v*}的数据。相应的模型为

$$\mathbf{X}^e = (X_1^e, \ldots, X_d^e) \sim P^e,$$

其中每个变量 X_j^e 表示相同的（物理）量，以环境 $e \in \mathcal{E}$ 测量。我们将讨论不同环境中的变量 X_j，这是一种轻微的记法滥用。

已知干预目标 第一种方法假设不同环境源于不同的干预设置。在干预目标 $\mathcal{I}^e \subseteq \{1, \ldots, d\}$ 已知的情况下，已有几种方法被提出。例如，Tian 和 Pearl [2001] 以及 Hauser 和 Bühlmann [2012] 分别假设忠实性并考虑机制变化和随机干预。他们定义并刻画了图的干预等价类：即能够解释给定分布的图类。对于机制变化，例如，我们可以在模型中包含一个干预节点，其子节点是被干预的变量。这样，我们增加了 v 结构的数量，并且如果两个图具有相同的骨架和 v 结构，且被干预的节点具有相同的父节点，则它们（相对于给定分布）成为干预等价的[参见 Tian and Pearl, 2001, Theorem 2]。Eberhardt 等人 [2010] 允许即使存在循环时也进行硬干预和随机干预。

Hyttinen等人[2012]分析了干预条件下图的可识别性。Eberhardt等人[2005]和Hauser与Bühlmann[2014]研究了在最坏情况下需要多少次干预实验才能识别图。

不同环境 现在我们转向一个略有不同的设定，其中我们并不试图学习整个因果结构。相反，我们考虑一个目标变量 Y 以及一组 d 预测变量 X，并尝试学习哪些预测变量是 Y 的因果父节点。X 和 Y 都在不同的环境 $e \in \mathcal{E}$ (中被观测到，这些环境可能是目标未知的干预设定)。也就是说，我们有

$$(\mathbf{X}^e, Y^e) \sim P_{\mathbf{X}^e, Y^e} =: P^e$$

对于 $e \in \mathcal{E}$。关键假设是存在一个未知集合 $\text{PA}_Y \subseteq \{1,\dots,d\}$ (，人们可以将其视为 Y) 的直接原因，使得在给定 PA_Y 的条件 Y 在所有环境中保持不变，也就是说，对于所有 $e, f \in \mathcal{E}$，我们有

$$P_{Y^e \mid \mathbf{PA}_Y^e} = P_{Y^f \mid \mathbf{PA}_Y^f}.$$

如果分布是由潜在的SCM诱导的，且不同环境对应于不同的干预分布，其中Y未被干预，则该假设得到满足[Peters等，2016]（参见代码片段7.11的示例）。尽管如此，该设定更为一般，环境无需对应于干预；甚至不需要潜在的SCM。可以考虑所有变量集$S \subseteq \{1,\dots,d\}$的集合$\mathcal{S}$，这些变量集导致“不变预测”，即对于所有$e, f \in \mathcal{E}$和所有$S \in \mathcal{S}$，我们有

$$P_{Y^e \mid S^e} = P_{Y^f \mid S^f}. \tag{7.4}$$

这里，$Y^e \mid S^e$ 是 $Y^e \mid \mathrm{X}_S^e$ 的简写。不难看出（问题7.15），*all* 这些集合 $S \in \mathcal{S}$ 中出现的变量必定是 Y 的直接原因：

$$\bigcap_{S \in \mathcal{S}} S \subseteq \mathbf{PA}_Y, \tag{7.5}$$

其中我们将空索引集上的交集定义为空集。Peters等人[2016]将（7.5）式的左侧视为PA{v*}的估计。（7.5）式随后保证了该方法输出中包含的任何变量确实在PA{v*}中。在SCMs和干预的特殊情况下，存在充分条件[Peters等人，2016]，在这些条件下PA{v*}变得可识别，换言之，（7.5）式是一个等式。有趣的是，我们在第7.2.5节中提出的方法能够识别数据是否来自这种可识别的情况，而不需要假设它。

Tian和Pearl [2001]也探讨了未知干预目标的可识别性问题。他们没有指定目标变量，并侧重于边际分布的变化而非条件分布。

7.2 结构识别方法

我们已经看到了一些导致因果结构（部分）可识别性的假设。本节的目的在于展示如何利用这些假设，从有限的数据量中提供底层图的估计量（参见图7.1中的两个示例）。我们概述了方法，并

尝试聚焦于他们的想法。存在大量的方法，我们相信未来的研究需要展示这些方法中哪些在实际应用中最有用。尽管如此，我们仍试图强调一些方法潜在的问题和最关键的假设。虽然有些论文研究了所提出方法论的一致性，但我们省略了大多数这些结果，仅呈现思想。算法实现的微妙之处也不再讨论，我们建议感兴趣的读者参考我们提供的参考文献。Kalisch等人[2012]维护了用于R[R Core Team, 2016]的软件包`pcalg`，其中不仅包含PC（由Peter Spirtes和Clark Glymour发明）算法的代码（见第7.2.1节），还包含许多所述方法的代码。

在提供有关现有方法的更多细节之前，我们想先补充两点说明：(1) 尽管已有若干模拟研究，但损失函数这一问题却鲜有关注。给定真实的底层因果结构，估计出的因果图究竟有多“好”？ 在实践中，人们常使用结构汉明距离的变体[Acid and de Campos, 2003, Tsamardinos et al., 2006]，即计算错误设定的边的数量。作为一种替代方案，Peters and Bühlmann [2015] 建议根据图预测干预分布的能力来评估图。(2) 我们所介绍的一些方法假设结构赋值(6.1)以及相应的函数，特别是f_j，是简单的。通常，这些方法不仅提供因果结构的估计，还提供相应赋值的估计，而这些赋值通常也可用于计算残差。原则上，在此模型下，我们可以检验噪声变量相互独立这一强假设(定义3.1)，例如，通过应用互独立性检验[e.g., Pfister et al., 2017]；关于此类程序的统计细微之处，请参见第4.2.1节。

7.2.1 基于独立性的方法

基于独立性的方法，如归纳因果（IC）算法、SGS（以发明者Spirtes、Glymour和Scheines命名）算法以及PC算法，均假设分布忠实于潜在的DAG。这使得马尔可夫等价类，即相应的CPDAG，可识别（见第7.1.1节）。图中的d-分离与$P_{\mathbf{X}}$中的条件独立之间存在一一对应关系。因此，任何关于d-分离陈述的查询都可以通过检查相应的条件独立性测试来回答。我们首先假设有一个预言机为我们提供条件独立问题的正确答案，并在“条件独立性测试”段落中讨论一些有限样本问题。

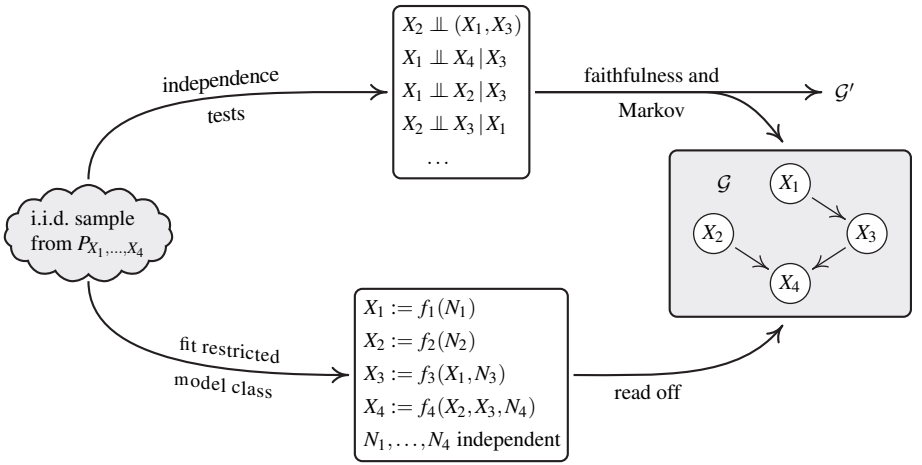

图7.1：该图总结了识别因果结构的两种方法。基于独立性的方法（上图）检验数据中的条件独立性；这些属性通过马尔可夫条件和忠实性关联到图结构。通常，图不是唯一可识别的；因此该方法可能会输出不同的图 {v*} 和 {v*}。或者，可以限制模型类别并直接拟合SCM（下图）。

骨架估计 大多数基于独立性的方法首先估计骨架，即无向边，然后再尽可能多地定向边。对于骨架搜索，以下引理是有用的[参见 Verma 和 Pearl，1991，引理1]。

引理 7.8 *The following two statements hold.*

(i) Two nodes X, Y in a DAG $(\mathrm{X}, \mathcal{E})$ are adjacent if and only if they cannot be d-separated by any subset $S \subseteq \mathrm{V} \setminus \{X, Y\}$. (ii) If two nodes X, Y in a DAG $(\mathrm{X}, \mathcal{E})$ are not adjacent, then they are d-separated by either PA_X or PA_Y.

利用引理7.8(i)，我们得知，如果两个变量始终相关，无论以其他哪些变量为条件，这两个变量必定相邻。这一结果在IC算法[Pearl, 2009]和SGS算法[Spirtes等，2000]中均有应用。对于每一对节点(X, Y)，这些方法会遍历所有可能的变量子集$\mathrm{A} \subseteq \mathrm{X} \setminus \{X, Y\}$，该子集既不包含$X$也不包含$Y$，并检查在给定A的情况下，$X$和$Y$是否被$d$-分离。经过所有这些测试后，$X$和$Y$相邻当且仅当不存在任何集合A能使$X$和$Y$被$d$-分离。

通过搜索所有可能的子集 A 似乎并非最优选择，特别是在图较为稀疏的情况下。PC 算法 [Spirtes 等人，2000] 从一个完全连接的无向图开始，逐步增加条件集 A 的大小，初始时 #A = 0。在第 k 次迭代中，它考虑大小为 #A = k 的集合 A，利用以下巧妙技巧：为了检验 X 和 Y 是否能被 d 分离，只需遍历那些作为 X 的邻居子集或 Y 的邻居子集的集合 A；这一思路基于引理 7.8(ii)，显然能提升计算效率，尤其在稀疏图中更为明显。

边方向 引理6.25表明，我们应当能够确定图中非道德性（或v-结构）的方向。如果在所获得的骨架中，两个节点并非直接相连，则存在一个集合，d将这些节点分离。假设骨架中包含结构$X - Z - Y$，且X与Y之间无直接边缘；进一步，令A为一个集合，d将X与Y分开。结构$X - Z - Y$是一种非道德性，因此当且仅当$Z \notin$ A时，可以定向为$X \to Z \leftarrow Y$。在非道德性定向之后，为了例如避免形成循环，我们或许还能确定一些额外边的方向。有一套这样的定向规则已被证明是完备的，被称为Meek的定向规则[Meek, 1995]。

可满足性方法 刚刚描述的图形化方法的一种替代方案是将因果学习表述为可满足性（SAT）问题[Triantafillou et al., 2010]。首先，人们将图形关系表述为布尔变量，例如 A：$=$ *“There is a direct edge from X to Y.”* 随后，非平凡的部分是将独立性陈述（我们仍然假设它们由独立性预言机提供），作为 d-分离陈述，翻译为涉及布尔变量以及运算符“与”和“或”的“公式”。SAT问题接着询问，我们是否可以为每个布尔变量赋予“真”或“假”的值，以使整体公式为真。SAT求解器不仅检查是否如此，还向我们提供信息，即在所有使整体公式为真的赋值中，某些变量是否总是被赋予相同的值。例如，d-分离陈述可能由对应不同赋值的不同图结构满足，但如果在所有这样的赋值中，上面的布尔变量 A 都取值为“真”，我们可以推断在底层图中，X 必须是 Y 的父节点。尽管布尔SAT问题已知是非确定性多项式时间（NP）完全的[Cook, 1971, Levin, 1973]，也就是说，它是NP且NP困难的，但仍存在启发式算法可以求解实例

针对大规模问题，涉及数百万变量的情况。因果学习中的SAT方法使我们能够将特定陈述作为祖先关系进行查询，而不是估计整个图。它们允许我们融入不同类型的先验知识，并且，如果我们认为某些（统计）发现相互矛盾，我们还可以对独立性约束赋予权重。这些方法已被扩展到处理循环、潜在变量以及重叠数据集的情况[Hyttinen等，2013，Triantafillou和Tsamardinos，2015]。

条件独立性检验 在前三段中，我们假设存在一个独立性预言机，它告诉我们分布中是否存在特定的（条件）独立性。然而，在实践中，我们必须从有限的数据量中推断出这一陈述。这带来了两个主要挑战：（1）所有基于条件独立性检验的因果发现方法都从依赖关系和独立性中得出结论。然而，在实践中，人们最常使用统计显著性检验，这些检验本质上是不对称的。因此，人们通常忘记了显著性水平的原始含义，并将其视为一个调参参数。此外，由于有限样本，检验结果甚至可能相互矛盾，即在某种意义上不存在能够编码推断出的条件独立性精确集合的图结构。（2）尽管最近有一些关于基于核的检验的工作[Fukumizu et al., 2008, Tillman et al., 2009, Zhang et al., 2011]，但非参数条件独立性检验在有限数据量下难以进行。因此，人们通常将自己限制在可能的依赖关系的一个子类中，我们现在简要回顾其中的一些。

如果假设变量服从高斯分布，我们可以检验偏相关是否为零（见附录A.1和A.2）。在忠诚性假设下，底层DAG的马尔可夫等价类变得可识别（引理7.2），并且实际上，在高斯设定中，带有偏相关消失检验的PC算法为正确的CPDAG提供了一致估计量[Kalisch and Bühlmann, 2007]。额外假设一个称为强忠诚性的条件[Zhang and Spirtes, 2003, Uhler et al., 2013]，甚至可以得到一致一致性[Kalisch and Bühlmann, 2007]；另见Robins et al. [2003]中的讨论。

非参数条件独立性检验在理论和实践中都是一个难题。对于非高斯分布，偏相关为零既不是条件独立的必要条件，也不是充分条件，如下例所示。

示例 7.9（条件独立与偏相关）

(i) 如果分布 {v*} 由SCM蕴含

$$Z := N_Z, \quad X := Z^2 + N_X, \quad Y := Z^2 + N_Y,$$

其中 $N_X, N_Y, N_Z \overset{\text{iid}}{\sim} \mathcal{N}(0,1)$，它满足

$$X \perp\!\!\!\perp Y \,|\, Z \qquad \text{and} \qquad \rho_{X,Y|Z} \neq 0.$$

偏相关系数 $\rho_{X,Y|Z}$ 等于 $X - \alpha Z$ 和 $Y - \beta Z$ 的相关性，其中 α 和 β 分别是将 X 和 Y 对 Z 进行回归时的回归系数。在本例中，$\alpha = \beta = 0$，因为 X 和 Y 与 Z 不相关。

(ii) SCM 所蕴含的分布 $P_{X,Y,Z}$

$$Z := N_Z, \quad X := Z + N_X, \quad Y := Z + N_Y,$$

其中 $(N_X, N_Y) \perp\!\!\!\perp N_Z$ 和 (N_X, N_Y) 不相关但不独立，满足

$$X \not\perp\!\!\!\perp Y \,|\, Z \qquad \text{and} \qquad \rho_{X,Y|Z} = 0$$

由于此处，$\rho_{X,Y|Z}$ 是 N_X 与 N_Y 之间的相关性。

因此，偏相关消失并不意味着条件独立，也不被条件独立所蕴含。

□

以下用于检验在给定 Z 时 X 和 Y 是否条件独立的流程，为偏相关提供了一种自然的非线性扩展 [例如，Ramsey，2014]：(1) 对 X 关于 Z 进行（非线性）回归，并检验残差是否与 Y 独立；(2) 对 Y 关于 Z 进行（非线性）回归，并检验残差是否与 X 独立；(3) 如果这两个独立性中的某一个成立，则得出结论 $X \perp\!\!\!\perp Y \,|\, Z$。在 ANMs 的情况下，这似乎是正确的检验；见第 7.1.2 节。例如，对于三个变量，我们有以下结果。

命题 7.10 *Consider a distribution $P_{X,Y,Z}$ induced by an ANM (Definition 7.3) with all variables having strictly positive densities. If X and Y are d-separated given Z, then the procedure just described outputs the corresponding conditional independence in the sense that either $X - \mathbb{E}[X|Z]$ is independent of Y or $Y - \mathbb{E}[Y|Z]$ is independent of X.*

证明。假设 $X := h(Z) + N_X$ 且 $Y := f(Z) + N_Y$，其中 Z、N_X 和 N_Y 相互独立。那么，$X - \mathbb{E}[X|Z] = N_X$ 与 Y 独立。该陈述对其他可能的结构类似成立，例如，$X \to Z \to Y$ 或 $X \leftarrow Z \leftarrow Y$。□

该命题表明（在总体意义上），所描述的检验适用于具有三个变量的ANM。然而，考虑四个变量X, Y, Z, V可能已经导致问题。显然，图 $X \leftarrow Z \to W \to Y$和$X \to Z \to W \to Y$是马尔可夫等价的。但是，尽管检验对第一个图输出$X \perp\!\!\!\perp Y \,|\, Z$，对于第二个图却没有这样的保证。因此，上述对随机变量之间依赖模型的限制——可用于构建可行的条件独立检验——导致马尔可夫等价类内的图受到非对称处理。这种效应对于许多其他类型的条件独立检验方法可能也是如此。这种非对称性不一定需要是一个缺点，因为正如我们所看到的，受限的函数类可能导致马尔可夫等价类内的可识别性（见第7.1节）。不过，这确实需要加以考虑。

7.2.2 基于评分的方法

在前一节中，我们直接利用独立性陈述来推断图结构。另一种方法是，我们可以测试不同图结构对数据的拟合能力。其基本原理是，编码了错误条件独立性的图结构，例如，将会导致模型拟合效果不佳。尽管基于得分的因果学习方法之根源可能更为久远，我们主要参考Geiger和Heckerman [1994a]、Heckerman等人 [1999]、Chickering [2002]及其中的参考文献。最大-最小爬山算法[Tsamardinos等人，2006]结合了基于得分和基于独立性的技术。

给定来自变量向量 $\mathbf{X}$ 的数据 $\mathcal{D} = (\mathbf{X}^1, \ldots, \mathbf{X}^n)$，即一个包含 n 个独立同分布观测的样本，其思路是为每个图 $\mathcal{G}$ 分配一个得分 $S(\mathcal{D}, \mathcal{G})$，并在 DAG 空间中搜索以找到得分最高的图：

$$\hat{\mathcal{G}} := \underset{\mathcal{G} \text{ DAG over } \mathbf{X}}{\operatorname{argmax}} \; S(\mathcal{D}, \mathcal{G}). \tag{7.6}$$

有几种可能性来定义这样的评分函数S。通常假设一个参数模型（例如，线性高斯方程或多项式分布），这引入了一组参数$\theta \in \Theta$。

(惩罚)似然 对于每个图，我们可以考虑θ的最大似然估计量$\hat{\theta}$，然后通过BIC定义评分函数

$$S(\mathcal{D},\mathcal{G}) = \log p(\mathcal{D}|\hat{\theta},\mathcal{G}) - \frac{\#\text{parameters}}{2}\log n, \tag{7.7}$$

其中 $\log p(\mathcal{D}|\hat{\theta},\mathcal{G})$ 是对数似然，n 是样本量。输出具有最大（惩罚）似然的图的估计量通常具有一致性。这源于 BIC 的一致性 [Haughton, 1988] 以及模型类的可识别性。然而，为了保证收敛速度，通常依赖于“可识别度” [例如，Bühlmann et al., 2014]。在实践中，在所有可能的图中找到最佳评分的图可能不可行，需要对图空间进行搜索技术（例如，参见“贪婪搜索技术”段落）。也可以使用不同于 BIC 的正则化。例如，Roos et al. [2008] 将他们的评分基于最小描述长度原则 [Grünwald, 2007]。利用 Haughton [1988] 的工作，Chickering [2002] 讨论了 BIC 方法如何与我们接下来讨论的贝叶斯公式相关联。

贝叶斯评分函数我们分别针对DAG和参数定义先验分布$p_{pr}(\mathcal{G})$和$p_{pr}(\theta)$，并将对数后验视为评分函数（注意$p(\mathcal{D})$对于所有DAG是常数）：

$$S(\mathcal{D},\mathcal{G}) := \log p(\mathcal{G}\,|\,\mathcal{D}) \propto \log p_{pr}(\mathcal{G}) + \log p(\mathcal{D}\,|\,\mathcal{G}),$$

其中 $p(\mathcal{D}|\mathcal{G})$ 是边际似然

$$p(\mathcal{D}|\mathcal{G}) = \int_{\theta\in\Theta} p(\mathcal{D}|\mathcal{G},\theta)\, p_{pr}(\theta\,|\,\mathcal{G})\, d\theta.$$

这里，由公式（7.6）得到的估计量$\hat{\mathcal{G}}$ 是后验分布的众数，通常称为最大后验（MAP）估计量。另一种方法是，可以输出DAG上的完整后验分布，并且原则上甚至可以获取更详细的信息。例如，可以对所有图进行平均，以获得特定边存在的后验概率。

例如，考虑仅取有限多个值的随机变量。对于给定的结构 $\mathcal{G}$，可以假设对于每个父配置，随机变量 X_j 的概率分布遵循多项分布。如果我们对其参数施加 Dirichlet 先验（连同对参数独立性和模块性的一些进一步条件），这将导致贝叶斯 Dirichlet（BD）评分 [Geiger and Heckerman, 1994b]。

在参数模型的情况下，如果对于每个参数 θ_1 都存在一个对应的参数 θ_2，使得从图 $\mathcal{G}_1$ 结合参数 θ_1 得到的分布与从图 $\mathcal{G}_2$ 结合参数 θ_2 得到的分布相同，反之亦然，那么我们称这两个图 $\mathcal{G}_1$ 和 $\mathcal{G}_2$ 是分布等价的。可以证明（见习题7.12），例如在线性高斯情况下，两个图是分布等价的当且仅当它们是马尔可夫等价的。因此，有人认为对于马尔可夫等价的图 $\mathcal{G}_1$ 和 $\mathcal{G}_2$，$p(\mathcal{D}|\mathcal{G}_1)$ 和 $p(\mathcal{D}|\mathcal{G}_2)$ 应该是相同的。BD评分可以调整以满足这一性质。它通常被称为贝叶斯狄利克雷等价（BDe）评分[Geiger and Heckerman, 1994b]。Buntine [1991] 提出了这个评分的一个特定版本，其超参数更少。

贪婪搜索技术 所有DAG的搜索空间随着变量数量呈超指数增长[例如，Chickering，2002]，对于2、3、4和10个变量，DAG的数量分别为3、25、543和4175098976430598143（见表B.1）。因此，通过搜索所有图来求解方程(7.6)往往不可行。相反，可以采用贪婪搜索算法来求解(7.6)。在每一步中，都有一个候选图及其一组邻接图。对于所有这些邻接图，计算得分，并将得分最高的图视为新的候选图。如果没有任何邻接图获得更好的得分，搜索过程终止（此时并不知道是否仅得到了局部最优解）。显然，因此必须定义邻域关系。从图$\mathcal{G}$出发，我们可以将所有可以通过删除、添加或反转一条边而得到的图定义为$\mathcal{G}$的邻接图，例如。

在线性高斯结构因果模型（SCM）中，无法区分马尔可夫等价图。结果表明，此时将搜索空间改为马尔可夫等价类而非有向无环图（DAGs）是有益的。贪婪等价搜索（GES）[Chickering, 2002]优化了BIC准则（7.7），并从空图开始。该算法包含两个阶段：第一阶段，不断添加边直至达到局部最大值；第二阶段，移除边直至达到局部最大值，随后算法输出该结果。

精确方法 一般来说，寻找最优评分的有向无环图是NP难问题[Chickering, 1996]，但仍有许多有趣的研究尝试扩大精确方法的适用范围。在这里，“精确”意味着它们旨在为给定的有限数据集找到（其中之一）最佳评分的图。贪婪搜索技术通常是启发式的，并且仅在无限数据极限情况下才具有保证——如果有的话。

一个研究方向基于动态规划 [Silander and Mylly-mak, 2006, Koivisto and Sood, 2004, Koivisto, 2006]。这些方法利用了实践中使用的许多评分的可分解性：由于马尔可夫因式分解，对于 $\mathcal{D} = (\mathrm{X}^1, \ldots, \mathrm{X}^n)$，我们有

$$\log p(\mathcal{D}|\hat{\theta}, \mathcal{G}) = \sum_{j=1}^{d} \sum_{i=1}^{n} \log p(X_j^i | X^i_{\mathbf{PA}_j^{\mathcal{G}}}, \hat{\theta}),$$

这是d个“局部”得分的和。基于动态规划的方法利用了这一可分解性，尽管其复杂度呈指数级，它们仍能为≥个变量找到最佳评分图，即使不限制父节点的数量。考虑到在这个变量数量下不同有向无环图的数量极其庞大（见表B.1），这是一个显著的结果。

整数线性规划（ILP）框架不仅假设可分解性，还假设评分函数对马尔可夫等价图给出相同的分数。其思想是将图结构表示为向量，使得评分函数在这种向量表示中成为仿射函数。Studený 和 Haws [2014] 描述了 Hemmecke 等人 [2012] 如何将他们的表示基于特征 imsets，而 Jaakkola 等人 [2010] 和 Cussens [2011] 则使用（指数级长的）零一编码来指示节点之间的父子关系，并利用 De Campos 和 Ji [2011] 的工作来缩小搜索空间。将问题表述为 ILP 问题后，问题仍然是 NP 难的，但现在可以使用现成的 ILP 方法。限制父节点的数量带来了进一步的进展，例如，在“系谱学习”中，每个节点最多有两个父节点 [Sheehan 等人，2014]。

7.2.3 加性噪声模型

可以使用基于分数的方法结合贪婪搜索技术来学习ANMs。这已被提出用于具有等误差方差的线性高斯模型（第7.1.3节）或非线性高斯ANMs（第7.1.5节）[参见Peters和Bühlmann，2014年，Bühlmann等人，2014年]。例如，在非线性高斯情况下，我们可以类比双变量情况（参见方程(4.18)和(4.19)）进行。对于给定的图结构$\mathcal{G}$，我们对每个变量关于其父节点进行回归并获得分数

$$\log p(\mathcal{D}|\mathcal{G}) = \sum_{j=1}^{d} -\log \widehat{\mathrm{var}}[R_j];$$

这里，$\widehat{\text{var}}[R_j]$ 是从变量 X_j 对其父节点回归得到的残差 R_j 的经验方差。直观上，模型对数据的拟合越好，残差的方差就越小，因此我们的得分就越大。形式上，该过程是最大似然的一个实例，并且可以证明是一致的 [Bühlmann et al., 2014]。在计算上，我们可以再次利用得分在不同节点上可分解的性质。当计算一个仅改变一个变量的父集的相邻图的得分时，我们只需更新相应的求和项。如果噪声不能假定为具有高斯分布，例如，可以估计噪声分布 [Nowzohour and Bühlmann, 2016] 并获得类似熵的得分。

另外，可以通过独立性检验以迭代方式估计结构。Mooij等人[2009]和Peters等人[2014]提出了一种后续独立性检验的回归方法（RESIT）。该方法基于噪声变量与所有前驱变量独立的性质。对于线性非高斯模型（第7.1.4节），Shimizu等人[2006]提供了一种基于ICA的实用方法[Comon, 1994, Hyvärinen等人, 2001]，可应用于有限数据量。随后，Shimizu等人[2011]提出了该方法的改进版本。

7.2.4 已知因果顺序

通常很难找到潜在因果模型的因果排序（见附录B）。然而，给定因果排序后，估计图就简化为“经典”变量选择问题。例如，假设

$$
\begin{aligned}
X &:= N_X \\
Y &:= f(X, N_Y) \\
Z &:= g(X, Y, N_Z)
\end{aligned}
$$

在f, g, N_X, N_Y, N_Z未知的情况下。判断f是否依赖于X，以及g是否依赖于X和/或Y (参见Remark 6.6中的结构最小性假设)，这在“传统”统计学中是一个经过充分研究的重要性问题。可以使用标准方法，特别是在做出进一步的结构假设时，例如线性性[例如，Hastie et al., 2009, Bühlmann and van de Geer, 2011]。这一观察此前已有提出[例如，Teyssier and Koller, 2005, Shojaie and Michailidis, 2010]，并且有人建议，与其在有向无环图的空间中搜索，不如先搜索因果顺序，然后进行变量选择[例如，Teyssier and Koller, 2005, Bühlmann et al., 2014]。

7.2.5 观测与实验数据

第7.1.6节描述了当我们观察系统在不同条件（“环境”）下的情况时，因果结构如何变得可识别。现在我们讨论如何在实践中利用这些结果，即仅给定有限数量的数据。因此，让我们假设我们为每个环境$e \in \mathcal{E}$获得一个样本$\mathrm{X}^e_{n_e}$；也就是说，对于每个环境，我们观察到n^e个独立同分布的数据点。

已知干预目标 在此，每个设置对应一个干预实验，并且我们额外了解干预目标 $\mathcal{I}^e \subseteq \{1, \dots, p\}$。Cooper和Yoo [1999]将干预效应作为机制变化纳入贝叶斯框架。对于完美干预，Hauser和Bühlmann [2015]考虑线性高斯SCM，并提出贪心干预等价搜索（GIES），这是我们在第7.2.2节简要描述的GES算法的修改版本。

有时，人们无法在每次实验中测量所有变量（即使所有实验都是观察性的，这种情况也可能发生），但仍希望结合可用数据中的信息；这一问题已通过基于SAT的方法得到解决[参见，例如，Triantafillou and Tsamardinos, 2015, Tillman and Eberhardt, 2014, 及其中的参考文献]。

未知干预目标 Eaton 和 Murphy [2007] 不假设不同干预的目标是已知的。相反，他们为每个环境 $e \in \mathcal{E}$ 引入一个没有入边的干预节点 I_e（参见第95页的“干预变量”）；对于每个数据点，只有一个干预节点是活跃的。然后，他们对具有 $d + \#\mathcal{E}$ 个变量的扩大模型应用标准方法，并满足干预节点没有任何父节点的约束。

Tian和Pearl [2001] 提出检验不同设置下边际分布是否变化，并利用这一信息推断图结构的部分内容。他们甚至将此方法与基于独立性的方法相结合。

不同环境 在第 7.1.6 节中，我们还考虑了在 d 个预测变量集合 X 中估计目标变量 Y 的因果父变量的问题。因此，我们将集合 $\mathcal{S}$ 定义为所有满足不变预测的集合 $S \subseteq \{1, \dots, d\}$ 的集合，即对于这些集合，$P_{Y^e \mid S^e}$ 在所有环境 $e \in \mathcal{E}$ 下保持不变；参见 (7.4)。在实践中，我们可以在水平 α 上检验不变预测的假设，并将所有通过检验的集合 S 收集为集合 $\mathcal{S}$ 的估计$\hat{\mathcal{S}}$。因为真实的父变量集合 $\mathrm{PA}_Y \subseteq \mathrm{X}$ 是$\hat{\mathcal{S}}$ 中的一个成员，且具有高

概率 $(1-\alpha)$，我们得到覆盖声明

$$\bigcap_{S\in\hat{\mathcal{S}}} S \subseteq \mathbf{PA}_Y \tag{7.8}$$

以高概率 $(1-\alpha)$。(7.8) 式的左侧是一种称为“不变因果预测”的方法的输出 [Peters et al., 2016]。代码片段 7.11 展示了一个示例，其中环境对应于不同的干预（这不是该方法所要求的）。为了在 (7.8) 的意义上获得正确的覆盖，只需对给定 PA_Y 的条件 Y 建模；特别地，不需要对 d 预测变量 X 的分布做任何假设。这与 Eaton 和 Murphy [2007] 提出的方法（见“未知干预目标”段落）不同，后者还试图估计完整的因果结构。

代码片段 7.11 以下代码展示了在两个环境中的因果系统示例。在真实的底层结构中，X_1 和 X_2 导致 Y，而 Y 又导致 X_3。在合并数据上的线性模型（第13行）中，所有变量 X_1、X_2 和 X_3 都极为显著，因为它们都是 Y 的良好预测因子。然而，这样的模型并不具有不变性。在两个环境中，从 Y 对 X_1、X_2、X_3 进行回归分别得到的系数为 -0.15、1.09、-0.39 和 -0.32、1.62、-0.54。不变因果预测方法仅输出 Y 的因果父节点，即 X_1 和 X_2。在这个例子中，$\{1,2\}$ 是唯一产生不变模型的集合，即 $\hat{\mathcal{S}} = \{\{1,2\}\}$。

```
1  library(InvariantCausalPrediction)
2  #
3  # generate data from two environments
4  env <- c(rep(1,400),rep(2,700))
5  n <- length(env)
6  set.seed(1)
7  X1 <- rnorm(n)
8  X2 <- 1*X1 + c(rep(0.1,400), rep(1.0,700))*rnorm(n)
9  Y <- -0.7*X1 + 0.6*X2 + 0.1*rnorm(n)
10 X3 <- c(rep(-2,400),rep(-1,700))*Y + 2.5*X2 + 0.1*rnorm(n)
11 #
12 summary(lm(Y~-1+X1+X2+X3))
13 # Coefficients:
14 # ----Estimate Std.Error t.val. Pr(>|t|)
15 # X1 -0.396212 0.008667 -45.71 <2e-16 ***
16 # X2 +1.381497 0.021377 +64.63 <2e-16 ***
17 # X3 -0.410647 0.011152 -36.82 <2e-16 ***
18 #
19 ICP(cbind(X1,X2,X3),Y,env)
20 #lower bd upper bd p-value
21 # X1 -0.71 -0.68 3.7e-06 ***
22 # X2 +0.59 +0.61 0.0092 **
23 # X3 -0.00 +0.00 0.2972
```

7.3 问题

问题 7.12（高斯 SCM）*Prove that for linear Gaussian SCMs, two graphs $\mathcal{G}_1$ and $\mathcal{G}_2$ are distribution equivalent if and only if they are Markov equivalent. Here, we allow for zero coefficients.*

问题 7.13（高斯 SCMs）*Consider a distribution $P_{\mathbf{X}}$ of $\mathrm{X} = (X_1, \ldots, X_d)$ with density p induced from a linear Gaussian SCM $\mathfrak{C}$. Prove that for any DAG $\mathcal{G}$ such that $P_{\mathbf{X}}$ is Markovian with respect to $\mathcal{G}$, there is a corresponding linear Gaussian SCM $\mathfrak{C}_{\mathcal{G}}$ entailing $P_{\mathbf{X}}$.*

问题 7.14 (ANMs) *Prove that ANMs over $\mathrm{X} = (X_1, \ldots, X_d)$ with differentiable functions f_j and noise variables that have a strictly positive density entail a distribution over X that has a strictly positive density, too (see Definition 7.3).*

问题 7.15（不变因果预测）*Prove Equation* (7.5).

8

与机器学习的联系，第二部分

正如第5章所论述的，支撑统计模型的因果结构对半监督学习或领域适应等机器学习任务具有重要影响。我们现在重新审视这一广泛议题，重点聚焦于多变量情形。我们首先介绍一种利用机器学习来为给定因果结构建模系统性误差的方法，随后探讨关于强化学习的一些思考（及其在计算广告中的应用），最后对领域适应这一主题进行评述。

8.1 半同胞回归

该方法利用给定的因果结构（见图 8.1）来减少预测任务中的系统性噪声。目标是重建未观测信号 Q。Schölkopf 等人 [2015] 提出，我们可以通过移除所有能够由其他受到同一噪声源污染的测量 X 所解释的信息来对信号 Y 进行去噪。在这里，X 是某些信号 R 的测量值，这些信号与 Q 独立。直观地说，Y 中所有能够由 X 解释的内容必定源于系统性噪声 N，因此应当被移除。更准确地说，我们考虑

$$\hat{Q} := Y - \mathbb{E}[Y \,|\, X]$$

作为Q的估计。这里，$\mathbb{E}[Y \,|\, X]$是Y在其*half-siblings* X (上的*regression*，注意X和Y共享父节点N；参见图8.1)。

可以证明　　对于任何满足$Q \perp\!\!\!\perp X$的随机变量Q, X, Y，t，w　　我们有

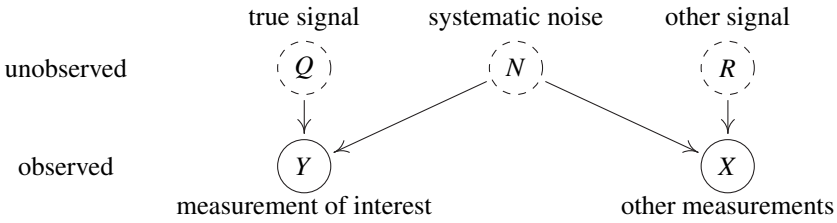

图8.1：适用于系外行星搜索问题的因果结构。感兴趣的潜在信号Q只能作为含噪版本Y被测量。如果相同的噪声源也破坏了与Q无关的其他信号的测量，那么这些测量可以用于去噪。在我们的例子中，望远镜N构成了影响独立光变曲线测量X和Y的系统噪声。

[Schölkopf 等人，2016，命题 1]：

$$\mathbb{E}\left[\left(Q - E[Q] - \hat{Q}\right)^2\right] \leq \mathbb{E}\left[\left(Q - E[Q] - (Y - E[Y])\right)^2\right],$$

也就是说，该方法绝不比采用测量 Y 更差。此外，如果系统噪声以加性方式作用，即对于某个（未知的）函数f有 $Y = Q + f(N)$，我们有 [Schölkopf et al., 2016, Proposition 3]：

$$\mathbb{E}\left[\left(Q - E[Q] - \hat{Q}\right)^2\right] = \mathbb{E}[\mathrm{var}[f(N)|X]]. \tag{8.1}$$

如果加性噪声是 X 的函数，即对于某个（未知）函数 ψ，有$f(N) = \psi(X)$，那么(8.1)式的右侧将消失，因此$\hat{Q}$ 在可加性偏移的意义下恢复 Q；其他充分条件参见 Schölkopf 等人[2016]。

例如，考虑寻找系外行星。2009年发射的开普勒太空天文台在寻找系外行星的过程中观测了银河系的一小部分，监测了约15万颗恒星的亮度。[1]那些被具有合适轨道的行星环绕、从而允许行星部分遮挡恒星的恒星，会表现出显示光强度周期性下降的光变曲线；见图8.2。这些测量受到来自望远镜的系统噪声的干扰，这使得可能行星的信号难以检测。

幸运的是，望远镜同时观测许多恒星。由于这些恒星彼此相隔数光年，可以假设它们在因果关系上，因此也在统计上是独立的。因此，图8.1所描绘的因果结构非常适合这个问题，我们可以应用半同胞回归。这种简单的方法表现得出奇地好[Schölkopf et al., 2015]。

[1] `https://en.wikipedia.org/wiki/Kepler_(spacecraft)`, accessed 13.07.2016.

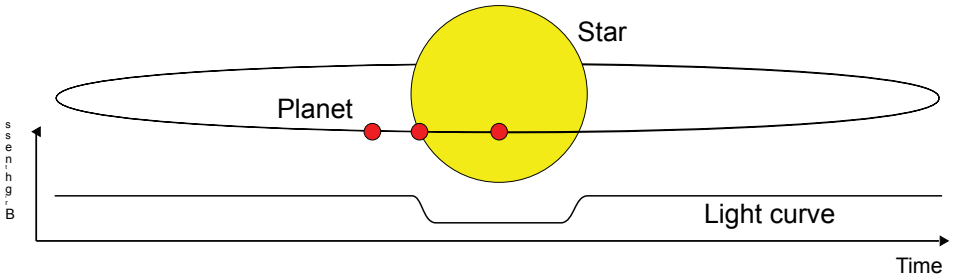

图8.2：每当一颗行星遮挡住恒星的一部分时，光强度就会减弱。如果行星绕恒星运行，这种现象会周期性地出现。（图片由Nikola Smolenski提供，https://en.wikipedia.org/wiki/File:Planetary_transit.svg，[CC BY-SA 3.0]。为了提高清晰度和风格，图片经过了编辑。）

相关方法已在其他应用领域中使用，而未提及因果建模 [Gagnon-Bartsch and Speed, 2012, Jacob et al., 2016]。考虑问题的因果结构（图 8.1）立即提示了所提出的方法，并引出了支持该方法的理论论证。

8.2 因果推断与情景强化学习

我们现在从因果视角描述一类强化学习问题。粗略地说，在强化学习中，智能体嵌入于一个世界之中，并在一组不同的动作中进行选择。根据世界的当前状态，这些动作会产生某种奖励并改变世界的状态。智能体的目标是最大化期望累积奖励（更多细节见第8.2.2节）。我们首先介绍逆概率加权这一概念，它已在机器学习和统计学的不同场景中得到应用，然后将其与情节式强化学习联系起来。建立这一联系是迈向关联因果性与强化学习的一小步。因果视角使我们能够利用直接由因果结构得出的条件独立性。我们简要提及两个应用——二十一点和广告投放——并展示它们如何从因果知识中获益。因果表述非常自然地带来了这些方法学上的改进，但当然也可以不用因果语言来表述这些问题及相应算法。本节并未证明强化学习受益于因果性。相反，我们将其视为一步

致力于在这两个领域之间建立正式联系，这可能在未来带来富有成果的研究[例如，参见Bareinboim等人，2015]。更具体地说，我们认为因果性在强化学习中不同任务之间的知识迁移时可能发挥作用（例如，在电脑游戏中晋升到下一关或在乒乓球中更换对手时）；然而，我们尚未发现任何此类结果。

8.2.1 逆概率加权

逆概率加权是一种众所周知的技术，用于从遵循不同分布的样本中估计分布的特性。因此，它自然地与因果推断相关联。考虑肾结石的例子（例6.37）。我们定义了二值变量大小 S、治疗 T 和康复 R，在获得观察数据后，我们感兴趣的是在假设研究中每个人都接受治疗 A 的情况下的预期康复率 $\tilde{\mathbb{E}}[R]$，即在不同的分布下。形式上，考虑一个涉及变量 $\mathbf{X} = (X_1, \ldots, X_d)$ 上分布 $P_{\mathbf{X}}^{\mathfrak{C}}$ 的 SCM $\mathfrak{C}$。我们已经论证，人们经常观察到来自观察分布 $P_{\mathbf{X}}^{\mathfrak{C}}$ 的样本，但感兴趣的是某些干预分布 $P_{\mathbf{X}}^{\tilde{\mathfrak{C}}}$。在这里，新的 SCM $\tilde{\mathfrak{C}}$ 是通过对节点 X_k 进行干预，从原始 $\mathfrak{C}$ 构建的，例如，

$$do\left(X_k := \tilde{f}(X_{\widetilde{\mathbf{PA}}_k, \tilde{N}_k})\right);$$

请参见第6.3节。特别地，我们可能想要估计某个性质

$$\tilde{\mathbb{E}}\,\ell(\mathbf{X}) := \mathbb{E}_{P_{\mathbf{X}}^{\tilde{\mathfrak{C}}}}\,\ell(\mathbf{X})$$

在新分布 $P_{\mathbf{X}}^{\tilde{\mathfrak{C}}}$（的肾结石示例中，这是 $\tilde{\mathbb{E}}[R]$）。如果密度存在，我们在第6.3节中已经看到 $\mathfrak{C}$ 和 $\tilde{\mathfrak{C}}$ 的密度以类似方式分解：

$$\begin{aligned} p(x_1, \ldots, x_d) &:= p^{\mathfrak{C}}(x_1, \ldots, x_d) = \prod_{j=1}^{d} p^{\mathfrak{C}}\left(x_j \,|\, x_{pa(j)}\right) \quad \text{and} \\ \tilde{p}(x_1, \ldots, x_d) &:= p^{\tilde{\mathfrak{C}}}(x_1, \ldots, x_d) = \prod_{j \neq k} p^{\mathfrak{C}}\left(x_j \,|\, x_{pa(j)}\right)\ \tilde{p}\left(x_k \,|\, x_{\widetilde{pa}(k)}\right). \end{aligned}$$

除了被干预变量的项外，因式分解一致。因此我们有

$$\xi := \tilde{\mathbb{E}}\,\ell(\mathbf{X}) = \int \ell(\mathbf{x})\,\tilde{p}(\mathbf{x})\,d\mathbf{x} = \int \ell(\mathbf{x})\,\frac{\tilde{p}(\mathbf{x})}{p(\mathbf{x})}\,p(\mathbf{x})\,d\mathbf{x}$$
$$= \int \ell(\mathbf{x})\,\frac{\tilde{p}\left(x_k \,|\, x_{\widetilde{pa}(k)}\right)}{p\left(x_k \,|\, x_{pa(k)}\right)}\,p(\mathbf{x})\,d\mathbf{x}.$$

(为简化起见，我们在整个章节中假设密度严格为正。) 给定一个从分布 $P_{\mathbf{X}}^{\mathfrak{C}}$ 中抽取的样本 $\mathrm{X}^1, \ldots, \mathrm{X}^n$，因此我们可以构建一个估计量

$$\hat{\xi}_n := \frac{1}{n}\sum_{i=1}^{n} \ell(\mathbf{X}^i)\,\frac{\tilde{p}\left(X_k^i \,|\, \mathbf{X}^i_{\widetilde{pa}(k)}\right)}{p\left(X_k^i \,|\, \mathbf{X}^i_{pa(k)}\right)} = \frac{1}{n}\sum_{i=1}^{n} \ell(\mathbf{X}^i)\,w_i \tag{8.2}$$

对于观测值 $\xi = \tilde{\mathbb{E}}\,\ell(\mathrm{X})$ 由 *reweighting*，这里，权重 w_i 定义为条件密度的比率。那些在 $P_{\mathbf{X}}^{\tilde{\mathfrak{C}}}$ (下具有高似然度的数据点，即“可能来自”新的感兴趣的分布) 的数据点，会获得较大的权重，并且对估计 $\hat{\xi}_n$ 的贡献大于权重较小的数据点。例如，这种估计器出现在以下三种情况中。

(i) 假设 $\mathrm{X} = (Y, Z)$ 仅包含一个目标变量 Y 和一个 *causal* 协变量 Z，即 $Z \to Y$。让我们考虑对 Z 的干预以及函数 $\ell(\mathrm{X}) = \ell((Z,Y)) = Y$。那么，估计量 (8.2) 简化为

$$\hat{\xi}_n := \frac{1}{n}\sum_{i=1}^{n} Y^i\,\frac{\tilde{p}(Z^i)}{p(Z^i)}, \tag{8.3}$$

这被称为霍维茨-汤普森估计量 [Horvitz and Thompson, 1952]。该设定对应于协变量偏移的假设 [例如，Shimodaira, 2000, Quionero-Candela et al., 2009, Ben-David et al., 2010]；另见第5.2节和第8.3节。估计量 (8.3) 是加权似然估计量的一个例子。

(ii) 对于 $\mathrm{X} = Z$，我们可以利用从 p 中采样的数据，在 $\tilde{p}$ 下估计期望 $\tilde{\mathbb{E}}\,[\ell(Z)]$。因此，方程 (8.2) 简化为

$$\hat{\xi}_n := \frac{1}{n}\sum_{i=1}^{n} \ell(Z^i)\,\frac{\tilde{p}(Z^i)}{p(Z^i)},$$

一种被称为重要性采样的公式[e.g., MacKay, 2002, Chapter 29.2]。如果p和$\tilde{p}$仅已知到常数，该公式可以进行调整。

(iii) 我们将在 episodic 强化学习的背景下利用公式(8.2)。接下来我们将更详细地描述这一应用。

8.2.2 情景强化学习

强化学习 [例如 Sutton 和 Barto，2015] 模拟了在世界中采取行动的智能体的行为。根据世界的当前状态S_t和动作A_t，世界的状态根据马尔可夫决策过程变化，例如 [例如，Bellman，1957]；即，进入新状态s的概率$P(S_{t+1} = s)$仅取决于当前状态S_t和动作A_t。此外，智能体将获得一些奖励R_{t+1}，该奖励取决于S_t、A_t和S_{t+1}；所有奖励的总和有时称为回报，我们将其写作$Y := \sum_t R_t$。回报Y如何取决于状态和动作对于试图改进其策略$(a,s) \mapsto \pi(a\,|\,s) := P(A_t = a\,|\,S_t = s)$的智能体来说是未知的，即，他根据世界状态的观测部分选择动作的条件。在分段强化学习中，状态在有限数量的动作后被重置（见图8.3）。在第8.2.3节中，我们考虑以下示例：

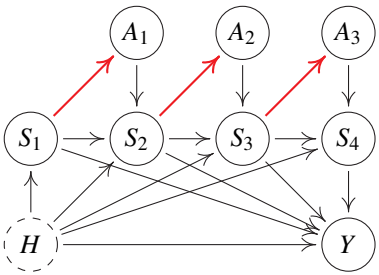

图8.3：该图描述了一个情节式强化学习问题。动作变量A_i影响系统下一状态S_{i+1}。变量Y描述我们在一个情节后获得的输出或回报。这个回报Y也可能取决于动作（为清晰起见，省略了边）；它通常被建模为每个决策后收到奖励的（可能加权的）总和；参见第8.2.3节。整个系统可能受到一个未观测变量H的混杂影响。粗体红色边表示玩家可以影响的条件，即策略。方程(8.4)根据使用策略π获得的数据，估计在策略$\tilde{\pi}$下的预期结果$\tilde{\mathbb{E}}[Y]$。当存在从动作A到H和/或Y的额外边时，该方程仍然成立。

二十一点。在图8.3的示例中，玩家做出$K = 3$次决策，之后牌被重新洗牌。然后，新的一轮开始。

假设我们在某个策略$(a,s) \mapsto \pi(a|s)$下玩n局游戏，每一局都是一个回合。这个函数π不依赖于我们到目前为止所玩过的“步数”，而仅依赖于状态的值。只要该策略对任何动作赋予正概率，式（8.2）就允许我们估计另一个策略$(a,s) \mapsto \tilde{\pi}(a|s)$的性能。

$$\hat{\xi}_{n,\mathrm{ERL}} := \frac{1}{n}\sum_{i=1}^{n} Y^i \frac{\prod_{j=1}^{K} \tilde{\pi}(A_j^i|S_j^i)}{\prod_{j=1}^{K} \pi(A_j^i|S_j^i)}. \tag{8.4}$$

这可以视为一种用于离策略评估的蒙特卡洛方法[Sutton and Barto, 2015, 第5.5章]。在实际应用中，估计量(8.4)往往具有较大的方差；在连续设置中，方差甚至可能是无限的。有建议提出重新加权[Sutton and Barto, 2015]或忽略（五个）最大权重[Bottou et al., 2013]以在方差与偏差之间进行权衡。Bottou等人[2013]在参数化密度的情况下还计算了置信区间和梯度。若要寻找最优策略，后者尤为重要。

我们现在简要讨论两个例子，其中利用因果结构导致学习过程的*statistical*性能提升。我们认为这些是有趣的例子，揭示了强化学习与因果性之间的关系。

8.2.3 二十一点中的状态简化

第8.2.2节中提出的方法可用于学习如何玩21点（一种纸牌游戏）。我们假设一名玩家进入赌场并开始玩21点，既不知道游戏目标也不知道最优策略；相反，他采用随机策略。在游戏的每个时刻，玩家被询问他想采取哪种合法行动，而在游戏结束后，庄家会揭示玩家赢或输了多少钱。过一段时间后，玩家可能会将其策略更新为已被证明成功的决策，并继续玩。从数学角度来看，21点已被解决。最优策略（针对无限副牌）由Baldwin等人[1956]发现，对于下注1的玩家，其期望值为$\mathbb{E}[Y] \approx -0.006$€。

因果关系如何发挥作用？我们假设玩家并不了解21点的精确规则；然而，他可能知道输赢仅由牌的点数决定，而非花色；也就是说，规则不区分梅花Q和红桃Q。玩家可以

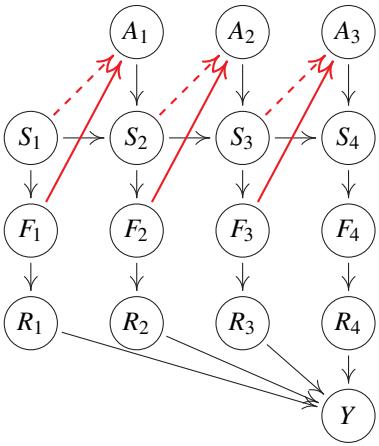

图8.4：此处存在变量$F_1,\ldots,F_4$，其包含了关于状态$S_1,\ldots,S_4$的所有相关信息，即满足方程(8.5)和(8.6)。方程(8.6)未在图中表示。因此，只要动作A_j依赖于F_{j-1} (红色实线)而非S_{j-1} (红色虚线)即可。在二十一点示例中，S_j编码了庄家的手牌和玩家的手牌，包括花色，而F_j编码了相同信息但不含花色（花色不影响二十一点的结果）。由于F_j取值比S_j少，最优策略更易于学习。

那么立即得出结论，最优策略不依赖于花色。这在寻找最优策略时具有明显的优势：相关状态空间的数量以及因此可能策略的空间显著减少。图8.4描绘了这一论点：变量S_t包含所有信息，而变量F_t不包含花色。例如，

$$\begin{aligned} S_3 &= (\text{Player: } \heartsuit K, \spadesuit 5, \diamondsuit 4; \quad \text{Dealer: } \diamondsuit K) \\ F_3 &= (\text{Player: } \quad K, \quad 5, \quad 4; \quad \text{Dealer: } \quad K). \end{aligned}$$

由于最终结果 Y 仅依赖于$(F_1,\ldots,F_4)$，而不依赖于“全状态”$(S_1,\ldots,S_4)$，因此可以选择动作仅依赖于 F 变量。同样，也可以利用卡牌顺序无关这一事实。更正式地，我们得到以下结果：

命题 8.1（状态简化）*Suppose that we are interested in the re- turn* $Y := \sum_j R_j$*, and all variables are discrete. Assume that there is a function* f *such that for all* j *and for* $F_j := f(S_j)$*, we have*

$$R_j \perp\!\!\!\perp S_j \,|\, F_j, A_j, \tag{8.5}$$

and the full states do not matter for the change of states in the following sense: for all s_j and for all s_{j-1}, s°_{j-1} with $f(s_{j-1}) = f(s^\circ_{j-1})$

$$p(f(s_j)\,|\,s_{j-1}) = p(f(s_j)\,|\,s^\circ_{j-1}). \tag{8.6}$$

Then the optimal strategy $(a,s) \mapsto \pi_{opt}(a\,|\,s)$ depends only on F_j and not on S_j. There exists

$$\pi_{opt} \in \operatorname*{argmax}_{\pi} \mathbb{E}[Y],$$

such that

$$\pi_{opt}(a_j\,|\,s_{j-1}) = \pi_{opt}(a_j\,|\,s^\circ_{j-1}) \quad \forall s_{j-1}, s^\circ_{j-1} : f(s_{j-1}) = f(s^\circ_{j-1}).$$

如果 F_j 取的值比 S_j 少，这一结果尤其有用。证明见附录 C.11。在二十一点示例中，方程 (8.6) 表明再抽到一张 K 的概率只取决于之前抽到的牌的值（尤其是 K 的数量），而不取决于它们的花色。

8.2.4 广告投放中的改进加权

一个相关的论点被Bottou等人[2013]用于广告的最佳放置。考虑以下对系统的简化描述。一家公司，我们将称之为发布商，运营一个搜索引擎，并可能希望在搜索结果上方的空间，即主线上展示广告。只有当用户点击广告时，发布商才会从相应的公司获得收入。在展示广告之前，发布商设置主线保留价A，这是一个实值参数，决定了在主线上展示多少广告。在大多数系统中，主线广告的数量F在0到4之间变化，即$F \in \{0, 1, 2, 3, 4\}$。主线保留价A通常取决于许多变量（例如，搜索查询、查询的日期和时间、位置），我们称之为状态S。例如，如果搜索查询表明用户打算购买新鞋，那么与用户查找教堂下一次服务的时间相比，可能希望展示更多广告。我们可以将系统建模为长度为1的情节式强化学习。[2]回报Y等于每集的点击次数；其值为0或1。如何选择最佳主线保留价A的问题则对应于找到最佳策略$(a,s) \mapsto \pi_{\text{opt}}(a|s)$。图8.5展示了简化问题的示意图。状态$S$包含信息

[2]In reality, the systems are usually more complicated. For example, in an auction-like procedure, the advertisers place bids on certain search queries, which then influence the price for a click.

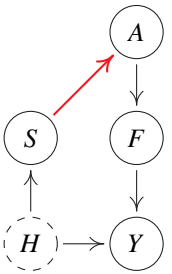

图8.5：广告投放示例。目标变量Y表示用户是否点击了展示的广告之一。H (未知)和S (已知)是状态变量，动作A对应于主线预留，这是一个实值参数，决定主线中展示多少广告。F是一个离散变量，表示主线中投放的（已知）广告数量。尽管条件$p(a\,|\,s)$是随机化的，我们可以使用$p(f\,|\,s)$进行重加权（见命题8.2）。

关于发布者可用的用户信息。隐藏变量H包含未知的用户信息（例如，其意图），动作A是主线储备，而Y是一个事件，表示用户是否点击了其中一个广告。最后，F是一个离散变量，表示展示了多少广告。评估新策略$(a,s) \mapsto \tilde{p}(a\,|\,s)$，对应于应用公式(8.4)：

$$\hat{\xi}_{n,\mathrm{ERL}} := \frac{1}{n}\sum_{i=1}^{n} Y^i \,\frac{\tilde{p}(A^i\,|\,S^i)}{p(A^i\,|\,S^i)}.$$

(这里，为记号方便我们写 $p(a\,|\,s)$ 而不是 $\pi(a\,|\,s)$。) 我们现在可以受益于以下关键见解。一个人是否点击广告取决于主线保留价 A，但仅通过 F 的值。用户永远不会看到实值参数 A。当我们思考系统的因果结构时（见图8.5），这是一个有些微不足道的观察。然而，利用这一事实，我们可以使用不同的估计量

$$\frac{1}{n}\sum_{i=1}^{n} Y^i \,\frac{\tilde{p}(F^i\,|\,S^i)}{p(F^i\,|\,S^i)};$$

参见命题8.2。并且由于F是一个取值在0到4之间的离散变量，通常会导致权重的表现要好得多。实际上，这种修改可能会大大减小置信区间的尺寸[Bottou等，2013，第5.1节]。如同第8.1节，我们可以利用对因果结构的了解来提高统计性能。更正式地说，该过程由以下命题证明是合理的：

Method	Training data from	Test domain
Domain generalization	$(\mathbf{X}^1, Y^1), \ldots, (\mathbf{X}^D, Y^D)$	$T := D+1$
Multi-task learning	$(\mathbf{X}^1, Y^1), \ldots, (\mathbf{X}^D, Y^D)$	$T \in \{1, \ldots, D\}$
Asymmetric multi-task learning	$(\mathbf{X}^1, Y^1), \ldots, (\mathbf{X}^D, Y^D)$	$T := D$

表8.1：在领域泛化中，测试数据来自未见过的领域，而在多任务学习中，测试领域的一些数据是可用的。

命题 8.2（改进的加权）*Suppose there is a density p over* $\mathrm{X} = (A, F, H, S, Y)$ *that is entailed by an SCM $\mathfrak{C}$ with graph shown in Figure 8.5. Assume further that the density $\tilde{p}$ is entailed by an SCM $\tilde{\mathfrak{C}}$ that corresponds to an intervention in A of the form do $\big(A := \tilde{f}(S, \tilde{N}_A)\big)$ and satisfies $\tilde{p}(f \,|\, s) = 0$ if $p(f \,|\, s) = 0$ and $\tilde{p}(a \,|\, s) = 0$ if $p(a \,|\, s) = 0$. We then have*

$$\tilde{\mathbb{E}} Y \;=\; \int y \, \frac{\tilde{p}(a \,|\, s)}{p(a \,|\, s)} \, p(\mathbf{x}) \, d\mathbf{x} \;=\; \int y \, \frac{\tilde{p}(f \,|\, s)}{p(f \,|\, s)} \, p(\mathbf{x}) \, d\mathbf{x}.$$

证明可在附录C.12中找到。一般来说，非零密度的条件确实是必要的：如果存在一组a和s值（具有非零勒贝格测度），它们属于$\tilde{p}$的支持集并对Y的期望有贡献，那么在p下采样到该区域数据的概率必定非零。

8.3 领域适应

领域适应是另一个与因果性自然相关的机器学习问题[Schölkopf等人，2012]。在这里，我们将把领域适应与我们在第7.2.5节“不同环境”中所称的不变预测联系起来。我们并不声称这种联系在当前形式下会带来重大改进，但我们相信它可能对开发领域适应中的新方法有用。

假设我们从目标变量Y^e和不同领域$e \in \mathcal{E} = \{1, \ldots, D\}$中的$d$个可能的预测变量$\mathrm{X}^e = (X_1^e, \ldots, X_d^e)$获取数据，并且我们对预测$Y$感兴趣。为了适应广泛使用的记号，我们使用术语“领域”或“任务”。表8.1描述了我们在此考虑的领域适应中三个问题的分类。

我们的主要假设是存在一个集合 $S^* \subseteq \{1, \ldots, d\}$，使得条件 $Y^e \,|\, \mathrm{X}^e_{S^*}$ 对于所有领域 $e \in \mathcal{E}$（包括测试领域）都是相同的，也就是说，对于所有 $e, f \in \mathcal{E}$ 和所有 x_{S^*}

$$Y^e \,|\, \mathbf{X}^e_{S^*} = \mathbf{x}_{S^*} \quad \text{and} \quad Y^f \,|\, \mathbf{X}^f_{S^*} = \mathbf{x}_{S^*} \quad \text{have the same distribution.} \tag{8.7}$$

在第7.1.6节和第7.2.5节中，我们考虑了一个类似的设置，其中我们使用了术语“环境”而非“域”，并将性质(8.7)称为“不变预测”。我们论证了如果存在一个底层的SCM，并且这些环境对应于对目标Y以外节点的干预，那么性质(8.7)对于$S^* = \mathrm{PA}_Y$ (成立，参见我们在第2.2节中对Simon不变性准则的讨论)。然而，性质(8.7)也可能对非因果父节点的集合成立。由于我们的目标是预测，我们最感兴趣的是满足(8.7)并且额外尽可能准确地预测Y的集合S^*。让我们暂时假设，我们被给定了这样一个集合S^* (我们稍后将回到这个问题)，并指出假设(8.7)与域适应之间的关系。

在协变量偏移的设置中[例如，Shimodaira, 2000, Quionero-Candela et al., 2009, Ben-David et al., 2010]，通常假设条件$Y^e \mid \mathrm{X}^e = \mathrm{x}$ 对所有任务e保持不变。假设(8.7)意味着协变量偏移对某些变量子集S^*成立，因此构成了协变量偏移假设的泛化。

对于域泛化，如果集合 S^* 已知，我们可以对该子集 S^* 应用传统的协变量偏移方法。例如，如果输入空间中数据的支撑集重叠（或系统是线性的），我们可以在测试域 T 中使用估计量 $f_{S^*}(\mathrm{X}^T_{S^*})$，其中 $f_{S^*}(\mathrm{x}) := \mathbb{E}\left[Y^1 \mid \mathrm{X}^1_{S^*} = \mathrm{x}\right]$。可以证明，在对抗性设置下，这种方法是极优的，其中测试域的分布可以与训练域任意不同，除了我们要求保持不变的條件分布（8.7）[Rojas-Carulla et al., 2016, Theorem 1]。在多任务学习中，如何利用这样一个集合 S^* 的知识则不那么显而易见。实践中，需要将从任务池化和在 S^* 上回归 Y 中获得的信息与从单独考虑测试任务中得到的知识相结合 [Rojas-Carulla et al., 2016]。

如果集合 S^* 未知，我们再次建议在可用域上搜索满足（8.7）的集合 S。在学习因果预测变量时，人们倾向于保持保守，因此不变因果预测方法 [Peters et al., 2016] 输出所有满足（8.7）的集合 S 的交集；见公式（7.5）。在这里，我们感兴趣的是预测。因此，在所有导致不变预测的集合中，可以选择导致最佳预测性能的集合 S，这通常是那些集合中较大的一个。如果存在不同的已知集合 S 都满足（8.7），情况也是如此。如果数据由 SCM 生成，并且域对应于不同的干预，那么在无限数据的极限下，满足（8.7）且具有最佳预测能力的集合 S 可以证明是 Y (的马尔可夫毯的子集，见问题 8.5)。

8.4 问题

问题 8.3（半同胞回归）*Consider the DAG in Figure 8.1. The fact that X provides additional information about Q on top of the one provided by Y follows from causal faithfulness. Why?*

问题 8.4（逆概率加权）*Consider an SCM $\mathfrak{C}$ of the form*

$$\begin{aligned} Z &:= N_Z \\ Y &:= Z^2 + N_Y, \end{aligned}$$

with $N_Y, N_Z \overset{iid}{\sim} \mathcal{N}(0,1)$ and an intervened version $\tilde{\mathfrak{C}}$ with

$$do\left(Z := \tilde{N}_Z\right),$$

where $\tilde{N}_Z \sim \mathcal{N}(2,1)$.

a) (optional) Compute $\mathbb{E}[Y] := \mathbb{E}_{P^{\mathfrak{C}}}[Y]$ and $\tilde{\mathbb{E}}[Y] := \mathbb{E}_{P^{\tilde{\mathfrak{C}}}}[Y]$. b) Draw $n = 200$ i.i.d. data points from the SCM $\mathfrak{C}$ and implement the estima- tor (8.3) for estimating $\tilde{\mathbb{E}}[Y]$.
c) Compute the estimate in b) and the empirical variance of the weights appearing in (8.3) for increasing sample size n between $n = 5$ and $n = 50,000$. What do you conclude?

问题 8.5（不变预测器）*We want to justify the last sentence in Section 8.3. Consider a DAG over variables Y, E, and $X_1, \dots, X_d$, in which E (for "environment") is not a parent of Y and does not have any parents itself. Denote the Markov blanket of Y by M. Prove that for any set $S \subseteq \{X_1, \dots, X_d\}$ with*

$$Y \perp\!\!\!\perp E \,|\, S$$

there is another set $S_{new} \subseteq M$ such that

$$Y \perp\!\!\!\perp E \,|\, S_{new} \quad \text{and} \quad Y \perp\!\!\!\perp (S \setminus S_{new}) \,|\, S_{new}.$$

9

隐藏变量

到目前为止，我们假设模型中的所有变量都已被测量（噪声除外）。由于在实践中，我们自行选择随机变量集合，因此需要定义“因果相关”变量的概念。在9.1节中，我们引入了“因果充分性”和“干预充分性”这两个术语。但即便撇开精确定义的细节，显然在大多数实际应用中，许多因果相关变量将无法观测。辛普森悖论（9.2节）描述了忽视隐藏混杂因素如何导致错误的因果结论。在线性设定中，一种通常被称为工具变量的结构可以使与因果效应相对应的回归系数（参见例6.42）变得可识别（9.3节）。寻找含隐藏变量的SCM的良好图形表示，特别是那些编码条件独立性结构的表示，是一个活跃的研究领域；我们将在9.4节中介绍一些解决方案。最后，隐藏变量导致观测分布中出现超越条件独立性的约束（9.5节）。我们简要讨论了如何将这些约束用于结构学习，但未提供任何方法论细节。关于隐藏变量处理的更多历史注释，请参阅Spirtes等人[2000，第6.1节]。

9.1 介入充分性

如果不存在隐藏的共同原因$C \notin \mathbf{X}$导致$\mathbf{X}$中的多个变量，则通常称变量集合$\mathbf{X}$是因果充分的[例如，Spirtes，2010]。虽然这个定义符合“相关”集合的直观含义

变量，它使用了“共同原因”的概念，因此应当相对于一个更大的变量集$\tilde{\mathbf{X}} \supseteq \mathbf{X}$（对于这个集合，我们可能再次想要定义因果充分性）来理解。在对应于这个更大集合$\tilde{\mathbf{X}}$的结构因果模型中，如果存在从C到X和Y的分别不包含Y和X的有向路径，则变量C是X和Y的共同原因。共同原因也称为混杂因素，我们互换使用这两个术语。

我们提出对因果充分性的一个小修改，称之为干预充分性，这是一个基于SCM可证伪性的概念；见第6.8节。

定义 9.1（干预充分性）*We call a set* $\mathbf{X}$ *of variables interventionally sufficient if there exists an SCM over* $\mathbf{X}$ *that cannot be falsified as an interventional model; that is, it induces observational and intervention distributions that coincide with what we observe in practice.*

我们认为这个概念在直觉上很有吸引力，因为它描述了一组变量何时足够大以进行因果推理，即计算观察分布和干预分布。

如果存在一个潜在的共同原因，那么仅考虑两个变量通常是不够的，这应该是直观的。根据定义，这两个变量在因果上是不充分的，而第9.2节中的辛普森悖论（另见例6.37）表明，一般而言，这两个变量在干预上也不充分。事实上，该悖论将这一论断推向了极端：一个忽略混杂因素的、仅基于这两个观测变量的SCM不仅会得出错误的干预分布，甚至可能逆转因果效应的符号：一种治疗可能看起来有益，尽管它实际上是有害的；见(9.2)。

然而，有时即使存在潜在混杂因素，我们仍能计算出正确的干预分布。下面例子中的变量集在干预上是充分的，但在因果上是不充分的。

例9.2 考虑以下SCM

$$\begin{aligned} Z &:= N_Z \\ X &:= \mathbf{1}_{Z \geq 2} + N_X \\ Y &:= Z \bmod 2 + X + N_Y \end{aligned}$$

其中 $N_Z \sim \mathcal{U}(\{0,1,2,3\})$ 均匀分布在 $\{0,1,2,3\}$ 和 $N_X, N_Y \overset{\text{iid}}{\sim} \mathcal{N}(0,1)$ 上；见图9.1（左）。虽然变量 X 和 Y 明显在因果上不充分——

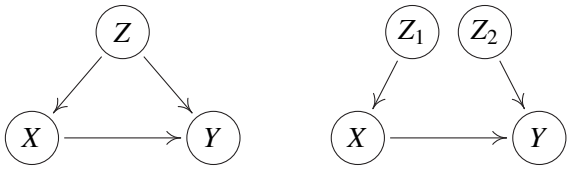

图 9.1：两幅图都表示示例 9.2 中所述模型在干预下等价的 SCM。虽然只有第二种表示使 X 和 Y 因果充分，但无论采用哪种表示，X 和 Y 都是干预充分的。

[1] 可以证明，两个变量 X 和 Y 在干预上是充分的。原因是“混杂因子” Z 由两个独立部分组成：$Z_1 := 1_{Z\geq 2}$ 是 Z 二进制表示的第一位，而 $Z_2 := Z \bmod 2$ 是第二位。在这个意义上，我们可以将“混杂因子”分解为独立变量 Z_1 和 Z_2，其中 Z_1 影响 X，而 Z_2 影响 Y；见图 9.1。 □

一般来说，因果充分性和干预充分性之间存在以下关系（证明见附录C.13）：

命题 9.3（干预充分性与因果充分性）*Let* $\mathfrak{C}$ *be an SCM for the variables* X *that cannot be falsified as an interventional model.*

(i) If a subset $\mathrm{O} \subseteq \mathrm{X}$ *is causally sufficient, then it is interventionally sufficient.*
(ii) In general, the converse is false; that is, there are examples of interventionally sufficient sets $\mathrm{O} \subseteq \mathrm{X}$ *that are not causally sufficient.*

此外，例9.2表明，不存在仅基于图的准则来判断变量的子集是否干预充分。对于许多结构类似于图9.1（左侧）的SCM，X和Y干预不充分。然而，以下注记表明，省略一个“中间”变量可保持干预充分性。

备注 9.4 我们有以下三个陈述。

(i) 假设存在一个关于 X, Y, Z 的结构因果模型，其图为 $X \to Y \to Z$ 且 $X \not\perp\!\!\!\perp Z$ 能导出正确的干预。那么由于满足 $X \to Z$ 的关于 X, Z 的结构因果模型，X 和 Z 在干预上是充分的。

[1] Here, the hidden common cause Z not only points into X and Y but also has a total causal effect on both of them; see Definition 6.12.

(ii) 假设存在一个在 X,Y,Z 上的 SCM $\mathfrak{C}$，它诱导出与图 $X \to Y \to Z$ 和额外 $X \to Z$ 相关的正确干预，并进一步假设 $P^{\mathfrak{C}}_{X,Y,Z}$ 相对于该图是忠实的；另见 (iii)。那么，同样地，由于在 X,Z 上满足 $X \to Z$ 的 SCM，X 和 Z 在干预意义下是充分的。

（iii）如果情况与（ii）相同，但区别在于

$$P^{\mathfrak{C}}_{Z|X=x} = P^{\mathfrak{C};do(X:=x)}_{Z} = P^{\mathfrak{C}}_{Z}$$

对于所有x (，特别地，$P^{\mathfrak{C}}_{X,Y,Z}$相对于图)不是忠实的。然后，由于X,Z上的SCM具有空图，X和Z在干预上是充分的。请注意，反事实可能没有被正确表示。

这些陈述的证明留给读者（见习题9.10）。 □

每当我们在观测变量上找到一个结构因果模型（SCM），它在干预意义上等同于所有变量上的原始SCM时，我们可能想把前者称为边缘化SCM。我们已经看到，仅凭图形准则无法确定边缘化SCM的结构。相反，需要关于因果机制的一些信息，即赋值{ v* }的具体形式。Bongers等人[2016]更详细地研究了SCM的边缘化。关键思想是从原始SCM出发，仅考虑观测变量的结构赋值。然后，每当隐藏变量出现在右侧时，就反复代入它们的赋值。这产生了一个带有多元、可能相关的噪声变量的SCM。在某些情况下，随后可以选择一个具有单变量噪声变量的干预等价SCM。

9.2 辛普森悖论

例6.16中的肾结石数据集因以下原因而广为人知。我们有

$$\begin{aligned} &P^{\mathfrak{C}}(R=1\,|\,T=A) < P^{\mathfrak{C}}(R=1\,|\,T=B) \qquad \text{but} \\ &P^{\mathfrak{C};do(T:=A)}(R=1) > P^{\mathfrak{C};do(T:=B)}(R=1); \end{aligned} \tag{9.1}$$

参见例 6.37。假设我们尚未测量石头 Z (size) 这一变量，而且甚至不知道它的存在。我们可能

然后假设$T \to R$是正确的图。如果我们把这个（错误的）SCM记为$\tilde{\mathfrak{C}}$，我们可以将(9.1)重写为

$$P^{\tilde{\mathfrak{C}};do(T:=A)}(R=1) < P^{\tilde{\mathfrak{C}};do(T:=B)}(R=1) \text{ but}$$
$$P^{\mathfrak{C};do(T:=A)}(R=1) > P^{\mathfrak{C};do(T:=B)}(R=1). \tag{9.2}$$

由于模型设定错误，因果陈述被颠倒了。尽管A是更有效的药物，但我们建议使用B。但即使我们知道了共同原因Z，是否可能存在另一个我们没有校正的混杂变量？如果我们不走运，情况确实如此，并且如果我们将这个变量纳入考虑，就必须再次颠倒结论。原则上，这可能导致任意长的颠倒因果结论序列（见习题9.11）。

这个例子表明，我们在写下潜在的因果图时必须多么谨慎。在某些情况下，我们可以从描述数据获取的协议中推断出DAG。例如，如果分配治疗的医生除了肾结石的大小之外对患者没有任何了解，那么除了结石的大小之外不可能存在任何混杂因素。

综上所述，辛普森悖论与其说是一个悖论，不如说是对因果推理在模型误设方面可能极为敏感的一个警告。尽管我们是在存在混杂因素的背景下阐述这个例子的，但它也可能由于未考虑到的选择偏差（例6.30）而发生。

9.3 工具变量

工具变量可以追溯到20世纪20年代[Wright, 1928]，并在实践中被广泛使用[参见，例如，Imbens and Angrist, 1994, Bowden and Turkington, 1990, Didelez et al., 2010]。存在许多扩展和替代方法；我们关注其核心思想。考虑一个线性高斯结构因果模型，其图形如图9.2（左）所示。在这里，结构分配中的系数α

$$Y := \alpha X + \delta H + N_Y$$

是感兴趣的量（见例6.42中的方程(6.18)）；有时被称为平均因果效应（ACE）。然而，由于隐藏的共同原因H，它不能直接获取。简单地将Y对X进行回归并取

回归系数通常会导致 α 的估计量有偏:

$$\frac{\text{cov}[X,Y]}{\text{var}[X]} = \frac{\alpha\,\text{var}[X] + \delta\gamma\,\text{var}[H]}{\text{var}[X]} = \alpha + \frac{\delta\gamma\,\text{var}[H]}{\text{var}[X]}.$$

相反，如果存在工具变量，我们或许能够利用它。形式上讲，在一个SCM中，如果满足以下条件，我们称变量Z为(X,Y)的工具变量：(a) Z与H独立，(b) Z与X（“相关性”)不独立，以及(c) Z仅通过X（“排除限制”)影响Y。就我们的目的而言，考虑图9.2（左）所示的示例图就足够了，该图满足所有这些假设。然而，请注意其他结构也同样满足。例如，可以允许Z和X之间存在隐藏的共同原因。在实践中，人们通常利用领域知识来论证条件(a)、(b)和(c)为何成立。

在线性情况下，我们可以利用 Z 的存在，方式如下。由于 (H,N_X) 独立于 Z，我们可以将 $\gamma H + N_X$ 视为在

$$X := \beta Z + \gamma H + N_X$$

作为噪声。由此可见，我们因此能够一致地估计系数β，从而获取βZ（，在有限数据的情况下，这通过Z)的拟合值来近似。由于

$$Y := \alpha X + \delta H + N_Y = \alpha(\beta Z) + (\alpha\gamma + \delta)H + N_Y,$$

我们可以通过将 Y 对 βZ 进行回归，从而一致地估计 α。总结来说，我们首先将 X 对 Z 进行回归，然后将 Y 对第一次回归预测得到的值$\hat{\beta}Z$ (predicted进行回归)。在无限数据的极限下，平均因果效应 α 变得可识别。这种方法通常被称为“两阶段最小二乘法”。它利用了线性结构因果模型以及上述假设：(a) H 与 Z 之间的独立性，(b) 在 β 很小或趋于零的情况下，β（非零，此时 Z 被称为“弱工具变量”)，以及 (c) Z 对 Y 不存在直接影响。

然而，可识别性并不局限于线性设定。我们现在仅提及四个此类结果，尽管还有更多（例如，Hernán and Robins, 2006）。

(i) 不难看出，如果 X 以非线性但可加的方式依赖于 Z 和 H，两阶段最小二乘法仍然有效；见习题9.12。

(ii) 如果变量 Z、X 和 Y 是二进制的，则 ACE 定义为

$$P^{\mathfrak{C};do(X:=1)}(Y=1) - P^{\mathfrak{C};do(X:=0)}(Y=1).$$

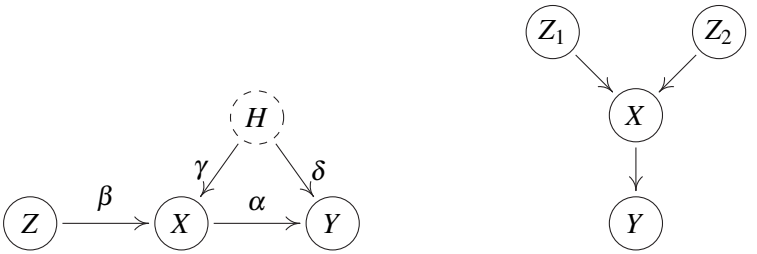

图9.2：左图：工具变量的设置（第9.3节）。一个著名的例子是存在不依从性的随机临床试验：Z是治疗分配，X是治疗，Y是结果。右图：Y结构；见第9.4.1节。

Balke和Pearl [1997]在不对Y与X和H之间关系做进一步假设的情况下，提供了ACE的（紧致）下界和上界。例如，这些界限可能相当不具信息性，也可能坍缩为单一的点。在后一种情况下，我们称ACE是可识别的。(iii) Wang和Tchetgen Tchetgen [2016]表明，在二值处理情形下，如果Y的结构赋值对于X和H是加性的，则ACE变得可识别[Wang and Tchetgen Tchetgen, 2016, Theorem 1]。(iv)关于连续情形下的可识别性，参见Newey [2013]及其中的参考文献。

大多数涉及工具变量的概念，如之前描述的线性设定，都扩展到了观察到的协变量 W 引起一些（或全部）相关变量的情况。例如，在图9.2（左）中，我们可以考虑一个变量 W 指向 Z、X 和 Y。假设（a）、（b）和（c），以及程序，随后被修改，并且总是包括对 W 的条件化。Brito和Pearl [2002b]将这一思想扩展到了多变量 Z 和 X（“广义工具变量”）。

9.4 条件独立性与图形表示

在因果学习中，我们试图从观测数据中重构因果模型。我们已经看到了一些可识别性结果，这些结果允许我们根据观测分布$P_{\mathbf{X}}$识别变量X上SCM的图结构。现在让我们转向一个包含观测变量O和隐藏变量H的SCM $\mathfrak{C}$，其变量为$\mathrm{X} = (\mathrm{O}, \mathrm{H})$。我们仍然可以问图结构是否

$\mathfrak{C}$ 是否可以从观察变量上的分布 $P_{\mathbf{O}}$ 中识别出来，如果可以，我们如何识别它。

在没有隐变量的情况下，我们在第7.2.1节讨论了如何在马尔可夫条件和忠实性下学习（部分）因果结构。这些假设保证了*d*-分离与条件独立之间的一一对应关系，因此我们可以在$P_{\mathbf{X}}$中检验条件独立性，并重建底层图的性质。回想一下，基于独立性的方法原则上在DAG空间中搜索，并输出一个图（或图的等价类），该图精确地表示了数据中发现的条件独立关系集合。

对于带有隐变量的因果学习，我们原则上希望在有隐变量的DAG空间中进行搜索。然而，这带来了额外的困难。我们不知道H的大小，因此如果不限制隐变量的数量，就会有无限多的图候选需要搜索。此外，还有一个反对这种方法的统计论据：关于DAG是马尔可夫且忠诚的分布集合形成一个弯曲指数族，这为使用BIC提供了依据，例如[Haughton, 1988]；然而，关于带有隐变量的DAG是马尔可夫且忠诚的分布集合则不然[Geiger and Meek, 1998]。如果搜索带有隐变量的DAG不可行，我们能否转而通过观测变量上的边缘化图来表示每个带有隐变量的DAG，可能使用不止一种类型的边，然后在这些结构上进行搜索？我们在第9.1节中已经看到，这种方法也伴随着一个困难：边缘化图应依赖于原始底层SCM，仅考虑原图中包含的信息是不够的。如前所述，Bongers等人[2016]更详细地研究了SCM的边缘化。

由于这些原因，在本节剩余部分，我们考虑一个略有偏移的问题：不再检查某个完整分布是否可能由具有潜在变量的特定DAG结构诱导，而是将注意力限制在某些类型的约束上。例如，我们考虑所有在观测变量O上满足相同条件独立陈述集的分布（隐含地假设马尔可夫条件和忠实性）。接着，我们探讨如何表示这组条件独立性。

一个直接的解决方案是假设所蕴含的分布$P_{\mathbf{O}}$相对于无隐藏变量的有向无环图是马尔可夫且忠实的，并且像之前一样，输出一类代表观察变量分布中条件独立性的有向无环图。表示这一条件独

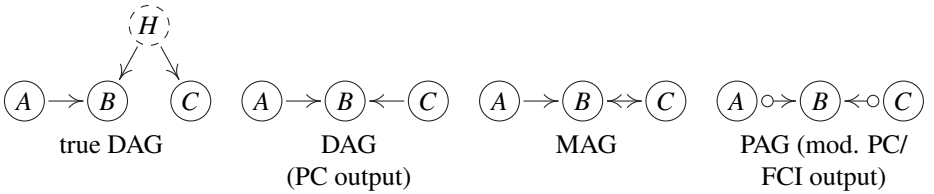

图 9.3：从左侧的 SCM 开始，右侧的三个图编码了条件独立集 ({v*})。由于错误的因果解释，DAG 不适合作为因果学习方法的输出。在此例中，IPG 和潜在投影（ADMG）等同于 MAG。

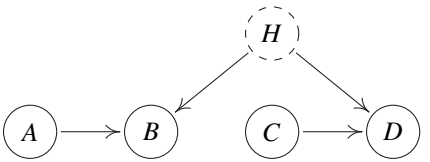

图9.4：此示例取自Richardson和Spirtes [2002, 图2(i)]。它表明有向无环图在边缘化下不是封闭的。不存在一个仅包含节点O = $\{A,B,C,D\}$的有向无环图，能够编码包括H在内的图中所有条件独立关系。

用DAG表示条件独立结构$P_{\mathbf{O}}$有两个众所周知的缺点：(1) 用观测变量上的DAG表示条件独立集可能导致因果误解；(2) 其独立模式对应于DAG中d-分离语句的分布集在边缘化下不封闭 [Richardson and Spirtes, 2002]。

对于(1)，考虑一个SCM，它蕴含一个分布$P_{A,B,C,H}$，该分布相对于图9.3（左）所示的相应DAG是马尔可夫且忠实的。在观测分布$P_{A,B,C}$中唯一能找到的（条件）独立关系是$A \perp\!\!\!\perp C$，因此图9.3（左起第二）中的DAG完美地表示了这种条件独立；在这个意义上，它可以被视为PC的输出。然而，因果解释是错误的。虽然在原始SCM中对C的干预对B没有任何影响，但PC的输出表明从C到B存在因果效应。关于(2)，图9.4（它展示了一个取自Richardson和Spirtes [2002]的图）展示了一个关于变量X = (O, H)的SCM结构，其分布相对于一个DAG $\mathcal{G}$ ($\mathcal{G}$是马尔可夫且忠实的，该DAG表示X)中的所有条件独立，满足以下性质。不存在关于O的DAG能够表示在$P_{\mathbf{O}}$中找到的条件独立。在这个意义上，DAG在边缘化下不封闭。

以下小节讨论了一些建议用图（在O上）表示条件独立性的想法。然而，请注意，这些想法并不一定具有直观的因果含义。可能难以从图形对象推断出底层SCM（在$\mathbf{X} = (\mathbf{O}, \mathbf{H})$上）的结构性质。例如，第6.6节中的调整图形准则需要针对每种图类型重新开发和证明。

9.4.1 图

之前，我们使用图来表示SCM的结构关系；参见定义3.1和6.2。本节的目标有所不同：在这里，目的是使用图来表示由SCM诱导的分布中的约束。在本节9.4中，我们主要考虑条件独立关系，并在9.5节中更详细地讨论其他约束。我们已经看到，在存在隐藏变量的情况下，DAG不是表示条件独立性的好选择。DAG的这些缺点推动了因果推断中新图形表示的发展。例如，Richardson和Spirtes [2002]引入了最大祖先图（MAGs），并表明它们构成了在边缘化下封闭的DAG的最小超类（见前面的讨论）。这些是混合图，包含有向边和双向边。[2] MAGs带有略微不同的分离准则：现在不是*d*-分离，而是查看*m*-分离[Richardson和Spirtes，2002]。然后，对于每个带有隐藏变量的DAG，在观察变量上存在一个唯一的MAG，它表示相同的条件独立集（通过*m*-分离）；Richardson和Spirtes [2002，第4.2.1节]提供了一个简单的构造协议，示例见图9.3。这种映射不是一对一的。每个MAG都可以由无限多个不同的DAG（包含任意数量的隐藏变量）构造出来。与DAG一样，马尔可夫条件将MAG中的图形分离陈述与条件独立联系起来。表示相同*m*-分离集的不同MAG被归纳在一个马尔可夫等价类中[Zhang，2008b]；这个等价类本身通常由部分祖先图（PAG）表示；参见表9.1的概述。在PAG中，边可以以圆圈结尾，这表示箭头头部和尾部两种可能性；参见图9.3。Ali等人[2009]提供了确定两个MAG是否马尔可夫等价的图形准则。

[2] In fact, they may even contain undirected edges and can therefore model selection bias. We refer to Richardson and Spirtes [2002] for details.

Category	GMDA (Mixed-method research)	GAM	GPI	GADGAD (Both)
Cognitive behavioral therapy	✓	✓	✓	✓
Psychodynamic therapy	✓	✓	✓	✗
Exposure therapy	✓	✓	✓	✗
Mindfulness-based stress reduction	✓	✓	✓	✗
Acceptance and commitment therapy	✓	✓	✓	✗
Dialectical behavior therapy	✓	✓	✓	✗
Interpersonal therapy	✓	✓	✓	✗
Supportive therapy	✓	✓	✓	✗
Problem-solving therapy	✓	✓	✓	✗
Motivational interviewing	✓	✓	✓	✗
Solution-focused brief therapy	✓	✓	✓	✗
Narrative therapy	✓	✓	✓	✗
Emotion-focused therapy	✓	✓	✓	✗
Schema therapy	✓	✓	✓	✗
Transference-focused psychotherapy	✓	✓	✓	✗
Mentalization-based therapy	✓	✓	✓	✗
Systems training for emotional predictability and problem solving	✓	✓	✓	✗
Collaborative assessment and management of suicidality	✓	✓	✓	✗
Dialectical behavior therapy for suicide prevention	✓	✓	✓	✗
Cognitive therapy for suicide prevention	✓	✓	✓	✗
Attempted suicide short intervention program	✓	✓	✓	✗
Suicide prevention effectiveness trial	✓	✓	✓	✗
Treatment of suicidal inpatients study	✓	✓	✓	✗
Emergency department intervention for suicide trial	✓	✓	✓	✗
Ketamine for treatment-resistant depression in adolescents with suicidality	✓	✓	✓	✗
Comparison of the beck depression inventory-ii and the patient health questionnaire-9 for screening patients for depression	✓	✓	✓	✗
Screening for suicidal risk in medical settings	✓	✓	✓	✗
Columbia-suicide severity rating scale screener	✓	✓	✓	✗
Ask suicide-screening questions	✓	✓	✓	✗
Patient health questionnaire-9	✓	✓	✓	✗
Beck depression inventory-ii	✓	✓	✓	✗
Hamilton rating scale for depression	✓	✓	✓	✗
Montgomery–asberg depression rating scale	✓	✓	✓	✗
Quick inventory of depressive symptomatology	✓	✓	✓	✗
Inventory of depressive symptomatology	✓	✓	✓	✗
Geriatric depression scale	✓	✓	✓	✗
Edinburgh postnatal depression scale	✓	✓	✓	✗
Zung self-rating depression scale	✓	✓	✓	✗
Cornell scale for depression in dementia	✓	✓	✓	✗
Children's depression rating scale, revised	✓	✓	✓	✗
Columbia-suicide severity rating scale	✓	✓	✓	✗
Scale for suicide ideation	✓	✓	✓	✗
Suicide intent scale	✓	✓	✓	✗
Suicide probability scale	✓	✓	✓	✗
Suicide assessment five-inventory	✓	✓	✓	✗
Risk-of-suicide questionnaire	✓	✓	✓	✗
Modified scale for suicidal ideation	✓	✓	✓	✗
Reasons for living inventory	✓	✓	✓	✗
Suicide opinion questionnaire	✓	✓	✓	✗
Adult suicidal ideation questionnaire	✓	✓	✓	✗
Multidimensional scale of perceived social support	✓	✓	✓	✗
Social provisions scale	✓	✓	✓	✗
Social support questionnaire	✓	✓	✓	✗
Interpersonal support evaluation list	✓	✓	✓	✗
Beck hopelessness scale	✓	✓	✓	✗
Adult hope questionnaire	✓	✓	✓	✗
Snyder hope scale	✓	✓	✓	✗
Herth hope index	✓	✓	✓	✗
Miller hope scale	✓	✓	✓	✗
Nowotny hope scale	✓	✓	✓	✗
Dispositional hope scale	✓	✓	✓	✗
Children's hope scale	✓	✓	✓	✗
Adult hope scale	✓	✓	✓	✗
Life orientation test	✓	✓	✓	✗
Optimism/pessimism questionnaire	✓	✓	✓	✗
Revised life orientation test	✓	✓	✓	✗
Life orientation test-revised	✓	✓	✓	✗
Dispositional optimism

例 9.5（Y-结构）鉴于甚至单个 MAG 就能表示任意数量的隐藏变量，人们可能会想，由一个含有隐藏变量的 DAG 构造出的 PAG 是否总包含非平凡的因果信息。例如，在图 9.3 中，PAG 并未指明 C 与 B 之间是否存在有向路径，或存在一个隐藏变量，其有向路径同时指向 C 和 B。图 9.2（右）展示了 Y-结构的一个例子（Z_1、Z_2 和 Y 之间没有直接连接）。现在考虑一个包含任意数量变量的 SCM，其中包含四个变量 X、Z_1、Z_2 和 Y，该 SCM 在这四个变量上诱导出的条件独立性与 Y-结构相同。由此我们可以推断，对应的 PAG 中包含一条从 $X \to Y$ 出发的有向边。此外，X 与 Y 之间的因果关联必须是无混杂的 [例如，Mani et al., 2006, Spirtes et al., 2000, 图 7.23]。任何 SCM，若其中 X 和 Y 受到混杂，或 X 不是 Y 的祖先，都会导致一组不同的条件独立性。

□

我们已经提到，诸如MAGs之类的图形对象主要是为了表示条件独立性而构建的，并非用于可视化SCMs（这是我们在定义3.1中引入图的方式）。因此，因果语义变得更加复杂。例如，在一个MAG中，边$A \to B$意味着在底层的DAG（包括隐藏变量）中，A是B的祖先，而B不是A的祖先；也就是说，祖先关系得到了保留。以图9.3中的PAG为例，其解释应为：“在底层的DAG中，可能存在从C到B的有向路径，一个隐藏的共同原因，或两者的组合。”因此，在这类图中进行因果推理，即计算干预分布，也变得更加复杂[例如，Spirtes等人，2000年，Zhang，2008b]。Perkovic等人[2015]描述了有效调整集（第6.6节），这些调整集不仅适用于DAGs，也适用于MAGs。

作为MAG和PAG的替代方案，可以考虑诱导路径图（IPG）和（完全）部分定向诱导路径图（POIPG），它们可用于表示IPG的集合[Spirtes et al., 2000, Section 6.6]。这些图最初被用于表示快速因果推断（FCI）算法的输出；参见第9.4.2节。考虑一个相对于MAG是马尔可夫且忠实的分布。由于每个MAG都是一个IPG，但反之不成立，MAG的马尔可夫等价类包含在相应IPG的马尔可夫等价类中，因此PAG通常比POIPG包含更多的因果信息[Zhang, 2008b, Appendix A]。

还有一种可能性是从包含隐变量的原始DAG开始，然后应用潜在投影[参见Pearl, 2009, Verma和Pearl, 1991, 分别为定义2.6.1和“嵌入模式”]。此操作

取一个带有观测变量和隐藏变量的图 $\mathcal{G}$，并在观测变量上构造一个新的图对象$\tilde{\mathcal{G}}$。精确的定义可以在 Shpitser 等人 [2014，定义 4] 中找到，例如。所得图结构称为无环有向混合图（ADMG），包含有向边和双向边。同样，*m*-分离导致马尔可夫性质 [Richardson，2003]。现在，我们可以搜索 ADMG，而不是搜索带有潜在变量的 DAG。

我们将在第9.5节中看到，来自含有潜在变量的DAG的观测变量分布满足除条件独立性之外的约束。ADMGs遵循以下方式考虑其中一些约束的可能性。其思想是定义一个嵌套马尔可夫性质[Richardson等人，2012, 2017, Shpitser等人，2014]，使得一个分布关于ADMG是嵌套马尔可夫的，如果不仅由图结构暗示的一些条件独立性成立，而且还满足其他约束；例如，参见第9.5.1节。事实证明，即使是嵌套马尔可夫性质也不能编码所有约束（虽然在离散情况下它们确实编码了所有等式约束[Evans，2015]）。因此我们有[Shpitser等人，2014]：

$$\{P_{\mathrm{O}} : P_{\mathbf{O},\mathbf{V}} \text{ 由带有潜在变量的DAG } \mathcal{G} \text{ 诱导 }\} \subseteq \{P_{\mathbf{O}} : P_{\mathbf{O}} \text{ 关于相应的ADMG嵌套马尔可夫 }\} \subseteq \{P_{\mathbf{O}} : P_{\mathbf{O}} \text{ 关于相应的ADMG马尔可夫 }\}.$$

对于具有离散数据和普通马尔可夫性质的ADMGs，Evans和Richardson [2014] 提供了一种参数化方法。这种参数化方法可以扩展到嵌套马尔可夫模型，并且可用于计算（约束）最大似然估计量 [Shpitser等人，2012]。如果每对节点之间只有一种边，则ADMGs被称为无弓形（bow-free）。对于线性高斯模型，这一模型子类允许参数可识别性 [Brito和Pearl，2002a]；此外，还有计算最大似然估计 [Drton等人，2009a] 或进行因果学习 [Nowzohour等人，2015] 的算法。

链图由有向边和无向边组成，不允许存在部分有向环[Lauritzen, 1996, 第2.1.1节]。关于链图已有大量研究工作；例如，可参见Lauritzen [1996]的综述以及Lauritzen和Richardson [2002]的因果解释。需要注意的是，对于链图，已提出了不同的马尔可夫性质[Lauritzen and Wermuth, 1989, Frydenberg, 1990, Andersson et al., 2001]。

总结来说，约束的表示（到目前为止，我们主要讨论了条件独立性）使用图，特别是在隐藏

变量，是一项仍在活跃研究中的非平凡任务；Sadeghi 和 Lauritzen [2014] 关联了几种类型的混合图并讨论了它们的马尔可夫性质。通常，图形对象及其相应的分离准则很复杂，并且将边与因果效应的存在联系起来并非易事（尽管有人可能会认为嵌套马尔可夫模型是朝着简化迈出的一步）。令人惊讶的是，尽管在某些情况下存在所有困难（参见示例 9.5 中的 Y 结构），我们仍然能够学习因果祖先关系。

9.4.2 快速因果推断

我们已经看到，对于结构学习，PAG 可能比 CPDAG 更合理。实际上，可以修改 PC 算法使其输出 PAG [Spirtes et al., 2000, Section 6.2]。虽然这种对 PC 的简单修改在许多例子中表现良好，但通常并不正确。在每次迭代中，PC 算法考虑一对（当前）相邻节点 A 和 B，并寻找一个将它们 d 分离的集合。为了实现显著的加速，它仅基于第 7.2.1 节中的引理 7.8(ii)，在当前邻居节点 A 和 B 的子集中进行搜索。然而，在存在隐藏变量的情况下，将搜索空间限制在邻居集合的子集上已不再足够 [Verma and Pearl, 1991, Lemma 3]；Spirtes et al. [2000, Section 6.3] 提供了一个例子，其中修改后的 PC 算法无法找到一个 d 分离集。

FCI算法[Spirtes et al., 2000]解决了这个问题。它输出一个表示多个MAG的PAG。Zhang和Spirtes[2005]以及Zhang[2008a]证明，对原始FCI算法稍作修改即可使其完备。也就是说，其输出具有最大信息量。如果条件独立性源自含有隐变量的DAG，则输出确实表示正确的对应PAG。

FCI的若干改进带来了显著的加速。Spirtes [2001] 提出限制条件集的大小（anytime FCI），而 Colombo 等人 [2012] 减少了条件独立性检验的数量和条件集的大小（really fast causal inference）。这两种算法在信息量上可能略逊于 FCI。它们被 FCI+ 所取代，后者既快速又完备 [Claassen et al., 2013]。

作为一种替代方案，人们可能会考虑对MAGs或MAGs的等价类进行评分。这类评分函数仅对某些类型的结构因果模型（SCMs）存在，例如线性SCMs[Richardson and Spirtes, 2002]；同时，我们尚未发现任何高效搜索此MAGs空间的方法[Mani et al., 2006]。Silva和Ghahramani[2009]探讨了学习混合图的一种贝叶斯方法。

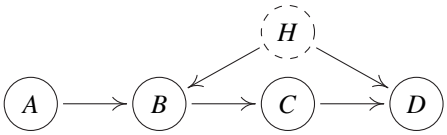

图 9.5：任何关于此图具有马尔可夫性的分布都满足 Verma 约束 (9.3)，这是一个出现在关于 A、B、C 和 D 的边缘分布中的非独立性约束；虚线变量 H 未被观测到 [Verma and Pearl, 1991]。

9.5 超越条件独立性的约束

我们已经提到，含有隐变量的模型可能导致不同于条件独立约束的约束。我们将提及其中一些，以培养我们对可能遇到的约束类型的直觉，但主要推荐查阅文献以获取详情；关于近期的工作及大量早期工作的参考文献，也可参见Kela等人[2017]。

9.5.1 Verma 约束

Verma 和 Pearl [1991] 提供了图 9.5 所示的例子。任何关于相应图满足马尔可夫性的分布都允许以下 Verma 约束 [例如，Spirtes 等人，2000，第 6.9 章]。对于某个函数 f，我们有

$$\sum_b p(b\,|\,a)p(d\,|\,a,b,c) = f(c,d). \tag{9.3}$$

与条件独立性约束不同，(9.3)使我们能够判断是否存在从A到D (的有向边，注意在图9.5中A和D不能是d-分离的)。尽管关于这些代数约束的许多未解问题仍然存在，但人们在理解这类约束何时出现方面已取得了进展[Tian and Pearl, 2002]。Shpitser和Pearl [2008b]研究了休眠独立性的特殊子类；这些约束在干预分布中表现为独立性约束。

问题依然在于如何利用这些约束进行因果学习。例如，在二元变量的情况下，Richardson等人[2012, 2017]和Shpitser等人[2012]使用嵌套马尔可夫模型对此类模型进行参数化，并提供了一种计算（约束）最大似然估计量的方法；另见第9.4.1节。然而，嵌套马尔可夫模型并未包含所有不等式约束，我们将在下一节讨论这些约束。

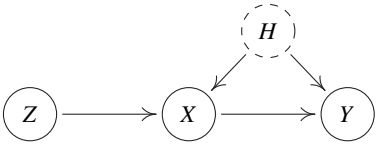

(一个)因果结构，其中Z被称为X的工具，并使得关于X对Y影响的一些因果陈述成为可能。

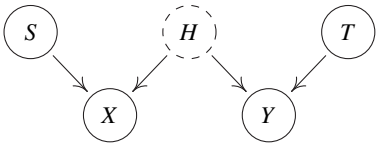

(b) 量子物理学家用来否证经典物理假设的一个著名实验的因果结构；见9.5.2节。

图9.6：两个涉及不等式约束的潜在结构的重要示例。

9.5.2 不等式约束

将图模型对某些变量进行边缘化会引出一大组不等式约束[参见，例如，Kang and Tian, 2006, Evans, 2012, 及其参考文献]。提及所有已知的约束将超出本书范围。相反，我们想指出它们已被应用的领域的多样性。为此，我们考虑两个包含已观测和未观测变量的示例DAG，它们出现在完全不同的背景中。注意，本节仅讨论涉及可观测变量的*observational*分布的不等式，而文献中还包含关联可观测变量的观测分布和干预分布的不等式[参见，例如，Balke, 1995, Pearl, 2009, 第8章]，有时还带有附加假设[Silva and Evans, 2014, Geiger et al., 2014]。前一项任务旨在证伪一个假设的潜在结构，而后一项任务则允许在相应DAG为真时对干预作出陈述。为了展示一些仅涉及观测概率的不等式，图9.6(a)中具有二元变量的因果结构意味着，例如，

$$P(X=0,Y=0|Z=0)+P(X=1,Y=1|Z=1)\leq 1. \tag{9.4}$$

文献中已提供此类不等式 [Bonet, 2001, eq. (3)] 以检验一个变量是否为工具变量。该有向无环图在分析具有不完全依从性的随机临床试验中起着关键作用，其中 Z 是服用某种药物的指令，X 描述患者是否服用了该药物（例如，假设这可以从血液检测中推断），而 Y 表示患者是否康复 [参见，例如，Pearl, 2009]。

因果结构 如图 9.6(b) 所示，已知对于 instan ce，那个

克劳泽-霍恩-希莫尼-霍尔特（CHSH）不等式[Clauser et al., 1969]：

$$\begin{aligned}\mathbb{E}[XY|S=-1,T=-1]+\mathbb{E}[XY|S=-1,T=1]\\ +\mathbb{E}[XY|S=1,T=-1]+\mathbb{E}[XY|S=1,T=1]\leq 2\end{aligned} \tag{9.5}$$

如果X,Y,S,T在$\{-1,1\}$中取值。方程(9.5)是贝尔不等式[Bell, 1964]的推广。潜在的共同原因可以取任意多个值，正如存在一个变量d将$\{X,S\}$与$\{Y,T\}$分离意味着(9.5)一样。值得注意的是，在量子物理中，在一个人们直观上会同意潜在因果结构是图9.6(b)所示的情景中，CHSH不等式被违反。两位物理学家A和B在不同地点接收来自由H描述的公共源的粒子。变量X和Y分别描述对A和B接收到的粒子进行的二分测量的结果。S是一次抛硬币，决定由A执行两种可能选项中的哪一种测量。同样，T是一次抛硬币，决定由B执行的测量。X和Y的未观察到的共同原因是A和B接收到的粒子的公共源。根据一种广泛接受的解释，实验中观察到的(9.5)的违反[Aspect et al., 1981]表明，不存在描述入射粒子联合状态的经典随机变量H，使得在给定H的情况下，$\{S,X\}$和$\{T,Y\}$条件独立。这是因为量子物理系统的状态不能由随机变量的值来描述。相反，它们是希尔伯特空间上的密度算子。

自潜在结构的信息论不等式因其有时比直接涉及概率的不等式更易于处理而引起了关注[参见，例如，Steudel and Ay, 2015]。Chaves等人[2014]描述了针对离散变量情况的一类不等式，该类不等式虽不完备，但可通过以下系统方法生成。

首先，从一个由结构因果模型（SCM）在 d 个离散变量 $\mathrm{X} := (X_1,\ldots,X_d)$ 上蕴含的分布开始。对于给定的联合分布 $P_{X_1,\ldots,X_d}$，我们可以定义一个函数

$$H : 2^{\mathbf{X}} \to \mathbb{R}_0^+$$

使得 $H(X_{j_1},\ldots,X_{j_k})$ 是 $(X_{j_1},\ldots,X_{j_k})$ 的香农熵[3]。著名的

[3]We write $H(X_{j_1},\ldots,X_{j_k})$ instead of $H\big((X_{j_1},\ldots,X_{j_k})\big)$ for notational convenience and again perform set operations on vectors.

H 的性质是基本不等式

$$\begin{aligned} H(S\cup\{X_j\}) &\geq H(S) && (9.6)\\ H(S\cup\{X_j,X_k\}) &\leq H(S\cup\{X_j\})+H(S\cup\{X_k\}) && (9.7)\\ H(\emptyset) &= 0, && (9.8)\end{aligned}$$

其中 S 表示 X 的一个子集。不等式 (9.6) 和 (9.7) 分别称为单调性和子模性条件；另见第 6.10 节。此外，不等式 (9.6)–(9.8) 在组合优化中也称为多拟阵公理。

为了利用因果结构，我们现在回顾，对于节点的所有三个不相交子集 S、T 和 R，其中 S 和 T 被 R 以 d 分离。这可以用香农互信息 [Cover and Thomas, 1991] 重新表述为

$$I(S:T\,|\,R)=0, \tag{9.9}$$

这相当于

$$H(S\cup R)+H(T\cup R)=H(S\cup T\cup R)+H(R). \tag{9.10}$$

值得注意的是，(9.10) 是一个线性方程。由于条件独立定义了概率向量空间上的 *nonlinear* 约束，考虑熵向量空间上的约束更为方便。

这些基本不等式与公式 (9.9) 结合，可推导出更多不等式。为了以算法方式导出它们，Chaves 等人 [2014] 使用了线性规划中的一种技术，即 Fourier-Motzkin 消元法 [Williams, 1986]。给定观测变量的某个子集 O $\subset$ X，该过程通常会产生仅包含 O 中变量熵的不等式，尽管可能不存在仅包含观测变量的条件独立约束。图 9.7 给出了一个例子，对于该例，Chaves 等人 [2014, 定理 1] 得到

$$I(X:Z)+I(Y:Z)\leq H(Z), \tag{9.11}$$

同样地，对于变量名的循环置换也是如此。违反(9.11)的一个联合分布的例子是，所有观测变量均为0或所有变量均为1，且每种情况的概率为$1/2$，因为此时$H(Z)=1$比特且$I(X:Z)=I(Y:Z)=1$比特。为了直观理解这一点，请注意在这个例子中，对于每个观测节点，比如Z，我们要求它与X和Y以及因此与U和V都存在确定性关系。但是，在Z能在多大程度上由其未观测原因U或由V决定之间存在权衡。Z无法同时完美遵循U和V的“指令”（而它们本身是相互独立的）。

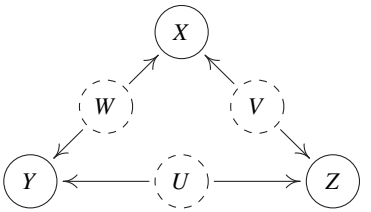

图9.7：无法生成一个关于X, Y和Z的联合分布的DAG，其中三个观测变量同时以概率1/2分别取0或1。

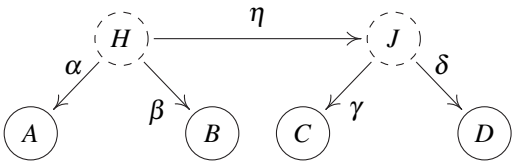

图9.8：如果图对应于线性结构因果模型，则所蕴含的分布将满足四分体约束(9.12)–(9.14)。

9.5.3 基于协方差的约束

另一类约束出现在含隐变量的线性模型中。例如，在图9.8中，我们得到四分体约束[Spirtes et al., 2000, Spearman, 1904]：

$$\rho_{AC}\rho_{BD} - \rho_{AD}\rho_{BC} = 0 \tag{9.12}$$

$$\rho_{AB}\rho_{CD} - \rho_{AD}\rho_{BC} = 0 \tag{9.13}$$

$$\rho_{AC}\rho_{BD} - \rho_{AB}\rho_{CD} = 0, \tag{9.14}$$

其中ρ_{AC}是变量A和C之间的相关系数。例如，第一个约束条件（9.12）可以从图9.8中轻易验证：

$$\begin{aligned}\operatorname{cov}[A,C]\cdot\operatorname{cov}[B,D] &= \alpha\gamma\eta\operatorname{var}[H]\cdot\beta\delta\eta\operatorname{var}[H] \\ &= \alpha\delta\eta\operatorname{var}[H]\cdot\beta\gamma\eta\operatorname{var}[H] = \operatorname{cov}[A,D]\cdot\operatorname{cov}[B,C].\end{aligned}$$

可以使用 treks 和 choke points 的语言以图形方式刻画消失四元组约束的出现 [Spirtes et al., 2000, Theorem 6.10]。同样，这些约束使我们能够仅从观测数据中区分不同的因果结构。Bollen [1989] 和 Wishart [1928] 构建了统计检验来检验消失四元组差异。这些可以转化为可用于因果学习的分数；例如，Spirtes et al. [2000, Chapter 11.2] 和 Silva et al. [2006] 对此进行了研究。

Kela等人[2017]考虑了潜在结构，其中观察变量之间的所有依赖关系均源于一组独立的共同原因，并描述了观察变量可能协方差矩阵的约束条件。他们强调，相较于使用完整分布，采用协方差矩阵在统计可行性和计算易处理性方面均具有优势。通过利用观察变量的函数（即，通过将它们映射到特征空间，类似于基于再生核希尔伯特空间的方法），该方法还能考虑到更高阶的依赖关系。

9.5.4 加性噪声模型

我们在第7.2.3节提到，学习LiNGAMs的结构可以基于ICA。Hoyer等人[2008b]表明，通过利用过完备ICA下已知的信息，可识别性陈述和方法都可以扩展到具有隐藏变量的线性非高斯结构。

对于非线性ANM（第4.1.4节），我们已看到在一般情况下，不能同时有$Y = f(X) + N_Y$与$N_Y \perp\!\!\!\perp X$以及$X = g(Y) + M_X$与$M_X \perp\!\!\!\perp Y$。我们预期对于隐变量也存在类似的可识别性。以下ANM描述了隐变量H对可观测变量X和Y的影响：

$$H := N_H \tag{9.15}$$
$$X := f(H) + N_X \tag{9.16}$$
$$Y := g(H) + N_Y. \tag{9.17}$$

对于足够低噪声的情形，Janzing等人[2009a]证明了联合分布$P_{H,X,Y}$可以从$P_{X,Y}$重构，直至H的重参数化。合理的是，低噪声的限制并非必要，而仅是证明的一个弱点。设定$f(H) = H$和N_X =为0，可得到从X到Y (的一个ANM；同样，我们可以获得从Y到X)的一个ANM；这表明加性噪声假设使得三种情况$X \to Y$、$X \leftarrow Y$和$X \leftarrow * \to Y$仅凭$P_{X,Y}$即可区分。与降维的关系有助于我们理解如何从数据拟合模型(9.15)–(9.17)：分布$P_{X,Y}$中的数据点(x,y)可通过以下步骤抽取（见图9.9）：

1. 根据P_H绘制h。
2. 考虑流形上对应的点 $\big(f(h), g(h)\big)$

$$M := \big\{ \big(f(h), g(h)\big) \in \mathbb{R}^2 : h \in \mathbb{R} \big\}. \tag{9.18}$$

3在每个维度中添加一些独立噪声（n_X, n_Y）。 on.

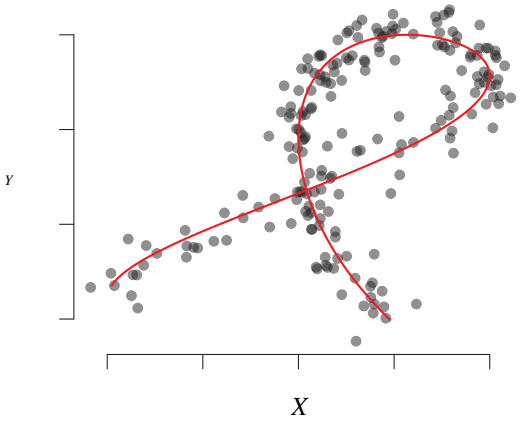

图9.9：该图显示了$P_{X,Y}$的散点图。红线描述了流形M；参见方程(9.18)。

为了将模型(9.15)–(9.17)拟合到来自$P_{X,Y}$的数据样本，我们可以因此对样本应用降维技术以获得估计值$\hat{M}$。为了从给定点(x,y)恢复h的相应值，这个点(x,y)不应投影到流形M上，因为这通常会导致残差依赖于H。我们要求残差尽可能独立于H，而不是小的残差（n_X, n_Y）[Janzing et al., 2009a]。

关于带有隐藏变量的ANM的可识别性，仍有许多未解决的问题。然而，这样的结果可能具有重要的意义：每当我们发现一个从X到Y的ANM，而不是从Y到X的ANM时，这些可识别性结果将表明效应并未混杂（在加性噪声的模型类别内）。

9.5.5 检测低复杂度混杂因素

这里我们解释Janzing等人[2011]提出的两种方法，用于推断两个观测变量X和Y之间的路径是否由某个仅取少数几个值的变量中介；见图9.10。情景如下：X通过一个有向无环图与Y存在因果联系，该图在Y处有一个箭头。问题是X和Y之间的路径是否由一个仅取少数几个值的变量U中介。在这里，连接X和U的箭头方向并不重要，但该方法的典型应用是，当中介混杂路径的变量U属于这种简单类型时，检测混杂。Janzing

图9.10：检测低复杂度中间变量：若X与Y之间的路径被某些仅取少数值的变量U所阻断，则$P_{Y|X}$常表现出典型特性，作为U的“指纹”。

et al. [2011] 考虑例如两个二元变量 X 和 U 描述动植物遗传变异（单核苷酸多态性）以及一个与某种表型对应的变量 Y。每当 X 和 Y 之间的统计依赖仅由于 U 对 Y 有影响且 U 与 X 在统计上相关时，U 就扮演这种中间变量的角色。在此，U 和 X 彼此都不构成对方的原因，但存在像“族群”这样的变量同时影响两者。因此，U 本身并非共同原因，而是位于混杂路径上。

检测这类混杂的想法是，U以特征性的方式改变条件分布$P_{Y|X}$。为了讨论这一点，我们首先定义一类条件分布，稍后我们将表明，通常只有当X和Y之间的路径被这样的U以*not*方式中介时，这类条件分布才会出现。

定义 9.6（成对纯条件句）*The conditional distribution $P_{Y|X}$ is said to be pairwise pure if for any two $x_1, x_2 \in \mathcal{X}$ the following condition holds. There is no $\lambda < 0$ or $\lambda > 1$ for which*

$$\lambda P_{Y|X=x_1} + (1-\lambda) P_{Y|X=x_2} \tag{9.19}$$

is a probability distribution.

要理解定义9.6，请注意(9.19)对于$\lambda \in [0,1]$始终是一个概率分布，因为它此时是两个分布的凸和。另一方面，对于$\lambda \notin [0,1]$，(9.19)可能不再是一个非负测度：考虑Y取有限多个值$\mathcal{Y} := \{y_1, \ldots, y_k\}$的情况。那么$Y$的分布空间是一个单纯形，其$k$个顶点由$y_1, \ldots, y_k$上的点质量给出。图9.11展示了$k = 3$的情况，其中$\mathcal{Y}$上的概率分布空间是一个三角形。图9.11(a)展示了一个纯条件分布的示例：延长$P_{Y|X=x_1}$和$P_{Y|X=x_2}$之间的连线会离开三角形，而在图9.11(b)中，这种在分布空间内的延长是可能的。然而，图9.12表明，纯度比点$P_{Y|X=x}$位于单纯形内部的条件更强。在这里，它们位于三角形的边上，却仍然允许在三角形内进行延长。

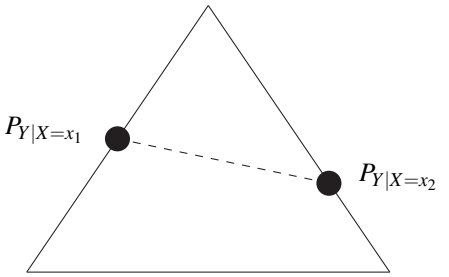

(a) Example of a pure conditional: extending the line connecting the two points $P_{Y|X=x_1}$ and $P_{Y|X=x_2}$ would leave the simplex of probability distributions.

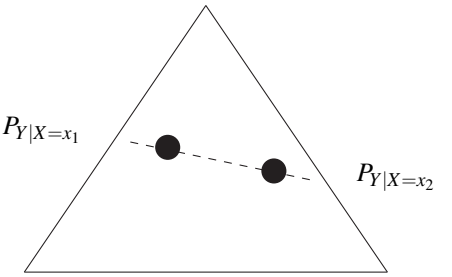

(b) Example of a non-pure conditional: the line connecting $P_{Y|X=x_1}$ and $P_{Y|X=x_2}$ can be slightly extended without leaving the simplex.

图9.11：纯条件和非纯条件的可视化。

如果 $P_{Y|X}$ 具有密度 (x,y)，则 $\mapsto p(y|x)$ 纯度可以通过以下直观条件来定义：

$$\inf_{y\in\mathcal{Y}} \frac{p(y|x_1)}{p(y|x_2)} = 0 \quad \forall x_1, x_2 \in \mathcal{X}.$$

要探讨与$X \to Y$在本质上相对应的因果条件句在多大程度上是纯粹的，必须留待未来研究。为了给出一个有趣的纯条件句类别的例子，我们想提到，如果$P_{Y|X}$允许具有双射函数f_Y的ANM [Janzing et al., 2011, Lemma 4]，并且噪声的密度满足某一衰减条件，则$P_{Y|X}$是成对纯粹的。

以下结果表明，一个纯条件强烈暗示 X 和 Y 之间的因果路径并非由一个仅取少数几个值的变量所中介。

定理 9.7（严格正条件与非纯性）*Assume there is a variable U such that $X \perp\!\!\!\perp Y \,|\, U$. Further, assume that the range $\mathcal{U}$ of U is finite and that the conditional density $p(u|x)$ is strictly positive for all $u \in \mathcal{U}$ and for all x such that $P_{Y|X=x}$ is defined. Then, $P_{Y|X}$ is not pairwise pure.*

证明。容易看出，条件 $P_{U|X}$ 不是成对纯的，因为对于所有定义了 $P_{Y|X=x_i}$ 的 x_1, x_2，$\inf_{u\in\mathcal{U}} p(u|x_1)/p(u|x_2) \neq 0$。由于 $p(y|x) = \sum_u p(y|u)p(u|x)$，条件 $P_{Y|X}$ 是 $P_{Y|U}$ 和 $P_{U|X}$ 的拼接，因此也不是纯的，因为 $P_{U|X}$ 不是纯的 [见 Janzing et al., 2011, Lemma 8]。□

虽然该定理对所有有限变量都成立，但条件$P_{U|X}$严格为正的第二个假设在U仅取

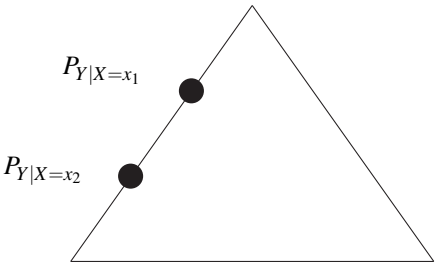

图9.12：非纯条件分布的另一个例子：连接$P_{Y|X=x_1}$和$P_{Y|X=x_2}$的直线可以延伸而不离开单纯形。

少数值。否则，可能会出现这样的情况：存在某些值u，使得$p(u|x)$非常接近于0，以至于可能导致$P_{Y|X}$成为*almost*纯的。

为了看到一个有启发性的例子，展示中间节点通常如何破坏纯度，假设U和X是二元的，且对于$u = x$有$p(u|x) = 1 - \varepsilon$。于是我们有

$$\begin{aligned} P_{Y|X=0} &= P(U=0|X=0)P_{Y|U=0} + P(U=1|X=0)P_{Y|U=1} \\ &= (1-\varepsilon)P_{Y|U=0} + \varepsilon P_{Y|U=1}. \end{aligned}$$

因此，$P_{Y|X=0}$ 位于连接 $P_{Y|U=0}$ 与 $P_{Y|U=1}$ (的线段内部，$P_{Y|X=1}$) 同理。所以，$P_{Y|X}$ 不是纯的。

另一个关于中间变量如何在$P_{X,Y}$分布中留下特征性“指纹”的例子，将利用条件[Allman et al., 2009, Janzing et al., 2011]的以下性质来阐述：

定义 9.8（条件的秩）*The rank of $P_{Y|X}$ is the dimension of the vector space spanned by all vectors $P_{Y|X\in\mathcal{A}}$ in the space of measures, where $\mathcal{A}$ runs over all measurable subsets of the range of X with non-zero probability.*

然而，Janzing等人[2011]并未提供估计秩的算法。如果Y具有有限范围，$P_{Y|X}$定义了一个随机矩阵，其秩与$P_{Y|X}$的秩一致。以下结果是一个简单的观察[Allman等人，2009]：

定理 9.9（U 的秩与值域）*If $X \perp\!\!\!\perp Y \,|\, U$ and U attains k values, then the rank of $P_{Y|X}$ is at most k.*

容易证明，在定理9.9的条件下，$P_{X,Y}$可以分解为k乘积分布的混合。这一观察可以推广到多变量情形：只要存在一个取k个值的变量U，使得在给定U的条件下，$X_1,\ldots,X_d$联合独立，那么$P_{X_1,\ldots,X_d}$分解为

转化为 d 个产品分布的混合。Sgouritsa 等人 [2013] 和 Levine 等人 [2011] 描述了寻找这种分解的方法，目的是通过识别产品分布来检测“混杂因素”U。

9.5.6 不同环境

我们在第7.1.6节和第7.2.5节中描述的不变因果预测方法可以修改以处理隐变量[Peters等人，2016，第5.2节]，只要隐变量不受干预的影响。此外，Rothenhäusler等人[2015，“backShift”]考虑了线性SCMs的特殊情况。假设我们观察到在不同环境$e \in \mathcal{E}$中的d个随机变量的向量X^e。在这里，环境是由（未知的）偏移变量$\mathrm{C}^e = (C_1^e, \dots, C_d^e)$生成的，这些变量要求彼此独立且与噪声变量独立。也就是说，对于每个环境e，我们有

$$\mathbf{X}^e = \mathbf{B}\mathbf{X}^e + \mathbf{C}^e + \mathbf{N}^e,$$

其中 N^e 的分布不依赖于 e。我们可以通过假设噪声变量的不同分量之间存在非零协方差来允许隐藏变量。由此仍然可以得出

$$(\mathbf{I} - \mathbf{B})\Sigma_{\mathbf{X},e}(\mathbf{I} - \mathbf{B})^T = \Sigma_{\mathbf{C},e} + \Sigma_{\mathbf{N}}$$

其中 $\Sigma_{\mathbf{X},e}$、$\Sigma_{\mathbf{C},e}$ 和 $\Sigma_{\mathbf{N}}$ 分别是 X^e、C^e 和 N^e 的协方差矩阵。因此，

$$(\mathbf{I} - \mathbf{B})\left(\Sigma_{\mathbf{X},e} - \Sigma_{\mathbf{X},f}\right)(\mathbf{I} - \mathbf{B})^T = \Sigma_{\mathbf{C},e} - \Sigma_{\mathbf{C},f}. \tag{9.20}$$

(请注意，对于每个环境 e，可以将所有其他环境合并以获得“环境”f。) 根据假设，对于所有 e 和 f 的选择，方程 (9.20) 的右侧是对角矩阵，这允许我们通过 $\Sigma_{\mathbf{X},e} - \Sigma_{\mathbf{X},f}$ 的联合对角化来重构因果结构 B。如果至少有三个环境，这一过程允许我们在弱假设下识别 B [Rothenhäusler et al., 2015, Theorem 1]。

后一个示例展示了如何在不同环境之间施加正则性条件（如线性模型和独立偏移干预），使我们即使在存在隐藏变量的情况下也能重建潜在的因果结构。

9.6 问题

问题9.10（充分性）*Prove Remark 9.4.*

问题 9.11（辛普森悖论）*Construct an SCM $\mathfrak{C}$ with binary random variables X, Y and a sequence $Z_1, Z_2, \ldots$ of variables, such that for all even $d \geq 0$ and all $z_1, \ldots, z_{d+1}$,*

$$\begin{aligned} &P^{\mathfrak{C}}(Y = 1 \,|\, X = 1, Z_1 = z_1, \ldots, Z_d = z_d) \\ &> P^{\mathfrak{C}}(Y = 1 \,|\, X = 0, Z_1 = z_1, \ldots, Z_d = z_d) \end{aligned}$$

but

$$\begin{aligned} &P^{\mathfrak{C}}(Y = 1 \,|\, X = 1, Z_1 = z_1, \ldots, Z_d = z_d, Z_{d+1} = z_{d+1}) \\ &< P^{\mathfrak{C}}(Y = 1 \,|\, X = 0, Z_1 = z_1, \ldots, Z_d = z_d, Z_{d+1} = z_{d+1}). \end{aligned}$$

This example drives the Simpson's paradox to an extreme. If X indicates treatment, Y recovery, and $Z_1, Z_2, \ldots$ some confounding factors, then, by the adjustment formula (6.13), adjusting for more and more variables always turns around the causal conclusion whether the treatment is helpful or harmful.

问题 9.12（工具变量）*Consider the SCM*

$$\begin{aligned} H &:= N_H \\ Z &:= N_Z \\ X &:= f(Z) + g(H) + N_X \\ Y &:= \alpha X + j(H) + N_Y \end{aligned}$$

and assume that we observe the joint distribution over Z, X, and Y. Given the distribution rather than a finite sample, regressing X on Z non-parametrically yields the conditional mean $\mathbb{E}[X \,|\, Z = z]$ as regression function. Write down the two-stage least square method and prove that it identifies α.

10

时间序列

关于指代不同时间实例的变量之间因果关系的推理，比没有时间结构的因果推理更容易。因果结构必须与时间顺序一致。我们在第7.2.4节中已经看到，在知道了节点的因果排序并假设不存在隐藏变量的情况下，寻找因果DAG不需要除马尔可夫条件和最小性之外的假设（例如，诸如忠实性或受限函数类等更有争议的条件则不是必需的）。给定时间顺序，仍有三个主要问题。第一，所考虑的变量集合可能不是因果充分的；第二，可能存在指代同一时间瞬间（在给定测量精度内）的变量，它们无法先验地按因果排序；第三，在实践中，我们通常只得到时间序列的一次重复——这与通常的i.i.d.设定不同，在后者中我们会多次观测每个变量。因此，所有这些问题在时间序列的因果推理中都起着至关重要的作用。

10.1 预备知识与术语

到目前为止，我们考虑了样本从联合分布 $P_{X_1,\dots,X_d}$ 中独立同分布抽取的情形。在这里，我们讨论时间序列中的因果推断，即我们有一个 d 维时间序列 $(\mathrm{X}_t)_{t\in\mathbb{Z}}$，其中对于固定的 t，每个 X_t 是向量 $(X_t^1,\dots,X_t^d)$。我们假设它描述了一个严格平稳随机过程 [例如，Brockwell and Davis, 1991]。每个变量 X_t^j 表示在时间 t 对某系统第 j 个可观测量的测量。由于因果影响永远不会

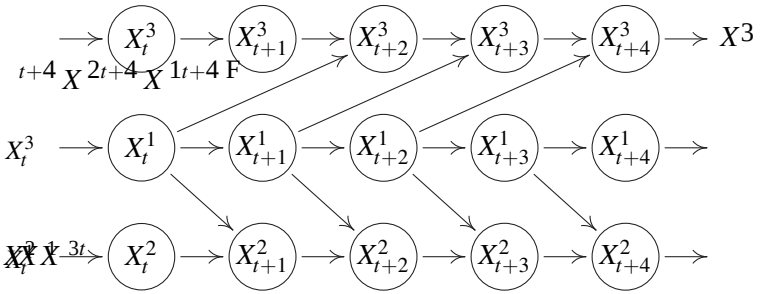

图10.1：无瞬时时间序列示例

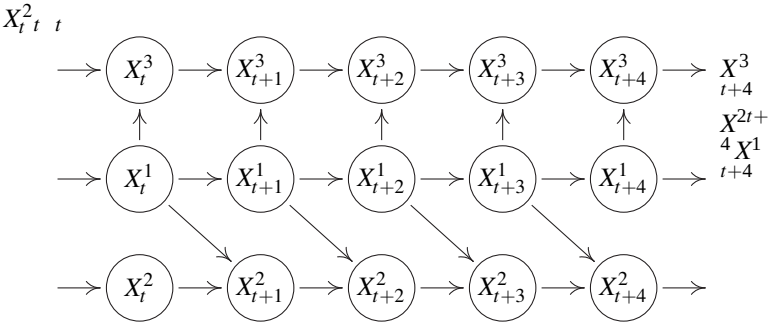

图10.2：具有瞬时效应的时间序列示例。

从未来到过去，我们区分多变量时间序列中的两种因果关

首先，节点为X_t^j的因果图[1]，对应于$(j,t) \in \{1,\dots,d\} \times \mathbb{Z}$，仅包含从$X_t^j$到$X_s^k$的箭头，对于$t < s$成立，但对$t = s$不成立；见图10.1。然后我们说没有瞬时效应。其次，因果图包含瞬时效应，即除了从X_t^m到X_s^ℓ的箭头（对于$t < s$以及某些m和ℓ）之外，还存在从X_t^j到X_t^k的箭头（对于某些j和k），如图10.2所示。如果对于任意$j \neq k$和$h > 0$，变量X_t^j可能影响X_t^k和X_{t+h}^j，但不影响X_{t+h}^k，则称该因果结构为纯瞬时结构；见图10.5(a)和10.5(b)。每个X_t^j不受任何先前变量（包括其自身过去）影响的情况可以忽略，因为它无需被描述为时间序列。相反，在之前章节的i.i.d.设定中，索引t可被视为统计样本中独立实例的标记索引。

我们将完整时间图定义为以 {v*} 为节点的有向无环图，可视化如下

[1]Strictly speaking, we have introduced the causal DAG only for finitely many nodes so far. Here, however, we need infinite graphs and neglect this technical subtlety [see, e.g., Peters et al., 2013].

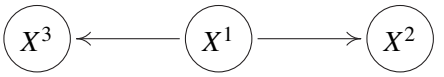

图10.3：图10.1和图10.2中所示的完整时间图的汇总图。

图10.1和10.2。与前几章不同，全时间图是一个具有无限多节点的有向无环图。摘要图是一个有向图，其节点为$X^1,\dots,X^d$，对于$j \neq k$，当存在从X_t^j到X_s^k的箭头对应某些$t \leq s \in \mathbb{Z}$时，包含一条从X^j到X^k的箭头。注意，摘要图是一个可能包含环的有向图，尽管我们将假设全时间图是无环的。图10.3展示了与图10.1和10.2中描绘的全时间图相对应的摘要图。对于任意$t \in \mathbb{Z}$，我们用$\mathrm{X}_{\mathrm{past}(t)}$表示所有$\mathrm{X}_s$的集合，其中$s < t$，并使用$X^j_{\mathrm{past}(t)}$表示特定组件$X^j$的过去。如果$t$是某个固定的参考时间点，我们也写作$X^j_{\mathrm{past}}$。此外，$(\mathrm{X}_t^{-j})_{t\in\mathbb{Z}}$表示所有$k \neq j$的时间序列$(\mathrm{X}_t^k)_{t\in\mathbb{Z}}$的集合。

10.2 结构因果模型与干预

我们假设随机过程 $(\mathrm{X}_t)_{t\in\mathbb{Z}}$ 可以由一个SCM描述，其中最多出现所有变量的过去q个值（对于某个q）：

$$X_t^j := f^j\left((\mathbf{PA}_q^j)_{t-q},\dots,(\mathbf{PA}_1^j)_{t-1},(\mathbf{PA}_0^j)_t,N_t^j\right), \tag{10.1}$$

其中

$$\dots,N_{t-1}^1,\dots,N_{t-1}^d,N_t^1,\dots,N_t^d,N_{t+1}^1,\dots,N_{t+1}^d,\dots$$

是联合独立的噪声项。在此，对于每个 $s \in \mathbb{Z}$，符号 $(\mathrm{PA}_s^j)_{t-s}$ 表示变量集 X_{t-s}^k、$k = 1,\dots,d$，这些变量影响 X_t^j。注意 PA_{t-s}^j 可能包含 X_{t-s}^j 对所有 $s > 0$，但不包含 $s = 0$。我们假设相应的全时间图是无环的。

(10.1) 的一个常见特殊情况是向量自回归模型（VAR）类 [Lütkepohl, 2007]：

$$X_t^j := \sum_{i=1}^{q} A_i^j \mathbf{X}_{t-i} + N_t^j, \tag{10.2}$$

其中每个 A_i^j 都是一个 $1 \times d$-矩阵；另见关于线性循环模型的注 6.5，特别是方程 (6.4)。

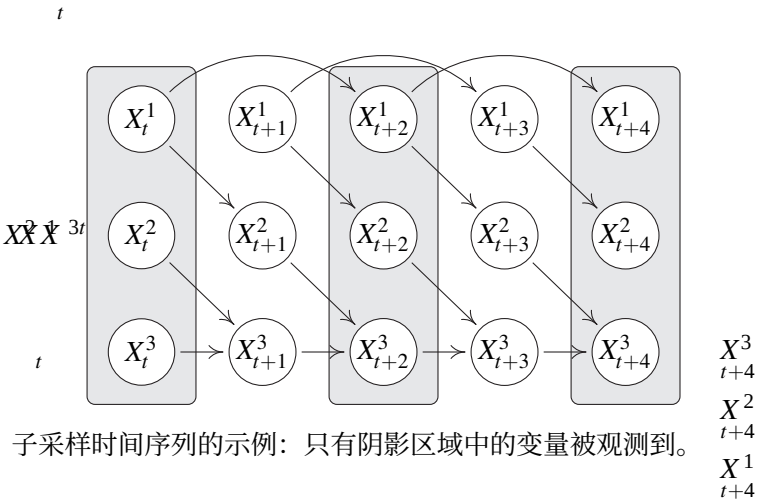

图 10.4：子采样时间序列的示例：只有阴影区域中的变量被观测到。

与i.i.d.设置一样，SCMs形式化了干预的效果；更准确地说，干预对应于替换某些结构赋值。例如，干预可能包括将某些j的所有值$\{X_t^j\}_{t\in\mathbb{Z}}$设置为特定值。或者，也可以仅在特定时间点$t$对$X_t^j$进行干预。

10.2.1 子采样

在许多应用中，采样过程可能比因果过程的时间尺度更慢。图10.4展示了一个例子，其中仅每隔一个时间实例被观测到。原始完整系统的汇总图包含边$X^1 \to X^2 \to X^3$。我们现在可能想要为观测到的、子采样的过程构建一个因果模型。因此，明确我们希望允许哪些干预非常重要。首先，如果我们将自己限制在对观测时间点上的干预，那么从X^1到X^2就不应有因果影响。对X^1的一个观测实例进行干预不会对X^2 (的可观测部分产生任何影响，注意时间序列X^1只有滞后两个效应$X_t^1 \to X_{t+2}^1$)。此外，在这种情况下，如果之前不存在虚假瞬时效应，子采样就不能创造它们。对于SCM的情形，Bongers等人[2016，第3章]描述了如何通过将隐藏时间步的因果机制代入其他机制来边缘化模型的形式化过程。如果干预被限制在观测时间点上，所得到的模型能正确描述干预的效果。其次，如果我们确实考虑对隐藏变量的干预，那么，我们可能感兴趣的是恢复原始汇—

mary graph，例如，这是 Danks 和 Plis [2013] 以及 Hyttinen 等人 [2016] 所探讨的问题。

存在这样的情况：子采样并不是数据生成过程的一个良好模型。例如，对于许多物理测量，人们可能希望将观测建模为连续时间点的平均值，而不是这些时间点的一个稀疏子集。前者是一种有用但也复杂的模型假设：平均过程可能会改变模型类别，而且人们还必须谨慎处理干预建模。

10.3 学习因果时间序列模型

目前，格兰杰因果关系及其变体是因果时间序列分析中最流行的方法之一。为了更好地连接各章节，我们仍然首先解释使用基于条件独立的方法可以得出的结论。这一顺序绝不应被误解为对这些方法的评判。

第10.3.1节和第10.3.2节主要包含可识别性结果。其余三个小节，即10.3.3、10.3.4和10.3.5节，包含了更多针对时间序列的具体因果学习方法。如果多变量时间序列仅在一个时间点、有限个时间点被采样，这些方法可被应用。然而，大多数思想可转移至我们接收到同一时间序列的多个独立同分布重复情况。

10.3.1 马尔可夫条件与忠实性

引理6.25指出，两个有向无环图是马尔可夫等价的，当且仅当它们的骨架和{v*}集合一致。若不存在瞬时效应，全时图便已通过其骨架得以确定。箭头的方向只能随时间向前。由此我们得出结论[Peters等，2013，定理1的证明]：

定理 10.1（无瞬时效应下的可识别性）*Assume that two full time graphs are induced by SCMs without instantaneous effects. If the full time graphs are Markov equivalent, then they are equal.*

因此，只要马尔可夫条件和忠实性成立，我们就能通过条件独立性唯一地识别出完整的时间图（为了处理无限大的有向无环图，有时会假设时间序列从 $t = 0$ 开始）。

在存在瞬时效应的情况下，马尔可夫等价图至多只能在那些效应的方向上有所不同。然而，在许多情况下，即使

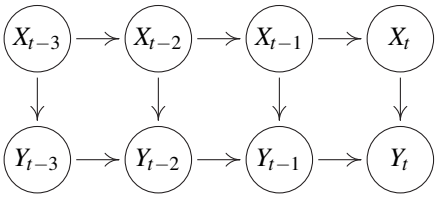

(a) There are v-structures at all nodes of $(Y_t)_{t\in\mathbb{Z}}$.

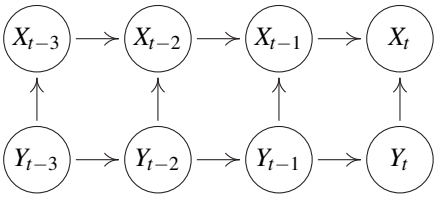

(b) There are v-structures at all nodes of $(X_t)_{t\in\mathbb{Z}}$.

图10.5：两个DAG不是马尔可夫等价的，尽管它们在瞬时效应上完全一致。

该方向可以被识别，因为瞬时效应的不同方向会导致不同的v-结构集合。图10.5展示了一个简单的例子。即使将所有$t \in \mathbb{Z}$到Y_{t+1}的箭头从X_t添加到图10.5中，瞬时效应的方向仍然可以被推断出来；同样，如果从Y_t到X_{t+1}添加箭头也是如此；然而，我们不能同时添加两者，因为这会移除所有的v-结构。Peters等人[2013，定理1]给出了瞬时效应方向可识别性的以下充分条件：

定理 10.2（无环摘要图的可识别性）*Assume that two full time graphs are induced by SCMs, and that in both cases for each j, X_t^j is influenced by X_{t-s}^j for some $s \geq 1$. Assume further that the summary graphs are acyclic. If the full time graphs are Markov equivalent, then they are equal.*

以下结果表明，原则上可以通过单个条件独立性检验来确定摘要图中是否存在任何箭头。

定理 10.3（格兰杰因果关系的正当性）*Consider an SCM without instantaneous effects for the time series $(\mathrm{X}_t)_{t\in\mathbb{Z}}$ such that the induced joint distribution is faithful with respect to the corresponding full time graph. Then the summary graph has an arrow from X^j to X^k if and only if there exists a $t \in \mathbb{Z}$ such that*

$$X_t^k \not\perp\!\!\!\perp X_{past(t)}^j \,|\, \mathbf{X}_{past(t)}^{-j}. \tag{10.3}$$

为完整起见，我们在附录 C.14 中包含了证明。类似的结果可以在 White 和 Lu [2010] 以及 Eichler [2011, 2012] 中找到。正如定理 10.3 的标题所暗示的，这是我们在第 10.3.3 节中更详细讨论的 Granger 因果关系的基础。

10.3.2 一些因果结论并不需要忠实性

值得注意的是，即使不使用忠实性，从条件依赖关系中也能得出有趣的因果结论。这与独立同分布（i.i.d.）情形形成对比，在后者中，对于任意节点排序，任何分布都关于完全DAG满足马尔可夫性。由于时间上没有向后的箭头，时间序列的马尔可夫条件足以推断出汇总图是$X \to Y$还是$Y \to X$，前提是两个备选之一为真。

定理 10.4（箭头 $X \to Y$ 的检测）*Consider an SCM for the bivariate time series* $(X_t, Y_t)_{t\in\mathbb{Z}}$.

(i) If there is a $t \in \mathbb{Z}$ *such that*

$$Y_t \not\perp\!\!\!\perp X_{past(t)} \,|\, Y_{past(t)}, \tag{10.4}$$

then the summary graph contains an arrow from X *to* Y.

(ii) Assume further that there are no instantaneous effects and the joint density of any finite subset of variables is strictly positive. If for all $t \in \mathbb{Z}$*, we have*

$$Y_t \perp\!\!\!\perp X_{past(t)} \,|\, Y_{past(t)}, \tag{10.5}$$

then the summary graph contains no arrow from X *to* Y.

同样，这个证明可能已经出现在其他地方，但为了完整性，我们在附录C.15中包含了它。证明(ii)需要因果最小性，这严格弱于忠实性。

在下一小节中，我们将看到定理10.4及其多种变体[例如，怀特和卢，2010年，艾希勒，2011年，2012年]将基于条件独立性的因果发现方法与格兰杰因果关系联系起来。

10.3.3 格兰杰因果关系

为简单起见，我们从格兰杰因果关系的双变量版本开始。

双变量格兰杰因果定理10.4表明（在排除瞬时效应并满足一些温和的技术条件下），汇总图中箭头的存在与否可通过检验(10.5)以及交换X和Y角色时的类似陈述来推断。于是，我们可以区分可能的汇总图$X \quad Y$、$X \to Y$、$X \leftarrow Y$、$X \rightleftarrows Y$。一

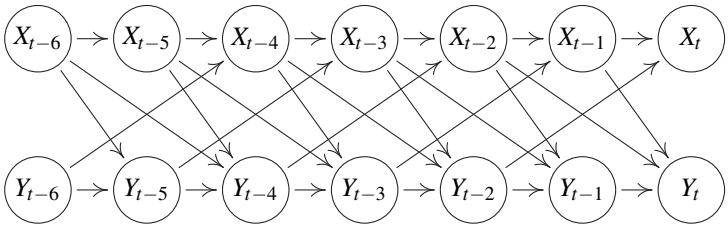

图10.6：格兰杰因果关系有效的典型场景：如果从X到Y的所有箭头都缺失，那么Y_t在给定自身过去值的条件下，将与X的过去值条件独立。在此，Y_t在给定自身过去值的条件下，确实依赖于X的过去值。因此，条件（10.4）证明了从X到Y存在影响。

推断出，当X的过去值有助于从Y自身的过去预测Y时，X便影响Y。形式上，我们写作

$$X \text{ Granger-causes } Y \quad :\Longleftrightarrow \quad Y_t \not\perp\!\!\!\perp X_{\text{past}(t)} \,|\, Y_{\text{past}(t)}. \tag{10.6}$$

这个想法可以追溯到维纳 [1956，第189–190页]，他认为如果通过额外考虑 X 能改善根据自身过去对 Y 的预测，那么 X 对 Y 具有因果影响。定理10.4成立的典型场景如图10.6所示。

通常，格兰杰因果关系指的是线性预测。接着，人们会比较以下两种线性回归模型：

$$Y_t = \sum_{i=1}^{q} a_i Y_{t-i} + N_t \tag{10.7}$$

$$Y_t = \sum_{i=1}^{q} a_i Y_{t-i} + \sum_{i=1}^{q} b_i X_{t-i} + \tilde{N}_t, \tag{10.8}$$

其中 $(N_t)_{t\in\mathbb{Z}}$ 和 $(\tilde{N}_t)_{t\in\mathbb{Z}}$ 分别被假定为独立同分布的时间序列。当包含 X) 的预测的噪声项$\tilde{N}_t$ (的方差显著小于不包含 X 时获得的噪声项 N_t 的方差时，推断 X 格兰杰导致 Y。这相当于说，在给定 $Y_{\text{past}(t)}$ 的情况下，Y_t 与 $X_{\text{past}(t)}$ 具有非消失的偏相关。对于多元高斯分布，这等价于依赖陈述（10.4）。使用非线性回归对这一思想的修改也已被广泛研究[例如，Ancona 等人，2004，Marinazzo 等人，2008]。关于（10.5）的非参数检验，参见例如 Diks 和 Panchenko [2006] 及其中的参考文献。

一个信息 {v*}　衡量 Y_t a 之间依赖关系的理论量　找到

给定 Y 的过去，X 的过去由传递熵给出 [Schreiber, 2000]:

$$TE(X \to Y) := I(Y_t : X_{\text{past}(t)} | Y_{\text{past}(t)}), \tag{10.9}$$

其中 I(A : B | C) 表示任意三个变量集 A、B、C 的条件互信息 [Cover and Thomas, 1991]；另见附录 A。估计转移熵并在其显著大于 0 时推断 X 导致 Y，因此可以被视为格兰杰因果关系的一种信息论实现，能够处理任意非线性影响。因此，人们很容易将转移熵视为 X 对 Y 影响 *strength* 的一种度量，但“格兰杰因果关系的局限性”将解释为什么这样做并不恰当。

多元格兰杰因果性 如同定理10.4中双变量时间序列的因果充分性假设往往是不恰当的。格兰杰[1980]已经对此进行了讨论。因此，我们说如果

$$X_t^k \not\perp\!\!\!\perp X^j_{\text{past}(t)} \,|\, \mathbf{X}^{-j}_{\text{past}(t)}.$$

Granger已经强调，正确使用Granger因果关系实际上需要考虑世界上所有相关的变量。然而，Granger因果关系常常以其双变量版本或在明显重要变量未被观察的情况下被使用。这种使用方式在因果解释结果时可能会导致误导性的陈述。

格兰杰因果关系的局限性违反因果充分性——正如前几章中的独立同分布情景一样——是因果时间序列分析中的一个严重问题。为了解释为什么在因果不充分的多元时间序列中格兰杰因果关系具有误导性，我们将注意力限制在仅观察到双变量时间序列 $(X_t, Y_t)_{t\in\mathbb{Z}}$的情形。假设$X_t$和$Y_t$都受到隐藏时间序列 $(Z_t)_{t\in\mathbb{Z}}$的先前实例的影响。这在图10.7（a）中进行了描绘，其中Z以延迟1影响X，而Y以延迟2影响。假设忠实性，d-分离准则告诉我们

$$Y_t \not\perp\!\!\!\perp X_{\text{past}(t)} \,|\, Y_{\text{past}(t)},$$

当我们有

$$X_t \perp\!\!\!\perp Y_{\text{past}(t)} \,|\, X_{\text{past}(t)}.$$

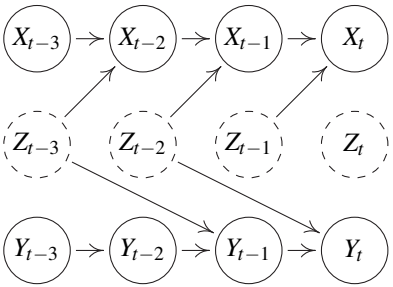

(a) 由于隐藏的共同原因 Z，格兰杰因果关系错误地推断出从 X 到 Y 的因果影响。

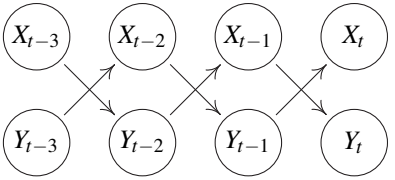

(b) 如果 X_t 对 Y_{t+1} 的影响以及 Y_t 对 X_{t+1} 的影响都是确定性的，那么格兰杰因果关系既无法正确推断从 X 到 Y 的因果影响，也无法正确推断从 Y 到 X 的因果影响。

图10.7：在这些例子中，格兰杰因果关系推断出错误的图结构。

因此，朴素地应用格兰杰因果关系会推断出X导致Y，而Y不会导致X。例如，这种效应已经在黄油价格与奶酪价格的关系中被观察到。两种价格都受到牛奶价格的强烈影响，但奶酪的生产比黄油的生产耗时更长，这导致牛奶价格与奶酪价格之间存在更大的延迟[Peters et al., 2013, Experiment 10]。然而，格兰杰因果关系的这种失败之所以可能，只是因为并非所有相关变量都被观察到，而这一点正是格兰杰本人所提出的要求。

Granger失败的第二种情形示例由Ay和Polani[2008]提供，并展示在图10.7(b)中。假设X_{t-1}通过复制操作确定性地影响Y_t，即$Y_t := X_{t-1}$。同样，Y_{t-1}的值被复制到X_t。那么直观上显而易见的是，X和Y在干预X_t的值会改变所有Y_{t+1+2k}对于$k \in \mathbb{N}_0$的值这一意义上强烈地相互影响。同样，干预Y_t会改变所有X_{t+1+2k}的值。然而，X的过去对于从其过去预测Y_t是无用的，因为Y_t已经可以从其自身的过去完美预测。当然，确定性关系总体上对于基于条件独立性的因果推断是有问题的，因为确定性会诱导额外的独立性。例如，如果在因果链$X \to Y \to Z$中Y是X的函数，我们得到$Y \perp\!\!\!\perp Z \,|\, X$，这不是该因果结构的典型情况。因此，有人可能会认为这个例子是人为的，更自然的版本应该是*noisy*复制操作。对于X_t和Y_t是二值变量的情况，Janzing等人[2013，例7]表明，当复制操作的噪声水平趋于0时，转移熵收敛于0。那么，Granger因果性确实会推断出X导致Y且Y导致X，但对于小噪声，X的过去改善Y_t预测的微小量并不

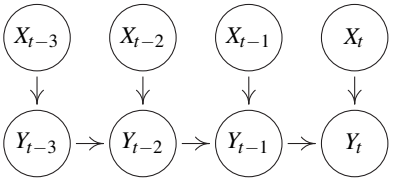

(a) 格兰杰因果性无法检测到 X 对 Y 的影响，因为 X 的过去仅通过 Y 的过去影响 Y_t。

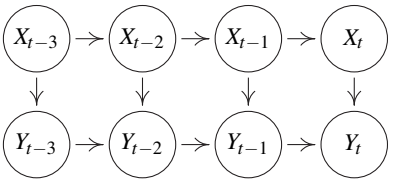

(b) 在这里，X 的过去仍然有助于预测 Y_t，因为 X_{t-1} 通过 X_t 间接影响 Y_t。因此，格兰杰因果关系仍然能够检测到 X 对 Y 的影响。

图10.8：两种存在瞬时效应的情景，一种是格兰杰因果性未能检测到这些效应的情况（a），另一种则是能检测到的情况（b）。

充分考虑时间序列之间的相互影响（从直观意义上讲，这种影响仍然很强）。在这个意义上，传递熵并不是衡量一个时间序列对另一个时间序列因果影响强度的充分指标。Janzing等人[2013]讨论了量化因果影响的不同提案的局限性（无论是对于时间序列还是独立同分布设置），并提出了一种新的因果强度的信息论度量。总结这一段，我们强调，*qualitative*关于在两个因果充分的时间序列情况下因果影响存在与否的陈述仅在一个相当人为的场景中失败，而*quantifying*通过传递熵（这是通过将“预测的改进”解释为信息论术语所暗示的）的因果影响在不太人为的场景中也可能存在问题。

还有另一种情况，格兰杰因果关系在定量上可能产生误导，但其定性表述依然正确，除非违背了忠实性（然而，它利用了瞬时效应，有人可能会认为，在足够精细的时间分辨率下，这些效应会消失[Granger, 1988]）。对于图10.8(a)，d-分离导致

$$Y_t \perp\!\!\!\perp X_{\mathrm{past}(t)} \,|\, Y_{\mathrm{past}(t)}.$$

直观地说，只有当前值 X_t 有助于更好地预测 Y_t，而过去的值 $X_{t-1}, X_{t-2}, \ldots$ 则无用，因此格兰杰因果关系并未提出从 X 到 Y 的链接。然而，在图10.8(b)中，如果我们假设忠实性)，格兰杰因果关系确实检测到了 X 对 Y (的影响，尽管它仍然是纯瞬时的，但预测的轻微改善并不能恰当解释 X_t 对 Y_t 的潜在强烈影响。为了考虑瞬时效应，已经提出了格兰杰因果关系的修正方法，在相应的SCM中添加瞬时项，但随后可识别性

可能会失效[例如，Lütkepohl, 2007, (2.3.20) 和 (2.3.21)]。了解到系统包含瞬时效应后，可能建议通过不仅对$X_{\text{past}(t)}$回归(10.8)中的Y_t，而是对$X_t \cup X_{\text{past}(t)}$进行回归来修改格兰杰因果关系。然而，正如Granger[1988]已经指出的，这可能会得出错误的结论：如果X_t有助于预测Y_t，这同样可能意味着Y_t影响了X_t，而不是表明从X_t到Y_t的影响。

备注 10.5（模型误设可能有帮助） 这一洞见存在一个悖论式的信息：即使在变量瞬时影响其他变量的情况下，对于推断因果陈述而言，检查一个变量的过去是否有助于预测，比检查过去的 *and the present* 值是否有帮助更具结论性。定理 10.4 的条件 (i) 并不排除瞬时效应。因此（在因果充分性成立的前提下），我们仍可得出结论：$X_{\text{past}(t)}$ 对从 $Y_{\text{past}(t)}$ 预测 Y_t 的任何益处，都源于 X 对 Y 的影响。此外，只要 X 对 Y 存在任何影响，无论其是否纯粹是瞬时的，在一般情况下，给定 $Y_{\text{past}(t)}$，$X_{\text{past}(t)}$ 都会改善我们对 Y_t 的预测。

□

10.3.4 具有受限函数类的模型

为了解决Granger因果性的局限性，Hyvärinen等人[2008]描述了线性非高斯自回归模型，这些模型能够识别具有瞬时效应的因果结构。Peters等人[2013]描述了如何使用(10.1)中限制较少的函数类f^j来解决这一任务。一个例子是通过将ANMs适应于时间序列，即使用SCM

$$X_t^j := f^j\left((\mathbf{PA}_q^j)_{t-q}, \cdots, (\mathbf{PA}_1^j)_{t-1}, (\mathbf{PA}_0^j)_t\right) + N_t^j,$$

对于$j \in \{1, \ldots, d\}$。除了马尔可夫等价类内因果结构的可识别性之外，使用受限函数类的第二个动机是：利用模拟时间序列，Peters等人[2013]提供了一些经验证据，支持这样一个信念，即允许来自受限函数类的模型的时间序列更不容易受到混杂影响。

10.3.5 谱独立准则

谱独立性准则（SIC）是一种基于Shajarisales等人[2015]中所描述的因果与机制独立性思想的方法。假设给定一个弱平稳双变量时间序列$(X_t, Y_t)_{t\in\mathbb{Z}}$

其中 X 影响 Y，或 Y 通过线性时不变滤波器影响 X。更明确地说，对于 X 影响 Y 的情况，Y 则通过将 X 与函数 h 卷积得到：

$$Y_t = \sum_{k=1}^{\infty} h(k) X_{t-k}. \tag{10.10}$$

关于技术细节，例如确保(10.10)及以下表达式定义良好的h衰减条件，我们参考Shajarisales等人[2015]。为了形式化X和h之间的独立性条件，我们考虑滤波器在频域中的作用：对于所有$\nu \in [-1/2, 1/2]$，令$S_{XX}(\nu)$表示频率ν的功率谱密度；后者由自协方差函数的傅里叶变换明确给出

$$C_{XX}(\tau) := \mathbb{E}[X_t X_{t+\tau}], \quad \text{with } \tau \in \mathbb{Z}.$$

然后，(10.10) 式得出

$$S_{YY}(\nu) = |\tilde{h}(\nu)|^2 \cdot S_{XX}(\nu), \tag{10.11}$$

其中 $\tilde{h}(\nu) = \sum_{k\in\mathbb{Z}} e^{-i2\pi k\nu} h(k)$ 表示 h 的傅里叶变换。换句话说，将输入时间序列的功率谱与滤波器的传递函数平方相乘，即得到输出的功率谱。当 $\tilde{h}$ 可逆时，除 (10.11) 之外，我们还有

$$S_{XX}(\nu) = \left|\frac{1}{\tilde{h}(\nu)}\right|^2 \cdot S_{YY}(\nu). \tag{10.12}$$

虽然方程（10.11）和（10.12）都是有效的，但问题在于哪一个描述了因果模型。其核心理念是，对于因果方向而言，输入时间序列的功率谱不携带关于滤波器传递函数的任何信息。为了形式化这一点，Shajarisales等人[2015]提出了以下独立性条件：

定义10.6（SIC）*The time series X and the filter h are said to satisfy the SIC if S_{XX} and $\tilde{h}$ are uncorrelated, that is,*

$$\langle S_{XX} \cdot |\tilde{h}|^2 \rangle = \langle S_{XX} \rangle \cdot \langle |\tilde{h}|^2 \rangle, \tag{10.13}$$

where $\langle f \rangle := \int_{-1/2}^{1/2} f(\nu) d\nu$ denote the average of any function on the frequency interval $[-1/2, 1/2]$.

Shajarisales 等人 [2015] 表明，(10.13) 意味着反向的类似独立性条件不成立，除非在非一般情形下，即 $|\tilde{h}|$ 在整个频率区间上恒定。

定理 10.7（通过 SIC 的可辨识性）*If* (10.13) *holds and* $|\hat{h}|$ *is not constant in* ν *then* S_{YY} *is negatively correlated with* $1/|\tilde{h}|$*, that is,*

$$\langle S_{YY} \cdot 1/|\tilde{h}|^2 \rangle < \langle S_{YY} \rangle \cdot \langle 1/|\tilde{h}|^2 \rangle. \tag{10.14}$$

证明。(10.13)和(10.14)的左侧分别由$\langle S_{YY} \rangle$和$\langle S_{XX} \rangle$给出。Jensen不等式表明$1/\langle |\tilde{h}|^2 \rangle < \langle 1/|\tilde{h}|^2 \rangle$，从而蕴含该命题。□

Shajarisales等人[2015]提出了一种简单的因果推断算法，该算法检查哪个方向更接近于满足SIC。他们报告了使用SIC在各种模拟和真实世界数据集实验中的一些令人鼓舞的结果。

10.4 动态因果建模

动态因果建模（DCM）是一种专门为推断不同脑区活动之间因果关系而开发的技术[Friston等，2003]。如果向量$z \in \mathbb{R}^n$编码了n个脑区的活动，而$u \in \mathbb{R}^m$是扰动向量，则z的动力学由以下形式的微分方程给出

$$\frac{d}{dt} z = F(z, u, \theta), \tag{10.15}$$

其中 F 是已知函数，$u \in \mathbb{R}^m$ 是外部刺激向量，而 θ 参数化了描述不同脑区之间因果联系的模型类。人们常常考虑对（10.15）的以下双线性近似：

$$\frac{d}{dt} z = \left(A + \sum_{j=1}^{m} u_j B^j \right) z + Cu, \tag{10.16}$$

其中 $A, B^1, \ldots, B^m$ 是 $n \times n$ 矩阵，C 的大小为 $n \times m$。虽然 A 描述了不同区域中活动 z_j 之间的相互影响，矩阵 B^j 描述了 u 如何改变它们的相互影响。C 编码了 u 对 z 的直接影响。

这里，z 不能直接观察到，但可以检测 *hemodynamic response*。血流提供了增加量的营养物质（如氧气和葡萄糖），以补偿增加的能量需求。功能性磁

功能磁共振成像（fMRI）能够通过血氧水平依赖（BOLD）信号检测到这种增加。定义一个包含大脑活动和一些血流动力学状态变量的状态向量{v*}，最终会得到关于{v*}的微分方程。

$$\frac{d}{dt}x = f(x,u,\theta) \tag{10.17}$$

通过将 (10.16) 与血流动力学响应的动力学模型相结合。高维参数 θ 由 (10.16) 中所有自由参数以及建模血流动力学响应的参数组成。然后，使用一个模型来描述 x 如何决定测得的 BOLD 信号 y：

$$y = \lambda(x). \tag{10.18}$$

最后，作为数据，我们获得了一个观测到的y向量时间序列。DCM随后利用各种已知的潜在变量模型学习技术，例如期望最大化(EM)，从这些数据中推断出(10.16)中的矩阵。

Lohmann等人[2012a]主要批评DCM，因为随着n和m的增长，模型参数的数量激增，这使得从经验数据中识别它们变得不可能。根据他们关于模拟大脑连接的实验，大部分错误模型通过DCM获得了比真实模型更高的证据。这些发现引发了对DCM的辩论；另见Friston等人[2013]对Lohmann等人[2012a]的回应，以及Lohmann等人[2012b]对Friston等人[2013]的回应。

10.5 习题

问题 10.8（无环摘要图）*Prove Theorem 10.2.*

问题 10.9（瞬时效应）*Consider an SCM over a multivariate time series, in which each variable X_t^j is influenced by all past values of all components X^k. Additionally, assume that the instantaneous effects form a DAG and that the distribution is Markovian and faithful with respect to the full time graph. To which extent can one identify the instantaneous DAG structure from the distribution?*

问题 10.10（格兰杰因果关系）*Argue why Granger causality results in "X G causes Y" and "Y G causes X" if one adds arrows $Z_t \to Z_{t+1}$ for $t \in \mathbb{Z}$ in Figure 10.7(a).*

A

一些概率与统计

A.1 基本定义

(i) 我们将基础概率空间表示为$(\Omega, \mathcal{F}, P)$。这里，Ω、$\mathcal{F}$和P分别是集合、σ-代数和概率测度。

(ii) 我们用大写字母表示实值随机变量。例如，X： $(\Omega, \mathcal{F}) \to (\mathbb{R}, \mathcal{B}_{\mathbb{R}})$ 是一个可测函数，关于 Borel σ - 代数。随机向量是可测函数 X： $(\Omega, \mathcal{F})$ $\to (\mathbb{R}^d, \mathcal{B}_{\mathbb{R}^d})$。如果不存在值 $\mathrm{c} \in \mathbb{R}^d$ 使得 $P(\mathrm{X} = \mathrm{c}) = 1$，则称 X 为非退化的。关于测度论的介绍，参见，例如，Dudley [2002]。

(iii) 我们通常用粗体字母表示向量。在略微滥用符号的情况下，我们将变量集合 $\mathrm{B} \subseteq \mathrm{X}$ 视为单个多变量。

(iv) $P_{\mathbf{X}}$ 是 d 维随机向量 X 的分布，即 $(\mathbb{R}^d, \mathcal{B}_{\mathbb{R}^d})$ 上的概率测度。

(v) 我们使用$x \mapsto p_X(x)$或简写为$x \mapsto p(x)$来表示密度，即P_X关于乘积测度的Radon-Nikodym导数。我们（有时隐含地）假设其存在或连续。

（vi）当且仅当以下情况时，我们称X独立于Y，并记作$X \perp\!\!\!\perp Y$:

$$p(x, y) = p(x)p(y) \tag{A.1}$$

对于所有 x, y。否则，X 和 Y 是相关的，我们记作 $X \not\perp\!\!\!\perp Y$。（vii）当且仅当以下条件成立时，我们称 $X_1, \ldots, X_d$ 是联合（或相互）独立的:

$$p(x_1, \ldots, x_d) = p(x_1) \cdot \ldots \cdot p(x_d) \tag{A.2}$$

对于所有 $x_1,\ldots,x_d$。如果 $X_1,\ldots,X_d$ 是联合独立的，那么任何一对 X_i 和 X_j（其中 $i \neq j$）也是独立的。反之通常不成立：两两独立并不意味着联合独立。

(viii) 我们称 X 在给定 Z 的条件下独立于 Y，并记作 $X \perp\!\!\!\perp Y \,|\, Z$，当且仅当

$$p(x,y\,|\,z) = p(x\,|\,z)p(y\,|\,z) \tag{A.3}$$

对于所有 x,y,z，使得 $p(z) > 0$。否则，X 和 Y 在给定 Z 的条件下不独立，我们记作 $X \not\perp\!\!\!\perp Y \,|\, Z$。

(ix) 条件独立关系遵循以下重要规则[例如，Pearl, 2009, 第1.1.5节]:

$$\begin{aligned}
X \perp\!\!\!\perp Y \,|\, Z &\;\Rightarrow\; Y \perp\!\!\!\perp X \,|\, Z && \text{(symmetry)}\\
X \perp\!\!\!\perp Y, W \,|\, Z &\;\Rightarrow\; X \perp\!\!\!\perp Y \,|\, Z && \text{(decomposition)}\\
X \perp\!\!\!\perp Y, W \,|\, Z &\;\Rightarrow\; X \perp\!\!\!\perp Y \,|\, W, Z && \text{(weak union)}\\
X \perp\!\!\!\perp Y \,|\, Z \text{ and } X \perp\!\!\!\perp W \,|\, Y, Z &\;\Rightarrow\; X \perp\!\!\!\perp Y, W \,|\, Z && \text{(contraction)}\\
X \perp\!\!\!\perp Y \,|\, W, Z \text{ and } X \perp\!\!\!\perp W \,|\, Y, Z &\;\Rightarrow\; X \perp\!\!\!\perp Y, W \,|\, Z && \text{(intersection).}
\end{aligned}$$

严格正密度的存在足以使交集性质成立。离散情况的充要条件由Drton等人[2009b，练习6.6]和Fink[2011]提供。Peters[2014]探讨了连续情况。

(x) 随机变量 X 的方差定义为

$$\operatorname{var}[X] := \mathbb{E}\left[(X - \mathbb{E}[X])^2\right] = \mathbb{E}\left[X^2\right] - \mathbb{E}[X]^2$$

如果 $\mathbb{E}[X^2] < \infty$。

(xi) 如果 $\mathbb{E}[X^2], \mathbb{E}[Y^2] < \infty$ 且，我们称 X 和 Y 不相关

$$\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y],$$

那就是

$$\rho_{X,Y} := \frac{\mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]}{\sqrt{\operatorname{var}[X]\operatorname{var}[Y]}} = 0.$$

否则，即如果$\rho_{X,Y} \neq 0$，那么X和Y是相关的。$\rho_{X,Y}$被称为X与Y之间的相关系数。

(xii) 如果 X 和 Y 独立，则它们不相关：

$$X \perp\!\!\!\perp Y \;\Rightarrow\; \rho_{X,Y} = 0.$$

另一个方向不一定成立（见代码片段A.1）。仅在特殊情况下，如双变量高斯分布或二元变量，反向也成立。

(xiii) 若满足以下条件，我们说在给定Z的情况下，X与Y部分不相关：

$$\rho_{X,Y|Z} := \frac{\rho_{X,Y} - \rho_{X,Z}\rho_{Z,Y}}{\sqrt{(1-\rho_{X,Z}^2)(1-\rho_{Z,Y}^2)}} = 0.$$

以下对偏相关的解释很重要：$\rho_{X,Y|Z}$ 等于将 X 对 Z 进行线性回归后，以及将 Y 对 Z 进行线性回归后所得残差之间的相关性。

（十四）一般来说，我们有（见例7.9）

$$\begin{aligned} \rho_{X,Y|Z} = 0 \quad &\not\Rightarrow \quad X \perp\!\!\!\perp Y \,|\, Z \qquad \text{and} \\ \rho_{X,Y|Z} = 0 \quad &\not\Leftarrow \quad X \perp\!\!\!\perp Y \,|\, Z. \end{aligned}$$

(xv) 在回归估计中，我们通常得到一个来自联合分布 $P_{\mathbf{X},Y}$ 的独立同分布样本 $(\mathrm{X}_1, Y_1), \ldots, (\mathrm{X}_n, Y_n)$。我们的目标是根据协变量或预测变量 X 预测目标 Y。例如，在最小二乘回归中，我们正在寻找一个函数$\hat{f}$，使得

$$\hat{f} = \operatorname*{argmin}_{f \in \mathcal{F}} \sum_{i=1}^{n} (Y_i - f(\mathbf{X}_i))^2 .$$

在这里，我们在函数类$\mathcal{F}$ (见A.3节)上进行优化。不同的回归技术使用不同的函数类。在线性回归中，我们仅考虑线性函数f；参见代码片段6.43的示例。代码片段4.14展示了一个非线性回归技术的示例。

(xvi) 离散随机变量集X和Y之间的依赖关系可以通过香农互信息[Cover and Thomas, 1991]来衡量。

$$I(\mathbf{X} : \mathbf{Y}) := \sum_{\mathbf{x},\mathbf{y}} p(\mathbf{x},\mathbf{y}) \log \frac{p(\mathbf{x},\mathbf{y})}{p(\mathbf{x})p(\mathbf{y})}.$$

(xvii) 给定集合 Z 时，离散随机变量集合 X 和 Y 的条件依赖性通过条件香农互信息来度量 [Cover and Thomas, 1991]

$$I(\mathbf{X} : \mathbf{Y} \,|\, \mathbf{Z}) := \sum_{\mathbf{x},\mathbf{y},\mathbf{z}} p(\mathbf{x},\mathbf{y},\mathbf{z}) \log \frac{p(\mathbf{x},\mathbf{y}|\mathbf{z})}{p(\mathbf{x}|\mathbf{z})p(\mathbf{y}|\mathbf{z})}.$$

(xviii) 对于连续变量，求和被积分所取代

$$I(\mathbf{X}:\mathbf{Y}) := \int p(\mathbf{x},\mathbf{y}) \log \frac{p(\mathbf{x},\mathbf{y})}{p(\mathbf{x})p(\mathbf{y})}\, d\mathbf{x}\, d\mathbf{y},$$

和

$$I(\mathbf{X}:\mathbf{Y}\,|\,\mathbf{Z}) := \int p(\mathbf{x},\mathbf{y},\mathbf{z}) \log \frac{p(\mathbf{x},\mathbf{y}|\mathbf{z})}{p(\mathbf{x}|\mathbf{z})p(\mathbf{y}|\mathbf{z})}\, d\mathbf{x}\, d\mathbf{y}\, d\mathbf{z}.$$

A.2 独立性与条件独立性检验

在实践中，我们给定一个有限样本 $(X_1,Y_1),\ldots,(X_n,Y_n) \overset{\text{iid}}{\sim} P_{X,Y}$，并希望判断潜在的随机变量是否独立。由于我们不期望经验相关性（或任何独立性度量）恰好为0，因此需要考虑依赖度量的随机波动。这可以通过统计假设检验来实现。其思路是考虑零假设 H_0： $X \perp\!\!\!\perp Y$ 和备择假设 H_A： $X \not\perp\!\!\!\perp Y$。因此，通常会构造一个检验统计量 T_n，将任何有限样本映射到一个实数，并根据以下规则进行判断：

$$(x_1,y_1),\ldots,(x_n,y_n) \mapsto \begin{cases} H_0 & \text{if } T_n \le c \\ H_A & \text{if } T_n > c. \end{cases}$$

这里，T_n是$T_n((x_1,y_1),\ldots,(x_n,y_n))$的简写表示。选择阈值$c \in \mathbb{R}$使得我们可以控制第一类错误；也就是说，对于任何满足H_0的P，我们有$P(T_n > c) \le \alpha$，其中α是测试的显著性水平，由用户指定。在实践中，我们给定数据并计算统计量T_n。如果$T_n > c$，则拒绝原假设，我们可以相对确信我们的决策是正确的；否则，原假设不被拒绝，这并不一定意味着很多（可能是样本量n太小，无法检测到X和Y之间的依赖性）。测试的p-值是最小的显著性水平，使得测试被拒绝。

我们现在简要提及 T_n 的几种选择。然而，还有更多的测试，我们并不声称该列表包含最优的程序；关于实际示例，请参见代码片段 A.1。

(i) 为了检验相关性是否消失，我们可以使用经验相关系数和 t 检验（对于高斯变量）或 Fisher 的 z 变换（例如，R Core Team [2016] 中的 `cor.test`）。

(ii) 作为独立性检验，我们可以对离散或离散化数据使用 χ^2 检验（例如，R Core Team [2016] 中的 `chisq.test`）。

(iii) 一般非参数独立性检验的一个例子是希尔伯特-施密特独立性准则（HSIC）[参见 Gretton 等人，2008]。其思想基于到再生核希尔伯特空间（RKHS）的单射映射 [Schölkopf and Smola, 2002]。给定一个正定核，我们可以将概率分布映射到相应的 RKHS $\mathcal{H}$ 中，即 $P_{X,Y} \mapsto \mu(P_{X,Y}) \in \mathcal{H}$。对于所谓的特征核（例如高斯核），该映射是单射的。特别地，我们于是有

$$\mu(P_{X,Y}) = \mu(P_X \otimes P_Y) \quad \text{if and only if} \quad P_{X,Y} = P_X \otimes P_Y,$$

并且后者成立当且仅当 X 和 Y 是独立的。HSIC 被定义为联合分布与边缘分布乘积之间的 RKHS 距离的平方：

$$\mathrm{HSIC}(P_{X,Y}) := \|\mu(P_{X,Y}) - \mu(P_X \otimes P_Y)\|^2_{\mathcal{H}}.$$

作为检验统计量 T_n，我们现在可以使用 $\mathrm{HSIC}(P_{X,Y})$ 的估计量。如果 X 和 Y 独立，$\mathrm{HSIC}(P_{X,Y})$ 等于 0，并且我们期望其估计量 T_n 较小。Gretton 等人 [2008] 提供了如何选择阈值 c 的方法。

或者，我们可以将HSIC表示为协方差算子的Hilbert-Schmidt范数C_{XY}。后者的定义使得对于所有属于相应RKHS的f和g

$$\langle f, C_{XY} g \rangle = \mathbb{E}\left[f(X)g(Y)\right] - \mathbb{E}\left[f(X)\right]\mathbb{E}\left[g(Y)\right].$$

因此，交叉协方差算子是协方差矩阵的一种推广。若X为d_X维，Y为d_Y维，且对应的RKHS分别同构于$\mathbb{R}^{d_X}$和$\mathbb{R}^{d_Y}$，则C_{XY}可由$d_X \times d_Y$维交叉协方差矩阵描述。当然，如果协方差矩阵消失，X和Y不必独立。然而，对于特征核，RKHS是无限维的，且不同构于$\mathbb{R}^d$。交叉协方差算子的范数为零当且仅当X和Y独立。

Pfister等人[2017]将该程序扩展至检验d变量间的联合独立性。例如，这对于检验噪声变量的联合独立性是必要的。他们为双变量和多变量程序提供了代码（参见R包`dHSIC`）。

在实践中，通常需要选择核参数。对于高斯核，许多实现依据常见的所谓中位数启发式方法[例如，Gretton等人，2008年]来选择带宽σ。

(iv) 条件独立性检验 条件独立性检验是一个难题，尤其是在条件集很大时。尽管目前的研究旨在为这一陈述获得精确的形式化表述，但我们提供了一个例子来说明该问题的难度。如果$Z_1,\ldots,Z_d$是二元变量，我们有

$$X \perp\!\!\!\perp Y \,|\, Z_1,\ldots,Z_d \quad \Leftrightarrow \quad \forall (z_1,\ldots,z_d) \in \{0,1\}^d : \quad X \perp\!\!\!\perp Y \,|\, Z_1 = z_1,\ldots,Z_d = z_d.$$

如果我们不能对 X 和 Y 如何可能依赖于 Z 做出任何假设，我们需要对每一个 2^d 赋值执行无条件独立性检验（例如，Z_d 可能是 X 和 Y 的共同子节点，且该依赖关系仅在其他 $Z_1,\ldots,Z_{d-1}$ 的特定赋值下可检测）。

对于连续变量，已提出了HSIC检验的扩展。Fukumizu等人[2008]将这一思想扩展到条件互协方差算子，从而得到条件独立性检验。Zhang等人[2011]进一步发展了这一方法，他们还提供了原假设下检验统计量分布的近似。

代码片段 A.1 以下代码生成了一个关于两个不相关但相互依赖的变量的分布样本。

```
library(dHSIC)
#
# generates a sample from two uncorrelated but dependent random variables
set.seed(1)
A <- runif(200)-0.5
B <- runif(200)-0.5
X <- t( c(cos(pi/4), -sin(pi/4)) %*% rbind(A, B) )
Y <- t( c(sin(pi/4), cos(pi/4)) %*% rbind(A, B) )
#
# performs the statistical test
cor.test(X,Y)$p.value
# 0.3979561
dhsic.test(X,Y)$p.value
# 1.970705e-08
```

A.3 函数类的容量

这里，我们探讨的问题是，最小化经验风险（1.3）的函数序列是否收敛于同样最小化风险（1.2）的函数；参见第1.2节。根据大数定律，我们知道对于任意固定的$f \in \mathcal{F}$和$\varepsilon > 0$,

$$\lim_{n\to\infty} P\left(\left|R[f] - R^n_{\text{emp}}[f]\right| > \varepsilon\right) = 0, \tag{A.4}$$

在Chernov界的作用下，收敛速度呈指数级快速[例如，Vapnik, 1998]。然而，这并不意味着经验风险最小化的一致性。原因在于我们通过最小化(1.3)来选择函数f。这意味着即使(x_i, y_i)是独立的，误差或损失$\frac{1}{2}|f(x_i) - y_i|$并非如此。在这种情况下，通常形式的大数定律并不适用。事实证明，为了获得一致性，我们需要一致大数定律[Vapnik, 1998]。这相当于

$$\lim_{n\to\infty} P\left(\sup_{f\in\mathcal{F}}(R[f] - R^n_{\text{emp}}[f]) > \varepsilon\right) = 0 \tag{A.5}$$

f或者所有 $\varepsilon >$ 为0，这一性质取决于函数类。 s $\mathcal{F}$。

选择 $\mathcal{F} = \mathcal{Y}^{\mathcal{X}}$，换言之，从 $\mathcal{X}$ 到 $\mathcal{Y}$ 的 *all* 函数怎么样？不幸的是，这并不能推导出（A.5），推理过程如下：假设根据可用的样本（1.1），我们认定 f^* 是一个好的解——例如，因为它对所有 i 都满足 $f(x_i) = y_i$。在这种情况下，让我们构造另一个函数 f^{**}，它在样本上与 f^* 一致，而在其他所有地方都不一致。如果我们的分布 $P_{X,Y}$ 具有密度，那么未来再次遇到任何训练点 *exactly* 的概率为零。因此，f^* 和 f^{**} 几乎总是会不一致。然而，仅基于训练集，我们无法在两者之间做出选择。同样，在（A.5）中我们会发现，每当我们找到一个函数 f^*，使得 $(R[f^*] - R^n_{\text{emp}}[f^*])$ 恰好很小时，我们就能构造出另一个函数 f^{**}，使得 $(R[f^{**}] - R^n_{\text{emp}}[f^{**}])$ 很大，因此在我们考虑的 $\mathcal{F} = \mathcal{Y}^{\mathcal{X}}$ 这一情形下，一致收敛（A.5）是无法实现的。

另一方面，当我们使 $\mathcal{F}$ 更小时，条件 (A.5) 变得更弱。如何衡量 $\mathcal{F}$ 的大小（或容量）超出了本书的范围，但事实证明，对于 $\mathcal{F}$ 大小的总结，无论其背后的分布如何，一个单一的数字就足够了。它被称为 $\mathcal{F}$ 的 VC（Vapnik-Chervonenkis）维数。它有时与自由参数的数量一致，但也可能大不相同。如果 VC 维数是有限的，我们

得到任何 $P_{X,Y}$ 的经验风险最小化的一致性 [Vapnik, 1998]。VC 维与可证伪性以及 Popper 的理论维数概念有关 [Corfield et al., 2009]。统计学习理论的一个典型风险界表明，对于所有 $\delta > 0$，以概率 $1 - \delta$ 且对于所有 $f \in \mathcal{F}$，我们有

$$R[f] \leq R^n_{\text{emp}}[f] + \sqrt{\frac{h\,(\log(2n/h) + 1) - \log(\delta/4)}{n}}, \tag{A.6}$$

其中 h 是函数类 $\mathcal{F}$ 的 VC 维数。这意味着，如果我们能够构造一个 $\mathcal{F}$，其 VC 维较小，但包含的函数对于给定任务足够合适，从而实现较小的 $R^n_{\text{emp}}[f]$，那么我们可以（以高概率）保证这些函数在同一分布的 future data 上具有较小的 expected error。这形成了一个非平凡的权衡：一方面，我们希望使用 large class of functions 以允许较小的 R^n_{emp}，但另一方面，我们希望该类较小以控制 h。

B

因果排序与邻接矩阵

定义 B.1 *Given a DAG $\mathcal{G}$, we call a permutation, that is, a bijective mapping,*

$$\pi : \{1, \ldots, p\} \to \{1, \ldots, p\},$$

*a **causal ordering** (sometimes one says topological ordering) if it satisfies*

$$\pi(i) < \pi(j) \quad \textit{if} \quad j \in \mathbf{DE}_i^{\mathcal{G}}.$$

由于DAG的无环结构，总是存在拓扑排序（见命题B.2）。但这个顺序不必是唯一的。节点$\pi^{-1}(1)$没有任何父节点，因此是源节点，而$\pi^{-1}(p)$没有任何后代节点，因此是汇节点。

命题 B.2 *For each DAG there is a topological ordering.*

证明。我们通过归纳法进行。我们需要证明在每个有向无环图中，都存在一个没有任何祖先的节点。从任意节点开始，移动到其任何一个父节点（如果存在的话）。你永远不会访问之前已经见过的父节点（如果你这样做了，那就存在一个有向环）。经过至多 $p-1$ 步后，你会到达一个没有任何父节点的节点。□

定义 B.3 *We can represent a directed graph $\mathcal{G} = (V, \mathcal{E})$ over d nodes with a binary $d \times d$ matrix A (taking values 0 or 1):*

$$A_{i,j} = 1 \quad \Leftrightarrow \quad (i, j) \in \mathcal{E}.$$

*A is called the **adjacency matrix** of $\mathcal{G}$.*

这种DAG表示对于算法的高效实现特别有用。有几个转换邻接矩阵的有用结果，这里我们报告其中一些。

备注 B.4 (i) 设 A 为 DAG $\mathcal{G}$ 的邻接矩阵。方阵 A^2 的条目 (i, j) 等于从 i 到 j 的长度为二的路径数。这是因为

$$A^2_{i,j} = \sum_k A_{ik} A_{kj}.$$

(ii) 一般来说，我们有

$$A^k_{ij} = \#\text{ paths of length } k \text{ from } i \text{ to } j.$$

(iii) 如果有向路径上的索引递增，即 $j \in \mathrm{DE}_i^{\mathcal{G}}$ 意味着 $j > i$，那么该标识是因果排序，且邻接矩阵为上三角矩阵，即矩阵的右上部分才包含非零元素。

(iv) 当图稀疏时，我们可能希望使用稀疏矩阵以节省空间和/或计算时间。

□

具有d个节点的DAG数量已由Robinson [1970, 1973]研究，并由Stanley [1973]独立研究。此类矩阵（或DAG）的数量在d (见表B.1)中增长得非常快。

McKay [2004] 证明了以下由 Eric W. Weisstein 猜想的 DAG 等价描述。

定理 B.5 *The matrix A is an adjacency matrix of a DAG $\mathcal{G}$ if and only if $A + \mathrm{Id}$ is a* 0-1*-matrix with all eigenvalues being real and strictly greater than zero.*

d	具有d个节点的DAG数量
1	1
2	3
3	25
4	543
5	29281
6	3781503
7	1138779265
8	783702329343
9	1213442454842881
10	4175098976430598143
11	3160345939641891760742 5
12	521939651343829405020504063
13	1867660074443203518666481692 6721
14	1439428141044398334941790719839535103
15	2377252655534103549921802182862 76719253505
16	8375667077373332028769930304799641223522313830 3
17	6270792119692388989944645260249492190696355148267 5201
18	9942119532215951589522891459235452451655502687858830501 4783
19	3327719012271075917361775733112611258835830762584219025835467735 05

表 B.1：DAG 的数量取决于节点数 d，摘自 `http://oeis.org/A003024` [OEIS Foundation Inc., 2017]。数字长度的增长速度超过任何线性项。

C

证明

C.1 定理4.2的证明

我们首先陈述一个引理；其证明可以在例如Peters [2008]中找到。

引理 C.1 *Let X and N be independent variables and assume that N is non-deterministic. Then $N \not\perp\!\!\!\perp (X+N)$.*

定理4.2的证明。如果X和N_Y呈正态分布，我们有

$$\beta := \frac{\mathrm{cov}[X,Y]}{\mathrm{cov}[Y,Y]} = \frac{\alpha \mathrm{var}[X]}{\alpha^2 \mathrm{var}[X] + \mathrm{var}[N_Y]}$$

并定义 $N_X := X - \beta Y$。N_X 和 Y 在构造上是不相关的，并且由于 N_X 和 Y 联合高斯，因此它们也是独立的。

为了证明“仅当”陈述，我们假设

$$\begin{aligned} Y &= \alpha X + N_Y \\ \text{and} \quad N_X &= (1-\alpha\beta)X - \beta N_Y \end{aligned}$$

是独立的。区分以下情况：

(i) $(1-\alpha\beta) \neq 0$ 和 $\beta \neq 0$。这里，定理4.3意味着 X, N_Y 以及因此 Y, N_X 都是正态分布的。因此，$P_{X,Y}$ 也是二元高斯分布。

(ii) $\beta = 0$。这意味着

$$X \perp\!\!\!\perp \alpha X + N_Y,$$

这与引理C.1相矛盾。

(iii) $(1-\alpha\beta)=0$.
它遵循$-\beta N_Y \perp\!\!\!\perp \alpha X + N_Y$。因此

$$N_Y \perp\!\!\!\perp \alpha X + N_Y,$$

这与引理C.1再次矛盾。

到此证明完毕。 □

C.2 命题6.3的证明

证明。回顾我们对SCM的定义，其中包括要求底层图是无环的。我们现在可以将结构赋值递归地相互替换，因此可以将每个节点 X_j 写成所有属于 X_j 的祖先的噪声项（N_k）$_{k\in\mathbf{AN}_j}$ 的唯一函数。即，

$$X_j := g_j\big((N_k)_{k\in\mathbf{AN}_j}\big).$$

(函数 不一定依赖于 *all* 的噪声项 cestors.) □

C.3 备注6.6的证明

证明。我们将证明，只要能在PA $_j$中移除一个变量，我们仍然能在简化模型中的PA$_j^*$中移除它。
考虑一个输入 $X_k \in \mathrm{PA}_j \cap \mathrm{PA}_j^*$，且该输入不依赖于 f_j。也就是说，对于所有满足 $p(n_j)>0$ 的 x_k, x_k', pa $_{j,-k}$ 和 n_j，我们有 $f_j(\text{pa}_{j,-k}, x_k, n_j) = f_j(\text{pa}_{j,-k}, x_k', n_j)$。这里，$\mathrm{PA}_{j,-k} := \mathrm{PA}_j \setminus \{k\}$ 表示除 k 之外的所有输入变量的集合。那么，g 也不依赖于这个变量 x_k，因为对于所有满足 $p(n_j)>0$ 的 x_k, pa $^*_{j,-k}$ 和 n_j，有 $g(\text{pa}^*_{j,-k}, x_k, n_j) = f_j(\text{pa}_j, x_k, n_j)$。□

C.4 命题6.13的证明

证明。为了模拟简化记号，我们写X_1而不是X和X_2 Y的。首先，

截断分解公式（6.9）意味着

$$\begin{aligned} p_{X_2}^{\mathfrak{C};do(X_1:=x_1)}(x_2) &= \int \prod_{j\neq 1} p_j(x_j\,|\,x_{pa(j)})\,dx_3\cdots dx_d \\ &= \int \prod_{j\neq 1} p_j(x_j\,|\,x_{pa(j)})\frac{\tilde{p}(x_1)}{\tilde{p}(x_1)}\,dx_3\cdots dx_d \\ &= p_{X_2\,|\,X_1=x_1}^{\mathfrak{C};do\left(X_1:=\tilde{N}_1\right)}(x_2) \end{aligned} \tag{C.1}$$

如果$\tilde{N}_1$在x_1上赋予正质量，即$\tilde{p}(x_1)>0$。我们进一步要求以下两个陈述对所有在(X_1,X_2)上具有密度q的分布Q_{X_1,X_2}成立：

$$X_2 \not\perp\!\!\!\perp X_1 \text{ in } Q \iff \exists x_1^{\triangle}, x_1^{\square} \text{ with } q(x_1^{\triangle}), q(x_1^{\square})>0 \text{ and } Q_{X_2\,|\,X_1=x_1^{\triangle}} \neq Q_{X_2\,|\,X_1=x_1^{\square}} \tag{C.2}$$

和

$$X_2 \not\perp\!\!\!\perp X_1 \text{ in } Q \iff \exists x_1^{\triangle} \text{ with } q(x_1^{\triangle})>0 \text{ and } Q_{X_2\,|\,X_1=x_1^{\triangle}} \neq Q_{X_2}. \tag{C.3}$$

然后对于任何具有完整支集的$\hat{N}_1$，我们有

$$\begin{aligned} (i) &\overset{(C.2)}{\Longrightarrow} \exists x_1^{\triangle}, x_1^{\square} \text{ with pos. density under } \tilde{N}_1 \text{ s.t. } P_{X_2\,|\,X_1=x_1^{\triangle}}^{\mathfrak{C};do\left(X_1:=\tilde{N}_1\right)} \neq P_{X_2\,|\,X_1=x_1^{\square}}^{\mathfrak{C};do\left(X_1:=\tilde{N}_1\right)} \\ &\overset{(C.1)}{\Longrightarrow} (ii) \\ &\overset{(C.1)}{\Longrightarrow} \exists x_1^{\triangle}, x_1^{\square} \text{ with pos. density under } \hat{N}_1 \text{ s.t. } P_{X_2\,|\,X_1=x_1^{\triangle}}^{\mathfrak{C};do\left(X_1:=\hat{N}_1\right)} \neq P_{X_2\,|\,X_1=x_1^{\square}}^{\mathfrak{C};do\left(X_1:=\hat{N}_1\right)} \\ &\overset{(C.2)}{\Longrightarrow} (iv) \\ &\overset{(\text{trivial})}{\Longrightarrow} (i) \end{aligned}$$

我们进一步有$(ii) \overset{(\text{trivial})}{\Longrightarrow} (iii)$，并且$P_{X_2}^{\mathfrak{C}} = P_{X_2}^{\mathfrak{C};do(X_1:=N_1^*)}$中$N_1^*$的分布为$P_{X_1}^{\mathfrak{C}}$。结合$\neg(i)\Rightarrow\neg(ii)$，后者意味着

$$\begin{aligned} \neg(i) &\implies X_2 \perp\!\!\!\perp X_1 \text{ in } P_{\mathbf{X}}^{\mathfrak{C};do(X_1:=N_1^*)} \\ &\overset{(C.3)}{\Longrightarrow} P_{X_2\,|\,X_1=x^{\triangle}}^{\mathfrak{C};do(X_1:=N_1^*)} = P_{X_2}^{\mathfrak{C};do(X_1:=N_1^*)} \text{ for all } x^{\triangle} \text{ with } p_1(x^{\triangle})>0 \\ &\overset{(C.1)}{\Longrightarrow} P_{X_2}^{\mathfrak{C};do\left(X_1:=x^{\triangle}\right)} = P_{X_2}^{\mathfrak{C}} \text{ for all } x^{\triangle} \text{ with } p_1(x^{\triangle})>0 \\ &\overset{\neg(ii)}{\Longrightarrow} P_{X_2}^{\mathfrak{C};do\left(X_1:=x^{\triangle}\right)} = P_{X_2}^{\mathfrak{C}} \text{ for all } x^{\triangle} \\ &\implies \neg(iii) \end{aligned}$$

这里，符号“¬”表示对陈述的否定。 □

C.5 命题6.14的证明

证明。(i) 直接由干预SCM的马尔可夫性质得出。该干预移除了指向 X 的入边，并且如果在原图中不存在从 X 到 Y 的直接路径，则 X 和 Y 是 d-分离的。

陈述(ii)可以通过一个反例来证明（例如，参见例6.34）。 □

C.6 命题6.36的证明

证明。“如果”：假设因果最小性不满足。那么，存在一个 X_j 和一个 $Y \in \mathrm{PA}_j^{\mathcal{G}}$，使得当从 $\mathcal{G}$ 中移除边 $Y \to X_j$ 后得到的图对于 $P_{\mathbf{X}}$ 也是马尔可夫的。这意味着根据局部马尔可夫性质，有 $X_j \perp\!\!\!\perp Y \mid \mathrm{PA}_j^{\mathcal{G}} \setminus \{Y\}$。

“仅当”：如果 $P_{\mathbf{X}}$ 具有密度，则马尔可夫条件等价于马尔可夫分解 [Lauritzen, 1996, Theorem 3.27]。现在假设 $Y \in \mathrm{PA}_j^{\mathcal{G}}$ 且 $X_j \perp\!\!\!\perp Y \mid \mathrm{PA}_j^{\mathcal{G}} \setminus \{Y\}$，这意味着 $p(x_j|\mathrm{pa}_j^{\mathcal{G}}) = p(x_j|\mathrm{pa}_{j,-Y}^{\mathcal{G}})$，其中 $\mathrm{PA}_{j,-Y}^{\mathcal{G}}$ 被定义为 $\mathrm{PA}_{j,-Y}^{\mathcal{G}} = \mathrm{PA}_j^{\mathcal{G}} \setminus \{Y\}$。那么，$p(\mathrm{x}) = p(x_j|\mathrm{pa}_{j,-Y}^{\mathcal{G}}) \prod_{k \neq j} p(x_k|\mathrm{pa}_k^{\mathcal{G}})$，这意味着 $P_{\mathbf{X}}$ 关于 $\mathcal{G}$ 是马尔可夫的，而不含 $Y \to X_j$。 □

C.7 命题6.48的证明

证明。我们假设两个模型都满足因果最小性，并带有图$\mathcal{G}$和$\mathcal{H}$。直观上，我们可以识别节点X的子节点，因为在干预X之后它们会发生变化。然而，由于例如两条相互抵消的路径，某些子节点在干预后可能不会改变其分布。因此，我们引入以下记号。给定一个有向无环图$\mathcal{G}$，如果$X \in$是$_Y$的父节点，并且X不是Y的任何其他父节点的祖先，则称X为节点Y的最年轻父节点，并记作$X \in \mathrm{YPA}_Y$。一个节点Y可能有多个最年轻父节点。该证明需要两个论证：

(i) 如果 $X \in \mathrm{YPA}_Y^{\mathcal{G}}$，则从 X 到 Y 存在总因果效应，这意味着存在 $x^{\triangle}$ 和 $x^{\square}$，使得 $P_Y^{do\left(X:=x^{\triangle}\right)} \neq P_Y^{do\left(X:=x^{\square}\right)}$。这由因果最小性得出。

(如果 $Z \in \mathrm{AN}_Y^{\mathcal{G}}$，则存在 $X_1,\ldots,X_k$，使得 $X_1 = Z$、$X_k = Y$，且对于 $i \in \{1$ $,\ldots,k-1\}$，有 $X_i \in \mathrm{YPA}_{X_{i+1}}^{\mathcal{G}}$。

最后，我们可以将这两个陈述结合起来，得出结论：如果 $Z \in \mathrm{AN}_Y^{\mathcal{G}}$，那么存在 $X_1,\ldots,X_k$，使得对于 $i \in \{1,\ldots,k-1\}$，X_i 对 X_{i+1} 具有总因果效应，这意味着在 $\mathcal{H}$ 中也必然存在从 X_i 到 X_{i+1} 的直接因果路径；见命题6.13。但如此一来，$Z \in \mathrm{AN}_Y^{\mathcal{H}}$，这意味着 $\mathcal{G}$ 和 $\mathcal{H}$ 具有相同的祖先关系。由于 $\mathcal{G}$ 和 $\mathcal{H}$ 都满足因果最小性，这意味着 $\mathcal{G} = \mathcal{H}$，因此这两个模型作为因果图模型是等价的。□

C.8 命题6.49的证明

证明。根据命题6.3的证明，我们可以将第一个SCM X记为= g(N)。但由于

$$\mathbf{g}(\mathbf{n}) = \mathbf{g}^*(\mathbf{n}) \quad \forall \mathbf{n} \text{ with } p(\mathbf{n}) > 0,$$

我们显然有，两个SCM都诱导出相同的观测分布（以及具有相同参数的干预分布）。关于反事实，我们通过以$\mathrm{X} \in A$为条件并令$P(\mathrm{X} \in A) > 0$，涵盖了离散和连续两种情况；参见定义6.17。噪声变量上的新密度满足

$$\begin{aligned}
\tilde{p}(n_1,\ldots,n_d) &= \begin{cases} \frac{p(n_1,\ldots,n_d)}{P(X \in A)} & \text{if } \mathbf{g}(n_1,\ldots,n_d) \in A \\ 0 & \text{else} \end{cases} \\
&= \begin{cases} \frac{p(n_1,\ldots,n_d)}{P(\mathbf{g}(\mathbf{N}) \in A)} & \text{if } \mathbf{g}^*(n_1,\ldots,n_d) \in A \\ 0 & \text{else} \end{cases} \\
&= \begin{cases} \frac{p(n_1,\ldots,n_d)}{P(\mathbf{g}^*(\mathbf{N}) \in A)} & \text{if } \mathbf{g}^*(n_1,\ldots,n_d) \in A \\ 0 & \text{else} \end{cases} \\
&= \tilde{p}^*(n_1,\ldots,n_d).
\end{aligned}$$

我们仍然有

$$\mathbf{g}(\mathbf{n}) = \mathbf{g}^*(\mathbf{n}) \quad \forall \mathbf{n} \text{ with } \tilde{p}(\mathbf{n}) > 0,$$

这意味着所有反事实陈述都一致 e. □

C.9 命题7.1的证明

证明。设 $N_1,\dots,N_d$ 独立且在0与1之间均匀分布。我们随后定义 X_j:
$= f_j(X_{\mathbf{PA}_j}, N_j)$，其中

$$f_j(\mathbf{pa}_j, n_j) := F^{-1}_{X_j|\mathbf{PA}_j=\mathbf{pa}_j}(n_j) \tag{C.4}$$

其中 $F^{-1}_{X_j|\mathbf{PA}_j=\mathbf{pa}_j}$ 是给定 $\mathrm{PA}_j = \mathrm{pa}_j$ 时来自 X_j 的广义逆累积分布函数。随机变量 Y 的广义逆累积分布函数定义为 $F_Y^{-1}(a) := \inf\{y \in \mathbb{R} : F_Y(y) \geq a\}$。公式 (C.4) 保证在构造的 SCM 中，条件 $X_j|\mathrm{PA}_j = \mathrm{pa}_j$ 具有正确的分布。该陈述随后由马尔可夫分解，定义 6.21(iii) 得出。□

C.10 命题7.4的证明

证明。假设因果最小性不满足。我们然后可以找到节点j和$i \in \mathrm{PA}_j$，其中 $X_j = f_j(\mathrm{PA}_j \setminus \{i\}, X_i) + N_j$不依赖于$X_i$，如果我们以所有其他父节点$A := \mathrm{PA}_j \setminus \{i\}$为条件，即$X_j \perp\!\!\!\perp X_i \,|\, X_A$ (见命题6.36)。这里，我们将$\mathrm{PA}_j \setminus \{X_i\}$表示为$X_A$。对于函数$f_j$，我们现在将证明对于$P_{X_A,X_i}$-几乎所有$(x_A, x_i)$，$f_j(x_A, x_i) = c_{x_A}$。确实，不失一般性假设$\mathbb{E}[N_j] = 0$，那么$X_j \,|\, \mathrm{PA}_j = (x_A, x_i)$的均值等于$f_j(x_A, x_i)$。Dawid [1979]的方程(2b)指出，如果$X_j \perp\!\!\!\perp X_i \,|\, X_A$，那么$X_j \,|\, X_A, X_i$的密度不依赖于$X_i$的参数。因此，条件均值$f_j(x_A, x_i)$也不依赖于$x_i$。由此可得$f_j(x_A, x_i) = c_{x_A}$。$f_j$的连续性意味着$f_j$在其最后一个参数中是常数。

逆命题也可由命题6.36推出。 □

C.11 命题8.1的证明

证明。我们使用贝尔曼最优方程 [例如，Sutton 和 Barto，2015,

第3.8章]。对于所有带有$f(s^\circ) = f(s)$的s°和s，我们有

$$\begin{aligned}
Q^*(s,a) &= \sum_{s'} p(s' \,|\, s,a) \Big(\mathbb{E}[R \,|\, s',a] + \max_{a'} Q^*(s',a') \Big) \\
&= \sum_{f'} \sum_{s' : f(s') = f'} p(s' \,|\, s,a) \Big(\mathbb{E}[R \,|\, s',a] + \max_{a'} Q^*(s',a') \Big) \\
&= \sum_{f'} p(f' \,|\, s,a) \Big(\mathbb{E}[R \,|\, f',a] + \max_{a'} Q^*(s',a') \Big) \\
&= \sum_{f'} p(f' \,|\, s^\circ,a) \Big(\mathbb{E}[R \,|\, f',a] + \max_{a'} Q^*(s',a') \Big) = Q^*(s^\circ,a).
\end{aligned}$$

到此证明完毕。 □

C.12 命题8.2的证明

证明。第一个等式由8.2.1节的讨论得出。马尔可夫分解性质意味着

$$p(\mathbf{x}) = p(a|s)\, p(s|h)\, p(h)\, p(y|f,h)\, p(f|a);$$

参见图8.5。现在由此及$F \perp\!\!\!\perp S \,|\, A$可得

$$\begin{aligned}
\int y \, \frac{\tilde{p}(a|s)}{p(a|s)} \, p(\mathbf{x}) \, d\mathbf{x} &= \int y \, \tilde{p}(a|s) p(s|h) p(h) p(y|f,h) p(f|a,s) \, da \, df \, dh \, ds \, dy \\
&= \int y \, \tilde{p}(f,a|s) p(s|h) p(h) p(y|f,h) \, da \, df \, dh \, ds \, dy \\
&= \int y \, \frac{\tilde{p}(f|s)}{p(f|s)} p(s \,|\, h) p(h) p(y|f,h) p(f|s) \, df \, dh \, ds \, dy \\
&= \int y \, \frac{\tilde{p}(f|s)}{p(f|s)} p(s \,|\, h) p(h) p(y|f,h) p(f,a|s) \, da \, df \, dh \, ds \, dy \\
&= \int y \, \frac{\tilde{p}(f|s)}{p(f|s)} \, p(\mathbf{x}) \, d\mathbf{x}.
\end{aligned}$$

最后一个等式由 $p(f,a|s) = p(f|a,s)p(a|s)$ 得出。 □

C.13 命题9.3的证明

证明。为说明(i)，我们从X上的SCM $\mathfrak{C}$及其蕴含分布$P_{\mathbf{X}}$开始。然后我们考虑变量$O \in$ O的结构赋值，并反复代入变量$X \in$ X $\setminus$ O的赋值，只要这些变量

出现在右侧。这导致一个新的SCM，其中每个针对 $O \in \mathrm{O}$ 的结构赋值都包含一个多元误差变量 $\tilde{\mathrm{N}}_O$。显然，这个较小的SCM蕴含相同的观测分布 $P_{\mathbf{O}}$ 以及对任何 $O \in \mathrm{O}$ 进行干预时的相同干预分布。由因果充分性可知，新的噪声变量 $(\tilde{\mathrm{N}}_O)_{O \in \mathbf{O}}$ 是联合独立的。如同在一维噪声变量的情形中一样（命题6.31），这再次意味着分布 $P_{\mathbf{O}}$ 关于所诱导的图结构是马尔可夫的。该陈述现在可由以下事实推出：这个新的SCM可以被转换为一个具有一维误差变量的SCM，且该SCM蕴含相同的观测分布和干预分布（利用与命题7.1中相同的构造）。关于此过程更形式化的描述，以及关于这些论证的更多细节，参见Bongers et al. [2016]。

陈述 (ii) 由例 9.2 推出。 □

C.14 定理10.3的证明

证明。如果存在从 $X^j_{\mathrm{past}(t)}$ 到 X^k_t 的箭头，那么依据忠实性，依赖关系（10.3）立即成立，因为两个直接相连的变量不能被 d-分离。现在假设从 $X^j_{\mathrm{past}(t)}$ 到 X^k_t 没有边。那么，在给定 $\mathrm{X}^{-j}_{\mathrm{past}(t)}$ 的条件下，X^k_t 与 $X^j_{\mathrm{past}(t)}$ 是 d-分离的。任何以出边离开 X^k_t 的路径都会被阻断，因为它将含有一个对撞节点（并且其后没有时间索引大于或等于 t 的节点被条件化）；任何以入边离开 X^k_t 的路径都会被阻断，因为下一个节点在条件集 $\mathrm{X}^{-j}_{\mathrm{past}(t)}$ 中。□

C.15 定理10.4的证明

证明。为了证明 (i)，考虑一个完整的时间图，其中不包含从 X 到 Y 的箭头。那么，从 Y_t 到 $X_{\mathrm{past}(t)}$ 的每条路径都被 $Y_{\mathrm{past}(t)}$ 阻断。任何以从 Y_t 出发的出边开始的路径必定包含一个不在条件集中的对撞节点（其后代也不在）；任何以入边开始的路径都被阻断，因为该路径上的第一个节点在 $Y_{\mathrm{past}(t)}$ 中。

为了证明(ii)，假设Y_t有来自X的父母，表示为$\mathrm{PA}^X_{Y_t}$。那么(10.5)意味着

$$Y_t \perp\!\!\!\perp \mathbf{PA}^X_{Y_t} \,|\, Y_{\mathrm{past}(t)}. \tag{C.5}$$

对于任意 $X_s \in \mathrm{PA}^X_{Y_t}$，(C.5) 根据弱并集（见附录 A.1）蕴含

$$Y_t \perp\!\!\!\perp X_s \,|\, Y_{\mathrm{past}(t)} \cup (\mathbf{PA}^X_{Y_t} \setminus \{X_s\}). \tag{C.6}$$

由于Peters等人[2014，引理38]，最小性意味着Y_t依赖于Y_t的任意父节点A，给定任何Y_t的非后代集合，该集合包括Y_t除A之外的其他父节点。因此我们有

$$Y_t \not\perp\!\!\!\perp X_s \,|\, Y_{\text{past}(t)} \cup (\mathbf{PA}_{Y_t}^X \setminus \{X_s\}),$$

与（C.6）矛盾。 □

参考文献

S. Acid 和 L. M. de Campos。在受限无环部分有向图空间中搜索贝叶斯网络结构。*Journal of Artificial Intelli- gence Research*，18：445–490，2003年。

J. Aldrich. 自主性. *Oxford Economic Papers*, 41:15–34, 1989.

R. A. Ali、T. S. Richardson 和 P. Spirtes。祖传图的马尔可夫等价性。*The Annals of Statistics*，37:2808–2837，2009。

E. S. Allman, C. Matias, 和 J. A. Rhodes. 大量观察变量下潜在结构模型参数的可识别性. *The Annals of Statistics*, 37: 3099–3132, 2009.

N. Ancona、D. Marinazzo 和 S. Stramaglia。时间序列非线性格兰杰因果关系的径向基函数方法。*Physical Review E*，70:056221–1–7，2004。

S. A. Andersson, D. Madigan, and M. D. Perlman. 链图的替代马尔可夫性质. *Scandinavian Journal of Statistics*, 28:33–86, 2001.

A. Aspect、P. Grangier 和 G. Roger。通过贝尔定理对现实局域理论的实验检验。*Physical Review Letters*，47：460–467，1981。

N. Ay 和 D. Polani. 因果网络中的信息流. *Advances in Complex Systems*, 11(1): 17–41, 2008.

R. R. Baldwin, W. E. Cantey, H. Maisel, and J. P. McDermott. 二十一点中的最优策略. *Journal of the American Statistical Association*, 51(275): 429–439, 1956.

A. Balke. *Probabilistic Counterfactuals: Semantics, Computation, Applications*. 博士论文，加利福尼亚大学洛杉矶分校，加利福尼亚州，1995年。

A. Balke 和 J. Pearl. 不完美依从性研究中的治疗效果界限。
Journal of the American Statistical Association, 92:1172–1176, 1997.

E. Bareinboim 和 J. Pearl. 有限实验下多环境的可移植性：完备性结果。载于 *Advances in Neural Information Processing Systems 27 (NIPS)*，第280–288页，2014年。

E. Bareinboim 和 J. Pearl。大数据中的因果推断：理论基础与数据融合问题。*Proceedings of the National Academy of Sciences*，113(27)：7345–7352，2016年。

E. Bareinboim, A. Forney, 和 J. Pearl. 存在未观测混杂因素的赌博机：一种因果方法。在 *Advances in Neural Information Processing Systems 28 (NIPS)* 中，第 1342–1350 页，2015 年。

S. Bauer, B. Schölkopf, and J. Peters. 多变量时间序列中的时间箭头. In *Proceedings of the 33rd International Conference on Machine Learning (ICML)*, pages 2043–2051, 2016.

J. Bell。论爱因斯坦-波多尔斯基-罗森佯谬。*Physics*，1：195–200，1964。*Reprinted in* J. Bell：量子力学中可说与不可说，剑桥大学出版社，英国剑桥，1987。

R. Bellman。马尔可夫决策过程。*Indiana University Mathematics Jour- nal*，6：679–684，1957。

S. Ben-David，T. Lu，T. Luu 和 D. Pál。领域自适应的不可能性定理。载于 *Proceedings of the International Conference on Artificial Intelligence and Statistics 13 (AISTATS)*，第129–136页，2010年。

C. Bennett. 计算的热力学——综述. *International Jour- nal of Theoretical Physics*, 21:905–940, 1982.

J. O. Berger. *Statistical Decision Theory and Bayesian Analysis*. Springer，纽约，纽约州，1985年。

J. Berkson. 四格表分析在医院数据应用中的局限性。*Biometrics Bulletin*, 2:47–53, 1946.

M. Besserve, N. Shajarisales, D. Janzing, 和 B. Schölkopf. 线性动力系统中通过谱独立性的因果推断. 筹备中。

A. Bhatt。临床研究的演变：詹姆斯·林德之前及其后的历史。*Perspectives in Clinical Research*, 1(1):6–10, 2010。

K. A. Bollen. *Structural Equations with Latent Variables*. Wiley，纽约，纽约州，1989年。

B. Bonet. 工具性测试再探讨. 载于 *Proceedings of the 17th Conference on Uncertainty in Artificial Intelligence (UAI)*, 第48–55页, 2001年.

S. Bongers, J. Peters, B. Schölkopf, and J. M. Mooij. 结构因果模型：循环、边缘化、外生重参数化与约简。*ArXiv e-prints (1611.06221)*, 2016.

L. Bottou, J. Peters, J. Quiñonero-Candela, D. X. Charles, D. M. Chickering, E. P ortugualy, D. Ray, P. Simard, and E. Snelson. 反事实推理与学习系统：计算广告的实例。*Journal of Machine Learning Research*, 14:3207–3260, 2013.

R. J. Bowden 和 D. A. Turkington。*Instrumental Variables*。计量经济学会专著。剑桥大学出版社，纽约，1990年。

C. Brito 和 J. Pearl. 递归模型中具有相关误差的新识别条件. *Structural Equation Modeling*, 9:459–474, 2002a.

C. Brito 和 J. Pearl. 广义工具变量. 在 *Proceedings of the 18th Conference on Uncertainty in Artificial Intelligence (UAI)* 中, 第85–93页, 2002b.

P. J. Brockwell 和 R. A. Davis。*Time Series: Theory and Methods*。Springer，纽约，NY，第2版，1991年。

P. Bühlmann 和 S. A. van de Geer。*Statistics for High-Dimensional Data: Methods, Theory and Applications*。Springer 统计学系列。Springer，纽约，NY，2011年。

P. Bühlmann, J. Peters, 和 J. Ernest. CAM：因果加性模型、高维顺序搜索与惩罚回归. *The Annals of Statistics*, 42(6):2526–2556, 2014.

W. L. Buntine. 贝叶斯网络上的理论细化. 在 *In Proceedings of the 7th Annual Conference on Uncertainty in Artificial Intelligence (UAI)* 中，第52–60页，1991年。

R. M. J. Byrne. *The Rational Imagination: How People Create Alternatives to Reality*. MIT出版社，剑桥，马萨诸塞州，2007年。

G. 蔡廷。关于计算有限二进制序列的程序长度。
Journal of the Assocation for Computing Machinery，13(4)：547–569，1966年。

O. Chapelle, B. Schölkopf, 和 A. Zien. *Semi-Supervised Learning*. MIT出版社, 剑桥, 马萨诸塞州, 2006.

C. R. Charig, D. R. Webb, S. R. Payne, 和 J. E. A. Wickham. 肾结石治疗的比较：开放手术、经皮肾镜取石术与体外冲击波碎石术。
British Medical Journal (Clin Res Ed), 292(6254):879–882, 1986.

R. Chaves, L. Luft, T. O. Maciel, D. Gross, D. Janzing, 和 B. Schölkopf. 通过信息不等式推断潜在结构. 在 *Proceedings of the 30th Annual Conference on Uncertainty in Artificial Intelligence (UAI)* 中, 第112–121页, 2014年.

D. M. Chickering. 学习贝叶斯网络是NP完全的。在 *Learning from Data: Artificial Intelligence and Statistics V* 中，第121–130页。Springer，纽约，纽约州，1996年。

D. M. Chickering. 使用贪心搜索的最优结构识别. *Journal of Machine Learning Research*, 3:507–554, 2002.

T. Claassen, J. M. Mooij, 和 T. Heskes. 学习稀疏因果模型并非NP难问题. 在 *Proceedings of the 29th Annual Conference on Uncertainty in Artificial Intelligence (UAI)*中, 第172–181页, 2013年.

J. Clauser, M. Horne, A. Shimony, and R. Holt. 检验局部隐变量理论的提议实验. *Physical Review Letters*, 23:880–884, 1969.

D. Colombo, M. H. Maathuis, M. Kalisch, 和 T. S. Richardson. 学习具有潜在变量和选择变量的高维有向无环图. *The Annals of Statistics*, 40:294–321, 2012.

J. Comley 和 D. Dowe。通用贝叶斯网络与非对称语言。载于 *Proceedings of the 2nd Hawaii International Conference on Statistics and Related Fields*，2003年。

P. Comon. 独立成分分析——一个新概念？*Signal Processing*，36：287–314，1994。

S. A. Cook. 定理证明过程的复杂性. 在 *Proceedings of the 3rd Annual ACM Symposium on Theory of Computing* 中，第151–158页，1971年.

G. Cooper 和 C. Yoo。从实验与观察数据混合中进行因果发现。载于 *Proceedings of the 15th Annual Conference on Uncertainty in Artificial Intelligence (UAI)*，第116–125页，1999年。

D. Corfield, B. Schölkopf, 和 V. Vapnik. 否证主义与统计学习理论：比较波普尔与Vapnik-Chervonenkis维度. *Journal for General Philosophy of Science*, 40(1):51–58, 2009.

T. Cover和J. Thomas。*Elements of Information Theory*。Wiley电信与信号处理系列，Wiley出版社，纽约，1991年。

D. R. Cox. *Planning of Experiments*. Wiley，纽约，纽约州，1958年。

J. Cussens. 使用切割平面的贝叶斯网络学习. 在 *Proceedings of the 27th Annual Conference on Uncertainty in Artificial Intelligence (UAI)* 中，第153–160页，2011年.

P. Daniušis, D. Janzing, J. M. Mooij, J. Zscheischler, B. Steudel, K. Zhang, 和 B. Schölkopf. 推断确定性因果关系. 在 *Proceedings of the 26th Annual Conference on Uncertainty in Artificial Intelligence (UAI)* 中，第143–150页，2010年.

D. Danks 和 S. Plis. 从欠采样时间序列中学习因果结构，2013. URL `http://repository.cmu.edu/cgi/viewcontent.cgi?article=1638&context=philosophy`. 结果在2013年NIPS因果性研讨会上展示；最后访问网站日期：2017年1月31日。

G. Darmois. 随机关联的一般分析. *Revue de l'Institut International de Statistique*, 21:2–8, 1953.

D. Dash. 在均衡中重构动态因果系统. 在 *Proceedings of the 10th International Conference on Artificial Intelligence and Statistics (AISTATS)* 中，第81–88页，2005年.

A. P. Dawid. 统计理论中的条件独立性. *Journal of the Royal Statistical Society, Series B: Statistical Methodology (with discussion)*, 41(1): 1–31, 1979.

A. P. Dawid。从决策论视角看统计因果性。*Annual Review of Statistics and Its Application*，2：273–303，2015。C. P. De Campos和Q. Ji。利用约束高效学习贝叶斯网络结构。*Journal of Machine Learning Research*，12：663–689，2011。L. Devroye、L. Györfi和G. Lugosi。*A Probabilistic Theory of Pattern Recog- nition*，第31卷，*Applications of Mathematics*。Springer，纽约，纽约州，1996。V. Didelez、S. Meng和N. A. Sheehan。观察性流行病学中IV方法的假设。*Statistical Science*，25：22–40，2010。

C. Diks 和 V. Panchenko。一种新的统计量及非参数格兰杰因果检验的实用指南。*Journal of Economic Dynamics and Control*，30(9–10)：1647–1669，2006。

D. DiVincenzo。两量子比特门对于量子计算是通用的。*Physical Review A*，51：1015–1022，1995。

M. Drton、M. Eichler 和 T. S. Richardson。计算具有相关误差的递归线性模型中的最大似然估计。*Journal of Machine Learning Research*，10：2329–2348，2009a。

M. Drton、B. Sturmfels 和 S. Sullivant。*Lectures on Algebraic Statistics*，第 39 卷，*Oberwolfach Seminars*。Birkhäuser，巴塞尔，2009b。

M. Druzdzel 和 H. Simon. 贝叶斯信念网络中的因果关系. 在 *In Proceedings of the 9th Annual Conference on Uncertainty in Artificial Intelligence (UAI)* 中, 第 3–11 页, 1993 年.

M. J. Druzdzel 和 H. van Leijen. 贝叶斯网络中的因果可逆性. *Journal of Experimental and Theoretical Artificial Intelligence*, 13(1):45–62, 2001. R. M. Dudley. *Real Analysis and Probability*. 剑桥大学出版社，纽约，2002年。

D. Eaton 和 K. P. Murphy。从不确定干预中进行精确贝叶斯结构学习。见 *Proceedings of the 11th International Conference on Artificial Intelligence and Statistics (AISTATS)*，第107–114页，2007年。

F. Eberhardt 和 R. Scheines。干预与因果推断。*Philosophy of Science*，74(5)：981–995，2007。

F. Eberhardt、C. Glymour和R. Scheines。关于足以并在最坏情况下必要确定 *n* 变量间所有因果关系的实验数量。载于 *Proceedings of the 21st Annual Conference on Uncertainty in Artificial Intelligence (UAI)*，第178–184页，2005年。

F. Eberhardt, P. O. Hoyer, and R. Scheines. 结合实验以发现带有潜在变量的线性循环模型。 在 *Proceedings of the 13th International Conference on Artificial Intelligence and Statistics (AISTATS)* 中，第 185–192 页，2010 年。

M. Eichler. 多变量时间序列的图建模. *Probability Theory and Related Fields*, 第1–36页, 2011.

M. Eichler. 时间序列分析中的因果推断. 在C. Berzuini, P. Dawid, 和 L. Bernardinelli, 编辑, *Causality: Statistical Perspectives and Applications*, 第327–354页. Wiley, 奇切斯特, 英国, 2012.

J. Ellenberg. *How Not to Be Wrong: The Power of Mathematical Thinking*. Penguin Press，伦敦，英国，2014年。

R. F. Engle、D. F. Hendry 和 J.-F. Richard。外生性。*Econometrica*，51(2)：277–304，1983。

R. J. Evans. 边缘化DAG中不等式约束的图方法. In *Proceedings of the 22nd Workshop on Machine Learning and Signal Processing*, pages 1–12, 2012.

R. J. Evans. 离散贝叶斯网络的边缘. *ArXiv e-prints (arXiv:1501.02103)*, 2015.

R. J. Evans 和 T. S. Richardson. 面向离散数据的马尔可夫无环有向混合图. *The Annals of Statistics*, 42(2):1452–1482, 2014.

T. S. Ferguson。*Mathematical Statistics — A Decision Theoretic Approach*。学术出版社，纽约，纽约州和伦敦，英国，1967年。

A. Fink. 条件概率交公理的二项式理想. *Journal of Algebraic Combinatorics*, 33(3):455–463, 2011.

R. A. Fisher. *Statistical Methods for Research Workers*. Oliver & Boyd，英国爱丁堡，1925年。

W. T. Freeman。视觉感知框架中的通用视点假设。*Nature*，368(6471)：542–545，1994。

R. Frisch 和 F. V. Waugh。部分时间回归与个体趋势的比较。*Econometrica*，1(4)：387–401，1933年。

R. Frisch、T. Haavelmo、T. C. Koopmans 和 J. Tinbergen。*Autonomy of Economic Relations*。系列：Memorandum fra Universitets Socialøkonomiske Institutt。Universitets Socialøkonomiske Institutt，挪威奥斯陆，1948年。

K. Friston、L. Harrison 和 W. Penny。动态因果建模。*NeuroImage*，19:1273–1302，2003。

K. Friston, J. Daunizeau, and K. Stephan. 模型选择与胡言乱语：回应 Lohmann 等人。*NeuroImage*, 75:275–278, 2013.

M. Frydenberg. 链图马尔可夫性质. *Scandinavian Journal of Statis- tics*, 17(4):333–353, 1990.

K. Fukumizu, A. Gretton, X. Sun, 和 B. Schölkopf. 条件依赖的核度量. 在 *Advances in Neural Information Processing Systems 20 (NIPS)*中, 页码 489–496, 2008.

J. A. Gagnon-Bartsch 和 T. P. Speed。利用控制基因校正微阵列数据中的不需要变异。*Biostatistics*，13：539–552，2012。

D. Galles 和 J. Pearl. 因果反事实的公理化特征. *Foundations of Science*, 3(1):151–182, 1998.

D. Geiger 和 D. Heckerman。学习高斯网络。见 *Proceedings of the 10th Annual Conference on Uncertainty in Artificial Intelligence (UAI)*，第235–243页，1994a。

D. Geiger 和 D. Heckerman。学习贝叶斯网络：知识与统计数据的结合。载于 *Proceedings of the 10th Annual Conference on Uncertainty in Artificial Intelligence (UAI)*，第293–301页，1994b。

D. Geiger 和 C. Meek. 图模型与指数族. 在 *Proceedings of 14th Annual Conference on Uncertainty in Artificial Intelligence (UAI)* 中，第156–165页, 1998.

P. Geiger, D. Janzing, 和 B. Schölkopf. 通过界定混杂因素估计因果效应. 在 *Proceedings of the 30th Conference on Uncertainty in Artificial Intelligence (UAI)* 中, 第240–249页, 2014年.

D. Geradin 和 I. Girgenson。欧盟竞争法中的反事实方法：基于效果方法的基石。SSRN 可获取：`http:// ssrn.com/abstract=1970917`，2011年。

C. W. J. Granger. 因果性检验：个人观点. *Journal of Economic Dynamics and Control*, 2(1):329–352, 1980.

C. W. J. 格兰杰. 因果性概念的近期发展. *Journal of Econometrics*, 39(1–2):199–211, 1988.

A. Gretton, K. Fukumizu, C. H. Teo, L. Song, B. Schölkopf, 和 A. Smola. 独立性的核统计检验. 在 *Advances in Neural Information Processing Systems 20 (NIPS)* 中, 第585–592页, 2008年.

P. D. Grünwald. *The Minimum Description Length Principle*. MIT 出版社，马萨诸塞州剑桥，2007 年。

I. Guyon。挑战：因果关系对，2013年。网址 `https://www.kaggle.com/c/cause-effect-pairs/`。结果在NIPS 2013研讨会上展示 `http://clopinet.com/isabelle/Projects/NIPS2013/`；网站最后访问日期：2016年7月19日。

J. Gwiazda, E. Ong, R. Held, 和 F. Thorn. 视觉：近视与夜间环境照明。*Nature* , 404:144, 2000.

T. Haavelmo. 联立方程系统的统计含义. *Econometrica*, 11(1):1–12, 1943.

T.哈维尔莫。计量经济学中的概率方法。*Econometrica*, 12:S1– S115 (增刊), 1944.

J. Y. Halpern. 因果推理的公理化. *Journal of Artificial Intelligence Research*, 12 :317–337, 2000.

J. Y. Halpern. *Actual Causality*. MIT Press，剑桥，马萨诸塞州，2016年。

N. R. Hansen 和 A. Sokol。随机微分方程的因果解释。*Electronic Journal of Probability*, 19(100):1–24, 2014。

T. Hastie, R. Tibshirani, and J. Friedman. *The Elements of Statistical Learning: Data Mining, Inference and Prediction*. Springer, New York, NY, 第2版, 2009.

D. M. A. Haughton. 关于选择模型以拟合来自指数族的数据. *The Annals of Statistics*, 16(1):342–355, 1988.

A. Hauser 和 P. Bühlmann。有向无环图干预马尔可夫等价类的刻画与贪心学习。*Journal of Ma- chine Learning Research*，13：2409–2464，2012。

A. Hauser 和 P. Bühlmann。从干预数据中主动学习因果模型的两个最优策略。*International Journal of Approximate Reason- ing*，55：926–939，2014。

A. Hauser 和 P. Bühlmann。联合干预与观察数据：有向无环图干预马尔可夫等价类的估计。*Journal of the Royal Statistical Society, Series B: Statistical Methodology*，77：291–318，2015。

D. M. Hausman 和 J. Woodward。独立性、不变性与因果马尔可夫条件。*The British Society for the Philosophy of Science*，50：521–583，1999年。

D. Heckerman、C. Meek 和 G. Cooper。因果发现的贝叶斯方法。收录于 C. Glymour 和 G. Cooper 编，*Computation, Causation, and Discovery*，第141–165页。MIT出版社，剑桥，马萨诸塞州，1999年。

R. Hemmecke, S. Linder, 和 M. Studený. 学习贝叶斯网络结构的特征 imset. *International Journal of Approximate Reasoning*, 53:1336–1349, 2012.

M. A. Hernán 和 J. M. Robins。因果推断的工具：流行病学家的梦想? *Epidemiology*，17：360–372，2006。

P. W. Holland. 统计学与因果推断. *Journal of the American Statistical Association*, 81:968–970, 1986.

K. D. Hoover. 经济学与计量经济学中的因果关系。载于 S. N. Durlauf 与 L. E. Blume 编，*The New Palgrave Dictionary of Economics*。Palgrave Macmillan，英国贝辛斯托克，第二版，2008年。

D. G. Horvitz 和 D. J. Thompson. 有限总体中无放回抽样的推广. *Journal of the American Statistical Association*, 47 (260):663–685, 1952. P. O. Hoyer, A. Hyvärinen, R. Scheines, P. Spirtes, J. Ramsey, G. Lacerda, 和 S. Shimizu. 具有任意分布的线性无环模型的因果发现. 在 *Proceedings of the 24th Annual Conference on Uncertainty in Artificial Intelligence (UAI)* 中, 页码 282–289, 2008a. P. O. Hoyer, S. Shimizu, A. J. Kerminen, 和 M. Palviainen. 使用带有隐藏变量的线性非高斯因果模型估计因果效应. *Interna- tional Journal of Approximate Reasoning*, 49(2):362–378, 2008b. P. O. Hoyer, D. Janzing, J. M. Mooij, J. Peters, 和 B. Schölkopf. 基于加性噪声模型的非线性因果发现. 在 *Advances in Neural Information Processing Systems 21 (NIPS)* 中, 页码 689–696, 2009. Y. Huang 和 M. Valtorta. Pearl的干预演算是完备的. 在 *Proceedings of the 22nd Annual Conference on Uncertainty in Artificial Intelligence (UAI)* 中, 页码 217–224, 2006. L Hurwicz. 关于相互依赖系统的结构形式. 在 E. Nagel, P. Suppes, 和 A. Tarski 编辑, *Logic, Methodology and Philosophy of Science, Proceedings of the 1960 International Congress*, 页码 232–239. 斯坦福大学出版社, 斯坦福, 加州, 1962. A. Hyttinen, F. Eberhardt, 和 P. O. Hoyer. 学习带有潜在变量的线性循环因果模型. *Journal of Machine Learning Research*, 13(1):3387–3439, 2012. A. Hyttinen, P. O. Hoyer, F. Eberhardt, 和 M. Järvisalo. 发现带有潜在变量的循环因果模型：一种通用的基于SAT的过程. 在 *Proceedings of the 29th Annual Conference on Uncertainty in Artificial Intelligence (UAI)* 中, 页码 301–310, 2013. A. Hyttinen, S. Plis, M. Järvisalo, F. Eberhardt, 和 D. Danks. 通过约束优化从子采样时间序列数据中发现因果关系. 在 *Proceedings of the 8th International Conference on Probabilistic Graphical Models (PGM)* 中, 页码 216–227, 2016.

A. Hyvärinen, J. Karhunen, 和 E. Oja. *Independent Component Analysis*. 信号处理、通信与控制的适应性和学习系统. Wiley, 纽约, 纽约州, 2001.

A. Hyvärinen, S. Shimizu, 和 P. Hoyer. 结合瞬时与滞后效应的因果建模：基于非高斯性的可识别模型. 在 *Proceedings of the 25th International Conference on Machine Learning (ICML)* 中, 第424–431页, 2008年.

G. W. Imbens 和 J. Angrist. 局部平均处理效应的识别与估计. *Econometrica*, 62(2):467–75, 1994. G. W. Imbens 和 D. B. Rubin. 关于J. Pearl的“因果图在实证研究中的应用”的讨论. *Biometrika*, 82(4):694–695, 1995.

G. W. Imbens 和 D. B. Rubin。 *Causal Inference for Statistics, Social, and Biomedical Sciences: An Introduction*。剑桥大学出版社，纽约，纽约州，2015年。

T. Jaakkola, D. Sontag, A. Globerson, 和 M. Meila. 使用LP松弛学习贝叶斯网络结构. *Proceedings of the 13th International Conference on Artificial Intelligence and Statistics (AISTATS)*, 第358–365页, 2010年.

L. Jacob, J. A. Gagnon-Bartsch, 和 T. P. Speed. 在既未观察到不需要的变异也未观察到感兴趣的因素时校正基因表达数据。*Bio- statistics*, 17(1):16–28, 2016.

D. Janzing。关于具有单向线性性的时间序列的熵产生。 *Journal of Statistical Physics*, 138:767–779, 2010。

D. Janzing 和 B. Schölkopf。使用算法马尔可夫条件的因果推断。 *IEEE Transactions on Information Theory*，56(10)：5168–5194，2010。D. Janzing 和 B. Schölkopf。反因果学习场景中的半监督插值。 *Journal of Machine Learning Research*，16：1923–1948，2015。D. Janzing 和 B. Steudel。通过算法信息论证明基于加性噪声的因果发现。 *Open Systems and Information Dynamics*，17(2)：189–212，2010。D. Janzing、J. Peters、J. M. Mooij 和 B. Schölkopf。使用加性噪声模型识别混杂因素。载于 *Proceedings of the 25th Annual Conference on Uncertainty in Artificial Intelligence (UAI)*，第249–257页，2009a。

D. Janzing, X. Sun, 和 B. Schölkopf. 通过二阶指数模型区分因果。
ArXiv e-prints (0910.5561), 2009b.

D. Janzing, P. O. Hoyer, 和 B. Schölkopf. 基于高维观测的因果推断. 在
Proceedings of the 27th International Conference on Machine Learning (ICML)
中, 第479–486页, 2010年.

D. Janzing, E. Sgouritsa, O. Stegle, J. Peters, 和 B. Schölkopf. 检测低复杂度的
未观察原因. 在 *Proceedings of the 27th Annual Conference*
*on Uncertainty in Artificial Intelligence (UAI)*中， 第383–391页， 2011年.

D. Janzing, J. M. Mooij, K. Zhang, J. Lemeire, J. Zscheischler, P. Daniušis, B. Ste
udel, 和 B. Schölkopf. 推断因果方向的信息几何方法. *Artificial Intelligence*, 18
2–183:1–31, 2012.

D. Janzing, D. Balduzzi, M. Grosse-Wentrup, 和 B. Schölkopf. 量化因果影响.
The Annals of Statistics, 41(5):2324–2358, 2013.

D. Janzing, B. Steudel, N. Shajarisales, 和 B. Schölkopf. 证明信息-几何因果推
断的合理性. 在V. Vovk, H. Papadopolous, 和 A. Gammerman编辑,
Measures of Complexity, 纪念Alexey Chervonenkis文集, 页码253–265. Springe
r, 海德堡, 德国, 2015.

D. Janzing, R. Chaves, 和 B. Schölkopf. 热力学与因果推断中初始条件与动力
学定律的算法独立性. *New Journal of Physics*, 18(093052):1–13, 2016.

M. Kääriäinen。使用未标记数据的泛化误差界。载于*Proceedings*
of the 18th Annual Conference on Learning Theory (COLT)，第127–142页，2
005年。

M. Kalisch 和 P. Bühlmann。使用 PC 算法估计高维有向无环图。
Journal of Machine Learning Research，8：613–636，2007。

M. Kalisch, M. Mächler, D. Colombo, M. H. Maathuis, 和 P. Bühlmann. 使用R
包pcalg的图模型进行因果推断. *Journal of Statistical Software*, 47(11):1–26, 20
12.

C. Kang 和 J. Tian. 含隐变量因果模型中的不等式约束. 在
Proceedings of the 22th Annual Conference on Uncertainty in Artificial Intel-
ligence (UAI) 中， 第233–240页， 2006年.

Y. Kano 和 S. Shimizu。利用非正态性进行因果推断。载于 *Proceedings of the International Symposium on the Science of Modeling, the 30th Anniversary of the Information Criterion*，第 261–270 页，2003 年。

A. Kela, K. von Prillwitz, J. Åberg, R. Chaves, 和 D. Gross. 潜在因果结构的半定测试. *ArXiv e-prints (1701.00652)*, 2017.

M. Koivisto. 贝叶斯网络中精确贝叶斯结构发现的进展. 在 *Proceedings of the 22nd Annual Conference on Uncertainty in Artificial Intelligence (UAI)* 中， 第241–248页， 2006.

M. Koivisto 和 K. Sood. 贝叶斯网络中的精确贝叶斯结构发现. *Journal of Machine Learning Research*, 5:549–573, 2004.

D. Koller 和 N. Friedman。*Probabilistic Graphical Models: Principles and Techniques*。麻省理工学院出版社，马萨诸塞州剑桥，2009年。

A. Kolmogorov. 信息定量定义的三种方法. *Problems of Information Transmission*, 1(1):3–11, 1965.

T. C. Koopmans. 何时一个方程组在统计目的上是完整的？见 T. C. Koopmans 编，*Statistical Inference in Dynamic Economic Models*，第393–409页。Wiley and Chapman & Hall，纽约，纽约州，及伦敦，英国，1950年。

K. Korb、L. Hope、A. Nicholson 和 K. Axnick。因果干预的多样性。载于 *Proceedings of the Pacific Rim Conference on Artifical Intelligence*，第 322–331 页，2004年。

S. Kpotufe, E. Sgouritsa, D. Janzing, 和 B. Schölkopf. 加法噪声模型下因果推断的一致性. 在 *Proceedings of the 31st International Conference on Machine Learning, ICML 2014, Beijing, China*中, 第478–486页, 2014年.

G. Lacerda, P. Spirtes, J. Ramsey, 和 P. O. Hoyer. 通过独立成分分析发现循环因果模型. 在 *Proceedings of the 24th Annual Conference on Uncertainty in Artificial Intelligence (UAI)*, 第366–374页, 2008年.

S. L. Lauritzen. *Graphical Models*. 牛津大学出版社，纽约，纽约州，1996年。

S. L. Lauritzen。关于因果关系的讨论。*Scandinavian Journal of Statistics*，31(2)：189−193，2004。

S. L. Lauritzen 和 T. S. Richardson. 链图模型及其因果解释. *Journal of the Royal Statistical Society, Series B: Statistical Methodology (with discussion)*, 64(3):321−361, 2002.

S. L. Lauritzen和N. Wermuth. 变量间关联的图模型，其中一些是定性的，一些是定量的。*Annals of Statistics*, 17(1):31−57, 1989.

J. Lemeire和E. Dirkx。因果模型作为多变量系统的最小描述。`http://parallel.vub.ac.be/~jan/`，2006年。

J. Lemeire 和 D. Janzing。用条件算法的独立性替代因果忠实性。*Minds and Machines*, 23:227−249, 2013。

L. A. Levin. 通用顺序搜索问题. *Problems of Information Trans- mission*, 9(3):115−116, 1973. (由B. A. Trakhtenbrot翻译成英文：“关于perebor（暴力搜索）算法的俄罗斯方法综述”，*Annals of the History of Computing* 6(4): 384−400, 1984).

M. Levine, D. R. Hunter, and D. Chauveau. 多元混合模型的最大平滑似然。*Biometrika*, 98(2):403−416, 2011.

M. Li 和 P. Vitányi。*An Introduction to Kolmogorov Complexity and Its Applications*。Springer，纽约，纽约州，第3版，1997年。

G. Lohmann, K. Erfurth, K. Müller, and R. Turner. 对动态因果建模的批判性评论. *NeuroImage*, 59:2322−2329, 2012a.

G. Lohmann、K. Müller和R. Turner。对关于我们论文：动态建模批判性评论的评论的回应。*NeuroImage*，75:279−281，2012b。

D. Lopez-Paz, K. Muandet, B. Schölkopf, and I. Tolstikhin. 迈向因果效应推断的学习理论. In *Proceedings of the 32nd International Conference on Machine Learning (ICML)*, pages 1452−1461, 2015.

H. Lütkepohl。*New Introduction to Multiple Time Series Analysis*。Springer，柏林，德国，2007年。

M. H. Maathuis, D. Colombo, M. Kalisch, 和 P. Bühlmann。从观测数据估计高维干预效应。*The Annals of Statis- tics*, 37(6A):3133–3164, 2009。

D. J. C. MacKay. *Information Theory, Inference, and Learning Algorithms*。剑桥大学出版社，纽约，2002年。

S. Mani, G. F. Cooper, 和 P. Spirtes. 因果发现中y结构的理论研究. 在 *Proceedings of the 22nd Annual Conference on Uncertainty in Artificial Intelligence (UAI)* 中, 第314–323页, 2006年.

D. Marinazzo, M. Pellicoro, 和 S. Stramaglia. 非线性格兰杰因果关系的核方法. *Physical Review Letters*, 100:144103–1–4, 2008.

F. Markowetz、S. Grossmann 和 R. Spang。条件高斯网络中的概率软干预。载于 *Proceedings of the 10th International Conference on Artificial Intelligence and Statistics (AISTATS)*，第214–221页，2005年。

J. Marschak。经济学中的统计推断：导论。载于 T. C. Koopmans 编，*Statistical Inference in Dynamic Economic Models*，第1–50页。Wiley and Cha pman & Hall，纽约州纽约市及英国伦敦，1950年。Cowles 经济研究委员会，专论第10号。

B. D. McKay. 无环有向图与(0, 1)矩阵的特征值. *Journal of Integer Sequences*, 7(2):1–5, 2004.

C. Meek. 带有背景知识的因果推断与因果解释. 在 *Proceedings of the 11th Annual Conference on Uncertainty in Artificial Intelligence (UAI)* 中， 第403–441页， 1995.

J. M. Mooij, D. Janzing, J. Peters, 和 B. Schölkopf. 通过依赖最小化进行回归及其在因果推断中的应用. 在 *Proceedings of the 26th International Conference on Machine Learning (ICML)*中, 第745–752页, 2009年.

J. M. Mooij, D. Janzing, T. Heskes, 和 B. Schölkopf. 关于循环加性噪声模型的因果发现. 在 *Advances in Neural Information Processing Systems 24 (NIPS)*中, 第639–647页, 2011年.

J. M. Mooij, D. Janzing, 和 B. Schölkopf. 从常微分方程到结构因果模型：确定性情形. 在 *Proceedings of the 29th Annual Conference on Uncertainty in Artificial Intelligence (UAI)*中, 第440–448页, 2013年.

J. M. Mooij, J. Peters, D. Janzing, J. Zscheischler, 和 B. Schölkopf. 使用观察数据区分因果：方法与基准。*Jour- nal of Machine Learning Research*, 17:1–102, 2016.

S. L. Morgan 和 C. Winship。*Counterfactuals and Causal Inference: Methods and Principles for Social Research*。剑桥大学出版社，纽约，纽约州，第2版，2007年。

W. K. Newey. 非参数工具变量估计. *American Eco- nomic Review*, 103(3):550–556, 2013.

J. Neyman. 论概率论在农业实验中的应用。原理探讨。第9节（译文）。*Statistical Science*，5：465–480，1923年。

M. Nielsen 和 I. Chuang。*Quantum Computation and Quantum Information*。剑桥大学出版社，纽约，2000年。

C. Nowzohour 和 P. Bühlmann。加性噪声模型中基于得分的因果学习。*Statistics*，50(3)：471–485，2016。

C. Nowzohour、M. Maathuis 和 P. Bühlmann。基于无弓无环路径图的结构学习。*ArXiv e-prints (1508.01717)*，2015年。

OEIS基金会。整数序列在线百科全书。`http://oeis.org/A003024`，2017年。网站最后访问日期：2016年9月5日。

J. Pearl. 一种用于概率推理的约束传播方法. 在 *Proceedings of the 4th Annual Conference on Uncertainty in Artificial Intelligence (UAI)* 中， 第31–42页， 1985.

J. Pearl. *Probabilistic Reasoning in Intelligent Systems: Networks of Plausible Inference*. Morgan Kaufmann Publishers Inc.，旧金山，加利福尼亚州，1988年。J. Pearl. 再探信念网络. *Artificial Intelligence*, 59:49–56, 1993年。J. Pearl. 实证研究的因果图. *Biometrika*, 82(4):669–688, 1995年。J. Pearl. *Causality: Models, Reasoning, and Inference*. 剑桥大学出版社，纽约，纽约州，第二版，2009年。

J. Pearl. Trygve Haavelmo与因果演算的出现. *Econometric Theory*, 31:152–179, 2015.

J. Pearl、M. Glymour 和 N. P. Jewell。*Causal Inference in Statistics*。Wiley，纽约，纽约州，2016 年。

C. S. Peirce。 可能推理的理论。 在C. S. Peirce编辑的 *Studies in Logic by Members of the Johns Hopkins University* 中，第126–181页。 Little, Brown, and Company，马萨诸塞州波士顿，1883年。

C. S. Peirce 和 J. Jastrow。 论感觉中的微小差异。 *Memoirs of the National Academy of Sciences*，3：73–83，1885。

E. Perkovic, J. Textor, M. Kalisch, 和 M. Maathuis. 完全广义调整准则. 在 *Proceedings of the 31st Annual Conference on Uncertainty in Artificial Intelligence (UAI)* 中, 第682–691页, 2015年.

J. Peters. 时间序列在方向反转下的不对称性. 文凭论文，海德堡大学，海德堡，德国，2008年.

J. Peters. *Restricted Structural Equation Models for Causal Inference*. 博士论文，苏黎世联邦理工学院与马克斯·普朗克智能系统研究所，2012年. http://dx.doi.org/10.3929/ethz-a-007597940.

J. Peters。关于条件独立的交集性质及其在因果发现中的应用。*Journal of Causal Inference*，3：97–108，2014。

J. Peters 和 P. Bühlmann. 等误差方差高斯结构方程模型的可识别性. *Biometrika*, 101(1):219–228, 2014.

J. Peters 和 P. Bühlmann。用于评估因果图的结构干预距离（SID）。*Neural Computation*，27:771–799，2015。

J. Peters, D. Janzing, A. Gretton, 和 B. Schölkopf. 检测时间序列方向的核方法. 在 *Proccedings of the 32nd Annual Conference of the German Classification Society (GfKl 2008)* 中， 第1–10页， 2009a.

J. Peters, D. Janzing, A. Gretton, 和 B. Schölkopf. 因果时间序列方向的检测. 在 *Proceedings of the 26th International Conference on Ma- chine Learning (ICML)* 中, 第 801–808 页, 2009b.

J. Peters, D. Janzing, 和 B. Schölkopf. 使用加性噪声模型识别离散数据上的因果。在 *Proceedings of the 13th International Conference on Artificial Intelligence and Statistics (AISTATS)* 中，页码 597–604，2010年。

J. Peters, D. Janzing, 和 B. Schölkopf. 使用加性噪声模型对离散数据进行因果推断. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 33:2436–2450, 2011a.

J. Peters, J. M. Mooij, D. Janzing, 和 B. Schölkopf. 使用功能模型的因果图可识别性. 在 *Proceedings of the 27th Annual Conference on Uncertainty in Artificial Intelligence (UAI)*中, 第589–598页, 2011b.

J. Peters、D. Janzing 和 B. Schölkopf。使用受限结构方程模型对时间序列进行因果推断。载于 *Advances in Neural Information Processing Systems 26 (NIPS)*，第154–162页，2013年。

J. Peters, J. M. Mooij, D. Janzing, and B. Schölkopf. 连续加性噪声模型的因果发现. *Journal of Machine Learning Research*, 15:2009–2053, 2014.

J. Peters, P. Bühlmann, 和 N. Meinshausen. 使用不变预测的因果推断：识别与置信区间. *Journal of the Royal Statistical Society, Series B: Statistical Methodology (with discussion)*, 78(5):947–1012, 2016.

K. Peterson. 带睡眠定时器的夜灯，2005年。URL `http://www.google.com/patents/US20050007889`。美国专利申请 10/614,245；网站最后访问日期：2016年7月19日。

N. Pfister, P. Bühlmann, B. Schölkopf和J. Peters。基于核的联合独立性检验。*Journal of the Royal Statistical Society: Series B (to appear)*, 2017. doi: 10.1111/rssb.12235。

K. R. Popper. *The Logic of Scientific Discovery*. Routledge，伦敦，2002年。第一版英文版：1959年。

G. E. Quinn, C. H. Shin, M. G. Maguire, 和 R. A. Stone. 夜间近视与环境照明. *Nature*, 399:113–114, 1999.

J. Quionero-Candela, M. Sugiyama, A. Schwaighofer, 和 N. D. Lawrence. *Dataset Shift in Machine Learning*. MIT出版社, 剑桥, 马萨诸塞州, 2009.

R Core Team。*R: A Language and Environment for Statistical Computing*。R Foundation for Statistical Computing，奥地利维也纳，2016年。URL `http://www.R-project.org`。

J. Ramsey。一种适用于非线性、非高斯数据的可扩展条件独立性检验。*ArXiv e-prints (1401.5031)*，2014。

H. 赖兴巴赫。*The Direction of Time*。加州大学出版社，加利福尼亚州伯克利，1956年。

T. S. Richardson. 无环有向混合图的马尔可夫性质. *Scandinavian Journal of Statistics*, 30(1):145–157, 2003.

T. S. Richardson 和 J. M. Robins. 单世界干预图（SWIGs）：因果关系的反事实与图形方法的统一，2013年。工作论文编号128，统计与社会科学中心，华盛顿大学。

T. S. Richardson 和 P. Spirtes。祖先图马尔可夫模型。*The Annals of Statistics*，30(4)：962–1030，2002。

T. S. Richardson, J. M. Robins, 和 I. Shpitser. 无环有向混合图的嵌套马尔可夫性质（仅摘要）。在 *Proceedings of the 28th Annual Conference on Uncertainty in Artificial Intelligence (UAI)* 中，2012年。

T. S. Richardson, R. J. Evans, J. M. Robins, 和 I. Shpitser. 有向无环混合图的嵌套马尔可夫性质. *ArXiv e-prints (1701.06686)*, 2017.

J. M. Robins. 一种在具有持续暴露期的死亡率研究中进行因果推断的新方法——应用于控制健康工人幸存者效应。*Mathematical Modeling*，7：1393–1512，1986。

J. M. Robins, R. Scheines, P. Spirtes, 和 L. Wasserman. 因果推断中的均匀一致性. *Biometrika*, 90(3):491–515, 2003.

R. W. Robinson. 无环有向图的枚举. In *Proceedings of the 2nd Chapel Hill Conference on Combinatorial Mathematics and its Applications (University of North Carolina)*, pages 391–399, 1970.

R. W. Robinson. 计数有标号无环有向图. 载于 F. Harary 编, *New Directions in the Theory of Graphs*, 第239–273页. Academic Press, 纽约, 纽约州, 1973.

N. J. Roese. 反事实思维. *Psychological Bulletin*, 121:133–148, 1997.

M. Rojas-Carulla, B. Schölkopf, R. Turner, and J. Peters. 机器学习中的因果迁移. *ArXiv e-prints (1507.05333v3)*, 2016.

T. Roos, T. Silander, P. Kontkanen, 和 P. Myllymaki. 使用因子化NML通用模型的贝叶斯网络结构学习. 在 *2008 Information Theory and Applications Workshop* 中, 第272–276页, 2008年.

P. R. Rosenbaum 和 D. B. Rubin。倾向得分在因果效应观察性研究中的核心作用。*Biometrika*， 70(1)：41–55, 1983.

D. Rothenhäusler, C. Heinze, J. Peters, 和 N. Meinshausen. backShift：从未知的转移干预中学习因果循环图. 在 *Advances in Neural Information Processing Systems 28 (NIPS)* 中, 第 1513–1521 页, 2015.

D. B. Rubin. 在随机和非随机研究中估计处理因果效应. *Journal of Educational Psychology*, 66:688–701, 1974.

D. B. Rubin. 通过潜在结果的直接和间接因果效应. *Scandinavian Journal of Statistics*, 31(2):161–170, 2004.

D. B. Rubin. 使用潜在结果的因果推断. *Journal of the American Statistical Association*, 100(469):322–331, 2005.

K. Sadeghi 和 S. Lauritzen。混合图的马尔可夫性质。*Bernoulli*， 20 (2)：676–696， 2014。

B. Schölkopf 和 A. J. Smola。*Learning with Kernels*。MIT出版社， 马萨诸塞州剑桥， 2002年。

B. Schölkopf, D. Janzing, J. Peters, E. Sgouritsa, K. Zhang, and J. M. Mooij. 关于因果与反因果学习. In *Proceedings of the 29th International Conference on Machine Learning (ICML)*, pages 1255–1262, 2012.

B. Schölkopf, D. W. Hogg, D. Wang, D. Foreman-Mackey, D. Janzing, C.-J. Simon-Gabriel, and J. Peters. 通过潜在原因消除系外行星搜索中的系统误差。In *Proceedings of the 32nd International Conference on Machine Learning (ICML)*, pages 2218–2226, 2015.

B. Schölkopf, D. W. Hogg, D. Wang, D. Foreman-Mackey, D. Janzing, C.-J. Simon-Gabriel, 和 J. Peters. 通过半同胞回归建模混杂因素. *Proceedings of the National Academy of Sciences*, 113(27):7391–7398, 2016.

T. Schreiber. 测量信息传递. *Physical Review Letters*, 85:461– 464, 2000.

E. Sgouritsa, D. Janzing, J. Peters, 和 B. Schölkopf. 识别非参数乘积分布的有限混合及混杂因素的因果推断. 在
Proceedings of the 29th Annual Conference on Uncertainty in Artificial Intelligence (UAI) 中, 第 556–565 页, 2013 年.

E. Sgouritsa, D. Janzing, P. Hennig, 和 B. Schölkopf. 无监督逆回归的因果推断. 在 *Proceedings of the 18th International
Conference on Artificial Intelligence and Statistics (AISTATS)* 中，第 847–855 页，2015 年。

N. Shajarisales, D. Janzing, B. Schölkopf, 和 M. Besserve. 在确定性线性动力系统中区分因果。在 *Proceedings of the 32nd
International Conference on Machine Learning (ICML)* 中，第 285–294 页，2015 年。

N. A. Sheehan, M. Bartlett, and J. Cussens. 改进的复杂多代谱系最大似然重建。*Theoretical Population Biology*, 97:11–19, 2014.

S. Shimizu, P. O. Hoyer, A. Hyvärinen, and A. J. Kerminen. 用于因果发现的线性非高斯无环模型. *Journal of Machine Learning Research*, 7: 2003–2030, 2006.

S. Shimizu, T. Inazumi, Y. Sogawa, A. Hyvärinen, Y. Kawahara, T. Washio, P. O. Hoyer, 和 K. Bollen. DirectLiNGAM：一种学习线性非高斯结构方程模型的直接方法。*Journal of Machine Learning Re- search*, 12:1225–1248, 2011.

H. Shimodaira。通过加权对数似然函数改进协变量偏移下的预测推断。*Journal of Statistical Planning and Inference*, 90 (2):227–244, 2000.

A. Shojaie 和 G. Michailidis. 稀疏高维有向无环图估计的惩罚似然方法. *Biometrika*, 97(3):519–538, 2010.

I. Shpitser 和 J. Pearl。递归半马尔可夫因果模型中联合干预分布的识别。见 *Proceedings of the 21st AAAI Confer- ence on Artificial Intelligence — Volume 2*，第1219–1226页，2006年。

I. Shpitser 和 J. Pearl. 因果层级的完整识别方法.
Journal of Machine Learning Research, 9:1941–1979, 2008a.

I. Shpitser 和 J. Pearl. 潜伏独立性. 在 *Proceedings of the 23rd AAAI Conference on Artificial Intelligence* 中，第1081–1087页，2008b.

I. Shpitser, T. J. VanderWeele, 和 J. M. Robins. 关于协变量调整估计因果效应的有效性. 在 *Proceedings of the 26th Annual Conference on Uncertainty in Artificial Intelligence (UAI)* 中, 第527–536页, 2010年.

I. Shpitser, T. S. Richardson, J. M. Robins, 和 R. Evans. 嵌套马尔可夫模型中的参数与结构学习. *ArXiv e-prints (1207.5058)*, 2012.

I. Shpitser, R. J. Evans, T. S. Richardson, 和 J. M. Robins. 嵌套马尔可夫模型引论. *Behaviormetrika*, 41:3–39, 2014.

T. Silander 和 P. Myllymak。一种寻找全局最优贝叶斯网络结构的简单方法。载于 *Proceedings of the 22nd Annual Conference on Uncertainty in Artificial Intelligence (UAI)*，第445–452页，2006年。

R. Silva 和 R. Evans. 通过见证程序进行因果推断. 在 *Advances in Neural Information Processing Systems 27 (NIPS)* 中，第 298–306 页，2014年.

R. Silva 和 Z. Ghahramani。潜变量的隐藏生活：混合图模型下的贝叶斯学习。*Journal of Machine Learning Research*，10：1187–1238，2009。

R. Silva, R. Scheines, C. Glymour, and P. Spirtes. 学习线性潜变量模型的结构. *Journal of Machine Learning Research*, 7:191–246, 2006.

H. A. Simon. 因果排序与可识别性. 载于 W. C. Hood 和 T. C. Koopmans 编, *Studies in Econometric Methods*，第49–74页. Wiley，纽约，1953年. 考尔斯经济研究委员会，专著第14号.

E. H. Simpson. 列联表中交互作用的解释. *Journal of the Royal Statistical Society, Series B: Statistical Methodology*, 13:238–241, 1951.

V. P. Skitovič. 独立随机变量中的线性形式与正态分布律（俄文）. *Izvestiia Akademii Nauk SSSR, Serija Matematiceskie*, 18:185–200, 1954.

V. P. Skitovič. 独立随机变量的线性组合与正态分布律. *Selected Translations in Mathematical Statistics and Prob- ability*, 2:211–228, 1962.

R. Solomonoff。归纳推理的形式理论。*Information and Control, Part II*， 7(2)：224–254， 1964。

C. Spearman. 一般智力，客观确定与测量. *The American Journal of Psychology*, 15(2):201–292, 1904.

P. Spirtes. 因果推断的随时算法。In *Proceedings of the 8th International Conference on Artificial Intelligence and Statistics (AISTATS)*, pages 213–221, 2001.

P. Spirtes. 因果推断导论. *Journal of Machine Learning Research*, 11:1643–1662, 2010.

P. Spirtes, C. Glymour, and R. Scheines. *Causation, Prediction, and Search*. MIT Press, Cambridge, MA, 2nd edition, 2000.

J. Splawa-Neyman、D. M. Dabrowska 和 T. P. Speed。论概率论在农业实验中的应用。原则 essay。第9节。*Statistical Science*， 5(4)：465–472， 1990。

W. Spohn. 随机独立性、因果独立性与可屏蔽性. *Journal of Philosophical Logic*, 9:73–99, 1980.

R. P. 斯坦利。 图的无环定向。 *Discrete Mathematics*， 7(5)：171–178, 1973。

I. Steinwart 和 A. Christmann。*Support Vector Machines*。Springer，纽约， NY，2008年。

B. Steudel 和 N. Ay. 共同祖先的信息论推断。*En- tropy*, 17(4):2304–2327, 2015.

B. Steudel, D. Janzing, 和 B. Schölkopf. 子模信息测度的因果马尔可夫条件. 在 *Proceedings of the 23rd Annual Conference on Learning Theory (COLT)* 中, 第464–476页, 2010年.

M. Studený 和 D. Haws. 学习贝叶斯网络结构：通过整数线性规划工具趋向本质图。*International Journal of Approximate Reasoning*, 55:1043–1071, 2014.

M. Sugiyama 和 M. Kawanabe。 *Machine Learning in Non-Stationary Environment*。 MIT Press，剑桥，马萨诸塞州，2012年。

X. Sun, D. Janzing, 和 B. Schölkopf. 通过选择具有最合理马尔可夫核的图进行因果推断. 在 *Proceedings of the 9th International Symposium on Artificial Intelligence and Mathematics* 中, 第 1–11 页, 2006 年.

R. S. Sutton 和 A. G. Barto. *Reinforcement Learning: An Introduction*. MIT 出版社，剑桥，马萨诸塞州，第二版，2015 年。

M. Teyssier 和 D. Koller。基于排序的搜索：一种简单有效的贝叶斯网络学习算法。见 *Proceedings of the 21st Annual Conference on Uncertainty in Artificial Intelligence (UAI)*，第584–590页，2005年。

J. Tian. *Studies in Causal Reasoning and Learning*. 博士论文， 加州大学洛杉矶分校计算机科学系， 加利福尼亚州洛杉矶， 2002年。

J. Tian 和 J. Pearl。从变化中发现因果关系。In *Proceedings of the 17th Annual Conference on Uncertainty in Artificial Intelligence (UAI)*，第512–522页，2001年。

J. Tian和J. Pearl。 关于含有隐变量的因果模型的可测试含义。 在 *Proceedings of the 18th Annual Conference on Uncertainty in Artificial Intelligence (UAI)*中，第519–527页，2002年。

R. Tillman, A. Gretton, 和 P. Spirtes. 弱加性噪声模型下的非线性有向无环结构学习. 在 *Advances in Neural Information Process- ing Systems 22 (NIPS)* 中, 页码 1847–1855, 2009年.

R. E. Tillman 和 F. Eberhardt。从具有相似变量集的多数据集中学习因果结构。*Behaviormetrika*，41(1)：41–64，2014。

S. Triantafillou 和 I. Tsamardinos. 基于约束的因果发现，来自对重叠变量集的多重干预。*Journal of Machine Learning Research*, 16:2147–2205, 2015.

S. Triantafillou, I. Tsamardinos, 和 I. G. Tollis. 从重叠变量集中学习因果结构. 在 *Proceedings of the 13th International Conference on Artificial Intelligence and Statistics (AISTATS)* 中, 第860–867页, 2010年.

I. Tsamardinos, L. E. Brown, 和 C. F. Aliferis. 最大最小爬山贝叶斯网络结构学习算法. *Machine Learning*, 65(1):31– 78, 2006.

C. Uhler, G. Raskutti, P. Bühlmann, 和 B. Yu. 因果推断中忠实性假设的几何学. *The Annals of Statistics*, 41(2):436–463, 2013.

S. Ullman. *The Interpretation of Visual Motion*. MIT出版社，剑桥，马萨诸塞州，1979年。

R. Urner、S. Shalev-Shwartz 和 S. Ben-David。访问未标记数据可以加速预测时间。在 *Proceedings of the 28th International Conference on Machine Learning (ICML)* 中，第 641–648 页，2011 年。

S. A. van de Geer. *Empirical Processes in M-Estimation*. 剑桥统计与概率数学系列。剑桥大学出版社，英国剑桥，2009年。

V. N. Vapnik. *Statistical Learning Theory*. Wiley，纽约，纽约州，1998年。

T. Verma 和 J. Pearl. 因果网络：语义与表达力. 在 *Proceedings of the 4th Annual Conference on Uncertainty in Artificial Intelligence (UAI)* 中， 第352–359页， 1988年.

T. Verma 和 J. Pearl. 因果模型的等价性和综合. 在 *Proceedings of the 6th Annual Conference on Uncertainty in Artificial Intelligence (UAI)* 中， 第255–270页， 1991年.

D. Voiculescu，编辑。*Free Probability Theory*，*Fields Institute Communications*的第12卷。美国数学学会，普罗维登斯，罗德岛州，1997年。

A. Wald. *Statistical Decision Functions*. Wiley，纽约，NY，1950。

L. Wang 和 E. Tchetgen Tchetgen. 使用工具变量的平均处理效应的有界、有效及三重稳健估计。*ArXiv e-prints (1611.09925)*, 2016.

H. White 和 X. Lu. 格兰杰因果与动态结构系统. *Journal of Financial Econometrics*, 8(2):193–243, 2010.

N. Wiener. 预测理论. 在 E. Beckenbach, 编辑, *Modern Mathematics for Engineers*. McGraw-Hill, 纽约, 纽约州, 1956.

H. P. Williams. 线性规划的傅里叶方法及其对偶. *The American Mathematical Monthly*, 93(9):681–695, 1986.

J. Wishart. 双因素理论中的抽样误差. *British Journal of Psy- chology*, 第180–187页, 1928年.

S. N. Wood. *Generalized Additive Models: An Introduction with R*. Chapman & Hall/CRC，英国伦敦，2006年。

P. G. Wright。*The Tariff on Animal and Vegetable Oils*。国际商业政策研究。Macmillan，纽约，纽约州，1928年。

S. Wright. 关于尺寸因子的本质. *Genetics*, 3:367–374, 1918.

S. Wright。遗传和环境在决定豚鼠花斑图案中的相对重要性。*Proceedings of the National Academy of Sciences*，6(6)：320–332，1920。

S. Wright. 相关与因果. *Journal of Agricultural Research*, 20(7): 557–585, 1921.

S. Wright. 路径系数法. *Annals of Mathematical Statistics*, 5 (3):161–215, 1934.

K. Zadnik, L. A. Jones, B. C. Irvin, R. N. Kleinstein, R. E. Manny, J. A. Shin, and D. O. Mutti. 视觉：近视与环境夜间照明。*Nature*, 404: 143–144, 2000。

J. Zhang. 关于在存在潜在混杂因素和选择偏差时因果发现的方向规则的完备性. *Artificial Intelligence*, 172: 1873–1896, 2008a.

J. Zhang. 基于祖先图的因果推理. *Journal of Machine Learning Research*, 9:1437–1474, 2008b.

J. Zhang 和 P. Spirtes。因果推断中的强忠实性与一致一致性。载于 *Proceedings of the 19th Annual Conference on Uncertainty in Artificial Intelligence (UAI)*，第632–639页，2003年。

J. Zhang 和 P. Spirtes。祖先图模型马尔可夫等价类的表征。技术报告编号 CMU-PHIL-168，2005年。

J. Zhang 和 P. Spirtes。不忠实性的检测与稳健因果推断。*Minds and Machines*，18(2)：239–271，2008。

张凯和陳立。ICA 在香港股票市场因果发现中的扩展。收录于 *13th International Conference on Neural Information Processing, (ICONIP)*，第400–409页，2006年。

K. Zhang 和 A. Hyvärinen。关于后非线性因果模型的可识别性。载于 *Proceedings of the 25th Annual Conference on Uncertainty in Artificial Intelligence (UAI)*，第 647–655 页，2009 年。

张凯、J. 彼得斯、D. 扬青和B. 舍尔科夫普夫。基于核的条件独立性检验及其在因果发现中的应用。载于{共} {第}，页码804-813，2011年。

张科、B. Schölkopf、K. Muandet 和 Z. Wang。目标偏移和条件偏移下的域适应。见 *Proceedings of the 30th International Conference on Machine Learning (ICML)*，第 819–827 页，2013 年。

K. Zhang, M. Gong, 和 B. Schölkopf. 多源领域适应：因果视角。在 *Proceedings of the 29th AAAI Conference on Artificial Intelligence*中，第3150–3157页，2015年。

J. Zscheischler、D. Janzing 和 K. Zhang。测试线性方程是否具有因果性：一种自由概率论方法。载于 *Proceedings of the 27th Annual Conference on Uncertainty in Artificial Intelligence (UAI)*，第 839–846 页，2011 年。

W. Zurek. 算法随机性与物理熵. *Physical Review A*, 40 (8):4731–4751, 1989.

索引

ACE，*see* 平均因果效应加性噪声模型，48, 50, 52, 69, 137, 138, 140, 151, 190, 208 调整，109 ANM，*see* 加性噪声模型时间之箭，29, 50 自回归模型，50, 199, 208 平均因果效应，112, 116, 175,

后门准则，115 贝叶斯狄利克雷等价评分，150 贝叶斯狄利克雷评分，149 贝叶斯信息准则，139, 149, 150, 178 贝叶斯方法，149 BD评分，*see* 贝叶斯狄利克雷评分 BDe评分，*see* 贝叶斯狄利克雷等价评分 BIC，*see* 贝叶斯信息准则

CAM，*see* 因果加性模型 因果加性模型，140 因果发现，*see* 因果学习 因果效应，*see* 总因果效应 因果学习, 135 因果马尔可夫条件, 105, 106 因果最小性, 107, 108, 109 因果充分性, *see* 充分性 瓶颈点, 189 碰撞器, *see* 图 共同原因, 11, 95, 104, 129, 172, 173, 175, 187, 206 条件独立性, 214 混杂因素, *see* 共同原因 反事实, 36, 96, 106 有向无环图, *see* 图 DCM, *see* 动态因果建模 后代, *see* 图 有向无环图, *see* 图 分布等价性, 150 动态因果建模, 210 动态规划, 151 熵 香农熵, 59, 67, 68, 127, 187 传递熵, 205, 206 等误差方差, 139 忠实性, 107, 136 FCI 算法, 184 fMRI, *see* 功能磁共振成像

功能性磁共振成像，211

GES，*see* 贪婪等价搜索 GIES，*see* 贪婪干预等价搜索 Granger因果关系，201, 202, 203, 204–206, 208, 211 图碰撞，82 d-分离，83 后代，82 有向无环图（DAG），82 诱导路径图（IPG），182 最大祖先图（MAG），180 父节点，82 部分祖先图（PAG），180 部分有向无环图（PDAG），82 部分定向诱导路径图（POIPG），182 路径，82 v-结构，82, 102, 145 Y-结构，177, 182, 184 贪婪等价搜索，150 贪婪干预等价搜索，153 IC算法，143, 144 ICA，*see* 独立成分分析 ILP，*see* 整数线性规划 独立因果机制，16, 47, 54, 57, 72, 77

通用视点假设，15 噪声，18 对象，127 随机变量，213 运动恢复结构，16 独立成分分析，139, 152，190 诱导路径图，*see* 图瞬时效应，198 工具变量，175，186 整数线性规划，151 干预充分性，*see* 充分性干预，34，88 不变性西蒙准则，24 不变因果预测，154 条件，113 机制，20 逆概率加权，159，160 IPG，*see* 图柯尔莫哥洛夫复杂度，47，59，60，128

潜在投影，179，182 线性非高斯无环模型，48–50，139，140，208 LiNGAM，*see* 线性非高斯无环模型

MAG，*see*图边缘化，174，179 马尔可夫条件，109 马尔可夫等价，102

马尔可夫性, 100, 101, 104, 105, 108 最大祖先图, *see* 图机制, 9, 17 独立, 19, 20 不变, 18, 20 噪声独立, 8 非后代, *see* 图非确定性多项式时间, 145, 150, 151 NP, *see* 非确定性多项式时间 PAG, *see* 图父节点, *see* 图部分祖先图, *see* 图部分有向无环图, *see* 图部分定向诱导路径图, *see* 图路径, *see* 图路径模型, 22 PC算法, 143, 145, 179, 184 PDAG, *see* 图POIPG, *see* 图潜在结果, 122 倾向评分匹配, 117 随机变量, 213 回归, 215 半同胞, 157 回归与后续独立性检验, 152 RESIT, *see* 回归与后续独立性检验 SCM, *see*结构因果模型 选择偏差, 104 SEM, *see*结构方程模型 半监督学习, 71 SGS算法, 143, 144 SIC, *see*谱独立性准则 辛普森悖论, 172, 174, 196 谱独立性准则, 208, 209 结构因果模型, 9, 22, 33, 83 结构方程模型, *see*结构因果模型 结构学习, *see*因果学习 充分性因果充分性, 171, 173 干预充分性, 171, 172, 173 四元约束, 189 时间序列 全时间图, 198 汇总图, 199, 200 总因果效应, 91 传递熵, *see*熵 v结构, *see*图 变量 内生, 23 外生, 23 视觉感知, 15, 30 Y结构, *see*图

自适应计算与机器学习

Francis Bach，编辑

克里斯托弗·毕晓普、大卫·赫克曼、迈克尔·乔丹和迈克尔·卡恩斯，副主编

Bioinformatics: The Machine Learning Approach，Pierre Baldi 和 Søren Brunak
Reinforcement Learning: An Introduction，Richard S. Sutton 和 Andrew G. Barto
Graphical Models for Machine Learning and Digital Communication，Brendan J. Frey
Learning in Graphical Models，Michael I. Jordan *Causation, Prediction, and Search*，第二版，Peter Spirtes、Clark Glymour 和 Richard Scheines *Principles of Data Mining*，David Hand、Heikki Mannila 和 Padhraic Smyth
Bioinformatics: The Machine Learning Approach，第二版，Pierre Baldi 和 Søren Brunak *Learning Kernel Classifiers: Theory and Algorithms*，Ralf Herbrich
Learning with Kernels: Support Vector Machines, Regularization, Optimization, and Beyond，Bernhard Schölkopf 和 Alexander J. Smola

Introduction to Machine Learning, Ethem Alpaydin
Gaussian Processes for Machine Learning，Carl Edward Rasmussen 和 Christopher K.I. Williams *Semi-Supervised Learning, Olivier Chapelle*，Bernhard Schölkopf 和 Alexander Zien 编 *The Minimum Description Length Principle*，Peter D. Grünwald
Introduction to Statistical Relational Learning，Lise Getoor 和 Ben Taskar 编
Probabilistic Graphical Models: Principles and Techniques，Daphne Koller 和 Nir Friedman *Introduction to Machine Learning*，第二版，Ethem Alpaydin
Machine Learning in Non-Stationary Environments: Introduction to Covariate Shift Adaptation，Masashi Sugiyama 和 Motoaki Kawanabe
Boosting: Foundations and Algorithms，Robert E. Schapire 和 Yoav Freund
Machine Learning: A Probabilistic Perspective，Kevin P. Murphy
Foundations of Machine Learning，Mehryar Mohri、Afshin Rostami 和 Ameet Talwalker *Introduction to Machine Learning*，第三版，Ethem Alpaydin *Deep Learning*，Ian Goodfellow、Yoshua Bengio 和 Aaron Courville
Elements of Causal Inference: Foundations and Learning Algorithms，Jonas Peters、Dominik Janzing 和 Bernhard Schölkopf