Computational Biology: Genomes, Networks, Evolution
MIT course 6.047/6.878

Taught by Prof. Manolis Kellis

January 6, 2016

CONTENTS

1 Introduction to the Course **3**
1.1 引言与目标 3
1.1.1 计算生物学课程 . . . . . 3 1.1.2 目标的二元性：基础与前沿 . . . . . 3 1.1.3 学科的二元性：计算与生物学 . . . . . 4 1.1.4 为什么选择计算生物学? . . . . . 4 1.1.5 寻找功能元素：一个计算生物学问题 6
1.2 期末项目 - 计算生物学研究导论 7
1.2.1 最终项目目标 . . . . . 7 1.2.2 最终项目里程碑 . . . . . 7 1.2.3 项目交付成果 . . . . . 8 1.2.4 项目评分 8
1.3 附加材料 9
1.3.1 2015年秋季在线材料 . . . . . 9 1.3.2 教材 9
1.4 分子生物学速成课程 . . . . . 9 1.4.1 分子生物学的中心法则 . . . . . 9 1.4.2 DNA . . . . . 10 1.4.3 转录 . . . . . 11 1.4.4 RNA . . . . . 12 1.4.5 翻译 . . . . . 13 1.4.6 蛋白质 . . . . . 14 1.4.7 调控：从分子到生命 . . . . . 15 1.4.8 代谢 . . . . . 16 1.4.9 系统生物学 . . . . . 16 1.4.10 合成生物学 . . . . . 17 1.4.11 模式生物与人类生物学 . . . . . 17 1.5 算法与概率推断简介 . . . . . 18 1.5.1 概率分布 . . . . . 19 1.5.2 图概率模型 . . . . . 19 1.5.3 贝叶斯法则：先验、似然、后验 . . . . . 19 1.5.4 马尔可夫链与序列模型 . . . . . 19 1.5.5 概率推断与学习 . . . . . 19 1.5.6 最大似然与最大后验估计 19

I Comparing Genomes **21**

2 Sequence Alignment and Dynamic Programming **23**
2.1 引言 23

2.2 序列比对 . . . . . 24 2.2.1 示例比对 . . . . . 24 2.2.2 求解序列比对 . . . . . 24 2.3 问题形式化 26

2.3.1 形式1：最长公共子串 . . . . . 26 2.3.2 形式2：最长公共子序列（LCS） . . . . . 27 2.3.3 形式3：作为编辑距离的序列比对 . . . . . 28 2.3.4 形式4：变化的间隙成本模型 28

2.3.5 枚举 29
2.4 动态规划 29
2.4.1 动态规划理论 . . . . . 29 2.4.2 斐波那契数 . . . . . 30 2.4.3 使用动态规划进行序列比对 . . . . . 32 2.5 Needleman-Wunsch 算法 32

2.5.1 动态规划与记忆化 . . . . . 32 2.5.2 问题陈述 . . . . . 33 2.5.3 子问题的索引空间 . . . . . 33 2.5.4 局部最优性 . . . . . 33 2.5.5 最优解 . . . . . 34 2.5.6 解分析 . . . . . 34 2.5.7 实践中的Needleman-Wunsch算法 . . . . . 34 2.5.8 优化 35

2.6 多序列比对 37
2.6.1 三条序列的比对 . . . . . 37 2.6.2 启发式多序列比对 38
2.7 当前研究方向 . . . . . 39 2.8 进一步阅读 . . . . . 39 2.9 工具与技术 . . . . . 39 2.10 我们学到了什么？ . . . . . 39 2.11 附录 . . . . . 39 2.11.1 同源性 . . . . . 39 2.11.2 自然选择 . . . . . 39 2.11.3 动态规划与贪心算法 . . . . . 40 2.11.4 Needleman-Wunsch 算法的伪代码 41

3 Rapid Sequence Alignment and Database Search 43
3.1 引言 43
3.2 全局比对 vs. 局部比对 vs. 半全局比对 . . . . . 45 3.2.1 使用动态规划进行局部比对 . . . . . 47 3.2.2 算法变体 . . . . . 47 3.2.3 广义间隙惩罚 . . . . . 49 3.3 线性时间精确字符串匹配 . . . . . 49 3.3.1 Karp-Rabin 算法 . . . . . 49 3.4 BLAST 算法（基本局部比对搜索工具） . . . . . 52 3.4.1 BLAST 算法 . . . . . 52 3.4.2 BLAST 的扩展 . . . . . 54 3.5 线性时间字符串匹配的预处理 . . . . . 54 3.5.1 后缀树 . . . . . 54 3.5.2 后缀数组 . . . . . 55 3.5.3 Burrows-Wheeler 变换 . . . . . 55 3.5.4 基础预处理 . . . . . 55 3.5.5 有知识的字符串匹配 . . . . . 55 3.6 序列比对的概率基础 . . . . . 56 3.7 当前研究方向 58

3.8 进一步阅读 . . . . . 58 3.9 工具与技术 59
3.10 我们学到了什么？ 59

4 Comparative Genomics I: Genome Annotation **61**
4.1 引言 . . . . . 62 4.1.1 动机与挑战 . . . . . 62 4.1.2 许多紧密相关基因组的重要性 . . . . . 63 4.1.3 比较基因组学与进化特征 . . . . . 64 4.2 基因组序列的保守性 . . . . . 65 4.2.1 *Drosophila*中的功能元件 . . . . . 65 4.2.2 选择的速率与模式 65

4.3 过度约束 66
4.3.1 过度约束的原因 . . . . . 67 4.3.2 过度约束建模 . . . . . 68 4.3.3 人类基因组中的过度约束 . . . . . 69 4.3.4 过度约束的示例 . . . . . 71 4.3.5 在单个核苷酸水平测量约束 . . . . . 72 4.4 进化特征的多样性：选择模式概述 . . . . . 72 4.4.1 不同功能元件上的选择压力 . . . . . 73 4.5 蛋白质编码特征 . . . . . 75 4.5.1 阅读框保守性 (RFC) . . . . . 76 4.5.2 密码子替换频率 (CSFs) . . . . . 77 4.5.3 *Drosophila* 基因组序列的分类 . . . . . 80 4.5.4 泄漏终止密码子 . . . . . 81 4.6 microRNA (miRNA) 基因特征 . . . . . 84 4.6.1 计算挑战 . . . . . 84 4.6.2 不寻常的 miRNA 基因 . . . . . 85 4.6.3 示例：重新审视“可疑”蛋白质编码基因 . . . . . 87 4.7 调控基序 . . . . . 87 4.7.1 计算检测调控基序 . . . . . 87 4.7.2 调控基序的个体实例 . . . . . 88 4.8 当前研究方向 . . . . . 88 4.9 进一步阅读 . . . . . 88 4.10 工具与技术 . . . . . 88 4.11 参考文献 88

5 Genome Assembly and Whole-Genome Alignment **89**
5.1 引言 91
5.2 基因组组装 I：重叠-布局-一致性方法 . . . . . 91 5.2.1 设置实验 . . . . . 91 5.2.2 寻找重叠读取 . . . . . 93 5.2.3 将读取合并为重叠群 . . . . . 94 5.2.4 将重叠群图布局为支架 . . . . . 95 5.2.5 推导一致性序列 . . . . . 96 5.3 基因组组装 II：字符串图方法 . . . . . 97 5.3.1 字符串图定义与构建 . . . . . 97 5.3.2 流与图一致性 . . . . . 99 5.3.3 可行流 . . . . . 99 5.3.4 处理测序错误 . . . . . 100 5.3.5 资源 . . . . . 100 5.4 全基因组比对 . . . . . 100 5.4.1 全局、局部和‘全局-局部’比对 . . . . . 100 5.4.2 Lagan：链接局部比对 101

5.5 基于基因的区域比对 . . . . . 102 5.6 基因组进化机制 . . . . . 105 5.6.1 染色体重排 . . . . . 106 5.7 全基因组复制 . . . . . 107 5.8 补充图表 107

6 Bacterial Genomics– Molecular Evolution at the Level of Ecosystems 111
6.1 引言 . . . . . 111 6.1.1 微生物组研究的演进 . . . . . 112 6.1.2 微生物组研究的数据生成 . . . . . 112 6.2 研究1：地球上生命的演化 . . . . . 112 6.3 研究2：与Athos Boudvaros合作的儿童IBD研究 . . . . . 113 6.4 研究3：人类肠道生态学（HuGE）项目 . . . . . 114 6.5 研究4：微生物组作为饮食与表型之间的连接 . . . . . 118 6.6 研究5：细菌群体间的水平基因转移（HGT）及其对抗生素耐药性的影响 . . . . . 119 6.7 研究6：鉴定脑膜炎中的毒力因子 . . . . . 119 6.8 问答 . . . . . 121 6.9 当前研究方向 . . . . . 122 6.10 进一步阅读 . . . . . 122 6.11 工具与技术 . . . . . 122 6.12 我们学到了什么？ 122

II Coding and Non-Coding Genes 125

7 Hidden Markov Models I 127
7.1 引言 . . . . . 127 7.
2 动机： . . . . . 128 7.2.1 我们有了一个新的DNA序列，接下来怎么办？ . . . . . 128 7.2.2 为什么要进行概率序列建模？ 129
7.3 马尔可夫链与隐马尔可夫模型：从示例到形式化 . . . . . 129 7.3.1 启发示例：天气预测 . . . . . 129 7.3.2 马尔可夫链与隐马尔可夫模型的形式化 . . . . . 129 7.4 将隐马尔可夫模型应用于现实世界：从赌场到生物学 . . . . . 131 7.4.1 不诚实的赌场 . . . . . 131 7.4.2 回到生物学 . . . . . 134 7.5 隐马尔可夫模型的算法设置 137
7.5.1 评分 . . . . . 137 7.5.2 解码 . . . . . 138 7.5.3 评估 140
7.6 一个有趣的问题：我们能否在模型中融入记忆？ . . . . . 142 7.7 进一步阅读 . . . . . 143 7.7.1 状态的长度分布与广义隐马尔可夫模型 . . . . . 143 7.7.2 条件随机场 . . . . . 143 7.8 当前研究方向 . . . . . 143 7.9 工具与技术 . . . . . 143 7.10 我们学到了什么？ 143

8 Hidden Markov Models II - Posterior Decoding and Learning 145
8.1 上节课回顾 . . . . . 145 8.1.1 隐马尔可夫模型简介 . . . . . 145 8.1.2 隐马尔可夫模型在基因组学中的应用 . . . . . 146 8.1.3 维特比解码 147

8.1.4 前向算法 . . . . . 147 8.1.5 本节内容 . . . . . 149 8.2 后验解码 . . . . . 150 8.2.1 动机 . . . . . 150 8.2.2 后向算法 . . . . . 150 8.2.3 全局概览 . . . . . 152 8.3 在 HMM 中编码记忆：CpG 岛的检测 . . . . . 153 8.4 学习 . . . . . 155 8.4.1 监督学习 . . . . . 156 8.4.2 无监督学习 . . . . . 156 8.5 使用 HMM 进行带仿射间隙罚分的序列比对 159

8.6 当前研究方向 . . . . . 160 8.7 进一步阅读 . . . . . 162 8.8 工具与技术 . . . . . 162 8.9 我们学到了什么? 162

9 Gene Identification: Gene Structure, Semi-Markov, CRFs 163

9.1 引言 . . . . . 163 9.2 章节内容概览 . . . . . 164 9.3 真核基因：简介 . . . . . 164 9.4 计算基因识别的假设 . . . . . 164 9.5 隐马尔可夫模型 . . . . . 165 9.6 条件随机场 . . . . . 166 9.7 其他方法 . . . . . 167 9.8 结论 . . . . . 168 9.8.1 HMM . . . . . 168 9.8.2 CRF . . . . . 168 9.9 当前研究方向 . . . . . 169 9.10 进一步阅读 . . . . . 169 9.11 工具与技术 . . . . . 169 9.12 我们学到了什么? 169

10 RNA Folding 171

10.1 动机与目的 172
10.2 RNA的化学 172
10.3 RNA的起源与功能 . . . . . 173 10.3.1 核糖开关 . . . . . 173 10.3.2 microRNA . . . . . 173 10.3.3 其他类型的RNA 174

10.4 RNA 结构 174
10.5 RNA折叠问题与方法 . . . . . 176 10.5.1 Nussinov算法 . . . . . 177 10.5.2 Zuker算法 178

10.6 RNA的进化 181
10.7 RNA 折叠问题的概率方法 . . . . . 181 10.7.1 SCFGs 的应用 182
10.8 高级话题 183
10.8.1 其他问题 . . . . . 183 10.8.2 相关性 . . . . . 185 10.8.3 当前研究 185

10.9 总结与要点 185
10.10 进一步阅读 186

11 RNA Modifications **189**
11.1 引言 . . . . . 189 11.2 转录后调控 . . . . . 190 11.2.1 蛋白质翻译基础 . . . . . 190 11.2.2 翻译的测量 . . . . . 191 11.2.3 密码子进化 . . . . . 193 11.2.4 翻译调控 . . . . . 195 11.3 当前研究方向 195

11.4 进一步阅读 . . . . . 195 11.5 工具与技术 . . . . . 195 11.6 我们学到了什么？ 195

12 Large Intergenic non-Coding RNAs **197**
12.1 引言 . . . . . 197 12.2 从植物到哺乳动物的非编码RNA . . . . . 198 12.2.1 长非编码RNA . . . . . 199 12.3 实践主题：RNAseq 199

12.3.1 工作原理 . . . . . 199 12.3.2 将RNA-Seq读段比对到基因组和转录组 . . . . . 200 12.3.3 计算基因和转录本的表达量 . . . . . 202 12.3.4 使用RNA-Seq进行差异分析 203

12.4 表观遗传调控中的长非编码RNA . . . . . 204 12.5 基因间非编码RNA：干细胞/癌细胞中缺失的linc？ . . . . . 206 12.5.1 一个例子：XIST . . . . . 206 12.6 技术：在湿实验室中，我们如何发现这些？ . . . . . 206 12.6.1 例子：p53 . . . . . 207 12.7 当前研究方向 . . . . . 208 12.8 进一步阅读 . . . . . 208 12.9 工具与技术 . . . . . 208 12.10我们学到了什么？ 208

13 Small RNA **209**
13.1 引言 209
13.1.1 ncRNA 分类 . . . . . 209 13.1.2 小 ncRNA . . . . . 211 13.1.3 长 ncRNA 211
13.2 RNA干扰 212
13.2.1 发现的历史 . . . . . 212 13.2.2 生物发生途径 . . . . . 212 13.2.3 功能和沉默机制 213

III Gene and Genome Regulation **217**

14 mRNA sequencing for Expression Analysis and Transcript discovery **219**
14.1 引言 . . . . . 219 14.2 表达微阵列 . . . . . 220 14.3 mRNA测序的生物学 . . . . . 220 14.4 读取映射 - 间隔种子对齐 . . . . . 220 14.5 重建 . . . . . 221 14.6 定量 224

15 Gene Regulation 1 –Gene Expression Clustering **225**
15.1 引言 . . . . . 226 15.1.1 聚类与分类 . . . . . 226 15.1.2 应用 226

15.2 基因表达测量方法 227
15.2.1 微阵列 . . . . . 227 15.2.2 RNA-seq . . . . . 228 15.2.3 基因表达矩阵 . . . . . 229 15.3 聚类算法 231

15.3.1 K-均值聚类 . . . . . 231 15.3.2 模糊 K-均值聚类 . . . . . 232 15.3.3 K-均值作为生成模型 . . . . . 233 15.3.4 期望最大化 . . . . . 234 15.3.5 K-均值算法的局限性 . . . . . 235 15.3.6 层次聚类 235
15.3.7 评估聚类性能 236

15.4 当前研究方向 . . . . . 237 15.5 进一步阅读 . . . . . 237 15.6 资源 . . . . . 237 15.7 我们学到了什么? 238

16 Gene Regulation 2 –Classification **239**
16.1 引言 239
16.2 分类 - 贝叶斯技术 . . . . . 240 16.2.1 单特征与贝叶斯规则 . . . . . 240 16.2.2 收集数据 . . . . . 242 16.2.3 估计先验 . . . . . 242 16.2.4 多特征与朴素贝叶斯 . . . . . 243 16.2.5 测试分类器 . . . . . 243 16.2.6 MAESTRO 线粒体蛋白质分类 244

16.3 分类支持向量机 . . . . . 245 16.3.1 核函数 . . . . . 245 16.4 使用SVM进行肿瘤分类 . . . . . 247 16.5 半监督学习 . . . . . 248 16.5.1 未解决的问题 . . . . . 248 16.6 当前研究方向 . . . . . 248 16.7 进一步阅读 . . . . . 248 16.8 资源 248

17 Regulatory Motifs, Gibbs Sampling, and EM **251**
17.1 调控基序与基因调控简介 . . . . . 252 17.1.1 调控密码：转录因子与基序 . . . . . 252 17.1.2 基序发现的挑战 . . . . . 253 17.1.3 基序概括了转录因子序列特异性 253
17.2 期望最大化 254
17.2.1 EM 背后的核心思想 . . . . . 254 17.2.2 E 步：从 PWM 估计 Z_{ij} . . . . . 255 17.2.3 M 步：从起始位置 Zij 寻找最大似然模体 256
17.3 吉布斯采样：从联合 (M,Zij) 分布中采样 . . . . . 257 17.3.1 基于 Z 向量采样模体位置 . . . . . 257 17.3.2 更可能找到全局最大值，易于实现 . . . . . 257 17.4 从头模体发现 . . . . . 258 17.4.1 使用全基因组保守性进行模体发现 . . . . . 258 17.4.2 使用功能数据集验证发现的模体 259

17.5 用于实例识别的进化特征 . . . . . 259 17.6 系统发育，分支长度得分 置信度得分 . . . . . 259 17.6.1 前景 vs. 背景。真实 vs. 对照模体 . . . . . 259 17.7 可能已弃用的内容如下： . . . . . 259 17.7.1 贪心 . . . . . 259 17.8 比较不同方法 . . . . . 260 17.9 OOPS、ZOOPS、TCM . . . . . 260 17.10 EM 方法的扩展 . . . . . 261 17.10.1 ZOOPS 模型 . . . . . 261 17.10.2 寻找多个模体 . . . . . 262 17.11 模体表示与信息含量 262

18 Regulatory Genomics **265**

18.1 引言 . . . . . 265 18.1.1 该领域的历史 . . . . . 266 18.1.2 开放问题 . . . . . 266 18.2 *De Novo* 模体发现 . . . . . 266 18.2.1 TF 模体发现 . . . . . 266 18.2.2 验证发现的模体 . . . . . 267 18.2.3 小结 267

18.3 预测常规目标 268
18.3.1 模体实例识别 . . . . . 268 18.3.2 验证目标 268
18.4 微小RNA基因及其靶标 269
18.4.1 MiRNA基因发现 . . . . . 269 18.4.2 验证发现的MiRNA . . . . . 269 18.4.3 MiRNA的5‘端识别 . . . . . 270 18.4.4 编码区中的功能基序 . . . . . 270 18.5 当前研究方向 . . . . . 270 18.6 进一步阅读 . . . . . 270 18.7 工具与技术 . . . . . 270 18.8 我们学到了什么？ . . . . . 270 **19 Epigenomics/Chromatin States 271**

19.1 引言 272
19.2 核小体中的表观遗传信息 . . . . . 273 19.2.1 表观遗传 274
19.3 表观基因组学检测 275
19.3.1 ChIP：一种确定蛋白质在DNA上结合位置或组蛋白修饰位置的方法 . . . . . 275 19.3.2 亚硫酸氢盐测序：一种确定DNA甲基化位置的方法 . . . . . 276 19.4 ChIP数据的主要数据处理 . . . . . 276 19.4.1 读取比对 . . . . . 276 19.4.2 质量控制指标 . . . . . 277 19.4.3 峰值检测与选择 . . . . . 279 19.5 使用染色质特征注释基因组 . . . . . 282 19.5.1 数据 . . . . . 283 19.5.2 用于染色质状态注释的隐马尔可夫模型 . . . . . 283 19.5.3 选择要建模的状态数量 . . . . . 284 19.5.4 结果 . . . . . 285 19.5.5 多种细胞类型 . . . . . 286 19.6 当前研究方向 . . . . . 287 19.7 进一步阅读 . . . . . 288 19.8 工具与技术 288

19.9 我们学到了什么? 288

20 Networks I: Inference, structure, spectral methods **297**
20.1 引言 . . . . . 297 20.1.1 生物网络介绍 . . . . . 298 20.1.2 生物网络间的相互作用 . . . . . 299 20.1.3 网络表示 . . . . . 299 20.2 网络中心性度量 301

20.2.1 度中心性 . . . . . 301 20.2.2 介数中心性 . . . . . 302 20.2.3 接近中心性 . . . . . 303 20.2.4 特征向量中心性 303

20.3 线性代数复习 303
20.3.1 特征向量 . . . . . 303 20.3.2 向量分解 . . . . . 304 20.3.3 对角分解 304
20.3.4 奇异值分解 . . . . . 305 20.4 稀疏主成分分析 307
20.4.1 主成分分析的局限性 . . . . . 307 20.4.2 稀疏PCA 308
20.5 网络社区与模块 311
20.5.1 以节点为中心的社区 . . . . . 312 20.5.2 以群体为中心的社区 . . . . . 313 20.5.3 以网络为中心的社区 313
20.6 网络扩散核 319
20.7 神经网络 321
20.7.1 前馈网络 . . . . . 321 20.7.2 反向传播 . . . . . 321 20.7.3 深度学习 322

20.8 待解决的问题与挑战 . . . . . 323 20.9 当前研究方向 . . . . . 324 20.10 进一步阅读 324
20.11 工具与技术 . . . . . 325 20.12 我们学到了什么? 325

21 Regulatory Networks: Inference, Analysis, Application **327**
21.1 引言 . . . . . 327 21.1.1 生物网络介绍 . . . . . 328 21.1.2 生物网络间的相互作用 . . . . . 329 21.1.3 研究调控网络 . . . . . 329 21.2 结构推断 330

21.2.1 结构干扰中的关键问题 . . . . . 330 21.2.2 网络的抽象数学表示 330
21.3 PGM学习任务概述 . . . . . 331 21.3.1 贝叶斯网络的参数学习 . . . . . 331 21.3.2 模块调控程序的学习 . . . . . 333 21.3.3 网络推断中的结论 . . . . . 333 21.4 网络的应用 333

21.4.1 功能模型概述 . . . . . 333 21.4.2 未注释节点的功能预测 334
21.5 网络的结构特性 . . . . . 336 21.5.1 度分布 . . . . . 336 21.5.2 网络模体 337

21.6 网络聚类 338

21.6.1 网络的代数视角 339
21.6.2 谱聚类算法 341

22 Chromatin Interactions **345**
22.1 引言 345
22.1.1 已知内容 . . . . . 346 22.1.2 未知内容 . . . . .

23.4.1 *In Silico* 检测分析 . . . . . 368 23.4.2 定量通量 *In Silico* 模型预测 . . . . . 369 23.4.3 准稳态建模 (QSSM) . . . . . 370 23.4.4 基于布尔逻辑的调控 . . . . . 371 23.4.5 基因表达与代谢的耦合 . . . . . 373 23.4.6 预测营养源 . . . . . 374 23.5 当前研究方向 . . . . . 377 23.6 延伸阅读 . . . . . 377 23.7 工具与技术 . . . . . 377 23.8 我们学到了什么? 377

24 The ENCODE project: Systematic experimentation and integrative genomics 379
24.1 引言 . . . . . 379 24.2 实验技术 . . . . . 380 24.3 计算技术 . . . . . 381 24.4 当前研究方向 . . . . . 383 24.5 进一步阅读 . . . . . 384 24.6 工具与技术 . . . . . 384 24.7 我们学到了什么? 384

25 Pharmacogenomics 387
25.1 引言 . . . . . 387 25.2 当前研究方向 . . . . . 387 25.3 进一步阅读 . . . . . 387 25.4 工具与技术 . . . . . 387 25.5 我们学到了什么? 387

26 Synthetic Biology 389
26.1 引言 . . . . . 389 26.2 当前研究方向 . . . . . 391 26.3 进一步阅读 392
26.4 工具与技术 . . . . . 392 26.5 我们学到了什么? 393

IV Phylogenomics and Population Genomics 395

27 Molecular Evolution and Phylogenetics 397
27.1 引言 398
27.2 系统发育基础 398
27.2.1 树 . . . . . 398 27.2.2 性状 . . . . . 399 27.2.3 树重建方法 400
27.3 基于距离的方法 402
27.3.1 从比对到距离 . . . . . 402 27.3.2 到树的距离 407
27.4 基于字符的方法 411
27.4.1 评分 . . . . . 412 27.4.2 搜索 417
27.5 探讨方法可能存在的理论与实践问题 419
27.6 迈向最终项目 . . . . . 419 27.6.1 项目想法 . . . . . 419 27.6.2 项目数据集 . . . . . 419 27.7 我们学到了什么? 420

28 Phylogenomics II **421**
28.1 引言 . . . . . 422 28.2 推断直系同源/旁系同源、基因复制与丢失 . . . . . 422 28.2.1 物种树 . . . . . 422 28.2.2 基因树 . . . . . 423 28.2.3 基因家族演化 . . . . . 423 28.2.4 调和 . . . . . 423 28.2.5 调和示例解读 . . . . . 427 28.3 重构 . . . . . 428 28.3.1 物种树重构 . . . . . 428 28.3.2 改进基因树重构与跨基因树学习 429

28.4 建模种群与等位基因频率 430
28.4.1 Wright-Fisher 模型 . . . . . 430 28.4.2 溯祖模型 . . . . . 432 28.4.3 多物种溯祖模型 . . . . . 434 28.5 SPIDIR . . . . . 434 28.5.1 背景 . . . . . 434 28.5.2 方法与模型 . . . . . 436 28.6 祖先重组图 . . . . . 437 28.6.1 序列马尔可夫溯祖 . . . . . 437 28.7 结论 . . . . . 437 28.8 当前研究方向 . . . . . 438 28.9 延伸阅读 . . . . . 438 28.10工具与技术 . . . . . 438 28.11我们学到了什么? 438

29 Population History **439**
29.1 引言 . . . . . 439 29.2 人类遗传变异的快速概览 . . . . . 440 29.3 非洲与欧洲的基因流动 . . . . . 441 29.4 印度次大陆的基因流动 . . . . . 442 29.4.1 几乎所有印度大陆群体都是混合的 . . . . . 442 29.4.2 印度的群体结构与欧洲不同 . . . . . 444 29.4.3 讨论 . . . . . 444 29.5 古人类群体间的基因流动 . . . . . 445 29.5.1 背景 . . . . . 445 29.5.2 人类与尼安德特人之间基因流动的证据 . . . . . 445 29.5.3 人类与丹尼索瓦人之间的基因流动 . . . . . 446 29.5.4 高覆盖度古基因组分析 . . . . . 447 29.5.5 讨论 . . . . . 447 29.6 欧洲血统与迁徙 . . . . . 448 29.6.1 追溯欧洲遗传学的起源 . . . . . 448 29.6.2 来自草原的迁徙 . . . . . 449 29.6.3 自然选择的筛查 . . . . . 449 29.7 工具与技术 . . . . . 449 29.7.1 研究群体关系的方法 . . . . . 449 29.7.2 从尼安德特人骨骼中提取DNA . . . . . 451 29.7.3 重新组装古DNA 452

29.8 研究方向 452
29.9 进一步阅读 453

30 Population Genetic Variation **455**
30.1 引言 456
30.2 群体选择基础 456
30.2.1 多态性 . . . . . 456 30.2.2 等位基因与基因型频率 . . . . . 457 30.2.3 多态性的祖先状态 . . . . . 460 30.2.4 测量衍生等位基因频率 461
30.3 遗传连锁 . . . . . 462 30.3.1 相关系数 r^2 . . . . . 463 30.4 自然选择 . . . . . 463 30.4.1 自然选择的基因组信号 . . . . . 464 30.5 人类进化 467
30.5.1 种群动力学研究史 . . . . . 467 30.5.2 理解疾病 . . . . . 470 30.5.3 理解近期的种群混合 471
30.6 当前研究 . . . . . 472 30.6.1 单倍型图谱计划 . . . . . 472 30.6.2 千人基因组计划 . . . . . 472 30.7 进一步阅读 472

v Medical Genomics **475**

31 Medical Genetics – The Past to the Present **477**
31.1 引言 477
31.2 研究疾病遗传基础的目标 . . . . . 478 31.2.1 个性化基因组医学 . . . . . 478 31.2.2 指导治疗开发 478
31.3 孟德尔性状 479
31.3.1 孟德尔 . . . . . 479 31.3.2 连锁分析 479
31.4 复杂性状 482
31.5 全基因组关联研究 482
31.5.1 使全基因组关联研究成为可能的事件 . . . . . 483 31.5.2 质量控制 . . . . . 484 31.5.3 关联性检验 484
31.5.4 解读：GWAS如何揭示疾病的生物学机制？ . . . . . 486 31.5.5 自下而上 . . . . . 486 31.5.6 自上而下 . . . . . 487 31.5.7 与连锁分析的比较 . . . . . 487 31.5.8 非编码变异的挑战 . . . . . 487 31.5.9 结论 488
31.6 当前研究方向 . . . . . 488 31.7 进一步阅读 . . . . . 489 31.8 工具和技术 . . . . . 489 31.9 我们学到了什么？ 489

32 Variation 2: : Quantitative trait mapping, eQTLs, molecular trait variation **493**
32.1 引言 . . . . . 493 32.2 eQTL 基础 . . . . . 494 32.2.1 顺式eQTL . . . . . 494 32.2.2 反式eQTL . . . . . 495 32.3 eQTL 研究的结构 . . . . . 495 32.3.1 表达数据的考量 496

32.3.2 基因组数据的考量 . . . . . 496 32.3.3 协变量调整 . . . . . 496 32.3.4 需要考虑的要点 . . . . . 497 32.4 当前研究方向 . . . . . 497 32.4.1 量化性状变异 . . . . . 497 32.4.2 新应用 . . . . . 498 32.5 我们学到了什么? . . . . . 498 32.6 进一步阅读 . . . . . 498 32.7 工具与资源 499

33 Missing Heretibility **505**
33.1 引言 . . . . . 505 33.2 当前研究方向 . . . . . 505 33.3 进一步阅读 . . . . . 505 33.4 工具与技术 . . . . . 505 33.5 我们学到了什么? 505

34 Personal Genomes, Synthetic Genomes, Computng in C vs. Si **507**
34.1 引言 . . . . . 507 34.2 基因组读取与写入 . . . . . 507 34.3 个人基因组 . . . . . 508 34.4 当前研究方向 . . . . . 509 34.5 进一步阅读 . . . . . 509 34.6 工具与技术 . . . . . 509 34.7 我们学到了什么? 509

35 Personal Genomics **511**
35.1 引言 . . . . . 511 35.2 流行病学: 概述 . . . . . 512 35.3 遗传流行病学 . . . . . 513 35.4 分子流行病学 . . . . . 514 35.4.1 meQTLs . . . . . 515 35.4.2 EWAS . . . . . 516 35.5 因果建模与检验 . . . . . 516 35.5.1 多基因风险预测 . . . . . 517 35.6 当前研究方向 . . . . . 518 35.7 进一步阅读 . . . . . 518 35.8 工具与技术 . . . . . 518 35.9 我们学到了什么? 518

36 Cancer Genomics **519**
36.1 引言 . . . . . 519 36.2 特征描述 . . . . . 519 36.3 解释 . . . . . 521 36.4 当前研究方向 . . . . . 521 36.5 进一步阅读 . . . . . 522 36.6 工具与技术 . . . . . 522 36.7 我们学到了什么? 522

37 Genome Editing **523**
37.1 引言 . . . . . 523 37.1.1 什么是 CRISPR/Cas? . . . . . 523 37.1.2 为什么CRISPR/Cas对我们重要? 523 37.1.3 Cas-9 524

37.2 当前研究方向 524

37.2.1 Cas-9的改进 . . . . . 524 37.2.2 当前利用CRISPR/Cas-9进行的研究 . . . . . 524 37.3 进一步阅读 . . . . . 525 37.4 工具与技术 . . . . . 525 37.5 我们学到了什么？ 525

Preface and Acknowledgements

这些笔记总结了麻省理工学院课程“计算生物学：基因组、网络、进化”所教授的内容，多年来也与哈佛、HST、HSPH和BU交叉列出。该课程在2007-2011年被列为MIT课程6.047/6.878（并在2005年秋季至2006年期间使用临时编号6.085/6.095/6.895，2005年春季使用6.096）。2007-2011年，该课程与MIT/哈佛健康科学与技术（HST）课程HST.507交叉列出，2008年和2009年与波士顿大学生物工程课程BE-562交叉列出，2009-2011年与哈佛公共卫生学院课程IMI231交叉列出。

该课程最初由麻省理工学院的Manolis Kellis教授开发，并得到了**Silvio Micali**的建议。它于2005年春季作为算法导论课程（6.046）的半课程延伸首次讲授，并在2005年秋季至2011年期间作为独立的满学分课程开设。该课程在2005年至2006年秋季由**Piotr Indyk**教授共同授课，他为哈希和降维技术材料做出了贡献。在2007年至2009年秋季，与**James Galagan**教授共同授课，他为表达聚类、监督学习和代谢建模的讲座做出了贡献，并继续在波士顿大学独立教授该课程。

本课程的材料极大地受益于麻省理工学院的**Bonnie Berger**所教授的课程，其课程“计算生物学导论（18.417）”于2001年秋季由当时还是学生的Manolis Kellis共同讲授，以及斯坦福大学的**Serafim Batzoglou**所教授的课程“计算基因组学（CS262）”，后者在清晰度和风格上给予了启发，并为早期关于比对和HMM的章节提供了图表和示意图。最后，本课程的材料还受益于过去几年中课程广泛使用的两本书，分别是**Durbin, Eddy, Drogh, and Mitchison**所著的《生物序列分析》和**Jones and Pevzner**所著的《生物信息学算法》。

若干章节的材料最初由领域内专家客座讲师开发，他们以一次或多次讲座的形式贡献了新材料、图表、幻灯片、组织结构和思想。没有他们，相应的章节就不可能完成。他们是：**Pardis Sabeti** (群体遗传变异)，**Mark Daly** (医学遗传学)，**David Reich** (群体历史)，**Eric Alm** (细菌基因组学)，**John Rinn** (长非编码RNA)，**James Galagan** (稳态建模)，**Matt Rasmussen** (系统发育基因组学)，**Mike Lin** (基因发现)，**Stefan Washietl** (RNA折叠)，**Jason Ernst** (表观基因组学)，**Sushmita Roy** (调控网络)，**Pouya Kheradpour** (调控基因组学)。

讲授复习课并帮助开发课程习题集的助教分别有 **Reina Reimann** (2005年春季)、**Pouya Kheradpour** (2005年秋季)、**Matt Rasmussen** 和 **Mike Lin** (2006年秋季)、**Mike Lin** 和 **David Sontag** (2007年秋季)、**Matt Rasmussen** 和 **Pouya Kheradpour** (2008年秋季)、**Ed Reznik** 和 **Bob Altshuler** (2009年秋季)、**Matt Edwards** (2010年秋季)，以及 **Melissa Gymrek** (2011年秋季)。这些笔记最初是在 **Anna Shcherbina** (2011年秋季) 以统一格式汇编的。

MIT CompBio Lab (`http://compbio.mit.edu/people.html`) 的现任和前任成员，他们在成长为各自领域的专家的过程中教导了我。他们是：Matt Rasmussen、Mike Lin、Pouya Kheradpour、Alexander Stark、Xiaohui Xie、Jason Ernst、Sushmita Roy、Luke Ward、Chris Bristow、Abdoulaye Diallo、David Hendrix、Loyal Goff、Stefan Washietl、Daniel Marbach、Mukul Bansal、Matthew Eaton、Irwin Jungreis、Rachel Sealfon、Bob Altshuler、Jessica Wu、Angela Yen、Soheil Feizi、Luis Barrera、Ben Holmes、Anna Ayuso、Wouter Meuleman、Ferhat Ay、Rogerio Candeias、Patrick Meyer、Tom Morgan、Wes Brown、Will Gibson、Rushil Goel、Luisa Di Stefano、Stephan Ossowski、Aviva Presser、Erez Lieberman、Joshua Grochow、Yuliya Kodysh、Leopold Parts、Ameya Deoras、Matt Edwards、Adrian Dalca。

学生 参加课程并为笔记做出贡献的学生 是：

- 2005年春季：Dan Arlow, Arhab Battacharyya, Punyashloka Biswal, Adam Bouhenguel, Dexter Chan, Shuvo Chatterjee, Tiffany Dohzen, Lyric Doshy, Robert Figueiredo, Edena Gallagher, Josh Grochow, Aleksas Hauser, Blanca Himes, George Huo, Xiaoming Jia, Scott Johnson, Steven Kannan, Faye Kasemset, Jason Kelly, Daniel Kim, Yuliya Kodysh, Nate Kushman, Lucy Mendel, Jose Pacheco, Sejal Patel, Haiharan Rahul, Gireeja Ranade, Sophie Rapoport, Aditya Rastogi, Shubhangi Saraf, Oded Shaham, Walter Stiehl, Kevin Stolt, James Sun, Xin Sun, Kah Tai, Kah Tay, Chester Tse, Verlik Tzanov, Brian Wu

- 2005年秋季：Ebad Ahmed、Christophe Falling、Michael Farry、Elaine Gee、Luke Hutchison、Michael Lin、Grigore Pintilie、Asfandyar Qureshi、Matthew Rasmussen、Alexandru Salcianu、Zeeshan Syed、Hayden

泰勒、维林·察诺夫、格兰特·王

- 2006年秋季：Mats Ahlgren、Zhu Ailing、Bob Altshuler、Nada Amin、Shay Artzi、Solomon Bisker、Allen Bryan、Sumeet Gupta、Adam Kiezun、Richard Koche、Mieszko Lis、Ryan Newton、Michael O'Kelly、Chris Reeder、Jonathan Rhodes、Michael Schnall-Levin、Alex Tsankov、Tarak Upadhyaya、Kush Varsh- ney、Sam Volchenboum、Jon Wetzel、Amy Williams

- 2007年秋季：Anton Aboukhalil、Matthew Belmonte、Ellenor Brown、Brad Cater、Alal Eran、Guilherme Fujiwara、Saba Gul、Kate Hoff、Shannon Iyo、Eric Jonas、Peter Kruskall、Michael Lee、Ben Levick、Fulu Li、Alvin Liang、Joshua Lim、Chit-Kwan Lin、Po-Ru Loh、Kevin Modzelewski、Georgis Papachristoudis、Michalis Potamias、Emmanuel Santos、Alex Schwendner、Maryam Shanechi、Timo Somervuo、James Sun、Xin Sun、Robert Toscano、Qingqing Wang、Ning Xie、Qu Zhang、Blaine Ziegler

- 2008年秋季：Burak Alver、Tural Badirkhanli、Arnab Bhattacharyya、Can Cenik、Clara Chan、Lydia Chilton、Arkajit Dey、Ardavan Farjadpour、Jeremy Fineman、Bernhard Haeupler、Arman Hajati、Ethan Heilman、Joe Herman、Irwin Jungreis、Arjun Manrai、Nilah Monnier、Christopher Rohde、Rachel Sealfon、Daniel Southern、Paul Steiner、David Stiebel、Mengdi Wang

- 2009年秋季：Layla Barkal、Michael Bennie、David Charlton、Guoliang Chew、John Dong、Matthew Edwards、Eric Eisner、Subha Gollakota、Nathan Haseley、Allen Lin、Christopher McFarland、Michael Melgar、Anrae Motes、Anand Oza、Elizabeth Perley、Brianna Petrone、Arya Tafvizi Zavareh、Yi-Chieh Wu、Angela Yen、Morteza Zadimoghaddam、Chelsea Zhang、James Zou

- 2010年秋季：Minjeong Ahn, Andreea Bodnari, Wesley Brown, Jenny Cheng, Bianca Dumitrascu, Sam Esfahani, Amer Fejzic, Talitha Forcier, Maria Frendberg, Dhruv Garg, Rushil Goel, Melissa Gymrek, Benjamin Holmes, Wui Ip, Isaac Joseph, Geza Kovacs, Gleb Kuznetsov, Adam Marblestone, Alexander Mccauley, Sheida Nabavi, Jacob Shapiro, Andrew Shum, Ashutosh Singhal, Mark Smith, Mashaal Sohail, Eli Stickgold, Tahin Syed, Lance Wall, Albert Wang, Fulton Wang, Jerry Wang

- 2011年秋季：Asa Adadey, Leah Alpert, Ahmed Bakkar, Rebecca Bianco, Brett Boval, Kelly Brock, Pe-ter Carr, Efrain Cermeno, Alex Chernyakhovsky, Diana Chien, Akashnil Dutta, Temuge Enkhbaatar, Maha Farhat, Alec Garza-Galindo, Fred Grober, Gabriel Ha, Marc Hafner, Neel Hajare, Timothy Helbig, Ivan Imaz, Yarden Katz, Gwang Ko, David Ku, Yu-Chi Kuo, Dan Landay, Yinqing Li, Mark Mimee, Selene Mota, Hyun Ji Noh, Chrisantha Perera, Aleksey Pesterev, Michael Quintin, Maria Rodriguez, Megan Roytman, Abhishek Sarkar, Angela Schwarz, Meriem Sefta, Anna Shcherbina, Mindy Shi, Noam Shoresh, Eric Soderstrom, Ying Qi Soh, Sarah Spencer, Derrick Sund, Ruqi Tang, Zenna Tavares, Arvind Thiagarajan, Paul Tillberg, Christos Tzamos, Leonardo Urbina, Manasi Vartak, Nathan Villagaray-Carski, Sajith Wickramasekara, Thomas Willems, Maxim Wolf, Lok Sang Wong, Iris Xu, Johannes Yeh, Deniz Yorukoglu, Boyang Zhao。

- 2013年秋季：Maria Alexis、Polina Binder、Jake Bograd-Denton、Orhan Tunc Celiker、Hyunghoon Cho、Brian Cleary、David Danko、Vivek Dasari、Dalesh Dharamshi、Atray Dixit、Joseph Driscoll、John Froberg、Themistoklis Gouleakis、Carissa Jansen、Yuta Kato、Hanna Levitin、Brendan Liu、Quan-quan Liu、Yang Li、Julianna Mello、Hayden Metsky、Peter Nguyen、Luke O'Connor、Alexander Pagan、Sebastian Palacios、Peter Palmedo, Jr.、Staphany Park、Nicole Power、Emma Seropian、Meena Subramaniam、Nirvan Tyagi、Joseph Vitti、Timothy Wall、Deena Wang、James Weis、Iris Xu、Haoyang Zeng、Sidi Zhang

- 2014年秋季：Abdulaziz Alghunaim、Sahar Alkhairy、Benjamin Bauchwitz、Tristan Bepler、Silvia Canas Duarte、Kevin Chen、Michael Coulombe、Lei (Jerry) Ding、Gabriel Filsinger、Matthew Fox、Kristjan Kaseniit、Joseph Kim、David Lazar、William Leiserson、Jenny Lin、Kathy Lin、Yunpeng Liu、Nicolai Ludvigsen、Eric Mazumdar、Hilary Mulholland、Pavel Muravyev、Muneeza Patel、Divya Pillai、Clément Pit-Claudel、Adam Sealfon、Ha Kyung (Kris) Shin、Aradhana Sinha、Daniel Sosa、Yi-Shiuan Tung、Margaret Walker、Sarah Walker、Yuhao Wang、Hui Ting Grace Yeo、Catherine Yun

- 2015年秋季：Jonathan Li、Jesse Tordoff、Thrasyvoulos Karydis、Heather Sweeney、Eric Bartell、Anastasiya Belyaeva、Justin Gullingsrud、Cara Weisman、Robert Hunt、Alex Genshaft、Ge Liu、Richard

Hsu, Karthik Murugadoss, Sagar Indurkhya, Max Shen, Kevin Tian, Alvin Shi, Connor Duffy, Narek Dshkhun yan, Joyce Hong, Gil Goldshlager, Sophia Liu, Aurora Alvarez-Buylla, Giri Anand, Tejas Sundaresan, Nolan Kamitaki, Bryce Hwang, Hunter Gatewood, Misha Jamy, Nadia Wallace, Carles Boix, Ava Soleimany, Brock Wooldridge, Sadik Yildiz, Anne Kim, Divya Shanmugam, Deniz Aksel, Molly Schmidt, Jonahtan Uesato, Jose ph Cunningham, Suganya Sridharma, Oleksandr Chaykovskyy, Eunice Wu, Sam Johnson, Ye Tao

CHAPTER

ONE

课程简介

Figures

1.1 在这个计算生物学问题中，我们获得了一个碱基序列，并希望定位基因和调控基序。 . . . . . 6 1.2 DNA的双螺旋结构。核苷酸位于中心，糖-磷酸骨架位于外侧。 . . . . . 11 1.3 DNA经过多层组织层次打包成紧凑的染色体。 . . . . . 12 1.4 RNA在转录过程中从DNA模板产生。DNA中打开一个“泡”，使RNA聚合酶能够进入并放置与DNA互补的碱基。 . . . . . 13 (a) 转录起始 . . . . . 13 (b) 转录延伸 . . . . . 13 (c) 转录终止 . . . . . 13 1.5 该密码子表显示了mRNA中每个3核苷酸密码子被翻译成20种氨基酸中的哪一种。红色的是终止密码子，它们终止翻译。 . . . 14 1.6 乳糖操纵子展示了一个简单的生物调控系统。在葡萄糖存在时，乳糖代谢基因被关闭，因为葡萄糖使激活蛋白失活。在乳糖不存在时，阻遏蛋白也会关闭该操纵子。乳糖代谢基因仅在乳糖存在且葡萄糖不存在时表达。 . . . . . 15 1.7 代谢途径和调控可以通过计算生物学来研究。模型由基因组规模信息构建，并用于预测代谢功能和代谢工程。生物工程的一个例子是修改细菌基因组以过量生产青蒿素，一种用于治疗疟疾的抗生素。 16

1.1 Introduction and Goals

1.1.1 A course on computational biology

这些讲义旨在作为计算生物学的一学期课程进行教授，每1.5小时的讲座涵盖一章，并辅以双周作业和辅导课程，以帮助学生完成他们自己的独立研究项目。这些讲义源自麻省理工学院课程6.047/6.878，并非常贴近相应讲座的结构。

1.1.2 Duality of Goals: Foundations and Frontiers

本课程有两个目标。第一个目标是向您介绍计算生物学领域的**foundations**。也就是说，介绍该领域的基本生物学问题，并学习解决这些问题所需的算法和机器学习技术。这不仅仅是学习如何

使用当年流行的程序和在线工具。相反，目标是让你理解当前最成功技术的基本原理，并赋予你设计和实现下一代工具的能力。这就是为什么算法入门课程被设为先修课的原因；深入理解所介绍的算法的最佳方式就是自己动手实现它们。

本课程的第二个目标是攻克计算生物学的研究**frontiers**，这正是所有高级主题和实践作业的真正意义所在。我们实际上希望让您一窥研究是如何运作的，让您接触当前的研究方向，引导您找到最感兴趣的问题，并帮助您成为该领域的积极实践者。这通过客座讲座、问题集、实验室，以及最重要的为期一学期的独立研究**project**来实现，在那里您进行自己的独立研究。

该课程的**modules**遵循这一模式，每个版本都包含涵盖各主题基础与前沿的讲座。基础讲座介绍该领域的经典问题。这些问题已被深入理解，且已找到优雅的解决方案；有些甚至已被教授超过十年。模块的前沿部分涵盖高级主题，通常通过探讨该领域仍未解决的核心问题来进行。这些章节经常包括各领域一些先驱的客座讲座，他们既讲述该领域的总体状况，也介绍自己实验室的研究。

课程的 **assignments** 遵循相同的基础/前沿模式。一半的作业将是在纸上用铅笔推导方法，并深入探讨问题的算法和机器学习概念。另一半实际上是实践问题，包括编程作业，其中提供真实数据集。你将使用所学技术分析这些数据并解释你的结果，从而获得真实的动手经验。这些作业逐步构建到最终项目，在该项目中你将提出并开展一项原创研究项目，并以会议格式展示你的发现。总的来说，这些作业旨在为你提供将计算生物学方法应用于生物学真实问题的机会。

1.1.3 Duality of disciplines: Computation and Biology

除了旨在涵盖基础知识和前沿领域外，本课程的另一个重要的双重性是计算与生物学之间的结合。

从课程的**biological**角度来看，我们旨在教授对生物学、医学和人类健康理解至关重要的主题。因此，我们避免那些受生物学启发但在计算上有趣却与生物学无关的问题。我们不会仅仅因为在生物学中看到某些现象，受到启发后就转向计算机科学领域，做许多生物学永远不会关心的事情。相反，我们的目标是解决能够在生物学领域产生重大影响的问题。我们希望你们发表的论文对生物界真正重要，并具有实际的生物学影响力。这一目标因此指导了课程主题的选择，每一章都聚焦于一个基本的生物学问题。

从课程的**computational**视角来看，毕竟这是一门计算机科学课程，我们专注于探索那些在计算生物学中固然重要，但同样可应用于任何其他需要数据分析和解读领域的通用技术与原则。因此，如果你希望进入宇宙学、气象学、地质学或类似领域，本课程提供的计算技术在处理与这些领域相关的现实世界数据集时，很可能会变得非常有用。

1.1.4 Why Computational Biology?

`lecture1_transcript.html#Motivations`

近年来，计算生物学之所以成为一门重要学科，有许多原因，其中一些或许正是促使你拿起这本书或注册这门课程的因素。尽管我们对此有自己的看法，但我们年复一年地询问学生，他们对于是什么使得计算生物学领域在过去几年里迅速扩张有何见解。他们的回答可归纳为几个广泛的主题，我们在此进行总结。

1. 计算方法之所以非常适合生物数据研究，最根本的原因或许在于，生物系统本质上就是**fundamentally digital in nature**。直白地说，人类并不是最早构建数字计算机的——我们的祖先*are*了第一台数字计算机，因为最早的基于DNA的生命形式就已经在存储、复制和处理以A、C、G、T字母编码的数字信息。数字媒介存储遗传信息的主要进化优势在于，它能够跨越数千代而持续存在，而模拟信号则会因基本的化学扩散而在代代相传中被稀释。2. 除了DNA之外，生物学的许多其他方面也是数字化的，例如**biological switches**，它们通过反馈回路和亚稳态过程确保仅实现两种离散的可能状态，尽管这些是由分子水平实现的。广泛的反馈回路和其他多样的调控电路通过原本不稳定的组件实现离散决策，其设计原理同样类似于工程实践，这使我们从工程角度理解生物系统的探索更加可行。3. 严重受益于数据处理的科学，如计算生物学，遵循一个涉及可用于处理的数据的良性循环。通过对可用数据进行处理和分析所能做的事情越多，就会有越多的资金被投入到开发技术中，以获取、处理和分析更多的数据。诸如测序等新技术，以及微阵列、酵母双杂交和ChIP-chip测定等高通量实验技术，正在创造**enormous and increasing amounts of data**，这些数据可以使用计算技术进行分析和处理。1000美元基因组计划和100美元基因组计划就是这一循环的证据。十多年前，当这些项目启动时，想象处理如此海量的数据简直是荒谬的。然而，随着从这些数据的处理中设计出更多潜在优势，更多资金被投入到开发使这些项目可行的技术中。4. 近年来，处理数据的能力有了极大提升，这归功于：1）当今可用的巨大计算能力（除其他因素外，还得益于摩尔定律），以及2）手头算法技术的进步。5. 优化方法可以通过计算技术用于解决原本棘手的问题。6. 在处理海量数据集时，**Running time & memory**方面的考量至关重要。一个在小基因组（例如细菌）上运行良好的算法，可能因时间或空间效率太低而无法应用于1000个哺乳动物基因组。此外，组合问题会急剧增加算法复杂度。7. 生物数据集可能是**noisy**的，而从噪声中过滤信号是一个计算问题。8. **Machine learning**方法有助于进行推断、对生物特征进行分类以及识别稳健信号。9. 随着我们对生物系统理解的加深，我们开始意识到此类系统不能孤立地进行分析。这些系统已被证明以前所未有的方式相互交织，我们已开始将分析转向将其视为一个整体的技术。10. 可以使用计算方法以无偏的方式发现相关性，并得出改变生物学知识、促进主动学习的结论。这种方法被称为**data-driven discovery**。11. 计算研究可以为解释实验观察结果**predict**假设、机制和理论。这些可证伪的假设随后可以通过实验进行检验。12. 计算方法不仅可用于分析现有数据，还可用于**motivate datacollection**并建议有用的实验。此外，计算过滤可以缩小实验搜索空间，从而实现更聚焦、更高效的实验设计。

13. 生物学有**rules**：进化由两条简单规则驱动：1）随机突变，和2）残酷选择。生物系统受限于这些规则，在分析数据时，我们寻找并解释这些规则产生的新兴行为。

14. **Datasets can be combined** 使用计算方法，以便跨多个实验收集的信息以及采用多种实验方法的信息，能够应用于感兴趣的问题。

15. E 有效的生物数据 **visualizations** 可以促进 di 发现。

16. 计算方法可用于**simulate & model**生物数据。

17. 计算方法可能更加**ethical**。例如，某些生物实验对活体进行可能不道德，但可以通过计算机模拟。

18. 大规模、系统工程方法通过计算技术得以促进，以获取对生物体的全局视图，这些视图过于复杂，否则无法分析。

1.1.5 Finding Functional Elements: A Computational Biology Question

`lecture1_transcript.html#Codons`

多个计算生物学问题涉及在DNA数据中寻找生物信号（例如编码区、启动子、增强子、调控因子等）。

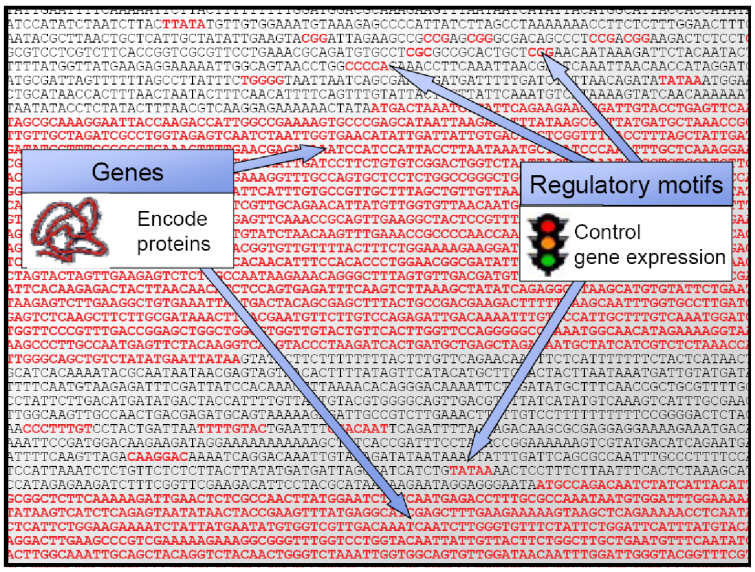

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图1.1：在这个计算生物学问题中，我们获得了一个碱基序列，并希望定位基因和调控基序。

随后，我们探讨了计算生物学能够解决的一个具体问题：如何在基因组序列中找到功能元素？图1.1展示了酵母基因组序列的一部分。针对这一序列，我们可以提出这样的问题：

Q: 哪些基因编码蛋白质?

A: 在翻译过程中，起始密码子标记蛋白质中的第一个氨基酸，而终止密码子则表示蛋白质的结束。然而，正如“从噪声中提取信号”幻灯片所示，DNA中这些ATG序列中只有少数实际上标记了将被表达为蛋白质的基因起始。其他的是“噪声”；例如，它们可能是内含子（转录后被剪接去除的非编码序列）的一部分。

Q: 我们如何在基因组序列中找到特征（基因、调控基序和其他功能元件）？

A: 这些问题可以通过实验或计算来解决。对这个问题的一种实验方法是创建一个敲除，并观察该生物体的适应度是否受到影响。我们也可以通过计算来解决这个问题，方法是观察该序列在多个物种的基因组中是否保守。如果该序列在进化时间中显著保守，它很可能执行重要功能。

这两种方法都存在一些注意事项。移除某个元素可能无法揭示其功能——即使与原版没有明显差异，这也可能仅仅是因为尚未测试到合适的条件。此外，仅仅因为某个元素不保守，并不意味着它没有功能。（同时，请注意“功能元素”是一个模糊的术语。当然，基因组中有许多类型的功能元素并不编码蛋白质。有趣的是，人类基因组的90-95%被转录（用作制造RNA的模板）。目前尚不清楚大多数这些转录区域的功能是什么，或者它们是否真的具有功能）。

1.2 Final Project - Introduction to Research In Computational Biology

`lecture1_transcript.html#FinalProject`

1.2.1 Final project goals

成为一名计算生物学家的重要组成部分是在该领域开展独立研究的能力。成功研究者的技能因人而异，但在教授这门课程的过程中，我们识别出了几个都需要的方面，并为一个学期长的项目安排了活动，使学生能够开展他们的独立研究。

该项目模拟了现实世界的科学过程：提出一个想法→构建它→提出它→修改它→实施它→展示你的成果。学生应对自己的项目进行批判性思考，同时评估同伴的研究提案，最后回应同伴的反馈。

学生应使用真实数据，并以会议形式展示他们的结果。最终目标是可发表的研究。鼓励学生在构思最终项目想法时与课程工作人员交流，提前浏览各章节和模块，并了解哪些领域最吸引你。

1.2.2 Final project milestones

与其等到学期末才开始头脑风暴或提供反馈，我们从第一组问题集开始就启动项目活动，以识别感兴趣的问题和项目类型，寻找合作伙伴，与计算生物学领域的在读学生和博士后交流，他们可以作为导师，并按照NIH提案的风格制定研究计划，以便及早发现潜在陷阱，并在它们成为瓶颈之前解决或绕过它们。

通过在整个学期中设置若干个渐进式进度里程碑，并结合整个学期的指导和反馈，我们在过去几年中实现了持续进步，这对处于职业生涯任何阶段、正在开展新项目的学生都可能有所帮助。以往本课程的研究项目曾被用作发表论文的起点，促成了硕士和博士论文，并在学术和会议上获得了奖项。

最终项目的时间安排如下：

1. **Set-up:** 简要概述您的经验和兴趣。截止日期 9/29 2. **Brainstorming:** 初步项目想法和合作伙伴列表。截止日期 10/6 3. **Proposal:** 以NIH提案形式提交项目提案。截止日期 10/20

4. **Proposal presentation:** 向班级和导师展示提案幻灯片。截止日期 10/23

5. **Review:** 审查并评论3份同行提案。截止日期10 /30

6. **Midterm Progress Report:** 撰写最终报告的大纲。截止日期 11/19

7. 以会议论文格式撰写**Final Project Report:**报告。截止日期12/6

8. **Final Class Presentation:** 10分钟会议演讲。截止日期12/10

在最终项目每个部分截止之前，都会有周五辅导课，我们鼓励你在前几次辅导课中寻找一位对你的项目积极感兴趣、并能更频繁帮助你的导师。辅导课有助于判断意外结果是源于错误还是一项发现。

确保你在等待同行评审的同时就开始着手项目，这样你将有4-5周的时间来完成研究本身。

1.2.3 Project deliverables

最终项目将包含以下两项交付物：

1. 书面报告，截止时间为上课最后一周的周一晚上8点。书面报告可以包含以下要素：

   - 谁做了什么（以反映出版趋势）
   - 整体项目经验
   - 你的发现
   - 从经验中学到的东西（内省）

2. 口头报告，在书面报告之后的周四进行。这为学生提供了三天时间来准备口头报告。

1.2.4 Project grading

选择一个能够成功的项目可能很困难。为了帮助学生优化以成功完成项目，我们提前告知他们评分方案，该方案旨在通过原创性、挑战性和与领域的相关性来最大化项目影响，但当然，成绩最终取决于整体成就和陈述的清晰度。

简而言之，最终项目的评分公式为：

$$\min(O, C, R) \times A + P$$

其中

Originality - 非原创的计算实验不会被发表

Challenge - 项目需要足够困难

Relevance - 它必须来源于生物学，不能简单地从另一个领域挪用

Achievement - 如果你什么都没完成，你就不会得到好成绩

Presentation - 即使你已经完成了一个优秀的项目，你也必须能够展示它，让所有人都知道，并让它看起来轻松。演示应该展示项目是如何O、C和R的。

原创性、挑战性、相关性各满分5分，成果与展示各满分10分。

1.3 Additional materials

1.3.1 Online Materials for Fall 2015

`lecture1_transcript.html#Handouts`
除了这些 {v*} 注释之外，本课程还有几个在线资源：

- Google 日历上的课程日历。您可以添加 “6.047 Lectures”，一个公开的日历 r.
- 用于标注这些笔记的NB笔记系统 `http://nb.mit.edu/`

1.3.2 Textbooks

`lecture1_transcript.html#CourseInformation` 建议本课程使用以下三本（可选）参考教材。

1. Richard Durbin, Sean R. Eddy, Anders Krogh and Graeme Mitchison, 生物序列分析：蛋白质与核酸的概率模型。

2. Neil Jones 和 Pavel Pevzner, 《生物信息学算法导论》。

3. Richard Duda, Peter Hart, David Stork, Pattern Classification.

每本书各有所长。第一本书是经典之作。它数学内容繁重，涵盖了课堂上的大部分内容。该书聚焦于序列比对。作为序列比对理论的一部分，该书探讨了隐马尔可夫模型（HMM）、成对和多序列比对方法、系统发育树以及概率论的简短背景。

第二本书旨在平衡数学严谨性和生物学相关性。据作者所述，这是一本适合本科生的好书。书中包含一个表格，将算法与生物学问题相关联。

第三本书是关于机器学习的。它更倾向于工程方法。它涵盖了机器学习理论、神经网络，以及顾名思义，模式识别。

1.4 Crash Course in Molecular Biology

对于以计算为主的学生，我们简要介绍了本学期将遇到的关键分子生物学概念。

1.4.1 The Central Dogma of Molecular Biology

`lecture1_transcript.html#CentralDogma` $DNA \rightarrow RNA \rightarrow Protein$
分子生物学的中心法则描述了细胞中遗传信息如何存储和解读：生物体的遗传密码储存在DNA中，DNA转录为RNA，RNA最终翻译为蛋白质。蛋白质执行大多数细胞功能，如运动、DNA调控和复制。

尽管中心法则在大多数情况下成立，但该模型也有许多显著的例外。例如，逆转录病毒能够通过逆转录从RNA生成DNA。此外，有些病毒非常原始，甚至没有DNA，只利用RNA来制造蛋白质。

Did You Know?
中心法则有时被**incorrectly**过于强烈地解读为：DNA只储存从一代到下一代的不变信息，且在某一代内保持相同，RNA仅用作临时信息传递媒介，而蛋白质是唯一能执行复杂行动的分子。

同样，这种解释也有很多例外，例如：

- 体细胞突变可以在一个世代内改变DNA，并且不同细胞可以具有不同的DNA含量。
- 一些细胞在成熟过程中会经历程序性DNA改变，导致DNA含量不同，其中最著名的是B细胞和T细胞免疫细胞
- DNA的表观遗传修饰可以一代传给一代
- RNA可以在基因调控、代谢感知和酶促反应中发挥多种多样的作用，这些功能此前被认为仅限于蛋白质。
- 蛋白质本身可以发生构象变化，这些变化可通过表观遗传方式遗传，尤其是著名的朊病毒状态，它曾是疯牛病的罪魁祸首。

1.4.2 DNA

DNA → RNA → Protein

DNA function

DNA分子存储着生物体的遗传信息。DNA包含称为基因的区域，这些区域编码将要产生的蛋白质。DNA的其他区域包含调控元件，这些元件部分地影响每个基因的表达水平。在DNA的遗传密码中，既蕴含着需要被编码的蛋白质的数据，也蕴含着以调控基序形式存在的控制电路。

DNA structure

DNA由四种**nucleotides**组成：A（**adenine**）、C（**cytosine**）、T（**thymine**）和G（**guanine**）。A和G是嘌呤，具有两个环，而C和T是嘧啶，具有一个环。A和T通过两个氢键连接，而C和G通过三个键连接。因此，A-T配对比C-G配对弱。（出于这个原因，生活在温泉中的细菌的遗传组成80%是G-C）。
`lecture1_transcript.html#Complementarity`

双螺旋结构中的两条DNA链是**complementary**，这意味着如果一条链上有一个A，它将与另一条链上的T结合；如果一条链上有一个C，它将与另一条链上的G结合。DNA链还具有**directionality**，指的是磷酸骨架连接的戊糖环位置。这种方向性约定源自DNA和RNA聚合酶按5'到3'方向合成的事实。考虑到这一点，我们可以说DNA链是**anti-parallel**，因为一条链的5'端与另一条链的3'端相邻。因此，DNA可以从3'到5'方向以及5'到3'方向读取，基因和其他功能元件可以在每个方向上找到。按照惯例，DNA是从5'到3'书写的。5'和3'方向指的是戊糖环上磷酸骨架连接的位置。

DNA核苷酸之间的碱基配对构成了其一级和二级结构。除DNA的二级结构外，还有几个额外的结构层次使DNA能够紧密压缩并影响基因表达（图3）。三级结构描述了DNA梯状结构中形成螺旋形状的扭曲。在四级结构中，DNA紧密缠绕在称为组蛋白的小蛋白质上。这些DNA-组蛋白复合物进一步缠绕成在染色质中看到的更紧密的结构。

在DNA复制或转录为RNA之前，染色质结构必须局部“解包”。因此，基因表达可能通过改变染色质结构的修饰来调控，这些修饰使其

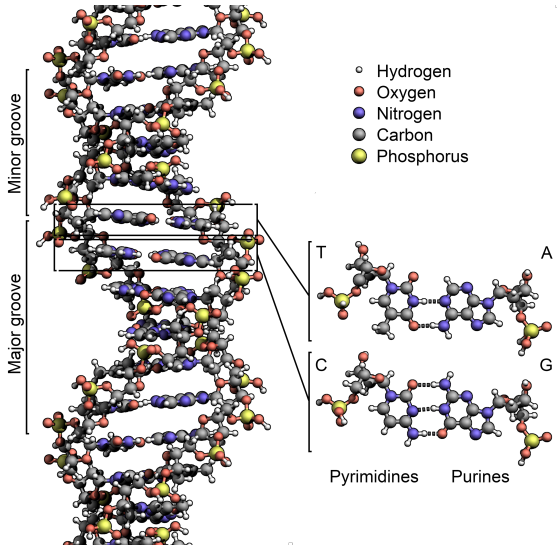

© 维基百科上的 Zephyris。保留部分权利。许可协议：CC BY-SA。此内容不在我们的知识共享许可协议范围内。
有关更多信息，请参见 http://ocw.mit.edu/help/faq-fair-use/。

图1.2：DNA的双螺旋结构。核苷酸位于中心，而糖-磷酸骨架则位于外侧。

DNA 是更容易还是更难被解包。这种通过染色质修饰进行的基因表达调控是表观遗传学的一个例子。

DNA replication

DNA的结构，其中心碱基间通过弱氢键相连，使得两条链易于分离，以便进行DNA复制（DNA链分离的能力也促进了转录、翻译、重组及DNA修复等过程）。这一点被沃森和克里克指出：“我们注意到，我们所假设的特定配对立即暗示了遗传物质可能的复制机制。”在DNA复制过程中，两条互补链被分开，每条链都作为构建新链的模板。

DNA聚合酶附着在复制起点处的每条链上，沿3’到5’方向读取每条现有链，并放置互补碱基，使新链沿5’到3’方向生长。由于新链必须从5’向3’生长，一条链（前导链）可以连续复制，而另一条链（滞后链）则以片段形式生长，这些片段随后由DNA连接酶连接在一起。最终结果是2条双链DNA片段，其中每条都由1条旧链和1条新链组成；因此，DNA复制是半保留的。

许多生物的DNA被分成若干条染色体。每条染色体包含两条DNA链，它们彼此互补，但读取方向相反。基因可以出现在DNA的任意一条链上。基因之前的DNA（位于5’区域）被认为是“上游”，而基因之后的DNA（位于3’区域）被认为是“下游”。

1.4.3 Transcription

`lecture1_transcript.html#Transcription`

$$\text{DNA} \rightarrow \text{RNA} \rightarrow \text{Protein}$$

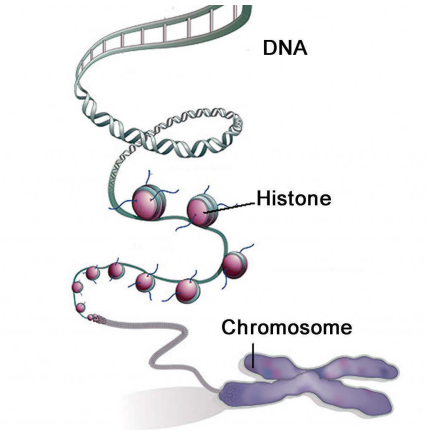

由麦克米伦出版有限公司提供。经许可使用。来源：Qiu, Jane. “表观遗传学：未完成的交响曲。” *Nature* 441, 第7090期 (2006): 143-45。

图1.3：DNA经过多层组织包装成一个紧凑的染色体。

mRNA generation

转录是使用DNA模板生成RNA的过程。DNA部分解旋形成一个“气泡”，RNA聚合酶被调控蛋白复合物招募到转录起始位点（TSS）。RNA聚合酶从3’到5’方向读取DNA，并放置互补碱基形成信使RNA（mRNA）。RNA使用与DNA相同的核苷酸，只是用尿嘧啶代替胸腺嘧啶。

Post-transcriptional modifications

真核生物中的mRNA经历翻译后修饰，即进一步编辑mRNA链的过程。最显著的是，一个称为剪接的过程移除**introns**，即不编码蛋白质的介入区域，从而仅保留编码区域，即**exons**。初级转录本的不同区域可能被剪接掉，以产生不同的蛋白质产物（可变剪接）。通过这种方式，基于不同的剪接排列，可以生成数量庞大的不同分子。

除了剪接之外，mRNA分子的两端也会被加工。5’端通过修饰的鸟嘌呤核苷酸加帽。在3’端，大约250个腺嘌呤残基被添加，形成poly(A)尾巴。

1.4.4 RNA

`lecture1_transcript.html#RNA`

$$\text{DNA} \rightarrow \text{RNA} \rightarrow \text{Protein}$$

当DNA转录时，会产生RNA。它在结构上与DNA相似，但有以下几个主要区别：

1. 使用核苷酸尿嘧啶（U）代替 DNA 中的胸腺嘧啶（T）。
2. RNA含有核糖而不是脱氧核糖（脱氧核糖在2'位缺少核糖中存在的氧分子）。
3. RNA是单链的，而DNA是双链的。

RNA 分子是编码蛋白质的中间步骤。RNA 分子还具有催化和调控功能。催化功能的一个例子是在蛋白质合成中，RNA 是核糖体的一部分。

RNA有许多不同类型，包括：

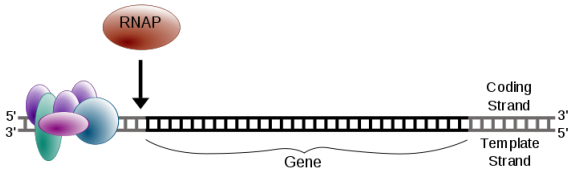

(a) Transcription initiation

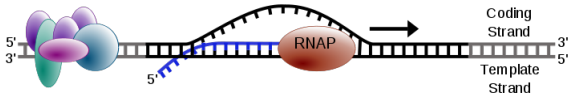

(b) Transcription elongation

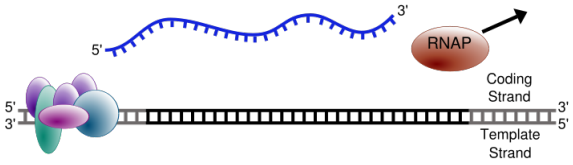

(c) Transcription termination

由维基百科的Forluvoft提供。图片属于公有领域。

图1.4：转录过程中，RNA由DNA模板生成。DNA中形成一个“泡”，允许RNA聚合酶进入并放置与DNA互补的碱基。

1. **mRNA** (信使RNA)包含制造蛋白质的信息，并被翻译成蛋白质序列。2. **tRNA** (转运RNA)指定密码子到氨基酸的翻译过程。它含有一个与mRNA上的密码子互补的3碱基对反密码子，并携带与其反密码子相对应的氨基酸附着在其3'端。3. **rRNA** (核糖体RNA)构成核糖体的核心，核糖体是负责将mRNA翻译成蛋白质的细胞器。4. **snRNA** (小核RNA)参与前体mRNA的剪接（去除内含子），以及其他功能。

其他功能类型的RNA存在，并且仍在被发现。尽管蛋白质通常被认为执行必要的细胞功能，但RNA分子可以具有复杂的三维结构并在细胞中发挥多种功能。

根据“RNA世界”假说，早期生命完全基于RNA。在早期生物体中，RNA既充当信息储存库（如同今天的DNA），又承担功能执行者的角色（如同今天的蛋白质）。蛋白质被认为是在此之后通过核糖体出现的，而DNA则被认为是最后通过逆转录出现的。

1.4.5 Translation

`lecture1_transcript.html#Translation`

$$\text{DNA} \rightarrow \text{RNA} \rightarrow \text{Protein}$$

Translation

与转录不同，在转录过程中，核苷酸仍然是DNA和RNA中编码信息的手段，而当RNA被翻译成蛋白质时，蛋白质的一级结构是由

它由氨基酸序列组成。由于有20种氨基酸而只有4种核苷酸，mRNA中的3个核苷酸序列，称为密码子，编码这20种氨基酸中的每一种。

64种可能的核苷酸三序列（密码子）中的每一种都独特地指定了某种特定氨基酸，或者是终止蛋白质翻译的终止密码子（起始密码子也编码甲硫氨酸）。由于有64种可能的密码子序列，该密码具有简并性，一些氨基酸由多种编码指定。大多数简并性发生在密码子的第三位。

Post-translational modifications

与mRNA类似，蛋白质也会经历进一步修饰，从而影响其结构和功能。一种翻译后修饰（PTM）涉及向氨基酸引入新的功能团。其中最显著的是磷酸化，即向氨基酸添加磷酸基团的过程，这一过程可以完全激活或失活蛋白质。另一种PTM是肽键的切割。例如，激素胰岛素在原始蛋白质内形成二硫键后会被切割两次。

SECOND POSITION

FIRST POSITION	U	C	A	G	THIRD POSITION
U	phenyl-alanine	serine	tyrosine	cysteine	U
					C
	leucine		stop	stop	A
			stop	tryptophan	G
C	leucine	proline	histidine	arginine	U
					C
			glutamine		A
					G
A	isoleucine	threonine	asparagine	serine	U
					C
	* methionine		lysine	arginine	A
					G
G	valine	alanine	aspartic acid	glycine	U
					C
			glutamic acid		A
					G

* and start

图1.5：此密码子表显示了mRNA中的每个3核苷酸密码子被翻译成20种氨基酸中的哪一种。红色表示终止密码子，它们终止翻译过程。

1.4.6 Protein

DNA → RNA → 蛋白质

蛋白质是负责执行细胞大部分任务的分子，具有多种功能，例如酶催化、收缩、运输、免疫系统、信号传导和受体等。与RNA和DNA一样，蛋白质是由重复亚单位构成的聚合物。然而，蛋白质由氨基酸组成，而非核苷酸。

每种氨基酸都具有大小、电荷、形状和酸度等特殊性质。因此，除了氨基酸序列（一级结构）之外，由于氨基酸之间的相互作用，还会产生额外的结构。因此，蛋白质的三维形状及其功能由其序列决定。然而，从序列确定蛋白质的形状是计算生物学中一个尚未解决的问题。

1.4.7 Regulation: from Molecules to Life

`lecture1_transcript.html#Regulation`

并非所有基因在细胞中同时表达。例如，如果细胞在没有乳糖的情况下产生乳糖转运蛋白，将会浪费能量。细胞必须知道应该表达哪些基因以及何时表达。在特定情况下，一个调控网络参与控制基因的表达水平。

转录是蛋白质水平受到调控的步骤之一。启动子区域，即位于基因上游（越过5’端）的一段DNA，在转录调控中发挥作用。启动子区域包含被称为转录因子的蛋白质所识别的基序。转录因子结合后，可以招募RNA聚合酶，从而导致基因转录。然而，转录因子也可以参与复杂的调控相互作用。启动子中可能有多个结合位点，它们可以作为基因激活的逻辑门。真核生物中的调控可能极其复杂，基因表达不仅受附近启动子区域的影响，还受远处增强子和抑制因子的影响。

我们可以使用概率模型来识别受给定转录因子调控的基因。例如，给定一组已知能结合特定转录因子的基序，我们可以计算候选基序同样结合该转录因子的概率（参见precept #1的笔记）。比较序列分析也可用于识别调控基序，因为调控基序展现出特征性的进化保守模式。

大肠杆菌和其他细菌中的乳糖操纵子是简单调节回路的一个例子。在细菌中，具有相关功能的基因通常彼此相邻，由相同的调节区域控制，并一起转录；这组基因称为操纵子。乳糖操纵子参与乳糖的代谢，乳糖可作为能源使用。然而，细菌更喜欢使用葡萄糖作为能源，因此如果环境中存在葡萄糖，细菌就不想制造由乳糖操纵子编码的蛋白质。因此，乳糖操纵子的转录由一个精巧的回路调节，其中只有当环境中存在乳糖但不存在葡萄糖时才会发生转录。

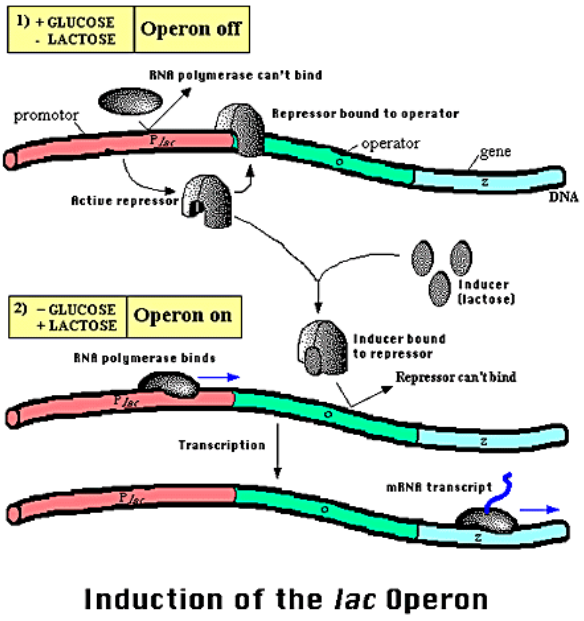

Induction of the *lac* Operon

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图1.6：乳糖操纵子展示了一个简单的生物调节系统。在葡萄糖存在时，由于葡萄糖使激活蛋白失活，乳糖代谢基因被关闭。在乳糖不存在时，阻遏蛋白也会关闭操纵子。乳糖代谢基因仅在乳糖存在且葡萄糖不存在时才表达。

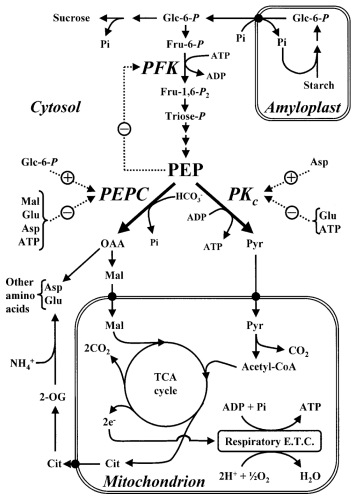

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图1.7：代谢途径及其调控可通过计算生物学进行研究。模型基于基因组规模信息构建，用于预测代谢功能和进行代谢工程。生物工程的一个实例是修改细菌基因组以过量产生青蒿素，这是一种用于治疗疟疾的抗生素。

1.4.8 Metabolism

lecture1_transcript.html#

活生物体由自组织的构建模块组成。能量来源是组织这些模块所必需的。构建模块涉及的基本机制是降解小分子以获取能量来构建大分子。降解分子以释放能量的过程称为分解代谢，利用能量组装更复杂分子的过程称为合成代谢。合成代谢和分解代谢都是代谢过程。代谢调节质量和能量的流动，以使生物体保持低熵状态。

酶是代谢反应的关键组成部分。绝大多数（但并非全部！）酶是蛋白质。许多生物学上至关重要的反应具有高活化能，因此未催化的反应会极其缓慢地发生或根本不发生。酶加速这些反应，使其能够以细胞可持续的速率发生。在活细胞中，反应被组织成代谢途径。一个反应可能有许多步骤，其中一步的产物作为下一步的底物。此外，代谢反应通常需要能量投入（特别是以一种称为ATP的分子形式），而一个反应释放的能量可能被途径中后来的反应所捕获。代谢途径对于代谢反应的调节也很重要——如果任何步骤被抑制，后续步骤可能缺乏进行所需的底物或能量。通常，调节检查点出现在代谢途径的早期，因为如果需要停止反应，显然在投入大量能量之前停止它更好。

1.4.9 Systems Biology

lecture1_transcript.html#SystemsBiology

系统生物学致力于探索和解释生物系统各组成部分之间复杂相互作用所涌现出的行为。近期系统生物学中一篇有趣的论文是“动态变化环境中的代谢基因调控”（Bennett等人，2008年）。这项工作假设酵母是一个线性、时不变系统，并通过向系统输入信号（葡萄糖）来观察响应。观察到对葡萄糖水平低频波动的周期性响应，但对高频波动几乎没有响应。因此，这项研究发现酵母对葡萄糖水平的波动起到低通滤波器的作用。

1.4.10 Synthetic Biology

`lecture1_transcript.html#SyntheticBiology`

我们不仅可以使用计算方法来建模和分析从细胞中收集的生物数据，还可以设计细胞来实现特定的逻辑电路以执行新颖的功能。设计新颖生物系统的任务被称为合成生物学。

合成生物学的一个特别显著的成功是青蒿素生产的改进。青蒿素是一种用于治疗疟疾的药物。然而，青蒿素的生产成本相当高。最近，一种酵母菌株被工程化，以先前成本的一半合成青蒿酸的前体。

1.4.11 Model organisms and human biology

人类生物学的各个方面都有多种模型生物。在适当的复杂程度使用模型生物的重要性。

注意：在这本特定的书中，我们将重点讨论人类生物学，并使用酿酒酵母 *Saccharomyces cerevisiae*、果蝇 *Drosophila melanogaster*、线虫 *Coenorhabditis elegans* 和小家鼠 *Mus musculus* 的例子。我们仅在人类微生物组的宏基因组学背景下探讨细菌演化。

1.5 Introduction to algorithms and probabilistic inference

1. 我们将通过考虑表示模体的另一种方式——*position weight matrix* (PWM)——来快速回顾一些基本概率。我们希望建模的事实是，蛋白质可能结合到并未完全指定的模体。也就是说，某些位置可能需要特定的核苷酸（例如A），而其他位置则可以是4种核苷酸的子集（例如A或C）。PWM通过使用一个矩阵来表示属于该模体的所有DNA序列，该矩阵存储了在模体每个位置上找到4种核苷酸中每一种的概率。例如，考虑以下长度为4的模体的PWM：

	1	2	3	4
A	0.6	0.25	0.10	1.0
G	0.4	0.25	0.10	0.0
T	0.0	0.25	0.40	0.0
C	0.0	0.25	0.40	0.0

我们认为该模体能生成长度为4的序列。PWMs通常假定一个位置的分布不受另一个位置碱基的影响。注意，每个位置都与核苷酸上的概率分布相关联（它们的总和为1且非负）。

2. 我们还可以对核苷酸的 *background distribution* 进行建模（在整个基因组中发现的分布）：

A	0.1
G	0.4
T	0.1
C	0.4

注意 A 和 T 的概率相同，G 和 C 的概率也相同。这是 DNA 互补性的结果，它确保了基因组中 A 与 T 、G 与 C 的整体组成相同。

3. 考虑序列 $S = \text{GCAA}$。

该基序生成此序列的概率为 $P(S|M) = 0.4 \times 0.25 \times 0.1 \times 1.0 = 0.01$。

背景生成这个序列 $P(S|B) = 0.4 \times 0.4 \times 0.1 \times 0.1 = 0.0016$ 的概率。

4. 仅此一点并不特别有趣。然而，给定由模体生成的序列比例，例如 $P(M) = 0.1$，并假设所有其他序列由背景（$P(B) = 0.9$）生成，我们可以使用贝叶斯法则计算模体生成该序列的概率：

$$\begin{aligned} P(M|S) &= \frac{P(S|M)P(M)}{P(S)} \\ &= \frac{P(S|M)P(M)}{P(S|B)P(B) + P(S|M)P(M)} \\ &= \frac{0.01 \times 0.1}{0.0016 \times 0.9 + 0.01 \times 0.1} = 0.40984 \end{aligned}$$

1.5.1 Probability distributions

1.5.2 Graphical probabilistic models

1.5.3 Bayes rules: priors, likelihood, posterior

1.5.4 Markov Chains and Sequential Models

1.5.5 Probabilistic inference and learning

1.5.6 Max Likelihood and Max A Posteriori Estimates

Bibliography

[1] lec1test。 lec1test, lec1test。

Part I

Comparing Genomes

CHAPTER
TWO

序列比对与动态规划

Guilherme Issao Fujiwara, Pete Kruskal (2007) Ar kajit Dey, Carlos Pards (2008) Victor Costan, Mart en van Dijk (2009) Andreea Bodnari, Wes Brown (2010) Sarah Spencer (2011) Nathaniel Parrish (201 2) Clément Pit-Claudel (2014) Jesse Tordoff, Thra syvoulos Karydis (2015)

Figures

2.1 四种酵母菌株间Gal10-Gal1的序列比对。星号标记保守核苷酸。 . . . . . 25 2.2 遗传序列的进化变化 . . . . . 25 2.3 将人类与小鼠序列比对类似于追踪 . . . . . 26 2.4 最长公共子串示例 . . . . . 27 2.5 最长公共子序列公式化示例 . . . . . 27 2.6 匹配与不匹配的成本矩阵 . . . . . 28 2.7 自然界中斐波那契数的例子无处不在。 . . . . . 30 2.8 fib过程的递归树显示重复的子问题。树的大小为$O(\phi(n))$，其中ϕ是黄金比例。 . . . . . 31 2.9 （示例）Needleman-Wunsch的初始设置 . . . . . 35 2.10 （示例）Needleman-Wunsch第二步进行到一半 . . . . . 35 2.11 （示例）追踪最优比对 . . . . . 36 2.12 有界动态规划示例 . . . . . 36 2.13 使用$O(m+n)$空间恢复序列比对 . . . . . 37 2.14 直系同源和旁系同源序列 40

2.1 Introduction

序列比对是一种强大的工具，能够揭示基因的模式和功能。如果两个遗传区域相似或相同，序列比对可以展示它们之间的保守元件或差异。进化在基因组中保留了两大类功能元件。这些物种间保存的元件通常是同源物{v*}——要么是直系同源序列，要么是旁系同源序列（参见附录2.11.1）。这两类保守元件都能帮助证明基因序列的功能或进化历史。主要使用计算方法解决（最常见的是动态

[1] Homologous sequences are genomic sequences descended from a common ancestor.

（编程），序列比对是一种快速且强大的方法，用于发现基因或基因组之间的相似性。这些笔记讨论了序列比对问题、动态规划技术，以及使用该技术解决该问题的一种具体方案。

2.2 Aligning Sequences

序列比对是指比较两条或多条遗传链（如DNA或RNA）的方法。这些比较有助于发现遗传共性，并（隐含地）追踪链的进化。比对主要有两种类型：

- 全局比对：尝试比对基因链中的每一个元素，当考虑的基因链大小大致相同时最为有用。全局比对也可能以空位结束。
- 局部比对：尝试在更大的背景下对包含相似序列模体的序列区域进行比对。

2.2.1 Example Alignment

在直系同源基因序列中，存在保守岛，即在世代间保留下来的相对较长的核苷酸序列。这些保守区域通常意味着功能元件，反之亦然。作为一个例子，我们考虑了四个

不同酵母物种之间的首个跨物种全基因组比对（图2.1）。当我们观察这个
对齐，我们注意到有些区域比其他区域更相似，这表明这些区域在进化过程中被保留了。特别是，我们注意到一些小的保守基序，如CGG和CGC，这些
事实上，[2]是Gal4结合中的功能元件[8]。这个例子突出了进化数据如何
可以帮助定位基因组的功能区域：每个核苷酸的保守水平表示每个核苷酸的重要性，而外显子是基因组中最保守的元件之一。

然而，我们在解读时必须谨慎，因为保守性有时是偶然发生的。为了从序列比对中提取准确的生物学信息，我们必须将真实的信号与噪声区分开来。解决这一问题最常见的方法涉及建立进化过程模型。例如，通过使用已知的密码子替换频率和RNA二级结构约束，我们可以计算进化作用以保持生物功能的概率。关于基因组注释背景下进化建模和功能保守性的深入讨论，请参见第**??**章。

2.2.2 Solving Sequence Alignment

基因组随时间发生变化，而古代基因组的稀缺性使得将现存物种的基因组与其祖先的基因组进行比较几乎不可能。因此，我们只能比较现存后代的基因组。序列比对的目标是仅通过观察这些终点来推断改变基因组的“编辑操作”。

在进行序列比对时，我们必须做出一些假设，哪怕仅仅是因为我们需要将一个生物学问题转化为计算上可行的问题，并且我们需要一个相对简单且易于处理的模型。实际上，序列进化主要是由于核苷酸突变、缺失和插入所导致的。
（图 2.2）。因此，我们的序列比对模型将只考虑这三种操作，并忽略
其他以较低概率发生的现实事件（例如重复）。[3]

1. 当一个序列中的某个核苷酸在进化过程中变为另一个核苷酸时，就发生了核苷酸**mutation**。

2. 当序列在进化过程中发生某个核苷酸缺失时，就会出现核苷酸 **deletion**。

[2]Gal4 in fact displays a particular structure, comprising two arms that each bind to the same sequence, in reversed order.
[3]Interestingly, modeling decisions taken to improve tractability do not necessarily result in diminished relevance; for example, accounting for directionality in the study of chromosome inversions yields polynomial-time solutions to an otherwise NP problem.[6]

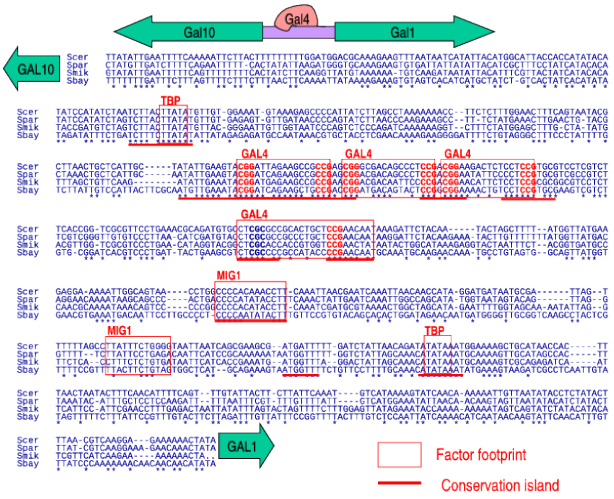

© source unknown. All rights reserved. This content is excluded from our C创造性 Commons license. For more information, see http://ocw.mit.edu/help/faq-f空气使用/。

图2.1：四种酵母菌株间Gal10-Gal1序列比对。星号表示保守核苷酸。图2.2：遗传序列的进化变化

3. 当一个核苷酸在进化过程中被添加到序列中时，就出现了核苷酸**insertion**。

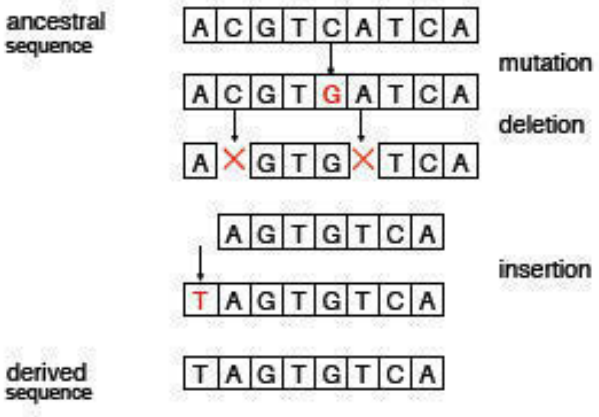

请注意，这三个事件都是可逆的。例如，如果核苷酸N突变为某个核苷酸M，那么核苷酸M也有可能突变为核苷酸N。同样，如果核苷酸N被删除，若核苷酸N被（重新）插入，则该事件可能被逆转。显然，插入事件通过相应的删除事件被逆转。

这种可逆性是更大设计假设的一部分：时间可逆性。具体来说，我们模型中的任何事件在时间上都是可逆的。例如，随时间向前发生的核苷酸缺失可以被视为随时间向后发生的核苷酸插入。这很有用，因为我们将比对都存在于现在的序列。为了比较进化相关性，我们会想象自己沿着一个序列逆时间追溯到共同祖先，然后再顺时间前进到另一个序列。这样，我们可以避免没有祖先核苷酸序列的问题。

注意，时间可逆性在解决某些生物学问题时很有用，但实际上并不适用于

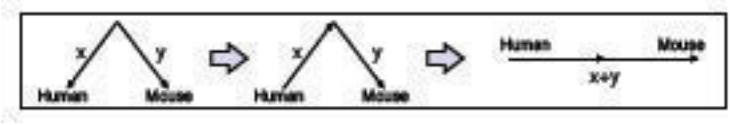

图2.3：将人类序列与小鼠序列对齐，类似于从人类追溯至共同祖先，再向前追溯至小鼠

生物系统。例如，CpG[4]在DNA复制过程中可能错误地与TpG或CpA配对，但反向操作不会发生；因此这种转变不是时间可逆的。需要明确的是，时间可逆性只是我们模型中的一个设计决定；它并非生物学固有的[5]。

我们还需要某种方法来评估我们的比对。将一种基因组转变为另一种基因组的事件序列有许多可能。也许最明显的是最小化两个基因组之间的事件数量（即突变、插入和缺失），但许多插入之后伴随相应缺失的事件序列也是可能的。我们希望建立一种最优性准则，使我们能够选择描述基因组之间变化的“最佳”事件序列。

我们选择援引奥卡姆剃刀原则，并选取最大简约法作为我们的最优性准则。也就是说，我们通常希望最小化用于解释两个核苷酸序列差异的事件数量。在实践中，我们发现点突变比插入和缺失更可能发生，而且某些突变比其他突变更常见[11]。我们的简约法在最大化简约性时必须考虑这些以及其他不等式。这引出了替换矩阵和空位罚分的概念，这些将在后续章节中展开。请注意，我们并非必须选择最大简约法作为最优性准则。我们可以选择概率方法，例如使用隐马尔可夫模型（HMMs），在可能的事件路径空间上赋予概率测度，并使用其他方法（如贝叶斯方法）来评估比对。注意这两种方法之间的对偶性：我们的最大简约法反映了这样一种信念，即突变事件发生的概率较低，因此在寻找最小化事件数量的解时，我们实际上是在隐式地最大化其似然。

2.3 Problem Formulations

在本节中，我们介绍一个简单问题，对其进行分析，并逐步增加其复杂度，直至其 closely resembles 序列比对问题。本节应被视为关于 Needleman-Wunsch 算法的第 2.5 节的预热。

2.3.1 Formulation 1: Longest Common Substring

作为初步尝试，假设我们将核苷酸序列视为字母表A、C、G和T上的字符串。给定两个这样的字符串S1和S2，我们可能会尝试通过找到它们之间的最长公共子串来进行比对。特别地，这些子串中不能有间隙。

例如，如果S1 = ACGTCATCA且S2 = TAGTGTCA（参见图2.4），它们之间的最长公共子串是GTCA。因此，在这个公式中，我们可以沿着最长的公共子串GTCA对S1和S2进行比对，以获得最多的匹配。一个简单的算法是尝试将S1与S2的不同偏移量进行比对，并记录目前为止找到的最长子串匹配。请注意，该算法在最短序列的长度上是二次的，这对于这样一个简单的问题来说比我们希望的要慢。

[4]p denotes the phosphate backbone in a DNA strand

[5]This is an example where understanding the biology helps the design greatly, and illustrates the general principle that success in computational biology requires strong knowledge of the foundations of both CS and biology. Warning: computer scientists who ignore biology will work too hard.

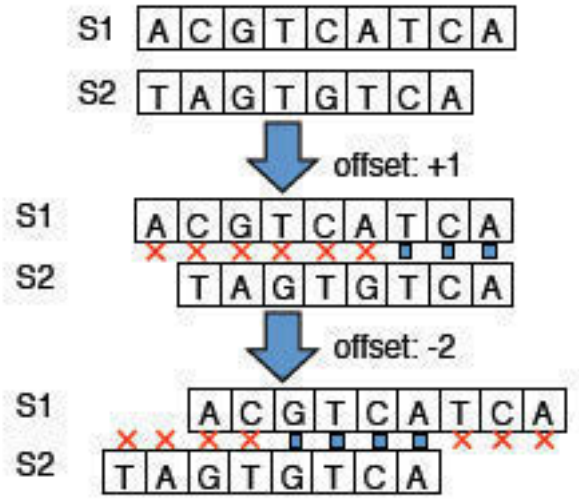

图2.4：最长公共子串公式示例

2.3.2 Formulation 2: Longest Common Subsequence (LCS)

另一种表述是允许子序列中存在间隙，而不仅仅局限于无间隙的子串。给定一个序列 X = $(x_1$, .., $x_m)$，我们正式定义 $Z = (z_1, \ldots, z_k)$ 为 X 的子序列，如果存在一个严格递增的索引序列 $i_1 < i_2 < \ldots < i_k$，使得对于所有 j，$1 \leq j \leq k$，我们有 $x_{i_j} = z_j$(CLRS 350-1)。

在最长公共子序列（LCS）问题中，我们被给定两个序列X和Y，目标是找到最大长度的公共子序列Z。以序列S1 = ACGTCATCA和S2 = TAGTGTCA为例（参见图2.5）。最长的公共子序列是AGTTCA，这比仅仅是最长公共子串的匹配更长。

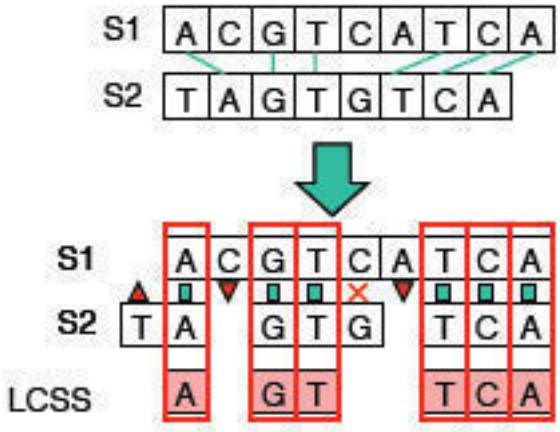

图 2.5：最长公共子序列公式示例

2.3.3 Formulation 3: Sequence Alignment as Edit Distance

Formulation

先前的LCS表述接近完整的序列比对问题，但到目前为止，我们尚未指定任何能够区分三种编辑操作类型（插入、删除和替换）的成本函数。隐含地，我们的成本函数一直是统一的，意味着所有操作的可能性相同。由于替换的可能性更大，我们希望通过对成本函数施加偏好，使LCS解决方案偏向于替换而非插入和删除。

我们将序列比对重新表述为计算机科学中经典编辑距离[6]问题的一个特例（CLRS 366）。我们为不同的编辑操作添加不同的惩罚，以反映生物学事件。这一打分决策的一个生物学依据是碱基在聚合过程中被错误转录的概率。在四种核苷酸碱基中，A和G是嘌呤（较大，两个稠合环），而C和T是嘧啶（较小，一个环）。因此，DNA聚合酶[7]更可能混淆两个嘌呤或两个嘧啶，因为它们在结构上相似。图2.6中的打分矩阵对上述考虑进行了建模。注意该表是对称的——这支持了我们的时间可逆设计。

	A	G	T	C
A	+1	-½	-1	-1
G	-½	+1	-1	-1
T	-1	-1	+1	-½
C	-1	-1	-½	+1

图2.6：匹配与不匹配的代价矩阵

计算得分意味着在生物事件发生频率的概率解释与为每个操作分配得分的算法解释之间交替进行。问题在于找到能够将初始核苷酸序列转化为最终核苷酸序列的最廉价（按照成本矩阵）操作序列。

Complexity of Edit Distance

所有求解两个字符串之间编辑距离的算法都在近多项式时间内运行。2015年，Backurs和Indyk [**?**]发表了一个证明，表明在一般情况下编辑距离无法在快于 $O(n^2)$ 的时间内求解。这一结果依赖于强指数时间假设（SETH），该假设指出NP完全问题无法在最坏情况下于次指数时间内求解。

2.3.4 Formulation 4: Varying Gap Cost Models

在生物学上，创建间隙的成本比扩展现有间隙的成本更高。因此，我们可以建立一个考虑这种成本变化的模型。有许多这样的模型可供我们使用，包括以下几种：

- **Linear gap penalty:** 所有间隙的固定成本（与公式3相同）。
- **Affine gap penalty:** 为打开一个缺口施加较大的初始成本，然后为每个缺口延伸施加较小的增量成本。
- **General gap penalty:** 允许任何成本函数。注意这可能会改变我们算法的渐近运行时间。

[6]Edit-distance or Levenshtein distance is a metric for measuring the amount of difference between two sequences (e.g., the Levenshtein distance applied to two strings represents the minimum number of edits necessary for transforming one string into another).

[7]DNA polymerase is an enzyme that helps copy a DNA strand during replication.

- **Frame-aware gap penalty:** 调整成本函数以考虑编码框的破坏（导致功能元件移码的插入缺失通常会引起重要的表型改变）。

2.3.5 Enumeration

回想一下，为了求解最长公共子串问题，我们可以简单地枚举所有可能的对齐方式，评估每一种，然后选择最好的。这是因为两个序列只有$O(n)$种对齐方式。然而，一旦我们允许对齐中存在间隙，情况就不再如此。众所周知，所有可能的带间隙对齐的数量无法枚举（至少当序列很长时是这样）。例如，对于两个长度为1000的序列，可能的对齐数量超过了宇宙中原子的数量。

给定一个用于对给定对齐进行评分的度量，简单的暴力算法会枚举所有可能的对齐，计算每一个的分数，并选择得分最高的对齐。这引出了一个问题："可能有多少种对齐？"如果只考虑NBA [8] $n > m$，对齐的数量是

$$\binom{n+m}{m} = \frac{(n+m)!}{n!m!} \approx \frac{(2n)!}{(n!)^2} \approx \frac{\sqrt{4\pi n}\frac{(2n)^{2n}}{e^{2n}}}{(\sqrt{2\pi n}\frac{(n)^n}{e^n})^2} = \frac{2^{2n}}{\sqrt{\pi n}} \tag{2.1}$$

这个数字增长极快，对于小至30的n值而言，就已经过大（$> 10^{17}$），以至于这种枚举策略不可行。因此，必须采用比暴力破解更优的算法。

2.4 Dynamic Programming

在继续解决序列比对问题之前，我们首先讨论动态规划，这是一种解决具有特定结构类型问题的通用且强大的方法。

2.4.1 Theory of Dynamic Programming

动态规划可用于解决具有以下特征的问题：

1. **Optimal Substructure**：问题实例的最优解包含子问题的最优解。

2. **Overlapping Subproblems**：子问题的数量有限，其中许多/大多数会重复多次。

动态规划通常（但并非总是）用于解决优化问题，类似于贪心算法。与需要满足贪心选择性质才有效的贪心算法不同，动态规划适用于一系列局部最优选择无法产生全局最优结果的问题。

附录 2.11.3 更详细地讨论了贪心算法和动态规划之间的区别
细节；一般来说，贪心算法解决的问题类比动态规划要少。

在实践中，运用动态规划解决问题主要包括两个主要部分：建立动态规划模型，然后进行计算。建立动态规划通常需要以下5个步骤：

1. 找到问题的"矩阵"参数化形式。确定维度（变量）的数量。

2. 确保子问题空间是多项式的（而非指数级的）。请注意，如果仅使用少量子问题，那么记忆化可能更合适；同样，如果子问题重用不广泛，动态规划可能不是该问题的最佳解决方案。

3. 确定有效的横向顺序。子问题在需要时必须已经准备就绪（解决），因此计算顺序很重要。

[8] Non-Boring Alignments, or alignments where gaps are always paired with nucleotides.

4. 确定递归公式：一个较大的问题通常通过其子部分的功能来解决。

5. 记住选择：通常，递归公式涉及最小化或最大化步骤。此外，往往需要一种表示来存储横向指针，并且这种表示应该是多项式的。

一旦动态规划建立起来，计算通常就很直接：

1. 系统地填写结果表（通常还有回溯指针），并找到最优分数。

2. 通过指针从最优分数回溯，以确定一个最优解。

2.4.2 Fibonacci Numbers

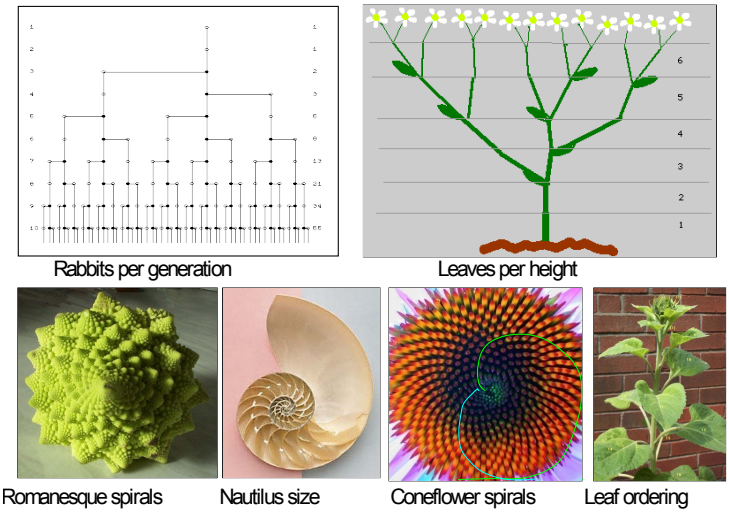

© source unknown. All rights reserved. This content is excluded from our Creat知识共享许可协议。如需了解更多信息，请参见 http://ocw.mit.edu/help/faq-fair-use/。

图2.7：自然界中斐波那契数的例子无处不在。

斐波那契数列为动态规划的优势提供了一个富有启发性的例子。斐波那契数列递归定义为 $F_0 = F_1 = 1$, $F_n = F_{n-1} + F_n$ 对应于 $_{-2}$ $n \leq 2$。我们开发一个算法来计算第 n^{th} 个斐波那契数，并首先使用记忆化对其进行改进，之后使用动态规划来阐述关键概念。

The Naïve Solution

简单的自顶向下方法是直接应用递归定义。代码清单1展示了一个简单的Python实现。

```
# Assume n is a non-negative integer.
def fib(n):
    if n == 0 or n == 1:
        return 1
    else:
        return fib(n - 1) + fib(n - 2)
```

清单 2.1：用于递归计算斐波那契数的 Python 实现。

但这种自顶向下的算法运行时间为指数级。也就是说，如果$T(n)$是计算第n^{th}个斐波那契数所需的时间，我们有$T(n) = T(n-1) + T(n-2) + O(1)$，因此$T(n) = O(\phi^n)$ [9]。问题在于我们通过多次解决相同的子问题重复了工作。

[9] ϕ is the **golden ratio**, i.e. $\frac{1+\sqrt{5}}{2}$

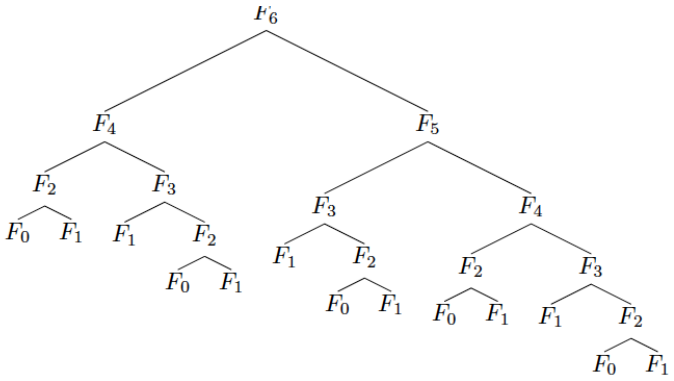

图2.8：fib过程的递归树，显示了重复的子问题。树的大小为$O(\phi(n))$，其中ϕ为黄金比例。

The Memoization Solution

一个仍然采用自顶向下方法的更好解决方案是记忆子问题的答案。列表2给出了使用记忆化的Python实现。

```
# Assume n is a non-negative integer.
fibs = {0: 1, 1: 1} # stores subproblem answers
def fib(n):
    if n not in fibs:
        x = fib(n - 2)
        y = fib(n - 1)
        fibs[n] = x + y
    return fibs[n]
```

清单 2.2：用于计算的 Python 实现　　使用记忆化计算斐波那契数。

注意，此实现现在运行时间为 $T(n) = O(n)$，因为每个子问题最多计算一次。

The Dynamic Programming Solution

为了计算n^{th}斐波那契数，而不是从$F(n)$开始并使用递归，我们可以自底向上进行计算，因为我们已经知道无论如何都会需要所有的子问题。这样，我们将省去许多在朴素的自顶向下方法中会进行的重复工作，并且我们能够以$O(n)$时间计算n^{th}斐波那契数。

作为一个形式练习，我们可以应用第2.4.1节中概述的步骤：

1. **Find a 'matrix' parameterization:** 在这种情况下，矩阵是一维的；任何子问题 $F(x)$ 都只有一个参数。2. **Ensure the subproblem space is polynomial:** 由于只有 $n-1$ 个子问题，空间是多项式的。3. **Determine an effective transversal order:** 如上所述，我们将采用自底向上的遍历顺序（即按升序计算子问题）。4. **Determine a recursive formula:** 这其实就是著名的递推式 $F(n) = F(n-1)+F(n-2)$。

5. **Remember choices:** 在这种情况下，无需记忆，因为递归公式中没有做出任何选择。

清单3展示了这种方法的Python实现。

```python
# Assume n is a non-negative integer
def fib(n):
    x = y = 1
    for i in range(1, n):
        x, y = y, x + y
    return x
```

清单 2.3：使用动态规划迭代计算斐波那契数的 Python 实现。

此方法经过优化，仅使用常量空间而非整个表格，因为我们只需每个子问题的答案一次。但在一般的动态规划解决方案中，我们希望将子问题的解存储在一个表格中，因为我们可能需要多次使用它们而无需重新计算答案。这样的解决方案看起来有点类似于清单2中的记忆化解决方案，但它们通常采用自底向上的方式而非自顶向下。在这个特定例子中，记忆化解决方案与动态规划解决方案之间的区别微乎其微，因为两种方法都计算了所有子问题的解，并以相同的次数使用它们。一般来说，当不是所有子问题都会被计算时，记忆化很有用，而动态规划则节省了递归函数调用的开销，

因此在必须计算所有子问题解时更为可取[10]。额外的动态规划
在线可以找到示例[7]。

2.4.3 Sequence Alignment using Dynamic Programming

我们现在准备使用动态规划来解决更困难的序列比对问题，这将在下一节中深入介绍。请注意，解决序列比对问题的关键洞察在于比对分数是可加的。这使我们能够创建一个矩阵 M，其索引由 i 和 j 表示，它们是要比对的两个序列 S 和 T 中的位置。在使用递归公式填充矩阵 M 后，S 和 T 的最佳比对对应于穿过该矩阵的最佳路径。

通过使用动态规划来解决序列比对问题，我们能获得一个可证明最优的解决方案，其效率远高于蛮力枚举。

2.5 The Needleman-Wunsch Algorithm

我们现在将使用动态规划来解决更困难的通用序列比对问题。给定两个字符串 S =$(S_1, \ldots, S_n)$ 和 T =$(T_1, \ldots, T_m)$，我们希望找到最长公共子序列，该子序列可能包含也可能不包含空位。我们不是最大化公共子序列的长度，而是要计算根据我们的评分函数所定义的分数最优的公共子序列。设 d 表示空位罚分成本，s(x; y) 表示比对碱基 x 和碱基 y 的分数。这些是从插入/缺失和替换概率推断出来的，这些概率可以通过实验确定，或者通过观察我们知道密切相关的序列来确定。我们将在以下各节中开发的用于解决序列比对的算法被称为 Needleman-Wunsch 算法。

2.5.1 Dynamic programming vs. memoization

在我们深入算法之前，有必要对记忆化做一个最后的说明。与斐波那契问题非常相似，序列比对问题也可以通过自顶向下或自底向上的方法来解决。

在*top-down recursive approach*中，我们可以使用记忆化技术创建一个可能很大的字典，其索引对应我们正在求解的每个子问题（已对齐的序列）。如果我们将每个子问题按其需要计算最优对齐的子序列的起始和结束点进行索引，则需要$O(n^2m^2)$的空间。其优点在于每个子问题至多求解一次：如果它不在字典中，则计算该问题并将其插入字典以供后续参考。

在*bottom-up iterative approach*中，我们可以使用动态规划。我们定义子问题的计算顺序，使得在相关子问题已经计算完成后，问题的解才被计算。

[10] In some cases dynamic programming is virtually the only acceptable solution; this is the case in particular when dependency chains between subproblems are long: in this case, the memoization-based solution recurses too deeply, and causes a stack overflow

已经解决。特别是，较简单的子问题会先于更复杂的出现。这样就不需要跟踪哪些子问题已被解决（备忘录中的字典转变为矩阵），并确保了没有重复工作（每个子对齐仅计算一次）。

因此，在这个特定情况下，记忆化与动态规划之间唯一实际的区别在于记忆化方法中递归调用产生的开销（空间使用相同）。

2.5.2 Problem Statement

假设我们有两个序列$S_{1...n}$和$T_{1...m}$的最优比对，其中S_i与T_j匹配。关键在于，这个最优比对是由$(S_1, \ldots, S_i)$与$_{-1}(T_1, \ldots, T_{j\ \ 1})$之间的最优比对，以及$(S\ \ , \ldots, S)$与$(T\ \ , \ldots, T)$之间的最优比对所组成。这一结论源自$_{-i+1\ \ \ \ n\ \ \ \ j+1\ \ \ \ m}$的剪切-粘贴论证：若这些部分比对中有一个非最优，则我们剪切并粘贴一个更优的比对来替代那个次优的。这样可以得到整体比对更高的得分，从而与初始全局比对的最优性相矛盾。换句话说，最优路径中的每一子路径也必须是最优的。注意，分数是可加的，因此整体比对的得分等于子序列比对得分的总和。这隐含地假定计算子序列最优评分比对的子问题是相互独立的。我们需要从生物学角度说明这种假设能够导出有意义的结果。

2.5.3 Index space of subproblems

现在需要对子问题空间进行索引。令$F_{i,j}$为$(S_1, \ldots, S_i)$和$(T_1, \ldots, T_j)$最优比对的得分。子问题空间为$\{F_{i,j}, i \in [0, |S|], j \in [0, |T|]\}$。这使我们能够维护一个$(m+1) \times (n+1)$矩阵F，其中包含所有子问题的解（即最优得分）。

2.5.4 Local optimality

我们可以通过基于较小子问题的结果做出局部最优选择，来计算子问题的最优解。因此，我们需要建立一个递归函数，展示给定问题的解如何依赖于其子问题。并且我们使用这个递归定义以自底向上的方式填充表 F 。

我们可以考虑 4 种可能性（插入、删除、替换、匹配），并根据我们已经计算出的较小子问题的结果来评估每一种。为了初始化表格，我们设置 $F_{0,j} = -j \cdot d$ 和 $F_{i,0} = -i \cdot d$，因为这些是将 $(T_1, \ldots, T_j)$ 与 j 个空位对齐以及将 $(S_1, \ldots, S_i)$ 与 i 个空位对齐（即两个序列之间零重叠）的得分。然后我们逐列遍历矩阵，通过考虑这四种可能性来计算每个对齐子问题的最优得分：

- 序列 S 在当前对齐位置存在一个空隙。
- 序列T在当前对齐位置有一个空位。
- 当前位置存在突变（核苷酸替换）。
- 当前位置存在匹配项。

然后我们使用产生最大分数的可能性。我们通过递归公式对$F_{i,j}$进行数学表达：

$$
\begin{aligned}
Initialization \quad &: \quad F(0,0) = 0 \\
&\qquad\quad F(i,0) = F(i-1,0) - d \\
&\qquad\quad F(0,j) = F(0,j-1) - d
\end{aligned}
$$

$$
Iteration \quad : \quad F(i,j) = \max \begin{cases} F(i-1,j) - d & \text{insert gap in } S \\ F(i,j-1) - d & \text{insert gap in } T \\ F(i-1,j-1) + s(x_i, y_j) & \text{match or mutation} \end{cases}
$$

$$
Termination \quad : \quad Bottom\ right
$$

遍历矩阵后，全局对齐的最优得分由$F_{m,n}$给出。遍历顺序需要确保在需要时我们已经解决了给定的子问题。具体来说，为了计算$F_{i,j}$，我们需要知道表中$F_{i,j}$左侧、上方和对角线上方的值。因此，我们可以按行优先、列优先，甚至从左上角单元格到右下角单元格的对角线顺序遍历表格。现在，为了获得实际的对齐方式，我们只需记住每一步所做的选择。

2.5.5 Optimal Solution

通过矩阵 F 的路径对应于最优序列比对。在评估每个单元格 $F_{i,j}$ 时，我们通过选择三种可能性中的最大值来做出选择。因此，矩阵中每个（未初始化的）单元格的值由左侧、上方或左上方对角线的单元格决定。匹配和替换都表示为沿对角线方向移动；然而，根据我们比对的两个碱基对是否匹配，可以分别应用不同的代价。为了构建实际的最优比对，我们需要回溯矩阵中的选择。在填充表格时，为每个单元格维护一个指针，显示为获得该单元格分数所做的选择，这是有帮助的。然后，我们只需反向跟随指针来重建最优比对。

2.5.6 Solution Analysis

该算法的运行时间分析非常简单。每次更新需要$O(1)$的时间，并且由于矩阵F中有mn个元素，总运行时间为$O(mn)$。类似地，总存储空间为$O(mn)$。对于更新规则更复杂的一般情况，运行时间可能更昂贵。例如，如果更新规则需要测试所有大小的间隙（例如，间隙的成本不是线性的），那么运行时间将为$O(mn(m+n))$。

2.5.7 Needleman-Wunsch in practice

假设我们要比对两个序列S和T，其中

S = AGT T

= AAGC

第一步是将两条序列放置在矩阵的边缘，并初始化矩阵单元。为了初始化，我们将矩阵中的第一个条目赋值为0，然后根据间隙罚分的累加填充第一行和第一列，如图2.9所示。尽管算法可以通过迭代来填充第一行和第一列，但清晰地定义并设定问题的边界非常重要。

下一步是遍历矩阵。算法沿行或沿列进行，每次考虑一个单元格。对于每个单元格，根据三个相邻矩阵单元格的得分计算三个分数（具体是上方单元格、左上对角线单元格和左侧单元格）。这三种可能回溯中的最高得分被分配给该单元格，并同时存储相应的指针。当算法到达右下角时终止。在图2.10中，序列S和T的比对矩阵已填入得分和指针。

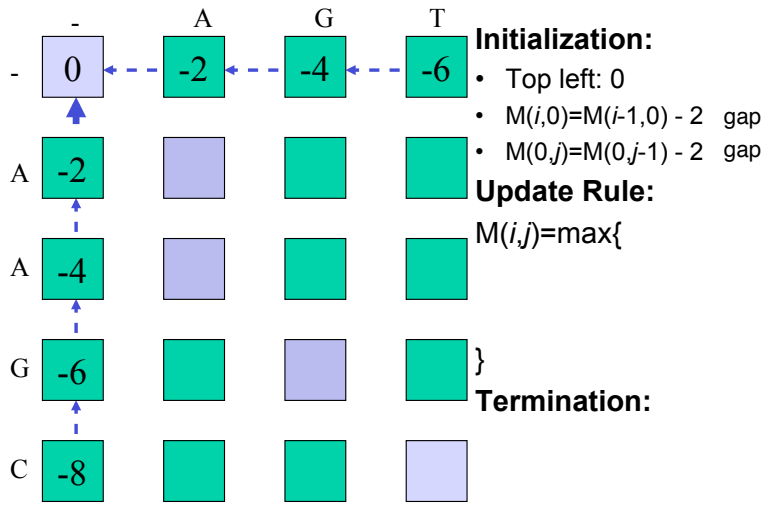

图2.9：（示例）Needleman-Wunsch的初始设置

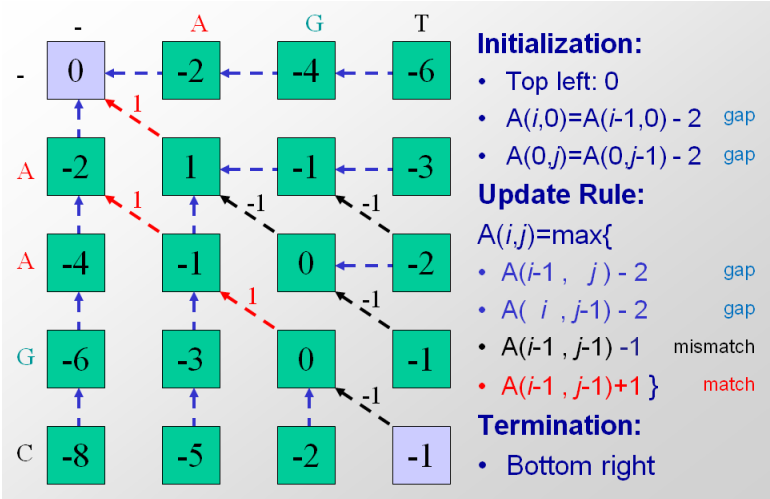

图2.10：（示例）Needleman-Wunsch算法第二步进行到一半

算法的最后一步是最优路径回溯。在我们的例子中，我们从右下角开始，沿着可用的指针向左上角移动。通过在回溯过程中记录每个单元格所做的比对决策，我们可以从末尾到开头重建最优序列比对，然后将其反转。注意，在这个特定情况下，存在多条最优路径（图2.11）。Needleman-Wunsch算法的伪代码实现包含在附录2.11.4中。

2.5.8 Optimizations

我们提出的动态算法比枚举比对的暴力策略快得多，对于长达10千碱基的序列表现良好。然而，在全基因组比对的规模上，给出的算法并不可行。为了比对更大的序列，我们可以对算法进行修改并进一步提高其性能。

Bounded Dynamic Programming

一种可能的优化是忽略轻微无聊对齐（MBA）或间隙过多的对齐。具体来说，我们可以限制自己保持在矩阵中对角线距离W的范围内。

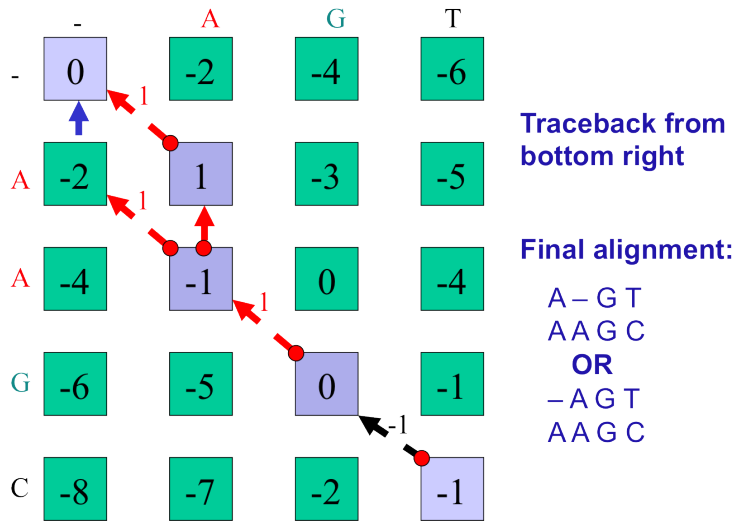

图2.11：（示例）追踪最优对齐

F的子问题。也就是说，我们假设从$F_{0,0}$到$F_{m,n}$在F中的优化路径在对角线方向上的距离不超过W。这意味着递归式(2.2)仅需应用于F中围绕对角线距离W以内的元素，这将导致时间/空间成本为$O((m+n)W)$（参见图2.12）。

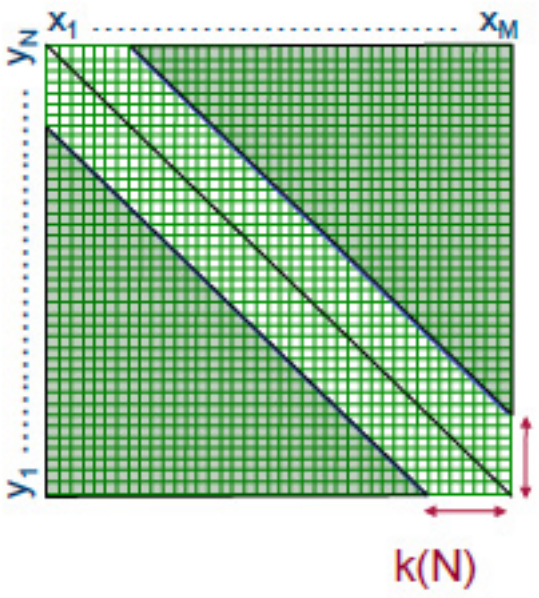

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图2.12：有界动态规划示例

然而，请注意，这种策略是启发式的，不再保证得到最优比对。相反，它只能达到最优得分的一个下界。这可以用于后续步骤，在此步骤中，我们基于该下界排除矩阵F中无法导向最优比对的递归。

Linear Space Alignment

递归（2.2）可以仅使用线性空间求解：我们自左向右更新F中的列，在此过程中仅需追踪最近更新的列，其占用$O(m)$空间。然而，除分数之外

$F_{m,n}$ 关于最优对齐，我们还希望计算相应的对齐。如果使用回溯，那么我们需要为 F 中的每个条目存储指针，这将消耗 $O(mn)$ 空间。

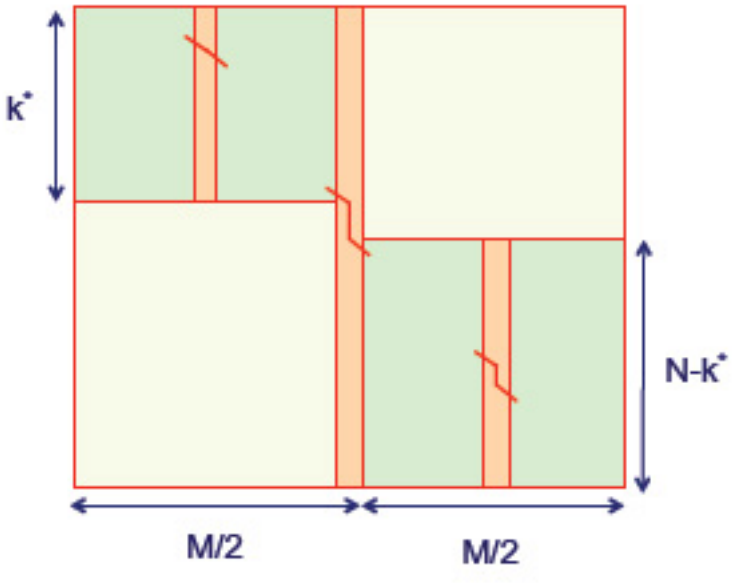

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图 2.13：使用$O(m+n)$恢复序列比对 空间

也可以仅使用线性空间来找到最优比对！目标是使用分治法，以便在每一步中计算一个矩阵条目的最优比对结构。图2.13展示了该过程。关键思想是，动态规划比对同样可以轻松地在反方向上进行，从右下角开始，终止于左上角。因此，如果将矩阵一分为二，那么正向遍历和反向遍历可以同时进行，并在中间列汇合。在交叉点处，我们可以将两个比对得分相加；中间列中得分最大的单元格必然位于整体最优路径上。

我们可以更正式、更定量地描述这个过程。首先计算在穿过第$\frac{n}{2}^{\text{th}}$列时位于最优路径上的行索引$u \in \{1, \ldots, m\}$。对于$1 \leq i \leq m$和$\frac{n}{2} \leq j \leq n$，令$C_{i,j}$表示在穿过第$\frac{n}{2}^{\text{th}}$列时位于通往$F_{i,j}$的最优路径上的行索引。然后，当我们从左到右更新F的列时，我们也可以从左到右更新C的列。因此，在$O(mn)$时间和$O(m)$空间中，我们能够计算得分$F_{m,n}$以及$C_{m,n}$，它等于在穿过第n列时位于最优路径上的行索引$u \in \{1, \ldots, m\}$

$\frac{n}{2}$第 列。

现在分治的思想开始发挥作用。我们对F的左上$u \times \frac{n}{2}$子矩阵重复上述过程，并对F的右下$(m-u) \times \frac{n}{2}$子–矩阵也重复上述过程。这可以使用$O(m+n)$分配的线性空间来完成。左上子矩阵的运行时间为$O(\frac{un}{2})$，右下子矩阵的运行时间为$O(\frac{(m-u)n}{2})$，两者相加得到运行时间$O(\frac{mn}{2}) = O(mn)$。

我们对F的越来越小的子矩阵重复上述过程，同时收集越来越多具有最优得分的比对条目。总运行时间为$O(mn)+O(\frac{mn}{2})+O(\frac{mn}{4})+\ldots = O(2mn) = O(mn)$。因此，在不牺牲总体运行时间（至多相差一个常数因子）的前提下，分治法导向了一个线性空间的解决方案（另见第3讲中的第??节）。

2.6 Multiple alignment

2.6.1 Aligning three sequences

既然我们已经了解了如何对一对序列进行比对，自然而然会想到将此概念扩展至*multiple*序列。假设我们希望找到3个序列的最佳比对方式，应该如何进行呢?

回想一下，当我们对齐两个序列S和T时，我们为对齐的最终位置选择三种可能性中的最大值（序列T与间隙对齐，序列S与间隙对齐，或序列S与序列T对齐）：

$$F_{i,j} = \max \begin{cases} F_{i,j-1} + d \\ F_{i-1,j} + d \\ F_{i-1,j-1} + s(S_i, T_j) \end{cases}$$

对于三个序列 S、T 和 U，共有七个 对齐最终位置的可能性。也就是说，有三种方式在最终位置有两个 、一个 、零个 间隙 ，三种方式有一个间隙，以及一种方式使三个序列全部对齐（ $^3 + ^3 + (^3 = 7)$）。现在的更新规则是：1 2 3

$$F_{i,j,k} = \max \begin{cases} F_{i-1,j,k} + s(S_i, -, -) \\ F_{i,j-1,k} + s(-, T_j, -) \\ F_{i,j,k-1} + s(-, -, U_k) \\ F_{i-1,j-1,k} + s(S_i, T_j, -) \\ F_{i-1,j,k-1} + s(S_i, -, U_k) \\ F_{i,j-1,k-1} + s(-, T_j, U_k) \\ F_{i-1,j-1,k-1} + s(S_i, T_j, U_k) \end{cases}$$

其中 s 是描述间隙、匹配和错配得分的函数。

然而，这种方法在我们要比对的序列数量上是指数级的。如果我们有 k 条长度为 n 的序列，使用 k 维动态规划矩阵计算最优比对需要 $O((2n)^k)$ 时间（因子 2 源于一个 k 维立方体有 2^k 个顶点，因此对于得分矩阵中的每个条目，我们需要取 $2^k -$ 个相邻单元格的最大值）。可以想象，随着序列数量的增加，该算法很快变得不切实际。

2.6.2 Heuristic multiple alignment

一种常用的多序列比对方法称为*progressive multiple alignment*。假设我们已知每条序列之间的进化树关系。然后，我们首先对亲缘关系最近的两条序列进行两两比对。这一初始比对称为*seed alignment*。接着，我们将下一条最接近种子序列的序列进行比对，并用这一新的比对结果替换种子序列。这一过程持续进行，直到生成最终比对结果。

在实践中，我们通常并不知道进化树（或{v*}），这种技术通常与某种聚类算法配合使用，该算法可能采用低分辨率的相似度度量来生成树的估计。

虽然这种启发式方法的运行时间比以前的方法有了很大改善（序列数量的多项式而非指数），但我们再也无法保证最终比对是最优的。

注意，我们尚未解释如何将序列与现有比对进行比对。一种可能的方法是将新序列与种子比对中已有的每个序列进行成对比对（我们假设种子比对中任何已经是空位的位置将保持为空位）。然后，我们可以基于最佳成对比对将新序列添加到种子比对中（这种方法先前由Feng和Doolittle[4]描述过）。或者，我们可以设计一个函数来评分一个序列与另一个比对的比对（这类评分函数通常基于每个位置上分数的成对总和）。

设计更好的多序列比对工具是一个活跃的研究领域。第2.9节详细介绍了该领域当前的一些工作。

2.7 Current Research Directions

2.8 Further Reading

2.9 Tools and Techniques

Lalign 查找两个序列之间的局部比对。Dotlet 是一个基于浏览器的 Java 小程序，用于以点阵形式可视化两个序列的比对。

以下工具可用于多序列比对：

- Clustal Omega - 一种多序列比对程序，它使用种子指导树和HMM轮廓-轮廓技术来生成比对。[10]
- MUSCLE - 通过对数期望进行多序列比较[3]
- T-Coffee——允许您结合多种比对方法获得的结果[2]
- MAFFT - （使用快速傅里叶变换的多重比对）是一个高速多序列比对程序[5]
- Kalign - 一种快速准确的多种序列比对算法[9]

2.10 What Have We Learned?

2.11 Appendix

2.11.1 Homology

序列比对的关键目标之一是在基因组中识别同源序列（例如基因）。同源的两条序列在进化上相关，具体而言是源自共同祖先。同源体的两种主要类型是直系同源和旁系同源（参见图2.14[11]）。还存在其他形式的同源性（例如异源同源），但它们不在本笔记的讨论范围内。

Orthologs 源于物种形成事件，导致两个生物体拥有同一基因的副本。例如，当一个物种A分化成两个物种B和C时，物种B和C中的某些基因源自物种A中的一个共同基因，且B和C中的这些基因是直系同源的（这些基因继续独立进化，但仍执行相同的相对功能）。

Paralogs 由物种内的复制事件产生。例如，当某个物种A中发生基因复制时，该物种拥有一个原始基因B和一个基因拷贝B′，基因B和B′是旁系同源的。

通常，两个物种之间的直系同源序列比旁系同源序列彼此关系更密切。这是因为直系同源通常（尽管并非总是）随时间保留功能，而旁系同源则往往随时间发生变化，例如通过特化基因的（亚）功能或演化出新功能。因此，在衡量进化相关性时，确定直系同源序列通常比识别旁系同源序列更为重要。

2.11.2 Natural Selection

自然选择这个主题太大，无法用短短几段话有效概括；因此，本附录改为介绍三种广泛类型的自然选择：正选择、负选择和中性选择。

- *Positive selection* 当一种特征在进化上具有优势并提高了个体的适应度，使得拥有该特征的个体更有可能拥有（健壮的）后代时，就会出现这种情况。它通常与新特征的发展相关联。

[11] R.B. - BIOS 60579

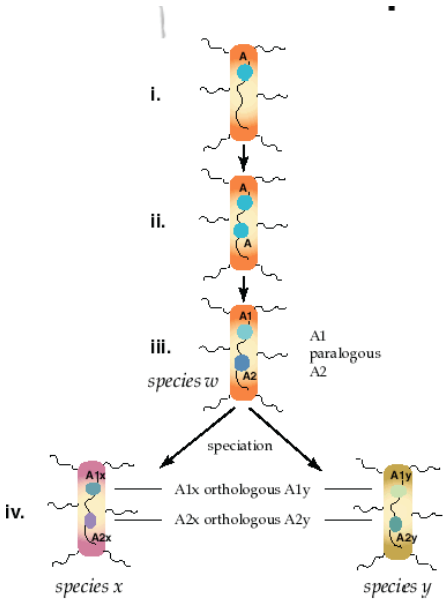

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图2.14：直系同源和旁系同源序列

- *Negative selection* 当某一性状在进化上不利并降低个体适应度时就会发生。负选择的作用是减少那些降低物种适应度的等位基因的普遍性。负选择也被称为净化选择，因为它倾向于“净化”等位基因，直到群体中只存在最成功的等位基因。

- *Neutral selection* 描述了随机发生的进化，这是由于等位基因不影响个体适应度的结果。在没有选择压力的情况下，不会发生正向或负向选择，其结果就是中性选择。

2.11.3 Dynamic Programming v. Greedy Algorithms

动态规划和贪心算法有些相似，了解两者之间的区别是很有必要的。通常可以使用动态规划解决的问题是优化问题，它们表现出两个特征：

1. **optimal substructure** 和
2. **overlapping subproblems**。

贪心算法可解决的问题需要同时具备这两个特征以及(3) **greedy choice property**。在处理“实际”问题时，通常容易判断其是否满足(1)和(2)，但难以确定其是否必须具有贪心选择性质。局部最优选择是否能产生全局最优解并不总是显而易见的。

对于计算生物学家来说，关于是否采用动态规划还是贪婪编程，有两点值得注意。首先，如果一个问题可以通过贪婪算法解决，那么它也可以通过动态规划解决，但反之则不然。其次，允许贪婪算法的问题结构通常不会出现在计算生物学中。

为了阐明第二点，考虑使贪婪编程得以运作的结构或许有所助益，但此类讨论会偏离主题太远。有兴趣的学生（最好具备数学背景）应当研究拟阵和贪心结构，这些是具有贪婪选择性质的结构。就我们的目的而言，我们只需指出，生物学问题通常涉及的实体高度系统化，并且大多数问题中几乎没有理由怀疑存在足以采用贪婪算法的充分结构。

2.11.4 Pseudocode for the Needleman-Wunsch Algorithm

第一个问题集中的第一个问题要求你完成Needleman-Wunsch (NW) 算法的一个实现，并且该算法的Python工作代码被故意省略。相反，本附录在单一位置总结了NW算法的一般步骤（第2.5节）。

问题：给定两个长度分别为 m 和 n 的序列 S 和 T，一个匹配得分的替换矩阵 vU，以及空位罚分 G，确定 S 和 T 的最优比对及该比对的得分。

算法：

1. 创建两个 $m+1$乘$n+1$ 矩阵 A 和 B。A 将是评分矩阵，B 将是回溯矩阵。矩阵 A 的条目 (i, j) 将保存序列 $S[1, \ldots, i]$ 和 $T[1, \ldots, j]$ 的最优比对得分，而矩阵 B 的条目 (i, j) 将保存指向构建最优比对的条目的指针。

2. 初始化得分矩阵A的第一行和第一列，使得得分考虑到间隙惩罚，并以显而易见的方式初始化回溯矩阵B的第一行和第一列。

3. 以某种合理的顺序遍历矩阵A的元素(i, j)，利用元素$(i-1, j-1)$、$(i-1, j)$和$(i, j-1)$确定序列$S[1, \ldots, i]$与$T[1, \ldots, j]$的最优比对。将矩阵B中的指针设置为构建(i, j)处最优比对的对应元素。

4. 一旦矩阵A和B的所有条目填写完毕，最优对齐的得分可在矩阵A的条目（m, n）中找到。

5. 通过从矩阵B的条目(m, n)开始，沿着指针路径至矩阵B的条目(0, 0)结束，构建最优对齐。

Bibliography

[1] Thomas H. Cormen、Charles E. Leiserson、Ronald L. Rivest 和 Clifford Stein。*Introduction to Algorithms*。麻省理工学院出版社，伦敦，第三版，1964年。

[2] Paolo Di Tommaso, Sebastien Moretti, Ioannis Xenarios, Miquel Orobitg, Alberto Montanyola, Jia-Ming Chang , Jean-François Taly, and Cedric Notredame. T-Coffee：一种利用结构信息和同源扩展进行蛋白质和RNA序列多序列比对的网络服务器。*Nucleic Acids Research*, 39(Web Server issue):W13–W17, 2011.

[3] Robert C Edgar. MUSCLE：高精度高通量的多序列比对。*Nucleic acids research*, 32(5):1792–7, 2004年1月。

[4] D F Feng 和 R F Doolittle. 渐进序列比对作为正确系统发育树的前提。*Journal of Molecular Evolution*, 25(4)：351–360，1987年。

[5] Kazutaka Katoh、George Asimenos 和 Hiroyuki Toh。使用 MAFFT 进行 DNA 序列的多重比对。*Methods In Molecular Biology Clifton Nj*, 537:39–64, 2009。

[6] John D. Kececioglu 和 David Sankoff。定向染色体倒位距离的有效边界。在*Proceedings of the 5th Annual Symposium on Combinatorial Pattern Matching*中，CPM '94，第307-325页，伦敦，英国，英国，1994年。Springer-Verlag。

[7] Manolis Kellis. 动态规划练习题. http://people.csail.mit.edu/bdean/6.046/dp/, 2010年9月.

[8] Manolis Kellis, Nick Patterson, Matthew Endrizzi, Bruce Birren, 和 Eric S Lander. 酵母物种的测序与比较以识别基因和调控元件. *Nature*, 423(6937):241–254, 2003.

[9] Timo Lassmann 和 Erik L L Sonnhammer. Kalign——一种准确快速的多序列比对算法. *BMC Bioinformatics*, 6(1):298, 2005.

[10] Fabian Sievers, Andreas Wilm, David Dineen, Toby J Gibson, Kevin Karplus, Weizhong Li, Rodrigo Lopez, Hamish McWilliam, Michael Remmert, Johannes Söding, Julie D Thompson, and Desmond G Higgins. 使用Clustal Omega快速、可扩展地生成高质量蛋白质多序列比对。*Molecular Systems Biology*, 7(539):539, 2011. [11] Zhaolei Zhang and Mark Gerstein. 从假基因推断的人类基因组中核苷酸替换、插入和缺失的模式。
Nucleic Acids Research, 31(18):5338–5348, 2003.

CHAPTER

THREE

快速序列比对与数据库搜索

Heather Sweeney（2015年9月20日）Eric Bartel
l（2015年9月20日）Kathy Lin（2014年9月11
日）Maria Rodriguez（2011年9月13日）Rushil
Goel（2010年9月16日）Eric Eisner -Guilhelm
Richard（2009年9月17日）Tural Badirkhnali（
2008年9月11日）

Figures

3.1 全局比对 . . . . . 44 3.2 全局比对 . . . . . 45 3.3 局部比对 . . . . . 46 3.4 用于检测重排的局部比对 . . . . . 46 3.5 半全局比对 . . . . . 46 3.6 有界空间计算 . . . . . 48 3.7 用于最优比对得分的线性空间计算 . . . . . 48 3.8 用于寻找最优比对的节省空间优化 . . . . . 48 3.9 分治法 . . . . . 49 3.10 朴素 Karp-Rabin 算法 . . . . . 50 3.11 最终 Karp-Rabin 算法 . . . . . 51 3.12 鸽巢原理 . . . . . 52 3.13 BLAST 算法 . . . . . 53 3.14 有指导的字符串匹配 . . . . . 56 3.15 最终字符串匹配 . . . . . 56 3.16 核苷酸匹配得分 . . . . . 57 3.17 氨基酸的 BLOSUM62 矩阵 58

3.1 Introduction

在上一章中，我们使用动态规划来计算$O(n^2)$中的序列比对。特别是，我们学习了全局比对算法，该算法在核苷酸水平上将完整序列相互匹配。当已知序列同源（即序列来自共享共同祖先的生物体）时，我们通常应用此方法。

发现序列比对在生物学上的意义在于能够推断出最有可能发生的一系列进化事件，如点突变/错配和间隙（插入或删除），这些事件是为了将一个序列转化为另一个序列。为此，我们首先假设转化集包含

最低成本对应最可能的变换序列。通过为每种变换类型（错配或空位）分配反映其各自进化难度的成本，寻找最优比对就归结为寻找导致总体成本最低的变换集合。

我们通过使用一种称为Needleman-Wunsch算法的动态规划算法来实现这一点。动态规划利用最优子结构将问题分解为相似的子问题。寻找序列比对的问题可以很好地表示为动态规划算法，因为比对得分是可加的，这意味着可以通过递归地寻找较小子序列的比来找到较大序列的比对。得分存储在一个矩阵中，一个序列对应列，另一个序列对应行。每个单元格表示对应于该单元格行和列的两个核苷酸之间所需的转换。通过回溯动态规划矩阵（如下所示）来恢复比对。动态规划方法优于贪心算法，后者在每一步简单地选择最小成本的转换，因为贪心算法不能保证整体结果会给出最优或最低成本的比对。

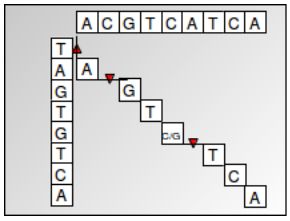

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图3.1：全局比对

总结用于全局比对的Needleman-Wunsch算法：

我们计算矩阵中每个单元格对应的分数，并在该步骤记录我们的选择（记忆化），即顶部、左侧或对角线单元格中哪一个导致了当前单元格的最大分数。我们最终得到一个矩阵，其中每个单元格位置都充满了最优分数，并且每个单元格都有指针，反映了导致该特定单元格的最优选择。

然后，我们可以通过从右下角的单元格（其中包含将一个完整序列与另一个序列对齐的得分）回溯，沿着反映局部最优选择的指针，进而构建与矩阵中所走最优路径相对应的对齐方式，从而恢复最优对齐。

Needleman-Wunsch 算法的运行时间为 $O(n^2)$，因为对于矩阵中的每个单元格，我们进行有限量的计算。我们使用已计算出的分数来计算3个值，然后取这些值的最大值来找到对应于该单元格的分数，这是一个常数时间（$O(1)$）操作。

为了保证正确性，必须计算矩阵中每个单元格的成本。最优比对可能由开始部分的不良比对（包括空位和错配）和随后的许多匹配组成，使其成为整体上最好的比对。这些情况穿越了比对矩阵的边界。因此，为了保证全局最优比对，我们需要计算矩阵的每一个条目。

全局比对适用于比较被认为同源的两个序列。对于比较存在重排或倒位的序列，或者将新测序的基因与已知基因组中的参考基因进行比对（即数据库搜索），则不太适用。在实践中，如果我们知道某些比对明显次优，通常也可以限制需要探索的比对空间。

本章将讨论其他形式的比对算法以应对此类场景。首先将介绍用于局部比对的Smith-Waterman算法，该算法用于比对子序列而非完整序列，与用于全局比对的Needleman-Wunsch算法形成对比。随后，将概述哈希和半数值方法，如用于寻找最长

(连续的)核苷酸共同子串。这些算法在BLAST程序中被实现并扩展用于不精确匹配，BLAST是计算生物学中引用最多、最成功的工具之一。最后，本章将介绍用于数据库搜索的BLAST，以及序列比对的概率基础，以及如何将比对得分解释为似然比。

大纲:

1. **Introduction**
   - 全局比对（Needleman-Wunsch）回顾
2. **Global alignment vs. Local alignment vs. Semi-global alignment**
   - 全局比对（Needleman-Wunsch）、局部比对（Smith-Waterman）与半全局比对的初始化、终止和更新规则
   - 可变间隙惩罚，算法加速
3. **Linear-time exact string matching**
   - Karp-Rabin 算法与半数值方法
   - 哈希函数与随机算法
4. **The BLAST algorithm and inexact matching**
   - 邻域搜索哈希
   - 两次打击爆破与梳状哈希
5. **Pre-processing for linear-time string matching**
   - 基础预处理
   - 后缀树
   - 后缀数组
   - Burrows-Wheeler 变换
6. **Probabilistic foundations of sequence alignment**
   - 错配罚分、BLOSUM 和 PAM 矩阵
   - 比对得分的统计显著性

3.2 Global alignment vs. Local alignment vs. Semi-global alignment

一个**global alignment**被定义为两个字符串s和t的$end\text{-}to\text{-}end$对齐。

字符串 s 和 t 的 **local alignment** 是 s 的 $substrings$ 与 t 的子串的对齐。

通常用于寻找高度局部相似性的区域。我们通常更关注寻找局部对齐，因为我们通常不知道基因的边界，而且基因中可能只有一小部分结构域是保守的。在这种情况下，我们并不希望强制序列的其他（可能非同源的）部分也进行对齐。在搜索大染色体中的小基因或检测长序列是否可能发生重排时，局部对齐也很有用（图4）。

字符串s和t的**semi-global alignment**是s的一个子串与t的一个子串的比对。

这种对齐方式在重叠检测中很有用，当我们不希望惩罚起始或结束处的空位时。为了找到半全局对齐，关键的区分在于将顶行和最左列初始化为零，并在底行或最右列结束。

算法如下:

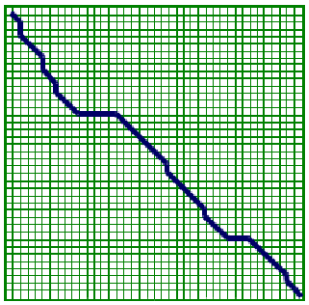

图3.2：全局比对

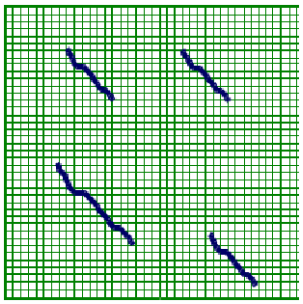

图3.3：局部对齐

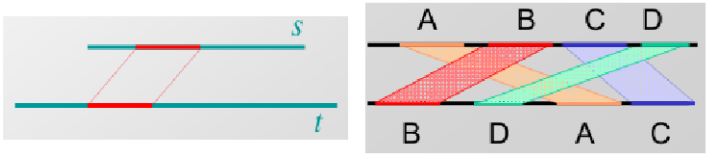

图3.4：检测重排的局部比对

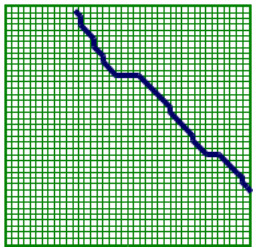

图3.5：半全局比对

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

$$
\begin{aligned}
Initialization \quad &: \quad F(i,0) = 0 \\
&\qquad\quad F(0,j) = 0 \\
Iteration \quad &: \quad F(i,j) = \max \begin{cases} F(i-1,j) - d \\ F(i,j-1) - d \\ F(i-1,j-1) + s(x_i, y_j) \end{cases} \\
Termination \quad &: \quad Bottom\ row\ or\ Right\ column
\end{aligned}
$$

3.2.1 Using Dynamic Programming for local alignments

在本节中，我们将了解如何通过微调上一章讨论的用于寻找全局对齐的Needleman-Wunsch算法，来找到局部对齐。

为了找到全局比对，我们使用了以下动态规划算法（Needleman-Wunsch算法）：

$$
\begin{aligned}
Initialization &: \quad F(0,0) = 0 \\
Iteration &: \quad F(i,j) = \max \begin{cases} F(i-1,j) - d \\ F(i,j-1) - d \\ F(i-1,j-1) + s(x_i, y_j) \end{cases} \\
Termination &: \quad Bottom\ right
\end{aligned}
$$

为了找到局部比对，我们只需对Needleman-Wunsch算法稍作修改，每当现有比对得分变为负数时，就重新开始并寻找新的局部比对。由于局部比对可以从任意位置开始，我们将矩阵的第一行和第一列初始化为零。迭代步骤经过修改，加入了一个零，以包含开始新比对可能比有许多错配更经济的情况。此外，由于比对可以在任意位置结束，我们需要遍历整个矩阵来寻找最优比对得分（不仅仅是在右下角）。算法的其余部分，包括回溯，保持不变，其中回溯指示在零处结束，标志着最优比对的开始。

这些变化产生了以下用于局部比对的动态规划算法，这也被称为:

$$
\begin{aligned}
Initialization &: \quad F(i,0) = 0 \\
&\qquad\quad F(0,j) = 0 \\
Iteration &: \quad F(i,j) = \max \begin{cases} 0 \\ F(i-1,j) - d \\ F(i,j-1) - d \\ F(i-1,j-1) + s(x_i, y_j) \end{cases} \\
Termination &: \quad Anywhere
\end{aligned}
$$

3.2.2 Algorithmic Variations

有时运行这些比对算法在时间和空间上可能都很昂贵。因此，本节介绍一些在实践中效果良好的算法变体，以节省时间和空间。

节省时间的一种方法是限制待探索的对齐空间。其思路是良好的对齐通常接近矩阵的对角线。因此，我们只需探索距离对角线k半径内的矩阵单元。这种修改的问题在于这是一种启发式方法，可能导致次优解，因为它未包含本章开头提到的边界情况。尽管如此，这在实际应用中效果很好。此外，根据评分矩阵的性质，有可能论证有界空间算法的正确性。该算法需要$O(k*m)$空间和$O(k*m)$时间。

我们之前看到，为了计算最优解，我们需要在每个单元格中存储对齐分数以及反映导致每个单元格的最优选择的指针。然而，如果我们只对*optimal alignment score*感兴趣，而不关心实际的对齐本身，有一种方法可以在节省空间的同时计算解。为了计算任何单元格的分数，我们只需要当前单元格上方、左侧和左对角线单元格的分数。通过保存我们正在计算分数的前一列和当前列，可以在线性空间内计算出最优解。

如果使用分治原理，我们实际上可以在线性空间内找到*optimal alignment*。其思路是计算矩阵两侧的最优对齐，即从左到右以及从右到左。设$u = \lfloor \frac{n}{2} \rfloor$。假设我们能确定$v$，使得单元格$(u, v)$位于最优

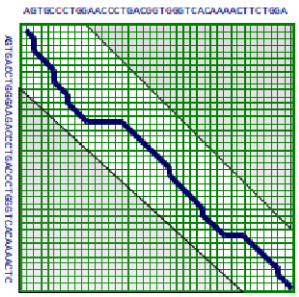

图3.6：有界空间计算

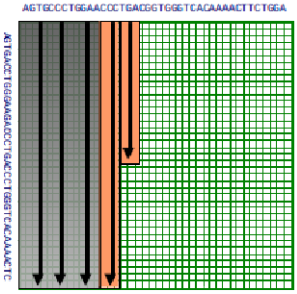

图3.7：最优对齐得分的线性空间计算

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

对齐路径。这意味着 v 是比对穿过矩阵列 u 的行。我们可以通过将 (0,0) 到 (u, v) 的最优比对与 (u, v) 到 (m, n) 的最优比对连接起来，找到最优比对，其中 m 和 n 是右下角单元格（注意：使用我们的评分方案，连接子比对的对齐分数是可加的。因此，我们将问题隔离为 DP 矩阵左上角和右下角的两个独立问题。然后我们可以递归地将这些子问题不断划分为更小的子问题，直到我们降到对齐 0 长度序列，或者我们的问题足够小，可以应用常规 DP 算法。为了找到 v，即最优比对穿过的中间列中的行，我们只需将该列的传入和传出分数相加。

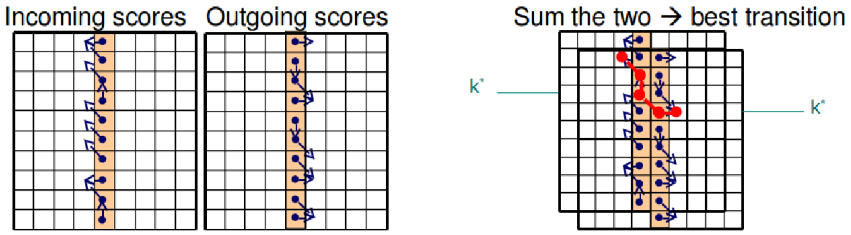

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图3.8：寻找最优对齐的空间节省优化

这种分治方法的一个缺点是运行时间较长。然而，运行时间并没有显著增加。由于v可以通过一次常规DP遍历找到，我们可以在$O(mn)$时间内为每一列找到v，并且使用线性空间，因为这一步不需要追踪回溯指针。然后通过应用分治方法，子问题所需时间减半，因为我们只需沿最优对齐路径对角线追踪单元格（上一步矩阵的一半）。这导致总运行时间为$O(mn(1 + \frac{1}{2} + {}^{1}$。

$$- \quad - + \ldots)) = O(2MN) = O(mn)$$ (使用4几何级数求和)，给我们一个二次运行时间（比以前慢两倍，但仍然是相同的渐进行为）。总时间永远不会超过$2MN$ (先前算法的两倍时间)。虽然运行时间增加了一个常数因子，但分治方法的一大优势是空间显著减少到$O(N)$。

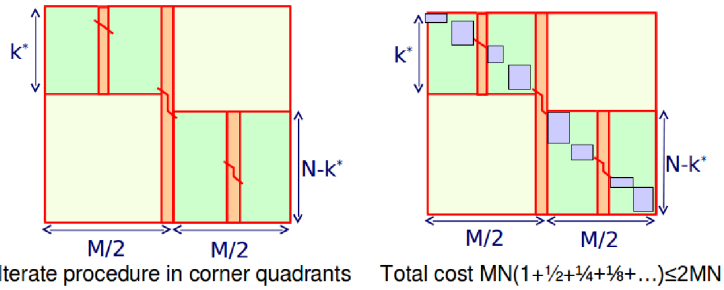

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图3.9：分而治之

Q: 为什么不使用有界空间变体而非线性空间变体，以同时获得线性时间和线性空间?

A: 有界空间变化是一种启发式方法，实践中可能效果良好，但不能保证最优对齐。

3.2.3 Generalized gap penalties

空位罚分决定了对子序列计算的得分，从而影响选择哪个比对。正常模型是使用一个罚分，其中长度为 k 的空位序列中的每个单独空位都以值 p 等量罚分。这种罚分可以建模为 $w(k) = k * p$。

根据情况，对于不同长度的间隙，采取不同的惩罚方式可能是个好主意。一个例子是，随着间隙大小的增长，增量惩罚呈二次方递减。这可以建模为$w(k) = p + q * k + r * k^2$。然而，权衡之处在于，使用更复杂的间隙惩罚函数会显著增加运行时间，从而带来额外成本。

这种成本可以通过使用更简单的间隙惩罚函数近似值来减轻。有一个不错的折中方案：开始一个间隙时有一个固定的惩罚，而向间隙中添加元素则有线性成本；这可以用 $w(k) = p + q * k$ 来建模。

你也可以考虑更复杂的函数，这些函数会考虑到蛋白质编码序列的特性。在蛋白质编码区比对的情况下，长度为模3的间隙可以受到较小的惩罚，因为它不会导致移码。

3.3 Linear-time exact string matching

虽然我们已经研究了各种形式的比对以及用于找到此类比对的算法，但这些算法对于某些目的来说还不够快。例如，我们可能有一个100个核苷酸的序列，想要在整个基因组中搜索它，而基因组可能超过十亿个核苷酸长。在这种情况下，我们需要一种运行时间取决于查询序列长度的算法，可能还需要对数据库进行一些预处理，因为对每个查询都处理整个基因组会极其缓慢。对于这类问题，我们进入了随机化算法的领域，在这里我们不再担心最坏情况下的性能，而是更关注确保算法在期望情况下是线性的。当寻找一个序列的精确（连续）匹配时，Karp-Rabin算法将这种匹配数值化解释。这个问题还有许多其他解决方案，其中一些可以确保问题在最坏情况下也是线性的，例如：Z算法、Boyer-Moore和Knuth-Morris-Pratt算法、基于后缀树、后缀数组等的算法（在“第3讲附录”幻灯片中讨论）。

3.3.1 Karp-Rabin Algorithm

该算法试图将特定模式与字符串匹配，这是数据库搜索的基本原理。问题如下：在长度为 n 的文本 T 中，我们寻找长度为 m 的模式 P。字符串映射为数字以便快速比较。该算法的朴素版本涉及映射字符串 P 并且

m长度子串Ts分别转化为数字x和y，沿T在每个偏移量滑动x，直到数字匹配。

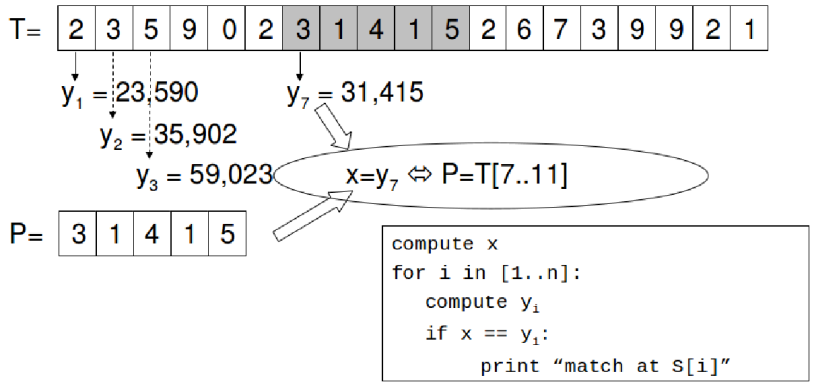

图3.10：朴素Karp-Rabin算法

然而，可以看出该算法如所述实际上是两个原因造成的非线性：

1. 计算每个 y_i 所需时间超过常数时间（实际上，如果我们针对每个子序列从头开始天真地计算每个数字，则是线性的）2. 如果数字非常大，比较 x 和 y_i 可能会很昂贵，这可能在待匹配的模式非常长时发生

为了使算法更快，我们首先修改了在常数时间内计算 y_i 的过程，通过使用先前计算出的数字 $y_i - 1$。我们可以通过一些位操作来实现这一点：用减法移除高位，用乘法将字符左移，以及用加法追加低位数字。例如，在图10中，我们可以通过以下方式从 y_1 计算出 y_2：

- 删除最高位：$23590 \bmod 10000 = 3590$
- 左移：$3590 * 10 = 35900$
- 添加新的低位数字：$35900 + 2 = 35902$

我们接下来的问题出现在有非常长的序列需要比较时。这导致我们的计算涉及非常大的数字，从而不再保持线性时间。为了使数字保持较小，以确保高效比较，我们在模p下进行所有计算（一种哈希形式），其中 p 反映了可用于存储数字的字长，但足够小，使得 x 和 y_i 之间的比较可以在常量时间内完成。

：使用函数将数据值映射到固定大小的数据集。
由于我们使用了哈希技术，将映射至模p的数空间时，可能会因哈希碰撞而产生误报，因此我们修改算法，通过显式验证报告的哈希值命中情况来处理这类误报。于是，Karp-Rabin算法的最终版本为：

要计算Karp-Rabin算法的期望运行时间，我们必须考虑验证的预期成本。如果我们能证明虚假命中的概率很小，那么期望运行时间就是线性的。

Questions:

Q: 如果字母表中有超过10个字符怎么办?

A: 在这种情况下，我们只需通过包含更多位数，即采用非10的基数（例如基数256）来运行上述算法即可。但通常，在使用哈希时，字符串会被映射到数字空间中，因此字符串是以数值形式解释的。

Q: 我们如何将其应用于文本?

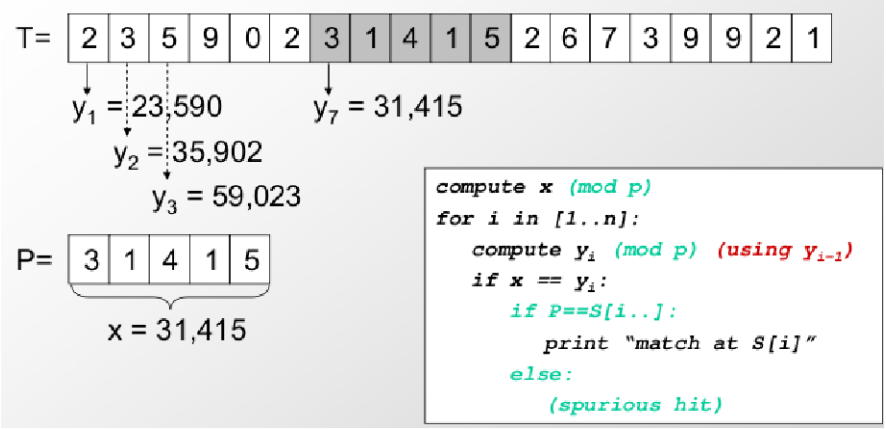

图3.11：最终Karp-Rabin算法

A: 使用哈希函数将文本转换为更易于比较的数字。例如，如果使用整个字母表，可以给字母分配0到25之间的值，然后像一串数字一样使用它们。

Q: 为什么使用模数会减少计算时间?

A: 模运算可以应用于计算中的每个单独部分，同时保持答案不变。例如：假设我们当前的文本是“314152”，词长为5。在完成对“31415”的第一次计算后，我们将窗口移过来进行第二次计算，即：$14152 = (31415 - 3 * 10000) * 10 + 2(mod 13) = (7 - 3 * 3) * 10 + 2(mod 13) = 8(mod 13)$ 这个计算现在可以在线性时间内完成。

Q: 算法中是否有针对不精确匹配的规定?

A: 上述算法仅在查询序列与数据库之间存在完全相似区域时有效。然而，我们稍后将探讨的BLAST算法扩展了上述思想，纳入了在查询序列的生物学意义邻域内搜索的概念，以考虑一些不精确匹配。这是通过在数据库中不仅搜索查询序列，还搜索该序列的一些变体，这些变体最多包含固定数量的变化来实现的。

一般来说，为了减少对诸如非常长的数字或字符串等参数进行操作的时间，有必要将数值范围缩减到更为可控的程度。哈希是一种通用的解决方案，它涉及将来自大宇宙U的字符串/数字键k映射到位于较小范围，比如[1...m]内的键的哈希值$h(k)$。有多种哈希函数可供使用，它们各自拥有不同的理论和实用特性。我们需要哈希满足的两个关键属性是:

1. 若 $x = y$，则 $h(x) = h(y)$ 的可复现性。这对于我们的映射能够成立至关重要。

2. 均匀输出分布 这意味着无论输入分布如何，输出分布都是均匀的。即，如果$x! = y$，则 $P(h(x) = h(y)) = 1/m$，与输入分布无关。这是一个理想的特性，可以减少虚假命中的机会。

一个有趣的想法是，从邻域搜索的角度来看，具有局部敏感性的哈希函数可能很有用，这样U中彼此接近的点会被哈希函数映射到相近的点。随机投影的概念，作为BLAST算法的一种扩展，正是基于这一思想。此外，需要注意的是，取模并不满足上述性质2，因为可能存在这样的输入分布（例如，所有关于

取模运算会导致大量碰撞。然而，选择一个随机数作为模运算的除数可以避免许多碰撞。

使用哈希增加了分析算法的复杂性，因为现在我们需要通过包含验证成本来计算预期运行时间。为了证明预期运行时间是线性的，我们需要证明虚假命中的概率很小。

3.4 The BLAST algorithm (Basic Local Alignment Search Tool)

BLAST算法研究的是序列数据库搜索问题，其中我们有一个查询，它是一个新序列，还有一个目标，它是一组许多旧序列，我们感兴趣的是知道目标序列中哪些（如果有的话）与查询相关。BLAST的关键思想之一是它不要求各个比对是完美的；一旦识别出初始匹配，我们之后就可以微调匹配，以找到一个满足阈值分数的良好比对。此外，BLAST利用了数据库搜索问题的一个显著特征：大多数目标序列将与查询序列完全不相关，只有极少数序列会匹配。

然而，正确（近乎完美）的比对将具有长的完美匹配的核苷酸子串。例如，如果我们寻找长度为100的序列，并且要拒绝那些低于90%同一性的匹配，我们无需查看那些甚至不包含少于10个连续匹配核苷酸的序列。我们基于鸽巢原理做出这一假设：如果将m个物品放入n个容器中且m{v*}n，则至少有两个物品必须放入其中一个容器中。

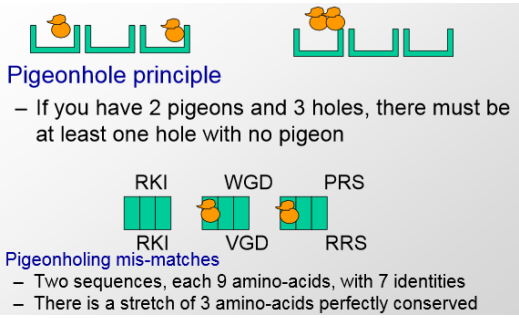

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图3.12：鸽巢原理

此外，在生物学中，功能性DNA更有可能被保守，因此我们发现的突变实际上并不会随机分布，而是会聚集在DNA的非功能区域，同时使长段的功能性DNA保持不变。因此，由于鸽巢原理以及高度相似的序列会具有相似的长片段，我们可以预筛选序列以寻找共同的长片段。BLAST中就使用了这一思想，它将查询序列分解为W-mer，并通过将我们的种子限制为满足某一阈值的邻域内的$W-mers$，来预筛选目标序列中所有可能的$W-mers$。

BLAST 另一个能加速重复查询的方面是能够离线预处理一个大型 DNA 数据库。预处理后，在长度为 n 的数据库中搜索长度为 m 的序列仅需 $O(m)$ 时间。BLAST 所基于的关键见解是哈希和邻域搜索的思想，即使没有精确匹配，也能搜索 $W-mers$。

3.4.1 The BLAST algorithm

步骤如下：

1. 将查询分割成长度为W (的重叠单词W-$mers$)
2. 为每个词找到相似词的“邻域”（见下文）

3. 在哈希表中查找邻域中的每个词，以找到数据库中每个词出现的位置。将这些称为*seeds*，并令S为种子集合。

4. 在S中扩展种子，直到对齐得分下降到低于某个阈值X。

5. 报告整体得分最高的匹配项

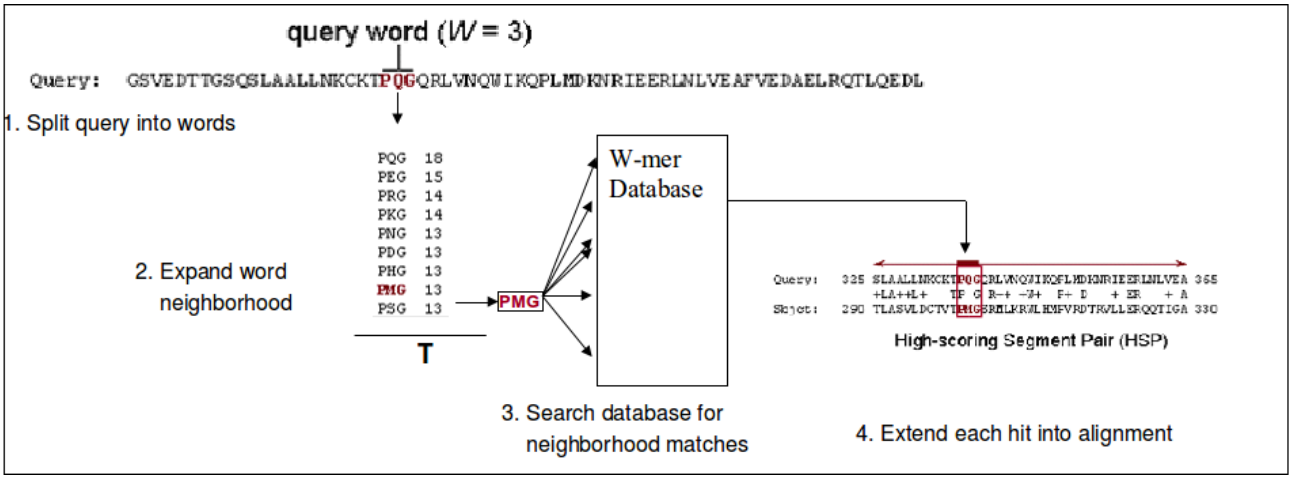

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图 3.13：BLAST 算法

BLAST的预处理步骤确保所有W个核苷酸的子串都将被包含在我们的数据库（或哈希表）中。这些被称为数据库的W-*mers*。如同步骤1，我们首先通过查看查询中所有连续W个核苷酸的子串来分裂查询。为了找到这些W-*mers*的邻域，我们随后通过轻微改变这些序列并计算它们与原始序列的相似度来修改它们。我们在邻域中逐步生成越来越不相似的词，直到我们的相似度度量降至某个阈值T以下。这赋予我们灵活性，以找到并非恰好有W个连续匹配字符的匹配项，但这些匹配项有足够的匹配以被认为是相似的，即达到一定的阈值分数。

然后，我们在哈希表中查找所有这些单词，以找到连续匹配的W个核苷酸的种子。接着，我们使用Smith-Waterman算法进行局部比对，将这些种子扩展以找到我们的比对，直到得分低于某个阈值X。由于我们考虑的区域要短得多，因此这不会像在整个DNA数据库上运行该算法那样慢。

同样有趣的是，注意到BLAST的各种参数对算法性能的影响，涉及运行时间和灵敏度：

- **W** 尽管较大的 W 会导致更少的虚假命中/冲突，从而使其更快，但也存在权衡，即：略为不同的查询序列的较大邻域、较大的哈希表以及过少的命中。另一方面，如果 W 太小，我们可能会得到过多的命中，从而将运行成本推高到种子扩展/比对步骤。

- **T** 如果T更高，算法将更快，但您可能会错过进化上更远的序列。如果比较两个相关的物种，您可以设置较高的T值，因为您期望在相当相似的序列之间找到更多匹配。

- **X** 它的影响与T非常相似，两者都会控制算法的灵敏度。而W和T影响得到的总命中次数，因此极大地影响算法的运行时间，设置非常严格的X尽管W和T不太严格，将导致尝试不符合X严格性的不必要序列，从而产生运行时成本。因此，重要的是要将X的严格性与W和T的严格性相匹配，以避免不必要的计算时间。

3.4.2 Extensions to BLAST

- **Filtering** 低复杂度区域可能导致虚假命中。例如，如果我们的查询包含一串相同核苷酸的副本，比如 AC 的重复或只是 G，而数据库中有一段很长的相同核苷酸，那么将会有许多许多无用的命中。为了防止这种情况，我们可以尝试过滤掉查询中的低复杂度部分，或者我们可以忽略数据库中不合理过度表示的部分。

- **Two-hit BLAST** 这里的思路是使用双重哈希，即不再对单个长W-mer进行哈希，而是对两个短W-mer进行哈希。这使我们能够找到小的相似区域，因为两个较短的W-$mers$匹配的可能性远大于一个长W-mer匹配的可能性。这使我们能够在较小的W下获得更高的灵敏度，同时仍然剔除虚假命中。这意味着我们将花更少的时间尝试扩展实际上并不匹配的匹配项。因此，这使我们能够在保持灵敏度的同时提高速度。

  Q: 对于足够长的W，考虑多于2个更小的W-$mers$是否有意义?

  A: 观察这些 W-$mers$ 的数量如何影响算法的敏感性将会很有趣。这与接下来描述的梳子使用方式相似。

- **Combs** 这是使用非连续的 W-$mers$ 进行哈希的思想。回想一下你的生物学课程，三联体中的第三个核苷酸通常实际上并不影响所代表的氨基酸。这意味着序列中的每个第三个核苷酸不太可能被进化保留，因为它通常无关紧要。因此，我们可能希望寻找除了每个第三个密码子外看起来相似的 W-$mers$ 。这是梳子的一个特定示例。梳子只是一个位掩码，表示在尝试寻找匹配时我们关心哪些核苷酸。我们上面解释了为什么110110110...（忽略每个第三个核苷酸）可能是一个好的梳子，而事实证明它确实如此。然而，其他梳子也有用。选择梳子的一种方法是随机选取一些核苷酸。与其为投影只选择一个梳子，不如随机选择一组这样的梳子，并沿每个梳子投影W-mer，以获得一组查找数据库。然后，查询字符串也可以沿这些梳子随机投影，以便在这些数据库中查找，从而增加找到匹配的概率。这称为随机投影。扩展这一点，一个有趣的最终项目想法是思考在生物学上有意义的不同投影或哈希技术。这项技术的一个补充是分析假阴性和假阳性，并改变梳子以更具选择性。一些探索此搜索增补的论文包括Califino-Rigoutsos'93、Buhler'01和Indyk-Motwani'98。

- **PSI-BLAST** 位置特异性迭代BLAST使用BLAST创建相关蛋白质的概要文件。经过一轮BLAST后，它从多序列比对中更新评分矩阵，然后运行后续轮次的BLAST，迭代更新评分矩阵。它构建隐马尔可夫模型来追踪特定氨基酸的保守性。PSI-BLAST允许检测远缘相关蛋白质。

3.5 Pre-processing for linear-time string matching

BLAST 算法核心的哈希技术是一种强大的字符串快速查找方式。处理整个基因组或一大组基因组需要投入大量时间，$in\ advance$以获得查询序列。一旦获得查询序列，就可以对其进行类似处理，并将其各部分在线性时间内与索引数据库进行搜索比对。

在本节中，我们简要介绍四种额外的数据库预处理方法，用于快速字符串查找，每种方法都具有实践和理论上的重要性。

3.5.1 Suffix Trees

后缀树通过在后缀树中捕获目标序列T的所有后缀，为目标序列T的子串提供了一种强大的树状表示。

Representation of a sequence in a suffix tree

Searching a new sequence against a suffix tree

Linear-time construction of suffix trees

3.5.2 Suffix Arrays

对于许多基因组应用而言，后缀树在内存中的存储成本过高，因此需要更为高效的表示方法。后缀数组正是为了减少后缀树的内存消耗而专门开发的，它能在显著降低空间需求的同时实现相同的目标。

使用后缀数组，可以通过对有序后缀列表进行二分查找来找到任何子串。通过这样探索每个后缀的前缀，我们最终搜索了所有子串。

3.5.3 The Burrows-Wheeler Transform

比后缀树更高效的表示方法是Burrows-Wheeler变换（BWT），它能够以与原字符串相同数量的字符存储整个哈希后的字符串（甚至更紧凑，因为它包含频繁的同聚物字符连续段，更容易压缩）。这有助于使程序运行得更加高效。

我们首先考虑BWT矩阵，它是后缀数组的一种扩展，不仅包含了按排序（字典序）排列的所有后缀，而且在每个从位置i开始的后缀后附加了到位置$i-1$结束的前缀，每一行因此包含了原始字符串的一个完整循环。这使得所有后缀数组和后缀树的操作，即以查询字符串线性时间查找后缀的位置成为可能。

与后缀数组的关键区别在于空间使用，后缀数组即便在内存中存储所有后缀也非常昂贵，而这里仅存储BWT矩阵的最后一列，基于此即可恢复原始矩阵。

可以使用辅助数组来进一步加速，并避免重复查找修改后的后缀数组中每个字符首次出现的操作。

最后，一旦在修改后的字符串（BTW 矩阵的最后一列）中找到数十万个子字符串的位置，这些坐标就可以转换回原始位置，从而通过将转换成本分摊到大量读取操作上来节省运行时间。

BWT 对短字符串匹配算法产生了非常强大的影响，并且几乎所有最快的读取映射工具目前都基于 Burrows-Wheeler 变换。

3.5.4 Fundamental pre-processing

这是处理的一种变体，它具有理论意义，但在生物信息学中的实际应用相对较少。它依赖于Z向量，该向量在每个位置i包含字符串的最长前缀长度，该前缀也与从i开始的子串匹配。这使得能够计算L和R (左和右)向量，这些向量表示包含当前位置i的最长重复子串的结束位置。

3.5.5 Educated String Matching

Z 算法使得线性时间字符串匹配中的 Boyer-Moore 和 Knuth-Morris-Pratt 算法能够轻松计算。这些算法利用每次比较中收集的信息

在匹配字符串时，以改进对$O(n)$的字符串匹配。
朴素算法如下：将其长度为m的字符串逐字符与序列进行比较。比较完整个字符串后，如果有任何不匹配，就移到下一个索引并再次尝试。这个过程在$O(m*n)$时间内完成。

该算法的一个改进是，一旦发现不匹配就停止当前比较。然而，当所比较的字符串与整个序列匹配时，这仍然需要$O(m*n)$时间来完成。

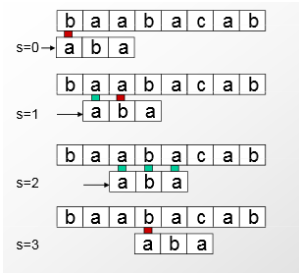

图3.14：经过训练的字符串匹配

关键洞察来自于从待比较字符串的内部冗余中学习，并利用这一点在目标序列上做出更大的偏移。当发生错误时，当前比较中的所有碱基都可以用来将下一次比较所考虑的框架进一步下移。如下所示，这大大减少了所需的比较次数，将运行时间降低到$O(n)$。

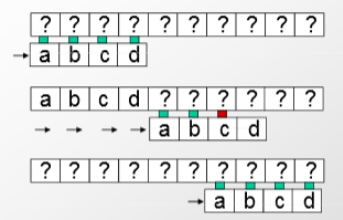

图3.15：最终字符串匹配

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

3.6 Probabilistic Foundations of Sequence Alignment

如上所述，BLAST 算法使用评分（替换）矩阵来扩展 W-*mers* 列表，以便在种子扩展过程中寻找并确定近似匹配的序列。此外，评分矩阵还用于评估比对算法中的匹配或不匹配。但最初我们如何构建这个矩阵？你如何确定全局/局部比对中 $s(x_i, y_j)$ 的值?

评分矩阵背后的理念是，比对得分应当体现两条相似序列同源的概率，即两条有若干共同核苷酸的序列也共享同一祖先的概率。为此，我们考察两种假设之间的似然比。

1. **Hypothesis 1:** – 两个序列之间的比对是偶然的，且序列实际上是不相关的。

2. **Hypothesis 2:** – 这种对齐是由于共同祖先，且这些序列实际上是相关的。

然后，我们根据每个假设计算观察到一种对齐的概率。$Pr(x, y|U)$是在假设x与y不相关的情况下对齐的概率，而$Pr(x, y|R)$是

	A	G	T	C
A	+1	-½	-1	-1
G	-½	+1	-1	-1
T	-1	-1	+1	-½
C	-1	-1	-½	+1

图3.16：核苷酸匹配分数

对齐，假设它们是相关的。然后，我们将对齐分数定义为两者之间似然比的对数：

$$S \equiv \log \frac{P(\mathbf{x}, \mathbf{y}|R)}{P(\mathbf{x}, \mathbf{y}|U)} \tag{3.1}$$

由于对数之和等于乘积的对数，我们可以通过将各个比对的得分相加来得到比对的总体得分。这给出了整个比对的可能性，假设每个单独的比对是独立的。因此，加性矩阵得分恰好给出了两个序列相关而非偶然比对的可能性。更正式地说，考虑蛋白质比对的情况，对于不相关的序列，在 x 和 y 之间具有 n 个残基比对的概率是各个序列概率的简单乘积，因为残基配对是独立的。

也就是说，{v*}

$$\begin{aligned} \mathbf{x} &= \{x_1 \dots x_n\} \\ \mathbf{y} &= \{y_1 \dots x_n\} \\ q_a &= P(\text{amino acid } a) \\ P(\mathbf{x}, \mathbf{y}|U) &= \prod_{i=1}^{n} q_{x_i} \prod_{i=1}^{n} q_{y_i} \end{aligned}$$

对于相关序列，残基配对不再是独立的，因此我们必须使用不同的联合概率，假设每一对对齐的氨基酸都从一个共同祖先进化而来：

$$\begin{aligned} p_{ab} &= P(\text{evolution gave rise to } a \text{ in } \mathbf{x} \text{ and } b \text{ in } \mathbf{y}) \\ P(\mathbf{x}, \mathbf{y}|R) &= \prod_{i=1}^{n} p_{x_i y_i} \end{aligned}$$

然后，两者之间的似然比由下式给出：

$$\begin{aligned} \frac{P(\mathbf{x}, \mathbf{y}|R)}{P(\mathbf{x}, \mathbf{y}|U)} &= \frac{\prod_{i=1}^{n} p_{x_i y_i}}{\prod_{i=1}^{n} q_{x_i} \prod_{i=1}^{n} q_{y_i}} \\ &= \frac{\prod_{i=1}^{n} p_{x_i y_i}}{\prod_{i=1}^{n} q_{x_i} q_{y_i}} \end{aligned}$$

因为我们最终想要计算分数之和　　而概率需要对乘积求和时，我们取乘积的对数，得到一个方便的求和形式：

$$
\begin{aligned}
S &\equiv \log \frac{P(\mathbf{x},\mathbf{y}|R)}{P(\mathbf{x},\mathbf{y}|U)} \\
v &= \sum_i \log\left(\frac{p_{x_i y_i}}{q_{x_i} q_{y_i}}\right) \\
&\equiv \sum_i s(x_i, y_i)
\end{aligned}
\tag{3.2}
$$

因此，给定对 a, b 的替换矩阵分数由下式给出

$$
s(a,b) = \log\left(\frac{p_{ab}}{q_a q_b}\right)
$$

然后将上述表达式用于生成氨基酸的BLOSUM62等替换矩阵。有趣的是，一个氨基酸与其自身匹配的得分取决于该氨基酸本身，因为氨基酸随机出现的频率影响计算比对似然比得分时所用的项。因此，这些矩阵不仅捕捉了比对的序列相似性，还反映了各种氨基酸的化学相似性。

	C	S	T	P	A	G	N	D	E	Q	H	R	K	M	I	L	V	F	Y	W	
C	9																				C
S	-1	4																			S
T	-1	1	5																		T
P	-3	-1	-1	7																	P
A	0	1	0	-1	4																A
G	-3	0	-2	-2	0	6															G
N	-3	1	0	-2	-2	0	6														N
D	-3	0	-1	-1	-2	-1	1	6													D
E	-4	0	-1	-1	-1	-2	0	2	5												E
Q	-3	0	-1	-1	-1	-2	0	0	2	5											Q
H	-3	-1	-2	-2	-2	-2	1	-1	0	0	8										H
R	-3	-1	-1	-2	-1	-2	0	-2	0	1	0	5									R
K	-3	0	-1	-1	-1	-2	0	-1	1	1	-1	2	5								K
M	-1	-1	-1	-2	-1	-3	-2	-3	-2	0	-2	-1	-1	5							M
I	-1	-2	-1	-3	-1	-4	-3	-3	-3	-3	-3	-3	-3	1	4						I
L	-1	-2	-1	-3	-1	-4	-3	-4	-3	-2	-3	-2	-2	2	2	4					L
V	-1	-2	0	-2	0	-3	-3	-3	-2	-2	-3	-3	-2	1	3	1	4				V
F	-2	-2	-2	-4	-2	-3	-3	-3	-3	-3	-1	-3	-3	0	0	0	-1	6			F
Y	-2	-2	-2	-3	-2	-3	-2	-3	-2	-1	2	-2	-2	-1	-1	-1	-1	3	7		Y
W	-2	-3	-2	-4	-3	-2	-4	-4	-3	-2	-2	-3	-3	-1	-3	-2	-3	1	2	11	W
	C	S	T	P	A	G	N	D	E	Q	H	R	K	M	I	L	V	F	Y	W	

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图3.17：氨基酸的BLOSUM62矩阵

3.7 Current Research Directions

3.8 Further Reading

BLAST 相关算法：Califino-Rigoutsos’93、Buhler’01 和 Indyk-Motwani’98

3.9 Tools and Techniques

3.10 What Have We Learned?

在本节中，我们探讨了全局对齐之外的算法。我们首先回顾了运用动态规划解决全局对齐问题的方法，即Needleman-Wunsch算法。随后，我们深入研究了局部对齐（Smith-Waterman）和半全局对齐这两种替代方案。接着，我们讨论了利用哈希函数在线性时间内匹配精确字符串（Karp-Rabin算法），以及进行邻域搜索，在概率线性时间内查找相似序列（鸽巢原理、梳子、双命中Blast、随机投影）。我们还涉及了使用预处理实现线性时间字符串匹配，以及序列对齐的概率背景。

Bibliography

CHAPTER

FOUR

比较基因组学 I：基因组注释

刘全全（2013），马克·史密斯，亚尔登·卡茨（部分改编自安吉拉·严、克里斯托弗·罗布德、蒂莫·索默武奥和萨巴·古尔的笔记）

Figures

4.1 从哺乳动物到鱼类的 exon 保守性. . . . . 64 4.2 12 个 *Drosophila* 物种中功能元件的比较鉴定. . . . . 66 4.3 具有不同选择率 ω 的两个基因组区域之间的比较. . . . . 66 4.4 不寻常的替换模式 . . . . . 67 4.5 检测小约束元件功效的增加 . . . . . 68 4.6 哺乳动物物种间 HOXB5 的保守性. . . . . 69 4.7 使用速率矩阵建模突变. . . . . 69 4.8 测量全基因组范围的过剩约束. . . . . 70 4.9 从功能元件的演化特征中检测它们. **A** 全基因组相对于祖先重复序列（背景）的约束分布. **B** 全基因组与背景约束之间的差异. **C** 从过剩约束中发现功能元件. 新元件以红色显示. **D** 元件在过剩约束区域中的富集. . . . . 71 4.10 不同元件集合的覆盖深度. . . . . 72 4.11 蛋白质编码区和非蛋白质编码区中不同的突变模式. . . . . 72 4.12 蛋白质编码基因的演化特征 . . . . . 73 4.13 具有次级茎环结构的 RNA . . . . . 74 4.14 沉默点突变 . . . . . 75 4.15 蛋白质编码与非蛋白质编码保守区域 . . . . . 76 4.16 阅读框保守性. . . . . 77 4.17 被拒绝的开放阅读框. . . . . 78 4.18 零模型和备择模型速率矩阵. . . . . 79 4.19 一个区域为蛋白质编码的概率 . . . . . 80 4.20 使用演化特征预测新基因和外显子. . . . . 81 4.21 OPRL1 神经递质：一个新的翻译通读候选. . . . . 82 4.22 终止密码子抑制解释. . . . . 83 4.23 *Caki* 的 Z 曲线. . . . . 83 4.24 miRNA 发夹结构. . . . . 84 4.25 miRNA 特征性保守模式. . . . . 84 4.26 新 miRNA 证据 1. . . . . 85 4.27 新 miRNA 证据 2. 85

4.28 miRNA detection decision tree. 86
4.29 CG31044 and CG33311 Transcripts. 87
4.30 TAATTA regulatory motif. 87

4.1 Introduction

在本章中，我们将主要通过多个物种基因组比对的实例（由Kellis实验室完成的工作）来探索新兴的比较基因组学领域。分析基因组的一种方法是通过应用对进化的理解来寻找预期的进化模式，从而推断重要的基因功能。另一种方法是通过研究基因组本身来发现进化趋势。综合来看，进化见解和大型基因组数据集为发现新的生物现象提供了巨大的潜力。

本工作的一个反复出现的主题是采用全局计算方法来分析基因组中编码的基因和RNA元素，并借此发现有趣的新生物学现象。我们能够通过观察个别案例如何“偏离”或不同于平均情况来做到这一点。例如，通过研究众多蛋白质编码基因，我们可以识别出代表该类基因座的特征。进而，我们能设计出高度精确的测试，以区分蛋白质编码基因与非蛋白质编码基因。通常，这些基于数千个例子的计算测试，会比传统的低通量湿实验室测试更为决定性。（在需要确定某一特定基因座是否为蛋白质编码时，这类测试可包括质谱法来检测蛋白质产物。）

4.1.1 Motivation and Challenge

随着基因组测序成本的持续下降，已测序基因组数据的可用性呈爆炸式增长。然而，数据分析并未跟上步伐，而在无尽的ATGC序列中，仍有许多有趣的生物现象未被发现。比较基因组学的目标是利用大量可用信息寻找生物学模式。

顾名思义，比较基因组学并不专注于某一组特定的基因组。仅仅关注单一基因组层面的问题在于，关键的进化特征会被遗漏。比较基因组学通过比较来自许多从共同祖先进化而来的物种的基因组来解决这个问题。随着进化改变一个物种的基因组，它留下了其存在的痕迹。我们将在本章后面看到，进化根据生物功能对基因组的部分进行区分。通过利用进化指纹与基因组子序列的生物学作用之间的这种相关性，比较基因组学能够将湿实验室研究引向基因组中有趣的部分，并发现新的生物学现象。

FAQ

Q: 为什么突变只积累在基因组的某些区域，而其他区域却保持不变?

A: 在DNA的非功能区域，累积的突变得以保留，因为它们不会干扰DNA的功能。而在功能区域，这些突变可能导致适应度下降；随后，这些突变会通过自然选择从物种中被淘汰。

我们可以通过研究基因组学来获取大量关于进化的信息，同样，我们也可以通过研究进化来了解基因组。例如，根据“适者生存”的原则，我们可以比较相关物种，以发现基因组中哪些部分是功能元件。进化过程会在任何基因组中引入突变。在DNA的非功能区域，积累的突变会被保留下来，因为它们不会干扰DNA的功能。然而，在功能区域，积累的突变往往会导致适合度降低。因此，这些降低适合度的突变不太可能延续到后代。随着时间的推移，进化上不适合的生物很可能

无法存活，其基因逐渐稀疏。通过对比存活物种的基因组与其祖先的基因组，我们可以辨识出哪些部分构成了功能元件，哪些部分构成了“垃圾DNA”。

迄今为止，通过比较基因组学方法已发现了多种重要的生物学标记和现象。例如，在细菌和古菌中发现的CRISPRs（成簇规律间隔短回文重复序列），最初就是通过比较基因组学发现的。后续实验揭示，它们为质粒和噬菌体提供适应性免疫。另一个例子，我们将在本章后面探讨，是终止密码子通读现象，即在蛋白质生物合成的翻译阶段，终止密码子偶尔会被忽略。如果没有比较基因组学作为指导，实验学家们可能许多年都会忽视这两个特征。

如果没有一个解释和识别基因组重要特征的系统，地球上的所有DNA序列都只是一片无意义的数据海洋。然而，在比较基因组学中，我们不能忽视计算机科学和生物学的重要性。如果没有生物学知识，人们可能会错过同义替换或移码突变的特征。另一方面，忽视计算方法将导致无法解析测序中心产生的日益庞大的数据集。比较基因组学需要罕见的多学科技能和洞察力。

现在正是进入比较基因组学领域的激动人心的时刻，因为这个领域已经足够成熟，有可用的工具和数据来促成发现。但它又足够年轻，重要的发现很可能在未来许多年持续涌现。

4.1.2 Importance of many closely–related genomes

为了解析重要的生物学特征，我们既需要足够的相似性以便进行比较，又需要足够的差异性来识别进化过程中变化的标志。这在成对比较中难以实现。我们通过将分析扩展至同时涉及众多基因组，其中包含一些相似生物集群及一些不相似生物，从而提高了分析的分辨率。一个简单的类比是观察一个管弦乐队。如果你放置一个单一的麦克风，将很难 decipher 来自整个系统的信号，因为它会被来自单一观测点——最近乐器——的局部噪音所淹没。如果你在管弦乐队周围合理距离分布许多麦克风，那么你不仅能获得关于整体信号的更佳视角，还能了解局部噪音的结构。同样地，通过对生命树中众多基因组进行测序，我们能够区分功能元素的生物信号与中性突变的噪音。这是因为自然界倾向于在较大的系统发育距离上保护功能元素的保守性，同时通过短期时间尺度上的诱变过程不断引入噪音。

在本章中，我们将假设已经获得了多个近缘物种的完整基因组范围比对，涵盖编码区和非编码区。实际上，构建完整的基因组组装和全基因组比对是一个非常具有挑战性的问题；这将是下一章的主题。

FAQ

Q: 为什么物种之间的进化距离或分支长度增加时，分辨能力会更强?

A: 如果我们比较两个非常接近的物种，如人类和黑猩猩，我们预期会看到极少甚至没有突变。这给予我们较小的区分能力，因为在功能元件中的突变数量与非功能元件中的突变数量之间我们看不到差异。然而，随着物种间进化时间的增加，我们预期会看到更多突变，但实际上我们观察到基因组某些区域中观察到的突变数量显著减少。我们可以得出结论，这些区域是功能区域。因此，随着分支长度的增加，我们对所识别的功能元件的信心也随之增强。

FAQ

Q: 为什么对于相同的分支长度，拥有许多亲缘关系较近的物种比拥有一个亲缘关系较远的物种更好?

A: 随着远缘物种之间分支长度的增加，即便是功能元件也非保守。此外，使用当前技术如BLAST，可靠地对同一物种远亲的基因进行比对，即使可能也极为困难。

4.1.3 Comparative genomics and evolutionary signatures

给定一个全基因组比对，我们可以随后分析所考虑的每个基因组中功能元件的保守水平。使用UCSC基因组浏览器，人们可以查看人类基因组中每个基因的保守水平，这些保守水平是通过比对许多其他物种的基因组得出的。在下面的图4.1中，我们看到x轴上表示的一段DNA序列，而每一“行”代表一个不同的物种。每一行内的y轴表示该物种在染色体该部分的保守程度（尽管未显示的其他物种也被用于计算保守性）。较高的条形对应较高的保守性。

从这张图中，我们可以看到存在由非保守区域分隔开的保守区块。12个外显子（用红色矩形标出）在物种间大多是保守的，但有时某些外显子会缺失；例如，斑马鱼就缺少外显子9。然而，我们还看到在某些物种中存在一个峰值（用红圈标出），它并不对应于已知的蛋白编码基因。这告诉我们，一些内含子区域在进化上也是保守的，因为不编码蛋白质的DNA区域仍可能作为功能元件而具有重要性，例如RNA、microRNA和调控基序。通过观察区域如何保守，而不仅仅是关注保守的程度，我们可以观察到不同功能元件的“进化特征”。

突变/插入/缺失的模式可以帮助我们区分基因组中不同类型的功能元件。不同的功能元件受到不同的选择压力，通过考虑每个元件所受到的选择压力，我们可以开发出每种功能特有的进化特征。例如，我们看到蛋白质编码基因与调控基序等所表现出的进化特征差异。

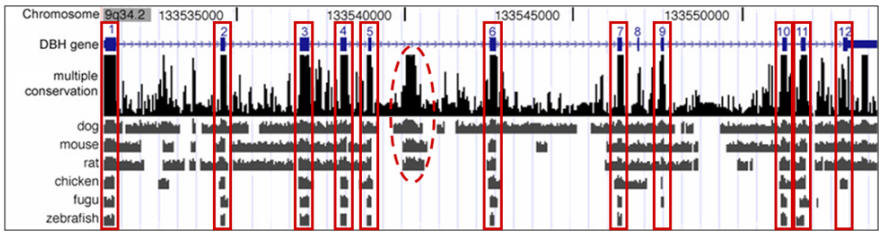

© source unknown. All rights reserved. This content is excluded from our Creative 知识共享许可协议。如需了解更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图4.1：外显子（红色方框内）从哺乳动物到鱼类高度保守。其他元件也同样高度保守，如圆圈标记的峰位于图中心附近。这可能是一个在哺乳动物中存在但在鸟类或鱼类中不存在的调控元件。

FAQ

Q: 给定来自多个物种的基因比对，你可以测量什么来确定特定基因的保守程度?

A: 一种简单的方法就是查看每个基因的比对得分。如果想要区分高度保守的蛋白质编码片段与非蛋白质编码片段，还可以观察密码子保守性。然而，在这两种方法中，我们都必须考虑被比较的每个物种在系统发育树中的位置。在系统发育树中相隔较远的两个物种之间的成对比对得分低于亲缘关系较近的两个物种之间的成对得分，并不一定意味着保守性较低。

4.2 Conservation of genomic sequences

4.2.1 Functional elements in *Drosophila*

在2007年的一篇论文[1]中，Stark等人识别了不同功能元件的进化特征，并利用保守特征预测了功能。一个重要发现是，在进化时间上，基因往往保持在相似的位置。图4.2说明了这一点，该图展示了来自十二个*Drosophila*物种基因组直系同源片段的多重比对结果。每个基因组由一条水平蓝线表示，其中顶部的线代表参考序列。灰线连接直系同源的功能元件，很明显它们的位置在不同物种间通常是保守的。

FAQ

Q: 为什么直系同源元件的位置保守具有重要意义?

A: 位置保守这一事实使我们能够跨物种进行比较。否则，我们就无法可靠地对非编码区域进行比对。

果蝇是一个非常适合研究的物种，因为事实上，果蝇的分离程度比哺乳动物更大。这引出了一个有趣的旁注，即在寻找保守特征时应该选择哪些物种。你不希望选择非常相似的物种（例如人类和黑猩猩，它们共享98%的基因组），因为很难区分不同的区域和相同的区域。当将物种与人类进行比较时，合适的保守性研究水平是哺乳动物。具体来说，该领域的大多数研究都是使用29种真兽亚纲哺乳动物（胎盘哺乳动物，不包括有袋类和单孔类）进行的。另一个需要考虑的因素是两个物种之间的分支长度差异。理想的研究对象应该是几个密切相关的（短分支长度）物种，以避免长分支长度突变（如回复突变）带来的解释问题。

4.2.2 Rates and patterns of selection

既然我们已经确定基因组序列的演化具有结构，我们就可以开始分析保护的具体特征。在本节中，我们将考虑单个核苷酸水平的基因组数据。在本章的后续部分，我们将看到我们还可以分析氨基酸序列。

我们可以通过根据基因组比对数据推断的替换率建立概率模型来估计选择约束ω的强度。使用ω的最大似然（ML）估计可以为我们提供选择率ω以及该速率非自然的对数优势比得分。

[1] http://www.nature.com/nature/journal/v450/n7167/abs/nature06340.html

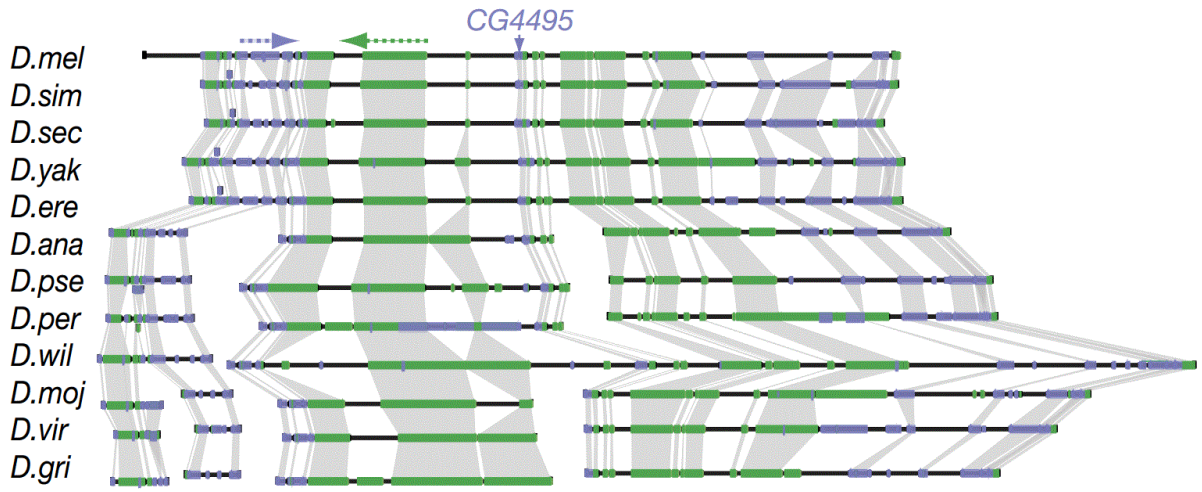

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图4.2：12个*Drosophila*物种中功能元件的比较鉴定。灰线表示直系同源区域的对齐。颜色表示转录方向。

这项测量可能考虑的一个性质是基因组中核苷酸的替换率。图4.3展示了来自哺乳动物集合中的两个核苷酸序列。其中一个序列受到正常变化率的影响，而另一个则显示出较低的速率。因此，我们可以假设后者序列受到更高程度的进化约束，可能代表了基因组中更为重要的生物学区域。

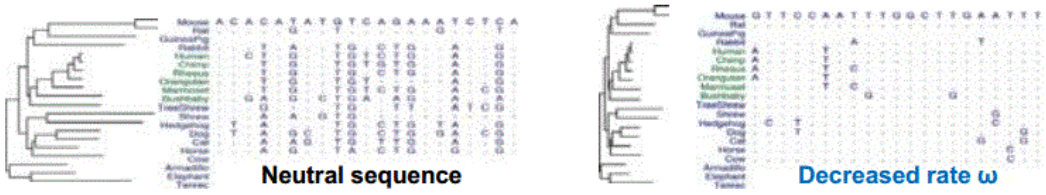

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图4.3：比较两个具有不同选择率ω的基因组区域。左侧的序列显示了正常的突变率，而右侧的序列显示出高保守水平，这由减少的突变数量所证明。

我们可以通过观察不同于背景分布的平稳分布的概率模型，进一步检测不寻常的选择模式π。π的ML估计为我们提供了基因组中每个k-mer的概率权重矩阵（PWM），以及不寻常替换（例如一个碱基变为唯一一个其他碱基）的对数几率得分。从图4.4可以看出，特定字母很重要，因为某些碱基选择性地变为一个（或两个其他碱基），而它所变成的特定碱基可能暗示序列的功能。

我们可以通过观察更多的物种来提高我们检测约束元素的能力，如图4.5所示，我们看到检测小约束元素的能力显著提高。

4.3 Excess Constraint

在基因组中大多数我们观察到跨物种保守的区域，我们预期至少存在一定数量的*synonymous*替换。这些是“沉默”核苷酸替换，它们以这样一种方式修改密码子，使得其所编码的氨基酸保持不变。在2011年的一篇论文[2]中，Lindblad–Toh等人研究了

[2] http://www.nature.com/nature/journal/v478/n7370/full/nature10530.html

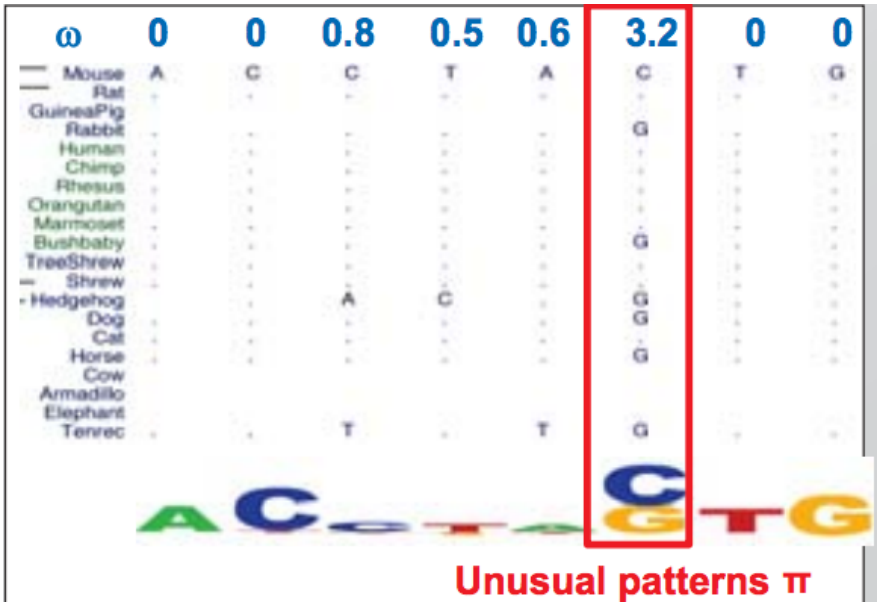

© source unknown. All rights reserved. This content is excluded from our Creative
知识共享许可协议。如需了解更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图4.4：此序列显示了C与G之间异常高的替换率，反之亦然。

通过对29种哺乳动物进行对比分析，他们发现了人类基因组中的进化约束。他们发现，在这29个基因组中，平均每个核苷酸位点有4.5个替换。

考虑到如此高的平均替换率，我们并不期望在所有保守区域内都能观察到完美的保守性。例如，忽略所有其他效应，一个12聚体在所有29个物种中保持不变的概率小于10^{-25}。因此，在多个物种间几乎完美保守的区域显得尤为独特，值得进一步研究。图4.6展示了一个这样的区域。

4.3.1 Causes of Excess Constraint

问题在于，是什么样的进化压力导致某些区域如此完美地保守？课堂上提到了以下几种可能性：

- 会不会有一种特殊的DNA结构保护这个区域免受突变?
- 是否有一些特殊的纠错机制位于这个位置?
- 细胞能否利用两份DNA的甲基化状态作为纠错机制？这种机制将依赖于新合成的DNA拷贝未被甲基化这一事实，因此DNA复制机器可以对照旧的甲基化拷贝来检查新的拷贝。

- 如果这个区域发生突变，下一代也许就无法存活?

另一种可能的解释是，选择是为了保守特定的密码子。某些密码子比其他密码子更高效：例如，需要快速翻译的高丰度蛋白质可能会选择那些能提供最高翻译效率的密码子，而其他蛋白质则可能选择那些翻译效率较低的密码子。

不过，这些区域似乎过于完美地保守，仅用密码子使用偏好无法解释。还有什么能解释这种过度约束呢？必定存在某种核苷酸水平上的精确性要求，阻止了这些序列发生分歧。

可能是因为我们正在观察两个刚刚分化不久的物种中的同一区域，或者存在一种特定的遗传机制保护这一区域。然而，更有可能的是，如此高的保守性是蛋白质编码区域的标志，这些区域同时编码了其他功能元素。例如，HOXB5基因显示出明显的过度约束，并有证据表明HOXB5开放阅读框的5’端同时编码蛋白质和RNA二级结构。

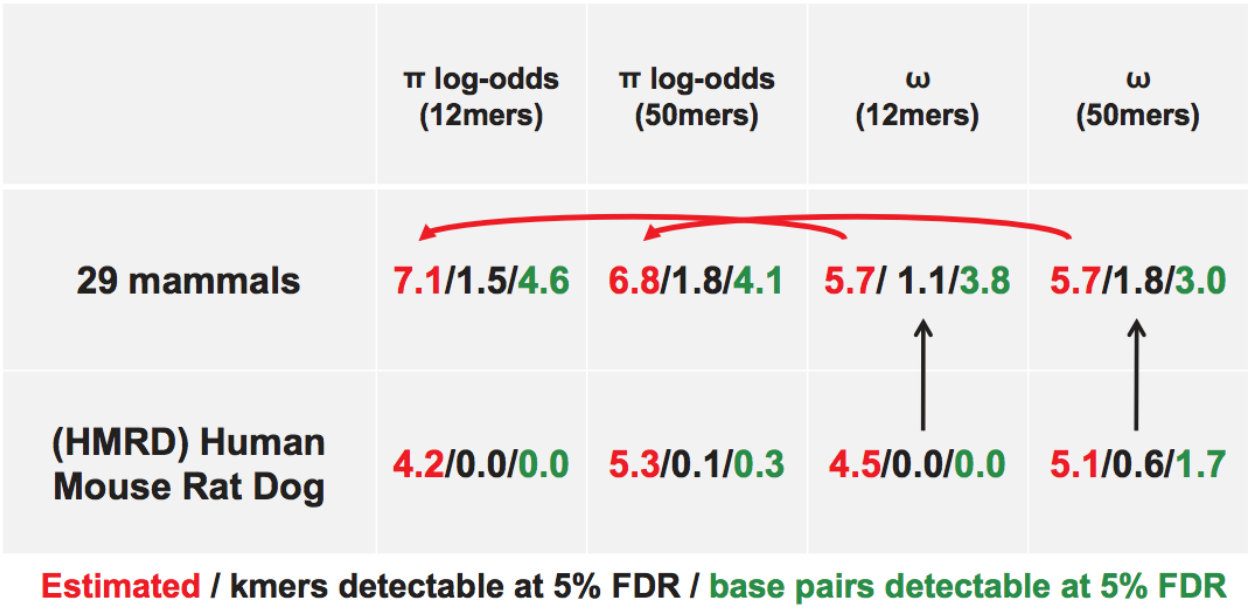

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图4.5：通过增加研究的哺乳动物数量，我们可以观察到可检测的受限k-mers和碱基对有所增加。

编码多于一种功能元件的区域承受着重叠的选择压力。蛋白质编码空间可能存在压力，要求保持与该区域对应的氨基酸序列不变，同时RNA空间也有压力，要求保持能维持RNA二级结构的核苷酸序列。由于这两种压力——既要保持相同氨基酸的密码子，又要产生相同的RNA结构——该区域对任何同义替换模式的耐受性可能要低得多。

基于跨多个物种的基因组比对数据估计进化约束的过程遵循以下步骤：

- 统计编辑操作的数量（即替换和/或删除/插入的次数）
- 估计包括回复突变在内的突变数量
- 通过查看“守恒窗口”，融入关于守恒元素邻域元素的信息

- 使用隐马尔可夫模型估计受约束的“隐藏状态”的概率
- 使用系统发育来估计树突变率（即拒绝应沿树发生的替换）

- 允许树的不同部分具有不同的突变率

4.3.2 Modeling Excess Constraint

为了更好地研究过度约束区域，我们开发了数学模型，以系统地测量不同区域的同义和非同义保守程度。我们将测量两种速率：密码子保守率和核苷酸保守率。

为了表示零模型，我们可以构建速率矩阵（在核苷酸情况下为4×4，在密码子情况下为64×64），给出单位时间内密码子或核苷酸之间的替换速率。我们通过查看大量数据并估计每种替换类型的概率来估计零模型中的速率。关于密码子情况的零矩阵示例，请参见4.5.2中的图4.18a。

- λ_s：同义替换率

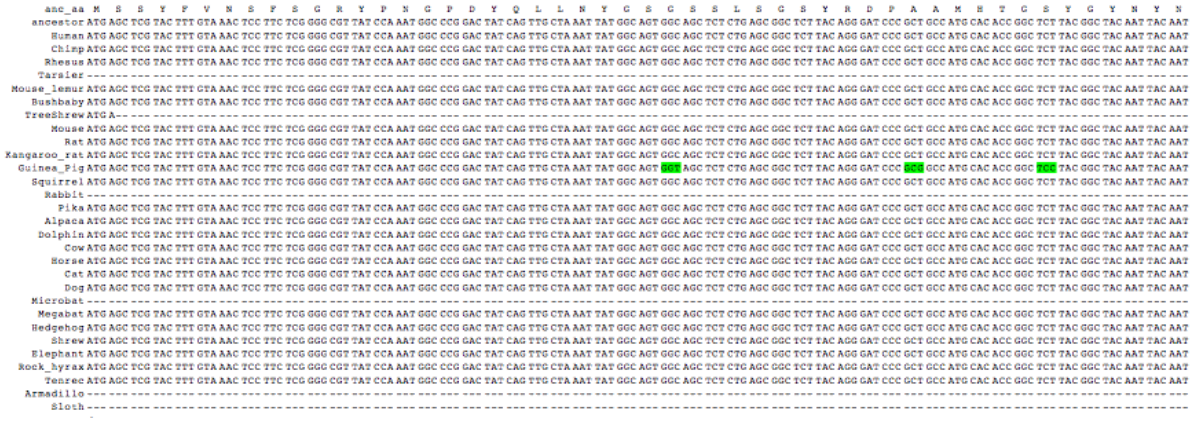

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图4.6：许多基因组区域，如HOXB5，展现出的保守性超出了我们在正常保守编码区所预期的程度。在研究的29个物种中，除7个外，其余都具有完全相同的核苷酸序列。绿色区域表示经历了进化突变的区域。

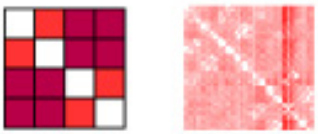

© 来源未知。版权所有。本内容不在我们的知识共享许可范围内。有关更多信息，请参见 http://ocw.mit.edu/help/faq-fair-use/。

图4.7：如左图所示，我们可以使用速率矩阵来模拟核苷酸替换，如右图所示，模体密码子替换。在每个矩阵中，位于第m行第n列的单元格代表了第m个符号突变为第n个符号的可能性。颜色越深，表示突变的可能性越小。

- λ_n：非同义替换率

例如，如果λ_s =为0.为5，那么同义替换率是该区域零模型预期的一半。随后，我们可以评估所获得速率估计的统计显著性，并找出替换率远低于预期的区域。

在这里使用零模型有助于我们考虑某些密码子比对覆盖度的偏差，并且还考虑了密码子简并的可能性，在这种情况下，我们预期会看到更高的替换率。在课程后面讨论系统发育树和进化时，我们将学习如何将此类模型与系统发育方法结合起来。

应用该模型表明，首次翻译的密码子、盒式外显子（存在于一种mRNA转录本但不存在于该转录本的异构体中的外显子）以及可变剪接区域中的序列具有特别低的同义替换率。

4.3.3 Excess Constraint in the Human Genome

在本节中，我们将探讨确定人类基因组中受额外约束的总比例这一问题。特别地，我们将重新审视Lindblad-Toh等人（2011）的工作，该研究比较了29种哺乳动物基因组。他们通过将上一节所述过程应用于50-mer，测量了整个基因组的保守水平。通过仅考虑作为祖先重复序列一部分的50-mer，可以确定保守的背景水平。我们可以设想，50-mer之间的保守强度按照一个隐藏的概率分布进行分布，如图4.8所示。在图中，背景曲线代表了在缺乏

特殊约束机制，根据祖先重复序列确定，而信号（前景）曲线代表基因组的实际分布。由于自然选择的净化效应，信号曲线整体上具有更多的保守性。

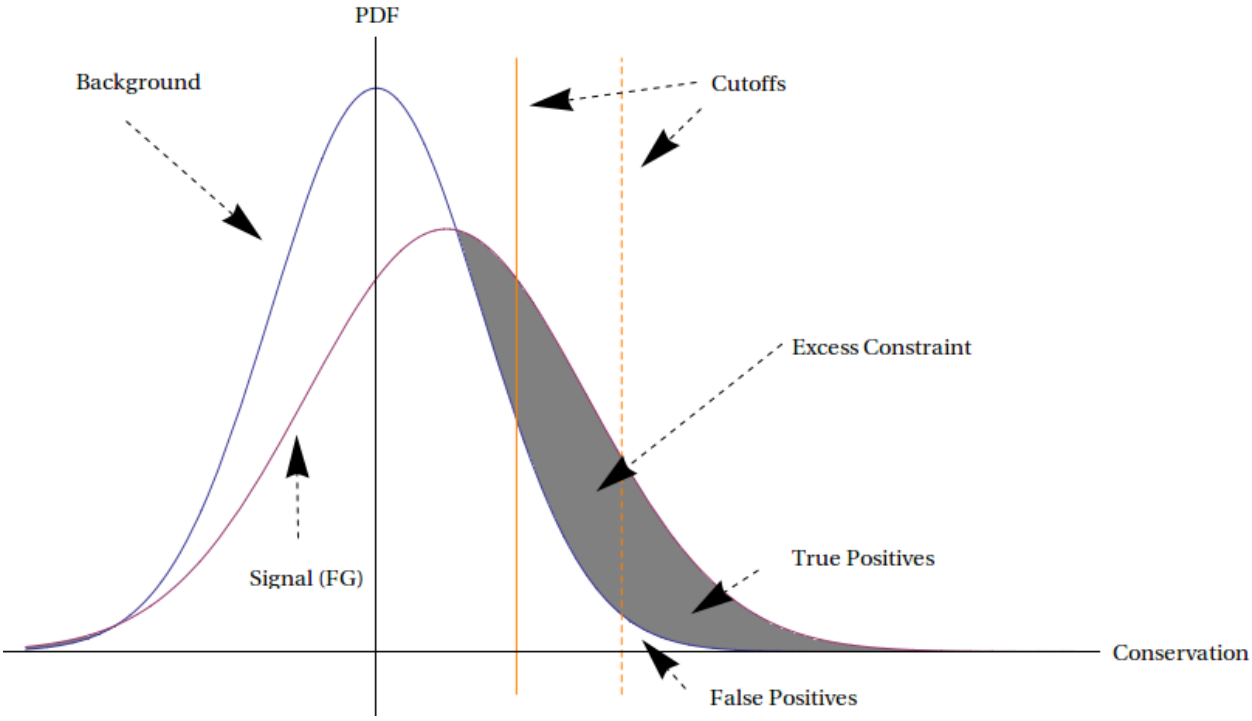

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图4.8：测量全基因组范围的超额约束。解释见随附正文。

我们可能希望通过设定一个保守性阈值并检查更保守的区域，来研究基因组中受到过度约束的特定区域。在示例中，这对应于考虑所有位于某条橙色线右侧的50-mer。我们看到，尽管这种方法确实给出了受到过度约束的区域，但它也给出了假阳性。这是因为即使不存在纯化选择和其他效应，某些区域也会仅仅由于随机机会而高度保守。将阈值设得更高，例如使用虚线橙色线作为我们的阈值，会降低假阳性（FP）与真阳性（TP）的比例，同时也会降低检测到的真阳性数量，从而以更高的特异性换取更低的敏感性。

然而，并非所有希望都已破灭。如前所述，我们可以通过实验测量背景（BG）和前景（FG）信号曲线。一旦完成这一步骤，它们之间区域的面积，即图4.8中灰色阴影部分，可以通过积分确定。这个面积代表了基因组中受到额外约束的比例。由于曲线重叠，我们无法检测到所有保守元件，但我们可以估计出额外约束的总量。这个估计的约束量大约占人类基因组的5%，具体取决于所使用的窗口大小。这些区域很可能都是功能性的，但由于人类基因组中约1.5%是蛋白质编码区，我们可以推断剩下的3.5%由功能性非编码元件组成，其中大多数可能发挥调控作用。

我们已经看到，整个基因组的进化约束可以通过评估基因组约束相对于背景分布来估计。Lindblad-Toh等人(2011)将29种哺乳动物的基因组保守性与基于祖先重复元件计算的背景进行比较，以找出具有过度约束的区域（图4.9A和B）。对进化上受约束碱基的注释显示，大多数发现的区域位于基因间和内含子中，并表明从四种（HMRD）到29种哺乳动物基因组，这种分析的能力主要在非编码区域增加（图4.9C）。基因组中受约束最强的区域是编码区（图4.9D）。

如图4.9所示，从HMRD增加到29个基因组比对极大地提高了效能

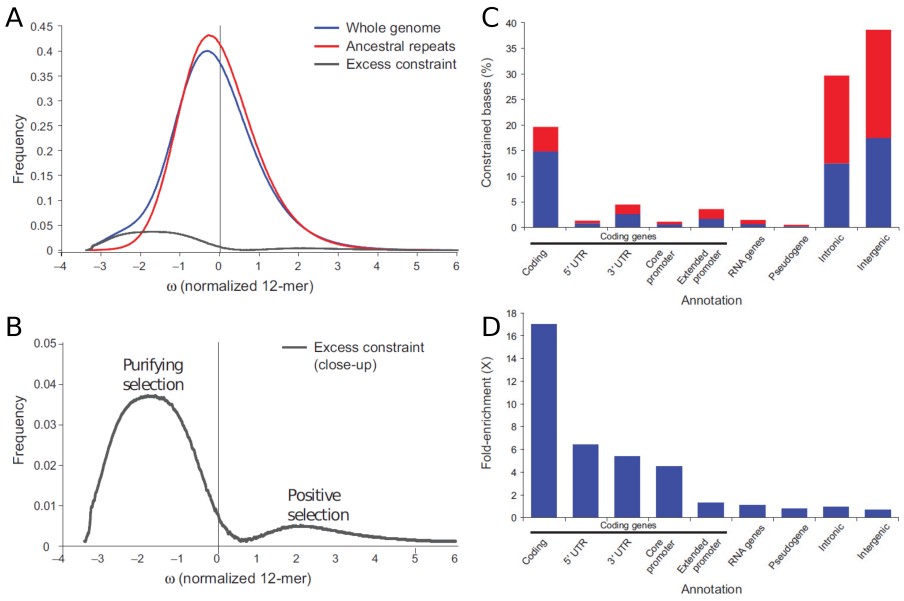

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图4.9：从进化特征中检测功能元件。**A** 全基因组相对于祖先重复序列（背景）的约束分布。**B** 全基因组与背景约束之间的差异。**C** 从过量约束中发现功能元件。新元件以红色显示。**D** 元件在过量约束区域的富集。

这一分析。然而，尽管检测到的基因间元素数量显著增加，但检测仍受限于一个事实，即在多序列比对中，非功能元素的物种覆盖深度远低于功能区域（图4.10）。例如，祖先重复序列（AR，$\mu = 11.4$）的平均覆盖深度远低于外显子（$\mu = 20.9$）。一方面，这显示了对功能元素中插入和缺失的选择证据，而这些在碱基约束分析中并未被考察。另一方面，这也使进化约束分析变得复杂，因为此类工作必须处理基因组中覆盖度的变化。

4.3.4 Examples of Excess Constraint

考试 在以下内容中发现了过度约束的示例: 案例:

- 大多数Hox基因显示出重叠的限制区域。特别是，如上所述，HOXB5的前50个氨基酸几乎完全保守。此外，HOXA2显示出重叠的调控模块。这两个位点编码发育增强子，为组织特异性表达提供了机制。

- ADAR：mRNA编辑的主要调控因子，有一个剪接变体在9个密码子的分辨率下被发现同义替换率低。

- BRCA1：Hurst和Pal（2001）发现，在与乳腺癌相关的主基因BRCA1的某些区域中，同义替换率较低。他们推测这些区域正发生着净化选择。（这一说法被Schmid和Yang（2008）反驳，他们认为此现象是滑动窗口分析的假象）。

- THRA/NR1D1：这些基因也参与乳腺癌，属于一个同时编码这两个基因的双重编码区，并且高度保守。

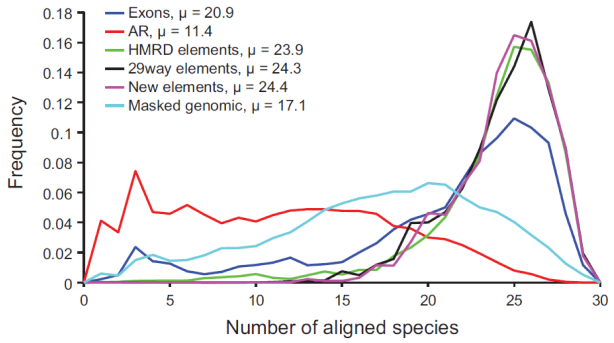

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图4.10：不同元素集合的覆盖深度。

- SEPHS2：具有参与硒代半胱氨酸重编码的发夹结构。由于该区域必须选择密码子，以既保留蛋白质的氨基酸序列，又保持相同的RNA二级结构所需的核苷酸，因此它显示出过度的限制。

4.3.5 Measuring constraint at individual nucleotides

通过测量单个核苷酸而非序列块上的进化约束，我们可以发现单个转录因子结合位点、基序实例内的位置特异性偏倚，并揭示大多数物种中的基序共有序列。具体来说，我们可以检测破坏保守调控基序的SNP，并通过观察基因中的每个核苷酸来确定进化水平。通过单独观察核苷酸，我们可以找到在特定序列功能中重要的SNP。

4.4 Diversity of evolutionary signatures: An Overview of Selection Patterns

独立于替换率，我们还可以考虑特定核苷酸子序列中的替换模式。考虑编码蛋白质的核苷酸序列。由于tRNA摆动，密码子第三位核苷酸的突变比其他位置的突变更不可能影响最终蛋白质。因此，在观察基因组的蛋白质编码子序列时，我们预期会看到第三位替换增加的模式。如图4.11所示，这确实得到了实验验证。

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图4.11：蛋白质编码区和非蛋白质编码区的不同突变模式。星号表示该核苷酸在所有物种中都是保守的。请注意，在蛋白质编码外显子内，每个密码子的第1和第2位核苷酸倾向于保守，而第3位密码子允许更多变异，这与摆动现象一致。

FAQ

Q: 在图4.11中，我们同样观察到以三个或六个为一组的核苷酸替换。为什么会这样呢?

A: 三的倍数和六的倍数的插入和缺失也有助于保持阅读框。如果一个密码子中的所有核苷酸都被删除，那么在氨基酸翻译过程中，其余的密码子不受影响。然而，如果我们删除的核苷酸数量不是三的倍数（即我们只删除了某些密码子的一部分），那么由于阅读框发生了移码，其余密码子的翻译就会变得无意义。

在图4.12中，我们可以观察到蛋白质编码基因的另一个特征。保守区域的边界非常清晰，且位于剪接位点附近。周期性的突变（以三的倍数出现）开始于剪接位点边界之后。

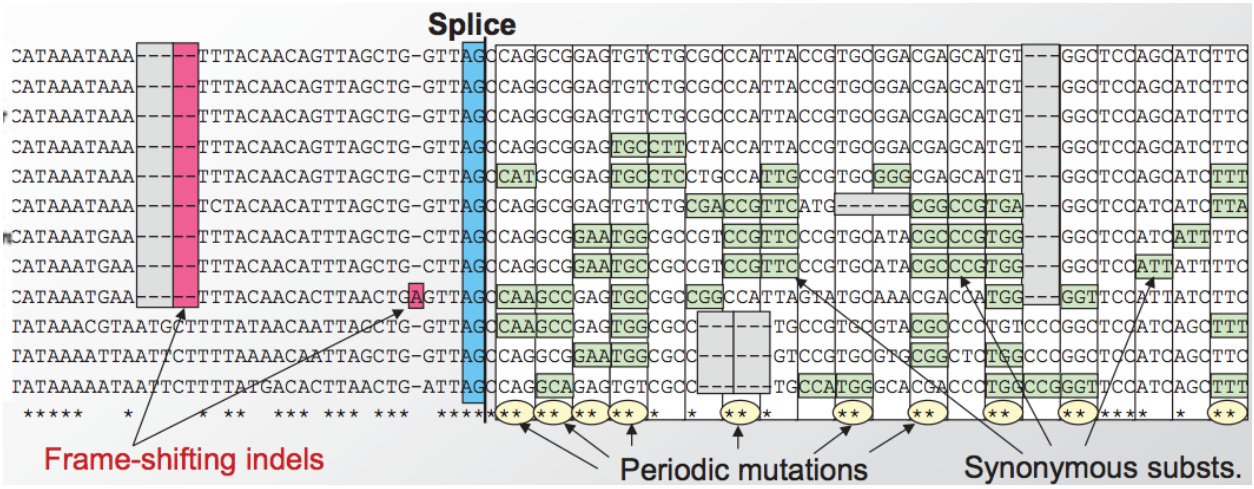

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图4.12：除了阅读框保守性和每三个核苷酸的替换外，我们还观察到精确划分剪接位点的清晰保守边界。

正如我们在检测蛋白质编码基因时所见，不仅需要考虑替换率，还要考虑替换模式。通过观察区域如何保守，而不仅仅是关注保守程度，我们可以观察到不同功能元件的“进化特征”保守性。

4.4.1 Selective Pressures On Different Functional Elements

不同的功能元件具有不同的选择压力（由于其结构和其他特征）；某些变化（插入、缺失或突变）可能对某个功能元件极为有害，但对另一个功能元件却可能无害。通过弄清楚不同元件的“特征”是什么，我们可以通过观察某个区域所表现出的保守模式来更准确地注释该区域。

这种模式被称为**evolutionary signature**：一种在仍保留其功能的元件中被容忍的变化模式。进化特征与保守程度的不同之处在于，你容忍突变，但仅限于特定位置的特定类型突变。进化特征之所以出现，是因为进化和自然选择在某些功能元件中作用于不同层次。例如，在蛋白质编码基因中，进化作用于氨基酸层次，因此自然选择不会过滤掉不影响氨基酸序列的核苷酸变化。而结构性RNA则会有保持核苷酸对的压力，但不一定是个别核苷酸。

重要的是，保守模式具有明显的系统发育结构。更相似的物种（哺乳动物）聚集在一起，共享鱼类所缺乏的保守结构域，这表明可能是哺乳动物特有的创新，或许是为了调节元件而非鱼类所共享。同时，一些特征是全局保守的，表明具有普遍意义，例如蛋白质编码。利用一个简单的启发式方法，即如果从人类到鱼类都是保守的，那么它很可能作为蛋白质编码区域，初步近似注释人类基因组中的蛋白质编码区是可能的。

一个有趣的期末项目想法是映射多序列比对中的分歧，并将这些事件称为新编码元件的“诞生”。通过聚焦于某一特定元件（例如 microRNA），可以识别创新时期，并分离出系统发育树中对这些元件的某些类别富集的部分。

本章的剩余部分将聚焦于量化一个序列遵循特定模式的程度。Kellis将进化过程比作探索适应度景观，特定序列的适应度得分受其编码功能的约束。例如，蛋白质编码基因受到对其翻译产物的选择约束，因此密码子第三碱基对中的同义替换是被容忍的。

以下是各种功能元素所遵循的预期模式概述：

- 蛋白质编码基因表现出特定的密码子替换频率以及阅读框保守性。这是合理的，因为这些基因的意义在于它们所编码的蛋白质；因此，导致相同或相似氨基酸的变化很容易被容忍，而一个微小变化如果剧烈改变所得到的蛋白质，则可被视为灾难性的。除了错配修复系统和DNA聚合酶本身的纠错之外，遗传密码的冗余性还提供了额外一层的固有纠错/容忍。

- 结构RNA是基于转录RNA的二级序列进行选择的，因此需要补偿性变化。例如，一些RNA具有二级茎环结构，使得其序列的某些部分在“茎”中与其序列的其他部分结合，如图4.13所示。

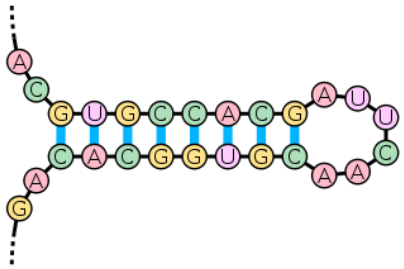

Courtesy of Sakurambo on wikipedia. Image in the public domain.

图4.13：具有二级茎环结构的RNA

想象一个核苷酸（A）及其配对伙伴（T）在茎区相互结合，随后（A）突变为（C）。这会破坏RNA的二级结构。为了纠正这一点，要么（C）突变为（A），要么（T）突变为（G）。这样，（C）-（G）配对将维持二级结构。这被称为补偿性突变。因此，在RNA结构中，二级结构（例如茎环）的变化程度比一级结构（仅序列）的变化程度更为重要。理解RNA结构变化的影响需要了解二级结构。RNA可能的二级结构可以通过模拟多种可能构象的稳定性并选择最可能的构象来确定。

- MicroRNA是一种从细胞核排入细胞质的分子。它们的特征性特征在于，它们也具有图4.13所示的发夹（茎环）结构，但茎的一部分与mRNA的一部分互补。

当microRNA将其互补序列结合到mRNA的相应部分时，它会降解mRNA。这意味着它是一种转录后调节因子，因为它被用来限制

转录后蛋白质的生产（翻译）。MicroRNA的保守性与结构RNA不同。由于其与mRNA靶标的结合，结合区域更加保守以维持靶标特异性。

- 最后，调控基序在序列上是保守的（以结合特定的相互作用蛋白伴侣），但在位置上不一定保守。调控基序可以移动，因为它们只需要将某个因子招募到特定区域。那些保持基序共有序列不变的小变化（插入和缺失）是被容忍的，同样，改变基序位置的上游和下游变化也是被容忍的。

在试图理解保守性在功能类别预测中的作用时，一个重要的问题是，已知模式能在多大程度上解释观察到的保守性。即使在考虑了“随机”保守性之后，果蝇基因组中大约60%的非随机保守性仍无法解释——也就是说，我们无法将其识别为蛋白质编码基因、RNA、microRNA或调控基序。然而，它们保持保守这一事实表明其具有功能作用。如此多的保守序列仍然鲜为人知，突显了许多令人兴奋的问题仍有待解答。过去6.047的一个期末项目是利用聚类（无监督学习）来解释其他保守性。该项目发展成了一个工程硕士项目，并识别出了一些聚类，但这些聚类的功能当时和现在仍不清楚。这是一个未解决的问题！

4.5 Protein–Coding Signatures

在第12张幻灯片中，我们看到了三个保守性的例子：一个保守性较差的内含子序列，一个高度保守的编码区，以及一个高度保守的非编码区，这意味着它可能是一个功能元件。正如我们在本节开头所见，需要记住的蛋白质编码区的重要特征是，密码子（核苷酸的三联体）编码氨基酸，而氨基酸构成蛋白质。这导致了蛋白质编码区的进化特征，如第13张幻灯片所示：(i) 阅读框保守性和 (ii) 密码子替换模式。这一特征的直观理解相对直接。

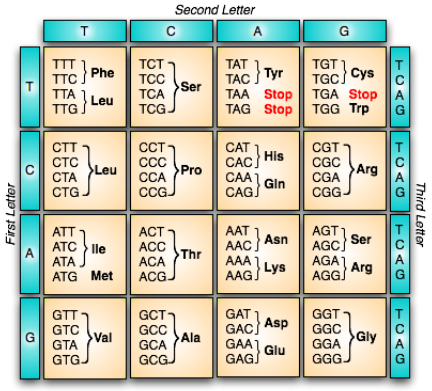

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图4.14：DNA序列中的某些点突变不会改变蛋白质翻译

首先，阅读框保守性是有道理的，因为一个或两个核苷酸的插入或缺失会“改变”后续所有密码子的读取方式。然而，如果插入或缺失的核苷酸数量是3的倍数，其他密码子仍然会以相同的方式读取，因此这种变化的影响较小。其次，某些突变比其他突变危害更小也是合理的，因为不同的三联体可以编码相同的氨基酸（如下方矩阵所示，这是一种保守替换），甚至那些导致不同氨基酸的突变，如果替换发生在蛋白质结构域中相似氨基酸之间，且该区域并不要求氨基酸具有精确特性，那么在进化上可能是中性的。这些独特的模式使我们能够对基因组进行“着色”，并清晰地看到外显子的位置，如图4.15所示。

在利用这些模式区分进化特征时，我们必须确保考虑以下几点：

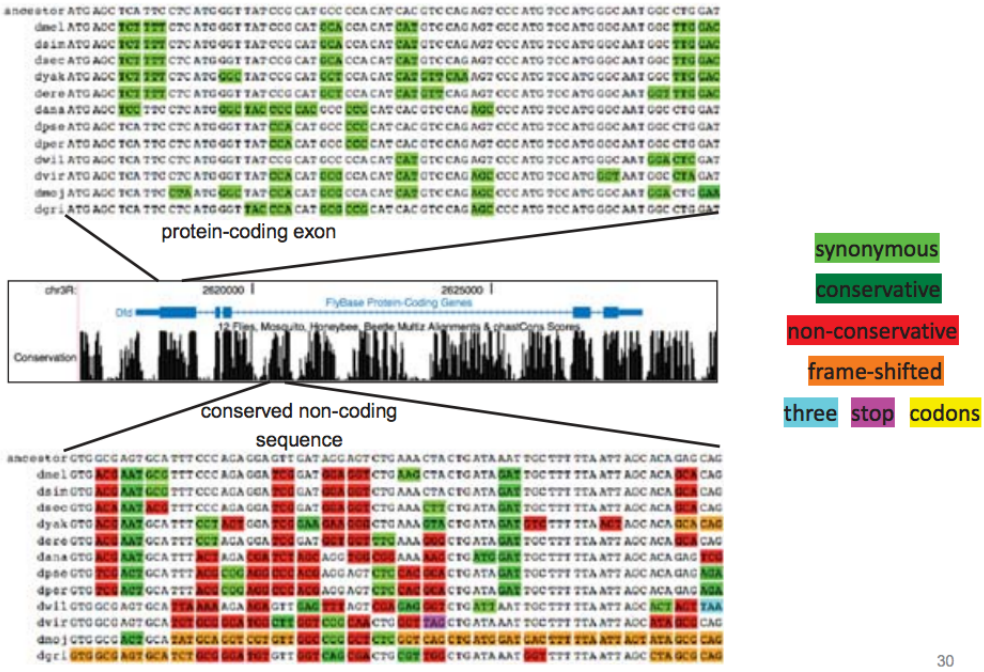

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图4.15：通过对序列中发生的插入/删除/替换类型进行着色，我们可以观察到区分蛋白质编码保守区域与非蛋白质编码保守区域的模式或进化特征。

- 通过考虑同义（在蛋白质编码序列中频繁出现）和无义（在非编码序列中比编码序列更频繁）区域，量化所有64^2个可能的密码子替换的独特性。
- 对物种之间的系统发育关系进行建模：多个明显的替换可能由一个进化事件来解释。
- 容忍输入中的不确定性，如未知的祖先序列和比对中的缺口（缺失数据）。
- 报告结果的确定性或不确定性：使用p值、比特、分贝等单位量化给定比对是蛋白质编码的置信度。

4.5.1 Reading–Frame Conservation (RFC)

既然我们了解了蛋白质编码基因中的这种保守模式，我们就可以开发方法来判断一个基因是否属于蛋白质编码基因。

通过对维持同一阅读框的压力进行评分，我们可以量化一个区域是蛋白质编码的可能性。如幻灯片20所示，我们可以通过将一个目标序列（Scer，*S. cerevisiae*的基因组）与一个选择序列（Spar，*S. paradoxus*）进行比对，并计算选择序列与目标序列阅读框匹配的时间比例来实现这一点。

由于我们不知道所选序列中阅读框的起始位置，我们进行三次比对以尝试所有可能的偏移：

$$(\mathrm{Spar}_{\mathrm{f1}}, \mathrm{Spar}_{\mathrm{f2}}, \mathrm{Spar}_{\mathrm{f3}})$$

从中，我们选择所选序列与目标序列最常同步的对齐方式。例如，我们可以从“1, 2, 3...等”开始对核苷酸编号，直到遇到我们不编号的间隙。或者我们可以从“2, 3, 1...等”开始对核苷酸编号，其中每三个“1,2, 3”代表一个密码子。

最后，为了获得最佳比对，我们计算移码核苷酸的百分比——如果该比例高于某个阈值，则所选物种“投票”认为该区域是蛋白质编码区；如果该比例较低，则该物种“投票”认为这是基因间区。这些“投票”从所有物种中汇总，以累加得到RFC分数。

© source unknown. All rights reserved. This content is excluded from our Creative 知识共享许可协议。如需了解更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图4.16：两个比对展示了基因与基因间序列在保守模式上的差异。红色框表示导致编码框移码的间隙，灰色框则是非移码间隙（长度为三的倍数）。绿色区域表示保守，黄色区域表示突变。注意蛋白质编码序列中“匹配、匹配、不匹配”的模式，这指示了同义突变。

该方法对测序错误不稳健。我们可以通过使用更小的扫描窗口并观察局部阅读框保守性来补偿这些错误。

该方法在应用于酵母基因组时显示出99.9%的特异性和99%的灵敏度。当应用于酵母中的2000个假设的ORF（开放阅读框，或提议的基因）[3]时，它拒绝了500个这些假定蛋白质编码基因，认为它们不是蛋白质编码的。

同样，人类基因组中的4000个假设基因被这种方法所否定。该模型提出了一个具体的假设（即这些DNA序列不太可能编码蛋白质），随后这一假设得到了实验证实，即这些区域在体内并不编码蛋白质。[4]

这对基因组注释而言是向前迈出的重要一步，因为此前仅凭缺乏证据很难断定一段DNA序列是非编码的。通过缩小关注范围并提出一个新的零假设（即所讨论的基因似乎是一个非编码基因），不仅接受编码基因变得更加容易，而且在计算支持下拒绝非编码基因也变得容易得多。在课堂上讨论阅读框保守性时，我们发现了一个令人兴奋的期末项目构想，即寻找由移码突变产生的新功能蛋白的诞生。

4.5.2 Codon–Substitution Frequencies (CSFs)

蛋白质编码区的第二个特征，即密码子替换频率，作用于多个保守层次。为了探究这些频率，记住密码子演化可以被建模是有帮助的

[3]Kellis M, Patterson N, Endrizzi M, Birren B, Lander E. S. 2003. Sequencing and comparison of yeast species to identify genes and regulatory elements. Science. 423: 241–254.

[4]Clamp M et al. 2007. Distinguishing protein–coding and noncoding genes in the human genome. PNAS. 104: 19428–19433.

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图4.17：红色框表示移码缺口，而三的倍数的缺口则未着色。保守区域和突变区域分别以绿色和黄色表示。

通过条件概率分布（CPDs）——即后代在祖先于t时间前拥有密码子a的情况下拥有密码子b的可能性。

最保守的事件是密码子的精确维持。编码相同氨基酸的突变可能是保守的，但由于物种特定的密码子使用偏好，并非完全同义。即使改变氨基酸身份的突变，如果它们编码具有相似生化特性的氨基酸，也可能是保守的。

我们使用CPD来捕捉所有这些考虑因素的综合效应。为了计算这些CPD，我们需要一个“速率”矩阵Q，它衡量单位时间内的交换率；也就是说，它指示了在单位分支长度内，物种1中的密码子a被物种2中的密码子b替换的频率。然后，通过使用e^{Qt}，我们可以估计在时间t时的替换频率。

当CPD与表示进化树的网络图拓扑结构一同考虑时，它大约有 $(2L-2)\cdot 64^2$ 个参数，其中 L 是树中叶子的数量（进化系统发育中的物种数）。这一参数数量源自 Q 中的条目数量以及独立分支长度的数量 t。这些参数的估计值可以通过最大似然估计从训练数据中确定。

CPD 通过 e^{Qt} 定义如下：

$$\Pr(child = a | parent = b; t) = [e^{Qt}]_{a,b} \tag{4.1}$$

直觉是，随着时间增加，替换的概率也增加，而在“初始”时间（$t=0$），e^{Qt} 是单位矩阵，因为每个密码子都保证是它本身。但我们如何得到速率矩阵呢?

- Q 是从序列中“学习”得到的，例如通过期望最大化方法。许多已知的蛋白质编码序列被用作训练数据（或者在生成该模型时使用非编码区域）。
- 给定模型参数，我们可以使用Felsenstein算法[1]来计算任何对齐的概率，同时考虑系统发育，给定替换模型（E步）。

$$Likelihood(\boldsymbol{Q}) = \Pr(\text{Training Data}; \boldsymbol{Q}, t) \tag{4.2}$$

- 然后，给定比对和系统发育关系，在M步中我们可以选择使这些比对似然最大化的参数（速率矩阵：Q，以及分支长度：t）；例如，为了估计Q，我们可以统计比对中一个密码子被另一个密码子替换的次数。参数空间包含Q和t的数千种可能。这个空间由$\mathbf{Q}$表示。$\hat{Q}$是使似然最大化的参数：

$$\hat{Q} = argmax_{\boldsymbol{Q}}(Likelihood(Q)) \tag{4.3}$$

其他最大化策略包括：期望最大化、梯度上升、模拟退火、谱分解。分支长度 t 可以同时使用相同的方法进行优化。

FAQ

Q: 分支长度如何有助于确定速率矩阵?

A: 分支长度指定了任意两个节点之间经过了多长“时间”。速率矩阵描述了每个**unit branch length**密码子替换的相对频率。

使用两个估计的速率矩阵，对于每个矩阵，任意给定比对的计算概率在$Pr(Leaves;Q_c,t)$上是不同的。现在，我们可以比较似然比，即该比对来自$Pr(Leaves;Q_N,t)$蛋白质编码区域而非非蛋白质编码区域的概率。

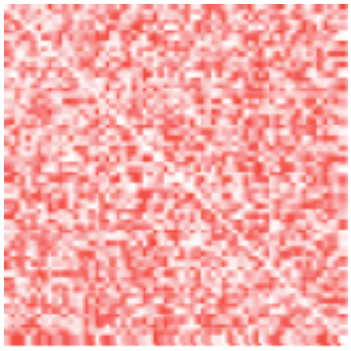

(a) Rate matrix Q_N estimated from non–coding regions

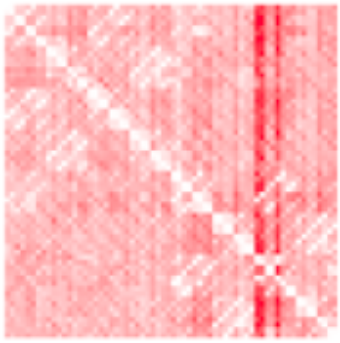

(b) Rate matrix Q_c estimated from known coding regions.

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图4.18：零模型和备择模型的速率矩阵。颜色越浅表示替换的可能性越大。

既然我们知道了如何获得我们的模型，我们注意到，鉴于蛋白质编码中密码子替换频率的特定模式，我们需要两个模型，以便能够区分编码区和非编码区。图4.18a和4.18b分别显示了基因间区和基因区的速率矩阵。在基因的密码子替换矩阵（CSM）中，有几个显著特征凸显出来。注意，主对角线元素已被移除，因为一个三联体被自身替换的频率显然会远高于任何其他替换。然而，

1. 显而易见，在蛋白质编码区域中存在一个强烈的对角元素。

2. 我们还注意到编码CSM中的某些高分非对角元素：这些是功能相近而非序列相近的替换，例如6重简并密码子或非常相似的氨基酸。

3. 我们还注意到暗色垂直条纹，这表明这些替换特别不可能发生。这些列对应终止密码子，因为替换到这一三联体会显著改变蛋白质功能，因此受到强烈的选择排斥。

另一方面，在基因间区域的矩阵中，交换率更为均匀。在这些区域中，重要的是*mutational proximity*，即编辑距离或从一个序列到另一个序列的变化数量。遗传区域由*selective proximity*决定，或者由基因产生的蛋白质氨基酸序列的相似性决定。

现在我们有了两个区域的两个速率矩阵，我们可以计算每个矩阵生成两个物种基因组的概率。这可以通过使用Felsenstein的算法，并将两个物种中每对相应密码子的“得分”相加来实现。最后，我们可以通过将来自编码区的比对与来自非编码区的比对的可能性相除，来计算似然比。

得分——这表明我们对序列注释的信心。如果比率大于1，我们可以推测它是一个编码区；如果小于1，那么它就是一个非编码区。例如，在图4.16中，我们对每个区域的分类非常有信心。

然而，需要注意的是，尽管序列的“着色”证实了我们的分类，但似然比的计算是独立于‘着色’进行的，后者利用了我们对同义或保守替换的知识。这进一步意味着，该方法通过观察高得分替换，自动从发生的替换模式中推断遗传密码。在具有不同遗传密码的物种中，密码子交换的模式将有所不同；例如，在白假丝酵母中，CTG编码丝氨酸（极性）而非亮氨酸（疏水性），这一点可以从CSMs中推断出来。然而，该方法并不需要这方面的知识；相反，我们可以从CSM中推断出*a posteriori*。

总之，我们能够基于进化特征区分基因组的非编码区和编码区，通过创建两个独立的64乘64的*rate matrices*：一个衡量编码区密码子替换速率，另一个衡量非编码区。速率矩阵给出了单位时间内密码子或核苷酸的交换率。

我们使用这两个矩阵来计算任何给定比对的两种概率：它来自编码区的可能性以及它来自非编码区的可能性。取这两个概率的*likelihoodratio*，可以得到比对是蛋白质编码的置信度度量，如图4.19所示。使用这种方法，我们可以挑选出根据蛋白质编码特征进化的基因组区域。

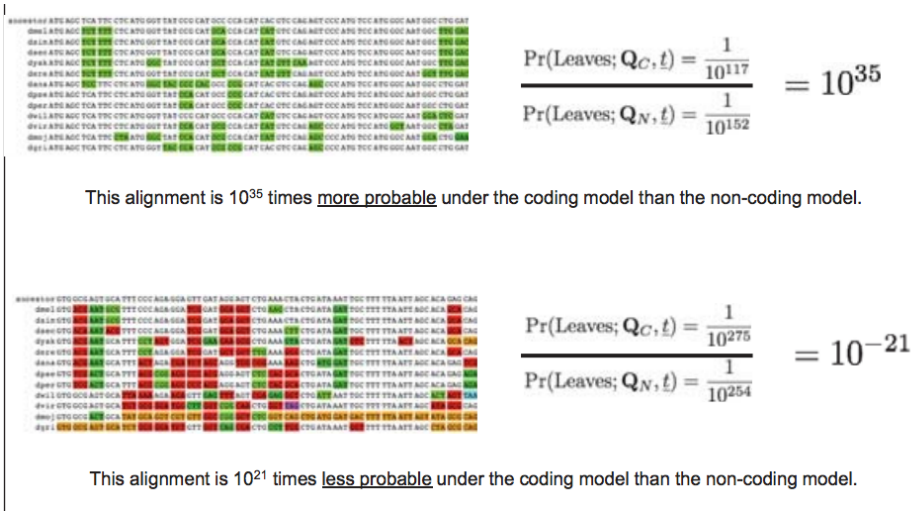

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图4.19：从图中可以看出，对于可能是蛋白质编码的序列，似然比为正，而对于不太可能是蛋白质编码的序列，似然比为负。

稍后我们将看到如何将这种似然比方法与系统发育方法相结合，以寻找蛋白质编码区的进化模式。

然而，这种方法仅能帮助我们找到在翻译水平上受到选择的区域。关键在于，此处我们仅检测蛋白质编码的选择。今天我们将探讨如何寻找其他具有独特特征的保守功能元件。

4.5.3 Classification of *Drosophila* Genome Sequences

我们已经看到，使用这些RFC和CSF度量允许我们以极高的特异性和敏感性对外显子和内含子进行分类。使用这些度量对序列进行分类的分类器可以通过HMM或半马尔可夫条件随机场（SMCRF）来实现。CRFs允许整合不一定是概率性质的各种特征，而HMMs则要求我们建模

将一切视为转移和发射概率。CRFs将在即将到来的讲座中讨论。人们可能会想知道，既然检查阅读框保守性的简单方法效果良好，为何还需要实现这些更复杂的方法。原因是，在非常短的区域内，插入和缺失即使偶然发生也会非常罕见，因此没有足够的信号来区分蛋白质编码区和非蛋白质编码区。在下面的图中，我们沿x轴看到一条DNA序列，各行分别代表一个注释基因、保守程度、蛋白质编码进化特征的数量，以及使用SMCRF进行维特比解码的结果。

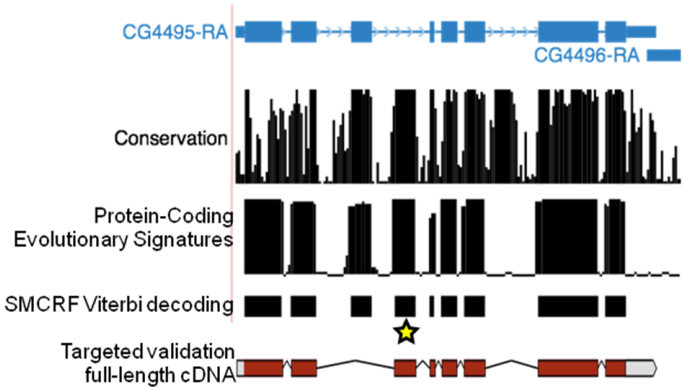

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图4.20：进化特征能够预测新基因和外显子。星号表示一个新外显子，它是通过三种比较基因组学测试预测出来的，随后通过cDNA测序得到了验证。

这是利用蛋白质编码特征对区域进行分类的一个非常成功的例子。识别那些曾被认为是基因但不具有高蛋白质编码特征的区域，使我们能够强烈排除果蝇基因组中先前被归类为仅CGid基因的414个基因，这促使FlyBase策展人删除了其中222个，并将另外73个标记为不确定。此外，还存在明确的假阴性，因为所检查的基因有功能证据。最后，在数据中，我们还看到既有保守性，又有大量蛋白质编码特征，但之前未被标记为基因部分的区域，如图4.20所示。其中一些已经过实验测试，并已被证明是新基因的一部分或现有基因的延伸。这强调了计算生物学在利用和指导实验工作方面的效用。

4.5.4 Leaky Stop Codons

终止密码子（DNA中的TAA、TAG、TGA以及RNA中的UAG、UAA、UGA）通常标志着一个基因的终止。当在mRNA中发现时，它们清晰地反映了翻译的终止，并将氨基酸链从核糖体释放。然而，在一些不寻常的情况下，观察到了翻译越过第一个终止密码子继续进行的现象。在单次通读的情况下，存在一个具有明确蛋白质编码特征区域内的终止密码子，随后不远处有第二个终止密码子。人类基因组中的一个例子在图4.21中给出。这表明翻译穿过了第一个终止密码子。双次通读的情况，即两个终止密码子位于蛋白质编码区内，也已被观察到。在这些终止密码子抑制的实例中，终止密码子被发现高度保守，表明这些被跳过的终止密码子扮演着重要的生物学角色。

翻译通读在两种果蝇中都保守，果蝇中有350个已鉴定的蛋白质表现出终止密码子通读，而人类中有4个已鉴定的此类蛋白质实例。它们主要在成年大脑的神经元蛋白质和果蝇中脑表达的蛋白质中观察到。

kelch基因展示了终止密码子抑制作用的另一个例子。该基因编码两个开放阅读框，它们之间有一个UGA终止密码子。从这个序列翻译出两种蛋白质，一种来自第一个开放阅读框，另一种来自整个序列。这两种蛋白质的比例以组织特异性的方式受到调控。就kelch基因而言，终止密码子从UGA突变为UAA会导致功能丧失，这表明tRNA抑制是终止密码子抑制背后的机制。

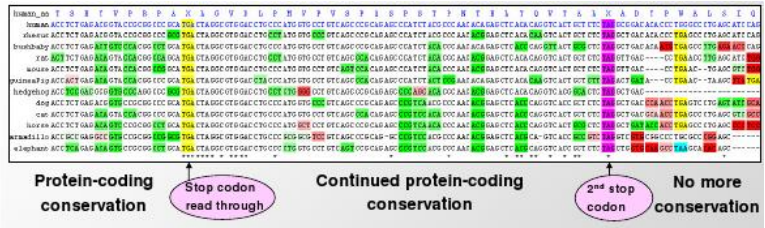

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图4.21：OPRL1神经递质：人类基因组中四个新的翻译通读候选之一。注意，第一个终止密码子之后的区域展现出与终止密码子之前的编码区相似的进化特征，表明该终止密码子被“抑制”。

终止密码子抑制的另一个例子是Caki，一种在*Drosophila*中活跃于调节神经递质释放的蛋白质。开放阅读框（ORFs）是包含起始和终止密码子的DNA序列。在Caki中，以第一阅读框（Frame 0）读取基因比以Frame 1或Frame 2读取产生显著更多的ORFs（多出440个ORF）。图4.22列出了ORF过剩的十二种可能解释。然而，由于仅在Frame 0中观察到过剩，只有前4种解释是可能的：

- 终止密码子通读：当核糖体引入与终止密码子错误配对的tRNA时，终止密码子被抑制。
- 最近的无义突变：也许最近的一些无义突变导致了终止密码子的通读。
- A到I编辑：与我们之前的想法不同，RNA在转录后仍可被编辑。在某些情况下，A碱基会变为I，而I可被读取为G。这可以将TGA终止密码子变为TGG，后者编码一种氨基酸。然而，这种现象仅在少数情况下被发现。
- 硒代半胱氨酸，即“第21种氨基酸”：有时，当TGA密码子被一个特定环读取，导致RNA的特定折叠时，它可被解码为硒代半胱氨酸。然而，这仅发生在四种蝇类蛋白质中，因此无法解释所有终止密码子的抑制现象。

在这四种情况中，有三种（近期无义突变、A到I编辑和硒代半胱氨酸）仅占17例。因此，似乎通读必须对剩余案例中的大多数（如果不是全部）负责。此外，观察到终止密码子使用的偏好性，从而排除了其他过程，如可变剪接（转录后RNA外显子以多种方式重新连接，导致多种蛋白质）或独立的开放阅读框。

通读区域可以通过其密码子使用模式在单一物种中确定。如图4.23所示的Z曲线测量了DNA区域中的密码子使用模式。从图中可以观察到，通读区域与常规终止密码子之前的分布相匹配。然而，在第二个终止密码子之后，该区域与常规终止后发现的区域相匹配。

课堂上提出的另一个建议是核糖体滑动的可能性，即核糖体在翻译过程中跳过某些碱基。这可能导致核糖体跳过终止密码子。这种现象发生在细菌和病毒基因组中，它们有更大的压力保持基因组小，因此可以使用这种滑动技术在每个不同的阅读框中读取单个转录本。然而，人类和果蝇没有这样极端的压力来保持其基因组小。此外，我们在上面展示了在终止密码子之外观察到的过量是框0特异性的，表明核糖体滑动不是原因。

细胞通常是随机的，大多数过程能容忍低频错误。系统并不完美，终止密码子泄露时有发生。然而，以下证据表明，终止密码子通读并非随机，而是受到调控控制：

- 在93%的案例中观察到通读终止密码子的完美保守，这远高于背景中的24%。
- 在读穿终止密码子上游观察到保守性增加。

	Frame 0	Frame 1	Frame 2
Interpretation			
Readthrough	√		
Recent nonsense	√		
A -> I editing	√	Only 17 cases.	
Selenocysteine	√		
Alternative splicing	√	√	√
Dicistronic	√	√	√
Cryptic promotor	√	√	√
Hopping	√	√	√
Antisense	√	√	√
Chance	√	√	√
Frame shift		√	√
CDS overlaps stop		√	√
# with PCSF > 0	662	219	225

图4.22：终止密码子抑制的各种解释。详见正文说明。

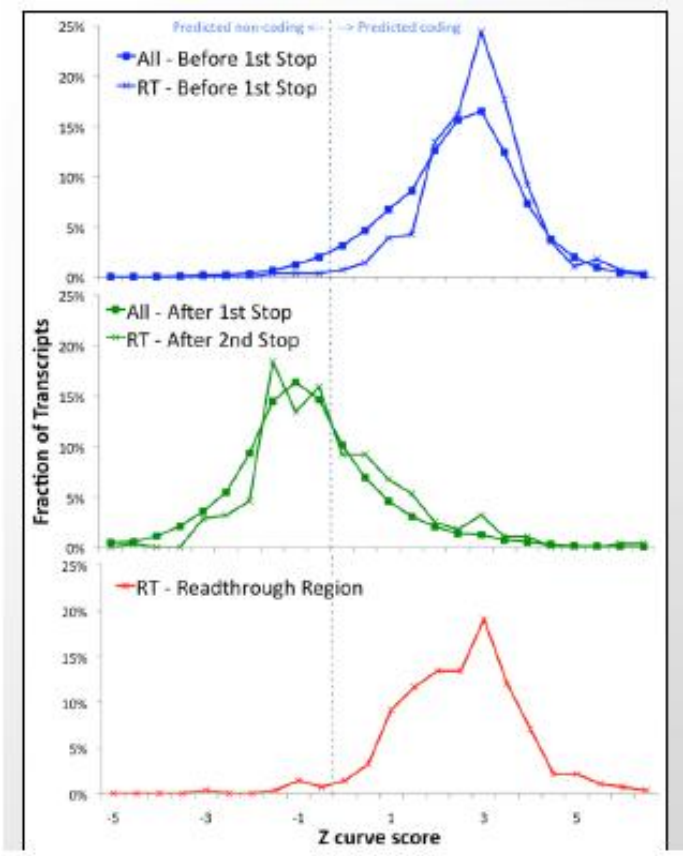

图4.23：*Caki*的Z曲线。注意，通读区域中的密码子使用与第一个终止密码子之前的区域中的密码子使用相似。

- 观察到终止密码子偏好性。TGAC是read中终止密码子处最常见的序列–

通过且最不常见于正常终止密码子处。已知它是一个“渗漏”终止密码子。TAAA几乎普遍仅存在于非通读实例中。

- 通过通读终止密码子观察到异常高数量的GCA重复。
- 转录后观察到RNA二级结构增加，表明存在进化上保守的发夹结构。

4.6 microRNA (miRNA) Gene Signatures

受高度保守影响的功能基因组区域的一个例子是编码微小RNA（miRNA）的序列。miRNA是一种RNA分子，它们与目标mRNA分子3’非翻译区的互补序列结合，导致基因沉默。

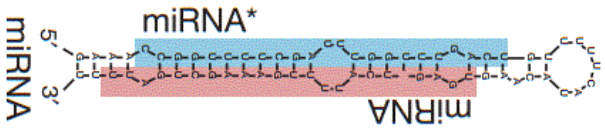

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图4.24：微小RNA的发夹结构。注意，miRNA*表示发夹对侧的链，其序列与被miRNA抑制的mRNA分子相同。

我们如何找到miRNA基因及其靶标的进化特征，并且能否利用这些特征来获得关于它们生物学功能的新见解？我们将看到，这是一项艰巨的任务，因为miRNA留下了一个高度保守但非常微妙的进化信号。

4.6.1 Computational Challenge

预测miRNA基因及其靶标的位置是一个计算上的难题。我们可以寻找“发夹”区域，在那里我们发现彼此互补的核苷酸序列并预测发夹结构。但在细胞中发现的760，355个类似miRNA的发夹中，只有60-100个是真正的miRNA。因此，为了进行任何能给我们提供统计上可能是miRNA区域的测试，我们需要一个具有99.99%特异性的测试。

图4.25是miRNA基因保守模式的一个示例。你可以看到红色和蓝色区域中保守的两个发夹结构，中间有一个低保守区域。这种模式是miRNA的特征。

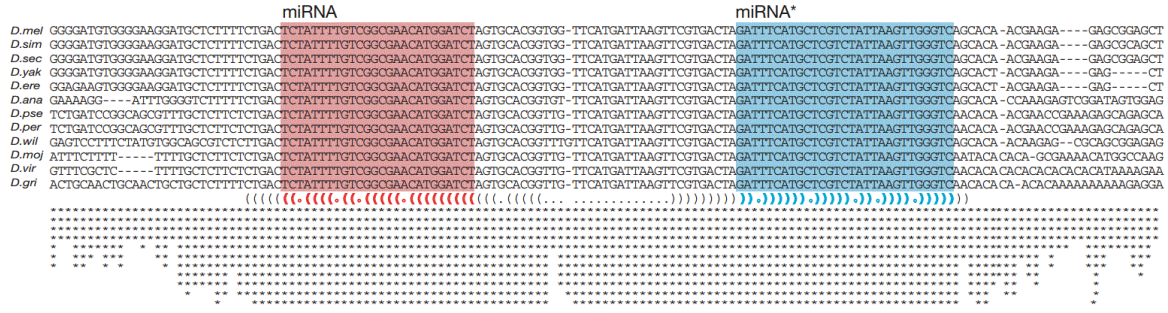

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图4.25：miRNA的特征保守模式。核苷酸下方的星号数量表示该核苷酸在多少个物种中保守。蓝色和红色高度保守区域代表miRNA的互补链，如图4.24所示。

通过分析miRNA特有的进化和结构特征，我们可以利用这些特征的组合来挑选出miRNA区域，其富集程度相比随机发夹结构高出>4,500倍。以下是帮助识别miRNA的特征示例：

- miRNAs与3’UTR中高度保守的靶基序结合
- miRNAs可以在已知基因的内含子中找到

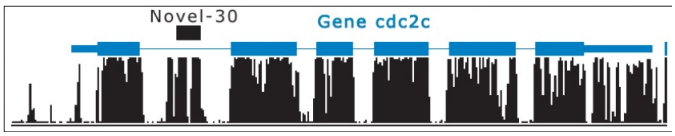

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图4.26：内含子中的新miRNA

- miRNA偏好DNA的正链和转录因子
- miRNAs通常不存在于基因组的外显子和重复元件中（反例见图4.29）。
- 新型miRNA可能与已知miRNA聚集，特别是如果它们属于同一家族或具有共同起源

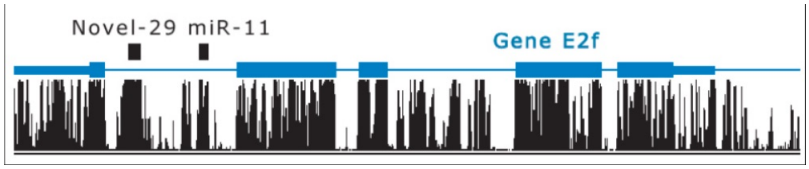

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图4.27：新颖和已知miRNA聚类。

miRNA编码区的这些特征可以归为结构家族，从而能够基于每个家族中已知的RNA构建分类器。RNA结构的能量考量可用于支持这种家族分类。在每个家族内，会发生直系同源保守（不同物种中具有相同功能且源自共同祖先基因的基因）和旁系同源保守（同一物种内复制并演化出不同功能的基因）。

Evolutionary	**Structural**
与保守性分布的相关性	发夹结构稳定性（MFE z-score）
共识折叠的MFE	非对称循环的数量
结构保守性指数	对称循环的数量

我们可以通过使用决策树将多个特征合并到一个测试中，如图4.28所示。在树的每个节点上，应用一个测试来确定接下来将遵循哪个分支。从根节点开始遍历树，直到到达终端节点，此时树将输出一个分类。可以使用已分类的基因组子序列体来训练决策树，之后它可用于预测新子序列是否为miRNAs。此外，许多决策树可以组合成一个“随机森林”，其中训练了几棵决策树。当需要对一个新的核苷酸序列进行分类时，每棵树都会投票决定它是否为miRNA，然后汇总投票结果以确定最终的分类。

将该技术应用于果蝇基因组后，显示出101个发夹结构超过0.95的阈值，重新发现了74个已知miRNA中的60个，预测了24个经实验验证的新miRNA，并找到了另外17个显示出多种功能证据的候选miRNA。

4.6.2 Unusual miRNA Genes

在观察特定miRNA基因时，发现了以下四个“意外”：

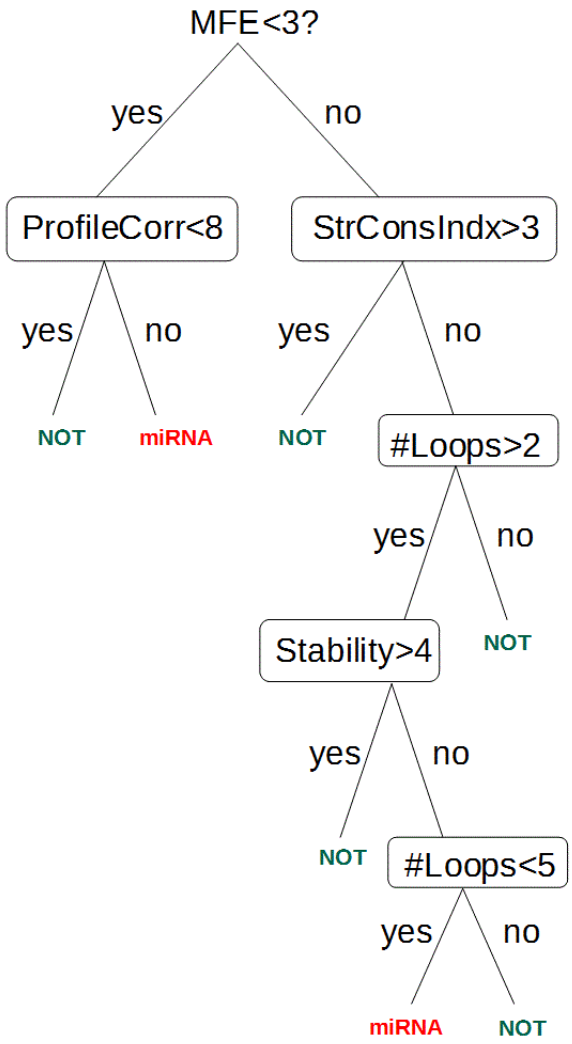

图4.28：用于miRNA检测的一个可能的决策树。该树使用的特征包括最小自由能、保守性轮廓相关性、结构保守性指数、环的数量以及稳定性。

惊喜1 两条链都可能被表达且具有功能。例如，在miR-iab-4基因中， sense和antisense链在胚胎的不同区域表达。两条链预测miRNA的得分均为> 0.95。

意外 2 某些 miRNA 可能在一个 miRNA 臂上具有多个 5’ 端，这为不精确的起始位点提供了证据。这可能导致产生多种成熟产物，每种都可能具有其自身的功能靶标。意外 3 高分 miRNA* 区域（星号臂与实际 miRNA 序列互补）表达非常高，从而产生基因组中既高表达又含有功能元件的区域。意外 4 miR−10 和 miR−10* 均已被证明是非常重要的 Hox 调控因子，从而引出预测：miRNA 可能是“主 Hox 调控因子”。第五讲第一组幻灯片的第 10 页和第 11 页展示了形成不同 Hox 基因调控网络的 miRNA 的重要性。

4.6.3 Example: Re-examining 'dubious' protein-coding genes

两个基因CG31044和CG33311因保守模式与蛋白质进化特征不符而被独立排除（见第4.5节）。基于基因组特性和高表达水平，它们被鉴定为前体miRNA（Lin等人）。这是miRNA在先前的外显子序列中被发现的罕见例子，说明了识别miRNA进化特征的挑战。

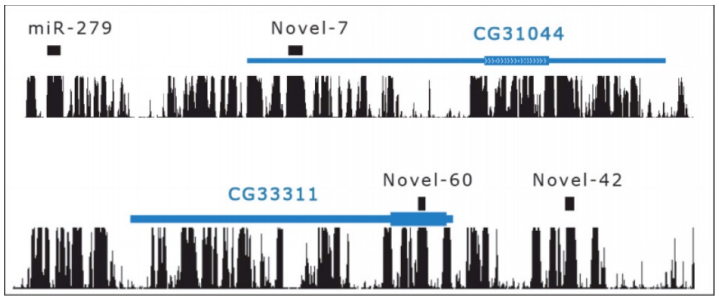

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图4.29：'可疑'蛋白质编码区域中的现有注释和转录水平。

4.7 Regulatory Motifs

另一类在许多基因组中高度保守的功能元件包含*regulatory motifs*。调控基序是高度保守的核苷酸序列，在整个基因组中出现多次，并发挥某种调控功能。例如，这些基序可能表征增强子、启动子或其他基因组元件。

```
D.mel  CAGCT--AGCC-AACTCTCTAATTAGCGACTAAGTC-CAAGTC
D.sim  CAGCT--AGCC-AACTCTCTAATTAGCGACTAAGTC-CAAGTC
D.sec  CAGCT--AGCC-AACTCTCTAATTAGCGACTAAGTC-CAAGTC
D.yak  CAGC--TAGCC-AACTCTCTAATTAGCGACTAAGTC-CAAGTC
D.ere  CAGCGGTCGCCAAACTCTCTAATTAGCGACCAAGTC-CAAGTC
D.ana  CACTAGTTCCTAGGCACTCTAATTAGCAAGTTAGTCTCTAGAG
        **       *    * *********** *   ****  * **
```

图4.30：TAATTA是一个六聚体，在许多不同的功能元件中作为基因组中的保守元素出现，包括此处。它是调控基序的一个例子。

4.7.1 Computationally Detecting Regulatory Motifs

已经开发了计算方法来测量基因组中调控基序的保守性，并发现新的未注释基序 *de novo*。已知基序通常出现在高度保守的区域，因此我们可以通过测试保守性，然后寻找调控基序的特征来提高测试效力。

评估已知基序的保守模式与无基序区域的“零模型”相比，得出以下特征：

Conservation within:	Gal4 (known motif region)	Controls
All intergenic regions	13%	2%
Intergenic: coding	13%: 3%	2%:7%
Upstream: downstream	12: 0	1:1

正如我们所见，含有调控基序的区域在基因间区及目标基因上游显示出更高程度的保守性。

要发现新的模体，我们可以使用以下流程：

- 选择一个由两组三个非退化字符组成的模体“种子”，中间有一个可变大小的间隔。
- 使用保留比率对种子模体进行排序
- 使用爬山算法扩展种子模体，以填充种子周围的碱基。
- 聚类以消除冗余。

发现模体和执行聚类已经导致了许多模体类别的发现，如组织特异性模体、功能特异性模体以及协同模体模块。

4.7.2 Individual Instances of Regulatory Motifs

为了寻找预期的模体区域，我们可以先为疑似调控模体的区域计算一个*branch–length score*，然后利用这个得分给出一个置信水平，表明某物成为真正模体的可能性有多大。

分支长度得分（BLS）对给定基序在系统发育树各分支上的证据进行求和。给定基序在树中各物种中存在或不存在的模式，该得分评估包含该基序的物种所连接的子树的总分支长度。如果所有物种都具有该基序，则BLS为100%。注意，亲缘关系较远的物种会获得更高的分数，因为它们跨越了更长的进化距离。如果一个预测的基序跨越了如此长的进化时间范围，那么它很可能是一个功能性元件，而不仅仅是一个由随机机会保守的区域。

为了构建一个零模型，我们可以选择控制模体。零模型模体应被选定为具有与原始模体相同的组成，彼此之间不太相似，并且与已知模体不同。我们可以通过比较在给定BLS分数下，模体实例与控制模体的比例来获得一个置信度分数。

4.8 Current Research Directions

4.9 Further Reading

1. 关于约束计算和识别的更多信息，请参考Lindblad-Toh等人的“利用29种哺乳动物绘制的人类进化约束高分辨率图谱”。

2. 关于翻译终止密码子通读及其进化特征，更多信息请参考Lin等人所著的《利用12种果蝇基因组重新审视黑腹果蝇的蛋白质编码基因目录》。

4.10 Tools and Techniques

1. 对于蛋白质序列比对，请参见http://mafft.cbrc.jp/alignment/software/。2. 对于原核生物中通过移码进行基因预测，请参见GeneTack。

4.11 Bibliography

Bibliography

[1] Joseph Felsenstein. 从DNA序列构建进化树：一种最大似然方法。*Journal of Molecular Evolution*，17：368–376，1981。10.1007/BF01734359。

CHAPTER

FIVE

基因组组装与全基因组比对

梅丽莎·吉姆雷克、莉兹·蔡、丽贝卡·塔夫特（2012年）、凯沙夫·丹达尼亚（2012年）、乔·维蒂（2013年）、马特·福克斯（2014年）

Figures

5.1 我们可以利用进化特征来寻找基因组功能元件，进而通过观察基因组变异和变化的模式来研究进化机制。. 91 5.2 这里简要介绍几种可用于读取基因组的平台。. . . . . 92 5.3 鸟枪法测序涉及将基因组随机打断成小片段以便测序，然后通过计算将它们重新组装成连续序列。. 93 5.4 从读数重叠构建序列. . . . . 93 5.5 我们可以通过让图中的节点表示读数、边表示重叠，来可视化将片段合并成重叠群的过程。通过移除可传递推断的边（此图中的粉色边），我们得到按顺序排列形成重叠群的读数链。 94 5.6 过度折叠的重叠群是由基因组中的重复区域引起的，这些区域在测序过程中无法相互区分。在将片段合并成重叠群的过程中出现的分支比对模式强烈表明其中一个区域可能被过度折叠。. . . . . 95 5.7 在连接重叠群的此图中，重复区域X的入度和出度均等于2。顶部所示的目标序列可以从图中的链接推断出来。. . . . . 95 5.8 配对末端帮助确定重叠群的相对顺序，以便将它们连接成超级重叠群。. . . . . 96 5.9 我们通过在每个碱基处进行加权投票来推导多序列比对一致序列。. . . 96 5.10 构建字符串图。. . . . . 97 5.11 构建字符串图 . . . . . 97 5.12 字符串图移除传递边的示例。. . . . . 98 5.13 字符串图进行链折叠的示例。. . . . . 98 5.14 *Left:* 流解析概念。*Right:* 流解析示例。. . . . . 99 5.15 用于2个和3个基因组比对的Needleman-Wunsch算法。. . . . . 101 5.16 我们可以通过首先找到所有局部比对，然后使用受限动态规划沿对角线将它们连接起来，从而在进行全局比对时节省时间。. . . . . 101 5.17 全局局部比对允许存在重复、倒位和易位的可能性。. 102 5.18 运行SLAGAN算法的步骤是：A. 找到所有局部比对，B. 构建粗略的同源图谱，以及C. 使用常规LAGAN算法对一致部分进行全局比对 . . . . . 103 5.19 利用全局局部比对的概念，我们可以发现不同物种（如人类和小鼠）之间的倒位、易位和其他同源关系。. . . . . 103 5.20 *S. cerevisae*和*S. bayanus*基因对应关系图。. 104

5.21 Illustration of gene correspondence for *S.cerevisiae* Chromosome VI (250-300bp). 104

5.22 变化基因的动态视图 105

5.23 染色体进化机制 106

5.24 在进化时间上进一步追溯酿酒酵母。。。 107

5.25 *S.cerevisiae* 染色体与 *K.waltii* 支架的基因对应关系。 108

5.26 *K.waltii* 和 *S.cerevisae* 中姊妹区域显示的基因交错 108

5.27 S-LAGAN结果. 109

5.28 IGF基因座的S-LAGAN结果 109

5.29 IGF基因座的S-LAGAN结果. 109

5.1 Introduction

在上一章中，我们了解了比较基因组学分析对于发现功能元件的重要性。在本书的“第四部分”中，我们将看到如何利用比较基因组学研究跨物种和个体的基因进化。然而，在这两种情况下，我们都假设可以获得多个物种的完整且对齐的基因组。

在本章中，我们将研究基因组组装和全基因组比对的挑战，这两者是全基因组比较基因组学方法的基础。首先，我们将研究当今许多最流行的基因组组装方法背后的核心算法原理。其次，我们将研究全基因组比对问题，这需要理解基因组重排机制（例如，片段重复和其他易位）。基因组组装和全基因组比对这两个问题在本质上是相似的，最后我们将讨论它们之间的一些相似之处。

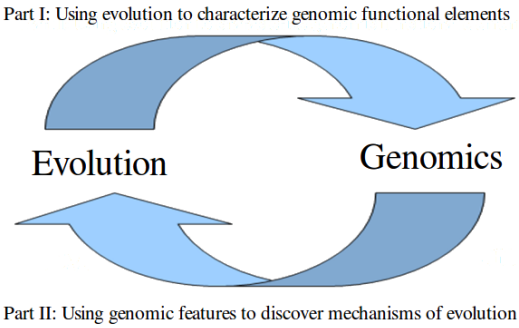

图5.1：我们可以利用进化特征来发现基因组功能元件，反过来，通过观察基因组变异和变化的模式，也能够研究进化机制。

5.2 Genome Assembly I: Overlap-Layout-Consensus Approach

计算生物学研究的许多领域都依赖于完整全基因组序列数据的可用性。然而，对全基因组进行测序的过程本身并非易事，且是一个活跃的研究领域。问题在于，当前的基因组测序技术无法从长基因组序列的一端连续读取到另一端；它们只能准确测序小片段碱基对（根据方法不同，范围从100到几千个），称为*reads*。因此，为了构建数百万或数十亿碱基对的序列（例如人类基因组），计算生物学家必须找到将较小读段组合成更大、连续DNA序列的方法。首先，我们将考察重叠-布局-一致性方法的实验设置方面，然后我们将继续学习如何组合读段并从中获取信息。

5.2.1 Setting up the experiment

建立此实验时必须首先解决的第一个挑战是，我们需要从每个染色体的许多副本开始，以便使用这种方法。这个数量大约为10^5。重要的是要注意，我们获取这些副本的方式非常重要，并且会在后续影响我们的结果，因为我们所做的许多比较将依赖于一致的数据。我们可能首先想到的获取如此多数据的方法是扩增给定的基因组。然而，扩增会造成损伤，这会在后续步骤中干扰我们的算法并导致更差的结果。另一种可能的方法是通过近亲繁殖基因组来获得每个染色体的许多副本。如果你想消除多态性，这

可能是一种好技术，但在近亲繁殖时，我们也会从多态位点丢失宝贵数据。获取这些数据的一个建议方法是使用一个个体的数据，尽管该生物体需要相当大。我们还可以使用诸如单亲后代或双亲后代等技术，以尽可能获得每种染色体的少数版本。这将在每条染色体上获得高测序深度，这就是我们希望所有染色体尽可能相似的原因。

接下来，让我们看看在现有技术条件下如何决定读取长度。观察（图5.2），我们可以看到必须进行成本效益分析，以决定在特定项目中使用哪个平台。在当前技术下，我们常用读取长度约为250的HiSeq2500，尽管这一情况正在迅速变化。

capability	platform	read length	scale	cost	other
short reads	HiSeq 2500	125	high	medium	high output mode
longer reads	HiSeq 2500	250	high	medium	rapid run mode
	MiSeq	300	low	high	
cheap human reads	HiSeq X	150	high	low	human only min 10 purchase

图5.2：此处是　　快速了解几个可用于阅读的平台　　基因组。

最后，让我们来看一些在使用短读长平台时会引起麻烦的序列。高GC含量的序列（例如GGCGGCGATC）、低GC含量的序列（例如AAATAATCAA）或低复杂度的序列（例如ATATATATA）可能会给短读长带来麻烦。这仍然是一个活跃的研究领域，但一些可能的解释包括聚合酶滑移以及DNA变性过于容易或不够容易。

本节将探讨一种从一组 DNA 读段计算组装基因组的最成功的早期方法之一，称为鸟枪法测序（图 5.3）。鸟枪法测序涉及将同一基因组的多个副本随机打断成许多小片段，就像用霰弹枪射击 DNA 一样。通常，DNA 实际上是使用超声破碎（超声波的短暂爆发）或设计用于在特定序列基序处切割基因组的靶向酶来片段化的。这两种方法都可以调整以产生不同大小的片段。

在DNA被扩增和片段化之后，使用由弗雷德里克·桑格于1977年开发的称为链终止测序（也称为桑格测序）的技术对片段进行测序。简而言之，片段由DNA聚合酶延伸，直到掺入一个双脱氧核苷三磷酸；这些特殊核苷酸会导致片段延伸的终止。因此，片段的长度成为给定ddNTP在序列中添加位置的代理。可以运行四个单独的反应，每个反应使用不同的ddNTP（A、G、C、T），然后将结果在凝胶上电泳，以确定碱基的相对顺序。结果是许多带有相应逐碱基质量分数的碱基序列，表示每个碱基被正确判读的概率。较短的片段可以被完整测序，但较长的片段只能在其两端进行测序，因为质量会显著下降

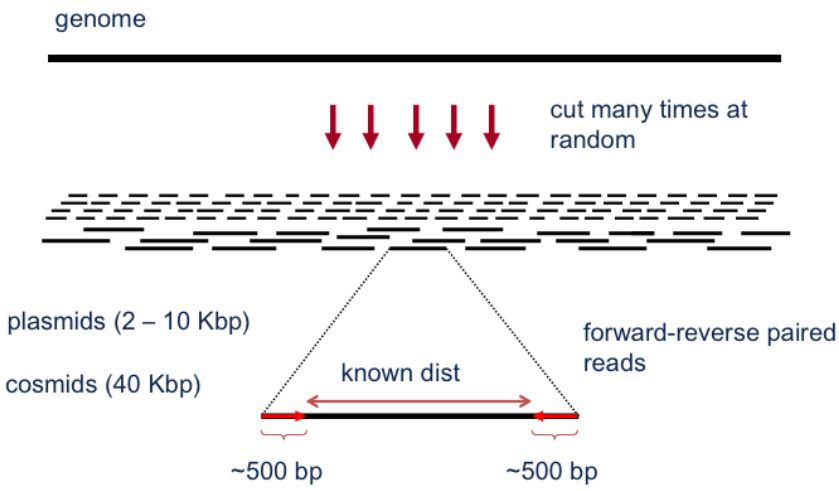

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图5.3：鸟枪法测序涉及将基因组随机打断成小片段以便进行测序，然后通过计算将它们重新组装成连续序列。

大约在500-900个碱基对之后。这些双端读取被称为*mate pairs*。在本节的剩余部分，我们将讨论如何利用这些读取来构建更长的序列，直至整个染色体的长度。

5.2.2 Finding overlapping reads

为了将DNA片段组合成更大的片段，我们必须找到两个或多个读段重叠的位置，即一个片段的起始序列与另一个片段的末尾序列相匹配的地方。例如，给定两个片段，如ACGTTGACCGCATTCGCCATA和GACCGCATTCGCCATACGGCATT，我们可以基于重叠部分构建一个更大的序列：ACGTTGACCGCATTCGCCATACGGCATT（图5.4）。

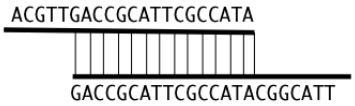

图5.4：从读取重叠构建序列

寻找匹配序列的一种方法是Needleman-Wunsch动态规划算法，该算法在第2章中已讨论过。然而，由于我们需要执行数百万次成对对齐，每次耗时$O(n^2)$，以便从DNA片段构建整个基因组，因此Needleman-Wunsch方法对于基因组组装来说是不切实际的。

更好的方法是使用BLAST算法（在第3章中讨论）对读段中的所有k聚体（长度为k的唯一序列）进行哈希，并找出两个或更多读段共有一个k聚体的所有位置。这使我们能够实现$O(k^n)$效率，而不是$O(n^2)$成对比较。k可以是任何小于读段大小的数字，但会根据所需的灵敏度和特异性而变化。通过调整读段长度以跨越基因组中的重复区域，我们可以正确地解析这些区域

并且非常接近完整、连续的基因组的理想状态。一个名为 Arachne 的流行的重叠-布局-一致性组装器使用了 $k = 24$ [2]。

给定匹配的 k-mers，我们可以比对每个对应的读数，并丢弃任何相似度低于97%的匹配项。我们并不要求读数完全相同，因为我们考虑到可能存在测序错误和杂合性（即，像人类这样的二倍体生物可能在多态位点拥有两种不同的变异）。

5.2.3 Merging reads into contigs

使用上述技术来寻找 DNA 片段之间的重叠部分，我们可以将较大的连续序列片段拼接在一起，这些片段被称为 *contigs*。可视化这一过程的一种方法是创建一个图，其中所有节点代表 reads，边代表 reads 之间的重叠（图 5.5）。我们的图将具有 *transitive overlap*；也就是说，一些边将连接那些已经通过中间节点相连的不相邻节点。通过去除可传递推断出的重叠，我们可以创建一条经过排序的 reads 链，从而形成更大的 contig。这些图变换将在下文 5.3.1 节中更深入地讨论。为了更好地理解 contig 的大小，我们计算一种称为 *N50* 的指标。由于 contig 长度的度量往往对最小 contig 截断值高度敏感，N50 按长度加权中位数计算。对于人类而言，N50 通常接近 125 kb。

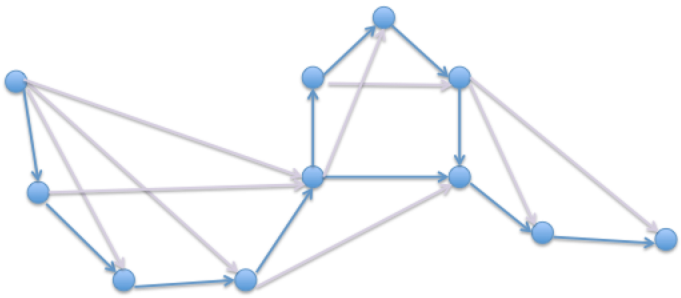

图5.5：通过让图中的节点代表读取序列，边代表重叠区域，我们可以可视化将片段合并成连续序列的过程。通过移除可传递推断的边（此图中粉色的边），我们得到了一系列排序后的读取序列，形成了连续序列。

理论上，只要我们对给定区域有足够的覆盖度，就应该能够利用上述方法从读取序列中构建出大的重叠群。然而在实践中，我们常遇到基因组中极其重复的大片段，因此难以组装。例如，如何准确比对以下两个序列：ATATATAT和ATATATATAT并不明确。由于序列模式中的信息含量极低，它们可能以多种方式重叠。此外，这些重复区域可能出现在基因组的多个位置，很难确定哪些读取来自哪个位置。由这些模糊、重复的读取构成的重叠群被称为*overcollapsed contigs*。

为了确定哪些区域过度折叠，通常可以量化构成每个重叠群（contig）的片段的覆盖深度。如果一个重叠群的覆盖度显著高于其他重叠群，那么它很可能是过度折叠区域的候选。此外，多个独特的重叠群可能在同一位置与一个重叠群重叠，这是该重叠群可能过度折叠的另一个迹象（图5.6）。

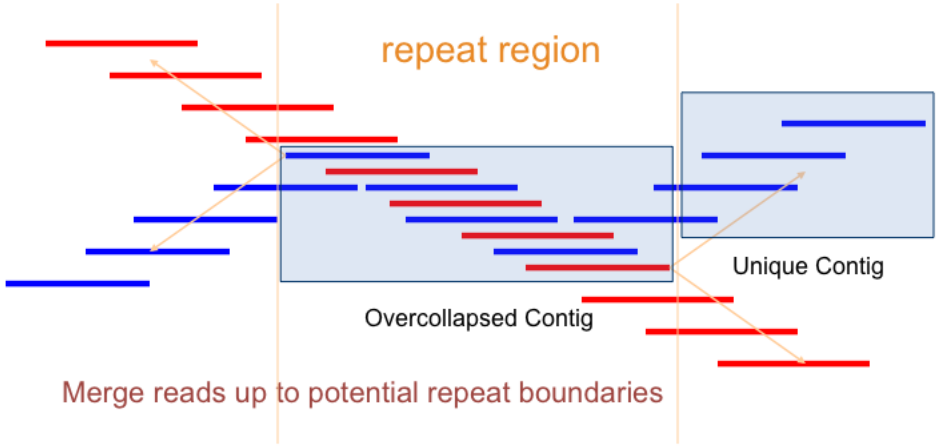

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图5.6：过度折叠的重叠群是由基因组中的重复区域引起的，这些区域在测序过程中无法相互区分。在将片段合并为重叠群的过程中出现的分支对齐模式强烈表明，其中一个区域可能被过度折叠了。

将片段组装成可能重复区段之前的重叠群后，结果是一个图，其中节点是重叠群，边是独特重叠群与过度压缩重叠群之间的链接（图5.7）。

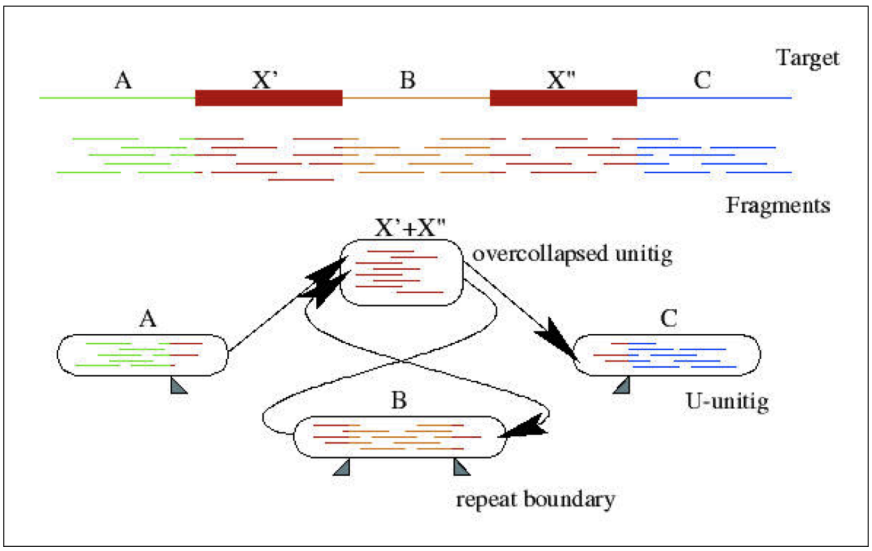

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图5.7：在这个连接重叠群的图中，重复区域X的入度和出度均为2。顶部所示的目标序列可以从图中的链接推断得出。

5.2.4 Laying out contig graph into scaffolds

一旦我们的片段组装成重叠群和重叠群图，我们就可以使用较大的配对读段将重叠群连接成*supercontigs*或*scaffolds*。配对读段既有助于确定重叠群的方向，也有助于将它们按正确顺序排列。如果配对读段足够长，它们通常可以跨越重复区域，并帮助解决上一节所述的歧义（图5.8）。

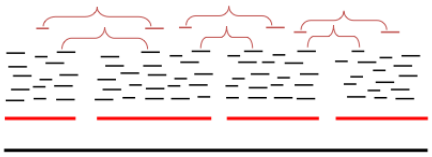

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图5.8：配对帮助确定重叠群的相对顺序，以便将它们连接成超级重叠群。

与重叠群不同，超级重叠群可能因连接重叠群的配对末端仅测序了两端而在序列中包含一些间隙。由于我们通常知道给定配对末端的大致长度，我们可以估计缺失了多少碱基对，但由于鸟枪法测序中切割的随机性，我们可能没有可用数据来填补确切的序列。填补每一个间隙都可能极其昂贵，因此即使是最完整组装的基因组通常也包含一些间隙。

5.2.5 Deriving consensus sequence

基因组组装的目标是创建一个连续的序列，因此在读取序列被比对到重叠群后，我们需要解决它们之间的任何差异。如上所述，由于测序错误或多态性，一些重叠的读取序列可能不完全相同。当一个碱基与所有其他比对到它的碱基不一致时，我们通常可以确定发生了测序错误。考虑到每个碱基的质量分数，我们通常可以相当容易地解决这些冲突。这种冲突解决方法称为加权投票（图5.9）。另一种选择是忽略每个碱基的频率，并将最高质量的字母作为共识。有时，你会希望保留形成多态集合的所有碱基，因为这可能是重要的信息。在这种情况下，我们将无法使用这些方法来推导共识序列。

图5.9：我们通过在每个碱基处进行加权投票来推导多序列比对一致序列。

在某些情况下，无法达成共识，例如，如果基因组是杂合的，并且在某个位置有两种不同碱基的数量相等。在这种情况下，组装器必须选择一个代表。

Did You Know?

由于多态性会显著增加二倍体基因组组装的复杂性，一些研究人员在尝试对基因组进行测序之前，会在选定的物种中诱导几代近亲繁殖，以减少杂合度。

本节中，我们了解了一种根据读取片段进行基因组装配的算法。然而，当读取片段长度达到500至900个碱基或更长时，该算法表现良好，这是Sanger测序的典型特征。如果我们从测序方法中获得的读取片段要短得多，就需要采用其他的基因组装配算法。

5.3 Genome Assembly II: String graph methods

霰弹枪测序是一种更为现代且经济的测序方法，它能产生长度约为100个碱基的读数。读数较短的特性导致大量重复序列的长度超过读数本身。因此，我们需要新的、更复杂的算法来正确进行基因组组装。

5.3.1 String graph definition and construction

字符串图组装背后的思想类似于我们在5.2.2节中看到的读取图。简而言之，我们构建一个图，其中节点是序列数据，边是重叠部分，然后尝试找到一条通过所有边的最稳健路径，以代表我们的底层序列。

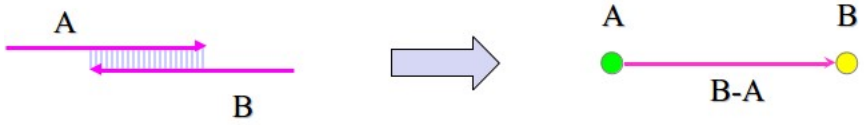

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图5.10：构建字符串图。

从Shotgun测序得到的reads出发，通过为每一对重叠的reads添加一条边来构建字符串图。注意，图的顶点表示连接点，边对应于碱基串。每个read对应一个单独的节点，遍历图时到达该节点相当于读取该节点对应read末尾之前的所有碱基。例如，在图5.10中，我们有两个重叠的reads A和B，且它们是我们仅有的reads。相应的字符串图有两个节点和两条边。一条边的尾端没有顶点，头端为A。这条边表示read A中的所有碱基。第二条边从节点A到节点B，仅表示B-A中的碱基（即read B中不与A重叠的部分）。这样，当我们遍历每条边一次时，恰好读取整个区域一次。特别地，注意我们不会两次遍历read A和read B的重叠部分。

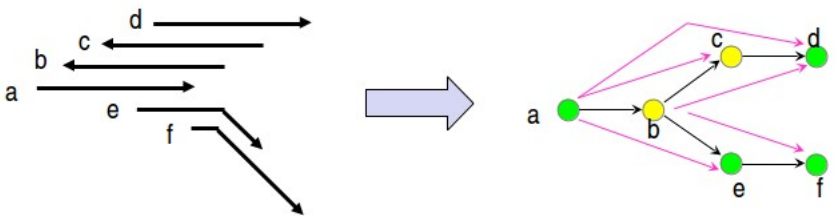

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图5.11：构建弦图

字符串图（图5.11）中有几个微妙之处需要提及：

- 由于DNA可以从两个方向读取，节点有两种不同的颜色。如果重叠发生在读数之间，则节点接收相同的颜色。而如果重叠发生在读数与另一个读数的互补碱基之间，则它们接收不同的颜色。

- 其次，如果A和B重叠，那么在绘制从A到B的边还是从B到A的边时存在歧义。这种歧义需要在因重复导致的交汇点处一致地解决。

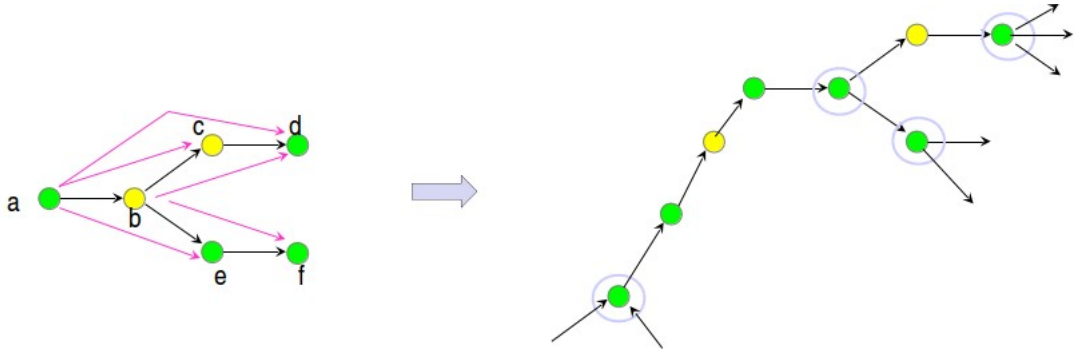

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图5.12：经历传递边移除的字符串图示例。

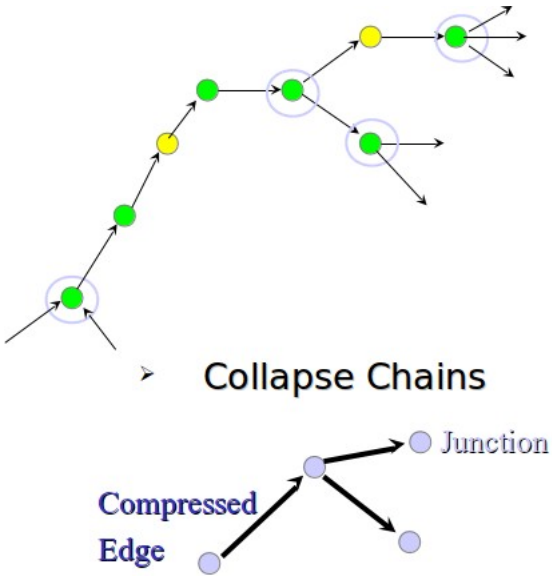

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图 5.13：经历链折叠的字符串图示例。

在从重叠读取中构建字符串图之后，我们：-

- *Remove transitive edges:* 传递边是由传递重叠引起的，即A与B重叠，B与C重叠，以至于A与C重叠。存在随机算法，其期望运行时间为O(E)，可以移除传递边。在图5.12中，您可以看到一个移除传递边的例子。

- *Collapse chains:* 删除传递边后，我们构建的图将包含许多链，每个节点都有一条入边和一条出边。我们将所有这些链折叠为单一边。图5.13展示了这一示例。

5.3.2 Flows and graph consistency

完成上述所有步骤后，我们将得到一个相当复杂的图，即由于基因组中相对较长的重复序列与读长相比，图中仍会存在多个交汇点。我们现在将探讨如何利用流的概念来处理重复序列。

首先，我们根据与边对应的读取数量来估算每条边的权重。如果某条边的读取数量是我们所测序DNA数量的两倍，那么可以合理假设基因组的这一区域发生了重复。然而，这种技术本身不够准确。因此，有时我们可能通过说某条边的权重是≥ 2来进行估算，而不是给它指定一个具体的数字。

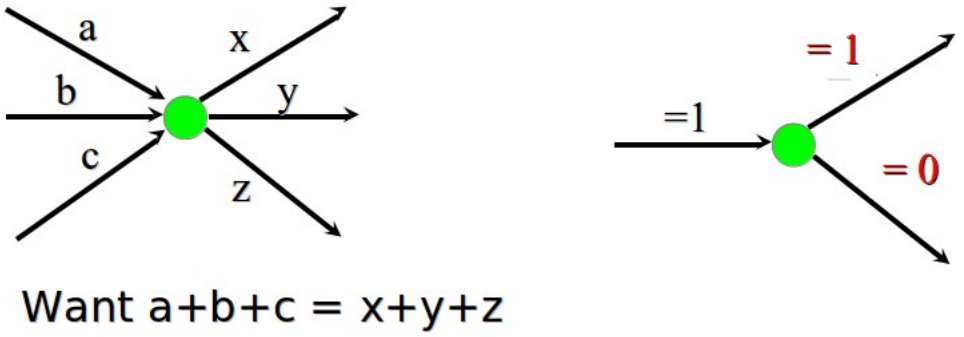

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图5.14：*Left:*流动解析概念。*Right:*流动解析示例。

我们利用流中的推理来解决这类歧义。我们需要在每个交汇点满足流约束，即所有进入边的总权重必须等于所有离开边的总权重。例如，在图5.14中，有一个交汇点，其进入边权重为1，两条离开边的权重分别为≥ 0和≥ 1。因此，我们可以推断出离开边的权重分别精确等于0和1。通过在整个图中迭代应用这一相同过程，可以推断出大量权重。

5.3.3 Feasible flow

一旦我们有了图和边权重，就在图上运行最小成本流算法。由于较大的基因组可能没有唯一的最小成本流，我们迭代执行以下操作：

- 为解决方案中的所有边添加 ϵ 惩罚
- 再次求解流 - 如果存在替代的最小成本流，它相对于前一个流将具有更小的成本。
- 重复直到我们找不到新的边

完成上述操作后，我们将能够将每条边标记为以下之一

- *Required:* 作为所有解决方案一部分的边
- *Unreliable:* {v*}的一些解决方案中涉及的边
- *Not required:* 不属于任何解的边

5.3.4 Dealing with sequencing errors

基因组测序过程中有多种误差来源。误差通常分为两种不同类型：局部误差和全局误差。

局部错误包括插入、缺失和突变。这些局部错误在我们寻找重叠读段时会得到处理。也就是说，在检查读段是否重叠时，我们会在容忍测序错误的情况下检查重叠。一旦计算出重叠，我们就可以通过诸如移除未被其他任何读段支持且至少被2个读段反驳的插入缺失和突变等机制来推导出共识。

全局错误由其他机制引起，例如两个不同的序列在读取前结合在一起，因此我们得到的读取来自基因组的不同位置。这类读取被称为嵌合体。这些错误在寻找网络中的可行流时得到解决。当对应于嵌合体的边被使用时，通过这条边的流量相比流量容量较小。因此，该边可以被检测到并随后忽略。

算法的每一步都尽可能做到稳健且能抵御测序错误。而拆分并测序的DNA数量则以能够构建出大部分DNA的方式来决定（即满足如98%或95%这样的质量保证）。

5.3.5 Resources

下面列出了一些使用字符串图的流行基因组组装器

- 欧拉（Pevzner，2001/06）：索引→德布鲁因图→挑选路径→共识
- Valvel (Birney, 2010)：短读长 → 小基因组 → 简化 → 错误校正
- ALLPATHS（Gnerre，2011）：短读长 → 大基因组 → 跳跃数据 → 不确定性

5.4 Whole-Genome Alignment

一旦我们获得了几个不同物种的全基因组序列，我们就可以尝试将它们比对，以推断进化分化这些物种所采取的路径。在本节中，我们将讨论一些用于在多个物种之间进行全基因组比对的方法。

5.4.1 Global, local, and 'glocal' alignment

第2章讨论的Needleman-Wunsch算法是生成两个或多个有限大小的基因组序列之间最优比对的最佳方法。然而，在全基因组层面上，$O(n^2)$的时间界限是不切实际的。此外，为了找到k不同物种之间的最优比对，Needleman-Wunsch算法的时间扩展到$O(n^k)$。对于长达数百万碱基的基因组，这种运行时间是难以承受的（图5.15）。

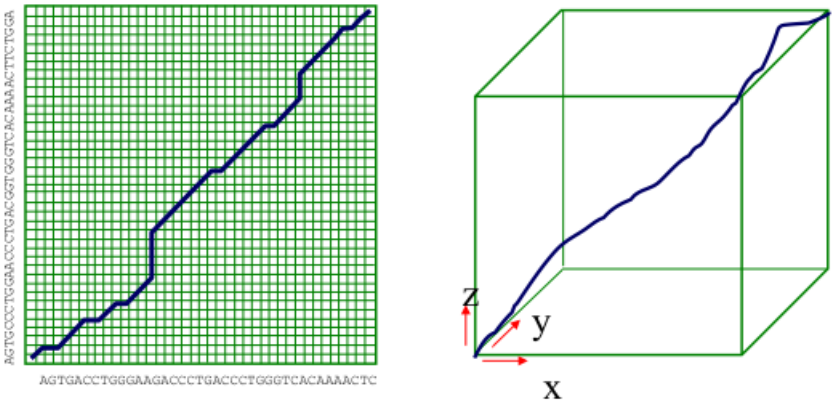

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图5.15：用于2个和3个基因组比对的Needleman-Wunsch算法。

一种替代方法是使用高效的局部比对工具，如BLAST，来找出所有局部比对，然后沿对角线将它们串联起来形成全局比对。这种方法可以节省大量时间，因为寻找局部比对的过程非常高效，之后我们只需在局部比对之间的小矩形区域内执行耗时的Needleman-Wunsch算法（图5.16）。

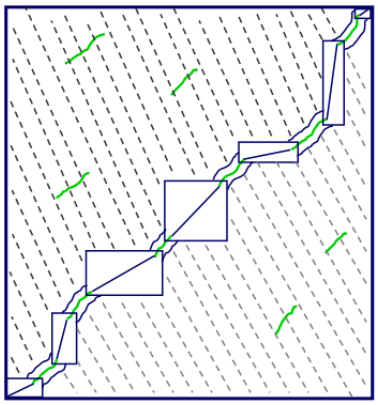

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图5.16：在进行全局对齐时，我们可以通过首先找到所有局部对齐，然后沿对角线使用受限动态规划将它们串联起来，以此节省时间。

全基因组比对的一种新颖方法是将局部比对搜索扩展到包括倒位、重复和易位。接着，我们可以利用序列间成本最低的转换将这些元素串联起来。这种方法通常被称为全局局部比对，因为它旨在结合局部比对和全局比对的优点，以最准确地描绘基因组随时间演化的过程（图5.17）。

5.4.2 Lagan: Chaining local alignments

LAGAN 是一个流行的软件工具包，它融合了上述许多理念，可用于物种间的局部、全局、全局部以及多重比对。

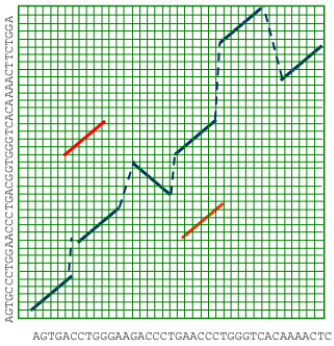

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图5.17：Glocal对齐　　nment 允许重复、反转的可能性　　，以及易位。

常规LAGAN算法包括寻找局部比对、沿对角线链接局部比对，以及随后执行受限的动态规划以找出局部比对间的最优路径。

Multi-LAGAN使用与常规LAGAN相同的方法，但将其推广至多物种比对。在此算法中，用户需提供一组基因组及相应的系统发生树。Multi-LAGAN在系统发生树的指导下进行成对比对，首先比较高度相关的物种，然后逐步迭代比较越来越远缘的物种。

Shuffle-LAGAN是一种全局局部比对工具，它寻找局部比对，构建粗略的同源图谱，然后对每个一致部分进行全局比对(图5.18)。为了构建同源图谱，该算法基于特定的间隙和转换惩罚，选择局部比对的最大得分子集，这些局部比对在两条序列中的至少一条上形成非递减链。与常规LAGAN不同，所有可能的局部比对序列都被视为全局局部比对中的步骤，因为它们可能代表易位、倒位和倒位易位以及常规未转换序列。一旦构建了粗略的同源图谱，该算法就将同源区域分解为大致沿同一连续路径的局部比对块。最后，将LAGAN算法应用于每个块，使用受限动态规划链接局部比对。

通过运行Shuffle-LAGAN或其他全局局部比对工具，我们可以发现不同物种间的倒位、易位及其他同源关系。通过映射这些重排之间的连接，我们能够洞悉每个物种是如何从共同祖先演化而来的（图5.19）。

5.5 Gene-based region alignment

另一种比对多个基因组的方法是根据基因组片段所含基因对其进行锚定，并利用基因的对应关系来确定每对物种中相对应的区域。随后，依据先前描述的方法，在每个多重保守区域中构建核苷酸水平的比对。

由于并非所有区域都一一对应，且序列并非静止不变，这使得问题更为复杂：基因会经历分化、复制和丢失，整个基因组也会发生重排。为帮助克服这些挑战，研究人员会考察不同基因组间基因对的氨基酸相似性以及基因在各基因组内的位置。

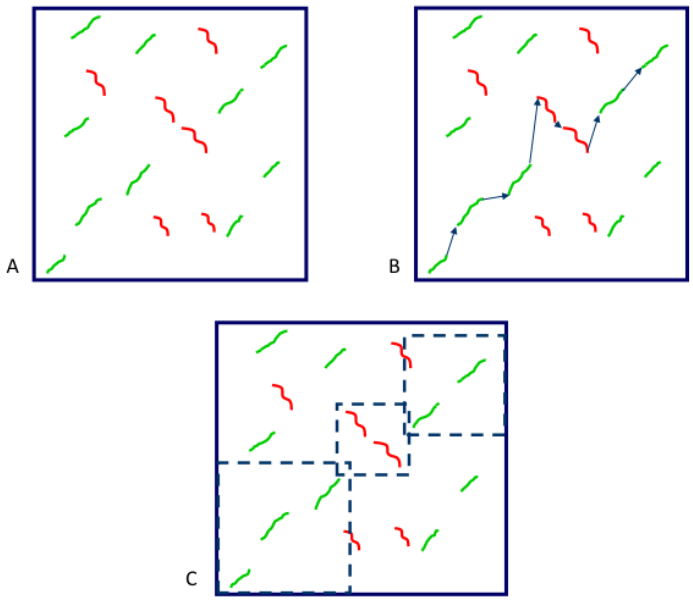

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图5.18：运行SLAGAN算法的步骤为A. 找到所有局部比对，B. 构建粗略的同源图谱，以及C. 使用常规LAGAN算法对一致部分进行全局比对

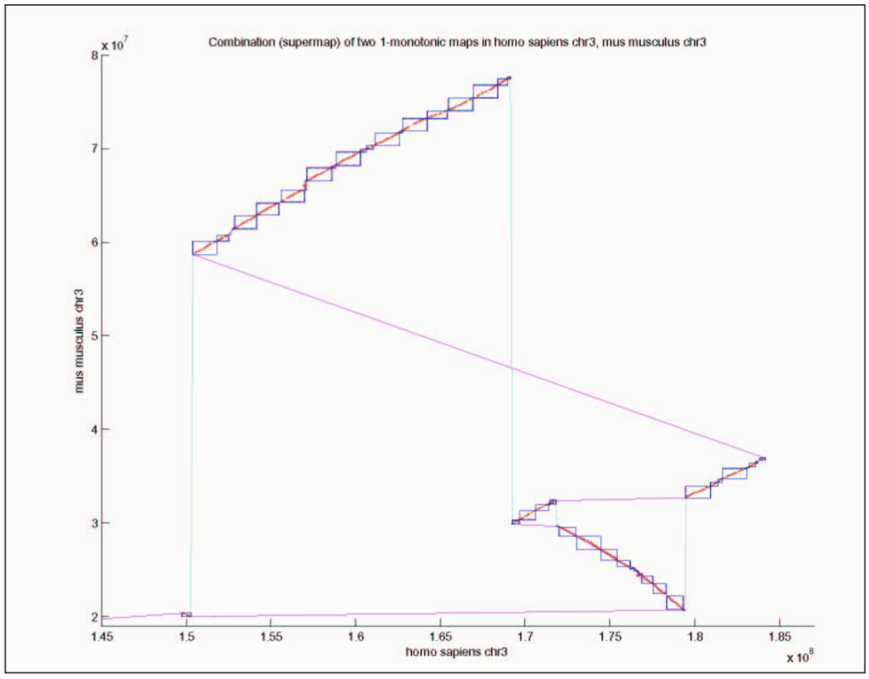

图5.19：利用全局局部对齐的概念，我们可以发现不同物种如人类和小鼠之间的倒位、易位以及其他同源关系。

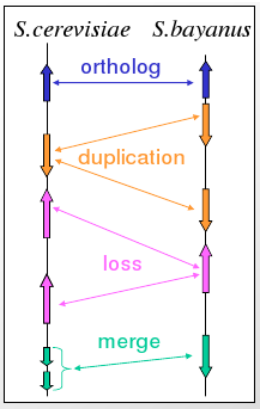

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图5.20：*S. cerevisae*和*S. bayanus*基因对应关系图。

基因对应关系可以用加权二分图表示，其中节点表示带有坐标的基因，边表示加权序列相似性（图5.20）。直系同源关系是一对一匹配，旁系同源关系是一对多或多对多匹配。该图首先通过消除虚假边来简化，然后根据可用信息（如保守基因顺序块和蛋白质序列相似性）选择边。

最佳无歧义亚组(BUS)算法可以用来解析基因和区域的对应关系。BUS扩展了最佳双向命中的概念，并使用具有递增相对阈值的迭代细化。它使用了结合氨基酸相似性和基因顺序信息的完全二分图连通性。

Did You Know?
二分图是一种图，其顶点可以分割成两个不相交的集合 U 和 V，使得每条边都连接 U 中的一个顶点和 V 中的一个顶点。

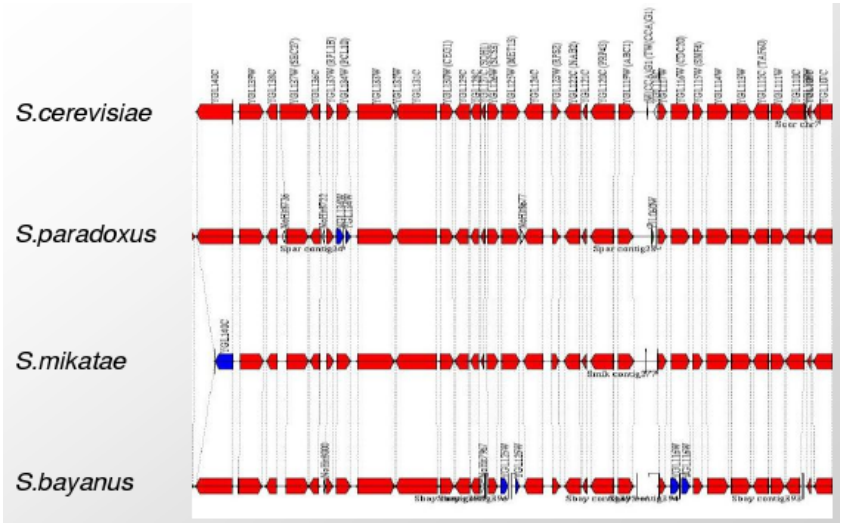

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图5.21：*S.cerevisiae* 6号染色体（250-300bp）的基因对应关系示意图。

在*S.cerevisiae*与其他三个相关物种正确解析基因对应关系的示例中，超过90%的基因具有一一对应关系，并且识别出了快速变化的区域和蛋白质家族。

5.6 Mechanisms of Genome Evolution

一旦我们获得了多个相关物种间大基因组区域（或全基因组）的比对结果，我们就可以开始进行比较，以推断这些区域的进化历史。

物种间和基因组区域间的进化速率各不相同。例如，在*S. cerevisiae*中，80%的模糊性存在于5%的基因组中。端粒是染色体末端的重复DNA序列，保护染色体末端免受退化。端粒区域本质上不稳定，倾向于经历快速的结构进化，而80%的变异对应于32个端粒区域中的31个。这些区域内包含的基因家族，如HXT、FLO、COS、PAU和YRF，在数量、顺序和方向上显示出显著的进化。在这些区域可以发现一些新的和蛋白质编码序列。由于在*S. cerevisiae*中除了端粒区域外，很少发现基因组重排，因此可以通过染色体末端的蛋白质家族扩张来识别快速变化的区域。

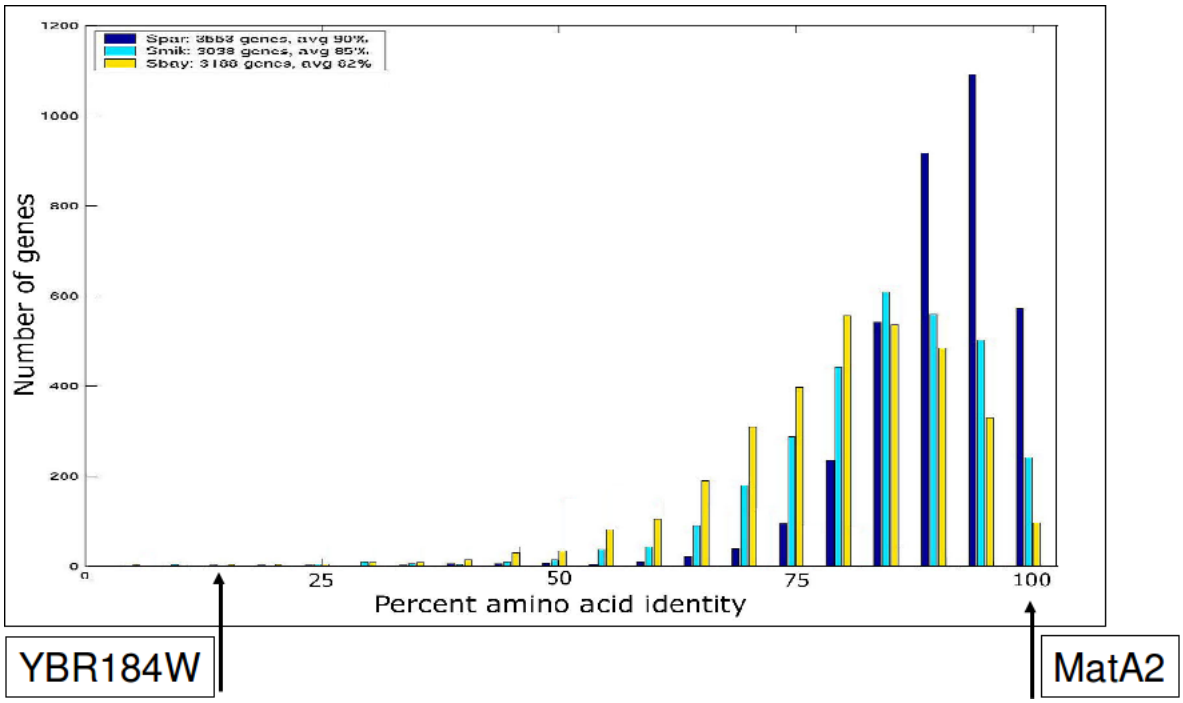

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图5.22：变化基因的动态视图。

基因以不同的速率进化。例如，如图5.22所示，一方面，酵母中的YBR184W显示出异常低的序列保守性，并在不同物种间表现出众多的插入和缺失。另一方面，MatA2显示出完美的氨基酸和核苷酸保守性。突变率也常因功能分类而异。例如，线粒体核糖体蛋白比核糖体蛋白保守性更低。

某些基因在一个物种中比在另一个物种中进化得更慢，这可能归因于更长的生命周期等因素。然而，特定基因缺乏进化变化表明，还有其他生物学功能负责保持核苷酸序列的压力。酵母可以通过转换其所有A和α基因来切换交配型，而MatA2是四个酵母交配型基因之一（MatA2、Matα2、MatA1、Matα1）。其作用可能通过核苷酸保守性分析得以揭示。

快速进化的基因　　也可以是具有生物学意义的。快速机制　　蛋白质变化包括:

- 通过谷氨酰胺（Q）和天冬酰胺（N）的片段以及蛋白质-蛋白质相互作用创建蛋白质结构域,
- 补偿性移码，使得能够探索新的阅读框以及读取/创建RNA编辑信号,
- 终止密码子变异和受调控的通读，其中获得可实现快速变化，而缺失可能导致新的多样性
- 内含肽是蛋白质中能够自我切除并与剩余蛋白质重新连接的片段，它们通过翻译后自我剪接内含肽的水平转移而获益。

我们现在观察不同物种间基因内容的差异（*S.cerevisiae*、*S.paradoxus*、*S.mikatae*和*S.bayanus*）。通过观察旁系同源基因在相关物种中的位置以及旁系同源基因的变化速率，可以揭示大量关于基因丢失和转换的信息。每个基因组有8-10个独特的基因，主要涉及代谢、调节和沉默以及应激反应。此外，基因剂量也发生变化，包括串联重复和片段重复。还存在蛋白质家族扩张，有211个基因具有模糊的对应关系。然而，总的来说，不同物种中的新基因很少。

5.6.1 Chromosomal Rearrangements

这些通常是由特定机制介导的，如图5.23中对酿酒酵母所示。[Matt Fox]Fig11{v*13}

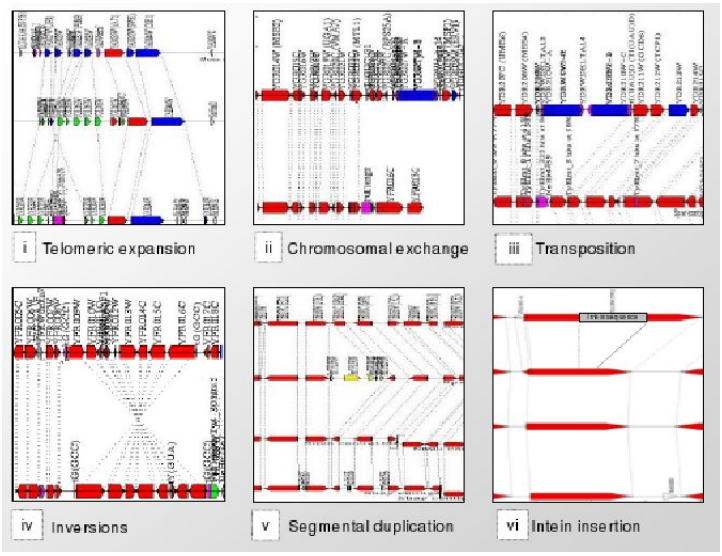

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图5.23：染色体进化机制。

不同基因间的易位通常发生在转座遗传元件（例如酵母中的Ty元件）之间。转座子的位置是保守的，近期插入出现在旧位置，而在其他基因组中发现长末端重复序列残留。然而，它们在进化上是活跃的（例如酵母中的Ty元件是近期出现的），并且通常只出现在一个基因组中。这种位置保守的转座子可能具有的进化优势在于介导可逆排列的可能性。倒位通常两侧是转录方向相反的tRNA基因。这可能表明它们起源于tRNA基因之间的重组。

5.7 Whole Genome Duplication

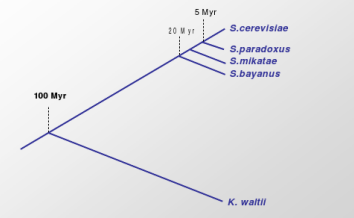

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图5.24：在酿酒酵母的进化时间中进一步回溯。

当你在演化时间轴上追溯物种到更久远的历史时，你能够提出不同的一系列问题。在课堂上，所用的例子是*K. waltii*，它比*S.cerevisiae*早大约9500万年，比*S.bayanus*早8000万年。

观察*S.cerevisiae*染色体和*K.waltii*支架的dotplot，在图的中间沿对角线发现了一个分歧，而大多数保守区域对都呈现出清晰、笔直的对角线点图。在更高的放大倍数下查看该片段（图5.25），似乎*S.cerevisiae*姐妹片段都映射到对应的*K.waltii*支架。

示意图（图5.26）显示姐妹区域存在基因交错。在着丝粒的重复映射中，可以根据基因顺序识别姐妹区域。这种观察到的基因交错提供了全基因组复制的证据。

5.8 Additional figures

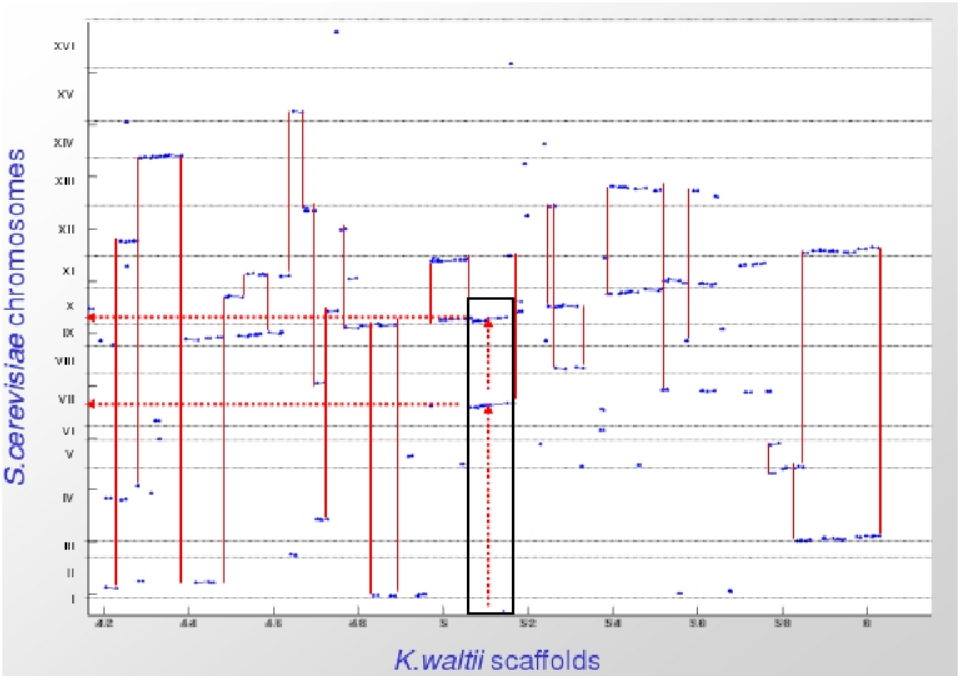

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图5.25：*S.cerevisiae*染色体与*K.waltii*支架的基因对应关系。

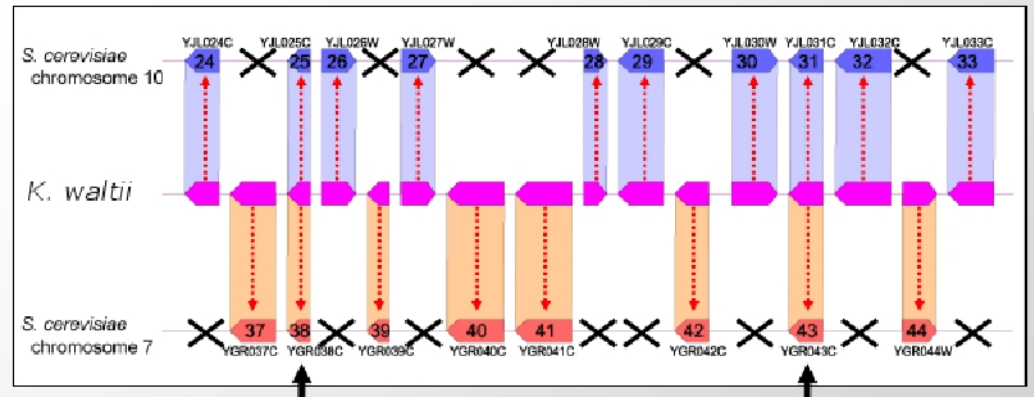

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图5.26：G *K.waltii*和中的姐妹区域显示的ene交错 *S.cerevisae*

Bibliography

[1] Embl allextron数据库——盒式外显子。

[2] Batzoglou S 等人。Arachne：一种全基因组鸟枪法组装器。*Genome Res*，2002。

[3] Manolis Kellis。讲座幻灯片04：比较基因组学i。2010年9月21日。

[4] Manolis Kellis. 讲座幻灯片05.1：比较基因组学ii. 2010年9月23日.

[5] Manolis Kellis. 讲座幻灯片 05.2：比较基因组学 iii，进化。2010年9月25日。

[6] Nikolaus Rajewsky Kevin Chen. 转录因子和微小RNA对基因调控的演化。*Nature Reviews Genetics*, 2007.

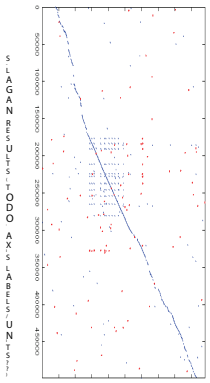

图5.27：S-LAGAN结果。

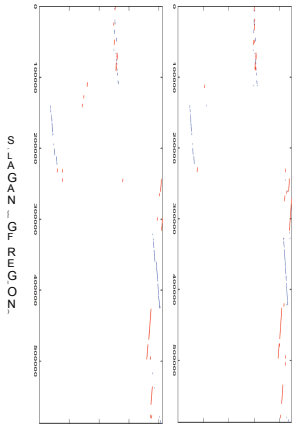

图5.28：IGF位点的S-LAGAN结果。

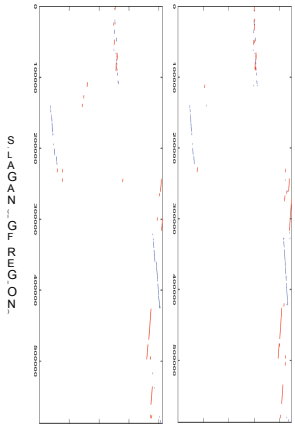

图5.29：IGF基因座的S-LAGAN结果。

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

[7] Douglas Robinson 和 Lynn Cooley。由终止密码子抑制产生的两种 kelch 蛋白的功能检测。*Development*, 1997。

[8] Stark。利用进化特征发现12个果蝇基因组中的功能元件。*Nature*，2007年。

[9] Angela Tan. Lecture 15 notes: Comparative genomics i: Genome annotation. November 4, 2009.

CHAPTER

SIX

细菌基因组学——生态系统层面的分子进化

Eric Alm 的客座讲座，由 Deniz Yorukoglu 记录（2011年）

Figures

6.1 展示每个分支点上基因诞生、复制、丢失和水平基因转移速率的生命之树。 . . . . . 113 6.2 太古宙基因扩张期间新基因诞生、复制、丢失和水平基因转移的速率 . . . . . 114 6.3 对照组患者、克罗恩病患者和溃疡性结肠炎患者中不同细菌类群的丰度水平。 . . . . . 115 6.4 参与HuGE项目的两名供体的肠道细菌丰度随时间变化图。 . . . . . 116 6.5 如何阅读地平线图的说明。 . . . . . 116 6.6 HuGE研究中供体B的地平线图。 . . . . . 117 6.7 HuGE研究中供体A的地平线图。 . . . . . 118 6.8 供体A和供体B的逐日细菌丰度相关矩阵。 . . . . . 118 6.9 取自非人类位点、人类位点、人类内相同位点以及人类内不同位点的不同细菌类群之间的水平基因转移速率。 . . . . . 120 6.10 从同一大陆和不同大陆采样的细菌类群之间的水平基因转移速率。 . . . . . 120 6.11 不同人类和非人类位点之间的水平基因转移速率（右上）以及水平基因转移中抗生素抗性基因的百分比（左下）。 121

6.1 Introduction

由于人体内细菌种群的规模和多样性，人类微生物组与环境生物学中研究的自然生态系统有许多共同特性。作为一个有大量定量问题需要解决的领域，细菌基因组学为计算生物学家积极参与这一研究领域的进展提供了机会。

平均人体肠道中约有10^{14}个微生物细胞，而人体总共只有10^{13}个人类细胞。此外，还有10^{12}个外部微生物细胞生活在我们的皮肤上。从细胞数量的角度来看，这意味着我们体内的细菌细胞数量是我们自身细胞的10倍。从基因数量的角度来看，生活在我们体内/体表的细菌所拥有的基因数量是我们自身细胞基因的100倍。因此，这些生活在我们体内的微生物群落是

是什么让我们成为人类，我们应该研究这些并非直接编码于我们基因组中，但仍对我们的生理机能有显著影响的基因。

6.1.1 Evolution of microbiome research

微生物组研究的早期阶段主要基于对特定生态系统中存在的细菌群落调查数据的收集和分析。除了收集数据外，这类研究还涉及细菌基因组的测序和基因标记的识别，以确定样本中存在的不同细菌群落。用于此目的最常用的标记是16S rRNA基因，它是原核生物DNA中编码核糖体RNA的一部分。16S基因使其成为微生物组研究非常有效标记的三个主要特征是：(1)其短小尺寸（~1500个碱基），使得测序和分析成本更低；(2)由于其所编码的核糖体RNA精确折叠需求而导致的高度保守性；以及(3)其对原核生物的特异性，使我们能够区分污染的原生生物、真菌、植物和动物DNA。

早期微生物研究的另一个方向是根据生成的微生物生态系统数据集推断规则。这些研究考察了最初生成的微生物数据，并试图理解不同类型生态系统中微生物丰度的规律，并推断细菌种群之间在共现、相关性和因果关系方面的网络。

一种较新的微生物研究采用预测性方法，旨在利用微分方程对生态系统中细菌种群随时间的变化进行建模。例如，我们可以将人类肠道中特定细菌群体种群大小的变化率建模为常微分方程（ODE），并通过对时间区间进行积分，利用该模型预测未来某一时间点的种群大小。

我们可以进一步用多个参数来模拟细菌种群的变化，例如时间和空间。当我们有足够的数据在时间和空间上表示微生物种群时，我们可以使用偏微分方程（PDEs）来建模，以便使用多元函数进行预测。

6.1.2 Data generation for microbiome research

微生物组研究的数据生成通常遵循以下工作流程：(1) 从所研究的特定部位（例如患者的皮肤或湖泊）采集微生物生态系统的样本，(2) 提取样本中细菌的DNA，(3) 对16S rDNA基因进行测序，(4) 将16S基因某些片段中的保守基序（DNA条形码）聚类为**operational taxonomic units** (OTUs)，(5) 为样本中的所有物种构建丰度向量。在微生物学中，由于难以将传统的物种定义应用于细菌世界，细菌根据其功能特性而非物种被分类为OTUs。

在讲座的剩余部分，将介绍一系列与细菌基因组学和人类微生物组研究领域相关的近期研究。

6.2 Study 1: Evolution of life on earth

这项研究[2]受到马克斯·德尔布吕克一句名言的启发：“任何活细胞都携带着其祖先数十亿年实验的经验。”在这个方向上，可以从活生物体的基因组中找到证据，证明曾发生过具有重大生物影响的古代环境变化。例如，目前大多数生物所使用的氧气，在通过产氧光合作用积累氧气之前，对地球上的几乎所有生命都会极具毒性。众所周知，这一事件发生在大约24亿年前，并导致了地球上生命的剧烈转变。

为了推断基因的诞生、复制、丢失和水平基因转移事件，基于物种系统发育和不同基因的系统发育，开发了一种动态规划算法。**Horizontal gene transfer**是指细菌将其基因组的一部分转移到来自不同分类群的其他细菌中的事件。

图6.1展示了一棵侧重于原核生物生命的系统发育树中这些推断事件的概览。在每个节点中，饼图的大小表示两个分支之间的遗传变化量，而每个彩色切片代表特定遗传修饰事件的速率。从

树，我们看到几乎整个饼图都由红色代表的新生基因组成。然而，大约25亿年前，绿色和蓝色部分变得更加普遍，它们分别代表水平基因转移和基因复制事件的速率。

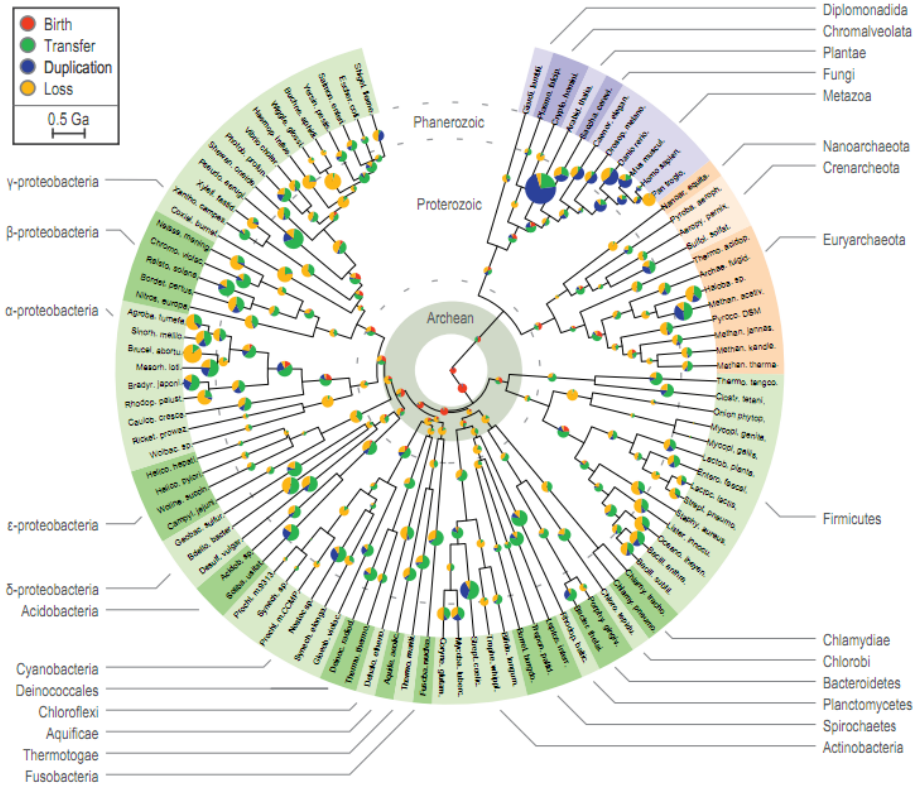

© Lawrence David. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图6.1：一棵生命之树，展示了每个分支点上的基因诞生、复制、丢失和水平基因转移速率。

在图6.2中，太古宙时期出现了一个大的峰值，表明地球上大量的遗传变化发生在这一特定时期。这项研究寻找在这个宙诞生的基因与已经存在的基因不同的酶活性。在图6.2的右侧，显示了不同代谢物的对数富集水平。研究发现，这些基因产生的大多数富集代谢物在氧化还原和电子传递中具有功能。总体而言，这项研究表明生命在大约33亿年前发明了现代电子传递链，并且在大约28亿年前，生物进化出使用与产生氧气相同的蛋白质来呼吸氧气。

6.3 Study 2: Pediatric IBD study with Athos Boudvaros

在某些疾病如炎症性肠病（IBD）中，如果疾病未被诊断并密切监测，其结果可能非常严重，例如患者结肠的切除。另一方面，当前存在的最可靠的诊断方法非常侵入性（例如结肠镜检查）。诊断的另一种方法可以是分析从患者结肠采集的微生物样本的丰度。本研究旨在根据从患者粪便样本中获得的细菌丰度预测受试者的疾病状态。

本研究从Athos Boudvaros医生的患者中收集了105个样本；其中一些

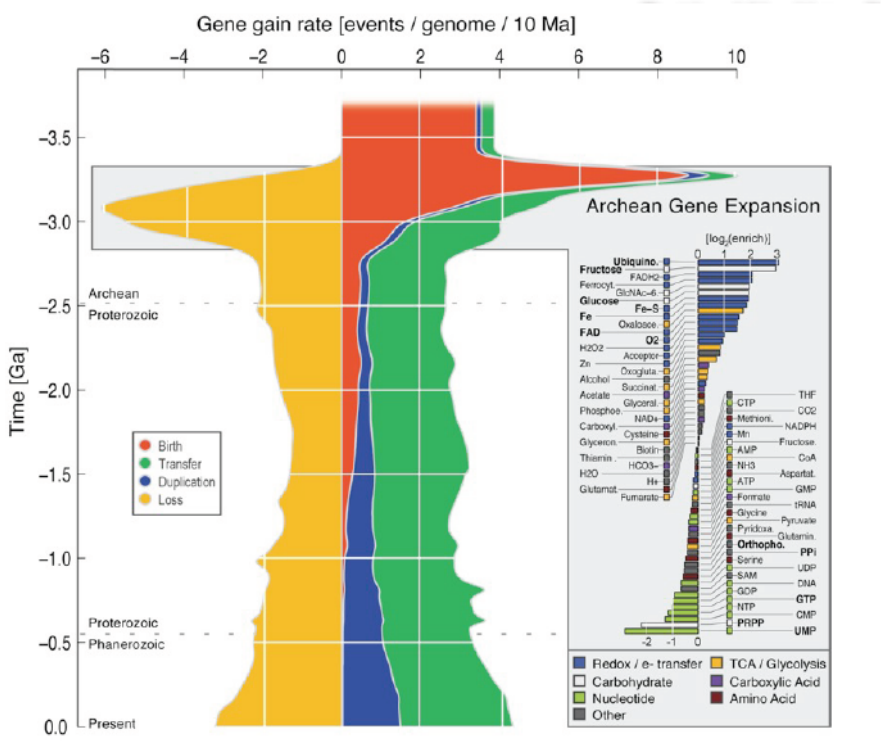

Courtesy of Macmillan Publishers Limited. Used with permission.
Source: David, Lawrence A., and Eric J. Alm. "Rapid Evolutionary Innovation during an Archaean Genetic Expansion." *Nature* 469, no. 7328 (2011): 93-96。

图6.2：太古宙基因扩张期间新基因诞生、复制、丢失和水平基因转移的速率

展示IBD症状和其他不同疾病（对照组）。在图6.3中，每一行区块代表一个分类水平上的细菌群组集合（顶部为门水平，底部为属水平），每一列区块代表不同的患者组：对照组患者、克罗恩病（CD）和溃疡性结肠炎（UC）。唯一显著的单一生标志物是大肠杆菌，它在对照组和CD患者中未出现，但在约三分之一的UC患者中出现。从这些丰度指标来看，似乎没有其他单一的细菌群组能在患者组之间给出显著分类。

由于大肠杆菌丰度并非明确的单一细菌生物标志物，将其用作诊断工具会导致分类准确率较低。另一方面，我们可以取整个细菌群落丰度分布，将其输入随机森林并估计交叉验证准确率。采用该分类方法后，它能够以90%的准确率判断患者是否患病。这表明，相对于其他通常具有高度特异性但灵敏度不足的非侵入性诊断方法，这是一种具有竞争力的方法。

对照组和疾病组之间的一个关键差异是生态系统多样性的减少。这表明疾病状态并非由单一病菌控制，而是由生态系统的整体稳健性和恢复力决定。当生态系统中的多样性减少时，患者可能开始出现疾病症状。

6.4 Study 3: Human Gut Ecology (HuGE) project

本研究旨在识别三百多种影响人类微生物组的饮食和环境因素。这些因素由一款iPhone应用程序定期追踪，包括受试者所食用的食物、睡眠时长、情绪状态等。此外，为了对特定日期的细菌群落丰度进行序列分析，一年内每天从受试者处采集粪便样本。

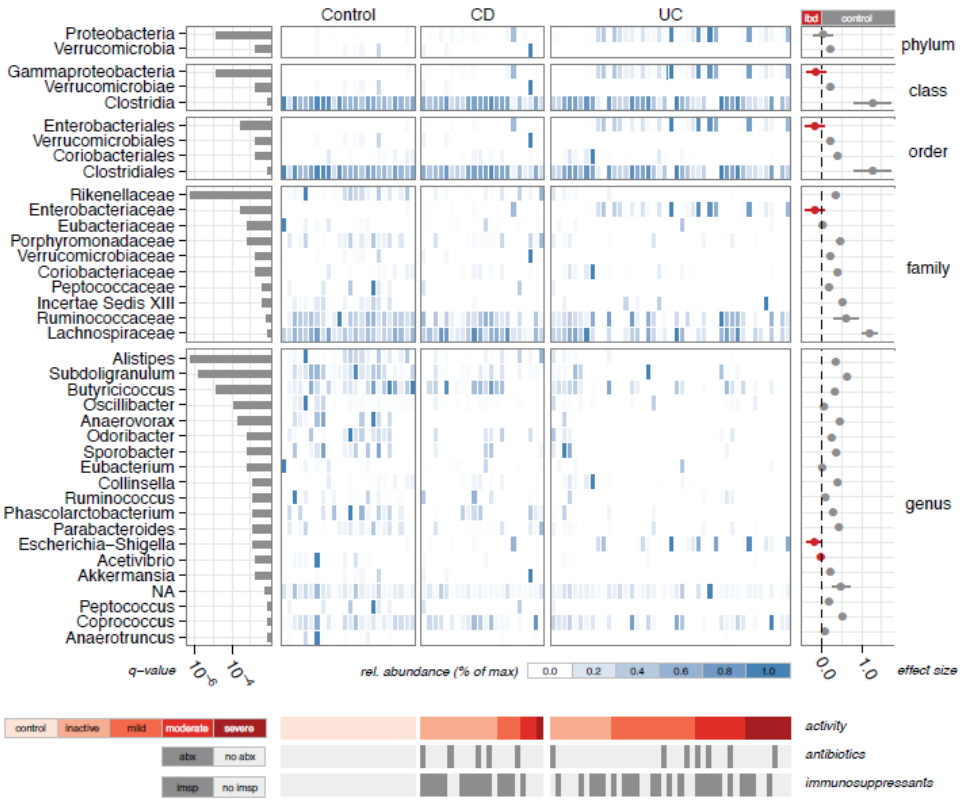

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图6.3：对照组患者、克罗恩病患者和溃疡性结肠炎患者中不同细菌群的丰度水平。

与特定环境因素相关。进行这项研究的动机在于，通常很难在细菌丰度与疾病状态之间获得强烈的信号。探索饮食对人类微生物组的影响可能有助于阐明细菌丰度分析中的一些混杂因素。然而，这项研究仅分析了两名受试者肠道生态系统中的饮食和环境因素；要推断与环境因素之间具有统计学显著性的相关性，将需要大规模受试者队列。

图6.4显示了实验期间两名供体肠道中不同细菌群的丰度水平。需要注意的一个关键点是，同一个体内部的细菌丰度随时间变化很小。然而，不同个体间的肠道细菌群丰度存在显著差异。

一个被发现有统计学显著性的、可作为细菌种群丰度预测标志物的饮食因素是纤维摄入量。据推断，纤维摄入量与Lachnospiraceae、Bifidobacteria和Ruminococcaceae等细菌群的丰度高度相关。在供体B中，纤维摄入量增加10克，这些细菌群的整体丰度增加了11%。

在图6.6和图6.7中，分别展示了两个捐献者B和A的水平图。用于解读这些水平图的图例见图6.5。对于每个细菌组，丰度-时间图以不同丰度层的不同颜色展示，不同层的片段被压缩为单一层的高度，仅显示与正常丰度绝对差值最大的颜色，最后，负峰值被转换为正峰值，同时保留其原始颜色。

在图6.6中，我们看到在捐赠者前往泰国期间，其肠道细菌生态系统发生了显著变化。捐赠者一开始在泰国生活，大量细菌群便消失（显示在地平线图的下半部分）。而当捐赠者一返回美国，这些菌群的丰度

Figures from the David lab removed due to copyright restrictions.

图6.4：参与HuGE项目的两名供体随时间变化的肠道细菌丰度图。

Figures from the David lab removed due to copyright restrictions.

图6.5：如何阅读水平图表的说明。

levels of these bacterial groups quickly return back to their normal levels. Moreover, some bacterial groups that are normally considered to be pathogens (first 8 groups shown on top) appears in the donor's ecosystem almost as soon as the donor moves to Thailand and mostly disappears when he returns back to United States. This indicates that environmental factors (such as location) can cause major changes in our gut ecosystem

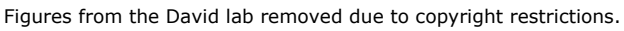

图6.6：HuGE研究中Donor B的地平线图。

虽然环境因素存在，但在移除该因素后可能消失。

在图6.7中，我们看到在供体感染沙门氏菌后，其肠道生态系统的一大部分被其他细菌群所替代。大量细菌群在感染期间永久消失，而其他细菌群则取代了它们的生态位。换句话说，新环境因素的引入使供体肠道中的细菌生态系统从一个平衡点转向一个完全不同的平衡点。尽管感染期间细菌种群主要由沙门氏菌组成，但在感染前后，细菌数量基本保持稳定。这里发生的情况是，沙门氏菌导致肠道内一些细菌群灭绝，而类似的细菌群接管了它们空出的生态位。

在图6.8中，展示了供体A和B日间细菌丰度相关性水平的p值。在供体A的相关矩阵中，感染前的时间区间a内及感染后的时间区间b内均存在高度相关性。然而，在a与b之间几乎完全没有相关性。另一方面，在供体B的相关矩阵中，我们可以看到泰国旅行前和旅行后的时间区间c内部及其相互间存在高度相关性。然而，对应供体B泰国旅行期间的区间d，与c的相关性相对较小。这表明，供体B细菌生态系统的扰动不足以像供体A因沙门氏菌感染那样导致丰度平衡的永久性转变。

Figures from the David lab removed due to copyright restrictions.

图6.7：HuGE研究中供体A的地平线图。

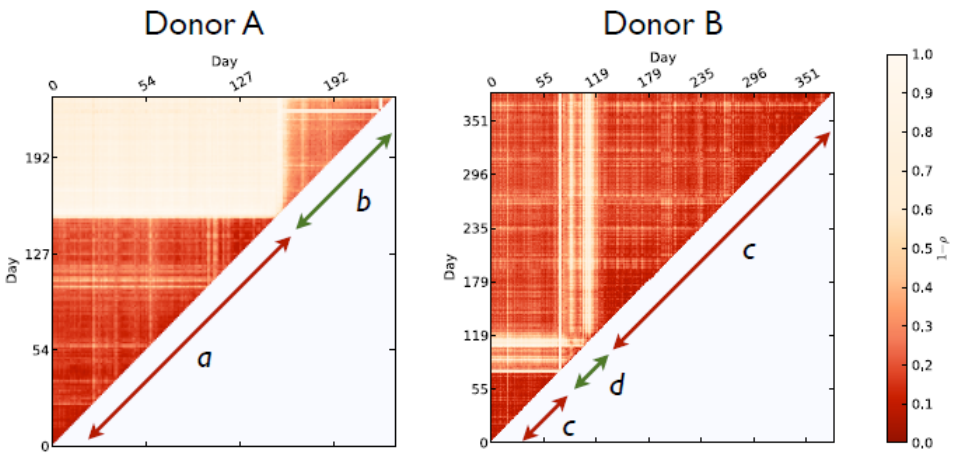

Courtesy of Lawrence David. Used with permission.

图6.8：供体A和供体B的日间细菌丰度相关性矩阵。

6.5 Study 4: Microbiome as the connection between diet and phenotype

在Mozaffarian等人[4]的一项研究中，分析了超过十万名患者，旨在探究饮食和生活方式选择对长期体重增加及肥胖的影响。该研究建立了一个模型，根据患者在一定时期内消费的食物种类和数量来预测其体重。他们发现，快餐类食物（加工肉类、薯片、含糖

饮料）与肥胖的相关性最高。另一方面，酸奶的消费水平与肥胖呈负相关。

在小鼠和人类群体的进一步实验表明，在对照组和快餐组中，增加酸奶消费会导致体重减轻。在小鼠实验中，一些雌性小鼠被给予罗伊氏乳杆菌（一种在酸奶中发现的细菌群），并允许它们随意食用普通食物或快餐。这导致接受纯化细菌提取物的小鼠群体显著减轻体重。

意外发现，食用有机酸奶的小鼠和狗，其皮毛变得更为光亮。对对照组和喂食酸奶的小鼠皮肤活检进行的组织学分析证明，摄入酸奶中细菌的小鼠拥有活跃的毛囊，从而促进了更健康、光亮皮毛和毛发的积极发育。

6.6 Study 5: Horizontal Gene Transfer (HGT) between bacterial groups and its effect on antibiotic resistance

Hehemann等人的一项研究[3]发现了一个特定基因，该基因能消化一种仅存在于海藻寿司包装中的硫化糖类。这种基因存在于日本人的肠道微生物中，而北美人则没有。该研究得出结论，这一特定基因在历史上某一时刻，通过水平基因转移，从藻类本身转移到附着其上的细菌，再转移到某位日本人的肠道微生物组中。这项研究还表明，即使某些细菌群体可能终生居住在我们的肠道中，它们也能通过根据我们所吃食物类型获取新基因，在我们一生中获得新的功能。

在这个方向上，Alm实验室的一项研究调查了[1]中发布的约2000个细菌基因组，旨在检测100%相似但属于不同分类群细菌的基因。不同细菌群体之间完全相同的任何基因都将表明发生了水平基因转移事件。在这项研究中，发现了大约100000个此类实例。

当观察特定环境时，发现从人体分离的细菌主要与从人体部位分离的其他细菌共享基因。如果我们关注更具体的部位，我们会看到从人类肠道分离的细菌基因组主要与从肠道分离的其他细菌共享基因，而从人类皮肤分离的细菌基因组主要与从人类皮肤分离的其他细菌共享基因。这一发现表明，独立于细菌群落的系统发育，生态是决定细菌群落间基因转移事件数量的最重要因素。

在图6.9中，我们可以看到，从人类采集的不同细菌群之间，如果16S基因差异至少为3%，它们基因组中共享同一基因的概率约为23%。此外，如果它们同样是从同一部位采样得到的，那么共享同一基因的概率超过40%。

另一方面，图6.10显示地理对水平基因转移的影响较小。从同一大陆和不同大陆采样的细菌种群在检测到的水平基因转移量方面几乎没有差异。

图6.11展示了一个颜色编码矩阵，反映了不同人类与非人类环境间HGT水平的对比；右上三角代表水平基因转移的数量，而左下三角则显示了转移基因中抗生素抗性（AR）基因的百分比。在右上角，我们可以看到人类微生物组与从农场动物采集的细菌样本之间存在略多的HGT实例。当我们查看相应的抗生素抗性基因百分比时，发现超过60%的转移是AR基因。这一结果表明，给牲畜喂食亚治疗剂量的抗生素直接影响了人类肠道内细菌群体中抗生素抗性基因的出现。

6.7 Study 6: Identifying virulence factors in Meningitis

细菌性脑膜炎是一种由多种细菌引起的疾病，这些细菌能够进入血液并穿过血脑屏障。本研究旨在探究那些能够将

Figures removed due to copyright restrictions. See similar figures in this journal article: Smillie, Chris S. et al. "Ecology drives a global network of gene exchange connecting the human microbiome." Nature 480, no. 7376 (2011): 241-244.

图 6.9：来自非人类位点、人类位点、人体同一位点以及人体不同位点的不同细菌群之间的水平基因转移率。

由于版权限制，图表已移除。参见此期刊文章中的类似图表：Smillie, Chris S. 等。“生态学驱动了连接人类微生物组的全球基因交换网络。”《自然》480, no. 7376 (2011): 241-244。

Figure 6.10: Rate of horizontal gene transfer between bacterial groups sampled from the same continent and from different continents.

细菌转化为可引发脑膜炎的类型。该研究涉及从脑膜炎患者中分离出的70种细菌菌株，总计包含175172个基因。其中约24000个基因功能未知。这24000个基因中可能存在某些基因

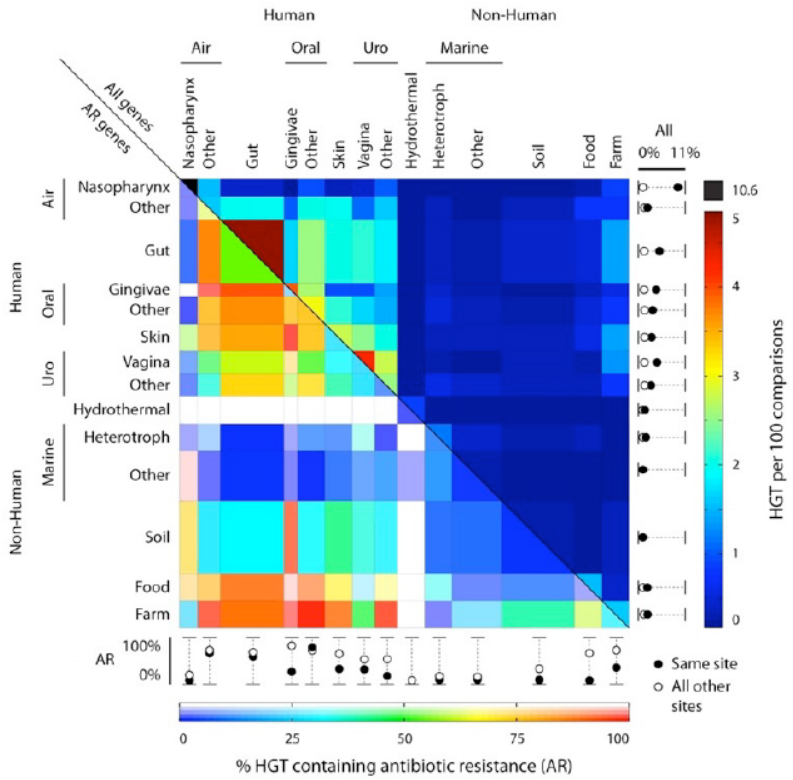

Courtesy of Macmillan Publishers Limited. Used with permission.
Source: Smillie, Chris S., et al. "Ecology Drives a Global Network of Gene Exchange Connecting the Human Microbiome." *Nature* 480, no. 7376 (2011): 241-4.

图6.11：不同人类和非人类场所之间的水平基因转移率（右上）以及水平基因转移中抗生素抗性基因的百分比（左下）。

可能导致脑膜炎的细菌，这些可能是良好的药物靶点。此外，发现了82个与水平基因转移有关的基因。其中69个具有已知功能，而另外13个属于我们尚无任何功能信息的24000个基因之一。在具有已知功能的基因中，一些与抗生素耐药性、解毒作用相关，还有一些与已知的毒力因子有关，例如能使细菌在血液中存活的溶血素，以及帮助细菌附着于血管并可能穿越血脑屏障的黏附素。

6.8 Q/A

问：你认为一段时间后，研究3中的供体A的细菌生态系统会恢复到感染前的原始状态吗?

A：沙门氏菌感染导致供体A的细菌生态系统中某些生态位被清除，随后这些生态位被相似类型的细菌填补，并达到一个新的平衡状态，形成了一个不同的生态系统。由于这些生态位已被新的细菌群占据，除非他的肠道生态系统发生大规模变化，否则之前的细菌群不可能取代它们。

问：沙门氏菌感染期间肠道中某些细菌群的死亡是由感染直接引起的，还是治愈疾病的免疫反应?

A：两者都有可能，但仅凭研究3中的数据很难判断，因为它只是一个对应于我们可观察事件的数据点。未来通过感染期间从患者身上抽血，可以观察免疫系统在感染期间发生了什么。

问：个体的基因组与细菌生态系统中的优势细菌群之间是否存在特定的联系？双胞胎是否会表现出更相似的细菌生态系统?

A：一般而言，双胞胎拥有相似的细菌生态系统，无论他们是一起生活还是分开生活。尽管这起初看似是遗传因素，但同卵双胞胎和异卵双胞胎具有完全相同的影响，同时也显示出与其母亲细菌生态系统的相似性。其原因是，从出生开始，有一段时间细菌生态系统会被编程设定。双胞胎之间的相似性效应更多是基于这一点，而非遗传因素。

6.9 Current research directions

对HuGE研究的进一步扩展可以观察沙门氏菌感染期间小鼠肠道微生物组，并观察某些细菌群被驱使至灭绝以及其他类型细菌取代它们所空出的生态位的过程。对这一现象在小鼠中的更高分辨率观察可以阐明细菌生态系统如何从一个平衡态转变到另一个平衡态。

6.10 Further Reading

- 人体微生物组计划概述：`http://commonfund.nih.gov/hmp/overview.aspx`
- Lawrence A. David 和 Eric J. Alm。（2011）。太古宙基因扩张期间的快速进化创新。*Nature*, 469(7328)：93-96。
- 关于16S rRNA基因及其在微生物组研究中应用的教程：`http://greengenes.lbl.gov/cgi-bin/JD_Tutorial/nph-Tutorial_2Main2.cgi`
- Dariush Mozaffarian, Tao Hao, Eric B. Rimm, Walter C. Willett, 和 Frank B. Hu. (2011). 饮食和生活方式变化与女性和男性的长期体重增加。*The New England journal of medicine*, 364(25):2392-2404.
- JH Hehemann, G Correc, T Barbeyron, W Helbert, M Czjzek, 和 G Michel. (2010). 海洋细菌中碳水化合物活性酶向日本肠道微生物群的转移. *Nature*, 464(5):908-12.
- 人类微生物组启动参考菌株联盟。（2010）。人类微生物组参考基因组目录。*Science*, 328(5981):994-999

6.11 Tools and techniques

6.12 What have we learned?

在本讲中，我们总体上了解了细菌基因组学领域，以及细菌生态系统如何用于验证进化早期阶段的主要环境变化（研究1），可作为非侵入性诊断工具（研究2），会暂时或永久受到不同环境和饮食因素的影响（研究3），可作为饮食与表型之间的纽带（研究4），可通过水平基因转移导致抗生素抗性基因在不同物种的微生物组之间携带（研究5），并可用于识别疾病状态下的重要毒力因子（研究6）。

Bibliography

[1] 人类微生物组启动参考菌株联盟。人类微生物组的参考基因组目录。*Science*, 328(5981):994–999, 2010年5月。

[2] Lawrence A. David 和 Eric J. Alm. 太古宙遗传扩张期间的快速进化创新。*Nature*, 469(7328):93–96, 2011年1月。

[3] JH Hehemann、G Correc、T Barbeyron、W Helbert、M Czjzek 和 G Michel。海洋细菌中碳水化合物活性酶向日本肠道微生物群的转移。*Nature*，464(5)：908–12，2010年4月8日。

[4] Dariush Mozaffarian, Tao Hao, Eric B. Rimm, Walter C. Willett, and Frank B. Hu. 饮食和生活方式的变化与女性和男性的长期体重增加。*The New England journal of medicine*, 364(25):2392–2404, June 2011.

Part II

Coding and Non-Coding Genes

CHAPTER

SEVEN

隐马尔可夫模型 I

阿纳斯塔西娅·别利亚耶娃，贾斯汀·古林斯鲁德（2015年9月26日）威廉·莱瑟森，亚当·西尔丰（2014年9月22日）曾浩洋（2013年9月28日）苏迈亚·纳齐恩（2012年9月25日）克里桑塔·佩雷拉（2011年9月27日）格列布·库兹涅佐夫，谢伊达·纳巴维（2010年9月28日）埃尔哈姆·阿齐齐（2009年9月29日）

Figures

7.1 生物序列建模 . . . . . 129 7.2 使用马尔可夫链和HMM的预测模型 . . . . . 130 7.3 HMM预测模型的参数化 . . . . . 130 7.4 隐马尔可夫模型表示的赌场骰子状态 . . . . . 132 7.5 潜在DNA来源：病毒注入与正常产生 . . . . . 132 7.6 观察到的骰子点数的一个可能序列 . . . . . 132 7.7 运行模型：给定路径由所有公平骰子组成时序列的概率 . . . . . 133 7.8 运行模型：给定路径由所有灌铅骰子组成时序列的概率 . . . . . 133 7.9 部分运行与骰子切换 . . . . . 134 7.10 HMM作为发现GC富含区域的生成模型 . . . . . 135 7.11 若全为启动子时序列、路径的概率 . . . . . 135 7.12 若全为背景时序列、路径的概率 . . . . . 136 7.13 若混合时序列、路径序列的概率 . . . . . 136 7.14 HMM的一些生物学应用 . . . . . 137 7.15 HMM的六种算法设置 . . . . . 138 7.16 维特比算法 . . . . . 140 7.17 前向算法 . . . . . 141 7.18 CpG岛 - 融入记忆 142

7.1 Introduction

隐马尔可夫模型（HMMs）是机器学习中的一种基础工具，在计算生物学中得到了广泛应用。利用HMMs，我们可以探索DNA或多肽序列的潜在结构，检测出特别感兴趣的区域。例如，我们可以识别保守的子序列，或揭示具有不同核苷酸或氨基酸分布的区块，如启动子区域和CpG岛。通过这种概率模型，我们能够阐明序列的属性与结构组成部分，并定位基因及其他功能元件。

这是关于HMM的两讲中的第一讲。在本讲中，我们将定义马尔可夫链和HMM，并提供一系列启发性的例子。在本讲的后半部分，我们将讨论评分和解码。我们将学习如何计算特定观测和状态组合的概率。我们将介绍前向算法，这是一种计算给定观测序列概率的方法，允许所有状态序列。最后，我们将讨论确定与给定观测相对应的最可能状态路径的问题，这一目标通过维特比算法实现。

在关于HMM的第二讲中，我们将通过探索后验解码来继续讨论解码问题，后验解码允许我们计算序列中每个点上最可能的状态。随后，我们将探讨如何学习隐马尔可夫模型。我们涵盖监督学习和无监督学习，解释如何使用每种方法来学习模型参数。在监督学习中，我们拥有可用的训练数据，这些数据用特定模型标记序列。在无监督学习中，我们没有标签，因此必须寻求基于发现的概率相似性将数据划分为离散类别。在讨论无监督学习时，我们将介绍通用且广泛适用的期望最大化（EM）算法。

7.2 Motivation:

7.2.1 We have a new sequence of DNA, now what?

1. **Align it:**
   - 利用我们已知的信息（数据库搜索）。
   - 处理未知事物（组装/聚类）
2. **Visualize it:** *"Genomics rule #1": Look at your data!*
   - 查找非标准核苷酸组成。
   - 查找与蛋白质编码区域、重复数据、高GC含量等相关的k-mer频率。
   - 寻找模体、进化特征。
   - 翻译并寻找开放阅读框、终止密码子等。
   - 寻找模式，然后开发机器学习工具以确定合理的概率模型。例如，通过观察多个四元组，我们决定对其进行颜色编码，以查看它们最频繁出现的位置。
3. **Model it:**
   - 提出假设。
   - 构建一个生成模型来描述该假设。
   - 使用该模型来找到相似的 **type** 序列。

   我们并非在寻找必然具有共同祖先的序列。相反，我们关注的是具有相似特性的序列。实际上，我们尚不清楚如何对整体基因组进行建模，但可以对基因组的细微方面进行建模。这项任务要求理解基因组区域的所有特性，并通过计算机构建生成模型来表示假设。对于给定的序列，我们希望标注出这些区域是内含子、外显子、基因间区、启动子，还是其他可分类的区域。

构建这一框架将使我们能够：

- 根据生成模型生成（产生）相似类型的序列
- 识别最有可能生成该观测的隐藏状态

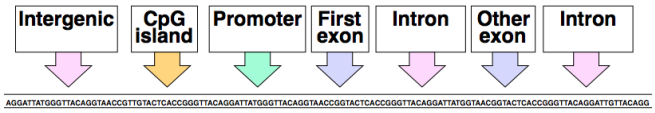

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图7.1：生物序列建模

- 学习（训练）大型数据集，并将其应用于先前已标记的数据（监督学习）和未标记的数据（无监督学习）。

在本讲中，我们讨论用于发射和识别的算法。

7.2.2 Why probabilistic sequence modeling?

- 生物数据是有噪声的。
- 更新关于生物序列的先前知识。
- 概率为操作模型提供了一种演算方法。
- 不限于是/否答案，可以提供信念程度。
- 许多常见的计算工具都基于概率模型。
- 我们的工具：马尔可夫链和隐马尔可夫模型。

7.3 Markov Chains and HMMS: From Example To Formalizing

7.3.1 Motivating Example: Weather Prediction

天气预报一直很困难，尤其是当我们想要预测多天、几周甚至几个月后的天气时。然而，如果我们只需要预测第二天的天气，通过构建图7.2中的图模型，使用一些相当简单的模型（如马尔可夫链和隐马尔可夫模型），我们可以达到不错的预测精度。

对于左侧的马尔可夫链模型，四种天气（晴天、雨天、多云和雪天）可以直接相互转换。这是一种“所见即所得”，因为下一个状态只取决于当前状态，没有对前一个状态的记忆。然而，对于右侧的隐马尔可夫模型，所有类型的天气都被建模为隐藏季节（夏季、秋季、冬季和春季）的发射（或结果）。其背后的关键洞察是，世界的隐藏状态（例如季节或风暴系统）决定了发射概率，而状态转换则由马尔可夫链控制。

7.3.2 Formalizing of Markov Chain and HMMS

为了更仔细地研究隐马尔可夫模型，让我们首先定义图7.3中的关键参数。向量 x 表示观测序列。向量 π 表示隐藏路径，即隐藏状态的序列。转移矩阵 A 的每个元素 a_{kl} 表示从状态k转移到状态l的概率。发射向量的每个元素 $e_k(x_i)$ 表示从状态k观测到 x_i 的概率。最后，利用这些参数和贝叶斯规则，我们可以使用 $p(x_i|\pi_i = k)$ 来估计 $p(\pi_i = k|x_i)$。

Markov Chains

马尔可夫链由有限的状态集合以及状态之间的转移概率给出。在每个时间步，马尔可夫链处于特定状态，并发生转移到另一个状态。转移到每个其他状态的概率仅取决于当前状态，尤其与如何到达当前状态无关。更正式地说，马尔可夫链是一个三元组 (Q, p, A)，其由以下部分组成：

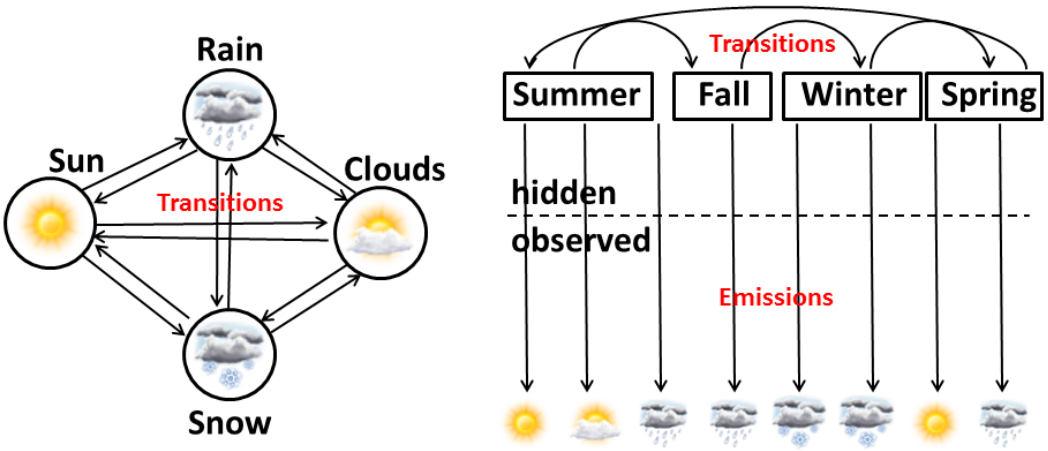

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图7.2：使用马尔可夫链和HMM的预测模型

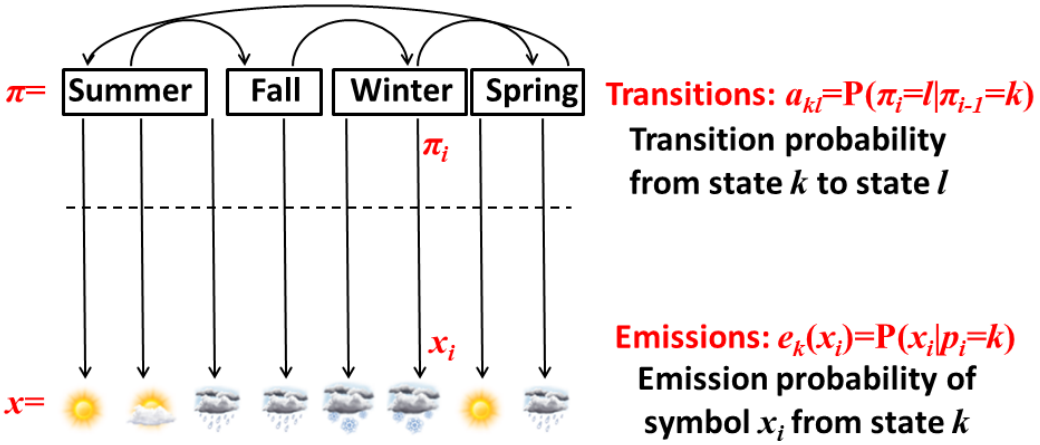

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图7.3：HMM预测模型的参数化

- 一组状态 {v*}。
- 一个转移矩阵 A，其元素对应于从状态 i 转移到状态 j 的概率 A_{ij}。
- 初始状态概率的向量 p。

马尔可夫链的关键特性是无记忆性，即每个状态仅依赖于前一个状态。因此，我们可以立即根据当前状态定义下一个状态的概率：

$$P(x_i|x_{i-1},...,x_1) = P(x_i|x_{i-1})$$

在此 wa y，该序列的概率可以分解为 遵循：

$$P(x) = P(x_L, x_{L-1}, ..., x_1) = P(x_L|x_{L-1})P(x_{L-1}|x_{L-2})...P(x_2|x_1)P(x_1)$$

$P(x_L)$ 也可以根据转移概率计算：如果我们将时间$t = 0$的初始状态概率乘以转移矩阵A，就得到时间$t = 1$的状态概率。乘以转移矩阵的适当幂A^L，我们就得到时间$t = L$的状态概率。

Hidden Markov Models

隐马尔可夫模型用于表示一个问题空间，其中观测结果是由我们无法直接观察到的系统状态产生的。这些观测结果，或发射，基于一组概率从特定状态产生。因此，HMM 是马尔可夫模型，其状态对观察者隐藏，取而代之的是，我们拥有与每个状态相关联的具有一定概率的观测结果。这些观测概率被称为发射概率。

形式上，隐马尔可夫模型是一个五元组 (Q, A, p, V, E)，包含以下参数：

- 一系列状态，{v*}。
- 一个转移矩阵，A
- 初始状态概率向量，p。
- 一组观察符号，例如 V，比如 {A、T、C、G}，或者英语词典中的氨基酸或单词集合。
- 一个发射概率矩阵，E：对于每个 s，t，在 Q 中，发射概率为

$$e_{sk} = P(v_k \text{ at time } t | q_t = s)$$

无记忆性的关键特性继承自马尔可夫模型。发射和转移仅取决于当前状态，而不取决于过去的历史。

7.4 Apply HMM to Real World: From Casino to Biology

7.4.1 The Dishonest Casino

The Scenario

设想以下场景：你进入一家提供掷骰子游戏的赌场。你下注1美元，然后你和庄家各掷一个骰子。如果你掷出的点数更高，你就赢2美元。现在这个看似简单的游戏有个转折。你知道赌场有两种类型的骰子：

1. 公平骰子：$P(1) = P(2) = P(3) = P(4) = P(5) = P(6) = 1/6$
2. Loaded die: $P(1) = P(2) = P(3) = P(4) = P(5) = 1/10$ and $P(6) = 1/2$

庄家可以在你不知情的情况下随时在这两个骰子之间切换。你唯一拥有的信息就是你观察到的掷骰结果。我们可以用一个简单的马尔可夫模型来表示赌场骰子的状态：

该模型展示了两种可能的状态、它们的排放以及它们之间转移的概率。转移概率充其量只是有根据的猜测。我们假设状态之间的切换不会太频繁，因此每次滚动保持在相同状态的概率为.95。

Staying in touch with biology: An analogy

为便于比较，下面的图7.5给出了生物学中一个类似情况的模型，其中DNA序列有两个潜在来源：病毒注入与生物体自身正常产生：

给定这个模型作为假设，我们将观察C和G的频率，以获取有关所讨论序列来源的线索。此模型假定病毒插入片段具有更高的CpG普遍性，这导致C和G出现的概率更高。

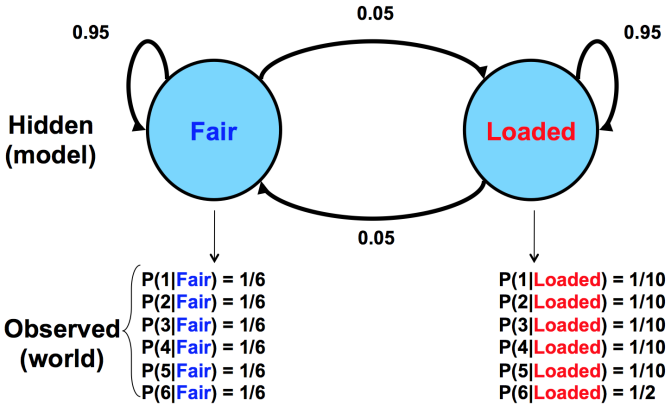

图 7.4：用隐马尔可夫模型表示的赌场骰子状态

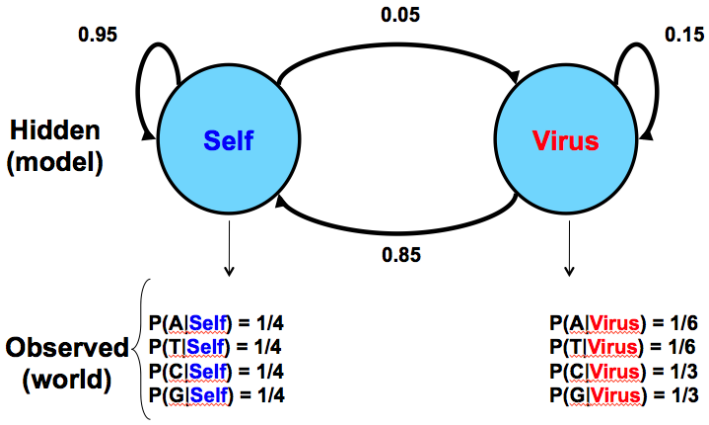

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/。

图7.5：潜在的DNA来源：病毒注射与正常生产

Running the Model

假设我们在赌场，观察图7.6中给出的掷骰序列。我们想知道赌场使用公平骰子还是灌铅骰子的可能性更大。

图7.6：观测到的骰子投掷的可能序列。

让我们来看一个特定的掷骰序列。

因此，我们将考虑基础HMM中两种可能的状态序列：一种是庄家始终使用公平骰子，另一种是庄家始终使用灌铅骰子。我们考察每条执行路径以理解其含义。对于每种情况，我们计算观测结果与该基础状态序列的联合概率。

在第一种情况下，我们假设庄家始终使用公平骰子，转移概率和发射概率如图7.7所示。这个状态序列和观测发射序列的概率是若干项的乘积，这些项可以归为三个部分：1/2，即从109公平骰子开始的概率；(1/6)，即如果我们始终使用公平骰子时掷出序列的概率；最后是(0.95)，即

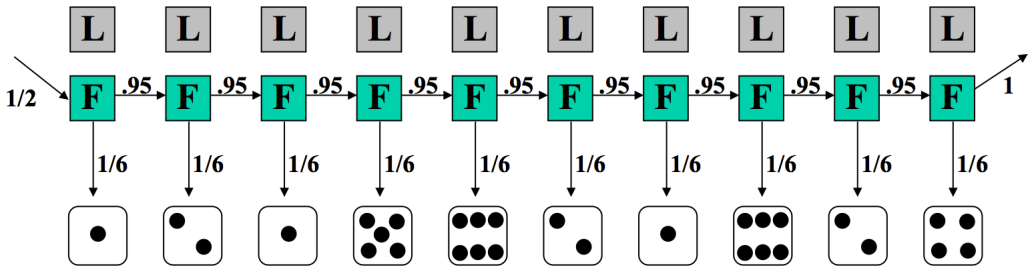

图7.7：运行模型：给定路径由全部公平骰子组成时，一个序列的概率

我们一直继续使用公平骰子的概率。

在这个模型中，我们假设$\pi = \{F, F, F, F, F, F, F, F, F, F\}$，并观察到$x = \{1, 2, 1, 5, 6, 2, 1, 6, 2, 4\}$。现在我们可以计算$x$和$\pi$的联合概率如下：

$$\begin{aligned} P(x, \pi) &= P(x|\pi)P(\pi) \\ &= \frac{1}{2} \times P(1|F) \times P(F|F) \times P(2|F) \cdots \\ &= \frac{1}{2} \times \left(\frac{1}{6}\right)^{10} \times (0.95)^9 \\ &= 5.2 \times 10^{-9} \end{aligned}$$

在如此小的概率下，这看起来似乎是一个极不可能的情况。实际上，概率之所以低，是因为有许多同样可能的情况，而没有哪一个结果是特别$a\ priori$的。问题不在于这个隐藏状态序列是否可能，而在于它是否比其他的选择更$more$。

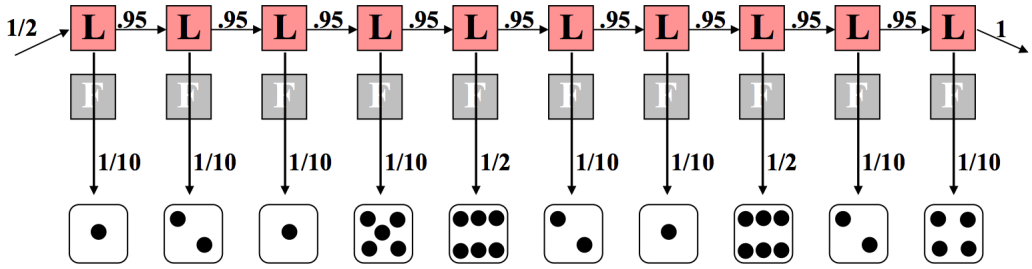

图7.8：运行 t　　模型：给定路径的序列概率由　　所有灌铅骰子

让我们考虑相反的极端情况，即庄家总是使用灌铅骰子，如图7.8所示。这里的计算类似，只是我们注意到发射组件有所不同。这一次，10次投掷中有8次带有1/10的概率，因为灌铅骰子不利于非六点。剩下的两次六点投掷各有1/2的概率发生。我们再次根据独立性和条件性原则将所有这些概率相乘。在这种情况下，计算如下：

$$\begin{aligned} P(x, \pi) &= \frac{1}{2} \times P(1|L) \times P(L|L) \times P(2|L) \cdots \\ &= \frac{1}{2} \times \left(\frac{1}{10}\right)^8 \times \left(\frac{1}{2}\right)^2 \times (0.95)^9 \\ &= 7.9 \times 10^{-10} \end{aligned}$$

注意指数的差异。如果我们直接比较，可以说在整个序列中使用公平骰子的情况是52×10^{-10} (，而使用灌铅骰子的情况是7.9×10^{-10})。

因此，使用公平骰子的可能性是使用灌铅骰子的六倍。这并不太令人惊讶——十次投掷中出现两次6，与公平骰子预期的1.7次相差不大，而与灌铅骰子预期的5次相差较远。

Adding Complexity

现在想象一个更复杂且有趣的情况，其中庄家在序列中的某个时刻更换了骰子。我们根据这一假设在图7.9中对潜在模型进行猜测。

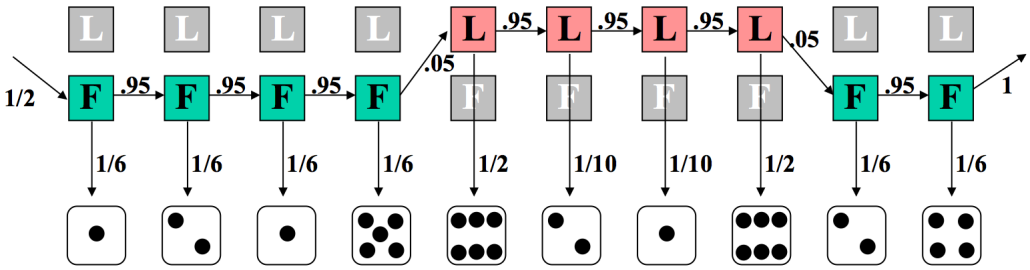

图7.9：部分运行和模具切换

同样，我们可以计算这个状态和观测序列联合概率的似然值。在这里，六次投掷是用公平骰子计算的，四次是用作弊骰子计算的。此外，并非所有转移概率都是95%了。两次交换（在公平骰子和作弊骰子之间）各自有5%的概率。

$$
\begin{aligned}
P(x,\pi) &= \frac{1}{2} \times P(1|L) \times P(L|L) \times P(2|L) \cdots \\
&= \frac{1}{2} \times \left(\frac{1}{10}\right)^2 \times \left(\frac{1}{2}\right)^2 \times \left(\frac{1}{6}\right)^6 \times (0.95)^7 \times (0.05)^2 \\
&= 4.67 \times 10^{-11}
\end{aligned}
$$

显然，我们猜测的路径远不如前两种情况可能性大。但如果我们寻找最可能的情景，就无法通过这种方式计算 {v*} 个备选方案。我们需要新的技术来推断潜在模型。在上述情况中，我们或多或少只是猜测模型，但我们想要的是一种系统地推导可能模型的方法。让我们将迄今引入的模型形式化，继续理解与HMM相关的技术。

7.4.2 Back to Biology

现在我们已经形式化了HMM，我们想用它们来解决一些实际的生物学问题。事实上，HMM是基因序列分析的绝佳工具，因为我们可以将DNA序列视为由混合模型发射出来的。这些模型可能包括内含子、外显子、转录因子等。虽然我们可能有一些将模型与DNA序列匹配的样本数据，但当我们面对一段全新的DNA时，我们可以使用HMM为所讨论的DNA归因一些潜在的模型。我们首先引入一个简单的例子并稍作思考。然后，我们将讨论HMM在解决有趣生物学问题中的一些应用，最后描述解决此类初次尝试/原生分析中出现问题的HMM技术。

A simple example: Finding GC-rich regions

想象以下场景：我们试图通过建模来自两个不同分布的核苷酸序列来寻找富含GC的区域：背景和启动子。背景区域中A、T、G、C的均匀分布概率均为0.25。启动子区域的概率为：A: 0.15, T: 0.13, G: 0.30, C: 0.42。给定观察到一个核苷酸，我们无法判断它来自哪个区域，因为

任一区域将以某种概率产生每个核苷酸。我们可以基于稳态概率学习这些初始状态概率。通过观察一个序列，我们希望识别哪些区域源自背景分布（B），哪些区域来自启动子模型（P）。

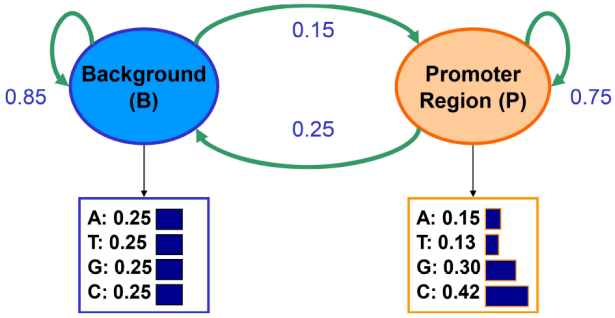

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/。

图7.10：HMMS作为发现富含GC区域的生成模型。

给定基于相关丰度和区域平均长度的转移概率和发射概率，其中 x = 由字母表 {A、T、G、C} 中符号组成的可观测发射向量；π = 路径中的状态向量（例如 BPPBP）；π^* = 生成该路径的最大似然。在我们对序列的解释中，最大似然路径将通过动态规划整合所有发射概率和转移概率来找到。

HMM是生成模型，因为它通过贝叶斯规则给出在给定状态下的发射概率，本质上告诉你该状态生成这些序列的可能性有多大。因此，我们总可以运行一个生成模型来模拟状态间的转移，并可以从任意位置开始。在马尔可夫链中，下一个状态将以不同的概率产生不同的结果。无论下一个状态是什么，在下一个状态中，下一个符号仍将以不同的概率出现。HMM与之类似：你可以根据初始概率向量选择一个初始状态。在上面的例子中，我们将以高概率从状态B开始，因为大多数位置并不对应于启动子区域。然后你从$P(X|B)$中抽取一个发射。在背景状态下，每个核苷酸出现的概率为0.25。假设抽样得到的核苷酸是G。后续状态的分布仅取决于我们处于背景状态这一事实，而与该发射无关。因此，我们有留在状态B的概率为0.85，转移到状态P的概率为0.15，依此类推。

我们可以通过将模型做出我们所假设的确切选择的概率相乘来计算这样一次生成的概率。考虑图7.11、7.12和7.13中所示的例子。

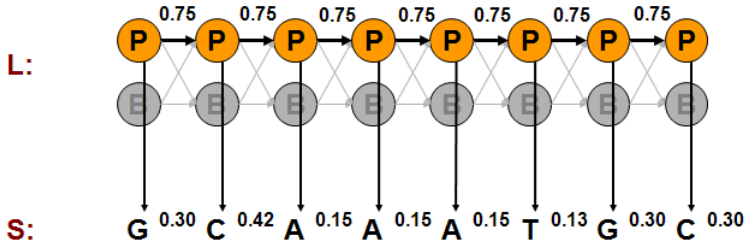

$$P(x,\pi)=a_P*e_P(G)*a_{PP}*e_P(G)*a_{PP}*e_P(C)*a_{PP}*e_P(A)*a_{PP}*\ldots$$
$$=a_p*(0.75)^7*(0.15)^3*(0.13)^1*(0.30)^2*(0.42)^2$$
$$=9.3*10^{-7}$$

图7.11：若全部为启动子，则seq、path的概率

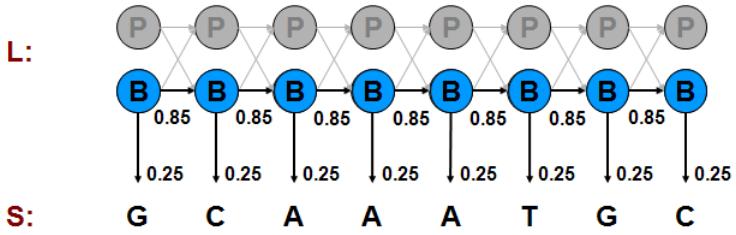

$$P = P(G \mid B)P(B_1 \mid B_0)P(C \mid B)P(B_2 \mid B_1)P(A \mid B)P(B_3 \mid B_2)\ldots P(C \mid B_7)$$
$$= (0.85)^7 \times (0.25)^8$$
$$= 4.9 \times 10^{-6}$$

A: 0.25
T: 0.25
G: 0.25
C: 0.25

图7.12：如果所有都是背景，序列路径的概率

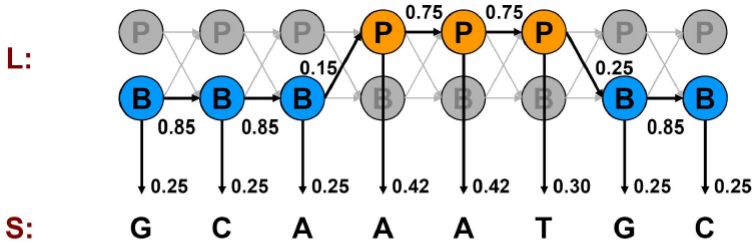

$$P = P(G \mid B)P(B_1 \mid B_0)P(C \mid B)P(B_2 \mid B_1)P(A \mid B)P(P_3 \mid B_2)\ldots P(C \mid B_7)$$
$$= (0.85)^3 \times (0.25)^6 \times (0.75)^2 \times (0.42)^2 \times 0.30 \times 0.15$$
$$= 6.7 \times 10^{-7}$$

图7.13：若混合，序列{v*}、路径序列的概率

我们可以像在赌场示例中那样，计算与观测排放相对应的特定状态序列的联合概率：

$$\begin{aligned}
P(x, \pi_P) &= a_P \times e_P(G) \times a_{PP} \times e_P(G) \times \cdots \\
&= a_P \times (0.75)^7 \times (0.15)^3 \times (0.13) \times (0.3)^2 \times (0.42)^2 \\
&= 9.3 \times 10^{-7} \\
P(x, \pi_B) &= (0.85)^7 \times (0.25)^8 \\
&= 4.9 \times 10^{-6} \\
P(x, \pi_{mixed}) &= (0.85)^3 \times (0.25)^6 \times (0.75)^2 \times (0.42)^2 \times 0.3 \times 0.15 \\
&= 6.7 \times 10^{-7}
\end{aligned}$$

纯背景替代方案是我们所考察的可能性中最有可能的选项。但我们如何知道它是否是在所有可能生成观测序列的状态路径中最有可能的选项?

暴力方法是检查所有路径，尝试所有可能性并计算它们的联合

概率 $P(x, \pi)$，如我们上面所做的那样。所有备选方案的概率之和为 1。例如，如果所有状态都是启动子，$P(x, \pi) = 9.3 \times 10^{-7}$。如果所有发射都是 G，$P(x, \pi) = 4.9 \times 10^{-6}$。如果我们使用如图 7.13 所示的 B 和 P 的混合，$P(x, \pi) = 6.7 \times 10^{-7}$；这个值很小，因为 B 和 P 之间的转移支付了大量惩罚，而这些惩罚随序列长度呈指数增长。通常，如果你观察到更多的 G，它更可能位于启动子区域；如果你观察到更多的 A 和 T，那么它更可能位于背景中。但我们需要的不只是观察来支持我们的信念。我们将在以下各节中看到如何在数学上支持我们的直觉。

Application of HMMs in Biology

HMM被用于回答许多有趣的生物学问题。图7.14总结了HMM的一些生物学应用。

Application	Detection of GC-rich region	Detection of Conserved region	Detection of Protein coding exons	Detection of Protein coding conservation	Detection of Protein coding gene structures	Detection of chromatin states
Topology / Transitions	2 states, different nucleotide composition	2 states, different conservation levels	2 states, different tri-nucleotide composition	2 states, different evolutionary signatures	~20 states, different composition / conservation, specific structure	40 states, different chromatin mark combinations
Hidden States / Annotation	GC-rich / AT-rich	Conserved / non-Conserved	Coding (exon) / non-Coding (intron or intergenic)	Coding (exon) / non-Coding (intron or intergenic)	First / last / middle coding exon, UTRs, intron 1/2/3, intergenic, *(+,-) strand	Enhancer / Promoter / Transcribed / Repressed / Repetitive
Emissions / Observations	Nucleotides	Level of conservation	Triplets of nucleotides	64 x 64 matrix of codon substitution frequencies	Codons, nucleotides, splice sites, start/stop codons	Vector of chromatin mark frequencies

图7.14：HMM的一些生物学应用

7.5 Algorithmic Settings for HMMs

我们使用HMM进行三种类型的操作：**scoring**、**decoding**和**learning**。本讲将讨论评分与解码。这些操作可以针对单一路径或所有可能路径进行。对于单一路径操作，我们的重点是发现具有最大概率的路径。然而，对于所有路径操作，我们感兴趣的是观测或发射序列，而不管其对应的路径。

7.5.1 Scoring

Scoring over a single path

7.4节中描述的不诚实赌场问题和富含GC区域预测问题都是寻找对应于单一　　径的概率得分的问题。对于单一　　径，我们将评分问题定义如下：

- **Input:** 由HMM $M(Q, A, p, V, E)$生成的一系列观测值$x = x_1 x_2 \ldots x_n$，以及状态路径$\pi = \pi_1 \pi_2 \ldots \pi_n$。
- **Output:** 联合概率，$P(x, \pi)$，若隐藏状态序列为π，则观测到x。

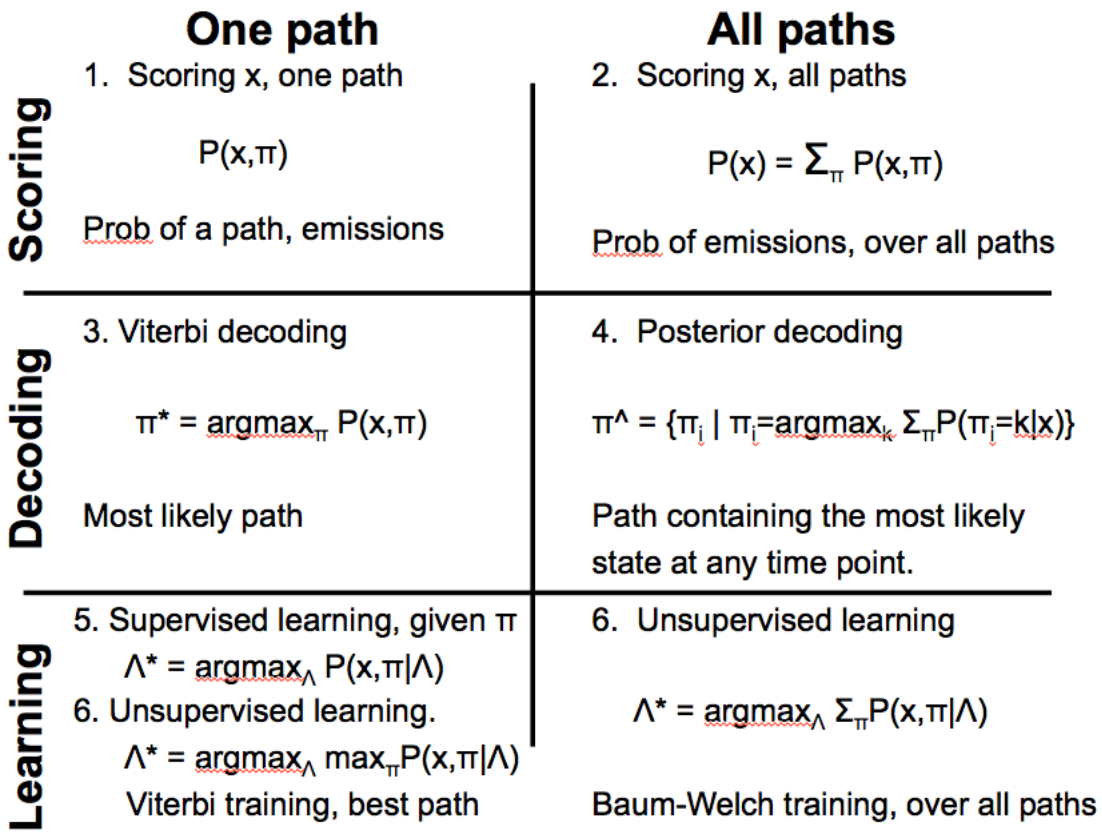

图7.15：HMMS的六种算法设置

单路径计算本质上是在特定路径上观测到给定序列的可能性，使用以下公式：

$$P(x, \pi) = P(x|\pi)P(\pi)$$

我们已经在不诚实的赌场和富含GC区域示例中看到了单路径评分的例子。

Scoring over all paths

W我们将所有路径版本的评分问题定义如下　　s：

- **Input:** 由HMM $M(Q, A, p, V, E)$生成的一系列观测值$x = x_1 x_2 \ldots x_n$。
- **Output:** 联合概率，$P(x, \pi)$，即在所有可能的隐藏状态序列下观测到x的概率　　ates π。

给定观测序列下，隐藏状态所有路径π的概率由以下公式给出。

$$P(x) = \sum_{\pi} P(x, \pi)$$

当我们需要了解给定HMM下特定序列的可能性时，我们会使用这个分数。然而，直接计算这个和需要考虑到可能路径的数量呈指数级增长。在后续的讲座中，我们将看到如何在多项式时间内计算这个量。

7.5.2 Decoding

解码回答的问题是：给定一些观察到的序列，什么路径使我们观察到这个序列的可能性最大？我们形式化地定义问题如下：

- **Decoding over a single path:**

  – 输入：由 HMM $M(Q, A, p, V, E)$ 生成的一系列观测 $x = x_1 x_2 \ldots x_N$。 – 输出：最可能的状态路径，$\pi^* = \pi_1^* \pi_2^* \ldots \pi_N^*$

- **Decoding over all paths:**

  – 输入：由HMM $M(Q, A, p, V, E)$生成的一系列观测值$x = x_1 x_2 \ldots x_N$。 –输出：状态路径 $\pi^* = \pi_1^* \pi_2^* \ldots \pi_N^*$，其中包含每个时间点上最可能的状态。

在本讲中，我们将只探讨单路径解码问题。关于所有路径的解码问题将在下一讲中讨论。

对于单路径解码问题，我们可以设想一种暴力方法，即计算给定发射序列与所有可能路径的联合概率，然后选择联合概率最大的路径。问题在于路径的数量呈指数级增长，使用这种暴力搜索在所有可能路径中寻找最大似然路径非常耗时且不切实际。**Dynamic Programming**可以用来解决这个问题。让我们用动态规划方法来表述这个问题。

我们希望根据观测找出最可能的状态序列。作为输入，我们给定模型参数$e_i(s)$，即每个状态的发射概率，以及$a_{ij}s$，即转移概率。发射序列x也是给定的。目标是找到隐藏状态序列π^*，使得与给定发射序列的联合概率最大化。即，

$$\pi^* = \arg\max_\pi P(x, \pi)$$

给定发射序列 x，我们可以评估任何通过隐藏状态的路径。然而，我们寻找的是最佳路径。我们从寻找此问题的最优子结构开始。

对于最佳路径，我们可以说，通过给定状态的最佳路径必须包含以下内容：

- 回到之前状态的最佳路径
- 从先前状态到该状态的最佳转移
- 通往最终状态的最佳路径

因此，最佳路径可以基于前几个状态的最佳路径来获得，也就是说，我们可以找到最佳路径的递推关系。**Viterbi**算法是一种常用于获取最佳路径的动态规划算法。

Most probable state path: the Viterbi algorithm

假设 $v_k(i)$ 是已知的在状态 k 下，以位置（或时间实例）i 结束的最可能路径的概率，对于每个 k。然后我们可以通过以下递推关系计算时间 $i + 1$ 时的相应概率。

$$v_l(i + 1) = e_l(x_{i+1}) \max_k (a_{kl} v_k(i))$$

最可能的路径 π^*，或最大值 $P(x, \pi)$，可以通过递归方式找到。假设我们已知 $v_j(i - 1)$，即截至时间 $i - 1$ 的最大路径得分，我们需要增加下一个时间步的计算。每个状态的新最大得分路径取决于

- 之前状态的最大分数
- 转移概率
- 发射概率。

换句话说，在时间 i 时，某个特定状态的新最大分数是通过最大化所有可能的前一状态转移到该特定状态的过渡值来获得的，该过渡值等于过渡惩罚乘以它们各自的最大前分数再乘以当前时间的发射概率。

所有序列都必须从状态0（起始状态）开始。通过保留向后指针，可以通过回溯找到实际的状态序列。这个动态规划问题的解决方案与之前讲座中介绍的对齐算法非常相似。

维特比算法[2]的步骤如下所述:

1. 初始化 ($i = 0$)：$v_0(0) = 1$，$v_k(0) = 0$ 对于 $k > 0$。

2. 递归 ($i = 1 \ldots N$): $v_k(i) = e_k(x_i)\ \max_j(a_{jk}v_j(i-1))$; $ptr_i(l) = \arg\max_j(a_{jk}v_j(i-1))$。

3. 终止：$P(x, \pi^*) = \max_k v_k(N)$；$\pi_N^* = \arg\max_k v_k(N)$。

4. 回溯（$i = N \ldots 1$）：$\pi_{i-1}^* = ptr_i(\pi_i^*)$。

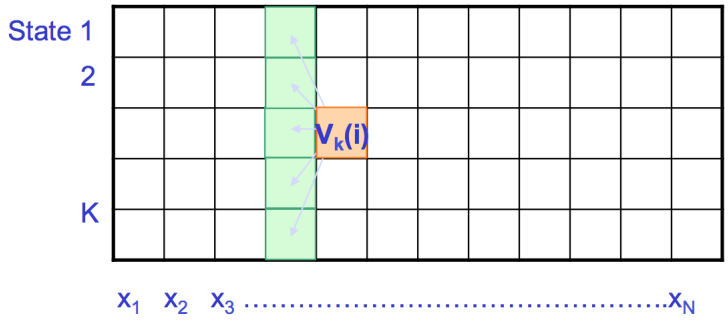

图7.16: 维特比算法

如图 7.16 所示，我们从左到右填充矩阵并进行回溯。矩阵中的每个位置有 K 种状态需要考虑，矩阵中有 KN 个单元格，因此所需的计算时间为 $O(K^2N)$，所需的存储空间为 $O(KN)$ 来记录指针。在实际应用中，我们使用对数分数进行计算。注意，运行时间已从指数级降低到多项式级。

7.5.3 Evaluation

评估是关于回答这样一个问题：我们的数据模型在多大程度上捕捉到了实际数据？给定一个序列x，许多路径可以生成这个序列。问题在于，给定模型，这个序列的可能性有多大？换句话说，这是一个好的模型吗？或者，模型在多大程度上准确捕捉了特定序列的特性？我们使用HMM的评估来解答这些问题。此外，通过评估，我们可以比较不同的模型。

让我们首先给出评估问题的正式定义。

- 输入：观测序列 $x = x_1x_2 \ldots x_N$ 和一个 HMM $M(Q, A, p, V, E)$。
- 输出：x 由 M 生成的概率，对所有路径求和。

我们知道，如果给定一个HMM，我们可以使用以下步骤生成长度为n的序列:

- 从状态 π_1 开始，依据使用向量 p) 得到的概率 $a_{0\pi_1}$ (。
- 根据发射概率 $e_{\pi_1}(x_1)$ 发射字母 x_1。
- 根据转移概率 $a_{\pi_1|\pi_2}$ 转到状态 π_2
- 继续这样做，直到发出 x_N。

因此，我们可以生成任意序列并计算其似然。然而，许多状态序列可以生成相同的x。那么，我们如何计算在给定x下所有路径生成的总概率？也就是说，我们的目标是获得以下概率：

$$P(x|M) = P(x) = \sum_{\pi} P(x, \pi) = \sum_{\pi} P(x|\pi)P(\pi)$$

获得该概率的挑战在于路径太多（数量呈指数级），且每条路径都有一个相关的概率。一种方法可能是仅使用 Viterbi 路径而忽略其他路径，因为我们已经知道如何获得这条路径。但它的概率非常小，因为它只是众多可能路径中的一条。只有当它具有高概率密度时，这才是一个好的近似。在其他情况下，Viterbi 路径会给我们一个不准确的近似。或者，迭代计算精确总和的正确方法是使用动态规划。实现这一点的算法被称为 **Forward Algorithm**。

The Forward Algorithm

首先我们推导前向概率$f(i)$的公式。

$$\begin{aligned}
f_l(i) &= P(x_1 \dots x_i, \pi = l) && (7.1)\\
&= \sum_{\pi_1 \dots \pi_{i-1}} P(x_1 \dots x_{i-1}, \pi_1, \dots, \pi_{i-2}, \pi_{i-1}, \pi_i = l) e_l(x_i) && (7.2)\\
&= \sum_k \sum_{\pi_1 \dots \pi_{i-2}} P(x_1 \dots x_{i-1}, \pi_1, \dots, \pi_{i-2}, \pi_{i-1} = k) a_{kl} e_l(x_i) && (7.3)\\
&= \sum_k f_k(i-1) a_{kl} e_l(x_i) && (7.4)\\
&= e_l(x_i) \sum_k f_k(i-1) a_{kl} && (7.5)\\
& && (7.6)
\end{aligned}$$

完整算法[2]总结如下：

- 初始化（$i = 0$）：$f_0(0) = 1$，$f_k(0) = 0$ 对应 $k > 0$。
- 迭代（$i = 1 \dots N$）：$f_k(i) = e_k(x_i) \sum_j f_j(i-1) a_{jk}$。
- 终止：$P(x, \pi^*) = \sum_k f_k(N)$

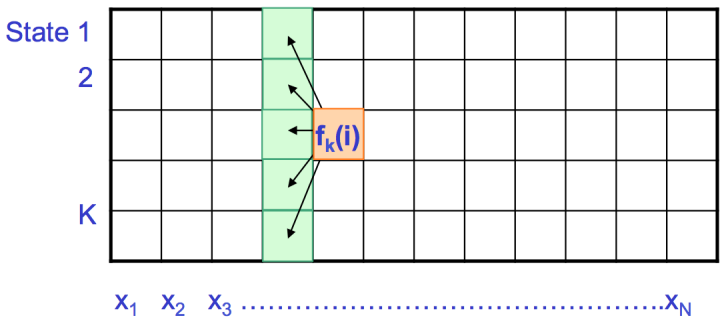

图7.17：前向算法

从图7.17可以看出，前向算法与维特比算法非常相似。在前向算法中，使用求和代替最大化。在这里，我们可以重用

前一个问题包括排放惩罚、转移惩罚以及先前状态之和。所需的计算时间为$O(K^2N)$，所需空间为$O(KN)$。该算法的缺点是在实践中，取对数之和很困难；因此，转而使用概率的近似和缩放。

7.6 An Interesting Question: Can We Incorporate Memory in Our Model?

这个问题的答案是——是的，我们可以！但如何做到呢？回想一下，马尔可夫模型是无记忆的。换句话说，模型的所有记忆都包含在状态中。因此，为了存储额外的信息，我们必须增加状态的数量。现在，回顾我们在第7.4.2节中给出的生物学例子。在我们的模型中，状态发射仅依赖于当前状态。而且，当前状态仅编码了一个核苷酸。但是，如果我们希望我们的模型计算二核苷酸频率（用于CpG岛[1]），或者三核苷酸频率（用于密码子），或者涉及六核苷酸的二密码子频率呢？我们需要扩展状态的数量。

例如，可以通过将高GC/低GC HMM中的加号和减号状态拆分为多个状态，来把最近出现的核苷酸整合到HMM的“记忆”中：每个核苷酸/区域组合对应一个状态，如图7.18所示。

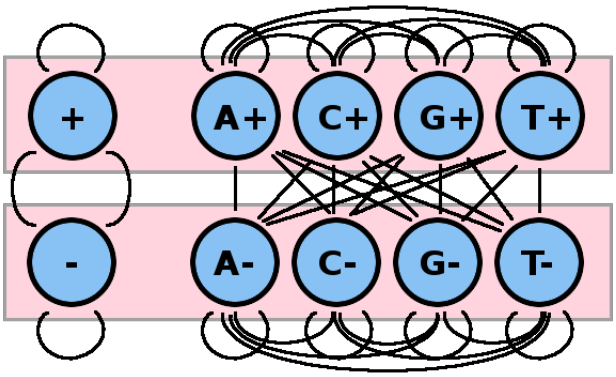

图7.18：CpG岛——引入记忆机制

从两个状态扩展到八个状态，使我们能够保留对上一次观察到的核苷酸的记忆，同时还能区分两个不同的区域。在High/Low-GC HMM中，原本两个状态现在各对应四个新状态。较小的HMM中的转换权重仅基于单个核苷酸的频率，而现在较大的HMM中的转换权重则基于二核苷酸频率。

有了这种增强的能力，某些二核苷酸序列，如CpG岛，可以被特别建模：从C+到G+的转换可以被赋予比从A+到G+的转换更大的权重。此外，+与-之间的转换可以更具体地建模，以反映特定二核苷酸序列在其中一个或另一个中的频率（或非频率）。

向HMM中添加记忆的过程可以泛化，并且可以添加更多记忆以允许识别更长的序列。例如，我们可以用32个状态检测密码子三联体，或用2048个状态检测二密码子六联体。HMM中的记忆允许在扫描中实现越来越定制的特异性。

[1] CpG stands for C-phosphate-G. So, CpG island refers to a region where GC di-nucleotide appear on the same strand.

7.7 Further Reading

7.7.1 Length Distributions of States and Generalized Hidden Markov Models

给定一个马尔可夫链，其中从任意状态转移到结束状态的概率为 τ，生成一个长度为 L (的序列，然后以转移到结束状态) 结束的概率由下式给出：

$$\tau(1-\tau)^{L-1}$$

同样，在我们一直在研究的HMM中，状态的长度将呈指数分布，这在许多情况下并不适用。（例如，在基因组序列中，指数分布无法准确捕捉基因、外显子、内含子等的长度）。我们如何构建一个模型，使其输出的状态序列长度不呈指数分布？假设我们要确保序列的长度恰好为5。我们可以构建一个由五个状态组成的序列，其转移概率仅允许一条路径。如果在其中一个状态中包含自循环，我们将输出长度至少为5的序列，而更长的序列则呈指数分布。假设我们有一个由n个状态组成的链，所有链都从状态π_1开始，并在π_n之后转移到一个结束状态。同时假设状态π_i和π_{i+1}之间的转移概率为$1-p$，而状态π_i的自转移概率为p。由这个马尔可夫链生成的序列长度为L的概率由下式给出：

$$\binom{L-1}{n-1}p^{L-n}(1-p)^n$$

这称为负二项分布。

更一般地，我们可以调整HMM以产生任意长度的输出序列。在一个*Generalized Hidden Markov Model* [1]（也称为*hidden semi-Markov model*）中，每个状态的输出是一个符号串，而不是单个符号。这个输出串的长度和内容都可以根据概率分布来选择。许多基因发现工具都是基于广义隐马尔可夫模型的。

7.7.2 Conditional random fields

条件随机场模型是一种判别式无向概率图模型，常作为隐马尔可夫模型的替代方案。它用于编码观测之间的已知关系并构建一致的解释。它通常用于序列数据的标注或解析。它广泛应用于基因发现。以下资源有助于进一步了解条件随机场：

- 概率图模型课程中关于条件随机场的讲座：`https://class.coursera.org/pgm/lecture/preview/33`。为了了解背景知识，你可能还想观看前两段视频，分别关于成对马尔可夫网络和一般吉布斯分布。
- 生物学中的条件随机场：`http://www.cis.upenn.edu/~pereira/papers/crf.pdf`
- 条件随机场教程：`http://people.cs.umass.edu/~mccallum/papers/crf-tutorial.pdf`

7.8 Current Research Directions

7.9 Tools and Techniques

7.10 What Have We Learned?

在本节中，我们涵盖的主要内容如下：

- 首先，我们介绍了在基因组注释分析中采用隐马尔可夫模型背后的动机。

- 其次，我们在天气预报示例的启发下形式化了马尔可夫链和HMM。
- 第三，通过观察不诚实的赌场和富含CG区域问题，我们了解了如何将HMM应用于现实世界数据中。
- 第四，我们系统地介绍了HMM的算法设置，并详细探讨了其中的三种：–评分：单路径评分–评分：所有路径评分–解码：维特比编码确定最可能路径
- 最后，我们讨论了在HMM分析中引入记忆的可能性，并为感兴趣的读者提供了进一步的阅读材料。

Bibliography

[1] GHMMs 简介：`www.cs.tau.ac.il/~rshamir/algmb/00/scribe00/html/lec07/node28.html`。

[2] R. Durbin, S. Eddy, A. Krogh, and G. Mitchison. *Biological sequence analysis*. 第十一版，2006年。

CHAPTER
EIGHT

隐马尔可夫模型 II - 后验解码与学习

查拉拉姆波斯·马夫罗福拉基斯和奇杜贝·埃泽奥祖 (2012)
托马斯·威廉姆斯 (2011) 阿梅尔·费伊齐奇 (2010) 埃尔哈
姆·阿齐齐 (2009)

Figures

8.1 HMM在基因组学中的应用 . . . . . 146 8.2 前向算法 . . . . . 148 8.3 后向算法 . . . . . 152 8.4 CpG岛的HMM . . . . . 155 8.5 CpG岛的监督学习 . . . . . 156 8.6 带仿射空位罚分的比对HMM模型 . . . . . 159 8.7 GENSCAN中使用的状态空间图 161

8.1 Review of previous lecture

8.1.1 Introduction to Hidden Markov Models

在上一讲中，我们熟悉了离散时间马尔可夫链和隐马尔可夫模型（HMMs）的概念。特别地，马尔可夫链是一种遵循马尔可夫性质的离散随机过程，即下一个状态的概率仅取决于当前状态；这一性质也常被称为“无记忆性”。为了模拟状态如何逐步变化，马尔可夫链使用了一个转移概率矩阵。此外，其特点是状态与观测符号之间存在一一对应关系；即状态完全决定了所有相关的可观测量。更正式地说，马尔可夫链完全由以下变量定义：

- $\pi_i \in Q$，长度为 N 的有限状态序列 Q 中第 i^{th} 步的状态，该状态可以取长度为 K 的有限字母表 Σ 中的值
- a_{jk}，从状态j转移到状态k的转移概率，$P(\pi_i = k|\pi_{i-1} = j)$，对于$Q$中的每个$j, k$
- ${}^{a}0_j \in P$，初始状态将为j的概率

马尔可夫链的例子在日常生活中比比皆是。在上一讲中，我们考虑了一个典型的天气系统例子，其中每个状态要么是雨、雪、晴或云，系统的可观测量恰好对应于底层状态：我们一旦做出观察，就没有什么未知的

观察，作为观察，即无论是晴天还是下雨，完全决定了潜在状态，即无论是晴天还是下雨。然而，假设我们将天气视为由季节概率性地决定——例如，冬天比春天更常下雪——并进一步假设我们处于古代，尚未获得关于当前季节是什么的知识。现在考虑尝试从天气（可观察的）推断季节（隐藏状态）的问题。季节与天气之间存在某种关系，使得我们可以利用关于天气的信息来推断现在是什么季节（如果下很多雪，那很可能不是夏天）；这正是HMM试图承担的任务。因此，在这种情况下，状态，即季节，被视为“隐藏”的，不再与可观察的天气一一对应。这类情况需要一种马尔可夫链的推广，称为隐马尔可夫模型（HMM）。

Did You Know?
马尔可夫链可以被视为所见即所得——你看到的就是你得到的

隐马尔可夫模型引入了额外的元素来建模系统可观测量与隐藏状态之间的脱节。对于长度为 N 的序列，每个可观测状态都被替换为一个隐藏状态（季节）和从该状态发射的一个字符（天气）。需要注意的是，每个状态发射的字符遵循一系列发射概率（例如冬季有50%的概率下雪、30%的概率晴天、20%的概率下雨）。更正式地说，HMM的两个额外描述符是:

- $x_i \in X$，在长度为 N 的有限字符序列 X 中，第 i^{th} 步的发射，该序列可容纳来自有限观测符号集 $v_l \in V$的一个字符
- $e_k(v_l) \in E$，当状态为 k 时发射字符 v_l 的发射概率，$P(x_i = v_l|\pi_i = k)$ 总之，HMM 由以下变量定义:
- a_{jk}、$e_k(v_l)$ 和 a_{0j}，用于建模离散随机过程
- π_i，隐藏状态序列
- x_i，观测到的排放序列

8.1.2 Genomic Applications of HMMs

下图展示了HMM的一些基因组应用

Application	Detection of GC-rich region	Detection of Conserved region	Detection of Protein coding exons	Detection of Protein coding conservation	Detection of Protein coding gene structures	Detection of chromatin states
Topology / Transitions	2 states, different nucleotide composition	2 states, difference conservation levels	2 states, different tri-nucleotide composition	2 states, different evolutionary signatures	~20 states, different composition / conservation, specific structure	40 states, different chromatin mark combinations
Hidden States / Annotation	GC-rich / AT-rich	Conserved/ non-Conserved	Coding (exon) / non-Coding (intron or intergenic)	Coding (exon) / non-Coding (intron or intergenic)	First / last / middle coding exon, UTRs, intron 1/2/3, intergenic, *(+,-) strand	Enhancer / Promoter / Transcribed / Repressed / Repetitive
Emissions / Observations	Nucleotides	Level of conservation	Triplets of nucleotides	64 x 64 matrix of codon substitution frequencies	Codons, nucleotides, splice sites, start/stop codons	Vector of chromatin mark frequencies

图8.1：HMM的基因组应用

图8.1中展示的一些应用的细节包括:

- **Detection of Protein coding conservation**
  这类似于检测蛋白质编码外显子的应用，因为发射物也不是核苷酸，但不同之处在于，它不是发射密码子，而是发射密码子的替换频率。

- **Detection of Protein coding gene structures**
  在这里，不同状态分别对首个、末尾和中间外显子进行独立建模非常重要，因为它们具有各自不同的相关结构特征：例如，转录本中的首个外显子会经过起始密码子，末尾外显子会经过终止密码子等，为了做出最佳预测，我们的模型应当编码这些特征。这与检测蛋白质编码外显子的应用不同，因为在那种情况下，外显子的位置并不重要。

  同样重要的是要区分内含子1、2和3，以便记住一个外显子与下一个外显子之间的阅读框，例如，如果一个外显子在第二个密码子位置停止，下一个外显子必须在第三个密码子位置开始。因此，额外的内含子状态编码了密码子位置。

- **Detection of chromatin states**
  染色质状态模型是动态的，并且因细胞类型而异，因此每种细胞类型都会有自己的注释。它们将在基因组学讲座中进行更详细的讨论，包括堆叠/连接细胞类型的策略。

8.1.3 Viterbi decoding

之前，我们已经证明，当给定一个完整的隐马尔可夫模型（Q, A, X, E, P）时，离散随机过程生成所提供的一系列隐藏状态和观测值的似然度由下式给出:

$$P(x_1, \ldots, x_N, \pi_1, \ldots, \pi_N) = a_{0\pi_i} \prod_i e_{\pi_i}(x_i) a_{\pi_i \pi_{i+1}} \tag{8.1}$$

这对应于总联合概率，$P(x, \pi)$。然而，通常隐藏状态并未给出，必须推断；我们并不感兴趣于已知隐藏状态的基础模型下观测序列的概率，而是希望利用观测序列来推断隐藏状态，比如当我们使用生物体的基因组序列来推断其基因的位置时。解决这个*decoding*问题的一个方法被称为**Viterbi decoding**算法。该算法运行时间为$O(K^2N)$，空间为$O(KN)$，其中K是状态的数量，N是观测序列的长度，它确定了使观测值和状态联合概率最大化的隐藏状态序列（路径π^*），即$P(x, \pi)$。本质上，该算法定义$V_k(i)$为以状态$\pi_i = k$结束的最可能路径的概率，并利用我们在课程序列比对模块中看到的最优子结构论证，在动态规划算法中递归计算$V_k(i) = e_k(x_i) \times \max_j(V_j(i-1)a_{jk})$。

8.1.4 Forward Algorithm

暂时回到“评分”而非“解码”的问题上，我们可能想要解决的另一个问题是，不是计算单个隐藏状态路径发出观测序列的概率，而是计算序列由所有可能路径产生的*total*概率。例如，在赌场例子中，如果掷骰序列足够长，任何*single*观测序列及其潜在路径的概率都非常低，即使它是最可能的序列-路径组合。我们可能反而想对路径采取不可知的态度，并评估观测序列以任何方式出现的总概率。

为了实现这一点，我们提出了**Forward algorithm**，如图8.2所述。

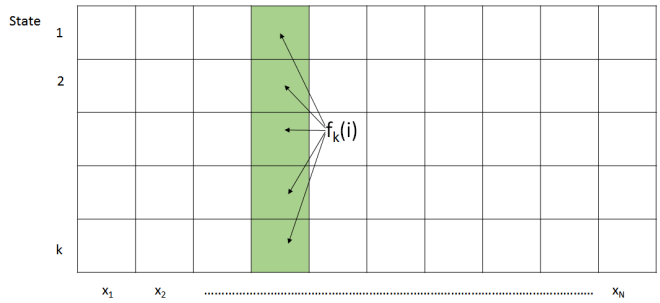

图8.2：前向算法

输入：$x = x_1 \dots x_N$

初始化：

$f_0(0) = 1, f_k(0) = 0, \quad \text{for all } k > 0$

迭代：

$f_k(i) = e_k(x_i) \times \sum_j a_{jk} f_j(i-1)$

终止：

$P(x, \pi^*) = \sum_k f_k(N)$

前向算法首先计算观测到前t个发射字符且在时间t处于状态k的联合概率。更正式地，

$$f_k(t) = P(\pi_t = k, x_1, \dots, x_t) \tag{8.2}$$

鉴于路径数量在t中呈指数级增长，必须采用动态规划来解决此问题。我们可以利用马尔可夫性质，为前向算法构建一个简单的递归式，如下所示：

$$f_k(t) = \sum_l P(x_1, \dots, x_t, \pi_t = k, \pi_{t-1} = l) = \sum_l P(x_1, \dots, x_{t-1}, \pi_{t-1} = l) * P(x_t, \pi_t | \pi_{t-1}) \tag{8.3}$$

认识到第一项对应于 $f_l(t-1)$，并且第二项可以用转移概率和发射概率来表示，这引出了最终的递归式：

$$f_k(t) = e_k(x_t) \sum_l f_l(t-1) * a_{lk} \tag{8.4}$$

直观上，可以这样理解这个递归：任何在时间t处于状态k的路径，必定来自时间t –处于状态l的路径1。然后，这些路径集合的贡献由从状态l转移到状态k的成本加权。同样重要的是要注意，维特比算法和前向算法在很大程度上共享相同的递归。两种算法之间的唯一区别在于，维特比算法为了找到唯一最可能的路径，使用了最大化函数，而前向算法为了找到序列在所有路径上的总概率，使用了求和。

我们现在可以根据上一步时间步骤中汇总的所有前向算法结果的加权和来计算 $f_k(t)$。如图8.2所示，前向算法可以轻松地在一个KxN的动态规划表中实现。表的第一列根据初始状态概率 a_{i0} 进行初始化，然后算法从左到右处理每一列。由于有KN个条目，且每个条目总共检查K个其他条目，这导致了 $O(K^2N)$ 的时间复杂度和 $O(KN)$ 的空间。

现在，为了计算当前HMM下观测字符序列的总概率，我们需要用前向算法给出的方式来表达这个概率，具体如下：

$$P(x_1, \dots, x_n) = \sum_l P(x_1, \dots, x_n, \pi_N = l) = \sum_l f_l(N) \tag{8.5}$$

因此，动态规划表最后一列元素的总和给出了观测字符序列的总概率。在实践中，给定足够长的发射字符序列，前向概率会非常迅速地减小。为了规避与存储小浮点数相关的问题，在计算中使用对数概率而非概率本身。这一改动要求对算法进行微调，并使用指数函数的泰勒级数展开。

8.1.5 This lecture

- 本节课将讨论**posterior decoding**算法，该算法同样推断出使不同度量最大化的隐藏状态序列π。特别地，它利用**forward**和**backward**算法，在所有可能路径中找到每个位置上最可能的状态。

- 之后，我们将展示如何通过添加更多状态来在马尔可夫链中编码“记忆”，以在基因组中搜索二核苷酸CpG岛。

- 接下来我们将讨论如何使用最大似然参数估计，基于带标签数据集进行监督学习

- 我们还将简要介绍如何使用维特比学习来对未标记数据集的参数进行无监督估计。

- 最后，我们将学习如何使用期望最大化（EM）对未标记数据集的参数进行无监督估计，其中针对HMM的特定算法被称为Baum-Welch算法。

8.2 Posterior Decoding

8.2.1 Motivation

虽然**Viterbi decoding**算法提供了一种估计观测字符序列背后隐藏状态的方法，但**posterior decoding**提供了另一种有效的推断方法。

后验解码提供了任意时间点上最可能的状态。为了对后验解码有一些直观理解，让我们看看它如何应用于一个不诚实的赌场在公平骰子和灌铅骰子之间交替的情况。假设我们进入赌场时知道不公平骰子有60%的时间被使用。基于这一知识且没有骰子投掷，我们对当前骰子的最佳猜测显然是被灌铅的那个。在一次投掷之后，使用灌铅骰子的概率由下式给出

$$P(die = loaded|roll = k) = \frac{P(die = loaded) * P(roll = k|die = loaded)}{P(roll = k)}. \tag{8.6}$$

如果我们改为观察N次掷骰子的序列，如何进行类似的推断呢？通过允许信息在N次投掷之间流动并影响每个状态的概率，后验解码是将上述推断自然扩展到任意长度序列的方法。更正式地说，后验解码不是识别单一的最大似然路径，而是考虑在给定所有观察到的字符条件下，任何路径在时间t处于状态k的概率，即$P(\pi_t = k|x_1, \ldots, x_n)$。然后，对于给定的时间，最大化这一概率的状态被视为该点上最可能的状态。

需要注意的是，除了信息向前流动以确定某一点最可能的状态外，信息也可能从序列的末端向后流动到该状态，以增强或减弱该点每个状态的可能性。这部分是贝叶斯规则可逆性的自然结果：随着我们观察到更多数据，我们的概率从先验概率转变为后验概率。为了阐明这一点，再次想象赌场示例。如前所述，在未观察到任何掷骰结果的情况下，$state_0$ 最有可能是不公平的：这是我们的先验概率。如果第一次掷出的是6，我们对 $state_1$ 不公平的信念会得到加强（如果不公平骰子掷出六点的可能性更大）。如果再次掷出6，信息会从第二次掷骰向后流动，并进一步强化我们对 $state_1$ 不公平骰子的信念。我们拥有的掷骰次数越多，向后流动并强化或对比我们对状态信念的信息就越多，从而说明信息向后和向前流动以影响我们对后验解码中状态信念的方式。

使用一些基本的操作，我们可以利用贝叶斯规则将这个概率重新排列成以下形式：

$$\pi_t^* = argmax_k P(\pi_t = k|x_1, \ldots, x_n) = argmax_k \frac{P(\pi_t = k, x_1, \ldots, x_n)}{P(x_1, \ldots, x_n)} \tag{8.7}$$

因为 $P(x)$ 是常数，我们在最大化函数时可以忽略它。因此，

$$\pi_t^* = argmax_k P(\pi_t = k, x_1, \ldots, x_t) * P(x_{t+1}, \ldots, x_n|\pi_t = k, x_1, \ldots, x_t) \tag{8.8}$$

利用马尔可夫性质，我们可以简单地将此表达式写为：

$$\pi_t^* = argmax_k P(\pi_t = k, x_1, \ldots, x_t) * P(x_{t+1}, \ldots, x_n|\pi_t = k) = argmax_k f_k(t) * b_k(t) \tag{8.9}$$

这里，我们定义了 $f_k(t) = P(\pi_t = k, x_1, \ldots, x_t)$ 和 $b_k(t) = P(x_{t+1}, \ldots, x_n|\pi_t = k)$。正如我们即将看到的，这些参数分别使用 **forward algorithm** 和 **backward algorithm** 来计算。为了解决后验解码问题，我们只需解决每个子问题即可。前向算法已在前一章及本章开头的回顾中说明，而后向算法将在下一节中解释。

8.2.2 Backward Algorithm

如前所述，使用后向算法计算以下概率：

$$b_k(t) = P(x_{t+1}, \ldots, x_n|\pi_t = k) \tag{8.10}$$

我们可以开始通过展开成以下形式来开发一个递归n:

$$b_k(t) = \sum_l P(x_{t+1}, \ldots, x_n, \pi_{t+1} = l | \pi_t = k) \tag{8.11}$$

From the Markov property, we then obtain:

$$b_k(t) = \sum_l P(x_{t+2}, \ldots, x_n | \pi_{t+1} = l) * P(\pi_{t+1} = l | \pi_t = k) * P(x_{t+1} | \pi_{t+1} = k) \tag{8.12}$$

第一项仅对应于 $b_l(t+1)$。用发射概率和转移概率表示，得到最终的递归式:

$$b_k(t) = \sum_l b_l(i+1) * a_{kl} * e_l(x_{t+1}) \tag{8.13}$$

比较前向和后向递归可以得出一些有趣的见解。前向算法使用 $t-1$ 处的结果来计算 t 的结果，而后向算法则使用 $t+1$ 处的结果，这自然导致了它们各自的名称。另一个显著差异在于发射概率；前向算法的发射发生在当前状态，因此可以从求和中排除，而后向算法的发射发生在时间 $t+1$ 处，因此必须包含在求和内。

鉴于它们的相似性，后向算法同样采用KxN动态规划表来实现也就不足为奇了。如图8.3所示，该算法首先将表格最右列初始化为单位值。从右向左逐列计算时，每一列的值依据上述递归关系，通过对其右侧列中值的加权求和得出。完成最左列的计算后，所有后向概率即已得出，算法随之终止。由于表中有KN个条目，且每个条目需考察总计K个其他条目，这导致时间复杂度为$O(K^2N)$，空间复杂度为$O(KN)$，其界限与前向算法完全相同。

正如通过前向算法DP表的最右列求和来计算P(X)一样，P(X)也可以通过后向算法DP表的最左列求和来计算。因此，对于这个特定计算而言，这些方法几乎是可以互换的。

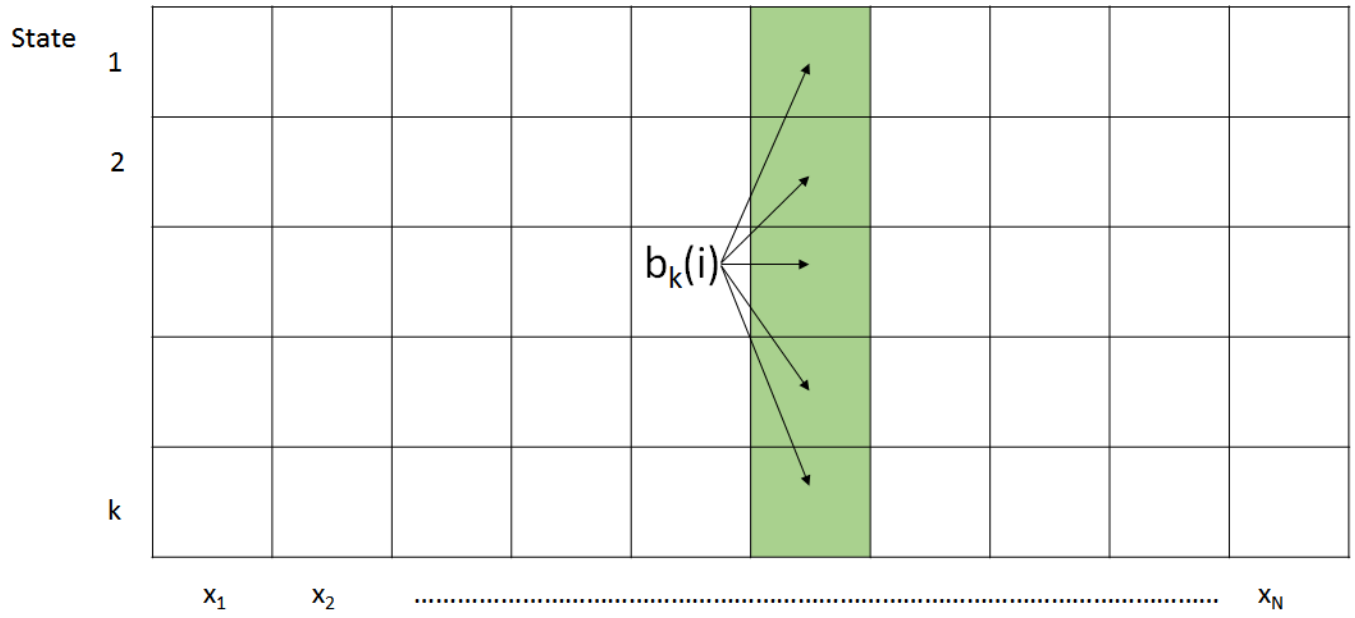

- Input: $x = x_1 \ldots\ldots x_N$
- Initialization: $b_k(N) = a_{k0}$, for all k
- Iteration: $b_k(i) = \sum_l e_l(x_{i+1})\, a_{kl}\, b_l(i+1)$
- Termination: $P(x) = \sum_l a_{0l}\, e_l(x_1)\, b_l(1)$

图8.3：反向算法

Did You Know?

请注意，即使执行后向算法时，使用的也是前向转移概率，即如果向后移动涉及从状态 B → A 的转移，则使用从状态 A→ B 的转移概率。这是因为从状态 B 向后移动到状态 A 意味着在正常的正向顺序中，状态 B 跟在状态 A 之后，因此需要相同的转移概率。

8.2.3 The Big Picture

为什么后验解码需要进行前向和后向计算，而我们之前讨论的算法只需要一个方向？区别在于，后验解码旨在为**individual positions**的底层状态生成概率，而不是整个位置序列。在寻找给定位置最可能的底层状态时，我们需要考虑该位置所在的整个序列，包括其前后，这符合贝叶斯方法——在动态规划算法中做到这一点，即我们递归计算并以最大化函数结束，我们必须从两侧接近我们感兴趣的位置。

鉴于我们可以在 $\theta(K\ N)$ 时间和 $\theta(KN)$ 空间内计算所有 $t = 1 \ldots n$ 的 $f_k(t)$ 和 $b_k(t)$ [2]，我们可以使用后验解码来确定 $t = 1 \ldots n$ 的最可能状态 π_t^*。相关表达式为

由以下给出

$$\pi_t^* = argmax_k P(\pi_i = k|x) = \frac{f_k(i) * b_k(i)}{P(x)} \tag{8.14}$$

有两种解码方法（维特比和后验），哪种更合适？当尝试对每个隐藏状态进行分类时，后验解码方法更具信息性，因为它在确定最可能状态时考虑了所有可能的路径。相比之下，维特比方法只考虑一条路径，这可能最终只代表总概率的一小部分。然而，同时，后验解码可能会给出无效的状态序列！通过独立选择每个位置的最大概率状态，我们没有考虑这些状态之间转移的可能性。例如，在时间点t和$t+1$识别的状态之间可能具有零转移概率。因此，选择解码方法高度依赖于所关注的应用。

FAQ

Q: 当维特比算法和后验解码在路径上出现分歧时，这说明了什么？

A: 在某种意义上，这只是提醒我们，模型给出的是它所选择的结果。当我们寻求每个独立位置的最大概率状态，并忽视这些最大概率状态之间的转移时，我们得到的结果可能与寻找最可能的整体路径时不同。生物学是复杂的；重要的是要考虑哪种度量标准与当前生物学情境最为相关。在基因组背景下，分歧可能是由于某些“奇特”的生物学现象，例如可变剪接。在某些情况下，维特比算法会接近后验解码，而在其他情况下，它们可能会产生分歧。

8.3 Encoding Memory in a HMM: Detection of CpG islands

CpG岛被定义为基因组内同一链上富含C和G核苷酸对的区域。通常，当这种二核苷酸存在于基因组中时，它会被甲基化；而当胞嘧啶发生脱氨作用（以一定碱基频率发生）时，它会变成胸腺嘧啶——另一种天然核苷酸，因此细胞不易将其识别为突变，从而导致C突变为T。CpG岛突变频率的增加在进化过程中耗尽了CpG岛，使其相对稀少。由于甲基化可发生在任一条链上，CpG通常突变为TpG或CpA。然而，当位于活跃启动子内时，甲基化受到抑制，CpG二核苷酸得以保留。同样，位于对细胞功能重要区域的CpG由于进化压力而保守。因此，检测CpG岛可以突出显示基因组中的启动子区域、其他转录活跃区域或纯化选择位点。

Did You Know?

CpG代表[C]胞嘧啶 - [p]磷酸骨架 - [G]鸟嘌呤。其中的'p'意味着我们指的是双螺旋中的同一条链，而不是跨越螺旋的G-C碱基对。

鉴于其生物学意义，CpG岛成为建模的首选对象。起初，人们可能试图通过扫描基因组中GC含量丰富的固定区间来识别这些岛屿。然而，这种方法的效果受到合适窗口大小选择的制约；窗口过小可能无法涵盖某个特定CpG岛的全部，而窗口过大则会遗漏许多较小但真实的CpG岛。以每个密码子为单位检查基因组也会带来困难，因为CpG对不一定编码氨基酸，因此可能不在单个密码子内。相反，隐马尔可夫模型（HMMs）更适合模拟这种情况，因为正如我们在无监督学习部分即将看到的，HMMs能够调整其底层参数以最大化其似然度。

然而，并非所有HMM都适合这个特定任务。仅考虑C和G单核苷酸频率的HMM模型无法捕捉CpG岛的本质。考虑一个具有以下两个隐藏状态的此类HMM：

- 表示CpG岛的’+’状态
- '-' 状态：表示非岛屿

这两个状态随后各自以一定的概率发出A、C、G和T碱基。尽管在这个模型中，可以通过增加C和G各自的发射概率来使CpG岛富含C和G，但该模型无法捕捉到C和G主要成对出现的事实。

由于支配HMM的马尔可夫性质，每个时间步可用的信息必须包含在当前状态中。因此，为了在马尔可夫链中编码记忆，我们需要扩展状态空间。为此，可以将单独的'+'和'-'状态替换为4个'+'状态和4个'-'状态：A+、C+、G+、T+、A-、C-、G-、T-（图8.4）。具体来说，有两种建模方法，而这种选择将导致不同的发射概率：

- 例如，一个模型表明状态A+意味着我们当前处于CpG岛，且*previous*字符是A。这里的发射概率将携带大部分信息，而转移则相当退化。

- 另一个模型表明，状态A+暗示我们当前位于CpG岛，且*current*字符为A。此处的发射概率对于A将是1，对于其他所有字母则为0，而转移概率将承载模型中大部分信息，发射则相对退化。从现在起，我们将采用这一模型。

Did You Know?
转移的数量是状态数量的平方。这粗略地说明了增加HMM的“记忆”（以及随之增加的状态）是如何扩展的。

该系统的记忆源于每个状态只能发出一个字符，因此“记住”了它所发出的字符。此外，CpG岛的二核苷酸特性被纳入转移矩阵中。特别地，从C_+到G_+状态的转移频率显著高于从C到G状态的转移频率，表明这些配对在岛内更频繁地出现。– –

FAQ

Q: 由于每个状态只产生一个字符，我们能否说这就简化为一个马尔可夫链，而非隐马尔可夫模型？

A: 不。尽管发射符号指示了隐藏状态的字母，但它们并不指示该状态是否为CpG岛：A状态和A+状态都只发射可观测的A。

FAQ

Q: 在训练HMM模型时，我们如何结合实际系统知识，例如在CpG岛检测案例中某些发射概率为0的情况?

A: 我们可以通过设置一些参数并让其他参数变化来强制我们的知识应用于模型，或者我们可以让HMM在模型上自由运行，让它发现这些关系。事实上，甚至有一些方法通过强制一部分参数为0来简化模型，但允许HMM选择哪些子集。

给定上述框架，我们可以使用后验解码来分析基因组中的每个碱基，并确定它是否最可能是CpG岛的组成部分。但是，在构建了扩展的HMM模型之后，我们如何验证它确实比单核苷酸模型更好呢？我们之前已经证明，前向或后向算法可以用来计算给定

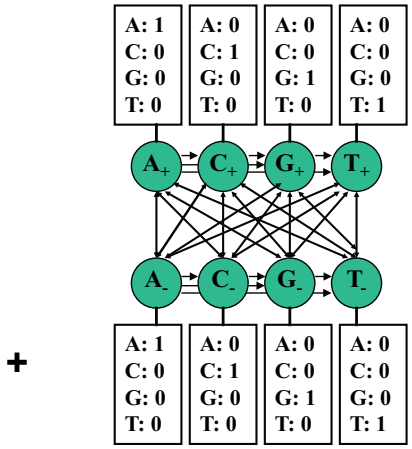

图8.4：CpG岛的HMM模型

模型。如果给定第二个模型时我们数据集的似然比第一个模型更高，那么它很可能更有效地捕捉了底层行为。

然而，模型复杂化存在一个风险，即过拟合。增加HMM的参数数量会使HMM更可能过拟合数据，并且在捕捉潜在行为方面准确性降低。机器学习中对此的常见解决方案是使用正则化，这本质上意味着使用更少的参数。在这种情况下，可以通过将所有+/-转移概率约束为相同的值，以及将所有-/+转移概率约束为相同的值来减少需要学习的参数数量，因为我们感兴趣的是建模从+和-状态之间的来回转移，而转移发生的实际碱基对我们的模型并不那么重要。因此，对于这个受限模型，我们需要学习的参数更少，这导致模型更简单，并有助于避免过拟合。

FAQ

Q: 还有其他编码记忆以进行CpG岛检测的方法吗?

A: 其他可能尝试的想法包括:

- 生成二核苷酸并找出处理重叠的方法。 - 添加一个从C到G的特殊状态。

8.4 Learning

我们已经看到了如何以两种不同的方式对HMM生成的序列进行评分和解码。然而，这些方法都假设我们已经知道了发射概率和转移概率。虽然我们总是可以自由地猜测这些概率，但有时我们可能希望使用更加数据驱动、经验性的方法来推导这些参数。幸运的是，HMM框架允许在给定一组训练数据和模型的固定架构时学习这些概率。

当训练数据被标注时，概率估计是一种监督学习的形式。一个这样的例子是，如果我们获得了一段包含一百万个核苷酸的DNA序列，其中CpG岛都经过了实验标注，并被要求使用这些数据来估计我们的模型参数。

相反，当训练数据未标记时，估计问题属于无监督学习的一种形式。继续以CpG岛为例，如果提供的DNA序列完全不含岛注释，我们需要同时估计模型参数并识别

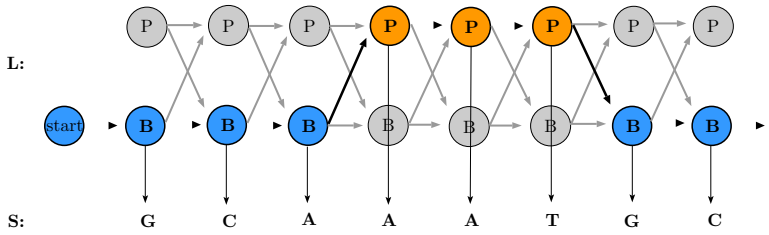

图8.5：CpG岛的有监督学习

岛屿。

8.4.1 Supervised Learning

当给定标注数据时，估计模型参数的想法是直接的。假设给定一个标注序列 $x_1, \ldots, x_N$ 以及真实的隐藏状态序列 $\pi_1, \ldots, \pi_N$。直观上，人们可能期望最大化数据似然的概率就是数据中实际观察到的概率。事实确实如此，并且可以通过定义 A_{kl} 为隐藏状态 k 转移到 l 的次数，以及 $E_k(b)$ 为 b 从隐藏状态 k 发射的次数来形式化。最大化 $P(x|\theta)$ 的参数 θ 只需通过如下计数获得：

$$a_{kl} = \frac{A_{kl}}{\sum_i A_{ki}} \tag{8.15a}$$

$$e_k(b) = \frac{E_k(b)}{\sum_c E_k(c)} \tag{8.15b}$$

图8.5展示了一个训练集示例。在这个例子中，从B转移到P的概率显然是$\frac{1}{5+1} = \frac{1}{6}$（有3次B到B的转移和1次B到P的转移），而从B状态发射G的概率是$\frac{2}{2+2+1} = \frac{2}{5}$（从B状态发射了2个G，2个C和1个A）

然而，请注意，在上面的例子中，从状态B发射字符T的概率为0，因为在训练集中未遇到此类发射。零概率，无论是转移还是发射，都特别成问题，因为它会导致无限的对数惩罚。但实际上，零概率可能仅仅是由于过拟合或样本量小而产生的。为了解决这个问题并保持我们模型的灵活性，我们可以收集更多数据来进行训练，减少零概率因样本量小而产生的可能性。另一种可能性是使用“伪计数”而不是绝对计数：人为地向我们的训练数据添加一些我们认为更准确地代表实际参数并有助于抵消样本量误差的计数。

- $A^*_{kl} = A_{kl} + r_{kl}$
- $E_k(b)^* = E_k(b) + r_k(b)$

较大的伪计数参数对应于对参数的强烈先验信念，这一点体现在这些源自先验的伪计数相对而言压倒了观测数据，即你的训练数据。同样，当我们的先验相对较弱，且我们旨在不压倒经验数据，而仅仅是避免过于严苛的概率为0时，通常会使用较小的伪计数参数（$r << 1$）。

8.4.2 Unsupervised Learning

无监督学习涉及基于未标记数据估计参数。这似乎是不可能的——我们如何能利用我们一无所知的数据来“学习”？——但一种迭代方法

在這些情況下，這通常能產生令人驚訝的良好結果，是典型的選擇。這可以粗略地視為一種演化算法：從某些初始參數選擇開始，算法評估這些參數對數據的解釋或關聯程度，利用該評估中的某些步驟來改進參數，然後評估新的參數，在每一步中對參數產生增量改進，就像特定生物在其環境中的適應度或缺乏適應度，隨著有利等位基因被優先傳遞，在演化時間中產生增量增加一樣。

假设我们对每个发射概率和转移概率应该是什么有一些先验信念。给定这些参数，我们可以使用解码方法来推断所提供数据序列背后的隐藏状态。使用这个特定的解码解析，我们可以然后以类似于监督学习所用的过程重新估计转移和发射计数及概率。如果我们重复这个过程，直到数据似然的改进保持相对稳定，数据序列最终应该将参数驱动到其适当的值。

FAQ

Q: 无监督学习为何有效？还是说这是魔法?

A: 无监督学习之所以有效，是因为我们有序列（输入数据），它指导着迭代的每一步；从标记序列到一组参数，后者由输入及其注释引导，而要注释输入数据，则需参数和序列指导整个过程。

特别是对于HMMs，两种主要的无监督学习方法是有用的。

Expectation Maximization using Viterbi training

第一种方法，**Viterbi training**，相对简单但不够严谨。在选取一些初步的最佳猜测模型参数后，其过程如下：

E step: 执行维特比解码以找出 $\pi^\star$ 根据最新参数和观测序列，利用在 $\pi^\star$ 状态中观察到的转移和发射的伪计数来计算 A^*_{kl}、$E_k(b)^*$（期望步骤）

M step计算新参数 a_{kl}、$e_k(b)$，使用监督学习中的简单计数形式（最大化步骤）

Iteration: 重复E步和M步，直到似然 $P(x|\theta)$ 收敛

虽然维特比训练收敛迅速，但其参数估计结果通常逊于鲍姆-韦尔奇算法。这一结果源于维特比训练仅考虑最可能的隐藏路径，而非所有可能隐藏路径的集合。

Expectation Maximization: The Baum-Welch Algorithm

更严谨的无监督学习方法涉及将期望最大化应用于HMM。通常，EM按以下方式进行：

Init：将参数初始化为某个最佳猜测状态

E step根据最新参数和观测序列估计隐藏状态的期望概率（期望步骤）

M step：使用隐藏状态的概率分布选择新的最大似然参数（最大化步骤）

Iteration重复E步和M步，直到给定参数下数据的似然收敛

EM 的强大之处在于，$P(x|\theta)$ 在算法的每次迭代中保证会增加。因此，当这个概率收敛时，就达到了局部最大值。因此，如果我们利用各种初始化状态，我们很可能能够识别全局最大值，即最佳参数 θ。Baum-Welch 算法将 EM 推广到 HMM。特别地，它使用前向和后向算法来计算 $P(x|\theta)$，并估计 A_{kl} 和 $E_k(b)$。该算法过程如下：

Initialization 1. 将参数初始化为某些最佳猜测状态

Iteration 1. 运行前向算法 2. 运行后向算法 3. 计算新的对数似然 $P(x|\theta)$ 4. 计算 A_{kl} 和 $E_k(b)$ 5. 使用伪计数公式计算 a_{kl} 和 $e_k(b)$ 6. 重复直到 $P(x|\theta)$ 收敛

之前，我们讨论了如何使用前向或后向算法的最终结果来计算 $P(x|\theta)$。但是，我们如何估计 A_{kl} 和 $E_k(b)$ 呢？让我们考虑在给定当前参数集 θ 的情况下，从状态 k 到状态 l 的期望转移次数。我们可以将这个期望表示为

$$A_{kl} = \sum_t P(\pi_t = k, \pi_{t+1} = l|x, \theta) = \sum_t \frac{P(\pi_t = k, \pi_{t+1} = l, x|\theta)}{P(x|\theta)} \tag{8.16}$$

利用马尔可夫性质以及发射概率和转移概率的定义，可以得到以下推导：

$$A_{kl} = \sum_t \frac{P(x_1 \dots x_t, \pi_t = k, \pi_{t+1} = l, x_{t+1} \dots x_N|\theta)}{P(x|\theta)} \tag{8.17a}$$

$$= \sum_t \frac{P(x_1 \dots x_t, \pi_t = k) * P(\pi_{t+1} = l, x_{t+1} \dots x_N|\pi_t, \theta)}{P(x|\theta)} \tag{8.17b}$$

$$= \sum_t \frac{f_k(t) * P(\pi_{t+1} = l|\pi_t = k) * P(x_{t+1}|\pi_{t+1} = l) * P(x_{t+2} \dots x_N|\pi_{t+1} = l, \theta)}{P(x|\theta)} \tag{8.17c}$$

$$\Rightarrow A_{kl} = \sum_t \frac{f_k(t) * a_{kl} * e_l(x_{t+1}) * b_l(t+1)}{P(x|\theta)} \tag{8.17d}$$

A 类似的推导得出 E 的以下表达式 $_k(b)$：

$$E_k(b) = \sum_{i|x_i=b} \frac{f_k(t) * b_k(t)}{P(x|\theta)} \tag{8.18}$$

因此，通过运行前向和后向算法，我们掌握了计算 $P(x|\theta)$ 所需的所有信息，并能在每次迭代中更新发射概率和转移概率。由于一旦计算出 $P(x|\theta)$、$f_k(t)$ 和 $b_k(t)$，这些更新操作就是常数时间复杂度，所以这一无监督学习版本的总时间复杂度为 $\theta(K^2NS)$，其中 S 表示总迭代次数。

FAQ

Q: 在使用Baum-Welch算法学习时，你如何编码你的先验信念?

A: 这些先验信念被编码在前向和后向算法的初始化中

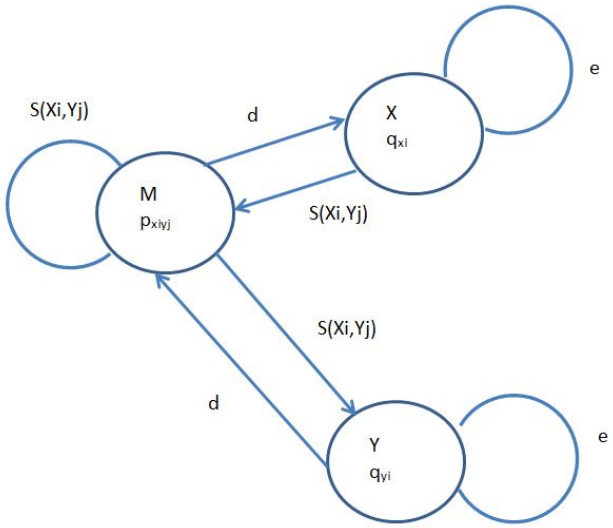

图8.6：具有仿射间隙惩罚的比对HMM模型

8.5 Using HMMs to align sequences with affine gap penalties

我们可以使用HMM来对具有仿射间隙罚分的序列进行比对。回想一下，仿射间隙罚分对打开/起始间隙的惩罚比对扩展间隙的惩罚更重，因此长度为g的间隙的罚分为r(g) = -d -(g-1)*e，其中d是打开间隙的罚分，e是扩展已打开间隙的罚分。

我们将研究使用仿射空位罚分对两个序列进行比对。给定两个序列X和Y，评分矩阵S（S(xi,yj) = 将xi与yj匹配的得分），空位开放罚分d和空位延伸罚分e。我们可以通过使用以下状态、转移概率和发射概率，将此问题映射为一个HMM问题。

状态:

涉及三种状态：M（将xi与yj匹配）、X（将xi与间隙对齐）、Y（将yj与间隙对齐）。此外，伴随每次转换，还会有i,j索引的更新。当处于状态M时，(i,j) = (i,j) + (1,1)。在状态X时，(i,j) = (i,j) + (1,0)。在状态Y时，(i,j) = (i,j) + (0,1)。

转移概率:

如图6所示，需要考虑7个转移概率。

P(下一状态 = M | 当前 = M) = S(xi,yj) P(下一状态 = X | 当前 = M) = d P(下一状态 = Y | 当前 = M) = d P(下一状态 = X | 当前 = X) = e P(下一状态 = M | 当前 = X) = S(xi,yj) P(下一状态 = Y | 当前 = Y) = e P(下一状态 = M | 当前 = Y) = S(xi,yj)

我们也可以将转移概率保存在转移矩阵A = [aij]中，其中aij = P(下一个状态 = j | 电流 = i) 与 $\sum_j Aij = 1$

发射概率：发射概率为：从状态 M：p_{xiyi} = p(x_i 比对到 y_j) 从状态 X：q_{xi} = p(x_i 比对到空位) 从状态 Y：q_{yi}= p(y_j比对到空位) 示例：X = ’ VLSPADK’

Y = ’ HLAESK’ 模型生成的对齐结果是
: MMXXMYM 对应于: X = ’ VLSPAD
K’ Y = ’ HL AESK’

Did You Know?
为了分类目的，后验解码“路径”比维特比路径更具信息性，因为它更精细地衡量了哪些隐藏状态生成了x。然而，它可能给出无效的状态序列，例如当并非所有j $->$ k转移都可能时，它可能具有状态(i) = j 和状态(i+1) =k。

8.6 Current Research Directions

- HMM已在计算生物学的各个领域中得到广泛应用。最早的此类应用之一是Chris Burge和Samuel Karlin编写的名为GENSCAN的基因发现算法[1]。由于HMM的几何长度分布不能很好地模拟外显子区域，Burge等人使用了HMM的一种变体，称为隐半马尔可夫模型（HSMM）。这些类型的模型的不同之处在于，每当达到一个隐藏状态时，该状态的持续时间长度（d_i）是从一个分布中选择的，然后该状态恰好发出d_i个字符。从这个隐藏状态到下一个状态的转移与HMM过程类似，只不过对于所有k，a_{kk} =为0，从而防止了自转移。许多先前为HMM开发的相同算法都可以修改用于HSMM。尽管这里不会讨论细节，但前向和后向算法可以修改为在$O(K^2N^3)$时间内运行，其中N是观察到的字符数。这个时间复杂度假设状态持续时间的长度没有上限，但施加这样的上限会将复杂度降低到$O(K^2ND^2)$，其中D是状态的最大可能持续时间。

  Burge 模型的基本状态图如图 8.7 所示。图中仅列出了 DNA 正链上的状态，但实际上，反链也包含了这些状态的镜像，总共形成了 27 个隐藏状态。如图所示，该模型融合了基因的许多主要功能单元，包括外显子、内含子、启动子、UTR 和 poly-A 尾。此外，还使用了三种不同的内含子和外显子状态，以确保基因中所有外显子的总长度是三的倍数。与 CpG 岛示例类似，这种扩展的状态空间使得模型内部能够编码记忆。

- 最近的一项努力是使基于 HMM 的同源搜索方法，称为 HMMER，在计算效率方面成为 BLAST 的可行替代方案。与大多数其他同源搜索算法不同，由 Sean Eddy 编写的 HMMER 使用前向算法在对齐不确定性上的平均值，而不是仅报告最大似然对齐（如 Viterbi 算法）；这种方法通常更适合检测更远的同源性，因为随着分歧时间的增加，可能会有更多可行的序列对齐方式，每一种单独都不足以与噪声区分，但合在一起则提供了同源性的证据。一个特别令人兴奋的近期发展是 HMMER 现在可作为网络服务器使用；它可以在 http://www.ebi.ac.uk/Tools/hmmer/ 找到。

- 一个也可能值得探讨的有趣主题涉及维特比与后验解码路径的一致性；不仅限于CpG岛检测，甚至还包括染色质状态检测。人们可以通过抽样来观察多条路径，提出如下问题:

  – 最大后验路径与维特比路径是什么？它们在哪里不同?
  – 能否找到完整的但最大程度不相交（相对于维特比）的路径?

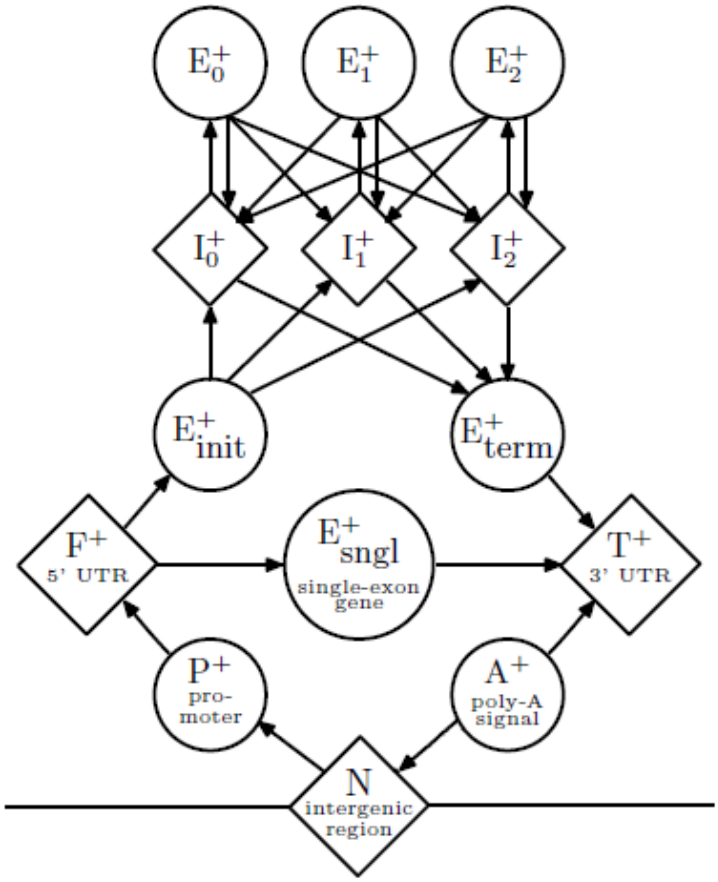

图8.7：GENSCAN中使用的状态空间图

8.7 Further Reading

8.8 Tools and Techniques

8.9 What Have We Learned?

利用隐马尔可夫模型提供的基本计算框架，我们学会了如何推断出一系列观测字符背后最可能的隐藏状态集。特别是，前向和后向算法的结合，使得我们能够在{v*}时间内实现一种形式的推断，即后验解码。我们还了解到，当提供未标记或标记的数据集时，无论是无监督学习还是有监督学习，都可以用来确定HMM的最佳参数。这些解码和参数估计方法的结合，使得HMM能够应用于计算生物学中的众多问题，其中CpG岛和基因识别只是其中的一小部分。鉴于HMM所提供的灵活性和分析能力，这些方法在可预见的未来将在计算生物学中发挥重要作用。

Bibliography

[1] Christopher B Burge 和 Samuel Karlin。在基因组DNA中寻找基因。*Current Opinion in Structural Biology*，8(3)：346 – 354，1998。

CHAPTER
NINE

基因识别：基因结构、半马尔可夫模型、条件随机场

蒂姆·赫尔比格 (2011
) 珍妮·程 (2010)

Figures

9.1 基因间DNA . . . . . 164 9.2 内含子/外显子剪接 . . . . . 164 9.3 外显子和开放阅读框的界定 . . . . . 165 9.4 利用GT供体假设的隐马尔可夫模型 . . . . . 165 9.5 基因识别的多线索证据 . . . . . 165 9.6 具有复合发射的HMMs . . . . . 166 9.7 考虑RNA翻译方向的状态图 . . . . . 166 9.8 条件随机场：基于输入序列条件的判别方法 . . . . . 167 9.9 特征函数示例 . . . . . 167 9.10 发射序列的条件概率得分 . . . . . 167 9.11 HMMs与CRFs的比较 168

9.1 Introduction

在对基因组进行测序后，一个常见的下一步是尝试通过仔细分析该序列来推断生物体或细胞所编码的功能潜力。这主要采取识别序列内蛋白质编码基因的形式，因为这些基因被认为是生命系统内的主要功能单位；这并不是说它们是基因组中唯一的功能单位，因为诸如调控基序和非编码RNA等也是至关重要的元素。

蛋白质编码区域的注释工作极为繁琐，难以手工完成，因此这一过程通过称为计算基因识别的流程实现自动化。该过程所依赖的算法常基于隐马尔可夫模型（HMMs），这一概念在前几章中已讨论过，用于解决诸如判断赌场掷的是公平骰子还是灌铅骰子这类简单问题。然而，基因组是极其复杂的数据集合，充斥着长重复序列、重叠基因（即一个或多个核苷酸同时属于两个或多个不同基因的部分）以及假基因（看似基因但非转录区域）等诸多混淆因素。因此，为了提高注释准确性，往往需要将实验和进化数据纳入HMMs中，这可能导致可扩展性的丧失或对独立性错误假设的依赖。为应对HMMs存在的问题，已采用其他算法，包括基于条件随机场（CRFs）的方法，这些方法依赖于根据已知数据构建所研究基因组序列隐藏状态的分布。CRFs的使用并未淘汰HMMs，两者在实践中均有应用，成效各异。[1]

[1] R. Guigo (1997). “Computational gene identification: an open problem.” Computers Chem. Vol. 21.

9.2 Overview of Chapter Contents

本章将首先讨论真核基因的复杂性。接着，将阐述如何利用HMM作为模型，将真核基因组解析为编码蛋白质的基因区域和非编码区域；这包括对HMM方法优缺点的提及。最后，将介绍使用CRFs标注蛋白质编码区域作为替代方案。

9.3 Eukaryotic Genes: An Introduction

在真核生物基因组中，仅有很小一部分核苷酸内容实际由蛋白质编码基因组成（在人类中，蛋白质编码区约占整个基因组的1%-1.5%）。其余的DNA被归类为基因间区域（见图9.1），并包含调控基序、转座子、整合子以及非蛋白质编码基因等内容。[2]

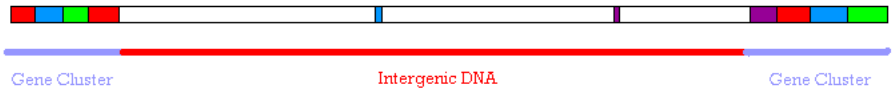

图9.1：基因间DNA

此外，在转录为mRNA的少量DNA中，并非全部都被翻译成蛋白质。一些被称为内含子的区域会从前体mRNA中被移除或“剪接”掉。这种经过处理的mRNA，仅包含“外显子”以及前几章讨论过的一些其他附加修饰，会被翻译成蛋白质。（见图9.2）因此，计算基因识别的目标不仅是从整个真核生物基因组中挑选出少数编码蛋白质的区域，还要将这些蛋白质编码区域解析为外显子或内含子的身份，以便能够知道所合成蛋白质的序列。

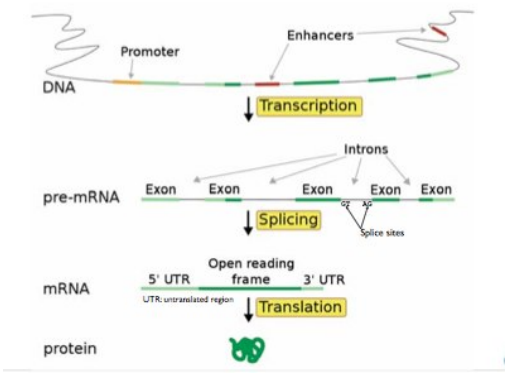

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图9.2：内含子/外显子剪接

9.4 Assumptions for Computational Gene Identification

计算基因识别的一般假设是，外显子由位于外显子起始处的序列AG和位于外显子末端的序列GT来界定。对于蛋白质编码基因，起始密码子（ATG）和终止密码子（TAA、TGA、TAG）界定了开放阅读框。（这些概念大多可见于图9.3）这些假设将被纳入下文所述更复杂的HMM中。

[2] “Intergenic region.” http://en.wikipedia.org/wiki/Intergenic_region

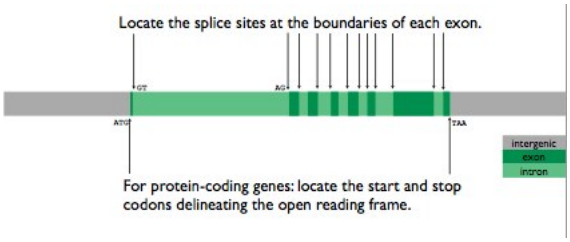

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图9.3：外显子和开放阅读框的描绘

9.5 Hidden Markov Models

一个玩具级隐马尔可夫模型是一种生成式方法，用于对此行为进行建模。HMM的每次发射是一个DNA碱基/字母。该模型的隐状态为基因间区、外显子、内含子。对该模型的改进将涉及包括隐状态DonorG和DonorT。DonorG和DonorT状态利用了外显子在序列末端、内含子开始之前由GT界定的这一信息。（关于将DonorG和DonorT纳入模型，请参见图9.4）

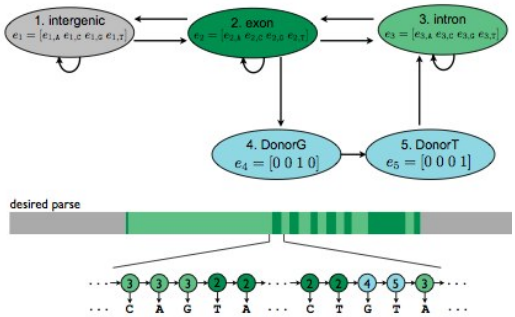

© source unknown. All rights reserved. This content is excluded from our 创意 Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/。

图 图9.4：利用GT供体假设的隐马尔可夫模型 消耗

每个状态中的e表示发射概率，箭头则表示转移概率。除了初始假设外，诸如进化保守性和实验mRNA数据等额外证据有助于构建更佳的HMM来模拟这种行为。（见图9.5）

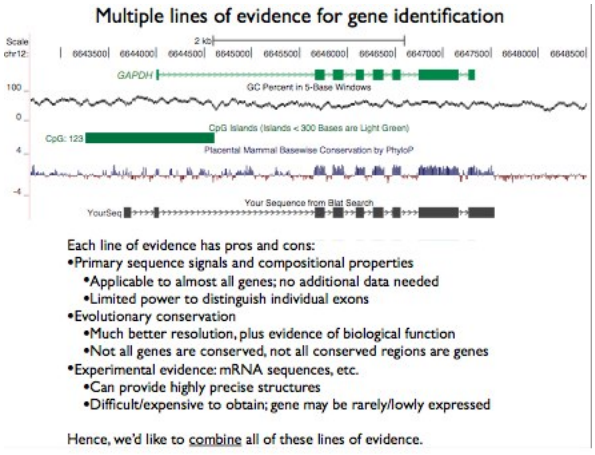

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图9.5：基因识别的多重证据线

综合上述所有证据线索，我们可以构建一个具有复合发射的HMM，其中每个发射值都是收集值的“元组”。（参见图9.6）

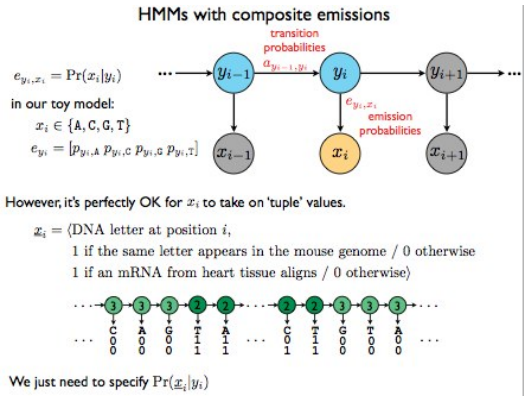

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图9.6：具有复合发射的HMMs

这种复合模型的一些假设是每个新的排放“特征”都独立于其他特征。然而，这带来了一个问题：随着每个新特征的加入，元组长度增加，HMM的状态数量呈指数增长，导致组合爆炸，从而意味着扩展性差。（可能导致扩展性差的更复杂HMM示例可见图9.7）

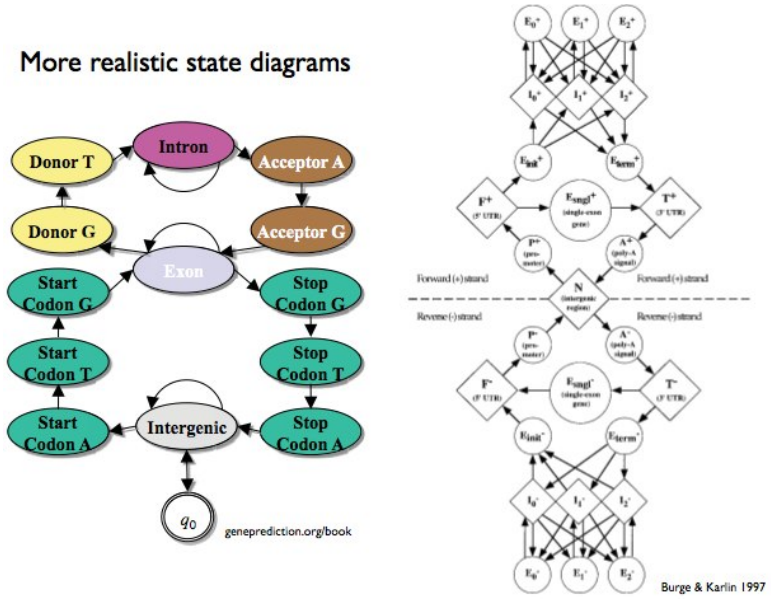

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图 9.7：考虑RNA转录方向的状态图 翻译

9.6 Conditional Random Fields

条件随机场，CRFs，是HMMs的一种替代方法。作为一种判别式方法，这类模型并不像扩展性差的HMM那样考虑所有事物的联合分布。CRF中的隐藏状态是以输入序列为条件的。（见图9.8）[3]

[3]Conditional Random Field. Wikipedia. http://en.wikipedia.org/wiki/Conditional_random_field

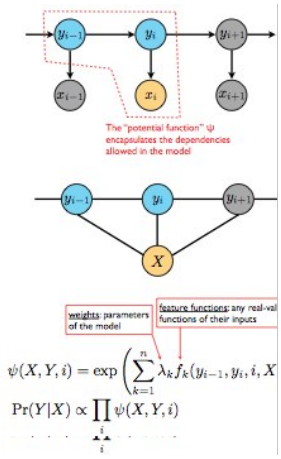

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 htt
p://ocw.mit.edu/help/faq-fair-use/。

图9.8：条件随机场：一种基于输入序列的条件判别方法

特征函数类似于一个分数，它根据输入返回一个实数值，反映特定位置上某个标签的证据。（见图9.9）发射序列的条件概率是其分数除以隐藏状态的总分数。（见图9.10）

$$f_1(y_{i-1}, y_i, i, X) = \begin{cases} 1 & \text{if } y_i = \texttt{exon} \text{ and position } i \text{ is conserved in mouse} \\ 0 & \text{otherwise} \end{cases}$$

$$f_2(y_{i-1}, y_i, i, X) = \begin{cases} 1 & \text{if } y_i = \texttt{exon} \text{ and position } i \text{ is conserved in rat} \\ 0 & \text{otherwise} \end{cases}$$

$$f_3(y_{i-1}, y_i, i, X) = \#\text{ of mRNA sequences aligning to position } i \text{ (if } y_i = \texttt{exon}\text{; 0 otherwise)}$$

图9.9：特征函数示例

$$\Pr(Y|X) = \frac{1}{Z(X)} \prod_i \psi(X, Y, i) \quad \text{where} \quad Z(X) = \sum_{Y'} \prod_i \psi(X, Y', i)$$

图9.10：发射序列的条件概率得分

每个特征函数都有权重，因此在训练过程中，可以相应地设置权重。

特征函数可以纳入大量证据，而不需要朴素贝叶斯独立性假设，这使得它们既可扩展又准确。然而，与HMM相比，CRF的训练要困难得多。

9.7 Other Methods

除HMMs和CRFs之外，还有其他方法用于计算基因识别。半马尔可夫模型生成可变序列长度的发射，意味着隐藏状态之间的转移并非完全无记忆。

最大-最小模型是支持向量机的变体。这些方法尚未应用于哺乳动物基因组。[4]

[4]For better understanding of SVM: http://dspace.mit.edu/bitstream/handle/1721.1/39663/6-034Fall-2002/OcwWeb/Electrical-Engineering-and-Computer-Science/6-034Artificial-IntelligenceFall2002/Tools/detail/svmachine.htm

9.8 Conclusion

计算基因识别，由于它涉及寻找基因组中编码的功能元素，对于生物学领域的进步具有重要的实际意义和理论意义。

上述两种方法总结如下图9.11所示：

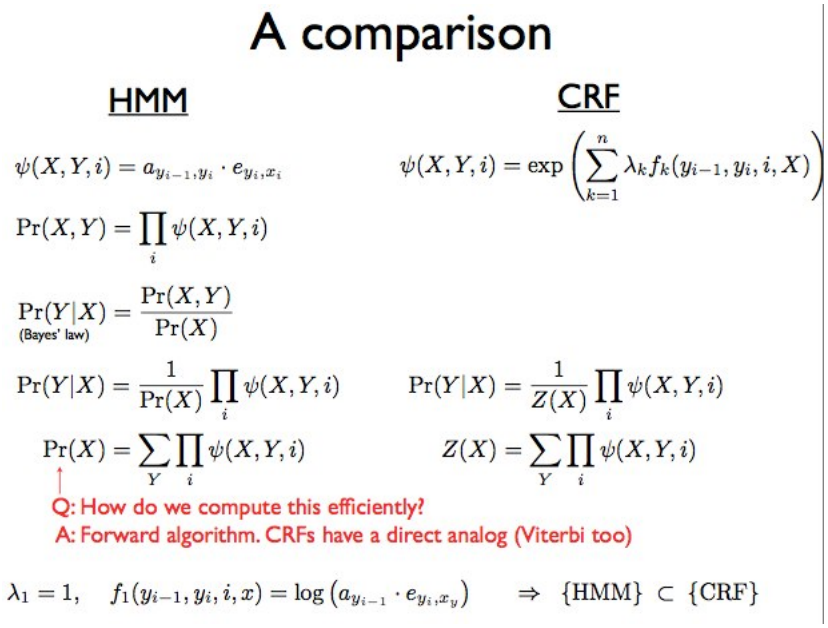

图9.11：HMMs与CRFs的比较

9.8.1 HMM

- 生成模型
- 随机生成可观测数据，通常带有隐藏状态
- 指定一个联合概率分布
- $P(x,y) = P(x|y)P(y)$
- 有时很难正确建模依赖关系
- 隐藏状态是每个DNA碱基/字母的标签
- 复合排放是所排放的DNA碱基/字母与额外证据的组合

9.8.2 CRF

- 判别模型
- 模型将未观测变量y对观测变量x的依赖关系进行建模
- $P(y|x)$
- 难以在没有监督的情况下训练
- 对于模型不需要联合分布的情况更为有效

在实践中，使用CONTRAST（一种CRF实现）得到的基因规格最高约为46.2%。这是因为在生物学中，标准模型有许多例外情况，如重叠基因、嵌套基因和选择性剪接。将所有例外情况纳入模型有时会导致预测效果变差；这是一个不小的权衡。然而，技术在进步，未来五年内，将有更多实验数据推动计算基因识别的发展，进而有助于更好地理解DNA的语法。

9.9 Current Research Directions

9.10 Further Reading

9.11 Tools and Techniques

9.12 What Have We Learned?

Bibliography

1.R. Guigo（1997）。“计算基因识别：一个开放问题。” 2.“基因间区。” http://zh.wikipedia.org/wiki/基因间区 3.条件随机场。维基百科。http://zh.wikipedia.org/wiki/条件随机场 4.http://dspace.mit.edu/bitstream/handle/1721.1/39663/6-034Fall-2002/OcwWeb/Electrical-Engineering- and-Computer-Science/6-034Artificial-IntelligenceFall2002/Tools/detail/svmachine.htm

CHAPTER

TEN

RNA FOLDING

Stefan Washietl 的客座讲座 由 Sam Sinaei 记录（2010年） 由 Archit Bhise 记录（2012年） 由 Eric Mazumdar 记录（2014年）

Figures

10.1 RNA结构复杂度层级的图形表示 . . . . . 175 10.2 教科书中RNA二级结构的典型表示。它清晰地展示了RNA中的二级子结构。 . . . . . 175 10.3 主链为圆、碱基配对为圆内弧线的图形绘制。注意该图是外平面的，即弧线不相交。 . . . . . 175 10.4 一种机器可读的点括号表示法，其中对于每个配对的核苷酸，你打开一个括号(并在到达其配对时关闭)，对于每个未配对元素，你有一个点。 . . . . . 176 10.5 一种矩阵表示，其中每个配对有一个点。 . . . . . 176 10.6 山形图，其中对于配对你在图中上升一步，若非配对则向右移动一步。 . . . . . 176 10.7 碱基配对匹配评分方案的示例。注意G-U在RNA中可以形成摆动配对。 . . . . . 176 10.8 Nussinov算法的递归公式，以及其工作原理的图形描述。 . . . . . 177 10.9 对角线初始化为0。然后，根据递推关系从下到上、从左到右填充表格。在此示例中，互补碱基配对评分为-1，非互补配对评分为0。整个序列的最优评分位于右上角。 . . . . . 178 10.10在递归过程中填充的回溯矩阵K_{ij}，当k与i配对时，对于子序列$[i, j]$，它保存最优二级结构。如果i在最优结构中未配对，则$K_{ij} = 0$。 . . . . . 178 10.11 RNA中相邻碱基对之间的堆积。碱基的平面芳香结构导致堆叠碱基之间的量子相互作用，并改变其物理稳定性。 . . . 178 10.12折叠RNA中的各种内部子结构。发夹由一个末端环连接到一个配对区域组成，内部环是配对区域内的未配对区域。凸起是内部环的一种特殊情况，具有单个错配。多环是由多个这些组件组成的环(在此示例中为两个发夹和一个配对区域，均连接到一个环)。 179

10.13F 描述了非配对情况，C 由以下三个条件之一描述：发夹、内部环或结构的组合，即多环。M^1 是只有一个组件的多环，而 M 可能有多个组件。| 图标是 *"or"* 的表示法。 . . . . . 179 10.14A) 单序列：终端符号是碱基或碱基对，发射概率是环和配对区域中的碱基频率 B) 系统发育 SCFG：终端符号是单列或配对列比对，发射概率使用 Felsenstein 算法从系统发育模型和树计算得出我们尝试更好地理解 RNA-RNA 相互作用。183 10.15我们可以更深入地研究动力学和折叠路径。 . . . . . 184 10.16我们可以研究假结。 . . . . . 184 10.17我们可以尝试更好地理解 RNA-RNA 相互作用。 185

10.1 Motivation and Purpose

RNA (**Ribonucleic acid**) 作为一种分子，被认为是生命的起源。尽管长期以来它仅被视为DNA编码与功能蛋白质之间的中介，但RNA已被证实具有多种功能，涵盖了整个基因组学领域。其多功能性的部分原因在于RNA可以呈现多种可能的构象。由于拥有比DNA更灵活的骨架，RNA展现出有趣且多样的结构，这些结构能揭示其众多用途。例如，RNA的某些结构有利于催化活性，而另一些则作为tRNA和mRNA，在将DNA的编码转换为蛋白质的过程中至关重要。本章旨在学习能够解释甚至预测RNA二级结构的方法，希望这些方法能揭示这一多功能分子的众多特性。

为了实现这一点，我们首先从生物学角度审视RNA，并解释已知的RNA生物学作用。然后，我们研究现有的预测RNA结构的不同方法。RNA折叠问题主要有两种方法：1）基于分子的热力学稳定性预测RNA结构，并寻找热力学最优解；2）概率模型，试图在概率最优解中找到RNA分子的状态。

最后，我们可以利用进化数据，通过这些方法提高预测的可信度。

10.2 Chemistry of RNA

RNA由5碳糖核糖组成，核糖与有机碱基（腺嘌呤、尿嘧啶、胞嘧啶或鸟嘌呤）相连。DNA与RNA之间存在两个生化差异：

1. 5位碳糖在5位没有羟基　　翻译

2. RNA中存在尿嘧啶，它是胸腺嘧啶的非甲基化形式，而不仅仅是胸腺嘧啶。

RNA中核糖的存在使其结构比DNA更灵活，使RNA分子能够折叠并在自身内部形成键，这使得单链RNA比单链DNA更为复杂。

10.3 Origin and Functions of RNA

人们最初认为RNA仅充当DNA密码与蛋白质之间的中间体，然而在80年代初，催化性RNA（核酶）的发现拓宽了人们对这种分子在生物体内实际功能的认识。Sidney Altman和Thomas Cech发现了第一个核酶——RNase P，它能够切除tRNA的头部。自我剪接内含子（I类内含子）也是最早发现的核酶之一。它们不需要任何蛋白质作为催化剂来进行剪接。单链或双链RNA在某些病毒中也充当信息储存和复制因子。

RNA World Hypothesis由Walter Gilbert于1986年提出，认为RNA是现代生命的前体。它基于这样一个事实：RNA同时具备信息存储和催化活性，这两者都是生命系统的基本特征。简而言之，RNA世界假说认为，由于RNA在细胞中可以具有催化作用，并且有证据表明RNA能够不依赖其他分子进行自我复制，因此RNA世界是当今以DNA和蛋白质为基础的世界的一个合理前体。尽管至今在体内未发现天然的自复制RNA，但通过人工选择已在实验室中创建了自复制的RNA分子。例如，一种自然连接酶核酶与体外选择模板结合域的嵌合构建体已被证明能够复制至少一圈RNA螺旋。因此，Gilbert提出RNA是生命的一个合理起源。该理论认为，通过进化，RNA已将其信息存储角色传递给了DNA，一种更稳定且更不易发生突变的分子。RNA随后承担了DNA与蛋白质之间的中间角色，而蛋白质接管了RNA在细胞中的部分催化角色。因此，科学家有时将RNA称为分子化石。尽管RNA已将大量信息存储功能让渡给DNA，并将其功能特性让渡给蛋白质，RNA仍在生物体中发挥着不可或缺的作用。例如，核糖体的催化部分，即核糖体复合物的主要功能部分，由RNA组成。RNA在细胞中还具有调控作用，基本上充当细胞感知和响应环境的媒介。

10.3.1 Riboswitches

调节RNA有不同的家族，其中最重要的家族之一是**riboswitches**。核糖开关参与不同层次的基因调控。在一些细菌中，重要的调控由简单的RNA家族完成。一个例子是李斯特菌中的热传感器，这是一种在低温下阻断核糖体的核糖开关（因为此时氢键更稳定）。RNA随后形成一种半双链构象，不与核糖体结合，从而关闭核糖体。在较高温度（37°C）下，双链打开，允许核糖体附着到核糖开关的特定区域，使翻译再次成为可能。另一个著名的核糖开关是腺嘌呤核糖开关（以及一般的嘌呤核糖开关），它们调控蛋白质合成。例如，ydhl mRNA末端有一个终止子茎，阻止其翻译，但当细胞中腺嘌呤浓度增加时，腺嘌呤与mRNA结合并改变其构象，使终止子茎消失。

10.3.2 microRNAs

还有其他种类的RNA，例如**microRNAs**，一种相对更现代的RNA变体。它们的发现揭示了一种新颖的非蛋白质基因调控层（例如EVF-2和HOTAIR miRNAs）。EVF-2之所以引人注目，是因为它由一个超保守的增强子转录而来，并通过形成发夹结构与转录链分离，随后（与蛋白质Dlx-2一起）返回至同一增强子并调节其活性。HOTAIR RNA诱导染色质状态的变化，并调控

组蛋白的甲基化，这反过来又使HOX-D基因簇沉默。

10.3.3 Other types of RNA

我们还可以查看 **noncoding RNAs** 的类型。

piRNAs 是动物中最大类的小非编码RNA分子。它们主要参与转座子的沉默，但可能具有许多功能。它们还参与表观遗传修饰和转录后基因沉默。

lncRNAs 是产生了长转录本，其在功能上作为RNA运作，并不翻译成蛋白质。许多研究表明lncRNAs参与表观遗传修饰，可能作为靶向机制或Polycomb蛋白的分子支架。lncRNAs很可能具有多种功能，许多在核内，许多在细胞质中。

10.4 RNA Structure

我们已经了解了RNA的不同功能，现在应该清楚RNA在生命系统中的根本作用。由于如果不了解RNA的结构，就无法理解它如何在细胞中实际执行所有这些活动，因此在这部分我们将探讨RNA的结构。

RNA结构可以在三个不同层次上进行研究 10 .1:

1. *Primary*结构：碱基（U、A、C、G）排列的顺序。2. *Seconary*结构：RNA不同部分之间[氢]键的二维分析。换句话说，RNA在何处变成双链，在何处形成发夹结构、环结构或其他类似形式。3. *Tertiary*结构：RNA的完整三维结构，即字符串如何弯曲，在何处扭曲等。

如前所述，RNA中核糖的存在使其能够折叠并自身形成双螺旋结构。一级结构通过RNA测序相当容易获得。我们主要感兴趣的是理解RNA的二级结构：环和氢键形成的位置以及它们如何赋予RNA功能特性。理想情况下，我们希望研究三级结构，因为这是RNA的最终状态，也是其真正功能的来源。然而，三级结构的计算非常困难，超出了本讲座的范围。

尽管研究二级结构可能有些棘手，但有一些简单的思路在预测其结构时相当有效。与蛋白质不同，在RNA中，分子的大部分稳定自由能来源于其二级结构（而非蛋白质中的三级结构）。RNA首先折叠成二级结构，然后形成三级结构，因此，仅通过了解某个RNA分子的二级结构，我们就能获得关于该分子的非常有趣的信息。

最后，二级结构的另一个重要特性是它在进化中通常高度保守，这有助于我们改进二级结构预测，也有助于发现ncRNA（非编码RNA）。对于RNA的二级结构，有广泛使用的表示方法:

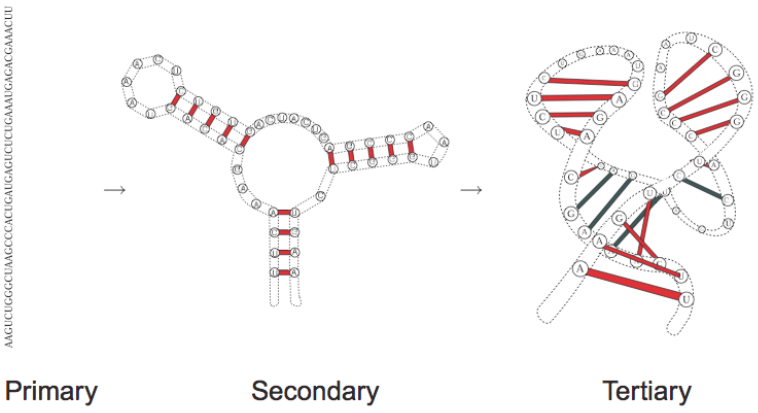

© Stefan Washietl。保留所有权利。此内容不在我们的知识共享许可协议范围内。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图10.1：RNA结构复杂性层次的图形表示

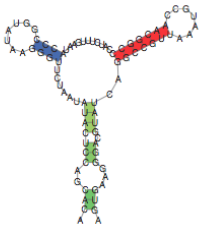

© Stefan Washietl。保留所有权利。此内容不在我们的知识共享许可协议范围内。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图10.2：教科书中RNA二级结构的典型表示。它清晰地展示了RNA中的二级子结构。

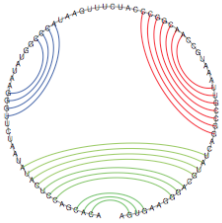

© Stefan Washietl。保留所有权利。此内容不在我们的知识共享许可协议范围内。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图10.3：图绘制中，主干为一个圆，碱基配对是圆内的弧。请注意，该图是外平面的，意味着弧不会交叉。

形式化地说：二级结构是一个在n个顶点上的顶点标记图，其邻接矩阵 $A = (a_{ij})$ 满足：

- $a_{i,i+}1 = 1 for 1 \leq i \leq n1$（连续主干）
- 对于每个 $i, 1 \leq i \leq N$，最多只有一个 $a_{ij} = 1$，其中 $j \gneqq i + / - 1$（一个碱基一次只与另一个形成配对）
- 如果 $a_{ij} = a_{kl} = 1 and i < k < j then i < l < j$（忽略伪结）

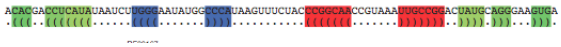

© Stefan Washietl. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图10.4：一种机器可读的点括号表示法，其中对于每个配对核苷酸，您打开一个括号“（”并在遇到其匹配项时关闭“）”，而对于每个未配对元素，则用一个点表示。

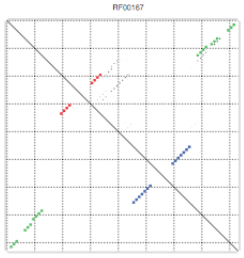

© Stefan Washietl。保留所有权利。此内容不在我们的知识共享许可协议范围内。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图10.5：矩阵表示，其中每对都有一个点。

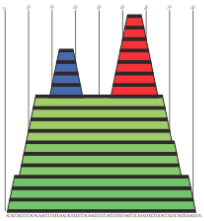

© Stefan Washietl。保留所有权利。此内容不在我们的知识共享许可协议范围内。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图10.6：山形图，其中对于成对情况，你在图中向上走一步，如果不是，则向右走一步。

10.5 RNA Folding Problem and Approaches

最后，我们进入到想要研究 RNA 结构的地步。这里的目标是，在给定 RNA 的一级结构（或其序列）的情况下，预测其二级结构。好消息是我们可以使用动态规划找到最优结构。现在，为了建立我们的动态规划框架，我们需要一个评分方案，而我们将利用每个碱基配对对分子物理稳定性的贡献来创建这个评分方案。换句话说，我们希望创建一个具有最小自由能的结构，而在我们的简单模型中，我们会为每个碱基对分配一个能量值。10.7

	A	C	G	U
A	+10	+10	+10	−2
C	+10	+10	−3	+10
G	+10	−3	+10	−1
U	−2	+10	−1	+10

图10.7：碱基配对匹配评分方案示例。注意，在RNA中G-U可以形成摆动配对。

最优结构将是具有最小自由能的结构，按照惯例，负能量是稳定性的，正能量是非稳定性的。利用这个框架，我们可以使用动态规划（DP）来计算最优结构，因为1）这种评分方案是可加的 2）我们禁止了伪结，这意味着我们可以将RNA分成两个独立的较小RNA，并为这些较小的RNA解决问题。

我们希望找到一个DP矩阵 E_{ij}，在其中我们计算子序列 i 的最小自由能，以

j对此的第一种方法是Nussinov算法。

10.5.1 Nussinov's algorithm

该问题的递推公式由Nussinov于1978年首次描述。

该算法背后的直觉如下：给定一个子序列 $[i, j]$，要么没有边连接到第 i 个碱基（意味着它未配对）or，要么存在某条边将第 i 个碱基连接到第 k 个碱基，其中 $i < k \leq j$ (表示第 i 个碱基与第 k 个碱基配对)。在第 i 个碱基未配对的情况下，子序列的能量 $E_{i,j}$ 简化为从 $i + 1$ 到 j、$E_{i+1,j}$ 的子序列能量。这是 Nussinov 递推关系的第一项。然而，如果第 i 个碱基与第 k 个碱基配对，那么 $E_{i,j}$ 简化为第 i, k 个配对的能量贡献 $\beta_{i,k}$，加上通过围绕 k、$E_{i+1,k\ \ 1}$ 和 $E_{k+1,j}$ 划分 $[i +] 1, j$ 所形成的子序列的能量。选择使 – 最小化的 k，该值产生 Nussinov 递推关系的第二项。因此，最优子序列能量是第 i 个碱基与最优第 k 个碱基配对时以及第 i 个碱基未配对时子序列能量的最小值。这产生了图 10.8 中描述的总体关系。

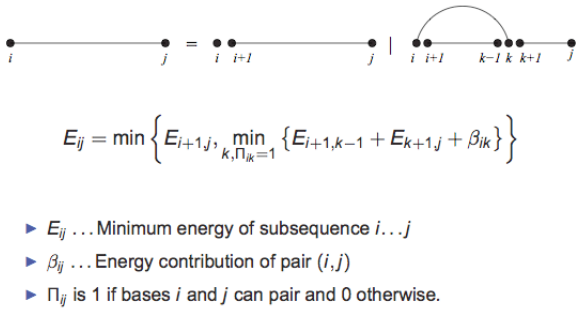

图10.8：Nussinov算法的递归公式，并附有工作原理的图形说明。

基于这个递推关系，我们可以看到DP矩阵将包含所有i, j的条目，其中$1 \leq i \leq n$且$i \leq j \leq n$且n是RNA序列的长度。换句话说，矩阵将是$n * n$，且仅包含右上三角区域内的条目。矩阵首先进行初始化，使得对角线上的所有值都等于零。接着，我们遍历$i = n - 1...1$以及$j = i + 1...n$ (从下到上，从左到右)，并依据递推关系填充每个条目。总得分即为$[1, n]$子序列的得分，对应矩阵的右上角。图10.9展示了这一过程。

当我们计算最小自由能时，我们通常对相应的折叠结构感兴趣。为了从动态规划算法中恢复最优折叠结构，使用了一个回溯矩阵来存储从每个条目到其父条目的指针。图10.10描述了回溯算法。

这个模型非常简单，存在一些局限性。朴素实现的Nussinov算法没有考虑到RNA折叠的一些限制因素。最重要的是，它没有考虑相邻碱基对之间的堆积相互作用，这是RNA折叠中的一个关键因素（甚至比氢键更为重要）。图10.11

因此，将生物物理因素纳入我们的预测是可取的。例如，一个改进的方法是将能量分配给图面（图10.12中的结构元素），而不是单个碱基对。结构的总能量则变为各个子结构能量之和。堆叠能量可以通过实验熔解寡核苷酸来计算。

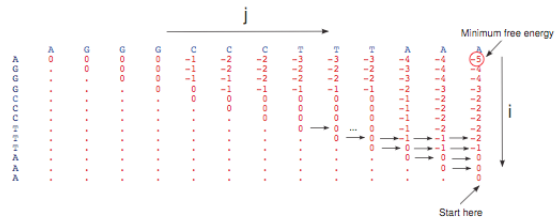

- Folding the sequence AGGGCCCTTTAAA
- Simple energy model with $\beta_{ij} = -1$ for all base-pairs (i.e. finds maximum matching structure)
- Backtracking finds the following optimal structure: (.((.)))((.))

© Stefan Washietl。保留所有权利。此内容不在我们的知识共享许可协议范围内。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图10.9：对角线初始化为0。然后，根据递推关系，表格从底部到顶部、从左到右填充。在此例中，互补碱基配对得分为-1，非互补配对得分为0。整个序列的最优得分位于右上角。

```
function Backtrack(i,j)
begin
    if i > j then return
    if K_ij = 0 then Backtrack(i+1,j) else
        output: (i, K_ij)
        Backtrack(i+1,K_ij − 1)
        Backtrack(K_ij + 1,j)
    end
end
```

图10.10：回溯矩阵K_{ij}，在递归过程中填充，当k与i配对时，对于子序列$[i, j]$，它保存了最优的二级结构。如果在最优结构中i未配对，则$K_{ij} = 0$。

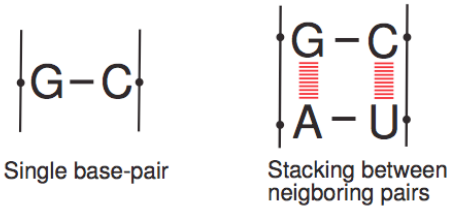

© Stefan Washietl。保留所有权利。此内容不在我们的知识共享许可协议范围内。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图10.11：RNA中相邻碱基对之间的堆积。碱基的平面芳香结构导致堆叠碱基之间的量子相互作用，并改变其物理稳定性。

10.5.2 Zuker Algorithm

因此，我们使用一种包含堆叠能量的变体来计算RNA结构。这被称为Zuker算法。与Nussinov算法类似，它假设最优结构是平衡自由能最低的结构。然而，它包括了由堆叠能量部分决定的各种子结构的总能量贡献。一些现代RNA折叠算法使用此算法进行RNA结构预测。

在Zuker算法中，我们需要处理四种不同的情况。图10.13展示了分解步骤的图形概览。该过程需要四个矩阵。F_{ij}包含了子序列x_{ij}整体最优结构的自由能。新加入的碱基可以是未配对的，也可以形成配对。对于

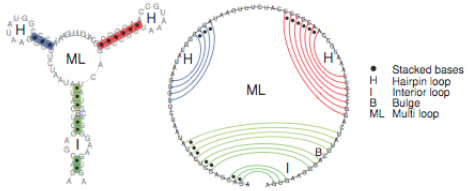

© Stefan Washietl。保留所有权利。此内容不在我们的知识共享许可协议范围内。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图10.12：折叠RNA中的各种内部子结构。发夹结构由连接至配对区的末端环组成，内部环则是配对区内的未配对区域。凸起是内部环的一种特殊情况，仅含有一个错配。多环是由多个这些组件构成的环（在此示例中，两个发夹结构和一个配对区均连接至一个环）。

在后一种情况下，我们引入辅助矩阵C_{ij}，其中包含了在i与j配对约束下x_{ij}最优子结构的自由能。这个由碱基对封闭的结构可以是发夹、内部环或多环。

发夹情况是微不足道的，因为无需进一步分解。内部循环情况也很简单，因为它再次简化为相同的分解步骤。多环步骤更为复杂。多环的能量取决于组件的数量，即从环中发出的子结构。为了隐式跟踪这个数量，需要两个额外的辅助矩阵。M_{ij} 保存 x_{ij} 的最优结构的自由能，约束条件是 x_{ij} 是多环的一部分且至少有一个组件。M^1_{ij} 保存 x_{ij} 的最优结构的自由能，约束条件是 x_{ij} 是多环的一部分，并且恰好有一个由碱基对 (i,k) 与 $i<k<j$ 封闭的组件。这个想法是将多环分解为两个任意部分，其中第一部分是具有至少一个组件的多环，第二部分是具有恰好一个组件并以碱基对开始的多环。

对应于 M 和 M^1 的这两个部分可以进一步分解为我们已知的子结构，即未配对区间、由碱基对封闭的子结构，或（较短的）多环。（这些递推关系也在10.13中进行了总结。

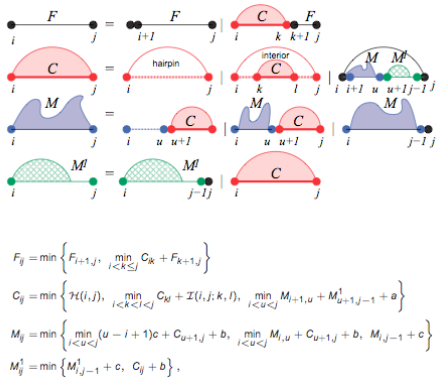

$$F_{ij} = \min\left\{F_{i+1,j},\ \min_{i<k\le j} C_{ik} + F_{k+1,j}\right\}$$

$$C_{ij} = \min\left\{\gamma\epsilon(i,j),\ \min_{i<k<l<j} C_{kl} + \mathcal{I}(i,j;k,l),\ \min_{i<u<j} M_{i+1,u} + M^1_{u+1,j-1} + a\right\}$$

$$M_{ij} = \min\left\{\min_{i<u<j}(u-i+1)c + C_{u+1,j} + b,\ \min_{i<u<j} M_{i,u} + C_{u+1,j} + b,\ M_{i,j-1} + c\right\}$$

$$M^1_{ij} = \min\left\{M^1_{i,j-1} + c,\ C_{ij} + b\right\},$$

© Stefan Washietl。保留所有权利。此内容不在我们的知识共享许可协议范围内。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图 10.13：F 描述未配对的情况，C 由以下三个条件之一描述：发夹、内部环或结构的组合，即多环。M^1 是仅有一个组件的多环，而 M 可能有多个组件。| 图标是 *"or"* 的表示法。

然而，在现实中，在室温（或细胞温度）下，RNA实际上并不是处于单一状态，而是处于一个热力学系综的结构变化中。碱基对可以相当容易地断裂其键，尽管我们可能会在自由能方面找到一个绝对最优解，但可能存在另一种次优结构，它与我们预测的非常不同，并在其中发挥重要作用。

细胞。为了解决这个问题，我们可以计算碱基对概率以获得结构集合，然后我们就能更好地了解RNA结构可能的样子。为了实现这一点，我们利用玻尔兹曼因子：

$$\text{Prob}(\mathcal{S}) = \frac{\exp(-\Delta G(\mathcal{S})/RT)}{Z}$$

这给出了在热力学系统中给定结构的概率。我们需要使用配分函数Z来对温度进行归一化，配分函数是所有结构的加权和，基于它们的玻尔兹曼因子：

$$Z = \sum_{\mathcal{S}} \exp(-\Delta G(\mathcal{S})/RT)$$

我们也可以用点图来直观地表示这个集合，以可视化碱基对概率。为了计算特定碱基对(i, j)的概率，我们需要计算配分函数，其由以下公式给出：

$$p_{ij} = \frac{\hat{Z}_{ij} Z_{i+1,j-1} \exp(-\beta_{ij}/RT)}{Z}$$

为了计算Z (整个结构上的配分函数)，我们使用类似于Nussinov算法（称为McCaskill算法）的递归方法。内部配分函数使用以下公式计算：

$$Z_{ij} = Z_{i+1,j} + \sum_{\substack{i+1 \le k \le j \\ \Pi_{ik}=1}} Z_{i+1,k-1} Z_{k+1,j} \exp(-\beta_{ik}/RT)$$

其中每一个加法项都对应着我们序列中不同的划分，如下图所示。请注意，这些加法项是乘以能量函数的，因为它是用指数形式表示的。

相应地，外层配分函数采用相同学术构想，通过公式{v*}进行计算：

$$\begin{aligned}\hat{Z}_{ij} = \hat{Z}_{i,j+1} &+ \sum_{\substack{1 \le k < i \\ \Pi_{k,j+1}=1}} \hat{Z}_{k,j+1} \exp(-\beta_{k,j+1}/RT) Z_{k+1,i-1} \\ &+ \sum_{\substack{j+2 \le k \le n \\ \Pi_{k,j+1}=1}} \hat{Z}_{i,k} \exp(-\beta_{k,j+1}/RT) Z_{j+2,k-1}\end{aligned}$$

对应于碱基对（i, j）外部区域中的不同分割。

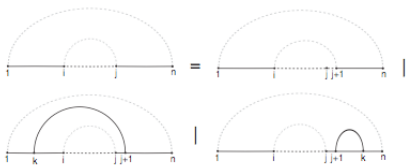

10.6 Evolution of RNA

了解RNA结构的演化是很有用的，因为它揭示了宝贵的数据，并且还能为我们提供线索，以改进我们的结构预测。当我们随时间观察功能重要的RNA时，我们会发现它们的核苷酸在某些部分已经发生了变化，但它们的三维结构却高度保守。

在RNA中存在大量的**compensatory mutations and consistent mutations**。在一致性突变中，结构不会改变，例如AU配对突变为形成G配对。在补偿性突变中，实际上有两个突变，一个破坏了结构，但第二个突变恢复了它，例如AU配对变为CU，这不能很好地配对，但反过来U突变为G以恢复CG配对。在理想情况下，如果我们拥有这种知识，这将是预测RNA结构的关键，因为进化从不撒谎。我们可以计算两种不同RNA的**mutual information content**并进行比较。换句话说，你比较的是两种碱基配对结构随机一致的概率与它们进化以保守结构的概率。

互信息内容通过以下公式计算：

$$MI_{ij} = \sum_{X,Y} f_{ij}(XY) \log \frac{f_{ij}(XY)}{f_i(X) f_j(Y)}$$

如果将这些概率归一化，并以比特为单位存储互信息，我们就可以在三维模型中绘制它，并追踪进化特征。事实上，早在核糖体RNA通过晶体学被发现之前，这种方法就已经被用于确定其结构。

真正的问题是我们没有那么多信息，因此我们通常做的是将折叠预测方法与系统发育信息相结合，以获得可靠的预测。最常见的做法是将Zuker算法与一些协变分数结合起来。例如，如果我们有补偿性突变，我们就添加稳定能量；如果我们有单核苷酸突变，我们就添加去稳定能量。

10.7 Probabilistic Approach to the RNA Folding Problem

RNA-coding sequence inside the genome 在基因组中寻找编码RNA的序列是一个非常困难的问题。然而，有一些方法可以实现这一点。一种方法是将热力学稳定性信息与标准化的RNAfold得分结合起来，然后我们可以进行支持向量机（SVM）分类，并将序列的热力学稳定性与具有相同GC含量和相同长度的一些随机序列进行比较，看看给定结构比预期值稳定多少个标准差。我们可以将其与进化度量结合起来，看看RNA是否更保守。这使我们能够（以相对准确性）判断基因组序列是否实际上编码RNA。

我们仅研究了故事的一半。尽管热力学方法是折叠RNA的一种好方法（也是经典方法），但部分研究者喜欢从不同的角度来研究它。

现在让我们暂且假设我们对RNA的物理性质或玻尔兹曼因子一无所知。相反，我们将RNA视为一串字母，试图找到其最可能的结构。在之前的讲座中，我们已经学习了隐马尔可夫模型。它们是预测概率系统隐藏状态的一种好方法。问题在于，我们能否将隐马尔可夫模型用于RNA折叠问题？答案是肯定的。

我们可以将RNA结构表示为一组点和括号的隐藏状态（回顾第3部分中RNA的点括号表示）。这里有一个重要的观察：RNA内部的位置和配对不是独立的，因此我们不能简单地拥有一个开括号的状态，而不考虑下游正在发生的事件。

因此，我们需要扩展HMM框架以允许嵌套相关性的存在。幸运的是，处理这类问题的概率框架已经存在，它被称为随机上下文无关文法（SCFG）。

Context Free Grammar in a nutshell
你有：

- 非终结符（状态）的有限集合，例如 $\{A, B, C\}$，以及终结符，例如 $\{a, b, c\}$
- 有限的产生式规则集合。例如 $\{A \to aB, B \to AC, B \to aa, \to ab\}$
- 一个初始（起始）非终结符

你想找到一种从一个状态到达另一个状态（或到达终止状态）的方法。$A \to aB \to aAC \to aaaC \to aaaab$ 在随机上下文无关文法中，唯一的区别在于每个关系都有一定的概率。例如，$P(B \to AC) = 0.25$ $P(B \to aa) = 0.75$

系统发育评估很容易与SCFG结合，因为针对系统发育数据存在许多概率模型。本讲不详细讨论这些概率模型，但下图基本上给出了随机模型与本课程迄今所见方法之间的类比。

- 类比热力学折叠：
  - CYK $\leftrightarrow$ 最小自由能 (Nussinov/Zuker) – 内外算法 $\leftrightarrow$ 配分函数 (McCaskill)
- 隐马尔可夫模型的类比：– CYK 最小值 $\leftrightarrow$ 维特比算法 – 内外算法 $\leftrightarrow$ 前向/后向算法

- 给定一个参数化的SCFG（Θ, Ω）和一个序列x，Cocke-Younger-Kasami（CYK）动态规划算法找到一棵最优（最大概率）解析树$\hat{\pi}$ $\hat{\pi} = argmax Prob(\pi, x|\Theta, \Omega)$

- *Inside algorithm* 用于获取给定模型下序列的总概率，对所有解析树求和，$Prob(x|\Theta, \Omega) = \Sigma Prob(x, \pi|\Theta, \Omega)$

10.7.1 Application of SCFGs

- 共识二级结构预测：Pfold – 首个系统发育SCFG

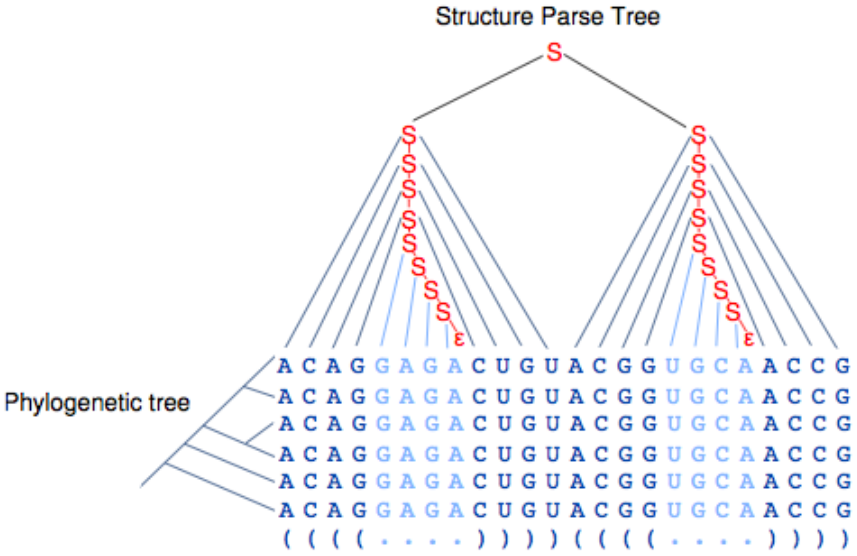

© Stefan Washietl. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/。

图10.14：A）单序列：终端符号是碱基或碱基对，发射概率是环区和配对区域中的碱基频率 B）系统发育-随机上下文无关文法：终端符号是单列或成对的对齐列，发射概率使用Felsenstein算法从系统发育模型和树计算得出我们试图更好地理解RNA-RNA相互作用。

- Structural RNA gene nding: EvoFold
  - Uses Pfold grammar
  - Two competing models:
    - Non-structural model with all columns treated as evolving independently
    - Structural model with dependent and independent columns
  - Sophisticated parametrization

10.8 Advanced topics

仍有许多其他问题需要通过研究RNA结构来解决。本节将概述其中的一些问题。

10.8.1 Other problems

以图形方式观察下面描述的一些问题：

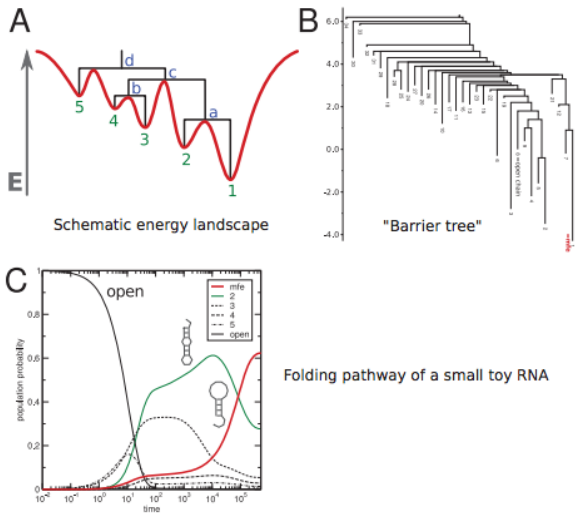

© Stefan Washietl. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图 10.1　　5: 我们可以在further中研究动力学和折叠路径　　r 深度。

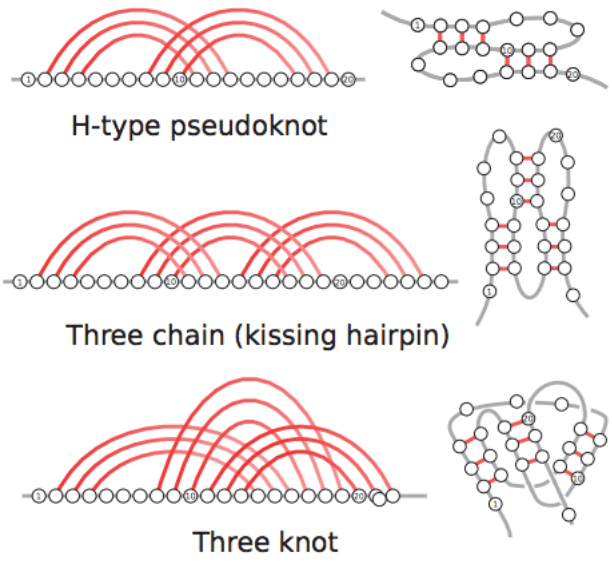

© Stefan Washietl。保留所有权利。此内容不在我们的知识共享许可协议范围内。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图10.16：我们可以研究伪结。

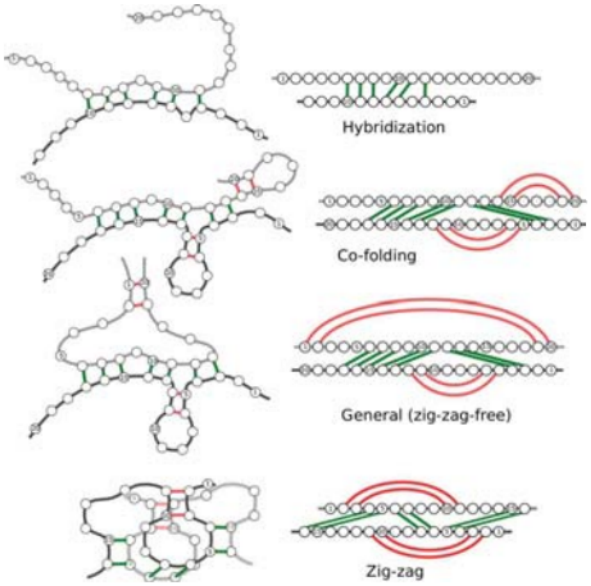

© Stefan Washietl。保留所有权利。此内容不在我们的知识共享许可协议范围内。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图10.17：我们可以尝试更好地理解RNA-RNA相互作用。

10.8.2 Relevance

细胞中除了mRNA、tRNA和rRNA之外，还有大量的RNA。问题是，所有这些非编码RNA的相关性是什么？有些人认为这是通过实验产生的噪音，有些人认为它只是生物噪音，在生物体中没有意义。另一方面，有些人认为垃圾RNA可能实际上在细胞内部作为信号发挥着重要作用，而且所有这些实际上都是功能性的，真相可能介于两者之间。

10.8.3 Current research

There are conserved regions in the genome that do not code any proteins, and now Stefans et al. are looking into them to see if they have structures that are stable enough to form functional RNAs. It turns out that around 6% of these regions have hallmarks of good RNA structure, which is still 30000 structural elements. The group has annotated some of these elements, but there is still a long way to go. a lot of miRNA, snowRNAs have been found and of course lots of false positives. But there exciting results coming up in this topic! so the final note is, it's a very good area to work in!

10.9 Summary and key points

1RNA的功能谱实际上是无限的 ed

(a) 与现代核酶和核糖开关相似的RNA可能存在于RNA世界中。其中一些仍作为活化石存在于当前细胞中。(b) 进化上较年轻的RNA，包括miRNA和许多长非编码RNA，形成了一个非蛋白质为基础的调控层。

2. RNA结构对其功能至关重要，并可通过计算进行预测

(a) Nussinov/Zuker：最小自由能结构 (b) McCaskill：配分函数和配对概率 (c) CYK/Inside-Outside：使用SCFGs的概率解法

3系统发育信息可以改进结构预测　　离子

4. RNA的计算生物学是一个活跃的研究领域，仍有许多棘手的算法问题尚待解决。

10.10 Further reading

- 概述
  - Washietl S, Will S. 等。非编码RNA的计算分析。Wiley Interdiscip Rev RNA。2012, 10.1002/wrna.1134
- RNA功能：John Mattick的综述论文
- 单序列 RNA 折叠
  - Nussinov R, Jacobson AB，预测单链RNA二级结构的快速算法。Proc Natl Acad Sci U S A. 1980年11月；77:(11)6309-13 – Zuker M, Stiegler P 利用热力学和辅助信息对大型RNA序列进行最佳计算机折叠。Nucleic Acids Res. 1981年1月；9:(1)133-48 – McCaskill JS RNA二级结构的平衡配分函数和碱基对结合概率。Biopolymers. 1990年；29:(6-7)1105-19 – Dowell RD, Eddy SR，几种轻量级随机上下文无关文法用于RNA二级结构预测的评估。BMC Bioinformatics. 2004年6月；5:71 – Do CB, Woods DA, Batzoglou S, CONTRAfold：不依赖物理模型的RNA二级结构预测。Bioinformatics. 2006年7月；22:(14)e90-8
- 共识RNA折叠
  - Hofacker IL, Fekete M, Stadler PF, 对齐RNA序列的二级结构预测. J Mol Biol. 2002 Jun; 319:(5)1059-66
  - Knudsen B, Hein J，使用随机上下文无关文法和进化历史预测RNA二级结构。Bioinformatics。1999年6月；15:(6)446-54
- RNA基因发现
  - Pedersen JS, Bejerano G, Siepel A, Rosenbloom K, Lindblad-Toh K, Lander ES, Kent J, Miller W, Haussler D 人类基因组中保守RNA二级结构的识别与分类。PLoS Comput Biol. 2006年4月；2:(4)e33
  - Washietl S, Hofacker IL, Stadler PF, 非编码RNA的快速可靠预测。美国国家科学院院刊。2005年2月；102:(7)2454-9

Bibliography

[1] R·德宾。*Biological Sequence Analysis*。

[2] W. Gilbert. “生命的起源：RNA世界”。*Nature.*，319(6055)：618，1986。

[3] Rachel Sealfon，2012年。额外信息取自背诵5的幻灯片。

[4] Z. Wang, M. Gestein, 和 M. Snyder. RNA-seq：转录组学的革命性工具. *Nat Rev Genet.*, 10(1):57–63, 2009.

[5] Stefan Washietl，2012。所有图片/公式由Stefan的幻灯片提供。[6] R. We
aver. *Molecular Biology.* 第3版。

CHAPTER

ELEVEN

RNA修饰

Figures

11.1 mRNA并不总是蛋白质水平的适当代表。 . . . . . 190 11.2 mRNA水平与蛋白质丰度之间的差异。 . . . . . 190 11.3 遗传信号将氨基酸映射到特定的三核苷酸序列。 190 11.4 使用环己酰亚胺（延伸冻结）或哈灵顿碱（起始冻结）时的核糖体图谱描绘。 . . . . . 192 11.5 使用哈灵顿碱与无药物时的核糖体图谱。红色峰值显示了翻译起始可以开始的不同位置，描绘了不同的可能同工型。 . . . . . 192 11.6 使用哈灵顿碱与无药物时的核糖体图谱。红色峰值先前未识别的开放阅读框。 . . . . . 193 11.7 在丰富条件和饥饿条件下的核糖体图谱。此图像显示饥饿期间蛋白质翻译的急剧减少。mRNA图谱并不表明这一点。 193

11.1 Introduction

生物学中的许多观点都依赖于了解细胞中的蛋白质水平。蛋白质丰度通常是从相应的mRNA水平推断出来的。之所以进行这种推断，是因为测量mRNA水平相对容易。此外，长期以来，人们认为表达调控全部发生在mRNA形成之前。如今已知，表达在翻译阶段仍持续受到调控。图1显示，可用于转录后调控的数据极少，并举例说明了mRNA水平如何不能指示蛋白质丰度。

图11.1：mRNA并不总是蛋白质水平的合适替代指标。

有许多因素可能会影响mRNA的翻译过程，导致mRNA水平与蛋白质水平并非直接相关。这些因素包括：

1. ***Translation elongation rates*** - 取决于密码子使用偏性、tRNA适应性和RNA编辑 2. ***Translation initiation rates*** - 取决于AUG频率、TOP存在与否、起始类型（帽依赖/IRES）及二级结构 3. ***Translation termination rates*** - 取决于终止密码子的身份 4. ***mRNA degradation rates*** - 取决于polyA尾长度、加帽、mRNA编辑及二级结构 5. ***Protein degradation rates*** - 取决于PEST序列、蛋白质稳定性、无序区域及极性氨基酸的存在 6. ***Cis and Trans regulatory elements*** - 取决于AU富集元件、miRNA、ncRNA及RNA结合蛋白

图11.2：mRNA水平与蛋白质丰度之间的差异。

11.2 Post-Transcriptional Regulation

11.2.1 Basics of Protein Translation

关于转录和翻译的基础知识，请参考第1讲第4.3至4.5节。

图11.3：遗传信号，即氨基酸被映射到特定的三核苷酸序列。

遗传密码几乎是通用的。

FAQ

Q: 为什么生物之间的遗传密码如此相似?

A: 基因组物质不仅垂直传递（从父母）而且在生物体之间水平传递。这种基因相互作用为通用遗传密码创造了进化压力。

FAQ

Q: 不同生物体遗传密码存在细微差异的原因是什么?

A: 氨基酸在进化中出现得较晚或较早可以解释这些差异。此外，某些物种（例如深海热液喷口处的细菌）拥有更多资源来合成特定氨基酸，因此它们会倾向于在遗传密码中使用这些氨基酸。

Did You Know?
苏氨酸和苏氨酸经常被tRNA合成酶意外互换，因为它们源自一种氨基酸。

11.2.2 Measuring Translation

翻译效率定义为,

$$T_{eff} = \frac{[\text{mRNA}]}{[\text{protein}]}$$

我们感兴趣的是了解我们的mRNA有多少被翻译成蛋白质，即效率。然而，具体测量多少mRNA转化为蛋白质是一项艰巨的任务，需要一点创造力。解决这个问题有多种方法，但每种方法都有其不足之处:

1. ***Measure mRNA and protein levels directly*** 陷阱：未考虑合成和降解速率。此方法测量的是蛋白质
n
‘旧’ mRNA 的水平，因为从 mRNA 到蛋白质存在时间滞后。2.
Use drugs to inhibit transcription and translation 陷阱：药物具有副作用，会改变翻译 3.
Artificial fusion of proteins with tags 陷阱：蛋白质标签可能影响蛋白质稳定性 4.
Pulse label with radioactive nucleosides or amino acids (SILAC) **目前在使用** 陷阱
：不提供动态变化信息：它只是 X 小时后所得 mRNA 和蛋白质水平的快照

另一种常用技术是利用“核糖体印迹”在亚密码子分辨率下测量蛋白质翻译。这是通过将正在翻译过程中的核糖体冷冻并降解未被核糖体保护的序列来实现的。此时，这些序列可以被重新拼接起来，并且某个区域被翻译的频率可以被插值计算。使用这些核糖体足迹来观察哪些区域正在被翻译的缺点是，核糖体之间的区域会丢失。该技术需要并行进行RNA-seq。

问题依然存在，为什么核糖体图谱技术具有优势？这项技术是一种更好的测量蛋白质丰度的方法，因为它：

1. 是一个***better measure of protein abundance***

2. ***independent of protein degradation*** (与蛋白质丰度/mRNA比率)相比吗?

3. 允许我们 ***measure codon-specific translation rates***

使用核糖体图谱技术，可以观察到正在解码的密码子：这一过程通过映射核糖体足迹，并依据足迹长度来解读正在翻译的密码子实现。我们可以通过基于周期性（密码子中的三个碱基）映射翻译密码子谱来验证我们的预测。通过使用抗翻译药物如$harringtonine$和$cyclohex\text{-}amide$，该技术还能进一步提升。环己酰亚胺阻断延伸过程，而哈林顿碱抑制起始阶段。后者可用于确定起始点（哪些基因即将被翻译）。图4展示了这些药物对核糖体图谱的影响。

图11.4：使用环己酰亚胺（延伸冻结）或哈灵顿碱（起始冻结）时的核糖体图谱描绘。

这项技术所提供的远不止简单地量化翻译。核糖体图谱分析能够实现：

1. ***Prediction of alternative isoforms*** (不同的翻译起始位置)

图11.5：使用哈灵顿碱与未用药时的核糖体图谱。红色峰值显示了翻译起始可能开始的不同位置，描绘了不同的可能异构体。

2. ***Prediction of un-indentified ORFs*** (开放阅读框)

图11.6：使用哈灵顿碱与未用药时的核糖体图谱。红色峰表示之前未识别的开放阅读框(ORF)。

3. ***Comparing translation across different environmental conditions***

图11.7：在丰富条件和饥饿条件下的核糖体图谱。此图展示了饥饿条件下蛋白质翻译的显著减少。mRNA图谱并未反映这一情况。

4. ***Comparing translation across life stages***

因此，我们可以看到，核糖体图谱分析是一种非常强大的工具，具有巨大的潜力，能够揭示有关基因组翻译中以前难以捉摸的信息。

11.2.3 Codon Evolution

Basic concepts

需要明确的是，密码子并非以相同的频率使用{v*}。实际上，根据RNA稳定性、链特异性突变偏置、转录效率、GC组成、蛋白质亲疏水性以及翻译效率的不同，不同物种间可被视为最优的密码子各不相同。同样，tRNA同工受体在物种内部及物种之间也并非以相同频率使用。下一节的动机在于确定我们如何衡量这种密码子偏置。

Measures of Codon Bias

有几种方法可以完成这项任务：

a) 计算最优密码子的频率，其定义为“最优”密码子除以“最优”和“非最优”密码子之和。这种方法的局限性在于，它需要知道每个tRNA识别哪个密码子，并假设tRNA丰度与tRNA基因拷贝数高度相关。

b) 计算密码子偏性指数。这衡量的是最优密码子相对于编码同一氨基酸的总密码子的比率。然而，在这种情况下，最优密码子的数量是根据预期的随机使用情况归一化的。$CBI = (o_{opt} - e_{rand})/(o_{tot} - e_{rand})$。这种方法的局限性

是需要一组参考蛋白质，比如高表达的核糖体蛋白。

c) 计算密码子适应指数。该指数衡量基因密码子使用相对于一组参考蛋白质（即高表达基因）密码子使用的相对适应性或偏差。其定义为相对适应性值的几何平均数，这些值以基因序列长度（以密码子计）上每个密码子的权重来衡量。每个权重计算为给定密码子的观测频率与其对应氨基酸频率之间的比率。这种方法的局限性在于，正如上一种方法一样，它需要定义一组参考蛋白质。

d) 计算有效密码子数。这衡量了一个序列中使用的不同密码子的总数，从而衡量了偏向使用较小密码子子集的程度，而非同义密码子的均等使用。$N_c = 20$，如果每个氨基酸只使用一个密码子；$N_c = 61$，当所有可能的同义密码子均等使用时。该过程的步骤包括：根据密码子频率的平方估计每种氨基酸的纯合性，获得每种氨基酸的有效密码子数，并计算总有效密码子数。这种方法的优势在于它不需要任何关于tRNA-密码子配对的知识，也不需要任何参考集。然而，它的局限性在于没有考虑到tRNA池。

e) 计算tRNA适应指数。假设tRNA基因拷贝数与细胞内tRNA丰度呈高度正相关。这进而衡量了一个基因对tRNA池的适应程度。

重要的是要区分何时使用每个索引。某个索引有利的情况非常依赖于上下文，因此当情况需要时，通常更倾向于使用一个索引而不是其他所有索引。通过精心选择一个索引，可以揭示有关密码子翻译成氨基酸频率的信息。

RNA Modifications

当我们考虑RNA可能发生的修饰时，情况变得更加复杂。例如，一些修饰能够扩大或限制tRNA的摆动能力。实例包括肌苷修饰和xo^{5}U修饰。这些修饰使得tRNA能够解码之前无法读取的密码子。有人可能会问，为何在进化过程中RNA修饰被正向选择，其理由是这使得在特定环境下存在匹配tRNA来解码密码子的概率得以增加。

Examples of applications

基于我们对密码子进化的理解，有几个自然的应用。

a) 用于异源蛋白表达的密码子优化 b) 预测基因组的编码区和非编码区 c) 预测密码子通读 d) 理解基因如何被解码——研究基因中密码子使用偏好的模式

11.2.4 Translational Regulation

在转录后水平上有许多已知的调控方式。这些包括tRNA可用性的调节、mRNA的变化以及顺式和反式调控元件。首先，tRNA的调节具有重大影响。tRNA同工受体的变化、tRNA修饰的变化以及在tRNA氨酰化水平上的调控。影响翻译的mRNA变化包括mRNA修饰、polyA尾巴、剪接、加帽以及mRNA的定位（进出细胞核）。顺式和反式调控元件包括RNA干扰（即siRNA和miRNA）、移码事件和核糖开关。此外，许多调控元件仍未被发现！

11.3 Current Research Directions

11.4 Further Reading

11.5 Tools and Techniques

11.6 What Have We Learned?

希望在本章结束时，我们已经意识到转录调控的重要性。我们发现mRNA水平与蛋白质水平并非1：1对应。此外，我们还了解到遗传密码并非普遍适用，而所谓的首选tRNA-密码子配对是动态变化的。同样，同义突变在不同物种间并不等同。我们已经见识到核糖体 profiling 技术的强大之处，它使我们能够以亚密码子分辨率测量翻译过程。尽管如此，利用工具建模翻译和密码子进化仍有助于提高异源系统中蛋白质的翻译效率/折叠、预测编码区域、理解细胞类型特异性的翻译模式，并比较健康与疾病状态下的翻译差异。最后，通过分析翻译调控，我们了解到蛋白质水平是如何被调节的，并发现实现转录后调控有多种不同的方式。或许我们会意识到，这些不同的调控策略之间的相互联系比我们最初想象的要多。

Bibliography

CHAPTER

TWELVE

大型基因间非编码RNA

约翰·林恩客座讲座，由伊莱·斯蒂克戈尔德记录 (2010)

Figures

12.1 Tuxedo 工具 . . . . . 200 12.2 间隔种子索引的工作原理 . . . . . 200 12.3 Burrows-Wheeler 索引的工作原理 . . . . . 201 12.4 比对中空隙的一个示例 . . . . . 201 12.5 如何使用图来寻找转录本的一个示例 . . . . . 202 12.6 F_1 . . . . . 202 12.7 F_2 . . . . . 203 12.8 技术变异性遵循泊松分布 . . . . . 204 12.9 人类成纤维细胞通过表观遗传调控特化，根据其在体内的位置形成不同的皮肤类型。研究发现，手部皮肤与足部皮肤具有极其相似的表观遗传特征，而足部也位于远端。 . . . . . 205 12.10 对两种皮肤细胞类型的染色质结构域进行分析。在靠近身体的肺细胞类型与远离身体的足细胞类型之间存在明显的边界。 . . . . . 205 12.11 Polycomb 是一种能够重塑染色质从而实现基因表观遗传沉默的蛋白质，可能受 HOTAIR 等非编码 RNA 的调控。 . . . . . 205 12.12 linc RNA 与发育调控因子相邻 207

12.1 Introduction

表观遗传学研究的是不源于DNA序列的遗传表达和表型中的可遗传变化。每个细胞尽管拥有相同的基因组副本，却能够分化成

一种专门类型。有许多生物装置可以实现这些，包括DNA甲基化、组蛋白修饰以及各种类型的RNA。

DNA甲基化是一种二进制代码，实际上等同于将基因“开启”或“关闭”。然而，很多时候一个基因可能需要更高水平的表达，而不仅仅是开启。为此，组蛋白具有可被修饰的尾部。这两个元素在一段DNA上的独特组合可以被视为细胞类型的条形码。更重要的是它们在复制过程中的保存方法。就DNA甲基化而言，每条母细胞或子细胞都会分配到一条适当甲基化的链。通过留下一条踪迹，细胞能够填补空缺并适当地甲基化另一个细胞。

作为DNA序列和蛋白质之间的中介，RNA可以说是最多才多艺的调控手段。因此，它们将成为本章的重点。

Did You Know?
细胞类型可以通过组蛋白修饰或 DNA 甲基化（一种依赖于常染色质和异染色质状态的二进制代码）来确定。这些组蛋白修饰可以被视为一种表观遗传条形码，允许对细胞 DNA 进行类型扫描。称为大型基因间非编码 RNA（lincRNA）的非编码 RNA 大量参与这一过程。

RNA简史：

- **1975:** 一个实验室在检测公牛精子中RNA和DNA的相对水平时发现，RNA的含量是DNA的两倍。
- **1987:** 随着自动测序技术的发展，最初发现了奇怪的非编码RNA。
- **1988:** RNA被证明对维持染色体结构很重要，通过染色质架构
- **1990s:** 大量实验开始研究
- **2000s:** 研究表明组蛋白甲基转移酶依赖于RNA，因为RNA酶会导致这些蛋白质去定位。

转录是细胞中活跃物质及将转化为蛋白质的物质的一个良好指标。微阵列技术最初发现了非编码基因的数量是编码基因的两倍；如今我们知道这一比例甚至远高于此。

12.2 Noncoding RNAs from Plants to Mammals

基本循环：大RNA被切割成小RNA（siRNA）RNA按类别使用：

Protists: RNA被用作模板以剪接出DNA（依赖RNA的DNA消除与剪接）

mRNA and DNA in nucleus: DNA根据mRNA中的间隙被切割并重组（“奇特现象”）

Plants: RNA依赖性RNA聚合酶，其中聚合酶以RNA为模板并制造其拷贝，存在于植物中但不存在于人类中，并且可以制造小RNA。哺乳动物最多有一个

拷贝。在结构上与RNA聚合酶和DNA聚合酶非常不同。由此，我们了解到植物利用非编码RNA进行DNA甲基化。

Flies: 使用RNA作为RNA开关；hox基因的协调调控需要非编码RNA。

Mammals: 非编码RNA能够形成三链螺旋，引导蛋白质与之结合；染色质修饰复合体；参与生殖细胞系；引导转录因子的行为。

在本次演讲的剩余部分，我们将特别关注lincRNA，我们将其定义为大于200个核苷酸的RNA。

12.2.1 Long non-coding RNAs

表观遗传调控通过多种不同的机制和生物装置实现。其中之一是长链非编码RNA，可以将其视为在细胞内发挥空中交通管制功能。

长非编码RNA与微小RNA有许多相似的特征。它们经过剪接，包含多个外显子，具有5'端帽子和多聚腺苷酸化。然而，它们并不具备开放阅读框。它们看起来就像蛋白质编码基因，但实际上并不能编码蛋白质。

它们根据解剖位置分类会更好：

Antisense: 这些是在蛋白质编码基因的相反链上编码的。

Intronic: 完全包含在蛋白质编码基因的内含子中。

Bidirectional: 它们与一个蛋白质编码基因共享相同的启动子，但位于相反的一侧。

Intergenic: 它们不与任何蛋白质编码基因重叠。可以将它们想象成盲目地暴露在开阔地带。它们是更容易的目标，并将成为本章的重点。

12.3 Practical topic: RNAseq

RNA-seq是一种利用下一代测序技术对cDNA进行测序的方法，使我们能够深入了解RNA的内容。RNA-seq解决的两个主要问题是：(1)发现新基因，如先前发现基因的剪接异构体，(2)从测序数据中揭示基因和转录本的表达水平。此外，RNA-seq也开始取代许多传统的测序技术，使实验室能够更高效地进行实验。

12.3.1 How it works

RNA-Seq机器抓取一个转录本并将其断裂成不同的片段，这些片段呈正态分布。鉴于RNA-seq测序这些转录本片段（或读段）的速度，我们能够获得大量的读段，从而提取表达水平。这种方法背后的基本思想基于这样一个事实：转录本越丰富，我们从中测序得到的片段就越多。

用于分析RNA-Seq数据的工具统称为“Tuxedo Tools”

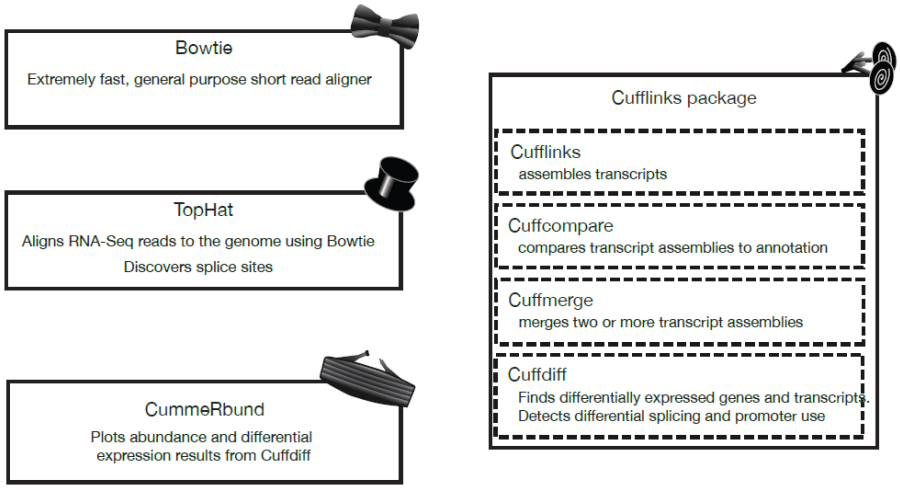

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图12.1：Tuxedo工具

12.3.2 Aligning RNA-Seq reads to genomes and transcriptomes

由于 RNA-Seq 产生的读数非常多，比对算法的运行时间必须很快，大约为 O(n) 量级。比对短读数主要有两种策略，它们都要求我们已经拥有转录本。

1. 间隔种子索引

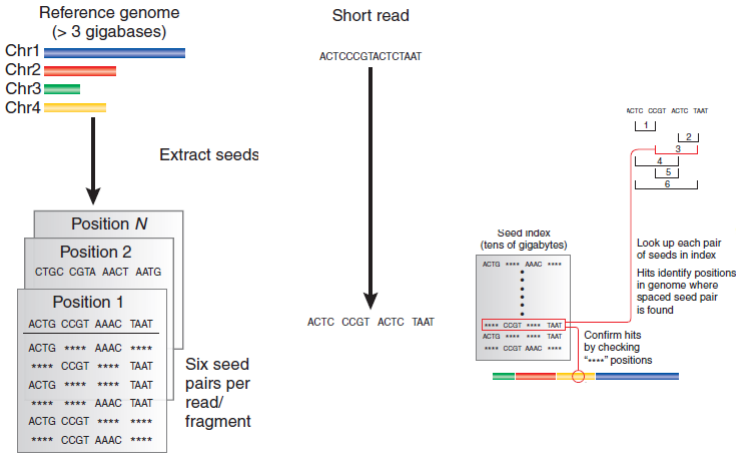

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/。

图12.2：间隔种子索引的工作原理

间隔种子索引涉及将每个读取序列分解成片段，或称“种子”。我们取两个片段的所有组合（“种子对”），并将它们与种子索引进行比较（这将

需要占用数十GB的空间）以寻找潜在的匹配项。将其他种子与索引进行比较，以确保我们找到了匹配项。

2. 布伦斯-惠勒索引

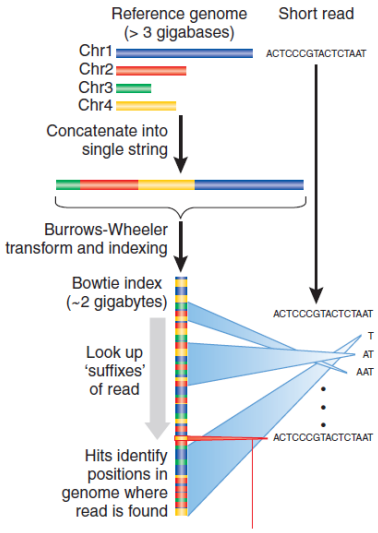

© source unknown. All rights reserved. This content is excluded来自我们的创意
Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图12.3：Burrows-Wheeler索引的工作原理

Burrows-Wheeler索引对基因组进行打乱，使得你可以逐个字符地查看读取序列，并迅速排除基因组中大量的可能比对位置。

这两种通用对齐策略的一个主要问题是它们没有考虑到对齐中的大间隙。

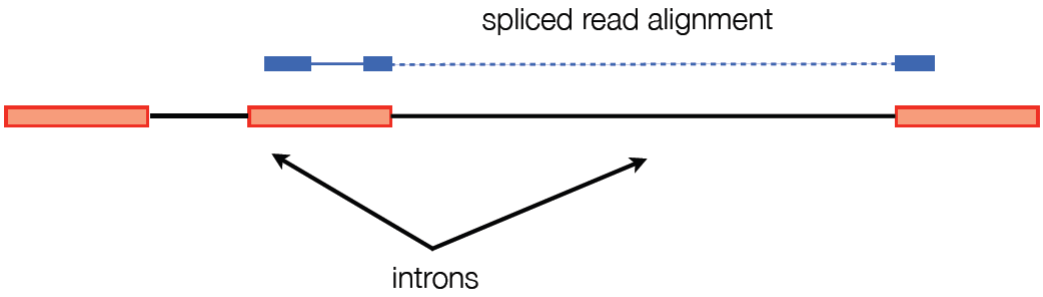

图12.4：对齐间隙示例

为了解决这个问题，TopHat将读取序列拆分成更小的片段。这些片段被比对，而那些片段映射到相距较远的读取序列则被标记为可能的内含子位点。未能比对的片段用于确认剪接位点。之后，读取序列被重新拼接起来，形成完整的读取比对。

基于RNA-Seq读取组装转录本有两种策略。

1. 基因组导向方法（用于Cufflinks等软件）

   这种方法背后的思想是，我们不一定知道两个读取是否来自同一转录本，但我们会知道它们是否来自不同的转录本。算法如下：取比对结果并将它们放入一个图中。如果{·v2}在基因组中位于{·v3}的左侧，{·v4}和{·v5}一致重叠，且{·v6}不包含在{·v7}中，则从{·v1}添加一条边。因此，如果它们可能来自同一转录本，我们就从{·v8}添加一条边。

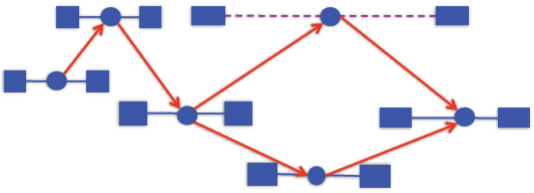

图12.5：如何使用该图查找转录本的示例

   如果我们从左到右遍历这个图，就得到一个潜在的转录本。将Dilworth定理应用于读段偏序，我们可以看到图中最大反链的大小是解释该比对所需的最少转录本数量。反链是一组比对，其中任意两个都不兼容（即不可能来自同一转录本）

2. 独立于基因组的 approach（用于诸如这样的软件中　　三位一体)

   不依赖基因组的方试图直接用读段拼装转录本，采用基于重叠的读段组装经典方法，类似于基因组组装方法。

12.3.3 Calculating expression of genes and transcripts

我们希望统计每个转录本的读取数量，以确定转录本的表达水平。然而，由于我们将转录本分割成等长的片段，因此遇到了较长转录本自然会产生比短转录本更多读取的问题。为了解决这个问题，我们使用FPKM（每百万映射片段中每千碱基的片段数）来计算表达水平。

Likelihood function for a gene

假设我们对一个特定的读段进行测序，称其为F_1。

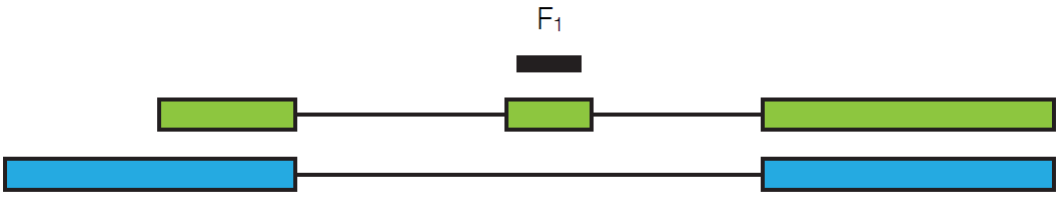

图 12.6：F_1

为了获得这个特定的读取，我们需要选择它所在的那个特定转录本，然后我们需要从整个转录本中挑选出这个特定的读取。如果我们定义 γ_{green} 为绿色转录本的相对丰度，那么我们有

$$P(F_1|\gamma_{\text{green}}) = \frac{\gamma_{\text{green}}}{l_{\text{green}}}$$

其中 l_{green} 是绿色转录本的长度。现在假设我们看另一个读取片段，F_2。

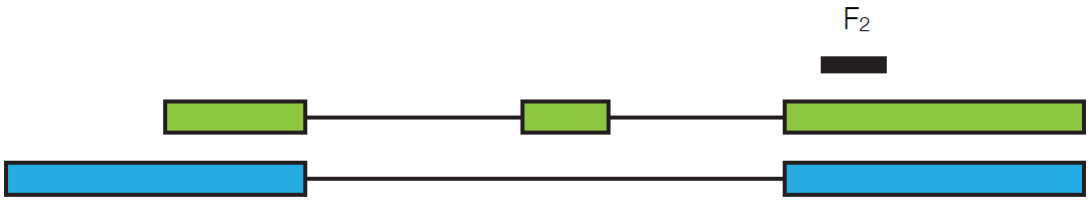

图 12.7：F_2

它本来可以　来自蓝色转录本的绿色转录本　　ipt，所以：

$$P(F_2|\gamma) = \frac{\gamma_{\text{green}}}{l_{\text{green}}} + \frac{\gamma_{\text{blue}}}{l_{\text{blue}}}$$

我们可以看到，同时得到 F_1 和 F_2 的概率正好是各自概率的乘积：

$$P(F|\gamma) = \frac{\gamma_{\text{green}}}{l_{\text{green}}} \cdot (\frac{\gamma_{\text{green}}}{l_{\text{green}}} + \frac{\gamma_{\text{blue}}}{l_{\text{blue}}})$$

我们将其定义为似然函数，$L(F|\gamma)$。给定输入的丰度，我们可以得到读取序列可能性的概率。因此，从一组读取和转录本中，我们可以构建一个似然函数，并计算出使该函数最大化的伽马值。Cufflinks通过在山登爬坡或对数似然函数上使用EM算法来实现这一点。

12.3.4 Differential analysis with RNA-Seq

假设我们对一个基因在两种不同条件下进行 RNA-Seq 分析。我们如何判断片段计数是否存在显著差异？我们通过估计来自每个转录本的预期片段数来计算表达量。为了检验显著性，我们需要知道该估计值的方差。我们将方差建模为：

$$\text{Var（expression）} = \text{技术变异} + \text{生物变异}$$

技术变异性，即来自读数映射不确定性的变异性，可以很好地用泊松分布来建模（见下图）。然而，使用泊松分布来模拟生物学变异性，或跨重复实验的变异性，会导致过度离散。

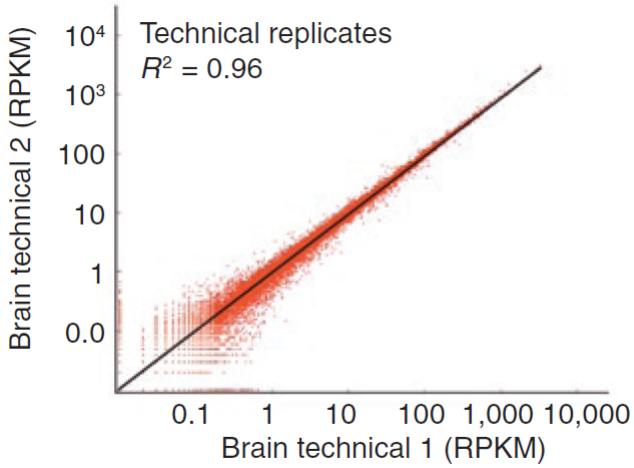

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图12.8：技术变异遵循泊松分布

在简单情况下，如果我们在重复实验间存在变异性，但没有不确定性，我们可以将每个重复的泊松分布混合成一个新的分布来模拟生物变异性。我们可以将泊松分布的lambda参数视为遵循伽马分布的随机变量：

$$X \sim Poisson(\Gamma(r, p))$$

该模型得到的计数服从负二项分布。为了确定每个基因的负二项分布参数，我们可以通过拟合均值计数与重复样本间计数方差的散点图来得到伽马函数。

在存在读段映射不确定性但无生物学变异性的简单情况下，我们需要将映射不确定性纳入方差估计中。由于我们以概率方式将读段分配给转录本，因此需要计算该分配中的方差。

RNA-Seq表达分析研究的两个方向分别关注这两个简单案例中的问题。其中一个方向侧重于推断单个异构体的丰度，以了解差异剪接和启动子使用，而另一个方向则侧重于对重复样本间的变异性进行建模，以实现更稳健的差异基因表达分析。Cuffdiff将这两个独立的方向结合起来，研究我们同时面临生物学变异性和读段映射模糊性的情况。由于过离散可以用负二项分布建模，而映射不确定性可以用Beta分布建模，我们将这两者结合起来，用beta负二项分布来建模这种情况。

12.4 Long non-coding RNAs in Epigenetic Regulation

让我们以人类皮肤为例，来说明长非编码RNA如何参与表观遗传调控。人类皮肤面积巨大，事实上它是人体中按重量计算最大的器官。它结构复杂，具有特化的特征，并且不断再生，以新细胞替换衰老死亡的细胞。皮肤必须受到调控，使毛发只长在手背上，而不是手掌上。此外，这些边界不能

变化，并从出生起就保持不变。

身体所有部位的皮肤均由上皮层和一层由称为成纤维细胞的细胞构成的结缔组织组成。这些成纤维细胞分泌控制外层的细胞因子信号，决定诸如毛发有无等特性。全身各处的成纤维细胞都是相同的，除了特定的表观遗传折叠，它决定了给定位置将形成何种类型的皮肤。根据皮肤是远端还是近端、内侧还是外侧、后部还是前部，一组不同的表观遗传折叠将决定所形成的皮肤类型。

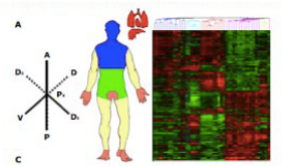

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 htt
p://ocw.mit.edu/help/faq-fair-use/。

图12.9：人体成纤维细胞通过表观遗传调控，根据其在体内的位置特化形成不同的皮肤类型。研究发现，手部皮肤与同样位于远端的足部皮肤具有显著相似的表观遗传特征。

已发现，特定的HOX基因在发育过程中划定了这些解剖边界。仅通过观察人类HOX遗传密码，就能预测细胞将位于何处。利用染色质免疫沉淀微阵列（ChIP-on-chip）技术，已在HOX基因间发现了二聚体染色质结构域。在下图中，我们可以清晰地看到近端细胞类型与远端细胞类型的染色质结构域之间存在明确的边界。这一边界不仅精确，而且在数万亿皮肤细胞中得以维持。

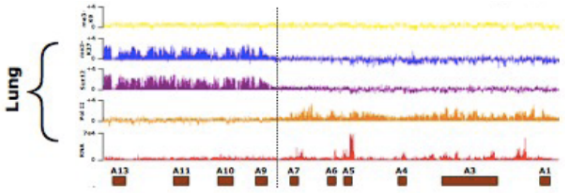

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 htt
p://ocw.mit.edu/help/faq-fair-use/。

图12.10：对两种皮肤细胞类型的染色质结构域进行了分析。在靠近身体的肺细胞类型和远离身体的足细胞类型之间存在明显的边界。

HOTAIR或HOX转录本反义基因间RNA已被研究作为可能的RNA调节因子，维持染色质中对立域之间的边界。当在HOXC位点敲除HOTAIR时，有人假设染色质域可能会相互渗透。然而，研究发现HOTAIR并不直接影响表观遗传边界，但研究人员确实发现了基于RNA的基因组交互作用的证据。HOTAIR基因影响了另一个称为HOXD的位点。

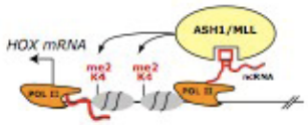

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 htt
p://ocw.mit.edu/help/faq-fair-use/。

图12.11：Polycomb是一种能够重塑染色质从而实现基因的表观遗传沉默的蛋白质，它可能受到诸如HOTAIR之类的非编码RNA的调控。

通过ncRNA依赖的Polycomb抑制过程，HOTAIR序列能够控制表观遗传调控。Polycomb是一种在组蛋白尾部加上停止标记的蛋白质，从而它们能在遗传物质中引起特定的折叠。组蛋白本身是无方向性的，因此需要一些

机制来决定它们如何附着到基因组上。这一发现过程引起了人们对长基因间非编码RNA影响表观遗传调控能力的极大兴趣。

12.5 Integergenic Non-coding RNAs: missing lincs in Stem/Cancer cells?

12.5.1 An example: XIST

XIST是最早被表征的lincRNA之一。它直接参与胚胎发育过程中女性X染色体的去活化。它被描述为具有“使整条染色体皱缩”的能力。这一点很重要，因为去活化可以防止X染色体上基因的致命性过度表达。

RNA对于将多色复合体带到染色体上至关重要，非编码RNA能在顺式作用中激活下游基因，反式作用中则相反；Xist也执行同样的功能。

12.6 Technologies: in the wet lab, how can we find these?

我们如何找到ncRNA？我们有大约20-30个具有重要性证据的ncRNA例子，但还有更多有待发现。染色质状态图（来自ENCODE、ChIP-seq）可用于寻找不与蛋白质重叠的转录单元。我们可以沿着图谱寻找基因（通过肉眼观察染色质图来发现ncRNA）。几乎90%的情况下，发现这样的特征时，RNA会从中转录。我们可以通过Northern印迹来验证这一点。

在查看染色质图谱以寻找ncRNA时，我们实际上是用一个给定大小的窗口浏览图谱，观察所获得的信号与噪声之比，与随机假设下可能预期的结果相比如何。由于大窗口和小窗口各有优势，因此在每个图谱区段上都应同时使用两者。较大的窗口能包含更多信息；较小的窗口则更为灵敏。

在找到基因间区之后，我们寻找保守区域。

我们检查新区域是否处于选择压力下；保守区域中的突变较少。如果一个核苷酸在物种之间从未发生突变，那么它是高度保守的。

linc-RNA比内含子更保守，但不如蛋白质编码内含子保守，这可能是由于lincRNA环区中的非保守序列所致。

寻找lincRNA的功能：“关联定罪”：我们可以找到在表达上与特定lincRNA相关的蛋白质；lincRNA可能与特定通路相关。通过这种方式，我们为每个lincRNA获得一个多维条形码（它与什么相关，与什么不相关）。我们可以对lincRNA特征进行聚类，并识别常见模式。许多与细胞周期基因有关。（这种方法在60-70%的情况下有效）

由于大多数lincRNA超过3000个碱基，许多仅凭偶然就包含了编码100个氨基酸开放阅读框的序列。这导致检测过程中出现许多假阴性。

研究发现，许多lincRNA往往邻近基因组的发育区域。与蛋白质编码基因相比，它们的表达水平也往往较低。

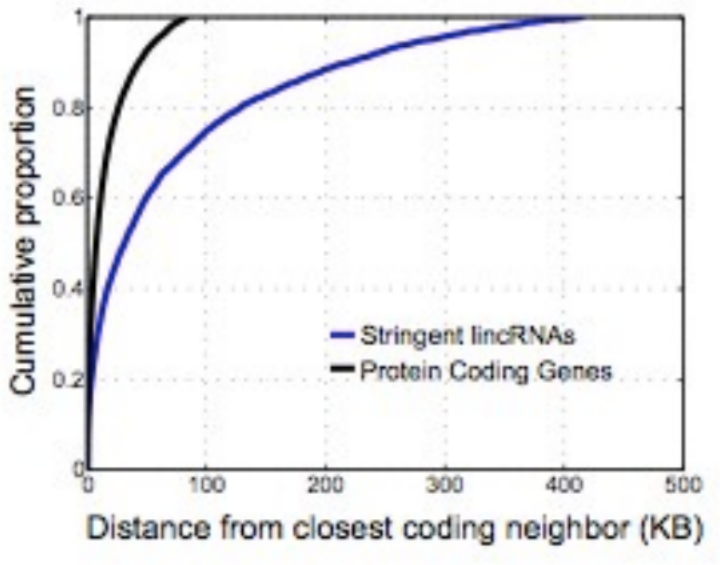

图12.12：lincRNAs邻近发育调控因子

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

12.6.1 Example: p53

独立验证：我们使用动物模型，其中一个是野生型p53，另一个是敲除型。我们诱导p53，然后询问lincRNAs是否开启。在发现的与p53相关的39个lincRNAs中，有32个在开启p53后被暂时诱导。

特别是一种RNA位于p53通路中一个蛋白质编码基因旁边。我们试图弄清楚p53是否结合到启动子上并将其开启。为了做到这一点，我们克隆了lincRNA的启动子，并探究p53是否会将其开启？我们对p53蛋白进行了免疫沉淀，以观察它是否与启动子的lincRNA相关联。结果发现，lincRNA与p53直接相关——p53将其开启。P53也会关闭基因——某些lincRNA充当抑制因子。

从这个例子（以及其他例子）中，我们开始看到RNA通常有一个蛋白质伴侣。

RNA可以将多种不同的蛋白质聚集在一起，赋予细胞极大的多样性。在这方面，它类似于磷酸化作用。RNA与重要的染色质复合体结合，并且是重编程皮肤细胞成为干细胞所必需的。

12.7 Current Research Directions

12.8 Further Reading

12.9 Tools and Techniques

12.10 What Have We Learned?

Bibliography

[1] R.P. Dilworth. 偏序集的分解定理. *Annal of Mathematics*, 1950.

[2] Mitchell Guttman, Manuel Garber, Joshua Z Levin, Julie Donaghey, James Robinson, Xian Adiconis, Lin Fan, M agdalena J Koziol, Andreas Gnirke, Chad Nusbaum, 等. 小鼠细胞类型特异性转录组的从头重建揭示了lincrnas保守的多外显子结构. *Nature Biotechnology*, 28(5):503–510, 2010.

[3] C. Trapnell。

CHAPTER

THIRTEEN

SMALL RNA

David Bartel（MIT/Whitehead/HHMI）客座讲座，由Boyan
g Zhao（2011）记录

Figures

13.1 siRNA 和 miRNA 生物发生途径 . . . . . 213 13.2 miR-223 缺失后的蛋白质
和 mRNA 变化 214

13.1 Introduction

20世纪90年代利用表达序列标签进行的大规模分析估计，人类基因组总共编码35,000至100,000个基因。然而，人类基因组的完整测序令人惊讶地揭示，蛋白质编码基因的数量可能仅为∼20,000至25,000个[12]。虽然这仅占基因组序列总数的<2%，但全基因组和转录组测序以及高分辨率基因组微阵列研究表明，超过>90%的基因组仍被活跃转录[8]，主要以非蛋白质编码RNA（ncRNAs）的形式存在。尽管最初的推测认为这些是转录机制固有的无功能转录噪声，但越来越多的证据表明，这些ncRNAs在细胞过程以及疾病的表现/进展中发挥着重要作用。因此，这些发现挑战了RNA仅作为DNA与蛋白质之间中间体的经典观点。

13.1.1 ncRNA classifications

近年来对ncRNA的关注日益增加，加之测序技术（如Roche 454、Illumina/Solexa和SOLiD；关于这些方法的更多细节请参考[16]）的进步，导致了非编码RNA多样群体鉴定数量的激增。尽管目前尚无统一的命名规则，但根据转录本大小，ncRNA可分为两大类：小ncRNA（<200

核苷酸）和长非编码RNA（lncRNA）（≥200个核苷酸）（表13.1）[6, 8, 13, 20, 24]。其中，小非编码RNA microRNA（miRNA）和小干扰RNA（siRNA）在RNA沉默中的作用在最近的历史中得到了最充分的记录。因此，本章剩余部分的大部分讨论将集中在这些小非编码RNA的作用上。但首先，我们将简要描述其他多样化的非编码RNA集合。

表13.1：ncRNA分类（基于[6, 8, 13, 20, 24]）

Name	Abbreviation	Function
	Housekeeping RNAs	
Ribosomal RNA	rRNA	translation
Transfer RNA	tRNA	translation
Small nucleolar RNA	snoRNA (∼60-220 nt)	rRNA modification
Small Cajal body-specific RNA	scaRNA	splicesome modification
Small nuclear RNA	snRNA (∼60-300 nt)	RNA splicing
Guide RNA	gRNA	RNA editing
	Small ncRNAs (<200 nt)	
MicroRNA	miRNA (∼19-24 nt)	RNA silencing
Small interfering RNA	siRNA (∼21-22 nt)	RNA silencing
Piwi interacting RNA	piRNA (∼26-31 nt)	Transposon silencing, epigenetic regulation
Tiny transcription initiation RNA	tiRNA (∼17-18 nt)	Transcriptional regulation?
Promoter-associated short RNA	PASR (∼22-200 nt)	*unknown*
Transcription start site antisense RNA	TSSa-RNA (∼20-90 nt)	Transcriptional maintainence?
Termini-associated short RNA	TASR	*not clear*
Antisense termini associated short RNA	aTASR	*not clear*
Retrotransposon-derived RNA	RE-RNA	*not clear*
3'UTR-derived RNA	uaRNA	*not clear*
x-ncRNA	x-ncRNA	*not clear*
Small NF90-associated RNA	snaR	*not clear*
Unusually small RNA	usRNA	*not clear*
Vault RNA	vtRNA	*not clear*
Human Y RNA	hY RNA	*not clear*
	Long ncRNAs (≥200 nt)	
Large intergenic ncRNA	lincRNA	Epigenetics regulation
Transcribed ultraconserved regions	T-UCR	miRNA regulation?
Pseudogenes	*none*	miRNA regulation?
Promoter upstream transcripts	PROMPT	Transcriptional activation?
Telomeric repeat-containing RNA	TERRA	telomeric heterochromatin maintenance
GAA-repeat containing RNA	GRC-RNA	*not clear*
Enhancer RNA	eRNA	*not clear*
Long intronic ncRNA	*none*	*not clear*
Antisense RNA	aRNA	*not clear*
Promoter-associated long RNA	PALR	*not clear*
Stable excised intron RNA	*none*	*not clear*
Long stress-induced non-coding transcripts	LSINCT	*not clear*

13.1.2 Small ncRNA

在过去的几十年里，已有多种小非编码RNA种类得到深入研究。所有这些种类要么参与RNA翻译（转移RNA（tRNA）），要么参与RNA修饰和加工（小核仁RNA（snoRNA）和小核RNA（snRNA））。特别地，snoRNA（分为两大类：C/D盒和H/ACA盒，分别参与甲基化和假尿苷化）定位于核仁，并参与rRNA的加工和修饰。另一组小ncRNA是snRNA，它们与其他蛋白质以及彼此相互作用，形成用于RNA剪接的剪接体。值得注意的是，这些snRNA会被另一组小ncRNA——小卡哈尔体特异性RNA（scaRNA）修饰（甲基化和假尿苷化），后者在序列、结构和功能上与snoRNA相似，并定位于细胞核中的卡哈尔体。在另一类小ncRNA中，指导RNA（gRNA）已在锥虫类中主要被证明参与RNA编辑。最近还提出了许多其他类别（见表13.1），尽管它们的功能作用仍有待确定。近年来 perhaps 研究最广泛的ncRNA是微小RNA（miRNA），其参与基因沉默，并负责调控超过60%的蛋白质编码基因[6]。鉴于过去几年中大量工作集中于RNAi，以及由此出现的广泛基于RNAi的应用，下一节（RNA干扰）将完全致力于这一主题。

13.1.3 Long ncRNA

长链非编码RNA（lncRNA）构成了非编码RNA的最大部分[6]。然而，对长链非编码RNA研究的重视直到近年来才得以实现。因此，这一非编码RNA家族的术语仍处于初级阶段，且在文献中往往不一致。部分复杂性还源于某些lncRNA也可作为生成短RNA的转录本。鉴于这些混淆，如前一章所讨论，lncRNA被任意定义为长度大于200个核苷酸的非编码RNA（基于RNA纯化方案的截断值），并可大致分类为：正义、反义、双向、内含子或基因间[19]。例如，一类被称为长链基因间非编码RNA（lincRNA）的lncRNA专门存在于基因间区域，并具有表明活跃转录的染色质修饰（例如，转录起始位点的H3K4me3和整个基因区域的H3K36me3）[8]。

尽管近年来对lncRNAs的兴趣日益增长，但最早基于cDNA文库搜索发现的lncRNAs（*XIST*和*H19*）可以追溯到20世纪80年代和90年代，早于miRNAs的发现[3, 4]。随后的研究证明了lncRNAs与多梳家族蛋白的关联，暗示了lncRNAs在表观遗传基因沉默/激活中的潜在作用[19]。另一个lncRNA，*HOX Antisense Intergenic RNA (HOTAIR)*，最近被发现于转移性乳腺肿瘤中高度上调[11]。*HOTAIR*与多梳复合体的关联再次支持了lncRNAs在染色质重塑/表观遗传调控（无论是通过*cis*调控方式（*XIST*和*H19*），还是*trans*调控方式（例如*HOTAIR*））及疾病病因学中可能扮演的统一角色。

最近的研究还发现了*HULC*和假基因（类似于真实基因但包含阻止其翻译成功能蛋白的突变的转录本）*PTENP1*，它们可能作为诱饵与miRNA结合，从而降低miRNA的整体有效性[18, 25]。lncRNA的其他潜在作用仍有待探索。然而，越来越清楚的是，lncRNA不太可能是转录噪声的结果，而可能在细胞过程的控制中发挥关键作用。

13.2 RNA Interference

RNA干扰是近代最重大、最令人兴奋的发现之一。这一发现的影响巨大，其应用范围从敲低和功能缺失研究，到构建具有目标基因条件性敲低的更优动物模型，再到基于RNAi的大规模筛选以助力药物发现。

13.2.1 History of discovery

基因沉默现象的发现可以追溯到20世纪90年代，当时Napoli和Jorgensen展示了在植物中引入外源转基因后，查尔酮合成酶的下调[17]。随后，在其他系统中也观察到了类似的抑制现象[10, 22]。在当时的另一组不相关研究中，Lee等人在遗传筛选中发现，内源性*lin-4*表达了一种非蛋白质编码产物，该产物与lin-14基因互补，并控制着*C. elegans*中幼虫发育的时间（从第一龄到第二龄）[15]。我们现在知道这是第一个被发现的miRNA。2000年，在同一生物体中发现了另一个miRNA，*let-7*，并发现它参与促进晚期幼虫向成虫的转变[21]。Mello和Fire在1998年的开创性工作（因此获得了2006年诺贝尔奖）证明了在*C. elegans*中引入外源dsRNA通过RNA干扰特异性沉默基因，解释了先前在植物中观察到的抑制现象[7]。随后的研究发现了RNAi途径中dsRNA向siRNA的转化。2001年，miRNA这一术语以及miRNA与RNAi之间的联系在三篇发表于*Science*的论文中被描述[23]。至此，我们逐渐认识到基因调控机制主要由两类小RNA组成，其中miRNA参与内源基因的调控，而siRNA参与针对病毒核酸、转座子和转基因的防御[5]。后续工作揭示了下游效应因子：Dicer酶（用于前体物种的切割）和Argonaute蛋白（RNA诱导沉默复合体的组成部分，执行实际的沉默效应），从而完善了我们目前对RNA沉默途径的理解。该机制的细节以及物种间的差异将在下文进一步讨论。

13.2.2 Biogenesis pathways

siRNA介导和miRNA介导的沉默机制涉及一个共同主题。在siRNA和miRNA的生物发生过程中，双链前体被RNase切割成短的~22 nt片段。其中一条链（引导链）被加载到Argonaute蛋白中，这是较大的核糖核蛋白复合体RISC的核心组分，该复合体促进靶RNA的识别和沉默。沉默机制要么是切割靶mRNA，要么是翻译抑制。

除这一共同主题外，参与这些过程的蛋白质在不同物种间存在差异，并且在miRNA成熟并整合入RISC之前，其加工过程中还存在额外的步骤（图13.1）。对于siRNA的生物发生，前体是双链RNA，通常来源于外源性来源，如病毒或转座子。然而，近期研究也发现了内源性siRNA [9]。无论来源如何，这些双链RNA均由RNase III内切酶Dicer加工成~22 nt的siRNA。这种RNase III催化的切割留下了特征性的5’磷酸和2 nt的3’突出端 [2]。值得注意的是，不同物种进化出了不同数量的旁系同源物。这一点变得重要，因为正如后文将要讨论的，miRNA生物发生途径也利用Dicer来加工miRNA前体（更具体地说是pre-miRNA）。对于像*D. melanogaster*这样的物种，存在两种不同的Dicer蛋白，因此通常会对前体进行优先加工（例如，Dicer-1负责miRNA切割，Dicer-2负责siRNA切割）[5]。相比之下，哺乳动物和线虫仅有一种Dicer蛋白，因此两种生物发生途径汇聚到相同的加工步骤 [5]。在随后的步骤中，

siRNA生物发生途径中，siRNA双链体的一条链被加载到RISC中，以沉默目标RNA（图13.1C）。

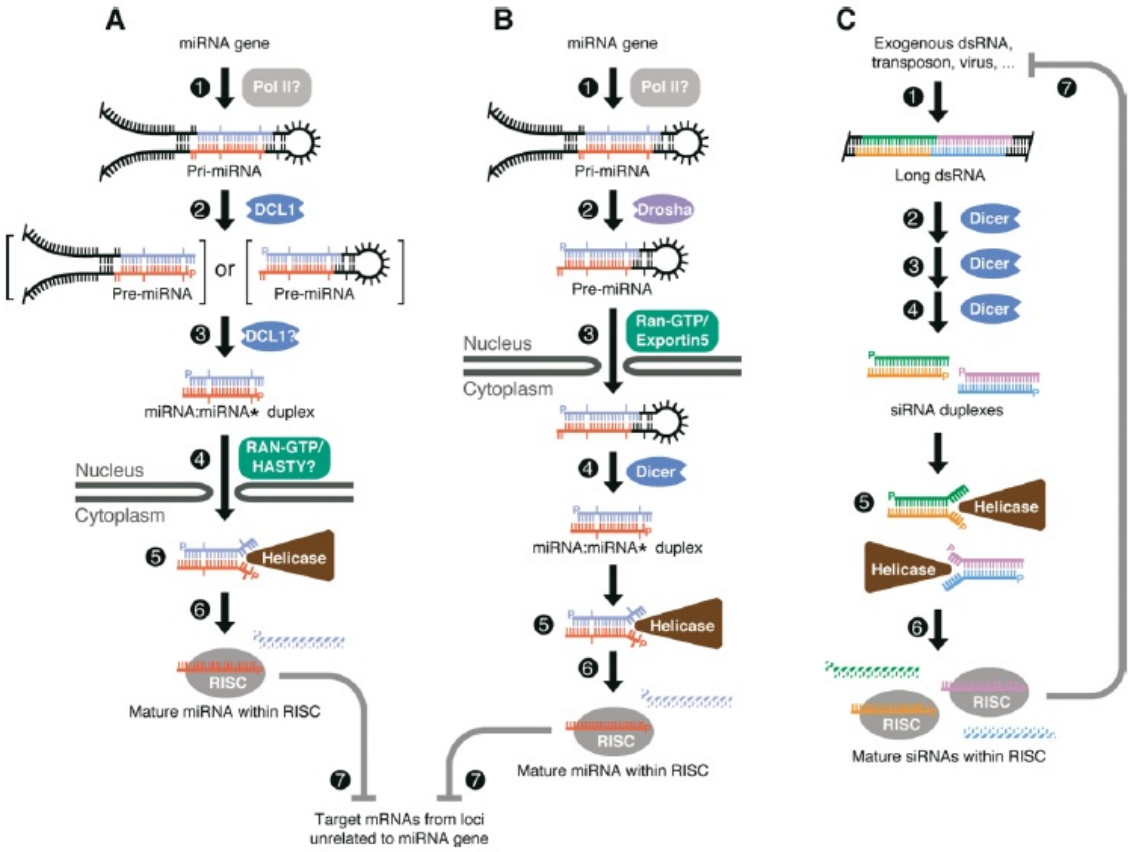

Courtesy of Elsevier, Inc., http://www.sciencedirect.com. Used with permission.
Source: Bartel, David P. "MicroRNAs: Genomics, Biogenesis, Mechanism, and Function." *Cell* 116, no. 2 (2004): 281-97.

图13.1：siRNA和miRNA生物合成途径。（A）植物miRNA的生物合成（B）动物miRNA的生物合成（C）动物siRNA的生物合成。改编自Bartel，2004（参考文献[2]）。版权所有©2004 Cell Press。

在miRNA生物发生途径中，大多数前体是内含子区域的pol II转录本，其中一些以簇形式编码多个miRNA。这些前体以茎环结构的形式存在，被称为pri-miRNAs。pri-miRNAs首先在细胞核中被RNase III内切酶（动物中的Drosha和植物中的Dcl1）切割成~60-70 nt的茎环中间体，称为pre-miRNAs[2]。在动物中，pre-miRNA随后由Exportin-5输出到细胞质中。接着，pre-miRNA中间体被Dicer切割以移除茎环。成熟miRNA双链中的一条链被装载到RISC上，类似于siRNA生物发生中描述的过程（图13.1B）。有趣的是，在植物中，pri-miRNA在细胞核中通过同一酶Dcl1的两次切割加工成成熟miRNA，然后输出到细胞质中进行装载（图13.1A）。

13.2.3 Functions and silencing mechanism

基于早期miRNA发现的经典miRNA功能观点，一直类似于一个二元开关，即miRNA通过抑制少数关键mRNA靶标的翻译来启动发育过程。

转变。然而，后续研究大大拓宽了这一定义。在植物中，大多数miRNA以近乎完美的互补性与mRNA的编码区结合。另一方面，动物miRNA以部分互补性（除种子区域，即第2-8位残基外）与mRNA的3'非翻译区结合。因此，在动物中，单个miRNA可能潜在有数百个靶标，而非仅有几个[1]。此外，在哺乳动物中，只有一小部分预测靶标参与发育，其余预测靶标则涵盖广泛的分子和生物学过程[2]。最后，miRNA沉默通过翻译抑制和mRNA切割（以及如下文所讨论的去稳定化）两种方式起作用（例如Bartel及其同事展示的miR-196引导的*HOXB6*切割[26]）。综上所述，关于miRNA功能的现代观点认为，miRNA通过抑制许多mRNA靶标的表达来优化表达、强化细胞身份并锐化转变。

miRNA介导靶mRNA沉默的机制仍是一个活跃的研究领域。如前所述，RNA沉默可以采取切割、去稳定化（导致mRNA随后降解）或翻译抑制的形式。在植物中，已发现RNA沉默的主要模式是通过Argonaute催化的切割。然而，在动物中，这些不同沉默模式的贡献尚不明确。Bartel团队与Gygi、Ingolia和Weissman合作进行的近期全局分析为这一问题提供了线索。在2008年的一项研究中，Bartel和Gygi团队利用质谱技术检测了miRNA引入或缺失后蛋白质水平的全局变化[1]。他们的结果揭示了个别miRNA对数百个基因的抑制，更重要的是，mRNA去稳定化构成了大多数高度受抑制靶标的主要机制（图13.2）。

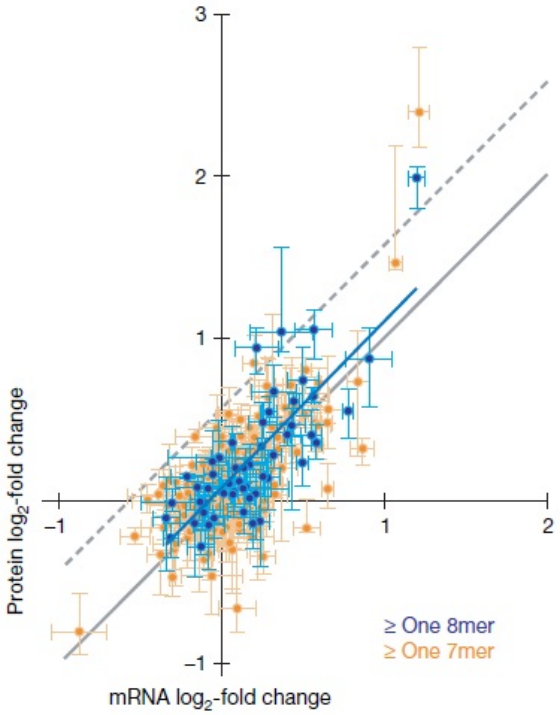

Courtesy of Macmillan Publishers Limited. Used with permission.
Source: Baek, Daehyun, et al. "The Impact of MicroRNAs on Prote在
Output." *Nature* 455, no. 7209 (2008): 64-71.

图13.2：miR-223缺失后，具有至少一个8-mer 3’ UTR位点（蓝色）或至少一个7-mer（橙色）的mRNA对应的蛋白质和mRNA变化。改编自Baek等人，2008年（参考文献[1]）。版权所有 © 2008 Macmillan Publishers Limited。

随后一项同时使用RNA-seq和一种新型核糖体图谱分析的研究进一步支持了这一点，该技术由Inoglia和Weissman于2009年首次展示，使得能够探究全局翻译活动。

在亚密码子分辨率下[14]。结果表明，目标mRNA的不稳定化是miRNA减少蛋白质输出的主要机制。

Bibliography

[1] Daehyun Baek, Judit Villén, Chanseok Shin, Fernando D Camargo, Steven P Gygi, 和 David P Bartel. microRNA对蛋白质产出的影响. *Nature*, 455(7209):64–71, 2008年9月.

[2] David P Bartel. MicroRNAs：基因组学、生物发生、机制和功能。*Cell*, 116(2):281–97, January 2004.

[3] M S Bartolomei、S Zemel 和 S M Tilghman。小鼠H19基因的亲本印记。*Nature*, 351(6322):153–5, 1991年5月。

[4] C J Brown, A Ballabio, J L Rupert, R G Lafreniere, M Grompe, R Tonlorenzi, and H F Willard. 来自人类X染色体失活中心区域的一个基因仅从失活的X染色体表达。*Nature*, 349(6304):38–44, 1991年1月。

[5] Richard W Carthew 和 Erik J Sontheimer. miRNA 和 siRNA 的起源与机制. *Cell*, 136(4):642–55, 2009年2月. [6] Manel Esteller. 人类疾病中的非编码RNA. *Nature Reviews Genetics*, 12(12):861–874, 2011年11月. [7] A Fire, S Xu, M K Montgomery, S A Kostas, S E Driver, 和 C C Mello. 双链RNA在秀丽隐杆线虫中的强效特异性基因干扰. *Nature*, 391(6669):806–11, 1998年2月. [8] Ewan a Gibb, Carolyn J Brown, 和 Wan L Lam. 长非编码RNA在人类癌症中的功能作用. *Molecular cancer*, 10(1):38, 2011年1月. [9] Daniel E Golden, Vincent R Gerbasi, 和 Erik J Sontheimer. siRNA的内部作用. *Molecular cell*, 31(3):309–12, 2008年8月.

[10] S Guo 和 K J Kemphues。par-1，一种在秀丽隐杆线虫胚胎中建立极性所需的基因，编码一种不对称分布的推定Ser/Thr激酶。*Cell*，81(4)：611–20，1995年5月。

[11] Rajnish A Gupta, Nilay Shah, Kevin C Wang, Jeewon Kim, Hugo M Horlings, David J Wong, Miao- Chih Tsai, Tiffany Hung, Pedram Argani, John L Rinn, Yulei Wang, Pius Brzoska, Benjamin Kong, Rui Li, Robert B West, Marc J van de Vijver, Saraswati Sukumar, and Howard Y Chang. 长链非编码RNA HOTAIR重编程染色质状态以促进癌症转移。*Nature*, 464(7291):1071–6, April 2010. [12] Masahira Hattori. 完成人类基因组的常染色质序列。*Nature*, 431(7011):931–45, October 2004. [13] Christopher L Holley and Veli K Topkara. 小非编码RNA简介：miRNA和snoRNA。*Cardiovascular Drugs and Therapy*, 25(2):151–159, 2011. [14] Nicholas T Ingolia, Sina Ghaemmaghami, John R S Newman, and Jonathan S Weissman. 使用核糖体图谱技术以核苷酸分辨率在体内全基因组范围内分析翻译。*Science (New York, N.Y.)*, 324(5924):218–23, April 2009. [15] R C Lee, R L Feinbaum, and V Ambros. 秀丽隐杆线虫异时基因lin-4编码与lin-14反义互补的小RNA。*Cell*, 75(5):843–54, December 1993. [16] Michael L Metzker. 测序技术——下一代。*Nature Reviews Genetics*, 11(1):31– 46, January 2010.

[17] C. Napoli、C. Lemieux 和 R. Jorgensen。将嵌合查尔酮合酶基因引入矮牵牛导致同源基因的反式可逆共抑制。*The Plant cell*，2(4)：279–289，1990年4月。[18] Laura Poliseno、Leonardo Salmena、Jiangwen Zhang、Brett Carver、William J Haveman 和 Pier Paolo Pandolfi。基因和假基因mRNA的编码非依赖性功能调节肿瘤生物学。*Nature*，465(7301)：1033–8，2010年6月。[19] Chris P Ponting、Peter L Oliver 和 Wolf Reik。长非编码RNA的进化与功能。*Cell*，136(4)：629–41，2009年2月。[20] J. R. Prensner 和 A. M. Chinnaiyan。lncRNAs在癌症生物学中的出现。*Cancer Discovery*，1(5)：391–407，2011年10月。[21] B J Reinhart、F J Slack、M Basson、A E Pasquinelli、J C Bettinger、A E Rougvie、H R Horvitz 和 G Ruvkun。21个核苷酸的let-7 RNA调节秀丽隐杆线虫的发育时序。*Nature*，403(6772)：901–6，2000年2月。[22] N Romano 和 G Macino。Quelling：通过同源序列转化导致粗糙脉孢菌基因表达的瞬时失活。*Molecular microbiology*，6(22)：3343–53，1992年11月。[23] G Ruvkun。分子生物学。微小RNA世界的瞥见。*Science*，294(5543)：797–9，2001年10月。[24] Ryan J Taft、Ken C Pang、Timothy R Mercer、Marcel Dinger 和 John S Mattick。非编码RNA：疾病的调节者。*The Journal of pathology*，220(2)：126–39，2010年1月。[25] Jiayi Wang、Xiangfan Liu、Huacheng Wu、Peihua Ni、Zhidong Gu、Yongxia Qiao、Ning Chen、Fenyong Sun 和 Qishi Fan。CREB通过与非编码RNA microRNA-372相互作用上调肝癌中长非编码RNA HULC的表达。*Nucleic acids research*，38(16)：5366–83，2010年9月。[26] Soraya Yekta、I-Hung Shih 和 David P Bartel。MicroRNA引导的HOXB8 mRNA切割。*Science*，304(5670)：594–6，2004年4月。

Part III

Gene and Genome Regulation

CHAPTER

FOURTEEN

用于表达分析和转录本发现的mRNA测序

Manuel Garber 的客座讲座

Figures

14.1 图1：表达微阵列流程 . . . . . 220 14.2 将读取映射到参考基因组的间隔k-mer方法 . . . . . 221 14.3 框1：我们如何计算qMS？ . . . . . 222 14.4 图3：重建工作是通过确定在特定窗口内观察到该数量读取（左上角）的概率，给定总读取的均匀分布（左下角）。此概率遵循泊松分布。 . . . . . 222 14.5 图4：基于读取使用扫描分布重建基因组的过程 . 223 14.6 图5：替代异构体为重建带来挑战，必须依赖于跨越外显子连接点的读取 . . . . . 223 14.7 框2：Scripture方法 224

14.1 Introduction

mRNA测序（RNA-seq）的目的是测量给定细胞中每个基因的mRNA转录本水平。mRNA测序是一项艰巨的任务，需要大约4000万个比对读数才能准确测量mRNA转录本。直到2009年，当下一代测序技术变得更加先进和高效时，这才成为可能。

在本章中，我们将探讨利用mRNA测序数据辅助基因和转录本发现以及表达分析的不同技术。

14.2 Expression Microarrays

在mRNA测序技术发展之前，mRNA水平是通过表达微阵列来测量的。这些微阵列的工作原理是在玻片上插入DNA探针，并测量与DNA进行互补杂交的转录本水平，这一过程可以逐个基因地分析表达情况(图1)。

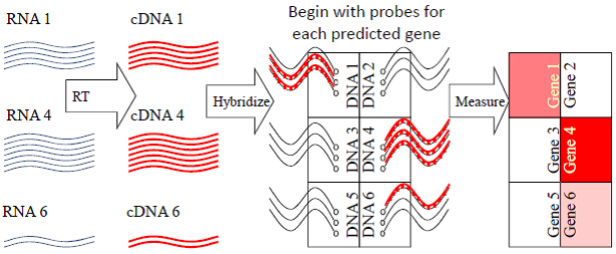

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图14.1：图1：表达谱微阵列流程

然而，该技术存在一些局限性：它无法区分mRNA异构体，无法在序列或数字层面上进行分析，只能测量已知的转录本，并且对于高度饱和的转录本水平，其表达测量结果变得不太可靠。

14.3 The Biology of mRNA Sequencing

mRNA测序的第一步是裂解目标细胞。这会释放出大量蛋白质、核苷酸和其他分子，随后经过滤，只保留RNA（或特异性mRNA）分子。接着，将所得的转录本片段化为长度200-1000碱基对的读段，并进行逆转录反应，构建链特异性DNA文库。最后，对这些DNA片段的两端进行测序。在获得这些测序读段后，RNA-Seq的计算部分可分为三个部分：读段比对、重构和定量。

14.4 Read Mapping - Spaced Seed Alignment

读映射的核心思想是将测序读段比对到参考基因组上。由于问题的规模，前几章讨论的序列比对算法在这种情况下并不适用。目标是将数百万条读段比对到基因组上，如果逐个比对每条读段，将耗时过长。因此，我们将引入间隔种子比对方法。该过程首先利用参考基因组构建一个8-mer的哈希表，这些8-mer不必是连续的。这些存储的间隔种子的位置被映射到哈希表中。然后，利用这些间隔的8-mer，将每条读段与参考基因组中每个可能的位置进行比较，并根据碱基对匹配的数量进行评分（图2）。

更准确地说，对于每个位置，可以使用方程 $q_{MS} = -10 \log_{10}(1 - P(i|G, q))$ 计算得分，其中 $P(i|G, q)$ 表示读段 q 映射到参考基因组 G 的位置 i 的概率。有关推导此得分的更多细节可在图13.2中找到。

可以调整该方法的参数，以改变灵敏度、速度和内存。

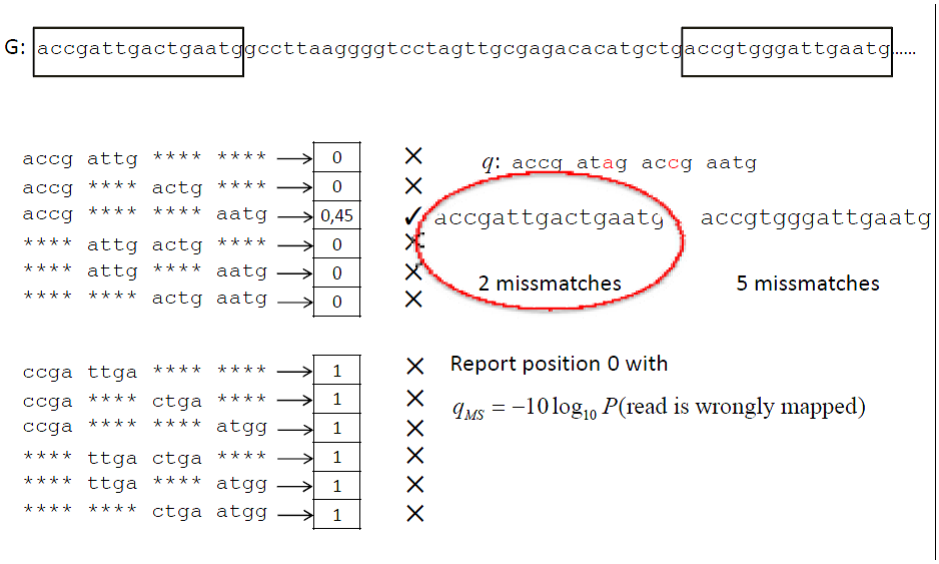

图14　　.2：将读段映射到参考基因组g的间隔k-mer方法　　基因组

算法的部分。使用较小的k-mer种子允许不太精确的碱基配对匹配（更高的灵敏度），但需要尝试更多的匹配。较小的种子占用较少的内存，而较大的种子运行更快。

除了上述方法外，还存在其他进行此对齐的方法。其中最流行的是Burrows-Wheeler方法。Burrows-Wheeler变换是一种更高效的读取映射算法，将在后续章节中讨论。它能够通过对基因组进行非常特定的排列来加速在庞大基因组中查找匹配项的过程。这使得读取匹配仅取决于读取长度，而与基因组无关。随着更先进的测序技术使得读取长度增加，将需要开发更多算法来处理额外的处理工作。

与ChIP-Seq类似的技术相比，RNA-seq更为复杂。这是因为读取映射器需要处理散布在大内含子之间的小外显子，并能找到外显子的两侧。这种复杂性可以通过使用上述的间隔种子匹配技术来克服，并检测同一读取中的两个k-mer是否被长距离分隔。这将指示可能存在内含子，并可通过扩展k-mer填补间隙（SNO方法）来修正。另一种方法是基于连续读取进行对齐，这些读取进一步分割成20-30 bp的区域。这些区域重新映射后，具有两个或更多不同对齐的位置被标记为剪接点。外显子优先的对齐器比之前的方法更快，但代价是：它们无法区分假基因、预剪接基因和转座基因。

14.5　Reconstruction

读段的重建在很大程度上是一个统计问题。目标是确定基因组中每个固定大小窗口的得分。该得分表示在给定窗口大小的情况下，观察到当前读段数的概率。换句话说，在给定基因组的情况下，某个特定窗口中的读段数是否不太可能？每个窗口的期望读段数基于总读段数，由均匀分布推导而来（图3）。该得分由泊松分布建模。

然而，该分数必须考虑多重假设检验的问题，因为预期大约有1.5亿个碱基。处理这个问题的一种方法是Bonferroni校正，其中名义上的

图14.3：方框1：我们如何计算qMS?

What does $q_{MS} = -10\log_{10} P(\text{read is wrongly mapped})$ mean?

Lets compute the probability the read originated at genome position i

q: accg atag accg aatg

q_s: 30 40 25 30 30 20 10 20 40 30 20 30 40 40 30 25

$q_s[k] = -10\log_{10} P(\text{sequencing error at base k})$, the PHRED score. Equivalently:

$P(\text{sequencing error at base k}) = 10^{-\frac{q_s}{10}}$

So the probability that a read originates from a given genome position i is:

$$P(q \mid G,i) = \prod_{j \text{ match}} P(q_j \text{good call}) \prod_{j \text{ missmatch}} P(q_j \text{bad call}) \approx \prod_{j \text{ missmatch}} P(q_j \text{bad call})$$

In our example

$$P(q \mid G,0) = \left[(1-10^{-3})^6 (1-10^{-4})^4 (1-10^{-2.5})^2 (1-10^{-2})^2\right]\left[10^{-1}10^{-2}\right] = [0.97]*[0.001] \approx 0.001$$

What does $q_{MS} = -10\log_{10} P(\text{read is wrongly mapped})$ mean?

$$P(q \mid G,i) = \prod_{j \text{ match}} P(q_j \text{good call}) \prod_{j \text{ missmatch}} P(q_j \text{bad call}) \approx \prod_{j \text{ missmatch}} P(q_j \text{bad call})$$

But what we need is the posterior probability, the probability that the region starting at i was sequenced *given* that we observed the read q:

$$P(i \mid G,q) = \frac{P(q \mid G,i)P(i \mid G)}{P(q \mid G)} = \frac{P(q \mid G,i)P(i \mid G)}{\sum_j P(q \mid G,j)}$$

Fortunately, there are efficient ways to approximate this probability (see Li, H *genome Research* 2008, for example)

$$q_{MS} = -10\log_{10}(1 - P(i \mid G,q))$$

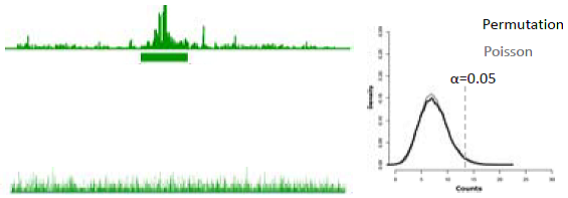

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图14.4：图3：重构工作通过确定在特定窗口内，鉴于总读取数的均匀分布（左下），观察到该读取数（左上）的概率。此概率遵循泊松分布。

p值 = n * p值。由于其非常保守的性质，这种方法导致灵敏度较低。另一种选择是对基因组中观察到的reads进行排列，并找出单个碱基上观察到的最大reads数。这允许建立一个最大计数分布模型，但该过程非常缓慢。扫描分布通过计算最大计数分布的闭式解来加速这一过程，以考虑重叠窗口的依赖性（图4）。在大小为L的基因组中，给定总reads数为N，在大小为w的窗口上观察到k个reads的概率可以近似为[幻灯片不清晰]。

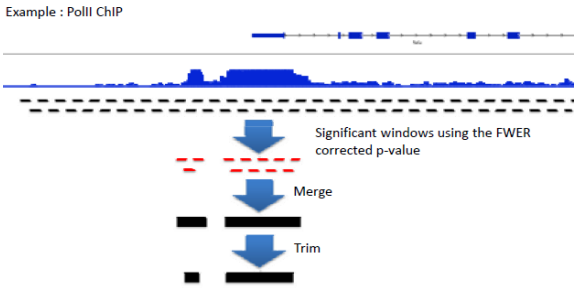

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图14.5：图4：基于reads并使用扫描分布重建基因组的流程

选择窗口大小也是一个重要决策，因为基因存在于不同的表达水平，且跨越不同的数量级。小窗口更擅长检测点状区域，而较大的窗口能够检测到较长的适度增强区域。在大多数情况下，使用不同大小的窗口来捕捉不同规模的信号。

转录本重建可以被视为一个分割问题，面临若干挑战。如上所述，基因的表达水平不同，跨越几个数量级。此外，用于重建的读数来自成熟和未成熟的mRNA，后者仍含有内含子。最后，许多基因具有多种异构体，而读数的短小特性使得区分这些不同的转录本变得困难。一种名为Scripture的计算工具利用片段连接性的先验知识来检测转录本。

替代异构体只能通过跨越外显子连接处的读段来检测，这些读段包含外显子的末端。较长的读段更有可能跨越这些连接处（图5）。Scripture通过使用图结构对读段进行建模来工作，其中碱基与邻近碱基以及剪接邻近碱基相连。这一过程与字符串图技术不同，因为它关注整个基因组，并且不直接映射重叠序列。当滑动窗口时，Scripture可以跳过剪接连接处，同时仍然检查替代异构体。从这个有向连通图中，程序识别出图中的片段，并寻找显著的片段（框2）。

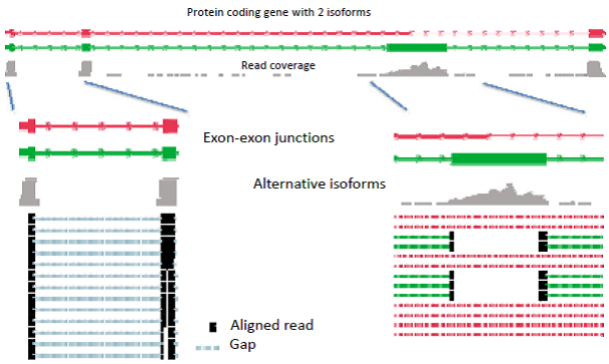

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图14.6：图5：可变剪接异构体给重建带来挑战，重建必须依赖于跨越外显子连接处的读段

直接转录本组装是另一种重建方法（与Scripture等基因组引导方法相对）。转录本组装方法能够从没有参考序列的生物体中重建转录本，而基因组引导方法则非常适合用于注释高质量基因组和扩展表达转录本的目录。混合方法用于质量较低的转录本或经历了重大重排的转录组，例如癌细胞的转录组。流行的转录本

组装工具包括Oasis、Trans-ABySS和Trinity。另一款流行的基因组引导软件是Cuf-flinks。无论采用何种方法或软件类型，任何产生更多基因组覆盖度的测序实验都将获得更好的转录本重建效果。

图14.7：框2：经文方法

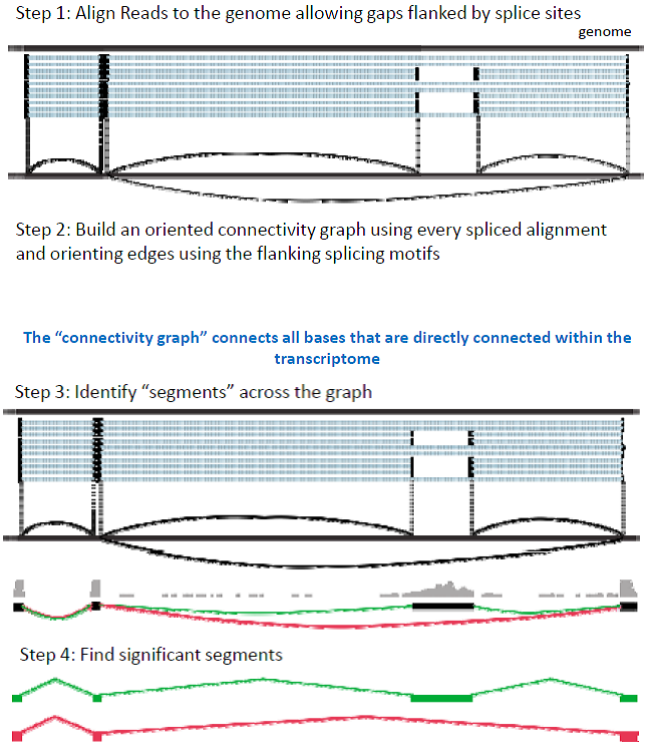

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

14.6 Quantification

定量步骤的目标是根据读取数对基因组中的区域进行评分。回想一下，每个转录本会被片段化成许多较小的读取。因此，仅仅计算每个区域的读取数是不够的，因为这个值会受到（1）表达率和（2）转录本长度的影响。转录本的表达率越高，我们获得的读取数就越多。同样，转录本越长，我们获得的读取数也越多。这个问题可以通过将读取数按转录本长度和实验中的总读取数进行归一化来解决。这提供了RPKM值，即每百万映射读取中每千碱基外显子序列的读取数。

该方法对只有一个同种型（isoform）的基因是稳健的。然而，转录本的冲突变异之间可能存在重叠。当涉及多个转录本变异时，这个问题被称为差异表达分析。有几种不同的方法来处理这种复杂性。外显子交集模型仅对组成外显子进行评分。外显子并集模型简单地基于合并的转录本进行评分，但容易因各同种型的相对比例而产生偏差。一个更全面的模型是转录本表达模型，它将唯一reads分配给不同的同种型。

CHAPTER

FIFTEEN

基因调控1——基因表达聚类

Ge Liu(2015) Shau-Chieh Hsu (2015) Franck Der noncourt (2012) Arvind Thiagarajan (2011) Tahin Syed (2010) Barrett Steinberg 和 Brianna Petrone (2009) Mia Y. Qia (2008)

Figures

15.1 聚类与分类的比较。在聚类中，我们根据观测值彼此之间的接近程度将其分组到聚类中。在分类中，我们希望有一个能够准确为新点分配标签的规则。. . . . . 226 15.2 来自微阵列实验的基因表达值可以表示为热图，以可视化数据分析的结果。. . . . . 228 15.3 RNA-Seq读段映射到一个基因（*c-fos*）及其剪接连接点。沿外显子的密度表示映射到外显子的读段密度（以$\log_{10}$表示），弧线对应连接点读段，其中弧线宽度与该连接点中的读段数量成比例绘制。与样本1相比，该基因在样本2中下调。. . . . . 228 15.4 将图4转换为热图 . . . . . 229 15.5 以对数值表示的基因表达水平与参考样本的比较 . . . . . 229 15.6 基因表达值的样本矩阵，表示为热图并带有层次聚类。[1] . . . . . 230 15.7 使用基因表达矩阵推断更多关于疾病和基因区段的信息 . . . . . 230 15.8 k均值聚类算法 . . . . . 231 15.9 模糊k均值使用$k = 4$的最终聚类分配示例，其中质心、正确聚类和最可能分配的聚类分别用叉号、点的形状和颜色标记。注意，原始数据集是非高斯分布。. . . . . 232 15.10K-Means作为生成模型。样本从正态分布中抽取。. . . . . 233 15.11K-Means作为期望最大化（EM）算法。. . . . . 234 15.12聚类、HMM和模体发现相对于期望最小化（EM）算法的比较。. 234

15.13层次聚类 . . . . . 236 15.14层次聚类的距离度量。从左上角顺时针方向：最小距离、最大距离、平均距离和质心距离。 . . . . . 236 15.15计算在随机选择的聚类中拥有超过r +个的概率。 . 237

15.1 Introduction

在本章中，我们探讨在大型数据集中识别相似性或模式的问题。发现这类数据集中的结构，使我们能够就观测背后的过程及结构得出结论。我们通过应用聚类技术来解决这一问题。下一章将聚焦于分类技术。

15.1.1 Clustering vs Classification

早期需要进行的一个重要区分是分类与聚类之间的差异。**Clas- sification** 是在包含类别归属已知的观测或实例的训练数据集基础上，识别一个新观测属于一组类别（子群体）中哪一个的问题。训练集用于学习能够准确地将标签分配给新观测的规则。难点在于找到最重要的特征（特征选择）。

在机器学习的术语中，分类被视为监督学习的一个实例，即利用一组正确标识的观测数据进行训练的学习过程。相应的无监督过程称为**clustering**或聚类分析，它涉及根据某种内在相似度度量将数据分组到不同类别中，例如将实例视为多维向量空间中的向量并计算它们之间的距离。难点在于识别数据的结构。图15.1展示了聚类与分类之间的区别。

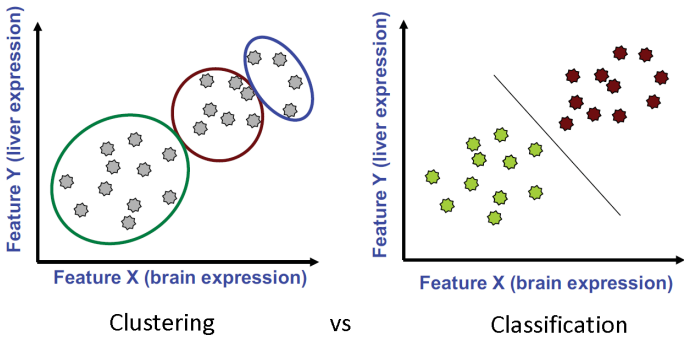

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 htt p://ocw.mit.edu/help/faq-fair-use/。

图15.1：聚类与分类的比较。在聚类中，我们根据观测值之间的接近程度将它们分组为簇。在分类中，我们希望有一个能够准确地将标签分配给新点的规则。

15.1.2 Applications

聚类最初是在人工智能领域发展起来的。能够对相似对象进行分组，并充分体现其所蕴含的普遍性含义，确实是人工智能非常理想的一项属性，也是人类在一生中经常执行的一种能力。随着聚类算法的不断发展，很快就变得很清楚：将这些算法应用于越来越大的数据集并不存在内在障碍。这一认识促使聚类被迅速引入计算生物学以及其他处理大型数据集的领域。

聚类在计算生物学中有许多应用。例如，考虑在许多发育阶段采集的许多基因的表达谱。聚类可能显示某些基因集在各个阶段排列一致（即显示出相同的表达水平）。这可能表明这组基因具有共同的表达或调控，我们可以利用这一点来推断相似的功能。此外，如果我们在这样一组基因中发现一个未表征的基因，我们可以通过关联推定该未表征的基因也具有相似的功能。

染色质标记和调控基序可以以类似的方式用于预测调控因子与靶基因之间的逻辑关系。这类分析使得构建能够预测基因表达的模型成为可能。这些模型可用于修改特定基因的调控特性、预测疾病状态是如何产生的，或帮助基于相关器官细胞中的调控回路将基因靶向到特定器官。

计算生物学涉及日益庞大且开放获取的数据集。ENCODE项目[2]便是这样一个例子。该项目于2003年启动，目标是构建人类基因组中功能元件的全面清单，包括在蛋白质和RNA水平上发挥作用的元件，以及控制细胞和基因活跃环境的调控元件。ENCODE数据现已针对整个人类基因组免费且即时提供：`http://genome.ucsc.edu/ENCODE/`。利用所有这些数据，可以通过聚类对基因进行功能预测。

15.2 Methods for Measuring Gene Expression

研究某种表型最直观的方法是测量细胞在特定时间存在的功能蛋白的表达水平。然而，测量蛋白质浓度可能很困难，因为蛋白质的位置、修饰和所处的环境各不相同，而且蛋白质组也不完整。然而，mRNA表达水平更容易测量，通常是一个很好的近似。通过测量mRNA，我们分析了转录水平的调控，而不需要额外考虑翻译调控和活跃的蛋白质降解带来的复杂性，这简化了分析，但代价是丢失了信息。在本章中，我们将考虑两种生成基因表达数据的技术：微阵列和RNA-seq。

15.2.1 Microarrays

微阵列技术能够在一次实验中分析数千个预选基因的表达水平。微阵列背后的基本原理是互补DNA片段的杂交。首先，将称为探针的短DNA片段附着在固体表面，通常称为基因芯片。然后，从细胞中提取的目标RNA群体通过逆转录酶逆转录为cDNA（互补DNA），该酶利用poly-A尾巴作为引物从RNA合成DNA。对于没有poly-A尾巴的基因间序列，可以将标准引物连接到末端。

mRNA的。所得DNA与载玻片上的DNA互补性高于RNA。随后，将cDNA洗涤过芯片，由此产生的杂交触发探针发出荧光。这一现象可被检测以确定目标中mRNA的相对丰度，如图15.2所示。

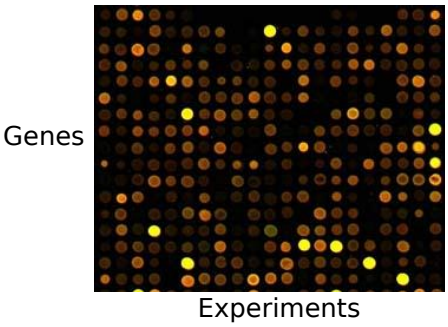

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 htt
p://ocw.mit.edu/help/faq-fair-use/。

图15.2：来自微阵列实验的基因表达值可以表示为热图，以可视化数据分析的结果。

目前使用两种基本类型的微阵列。Affymetrix基因芯片为每个基因设置一个斑点，并具有数百个核苷酸数量级长度的较长探针。另一方面，点样寡核苷酸阵列则对基因进行平铺，并具有约几十个碱基的较短探针。

当前方法中存在众多误差来源，未来的方法力求去除流程中的步骤。例如，逆转录酶可能引入错配，从而削弱与正确探针的相互作用或导致交叉杂交，或与多个探针结合。针对这一问题的一种解决方案是每个基因使用多个探针，因为每个基因的交叉杂交情况会有所不同。尽管如此，由于RNA的二级结构，逆转录仍是必需的。DNA的结构稳定性使其不太可能弯曲而不与探针杂交。下一代技术，如RNA-Seq，对从细胞中出来的RNA进行测序，本质上探测基因组的每一个碱基。

15.2.2 RNA-seq

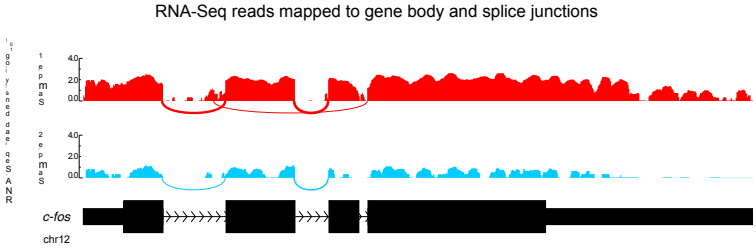

© source unknown. All rights reserved. This content is excluded from our Creative
Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/。

图15.3：RNA-Seq读数映射到一个基因（*c-fos*）及其剪接接头。外显子上的密度表示映射到外显子的读数密度（以对数$_{10}$表示），弧线对应接头读数，其中弧线宽度与接头中的读数数量成比例。与样本1相比，该基因在样本2中表达下调。

RNA-Seq，也称为全转录组鸟枪法测序，试图实现过去DNA微阵列所执行的功能，但具有更高的分辨率。特别是，DNA微阵列利用特定探针，而这些探针的创建必然依赖于对基因组以及所生产阵列大小的先验知识。RNA-seq通过简单地对微阵列实验中产生的所有cDNA进行测序，消除了这些限制。这是通过下一代测序实现的

技术。该技术已在癌症等疾病的研究中被迅速采用[4]。随后，RNA-seq数据通过聚类分析，其方式与通常分析微阵列数据相同。

15.2.3 Gene Expression Matrices

微阵列和RNA-seq常用于比较不同条件下细胞的基因表达谱。这些实验产生的数据量是巨大的。微阵列可以分析数千个基因，而RNA-seq原则上可以分析每一个活跃表达的基因。这些基因中每一个的表达水平都是在多种条件下测量的，包括时间过程、发育阶段、表型、健康与疾病以及其他因素。

要理解基因表达矩阵的热图（图15.4）所传达的信息，我们首先需要明白表达数据矩阵告诉我们什么。通过使用微阵列和RNA-seq技术，我们能够在实验中以定量形式获取基因表达水平。如果有多个实验，我们可以构建一个值矩阵（图15.5），表示测试样本中基因表达水平(T)与参考样本中基因表达水平(R)比值的对数值。

The Expression Matrix removed due to copyright restrictions.

图15.4：将图4转换为热力图

如果我们将矩阵可视化为热图，则得到以下新的彩色矩阵：

	Exp 1	Exp 2	Exp 3	Exp 4	Exp 5	Exp 6
Gene 1	-1.2	-2.1	-3	-1.5	1.8	2.9
Gene 2	2.7	0.2	-1.1	1.6	-2.2	-1.7
Gene 3	-2.5	1.5	-0.1	-1.1	-1	0.1
Gene 4	2.9	2.6	2.5	-2.3	-0.1	-2.3
Gene 5	0.1		2.6	2.2	2.7	-2.1
Gene 6	-2.9	-1.9	-2.4	-0.1	-1.9	2.9

图15.5：Gen　　与参考值进行对数比较的表达水平　　样本

这些矩阵可以进行层次聚类，显示基因对、对的对等之间的关系，从而生成一个树状图，其中行和列可以通过最优叶排序算法进行排序。

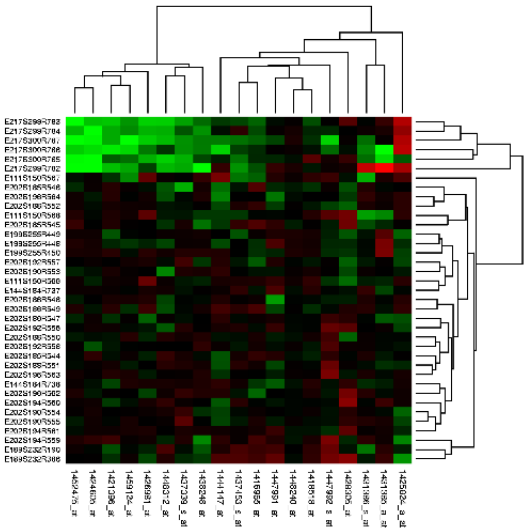

图像属于公有领域。此图是使用Michael Eisen的Cluster程序生成的，该程序可从http://rana.lbl.gov/EisenSoftware.htm获取，数据来源于基因表达数据StemBase数据库。

图15.6：一个基因表达值样本矩阵，以热图和层次聚类的方式表示。[1]

通过揭示一段长基因组隐藏的结构，我们得以深入洞察基因片段的功能，并进而更深入地理解未知疾病的根本原因。

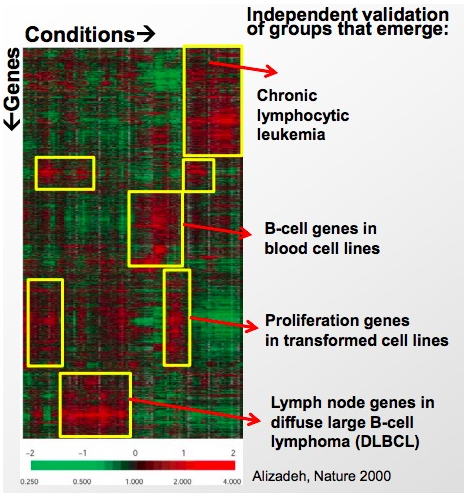

Courtesy of Macmillan Publishers Limited. Used with permission.
Source: Alizadeh, Ash A., Michael B. Eisen, et al. "Distinct Types of Diffuse Large B-cell Lymphoma Identified by Gene Expression Profiling." *Nature* 403, no. 6769 (2000): 503-11.

图15.7：利用基因表达矩阵推断更多关于疾病和基因片段的信息

这种预测和分析能力因数据双聚类的能力而增强；也就是说，沿矩阵的两个维度进行聚类。该矩阵允许比较基因的表达谱，以及比较不同条件（如疾病）的相似性。然而，一个挑战是维度灾难。随着数据空间的增加，点的聚类会减弱。有时，可以将数据降至低维空间，以使用聚类找到数据中的结构，从而根据接近程度推断哪些点属于一起。

解读数据也可能是一项挑战，因为可能还有其他生物现象在起作用。对于

例如，蛋白质编码外显子具有更高的强度，因为内含子被迅速降解。同时，并非所有内含子都是垃圾，可变剪接中可能存在模糊性。还有一些细胞机制通过无义介导的衰变来降解异常转录本。

15.3 Clustering Algorithms

为了分析基因表达数据，通常需要进行聚类分析。聚类算法有两种类型：划分式和凝聚式。划分式聚类将对象划分为互不重叠的聚类，使得每个数据对象仅位于一个子集中。另一种方法是凝聚式聚类，它产生一组嵌套的聚类，以层次结构组织，代表从较宽泛到更精细层次的细节结构。

15.3.1 *K*-Means Clustering

k-means 算法根据对象的属性将其聚类为 k 个分区，其中 n 个对象被聚类。这是一个划分的例子，其中每个点被分配给恰好一个簇，使得每个点到其相应标记中心的距离之和最小化。这一过程背后的动机是使簇尽可能紧凑，通常以欧几里得距离度量来衡量。

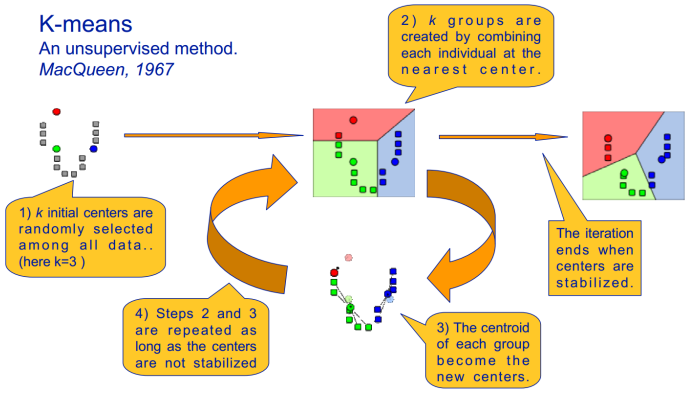

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图15.8：k-means聚类算法

k-means 算法，如图15.8所示，实现为 遵循：

1. 假设固定数量的聚类，k

2. *Initialization*：随机初始化与聚类相关的k个均值μ_k，并将每个数据点x_i分配给最近的聚类，其中x_i和μ_k之间的距离由$d_{i,k} = (x_i - \mu_k)^2$给出。

3. *Iteration*：根据分配给它的点重新计算聚类中心：$\mu_k(n+1) = \sum_x \frac{x_i}{i \in k \overline{|x^k|}}$
   其中 x_k 是标签为 k 的点数。根据给定的距离度量，将数据点重新分配给 k 个新质心。新中心实际上被计算为分配给每个簇的点的平均值。

4. *Termination*：迭代直到收敛或达到用户指定的迭代次数。请注意，迭代可能会陷入某些局部最优解。

有几种方法可以选择 k：简单地查看数据以识别潜在的聚类，或者迭代尝试 n 的值，同时对模型复杂度进行惩罚。我们总是可以通过增加 k 来获得更好的聚类，但在某个点上，我们开始对数据过拟合。

我们也可以将k均值看作试图最小化与每个聚类大小相关的成本准则，其中当聚类变得不那么紧凑时成本会增加。然而，有些点可能几乎位于两个中心之间，这与二值归属的k均值聚类不太吻合。

15.3.2 Fuzzy K-Means Clustering

在模糊聚类中，每个点都有属于每个簇的概率，而不是完全只属于一个簇。模糊k均值特别试图通过用概率替换距离来处理点有点位于中心之间或否则模糊的问题，这当然可以是距离的某个函数，例如具有相对于距离倒数的概率。模糊k均值使用基于这些概率的加权质心。初始化、迭代和终止的过程与k均值中使用的过程相同。结果簇最好分析为概率分布，而不是标签的硬分配。人们应该意识到，当使用的概率函数简单地为1，如果数据点最接近一个质心，否则为0时，k均值是模糊k均值的一个特例。

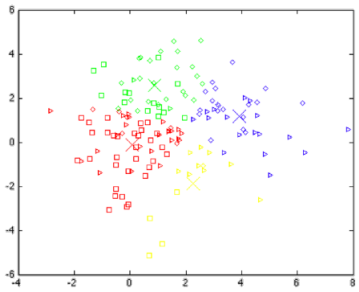

图15.9：使用k=4的模糊k-均值最终聚类分配示例，其中质心、正确聚类和最可能的分配聚类分别以十字、点形状和颜色标记。注意原始数据集是非高斯的。

模糊k均值算法如下：

1. 假设固定数量的聚类 k

2. *Initialization*：随机初始化与聚类相关的k均值μ_k，并计算每个数据点x_i属于给定聚类k的概率，P(点x_i具有标签$k|x_i, k$)。

3. *Iteration*：根据所有数据点x_i的隶属概率，将聚类的质心重新计算为加权质心：

$$\mu_k(n+1) = \frac{\sum_{x_i \in k} x_i \times P\left(\mu_k|x_i\right)^b}{\sum_{x_i \in k} P\left(\mu_k|x_i\right)^b}$$

并重新计算更新后的隶属度 $P\left(\mu \quad {}_k|x_i\right)$(有多种定义隶属度的方法，这里

仅举一例）：

$$P\left(\mu_k|x_i\right)=(\sum_{j=1}^{k}(\frac{d_{ik}}{d_{jk}})^{\frac{2}{b-1}})^{-1}$$

4. *Termination*：迭代直到隶属度矩阵收敛或达到用户指定的迭代次数（迭代可能会陷入某些局部最大值或最小值）

这里的b是加权指数，它控制着每个分区的相对权重，即模糊度。当$b->$为1时，使平方误差函数最小化的分区越来越硬（非模糊），而当$b->\infty$时，隶属度都趋近于^1，这是最模糊的状态。没有$_k$理论证据表明如何选择最优的b，而经验有效值在$[1,30]$之间，在大多数研究中，$1.5\leqslant b\leqslant 3.0$效果良好。

15.3.3 *K*-Means as a Generative Model

生成模型是一种在给定一些隐藏参数的情况下，随机生成可观测数据值的模型。生成模型是所有变量的概率模型，而判别模型仅基于观测变量提供目标变量的条件模型。

为了使 k-means 成为一种生成模型，我们现在以概率方式来看待它，其中我们假设聚类 k 中的数据点是使用均值为聚类中心、方差为1的高斯分布生成的，从而得到 $P(x_i|\mu_k)=\frac{1}{\sqrt{2\pi}}exp\{-^{(x_i-\mu_k)^2}$ 随机 $_2$ $\}$。这给出了数据的随机表示，如图15.10所示。现在这转化为一个~~最大~~似然问题，~~我~~们将在下面展示，它恰好等价于上面提到的原始 k-means 算法。

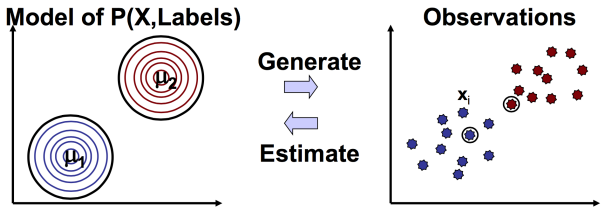

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 htt
p://ocw.mit.edu/help/faq-fair-use/。

图15.10：K-均值作为生成模型。样本是从正态分布中抽取的。

在生成步骤中，我们希望为每个x_i在给定均值μ_k的情况下找到最可能的分割或标签分配。假设每个点独立抽取，我们可以分别寻找每个点的最大似然标签：

$$\arg\max_k P(x_i|\mu_k)=\arg\max_k\frac{1}{\sqrt{2\pi}}exp\left\{-\frac{(x_i-\mu_k)^2}{2}\right\}=\arg\min_k(x_i-\mu_k)^2$$

这完全等价于在原始k-均值算法中找到最近的聚类中心。

在估计步骤中，我们在给定划分（标签）的情况下，寻找聚类均值 μ_k 的最大似然估计：

$$\arg\max_\mu\left\{log\prod_i P\left(x_i|\mu\right)\right\}=\arg\max_\mu\sum_i\left\{-\frac{1}{2}(x_i-\mu)^2+log(\frac{1}{\sqrt{2\pi}})\right\}=\arg\min_\mu\sum_i\left(x_i-\mu\right)^2$$

注意，这个问题的解恰好是x_i的质心，这与原始k-均值算法的过程相同。

不幸的是，由于 k-means 假设各轴之间相互独立，k-means 并未考虑协方差和方差，因此无法建模如椭圆形分布这样的模型。然而，当将此问题推广到期望最大化问题时，这一问题可以得到解决。

15.3.4 Expectation Maximization

K-means 可以看作 EM（期望最大化算法）的一个例子，如图 15.11 所示，其中期望包括对隐藏标签 Q 的估计，而最大化期望似然则在给定数据和 Q 的情况下发生。将每个点分配最近中心的标签对应于 E 步，即在先前参数下估计最可能的标签。然后，使用 E 步产生的数据作为观测，将质心移动到分配给该中心的标签的平均值对应于 M 步，即在给定标签的情况下最大化中心的似然。这种情况类似于 Viterbi 学习。类似地，可以对模糊 k-means 进行类似的比较，它类似于 HMM 的 Baum-Welch 算法。图 15.12 比较了聚类、HMM 和模体发现与期望最小化算法的关系。

需要注意的是，使用EM框架，k均值方法可以推广到形状为长方形且大小不同的聚类。使用k均值时，数据点总是被分配到最近的聚类中心。通过在高斯概率函数中引入协方差矩阵，我们可以允许不同大小的聚类。通过沿不同轴设置不同的方差，我们甚至可以创建长方形分布。

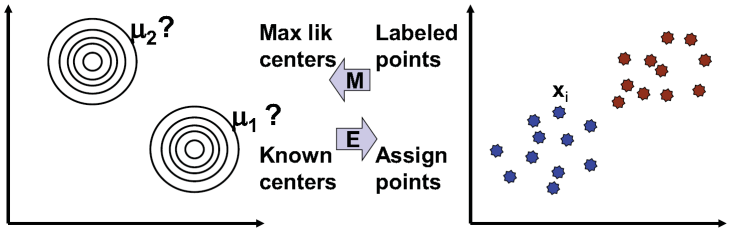

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图15.11：K -均值作为期望最大化（EM）算法。

Update rule	Update assignments (E step) ➔ Estimate hidden labels	Algorithm implementing E step in each of the three settings			Update model parameters (M step) ➔ max likelihood
		Expression clustering	HMM learning	Motif discovery	
The hidden label is:		Cluster labels	State path π	Motif positions	
Pick a best	Assign each point to best label	**K-means:** Assign each point to nearest cluster	**Viterbi training:** label sequence with best path	**Greedy:** Find best motif match in each sequence	Average of those points assigned to label
Average all	Assign each point to all labels, probabilistically	**Fuzzy K-means:** Assign to all clusters, weighted by proximity	**Baum-Welch training:** label sequence w all paths (posterior decoding)	**MEME:** Use all positions as a motif occurrence weighed by motif match score	Average of all points, weighted by membership
Sample one	Pick one label at random, based on their relative probability	**N/A:** Assign to a random cluster, sample by proximity	**N/A:** Sample a single label for each position, according to posterior prob.	**Gibbs sampling:** Use one position for the motif, by sampling from the match scores	Average of those points assigned to label(a sample)

图15.12：关于期望最小化（EM）算法的聚类、HMM和模体发现的比较。

EM 确保收敛，并确保找到最佳可能答案，至少从算法角度而言

从这一角度看，该解决方案的显著问题是概率密度的局部最大值可能阻碍算法收敛至全局最大值。为避免这一复杂情况，一种方法是通过尝试多种初始化来更好地描绘概率分布的全貌。

15.3.5 The limitations of the K-Means algorithm

k-means 算法有一些局限性，在使用它和选择它之前需要牢记。首先，它需要一个度量。例如，我们不能在一组单词上使用 k-means 算法，因为我们没有任何度量。

k-means 算法的第二个主要局限是其对噪声的敏感性。减少噪声的一种方法是事先进行主成分分析。另一种方法是权衡每个变量，以便给受显著噪声影响的变量分配较少的权重：这些权重将在K-means算法[3]的每次迭代中动态计算。

第三个局限是初始中心的选择可能会影响结果。存在一些启发式方法来选择初始聚类中心，但没有一种是完美的。

最后，我们需要先验地知道类的数量。正如我们所看到的，有几种方法可以规避这个问题，基本上是通过在改变k的情况下多次运行算法，或者如果我们计算资源有限，使用经验法则$k \approx \sqrt{n/2}$。`http://en.wikipedia.org/wiki/Determining_ the_number_of_clusters_in_a_data_set`很好地总结了选择聚类数量的不同技术。层次聚类为选择聚类数量提供了一种便捷的方法。

15.3.6 Hierarchical Clustering

迄今为止所讨论的聚类方法，尽管常常为各类数据的本质提供宝贵的洞察，但它们普遍忽视了一个生物数据的关键要素，即相似性可能存在于多个层次上。更确切地说，相似性本质上是一种层次属性，而这一点在之前讨论的聚类算法中并未得到解决。层次聚类以一种非常直接的方式专门处理这一问题，可能是表达数据中最广泛使用的算法。如图15.13所示，其实现方式如下：

1. *Initialization*：初始化一个列表，将每个点作为独立的聚类。
2. *Iteration*：在列表中创建一个包含两个最接近聚类的新聚类。将此新聚类添加到列表中，并从列表中移除这两个组成聚类。

使用层次聚类并记录合并某些聚类的时间的一个关键好处是，我们可以创建一个树状结构，详细记录合并每个聚类的时间，如图15.13所示。因此，为了得到适合你问题的聚类数量，你只需在图15.13中按照你选择的切割级别进行切割，就能得到与该切割级别相对应的聚类数量。然而，需要注意的是，这种方法的一个潜在陷阱是，在某些切割级别上，空间上相当接近的元素（如图15.13中的e和b）可能不在同一个聚类中。

当然，确定聚类间距离的方法是必需的。所使用的具体度量随上下文变化，但（如图15.14所示），一些常见的实现包括最大距离，

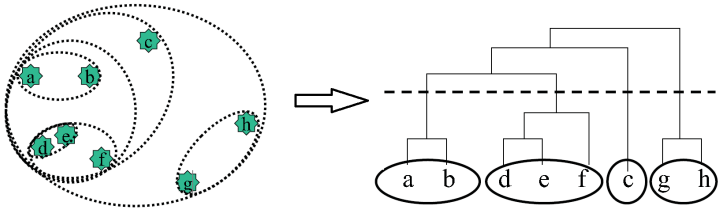

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图15.13：层次聚类

构成簇之间的最小距离、平均距离，以及簇质心之间的距离。

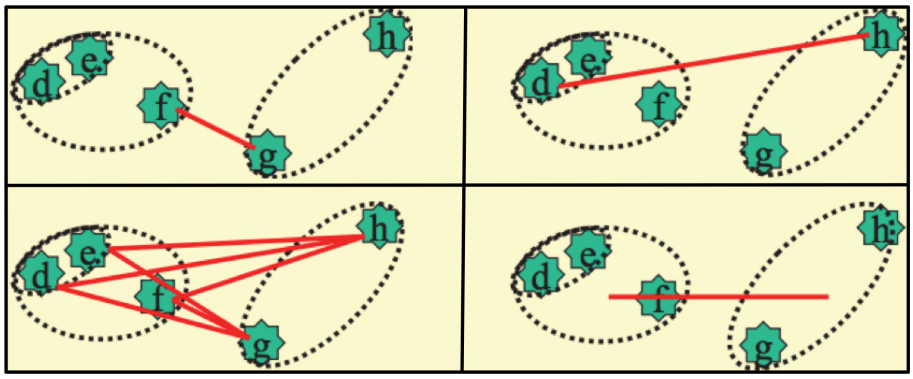

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图15.14: 层次聚类的距离度量。从左上角顺时针方向：最小距离、最大距离、平均距离和质心距离。

注意到在选择最近的聚类时，计算所有成对距离非常耗时且占用空间，因此需要一种更好的方案。一种可能的方法是：1）定义一些边界框，将特征空间划分为几个子空间 2）计算每个框内的成对距离 3）在不同方向上移动边界框的边界并重新计算成对距离 4）根据所有迭代的结果选择最近的一对。

15.3.7 Evaluating Cluster Performance

特定聚类的有效性可以通过多种不同方式进行评估。已知基因群在聚类中的过度呈现，或者更一般地，聚类与已确认的生物学关联之间的相关性，是有效性和显著性的良好指标。然而，如果生物学数据尚不可用，也有方法利用统计学来评估有效性。例如，即使仅使用总可用数据的子集来生成聚类，稳健的聚类也会显现出来。此外，可以通过计算每个聚类随机获得特定分布的概率来确定聚类的统计显著性。该计算利用了超几何分布的变体。从图15.15可以看出，我们可以通过计算当我们从总共N个元素中选取k个元素时，得到超过r +个的概率来实现这一点。

`http://en.wikipedia.org/wiki/Cluster_analysis#Evaluation_of_clustering_results`给出了几个评估聚类质量的公式。

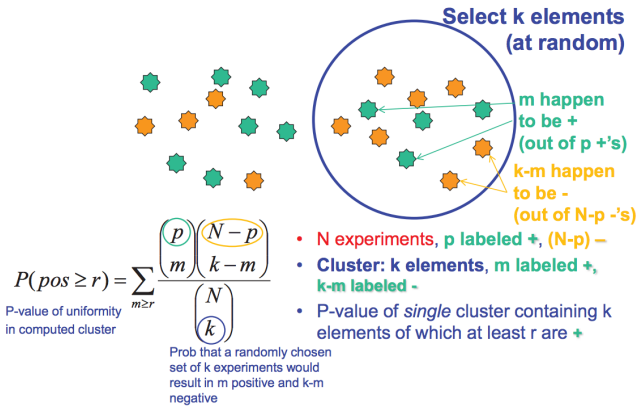

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图15.15：计算在随机选取的簇中你拥有超过r +的概率。

15.4 Current Research Directions

目前与聚类相关的最重要问题涉及现有算法在两个属性上的平滑扩展：规模和维度。为了处理越来越大的数据集，已经开发了诸如 canopy 聚类之类的算法，其中数据集以旨在预处理数据的方式进行粗聚类，随后应用标准聚类算法（例如 k-means）来细分各个簇。维度的增加是一个更令人沮丧的问题，试图解决这一问题通常涉及一个两阶段过程，其中首先通过对原始空间进行适当的变换来识别适当的相关子空间，然后对其应用标准聚类算法。

15.5 Further Reading

- 特雷弗·哈斯蒂、罗伯特·蒂布希拉尼和杰罗姆·弗里德曼。《统计学习基础：数据挖掘、推理与预测》。第二版，2009年2月。在线访问地址：`http://www-stat.stanford.edu/~tibs/ElemStatLearn/download.html`
- 《数值 Recipes：科学计算的艺术》（第3版）。纽约：剑桥大学出版社。
- McLachlan, G.J. 和 Basford, K.E. (1988)《混合模型：推断及其在聚类中的应用》，Marcel Dekker 出版。
- 贝兹德克，J. C.，埃利希，R.，富尔，W.（1984）。FCM：模糊c均值聚类算法。计算机与地球科学，10(2)，191-203。
- `http://nlp.stanford.edu/IR-book/html/htmledition/evaluation-of-clustering-1.html`
- `http://compbio.uthsc.edu/microarray/lecture1.html`

15.6 Resources

- Cluster 3.0：开源聚类软件，实现了基因表达数据分析中最常用的聚类方法。

- MATLAB：K均值聚类：`http://www.mathworks.com/help/stats/kmeans.html`；模糊C均值聚类：`http://www.mathworks.com/help/fuzzy/fcm.html`；层次聚类：`http://www.mathworks.com/help/stats/linkage.html`
- Orange 是一款免费的数据挖掘软件套件（有关 Python 脚本编写，请参见 orngClustering 模块）：`http://bonsai.hgc.jp/~mdehoon/software/cluster/software.htm`
- R（参见聚类分析和有限混合模型）
- SAS 集群

15.7 What Have We Learned?

总之，在本章中我们已经看到：

- 在*clustering*中，我们识别未标记数据中的结构。例如，我们可能使用聚类来识别显示相似表达谱的基因群。
  - 划分聚类算法构建互不重叠的聚类，使得每个项恰好被分配到一个聚类中。例如：k-means – 凝聚层次聚类算法构建一个层次化的嵌套聚类集合，表明聚类之间的相关性。例如：层次聚类 – 通过使用聚类算法，我们可以揭示基因表达矩阵的隐藏结构，这为我们理解复杂疾病的机制和分类不同疾病提供了有价值的线索
- 在*classification*中，我们将数据划分为已知标签。例如，我们可能构建一个分类器，根据基因表达谱将一组肿瘤样本分为可能对特定药物有反应和不太可能对特定药物有反应的两类。我们将在下一章重点讨论分类。

Bibliography

[1] http://en.wikipedia.org/wiki/File:Heatmap.png。

[2] http://genome.ucsc.edu/ENCODE/。

[3] J.Z. Huang, M.K. Ng, Hongqiang Rong, 和 Zichen Li. k-means 类型聚类中的自动变量加权. *Pattern Analysis and Machine Intelligence, IEEE Transactions on*, 27(5):657 –668, 2005年5月.

[4] Christopher A. Maher, Chandan Kumar-Sinha, Xuhong Cao, Shanker Kalyana-Sundaram, Bo Han, Xiao-jun Jing, Lee Sam, Terrence Barrette, Nallasivam Palanisamy, and Arul M. Chinnaiyan. 转录组测序检测癌症中的基因融合. *Nature*, 458(7234):97–101, Mar 05 2009.

CHAPTER

SIXTEEN

基因调控2——分类

阿尔温德·蒂亚加拉
詹 富尔顿·王 萨利尔
·德赛 大卫·查尔顿
凯文·莫泽莱夫斯基
罗伯特·托斯卡诺

16.1 Introduction

在前一章中，我们探讨了*clustering*，它提供了一种无需事先了解底层结构即可分析数据的工具。正如之前提到的，这是“无监督”学习的一个例子。本章将讨论**supervised learning**，其中我们能够利用预先分类的数据构建模型，以此对更多数据点进行分类。通过这种方式，我们将利用现有的已知结构来制定识别和归类更多信息的规则。

有两种方法可以进行分类。这两种方法类似于我们进行模体发现时的两种方式：HMM，这是一种生成模型，使我们能够实际描述特定指定有效的概率；以及CRF，这是一种判别方法，使我们能够在特定上下文中区分对象。生成方法与判别方法之间存在二分法。我们将使用贝叶斯方法对线粒体蛋白质进行分类，并使用SVM对肿瘤样本进行分类。

在本讲中，我们将探讨两种新算法：生成式分类器——朴素贝叶斯，以及判别式分类器——支持向量机（SVM）。我们将讨论这两种模型在生物学中的应用，特别是使用朴素贝叶斯分类器预测全基因组中的线粒体蛋白，以及使用SVM基于DNA微阵列的基因表达监测对癌症进行分类。还将讨论这两种技术的显著特征以及使用每种技术的注意事项。

与聚类一样，分类（更广泛地说，监督学习）起源于人工智能领域的努力。

Intelligence and Machine Learning. Furthermore, much of the motivating infrastructure for classification had already been developed by probability theorists prior to the advent of either AI or ML.

16.2 Classification - Bayesian Techniques

考虑识别线粒体蛋白的问题。如果我们查看人类基因组，如何确定哪些蛋白质参与线粒体过程，或者更一般地说，哪些蛋白质被靶向到线粒体1? [1] 这特别有用，因为如果我们知道线粒体蛋白，就可以研究这些蛋白如何介导疾病过程和代谢功能。我们将考虑的分类方法针对所有人类蛋白质考察7个特征：

1. 靶向信号 2. 蛋白质结构域 3. 共表达 4. 质谱 5. 序列同源性 6. 诱导 7. 基序

我们的总体方法是确定这些特征在线粒体蛋白和非线粒体蛋白中是如何分布的。然后，对于一个新的蛋白质，我们可以对这七个特征应用概率分析，以判断它最可能属于哪一类。

16.2.1 Single Features and Bayes Rule

让我们先只关注一个特征。我们必须首先假设特征存在一个依赖于类别的分布。我们必须首先从真实数据中推导出这个分布。我们需要的第二件事是在查看数据之前抽取特定类别样本的先验概率。得到特定类别的概率就是该类别相对大小。一旦我们有了这些概率，就可以使用贝叶斯规则来得到在给定数据下样本属于特定类别的概率（这被称为后验概率）。我们有前向生成概率，并使用贝叶斯规则执行反向推断。注意，仅仅考虑特征从每个类别依赖分布中抽取的概率是不够的，因为如果我们先验地知道一个类别（比如类别A）比另一个类别常见得多，那么就需要压倒性的证据表明该特征是从类别B的分布中抽取的，我们才会相信该特征确实来自类别B。根据证据和先验知识找到我们所需内容的正确方法是使用贝叶斯规则：

$$P(\text{Class}|\text{feature}) = \left(\frac{P(\text{feature}|\text{Class})P(\text{Class})}{P(\text{feature})}\right)$$

[1] Mitochondria is the energy producing machinery of cell. Very early in life, the mitochondria was engulfed by the predecessor to modern day eukaryotes, and now, we have different compartments in our cells. So the mitochonria has its own genome, but it is very depleted from its own ancestral genome - only about 11 genes remain. But there are hundreds are genes that make the mitochondria work, and these proteins are encoded by genes transcribed in the nucleus, and then transported to the mitochondria. So the goal is to figure out which proteins encoded in the genome are targeted to the mitochondria. This is important because there are many diseases associated with the mitochonria, such as aging.

- **Posterior** : P(类|特征)
- **Prior** : P(类)
- **Likelihood** : P(功能|类)

这个公式恰好为我们提供了所需的联系，使我们能够将已知的特征概率转换为分类算法中的类别概率。它让我们能够整合从观察中得出的似然度与关于某事物普遍程度的先验知识。以mtDNA为例，我们可以估计线粒体DNA约占人类基因组的1500/21000（即不到10%）。因此，应用贝叶斯规则，我们的分类器仅当有**very strong likelihood based on the observed features**时，才应将基因分类为线粒体，因为任何基因属于线粒体的先验概率都非常低。

根据这个规则，我们现在可以基于观察到的特征，构建一个最大似然规则来预测物体的类别。我们要选择在给定观察特征下概率最高的类别，因此，如果满足以下条件，我们将选择Class1而非Class2：

$$\left(\frac{P(\text{feature}|\text{Class1})P(\text{Class1})}{P(\text{feature})}\right) > \left(\frac{P(\text{feature}|\text{Class2})P(\text{Class2})}{P(\text{feature})}\right)$$

注意，P(feature) 出现在两边，因此我们可以将其完全抵消，只需选择具有 P(feature|Class)P(Class) 最高值的类别。

另一种看待方式是将它视为判别函数：通过重新排列上述公式并取对数，我们应当在满足以下条件时选择类别1而非类别2：

$$\log\left(\frac{P(\text{X}|\text{Class1})P(\text{Class1})}{P(\text{X}|\text{Class2})P(\text{Class2})}\right) > 0$$

在这种情况下，使用对数提供了明显的优势：

1. 数值稳定性
2. 更简单的数学（将展开的项相加比相乘更容易）
3. 单调递增的判别器。

该判别函数未考虑误分类带来的代价（换言之，某一分类是否比另一分类更为不利）。在此情形下，我们实质上是在整体上最小化误分类的数量，但并未对个别误分类赋予惩罚。从课堂讨论和习题集中的例子来看——如果我们试图将患者分类为患有癌症或未患有癌症，可以说，将实际患有癌症的患者误分类为健康，远比将健康人误分类为患有癌症更为有害。在第一种情况下，患者将得不到治疗，更可能死亡，而第二种错误则涉及情感上的痛苦，但不会增加失去生命的可能性。为了形式化误分类的惩罚，我们定义了所谓的损失函数L_{kf}，它将真实类别为类别k的对象被误分类为类别j时赋予一个损失（损失函数的一个具体例子见习题集2）。

16.2.2 Collecting Data

前面的内容告诉我们，如果已经知道每个类别对应的确切概率，如何处理预测。如果我们想基于特征X对线粒体蛋白质进行分类，我们仍然需要确定概率$P(\text{mito})$、$P(\text{not mito})$、$P(X|\text{mito})$和$P(X|\text{not mito})$的方法。为此，我们需要一个训练集：一组已经分类的数据，我们的算法可以用它来学习每个类别对应的分布。一个**high-quality training set** (既大又无偏)是任何分类器中最重要的部分。此时一个重要的问题是，我们需要多少关于已知基因的数据才能为未知基因构建一个好的分类器？这是一个难题，其答案尚未完全清楚。然而，有一些简单的方法可以给我们一个很好的估计：当我们有一个固定的训练数据集时，我们可以保留一个留出集，不用于我们的算法，而是用那些（已知）数据点来测试我们尝试分类它们时算法的准确性。通过尝试不同大小的训练集与$holdout$集，我们可以检查算法的准确性曲线。一般来说，当我们增加训练数据量时，如果看到准确性曲线趋于平坦，我们就有了足够的训练数据（这表明额外的数据可能只会带来轻微的边际改进）。留出集也称为测试集，因为它允许我们测试分类器的泛化能力。

假设我们已经收集了训练数据，然而，我们应该如何建模$P(X|Class)$呢？有许多可能性。一种是使用我们在上一讲中聚类时所用的相同方法，将特征建模为高斯分布，然后我们可以遵循最大似然原理来找到最佳的中心和方差。在线粒体研究中使用的是一个简单的密度估计：对于每个特征，将可能值的范围划分为一组箱（例如，每个特征五个箱）。然后我们使用给定的数据来估计在给定类别下特征落入每个箱的概率。这背后的原理同样是最大似然，但针对的是多项分布而不是高斯分布。我们可能选择将一个原本连续的分布离散化，因为估计连续分布可能很复杂。

这种策略存在一个问题：如果某个箱中样本数为零怎么办？概率为零会覆盖公式中的其他所有因素，因此分类器不会认为这个箱仅仅是不太可能，而是会认为它是$impossible$。有许多可能的解决方案，但这里采用的方法是应用$Laplace\ Correction$：向每个箱中加入少量（比如一个元素），使概率估计略微趋向均匀，并考虑到（在大多数情况下）没有一个箱是真正不可能的。另一种避免必须应用此校正的方法是选择不太小的箱，这样在实践中箱内就不会出现零样本。如果你有很多很多数据点，你可以设置更多的箱，但会有过拟合训练数据的风险。

16.2.3 Estimating Priors

我们现在有一种方法来近似给定类别的特征分布，但我们仍然需要知道这些类别本身的相对概率。有**three general approaches**：

1. 通过计算训练数据中每个类别的相对频率来估计先验概率。然而，这种方法容易产生偏差，因为可用的数据往往不成比例地偏向于较少见的类别（因为这些类别常常是特别研究的对象）。但如果我们有高质量（具有代表性）的训练数据样本，这种方法效果非常好。

2. 基于专家知识进行估计——可能存在独立于我们训练数据的、由其他方法获得的先前估计，我们可将其作为自己预测的初步近似。换句话说，你可以询问专家线粒体蛋白质的百分比是多少。

3. 假设所有类别出现的概率相同，我们通常在完全不了解真实频率信息的情况下这样做。这实际上就是我们在使用最大似然原理时所采取的方法：

我们的聚类算法本质上是在假设所有先验均相等的情况下使用贝叶斯分析。这实际上是一个强有力的假设，但当你没有其他数据时，这是你能做的最好的。

为了对线粒体DNA进行分类，我们采用方法(2)，因为关于mtDNA比例的某些估计值已经已知。但存在一个复杂情况，即有多个特征。

16.2.4 Multiple features and Naive Bayes

在分类线粒体DNA时，我们关注的是7个特征，而不仅仅是一个。为了将前述方法应用于多个特征，我们不仅需要为每个单独的特征范围划分一个区间，如果考虑两个特征各有五个范围，那就已经是25个区间了。所有七个特征则会给我们带来近80,000个区间，而我们可预见到大多数这些区间将会是空的，仅仅是因为我们没有足够的训练数据来填充它们。这会导致问题，因为零值会导致属于某一类别的概率发生无限变化。显然，随着我们增加更多特征，这种方法无法很好地扩展，因此我们需要一种更好的方式来估计组合概率。

我们将使用的解决方案是 **assume the features are independent**，即一旦我们知道类别，任何特征的概率分布都不受其他特征值的影响。这就是朴素贝叶斯假设，它几乎总是错误的，但尽管如此，它还是经常被使用，原因在于它在数学上非常容易处理，并且往往足够接近真相，能给出合理的近似。（注意，这个假设并不是说所有特征都是独立的：如果我们看整个模型，不同特征之间可能存在很强的联系，但这个假设认为这些联系被不同的类别分割开了，并且在每个单独的类别内部没有进一步的依赖关系。）此外，如果你知道某些特征是耦合的，你可以只学习部分特征对的联合分布。

一旦我们假设独立性，组合特征的概率就是与每个特征相关的个体概率的乘积。因此我们现在有：

$$P(f_1, f2, K, f_N|\text{类}) = P(f_1|\text{类})P(f_2|\text{类})KP(f_N|\text{类})$$

其中 f_1 表示特征1。类似地，判别函数可以改为先验概率的乘积：

$$G(f_1, f_2, K, f_N) = \log\left(\frac{\Pi P(f_1|\text{Class1})P(\text{Class1})}{\Pi P(f_1|\text{Class2})P(\text{Class2})}\right)$$

16.2.5 Testing a classifier

分类器应始终在未包含在其训练集中的数据上进行测试。我们可以想象最坏的情况是，一种算法仅仅记住了其训练数据，并对其他任何情况随机应对。这样的分类器在训练数据上会表现得完美无缺，但这并不能说明其在新的输入上的真实性能。这就是为什么如前所述，使用测试集或留出集如此重要。然而，简单的错误率并不能概括错误可能带来的所有后果。对于简单的二分类器（一个对象要么属于某个单一目标类别，要么不属于），存在以下几种错误类型：

1. 真阳性（TP）

2. 真阴性（TN） 3. 假阳性（FP） 4. 假阴性（FN）

这些错误的频率可以概括为分类器的性能指标，其定义为：

1. *Sensitivity* 在一个类别中，被正确标记为该类别的对象比例是多少？也就是说，真阳性结果的比例是多少？高灵敏度意味着一个类别中的元素很可能被标记为该类别。低灵敏度意味着假阴性太多。2. *Specificity* 不在某个类别中的对象被正确标记为不属于该类别的比例是多少？也就是说，真阴性结果的比例是多少？高特异性意味着被标记为属于某个类别的元素很可能确实属于该类别。低特异性意味着假阳性太多。

在大多数算法中，存在一个**tradeoff between sensitivity and specificity**。例如，通过将所有对象标记为目标类别，我们可以达到100%的灵敏度，但特异性将为0%，因此这并无实用价值。通常，大多数算法会使用某个概率阈值来决定是否将对象归类于某一类别（例如，我们上述的判别函数）。提高该阈值会增加特异性但降低灵敏度，而降低阈值则相反。用于分类线粒体蛋白质的MAESTRO算法（本讲座中描述）实现了99%的特异性和71%的灵敏度。

16.2.6 MAESTRO Mitochondrial Protein Classification

他们通过创建若干分箱并评估每个分箱中线粒体和非线粒体蛋白质的比例，为每个特征找到一个类别相关的分布。这让你能够评估分类中的**usefulness of each feature**。你最终会得到一堆中等强度的分类器，但当你把它们组合在一起时，你希望能得到一个更强的分类器。Calvo等人[1]试图通过生成和整合提供线粒体定位互补线索的数据集，构建对人类蛋白质定位于线粒体的高质量预测。具体来说，对于每个人类基因产物p，他们使用以下七个基因组规模数据集中的每一个分配一个分数$s_i(p)$：靶向信号分数、蛋白质结构域分数、顺式基序分数、酵母同源分数、祖先分数、共表达分数和诱导分数（每个数据集的意义和内容的细节可在原稿中找到）。这些分数$s_1 - S_7$中的每一个都可以单独用作线粒体定位的弱全基因组预测因子。每种方法的性能使用大型金标准精选训练集进行评估——由MitoP2数据库1维护的654个线粒体蛋白质T_{mito}和注释为定位到其他细胞区室的2,847个非线粒体蛋白质T_{mito}。为了提高预测准确性，作者使用朴素贝叶斯分类器整合了这八种方法，该分类器被实现为一个名为MAESTRO的程序。因此，我们可以取几个弱分类器，并将它们组合起来得到一个更强的分类器。

当MAESTRO应用于人类蛋白质组时，预测出1451种蛋白质为线粒体蛋白质，并做出了450种新蛋白质的预测。如前一节所述，MAESTRO算法在分类线粒体蛋白质方面达到了99%的特异性和71%的敏感性，这表明即使假设特征独立，朴素贝叶斯分类技术对于大规模（即全基因组）规模的分类也能证明极为有效。

16.3 Classification Support Vector Machines

上一节探讨了使用概率（或生成）模型进行分类，本节则着眼于判别技术，本质上，我们能否通过一个函数处理数据以确定其结构？这类判别技术避免了生成模型中固有的成本，因为生成模型可能需要比实际必要更多的信息。

支持向量机技术本质上涉及绘制一条垂直于分隔训练数据的直线（超平面）的向量。其方法是，我们查看训练数据以获得一个分隔超平面，使得两类数据位于超平面的不同侧。一般来说，有许多超平面可以分隔数据，因此我们希望绘制能够最大程度分隔数据的超平面——我们希望选择使超平面到任何数据点的距离最大化的直线。换句话说，SVM 是一个最大间隔分类器。你可以将超平面想象为在直线的每一侧都被相等大小的间隔所包围，且任一侧的间隔内都没有数据点。我们希望绘制能够允许我们画出最大间隔的直线。请注意，一旦分隔直线和间隔被确定，一些数据点将正好位于间隔的边界上。这些数据点阻止我们进一步扩大间隔，因此决定了直线/间隔。这样的点称为支持向量。如果我们添加位于间隔之外的新数据点，或移除不是支持向量的点，我们不会改变任何超平面所能实现的最大间隔。

假设 垂直于超平面的向量是w，且超平面经过点^b。那么，如果$w_{|w|} * x$大于b，则点x被分类为正类，否则为负类。可以证明，最优的w，即达到最大间隔的超平面，实际上可以表示为数据向量$\Sigma a_i * x_i$的线性组合。然后，为了对新数据点x进行分类，我们需要取w与x的点积以得到一个标量。注意，这个标量$\Sigma a_i * (x_i * x)$仅依赖于x与训练向量x_is之间的点积。此外，可以证明，对于一组（训练）点找到最大间隔超平面等同于最大化一个线性规划，其目标函数仅依赖于训练点彼此之间的点积。这很好，因为它告诉我们，求解该线性规划的复杂度与数据点的维度无关。如果我们预先计算训练向量的两两点积，那么数据的维度对于求解线性规划的运行时间没有影响。

16.3.1 Kernels

我们看到，SVM仅依赖于向量的点积。因此，如果我们称变换为$\phi(v)$，对于两个向量，我们只关心$\phi(v_1) \cdot \phi(v_2)$的值。使用核技巧的关键在于认识到，对于某些变换$\phi$，存在一个函数$K(v_1, v_2)$，使得：

$$K(v_1, v_2) = \phi(v_1) \cdot \phi(v_2)$$

在上述关系中，右侧是高维向量的点积，而左侧是低维向量的函数。在我们之前映射$x \to (x, y = x^2)$的例子中，我们得到

$$K(x_1, x_2) = (x_1 x_1^2) \cdot (x_2, x_2^2) = x_1 x_2 + (x_1 x_2)^2$$

现在我们实际上并没有应用变换 ϕ，我们可以在低维空间中进行所有计算，但获得使用高维空间的所有优势。

示例内核如下：

1. 线性核：$K(v_1, v_2) = v_1 \cdot v_2$，表示$\phi(x) = x$的平凡映射

2. 多项式核：$K(v_1, v_2) = (1 + v_1 \cdot v_2)^n$，在之前的例子中使用了 $n = 2$。

3. 径向基核：$K(v_1, v_2) = \exp(-\beta|v_1 - v_2|^2)$ 这个变换实际上是从点 v_1 到无限维空间中的函数（可以视为希尔伯特空间中的一个点）。因此，我们实际上是在将训练集转换为函数，并将它们结合起来以得到决策边界。这些函数是以输入点为中心的高斯函数。

4. Sigmoid 核：$K(v_1, v_2) = \tanh[\beta(v_1^T v_2 + r)]$ Sigmoid 核因其起源于神经网络（例如，Sigmoid 核函数等价于两层感知器神经网络）而在 SVM 中广受欢迎。先前的研究（Vapnik 1995）指出，对于参数 μ 和 r 的某些值，核矩阵可能不是半正定的。尽管如此，Sigmoid 核在实际应用中仍被使用[2]。

这里有一个核函数的具体示例。考虑两类一维数据：

$\{-5, -4, -3, 3, 4, 5\} and \{-2, -1, 0, 1, 2\}$

这些数据显然不是线性可分的，我们能找到的最佳分离边界可能是$x > -2.5$。现在考虑应用变换。数据现在可以写成新的对，

$\{-5, -4, -3, 3, 4, 5\} \to \{(-5, 25), (-4, 16), (-3, 9), (3, 9), (4, 16), (5, 25)\}$

和

$\{-2, -1, 0, 1, 2\} \to \{(-2, -4), (-1, 1), (0, 0), (1, 1), (2, 4)\}$

该数据可通过规则$y > 6.5$进行分离，一般而言，我们将数据转换到的维度越多，它就越可分。

另一种思考这个问题的方式是将分类器变换回原始的低维空间。在这个特定的例子中，我们会得到规则 $x^2 < 6.5$，这将在数轴上的两个点处将其平分。一般来说，我们变换到的空间维度越高，当我们变换回原始空间时，得到的分类器就越复杂。

使用核变换输入数据的注意事项之一是数据过拟合（或过度分类）的风险。更一般地说，SVM可能会生成过多的特征向量维度，以至于它不能很好地泛化到其他数据。为了避免过拟合，通常使用交叉验证来评估在网格或模式搜索过程中尝试的每个参数集所提供的拟合。在径向基核中，你本质上可以增大β的值，直到每个点都位于自己的分类区域内（从而完全破坏了分类过程）。SVM通常能避免这种过拟合问题，因为它们最大化了数据点之间的间隔。

当使用难以分离的训练集时，SVM可以引入一个代价参数C，以允许在分离类别时有一定的灵活性。该参数控制着允许训练误差与强制严格边界之间的权衡。因此，它可以创建一个允许一些误分类的$soft$边界。增加C的值会增加误分类点的代价，并迫使创建一个可能泛化能力不佳的更精确模型。

我们能将任意函数用作核函数吗？默瑟条件为这个问题提供了答案，它为我们选择可接受的核函数提供了一个解析判据。默瑟条件指出，核函数 $K(x,y)$ 是有效核函数当且仅当以下条件成立：对于任意满足 $g(x)^2dx$ 有限的 $g(x)$，我们有：

$\int\int K(x,y)g(x)g(y)dxdy \geq 0$[3]

总之，我们已经定义了SVM判别器，并展示了如何通过适当的核映射函数进行分类，这些函数允许在较低维度上执行计算，同时能够捕获较高维度中的所有可用信息。下一节将描述SVM在癌症诊断中肿瘤分类的应用。

16.4 Tumor Classification with SVMs

Golub等人[4]提出了一种分类两种急性白血病——急性髓系白血病（AML）和急性淋巴细胞白血病（ALL）的通用方法。该方法主要集中在有效解决三个主要问题：

1. 是否存在其表达模式预测与类别区分强烈相关的基因（即，能否区分ALL和AML）

2. 如何使用已知样本集合创建一个“类别预测器”，以便能够将新样本分配给两个类别中的一个

3. 如何测试其类预测器的有效性

他们通过使用“邻域分析”技术来确定观察到的相关性是否比偶然预期的更强，从而解决了（1）。这项分析显示，大约有1100个基因与AML-ALL类别区分之间的相关性比偶然预期的更高。为了解决（2），他们开发了一种程序，该程序使用一组固定的“信息基因”（根据其与AML和ALL类别区分之间的相关性选择），并根据这些基因在新样本中的表达水平进行预测。每个信息基因对其中一个类别投出“加权票”，每票的权重取决于新样本中的表达水平以及该基因与类别区分的相关程度。将投票相加，以确定获胜类别。为了解决（3），他们通过首先在初始数据集上进行交叉验证测试，然后在独立样本集上评估其准确性，从而有效测试他们的预测器。基于他们的测试，他们能够识别出38个样本中的36个（这些样本是其训练集的一部分！），并且所有36个预测在临床上都是正确的。在独立测试集上，34个样本中有29个被强烈预测，准确率为100%，另有5个未被预测。

针对同一分类问题，Mukherjee等人[5]采用了SVM方法。经典SVM的输出是二分类标签。在此特定应用中，能够拒绝分类器不够确信的点尤为重要。因此，作者在SVM输出上引入了置信区间，允许拒绝低置信值的点。与Golub等人[4]的情况一样，作者必须推断哪些基因对分类重要。SVM在训练集的38个样本上进行训练，并在独立测试集的34个样本上进行测试（与Golub等人的情况完全相同）。作者的结果总结在下表中（其中$|d|$对应于拒绝的截断值）。

这些结果相较于之前报道的技术有显著改进，表明SVM在大型数据集分类中扮演着重要角色（如DNA微阵列实验产生的数据集）。

16.5 Semi-Supervised Learning

在某些场景中，我们的数据集仅包含少量标记数据点、大量未标记数据点以及数据中的固有结构。这种情况下，聚类和分类都表现不佳，需要采用混合方法。这种半监督方法可能涉及先对数据进行聚类，随后对生成的聚类进行分类。

16.5.1 Open Problems

16.6 Current Research Directions

16.7 Further Reading

- 理查德·O杜达，彼得·E哈特，大卫·G斯托克（2001）模式分类（第二版），威利，纽约
- 有关更多书籍和文章，请参见前一章。

16.8 Resources

- 用于Matlab的统计模式识别工具箱。
- 有关更多工具，请参见上一章

Bibliography

[1] Calvo, S., Jain, M., Xie, X., Sheth, S.A., Chang, B., Goldberger, O.A., Spinazzola, A., Zeviani, M., Carr, S.A., and Mootha, V.K. (2006). 通过整合基因组学系统识别人类线粒体疾病基因。Nat. Genet. 38, 576582。

[2] Scholokopf, B., 等， 1997年。比较具有高斯核的支持向量机与径向基函数分类器。IEEE信号处理汇刊。

[3] Christopher J.C. Burges. 支持向量机模式识别教程. *Data Mining and Knowledge Discovery*, 2:121–167, 1998.

[4] T. R. Golub, D. K. Slonim, P. Tamayo, C. Huard, M. Gaasenbeek, J. P. Mesirov, H. Coller, M. L. Loh, J. R. Downing, M. A. Caligiuri, and C. D. Bloomfield. 癌症的分子分类：通过基因表达监测进行类别发现和类别预测。*Science*, 286:531–537, 1999.

[5] S. Mukherjee, P. Tamayo, D. Slonim, A. Verri, T. Golub, J. P. Mesirov, 和 T. Poggio. 微阵列数据的支持向量机分类. 技术报告, AI Memo 1677, 麻省理工学院, 1998.

Genes	**Rejects**	**Errors**	**Confidence level**	$\|d\|$
7129	3	0	93%	0.1
40	0	0	93%	0.1
5	3	0	92%	0.1

CHAPTER

SEVENTEEN

调控基序、吉布斯采样与EM算法

珍妮·林（2014）玛丽亚·亚历克西斯（2013）
詹姆斯·杨（2012）李音清和阿文德·蒂亚加拉
詹（2011）比安卡·杜米特拉什库和尼尔·瓦德
瓦（2010）约瑟夫·莱恩（2009）布拉德·卡特
和伊桑·海尔曼（2008）

Figures

17.1 转录因子在基序位点与DNA结合 . . . . . 253 17.2 示例配置文件矩阵 . . . . . 254 17.3 计算得到的Z矩阵示例 . . . . . 255 17.4 选择基序位置：贪婪算法总是会选择基序最可能的位置。EM算法会取平均值，而Gibbs采样实际上会使用由*Z*给出的概率分布来在每一步中采样一个基序 . . . . . 255 17.5 样本位置权重矩阵 . . . . . 256 17.6 Gibbs采样 . . . . . 258 17.7 使用基序种子来寻找退化基序 . . . . . 259 17.8 通过EM、Gibbs采样和贪婪算法计算得到的Z矩阵示例 . . . . . 260 17.9 选择基序位置：贪婪算法总是会选择基序最可能的位置。EM算法会取平均值，而Gibbs采样实际上会使用由*Z*给出的概率分布来在每一步中采样一个基序 . . . . . 260 17.10含有零个、一个或两个基序的序列 . . . . . 262 17.11当头尾出现的概率相等时，熵达到最大 . . . . . 263 17.12每个堆叠的高度代表了Gibbs采样或EM告诉我们的关于基序中位置的信息比特数 263 17.13假设低G-C含量并使用K-L距离的lexA结合位点 264

17.1 Introduction to regulatory motifs and gene regulation

我们已经探讨了动态规划、序列比对、序列分类与建模、隐马尔可夫模型以及期望最大化等领域。在接下来的章节中，我们将探讨这些技术如何在识别新颖基序及阐明其功能方面同样发挥作用。

17.1.1 The regulatory code: Transcription Factors and Motifs

模体是短的（6-8个碱基长）、重复出现的模式，具有明确界定的生物学功能。模体包括增强子区域中的DNA模式或启动子模体，以及RNA序列中的模体，如剪接信号。正如我们所讨论的，遗传活动是根据环境变化进行调节的。模体负责将转录因子或调节蛋白招募到适当的靶基因。模体也可以被microRNA识别，microRNA通过与模体的互补性结合；核小体，根据其GC含量识别模体；以及其他RNA，利用DNA序列和结构的组合。一旦结合，它们可以激活或抑制相关基因的表达。

转录因子（TFs）可以利用多种机制来控制基因表达，包括组蛋白的乙酰化和去乙酰化、将辅因子分子招募到TF-DNA复合物中，以及在转录过程中稳定或破坏RNA-DNA界面。它们通常调控一组参与相似细胞过程的基因。因此，在上游区域含有相同基序的基因很可能在功能上相关。事实上，许多调控基序是通过分析已知具有相似功能的基因上游区域来鉴定的。

模体在定义基因调控网络和解析单个基因功能方面已变得极其有用。凭借我们当前的计算能力，调控模体的发现与分析已取得长足进展，并始终处于基因组学研究的前沿。

17.1.2 Challenges of motif discovery

在我们深入探讨模体发现算法之前，必须先理解模体的特性，尤其是那些使模体难以被发现的特性。如前所述，模体通常非常短，一般只有6-8个碱基对长。此外，模体可以是简并的，即模体内某些位置的核苷酸仅影响模体的功能。这种简并性的出现是因为转录因子与相应模体的相互作用方式远比简单的互补关系复杂。如17.1所示，许多蛋白质与模体的相互作用并非通过打开DNA来检查碱基互补性，而是通过扫描两个糖磷酸骨架之间的空间或沟槽。根据转录因子的物理结构，蛋白质可能仅对嘌呤和嘧啶或弱碱和强碱之间的差异敏感，而不是识别特定的碱基对。转录因子的拓扑结构甚至可能导致某些核苷酸完全不发生相互作用，使这些碱基充当通配符。

模体内部的这种简并性问题构成了一个挑战。如果我们仅仅寻找一个固定的k-mer，我们可以简单地使用局部比对在我们正在查看的所有序列中搜索该k-mer。

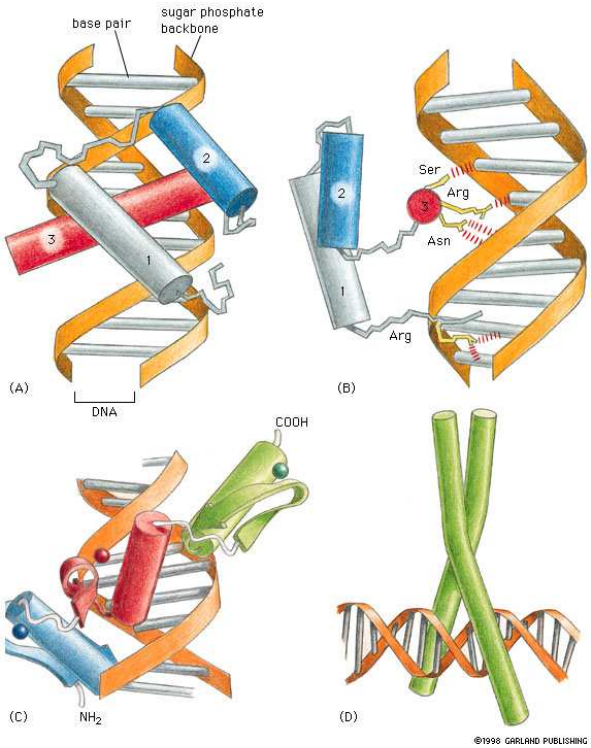

图17.1：转录因子在基序位点与DNA结合

© Garland Publishing。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

工具。然而，模体可能因序列而异。因此，一段已知为调控模体的核苷酸序列被称为模体的$instance$，因为它代表了可能满足模体功能的众多不同核苷酸组合之一。

在我们的方法中，我们对数据做出两个假设。首先，我们假设碱基之间不存在成对相关性，即每个碱基与其他所有碱基独立。尽管这种相关性在现实生活中确实存在，但在我们的分析中考虑它们会导致所考虑的参数空间呈指数增长，从而有可能使我们的数据过拟合。我们做出的第二个假设是所有模体都具有固定长度；实际上，这一近似大大简化了问题。然而，即使有这两个假设，模体发现仍然是一个非常具有挑战性的问题。模体相对较小的尺寸及其极大的多样性，使得定位它们相当困难。此外，模体相对于对应基因的位置远非固定；模体可以在上游或下游，基因与模体之间的距离也各不相同。实际上，有时模体距离基因远达10k到10M个碱基对。

17.1.3 Motifs summarize TF sequence specificity

由于模体实例表现出极大的多样性，我们通常使用位置权重矩阵（Position Weight Matrix, PWM）来表征模体。该矩阵给出了模体中每个位置上每种碱基的频率。下图展示了一个PWM示例，其中p_{ck}对应于模体内位置k上碱基c的频率，p_{c0}表示非模体区域中碱基的分布。

我们现在更严格地定义模体发现问题。我们假设给定一组共调控且功能相关的基因。许多模体先前是通过足迹法发现的。

sequence positions

	1	2	3	4	5	6	7	8
A	0.1	0.3	0.1	0.2	0.2	0.4	0.3	0.1
C	0.5	0.2	0.1	0.1	0.6	0.1	0.2	0.7
G	0.2	0.2	0.6	0.5	0.1	0.2	0.2	0.1
T	0.2	0.3	0.2	0.2	0.1	0.3	0.3	0.1

图17.2：示例配置文件矩阵

实验，这些实验分离出被特定转录因子结合的序列，因此更可能对应于基序。有几种计算方法可用于定位基序:

1. 对序列集合进行局部比对，并探究导致极高比对得分的比对结果。2. 使用隐马尔可夫模型对启动子区域建模，然后使用生成模型寻找非随机序列。3. 通过应用关于基序应具有何种样式的先验知识来缩小搜索空间。4. 搜索不同序列之间的保守区块。5. 检查极可能含有基序的区域中k-mer的频率。6. 使用概率方法，如EM、吉布斯采样或贪心算法

方法5，利用相对kmer频率来发现模体，存在一些需要考虑的挑战。例如，这些区域中可能存在许多常见的词，它们实际上并不是调控模体，而是不同的指令集。此外，给定一个可能是模体的词列表，并不能确定最可能的模体就是最常见的词；例如，尽管模体通常在启动子区域中过表达，但如果模体过多，转录因子可能无法结合。解决这个问题的一个可能方法是在启动子区域与背景区域相比，找到具有最大相对频率的kmer。这种策略通常作为后处理步骤来缩小可能的模体数量。

在下一节中，我们将更深入地探讨这些概率算法，以及利用kmer频率进行模体发现的方法。我们还将回到使用kmers在进化保守性背景下寻找模体的思路，以进行模体发现。

17.2 Expectation maximization

17.2.1 The key idea behind EM

给定一组序列，并假设其中富含模体。任务是在这些序列中找到共同的模体。以下概率算法的核心思想是，如果

我们在每个序列中得到了模体起始位置，找到模体PWM将是微不足道的；同样，如果我们得到了特定模体的PWM，那么在输入序列中找到起始位置也会很容易。令Z为矩阵，其中Z_{ij}对应于模体实例在序列i (中位置j开始的概率，Z中总结的概率分布的图形展示在图17.8)中。因此，这些算法依赖于一个基本的迭代方法：给定模体长度L和初始矩阵Z，我们可以使用起始位置来估计模体，反过来再用得到的模体重新估计起始位置，对这两个步骤进行迭代，直到模体收敛。

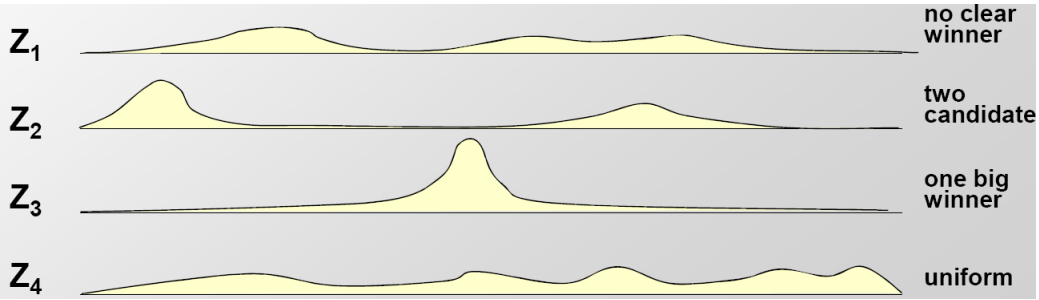

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图17.3：计算得到的Z矩阵示例

17.2.2 The E step: Estimating Z_{ij} from the PWM

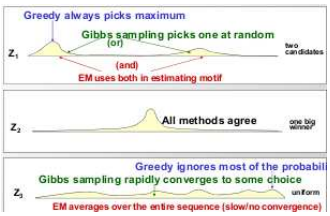

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图17.4：选择模体位置：贪婪算法总是会选择模体最可能的位置。EM算法会取平均值，而Gibbs采样实际上会在每一步利用由Z给出的概率分布来抽样一个模体。

Step 1: Initialization EM的第一步是生成初始概率权重矩阵（PWM）。PWM描述了基序中每个位置每种核苷酸的频率。在17.5中，有一个PWM的例子。在这个例子中，我们假设基序长度为八个碱基。

如果给定一组对齐的序列以及其中疑似模体的位置，那么通过计算疑似模体每个位置上每个碱基的频率即可得到PWM。我们可以通过随机选择起始位置来初始化PWM。

我们将PWM称为p_{ck}，其中p_{ck}是基c在模体位置k出现的概率。注意：如果概率为0，通常最好在概率中插入伪计数。PWM也称为概貌矩阵。除了PWM之外，我们还保留一个背景分布$p_{ck,k=0}$，即不在模体中的碱基分布。

Step 2: Expectation 在期望步骤中，我们生成一个向量 Z_{ij}，其中包含基序在序列 i 中位置 j 开始的概率。在EM算法中，Z 向量为我们提供了一种分类序列中所有核苷酸的方法，并告诉我们它们是否属于基序的一部分。我们可以使用贝叶斯规则计算 Z_{ij}。这简化为：

$$Z_{ij}^t = \frac{Pr^t(X_i|Z_{ij})Pr^t(Z_{ij}=1)}{\Sigma_{k=1}^{L-W+1} Pr^t(X_i|Z_{ij}=1)Pr^t(Z_{ik}=1)}$$

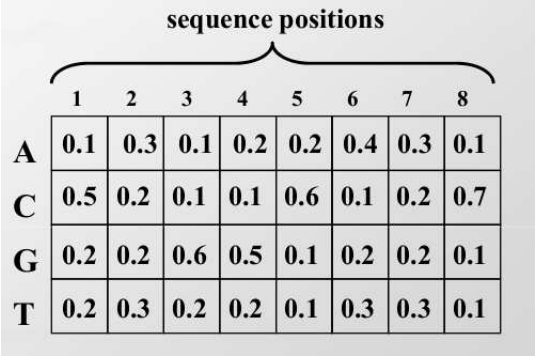

图17.5：样本位置权重矩阵

$$\Pr(X_i \mid Z_{ij} = 1, p) = \underbrace{\prod_{k=1}^{j-1} p_{c_k,0}}_{\text{before motif}} \underbrace{\prod_{k=j}^{j+W-1} p_{c_k,k-j+1}}_{\text{motif}} \underbrace{\prod_{k=j+W}^{L} p_{c_k,0}}_{\text{after motif}}$$

其中 $Pr^t(X_i|Z_{ij}=1) = Pr(X_i|Z_{ij}=1,p)$ 定义为

这是给定模体从位置j开始时序列i的概率。第一个和最后一个乘积对应于候选模体之前和之后的序列来自某个背景概率分布的概率，而中间的乘积对应于候选模体实例来自模体概率分布的概率。在此方程中，我们假设序列长度为L，模体长度为W。

17.2.3 M step: Finding the maximum likelihood motif from starting positions Zij

Step 3: Maximization 一旦我们计算出 Z^t，我们就可以利用这些结果来更新PWM和背景概率分布。我们可以使用以下方程来更新PWM

$$p_{c,k}^{(t+1)} = \frac{n_{c,k} + d_{c,k}}{\sum_b (n_{b,k} + d_{b,k})}$$

pseudo-counts

$$n_{c,k} = \begin{cases} \sum_i \sum_{\{j|X_{i,j+k-1}=c\}} Z_{ij} & k > 0 \text{ motif} \\ n_c - \sum_{j=1}^{W} n_{c,j} & k = 0 \end{cases}$$

total # of c's in data set

Step 4: Repeat 重复步骤2和3，直到收敛 e.

一个可能的测试方法是，检查剖面矩阵是否收敛，通过衡量在最大化步骤后PWM中每个元素的变化量。若变化量低于预设阈值，即可终止算法。EM算法是确定性的，完全依赖于初始起点，因为它使用了整个概率分布的平均值。因此，建议使用不同的初始位置重新运行算法，以降低收敛于非全局最大值的局部最大值的概率，并更好地理解解空间。

17.3 Gibbs Sampling: Sample from joint (M,Zij) distribution

17.3.1 Sampling motif positions based on the Z vector

Gibbs采样与EM相似，但区别在于Gibbs采样是一个随机过程，而EM是确定性的。在期望步骤中，我们在Gibbs采样中仅考虑模体窗口内的核苷酸。在最大化步骤中，我们从Z_{ij}中抽样，并使用结果更新PWM，而不是像EM那样对所有值求平均。

Step 1: Initialization 与EM一样，你通过随机抽样初始起始位置来生成初始PWM。主要区别在于最大化步骤。在EM过程中，算法通过考虑模体的所有可能起始点来创建序列模体。而在Gibbs中，算法根据起始点的概率Z选择单个起始点来生成模体。

Step 2: Remove 从你的序列集合中移除一个序列X_i。你将更改这个特定序列的起始位置。

Step 3: Update 使用剩余的序列集合，通过计算每个位置每种碱基出现的频率来更新PWM，并在必要时添加伪计数。

Step 4: Sample 使用新更新的PWM，计算序列X_i中每个起始点的得分。为了生成每个得分Z_{ij}，使用以下公式：

$$A_{ij} = \frac{\prod_{k=j}^{j+W-1} p_{ck}, k-j+1}{\prod_{k=j}^{j+W-1} p_{ck}, 0}$$

这仅仅是使用模体PWM生成该序列的概率除以使用背景PWM生成该序列的概率。通过基于其Z_{ij}随机选择一个位置，为X_i选取一个新的起始位置。

Step 5: Iterate L回到步骤2并迭代算法直到收敛 收敛。

17.3.2 More likely to find global maximum, easy to implement

由于Gibbs在最大化步骤中根据Motif的单个样本而非每个样本按其得分加权来更新其序列模体，因此Gibbs对起始PWM的依赖性较小。由于这一事实，EM比Gibbs更可能陷入局部最大值。然而，这并不意味着Gibbs总能返回全局最大值。必须多次运行Gibbs以确保找到的是全局最大值而非局部最大值。应用于此问题的两种流行的Gibbs采样实现是AlignACE和BioProspector。更通用的Gibbs采样器可在

程序 WinBUGS。AlignACE 和 BioProspector 都使用上述算法对多个初始值进行选择，然后报告常见的模体。Gibbs 采样比 E-M 更容易实现，理论上它收敛快，且不太可能陷入局部最优。然而，搜索不够系统。

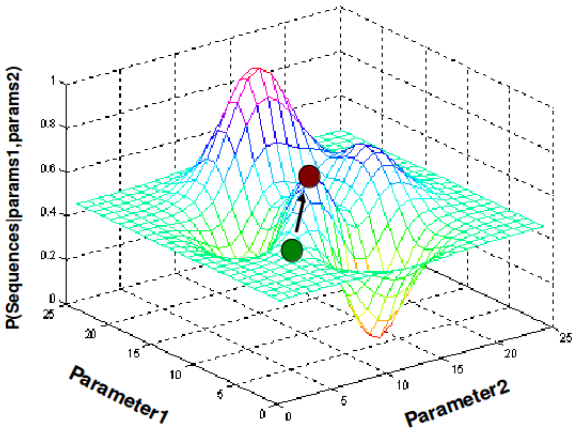

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图17.6：吉布斯采样

17.4 De novo motif discovery

如本章开头所述，模体发现的核心问题是定义有效模体的标准及其位置。由于大多数模体与重要的生物功能相关联，人们可以将生物体置于多种条件下，以期触发这些生物功能。然后可以寻找差异表达的基因，再以这些基因为基础，判断哪些基因在功能上相关，因而可能受同一模体实例调控。然而，这种技术不仅依赖于对感兴趣生物功能的先验知识来进行探测，还容易受到实验过程中的偏差影响。另外，也可以使用ChIP-seq来寻找模体，但这种方法不仅依赖于已知的感兴趣转录因子，还需要开发能够识别该转录因子的抗体，这可能既昂贵又耗时。

理想情况下，人们能够从头发现模体，即不依赖于已知基因集或转录因子。尽管这看似是一个难题，但实际上可以通过利用全基因组的保守性来实现。由于生物学功能通常在物种间是保守的，并具有独特的进化特征，因此可以比对近缘物种的序列，并专门在保守区域（也称为保守岛）中搜索，以提高发现功能性模体的速率。

17.4.1 Motif discovery using genome-wide conservation

保守岛通常与已知模体重叠，因此通过进化保守区域进行全基因组扫描可以帮助我们从头发现模体。然而，并非所有保守区域都是模体；例如，模体周围的核苷酸也可能保守，即使它们本身并非模体的一部分。通过寻找富集，可以将模体与背景保守区域区分开来，这将更特异性地选择参与调控模体的kmer。例如，可以通过寻找基因上游基因间区中相对于对照富集的保守序列来发现调控模体。

例如编码序列等区域，因为人们会预期模体在基因启动子内或周围富集。我们还可以扩展此模型以寻找简并模体：我们可以寻找由可变长度间隔分隔的较小、非简并模体的保守性，如下图所示。我们还可以通过贪婪搜索扩展此模体，以更接近找到局部最大似然模体。最后，模体的进化也可以揭示哪些模体是简并的；由于一个特定模体如果在整个进化过程中经常被另一个模体替换，则它更可能是简并的，因此模体聚类可以揭示哪些kmer可能对应于同一模体。

事实上，该策略具有其生物学相关性。2003年，Kellis教授提出，必定存在某种选择压力，促使特定序列出现在特定位置。他关于此主题的博士论文可在以下位置找到：
http://web.mit.edu/manoli/www/publications/KellisThesis03.pdf

图17.7：使用模体种子寻找简并模体

17.4.2 Validation of discovered motifs with functional datasets

这些预测的基序随后可通过功能数据集进行验证。具有以下至少一项特征的预测基序更可能是真实的基序：-在共调控基因中富集。这可以进一步扩展到更大的基因群；例如，已发现基序在特定组织中表达的基因中富集-与TF结合实验重叠-在同一复合体的基因中富集-相对于转录起始位点（TSS）的位置偏好：基序在基因TSS中富集-基因上游与下游、基因间与基因内的位置偏好：基序通常在编码序列中缺失-与已知转录因子基序的相似性：一些但并非所有发现的基序可能与已知基序匹配（然而，并非所有基序都是保守的，且$known$基序可能不完全正确）

17.5 Evolutionary signatures for instance identification

17.6 Phylogenies, Branch length score Confidence score

17.6.1 Foreground vs. background. Real vs. control motifs.

17.7 Possibly deprecated stuff below:

17.7.1 Greedy

虽然贪婪算法在实际中并不常用，但了解其运作方式及其相较于EM和吉布斯采样的优缺点至关重要。贪婪算法的工作机制与吉布斯采样相似，主要区别在于第四步。它不是随机选择一个新起始位置，而是总是选择概率最高的起始位置。

这使得贪婪算法比吉布斯采样略快，但显著降低了找到全局最大值的可能性。在起始位置概率分布相当均匀的情况下，贪婪算法忽略了除最可能位置外的所有其他起始位置的权重。

17.8 Comparing different Methods

Gibbs、EM和Greedy算法的主要区别在于计算完Z矩阵后的最大化步骤。Z矩阵的示例以图形方式表示如下。这个Z矩阵随后被用来重新计算原始剖面矩阵，直到收敛。该矩阵的一些示例由图17.8以图形方式表示。

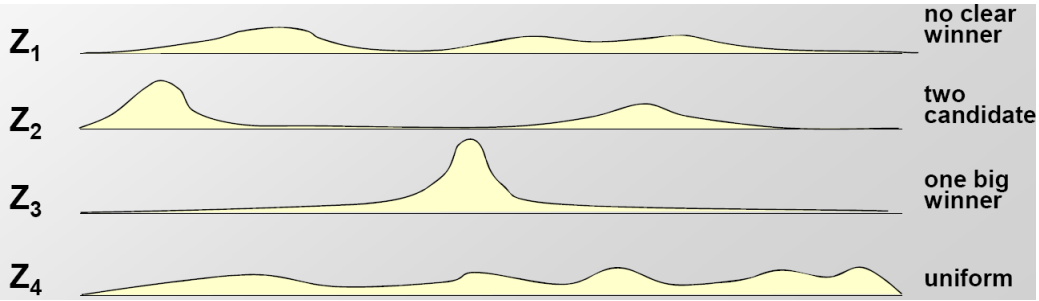

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图17.8：通过EM算法、Gibbs采样和贪心算法计算得到的Z矩阵示例。

直观上，贪婪算法总是会选择模体最可能的位置。EM算法会取所有值的平均值，而Gibbs采样实际上会利用Z给出的概率分布，在每一步中采样一个模体。

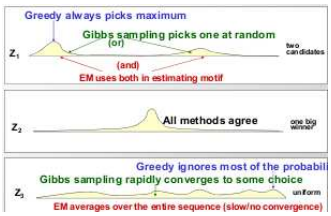

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图 17.9：选择模体位置：贪心算法总是选择最可能的模体位置。EM 算法取平均值，而 Gibbs 采样实际上使用由 Z 给出的概率分布，在每一步中采样一个模体。

17.9 OOPS,ZOOPS,TCM

不同类型的序列模型对数据集中模体出现的位置和方式做出不同的假设。最简单的模型类型是 OOPS（每序列一次出现），因为它假设数据集中每个序列恰好有一个模体出现。这就是我们在 Gibbs 采样部分分析的情况。这种模型类型由 Lawrence & Reilly (1990) [2] 引入，他们首次描述了 OOPS 的推广，称为 ZOOPS（每序列零次或一次出现），它假设每个数据集序列有零个或一个模体出现。最后，TCM（双组分混合）

模型假设数据集中每个序列中基序的出现次数为零次或多次且互不重叠，如Baily & Elkan（1994）所述。[1]这两类序列模型各自包含两个组件，分别对序列中的基序位置和非基序（背景）位置进行建模。基序由一系列离散随机变量建模，这些变量的参数给出了基序出现时各个位置上不同字母（DNA为4种，蛋白质为20种）出现的概率。序列中的背景位置则由单个离散随机变量建模。

17.10 Extension of the EM Approach

17.10.1 ZOOPS Model

之前介绍的方法（OOPS）依赖于这样一个假设：每个序列仅有一个基序特征（例如，给定序列中恰好有一个基序出现）。而ZOOPS模型则考虑了序列可能不包含基序的情况。

在这种情况下，令 i 表示一个不包含模体的序列。这一额外信息通过另一个参数 λ 添加到我们之前的模型中，用于表示序列中任意位置为模体起始位置 的先验概率。接下来，整个序列包含模体的概率为 $\lambda = (L - W + 1) * \lambda$

The E-Step

ZOOPS模型的E步计算缺失信息的期望值——即模体出现从序列X_i的位置j开始的概率。三种模型类型所使用的公式如下所示。

$$Z_{ij}^{t} = \frac{\Pr^{(t)}(X_i|Z_{ij}=1)\lambda^{(t)}}{\Pr^{(t)}(X_i|Q_i=0)(1-\lambda^{(t)}) + \sum_{k=1}^{L-W+1}\Pr^{(t)}(X_i|Z_{ik}=1)\lambda^{(t)}}$$

其中 λ^t 是序列 i 具有基序的概率，$Pr^t(X_i|Q_i = 0)$ 是 X_i 由一个不包含基序的序列 i 生成的概率

The M-Step

MEME中EM的M步使用前面的公式重新估计λ的值。数学原理与OOPS相同，我们只是更新λ和γ的值。

$$\lambda^{(t+1)} = \frac{\gamma^{(t+1)}}{(L-W+1)} = \frac{1}{n(L-W+1)}\sum_{i=1}^{n}\sum_{j=1}^{m} Z_{i,j}^{(t)}$$

上述模型考虑了没有任何基序的序列。挑战在于还要考虑每条序列中存在多个基序的情况。这可以

通过更通用的模型 TCM 实现。TCM（双组分混合模型）基于以下假设：每条序列中可能有零个、一个甚至两个模体出现。

图17.10：包含零个、一个或两个基序的序列。

17.10.2 Finding Multiple Motifs

以上所有序列模型类型都对包含单个基序的序列进行建模（注意TCM模型可以描述具有同一基序多次出现的序列）。为了在单个数据集中找到多个非重叠的不同基序，需将已发现基序的信息融入当前模型，以避免重复发现同一基序。三种序列模型类型均假设基序出现于序列x_i中每个位置j的概率相等。这转化为缺失数据变量Z_{ij}上的均匀先验概率分布。在E步中，必须对每个Z_{ij}使用新的先验，该先验考虑了从位置X_{ij}开始的新宽度-W基序出现可能与先前发现的基序出现重叠的概率。为帮助计算Z_{ij}上的新先验，我们引入变量V_{ij}，其中如果宽度-W基序出现可以从序列X_i中的位置j开始而不与先前遍历中发现的基序出现重叠，则V_{ij} ==1。否则V_{ij} ==0。

$$V_{\mathrm{ij}} = \begin{cases} 1, & \text{no previous motifs in } [X_{i,j}, \ldots, X_{i,j+w-1}] \\ 0, & \text{otherwise} \end{cases}$$

17.11 Motif Representation and Information Content

不使用Profile Matrix，我们也可以利用信息论来表示Motifs。在信息论中，关于某个事件的信息是通过消息传递的。消息携带的信息量以比特为单位衡量。通过观察消息所述事件的概率分布，我们可以确定消息携带的信息比特数。基本上，如果我们对事件的结果一无所知，消息将包含很多比特。然而，如果我们相当确定事件将如何发展，而消息只是证实了我们的猜测，那么消息携带的信息比特就非常少。例如，“明天太阳会升起”这句话并不令人惊讶，因此其信息量相当低。相反，“明天太阳不会升起”这句话非常令人惊讶，具有很高的信息含量。我们可以用以下方程计算给定消息中的具体信息量：$-\log p$。

香农熵是衡量消息中包含的预期信息量的一个指标。换句话说，它是通过每个事件发生的概率加权，衡量所有可能发生事件的消息所包含的信息量。香农熵由以下公式给出：

$$H(X) = -\sum_i p_i \log_2 p_i$$

当所有事件发生的概率相等时，熵达到最大值。这是因为熵告诉我们预期将获取的信息量。如果每个事件发生的几率相同，我们对事件本身了解得最少，因此预期将学到的信息量达到最大。例如，只有硬币公平的时候，抛硬币才具有最大熵。如果硬币不公平，那么我们对抛硬币的结果了解得更多，抛硬币结果的预期消息将包含较少的信息。

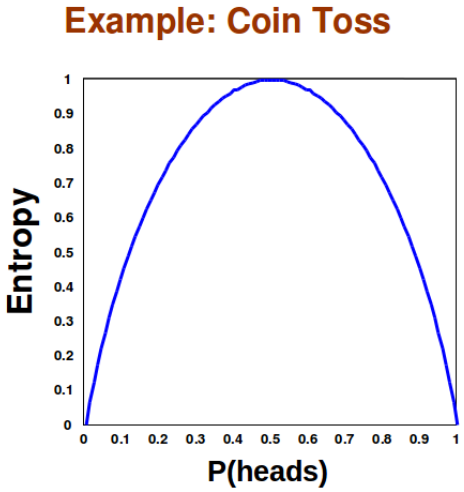

© source unknown. All rights reserved. This content is excluded 我们从Creative Commons 许可协议中提取。更多信息，请参见 http://ocw.mit.edu/help/faq-fair-use/。

图17.11：当正面和反面出现的概率相等时，熵达到最大。

我们可以通过应用Gibs采样或EM后对每个位置拥有多少信息来建模一个基序。在下面的图中，每个字母的高度表示我们对该碱基已学习到的信息比特数。较高的堆叠对应于基序中该位置碱基的更大确定性，而较低的堆叠则对应于更高程度的不确定性。有四个密码子可供选择时，每个位置的香农熵为2比特。看待这个图的另一种方式是，一个字母的高度与该位置碱基的频率成正比。

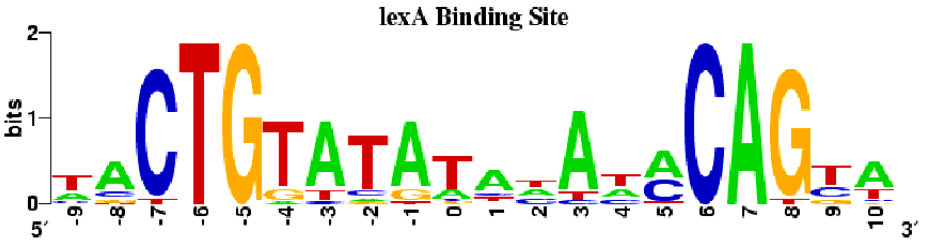

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图17.12：每个堆叠的高度表示吉布斯采样或EM算法告知我们的关于基序中位置的信息位数

在概率分布上存在一个称为Kullback-Leibler距离的度量。这使我们能够比较主题分布与某个真实分布的差异。K-L距离由下式给出：

$$D_{KL}(P_{motif}|P_{background}) = \Sigma_{A,T,G,C} P_{motif}(i) \log \frac{P_{motif}(i)}{P_{background}(i)}$$

在疟原虫中，G-C含量较低。假设G-C含量为20%，那么上述模体的表示如下。C和G碱基更为罕见，因此它们的普遍性极不寻常。请注意，在此表示中，我们使用了K-L距离，因此堆叠高度可能超过2。

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图17.13：假定低G-C含量并使用K-L距离时的lexA结合位点

Bibliography

[1] Timothy L. Bailey. 通过期望最大化拟合混合模型以发现生物聚合物中的基序。在 *Proceedings of the Second International Conference on Intelligent Systems for Molecular Biology* 中，第 28–36 页。AAAI Press，1994年。

[2] C E Lawrence 和 A A Reilly。一种用于识别和表征未对齐生物聚合物序列中共有位点的期望最大化(EM)算法。*Proteins*，7(1)：41–51，1990年。

CHAPTER

EIGHTEEN

监管基因组学

讲师：Pouya Kheradpour 记录
员：Maria Frendberg

Figures

18.1 Challenges in Regulatory Genomics 266

18.1 Introduction

每个细胞都有相同的DNA，但由于基因在时间和空间上的调控，它们的表达模式各不相同。调控基因组学解释了这些复杂的基因表达模式。我们将要讨论的调控因子包括：

- *Transcription Factor (TF)*- 调控DNA向mRNA的转录过程。转录因子是在转录前与DNA结合的蛋白质，能增强或减弱转录。通过使用蛋白质或抗体的实验方法，我们可以确定转录因子的特异性。通过基因与已知转录因子的相似性，我们可以找到这些基因。

- *Micro RNA (miRNA)*- 调控mRNA向蛋白质的翻译。miRNA是转录后与mRNA结合并能减少翻译的RNA分子。我们可以通过实验方法（如克隆）或利用保守性和结构的计算方法来确定miRNA的特异性。

18.1.1 History of the Field

18.1.2 Open Problems

转录因子（TF）和微小RNA（miRNA）都是调节因子，我们可以通过实验和计算方法来发现它们。我们将讨论一些计算方法，特别是利用进化特征的方法。这些调节因子与特定的模式结合，称为基序。我们可以使用实验和计算方法来预测调节因子将结合的基序。我们将讨论通过进化和结构特征来识别miRNA，以及通过从头比较发现来识别TF和miRNA，这种方法理论上可以找到所有基序。给定一个基序，找到与之结合的调节因子是困难的。

靶标是因子结合的位置。存在许多序列模体，但许多不会结合；只有一部分会成为靶标。特定调控子的靶标可以通过实验方法确定。在第11讲中，讨论了给定靶标寻找模体的方法。我们还将讨论给定模体寻找靶标。

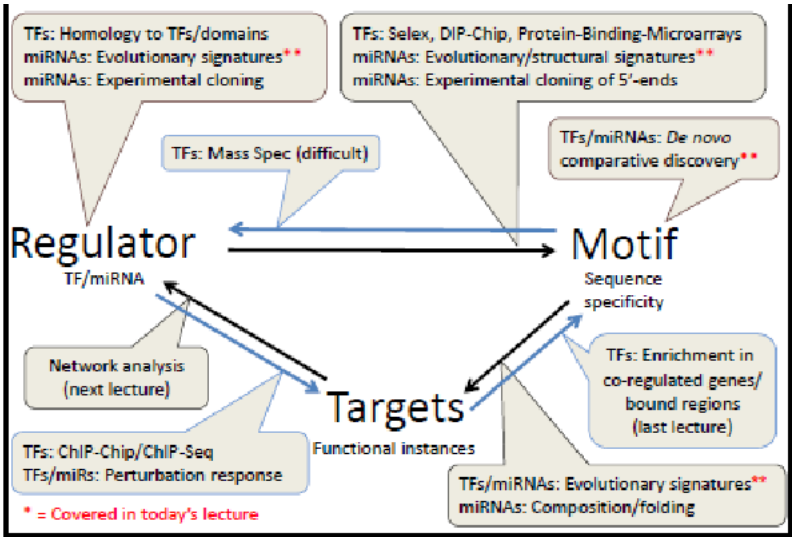

图18.1：监管基因组学中的挑战

18.2 *De Novo* Motif Discovery

18.2.1 TF Motif Discovery

转录因子通过结合基因附近的DNA，作为激活因子或抑制因子影响靶基因的表达。这种结合受转录因子序列特异性的引导。DNA序列越接近碱基偏好，该因子结合的可能性就越大。这些基序既可以通过计算方法发现，也可以通过实验方法发现。发现这些基序主要有三种方法。

- *Co-Regulation*- 在第11讲中，我们讨论了一种通过寻找可能结合模体的序列来发现模体的共调控类型。我们随后可以使用枚举方法或

在上游区域中寻找这些基序的对齐方法。我们可以将类似的技术应用于已知基序结合位置的实验数据。

- *Factor Centric*- 还有一些以因子为中心的方法用于发现模体。这些方法大多是实验性的，需要蛋白质或抗体。示例包括SELEX、DIP-Chip和PBMs。所有这些方法都是体外的。

- *Evolutionary*- 进化方法不是只关注一个因素，而是关注所有因素。我们可以从查看单个因素开始，确定我们可以利用哪些特性。有些序列优先被保守（保守岛）。然而，这些并不总是模体，而可能是由于偶然或非模体保守。然后，我们可以查看许多区域，找到更多保守模体，并确定哪些总体上更保守。通过在许多基因组中的许多区域测试保守性，我们提高了检验效力。这些模体具有某些进化特征，有助于我们识别它们：模体在基因间区比在编码区更保守，模体更可能位于基因上游而不是下游。这是一种获取已知模体并检验其是否保守的方法。

我们现在想要找出所有比预期更保守的内容。这可以通过爬山法来实现。我们首先枚举模体种子，这些种子通常呈现为3-间隔-3的形式。接着，使用经过组成和小计数校正的保守比率对每个种子进行评分和排序。随后，这些种子通过爬山法扩展，以填补种子周围未指定的碱基。通过这些方法，有可能以不同方式达到相同或非常相似的种子。因此，我们的最后一步是利用序列相似性对种子进行聚类，以去除冗余。

我们可以使用的最后一种方法是记录在进化过程中一个序列被另一个序列替换的频率。这会产生对应于单个基序的k-mer簇。

18.2.2 Validating Discovered Motifs

我们有很多方法可以验证发现的模体。首先，我们期望它们与真实模体匹配，这确实比随机模体发生的频率显著更高。然而，这并不完全一致，可能是因为许多已知模体并不保守，而且已知模体存在偏差，可能遗漏了真实模体。位置偏差。偏向于TSS，

模体也具有功能富集。如果特定转录因子在某一组织中表达，那么我们预期其上游区域会含有该因子的模体。这也揭示了协同模体的模块。我们还发现，大多数模体在普遍表达的基因中被规避，从而避免它们被随机开启和关闭。

18.2.3 Summary

所有这些方法都有缺点。无论是转录因子中心还是区域中心的方法都不全面，且带有偏向性。转录因子中心的方法需要转录因子或抗体，耗时且昂贵，还面临计算挑战。利用保守性进行从头发现是无偏的，但它无法将基序与因子匹配，并且需要多个基因组。

18.3 Predicting Regular Targets

18.3.1 Motif Instance Identification

一旦发现潜在的模体，下一步是确定哪些模体匹配是真实的。这可以通过实验和计算方法来完成。

- *Experimental* - 可以使用ChIP-Chip和ChIP-Seq方法通过实验识别实例。这两种方法都是体内方法。这是通过交联细胞来完成的。DNA首先被切成片段。然后加入蛋白质及其抗体或标记的蛋白质，它会与各种序列结合。这些结合的序列现在被拉出，并且交联被逆转。这使我们能够确定该因子在基因组中的结合位置。这有很高的假阳性率，因为在许多情况下，因子结合了但并不具有功能。这是一种非常流行的实验方法，但它受到抗体可用性的限制，而许多因子的抗体很难获得。

- *Computational*- 计算方法。也有许多计算方法来识别实例。单基因组方法使用模体聚类。它们寻找许多匹配以增加功效，并能够找到调控区域（CRMs）。然而，它们会遗漏单独出现的模体实例，以及需要一组特定因子共同作用的情况。多基因组方法，被称为系统发育足迹法，面临许多挑战。它们首先比对许多序列，但即使在功能性模体中，序列也可能移动、突变或缺失。Kheradpour 采取的方法通过不要求完全保守（使用分支长度得分）以及不要求精确比对（在窗口内搜索）来处理这一问题。

分支长度分数（BLS）是通过取一个基序匹配并在其他物种中搜索它来计算的。然后，找到包含所有具有基序匹配的物种的最小子树。总树的百分比即为BLS。以这种方式计算BLS允许基序简并性、错配和窗口内移动所允许的突变，以及密集物种树中缺失的基序。

然后将该BLS转换为置信度分数。这使我们能够评估给定分数的可能性，并考虑基序组成和长度的差异。我们通过在每个BLS处计数所有基序实例和控制基序来计算这个置信度分数。然后我们想要查看基序实例中哪些部分看起来是真实的。置信度分数是信号/(信号+噪声)。用于此计算的控制基序是通过生成原始基序的100次混合并筛选结果而产生的，要求它们与基因组的匹配程度为原始基序的+/- 20%。然后根据它们与已知基序的相似性进行排序和聚类。按照相似性递增的顺序，从每个簇中最多取一个基序，以生成我们的控制基序。

18.3.2 Validating Targets

与模体发现类似，我们可以通过观察靶标在基因组中的位置来验证它们。置信度会选择启动子中的TF模体实例和3‘UTR中的miRNA模体，这正是我们所预期的。TF可以出现在任一条链上，而miRNA必须仅落在一条链上。因此，尽管对TF没有偏好，miRNA却优先发现于正链上。

验证靶标的另一种方法是通过计算富集度。这需要有一组背景和前景区域。这些区域可以是共调控基因的启动子与所有基因或与由某个因子结合的区域与其他基因间区域的对比。富集度的计算是通过取模体

前景内的实例与前景中碱基的比例。使用对照基序对组成和保守水平进行校正。这些比例可以使用二项置信区间使其更保守。

然后可以通过与使用ChIP-Seq发现的实验实例进行比较来验证目标。这表明保守的CTCF基序实例在ChIP-Seq位点中高度富集。提高置信度也会增加富集。利用这一点，许多基序实例得到了验证。ChIP-Seq并不总能找到功能性基序，因此这些结果可以通过与保守的结合区域进行比较来进一步验证。这发现交叉区域中的富集显著更高。这显示了因子结合的位置，这些结合在进化中具有值得保守的影响。这两种方法互为补充，结合使用时效果更佳。

18.4 MicroRNA Genes and Targets

18.4.1 MiRNA Gene Discovery

MiRNA是转录后调节因子，通过与mRNA结合来沉默基因。它们在发育过程中是极其重要的调节因子。当miRNA基因从基因组转录时，这些调节因子便形成了。由此产生的链在某个时刻形成发夹结构。这一结构经过加工、修剪并被输出到细胞质中。随后，另一种蛋白质修剪发夹结构，其中一半被整合进RISK复合体中。通过这种方式，它能够告知RISK复合体应结合到哪里，从而决定哪个基因被关闭。第二条链通常会被丢弃。确定哪条链是哪一条是一个计算问题。这里的计算问题是如何找到与这些miRNA相对应的基因。

第一个问题是找到发夹结构。简单折叠基因组会产生大约760,000个发夹结构，但真正的miRNA只有60到200个。因此，我们需要方法来提高特异性。可以考虑结构特征，包括折叠能量、环（数量、对称性）、发夹长度和对称性、子结构和配对，然而这只能将特异性提高40倍。因此，仅凭结构无法预测miRNA。还可以考虑进化特征。MiRNA显示出特征性的保守性质。发夹由一个环、两个臂和侧翼区域组成。在大多数RNA中，由于环用于结合，它是最保守的部分。然而，在miRNA中，臂更为保守，因为它们决定了RISK复合物将在何处结合。这将特异性提高了300倍。这些结构特征和保守性质可以结合起来，更好地预测潜在的miRNA。

这些特征通过机器学习，特别是随机森林，进行组合。这在正例和负例的子集上产生许多弱分类器（决策树）。然后，每个树对给定miRNA的最终分类进行投票。使用这种技术使我们能够达到所需的灵敏度（提高了4，500倍）。

18.4.2 Validating Discovered MiRNAs

发现的miRNA可以通过与已知miRNA比较来验证。课堂上给出的一个例子表明，81%的发现miRNA是已知存在的，这表明这些方法表现良好。推测的miRNA尚未经过测试，然而这可能会很困难，因为测试是通过克隆来完成的。

区域特异性是另一　　验证miRNA的r方法。在背景中，发　　引脚分布相当均匀

分布在内含子、外显子、基因间区以及重复序列和转座子之间。随着预测置信度的提高，几乎所有miRNA都如预期那样落入内含子和基因间区。这些预测也与测序读数相符。

这也产生了一些典型的miRNA基因组特性。它们偏好转录链，这使得它们能够搭便车存在于真实基因的内含子中，因此不需要单独的转录。它们还与已知和预测的miRNA聚集在一起，这表明它们属于同一家族，具有共同的起源。

18.4.3 MiRNA's 5' End Identification

前七个碱基决定了miRNA的结合位置，因此确切了解切割发生的位置至关重要。如果这个切割点即使错两个碱基，miRNA也会被预测为与完全不同的基因结合。这些切割点可以通过计算发现，方法是搜索可能作为靶标的高度保守的7-mer。这些7-mer也与广泛表达基因中缺乏抗靶标相关。利用这些特征、结构特征和保守特征，可以采用机器学习方法（SVMs）来预测切割位点。有些miRNA没有单一的高得分位置，而这些在细胞中也表现出不精确的加工。如果星序列得分很高，那么它在细胞中往往也表达得更多。

18.4.4 Functional Motifs in Coding Regions

每种基序类型都有独特的特征。DNA是链对称的，RNA是链特异且框不变的，而蛋白质是链特异且框偏向的。这种框不变性可以用作一种特征。然后可以分别评估每个框。由双密码子使用偏好引起的基序仅在一个框偏移中保守，而由RNA水平调控引起的基序在所有三个框偏移中保守。这使得能够区分重叠的压力。

18.5 Current Research Directions

18.6 Further Reading

18.7 Tools and Techniques

18.8 What Have We Learned?

Bibliography

CHAPTER

NINETEEN

表观基因组学/染色质状态

Figures

19.1 A. 表观基因组中存在多种多样的修饰。DNA的某些区域紧密缠绕在组蛋白上，使得DNA难以接近，基因处于非活性状态。其他区域则有更易接近的DNA，因此基因活性较高。表观遗传因子可以结合到这些组蛋白的尾部，以改变这些特性。B. 组蛋白修饰提供了关于哪些类型的蛋白质结合到DNA上以及该区域功能的信息。在此示例中，组蛋白修饰使得一个增强子区域（可能远超过100千碱基）能够与启动子区域相互作用。[6] . . 290 19.2 染色质免疫沉淀法[5]。此图中的步骤对应于此过程的六个步骤。 . . . . . 290 19.3 （顶部）在Burrows-Wheeler正向转换中，生成并排序旋转。排序后列表的最后一列（加粗）构成了转换后的字符串。（底部）在Burrows-Wheeler逆向转换中，转换后的字符串被排序，生成两列：一列由原始字符串组成，另一列由排序后的字符串组成。这两列实际上形成了正向转换中旋转的两个列。重复此过程，直到生成完整的旋转。 . . . . . 291 19.4 为了使用输入DNA作为对照，可以正常进行ChIP实验，同时进行相同的实验（使用相同的DNA）但不加抗体。这会产生一个背景信号，我们可以据此进行校正。 . . . . . 291 19.5 上图中，每一列是一个颜色编码的直方图，编码了所有映射读段中在每个位置（x轴）具有碱基得分Q（y轴）的比例。每个碱基平均得分低意味着错配概率较大。我们通常拒绝平均得分Q低于10的读段。 . . . . . 292 19.6 样本信号轨迹。在此，红色信号来源于针对目标H3K36me3的ChIP-seq实验中，每个位置映射到基因组的读段数量。该信号给出了标记的富集水平。 . . . . . 292 19.7 真实实验和背景（对照）的样本信号轨迹。当真实实验信号值远高于背景信号值时，认为区域具有统计学显著性富集。 . . . . . 292 19.8 HMM模型的数据和注释示例。底部部分显示了映射到基因组的读段原始数量。顶部部分显示了HMM模型的注释。 293

19.9 具有51个状态的最终模型的发射概率。对应于标记 i 和状态 k 的单元格表示在状态 k 中观测到标记 i 的概率。. . . . . 294 19.10具有51个状态的最终模型的转移概率。转移概率从绿色到红色增加。通过聚类转移矩阵，揭示了相邻染色质状态之间以及状态的不同子组之间的空间关系。值得注意的是，该矩阵是稀疏的，因此表明大多数是不可能的。. . . . . 295 19.11染色质状态定义和功能解释。[7] a. 与每个状态相关的染色质标记组合。每一行显示了与每个染色质状态相关的标记的特定组合，以及它们在颜色标度中出现的频率介于0和1之间。这些对应于在模型训练期间在整个基因组中学习到的HMM的发射概率参数。b. 染色质状态的基因组和功能富集，包括基因组不同部分（例如转录区域、TSS、基因的RefSeq 5'端或3'端等）的倍数富集，以及进化上保守元件、DNaseI超敏位点、CpG岛等的倍数富集。所有富集均基于后验概率分配。c. 生物状态功能和解释的简要描述（chr，染色质；enh，增强子）。. 296

19.1 Introduction

人体包含大约210种不同的细胞类型，但每种细胞类型都共享相同的基因组序列。尽管拥有相同的遗传密码，细胞不仅从这一相同序列发展成不同的类型，而且随着时间的推移和分裂过程，还能保持相同的细胞类型。关于细胞类型和细胞状态的信息被称为$epigenomic$信息。表观基因组（“epi”在希腊语中意为“之上”，因此表观基因组意味着基因组之上）是一组化学修饰或标记，它们影响基因表达，并在细胞分裂过程中传递，且在少数有限的情况下，还能跨越生物体的世代传递。

如图19.1所示，细胞中的表观基因组信息以多种方式编码。例如，DNA甲基化（如CpG二核苷酸处）可以改变基因表达。类似地，核小体（DNA包装单元）的定位决定了DNA哪些部分可供转录因子结合以及其他酶作用。近二十年的研究已揭示了数百种组蛋白尾巴的翻译后修饰。由于对于任何给定的组蛋白尾巴，可能存在极大量的组蛋白修饰状态，因此提出了“组蛋白密码假说”。该假说认为，特定的组蛋白修饰组合编码信息。尽管这一假说存在争议，但它指导了表观遗传学领域。表观遗传学的核心是理解染色质的化学修饰（无论是DNA甲基化、组蛋白修饰还是染色质结构）是如何建立的，以及细胞如何“解读”这些信息以建立和维持基因表达状态。

在本章中，我们将探讨用于揭示细胞类型内染色质状态的实验和计算技术。我们将学习如何利用染色质免疫沉淀来推断基因组中被蛋白质或目标结合的区域，以及一种常用算法（Burrows-Wheeler变换）如何能够快速将大量短测序读段映射到参考基因组。在此基础上，我们进一步抽象一个层次，并使用隐马尔可夫模型（HMM）将基因组分割为具有相似染色质状态的区域。最后，我们将展示这些全面的染色质状态图谱如何在不同细胞类型之间进行比较，并可用于提供关于细胞状态如何建立和维持以及遗传变异对基因表达影响的信息。

19.2 Epigenetic Information in Nucleosomes

为了将两米长的DNA装入直径5-20 μm 的细胞核中，并安排DNA便于转录机制访问，DNA被包装成染色质。核小体构成了这种包装的单位。一个核小体由大约150-200 bp长的DNA组成，缠绕在一个由组蛋白H2A、H2B、H3和H4各两份拷贝组成的八聚体上（偶尔还包括连接组蛋白H1或H5）。虽然核小体更高级别包装的结构和重要性了解较少，但核小体较低级别的排列和修饰对转录调控和不同细胞类型的发展非常重要。组蛋白H3和H4是真核生物域中最保守的蛋白质。

核小体通过两种主要方式编码表观遗传信息：染色质可及性和组蛋白修饰。

首先，核小体在DNA上的位置决定了DNA哪些部分是可达的。核小体常位于不活跃基因的启动子处。为了启动基因的转录，转录因子（TFs）和RNA聚合酶复合体必须与其启动子结合。因此，当基因变得活跃时，位于其启动子处的核小体通常会被移除，以便RNA聚合酶能够启动转录。因此，核小体在DNA上的定位是稳定的，但也是可变的。这种稳定性和可变性的特性是任何形式的表观遗传信息的前提条件，因为细胞需要维持特定细胞类型的身份，同时仍能改变其表观遗传状态以响应环境变化。

染色质可及性还可以由在细胞核中漂浮的转录RNA（具体而言是“增强子RNA”或eRNA）调节。特别是，Mousavi等人在2013年发现，在基因外增强子区域转录的eRNA增强了RNA聚合酶II的占据（其速率受染色质可及性限制）以及其他转录机制的部署，从而导致远端靶基因的表达增强[9]。

其次，组蛋白包含从构成核小体八聚体的球状核心结构域突出的非结构化尾部。这些尾部可以经历翻译后修饰，如甲基化、乙酰化和磷酸化，每一种都会影响基因表达。一些参与转录调控的蛋白质特异性地结合于特定的组蛋白修饰或修饰组合，并招募更多的转录因子，从而增强或抑制附近基因的表达。因此，“组蛋白密码假说”认为，特定基因组位点上组蛋白修饰的不同组合通过差异转录调控编码生物学功能。在这个模型中，组蛋白修饰类似于不同的读者用不同颜色的便利贴标记书本的各个部分——组蛋白修饰允许同一基因组在不同时间和不同组织中被不同地解读（即转录）。实验已发现超过100种不同的组蛋白修饰。表19.1列出了六种最为明确的组蛋白修饰，以及它们在基因组中出现的典型特征宽度和推测的相关调控元件。请注意，所有这些修饰都位于H3和H4的赖氨酸上。H3和H4的修饰最为明确，因为H3和H4是最高度保守的组蛋白（使得这些组蛋白的修饰更可能具有保守的调控功能），并且因为这些组蛋白所有常见观察到的修饰都有良好的抗体可用。

组蛋白修饰是如此频繁地被引用，以至于人们开发了一种简写来标识它们。这种简写包括组蛋白的名称、其尾部被修饰的氨基酸残基以及对该残基所做的修饰类型。举例来说，组蛋白H3从N端数起的第四个残基——赖氨酸，在活跃基因的启动子区域常发生甲基化。这种修饰被描述为H3K4me3（如果发生三次甲基化）。简写的首部分对应组蛋白，本例中为H3；K4对应从末端数起的第4个残基，本例中为赖氨酸，而me3

对应于实际的修饰，即在此情况下添加3个甲基基团。

Histone Modification	Signature	Associated Regulatory Element
H3K4me1	(wide) focal	active promoters/enhancers
H3K4me3	(wide) focal	active promoters/enhancers
H3K9me3	wide	repressed regions
H3K27ac	focal	active promoters/enhancers
H3K27me3	wide	repressed regions
H3K36me3	wide	transcribed regions

表19.1：六种最为明确的组蛋白修饰及其典型特征宽度和推测相关的调控元件。“聚焦”表示每种组蛋白修饰在基因组中具有相对狭窄的特征（峰宽 < 5kb），而“广泛”则表示广泛特征。

表观遗传修饰影响生物学功能的一个例子常见于基因组的增强子区域。这些增强子区域通常远离它们所调控的基因和启动子。增强子能够通过组蛋白修饰（乙酰化和甲基化）与特定启动子接触。这导致DNA自身折叠，使启动子、增强子和招募的转录因子相互接触，从而激活先前被抑制的启动子。这个系统可以非常动态，以至于在组蛋白修饰后不到一分钟，细胞就会显示出表观遗传影响的迹象，而其他修饰（主要是在发育过程中的修饰）则会以较慢的方式显现。这也是某些类型的组蛋白修饰如何帮助我们预测增强子区域的一个例子。

在给定的基因组位点上，可能存在不止一种组蛋白修饰，因此组蛋白修饰能够协同且竞争性地发挥作用。甚至同一核小体内某个组蛋白的两个拷贝也可能具有不同的修饰（尽管通常组蛋白修饰的“书写者”会定位在一起，从而在核小体内的两个拷贝上产生相同的修饰）。因此，为了准确判定某个基因组区域的染色质状态，有必要同时考虑该区域内所有的组蛋白修饰。如第节所述，随着2015年Roadmap表观基因组计划的完成，可以使用一个稳健的隐马尔可夫模型（以组蛋白修饰为发射，以染色质状态为隐藏状态）来实现这一点。

Did You Know?
具有表观遗传修饰的最简单生物是酵母。酵母是单细胞生物；因此，表观遗传修饰并不负责细胞分化。随着生物体变得更加复杂，它们往往具有更多的表观遗传修饰。

19.2.1 Epigenetic Inheritance

表观遗传/表观基因组特征的可遗传程度尚不清楚，因此成为许多争论和持续研究的主题。在有性生殖的生物体中，大多数表观遗传修饰在减数分裂和/或受精过程中丢失，但有些修饰有时会保留下来。此外，在此过程中，父源与母源表观遗传标记被移除或重塑的方式存在偏差。特别是，母源DNA甲基化通常在受精时保留，而父源DNA几乎总是完全去甲基化。此外，由于未知原因，一些基因组元件，如着丝粒卫星，更可能逃避表观遗传重置。在减数分裂和受精时表观基因组擦除不完全发生的情况下，跨代表观遗传继承可能发生。一般参见[4]。

另一种可能受表观遗传继承机制调控的现象是亲本印记。

印记。在亲本印记中，某些常染色体基因当且仅当从个体的母亲遗传时才表达，而其他常染色体基因当且仅当从个体的父亲遗传时才表达。例如，小鼠的Igf2基因（仅当从父亲遗传时才表达）和小鼠的H19基因（仅当从母亲遗传时才表达）。这些基因的DNA序列没有变化，但在基因的失活拷贝中，某些核苷酸上观察到额外的甲基基团。这种印记的机制和因果关系尚不清楚。

19.3 Epigenomic Assays

19.3.1 ChIP: a method for determining where proteins bind to DNA or where histones are modified

鉴于表观基因组信息在生物学中的重要性，人们投入了大量精力来研究量化这一信息的信号。一种常用的表观基因组标记测量方法称为染色质免疫沉淀（ChIP）。**ChIP technology**产生DNA片段，其在基因组中的位置表示特定组蛋白修饰或转录因子的位置。ChIP的步骤如下所述，并在图19.2中展示：

1. 细胞暴露于交联剂如甲醛中，促使DNA与其结合蛋白（例如具有特定修饰的组蛋白）之间形成共价键。 2. 从细胞核中分离基因组DNA。 3. 通过超声破碎或酶解将分离的DNA片段化。 4. 培养抗体以识别特定蛋白质，如参与组蛋白修饰的蛋白质。抗体的培养方法是将目标蛋白质暴露给哺乳动物，如山羊或大鼠，其免疫反应随后引发所需抗体的产生。 5. 将抗体加入溶液中，进行免疫沉淀并纯化复合物。 6. 解除蛋白质与DNA间的交联，并纯化针对特定表观遗传标记的DNA片段。

在ChIP实验之后，我们得到了一些短的DNA序列，这些序列对应于组蛋白与DNA结合的位置。为了确定这些DNA片段在基因组中的位置，我们可以将它们与阵列或基因芯片上的已知DNA片段进行杂交，并通过荧光标记进行可视化；这种方法被称为ChIP-chip。另外，也可以对这些片段进行大规模并行下一代测序；这被称为**ChIP-seq**。后一种方法，即ChIP-seq，是一种更新且使用更为频繁的方法。它之所以更受青睐，是因为它具有更宽的检测动态范围，并避免了ChIP-chip中的交叉杂交等问题。

每个序列标签长30个碱基对。这些标签映射到30亿碱基的参考基因组中的唯一位置。读取数量取决于测序深度，但通常每个ChIP-seq实验大约有1000万条映射读取。

给定一组来自ChIP-seq实验的短测序读段，有一个相当标准的流程用于推断感兴趣蛋白质在基因组每个位点上的富集情况。首先，必须将DNA片段映射到DNA上（称为读段映射）。接下来，我们必须确定基因组中哪些区域具有统计上显著的感兴趣蛋白质富集（称为峰调用）。在这些预处理之后

通过这些步骤，我们可以构建不同的监督和无监督模型，以研究染色质状态及其与生物学功能的关系。我们将逐一探讨这些步骤。

19.3.2 Bisulfite Sequencing: a method for determining where DNA is methylated

DNA甲基化是首个被发现的表观基因组修饰，并且是一个重要的转录调控因子，因为CpG二核苷酸中胞嘧啶残基的甲基化会导致转录的“沉默”或抑制。亚硫酸氢盐测序是一种在测序前用亚硫酸氢盐处理DNA的方法，能够精确确定DNA中被甲基化的核苷酸。亚硫酸氢盐处理将未甲基化的胞嘧啶残基转化为尿嘧啶，但不影响甲基化的胞嘧啶。因此，基因组DNA可以在有或没有亚硫酸氢盐处理的情况下进行测序，并比较序列，处理过的DNA中胞嘧啶未转化为尿嘧啶的位点（或者等效地，处理与未处理序列之间存在亚硫酸氢盐生成差异的位点）即为胞嘧啶被甲基化的位点。这种分析假设未甲基化的胞嘧啶残基完全转化为尿嘧啶，因此不完全转化可能导致假阳性（即被鉴定为甲基化但实际上并未甲基化的核苷酸）[11]。

19.4 Primary data processing of ChIP data

19.4.1 Read mapping

read mapping的问题旨在将给定的读段分配到参考基因组中最佳匹配的位置。鉴于读段数量庞大和人类基因组的规模，所有读段映射算法的一个共同要求是它们在空间和时间上都要高效。此外，它们必须允许由于测序错误和SNP导致的错配。

根据之前的讲座，我们知道多种进行读取映射的方法：序列比对（$O(mn)$时间复杂度）以及基于哈希的方法，比如BLAST等。还存在其他方法：线性时间字符串匹配（$O(m+n)$时间复杂度）和后缀树及后缀数组（$O(m)$时间复杂度）。然而，所有这些技术的一个问题是它们有较大的内存需求（通常是$O(mn)$）。相反，基于Burrows-Wheeler变换[1]的先进技术被采用。这些技术运行时间为$O(m)$，仅需$O(n)$空间。

Burrows-Wheeler transform最初源于压缩信息的需要。它接收一个长字符串，并以一种使相邻字母重复的方式重新排列它。这个字符串可以被压缩，因为例如，计算机现在不必写100个A，而只需指出有100个连续的A。Burrows-Wheeler变换还具有一些我们将利用来在亚线性时间内搜索的其他特殊性质。

Burrows-Wheeler变换创建了一个比原始字符串更短的唯一变换字符串。它也可以轻松逆转以生成原始字符串，因此没有信息丢失。变换后的字符串按排序顺序排列，这使得搜索变得容易。Burrows-Wheeler变换的细节如下所述，并在图19.3中进行了说明。

首先，我们通过以下步骤从原始字符串生成一个变换。特别地，我们生成参考基因组的变换。

1. 对于给定的参考基因组，在字符串的开头和结尾添加一个特殊字符（例如，“BANANA”变为`^BANANA@`）。然后生成该字符串的所有旋转（例如，其中一个旋转将是`NANA@^BA`）。2. 按字典顺序对这些旋转进行排序——即按字母顺序——特殊字符排在最后。3. 仅保留排序后旋转列表的最后一列。这一列包含了转换后的字符串

一旦计算了Burrows-Wheeler变换，就可以反转该变换以计算原始字符串。这可以通过图**??**中的过程完成。简而言之，逆向变换的工作方式如下：给定变换后的字符串，按字母顺序对字符串字符进行排序；这给出了变换中的第一列。将最后一列与第一列结合，得到来自原始旋转的字符对。对这些对进行排序并重复。

通过使用排序指针而非完整字符串，可以在与参考基因组大小成线性关系的空间中生成其变换。此外，即使读取数量极其庞大，也只需进行一次正向变换。在变换后的空间中计数读取后，仅需执行一次逆变换即可将计数映射到基因组坐标上。

特别地，从Burrows-Wheeler变换中我们观察到，相同后缀的所有出现实际上彼此相邻，而不是散布在整个基因组中。此外，第一列中字符的第i^{th}次出现对应于最后一列中的第i^{th}次出现。使用该变换搜索子串也很容易。假设我们在给定字符串中寻找子串“ANA”。那么搜索问题就简化为在所有可能的有序后缀（由旋转生成）中搜索前缀“ANA”。首先在排序旋转的首字母中搜索子串的最后一个字母（“A”）。然后，考虑这些匹配的单字母旋转；在这些单字母旋转的前两个字母中搜索子串的最后两个字母（“NA”）。这一过程可以随着后缀长度的增加而继续，以将子串作为旋转的前缀来找到。具体而言，每条读段都被搜索并作为参考基因组旋转的前缀被找到；这给出了读段在基因组中的位置。通过进行反向变换，可以找到比对读段的基因组坐标。

注意，这个想法在理论上并不比哈希更快，但在实践中它可以更快，因为它使用更小的内存占用。

19.4.2 Quality control metrics

与所有实验数据一样，ChIP方法也存在偏差，其输出质量可能参差不齐。因此，在处理数据之前，有必要控制这些偏差，确定数据中哪些读数达到一定的质量标准，并对整个数据集的质量设定目标阈值。在本节中，我们将描述这些**quality control**问题及与之相关的度量指标。

QC1: Use of input DNA as control

首先，ChIP产生的读段*not*在基因组中均匀分布。例如，基因组中的可及区域更容易被片段化，导致非均匀片段化。为了控制这种偏差，我们可以在不使用抗体的情况下对同一部分DNA进行ChIP实验。这会产生输入DNA，随后可以对其进行片段化并映射，从而得到一个可视为背景的信号轨迹——即我们随机预期会出现的读段。（事实上，即使在背景中我们也看不到

均匀性。）此外，我们有一条来自染色体免疫沉淀DNA的真实实验信号轨迹。如图19.4所示

QC2: Read-level sequencing quality score threshold

在进行DNA测序时，每个碱基对都与一个质量分数相关联。因此，ChIP-seq给出的读数包含碱基对级别的质量分数，其中较低的质量分数意味着错配概率较高。我们可以在预处理步骤中轻松利用这一信息，只需拒绝平均质量分数低于某个阈值的任何读数（例如，仅使用平均质量分数Q大于10的读数）。如图19.5所示

QC3: Fraction of short reads mapped

每个通过上述质量指标的读取可能精确映射到基因组中的一个位置、多个位置，或完全不映射。当读取映射到多个位置时，有多种处理方法：

- 保守方法：由于我们非常不确定，因此不将读段分配到任何位置。缺点：我们可能会丢失信号
- 一种概率方法：我们将读段按比例分配到所有位置。缺点：可能会引入伪影（不真实的峰）
- 一种采样方法：我们只随机选择一个位置进行读取。很可能在许多读取中，我们会均匀地分配它们。缺点：可能引入假象（不真实的峰值）
- 一种EM方法：我们可以根据明确reads的密度来映射reads。也就是说，许多映射到某个区域的唯一reads给出了一个高先验概率，表明一个read映射到该区域。注意：我们必须假设每个区域内的密度是恒定的。
- 双端方法：因为我们同时对DNA片段的两端进行测序，如果我们知道一端读段的映射，即使另一端读段的映射是模糊的，我们也能确定它。

无论哪种方式，都可能存在未映射到基因组的读取。一个质量控制指标是考虑映射读取的比例；例如，我们可能设定目标为50%。同样，可能存在没有读取映射到的区域。这可能是由于组装覆盖不足或映射到该区域的读取过多；我们将无法映射的区域视为缺失数据。

QC4: Cross-correlation analysis

另一个质量控制步骤是互相关分析。如果采用单端读取，DNA结合蛋白会在正向链上产生读取峰，与映射到反向链的读取峰相距大约等于DNA片段长度的距离。双端读取也会产生类似的模式，其中读取末端分为两组，具有给定的偏移量，一个读取末端映射到正向链，另一个映射到反向链。通过计算映射到正向链的读取数量与映射到反向链的读取数量之间的相关性，可以推断出平均片段长度。

映射到反向链的读取数与正向和反向读取之间的距离有关。相关性将在平均片段长度处达到峰值。

互相关分析还提供了有关ChIP-seq数据集质量的信息。输入DNA不应包含任何真正的峰，但通常在等于读长的距离处显示出强烈的互相关。这是因为一些读段独特地映射到不可映射区域之间的位置。如果一个读段可以在正链上两个不可映射区域之间的位置x处独特映射，那么一个读段也可以独特地映射到反链上的位置x + r -1，其中r是读长。以这种方式映射的读段在输入DNA中于等于读长的距离处产生强烈的互相关。如果ChIP-seq实验不成功，并且没有显著富集目标蛋白，那么大部分读段将类似于未富集的输入，这将在读长处的互相关中产生一个峰。因此，读长处的互相关强度相对于片段长度处的强度可以用来评估ChIP-seq数据集的质量。可接受的ChIP-seq文库在片段长度处的互相关应至少与读长处一样高，并且片段长度互相关与读长互相关之间的比率越高越好。

QC5: Library Complexity

作为最终的质量控制指标，我们可以考虑文库的复杂度，即非冗余读段的比例。在有信号存在的区域，我们预期读段可能来自该区域的所有位置；然而，有时我们会发现只有少数几个位置有读段映射到。这可能是由于扩增伪影导致的，其中单个读段的扩增量远超其应有水平。因此，我们考虑文库的非冗余比例：

$$\text{NRF} = \frac{\text{No. of distinct unique-mapping reads}}{\text{No. of unique mapping reads}}$$

该值衡量文库的复杂度。低值表示复杂度较低，这可能发生在例如DNA不足或某一个DNA片段被过度测序的情况下。当处理至少1000万条唯一比对读段时，我们通常将NRF的目标设定为至少0.8。

19.4.3 Peak Calling and Selection

读段比对完成后，即可生成如图19.6所示的信号轨迹。这些数据可以整理成一个跨越整个基因组长度的长直方图，其对应着基因组每个位置上所发现的读段数量（在ChIP-chip的情况下则对应荧光强度）。读段（或荧光）越多，表明该特定位置上感兴趣的的表观遗传标记的存在越强。

特别是，为了生成这些信号轨迹，我们将读取计数转换为归一化强度信号。首先，我们可以使用链交叉相关分析来估计片段长度分布 f。既然我们现在知道了 f，以及每个读取的长度，我们就可以从5'到3'方向延伸每个读取（通常仅为36 bp），使其长度等于平均片段长度。然后，不仅仅是累加原始读取中每个碱基的强度，我们还可以累加来自两个链的延伸读取中每个碱基的强度。换句话说，即使我们只测序了一个小读取，我们也能够利用该读取所属整个区段的信息。我们可以在对照数据上执行相同的操作。这样，我们就得到了真实实验和对照的信号轨迹，如图19.7所示。

为了处理数据，我们首先关注利用这些信号轨迹来发现富集区域（即离散区间）。这是***peak calling***的目标。有许多程序执行峰值

使用不同方法进行调用。例如，MACS使用局部泊松分布作为其统计模型，而PeakSeq则使用条件二项模型。

一种对读取计数分布进行建模的方法是使用泊松分布。我们可以从控制数据中估计期望的读取计数，λ_{local}。然后，

$$\Pr(\text{count} = x) = \frac{\lambda_{\text{local}}^{x} e^{-\lambda_{\text{local}}}}{x!}$$

因此，读取计数x的泊松p值由Pr(count $\geq x$)给出。我们指定一个阈值p值（例如0.00001），低于该值的基因组区域被视为峰。

我们可以通过将ChIP（真实）实验数据与输入DNA（对照）轨道互换，将这个p值转换为经验错误发现率，即eFDR。这将产生基因组中背景信号高于ChIP信号的位置。对于每个p值，我们可以从ChIP数据和对照数据中找到。然后，对于每个p值，eFDR就是对照峰的数量除以ChIP峰的数量。据此，我们可以根据eFDR阈值选择要称为的峰。

一个主要问题是，无法使用单一的通用eFDR或p值阈值。理想的阈值取决于多种因素，包括ChIP、测序深度以及目标因子的普遍性。此外，eFDR阈值的微小变化可能导致发现的峰值发生巨大变化。另一种衡量标准是不可重复发现率（Irreproducible Discovery Rate，简称IDR），这种衡量标准避免了这些FDR特有的问题。

Irreducible Discovery Rate (IDR)

使用传统统计方法评估ChIP-seq峰显著性的一个主要缺点是，基于FDR和p值的方法对富集与显著性之间的关系做出了特定假设。使用IDR而非p值或FDR来评估ChIP峰的显著性具有优势，因为它允许我们利用生物重复中存在的信息来调用峰，而无需设定显著性阈值。基于IDR的方法依赖于这样一个理念：真实信号很可能在重复之间是可重现的，而噪声则不应该是可重现的。使用IDR来调用显著峰会返回满足给定显著性阈值的峰。为了通过IDR确定哪些峰是显著的，每个生物重复中的峰根据其富集程度按降序排列。然后，将每个重复中排名前N的峰相互比较，给定重复的IDR是该重复中排名前N的峰中未出现在其他重复中的峰的比例（即，在重复之间不可重现的峰的比例）。为了培养更多的数学直觉，以下（完全可选的）小节将严格介绍IDR的概念。

Mathematical Derivation of the IDR

由于IDR利用秩，这意味着边际分布是均匀的，而信息主要编码在跨生物学重复的秩的联合分布中。具体来说，当边际分布均匀时，我们可以通过一个**copula**模型来建模联合分布。简而言之，copula是一个多变量概率分布，其中每个变量的边际概率都是均匀的。**Skar's Theorem**表明至少存在一个copula函数，使我们能够根据边际分布的依赖性来表达联合分布。

$$F_k(x_1, x_2, \ldots x_k) = C_x(F_{X_1}(x_1), \ldots F_{X_k}(x_K))$$

其中 C_x 是 copula 函数，$F(x)$ 是变量 x 的累积分布。基于此信息，我们可以设置一个伯努利分布 $K_i \sim$ Bern (π_i)，用以表示第 i 个峰来自一致集合还是虚假集合。若 $K_i =$ 为 1，则可推导出 $z_1 = (z_{1,1}, z_{1,2})$；若 $K_i =$ 为 0，则可推导出 $z_0 = (z_{0,1}, z_{0,2})$（其中 $z_{0,i}$ 表示其来自生物学重复 i 中的虚假集合）。利用这一点，我们可以将 $z_{1,1}$ 和 $z_{0,1}$ 模型建模如下：

$$\begin{pmatrix} z_{i,1} \\ z_{i,2} \end{pmatrix} \mid K_i = k \sim N\left(\begin{pmatrix} \mu_k \\ \mu_k \end{pmatrix}, \begin{pmatrix} \sigma_k^2 & \rho_k\sigma_k^2 \\ \rho_k\sigma_k^2 & \sigma_k^2 \end{pmatrix}\right)$$

我们可以利用两个不同的模型来建模它来自虚假集（用0表示）还是真实集（1）。如果是真实集，我们有$\mu_1 > 0$且$0 < \rho_1 < 1$，而在空集中我们有$\mu_0 = 0$和$\sigma_0^2 = 1$。我们可以用以下公式对变量$u_{i,1}$和$u_{i,2}$进行建模：

$$u_{i,1} = G(z_{i,1}) = \pi_1\Phi\left(\frac{z_{i,1} - \mu_1}{\sigma_1}\right) + \pi_0\Phi(z_{i,1})$$
$$u_{i,2} = G(z_{i,2}) = \pi_1\Phi\left(\frac{z_{i,2} - \mu_1}{\sigma_1}\right) + \pi_0\Phi(z_{i,2})$$

其中 Φ 是正态累积分布函数。然后，令观测到的 $x_{i,1} = F^{-1}(u_{i,1})$ 和 $x_{i,2} = F^{-1}(u_{i,2})$，其中 F_1 和 F_2 是两个坐标的边缘分布。因此，对于信号 i，我们有：

$$P(X_{i,1} \le x_1, X_{i,2} \le x_2) = \pi_0 h_0(G^{-1}(F_1(x_{i,1}), G^{-1}(F_2(x_{i,2})) + \pi_1 h_1(G^{-1}(F_1(x_{i,1}), G^{-1}(F_2(x_{i,2}))$$

我们可以用以下正态分布来表示 h_0 和 h_1，这与上文定义的 z_1 和 z_2 类似：

$$h_0 \sim N\left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}\right)$$
$$h_1 \sim N\left(\begin{pmatrix} \mu_1 \\ \mu_1 \end{pmatrix}, \begin{pmatrix} \sigma_1^2 & \rho_1\sigma_1^2 \\ \rho_1\sigma_1^2 & \sigma_1^2 \end{pmatrix}\right)$$

我们现在可以使用EM算法推断参数$\theta = (\mu_1, \rho_1, \pi_0)$。其中推断基于$\hat{} 1 \mid (x_{i,1}, x_{i,2}); \theta)$。因此，我们可以将局部不可重现发现率定义为：

$$idr(x_{i,1}, x_{i,2}) = P(K_i = 0 \mid (x_{i,1}, x_{i,2}); \hat{\theta})$$

因此，要在某个层面 α 控制 IDR，我们可以按其 IDR 值对 $(x_{i,1}, x_{i,2})$ 进行排序。然后我们可以选择 $(x_{(i),1}, x_{(i),2}), i = 1 \dots l$，其中

$$I = \underset{i}{\text{argmax}} \frac{1}{i}\sum_{j=1}^{i} idr_j \le \alpha$$

IDR 在这个 copula 混合模型中类似于 FDR 控制。本小节总结了本次讲座中提供的信息：`https://www.biostat.wisc.edu/~kendzior/STAT877/SK_2.pdf`。原始论文以及更详细的 IDR 公式可以在 Li et al. [10] 中找到。

Advantages and use cases of the IDR

可以通过增加N来进行IDR分析，直到达到所需的IDR（例如，增加N直到IDR{v*}0.05，意味着排名前N的峰值中有5%不可重现）。注意，N可以是

同一实验的不同重复之间可能存在差异，因为某些重复由于技术或生物伪影的原因，可能比其他重复更具可重复性。

IDR也优于使用实验间可重复性来定义显著性的更简单方法。一种方法可能是将两次重复中所有峰的并集视为显著，然而；这种方法会同时接受每个数据集中的真实峰和噪声。另一种方法是取两次重复中峰的交集，即只将两个数据集中都存在的峰计为显著。虽然这种方法能非常有效地消除虚假峰，但它很可能遗漏许多真实峰。IDR可以被视为结合了这两种方法，因为它接受所有峰，无论它们是否可重复，只要这些峰具有足够的富集，使其落在整体不可重复率高于给定阈值的数据段内。IDR的另一个优势是，即使没有生物学重复也可以执行，这在稀有细胞类型中进行的ChIP实验中常常是这种情况。可以通过将一半reads随机分配给一个伪重复、另一半分配给另一个伪重复，从单个数据集生成伪重复。

Interpreting Chromatin Marks

现在我们转向解释染色质标记的技术。分析表观基因组标记有许多方法，例如在已知特征类型（例如表达水平高或低的基因的启动子）上聚合染色质信号（例如H3K4me3），并执行监督或无监督机器学习方法，以推导出能够预测不同类型基因组元件（如启动子、增强子或大型基因间非编码RNA）的表观基因组特征。特别地，在本讲中，我们详细考察了[7]中对染色质标记的分析。

19.5 Annotating the Genome Using Chromatin Signatures

组蛋白密码假说认为，染色质与DNA的相互作用是由**combinatorial his- tone modifications**引导的。这些组合修饰，当综合考虑时，可以部分决定细胞如何解释一段DNA区域（即作为转录因子结合域、剪接位点、增强子区域、活跃表达的基因、被抑制的基因或非功能区域）。我们感兴趣的是解读这一“密码”（即根据某一区域的组蛋白标记判断该区域是否为转录起始位点、增强子、启动子等）。通过理解组合组蛋白标记，我们能够将基因组注释为功能区域，并预测新的增强子、启动子、基因等。挑战在于，标记有数十种，且它们展现出复杂的组合效应。

换言之，DNA可以呈现一系列（隐藏的）状态（编码、非编码等）。每一个这样的状态都会发出细胞所识别的特定表观遗传修饰组合（H3K4me3、H3K36me3等）。我们希望能够从观察到的表观遗传修饰预测这些隐藏的、具有生物学意义的状态。

在本节中，我们探讨一种解释“代码”的技术及其在特定数据集[7]上的应用，该数据集测量了人类基因组中的41种染色质标记。

19.5.1 Data

本分析的数据包括CD4 T细胞中的41种染色质标记，涵盖乙酰化、甲基化、H2AZ、CTCF和PolII。首先，将基因组划分为200 bp的非重叠区间，在这些区间中确定41种染色质标记各自的二元缺失或存在。此数据使用**databinarization**进行处理，其中每个区间中的每个标记根据该区间内标记信号的富集是否超过阈值而被赋值为0或1。具体而言，设C_{ij}为通过ChIP-seq检测到的标记i的读数，映射到200bp区间j。设λ_i为标记i映射到某个区间的平均读数。若$P(X > C_{ij})$小于可接受阈值10^{-4}，则确定标记i存在于区间j中，其中X是均值为λ_i的泊松随机变量，否则视为不存在。该阈值由用户定义，类似于泊松p值。换句话说，特定区间的读数富集必须显著高于将读数随机放入区间的过程。7号染色体上CAPZA2基因周围的染色质状态示例如图19.8所示。因此，通过这种方式，对于每个标记i，我们可以用1标记每个区间j（如果该标记存在）或用0标记（如果不存在）。从整体上看数据，我们可以将其视为一个大型二元矩阵，其中每一行对应一个标记，每一列对应一个区间（即基因组中一个简单的200bp区域）。

用于分析的附加数据包括基因本体数据、SNP数据、表达数据及其他。

19.5.2 HMMs for Chromatin State Annotation

我们的目标是识别具有生物学意义且空间连贯的染色质标记组合。请记住，我们将基因组分割成了200bp的区块，因此所谓空间连贯，是指如果我们有一个长度超过200bp的基因组元件，我们期望该区域内每个200bp区间上的染色质标记组合是一致的。我们将这些具有生物学意义且空间连贯的染色质标记组合称为**chromatin states**。在之前的讲座中，我们已经看到隐马尔可夫模型被应用于基因和CpG岛的基因组注释。我们希望将同样的思路应用到这种情况，但在这种情况下，我们事先并不知道隐藏状态（例如是否为CpG岛区域），我们希望学习它们*de novo*。这个模型既能捕捉不同状态的功能顺序（例如从启动子到转录区域），也能捕捉某些染色质结构域在基因组上的扩展。总结来说，我们希望学习一个隐马尔可夫模型，其中隐马尔可夫模型的隐藏状态就是染色质状态。

正如我们之前所学，即使我们不知道HMM的发射概率和转移概率，我们也可以使用Baum-Welch训练算法来学习这些参数的最大似然值。在我们的情况下，我们面临一个额外的困难，我们甚至不知道存在多少染色质状态！在以下小节中，我们将详细说明如何对数据进行建模，以及如何为HMM选择状态数量。

Emission of a Vector

在之前讲座的HMMs中，每个状态每次发射单个核苷酸或单个核苷酸串。在本问题的HMM中，每个状态发射表观遗传标记的组合。每个组合可以表示为一个n维向量，其中n是正在分析的染色质标记数量（我们的数据中n =为41）。例如，假设有四种可能的表观遗传修饰：H3K4me3、H2BK5ac、Methyl-C和Methyl-A，包含H3K4me3和Methyl-C的序列可以表示为向量(1, 0, 1, 0)。可以想象二元n向量上有许多不同的概率分布，为简单起见，我们假设这些标记是独立的，并建模为伯努利随机变量。因此，我们假设在HMM的隐藏状态给定下标记是独立的（注意，这与假设标记独立并不相同）。

如果有 n 个输入标记，每个状态 k 都有一个向量 $(p_{k1}, .., p_{kn})$，表示观察到标记 1 到 n 的概率。由于概率被建模为一组独立的伯努利随机变量，在给定我们处于隐藏状态 k 的情况下，观察到一组标记的概率等于观察到各个标记的概率之积。例如，如果 $n = 4$，在区间 j 观察到的标记是 $(1, 0, 1, 0)$，并且我们处于状态 k，那么该数据的似然是 $p_{k1}(1 - p_{k2})p_{k3}(1 - p_{k4})$。

学习　　数据的发射概率如图　　19.9.

Transition Probabilities

回想一下，转移概率表示从一个隐藏状态转移到另一个隐藏状态的频率。在这种情况下，我们的隐藏状态是染色质状态。我们数据的转移矩阵如图19.10所示。从图中可以看出，该矩阵是稀疏的，表明只有少数可能的转移实际发生。转移矩阵揭示了相邻状态之间的空间关系。矩阵中的状态块揭示了状态的子群，从这些更高级别的块中，我们可以看到这些元状态之间的转移。

19.5.3 Choosing the Number of states to model

与大多数机器学习算法一样，增加模型的复杂度（例如隐藏状态的数量）将使其能更好地拟合训练数据。然而，训练数据仅是真总体的有限样本。随着我们增加更多复杂度，在某个点上，我们正在拟合训练数据中仅由于有限采样而存在的模式，因此模型将无法泛化到真总体。这被称为**over-fitting**训练数据；我们应在模型拟合训练数据中的噪声之前停止增加模型的复杂度。

Bayesian Information Criterion (BIC) 是一种用于优化模型复杂度的常用技术，它在增加对数据的拟合度与模型复杂度之间寻求平衡。利用BIC，我们可以可视化HMM随着状态数增加而增强的能力。通常，人们会选择使得增加更多状态在预测能力增益方面收益相对较小的状态数k ()。然而，模型复杂度与模型可解释性之间存在权衡，这是BIC无法解决的。根据BIC得出的最优模型很可能比理想模型拥有更多的状态，因为我们愿意牺牲一些预测能力来换取一个状态更少、能在生物学上解释的模型。人类基因组如此庞大，染色质标记如此复杂，以至于找到统计学上显著的差异很容易，但其中许多差异在生物学上并不显著。

为了解决这个问题，我们首先构建一个隐藏状态数量多于我们认为必要的模型，并在更大模型中的所有感兴趣状态都能被充分捕捉的前提下，逐步精简隐藏状态。Baum-Welch 算法（以及一般的 EM 算法）对初始条件敏感，因此我们在学习过程中尝试多种随机初始化。对于隐藏状态数量从2到80的每个取值，我们生成三组随机初始化的参数，并使用 Baum-Welch 算法训练模型。根据 BIC 准则，最佳模型拥有79个状态，随后，我们从这79个状态集合中逐步剔除状态。

如前所述，Baum-Welch算法对初始参数敏感，因此我们在修剪状态时，采用了嵌套初始化而非随机初始化的方法来处理修剪后的模型。具体而言，是从BIC最优的79个状态模型中贪婪地移除状态。被移除的状态是这样一个状态：确保从237个随机初始化模型中所有状态都能被良好捕捉。移除状态时，其发射概率会被删除，任何转移到该被移除状态的转移概率将均匀重新分配给剩余的状态。这一过程被用作初始化，以便

Baum-Welch训练。然后，可以通过选择从这种嵌套初始化训练得到的、能够充分捕捉所有提供不同生物学解释的状态的最少状态数的模型，来选择用于分析的模型的状态数。最终得到的模型有51个状态。

我们还可以通过查看数据如何违反模型假设来检查模型拟合情况。给定隐状态，HMM假设每个标记是独立的。我们可以通过绘制标记之间的依赖关系来检验数据在多大程度上符合这一假设。这可以揭示拟合良好的状态和拟合不佳的状态。特别地，重复状态揭示了模型拟合不佳的情况。随着我们添加更多状态，模型能够更好地拟合数据，从而拟合依赖关系。通过监测我们感兴趣的各个状态的拟合情况，我们可以控制模型的复杂度。

19.5.4 Results

这个多变量HMM模型产生了一组51个生物学相关的染色质状态。然而，每个状态与已知的基因组元件类别（例如内含子、外显子、启动子、增强子等）之间并不存在一一对应关系。相反，多个染色质状态常常与一个基因组元件相关联。每个染色质状态都编码了关于其相关基因组元件的特定生物学相关信息。例如，三个不同的染色质状态与转录起始位点（TSS）相关联，但其中一个与高表达基因的TSS相关联，而另外两个分别与中表达和低表达基因的TSS相关联。这种表观遗传标记的使用极大地改进了基因组注释，尤其是与前面讲座中讨论的进化信号相结合时。这51个染色质状态可以分为五大类。这些类别的特性描述如下，并在19.11中进一步说明：

1. **Promoter-Associated States (1-11):**
   这些染色质状态在启动子区域均表现出高度富集。每种状态中40-89%位于RefSeq TSS的2 kb范围内，而全基因组范围内这一比例仅为2.7%。这些状态均具有高频的H3K4me3、对DNase I超敏感位点、CpG岛、进化保守基序及结合转录因子的显著富集。然而，这些状态在相关标记如H3K79me2/3、H4K20me1、乙酰化等的水平上存在差异。这些状态在基于基因本体（GO）的功能富集方面也有所不同。例如，与T细胞激活相关的基因在状态8中富集，而与胚胎发育相关的基因在状态4中富集。此外，在这些启动子状态中还存在着不同的位置富集。状态1-3在TSS的上游和下游均有峰值；状态4-7集中在TSS正上方，而状态8-11的峰值位于TSS下游400 bp至1200 bp之间。这表明染色质标记能够招募起始因子，并且转录行为可以强化这些标记。不同的功能富集还表明，这些标记编码了一段激活的历史。

2. **Transcription-Associated States (12-28):**
   这是第二大染色质状态群体，包含了17种与转录相关的状态。与全基因组其他区域36%相比，这些状态在已注释的转录区域中的占比高达70-95%。这些状态并非主要与单一标记相关联，而是由七种标记的组合来定义——H3K79me3、H3K79me2、H3K79me1、H3K27me1、H2BK5me1、H4K20me1和H3K36me3。这些状态有与5’端近端或5’端远端位置相关的亚群。其中一些状态与剪接的外显子、转录起始位点或终止位点相关。值得注意的是，状态28，其特征为H3K9me3、H4K20me3和H3K36me3的高频率出现，在锌指基因中显示出高度富集。这种特定的标记组合先前已有报道，标志着KAP1结合区域，KAP1是一种锌指特异性的共抑制因子。

3. **Active Intergenic States (29-39):**

这些状态与几类候选增强子区域和绝缘子区域相关联，并且与H3K4me1、H2AZ及几种乙酰化标记的较高频率相关，但与甲基化标记的较低频率相关。此外，染色质标记可用于区分活性增强子与活性较低的增强子。这些区域通常远离启动子，并且位于转录基因之外。有趣的是，几种活跃的基因间状态在全基因组关联研究（GWAS）中显示出疾病SNP或单核苷酸多态性的显著富集。例如，一个与炎症性疾病中血浆嗜酸性粒细胞计数水平相关的SNP（rs12619285）被发现位于染色质状态33，该状态富集了GWAS命中。相比之下，该SNP的周围区域被归因于其他染色质状态，没有显著的GWAS关联。这可以根据疾病SNP不同的染色质状态，揭示其可能的功能意义。

4. **Large-Scale Repressed States (40-45):**
   这些状态标志着大规模抑制和异染色质区域，占基因组的64%。H3K27me3和H3K9me3是该组中最常检测到的两个标记。

5. **Repetitive States (46-51):**
   这些状态对特定的重复元件表现出强烈而明显的富集。例如，状态46具有低复杂度重复序列如(CA)n、(TG)n和(CATG)n的强烈序列特征。状态48-51似乎对许多修饰表现出高频率，但也富集了来自非特异性抗体对照的读数。因此，该模型还能够捕捉因重复元件额外拷贝缺乏覆盖而产生的伪影。

由于许多染色质状态是由多个标记描述的，因此量化了每个标记对某一状态的贡献。通过测试不同的染色质标记子集，评估了它们区分染色质状态的潜力。通常发现，当贪婪地选择标记时，增加的标记子集能够收敛到准确的染色质状态。

染色质状态在发现功能元件方面的预测能力始终优于基于单个标记的预测。这种利用表观基因组标记组合和空间基因组信息的无监督模型在基因组注释方面表现得与许多监督模型一样好。研究表明，这种基于染色质状态的HMM模型能够揭示先前未注释的启动子和转录区域，这些区域得到了独立实验证据的支持。当在全基因组范围内分析染色质标记时，观察到的一些特性包括着丝粒中富集的卫星富集状态（47-51）、19号染色体上富集的锌指富集状态（状态28）等。因此，这种基于染色质状态的全基因组注释可以帮助更好地解释生物学数据，并有可能发现基因组中新的功能元件类别。

19.5.5 Multiple Cell Types

上述所有工作都是在单一细胞类型（CD4+ T细胞）中完成的。由于表观基因组标记会随时间、细胞类型和环境条件而变化，因此考虑不同细胞类型和实验条件下染色质状态的动态变化非常重要。Brad Bernstein染色质小组的ENCODE项目[3]在九种人类细胞系中测量了9种不同的染色质标记。在这种情况下，我们希望为所有数据学习一组统一的染色质标记。解决这个问题有两种方法：拼接和堆叠。对于拼接，我们可以将全部9种细胞系合并，如同它们是单一细胞系一样。通过拼接不同的细胞系，我们确保学习到一套共同的状态定义。我们之所以能在这里这样做，是因为每个实验中分析的标记都相同。然而，如果我们对不同细胞系分析了不同的标记，就需要采用另一种方法。或者，我们可以将这9种细胞系对齐，并将所有标记视为一个超级向量。这使我们能够学习细胞系特异性的活性状态，例如可能存在针对ES特异性增强子的状态（在那

说明在ES中会有增强子标记，但在其他细胞类型中没有标记）。遗憾的是，这大大增加了HMM产生的向量维度，这意味着为了充分拟合数据，模型复杂度需要增加。

假设我们有多种细胞类型，其中我们分析了不同的标记，并希望将它们拼接起来。一种方法是学习独立模型然后将其组合。我们可以通过匹配相似的发射向量或匹配在基因组中相同位置出现的状态来找到对应的状态。第二种方法是将缺失的标记视为缺失数据。EM框架允许未指定的数据点，因此只要在某些细胞类型中观察到标记之间的成对关系，我们就可以使用EM。最后，我们可以使用最大似然法，如Viterbi算法，基于观察到的标记来预测缺失的染色质标记。如果最终目标是染色质状态学习，这种方法的效力较低，因为我们只关注最可能的状态，而不是像第二种方法那样对所有可能性进行平均。

在9种人类细胞系中有9个标记的情况下，将细胞系串联起来并学习了一个具有15个状态的模型[8]。对每种细胞类型进行了类别富集分析。结果显示，一些染色质状态，如编码活跃启动子的状态，在所有细胞类型中高度稳定。其他状态，如编码强增强子的状态，则以细胞类型特异性的方式高度富集，表明它们在组织特异性基因表达中的作用。最后，研究表明，增强子上的表观遗传标记与其调控的基因上的表观遗传标记之间存在显著相关性，即使这些标记可能相隔数千个碱基对。这种染色质状态模型已被证明在将增强子与其各自的基因匹配方面很有用，这是现代生物学中一个很大程度上未解决的问题。因此，染色质状态提供了一种研究跨多种细胞类型的染色质动态性质的方法。特别是，我们可以根据染色质注释看到基因组特定区域的活性。它还允许我们将24亿条读取中包含的重要信息总结为仅仅15种染色质状态。

2015年*Nature*表观基因组路线图项目发布的一篇出版物展示了一个无与伦比的人类表观基因组学特征参考，涵盖了超过一百种不同的组织[2]。在他们的分析中，他们利用了本章深入讨论的几个概念，例如使用15状态或18状态的ChromHMM模型来注释表观基因组。在111个数据集上进行训练使得之前讨论的HMM模型具有更强的鲁棒性。路线图项目在他们的论文中探索了许多有趣的方向，强烈建议感兴趣的读者阅读这篇出版物。有趣的结论包括H3K4-me1相关状态是最具组织特异性的染色质标记，而二价启动子和抑制状态也是不同组织类型中变异性最高的注释。对于增强子，路线图项目发现大量与疾病相关的SNP与注释的增强子区域相关。MIT计算生物学小组正在积极探讨这种联系。

19.6 Current Research Directions

目前正在进行几个大规模数据生产工作，如ENCODE、modENCODE和表观基因组路线图项目，因此有机会对这些新数据进行计算分析。表观基因组数据也被用于研究行为如何改变你的基因组。已有研究探讨饮食和运动及其对疾病易感性的影响。

另一个有趣的研究领域是疾病中表观遗传变化的分析。麻省理工学院计算生物学组当前的研究正在探讨染色质状态与阿尔茨海默病之间的联系。下面提供了一系列关于表观遗传学与疾病关联的论文。

19.7 Further Reading

有几篇有趣的论文从表观遗传学角度总体性地研究染色质状态。以下列出几个URL供您初步探索:

1. http://www.nature.com/nmeth/journal/v8/n9/full/nmeth.1673.html 2. http://www.nature.com/nature/journal/v473/n7345/full/nature09906.html 3. http://www.nature.com/nbt/journal/v28/n8/abs/nbt.1662.html 4. http://www.nytimes.com/2012/09/09/opinion/sunday/why-fathers-really-matter.html?_r=1 5. http://www.nature.com/doifinder/10.1038/nature14248

以下是一些精选的关于表观遗传学与疾病的出版物。

1. http://www.nature.com/nature/journal/v429/n6990/full/nature02625.html
2. http://www.sciencedirect.com/science/article/pii/S2211124712003725 3. http://www.nature.com/nbt/journal/v28/n10/pdf/nbt.1685.pdf

19.8 Tools and Techniques

ChromHMM是文中描述的HMM。它可免费下载，附有使用说明和示例，网址为: http://compbio.mit.edu/ChromHMM/。

Segway是另一种分析多轨道功能基因组学数据的方法。它使用动态贝叶斯网络（HMMs是动态贝叶斯网络的一种特殊类型），使其能够以1-bp的分辨率分析整个基因组。缺点是它比ChromHMM慢得多。可在此处免费下载: http://noble.gs.washington.edu/proj/segway/。

19.9 What Have We Learned?

在本讲中，我们学习了如何利用染色质标记来推断生物学相关状态。[7]中的分析展示了一种复杂的方法，将先前学到的技术如HMMs应用于一个复杂问题。讲座还介绍了强大的Burrows-Wheeler变换，它使得高效的读取映射成为可能。

Bibliography

[1] Langmead B, Trapnell C, Pop M, 和 Salzberg S. 超快速、内存高效的短DNA序列与人类基因组的比对。*Genome Biology*, 10(3), 2009.

[2] Roadmap Epigenomics Consortium, Kundaje A, Meuleman W, 等. 111 个人类参考表观基因组的整合分析. *Nature*, 518(7539):317–330, 2015. [3] ENCODE 项目联盟. 人类基因组 DNA 元件的整合百科全书. *Nature*, 489(7414):57–74, 2012. [4] Heard E 和 Martienssen RA. 跨代表观遗传：迷思与机制. *Cell*, 157(1):95–109, 2014. [5] Mardis ER. ChIP-seq：欢迎来到新前沿. *Nature Methods*, 4(8):614–614, 2007. [6] Herz H-M, Hu D, 和 Shilatifard A. 癌症中的增强子功能障碍. *Molecular Cell*, 53(6):859–866, 2014. [7] Ernst J 和 Kellis M. 用于人类基因组系统注释的染色质状态的发现与表征. *Nature Biotechnology*, 28:817–825, 2010. [8] Ernst J, Kheradpour P, Mikkelsen TS, 等. 九种人类细胞类型中染色质状态动态的映射与分析. *Nature*, 473(7345):43–49, 2011. [9] Mousavi K, Zare H, Dell' orso S, Grontved L, 等. eRNA 通过在定义的基因组位点建立染色质可及性促进转录. *Molecular Cell*, 51(5):606–17, 2013.

[10] Qunhua Li, James B. Brown, Haiyan Huang, 和 Peter J. Bickel. 从仪器、和 ChIP-seq 的数据库中做基于高通量实验的准重复值。\n2. 根据正态分布采样 $\sig
The Annals of Applied Statistics, 5(3)：1752–1779，2011。

[11] 请提供需要翻译的 MCL DNA 甲基化检测：亚硫酸氢盐基因组测序分析. *Methods Molecular Biology*, 791:11–21, 2011.

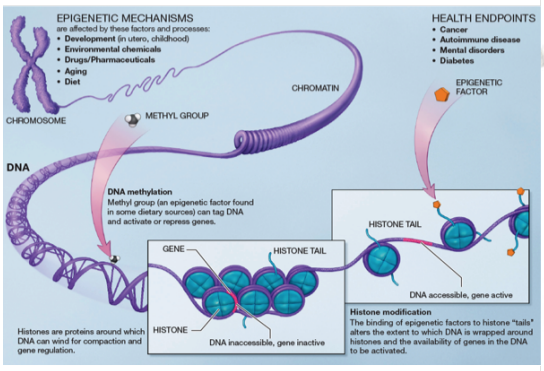

Courtesy of National Institutes of Health.
Image in the public domain.

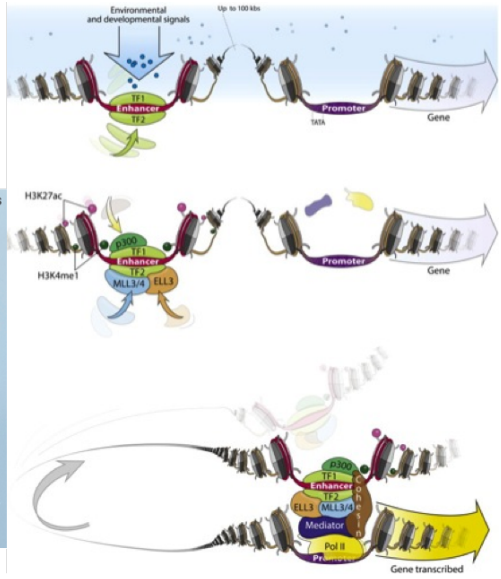

Courtesy of Elsevier, Inc. Used with permission.
Source: Herz, Hans-Martin, Deqing Hu, et al. "Enhancer 癌症中的功能障碍。"
Molecular Cell 53, no. 6 (2014): 859-66.

图19.1：A. 表观基因组中存在多种多样的修饰。DNA的某些区域紧密缠绕在组蛋白上，使得DNA难以接近，基因处于非活跃状态。而其他区域则有更易接近的DNA，因此基因活跃。表观遗传因子能结合到这些组蛋白的尾部，从而改变这些属性。B. 组蛋白修饰提供了关于哪些类型的蛋白质与DNA结合以及该区域功能的信息。在此例中，组蛋白修饰使得一个增强子区域（可能距离超过100千碱基）能与启动子区域相互作用。[6]

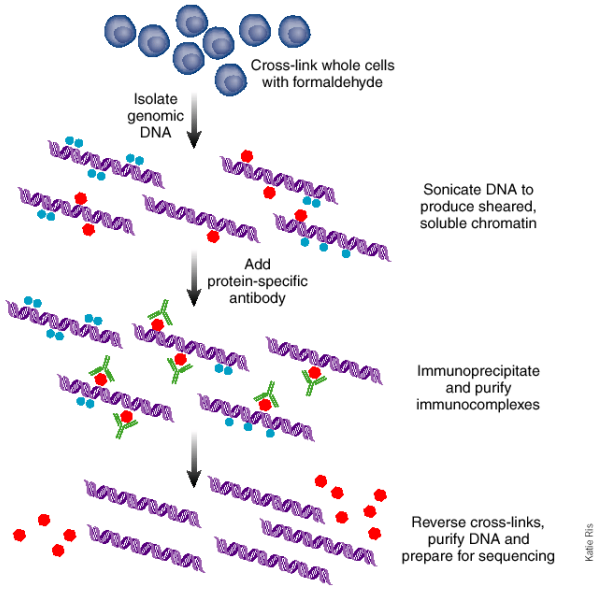

Courtesy of Nature Publishing Group. Used with permission.
Source: Mardis, Elaine R. "ChIP-seq: Welcome to the New Frontier."
Nature Methods 4, no. 8 (2007): 613.

图19.2：染色质免疫共沉淀方法[5]。图中步骤与该流程的六个步骤相对应。

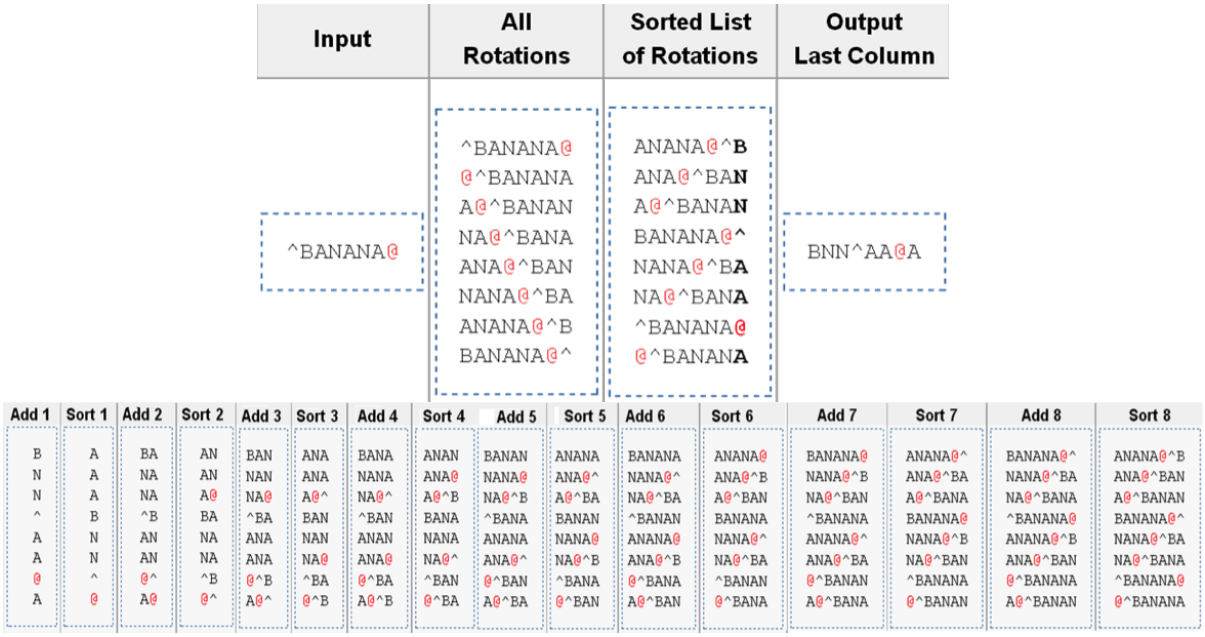

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图19.3：（上）在Burrows-Wheeler正向变换中，生成并排序旋转。（排序列表的最后一列（加粗）构成了变换后的字符串。）（下）在Burrows-Wheeler逆向变换中，对变换后的字符串进行排序，并生成两列：一列由原始字符串组成，另一列由排序后的字符串组成。这些列有效地构成了正向变换中旋转的两列。重复此过程，直到生成完整的旋转。

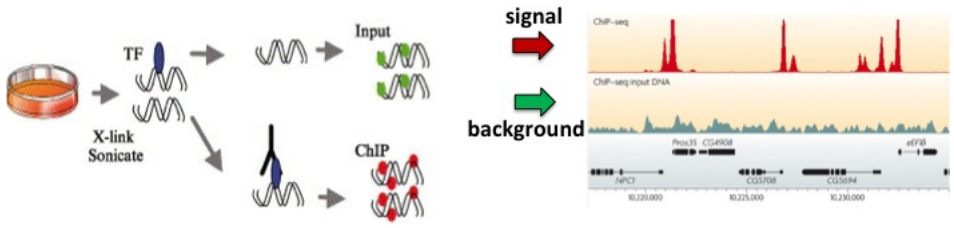

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图19.4：为了使用输入DNA作为对照，可以正常进行ChIP实验的同时，不使用抗体进行相同的实验（使用相同的DNA）。这样就能产生一个背景信号，我们可以据此进行校正。

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图19.5：在上图中，每一列都是一个颜色编码的直方图，表示所有映射读段在每个位置（x轴）具有碱基评分Q（y轴）的比例。每个碱基的平均评分低意味着错误映射的概率更高。我们通常会拒绝平均评分Q低于10的读段。

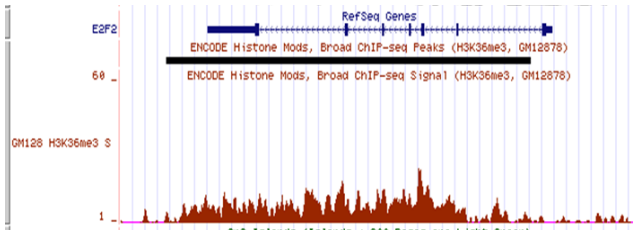

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图19.6：一个样本信号轨迹。在此图中，红色信号来源于针对目标H3K36me3进行的ChIP-seq实验中，每个位置上比对到基因组的读取数量。该信号表示了标记的富集程度。

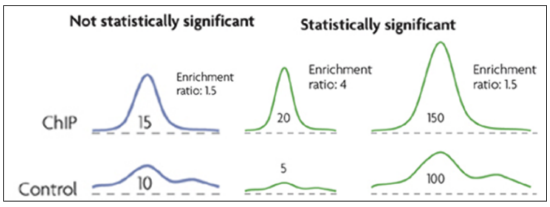

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图19.7：真实实验与背景（对照）的样本信号轨迹。当真实实验的信号值显著高于背景信号值时，认为这些区域具有统计显著性的富集。

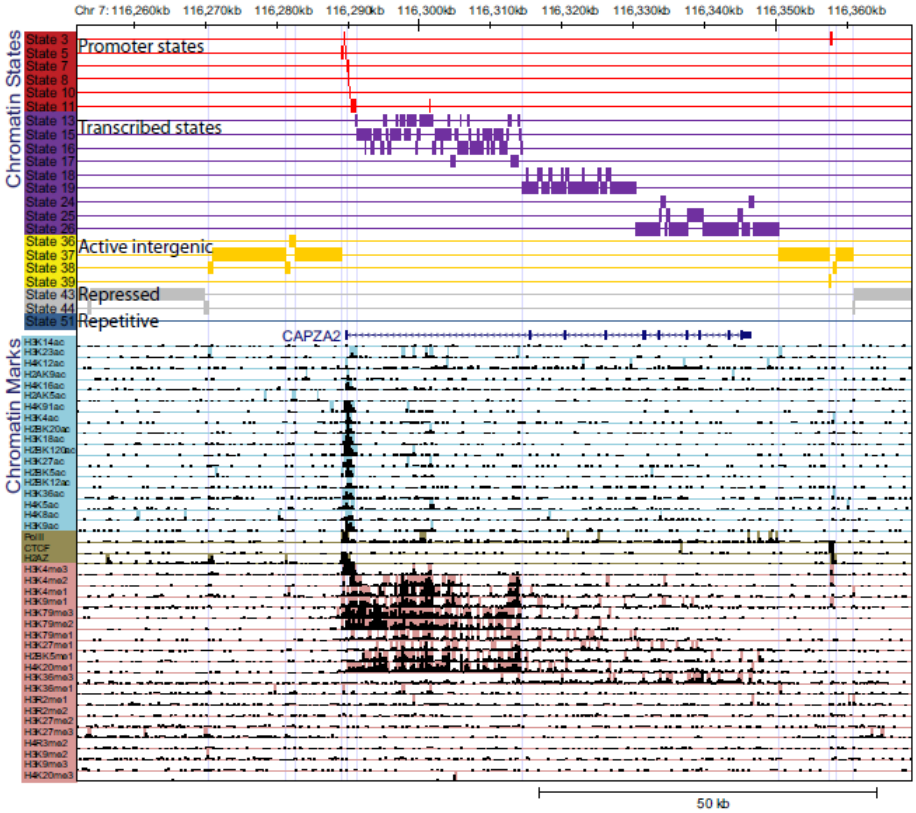

由Macmillan Publishers Limited提供。经许可使用。来源：Ernst, Jason, 和 Manolis Kellis. “发现和描述用于人类基因组系统注释的染色质状态。” *Nature Biotechnology* 28, no. 8 (2010): 817-25.

图19.8：HMM模型的数据和注释示例。底部展示了映射到基因组的原始读取数量。顶部显示了HMM模型的注释。

© Macmillan Publishers Limited。保留所有权利。此内容不包含在我们的知识共享许可范围内。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。来源：Ernst, Jason, 和 Manolis Kellis。“发现和表征染色质状态以系统注释人类基因组。”*Nature Biotechnology* 28, no. 8 (2010): 817-25。

图19.9：具有51个状态的最终模型的发射概率。对应于标记i和状态k的单元格表示在状态k中观察到标记i的概率。

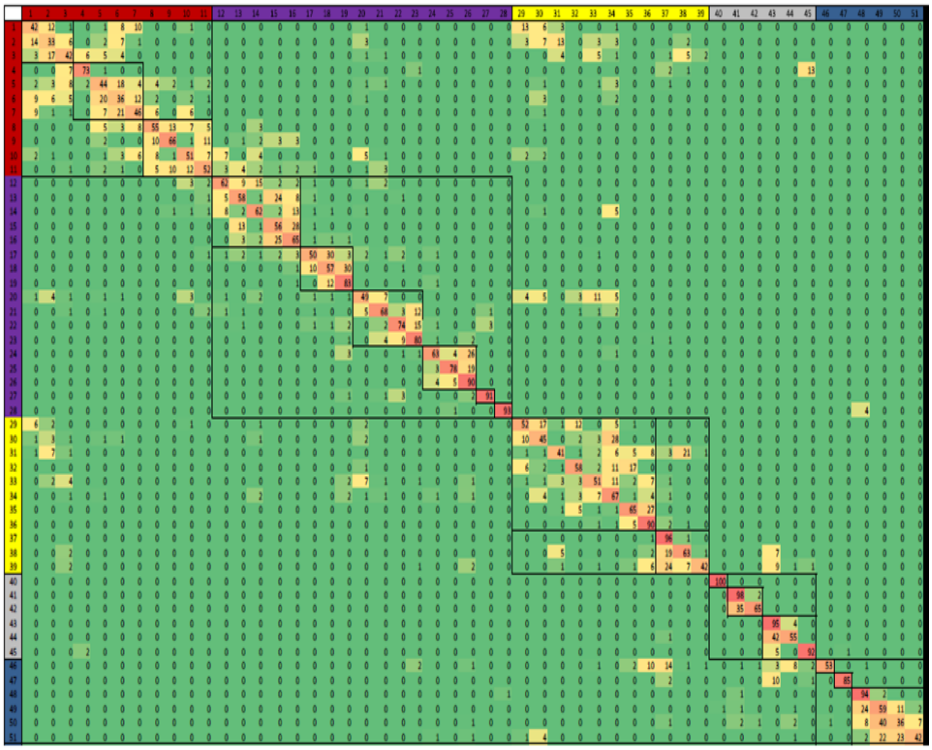

图19.10：具有51个状态的最终模型的转移概率。转移概率从绿色到红色递增。通过聚类转移矩阵，揭示了相邻染色质状态及状态子群之间的空间关系。值得注意的是，该矩阵是稀疏的，表明大多数转移是不可能的。

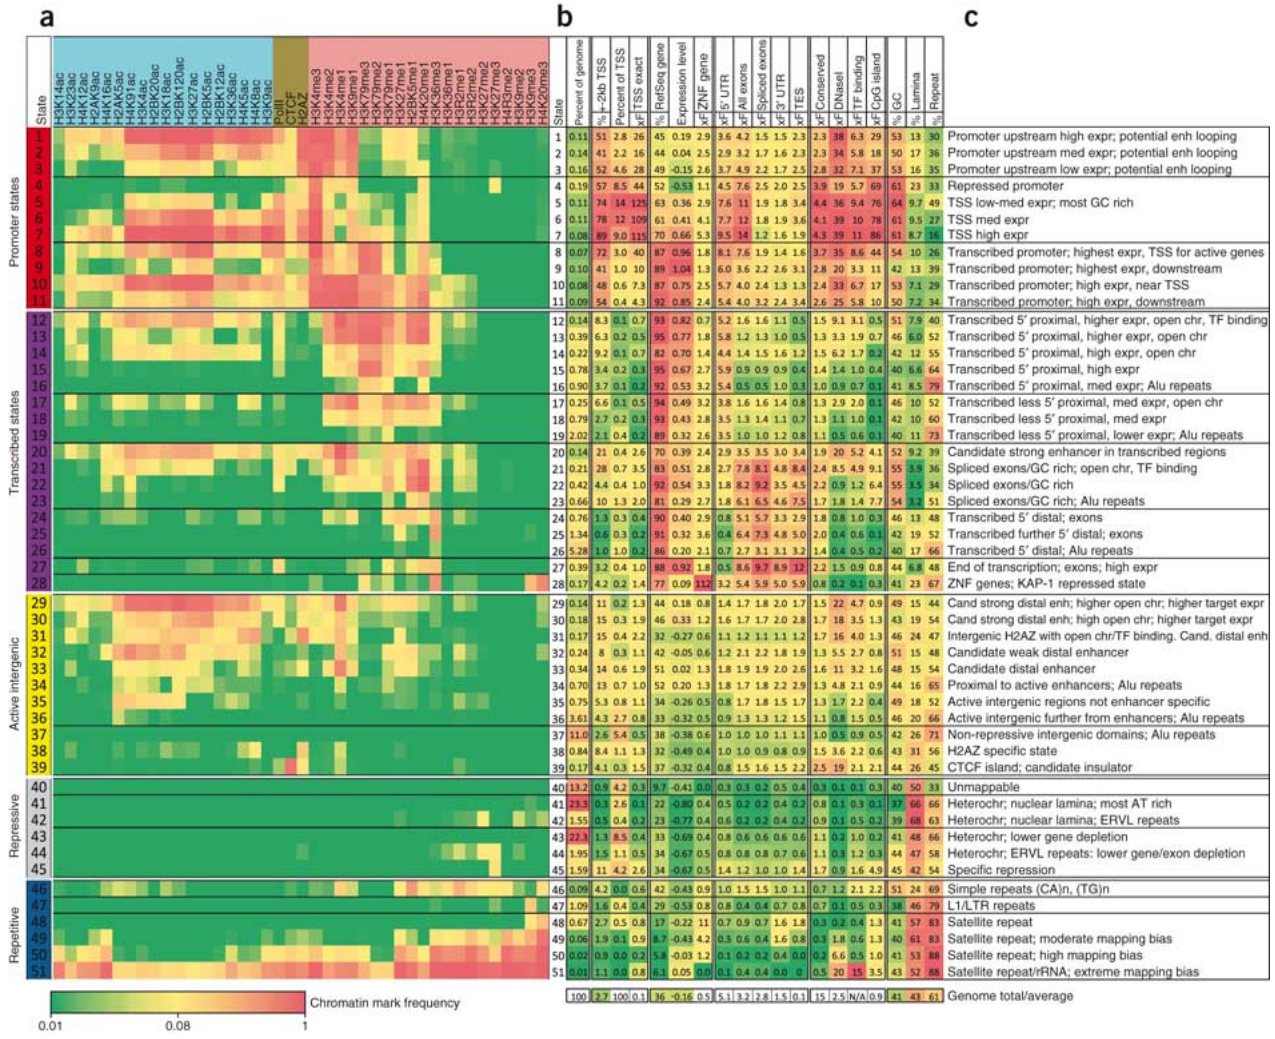

图19.11：染色质状态定义与功能解读。[7] a. 与每种状态相关的染色质标记组合。每一行展示了与每种染色质状态相关的特定标记组合，以及它们出现的频率，频率范围在0到1之间，以颜色标度表示。这些对应于模型训练期间在全基因组范围内学习到的HMM发射概率参数。b. 染色质状态的基因组和功能富集，包括基因组不同部分（例如转录区域、TSS、RefSeq基因的5'端或3'端等）的倍数富集，以及进化保守元件、DNaseI超敏位点、CpG岛等的倍数富集。所有富集均基于后验概率分配。c. 生物学状态功能和解读的简要描述（chr，染色质；enh，增强子）。

CHAPTER

TWENTY

网络 I：推理、结构、谱方法

Figures

20.1 生物网络之间的相互作用 . . . . . 299 20.2 不同类型网络的表示 . . . . . 300 20.3 一个3节点上的简单网络。该图的邻接矩阵由方程(21.1)给出 . . . . . 301 20.4 维格纳半圆律 . . . . . 306 20.5 使用SVD进行结构推断 . . . . . 307 20.6 使用PCA的特征基因分解 . . . . . 308 20.7 线性回归的最小二乘解。左：二维情况，右：三维情况 . . . . . 309 20.8 回归框架中的PCA . . . . . 310 20.9 PCA与SPCA . . . . . 311 20.10迭代分类算法 . . . . . 311 20.11使用关联预测基因功能 . . . . . 312 20.12一个包含4-团的示例网络 . . . . . 312 20.13一个具有8个节点的网络 . . . . . 317 20.14还有哪些其他距离度量有用？ . . . . . 319 20.15随机游走的图示 . . . . . 320 20.16神经网络的图示 . . . . . 321 20.17 DeepBind流程的流程图（取自DeepBind论文）。模型并行处理五个序列。模型对序列进行卷积（我们可以将DeepBind模型视为一个扫描序列的滤波器），整流并池化它们以产生特征向量，然后将其传递通过深度神经网络。深度网络的输出与期望输出进行比较，误差通过管道反向传播。 . . . . . 323 20.18 DeepBind方法使用的校准、训练和测试过程的图示（取自DeepBind论文）。 . . . . . 323 20.19（取自Srivastava等人论文）应用dropout过程后产生的稀疏网络的图示。被划掉的单元已被丢弃。 324 20.20（取自Srivastava等人论文）一个图表，说明应用dropout过程后分类错误率显著降低。 325

20.1 Introduction

分子与细胞生物学描述了一个高度多样化的相互作用组件系统，该系统能够产生错综复杂的现象。蛋白质组内的相互作用描述了细胞代谢、信号传导级联以及对环境的响应。网络是帮助表示、理解和分析生物组件间复杂相互作用的宝贵工具。生命系统可被视为多层结构的组合，每一层都编码了关于系统的信息。一些重要的层次包括：

1. 基因组：包括编码DNA和非编码DNA。由编码DNA定义的基因用于构建RNA，而顺式调控元件则调控这些基因的表达。2. 表观基因组：由染色质构型定义。染色质的结构基于组蛋白组织DNA的方式。DNA被分为核小体和核小体游离区域，形成其最终形态并影响基因表达。[1] 3. 转录组 RNA（例如mRNA、miRNA、ncRNA、piRNA）由DNA转录而来。它们具有调控功能并制造蛋白质。4. 蛋白质组 由蛋白质组成。这包括转录因子、信号蛋白和代谢酶。

每一层都由一个相互作用网络组成。例如，mRNA和miRNA相互作用以调节蛋白质的产生。层与层之间也可以相互作用，形成网络之间的网络。例如，一种称为Xist的长非编码RNA在X染色体上产生表观基因组变化，通过X失活实现剂量补偿。

20.1.1 Introducing Biological Networks

五种生物网络类型的示例：

Regulatory Network – 生物体中的调控相互作用集合。

- 节点表示调控因子（例如转录因子）及相关靶标。
- 边表示调控相互作用，方向从调控因子指向其靶标。它们根据正效应或负效应来赋予符号，并根据反应强度赋予权重。

Metabolic Network – 连接代谢过程。在表示上有一定的灵活性，一个例子是展示酶之间共享代谢产物的图。

- 节点代表酶。

[1] More in the epigenetics lecture.

图20.1：生物网络之间的相互作用。

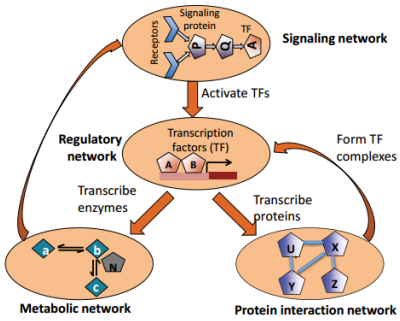

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

- 边表示调控反应，边的权重根据反应的强度来确定。边是无向的。

Signaling Network – 代表生物信号的路径。

- 节点代表称为信号受体的蛋白质。
- 边表示发送和接收的生物信号，方向从发送者指向接收者。边是有向且无权重的。

Protein Network – 显示蛋白质之间的物理相互作用。

- 节点表示单个蛋白质。
- 边表示蛋白质对之间的物理相互作用。这些边是无向且无权重的。

Coexpression Network – 描述基因之间的共表达功能。相当通用；与其他类型的网络不同，它代表的是功能而非物理交互网络。在生物数据的计算分析中是强大的工具。

- 节点代表单个基因。
- 边表示共表达关系。这些边是无向且无权的。

今天，我们将专门聚焦于调控网络。调控网络控制着情境特异性基因表达，因此对发育过程有着极大的控制作用。它们值得研究，因为它们容易发生故障，并与疾病相关联。

20.1.2 Interactions Between Biological Networks

个体生物网络（即层）本身可以被视为代表整个生物系统的更大网络中的节点。例如，我们可以有一个感知环境的信号网络，控制转录因子的表达。在这个例子中，网络将显示转录因子控制蛋白质的表达，蛋白质可以作为代谢途径中的酶发挥作用，等等。

这些网络之间信息交换的一般路径如图21.1a所示。

图20.2：不同类型的网络表示。

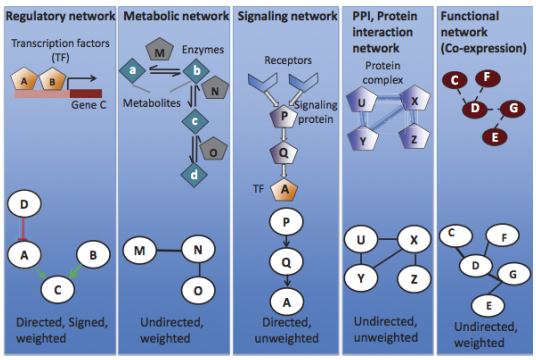

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

20.1.3 Network Representation

在图20.2中，我们展示了若干此类网络及其作为图的可视化。然而，我们是如何决定用这些特定网络来表示潜在的生物学模型的呢？给定一个大型生物数据集，我们如何理解生物对象之间的依赖关系，以及对这些依赖关系建模的最佳方式是什么？下面，我们介绍几种网络表示方法。在实践中，没有模型是完美的。模型选择应在生物学知识与可计算性之间取得平衡，以便进行合理高效的分析。

网络通常被描述为图。图由1. 节点组成，节点代表对象；以及2. 边，边代表节点之间的连接或相互作用。将生物网络视为图主要有三种方式。

Probabilistic Networks – 也称为图模型。它们对节点之间的概率分布进行建模。

- 使用图对变量的联合概率分布进行建模。
- 一些例子包括贝叶斯网络（有向）和马尔可夫随机场（无向）。关于贝叶斯网络的更多内容将在后续章节中介绍。

Physical Networks – 在这种方案中，我们通常认为节点之间是物理相互作用的，而边则捕捉了这种相互作用。

- 边表示节点之间的物理交互。
- 示例：物理调控网络。

Relevance Network – 对节点之间的相关性进行建模。

- 边权重表示节点相似度。
- 示例：功能性调控网络。

Networks as Graphs

计算机科学家考虑图的各种子类型，每种类型的边和节点都有不同的性质。

图20.3：一个3节点简单网络。该图的邻接矩阵见公式{{21.1}}。

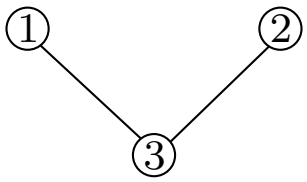

- **Weighted graph**边有相关的权重。权重通常为正。当所有重量都是 1 时，我们称之为 **unweighted graph**。
- **Directed graphs**: 边具有方向性。例如，$A \to B$与$A \leftarrow B$不同。当边没有方向时，我们称之为 **undirected graph**。
- **Multigraphs (pseudographs)**: 当我们允许两个节点之间存在多条边（如果是有向图，则超过两条）时，我们称之为多重图。例如，这对于建模两个节点之间具有不同权重的多重交互非常有用。
- **Simple graph**: 所有边都是无向且无权重的。禁止节点间的多重边和自环。

Matrix Representation of Graphs

Adjacency matrix 表示网络的一种方法是使用所谓的$adjacency\ matrix$。具有n个节点的网络的邻接矩阵是一个$n \times n$矩阵A，其中如果节点i和j之间存在边，则A_{ij}等于1，否则为0。例如，图21.6b中表示的图的邻接矩阵为：

$$A = \begin{bmatrix} 0 & 0 & 1 \\ 0 & 0 & 1 \\ 1 & 1 & 0 \end{bmatrix} \tag{20.1}$$

如果网络是加权的（即网络的每条边都有一个关联的权重），则邻接矩阵的定义会修改为：如果边存在，A_{ij} 保存 i 和 j 之间边的权重，否则为零。

邻接矩阵表示的另一个便利之处在于，当我们有一个二值矩阵（无权图）时，行 i 的和给出了节点 i 的 **degree**。在无向图中，节点的度是其拥有的边的数量。由于行中的每个条目告诉我们节点 i 是否与另一个节点相连，通过将所有值相加，我们知道节点 i 连接到了多少个节点，从而得到度数。

20.2 Network Centrality Measures

我们在上一章讨论了如何将生物网络进行数学建模。现在，当我们可视化这些图并试图理解它们时，我们需要一些衡量节点/边对系统结构特征重要性的标准。衡量节点重要性（我们称之为中心性）的方法有很多。在本章中，我们将探讨这些概念并研究它们的意义。

vector decomposition – Lasso and Elastic lasso

Low
still i

20.2.1 Degree Centrality

关于中心性的第一个想法是通过节点的度来衡量重要性。这可能是最直观的中心性度量之一，因为它非常容易可视化和推理。连接到你的边越多，你在网络中就越重要。

让我们通过一个简单的例子来探讨如何计算这些中心性。我们有以下图形

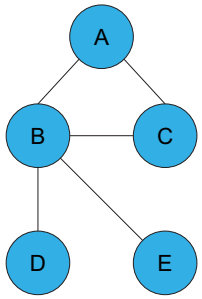

我们的目标是找出图中每个节点的度中心性。为此，我们首先写出该图的邻接矩阵。边的顺序为A、B、C、D、E。

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 1 & 1 \\ 1 & 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \end{bmatrix} \tag{20.2}$$

之前我们讨论了如何根据邻接矩阵找到节点的度数。我们对邻接矩阵的每一行进行求和。

$$D = \begin{bmatrix} 1 \\ 4 \\ 3 \\ 1 \\ 1 \end{bmatrix} \tag{20.3}$$

现在 D 是一个包含每个节点度数的向量。这个向量为我们提供了网络中节点的相对中心性度量。我们可以观察到，节点 B 具有最高的度中心性。

尽管这个指标给了我们很多洞见，但它也有其局限性。设想这样一种情况：有一个节点将网络的两个部分连接在一起。这个节点的度数会是2，但其重要性远不止于此。

20.2.2 Betweenness Centrality

介数中心性为我们提供了一种思考网络中重要性的另一种方式。它衡量的是图中经过该节点的最短路径数量与最短路径总数之比。换句话说，该指标计算每对节点之间的所有最短路径，并查看其中经过节点 k 的百分比。这个百分比给出了节点 k 的中心性。

- 介数中心性高的节点控制着网络中的信息流动。
- 边介数的定义方式类似。

20.2.3 Closeness Centrality

为了正确定义紧密性，我们需要定义术语**farness**。两个节点之间的距离是它们之间的最短路径。节点的远度是该节点与所有其他节点之间距离的总和。节点的紧密性是其余远度的倒数。换句话说，它是图中拓扑距离之和的归一化倒数。

最中心的节点是网络中信息传播最快的节点。

紧密度中心性的描述使其与度中心性相似。最高度中心性是否总是最高紧密度中心性？不是。想想一个节点连接两个组件的例子，该节点的度中心性较低，但紧密度中心性较高。

20.2.4 Eigenvector Centrality

特征向量中心性扩展了度中心性的概念。理解它的最佳方式是将其视为其网络邻居中心性的平均值。中心性向量可表示为：

$$x = \frac{1}{\lambda} Ax$$

其中 A 是邻接矩阵。上述方程的解将是与 **principle component** (最大特征值)相对应的 **eigenvector** 。

以下部分回顾了线性代数概念，包括特征值和特征向量。

20.3 Linear Algebra Review

本节的目标是提醒你一些你在先行代数课上学到的概念。这并不是要详细讲解。如果你想了解更多关于以下任何概念的内容，我建议你拿起一本线性代数书，阅读相关章节。但这将作为一个很好的提醒，并指出本章中对我们很重要的概念。

20.3.1 Eigenvectors

给定方阵 A，$(m \times m)$，特征向量 v 是以下方程的解。

$$Av = \lambda v$$

换句话说，如果我们将矩阵乘以那个向量，我们仅改变平行于该向量的位置（我们得到向量 v 的缩放版本）。

而向量v被缩放)的程度被称为**eigenvalue**。

那么最多有多少个特征值？让我们迈出解这个方程的第一步。

$$Av = \lambda v \Rightarrow (A - \lambda I)v = 0$$

当$|A - \lambda I| = 0$时，该方程有非零解。即关于λ的一个m阶方程，最多可有m个不同的解。请记住，这些解可能是复数，即使A是实数。

20.3.2 Vector decomposition

由于特征向量构成了所有基的集合，它们完全代表了列空间。鉴于此，我们可以将任意向量x分解为特征向量的组合。

$$x = \sum_i c_i v_i$$

因此，当我们将向量与矩阵A相乘时，我们可以用特征向量来重写它。

$$Ax = A(c_1 v_1 + c_2 v_2 + ...)$$

$$Ax = c_1 A v_1 + c_2 A_v 2 + ...$$

$$Ax = c_1 \lambda_1 v_1 + c_2 \lambda_2 v_2 + c_3 \lambda_3 v_3 + ...$$

因此，A作用在x上是由特征值和特征向量决定的。我们可以观察到，小特征值对乘法的影响较小。

Did You Know?

- 对于对称矩阵，不同特征值对应的特征向量是正交的。
- 实对称矩阵的所有特征值都是实数。
- 半正定矩阵的所有特征值均为非负。

20.3.3 Diagonal Decomposition

也称为特征分解。设 S 为一个方阵 $m \times m$，具有 m 个线性无关的特征向量（一个非亏损矩阵）。

然后，存在一个分解（矩阵数字化定理）

$$S = U\Lambda U^{-1}$$

其中U的列是S的特征向量。而Λ是一个对角矩阵，其对角线上的元素为特征值。

20.3.4 Singular Value Decomposition

通常，奇异值分解（SVD）用于更一般的情况，即分解一个$m \times n$非方阵:

$$\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T \tag{20.4}$$

其中 $\mathbf{U}$ 是一个表示 $\mathbf{A}\mathbf{A}^T$ 的正交特征向量的 $m \times m$ 矩阵，$\mathbf{V}$ 是一个表示 $\mathbf{A}^T\mathbf{A}$ 的正交特征向量的 $n \times n$ 矩阵，$\mathbf{\Sigma}$ 是一个表示 $\mathbf{A}^T$ × $\mathbf{A}$ (的特征值的平方根的 m n 矩阵，称为 $\mathbf{A}$) 的奇异值:

$$\mathbf{\Sigma} = diag(\sigma_1, ..., \sigma_r),\ \sigma_i = \sqrt{\lambda_i} \tag{20.5}$$

在Matlab中，只需一条命令即可计算任意给定矩阵的SVD，我们不会涉及计算它的技术细节。请注意，所得到的“对角”矩阵$\mathbf{\Sigma}$可能并非满秩，即它可能有零对角线，非零奇异值的最大数量是min(m, n)。

例如，令

$$A = \begin{bmatrix} 1 & -1 \\ 1 & 0 \\ 1 & 0 \end{bmatrix},$$

因此 $m = 3,\ n = 2$。其SVD为

$$\begin{bmatrix} 0 & \frac{2}{\sqrt{6}} & \frac{1}{\sqrt{3}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{6}} & \frac{1}{\sqrt{3}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{6}} & -\frac{1}{\sqrt{3}} \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & \sqrt{3} \\ 0 & 0 \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{bmatrix}.$$

通常，奇异值按递减顺序排列。

SVD在统计、数值分析和图像处理技术中被广泛使用。SVD的一个典型应用是矩阵的最优低秩近似。例如，如果我们有一个大型数据矩阵，比如1000×500，并且我们希望用低秩矩阵对其进行近似，同时尽量减少信息损失，则可以将其表述为以下优化问题：

$$\text{Find } \mathbf{A}_k \text{ of rank } k \text{ such that } \mathbf{A}_k = \min_{\mathbf{X}:rank(\mathbf{X})=k} ||\mathbf{A} - \mathbf{X}||_F \tag{20.6}$$

其中下标F表示Frobenius 范数 $||\mathbf{A}||_F = \sqrt{\sum_i \sum_j |a_{ij}|^2}$。通常 k 远小于 r。该问题的解是 $\mathbf{X}$、$\mathbf{U\Sigma V}^T$ 的SVD，其中 中 个最小的 $r - k$ 奇异值在 $\mathbf{\Sigma}$ 中被置零：

$$\mathbf{A}_k = \mathbf{U}\text{diag}(\sigma_1, ..., \sigma_k, ..., 0)\mathbf{V}^T. \tag{20.7}$$

可以证明这种近似的误差为$||\mathbf{A} - \mathbf{A}_k||_F = \sigma_{k+1}$。这也称为Eckart-Young定理。

SVD在网络分析中的一个常见应用是利用邻接矩阵奇异值的分布来评估我们的网络是否看起来像一个随机矩阵。由于奇异值的分布（Wigner半圆律）和矩阵最大特征值的分布（Tracy-Widom分布）已在理论上推导出来，因此可以推导出观察到的网络（矩阵）的特征值（SVD中的奇异值）的分布，并为每个特征值计算一个p值。然后我们只需查看显著的特征值（奇异值）及其对应的特征向量（奇异向量），以检查网络中的重要结构。下图显示了随机高斯酉系综（GUE，定义和性质见此维基百科链接 `http://en.wikipedia.org/wiki/Random_matrix`）矩阵的奇异值分布，根据Wigner半圆律，其形成半圆形（图20.4）。

图20.5展示了一个利用SVD推断矩阵或网络中结构模式的例子。左上图显示了一个结构（红色）被添加到随机矩阵中（热图中的蓝色背景），该结构跨越了第一行和前三列。SVD通过识别出一个大的奇异值（在奇异值分布上以红色圈出）以及相应的大行载荷（U_1）和三个大的列载荷（V_1）来检测这一点。随着更多结构被添加到网络中（右上图和底图），可以通过查看下一个最大的奇异值及相应的行/列载荷等，利用SVD来发现它们。

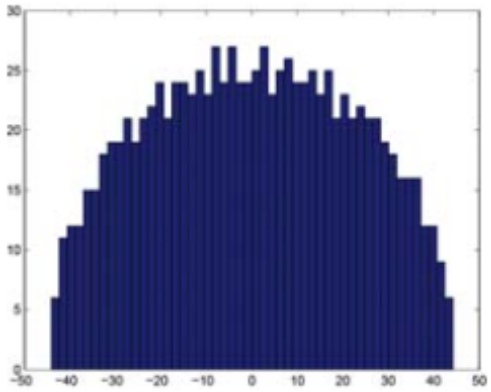

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图20.4：维格纳半圆定律

20.4 Sparse Principal Component Analysis

20.4.1 Limitations of Principal Component Analysis

在分析基于微阵列的基因表达数据时，我们经常处理维度为 $m \times n$ 的数据矩阵，其中 m 是微阵列的数量，n 是基因的数量。通常 n 在数千的数量级，而 m 在数百的数量级。我们希望识别出最能解释数据集中表达变异或模式的最重要特征（基因）。这可以通过对表达矩阵进行PCA来实现：

$$\mathbf{E} = \mathbf{UDV}^T. \tag{20.8}$$

这本质上是对表达矩阵**E**的SVD，它旋转并缩放特征空间，使得在新正交坐标系中每个基因的表达向量尽可能不相关，其中**E**是m乘以n的表达矩阵，**U**是m乘以m的左奇异向量矩阵（即主成分），或称“特征基因”，**V**是n乘以n的右奇异向量矩阵，或称“特征阵列”，而**D**是特征基因的奇异值对角矩阵，或称“特征表达”。这在图20.6中进行了说明。

在PCA中，每个主成分（特征基因，**U**的一列）是n个变量（基因）的线性组合，这对应于一个载荷向量（**V**的一列），其中载荷是线性组合中变量对应的系数。

然而，将PCA直接应用于表达矩阵或任何大型数据矩阵可能存在问题，因为主成分（特征基因）是$all\ n$个变量（基因）的线性组合，从功能相关性的角度难以解释。在实践中，我们希望使用尽可能少的基因组合来解释表达模式，这可以通过PCA的稀疏版本实现。

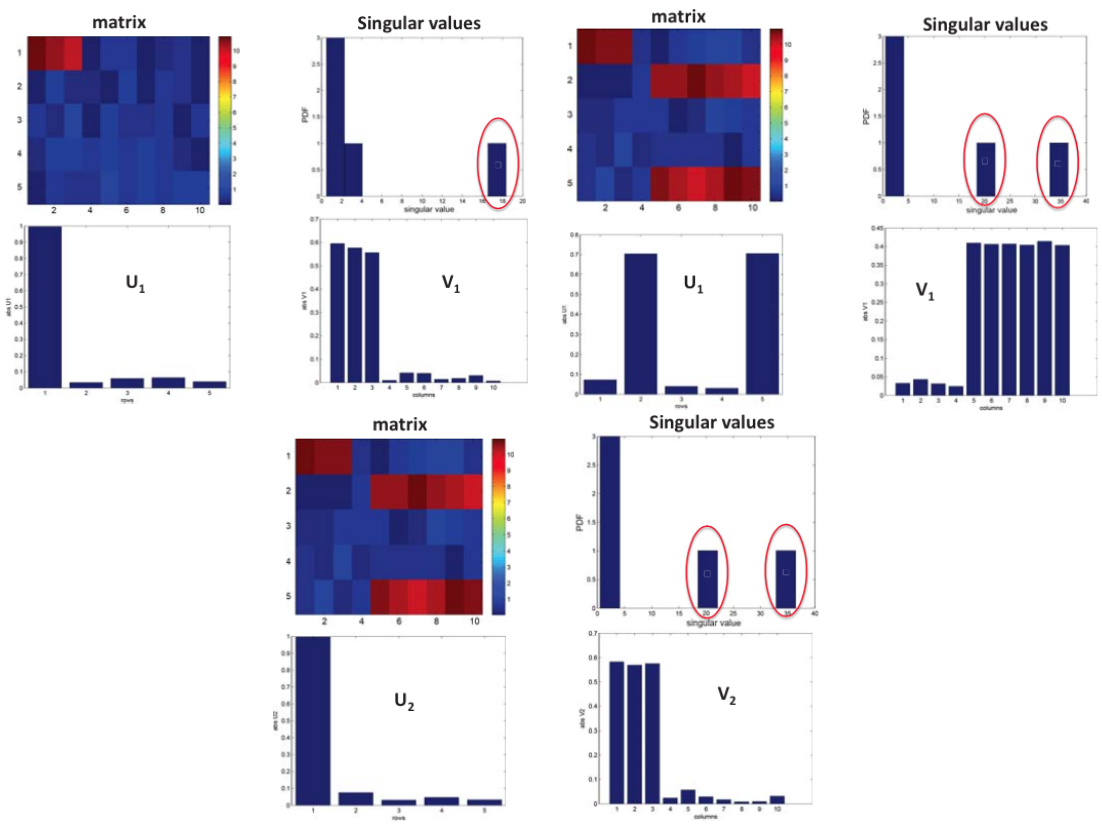

© source unknown. All rights reserved. This content is excluded from our Creative
知识共享许可协议。如需了解更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图20.5：使用SVD进行结构推断

20.4.2 Sparse PCA

稀疏PCA（SPCA）修改了PCA，以约束主成分（PCs）具有稀疏载荷，从而减少了显式使用的变量数量（如微阵列数据中的基因等），并促进了可解释性。这是通过将PCA表述为线性回归型优化问题并施加稀疏性约束来实现的。

线性回归问题接收一组输入变量 $\mathbf{x} = (1, x_1, ..., x_p)$ 和响应变量 $\mathbf{y} = \mathbf{x}\beta + \epsilon$，其中 β 是回归系数的行向量 $(\beta_0, \beta_1, ..., \beta_p)^T$，$\epsilon$ 是误差。对于 N 个观测值的回归模型可以写成矩阵形式：

$$\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix} = \begin{bmatrix} 1 & x_{1,1} & x_{1,2} & \cdots & x_{1,p} \\ 1 & x_{2,1} & x_{2,2} & \cdots & x_{2,p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{N,1} & x_{N,2} & \cdots & x_{N,p} \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{bmatrix} + \begin{bmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_N \end{bmatrix} \tag{20.9}$$

线性回归问题的目标是估计系数β。常用的方法有最小二乘法、Lasso法和弹性网络法。

Least Squares 方法最小化残差平方和 错误：

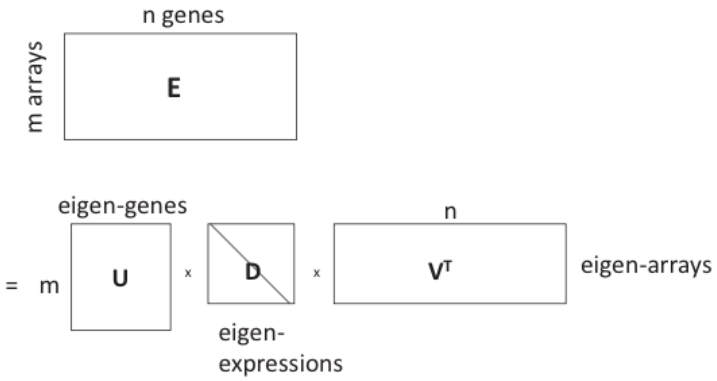

图 20.6：使用 PCA 的特征基因分解

$$\hat{\beta} = \text{argmin}_{\beta}\{RSS(\beta)|D\} \tag{20.10}$$

其中 $RSS(\beta \equiv \sum_{i=1}^{N}(y_i - X_i\beta)^2$ (X_i 是输入变量 $\mathbf{x}$) 的第 i 个实例。图 20.7 展示了二维和三维情况下的这一过程，其中会产生回归线或超平面。

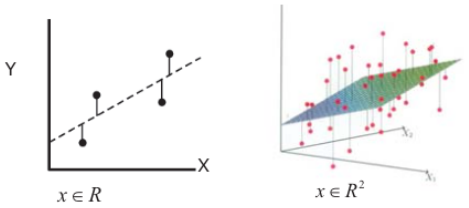

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 htt
p://ocw.mit.edu/help/faq-fair-use/。

图20.7：线性回归的最小二乘解。左：二维情况，右：三维情况

Lasso 该方法不仅最小化残差误差的总和，同时还最小化一个Lasso惩罚项，该惩罚项与系数向量β的L-1范数成正比：

$$\hat{\beta} = \text{argmin}_{\beta}\{RSS(\beta) + L_1(\beta)|D\} \tag{20.11}$$

其中 $L_1(\beta) = \lambda \sum_{j=1}^{p} |\beta_j|$, $\lambda \geq 0$。稀疏 PCA 的理想惩罚是 L_0 范数，它对每个非零元素惩罚 1，而零元素惩罚为 0。然而，L_0 惩罚函数是非凸的，探索指数空间（非零元素可能组合的数量 ）的最佳解决方案是 NP 难问题。L_1 范数提供了对 L_0 范数的凸近似。Lasso 回归模型本质上尽可能地将系数持续向零收缩，从而产生一个稀疏模型。它自动选择能够解释数据变异的最小变量集。然而，Lasso 方法存在一个问题：如果存在一组高度相关的变量，它倾向于仅选择这些变量中的一个。此外，Lasso 最多选择 N 个变量，即所选变量的数量受样本大小的限制。

Elastic Net 该方法通过添加岭约束，消除了Lasso方法的组选择限制：

$$\hat{\beta} = \text{argmin}_\beta\{RSS(\beta) + L_1(\beta) + L_2(\beta)|D\} \tag{20.12}$$

其中 $L_2(\beta) = \lambda_2 \sum_{j=1}^{p} |\beta_j|^2$, $\lambda_2 \geq 0$。在弹性网络解中，一组高度相关的变量一旦其中被包含，就会被选中。

上面所有的附加惩罚项都源自正则化的理论框架。我们略过该技术背后的数学原理，并指向`http://scikit-learn.org/stable/modules/linear_model.html`中关于正则化的在线简明解释和教程。

PCA 可以通过将每个主成分视为 p 变量的线性组合，在回归框架中重构。因此，其载荷可以通过将主成分对 p 变量进行回归来恢复（图20.8）。令 $\mathbf{X} = \mathbf{UDV}^T$.$\forall i$ 表示 $Y_i = U_i D_{ii}$，则 Y_i 是 $\mathbf{X}$ 的第 i 个主成分。我们不加证明地陈述以下定理，以确认重构的正确性：

Theorem 20.4.1. $\forall \lambda > 0$, *suppose* $\hat{\beta}_{ridge}$ *is the ridge estimate given by*

$$\hat{\beta}_{ridge} = \text{argmin}_\beta |Y_i - X_i\beta|^2 + \lambda|\beta|^2,$$

and let $\hat{\mathbf{v}} = \frac{\hat{\beta}_{ridge}}{|\hat{\beta}_{ridge}|}$, *then* $\hat{\mathbf{v}} = V_i$.

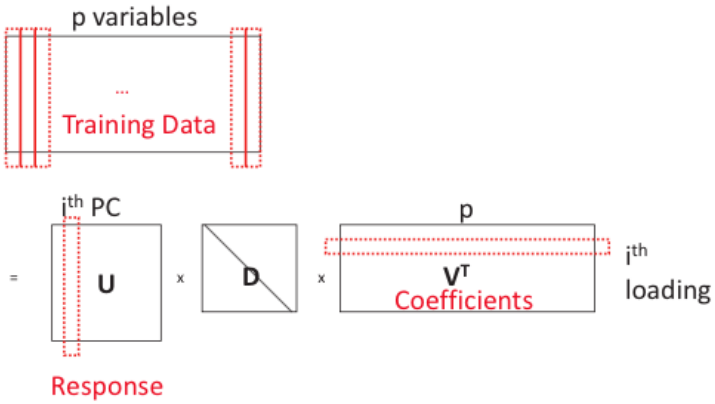

图20.8：回归框架中的PCA

请注意，岭惩罚并不惩罚系数，而是确保主成分的重建。这样的回归问题不能作为朴素PCA的替代方案，因为它直接在模型中使用了其结果**U**，但可以通过在回归问题中添加Lasso惩罚来惩罚系数的绝对值，从而对其进行修改：

$$\hat{\beta}_{ridge} = \text{argmin}_\beta |Y_i - X_i\beta|^2 + \lambda|\beta|^2 + \lambda_1|\beta|, \tag{20.13}$$

其中 $\mathbf{X} = \mathbf{UDV}^T$ 和 $\forall i$，$Y_i = U_i D_{ii}$ 是 $\mathbf{X}$ 的第 i 个主成分。所得到的 β 当其按范数缩放时，$\hat{}$ 正是 SPCA 所追求的目标——稀疏载荷：

$$\hat{V}_i = \frac{\hat{\beta}}{|\hat{\beta}|} \approx V_i, \tag{20.14}$$

其中$X\hat{V_i} \approx Y_i$是第i个稀疏主成分。

这里我们给出一个模拟的示例数据集，并比较使用PCA和SPCA恢复隐藏因子的效果。我们有10个变量用于生成数据点：$\mathbf{X} = (X_1, ..., X_{10})$，并使用一个包含3个隐藏因子$V_1$、$V_2$和$V_3$的模型来生成数据：

$$
\begin{aligned}
V_1 &\sim N(0, 290) \\
V_2 &\sim N(0, 300) \\
V_3 &\sim -0.3V_1 + 0.925V_2 + e, e \sim N(0, 1) \\
X_i &= V_1 + e_i^1, e_i^1 \sim N(0, 1), i = 1, 2, 3, 4 \\
X_i &= V_2 + e_i^2, e_i^2 \sim N(0, 1), i = 5, 6, 7, 8 \\
X_i &= V_3 + e_i^3, e_i^3 \sim N(0, 1), i = 9, 10
\end{aligned}
$$

根据这些数据，我们预期稀疏PCA模型能够揭示出两个显著的结构，分别由隐藏因子V_1和V_2所主导（而V_3仅是这两者的线性混合）。实际上，如图20.9所示，通过限制所使用的变量数量，SPCA能正确恢复解释V_1和V_2效应的主成分，而PCA则无法在隐藏因子的混合中做出良好区分。

	PCA			SPCA ($\lambda = 0$)	
	PC1	PC2	PC3	PC1	PC2
X_1	0.116	-0.478	-0.087	0.0	0.5
X_2	0.116	-0.478	-0.087	0.0	0.5
X_3	0.116	-0.478	-0.087	0.0	0.5
X_4	0.116	-0.478	-0.087	0.0	0.5
X_5	-0.395	-0.145	0.270	0.5	0.0
X_6	-0.395	-0.145	0.270	0.5	0.0
X_7	-0.395	-0.145	0.270	0.5	0.0
X_8	-0.395	-0.145	0.270	0.5	0.0
X_9	-0.401	0.010	-0.582	0.0	0.0
X_{10}	-0.401	0.010	-0.582	0.0	0.0
Adjusted Variance (%)	60.0	39.6	0.08	40.9	39.5

图20.9：PCA与SPCA

20.5 Network Communities and Modules

是否可以利用网络来推断未标记节点或数据的标签？假设网络中的某些数据已被标记，我们可以利用网络通过“关联定罪”方法捕捉关系信息的思想。简而言之，我们可以查看网络中一个节点的已标记“朋友”来推断新节点的标签。尽管“关联定罪”的推理方式是一种逻辑谬误，在法律法庭环境中不足以作为证据，但通过查看节点邻居的标签来预测网络中节点的标签（例如基因功能）通常是有帮助的。本质上，一个与许多具有相同标签的节点相连的节点很可能也具有该标签。在生物网络中，节点代表基因，边代表相互作用（调控、共表达、蛋白质-蛋白质相互作用等，见图20.11），可以根据查询基因所连接的基因的功能来预测未注释基因的功能。很容易看出，我们可以立即将其应用于迭代算法中，即从一组已标记节点和未标记节点开始，迭代更新关系属性

然后重新推断节点的标签。我们迭代直到所有节点都被标记。这被称为迭代分类算法。

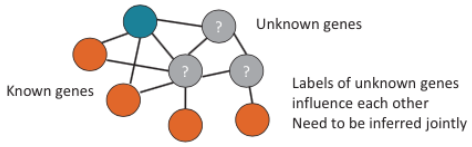

图20.10：迭代分类算法

“连带罪责”暗示了一种关联的概念。我们在上文中隐含考虑的关联定义是一种直接的定义，即我们考虑与特定节点直接相连的所有节点。我们能否给出一个更好的关联定义？思考这个问题，我们自然想到图中的社区或模块的概念。社区一词试图捕捉图中一个区域的概念，该区域内的节点连接密集，而与其他区域则以稀疏的边相连。像这样具有密集连接子图的图通常被称为模块化的。请注意，对于社区的精确定义尚无共识。在实际应用中，社区的定义应当具有生物学动机，并基于对被建模系统的先验知识。在生物学中，调控网络通常是模块化的，每个密集连接子图中的基因具有相似的功能和共同调控。然而，基于不同的拓扑特征，已经发展出了广泛的社区类别。它们大致可以分为4类：以节点为中心、以群体为中心、以网络为中心和以层次为中心的社区。在此，我们分别考察前三种类型中每种类型的一个常用标准，并简要介绍一些检测这些社区的著名算法。

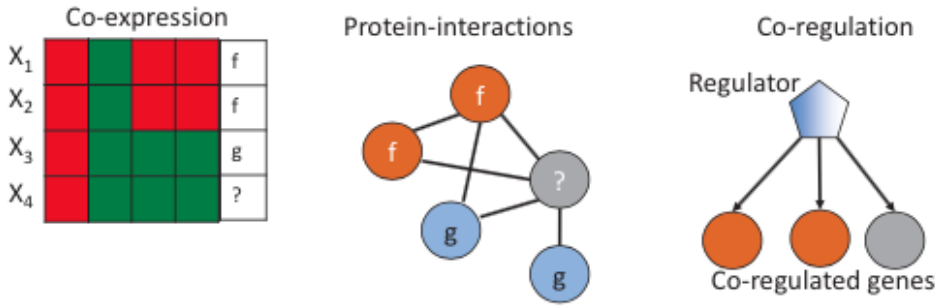

图20.11：利用关联预测基因功能

20.5.1 Node-Centric Communities

以节点为中心的社区标准通常要求组中的 *each node* 满足某些性质。一个常用的以节点为中心的社区定义是**clique**，即一个最大完全子图，其中所有节点都彼此相邻。图20.12展示了网络中的一个团（节点5、6、7和8）的示例。

在网络中精确寻找最大团是NP难问题，因此实现直接用于团寻找的算法计算成本非常高。启发式方法常被用来通过牺牲一定比例的准确性来限制时间复杂度。最大团寻找中常用的一种启发式方法基于这样的观察：在大小为k的团中，每个节点至少保持$k-1$的度数。因此，我们可以应用以下修剪过程：

- 从给定网络中采样一个子网络，并在该子网络中使用高效方法找到团。

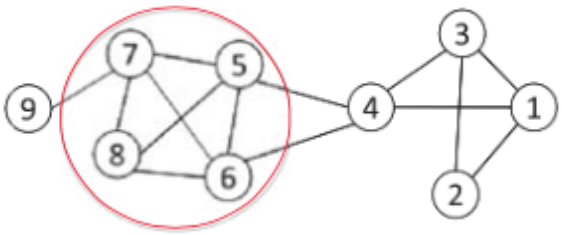

图20.12：一个包含4-团的示例网络

（例如贪心）方法

- 假设已识别的团大小为 k，要找到更大的团，则移除所有度数小于或等于 $k-1$ 的节点
- 重复直到网络足够小

在实践中，许多节点会因社交媒体网络及多种形式的生物网络遵循节点度的幂律分布而被剪枝，这种分布导致大量低度节点的存在。

以图20.12中的网络为例，说明这种团寻找过程。假设我们采样了一个节点编号为1至9的子网络，并找到了一个大小为3的团$\{1, 2, 3\}$。为了找到大小大于3的团，我们迭代地移除所有度数为≤ 2的节点，即节点$\{2, 9\}$、$\{1, 3\}$和4将被依次移除。这留下了4-团$\{5, 6, 7, 8\}$。

20.5.2 Group-Centric Communities

以群体为中心的社区标准将连接 *within a group* 视为一个整体，并且群体必须满足某些属性，而无需深入到节点级别，例如群体边密度必须超过给定阈值。如果满足以下条件，我们称子图 $G_s(V_s, E_s)$ 为 $\gamma - dense$ **quasi-clique**：

$$\frac{2|E_s|}{|V_s||V_s - 1|} \geq \gamma \tag{20.15}$$

其中分母是网络中边的最大数量。根据这样的定义，可以采用与我们讨论过的寻找最大团的启发式方法相似的策略：

- 采样一个子网络并找到一个最大 $\gamma - dense$ 准团（例如大小为 $|V_s|$
- 除度数小于平均度数的节点（$< |V_s|\gamma \leq \frac{2\,E\,移}{|V_s|-1}$）
- 重复直到网络足够小

20.5.3 Network-Centric Communities

以网络为中心的定义旨在将 *the entire network* 划分为几个不相交的集合。实现这一目标存在多种方法，如下所列：

- 马尔可夫聚类算法[6]：马尔可夫聚类算法（MCL）通过在图中进行随机游走并观察该游走的稳态分布来工作。这种稳态分布允许将图聚类为密集连接的子图。
- Girvan-Newman算法[2]：Girvan-Newman算法利用通过节点的最短路径数量来计算边的*essentiality*，进而可用于网络的聚类。
- 谱划分算法

在本节中，我们将详细探讨谱分区算法。关于其他算法的描述，请参阅参考文献[2, 6]。

谱划分算法依赖于使用矩阵表示网络的某种方式。在介绍该算法之前，我们先引入网络的一个重要描述——其拉普拉斯矩阵。

Laplacian matrix 对于本节稍后将介绍的聚类算法，我们需要计算网络划分中两个不同组之间的边数。例如，在图21.6a中，两组之间的边数为1。我们即将引入的*Laplacian matrix*正好可以用来代数地表示这个量。一个包含n个节点的网络的拉普拉斯矩阵L是一个$n \times n$矩阵L，它与邻接矩阵A非常相似，只是在符号和 diagonal 元素上有所不同。邻接矩阵的对角元素总是等于零（因为我们没有自环），而拉普拉斯矩阵的对角元素则持有每个节点的*degree*（其中节点的度定义为其关联的边数）。此外，拉普拉斯矩阵的非对角元素在有边存在时设为-1，否则为零。换句话说，我们有：

$$L_{i,j} = \begin{cases} \text{degree}(i) & \text{if } i = j \\ -1 & \text{if } i \neq j \text{ and there is an edge between } i \text{ and } j \\ 0 & \text{if } i \neq j \text{ and there is no edge between } i \text{ and } j \end{cases} \tag{20.16}$$

例如，图21.6b的图的拉普拉斯矩阵为（我们用粗体强调了对角线元素）：

$$L = \begin{bmatrix} \mathbf{1} & 0 & -1 \\ 0 & \mathbf{1} & -1 \\ -1 & -1 & \mathbf{2} \end{bmatrix}$$

Some properties of the Laplacian matrix 任何网络的拉普拉斯矩阵都具有一些良好的性质，这些性质在我们后面研究聚类算法时将变得很重要。我们在此简要回顾这些性质。

拉普拉斯矩阵 L 总是 **symmetric**，即对于任何 i, j，有 $L_{i,j} = L_{j,i}$。这一观察的一个重要推论是，L 的所有特征值都是实数（即它们没有复数虚部）。事实上，甚至可以证明 L 的所有特征值都是非负的[2] 我们提到的最后一个性质

[2]One way of seeing this is to notice that L is diagonally dominant and the diagonal elements are strictly positive (for more details the reader can look up "diagonally dominant" and "Gershgorin circle theorem" on the Internet).

关于 L 的一点是，L 的所有行和列之和都为零（这很容易用 L 的定义来验证）。这意味着 L 的最小特征值始终等于零，并且对应的特征向量是 $s = (1, 1, \ldots, 1)$。

Counting the number of edges between groups using the Laplacian matrix 利用拉普拉斯矩阵，我们现在可以通过简单的矩阵运算轻松计算出将图的两个不相交部分分隔开的边数。事实上，假设我们将图划分为两组，并定义一个大小为 n 的向量 s，它告诉我们每个节点 i 属于哪一组：

$$s_i = \begin{cases} 1 & \text{if node } i \text{ is in group 1} \\ -1 & \text{if node } i \text{ is in group 2} \end{cases}$$

然后可以很容易地证明，组1和组2之间的边总数由量[1] $s^T L s$给出，其中L是网络的拉普拉斯矩阵。[4]

为了弄清为什么会这样，让我们先计算矩阵-向量乘积 Ls。特别地，让我们固定一个节点 i，比如在第1组（即 $s_i = +1$），然后看看矩阵-向量乘积 Ls 的第 i 个分量。根据矩阵-向量乘积的定义，我们有：

$$(Ls)_i = \sum_{j=1}^{n} L_{i,j} s_j.$$

我们可以将这个和分解为三个加数，如下所示：

$$(Ls)_i = \sum_{j=1}^{n} L_{i,j} s_j = L_{i,i} s_i + \sum_{j \text{ in group 1}} L_{i,j} s_j + \sum_{j \text{ in group 2}} L_{i,j} s_j$$

利用拉普拉斯矩阵的定义，我们很容易看出，第一项对应于i的度数，即与i相关联的边的数量；第二项等于连接i与第一组中其他节点的边的数量的负值，而第三项等于连接i与第二组中某个节点的边的数量。因此，我们有：

$$(Ls)_i = \text{degree}(i) - (\#\text{ edges from } i \text{ to group 1}) + (\#\text{ edges from } i \text{ to group 2})$$

现在，由于来自 {v*} 的任何边要么进入组1，要么进入组2，我们有

$$\text{degree}(i) = (\#\text{ edges from } i \text{ to group 1}) + (\#\text{ edges from } i \text{ to group 2}).$$

因此，结合上述两个方程，我们得到：

$$(Ls)_i = 2 \times (\#\text{ edges from } i \text{ to group 2}).$$

现在，要得到组1和组2之间的总边数，我们只需将上述数量对组1中的所有节点{v*}求和：

$$(\#\text{ edges between group 1 and group 2}) = \frac{1}{2} \sum_{i \text{ in group 1}} (Ls)_i$$

我们还可以看　在组2的节点上计算相同的量和w　我们有：

$$(\#\text{ edges between group 1 and group 2}) = -\frac{1}{2} \sum_{i \text{ in group 2}} (Ls)_i$$

现在对上面两个方程取平均，我们得到所需结果：

$$\begin{aligned}(\#\text{ edges between group 1 and group 2}) &= \frac{1}{4}\sum_{i\text{ in group 1}}(Ls)_i - \frac{1}{4}\sum_{i\text{ in group 2}}(Ls)_i \\ &= \frac{1}{4}\sum_i s_i(Ls)_i \\ &= \frac{1}{4}s^TLs\end{aligned}$$

其中 s^T 是通过转置列向量 s 得到的行向量。

The spectral clustering algorithm 现在我们将看到如何使用上一节给出的网络的线性代数视角来产生图的“良好”划分。在图的任何良好划分中，两组之间的边数必须相对于每组内部的边数而言相对较小。因此，解决该问题的一种方法是寻找一种划分，使得两组之间的边数最小。使用上一节引入的工具，这个问题因此等价于寻找一个仅取值-1或$+1$的向量$s \in \{-1,+1\}^n$，使得$\frac{1}{4}s^TLs$最小，其中L是图的拉普拉斯矩阵。换句话说，我们想求解最小化问题：

$$\underset{s\in\{-1,+1\}^n}{\text{minimize}} \quad \frac{1}{4}s^TLs$$

如果s^*是最优解，则最优划分是将节点i分配给组1，如果$s_i = +$为1；否则分配给组2。

这个公式看起来合理，但遗憾的是有一个小问题：这个问题的解总是会变成 $s = (+1,\ldots,+1)$，这意味着将网络中的所有节点都放入组1，而组2中没有任何节点！组1和组2之间的边数因此为零，确实是最小的！

为了获得有意义的分割，我们必须考虑图的非平凡分割。回想一下，拉普拉斯矩阵 L 总是对称的，因此它允许特征分解：

$$L = U\Sigma U^T = \sum_{i=1}^n \lambda_i u_i u_i^T$$

其中 Σ 是一个对角矩阵，包含 L 的非负特征值 $\lambda_1,\ldots,\lambda_n$，$U$ 是特征向量矩阵，并且满足 $U^T = U^{-1}$。

划分 $s \in \{-1,+1\}^n$ 的代价由下式给出

$$\frac{1}{4}s^TLs = \frac{1}{4}s^TU\Sigma U^Ts = \frac{1}{4}\sum_{i=1}^n \lambda_i\alpha_i^2$$

其中 $\alpha = U^T{}_n\, s$ 给出了 s 作为 L 的特征向量的线性组合的分解：$s = \sum_{i=1}\alpha_i u_i$。

另请回想，$0 = \lambda_1 \le \lambda_2 \le \cdots \le \lambda_n$。因此，使上述量尽可能小（不采用平凡划分）的一种方法是将所有权重集中在 λ_2 上，它是 L 的最小非零特征值。为了实现这一点，我们只需选择 s，使得对于所有 $k \neq 2$，$\alpha_2 = 1$ 且 $\alpha_k = 0$。换句话说，这相当于取 s 等于 u_2，即 L 的第二特征向量。由于一般来说特征向量 u_2 不是整数值（即 u_2 的分量可能不同于 -1 或 $+1$），我们必须首先转换

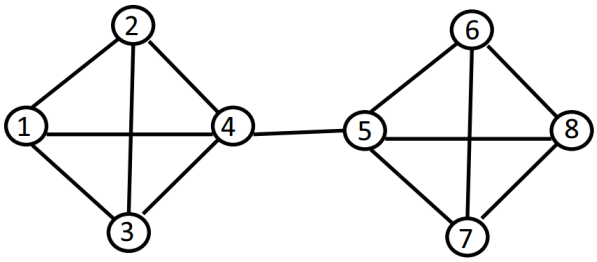

图20.13：一个包含8个节点的网络。

将向量u_2转换为由+1或−1组成的向量。实现这一点的简单方法是仅查看u_2的分量的符号，而不是数值本身。因此，我们的划分由下式给出：

$$s = \text{sign}(u_2) = \begin{cases} 1 & \text{if } (u_2)_i \geq 0 \\ -1 & \text{if } (u_2)_i < 0 \end{cases}$$

总之，谱聚类算法的流程如下 s：

Spectral partitioning algorithm

- 输入：一个网络
- 输出：网络的一种划分，其中每个节点被分配到组1或组2，使得两组之间的边数较少

1. 计算由图给出的拉普拉斯矩阵 L：

$$L_{i,j} = \begin{cases} \text{degree}(i) & \text{if } i = j \\ -1 & \text{if } i \neq j \text{ and there is an edge between } i \text{ and } j \\ 0 & \text{if } i \neq j \text{ and there is no edge between } i \text{ and } j \end{cases}$$

2. 计算对应于 L 次小特征值的特征向量 u_2。

3. 输出以下划分：如果 $(u_2)_i \geq 0$，则将节点 i 分配到组 1，否则将节点 i 分配到组 2。

接下来，我们给出一个将谱聚类算法应用于具有8个节点的网络的例子。

Example 我们在此以图21.7所示的一个包含8个节点的简单网络为例，说明上述分区算法。该图的邻接矩阵和拉普拉斯矩阵如下所示：

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 1 & 1 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 1 & 0 & 0 & 0 & 0 \\ 1 & 1 & 1 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 1 & 1 & 1 \\ 0 & 0 & 0 & 0 & 1 & 0 & 1 & 1 \\ 0 & 0 & 0 & 0 & 1 & 1 & 0 & 1 \\ 0 & 0 & 0 & 0 & 1 & 1 & 1 & 0 \end{bmatrix} \qquad L = \begin{bmatrix} 3 & -1 & -1 & -1 & 0 & 0 & 0 & 0 \\ -1 & 3 & -1 & -1 & 0 & 0 & 0 & 0 \\ -1 & -1 & 3 & -1 & 0 & 0 & 0 & 0 \\ -1 & -1 & -1 & 4 & -1 & 0 & 0 & 0 \\ 0 & 0 & 0 & -1 & 4 & -1 & -1 & -1 \\ 0 & 0 & 0 & 0 & -1 & 3 & -1 & -1 \\ 0 & 0 & 0 & 0 & -1 & -1 & 3 & -1 \\ 0 & 0 & 0 & 0 & -1 & -1 & -1 & 3 \end{bmatrix}$$

使用Matlab的`eig`命令，我们可以计算拉普拉斯矩阵的特征分解$L = U\Sigma U^T$，得到：

$$U = \begin{bmatrix} 0.3536 & \mathbf{-0.3825} & 0.2714 & -0.1628 & -0.7783 & 0.0495 & -0.0064 & -0.1426 \\ 0.3536 & \mathbf{-0.3825} & 0.5580 & -0.1628 & 0.6066 & 0.0495 & -0.0064 & -0.1426 \\ 0.3536 & \mathbf{-0.3825} & -0.4495 & 0.6251 & 0.0930 & 0.0495 & -0.3231 & -0.1426 \\ 0.3536 & \mathbf{-0.2470} & -0.3799 & -0.2995 & 0.0786 & -0.1485 & 0.3358 & 0.6626 \\ 0.3536 & \mathbf{0.2470} & -0.3799 & -0.2995 & 0.0786 & -0.1485 & 0.3358 & -0.6626 \\ 0.3536 & \mathbf{0.3825} & 0.3514 & 0.5572 & -0.0727 & -0.3466 & 0.3860 & 0.1426 \\ 0.3536 & \mathbf{0.3825} & 0.0284 & -0.2577 & -0.0059 & -0.3466 & -0.7218 & 0.1426 \\ 0.3536 & \mathbf{0.3825} & 0.0000 & 0.0000 & 0.0000 & 0.8416 & -0.0000 & 0.1426 \end{bmatrix}$$

$$\Sigma = \begin{bmatrix} 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & \mathbf{0.3542} & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 4.0000 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 4.0000 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 4.0000 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 4.0000 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 4.0000 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 5.6458 \end{bmatrix}$$

我们已将L的次小特征值及相关的特征向量用粗体标出。为了对网络进行聚类，我们观察该特征向量各分量的符号。我们发现前4个分量为负，后4个分量为正。因此，我们将节点1至4归为同一组，节点5至8归为另一组。这看起来是一个很好的聚类，实际上这也是人们乍看该图时所考虑的“自然”聚类。

Did You Know?

我们将谱聚类算法的动机表述为一个数学问题，即寻找一种将图划分为两组的方法，使得两组之间的边数最少。我们提出的谱划分算法并不总能给出该问题的最优解，但在实践中通常效果良好。实际上，事实证明，我们所表述的问题可以用一种高效算法精确求解。这个问题有时被称为 **minimum cut** 问题，因为我们希望从图中切割最少数量的边以使其不连通（我们切割的边是第1组和第2组之间的边）。最小割问题通常可以在多项式时间内求解，更多信息请读者参阅关于 *minimum cut* 的维基百科条目 [9]。然而，最小割划分的问题在于，它们通常会导致图的划分不平衡（例如，一组只有一个节点，而其余节点都在另一组）。一般来说，人们希望对簇施加额外约束（例如，簇大小的下界或上界等），以获得更符合实际的簇。有了这些约束，问题会变得更困难，更多细节请读者参阅关于 *Graph partitioning* 的维基百科条目 [8]。

FAQ

Q: 如何将图划分成多于两组?

A: 在本节中，我们仅探讨了将图划分为两个聚类的问题。如果我们希望将图聚类成超过两个的聚类呢？针对此，存在多种可能的算法扩展，以处理k个聚类而非仅两个。其核心思想是考察拉普拉斯矩阵中k个最小非零特征值对应的k个特征向量，然后适当地应用k-均值聚类算法。更多信息，请参阅教程[7]。

20.6 Network Diffusion Kernels

之前，我们将两个节点之间的距离度量定义为加权最短路径。这种简单的距离度量对于许多目的来说是足够的，但它明显没有利用关于整体图结构的任何信息。通常，基于两个节点之间可能路径的数量来定义距离，并根据采取这些路径的合理性或可能性进行加权，能更好地表示我们正在建模的实际系统。在本节中，我们探讨替代的距离度量。

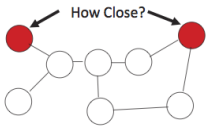

图20.14：还有哪些其他有用的距离度量?

扩散核矩阵有助于捕捉图的全局网络结构，为更复杂的距离定义提供信息。

设 A 为我们的正则邻接矩阵。D 是度的对角矩阵。我们可以定义 L，即拉普拉斯矩阵，如下所示:

$$L = D - A$$

然后我们将扩散核 K 定义为

$$K = exp(-\beta L)$$

其中 β 是扩散参数。请注意，我们采用的是矩阵指数而非逐元素指数，这是基于如下的泰勒级数展开:

$$exp(-\beta L) = \lim_{n\to\infty}(1 - \frac{\beta L}{n})^n$$

$$= \sum_{k=0}^{\infty} \frac{1}{k}(-\beta L)^k$$

那么矩阵 K 代表什么？对于 K 有多种解释方式，我们将在下面列出与我们最相关的几种：

Random Walks – 一种将K解释为随机游走结果的方法。假设我们有一个图，在感兴趣的节点上，我们有一个沿边移动的概率分布。如下图所示：

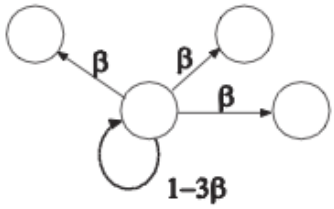

图20.15：随机游走示意图

β 是沿特定边的转移概率。此外，还存在不移动的概率（这里表示为自环）。请注意，为了使概率分布有效，其总和必须为1。

如果我们有上述设定，那么 K_{ij} 等于从 i 出发的随机游走在经过无限时间步后到达 j 的概率。为了推导这个结果，我们可以将图表示为马尔可夫模型，并取极限，当 $t \to \infty$

Stochastic Process – 我们可以通过随机过程来理解扩散核的另一种方式。

- 对于每个节点 i，考虑一个随机变量 $Z_i(t)$
- 让 $Z_i(t)$ 的均值为零，并具有某种定义的方差。
- $Z_i(t)$ 和 $Z_j(t)$ 的协方差为零（彼此独立）。
- 每个变量向邻居发送一个分数

$$Z_i(t+1) = Z_i(t) + \beta \sum_{j \neq i} (Z_j(t) - Z_i(t))$$

$$Z(t+1) = (I - \beta L)Z(t)$$

$$Z(t) = (I - \beta L)^t Z(0)$$

设时间演化算符 $T(t)$ 为

$$T(t) = (I - \beta L)^t$$

那么协方差等于

$$Cov_{ij}(t) = \sigma^2 T_{ij}(2t)$$

然后当我们取 $\Delta t \to$ 趋于0时，我们得到

$$Cov(t) = \sigma^2 exp(-2\beta t L)$$

20.7 Neural Networks

神经网络最初是为了模拟大脑和神经系统，旨在实现类脑学习。它们具有高度并行性，通过掌握简单的概念，我们能够实现极其复杂的行为。就本书而言，它们也被证明是非常优秀的生物模型（考虑到它们的起源，这一点并不令人意外）。

20.7.1 Feed-forward nets

在神经网络中，我们将输入映射到输出，通过由学习参数化的隐藏状态进行传递。

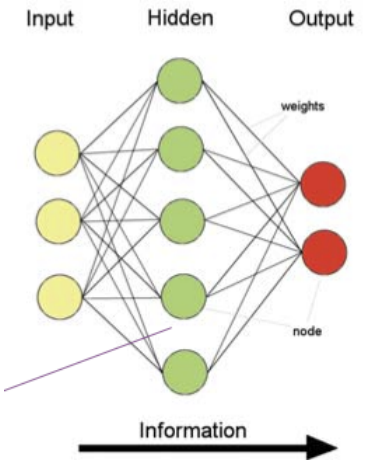

图 20.16：神经网络示意图

- 信息流是单向的
- 数据被呈现给输入层
- 传递给隐藏层
- 传递到输出层
- 信息是分布式的
- 信息处理是并行的

20.7.2 Back-propagation

反向传播是训练神经网络和让我们能够轻松处理多层网络的最具影响力的成果之一。

- 需要训练集（输入/输出对）
- 以小的随机权重开始

- 误差用于调整权重（监督学习）

它基本上在误差景观上执行梯度下降，试图最小化误差。因此，反向传播可能较慢。

20.7.3 Deep Learning

深度学习是一系列用于学习特征层次的统计机器学习技术的集合。通常基于人工神经网络。深度神经网络具有多个隐藏层。神经网络中的每个后续层都使用前一层的特征来学习更复杂的特征。深度学习方法的（相关）目标之一是执行分层特征提取。这使得深度学习成为建模系统生物学中常见的分层生成过程的一种有吸引力的方法。

Example: DeepBind (Alipanahi et al. 2015)

DeepBind[1] 是由 Alipanahi 等人开发的一种机器学习工具，旨在利用基于深度学习的方法预测 DNA 和 RNA 结合蛋白的序列特异性。

作者指出了在现代高通量技术产生的大量序列数据上训练特异性序列模型时遇到的三个困难：(a) 数据以性质不同的形式出现，包括蛋白质结合微阵列、RNAcompetee测定、ChIP-seq和HT-SELEX，(b) 数据量非常大（典型实验测量一到十万条序列），以及(c) 每种数据获取技术都有自己的格式和错误特征，因此需要一种对这些不良效应具有鲁棒性的算法。

DeepBind 方法能够通过以下方式解决这些难题：(a) 在图形处理单元上的并行实现，(b) 容忍中等程度的噪声和误分类的训练数据，以及 (c) 以自动方式训练预测模型，同时避免手动调参的需要。以下图表展示了 Deep Bind 流程的各个方面。

为了解决过拟合问题，作者使用了多种正则化方法，包括dropout、权重衰减和早停。

Dropout: Prevention of Over-Fitting

Dropout[5]是一种在大型网络背景下解决训练数据过拟合问题的技术。由于链式法则计算过程中梯度的乘法效应，隐藏单元权重会协同适应，这可能导致过拟合。避免隐藏单元权重协同适应的一种方法是简单地（随机）丢弃单元。丢弃单元的一个有益结果是，更大的神经网络在训练时计算强度更高。

然而，这种方法在训练方面需要稍长的时间。此外，调整步长有点挑战性。作者提供了一个附录，在其中（A部分）给出了一个有用的“dropout网络训练实用指南”。他们指出，dropout参数p (的典型值，这

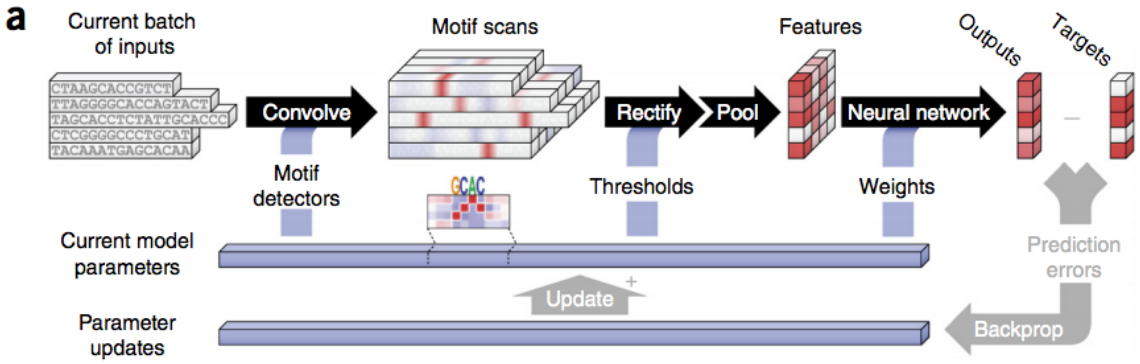

图 20.17：DeepBind 流程的流程图（取自 DeepBind 论文）。模型并行处理五条序列。模型对序列进行卷积（我们可以将 DeepBind 模型视为一个扫描序列的过滤器），整流并池化它们，以生成特征向量，然后通过深度神经网络传递。深度网络的输出与期望输出进行比较，误差通过管道反向传播。

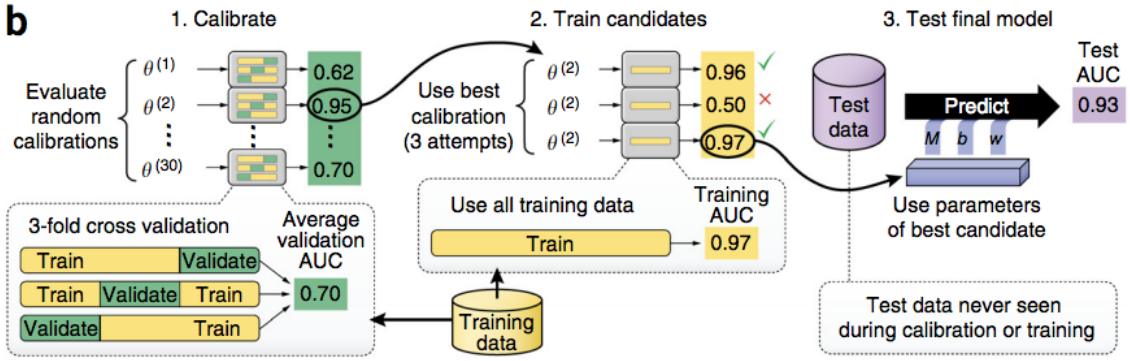

图20.18：DeepBind方法所用的校准、训练和测试过程的示意图（取自DeepBind论文）。

由Macmillan Publishers Limited提供。经许可使用。来源：Alipanahi, Babak, Andrew Delong, 等。“通过深度学习预测DNA和RNA结合蛋白的序列特异性。” *Nature Biotechnology* (2015)。

决定节点被丢弃概率的参数在隐藏层介于0.5到0.8之间，在输入层为0.8。

20.8 Open Issues and Challenges

关于之前涵盖主题的一些挑战是

- **Validation** 我们怎么知道网络结构是否正确?
- 我们如何知道网络函数是否正确?
- 测量和建模蛋白质表达
- 理解调控网络的演化
- 大多数情况下，计算联合分布是棘手的，因此我们专注于边缘分布。

Figures of neural nets before and after dropout removed due to copyright restrictions.
Source: Srivastava, Nitish et al. "Dropout: A simple way to prevent neural networks from overfitting." The Journal of Machine Learning Research 15, no. 1 (2014): 1929-1958.

图20.19：一张插图（摘自Srivastava等人的论文），展示了应用dropout过程后生成的稀疏网络。被划掉的单元已被丢弃。

- 通常我们有大量的调节器或目标，使得一些问题需要简化假设才能使其变得可处理。

20.9 Current Research Directions

20.10 Further Reading

要了解本章讨论的主题的更多信息，您可以查找以下关键词。

- 概率图模型
- 网络补全
- 非负矩阵分解
- 网络对齐
- 网络集成

Figures of neural nets before and after dropout removed due to copyright restrictions.
Source: Srivastava, Nitish et al. "Dropout: A simple way to prevent neural networks from overfitting." The Journal of Machine Learning Research 15, no. 1 (2014): 1929-1958.

图20.20：一幅取自Srivastava等人论文的图表，展示了应用dropout程序后，分类错误率显著下降。

20.11 Tools and Techniques

20.12 What Have We Learned?

- 网络有多种类型，可以用概率和代数视角表示
- 不同的中心性度量从不同方面衡量节点/边的重要性
- PCA和SVD通过执行矩阵分解，对于揭示网络中的结构模式非常有用。
- 稀疏PCA通过选择数据中少数最具代表性的变量，改进了PCA，并更准确地恢复社区结构。
- 网络社区有多种定义，每种定义都有针对社区检测设计的特定算法
- 神经网络和深度学习网络是捕捉数据中复杂模式的监督学习机器。

Bibliography

[1] B. Alipanahi, A. Delong, M.T. Weirauch, 和 B.J. Frey. 通过深度学习预测DNA和RNA结合蛋白的序列特异性. *Nature Biotechnology*, 33:831–838, 2015. [2] M. Girvan 和 M.E.J. Newman. 社会和生物网络中的社区结构. *Proceedings of the National Academy of Sciences*, 99(12):7821–7826, 2002. [3] O. Hein, M. Schwind, 和 W. Kö nig. 无标度网络：胖尾度分布对扩散和通信过程的影响. *Wirtschaftsinformatik*, 48(4):267–275, 2006.

[4] T.I. Lee, N.J. Rinaldi, F. Robert, D.T. Odom, Z. Bar-Joseph, G.K. Gerber, N.M. Hannett, C.T. Harbison, C.M. Thompson, I. Simon, 等. 酿酒酵母中的转录调控网络. *Science Signalling*, 298(5594):799, 2002. [5] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, 和 R. Salakhutdinov. Dropout：一种防止神经网络过拟合的简单方法. *Journal of Machine Learning Research*, 15:1929–1958, 2014. [6] S.M. van Dongen. *Graph clustering by flow simulation*. 博士论文, 乌得勒支大学, 荷兰, 2000. [7] U. Von Luxburg. 谱聚类教程. *Statistics and computing*, 17(4):395–416, 2007. [8] 维基百科. 图划分. `http://en.wikipedia.org/wiki/Graph_partitioning`, 2012. [9] 维基百科. 最小割. `http://en.wikipedia.org/wiki/Minimum_cut`, 2012.

CHAPTER

TWENTYONE

调控网络：推断、分析、应用

Sushmita Roy 的客座讲座 (2010) / Soheil Feizi (2012) 由 Ben Holmes (2010) / Hamza Fawzi 和 Sara Brockmueller (2012) 记录

Figures

21.3 实心符号表示$S.cerevisiae$ (基因调控网络中基因的入度分布，一个基因的入度是结合到该基因启动子上的转录因子数量)。空心符号表示可比较的随机网络中的入度分布。图取自[4]。 . . . . . 336 21.4 无标度与随机Erdős-Renyi网络 . . . . . 337 21.5 调控网络中的网络模体：参与加速靶基因响应的前馈环。调控因子用蓝色圆圈表示，基因启动子用红色矩形表示（图取自[4]） . . . . . 338 21.6 . . . . . 339 21.7 一个具有8个节点的网络。 342

21.1 Introduction

生命系统由多层构成，这些层次编码了关于系统的信息。主要的层次包括：

1. 表观基因组：由染色质构型定义。染色质的结构基于组蛋白组织DNA的方式。DNA被分为核小体和核小体自由区域，形成其最终形态并影响基因表达。[1]

[1] More in the epigenetics lecture.

2. 基因组：包括编码DNA和非编码DNA。由编码DNA定义的基因用于构建RNA，而顺式调控元件调节这些基因的表达。

3. 转录组RNA（例如mRNA、miRNA、ncRNA、piRNA）由DNA转录而来。它们具有调控功能并制造蛋白质。

4. 蛋白质组 由蛋白质组成。这包括转录因子、信号蛋白和代谢酶。

这些组件之间的相互作用各不相同，但理解它们可以将系统的特定部分置于整体的背景中。为了发现层内和层间的关系和相互作用，我们可以使用网络。

21.1.1 Introducing Biological Networks

生物网络由以下部分构成:

Regulatory Net – 生物体中的调控相互作用集　　机制。

- 节点是调节因子（例如转录因子）及相关靶标。
- 边对应于调控相互作用，从调控因子指向其靶标。它们根据正效应或负效应赋予符号，并根据反应强度赋予权重。

Metabolic Net – 连接代谢过程。在表示上有一定的灵活性，一个例子是展示酶之间共享代谢产物的图。

- 节点是酶。
- 边对应调控反应，并根据反应强度赋予权重。

Signaling Net – 代表生物信号的路径。

- 节点是称为信号受体的蛋白质。
- 边缘是传递和接收的生物信号，从发送者指向接收者。

Protein Net – 显示蛋白质之间的物理相互作用。

- 节点是单个蛋白质。
- 边是蛋白质之间的物理相互作用。

Co-Expression Net – 描述基因之间的共表达功能。相当通用；与其他类型的网络不同，它代表的是功能而非物理交互网络。在生物数据的计算分析中是强大的工具。

- 节点是单个基因。
- 边是共表达关系。

今天，我们将专门聚焦于调控网络。调控网络控制着特定情境下的基因表达，因此对发育过程有着极大的控制力。它们值得研究，因为它们容易发生故障并导致疾病。

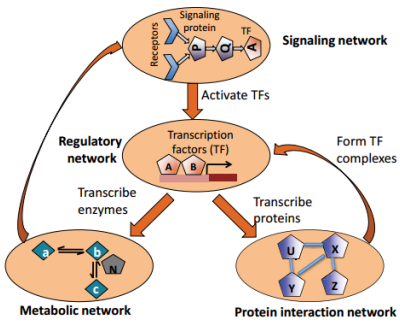

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

(a) 生物网络之间的相互作用。

21.1.2 Interactions Between Biological Networks

个体生物网络（即层）本身可以被视为代表整个生物系统的更大网络中的节点。例如，我们可以有一个感知环境的信号网络，控制转录因子的表达。在这个例子中，网络将显示转录因子控制蛋白质的表达，蛋白质可以作为代谢途径中的酶发挥作用，等等。

这些网络之间信息交换的一般路径如图21.4所示。

21.1.3 Studying Regulatory Networks

通常，网络用于表示变量之间的依赖关系。结构依赖可以通过节点之间是否存在边来表示——因此，未连接的节点是条件独立的。从概率上讲，边可以被赋予一个“权重”，表示相互作用的强度或可能性。网络也可以被视为矩阵，从而允许进行数学运算。这些框架为表示和研究生物系统提供了一种有效的方法。

这些网络特别值得研究，因为功能失常可能产生巨大影响。许多疾病是由调控网络的重连引起的。它们在发育过程中控制特定情境下的表达。因此，它们可用于系统生物学中预测发育、细胞状态、系统状态等。此外，它们还概括了遗传上相似的生物之间的大部分进化差异。

为了描述调控网络，有几个具有挑战性的问题需要回答。

Element Identification 网络的元素是什么？上一次讲座已经确定了构成调控网络的元素。这些包括上游基序及其相关的因子。

Network Structure Analysis 网络中的元素是如何连接的？给定一个网络，结构分析包括对重要属性的检查和表征。它可以用于生物网络，但并不局限于此。

Network Inference 调控因子如何相互作用并开启基因？这就是识别基因边和表征其作用的任务。

Network Applications 一旦我们拥有了网络，我们可以用它们做什么？应用包括预测调控基因的功能以及预测受调控基因的表达水平。

21.2 Structure Inference

21.2.1 Key Questions in Structure Inteference

How to choose network models? 存在多种用于表示网络的模型，关键问题在于根据数据和预测动态在这些模型之间做出选择。

How to choose learning methods? 学习网络存在两大类方法。无监督方法试图为未标记的数据点推断关系，并将在后续章节中描述。监督方法则取网络边的一个已知为调控关系的子集，学习一个分类器以预测新的边。[2]

How to incorporate data? 多种数据源可用于学习和构建网络，包括模体、ChIP结合实验和表达数据。数据源不断扩展；数据可用性的增加是当前生物网络分析革命的核心。

21.2.2 Abstract Mathematical Representations for Networks

将一个网络视为一个函数，一个黑箱。以调控网络为例，它们接收调控因子的输入表达式，并输出目标基因的表达结果。模型的不同之处在于选择函数的性质以及赋予节点和边意义的方式。

Boolean Network 该模型将节点表达水平和相互作用离散化。由边表示的函数为逻辑门。

Differential Equation Model 这些模型捕捉网络动态。表达率的变化是表达水平和调控因子变化率的函数。对于这些情况，参数估计可能非常困难。在哪里能找到非平衡系统的数据呢?

Probabilistic Graphical Model 这些系统将网络建模为随机变量上的联合概率分布。边表示条件依赖关系。本讲座重点关注概率图模型（PGMs）。

Probabilistic Graphical Models

概率图模型（PGMs）是可训练的，能够处理噪声，因此它们是处理生物数据的良好工具。[3] 在PGMs中，节点可以是转录因子或基因，并且它们由随机变量建模。如果你知道这些随机变量的联合分布，你就可以将网络构建为PGMs。由于这种图结构是网络的紧凑表示，我们可以轻松地使用它并完成学习任务。PGMs的例子包括:

Bayesian Network 有向图技术。每个节点要么是父节点，要么是子节点。父节点完全决定子节点的状态，但实验者可能无法获知父节点的状态。网络结构将网络的完整联合概率分布描述为各节点各自分布的乘积。通过将网络分解为局部势函数，计算复杂度大幅降低。

[2] Supervised methods will not be addressed today.
[3] These are Dr. Roys models of choice for dealing with biological nets.

Dynamic Bayesian Network 有向图技术。静态贝叶斯网络不允许循环依赖，但我们可以尝试用允许不同时间点节点之间任意依赖的贝叶斯网络来建模。因此，随着网络随时间推进，循环依赖是允许的，且网络联合概率本身可以描述为所有时间上的联合。

Markov Random Field 无向图技术。以团为单位建模势函数。允许对一般图进行建模，包括具有比成对依赖更高阶的循环图。

Factor Graph 无向图技术。因子图引入“因子”节点，指定沿边的交互势。因子节点也可以被引入以建模高于成对的势。

最容易学习贝叶斯模型的网络。马尔可夫随机场和因子图需要确定一个棘手的配分函数。为了编码网络结构，只需将随机变量分配给转录因子和基因，然后建模联合概率分布。

贝叶斯网络提供了JPD的紧凑表示

贝叶斯网络的主要优势在于其分解为父节点和子节点的简洁性。由于网络是有向的，完整的联合概率分布分解为条件分布的乘积，网络中每个节点对应一个条件分布。[4]

Network Inference from Expression Data

利用表达数据和先验知识，网络推断的目标是生成一个网络图。图可以是无向的或有向的。例如，调控网络通常是有向的，而表达网络通常是无向的。

21.3 Overview of the PGM Learning Task

我们必须从手头的数据中学习参数。一旦获得一组参数，便需运用参数化方法来学习结构。我们将重点放在基于评分的网络构建方法上，定义一个待优化的评分，作为网络构建的度量标准。

21.3.1 Parameter Learning for Bayesian Networks

Maximum Likelihood 选择参数以最大化给定模型下可用数据的似然。

在最大似然估计中，计算数据似然度时，将每个随机变量在给定其父节点条件下的得分作为依据，并注意到这些得分可以独立进行优化。根据模型的选择，得分 {v*}

[4]Bayesian networks are parametrized by θ according to our specific choice of network model. With different choices of random variables, we will have different options for parametrizations,θ and therefore different learning tasks:

Discrete Random variables suggest simple θ corresponding to parameter choices for a multinomial distribution.

Continuous Random variables may be modelled with θ corresponding to means and covariances of gaussians or other continuous distribution.

将以不同的方式最大化。对于高斯分布，可以简单地计算优化分数的参数。对于更复杂的模型选择，可能需要进行梯度下降。

Bayesian Parameter Estimation 将θ本身视为一个随机变量，并选择使后验概率最大化的参数。这些方法要求固定的结构，并寻求选择使得分最大化的内部参数。

Structure Learning

我们可以计算结构化网络的最佳猜测参数化。我们如何找到结构本身?

结构学习通过比较不同图结构下ML参数化的似然度来进行，以寻求那些实现ML评分最优的结构。

如果有一些先验理由相信某些图结构比其他结构更有可能，贝叶斯框架可以纳入关于图结构的先验概率。

为了在结构学习中进行搜索，我们不可避免地需要采用贪婪方法，因为结构空间太大，无法枚举。这类方法将通过类似于梯度下降优化的增量搜索来进行，以找到最大似然参数化。

考虑并根据ML分数评估一组图。由于可能存在局部最优解，从多个起始点进行图搜索是好的做法。

除了上述无法捕捉循环依赖之外，贝叶斯网络还有其他一些局限性。

Indirect Links 由于贝叶斯网络仅关注节点间的统计依赖性，它们很容易被误导，在实际上仅存在间接关系的地方添加边。

Neglected Interactions 特别是当结构分数局部优化时，可能会完全错过重要的生物相互作用。共表达的基因可能不共享适当的调控因子。

Slow Speed 贝叶斯　到目前为止讨论的方法太慢，无法有效运作　　全基因组数据。

Excluding Indirect Links

How to eliminate indirect links? 信息论方法可以通过修剪网络结构以去除冗余信息来移除无关链接。描述了两种方法。

ARACNE 对于每个三元组边，计算互信息分数，并且ARACNE算法根据某些阈值排除信息量最少的边，超过这些阈值则保留最小边。

MRNET 最大化调节因子与靶标之间的依赖性，同时通过去除对应于低方差调节因子的边来最小化调节因子间共享的冗余信息量。

另一种方法是，只需查看调控基序，并消除那些未被常见基序预测到的调控边。

21.3.2 Learning Regulatory Programs for Modules

How to fix omissions for coregulated genes? 通过学习调控模型的参数而非单个基因的参数，可以利用共表达基因倾向于受到相似调控的特点。类似于使用调控基序来修剪冗余边的方法，通过同时建模模块，我们减少了网络边的数量，同时增加了可利用的数据量。

通过扩展，还可以对循环依赖关系进行建模。模块网络允许聚类重访，其中基因根据它们被某个模块的调控程序预测的准确程度，被重新分配到各个聚类中。

然而，模块无法容纳共享模块归属的基因。分而治之以加速学习

How to speed up learning? Roy 博士开发了一种方法，利用分治技术针对无向图将大型学习问题分解为较小的任务。通过从聚类开始，可以推断各个聚类的调控网络，然后交叉边、重新分配基因并进行迭代。

21.3.3 Conclusions in Network Inference

调控网络很重要，但通常很难构建。通过利用模块化，往往能够为图及其子图找到可靠的结构。[5]

许多扩展在调控网络方面即将出现。这些包括从表达相关性推断因果边、学习如何在簇之间共享基因，以及其他方面。

21.4 Applications of Networks

使用线性回归和回归树，我们将尝试从网络中预测表达。使用集体分类和松弛标记，我们将尝试为未知网络元素分配功能。

我们希望使用网络来：

1. 从调控因子预测基因的表达。
   在表达预测中，目标是将调控因子表达水平与基因表达水平之间的关系参数化。这可以通过多种方式解决，包括回归方法，并且与寻找功能网络的问题相关。

2. 预测未知基因的功能。

21.4.1 Overview of Functional Models

一种预测模型是条件高斯模型：通过线性回归训练的简单模型。更复杂的预测模型是通过非线性回归训练的回归树。

[5] Dr. Roy notes that many algorithms are available for running module network inference with various distributions. Neural net pacakges and Bayesian packages among others are available.

Conditional Gaussian Models

条件高斯模型在连续空间上进行预测，并通过简单线性回归训练以最大化数据的似然。它们预测的目标，其表达水平为调控因子上高斯的均值。

条件高斯学习采用具有靶标和调节转录因子的结构化有向网络。你可以通过寻找使似然最大化的参数来从数据中估计高斯参数 μ、σ——求导后，最大似然方法简化为求解一个线性方程。

从多个数据源[6]导出的功能调控网络中，Roy博士利用时间序列表达数据训练了一个高斯预测模型，并在保留的测试集上进行了验证。与基于随机网络训练得到的模型预测结果相比，发现该网络的预测性能显著优于随机预测。

所使用的线性模型对交互的线性关系做出了强有力的假设。这很可能不是一个非常准确的假设，但在测试的数据集上，它似乎在一定程度上是有效的。

Regression Tree Models

回归树模型允许建模者使用一种多模态分布，其中包含调节基因与靶基因表达之间的非线性依赖关系。回归树的最终结构通过回归树节点上做出的一系列选择来描述表达语法。由于靶标可以共享调控程序，因此可以纳入重复基序的概念。回归树是丰富的模型，但学习起来较为棘手。回归树在预测表达方面的应用

在实践中，预测依据调控因子表达水平沿回归树下移。到达回归树的叶节点时，会进行基因表达的预测。

21.4.2 Functional Prediction for Unannotated Nodes

给定一个标签集不完整的网络，功能注释的目标是预测未知基因的标签。我们将使用属于关联定罪这一广泛类别的方法。如果我们对一个节点一无所知，只知道它的邻居参与了某个功能，就将该功能分配给这个未知节点。

关联可以包括上文讨论的任何网络相关性概念，如共表达、蛋白质-蛋白质相互作用和共调控。许多方法可行，这里将讨论两种：集体分类和松弛分类；这两种方法都适用于编码为无向图的调控网络。

Collective Classification

将功能预测视为一个分类问题：给定一个节点，它的调控类别是什么？

[6]data sources included chromatin, physical binding, expression, m奥蒂夫

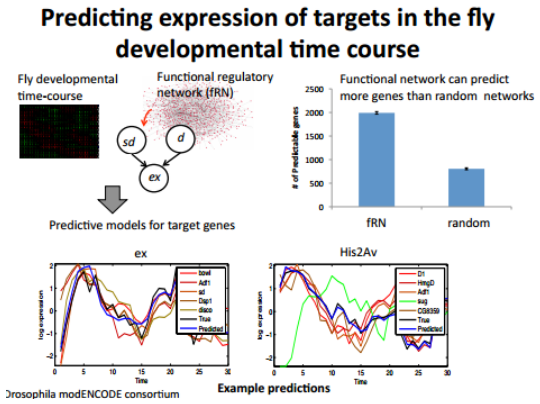

(a) Fly development.

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

为了在预测问题中利用图结构，我们在关系属性中捕获基因邻域的特性。由于所有点在网络中都是相连的，数据点不再是独立分布的——预测问题变得比标准分类问题困难得多。

迭代分类是解决分类问题的一种简单方法。它从对未标记基因的初始猜测开始，迭代地推断标签，允许更改的标签以类似于吉布斯采样的方式影响节点标签预测[7]

松弛标记法是另一种最初为追踪恐怖网络而开发的方法。该模型使用可疑度评分，其中节点根据其邻居的可疑程度被标记为相应的可疑性。该方法之所以被称为松弛标记法，是因为它根据学习参数逐渐收敛到一个解。它是迭代学习的另一个实例，其中基因被赋予具有给定功能的概率。

Regulatory Networks for Function Prediction

对于节点对，计算调控相似度——即交互量——等于其调控因子的交集大小除以其并集大小。将此交互相似度以网络目标上的无向图形式表示后，可在最终功能分类中使用从网络中导出的聚类。

该模型成功预测了内陷盘和神经系统的发育。图21.2a中的蓝线显示了每个基因预测其参与神经系统发育的得分。

共表达和共调控可以并用来扩充已知参与神经系统发育的基因集。

[7]see the previous lecture by Manolis describing motif discovery

21.5 Structural Properties of Networks

关于网络的早期研究大多是由生物学之外的科学家完成的。物理学家研究了互联网和社交网络，并描述了它们的性质。生物学家观察到，这些相同的性质也存在于生物网络中，于是生物网络这一领域便诞生了。在本节中，我们将讨论不同的生物网络以及在其他学科中出现的网络所共有的一些结构性质。

21.5.1 Degree distribution

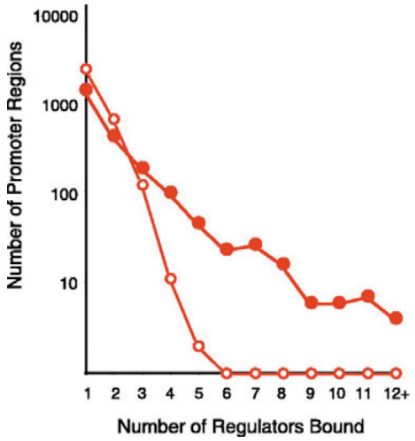

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图21.3：实心符号表示*S.cerevisiae* (基因的入度是结合到该基因启动子上的转录因子数量)，在调控网络中基因的入度分布。空心符号表示可比较的随机网络中的入度分布。图取自[4]。

在网络中，一个节点的*degree*是它拥有的邻居数量，即通过一条边与之相连的节点数。网络的*degree distribution*给出了对于每个可能的值$d = 1, 2, 3, \ldots$，度数为d的节点数量。例如，图21.3给出了*S. cerevisiae*基因调控网络的度分布。据观察，生物网络的度分布遵循幂律，即网络中具有度数d的节点数大约为$cd^{-\gamma}$，其中c是归一化常数，γ是正系数。在这样的网络中，大多数节点只有少量连接，少数节点则具有非常高的连通性。

这种幂律度分布的特性实际上在许多不同学科的不同网络中被观察到（例如社交网络、万维网等），并表明这些网络并非“随机”的：事实上，随机网络（由Erd{v*}os-Renyi模型构建）的度分布遵循泊松分布，其中几乎所有节点具有大致相同的度，而度较高或较低的节点非常罕见[6]（见图21.4）。

遵循幂律度分布的 network 被称为 **scale-free networks**。无标度网络中少数具有非常大度的节点被称为*hubs*，并且具有非常重要的解释。例如，在基因调控网络中，hubs 代表调控大量基因的 transcription factors 。无标度网络具有对“随机”节点故障高度 resilient 的特性，然而它们对协调性故障非常 vulnerable（即，如果其中一个 hub 节点故障，则网络会失败，更多信息见 [1]）。

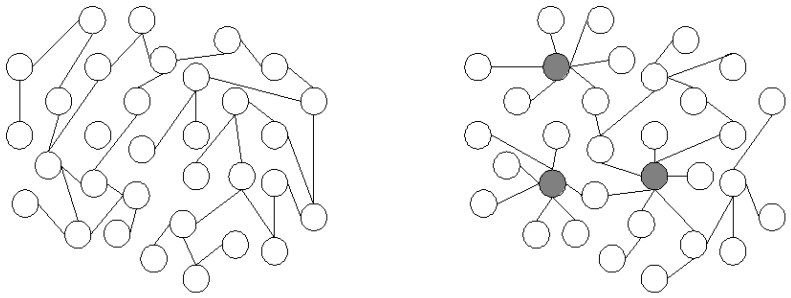

(a) Random network (b) Scale-free network

© Carlos Castillo。保留部分权利。许可证：CC BY-SA。本内容不在我们的知识共享许可范围内。有关更多信息，请参见http://ocw.mit.edu/help/faq-fair-use/。

(a) 无标度图与随机图的对比（图取自[10]）。

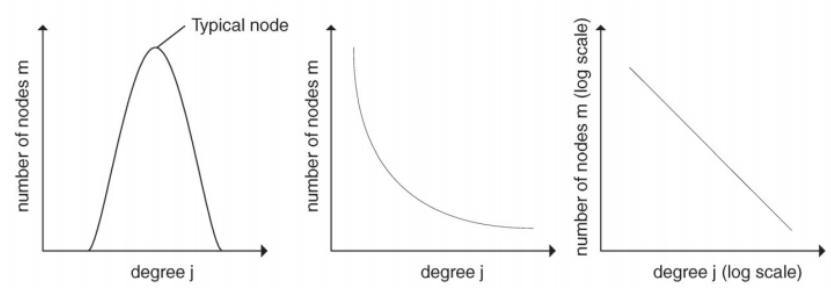

(b) 无标度网络与随机网络的度分布对比（图取自[3]）。© Vieweg Verlag。版权所有。此内容不包含在我们的知识共享许可协议中。更多信息，请参见 http://ocw.mit.edu/help/faq-fair-use/。 来源：Hein, Oliver, 等。“无标度网络。”*Wirtschaftsinformatik* 48, 第4期 (2006): 267-75。

图21.4：无标度网络与随机Erdős-Renyi网络的比较

在调控网络中，可以识别出四个层级的节点:

1. 有影响力的主调控节点位于顶部。这些是各自间接控制许多目标的枢纽。2. 瓶颈调控因子。中间的节点很重要，因为它们拥有最大数量的直接目标。3. 底部的调控因子往往具有较少的目标，但它们在生物学上常常是必需的！4. 目标。

21.5.2 Network motifs

网络模体是网络中显著多于随机出现的子图。有些将具有有趣的功能特性，并且推测具有生物学意义。

图21.5显示了酵母调控网络中的调控基序。反馈环允许控制调节因子的水平，前馈环则允许加速响应时间等。

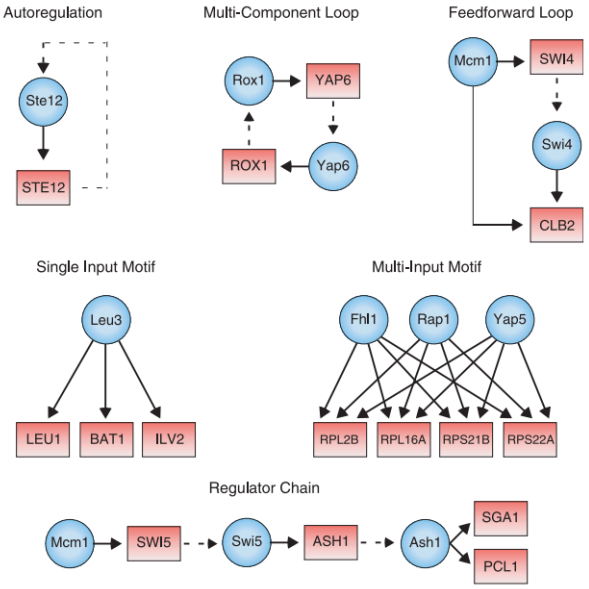

© American Association for the Advancement of Science. All rights reserved. This content被排除 from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.
Source: Lee, Tong Ihn et al. "Transcriptional Regulatory Networks in Saccharomyces Ce "revisiae。 *Science* 298，第5594期（2002年）：799-804。

图21.5：调控网络中的网络模体：前馈环参与加速目标基因的响应。调控因子用蓝色圆圈表示，基因启动子用红色矩形表示（图取自[4]）

21.6 Network clustering

网络分析中的一个重要问题是能够**cluster**或**modularize**网络，以识别密集连接的子图（例如，参见图21.6 a）。在基因相互作用网络的背景下，这些聚类可能对应于参与相似功能且被共同调控的基因。

有几种已知算法可实现此任务，这些算法通常被称为 *graph partitioning algorithms*，因为它们将图划分为独立的模块。一些著名的算法包括：

- 马尔可夫聚类算法[5]：马尔可夫聚类算法(MCL)通过在图中进行随机游走并观察此游走的稳态分布来工作。这种稳态分布使得能够将图聚类成密集连接的子图。
- Girvan-Newman算法[2]：Girvan-Newman算法利用经过节点的最短路径数量来计算边的*essentiality*，进而可用于对网络进行聚类。
- 谱划分算法

在本节中，我们将详细探讨谱分区算法。关于其他算法的描述，请读者参阅文献[2, 5]。

谱划分算法依赖于使用矩阵表示网络的一种特定方式。在介绍该算法之前，我们将回顾如何使用矩阵表示网络，以及如何通过矩阵运算提取网络信息。

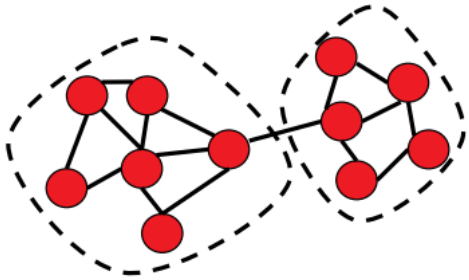

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

(a) A partition of a network into two groups.

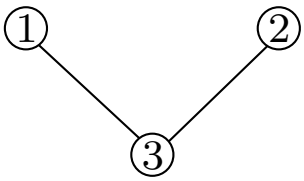

(b) A simple network on 3 nodes. The adjacency matrix of this graph is given in equation (21.1) .

图21.6

21.6.1 An algebraic view to networks

Adjacency matrix 表示网络的一种方式是使用所谓的*adjacency matrix*。具有n个节点的网络的邻接矩阵是一个$n \times n$矩阵A，其中如果节点i和j之间存在边，则$A_{i,j}$等于1，否则为0。例如，图21.6b中所表示的图的邻接矩阵为：

$$A = \begin{bmatrix} 0 & 0 & 1 \\ 0 & 0 & 1 \\ 1 & 1 & 0 \end{bmatrix} \tag{21.1}$$

如果网络是加权的（即，如果网络的边 每个元素都有一个相关的权重），邻接矩阵的定义被修改为：如果边存在，$A_{i,j}$保存i和j之间边的权重，否则为零。

Laplacian matrix 对于本节稍后将介绍的聚类算法，我们需要计算网络划分中两个不同组之间的边数。例如，在图21.6a中，两组之间的边数为1。我们现在将要引入的*Laplacian matrix*正好可以用来代数地表示这个量。一个包含n个节点的网络的拉普拉斯矩阵L是一个$n \times n$矩阵L，它与邻接矩阵A非常相似，只是在符号和对角元素上有所不同。邻接矩阵的对角元素始终为零（因为我们没有自环），而拉普拉斯矩阵的对角元素则持有每个节点的*degree*（其中节点的度定义为其入射边的数量）。此外，拉普拉斯矩阵的非对角元素在存在边时设为-1，否则为零。换句话说，我们有：

$$L_{i,j} = \begin{cases} \text{degree}(i) & \text{if } i = j \\ -1 & \text{if } i \neq j \text{ and there is an edge between } i \text{ and } j \\ 0 & \text{if } i \neq j \text{ and there is no edge between } i \text{ and } j \end{cases} \tag{21.2}$$

例如，图21.6b的图的拉普拉斯矩阵为（我们用粗体强调了对角线元素）：

$$L = \begin{bmatrix} \mathbf{1} & 0 & -1 \\ 0 & \mathbf{1} & -1 \\ -1 & -1 & \mathbf{2} \end{bmatrix}$$

Some properties of the Laplacian matrix 任何网络的拉普拉斯矩阵都具有一些良好的性质，这些性质在我们后面研究聚类算法时将变得很重要。我们在此简要回顾这些性质。

拉普拉斯矩阵 L 总是 **symmetric**，即对于任意 i, j，有 $L_{i,j} = L_{j,i}$。这一观察的一个重要推论是 L 的所有特征值都是实数（即它们没有复虚部）。事实上，甚至可以证明 L 的特征值都是非负的[8]。我们提到的关于 L 的最后一个性质是 L 的所有行和列之和均为零（使用 L 的定义很容易验证这一点）。这意味着 L 的最小特征值始终等于零，并且相应的特征向量为 $s = (1, 1, \ldots, 1)$。

Counting the number of edges between groups using the Laplacian matrix 使用拉普拉斯矩阵，我们现在可以通过简单的矩阵运算轻松计算将图的两个不相交部分分开的边数。实际上，假设我们将图分成两组，并定义一个大小为 n 的向量 s，它告诉我们哪个组每个节点 i 属于：

$$s_i = \begin{cases} 1 & \text{if node } i \text{ is in group 1} \\ -1 & \text{if node } i \text{ is in group 2} \end{cases}$$

然后可以很容易地证明，组1和组2之间的总边数由量[1] $s^T L s$给出，其中L是网络的拉普拉斯矩阵。[4]

为了了解为什么会这样，让我们首先计算矩阵-向量乘积Ls。特别地，让我们固定一个节点i，比如在第一组（即，$s_i = +1$），并让我们查看矩阵-向量乘积Ls的第i个分量。根据矩阵-向量乘积的定义，我们有：

$$(Ls)_i = \sum_{j=1}^{n} L_{i,j} s_j.$$

我们可以将这个和分解为三个加数，如下所示：

$$(Ls)_i = \sum_{j=1}^{n} L_{i,j} s_j = L_{i,i} s_i + \sum_{j \text{ in group 1}} L_{i,j} s_j + \sum_{j \text{ in group 2}} L_{i,j} s_j$$

利用拉普拉斯矩阵的定义，我们很容易看出第一项对应于i的度，即与i相连的边数；第二项等于连接i与组1中其他节点的边数的负值，第三项等于连接i与组2中某节点的边数。因此我们得到：

$$(Ls)_i = \text{degree}(i) - (\#\text{ edges from } i \text{ to group 1}) + (\#\text{ edges from } i \text{ to group 2})$$

由于来自 i 的任何边必须要么指向组1，要么指向组2，我们有

$$\text{degree}(i) = (\#\text{ edges from } i \text{ to group 1}) + (\#\text{ edges from } i \text{ to group 2}).$$

因此，结合上述两个方程，我们得到：

$$(Ls)_i = 2 \times (\#\text{ edges from } i \text{ to group 2}).$$

现在，要得到组1和组2之间的边总数，我们只需将上述数量对组1中的所有节点i求和：

$$(\#\text{ edges between group 1 and group 2}) = \frac{1}{2} \sum_{i \text{ in group 1}} (Ls)_i$$

[8] One way of seeing this is to notice that L is diagonally dominant and the diagonal elements are strictly positive (for more details the reader can look up "diagonally dominant" and "Gershgorin circle theorem" on the Internet).

我们也可以查看组2中的节点来计算相同的量，我们得到：

$$(\#\text{ edges between group 1 and group 2}) = -\frac{1}{2}\sum_{i \text{ in group 2}} (Ls)_i$$

现在对上面两个方程取平均，我们得到所需结果：

$$\begin{aligned}(\#\text{ edges between group 1 and group 2}) &= \frac{1}{4}\sum_{i \text{ in group 1}} (Ls)_i - \frac{1}{4}\sum_{i \text{ in group 2}} (Ls)_i \\ &= \frac{1}{4}\sum_i s_i (Ls)_i \\ &= \frac{1}{4} s^T L s\end{aligned}$$

其中 s^T 是通过转置列向量 s 得到的行向量。

21.6.2 The spectral clustering algorithm

我们现在来看如何利用上一节给出的网络的线性代数视角，来产生图的“良好”划分。在图的任何良好划分中，两组之间的边数必须相对于每组内部的边数来说相对较小。因此，处理该问题的一种方法是寻找一种划分，使得两组之间的边数最小。使用上一节引入的工具，这个问题因此等价于寻找一个仅取值为 -1 或 $+1$ 的向量 $s \in \{-1, +1\}^n$，使得 $\frac{1}{4} s^T L s$ 最小，其中 L 是图的拉普拉斯矩阵。换句话说，我们想求解最小化问题：

$$\underset{s \in \{-1,+1\}^n}{\text{minimize}} \quad \frac{1}{4} s^T L s$$

如果 s^* 是最优解，则最优划分是将节点 i 分配给组 1，如果 $s_i = +1$，否则分配给组 2。

这个公式看似合理，但遗憾的是有个小问题：这个问题的解总是会以$s = (+1, \ldots, +1)$结束，这相当于将网络中的所有节点都放在组1中，而没有节点放在组2中！组1和组2之间的边数因此简单地为零，确实是最小的！

为了获得有意义的分区，我们必须考虑图的非平凡分区。回想一下，拉普拉斯矩阵 L 总是对称的，因此它允许特征分解：

$$L = U \Sigma U^T = \sum_{i=1}^n \lambda_i u_i u_i^T$$

其中 Σ 是一个对角矩阵，包含 L 的非负特征值 $\lambda_1, \ldots, \lambda_n$，而 U 是特征向量矩阵，并满足 $U^T = U^{-1}$。

划分$s \in \{-1, +1\}^n$的成本由下式给出：

$$\frac{1}{4} s^T L s = \frac{1}{4} s^T U \Sigma U^T s = \frac{1}{4} \sum_{i=1}^n \lambda_i \alpha_i^2$$

其中 $\alpha = U^T{}_n\, s$ 给出了 s 作为 L 的特征向量的线性组合的分解：$s = \sum_{i=1} \alpha_i u_i$。

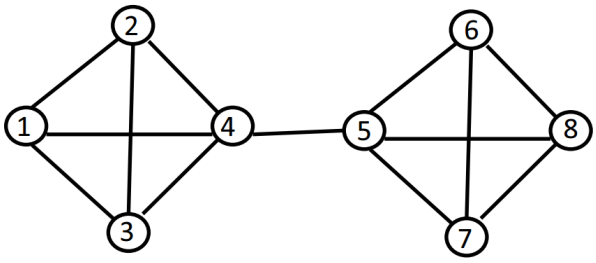

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 htt
p://ocw.mit.edu/help/faq-fair-use/。

图21.7：一个包含8个节点的网络。

回忆一下，$0 = \lambda_1 \leq \lambda_2 \leq \cdots \leq \lambda_n$。因此，使上述量尽可能小（不选取平凡划分）的一种方法是将所有权重集中在λ_2上，这是L的最小非零特征值。为了实现这一点，我们只需选择s，使得对于所有$k \neq 2$，$\alpha_2 = 1$且$\alpha_k = 0$。换句话说，这相当于取s等于u_2，即L的第二个特征向量。由于一般情况下特征向量u_2不是整数值（即u_2的分量可以不同于-1或$+1$），我们必须首先将向量u_2转换为由$+1$或-1组成的向量。一种简单的方法是直接查看u_2的分量的符号，而不是值本身。因此，我们的划分由下式给出：

$$s = \text{sign}(u_2) = \begin{cases} 1 & \text{if } (u_2)_i \geq 0 \\ -1 & \text{if } (u_2)_i < 0 \end{cases}$$

简而言之，谱聚类算法的工作流程如下：

Spectral partitioning algorithm

- 输入：一个网络
- 输出：网络的一种划分，其中每个节点被分配到组1或组2，使得两组之间的边数较少

1. 计算由下式给出的图的拉普拉斯矩阵 L：

$$L_{i,j} = \begin{cases} \text{degree}(i) & \text{if } i = j \\ -1 & \text{if } i \neq j \text{ and there is an edge between } i \text{ and } j \\ 0 & \text{if } i \neq j \text{ and there is no edge between } i \text{ and } j \end{cases}$$

2. 计算L的次小特征值对应的特征向量u_2。

3. 输出以下划分：如果 $(u_2)_i \geq 0$，则将节点 i 分配给组 1，否则将节点 i 分配给组 2。

接下来，我们给出一个将谱聚类算法应用于具有8个节点的网络的例子。

Example 我们在此以图21.7所示的一个包含8个节点的简单网络为例，说明上述分区算法。该图的邻接矩阵和拉普拉斯矩阵如下所示：

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 1 & 1 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 1 & 0 & 0 & 0 & 0 \\ 1 & 1 & 1 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 1 & 1 & 1 \\ 0 & 0 & 0 & 0 & 1 & 0 & 1 & 1 \\ 0 & 0 & 0 & 0 & 1 & 1 & 0 & 1 \\ 0 & 0 & 0 & 0 & 1 & 1 & 1 & 0 \end{bmatrix} \qquad L = \begin{bmatrix} 3 & -1 & -1 & -1 & 0 & 0 & 0 & 0 \\ -1 & 3 & -1 & -1 & 0 & 0 & 0 & 0 \\ -1 & -1 & 3 & -1 & 0 & 0 & 0 & 0 \\ -1 & -1 & -1 & 4 & -1 & 0 & 0 & 0 \\ 0 & 0 & 0 & -1 & 4 & -1 & -1 & -1 \\ 0 & 0 & 0 & 0 & -1 & 3 & -1 & -1 \\ 0 & 0 & 0 & 0 & -1 & -1 & 3 & -1 \\ 0 & 0 & 0 & 0 & -1 & -1 & -1 & 3 \end{bmatrix}$$

使用Matlab的`eig`命令，我们可以计算拉普拉斯矩阵的特征分解$L = U\Sigma U^T$，得到：

$$U = \begin{bmatrix} 0.3536 & \mathbf{-0.3825} & 0.2714 & -0.1628 & -0.7783 & 0.0495 & -0.0064 & -0.1426 \\ 0.3536 & \mathbf{-0.3825} & 0.5580 & -0.1628 & 0.6066 & 0.0495 & -0.0064 & -0.1426 \\ 0.3536 & \mathbf{-0.3825} & -0.4495 & 0.6251 & 0.0930 & 0.0495 & -0.3231 & -0.1426 \\ 0.3536 & \mathbf{-0.2470} & -0.3799 & -0.2995 & 0.0786 & -0.1485 & 0.3358 & 0.6626 \\ 0.3536 & \mathbf{0.2470} & -0.3799 & -0.2995 & 0.0786 & -0.1485 & 0.3358 & -0.6626 \\ 0.3536 & \mathbf{0.3825} & 0.3514 & 0.5572 & -0.0727 & -0.3466 & 0.3860 & 0.1426 \\ 0.3536 & \mathbf{0.3825} & 0.0284 & -0.2577 & -0.0059 & -0.3466 & -0.7218 & 0.1426 \\ 0.3536 & \mathbf{0.3825} & 0.0000 & 0.0000 & 0.0000 & 0.8416 & -0.0000 & 0.1426 \end{bmatrix}$$

$$\Sigma = \begin{bmatrix} 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & \mathbf{0.3542} & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 4.0000 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 4.0000 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 4.0000 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 4.0000 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 4.0000 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 5.6458 \end{bmatrix}$$

我们以粗体标出了 L 的第二小特征值及其对应的特征向量。为了对网络进行聚类，我们观察该特征向量的分量符号。我们看到前4个分量为负，后4个分量为正。因此，我们将节点1至4聚为一组，节点5至8聚为另一组。这看起来是一个很好的聚类，实际上，这是人们初见该图时所考虑的“自然”聚类。

Did You Know?

我们为谱聚类算法构建动机时提出的数学问题，是寻找将图划分为两组且两组之间边数最少的一种划分。我们提出的谱划分算法并不总是能给出该问题的最优解，但在实践中通常效果良好。

实际上，我们最初形式化的问题可以通过一种高效算法精确求解。这个问题有时被称为 **minimum cut** 问题，因为我们的目标是从图中切除最少数量的边，使其不连通（我们切除的边是第1组与第2组之间的边）。最小割问题在一般情况下可以在多项式时间内解决，更多信息请参阅维基百科关于 *minimum cut* [9] 的条目。然而，最小割划分的问题在于，它们通常导致图的划分并不均衡（例如，一个组仅含1个节点，而其余所有节点均在另一组）。一般来说，人们希望对聚类施加额外约束（例如，对聚类大小的上下界等），以获得更现实的聚类。在这些约束下，问题变得更加困难，更多详情请参阅维基百科关于 *Graphpartitioning* [8] 的条目。

FAQ

Q: 如何将图划分成多于两组?

A: 在本节中，我们仅探讨了将图划分为两个聚类的问题。如果我们希望将图聚类成超过两个的聚类呢？针对此，存在多种可能的算法扩展，以处理k个聚类而非仅两个。其核心思想是考察拉普拉斯矩阵中k个最小非零特征值对应的k个特征向量，然后适当地应用k-均值聚类算法。更多信息，请参阅教程[7]。

Bibliography

[1] R. Albert. 细胞生物学中的无标度网络. *Journal of cell science*, 118(21):4947–4957, 2005.

[2] M. Girvan 和 M.E.J. Newman. 社交与生物网络中的社区结构. *Proceedings of the National Academy of Sciences*, 99(12):7821–7826, 2002.

[3] O. Hein, M. Schwind, 和 W. König. 无标度网络：胖尾度分布对扩散和通信过程的影响. *Wirtschaftsinformatik*, 48(4):267–275, 2006.

[4] T.I. Lee, N.J. Rinaldi, F. Robert, D.T. Odom, Z. Bar-Joseph, G.K. Gerber, N.M. Hannett, C.T. Harbi- son, C.M. Thompson, I. Simon, et al. 酿酒酵母中的转录调控网络. *Science Signalling*, 298(5594):799, 2002.

[5] S.M. van Dongen. *Graph clustering by flow simulation*. 荷兰乌得勒支大学博士论文，2000年。

[6] M. Vidal, M.E. Cusick, 和 A.L. Barabasi. 相互作用网络与人类疾病. *Cell*, 144(6):986–998, 2011.

[7] U. Von Luxburg。谱聚类教程。*Statistics and computing*，17(4)：395–416，2007。

[8] 维基百科。图划分，2012年。

[9] 维基百科。最小割，2012年。

[10] 维基百科. 无标度网络, 2012.

CHAPTER

TWENTYTWO

CHROMATIN INTERACTIONS

Silvia Canas；Vivek Dasari

Figures

22.1 染色体领地 . . . . . 346 22.2 1) ChIP和DamID仅识别与核纤层密切接触的区域。 2) 基于3C的方法识别所有DNA-DNA相互作用，无论它们是否位于细胞核边缘 . . . . . 348 22.3 ChIP测量方法 . . . . . 349 22.4 DamID测量方法 . . . . . 350 22.5 基于3C的染色质相互作用识别方法 . . . . . 350 22.6 生成Hi-C数据的方法 . . . . . 352 22.7 ChIA-PET协议 . . . . . 352 22.8 核纤层关联域(LADs) . . . . . 353 22.9 表示Hi-C读取计数的矩阵 . . . . . 354 22.10描绘偏差来源的图像 . . . . . 355 22.11三维染色体领地 . . . . . 356 22.12核心染色体架构显而易见。约70%的区域是构成性的(cLAD/- ciLAD)，而30%的区域是兼性的(fLAD) . . . . . 357 22.13AT区域是构成性区域的指标 . . . . . 357 22.14(单)细胞周期中的LADs(Kind等人，Cell 2013) 358 22.15环挤出作为染色体定向机制 358

22.1 Introduction

近年来，许多细微且以往被忽视的精细遗传调控机制已被发现。除了蛋白质的直接调控外，这些机制还包括基因组非蛋白质编码区的参与、表观基因组因素如组蛋白修饰，以及多种RNA。

开关。细胞核内染色质的空间组织、染色质修饰复合物及其功能后果也已成为一个关注领域。在本章中，我们将深入探讨3D染色质结构的研究，从该领域的最新进展、最相关的术语和当前方法开始。特别地，我们将重点关注位于细胞核周边区域（因此与核纤层密切接触）的DNA区域的研究。最后，我们将讨论研究核基因组组织所涉及的计算方法。

22.1.1 What's already known

DNA在核小体中局部压缩，通过缠绕在组蛋白八聚体上实现。每个核小体包含约147个碱基对，以1.67个左手超螺旋圈包装。DNA作为染色体（在细胞分裂和有丝分裂期间）全局压缩。染色体已被染成不同颜色，并已证明某些染色体在细胞核内具有径向偏好，即使细胞并未积极进行分裂且染色体未凝缩。也就是说，一些染色体倾向于停留在细胞核中心附近，而另一些则倾向于周边。这些被称为染色体领域（CT）。同源染色体的领域通常不位于彼此附近。还知道存在一个总体核"架构"，它是可观察的，甚至在不同细胞类型之间也是保守的。

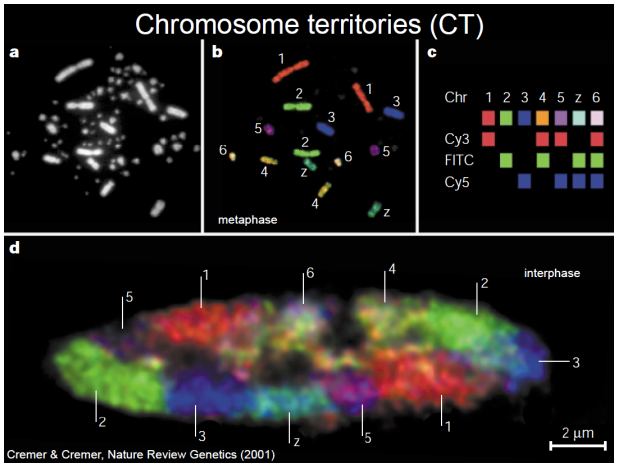

图22.1：染色体领地

由麦克米伦出版有限公司提供。经许可使用。来源：Cremer, Thomas, and Christoph Cremer. "Chromosome Territories, Nuclear Architecture and Gene Regulation in Mammalian Cells." N*ature Reviews Genetics* 2, no. 4 (2001): 292-301.

22.1.2 What we don't know

虽然DNA的局部组织（核小体包装）和全局组织（染色体凝聚）在某种程度上已被理解，但DNA的中间结构尚未得到很好的表征——许多推测的状态仅在体外观察到。基因组区域在亚染色体水平上在细胞核中的定位，例如包含几个基因的特定染色体区域的特定3D构象，也在很大程度上未知。

虽然已知染色体在整个细胞周期中保留了一些总体结构，但关于这种位置是如何维持的，以及不同染色体在整个细胞周期过程中如何继续相互作用，尚不清楚。

虽然我们确实了解染色体功能的某些部分，但我们对该过程的机制尚未有全面的理解。

22.1.3 Why do we study it?

一般来说，我们感兴趣的是理解基因组区域的功能特性及其编码的分子机制，这些机制可能与人类疾病有关。特别是，已表明空间上相邻区域编码的基因很可能受到共同调控。此外，细胞核内包装的DNA相当于将20公里长、20 μ米粗的线缠绕在网球大小的东西里，这长度可以从Kendall Square到Harvard再返回超过6次半！这不是很神奇吗？？

22.2 Relevant terminology

22.2.1 Nuclear lamina

核纤层是由蛋白质和丝状物组成的致密网络，位于内核膜的内表面。其功能包括：维持核的稳定性，与核孔复合体相互作用，以及通过直接相互作用和结合来组织染色质。该蛋白质网状结构主要由层粘连蛋白构成。

22.2.2 Lamina Associated Domains(LADs)

核纤层关联结构域（LADs）是染色质中与核纤层相互作用的部分。绘制染色质与核纤层的相互作用图有助于深入理解染色体折叠的图谱。尽管对LADs的了解尚不充分，但已知这些区域与高基因表达和低基因密度密切相关，这是一种有趣的组合。此外，LADs在其边界处与CTCFs、启动子和CPG岛相关联。

22.2.3 Histones

组蛋白是在真核生物中发现的高度碱性蛋白质，它们构成核小体的核心，负责包装和排序核DNA。由核心组蛋白H2A、H2B、H3和H4各两份形成的八聚体构成核小体，核小体充当DNA缠绕的线轴。

22.2.4 Chromatin

染色质是由DNA、蛋白质和RNA组成的复杂形式，它构成了真核细胞核中DNA的整体架构。其主要功能包括DNA包装、增强DNA大分子以允许有丝分裂、防止DNA损伤，以及调控基因表达和DNA复制。大多数

染色质结构形成和调控的机制在很大程度上仍然未知；然而，在细胞分裂过程中，染色质通过染色体进行组织。

22.2.5 Chromosome territories (CT)

染色体并非随机分布在整个细胞核中。染色体占据细胞核的特定区域。这些区域被称为染色体领地。

22.2.6 Gross folding principles

22.3 Molecular Methods for Studying Nuclear Genome Organization

研究细胞核中染色质三维结构的方法主要有两种类型。

- 第一组方法，即ChIP和DamID，是测量DNA与‘界标’相互作用的方法。也就是说，它们测量基因组位点与相对固定的核内界标的相互作用，只有与核纤层接触的基因组区域才会被识别出来。
- 第二类方法是基于3C的方法，这些方法用于测量DNA-DNA相互作用。无论这些DNA区域位于细胞核内部还是周边，只要它们之间存在相互作用，都可以被识别出来。

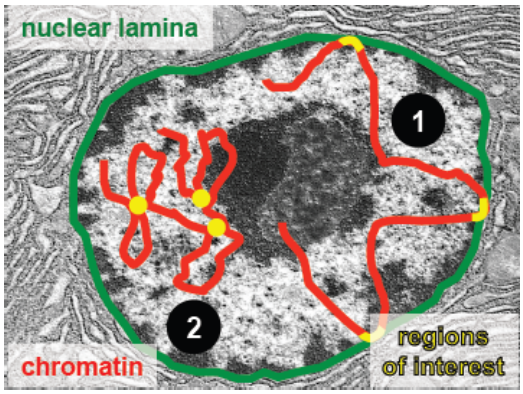

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图22.2：1）ChIP和DamID仅识别与核纤层紧密接触的区域。2）基于3C的方法识别所有DNA-DNA相互作用，无论它们是否位于细胞核外围。

22.3.1 Methods for measuring DNA-Nuclear Lamina interactions

以下方法，ChIP和DamID，都检测与核纤层特异性接触的DNA区域。

ChIP: Chromatin Immuno Precipitation

ChIP是一种检测与目标蛋白结合的DNA区域的方法。与DNA结合的蛋白质通过甲醛在原位交联。蛋白质-DNA复合物通过亲和色谱法被拉下，主要使用针对目标蛋白的特异性抗体。回收的复合物随后被解离，交联被打破，与蛋白质结合的DNA被片段化并分析。DNA片段随后可以使用测序（ChIP-Seq）或微阵列（ChIP-Chip）进行分析。然而，与各种ChIP技术相关的一个重大挑战是，获得高亲和力的抗体可能很困难。为了研究细胞核内DNA的3D结构，可以使用针对核纤层蛋白的抗体进行ChIP-Seq。

DamID: DNA adenine methyltransferase IDentification

DamID用于定位染色质结合蛋白的结合位点。在DamID方法中，来自*E. coli*的DNA腺嘌呤甲基转移酶（*Dam*）与LaminB1蛋白融合（Dam酶悬挂在蛋白质末端，因此处于相互作用的附近）。在*E. coli*中，*Dam*酶甲基化序列GATC中的腺嘌呤；细菌基因组含有类似Dam功能的蛋白质，以保护自身DNA免受限制酶切割，或作为其DNA修复系统的一部分。由于这一过程在真核生物中并不自然发生，因此某一区域中的甲基化腺嘌呤可归因于与融合了Dam的蛋白质的相互作用，从而表明该特定区域与核纤层发生了紧密接触。作为对照，未融合的*Dam*可以在低水平表达。这导致甲基化腺嘌呤的稀疏分布，其中甲基化腺嘌呤的精确位置可用于推断DNA可及性的变化。甲基化腺嘌呤通过二硫化物PCR测定或其他对模板DNA中甲基化敏感的PCR技术来确定。在其中一种测定中，基因组可被DpnI消化，DpnI仅切割甲基化的GATC序列。随后将接头序列连接到这些消化片段的末端，并使用与接头匹配的引物进行PCR。只有位于近端GATC位置之间的区域会被扩增。最终测量值是测试与对照核纤层关联之间比值的对数：正值优先与核纤层关联，因此被识别为LADs。使用DamID相较于ChIP的一个优势是，DamID不需要可能难以找到的特定抗体。然而，使用DamID的一个劣势是必须制备并表达融合蛋白。

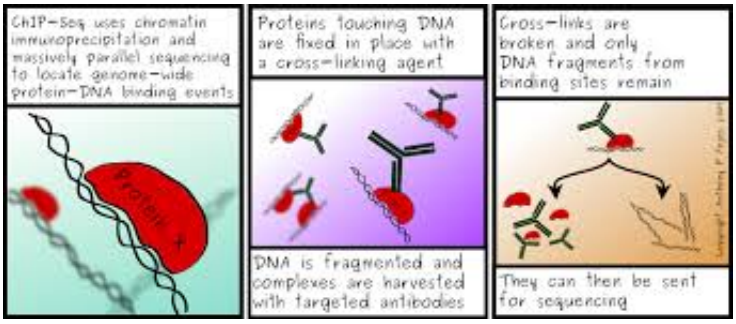

图22.3: ChIP测量方法
Courtesy of Anthony P. Fejes. Used with permission.

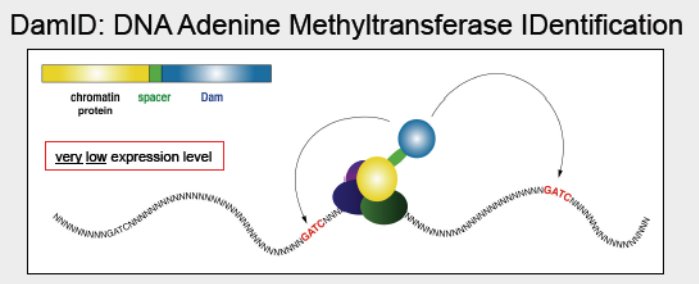

图22.4：DamID测量方法

由Bas van Steensel提供。经许可使用。

FAQ

Q: DNA需要多接近DamID才能被甲基化?

A: 它不必直接结合到核纤层，但必须非常接近。DamID的作用范围约为1.5kb。

22.3.2 Measuring DNA-DNA contacts

以下所有方法均基于染色体构象捕获（3C）并进行了一定的修改。

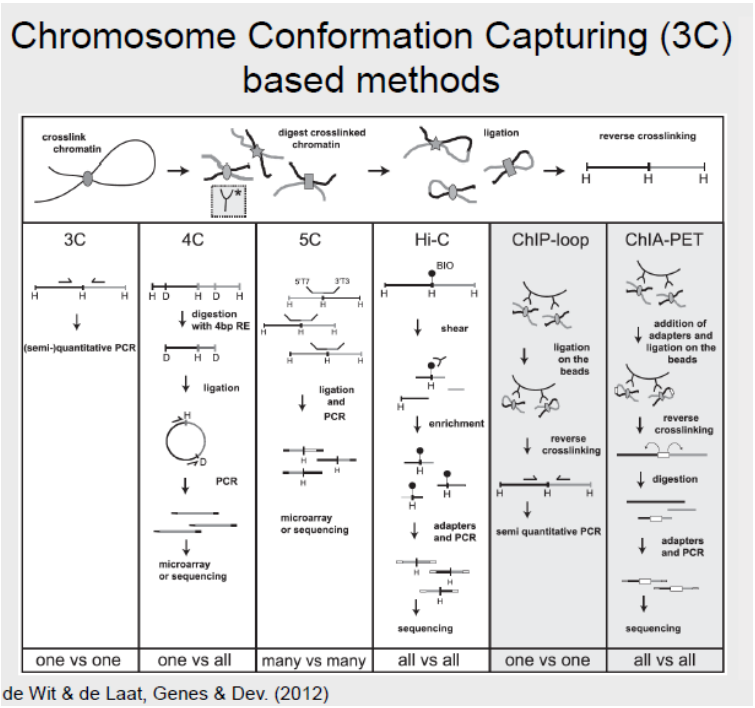

图22.5：基于3C的染色质相互作用识别方法

©冷泉港实验室出版社。保留所有权利。此内容不在我们的知识共享许可范围内。有关更多信息，请参见http://ocw.mit.edu/help/faq-fair-use/。 来源：de Wit, Elzo 和 Wouter de Laat。 “3C技术的十年：洞察核组织。” *Genes & Development* 26, no. 1 (2012): 11-24。

3C

染色体构象捕获（3C）是一种检测基因组中哪些位点在细胞核内与其他位点邻近的方法。与ChIP方法类似，交联剂被用于固定与DNA结合的蛋白质，形成蛋白质-DNA复合物。在允许结合的蛋白质解离后，DNA可被限制性内切酶消化。通常使用识别6个碱基对且产生粘性末端的酶，如*HindIII*。随后，产生的片段被诱导自我连接（使用极低浓度的DNA以防止片段与另一随机片段连接）。结果是得到一系列线性DNA片段，称为3C文库，可通过设计针对特定相互作用的引物进行PCR分析。3C可被描述为“一对一”方法，因为所用引物专门针对扩增两个感兴趣区域之间的相互作用产物。

Circularized Chromatin Conformation Capture (4C)

4C方法可以被描述为“一对所有”，因为对于单个感兴趣区域，我们可以检查它与基因组中所有其他区域的所有相互作用。4C的工作原理与3C类似，主要区别在于所使用的限制性内切酶。在4C中，使用常见切割酶来产生更多更小的片段。这些片段随后再次连接。一些较小的片段可能会被排除，但结果是形成一个环化的DNA片段。可以设计引物来扩增DNA的“未知”片段，从而鉴定出与感兴趣区域的所有相互作用。

Carbon-Copy Chromosome Conformation Capture (5C)

5C是一种“多对多”的方法，能够同时分析多个感兴趣区域与多个其他同样感兴趣的区域之间的相互作用。5C的工作原理与3C类似。然而，在获得3C文库后，会进行多重连接介导的扩增（LMA）。LMA是一种扩增多个目标的方法。所得的5C文库可以通过微阵列或高通量测序进行分析。

Hi-C

Hi-C 可以被描述为一种“全对全”方法，因为它识别所有染色质相互作用。Hi-C 的工作原理是在连接前用生物素标记所有 DNA 片段，从而标记所有连接点。然后使用磁珠纯化生物素标记的连接点。这个 Hi-C 文库随后可以进行下一代测序。

ChIP-loop

ChIP-loop 可以被描述为一种“一对一”的方法，因为它类似于3C，仅能识别两个感兴趣区域之间的相互作用。ChIP-loop 是 ChIP 和 3C 方法的结合体。首先，DNA-蛋白质复合物被交联并消化。接着，与 ChIP 类似，目标蛋白质及其结合的 DNA 通过抗体被下拉。随后，实验流程如同 3C：片段自由端被连接，交联被逆转，之后可采用针对“一对一”相互作用设计的引物进行测序。

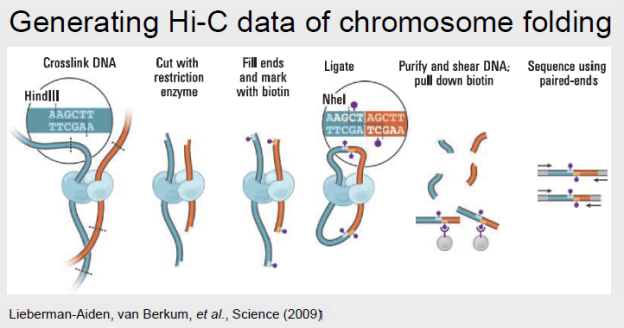

图22.6：生成Hi-C数据的方法

© 美国科学促进会。版权所有。此内容不属于我们的知识共享许可范围。有关更多信息，请参见 http://ocw.mit.edu/help/faq-fair-use/。来源：Lieberman-Aiden, Erez, et al. "Comprehensive Mapping of Long-range Interactions Reveals Folding Principles of the Human Genome." *Science* 326, no. 5950 (2009): 289-93.

ChIA-PET

通过配对末端标签测序进行染色质相互作用分析，或称ChIA-PET，结合了ChIP和3C方法，以全基因组范围确定远距离染色质相互作用。它可以被描述为一种“全对全”方法，因为尽管必须鉴定出感兴趣的单一蛋白质，但任何相互作用都将被识别。在ChIA-PET中，如先前讨论的方法一样，DNA-蛋白质复合物被交联。然而，随后使用超声破碎来打碎染色质，并减少非特异性相互作用。与ChIP协议一样，使用抗体拉下与感兴趣蛋白质结合的DNA区域。然后，两个不同的寡核苷酸接头被连接到DNA的游离端。这两个接头都具有*MmeI*切割位点。随后，接头被连接在一起，使游离端相连，之后片段用*MmeI*消化。*MmeI*在其识别序列下游20个核苷酸处切割，因此消化的结果是接头两侧由感兴趣的序列包围。这是一种“标签-接头-标签”结构，这些片段被称为PETs。PETs可以被测序并映射回基因组，以确定相互作用的DNA区域。

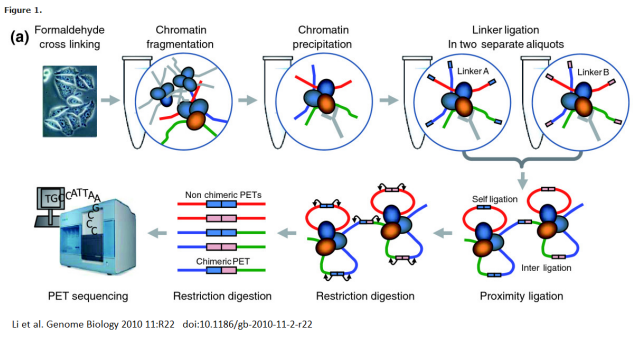

图22.7：ChIA-PET协议

Courtesy of the authors. License: CC BY.
Source: Li, Guoliang, et al. "Software ChIA-PET tool for Comprehensive Chromatin Interaction Analysis with Paired-end Tag Sequencing." *Genome Biology* 11 (2010): R22.

22.4 Mapping Genome-Nuclear Lamina Interactions (LADs)

在本节中，我们将介绍如何使用DamID和Hi-C方法绘制基因组中与核纤层相关的结构域图谱。

22.4.1 Interpreting DamID Data

DamID方法（在第3节中描述）被用于识别在核纤层处与lamin蛋白相互作用的DNA区域。

Did You Know?
DamID实验通常运行24小时，且甲基化是不可逆的。结果也是数百万个细胞的平均值。因此，DamID不适合用于基因组与精确时间相关的定位，尽管单细胞研究可能很快就会解决这个问题！再

DamID实验的结果被绘制为$log_2{}^{Dam\,fusion protein}$，如下图（黑色~~$Dam only$~~峰）所示。对于LaminB1融合实验，阳性区域（下图中用黄色下划线标出）表示优先与核纤层相关的区域。这些阳性区域被定义为核纤层相关结构域，即LADs。在人类中发现了大约1300个LADs

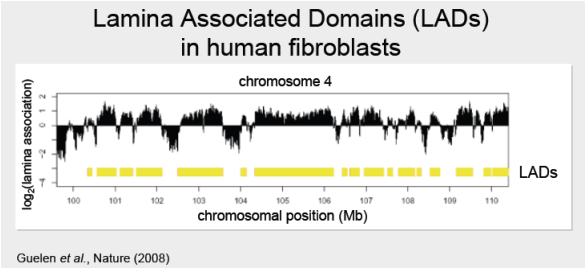

图22.8：核纤层关联结构域（LADs）

© 来源未知。版权所有。此内容不在我们的知识共享许可协议范围内。如需了解更多信息，请参见 http://ocw.mit.edu/help/faq-fair-use/。

成纤维细胞。它们大得惊人，范围约为0.1Mb至10Mb，中位大小为5Mb。

FAQ

Q: 在这种表示中，0的值重要吗?

A: 不，确实存在一个点，我们无法确定真正的0在哪里。相反，我们可以尝试对0值应处的位置做出较好的估计，以便观察相对偏好（细胞核内部与外部）

在识别出LADs后，我们可以对其边界进行比对，以发现诸如已知基因密度或基因表达水平等各种有趣特征与数据的关联，从而构建我们的LAD模型。实验表明，LADs的特点是基因密度和基因表达水平较低。人们注意到，LAD边界定义得非常清晰。通过比对许多LAD的起始位置，发现这些边界特别以CpG岛、向外指向的启动子和CTCF结合为标志。

FAQ

Q: 为什么CTCF结合位点如此重要？**A:** 这就是问题所在！它们或许有助于维持LADs。它们也许能防止LADs“扩散”。

位点。

FAQ

Q: 组织与多克隆表达有何关联?

A: 当然有事情发生；然而，多克隆抑制的作用规模小于LAD。它发生在LADs之外，作为一种额外的抑制机制。

22.4.2 Interpreting Hi-C Data

收集了Hi-C数据，并将读段映射回基因组。读段计数被编译成如下所示的矩阵O（，针对染色体14），其中元素$O_{i,j}$表示对应于位置i和j之间相互作用的读段数量。一条明显的对角线清晰可见，表明在1D中靠近的区域在3D中也可能相互作用。当Hi-C技术的假设被违反时，可能会出现数据解释错误：例如，假设参考基因组是正确的，这在癌细胞的情况下可能不成立。随后，该矩阵被

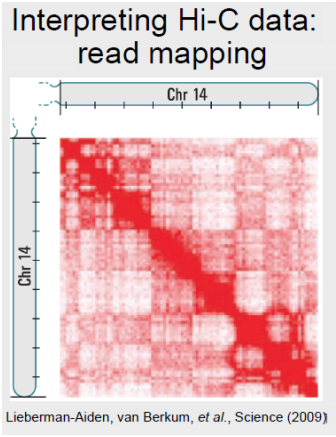

图22.9：表示Hi-C读取计数的矩阵

©美国科学促进会。保留所有权利。此内容不在我们的知识共享许可协议范围内。有关更多信息，请参见http://ocw.mit.edu/help/faq-fair-use/。来源：Lieberman-Aiden, Erez, et al. "Comprehensive Mapping of Long-range Interactions Reveals Folding Principles of the Human Genome." Science 326, no. 5950 (2009): 289-93.

归一化以考虑两个区域之间的遗传距离，以及一个矩阵，指示数据中哪些相互作用是富集或耗竭的。为了将二维矩阵中的数据与一维基因组数据集进行比较，必须使用主成分分析（PCA）。经过PCA后，可以对数据进行功能表征。Hi-C识别出两种全局类型的区域：

- A 型，其特征为开放染色质、基因丰富性和活跃的染色质标记。
- B型，其特征为封闭染色质，且基因贫乏。

两种类型的区域主要各自内部相互作用，而两类区域间的交互并不频繁。Hi-C技术也证实了染色体领地的存在，因为染色体内部相互作用远多于染色体间的相互作用。

22.5 Computational Methods for Studying Nuclear Genome Organization

22.5.1 Sources of Bias

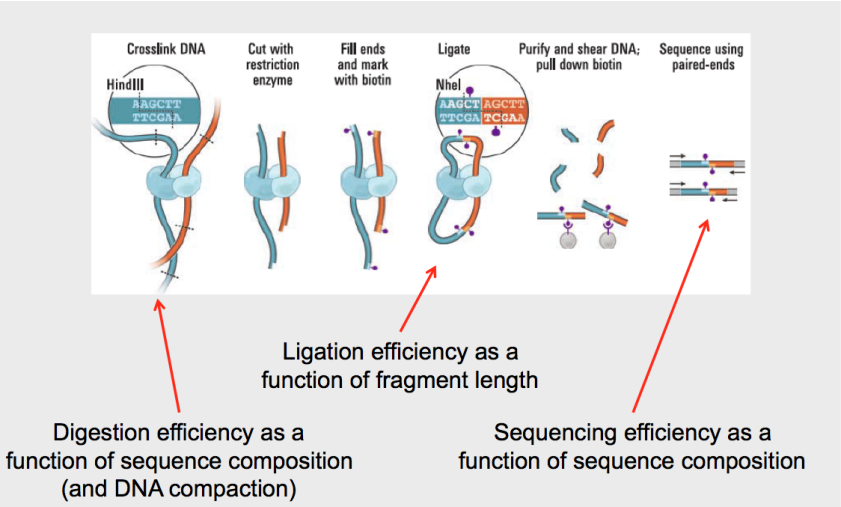

图22.10：描述偏见来源的示意图

©美国科学促进会。保留所有权利。此内容不在我们的知识共享许可协议范围内。有关更多信息，请参见http://ocw.mit.edu/help/faq-fair-use/。来源：Lieberman-Aiden, Erez, et al. "Comprehensive Mapping of Long-range Interactions Reveals Folding Principles of the Human Genome." Science 326, no. 5950 (2009): 289-93.

可能引入偏差的三个步骤包括：酶切、连接和测序。酶切效率取决于所用的限制性内切酶，因此基因组的某些区域可能因其特定识别位点的分布非常稀疏而不易被酶切。此外，某些区域可能富含识别位点，从而在结果中过度呈现。解决这一问题的一种方法是使用多种不同的限制性内切酶并比较结果。连接效率取决于片段长度。根据限制性内切酶切割序列的方式，某些末端可能更容易或更不容易连接在一起。最后，测序效率取决于序列的组成。基于GC含量和重复序列的存在，某些DNA链将更难测序，这会引入偏差。

22.5.2 Bias Correction

为最小化连接偏差，非特异性连接产物会被移除。由于非特异性连接产物通常具有较远的限制性位点，它们会引入大得多的片段。此外，片段大小对连接效率的影响（$F_{len}(a_{len}, b_{len})$）、G/C含量对扩增和测序的影响（$F_{gc}(a_{gc}, b_{gc})$），以及序列唯一性对可映射性的影响（$M(a) * M(b)$），都可以通过以下方程进行考虑和校正：

$$P(X_{a,b}) = P_{prior} * F_{len}(a_{len}, b_{len}) * F_{gc}(a_{gc}, b_{gc}) * M(a) * M(b)$$

或者，偏差来源可以通过以下方程更隐晦地表示：

$$O_{i,jj} = B_i * B_j * T_{i,j}$$

其中每个箱的所有相对接触概率 $T_{i,j}$ 之和等于1。假设偏差仅为乘法性的。这通过矩阵平衡，或通过迭代校正算法进行比例拟合来求解。

22.5.3 3D-modeling of 3C-based data

3D建模可以揭示基因组组织的许多一般原理。目前的模型是通过结合位点间相互作用和已知的核标志物之间的空间距离来生成的。然而，由于数据是从数百万个细胞中收集的，当前的3D模型仍然存在许多不确定性。影响3D建模的实际问题在于构建模型所需的大量数据以及单个细胞与群体之间的不同动力学，这导致模型不稳定。下一代建模趋向于使用单细胞基因组学。

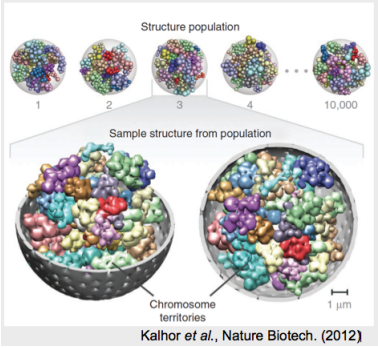

图22.11：三维染色体领地

由Macmillan Publishers Limited提供。经许可使用。来源：Kalhor, Reza, 等. “通过束缚染色体构象捕获和基于群体的建模揭示的基因组架构.” *Nature Biotechnology* 30, no. 1 (2012): 90-98.

22.6 Architecture of Genome Organization

22.6.1 Multiple cell types influence on determining architecture

胚胎干细胞（ESC）、神经祖细胞（NPC）和星形胶质细胞（AC）都是同基因细胞类型（它们都起源于胚胎干细胞）。胚胎干细胞不断分裂，并且完全未分化；它们生成神经祖细胞，后者仍在分裂但分裂程度较低，并且仅处于半分化状态。神经祖细胞随后生成完全分化的星形胶质细胞。研究发现，在这一分化过程中，一些区域从核纤层相关结构域转变为内部结构域。在胚胎干细胞中，转录非常少。然而，随着细胞变得越来越分化，转录增加。这与这些结构域从主要与核纤层相关（因此不表达）到定位于内部的定位变化相匹配。尽管这些细胞类型各自具有非常不同的特性，但DamID图谱显示，这三种同基因细胞以及一个独立的成纤维细胞之间具有高度相似性。采用隐马尔可夫模型来识别细胞之间的核纤层相关结构域。发现了一个核心染色体结构，其中约70%的染色体是组成型（cLad/ciLAD），30%的染色体是兼性型（fLAD）。

22.6.2 Inter-species comparison of lamina associations

为了确定物种间的层关联，使用了小鼠和人类。在小鼠和人类之间构建了全基因组比对。对于小鼠中的每个基因组区域，在人类中匹配了最佳互惠区域。然后重新映射了人类基因组，并用于重建一个

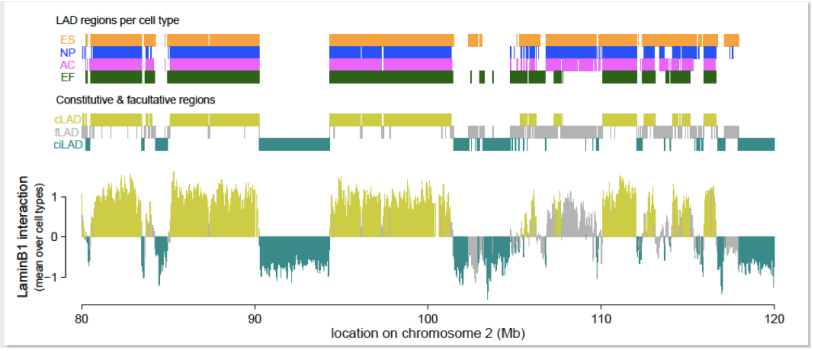

© Cold Spring Harbor Laboratory Press。保留所有权利。此内容不在我们的知识共享许可范围内。有关更多信息，请参见http://ocw.mit.edu/help/faq-fair-use/。来源：Meuleman, Wouter, et al. "Constitutive Nuclear Lamina–genome Interactions are Highly Conserved and Associated with A/T-rich Sequence." *Genome Research* 23, no. 2 (2013): 270-80。

图22.12：核心染色体结构显而易见。约70%的区域是构成性的（cLAD/- ciLAD），而30%的区域是兼性的（fLAD）

小鼠基因组。DamID数据被投射到这张图上，两个基因组之间有83%的一致性（组成型区域为91%；兼性区域为67%）。

22.6.3 A-T Content Rule

A-T含量已被发现是核心架构内层粘连的强预测因子。对这一预测的额外支持是，构成核心架构的LAD结构类似于一个等容线结构（一个大的均匀DNA区域）。

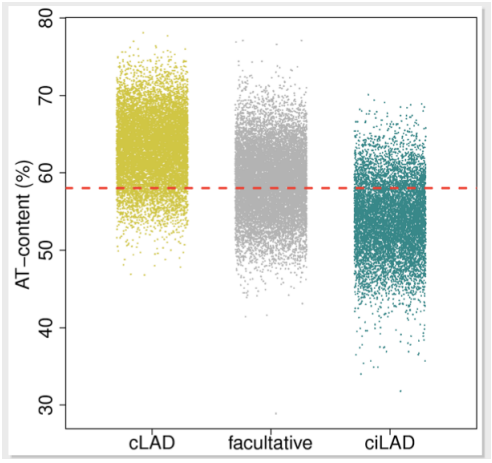

图22.13：AT区域是组成型区域的指标

© Cold Spring Harbor Laboratory Press。版权所有。此内容不在我们的知识共享许可范围内。有关更多信息，请参见http://ocw.mit.edu/help/faq-fair-use/。来源：Meuleman, Wouter, et al. "Constitutive Nuclear Lamina–genome Interactions are Highly Conserved and Associated with A/T-rich Sequence." *Genome Research* 23, no. 2 (2013): 270-80。

22.7 Mechanistic Understanding of Genome Architecture

22.7.1 Understanding Mitosis and LADs

在有丝分裂过程中，染色体的组织方式，尤其是与其他染色体部分的空间关系，尚未被充分理解。细胞的构象被认为符合两种不同的状态。高度区室化且细胞类型特异性的构象几乎完全限于间期。在向中期转变的过程中，染色体进入一种与基因座和组织无关的折叠状态。

在有丝分裂过程中，大约30%的LADs位于细胞周边。然而，这种定位反映了蛋白质-核纤层在间歇性间隔的接触，但细胞被限制在细胞周边。在有丝分裂期间，这种层状定位被子细胞随机继承。

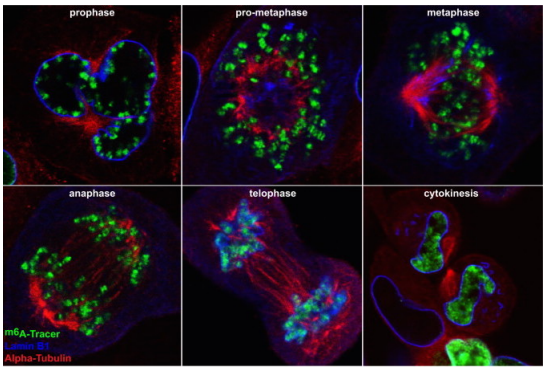

图22.14：通过（单一）细胞周期的LADs（Kind等人，Cell 2013）

由Elsevier, Incorporate提供，经许可使用。来源：Kind, Jop等，“基因组-核纤层相互作用的单细胞动力学”，*Cell* 153，第1期（2013年）：178-92。

22.7.2 Modeling

三维建模在理解染色体相互作用中将变得越来越重要。当前的技术已经对酵母基因组和α -珠蛋白基因座进行了建模（Duan *et al.* Nature (2010)，Bau *et al.* Nature SMB (2011)）。从建模研究中已经明确，我们无法在接触概率和空间距离之间建立直接关系（即接触概率 != 空间距离）。

然而，建模是一个逆问题，从一个方向到另一个方向比反过来要困难。具体来说，从蛋白质结构到蛋白质接触图比反过来更容易。同样，即使我们拥有接触图谱，染色体结构也是一个难题。

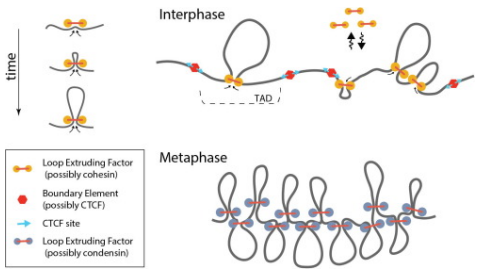

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图22.15：环挤压作为染色体定向的一种机制

22.8 Current Research Directions:

22.8.1 LADs

(a) 30% 的基因组在细胞类型之间是可变的，我们如何能够区分这些差异

(b) 核纤层与LADs如何相互作用？LADs与这些结构域之间是否存在吸引力，还是基于内部的排斥作用?

(c) LADs外围的基因为何以及如何受到抑制。

22.8.2 TADs and Other Compartments:

(a) compartments 的生物学基础是什么，是否存在 compartments 的某些多方面成分?

(b) 黏连蛋白如何工作？黏连蛋白挤出对足以解释所有结构域吗?

(c) 增强子-启动子环是否局限于特定结构域？这些是动态组件，还是由CTCF介导的结构环?

22.8.3 Other/Miscellaneous:

(a) 我们如何将不同的染色体组成部分（即LADs、TADs、多梳结构域、复制起点、组蛋白修饰、基因表达）相互关联?

(b) 基因组结构的进化基础：是否存在进化压力，折叠原理何时出现?

(c) 在染色体变化中，是定位还是表达变化先发生?

Did You Know?
这个问题已经（部分）得到解决！在研究经历多轮分化的细胞时，观察到一些区域在第一次分化时会定位到核纤层，但直到第二次分化才会被抑制！

Body Guard Hypothesis
1975年，Hsu TC提出了“保镖假说”。该假说认为，非活性DNA位于细胞核外围，以便‘守护’DNA的重要活跃区域免受病毒或自由基等外来威胁。通过引入人工DNA损伤来验证这一假说的尝试已产生了间接的结果，但该问题仍悬而未决。**Single Cell Experiments**

已知细胞在有丝分裂后保留其原有的组织，如染色体染色实验所示。然而，最近的实验表明，亲代细胞和子代细胞之间的组织可能存在较大差异。某些全局特性，如染色体领地，是保守的，

但在更精细的细节层面，组织结构可能会有很大差异。单细胞实验是一项新兴技术，或许能够解答这个悬而未决的问题。

FAQ

Q: 有没有人尝试过在LAD中间增加一个基因的表达？结果如何？

A: 目前尚不清楚是否存在这一具体实例，但已进行了几项相关研究。研究人员试图将一段DNA“拴系”到核纤层上，观察它是否会自发失活。然而，结果并不确定，因为在半数情况下该区域会失活，而在另一半情况下则不会！迄今为止，这类操作尚未取得太多成果，但研究发现，如果一段不含蛋白质的DNA片段被消化并与高度纯化的核纤层蛋白混合，结合后的片段会呈现出与LADs非常相似的模式。这告诉我们，核纤层直接与DNA结合。不过，这似乎在不同物种之间存在差异。

22.9 Further Reading

22.10 Available Tools and Techniques

22.11 What Have We Learned?

CHAPTER

TWENTYTHREE

稳态代谢建模简介

詹姆斯·加兰甘客座讲座 由梅里姆·塞夫塔记录（2011年）
杰克·夏皮罗、安德鲁·舒姆和阿舒托什·辛哈尔（1910年）
莫莉·福特·达库斯和阿南德·奥扎（1909年） 克里斯托弗·加雷（1908年）

Figures

23.1 导致柠檬酸循环并包括其在内的过程。 . . . . . 363 23.2 为极端途径添加约束。 . . . . . 366 23.3 使用线性规划最大化两个函数。 . . . . . 367 23.4 移除一个反应与从化学计量矩阵中移除一个基因是相同的。 . . . 368 23.5 约束可行解空间可能产生新的最优通量。 . . . . . 369 23.6 Coljin 等人的模型 [3] . . . . . 374 23.7 在变化药物治疗下预测代谢系统状态的基础通量 . . . . . 375 23.8 应用表达数据集允许约束锥形形状。 . . . . . 375 23.9 营养源预测实验结果。 376

23.1 Introduction

代谢建模使我们能够使用数学模型来表示复杂的生物系统。本讲讨论了对生物系统稳态进行建模在理解生物体代谢能力中的作用。我们还简要讨论了稳态模型在多大程度上能够复现体外实验。

23.1.1 What is Metabolism?

根据Matthews和van Holde的定义，代谢是生物体内所有化学反应的总和。这包括分解代谢反应，即导致分子分解为较小成分的反应，以及合成代谢反应，负责从较小成分中构建更复杂的分子（例如蛋白质、脂质、碳水化合物和核酸）。这些反应负责从化学键中释放能量以及储存这种能量。代谢反应还负责信息的转导和传递（例如，通过生成作为第二信使的cGMP或作为蛋白质翻译底物的mRNA）。

23.1.2 Why Model Metabolism?

代谢建模的一个重要应用是预测药物效果。建模的一个重要对象是结核分枝杆菌[15]。破坏该生物的霉菌酸合成途径有助于控制结核感染。计算建模为我们提供了一个识别该系统中最佳药物靶点的平台。
*Escherichia coli*中的基因敲除研究使科学家能够确定哪些基因和基因组合影响这一重要模式生物的生长[6]。模型与实验数据之间的一致与不一致都能帮助我们评估对生物系统的认识，并改进对代谢能力的预测。在下一讲中，我们将学习将表达数据纳入代谢模型的重要性。此外，多种传染病过程涉及微生物层面的代谢变化。

23.2 Model Building

代谢建模的一个总体目标是能够将通路的示意图转化为对该通路进行建模的数学公式。例如，将以下通路转换为数学模型将极其有用。

23.2.1 Chemical Reactions

在代谢模型中，我们关注的是模拟由酶催化的化学反应。酶通过作用于酶-底物复合物的过渡态来降低化学反应的活化能。讲义第1页幻灯片5上的图表展示了这一现象。描述酶反应的底物S转化为产物P的典型速率方程可以用米氏速率定律来描述:

$$\frac{V}{V_{max}} = \frac{[S]}{K_m + [S]}$$

在此方程中，V 是作为底物浓度 [S] 函数的反应速率。显然，参数 K_m 和 V_{max} 是表征该方程所必需的。

包含多个底物、产物和调控关系会迅速增加描述此类方程所需的参数数量。讲义第2页幻灯片1、2和3上的图表展示了生化途径的复杂性。动力学建模很快就会变得

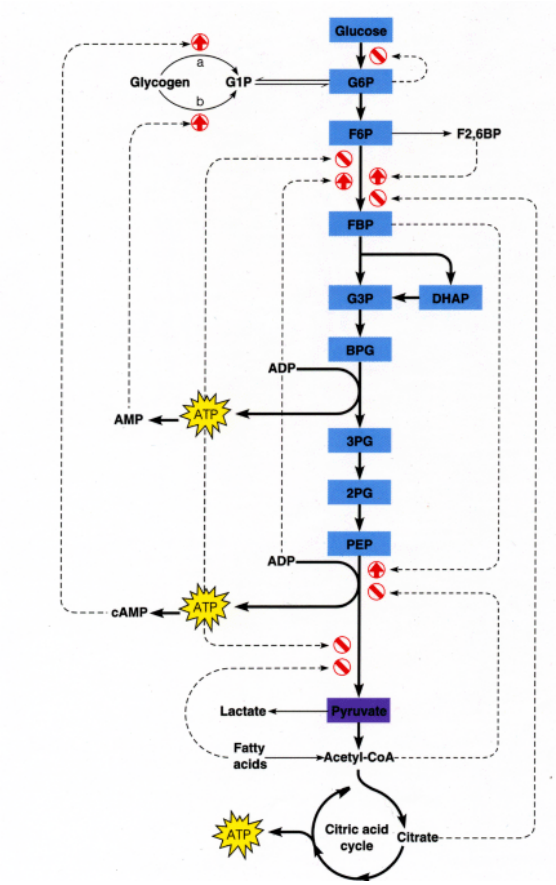

图23.1：导致并包括柠檬酸循环的过程。

© Pearson。保留所有权利。本内容不包含在我们的知识共享许可范围内。有关更多信息，请参见http://ocw.mit.edu/help/faq-fair-use/。来源：Matthews, C. K., 等. "生物化学." (2000).

不可行：必要参数难以测量，并且在不同生物体之间也存在差异[10]。因此，我们感兴趣的是这样一种建模方法，它允许我们使用少量精确确定的参数。为此，我们回顾普通化学中化学计量学的基本机制。考虑化学方程式$A+2B \rightarrow 3C$，它表示1个单位的反应物A与2个单位的反应物B结合，生成3个单位的反应物C。化合物X的生成速率由[X]的时间导数给出。注意，C的生成速率是A的三倍。因此，由于反应的化学计量关系，我们看到反应速率（或反应通量）由下式给出

$$flux = \frac{d[A]}{dt} = \frac{1}{2}\frac{d[B]}{dt} = \frac{1}{3}\frac{d[C]}{dt}$$

这在后续章节中将会很有用。我们现在必须说明使我们的模型易于处理的简化假设。

23.2.2 Steady-State Assumption

稳态假设假定系统中任何代谢物都不会积累。这使我们能够完全依据化学性质（即酶促反应各组分之间的化学计量关系）来表示反应。请注意，这并不意味{/* 翻译说明：此注释为占位，实际输出不应包含此注释 */}着不存在通量。

通过任何给定的反应。相反，稳态实际上意味着两个假设，这对简化代谢建模至关重要。第一个是内部代谢物浓度恒定，第二个是通量，即输入和输出通量，也恒定。

类比于一系列瀑布将水注入水池。当水从一个池子落到另一个池子时，尽管水持续流动，水位却不会改变（参见第2页幻灯片5）。这一框架使我们免受系统扰动可能导致的过于复杂的瞬态动力学所阻碍。由于我们通常关注长期的代谢能力（时间尺度超过毫秒或秒的功能），稳态动力学或许能提供我们所需的所有信息。

稳态假设使得跨物种泛化和在模型中重用保守通路的能力变得更加可行。反应化学计量通常在不同物种间是保守的，因为它们只涉及质量守恒。酶催化的生物学及其表征参数则不具有类似的保守性。这些包括物种依赖性参数，如反应的活化能、酶的底物亲和力以及各种反应的速率常数。然而，这些都不是稳态建模所必需的。

同样值得注意的是，由于代谢反应的时间常数通常以毫秒计，当今使用的大多数测量技术无法捕捉这些极快的动态变化。例如，基于质谱的代谢组学测量就是这种情况。在这种方法中，系统内所有内部代谢物的量在某一特定时间点被测量，但最多每小时才能进行一次测量。在大多数情况下，所测量到的仅仅是稳态。

23.2.3 Reconstructing Metabolic Pathways

有几个数据库可以提供在计算机中重建代谢途径所需的信息。这些数据库允许使用酶委员会编号访问反应化学计量。在利用特定酶的所有生物体中，反应化学计量是相同的。感兴趣的数据库包括ExPASy [5]、MetaCyc [16]和KEGG [14]。这些数据库通常包含按功能组织的途径，可以以SBML格式下载，使得对于特征明确的途径，途径重建变得非常容易。

23.3 Metabolic Flux Analysis

代谢通量分析（MFA）是一种计算在稳态下给定代谢网络中可能的反应通量分布的方法。我们可以对某些通量施加约束，以限制可能通量分布所描述的空间。在本节中，我们将为MFA建立数学表述。再次强调，这种分析与系统的具体生物学特性无关；相反，它仅取决于所讨论反应的（通用）化学计量关系。

23.3.1 Mathematical Representation

考虑一个具有 m 个代谢物和 n 个反应系统。设 x_i 为底物 i 的浓度，因此底物浓度的变化率由 x_i 的时间导数给出。设 x 为列向量

(包含m个组分)，其元素为x_i。为简单起见，我们考虑一个具有m=4种代谢物A、B、C和D的系统。该系统将由这些代谢物之间的许多反应组成，从而导致这些化合物之间复杂的平衡。

再次考虑简单反应 $A + 2B \rightarrow 3C$。我们可以将该反应表示为向量形式 (-1 -2 3 0)。注意前两个代谢物（A 和 B）具有负号，因为它们在反应中被消耗。此外，向量元素由反应的化学计量决定，如第 2.1 节所述。我们对系统中的每个反应重复此过程。这些向量成为化学计量矩阵 S 的列。如果系统有 m 个代谢物和 n 个反应，S 将是一个 m n 矩阵。因此，如果我们定义 v 为每个反应中通量的 n 分量列向量，向量 S_v 描述了每个代谢物浓度的变化率。在数学上，这可以表示为代谢通量分析的基本方程：

$$\frac{dx}{dt} = Sv$$

矩阵 S 是一种极其强大的数据结构，能够表示生物系统中多种可能的场景。例如，如果 S 的两列 c 和 d 具有性质 {v*}，则这两列表示一个可逆反应。此外，如果某一列具有仅一个分量非零的性质，它表示一个交换反应，其中根据非零分量的符号，存在流入（或来自）一个假定无限汇（或源）的通量。

我们现在施加稳态假设，即上述方程左侧恒为零。因此，我们需要找到满足准则$Sv = 0$的向量v。此方程的解将确定该系统的可行通量。

23.3.2 Null Space of S

模型系统中反应的可行的通量空间由S的零空间定义，如上所示。从基础线性代数回顾，矩阵的零空间是一个向量空间；即给定零空间中的两个向量y和z，向量$ay + bz$ (对于实数a、b)也位于零空间中。由于零空间是一个向量空间，存在一个基b_i，这是一组线性无关且张成零空间的向量。该基具有以下性质：对于S的零空间中的任何通量v，存在实数α_i，使得

$$v = \Sigma_i \alpha_i b_i$$

我们如何找到矩阵零空间的一组基？一个有用的工具是奇异值分解（SVD）[4]。矩阵S的奇异值分解定义为表示$S = UEV*$，其中U是大小为m的酉矩阵，V是大小为n的酉矩阵，而E是一个mxn对角矩阵x，其（必然为正的）奇异值按降序排列。（回想一下，酉矩阵是具有标准正交列和行的矩阵，即$U*U = UU* = I$单位矩阵）。可以证明任何矩阵都有SVD。注意，SVD可以重新排列为方程$Sv = \sigma u$，其中u和v分别是矩阵U和V的列，而是一个奇异值。因此，如果$\sigma = 0$，则v属于S的零空间。事实上，对应于零奇异值的V的列构成了S的零空间的标准正交基。通过这种方式，SVD使我们能够完全刻画系统的可能通量。

23.3.3 Constraining the Flux Space

上面提到的第一个约束是所有稳态通量向量都必须位于零空间中。此外，负通量在热力学上是不可能的。因此，一个基本约束是所有通量必须为正。（在此框架内，我们将可逆反应表示为化学计量矩阵 S 中具有两个单向通量的独立反应。）

这两个关键约束构成了一个可以通过凸分析求解的系统。解区域可以用一组唯一的极端路径来描述。在这个区域内，稳态通量向量v可以描述为这些极端路径的正线性组合。极端路径，在幻灯片25中以向量b_i表示，界定了一个凸通量锥。每个维度代表某个反应的速率。在幻灯片25中，z维度代表v_3的反应速率。我们可以认识到，在任何时间点，生物体都生活在通量锥中的某个点上，即展示了一种特定的通量分布。通量锥中的每一个点都可以用一个可能的稳态通量向量来描述，而锥外的点则不能。

一个问题是通量锥延伸至无穷大，而无穷大的通量在物理上是不可能的。因此，一个额外的约束是通过确定我们任何反应的最大通量来限制通量锥（这些值对应于我们的 V_{max} 参数）。由于许多代谢反应位于细胞内部，因此无需为每个通量设定上限。这些上限可以通过测量最大通量实验确定，或使用诸如扩散规则等数学工具计算。

我们还可以添加输入和输出通量，表示进出细胞的运输（V_{in} 和 V_{out}）。这些通量通常比内部通量更容易测量，因此有助于我们生成更具生物学相关性的通量空间。解决此问题的一个算法示例是单纯形算法 [1] 。幻灯片24-27展示了通量约束如何改变通量锥的几何形状。实际上，我们处理的是更高维空间中的问题。

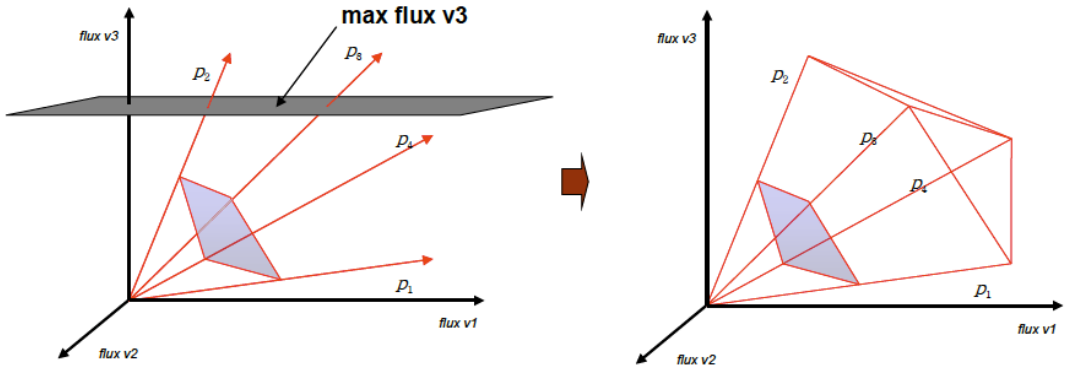

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 htt
p://ocw.mit.edu/help/faq-fair-use/。

图23.2：向极端途径添加约束。

23.3.4 Linear Programming

线性规划是一种通用解决方案，能够求解给定线性约束的优化问题。这些问题可以用几种不同的形式表示。

Canonical Form ：

- 最大化：$c^T x$
- 受限于：$Ax \leq b$

Standard Form ：

- 最大化 $\Sigma c_i * x_i$
- 以 $a_{ij} X_i \leq b_i for all i, j$ 为条件
- 非负性约束：$X_i \geq 0$

关于线性规划的简明清晰介绍可在此处获取：`http://www.purplemath. com/modules/linprog.htm` 第3节中描述的约束条件给出了讲座中所述的线性规划问题。线性规划可被视为一种初步近似，并且是优化领域中的一个经典问题。为了尝试缩小我们的可行通量范围，我们假设存在一个适应度函数，它是系统中任意数量通量的线性组合。线性规划（或线性优化）涉及在由线性约束和非负性约束所指定的凸多面体上最大化或最小化一个线性函数。

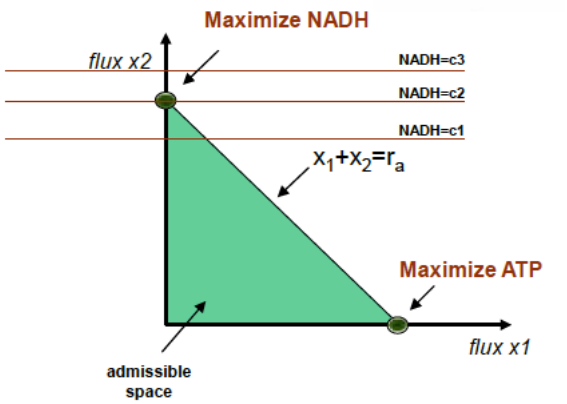

图23.3: 使用线性规划最大化两个函数。

我们通过确定使目标函数最大化的通量分布来解决这个问题：

线性规划的关键点在于，我们的解位于允许通量空间的边界上，且可能位于点、边或两者之上。然而，根据定义，最优解（如果存在的话）将位于允许通量空间的一个点上。这一概念在第30张幻灯片中得以展示。在该幻灯片中，A 是化学计量矩阵，x 是通量向量，而{v}15 是最大允许通量向量。

线性规划在手算时，通常采用单纯形法解决。单纯形法将问题置于矩阵中，并依据问题陈述中的基本变量进行一系列枢轴操作。然而，在最坏情况下，这可能会以指数时间运行。幸运的是，如果拥有计算机，还有另外两种算法可用。椭球算法和内点法均能在多项式时间内解决任何线性规划问题。有趣的是，许多看似困难的问题都可以建模为线性规划，并能高效求解（或达到通用解法解决特定问题的高效程度）。

在大肠杆菌等微生物中，这个目标函数通常是贡献于生物量的通量的组合，如幻灯片31所示。然而，这个函数不必完全具有生物学意义。

例如，我们可以模拟在*M. tuberculosis*中分枝菌酸的最大化，尽管这在生物学上并未发生。这将为我们提供有意义的预测，关于在体外可以进行哪些扰动，即使在那些代谢产物生产未最大化的情况下，也能干扰分枝菌酸的合成。通量平衡分析(FBA)由UCSD的Palsson团队开创，此后已应用于大肠杆菌、结核分枝杆菌和人类红细胞[?]。

23.4 Applications

23.4.1 *In Silico* Detection Analysis

随着FBA这样强大工具的出现，更多问题自然浮现。例如，我们能否根据基因敲除对代谢的模拟效应预测其表型？再者，即便存在如蛋白质相互作用图谱连通性等其他方法，我们为何还要尝试这样做？此类分析实则必要，因为其他方法并未直接考虑代谢流或其他特定的代谢条件。

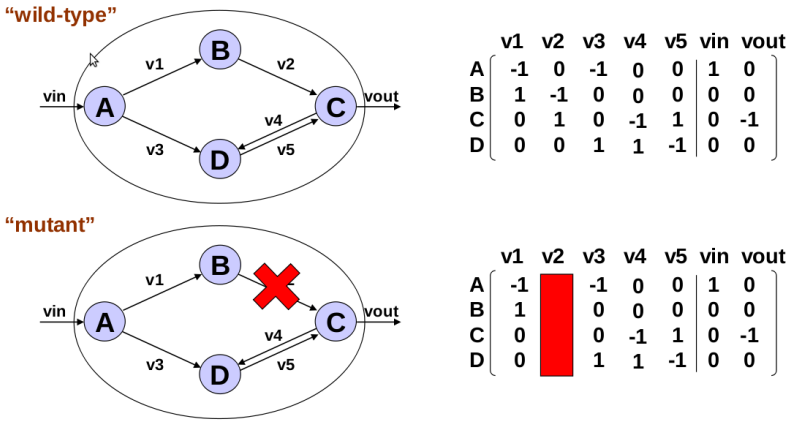

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图23.4：移除一个反应等同于从化学计量矩阵中移除一个基因。

在实验中敲除一个基因，简单地通过从化学计量矩阵中移除一列（反应）来建模。（课堂上一个问题澄清了单个基因可以敲除多个列/反应。）因此，这些敲除突变将通过移除通量及其相关的极端路径进一步限制可行解空间。如果原始最优通量在新空间之外，则会生成新的最优通量。因此，FBA分析将产生不同的解。该解是一个最大生长速率，可通过实验证实或否定。新解处的生长速率提供了敲除表型的度量。如果这些基因敲除实际上是致死的，则最优解将是生长速率为零。

Edwards、Palsson（1900）的研究探索了敲除表型预测在预测大肠杆菌（一种原核生物）中酶敲除后代谢变化方面的应用[?]。换句话说，构建了一个大肠杆菌的计算机代谢模型，以模拟影响糖酵解、戊糖磷酸、TCA和电子传递途径的突变（包含436种代谢物和719个反应）。对于每种特定条件，将突变体的最优生长与非突变体进行比较。随后比较了体内和计算机结果，一致率为86%。模型中的错误表明模型尚不完善（知识不足）。作者讨论了FBA未能模拟的7个错误，包括突变体抑制稳定RNA合成和产生毒性中间产物。

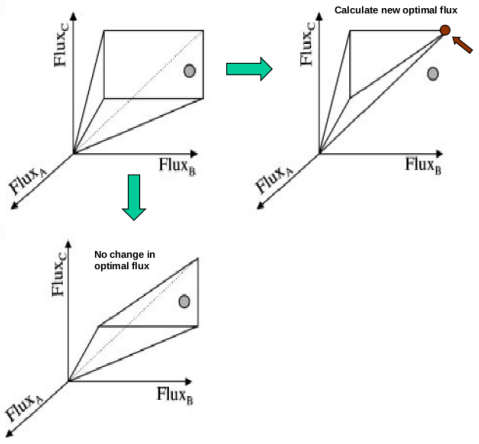

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图23.5：约束可行解空间可能会产生一个新的最优通量。

23.4.2 Quantitative Flux *In Silico* Model Predictions

模型能否定量预测通量和生长速率？我们展示了FBA在不同环境条件下对生长速率和反应通量给出定量预测的能力。更具体地说，预测指的是作为受控摄取速率和环境条件函数的外部可测量通量。由于FBA最大化一个目标函数，从而得到该函数的一个特定值，理论上我们应该能够从模型中提取定量信息。

Edwards、Ibarra和Palsson（1901）的一个早期例子预测了在大肠杆菌培养中，给定一系列固定的氧气和两种碳源（乙酸盐和琥珀酸盐）摄取速率下的生长速率，这些条件他们可以在批次反应器中控制[6]。他们假设大肠杆菌细胞在特定环境条件下调整其代谢以最大化生长（使用生长目标函数），并利用FBA来模拟该细菌中的代谢途径。该特定模型的输入为乙酸盐和氧气，标记为V_{IN}。

受控的摄取速率固定了网络中氧气和乙酸/琥珀酸输入通量的值，而其他通量则被计算以最大化生长目标的值。

增长率仍被视为FBA分析的解。总之，最优增长率被预测为氧气与乙酸盐以及氧气与琥珀酸盐 uptake 约束的函数。基本模型是一个预测线，可以通过在生物反应器中实验测量批式反应器的 uptake 和生长来确认（注意：实验 uptake 未被约束，仅被测量）。

Palsson的这一模型是首个良好的原理性计算机模拟模型。作者在不同条件下的定量生长速率预测与实验观察到的生长速率非常吻合，这意味着大肠杆菌确实拥有一个旨在最大化生长的代谢网络。该模型具有高的真阳性率和真阴性率。对于一个仅包含化学计量信息而不包含任何动力学信息的模型来说，预测与实验结果之间的一致性令人印象深刻。然而，Galagan教授提醒说，判断何为良好一致性往往很困难，因为我们不知道残差大小的意义。该生物体在多种不同的营养物质上生长。因此，研究人员能够预测特定条件下的生长。请记住，这一方法之所以有效，是因为某些基因仅对特定营养物质是必需的，比如糖异生中的fbp基因。因此，敲除fbp仅在没有葡萄糖的环境中才会致命，这是一个特定条件，在通过FBA分析时会导致生长解决方案。

23.4.3 Quasi Steady State Modeling (QSSM)

我们现在可以描述如何使用FBA通过准稳态建模来预测生长速率和代谢物浓度随时间的变化。之前的例子使用FBA在特定环境条件下进行定量生长预测（点预测）。现在，在生长和摄取通量之后，我们转向另一个假设和类型的模型。

我们能否使用代谢的稳态模型来预测细胞或环境中随时间变化的改变？我们确实必须做出一些准稳态假设 (QSSA)：

1. 代谢比环境/细胞变化本身更快地适应这些变化。

2. 细胞和环境浓度是动态变化的，但代谢是在每个时间点浓度静态（稳态模型）的条件下运作的。

是否可以使用 QSSM 来预测随时间变化的代谢动态？例如，如果随着培养物生长，每个细胞摄入的乙酸盐减少，那么生长速率必然减慢。但现在，应用了 QSSA 假设。也就是说，实际上，在任何给定时间点，生物体都处于稳态。

FBA问题的解能得到哪些值？有通量，还有生长速率。我们正在预测速率和通量（解），其中包含VIN/OUT。到目前为止，我们假设输入和输出是无限的汇和源。为了对底物/生长动力学建模，分析过程与先前的定量通量分析略有不同。我们首先将时间划分为多个时间片 δt。在每个时间点 t，我们使用FBA来预测间隔 δt 内的细胞底物摄取（Su）和生长（g）。QSSA意味着这些预测在 δt 上是恒定的。然后我们进行积分，以得到下一个时间点 $t + \delta t$ 的生物量（B）和底物浓度（Sc）。因此，新的VIN每次都会基于中间时间点 δt 来计算。这样我们就可以预测生长速率以及葡萄糖和乙酸的摄取（环境中可用的营养物质）。四步分析是：

1. 在时间t时的浓度由最后一步的底物浓度加上通过流入提供给细胞培养的任何额外底物决定，例如在补料分批培养中。

2. 底物浓度根据时间和生物量（X）进行缩放，以确定细胞可利用的底物量。这可能超过细胞的最大摄取速率，也可能低于该数值。

3. 使用通量平衡模型评估实际底物摄取速率，该速率可能高于或低于步骤2确定的可用底物量。

4. 然后通过积分标准微分方程来计算下一时间步的浓度：

$$\frac{dB}{dt} = gB \rightarrow B = B_o e^{gt}$$

$$\frac{dSc}{dt} = -SuB \rightarrow Sc = Sc_o \frac{X}{g}(e^{gt} - 1)$$

Varma等人（1994）的额外工作先验地指定了葡萄糖摄取速率[17]。模型模拟用于预测生长、氧气摄取和乙酸盐分泌的时间依赖性变化。这

逆向模型将摄取速率与生长进行作图，同时在体内和计算机模拟中仍能获得可比的结果。研究人员使用准稳态建模来预测*E. coli*分批培养中细胞生长和代谢物浓度的时变分布，这些培养物要么初始葡萄糖供应有限（左图），要么葡萄糖缓慢连续供应（右图）。拟合效果显著。

上图展示了模型预测结果（实线）与实验结果（各个数据点）的对比。因此，在*E. coli*中，即便模型未考虑酶表达水平随时间的变化，准稳态预测的准确性仍令人印象深刻。然而，该模型不足以描述已知涉及基因调控的行为。例如，若细胞生长在半葡萄糖/半乳糖培养基上，模型将无法预测从一种碳源到另一种碳源消耗的转换。（当*E. coli*仅在葡萄糖缺失时激活替代碳利用途径，实验中确实会发生这种情况。）

23.4.4 Regulation via Boolean Logic

有多个层次的调控机制通过代谢物、转录、翻译及翻译后水平来控制代谢通量。FBA相关的误差可能通过将基因调控信息纳入模型来解释。实现这一点的一种方法是布尔逻辑。下表描述了在特定营养物质存在下，相关酶的基因是否开启或关闭（这是纳入上述提到的*E. coli*偏好的一个示例）：

开启 无葡萄糖(0)	开启 乙酸酯存在(1)
开启 葡萄糖存在(1)	关 乙酸酯存在(1)

因此，人们可能会认为下一步是将这一事实纳入模型中。例如，如果环境中存在葡萄糖，那么与乙酸处理相关的基因就会关闭，因此不会出现在S矩阵中，而由于将调控纳入我们的模型，S矩阵现在变得动态了。最终，我们的模型并不是定量的。基本的调控描述了如果一个营养物质处理酶开启，另一个就会关闭。基本上，这是一堆基于酶、代谢物、基因等存在的布尔逻辑。这些布尔风格的假设随后在时间dt的每一个微小变化中用于评估生长速率、通量等变量。然后，根据预测的通量、V_{IN}、V_{OUT}以及系统状态，人们可以利用逻辑来开启和关闭基因，实际上就是每个δt对应一个δS。我们可以开始把上述所有分析整合起来，提出一种代谢建模的通用方法。我们可以说，如果糖酵解开启，那么糖异生必定关闭。

首次将调控机制纳入FBA模型的尝试由Covert、Schilling和Palsson于1901年发表[7]。研究人员通过将基因调控近似为布尔过程，将一组已知的转录调控事件纳入了他们对代谢调控网络的分析中。一个反应是否发生取决于酶和底物的同时存在：如果催化该反应的酶（E）未表达或底物（A）不可用，则该反应通量将为零：

$$\text{rxn} = \text{IF (A) AND (E)}$$

类似的布尔逻辑根据当前表达的基因和当前的环境条件来决定酶是否表达。例如，只有当适当的基因（G）可供转录且没有抑制因子（B）存在时，酶（E）才会发生转录：

$$转 = \text{IF (G) AND NOT (B)}$$

作者运用这些原则设计了一个布尔网络，该网络输入所有相关基因的当前状态（开或关）及所有代谢物的当前状态（存在或不存在），并输出一个包含这些基因和代谢物各自新状态的二进制向量。布尔网络的规则基于实验确定的细胞调控事件构建。将反应及酶/代谢物浓度视为二进制变量虽不允许定量分析，但此方法与FBA结合时，能预测代谢通量的定性变化。当某种酶缺失时，相应的列会从FBA反应矩阵中移除，如前所述用于敲除表型预测。这导致了一个迭代过程:

1. 给定所有基因和代谢物的初始状态，利用布尔网络计算新状态;
2. 根据酶的状态，从矩阵中删除相应的列后执行FBA，以确定新的代谢物浓度;
3. 使用新的代谢物浓度重复布尔网络计算；等等。上述模型不是定量的，而只是对任何特定时刻基因开启和关闭的纯模拟。

在少数代谢反应中，存在关于允许生物转换碳源（C1、C2）的规则。

Covert等人的研究[7]中，该方法的一个应用是模拟二次生长现象，即当首选碳源不可用时，从代谢首选碳源转向另一种碳源的过程。所建模的过程包括两种基因产物：调控蛋白RPc1，它能感知（被激活）Carbon 1；以及转运蛋白Tc2，负责转运Carbon 2。如果RPc1被Carbon 1激活，Tc2将不会被转录，因为细胞优先利用Carbon 1作为碳源。若Carbon 1不可用，细胞将转而依赖基于Carbon 2的代谢途径，并启动Tc2的表达。

布尔值可以表示这个信息:

$$\text{RPc1} = \text{IF(碳1) Tc2} = \text{IF NOT(RPc1)}$$

Covert等人发现，这种方法对代谢的预测与实验诱导的双峰生长转换结果相吻合。这种双峰生长转换通过上文图中的计算机模拟分析得到了很好的建模。在A阶段，C1作为营养物质被消耗，伴随生长发生。在B阶段，由于C1耗尽且C2处理酶尚未生成——因为相关基因还未被激活（或正在激活过程中）——因此没有生长，生物量保持恒定，出现延迟。在C阶段，C2的酶被激活，随着生物体利用新营养源继续生长，生物量增加。因此，若无C1，则会消耗C2。随着C1耗尽，生物体通过基因调控改变代谢活动，并开始吸收C2。调控预示了双峰生长现象，即优先利用C1而后利用C2。若缺乏调控，系统将同时利用C1和C2生长至最大生物量。

到目前为止，我们已经讨论了使用这种结合FBA-布尔网络的方法来模拟转录/翻译水平上的调控，该方法同样适用于其他类型的调控。主要局限性在于对缓慢形式的调控，因为该方法假设调控步骤在单个时间间隔内完成（由于布尔计算在每个FBA时间步进行，并未考虑系统先前状态）。这对于任何至少与转录/翻译速度相当的调控形式来说是可行的。例如，酶的磷酸化（一种酶激活过程）非常迅速，可以通过将磷酸化酶的存在纳入布尔网络中来建模。

然而，发生在更长时间尺度上的调控，如mRNA的隔离，并未被此模型考虑。这种方法还存在一个根本问题，即它不允许在相关时间点输入基因表达水平的实际实验测量值。

我们不需要模拟来人为预测某些基因是否开启或关闭。微阵列表达数据使我们能够确定哪些基因正在表达，这一信息可以被纳入我们的模型中。

23.4.5 Coupling Gene Expression with Metabolism

在实践中，我们无需人为构建基因水平模型，而是可以直接测量它们。如前所述，可以测量给定样本中所有mRNA的表达水平。由于mRNA表达数据与蛋白质表达数据相关联，将其纳入FBA将极为有用。通常，来自微阵列实验的数据会被聚类，未知基因被推测具有与其聚类在一起的已知基因相似的功能。然而，这种分析可能存在问题，因为具有相似作用的基因并不总是聚集在一起。将微阵列表达数据整合到FBA中，可为数据解读提供另一种方法。由此引出一个问题：基因水平与通过某一反应的通量之间有何关系?

假设反应 $A \rightarrow B$ 被一种酶催化。如果存在大量的 A，酶基因表达的增加会导致反应速率增加。否则，增加基因表达水平不会提高反应速率。然而，鉴于底物也具有合理的生理限制，酶浓度可以被视为最大可能通量的约束条件。

接下来，需要将mRNA表达水平与酶浓度关联起来。这更加困难，因为细胞有多种调控机制来独立于mRNA浓度控制蛋白质浓度。例如，翻译后的蛋白质可能需要额外的激活步骤（如磷酸化），每个mRNA分子在被降解前可能被翻译成不同数量的蛋白质（如通过反义RNA），mRNA翻译成蛋白质的速率可能比FBA每一步考虑的时间间隔更慢，蛋白质降解速率也可能较慢。尽管存在这些复杂因素，微阵列实验得到的mRNA表达水平通常被视为每个测量时间点上可能酶浓度的上限。鉴于上述酶浓度与通量之间的关系，这意味着mRNA表达水平也是由其编码蛋白质所催化反应的最大可能通量的上限。这一假设的有效性仍在争论中，但它在FBA分析中已经表现良好，并且与最近的证据一致，即细胞主要通过调节mRNA水平来控制代谢酶水平。（1907年，Galagan教授讨论了Zaslaver等人（1904年）的一项研究，该研究发现氨基酸生物合成途径所需的基因根据需要依次转录[2]）。这一假设对于将微阵列表达数据纳入FBA特别有用，因为FBA利用最大通量值来约束通量平衡锥。

Colijn等人探讨了表达数据与代谢网络的算法整合问题[3]。他们应用FBA来模拟代谢网络中每个反应的最大通量。例如，如果有来自在葡萄糖上生长的生物体和在醋酸盐上生长的生物体的微阵列数据，两个数据集之间很可能会观察到显著的调控差异。V_{max}告诉我们所能达到的最大值。微阵列检测转录本的水平，并给出了V_{max}的上限。

除了预测不同环境条件下的代谢途径外，FBA和微阵列实验还可以结合使用，以预测在不同药物治疗下代谢系统的状态。例如，几种结核病药物靶向霉菌酸生物合成。霉菌酸是细胞壁的主要成分。在Boshoff等人1904年的一篇论文中，研究人员测试了75种药物、药物组合和生长条件，以

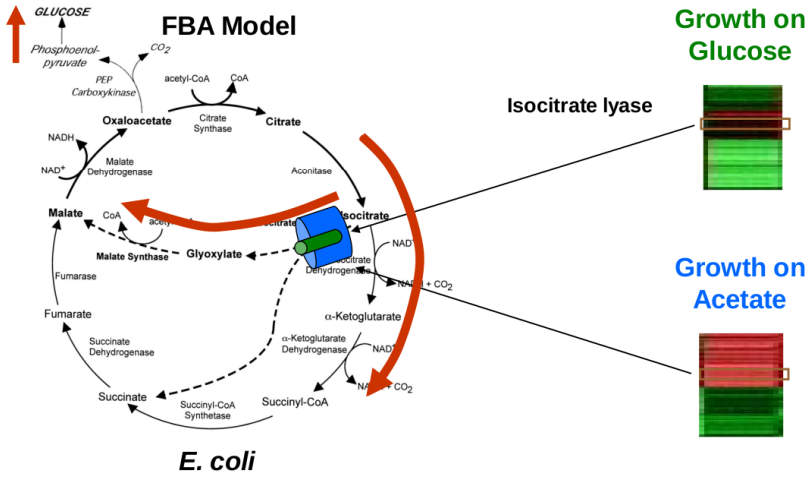

图23.6：Coljin等人的模型 [3]

由作者提供。许可证：CC BY。来源：Colijn, Caroline, et al. "Interpreting Expression Data with Metabolic Flux Models: Predicting Mycobacterium Tuberculosis Mycolic acid Production." *PLoS Computational Biology* 5, no. 8 (2009): e1000489.

看看不同处理对分枝菌酸合成有什么影响[9]。1905年，Raman等人发表了分枝菌酸生物合成的FBA模型，包含197个代谢物和219个反应[13]。

预测的基本流程是：针对特定的一组基因，取一个对照表达值和一个处理表达值，然后将这一信息输入FBA，并测量处理对分枝菌酸生产的最终效应。为了检查预测的抑制剂和增强剂，他们检查了显著性，即检查效应是否由噪声引起，以及特异性，即检查效应是由分枝菌酸引起，还是由代谢的整体抑制/增强引起。结果相当令人鼓舞。FBA鉴定出了几种已知的分枝菌酸抑制剂。在并非特别已知会抑制分枝菌酸合成的药物中也发现了有趣的结果。预测出了4种新型分枝菌酸合成抑制剂和2种新型增强剂。一种特定药物三氯生，根据FBA模型似乎是增强剂，而目前它被认为是抑制剂。对这种特定药物的进一步研究将会很有趣。实验测试和验证目前正在进行中。

聚类在识别各种处理的功能方面也可能无效。肉豆蔻酸合成的预测抑制剂和预测增强子并未聚集在一起。此外，基于FBA的算法分类不需要标记训练集，而监督聚类算法则需要。

23.4.6 Predicting Nutrient Source

现在，我们有了通过观察表达数据并寻找相关的营养物处理基因表达，来预测生物体在环境中可能利用的营养源的想法。这更容易，因为我们无法进入环境测量所有化学物质水平，但我们可以相当容易地获取表达数据。也就是说，我们尝试基于生物体很可能根据可用营养物调整代谢状态的假设，通过从表达数据预测代谢状态来预测营养源。然后可以根据营养物与代谢状态的匹配程度对它们进行排序。

反过来也可能行得通。给定一种状态，我能预测某种营养素吗？这样的预测可能有助于确定自然生活环境未知的生物的营养需求，或确定生物如何改变其环境。（例如，结核分枝杆菌能够生活在巨噬细胞吞噬溶酶体的环境中，大概是通过改变其中的环境条件来实现的

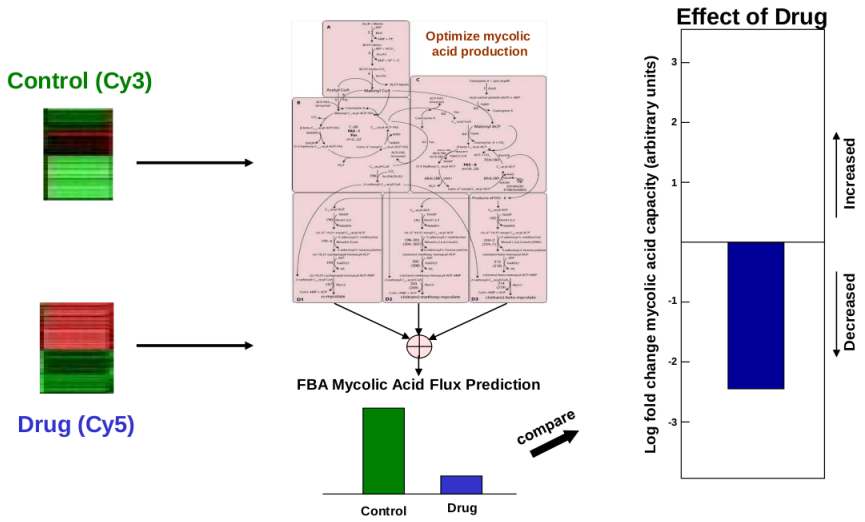

图23.7：在不同药物治疗下预测代谢系统状态的基本流程（吞噬溶酶体并阻止其成熟。）

由作者提供。许可证：CC BY。来源：Colijn, Caroline, et al. "Interpreting Expression Data with Metabolic Flux Models: Predicting Mycobacterium Tuberculosis Mycolic Acid Production." *PLoS Computational Biology* 5, no. 8 (2009): e1000489。

我们可以使用FBA来定义一个可能的代谢状态空间并从中选择一个。基本步骤是：

- 从最大通量锥开始（代表在环境中所有营养物质可用时的最佳生长）。为每种营养物质找到最优通量。
- 应用表达数据集（仍不知道营养物）。这将允许你约束锥形并找出营养物，其表示为与最优解距离最近的那个。

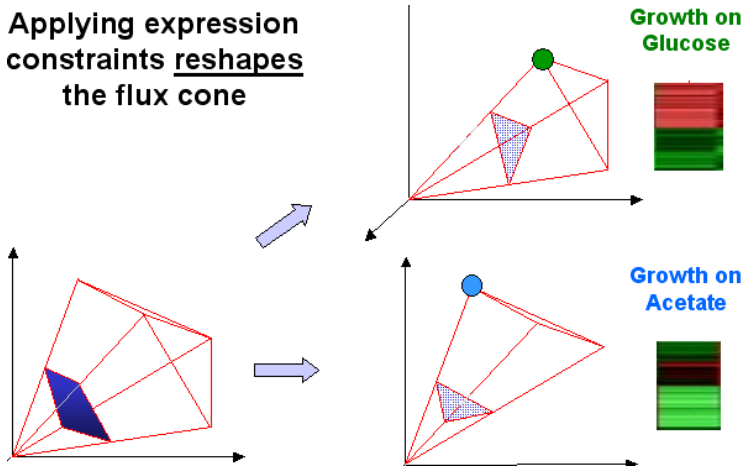

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/。

图23.8：应用表达式数据集可约束锥体形状。

在图8中，你可能会看到第一个锥体有多个最优解，因此实际的营养物是未知的。然而，在应用表达数据后，锥体被重塑。它只有一个最优解，这仍然在可行空间内，因此必定是你正在寻找的营养物。

和之前一样，测得的表达水平对反应通量施加约束，从而改变了形状。

通量平衡锥（现为表达约束的通量平衡锥）的。FBA可用于确定在这些表达约束内最大化生长的最优通量集合，并且可以将这组通量与在每个感兴趣的环境条件下通过实验确定的最优生长模式进行比较。生物体的计算状态与每种条件下的最优状态之间的差异，是衡量如果生物体实际上在该条件下生长时，其当前代谢状态会有多不最优的一种度量。

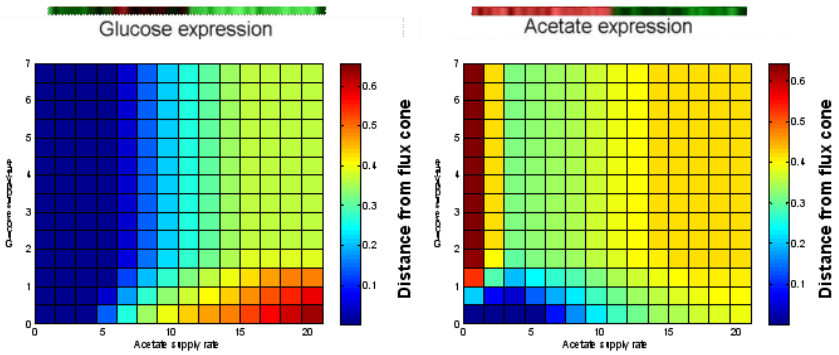

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

F图23.9：营养源预测实验结果 nt.

来自生长和代谢的表达数据随后可用于预测正在使用的碳源。例如，考虑大肠杆菌营养产物。我们可以针对葡萄糖与乙酸盐模拟该系统。颜色表示从受约束的通量锥到该营养组合的最优通量解的距离（步骤同上）。然后，可根据表达数据对多种营养物进行排序、确定优先级。来自Desmond Lun和Aaron Brandes的未发表数据提供了这种方法的一个示例。

他们使用FBA根据基因表达数据预测大肠杆菌培养物在哪种营养源上生长。他们将每种营养条件下的已知最优通量（通量空间中的最优点）与表达约束的通量平衡锥内允许的最优通量值进行了比较。那些最优通量保持在该表达约束锥内（或最接近该锥）的营养条件最有可能是培养物实际环境的可能性。

实验结果如图9所示，其中结果矩阵中的每个方块根据该营养条件下的最优通量与基于表达数据计算得到的最优通量之间的距离进行着色。红色值表示与表达约束通量锥的距离较大，蓝色值表示与通量锥的距离较小。例如，在葡萄糖-乙酸盐实验中，左侧实验的结果表明低乙酸盐条件是最可能的（并且培养物中的营养物质是葡萄糖），右侧实验的结果表明低葡萄糖/中等乙酸盐条件是最可能的（并且培养物中的营养物质是乙酸盐）。当考虑6种可能的营养物质时，模型总是预测出正确的那一种；当考虑18种可能的营养物质时，正确的那一种总是在排名前4的预测之中。这些结果表明，可以利用表达数据和FBA建模，根据关于生物体代谢状态的信息来预测环境条件。

这很重要，因为结核杆菌在免疫系统中的巨噬细胞内利用脂肪酸。我们并不确切知道哪些脂肪酸被利用。通过分析在生长阶段等时期哪些相关营养处理基因被激活，我们可以弄清楚结核杆菌在其环境中作为食物来源和增殖因子所看到的是什么。从而，我们可以确定它生长所需的营养物质，为通过不提供这些营养物质或敲除那些特定基因来消灭它提供了可能的方法。

更容易得到表达式 相比查看正在消耗的内容，查看通量活动所需的数据 环境通过

在如此微小的层面上分析化学反应。此外，我们可能无法在实验室中培养某些细菌，但我们可以通过从自然环境中生长的细菌获取表达数据，然后观察它利用什么来生长，从而解决这个问题。接着，我们可以将其添加到实验室培养基中，以成功培养这些细菌。

23.5 Current Research Directions

23.6 Further Reading

- Becker, S. A. 和 B. O. Palsson (1908). 上下文特异性代谢网络与实验一致。PLoS 计算生物学 4(5): e1000 082。– 如果基因表达低于某个阈值，则在模型中关闭该基因。

- Shlomi, T., M. N. Cabili, et al. (1908). 基于网络的人类组织特异性代谢预测. Nat Biotech 26(9): 1003-1010.

  – 嵌套优化问题。– 首先，标准FBA – 其次，最大化预测通量活性为*consistent with their*的酶的数量 *measured expression level*

23.7 Tools and Techniques

- 凯格
- BioCyc
- 通路浏览器 (`pathwayexplorer.genome.tugraz.at`)
- 加州大学圣地亚哥分校的Palssons小组（`http://gcrg.ucsd.edu/`）
- `www.systems-biology.org`
- BioModels数据库（`www.ebi.ac.uk/biomodels/`）
- JWS模型数据库（`jjj.biochem.sun.ac.za/database/index.html`）

23.8 What Have We Learned?

Bibliography

[1] [2] Zaslaver A, Mayo AE, Rosenberg R, Bashkin P, Sberro H, Tsalyuk M, Surette MG, and Alon U. 代谢途径中的即时转录程序。*Nat. Gen*, 36:486–491, 2004。

[3] Caroline Coljin。利用代谢通量模型解读表达数据：预测结核分枝杆菌霉菌酸产量。
PLoS Computational Biology，5(8)，2009年8月。[4] Price N. D.，Reed J. L.，Papin J.A，Famili I.，和Palsso n B.O. 使用极端途径矩阵的奇异值分解分析代谢能力。*Biophys J.*，84(2)：794–804，2003年2月。[5] Gastei ger E.，Gattiker A.，Hoogland C. 和Ivanyi I.，Appel R.D.，以及Bairoch A. Expasy：用于深入蛋白质知识与分析的蛋白质组学服务器。*Nucleic Acids Res*，31(13)：3784–3788。[6] J.S. Edwards，R. U. Ibarra，和B.O. Pal sson。大肠杆菌代谢能力的计算机模拟预测与实验数据一致。*Nat Biotechnology*，19：125–130，2001年。[7] Covert M等。代谢通量平衡模型中基因表达的调控。*Journal of Theoretical Biology*，213：73–88，2001 年11月。[8] J. Forster，I. Famili，B.O. Palsson，和J. Nielsen。酿酒酵母计算机模拟基因缺失的大规模评估。 *OMICS*，7(2)：193–202，2003年。PMID：14506848。[9] Boshoff H.I.，Myers T.G.，Copp B.R.，McNeil M. R.，Wilson M.A.，和Bary C.E. 结核分枝杆菌对代谢抑制剂的转录响应：对药物作用机制的新见解。
J Biol Chem，279：40174–40184，2004年9月。[10] Holmberg。关于包含Michaelis-Menten型非线性的微生物生长模型的实际可识别性。*Mathematical Biosciences*，62(1)：23–43，1982年。[11] Edwards J.S. 和Palsso n B.O. 第97卷，第5528–5533页。美国国家科学院院刊，2000年5月。PMC25862。[12] Edwards J.S.，Covert M.，和Palsson B. 微生物代谢建模：通量平衡方法。*Environmental Microbiology*，4(3)：133–140，2002年。 [13] Raman Karthik，Preethi Rajagopalan，和Nagasuma Chandra。霉菌酸途径的通量平衡分析：抗结核药物的靶点。*PLoS Computational Biology*，1，2005年10月。[14] Kanehisa M.，Goto S.，Kawashima S.，和Nakaya 。从基因组学到化学基因组学：KEGG的新进展。*Nucleic Acids Res.*，34，2006年。[15] Jamshidi N. 和Palss on B. 使用计算机模拟菌株iNJ661研究结核分枝杆菌H37Rv的代谢能力并提出替代药物靶点。
BMC Systems Biology，26，2007年。

[16] Caspi R., Foerster H., Fulcher C.A., Kaipa P., Krummenacker M., Latendresse M., Paley S., Rhee S.Y., Shearer A.G., Tissier C., Walk T.C. ZhangP., 和 Karp P. 代谢途径和酶的metacyc数据库以及途径/基因组数据库的biocyc集合。*Nucleic Acids Res*, 36(Suppl), 2008.

[17] A. Varma 和 B. O. Palsson. 化学计量通量平衡模型定量预测野生型大肠杆菌W3110的生长及代谢副产物分泌。《*Applied and Environmental Micro- biology*》，60:3724–3731，1994年10月。

CHAPTER

TWENTYFOUR

ENCODE项目：系统化实验与整合基因组学

Figures

24.1 ENCODE项目实验矩阵快照。 . . . . . 380 24.2 Chip-seq概述 [3] . . . . . 381 24.3 ENCODE统一处理流程 . . . . . 382 24.4 正反链信号偏移，互相关图 . . . . . 382 24.5 使用IDR评估ChIP-seq数据集的可重复性。散点图显示了在每个重复对中重叠的峰信号得分。(A,B) 高质量重复的结果。(C) 不同排名阈值下的估计IDR。[1] 383

24.1 Introduction

人类基因组于2003年被测序，这是理解生命蓝图的重要一步。然而，在充分利用这些信息之前，必须确定所有蛋白质编码和非蛋白质编码基因的位置、身份和功能。此外，人类基因组还有许多其他功能元件，从启动子、调控序列到决定染色质结构的其他因素。为了全面理解人类基因组，这些也必须被确定。

ENCODE（DNA元件百科全书）项目旨在通过描绘人类基因组的所有功能元件来解决这些问题。为了实现这一目标，成立了一个联盟来指导该项目。该联盟旨在推进和开发以更高准确性、完整性和成本效益对人类基因组进行注释的技术，{v*}

以及更多的标准化。他们还旨在开发一系列计算技术，以解析和分析所获取的数据。

为了实现这一目标，启动了一个试点项目。ENCODE试点项目旨在深入研究人类基因组的1%，大致从2003年到2007年。从2007年到2012年，ENCODE项目逐步扩大，以注释整个基因组。最后，从2012年起，ENCODE项目旨在在所有维度上进一步增加：更深入的测序、更多的实验、更多的转录因子等。

本章将介绍ENCODE项目中使用的部分实验和计算技术。

24.2 Experimental Techniques

ENCODE项目使用了广泛的实验技术，包括RNA-seq、CAGE-seq、外显子阵列、MAINE-seq、染色质ChIP-seq、DNase-seq等众多方法。

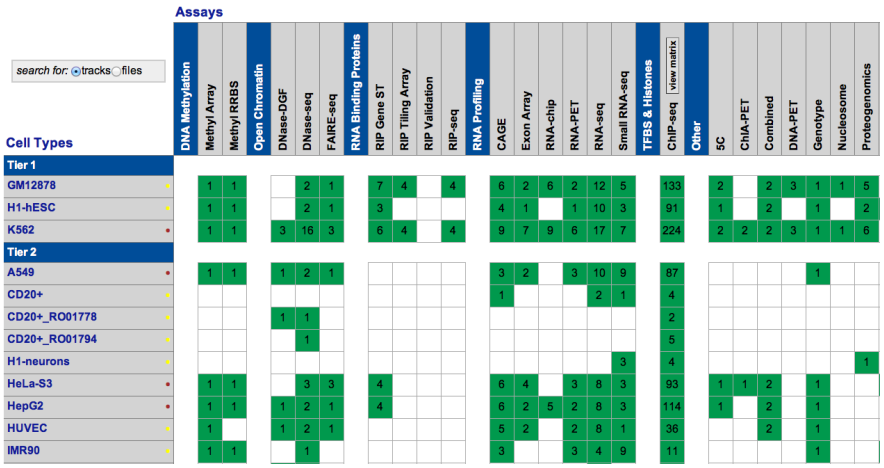

图24.1：ENCODE项目实验矩阵快照。

© ENCODE 项目。保留所有权利。此内容不在我们的知识共享许可范围内。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

最重要的技术之一是ChIP-seq（染色质免疫共沉淀后测序）。ChIP实验的第一步是靶向与特定蛋白质相关的DNA片段。这是通过使用针对特定蛋白质的抗体来免疫沉淀DNA-蛋白质复合物实现的。最后一步是检测DNA。这将确定与蛋白质结合的序列。

ChIP-seq相较于先前技术（如ChIP-chip）具有若干优势。例如，ChIP-seq具备单核苷酸分辨率，且其可比对性随读长增加而提高。然而，ChIP-seq也存在一些不足。测序错误在读数末端附近往往显著增多。此外，在读数数量较低时，检测富集区域的灵敏度和特异性往往会下降。这两个问题都在数据处理时出现，许多计算技术旨在对此进行修正。

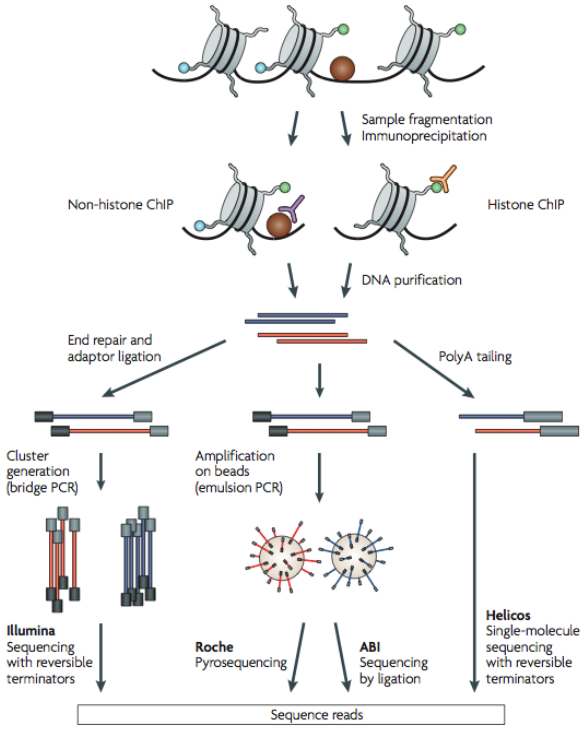

图24.2：Chip-seq概览[3]

由麦克米伦出版有限公司提供。经许可使用。来源：Park, Peter J. “ChIP–seq：成熟技术的优势与挑战。” *Nature Reviews Genetics* 10, no. 10 (2009): 669-80。

24.3 Computational Techniques

本节将重点介绍处理ENCODE项目原始数据的技术。在分析ENCODE数据之前（例如进行模体发现、共关联分析、元素上的信号聚合等），必须对原始数据进行处理。

即使在数据处理之前，也会应用一些质量控制。质量控制之所以必要，有多个原因。即使没有抗体，读取片段也不是均匀分布的。生物学原因包括基因组的不均匀断裂、开放染色质区域更容易断裂，以及组装基因组中重复序列的过度折叠。ENCODE项目以多种方式校正了这些偏差。在ChIP步骤之前，部分DNA被移除，从而去除了大量不需要的数据。对照实验也在不使用抗体的情况下进行。最后，片段输入DNA序列读取被用作背景。

由于ChIP-seq过程中固有的噪声，一些读段的质量会较低。通过使用读段质量指标，低于阈值的读段被剔除。

较短的读段（以及程度较轻的较长读段）可以映射到基因组中恰好一个位置（唯一映射）、多个位置（重复映射）或完全没有位置（无法映射）。处理重复映射有许多潜在方法，从概率性地分散读段到使用EM方法。然而，由于ENCODE项目力求尽可能正确，它不会将重复读段分配到任何位置。

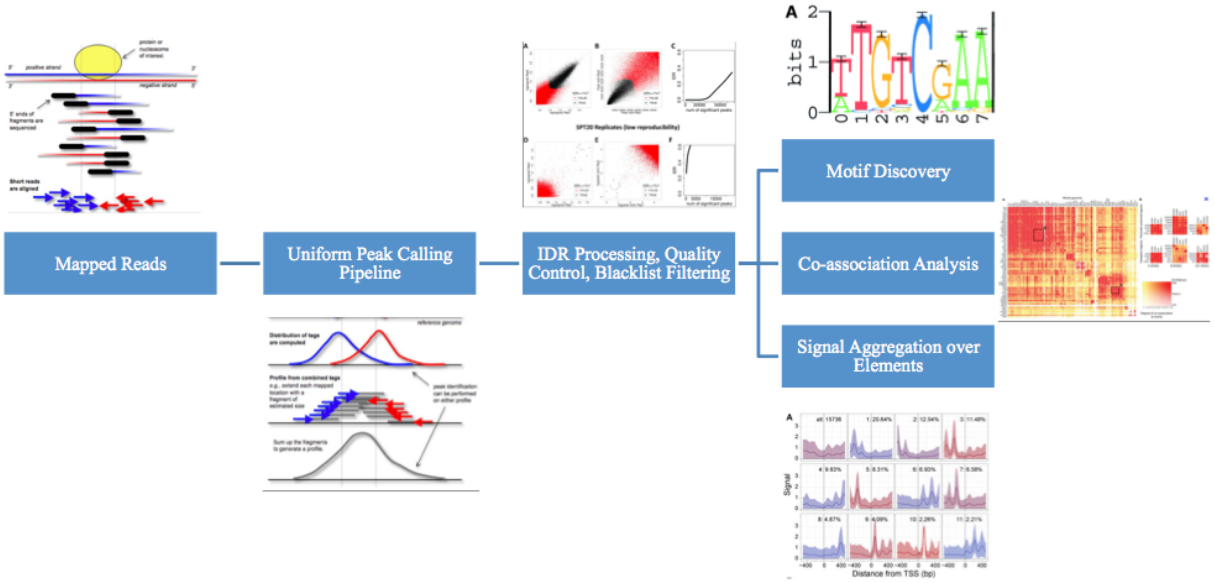

图24.3：ENCODE统一处理流程

© ENCODE 项目。保留所有权利。此内容不在我们的知识共享许可范围内。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

如果样本中DNA含量不足和/或测序过度，你将会反复对一组有限且独特的DNA片段的PCR duplicates进行测序。这种情况被称为低复杂度文库，是我们不希望出现的。为了解决这个问题，会创建一个显示重复数量的直方图，并剔除具有低非冗余分数(NRF)的样本。

ChIP-seq从每个片段的一端随机测序，因此为了确定哪些读段来自哪个片段，通常使用链交叉相关分析[图04]。为了实现这一点，首先计算正向和反向链信号，然后逐步将它们相互移动。在每一步中，都会计算相关性。在片段长度偏移量f处，相关性达到峰值。f是ChIP DNA被片段化的长度。通过进一步分析，我们可以确定在片段长度上应具有高绝对交叉相关性，并且相对于读长交叉相关性，片段长度交叉相关性较高。RSC（相对链相关性）应大于1。

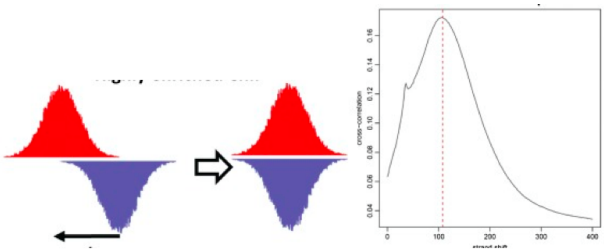

图24.4：移位正向和反向链信号，互相关图

$$RSC = \frac{CC_{fragment} - min(CC)}{CC_{readlength} - min(CC)} \tag{24.1}$$

一旦应用质量控制，数据会进一步处理以确定实际的富集区域。为此，ENCODE项目使用了峰调用的修改版本。现有许多峰

调用算法，但ENCODE项目使用了MACS和PeakSeq，因为它们是确定性的。然而，无法设定统一的p值或错误发现率（FDR）常数。FDR和p值取决于ChIP和输入测序深度、因子的结合普遍性，并且高度不稳定。此外，不同的工具需要不同的值。

ENCODE项目使用（同一实验的）重复样本并合并数据以找到更有意义的结果。简单的解决方案存在重大问题：取峰值的并集会保留两者的垃圾数据，交集过于严格并丢弃好的峰值，而取数据之和则没有利用数据集的独立性。相反，ENCODE项目使用独立发现率（IDR）。关键思想是真正的峰值在两个重复样本中都会排名靠前。因此，为了找到显著的峰值，按排名顺序考虑峰值，直到排名不再相关。

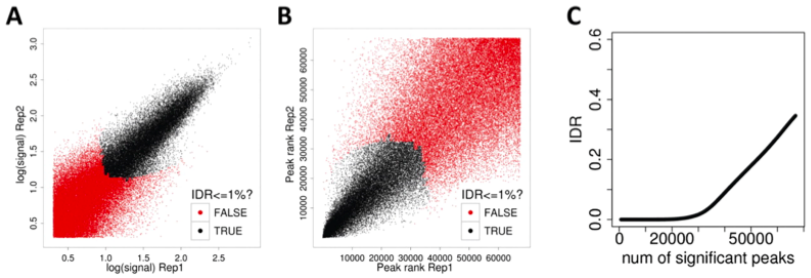

Courtesy of Cold Spring Harbor Laboratory Press. License: CC BY-NC.
Source: Landt, Stephen G., et al. "ChIP-seq Guidelines and Practices of the ENCODE and ModENCODE Consortia." *Genome Research* 22, no. 9 (2012): 1813-31.

图24.5：评估CHIP-seq数据集重复性的IDR。散点图展示了在每一对重复样本中重叠峰的信号得分。(A,B) 高质量重复样本的结果。(C) 不同等级阈值的估计IDR。[1]

两个重复样本的截断值可能不同，且实际包含的峰在重复样本间也可能有差异。它被建模为高斯混合模型，可以通过类似EM的算法进行拟合。使用IDR可以提高峰调用者之间的一致性。这是因为FDR仅依赖于相对于输入的富集，而IDR利用了重复样本。此外，通过采样方法，如果只有一个重复样本，仍可以使用伪重复样本执行IDR流程。

24.4 Current Research Directions

ENCODE项目仍在进行中。利用饱和技术，我们相信目前最多只发现了50%的元素。由于难以获取的细胞类型及其他因素，这一数字可能更低。此外，一些细胞类型极为罕见且难以获取，因此从这些细胞类型获取测序数据是另一大挑战。

在计算前沿领域，ENCODE项目产生了海量的原始数据。正如人类基因组全序列引发了一系列计算项目，ENCODE数据也可用于多种计算项目。

24.5 Further Reading

包含ENCODE论文的Nature网站位于http://www.nature.com/encode/。

官方 ENCODE 门户网站是 http://encodeproject.org/ENCODE/。

要浏览 ENCODE 数据，请访问 http://encodeproject.org/cgi-bin/hgHubConnect。

用于ENCODE数据处理的数据处理工具可在http://encodeproject.org/ENCODE/analysis. html处获得。

24.6 Tools and Techniques

ENCODE 数据挖掘，http://genome.ucsc.edu/cgi-bin/hgTables?db=hg18&hgta_group=regulation&hgta_track=wgEncodeHudsonalphaChipSeq

ENCODE 数据可视化，http://genome.ucsc.edu/cgi-bin/hgTracks?hgS_doOtherUser=submit&hgS_otherUserName=Kate&hgS_otherUserSessionName=encodePortalSession

用于分析ENCODE数据的软件和资源，http://genome.ucsc.edu/ENCODE/analysisTools. html

用于创建ENCODE资源的软件工具，http://genome.ucsc.edu/ENCODE/encodeTools. html

24.7 What Have We Learned?

本章概述了ENCODE项目，该项目旨在注释整个人类基因组。它利用CHIP-seq、RNA-seq和CAGE-seq等多种实验技术收集DNA序列。获取数据后，需经过一系列处理步骤，包括质量控制、峰调用、IDR处理以及黑名单过滤，方能进行分析。确保数据准确性后，可进行模体发现、共关联分析及元素上信号聚合等其他分析。

Bibliography

[1] S G Landt, G K Marinov, A Kundaje, P Kheradpour, F Pauli, S Batzoglou, B E Bernstein, P Bickel, J B Brown, P Cayting, Y Chen, G DeSalvo, C Epstein, K I Fisher-Aylor, G Euskirchen, M Gerstein, J Gertz, A J Hartemink, M M Hoffman, V R Iyer, Y L Jung, S Karmakar, M Kellis, P V Kharchenko, Q Li, T Liu, X S Liu, L Ma, A Milosavljevic, R M Myers, P J Park, M J Pazin, M D Perry, D Raha, T E Reddy, J Rozowsky, N Shoresh, A Sidow, M Slattery, J A Stamatoyannopoulos, M Y Tolstorukov,

K P White, S Xi, P J Farnham, J D Lieb, B J Wold, and M Snyder. ENCODE 和 modENCODE 联盟的 ChIP-seq 指南与实践。*Genome Research*, 22(9):1813–1831, 2012.

[2] Philippe Lefrançois, Ghia M Euskirchen, Raymond K Auerbach, Joel Rozowsky, Theodore Gibson, Christopher M Yellman, Mark Gerstein, 和 Michael Snyder. 使用多重短读DNA测序进行高效酵母ChIP-Seq. *BMC Genomics*, 10(1):37, 2009.

[3] P J Park. ChIP-seq：成熟技术的优点与挑战。*Nature reviews. Genetics*, 10(10)：669–680，2009年10月。

CHAPTER

TWENTYFIVE

PHARMACOGENOMICS

25.1 Introduction

25.2 Current Research Directions

25.3 Further Reading

25.4 Tools and Techniques

25.5 What Have We Learned?

Bibliography

CHAPTER

TWENTYSIX

SYNTHETIC BIOLOGY

Figures

26.1 机器人学与生物学中抽象层次的比较（感谢 Ron Weiss）。390 26.2 抑制振荡器基因调控网络。 . . . . . 390 26.3 在10小时内具有抑制振荡器电路的单个细胞的荧光。 . . . . . 390 26.4 合成一个碱基对的成本与美元对比 . . . . . 391 26.5 一个BioCompiler程序示例及其实现过程（感谢 Ron Weiss）392 26.6 一个组合来自 `http://2006.igem.org/wiki/index.php/Standard_Assembly` 的 BioBrick 片段的示例 393

26.1 Introduction

细胞就像机器人，它需要能够感知周围环境和内部状态，进行计算和判断，并完成一项任务或功能。新兴的合成生物学旨在使对细胞和蛋白质等生物实体的控制类似于设计机器人。合成生物学结合了技术、科学和工程，构建生物装置和系统以用于有益目的，包括解决健康、能源、环境和安全方面的世界性问题。

合成生物学涉及从DNA到组织的每一个生物学层次。合成生物学家的目标是创建类似数字计算机中的生物抽象层，以便高效地创建生物电路和程序。合成生物学的主要目标之一是开发一套标准化且定义明确的工具集，用于构建生物系统，使合成生物学家能够获得电气工程师构建复杂电路时可用的抽象层次。

合成生物学是一个相对较新的领域。迄今为止，合成基因回路的规模和复杂度一直较小，大约在六到十一个启动子的数量级。合成基因回路在总体规模上仍然较小。

图26.1：机器人学与生物学中抽象层次的对比（感谢Ron Weiss）。

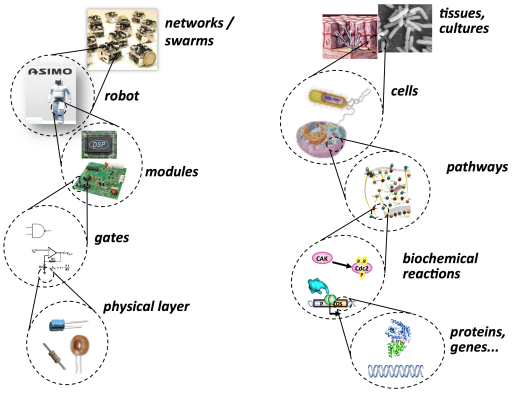

由EMBO与自然出版集团提供。经许可使用。来源：Andrianantoandro, Ernesto, et al. "合成生物学：新兴学科的新工程规则." *Molecular Systems Biology* 2, no. 1 (2006).

(10^3 - 10^5 碱基对)也与哺乳动物或其他动物的典型基因组大小(10^5 - 10^7 碱基对)相比。

合成生物学最早的一个里程碑发生在2000年，伴随着抑制振荡器的出现。抑制振荡器[2]是一种合成基因调控网络，其作用类似于具有固定时间周期的电子振荡器系统。在*E. coli*中表达了绿色荧光蛋白，并随时间的推移测量了荧光。在反馈回路中设置了三个基因，使得每个基因抑制回路中的下一个基因，并被前一个基因抑制。

图26.2：抑制振荡器基因调控网络。

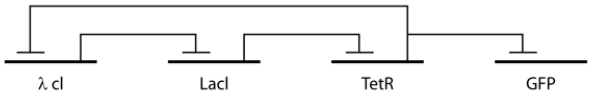

Courtesy of Timreid on wikipedia; in the public domain.

图26.3：含阻抑振荡器电路的单细胞在10小时内的荧光。

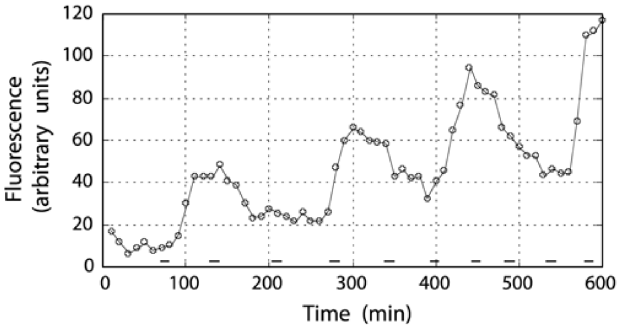

由 Macmillan Publishers Limited 提供。经许可使用。来源：Elowitz, Michael B., and Stanislas Leibler. "A Synthetic Oscillatory Network of Transcriptional Regulators." *Nature* 403, no. 6767 (2000): 335-8.

阻抑振荡器成功产生了荧光的周期性波动。它成为合成生物学最早的成功案例之一。过去十年中的其他成就包括程序化细菌种群控制、程序化模式形成、酵母中的人工细胞间通讯、通过转录因子的化学互补创建逻辑门，以及细菌基因组的完全合成、克隆和组装。

26.2 Current Research Directions

在DNA中编码功能是合成生物学家编程细胞的一种方式。随着DNA测序和合成成本的持续下降，编码DNA链已变得越来越可行。事实上，每美元能够合成的碱基对数量呈指数级增长，类似于摩尔定律。

图26.4：合成一个碱基对的成本与美元对比

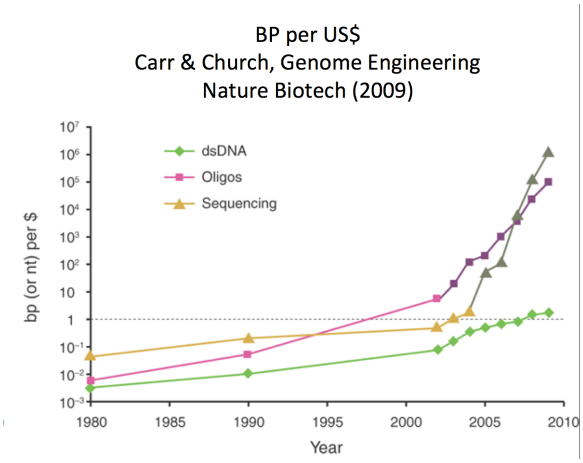

Courtesy of Macmillan Publishers Limited. Used with permission.
Source: Carr, Peter A. and George M. Church. "Genome Engineering."
Nature Biotechnology 27, no. 12 (2009): 1151-62.

这使得设计、构建和测试生物电路的过程变得更快、更便宜。合成生物学中的一个主要研究领域是快速、自动化地合成DNA分子以及创建具有所需DNA序列的细胞。创建这样一个系统的目标是加速生物系统设计和调试的过程，以便合成生物系统能够在快速、迭代的过程中进行原型制作和测试。

合成生物学还旨在开发具有标准化和明确定义行为的抽象生物组件，就像电气工程师可能从目录中订购的部件一样。为了实现这一目标，标准生物部件登记处（{v*}）[4]于2003年创建，目前包含超过7000个可供用户使用的部件。创建此类登记处的研究部分包括生物部件的分类和描述。目标是找到具有理想特性的部件，例如：

Orthogonality 监管者不应相互干涉。他们应当保持独立。

Composability 调节器可以融合以给出复合函数。

Connectivity 调节器可以串联在一起，以实现级联和反馈。

Homogeneity 调节器应遵循非常相似的物理规律。这保证了可预测性和效率。

合成生物学仍在发展之中，即便没有深厚领域背景的人也能进行研究。国际基因工程机器（iGEM）基金会（`http://igem.org`）[3]创办了iGEM竞赛，本科生和高中生在此竞赛中设计和构建能在活细胞内运作的生物系统。参赛学生团队在夏季初会收到一套生物部件工具包，并在各自机构开展工作以创建生物系统。一些有趣的项目包括：

Arsenic Biodetector 目标是开发一种细菌生物传感器，它能对一系列砷浓度作出响应，并产生与砷浓度相关的pH变化，这种变化可以被校准。该团队的目标是帮助许多欠发达国家，特别是孟加拉国，检测水中的砷污染。与其他检测器相比，所提出的设备旨在更经济、便携且更易于使用。

BactoBlood 加州大学伯克利分校的团队致力于开发一种由工程化大肠杆菌构建的经济高效的红细胞替代品。该系统旨在安全地在血液中运输氧气，而不引发败血症，并能以冻干状态长时间储存。

E. Chromi 剑桥团队项目致力于促进生物传感器的设计与构建。他们设计并表征了两种类型的部件——灵敏度调谐器和颜色生成器——经过工程改造的大肠杆菌，能够根据诱导剂浓度的不同产生不同的色素。这些部件的可用性彻底改变了未来生物传感器设计的路径。

26.3 Further Reading

26.4 Tools and Techniques

合成生物学融合了许多领域，而所使用的技术并非合成生物学所独有。与解决其他工程问题的过程非常相似，创建一个有用的生物系统的过程包括设计、构建、测试和改进阶段。一旦创建了生物系统期望特性的设计或陈述，问题就变成了寻找合适的生物组件来构建这样的系统。

BioCompiler [1] 是一款为使生物学电路能够使用高级编程语言进行编程而开发的工具。人们可以用类似于 LISP 的语言编写程序，并将其编译成生物电路。BioCompiler 采用类似于编程语言编译器的过程。它以人类编写的程序作为基因电路的高级描述，然后生成程序的形式化描述。在此基础上，它查找可以组合以创建基因电路的抽象遗传调控网络片段，并通过其 DNA 部件库查找合适的序列以匹配抽象遗传调控网络片段的功能。随后可以生成用于创建具有适当遗传调控网络的细胞的组装指令。

图26.5：一个示例 BioCompiler程序的，以及实现 提交它（归功于 Ron Weiss）

Flow chart removed due to copyright restrictions.

BioBrick标准生物部件（biobricks.org）是合成生物学中使用的另一种工具。与标准生物部件登记处中的部件类似，BioBrick标准生物部件是具有定义结构和功能的DNA序列。每个BioBrick部件都是一个DNA序列，被固定在一个环状质粒中。BioBrick的两端都包含已知且定义明确的序列，带有可在已知位置切割质粒的限制性内切酶。这使得可以通过将较小的BioBrick部件串联在一起来创建更大的BioBrick部件。iGEM竞赛中的一些参赛者使用BioBrick系统开发了一种*E.coli*系，可产生香蕉或薄荷等气味。

图26.6：来自 http://2006.igem.org/wiki/index. php/Standard_Assembly 的 BioBrick 部件组合示例

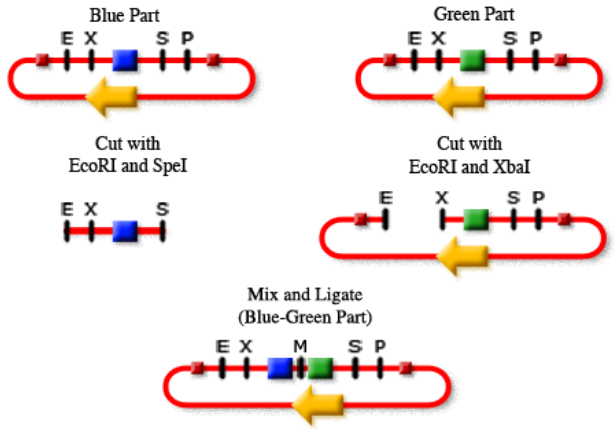

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

26.5 What Have We Learned?

合成生物学是一门新兴学科，旨在创建有用的生物系统，以解决能源、医学、环境以及许多其他领域的问题。合成生物学家试图利用抽象方法，使他们能够像软件工程师或电气工程师制作计算机程序或复杂电路那样，用更简单的系统构建更复杂的系统。标准生物部件注册处和BioBrick标准生物部件旨在对生物部件进行表征和标准化，就像人们对晶体管或逻辑门所做的那样，以实现抽象。诸如BioCompiler之类的工具允许人们使用高级语言描述基因电路，并实际构建具有所述功能的基因电路。合成生物学仍然很新，而且正如iGEM竞赛所展示的那样，不熟悉该领域的人也可以进行研究。

Bibliography

[1] J. Beal 和 J. Bachrach. 细胞是高级空间语言的合理目标，2008年。

[2] M. Elowitz 和 S. Leibler. 一种转录调节因子的合成振荡网络. *Nature*, 403:335–338, 2000.

[3] iGEM。igem：基于标准部件的合成生物学，2012年12月。

[4] 标准生物部件登记处。标准生物部件登记处，2012年12月。

Part IV

Phylogenomics and Population Genomics

CHAPTER

TWENTYSEVEN

分子进化与系统发育学

由 Andrew Cooper、Stephanie Chang 和 Stephen Serene 记录（2012年）Akashnil Dutta（2011年）Albert Wang 和 Mashaal Sohail（2010年）Guo-Liang Chew 和 Sara Baldwin（2009年）

Figures

27.1 生命的进化历史 . . . . . 398 27.2 定义树状术语。一棵分支节点的树被描绘为叶子在顶部，根在底部。时间向上延伸，朝向叶子。 . . . . . 398 27.3 三种类型的树。. . . . . 399 27.4 基于距离的系统发育重建的两个步骤。. . . . . 402 27.5 考虑回复突变的马尔可夫链 . . . . . 403 27.6 y轴表示观察到碱基的概率 - A(红色)，其他(绿色)。x轴表示时间。. . . . . 403 27.7 改变碱基的比例(x轴)与Jukes Cantor距离(y轴)的关系。黑线表示曲线，绿色是f小值时的趋势线，而红线表示渐近边界。. . . . . 405 27.8 不同复杂度(参数)的距离模型。. . . . . 406 27.9 从树到距离矩阵的映射及反之 . . . . . 407 27.10超度量距离。. . . . . 408 27.11加法距离。. . . . . 408 27.12UPGMA / 层次聚类 . . . . . 409 27.13UPGMA在此情况下无法找到正确的树 . . . . . 410 27.14基于特征方法的概述 . . . . . 411 27.15简约性评分：并集与交集 . . . . . 412 27.16通过简约性回溯找到祖先核苷酸 . . . . . 413 27.17通过动态规划进行简约性评分 . . . . . 413 27.18使用剥离算法评分的树。n=4 . . . . . 415 27.19递推关系 415 27.20使用最近邻交换方案的一个单位步骤 418

27.1 Introduction

系统发生学是研究具有共同起源的一组对象之间关系的学科，基于对对象个体特征的认识。这些对象可以是物种、基因或语言，它们相应的特征可以是形态特征、序列、词语等。在所有这些例子中，所研究的对象随时间逐渐变化，并从共同起源分化至今的对象。

在生物学中，系统发育学尤为重要，因为所有生物物种都是大约35亿至38亿年前存在的单一共同祖先的后代。随着时间的推移，遗传变异、隔离和选择造就了我们今天所观察到的物种多样性。然而，不仅物种形成，灭绝也在塑造我们今天所看到的生物圈中发挥了关键作用。研究不同物种之间的亲缘关系对生物学至关重要，因为它们为了解不同的生物功能、遗传机制以及进化过程本身提供了许多启示。

图27.1：生命的进化史

27.2 Basics of Phylogeny

27.2.1 Trees

树是对象之间关系的数学表示。一般树由节点和边构成。每个节点表示一个对象，每条边表示两个节点之间的关系。在系统发育树的情况下，我们用树来表示进化。在这种情况下，每个节点表示两个祖先谱系之间的分化事件，叶节点表示当前对象的集合，根节点表示共同祖先。

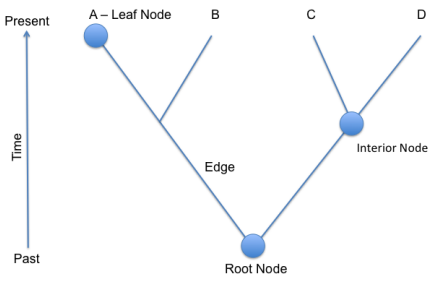

图27.2：定义树术语。一棵由分支节点组成的树如图所示，叶位于顶部，根位于底部。时间向上延伸，朝向叶的方向。

然而，有时分支长度反映了更多的信息，如经过的时间或差异的程度。根据这些差异，生物系统发育树可以分为三类:

Cladogram: 不对分支长度赋予任何意义；只有分支的序列和拓扑结构才重要。

Phylogram: 分支长度与**genetic change**的量直接相关。树的分支越长，发生的系统发育变化量就越大。由于突变速率不同，这棵树上的叶子不一定终止于同一条垂直线上。

Chronogram (ultrametric tree): 分支长度与{v*}直接相关。树的枝越长，经过的时间就越多。这棵树上的叶子必然终止于同一条垂直线上（即它们到根的距离相同），因为它们都处于现在，除非树中包含了已灭绝的物种。尽管在时间树上分支长度与遗传距离之间存在相关性，但它们不一定完全成比例，因为进化速率/突变速率并非恒定。有些物种的进化和突变速度比其他物种快，而某些历史时期也会促进比其他时期更快的进化速率。

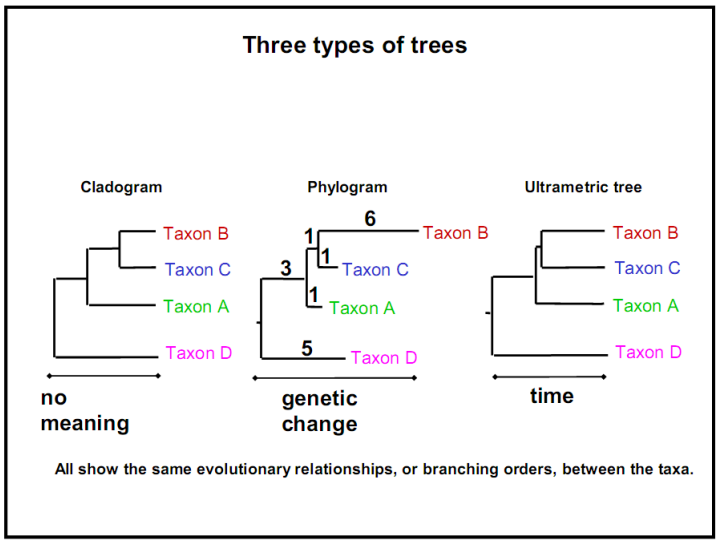

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图27.3：三种类型的树。

27.2.2 Traits

性状是物体或物种所拥有的任何特征。在人类中，性状的一个例子可能是双足行走（直立行走的能力）或对生拇指。另一个人类性状可能是人类拥有的特定DNA序列。物理性状的第一个例子被称为**morphological traits**，而后者DNA性状被称为**sequence traits**。每种性状在研究时都有其优势和劣势。所有树重建方法都依赖于研究给定对象中不同性状的出现。在传统系统发育学中，不同物种的形态数据被用于此目的。在现代方法中，遗传序列数据被取而代之。每种方法都有其优势和劣势。

Morphological Traits: 从对物理特征的经验评估中产生。这可能是有利的，因为物理特征对每个人来说都非常容易量化和理解，无论是科学家还是

儿童也一样。这种方法的缺点是，我们只能评估一小部分特征，如头发、指甲、蹄、牙齿等。此外，这些特征只能让我们建立物种。最后，我们更容易被趋同演化“欺骗”。数百万年前分化的物种可能会在科学家可观察到的少数特征上再次趋同，从而错误地表示这些物种之间的亲缘关系有多近。

Sequence Traits: 通过研究不同物种的基因组来发现。这种方法可能具有优势，因为它创造了更多的数据，并使科学家能够创建基因树，而不仅仅是物种树。这种方法的主要困难在于DNA仅由4个碱基构成，因此回复突变频繁。在这种方法中，科学家必须协调大量表现不佳的特征信号，而传统方法则是处理少量表现良好的特征。本章其余部分将主要聚焦于基于基因序列的树构建。

由于这种方法涉及基因对之间的比较，理解**homology**的概念很有帮助：如果一对基因源自基因复制事件，则称为**paralogues**，而如果它们源自物种形成事件，则称为**ortho- logues**。

FAQ

Q: 是否有可能使用灭绝物种的DNA序列?

A: 当前技术仅允许使用现存序列。然而，利用已灭绝物种DNA的研究已取得一些成功。从冷冻猛犸象中已收集到DNA并正在进行测序，但由于DNA随时间降解及环境 contamination，提取正确的序列极为困难。

27.2.3 Methods for Tree Reconstruction

一旦我们找到了一组物种的遗传数据，我们便有兴趣了解这些物种之间的相互关系。由于我们大多只能从活体生物中获取DNA，因此我们必须推断每个物种祖先的存在，并最终推断出一个共同祖先的存在。这是一个具有挑战性的问题，因为可用的数据非常有限。以下章节将探讨从序列数据推断祖源关系的现代方法。这些方法可以分为两类：基于距离的方法和基于特征的方法。

Distance based approaches 分两步解决该问题：其一，量化分隔每对序列的突变数量（这可能与它们被分隔以来的时间成正比，也可能不成正比）；其二，根据成对距离矩阵拟合最可能的树。第二步通常基于一些假设采用直接算法，但也可能更为复杂。

Charecter based approaches 相反，尝试找到最能解释观察到的序列的树。与直接重建不同，这些方法依赖于树提议和评分技术，在树的空间中进行启发式搜索。

Did You Know?

Occam's Razor正如前几章所讨论的，{v*}并不总是提供最准确的假设。在树重建的许多情况下，最简单的解释并非最可能的。例如，给定一些观测数据，可能存在一组可能的祖先关系。在这种情况下，如果某一性状在两个独立谱系中独立出现，那么最简单的祖先关系可能并不正确。这个问题将在后续章节中讨论。

27.3 Distance Based Methods

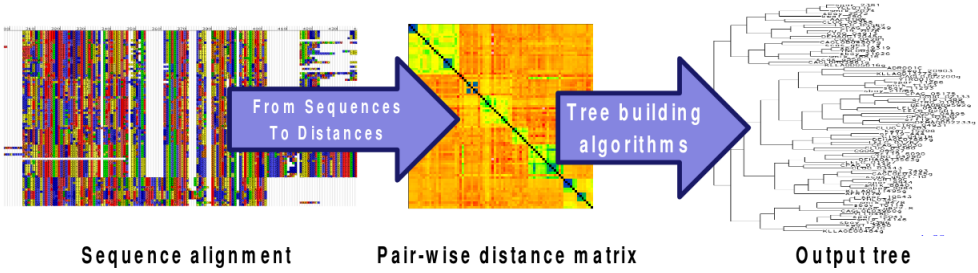

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图27.4：基于距离的系统发育重建的两个步骤。

基于距离的模型将序列数据转换为成对距离。这一步骤会丢失一些信息，但为直接进行树重建搭建了平台。本方法的两个步骤在此详细讨论。

27.3.1 From alignment to distances

为了理解基于距离的模型如何工作，重要的是要考虑在比较两个序列时距离意味着什么。主要有三种解释。

Nucleotide Divergence 是基于两个序列之间核苷酸不一致的位置数量来衡量距离的思想。这假设进化在整个基因组中以均匀的速率发生，并且一个给定的核苷酸进化成其他三种核苷酸中的任何一种的可能性相同。尽管它有缺点，但这通常是一种很好的思考方式。

Transitions and Transversions 这与核苷酸分歧相似，但它认识到A-G和T-C替换最为频繁。因此，它保留了两个参数，即转换概率和颠换概率。

Synonymous and non-synonymous substitutions 该方法通过假设不改变所编码蛋白质的替换不会受到选择淘汰，因此其发生概率高于那些改变所编码氨基酸的替换，来追踪影响编码氨基酸的替换。

解释两个序列之间差异的朴素方法可能仅仅是错配的数量，如上文核苷酸分歧所述。虽然这确实为我们提供了一个距离度量（即$d(a,b)+d(b,c)\geq d(a,c)$），但这并不能完全满足我们的要求，因为我们想要**additive dis-tances**，即那些对于进化序列的路径$a\to b\to c$满足$d(a,b)+d(b,c)=d(a,c)$的，因为沿着树中一条路径累积的突变数量应该是其各个组成部分之和。然而，朴素的错配比例并不总是具有这一性质，因为该量以1为界，而各个组成部分之和很容易超过1。

解决这一悖论的关键在于**back-mutations**。当大量突变在一条序列上累积时，并非所有突变都会引入新的错配，其中一些可能发生在已经突变的碱基对上，导致错配分数保持不变甚至降低。然而，对于较小的错配分数而言，这种效应在统计上是不显著的，因为相同的配对远远多于

错配对。然而，对于进化距离较远的序列，我们必须校正这一效应。Jukes-Cantor模型就是一种考虑了这一点的简单马尔可夫模型。

Jukes-Cantor distances

为了说明这个概念，考虑在时间零点处于状态“A”的一个核苷酸。在每个时间步，它有0.7的概率保持先前的状态，以及0.1的概率转移到其他三个状态中的每一个。在时间t观察到状态（碱基）B的概率$P(B|t)$本质上遵循递归

$$P(B|t+1) = 0.7P(B|t) + 0.1\sum_{b\neq B} P(b|t) = 0.1 + 0.6P(B|t)$$

。

图27.5：考虑回复突变

如果我们将 $P(B|t)$ 对 t 作图，我们会观察到分布起初集中在状态“A”，然后逐渐扩散到其余状态，最终趋向于等概率的平衡状态。这种进程在直观上是合理的。在数百万年的时间里，物种可能会进化得如此剧烈，以至于它们不再类似于其祖先。在这种极端情况下，祖先中某个给定的碱基位置，随着时间的推移，进化成该位置四种可能碱基中任何一种的可能性是相同的。

time:-	0	1	2	3	4
A	1	0.7	0.52	0.412	0.3472
C	0	0.1	0.16	0.196	0.2196
G	0	0.1	0.16	0.196	0.2196
T	0	0.1	0.16	0.196	0.2196

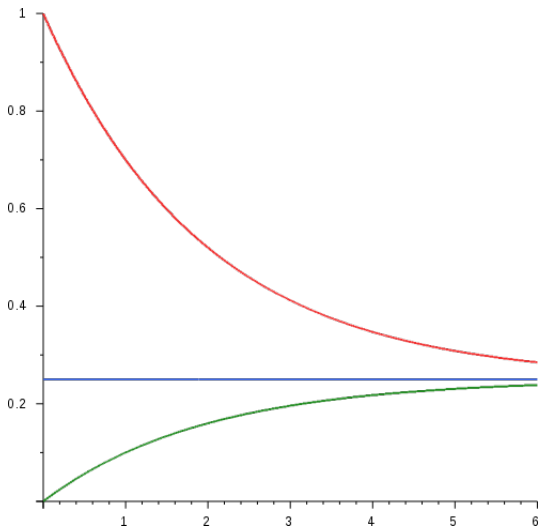

图27.6：y轴表示观察到碱基的概率——A（红色），其他（绿色）。x轴表示时间。

Jukes Cantor模型的本质是从碱基改变的比例回溯t，即经过的时间量。从概念上讲，这仅仅是将绿色曲线的x轴和y轴颠倒过来。为了定量地模拟这一过程，我们考虑以下矩阵$S(t)$，它表示在时间Δt内，从初始碱基y状态出发，观察到碱基x的相应概率$P(x|y,\Delta t)$。

$$S(\Delta t) = \begin{pmatrix} P(A|A,\Delta t) & P(A|G,\Delta t) & \cdots & P(A|T,\Delta t) \\ P(G|A,\Delta t) & \cdots & & \cdots \\ \cdots & & & \cdots \\ P(T|A,\Delta t) & \cdots & \cdots & P(T|T\Delta T) \end{pmatrix}$$

我们可以假设这是一个平稳马尔可夫模型，这意味着这个矩阵是可乘的 电子邮件，即

$$S(t_1 + t_2) = S(t_1)S(t_2)$$

在非常短的时间ϵ内，我们可以假设不存在二阶效应，即在同一个核苷酸上发生两次突变的时间不足。因此，交叉转换的概率都与ϵ成正比。此外，在Jukes Cantor模型中，我们假设从每个核苷酸到另一个核苷酸的所有转换率都是相同的。因此，对于短时间ϵ

$$S(\epsilon) = \begin{pmatrix} 1-3\alpha\epsilon & \alpha\epsilon & \alpha\epsilon & \alpha\epsilon \\ \alpha\epsilon & 1-3\alpha\epsilon & \alpha\epsilon & \alpha\epsilon \\ \alpha\epsilon & \alpha\epsilon & 1-3\alpha\epsilon & \alpha\epsilon \\ \alpha\epsilon & \alpha\epsilon & \alpha\epsilon & 1-3\alpha\epsilon \end{pmatrix}$$

在时间t处，矩阵由下式给出

$$S(t) = \begin{pmatrix} r(t) & s(t) & s(t) & s(t) \\ s(t) & r(t) & s(t) & s(t) \\ s(t) & s(t) & r(t) & s(t) \\ s(t) & s(t) & s(t) & r(t) \end{pmatrix}$$

从方程$S(t+\epsilon) = S(t)S(\epsilon)$中我们得到

$$r(t+\epsilon) = r(t)(1-3\alpha\epsilon) + 3\alpha\epsilon s(t) \text{ and } s(t+\epsilon) = s(t)(1-\alpha\epsilon) + \alpha\epsilon r(t))$$

它们重新整理为微分方程的耦合系统

$$r'(t) = 3\alpha(-r(t) + s(t)) \text{ and } s'(t) = \alpha(r(t) - s(t))$$

在初始条件 $r(0) = 1$ 和 $s(0) = 0$ 下。解可以表示为

$$r(t) = \frac{1}{4}(1 + 3e^{-4\alpha t}) \text{ and } s(t) = \frac{1}{4}(1 - e^{-4\alpha t})$$

现在，在给定的比对中，如果我们有碱基不同的位点占比为f，则有:

$$f = 3s(t) = \frac{3}{4}(1 - e^{-4\alpha t})$$

暗示

$$t \propto -\log\left(1 - \frac{4f}{3}\right)$$

为了与 f 渐近一致，我们将演化距离 d 设为

$$\boxed{d = -\frac{3}{4}\log\left(1 - \frac{4f}{3}\right)}$$

注意，当 f 的值较小时，距离大约与 f 成正比，并且当 $f \to 0.75$ 时，距离渐近趋于无穷大。直观上，这是因为经过很长一段时间后，我们会预期该序列完全随机，而这意味着大约四分之三的碱基与原始序列不匹配。但当 f 接近 0.75 时，Jukes-Cantor 距离的不确定度值也会变得非常大。

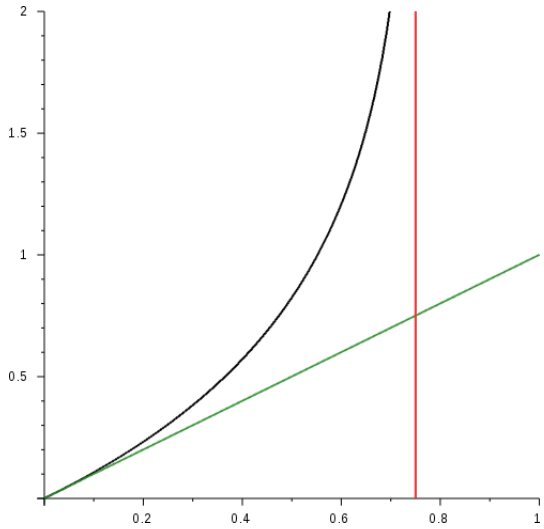

图27.7：改变碱基的比例（x轴）与Jukes Cantor距离（y轴）的关系。黑线表示曲线，绿线表示f较小值时的趋势线，而红线表示渐近边界。

Other Models

Jukes Cantor模型是最简单的模型，它为我们提供了理论上一致的加性距离模型。然而，它是一个单参数模型，假设每个碱基向不同碱基的突变具有相同的机会。但是，AG之间或TC之间的变化比它们之间的变化更可能发生。第一种类型的替换称为转换，而第二种类型称为颠换。Kimura模型有两个参数，考虑了这一点。还有许多其他修改的距离模型，考虑了转换和颠换等不同速率，如下所示。

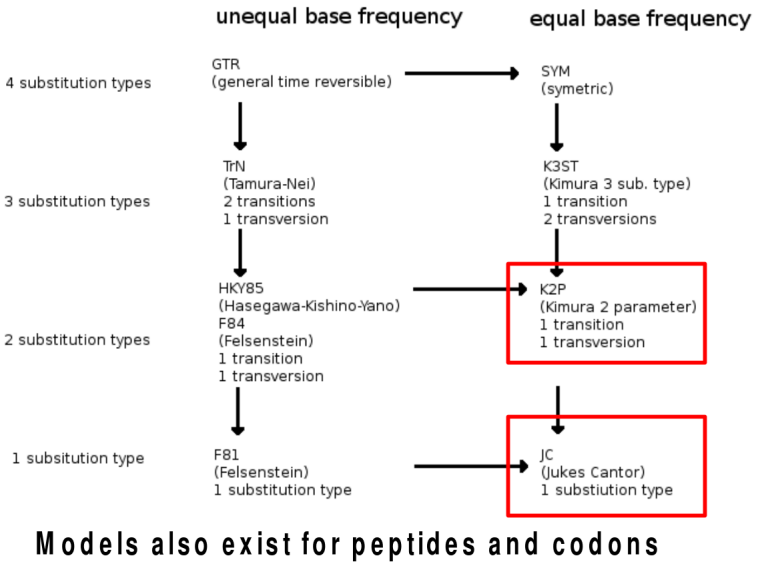

图27.8：不同复杂度（参数）的距离模型。

FAQ

Q: 我们能否为树的不同部分使用不同的参数？以考虑不同的突变率？

A: 这是可能的，这是当前研究的一个领域。

27.3.2 Distances to Trees

如果我们有一棵带权系统发育树，我们可以通过将路径中各个分支长度相加，求出某一对叶节点之间最短路径的总权重（长度）。考虑所有这样的叶节点对，我们就得到了一个表示数据的距离矩阵。在基于距离的方法中，问题是给定这个距离矩阵来重建这棵树。

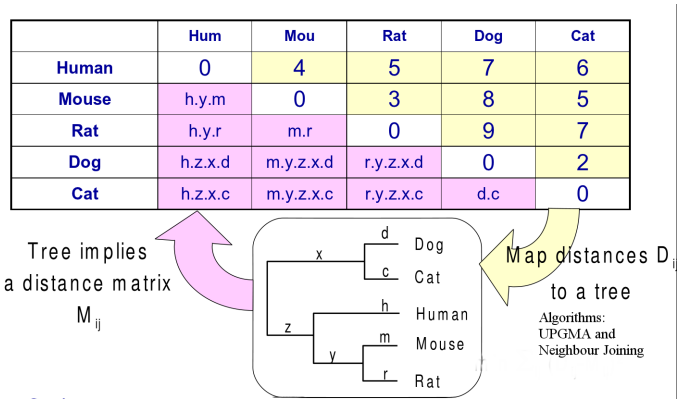

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图27.9：从树到距离矩阵的映射及反之亦然

FAQ

Q: 在图27.9中，m和r序列差异度量可能有一些重叠，因此小鼠和大鼠之间的距离不仅仅是m+r。难道只有在没有重叠的情况下才会这样吗?

A: 如果你正确建模进化，那么你将得到进化距离。这是一个不等式而非等式，我们同意无法精确推断出给定的距离就是确切的距离。因此，由于重叠、趋同进化和转换，小鼠与大鼠之间的序列距离可能小于 m + r。

然而，请注意，距离矩阵与加权树之间并非一一对应。每棵树确实对应一个距离矩阵，但反之则不一定成立。为了与某个加权树相对应，距离矩阵必须满足额外的属性。实际上，有两种模型对距离矩阵施加了特殊约束：

Ultrametric: 对于所有叶子的三元组 (a, b, c)，其中有两对距离相等，而第三个距离较小；即该三元组可以标记为 i, j, k，使得

$$d_{ij} \leq d_{ik} = d_{jk}$$

从概念上讲，这是因为亲缘关系更近的两片叶子（比如i, j）恰好在同一时间从第三片叶子（k）分化出来。与第三片叶子的时间间隔应该相等，而它们彼此之间的间隔应该更小。

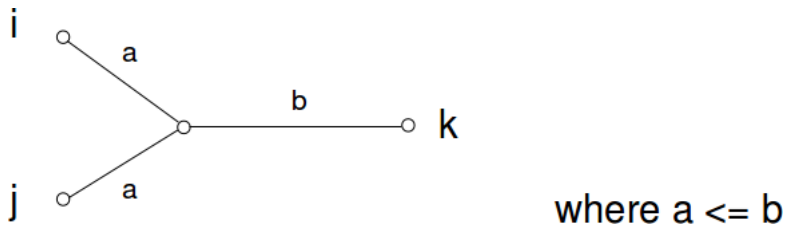

图27.10：超度量距离。

Additive: 可加距离矩阵满足如下性质：所有四个叶节点都可以被标记为 i, j, k, l，使得

$$d_{ij} + d_{kl} \leq d_{ik} + d_{jl} = d_{il} + d_{jk}$$

事实上，对于所有正权重树而言，这一点都是成立的。对于树中的任意4个叶子节点，恰好存在一种拓扑结构，即：

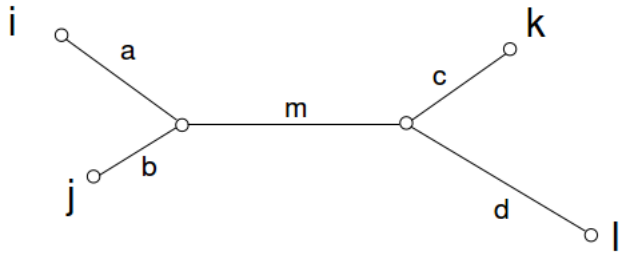

图27.11：加性距离。

那么上述条件逐项等价于

$$(a + b) + (c + d) \leq (a + m + c) + (b + m + d) = (a + m + d) + (b + m + c)$$

这个等式对应于通过遍历该树可能得到的所有成对距离。

在将树映射到距离矩阵时，这类冗余等式必然会出现，因为一棵有n个节点的树有n –个参数，每个分支长度对应一个参数，而距离矩阵有n^2个参数。因此，树本质上是高维空间的低维投影。这一观察的一个推论是，并非所有距离矩阵都有对应的树，但所有树都映射到唯一的距离矩阵。

然而，真实数据集并不完全满足超度量或加性约束。这可能是由于噪声（当我们进化模型的参数不精确时）、随机性和偶然性（由于样本量小）、波动、不同的突变率、基因转换和水平转移。因此，我们需要能够处理噪声距离矩阵的树构建算法。

接下来，将讨论两种直接依赖这些假设进行树重建的算法。

UPGMA - Unweighted Pair Group Method with Arithmetic Mean

这与第13讲“基因表达聚类”中讨论的**Hierarchical clustering**方法完全相同。它逐步形成聚类，从紧密相关的节点到相距较远的节点。每上升一个层级就形成一个分支节点。该算法可通过以下步骤恰当描述：

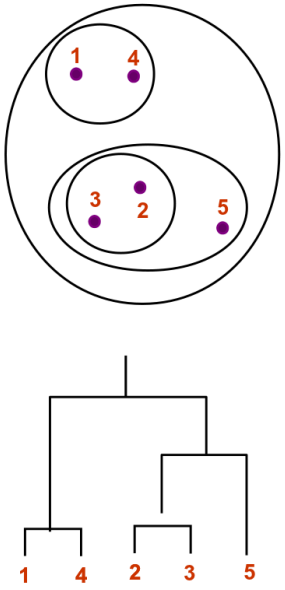

图27.12：UPGMA / 层次聚类

Initialization:

1. 为每个序列x_i定义一片叶子i。2. 将每片叶子i置于高度0。3. 定义每个仅含一片叶子i的簇C_i。

Iteration:

1. 通过计算各簇成员序列间距离的算术平均值，找出每对簇 d_{ij} 之间的两两距离 C_i, C_j 。2. 找到两个簇 C_i, C_j，使得 d_{ij} 最小化。

3. 令 $C_k = C_i \cup C_j$。4. 定义节点 k 为节点 i, j 的父节点，并将其置于 i, j 上方高度 $d_{ij}/2$ 处。5. 删除 C_i, C_j。

Termination: 当剩余两个聚类C_i, C_j时，将根置于高度$d_{ij}/2$处，作为节点i, j的父节点

Ultrametrification of non-ultrametric trees

如果一棵树不满足超度量条件，我们可以尝试寻找一组对n×n对称距离矩阵的修改，使其成为超度量。这可以通过构建一个完全连接的图来实现，图的权重由原始距离矩阵给出，找到该图的最小生成树（MST），然后构建一个新的距离矩阵，其元素D(i,j)由MST中从i到j唯一路径上的最大权重给出。完全连接图的生成树简单地识别出连接所有节点而不产生任何环的边子集，而最小生成树是使边权重总和最小的生成树。可以使用Prim算法找到MST，然后用它来修正非超度量树。

Weaknesses of UPGMA

尽管这种方法在距离矩阵满足超度量性质时能保证找到正确的树，但实际应用中被证明是一个不准确的算法。除了缺乏鲁棒性外，它还受制于分子钟假设，即所有物种的突变率随时间保持恒定。然而，这一假设并不成立，因为某些物种如大鼠和小鼠的进化速度远快于其他物种。这种突变率的差异

速率过快可能导致长枝吸引；共享较低突变率但存在于不同谱系中的节点可能会被合并，使得那些具有较高突变率（长枝）的节点在树中一起出现。下图展示了一个 UPGMA 失败的例子：

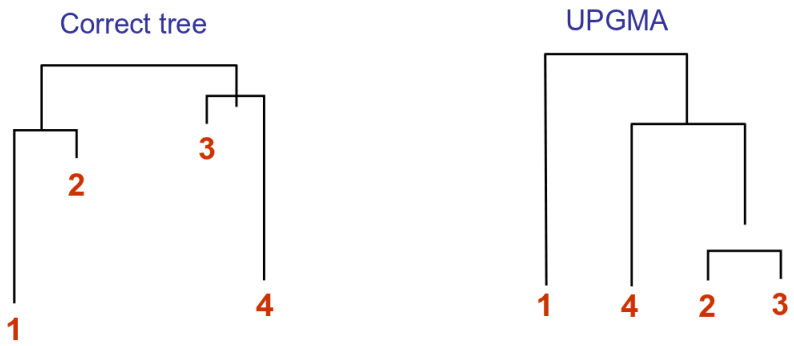

图27.13：在这种情况下，UPGMA无法找到正确的树状结构

Neighbor Joining

如果距离矩阵满足可加性，邻接法保证能产生正确的树。当数据中存在一些噪声时，它也可能生成一棵好的树。该算法描述如下：

Finding the neighboring leaves: 让

$$D_{ij} = d_{ij} - (r_i + r_j) \text{ where } r_a = \frac{1}{n-2}\sum_k d_{ak},\ a \in \{i, j\}$$

这里 n 是树中节点的数量；因此，r_i 是一个节点到其他节点的平均距离。可以证明，上述修改确保了只有当 i, j 是邻居时，D_{ij} 才是最小的。（证明可在 Durbin 的书第 189 页找到）。

Initialization: 定义 T 为叶节点集合，每个序列一个。令 $L = T$

Iteration:

1. 选择i, j，使得D_{ij}最小化。2. 定义新节点k，并设置 $d_{km} = \frac{1}{2}(d_{im} + d_{jm}d_{ij})\forall m \in L$。3. 将$k$添加到$T$，边长为 $d_{ik} = \frac{1}{2}(d_{ij} + r_i r_j)$。4. 从$L$中移除$i, j$。5. 将$k$添加到$L$。

Termination: 当 L 由两个节点 i, j 及它们之间长度为 d_{ij} 的边组成时，将根节点添加为 i 和 j 的父节点。

Summary of Distance Methods Pros and Cons

上述方法已被证明能够捕捉系统发育关系中的许多有趣特征，并且在算法意义上通常非常快。然而，有些信息确实

在距离矩阵中迷失，通常仅提出单一树。当关于突变率等基本假设被违反时，可能会犯下严重错误，如长枝吸引。最后，距离方法不推断特定位点的历史，因此不对序列的祖先状态提出建议。

27.4 Character-Based Methods

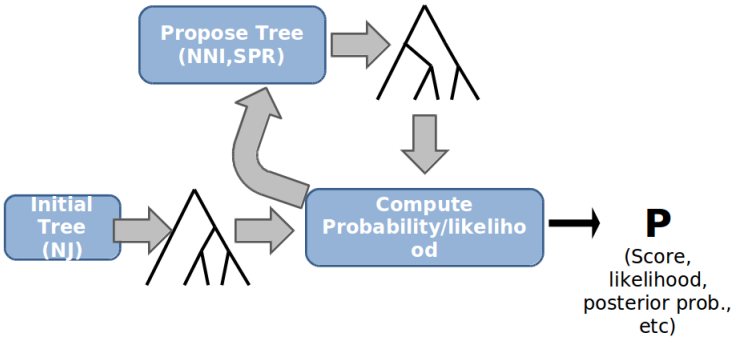

图27.14：基于字符的方法概述

在基于字符的方法中，目标是首先创建一个有效的算法，用于评估给定树在其叶节点产生观测序列的概率，然后通过搜索可能的树的空间，寻找使该概率最大化的树。良好的树评分算法，以及在搜索树空间时，尽管理论上是NP-Hard问题（由于可能的树数量庞大），但在许多情况下，可行的启发式搜索方法仍能找出好的树。我们将首先讨论树评分算法，然后探讨搜索技术。

27.4.1 Scoring

树评分主要有两种算法。第一种方法，我们称之为简约重建，基于奥卡姆剃刀原理，根据叶节点上（已知的）序列，依据其暗示的最少突变数量来评分拓扑结构。这种方法简单、直观且快速。第二种方法是最大似然法，通过显式建模在给定树拓扑结构下观察到叶节点序列的概率来对树进行评分。

Parsimony

从概念上讲，这种方法很简单。它只需为每个祖先节点上的每个碱基对分配一个值，以使得替换次数最小化。评分则是所有碱基对上最小突变次数的总和。（回想一下，最终目标是找到使该评分最小化的树。）

为了重建树上内部节点的祖先序列，该算法首先从（已知的）叶序列向上扫描，根据每个内部节点的子节点为其分配一组碱基。接下来，它向下遍历树，在每个节点从允许的碱基集合中挑选碱基，这次基于该节点的父节点。下面详细说明该算法（注意总共有$2N-1$个节点，从根节点开始索引，因此已知的叶节点索引为$N-1$到$2N-1$）：

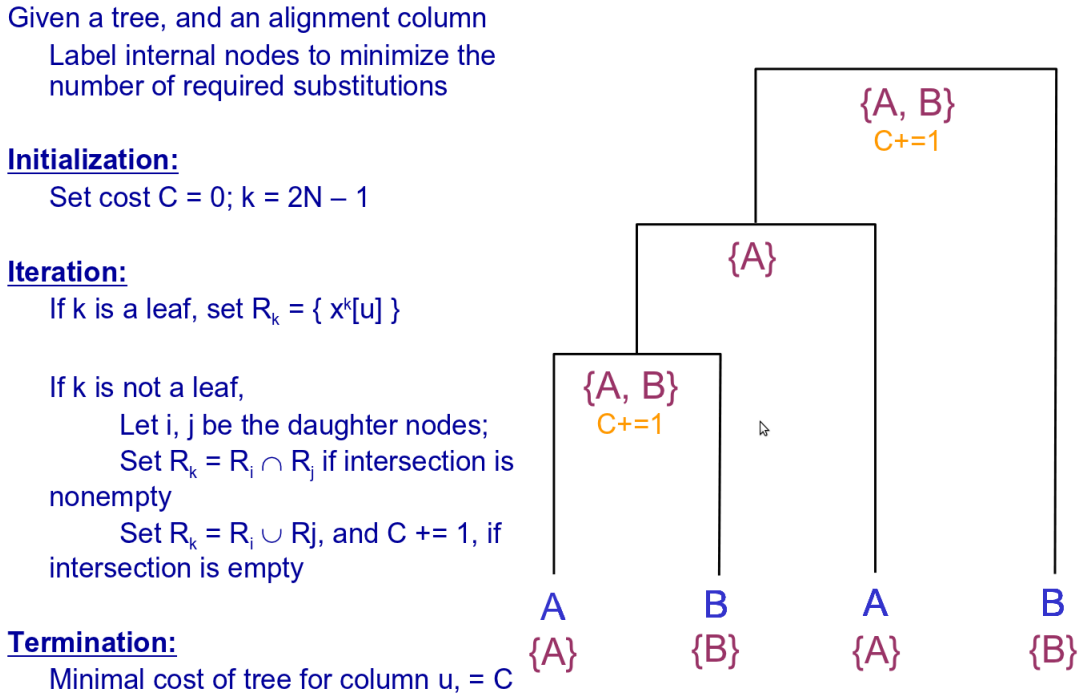

图27.15：简约评分：并集与交集

Traceback:

1. Choose an arbitrary nucleotide from R_{2N-1} for the root

2. Having chosen nucleotide r for parent k,
   If $r \in R_i$ choose r for daughter i
   Else, choose arbitrary nucleotide from R_i

Easy to see that this traceback produces some assignment of cost C

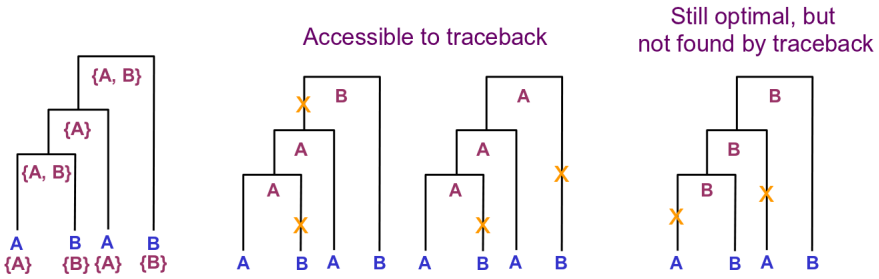

图27.16：简约法回溯以寻找祖先核苷酸

	M	R	B1	H	B2	D	B3
A	0	1	1	0	1	1	2
C	1	1	2	1	3	1	4
G	1	0	1	1	2	0	2
T	1	1	2	1	3	1	4

- Each cell (N,C) represents the min cost of the subtree rooted at N, if the label at N is C.
- Update table by walking up the tree from the leaves to the root, remembering max choices.
- Traceback from root to leaves

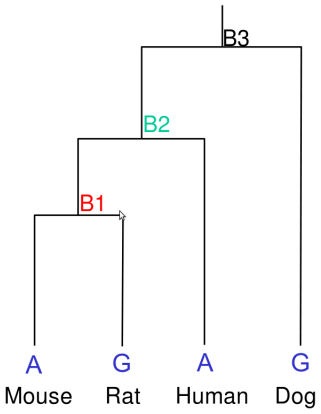

图27.17：通过动态规划进行简约性评分

正如我们之前提到的，这种方法简单快捷。然而，这种简便性可能会扭曲其分配的评分。首先，此处介绍的算法假设给定的碱基对在从给定节点出发的至多一个分支上经历替换，这可能导致它忽略那些违反此假设但很可能存在的内部序列。此外，该方法没有明确建模每条边所代表的时间，因此无法考虑沿代表长时间跨度的边发生替换的概率增加，或树中不同突变率的可能性。最大似然法在很大程度上解决了这些缺陷，因此更常用于树评分。

Maximum Likelihood - Peeling Algorithm

与一般的最大似然方法一样，该算法根据观察到数据和给定树的(对数)联合概率对树进行评分，即$P(D,T)$。剥离算法再次考虑单个碱基对，并假设所有位点独立进化。与简约法一样，该算法独立考虑所有碱基对：给定树、一组分支长度以及内部序列的最大似然分配，它计算在叶节点处的每个碱基对上观察到给定字符的概率，然后简单地将这些概率在所有碱基对上相乘，以得到观察到该树的总概率。请注意，与之前的方法相比，显式建模分支长度是一个不同之处。

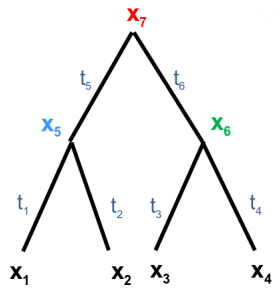

图27.18：将使用剥离算法进行评分的树。n=4

这里每个节点都有一个字符 x_i，而 t_i 是其父节点对应的分支长度。注意，我们已经知道 $x_1, x_2 \cdots x_n$ 的值，因此它们是常数，但 $x_{n+1}, \cdots x_{2n-1}$ 是祖先节点处未知的字符，这些是变量，我们将为其分配最大似然值。（另请注意，我们采用了从叶到根的节点索引方案，这与我们之前使用的方案相反。）我们想要计算 $P(x_1 x_2 \cdots x_n | T)$。为此，我们对祖先节点处所有可能的取值组合求和。这称为边缘化。在这个特定例子中

$$P(x_1 x_2 x_3 x_4 | T) = \sum_{x_5} \sum_{x_6} \sum_{x_7} P(x_1 x_2 \cdots x_7 | T)$$

这里有4^{n-1}项，但我们可以利用以下因式分解技巧：

$$= \sum_{x_5} \sum_{x_6} \sum_{x_7} P(x_1|x_5,t_1) P(x_2|x_5,t_2) P(x_3|x_6,t_3) P(x_4|x_6,t_4) P(x_5|x_7,t_5) P(x_6|x_7,t_6) P(x_7)$$

这里我们假设每个分支独立进化。概率 $P(b|c,t)$ 表示在给定时间 t 的条件下，碱基 c 突变为碱基 b 的概率，这基本上是从 Jukes Cantor 模型或之前讨论过的某些更高级模型得到的。接下来，我们可以将与求和变量无关的因子移到求和符号之外。这就得到：

$$= \sum_{x_7} \left[P(x_7) \left(\sum_{x_5} P(x_5|x_7,t_5) P(x_1|x_5,t_1) P(x_2|x_5,t_2) \right) \left(\sum_{x_6} P(x_6|x_7,t_6) P(x_3|x_6,t_3) P(x_4|x_6,t_4) \right) \right]$$

令 T_i 为 i 下方的子树。在这种情况下，我们的 $2n-1 \times 4$ 动态规划数组计算 $L[i,b]$，即在节点 i 包含碱基 b 时观察到 T_i 的概率 $P(T_i | x_i = b)$。然后我们要计算观察到 $T = T_{2n-1}$ 的概率，即

$$\sum_b P(x_{2n-1} = b) L[2n-1, b]$$

注意，对于每个祖先节点i及其子节点j,k，我们有

$$L[i,b] = \left(\sum_c P(c|b,t_j) L[j,c] \right) \left(\sum_c P(c|b,t_k) L[k,c] \right)$$

在叶节点的初始条件下，即对于$i \leq n$：

$$L[i,b] = 1 \text{ if } x_i = b \text{ and } 0 \text{ otherwise}$$

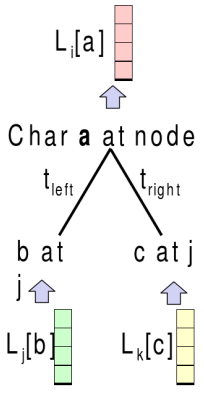

图27.19：递推

请注意，我们仍然没有$P(x_{2n-1}=b)$的值。它通常被平等地分配或来自某种先验分布，但这并不会极大地影响结果。最后一步当然是将各个位点的所有概率相乘，以获得观察到整个序列集合的概率。此外，

一旦我们根据树结构和分支长度集合为每个内部节点分配了最大似然值，就可以将所得分数乘以树结构和分支长度集合的某些先验概率，这些先验概率通常通过显式建模进化过程生成，例如尤尔过程或生死模型如莫兰过程。使用贝叶斯推断的语言，这最后一次乘法得到的结果称为后验概率。该算法的总体复杂度为$O(nmk^2)$，其中 n 是叶节点（分类单元）的数量，m 是序列长度，k 是字符数量。

该算法有优点也有缺点。例如

Advantages:

1. 本质上基于统计和进化模型。2. 通常是最一致的方法。3. 用于字符和速率分析。4. 可用于推断已灭绝祖先的序列。5. 考虑不平衡树中的分支长度效应。6. 核苷酸或氨基酸序列，以及其他类型的数据。

Disadvantages:

1. 不如许多其他方法简单直观。2. 计算强度受限，受分类单元数量和序列长度影响。3. 与简约法类似，可能被高度同塑性所误导。4. 违反模型假设可能导致错误的树。

27.4.2 Search

对所有树的空间进行全面搜索将极其昂贵。具有$n+$个1叶子的完整有根树的数量是第n个卡特兰数

$$C_n = \frac{1}{n+1}\binom{2n}{n} \approx \frac{4^n}{n^{3/2}\sqrt{\pi}}$$

此外，我们必须为这些树中的每一棵计算分支长度的最大似然集。因此，对于所有树绝对最大化得分是一个NP-Hard问题。幸运的是，启发式搜索算法通常能在树空间中找到良好的解决方案。这类搜索算法的一般框架如下：

Inititalization: 取一些树作为迭代的基础（随机选择或根据其他先验知识，或者来自基于距离的直接算法）。

Proposal: 通过随机轻微修改当前树来提出一棵新树。

Score: 根据上述方法对新提案进行评分。

Select: 随机选择新树或旧树（对应的概率根据得分（似然）比率确定。

Iterate: 重复到提案步骤，除非满足某些终止条件（达到某个阈值分数或步数）。

这里的基本思想是启发式假设：紧密相关树的得分是相似的，因此可以通过连续的局部优化来获得良好的解决方案，期望这能收敛到一个整体上良好的解。

Tree Proposal

一种修改树的方法是最近邻交换（NNI），如下所示。

图27.20：使用最近邻交换方案的单位步长

另一种常见但未在此描述的方法是树二分与连接（TBJ）。此类提议规则的重要标准是：

(a) 树空间应当是连通的，即任意一对树都应能通过一系列提议从一棵得到另一棵。(b) 单个新提议应与原始树足够接近。这样，由于接近已发现的好解，它更可能是一个好解。如果单个步骤过大，算法可能会偏离已发现的解（这也取决于选择步骤）。特别要注意，衡量这些步长大小的相似性度量，正是分配给两棵树的似然得分之差。

Selection

选择是否采纳某个提案，与生成提案的过程一样，本质上是启发式的，并且因人而异。一般的经验法则是：

1. 如果新方案的得分更高，就总是接受它。
2. 如果它的得分更差，那么应该有一定的概率选择它，否则算法将很快局限于局部最小值，忽视稍远一些的更好选择。
3. 选择较差新提案的概率不应过高，否则有可能拒绝已知的良好解决方案。

决定良好选择规则的是步骤 2 和 3 之间的权衡。Metropolis Hastings 是一种马尔可夫链蒙特卡洛方法（MCMC），它定义了探索状态空间的特定规则，使其成为从后验分布中抽取的样本。这些算法在实践中效果尚可，但无法保证找到合适的树。因此，使用了一种称为自举法的方法，其基本上是反复在叶序列中的碱基对子集上运行算法，然后倾向于选择与仅使用这些子序列生成的拓扑结构相匹配的全局树。

27.5 Possible Theoretical and Practical Issues with Discussed Approach

必须特别说明距离问题。由于距离通常是在已比对的基因序列之间计算的，当前大多数树重建方法依赖于高度保守的基因，因为非保守基因不会为不携带这些基因的物种提供信息。这导致忽略了原本有用的数据。因此，有一些算法尝试在重建树时考虑保守程度较低的基因，但由于树重建的NP-Hard性质，这些算法往往需要很长时间。

此外，比对后的序列对于产生它们的事件仍不够明确。也就是说，物种形成、复制、丢失和水平基因转移（hgt）事件的组合很容易混淆，因为只有当前的DNA序列可用。（关于此类理论问题的评论，见[11]）复制后发生丢失将很难检测。此外，复制后发生物种形成可能看起来像一个HGT事件。甚至事件发生的概率也仍然存在争议，尤其是水平基因转移事件。

另一个问题是，往往多个标记序列被拼接在一起，而拼接后的序列被用于计算距离并构建树。然而，这种方法假定所有拼接的基因具有相同的历史，并且鉴于上述如hgt和重复等事件可能对不同基因产生不同影响，这种方法是否有效尚存争议。[8]是一篇文章，展示了根据是使用多个基因拼接在一起构建树，还是使用每个单独的基因构建树，会得出不同的系统发育关系。相反，另一篇文献[4]声称，尽管hgt普遍存在，用于系统发育重建的直系同源基因与单一生命之树是一致的。这两个问题表明，该领域在如何非任意地定义物种以及推断系统发育关系以重建生命之树方面显然存在争议。

27.6 Towards final project

27.6.1 Project Ideas

1. 创建更好的距离模型，例如考虑基因重复或基因丢失。也可以分析序列中的肽编码区域，并基于肽链计算距离。

2. 创建一种更快/更准确的搜索算法，将距离转换为树。

3. 分析序列以计算物种形成、复制、丢失和水平基因转移事件的概率。

4. 将寻找HGTs的算法扩展至寻找已灭绝物种。HGTs的一个潜在应用是，如果一个程序能够推断不同时期之间的HGTs，这可能意味着存在一次物种形成事件，其中一个分支现已灭绝（或尚未被发现），并且该分支曾导致向另一个现存分支的HGT。

27.6.2 Project Datasets

1. 1000 Genomes Project http://www.1000genomes.org/
2. Microbes Online http://microbesonline.org/

27.7 What Have We Learned?

在本章中，我们学习了从序列数据重建系统发育树的不同方法和途径。在下一章中，将讨论其在基因树和物种树中的应用以及两者之间的关系，还有对物种内种群之间以及近缘物种之间的系统发育进行建模。

Bibliography

[1] 千人基因组计划。

[2] 等 Ciccarelli，Francesca. 朝向高度解析的生命之树的自动重建。*Science*，311，2006.

[3] Tal Dagan 和 William Martin. 百分之一的树. *Genome Biology*, 2006年11月.

[4] Ochman Howard Daubin Vincent, Moran Nancy A. 系统发生学与细菌基因组的凝聚力。*Science*, 301, 2003.

[5] A.J. Enright, S. Van Dongen, 和 C. A. Ouzounis. 一种高效的大规模蛋白质家族检测算法. *Nucleic Acids Research*, 30(7):1575–1584, 2002年4月.

[6] Stephanie Guindon 和 Olivier Gascuel。一种简单、快速且准确的算法，用于通过最大似然估计大型系统发育。*Systems Biology*，52(5)：696–704，2003年。[7] Sanderson MJ。r8s：在缺乏分子钟的情况下推断分子进化和分化时间的绝对速率。*Bioinformatics*，19(2)：301–302，2003年1月。[8] R. Thane Papke、Olga Zhaxybayeva、Edward J Fiel、Katrin Sommerfeld、Denise Muise 和 W. Ford Doolittle。在盐古菌中寻找物种。*PNAS*，104(35)：14092–14097，2007年。[9] Pere Puigbo、Yuri I Wolf 和 Eugene V Koonin。在系统发育森林的灌木丛中寻找“生命之树”。*Journal of Biology*，8(59)，2009年7月。

[10] [Sag'tpe'':'text', 和 Eugene V Koonin。从传感器基因组出发的数据驱动型推断。*PLoS computational biology*, 8(11), 2012.

[11] [Dou'type': 'text', ald. 'content' 相关理论和方法的综述。*Nature*, 405:419–422, 2000.

CHAPTER

TWENTYEIGHT

PHYLOGENOMICS II

马特·拉斯穆森2012年的客座讲座：由奥里特·吉古津斯基
和伊桑·舍邦迪更新

Figures

28.1 物种树 . . . . . 422 28.2 基因树 . . . . . 423 28.3 物种树内的基因树 . . . . . 423 28.4 基因家族演化：基因树与物种树 . . . . . 424 28.5 映射图 . . . . . 424 28.6 嵌套图 . . . . . 424 28.7 最大简约调和 (MPR) . . . . . 425 28.8 最大简约调和递归算法 . . . . . 425 28.9 调和示例1，简单映射情况 . . . . . 426 28.10调和示例2，复杂情况下的简约调和 . . . . . 426 28.11调和示例3，复杂情况下的非简约调和 . . . . . 427 28.12调和示例4，无效调和 . . . . . 427 28.13物种树重建 . . . . . 428 28.14利用物种树改进基因树重建 . . . . . 429 28.15我们可以开发一个模型来预测可预期的分支长度。我们可以利用保守基因顺序来识别直系同源基因并构建树。 . . . . . 429 28.16分支长度可以建模为两种不同的速率成分：基因特异性和物种特异性。 . . . . . 430 28.17Wright-Fisher模型 . . . . . 431 28.18多次迭代Wright-Fisher产生谱系树 . . . . . 431 28.19溯祖模型 . . . . . 432 28.20k个谱系中溯祖事件的几何概率分布 . . . . . 433 28.21多物种溯祖模型 . . . . . 434 28.22基因与物种树的MPR调和 435 28.23基因树中的不准确性 435

28.24Recombination. 437

28.1 Introduction

在上一章中，我们探讨了基于演化树进行推理的技术。我们介绍的建树算法，如UPGMA和邻接法，均假设我们在比较完全对齐的序列片段。

在本节中，我们介绍了在不同背景下使用系统发育树的额外模型。此处我们阐明了物种树与基因树之间的区别。接着，我们涵盖了一个称为协调的框架，它使我们能够通过将基因树映射到物种树上，有效地将两者结合起来。这种映射为我们提供了一种推断基因复制和丢失事件的方法。

我们还将提出一个用于推理群体遗传学的系统发育视角。由于群体遗传学涉及相对较近期的突变事件，我们提供Wright-Fisher模型作为表示整个群体变化的工具。遗憾的是，在处理现实世界数据时，我们通常只能对某一群体的当前存活后代的基因进行测序。作为对这一缺陷的补救，我们介绍了Coalescent模型，你可以将其视为时间反向的Wright-Fisher类似物。

通过使用溯祖理论，我们获得了一种新的方法来估计多个物种的分化时间和种群大小。在本章末尾，我们简要讨论了利用树模型来模拟重组事件所面临的挑战，并总结了该领域近期的工作以及有待探索的前沿领域。

28.2 Inferring Orthologs/Paralogs, Gene Duplication and Loss

有两种常用的树，即物种树和基因树。本节解释如何使用这些树以及如何将基因树拟合到物种树内（调和）。

28.2.1 Species Tree

物种树展示了不同物种如何从彼此演化而来。这些树是利用形态特征、化石证据等创建的。每棵树的叶子被标记为物种，树的其余部分展示了这些物种之间的关系。图28.1显示了一个物种树的例子。注意：在讲座中提到，一个物种可以被视为一个“基因袋”，即一个物种成员间共有基因的集合。

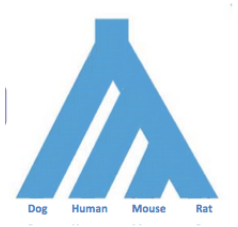

图 28.1：物种树

28.2.2 Gene Tree

基因树是研究不同物种中特定基因的树。基因树的叶子节点标注有基因序列或与特定序列关联的基因ID。图28.2展示了一个基因树的例子，该树包含4个基因（叶子节点）。每个基因相关的序列展示在图28.2的右侧。

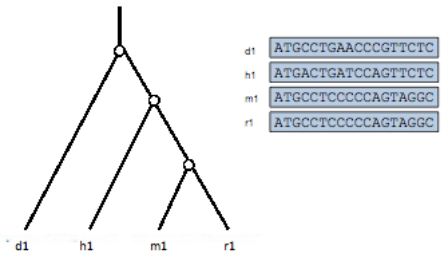

图 28.2：基因树

28.2.3 Gene Family Evolution

基因树在物种树内部演化。图28.3下方展示了包含在物种树中的一个基因树示例。

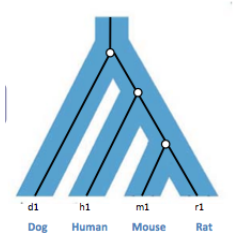

图28.3：物种树内的基因树

下一小节将解释如何使用调和（Reconciliation）将基因树嵌入物种树中。

28.2.4 Reconciliation

调和是一种算法，通过将基因树适配到物种树内部，帮助比较基因树与基因组树。这是通过将基因树中的顶点映射到物种树中的顶点来完成的。本小节将重点介绍调和、相关定义、算法（最大简约调和与SPIDIR）以及示例。

Definitions

如果两个基因的最近共同祖先（MRCA）是一次物种形成事件（分裂成不同的物种），那么这两个基因就是**orthologs**。
Paralogs 是那些其最近共同祖先为重复的基因。
图28.4展示了这类基因在基因树中如何表示。下面的树有4个物种形成节点、一个复制和一个丢失。

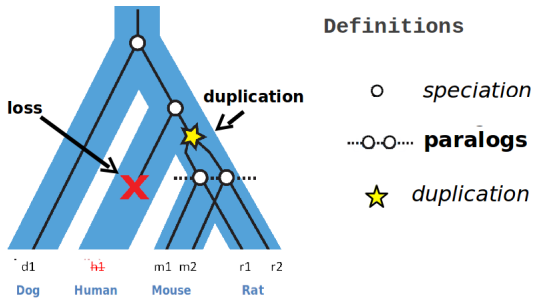

图 图28.4：基因家族进化：基因树与物种 树

映射图是显示从基因树到物种树的节点映射的图。图28.5展示了一个映射图的例子。

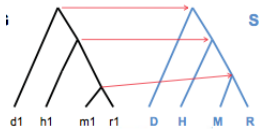

图28.5：映射图

嵌套图展示了基因树如何嵌套在物种树内。对于每个映射图，都有一个嵌套图。图28.6展示了图28.5中映射图的一个可能嵌套图示例。

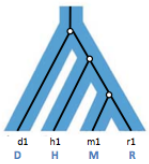

图 28.6：嵌套图

Maximum Parsimony Reconciliation (MPR) Algorithm

MPR是一种算法，它将基因树拟合到物种树中，同时最小化重复和缺失的数量。

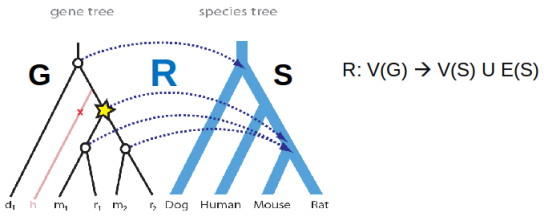

图28.7：最大简约调和（MPR ）

给定一棵基因树和一棵物种树，该算法寻找使重复和缺失数量最小化的调和关系。上方的图28.7展示了从基因树到物种树的一种可能映射示例。图28.8给出了MPR算法的伪代码。基本情况涉及将基因树的叶子与物种树的叶子进行匹配；随后算法沿基因树的顶点向上推进，在给定顶点子树内所有叶子的MRCA与物种树中对应的MRCA顶点之间建立关系。在伪代码中，I(G)表示物种树，L(G)表示基因树。

Solve recursively:
•R[v] = *species of* v if v ∈ L(G)
•R[v] = LCA(R[right(v)] , R[left(v)]) if v ∈ I(G)
•LCA = “least common ancestor”
(also called “most recent common ancestor”)

Labeling events:
•v is a dup if R[v] = R[right(v)] or R[left(v)]
•Branch above v has at least one loss if R[parent(v)] != R[v] or parent[R[v]]

图28.8：最大简约性协调递归算法

我们尽可能将箭头映射得低，因为较低的映射通常导致较少的事件。然而，我们不能映射得太低。映射得太低意味着违反了给定节点的MRCA至少与其子节点的MRCA一样高的约束。在不违反后代-祖先关系的前提下，我们尽可能低地映射。该算法从叶子开始自底向上递归进行。由于我们从已知物种中采样基因来构建基因树，基因树的叶子与物种树的叶子之间存在直接映射。为了映射祖先，对于每个节点（沿树递归向上），我们查看右子节点和左子节点，并取它们所映射到的物种的最近共同祖先（LCA）。如果一个节点映射到其右子节点或左子节点，我们知道存在一个复制。一个不存在的预期分支表示一个丢失。

Reconciliation Examples

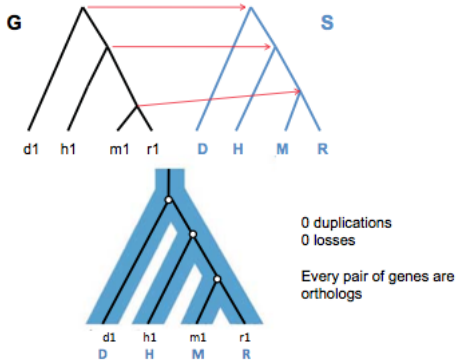

图28.9：对账示例1，简单映射情况

在图28.9中，节点可以直接映射，因为没有重复或丢失。

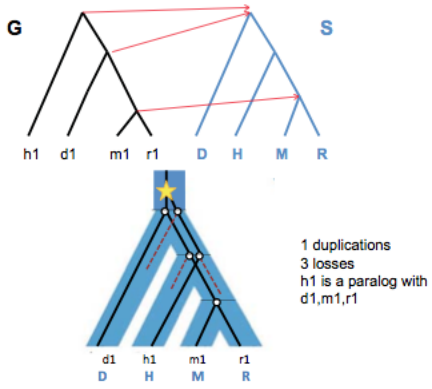

图28.10：对账示例2，复杂情况下的简约对账

在图28.10中，我们看到了一个简约（丢失和重复数最少）的调和案例，其中基因树的节点不能直接映射。这是由于基因树中h1和d1的位置互换所致；d1、m1和r1的最近共同祖先现在是物种树的根顶点。

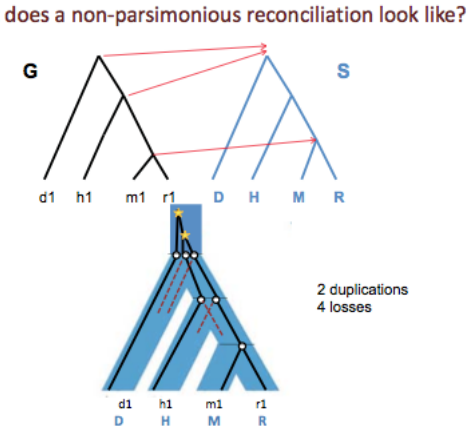

图28.11：对账示例3，复杂情况下的非简约对账

图28.11展示了一个非简约的调和。相同树的简约映射如图28.9所示。

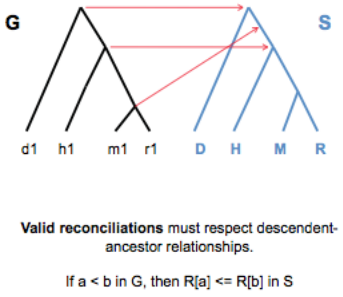

图28.12：对账示例4，无效对账

图28.12展示了一个无效的调和。这个调和之所以无效，是因为它不遵循后代-祖先关系。为了使这种调和成为可能，后代必须时间倒流并在其祖先之前被创造出来。显然，这样的场景是不可能发生的。有效的调和必须满足以下条件：**If a $<$ b in G, then R[a] $\leq$ R[b] in S**。

28.2.5 Interpreting Reconciliation Examples

当基因树与物种树进行比对时，能为了解进化事件（即基因重复和丢失）提供重要见解。基因重复描述的是同一基因在另一个位点被发现的现象——在此情况下为m2或r2——并且是产生新基因和新功能的主要机制。这些进化后果分为三类：非功能化、新功能化和亚功能化。非功能化相当常见，会导致其中一个拷贝，不出所料地，简单地失去功能。新功能化是指其中一个拷贝发展出全新的功能。亚功能化则是指各拷贝保留不同的部分（在某种程度上是分工），它们共同执行相同的功能。

在图4中，我们看到在鼠和鼠类物种分化之前发生了一次复制事件。这就是为什么我们在m1和m2处看到相似的基因，它们代表两个独立的位点。d2和h2未包含在图中，因为在所考虑的基因在这两个位点上不存在（由于没有发生复制事件），而在m2和r2处都存在。

如果复制事件发生在图4中更高一级的位置，且在基因树中没有观察到相应的h2，这将意味着物种树的h分支内发生了丢失。

28.3 Reconstruction

在上一节中，我们学习了如何比较和合并基因树与物种树。在本节中，我们将利用这些信息来重建基因树和物种树。

28.3.1 Species Tree Reconstruction

过去，要找到一种能揭示特定物种分化情况的标记基因真的很难。随着测序技术的进步，我们开始拥有大量关于各种基因的测序数据。基于不同的位点集合，人们构建了不同的树，而这些树高度依赖于所选择的位点集。树之所以不同的可能原因包括噪声（来自统计估计误差和噪声）、隐藏的重复与丢失，以及种群中的等位基因分选。

Species Tree Reconstruction Problem

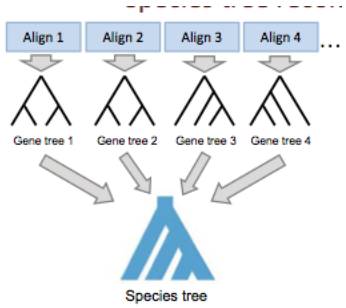

图28.13：物种树重建

给定许多相互不一致的不同基因树，我们的目标是将其整合为一棵物种树（如图28.13所示）。重建物种树的算法有很多。这些算法包括超级矩阵方法（Rokas 2003, Ciccareli 2006）、超级树方法（Creevey & McInerney 2005）、最小化深度溯祖（Maddison & Knowles 2006）以及溯祖建模（Liu & Pearl 2007）。

一种对于噪声数据大多有效的方法是，汇集更多数据以提高准确性。这是通过将基因比对连接成一个超矩阵来做到的。

另一种方法涉及 b　　为每一个构建一棵树，并采用共识方法　　总结这些

树。然后，我们在众多树木中识别出相似的枝条，并构建一个物种树，包含出现频率最高的枝条。

还有一种重建物种树的方法，当基因树因复制和丢失而产生分歧时，这种方法尤为有效。目标是找到应用最少复制事件的物种树。我们构建所有基因树，然后提出一个物种树。接着，我们利用调和分析来确定每个基因树与 proposed 物种树结合所暗示的事件数量。之后，我们提出其他物种树并调整分支位置。错误的物种树往往包含许多并未实际发生的事件。正确的树应该拥有最少的事件数量。

28.3.2 Improving Gene Tree Reconstruction and Learning Across Gene Trees

我们可以使用与上述类似的方法来构建更好的基因树。这可以通过利用物种树的信息来研究感兴趣的基因树来实现。例如，物种树可以用来确定丢失和复制发生的时间。其思路是，我们可以利用物种树通常是从整个基因组构建的这一事实，来获取更多关于相关基因树的信息。我们可以同时使用分支长度和事件数量来实现这一点。

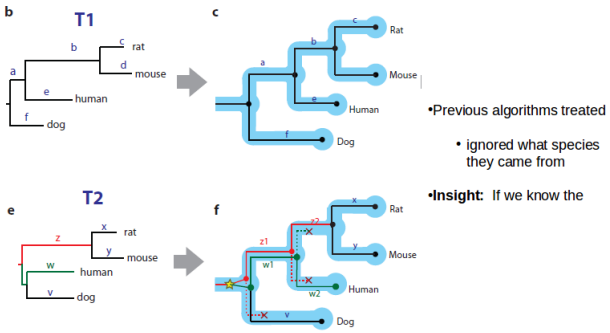

图28.14：使用物种树来改进基因树重建。

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

如果我们知道物种树，就可以建立一个模型来预测我们可能预期什么样的分支长度。我们可以利用保守的基因顺序来识别直系同源基因并构建树。

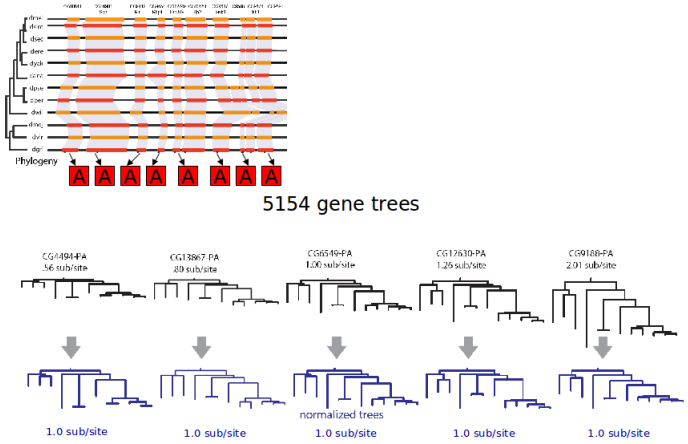

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图28.15：我们可以建立一个模型，用以预测可期望的分支长度类型。通过保守的基因顺序，我们能够辨识直系同源基因并构建进化树。

当一个基因在一个物种中快速进化时，它在所有物种中都会快速进化。我们可以将分支长度建模为两个不同的速率组成部分。一个是基因特异性的（存在于所有物种中），另一个是物种特异性的，它是针对特定物种定制的。

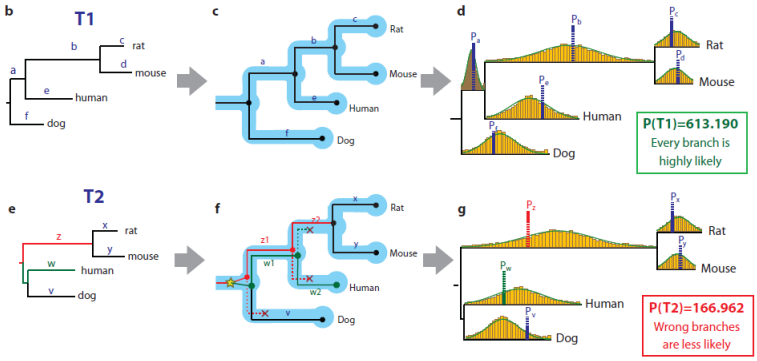

图28.16：分支长度可以建模为两个不同的速率分量：基因特异性和物种特异性。

该方法大大提高了重建精度。

28.4 Modeling Population and Allele Frequencies

随着下一代测序技术的出现，对群体内众多 _v2 个体的基因组进行测序变得更为经济。为了理解等位基因如何在群体中传播，有一个模型来对比数据是很有帮助的。在过去的70年里，{v*}繁殖模型一直扮演着这一角色。

28.4.1 The Wright-Fisher Model

与HMM类似，赖特-费舍尔过程也是一个马尔可夫过程：在每一步中，系统随机演进，而系统的当前状态仅依赖于前一个状态。在这种情况下，状态转移代表繁殖。通过建模染色体向后代的传递，我们可以研究遗传漂变。

该模型做出了许多简化假设：

1. 种群大小，**N**，在每一代中保持不变。
2. 仅同代成员繁殖（无重叠）。
3. 繁殖随机发生。
4. 所建模的基因仅有两个等位基因。
5. 基因经历中性选择。

请注意，如果你想模拟一个正选择或负选择的基因频率变化，Wright-Fisher 并不是一个合适的选择。如果我们使用 Wright-Fisher 来模拟二倍体个体的染色体，模型的群体大小变为 **2N**。

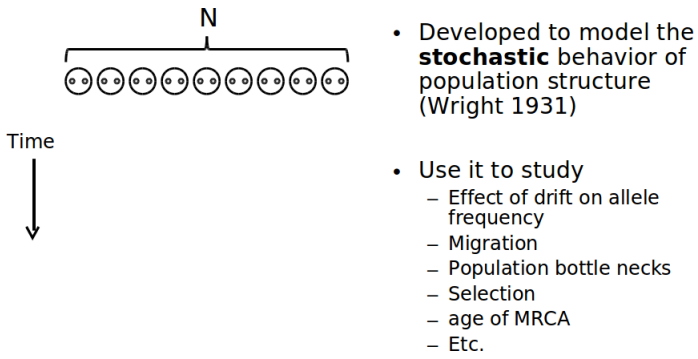

图28.17：赖特-费舍尔模型

用英语来说，Wright-Fisher 的工作原理如下：

在每一代中，对于每个子代，我们随机从亲本中选择（允许重复）。子代的等位基因成为随机选择的亲本的等位基因。

我们对许多代重复这个过程，将子代作为新的亲代，忽略染色体的排序。

就这么简单。要确定当等位基因在亲代中的频率为p时，其在子代中存在k个拷贝的概率，我们可以使用这个公式：

$$\binom{2N}{k} p^k q^{2N-k} \tag{28.1}$$

这里，$q = (1-p)$。它是亲代中非p等位基因的频率。

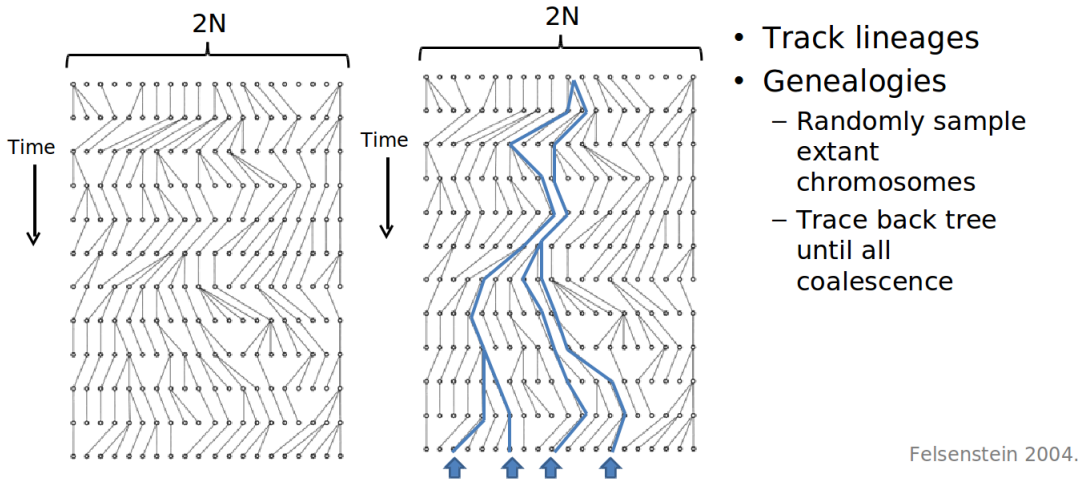

© Sinauer Associates, Inc. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图28.18：赖特-费舍尔模型的多次迭代生成的谱系树

现在我们可以开始探讨这样的问题：它有多大的可能性，以及它经过了多少代

一个给定等位基因预计需要多长时间才能成为**fixed**，即该等位基因在种群中的$every$个成员中存在?

在Wright-Fisher假设下，固定所需的预期时间（以世代计）与$4N_E$成正比，其中N_E是有效种群大小。

再次强调，重要的是要牢记这个模型的局限性，并思考它是否真正适用于你试图表示的系统。考虑如何调整所提出的模型，以适应选择系数在-1（致命负选择）到1（强正选择）之间的情况。

28.4.2 The Coalescent Model

Wright-Fisher 模型的问题在于，它假设你知道祖先世代的等位基因频率。当处理现存物种的基因组时，这些量是未知的。溯祖模型通过回溯性思考解决了这一难题。也就是说：我们从第 $current$ 代的等位基因开始，沿着时间 $backwards$ 方向回溯。基本的溯祖模型做出了与 Wright-Fisher 相同的假设。在每一代，我们问：两个相同等位基因在上一代合并或共享一个亲本的概率是多少。

我们可以将前一代发生合并事件的概率表示为：在最后一代之前的任意$t-1$代中发生合并not的概率，乘以它在上一代（第t代）发生的概率。这等价于表达式：

$$P_c(t) = \left(1 - \frac{1}{2N_e}\right)^{t-1} \left(\frac{1}{2N_e}\right) \tag{28.2}$$

其中N_e是有效种群大小。

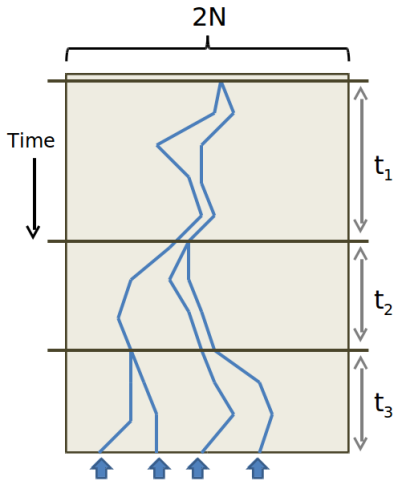

图28.19：合并模型。

通过将这个几何分布近似为指数分布：$P_c(t) = \frac{1}{2N_e} e^{-\left(\frac{t-1}{2N_e}\right)}$，我们可以确定回溯到合并的期望世代数，其结果是$2N_e$，标准差为$2N_e$。

要询问在给定世代中*multiple*个谱系的合并情况，我们必须像在Wright-Fisher模型中那样使用二项分布。k个谱系在第t代发生第*first*次合并的概率是：

$$P(T_k = t) = \left(1 - \binom{k}{2}\frac{1}{2N}\right)^{t-1}\binom{k}{2}\frac{1}{2N} \tag{28.3}$$

同样，对于足够大的 k，这可以用指数分布来近似。两条谱系汇合的个体被称为 **Most Recent Common Ancestor**。通过不断向前回溯直到所有祖先合并，我们最终得到一种新的树！通过将合并产生的树与我们构建的基因树进行比较，两者之间的差异可能表明溯祖模型的某些假设已被违反。也就是说，可能正在发生选择。

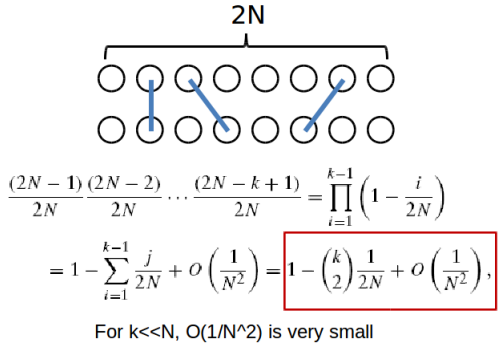

图28.20：k个谱系中合并事件的几何概率分布。

28.4.3 The Multispecies Coalescent Model

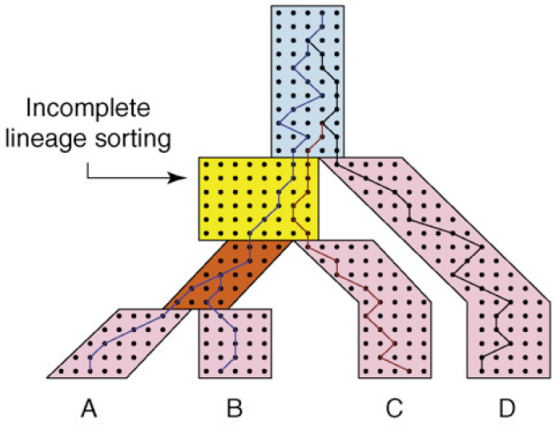

图28.21：多物种溯祖模型。

承蒙爱思唯尔公司惠允。使用须经许可。来源：Degnan, James H., 和 Noah A. Rosenberg。“基因树不一致性、系统发育推断与多物种溯祖过程。” *Trends in Ecology & Evolution* 24, no. 6 (2009): 332-40。

我们可以更进一步，追踪多个物种间的合并事件。在这里，每个物种的个体基因组被视为一个谱系。

注意，两个种群分离与两个基因谱系合并到一个共同祖先之间有一个滞后时间。还要注意，随着 N 变大以及对于短分支，合并速率是如何减慢的。

在上图中，三个谱系的深度合并以浅蓝色表示。这里的物种树和基因树不一致，因为在基因树中C和D是姐妹群，但在物种树中则不是。

有$\frac{2}{3}$的概率会发生不一致，因为一旦我们到达浅蓝色部分，Wright-Fisher过程便无记忆性，且仅有^{1}的概率保持一致。不一致的影响被称为$_3$**Incomplete Lineage Sorting**。通过测量**ILS**发生的频率，我们可以洞察物种树中异常大的种群或异常短的枝长。

你可以基于最小化ILS事件数量的概念，而非先前讨论的最小化隐含的复制/丢失事件，来构建最大简约物种树。甚至可以将这两种方法结合起来，理想情况下，创建一个比单独使用任一方法都更准确系统发育树。

28.5 SPIDIR

28.5.1 Background

正如SPIDIR的补充信息中所介绍的，一个基因家族是指在所有考虑物种的最近共同祖先（MRCA）中，源自单一基因的一组基因。此外，遗传序列在多个尺度上经历进化，即在碱基对层面和基因层面。在本讲座的背景下，如果两个基因的MRCA是物种形成事件，则它们是直系同源基因；如果两个基因的MRCA是复制事件，则它们是旁系同源基因。

在基因组时代，现代基因的物种通常是已知的；通过调和基因树与物种树，可以推断祖先基因。调和过程将每个基因树节点映射到物种树节点。一种常用技术是执行最大简约调和（Maximum Parsimony Reconciliation, MPR），它通过沿基因树G的内部节点v进行递归，找到暗示最少复制或丢失数量的调和R。MPR首先将基因树的每个叶节点映射到物种树对应的物种叶节点。然后，G的内部节点被递归映射：

$$R(v) = MRCA(R(right(v)), R(left(v)))$$

如果一个物种形成事件及其祖先节点被映射到物种树上的同一节点，那么该祖先节点必定是一个 duplication 事件。

使用MPR时，基因树的准确性至关重要。次优的基因树可能导致过多的丢失和复制事件。例如，如果只有一个分支位置错误（如??所示），那么调和分析会推断出3次丢失和1次复制事件。在[6]中，作者表明，当前的同期基因树方法在单基因上的表现不佳（准确率为60%）。但如果我们有更长的串联基因，准确率可能会提高到接近100%。此外，进化非常快或非常慢的基因与中等分化的序列（40-50%的序列一致性）相比携带的信息更少，并且表现相应更差。正如模拟所证实的那样，单基因缺乏足够的信息来重现正确的物种树。平均基因太短，包含的系统发育信息字符太少。虽然许多早期的基因树构建算法忽略了物种信息，但像SPIDIR这样的算法利用了物种树可以提供额外信息这一洞见，这些信息可用于基因树构建。同线性可用于独立测试不同基因树重建的相对准确性。这是因为同线性区块是基因组中近期分化的生物具有相同基因顺序的区域，并且比单基因包含更多的信息。

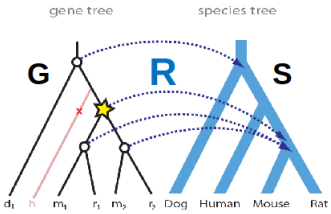

图28.22：基因树与物种树的MPR调和。

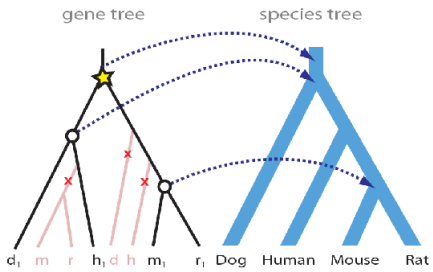

图28.23：基因树中的不准确之处。

最近出现了许多系统发育基因组学算法，包括：RIO [2]，它使用邻接法（NJ）和自举法来处理不一致性；Orthostrapper [7]，它使用NJ并调和到一个模糊的物种树；TreeFAM [3]，它使用人类对基因树的 curation 以及许多其他算法。许多算法采取了与SPIDIR [6]更相似的路线，包括[4]、一种概率调和算法[8]、一种带时钟的贝叶斯方法[9]，以及使用物种树的简约法，还有更多

近期进展：[1] 一种具有松弛时钟的贝叶斯方法以及[5] 一种具有基因和物种特异性松弛速率的贝叶斯方法（SPIDIR的扩展）。

28.5.2 Method and Model

SPIDIR是使用物种树构建基因树的一种迭代算法的典范。在SPIDIR中，作者定义了基因树进化的生成模型，该模型包括基因树拓扑结构和分支长度的先验。SPIDIR利用生灭过程来建模基因重复和丢失（这为拓扑结构的先验提供信息），进而学习基因特异性和物种特异性的替换速率（这为分支长度的先验提供信息）。SPIDIR是一种$Maximum\ a\ posteriori\ (MAP)$方法，因此，它享有若干优良的最优性准则。

就估计问题而言，完整的SPIDIR模型呈现如下：

$$argmax L,T,RP(L,T,R|D,S,\Theta) = argmax L,T,RP(D|T,L)P(L|T,R,S,\Theta)P(T,R|S,\Theta)$$

上述方程中的参数为：D = 对齐数据，L = 分支长度 T = 基因树拓扑结构，R = 调和，S = 物种树（以时间表示），Θ = (基因和物种特定参数[使用EM训练估计]，λ，μ 复制/丢失参数)）。该模型可以通过右侧表达式中的三项来理解，即：

1. 序列模型 – $P(D|T,L)$。作者采用了常见的HKY模型进行序列替换，该模型统一了Kimura关于转换和颠换的双参数模型与Felsenstein模型，其中替换率依赖于核苷酸平衡频率。

2. 第一个先验项，针对速率模型 – $P(L|T,R,S,\Theta)$，作者在学习了物种和基因特异性速率后通过数值计算得出。

3. 第二个先验项，针对复制/丢失模型——$P(T,R|S,\Theta)$，作者使用生灭过程来描述。

拥有一个速率模型是非常有用的，因为基因间的突变率差异很大。在讲座中，我们了解到速率可以通过基因和物种特异性速率的分解得到很好的描述。讲座中提到，逆伽马分布似乎能参数化基因特异性替换速率，并且我们被告知伽马分布显然能捕捉物种特异性替换速率。考虑基因和物种特异性速率使得SPIDIR能够比以往方法更准确地构建基因树。可以从与物种树一致的基因树中选择用于学习速率参数的训练集。基因树重建的一个重要算法关注点是设计快速的树搜索方法。在讲座中，我们了解到可以通过仅计算高先验概率树的完整$argmax L,T,RP(L,T,R|D,S,\Theta)$来加速树搜索。这是通过一个计算流程实现的，其中每次迭代通过某种启发式方法提出数百棵树。拓扑先验$P(T,R|D,S,\Theta)$可以快速计算。这被用作过滤器，仅选择具有高先验概率的拓扑作为完整似然计算的候选。

SPIDIR 的性能在包含 21 种真菌的真实数据集上进行了测试。SPIDER 恢复了超过 96% 的共线性直系同源基因，而其他算法发现的不到 65%。因此，SPIDER 引发的重复和丢失数量要少得多。

28.6 Ancestral Recombination Graphs

图28.24：重组。

在图28.24 a中，顶部的两条染色体代表一对同源染色体。红色染色体代表来自母亲的遗传信息，蓝色染色体代表来自父亲的遗传信息（即祖父母代）。在没有交叉互换（重组）的情况下，亲本将要么传递红色要么传递蓝色的遗传信息给子代。实际上，在减数分裂期间会发生重组，因此亲本会传递来自两位祖父母的一些遗传信息，有效地传递了亲本遗传信息的更好表示。

在每一代中，任何一个位点都可能发生重组事件。重组进化的历史可以通过树序列图来追踪，使得图中的第i棵树代表第i个位点的重组。

Fill in this section based on: www.eecs.berkeley.edu/yss/Pub/SH-JCB05.pdf *and the course notes from 2012.*
未来可以增加更多关于这个主题的内容

28.6.1 The Sequentially Markov Coalescent

顺序马尔可夫溯祖模型解决了重组在树构建中的作用。由于涉及重组，一个序列可能有两个父节点，这使得构建变得复杂。顺序马尔可夫溯祖模型告诉我们，从左到右依次移动是一种更简单且效率更高的树分析方法；该方法本质上将树分解为局部树，并通过叠加它们来描述重组事件。更多内容可阅读以下论文：

详细阐述模型本身的复杂性：http://www.ncbi.nlm.nih.gov/pubmed/21270390

28.7 Conclusion

通过引入独立的基因和物种替换率，将物种树信息整合到基因树构建过程中，可以实现准确的简约基因树重建。以往的基因树重建可能大大高估了复制和丢失事件的数量。为大型基因家族重建基因树仍然是一个具有挑战性的问题。

28.8 Current Research Directions

28.9 Further Reading

- 关于在酵母中发现全基因组复制事件的论文：http://www.nature.com/nature/journal/v428/n6983/pdf/nature02424.pdf

28.10 Tools and Techniques

28.11 What Have We Learned?

在本章中，我们得出了关于基因树与物种树之间关系的结论。随后，我们探讨了利用基因树来构建更准确的物种树的方法，反之亦然，这些方法涉及特定于基因和物种的突变率。Wright-Fisher模型以及Coalescent模型帮助我们进一步解读这些突变率，并理解种群内等位基因频率的动态变化。

Bibliography

[1] O. Akerborg, B. Sennblad, L. Arvestad, and J. Lagergren. 贝叶斯基因树重建与协调分析. *Proc Natl Acad Sci*, 106(14):5714–5719, Apr 2009.

[2] Zmasek C.M. 和 Eddy S.R. 利用重采样直系同源推断进行自动化系统发育基因组学蛋白质组分析。*BMC Bioinformatics*, 3(14), 2002.

[3] Li H, Coghlan A, Ruan J, Coin LJ, Heriche JK, Osmotherly L, Li R, Liu T, Zhang Z, Bolund L, Wong GK, Zheng W, DEhal P, Wang J, and Durbin R. Treefam：动物基因家族系统发育树的精选数据库。*Nucleic Acids Res*, 34，2006。

[4] Arvestad L., Berglund A., Lagergren J., 和 Sennblad B. 使用MCMC的贝叶斯基因/物种树协调及同源性分析。*Bioinformatics*, 19 Suppl 1, 2003.

[5] M. D. Rasmussen 和 M. Kellis. 一种快速准确的基因树重建的贝叶斯方法. *Mol Biol Evol*, 28(1):273290, 2011年1月. [6] Matthew D. Rasmussen 和 Manolis Kellis. 通过学习跨多个完整基因组的基因和物种特异性替换率来准确重建基因树. *Genome Res*, 17(12):1932–1942, 2007年12月.

[7] C.E.V. Storm 和 E.L.L. Sonnhammer。基于系统发育树的自动直系同源推断及直系同源性可靠性计算。《*Bioinformatics*》，18(1)：92–99，2002年1月。

[8] Hollich V., Milchert L., Arvestad L., 和 Sonnhammer E. 蛋白质距离测度及建树方法在系统发育树重建中的评估。*Mol Biol Evol*, 22:2257–2264, 2005.

[9] Wapinski, I. A. Pfeffer, N. Friedman, and A. Regev. 全基因组系统发育基因树的自动重建。*Bioinformatics*, 23(13):i549–i558, 2007.

CHAPTER

TWENTYNINE

POPULATION HISTORY

David Reich 的客座讲座，由 Deena Wang 记录（2013年），Brian Cass（2010年），Layla Barkal 和 Matt Edwards（2009年）

Figures

29.1 两个亚群之间的相似性可以通过在散点图中比较等位基因频率来衡量。这些图显示了欧洲裔美国人和美洲印第安人种群的相对差异性，以及欧洲裔美国人和中国人群体的较大相似性。 441

29.2 种群可以投影到其他种群的主成分上：将南亚人投影到中国人和欧洲人的主成分上会产生线性效应（印度梯度），而将欧洲人投影到南亚人和中国人的主成分上则不会。 443

29.3 一个符合印度历史的混合图 444

29.4 不同人类群体的主成分分析在二维上的投影。 446

29.5 祖先基因流的数据和模型 447

29.6 古代欧洲人在所有现代欧洲人群的二维PCP上的投影。现代西欧人，主要由左下方的斜线表示，不能仅描述为EEF和WHG人群的混合。然而，加入ANE成分后，这些变异就能得到解释。 448

29.7 欧洲遗传组成随时间的变化显示了两次大规模迁徙：首先，EEF人群的迁徙几乎完全替代了本土WHG人群；其次，ANE颜那亚人群的迁徙替代了当时约75%的本土人群。 450

29.8 从8000年前至今欧洲人群的身高选择。。。。。450

29.1 Introduction

人类彼此之间共享99.9%的遗传信息，与黑猩猩的相似度高达99%。尽管人类的遗传多样性相比许多其他物种要少[?]，但人群中的多态性仍能导致疾病风险的差异。了解人类之间0.1%的差异，可用于理解种群历史、追踪血统、预测疾病及分析自然选择趋势。

在本讲座中，哈佛医学院的David Reich博士描述了三个基因流动的人类种群历史案例：由于奴隶贸易导致的非洲人与欧洲人之间的基因流动，因迁移引起的印度人混血，以及尼安德特人、丹尼索瓦人与西欧亚血统现代人之间的杂交。

29.2 Quick Survey of Human Genetic Variation

在人类基因组中，大约每1000个碱基就存在一个多态性，尽管有些区域的多态性频率可高达四倍。这些单核苷酸多态性（SNPs）是遗传变异的一种表现形式。当SNPs发生时，它们根据重组率、突变的优势或劣势，以及SNP存在期间持续存在的种群结构进行分离。例如，在一次基因混合事件后，最初可见来自每个组成部分的整条染色体或近乎整条染色体。随着世代更迭，重组将这些SNP单倍型区块分割成更小的片段。因此，这些区块长度变化的速度取决于重组率及重组产物的稳定性。故而，保守单倍型的长度可用于推断突变或其特征选择的时间。然而，一个重要的考量是，重组率在基因组中并非均匀分布；相反，存在可扭曲单倍型年龄或选择性测量的重组热点。这使得单倍型区块比在均匀模型下预期的要长。

基因组中的每一个位置在个体间比较时都可以被视为一棵树。根据你在基因组中观察的位置不同，一棵树会与从特定SNP集合中得到的另一棵树不同。技巧在于利用我们手头关于SNP的数据来推断潜在的树，进而推断总体的系统发育关系。例如，Y染色体几乎不发生重组，因此能够生成一棵高度准确的树，因为它从父亲传给儿子。同样，我们可以研究从母亲传给孩子的线粒体DNA。虽然这些树可能具有高准确性，但其他常染色体树因重组而变得复杂，因此在预测系统发育关系时准确性较低。基因树最好通过观察低重组区域来构建，因为重组会混合树。通常，每代大约发生1到2次重组。

人类显示出大约10,000个碱基对的连锁，这对应于我们追溯大约10,000代的时间。相比之下，果蝇的连锁平衡块仅有几百个碱基。一个等位基因的固定将随时间发生，其速度与种群大小成正比。对于约10,000的种群，达到固定点大约需要10,000年。当种群增长时，基因漂变的效果减弱。奇怪的是，人类的变异看起来就像是在一个大小为10,000的种群中形成的那样。

如果将长单倍型映射到遗传树上，大约一半的深度位于第一条分支上；大多数形态变化发生在树的深处，因为有更多时间发生突变。一个没有自然选择的简单突变模型是Wright-Fisher中性模型，它利用二项抽样。在这个模型中，一个SNP要么达到固定（频率为1），要么消失（频率为0）。

在人类基因组中，t 这里有1000万到2000万个常见的SNPs。这相对较少 与黑猩猩相比，{v*}具有更强的能力，

这意味着人类在基因上彼此更为接近。

考虑到这种遗传相似性，比较人类亚群可以提供关于共同祖先的信息，并提示历史事件。两个亚群之间的相似性可以通过比较散点图中的等位基因频率来衡量。如果我们把不同群体中SNP的频率标绘在散点图上，我们会看到距离较远的群体之间有更多的散布。例如，下面的图显示了欧洲裔美国人和美洲印第安人群体之间的相对不相似性，以及欧洲裔美国人和中国人群体之间更大的相似性。这些图表明，过去中国人和美洲原住民之间发生了分化，这为考古学家所假设的北美迁徙瓶颈提供了证据。非洲内部不同群体之间的散布相当大。我们可以通过描述方差的固定指数（F_{st}）来衡量散布程度。

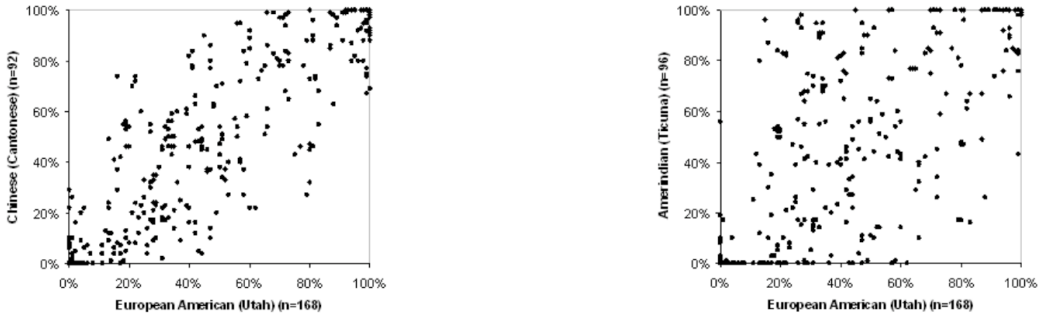

图29.1：两个亚群体之间的相似性可以通过比较散点图中的等位基因频率来衡量。图表显示了欧洲裔美国人和美洲印第安人群体之间的相对不相似性，以及欧洲裔美国人和中国人群体之间更大的相似性。

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

目前有多项研究表明，对遗传数据进行无监督聚类可以恢复自我选择的族群身份标签。[3] Rosenberg的实验采用了贝叶斯聚类算法。他们选取了1000人作为样本（50个群体，每个群体20人），并根据这些人的SNP遗传数据进行聚类，但并未将任何人的群体信息标注出来，以便观察算法在不了解族群信息的情况下如何进行聚类。他们尝试了许多不同的聚类数量，以找到最优数量。当聚类数为2时，东亚人与非东亚人被分开。当聚类数为3时，非洲人被与其他所有人分开。当聚类数为4时，东亚人与美洲原住民被分开。当聚类数为5时，较小的亚群体开始显现。

当一波波人类离开非洲时，遗传多样性随之减少；离开非洲的群体中人数较少，这使得系列奠基者事件得以发生。这些系列奠基者事件导致了遗传多样性较低的亚种群形成。这种奠基者效应通过以下事实得以证明：随着远离非洲，遗传多样性逐渐减少，而西非人的多样性在所有人类亚种群中是最高的。

29.3 African and European Gene Flow

大西洋奴隶贸易发生于16世纪至19世纪，将大约500万人从非洲运往美洲。如今，大多数非裔美国人拥有80%非洲血统和20%欧洲血统的混合遗传。当两个不同族裔的父母生育子女时，他们的子女将从父母各继承一条染色体，而由于重组，他们的孙辈将继承两个族裔镶嵌而成的染色体。随着时间的推移，重组事件的增加将缩短DNA中“非洲”或“欧洲”片段的长度。

重组事件并非均匀分布于染色体上，而是集中在热点区域发生。非洲与欧洲DNA的热点区域存在差异，这可能归因于*PRDM9*氨基酸组成的差异，*PRDM9*是一种组蛋白H3(K4)三甲基转移酶，对减数分裂至关重要。

非洲和欧洲人群的疾病易感性差异可以被预测。通过测序，这一知识也可应用于混合人群。例如，非洲人患前列腺癌的风险较高，这直接与染色体8上的一个区域相关，该区域映射到一个癌症原癌基因[?]。如果一个混血个体在该区域具有非洲序列，他或她将具有增加的风险，但如果该个体具有欧洲序列，他或她将不会具有增加的风险。同样的方法可以应用于乳腺癌、结肠癌、多发性硬化症和其他疾病。

29.4 Gene Flow on the Indian Subcontinent

遗传证据表明，印度次大陆上的现代人群是4000年前两个不同祖先人群融合的后代。研究人员从73个使用不同语系的印度群体中约500名不同个体身上收集了SNP阵列数据[?]。主成分分析图显示，达罗毗荼/印欧语系群体与南亚语系群体分属两个不同的聚类，这表明他们具有不同的世系。在达罗毗荼/印欧语系群体内部，与西欧亚群体的亲缘关系呈梯度变化。

用于非洲/欧洲混血研究中的同一镶嵌技术被用来估计混合的日期。印度人口是中亚/欧洲群体和另一个与安达曼群岛人最密切相关的群体的混合。属于每个群体的DNA片段大小表明大约100代以前，即2，000至4，000年前的混合。许多群体都有这种混合遗传，但在种姓制度形成后，混合就停止了。

基因遗传知识可以预测疾病。例如，南亚人群中肌球蛋白结合蛋白C的突变会导致心力衰竭风险增加七倍。许多族群实行内婚制，遗传多样性较低，导致隐性疾病的患病率较高。

过去在印度进行的调查研究了人体测量变异、线粒体DNA和Y染色体等方面。人体测量研究关注了因地理和种族而分隔的群体之间在身体特征上的显著差异。结果显示，其变异程度远高于欧洲。线粒体DNA研究是对母系血统的调查，结果表明存在单一的印度谱系树，因此可以通过突变数量推断谱系的年龄。数据还显示，印度人群至少在40,000年前就与非印度人群分离。最后，Y染色体研究考察了父系血统，并显示与中东男性有较晚近的相似性，且依赖于地理和种姓。这些数据与线粒体DNA结果相冲突。一种可能的解释是存在较晚近的男性迁移。无论如何，在印度进行的遗传研究已经表明其遗传复杂性。高度的遗传变异、与其他样本的差异性以及获取更多样本的困难，导致印度被排除在HapMap、1000 Genomes Project和HGDP之外。

在David Reich及其合作者对印度的研究中，选取了25个印度群体，以代表不同的地理区域、语言根源和民族。原始数据包含每个25个群体中的五个样本。尽管这个数字看起来很小，但每个样本的SNP数量包含了大量信息。每个个体大约有五十万个标记进行了基因分型。观察研究得出的数据，如果对来自西亚欧亚大陆和亚洲的数据使用主成分分析，并且如果使用相同的成分比较印度人口，就会出现印度倾斜线。这显示了一种相似性的渐变，可能表明印度人群体的交错分化和

欧洲人口。

29.4.1 Almost All Mainland Indian Groups are Mixed

对印度渐变现象的进一步分析产生了有趣的结果。例如，一些巴基斯坦次群体也具有沿印度渐变分布的祖源。群体可以投影到其他群体的主成分上：将南亚人投影到中国人和欧洲人的主成分上会产生线性效应（印度渐变），而将欧洲人投影到南亚人和中国人的主成分上则不会。一种解释是印度祖源比其他群体表现出更大的变异性。在比较非洲与非非洲群体时也出现了类似的变异性评估。这一分析产生了两种树形假说：

1. 印度历史上有过多次连续的创始人事件，或者
2. 祖先种群之间存在基因流动。

作者开发了一种正式的四群体检验，用于在存在混合或其他混杂效应的情况下检验血统假设。该检验采用一个提出的树拓扑结构，并对所有SNP求和(Pp1 Pp2)(Pp3 Pp4)，其中P值代表四个群体的频率。如果提出的树是正确的，相关性将为0，并且所讨论的群体形成一个分支。这种方法对限制其他模型的几个问题具有抵抗力。可以构建一个完整的模型来拟合历史。来自混合图的拓扑信息可以通过拟合过程用F_{st}值进行增强。这种方法不对群体分裂时间、扩张和收缩以及基因流动持续时间作出假设，从而产生更稳健的估计过程。

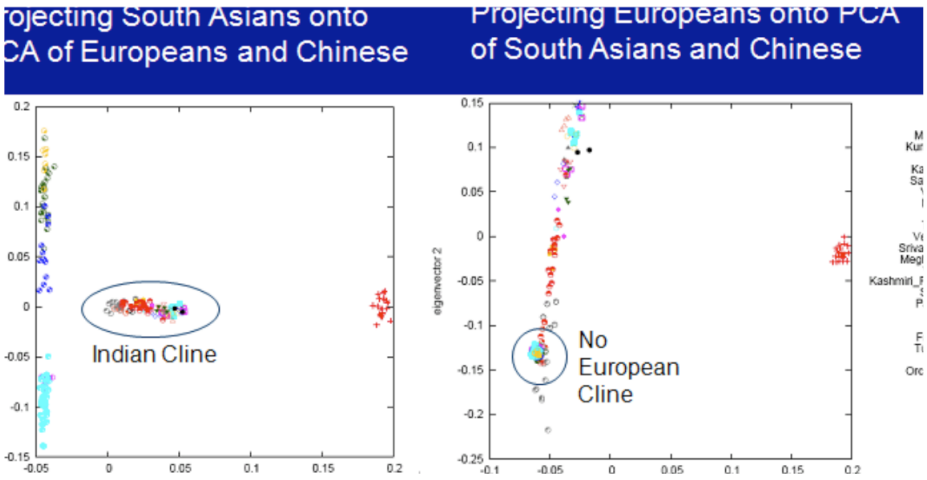

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图29.2：种群可以投影到其他种群的主成分上：南亚人投影到中国人和欧洲人的主成分上产生线性效应（印度渐变群），而欧洲人投影到南亚人和中国人的主成分上则不会。

此外，使用4群体统计量估计混合比例可以给出树上每个群体的误差估计。只要由4群体测试确定的拓扑结构有效，复杂的历史不会影响这一计算。

这些测试和cline分析使作者能够确定每个代表性人口样本中祖先北印度血统和祖先南印度血统的相对强度。他们发现

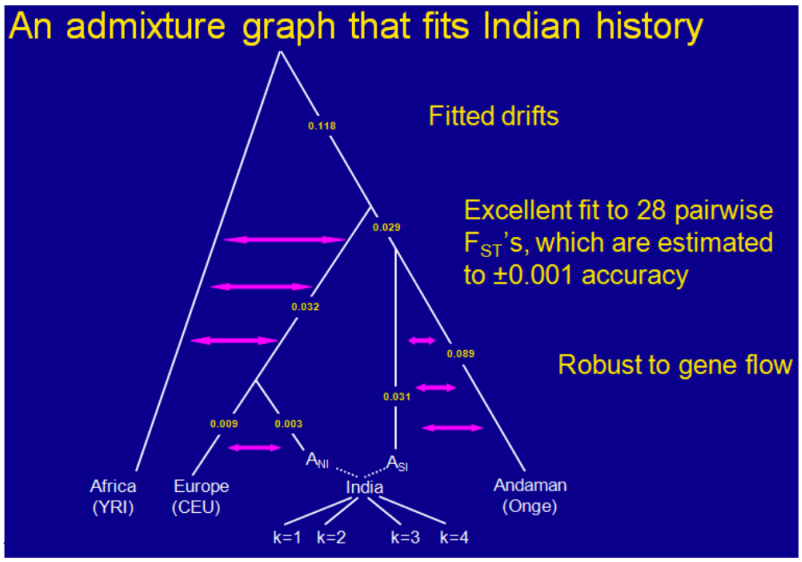

图29.3：一个符合印度历史的混合图

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

高祖先北印度血统与传统上较高的种姓以及某些语言群体相关。此外，祖先北印度（ANI）和南印度（ASI）血统与中国人之间的差异，和欧洲人一样大。

29.4.2 Population structure in India is different from Europe

与欧洲相比，印度的人口结构与地理的相关性要小得多。即使对语言、地理和社会地位差异进行校正后，F_{st}值仍为0.007，约为欧洲差异最大人群的7倍。一个未解之谜是，这是否可能是由于基因分型芯片上缺失（主要是印度特有的）SNP所致。这是因为目标SNP集主要来自HapMap项目，而该项目并未包含印度来源。

大多数印度遗传变异并非源自印度以外的事件。此外，近亲结婚无法解释这一信号。许多连续的奠基者事件，或许与种姓或先驱群体有关，可能有所贡献。逐一分析单个群体时，很明显种姓和亚种姓存在大量内婚制。通过分析群体内样本对之间等位基因共享的自相关性，可以判断是否发生过奠基者事件及其相对年代。存在来自奠基者的DNA片段，许多表明事件发生在1000多年前。在大多数群体中，有证据表明存在强烈的古代奠基者事件及随后的内婚制。这与欧洲或非洲大部分地区的种群结构形成对比，那里种群混合更多（内婚制较少）。

这些连续的奠基者事件及其由此形成的结构具有重要的医学意义。强烈的奠基者事件，随后发生的内婚制以及一定程度的混合，导致了某些群体对各种隐性疾病具有强烈的易感性。这种结构意味着印度群体拥有一系列流行疾病，类似于在其他群体中已经已知的那些疾病，例如德系犹太人或芬兰人。印度内部独特的变异意味着，仅使用非印度数据来源可能无法发现与印度流行的疾病等位基因之间的连锁关系。为了更好地绘制这些隐性疾病的图谱，需要从每个群体中采集少量样本，并涵盖更多群体。然后，这些图谱可用于更好地预测印度的疾病模式。

29.4.3 Discussion

总体而言，强烈的奠基者效应随后伴随着内婚制，使得印度比欧洲拥有更多的亚结构。所有调查的部落和种姓群体都显示出ANI和ASI血统的强烈混合，ANI身份在35%到75%之间变化。估计ANI-ASI混合的时间和机制目前是一个高度优先的事项。此外，未来的研究将确定如4-population测试和混合图等新技术是否以及如何应用于其他人群。

29.5 Gene Flow Between Archaic Human Populations

Reich博士曾作为群体遗传学家与马克斯·普朗克研究所合作，研究尼安德特人的遗传数据。本节将讨论他作为尼安德特人基因组计划一部分的研究背景、他们组装的序列草图，以及为现代人类与尼安德特人之间基因流动所汇编的证据。

29.5.1 Background

尼安德特人是唯一另一种拥有与*Homo sapiens*一样大的大脑的原始人类。20万年前的尼安德特人化石已在西欧亚大陆（欧洲和西亚）被发现，这远比*Homo erectus*早。最早的人类化石来自埃塞俄比亚，距今约20万年。然而，有证据表明尼安德特人与人类在13.5万至3.5万年前在时间和空间上存在重叠。

最初的接触地点可能发生在黎凡特地区，即今天的以色列。这里有12万年前的人类化石，之后出现了一段空白，约8万年前的尼安德特人化石，又一段空白，然后6万年前再次出现人类化石。这证明了在同一地点存在重叠，但并非在同一时间。在上旧石器时代，出现了人口大量迁出非洲的爆发（大约6万至4.5万年前的迁徙）。在4.5万年前的欧洲，有些遗址的化石记录中尼安德特人和人类并存。既然有证据表明这两个物种曾共存，那么是否存在杂交？这是一个可以通过研究群体基因组学来回答的问题。

关于从尼安德特人提取DNA的讨论，请参见工具和技术。

29.5.2 Evidence of Gene Flow between Humans and Neanderthals

1. 尼安德特人DNA与来自非洲和非非洲人群的人类DNA之间的比较测试表明，非非洲人群与尼安德特人的亲缘关系比非洲人群更近。我们可以查看基因组中的所有SNP，观察来自某一人群的人类SNP是否与尼安德特人的SNP相匹配。当将不同的人类人群与尼安德特人进行比较时，发现法国人、中国人和新几内亚人的SNP与尼安德特人的SNP匹配程度远高于尼日利亚约鲁巴人的SNP与尼安德特人的SNP匹配程度。来自非洲的桑人和约鲁巴人群，尽管在遗传上非常不同，但与尼安德特人DNA的距离相同。这一证据表明，从非洲迁出的人类人群与尼安德特人发生了杂交。

2. 一项长距离单倍型研究表明，当单倍型树的最深分支出现在非非洲人群中时，这些区域经常与尼安德特人DNA相匹配。非洲人群

今天，它们是世界上最多元化的群体。当人类迁出非洲时，由于奠基者效应，多样性减少了。根据这段历史，人们会预期，如果构建一棵关系树，最深的裂分会是非洲。

为了展示尼安德特人的遗产，伯克利的研究人员选取了基因组中的长片段，并在来自不同人群的随机挑选的人类中进行了比较。由该单倍型构建的系统树中，最深的支系几乎总是来自非洲人群。然而，偶尔非非洲人会拥有最深的支系。研究发现，有12个区域是非非洲人拥有最深支系的地方。当这些数据被用于分析尼安德特人基因组时，发现非非洲人的这些区域中有10个与尼安德特人的匹配程度超过与人类参考序列（来自不同人群序列的汇编）的匹配。这是该单倍型实际上源自尼安德特人的证据。

3. 最后，人类之间的差异比预期要大。尼安德特人与人类之间的平均分化时间约为80万年。而两个人类个体之间的典型分化时间约为50万年。在对比非洲与非非洲序列时，与非非洲序列相比，尼安德特人材料中出现了低分化区域。这些区域高度富集尼安德特人物质（94%为尼安德特人），这将增加人类间的平均分化时间（因为标准的尼安德特人-人类分化时间约为80万年）。

29.5.3 Gene Flow between Humans and Denisovans

2010年，科学家在西伯利亚南部发现了一块5万年前的指骨。这个丹尼索瓦人样本中的DNA与以往任何人类DNA都不同。丹尼索瓦人的线粒体DNA是尼安德特人和现代人类的外群。（使用线粒体DNA是因为其数量约为体细胞DNA的1000倍。多态性率也高出10倍。）丹尼索瓦人与尼安德特人的亲缘关系比与人类更近。

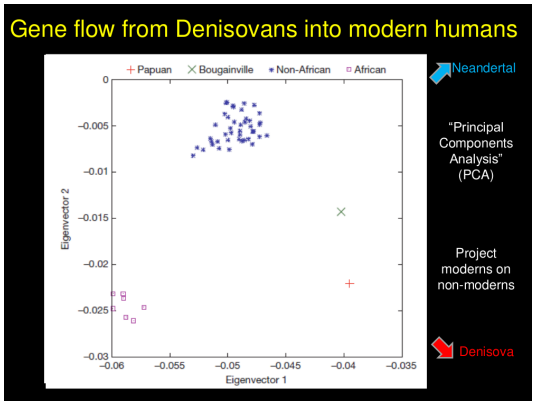

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图29.4：不同人类群体的主成分分析在二维上的投影。

使用与尼安德特人示例相同的SNP匹配技术，发现丹尼索瓦DNA与巴布亚新几内亚DNA的匹配程度高于中国DNA或欧洲DNA。据估计，丹尼索瓦人对现今巴布亚新几内亚人的血统贡献了约5%。一项关于与黑猩猩、尼安德特人和丹尼索瓦人亲缘关系的主成分分析投影（见图）显示，非洲以外的人群与尼安德特人的亲缘关系更近，而巴布亚新几内亚人/布干维尔人与丹尼索瓦人的亲缘关系更近。

这一证据表明一个m　　人类迁移和杂交的模型。人类可能　　grated out of Africa

并与尼安德特人杂交，随后扩散至亚洲各地，在东南亚与丹尼索瓦人杂交。人类在印度与丹尼索瓦人杂交的可能性较小，因为并非东南亚所有人群都具有丹尼索瓦人血统。

29.5.4 Analysis of High Coverage Archaic Genomes

高覆盖率的古老基因组能为我们揭示大量关于人科种群历史的信息。一个高覆盖率的阿尔泰尼安德特人序列是从丹尼索瓦洞发现的一节趾骨中获取的。通过这一序列，我们可以观察两条染色体拷贝达到一致的时间，以此估算种群规模。尼安德特人的DNA中包含许多长的纯合片段，这表明其种群规模长期较小且存在近亲繁殖。对于阿尔泰尼安德特人而言，其基因组中有八分之一是纯合的，大约相当于半兄弟姐妹之间的预期近亲繁殖水平。将此技术应用于非洲以外的人群，显示出5万年前经历了一次瓶颈效应，随后种群扩张，这与“走出非洲”理论相吻合。

尼安德特人和丹尼索瓦人也发生了杂交，这证明了类人生物在繁殖方面具有显著倾向。尽管尼安德特人基因组的大部分与丹尼索瓦人基因组之间的最小分化深度为数十万年，但丹尼索瓦人基因组中至少有0.5%与尼安德特人基因组之间的距离要短得多，尤其是在免疫基因方面。

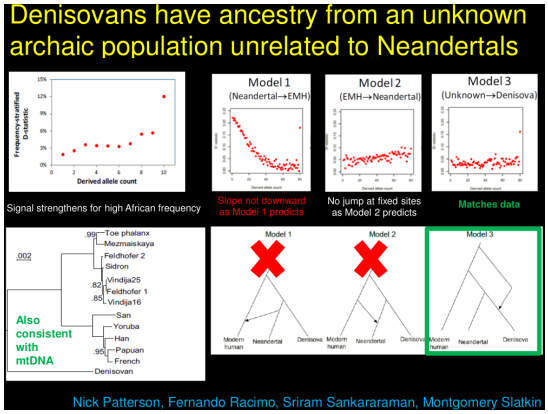

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图29.5：祖先基因流动的数据与模型。

丹尼索瓦人很可能拥有来自一个与尼安德特人无关的未知古老种群的祖先。一段非洲序列与尼安德特人DNA有23%的匹配度，与丹尼索瓦人DNA有47%的匹配度，这在统计上是显著的。如果你按种群中等位基因的频率对D统计量进行分层，你会看到一个递增的斜率，并在达到固定时出现一个急剧的跳跃，这与人们从一个未知种群流入丹尼索瓦人的情况中所能得到的预测最为吻合（见图）。

29.5.5 Discussion

由非洲迁出所造成的瓶颈只是众多例子之一。大多数科学家通常关注迁移事件的时代和强度，而不一定是持续时间，但持续时间非常重要，因为长期瓶颈会造成多样性范围缩小。预测瓶颈长度的一种方法是确定在此期间是否出现了任何新的变异，这在较长的瓶颈期间更有可能发生。多样性范围的变化也有助于形成不同的人类

亚群在地理上变得隔离。这只是群体基因组学有助于拼凑历史迁移的另一种方式。

物种之间的遗传差异（此处指灵长类动物内部）可用于帮助理解我们共同起源的系统发育树。我们研究了与尼安德特人DNA比较的案例，了解了如何获取古代DNA样本、如何发现和解读序列，以及这些证据如何表明现代人类（欧亚血统）与尼安德特人之间极有可能存在杂交。物种之间以及物种内部那些非常微小的差异，使我们能够通过群体遗传学推断出大量人类历史。

29.6 European Ancestry and Migrations

29.6.1 Tracing the Origins of European Genetics

2014年之前，人们认为现代欧洲遗传学主要是两个祖先群体的混合。第一个群体是所谓的西部狩猎采集者（WHG）群体，被认为是欧洲原住民群体。第二个群体被称为早期欧洲农民（EEF）群体，代表了农业民族迅速迁入欧洲，以及新农业群体随后与原始WHG群体的混合。然而，在2012年，Patterson等人[?]利用图29.6中的主成分分析表明，欧洲遗传学与仅由这两个群体混合而成的观点不符。相反，遗传混合分析表明，一些欧洲人只能解释为EEF/WHG群体与第三个遗传学上类似于美洲原住民的群体的混合。虽然这并不意味着美洲原住民是欧洲人的祖先，但该研究得出结论，最可能的假设是这两个已知群体与一个古代北欧亚（ANE）群体的混合，该群体迁移到亚洲和欧洲，并且不再在北欧亚地区发现。这项研究将这一神秘群体称为“北欧亚幽灵”。

然而，两年后的2014年，一个样本的发现证实了这一人群的存在。Raghavan、Skoglund等人[?]宣称“幽灵被找到了”，他们研究了在贝加尔湖（现位于俄罗斯南部）新发现的“Mal’ta”样本，并确定其与2012年预测的幽灵人群相匹配，且能够解释现代欧洲人群中的二维变异。特别是，现代欧洲人被发现由0-50%的WHG、32-93%的EEF和1-18%的ANE人群构成。

29.6.2 Migration from the Steppe

鉴于这个新种群作为欧洲血统的来源，自然会产生的问题是：ANE种群成员何时以及为何迁移到欧洲？当然，这个答案可以从关于欧洲种群历史的进一步遗传数据中梳理出来。第一条线索出现在线粒体DNA数据中，在Brandt、Haak等人2013年的一篇论文[?]中，该研究发现欧洲线粒体DNA中有两个不连续性：一个介于中石器时代和新石器时代早期之间，另一个介于新石器时代中期与晚新石器时代和青铜时代之间。2014年，对9个、随后对94个古代欧洲个体样本的研究清楚地显示了这两次迁移事件，如图29.7所示。第一次迁移大约在公元前6500年，是EEF种群的迁移，它以60%至100%的比例取代了现有的WHG种群。第二次迁移是被称为Yamnaya的草原牧民的迁移，它以60%至80%的比例取代了现有种群。在这两次

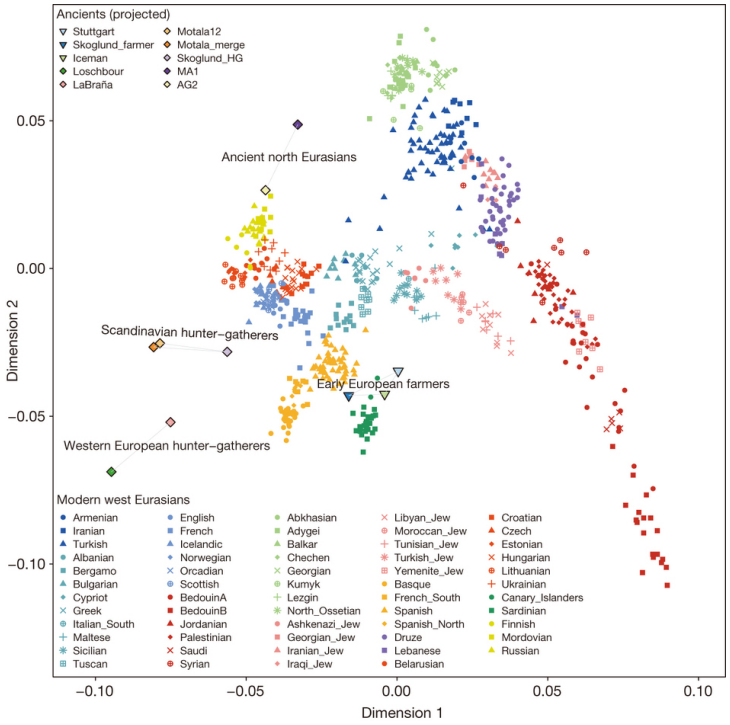

由麦克米伦出版有限公司提供。经许可使用。来源：Lazaridis, Iosif, 等. “古人类基因组暗示现代欧洲人有三个祖先群体.” *Nature* 513, no. 7518 (2014): 409-13.

图29.6：古代欧洲人投影到所有现代欧洲人群的二维PCP上。现代西欧人，主要由左下角的斜线表示，不能仅用EEF和WHG人群的混合来描述。然而，加入ANE成分后，这些变异就能得到解释。

在某些情况下，迁移人口几乎立即占据了遗传组成的一大部分，随后，原有人口在几千年的时间里逐渐复苏。

29.6.3 Screening for Natural Selection

DNA数据在历史研究中的另一个应用是追踪自然选择事件。本质上，人们可以通过观察现代欧洲DNA数据中各种等位基因的频率，来发现与群体祖先混合模型不符的情况。这类情况往往表明，自祖先混合事件发生以来，某些等位基因受到了正向或负向选择。最容易识别且最为人所知的此类性状例子是乳糖耐受性。该性状当前的普遍程度远高于任何祖先群体所代表的水平，这表明自祖先混合事件以来，它经历了正向选择（由于动物的驯化和挤奶）。

其他一些特征也可以被检测为选择的候选对象。另一个直接的例子是皮肤色素沉着。更有趣的是南欧和北欧人的遗传学所显示的关于身高选择的故事。特别是，数据显示发生了两种不同的选择效应。首先，南欧的早期农民在8000至4000年前经历了身高下降的选择。其次，北欧人（现代斯堪的纳维亚人等）在大约同一时期直至现在经历了正向选择。尽管对这些效应的人类学解释存在争议，但这些效应本身在遗传数据中得到了清晰的展示。

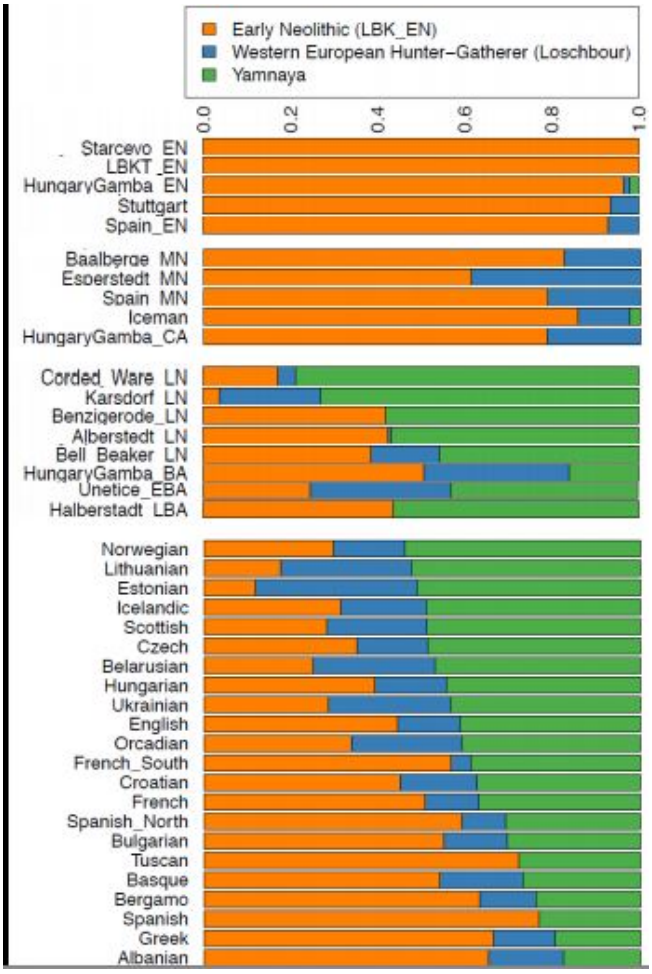

由麦克米伦出版有限公司提供。经许可使用。来源：Haak, Wolfgang, et al. "Massive Migration from the Steppe was a Source for Indo-European Languages in Europe." *Nature* (2015).

图29.7：欧洲遗传组成随时间的变化显示了两次大规模迁移：首先是EEF人群的迁移，几乎完全取代了本地的WHG人群；其次是ANE颜那亚人群的迁移，在那个时候取代了约75%的本地人群。

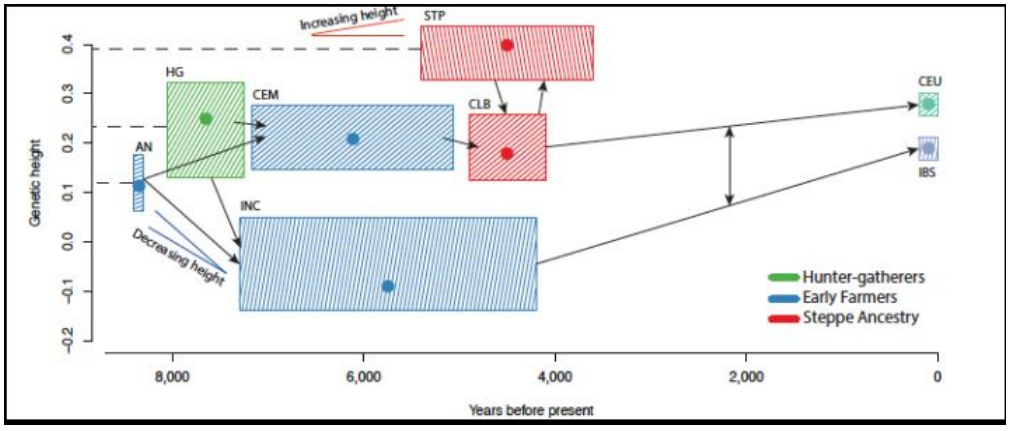

图29.8：从8000年前至今欧洲人群的身高选择。

由麦克米伦出版有限公司提供。经许可使用。来源：Mathieson, Iain等人，“230个古代欧亚人的全基因组选择模式。”*Nature* 528，第7583期（2015年）：499-503。

29.7 Tools and Techniques

29.7.1 Techniques for Studying Population Relationships

有几种不同的方法利用遗传数据研究种群关系。第一种通用类型的研究同时利用了系统发育和迁移数据。它将系统发育适应于F_{st}值，即亚种群杂合度的值（由Cavalli-Sforza和Edwards于1967年开创[?]）。这种方法还利用合成地图和主成分分析。[2] 以这种方式分析种群数据的主要缺点是结果的不确定性。数据处理中存在无法预测的数学和边缘效应。此外，某些群体已表明，分离的、有界的混合种群可以偶然产生看似显著的主成分。即使研究结果是正确的，那么，它们也是不确定的。

分析亚群关系的第二种方法是遗传聚类。可以使用自定义祖先[1]或STRUCTURE数据库形成聚类。[3]这种方法被过度使用，可能导致对数据的过度拟合；数据库的组成可能会使聚类结果产生偏差。

然而，技术进步和数据收集的增加产生了比以往大10,000倍的数据集，这意味着大多数具体的断言都可能被某些数据子集所反驳。因此，实际上，许多通过系统发生学和迁移或遗传聚类预测的模型都会在某个时候被反驳，导致结果的大规模混乱。解决这个问题的一个方法是使用一个简单的模型，该模型提出的陈述既有用又不太可能被证伪。

29.7.2 Extracting DNA from Neanderthal Bones

让我们来看看如何从古代遗骸中寻找并测序DNA。首先，你需要获取含有尼安德特人DNA的骨骼样本。人类DNA与尼安德特人DNA非常相似（我们与他们之间的相似度超过我们与黑猩猩的相似度），因此，在对极为古老的DNA进行短读长测序时，无法辨别DNA是来自尼安德特人还是人类。发现骨骼的洞穴首先根据垃圾或工具作为标识被分类为人类或非人类，这有助于预测骨骼的来源。即便拥有一块骨头，能够得到可挽救DNA的可能性仍然极低。事实上，尼安德特人99%的序列仅来自一个遗址中发现的三根长骨：克罗地亚的Vindija洞穴（5.3 Gb，1.3倍全基因组覆盖）。

接下来，将DNA送往古DNA实验室。由于这些骨骼已有4万年的历史，其中残留的DNA极少。因此，首先对它们进行DNA筛查。如果发现了DNA，接下来的问题便是：这是灵长类动物的DNA吗？通常，这些DNA来自生活在土壤中并分解死亡生物体的微生物和真菌。古骨骼中仅约1-10%的DNA属于灵长类动物。若确为灵长类DNA，它是否源于处理这些骨骼的人类（考古学家或实验室技术人员）造成的污染？人类与尼安德特人的DNA之间，每600个碱基对中仅有1个不同。来自4万年历史骨骼样本的读取片段长度约为30-40个碱基对。这些片段在人类与尼安德特人间几乎总是相同的，因此难以区分二者。

在一个实例中，对89份DNA提取物进行了尼安德特人DNA筛查，但实际只对6块骨骼进行了测序（要求无污染且DNA量足够高）。获取DNA的过程需要在骨骼表面下方钻孔（以尽量减少污染），并从内部取样。对于这三块长骨，能够获取的骨粉不到1克。随后对DNA进行测序，并将其比对到参考黑猩猩基因组。将其映射到黑猩猩而非特定人类，是因为如果你想要了解该序列与特定人类亚群的关系，映射到人类可能会引入偏差。

大多数成功的发现都是在凉爽的石灰岩洞穴中，那里干燥、寒冷，或许还略带碱性。保存下来的最佳机会出现在永久冻土区域。从热带地区能回收的DNA极少。热带地区拥有丰富的化石记录，但DNA却更难获取。由于大多数骨骼无法提供足够或优质的DNA，科学家们不得不反复筛选样本，直到最终找到一个好的。

29.7.3 Reassembling Ancient DNA

从尼安德特人骨骼中提取的DNA读长较短，平均约为37个碱基对。由于时间对DNA的侵蚀导致突变，存在许多缺口。因为人类与尼安德特人在每一千个碱基中仅有一个不同，所以很难判断一个序列是否是污染的结果。然而，我们可以利用古DNA特有的损伤特征来区分新旧DNA。旧DNA倾向于发生C到T和G到A的错误。C到T的错误迄今为止最为常见，出现频率约为2%。随着时间推移，一个甲基基团会从一个C上脱落，使其类似于U。当使用PCR扩增DNA以进行测序时，聚合酶会将U识别并修复为T。为了对抗这一错误，科学家使用一种特殊酶，它能识别U并在该链上切割，而不是将其替换为T。这有助于识别这些位点。G到A的突变则是在互补链上观察到的结果。

平均片段大小相当小，错误率仍为0.1% - 0.3%。对抗突变的一种方法是注意到在双链片段上，DNA在末端变得磨损，在那里它变成单链约10个碱基对。前10个和最后10个碱基往往有高突变率，但其他地方的DNA质量高，即开始时有更多C到T突变，末端有更多G到A突变。在黑猩猩中，最常见的突变是转换（嘌呤到嘌呤，嘧啶到嘧啶），而颠换要罕见得多。人类也是如此。由于G到A和C到T突变是转换，可以通过注意观察到的转换数与观察到的颠换数相比（通过比较尼安德特人与人类DNA），确定老尼安德特人DNA中的突变比如果是新鲜的DNA多约4倍。颠换的发生率相当稳定，因此该比率有助于确定通过C到T突变发生了多少错误。

我们现在能够将人工制品DNA的人类污染降低到约1%左右。当DNA被提取出来时，一旦从骨骼中移除，就会立即用7个碱基对的标签进行条形码标记。这个标签可以让你在实验的任何后续阶段避免污染，但不能在更早的阶段。在清洗骨骼后，提取也在一个带有紫外线的洁净室中进行。线粒体DNA有助于区分样本中被人类DNA污染的比例。线粒体DNA充满了特征性事件位点，因为人类和尼安德特人是互为单系群的。污染可以通过计算这些位点的比例来衡量。在尼安德特人DNA中，存在污染，但低于0.5%。

在测序中，错误率几乎总是高于多态性率。因此，序列中与人类不同的绝大多数位点是由测序错误导致的。因此，我们无法通过生成的序列确切了解尼安德特人的生物学特性，但只要我们清楚该关注哪些位置，就能分析特定的SNP。特定SNP因测序错误而发生改变的概率仅为^{1}至11000，因此仍能获得可用的数据。[300]

—

在对黑猩猩、尼安德特人和现代人的序列进行比对后，我们可以测量尼安德特人与人类及黑猩猩之间的距离。这个距离与人类参考序列仅相差约12.7%。一个法国样本与参考序列的差异约为8%，而一个布须曼人样本则约为10.3%。这表明尼安德特人的DNA处于我们作为一个物种的变异范围内。

29.8 Research Directions

目前，该领域最令人兴奋的趋势是，古代和现代群体遗传学数据日益增多。随着样本量的增加，我们能设计出更精细的统计测试，进而揭示更多关于群体构成与历史的信息。

29.9 Further Reading

Bibliography

[1] Bowcock AM, Ruiz-Linares A, Tomfohrde J, Minch E, Kidd JR, 和 Cavalli-Sforza LL。利用多态微卫星高分辨率解析人类进化史树。*Nature*，368:455–457，1994。

[2] Menozzi。欧洲人的合成人类基因频率图。*Science*，201(4358)：768–792，1978年9月。

[3] Rosenberg N. 人类群体的遗传结构。*Science*, 298(5602):2381–2385, 2002.

CHAPTER

THIRTY

群体遗传变异

帕迪斯·萨贝蒂的客座讲座，由穆罕默德·加塞米、乔纳斯·赫尔弗、本·梅恩（2012年）、亚历克斯·麦考利（2010年）、马修·李（2009年）、阿尔琼·K·曼莱和克拉拉·陈（2008年）记录。

Figures

30.1 不同等位基因频率的基因型频率图 . . . . . 458 30.2 等位基因频率随时间的变化 . . . . . 459 30.3 非洲裔美国人（AA）和欧洲裔美国人（EA）群体研究中每个个体的杂合和纯合衍生及有害基因型的比较。461 30.4 两个隔离群体 . . . . . 461 30.5 Sabeti 等人 *Science* 2006 年效应近似时间表 . . . . . 464 30.6 物种内疟疾抗性的局部正向选择 Sabeti 等人 *Science* 2006 465 30.7 乳糖酶持久性等位基因的局部正向选择 Sabeti 等人 *Science* 2006 . . . . . 466 30.8 北欧和南欧群体之间身高 SNP、匹配 SNP 和全基因组 SNP 的平均等位基因频率差异 Turchin 等人，Nature *Genetics* (2012) . . . . . 466 30.9 断裂单倍型作为自然选择的信号 . . . . . 467 30.10 两个主要瓶颈事件的描绘，一个发生在来自非洲的奠基群体中，另一个是东亚和西欧群体中较小的后续瓶颈事件。 . . . . . 469 30.11 两次瓶颈事件的图示 . . . . . 470 30.12 该图说明了瓶颈事件对群体中稀有等位基因数量的影响。 . . . . . 471 30.13 墨西哥和非洲裔美国人群体中欧洲混合水平的描绘。471 30.14 根据混合群体中片段长度和片段数量对迁移者规模和来源的图示。 472

30.1 Introduction

数百年来，生物学家不得不依赖生物的形态学和表型特征来推断生命之树，并对物种的进化历史做出有根据的猜测。直到最近，廉价地对整个基因组进行测序并从中寻找模式的能力转变了进化生物学。在分子水平上对基因组进行测序和比较已成为一种基本工具，使我们不仅能够比以前更深入地了解更古老的进化历史，还能在更小的时间分辨率上理解进化。借助这些新工具，我们不仅可以了解数十亿年前分离的远缘支系之间的关系，还能理解物种乃至同一物种内不同种群的现在与近期过去。

在本章中，我们将讨论人类遗传历史的研究以及近期选择。本节的方法论框架主要建立在前面几章的概念之上。最具体地说，包括疾病关联作图的方法和系统发育构建，如物种和基因之间的树构建，以及使用溯祖理论的突变历史。在上一章学习了这些方法之后，我们现在将研究它们的应用如何让我们了解人类群体之间的关系和差异。此外，我们还将寻找如何利用这些差异来寻找近期自然选择的信号和疾病位点的识别。本章还将讨论我们目前对人类群体之间差异的了解，并描述一些我们可以推断出的参数，仅使用我们观察到的遗传变异程度来量化群体差异。在人类遗传历史和近期选择的研究中，通常有两个主要的研究主题。第一个是群体大小的历史。第二个是群体之间相互作用的历史。人们经常询问这些领域的问题，因为答案往往可以提供知识来改进疾病作图过程。迄今为止，所有基于研究的人类历史知识都是通过研究基因组中功能中性的区域，并假设遗传漂变而得出的。使用中性区域的原因是，当突变发生在功能区域时，它们会受到正选择、负选择和平衡选择压力。因此，研究中性的区域提供了一个无选择偏差的代理，用于衡量物种之间的漂变。在本章中，我们将深入探讨人类选择过程的一些特征，并从跨物种比较、同义和非同义突变的比较以及单倍型结构方面寻找人类变异的模式。

30.2 Population Selection Basics

30.2.1 Polymorphisms

Polymorphisms 同一物种成员之间存在外观上的差异。其中许多差异源于基因组中的突变。这些突变，即遗传多态性，可以分为不同类型。

Single Nucleotide Polymorphisms (SNPs)

- 序列中单个核苷酸碱基的突变。在大多数情况下，这些变化没有影响。然而，在某些情况下，单个核苷酸的突变会产生重大影响。

- 例如，是由A到T的突变引起的，这导致血红蛋白中谷氨酸（GAG）变为缬氨酸（GTG）。

Variable Number Tandem Repeats

- 当短序列被多次重复时，DNA聚合酶有时会“打滑”，导致其复制该重复序列的次数过多或过少。这被称为。
- 例如，**Huntingtons disease**是由HTT基因中三核苷酸CAG重复过多引起的。重复超过36次可导致逐渐丧失肌肉控制和严重的神经退行性病变。通常，重复次数越多，症状越严重。

Insertion/Deletion

- 通过复制错误或DNA修复，一个或多个核苷酸可能会发生。
- 如果插入或缺失发生在外显子（基因的蛋白质编码区）内，且不是三个核苷酸的倍数，则会发生。
- 最典型的例子是CFTR基因的缺失，该基因编码肺部的氯离子通道，可能导致**Cystic Fibrosis**，患者无法清除肺部的黏液并引发感染

Did You Know?
DNA 分析基于短串联重复序列（STR）。用特定的限制性内切酶切割 DNA，产生长度可变的片段，可用于识别个体。不同国家使用不同（但常有重叠）的基因座进行这些分析。在北美，使用的是基于 13 个基因座的系统。

30.2.2 Allele and Genotype Frequencies

为了通过分析等位基因或基因型来理解物种的进化，我们必须有一个关于等位基因如何从一代传递到下一代的模型。在继续之前，读者对哈代-温伯格原理和赖特费舍尔模型有牢固的直觉是极其重要的。因此，我们将在此简要回顾通过这些方法对突变历史进行建模。赖特-费舍尔模型最早在百年前被提出，是一个关于种群中遗传漂变的数学模型。具体来说，它描述了在大小为N的种群中获得一个新等位基因p的k个拷贝的概率，其中非突变频率为q，以及它在连续世代中的预期频率。

Hardy-Weinberg Principle

等位基因和基因型频率在种群中保持不变的状态，除非有外部影响将它们推离该平衡。

H 哈迪-温伯格原理基于以下假设 ptions:

- 观察到的总体非常大

- 种群是隔离的，即没有其他亚种群被引入到普通种群中

- 所有个体产生后代的概率相等
- 群体中的所有交配都是随机的
- 在从一代到下一代的过程中，种群中不会发生随机突变。
- 等位基因频率驱动未来的基因型频率（流行等位基因驱动流行基因型）

在哈迪-温伯格平衡中，对于两个等位基因A和a，分别以概率p和$q = 1p$出现，随机选择的个体具有纯合AA或aa（分别为pp或qq）或杂合Aa或aA（2pq）基因型的概率可由以下方程描述：

$$p^2|2pq|q^2 = 1$$

该方程给出了每种基因型的概率表，可以将其与观察到的基因型频率使用诸如卡方检验之类的统计误差检验进行比较，以确定哈迪-温伯格模型是否适用。图30.1显示了不同等位基因频率下的基因型频率分布。

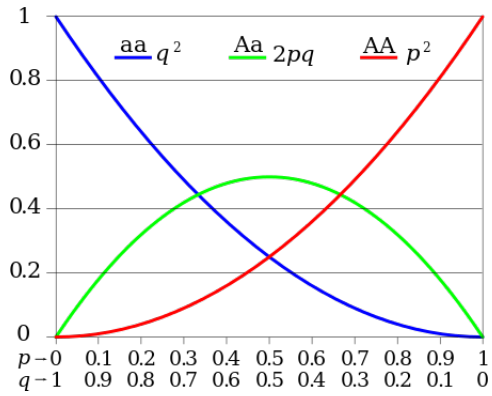

图30.1：不同等位基因频率下的基因型频率图

在自然种群中，哈迪-温伯格原理所作的假设很少成立。自然选择会发生，小种群经历遗传漂变，种群被分裂或合并等。在自然界中，一个突变要么总是从种群中消失（频率 = 0），要么在物种中变得普遍——这被称为固定；一般来说，99% 的突变会消失。图30.2展示了有限规模种群中突变流行度随时间变化的模拟：两者都进行随机游走，其中一个突变消失，另一个变得普遍：

一旦某个突变消失，它重现的唯一途径是种群中引入新的突变。对于人类而言，据信在无选择压力下，一个特定突变应在数百万年内固定为0或1（例如，在5%范围内）。然而，在选择作用下，这一过程会快得多。

Wright-Fisher Model

在该模型下，固定时间为4N，固定概率为1/2N。通常，Wright-Fisher模型用于以某种方式回答与固定相关的问题。为了确保你的直觉

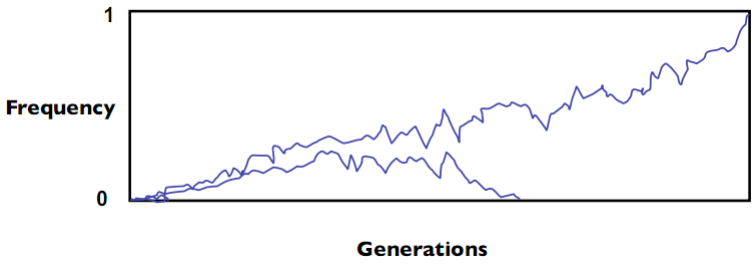

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图30.2：等位基因频率随时间的变化

考虑到以下问题，该方法是绝对清楚的：

FAQ

Q: 假设一个大小为30的群体中，一条染色体上总共有5个突变，如果每个个体只产生一个后代，那么平均而言，下一代中将存在多少个突变?

A: 如果每个亲本只有一个后代，那么平均而言，下一代中会有5个突变，因为根据基础生物学中的哈迪-温伯格平衡原理，等位基因频率的期望值保持不变。

FAQ

Q: Hardy-Weinberg平衡原理关于等位基因频率恒定的假设是否合理?

A: 不，现实情况要复杂得多，因为每一代的种群规模和选择都存在随机性。一种更恰当的理解方式是想象从一群亲本中抽取等位基因，下一代中等位基因的数量会随着种群规模的变化而变化。因此，下一代的频率完全可能上升或下降。这里要注意，如果等位基因频率降为零，它将永远保持为零。在每一代中，如果处于负选择下，该概率会更低；如果处于正选择下，该概率会更高。因此，如果是有益突变，固定时间会更短；如果是有害突变，固定时间会更长。如果带有某一给定突变的后代不存在，那么带有该突变的后代也不会有。然而，如果一个个体会产生多个后代，而这些后代又各自产生多个后代，那么这个等位基因频率上升的机会就更大。

FAQ

Q: 考虑平均每个人携带大约100个完全独特的突变。因此，当一个个体产生后代时，我们可以预期其中一半（或50个）突变可能出现在孩子身上，因为在每个精子或卵细胞中，平均会有50个这样的突变存在。因此，一个个体的后代可能继承大约100个突变，来自一个亲本50个，来自另一个亲本50个，此外还有他们自己既非来自任一亲本的独特突变。考虑到这一点，人们可能对以下问题感兴趣：如果一个人产生，比如n个孩子，某些突变出现在下一代的机会有多大。如何做到这一点？

该

A: 提示：为了计算这个值，我们假设某个等位基因起源于某个任意的染色体（例如1号染色体）的奠基者。然后我们问这样一个问题：整个群体中存在多少条1号染色体？目前，人类群体的大小为70亿，每个人都携带两条1号染色体。

以上问答应当极为清楚地表明，在许多自然情况下，包括迁移、基因突变和选择，等位基因频率从一代到下一代保持恒定的标准哈迪-温伯格假设被违反了。在选择的情况下，这个问题通过修改正式定义以包含一个衡量由于选择导致的基因型偏斜的S项来解决。参见表30.1，了解原始版本与经选择补偿版本的对比：

Behavior	With only drift	With drift and selection
n in next generation	Mean: $n(=2Np)$, Dist: $Binomial(2N,p)$	Mean: $n(1+\frac{s}{1+ps})$, Dist: $Binomial(2N, p\frac{1+s}{1+ps})$
Time to fixation	$4N$	$\frac{4N}{1+\frac{3}{8}N\lvert s\rvert}(\frac{1+\frac{1}{2}(\ln N)\lvert s\rvert}{1+\lvert s\rvert})$
Probability of fixation	$\frac{1}{2N}$	$\frac{1-e^{-2s}}{1-e^{-4Ns}}$

表30.1：Comp　　Wright-Fisher模型与漂变、对比漂变的比较　　nd Selection

从表30.1以及本章这一节中需要领会的主要点是，无论是否面临选择，单个等位基因在种群中固定下来的可能性都极低。然而，如果种群非常小，那么等位基因固定的机会就大得多。这种情况在人类种群中很常见，常常存在小型、近亲繁殖的群体，使得突变仅在几代之后就能在种群中固定，即使该突变本质上是有害的。这正是为什么我们在隔离种群中倾向于看到隐性有害的曼陀林失调症。

30.2.3 Ancestral State of Polymorphisms

我们如何确定对于给定的多态性，哪个版本是祖先型，哪个是突变型？祖先状态可以通过将基因组与已知系统发育树的近缘物种（例如人类和黑猩猩）的基因组进行比较来推断。突变可以发生在系统发育树的任何位置，有时在分化处的突变在不同群体中固定方式不同（“固定差异”），在这种情况下，整个群体的基因型都不同。然而，近期突变还没有足够的时间固定下来，并且一种多态性会出现在一个物种中而在另一个物种中完全缺失，因为两个物种同时发生突变是非常罕见的。在这种情况下，“衍生变体”是分化后出现的多态性版本，而祖先变体是在两个物种中都存在的版本。

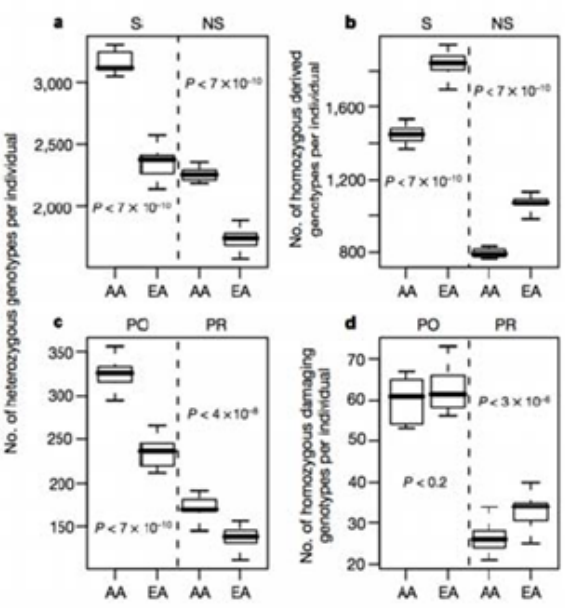

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图30.3：非裔美国人（AA）和欧裔美国人（EA）群体研究中，每个个体的杂合和纯合衍生及有害基因型比较。

30.2.4 Measuring Derived Allele Frequencies

如果假设种群是同质的，那么衍生等位基因在种群中的频率可以很容易地计算出来。然而，当两个群体之间存在导致它们分别独立进化的 unseen divide 时，如图30.4所示，这一假设可能不成立。

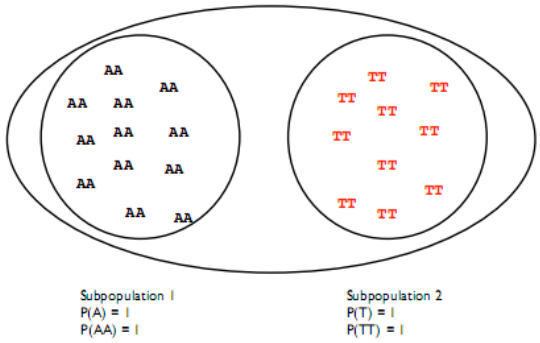

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图30.4：两个孤立的种群

在这种情况下，亚群体中变异体的流行率不同，从而违反了哈迪-温伯格原理。

量化这种差异的一种方法是使用（F_{st}）来比较物种内的亚种群。实际上，一个物种总杂合性中只有一部分存在于给定的亚种群中。Fst估计了当两个不同种群被错误地归为一组时，杂合性（等位基因p和q的2pq）预期的减少。给定一个具有n个等位基因且频率为p_i的种群，其中（$1 \leq i \leq n$），

群体的纯合性 G 计算为:

$$\Sigma^n{}_{i=1} {p_i}^2$$

种群中的总杂合度为 1-G。

$$F_{st} = \frac{Heterozygosity(total) - Heterozygosity(subpopulation)}{Heterozygosity(total)}$$

在图30.4所示的情况中，群体之间不存在杂合性，因此$F_{st} = 1$。实际上，同一物种内的Fst会很小。例如，在人类中，它仅为0.0625。因为在实践中，Fst是通过随机聚类亚群体或使用诸如种族或出身之类的明显特征来计算的。

30.3 Genetic Linkage

在目前我们所见的简单模型中，假设等位基因是独立传递的。尽管这一假设在长期内大体成立，但在短期内，我们通常会观察到某些等位基因一起传递的频率高于预期。这被称为遗传连锁。

，也称为孟德尔第二定律，指出:

Alleles of different genes are passed on independently from parent to offspring.

当这一“定律”成立时，不同多态性之间不存在相关性，而一个单倍型（一组给定的多态性）的概率简单等于每个独立多态性概率的乘积。

在两个基因位于不同染色体上的情况下，这种独立性假设通常成立，但如果两个基因位于同一染色体上，它们往往一起传递。在没有遗传重组事件（即同源染色体上的DNA片段交换，交叉互换）的情况下，两个基因的等位基因将保持完全相关。然而，经过几代之后，基因之间的相关性会减弱。在足够长的时间间隔内，重组将完全消除两个多态性之间的连锁；此时称它们处于平衡状态。相反，当多态性相关时，我们得到**Linkage Disequilibrium** (LD)。不平衡的量是观察到的单倍型频率与平衡状态下预测的频率之间的差异。

连锁不平衡可用于衡量观察到的组合与预期组合之间的差异。如果有两个等位基因（1和2）和两个基因座（A和B），我们可以计算单倍型概率并求出预期等位基因频率。

- 单倍型频率
  - $P(A_1) = x_{11}$

  - $P(B_1) = x_{12}$
  - $P(A_2) = x_{21}$
  - $P(B_2) = x_{22}$
- 等位基因频率
  - $P_{11} = x_{11} + x_{12}$
  - $P_{21} = x_{21} + x_{22}$
  - $P_{12} = x_{11} + x_{21}$
  - $P_{22} = x_{12} + x_{22}$
- $D = P_{11} * P_{22} P_{12} * P_{21}$

D_{max}，给定等位基因频率下D的最大值，与D的关系由以下方程表示：

$D' = \frac{D}{D_{max}}$

D' 对于给定的等位基因和等位基因频率，最大连锁不平衡或完全偏斜为{v*}。可以通过取预期单倍型频率$P(A_1, B_2)$或$P(A_2, B_1)$中的较小值来找到D_{max}。如果两个位点处于完全平衡状态，那么$D' = 0$。如果$D' = 1$，则存在完全连锁。

关键在于，相对较新的突变还没有足够的时间被交叉互换所打破。通常，这样的突变不会非常普遍。然而，如果它受到正选择，该突变在群体中的普遍程度将远超预期。因此，通过仔细结合连锁不平衡（LD）的度量和衍生等位基因频率，我们可以判断一个区域是否处于正选择之下。

{v*}的衰减由重组率和时间（以世代为单位）驱动，并呈指数衰减。重组率越高，连锁不平衡在更短时间内衰减得越快。然而，背景重组率难以估计，并且因基因组中的位置而异。跨多个物种比较基因组数据有助于确定这些背景速率。

30.3.1 Correlation Coefficient r^2

回答位点A的等位基因对位点B的等位基因的预测能力如何

$$r^2 = \frac{D^2}{P(A_1)P(A_2)P(B_1)P(B_2)}$$

当r^2的值接近1时，两个位点上的两个等位基因相关性越强。即使单倍型之间完全无关联，也可能存在连锁不平衡。在研究疾病与基因的关联时，相关系数尤为引人关注，此时知道位点A的基因型可能无法预测疾病，而位点B却能预测。还有一种可能是，位点A或位点B单独都不能预测疾病，但位点A和B共同则能预测。

30.4 Natural Selection

在19世纪中叶，进化这一概念并不罕见，但直到达尔文和华莱士提出自然选择作为驱动自然界进化的机制之前，进化理论并未

进化论得到了广泛认可。直到70年后的1948年，J.B.S.霍尔丹的疟疾假说才找到了人类自然选择的第一个例子。他展示了红细胞基因突变与疟疾流行分布之间的相关性，并发现携带特定突变而患镰状细胞贫血的个体同时也因此对疟疾具有抵抗力。

乳糖耐受（持续至成年）是自然选择的另一个例子。没有基因组序列，这类明确的例子很难证明。有了全基因组测序，我们现在可以在基因组中搜索与这些已知例子具有相同模式的区域，以识别更多正在经历自然选择的区域。

30.4.1 Genomics Signals of Natural Selection

- K_a/K_s 每个基因的非同义与同义变化比率
- 低多样性且一个区域内有许多稀有等位基因（例如关于镰状细胞贫血的Tajima's D）
- 区域高衍生等位基因频率（或低）（例如Fay和Wu的H）
- 种群间的分化速度快于漂变预期（用F_{st}测量）
- 长单倍型：选择性清除的证据。
- 特征在连续世代中的指数级流行度
- 有助于物种繁荣的突变

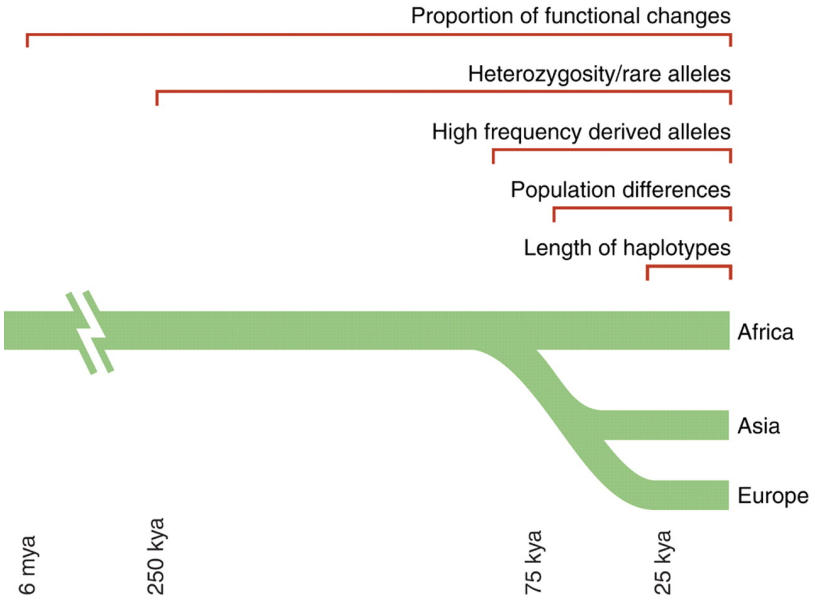

图30.5：Sabeti等人*Science* 2006年效应的近似时间表

© 美国科学促进会。保留所有权利。本内容不在我们的知识共享许可范围内。有关更多信息，请参见 http://ocw.mit.edu/help/faq-fair-use/。来源：Sabeti, P. C., et al. "Positive Natural Selection in the Human Lineage." *Science* 312, no. 5780 (2006): 1614-20.

Examples of Negative (Purifying) Selection

- **Across species** 我们在保守的功能元件（外显子等）中观察到新突变的负选择。

- **New alleles** 在同一物种内，如果等位基因是非同义的，其等位基因频率往往比同义等位基因低。致死等位基因的频率非常低。

Examples of Positive (Adaptive) Selection

- **Similar to negative selection** 在功能元件或非同义等位基因中，正向选择更有可能发生。

- **Across species** 在一个保守元件中，正向选择的突变可能在大多数哺乳动物中是相同的，但在特定物种中发生变化，因为正向选择的突变是在物种形成之后出现的，或者导致了物种形成。

- **Within a species** 正选择的等位基因在不同群体中的等位基因频率（F_{st}）可能不同。例子包括非洲人群的疟疾抗性（30.6）和欧洲人群的乳糖耐受性（30.7）。

- **Polygenic selection** 在物种内，当某一性状受到选择且该性状依赖于许多基因时，就可能产生这种情况。一个例子是人类身高，已知有139个SNP与身高相关。大多数并非种群特异性突变，而是存在于所有人类中的等位基因，这些等位基因在某些种群中比其他种群更受选择。(30.8)

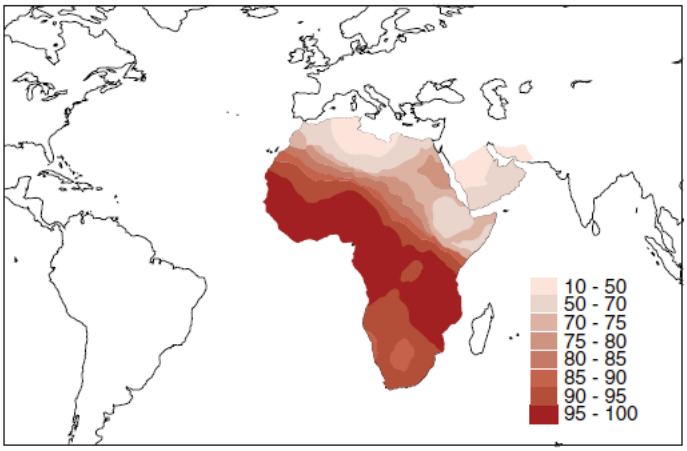

Extreme population differences in *FY*O* allele frequency. The *FY*O* allele, which confers resistance to *P. vivax* malaria, is prevalent and even fixed in many African populations, but virtually absent outside Africa (*38*).

© 美国科学促进会。保留所有权利。此内容不在我们的知识共享许可范围内。有关更多信息，请参见 http://ocw.mit.edu/help/faq-fair-use/。来源：Sabeti, P. C., et al. "Positive Natural Selection in the Human Lineage." *Science* 312, no. 5780 (2006): 1614-20.

图30.6：Sabeti等人2006年在物种内对疟疾抗性的局部正向选择 *Science*

Statistical Tests

- **Long range correlations (iHs, Xp, EHH):** 如果我们根据祖先对个体中的基因序列进行标记，最终会得到一个断裂的单倍型，其中断裂点（颜色变化）的数量与重组次数相关，并能告诉我们某一特定祖源是多久以前引入的。

- **SWEEP** 一个由Pardis Sabeti、Ben Fry和Patrick Varilly开发的程序。SWEEP通过分析基因组中的单倍型结构，利用长程

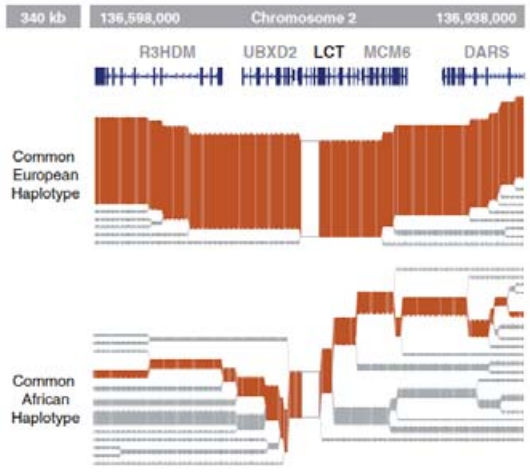

Long haplotype surrounding the lactase persistence allele. The lactase persistence allele is prevalent (~77%) in European populations but lies on a long haplotype, suggesting that it is of recent origin (6).

© American Association for the Advancement of Science. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.
Source: Sabeti, P. C., et al. "Positive Natural Selection in the Human Lineage." *Science* 312, no. 5780 (2006): 1614-20.

Figure 30.7: Localized positive selection for lactase persistence allele
Sabeti et al. *Science* 2006

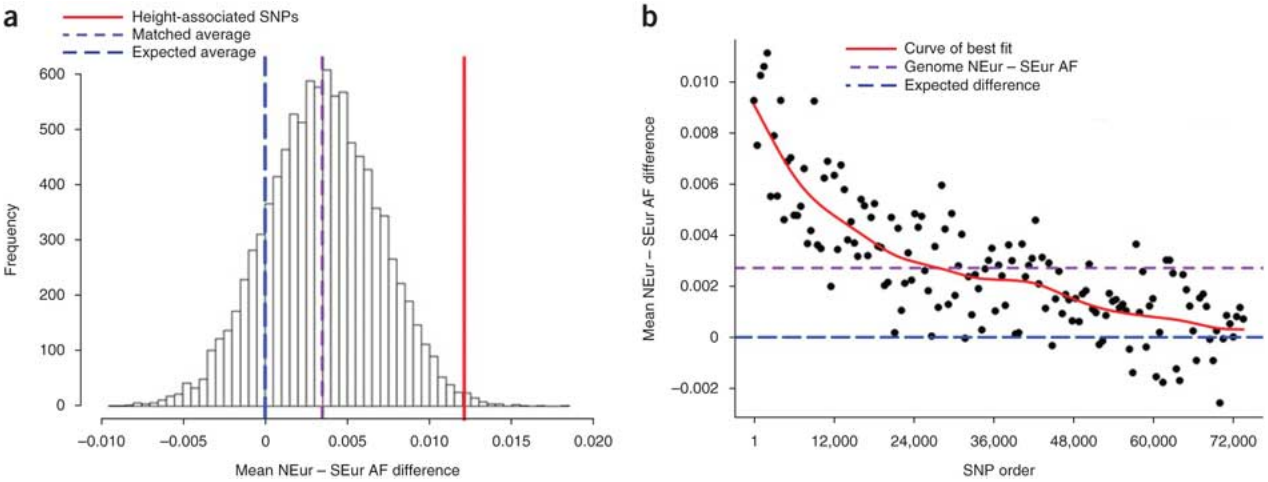

Courtesy of Macmillan Publishers Limited. Used with permission.
Source: Turchin, Michael C., et al. "Evidence of Widespread Selection on Standing Variation in Europe at Height-associated SNPs." *Nature Genetics* 44, no. 9 (2012): 1015-9.

图30.8：北欧与南欧人群之间身高SNP、匹配SNP及全基因组SNP的平均等位基因频率差异 Turchin等，《自然》*Genetics* (2012)

单倍型测试（LRH）。它寻找具有长范围连锁不平衡的高频等位基因，这暗示了单倍型的大规模增殖，其发生的速率大于重组将其与其标记分离的速率。

- **High Frequency Derived Alleles** 在设定位置中寻找衍生等位基因频率的大峰值。

- **High Differentiation** (F_{st}) 在某些位置处的微分出现大尖峰。

使用这些测试，我们可以发现受到选择压力的基因组区域。一个问题是，处于正选择下的单个SNP会允许附近的SNPs搭便车一同被选择。仅凭一项测试难以区分受选择的SNP与其邻近的SNP。在选择作用下，所有测试都强烈

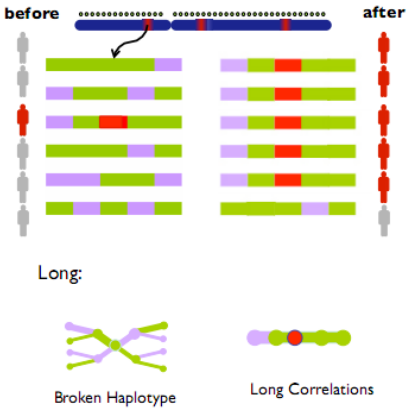

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图30.9：破碎的单倍型作为自然选择的信号

相关的；然而，在没有选择的情况下，它们通常是独立的。因此，通过采用由所有这些测试构成的综合统计量，可以分离出受选择的单个SNP。

单个SNP与某一性状相关的例子：

- Chr15 北欧的皮肤色素沉着
- 亚洲的Chr2毛发特征
- 第10号染色体 亚洲未知性状
- 非洲 Chr12 未知性状

30.5 Human Evolution

30.5.1 A History of the Study of Population Dynamics

毫不意外，科学界对近期人口动态的兴趣有着悠久且颇具争议的历史。尽管其中一些兴趣确实被应用于更为邪恶的目的，例如为种族主义优生学提供科学依据，但这些情况日益成为例外而非规律。早期的人口动态研究在许多方面都相当原始。最初，量化人类群体间差异是通过血型来进行的，因为血型在表型上似乎是中性的，可以在体外进行测试，并且在许多不同的人类群体中似乎具有多态性。快进到现在，科学界已经意识到，除了A、B和O血型之外，还有其他糖蛋白在群体中具有更高的多态性。随着科学的不断进步和测序成为现实，他们开始对Y染色体、线粒体及其周围的微卫星标记进行全基因组测序。这两类遗传数据有什么特别之处？首先，它们相当短，因此比其他染色体更容易测序。除了大小之外，Y染色体和线粒体染色体之所以如此引人注目，是因为它们不发生重组，可以轻松用于重建遗传树。这正是这些染色体相对于常染色体上短片段特别之处；我们确切知道它来自哪里，因为我们可以追溯父系或母系血统。

这种重建方式不适用于其他染色体。例如，如果某人在某一群体中利用1号染色体某一特定片段生成一棵树，他们确实会形成一种系统发育，但这种系统发育将从每个家系树中的随机祖先中选取。

随着测序技术持续发展并日益高效，人类基因组计划被提出，与此同时，人们强烈倾向于在基因组数据中加入某种多样性度量。从技术上讲，对于这种多样性度量，最简单的方法是直接观察微卫星，因为它们可以通过凝胶电泳研究来观察大小多态性，而不是检查序列多态性。提醒一下，微卫星是人类基因组中一段长度可变的区域，通常以短串联重复为特征。微卫星的一个成因是逆转录病毒将自身插入基因组，例如人类基因组中的ALU元件。这些元件有时会变得活跃，并会通过插入事件发生逆转座，人们可以追踪这些插入事件在人类谱系中发生的时间。因此，早期就有人推动在不同人群中检测基因组的这些部分。微卫星真正吸引人的地方在于它们具有高度多态性，而且人们实际上可以推断其突变率。因此，我们不仅可以根据这些速率说明人群之间存在某种关系，还可以说明它们已经演化了多长时间，甚至某些突变何时发生，以及它们在系统发育树的某些分支上存在了多久。

FAQ

Q: 难道不能简单地用SNP来完成吗

A: 用SNPs很难做到这一点。

你可以根据等位基因频率大致了解它们的古老程度，但它们也会受到选择的影响。

在人类基因组计划之后，出现了单倍型遗传Hapmap项目，该项目着眼于全基因组范围内的SNPs。我们在前几章中详细讨论了单倍型遗传，其中我们了解了Hapmap在设计基因分型阵列中的重要性，这些阵列关注标记群体中常见单倍型的SNPs。

瓶颈对人类多样性的影响利用跨研究的丰富数据和大量数学技术，人们意识到，鉴于我们的人口普查人口，人类的多样性实际上非常低；这意味着有效种群规模很小。利用赖特-费舍尔模型，可以从我们今天在种群中看到的多样性水平和突变数量反推，得出奠基种群规模。当进行这项计算时，结果约为10,000。

FAQ

Q: 为什么这比我们的人口普查人口规模小这么多?

A: {v*}种群瓶颈曾出现在某处。

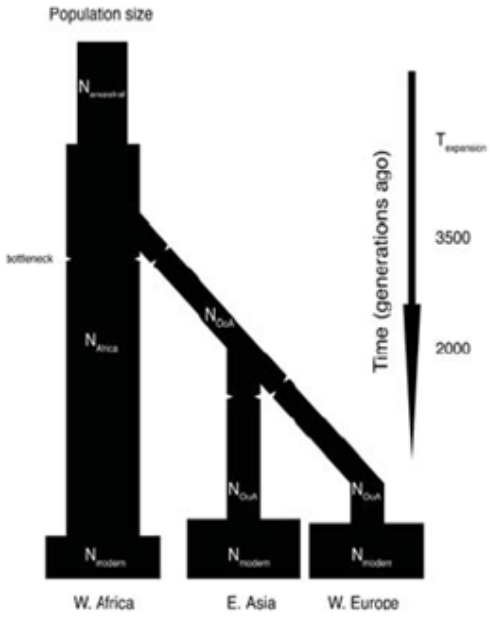

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 htt
p://ocw.mit.edu/help/faq-fair-use/。

图30.10：描绘了两次主要的瓶颈事件，一次发生在来自非洲的奠基人群中，另一次是随后在东亚和西欧人群中发生的较小瓶颈事件。

人类总变异的大部分发生在洲内。人们可以衡量有多少多样性由地理因素解释，以及多少不能。结果表明，其中大部分并不能由地理因素解释。事实上，大多数常见变异在每个群体中都是多态的，如果某个常见变异是某一特定群体所独有的，那么仅靠漂变本身可能还没有足够的时间使其发生。回想一下，仅凭偶然在若干代内达到高等位基因频率是一个多么不可能的过程。因此，当这种情况发生时，我们可以将其解释为选择的信号。就多样性模式的比较以及追溯到祖先单倍型的树而言，所有证据都汇聚于“走出非洲”假说，这是该领域压倒性的共识，也是我们审视所有遗传群体数据的视角。从非洲奠基者群体开始，已有研究表明，使用赖特－费舍尔模型来模拟群体增长是可能的。这些研究表明，我们在亚洲和欧洲群体中看到的增长率，只与走出非洲事件之后的大规模指数增长相一致。

Study	Sample size (n)*	Time growth started (years ago)†	Initial N_e‡	Growth per generation (%)
Gravel *et al.* (5)	60	23,000§ (21,000–27,000)	1032 (677–1290)	0.48 (0.30–0.75)
Gutenkunst *et al.* (6) (including New World modeling)	22	26,400§ (21,700–30,700)	1500 (900–2200)	0.23 (0.16–0.34)
Gutenkunst *et al.* (6) (excluding New World modeling)	22	21,200§ (17,600–23,900)	1000 (500–1500)	0.4 (0.26–0.57)
Schaffner *et al.* (29)	62	8750‖	7700	0.73‖
Coventry *et al.* (18)	10,422	1400 (900–2800)	7700#	9.4 (4.5–14.5)

表30.2：欧洲近期人口增长的遗传学估计

这有助于我们理解种族之间表型差异的原因，即瓶颈，这些瓶颈

随后出现的指数增长可能导致稀有等位基因过多。当前关于人类多样性的理论指出，奠基人群迁出非洲后发生了二次瓶颈事件。这些奠基者在更早的某个时期经历了更为严重的瓶颈事件，这一事件如今反映在地球上每一个人类基因组中，无论其直系祖先为何。通过观察非洲裔与欧洲裔个体之间的差异，推断二次瓶颈效应及欧洲人口指数增长的期限，有可能估算出最初瓶颈的规模。另一种估算瓶颈事件的方法是直接检查构建 coalescent 树所需的等位基因频率谱。通过这种方式，人们可以获取全基因组范围内的单倍型，并通过观察整个基因组中 coalescent 的变化来询问最近共同祖先是谁。例如，根据单倍型的长度，人们可能会猜测某些单倍型仅在近期受到了正选择。欧洲人群中一个近期突变的例子是乳糖酶基因。亚洲人群中的另一个例子是 EDAR 位点。

有大量文献表明，当为大多数单倍型绘制合并树时，其追溯的时间往往远远早于我们认为物种形成发生的时间。这表明某些特征在很长时间内保持了多态性。然而，人们可以通过观察整个基因组中这些特征的分布来推断种群历史的一些信息。如果一个种群近期经历了瓶颈效应，那么祖先的近期性会反映出来，而更古老的特征则会在瓶颈中存活下来。人们可以利用合并时间的分布，模拟种群大小随时间变化的影响。进行此类研究的模型由Li和Durbin提出。他们研究中的图30.11展示了两个这样的瓶颈事件。第一个是发生在非洲的瓶颈，远早于人类走出非洲的迁徙。随后是源自迁出非洲群体的人口特异性瓶颈。这反映在当今各种群基于其祖先的多样性上，并且可以通过观察这些种群中任意两个人的一对染色体来推断。

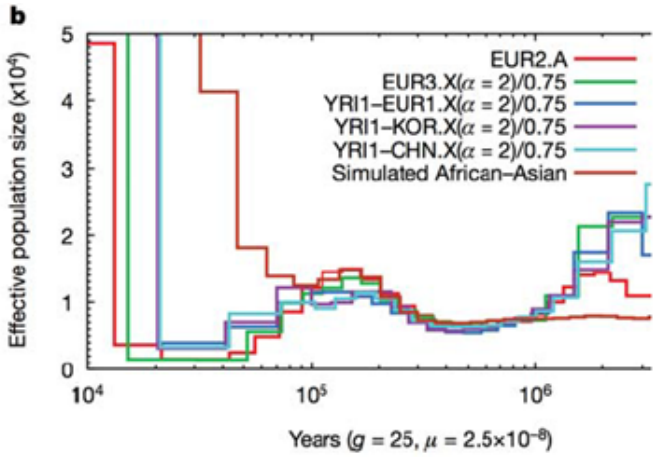

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图30.11：两个瓶颈事件的示意图

30.5.2 Understanding Disease

理解人类群体经历过瓶颈期对于理解群体特定疾病具有重要意义。Tennessen等人今年发表的一项研究关注了多个个体类别中的外显子组序列。该研究旨在探究罕见变异可能如何导致疾病，因此他们能够将群体遗传学模型拟合到数据中，并探究在对广泛群体面板进行外显子组测序时观察到了哪些类型的有害变异。使用这种方法，他们随后能够生成参数，描述指数增长发生在多久以前

在奠基者种群和分支种群之间发生了生长。参见下面图30.12的说明：

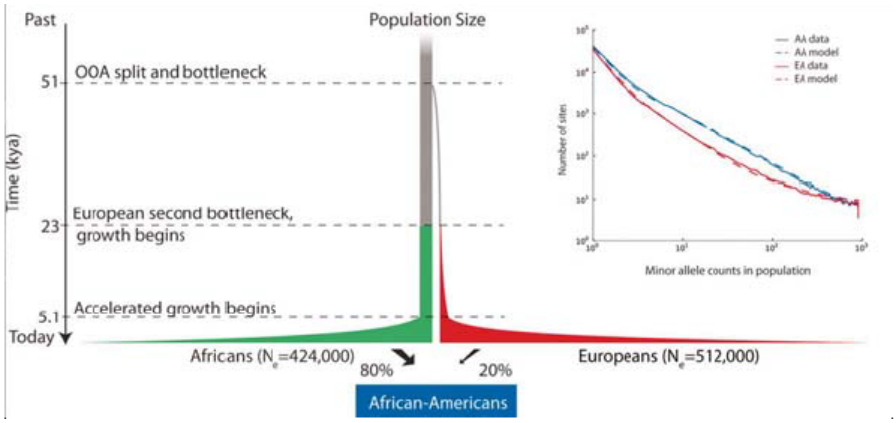

© American Association for the Advancement of Science. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.
Source: Tennessen, Jacob A., et al. "Evolution and Functional Impact of Rare Coding Variation from Deep Sequencing of Human Exomes." *Science* 337, no. 6090 (2012): 64-69.

图30.12：该图展示了瓶颈事件对群体中稀有等位基因数量的影响。

30.5.3 Understanding Recent Population Admixture

除查看溯祖时间外，还可以对SNP进行主成分分析，以了解更近期的种群混合情况。对大多数种群进行此分析会显示出与地理位置相关的聚类。然而，有些种群因历史原因经历了近期的混合。科学文献中最常提到的两个是：非裔美国人，平均有20

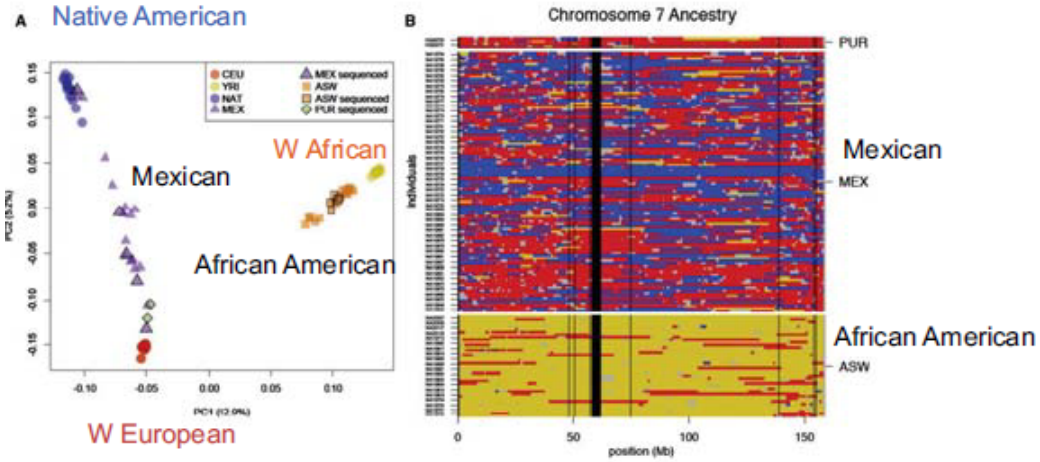

由Elsevier, Inc.提供，http://www.sciencedirect.com。经许可使用。来源：Kidd, Jeffrey M., et al. "Population Genetic Inference from Person al Genome Data: Impact of Ancestry and Admixtureon Human Genomic Variation." *The American Journal of Human Genetics* 91, no. 4 (2012): 660-71。

图30.13：墨西哥人和非裔美国人群体中欧洲血统混合水平的描述。

关于非洲裔美国人和墨西哥裔美国人的混血事件，有两大要点可说。第一个也是更为明显的，是推断混血程度。第二个，也是更有趣的，是根据实际混合程度推断混血事件发生的时间。正如我们在前几章所讨论的，基因组的种族标记会因每代的重组而在混血中瓦解。如果群体是封闭的，那么具有欧洲和西非

在每一代中，起源应保持不变，但由于混合，片段会变得越来越短。因此，单倍型块的长度可用于追溯最初发生混合的时间。（若是最初发生时，我们预期会看到大块的片段，例如某些片段完全源自非洲。）利用这种方法，人们可以观察近期祖先痕迹的分布，并据此拟合一个模型，以确定这些迁移者进入祖先群体的时间，如下图所示：

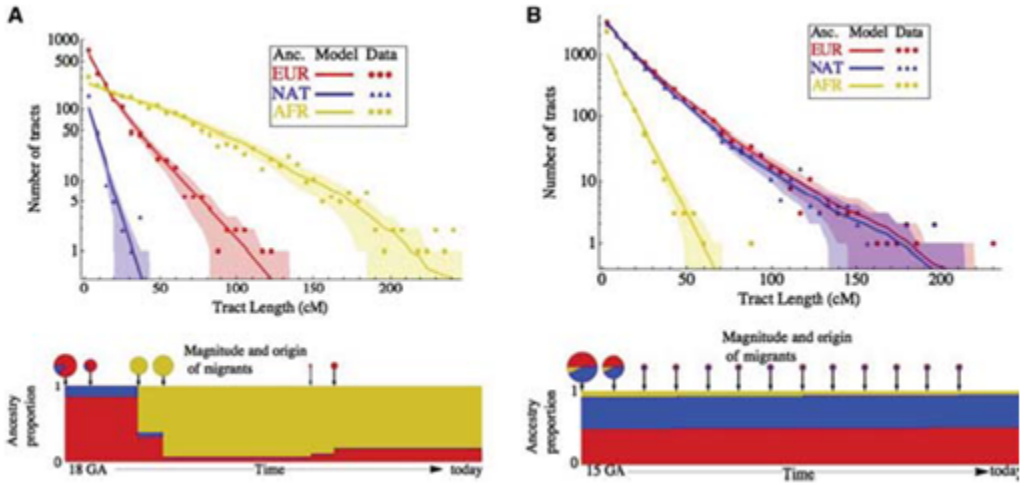

Courtesy of Elsevier, Inc., http://www.sciencedirect.com. Used with permission.
Source: Kidd, Jeffrey M., et al. "Population Genetic Inference from Personal Genome Data: Impact of Ancestry and Admixtureon 人类基因组变异。" *The American Journal of Human Genetics* 91，第4期 (2012): 660-71。

图30.14：基于混合群体中片段长度和片段数量，说明移民的数量和来源。

30.6 Current Research

30.6.1 HapMap project

国际项目旨在编目来自不同国家和地区的人类基因组，并找出相似性和差异性，以帮助研究人员发现将有益于疾病治疗进步和健康相关技术管理的基因。

30.6.2 1000 genomes project

千人基因组计划是一个由研究人员组成的国际联盟，旨在建立一个详细的人类遗传变异目录。其目标是测序来自多个不同族裔群体的千多名匿名参与者的基因组。2012年10月，在《自然》杂志的一篇论文中宣布了1092个基因组的测序完成。希望该项目收集的数据能帮助科学家更深入地了解人类进化、自然选择以及罕见致病变异。

30.7 Further Reading

- 坎贝尔生物学，第9版；*Pearson*；第23章：种群进化

- The Cell, 5th edition, *Garland publishing*; Chapters 5: DNA replication, repair and recombination, Chapter 20: Germ cells and fertilization

Bibliography

Part V

Medical Genomics

CHAPTER

THIRTYONE

医学遗传学——从过去到现在

Mark J. Daly（博士）客座讲座，由Anna Ayuso、Abhishek Sarkar（2011年）、Joel Brooks（2012年）、Grace Yeo（2014年）记录

Figures

31.1 具有遗传成分的疾病与数量性状示例 . . . . . 478 31.2 药物开发过程 . . . . . 479 31.3 展示某种性状遗传的家系图 . . . . . 480 31.4 将特定遗传模式表示为遗传向量 . . . . . 481 31.5 不同疾病类型基因的发现与时间的关系 . . . . . 482 31.6 不同类型的遗传变异 . . . . . 483 31.7 GWAS显著性的阈值，蓝线和红线分别代表IBDGC对克罗恩病研究的显著性阈值。蓝线代表p值为5e-8，红线代表约7.2e-8。 . . . . . 485 31.8 (A) 曼哈顿图和 (B) Q-Q图，用于克罗恩病的GWAS . . . . . 485 31.9 评估疾病网络显著性 487

31.1 Introduction

马克·J·戴利博士是麻省总医院/哈佛医学院的副教授，也是布罗德研究所的准成员。本讲座阐述了统计和计算方法如何帮助研究人员理解、诊断和治疗疾病。关联作图是识别能解释表型变异的遗传变异的过程，这对于理解疾病表型（例如，易感性）尤为重要。历史上，解决这一问题的首选方法是连锁分析。然而，基因组技术的进步使得一种更强大的方法成为可能，即全基因组关联分析。

最近技术和基因组数据的进步使得新的整合分析成为可能，这些分析能够对疾病做出有力的预测。任何关于疾病基础的讨论都必须考虑遗传和环境效应。然而，众所周知，许多性状，例如图31.1中的那些，具有显著的遗传成分。形式上，表型的*heritability*是该表型变异中可由遗传变异解释的比例。图31.1中的性状至少50%是可遗传的。准确估计遗传力需要对具有高度不同共享遗传变异水平的样本进行统计分析（例如，双胞胎、兄弟姐妹、亲属和无亲缘关系者）。例如，关于2型糖尿病遗传力的研究表明，如果你患有糖尿病，你旁边的人（无亲缘关系者）的风险增加5–10%；兄弟姐妹的风险增加30%；而同卵双胞胎的风险增加85%–90%。

31.2 Goals of investigating the genetic basis of disease

在确定疾病特征存在遗传因素后，这项研究如何帮助应对尚未解决的医学挑战？主要有两种方式：

31.2.1 Personalized genomic medicine

变异可用于基因筛查，以检测疾病特征风险增加并提供个体化医学见解。许多公司现在通过筛查癌症复发风险、遗传疾病（包括产前筛查）和常见疾病来提供个性化基因组服务。个体化基因组医学可以帮助确定从特定治疗干预中获益的可能性，或者可以预测不良药物反应。

31.2.2 Informing therapeutic development

识别解释疾病特征的遗传变异有助于我们理解疾病表现的机制（生化途径等）。这使我们能够设计更有效地针对疾病因果通路的药物。这尤其令人关注

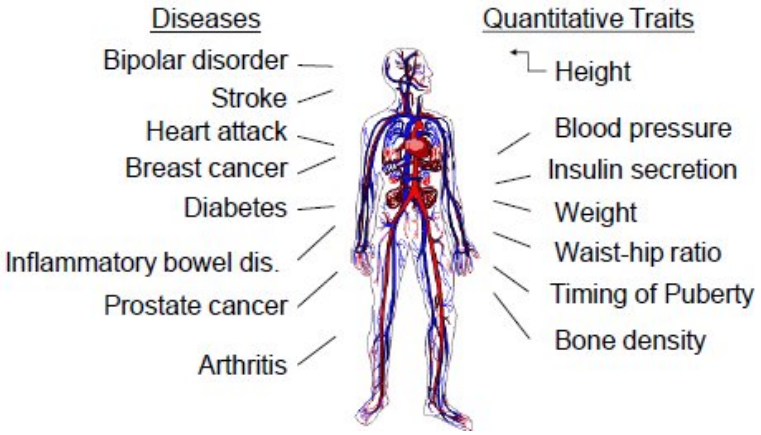

图31.1：具有遗传成分的疾病和数量性状示例

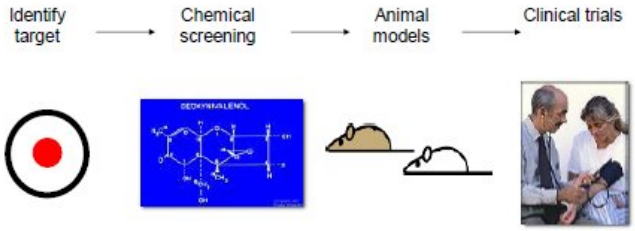

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图31.2：药物开发过程

因为当前的药物开发过程使得针对某些疾病开发药物变得困难。例如，在过去50年里，尚未开发出真正新颖的化合物来治疗各种精神疾病，如精神分裂症。识别遗传相关基因有助于确定开始药物开发的靶点。

图31.2展示了药物开发的周期。药物开发过程始于假设一个可能与疾病相关的潜在靶点。经过生化评估和药物开发，该靶点在模式生物中进行测试。若药物在模式生物中有效，则通过临床试验在人体中进行测试。然而，绝大多数通过此流程的药物最终在治疗其最初设计针对的疾病时无效。这一结果主要是由于作为疾病基础的靶点选择错误所致。他汀类药物是理解其所针对疾病特性的遗传基础后开发出的高效药物的突出例子。Michael Brown博士和Joseph Goldstein博士因在LDL胆固醇代谢调控方面的工作，于1985年荣获诺贝尔生理学或医学奖[5]。他们能够将极端家族性高胆固醇血症（FH）——一种孟德尔遗传病——的原因归结为编码LDL受体的单一基因突变。此外，他们还确定了受该突变影响，进而引发疾病状态的生化途径。他汀类药物正是针对这一途径，不仅对FH患者有益，也是普通人群中高LDL胆固醇的有效治疗方法。

31.3 Mendelian Traits

31.3.1 Mendel

格雷戈尔·孟德尔于1865年利用植物杂交首次揭示了遗传的证据。他认识到与表型特征相关的离散遗传单位，并指出这些单位的变异，以及因此表型的变异，是可以跨代传递的。然而，孟德尔忽略了其数据中的一个矛盾：某些表型对并非独立传递。这一现象直到1913年才被理解，当时连锁作图显示，同一染色体上的基因除非发生减数分裂交叉事件，否则会一起传递。此外，感兴趣基因之间的距离描述了两位点间发生重组事件的概率，因此也描述了两个基因一起被遗传的概率（**linkage**）。

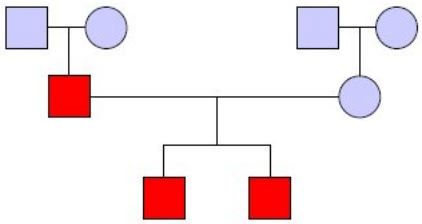

图31.3：显示某种性状遗传的家系图

31.3.2 Linkage Analysis

历史上，研究人员利用通过**linkage analysis**的连锁关系来确定解释表型变异的遗传变异。目标是确定哪些变异对*pedigree*中观察到的表型变异模式有贡献。图31.3展示了一个示例家系图，其中正方形代表男性个体，圆形代表女性个体，夫妻和后代之间相连，红色个体具有所关注的性状。

连锁分析依赖于这样一个生物学洞见：遗传变异并非独立遗传（如孟德尔所提出的）。相反，减数分裂重组发生的次数有限（大约每条染色体一次），因此许多变异 *cosegregate*（是一起遗传的）。这种现象被称为 *linkage disequilibrium* (LD)。

随着两个变异之间的距离增加，它们之间发生重组的概率也随之增加。托马斯·亨特·摩根和阿尔弗雷德·斯特蒂文特发展了这一思想，提出了**linkage maps**，它不仅能确定染色体上基因的顺序，还能确定它们彼此之间的相对距离。他们提出的遗传距离单位是摩根；被1厘摩（cM）分隔的位点有1%的概率被重组分开。非连锁位点有50%的概率被重组分开（如果它们之间发生奇数次重组，则它们被分开）。由于我们通常不知道*a priori*哪些变异是因果性的，我们转而使用*genetic markers*，它由于连锁不平衡（LD）而捕获其他变异。1980年，大卫·博特斯坦提出使用*single nucleotide polymorphisms* (SNPs)，即单个碱基的突变，作为人类遗传标记[4]。如果某个特定标记与实际因果变异处于连锁不平衡，那么我们将在系谱中观察到其对表型变异的遗传贡献模式，并能够缩小搜索范围。

连锁分析的统计学基础是在20世纪上半叶奠定的。罗纳德·费希尔提出了一种遗传模型，能够将孟德尔遗传规律与身高这样的连续表型调和起来[10]。牛顿·莫顿开发了一种名为**LOD score** (优势对数)的统计检验，用以检验观测数据源于连锁这一假设[26]。该检验的零假设是*recombination fraction* (两个相邻标记之间发生重组的概率) $\theta = 1/2$（无连锁），而备择假设则是该概率为某个较小的值。LOD得分本质上是一个对数似然比，体现了这一统计检验：

$$\text{LOD} = \frac{\log(\text{likelihood of disease given linkage})}{\log(\text{likelihood of disease given no linkage})}$$

连锁分析算法是在20世纪后半叶发展起来的。连锁分析主要有两类：*parametric*和*nonparametric* [34]。参数连锁分析依赖于特定变异的遗传、频率和外显率的模型（参数）。设F为系谱中的奠基者（原始祖先）集合，设g_i为个体i的基因型，设Φ_i为

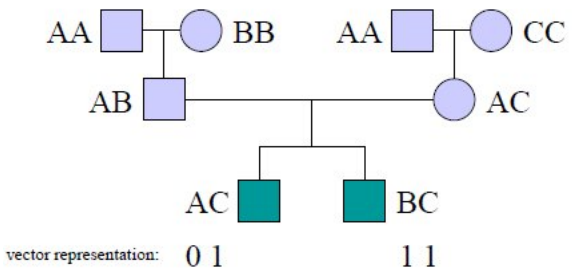

图31.4：将特定的遗传模式表示为遗传向量

个体i的表型，设$f(i)$和$m(i)$分别是个体i的父亲和母亲。那么，在系谱中观察到基因型和表型的似然为：

$$L = \sum_{g_1} \cdots \sum_{g_n} \prod_i \Pr(\Phi_i|g_i) \prod_{f \in F} \Pr(g_f) \prod_{i \notin F} \Pr(g_i|g_{f(i)}, g_{m(i)})$$

计算该似然所需的时间在考虑的标记数量以及系谱中个体数量上均呈指数增长。然而，Elston和Stewart提出了一种更高效计算它的算法，假设系谱中无近亲交配[8]。他们的洞察是，以父母基因型为条件，后代条件独立。换言之，我们可以将系谱视为贝叶斯网络，以更高效地计算联合概率分布。他们的算法在系谱规模上呈线性扩展，但在标记数量上呈指数扩展。

参数连锁分析存在若干问题。首先，单个标记可能无法为遗传模式提供明确的信息。例如，纯合亲本或基因分型错误可能导致标记信息量不足。为了解决这一问题，我们可以增加标记的分型数量，但算法的可扩展性并不理想，随着标记数量的增加，性能下降。其次，对于孟德尔遗传病，建立模型参数相对直接。然而，对于非孟德尔遗传病而言，这一步骤则颇为复杂。最后，标记间的连锁不平衡估计并非天然支持。

非参数连锁分析不需要遗传模型。相反，我们首先根据基因型和系谱推断遗传模式。然后我们确定遗传模式是否可以解释系谱中的表型变异。

Lander和Green提出了一个隐马尔可夫模型来执行该分析的第一部分[20]。该HMM的状态是*inheritance vectors*，它指定了系谱中每一次减数分裂的结果。每个个体由2位表示（每个亲本一位）。每一位的值是0或1，取决于继承了哪一个祖父母等位基因。图31.4展示了遗传向量中两个个体表示的示例。

HMM 的每一步对应一个标记；HMM 中的转移对应遗传向量某些位的变化。这意味着从某个减数分裂继承的等位基因发生了变化，即发生了重组。HMM 中的转移概率则是相邻标记之间的重组率与两个状态之间的汉明距离（不同的位数，即重组次数）的函数。我们可以使用前向-后向算法在该 HMM 上计算后验概率，并推断每个标记的每种遗传模式的概率。

该算法在标记数量上呈线性扩展，但在谱系规模上呈指数扩展。HMM 中的状态数随继承向量的长度呈指数增长，而继承向量的长度与谱系规模呈线性关系。一般来说，这个问题已知是 NP 难的（据我们所知，无法做得比在输入上呈指数扩展的算法更好）[28]。然而，这个问题很重要，不能

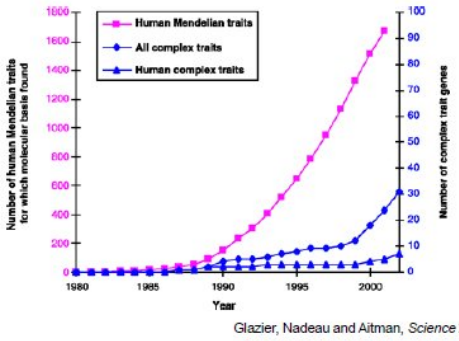

© 美国科学促进会。保留所有权利。此内容不在我们的知识共享许可范围内。有关更多信息，请参见 http://ocw.mit.edu/help/faq-fair-use/ 。来源：Glazier, Anne M., et al. “发现复杂性状背后的基因。” *Science* 298, no. 5602 (2002): 2345-9.

图31　　.5：发现不同疾病类型的基因与ti　　我

不仅在此上下文中，而且在*haplotype inference*或*phasing* (将等位基因分配给同源染色体)以及*genotype imputation* (基于已知基因型推断缺失基因型)的上下文中也是如此。为了使这种分析在实践中更加可行，已经进行了许多优化[1, 11, 12, 15–18, 21, 23]。

连锁分析确定了一个与所关注性状相关的广泛基因组区域。为了缩小该区域范围，我们可以利用重组断裂点的高分辨率遗传图谱。随后，通过对该区域进行测序并检测功能变化，我们能够识别出受影响的基因及致病突变。

31.4 Complex Traits

连锁分析已被证明在研究孟德尔（单基因）疾病的遗传基础方面非常有效。在过去三十年中，已有数千个基因被识别为导致孟德尔疾病的因素。我们已经确定了镰状细胞贫血、囊性纤维化、肌肉萎缩症以及糖尿病和高血压等常见疾病严重形式的遗传基础。对于这些疾病，突变是严重且明显的；环境、行为和偶然因素的影响很小。图31.5展示了已发表关联研究的激增。

然而，大多数疾病（以及许多其他感兴趣的特征）并非孟德尔式的。这些**complex traits**是由许多基因以及可能的环境和行为的相互作用产生的。一个典型的复杂性状是人类身高：它具有高度遗传性，但环境因素也会对其产生影响。最近，研究人员已经鉴定出数百个与身高相关的变异[2, 25]。

连锁分析不是寻找这些变异的可行方法。1920年，Altenburg和Muller首次进行了复杂性状定位，涉及*D. Melanogaster*中截翅的遗传基础。多基因性，即复杂性状在大量基因上的分布，为确定哪些基因与表型相关提供了根本性挑战。在复杂性状中，并非由一个基因决定疾病或性状（如孟德尔遗传），而是许多基因各自施加微小影响。所有这些基因的效应以及环境影响共同决定了个体结果。此外，大多数常见疾病都是这样运作的。这是因为针对每个个体基因型差异的选择压力非常小，因为没有任何一个差异是导致疾病的因果因素。这样，复杂性状在进化中“存活”下来，因为它们不是选择的目标。

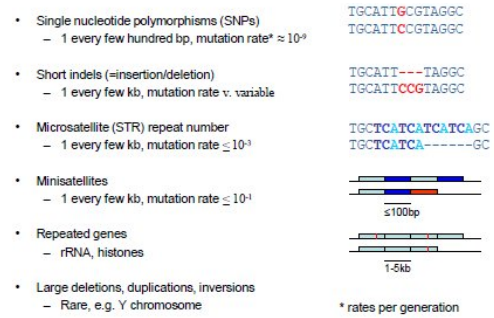

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图31.6：不同类型的遗传变异

31.5 Genome-wide Association Studies

20世纪90年代，研究人员提出了一种名为**genome-wide association**的方法论，以系统地将标记与性状关联起来。这些研究从大量病例和对照样本中抽样，在约一百万个标记上测量其基因型，并尝试将其基因型中的变异（SNPs、CNVs、indels）与表型变异相关联，通过群体而非家系来追踪疾病。

31.5.1 Events Enabling Genome-wide Association Studies

全基因组关联研究（GWASs）之所以可行，得益于三项进展。

首先，我们对基因组理解的进步以及基因组资源的创建使我们能够更好地理解和编目基因组中的变异。从这些数据中，我们认识到一个关键的生物学见解：人类是遗传多样性最少的物种之一。不同人类亚群之间共享着数千万个SNPs。对于基因组的任何特定区域，我们只观察到有限数量的**haplotypes** (等位基因组合，它们一起遗传)。这是因为作为一个物种，我们相对较新，突变尚未跟上我们快速增长的步伐。由于这种高度冗余，我们只需要测量人类基因组中所有变异的一小部分，就能通过LD捕获它们全部。然后，我们可以调整用于推断连锁分析中遗传模式的算法，以推断我们未进行基因分型的标记的基因型。此外，基因组资源使我们能够仔细选择要测量的标记，并基于显示统计学显著关联的标记进行预测。我们现在拥有人类基因组的参考序列（允许进行比对、基因分型和SNP调用）和HapMap，一个全面的人类SNP目录。我们还有全基因组范围的基因和调控元件注释。

其次，基因分型技术的进步，如微阵列和高通量测序，使我们有机会将患有各种表型的个体的基因组与对照组进行比较。使用这些技术，它们也是最容易且最经济实惠的测量对象。尽管人类基因组中存在多种变异类型（图31.6展示了一些示例），但单核苷酸多态性（SNPs）占据了绝大多数。此外，为了考虑其他类型的变异，最近开发的DNA微阵列不仅能检测SNPs，还能检测拷贝数变异，之后我们可以对未观察到的数据进行插补。

第三个进展是研究人员之间合作的新期望。GWAS依赖于大样本量来提高统计检验的$power$ (真阳性概率)。已发表GWAS数量的激增催生了一种新型的**meta-analysis**，它结合了多个

针对同一表型的GWAS，以形成更强大的关联。Meta分析考虑了单个研究中的各种技术和群体遗传偏差。进行GWAS的研究人员应与其他对同一性状进行过GWAS的研究人员合作，以展示结果的可重复性。通过汇总数据，我们对所报告的关联也更有信心，并且所发现的基因可能有助于识别关键通路和过程。

Did You Know?

改写自 Wellcome Trust Sanger Institute：克罗恩病和溃疡性结肠炎一直是复杂疾病遗传学研究的重点，国际炎症性肠病遗传学联合会（IIBDGC）的大规模协作努力加强了研究的成功。借助来自 IBD 患者的约 40，000 份 DNA 样本和 20，000 名健康对照，IIBDGC 已发现 99 个明确的 IBD 位点。总之，71 个克罗恩病位点和 47 个 UC 位点分别解释了 23% 和 16% 的疾病遗传力。基因发现已经带来对疾病生物学的关键见解（例如克罗恩病中的自噬、UC 中的屏障功能缺陷，以及 IBD 和一般免疫介导疾病中的 IL23 信号传导）。预计在基因发现所鉴定的众多新药物靶点中，少数最终将促成对这些毁灭性疾病更好的治疗。改进诊断、预后和治疗都是目标，以期未来将**personalized therapy** (使用个体遗传图谱作为治疗决策指南的实践)。[**?**]

31.5.2 Quality Controls

进行GWAS的主要问题是消除混杂因素，但最佳实践可用于支持高质量数据。

首先，存在基因分型错误，这种错误足够常见，无论采用哪种技术都需要特殊处理。这是技术质量控制，为了应对这类错误，我们对诸如次要等位基因频率和与**Hardy–Weinberg equilibrium**的偏差等指标设置阈值，并剔除不符合标准的SNP。

其次，人类亚群体之间的系统性遗传差异要求进行遗传质量控制。有几种方法可以考虑这一点**population substructure**，例如基因组控制[7]、孟德尔不一致性测试、结构化关联[30]和主成分分析[27, 29]。

第三，环境和行为效应或性别等协变量可能会使数据产生偏差。我们可以通过将它们纳入统计模型来解决这一问题。

31.5.3 Testing for Association

在执行质量控制后，GWAS涉及的统计分析相当直接，最简单的测试是**single marker regression**或**chi-square test**。事实上，需要复杂统计/多标记模型的关联结果往往不太可靠。

首先，我们假设每个SNP的效应是独立且相加的，以使分析变得可行。对于每个SNP，我们进行一个假设检验，其零假设是该SNP在受试者中的基因型观察变异与受试者中表型的观察变异不相关。因为我们为每个SNP执行一个测试，我们需要处理**multiple testing problem**。每个测试都有一定的概率给出假阳性结果，随着测试数量的增加，

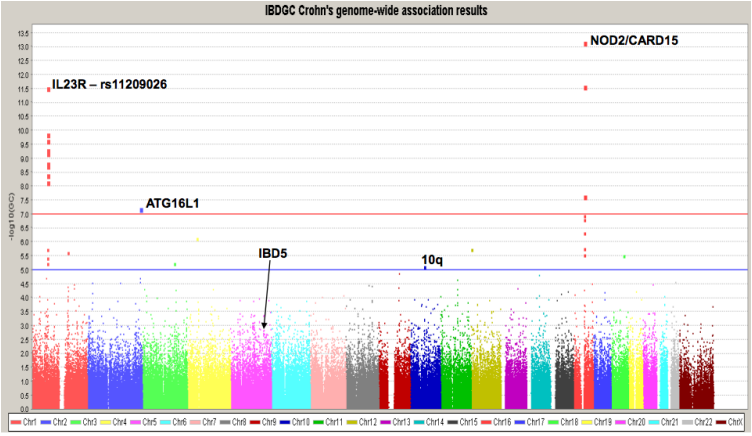

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/。

图31.7：IBDGC关于克罗恩病研究中的GWAS显著性阈值，蓝线和红线表示。蓝线代表p值为5e-8，红线大约代表7.2e-8。

在任何一项中获得假阳性的概率会增加。本质上，通过连锁分析，p = 0.001（0.05/50条染色体臂）会被认为可能具有显著性，但GWAS涉及执行O(10e6)次基本独立的测试。每项研究仅凭统计偶然就会有数百个p <0.001，与疾病没有真正关系。有几种方法可以校正多重检验，例如Bonferroni校正以及错误发现率[3]和不可重复发现率[22]等指标。通常，**genome-wide significance**设定为p = 5*10e-8（= 0.05/100万次测试），最早由Risch和Merikangas（1996）[]提出。2008年，三个研究组[]基于常见DNA的密集全基因组图谱发表了经验推导的估计值，并估计适当的密集图谱数值范围在2.5至7.2e-8之间。这些可在图31.7中可视化。由于这些不同的阈值，查看多项研究以验证关联非常重要，因为即使有严格的质量控制，也可能存在每千个或每万个SNP中影响一个并逃过注意的伪影。此外，严格的全基因组显著性在单项研究中通常不会被大幅超过，甚至可能根本达不到。

除了报告显示最强关联的SNP外，我们通常还会使用*Manhattan plots*来展示这些SNP在基因组中的位置，并使用*quantile-quantile (Q-Q) plots*来检测未被适当考虑的偏差。曼哈顿图是一种散点图，它将经过对数转换的p值与基因组位置（串联各染色体）相对应。在图31.8A中，红色的点表示那些达到显著性阈值的点，它们被标记有邻近的候选基因。Q-Q图是将观测到的对数转换后的p值与预期的对数转换后的p值进行对比的散点图。我们使用均匀分位数作为预期的p值：假设没有关联，我们期望p值呈均匀分布。偏离对角线表明p值比预期的更为显著。然而，早期且持续地偏离对角线则意味着过多的p值过于显著，即存在某种混杂测试的偏差。在图31.8B中，图表展示了观测到的测试统计量与预期的测试统计量（两者等价）的对比。考虑所有标记包括**Major Histocompatability Complex (MHC)**，这是与免疫反应相关的区域。该区域具有独特的连锁不平衡结构，会干扰统计分析，这一点从黑点偏离对角线（灰色区域）可以明显看出。排除MHC后，结果中的这一偏差大大减少（蓝色点）。

GWAS识别与感兴趣性状相关的标记。然而，每个标记捕获了与其处于连锁不平衡状态的一组SNP，这使得确定因果变异的问题更加困难。通常，标记的候选基因是与其最接近的那个。至此，我们需要进一步研究以确定我们所识别变异的关联性。然而，由于以下几个原因，这仍然是一个挑战性问题：

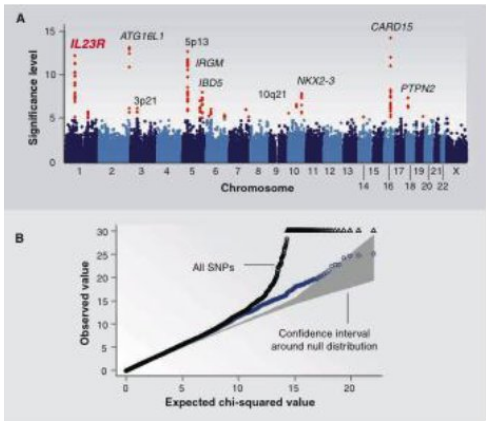

© source unknown. All rights reserved. This content is excluded from our Crea{t*}
Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图31.8: （A）克罗恩病GWAS的曼哈顿图和（B）Q-Q图

- 通过关联识别出的感兴趣区域通常涉及多个基因
- 其中一些关联根本不在任何蛋白质编码区段附近，且其起源也没有明显功能性的等位基因。
- 将这些区域与潜在的生物通路联系起来是困难的

31.5.4 Interpretation: How can GWAS inform the biology of disease?

我们的主要目标是利用这些发现的关联，以可操作的方式理解疾病的生物学机制，因为这将有助于指导治疗这些疾病的方法。大多数关联并未确定具体的基因和因果突变，而只是指向对疾病有因果影响的 *small regions*。为了制定并基于治疗假设采取行动，我们必须更进一步，回答以下问题：

- 哪个基因与疾病相关?
- 由此牵涉到哪些生物过程?
- 该过程在何种细胞环境中发挥作用并与疾病相关?
- 哪些特定的功能性等位基因会干扰该过程，并促进或防止疾病?

可以通过以下两种方式之一来处理：*bottom-up* 方法或 *top-down* 方法。

31.5.5 Bottom-up

bottom-up方法用于研究一个已知与某种疾病相关的特定基因，并探讨其在细胞内的生物学重要性。Kuballa等人[19]能够使用这种自下而上的方法了解到，一个与克罗恩病相关的特定风险变异会导致

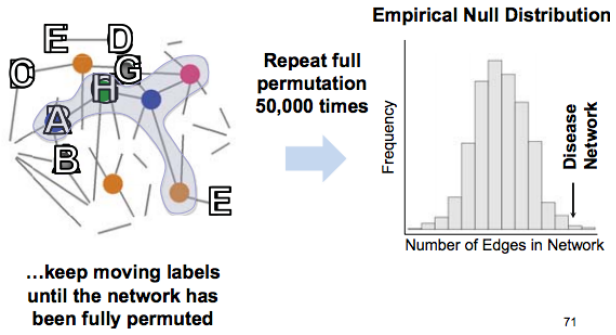

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图31.9：评估疾病网络显著性

某些病原体的自噬。此外，作者还能够创建出与人类中发现的风险变异相同的小鼠模型。在细胞水平上识别风险变异的生物学意义并创建这些模型是极其宝贵的，因为这些模型可直接用于测试新的潜在治疗化合物。

31.5.6 Top-down

相比之下，**top-down**方法涉及考察*all*已知关联，利用完整的GWAS结果集，并尝试将它们与疾病发病机制中涉及的共享生物过程/通路联系起来。这种方法基于这样一个理念：许多与疾病相关的基因共享相关的生物通路。这通常通过采用现有的网络（如蛋白质-蛋白质相互作用网络），并将相关基因叠加在其上来实现。然而，由于关联发现中的偏倚以及关联所整合数据的实验偏倚，这些由此产生的疾病网络可能不显著。这种显著性可以通过多次置换网络中节点的标签，然后计算给定疾病网络的连接水平有多么罕见来估计。这个过程在图31.9中进行了说明。由于网络中连接的基因应该共表达，已经表明这些疾病网络可以通过基因表达谱进一步验证[14]。

31.5.7 Comparison with Linkage Analysis

需要注意的是，GWAS捕获的变异比连锁分析更多。连锁分析识别具有负面效应的罕见变异，当具有表型信息的相关个体家系可用时，会使用连锁研究。它们能够识别存在于少数家族中的罕见等位基因，通常是由于奠基者突变，并已被用于识别与乳腺癌相关的突变，如BRCA1。另外，关联研究用于此目的，也用于发现更常见的遗传变化，这些变化对易感性的影响较小，例如具有保护效应的罕见变异。连锁分析无法识别这些变异，因为它们与疾病状态呈反相关。此外，连锁分析依赖于单一变异解释疾病的假设，这一假设对于诸如疾病这样的复杂性状并不成立。相反，我们需要考虑许多标记来解释这些性状的遗传基础。

31.5.8 Challenges of Non-coding Variants

虽然基因组医学在疾病机制、靶基因、治疗方法和个性化医疗方面有望带来新发现，但仍存在若干挑战，包括90+%的命中为非编码。

为了解决这个问题，非编码基因组已通过ENCODE/Roadmap项目进行了注释，并且增强子已与调控因子及靶基因建立了联系。一旦利用SNP连锁不平衡(LD)扩展每个GWAS位点，即可识别相关的细胞类型、驱动转录因子和靶基因。这些进展将特征与其相关细胞和组织类型联系起来。

31.5.9 Conclusions

我们从GWAS中学到了几个教训。首先，报告的关联中不到三分之一是编码或明显功能性变异。其次，只有一部分关联的非编码变异与附近基因的表达水平显著相关。第三，许多与没有附近编码基因的区域相关。最后，大多数报告的变异与多种自身免疫性或炎症性疾病相关。这些发现表明，基因组中仍有许多谜团等待被发现。

31.6 Current Research Directions

医学遗传学当前的一个挑战是转化问题。特别是，我们关注GWAS是否能指导新疗法的开发。GWAS研究在识别疾病相关位点方面已取得成功。然而，它们提供的关于所涉及的因果等位基因、通路、复合体或细胞类型的信息甚少。尽管如此，许多已知的可成药靶点与GWAS命中相关。因此，我们预期GWAS在指导治疗开发方面具有巨大潜力。

在我们寻求更深入了解遗传扰动的过程中，一项新工具是**next generation sequencing**(NGS)。NGS使得对个体基因组的测序成为一项成本更低、耗时更少的任务。在医学遗传学背景下，NGS有多种用途，包括对罕见和严重疾病的外显子组/基因组测序，以及为完成GWAS位点的等位基因结构而进行的外显子组/基因组测序。然而，NGS反过来也带来了计算和解读方面的新挑战。

NGS在人类疾病研究中的一项应用是识别和表征功能丧失（LoF）变异。LoF变异破坏蛋白质编码基因的阅读框，因此预计具有科学和临床意义。然而，这些变异的识别因自动化变异检出和基因注释中的错误而变得复杂。因此，许多推定的LoF变异很可能是假阳性。2012年，MacArthur等人着手描述一组严格的LoF变异。他们的结果表明，典型的人类基因组包含约100个LoF变异。他们还提出了一种根据候选基因的功能和进化特征对其进行优先级排序的方法[24]。

MacArthur实验室还参与了外显子组聚合联盟正在进行的一项工作，即汇编人类蛋白质编码变异目录以供数据挖掘。目前，该目录包含了来自超过60，000个个体的测序数据。此类数据有助于识别那些显著缺乏功能性编码变异的基因。这一点很重要，因为受到异常约束的基因预期是有害的。基于这一原则，Samocha等人能够识别出1000个与自闭症谱系障碍相关的基因，这些基因显著缺乏功能性编码变异。

这是通过一个描述新发突变模型的统计框架完成的[32]。类似地，De Rubeis等人能够识别出107个处于异常进化约束下的基因，这些基因出现在5%的自闭症受试者中。发现这些基因中的许多编码参与转录和剪接、染色质重塑和突触功能的蛋白质，从而促进了我们对这些变异致病机制的理解。

NGS也可用于研究罕见且严重的疾病，例如DGAT1突变的情况。在Haas等人的一项研究中，外显子组测序被用来识别DGAT1基因中的一个罕见剪接位点突变。这导致了阿什肯纳兹犹太血统家庭儿童中的先天性腹泻病[13]。在这个案例中，测序不仅对存活的孩子有治疗上的应用，还为正在进行的DGAT1抑制临床试验提供了见解。

虽然NGS让我们能够研究导致严重孟德尔疾病的高外显率变异，但也有遗传学研究提出了干预的假设。SCN9A的发现就是一个例子。SCN9A（也称为NaV1.7）的完全功能丧失会导致先天性无痛症。这促进了新型镇痛药的开发，其疗效超过吗啡，例如μ-SLPTX-Ssm6a，一种选择性NaV1.7抑制剂[35]。另一个例子是PCSK9的功能丧失变异，它降低LDL并预防冠状动脉疾病。这促进了PCSK9抑制剂REGN727的开发，该药物在1期临床试验中已被证明安全有效[6]。

NGS对于精细定位GWAS研究中发现的位点也至关重要。例如，2010年针对克罗恩病的GWAS研究涉及15号染色体上一个包含多个基因的区域。经过精细定位，国际炎症性肠病遗传学联盟（IIBDGC）能够将关联精确定位到SMAD3非编码功能元件。另一个例子是Farh等人进行的一项研究，该研究考察了21种自身免疫疾病的候选因果变异。他们发现90%的因果变异是非编码的，但只有10-20%改变了转录因子结合基序，这意味着当前的基因调控模型无法解释这些变异的机制[9]。最后，Rivas等人进行的一项研究分析了与炎症性肠病相关的GWAS位点的深度重测序，不仅发现了新的风险因素，还发现了保护性变异。例如，CARD9中导致蛋白质过早截断的保护性剪接变异被证明能强烈预防克罗恩病的发生[31]。

31.7 Further Reading

31.8 Tools and Techniques

- HapMap，一份详尽的人类SNP目录。
- PLINK，一个开源C/C++ GWAS工具集，能够分析大规模数据集，这些数据集包含了数千个个体上数十万计的标记基因型，以探究潜在的生物学途径。
- GRASS（关联研究中的基因集岭回归）将每个基因的遗传结构概括为特征SNP，并使用组岭回归为每个基因选择代表性的特征SNP，评估它们与疾病风险的关联，并降低GWAS数据的高维度。
- GWAMA（全基因组关联荟萃分析）对二分表型或数量性状的GWAS进行荟萃分析。

31.9 What Have We Learned?

在过去的几十年里，我们在开发研究疾病遗传基础的技术方面取得了巨大进步。历史上，我们利用连锁分析来寻找孟德尔疾病的因果变异，并取得了巨大成功。最近，我们利用全基因组关联研究开始研究更复杂的性状，并取得了一些成功。然而，在开发解释这些GWAS并识别因果变异及其在疾病机制中的作用的方法方面，还需要做更多的工作。提高我们对疾病遗传基础的理解将帮助我们开发更有效的诊断和治疗方法。

Bibliography

[1] G.R. Abeçasis, S.S. Cherny, W.O. Cookson, and L.R. Cardon. Merlin——使用稀疏基因流树快速分析密集遗传图谱。*Nature Genetics*, 30(1):97−101, 2002.

[2] H.L. Allen 等人。数百个聚集在基因组位点和生物通路中的变异影响人类身高。*Nature*, 467(7317):832−838, 2010.

[3] Y. Benjamini 和 Y. Hochberg。控制错误发现率：一种实用且强大的多重检验方法。*Journal of the Royal Statistical Society*，57：289−300，1995。

[4] D. Botstein、R.L. White、M. Skolnick 和 R.W. Davis。利用限制性片段长度多态性构建人类遗传连锁图。*American Journal of Human Genetics*，32：314−331，1980。

[5] M.S. Brown 和 J.L. Goldstein. 胆固醇稳态的受体介导途径. *Science*, 232(4746):34−47, 1986. [6] Jonathan C. Cohen, Eric Boerwinkle, Thomas H. Mosley, 和 Helen H. Hobbs. *PCSK9,* 低 LDL 中的序列变异及对冠心病的保护作用. 354(12):1264−1272. [7] B. Devlin 和 K. Roeder. 关联研究的基因组控制. *Biometrics*, 55:997−1004, 1999. [8] R.C. Elston 和 J. Stewart. 谱系数据遗传分析的一般模型. *Human Heredity*, 21:”523−542”, 1971. [9] Kyle Kai-How Farh, Alexander Marson, Jiang Zhu, Markus Kleinewietfeld, William J. Housley, Samantha Beik, Noam Shoresh, Holly Whitton, Russell J. H. Ryan, Alexander A. Shishkin, Meital Hatan, Marlene J. Carrasco-Alfonso, Dita Mayer, C. John Luckey, Nikolaos A. Patsopoulos, Philip L. De Jager, Vijay K. Kuchroo, Charles B. Epstein, Mark J. Daly, David A. Hafler, 和 Bradley E. Bernstein. 因果自身免疫疾病变异体的遗传和表观遗传精细定位. [10] Sir R.A. Fisher. 孟德尔遗传假设下亲属间的相关性. *Trans- actions of the Royal Society of Edinburgh*, 52:399−433, 1918. [11] D.F. Gudbjartsson, K. Jonasson, M.L. Frigge, 和 A. Kong. Allegro, 一种用于多点连锁分析的新计算机程序. *Nature Genetics*, 25(1):12−13, 2000. [12] D.F Gudbjartsson, T. Thorvaldsson, A. Kong, G. Gunnarsson, 和 A. Ingolfsdottir. Allegro 版本 2. *Nature Genetics*, 37(10):1015−1016, 2005. [13] Joel T. Haas, Harland S. Winter, Elaine Lim, Andrew Kirby, Brendan Blumenstiel, Matthew DeFe-lice, Stacey Gabriel, Chaim Jalas, David Branski, Carrie A. Grueter, Mauro S. Toporovski, Tobias C. Walther, Mark J. Daly, 和 Robert V. Farese. DGAT1 突变与先天性腹泻病相关. 122(12):4680−4684.

[14] X. Hu, H. Kim, E. Stahl, R. Plenge, M. Daly, 和 S. Raychaudhuri. 将自身免疫风险位点与基因表达数据整合可识别特定的致病免疫细胞亚群. *The American Journal of Human Genetics*, 89(4):496–506, 2011.

[15] R.M. Idury 和 R.C. Elston. 一种更快且更通用的隐马尔可夫模型算法，用于多点似然计算。*Human Heredity*, 47:197–202, 1997。

[16] A. Ingolfsdottir 和 D. Gudbjartsson。遗传连锁分析算法及其实现。载于 Corrado Priami、Emanuela Merelli、Pablo Gonzalez 和 Andrea Omicini 编，*Transactions on Computational Systems Biology III*, *Lecture Notes in Computer Science* 第 3737 卷，第 123–144 页。Springer Berlin / Heidelberg，2005 年。[17] L. Kruglyak、M.J. Daly、M.P. Reeve-Daly 和 E.S. Lander。参数与非参数连锁分析：一种统一的多点方法。*American Journal of Human Genetics*，58:1347–1363，1996 年。[18] L. Kruglyak 和 E.S. Lander。使用傅里叶变换的更快多点连锁分析。*Journal of Computational Biology*，5:1–7，1998 年。[19] P. Kuballa、A. Huett、J.D. Rioux、M.J. Daly 和 R.J. Xavier。克罗恩病相关 atg16l1 变异诱导的胞内病原体自噬受损。*PLoS One*，3(10):e3391，2008 年。[20] E.S. Lander 和 P. Green。人类多基因座遗传连锁图谱的构建。*Proceedings of the National Academy of Sciences*，84(8):2363–2367，1987 年。

[21] E.S. Lander, P. Green, J. Abrahamson, A. Barlow, M.J. Daly, S.E. Lincoln, and L. Newburg. Mapmaker：用于构建实验和自然群体初级遗传连锁图谱的交互式计算机软件包。*Genomics*，1(2)：174–181，1987。

[22] Q. Li, J.B. Brown, H. Huang, 和 P.J. Bickel. 高通量实验的可重复性测量. *Annals of Applied Statistics*, 5:1752–1797, 2011.

[23] E.Y. Liu, Q. Zhang, L. McMillan, F.P. de Villena, 和 W. Wang. 在具有近亲繁殖的复杂系谱中进行高效的基因组祖先推断. *Bioinformatics*, 26(12):i199–i207, 2010.

[24] D.G. MacArthur, S. Balasubramanian, A. Frankish, N. Huang, J. Morris, K. Walter, L. Jostins, L. Habegger, J.K. Pickrell, S.B. Montgomery, et al. 人类蛋白质编码基因中功能缺失变异的系统性调查. *Science*, 335(6070):823–828, 2012. [25] B.P. McEvoy and P.M. Visscher. 人类身高的遗传学. *Economics & Human Biology*, 7(3):294 – 306, 2009. [26] N.E. Morton. 连锁检测的序贯检验. *The American Journal of Human Genetics*, 7(3):277–318, 1955. [27] N. Patterson, A. Price, and D. Reich. 群体结构与特征分析. *PLoS Genetics*, 2:e190, 2006. [28] A. Piccolboni and D. Gusfield. 系谱分析中基本计算问题的复杂性. *Journal of Computational Biology*, 10:763–773, October 2003. [29] A. Price et al. 主成分分析校正全基因组关联研究中的分层. *Nature Genetics*, 38:904–909, 2006. [30] J. Pritchard, M. Stephens, N. Rosenberg, and P. Donnelly. 结构化群体中的关联定位. *American Journal of Human Genetics*, 67:170–181, 2000. [31] M.A. Rivas, M. Beaudoin, A. Gardet, C. Stevens, Y. Sharma, C.K. Zhang, G. Boucher, S. Ripke, D. Ellinghaus, N. Burtt, et al. 对gwas位点的深度重测序识别出与炎症性肠病相关的独立罕见变异. *Nature genetics*, 2011.

[32] Kaitlin E Samocha, Elise B Robinson, Stephan J Sanders, Christine Stevens, Aniko Sabo, Lauren M McGrath, J ack A Kosmicki, Karola Rehnstrm, Swapan Mallick, Andrew Kirby, Dennis P Wall, Daniel G MacArthur, Stacey B Gabriel, Mark DePristo, Shaun M Purcell, Aarno Palotie, Eric Boerwinkle, Joseph D Buxbaum, Edwin H Cook, Rich ard A Gibbs, Gerard D Schellenberg, James S Sutcliffe, Bernie Devlin, Kathryn Roeder, Benjamin M Neale, and Ma rk J Daly. 人类疾病中新发突变解释的框架. 46(9):944–950.

[33] Evan A. Stein, Scott Mellis, George D. Yancopoulos, Neil Stahl, Douglas Logan, William B. Smith, Eleanor Lis bon, Maria Gutierrez, Cheryle Webb, Richard Wu, Yunling Du, Therese Kranz, Evelyn Gasparino, 和 Gary D. Swer gold. 单克隆抗体对PCSK9对LDL胆固醇的影响. 366(12):1108–1118.

[34] T. Strachan 和 A.P. Read. *Human Molecular Genetics*. Wiley-Liss，纽约，第2版，1999年。

[35] S. Yang, Y. Xiao, D. Kang, J. Liu, Y. Li, E. A. B. Undheim, J. K. Klint, M. Rong, R. Lai, and G. F. King. 发现一种来自蜈蚣毒液的选择性NaV1.7抑制剂，其在啮齿动物疼痛模型中的镇痛效果超过吗啡。110(43):17534–17539。

CHAPTER

THIRTYTWO

变异2：数量性状定位、EQTL、分子性状变异

Tim Wall、Brendan Liu、Lei Ding（2014年）、Tejas Sundaresan、Giri Anand（2015年）

Figures

32.1 非编码与编码变异及性状解释 . . . . . 502 32.2 eQTL与GWAS方法的比较. . . . . 503 32.3 直接调控基因转录的顺式eQTL。[3] . . . . . 503 32.4 间接调控基因转录的反式eQTL。[3] . . . . . 503 32.5 eQTL研究方法 . . . . . 503 32.6 搜索半径和MAF对检测到的eQTL数量的影响 . . . . . 503 32.7 技术和群体方差对表达水平测定的影响 . . . . . 503 32.8 研究人员在进行eQTL研究时必须做出的决策参数 . . . . . 504 32.9 一个关于哮喘的eQTL研究实例 504

32.1 Introduction

不同生物体之间基因编码区的差异并不能完全解释我们所看到的表型变异。例如，尽管人类与黑猩猩之间的表型差异很大，而不同松鼠物种之间的表型差异较小，但松鼠物种之间的遗传变异却更多[1]。这些观察结果使我们得出结论：必定不仅仅只有基因编码变异能够解释表型变异；具体而言，非编码变异也会影响基因的表达方式，并因此影响生物体的表型。事实上，先前的研究表明，大多数遗传变异发生在非编码区[2]。此外，大多数表达模式已被发现是可遗传的性状。

理解非编码区域的变异如何影响共调控基因，不仅能让我们

不仅理解而且控制这些及其他相关基因的表达。这对于控制不良性状表达，如复杂的多基因疾病，尤为重要（图32.1）。在孟德尔疾病中，大部分疾病风险通过编码变异预测，而在多基因疾病中，绝大多数因果变异位于编码区之外。这表明，在这些多基因疾病中，基因表达调控的变异可能比基因型变异发挥更大的作用。因此，研究这些与性状相关的变异是朝着理解遗传序列如何既编码又控制这类疾病及其相关表型表达方向迈出的一步。

eQTLs（*expression quantitative trait loci*）概括了上文介绍的非编码区域影响mRNA表达的思想：我们可以将eQTL定义为基因组中与生物体编码的另一个基因表达定量相关的变异区域。通常，我们会看到某些非编码区域中的特定SNPs会增强或破坏某个基因的表达。在过去几年中，识别、分析和解释基因组中eQTL的研究领域发展迅猛，已发表了数百篇研究论文。

eQTL影响其关联基因表达的主要机制有四种:

1. 转录因子结合的改变
2. 组蛋白修饰
3. mRNA的可变剪接
4. miRNA沉默

FAQ

Q: eQTL研究与GWAS有何不同?

A: 有两个根本区别。首先，所考察表型的性质不同。在eQTL中，所检查的表型通常处于生物学抽象的较低层次（标准化的基因表达水平），而非GWAS中使用的更高层次、有时可见的表型，如“黑发”。其次，在GWAS中，通常由于与各种SNP相关的表型是更高层次的表型，我们极少见到组织特异性的GWAS。然而，在eQTL中，mRNA的表达模式在同一 个体的不同组织类型之间可能有很大差异，并且可以针对特定组织类型（如神经元和胶质细胞）进行eQTL研究（图32.2）。

32.2 eQTL Basics

32.2.1 Cis-eQTLs

全基因组eQTL分析的使用已将eQTL分为两种不同的表现形式。第一种是**cis-eQTL** (图32.3)，其中eQTL的位置映射到基因的物理位置附近。由于邻近性，顺式eQTL效应往往更强，因此更容易被GWAS和eQTL研究检测到。通常，这些作为某些多态性的启动子，影响甲基化和染色质构象（从而增加或减少转录的可及性），并且可以

表现为基因组的插入和缺失。顺式eQTL通常被归类为位于感兴趣基因100万碱基对范围内的变异。然而，这实际上是一个武断的截断值，例如，可以改变一个数量级。

32.2.2 Trans-eQTLs

第二种不同类型的eQTL是**trans-eQTL** (图32.4)。反式eQTL并不映射到其调控基因的物理位置附近。其对基因表达的影响通常更为间接（并非直接促进或抑制转录，而是影响动力学、信号通路等）。由于此类效应更难明确确定，因此在eQTL分析中更难发现；此外，此类网络可能极其复杂，进一步限制了反式eQTL分析。然而，eQTL分析已促成了**trans hotspots**的发现，其指的是具有广泛转录效应的基因座[11]。

eQTL研究最令人惊讶的或许在于，尽管存在反式热点和顺式eQTL的位置，但在人类中并未发现特定基因的主要反式位点[12]。这很可能归因于当前的全基因组eQTL分析流程本身。尽管全基因组eQTL分析既实用又广泛，但我们发现，在约20,000个基因上进行多重检验时，全基因组显著性出现在$p = 5\times10^{-8}$。因此，研究通常使用不足的样本量来确定许多反式eQTL关联的显著性，而这些关联从一开始就比顺式eQTL具有极低概率的先验[4]。此外，前文所述的偏差减少方法会缩小方差，而方差对于捕捉反式位点固有的微观性状关联至关重要。最后，非正态分布限制了反式eQTL与基因表达之间关联的统计显著性[4]。使用跨表型荟萃分析（CPMA）[5]已对此略有补救，该方法依赖于GWAS的汇总统计量而非个体数据。这种跨性状分析之所以有效，是因为反式eQTL影响许多基因，从而具有源自单个标记的多种关联。样本CPMA代码可在*Tools and Resources*中找到。

然而，虽然尚未发现反式基因座，但已发现反式作用*variants*。由于可以推断反式eQTL影响许多基因，CPMA和ChIP-Seq可用于检测此类跨性状变异。事实上，通过观察对群体的等位基因效应以及靶基因相互作用/连接，从1311个反式作用SNP变异中确定了24个不同的显著反式作用转录因子。

32.3 Structure of an eQTL Study

eQTL研究背后的基本方法是，将每个基因的表达视为一个定量的多因素性状，并对解释表达变异的主成分进行回归分析。首先，提取目标组织的细胞并提取其RNA。感兴趣的蛋白质表达通过微阵列或RNA-seq分析来测量。每个基因的表达水平对基因型进行回归，控制生物学和技术噪音，使得

$$Y_i = \alpha + X_i\beta + \epsilon_i$$

其中 Y_i 是基因 i 的表达量，X_i 是包含与该基因相关的每个 SNP 的等位基因组成的向量（在给定参考等位基因的情况下可取值为 0、1 或 2），α 和 β 是包含回归系数的列向量，ϵ_i 是残差误差（见图 32.5）[9]。在概念上，

这样的研究极为简单。实际上，过程中每一步都有数百个潜在混杂因素和统计不确定性需要考虑。然而，可以使用相同的回归模型来解释这些协变量。

图32.9包含一个关于哮喘的eQTL研究示例。研究的关键结果位于右上角的线性模型中：我们可以看到，随着基因型更倾向于“A”变体，目标基因表达下降。

32.3.1 Considerations for Expression Data

量化基因表达充满实验挑战。关于这些问题的更详细讨论，请参见第14章。进行此类表达分析时，一个重要的考虑因素是**SNP-under-probe effect**：与常见变异区域匹配的探针序列，由于探针内部变异对结合动力学的影响，会提供不一致的结果。因此，使用多套探针重复实验将产生更可靠的结果。表达分析通常还应排除**housekeeping genes**，这些基因在群体成员和/或细胞类型之间没有差异调控，因为它们的包含只会稀释研究的统计功效。

32.3.2 Considerations for Genomic Data

基因组数据分析主要有两个考虑因素：次要等位基因频率和搜索半径。**search radius**决定了所考虑效应的普遍性：无限搜索半径对应于全基因组顺式和反式eQTL扫描，而较小的半径则将分析限制在顺式eQTL。**minor allele frequency** (MAF)决定了不考虑SNP位点的阈值：它是研究统计功效的主要决定因素。较高的MAF阈值通常导致更高的统计功效，但MAF和搜索半径以非线性方式相互作用，以确定检测到的显著等位基因的数量（见图32.6）。

32.3.3 Covariate Adjustment

在eQTL研究中，存在众多可能的统计混杂因素，既有生物学上的，也有技术上的。许多生物因素可影响个体中任一特定mRNA的观察表达量；由于无法控制实现显著性所需的大规模群体样本的测试条件，这一问题更为突出。种群分层和种族群体间的基因组差异是额外的贡献因素。技术方面也存在统计变异性。即使在相同机器上不同时间运行的样本，其表达结果的聚类也显示出显著差异。（图32.7）。

研究人员已成功使用**Principal Component Analysis** (PCA)技术来分离这些混杂因素的影响。PCA能够生成新的坐标轴，使得与SNP相关的基因表达数据在这些轴上的方差最大，从而分离出不需要的一致变异来源（关于主成分分析的详细描述，请参见第20.4章）。在提取基因表达数据的主成分后，我们可以扩展线性回归模型以考虑这些混杂因素，从而产生更准确的回归。

FAQ

Q: 为什么PCA是在这种情况下适用的统计工具，以及为什么我们需要它?

A: 遗憾的是，我们的原始数据存在多种偏差和外部因素，这使得推断出良好的eQTL变得困难。然而，我们可以将这些偏差视为对数据集的独立影响，它们在观察到的表达水平中制造了人为的方差，混淆了导致实际变异的因素。通过使用PCA，我们可以将这些方差分解并识别为其主成分，并适当地过滤掉它们。此外，由于所分析性状的复杂性，PCA有助于降低数据维度，从而促进计算分析。

FAQ

Q: 我们如何决定使用多少个主成分?

A: 这是一个棘手的问题；一种可能的解决方案是尝试不同数量的主成分，并检查之后发现的eQTLs——通过观察输出的eQTLs是否可行，为未来的测试确定这个数量。请注意，为eQTL研究“优化”不同的参数将会很困难，因为每个数据集都会有最优的主成分数量、MAF的最佳值等等...

32.3.4 Points to Consider

以下是进行eQTL研究时需要考虑的一些要点。

- 在特定数据集中发现eQTL的最佳策略，包括各种归一化程序、非特异性基因过滤、搜索半径选择以及次要等位基因频率截断值的选择，可能无法直接应用于另一项eQTL研究。许多科学家通过使用这些参数的$greedytuning$来克服这一难题，迭代进行eQTL研究，直至找到最大数量的显著eQTL。

- 需要注意的是，eQTL研究仅发现遗传标记与基因表达模式之间的$correlation$，并不意味着因果关系。

- 进行eQTL研究时，请注意大多数显著的eQTL位于受调控基因的几kb范围内。

- 从历史上看，大多数eQTL研究的可重复性约为30-40%，这是数据集结构以及各自研究人员使用的不同标准化和过滤策略的遗留问题。然而，在两个或更多队列中发现且一致的eQTL在每个队列中均遵循相似的表达影响。

- 许多eQTL具有组织特异性；也就是说，它们对基因表达的影响可能在一个组织中发生，但在另一个组织中不发生，对此可能的解释是单个基因受多个eQTL共同调控，这取决于一个基因具有多个等位基因。

32.4 Current Research Directions

32.4.1 Quantifying Trait Variation

由于eQTL研究是在基因表达水平上的研究，因此开展一项信息丰富的研究的首要步骤是选择表达水平可变的性状，而非二元表达。此类定量可行性状的例子包括体重指数（BMI）和身高。在20世纪80年代末和90年代初，Damerval和de Vienne [8] [6]首次通过全基因组映射研究启动了基因表达的最初研究。然而，他们使用二维电泳进行蛋白质分离效率低下且不完全可靠，因为这会引入大量噪声，并且无法系统地和定量地总结。直到2000年代初，引入基于高通量阵列的方法来测量mRNA发生率，才加速了这种方法的成功应用，这首先在Brem [10]的一项研究中得到强调。

32.4.2 New Applications

eQTL研究有两个方向。首先，人们急于利用全基因组eQTL分析来验证人类群体中变异之间的关联，例如不同族群间基因表达的差异，因为能够进行此类分析的统计功效正开始达到显著性的阈值。第二个研究方向试图将遗传关联与不同表型以及基于非遗传基础的群体差异分离开来。这些非遗传因素包括环境、细胞系制备和批次效应。

32.5 What Have We Learned?

总之，迄今为止，我们所发现的复杂多基因疾病的大部分因果变异是非编码的。此外，物种间的表型差异并不能很好地用编码变异来解释，而基因表达在世代间具有高度遗传性。因此，有人提出基因表达水平的遗传控制是决定表型变异的关键因素。

eQTL是与基因表达水平相关的SNP变异位点。它们有两种形式。顺式eQTL是位点映射到受影响基因附近的位点，由于距离较近而相对容易检测，并且通常具有明确的作用机制。反式eQTL映射到基因组的远处区域，更难以检测，其机制也不那么直接。

eQTL研究将类似于GWAS的全基因组方法与表达测定（微阵列或RNA-seq）相结合。在使用PCA提取混杂因素后，通过线性回归将每个基因的表达水平与基因型进行相关性分析。确定MAF、搜索半径和混杂因素标准化的最优参数是一个开放的研究问题。eQTL的应用包括识别与疾病相关的变异，以及与种群亚种相关的变异，以及引起复杂性状的遗传和环境方差，

32.6 Further Reading

以下是一篇非常好的关于eQTL的入门文献综述，包括其历史和当前应用：

The role of regulatory variation in complex traits and disease
弗兰克·W阿尔伯特与列昂尼德·克鲁格利亚
克 *Nature Reviews Genetics 16* 2015

还有一些研究论文在eQTL研究的当前趋势中起到了开创性作用。其中一篇论文对于DNA甲基化影响人脑中基因表达的现象提供了信息。另一项研究则是关于秀丽隐杆线虫发育过程中表达变化的研究，在eQTL定位时将年龄作为协变量：

1. **Abundant quantitative trait loci exist for DNA methylation and gene expression in human brain** *PLOS Genet 6* 2010 2.
Gibbs JR, van der Brug MP, Hernandez DG, Traynor BJ, Nalls MA, et al.
The effects of genetic variation on gene expression dynamics during development
Francesconi, M. and Lehner, B.
Nature 505 2013

此外，最近发现eQTL变异与克罗恩病和多发性硬化症等疾病有关[4]。

如第4.2节所述，近期将eQTL研究应用于描绘人类亚群体之间的差异以及表征环境对性状变异的贡献的研究也急剧增加：

1. **Common genetic variants account for differences in gene expression among ethnic groups**
Spielman RS, Bastone LA, Burdick JT, Morley M, Ewens WJ, Cheung VG. *Nature Genetics* 2007 2.
Gene-expression Variation Within and Among Human populations
Storey JD, Madeoy J, Strout JL, Wurfel M, Ronald J, Akey JM *The American Journal of Human Genetics* 2007 3.
Population genomics of human gene expression [12] Stranger BE,Nica AC, Forrest MS, et. al. 4.
Evaluation of genetic Variation Contributing to Differences in Gene expression between populations *The American Journal of Human Genetics* 2007
Zhang W, Duan S, Kistner EO, Bleibel WK, Huang RS, Clark TA, Chen TX, Schweitzer AC, Blume JE, Cox NJ, Dolan ME
The American Journal of Human Genetics 2008 5.
A Genome-Wide Gene Expression Signature of Environmental Geography in Leukocytes of Moroccan Amazighs *PLoS* 2008 6.
Enghelbin Y, Storey JD, Tadelilah S, Gilson G
On the design and analysis of gene expression studies in human populations
Joshua M Akey, Shameek Biswas, Jeffrey T Leek, John D Storey *Nature Genetics* 2007

32.7 Tools and Resources

- Costapas 实验室提供了基于 GWAS 关联 p 值计算 CPMA 的代码，详情见：http://www.cotsapaslab.info/index.php/software/cpma/
- Pritchard实验室拥有多个用于eQTL研究和基因调控的资源（在此处找到：http://eqtl.uchicago.edu/Home.html），包括：

  – 来自70个YRI淋巴母细胞样细胞系的DNase-seq数据 – 下载HapMap淋巴母细胞样细胞系中通过CENTIPEDE推断的转录因子结合位点位置 – 来自Pickrell等人的原始和映射RNA-Seq数据 – 用于识别覆盖基因、多腺苷酸化位点和外显子-外显子连接处的测序读数的各类脚本 – HapMap淋巴母细胞样细胞系中Illumina27K甲基化数据的数据和meQTL结果 – 用于忽略基因组中易在ChIP-seq和其他基于测序的功能测定中导致假阳性的区域的文件 – 近期研究中在多种组织中鉴定的eQTL浏览器

- 威康信托桑格研究所开发了打包的数据库和网络服务（*Genevar*），旨在帮助eQTL研究中SNP-基因关联的整合分析与可视化。相关信息可在此处找到：http://www.sanger.ac.uk/resources/software/genevar/
- 维康信托桑格研究所还开发了包含与eQTL研究相关信息的重要数据库，例如在人类基因组序列中查找并识别所有功能元件，以及对选定的真核生物基因组进行自动注释维护。这些信息可以在此处找到：http://www.sanger.ac.uk/resources/databases/。
- 最后，NIH正在推进基因型-组织扩展项目（GTEx）。目前，该项目已从50名捐赠者中获取了35种组织；目标是获取并分析来自900名捐赠者的20,000份组织样本，希望能收集更多数据以供进一步的遗传分析，特别是需要更大样本量的eQTL和trans-eQTL分析。

Bibliography

[1] King, Mary-Claire 和 Wilson, A.C. (1975年4月) *Evolution at Two Levels in Humans and Chimpanzees*《科学》第188卷第4184期 [2] 千人基因组计划联盟。《自然》。2010年；467:1061-73。 [3] Cheung Vivien G. 和 Spielman Richard S. (2009) *Genetics of Human Gene Expression: Mapping DNA Variants that Influence Gene Expression*《自然综述：遗传学》 [4] C. Cotsapas, *Regulatory variation and eQTLs*. 2012年11月1日。 [5] C. Cotsapas, BF Voight, E Rossin, K Lage, BM Neale, 等. (2011) *Pervasive Sharing of Genetic Effects in Autoimmune Disease.*《公共科学图书馆·遗传学》7(8):e1002254. doi:10.1371/journal.pgen.1002254 [6] Damerval C, Maurice A, Josse JM, de Vienne D (1994年5月). *Quantitative Trait Loci Underlying Gene Product Variation: A Novel Perspective for Analyzing Regulation of Genome Expression*《遗传学》137 (1): 289301.PMC 1205945. PMID 7914503. [7] Dimas AS , 等. (2009年9月) *Common regulatory variation impacts gene expression in a cell type- dependent manner.*《科学》325(5945):1246-50. 2 Epub 2009年7月30日。

[8] D. de Vienne, A. Leonardi, C. Damerval（1988年11月）。
Genetic aspects of variation of protein amounts in maize and pea. 电泳 9 (11): 742750。doi:10.1002/elps.1150091110。PMID 3250877。
[9] 杨 Shengjie, 刘一源, 江宁, 陈静, Lindsey Leach, 罗泽伟, 王明辉.*Genome-wide eQTLs and heritability for gene expression traits in unrelated individuals.* BMC Genomics 15(1): 13. 2014年1月9日. [10] Rachel B. Brem 和 Leonid Kruglyak.
The landscape of genetic complexity across 5,700 gene expression traits in yeast. PNAS 102(5): 1572-1577. 2004年11月23日. [11] Michael Morley, Cliona M. Molony, Teresa M. Weber, James L. Devlin, Kathryn G. Ewens, Richard S. Spielman, Vivian G. Cheung.*Genetic analysis of genome-wide variation in human gene expression.* Nature 430: 743-747. 2004年8月12日. [12] Barbara E Stranger, Alexandra C Nica, Matthew S Forrest, Antigone Dimas, Christine P Bird, Claude Beazley, Catherine E Ingle, Mark Dunning, Paul Flicek, Daphne Koller, Stephen Montgomery, Simon Tavar, Panos Deloukas, Emmanouil T Dermitzakis.
Population genomics of human gene expression. Nature Genetics 39: 1217 - 1224. 2007年9月16日.

图32.1：非编码与编码变异及性状解释

eQTL_network.png

图32.2：eQTL与GWAS方法的比较。

图32.3：顺式eQTL直接调控基因转录。[3]

图 32.4：间接调控基因转录的反式 eQTL。[3]

图 32.5：eQTL 研究方法

图32.6：搜索半径和MAF对检测到的eQTL数量的影响

图32.7：技术方差和群体方差对表达水平测定的影响

图32.8：研究人员在进行eQTL研究时必须做出的决策参数

Figure 32.9: An example eQTL Study on asthma

CHAPTER

THIRTYTHREE

MISSING HERETIBILITY

33.1 Introduction

33.2 Current Research Directions

33.3 Further Reading

33.4 Tools and Techniques

33.5 What Have We Learned?

CHAPTER

THIRTYFOUR

个人基因组、合成基因组、C语言与SI的计算对比

乔治·丘奇的客座讲座，由劳森·王
记录（2011年）

34.1 Introduction

乔治·丘奇讨论了激发他过去和现在研究的各种话题。他首先谈到了读取和编写基因组，包括他自己参与测序技术发展和人类基因组计划的经历。在后半部分，他讨论了他最近的努力——个人基因组计划，该计划始于2005年。

34.2 Reading and Writing Genomes

作为一个动机，考虑以下问题：是否存在任何不是受生物启发或激励的技术？生物学以及我们对它的观察无处不在，影响着我们的生活。例如，在能源领域，生物质和生物能源一直存在，并且越来越成为关注的焦点。即使在电信领域，量子级分子计算的潜力也很有前景，并有望在未来发挥重要作用。

Church在其自身的研究中参与了分子计算，并声称一旦被驾驭，它相较于当前的硅 counterpart 具有巨大优势。例如，分子计算在计算中每焦耳至少能提供高出10%的效率。或许更为深远的是其对数据存储的潜在影响。当前的数据存储介质（磁盘、固态硬盘等）在密度上远不及DNA（数十亿倍）。DNA作为数据存储的局限性在于其错误率较高。Church目前正参与一个项目，探索通过使用纠错和其他技术实现可靠存储。

在2009年《自然生物技术》的一篇综述文章中[1]，Church探讨了高效读写DNA方法的潜力。他指出，在过去十年中，测序和寡核苷酸合成均呈现出10×的指数增长曲线，双链合成虽然滞后，但也在稳步增长。与VLSI（摩尔定律）的1.5×指数曲线相比，生物领域的增长更为显著，且目前尚无理论依据说明这一趋势为何会减缓。总之，基因组合成与工程拥有巨大的潜力。

Did You Know?

乔治·丘奇是基因组测序的早期先驱。1978年，丘奇能够以每个碱基10美元的价格对质粒进行测序。到1984年，他与沃尔特·吉尔伯特一起开发了第一种直接基因组测序方法[3]。凭借这一突破，他帮助在1984年启动了人类基因组计划。该提案旨在以每个碱基1美元的价格对整个人类单倍体基因组进行测序，总预算为30亿美元。这很快演变成众所周知的Celera与UCSC-Broad-Sanger之间的竞赛。尽管后者最终勉强获胜，但他们的序列有许多错误和缺口，而Celera的版本质量要高得多。Celera最初计划以50 kb片段的形式发布基因组，研究人员可以像BLAST那样对这些片段进行比对。丘奇曾联系Celera的创始人克雷格·文特尔，并得到承诺，在发布后将整个基因组以DVD形式提供。然而，丘奇对这个承诺表示怀疑，于是决定利用短片段发布的机会，直接从Celera下载基因组。使用自动化爬取和下载脚本，丘奇在三天内成功下载了以50 kb片段形式提供的整个基因组！

34.3 Personal Genomes

2005年，George Church发起了个人基因组计划[2]。如今，测序成本迅速下降，目前我们可以用4000美元获得整个二倍体人类基因组（相比之下，人类基因组计划中单倍体人类基因组耗资30亿美元），个人基因组和序列信息正变得越来越经济实惠。

个性化医疗是这一信息的一个重要应用领域。尽管许多疾病的预测、诊断和研究仍然复杂，但目前我们已经有一小部分疾病能够通过基因组数据高度预测。例如，苯丙酮尿症（PKU）、BRCA突变相关的乳腺癌以及肥厚型心肌病（HCM）。这些及类似疾病中的许多具有不确定性（无明显症状突然发作）且通常不被常规检查（由于相对罕见）。因此，它们特别适合作为通过个人基因组进行个性化医疗的目标，因为基因组数据提供了无法以其他方式获得的准确信息。目前，已有超过2500种疾病（涉及~6000个基因）高度可预测且在医学上可采取行动，诸如23andMe等公司正在探索这些机会。

关于这个主题的最后一点，Church谈到了他个人对于个性化医疗的一些看法。他发现许多人不愿意获取自己的基因组信息，并将此归因于公众对GWAS和个性化医疗的负面看法。他认为媒体过分关注GWAS的失败。长期以来反对个性化医疗的论点是，我们应该先关注常见疾病和变异，然后再研究罕见事件。Church反驳说，事实上并不存在所谓的常见疾病。高血压或高胆固醇等现象只能算作症状；许多“常见疾病”如心脏病和癌症有许多亚型和更细的分类。一直以来，将这些疾病归为一个大类只对教授医学生和销售药品（例如他汀类药物，商业上表现良好，但仅对极少数人有益）有好处。Church认为，归类意味着统计功效的损失，并且只有在其确实有意义时才有用。归根结底，每个人都是由于自己独特的基因和疾病组合而死亡，

因此，Church认为拆分（个性化基因组学）是前进的方向。

个人基因组学为规划和研究提供信息。作为一种商业模式，它类似于提供风险管理的保险单。然而，作为一个额外的好处，收到的信息允许早期发现，后果甚至可以避免。获取基因组信息使人们能够做出更明智的决定。

34.4 Current Research Directions

34.5 Further Reading

个人基因组计划：`http://www.personalgenomes.org/`

34.6 Tools and Techniques

34.7 What Have We Learned?

Bibliography

[1] Peter A. Carr 和 George M. Church. 基因组工程. *Nature biotechnology*, 27(12):1151–1162, 2009年12月.

[2] G. M. Church。个人基因组计划。*Molecular Systems Biology*，1(1)：msb4100040–E1–msb4100040–E3, 2005年12月。

[3] G. M. Church 和 W. Gilbert。基因组测序。*Proceedings of the National Academy of Sciences of the United States of America*，81(7)：1991–1995，1984年4月。

CHAPTER

THIRTYFIVE

PERSONAL GENOMICS

德尼兹·阿克塞尔，莫莉·施密特，乔纳森·尤萨托

Figures

35.1 导致患病概率的因素。除基因组与疾病之间的联系外，图中显示的每种关系均表示相关性。相关性并不意味着因果关系，但我们可以利用基因组来解析因果关系。 . . . . . 512 35.2 与孟德尔疾病相关的SNP通常位于编码区，而与多基因疾病相关的SNP通常位于非编码区。这是因为与孟德尔疾病相关的大效应变异、蛋白质编码变异由于选择压力而处于低频率。与多基因疾病相关的常见变异往往效应较低，因此选择压力所起的作用不那么显著。 . . . . . 513 35.3 确定甲基化对疾病状态作用的多因素和数据集，以及连接这些数据集的方法。 . . . . . 515 35.4 人类疾病建模 . . . . . 517 35.5 多基因风险预测 518

35.1 Introduction

个性化基因组学侧重于分析个体的基因组及其对疾病的易感性，而非着眼于群体层面。个性化医疗只有在掌握了遗传信息以及年龄、营养、生活方式或表观遗传标记（如甲基化）等许多其他因素的信息时才有可能实现。要使个性化医疗更加成为现实，我们需要更多地了解人群中以及个体中疾病的病因和模式。

35.2 Epidemiology: An Overview

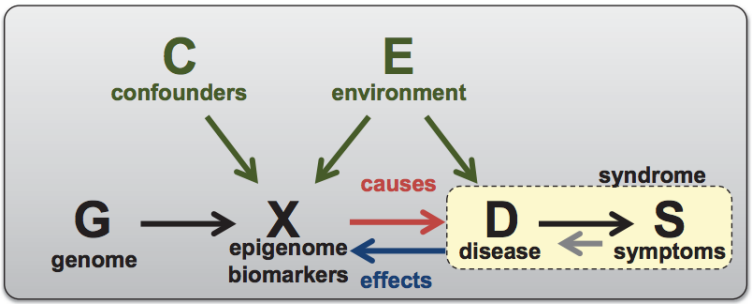

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/。

图35.1：影响患病概率的因素。除基因组与疾病之间的关联外，所示每种关系均表示相关性。相关性并不意味着因果关系，但我们可以利用基因组来解析因果关系。

流行病学是研究特定人群中健康和疾病状况的模式、原因和影响的学科。为了讨论流行病学，我们需要首先理解一些基本定义和术语：**Morbidity level**是指个体患病的程度，而死亡率则是指个体是否死亡。**incidence**是一个比率，描述在一定时期内出现的新病例/患病人数。**prevalence**是人群中病例的总稳态数。**attributable risk**是暴露于疾病与未暴露于疾病的人群之间疾病发病率的差异。**Population burden**指的是潜在寿命损失年（YPLL）、质量调整或残疾调整生命年（QALY/DALY）。**Syndrome**指的是观察到的疾病同时出现的体征或症状。**prevention challenge**是确定疾病及其原因，并理解是否、何时以及如何进行干预。

为了确定疾病原因，研究必须按照实验设计的特定原则来设计。这些原则包括对照组、随机化、重复、分组、正交性和组合性。需要对照组，以便可以与基线进行比较。安慰剂效应是真实存在的，因此拥有对照组是必要的。接受所测试的推定治疗的人也必须是随机的，以便没有偏差。研究还需要重复，以控制初始样本中的变异性。（这类似于赢家的诅咒。某人可能因为在那一轮中表现出色并超过了个人平均水平而赢得比赛，但在下一轮中，他们可能会回归到接近平均水平的 perform。）理解不同亚组之间的变异也可能在实验结果中发挥重要作用。这些可能包括基于年龄、性别或人口统计特征的亚组。人口中的某个亚组可能以比其余人更深刻的方式做出贡献，因此分别看待每个亚组很重要。在设计实验时，还必须考虑正交性，即所有因素和处理的组合，以及组合性、因子设计。特别是在疾病研究中，必须考虑涉及人类受试者时的伦理问题。存在由审查委员会监督的法律和伦理约束。临床试验必须以盲法（患者不知道他们是否在接受治疗）或双盲法（医生也不知道）进行。知道自己是否接受了治疗的患者可能会改变他们的习惯，从而导致偏差，或者知道患者接受了治疗的医生可能会以不同方式对待他们或以不同方式分析他们的结果。必须考虑这两个方面，以降低可能导致临床试验不同结果的偏差。

Example 一个需要随机对照试验的例子是埃博拉的治疗。治疗必须随机分配给在不同医院接受治疗的患者，并且必须是盲的。如果

有人认为他们正在接种疫苗，可能会改变习惯以自我保护，这可能影响结果。如果只有一家医院的患者接种了疫苗，那么观察到的效果可能仅仅是因为那家医院更加小心。

FAQ

Q: 在设计不佳的实验中，最常被忽视的一个方面是什么?

A: 最常被忽视的是亚组结构。有时不同亚组可能是什么并不明显。为帮助解决这一问题，研究人员可以通过尝试分别对病例和对照进行聚类并可视化聚类结果，来考察预测变量的一般性质。如果聚类中除病例/对照之外还存在其他亚结构，研究人员可以在每个聚类中寻找变量，以了解是什么驱动了亚结构。

35.3 Genetic Epidemiology

遗传流行病学关注导致疾病的遗传因素。全基因组关联研究（GWAS）已在前文详细描述，它识别与特定疾病相关的遗传变异，而忽略其他可能起作用的因素。随着全基因组测序成本的下降，这类研究正变得越来越普遍。

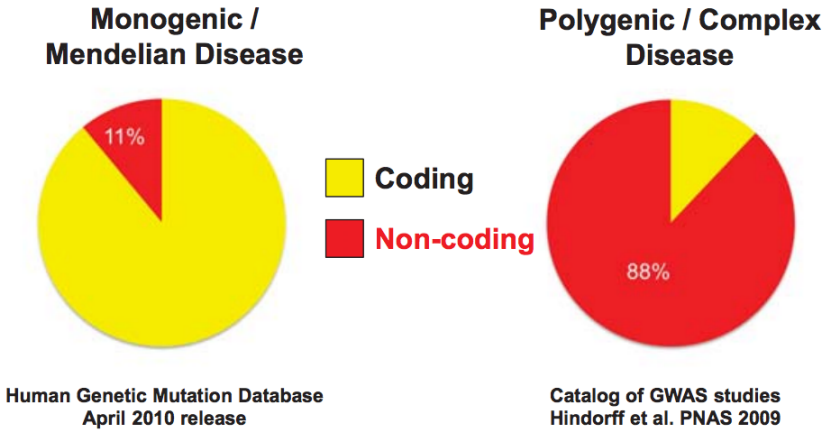

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图35.2：与孟德尔疾病相关的SNP通常位于编码区，而与多基因疾病相关的SNP通常发现于非编码区。这是因为与孟德尔疾病相关的大效应变异，即蛋白质编码变异，由于选择作用而处于低频率。与多基因疾病相关的常见变异往往具有较低的效应，因此选择作用的影响不那么显著。

在遗传流行病学中，有许多遗传因素可用于识别特定个体的疾病。你可以研究与特定基因或变异中共同遗传性状相关的家族风险等位基因。你可以研究单基因、可操作的蛋白质编码突变，这些突变是最被了解的，影响最大，也最容易解释。有可能测试所有与已知疾病关联的编码SNPs（单核苷酸多态性）。关于患者是否需要或是否愿意知道这些信息，有时存在争议，特别是当疾病并非

可治疗的。即使没有表现出症状，一个人仅仅因为知道自己可能患有无法治疗的疾病，其生活质量就可能下降。你还可以测试GWAS中的所有编码和非编码关联、所有常见SNPs（无论是否与任何疾病相关），或者整个基因组。

Did You Know?

23andMe是一家个人基因组学公司，提供基于唾液样本的直邮消费者基因检测服务。23andMe向消费者提供原始基因数据、与祖源相关的结果，以及对90多种性状和疾病易感性的估计。2010年，FDA通知包括23andMe在内的多家基因检测公司，其基因检测被视为医疗器械，上市销售需要获得联邦批准。2013年，FDA命令23andMe停止销售其唾液采集套件和个人基因组服务（PGS），因为23andMe未能证明他们“对PGS的预期用途进行了分析或临床验证”，并且“FDA担心PGS设备不准确结果对公共健康造成的影响”[?]。FDA对假阴性和假阳性基因风险结果都表示担忧，称假阳性可能导致消费者在BRCA相关风险的情况下接受手术、密集筛查或化学预防，而假阴性则可能使消费者无法获得所需的照护。在课堂上，我们讨论了是否应告知人们他们可能携带的潜在风险等位基因。通常，人们可能会误解提供给他们的概率，从而低估或高估自己应该担忧的程度。也有人提出这样的论点：如果当前医学和技术无法减轻风险，就不应告诉人们他们处于风险之中。如果人们将被告知某种风险，该风险应当是可采取行动的；也就是说，他们应该能够对此有所作为，而不是仅仅生活在担忧之中，因为这种额外的压力可能会给他们带来其他健康问题。

不仅要选择测试什么，还要考虑何时针对特定状况进行检测。诊断性测试是在症状显现后进行的，以确认假设或区分患有某种状况的不同可能性。你也可以进行预测性风险测试，这种测试甚至在患者出现症状之前就进行了。你可能需要对新生儿进行测试以便 early intervention，甚至通过超声波、母体血清、探针或绒毛膜绒毛取样进行产前测试。为了测试你可能遗传给孩子的疾病，你可以进行孕前测试。你还可以进行携带者测试，以确定你是否是某种可能在家系中传承的特定突变等位基因的携带者。遗传学和生物标志物的测试可能颇具挑战性，因为有时无法确定所见到的遗传特征或生物标志物是导致疾病的原因，还是患病后的结果。

为了解释疾病关联，我们需要使用表观基因组学和功能基因组学。遗传关联仍然只是概率性的：如果你有遗传变异，你仍然有可能不会患上这种疾病。然而，基于贝叶斯统计，如果先验概率增加，后验概率也会增加。随着我们发现越来越多的关联和变异，预测价值将会增加。

35.4 Molecular Epidemiology

分子流行病学涉及研究疾病状态的分子生物标志物。这包括观察基因表达谱、DNA甲基化模式（即表观基因组学），以及特定细胞类型中的染色质结构和组织。在前面的章节中，我们在eQTL研究的背景下讨论了基因表达（如RNA或蛋白质）与SNPs之间的联系。提醒一下，eQTLs（表达数量性状位点）旨在寻找基因表达水平与遗传位点不同变异之间的线性相关性。

本节将重点理解 **epigenomic markers** 作为疾病分子指标的作用。重要的是要理解，多种因素以及因此多个数据集在理解疾病的表观基因组基础中发挥作用：样本患者的甲基化模式（M）、同一个个体的基因组信息（G）、环境数据（E，涵盖年龄、性别、吸烟习惯等协变量）以及表型量化（P，可以捕捉多种表型标记，例如在阿尔茨海默病中，每位患者的神经元斑块数量）。此外，我们需要理解这些数据集之间的各种相互联系和依赖关系，以便就甲基化对某种疾病的影响得出有意义的结论。

为了去除实验、技术或环境协变量，我们依赖于已知的或ICA（独立成分分析）推断出的校正。为了将遗传数据与甲基化模式关联起来，我们寻找meQTLs（甲基化数量性状位点），这相当于eQTLs。分子表型如表达水平或甲基化水平也是数量性状。最后，为了将甲基化模式与疾病关联，我们实施EWAS（全表观基因组关联研究）。

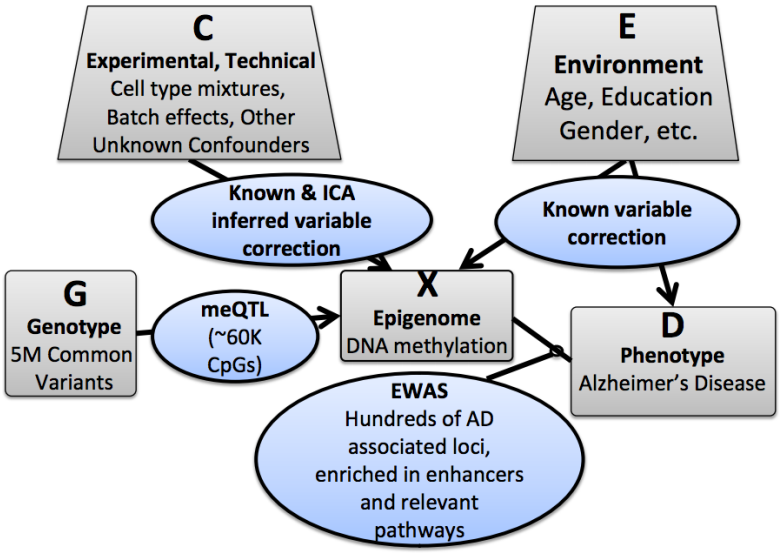

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图35.3：确定甲基化在疾病状态中作用的多因素和多数据集，以及将这些数据集关联起来的方法。

35.4.1 meQTLs

meQTL的发现过程与发现eQTL所使用的方法高度相似。为了发现顺式meQTL（即对甲基化的影响邻近测试位点的meQTL），我们选择一个基因组窗口，并使用线性模型来检验在该区域内是否观察到甲基化与SNP变异之间的相关性。我们通过F检验来判断这种相关性是否显著，其中零假设是通过基因组信息引入的额外模型复杂性并不能解释甲基化模式变异中的显著部分。发现meQTL的其他方法包括置换检验和线性混合模型（LMM）。

Example 在发现甲基化、基因型与疾病之间联系方面，使用meQTLs的一个例子是记忆与衰老项目。多年前，750位老年人加入了该项目，并且

今天，它们大多已经死亡，并将大脑捐献给科学。为了研究甲基化与阿尔茨海默病表型之间的联系以及基因型如何影响甲基化谱，研究人员测定了背外侧前额叶皮层的基因型和甲基化。研究考虑了SNP数据、甲基化、环境因素（如年龄、性别、样本批次、吸烟状况等）以及表型。首先需要发现并排除协变量，以确保所得结果并非由混杂因素导致。这是通过对甲基化数据矩阵进行ICA分解来实现的。这能够发现驱动该性状中最大变异性的变量。样本批次和细胞混合物可能对个体间变异产生最大影响。在校正这些因素后，使用线性模型、置换检验和线性混合模型来确定顺式meQTL——即基因型在多大程度上解释甲基化水平。

35.4.2 EWAS

全表观基因组关联研究（EWAS）旨在寻找患者甲基化模式与其表型之间的联系。与GWAS非常相似，EWAS依赖线性模型和p值检验来发现表观基因组图谱与疾病状态之间的关联。结合meQTLs，EWAS还可能有助于揭示特定甲基化模式是疾病的原因还是结果。理想情况下，目标是能够生成模型，使我们能够基于甲基化预测疾病状态（表型）。

EWAS存在一些缺点。首先，由表型引起的甲基化模式变异通常非常小，使得将表观基因组状态与疾病状态联系起来变得困难，类似于大海捞针。为了改善这种情况，我们需要控制甲基化数据中的其他变异来源，如性别、年龄等。以阿尔茨海默病为例，性别因素就包含了大量变异。我们还需要考虑由基因型（以meQTLs的形式）引起的变异。此外，样本间的变异性是收集EWAS甲基化数据时的一个主要问题[?]。由于同一个体中不同细胞类型会有不同的表观基因组特征，因此收集相关组织样本并针对研究中涉及的不同细胞/组织类型对数据进行校正至关重要。

35.5 Causality Modeling and Testing

个人基因组学的一个核心问题是哪些标记物是疾病的因果因素。例如，人们可能会问，某个位点的甲基化或某种组蛋白修饰是否会增加一个人患某种疾病的风险。这个问题之所以困难，是因为我们需要将虚假相关与因果效应区分开来——例如，基因组其他位置的突变可能导致疾病，同时也增加了观察到特定标记物的机会，但该标记物对疾病并没有因果效应。在这种情况下，尽管没有任何因果效应，我们仍会发现疾病表型与标记物存在之间的相关性。

使我们能够确定因果效应而非仅仅是相关性的关键洞察是：虽然基因型可能影响一个人患特定疾病的风险，但疾病不会改变一个人的基因型。这使我们能够将基因型用作甲基化的工具变量。这限制了可能模型的数量，因此我们可以在统计上检验哪个模型与观察到的数据最为一致。

对于复杂人类疾病的建模，存在三种可能性：独立关联模型、交互作用模型和因果通路模型，如图35.4所示。我们将以研究特定基因座甲基化与疾病之间的因果关系为例，来演示如何检验因果效应。

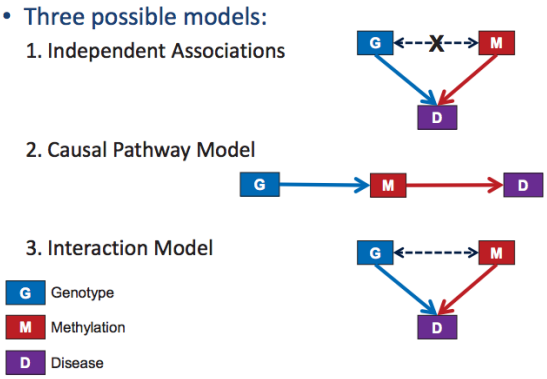

© 来源不明。保留所有权利。此内容不包含在我们的知识共享许可中。有关更多信息，请参阅 http://ocw.mit.edu/help/faq-fair-use/。

图35.4：人类疾病建模

在独立关联模型下，数据应显示基因型与疾病之间无相关性，这使该模型与交互作用模型和因果通路模型区别开来。然而，每个因素与疾病之间将分别存在相关性。因此，该模型易于检验。一个例子是两个独立的风险基因。

在交互模型中，因子B对疾病的影响可能因A的值而异。例如，一种药物对某人的效果可能因其基因型而不同。为了检验这一点，我们确定回归$D = \beta_0 A + \beta_1 B + \beta_2 A * B + c$中交互项$\beta_2$效应的统计显著性。如果存在显著的交互效应，我们可以通过按A的不同水平分层来分离各自的影响。

因果路径模型稍微复杂一些。如果我们注意到某个风险因素与某种疾病之间存在相关性，我们可能会想，风险因素A与疾病之间是否存在直接联系，还是风险因素A影响风险因素B，而B又影响疾病。在风险因素A仅通过B对疾病产生影响的情况下，我们会观察到，在对B进行条件化之后，A与D之间的相关性消失，也就是说，B“中介”了这种相互作用。在现实中，A对疾病的影响通常只部分地通过B中介，因此我们可以转而考察当观察到B时，A对疾病的效应量是否减小。

35.5.1 Polygenic Risk Prediction

个人基因组学中最核心的问题之一是利用多个基因预测各种遗传特征的遗传易感性。基本方法如图35.5所示。首先，将数据集分为训练集和测试集，在训练队列中，我们选择哪些SNP最重要及其适当的权重。然后我们使用测试集来评估我们预测的准确性。最后，我们利用从测试集中确定的置信度，使用该模型预测目标队列的遗传易感性。

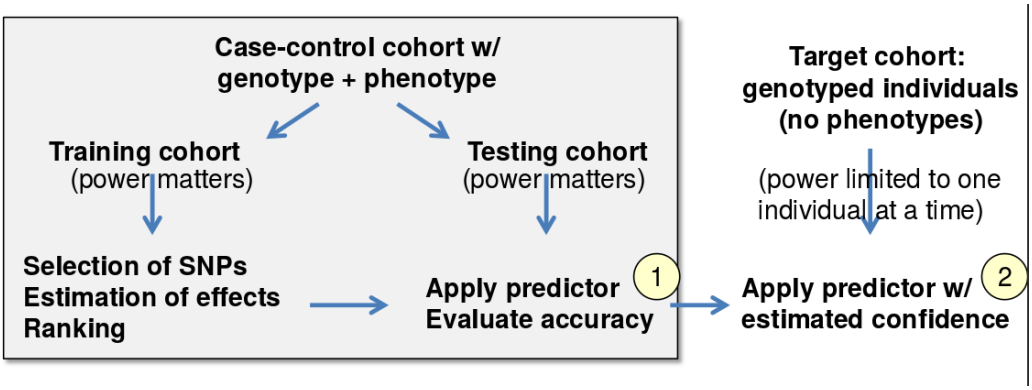

© source unknown. All rights reserved. This content is excluded from our Creative Commons license. For more information, see http://ocw.mit.edu/help/faq-fair-use/.

图35.5：多基因风险预测

35.6 Current Research Directions

35.7 Further Reading

35.8 Tools and Techniques

35.9 What Have We Learned?

在本节中，我们学习了流行病学的基础知识，包括遗传流行病学和分子流行病学。我们学习了设计流行病学实验的技术，以及如何以及何时使用遗传筛选来识别疾病。最后，我们重点讨论了使用遗传学作为工具变量来解决表观遗传标记与疾病之间的因果性与相关性问题。

Bibliography

CHAPTER

THIRTYSIX

CANCER GENOMICS

Pasha Muravyev (2014)

36.1 Introduction

什么是癌症？癌症代表一组疾病或肿瘤，它们会引发异常细胞生长，并有可能扩散到身体许多部位。癌症通常始于一个或多个“驱动基因”的突变，这些基因能够驱动肿瘤发生。这些突变被称为驱动事件，意味着它们为个体提供了选择性适应优势；其他不提供适应优势的突变被称为乘客突变。

癌症基因组学的主要目标是生成癌症基因和通路的全面目录。过去十年中，许多癌症基因组项目已经启动（主要是由于基因组测序成本的下降）；例如，癌症基因组图谱于2006年启动，旨在通过大量实验（SNP阵列、全外显子组测序、RNA测序等）分析20-25种肿瘤类型，每种类型500对肿瘤/正常样本。ICGC（国际癌症基因组联盟）是一个更大的伞式组织，在世界各地组织类似项目，最终目标是研究50种肿瘤类型，每种类型500对肿瘤/正常样本。

36.2 Characterization

对于每个肿瘤，我们的目标是获得该肿瘤的完整基础级特征描述、其演化历史以及塑造它的机制。我们可以使用$massively parallel sequencing$来获取基础级基因组特征，但这种方法也带来了一些相关的挑战。

1. 海量数据 数据量增加的主要挑战在于分析这些数据所需的计算能力增强，以及与跟踪所有已测序基因组相关的存储成本。此外，还需要一个分析流程（自动化、标准化、可重复），以确保不同表征工作之间的一致性发现。最后，我们必须想出新的方法来可视化和报告大规模数据。

2. 灵敏度 / 特异性 癌症表征始于正确识别癌细胞中存在的SNP突变，并最大限度地去除假阳性reads。在选择肿瘤样本时，提取的DNA是正常基因组和复杂肿瘤基因组的混合物。突变等位基因分数（来自一个基因座的DNA分子中携带突变的比例）用于研究突变的重要性及其在癌症亚型中的流行程度。该分数取决于肿瘤样本的纯度、局部拷贝数、多重性以及癌细胞分数（CCF，携带突变的癌细胞数量）。克隆性突变由所有癌细胞携带，而亚克隆性突变则由肿瘤细胞的一个子集携带。

除了检测克隆和亚克隆突变的存在外，正确的分析还需要去除假阳性诱变事件。两种类型的假阳性包括测序错误和种系突变。测序错误可能来自碱基误读、测序伪影和比对错误的读取，而种系突变通常发生在基因组中可预测的位置(已知1000/MB, 新发现10-20/MB)。通过对同一序列进行多次读取，测序中重复错误的可能性迅速下降，并且通过了解种系突变可能在基因组中的位置，过滤器可以校正额外的假阳性概率。检测单核苷酸变异的总体灵敏度取决于背景突变的频率和替代读取的数量。

第三种假阳性可能来自跨患者污染，如果肿瘤样本中包含了他人的DNA。ContEst是一种通过与SNP阵列比较来准确检测污染的方法。

突变调用器是一种分类器，它在每个基因组位点上询问，这里是否有突变? 这些分类器通过多种接收者操作特征（ROC）曲线进行评估，这些曲线取决于等位基因分数、肿瘤和正常样本的覆盖度以及测序和比对噪声。MuTect是一种高度敏感的体细胞突变调用器。MuTect的流程如下：将肿瘤和正常样本传入变异检测统计量（该统计量将变异模型与零假设进行比较），然后通过基于位点的过滤器（近端间隙、链偏倚、比对质量差、三-等位基因位点、聚集位置、在对照中观察到），再与正常样本面板进行比较，最后分类为候选变异。MuTect能够检测低等位基因分数的突变，因此适用于研究不纯和异质性肿瘤。

3. 发现突变过程

与其检测癌症基因中是否存在突变，另一种方法是发现癌症样本中是否存在特定的突变模式。“乐高图”是一种可视化突变模式的方式，其中每种颜色的高度表示6种碱基对替换类型的频率，并且每个频率相对于该突变可能发生的16种不同上下文（邻近核苷酸）进行绘制。每种癌症类型中特定类型的致突变事件可以被绘制并分析。例如，在食管癌中发现了一种新的突变模式（AA ¿ AC）。癌症可以根据这些特定的突变谱进行分组。使用乐高图数据的非负矩阵分解（NMF）进行降维可用于识别基本的谱特征。

4. Estimating purity, ploidy and cancer cell functions

除了检测癌细胞中的突变、去除假阳性以及检测突变模式外，还需要对每个肿瘤样本进行恰当的表征。由于异质性和样本杂质，为获得突变等位基因的正确总数和流行率，需要估计所测序肿瘤样本的纯度、绝对拷贝数和癌细胞分数（CCF）。

5. 肿瘤异质性与演化
   样本可能具有大量的点突变和拷贝数改变分布，但贝叶斯聚类算法可以帮助识别不同亚群中的突变和拷贝数改变。

36.3 Interpretation

解读测序结果的根本挑战在于区分驱动突变和乘客突变。为了实现这一点，我们需要对分析的序列的背景突变过程进行建模，并识别出比仅由背景模型预测的突变更多的通路/区域。这些区域随后成为我们的候选癌症基因。

然而，我们可能遇到选择错误背景模型的问题，或者在突变调用中遇到系统性伪影。在这种情况下，我们必须回到起点，尝试提出一个更好的背景模型，然后才能继续进行候选基因识别。

许多工具已被开发出来，旨在准确检测候选癌症基因和通路（子网络），包括NetSig、GISTIC和MutSig。NetSig用于识别蛋白质-蛋白质相互作用网络中突变基因的聚类。GISTIC可根据拷贝数事件的频率和幅度对区域进行评分。MutSig：用于根据突变的数量和类型对基因进行评分。寻找候选癌症基因的主要分析步骤包括：1) 估计背景突变率（该率在不同样本间有所变化），2) 基于统计模型计算p值，以及3) 对多重假设检验（N个基因）进行校正。

随着样本量和/或突变率的增加，癌症基因的重要基因列表增加，并包含许多可疑基因。减少可疑基因的一个重大突破是适当建模背景突变。标准工具使用一致的背景速率（CpG、C/G、A/T、indel的速率），而忽略了样本间的异质性、额外的序列上下文和基因组。但研究发现，癌症中的突变率变化达1000倍，高表达基因中的突变率较低，且体细胞突变的频率与DNA复制时间相关。基因组中复制较晚的区域比早期分裂的区域有更多突变。MutSigCV是一个校正背景突变率变异的工具。

36.4 Current Research Directions

当前癌症基因库中存在一些空白，包括那些出现在基因间区域的基因。为了发现更多的非编码突变，泛癌突变的分类被认为是必要的。

36.5 Further Reading

1. http://www.broadinstitute.org/cancer/cga/mutect 2. http://ww
w.broadinstitute.org/cancer/cga/ABSOLUTE

36.6 Tools and Techniques

36.7 What Have We Learned?

在过去十年中，测序成本的下降导致了对自动化分析流程以及更强大的计算和存储能力的需求，以应对由众多并行测序工作所产生的海量数据洪流。未来癌症基因组项目的两大任务大致可归类为两个领域：特征描述和解释。

在特征描述方面，似乎仍需要对分析方法进行系统性的基准测试（一个例子是ROC曲线——展示分类器在不同判别阈值下性能的曲线）。我们发现，不同肿瘤类型之间的癌症突变率往往相差超过1000倍。我们还了解到，克隆突变和亚克隆突变可用于研究肿瘤进化和异质性。

对测序结果进行显著性分析后，发现显著突变基因呈现长尾分布。由于我们所面对的是长尾分布，通过整合多种证据来源，我们可以提升模型的预测能力，并识别出更多的癌症基因。然而，我们必须考虑到，突变率会根据原始样本、基因以及每项研究中的类别有所不同。

Bibliography

CHAPTER

THIRTYSEVEN

GENOME EDITING

37.1 Introduction

37.1.1 What is CRISPR/Cas?

CRISPR/Cas系统是原核生物的免疫系统。当病毒或其他外来入侵者试图感染原核细胞并将其自身的DNA注入原核生物的基因组时，原核生物的CRISPR/Cas系统负责移除这些外来DNA。它是如何做到这一点的呢？CRISPR/Cas系统由两部分组成：CRISPR和Cas。CRISPR部分（CRISPR阵列）负责“记忆”外来DNA，而Cas部分（Cas蛋白）则负责剪切识别出的外来DNA。CRISPR阵列由短间隔DNA片段组成，这些片段是先前接触外来DNA的结果。这些间隔DNA被转录为RNA，可用于与构建该间隔DNA的外来DNA进行匹配。随后，这些RNA被Cas蛋白拾取。当Cas蛋白拾取特定的RNA后，它便对匹配的DNA序列变得敏感。下一次相同的外来DNA被插入原核生物时，对其敏感的Cas蛋白会与外来DNA匹配并将其从基因组中剪切掉，使其失活。

37.1.2 Why is CRISPR/Cas important to us?

因为大自然赋予了我们一种有效的基因组编辑方法！为了精确编辑基因组，能够在目标位置精确切割序列至关重要。一旦进行切割，修复机制就可以介入并在目标位点进行修改。CRISPR/Cas系统是一种自然存在且经过时间考验的对DNA序列进行改变的方法。

目前，研究人员扰动和探究基因组的能力落后于当前水平

在阅读技术方面。CRISPR提供了一种有效的方式来编写我们能够阅读的基因组，使我们能够确定遗传密码中的哪些变异导致了感兴趣的疾病。

37.1.3 Cas-9

CRISPR/Cas-9系统是一个特别受关注的系统。Cas-9是一种内切酶，能够在特定的靶位点进行切割，从而触发基因修复，这一过程由20个核苷酸的sgRNA引导。当发现与引导sgRNA互补的靶位点，并且其后跟随一个NGG PAM区域时，Cas-9蛋白将在该靶位点切割DNA。通过使用特定的sgRNA编程Cas-9，可以使其在特定目标处产生双链断裂，而PAM区域则在防止针对自身基因组方面发挥作用。已证明Cas-9在靶向效率上远超许多传统方法。遗憾的是，Cas-9的一个缺点在于它可能在并非完全与RNA引导序列互补的脱靶位点进行切割，这为精确的基因组编辑带来了挑战。

37.2 Current Research Directions

37.2.1 Improvement of Cas-9

最近的研究产生了 Cas-9 的一种变体，它极大地提高了 Cas-9 的特异性，降低了脱靶错误的可能性。

37.2.2 Current research being done with CRISPR/Cas-9

最近Cas-9的改进开辟了新的研究途径。例如，可以利用CRISPR/Cas-9仅移除特定基因并观察移除后的效果，以此分析该基因的功能。这种方法的一个应用实例是对黑色素瘤癌细胞的研究。

维莫非尼是一种经FDA批准用于治疗黑色素瘤的药物，已证明对具有V600E BRAF突变的黑色素瘤细胞有效，其作用机制是通过干扰BRAF通路并诱导程序性细胞死亡。

不幸的是，在许多情况下，癌症会通过创建替代的生存途径而对药物产生抗性。CRISPR/Cas-9可用于确定使癌细胞能够发展替代途径的基因。通过将Cas-9蛋白编程为单独靶向每个基因，并标记这些蛋白以便确定哪个蛋白影响了哪个细胞，就有可能确定生存所必需的基因。

37.3 Further Reading

37.4 Tools and Techniques

37.5 What Have We Learned?

CRISPR/Cas-9在DNA中产生双链断裂，并有两个主要组成部分：

20bp DNA

PAM

Bibliography

MIT OpenCourseWare
http://ocw.mit.edu

6.047 Computational Biology
Fall 2015

For information about citing these materials or our Terms of Use, visit: http://ocw.mit.edu/terms.